


# 计算与应用数学博士资格考试复习讲义

作者：藤藤蛇擅长找东西

# 目录

|                                                  |    |
|--------------------------------------------------|----|
| 第一部分 数值分析基础与逼近                                   | 37 |
| 第一章 多项式插值、Chebyshev 逼近、三角插值与谱微分                  | 38 |
| 1.1 多项式插值的统一框架：存在唯一性、Lagrange 形式与 Newton 公式      | 38 |
| 1.1.1 知识点一：插值问题、Vandermonde 系统与唯一性               | 38 |
| 1.1.2 知识点二：Newton 差商（牛顿公式）、增量插值与嵌套求值             | 40 |
| 1.2 插值余项、Lebesgue 常数、Runge 现象与节点稳定性              | 41 |
| 1.2.1 知识点三：Lagrange 余项与误差成立条件                    | 41 |
| 1.2.2 补充训练题：丘赛 2020 Problem 1——局部多项式近似向相邻单元延拓    | 42 |
| 1.2.3 知识点四：Lebesgue 常数、数据扰动与 Runge 现象            | 43 |
| 1.3 Chebyshev 多项式、节点与极值性质                        | 44 |
| 1.3.1 知识点五：Chebyshev 结构与极小极大证明套路                 | 44 |
| 1.3.2 补充训练题：丘赛 2021 Problem 1——Chebyshev 极值与插值误差 | 46 |
| 1.3.3 正式真题 [24F-Q1]——切比雪夫多项式                     | 46 |
| 1.3.4 正式真题 [25F-Q2]——切比雪夫多项式性质                   | 47 |
| 1.4 重心插值：稳定求值与复杂度                                | 48 |
| 1.4.1 知识点六：第一、第二重心公式                             | 48 |
| 1.5 Hermite 插值与重节点差商                             | 49 |
| 1.5.1 知识点七：函数值与导数值的联合插值                          | 49 |
| 1.6 三角插值、DFT、FFT、混叠与谱精度                          | 50 |
| 1.6.1 知识点八：周期等距节点上的三角插值                          | 50 |
| 1.6.2 补充训练题：[NLA-Set] 中的离散 Fourier 不确定性原理        | 52 |
| 1.7 数值微分：差分构造、Richardson 外推与非均匀网格                | 52 |
| 1.7.1 知识点九：Taylor 矩条件与高阶差分                       | 52 |
| 1.7.2 Richardson 外推                              | 54 |
| 1.7.3 非均匀三点一阶导数公式                                | 54 |
| 1.7.4 补充训练题：丘赛 2023 Problem 1——差分与外推             | 54 |
| 1.8 谱微分：插值求导矩阵、Fourier 微分与 Chebyshev 微分          | 55 |
| 1.8.1 知识点十：一般插值微分矩阵                              | 55 |
| 1.8.2 Fourier 谱微分矩阵的显式形式                         | 56 |
| 1.8.3 正式真题 [23F-Q3]——Lagrange 基函数                | 56 |




|                                                                 |    |
|-----------------------------------------------------------------|----|
| 第二章 分段插值、样条、有理逼近、最佳逼近与正交多项式                                     | 58 |
| 2.1 分段低次插值：局部性、稳定性与误差阶                                          | 58 |
| 2.1.1 知识点一：分段线性插值                                               | 58 |
| 2.1.2 知识点二：分段三次 Hermite 插值                                      | 59 |
| 2.2 三次样条插值：构造、边界条件、唯一性与误差                                       | 60 |
| 2.2.1 知识点三：样条空间及自由度计数                                           | 60 |
| 2.2.2 知识点四：三弯矩方程                                                | 61 |
| 2.2.3 知识点五：自然样条的变分刻画                                            | 62 |
| 2.2.4 知识点六：样条误差估计及边界失配                                          | 63 |
| 2.2.5 补充训练题：丘赛 2021 Problem 2——三次样条的线性传播                        | 63 |
| 2.2.6 知识点七：B 样条的基本概念                                            | 64 |
| 2.3 有理插值与 Padé 逼近                                               | 64 |
| 2.3.1 知识点八：有理插值                                                 | 64 |
| 2.3.2 知识点九：Padé 逼近                                              | 65 |
| 2.4 内积空间中的最佳逼近与正交投影                                             | 66 |
| 2.4.1 知识点十：投影定理与 Gram 方程                                        | 66 |
| 2.5 离散最小二乘、法方程、QR 与 SVD                                         | 68 |
| 2.5.1 法方程                                                       | 68 |
| 2.5.2 QR 与 SVD 的角色                                              | 68 |
| 2.6 最佳一致逼近与等振荡                                                  | 69 |
| 2.6.1 知识点十一：Chebyshev 等振荡定理                                     | 69 |
| 2.6.2 补充训练题：丘赛 2020 Problem 6——单首一矩阵多项式最优解的唯一性                  | 70 |
| 2.7 正交多项式：三项递推、零点与 Christoffel–Darboux 核                        | 71 |
| 2.7.1 知识点十二：正交多项式的一般结构                                          | 71 |
| 2.7.2 Christoffel–Darboux 核                                     | 72 |
| 2.7.3 补充训练题：丘赛 2022 Problem 1——节点值型标准正交基                        | 72 |
| 2.7.4 补充训练题：丘赛 2025 Problem 3——伴随 Legendre 函数的插值与最小二乘           | 73 |
| 2.8 正式真题 [26S–Q2]——正交多项式与最佳逼近                                   | 74 |
| 第三章 数值积分 I——插值型求积、Newton–Cotes、复合求积、Euler–Maclaurin 公式与 Romberg | 77 |
| 3.1 一般求积公式：节点、权重、插值型求积与代数精度                                     | 77 |
| 3.1.1 知识点一：一般线性求积公式                                             | 77 |
| 3.1.2 知识点二：插值型求积公式                                              | 78 |
| 3.1.3 节点多项式与额外代数精度                                              | 79 |
| 3.1.4 培训讲义完整例题：最大化求积公式的代数精度                                     | 80 |
| 3.2 Newton–Cotes 公式：开型、闭型、对称性与高阶失稳                              | 81 |
| 3.2.1 知识点三：闭型与开型 Newton–Cotes                                   | 81 |
| 3.2.2 Newton–Cotes 的对称性                                         | 81 |

|                                                                           |                                                     |           |
|---------------------------------------------------------------------------|-----------------------------------------------------|-----------|
| 3.2.3                                                                     | 高阶 Newton–Cotes 的稳定性问题                              | 82        |
| 3.3                                                                       | 求积误差：插值余项、Peano 核与误差常数                              | 82        |
| 3.3.1                                                                     | 知识点四：从插值余项到求积误差                                     | 82        |
| 3.3.2                                                                     | 知识点五：Peano 核定理                                      | 83        |
| 3.3.3                                                                     | 中点、梯形与 Simpson 的 Peano 核                            | 84        |
| 3.4                                                                       | 复合求积：局部误差累积、非均匀剖分与复杂度                               | 85        |
| 3.4.1                                                                     | 知识点六：复合中点、梯形与单元 Simpson 公式                          | 85        |
| 3.4.2                                                                     | 经典复合 Simpson 公式的步长约定                                | 85        |
| 3.4.3                                                                     | 复合梯形公式的递推更新                                         | 86        |
| 3.5                                                                       | Euler–Maclaurin 公式与周期梯形公式                           | 87        |
| 3.5.1                                                                     | 知识点七：Bernoulli 数与 Bernoulli 多项式                     | 87        |
| 3.5.2                                                                     | Euler–Maclaurin 展开                                  | 87        |
| 3.5.3                                                                     | 端点修正梯形公式                                            | 88        |
| 3.5.4                                                                     | 周期光滑函数的任意代数阶收敛                                      | 88        |
| 3.5.5                                                                     | 解析周期函数的指数收敛                                         | 88        |
| 3.6                                                                       | Richardson 外推与 Romberg 积分                           | 89        |
| 3.6.1                                                                     | 知识点八：一般 Richardson 外推                               | 89        |
| 3.6.2                                                                     | 梯形公式外推与 Simpson 公式                                  | 90        |
| 3.6.3                                                                     | Romberg 递推                                          | 90        |
| 3.7                                                                       | 正式真题 [25S–Q1]——周期梯形公式的高阶与指数收敛                       | 91        |
| 3.8                                                                       | 补充训练题：丘赛 2024 Problem 2——无穷区间积分、截断误差与变量代换           | 92        |
| <b>第四章 数值积分 II——Gauss 求积、Clenshaw–Curtis、自适应求积、奇异积分、多维积分与 Monte Carlo</b> |                                                     | <b>96</b> |
| 4.1                                                                       | Gauss 求积的一般理论                                       | 96        |
| 4.1.1                                                                     | 知识点一：加权积分、节点选择与最高代数精度                               | 96        |
| 4.1.2                                                                     | 知识点二：Gauss 权重的正性与显式表示                               | 97        |
| 4.1.3                                                                     | 知识点三：Gauss 误差公式                                     | 97        |
| 4.1.4                                                                     | Gauss 求积对连续函数的收敛                                    | 98        |
| 4.2                                                                       | 三项递推、Jacobi 矩阵与 Golub–Welsch 算法                     | 99        |
| 4.2.1                                                                     | 知识点四：标准正交多项式递推                                      | 99        |
| 4.2.2                                                                     | 权重与特征向量                                             | 99        |
| 4.2.3                                                                     | 常用 Gauss 求积族                                        | 100       |
| 4.3                                                                       | 补充训练题：丘赛 2023 Problem 2——对数权 Gauss 求积与 Jacobi 矩阵    | 101       |
| 4.4                                                                       | 正式真题 [25F–Q2(d)]——Gauss–Chebyshev 求积                | 103       |
| 4.5                                                                       | 正式真题 [26S–Q2(d)]——Gauss–Legendre 求积                 | 104       |
| 4.6                                                                       | 补充训练题：丘赛 2024 Problem 3——第二类 Chebyshev 与二点 Gauss 求积 | 106       |
| 4.7                                                                       | Clenshaw–Curtis 求积                                  | 107       |
| 4.7.1                                                                     | 知识点五：定义、节点与 Chebyshev 系数积分                          | 107       |



|                                                  |                                      |            |
|--------------------------------------------------|--------------------------------------|------------|
| 4.7.2                                            | Clenshaw–Curtis 显式权重                 | 108        |
| 4.7.3                                            | 收敛性与 Gauss–Legendre 比较               | 108        |
| 4.8                                              | 自适应求积与局部误差控制                         | 109        |
| 4.8.1                                            | 知识点六：局部细分与容差分配                       | 109        |
| 4.8.2                                            | 自适应 Simpson 的误差估计                    | 110        |
| 4.8.3                                            | Gauss–Kronrod 误差对                    | 110        |
| 4.9                                              | 弱奇异、近奇异与振荡积分                         | 111        |
| 4.9.1                                            | 知识点七：弱奇异积分的分类                        | 111        |
| 4.9.2                                            | 方法一：幂次变量代换                           | 111        |
| 4.9.3                                            | 方法二：加权 Gauss–Jacobi 求积               | 111        |
| 4.9.4                                            | 方法三：奇异项减除                            | 111        |
| 4.9.5                                            | 近奇异积分                                | 111        |
| 4.9.6                                            | 知识点八：振荡积分                            | 112        |
| 4.10                                             | 多维数值积分、张量积与稀疏网格                      | 113        |
| 4.10.1                                           | 知识点九：张量积公式                           | 113        |
| 4.10.2                                           | 稀疏网格与 Smolyak 思想                     | 113        |
| 4.11                                             | Monte Carlo 积分、置信区间与方差缩减             | 113        |
| 4.11.1                                           | 知识点十：基本 Monte Carlo 积分               | 113        |
| 4.11.2                                           | 中心极限定理与置信区间                          | 114        |
| 4.11.3                                           | 知识点十一：重要抽样                           | 115        |
| 4.11.4                                           | 其他方差缩减方法                             | 116        |
| 4.12                                             | 模块一正式真题映射与得分母题                       | 116        |
| 4.12.1                                           | 正式出现情况                               | 117        |
| <b>第二部分 非线性方程与常微分方程</b>                          |                                      | <b>118</b> |
| <b>第五章 标量非线性方程、二分法、不动点迭代、Newton 法、割线法、重根与收敛阶</b> |                                      | <b>119</b> |
| 5.1                                              | 标量非线性方程的统一框架                         | 119        |
| 5.1.1                                            | 知识点一：问题、根的重数与算法输出                    | 119        |
| 5.1.2                                            | 知识点二：收敛阶、超线性与渐近误差常数                  | 120        |
| 5.1.3                                            | 知识点三：根的条件数                           | 121        |
| 5.1.4                                            | 标量求根方法的局部比较                          | 121        |
| 5.2                                              | 二分法：存在性、误差证书与复杂度                     | 122        |
| 5.2.1                                            | 知识点四：二分法的完整算法                        | 122        |
| 5.3                                              | 不动点迭代与压缩映射                           | 124        |
| 5.3.1                                            | 知识点五：方程改写与压缩映射                       | 124        |
| 5.3.2                                            | 一维局部判据与迭代行为                          | 125        |
| 5.4                                              | 补充训练题：丘赛 2021 Problem 3——全局压缩迭代与迭代次数 | 125        |
| 5.5                                              | Newton 法：局部二次收敛、初值选择与全局化             | 126        |

|        |                                                  |     |
|--------|--------------------------------------------------|-----|
| 5.5.1  | 知识点六: Newton 线性化与纯 Newton 算法                     | 126 |
| 5.5.2  | Newton 局部二次收敛定理                                  | 127 |
| 5.5.3  | 简化 Newton 法                                      | 128 |
| 5.5.4  | 阻尼 Newton 与线搜索                                   | 128 |
| 5.5.5  | 二分-Newton 混合全局化                                  | 128 |
| 5.6    | 正式真题 [24F-Q3]——Kepler 方程、全局不动点与单调 Newton 法       | 129 |
| 5.7    | 割线法: 差商近似、误差方程与黄金分割阶                             | 130 |
| 5.7.1  | 知识点七: 割线法的构造                                     | 130 |
| 5.7.2  | 割线法的精确误差恒等式                                      | 131 |
| 5.7.3  | 局部收敛证明                                           | 131 |
| 5.7.4  | 黄金分割收敛阶                                          | 132 |
| 5.8    | 正式真题 [23F-Q1]——Newton 法与割线法误差极限                  | 132 |
| 5.9    | 补充训练题: 丘赛 2020 Problem 2——固定锚点弦截迭代               | 133 |
| 5.10   | 正式真题 [26S-Q1]——自适应差分 Newton 型迭代                  | 133 |
| 5.11   | 重根、修正 Newton 法与未知重数加速                            | 135 |
| 5.11.1 | 知识点八: 普通 Newton 法在重根处退化为线性收敛                     | 135 |
| 5.11.2 | 已知重数的修正 Newton 法                                 | 135 |
| 5.11.3 | 未知重数时的自适应 Newton 法                               | 136 |
| 5.12   | 正式真题 [25S-Q2]——简单根、重根与未知重数加速                     | 136 |
| 5.13   | 补充训练题: 丘赛 2025 Problem 1——两参数多点 Newton 型方法的最高阶   | 137 |
| 第六章    | 非线性方程组、拟 Newton、Broyden、同伦、延拓与多项式求根              | 140 |
| 6.1    | 非线性方程组的统一框架: Jacobian、正则根与条件数                    | 140 |
| 6.1.1  | 知识点一: 问题、对象空间与正则根                                | 140 |
| 6.1.2  | 知识点二: 向量不动点迭代                                    | 141 |
| 6.1.3  | 知识点三: 非线性 Jacobi 型与 Gauss-Seidel 型迭代             | 142 |
| 6.2    | 补充训练题: 丘赛 2022 Problem 2——二维 Gauss-Seidel 型固定点迭代 | 143 |
| 6.3    | 非线性方程组的 Newton 法                                 | 144 |
| 6.3.1  | 知识点四: Jacobian 线性化与 Newton 步                     | 144 |
| 6.3.2  | 知识点五: 局部二次收敛                                     | 145 |
| 6.3.3  | 知识点六: Kantorovich 型半局部条件                         | 146 |
| 6.3.4  | 知识点七: 阻尼 Newton 与线搜索                             | 147 |
| 6.3.5  | 基础例题: 圆与直线交点的 Newton 迭代                          | 148 |
| 6.4    | 拟 Newton 方法与 Broyden 更新                          | 149 |
| 6.4.1  | 知识点八: 拟 Newton 框架与割线条件                           | 149 |
| 6.4.2  | 知识点九: 良 Broyden 更新的最小改动推导                        | 149 |
| 6.4.3  | 逆 Jacobian 的秩一更新                                 | 149 |
| 6.4.4  | 知识点十: 超线性收敛与 Dennis-Moré 条件                      | 150 |
| 6.4.5  | Broyden 与有限差分 Jacobian 的比较                       | 151 |




|       |                                               |     |
|-------|-----------------------------------------------|-----|
| 6.4.6 | 基础例题：验证良 Broyden 的割线条件                        | 152 |
| 6.4.7 | 综合例题：Broyden 法求圆与直线交点                         | 152 |
| 6.5   | 求根同伦与参数延拓                                     | 153 |
| 6.5.1 | 知识点十一：基本同伦构造                                  | 153 |
| 6.5.2 | 预测-校正算法                                       | 153 |
| 6.5.3 | 知识点十二：伪弧长延拓                                   | 154 |
| 6.5.4 | 综合例题：三次方程的同伦跟踪                                | 155 |
| 6.6   | 多项式求根：Horner、Newton-Horner 与降次                | 155 |
| 6.6.1 | 知识点十三：Horner 嵌套乘法                             | 155 |
| 6.6.2 | 知识点十四：Newton-Horner 法                         | 156 |
| 6.6.3 | 知识点十五：综合除法与降次                                 | 157 |
| 6.7   | 多项式根的敏感性与伴随矩阵                                 | 158 |
| 6.7.1 | 知识点十六：系数扰动与根条件数                               | 158 |
| 6.7.2 | 知识点十七：Frobenius 伴随矩阵                          | 158 |
| 6.8   | Bairstow 法：实系数多项式的共轭根对                        | 160 |
| 6.8.1 | 知识点十八：二次因子与综合除法                               | 160 |
| 6.8.2 | 导数递推与二维 Newton 校正                             | 160 |
| 6.8.3 | 综合例题：求 $z^4 + 5z^2 + 4$ 的复共轭因子                | 162 |
| 第七章   | ODE 适定性、单步法、Euler、梯形、Runge-Kutta 及局部与整体误差     | 164 |
| 7.1   | 常微分方程初值问题的适定性                                 | 164 |
| 7.1.1 | 知识点一：初值问题、解流与适定性                              | 164 |
| 7.1.2 | 知识点二：初值和右端项扰动的连续依赖                            | 165 |
| 7.2   | 离散 Gronwall 不等式与单步法统一误差分析                     | 166 |
| 7.2.1 | 知识点三：离散 Gronwall 不等式                          | 166 |
| 7.2.2 | 知识点四：单步法、局部缺陷与整体误差                            | 166 |
| 7.2.3 | 知识点五：扰动稳定性                                    | 168 |
| 7.3   | Euler 方法、梯形法与二阶基本单步格式                         | 168 |
| 7.3.1 | 知识点六：前向 Euler 方法                              | 168 |
| 7.3.2 | 知识点七：后向 Euler 方法                              | 169 |
| 7.3.3 | 知识点八：隐式梯形方法                                   | 170 |
| 7.3.4 | 知识点九：显式梯形、显式中点与隐式中点                           | 171 |
| 7.4   | Runge-Kutta 方法的统一表示与阶条件                       | 172 |
| 7.4.1 | 知识点十：Butcher 表与阶段方程                           | 172 |
| 7.4.2 | 知识点十一：二阶段显式 RK 方法的阶条件                         | 173 |
| 7.4.3 | 知识点十二：一般 RK 阶条件                               | 173 |
| 7.4.4 | 知识点十三：经典四阶 Runge-Kutta 方法                     | 174 |
| 7.4.5 | 知识点十四：RK 稳定函数                                 | 174 |
| 7.5   | 补充训练题：丘赛 2021 Problem 5——半隐式二阶段 Runge-Kutta 族 | 175 |

|       |                                         |     |
|-------|-----------------------------------------|-----|
| 7.6   | 补充训练题：丘赛 2022 Problem 4——最优二阶段二阶 SSP 方法 | 176 |
| 7.7   | 补充训练题：丘赛 2023 Problem 4——三参数二阶段单步法      | 179 |
| 7.8   | 正式真题 [23F-Q4]——显式梯形 Runge-Kutta 方法      | 180 |
| 7.9   | 舍入误差、计算复杂度与失败诊断                         | 183 |
| 7.9.1 | 知识点十五：截断误差与舍入误差的平衡                      | 183 |
| 7.9.2 | 知识点十六：显式与隐式 RK 的成本                      | 183 |
| 7.9.3 | 知识点十七：隐式时间步的 Newton 求解                  | 184 |
| 第八章   | 线性多步法、零稳定性、根条件、Dahlquist 等价定理与绝对稳定性     | 186 |
| 8.1   | 线性多步法的统一形式与基本对象                         | 186 |
| 8.1.1 | 知识点一：一般线性多步格式                           | 186 |
| 8.1.2 | 知识点二：第一与第二特征多项式                         | 187 |
| 8.2   | 局部截断误差、相容性与阶条件                          | 188 |
| 8.2.1 | 知识点三：未归一化局部缺陷与归一化截断误差                   | 188 |
| 8.2.2 | 知识点四：线性多步法的阶条件                          | 188 |
| 8.3   | Adams 方法、BDF 方法与预测-校正                   | 190 |
| 8.3.1 | 知识点五：Adams-Bashforth 方法                 | 190 |
| 8.3.2 | 知识点六：Adams-Moulton 方法                   | 191 |
| 8.3.3 | 知识点七：后向差分公式 BDF                         | 191 |
| 8.3.4 | 知识点八：预测-校正方法                            | 192 |
| 8.3.5 | 知识点九：起步方法                               | 193 |
| 8.4   | 线性差分方程、根条件与零稳定性                         | 194 |
| 8.4.1 | 知识点十：齐次线性差分方程的解结构                       | 194 |
| 8.4.2 | 知识点十一：根条件                               | 194 |
| 8.4.3 | 知识点十二：非齐次差分方程的稳定估计                      | 195 |
| 8.4.4 | 知识点十三：零稳定性的定义                           | 195 |
| 8.5   | Dahlquist 等价定理与阶障碍                      | 197 |
| 8.5.1 | 知识点十四：Dahlquist 等价定理                    | 197 |
| 8.5.2 | 知识点十五：Dahlquist 第一障碍                    | 198 |
| 8.5.3 | 知识点十六：Dahlquist 第二障碍                    | 198 |
| 8.6   | 绝对稳定性、绝对根条件与边界轨迹                        | 199 |
| 8.6.1 | 知识点十七：测试方程与绝对特征多项式                      | 199 |
| 8.6.2 | 知识点十八：多步法不能只写一个稳定函数                     | 199 |
| 8.6.3 | 知识点十九：边界轨迹法                             | 200 |
| 8.6.4 | 知识点二十：A 稳定与 $A(\alpha)$ 稳定              | 200 |
| 8.6.5 | 基础例题：AB2 的负实轴稳定区间                       | 201 |
| 8.6.6 | 基础例题：梯形法的 A 稳定性                         | 201 |
| 8.7   | 易错点与失败情形：线性多步法                          | 202 |
| 8.8   | 补充训练题：丘赛 2020 Problem 4——BDF2 型隐式二步法    | 202 |




|                                                      |     |
|------------------------------------------------------|-----|
| 第九章 刚性问题、 $A/L$ 稳定、自适应步长、隐式求解、边值问题扩展与模块二真题映射         | 207 |
| 9.1 刚性初值问题：识别信号、时间尺度与步长限制                            | 207 |
| 9.1.1 知识点一：刚性不是单纯的“解变化快”                             | 207 |
| 9.1.2 知识点二：显式方法的稳定步长                                 | 208 |
| 9.1.3 知识点三：半离散 PDE 为何产生刚性 ODE                        | 208 |
| 9.2 $A$ 稳定、 $L$ 稳定与 $A(\alpha)$ 稳定                   | 209 |
| 9.2.1 知识点四：稳定函数与 $A$ 稳定性                             | 209 |
| 9.2.2 知识点五： $L$ 稳定性                                  | 209 |
| 9.2.3 知识点六： $A(\alpha)$ 稳定                           | 210 |
| 9.2.4 知识点七：典型隐式 Runge–Kutta 方法                       | 210 |
| 9.3 补充训练题：丘赛 2026 Problem 3—— $\theta$ 方法的阶与 $A$ 稳定性 | 211 |
| 9.4 补充训练题：丘赛 2025 Problem 6——刚性二维系统                  | 213 |
| 9.5 自适应步长与局部误差控制                                     | 216 |
| 9.5.1 知识点八：自适应步长的基本目标                                | 216 |
| 9.5.2 知识点九：嵌入式 Runge–Kutta 对                         | 216 |
| 9.5.3 知识点十：加权误差范数                                    | 217 |
| 9.5.4 知识点十一：步长更新公式                                   | 217 |
| 9.5.5 知识点十二：步长加倍                                     | 218 |
| 9.6 隐式时间步的非线性求解与容差协调                                 | 219 |
| 9.6.1 知识点十三： $\theta$ 方法的非线性方程                       | 219 |
| 9.6.2 知识点十四：简化 Newton、Jacobian 复用与线性求解               | 220 |
| 9.6.3 知识点十五：非线性求解误差必须小于时间离散误差                        | 221 |
| 9.6.4 知识点十六：隐式方法失败诊断                                 | 221 |
| 9.7 两点边值问题：打靶法、差分法与配点法                               | 222 |
| 9.7.1 知识点十七：一般两点边值问题                                 | 222 |
| 9.7.2 知识点十八：标量打靶法                                    | 222 |
| 9.7.3 知识点十九：打靶法失败与多重打靶                               | 223 |
| 9.7.4 知识点二十：有限差分与配点法                                 | 224 |
| 9.8 补充训练题：丘赛 2024 Problem 4——保守有限差分与特征值圆盘            | 224 |
| 9.9 模块二易错点与易混概念                                      | 227 |
| 第三部分 数值线性代数                                          | 229 |
| 第十章 矩阵范数、条件数、扰动、残差、后向误差与矩阵分析基础                       | 230 |
| 10.1 矩阵空间、复内积、酉变换与 Schur 分解                          | 230 |
| 10.1.1 知识点一：对象空间与统一符号                                | 230 |
| 10.1.2 知识点二：Schur 分解                                 | 231 |
| 10.1.3 知识点三：正规、Hermitian 与正定矩阵                       | 232 |
| 10.2 向量范数、从属矩阵范数与 Frobenius 范数                       | 233 |




|                                                      |            |
|------------------------------------------------------|------------|
| 10.2.1 知识点四：向量范数与对偶范数                                | 233        |
| 10.2.2 知识点五：从属矩阵范数                                   | 233        |
| 10.2.3 知识点六：Frobenius 范数                             | 234        |
| 10.3 谱半径、矩阵幂、Neumann 级数与数值域                          | 235        |
| 10.3.1 知识点七：谱半径                                      | 235        |
| 10.3.2 知识点八：数值域与数值半径                                 | 235        |
| 10.4 条件数：矩阵-向量乘法与线性方程组                               | 236        |
| 10.4.1 知识点九：矩阵-向量乘法的局部条件数                            | 236        |
| 10.4.2 知识点十：矩阵条件数                                    | 237        |
| 10.4.3 知识点十一：求解映射的实际条件数                              | 237        |
| 10.4.4 知识点十二：正规方程导致条件数平方                             | 237        |
| 10.5 线性方程组扰动分析                                       | 238        |
| 10.5.1 知识点十三：只扰动右端项                                  | 238        |
| 10.5.2 知识点十四：Banach 扰动引理                             | 238        |
| 10.5.3 知识点十五：同时扰动系数矩阵和右端项                            | 238        |
| 10.5.4 知识点十六：逆矩阵的扰动                                  | 239        |
| 10.6 残差、前向误差与后向误差                                    | 239        |
| 10.6.1 知识点十七：残差与真实误差                                 | 239        |
| 10.6.2 知识点十八：只扰动右端项的后向误差                             | 240        |
| 10.6.3 知识点十九：只扰动矩阵的后向误差                              | 240        |
| 10.6.4 知识点二十：同时扰动矩阵和右端项                              | 240        |
| 10.6.5 知识点二十一：分量后向误差                                 | 241        |
| 10.6.6 知识点二十二：后向稳定性与前向误差                             | 241        |
| 10.7 奇异值、秩亏距离与特征值扰动                                  | 242        |
| 10.7.1 知识点二十三：到奇异矩阵集合的距离                             | 242        |
| 10.7.2 知识点二十四：奇异值扰动                                  | 242        |
| 10.7.3 补充训练题：由 Hoffman-Wielandt 推出 Mirsky 不等式        | 242        |
| 10.7.4 知识点二十五：Hermitian 特征值扰动                        | 243        |
| 10.7.5 知识点二十六：Bauer-Fike 定理                          | 243        |
| 10.7.6 知识点二十七：简单特征值的局部条件数                            | 244        |
| 10.7.7 知识点二十八：特征向量与谱间隙                               | 244        |
| 10.8 正式真题 [25F-Q1]——Newton-Schulz 矩阵求逆迭代             | 244        |
| 10.9 正式真题 [24S-Q3]——Hilbert 矩阵                       | 247        |
| 10.10 补充训练题：奇偶结构矩阵的范数与矩阵级数                           | 250        |
| 10.11 补充训练题：递推矩阵的显式逆与条件数                             | 251        |
| 10.12 补充训练题：循环双对角矩阵的统一可逆界                            | 253        |
| <b>第十一章 Gaussian 消元、LU/PLU、Cholesky、QR、最小二乘与舍入误差</b> | <b>255</b> |
| 11.1 直接法统一框架与三角方程求解                                  | 255        |

|                                              |     |
|----------------------------------------------|-----|
| 11.1.1 知识点一：直接法的输入、输出与基本路线                   | 255 |
| 11.1.2 知识点二：前代与回代                            | 255 |
| 11.1.3 知识点三：三角求解的后向稳定性                       | 256 |
| 11.2 Gaussian 消元与 LU 分解                      | 257 |
| 11.2.1 知识点四：一步消元与消元矩阵                        | 257 |
| 11.2.2 知识点五：LU 存在唯一性                         | 258 |
| 11.2.3 知识点六：Doolittle 递推公式                   | 258 |
| 11.2.4 基础例题：无选主元消元为何会数值失败                    | 259 |
| 11.3 选主元、PLU 分解、增长因子与稳定性                     | 260 |
| 11.3.1 知识点七：部分选主元与完全选主元                      | 260 |
| 11.3.2 知识点八：增长因子                             | 261 |
| 11.3.3 综合例题：Wilkinson 矩阵的指数增长因子              | 261 |
| 11.3.4 知识点九：PLU 的后向误差                        | 262 |
| 11.4 Cholesky 与 $LDL^H$ 分解                   | 262 |
| 11.4.1 知识点十：Cholesky 存在唯一性                   | 262 |
| 11.4.2 知识点十一：Cholesky 递推与算法                  | 263 |
| 11.4.3 基础例题：Cholesky 分解与求解                   | 264 |
| 11.4.4 知识点十二：Cholesky 稳定性与失败情形               | 265 |
| 11.4.5 知识点十三： $LDL^H$ 分解                     | 265 |
| 11.5 QR 分解：Gram-Schmidt、Householder 与 Givens | 265 |
| 11.5.1 知识点十四：约化 QR 与完全 QR                    | 265 |
| 11.5.2 知识点十五：经典与修正 Gram-Schmidt              | 266 |
| 11.5.3 知识点十六：Householder 反射                  | 267 |
| 11.5.4 基础例题：构造一个 Householder 反射              | 268 |
| 11.5.5 知识点十七：Givens 旋转                       | 268 |
| 11.5.6 知识点十八：QR 算法的稳定性比较                     | 269 |
| 11.5.7 知识点十九：用 QR 解方阵线性系统                    | 269 |
| 11.6 线性最小二乘：投影、正规方程与 QR 算法                   | 270 |
| 11.6.1 知识点二十：问题与最优性条件                        | 270 |
| 11.6.2 知识点二十一：正规方程法                          | 270 |
| 11.6.3 知识点二十二：QR 最小二乘法                       | 271 |
| 11.6.4 综合例题：直线拟合的 QR 解法                      | 272 |
| 11.6.5 知识点二十三：正规方程、QR 与 SVD 的比较              | 273 |
| 11.6.6 知识点二十四：满秩最小二乘的条件数参数                   | 273 |
| 11.7 舍入误差、增长因子与迭代改进                          | 274 |
| 11.7.1 知识点二十五：矩阵乘法的标准误差模型                    | 274 |
| 11.7.2 知识点二十六：直接法稳定性总逻辑                      | 274 |
| 11.7.3 知识点二十七：迭代改进                           | 274 |
| 11.8 补充训练题：最小二乘增广矩阵的谱与最优缩放                   | 275 |



|                                                       |            |
|-------------------------------------------------------|------------|
| 11.9 补充训练题：上三角矩阵乘积减位移的快速求解 . . . . .                  | 277        |
| 11.10 本部分易错点与标准答题规范 . . . . .                         | 280        |
| <b>第十二章 SVD、伪逆、低秩逼近、核范数、正则化、低秩更新与矩阵方程</b>             | <b>282</b> |
| 12.1 奇异值分解：定义、存在性、基本子空间与计算 . . . . .                  | 282        |
| 12.1.1 知识点一：完整 SVD 与紧 SVD . . . . .                   | 282        |
| 12.1.2 知识点二：四个基本子空间 . . . . .                         | 283        |
| 12.1.3 知识点三：范数、秩与条件数的奇异值表达 . . . . .                  | 284        |
| 12.1.4 知识点四：SVD 的数值计算 . . . . .                       | 284        |
| 12.2 极分解、Moore–Penrose 伪逆与最小范数解 . . . . .             | 285        |
| 12.2.1 知识点五：极分解 . . . . .                             | 285        |
| 12.2.2 知识点六：Moore–Penrose 伪逆 . . . . .                | 286        |
| 12.2.3 知识点七：一致方程与最小二乘的全部解 . . . . .                   | 286        |
| 12.3 补充训练题：丘赛 2021 Problem 4——秩亏最小二乘 . . . . .        | 287        |
| 12.4 补充训练题：丘赛 2026 Problem 5——奇异值与固定点 . . . . .       | 288        |
| 12.5 最佳低秩逼近与 Eckart–Young–Mirsky 定理 . . . . .         | 289        |
| 12.5.1 知识点八：截断 SVD . . . . .                          | 289        |
| 12.5.2 知识点九：最优解唯一性 . . . . .                          | 290        |
| 12.5.3 知识点十：压缩、存储与快速乘法 . . . . .                      | 290        |
| 12.6 正式真题 [24S-Q1]——两种范数下的最佳秩- $k$ 逼近 . . . . .       | 291        |
| 12.7 补充训练题：数值代数题目合辑中的低秩与 PCA 母题 . . . . .             | 292        |
| 12.7.1 补充题一：Frobenius 范数下的最佳秩- $k$ 逼近 . . . . .       | 292        |
| 12.7.2 补充题二：无中心 PCA . . . . .                         | 292        |
| 12.7.3 补充题三：带平移的仿射 PCA . . . . .                      | 293        |
| 12.7.4 补充题四：满秩矩阵稠密性与秩稳定性 . . . . .                    | 294        |
| 12.8 核范数、迹对偶与奇异值软阈值 . . . . .                         | 294        |
| 12.8.1 知识点十一：Schatten 范数的统一视角 . . . . .               | 294        |
| 12.8.2 补充训练题：核范数的四个结论 . . . . .                       | 295        |
| 12.9 病态最小二乘与正则化 . . . . .                             | 296        |
| 12.9.1 知识点十二：小奇异值放大噪声 . . . . .                       | 296        |
| 12.9.2 知识点十三：截断 SVD 正则化 . . . . .                     | 297        |
| 12.9.3 知识点十四：Tikhonov 正则化 . . . . .                   | 297        |
| 12.10 低秩更新：Sherman–Morrison、Woodbury 与行列式引理 . . . . . | 298        |
| 12.10.1 知识点十五：Sylvester 行列式恒等式 . . . . .              | 298        |
| 12.10.2 知识点十六：矩阵行列式引理 . . . . .                       | 298        |
| 12.10.3 知识点十七：Sherman–Morrison 公式 . . . . .           | 298        |
| 12.10.4 知识点十八：Woodbury 公式 . . . . .                   | 299        |
| 12.11 正式真题 [25S-Q3]——秩二余弦核快速算法 . . . . .              | 300        |
| 12.12 补充训练题：秩一更新、列替换与三对角显式逆 . . . . .                 | 302        |






|                                                               |            |
|---------------------------------------------------------------|------------|
| 12.12.1 丘赛 2024 Problem 1: 快速更新求解                             | 302        |
| 12.12.2 数值代数题目合辑: 列替换                                         | 302        |
| 12.12.3 数值代数题目合辑: 三对角矩阵的显式逆及题面核对                              | 303        |
| 12.13 SVD 分块谱分析: 鞍点矩阵补充题                                      | 304        |
| 12.14 矩阵方程、Kronecker 积与 Frobenius 最小二乘                        | 305        |
| 12.14.1 知识点十九: 向量化与 Kronecker 积                               | 305        |
| 12.14.2 知识点二十: 矩阵最小二乘的正规方程                                    | 306        |
| 12.14.3 知识点二十一: 投影形式、最小值与全部最小点                                | 306        |
| 12.15 正式真题 [26S-Q3]——矩阵方程最小二乘                                 | 307        |
| 12.16 本部分易错点与易混概念                                             | 309        |
| <b>第十三章 幂法、反幂法、Rayleigh 商、Hessenberg 化、QR 迭代、位移、广义特征值与 QZ</b> | <b>311</b> |
| 13.1 标准特征值问题、残差、Rayleigh 商与后验误差                               | 311        |
| 13.1.1 知识点一: 标准特征值问题的对象与目标                                    | 311        |
| 13.1.2 知识点二: 近似特征对与残差                                         | 311        |
| 13.1.3 知识点三: Rayleigh 商                                       | 312        |
| 13.2 幂法: 主特征方向、收敛率与特征值估计                                      | 313        |
| 13.2.1 知识点四: 幂法的假设与基本展开                                       | 313        |
| 13.2.2 知识点五: 相位、符号与失败情形                                       | 314        |
| 13.2.3 知识点六: Rayleigh 商的特征值收敛                                 | 314        |
| 13.3 补充训练题: 丘赛 2020 Problem 3——幂法渐近常数                         | 315        |
| 13.4 补充训练题: 丘赛 2023 Problem 3——归一化幂法与递推比值                     | 315        |
| 13.5 子空间迭代与正交迭代                                               | 317        |
| 13.5.1 知识点七: 由单向量幂法到子空间迭代                                     | 317        |
| 13.5.2 补充训练题——向量与主不变子空间的角                                     | 317        |
| 13.5.3 补充训练题——子空间迭代的残差比                                       | 318        |
| 13.6 反幂法、位移反幂法与 Rayleigh 商迭代                                  | 319        |
| 13.6.1 知识点八: 位移反幂法                                            | 319        |
| 13.6.2 知识点九: Rayleigh 商迭代                                     | 320        |
| 13.6.3 知识点十: 病态线性系统为何仍可能给出准确方向                                | 321        |
| 13.7 补充训练题——有限精度反幂法                                           | 321        |
| 13.8 上 Hessenberg 约化、proper Hessenberg 与 Krylov 结构            | 323        |
| 13.8.1 知识点十一: 上 Hessenberg 矩阵                                 | 323        |
| 13.8.2 知识点十二: Householder Hessenberg 约化                       | 323        |
| 13.8.3 知识点十三: 为什么先约化再 QR                                      | 324        |
| 13.8.4 补充训练题——proper Hessenberg 与 Krylov 子空间                  | 324        |
| 13.9 QR 迭代、同时迭代、位移与消去                                         | 324        |
| 13.9.1 知识点十四: 无位移 QR 迭代                                       | 324        |
| 13.9.2 知识点十五: 位移 QR                                           | 325        |

|                                                            |     |
|------------------------------------------------------------|-----|
| 13.10 补充训练题：丘赛 2026 Problem 4——位移 QR 恒等式 . . . . .         | 326 |
| 13.11 正式真题 [23F-Q2]——显式位移 QR 与尾部收敛估计 . . . . .             | 328 |
| 13.12 结构化特征值母题：伴随矩阵、三对角矩阵与快速矩阵幂 . . . . .                  | 331 |
| 13.12.1 补充训练题：伴随矩阵的 Vandermonde 对角化 . . . . .              | 331 |
| 13.12.2 补充训练题：非对称三对角 Toeplitz 矩阵 . . . . .                 | 332 |
| 13.12.3 补充训练题：丘赛 2025 Problem 2——路径图矩阵逆的谱半径 . . . . .      | 333 |
| 13.12.4 补充训练题：快速 Fibonacci 矩阵幂 . . . . .                   | 334 |
| 13.13 广义特征值问题、矩阵铅笔与广义 Schur 分解 . . . . .                   | 335 |
| 13.13.1 知识点十六：齐次广义特征值 . . . . .                            | 335 |
| 13.13.2 知识点十七：酉等价变换与广义 Schur 形式 . . . . .                  | 335 |
| 13.13.3 知识点十八：Hessenberg-三角化与 QZ 算法 . . . . .              | 336 |
| 13.13.4 补充训练题——共享正弦特征向量的广义三对角问题 . . . . .                  | 336 |
| 13.14 正式真题 [25F-Q3]——广义 Schur 分解与 Hessenberg-三角化 . . . . . | 337 |
| 13.15 本部分易错点、失败情形与完整答题规范 . . . . .                         | 340 |

#### 第十四章 Jacobi、Gauss–Seidel、SOR、CG、Krylov、Arnoldi、Lanczos、GMRES、预

|                                                         |     |
|---------------------------------------------------------|-----|
| 处理与大型稀疏矩阵 . . . . .                                     | 342 |
| 14.1 定常线性迭代的统一框架 . . . . .                              | 342 |
| 14.1.1 知识点一：矩阵分裂、相容性与误差方程 . . . . .                     | 342 |
| 14.1.2 知识点二：谱半径收敛判据 . . . . .                           | 343 |
| 14.1.3 知识点三：Richardson 迭代 . . . . .                     | 343 |
| 14.2 补充训练题：一般分裂、有限步收敛与块 Jacobi/块 Gauss–Seidel . . . . . | 344 |
| 14.3 Jacobi、Gauss–Seidel 与 SOR . . . . .                | 346 |
| 14.3.1 知识点四：统一符号与算法公式 . . . . .                         | 346 |
| 14.3.2 知识点五：严格对角占优情形 . . . . .                          | 347 |
| 14.3.3 知识点六：对称正定情形 . . . . .                            | 348 |
| 14.3.4 知识点七：SOR 的必要与充分条件 . . . . .                      | 349 |
| 14.4 正式真题 [24S-Q2]——Gauss–Seidel 收敛性 . . . . .          | 350 |
| 14.5 补充训练题：丘赛 2022 Problem 3——严格对角占优矩阵的范数与谱界 . . . . .  | 351 |
| 14.6 补充训练题：分量松弛与题目有误？ . . . . .                         | 352 |
| 14.7 最小残量方向与最速下降 . . . . .                              | 354 |
| 14.7.1 知识点八：单方向最小残量校正 . . . . .                         | 354 |
| 14.7.2 补充训练题：NLA-Set-2016-Team-Q4 . . . . .             | 354 |
| 14.7.3 知识点九：最速下降法 . . . . .                             | 355 |
| 14.7.4 补充训练题：齐次二次型的最速下降 . . . . .                       | 355 |
| 14.8 共轭梯度法：Galerkin 最优性、正交性与多项式逼近 . . . . .             | 356 |
| 14.8.1 知识点十：CG 的适用条件 . . . . .                          | 356 |
| 14.8.2 知识点十一：CG 算法 . . . . .                            | 356 |
| 14.8.3 知识点十二：CG 的四个基本结构 . . . . .                       | 357 |




|                                                              |     |
|--------------------------------------------------------------|-----|
| 14.8.4 知识点十三: CG 的多项式观点 . . . . .                            | 357 |
| 14.8.5 补充训练题——CG 结构证明 . . . . .                              | 358 |
| 14.9 Krylov 子空间、Arnoldi 与 Lanczos . . . . .                  | 358 |
| 14.9.1 知识点十四: Krylov 子空间与等级 . . . . .                        | 358 |
| 14.9.2 知识点十五: Arnoldi 过程 . . . . .                           | 359 |
| 14.9.3 补充训练题: Arnoldi、breakdown 与最优首一多项式 . . . . .           | 359 |
| 14.9.4 知识点十六: Lanczos 过程 . . . . .                           | 360 |
| 14.9.5 补充训练题: Lanczos 正交性、终止与用途 . . . . .                    | 361 |
| 14.10 GMRES 与 MINRES . . . . .                               | 362 |
| 14.10.1 知识点十七: GMRES 的最小残量原理 . . . . .                       | 362 |
| 14.10.2 知识点十八: GMRES 算法 . . . . .                            | 363 |
| 14.10.3 知识点十九: GMRES 的多项式观点与非正规困难 . . . . .                  | 364 |
| 14.10.4 知识点二十: 重启 GMRES . . . . .                            | 364 |
| 14.11 补充训练题: GMRES 最小二乘、残差公式与完整算法 . . . . .                  | 364 |
| 14.11.1 知识点二十一: MINRES . . . . .                             | 366 |
| 14.12 正式真题 [24F-Q2]——CG 误差估计与非 Hermitian Krylov 方法 . . . . . | 366 |
| 14.13 预处理 . . . . .                                          | 368 |
| 14.13.1 知识点二十二: 预处理的目标 . . . . .                             | 368 |
| 14.13.2 知识点二十三: 左、右与分裂预处理 . . . . .                          | 368 |
| 14.13.3 知识点二十四: 预条件共轭梯度法 . . . . .                           | 368 |
| 14.13.4 知识点二十五: 常见预处理器 . . . . .                             | 369 |
| 14.14 大型稀疏矩阵的存储、复杂度与停止准则 . . . . .                           | 370 |
| 14.14.1 知识点二十六: 稀疏存储 . . . . .                               | 370 |
| 14.14.2 知识点二十七: 直接法与迭代法比较 . . . . .                          | 370 |
| 14.14.3 知识点二十八: 停止准则与真实误差 . . . . .                          | 370 |
| 14.14.4 知识点二十九: 矩阵无关实现 . . . . .                             | 371 |

#### 第四部分 偏微分方程数值解 372


#### 第十五章 PDE 数值方法统一基础——网格、截断误差、相容性、稳定性、收敛性、Lax 等价、von Neumann、能量法、最大值原理与 CFL 373

|                                       |     |
|---------------------------------------|-----|
| 15.1 连续问题的适定性与离散分析的基本对象 . . . . .     | 373 |
| 15.1.1 知识点一: 连续问题的适定性 . . . . .       | 373 |
| 15.1.2 知识点二: 统一网格与网格函数 . . . . .      | 374 |
| 15.1.3 知识点三: 离散范数 . . . . .           | 375 |
| 15.1.4 知识点四: 差分算子 . . . . .           | 375 |
| 15.1.5 知识点五: 模板、显式、隐式与计算复杂度 . . . . . | 376 |
| 15.2 截断误差、相容性与收敛性 . . . . .           | 376 |
| 15.2.1 知识点六: 本文的截断误差主约定 . . . . .     | 376 |



|                                                     |     |
|-----------------------------------------------------|-----|
| 15.2.2 知识点七：相容性的精确定义 . . . . .                      | 377 |
| 15.2.3 知识点八：整体误差与收敛阶 . . . . .                      | 378 |
| 15.3 PDE 差分格式的稳定性 . . . . .                         | 378 |
| 15.3.1 知识点九：一步线性格式的稳定性 . . . . .                    | 378 |
| 15.3.2 知识点十：隐式格式与传播矩阵 . . . . .                     | 379 |
| 15.3.3 知识点十一：多层格式的增广状态 . . . . .                    | 379 |
| 15.3.4 知识点十二：离散 Grönwall 不等式 . . . . .              | 379 |
| 15.4 Lax–Richtmyer 等价定理 . . . . .                   | 380 |
| 15.4.1 知识点十三：定理的精确适用范围 . . . . .                    | 380 |
| 15.4.2 知识点十四：稳定性推出收敛性 . . . . .                     | 381 |
| 15.4.3 知识点十五：收敛性推出稳定性的证明框架 . . . . .                | 381 |
| 15.5 补充训练题：丘赛 2020 Problem 5——稳定传播算子的有界扰动 . . . . . | 382 |
| 15.6 Fourier 与 von Neumann 稳定性分析 . . . . .          | 383 |
| 15.6.1 知识点十六：标量一步格式的 Fourier 符号 . . . . .           | 383 |
| 15.6.2 知识点十七：增长矩阵与非正规情形 . . . . .                   | 383 |
| 15.6.3 知识点十八：多层格式的根条件 . . . . .                     | 384 |
| 15.6.4 知识点十九：von Neumann 方法的适用边界 . . . . .          | 385 |
| 15.7 能量法与离散分部积分 . . . . .                           | 385 |
| 15.7.1 知识点二十：离散 summation by parts . . . . .        | 385 |
| 15.7.2 知识点二十一：半离散对流与扩散能量 . . . . .                  | 386 |
| 15.7.3 知识点二十二：后向 Euler 热格式的离散能量 . . . . .           | 386 |
| 15.7.4 知识点二十三：能量法标准答题框架 . . . . .                   | 387 |
| 15.8 CFL 条件与依赖域 . . . . .                           | 387 |
| 15.8.1 知识点二十四：连续依赖域 . . . . .                       | 387 |
| 15.8.2 知识点二十五：数值依赖域 . . . . .                       | 388 |
| 15.8.3 知识点二十六：CFL 只是必要条件 . . . . .                  | 388 |
| 15.9 补充训练题——FTCS 对流格式 . . . . .                     | 388 |
| 15.10 离散最大值原理、单调性与逆正性 . . . . .                     | 391 |
| 15.10.1 知识点二十七：一般离散最大值原理 . . . . .                  | 391 |
| 15.10.2 知识点二十八：稳定性估计 . . . . .                      | 391 |
| 15.11 正式真题 [24S-Q5]——三点差分最大值原理 . . . . .            | 392 |
| 15.12 补充训练题——迎风格式与网格范数 . . . . .                    | 394 |
| 15.13 矩阵法、边界稳定性与不同稳定工具的关系 . . . . .                 | 395 |
| 15.13.1 知识点二十九：矩阵法 . . . . .                        | 395 |
| 15.13.2 知识点三十：边界条件的数量和方向 . . . . .                  | 396 |
| 15.13.3 知识点三十一：四类稳定工具的选择 . . . . .                  | 396 |
| 15.14 资格考试稳定性分析的完整答题模板与易错点 . . . . .                | 396 |


|                                           |     |
|-------------------------------------------|-----|
| 16.1 椭圆边值问题的统一形式与适定性                      | 398 |
| 16.1.1 知识点一：问题对象与主约定                      | 398 |
| 16.1.2 知识点二：Poisson 方程                    | 398 |
| 16.1.3 知识点三：三类边界问题的唯一性差异                  | 399 |
| 16.2 Poisson 方程的五点差分格式                    | 399 |
| 16.2.1 知识点四：网格、格式与截断误差                    | 399 |
| 16.2.2 知识点五：矩阵形式                          | 400 |
| 16.2.3 知识点六：对称正定性                         | 401 |
| 16.2.4 知识点七：显式特征值与条件数                     | 401 |
| 16.2.5 知识点八：装配与求解算法                       | 402 |
| 16.3 Poisson 五点格式的离散最大值原理与 $M$ 矩阵         | 402 |
| 16.3.1 知识点九：最小值原理与比较原理                    | 402 |
| 16.3.2 知识点十： $Z$ 矩阵、 $M$ 矩阵与逆正性           | 403 |
| 16.4 Poisson 五点格式的全局误差估计                  | 404 |
| 16.4.1 知识点十一：障碍函数法                        | 404 |
| 16.4.2 知识点十二：边界误差的影响                      | 405 |
| 16.4.3 知识点十三：离散能量误差                       | 405 |
| 16.4.4 证明套路：最大值原理误差估计                     | 405 |
| 16.5 基础例题：一维 Poisson 问题的精确离散误差            | 406 |
| 16.6 九点格式与四阶 Poisson 离散                   | 407 |
| 16.6.1 知识点十四：九点离散 Laplace 算子              | 407 |
| 16.7 变系数散度型椭圆方程的保守离散                      | 408 |
| 16.7.1 知识点十五：为什么使用通量形式                    | 408 |
| 16.7.2 知识点十六：面系数的选择                       | 409 |
| 16.7.3 知识点十七：矩阵性质                         | 409 |
| 16.8 补充训练题：丘赛 2024 Problem 4——变系数保守离散与谱圆盘 | 410 |
| 16.9 Dirichlet、Neumann 与 Robin 边界离散       | 412 |
| 16.9.1 知识点十八：Dirichlet 边界                 | 412 |
| 16.9.2 知识点十九：Neumann 边界的二阶单边差分            | 413 |
| 16.9.3 知识点二十：虚点法                          | 413 |
| 16.9.4 知识点二十一：离散 Neumann 兼容条件             | 413 |
| 16.9.5 知识点二十二：Robin 边界                    | 414 |
| 16.10 含一阶项和零阶项的中心差分单调性                    | 414 |
| 16.10.1 知识点二十三：非散度形式                      | 414 |
| 16.10.2 知识点二十四：单调性条件                      | 415 |
| 16.11 正式真题 [24F-Q5]——二维中心差分最大值原理          | 416 |
| 16.12 正式真题 [26S-Q5]——最大值原理与后向 Euler 稳定性   | 417 |
| 16.13 非均匀网格、各向异性与单调宽模板                    | 419 |
| 16.13.1 知识点二十五：一维非均匀网格保守格式                | 419 |






|                                                                                                       |            |
|-------------------------------------------------------------------------------------------------------|------------|
| 16.13.2 知识点二十六: 各向异性张量 . . . . .                                                                      | 420        |
| 16.14 椭圆差分系统的求解器、条件数与停止准则 . . . . .                                                                   | 420        |
| 16.14.1 知识点二十七: 线性求解误差不能超过离散误差 . . . . .                                                              | 420        |
| 16.14.2 知识点二十八: 求解器选择 . . . . .                                                                       | 420        |
| 16.14.3 知识点二十九: 多重网格识别信号 . . . . .                                                                    | 421        |
| 16.15 椭圆有限差分易错点与参考答题规范 . . . . .                                                                      | 421        |
| <b>第十七章 抛物方程、对流扩散、显隐式格式、Crank–Nicolson、Du Fort–Frankel、IMEX、<br/>迎风、Lax–Friedrichs 与 Lax–Wendroff</b> | <b>423</b> |
| 17.1 抛物方程半离散、刚性与统一 $\vartheta$ 格式 . . . . .                                                           | 423        |
| 17.1.1 知识点一: 热方程及空间半离散 . . . . .                                                                      | 423        |
| 17.1.2 知识点二: 统一 $\vartheta$ 格式 . . . . .                                                              | 424        |
| 17.1.3 知识点三: 截断误差 . . . . .                                                                           | 424        |
| 17.1.4 知识点四: Fourier 与谱稳定性 . . . . .                                                                  | 425        |
| 17.1.5 知识点五: 单调性与最大值原理 . . . . .                                                                      | 425        |
| 17.1.6 知识点六: 算法与复杂度 . . . . .                                                                         | 426        |
| 17.2 补充训练题: 丘赛 2023 Problem 5——显式热方程格式的一致性、稳定性与收敛性 . . . . .                                          | 427        |
| 17.3 补充训练题: 丘赛 2024 Problem 6——周期扩散问题的离散 Fourier 分析 . . . . .                                         | 428        |
| 17.4 正式真题 [24S-Q4]——含参数的三时间层热方程格式 . . . . .                                                           | 430        |
| 17.5 补充训练题: Richardson 热方程格式及其隐式修正 . . . . .                                                          | 431        |
| 17.6 Du Fort–Frankel 格式 . . . . .                                                                     | 433        |
| 17.6.1 知识点七: 一维格式的构造 . . . . .                                                                        | 433        |
| 17.6.2 知识点八: 相容性的特殊性 . . . . .                                                                        | 433        |
| 17.7 正式真题 [25F-Q4]——二维 Du Fort–Frankel 格式 . . . . .                                                   | 434        |
| 17.8 补充训练题: 后向 Euler 热方程的非齐次边界能量估计 . . . . .                                                          | 435        |
| 17.9 对流扩散方程与 IMEX 离散 . . . . .                                                                        | 437        |
| 17.9.1 知识点九: 对流扩散模型 . . . . .                                                                         | 437        |
| 17.9.2 知识点十: 误差与实现 . . . . .                                                                          | 437        |
| 17.10 补充训练题: 对流扩散 IMEX 格式 . . . . .                                                                   | 438        |
| 17.11 一阶对流方程的标准差分格式 . . . . .                                                                         | 438        |
| 17.11.1 知识点十一: 模型与 Courant 数 . . . . .                                                                | 438        |
| 17.11.2 知识点十二: 迎风、逆风与中心 FTCS . . . . .                                                                | 439        |
| 17.11.3 知识点十三: Lax–Friedrichs 格式 . . . . .                                                            | 439        |
| 17.11.4 知识点十四: Lax–Wendroff 格式 . . . . .                                                              | 439        |
| 17.11.5 知识点十五: 耗散、相位和群速度 . . . . .                                                                    | 440        |
| 17.12 正式真题 [26S-Q4]——三种隐式对流格式 . . . . .                                                               | 441        |
| 17.13 补充训练题: BDF2–中心隐式对流格式 . . . . .                                                                  | 442        |
| 17.14 补充训练题: 紧致四阶空间差分的隐式 Leapfrog 格式 . . . . .                                                        | 443        |
| 17.15 补充训练题: FTCS 格式的稳定性方法 . . . . .                                                                  | 444        |

|                                                          |            |
|----------------------------------------------------------|------------|
| 17.16 二阶单边三点格式: Beam-Warming 型方法 . . . . .               | 445        |
| 17.16.1 知识点十六: 系数构造 . . . . .                            | 445        |
| 17.16.2 知识点十七: 稳定性 . . . . .                             | 445        |
| 17.17 补充训练题: 单边三点格式及入流边界 . . . . .                       | 446        |
| 17.18 补充训练题: 精确网格平移与稳定区间 . . . . .                       | 447        |
| 17.19 补充训练题: 非线性扩散显式格式 . . . . .                         | 447        |
| 17.20 补充训练题: 非线性守恒律半离散迎风格式 . . . . .                     | 448        |
| 17.21 实现容差、复杂度与资格考试易错点 . . . . .                         | 449        |
| 17.21.1 知识点十八: 隐式线性系统的求解容差 . . . . .                     | 449        |
| 17.21.2 知识点十九: 复杂度比较 . . . . .                           | 450        |
| 17.21.3 知识点二十: 高频失真与步长选择 . . . . .                       | 450        |
| <b>第十八章 波动方程、双曲系统、耦合格式、色散方程、数值边界条件、能量与传播</b>             | <b>452</b> |
| 18.1 波动方程的连续结构: 能量、特征线与有限传播速度 . . . . .                  | 452        |
| 18.1.1 知识点一: 问题、假设与适定性 . . . . .                         | 452        |
| 18.1.2 知识点二: 连续能量 . . . . .                              | 452        |
| 18.1.3 知识点三: 特征变量与传播方向 . . . . .                         | 453        |
| 18.1.4 知识点四: 有限传播速度与数值依赖域 . . . . .                      | 454        |
| 18.2 波动方程的标准 Störmer-Leapfrog 中心格式 . . . . .             | 454        |
| 18.2.1 知识点五: 格式构造与精度 . . . . .                           | 454        |
| 18.2.2 知识点六: 初始速度的二阶离散 . . . . .                         | 455        |
| 18.2.3 知识点七: Fourier 稳定性与根条件 . . . . .                   | 455        |
| 18.2.4 知识点八: 数值色散关系 . . . . .                            | 456        |
| 18.2.5 知识点九: 离散能量 . . . . .                              | 456        |
| 18.3 补充训练题: Störmer 方法与波动方程中心格式 . . . . .                | 457        |
| 18.4 隐式三层波动格式与无条件能量稳定性 . . . . .                         | 458        |
| 18.4.1 知识点十: 时间-空间平均格式 . . . . .                         | 458        |
| 18.5 正式真题 [25F-Q5]——波动方程隐式三层格式 . . . . .                 | 458        |
| 18.6 一阶线性双曲系统与特征分解 . . . . .                             | 460        |
| 18.6.1 知识点十一: 对称双曲系统 . . . . .                           | 460        |
| 18.6.2 知识点十二: 连续能量与边界条件个数 . . . . .                      | 460        |
| 18.6.3 知识点十三: 增长矩阵 . . . . .                             | 461        |
| 18.7 正式真题 [24F-Q4]——耦合双曲系统的 Lax-Friedrichs 型格式 . . . . . | 461        |
| 18.8 耦合色散系统与 Crank-Nicolson 的酉结构 . . . . .               | 463        |
| 18.8.1 知识点十四: 实耦合系统与复数形式 . . . . .                       | 463        |
| 18.8.2 知识点十五: Cayley 变换 . . . . .                        | 464        |
| 18.9 正式真题 [25S-Q4]——耦合色散系统的 Crank-Nicolson 格式 . . . . .  | 464        |
| 18.10 三阶色散方程的连续与半离散结构 . . . . .                          | 466        |
| 18.10.1 知识点十六: 连续适定性 . . . . .                           | 466        |



|                                                                     |            |
|---------------------------------------------------------------------|------------|
| 18.10.2 知识点十七：中心三阶差分算子                                              | 467        |
| 18.11 正式真题 [23F-Q5]——三阶色散方程的 Lax 型格式                                | 467        |
| 18.12 补充训练题：丘赛 2024 Problem 5——三阶色散方程适定性与中心三层格式                     | 469        |
| 18.13 高阶 Lax–Wendroff 构造：Taylor 法与特征回溯插值                            | 470        |
| 18.13.1 知识点十八：两种等价构造观点                                              | 470        |
| 18.14 补充训练题：丘赛 2022 Problem 5——三阶 Lax–Wendroff 格式                   | 471        |
| 18.15 Lax–Wendroff 格式的离散能量恒等式                                       | 472        |
| 18.15.1 知识点十九：算子形式                                                  | 472        |
| 18.16 正式真题 [25S-Q5]——Lax–Wendroff 能量与数值出流边界                         | 473        |
| 18.17 有限区间双曲问题的数值边界条件                                               | 475        |
| 18.17.1 知识点二十：连续边界与数值边界的区别                                          | 475        |
| 18.17.2 知识点二十一：常见出流闭合                                               | 475        |
| 18.17.3 知识点二十二：反射系数分析                                               | 475        |
| 18.18 补充训练题：双向波导系统与耦合边界                                             | 477        |
| 18.19 数值传播速度、耗散、色散与群速度                                              | 479        |
| 18.19.1 知识点二十三：增长因子的极坐标分解                                           | 479        |
| 18.19.2 知识点二十四：三类误差的区分                                              | 480        |
| 18.19.3 知识点二十五：修改方程                                                 | 480        |
| 18.20 系统格式的正规性、非正规性与暂态增长                                            | 480        |
| 18.20.1 知识点二十六：可对角化增长矩阵                                             | 480        |
| 18.20.2 知识点二十七：资格考试判断顺序                                             | 481        |
| 18.21 波动、双曲与色散格式的统一算法比较                                             | 481        |
| 18.21.1 知识点二十八：运算与存储复杂度                                             | 482        |
| 18.22 波动、双曲与色散题的易错点和反例                                              | 482        |
| 18.23 资格考试证明与分析套路                                                   | 484        |
| <b>第十九章 有限元、变分形式、Céa 引理、能量范数、Aubin–Nitsche 对偶技巧、时间依赖有限元、谱方法与配点法</b> | <b>486</b> |
| 19.1 从强形式到弱形式：试探空间、检验空间与边界条件                                        | 486        |
| 19.1.1 知识点一：Sobolev 空间与迹                                            | 486        |
| 19.1.2 知识点二：二阶椭圆问题的弱形式                                              | 486        |
| 19.1.3 知识点三：本质边界与自然边界                                               | 487        |
| 19.1.4 知识点四：弱解的含义                                                   | 488        |
| 19.2 Lax–Milgram 定理、能量范数与问题适定性                                      | 488        |
| 19.2.1 知识点五：连续性与强制性                                                 | 488        |
| 19.2.2 知识点六：能量范数                                                    | 488        |
| 19.2.3 知识点七：适定性、条件数与离散稳定性的区分                                        | 489        |
| 19.3 保形有限元空间、形函数、单元矩阵与组装                                            | 489        |
| 19.3.1 知识点八：网格与形状正则性                                                | 489        |

|         |                                                     |     |
|---------|-----------------------------------------------------|-----|
| 19.3.2  | 知识点九：连续分片多项式空间                                      | 489 |
| 19.3.3  | 知识点十：一维 $P_1$ 单元                                    | 490 |
| 19.3.4  | 知识点十一：二维三角形 $P_1$ 单元                                | 490 |
| 19.3.5  | 知识点十二：从局部矩阵到全局矩阵                                    | 490 |
| 19.4    | Galerkin 正交、Céa 引理与能量范数误差                           | 491 |
| 19.4.1  | 知识点十三：Galerkin 正交性                                  | 491 |
| 19.4.2  | 知识点十四：Céa 引理                                        | 492 |
| 19.4.3  | 知识点十五：插值误差                                          | 492 |
| 19.5    | Aubin–Nitsche 对偶技巧与 $L^2$ 误差                        | 493 |
| 19.5.1  | 知识点十六：对偶问题的构造                                       | 493 |
| 19.5.2  | 知识点十七：对偶估计                                          | 493 |
| 19.6    | 补充训练题：丘赛 2021 Problem 6——悬臂梁的三次 Hermite 有限元         | 494 |
| 19.7    | 时间依赖有限元：半离散、全离散、质量矩阵与稳定性                            | 498 |
| 19.7.1  | 知识点十八：抛物方程的空间半离散                                    | 498 |
| 19.7.2  | 知识点十九：半离散能量估计                                       | 499 |
| 19.7.3  | 知识点二十：隐式 Euler 全离散                                  | 499 |
| 19.7.4  | 知识点二十一：Crank–Nicolson 有限元                           | 500 |
| 19.7.5  | 知识点二十二：显式时间推进与质量集中                                  | 500 |
| 19.7.6  | 知识点二十三：时间依赖有限元误差分解                                  | 500 |
| 19.8    | 补充训练题：丘赛 2025 Problem 5——反应扩散 $\theta$ 格式           | 501 |
| 19.9    | 补充训练题：丘赛 2026 Problem 1——对流扩散方程的 $P_1$ 有限元与隐式 Euler | 502 |
| 19.10   | Fourier 谱 Galerkin 与 Fourier 谱配置                    | 505 |
| 19.10.1 | 知识点二十四：周期谱空间                                        | 505 |
| 19.10.2 | 知识点二十五：Sobolev 逼近估计                                 | 506 |
| 19.10.3 | 知识点二十六：Fourier 谱微分                                  | 506 |
| 19.10.4 | 知识点二十七：Fourier 谱 Galerkin 例子                        | 507 |
| 19.10.5 | 知识点二十八：谱配置与混叠                                       | 507 |
| 19.11   | Chebyshev 谱配置与微分矩阵                                  | 507 |
| 19.11.1 | 知识点二十九：Chebyshev–Lobatto 节点                         | 507 |
| 19.11.2 | 知识点三十：一般微分矩阵                                        | 508 |
| 19.12   | 正式真题 [23F–Q3]——Chebyshev 微分矩阵                       | 508 |
| 19.13   | Chebyshev 配置法求解边值问题                                 | 510 |
| 19.13.1 | 知识点三十一：Poisson 配置法                                  | 510 |
| 19.13.2 | 知识点三十二：谱收敛                                          | 511 |
| 19.13.3 | 知识点三十三：边界条件与条件数                                     | 511 |
| 19.14   | 谱 Galerkin、谱配置与谱 Tau 方法的区别                          | 512 |
| 19.14.1 | 知识点三十四：谱 Galerkin                                   | 512 |
| 19.14.2 | 知识点三十五：谱配置                                          | 512 |
| 19.14.3 | 知识点三十六：谱 Tau 方法                                     | 513 |




|                                           |            |
|-------------------------------------------|------------|
| 19.15 有限差分、有限元与谱方法中的“稳定性”                 | 513        |
| 19.15.1 知识点三十七：有限差分稳定性                    | 513        |
| 19.15.2 知识点三十八：有限元稳定性                     | 513        |
| 19.15.3 知识点三十九：谱方法稳定性                     | 514        |
| 19.16 有限元与谱方法易错点、反例与答题规范                  | 514        |
| 19.17 模块四正式真题完整映射                         | 515        |
| 19.17.1 正式题型频率                            | 516        |
| 19.18 模块四补充题集闭环映射                         | 517        |
| 19.18.1 丘赛中属于模块四的题目                       | 517        |
| 19.18.2 数值 PDE_FDM 题目合辑的十四组题              | 517        |
| <b>第五部分 渐近分析</b>                          | <b>519</b> |
| <b>第二十章 渐近记号、渐近序列、渐近级数、主导平衡、量纲分析与无量纲化</b> | <b>520</b> |
| 20.1 渐近分析的对象、参数趋向与有效区域                    | 520        |
| 20.1.1 知识点一：渐近问题的输入与输出                    | 520        |
| 20.1.2 知识点二：大参数与小参数的换算                    | 520        |
| 20.1.3 知识点三：固定变量、伸缩变量与移动区域                | 521        |
| 20.2 大 $O$ 、小 $o$ 、渐近等价与双边阶               | 521        |
| 20.2.1 知识点四：大 $O$ 记号                      | 521        |
| 20.2.2 知识点五：小 $o$ 记号                      | 521        |
| 20.2.3 知识点六：渐近等价                          | 522        |
| 20.2.4 知识点七：双边阶与数量级                       | 522        |
| 20.3 一致估计、多参数极限与特异极限                      | 523        |
| 20.3.1 知识点八：一致大 $O$ 与一致小 $o$              | 523        |
| 20.3.2 知识点九：一个几何级数的有效区间                   | 523        |
| 20.3.3 知识点十：多参数联合极限                       | 523        |
| 20.3.4 知识点十一：区分极限与特征极限                    | 524        |
| 20.4 渐近序列、Poincaré 渐近展开与系数唯一性             | 524        |
| 20.4.1 知识点十二：渐近序列                         | 524        |
| 20.4.2 知识点十三：Poincaré 渐近展开                | 524        |
| 20.4.3 知识点十四：首项与主导项                       | 525        |
| 20.5 渐近级数不必收敛：指数积分型标准例子                   | 525        |
| 20.6 渐近展开的代数运算、复合、微分与积分                   | 526        |
| 20.6.1 知识点十五：加减法与主导项抵消                    | 526        |
| 20.6.2 知识点十六：乘法与 Cauchy 卷积                | 527        |
| 20.6.3 知识点十七：倒数与商                         | 527        |
| 20.6.4 知识点十八：幂、指数与对数                      | 527        |
| 20.6.5 知识点十九：复合展开                         | 527        |




|                                                  |            |
|--------------------------------------------------|------------|
| 20.6.6 知识点二十: 逐项微分并非自动成立                         | 528        |
| 20.6.7 知识点二十一: 逐项积分所需条件                          | 528        |
| 20.7 主导平衡: 从未知尺度到有效展开                            | 529        |
| 20.7.1 知识点二十二: 主导平衡原则                            | 529        |
| 20.7.2 知识点二十三: 单项式方程的指数判据                        | 530        |
| 20.7.3 知识点二十四: 微分方程中的导数尺度                        | 532        |
| 20.8 量纲分析: 维数矩阵与 Buckingham II 定理                | 532        |
| 20.8.1 知识点二十五: 基本量纲与量纲向量                         | 532        |
| 20.8.2 知识点二十六: 量纲齐次性                             | 532        |
| 20.8.3 知识点二十七: 维数矩阵                              | 533        |
| 20.9 量纲分析基础例题: 单摆周期                              | 534        |
| 20.10 量纲分析综合例题: 球体阻力与 Reynolds 数                 | 535        |
| 20.11 无量纲化: 尺度选择、控制参数与极限模型                       | 536        |
| 20.11.1 知识点二十八: 一般无量纲化模板                         | 536        |
| 20.11.2 知识点二十九: 对流-扩散-反应方程                       | 537        |
| 20.11.3 知识点三十: 受迫 Duffing 型振子的无量纲化               | 537        |
| 20.11.4 知识点三十一: 无量纲化与数值条件                        | 538        |
| 20.12 尺度律: 由方程直接推导扩散长度和振幅                        | 538        |
| 20.12.1 知识点三十二: 扩散长度尺度                           | 538        |
| 20.13 过渡尺度与非一致展开                                 | 539        |
| 20.13.1 知识点三十三: 平方根模型中的过渡尺度                      | 539        |
| 20.13.2 知识点三十四: 绝对误差和相对误差的有效性                    | 539        |
| 20.14 误差项的主导平衡与最优参数选择                            | 540        |
| 20.15 渐近分析中的条件数、消去与数值实现                          | 541        |
| 20.15.1 知识点三十五: 小差值的敏感性                          | 541        |
| 20.15.2 知识点三十六: 渐近展开截断与舍入误差                      | 541        |
| 20.16 易错点、反例与资格考试答题模板                            | 542        |
| <b>第二十一章 Watson 引理、Laplace 方法、驻相法、最速下降法与振荡积分</b> | <b>544</b> |
| 21.1 渐近积分的统一结构: 局部化、临界点与贡献比较                     | 544        |
| 21.1.1 知识点一: 问题、目标与三类基本机制                        | 544        |
| 21.1.2 知识点二: 局部化原则                               | 544        |
| 21.2 非驻相区: 分部积分、端点展开与 van der Corput 估计          | 546        |
| 21.2.1 知识点三: 一次分部积分                              | 546        |
| 21.2.2 知识点四: 反复分部积分与端点渐近级数                       | 546        |
| 21.2.3 知识点五: 显式误差界                               | 546        |
| 21.3 Watson 引理: Laplace 变换型端点积分                  | 547        |
| 21.3.1 知识点六: 标准 Watson 引理                        | 547        |
| 21.3.2 知识点七: 无穷区间版本                              | 549        |

|                                                   |     |
|---------------------------------------------------|-----|
| 21.3.3 知识点八: 非线性端点相位的广义 Watson 形式 . . . . .       | 549 |
| 21.3.4 知识点九: Gaussian 核与偶部展开 . . . . .            | 550 |
| 21.4 Laplace 方法 I: 端点主导 . . . . .                 | 551 |
| 21.4.1 知识点十: 非驻定端点最大值 . . . . .                   | 551 |
| 21.4.2 知识点十一: 端点驻定最大值 . . . . .                   | 552 |
| 21.5 Laplace 方法 II: 内部非退化最大值、多最大值与退化最大值 . . . . . | 553 |
| 21.5.1 知识点十二: 内部唯一非退化最大值 . . . . .                | 553 |
| 21.5.2 知识点十三: 多个最大值 . . . . .                     | 553 |
| 21.5.3 知识点十四: 内部退化最大值 . . . . .                   | 554 |
| 21.6 来源例题: Stirling 公式的 Laplace 推导 . . . . .      | 554 |
| 21.7 来源综合例题: 黏性 Burgers 方程的零黏性极限 . . . . .        | 555 |
| 21.8 驻相法: 非退化驻相点的局部贡献 . . . . .                   | 558 |
| 21.8.1 知识点十五: 驻相点与非驻相区 . . . . .                  | 558 |
| 21.8.2 知识点十六: 一维非退化驻相定理 . . . . .                 | 558 |
| 21.8.3 知识点十七: 第一个修正项 . . . . .                    | 558 |
| 21.8.4 知识点十八: 端点驻相点 . . . . .                     | 559 |
| 21.8.5 知识点十九: 多个驻相点 . . . . .                     | 559 |
| 21.8.6 知识点二十: 退化驻相点 . . . . .                     | 559 |
| 21.9 驻相例题: Bessel 函数的大参数渐近 . . . . .              | 560 |
| 21.10 Airy 函数的振荡区: 驻相法与毛细波型渐近 . . . . .           | 560 |
| 21.11 复相位积分与最速下降路径 . . . . .                      | 561 |
| 21.11.1 知识点二十一: 复相位的实部与虚部 . . . . .               | 561 |
| 21.11.2 知识点二十二: 最速下降流方程 . . . . .                 | 561 |
| 21.11.3 知识点二十三: 鞍点与局部方向 . . . . .                 | 562 |
| 21.11.4 知识点二十四: 单鞍点首项 . . . . .                   | 562 |
| 21.11.5 知识点二十五: 全局路径选择 . . . . .                  | 563 |
| 21.12 来源例题: Airy 函数在正实轴的最速下降渐近 . . . . .          | 564 |
| 21.13 振荡积分中的端点奇异性: 对数振幅与复路径变形 . . . . .           | 565 |
| 21.14 多维 Laplace 方法与多维驻相公式 . . . . .              | 566 |
| 21.14.1 知识点二十六: 多维 Laplace 首项 . . . . .           | 566 |
| 21.14.2 知识点二十七: 多维驻相首项 . . . . .                  | 566 |
| 21.15 统一渐近失效: 临界点合并、端点接近与 Stokes 现象 . . . . .     | 567 |
| 21.15.1 知识点二十八: 参数依赖临界点 . . . . .                 | 567 |
| 21.15.2 知识点二十九: 驻相点接近端点 . . . . .                 | 567 |
| 21.15.3 知识点三十: 两个驻相点合并 . . . . .                  | 567 |
| 21.15.4 知识点三十一: Stokes 现象 . . . . .               | 567 |
| 21.16 渐近积分的数值条件、实现稳定性与复杂度 . . . . .               | 568 |
| 21.16.1 知识点三十二: 振荡抵消与相对条件数 . . . . .              | 568 |
| 21.16.2 知识点三十三: 直接求积的分辨率成本 . . . . .              | 568 |




|                                                          |            |
|----------------------------------------------------------|------------|
| 21.16.3 知识点三十四: Laplace 积分的上溢与下溢 . . . . .               | 568        |
| 21.16.4 知识点三十五: 渐近级数的停止准则 . . . . .                      | 569        |
| 21.17 易错点、反例与失败情形 . . . . .                              | 569        |
| 21.18 资格考试证明与分析套路 . . . . .                              | 570        |
| <b>第二十二章 正则摄动、隐式问题、特征值摄动、频率修正与 Poincaré–Lindstedt 方法</b> | <b>573</b> |
| 22.1 正则摄动的定义、判别与逐阶求解框架 . . . . .                         | 573        |
| 22.1.1 知识点一: 什么是正则摄动 . . . . .                           | 573        |
| 22.1.2 知识点二: 逐阶方程 . . . . .                              | 574        |
| 22.1.3 知识点三: 线性二阶常微分方程的标准递推 . . . . .                    | 575        |
| 22.2 隐式方程、代数根与反函数的摄动展开 . . . . .                         | 575        |
| 22.2.1 知识点四: 标量隐式方程的系数公式 . . . . .                       | 575        |
| 22.2.2 知识点五: 多重根与分数幂展开 . . . . .                         | 576        |
| 22.2.3 知识点六: 隐式展开的条件数 . . . . .                          | 577        |
| 22.3 初值问题的正则摄动、误差验证与有效区间 . . . . .                       | 577        |
| 22.3.1 知识点七: 非线性初值问题的逐阶方程 . . . . .                      | 577        |
| 22.3.2 知识点八: 固定时间区间上的误差估计 . . . . .                      | 578        |
| 22.3.3 知识点九: secular term 与固定时间展开的失效 . . . . .           | 578        |
| 22.4 Fredholm 可解性条件与共振消除 . . . . .                       | 579        |
| 22.4.1 知识点十: 抽象可解性条件 . . . . .                           | 579        |
| 22.4.2 知识点十一: 周期振子的可解性条件 . . . . .                       | 579        |
| 22.5 矩阵简单特征值的摄动展开 . . . . .                              | 580        |
| 22.5.1 知识点十二: 非 Hermitian 简单特征值的一阶修正 . . . . .           | 580        |
| 22.5.2 知识点十三: 特征向量修正与归一化 . . . . .                       | 581        |
| 22.5.3 知识点十四: Hermitian 矩阵的二阶公式 . . . . .                | 581        |
| 22.5.4 知识点十五: 特征值条件数与谱间隙 . . . . .                       | 582        |
| 22.5.5 知识点十六: 重特征值与分裂 . . . . .                          | 582        |
| 22.6 微分算子的特征值摄动 . . . . .                                | 583        |
| 22.6.1 知识点十七: 自伴算子的一阶公式 . . . . .                        | 583        |
| 22.7 正式真题 [23F–Q7]——Sturm–Liouville 特征值摄动 . . . . .      | 583        |
| 22.8 Poincaré–Lindstedt 方法 . . . . .                     | 585        |
| 22.8.1 知识点十八: 问题与目标 . . . . .                            | 585        |
| 22.8.2 知识点十九: 每阶消除共振项 . . . . .                          | 586        |
| 22.8.3 知识点二十: 二次–三次非线性振子的通用频率公式 . . . . .                | 587        |
| 22.9 正式真题 [26S–Q6]——闭轨道与周期展开 . . . . .                   | 588        |
| 22.10 Poincaré–Lindstedt 法与多尺度法的区别 . . . . .             | 593        |
| 22.11 有效区间、残量、相位误差与失败情形 . . . . .                        | 593        |
| 22.11.1 知识点二十一: 截断频率导致的相位误差 . . . . .                    | 593        |
| 22.11.2 知识点二十二: 接近分离曲线时周期展开失效 . . . . .                  | 594        |



|                                                                 |            |
|-----------------------------------------------------------------|------------|
| 22.11.3 知识点二十三: 残量小与解误差小的区别 . . . . .                           | 594        |
| 22.12 正则摄动与频率修正的易错点及答题模板 . . . . .                              | 594        |
| <b>第二十三章 奇异摄动、边界层、内外解、匹配与复合展开</b>                               | <b>596</b> |
| 23.1 奇异摄动的定义、识别信号与问题分类 . . . . .                                | 596        |
| 23.1.1 知识点一: 正则摄动与奇异摄动的本质区别 . . . . .                           | 596        |
| 23.1.2 知识点二: 四类典型快速区域 . . . . .                                 | 597        |
| 23.2 外部展开: 约化方程、递推关系与边界条件选择 . . . . .                           | 597        |
| 23.2.1 知识点三: 线性二阶问题的外部递推 . . . . .                              | 597        |
| 23.2.2 知识点四: 哪一个边界条件应分配给外部问题 . . . . .                          | 598        |
| 23.2.3 知识点五: 约化方程在转向点处失效 . . . . .                              | 598        |
| 23.3 边界层尺度: 主导平衡与快变量选择 . . . . .                                | 599        |
| 23.3.1 知识点六: 统一尺度方程 . . . . .                                   | 599        |
| 23.3.2 知识点七: 常见尺度表 . . . . .                                    | 599        |
| 23.3.3 知识点八: 退化对流系数的非整数层厚 . . . . .                             | 599        |
| 23.4 匹配原则、重叠区与一致复合展开 . . . . .                                  | 600        |
| 23.4.1 知识点九: 为什么不能只令两个近似在某一点相等 . . . . .                        | 600        |
| 23.4.2 知识点十: 领先阶匹配 . . . . .                                    | 601        |
| 23.4.3 知识点十一: 高阶匹配与 Van Dyke 原则 . . . . .                       | 601        |
| 23.4.4 知识点十二: 公共部分与加法复合展开 . . . . .                             | 601        |
| 23.5 残量、稳定性与一致误差估计 . . . . .                                    | 602        |
| 23.5.1 知识点十三: 小残量何时推出小解误差 . . . . .                             | 602        |
| 23.5.2 知识点十四: 带负零阶项问题的最大范数稳定性 . . . . .                         | 603        |
| 23.5.3 知识点十五: 函数误差与导数误差必须分开 . . . . .                           | 603        |
| 23.6 课程例题: 常系数问题的精确解、左边界层与一阶复合展开 . . . . .                      | 603        |
| 23.7 课程综合例题: 一阶内外展开的系统匹配 . . . . .                              | 605        |
| 23.8 退化边界层: 非整数尺度 $\varepsilon^{3/4}$ . . . . .                 | 607        |
| 23.9 内部层: 转向点两侧外解的连接 . . . . .                                  | 609        |
| 23.10 初始层: 快时间调整与慢流形匹配 . . . . .                                | 610        |
| 23.11 正式真题 [24F-Q6]——双边 $\sqrt{\varepsilon}$ 边界层与一致精度 . . . . . | 611        |
| 23.12 数值实现、层分辨率与计算复杂度 . . . . .                                 | 615        |
| 23.12.1 知识点十六: 直接均匀网格的代价 . . . . .                              | 615        |
| 23.12.2 知识点十七: 层适应网格与渐近公式 . . . . .                             | 615        |
| 23.13 奇异摄动易错点、反例与完整答题规范 . . . . .                               | 616        |
| <b>第二十四章 多尺度法、非线性振子、长时间有效性、模型定量分析与模块五真题映射</b>                   | <b>619</b> |
| 24.1 多尺度法的统一框架 . . . . .                                        | 619        |
| 24.1.1 问题、识别信号与基本假设 . . . . .                                   | 619        |
| 24.1.2 快慢变量和导数展开 . . . . .                                      | 620        |
| 24.1.3 领先解及振幅-相位表示 . . . . .                                    | 620        |




|                                                          |            |
|----------------------------------------------------------|------------|
| 24.1.4 共振投影和 Fredholm 可解性条件                              | 621        |
| 24.1.5 secular term 的显式来源                                | 621        |
| 24.2 平均定理、误差阶与长时间有效性                                     | 623        |
| 24.2.1 一阶平均定理                                            | 623        |
| 24.2.2 残量阶、固定时间误差与长时间误差                                  | 624        |
| 24.3 基础例题：线性弱阻尼振子与 secular term 重求和                      | 624        |
| 24.4 能量平均、振幅动力学与模型定量分析                                   | 625        |
| 24.4.1 速度型弱非线性统一振幅公式                                     | 625        |
| 24.4.2 振幅固定点和稳定性                                         | 626        |
| 24.4.3 无量纲化中的小参数识别                                       | 626        |
| 24.4.4 参数敏感性方程                                           | 626        |
| 24.5 正式真题 [25S-Q6]——三次阻尼振子的多尺度展开                         | 627        |
| 24.6 正式真题 [25F-Q6]——Rayleigh 振子、稳定极限环与相平面                | 630        |
| 24.7 WKB 方法：高频相位、输运方程、射线与焦散                              | 634        |
| 24.7.1 问题、适用条件与失败信号                                      | 635        |
| 24.8 补充训练题：丘赛 2023 Problem 6——半经典 Schrödinger 方程的 WKB 展开 | 635        |
| 24.9 渐近结果与数值模拟的定量比较                                      | 639        |
| 24.9.1 验证对象必须分层                                          | 639        |
| 24.9.2 渐近计算和直接积分的成本比较                                    | 640        |
| 24.9.3 数值验证中的误判                                          | 640        |
| 24.10 模块五正式真题映射与方法总表                                     | 640        |
| 24.10.1 六套正式试卷的模块五映射                                     | 640        |
| 24.10.2 模块五知识点优先级                                        | 641        |
| 24.10.3 渐近方法统一比较表                                        | 642        |
| 24.10.4 模型量的统一对应关系                                       | 642        |
| 24.11 模块五易错点、反例与参考答题规范                                   | 643        |
| <b>第六部分 线性规划与优化</b>                                      | <b>646</b> |
| <b>第二十五章 凸集、凸函数、分离、次梯度、投影、法锥、极集与双极理论</b>                 | <b>647</b> |
| 25.1 仿射集、凸集、凸包、凸锥与基本运算                                   | 647        |
| 25.1.1 知识点一：仿射组合与仿射集                                     | 647        |
| 25.1.2 知识点二：凸组合、凸集与凸包                                    | 647        |
| 25.1.3 知识点三：凸锥与锥包                                        | 648        |
| 25.1.4 知识点四：相对内部                                         | 649        |
| 25.1.5 知识点五：保持凸性的集合运算                                    | 649        |
| 25.2 Euclidean 投影、法锥与非扩张性                                | 650        |
| 25.2.1 知识点六：闭凸集投影的存在唯一性                                  | 650        |
| 25.2.2 知识点七：投影的变分不等式                                     | 651        |







|         |                                      |     |
|---------|--------------------------------------|-----|
| 25.2.3  | 知识点八：法锥与投影的等价关系                      | 651 |
| 25.2.4  | 知识点九：法锥的单调性与投影的牢固非扩张性                | 652 |
| 25.2.5  | 知识点十：距离函数与平方距离函数                     | 653 |
| 25.2.6  | 基础例题：投影到仿射集                          | 654 |
| 25.3    | 正式真题 [25S-Q7]——投影与平方距离函数             | 654 |
| 25.4    | 分离超平面、支撑超平面与分离裕量                     | 656 |
| 25.4.1  | 知识点十一：超平面与半空间                        | 656 |
| 25.4.2  | 知识点十二：弱分离和严格分离                       | 657 |
| 25.4.3  | 知识点十三：两个凸集的严格分离                      | 657 |
| 25.4.4  | 知识点十四：支撑超平面                          | 657 |
| 25.5    | 凸函数、严格凸、强凸、上图与次水平集                   | 659 |
| 25.5.1  | 知识点十五：扩展实值凸函数                        | 659 |
| 25.5.2  | 知识点十六：次水平集                           | 659 |
| 25.5.3  | 知识点十七：严格凸与强凸                         | 659 |
| 25.5.4  | 知识点十八：一阶与二阶判据                        | 659 |
| 25.5.5  | 知识点十九：最优性、唯一性与灵敏度                    | 660 |
| 25.6    | 正式真题：2024 Spring Problem 6——强凸型次水平集  | 660 |
| 25.7    | 次梯度、次微分、指示函数与 Fenchel 共轭             | 662 |
| 25.7.1  | 知识点二十：次梯度与次微分                        | 662 |
| 25.7.2  | 知识点二十一：内部点次微分非空和有界                   | 662 |
| 25.7.3  | 知识点二十二：最优性条件                         | 662 |
| 25.7.4  | 知识点二十三：次微分运算规则                       | 663 |
| 25.7.5  | 知识点二十四：指示函数与法锥                       | 663 |
| 25.7.6  | 知识点二十五：Fenchel 共轭                    | 664 |
| 25.8    | 正式真题 [24F-Q7]——次微分与软阈值               | 665 |
| 25.9    | 补充训练题：丘赛 2026 Problem 6——最大值函数与非负正交锥 | 668 |
| 25.10   | 对偶锥、极集、支撑函数与双极定理                     | 669 |
| 25.10.1 | 知识点二十六：对偶锥                           | 669 |
| 25.10.2 | 知识点二十七：极集                            | 669 |
| 25.10.3 | 知识点二十八：锥的极与对偶锥的关系                    | 670 |
| 25.10.4 | 知识点二十九：范数单位球的极                       | 670 |
| 25.10.5 | 知识点三十：多面体和椭球的极                       | 671 |
| 25.10.6 | 知识点三十一：双极定理                          | 671 |
| 25.10.7 | 知识点三十二：锥的 Moreau 分解                  | 671 |
| 25.11   | 正式真题 [26S-Q7]——极集与双极定理               | 673 |
| 25.12   | 数值稳定性、复杂度、证明套路与易错点                   | 674 |
| 25.12.1 | 投影、强凸性和分离的条件性                        | 674 |
| 25.12.2 | 主要计算对象的复杂度                           | 675 |
| 25.12.3 | 凸分析高频易错点                             | 675 |




|                                    |     |
|------------------------------------|-----|
| 第二十六章 线性规划标准型、顶点、基可行解、单纯形法、退化与两阶段法 | 677 |
| 26.1 线性规划模型、标准型与等价变换               | 677 |
| 26.1.1 知识点一：问题与目标                  | 677 |
| 26.1.2 知识点二：标准型                    | 677 |
| 26.1.3 知识点三：最小化和最大化的转换             | 678 |
| 26.1.4 知识点四：不等式转为等式                | 678 |
| 26.1.5 知识点五：自由变量、上下界和变量平移          | 678 |
| 26.1.6 知识点六：右端符号和冗余约束              | 679 |
| 26.1.7 基础例题：将一般线性规划化为标准型           | 679 |
| 26.2 多面体、顶点、基、基本解与基可行解             | 680 |
| 26.2.1 知识点七：顶点与极点                  | 680 |
| 26.2.2 知识点八：基、基本解和基可行解             | 680 |
| 26.2.3 知识点九：退化                     | 681 |
| 26.2.4 知识点十：支撑集刻画                  | 681 |
| 26.2.5 知识点十一：顶点的活跃约束判据             | 682 |
| 26.2.6 知识点十二：线性规划基本定理              | 682 |
| 26.3 单纯形法的字典、约化成本、枢轴与停止判据          | 683 |
| 26.3.1 知识点十三：单纯形法的核心思想             | 683 |
| 26.3.2 知识点十四：基字典                   | 684 |
| 26.3.3 知识点十五：最优性判据                 | 684 |
| 26.3.4 知识点十六：入基方向                  | 685 |
| 26.3.5 知识点十七：无界性判据                 | 685 |
| 26.3.6 知识点十八：最小比值检验                | 685 |
| 26.3.7 知识点十九：入基和出基规则               | 686 |
| 26.3.8 单纯形算法                       | 686 |
| 26.3.9 综合例题：完整单纯形枢轴                | 687 |
| 26.4 退化、多重最优解、循环与 Bland 规则         | 688 |
| 26.4.1 知识点二十：退化枢轴                  | 688 |
| 26.4.2 综合例题：零步长退化枢轴                | 689 |
| 26.4.3 知识点二十一：多重最优解                | 690 |
| 26.4.4 知识点二十二：循环                   | 690 |
| 26.4.5 知识点二十三：Bland 规则             | 690 |
| 26.4.6 知识点二十四：词典序规则                | 691 |
| 26.5 两阶段法、人工变量与初始可行基               | 691 |
| 26.5.1 知识点二十五：为什么需要第一阶段            | 691 |
| 26.5.2 知识点二十六：人工变量                 | 692 |
| 26.5.3 知识点二十七：第一阶段正确性              | 692 |
| 26.5.4 知识点二十八：人工变量的清除              | 692 |
| 26.5.5 两阶段单纯形算法                    | 693 |



|                                            |            |
|--------------------------------------------|------------|
| 26.5.6 综合例题：完整两阶段计算                        | 694        |
| 26.5.7 不可行情形                               | 695        |
| 26.5.8 知识点二十九：大 $M$ 法                      | 695        |
| 26.6 正式真题 [23F-Q6]——基可行解、顶点与对偶最优解          | 696        |
| 26.7 数值稳定性、复杂度、停止容差与失败情形                   | 698        |
| 26.7.1 知识点三十：不能显式形成 $B^{-1}$               | 698        |
| 26.7.2 知识点三十一：基矩阵条件数                       | 699        |
| 26.7.3 知识点三十二：浮点停止准则                       | 699        |
| 26.7.4 知识点三十三：复杂度                          | 700        |
| 26.7.5 知识点三十四：缩放和预处理                       | 701        |
| 26.8 线性规划与单纯形法易错点及答题模板                     | 701        |
| <b>第二十七章 线性规划对偶、强对偶、互补松弛、障碍函数与原始—对偶内点法</b> | <b>705</b> |
| 27.1 线性规划的原始—对偶配对与符号换算                     | 706        |
| 27.1.1 知识点一：最大化标准型的对偶构造                    | 706        |
| 27.1.2 知识点二：用 Lagrange 函数推导最大化对偶           | 706        |
| 27.1.3 知识点三：最小化标准型的对偶构造                    | 706        |
| 27.1.4 知识点四：一般最大化线性规划的符号表                  | 707        |
| 27.2 弱对偶、对偶间隙与最优性证书                        | 707        |
| 27.2.1 知识点五：弱对偶                            | 707        |
| 27.2.2 知识点六：对偶间隙                           | 708        |
| 27.2.3 知识点七：可计算证书                          | 708        |
| 27.3 Farkas 引理、不可行证书与强对偶                   | 709        |
| 27.3.1 知识点八：Farkas 引理                      | 709        |
| 27.3.2 知识点九：不等式系统的 Farkas 证书               | 710        |
| 27.3.3 知识点十：线性规划强对偶                        | 710        |
| 27.3.4 知识点十一：线性规划强对偶与 Slater 条件的区别         | 711        |
| 27.4 正式真题 [23F-Q6]——基可行解、对偶与强对偶            | 712        |
| 27.5 互补松弛与原始—对偶最优性                         | 714        |
| 27.5.1 知识点十二：标准型的互补松弛                      | 714        |
| 27.5.2 知识点十三：互补松弛的逻辑含义                     | 714        |
| 27.5.3 知识点十四：一般不等式形式的互补松弛                  | 714        |
| 27.5.4 知识点十五：严格互补                          | 715        |
| 27.5.5 综合例题：用互补松弛求原始—对偶最优解                 | 716        |
| 27.6 对偶变量、影子价格与灵敏度分析                       | 716        |
| 27.6.1 知识点十六：右端扰动的影子价格                     | 716        |
| 27.6.2 知识点十七：固定最优基下的右端灵敏度                  | 717        |
| 27.6.3 知识点十八：目标系数扰动                        | 717        |
| 27.6.4 知识点十九：非唯一对偶解与不可微灵敏度                 | 718        |




|          |                                   |     |
|----------|-----------------------------------|-----|
| 27.6.5   | 知识点二十：条件数与基稳定性                    | 718 |
| 27.7     | 一般凸问题的 Lagrange 对偶、Slater 条件与互补松弛 | 718 |
| 27.7.1   | 知识点二十一：一般 Lagrange 对偶             | 718 |
| 27.7.2   | 知识点二十二：一般弱对偶                      | 719 |
| 27.7.3   | 知识点二十三：Slater 条件                  | 719 |
| 27.7.4   | 知识点二十四：一般互补松弛                     | 720 |
| 27.7.5   | 课程例题：水位填充问题                       | 720 |
| 27.8     | 对数障碍函数、解析中心与中心路径                  | 721 |
| 27.8.1   | 知识点二十五：障碍函数的定义与适用条件               | 721 |
| 27.8.2   | 知识点二十六：梯度和 Hessian                | 722 |
| 27.8.3   | 知识点二十七：障碍子问题和中心路径                 | 723 |
| 27.8.4   | 知识点二十八：中心路径的近似互补关系                | 723 |
| 27.8.5   | 知识点二十九：中心点的对偶间隙                   | 723 |
| 27.8.6   | 知识点三十：等式约束 Newton 方程              | 724 |
| 27.8.7   | 知识点三十一：保持严格可行的线搜索                 | 724 |
| 27.8.8   | 知识点三十二：Newton 减量                  | 725 |
| 27.8.9   | 课程基础例题：标准单纯形的解析中心                 | 725 |
| 27.8.10  | 障碍法算法                             | 725 |
| 27.9     | 线性规划的原始障碍中心路径                     | 726 |
| 27.9.1   | 知识点三十三：原始对数障碍                     | 726 |
| 27.9.2   | 知识点三十四：中心路径间隙                     | 727 |
| 27.9.3   | 综合例题：二维线性规划的精确中心路径                | 727 |
| 27.10    | 原始—对偶内点法的扰动 KKT 系统                | 729 |
| 27.10.1  | 知识点三十五：精确 KKT 系统                  | 729 |
| 27.10.2  | 知识点三十六：三类残差                       | 729 |
| 27.10.3  | 知识点三十七：Newton 方程                  | 729 |
| 27.10.4  | 知识点三十八：消元到正规方程                    | 730 |
| 27.10.5  | 知识点三十九：对称不定增广系统                   | 730 |
| 27.10.6  | 知识点四十：边界步长                        | 731 |
| 27.10.7  | 知识点四十一：中心化参数                      | 731 |
| 27.10.8  | 知识点四十二：Mehrotra 预测—校正思想           | 732 |
| 27.10.9  | 原始—对偶内点算法                         | 732 |
| 27.10.10 | 知识点四十三：非可行迭代点上的间隙                 | 733 |
| 27.11    | 内点法的收敛性、复杂度与数值稳定性                 | 733 |
| 27.11.1  | 知识点四十四：收敛性含义                      | 733 |
| 27.11.2  | 知识点四十五：正规方程的条件数平方                 | 734 |
| 27.11.3  | 知识点四十六：正规方程与增广系统的比较               | 734 |
| 27.11.4  | 知识点四十七：数值稳定措施                     | 734 |
| 27.11.5  | 知识点四十八：严格可行性与中心路径存在               | 735 |




|                                                                              |            |
|------------------------------------------------------------------------------|------------|
| 27.11.6 知识点四十九: 齐次自对偶嵌入的作用                                                   | 735        |
| 27.11.7 知识点五十: 停止准则                                                          | 736        |
| 27.12 对偶理论与内点法的易错点、反例和完整答题规范                                                 | 736        |
| <b>第二十八章 KKT 条件、Newton 与拟 Newton 方法、BFGS、线搜索、信赖域、罚函数、障碍函数与增广 Lagrange 方法</b> | <b>741</b> |
| 28.1 一般约束优化问题、活跃约束与 KKT 条件                                                   | 741        |
| 28.1.1 知识点一: 一般非线性规划模型                                                       | 741        |
| 28.1.2 知识点二: Lagrange 函数与符号约定                                                | 741        |
| 28.1.3 知识点三: KKT 条件的完整形式                                                     | 742        |
| 28.1.4 知识点四: 约束资格条件                                                          | 742        |
| 28.1.5 知识点五: KKT 必要性                                                         | 743        |
| 28.1.6 知识点六: 凸问题中的 KKT 充分性                                                   | 744        |
| 28.2 KKT 条件的完整计算例题                                                           | 745        |
| 28.3 二阶最优性条件、临界锥与约化 Hessian                                                  | 746        |
| 28.3.1 知识点七: 线性化可行锥                                                          | 746        |
| 28.3.2 知识点八: 二阶必要条件                                                          | 747        |
| 28.3.3 知识点九: 二阶充分条件                                                          | 747        |
| 28.3.4 知识点十: 等式约束问题的约化 Hessian                                               | 747        |
| 28.4 KKT 系统的 Newton 线性化与序列二次规划                                               | 748        |
| 28.4.1 知识点十一: 等式约束 KKT 映射                                                    | 748        |
| 28.4.2 知识点十二: KKT 矩阵非奇异条件                                                    | 748        |
| 28.4.3 知识点十三: 与 SQP 子问题的等价关系                                                 | 749        |
| 28.5 无约束优化 Newton 法: 方向、局部二次收敛与修正                                            | 749        |
| 28.5.1 知识点十四: 优化 Newton 方向                                                   | 749        |
| 28.5.2 知识点十五: Newton 方向何时为下降方向                                               | 749        |
| 28.5.3 知识点十六: 局部二次收敛定理                                                       | 750        |
| 28.5.4 知识点十七: 修正 Newton 法                                                    | 751        |
| 28.5.5 知识点十八: 不精确 Newton 法                                                   | 751        |
| 28.5.6 Newton 法的算法模板                                                         | 751        |
| 28.6 线搜索: Armijo、Wolfe 条件与全局收敛                                               | 752        |
| 28.6.1 知识点十九: 下降方向与步长                                                        | 752        |
| 28.6.2 知识点二十: Armijo 充分下降条件                                                  | 752        |
| 28.6.3 知识点二十一: Armijo 回溯必定终止                                                 | 753        |
| 28.6.4 知识点二十二: Wolfe 条件                                                      | 753        |
| 28.6.5 知识点二十三: Wolfe 条件保证 BFGS 曲率条件                                          | 753        |
| 28.6.6 知识点二十四: Zoutendijk 条件                                                 | 754        |
| 28.6.7 最速下降法的强凸收敛率                                                           | 754        |
| 28.7 拟 Newton 法、DFP、BFGS 与 L-BFGS                                            | 754        |



|                                                                                |     |
|--------------------------------------------------------------------------------|-----|
| 28.7.1 知识点二十五: 割线条件的来源 . . . . .                                               | 754 |
| 28.7.2 知识点二十六: BFGS 的 Hessian 形式 . . . . .                                     | 755 |
| 28.7.3 知识点二十七: BFGS 的逆 Hessian 形式 . . . . .                                    | 755 |
| 28.7.4 知识点二十八: 正定性保持 . . . . .                                                 | 755 |
| 28.7.5 知识点二十九: DFP 更新 . . . . .                                                | 756 |
| 28.7.6 知识点三十: BFGS 超线性收敛 . . . . .                                             | 756 |
| 28.7.7 知识点三十一: 二次函数与精确线搜索 . . . . .                                            | 756 |
| 28.7.8 知识点三十二: L-BFGS . . . . .                                                | 757 |
| 28.8 补充训练题: 丘赛 2026 Problem 2——严格凸泛函、Newton 二次收敛与 Hilbert 空间<br>BFGS . . . . . | 757 |
| 28.9 信赖域方法 . . . . .                                                           | 762 |
| 28.9.1 知识点三十三: 信赖域子问题 . . . . .                                                | 762 |
| 28.9.2 知识点三十四: 信赖域子问题的最优性条件 . . . . .                                          | 762 |
| 28.9.3 知识点三十五: Cauchy 点 . . . . .                                              | 762 |
| 28.9.4 知识点三十六: 实际下降、预测下降与接受比 . . . . .                                         | 763 |
| 28.9.5 知识点三十七: Dogleg 与截断 CG . . . . .                                         | 763 |
| 28.9.6 信赖域算法 . . . . .                                                         | 764 |
| 28.9.7 知识点三十八: 信赖域收敛性 . . . . .                                                | 764 |
| 28.10 罚函数方法 . . . . .                                                          | 765 |
| 28.10.1 知识点三十九: 等式约束二次罚函数 . . . . .                                            | 765 |
| 28.10.2 知识点四十: 不等式二次罚函数 . . . . .                                              | 765 |
| 28.10.3 知识点四十一: 二次罚函数极小点的收敛 . . . . .                                          | 765 |
| 28.10.4 知识点四十二: 二次罚函数不是有限参数精确的 . . . . .                                       | 766 |
| 28.10.5 知识点四十三: 罚参数导致的条件数恶化 . . . . .                                          | 766 |
| 28.10.6 知识点四十四: 精确 $\ell^1$ 罚函数 . . . . .                                      | 767 |
| 28.10.7 外罚函数算法 . . . . .                                                       | 768 |
| 28.11 障碍函数: 与外罚法的区别及非线性约束形式 . . . . .                                          | 768 |
| 28.11.1 知识点四十五: 非线性约束的对数障碍 . . . . .                                           | 768 |
| 28.11.2 知识点四十六: 障碍 Hessian . . . . .                                           | 769 |
| 28.11.3 知识点四十七: 罚函数与障碍函数的严格区分 . . . . .                                        | 769 |
| 28.12 增广 Lagrange 方法 . . . . .                                                 | 769 |
| 28.12.1 知识点四十八: 等式约束增广 Lagrange 函数 . . . . .                                   | 769 |
| 28.12.2 知识点四十九: 乘子法 . . . . .                                                  | 770 |
| 28.12.3 知识点五十: 与对偶近端点法的关系 . . . . .                                            | 770 |
| 28.12.4 知识点五十一: 不等式约束增广 Lagrange 函数 . . . . .                                  | 770 |
| 28.12.5 知识点五十二: 增广 Lagrange 的局部与全局收敛 . . . . .                                 | 771 |
| 28.12.6 知识点五十三: 内层停止准则 . . . . .                                               | 771 |
| 28.12.7 增广 Lagrange 算法 . . . . .                                               | 771 |
| 28.13 增广 Lagrange 方法的完整计算例题 . . . . .                                          | 772 |



|                                                                |            |
|----------------------------------------------------------------|------------|
| 28.14 算法比较、条件数、数值稳定性与失败情形 . . . . .                            | 774        |
| 28.14.1 知识点五十四：问题条件数与算法稳定性 . . . . .                           | 774        |
| 28.14.2 知识点五十五：Newton 线性系统的数值误差 . . . . .                      | 775        |
| 28.14.3 知识点五十六：尺度不变性与变量缩放 . . . . .                            | 775        |
| 28.15 本部分易错点与完整答题规范 . . . . .                                  | 775        |
| <b>第二十九章 同伦、不动点、投影梯度、近端方法、<math>\ell^1</math> 优化、动态规划与总索引</b>  | <b>780</b> |
| 29.1 优化同伦、参数连续化与路径跟踪 . . . . .                                 | 780        |
| 29.1.1 知识点一：参数化问题与路径方程 . . . . .                               | 780        |
| 29.1.2 知识点二：隐函数定理与路径导数 . . . . .                               | 780        |
| 29.1.3 知识点三：预测-校正方法 . . . . .                                  | 781        |
| 29.1.4 知识点四：路径条件数与失败情形 . . . . .                               | 782        |
| 29.1.5 知识点五：伪弧长延拓 . . . . .                                    | 782        |
| 29.2 不动点映射、非扩张算子与优化最优性条件 . . . . .                             | 783        |
| 29.2.1 知识点六：四类常用映射 . . . . .                                   | 783        |
| 29.2.2 知识点七：压缩映射定理与线性收敛 . . . . .                              | 784        |
| 29.2.3 知识点八：平均映射的 Fejér 估计 . . . . .                           | 784        |
| 29.2.4 知识点九：优化问题改写为不动点 . . . . .                               | 785        |
| 29.3 补充训练题：丘赛 2021 Problem 3——标量压缩不动点迭代 . . . . .              | 786        |
| 29.4 补充训练题：丘赛 2022 Problem 2——二维 Gauss-Seidel 型不动点迭代 . . . . . | 787        |
| 29.5 投影映射与投影梯度法 . . . . .                                      | 788        |
| 29.5.1 知识点十：投影的最优性条件 . . . . .                                 | 788        |
| 29.5.2 知识点十一：投影的牢固非扩张性 . . . . .                               | 788        |
| 29.5.3 知识点十二：投影梯度迭代 . . . . .                                  | 788        |
| 29.5.4 知识点十三：梯度映射与停止准则 . . . . .                               | 789        |
| 29.5.5 知识点十四：下降估计 . . . . .                                    | 789        |
| 29.5.6 知识点十五：凸情形的 $O(1/k)$ 收敛率 . . . . .                       | 789        |
| 29.5.7 知识点十六：强凸情形的线性收敛 . . . . .                               | 790        |
| 29.6 近端映射、Moreau 包络与近端点法 . . . . .                             | 791        |
| 29.6.1 知识点十七：近端映射的存在唯一性 . . . . .                              | 791        |
| 29.6.2 知识点十八：近端映射的牢固非扩张性 . . . . .                             | 791        |
| 29.6.3 知识点十九：指标函数、投影与软阈值 . . . . .                             | 792        |
| 29.6.4 知识点二十：Moreau 包络 . . . . .                               | 792        |
| 29.6.5 知识点二十一：近端点法 . . . . .                                   | 793        |
| 29.6.6 知识点二十二：强凸时的线性收敛 . . . . .                               | 793        |
| 29.7 近端梯度、ISTA 与 FISTA . . . . .                               | 794        |
| 29.7.1 知识点二十三：前向-后向分裂 . . . . .                                | 794        |
| 29.7.2 知识点二十四：近端梯度映射 . . . . .                                 | 794        |
| 29.7.3 知识点二十五：下降性质 . . . . .                                   | 795        |



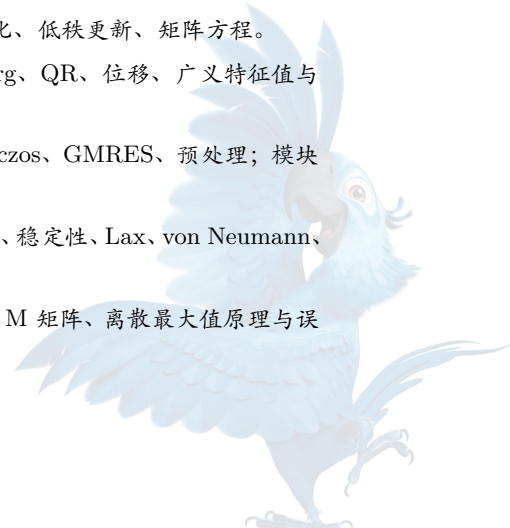
|                                                              |     |
|--------------------------------------------------------------|-----|
| 29.7.4 知识点二十六: 凸情形的收敛率 . . . . .                             | 795 |
| 29.7.5 知识点二十七: FISTA 加速 . . . . .                            | 795 |
| 29.8 $\ell^1$ 范数、稀疏性、软阈值与稀疏恢复 . . . . .                      | 796 |
| 29.8.1 知识点二十八: $\ell^1$ 次微分 . . . . .                        | 796 |
| 29.8.2 知识点二十九: Lasso 最优性条件 . . . . .                         | 797 |
| 29.8.3 知识点三十: ISTA 的软阈值形式 . . . . .                          | 797 |
| 29.8.4 知识点三十一: 基追踪及其线性规划形式 . . . . .                         | 797 |
| 29.8.5 知识点三十二: 零空间性质 . . . . .                               | 798 |
| 29.8.6 知识点三十三: $\ell^1$ 正则化路径与同伦 . . . . .                   | 798 |
| 29.9 正式真题 [25F-Q7]—— $\ell^1$ 正则化、对偶与稀疏性 . . . . .           | 799 |
| 29.10 补充训练题: 丘赛 2026 Problem 6——最大函数与非负正交锥的次微分 . . . . .     | 802 |
| 29.11 次梯度法与投影次梯度法 . . . . .                                  | 803 |
| 29.11.1 知识点三十四: 基本迭代 . . . . .                               | 803 |
| 29.12 动态规划、Bellman 原理与价值函数 . . . . .                         | 804 |
| 29.12.1 知识点三十五: 有限时域确定性控制问题 . . . . .                        | 804 |
| 29.12.2 知识点三十六: 价值函数 . . . . .                               | 804 |
| 29.12.3 知识点三十七: Bellman 最优性原理 . . . . .                      | 805 |
| 29.12.4 知识点三十八: 有限状态动态规划算法 . . . . .                         | 805 |
| 29.12.5 知识点三十九: Bellman 算子的稳定性 . . . . .                     | 805 |
| 29.12.6 知识点四十: 折扣无限时域与压缩不动点 . . . . .                        | 806 |
| 29.12.7 知识点四十一: 维数灾难 . . . . .                               | 806 |
| 29.12.8 知识点四十二: 动态规划与静态 KKT 方法的区别 . . . . .                  | 807 |
| 29.13 补充训练题: 丘赛 2022 Problem 6——整数投资分配与 Bellman 递推 . . . . . | 807 |
| 29.14 动态规划、近端方法与不动点方法的答题规范 . . . . .                         | 810 |



# 内容列表

| 模块 | 名称          | 章节部分  | 核心考试能力                                      |
|----|-------------|-------|---------------------------------------------|
| 一  | 数值分析基础与逼近   | 01-04 | 插值、逼近、数值微分；全部数值积分与 Monte Carlo。             |
| 二  | 非线性方程与常微分方程 | 05-09 | 求根收敛阶；Newton/拟 Newton；ODE 局部-整体误差、零稳定与绝对稳定。 |
| 三  | 数值线性代数      | 10-14 | 分解、扰动、低秩、特征值、Krylov、预处理、矩阵方程。               |
| 四  | 偏微分方程数值解    | 15-19 | 差分构造；稳定性、CFL、最大值原理；有限元与谱方法。                 |
| 五  | 渐近分析        | 20-24 | 主导平衡、渐近积分、正则/奇异摄动、边界层、多尺度。                  |
| 六  | 线性规划与优化     | 25-29 | 凸分析、LP、对偶、KKT、内点法、近端与动态规划。                  |

| 部分 | 模块  | 内容边界                                                             |
|----|-----|------------------------------------------------------------------|
| 01 | 模块一 | 多项式/Hermite 插值、Chebyshev 节点、Runge 现象、Lebesgue 常数、三角插值、谱微分。       |
| 02 | 模块一 | 分段插值、样条、有理逼近、最佳逼近、最小二乘、正交多项式。                                    |
| 03 | 模块一 | 数值积分 I: 插值型求积、Newton-Cotes、复合求积、误差、Euler-Maclaurin、Romberg、周期梯形。 |
| 04 | 模块一 | 数值积分 II: Gauss、Clenshaw-Curtis、自适应、奇异/多维积分、Monte Carlo；模块一总结。    |
| 05 | 模块二 | 标量非线性方程、二分、不动点、Newton、割线、重根与收敛阶。                                 |
| 06 | 模块二 | 非线性方程组、拟 Newton、Broyden、同伦、延拓与多项式求根。                             |
| 07 | 模块二 | ODE 适定性、单步法、Euler、梯形、Runge-Kutta、局部与整体误差。                        |
| 08 | 模块二 | 线性多步法、根条件、零稳定、Dahlquist 等价、绝对稳定。                                 |
| 09 | 模块二 | 刚性、A/L 稳定、自适应步长、隐式求解、边值问题扩展；模块二总结。                               |
| 10 | 模块三 | 矩阵范数、条件数、扰动、残差、后向误差与矩阵分析基础。                                      |
| 11 | 模块三 | Gaussian 消元、LU/PLU、Cholesky、QR、最小二乘与舍入误差。                        |
| 12 | 模块三 | SVD、伪逆、低秩逼近、核范数、正则化、低秩更新、矩阵方程。                                   |
| 13 | 模块三 | 幂法、反幂法、Rayleigh 商、Hessenberg、QR、位移、广义特征值与 QZ。                    |
| 14 | 模块三 | 定常迭代、CG、Krylov、Arnoldi、Lanczos、GMRES、预处理；模块三总结。                  |
| 15 | 模块四 | PDE 统一基础：网格、截断误差、相容性、稳定性、Lax、von Neumann、能量、最大值与 CFL。            |
| 16 | 模块四 | 椭圆方程有限差分、Poisson、边界条件、M 矩阵、离散最大值原理与误差估计。                         |



| 部分 | 模块  | 内容边界                                                        |
|----|-----|-------------------------------------------------------------|
| 17 | 模块四 | 抛物、对流扩散、显隐式、Crank–Nicolson、Du Fort–Frankel、IMEX、迎风与 Lax 格式。 |
| 18 | 模块四 | 波动方程、双曲系统、耦合/色散格式、数值边界条件、能量与传播。                             |
| 19 | 模块四 | 有限元、C’ea、Aubin–Nitsche、时间依赖有限元、谱方法与配点；模块四总结。                |
| 20 | 模块五 | 渐近记号、渐近序列/级数、主导平衡、量纲分析与无量纲化。                                |
| 21 | 模块五 | Watson 引理、Laplace 方法、驻相法、最速下降与振荡积分。                         |
| 22 | 模块五 | 正则摄动、隐式问题、特征值摄动、频率修正与 Poincar’e–Lindstedt。                  |
| 23 | 模块五 | 奇异摄动、边界层、内外解、匹配与复合展开。                                       |
| 24 | 模块五 | 多尺度、非线性振子、长时间有效性、模型定量分析；模块五总结。                              |
| 25 | 模块六 | 凸集、凸函数、分离、次梯度、投影、法锥、极集与双极理论。                                |
| 26 | 模块六 | LP 标准型、顶点、基可行解、单纯形、退化与两阶段法。                                 |
| 27 | 模块六 | LP 对偶、强对偶、互补松弛、障碍函数与原始–对偶内点法。                               |
| 28 | 模块六 | KKT、Newton、拟 Newton、BFGS、线搜索、信赖域、罚函数与增广 Lagrange。           |
| 29 | 模块六 | 同伦、不动点、投影梯度、近端、 $\ell^1$ 、动态规划。                             |





## 第一部分

### 数值分析基础与逼近



# 第一章 多项式插值、Chebyshev 逼近、三角插值与谱微分

## 1.1 多项式插值的统一框架：存在唯一性、Lagrange 形式与 Newton 公式

### 1.1.1 知识点一：插值问题、Vandermonde 系统与唯一性

【重要性等级】 **S 级**。多项式插值是求积公式、差分公式、谱微分、正交多项式节点以及 ODE 多步法构造的共同母题；正式试卷 [23F-Q3]、[24F-Q1]、[25F-Q2] 均直接依赖这一框架。

【问题与目标】 给定互异节点  $x_0, x_1, \dots, x_n \in [a, b]$ ,  $y_j = f(x_j)$ , 求唯一的  $p_n \in \mathbb{P}_n$  使

$$p_n(x_j) = y_j, \quad j = 0, 1, \dots, n. \quad (1.1)$$

输入是节点与数据值，输出是次数不超过  $n$  的插值多项式及其可稳定计算的表示。

#### 【精确定义与假设】


- 节点必须两两互异；若节点重复而只给函数值，条件不再独立，应改为 Hermite 插值并给导数数据。
- $f$  只需在节点处有定义即可保证插值多项式存在唯一；只有讨论余项时才需要  $f \in C^{n+1}$  等光滑性。
- 本节默认实节点；复节点情形的代数结论相同。

定理 1.1 (多项式插值存在唯一性). 若  $x_0, \dots, x_n$  两两互异，则对任意  $y_0, \dots, y_n \in \mathbb{F}$ , 存在唯一  $p_n \in \mathbb{P}_n$  满足式 (1.1)。

证明. 存在性可由后述 Lagrange 公式直接构造。唯一性方面，若  $p_n, q_n \in \mathbb{P}_n$  都满足插值条件，则  $r = p_n - q_n \in \mathbb{P}_n$  在  $n+1$  个互异点  $x_j$  处为零。非零的次数不超过  $n$  的多项式至多有  $n$  个互异零点，故  $r \equiv 0$ , 即  $p_n = q_n$ 。□

若采用单项式基  $p_n(x) = \sum_{k=0}^n a_k x^k$ , 则系数满足 Vandermonde 系统

$$V\mathbf{a} = \mathbf{y}, \quad V = \begin{pmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \vdots & \vdots & & \vdots \\ 1 & x_n & \cdots & x_n^n \end{pmatrix}, \quad \det V = \prod_{0 \leq i < j \leq n} (x_j - x_i) \neq 0. \quad (1.2)$$



这证明了存在唯一性，但通常不是推荐的数值算法：当次数增大或节点尺度不当时， $V$  可严重病态；显式求解式 (1.2) 还会破坏增量性。

【算法或离散格式】 Lagrange 基函数为

$$\ell_j(x) = \prod_{\substack{0 \leq k \leq n \\ k \neq j}} \frac{x - x_k}{x_j - x_k}, \quad \ell_j(x_i) = \delta_{ij}, \quad (1.3)$$

从而

$$I_n f(x) = p_n(x) = \sum_{j=0}^n f(x_j) \ell_j(x). \quad (1.4)$$

这里  $I_n : C([a, b]) \rightarrow \mathbb{P}_n$  称为插值算子。

【推导来源】 构造满足 Kronecker 插值条件的基函数式 (1.3)，再利用线性叠加。唯一性保证任何其他表示 (Newton、重心、Chebyshev 系数形式) 在精确算术下给出同一多项式。

【误差与精度】 存在唯一性不等于逼近误差小。误差同时受函数正则性、节点多项式  $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j)$  和插值算子范数控制；详见第 1.2 节。

【稳定性与条件数】 单项式系数问题的条件数与“从数据值到函数值”的插值问题条件数不同。即使最终多项式值尚可，单项式系数也可能极敏感。答题时应分别说明：

1. 基选择导致的系数求解病态；
2. 节点集合导致的插值算子病态；
3. 具体求值公式的舍入稳定性。

【收敛性】 对固定  $n$ ，插值问题总有唯一解；令  $n \rightarrow \infty$  时， $I_n f \rightarrow f$  并不对所有连续函数成立。高次插值的收敛性必须结合节点与函数正则性判断。

【复杂度】 直接构造全部 Lagrange 分母需  $O(n^2)$  运算、 $O(n)$  存储；朴素地在一个目标点计算所有基函数仍需  $O(n^2)$ 。重心形式可将预处理保持为  $O(n^2)$ 、每点求值降为  $O(n)$ ；特殊节点可将权重构造降为  $O(n)$ 。

【证明要求】 需要会完整证明：存在唯一性、Lagrange 公式、Vandermonde 行列式非零。需要掌握分析框架：为什么 Vandermonde 可逆不代表数值算法稳定。

#### 证明思路

识别信号：给出  $n+1$  个互异节点，要求构造次数不超过  $n$  的多项式或证明线性系统非奇异。

构造步骤：先写插值空间维数  $n+1$ ；构造 Lagrange 基或写 Vandermonde 系统；用零点个数证明唯一性。

关键估计：存在唯一性本身不需要误差估计；若题目继续问稳定性，应转向 Lebesgue 常数而不是只计算  $\det V$ 。

结论：明确节点互异是必要条件。

常见失败原因：以“方程数等于未知数个数”代替非奇异性证明；把  $\det V \neq 0$  误写成  $V$  条件数小。

## 基础例题：三点二次插值

在节点  $x_0 = -1, x_1 = 0, x_2 = 1$  上插值  $f(x) = e^x$ 。由式 (1.3),  $\ell_0(x) = \frac{x(x-1)}{2}$ ,  $\ell_1(x) = 1 - x^2$ ,  $\ell_2(x) = \frac{x(x+1)}{2}$ , 故  $p_2(x) = \frac{e^{-1}}{2}x(x-1) + (1-x^2) + \frac{e}{2}x(x+1)$ 。该表达式适合符号推导; 若需在大量点求值, 应转为重心形式或 Newton 嵌套形式。

## 1.1.2 知识点二: Newton 差商 (牛顿公式)、增量插值与嵌套求值

【重要性等级】 **S 级**。Newton 公式是“增加节点时不重算旧系数”的标准答案, 也是 Hermite 重节点差商、差分公式与插值余项的统一语言。

【问题与目标】 在保持插值多项式不变的前提下, 避免每增加一个节点就重构全部 Lagrange 基; 同时给出适合  $O(n)$  单点求值的嵌套表示。

【精确定义与假设】 零阶差商与高阶差商定义为

$$\begin{aligned} f[x_i] &= f(x_i), \\ f[x_i, \dots, x_{i+k}] &= \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i}, \quad k \geq 1. \end{aligned} \quad (1.5)$$

节点互异时分母非零。差商关于其节点对称, 虽递推定义看起来依赖顺序, 其值只依赖节点多重集。

【算法或离散格式】 Newton 公式为

$$p_n(x) = f[x_0] + \sum_{k=1}^n f[x_0, \dots, x_k] \prod_{j=0}^{k-1} (x - x_j). \quad (1.6)$$

## Algorithm 1 原地计算 Newton 差商系数

**Input:** 互异节点  $x_0, \dots, x_n$ , 数据  $f_0, \dots, f_n$

**Output:**  $a_k = f[x_0, \dots, x_k]$ ,  $k = 0, \dots, n$

- 1: **Initialization:**  $a_j \leftarrow f_j$ ,  $j = 0, \dots, n$
- 2: **for**  $k = 1, \dots, n$  **do**
- 3:     **for**  $j = n, n-1, \dots, k$  **do**
- 4:          $a_j \leftarrow (a_j - a_{j-1}) / (x_j - x_{j-k})$
- 5:     **end for**
- 6: **end for**
- 7: **Stopping criterion:** 完成第  $n$  列差商更新
- 8: **Complexity:**  $O(n^2)$  运算,  $O(n)$  额外存储

给定系数后, 用嵌套乘法

$$p_n(x) = a_0 + (x - x_0)[a_1 + (x - x_1)[\dots + (x - x_{n-1})a_n] \dots] \quad (1.7)$$

在  $O(n)$  时间、 $O(1)$  额外存储内求值。

【推导来源】 逐次加入节点。若  $p_{k-1}$  已插值  $x_0, \dots, x_{k-1}$ , 则  $p_k(x) = p_{k-1}(x) + a_k \prod_{j=0}^{k-1} (x - x_j)$ , 再用  $p_k(x_k) = f(x_k)$  确定  $a_k = f[x_0, \dots, x_k]$ 。

【误差与精度】 差商满足广义中值定理: 若  $f \in C^k$ , 则存在  $\xi$  位于节点凸包内, 使

$$f[x_0, \dots, x_k] = \frac{f^{(k)}(\xi)}{k!}. \quad (1.8)$$

该结论连接 Newton 余项与 Lagrange 余项。

**【稳定性与条件数】** Newton 公式避免求解完整 Vandermonde 系统，但差商中若节点极近，减法与小分母会放大数据噪声。节点排序影响有限精度舍入，却不改变精确插值多项式。对任意节点的大规模求值，重心公式通常更稳定。

**【收敛性】** 固定节点数时算法给出精确插值多项式； $n \rightarrow \infty$  的函数逼近收敛性仍由节点与函数决定，不能由 Newton 公式本身保证。

**【复杂度】** 全差商表为  $O(n^2)$  存储；原地版本为  $O(n)$  存储。加入一个新节点时只需新增一列/一条对角线，成本  $O(n)$ 。每个目标点嵌套求值  $O(n)$ 。

**【证明要求】** 必须会完整推导：Newton 增量形式、差商递推、嵌套求值。证明框架：差商中值定理可用 Rolle 定理或 Hermite-Genocchi 积分表示证明。

#### 证明思路

识别信号：节点逐个加入、要求递推更新、要求  $O(n)$  单点求值、出现重节点。

构造步骤：写  $p_k - p_{k-1}$  必须被  $\prod_{j < k} (x - x_j)$  整除；在新节点处求系数；递推生成差商。

关键估计：用式 (1.8) 把高阶差商转成导数界。

结论：明确预处理、求值和新增节点成本。

常见失败原因：原地更新时  $j$  从小到大，导致上一层数据被覆盖；把差商写成普通有限差分而忽略非均匀节点。

**【真题对应】** 正式试卷未单独要求写差商表，但 [23F-Q3] 的微分矩阵、[25F-Q2(c)] 的插值误差及后续 Gauss 求积都以差商/余项为前置。

## 1.2 插值余项、Lebesgue 常数、Runge 现象与节点稳定性

### 1.2.1 知识点三：Lagrange 余项与误差成立条件

**【重要性等级】** **S 级**。资格考试中“写出插值误差公式”通常只占少量分；真正的得分点是说明  $f$  的光滑性、 $\xi_x$  依赖  $x$ 、节点乘积的控制以及公式失效的情形。

**【问题与目标】** 估计  $f(x) - I_n f(x)$ ，区分“精确余项表示”和“一致范数上界”。

**【精确定义与假设】** 设  $x_0, \dots, x_n, x \in [a, b]$ ，节点互异，且  $f \in C^{n+1}[a, b]$ 。若  $x$  恰为节点，误差为零；否则可使用 Rolle 定理构造余项。

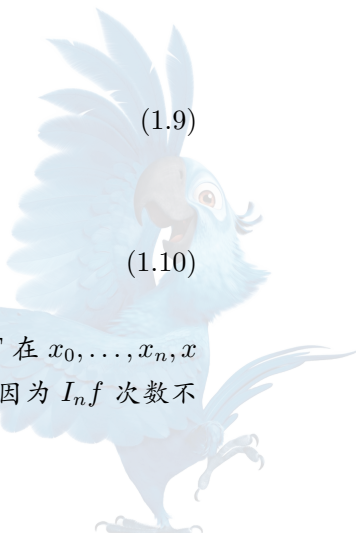
定理 1.2 (Lagrange 插值余项). 对每个  $x \in [a, b]$ ，存在依赖于  $x$  的  $\xi_x \in (a, b)$ ，使

$$f(x) - I_n f(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x), \quad \omega_{n+1}(x) = \prod_{j=0}^n (x - x_j). \quad (1.9)$$

因此

$$\|f - I_n f\|_\infty \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \|\omega_{n+1}\|_\infty. \quad (1.10)$$

证明. 固定非节点  $x$ ，令  $c = \frac{f(x) - I_n f(x)}{\omega_{n+1}(x)}$ ， $F(t) = f(t) - I_n f(t) - c\omega_{n+1}(t)$ 。函数  $F$  在  $x_0, \dots, x_n, x$  共  $n+2$  个互异点为零。连续应用 Rolle 定理  $n+1$  次，存在  $\xi_x$  使  $F^{(n+1)}(\xi_x) = 0$ 。因为  $I_n f$  次数不





超过  $n$  且  $\omega_{n+1}$  首项系数为 1,  $0 = f^{(n+1)}(\xi_x) - c(n+1)!$ , 故得到式 (1.9)。节点处由连续性或直接代入成立。□

**【算法或离散格式】** 余项不是计算算法, 因为  $\xi_x$  未知; 实际使用时以导数上界和节点多项式上界替代。

**【推导来源】** 辅助函数加上一个待定倍数的节点多项式, 使其具有  $n+2$  个零点, 再使用 Rolle 定理。

**【误差与精度】** 代数精确性与函数逼近误差必须分开。 $I_n$  对  $\mathbb{P}_n$  精确, 但若  $f^{(n+1)}$  巨大或不存在, 式 (1.10) 不能使用。

**【稳定性与条件数】** 余项控制的是精确数据、精确算术下的截断/逼近误差; 数据扰动与舍入误差由 Lebesgue 常数控制。两者不能合并为同一个“插值误差”。

**【收敛性】** 要从式 (1.10) 推出  $n \rightarrow \infty$  收敛, 必须同时控制高阶导数和  $\omega_{n+1}$ 。对一般连续函数, 导数型余项根本不可用。

**【复杂度】** 误差界本身不改变算法复杂度; 若通过自适应增加节点, 需要同步更新插值表示并监测稳定性。

**【证明要求】** 需要会完整证明 Lagrange 余项; 不能只背公式。

#### 易错点与反例

错误说法: “只要节点越来越密, 高次插值一定收敛。”

错误原因: 节点多项式、Lebesgue 常数和函数在复平面中的奇点均可能导致发散; 等距节点上的 Runge 函数是标准反例。

正确改法: 给出节点条件与函数正则性, 再使用最佳逼近误差或复分析估计。

### 1.2.2 补充训练题: 丘赛 2020 Problem 1——局部多项式近似向相邻单元延拓

#### 完整题目叙述

设  $f \in C^{k+1}[-1, 1]$ , 区间被划分为宽度为  $h$  的子区间  $I_j = [(j-1)h, jh]$ 。设  $p_j$  是次数不超过  $k$  的多项式, 并且在  $I_j$  上满足  $\max_{x \in I_j} |p_j(x) - f(x)| \leq C_0 h^{k+1}$ , 其中  $C_0$  与  $j$  无关。证明: 只要相邻区间  $I_{j \pm 1} \subset [-1, 1]$ , 就存在与  $j$  无关的常数  $C$ , 使  $\max_{x \in I_{j \pm 1}} |p_j(x) - f(x)| \leq C h^{k+1}$ 。

详细解答. 记  $I_j$  的中点为  $c_j$ , 并令  $q_j$  为  $f$  在  $c_j$  处的  $k$  阶 Taylor 多项式:  $q_j(x) = \sum_{r=0}^k \frac{f^{(r)}(c_j)}{r!} (x - c_j)^r$ 。设  $M_{k+1} = \frac{\|f^{(k+1)}\|_\infty}{(k+1)!}$ ,  $C_f = M_{k+1} \left(\frac{3}{2}\right)^{k+1}$ 。对  $x \in I_{j-1} \cup I_j \cup I_{j+1}$ , 有  $|x - c_j| \leq 3h/2$ , 故 Taylor 余项给出

$$|f(x) - q_j(x)| \leq C_f h^{k+1}. \quad (1.11)$$

令  $r_j = p_j - q_j \in \mathbb{P}_k$ 。在中心单元  $I_j$  上,

$$\|r_j\|_{L^\infty(I_j)} \leq (C_0 + C_f) h^{k+1}. \quad (1.12)$$

作仿射变换  $x = c_j + \frac{h}{2}t$ ,  $R_j(t) = r_j(c_j + \frac{h}{2}t)$ 。则  $I_j$  对应  $t \in [-1, 1]$ , 而  $I_{j+1}$  和  $I_{j-1}$  分别对应  $t \in [1, 3]$  和  $t \in [-3, -1]$ 。

下面使用 Chebyshev 区间外极值不等式：若  $R \in \mathbb{P}_k$ ，则对  $|t| \geq 1$ ，

$$|R(t)| \leq \|R\|_{L^\infty[-1,1]} |T_k(t)|. \quad (1.13)$$

为完整起见说明其证明。 $k=0$  时结论显然；以下设  $k \geq 1$  并归一化到  $\|R\|_\infty \leq 1$ 。若某  $t_0 > 1$  满足  $|R(t_0)| > |T_k(t_0)|$ ，可取  $|\alpha| < 1$  使  $\alpha R(t_0) = T_k(t_0)$ 。在  $T_k$  的  $k+1$  个交错极值点上， $T_k - \alpha R$  交替变号，因而在  $(-1, 1)$  内至少有  $k$  个零点；它还在  $t_0$  处为零，共有至少  $k+1$  个互异零点，与次数不超过  $k$  矛盾。 $t_0 < -1$  由奇偶变换同理。

由式 (1.12) and (1.13)，在任一相邻单元上  $|r_j(x)| \leq T_k(3)(C_0 + C_f)h^{k+1}$ 。再与式 (1.11) 相加，得到  $|p_j(x) - f(x)| \leq [T_k(3)(C_0 + C_f) + C_f]h^{k+1}$ 。因此可取

$$C = T_k(3)(C_0 + C_f) + C_f, \quad (1.14)$$

它只依赖  $k, C_0$  和  $\|f^{(k+1)}\|_\infty$ ，与单元编号  $j$  无关。  $\square$

#### 易错点与反例

本题不能仅写“ $p_j$  与  $f$  都连续，所以相邻区间仍然接近”。连续性不给出  $h^{k+1}$  量级，也不能保证常数与  $j$  无关。关键是用 Taylor 多项式把  $f$  局部多项式化，再用有限维多项式范数等价或 Chebyshev 区间外不等式控制  $p_j - q_j$ 。

### 1.2.3 知识点四：Lebesgue 常数、数据扰动与 Runge 现象

【重要性等级】 **B 级**。它精确区分“插值问题的条件数”和“具体求值算法的稳定性”。

【问题与目标】 量化节点数据扰动  $\delta f_j$  对整个插值多项式的最坏放大，并判断节点选择是否适合高阶插值。

【精确定义与假设】 Lebesgue 函数和 Lebesgue 常数定义为

$$\lambda_n(x) = \sum_{j=0}^n |\ell_j(x)|, \quad \Lambda_n = \max_{x \in [a,b]} \lambda_n(x) = \|I_n\|_{C \rightarrow C}. \quad (1.15)$$

其值只依赖节点，不依赖  $f$ 。

命题 1.3 (数据扰动界). 若节点数据由  $f_j$  变为  $\tilde{f}_j$ ，对应插值多项式为  $p_n, \tilde{p}_n$ ，则

$$\|p_n - \tilde{p}_n\|_\infty \leq \Lambda_n \max_{0 \leq j \leq n} |f_j - \tilde{f}_j|. \quad (1.16)$$

证明. 由线性性， $p_n(x) - \tilde{p}_n(x) = \sum_{j=0}^n (f_j - \tilde{f}_j) \ell_j(x)$ ，取绝对值和上确界即得。  $\square$

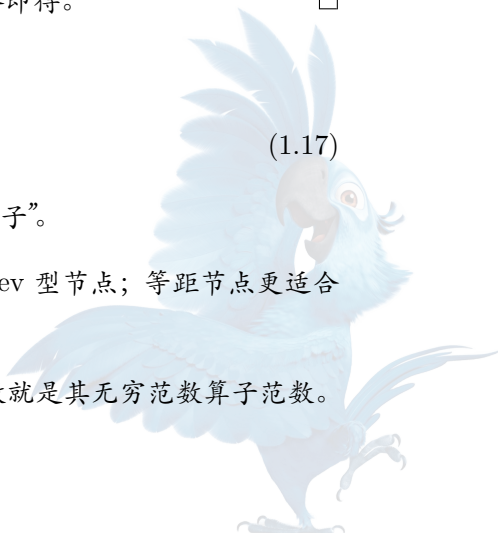
令  $E_n(f) = \inf_{q \in \mathbb{P}_n} \|f - q\|_\infty$ 。因为  $I_n q = q$ ，对任意  $q \in \mathbb{P}_n$  有

$$\|f - I_n f\|_\infty \leq (1 + \Lambda_n) E_n(f). \quad (1.17)$$

这称为 Lebesgue 引理。它把插值误差拆为“最佳逼近能力”与“节点放大因子”。

【算法或离散格式】 节点选择策略：高阶全局多项式优先使用 Chebyshev 型节点；等距节点更适合低阶分片公式，而不是直接提升全局次数。

【推导来源】 插值算子是从连续函数到  $\mathbb{P}_n$  的线性投影，Lebesgue 常数就是其无穷范数算子范数。



【误差与精度】 对 Chebyshev-Lobatto 节点  $x_j = \cos(j\pi/n)$ ,

$$\Lambda_n = \frac{2}{\pi} \log n + O(1). \quad (1.18)$$

对等距节点,  $\Lambda_n$  按  $\Theta(2^n/(n \log n))$  指数增长。因此同样的节点噪声在等距高次插值中可能被指数放大。

【稳定性与条件数】  $\Lambda_n$  是插值问题关于节点值扰动的绝对条件数; 它不是某段代码的后向误差。重心算法可使算法误差接近问题固有条件数, 但不能消除大  $\Lambda_n$ 。

【收敛性】 若  $E_n(f)$  衰减快于  $(1 + \Lambda_n)^{-1}$ , 则插值收敛。Chebyshev 节点仅有对数放大:

- 若  $f$  具有有限光滑性, 通常得到代数收敛;
- 若  $f$  可解析延拓到包含  $[-1, 1]$  的 Bernstein 椭圆, 得到几何/指数收敛;
- 若  $f$  仅连续, 仍不能无条件保证所有插值序列收敛。

【复杂度】 节点选择不改变渐近求值成本, 却显著改变可达到的有效次数与精度。Chebyshev 节点的重心权重显式可得, 无需  $O(n^2)$  乘积。

【证明要求】 需要会完整证明: 数据扰动界和 Lebesgue 引理。掌握结论: 等距指数增长、Chebyshev 对数增长。

#### 证明思路

识别信号: 题目问高次插值为何发散、数据误差放大、节点如何选择、插值与最佳逼近关系。

构造步骤: 写  $I_n$  及  $\lambda_n$ ; 对扰动或  $f - q$  应用三角不等式; 取上确界。

关键估计:  $\|I_n\| = \Lambda_n$ 。

结论: 问题条件数由节点决定; 算法稳定性另行分析。

常见失败原因: 把 Runge 现象完全归咎于浮点舍入; 认为 Chebyshev 节点使  $\Lambda_n$  有统一常数上界。

反例 1.4 (Runge 现象). 对  $f(x) = \frac{1}{1+25x^2}$ ,  $x \in [-1, 1]$ , 在等距节点上做次数  $n$  插值时, 尽管  $f$  在实轴上光滑且解析, 插值多项式可在端点附近出现不断加剧的振荡并不一致收敛。根源是距离实区间较近的复极点  $\pm i/5$  与等距节点指数增长的 Lebesgue 常数共同作用, 而不是单纯舍入误差。

## 1.3 Chebyshev 多项式、节点与极值性质

### 1.3.1 知识点五: Chebyshev 结构与极小极大证明套路

【重要性等级】 **S 级**。近三套相关正式题中, [24F-Q1] 与 [25F-Q2] 连续考查 Chebyshev 恒等式、离散正交、极值与插值误差; 它还是 CG 误差界、Clenshaw-Curtis 求积和谱方法的前置。

【问题与目标】 构造在  $[-1, 1]$  上振幅受控、零点与极值点显式、递推稳定且具有极小极大性质的多项式族。

【精确定义与假设】 第一类 Chebyshev 多项式定义为

$$T_n(x) = \cos(n \arccos x), \quad |x| \leq 1. \quad (1.19)$$

由余弦加法公式,

$$T_0 = 1, \quad T_1 = x, \quad T_{n+1} = 2xT_n - T_{n-1}. \quad (1.20)$$

故  $T_n$  确为次数  $n$  的多项式;  $n \geq 1$  时首项系数为  $2^{n-1}$ 。

**【算法或离散格式】** 递推求值适用于单点; 大量系数求值可用 Clenshaw 算法。节点分为:

$$\text{零点 (常称第一类点): } x_j^G = \cos \frac{(2j+1)\pi}{2(n+1)}, \quad j = 0, \dots, n, \quad (1.21)$$

$$\text{极值点 (常称第二类/Lobatto 点): } x_j^L = \cos \frac{j\pi}{n}, \quad j = 0, \dots, n. \quad (1.22)$$

不同资料对“第一类/第二类节点”的命名偶有互换; 全文优先使用“零点型/极值型”避免歧义。

**【推导来源】** 令  $x = \frac{1}{2}(z + z^{-1})$ , 则

$$T_n(x) = \frac{1}{2}(z^n + z^{-n}), \quad (1.23)$$

这揭示 Chebyshev、Fourier 与 Laurent 表示的同一性。

**【误差与精度】** 零点型节点的节点多项式为

$$\prod_{j=0}^n (x - x_j^G) = 2^{-n} T_{n+1}(x), \quad (1.24)$$

故其无穷范数恰为  $2^{-n}$ , 直接给出高质量插值余项界。

**【稳定性与条件数】** 极值型节点的 Lebesgue 常数仅对数增长; 其重心权重可取

$$\beta_j = \frac{(-1)^j}{c_j}, \quad c_0 = c_n = 2, \quad c_j = 1 \quad (1 \leq j \leq n-1), \quad (1.25)$$

只差一个无关的公共倍数。

**【收敛性】** 若  $f$  在 Bernstein 椭圆  $E_\rho$  内解析且  $|f(z)| \leq M$ , Chebyshev 截断和插值误差通常满足  $O(\rho^{-n})$ ; 若仅有  $s$  阶正则性, 则 Chebyshev 系数代数衰减。

**【复杂度】** Chebyshev 节点上的第二重心公式单点求值  $O(n)$ ; 通过 DCT 计算系数为  $O(n \log n)$ ; 直接解 Vandermonde 为  $O(n^3)$  且不推荐。

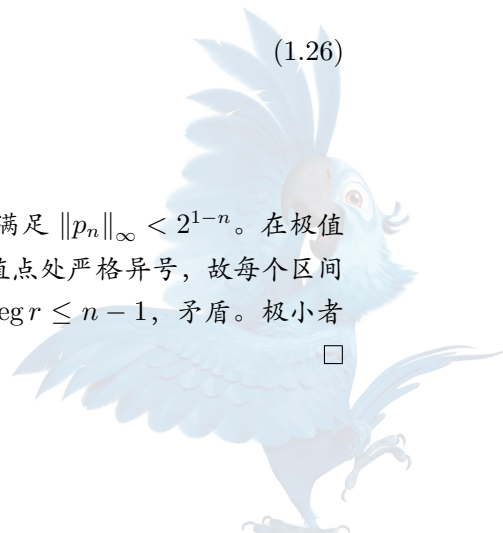
**【证明要求】** 需要会完整证明: 递推、次数与首项系数、零点/极值、复合恒等式、离散正交、单项首一多项式的极小极大性质。

**定理 1.5** (Chebyshev 极小极大性质). 在所有首一  $n$  次多项式中,

$$\min_{\substack{p \text{ 首一} \\ \deg p = n}} \|p\|_\infty = 2^{1-n}, \quad (1.26)$$

极小者为  $2^{1-n}T_n$ 。

证明. 令  $q_n = 2^{1-n}T_n$ , 则  $q_n$  首一且  $\|q_n\|_\infty = 2^{1-n}$ . 反设存在首一  $p_n$  满足  $\|p_n\|_\infty < 2^{1-n}$ . 在极值点  $x_j = \cos(j\pi/n)$  上,  $q_n(x_j) = 2^{1-n}(-1)^j$ . 于是  $r = q_n - p_n$  在相邻极值点处严格异号, 故每个区间  $(x_{j+1}, x_j)$  至少有一个零点, 共至少  $n$  个互异零点. 但  $r$  的首项相消,  $\deg r \leq n-1$ , 矛盾. 极小者唯一性可由非严格交错情形的等振荡唯一性论证得到.  $\square$



## 证明思路

识别信号：首一多项式、最大范数最小、交错极值、CG 多项式误差界。

构造步骤：缩放  $T_n$  使其满足首项/归一化约束；在  $n+1$  个交错极值点比较任意竞争多项式。

关键估计：若竞争者范数更小，则差多项式在相邻点异号，产生过多零点。

结论：给出最小值与极小者；若约束不同，先做仿射或尺度变换。

常见失败原因：把“ $p(1) = 1$ ”的平凡问题误写成首一极小极大问题；忘记  $T_n$  首项系数为  $2^{n-1}$ 。

## 1.3.2 补充训练题：丘赛 2021 Problem 1——Chebyshev 极值与插值误差

## 完整题目叙述

[Yau-20-26, 2021 Problem 1]

(a) 证明  $T_n(x) = \cos(n \arccos x)$ ,  $x \in [-1, 1]$ , 是  $n$  次多项式, 其极值点为  $x_k = \cos \frac{k\pi}{n}$ ,  $k = 0, 1, \dots, n$ , 且首项系数为  $2^{n-1}$ 。

(b) 设  $f \in C^{n+1}[-1, 1]$ ,  $P \in \mathbb{P}_n$  在上述  $n+1$  个极值点插值  $f$ 。证明  $\|f - P\|_\infty \leq \frac{1}{2^{n-1}(n+1)!} \|f^{(n+1)}\|_\infty$ 。

详细解答. (a) 多项式性、次数、首项与极值。由  $\cos((n+1)\theta) + \cos((n-1)\theta) = 2 \cos \theta \cos(n\theta)$  得递推式 (1.20)。归纳可知  $T_n \in \mathbb{P}_n$ 。若  $n \geq 1$ , 设  $T_n$  首项为  $a_n x^n$ , 则  $a_{n+1} = 2a_n$ ,  $a_1 = 1$ , 故  $a_n = 2^{n-1}$ 。

令  $x = \cos \theta$ ,  $0 \leq \theta \leq \pi$ 。有  $T'_n(x) = \frac{n \sin(n\theta)}{\sin \theta}$ , 其中端点按极限理解。内部驻点满足  $\sin(n\theta) = 0$ , 即  $\theta = k\pi/n$ ,  $k = 1, \dots, n-1$ ; 连同端点得到  $x_k = \cos(k\pi/n)$ 。且  $T_n(x_k) = \cos(k\pi) = (-1)^k$ , 故这些点为交错极值点。

(b) 节点多项式估计。令  $\omega_{n+1}(x) = \prod_{k=0}^n (x - x_k)$ 。第二类 Chebyshev 多项式  $U_{n-1}$  满足  $U_{n-1}(\cos \theta) = \frac{\sin(n\theta)}{\sin \theta}$ , 且首项系数为  $2^{n-1}$ 。由于  $x_0, \dots, x_n$  恰是  $(x^2 - 1)U_{n-1}(x)$  的全部零点, 并比较首项系数,

$$\omega_{n+1}(x) = 2^{1-n}(x^2 - 1)U_{n-1}(x). \quad (1.27)$$

写  $x = \cos \theta$ , 则  $|(x^2 - 1)U_{n-1}(x)| = |\sin \theta \sin(n\theta)| \leq 1$ 。因此  $\|\omega_{n+1}\|_\infty \leq 2^{1-n}$ 。代入 Lagrange 余项式 (1.10) 即得  $\|f - P\|_\infty \leq \frac{2^{1-n}}{(n+1)!} \|f^{(n+1)}\|_\infty$ 。□

## 1.3.3 正式真题 [24F-Q1]——切比雪夫多项式

## 完整题目叙述

第  $n$  个 Chebyshev 多项式定义为  $T_n(x) = \cos(n \arccos x)$ 。

(i) 证明  $T_n$  是  $n$  次多项式。

(ii) 对  $0 < x < 1$ , 证明  $T_n(2x - 1) = T_{2n}(\sqrt{x})$ 。

(iii) 令  $x_j = \cos \frac{(2j-1)\pi}{2n}$ ,  $j = 1, \dots, n$ , 并定义离散内积  $(u, v)_d = \sum_{j=1}^n u(x_j)v(x_j)$ 。证明  $\{T_k : 0 \leq k < n\}$  关于  $(\cdot, \cdot)_d$  正交。

详细解答. (i) 已由递推式 (1.20) 证明。更具体地,  $T_0 = 1, T_1 = x$ ; 若  $T_n, T_{n-1}$  分别为  $n, n-1$  次, 则  $2xT_n - T_{n-1}$  为  $n+1$  次, 首项系数非零。

(ii) 先证明复合恒等式

$$T_m(T_r(y)) = T_{mr}(y), \quad |y| \leq 1. \quad (1.28)$$



令  $y = \cos \theta$ , 则左端为  $T_m(\cos(r\theta)) = \cos(mr\theta) = T_{mr}(y)$ 。对  $0 < x < 1$ , 令  $y = \sqrt{x} \in (0, 1)$ 。因为  $T_2(y) = 2y^2 - 1 = 2x - 1$ , 故  $T_n(2x - 1) = T_n(T_2(y)) = T_{2n}(y) = T_{2n}(\sqrt{x})$ 。

(iii) 令  $\theta_j = \frac{(2j-1)\pi}{2n} = \frac{(j-1/2)\pi}{n}$ ,  $x_j = \cos \theta_j$ 。则  $T_k(x_j) = \cos(k\theta_j)$ 。先证对  $1 \leq r \leq 2n - 1$ ,

$$S_r := \sum_{j=1}^n \cos(r\theta_j) = 0. \quad (1.29)$$

考虑复指数和  $\sum_{j=1}^n e^{ir\theta_j} = e^{ir\pi/(2n)} \frac{1 - e^{ir\pi}}{1 - e^{ir\pi/n}}$ 。若  $r$  为偶数, 分子为零而分母非零, 故和为零; 若  $r$  为奇数, 可直接化简为纯虚数, 故其实部仍为零。于是式 (1.29) 成立。

对  $0 \leq k, \ell < n$ , 由积化和差公式,  $\sum_{j=1}^n T_k(x_j)T_\ell(x_j) = \frac{1}{2} \sum_{j=1}^n [\cos((k-\ell)\theta_j) + \cos((k+\ell)\theta_j)]$ 。若  $k \neq \ell$ , 则  $1 \leq |k-\ell| \leq n-1$  且  $1 \leq k+\ell \leq 2n-2$ , 两和均为零。若  $k = \ell \geq 1$ , 则  $\sum_{j=1}^n T_k(x_j)^2 = \frac{1}{2}(n + S_{2k}) = \frac{n}{2}$ 。若  $k = \ell = 0$ , 范数平方为  $n$ 。综上,

$$(T_k, T_\ell)_d = \begin{cases} n, & k = \ell = 0, \\ n/2, & k = \ell \geq 1, \\ 0, & k \neq \ell, \end{cases} \quad (1.30)$$

故所述多项式族离散正交。  $\square$

### 1.3.4 正式真题 [25F-Q2]——切比雪夫多项式性质

#### 前 3 小问原叙述

对连续函数  $f$  定义  $\|f\|_\infty = \max_{x \in [-1, 1]} |f(x)|$ 。由  $T_0 = 1$ ,  $T_1 = x$ ,  $T_{n+1} = 2xT_n - T_{n-1}$  定义 Chebyshev 多项式。

- (a) 证明  $T_n$  在  $|x| \leq 1$  时等于  $\cos(n \arccos x)$ , 并给出  $|x| > 1$  时的双曲余弦表示。
- (b) 证明  $\min_{\substack{p \in \mathbb{P}_n \\ p(1)=1}} \|p\|_\infty = 1$ , 且  $T_n$  可以 (但不是唯一) 达到该最小值。
- (c) 若  $f \in C^{n+1}[-1, 1]$ , 取  $T_{n+1}$  的  $n+1$  个零点为插值节点, 记  $n$  次插值多项式为  $L_n$ 。证明  $\|f - L_n\|_\infty \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!2^n}$ 。

本部分子题的详细解答. (a) 当  $|x| \leq 1$  时令  $x = \cos \theta$ , 递推初值和余弦递推一致, 故  $T_n(x) = \cos(n\theta) = \cos(n \arccos x)$ 。当  $x \geq 1$  时令  $x = \cosh \eta$ ,  $\eta = \operatorname{arcosh} x \geq 0$ 。双曲余弦满足  $\cosh((n+1)\eta) = 2 \cosh \eta \cosh(n\eta) - \cosh((n-1)\eta)$ , 故  $T_n(x) = \cosh(n \operatorname{arcosh} x)$ ,  $x \geq 1$ 。对  $x \leq -1$ , 利用奇偶性  $T_n(-x) = (-1)^n T_n(x)$ , 实值表达应写成

$$T_n(x) = (-1)^n \cosh(n \operatorname{arcosh}(-x)), \quad x \leq -1. \quad (1.31)$$

原卷将  $|x| > 1$  统一写作  $\cosh(n \operatorname{arcosh} x)$ ; 若只在实数范围讨论, 负半轴必须按式 (1.31) 解释, 不能静默把  $\operatorname{arcosh} x$  当作实数。

(b) 对任意满足  $p(1) = 1$  的多项式,  $\|p\|_\infty \geq |p(1)| = 1$ 。而  $T_n(1) = 1$  且  $|T_n(x)| \leq 1$ , 故  $T_n$  达到下界, 最小值为 1。

注意: 按原卷字面, 该极小者不唯一, 常数多项式  $p \equiv 1$  也达到最小值。标准的更强 Chebyshev 极小极大结论是定义 1.5, 其约束为“首一  $n$  次”, 不能与原卷的  $p(1) = 1$  静默替换。

(c) 设  $x_0, \dots, x_n$  为  $T_{n+1}$  的零点。因为  $T_{n+1}$  首项系数为  $2^n$ , 首一节点多项式为  $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j) = 2^{-n} T_{n+1}(x)$ 。在  $[-1, 1]$  上  $|T_{n+1}(x)| \leq 1$ , 故  $\|\omega_{n+1}\|_\infty \leq 2^{-n}$ 。由式 (1.10),  $\|f - L_n\|_\infty \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \|\omega_{n+1}\|_\infty \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!2^n}$ 。  $\square$

## 1.4 重心插值：稳定求值与复杂度

### 1.4.1 知识点六：第一、第二重心公式

【重要性等级】 **A 级**。培训材料明确将重心公式列为 Lagrange 插值的标准算法版本；资格考试可能要求写实现步骤、复杂度或解释为何不直接计算所有  $\ell_j$ 。

【问题与目标】 在不改变插值多项式的情况下，把单点求值从朴素  $O(n^2)$  降为  $O(n)$ ，并减少乘积重复与舍入误差。

【精确定义与假设】 定义节点多项式与重心权重

$$\omega(x) = \prod_{k=0}^n (x - x_k), \quad \beta_j = \frac{1}{\prod_{k \neq j} (x_j - x_k)} = \frac{1}{\omega'(x_j)}. \quad (1.32)$$

节点必须互异；权重乘以同一非零常数不改变第二重心公式。

【算法或离散格式】 由  $\ell_j(x) = \frac{\omega(x)\beta_j}{x - x_j}$  得到第一重心公式

$$p_n(x) = \omega(x) \sum_{j=0}^n \frac{\beta_j f_j}{x - x_j}, \quad (1.33)$$

以及利用  $\sum_j \ell_j(x) = 1$  得到第二重心公式

$$p_n(x) = \frac{\sum_{j=0}^n \frac{\beta_j f_j}{x - x_j}}{\sum_{j=0}^n \frac{\beta_j}{x - x_j}}. \quad (1.34)$$

---

#### Algorithm 2 第二重心公式求值

---

**Input:** 节点  $x_j$ 、数据  $f_j$ 、权重  $\beta_j$ 、目标点  $x$

**Output:**  $p_n(x)$

1: **Initialization:**  $N \leftarrow 0, D \leftarrow 0$

2: **for**  $j = 0, \dots, n$  **do**

3:     **if**  $x = x_j$  **then**

4:         **return**  $f_j$

5:     **end if**

6:      $t \leftarrow \beta_j / (x - x_j)$

7:      $N \leftarrow N + t f_j, D \leftarrow D + t$

8: **end for**

9: **Stopping criterion:** 完成全部节点累加

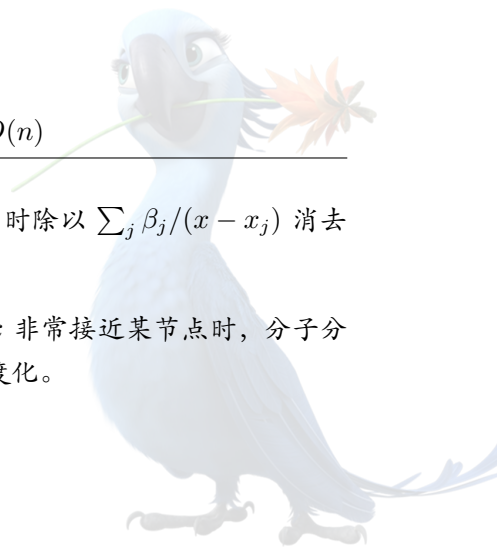
10: **return**  $N/D$

11: **Complexity:** 权重一般预处理  $O(n^2)$ ；单点求值  $O(n)$ ；额外存储  $O(n)$

---

【推导来源】 从 Lagrange 基中提出公共节点多项式；第二形式通过同时除以  $\sum_j \beta_j / (x - x_j)$  消去可能上溢/下溢的  $\omega(x)$ 。

【误差与精度】 在节点处必须直接返回  $f_j$ ，不能让程序计算  $0/0$ 。当  $x$  非常接近某节点时，分子分母均有大项，但比值保持有限；实现应避免不必要的溢出，可做统一尺度化。



【稳定性与条件数】 对区间内、Lebesgue 常数适中的节点，第二重心公式通常具有优良的前向/后向稳定性。对区间外外推，问题本身高度敏感，第二公式的分母还可能接近零，应改用第一形式并明确外推风险。

【收敛性】 重心公式只是同一插值多项式的稳定表示，不改变精确算术下的收敛或发散性质。

【复杂度】 一般权重  $O(n^2)$ ；Chebyshev–Lobatto 权重由式 (1.25) 显式给出，构造  $O(n)$ 。对  $m$  个目标点，总成本  $O(nm)$ ；若转为系数并用快速变换，可降至准线性级别。

【证明要求】 必须会推导两种重心公式；必须会写节点命中特判、复杂度和外推失败情形。

#### 易错点与反例

错误说法：“第二重心公式是有理插值，因此结果不是多项式。”

正确解释：当  $\beta_j$  恰为式 (1.32) 时，分子与分母的公共结构精确约去，结果就是唯一的多项式插值；任意选择权重才得到一般有理重心插值。

## 1.5 Hermite 插值与重节点差商

### 1.5.1 知识点七：函数值与导数值的联合插值

【重要性等级】 **A 级**。它是分段 Hermite、三次样条、Gauss 求积误差和高阶边界离散的基础。

【问题与目标】 给定互异节点  $x_0, \dots, x_n$  以及  $f(x_j), f'(x_j)$ ，求  $H_{2n+1} \in \mathbb{P}_{2n+1}$  满足

$$H_{2n+1}(x_j) = f(x_j), H'_{2n+1}(x_j) = f'(x_j), j = 0, \dots, n. \quad (1.35)$$

【精确定义与假设】 存在唯一性只需数据给定；余项要求  $f \in C^{2n+2}[a, b]$ 。节点重复不是把同一函数值重复写两遍，而是通过极限定义

$$f[\underbrace{x, \dots, x}_{r+1 \text{ 次}}] = \frac{f^{(r)}(x)}{r!}. \quad (1.36)$$

【算法或离散格式】 把节点序列展开为  $z_0 = z_1 = x_0, z_2 = z_3 = x_1, \dots$ ，在 Newton 差商表中用式 (1.36) 填充重节点差商，再使用 Newton 嵌套形式。

Lagrange 型显式基可写为

$$\begin{aligned} h_j(x) &= [1 - 2\ell'_j(x_j)(x - x_j)]\ell_j(x)^2, \\ \tilde{h}_j(x) &= (x - x_j)\ell_j(x)^2, \end{aligned} \quad (1.37)$$


从而

$$H_{2n+1}(x) = \sum_{j=0}^n [f(x_j)h_j(x) + f'(x_j)\tilde{h}_j(x)]. \quad (1.38)$$

【推导来源】 每个  $x_j$  是差多项式的二重零点。若两个多项式都满足式 (1.35)，其差被  $\prod_j (x - x_j)^2$  整除，而差的次数不超过  $2n + 1$ ，故只能恒为零。

【误差与精度】 存在  $\xi_x \in (a, b)$  使

$$f(x) - H_{2n+1}(x) = \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!} \prod_{j=0}^n (x - x_j)^2. \quad (1.39)$$



平方节点多项式正是 Gauss 求积达到  $2n+1$  代数精度的核心。

【稳定性与条件数】 导数数据的量纲与函数值不同，应在区间尺度  $h$  下使用  $hf'$  进行归一化。高阶全局 Hermite 插值对导数噪声很敏感；工程上更常用分段三次 Hermite 或样条。

【收敛性】 固定次数时余项如上；分片版本在网格加密时可得到一致阶。全局次数增加仍需节点与正则性条件。

【复杂度】 重节点差商预处理  $O(n^2)$ 、存储  $O(n)$  或  $O(n^2)$ ；单点求值  $O(n)$ 。显式基直接求值可能为  $O(n^2)$ 。

【证明要求】 需要会完整证明：唯一性与余项；必须会构造：两节点三次 Hermite 形函数。

#### 证明思路

识别信号：同时给  $f$  和  $f'$ 、节点重复、要求切触/密切插值、Gauss 误差。

构造步骤：把每个节点复制；重节点差商用导数除以阶乘；或构造值基与导数基。

关键估计： $\prod_j (x-x_j)^2$  及  $f^{(2n+2)}$  上界。

结论：写次数上界  $2n+1$ 、数据条件数  $2n+2$ 。

常见失败原因：把  $f[x, x]$  写成  $0/0$ ；余项阶数误写为  $n+1$ ；漏掉节点因子的平方。

#### 基础例题：两点三次 Hermite 插值

令  $h = b - a$ 、 $t = (x - a)/h$ 。三次 Hermite 插值为

$$H_3(x) = f(a)H_{00}(t) + hf'(a)H_{10}(t) + f(b)H_{01}(t) + hf'(b)H_{11}(t), \quad (1.40)$$

其中  $H_{00} = 2t^3 - 3t^2 + 1$ ,  $H_{10} = t^3 - 2t^2 + t$ ,  $H_{01} = -2t^3 + 3t^2$ ,  $H_{11} = t^3 - t^2$ 。若  $f \in C^4[a, b]$ ，则  $f(x) - H_3(x) = \frac{f^{(4)}(\xi_x)}{4!}(x-a)^2(x-b)^2$ 。

#### 综合例题： $\log x$ 在 $[1, 2]$ 上的三次 Hermite 插值

取  $a = 1, b = 2$ ，则  $t = x - 1$ ，且  $f(1) = 0$ ,  $f'(1) = 1$ ,  $f(2) = \log 2$ ,  $f'(2) = \frac{1}{2}$ 。由式 (1.40)， $H_3(x) = H_{10}(t) + (\log 2)H_{01}(t) + \frac{1}{2}H_{11}(t)$ 。在  $x = 3/2$  处  $t = 1/2$ ,  $H_3(3/2) = \frac{1}{16} + \frac{1}{2}\log 2 \approx 0.40907359$ 。真值  $\log(3/2) \approx 0.40546511$ 。又  $f^{(4)}(x) = -6x^{-4}$ ，故  $|f(3/2) - H_3(3/2)| \leq \frac{6}{4!} \left(\frac{1}{2}\right)^4 = \frac{1}{64}$ 。

## 1.6 三角插值、DFT、FFT、混叠与谱精度

### 1.6.1 知识点八：周期等距节点上的三角插值

【重要性等级】 **C 级**。三角插值是周期谱方法、周期梯形公式指数收敛、von Neumann 分析和 FFT 的共同基础。

【问题与目标】 给定  $2\pi$  周期函数在等距节点的采样值，构造唯一的低频三角多项式，并用 DFT 快速获得系数。

【精确定义与假设】 先取奇数点数  $N = 2m + 1$ ，节点  $x_j = \frac{2\pi j}{N}$ ,  $j = 0, \dots, N-1$ 。三角多项式空间为  $\mathcal{T}_m = \text{span}\{e^{ikx} : -m \leq k \leq m\}$ ,  $\dim \mathcal{T}_m = N$ 。



定理 1.6 (三角插值存在唯一性). 对任意数据  $f_j$ , 存在唯一  $p_m \in \mathcal{T}_m$  使  $p_m(x_j) = f_j$ , 且

$$p_m(x) = \sum_{k=-m}^m c_k e^{ikx}, \quad c_k = \frac{1}{N} \sum_{j=0}^{N-1} f_j e^{-ikx_j}. \quad (1.41)$$

证明. 离散正交关系

$$\frac{1}{N} \sum_{j=0}^{N-1} e^{i(k-\ell)x_j} = \delta_{k\ell}, \quad -m \leq k, \ell \leq m, \quad (1.42)$$

由有限几何级数直接得到。将数据方程乘  $e^{-i\ell x_j}$  并求和, 即得系数公式; DFT 矩阵可逆保证唯一性。□

【算法或离散格式】 若采用单位酉 DFT 约定  $\hat{f}_k^{(u)} = \frac{1}{\sqrt{N}} \sum_{j=0}^{N-1} f_j e^{-2\pi i j k / N}$ , 则插值系数为  $c_k = \hat{f}_k^{(u)} / \sqrt{N}$ , 不能漏掉尺度因子。

三角 Lagrange 形式为

$$p_m(x) = \frac{1}{N} \sum_{j=0}^{N-1} f_j D_m(x - x_j), \quad D_m(t) = \sum_{k=-m}^m e^{ikt} = \frac{\sin(Nt/2)}{\sin(t/2)}, \quad (1.43)$$

其中  $t=0$  按极限取  $D_m(0) = N$ 。

当  $N = 2m$  为偶数时, Nyquist 频率  $\pm m$  在采样上不可区分。必须选定约定, 例如使用

$$\text{span}\{1, \cos kx, \sin kx \ (1 \leq k < m), \cos(mx)\},$$

或在复系数中对  $\pm m$  作对称分配; 不得无条件照搬奇数  $N$  公式。

【推导来源】 周期等距节点使指数基成为离散正交基, 系数求解等价于 DFT。

【误差与精度】 若连续 Fourier 系数为  $\hat{f}_k$ , 离散系数满足混叠公式

$$c_k^{(N)} = \sum_{\ell \in \mathbb{Z}} \hat{f}_{k+\ell N}, \quad (1.44)$$

即所有相差  $N$  倍频率的模式在网格上不可区分。高频能量会折叠到低频, 而不是简单消失。

【稳定性与条件数】 单位酉 DFT 矩阵在 2-范数下条件数为 1; FFT 通常具有  $O(u \log N)$  量级的后向误差。但从采样恢复高频的连续问题仍受混叠限制, 酉性不能消除欠采样。

【收敛性】 Fourier 系数衰减由正则性决定:

- 若  $f$  有  $s$  阶周期光滑性, 系数通常按  $|k|^{-s}$  或更快衰减, 插值误差代数下降;
- 若  $f$  可解析延拓到宽度为  $\alpha$  的复条带,  $|\hat{f}_k| \leq C e^{-\alpha|k|}$ , 得到谱/指数收敛;
- 若函数在周期拼接点不连续, 出现 Gibbs 现象, 点态高阶收敛失效。

【复杂度】 直接 DFT 为  $O(N^2)$  运算; Cooley-Tukey FFT 在  $N$  可分解时为  $O(N \log N)$  运算、 $O(N)$  存储。插值系数一次计算后, 直接在任意点求值为  $O(N)$ ; 在同一网格上变换回值用逆 FFT。

---


### Algorithm 3 基于 FFT 的周期三角插值系数计算

---

**Input:** 等距样本  $f_j = f(2\pi j/N)$

**Output:** 低频插值系数  $c_k$

1. **Initialization:** 确定奇偶  $N$  与频率索引约定
2. 用 FFT 计算  $\hat{f}^{(u)} = F_N f$
3. 令  $c_k = \hat{f}_k^{(u)} / \sqrt{N}$ , 并重排负频率索引





- 4: if  $N$  为偶数 then
- 5:     按既定 Nyquist 约定处理  $k = \pm N/2$
- 6: end if
- 7: **Stopping criterion:** 所有保留频率系数已生成
- 8: **Complexity:**  $O(N \log N)$  运算,  $O(N)$  存储

【证明要求】 能够理解完整证明：离散正交、系数公式、混叠公式。会使用：FFT 复杂度与 Nyquist 特殊模式。

#### 证明思路

识别信号：周期、等距节点、复指数、循环矩阵、周期差分、FFT。

构造步骤：选频率集合；写离散正交；由 DFT 解系数；检查偶数点 Nyquist 模式。

关键估计：几何级数与 Fourier 系数尾和。

结论：说明归一化、频率索引和是否存在混叠。

常见失败原因：把三角插值等同于连续 Fourier 截断；漏掉离散系数中的混叠和。

### 1.6.2 补充训练题：[NLA-Set] 中的离散 Fourier 不确定性原理

#### 完整题目叙述

设  $x = (x_0, \dots, x_{N-1})^T \in \mathbb{R}^N$  且  $x \neq 0$ , 其单位酉离散 Fourier 变换为  $\hat{x}_w = \frac{1}{\sqrt{N}} \sum_{t=0}^{N-1} x_t \exp(-\frac{2\pi i w t}{N})$ ,  $w = 0, \dots, N-1$ . 用  $\|x\|_0$  表示  $x$  的非零分量个数。证明

$$\|x\|_0 \|\hat{x}\|_0 \geq N. \quad (1.45)$$

题面提示可证明  $\hat{x}$  不可能含有  $\|x\|_0$  个连续零。

详细解答一：范数法。记  $s = \|x\|_0$ ,  $t = \|\hat{x}\|_0$ . 对任意  $w$ , 由 Cauchy-Schwarz 不等式,  $|\hat{x}_w| \leq \frac{1}{\sqrt{N}} \|x\|_1 \leq \sqrt{\frac{s}{N}} \|x\|_2$ . 故  $\|\hat{x}\|_\infty \leq \sqrt{\frac{s}{N}} \|x\|_2$ . 另一方面,  $\hat{x}$  至多有  $t$  个非零分量, 且单位酉 DFT 满足 Parseval 恒等式, 故  $\|x\|_2 = \|\hat{x}\|_2 \leq \sqrt{t} \|\hat{x}\|_\infty \leq \sqrt{\frac{st}{N}} \|x\|_2$ . 因  $x \neq 0$ , 可约去  $\|x\|_2$ , 得到  $1 \leq \sqrt{st/N}$ , 即  $st \geq N$ .  $\square$

详细解答二：按题面提示的连续零法。设  $x$  的支撑为  $S = \{j_1, \dots, j_s\}$ . 若  $\hat{x}$  在  $s$  个连续频率  $w_0, w_0 + 1, \dots, w_0 + s - 1$  上均为零, 则  $\sum_{r=1}^s x_{j_r} \zeta^{(w_0+q)j_r} = 0$ ,  $q = 0, \dots, s-1$ ,  $\zeta = e^{-2\pi i/N}$ . 提取非零因子  $\zeta^{w_0 j_r}$  后, 系数矩阵为  $[(\zeta^{j_r})^q]_{q=0, \dots, s-1}^{r=1, \dots, s}$ , 这是以互异点  $\zeta^{j_r}$  构成的 Vandermonde 矩阵, 故可逆, 从而所有  $x_{j_r} = 0$ , 与支撑定义矛盾。因此  $\hat{x}$  的循环索引中, 每个连续零块长度至多  $s-1$ .

若  $\hat{x}$  有  $t$  个非零分量, 则其  $N-t$  个零分量被这  $t$  个非零位置分隔成至多  $t$  个零块, 因此  $N-t \leq t(s-1)$ , 即  $N \leq st$ .  $\square$

## 1.7 数值微分：差分构造、Richardson 外推与非均匀网格

### 1.7.1 知识点九：Taylor 矩条件与高阶差分

【重要性等级】 **S 级**。差分权重推导既可独立命题, 也直接用于 PDE 格式构造和谱微分矩阵。

**【问题与目标】** 用有限个函数值逼近  $f^{(m)}(x_0)$ ，给出公式、截断误差、舍入误差、最优步长、非均匀网格版本与复杂度。

**【精确定义与假设】** 设节点  $x_j = x_0 + \xi_j h$ ，构造

$$D_h^{(m)} f(x_0) = \frac{1}{h^m} \sum_{j=0}^r w_j f(x_0 + \xi_j h). \quad (1.46)$$

若希望对  $\mathbb{P}_q$  精确，权重必须满足矩条件

$$\sum_{j=0}^r w_j \xi_j^\ell = \begin{cases} m!, & \ell = m, \\ 0, & 0 \leq \ell \leq q, \ell \neq m. \end{cases} \quad (1.47)$$

**【算法或离散格式】** 常用公式：

$$\begin{aligned} D_h^+ f(x) &= \frac{f(x+h) - f(x)}{h} = f'(x) + \frac{h}{2} f''(x) + O(h^2), \\ D_h^- f(x) &= \frac{f(x) - f(x-h)}{h} = f'(x) - \frac{h}{2} f''(x) + O(h^2), \\ D_h^0 f(x) &= \frac{f(x+h) - f(x-h)}{2h} = f'(x) + \frac{h^2}{6} f^{(3)}(x) + O(h^4), \\ \delta_h^2 f(x) &= \frac{f(x+h) - 2f(x) + f(x-h)}{h^2} = f''(x) + \frac{h^2}{12} f^{(4)}(x) + O(h^4). \end{aligned} \quad (1.48)$$

五点四阶一阶导数公式为

$$f'(x) = \frac{f(x-2h) - 8f(x-h) + 8f(x+h) - f(x+2h)}{12h} + \frac{h^4}{30} f^{(5)}(\xi), \quad (1.49)$$

等价地，右端差分近似减去真导数的主误差为  $-h^4 f^{(5)}(x)/30$ 。

**【推导来源】** 逐点 Taylor 展开并解矩条件；也可先构造插值多项式，再在  $x_0$  处求导。后者自然推广到非均匀节点。

**【误差与精度】** 若公式对  $\mathbb{P}_q$  精确，则首个未消失矩决定截断阶。对称节点常使奇偶矩自动消失，产生比朴素计数更高的阶。

**【稳定性与条件数】** 差分权重绝对值之和控制数据噪声放大：若每个函数值误差不超过  $\delta$ ，则  $|\Delta D_h^{(m)}| \leq \frac{\delta}{h^m} \sum_j |w_j|$ 。因此高阶导数和小步长会强烈放大噪声。

**【收敛性】** 精确函数值下，若  $f$  有足够阶导数， $h \rightarrow 0$  时收敛。

**【复杂度】** 固定模板每点  $O(r)$  运算、 $O(1)$  额外存储；全网格  $N$  点为  $O(Nr)$ 。非均匀任意节点直接解 Vandermonde 型矩条件可能不稳定，可用 Fornberg 递推构造权重。

**【证明要求】** 必须会完整推导：前向、后向、中心、二阶中心、Richardson。掌握框架：任意节点矩条件。

#### 证明思路

识别信号：给定模板要求最高阶、非均匀节点、构造边界差分、要求消去低阶项。

构造步骤：写 Taylor 展开；列矩条件；解权重；找首个非零余项。

关键估计：权重绝对和与  $h^{-m}$  噪声放大。

结论：同时报告截断阶、所需正则性、单边/中心性质。

常见失败原因：只数节点个数就断言阶数；忽略边界处无法使用中心模板。

### 1.7.2 Richardson 外推

若

$$A(h) = A + ch^p + c_1 h^{p+1} + \cdots, \quad (1.50)$$

则

$$A_R(h) = \frac{2^p A(h/2) - A(h)}{2^p - 1} \quad (1.51)$$

消去  $ch^p$ 。外推成立的关键不是“有两个近似值”，而是存在具有稳定幂次结构的误差展开；非光滑函数、奇异点或网格改变后误差结构变化时，外推可能失效。

### 1.7.3 非均匀三点一阶导数公式

令  $h_- = x_0 - x_- > 0$ ,  $h_+ = x_+ - x_0 > 0$ 。二次插值求导给出

$$f'(x_0) \approx -\frac{h_+}{h_-(h_- + h_+)} f(x_-) + \frac{h_+ - h_-}{h_- h_+} f(x_0) + \frac{h_-}{h_+(h_- + h_+)} f(x_+), \quad (1.52)$$

若  $f \in C^3$ ，主误差为  $\frac{h_- h_+}{6} f^{(3)}(x_0) + O((h_- + h_+)^3)$ 。当  $h_- = h_+ = h$  时退化为中心差分。

### 1.7.4 补充训练题：丘赛 2023 Problem 1——差分与外推

完整题目叙述

定义  $D_h^+ f(x_0) = \frac{f(x_0+h) - f(x_0)}{h}$ ,  $D_h^0 f(x_0) = \frac{f(x_0+h) - f(x_0-h)}{2h}$ 。假设  $f$  在  $x_0$  邻域充分光滑。

- 证明  $D_h^+$  与  $D_h^0$  分别以  $O(h)$  与  $O(h^2)$  逼近  $f'(x_0)$ 。
- 从  $D_h^+$  出发，用 Richardson 外推构造  $O(h^2)$  公式。
- 取  $f(x) = \sin x, x_0 = 0$ ，证明两公式都二阶收敛，且在该特例中给出完全相同的近似值。

详细解答. (a) Taylor 展开为

$$\begin{aligned} f(x_0 + h) &= f(x_0) + hf'(x_0) + \frac{h^2}{2} f''(x_0) + \frac{h^3}{6} f^{(3)}(x_0) + O(h^4), \\ f(x_0 - h) &= f(x_0) - hf'(x_0) + \frac{h^2}{2} f''(x_0) - \frac{h^3}{6} f^{(3)}(x_0) + O(h^4). \end{aligned}$$


故  $D_h^+ f(x_0) = f'(x_0) + \frac{h}{2} f''(x_0) + O(h^2)$ ，而相减消去偶次项， $D_h^0 f(x_0) = f'(x_0) + \frac{h^2}{6} f^{(3)}(x_0) + O(h^4)$ 。

(b) 因  $D_h^+ = f' + c_1 h + c_2 h^2 + O(h^3)$ ，取  $p = 1$  使用式 (1.51)：

$$\begin{aligned} R_h f(x_0) &= 2D_{h/2}^+ f(x_0) - D_h^+ f(x_0) \\ &= \frac{-3f(x_0) + 4f(x_0 + h/2) - f(x_0 + h)}{h} = f'(x_0) - \frac{h^2}{12} f^{(3)}(x_0) + O(h^3). \end{aligned} \quad (1.53)$$

故为二阶。

(c) 因  $f(0) = 0$  且  $\sin(-h) = -\sin h$ ,  $D_h^+ f(0) = \frac{\sin h}{h}$ ,  $D_h^0 f(0) = \frac{\sin h - \sin(-h)}{2h} = \frac{\sin h}{h}$ 。又  $\frac{\sin h}{h} = 1 - \frac{h^2}{6} + \frac{h^4}{120} + O(h^6)$ ，故两者均以二阶收敛到  $f'(0) = 1$ 。前向差分在一般函数上只有一阶；此处二阶是由于  $f''(0) = 0$  使一阶误差系数偶然消失，属于点态超收敛，不能推广到一般  $x_0$ 。□



## 1.8 谱微分：插值求导矩阵、Fourier 微分与 Chebyshev 微分

### 1.8.1 知识点十：一般插值微分矩阵

【重要性等级】 **A 级**。虽然出现频率不高，但是 [23F-Q3] 直接要求从 Lagrange 基推导 Chebyshev 微分矩阵，是“公式构造 + 结构化显式计算”的典型资格考试题。

【问题与目标】 由节点值向量  $\mathbf{p} = (p(x_0), \dots, p(x_n))^T$  在线性时间/矩阵形式中得到导数节点值  $\mathbf{p}' = (p'(x_0), \dots, p'(x_n))^T = D\mathbf{p}$ 。

【精确定义与假设】 对任意互异节点，令  $\ell_j$  为 Lagrange 基。定义

$$D_{ij} = \ell'_j(x_i). \quad (1.54)$$

则对所有  $p \in \mathbb{P}_n$ ， $D$  精确给出  $p'$  在节点处的值。

若  $\beta_j$  为重权重，则

$$D_{ij} = \frac{\beta_j}{\beta_i(x_i - x_j)}, \quad i \neq j, \quad (1.55)$$

$$D_{ii} = -\sum_{j \neq i} D_{ij} = \sum_{j \neq i} \frac{1}{x_i - x_j}. \quad (1.56)$$

对角公式的第一种写法来自  $D\mathbf{1} = 0$ ，是数值实现中保证常数导数为零的关键结构。

【算法或离散格式】 构造  $D$  需  $O(n^2)$ ，矩阵-向量乘法需  $O(n^2)$ ，存储  $O(n^2)$ 。若节点对应快速变换，可采用“值  $\rightarrow$  系数  $\rightarrow$  系数求导  $\rightarrow$  值”的矩阵自由算法。

【推导来源】 对插值恒等式  $p(x) = \sum_j p(x_j)\ell_j(x)$  逐项求导，再在  $x_i$  处取值。

【误差与精度】 对非多项式  $f$ ， $D\mathbf{f}$  给出插值多项式导数而非  $f'$  本身： $D\mathbf{f} = ((I_n f)'(x_i))_i$ 。误差是“先插值再求导”的误差，通常比函数值插值损失若干阶；导数还会放大高频与噪声。

【稳定性与条件数】 Chebyshev-Lobatto 节点的最小间距为  $O(n^{-2})$ ，故一阶微分矩阵范数通常为  $O(n^2)$ ，二阶约为  $O(n^4)$ 。这不与谱精度矛盾：对光滑精确数据误差衰减快，但对噪声和显式时间步进更敏感。

【收敛性】 周期 Fourier 谱微分对解析周期函数指数收敛；Chebyshev 谱微分对非周期解析函数亦可指数收敛。若函数不光滑或边界兼容性差，只能得到代数收敛并可能出现 Gibbs 振荡。

【复杂度】 Fourier 谱微分可用 FFT 在  $O(N \log N)$  时间、 $O(N)$  存储完成：

$$\widehat{f'}_k = ik\widehat{f}_k. \quad (1.57)$$

Chebyshev 系数求导可用 DCT 与系数递推，亦为  $O(N \log N)$ ；直接微分矩阵为  $O(N^2)$ 。

【证明要求】 需要会完整证明：一般  $D_{ij} = \ell'_j(x_i)$ 、重心非对角公式、行和为零、Chebyshev 显式矩阵。

#### 证明思路

识别信号：给出节点值要求导数值、配置法、谱微分、Chebyshev 网格。

构造步骤：写插值展开；求导；用重心权重化简非对角元；用行和求对角元。

关键估计：最小节点间距、Fourier/Chebyshev 系数衰减。

结论：区分“对  $\mathbb{P}_n$  精确”和“对一般  $f$  近似”。

常见失败原因：把  $D^2$  无条件等同于独立构造的二阶矩阵而不说明多项式空间截断；忘记节点顺序改变符号。

### 1.8.2 Fourier 谱微分矩阵的显式形式

在  $x_j = 2\pi j/N$  上，令  $D^F$  表示一阶周期谱微分矩阵。对  $j \neq k$ ,

$$D_{jk}^F = \begin{cases} \frac{1}{2}(-1)^{j-k} \cot \frac{(j-k)\pi}{N}, & N \text{ 为偶数}, \\ \frac{1}{2}(-1)^{j-k} \csc \frac{(j-k)\pi}{N}, & N \text{ 为奇数}, \end{cases} \quad D_{jj}^F = 0. \quad (1.58)$$

偶数  $N$  时 Nyquist 模式必须按既定约定处理。矩阵是稠密的，但实际通常通过 FFT 实现，而不显式存储。

### 1.8.3 正式真题 [23F-Q3]——Lagrange 基函数

[23F-Q3]：完整题目叙述

设  $p$  是  $[-1, 1]$  上的  $n$  次多项式。给定  $n+1$  个节点  $x_0, \dots, x_n$ ，定义经典微分矩阵  $D = (D_{ij}) \in \mathbb{R}^{(n+1) \times (n+1)}$ ，使  $p'(x_i) = \sum_{j=0}^n D_{ij} p(x_j)$ 。

(1) 证明  $D_{ij} = \ell_j'(x_i)$ ，其中  $\ell_j$  是第  $j$  个 Lagrange 基函数。

(2) 当采用 Chebyshev-Lobatto 网格  $x_j = \cos \frac{j\pi}{n}$ ， $0 \leq j \leq n$ ，时，推导  $D_{ij}$  的显式公式。

详细解答. (1) 因  $p \in \mathbb{P}_n$ ，Lagrange 插值对  $p$  精确： $p(x) = \sum_{j=0}^n p(x_j) \ell_j(x)$ 。逐项求导并令  $x = x_i$ ，得到  $p'(x_i) = \sum_{j=0}^n p(x_j) \ell_j'(x_i)$ ，与  $D$  的定义比较即得  $D_{ij} = \ell_j'(x_i)$ 。

(2) 非对角元。令  $c_j = \begin{cases} 2, & j=0 \text{ 或 } j=n, \\ 1, & 1 \leq j \leq n-1, \end{cases} \quad \beta_j = \frac{(-1)^j}{c_j}$ 。下面说明  $\beta_j$  是 Chebyshev-Lobatto

节点的重心权重，至多差一个公共常数。节点多项式可取  $q(x) = (1-x^2)T_n'(x)$ ，其零点正是  $x_0, \dots, x_n$ 。对内部点  $x_j$ ， $T_n'(x_j) = 0$ ，而 Chebyshev 微分方程

$$(1-x^2)T_n''(x) - xT_n'(x) + n^2T_n(x) = 0 \quad (1.59)$$

给出  $q'(x_j) = (1-x_j^2)T_n''(x_j) = -n^2T_n(x_j) = -n^2(-1)^j$ 。端点处  $q'(1) = -2T_n'(1) = -2n^2$ ， $q'(-1) = 2T_n'(-1) = 2(-1)^{n-1}n^2$ 。故  $1/q'(x_j)$  与  $(-1)^j/c_j$  只差公共因子，结论成立。

由式 (1.55)，对  $i \neq j$ ，

$$D_{ij} = \frac{c_i}{c_j} \frac{(-1)^{i+j}}{x_i - x_j}, \quad i \neq j. \quad (1.60)$$

内部对角元。一般节点多项式  $q$  满足  $\ell_i'(x_i) = \frac{q''(x_i)}{2q'(x_i)}$ 。对内部  $x_i$ ，由  $q = (1-x^2)T_n'$ ， $q'(x_i) = (1-x_i^2)T_n''(x_i)$ ，且  $q''(x_i) = -4x_iT_n''(x_i) + (1-x_i^2)T_n'''(x_i)$ 。对式 (1.59) 求导，得  $(1-x^2)T_n''' - 3xT_n'' + (n^2-1)T_n' = 0$ 。在  $T_n'(x_i) = 0$  处， $(1-x_i^2)T_n'''(x_i) = 3x_iT_n''(x_i)$ ，故  $q''(x_i) = -x_iT_n''(x_i)$ ，从而

$$D_{ii} = -\frac{x_i}{2(1-x_i^2)}, \quad 1 \leq i \leq n-1. \quad (1.61)$$



端点对角元。对  $x_0 = 1$ ，端点 Lagrange 基可写为  $\ell_0(x) = \frac{(1+x)T'_n(x)}{2n^2}$ 。由式 (1.59) 在  $x = 1$  处取极限， $T'_n(1) = n^2$ 。再对式 (1.59) 求导并在  $x = 1$  处取值， $-3T''_n(1) + (n^2 - 1)T'_n(1) = 0$ ，故  $T''_n(1) = \frac{n^2(n^2-1)}{3}$ 。于是

$$D_{00} = \ell'_0(1) = \frac{T'_n(1) + 2T''_n(1)}{2n^2} = \frac{2n^2 + 1}{6}.$$

由节点与多项式的对称性， $D_{nn} = -D_{00} = -\frac{2n^2+1}{6}$ 。最终

$$D_{ij} = \begin{cases} \frac{c_i}{c_j} \frac{(-1)^{i+j}}{x_i - x_j}, & i \neq j, \\ -\frac{x_i}{2(1-x_i^2)}, & 1 \leq i = j \leq n-1, \\ \frac{2n^2+1}{6}, & i = j = 0, \\ -\frac{2n^2+1}{6}, & i = j = n. \end{cases} \quad (1.62)$$

作为核对，任意一行元素之和必须为零，因为  $D\mathbf{1} = 0$ 。□

#### 算法说明

实现建议：非对角元按式 (1.60) 计算；对角元优先设为负行和，以减少公式与浮点节点误差不一致造成的  $D\mathbf{1} \neq 0$ 。若  $n$  很大且只需矩阵作用，采用 Chebyshev 系数递推/DCT 而不显式存储  $D$ 。

#### 复杂度说明

显式构造与存储  $D$  均为  $O(n^2)$ ；一次稠密矩阵-向量乘为  $O(n^2)$ 。基于 DCT 的矩阵自由微分可达  $O(n \log n)$  时间和  $O(n)$  存储。由于  $\|D\| = O(n^2)$ ，显式时间离散的稳定步长往往受  $O(n^{-2})$  或更严限制。

#### 易错点与反例

错误说法 1： $D_{ii} = 0$ 。这只对周期 Fourier 一阶微分矩阵成立，不适用于 Chebyshev 网格。

错误说法 2：所有节点的  $c_j$  都等于 1。端点权重必须取  $c_0 = c_n = 2$ 。

错误说法 3：谱精度意味着  $D$  条件数小。Chebyshev 节点端点聚集使  $\|D\|$  随  $n^2$  增长，谱精度与噪声放大是不同概念。



## 第二章 分段插值、样条、有理逼近、最佳逼近与正交多项式

### 2.1 分段低次插值：局部性、稳定性与误差阶

设  $a = x_0 < x_1 < \cdots < x_n = b$ ,  $h_i = x_{i+1} - x_i$ ,  $h = \max_{0 \leq i \leq n-1} h_i$ 。分段方法的核心思想是：不通过提高单个全局多项式的次数来提高分辨率，而是保持局部次数较低，通过减小网格宽度获得收敛。与全局高次插值相比，其主要优势是：

1. 局部修改一个数据点只影响有限个相邻区间；
2. 条件数通常不随总节点数指数增长；
3. 可避免等距高次插值的 Runge 端点振荡；
4. 计算与存储复杂度通常关于节点数线性增长。

#### 2.1.1 知识点一：分段线性插值

【重要性等级】 **A 级**。分段线性插值是有限元形函数、复合求积、网格函数延拓和误差局部化的最基本模型。

【问题与目标】 给定节点值  $f_i = f(x_i)$ ,  $i = 0, \dots, n$ , 构造连续函数  $I_h^1 f$ , 使其在每个子区间  $[x_i, x_{i+1}]$  上为一次多项式, 并满足  $I_h^1 f(x_i) = f_i$ 。

【精确定义与假设】 对  $x \in [x_i, x_{i+1}]$ , 定义

$$I_h^1 f(x) = \frac{x_{i+1} - x}{h_i} f_i + \frac{x - x_i}{h_i} f_{i+1}. \quad (2.1)$$

若只讨论存在性, 则只需节点互异且数据给定; 若讨论二阶误差, 则需  $f \in C^2[a, b]$ 。

【算法或离散格式】

---

**Algorithm 4** 分段线性插值求值

---

**Input:** 节点  $x_0 < \cdots < x_n$ 、数据  $f_0, \dots, f_n$ 、目标点  $x \in [a, b]$

**Output:**  $I_h^1 f(x)$

- 1: **Initialization:** 定位满足  $x \in [x_i, x_{i+1}]$  的区间
- 2:  $t \leftarrow (x - x_i)/h_i$
- 3:  $p \leftarrow (1 - t)f_i + tf_{i+1}$
- 4: **Stopping criterion:** 返回  $p$
- 5: **Complexity:** 区间已知时  $O(1)$ ; 一般有序节点二分定位  $O(\log n)$ ; 均匀网格可  $O(1)$  定位; 存储  $O(n)$



【推导来源】 在每个子区间上使用两点 Lagrange 插值。

【误差与精度】 由两点插值余项，对每个  $x \in [x_i, x_{i+1}]$ ，存在  $\xi_x \in (x_i, x_{i+1})$  使

$$f(x) - I_h^1 f(x) = \frac{f''(\xi_x)}{2} (x - x_i)(x - x_{i+1}). \quad (2.2)$$

因为  $\max_{x \in [x_i, x_{i+1}]} |(x - x_i)(x - x_{i+1})| = \frac{h_i^2}{4}$ ，故

$$\|f - I_h^1 f\|_{L^\infty(x_i, x_{i+1})} \leq \frac{h_i^2}{8} \|f''\|_{L^\infty(x_i, x_{i+1})}, \quad (2.3)$$

从而

$$\|f - I_h^1 f\|_{L^\infty(a, b)} \leq \frac{h^2}{8} \|f''\|_\infty. \quad (2.4)$$

在每个开区间  $(x_i, x_{i+1})$  内， $(I_h^1 f)'(x) = \frac{f_{i+1} - f_i}{h_i}$ 。由中值定理及  $f'$  的 Lipschitz 连续性，

$$\|f' - (I_h^1 f)'\|_{L^\infty(x_i, x_{i+1})} \leq h_i \|f''\|_{L^\infty(x_i, x_{i+1})}. \quad (2.5)$$

【稳定性与条件数】 由于式 (2.1) 中的两个权重非负且和为 1，

$$|I_h^1 f(x)| \leq \max\{|f_i|, |f_{i+1}|\}, \quad \|I_h^1 f\|_\infty \leq \max_j |f_j|. \quad (2.6)$$

故分段线性插值在节点值的  $\ell^\infty$  扰动下具有条件数 1。其局部 Lebesgue 常数恰为 1。

【收敛性】 若  $f \in C^2[a, b]$  且  $h \rightarrow 0$ ，则由式 (2.4)  $I_h^1 f \rightarrow f$  在  $L^\infty(a, b)$  中二阶收敛。若  $f$  仅连续，仍可利用一致连续性证明  $I_h^1 f \rightarrow f$ ，但一般不能宣称二阶。

【复杂度】 构造仅保存节点与函数值，存储为  $O(n)$ 。每点求值在均匀网格上为  $O(1)$ 。与全局插值相比，无需解 Vandermonde 系统。

【证明要求】 需要会完整证明：余项公式、 $h^2/8$  误差界与无穷范数稳定性。

#### 证明思路

识别信号：题目给出网格、只要求连续、每段一次、要求局部误差或最大模稳定性。

构造步骤：在单元上写两点 Lagrange 公式；使用二阶余项；最大化节点乘积。

关键估计： $|(x - x_i)(x - x_{i+1})| \leq h_i^2/4$ 。

结论：函数值误差二阶，导数误差一阶；稳定常数为 1。

常见失败原因：把分段线性函数写成全局一次多项式；在节点处无条件讨论经典导数；在  $f \notin C^2$  时使用二阶余项。

#### 基础例题：指数函数的分段线性误差

在  $[0, 1]$  上取均匀网格  $x_i = ih$ ，用分段线性插值逼近  $f(x) = e^x$ 。因为  $\max_{x \in [0, 1]} |f''(x)| = e$ ，由式 (2.4)， $\|e^x - I_h^1 f\|_\infty \leq \frac{e}{8} h^2$ 。若要求该上界不超过  $10^{-4}$ ，只需  $h \leq \sqrt{\frac{8 \times 10^{-4}}{e}}$ 。

### 2.1.2 知识点二：分段三次 Hermite 插值

【重要性等级】 **B 级**。其局部四阶误差、形函数和导数数据处理是三次样条与高阶有限元的直接前置。

**【问题与目标】** 给定每个节点处的函数值  $f_i$  及斜率  $d_i$ ，在每个区间上构造三次多项式  $H_i$  满足  $H_i(x_i) = f_i$ ,  $H'_i(x_i) = d_i$ ,  $H_i(x_{i+1}) = f_{i+1}$ ,  $H'_i(x_{i+1}) = d_{i+1}$ 。

**【精确定义与假设】** 令  $t = \frac{x-x_i}{h_i} \in [0, 1]$ 。定义标准 Hermite 形函数

$$\begin{aligned} H_{00}(t) &= 2t^3 - 3t^2 + 1, \\ H_{10}(t) &= t^3 - 2t^2 + t, \\ H_{01}(t) &= -2t^3 + 3t^2, \\ H_{11}(t) &= t^3 - t^2. \end{aligned} \quad (2.7)$$

则

$$H_i(x) = f_i H_{00}(t) + h_i d_i H_{10}(t) + f_{i+1} H_{01}(t) + h_i d_{i+1} H_{11}(t). \quad (2.8)$$

**【算法或离散格式】** 若  $d_i = f'(x_i)$  已知，则各单元可完全独立构造。若  $d_i$  未知，可使用有限差分、单调性保持斜率或通过全局样条方程确定。

**【推导来源】** 在每个单元上求解四个线性条件确定四个三次多项式系数；等价地使用两点 Hermite 插值公式。

**【误差与精度】** 若  $d_i = f'(x_i)$  且  $f \in C^4[x_i, x_{i+1}]$ ，则

$$f(x) - H_i(x) = \frac{f^{(4)}(\xi_x)}{4!} (x - x_i)^2 (x - x_{i+1})^2. \quad (2.9)$$

由于  $\max_{x \in [x_i, x_{i+1}]} (x - x_i)^2 (x - x_{i+1})^2 = \frac{h_i^4}{16}$ ，有

$$\|f - H_i\|_{L^\infty(x_i, x_{i+1})} \leq \frac{h_i^4}{384} \|f^{(4)}\|_{L^\infty(x_i, x_{i+1})}. \quad (2.10)$$

若使用近似斜率  $\tilde{d}_i = d_i + \eta_i$ ，则额外误差为  $h_i \eta_i H_{10}(t) + h_i \eta_{i+1} H_{11}(t)$ 。因此若  $\eta_i = O(h^p)$ ，斜率误差对函数值插值通常贡献  $O(h^{p+1})$ 。要保持整体四阶，需要节点斜率至少三阶准确。

**【稳定性与条件数】** 形函数在参考区间上有界，因此局部函数值扰动和经过  $h_i$  尺度化的导数扰动不会随总节点数累积。然而，若直接使用高噪声导数数据， $h_i d_i$  仍可能引入明显振荡。

**【收敛性】** 精确斜率时，函数值四阶收敛；一阶导数通常三阶，二阶导数通常二阶。若斜率只是一阶近似，函数值误差通常退化为二阶。

**【复杂度】** 已知斜率时，构造与每点求值均为局部  $O(1)$ ，总存储  $O(n)$ 。无全局线性系统。

#### 易错点与反例

分段三次 Hermite 不自动是三次样条。它通常只有  $C^1$  连续性；三次样条要求全局  $C^2$ 。若相邻单元的二阶导数在节点处不匹配，就不能称为三次样条。

## 2.2 三次样条插值：构造、边界条件、唯一性与误差

### 2.2.1 知识点三：样条空间及自由度计数

**【重要性等级】** **B 级**。样条边界条件决定唯一性，是本模块最需要注意的地方，本质上就是“多少个解多少个未知数”。

**【问题与目标】** 寻找  $S \in C^2[a, b]$ ，使  $S|_{[x_i, x_{i+1}]} \in \mathbb{P}_3$ ,  $S(x_i) = f_i$ ,  $i = 0, \dots, n$ 。

定义 2.1 (三次样条空间). 对剖分  $\Delta = \{a = x_0 < x_1 < \cdots < x_n = b\}$ , 定义

$$\mathcal{S}_3(\Delta) = \{S \in C^2[a, b] : S|_{[x_i, x_{i+1}]} \in \mathbb{P}_3\}. \quad (2.11)$$

每个区间有 4 个系数, 共  $4n$  个; 每个内部节点要求函数值、一阶导数、二阶导数连续, 共  $3(n-1)$  个条件。因此

$$\dim \mathcal{S}_3(\Delta) = 4n - 3(n-1) = n + 3. \quad (2.12)$$

插值条件提供  $n+1$  个独立约束, 仍剩 2 个自由度。因此必须补充两个边界条件。

### 【常见边界条件】

1. 自然边界 (natural):

$$S''(x_0) = S''(x_n) = 0. \quad (2.13)$$

2. 夹持/完全边界 (clamped/complete):

$$S'(x_0) = s_0, \quad S'(x_n) = s_n. \quad (2.14)$$

当  $s_0 = f'(x_0), s_n = f'(x_n)$  时, 通常可获得完整四阶误差。

3. 周期边界 (periodic): 要求  $f_0 = f_n$  并施加

$$S'(x_0) = S'(x_n), \quad S''(x_0) = S''(x_n). \quad (2.15)$$

4. 非扭结边界 (not-a-knot): 要求  $S'''$  在  $x_1$  和  $x_{n-1}$  连续, 即最左两个单元、最右两个单元分别属于同一个三次多项式。

### 易错点与反例

错误说法: 给定  $n+1$  个节点值就唯一决定三次样条。

错误原因: 三次样条插值还剩 2 个自由度。

正确改法: 必须写明自然、夹持、周期、not-a-knot 或其他两条独立边界条件。

## 2.2.2 知识点四：三弯矩方程

令  $M_i = S''(x_i)$ ,  $\delta_i = \frac{f_{i+1} - f_i}{h_i}$ 。由于  $S''$  在每个单元上为一次函数,

$$S''(x) = M_i \frac{x_{i+1} - x}{h_i} + M_{i+1} \frac{x - x_i}{h_i}, \quad x \in [x_i, x_{i+1}]. \quad (2.16)$$

积分两次并使用  $S(x_i) = f_i, S(x_{i+1}) = f_{i+1}$ , 得到

$$\begin{aligned} S_i(x) &= \frac{M_i(x_{i+1} - x)^3}{6h_i} + \frac{M_{i+1}(x - x_i)^3}{6h_i} \\ &\quad + \left(f_i - \frac{M_i h_i^2}{6}\right) \frac{x_{i+1} - x}{h_i} + \left(f_{i+1} - \frac{M_{i+1} h_i^2}{6}\right) \frac{x - x_i}{h_i}. \end{aligned} \quad (2.17)$$


在内部节点  $x_i$  要求一阶导数连续, 得到

$$h_{i-1}M_{i-1} + 2(h_{i-1} + h_i)M_i + h_iM_{i+1} = 6(\delta_i - \delta_{i-1}), \quad i = 1, \dots, n-1. \quad (2.18)$$

对自然边界,  $M_0 = M_n = 0$ 。对夹持边界,

$$2h_0M_0 + h_0M_1 = 6(\delta_0 - s_0), \quad (2.19)$$

$$h_{n-1}M_{n-1} + 2h_{n-1}M_n = 6(s_n - \delta_{n-1}). \quad (2.20)$$





对周期边界, 可取  $M_n = M_0$  并补充

$$h_{n-1}M_{n-1} + 2(h_{n-1} + h_0)M_0 + h_0M_1 = 6(\delta_0 - \delta_{n-1}). \quad (2.21)$$

### Algorithm 5 三弯矩法构造三次样条

**Input:** 节点  $x_i$ 、数据  $f_i$ 、边界条件

**Output:** 各节点弯矩  $M_i$  及每个单元的三次多项式

- 1: **Initialization:** 计算  $h_i = x_{i+1} - x_i$  及  $\delta_i = (f_{i+1} - f_i)/h_i$
- 2: 按式 (2.18) 组装三对角或循环三对角系统
- 3: 根据自然、夹持、周期或 not-a-knot 条件写首末方程
- 4: 用 Thomas 算法或循环三对角算法求解  $M_i$
- 5: **for**  $i = 0, \dots, n-1$  **do**
- 6:   按式 (2.17) 生成  $S_i(x)$
- 7: **end for**
- 8: **Stopping criterion:** 所有单元系数已生成
- 9: **Complexity:** 三对角系统  $O(n)$  运算、 $O(n)$  存储; 一般稠密求解不应使用

**【存在唯一性】** 以自然样条为例, 未知量为  $M_1, \dots, M_{n-1}$ 。系数矩阵对称, 且第  $i$  行满足  $2(h_{i-1} + h_i) > h_{i-1} + h_i$ , 故严格对角占优, 从而非奇异。夹持系统同样严格对角占优。周期系统为循环三对角系统, 可由正定性或能量方法证明唯一性。

**【稳定性与条件数】** 若网格比  $\frac{\max_i h_i}{\min_i h_i}$  有统一上界, 则三弯矩系统具有与网格尺度协调的稳定性。高度不均匀网格会恶化矩阵条件数, 并放大二阶导数数据。

**【复杂度】** 自然与夹持样条可用 Thomas 算法在线性时间内求解。周期样条可用循环三对角消元或 Sherman-Morrison 修正, 仍为  $O(n)$ 。

#### 基础例题: 三节点自然三次样条

给定  $(x_0, f_0) = (0, 0)$ ,  $(x_1, f_1) = (1, 1)$ ,  $(x_2, f_2) = (2, 0)$ 。取自然边界  $M_0 = M_2 = 0$ 。因为  $h_0 = h_1 = 1$ ,  $\delta_0 = 1$ ,  $\delta_1 = -1$ 。内部方程为  $4M_1 = 6(\delta_1 - \delta_0) = -12$ , 故  $M_1 = -3$ 。

由式 (2.17),  $S(x) = \begin{cases} -\frac{1}{2}x^3 + \frac{3}{2}x, & 0 \leq x \leq 1, \\ -\frac{1}{2}(2-x)^3 + \frac{3}{2}(2-x), & 1 \leq x \leq 2. \end{cases}$  可直接验证  $S(0) = 0$ ,  $S(1) = 1$ ,  $S(2) = 0$ ,  $S', S''$  在  $x=1$  连续, 且  $S'''(0) = S'''(2) = 0$ 。

### 2.2.3 知识点五: 自然样条的变分刻画


**定理 2.2** (最小弯曲能量性质). 设  $S$  是节点  $x_i$  上的自然三次样条插值函数。对任意  $g \in H^2(a, b)$  满足  $g(x_i) = S(x_i) = f_i$ ,  $i = 0, \dots, n$ , 都有

$$\int_a^b |S'''(x)|^2 dx \leq \int_a^b |g'''(x)|^2 dx. \quad (2.22)$$

等号仅当  $g = S$ 。

证明. 令  $v = g - S$ , 则  $v(x_i) = 0$ 。先证明正交关系  $\int_a^b S'''v'' dx = 0$ 。逐单元分部积分:

$$\sum_{i=0}^{n-1} \int_{x_i}^{x_{i+1}} S'''v'' dx = \sum_{i=0}^{n-1} [S'''v']_{x_i}^{x_{i+1}} - \sum_{i=0}^{n-1} [S''''v]_{x_i}^{x_{i+1}}.$$



第一组内部边界项因  $S''$  连续而相消, 外端点项因自然边界  $S''(a) = S''(b) = 0$  而为零。第二组边界项因  $v(x_i) = 0$  而全部为零。故正交关系成立。

于是  $\int_a^b |g''|^2 = \int_a^b |S'' + v''|^2 = \int_a^b |S''|^2 + \int_a^b |v''|^2 \geq \int_a^b |S''|^2$ 。若等号成立, 则  $v'' = 0$ , 故  $v$  为一次函数。又  $v$  在至少两个不同节点处为零, 故  $v \equiv 0$ 。□

**【识别信号】** 题目出现“最平滑插值”、“弯曲能量”、“最小化  $\int |u''|^2$ ”、“自然端点条件”时, 应立即想到自然样条的变分刻画。

#### 2.2.4 知识点六: 样条误差估计及边界失配

对于拟均匀剖分, 即存在与  $h$  无关的  $\rho > 0$  使  $\frac{\max_i h_i}{\min_i h_i} \leq \rho$ , 有以下典型结论。

**定理 2.3** (匹配边界条件下的三次样条误差). 设  $f \in C^4[a, b]$ ,  $S$  为夹持样条且使用精确端点斜率  $S'(a) = f'(a)$ ,  $S'(b) = f'(b)$ , 或  $f$  与  $S$  满足相容的周期边界条件。则存在只依赖网格规则性的常数  $C$ , 使

$$\|(f - S)^{(r)}\|_{\infty} \leq Ch^{4-r} \|f^{(4)}\|_{\infty}, \quad r = 0, 1, 2, \quad (2.23)$$

且在每个开单元上  $\|(f - S)^{(3)}\|_{L^{\infty}(x_i, x_{i+1})} \leq Ch \|f^{(4)}\|_{\infty}$ 。

自然样条必须额外检查边界匹配。一般地, 可写成阶数型估计

$$\|f - S_N\|_{\infty} \leq C [h^4 \|f^{(4)}\|_{\infty} + h^2 (|f''(a)| + |f''(b)|)]. \quad (2.24)$$

因此:

- 若  $f''(a) = f''(b) = 0$ , 自然样条可保持四阶函数值误差;
- 若端点二阶导数不为零, 最大模整体误差一般只有  $O(h^2)$ ;
- 远离端点的内部区域可能仍表现出更高阶精度。

**反例 2.4** (自然样条不无条件再现二次多项式). 取  $f(x) = x^2$ 。虽然  $f^{(4)} \equiv 0$ , 但  $f''(a) = f''(b) = 2$ 。自然样条要求  $S''(a) = S''(b) = 0$ , 故除退化情形外  $S \neq f$ 。因此不能对任意  $f \in C^4$  无条件写  $\|f - S_N\|_{\infty} \leq Ch^4 \|f^{(4)}\|_{\infty}$ 。

#### 2.2.5 补充训练题: 丘赛 2021 Problem 2——三次样条的线性传播

##### 完整题目叙述

设  $S(x)$  是结点  $t_0 < t_1 < \cdots < t_n$  上的三次样条。已知  $S$  在  $[t_1, t_2]$  和  $[t_3, t_4]$  上都是一次函数。证明:  $S$  在中间区间  $[t_2, t_3]$  上也必为一次函数。

**详细解答.** 因为  $S$  在  $[t_1, t_2]$  上为一次函数, 所以  $S''(x) = 0$ ,  $x \in (t_1, t_2)$ 。由三次样条的  $C^2$  连续性,  $S''(t_2) = 0$ 。同理,  $S$  在  $[t_3, t_4]$  上为一次函数, 故  $S''(t_3) = 0$ 。

另一方面, 在中间区间  $[t_2, t_3]$  上,  $S$  是次数不超过 3 的多项式, 因此  $S''$  是次数不超过 1 的一次多项式。一个次数不超过 1 的多项式若在两个互异点  $t_2, t_3$  处都为零, 则恒等于零:  $S''(x) \equiv 0$ ,  $x \in [t_2, t_3]$ 。因此  $S$  在  $[t_2, t_3]$  上为一次函数。□

## 2.2.6 知识点七：B 样条的基本概念

给定非降结点序列  $t_0 \leq t_1 \leq \cdots \leq t_M$ , 零次 B 样条定义为  $N_{i,0}(x) = \begin{cases} 1, & t_i \leq x < t_{i+1}, \\ 0, & \text{其他.} \end{cases}$   $p$  次 B 样条由 Cox-de Boor 递推定义:

$$N_{i,p}(x) = \frac{x - t_i}{t_{i+p} - t_i} N_{i,p-1}(x) + \frac{t_{i+p+1} - x}{t_{i+p+1} - t_{i+1}} N_{i+1,p-1}(x), \quad (2.25)$$

其中分母为零的项按零处理。

其核心性质为:

1. 局部支撑:  $\text{supp } N_{i,p} \subset [t_i, t_{i+p+1}]$ .
2. 非负性:  $N_{i,p}(x) \geq 0$ .
3. 单位分解: 在有效参数区间内  $\sum_i N_{i,p}(x) = 1$ .
4. 局部修改: 改变一个系数只影响至多  $p+1$  个结点区间。
5. 光滑性: 若内部结点重数为  $r$ , 则跨该结点一般为  $C^{p-r}$ 。

B 样条表示  $S(x) = \sum_i c_i N_{i,p}(x)$  避免了逐段单项式系数的大规模耦合。用 de Boor 算法在一个点求值仅需局部  $p+1$  个系数; 固定次数下, 每点成本为  $O(p^2)$ , 与总节点数无关。

## 易错点与反例

错误说法: B 样条是一个特定插值函数。

正确解释: B 样条是样条空间的一组局部基函数。系数  $c_i$  需由插值、最小二乘、变分或控制点条件确定。

## 2.3 有理插值与 Padé 逼近

## 2.3.1 知识点八: 有理插值

【重要性等级】 **B 级**。正式六套试卷尚未单独设置有理逼近题, 但考纲明确要求; 其极点、稳定性和失败情形是高次多项式逼近的重要补充。

【问题与目标】 用

$$r_{m,n}(x) = \frac{p_m(x)}{q_n(x)}, \quad p_m \in \mathbb{P}_m, \quad q_n \in \mathbb{P}_n, \quad (2.26)$$

逼近或插值函数  $f$ , 并通过分母表示函数的极点、远场衰减或快速变化。

【精确定义与假设】 给定  $m+n+1$  个互异节点  $x_i$  及数据  $y_i$ , 要求  $r_{m,n}(x_i) = y_i$ 。因  $p, q$  同时乘非零常数不改变  $r$ , 必须选定归一化, 例如  $q_n(0) = 1$  或最高阶非零系数为 1。插值条件可写为

$$p_m(x_i) - y_i q_n(x_i) = 0, \quad i = 0, \dots, m+n. \quad (2.27)$$

这是关于  $p, q$  系数的线性齐次/归一化系统, 但还必须验证  $q_n(x_i) \neq 0$ 。若  $p(x_i) = q(x_i) = 0$ , 原条件只得到  $0=0$ , 并不定义有限插值。

【重心有理形式】 给定非零权重  $\lambda_j$ , 可写

$$r(x) = \frac{\sum_{j=0}^N \frac{\lambda_j f_j}{x - x_j}}{\sum_{j=0}^N \frac{\lambda_j}{x - x_j}}. \quad (2.28)$$

若分母在  $x_j$  处按极限解释, 且  $\lambda_j \neq 0$ , 则  $r(x_j) = f_j$ 。与多项式重心公式不同, 一般权重产生的确实是有理函数。

【误差与精度】 有理逼近可把函数的奇点或极点编码进分母, 因此对近极点函数往往远优于同自由度多项式。但误差不再只由节点多项式决定, 分母的最小模  $\min_{x \in [a, b]} |q_n(x)|$  进入误差常数。

【稳定性与条件数】 若  $q_n$  在逼近区间内接近零, 则微小数据扰动会产生巨大输出误差。数据噪声还可能产生相邻的伪极点—伪零点对, 称为 Froissart 双联体。

【复杂度】 一般系数系统为稠密系统, 直接求解约为  $O((m+n)^3)$ ; 重心形式预处理后单点求值为  $O(N)$ 。近秩亏时应使用带主元 QR 或 SVD, 而不应直接解法方程。

【识别信号】 函数具有已知极点、边界层、无穷远代数衰减、高次多项式振荡, 或题目要求“用较低自由度表示非多项式结构”。

#### 易错点与反例

有理逼近的高阶并不自动意味着稳定。分母零点是额外自由度, 也是额外风险。答案必须检查极点是否落在目标区间、节点处是否出现 0/0 以及系数系统是否秩亏。

### 2.3.2 知识点九: Padé 逼近

设  $f$  在  $z=0$  附近有 Taylor 展开  $f(z) = \sum_{k=0}^{\infty} c_k z^k$ 。[ $m/n$ ] 型 Padé 逼近为  $R_{m,n}(z) = \frac{P_m(z)}{Q_n(z)}$ , 其中  $Q_n(0) = 1$ , 且满足

$$Q_n(z)f(z) - P_m(z) = O(z^{m+n+1}). \quad (2.29)$$

写  $Q_n(z) = 1 + \sum_{j=1}^n q_j z^j$ ,  $P_m(z) = \sum_{k=0}^m p_k z^k$ 。比较系数得到:

$$\sum_{j=1}^n c_{k-j} q_j = -c_k, \quad k = m+1, \dots, m+n, \quad (2.30)$$

$$p_k = \sum_{j=0}^{\min(k,n)} q_j c_{k-j}, \quad k = 0, \dots, m, \quad (2.31)$$

其中  $q_0 = 1$ 。

#### Algorithm 6 [ $m/n$ ] 型 Padé 逼近

**Input:** Taylor 系数  $c_0, \dots, c_{m+n}$

**Output:**  $P_m, Q_n$  或秩亏诊断

- 1: **Initialization:** 设置  $q_0 = 1$
- 2: 由式 (2.30) 组装  $n \times n$  线性系统
- 3: 用带主元 QR 或 SVD 求  $q_1, \dots, q_n$
- 4: 由式 (2.31) 计算  $p_0, \dots, p_m$



- 5: 检查  $P_m, Q_n$  是否有近公共因子以及  $Q_n$  在目标区域是否接近零  
 6: **Stopping criterion:** 返回约分后的有理函数及极点诊断  
 7: **Complexity:** 一般稠密求解  $O(n^3)$ ; 存储  $O(n^2)$ ; 结构化算法可更快

【存在唯一性】 若式 (2.30) 非奇异, 则归一化后唯一。若系统奇异, 则可能:

1. 无法得到满次数分母;
2. 存在多个形式不同但约分后相同的表示;
3. 出现缺陷 Padé 逼近;
4. 对系数扰动高度敏感。

基础例题:  $e^z$  的  $1/1$  型 Padé 逼近

对  $e^z = 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \cdots$ , 取  $m = n = 1$ 。由  $k = 2$  的方程  $c_1 q_1 = -c_2$  得到  $q_1 = -\frac{1}{2}$ 。再由  $p_0 = c_0 = 1$ ,  $p_1 = c_1 + q_1 c_0 = \frac{1}{2}$ , 故

$$R_{1,1}(z) = \frac{1 + z/2}{1 - z/2}. \quad (2.32)$$

展开可得  $R_{1,1}(z) = 1 + z + \frac{z^2}{2} + \frac{z^3}{4} + O(z^4)$ , 因此  $e^z - R_{1,1}(z) = -\frac{z^3}{12} + O(z^4)$ 。

该逼近用两个一阶多项式获得了二阶 Taylor 匹配, 并保持  $R_{1,1}(-z) = R_{1,1}(z)^{-1}$ 。但它在  $z = 2$  处有极点, 而  $e^z$  是整函数; 该极点是有理逼近引入的结构, 不能解释为原函数真极点。

综合例题: 有理逼近对极点函数的优势

对  $f(z) = \frac{1}{1-z}$ , 任意有限次数 Taylor 截断  $1 + z + \cdots + z^m$  只能在  $|z| < 1$  内按几何级数意义逼近, 而  $[0/1]$  型 Padé 逼近直接给出  $R_{0,1}(z) = \frac{1}{1-z} = f(z)$ , 在除极点  $z = 1$  外的整个定义域精确。

这说明: 当函数具有低阶有理结构时, 有理逼近可用极少自由度精确表示; 但若极点位置由噪声数据估计, 极点误差可能主导整个逼近。

## 2.4 内积空间中的最佳逼近与正交投影

### 2.4.1 知识点十: 投影定理与 Gram 方程

【重要性等级】 **S 级**。它统一解释连续最小二乘、离散最小二乘、Galerkin 方法、Fourier 展开、正交多项式和正规方程。

【问题与目标】 设  $H$  为内积空间,  $V = \text{span}\{\phi_0, \dots, \phi_n\}$  为有限维子空间。给定  $f \in H$ , 求

$$p^* = \arg \min_{p \in V} \|f - p\|. \quad (2.33)$$

【精确定义与假设】 本文复内积对第一个变量共轭线性、对第二个变量线性。基函数  $\phi_j$  线性无关。有限维子空间自动闭, 因此最佳逼近存在唯一。

定理 2.5 (正交投影定理). 元素  $p^* \in V$  是  $f$  在  $V$  中的最佳逼近, 当且仅当

$$\langle \phi_i, f - p^* \rangle = 0, \quad i = 0, \dots, n. \quad (2.34)$$



证明. 若式 (2.34) 成立, 则对任意  $p = p^* + v \in V$ ,  $f - p = (f - p^*) - v$ ,  $\langle f - p^*, v \rangle = 0$ . 由 Pythagoras 恒等式,  $\|f - p\|^2 = \|f - p^*\|^2 + \|v\|^2 \geq \|f - p^*\|^2$ . 且等号仅在  $v = 0$  时成立, 故  $p^*$  唯一。

反之, 若  $p^*$  为极小点, 对任意  $v \in V$  考虑  $\varphi(t) = \|f - p^* - tv\|^2$ . 实数情形对  $t$  求导并在  $t = 0$  取值, 得到  $\varphi'(0) = -2\langle v, f - p^* \rangle = 0$ . 复数情形分别取  $v$  与  $iv$ , 得到完整复正交条件。□

写  $p^* = \sum_{j=0}^n a_j \phi_j$ , 则式 (2.34) 化为 Gram 系统

$$Ga = b, G_{ij} = \langle \phi_i, \phi_j \rangle, b_i = \langle \phi_i, f \rangle. \quad (2.35)$$

命题 2.6 (Gram 矩阵的正定性). 若  $\phi_0, \dots, \phi_n$  线性无关, 则  $G$  为 Hermitian 正定矩阵。

证明. 对任意  $c \neq 0$ ,  $c^* G c = \left\langle \sum_i c_i \phi_i, \sum_j c_j \phi_j \right\rangle = \left\| \sum_j c_j \phi_j \right\|^2 > 0$ . □

### 【算法或离散格式】

**Algorithm 7** 连续最佳平方逼近的 Gram 法

**Input:** 基函数  $\phi_0, \dots, \phi_n$ 、目标  $f$ 、内积  $\langle \cdot, \cdot \rangle$

**Output:** 最佳逼近系数  $a$

- 1: **Initialization:** 设  $G_{ij} = \langle \phi_i, \phi_j \rangle$ ,  $b_i = \langle \phi_i, f \rangle$
- 2: 计算全部 Gram 矩阵项和右端项
- 3: 若  $G$  正定, 使用 Cholesky 分解求  $Ga = b$
- 4: 检查残差  $f - \sum_j a_j \phi_j$  与每个基函数正交
- 5: **Stopping criterion:** 正交残差达到理论或数值容差
- 6: **Complexity:** 组装取决于积分成本; 稠密求解  $O(n^3)$ 、存储  $O(n^2)$ ; 正交基时降为  $O(n)$  个独立系数

【误差与精度】 若  $\{\phi_j\}$  为正交基, 则

$$a_j = \frac{\langle \phi_j, f \rangle}{\|\phi_j\|^2}. \quad (2.36)$$

若为标准正交基, 则  $a_j = \langle \phi_j, f \rangle$ . 此时

$$\|f - p^*\|^2 = \|f\|^2 - \sum_{j=0}^n \frac{|\langle \phi_j, f \rangle|^2}{\|\phi_j\|^2}. \quad (2.37)$$

【稳定性与条件数】 Gram 法的数值稳定性取决于基函数条件数。单项式基往往产生 Hilbert 型 Gram 矩阵; 正交基使  $G$  对角化。最佳逼近问题本身良态, 不等于任意基下的系数求解良态。

【收敛性】 若子空间序列  $V_n$  递增且其并在  $H$  中稠密, 则  $\|f - P_{V_n} f\| \rightarrow 0$ . 收敛率由  $f$  的正则性和基函数逼近性质决定。

【证明要求】 需要会完整证明: 投影定理、Gram 正定性、Pythagoras 误差分解。

### 证明思路

识别信号: 最小化平方范数、有限维函数空间、要求正规方程或“残差与空间正交”。

构造步骤: 写任意扰动  $p^* + tv$ ; 对平方范数求导; 得到正交条件; 展开为 Gram 系统。

关键估计: Pythagoras 恒等式。

结论: 存在唯一性来自子空间闭与范数严格凸。

常见失败原因：把最佳平方逼近误写成逐点插值；只写正规方程而不说明 Gram 矩阵为何可逆。

基础例题： $e^x$  在  $\text{span}\{1, x\}$  中的最佳平方逼近

在  $L^2[-1, 1]$  中求  $p_1(x) = a + bx$  使  $\|e^x - p_1\|_2$  最小。因为 1 与  $x$  正交， $a = \frac{\int_{-1}^1 e^x dx}{\int_{-1}^1 1 dx} = \frac{e - e^{-1}}{2} = \sinh 1$ 。又  $\int_{-1}^1 x e^x dx = [(x-1)e^x]_{-1}^1 = \frac{2}{e}$ ，且  $\int_{-1}^1 x^2 dx = \frac{2}{3}$ ，故  $b = \frac{2/e}{2/3} = \frac{3}{e}$ 。因此

$$p_1^*(x) = \sinh 1 + \frac{3}{e}x. \quad (2.38)$$

残差满足  $\int_{-1}^1 (e^x - p_1^*) dx = 0$ ,  $\int_{-1}^1 x(e^x - p_1^*) dx = 0$ 。

## 2.5 离散最小二乘、法方程、QR 与 SVD

设有  $m$  个数据点  $(x_i, y_i)$  和  $n+1$  个基函数  $\phi_j$ ，其中  $m \geq n+1$ 。定义设计矩阵  $A_{ij} = \phi_j(x_i)$ ， $\mathbf{y} = (y_1, \dots, y_m)^\top$ 。离散最小二乘问题为

$$\min_{\mathbf{a} \in \mathbb{R}^{n+1}} \|\mathbf{A}\mathbf{a} - \mathbf{y}\|_2. \quad (2.39)$$

若数据权重为  $w_i > 0$ ，令  $W = \text{diag}(w_1, \dots, w_m)$ ，则加权问题为  $\min_{\mathbf{a}} \|W^{1/2}(\mathbf{A}\mathbf{a} - \mathbf{y})\|_2$ 。

### 2.5.1 法方程

对目标函数  $\Phi(\mathbf{a}) = \frac{1}{2} \|\mathbf{A}\mathbf{a} - \mathbf{y}\|_2^2$  求梯度，得到

$$A^\top A \mathbf{a} = A^\top \mathbf{y}. \quad (2.40)$$

加权情形为  $A^\top W A \mathbf{a} = A^\top W \mathbf{y}$ 。若  $A$  满列秩，则  $A^\top A$  正定，解唯一。

#### 易错点与反例

法方程会平方 2-范数条件数：

$$\kappa_2(A^\top A) = \kappa_2(A)^2. \quad (2.41)$$

因此“法方程矩阵对称正定”不等于“数值上最优”。当  $A$  病态时，应优先使用 QR；秩亏或近秩亏时使用 SVD。

### 2.5.2 QR 与 SVD 的角色

若  $A = QR$  为薄 QR 分解，其中  $Q^\top Q = I$ 、 $R$  上三角，则  $\|\mathbf{A}\mathbf{a} - \mathbf{y}\|_2^2 = \|\mathbf{R}\mathbf{a} - Q^\top \mathbf{y}\|_2^2 + \|(I - QQ^\top)\mathbf{y}\|_2^2$ 。故满列秩时解三角系统

$$\mathbf{R}\mathbf{a} = Q^\top \mathbf{y}. \quad (2.42)$$

若  $A = U\Sigma V^\top$ ，则最小范数最小二乘解为

$$\mathbf{a}^\dagger = V\Sigma^\dagger U^\top \mathbf{y}. \quad (2.43)$$

QR 与 SVD 的完整稳定性、秩亏处理和复杂度分析将在第 12-13 部分系统展开。

**Algorithm 8** 离散最小二乘的稳健求解选择

**Input:** 设计矩阵  $A \in \mathbb{R}^{m \times (n+1)}$ 、数据  $\mathbf{y}$ 、容差  $\text{tol}$

**Output:** 最小二乘解及秩诊断

- 1: **Initialization:** 对列尺度进行必要归一化
- 2: **if**  $A$  明确满列秩且条件适中 **then**
- 3:     使用 Householder QR 求解
- 4: **else if** 存在秩亏或近秩亏风险 **then**
- 5:     使用 SVD 并按奇异值阈值构造  $\Sigma^\dagger$
- 6: **else**
- 7:     仅在条件数明确可控且成本敏感时考虑法方程
- 8: **end if**
- 9: **Stopping criterion:** 检查正规残差  $\|A^\top(A\mathbf{a} - \mathbf{y})\|$  与数据残差
- 10: **Complexity:** QR 约  $O(mn^2)$ ; SVD 同阶但常数更大; 存储通常  $O(mn)$

综合例题：三点数据的最佳直线拟合

对数据  $(0, 1), (1, 2), (2, 2)$ , 求最佳直线  $p(x) = a + bx$ 。设计矩阵和右端为  $A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$ ,  $\mathbf{y} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}$ 。法方程为  $\begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$ 。解得  $a = \frac{7}{6}$ ,  $b = \frac{1}{2}$ 。因此  $p^*(x) = \frac{7}{6} + \frac{1}{2}x$ 。

残差为  $\mathbf{r} = A \begin{pmatrix} a \\ b \end{pmatrix} - \mathbf{y} = \begin{pmatrix} 1/6 \\ -1/3 \\ 1/6 \end{pmatrix}$ , 并满足  $A^\top \mathbf{r} = 0$ 。

## 2.6 最佳一致逼近与等振荡

### 2.6.1 知识点十一：Chebyshev 等振荡定理

**【重要性等级】** **A 级**。该定理是无穷范数最佳逼近的标准识别工具，也是 Chebyshev 极小极大性质和 CG 误差多项式的理论底座。

**【问题与目标】** 对  $f \in C[a, b]$  求

$$E_n(f) = \min_{p \in \mathbb{P}_n} \|f - p\|_\infty. \quad (2.44)$$

**定理 2.7** (Chebyshev 等振荡定理). 多项式  $p_n^* \in \mathbb{P}_n$  是  $f$  的最佳一致逼近，当且仅当存在  $a \leq x_0 < x_1 < \cdots < x_{n+1} \leq b$  及  $\sigma \in \{-1, 1\}$ , 使

$$f(x_j) - p_n^*(x_j) = \sigma(-1)^j E_n(f), \quad j = 0, \dots, n+1. \quad (2.45)$$

最佳逼近多项式唯一。

#### 等振荡定理的证明框架

充分性。设  $q_n$  具有更小误差。令  $d = q_n - p_n^*$ 。在交错点上：

- 若  $f - p_n^* = E$ , 由  $|f - q_n| < E$  得  $d > 0$ ;

- 若  $f - p_n^* = -E$ , 由  $|f - q_n| < E$  得  $d < 0$ 。

故  $d$  在相邻交错点间至少有一个零点, 共至少  $n+1$  个互异零点。但  $d \in \mathbb{P}_n$ , 矛盾。

唯一性。若  $p_n^*, q_n^*$  均最佳, 则在交错点上  $q_n^* - p_n^*$  具有交替的非负/非正符号。通过微小凸组合或去除零点退化, 可推出其至少有  $n+1$  个零点, 故两者相同。

必要性。若误差极值集合不能形成  $n+2$  个交错点, 则其符号块数不超过  $n+1$ 。在相邻符号块间选点构造  $q \in \mathbb{P}_n$ , 使  $q$  在所有极值点处与误差同号。对充分小的  $\varepsilon > 0$ ,  $p_n^* + \varepsilon q$  将在极值点附近严格减小最大误差, 在非极值紧集上仍不超过原最大误差, 矛盾。

**【误差与精度】** 一致逼近控制最坏点误差; 它不等同于  $L^2$  投影。最佳一致逼近通常不满足普通正交条件, 而满足交错极值结构。

**【稳定性与条件数】** 等振荡点高度聚集或误差极值退化时, Remez 算法可能对初值和有限精度敏感。理论唯一性不等于数值求解容易。

**【算法】** Remez 交换法的基本步骤是:

1. 选取  $n+2$  个初始交错点;
2. 解线性系统  $f(x_j) - p_n(x_j) = (-1)^j E$ ;
3. 在全区间寻找新的误差极值点;
4. 用新的交错极值点替换旧点;
5. 直至最大正负误差幅值一致。

**【复杂度】** 每次 Remez 迭代需解  $(n+2)$  阶线性系统并进行全局极值搜索。成本依赖极值搜索策略, 通常高于单次最小二乘, 但获得的是最坏点最优性。

基础例题:  $x^2$  在  $\mathbb{P}_1$  中的最佳一致逼近

求  $\min_{p \in \mathbb{P}_1} \|x^2 - p(x)\|_{\infty, [-1, 1]}$ 。由于  $x^2$  为偶函数, 若  $p(x) = a + bx$  为最佳逼近, 则  $\tilde{p}(x) = \frac{p(x) + p(-x)}{2} = a$  的误差不大于  $p$ , 故最佳逼近可取常数。

令  $p(x) = c$ 。误差为  $e(x) = x^2 - c$ 。在  $x=0$  取值  $-c$ , 在  $x=\pm 1$  取值  $1-c$ 。令正负极值等幅:  $1-c = c$ , 得到  $c = \frac{1}{2}$ 。于是  $p_1^*(x) = \frac{1}{2}$ ,  $E_1(x^2) = \frac{1}{2}$ 。误差在  $x=-1, 0, 1$  处依次为  $\frac{1}{2}, -\frac{1}{2}, \frac{1}{2}$ , 形成  $n+2=3$  个交错极值点, 故由等振荡定理为唯一最佳逼近。

## 2.6.2 补充训练题: 丘赛 2020 Problem 6——单首一矩阵多项式最优解的唯一性

完整题目叙述及范数审计

设  $A \in \mathbb{R}^{m \times m}$  非奇异。记  $\mathcal{P}_n = \{p: p(z) = z^n + \text{低次项}\}$  为所有  $n$  次首一多项式的集合。假设  $\inf_{p \in \mathcal{P}_n} \|p(A)\| = \|p^*(A)\| > 0$ , 证明  $p^*$  是唯一的 (这里  $\|\cdot\|$  是 Frobenius 范数)。

证明. 记最小值为  $M = \|p^*(A)\|_F > 0$ 。假设  $p, q \in \mathcal{P}_n$  均为极小多项式, 即  $\|p(A)\|_F = \|q(A)\|_F = M$ 。平均多项式  $r = \frac{p+q}{2}$  仍属于  $\mathcal{P}_n$ 。由最优性,  $\|r(A)\|_F \geq M$ 。另一方面, Frobenius 范数来自内积, 满足平行四边形恒等式:

$$\|p(A)\|_F^2 + \|q(A)\|_F^2 = 2 \left\| \frac{p(A) + q(A)}{2} \right\|_F^2 + \frac{1}{2} \|p(A) - q(A)\|_F^2. \quad (2.46)$$

代入两边的最小值,  $2M^2 = 2\|r(A)\|_F^2 + \frac{1}{2}\|(p-q)(A)\|_F^2 \geq 2M^2 + \frac{1}{2}\|(p-q)(A)\|_F^2$ 。故

$$(p-q)(A) = 0. \quad (2.47)$$

令  $s = p - q$ 。由于  $p, q$  均首一, 最高次项相消, 因此  $\deg s \leq n-1$ 。若  $s \neq 0$ , 设  $s(z) = c_d z^d + \cdots$ ,  $c_d \neq 0$ ,  $d \leq n-1$ 。构造

$$\tilde{p}(z) = \frac{1}{c_d} z^{n-d} s(z). \quad (2.48)$$

则  $\tilde{p}$  是  $n$  次首一多项式, 且由式 (2.47)  $\tilde{p}(A) = \frac{1}{c_d} A^{n-d} s(A) = 0$ 。这与  $\inf_{p \in \mathcal{P}_n} \|p(A)\|_F = M > 0$  矛盾。因此  $s \equiv 0$ , 即  $p = q$ , 极小多项式唯一。□

注 2.8. 上述证明实际只需要:

1. 矩阵范数严格凸, 从而两个不同矩阵的平均值具有严格更小范数;
2. 或该范数来自内积, 因而可使用平行四边形恒等式;
3. 正最小值条件, 用于排除次数不超过  $n-1$  的非零多项式湮灭  $A$ 。

题面中的“ $A$  非奇异”在上述 Frobenius 证明中不是关键条件; 真正关键的是最小值严格为正。

#### 易错点与反例

不允许的写法:  $\left\| \frac{X+Y}{2} \right\| < \frac{\|X\| + \|Y\|}{2}$  对任意矩阵范数都严格成立。

一般范数只有非严格凸性不等式; 谱范数也不是严格凸范数。答题时必须注明所用范数性质。

## 2.7 正交多项式: 三项递推、零点与 Christoffel-Darboux 核

### 2.7.1 知识点十二: 正交多项式的一般结构

**【重要性等级】** **A 级**。正交多项式连续出现在正式试卷的 Chebyshev、Legendre、Gauss 求积与 CG 误差界中, 是模块一与模块三之间的关键桥梁。

**【问题与目标】** 给定区间  $[a, b]$  和正权函数  $w(x) > 0$ , 构造满足  $\langle p_n, p_m \rangle_w = \int_a^b p_n(x) p_m(x) w(x) dx = 0$ ,  $n \neq m$  的多项式族。

**【精确定义与假设】** 权函数满足  $w(x) > 0$  几乎处处, 且所需矩  $\int_a^b |x|^k w(x) dx$  有限。记  $\pi_n$  为  $n$  次首一正交多项式,  $h_n = \|\pi_n\|_w^2 > 0$ 。

**【构造方法】** 从  $1, x, x^2, \dots$  出发执行 Gram-Schmidt 正交化。直接在高次数上对单项式做经典 Gram-Schmidt 可能数值不稳定; 实际优先使用三项递推。

**定理 2.9** (首一正交多项式的三项递推). 存在实数  $\alpha_n$  和正数  $\beta_n$ , 使

$$\pi_{n+1}(x) = (x - \alpha_n)\pi_n(x) - \beta_n\pi_{n-1}(x), \quad n \geq 1, \quad (2.49)$$

其中

$$\alpha_n = \frac{\langle \pi_n, x\pi_n \rangle_w}{h_n}, \quad \beta_n = \frac{h_n}{h_{n-1}} > 0. \quad (2.50)$$





证明. 多项式  $x\pi_n - \pi_{n+1}$  次数不超过  $n$ , 可展开为  $x\pi_n - \pi_{n+1} = \sum_{j=0}^n c_j \pi_j$ . 若  $j \leq n-2$ , 则  $\langle \pi_j, x\pi_n \rangle_w = \langle x\pi_j, \pi_n \rangle_w = 0$ , 因为  $x\pi_j \in \mathbb{P}_{n-1}$ . 故仅保留  $\pi_n, \pi_{n-1}$  两项。

与  $\pi_n$  取内积得到  $c_n = \alpha_n$ . 与  $\pi_{n-1}$  取内积:  $c_{n-1}h_{n-1} = \langle \pi_{n-1}, x\pi_n \rangle_w = \langle x\pi_{n-1}, \pi_n \rangle_w = h_n$ , 故  $c_{n-1} = h_n/h_{n-1} = \beta_n$ .  $\square$

**定理 2.10 (正交多项式零点).** 若  $w > 0$  几乎处处, 则  $\pi_n$  在  $(a, b)$  内恰有  $n$  个互异实零点。

证明. 设  $\pi_n$  在  $(a, b)$  内所有奇重数零点为  $\xi_1, \dots, \xi_r$ , 并令  $q(x) = \prod_{j=1}^r (x - \xi_j)$ . 若  $r < n$ , 则  $\deg q < n$ , 故由正交性  $\int_a^b \pi_n(x)q(x)w(x)dx = 0$ . 但  $\pi_n q$  在  $(a, b)$  内不变号, 且不恒为零; 又  $w > 0$  几乎处处, 因此积分不可能为零, 矛盾. 故  $r = n$ . 由于  $\deg \pi_n = n$ , 所有零点均在  $(a, b)$  内且为单根.  $\square$

**【稳定性与条件数】** 三项递推对区间内求值通常比单项式系数稳定. 区间外递推可能产生一个指数增长解和一个指数衰减解, 递推方向必须谨慎选择。

**【复杂度】** 已知递推系数时, 求  $p_0(x), \dots, p_n(x)$  为  $O(n)$  时间、 $O(1)$  滚动存储. 计算全部 Gauss 节点可转化为对称三对角 Jacobi 矩阵特征值问题, 见第 04 部分。

## 2.7.2 Christoffel–Darboux 核

设  $\{\varphi_k\}_{k=0}^\infty$  为标准正交多项式, 满足  $x\varphi_k = a_{k+1}\varphi_{k+1} + b_k\varphi_k + a_k\varphi_{k-1}$ ,  $a_k > 0$ . 定义再生核

$$K_n(x, y) = \sum_{k=0}^n \varphi_k(x)\varphi_k(y). \quad (2.51)$$

对任意  $p \in \mathbb{P}_n$ ,

$$p(y) = \langle K_n(\cdot, y), p \rangle_w. \quad (2.52)$$

Christoffel–Darboux 公式为

$$K_n(x, y) = a_{n+1} \frac{\varphi_{n+1}(x)\varphi_n(y) - \varphi_n(x)\varphi_{n+1}(y)}{x - y}, \quad x \neq y. \quad (2.53)$$

若  $x_i, x_j$  均为  $\varphi_{n+1}$  的零点且  $i \neq j$ , 则

$$K_n(x_i, x_j) = 0. \quad (2.54)$$

## 2.7.3 补充训练题: 丘赛 2022 Problem 1——节点值型标准正交基

### 完整题目叙述

设  $\{p_i(x)\}_{i=0}^\infty$  是关于  $\langle f, g \rangle_w = \int_{-1}^1 f(x)g(x)w(x)dx$ ,  $w(x) > 0$ ,  $x \in (-1, 1)$ , 的一族正交多项式, 且  $\deg p_i = i$ . 设  $x_0, \dots, x_n$  是  $p_{n+1}$  的  $n+1$  个零点。

构造  $\mathbb{P}_n$  中的一组标准正交基, 使任意  $p \in \mathbb{P}_n$  在该基下的展开系数等于  $p$  在  $x_0, \dots, x_n$  处函数值的适当尺度倍数。

详细解答. 先把  $p_i$  标准化, 记  $\varphi_i(x) = \frac{p_i(x)}{\|p_i\|_w}$ . 定义 Christoffel–Darboux 核  $K_n(x, y) = \sum_{k=0}^n \varphi_k(x)\varphi_k(y)$ . 由式 (2.54),  $K_n(x_i, x_j) = 0$ ,  $i \neq j$ . 并且  $K_n(x_j, x_j) = \sum_{k=0}^n |\varphi_k(x_j)|^2 > 0$ . 定义

$$\lambda_j = \frac{1}{K_n(x_j, x_j)} > 0, \quad \psi_j(x) = \sqrt{\lambda_j} K_n(x, x_j), \quad j = 0, \dots, n. \quad (2.55)$$

下面验证  $\{\psi_j\}_{j=0}^n$  标准正交。利用再生核恒等式  $\langle K_n(\cdot, x_i), K_n(\cdot, x_j) \rangle_w = K_n(x_i, x_j)$ , 得到

$$\langle \psi_i, \psi_j \rangle_w = \sqrt{\lambda_i \lambda_j} K_n(x_i, x_j) = \begin{cases} 0, & i \neq j, \\ \lambda_j K_n(x_j, x_j) = 1, & i = j. \end{cases}$$

因此它们构成  $\mathbb{P}_n$  的一组标准正交基。

对任意  $p \in \mathbb{P}_n$ , 展开为  $p(x) = \sum_{j=0}^n c_j \psi_j(x)$ 。由标准正交性与再生性质,

$$c_j = \langle \psi_j, p \rangle_w = \sqrt{\lambda_j} \langle K_n(\cdot, x_j), p \rangle_w = \sqrt{\lambda_j} p(x_j). \quad (2.56)$$

故

$$p(x) = \sum_{j=0}^n \sqrt{\lambda_j} p(x_j) \psi_j(x). \quad (2.57)$$

此外,  $L_j(x) := \lambda_j K_n(x, x_j)$  满足  $L_j(x_i) = \delta_{ij}$ , 是这些 Gauss 节点上的 Lagrange 基函数, 而  $\psi_j(x) = \frac{L_j(x)}{\sqrt{\lambda_j}}$ 。□

#### 2.7.4 补充训练题: 丘赛 2025 Problem 3——伴随 Legendre 函数的插值与最小二乘

为避免与后文单首 Legendre 多项式  $P_n$  混淆, 本题把普通 Legendre 多项式记为  $L_k$ 。附件原文记为  $P_k$ 。

##### 完整题目叙述

普通 Legendre 多项式为  $L_k(x)$ 。定义伴随 Legendre 函数  $L_k^m(x) = (-1)^m (1-x^2)^{m/2} \frac{d^m}{dx^m} L_k(x)$ ,  $m > 0$ ,  $k \geq m$ 。特别地,  $L_k^1(x) = -\sqrt{1-x^2} L_k'(x)$ 。

(a) 对互异节点  $x_i \in (-1, 1)$ , 证明插值系统  $\sum_{k=1}^N a_k L_k^1(x_i) = y_i$ ,  $i = 1, \dots, N$ , 的系数矩阵非奇异。

(b) 求使  $\left\| f - \sum_{k=1}^N a_k L_k^1 \right\|_2^2$  最小的正规方程, 并证明系数矩阵非奇异。

(c) 若  $M$  为第 (b) 问中的系数矩阵, 证明当  $k+j$  为奇数时  $M_{kj} = 0$ 。

详细解答. (a) 插值矩阵非奇异。

设齐次系统存在系数  $a_k$  满足  $\sum_{k=1}^N a_k L_k^1(x_i) = 0$ ,  $i = 1, \dots, N$ 。因为  $x_i \in (-1, 1)$ , 有  $\sqrt{1-x_i^2} > 0$ , 故  $\sum_{k=1}^N a_k L_k'(x_i) = 0$ ,  $i = 1, \dots, N$ 。令  $q(x) = \sum_{k=1}^N a_k L_k'(x)$ 。由于  $\deg L_k' = k-1$ ,  $\deg q \leq N-1$ 。但  $q$  在  $N$  个互异点  $x_i$  处均为零, 因此  $q \equiv 0$ 。

又因为  $\deg L_k' = k-1$  且每个  $L_k'$  的最高次项系数非零, 集合  $\{L_1', \dots, L_N'\}$  关于多项式次数呈三角结构, 线性无关。故  $a_1 = \dots = a_N = 0$ 。齐次系统仅有零解, 插值矩阵非奇异。


(b) 最小二乘正规方程。

记  $\phi_k(x) = L_k^1(x)$ 。目标函数为  $J(\mathbf{a}) = \left\| f - \sum_{k=1}^N a_k \phi_k \right\|_2^2$ 。正交投影条件为  $\langle \phi_j, f - \sum_{k=1}^N a_k \phi_k \rangle = 0$ ,  $j = 1, \dots, N$ 。因此

$$M\mathbf{a} = \mathbf{b}, \quad M_{jk} = \int_{-1}^1 \phi_j(x) \phi_k(x) dx, \quad b_j = \int_{-1}^1 \phi_j(x) f(x) dx. \quad (2.58)$$

事实上  $M$  不仅正定, 而且为对角矩阵。利用 Legendre 微分方程

$$-\frac{d}{dx} [(1-x^2)L_k'(x)] = k(k+1)L_k(x), \quad (2.59)$$



有

$$\begin{aligned} M_{jk} &= \int_{-1}^1 (1-x^2) L'_j(x) L'_k(x) dx \\ &= - \int_{-1}^1 L_j(x) \frac{d}{dx} [(1-x^2) L'_k(x)] dx \\ &= k(k+1) \int_{-1}^1 L_j(x) L_k(x) dx. \end{aligned}$$

边界项为零, 因为  $1-x^2$  在  $x = \pm 1$  处消失。利用普通 Legendre 多项式的正交性,  $\int_{-1}^1 L_j L_k dx = \frac{2}{2k+1} \delta_{jk}$ , 得到

$$M_{jk} = \frac{2k(k+1)}{2k+1} \delta_{jk}. \quad (2.60)$$

故  $M$  对角元严格为正, 必非奇异, 并且最优系数为

$$a_k = \frac{2k+1}{2k(k+1)} \int_{-1}^1 f(x) L_k^1(x) dx. \quad (2.61)$$

(c) 奇偶性证明。

普通 Legendre 多项式满足  $L_k(-x) = (-1)^k L_k(x)$ 。对  $x$  求导,  $L'_k(-x) = (-1)^{k+1} L'_k(x)$ 。因此  $L_k^1(-x) = (-1)^{k+1} L_k^1(x)$ 。乘积满足  $L_k^1(-x) L_j^1(-x) = (-1)^{k+j} L_k^1(x) L_j^1(x)$ 。若  $k+j$  为奇数, 乘积为奇函数, 故  $M_{kj} = \int_{-1}^1 L_k^1(x) L_j^1(x) dx = 0$ 。事实上由式 (2.60), 只要  $k \neq j$  便有  $M_{kj} = 0$ , 第 (c) 问是这一更强正交性的直接推论。  $\square$

## 2.8 正式真题 [26S-Q2]——正交多项式与最佳逼近

完整原题叙述

在  $C[-1, 1]$  上定义  $\langle f, g \rangle = \int_{-1}^1 f(x)g(x) dx$ ,  $\|f\|_2 = \sqrt{\langle f, f \rangle}$ 。记

$$a_n = \frac{(2n)!}{2^n (n!)^2}. \quad (2.62)$$

定义第  $n$  个首一 Legendre 多项式  $P_0(x) = 1$ ,  $P_1(x) = x$ , 以及

$$P_{n+1}(x) = xP_n(x) - \frac{n^2}{4n^2 - 1} P_{n-1}(x). \quad (2.63)$$

(a) 计算  $\langle P_n, P_m \rangle$ 。

(b) 证明  $P_n$  解决  $\min_{\substack{p \in \mathbb{P}_n \\ p^{(n)}(1) = n!}} \|p\|_2$ , 并计算最小值。

(c) 对  $f \in C^{n+1}[-1, 1]$ , 取  $P_{n+1}$  的  $n+1$  个零点为插值节点, 记  $n$  次插值多项式为  $L_n$ 。(原卷要求) 证明

$$\|f - L_n\|_2 \leq \frac{2 \|f^{(n+1)}\|_2}{(2n+3)a_{n+1}(n+1)!}. \quad (2.64)$$

(d) 对  $f \in C^{2n+2}[-1, 1]$ , 推导  $n+1$  点 Gauss-Legendre 求积并估计误差。第 (d) 问属于数值积分, 完整解答将在第 04 部分给出。

## 第 (a) 问: 正交性与范数

令  $L_n$  表示标准 Legendre 多项式, 满足  $L_n(1) = 1$ , 其首项系数正是  $a_n$ , 且

$$\int_{-1}^1 L_n(x) L_m(x) dx = \frac{2}{2n+1} \delta_{nm}. \quad (2.65)$$

定义  $\tilde{P}_n(x) = \frac{L_n(x)}{a_n}$ . 则  $\tilde{P}_n$  为首一多项式。

标准 Legendre 递推为  $(n+1)L_{n+1} = (2n+1)xL_n - nL_{n-1}$ . 利用  $\frac{a_n}{a_{n+1}} = \frac{n+1}{2n+1}$ ,  $\frac{n}{n+1} \frac{a_{n-1}}{a_{n+1}} = \frac{n^2}{4n^2-1}$ , 可得  $\tilde{P}_{n+1} = x\tilde{P}_n - \frac{n^2}{4n^2-1}\tilde{P}_{n-1}$ . 它与题设递推及初值相同, 故  $P_n = \tilde{P}_n = \frac{L_n}{a_n}$ . 因此

$$\langle P_n, P_m \rangle = \begin{cases} 0, & n \neq m, \\ \frac{2}{(2n+1)a_n^2}, & n = m. \end{cases} \quad (2.66)$$

第 (b) 问: 单首一多项式的最佳  $L^2$  性质

若  $p \in \mathbb{P}_n$ , 则  $p^{(n)}$  为常数, 且  $p^{(n)}(1) = n!$  等价于  $p$  的最高次项系数为 1, 即  $p$  为  $n$  次首一多项式。

任意可行  $p$  可唯一写成  $p = P_n + q$ ,  $q \in \mathbb{P}_{n-1}$ . 因为  $P_n$  与所有次数不超过  $n-1$  的多项式正交,  $\langle P_n, q \rangle = 0$ . 故

$$\|p\|_2^2 = \|P_n\|_2^2 + \|q\|_2^2 \geq \|P_n\|_2^2, \quad (2.67)$$

等号仅当  $q = 0$ . 因此  $P_n$  是唯一极小者, 最小值为

$$\min \|p\|_2 = \|P_n\|_2 = \frac{\sqrt{2}}{a_n \sqrt{2n+1}}. \quad (2.68)$$

## 第 (c) 问

考试时的题目确实是这样写的, 事实上这道题是错误的。


反例 2.11 (原式 (2.64) 在  $n \geq 1$  时不成立). 取  $f = P_{n+1}$ . 插值节点恰为  $P_{n+1}$  的  $n+1$  个零点, 因此所有插值数据均为零, 故  $L_n \equiv 0$ . 于是

$$\|f - L_n\|_2 = \|P_{n+1}\|_2 = \frac{\sqrt{2}}{a_{n+1} \sqrt{2n+3}}. \quad (2.69)$$

另一方面,  $P_{n+1}$  为首一  $n+1$  次多项式, 因此  $f^{(n+1)}(x) = (n+1)!$ , 从而  $\|f^{(n+1)}\|_2 = \sqrt{2}(n+1)!$ . 原卷右端等于

$$\frac{2\sqrt{2}}{(2n+3)a_{n+1}}. \quad (2.70)$$

若原不等式成立, 则必须  $\frac{1}{\sqrt{2n+3}} \leq \frac{2}{2n+3}$ , 即  $\sqrt{2n+3} \leq 2$ . 该式对  $n \geq 1$  不成立. 因此原卷第 (c) 问按字面不存在正确证明。



## 第 (c) 问的可证明修正版一：无穷范数导数控制

设  $x_0, \dots, x_n$  为  $P_{n+1}$  的零点。因为  $P_{n+1}$  首一,  $\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j) = P_{n+1}(x)$ 。Lagrange 余项给出  $f(x) - L_n(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} P_{n+1}(x)$ 。故

$$\begin{aligned} \|f - L_n\|_2 &\leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} \|P_{n+1}\|_2 \\ &= \frac{\sqrt{2}}{a_{n+1}\sqrt{2n+3}(n+1)!} \|f^{(n+1)}\|_\infty. \end{aligned} \quad (2.71)$$

第 (c) 问的可证明修正版二：粗略  $L^2$ -Sobolev 估计

若  $g \in H^1(-1, 1)$  且在某点  $\xi \in [-1, 1]$  满足  $g(\xi) = 0$ , 则  $|g(x)| = \left| \int_\xi^x g'(t) dt \right| \leq |x - \xi|^{1/2} \|g'\|_2 \leq \sqrt{2} \|g'\|_2$ 。积分得到

$$\|g\|_2 \leq 2 \|g'\|_2. \quad (2.72)$$

令  $e = f - L_n$ 。函数  $e$  有  $n+1$  个互异零点。由 Rolle 定理,  $e^{(r)}$  至少有  $n+1-r$  个零点。重复使用式 (2.72),

$$\|f - L_n\|_2 = \|e\|_2 \leq 2^{n+1} \|e^{(n+1)}\|_2 = 2^{n+1} \|f^{(n+1)}\|_2. \quad (2.73)$$

该界较粗, 但在所给假设下数学正确。若要得到包含  $a_{n+1}$  的尖锐  $L^2$  导数界, 需要额外的 Sobolev 插值不等式或 Peano 核分析, 不能由原题常数直接推出。

注 2.12. 虽然后续的处理结果是这道题大家都算作满分, 但是这很可能会消耗你不少时间, 所以这里强调一个非常重要的答题技巧:

考试时遇到不对劲的题目不要耗在上面, 一定要先跳过!





# 第三章 数值积分 I——插值型求积、 Newton–Cotes、复合求积、 Euler–Maclaurin 公式与 Romberg

## 3.1 一般求积公式：节点、权重、插值型求积与代数精度

### 3.1.1 知识点一：一般线性求积公式

【重要性等级】 **S 级**。一般求积公式是 Newton–Cotes、Gauss、Clenshaw–Curtis、自适应求积和  
多维张量积公式的统一语言。资格考试中若只会背梯形、Simpson 公式，而不能从节点与权重重新构  
造公式，则难以处理参数化求积题。

【问题与目标】 给定积分泛函

$$I(f) = \int_a^b f(x) dx, \quad (3.1)$$

选取互异节点  $a \leq x_0 < x_1 < \cdots < x_n \leq b$  以及权重  $W_0, \dots, W_n$ ，构造线性泛函

$$Q_n(f) = \sum_{j=0}^n W_j f(x_j) \quad (3.2)$$

逼近  $I(f)$ 。

若考虑加权积分  $I_\rho(f) = \int_a^b f(x)\rho(x) dx$ ,  $\rho(x) \geq 0$ ，则以下结论只需把  $I$  替换为  $I_\rho$ ；本部分  
Newton–Cotes 公式均取  $\rho \equiv 1$ 。

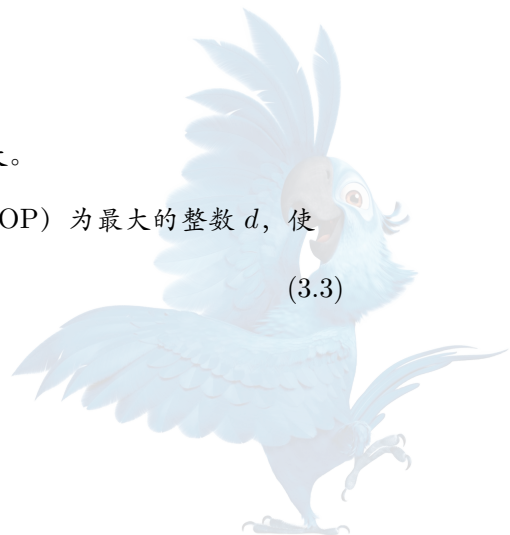
【精确定义与假设】

- 节点  $x_j$  必须位于积分区间内且通常要求互异；
- 权重可以为正、零或负，但其符号直接影响数值稳定性；
- 若  $f$  只以离散数据形式给出，则公式只能使用节点处数据；
- 若讨论误差阶，必须额外规定  $f$  的光滑性；
- 若积分本身存在强消去，则即使公式绝对稳定，相对误差仍可能很大。

定义 3.1 (代数精度). 求积公式  $Q_n$  的代数精度 (degree of precision, DOP) 为最大的整数  $d$ ，使

$$Q_n(p) = I(p), \quad \forall p \in \mathbb{P}_d. \quad (3.3)$$

等价地， $Q_n(x^k) = I(x^k)$ ,  $k = 0, 1, \dots, d$ ，但至少对  $x^{d+1}$  不再精确。



## 易错点与反例

代数精度不等于复合公式的收敛阶。

若一个单元上的公式代数精度为  $d$ , 在单元长度  $H$  缩小时, 局部误差通常为  $O(H^{d+2})$ 。固定总区间上约有  $O(H^{-1})$  个单元, 因此复合后的整体误差通常为  $O(H^{d+1})$ 。例如梯形公式代数精度为 1, 局部误差为  $O(H^3)$ , 复合整体误差为  $O(H^2)$ 。

## 3.1.2 知识点二: 插值型求积公式

定义 3.2 (插值型求积). 若  $Q_n$  可由节点  $x_0, \dots, x_n$  上的  $n$  次多项式插值积分得到, 即  $Q_n(f) = I(I_n f)$ , 则称其为插值型求积公式。

设  $\ell_j$  为节点  $x_0, \dots, x_n$  的 Lagrange 基函数:  $\ell_j(x_i) = \delta_{ij}$ 。插值多项式为  $I_n f(x) = \sum_{j=0}^n f(x_j) \ell_j(x)$ 。逐项积分得到

$$Q_n(f) = \sum_{j=0}^n W_j f(x_j), \quad W_j = \int_a^b \ell_j(x) dx. \quad (3.4)$$

定理 3.3 (插值型求积的等价刻画). 对给定互异节点  $x_0, \dots, x_n$ , 以下命题等价:

1.  $Q_n$  是插值型求积公式;
2.  $Q_n$  对  $\mathbb{P}_n$  中的所有多项式精确;
3. 权重唯一地满足  $W_j = \int_a^b \ell_j(x) dx$ .

证明. 若  $Q_n$  为插值型公式, 则对  $p \in \mathbb{P}_n$ ,  $I_n p = p$ , 故  $Q_n(p) = I(I_n p) = I(p)$ 。

反之, 若  $Q_n$  对  $\mathbb{P}_n$  精确, 则对每个 Lagrange 基函数  $\ell_j$ ,  $W_j = Q_n(\ell_j) = I(\ell_j)$ , 因此权重必为式 (3.4), 并且  $Q_n(f) = \sum_{j=0}^n f(x_j) \int_a^b \ell_j(x) dx = \int_a^b I_n f(x) dx$ 。□

【推导来源】 先用多项式插值逼近  $f$ , 再对插值多项式精确积分:  $f \approx I_n f \implies \int_a^b f \approx \int_a^b I_n f$ 。

【误差与精度】 插值型公式至少具有代数精度  $n$ 。它可能因节点对称性或额外正交条件而具有更高精度, 但仅由“有  $n+1$  个节点”不能直接断言精度为  $2n+1$ 。

【稳定性与条件数】 将节点数据向量记为  $\mathbf{f} = (f(x_0), \dots, f(x_n))^T$ 。从  $\ell^\infty$  数据扰动到求积结果的绝对条件数为

$$\kappa_{\text{abs}}(Q_n) = \sup_{\|\delta \mathbf{f}\|_\infty \leq 1} \left| \sum_{j=0}^n W_j \delta f_j \right| = \sum_{j=0}^n |W_j|. \quad (3.5)$$

若公式对常数精确, 则

$$\sum_{j=0}^n W_j = b - a. \quad (3.6)$$

因此  $\sum_{j=0}^n |W_j| \geq b - a$ , 且等号成立当且仅当所有权重均非负。故正权公式在节点数据的  $\ell^\infty$  扰动下具有最小可能的绝对放大常数。

命题 3.4 (正权公式的基本稳定性). 若  $W_j \geq 0$ ,  $\sum_{j=0}^n W_j = b - a$ , 则

$$|Q_n(f)| \leq (b - a) \max_j |f(x_j)|. \quad (3.7)$$

若所有  $f(x_j) \geq 0$ , 则  $Q_n(f) \geq 0$ 。

## 易错点与反例

正权性只控制绝对稳定性，不保证小相对误差。

若真实积分  $I(f)$  因正负区域相消而接近零，则  $\frac{|Q_n(f)-I(f)|}{|I(f)|}$  仍可能很大。此时问题本身在相对意义下病态。

【复杂度】 节点与权重预先给定时，一次求积需  $n+1$  次函数采样和  $O(n)$  次乘加，存储  $O(n)$ ；若函数值可流式生成，额外存储可降为  $O(1)$ 。高精度求和可采用成对求和或补偿求和。

【证明要求】 需要会完整证明：插值型求积等价刻画、权重和、正权稳定性。需要掌握：代数精度与误差阶的区别。

## 证明思路

识别信号：题目给定节点，要求求权重、最大化代数精度或判断公式是否插值型。

构造步骤：

1. 写矩条件  $\sum_j W_j x_j^k = \int_a^b x^k dx$ ;
2. 从  $k=0$  开始逐阶增加；
3. 未知数个数给出可能达到的基本精度；
4. 检查更高一阶矩，确定实际 DOP。

关键估计：稳定性由  $\sum |W_j|$  控制，而不是由  $\sum W_j$  单独控制。

常见失败原因：只解与未知数同样多的矩方程，未检查下一阶；得到负权后仍声称公式保持非负性。

## 3.1.3 节点多项式与额外代数精度

定义节点多项式

$$\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j). \quad (3.8)$$

定理 3.5 (插值型求积的正交判据). 设  $Q_n$  是  $n+1$  节点插值型求积公式,  $0 \leq k \leq n+1$ . 则  $Q_n$  至少具有代数精度  $n+k$ , 当且仅当

$$\int_a^b \omega_{n+1}(x) q(x) dx = 0, \quad \forall q \in \mathbb{P}_{k-1}, \quad (3.9)$$

其中  $k=0$  时条件为空。

证明. 任取  $p \in \mathbb{P}_{n+k}$ . 对  $\omega_{n+1}$  作多项式除法:  $p(x) = \omega_{n+1}(x)q(x) + r(x)$ ,  $q \in \mathbb{P}_{k-1}$ ,  $r \in \mathbb{P}_n$ . 由于  $\omega_{n+1}(x_j) = 0$ ,  $Q_n(p) = Q_n(r)$ . 又因  $Q_n$  插值型,  $Q_n(r) = I(r)$ . 故  $I(p) - Q_n(p) = I(\omega_{n+1}q)$ . 于是  $Q_n$  对所有  $p \in \mathbb{P}_{n+k}$  精确, 当且仅当式 (3.9) 成立.  $\square$

推论 3.6 (节点数给出的最高可能精度). 若积分测度在  $[a, b]$  上为正, 则任意  $n+1$  节点求积公式的代数精度不超过  $2n+1$ .

证明. 若代数精度至少为  $2n+2$ , 则应对  $p(x) = \omega_{n+1}(x)^2 \in \mathbb{P}_{2n+2}$  精确. 然而  $Q_n(\omega_{n+1}^2) = 0$ , 而  $\int_a^b \omega_{n+1}(x)^2 dx > 0$ , 矛盾.  $\square$

注 3.7. 第 04 部分将证明: Gauss 求积通过令  $\omega_{n+1}$  成为正交多项式, 达到最高可能代数精度  $2n+1$ .

## 3.1.4 培训讲义完整例题：最大化求积公式的代数精度

## 完整题目叙述

分别确定下列公式中的参数，使代数精度最大，并给出最大代数精度。

$$(1) \int_0^{2h} f(x) dx \approx A_0 f(0) + A_1 f(h) + A_2 f(2h).$$

$$(2) \int_{-h}^h f(x) dx \approx A f(-h) + B f(x_1), \text{ 其中 } A, B, x_1 \text{ 均未知。}$$

$$(3) \int_0^2 f(x) dx \approx A_0 f(0) + \frac{4}{3} f(x_1) + A_2 f(2), \text{ 其中 } A_0, A_2, x_1 \text{ 未知。}$$

第 (1) 题详细解答. 对  $f(x) = 1, x, x^2$  要求精确, 得到

$$A_0 + A_1 + A_2 = 2h, \quad (3.10)$$

$$hA_1 + 2hA_2 = 2h^2, \quad (3.11)$$

$$h^2 A_1 + 4h^2 A_2 = \frac{8h^3}{3}. \quad (3.12)$$

解得  $A_0 = \frac{h}{3}, A_1 = \frac{4h}{3}, A_2 = \frac{h}{3}$ 。所得公式为

$$\int_0^{2h} f(x) dx \approx \frac{h}{3} [f(0) + 4f(h) + f(2h)]. \quad (3.13)$$

由于节点与权重关于  $x = h$  对称, 所有关于  $x - h$  的奇次多项式自动精确, 因此公式对三次多项式也精确。直接验证:  $Q(x^3) = \frac{h}{3} [4h^3 + 8h^3] = 4h^4 = \int_0^{2h} x^3 dx$ 。但对  $x^4$ ,  $Q(x^4) = \frac{h}{3} (4h^4 + 16h^4) = \frac{20}{3}h^5$ , 而  $\int_0^{2h} x^4 dx = \frac{32}{5}h^5$ 。两者不等, 故最大代数精度为  $\boxed{3}$ 。□

第 (2) 题详细解答. 作无量纲化  $t = \frac{x_1}{h}$ ,  $a = \frac{A}{h}$ ,  $b = \frac{B}{h}$ 。要求对  $1, x, x^2$  精确, 得到

$$a + b = 2, \quad (3.14)$$

$$-a + bt = 0, \quad (3.15)$$

$$a + bt^2 = \frac{2}{3}. \quad (3.16)$$

由式 (3.15) 有  $a = bt$ , 代入第一式:  $b(1+t) = 2$ 。再代入第三式:  $bt(1+t) = \frac{2}{3}$ 。两式相除得到  $t = \frac{1}{3}$ 。因此  $b = \frac{3}{2}$ ,  $a = \frac{1}{2}$ 。即

$$x_1 = \frac{h}{3}, A = \frac{h}{2}, B = \frac{3h}{2}. \quad (3.17)$$

检查三次多项式:  $Q(x^3) = \frac{h}{2}(-h)^3 + \frac{3h}{2}(\frac{h}{3})^3 = -\frac{h^4}{2} + \frac{h^4}{18} = -\frac{4h^4}{9}$ , 而  $\int_{-h}^h x^3 dx = 0$ 。故最大代数精度为  $\boxed{2}$ 。

该公式是固定左端点的两节点 Gauss-Radau 型公式; 三个自由参数恰好匹配三个矩条件。□

第 (3) 题详细解答. 要求对  $1, x, x^2$  精确:


$$A_0 + \frac{4}{3} + A_2 = 2, \quad (3.18)$$

$$\frac{4}{3}x_1 + 2A_2 = 2, \quad (3.19)$$

$$\frac{4}{3}x_1^2 + 4A_2 = \frac{8}{3}. \quad (3.20)$$

由第一、第二式,  $A_2 = 1 - \frac{2}{3}x_1$ ,  $A_0 = -\frac{1}{3} + \frac{2}{3}x_1$ 。代入第三式:  $\frac{4}{3}x_1^2 + 4 - \frac{8}{3}x_1 = \frac{8}{3}$ 。乘以  $3/4$  后得到  $x_1^2 - 2x_1 + 1 = 0$ , 故  $x_1 = 1$ 。于是  $A_0 = A_2 = \frac{1}{3}$ 。公式成为

$$\int_0^2 f(x) dx \approx \frac{1}{3} [f(0) + 4f(1) + f(2)]. \quad (3.21)$$



由对称性，它对三次多项式精确；由  $\int_0^2 x^4 dx = \frac{32}{5} \neq \frac{1}{3}(4+16) = \frac{20}{3}$ ，知最大代数精度为  $\boxed{3}$ 。  $\square$

## 3.2 Newton-Cotes 公式：开型、闭型、对称性与高阶失稳

### 3.2.1 知识点三：闭型与开型 Newton-Cotes

【重要性等级】 **S 级**。中点、梯形、Simpson 及其复合形式是资格考试中最基本的求积公式；高阶 Newton-Cotes 的负权性是典型稳定性辨析点。

令  $H = b - a$ 。

闭型 Newton-Cotes 取  $N + 1$  个含端点的等距节点

$$x_j = a + \frac{jH}{N}, \quad j = 0, \dots, N. \quad (3.22)$$

由这些节点的 Lagrange 插值积分得到闭型 Newton-Cotes 公式。

开型 Newton-Cotes 本文约定使用  $r$  个不含端点的等距节点

$$x_j = a + \frac{j+1}{r+1}H, \quad j = 0, \dots, r-1. \quad (3.23)$$

部分资料以“子区间数”而非“节点数”编号开型公式；换算时必须说明编号口径。

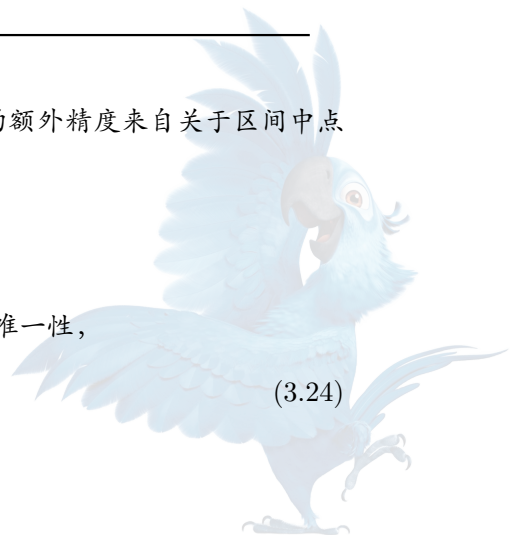
| 公式          | 单区间表达式                                                                         | 代数精度 | 主要特点                |
|-------------|--------------------------------------------------------------------------------|------|---------------------|
| 中点公式        | $Hf(\frac{a+b}{2})$                                                            | 1    | 开型、正权、对称。           |
| 梯形公式        | $\frac{H}{2}[f(a) + f(b)]$                                                     | 1    | 闭型、正权、对称。           |
| Simpson 公式  | $\frac{H}{6}[f(a) + 4f(\frac{a+b}{2}) + f(b)]$                                 | 3    | 闭型；二次插值却因对称性达到三次精度。 |
| Simpson 3/8 | $\frac{H}{8}[f(a) + 3f(a + \frac{H}{3}) + 3f(a + \frac{2H}{3}) + f(b)]$        | 3    | 四个闭型节点。             |
| Boole 公式    | $\frac{H}{90}[7f_0 + 32f_1 + 12f_2 + 32f_3 + 7f_4]$                            | 5    | 五个闭型节点。             |
| 两点开型        | $\frac{H}{2}[f(a + \frac{H}{3}) + f(a + \frac{2H}{3})]$                        | 1    | 正权、对称。              |
| 三点开型        | $\frac{H}{3}[2f(a + \frac{H}{4}) - f(a + \frac{H}{2}) + 2f(a + \frac{3H}{4})]$ | 3    | 已出现负权。              |

【推导来源】 所有公式均由等距节点插值多项式积分获得。Simpson 的额外精度来自关于区间中点的对称性。

### 3.2.2 Newton-Cotes 的对称性

设  $m = \frac{a+b}{2}$ 。等距对称节点满足  $x_{N-j} = a + b - x_j$ 。由插值权重的唯一性，

$$W_{N-j} = W_j. \quad (3.24)$$



因此对关于  $m$  的任意奇函数  $g$ ,  $I(g) = 0$ ,  $Q_N(g) = 0$ 。这正是对称求积产生超收敛的机制。

**定理 3.8** (闭型 Newton-Cotes 的基本精度). 具有  $N+1$  个节点的闭型 *Newton-Cotes* 公式至少具有代数精度  $N$ 。若  $N$  为偶数, 则至少具有代数精度  $N+1$ 。

**证明.** 插值型性质立即给出 DOP 至少为  $N$ 。

若  $N$  为偶数, 则节点数  $N+1$  为奇数, 并包含中点  $m$ 。节点多项式  $\omega_{N+1}(x) = \prod_{j=0}^N (x - x_j)$  关于  $m$  为奇函数:  $\omega_{N+1}(m+t) = -\omega_{N+1}(m-t)$ 。因此  $\int_a^b \omega_{N+1}(x) dx = 0$ 。由定义 3.5 取  $k=1$ , 得到代数精度至少为  $N+1$ 。□

注 3.9. 标准闭型 Newton-Cotes 公式实际满足: 
$$\text{DOP} = \begin{cases} N, & N \text{ 为奇数,} \\ N+1, & N \text{ 为偶数.} \end{cases}$$
 培训讲义中的练习只要求证明偶数  $N$  时额外精确一阶; 上面的证明已经完成该要求。

### 3.2.3 高阶 Newton-Cotes 的稳定性问题

低阶 Newton-Cotes 权重均较温和, 但当闭型公式的子区间数达到  $N=8$  时, 已经出现负权; 随  $N$  继续增加, 权重绝对值可能显著增大并交替变号。

若节点函数值含扰动  $\tilde{f}_j = f_j + \delta f_j$ ,  $|\delta f_j| \leq \delta$ , 则  $|Q_N(\tilde{f}) - Q_N(f)| \leq \delta \sum_{j=0}^N |W_j|$ 。当  $\sum_j |W_j| \gg b-a$  时, 数据噪声与舍入误差被显著放大。

#### 易错点与反例

错误说法: “增加 Newton-Cotes 节点数会同时提高精度和稳定性。”

错误原因:

1. 等距高次插值本身可能出现 Runge 振荡;
2. 高阶 Newton-Cotes 权重可能为负且幅值增大;
3. 固定区间上令  $N \rightarrow \infty$  并不等同于低阶复合公式中令网格宽度  $h \rightarrow 0$ 。

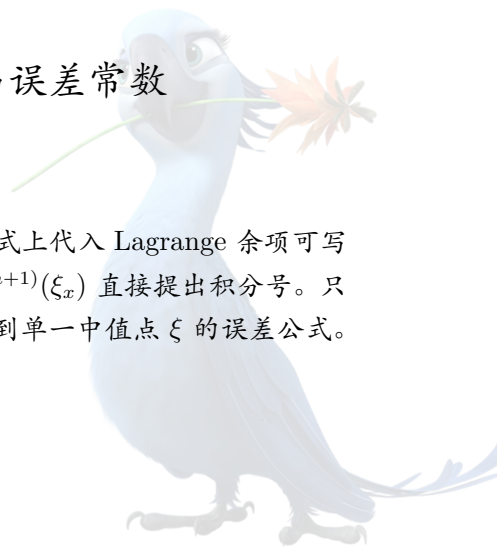
正确策略: 在大区间上使用低阶复合公式; 若需要高阶, 应使用 Gauss 或 Clenshaw-Curtis, 而不是无限提高单个 Newton-Cotes 面板的次数。

**【复杂度】** 单个  $N$  阶 Newton-Cotes 面板需  $N+1$  次函数值。高阶权重预计算可以离线完成, 但不能消除其条件数问题。

## 3.3 求积误差: 插值余项、Peano 核与误差常数

### 3.3.1 知识点四: 从插值余项到求积误差

若  $Q_n$  为插值型公式, 则  $I(f) - Q_n(f) = \int_a^b (f(x) - I_n f(x)) dx$ 。形式上代入 Lagrange 余项可写  $f(x) - I_n f(x) = \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x)$ 。但由于  $\xi_x$  依赖  $x$ , 不能无条件把  $f^{(n+1)}(\xi_x)$  直接提出积分号。只有在节点多项式不变号或通过 Peano 核证明核具有固定符号时, 才能得到单一中值点  $\xi$  的误差公式。





## 易错点与反例

错误推导： $\int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \omega_{n+1}(x) dx = \frac{f^{(n+1)}(\xi)}{(n+1)!} \int_a^b \omega_{n+1}(x) dx$  而未说明  $\omega_{n+1}$  或相应核是否保持同号。

正确工具：Peano 核定理。

## 3.3.2 知识点五：Peano 核定理

设误差泛函  $\mathcal{E}(f) = I(f) - Q(f)$ 。

定理 3.10 (Peano 核定理). 若线性泛函  $\mathcal{E}$  对  $\mathbb{P}_{m-1}$  中的所有多项式为零, 并且  $f \in C^m[a, b]$ , 则

$$\mathcal{E}(f) = \int_a^b f^{(m)}(t) K_m(t) dt, \quad (3.25)$$

其中

$$K_m(t) = \mathcal{E}_x \left[ \frac{(x-t)_+^{m-1}}{(m-1)!} \right], \quad (x-t)_+ = \max\{x-t, 0\}. \quad (3.26)$$

因此

$$|\mathcal{E}(f)| \leq \|f^{(m)}\|_\infty \int_a^b |K_m(t)| dt. \quad (3.27)$$

若  $K_m$  在  $[a, b]$  上不变号, 则存在  $\xi \in (a, b)$  使

$$\mathcal{E}(f) = f^{(m)}(\xi) \int_a^b K_m(t) dt. \quad (3.28)$$

证明. Taylor 公式的积分余项为

$$f(x) = \sum_{j=0}^{m-1} \frac{f^{(j)}(a)}{j!} (x-a)^j + \int_a^b f^{(m)}(t) \frac{(x-t)_+^{m-1}}{(m-1)!} dt. \quad (3.29)$$

对  $x$  变量施加  $\mathcal{E}$ 。由于  $\mathcal{E}$  消灭  $\mathbb{P}_{m-1}$ ,  $\mathcal{E}(f) = \mathcal{E}_x \left[ \int_a^b f^{(m)}(t) \frac{(x-t)_+^{m-1}}{(m-1)!} dt \right]$ 。由线性性及积分交换,  $\mathcal{E}(f) = \int_a^b f^{(m)}(t) \mathcal{E}_x \left[ \frac{(x-t)_+^{m-1}}{(m-1)!} \right] dt$ 。这即为式 (3.25)。误差界由三角不等式得到; 核不变号时使用积分中值定理得到式 (3.28)。□

【证明要求】 需要会完整证明: Peano 核表示。需要掌握: 核定号后如何得到误差常数。

## 证明思路

识别信号: 求积公式已知代数精度, 要求严格误差公式; 插值余项中的中值点无法直接提出积分号。

构造步骤:

1. 定义误差泛函  $\mathcal{E} = I - Q$ ;
2. 确定它消灭到几次多项式;
3. 写 Taylor 积分余项;
4. 定义截断幂函数对应的 Peano 核;
5. 判断核符号并积分核。

常见失败原因: 使用错误的  $m$ ; 若 DOP 为  $d$ , 应取  $m = d + 1$ 。

## 3.3.3 中点、梯形与 Simpson 的 Peano 核

先在标准区间  $[0, 1]$  上讨论。

中点公式  $Q_M(f) = f(1/2)$ 。其 DOP 为 1, 故取  $m = 2$ 。Peano 核为

$$K_M(t) = \begin{cases} \frac{t^2}{2}, & 0 \leq t \leq \frac{1}{2}, \\ \frac{(1-t)^2}{2}, & \frac{1}{2} \leq t \leq 1. \end{cases} \quad (3.30)$$

核非负, 且  $\int_0^1 K_M(t) dt = \frac{1}{24}$ 。因此

$$\int_0^1 f(x) dx - f(1/2) = \frac{1}{24} f''(\xi). \quad (3.31)$$

梯形公式  $Q_T(f) = \frac{1}{2}[f(0) + f(1)]$ 。Peano 核为

$$K_T(t) = -\frac{1}{2}t(1-t) \leq 0, \quad (3.32)$$

且  $\int_0^1 K_T(t) dt = -\frac{1}{12}$ 。故

$$\int_0^1 f(x) dx - \frac{1}{2}[f(0) + f(1)] = -\frac{1}{12} f''(\xi). \quad (3.33)$$

Simpson 公式  $Q_S(f) = \frac{1}{6}[f(0) + 4f(1/2) + f(1)]$ 。DOP 为 3, 故取  $m = 4$ 。Peano 核为

$$K_S(t) = \frac{(1-t)^4}{24} - \frac{(1-t)^3}{36} - \frac{1}{9} \left( \frac{1}{2} - t \right)_+^3. \quad (3.34)$$

分段化简为

$$K_S(t) = \begin{cases} \frac{t^3(3t-2)}{72}, & 0 \leq t \leq \frac{1}{2}, \\ \frac{(t-1)^3(3t-1)}{72}, & \frac{1}{2} \leq t \leq 1. \end{cases} \quad (3.35)$$

故  $K_S(t) \leq 0$ , 并且  $\int_0^1 K_S(t) dt = -\frac{1}{2880}$ 。于是

$$\int_0^1 f(x) dx - \frac{1}{6}[f(0) + 4f(1/2) + f(1)] = -\frac{1}{2880} f^{(4)}(\xi). \quad (3.36)$$

仿射缩放到长度为  $H = b - a$  的区间, 得到

$$I(f) - M(f) = \frac{H^3}{24} f''(\xi_M), \quad (3.37)$$

$$I(f) - T(f) = -\frac{H^3}{12} f''(\xi_T), \quad (3.38)$$

$$I(f) - S(f) = -\frac{H^5}{2880} f^{(4)}(\xi_S). \quad (3.39)$$

基础例题: 凸函数下中点与梯形公式的误差方向

若  $f''(x) \geq 0$ , 则  $f$  为凸函数。由式 (3.37) and (3.38),  $I(f) - M(f) \geq 0$ ,  $I(f) - T(f) \leq 0$ 。因此

$$M(f) \leq I(f) \leq T(f). \quad (3.40)$$

这不仅给出误差阶，还给出上下界。

### 3.4 复合求积：局部误差累积、非均匀剖分与复杂度

#### 3.4.1 知识点六：复合中点、梯形与单元 Simpson 公式

设一般剖分  $a = x_0 < x_1 < \cdots < x_N = b$ ,  $h_i = x_{i+1} - x_i$ ,  $h = \max_i h_i$ , 并令  $m_i = \frac{x_i + x_{i+1}}{2}$ 。

定义复合中点公式

$$M_{\Delta}(f) = \sum_{i=0}^{N-1} h_i f(m_i), \quad (3.41)$$

复合梯形公式

$$T_{\Delta}(f) = \sum_{i=0}^{N-1} \frac{h_i}{2} [f(x_i) + f(x_{i+1})], \quad (3.42)$$

以及逐单元 Simpson 公式

$$S_{\Delta}(f) = \sum_{i=0}^{N-1} \frac{h_i}{6} [f(x_i) + 4f(m_i) + f(x_{i+1})]. \quad (3.43)$$

**【局部误差到整体误差】** 若  $f \in C^2[a, b]$ , 则每个单元上  $\int_{x_i}^{x_{i+1}} f(x) dx - h_i f(m_i) = \frac{h_i^3}{24} f''(\xi_i^M)$ , 以及  $\int_{x_i}^{x_{i+1}} f(x) dx - \frac{h_i}{2} [f(x_i) + f(x_{i+1})] = -\frac{h_i^3}{12} f''(\xi_i^T)$ 。求和并用  $\sum_{i=0}^{N-1} h_i^3 \leq h^2 \sum_{i=0}^{N-1} h_i = (b-a)h^2$  得到

$$|I(f) - M_{\Delta}(f)| \leq \frac{b-a}{24} h^2 \|f''\|_{\infty}, \quad (3.44)$$

$$|I(f) - T_{\Delta}(f)| \leq \frac{b-a}{12} h^2 \|f''\|_{\infty}. \quad (3.45)$$

若  $f \in C^4[a, b]$ , 则  $\int_{x_i}^{x_{i+1}} f(x) dx - \frac{h_i}{6} [f(x_i) + 4f(m_i) + f(x_{i+1})] = -\frac{h_i^5}{2880} f^{(4)}(\xi_i)$ , 从而

$$|I(f) - S_{\Delta}(f)| \leq \frac{b-a}{2880} h^4 \|f^{(4)}\|_{\infty}. \quad (3.46)$$

#### 证明思路

识别信号：题目问“为什么局部三阶误差得到整体二阶”、“非均匀网格如何估计”。

构造步骤：

1. 在每个单元使用单面板误差；
2. 对局部误差绝对值求和；
3. 使用  $h_i^{p+1} \leq h^p h_i$ ；
4. 得到  $\sum_i h_i^{p+1} \leq (b-a)h^p$ 。

结论：局部误差指数比整体收敛阶高 1。

常见失败原因：把  $N$  个局部误差简单写成  $NO(h^{p+1})$  却不说明  $N = O(h^{-1})$ 。

#### 3.4.2 经典复合 Simpson 公式的步长约定

若使用均匀基础网格  $x_j = a + jh$ ,  $h = \frac{b-a}{2m}$ ,  $j = 0, \dots, 2m$ , 经典复合 Simpson 公式为

$$S_h(f) = \frac{h}{3} \left[ f(x_0) + f(x_{2m}) + 4 \sum_{j=1}^m f(x_{2j-1}) + 2 \sum_{j=1}^{m-1} f(x_{2j}) \right]. \quad (3.47)$$



此时每个 Simpson 面板宽度为  $2h$ ，故

$$I(f) - S_h(f) = -\frac{b-a}{180} h^4 f^{(4)}(\xi). \quad (3.48)$$

#### 易错点与反例

资料中常有两种“ $h$ ”:

1. 若  $h$  表示一个完整 Simpson 面板的宽度，则误差常数为  $\frac{b-a}{2880} h^4$ ;

2. 若  $h$  表示相邻基础节点间距，而一个面板宽度为  $2h$ ，则误差常数为  $\frac{b-a}{180} h^4$ .

两者完全一致，因为  $\frac{(2h)^4}{2880} = \frac{h^4}{180}$ 。答题时必须先定义步长。

### 3.4.3 复合梯形公式的递推更新

对均匀剖分，记  $T_N$  为  $N$  个子区间的复合梯形公式，步长  $h_N = \frac{b-a}{N}$ 。将每个旧单元二分，有

$$T_{2N} = \frac{1}{2} T_N + \frac{h_N}{2} \sum_{j=0}^{N-1} f\left(a + \left(j + \frac{1}{2}\right) h_N\right). \quad (3.49)$$

因此从  $N$  加密到  $2N$  时，只需计算新增中点处的  $N$  个函数值。

#### Algorithm 9 递推复合梯形公式

**Input:** 函数  $f$ 、区间  $[a, b]$ 、最大层数  $K$

**Output:**  $T_{2^k}$ ,  $k = 0, \dots, K$

1: **Initialization:**  $T_1 \leftarrow \frac{b-a}{2} [f(a) + f(b)]$

2: **for**  $k = 1, \dots, K$  **do**

3:  $N \leftarrow 2^{k-1}$ ,  $h \leftarrow (b-a)/N$

4:  $s \leftarrow \sum_{j=0}^{N-1} f\left(a + \left(j + \frac{1}{2}\right) h\right)$

5:  $T_{2N} \leftarrow \frac{1}{2} T_N + \frac{h}{2} s$

6: **end for**

7: **Stopping criterion:** 达到层数  $K$ ，或相邻层差满足用户给定容差

8: **Complexity:** 达到  $2^K$  个子区间共需  $2^K + 1$  个不同函数值；总运算  $O(2^K)$ ；滚动存储  $O(1)$

**【稳定性】** 复合中点、梯形和 Simpson 均为正权公式，因此关于节点数据的绝对稳定常数为  $b-a$ 。然而函数采样误差若随位置不均匀，应使用  $|\delta Q| \leq \sum_j |W_j| |\delta f_j|$  而非统一误差上界。

**【停止准则】** 相邻网格差  $|Q_{h/2} - Q_h|$  只有在已进入渐近误差区间、且主误差项未异常消失时，才能作为可靠误差估计。第 04 部分将讨论自适应容差分配。

#### 综合例题：非均匀复合梯形公式

设  $0 = x_0 < x_1 < \dots < x_N = 1$  为任意剖分， $h = \max h_i$ ，以复合梯形公式逼近  $I = \int_0^1 e^x dx$ 。由于  $\|f''\|_\infty = e$ ，有  $|I - T_\Delta| \leq \frac{e}{12} \sum_{i=0}^{N-1} h_i^3 \leq \frac{e}{12} h^2$ 。该结论不要求网格均匀；但若某个单元很大，则最大步长控制整体误差。

## 3.5 Euler-Maclaurin 公式与周期梯形公式

### 3.5.1 知识点七: Bernoulli 数与 Bernoulli 多项式

Bernoulli 多项式由生成函数定义:

$$\frac{te^{xt}}{e^t - 1} = \sum_{k=0}^{\infty} B_k(x) \frac{t^k}{k!}. \quad (3.50)$$

Bernoulli 数定义为  $B_k = B_k(0)$ 。前几个值为

$$B_0 = 1, \quad B_1 = -\frac{1}{2}, \quad B_2 = \frac{1}{6}, \quad B_4 = -\frac{1}{30}, \quad B_6 = \frac{1}{42}, \quad (3.51)$$

并且  $B_{2k+1} = 0, \quad k \geq 1$ 。

定义周期 Bernoulli 函数

$$\tilde{B}_m(t) = B_m(t - [t]), \quad (3.52)$$

在整数点处按适当单侧值或连续延拓解释。

### 3.5.2 Euler-Maclaurin 展开

设  $h = \frac{b-a}{N}$ ,  $x_j = a + jh$ , 并定义复合梯形公式

$$T_h(f) = h \left[ \frac{1}{2}f(a) + \sum_{j=1}^{N-1} f(x_j) + \frac{1}{2}f(b) \right]. \quad (3.53)$$

定理 3.11 (Euler-Maclaurin 渐近展开). 若  $f \in C^{2p+2}[a, b]$ , 则

$$\begin{aligned} T_h(f) - I(f) &= \sum_{r=1}^p \frac{B_{2r}}{(2r)!} h^{2r} [f^{(2r-1)}(b) - f^{(2r-1)}(a)] \\ &\quad + O(h^{2p+2}). \end{aligned} \quad (3.54)$$

特别地,

$$\begin{aligned} T_h(f) - I(f) &= \frac{h^2}{12} [f'(b) - f'(a)] \\ &\quad - \frac{h^4}{720} [f^{(3)}(b) - f^{(3)}(a)] \\ &\quad + \frac{h^6}{30240} [f^{(5)}(b) - f^{(5)}(a)] + \cdots. \end{aligned} \quad (3.55)$$

【推导来源】 Euler-Maclaurin 公式可由周期 Bernoulli 函数分部积分递推得到。其本质是把离散求和与连续积分之差表示为端点奇阶导数修正项加周期余项。

#### 证明思路

识别信号: 复合梯形公式、端点导数、仅出现偶次幂、Romberg 外推、周期函数高阶收敛。

构造步骤:

1. 将每个网格单元上的误差写成 Bernoulli 核积分;
2. 对周期 Bernoulli 函数反复分部积分;
3. 边界项产生  $f^{(2r-1)}(b) - f^{(2r-1)}(a)$ ;

4. 奇数 Bernoulli 数消失, 故仅保留  $h^{2r}$ 。

结论: 一般函数二阶; 若端点导数逐阶匹配, 则低阶项依次消失。

常见失败原因: 把“公式中只有偶次幂”误认为任何非均匀网格或奇异积分也具有同样展开。

### 3.5.3 端点修正梯形公式

若端点导数可得, 可定义

$$T_h^{[2p]}(f) = T_h(f) - \sum_{r=1}^p \frac{B_{2r}}{(2r)!} h^{2r} [f^{(2r-1)}(b) - f^{(2r-1)}(a)]. \quad (3.56)$$

则  $I(f) - T_h^{[2p]}(f) = O(h^{2p+2})$ 。该方法需要端点高阶导数; Romberg 则通过不同网格的函数值自动消去相同误差项。

### 3.5.4 周期光滑函数的任意代数阶收敛

设  $f$  是周期为  $L = b - a$  的函数。若  $f \in C^m(\mathbb{T}_L)$ , 则

$$f^{(r)}(a) = f^{(r)}(b), \quad r = 0, \dots, m-1. \quad (3.57)$$

Euler-Maclaurin 中的所有可用端点修正项均消失。

更精确地, 周期 Bernoulli 余项给出

$$I(f) - T_h(f) = -\frac{h^m}{m!} \int_a^b \tilde{B}_m\left(\frac{x-a}{h}\right) f^{(m)}(x) dx, \quad (3.58)$$

其中整体符号依 Bernoulli 函数在整数点的约定而可能改变, 但绝对值估计不变。因此

$$|I(f) - T_h(f)| \leq \frac{\|\tilde{B}_m\|_\infty}{m!} h^m \|f^{(m)}\|_{L^1(a,b)}. \quad (3.59)$$

若  $f \in C^\infty(\mathbb{T}_L)$ , 则对每个固定  $p$ ,  $|I(f) - T_h(f)| = O(h^p)$ 。这称为超代数收敛或谱精度。

#### 易错点与反例

$C^\infty$  不自动推出统一指数收敛。

虽然对任意固定  $p$  都有  $O(h^p)$ , 但常数包含  $\|f^{(p)}\|$ 。该常数可能随  $p$  快速增长, 因此不能令  $p \rightarrow \infty$  便宣称误差为零。真正的几何/指数收敛需要复解析延拓。

### 3.5.5 解析周期函数的指数收敛


考虑  $2\pi$  周期函数  $f(x) = \sum_{k \in \mathbb{Z}} \hat{f}_k e^{ikx}$ ,  $\hat{f}_k = \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-ikx} dx$ 。取  $h = \frac{2\pi}{N}$ ,  $T_N(f) = h \sum_{j=0}^{N-1} f(jh)$ 。

离散指数和满足  $\frac{1}{N} \sum_{j=0}^{N-1} e^{2\pi i k j / N} = \begin{cases} 1, & N \mid k, \\ 0, & N \nmid k. \end{cases}$  因此

$$T_N(f) = 2\pi \sum_{\ell \in \mathbb{Z}} \hat{f}_{\ell N}, \quad (3.60)$$

而  $I(f) = 2\pi \hat{f}_0$ 。故

$$T_N(f) - I(f) = 2\pi \sum_{\ell \neq 0} \hat{f}_{\ell N}. \quad (3.61)$$





若  $f$  可解析延拓到复条带  $S_\alpha = \{z \in \mathbb{C} : |\Im z| < \alpha\}$  并在其中满足  $|f(z)| \leq M$ , 则通过将 Fourier 系数积分路径向上或向下移动  $\alpha$ ,

$$|\hat{f}_k| \leq M e^{-\alpha|k|}. \quad (3.62)$$

代入式 (3.61):

$$\begin{aligned} |T_N(f) - I(f)| &\leq 2\pi M \sum_{\ell \neq 0} e^{-\alpha|\ell|N} \\ &= 4\pi M \frac{e^{-\alpha N}}{1 - e^{-\alpha N}} \\ &= \frac{4\pi M}{e^{\alpha N} - 1}. \end{aligned} \quad (3.63)$$

**【误差与精度】** 指数收敛率由距离实轴最近的复奇点决定。条带越宽,  $\alpha$  越大, 收敛越快。

**【稳定性】** 周期梯形公式为等权正权公式:  $W_j = \frac{2\pi}{N} > 0$ 。其数据扰动绝对稳定常数为  $2\pi$ 。指数逼近误差并不意味着舍入误差也指数下降; 当离散误差降到机器精度附近后, 继续增大  $N$  不再有效。

**【复杂度】** 只计算积分时为  $O(N)$  函数采样与求和; 若函数值已由周期 FFT 网格给出, 积分只是零频系数, 额外成本  $O(N)$  或可并入 FFT 流程。

## 3.6 Richardson 外推与 Romberg 积分

### 3.6.1 知识点八: 一般 Richardson 外推

**【重要性等级】** **B 级**。外推思想不仅用于积分, 还用于数值微分、ODE/PDE 网格收敛检验和误差阶估计。虽然没有直接考过, 但是这个思想还是有一定价值的。

设某近似量满足渐近展开

$$Q(h) = Q + c_1 h^{p_1} + c_2 h^{p_2} + \cdots, \quad 0 < p_1 < p_2 < \cdots. \quad (3.64)$$

则  $Q(h/2) = Q + 2^{-p_1} c_1 h^{p_1} + 2^{-p_2} c_2 h^{p_2} + \cdots$ 。消去首项得到

$$Q^{[1]}(h) = \frac{2^{p_1} Q(h/2) - Q(h)}{2^{p_1} - 1} = Q + O(h^{p_2}). \quad (3.65)$$

更一般地, 若加密比为  $r > 1$ ,

$$Q^{[1]}(h) = \frac{r^{p_1} Q(h/r) - Q(h)}{r^{p_1} - 1}. \quad (3.66)$$

**【必要条件】** Richardson 外推要求:

1. 存在稳定的幂次误差展开;
2. 不同网格上的主误差系数  $c_1$  相同;
3. 已进入渐近区间;
4. 函数正则性足以支持该展开;
5. 网格结构与边界处理保持一致。



## 易错点与反例

以下情形不能机械套用外推：

- 被积函数有端点奇异或不连续；
- 非均匀网格随加密方式改变；
- 误差含  $h^p \log h$  而非纯幂；
- 主项系数偶然为零，实际阶高于假设；
- 舍入误差已成为主导项。

## 3.6.2 梯形公式外推与 Simpson 公式

Euler-Maclaurin 给出  $T(h) = I + c_1 h^2 + c_2 h^4 + c_3 h^6 + \cdots$ 。取  $p_1 = 2$ ：

$$\frac{4T(h/2) - T(h)}{3} = I + O(h^4). \quad (3.67)$$

当粗细网格嵌套时，上式恰等于相应的复合 Simpson 公式。

## 3.6.3 Romberg 递推

令  $h_k = \frac{b-a}{2^k}$ ,  $R_{k,0} = T_{h_k}(f)$ 。定义

$$R_{k,j} = R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^j - 1} = \frac{4^j R_{k,j-1} - R_{k-1,j-1}}{4^j - 1}, \quad (3.68)$$

其中  $1 \leq j \leq k$ 。

若  $f$  足够光滑，使梯形误差具有足够长的偶次幂展开，则

$$R_{k,j} = I(f) + O(h_k^{2j+2}). \quad (3.69)$$

证明. 对  $j$  归纳。 $j = 0$  时  $R_{k,0} = I + c_1 h_k^2 + c_2 h_k^4 + \cdots$ 。假设  $R_{k,j-1} = I + c_j h_k^{2j} + O(h_k^{2j+2})$ 。因为  $h_{k-1} = 2h_k$ ，有  $R_{k-1,j-1} = I + c_j 4^j h_k^{2j} + O(h_k^{2j+2})$ 。代入式 (3.68)， $h_k^{2j}$  项恰好消失，故  $R_{k,j} = I + O(h_k^{2j+2})$ 。□

## Algorithm 10 Romberg 积分

**Input:** 函数  $f$ 、区间  $[a, b]$ 、最大层数  $K$ 、绝对容差  $\text{atol}$ 、相对容差  $\text{rtol}$

**Output:** Romberg 近似  $R_{k,k}$

- 1: **Initialization:**  $R_{0,0} \leftarrow \frac{b-a}{2} [f(a) + f(b)]$
- 2: **for**  $k = 1, \dots, K$  **do**
- 3:    $h_k \leftarrow (b-a)/2^k$
- 4:    $s_k \leftarrow \sum_{i=1}^{2^{k-1}} f(a + (2i-1)h_k)$
- 5:    $R_{k,0} \leftarrow \frac{1}{2} R_{k-1,0} + h_k s_k$
- 6:   **for**  $j = 1, \dots, k$  **do**
- 7:      $R_{k,j} \leftarrow R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^j - 1}$
- 8:   **end for**
- 9:   **if**  $|R_{k,k} - R_{k-1,k-1}| \leq \text{atol} + \text{rtol}|R_{k,k}|$  **then**



- 10:        **return**  $R_{k,k}$   
 11:        **end if**  
 12: **end for**  
 13: **Stopping criterion:** 满足对角线差准则, 或达到  $K$   
 14: **Complexity:** 达到第  $K$  层共需  $2^K + 1$  个不同函数值; 时间  $O(2^K + K^2)$ ; 完整表存储  $O(K^2)$ , 滚动数组可降为  $O(K)$

#### 算法说明

相邻对角元素之差只是后验经验误差指标。若尚未进入偶次幂渐近区间, 或者函数存在奇异性, 该差可能严重低估真实误差。

#### 完整例题: Romberg 对 $x^4$ 的逐级计算

计算  $I = \int_0^1 x^4 dx = \frac{1}{5}$ 。取 1, 2, 4 个子区间。

一级梯形:  $R_{0,0} = T_1 = \frac{1}{2}$ 。

二分一次:  $R_{1,0} = T_2 = \frac{1}{2} \left[ \left(\frac{1}{2}\right)^4 + \frac{1}{2} \right] = \frac{9}{32}$ 。第一次外推:  $R_{1,1} = \frac{4R_{1,0} - R_{0,0}}{3} = \frac{5}{24}$ 。

再二分:

$$\begin{aligned} R_{2,0} &= T_4 \\ &= \frac{1}{4} \left[ \left(\frac{1}{4}\right)^4 + \left(\frac{1}{2}\right)^4 + \left(\frac{3}{4}\right)^4 + \frac{1}{2} \right] = \frac{113}{512}. \end{aligned}$$

第一次外推:  $R_{2,1} = \frac{4R_{2,0} - R_{1,0}}{3} = \frac{77}{384}$ 。第二次外推:  $R_{2,2} = \frac{16R_{2,1} - R_{1,1}}{15} = \frac{1}{5}$ 。因此第二条 Romberg 对角线已对四次多项式精确。

### 3.7 正式真题 [25S-Q1]——周期梯形公式的高阶与指数收敛

#### 完整题目叙述

设  $f$  是周期为  $2\pi$  的函数, 考虑  $I(f) = \int_0^{2\pi} f(x) dx$  及复合周期梯形公式

$$I_h^{\text{Tr}}(f) = h \sum_{j=1}^n f(jh), \quad h = \frac{2\pi}{n}. \quad (3.70)$$

(i) 若  $f \in C^m([0, 2\pi])$  且按周期方式光滑拼接, 证明存在与  $h$  无关的常数  $C > 0$  使  $|I(f) - I_h^{\text{Tr}}(f)| \leq Ch^m$ 。


(ii) 若  $f$  进一步为解析周期函数, 证明该公式指数收敛。

第 (i) 问详细解答: Euler-Maclaurin 方法。首先说明式 (3.70) 确为复合梯形公式。因为  $f(0) = f(2\pi)$ , 有

$$h \sum_{j=1}^n f(jh) = h \left[ \frac{1}{2} f(0) + \sum_{j=1}^{n-1} f(jh) + \frac{1}{2} f(2\pi) \right].$$

“ $f$  为  $C^m$  周期函数”应解释为  $f$  定义在圆周  $\mathbb{T}$  上属于  $C^m$ , 从而

$$f^{(r)}(0) = f^{(r)}(2\pi), \quad r = 0, 1, \dots, m-1. \quad (3.71)$$



由周期 Euler-Maclaurin 余项公式,

$$I(f) - I_h^{\text{Tr}}(f) = -\frac{h^m}{m!} \int_0^{2\pi} \tilde{B}_m\left(\frac{x}{h}\right) f^{(m)}(x) dx, \quad (3.72)$$

其中  $\tilde{B}_m$  为有界的周期 Bernoulli 函数。于是

$$\begin{aligned} |I(f) - I_h^{\text{Tr}}(f)| &\leq \frac{h^m}{m!} \|\tilde{B}_m\|_\infty \int_0^{2\pi} |f^{(m)}(x)| dx \\ &= C_m(f) h^m, \end{aligned} \quad (3.73)$$

其中  $C_m(f) = \frac{\|\tilde{B}_m\|_\infty}{m!} \|f^{(m)}\|_{L^1(0,2\pi)}$  与  $h, n$  无关。因此公式达到  $m$  阶收敛。□

注 3.12. 若  $m \geq 2$ , 还可使用 Fourier 系数衰减证明。周期端点条件允许连续分部积分  $m$  次, 得到  $|\hat{f}_k| \leq \frac{\|f^{(m)}\|_{L^1}}{2\pi|k|^m}$ 。但直接求和  $\sum_{\ell \neq 0} |\ell n|^{-m}$  在  $m = 1$  时不绝对收敛, 因此要覆盖全部  $m \geq 1$ , 周期 Bernoulli 余项是更稳妥的统一证明。

第 (ii) 问详细解答: Fourier 混叠方法. 设  $f$  可解析延拓到复条带  $S_\alpha = \{z \in \mathbb{C} : |\Im z| < \alpha\}$ , 并在闭子条带上满足  $|f(z)| \leq M$ 。实解析且  $2\pi$  周期的函数在紧圆周上可取得某个统一正宽度的复解析邻域, 因此可选  $\alpha > 0$ 。

Fourier 展开为  $f(x) = \sum_{k \in \mathbb{Z}} \hat{f}_k e^{ikx}$ 。对  $k > 0$ , 将积分路径下移至  $x - i\alpha$ ; 对  $k < 0$ , 将路径上移至  $x + i\alpha$ 。由 Cauchy 定理及周期性,  $|\hat{f}_k| \leq M e^{-\alpha|k|}$ 。

另一方面, 离散正交关系给出  $I_h^{\text{Tr}}(f) = 2\pi \sum_{\ell \in \mathbb{Z}} \hat{f}_{\ell n}$ 。故

$$|I_h^{\text{Tr}}(f) - I(f)| = 2\pi \left| \sum_{\ell \neq 0} \hat{f}_{\ell n} \right| \leq 2\pi M \sum_{\ell \neq 0} e^{-\alpha|\ell|n} = \frac{4\pi M}{e^{\alpha n} - 1}.$$

因此

$$|I_h^{\text{Tr}}(f) - I(f)| = O(e^{-\alpha n}) = O(e^{-2\pi\alpha/h}), \quad (3.74)$$

即指数收敛。□

#### 易错点与反例

易错点 1: 把  $h \sum_{j=1}^n f(jh)$  误认为普通右矩形公式而断言只有一阶。周期性使首尾数据重合, 它正是周期梯形公式。

易错点 2:  $f \in C^m[0, 2\pi]$  若不满足周期导数匹配, 则不能得到  $m$  阶; 仅有  $f(0) = f(2\pi)$  时一般仍可能出现较低阶端点项。

易错点 3: 解析函数的指数常数由复奇点距离决定, 不是仅由实轴导数有界决定。

### 3.8 补充训练题: 丘赛 2024 Problem 2——无穷区间积分、截断误差与变量代换

#### 完整题目叙述

考虑无穷区间积分

$$I_\infty = \int_0^\infty f(x) dx, \quad (3.75)$$

其中  $f$  连续,  $f'(0) \neq 0$ , 且当  $x \rightarrow \infty$  时  $f(x)$  按  $x^{-1-\alpha}$  衰减,  $\alpha > 0$ 。

(a) 在  $[0, L]$  上使用  $n$  个等距子区间的复合梯形公式。固定  $L$ , 令  $n \rightarrow \infty$  时, 求离散误差的

渐近公式。

(b) 将第 (a) 问的求积值作为整个  $[0, \infty)$  积分的近似。应如何令  $L$  随  $n$  增长，以优化总误差衰减率？最优误差阶是多少？

(c) 作变量代换  $x = \frac{L(1+y)}{1-y}$ ,  $y = \frac{x-L}{x+L}$ , 将积分化为  $\int_{-1}^1 F_L(y) dy$ . 固定  $L$  时, 在  $[-1, 1]$  上使用等距复合梯形公式, 求其渐近误差。

(d) 根据  $\alpha$  比较“截断区间法”与“变量代换法”。

注 3.13 (题面正则性的必要补充). 原题只写  $f$  连续、 $f'(0) \neq 0$  以及代数衰减。要严格推导“渐近误差公式”，还需要补充足够的光滑性和尾部展开。以下采用

$$f(x) = c_\infty x^{-1-\alpha} + o(x^{-1-\alpha}), \quad c_\infty \neq 0, \quad (3.76)$$

并假设相应导数具有可微的渐近展开, 例如  $f'(x) = -(1+\alpha)c_\infty x^{-2-\alpha} + o(x^{-2-\alpha})$ 。若不增加这些条件, 只能给出数量级上界, 不能唯一确定渐近系数。

第 (a) 问详细解答. 令  $h = \frac{L}{n}$  并定义

$$T_{n,L} = h \left[ \frac{1}{2} f(0) + \sum_{j=1}^{n-1} f(jh) + \frac{1}{2} f(L) \right]. \quad (3.77)$$

固定  $L$  时, 由 Euler-Maclaurin 展开,

$$T_{n,L} - \int_0^L f(x) dx = \frac{h^2}{12} [f'(L) - f'(0)] + O(h^4). \quad (3.78)$$

代入  $h = L/n$ :

$$T_{n,L} - \int_0^L f(x) dx = \frac{L^2}{12n^2} [f'(L) - f'(0)] + O(n^{-4}). \quad (3.79)$$

其中  $O(n^{-4})$  的常数依赖固定的  $L$  及  $f$  在  $[0, L]$  上的高阶导数。□

第 (b) 问详细解答. 总误差定义为  $E_{n,L} = I_\infty - T_{n,L}$ 。分解为

$$E_{n,L} = \left[ \int_0^L f(x) dx - T_{n,L} \right] + \int_L^\infty f(x) dx. \quad (3.80)$$

由第 (a) 问,  $\int_0^L f - T_{n,L} = \frac{L^2}{12n^2} [f'(0) - f'(L)] + O\left(\frac{L^4}{n^4}\right)$ , 而由式 (3.76),

$$\int_L^\infty f(x) dx = \frac{c_\infty}{\alpha} L^{-\alpha} + o(L^{-\alpha}). \quad (3.81)$$

当  $L \rightarrow \infty$  时  $f'(L) = o(1)$ , 因此

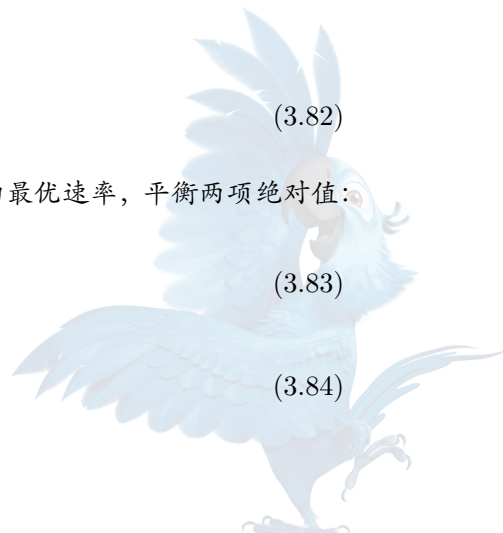
$$E_{n,L} = \frac{f'(0)}{12} \frac{L^2}{n^2} + \frac{c_\infty}{\alpha} L^{-\alpha} + o\left(\frac{L^2}{n^2} + L^{-\alpha}\right), \quad (3.82)$$

其中应注意两项可能因符号不同而发生偶然消去。为了获得对符号稳健的最优速率, 平衡两项绝对值:  $\frac{L^2}{n^2} \asymp L^{-\alpha}$ 。故

$$L^{\alpha+2} \asymp n^2, \quad \boxed{L \asymp n^{2/(\alpha+2)}}. \quad (3.83)$$

代回得到

$$\boxed{|E_{n,L}| = O(n^{-2\alpha/(\alpha+2)})}. \quad (3.84)$$



若进一步最小化上界  $\frac{|f'(0)|}{12} \frac{L^2}{n^2} + \frac{|c_\infty|}{\alpha} L^{-\alpha}$ , 则最优尺度常数满足

$$L_* = \left( \frac{6|c_\infty|}{|f'(0)|} \right)^{1/(\alpha+2)} n^{2/(\alpha+2)}. \quad (3.85)$$

□

第 (c) 问详细解答. 变量代换为  $x = x(y) = \frac{L(1+y)}{1-y}$ ,  $\frac{dx}{dy} = \frac{2L}{(1-y)^2}$ . 因此

$$I_\infty = \int_{-1}^1 F_L(y) dy, \quad F_L(y) = \frac{2L}{(1-y)^2} f\left(\frac{L(1+y)}{1-y}\right). \quad (3.86)$$

当  $y \rightarrow 1^-$  时, 由式 (3.76),

$$\begin{aligned} F_L(y) &\sim \frac{2L}{(1-y)^2} c_\infty \left[ \frac{L(1+y)}{1-y} \right]^{-1-\alpha} \\ &= 2c_\infty L^{-\alpha} (1-y)^{\alpha-1} (1+y)^{-1-\alpha}. \end{aligned} \quad (3.87)$$

由于  $1+y \rightarrow 2$ ,

$$F_L(y) \sim A_L (1-y)^{\alpha-1}, \quad A_L = 2^{-\alpha} c_\infty L^{-\alpha}. \quad (3.88)$$

现在按  $\alpha$  分类。

情形一:  $0 < \alpha < 1$  此时  $\alpha - 1 \in (-1, 0)$ , 故  $F_L$  在  $y = 1$  具有可积但无界的端点奇异性。标准闭型复合梯形公式需要计算  $F_L(1)$ , 因而不能直接使用。

若改用端点避开的开型或奇异性修正公式, 可以继续分析, 但这已属于第 04 部分的奇异积分内容。按原题“直接应用复合梯形公式”的字面, 变量代换法在此区间不可直接实施。

情形二:  $1 < \alpha < 2$  此时  $F_L(1) = 0$ , 但  $F'_L(y) \sim -A_L(\alpha - 1)(1 - y)^{\alpha-2}$  无界。普通二阶 Euler-Maclaurin 展开失效, 误差由代数端点奇异性主导。

令  $\beta = \alpha - 1 \in (0, 1)$ 。对模型函数  $(1 - y)^\beta$ , 幂和的 Euler 展开给出

$$T_n[(1 - y)^\beta] - \int_{-1}^1 (1 - y)^\beta dy = 2^{\beta+1} \zeta(-\beta) n^{-\beta-1} + o(n^{-\beta-1}), \quad (3.89)$$

其中  $\zeta$  为 Riemann zeta 函数。代入  $\beta + 1 = \alpha$  及  $A_L$ , 得到

$$\begin{aligned} T_n(F_L) - I_\infty &= A_L 2^\alpha \zeta(1 - \alpha) n^{-\alpha} + o(n^{-\alpha}) \\ &= \boxed{c_\infty L^{-\alpha} \zeta(1 - \alpha) n^{-\alpha} + o(n^{-\alpha})}. \end{aligned} \quad (3.90)$$

因此固定  $L$  时误差阶为  $O(n^{-\alpha})$ 。

情形三:  $\alpha > 2$  此时  $F_L \in C^1[-1, 1]$ , 且由尾部主项  $F'_L(1) = 0$ 。左端点  $y = -1$  对应  $x = 0$ 。由  $F_L(y) = R(y)f(x(y))$ ,  $R(y) = \frac{2L}{(1-y)^2}$ , 可得  $R(-1) = \frac{L}{2}$ ,  $R'(-1) = \frac{L}{2}$ ,  $x'(-1) = \frac{L}{2}$ 。故

$$F'_L(-1) = \frac{L}{2} f(0) + \frac{L^2}{4} f'(0). \quad (3.91)$$

在  $[-1, 1]$  上使用  $n$  个子区间, 步长为  $\eta = \frac{2}{n}$ 。由梯形 Euler-Maclaurin 公式,

$$\begin{aligned} T_n(F_L) - I_\infty &= \frac{\eta^2}{12} [F'_L(1) - F'_L(-1)] + o(n^{-2}) \\ &= -\frac{1}{3n^2} \left[ \frac{L}{2} f(0) + \frac{L^2}{4} f'(0) \right] + o(n^{-2}). \end{aligned} \quad (3.92)$$

故误差为  $O(n^{-2})$ 。





边界情形  $\alpha = 2$  此时  $F_L(y) \sim \frac{c_\infty}{4L^2}(1-y)$ , 从而  $F'_L(1) = -\frac{c_\infty}{4L^2}$ . 若尾部具有足够光滑的完整渐近展开, 则仍有二阶公式

$$T_n(F_L) - I_\infty = \frac{1}{3n^2}[F'_L(1) - F'_L(-1)] + o(n^{-2}). \quad (3.93)$$

边界情形  $\alpha = 1$  由式 (3.88),  $F_L(y)$  趋于有限非零极限  $F_L(1) = \frac{c_\infty}{2L}$ . 但仅知道  $f(x) \sim c_\infty x^{-2}$  不足以确定  $F_L$  在  $y = 1$  的下一阶正则性, 因此无法从原题假设唯一决定误差常数与精确阶. 若额外假设  $f$  具有关于  $x^{-1}$  的光滑渐近展开, 则  $F_L$  可光滑延拓, 并通常恢复  $O(n^{-2})$ .  $\square$

第 (d) 问详细解答. 截断区间法的最优误差指数为  $p_{\text{trunc}} = \frac{2\alpha}{\alpha+2}$ .

变量代换法在标准闭型梯形公式可直接使用时具有:  $p_{\text{map}} = \begin{cases} \alpha, & 1 < \alpha < 2, \\ 2, & \alpha \geq 2, \end{cases}$  并且  $\alpha > \frac{2\alpha}{\alpha+2}$ ,  $1 < \alpha < 2$ , 以及  $2 > \frac{2\alpha}{\alpha+2}$ ,  $\alpha \geq 2$ . 因此:

1. 对  $1 < \alpha < 2$ , 变量代换法的  $O(n^{-\alpha})$  优于截断法的  $O(n^{-2\alpha/(\alpha+2)})$ ;
2. 对  $\alpha \geq 2$ , 变量代换法通常二阶, 同样优于截断法;
3. 对  $0 < \alpha < 1$ , 变换后函数在端点无界, 标准闭型梯形公式不能直接使用, 截断法更稳健;
4. 对  $\alpha = 1$ , 是否优先使用变量代换取决于是否已知尾部常数及足够的下一阶渐近展开; 原题条件不足以作唯一结论。

若允许使用第 04 部分的奇异性修正、开型求积或变量再变换, 则  $0 < \alpha < 1$  时也可改进变量代换法; 但这已经超出原题“直接使用复合梯形公式”的范围.  $\square$

#### 易错点与反例

错误说法 1: 变量代换把无穷区间变成有限区间, 因此被积函数必然光滑。

反例: 若  $0 < \alpha < 1$ ,  $F_L(y) \sim (1-y)^{\alpha-1} \rightarrow \infty$ .

错误说法 2: 对变换后函数无条件使用  $T - I = \frac{h^2}{12}[F'(1) - F'(-1)] + O(h^4)$ . 该式要求足够端点光滑;  $1 < \alpha < 2$  时  $F'(1)$  发散。

错误说法 3: 只考虑尾截断误差而把  $L$  取得尽可能大. 增大  $L$  同时增大固定  $n$  下的网格宽度  $L/n$ , 使离散误差变大。



# 第四章 数值积分 II——Gauss 求积、Clenshaw–Curtis、自适应求积、奇异积分、多维积分与 Monte Carlo

## 4.1 Gauss 求积的一般理论

### 4.1.1 知识点一：加权积分、节点选择与最高代数精度

【重要性等级】 **S 级**。正交多项式与 Gauss 求积在 [25F-Q2]、[26S-Q2] 中直接考查，并在丘赛 2023、2024 题中以 Jacobi 矩阵和特殊权函数形式出现。必须能够完整证明节点选取、最高代数精度、权重正性和误差公式。

【问题与目标】 设

$$I_\rho(f) = \int_a^b f(x)\rho(x) dx, \quad (4.1)$$

其中积分区间可为有限或无限区间，权函数满足  $\rho(x) \geq 0$ ,  $\rho \not\equiv 0$ , 且所需矩  $\mu_k = \int_a^b x^k \rho(x) dx$  存在。目标是使用  $N$  个节点  $x_1, \dots, x_N$  构造

$$G_N(f) = \sum_{j=1}^N \lambda_j f(x_j), \quad (4.2)$$

使代数精度达到所有  $N$  节点公式中的最高值。

【精确定义与假设】 定义加权内积

$$\langle f, g \rangle_\rho = \int_a^b \overline{f(x)} g(x) \rho(x) dx. \quad (4.3)$$

在实多项式情形共轭可省略。

设  $\pi_N$  是  $N$  次首一正交多项式：

$$\deg \pi_N = N, \pi_N(x) = x^N + \text{低次项}, \langle q, \pi_N \rangle_\rho = 0 \quad \forall q \in \mathbb{P}_{N-1}. \quad (4.4)$$

记

$$h_N = \|\pi_N\|_\rho^2 = \int_a^b \pi_N(x)^2 \rho(x) dx > 0. \quad (4.5)$$

若  $\rho > 0$  几乎处处，则  $\pi_N$  在  $(a, b)$  内具有  $N$  个互异实零点。这些零点即 Gauss 节点。

定理 4.1 (Gauss 节点与最高代数精度). 令  $x_1, \dots, x_N$  为  $\pi_N$  的  $N$  个零点，并令  $\ell_j(x) = \prod_{\substack{1 \leq k \leq N \\ k \neq j}} \frac{x - x_k}{x_j - x_k}$  为相应 Lagrange 基函数。取

$$\lambda_j = \int_a^b \ell_j(x) \rho(x) dx. \quad (4.6)$$

则 Gauss 公式式 (4.2) 对所有  $p \in \mathbb{P}_{2N-1}$  精确, 且不存在具有  $N$  个节点、代数精度超过  $2N-1$  的求积公式。

证明. 任取  $p \in \mathbb{P}_{2N-1}$ 。对  $\pi_N$  作多项式除法:

$$p(x) = q(x)\pi_N(x) + r(x), \quad q, r \in \mathbb{P}_{N-1}. \quad (4.7)$$

因为  $\pi_N(x_j) = 0$ ,  $G_N(p) = G_N(r)$ 。由于  $G_N$  是节点  $x_j$  上的插值型公式, 并且  $\deg r \leq N-1$ ,  $G_N(r) = I_\rho(r)$ 。另一方面, 由正交性,  $I_\rho(q\pi_N) = \langle q, \pi_N \rangle_\rho = 0$ 。故  $I_\rho(p) = I_\rho(r) = G_N(r) = G_N(p)$ 。因此代数精度至少为  $2N-1$ 。

再考虑  $p(x) = \pi_N(x)^2 \in \mathbb{P}_{2N}$ 。在所有节点上  $p(x_j) = 0$ , 所以  $G_N(\pi_N^2) = 0$ 。但  $I_\rho(\pi_N^2) = h_N > 0$ 。故该公式不可能对  $\mathbb{P}_{2N}$  精确。

更一般地, 任意具有  $N$  个节点  $\xi_1, \dots, \xi_N$  的公式均对  $\omega_N(x)^2 = \prod_{j=1}^N (x - \xi_j)^2$  给出零值, 而其正权积分严格为正。因此任何  $N$  节点公式的代数精度均不超过  $2N-1$ 。□

### 4.1.2 知识点二: Gauss 权重的正性与显式表示

定理 4.2 (Gauss 权重严格为正)。在定义 4.1 的条件下,

$$\lambda_j > 0, \quad j = 1, \dots, N. \quad (4.8)$$

证明. 因为  $\ell_j^2 \in \mathbb{P}_{2N-2}$ , Gauss 公式对其精确:

$$\lambda_j = \sum_{k=1}^N \lambda_k \ell_j(x_k)^2 = G_N(\ell_j^2) = I_\rho(\ell_j^2) = \int_a^b \ell_j(x)^2 \rho(x) dx. \quad (4.9)$$

由于  $\ell_j \not\equiv 0$  且  $\rho > 0$  几乎处处, 积分严格为正。□

由 Christoffel–Darboux 公式还可得到

$$\lambda_j = \frac{h_{N-1}}{\pi'_N(x_j)\pi_{N-1}(x_j)}. \quad (4.10)$$

上式右端虽未显式写绝对值, 但其值由前一定理保证为正; 不同多项式归一化下公式需同步换算。

【稳定性与条件数】 因为 Gauss 权重均为正, 且公式对常数精确,  $\sum_{j=1}^N \lambda_j = \int_a^b \rho(x) dx =: \mu_0$ , 所以

$$|G_N(f)| \leq \mu_0 \max_j |f(x_j)|. \quad (4.11)$$

节点数据的  $\ell^\infty$  绝对扰动放大常数正好为  $\mu_0$ , 这是所有对常数精确公式可达到的最小值。

#### 易错点与反例

错误说法: Gauss 公式的权重之所以为正, 是因为节点关于区间中点对称。

错误原因: 一般 Jacobi、Laguerre、Hermite 权重和节点未必具有简单对称性。正权性的本质证明是  $\lambda_j = I_\rho(\ell_j^2) > 0$ 。

### 4.1.3 知识点三: Gauss 误差公式

定理 4.3 (Gauss 求积误差)。设  $[a, b]$  为有限区间,  $\rho \geq 0$ , 且  $f \in C^{2N}[a, b]$ 。则存在  $\xi \in (a, b)$  使

$$I_\rho(f) - G_N(f) = \frac{f^{(2N)}(\xi)}{(2N)!} h_N. \quad (4.12)$$



因此

$$|I_\rho(f) - G_N(f)| \leq \frac{\|f^{(2N)}\|_\infty}{(2N)!} h_N. \quad (4.13)$$

证明. 令  $H_{2N-1}$  为在 Gauss 节点  $x_j$  上满足  $H_{2N-1}(x_j) = f(x_j)$ ,  $H'_{2N-1}(x_j) = f'(x_j)$ ,  $j = 1, \dots, N$  的 Hermite 插值多项式. 其余项为

$$f(x) - H_{2N-1}(x) = \frac{f^{(2N)}(\xi_x)}{(2N)!} \prod_{j=1}^N (x - x_j)^2. \quad (4.14)$$

由于节点多项式恰为首一正交多项式,  $\prod_{j=1}^N (x - x_j) = \pi_N(x)$ .

Gauss 公式对  $H_{2N-1}$  精确, 而且  $G_N(f) = G_N(H_{2N-1})$ , 因为二者在全部节点处函数值相同. 因此

$$I_\rho(f) - G_N(f) = I_\rho(f - H_{2N-1}) = \int_a^b \frac{f^{(2N)}(\xi_x)}{(2N)!} \pi_N(x)^2 \rho(x) dx. \quad (4.15)$$

权函数  $\pi_N(x)^2 \rho(x) \geq 0$  不变号, 故由加权积分中值定理, 存在  $\xi \in (a, b)$  使  $I_\rho(f) - G_N(f) = \frac{f^{(2N)}(\xi)}{(2N)!} \int_a^b \pi_N(x)^2 \rho(x) dx$ . 这就是式 (4.12).  $\square$

#### 证明思路

识别信号: 题目出现  $2N$  阶导数、正交多项式平方、Gauss 误差常数.

构造步骤:

1. 不使用普通 Lagrange 插值, 而使用节点处函数值和导数同时匹配的 Hermite 插值;
2. 余项中节点多项式自动平方;
3. 利用 Gauss 对  $2N - 1$  次多项式精确;
4. 利用平方核非负提取单一中值点.

常见失败原因: 直接把普通插值余项  $f^{(N)}(\xi_x) \pi_N(x)$  积分; 该核一般变号, 不能直接得到  $2N$  阶 Gauss 误差.

#### 4.1.4 Gauss 求积对连续函数的收敛

定理 4.4 (正权 Gauss 公式对连续函数收敛). 设  $[a, b]$  有限,  $\rho \geq 0$  且  $\mu_0 < \infty$ . 则对任意  $f \in C[a, b]$ ,

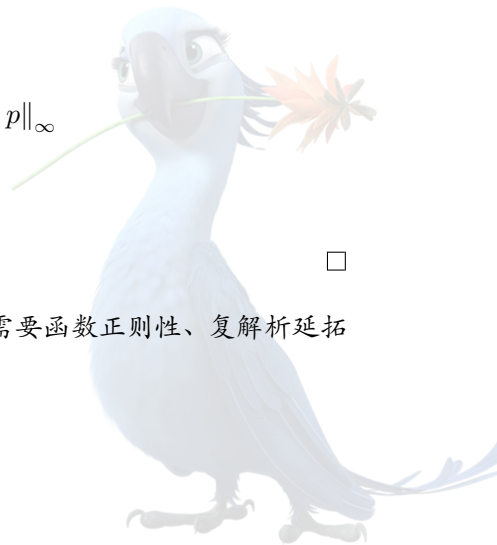
$$G_N(f) \longrightarrow I_\rho(f), \quad N \rightarrow \infty. \quad (4.16)$$

证明. 由 Weierstrass 逼近定理, 对任意  $\varepsilon > 0$ , 存在多项式  $p$  使  $\|f - p\|_\infty < \frac{\varepsilon}{2\mu_0}$ . 当  $N$  足够大时,  $\deg p \leq 2N - 1$ , 故  $G_N(p) = I_\rho(p)$ . 由正权性,

$$\begin{aligned} |I_\rho(f) - G_N(f)| &\leq |I_\rho(f - p)| + |G_N(f - p)| \\ &\leq \mu_0 \|f - p\|_\infty + \left( \sum_j \lambda_j \right) \|f - p\|_\infty \\ &= 2\mu_0 \|f - p\|_\infty < \varepsilon. \end{aligned}$$

$\square$

注 4.5. 该证明只给出收敛, 不给出收敛率. 要获得代数或指数收敛率, 需要函数正则性、复解析延拓或正交展开系数衰减.



## 4.2 三项递推、Jacobi 矩阵与 Golub–Welsch 算法

### 4.2.1 知识点四：标准正交多项式递推

设  $\{\varphi_k\}_{k=0}^{\infty}$  为关于  $\rho$  的标准正交多项式： $\langle \varphi_j, \varphi_k \rangle_{\rho} = \delta_{jk}$ ,  $\deg \varphi_k = k$ 。取  $\varphi_{-1} = 0$ 。存在  $\alpha_k \in \mathbb{R}$ ,  $\beta_k > 0$  使

$$x\varphi_k(x) = \beta_{k+1}\varphi_{k+1}(x) + \alpha_k\varphi_k(x) + \beta_k\varphi_{k-1}(x), \quad (4.17)$$

其中  $\beta_0 = 0$ 。系数为

$$\alpha_k = \langle \varphi_k, x\varphi_k \rangle_{\rho}, \quad (4.18)$$

$$\beta_k = \langle \varphi_{k-1}, x\varphi_k \rangle_{\rho}, \quad k \geq 1. \quad (4.19)$$

定义  $N$  阶 Jacobi 矩阵

$$J_N = \begin{pmatrix} \alpha_0 & \beta_1 & & & \\ \beta_1 & \alpha_1 & \beta_2 & & \\ & \beta_2 & \alpha_2 & \ddots & \\ & & \ddots & \ddots & \beta_{N-1} \\ & & & \beta_{N-1} & \alpha_{N-1} \end{pmatrix}. \quad (4.20)$$

它是实对称不可约三对角矩阵。

$$\text{令 } \Phi_N(x) = \begin{pmatrix} \varphi_0(x) \\ \varphi_1(x) \\ \vdots \\ \varphi_{N-1}(x) \end{pmatrix}. \text{ 由三项递推,}$$

$$x\Phi_N(x) = J_N\Phi_N(x) + \beta_N\varphi_N(x)\mathbf{e}_N. \quad (4.21)$$

若  $x_j$  是  $\varphi_N$  的零点, 则  $J_N\Phi_N(x_j) = x_j\Phi_N(x_j)$ 。因此:

**定理 4.6** (Gauss 节点的 Jacobi 矩阵刻画).  $N$  点 Gauss 求积节点恰为  $J_N$  的全部特征值。

由于  $J_N$  对称, 其特征值均为实数; 由于所有次对角元  $\beta_k > 0$ , 其特征值互异。这从矩阵角度重新证明了正交多项式零点的实性与单性。

### 4.2.2 权重与特征向量

令  $J_N = V\Lambda V^T$ ,  $\Lambda = \text{diag}(x_1, \dots, x_N)$ , 其中  $V$  正交,  $\mathbf{v}_j$  为对应  $x_j$  的单位特征向量。设  $\mu_0 = \int_a^b \rho(x) dx$ 。则

$$\lambda_j = \mu_0 |(\mathbf{v}_j)_1|^2. \quad (4.22)$$

证明要点为:  $\mathbf{v}_j$  与  $\Phi_N(x_j)$  成比例, 而  $\varphi_0(x) = \frac{1}{\sqrt{\mu_0}}$ 。结合 Christoffel 函数  $K_{N-1}(x_j, x_j) = \sum_{k=0}^{N-1} \varphi_k(x_j)^2$  和  $\lambda_j = K_{N-1}(x_j, x_j)^{-1}$ , 即可得到式 (4.22)。


---

**Algorithm 11** Golub–Welsch 构造 Gauss 节点与权重

---

**Input:** 正交递推系数  $\alpha_0, \dots, \alpha_{N-1}$ ,  $\beta_1, \dots, \beta_{N-1}$ , 零阶矩  $\mu_0$

**Output:** Gauss 节点  $x_j$  和权重  $\lambda_j$



- 1: **Initialization:** 组装对称三对角 Jacobi 矩阵  $J_N$
- 2: 使用对称三对角特征值算法计算  $J_N = V\Lambda V^T$
- 3: **for**  $j = 1, \dots, N$  **do**
- 4:      $x_j \leftarrow \Lambda_{jj}$
- 5:      $\lambda_j \leftarrow \mu_0 V_{1j}^2$
- 6: **end for**
- 7: 按节点递增顺序重排  $(x_j, \lambda_j)$
- 8: **Stopping criterion:** 所有节点位于支撑区间且  $\lambda_j > 0$
- 9: **Complexity:** 全部节点与权重通常为  $O(N^2)$  运算、 $O(N)$  至  $O(N^2)$  存储；不得按稠密矩阵无结构地使用  $O(N^3)$  算法

#### 易错点与反例

错误做法：先把正交多项式展开成单项式系数，再调用一般多项式求根器。

问题：高次单项式系数可能严重病态，且会丢失实对称结构。

正确做法：利用三项递推形成 Jacobi 矩阵，再解对称三对角特征值问题。

### 4.2.3 常用 Gauss 求积族

| 名称                 | 区间与权函数                                                     | 正交多项式/节点                                   | 备注                                                      |
|--------------------|------------------------------------------------------------|--------------------------------------------|---------------------------------------------------------|
| Gauss-Legendre     | $[-1, 1], \rho(x) = 1$                                     | Legendre 多项式零点                             | 普通有限区间无权积分。                                             |
| Gauss-Chebyshev I  | $[-1, 1], \rho(x) = (1 - x^2)^{-1/2}$                      | $T_N$ 零点 $x_j = \cos \frac{(2j-1)\pi}{2N}$ | 权重全为 $\pi/N$ 。                                          |
| Gauss-Chebyshev II | $[-1, 1], \rho(x) = \sqrt{1 - x^2}$                        | $U_N$ 零点 $x_j = \cos \frac{j\pi}{N+1}$     | $\lambda_j = \frac{\pi}{N+1} \sin^2 \frac{j\pi}{N+1}$ 。 |
| Gauss-Jacobi       | $[-1, 1], (1 - x)^\alpha(1 + x)^\beta, \alpha, \beta > -1$ | Jacobi 多项式零点                               | 包含 Legendre 和两类 Chebyshev。                              |
| Gauss-Laguerre     | $[0, \infty), x^\alpha e^{-x}, \alpha > -1$                | 广义 Laguerre 零点                             | 适合指数衰减半无穷积分。                                            |
| Gauss-Hermite      | $(-\infty, \infty), e^{-x^2}$                              | Hermite 多项式零点                              | 适合高斯权积分。                                                |

#### 易错点与反例

权函数必须保持在积分定义中。例如 Gauss-Hermite 近似的是  $\int_{-\infty}^{\infty} f(x)e^{-x^2} dx$ ，不是无权积分  $\int_{-\infty}^{\infty} f(x) dx$ 。若要处理后者，必须把  $e^{x^2}$  吸收到被积函数中，并重新检查其增长与数值稳定性。

#### 基础例题：二点 Gauss-Legendre 公式

求  $[-1, 1]$  上的二点 Gauss-Legendre 公式。

标准 Legendre 多项式  $L_2(x) = \frac{1}{2}(3x^2 - 1)$  的零点为  $x_{1,2} = \pm \frac{1}{\sqrt{3}}$ 。由对称性两权重相同，记为  $\lambda$ 。对常数精确要求  $2\lambda = 2$ ，故  $\lambda = 1$ 。因此

$$\int_{-1}^1 f(x) dx \approx f\left(-\frac{1}{\sqrt{3}}\right) + f\left(\frac{1}{\sqrt{3}}\right). \quad (4.23)$$

该公式对  $\mathbb{P}_3$  精确。



二点 Gauss-Legendre 误差为

$$\int_{-1}^1 f(x) dx - G_2(f) = \frac{1}{135} f^{(4)}(\xi), \quad \xi \in (-1, 1). \quad (4.24)$$

例如对  $f(x) = x^4$ ,  $I(f) = \frac{2}{5}$ ,  $G_2(f) = 2 \left(\frac{1}{\sqrt{3}}\right)^4 = \frac{2}{9}$ , 故  $I(f) - G_2(f) = \frac{8}{45}$ 。又  $f^{(4)} = 24$ ,  $\frac{24}{135} = \frac{8}{45}$ , 与误差公式一致。

### 4.3 补充训练题：丘赛 2023 Problem 2——对数权 Gauss 求积与 Jacobi 矩阵

完整题目叙述

在  $[0, 1]$  上考虑加权积分

$$I[f] = \int_0^1 f(x) \log(1/x) dx. \quad (4.25)$$

令  $P_n$  为关于内积  $\langle f, g \rangle = \int_0^1 f(x)g(x) \log(1/x) dx$  的一族首一正交多项式。

- (a) 设  $P_0 = 1$ 。求  $P_1(x)$ , 以及一节点 Gauss 求积的节点  $x_1^1$  和权重  $\omega_1^1$ 。
- (b) 推导用  $P_n, P_{n-1}$  表示  $P_{n+1}$  的三项递推。
- (c) 令  $Q_n(x) = \frac{P_n(x)}{\|P_n\|}$ ,  $\|P_n\|^2 = \int_0^1 P_n(x)^2 \log(1/x) dx$ . 推导  $Q_{n+1}$  关于  $Q_n, Q_{n-1}$  的递推。
- (d) 证明  $x = \lambda$  为四节点 Gauss 求积节点, 当且仅当  $\lambda$  是某个实对称三对角矩阵的特征值, 并显式写出该矩阵。

第 (a) 问详细解答. 首先计算矩:

$$\mu_k = \int_0^1 x^k \log(1/x) dx = \frac{1}{(k+1)^2}. \quad (4.26)$$

证明可由  $\int_0^1 x^k dx = \frac{1}{k+1}$  对参数  $k$  求导得到:  $\int_0^1 x^k \log x dx = -\frac{1}{(k+1)^2}$ 。

设  $P_1(x) = x - \alpha_0$ 。由  $P_1 \perp P_0$ ,  $0 = \langle 1, P_1 \rangle = \mu_1 - \alpha_0 \mu_0$ 。因为  $\mu_0 = 1$ ,  $\mu_1 = \frac{1}{4}$ , 故

$$P_1(x) = x - \frac{1}{4}. \quad (4.27)$$

一节点 Gauss 节点是  $P_1$  的零点:  $x_1^1 = \frac{1}{4}$ 。一节点公式  $I[f] \approx \omega_1^1 f(1/4)$  对常数精确, 故  $\omega_1^1 = I[1] = \mu_0 = 1$ 。因此

$$I[f] \approx f(1/4) \quad (4.28)$$

对所有一次多项式精确。□

第 (b) 问详细解答. 记  $h_n = \|P_n\|^2$ 。由于  $P_n$  首一,  $xP_n - P_{n+1} \in \mathbb{P}_n$ 。在正交基  $P_0, \dots, P_n$  中展开:  $xP_n - P_{n+1} = \sum_{k=0}^n c_{n,k} P_k$ 。当  $k \leq n-2$  时,  $\langle P_k, xP_n \rangle = \langle xP_k, P_n \rangle = 0$ , 因为  $xP_k \in \mathbb{P}_{n-1}$ 。因此只剩  $P_n$  与  $P_{n-1}$ :  $xP_n - P_{n+1} = \alpha_n P_n + \beta_n P_{n-1}$ 。即

$$P_{n+1}(x) = (x - \alpha_n)P_n(x) - \beta_n P_{n-1}(x), \quad (4.29)$$

其中

$$\alpha_n = \frac{\langle P_n, xP_n \rangle}{h_n}, \quad (4.30)$$

$$\beta_n = \frac{h_n}{h_{n-1}} > 0, \quad n \geq 1. \quad (4.31)$$

初值取  $P_{-1} = 0$ ,  $P_0 = 1$ 。 □

第 (c) 问详细解答. 将  $P_n = \sqrt{h_n}Q_n$  代入式 (4.29):  $\sqrt{h_{n+1}}Q_{n+1} = (x - \alpha_n)\sqrt{h_n}Q_n - \beta_n\sqrt{h_{n-1}}Q_{n-1}$ 。因为  $\beta_n = \frac{h_n}{h_{n-1}}$ , 有  $\beta_n \frac{\sqrt{h_{n-1}}}{\sqrt{h_n}} = \sqrt{\beta_n}$ 。又定义  $\beta_{n+1} = \frac{h_{n+1}}{h_n}$ 。故

$$xQ_n = \sqrt{\beta_{n+1}}Q_{n+1} + \alpha_nQ_n + \sqrt{\beta_n}Q_{n-1}. \quad (4.32)$$

等价地,

$$Q_{n+1} = \frac{(x - \alpha_n)Q_n - \sqrt{\beta_n}Q_{n-1}}{\sqrt{\beta_{n+1}}}. \quad (4.33)$$

□

第 (d) 问详细解答. 由式 (4.32), 四节点 Gauss 节点为  $Q_4$  的零点, 也就是  $4 \times 4$  Jacobi 矩阵

$$J_4 = \begin{pmatrix} \alpha_0 & \sqrt{\beta_1} & 0 & 0 \\ \sqrt{\beta_1} & \alpha_1 & \sqrt{\beta_2} & 0 \\ 0 & \sqrt{\beta_2} & \alpha_2 & \sqrt{\beta_3} \\ 0 & 0 & \sqrt{\beta_3} & \alpha_3 \end{pmatrix} \quad (4.34)$$

的特征值。

下面由矩式 (4.26) 显式计算系数。首先  $h_0 = 1$ ,  $\alpha_0 = \frac{1}{4}$ 。由  $P_1 = x - \frac{1}{4}$  得到

$$\begin{aligned} h_1 &= \mu_2 - \frac{1}{2}\mu_1 + \frac{1}{16}\mu_0 \\ &= \frac{1}{9} - \frac{1}{8} + \frac{1}{16} = \frac{7}{144}. \end{aligned}$$

故  $\beta_1 = \frac{7}{144}$ ,  $\sqrt{\beta_1} = \frac{\sqrt{7}}{12}$ 。

又

$$\begin{aligned} \langle P_1, xP_1 \rangle &= \mu_3 - \frac{1}{2}\mu_2 + \frac{1}{16}\mu_1 \\ &= \frac{1}{16} - \frac{1}{18} + \frac{1}{64} = \frac{13}{576}, \end{aligned}$$

所以  $\alpha_1 = \frac{13/576}{7/144} = \frac{13}{28}$ 。由递推得到


$$P_2(x) = x^2 - \frac{5}{7}x + \frac{17}{252}, \quad h_2 = \frac{647}{226800}. \quad (4.35)$$

因此  $\beta_2 = \frac{h_2}{h_1} = \frac{647}{11025}$ ,  $\alpha_2 = \frac{8795}{18116}$ 。继续递推,

$$P_3(x) = x^3 - \frac{3105}{2588}x^2 + \frac{5751}{16175}x - \frac{4679}{258800}, \quad (4.36)$$

并有

$$h_3 = \frac{878769}{5072480000}, \quad \beta_3 = \frac{71180289}{1172105200}, \quad \alpha_3 = \frac{124351943}{252694908}. \quad (4.37)$$



故所求显式矩阵为

$$J_4 = \begin{pmatrix} \frac{1}{4} & \sqrt{\frac{7}{144}} & 0 & 0 \\ \sqrt{\frac{7}{144}} & \frac{13}{28} & \sqrt{\frac{647}{11025}} & 0 \\ 0 & \sqrt{\frac{647}{11025}} & \frac{8795}{18116} & \sqrt{\frac{71180289}{1172105200}} \\ 0 & 0 & \sqrt{\frac{71180289}{1172105200}} & \frac{124351943}{252694908} \end{pmatrix}. \quad (4.38)$$

更严格地, 令  $\mathbf{Q}_4(x) = (Q_0(x), Q_1(x), Q_2(x), Q_3(x))^T$ . 递推给出  $x\mathbf{Q}_4(x) = J_4\mathbf{Q}_4(x) + \sqrt{\beta_4}Q_4(x)\mathbf{e}_4$ . 因此  $Q_4(\lambda) = 0 \iff J_4\mathbf{Q}_4(\lambda) = \lambda\mathbf{Q}_4(\lambda)$ . 由于  $Q_4$  有四个互异实零点, 而  $J_4$  有四个实特征值, 二者完全一致。

数值上, 四个节点约为

$$0.04144848, \quad 0.24527491, \quad 0.55616545, \quad 0.84898239. \quad (4.39)$$

由 Golub-Welsch 公式, 权重约为

$$0.38346407, \quad 0.38687532, \quad 0.19043513, \quad 0.03922549, \quad (4.40)$$

其和为  $\mu_0 = 1$ . □

注 4.7. 这道题第 4 问算出来真的就是 4.38 这么个数字, 我强烈不建议你尝试。

#### 易错点与反例

错误说法: Jacobi 矩阵的次对角元是  $\beta_n$ .

正确形式: 对首一递推, 系数为  $\beta_n$ ; 对标准正交递推及对称 Jacobi 矩阵, 次对角元必须是  $\sqrt{\beta_n}$ .

## 4.4 正式真题 [25F-Q2(d)]——Gauss-Chebyshev 求积

### 完整题目叙述

[25F-Q2] 前 (a)–(c) 问已在第 01 部分完成。本节完整解答第 (d) 问:

对  $f \in C^{2n+2}[-1, 1]$ , 推导  $n+1$  节点 Gauss 求积公式

$$I(f) = \int_{-1}^1 \frac{f(x)}{\sqrt{1-x^2}} dx \approx I_{n+1}(f), \quad (4.41)$$

并证明

$$|I(f) - I_{n+1}(f)| \leq \frac{\pi \|f^{(2n+2)}\|_{\infty}}{(2n+2)!2^{2n+1}}. \quad (4.42)$$

详细解答. 令  $N = n+1$ . 关于权函数  $\rho(x) = \frac{1}{\sqrt{1-x^2}}$  的  $N$  次正交多项式是第一类 Chebyshev 多项式  $T_N(x) = \cos(N \arccos x)$ . 其  $N$  个零点为

$$x_j = \cos \frac{(2j-1)\pi}{2N}, \quad j = 1, \dots, N. \quad (4.43)$$

作变量代换  $x = \cos \theta$ ,  $0 \leq \theta \leq \pi$ . 因为  $dx = -\sin \theta d\theta$ ,  $\sqrt{1-x^2} = \sin \theta$ , 所以

$$I(f) = \int_0^\pi f(\cos \theta) d\theta. \quad (4.44)$$

Gauss-Chebyshev 公式为

$$I_{n+1}(f) = \frac{\pi}{n+1} \sum_{j=1}^{n+1} f\left(\cos \frac{(2j-1)\pi}{2n+2}\right). \quad (4.45)$$

下面验证其代数精度。由于  $T_k(\cos \theta) = \cos(k\theta)$ , 有  $I(T_0) = \pi$ ,  $I(T_k) = 0$ ,  $k \geq 1$ . 对  $1 \leq k \leq 2N-1$ , 离散余弦和满足

$$\sum_{j=1}^N \cos\left(\frac{k(2j-1)\pi}{2N}\right) = 0. \quad (4.46)$$

因此公式对  $T_0, T_1, \dots, T_{2N-1}$  全部精确。由于这些多项式构成  $\mathbb{P}_{2N-1}$  的一组基, 公式的代数精度为  $2N-1 = 2n+1$ 。

再证明误差界。 $T_N$  的首项系数为  $2^{N-1}$ , 故首一正交多项式为

$$\pi_N(x) = 2^{1-N} T_N(x) = 2^{-n} T_{n+1}(x). \quad (4.47)$$

利用 Chebyshev 正交性,

$$\int_{-1}^1 \frac{T_N(x)^2}{\sqrt{1-x^2}} dx = \frac{\pi}{2}, \quad N \geq 1. \quad (4.48)$$

因此

$$\begin{aligned} h_N &= \int_{-1}^1 \frac{\pi_N(x)^2}{\sqrt{1-x^2}} dx \\ &= 2^{2-2N} \frac{\pi}{2} = \frac{\pi}{2^{2N-1}} = \frac{\pi}{2^{2n+1}}. \end{aligned} \quad (4.49)$$

由 Gauss 误差公式 (4.12), 存在  $\xi \in (-1, 1)$  使

$$I(f) - I_{n+1}(f) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \frac{\pi}{2^{2n+1}}. \quad (4.50)$$

取绝对值得  $|I(f) - I_{n+1}(f)| \leq \frac{\pi \|f^{(2n+2)}\|_\infty}{(2n+2)! 2^{2n+1}}$ , 即为所证。□

#### 易错点与反例

**Gauss-Chebyshev** 与 **Clenshaw-Curtis** 不是同一公式。

Gauss-Chebyshev I:  $\int_{-1}^1 \frac{f(x)}{\sqrt{1-x^2}} dx$ , 节点是  $T_N$  零点, 不含端点, 权重相等。

Clenshaw-Curtis:  $\int_{-1}^1 f(x) dx$ , 节点通常为  $T_N$  极值点, 包含端点, 权重不相等。

## 4.5 正式真题 [26S-Q2(d)]——Gauss-Legendre 求积

### 完整题目叙述

[26S-Q2] 前 (a)-(c) 问已在第 02 部分处理。第 (d) 问要求:

设  $f \in C^{2n+2}[-1, 1]$ , 使用  $n+1$  个节点推导

$$I(f) = \int_{-1}^1 f(x) dx \approx I_{n+1}(f) \quad (4.51)$$

的 Gauss-Legendre 公式, 并估计  $|I(f) - I_{n+1}(f)|$ 。题设中的  $P_k$  为  $k$  次首一 Legendre 多项式,  $P_k(x) = \frac{L_k(x)}{a_k}$ ,  $a_k = \frac{(2k)!}{2^k(k!)^2}$ , 其中  $L_k(1) = 1$  为标准 Legendre 多项式。

详细解答. 令  $N = n + 1$ 。取  $x_1, \dots, x_N$  为  $P_N$ , 等价地为  $L_N$  的  $N$  个零点。定义 Lagrange 基函数  $\ell_j(x) = \prod_{\substack{1 \leq k \leq N \\ k \neq j}} \frac{x - x_k}{x_j - x_k}$ 。Gauss-Legendre 公式为

$$I_N(f) = \sum_{j=1}^N w_j f(x_j), \quad w_j = \int_{-1}^1 \ell_j(x) dx. \quad (4.52)$$

由一般 Gauss 理论, 公式对  $\mathbb{P}_{2N-1}$  精确, 即在本题记号下对  $\mathbb{P}_{2n+1}$  精确。

下面推导显式权重。首一公式式 (4.10) 给出  $w_j = \frac{\|P_{N-1}\|_2^2}{P'_N(x_j)P_{N-1}(x_j)}$ 。由第 02 部分的 Legendre 范数,  $\|P_{N-1}\|_2^2 = \frac{2}{(2N-1)a_{N-1}^2}$ 。又  $P'_N = \frac{L'_N}{a_N}$ ,  $P_{N-1} = \frac{L_{N-1}}{a_{N-1}}$ , 且  $\frac{a_N}{a_{N-1}} = \frac{2N-1}{N}$ 。故

$$w_j = \frac{2}{N L'_N(x_j) L_{N-1}(x_j)}. \quad (4.53)$$

Legendre 恒等式

$$(1-x^2)L'_N(x) = N(L_{N-1}(x) - xL_N(x)) \quad (4.54)$$

在  $x = x_j$  处化为  $L_{N-1}(x_j) = \frac{1-x_j^2}{N} L'_N(x_j)$ 。代入式 (4.53), 得到标准公式

$$w_j = \frac{2}{(1-x_j^2)[L'_N(x_j)]^2} > 0. \quad (4.55)$$

在原题  $n$  的记号中,

$$I_{n+1}(f) = \sum_{j=1}^{n+1} \frac{2f(x_j)}{(1-x_j^2)[L'_{n+1}(x_j)]^2}, \quad L_{n+1}(x_j) = 0. \quad (4.56)$$

下面估计误差。 $P_N$  为首一正交多项式, 因此  $\|P_N\|_2^2 = \frac{2}{(2N+1)a_N^2}$ 。由一般 Gauss 误差公式, 存在  $\xi \in (-1, 1)$  使

$$I(f) - I_N(f) = \frac{f^{(2N)}(\xi)}{(2N)!} \frac{2}{(2N+1)a_N^2}. \quad (4.57)$$

取  $N = n + 1$ :

$$I(f) - I_{n+1}(f) = \frac{2f^{(2n+2)}(\xi)}{(2n+3)a_{n+1}^2(2n+2)!}. \quad (4.58)$$


因此

$$|I(f) - I_{n+1}(f)| \leq \frac{2 \|f^{(2n+2)}\|_\infty}{(2n+3)a_{n+1}^2(2n+2)!}. \quad (4.59)$$

代入  $a_{n+1} = \frac{(2n+2)!}{2^{n+1}((n+1)!)^2}$ , 可得等价形式

$$|I(f) - I_{n+1}(f)| \leq \frac{2^{2n+3}((n+1)!)^4}{(2n+3)[(2n+2)!]^3} \|f^{(2n+2)}\|_\infty. \quad (4.60)$$

□



## 易错点与反例

错误说法:  $n+1$  节点 Gauss 公式的代数精度为  $2n+2$ 。

正确结论:  $2(n+1)-1=2n+1$ 。误差中出现的是下一阶偶数导数  $f^{(2n+2)}$ 。

## 4.6 补充训练题: 丘赛 2024 Problem 3——第二类 Chebyshev 与二点 Gauss 求积

## 完整题目叙述

第一类 Chebyshev 多项式定义为  $T_n(x) = \cos(n\theta)$ ,  $x = \cos \theta$ ,  $x \in [-1, 1]$ 。第二类 Chebyshev 多项式按标准记号定义为

$$U_n(x) = \frac{1}{n+1} T'_{n+1}(x), \quad n \geq 0. \quad (4.61)$$

(a) 推导计算  $U_n(x)$  的递推公式。

(b) 证明  $U_n$  关于内积  $\langle f, g \rangle = \int_{-1}^1 f(x)g(x)\sqrt{1-x^2} dx$  正交。

(c) 推导积分  $\int_{-1}^1 f(x)\sqrt{1-x^2} dx \approx \sum_{j=1}^2 w_j f(x_j)$  的二节点 Gauss 公式。

第 (a) 问详细解答. 由  $T_{n+1}(\cos \theta) = \cos((n+1)\theta)$  及链式法则,

$$\begin{aligned} T'_{n+1}(\cos \theta) &= \frac{-(n+1)\sin((n+1)\theta)}{-\sin \theta} \\ &= (n+1) \frac{\sin((n+1)\theta)}{\sin \theta}. \end{aligned} \quad (4.62)$$

因此

$$U_n(\cos \theta) = \frac{\sin((n+1)\theta)}{\sin \theta}. \quad (4.63)$$

利用正弦递推  $\sin((n+2)\theta) = 2\cos \theta \sin((n+1)\theta) - \sin(n\theta)$ , 除以  $\sin \theta$ , 得到

$$U_{n+1}(x) = 2xU_n(x) - U_{n-1}(x), \quad U_0(x) = 1, \quad U_1(x) = 2x. \quad (4.64)$$

□

第 (b) 问详细解答. 作变量代换  $x = \cos \theta$ ,  $0 \leq \theta \leq \pi$ . 则  $dx = -\sin \theta d\theta$ ,  $\sqrt{1-x^2} = \sin \theta$ . 由式 (4.63),

$$\begin{aligned} \int_{-1}^1 U_m(x)U_n(x)\sqrt{1-x^2} dx &= \int_0^\pi \frac{\sin((m+1)\theta)\sin((n+1)\theta)}{\sin^2 \theta} \sin^2 \theta d\theta \\ &= \int_0^\pi \sin((m+1)\theta)\sin((n+1)\theta) d\theta. \end{aligned} \quad (4.65)$$


由正弦函数正交性,

$$\int_{-1}^1 U_m(x)U_n(x)\sqrt{1-x^2} dx = \frac{\pi}{2} \delta_{mn}. \quad (4.66)$$

□

第 (c) 问详细解答. 二节点 Gauss 公式的节点是  $U_2$  的两个零点. 由递推,  $U_2(x) = 4x^2 - 1$ , 故

$$x_1 = -\frac{1}{2}, \quad x_2 = \frac{1}{2}. \quad (4.67)$$





权函数与节点关于原点对称, 故  $w_1 = w_2 =: w$ 。对常数精确:  $2w = \int_{-1}^1 \sqrt{1-x^2} dx = \frac{\pi}{2}$ , 故  $w = \frac{\pi}{4}$ 。因此

$$\int_{-1}^1 f(x) \sqrt{1-x^2} dx \approx \frac{\pi}{4} \left[ f\left(-\frac{1}{2}\right) + f\left(\frac{1}{2}\right) \right]. \quad (4.68)$$

该公式对  $\mathbb{P}_3$  精确。

作为误差扩展, 首一正交多项式为  $\pi_2(x) = \frac{1}{4}U_2(x) = x^2 - \frac{1}{4}$ 。由式 (4.66),  $\int_{-1}^1 \pi_2(x)^2 \sqrt{1-x^2} dx = \frac{1}{16} \frac{\pi}{2} = \frac{\pi}{32}$ 。故若  $f \in C^4[-1, 1]$ , 存在  $\xi \in (-1, 1)$  使

$$I(f) - G_2(f) = \frac{\pi}{768} f^{(4)}(\xi). \quad (4.69)$$

□

## 4.7 Clenshaw-Curtis 求积

### 4.7.1 知识点五: 定义、节点与 Chebyshev 系数积分

【重要性等级】 **A 级**。培训资料将 Clenshaw-Curtis 列为必须理解基本思想的进阶内容; 它与 Chebyshev 插值、DCT、FFT 和谱方法构成统一结构。

【问题与目标】 使用 Chebyshev-Lobatto 节点

$$x_j = \cos \frac{j\pi}{N}, \quad j = 0, \dots, N, \quad (4.70)$$

构造无权积分  $I(f) = \int_{-1}^1 f(x) dx$  的插值型求积公式。

注意节点次序  $x_0 = 1, x_N = -1$  为递减; 若实现中改为递增, 只改变数据排列, 不改变公式。

令  $p_N$  为这些节点上的 Chebyshev 插值多项式:

$$p_N(x) = \sum_{k=0}^N c_k T_k(x), \quad (4.71)$$

其中  $c_k$  表示实际多项式系数, 不采用端点半权缩写。

由

$$\int_{-1}^1 T_k(x) dx = \begin{cases} 0, & k \text{ 为奇数,} \\ \frac{2}{1-k^2}, & k \text{ 为偶数,} \end{cases} \quad (4.72)$$

得到

$$I_N^{\text{CC}}(f) = \int_{-1}^1 p_N(x) dx = \sum_{\substack{0 \leq k \leq N \\ k \text{ 偶}}} \frac{2c_k}{1-k^2}. \quad (4.73)$$

【推导来源】 令  $x = \cos \theta$ ,  $F(\theta) = f(\cos \theta)$ 。Chebyshev 插值等价于在  $\theta_j = \frac{j\pi}{N}$  上对偶周期函数  $F$  作余弦插值。函数值到  $c_k$  的变换就是 DCT-I, 可通过偶延拓后调用 FFT 实现。

---

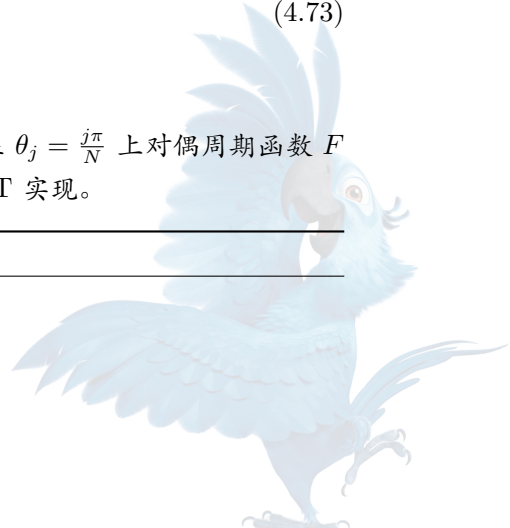
**Algorithm 12** 基于 DCT 的 Clenshaw-Curtis 求积

---

**Input:** 函数  $f$ 、阶数  $N$

**Output:**  $I_N^{\text{CC}}(f)$

1: **Initialization:**  $x_j \leftarrow \cos(j\pi/N)$ ,  $f_j \leftarrow f(x_j)$ ,  $j = 0, \dots, N$



- 2: 对  $\{f_j\}$  作正确归一化的 DCT-I, 得到实际 Chebyshev 系数  $c_0, \dots, c_N$
- 3:  $I \leftarrow \sum_{\substack{0 \leq k \leq N \\ k \text{ even}}} \frac{2c_k}{1-k^2}$
- 4: **Stopping criterion:** 返回  $I$
- 5: **Complexity:** 节点与函数采样  $O(N)$ ; DCT/FFT 为  $O(N \log N)$ ; 存储  $O(N)$

#### 易错点与反例

不同软件的 DCT-I 归一化不同。必须先确认展开采用  $p_N = \sum_{k=0}^N c_k T_k$  还是端点系数减半的撇号约定。若归一化不一致,  $c_0, c_N$  将相差 2 倍。

### 4.7.2 Clenshaw-Curtis 显式权重

Clenshaw-Curtis 公式也可写为

$$I_N^{\text{CC}}(f) = \sum_{j=0}^N w_j f(x_j). \quad (4.74)$$

$$\text{令 } d_j = \begin{cases} 2, & j = 0, N, \\ 1, & 1 \leq j \leq N-1. \end{cases}$$

若  $N$  为奇数,

$$w_j = \frac{2}{Nd_j} \left[ 1 - \sum_{k=1}^{(N-1)/2} \frac{2 \cos(2kj\pi/N)}{4k^2 - 1} \right]. \quad (4.75)$$

若  $N$  为偶数,

$$w_j = \frac{2}{Nd_j} \left[ 1 - \sum_{k=1}^{N/2-1} \frac{2 \cos(2kj\pi/N)}{4k^2 - 1} - \frac{\cos(j\pi)}{N^2 - 1} \right]. \quad (4.76)$$

权重可借助 FFT 在  $O(N \log N)$  时间内生成, 并且全部为正。

**【代数精度】** 因为它是  $N$  次插值型公式, 至少对  $\mathbb{P}_N$  精确。进一步由对称性,

$$\text{DOP} = \begin{cases} N, & N \text{ 为奇数}, \\ N+1, & N \text{ 为偶数}. \end{cases} \quad (4.77)$$

这远低于同样  $N+1$  个节点的 Gauss-Legendre 精度  $2N+1$ , 但实际函数积分误差往往没有代数精度差距所暗示的那么大。


**【稳定性与条件数】** Clenshaw-Curtis 权重为正, 且  $\sum_{j=0}^N w_j = 2$ 。因此  $|I_N^{\text{CC}}(f)| \leq 2 \max_j |f(x_j)|$ 。当  $N$  翻倍时, 旧节点嵌入新节点:  $\{\cos \frac{j\pi}{N}\}_{j=0}^N \subset \{\cos \frac{j\pi}{2N}\}_{j=0}^{2N}$ 。这种嵌套性有利于自适应加密和函数值复用。

### 4.7.3 收敛性与 Gauss-Legendre 比较

若  $f$  可解析延拓到 Bernstein 椭圆  $E_\rho$ ,  $\rho > 1$ , 并满足  $|f(z)| \leq M$ ,  $z \in E_\rho$ , 则存在只依赖  $\rho$  的常数  $C_\rho$  使

$$|I(f) - I_N^{\text{CC}}(f)| \leq C_\rho M \rho^{-N}, \quad (4.78)$$

$$|I(f) - G_{N+1}^{\text{GL}}(f)| \leq \tilde{C}_\rho M \rho^{-2N}. \quad (4.79)$$



培训讲义给出的一组具体充分界为

$$|I - I_N^{\text{CC}}| \leq \frac{64}{15} \frac{M \rho^{1-N}}{\rho^2 - 1}, \quad (4.80)$$

$$|I - G_{N+1}^{\text{GL}}| \leq \frac{64}{15} \frac{M \rho^{-2N}}{\rho^2 - 1}. \quad (4.81)$$

对于仅具有有限光滑性的函数，两者均表现为由 Chebyshev 或 Legendre 系数衰减决定的代数收敛。实际计算中，Clenshaw–Curtis 与 Gauss–Legendre 通常具有相近的误差量级；代数精度不是评价非多项式积分效果的唯一标准。

| 比较项          | Gauss–Legendre           | Clenshaw–Curtis           |
|--------------|--------------------------|---------------------------|
| 节点           | Legendre 零点，不含端点         | Chebyshev–Lobatto 极值点，含端点 |
| $N+1$ 节点 DOP | $2N+1$                   | 一般 $N$ 或 $N+1$            |
| 权重           | 正                        | 正                         |
| 嵌套性          | 一般不嵌套                    | $N \rightarrow 2N$ 时嵌套    |
| 节点生成         | Jacobi 矩阵、Newton 或快速特殊算法 | 显式余弦节点                    |
| 权重生成         | 通常 $O(N^2)$ ；特殊算法更快      | FFT/DCT, $O(N \log N)$    |
| 端点函数值        | 不需要                      | 需要                        |
| 端点奇异性        | 可避免直接采样端点                | 需先消奇或改用 Fejér 型节点         |
| 解析函数         | 几何收敛                     | 几何收敛                      |

基础例题： $N=2$  的 Clenshaw–Curtis 就是 Simpson 公式

节点为  $x_0 = 1$ ,  $x_1 = 0$ ,  $x_2 = -1$ 。由式 (4.76),  $w_0 = w_2 = \frac{1}{3}$ ,  $w_1 = \frac{4}{3}$ 。故

$$I_2^{\text{CC}}(f) = \frac{1}{3} [f(-1) + 4f(0) + f(1)]. \quad (4.82)$$

这正是区间  $[-1, 1]$  上的 Simpson 公式。

## 4.8 自适应求积与局部误差控制

### 4.8.1 知识点六：局部细分与容差分配

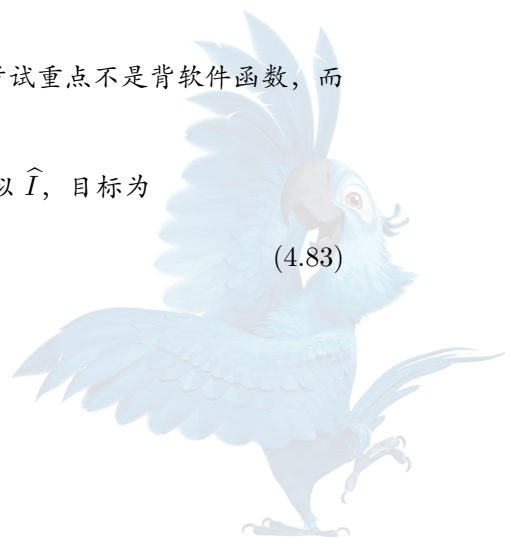
【重要性等级】 **A 级**。培训资料将自适应求积列为进阶必需思想。考试重点不是背软件函数，而是写清误差估计、区间细分、局部容差和失败情形。

【问题与目标】 对  $I = \int_a^b f(x) dx$  给定  $\text{atol} > 0$ ,  $\text{rtol} \geq 0$ , 构造近似  $\hat{I}$ , 目标为

$$|I - \hat{I}| \lesssim \text{atol} + \text{rtol} |I|. \quad (4.83)$$

由于  $I$  未知，实际停止准则以  $|\hat{I}|$  或累计尺度估计代替。

【核心机制】



1. 在当前区间计算低成本粗近似  $Q_c$ ;
2. 通过更高阶规则或区间二分得到细近似  $Q_f$ ;
3. 由  $Q_f - Q_c$  估计局部误差;
4. 若误差过大, 则细分区间;
5. 将父区间容差分配给子区间;
6. 累加所有已接受面板的近似和误差预算。

#### 4.8.2 自适应 Simpson 的误差估计

设单面板 Simpson 误差具有渐近形式  $I_{[a,b]} - S_{[a,b]} = C(b-a)^5 + O((b-a)^6)$ 。令  $m = (a+b)/2$ ,  $S_c = S_{[a,b]}$ ,  $S_f = S_{[a,m]} + S_{[m,b]}$ 。若主误差系数在局部近似不变, 则  $I - S_f \approx \frac{1}{16}(I - S_c)$ 。因此  $S_f - S_c \approx \frac{15}{16}(I - S_c)$ , 从而细网格误差估计为

$$I - S_f \approx \frac{S_f - S_c}{15}. \quad (4.84)$$

Richardson 修正值为

$$S_{\text{corr}} = S_f + \frac{S_f - S_c}{15}. \quad (4.85)$$

#### 4.8.3 Gauss-Kronrod 误差对

$N$  点 Gauss 公式可扩展为包含原 Gauss 节点的  $(2N+1)$  点 Kronrod 公式:  $G_N(f)$ ,  $K_{2N+1}(f)$ 。因为两套公式共享节点, 计算  $K_{2N+1}$  时可复用全部 Gauss 函数值。常用误差指示为  $\eta = |K_{2N+1}(f) - G_N(f)|$ 。该差不是严格误差上界, 但通常比两个非嵌套公式更经济、可靠。

##### 【稳定性与失败情形】

自适应求积可能失败或给出过度乐观误差估计的典型情况:

1. 窄尖峰未被采样: 所有采样点恰好避开尖峰;
2. 间断点或奇异点未知: 误差展开不成立;
3. 强振荡: 粗细规则同时发生混叠, 差值很小但真实误差大;
4. 积分接近零: 纯相对容差失去意义, 必须设置绝对容差;
5. 不可积奇异: 无限细分也不能收敛;
6. 机器舍入主导: 继续细分导致节点重合和消去;
7. 高成本函数: 递归中若不缓存共享节点, 会重复计算;
8. 最大递归深度: 必须报告未达到容差, 而不能静默返回。

##### 综合例题: 自适应 Simpson 误差估计对 $x^4$ 恰好准确

计算  $I = \int_0^1 x^4 dx = \frac{1}{5}$ 。粗 Simpson 公式为  $S_c = \frac{1}{6} \left[ 0 + 4 \left( \frac{1}{2} \right)^4 + 1 \right] = \frac{5}{24}$ 。将区间二分后,  $S_f = S_{[0,1/2]} + S_{[1/2,1]} = \frac{77}{384}$ 。两者之差为  $D = S_f - S_c = -\frac{1}{128}$ 。细网格误差估计为  $\frac{D}{15} = -\frac{1}{1920}$ 。真实细网格误差恰为  $I - S_f = \frac{1}{5} - \frac{77}{384} = -\frac{1}{1920}$ 。因此 Richardson 修正  $S_f + \frac{D}{15} = \frac{1}{5}$  对四次多项式精确。

## 4.9 弱奇异、近奇异与振荡积分

### 4.9.1 知识点七：弱奇异积分的分类

考虑端点弱奇异积分

$$I = \int_a^b \frac{\phi(x)}{(x-a)^\mu} dx, \quad 0 \leq \mu < 1, \quad (4.86)$$

其中  $\phi$  在  $a$  附近光滑。因为  $\mu < 1$ ，该奇异性可积；但普通高阶求积依赖的导数有界性失效，收敛阶会显著下降。

常见处理方法如下。

### 4.9.2 方法一：幂次变量代换

令

$$x = a + (b-a)t^q, \quad 0 \leq t \leq 1, \quad q > 0. \quad (4.87)$$

则  $dx = q(b-a)t^{q-1} dt$  且  $(x-a)^{-\mu} = (b-a)^{-\mu} t^{-q\mu}$ 。因此

$$I = q(b-a)^{1-\mu} \int_0^1 \phi(a + (b-a)t^q) t^{q(1-\mu)-1} dt. \quad (4.88)$$

若取  $q = \frac{1}{1-\mu}$ ，则幂指数为零，显式代数奇异性被消除。若该  $q$  不是整数，仍需检查复合函数在  $t=0$  的可微性。

### 4.9.3 方法二：加权 Gauss–Jacobi 求积

作仿射变换  $x = \frac{a+b}{2} + \frac{b-a}{2}t$ 。若积分含  $(x-a)^\beta(b-x)^\alpha$ ， $\alpha, \beta > -1$ ，则

$$\begin{aligned} & \int_a^b (b-x)^\alpha (x-a)^\beta \phi(x) dx \\ &= \left(\frac{b-a}{2}\right)^{\alpha+\beta+1} \int_{-1}^1 (1-t)^\alpha (1+t)^\beta \tilde{\phi}(t) dt. \end{aligned} \quad (4.89)$$

可直接使用 Gauss–Jacobi 公式，而不是把奇异权吸收到函数后再使用普通 Gauss–Legendre。

### 4.9.4 方法三：奇异项减除

设  $\phi$  在  $a$  处有 Taylor 多项式  $\Phi_p(x) = \sum_{k=0}^{p-1} \frac{\phi^{(k)}(a)}{k!} (x-a)^k$ 。分解

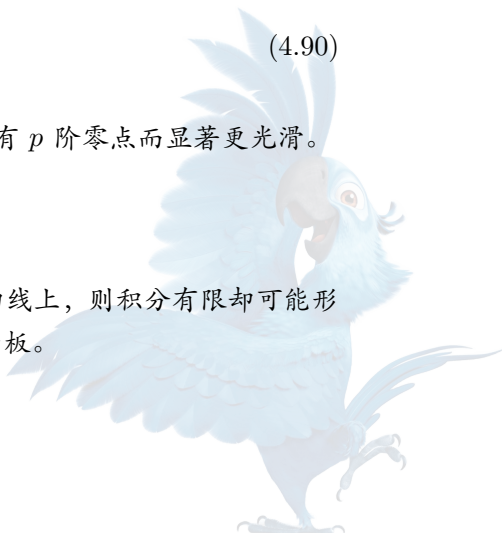
$$\begin{aligned} I &= \int_a^b \frac{\phi(x) - \Phi_p(x)}{(x-a)^\mu} dx \\ &+ \sum_{k=0}^{p-1} \frac{\phi^{(k)}(a)}{k!} \int_a^b (x-a)^{k-\mu} dx. \end{aligned} \quad (4.90)$$

第二部分可精确积分： $\int_a^b (x-a)^{k-\mu} dx = \frac{(b-a)^{k+1-\mu}}{k+1-\mu}$ 。第一部分因分子具有  $p$  阶零点而显著更光滑。

### 4.9.5 近奇异积分

若核  $K(x, y)$  仅在  $x=y$  时奇异，而目标点  $x$  非常接近但不在积分曲线上，则积分有限却可能形成宽度极窄的峰值。这称为近奇异积分。普通自适应细分可能需要极多面板。

常用策略包括：



1. 对靠近目标点的面板局部加密;
2. 解析减去已知奇异核;
3. 采用目标点相关的校正权重;
4. 在安全区域内展开, 再向目标点外推;
5. 对边界积分使用专门的 QBX 或高阶 Nyström 校正。

基础例题: 平方代换消除平方根奇异

考虑  $I = \int_0^1 \frac{e^{-x}}{\sqrt{x}} dx$ 。普通闭型公式会直接采样  $x = 0$  处无穷大函数值。令  $x = t^2$ ,  $dx = 2t dt$ , 则

$$I = 2 \int_0^1 e^{-t^2} dt. \quad (4.91)$$

变换后的被积函数在  $[0, 1]$  上解析, 可使用 Gauss-Legendre、Clenshaw-Curtis 或高阶复合规则。

该积分还可写为  $I = \sqrt{\pi} \operatorname{erf}(1)$ , 可用于验证数值结果。

#### 4.9.6 知识点八: 振荡积分

考虑

$$I(\omega) = \int_a^b f(x) e^{i\omega g(x)} dx, \quad \omega \gg 1. \quad (4.92)$$

若直接使用普通多项式求积, 网格必须解析振荡:  $h\omega \max |g'| \ll 1$ 。否则可能发生混叠。

无驻点情形 若  $g'(x) \neq 0$  在  $[a, b]$  上成立, 则分部积分:

$$I(\omega) = \left[ \frac{f(x)}{i\omega g'(x)} e^{i\omega g(x)} \right]_a^b - \frac{1}{i\omega} \int_a^b \frac{d}{dx} \left( \frac{f(x)}{g'(x)} \right) e^{i\omega g(x)} dx. \quad (4.93)$$

因此在适当正则性下  $I(\omega) = O(\omega^{-1})$ 。Filon 方法通过插值缓变振幅  $f$  并精确积分  $p(x) e^{i\omega g(x)}$  来避免逐周期采样。Levin 方法则寻找  $p$  使  $p'(x) + i\omega g'(x)p(x) \approx f(x)$ , 从而  $I(\omega) \approx p(b) e^{i\omega g(b)} - p(a) e^{i\omega g(a)}$ 。

驻点情形 若存在  $g'(x_0) = 0$ ,  $g''(x_0) \neq 0$ , 则普通分部积分在  $x_0$  失效。主要贡献来自宽度  $O(\omega^{-1/2})$  的驻点邻域, 典型主项为

$$I(\omega) \sim f(x_0) e^{i\omega g(x_0)} e^{i\frac{\pi}{4} \operatorname{sgn} g''(x_0)} \sqrt{\frac{2\pi}{\omega |g''(x_0)|}}. \quad (4.94)$$

驻相法将在第 20 部分系统推导。

基础例题: 无驻点振荡积分

对  $I(\omega) = \int_0^1 e^{i\omega x} dx$ , 精确值为  $I(\omega) = \frac{e^{i\omega} - 1}{i\omega}$ 。因此  $|I(\omega)| \leq \frac{2}{\omega}$ 。若固定使用少量等距节点, 采样值可能在某些  $\omega$  下全部接近 1, 导致错误地得到  $O(1)$  积分; 这说明振荡积分必须考虑频率与网格的相对尺度。



## 4.10 多维数值积分、张量积与稀疏网格

### 4.10.1 知识点九：张量积公式

设一维公式为  $Q^{(r)}f = \sum_{j=1}^{N_r} w_j^{(r)} f(x_j^{(r)})$ 。对直积区域  $\Omega = [a_1, b_1] \times \cdots \times [a_d, b_d]$  构造张量积公式

$$Q^{\otimes d}(f) = \sum_{j_1=1}^{N_1} \cdots \sum_{j_d=1}^{N_d} \left( \prod_{r=1}^d w_{j_r}^{(r)} \right) f(x_{j_1}^{(1)}, \dots, x_{j_d}^{(d)}). \quad (4.95)$$

若每一维使用  $N$  个节点，则总节点数为

$$N_{\text{tot}} = N^d. \quad (4.96)$$

这就是维数灾难：即使每维只取  $N = 10$ ，当  $d = 10$  时已有  $10^{10}$  个节点。

**【代数精度】** 若每维一维公式对次数不超过  $p$  的多项式精确，则张量积公式对每个变量分别次数不超过  $p$  的张量多项式精确： $x_1^{\alpha_1} \cdots x_d^{\alpha_d}$ ， $0 \leq \alpha_r \leq p$ 。这不同于“总次数不超过  $p$ ”。

**【稳定性】** 若一维权重均为正，则张量积权重也为正，且权重和等于区域体积或加权总质量。

**【复杂度】** 函数采样、运算与存储均为  $O(N^d)$ 。若函数具有可分离结构  $f(x_1, \dots, x_d) = \prod_{r=1}^d f_r(x_r)$ ，积分可分解为一维积分乘积，无需显式形成全部张量节点。

### 4.10.2 稀疏网格与 Smolyak 思想

令  $U_i$  为一维第  $i$  层嵌套求积规则，并定义增量  $\Delta_i = U_i - U_{i-1}$ ， $U_0 = 0$ 。对  $q \geq d$ ，Smolyak 公式可写为

$$\mathcal{A}(q, d) = \sum_{\substack{\mathbf{i} \in \mathbb{N}^d \\ |\mathbf{i}|_1 \leq q}} \Delta_{i_1} \otimes \cdots \otimes \Delta_{i_d}. \quad (4.97)$$

它只保留“总层数较低”的张量增量，舍弃所有高层组合。

若一维第  $i$  层节点数约为  $2^i$ ，则：

- 完整张量第  $q$  层成本约为  $2^{qd}$ ；
- 稀疏网格成本约为  $O(2^q q^{d-1})$ 。

**【适用条件】** 稀疏网格最适合具有有界混合偏导数的函数。若函数沿对角线、曲面或局部小区域存在奇异性，标准稀疏网格的优势可能显著下降，需要局部自适应或坐标变换。

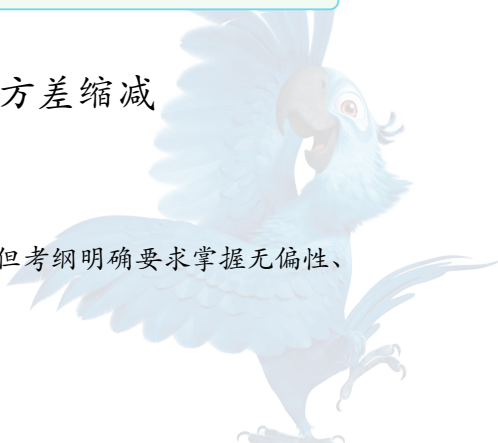
#### 基础例题：二维张量 Gauss 公式

计算  $I = \int_0^1 \int_0^1 x^2 y^2 dx dy$ 。精确值为  $I = \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{9}$ 。把二点 Gauss-Legendre 从  $[-1, 1]$  映射到  $[0, 1]$ ： $\xi_{1,2} = \frac{1}{2} \left( 1 \mp \frac{1}{\sqrt{3}} \right)$ ， $\omega_{1,2} = \frac{1}{2}$ 。二维张量公式为  $Q(f) = \sum_{i=1}^2 \sum_{j=1}^2 \frac{1}{4} \xi_i^2 \xi_j^2$ 。因为一维二点 Gauss 公式对二次多项式精确， $\sum_{i=1}^2 \frac{1}{2} \xi_i^2 = \frac{1}{3}$ 。故  $Q(f) = \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{9}$ ，与精确值一致。

## 4.11 Monte Carlo 积分、置信区间与方差缩减

### 4.11.1 知识点十：基本 Monte Carlo 积分

**【重要性等级】** **A 级**。正式六套试卷尚未直接设置 Monte Carlo 题，但考纲明确要求掌握无偏性、方差、均方误差、置信区间与重要抽样。



设  $\Omega \subset \mathbb{R}^d$  可测且体积  $|\Omega| < \infty$ 。令  $X_1, \dots, X_N \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(\Omega)$ 。对  $I = \int_{\Omega} f(x) dx$  定义估计量

$$\hat{I}_N = \frac{|\Omega|}{N} \sum_{i=1}^N f(X_i). \quad (4.98)$$

【无偏性】 若  $f \in L^1(\Omega)$ , 则

$$\mathbb{E}[\hat{I}_N] = |\Omega| \mathbb{E}[f(X_1)] = |\Omega| \frac{1}{|\Omega|} \int_{\Omega} f(x) dx = I. \quad (4.99)$$

【方差与均方误差】 若  $f \in L^2(\Omega)$ , 令  $\sigma_f^2 = \text{Var}(f(X_1))$ 。由独立性,

$$\text{Var}(\hat{I}_N) = \frac{|\Omega|^2 \sigma_f^2}{N}. \quad (4.100)$$

因为估计无偏,

$$\text{MSE}(\hat{I}_N) = \mathbb{E}[(\hat{I}_N - I)^2] = \frac{|\Omega|^2 \sigma_f^2}{N}. \quad (4.101)$$

均方根误差为

$$\text{RMSE} = \frac{|\Omega| \sigma_f}{\sqrt{N}} = O(N^{-1/2}). \quad (4.102)$$

#### 易错点与反例

$N^{-1/2}$  是随机均方意义的速率, 不是确定性截断误差。

对一次具体随机运行, 不存在无条件确定性保证  $|\hat{I}_N - I| \leq CN^{-1/2}$ 。正确表述应使用方差、均方误差、概率界或置信区间。

#### 4.11.2 中心极限定理与置信区间

若  $0 < \sigma_f^2 < \infty$ , 则中心极限定理给出

$$\frac{\sqrt{N}(\hat{I}_N - I)}{|\Omega| \sigma_f} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1). \quad (4.103)$$

以样本方差

$$s_f^2 = \frac{1}{N-1} \sum_{i=1}^N (f(X_i) - \bar{f}_N)^2, \quad \bar{f}_N = \frac{1}{N} \sum_{i=1}^N f(X_i), \quad (4.104)$$

估计  $\sigma_f^2$ 。大样本近似  $100(1-\alpha)\%$  置信区间为

$$\left[ \hat{I}_N \pm z_{1-\alpha/2} \frac{|\Omega| s_f}{\sqrt{N}} \right]. \quad (4.105)$$

其中  $z_{1-\alpha/2}$  为标准正态分位数, 例如  $z_{0.975} \approx 1.96$ 。

#### Algorithm 13 基本 Monte Carlo 积分与置信区间

**Input:** 被积函数  $f$ 、采样分布、样本数  $N$ 、置信水平  $1-\alpha$

**Output:**  $\hat{I}_N$ 、标准误差和置信区间

- 1: **Initialization:**  $S_1 \leftarrow 0, S_2 \leftarrow 0$
- 2: **for**  $i = 1, \dots, N$  **do**
- 3:     独立抽样  $X_i \sim \text{Unif}(\Omega)$
- 4:      $Y_i \leftarrow f(X_i)$



```

5:    $S_1 \leftarrow S_1 + Y_i$ 
6:    $S_2 \leftarrow S_2 + Y_i^2$ 
7: end for
8:  $\bar{Y} \leftarrow S_1/N$ 
9:  $s^2 \leftarrow (S_2 - N\bar{Y}^2)/(N-1)$ 
10:  $\hat{I}_N \leftarrow |\Omega|\bar{Y}$ 
11:  $\text{SE} \leftarrow |\Omega|s/\sqrt{N}$ 
12: Stopping criterion: 达到预定样本数, 或估计置信半宽低于容差
13: Complexity:  $O(N)$  次函数采样与运算; 流式实现额外存储  $O(1)$ 

```

【稳定性与条件数】 若  $f$  正负相消导致  $I$  很小, 则绝对标准误差可能合理而相对误差巨大。应报告  $\frac{\text{SE}}{|\hat{I}_N|}$  时同时检查分母是否接近零。

若  $f$  具有重尾且  $f \notin L^2$ , 则方差不存在, 经典中心极限定理和式 (4.105) 不能直接使用。

【维数影响】 速率指数  $1/2$  不显式依赖维数  $d$ , 这是 Monte Carlo 相对张量积规则的主要优势。但以下量仍可能随  $d$  恶化:

- 方差  $\sigma_f^2$ ;
- 单次函数评估成本;
- 稀有事件概率;
- 有效样本比例;
- 重要抽样密度设计难度。

基础例题: 估计  $\int_0^1 x^2 dx$

令  $X_i \sim U(0, 1)$ , 估计量为  $\hat{I}_N = \frac{1}{N} \sum_{i=1}^N X_i^2$ 。精确积分为  $I = \frac{1}{3}$ 。由于  $\mathbb{E}[X^2] = \frac{1}{3}$ ,  $\mathbb{E}[X^4] = \frac{1}{5}$ , 方差为  $\text{Var}(X^2) = \frac{1}{5} - \left(\frac{1}{3}\right)^2 = \frac{4}{45}$ 。故

$$\text{RMSE} = \frac{2}{\sqrt{45N}}. \quad (4.106)$$

若希望 95% 置信区间的理论半宽约不超过  $10^{-3}$ , 按已知方差估算需  $1.96 \frac{2}{\sqrt{45N}} \leq 10^{-3}$ , 即  $N \geq \frac{1.96^2 \cdot 4}{45 \cdot 10^{-6}} \approx 3.42 \times 10^5$ 。这说明 Monte Carlo 在低维高精度积分中通常不如高阶确定性求积。

### 4.11.3 知识点十一: 重要抽样

设  $p(x)$  是  $\Omega$  上的概率密度, 满足  $p(x) > 0$  在  $f(x) \neq 0$  的区域。则  $I = \int_{\Omega} \frac{f(x)}{p(x)} p(x) dx = \mathbb{E}_p \left[ \frac{f(X)}{p(X)} \right]$ 。重要抽样估计量为

$$\hat{I}_N^{\text{IS}} = \frac{1}{N} \sum_{i=1}^N \frac{f(X_i)}{p(X_i)}, \quad X_i \sim p. \quad (4.107)$$

其方差为

$$\text{Var}(\hat{I}_N^{\text{IS}}) = \frac{1}{N} \left[ \int_{\Omega} \frac{f(x)^2}{p(x)} dx - I^2 \right]. \quad (4.108)$$

形式上, 使方差最小的密度为

$$p_*(x) = \frac{|f(x)|}{\int_{\Omega} |f(t)| dt}. \quad (4.109)$$



若  $f \geq 0$ , 则  $f(X)/p_*(X)$  为常数, 理论方差为零。但  $p_*$  需要未知归一化积分, 实际只能寻找结构相近、易采样的近似密度。

#### 易错点与反例

若  $p(x)$  在  $f(x) \neq 0$  处为零, 则估计量有偏或未定义。重要抽样的核心条件不是“在大函数值处多采样”这一口号, 而是  $\int \frac{f^2}{p} < \infty$ 。

#### 综合例题: 重要抽样消除奇异积分的无限方差

考虑  $I = \int_0^1 x^{-1/2} dx = 2$ 。

若用均匀抽样  $X \sim U(0, 1)$ , 则  $f(X) = X^{-1/2}$ 。虽然  $\mathbb{E}[f(X)] = 2$ , 但  $\mathbb{E}[f(X)^2] = \int_0^1 x^{-1} dx = \infty$ 。因此均匀 Monte Carlo 估计量没有有限方差, 经典  $N^{-1/2}$  方差公式和正态置信区间均失效。改取密度

$$p(x) = \frac{1}{2\sqrt{x}}, \quad 0 < x < 1. \quad (4.110)$$

它是合法密度, 因为积分为 1。此时  $\frac{f(x)}{p(x)} = \frac{x^{-1/2}}{(2\sqrt{x})^{-1}} = 2$ 。故每个样本都给出 2:  $\hat{I}_N^{\text{IS}} \equiv 2$ , 方差为零。

可通过  $U \sim U(0, 1)$ ,  $X = U^2$  生成该密度下的样本。

#### 4.11.4 其他方差缩减方法

**控制变量** 设  $g(X)$  的期望  $\mu_g = \mathbb{E}[g(X)]$  已知。定义

$$Y_c = f(X) - c(g(X) - \mu_g). \quad (4.111)$$

其期望仍为  $\mathbb{E}[f]$ , 方差为  $\text{Var}(Y_c) = \text{Var}(f) - 2c \text{Cov}(f, g) + c^2 \text{Var}(g)$ 。最优系数为

$$c_* = \frac{\text{Cov}(f, g)}{\text{Var}(g)}. \quad (4.112)$$

**对偶变量** 若  $U \sim U(0, 1)$ , 同时使用  $U$  与  $1 - U$ :  $\hat{I}_{\text{anti}} = \frac{1}{2N} \sum_{i=1}^N [f(U_i) + f(1 - U_i)]$ 。当  $f$  单调时, 两个函数值常负相关, 从而降低方差。

**分层抽样** 将  $\Omega$  分为互不相交区域  $\Omega_r$ , 在每层独立采样:  $I = \sum_r |\Omega_r| \mathbb{E}[f(X) \mid X \in \Omega_r]$ 。分层可以保证每个区域均被采样, 避免样本随机聚集。

**准 Monte Carlo** 准 Monte Carlo 使用低差异确定性点列, 并通过 Koksma-Hlawka 型界把误差与点列差异及函数变差联系起来。它不是普通随机 Monte Carlo; 误差率、置信区间和随机化方式均需单独说明。

## 4.12 模块一正式真题映射与得分母题

本节只统计六套博士资格考试, 不把丘赛与专题合辑计入频率。



| 正式题      | 主要知识点                                     | 完整答案位置                              | 主要题型                  |
|----------|-------------------------------------------|-------------------------------------|-----------------------|
| [23F-Q3] | Chebyshev 微分矩阵                            | 第 01 部分1.8                          | 算法推导; 显式矩阵构造。         |
| [24F-Q1] | Chebyshev 递推、复合恒等式、离散正交                   | 第 01 部分1.3                          | 恒等式证明; 离散正交证明。        |
| [25S-Q1] | 周期梯形公式高阶与指数收敛                             | 第 03 部分3.7                          | 收敛阶证明; Fourier 误差估计。  |
| [25F-Q2] | Chebyshev 极值、插值、Gauss-Chebyshev           | 第 01 部分处理 (a)-(c); 第 04 部分4.4处理 (d) | 极小极大; 插值误差; Gauss 求积。 |
| [26S-Q2] | Legendre 正交、最佳 $L^2$ 逼近、插值、Gauss-Legendre | 第 02 部分处理 (a)-(c); 第 04 部分4.5处理 (d) | 正交投影; 反例审计; Gauss 求积。 |

#### 4.12.1 正式出现情况

六套正式试卷共出现 5 道以模块一为主要模块的题号, 覆盖 5 套试卷:

| 主题母题                     | 正式题号数 | 说明                          |
|--------------------------|-------|-----------------------------|
| Chebyshev/Legendre 正交多项式 | 3     | [24F-Q1]、[25F-Q2]、[26S-Q2]。 |
| Gauss 求积                 | 2     | [25F-Q2(d)]、[26S-Q2(d)]。    |
| 周期梯形与谱收敛                 | 1     | [25S-Q1]。                   |
| 谱微分矩阵                    | 1     | [23F-Q3]。                   |



## 第二部分

### 非线性方程与常微分方程





# 第五章 标量非线性方程、二分法、不动点迭代、Newton 法、割线法、重根与收敛阶

## 5.1 标量非线性方程的统一框架

### 5.1.1 知识点一：问题、根的重数与算法输出

【重要性等级】 **S 级**。标量非线性方程在 [23F-Q1]、[24F-Q3]、[25S-Q2] 和 [26S-Q1] 中连续出现。资格考试不仅要求写出迭代公式，还要求证明局部收敛、计算收敛阶和渐近误差常数，并说明初值与光滑性条件。

【问题与目标】 给定函数  $f: D \subset \mathbb{R} \rightarrow \mathbb{R}$ , 求

$$f(x^*) = 0. \quad (5.1)$$

算法输入通常包括：

- 函数  $f$ ，以及在需要时提供  $f'$ 、 $f''$ ；
- 包含根的区间  $[a, b]$ ，或一个、两个初始近似；
- 绝对容差与相对容差；
- 最大迭代次数；
- 必要时给出根的重数  $m$ 。

算法输出至少应包括：

- 根的近似  $x_k$ ；
- 残差  $f(x_k)$ ；
- 步长或后验误差估计；
- 是否达到停止准则；
- 若失败，应给出导数过小、差商过小、超出可行区间或达到最大迭代次数等原因。

定义 5.1 (简单根与重根). 设  $f$  在  $x^*$  附近足够光滑。

若  $f(x^*) = 0$ ,  $f'(x^*) \neq 0$ , 则称  $x^*$  为  $f$  的简单根。

若存在整数  $m \geq 2$  及函数  $g$ , 使

$$f(x) = (x - x^*)^m g(x), \quad g(x^*) \neq 0, \quad (5.2)$$



则称  $x^*$  为  $m$  重根。在经典可微条件下, 这等价于  $f(x^*) = f'(x^*) = \cdots = f^{(m-1)}(x^*) = 0, f^{(m)}(x^*) \neq 0$ 。

### 【识别信号】

- 题目给出  $f'(x^*) \neq 0$ : 应立即想到简单根、局部条件数有限和 Newton 二次收敛。
- 题目给出  $f, f', \dots, f^{(m-1)}$  在根处同时为零: 应因式分解  $f(x) = (x - x^*)^m g(x)$ 。
- 题目要求“求收敛阶”: 应令  $e_k = x_k - x^*$  并推导误差递推。
- 题目要求“保证收敛”: 仅有渐近误差展开不够, 必须先构造根邻域的不变性或压缩性。
- 题目给出异号端点: 优先考虑二分法或带区间保护的 Newton 法。

### 5.1.2 知识点二: 收敛阶、超线性与渐近误差常数

定义 5.2 ( $Q$ -收敛阶). 设  $x_k \rightarrow x^*$ , 并记  $e_k = x_k - x^*$ 。若存在  $p \geq 1$  及常数  $C \in (0, \infty)$ , 使

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = C, \quad (5.3)$$

则称  $\{x_k\}$  以  $Q$ -阶  $p$  收敛到  $x^*$ ,  $C$  称为渐近误差常数。

特别地:

- $p = 1$  且  $0 < C < 1$ :  $Q$ -线性收敛;
- $p > 1$ : 超线性收敛;
- $p = n$ :  $n$  次收敛 ( $n \geq 2$ )。

注 5.3. 如果只有  $|e_k| \leq C_0 q^k$ ,  $0 < q < 1$ , 则通常称为  $R$ -线性收敛。二分法的区间半径严格按因子  $1/2$  收缩, 但二分中点的实际误差比值未必存在。因此更准确的说法是: 二分法具有因子  $1/2$  的线性区间收缩, 并使中点误差  $R$ -线性收敛。

定理 5.4 (迭代函数导数与收敛阶). 设迭代写成  $x_{k+1} = \Phi(x_k)$ ,  $\Phi(x^*) = x^*$ , 且  $\Phi$  在  $x^*$  附近  $p$  次连续可微。若  $\Phi'(x^*) = \Phi''(x^*) = \cdots = \Phi^{(p-1)}(x^*) = 0, \Phi^{(p)}(x^*) \neq 0$ , 则只要迭代已经局部收敛,

$$e_{k+1} = \frac{\Phi^{(p)}(x^*)}{p!} e_k^p + o(e_k^p), \quad (5.4)$$

因而收敛阶为  $p$ , 渐近误差常数为  $\frac{|\Phi^{(p)}(x^*)|}{p!}$ 。

证明. 由 Taylor 展开,  $\Phi(x^* + e_k) = \Phi(x^*) + \sum_{j=1}^{p-1} \frac{\Phi^{(j)}(x^*)}{j!} e_k^j + \frac{\Phi^{(p)}(x^*)}{p!} e_k^p + o(e_k^p)$ 。利用  $\Phi(x^*) = x^*$  及前  $p-1$  阶导数为零, 立即得到式 (5.4)。□

#### 易错点与反例

“ $\Phi'(x^*) = 0$ ”不单独构成完整的局部收敛证明。

它说明若迭代进入并停留在根的邻域, 则至少具有超线性趋势。完整答案还应证明存在  $\delta > 0$ , 使  $|x_0 - x^*| \leq \delta \implies x_k \in [x^* - \delta, x^* + \delta]$  并且  $x_k \rightarrow x^*$ 。

### 5.1.3 知识点三：根的条件数

【问题条件数】 算法收敛快慢与根本身对数据扰动的敏感性是两个不同问题。对带参数方程

$$F(x, p) = 0, \quad (5.5)$$

设  $F(x^*, p_0) = 0$ ,  $F_x(x^*, p_0) \neq 0$ 。由隐函数定理,

$$\frac{dx^*}{dp} = -\frac{F_p(x^*, p_0)}{F_x(x^*, p_0)}. \quad (5.6)$$

因此小的参数扰动  $\delta p$  引起

$$\delta x^* = -\frac{F_p(x^*, p_0)}{F_x(x^*, p_0)}\delta p + o(|\delta p|). \quad (5.7)$$

对函数的加性扰动  $\tilde{f} = f + \delta f$ ,  $\tilde{f}(\tilde{x}^*) = 0$ , 简单根满足

$$\tilde{x}^* - x^* = -\frac{\delta f(x^*)}{f'(x^*)} + o(\|\delta f\|), \quad (5.8)$$

故在局部一致范数扰动模型下, 绝对条件数为

$$\kappa_{\text{abs}}(x^*) = \frac{1}{|f'(x^*)|}. \quad (5.9)$$

反例 5.5 (重根不存在有限的一阶条件数). 考虑  $f(x) = x^m$ ,  $m \geq 2$ , 其根  $x^* = 0$  为  $m$  重根。加入常数扰动  $\tilde{f}(x) = x^m - \delta$ ,  $\delta > 0$ , 则正实根为  $\tilde{x}^* = \delta^{1/m}$ 。因此  $|\tilde{x}^* - x^*| = \delta^{1/m}$ , 而不是  $O(\delta)$ 。当  $\delta \rightarrow 0$  时,  $\frac{\delta^{1/m}}{\delta} = \delta^{1/m-1} \rightarrow \infty$ 。所以重根对一般函数扰动具有 Hölder 型而非 Lipschitz 型敏感性。

### 5.1.4 标量求根方法的局部比较

| 方法             | 主要输入                  | 典型收敛阶                  | 单步主要成本           | 主要限制                        |
|----------------|-----------------------|------------------------|------------------|-----------------------------|
| 二分法            | 异号区间 $[a, b]$         | 区间因子 1/2               | 一个新函数值           | 不能直接发现偶重根; 速度较慢。            |
| 不动点迭代          | $x_{k+1} = \Phi(x_k)$ | 通常线性                   | 一次 $\Phi$ 计算     | 收敛性强烈依赖方程改写。                |
| Newton 法       | $f, f', x_0$          | 简单根二次                  | 一次 $f$ 、一次 $f'$  | 局部方法; 导数过小或初值差时可能失败。        |
| 简化 Newton      | $f$ 及固定斜率 $d$         | 通常线性                   | 一次 $f$           | 需满足 $ 1 - f'(x^*)/d  < 1$ 。 |
| 割线法            | $f, x_0, x_1$         | $\frac{1+\sqrt{5}}{2}$ | 一个新函数值           | 差商可能接近零; 局部方法。              |
| 已知重数修正 Newton  | $f, f', m$            | 通常二次                   | 一次 $f$ 、一次 $f'$  | 必须知道正确重数。                   |
| 未知重数自适应 Newton | $f, f', f''$          | 通常二次                   | $f, f', f''$ 各一次 | 二阶导数成本及分母稳定性。               |

| 方法               | 主要输入  | 典型收敛阶 | 单步主要成本 | 主要限制               |
|------------------|-------|-------|--------|--------------------|
| 差分 Newton 型<br>法 | 两个函数值 | 通常二次  | 两个函数值  | 差分分母可能发生严重<br>重消去。 |

## 5.2 二分法：存在性、误差证书与复杂度

### 5.2.1 知识点四：二分法的完整算法

【重要性等级】 **A 级**。二分法公式简单，但它是所有全局化求根方法的基准。资格考试常从“保证收敛”、“迭代次数”、“停止准则”和“偶重根失败”角度考查。

【精确定义与假设】 设  $f \in C[a_0, b_0]$ ,  $f(a_0)f(b_0) < 0$ . 由介值定理，区间内至少存在一个根。二分法不要求  $f$  可微，也不要求根唯一。

#### Algorithm 14 二分法

**Input:** 连续函数  $f$ ; 异号端点  $a_0 < b_0$ ; 位置容差  $\text{tol}_x$ ; 残差容差  $\text{tol}_f$ ; 最大迭代次数  $K_{\max}$

**Output:** 根近似  $x$  及最终包围区间

```

1: Initialization:  $a \leftarrow a_0, b \leftarrow b_0, f_a \leftarrow f(a), f_b \leftarrow f(b)$ 
2: if  $f_a = 0$  then
3:   return  $a$ 
4: end if
5: if  $f_b = 0$  then
6:   return  $b$ 
7: end if
8: if  $f_a f_b > 0$  then
9:   报告“初始区间不满足异号条件”并终止
10: end if
11: for  $k = 0, 1, \dots, K_{\max} - 1$  do
12:    $c \leftarrow a + \frac{b-a}{2}$ 
13:    $f_c \leftarrow f(c)$ 
14:   if  $f_c = 0$  then
15:     return  $c$ 
16:   end if
17:   if  $(b-a)/2 \leq \text{tol}_x$  then
18:     return  $c$  及区间  $[a, b]$ 
19:   end if
20:   if  $|f_c| \leq \text{tol}_f$  then
21:     记录“残差准则满足”; 若需要严格位置证书, 仍需导数下界
22:   end if
23:   if  $f_a f_c < 0$  then
24:      $b \leftarrow c, f_b \leftarrow f_c$ 
25:   else
26:      $a \leftarrow c, f_a \leftarrow f_c$ 

```



27:     **end if**  
 28: **end for**  
 29: 报告“达到最大迭代次数”  
 30: **Stopping criterion:** 区间半宽达到位置容差，或精确命中根  
 31: **Complexity:** 每步一个新函数值；运算复杂度  $O(k)$ ；存储复杂度  $O(1)$

定理 5.6 (二分法误差与迭代次数). 设第  $k$  次区间为  $I_k = [a_k, b_k]$ , 并取其中点  $x_k = \frac{a_k + b_k}{2}$ . 则

$$b_k - a_k = \frac{b_0 - a_0}{2^k}, \quad (5.10)$$

且对  $I_k$  内任一根  $x^*$ ,

$$|x_k - x^*| \leq \frac{b_0 - a_0}{2^{k+1}}. \quad (5.11)$$

若希望  $|x_k - x^*| \leq \varepsilon_x$ , 充分条件为

$$k \geq \left\lceil \log_2 \frac{b_0 - a_0}{2\varepsilon_x} \right\rceil. \quad (5.12)$$

证明. 每次二分保留一个长度为父区间一半的子区间, 归纳得式 (5.10). 根与中点均属于  $I_k$ , 故二者距离不超过区间半长, 即得式 (5.11). 对该上界求解即可得到式 (5.12).  $\square$

**【稳定性与条件数】** 二分法具有强几何稳定性: 只要函数值符号判断正确, 根始终被包围. 但若  $f(a)$  或  $f(b)$  非常接近零, 浮点舍入可能导致错误符号判断. 实现中应避免通过  $f_a f_c$  直接判断符号, 因为乘积可能上溢或下溢; 更稳妥的实现是分别比较符号位.

若在区间上已知  $|f'(x)| \geq m_1 > 0$ , 则由中值定理,

$$|x - x^*| \leq \frac{|f(x)|}{m_1}. \quad (5.13)$$

没有导数下界时, 小残差不自动意味着小根误差.

#### 【失败情形】

- 偶重根附近函数不变号, 二分法无法由异号条件发现该根;
- 区间内可能有多个根, 二分法只保证收敛到某个被持续包围的根;
- 函数不连续时, 异号可能对应跳跃间断而不是零点;
- 函数值计算带噪声时, 符号可能不可靠;
- 当区间小于机器可分辨尺度时, 中点可能等于端点.

#### 基础例题：二分法的迭代次数

求  $f(x) = x^3 - x - 1$  在  $[1, 2]$  内的根. 因为  $f(1) = -1 < 0$ ,  $f(2) = 5 > 0$ , 二分法适用. 初始区间长度为 1. 若要求中点误差不超过  $10^{-8}$ , 则由式 (5.11),  $\frac{1}{2^{k+1}} \leq 10^{-8}$ . 由于  $2^{26} < 10^8 < 2^{27}$ , 取  $k = 26$  即可保证  $|x_{26} - x^*| \leq 2^{-27} < 10^{-8}$ . 这里的结论是确定性的误差证书, 不依赖根附近的导数大小.

## 5.3 不动点迭代与压缩映射

### 5.3.1 知识点五：方程改写与压缩映射

【重要性等级】 **S 级**。不动点思想是 Newton 法、非线性方程组迭代、ODE 隐式方程求解和优化近端方法的共同基础。资格考试要求区分：“方程具有唯一根”和“某个特定不动点迭代收敛”不是同一结论。

将  $f(x) = 0$  改写成

$$x = \Phi(x), \quad (5.14)$$

并迭代

$$x_{k+1} = \Phi(x_k). \quad (5.15)$$

同一个方程通常有许多不同改写，而不同  $\Phi$  具有完全不同的收敛性质。

定理 5.7 (Banach 压缩映射定理). 设  $(X, \|\cdot\|)$  为完备度量空间,  $D \subset X$  非空且闭, 并且  $\Phi: D \rightarrow D$ . 若存在  $q \in [0, 1)$  使

$$\|\Phi(x) - \Phi(y)\| \leq q \|x - y\|, \quad \forall x, y \in D, \quad (5.16)$$

则:

1.  $\Phi$  在  $D$  内存在唯一不动点  $x^*$ ;
2. 对任意  $x_0 \in D$ , 迭代  $x_{k+1} = \Phi(x_k)$  收敛到  $x^*$ ;
3. 具有先验误差估计

$$\|x_k - x^*\| \leq q^k \|x_0 - x^*\|; \quad (5.17)$$

4. 具有不含未知根的估计

$$\|x_k - x^*\| \leq \frac{q^k}{1 - q} \|x_1 - x_0\|; \quad (5.18)$$

5. 具有后验估计

$$\|x_k - x^*\| \leq \frac{q}{1 - q} \|x_k - x_{k-1}\|, \quad k \geq 1. \quad (5.19)$$

证明. 由压缩性,  $\|x_{j+1} - x_j\| \leq q^j \|x_1 - x_0\|$ . 对任意  $p \geq 1$ ,

$$\|x_{k+p} - x_k\| \leq \sum_{j=k}^{k+p-1} \|x_{j+1} - x_j\| \leq \sum_{j=k}^{k+p-1} q^j \|x_1 - x_0\| \leq \frac{q^k}{1 - q} \|x_1 - x_0\|.$$

右端随  $k \rightarrow \infty$  趋于零, 因此  $\{x_k\}$  为 Cauchy 列. 由  $X$  完备且  $D$  闭, 存在  $x^* \in D$  使  $x_k \rightarrow x^*$ . 压缩映射连续, 故  $x^* = \lim_{k \rightarrow \infty} x_{k+1} = \lim_{k \rightarrow \infty} \Phi(x_k) = \Phi(x^*)$ .

若  $y^*$  也是不动点, 则  $\|x^* - y^*\| = \|\Phi(x^*) - \Phi(y^*)\| \leq q \|x^* - y^*\|$ , 由  $q < 1$  得  $x^* = y^*$ .

估计式 (5.17) 由  $\|x_k - x^*\| \leq q^k \|x_0 - x^*\|$  直接归纳得到. 对无穷尾和取极限得到式 (5.18). 再以  $\|x_{j+1} - x_j\| \leq q^{j-k+1} \|x_k - x_{k-1}\|$  估计尾和, 得到式 (5.19).  $\square$

---

#### Algorithm 15 带压缩常数证书的不动点迭代

---

**Input:** 迭代函数  $\Phi$ ; 初值  $x_0 \in D$ ; 已知压缩常数  $q < 1$ ; 位置容差  $\text{tol}_x$ ; 最大迭代次数  $K_{\max}$

**Output:** 不动点近似  $x_k$

- 1: **Initialization:**  $k \leftarrow 0$
- 2: **for**  $k = 0, 1, \dots, K_{\max} - 1$  **do**



```

3:    $x_{k+1} \leftarrow \Phi(x_k)$ 
4:   检查  $x_{k+1} \in D$ 
5:   if  $\frac{q}{1-q}|x_{k+1} - x_k| \leq \text{tol}_x$  then
6:     return  $x_{k+1}$ 
7:   end if
8: end for
9: 报告“未达到容差”
10: Stopping criterion: 使用压缩映射后验误差界，而不只是相邻步差
11: Complexity: 每步一次  $\Phi$  计算；存储  $O(1)$ 

```

### 5.3.2 一维局部判据与迭代行为

若  $\Phi \in C^1[a, b]$ , 且  $\Phi([a, b]) \subset [a, b]$ ,  $\max_{x \in [a, b]} |\Phi'(x)| \leq q < 1$ , 则由中值定理,  $\Phi$  是压缩映射。

若只知道  $|\Phi'(x^*)| < 1$ , 则由连续性可缩小根邻域, 使其中  $|\Phi'(x)| \leq q < 1$ , 从而得到局部收敛。

若  $|\Phi'(x^*)| > 1$ , 则该不动点是局部排斥的; 除非初值恰好落在特殊轨道上, 否则迭代不收敛到  $x^*$ 。

若  $\Phi'(x^*) = 1$  或  $\Phi'(x^*) = -1$ , 一阶导数判据不能决定收敛性, 必须考察高阶项。

当  $0 \leq \Phi'(x) \leq q < 1$  时, 误差通常不变号, 迭代呈单调趋近; 当  $-q \leq \Phi'(x) \leq 0$  时, 误差通常交替变号, 迭代在根两侧振荡趋近。

#### 易错点与反例

错误说法: 只要  $f(x) = 0$  有唯一解, 任意不动点改写都收敛。

错误原因: 收敛由迭代函数  $\Phi$  决定, 而不是仅由零点唯一性决定。必须检查  $\Phi(D) \subset D$  和  $\sup_D |\Phi'| < 1$ , 或者证明其他局部、单调或能量型收敛条件。

## 5.4 补充训练题：丘赛 2021 Problem 3——全局压缩迭代与迭代次数

### 完整题目叙述

令  $f: \mathbb{R} \rightarrow \mathbb{R}$ ,  $f(x) = 2x - \cos x$ 。

(a) 证明方程  $f(x) = 0$  在  $\mathbb{R}$  上有唯一解  $x^*$ , 且  $x^* \in (\frac{1}{4}, \frac{1}{2})$ 。

(b) 证明对任意初值  $x_0 \in \mathbb{R}$ , 不动点迭代

$$x_n = \frac{1}{2} \cos x_{n-1}, \quad n = 1, 2, \dots, \quad (5.20)$$

均收敛到  $x^*$ 。

(c) 当  $x_0 = \pi/6$  时, 求一个能够保证  $|x_n - x^*| < \frac{1}{2} \times 10^{-8}$  的  $n$ 。当  $x_0 = 20$  时, 求一个能够保证  $|x_n - x^*| < \frac{1}{4}$  的  $n$ 。

第 (a) 问详细解答. 首先,  $f'(x) = 2 + \sin x \geq 1 > 0$ ,  $x \in \mathbb{R}$ . 因此  $f$  在  $\mathbb{R}$  上严格单调递增, 故至多有一个实根。

另一方面, 利用  $\cos t \geq 1 - \frac{t^2}{2}$ , 有  $\cos \frac{1}{4} \geq 1 - \frac{1}{32} = \frac{31}{32}$ . 于是  $f(\frac{1}{4}) = \frac{1}{2} - \cos \frac{1}{4} \leq \frac{1}{2} - \frac{31}{32} = -\frac{15}{32} < 0$ 。

同时  $f(\frac{1}{2}) = 1 - \cos \frac{1}{2} > 0$ . 由介值定理, 在  $(1/4, 1/2)$  内至少存在一个根. 结合严格单调性, 根唯一.  $\square$

第 (b) 问详细解答. 定义  $\Phi(x) = \frac{1}{2} \cos x$ . 由均值定理,  $|\Phi(x) - \Phi(y)| = \frac{1}{2} |\cos x - \cos y| \leq \frac{1}{2} |x - y|$ . 因此  $\Phi: \mathbb{R} \rightarrow \mathbb{R}$  是压缩映射, 压缩常数可取  $q = \frac{1}{2}$ . 由于  $\mathbb{R}$  完备, Banach 不动点定理说明:

- $\Phi$  在  $\mathbb{R}$  上具有唯一不动点;
- 从任意  $x_0 \in \mathbb{R}$  出发, 迭代均收敛到该不动点.

不动点满足  $x^* = \frac{1}{2} \cos x^* \iff 2x^* - \cos x^* = 0$ , 所以该不动点正是第 (a) 问的唯一根.  $\square$

第 (c) 问第一种初值. 当  $x_0 = \frac{\pi}{6}$  时,  $x_1 = \frac{1}{2} \cos \frac{\pi}{6} = \frac{\sqrt{3}}{4}$ . 由 Banach 先验估计式 (5.18),

$$|x_n - x^*| \leq \frac{q^n}{1-q} |x_1 - x_0| = 2^{1-n} \left( \frac{\pi}{6} - \frac{\sqrt{3}}{4} \right). \quad (5.21)$$

要求右端小于  $5 \times 10^{-9}$ , 即  $2^{n-1} > \frac{\frac{\pi}{6} - \frac{\sqrt{3}}{4}}{5 \times 10^{-9}}$ . 数值上,  $\frac{\pi}{6} - \frac{\sqrt{3}}{4} \approx 0.0905860737$ , 故右端约为  $1.811721474 \times 10^7$ . 而  $2^{24} = 1.6777216 \times 10^7$ ,  $2^{25} = 3.3554432 \times 10^7$ . 因此

$$\boxed{n = 26} \quad (5.22)$$

可以保证所需精度, 并且这是上述统一压缩估计给出的最小整数.  $\square$

第 (c) 问第二种初值. 若直接使用  $|x_n - x^*| \leq 2^{1-n} |x_1 - x_0|$ , 并以  $|x_1 - x_0| \leq 20.5$  估计, 则  $n = 8$  已经足够, 但该估计较粗.

利用迭代映射的值域可以得到更强结论. 无论  $x_0 = 20$  为何,  $x_1 = \frac{1}{2} \cos 20 \in [-\frac{1}{2}, \frac{1}{2}]$ . 又由第 (a) 问,  $x^* \in (\frac{1}{4}, \frac{1}{2})$ . 故  $|x_1 - x^*| < 1$ . 从第 1 步起使用压缩估计:  $|x_n - x^*| \leq 2^{-(n-1)} |x_1 - x^*| < 2^{-(n-1)}$ . 取  $n = 3$ , 得到  $|x_3 - x^*| < \frac{1}{4}$ . 因此

$$\boxed{n = 3} \quad (5.23)$$

即可保证题目要求.  $\square$

## 5.5 Newton 法: 局部二次收敛、初值选择与全局化

### 5.5.1 知识点六: Newton 线性化与纯 Newton 算法

【重要性等级】 **S 级**. Newton 误差方程是资格考试最常见的收敛阶证明母题.

在  $x_k$  处作一阶 Taylor 线性化:  $f(x) \approx f(x_k) + f'(x_k)(x - x_k)$ . 令线性模型为零, 得到

$$\boxed{x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}}. \quad (5.24)$$

几何上,  $x_{k+1}$  是  $f$  在  $(x_k, f(x_k))$  处切线与  $x$  轴的交点.

---

#### Algorithm 16 标量纯 Newton 法

---

**Input:**  $f, f'$ ; 初值  $x_0$ ; 位置容差  $\text{tol}_x$ ; 残差容差  $\text{tol}_f$ ; 导数阈值  $\text{tol}_d$ ; 最大迭代次数  $K_{\max}$

**Output:** 根近似  $x_k$

- 1: **for**  $k = 0, 1, \dots, K_{\max} - 1$  **do**
- 2:  $f_k \leftarrow f(x_k)$

```

3:   if  $|f_k| \leq \text{tol}_f$  then
4:       return  $x_k$ 
5:   end if
6:    $d_k \leftarrow f'(x_k)$ 
7:   if  $|d_k| \leq \text{tol}_d$  then
8:       报告“导数过小, Newton 步不可靠”并终止
9:   end if
10:   $s_k \leftarrow -f_k/d_k$ 
11:   $x_{k+1} \leftarrow x_k + s_k$ 
12:  if  $|s_k| \leq \text{tol}_x(1 + |x_{k+1}|)$  then
13:      return  $x_{k+1}$ 
14:  end if
15: end for
16: 报告“达到最大迭代次数”
17: Stopping criterion: 同时监视残差和步长; 单独使用其中之一可能误判
18: Complexity: 每步一次  $f$  和一次  $f'$ ; 标量存储  $O(1)$ 

```

### 5.5.2 Newton 局部二次收敛定理

**定理 5.8** (简单根 Newton 法的局部二次收敛). 设  $f \in C^2[x^* - r, x^* + r]$ ,  $f(x^*) = 0$ ,  $f'(x^*) \neq 0$ . 若  $r > 0$  取得足够小, 使  $m_1 := \min_{|x-x^*| \leq r} |f'(x)| > 0$ ,  $M_2 := \max_{|x-x^*| \leq r} |f''(x)| < \infty$  并且

$$\gamma r < 1, \quad \gamma := \frac{M_2}{2m_1}, \quad (5.25)$$

则对任意  $|x_0 - x^*| \leq r$ , Newton 迭代有定义, 始终留在该邻域内, 并收敛到  $x^*$ . 此外

$$|e_{k+1}| \leq \gamma |e_k|^2, \quad e_k = x_k - x^*. \quad (5.26)$$

并且

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^2} = \frac{f''(x^*)}{2f'(x^*)}. \quad (5.27)$$

**证明.** 对  $x^*$  在  $x_k$  处作 Taylor 展开. 存在  $\xi_k$  位于  $x_k$  与  $x^*$  之间, 使  $0 = f(x^*) = f(x_k) + f'(x_k)(x^* - x_k) + \frac{1}{2}f''(\xi_k)(x^* - x_k)^2$ . 整理得  $f(x_k) = f'(x_k)e_k - \frac{1}{2}f''(\xi_k)e_k^2$ . 代入 Newton 迭代:

$$e_{k+1} = e_k - \frac{f(x_k)}{f'(x_k)} = \frac{f''(\xi_k)}{2f'(x_k)}e_k^2. \quad (5.28)$$

因此  $|e_{k+1}| \leq \frac{M_2}{2m_1}|e_k|^2 = \gamma|e_k|^2$ . 若  $|e_k| \leq r$ , 则  $|e_{k+1}| \leq \gamma r|e_k| < |e_k| \leq r$ . 所以该邻域对 Newton 迭代不变, 且误差单调趋于某个极限. 由  $|e_{k+1}| \leq q|e_k|$ ,  $q = \gamma r < 1$ , 知  $e_k \rightarrow 0$ .

最后,  $\xi_k \rightarrow x^*$  且  $x_k \rightarrow x^*$ , 在式 (5.28) 中取极限, 得到式 (5.27).  $\square$

#### 证明思路

识别信号: 简单根、 $f \in C^2$ 、要求二次收敛或渐近误差常数。

构造步骤:

1. 令  $e_k = x_k - x^*$ ;
2. 在  $x_k$  处将  $f(x^*) = 0$  展开到二阶;

3. 用 Newton 公式消去一阶项;

4. 得到  $e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)} e_k^2$ ;

5. 先用上下界证明邻域不变和收敛, 再令  $k \rightarrow \infty$  求渐近常数。

常见失败原因: 直接写  $e_{k+1} = O(e_k^2)$  而没有保证  $f'(x_k)$  远离零, 也没有证明  $x_k$  始终留在 Taylor 展开适用邻域内。

### 5.5.3 简化 Newton 法

若导数计算昂贵, 可固定一个非零斜率  $d$ :

$$x_{k+1} = x_k - \frac{f(x_k)}{d}. \quad (5.29)$$

相应迭代函数为  $\Phi_d(x) = x - \frac{f(x)}{d}$ 。在简单根处,

$$\Phi'_d(x^*) = 1 - \frac{f'(x^*)}{d}. \quad (5.30)$$

因此局部收敛的基本条件是

$$\left| 1 - \frac{f'(x^*)}{d} \right| < 1. \quad (5.31)$$

除非  $d = f'(x^*)$  或具有特殊抵消, 简化 Newton 法通常只有线性收敛。

若取  $d = f'(x_0)$ , 则只需在初始化时计算一次导数, 后续每步只计算  $f$ 。这降低了单步成本, 但可能增加迭代次数。

### 5.5.4 阻尼 Newton 与线搜索

纯 Newton 步  $p_k = -\frac{f(x_k)}{f'(x_k)}$  可能过大。定义标量残差平方目标

$$\Psi(x) = \frac{1}{2} f(x)^2. \quad (5.32)$$

当  $f'(x_k) \neq 0$  且  $f(x_k) \neq 0$  时,  $\Psi'(x_k)p_k = f(x_k)f'(x_k)\left(-\frac{f(x_k)}{f'(x_k)}\right) = -f(x_k)^2 < 0$ , 所以 Newton 方向是  $\Psi$  的下降方向。

阻尼 Newton 更新为

$$x_{k+1} = x_k + \lambda_k p_k, \quad 0 < \lambda_k \leq 1. \quad (5.33)$$

Armijo 回溯可选取  $\rho \in (0, 1)$ 、 $\sigma \in (0, 1/2)$ , 从  $\lambda = 1$  开始依次尝试  $\lambda = \rho^j$ , 直到

$$\Psi(x_k + \lambda p_k) \leq \Psi(x_k) - \sigma \lambda f(x_k)^2. \quad (5.34)$$

在简单根附近, 充分光滑条件下最终会接受  $\lambda_k = 1$ , 因而恢复纯 Newton 法的二次收敛。

### 5.5.5 二分-Newton 混合全局化

若已知异号区间  $[a_k, b_k]$ , 可按以下原则使用保护 Newton 法:

1. 从当前点提出 Newton 候选  $x_N = x_k - \frac{f(x_k)}{f'(x_k)}$ ;
2. 若  $x_N \notin [a_k, b_k]$ 、导数过小或残差下降不足, 则改用中点;



3. 用新点函数值更新异号区间;

4. 根附近 Newton 步稳定后, 通常连续接受完整 Newton 步。

该方法同时继承:

- 二分法的全局包围性;
- Newton 法的局部二次收敛。

反例 5.9 (纯 Newton 法可能形成周期轨道). 考虑  $f(x) = x^3 - 2x + 2$ . Newton 迭代为  $x_{k+1} = x_k - \frac{x_k^3 - 2x_k + 2}{3x_k^2 - 2}$ . 若  $x_0 = 0$ , 则  $x_1 = 0 - \frac{2}{-2} = 1$ . 而  $x_2 = 1 - \frac{1}{1} = 0$ . 所以  $0 \longleftrightarrow 1$  形成二周期, 迭代不收敛到任何根。

## 5.6 正式真题 [24F-Q3]——Kepler 方程、全局不动点与单调 Newton 法

### 完整题目叙述

[24F-Q3] 考虑 Kepler 方程

$$f(x) = x - \varepsilon \sin x - \eta, \quad 0 < |\varepsilon| < 1, \quad \eta \in \mathbb{R}. \quad (5.35)$$

- (i) 证明对每组  $\varepsilon, \eta$ , 方程恰有一个实根  $\alpha = \alpha(\varepsilon, \eta)$ , 并证明  $\eta - |\varepsilon| \leq \alpha \leq \eta + |\varepsilon|$ .
- (ii) 将方程写成不动点形式  $x = \phi(x)$ ,  $\phi(x) = \varepsilon \sin x + \eta$ , 证明迭代  $x_{n+1} = \phi(x_n)$  对任意初值  $x_0 \in \mathbb{R}$  收敛。
- (iii) 设  $m$  为满足  $m\pi < \eta < (m+1)\pi$  的整数。证明 Newton 法从

$$x_0 = \begin{cases} (m+1)\pi, & (-1)^m \varepsilon > 0, \\ m\pi, & \text{否则} \end{cases} \quad (5.36)$$

出发, 必单调收敛到  $\alpha$ 。

第 (i) 问详细解答. 有

$$f'(x) = 1 - \varepsilon \cos x. \quad (5.37)$$

由于  $|\varepsilon \cos x| \leq |\varepsilon| < 1$ , 故

$$f'(x) \geq 1 - |\varepsilon| > 0. \quad (5.38)$$

所以  $f$  在  $\mathbb{R}$  上严格单调递增。


又因为  $f(x) = x + O(1)$ ,  $|x| \rightarrow \infty$ , 所以  $\lim_{x \rightarrow -\infty} f(x) = -\infty$ ,  $\lim_{x \rightarrow +\infty} f(x) = +\infty$ . 由介值定理存在实根, 再由严格单调性知实根唯一。

根满足  $\alpha - \varepsilon \sin \alpha - \eta = 0$ , 即  $\alpha - \eta = \varepsilon \sin \alpha$ . 因此  $|\alpha - \eta| = |\varepsilon| |\sin \alpha| \leq |\varepsilon|$ , 从而  $\eta - |\varepsilon| \leq \alpha \leq \eta + |\varepsilon|$ 。

□

第 (ii) 问详细解答. 定义  $\phi(x) = \varepsilon \sin x + \eta$ . 对任意  $x, y \in \mathbb{R}$ ,

$$\begin{aligned} |\phi(x) - \phi(y)| &= |\varepsilon| |\sin x - \sin y| \\ &\leq |\varepsilon| |x - y|. \end{aligned}$$



由于  $|\varepsilon| < 1$ ,  $\phi: \mathbb{R} \rightarrow \mathbb{R}$  是全局压缩映射, 压缩常数为  $q = |\varepsilon|$ 。由 Banach 不动点定理,  $\phi$  具有唯一不动点, 且任意  $x_0 \in \mathbb{R}$  生成的迭代均收敛到该不动点。

不动点方程  $x = \varepsilon \sin x + \eta$  与  $f(x) = 0$  等价, 所以该不动点就是唯一根  $\alpha$ 。

此外,

$$|x_n - \alpha| \leq |\varepsilon|^n |x_0 - \alpha|, \quad (5.39)$$

故迭代至少全局  $R$ -线性收敛。若  $|\varepsilon \cos \alpha| \neq 0$ , 则其局部  $Q$ -线性渐近因子为  $|\phi'(\alpha)| = |\varepsilon \cos \alpha|$ 。□

第 (iii) 问详细解答. 首先,  $f(m\pi) = m\pi - \eta < 0$ , 而  $f((m+1)\pi) = (m+1)\pi - \eta > 0$ 。由  $f$  严格递增,

$$\alpha \in (m\pi, (m+1)\pi). \quad (5.40)$$

二阶导数为

$$f''(x) = \varepsilon \sin x. \quad (5.41)$$

在区间  $(m\pi, (m+1)\pi)$  内,  $\operatorname{sgn}(\sin x) = (-1)^m$ 。故  $\operatorname{sgn}(f''(x)) = \operatorname{sgn}((-1)^m \varepsilon)$  在整个开区间内保持不变。

情形一:  $(-1)^m \varepsilon > 0$  此时  $f''(x) > 0$ , 函数在该区间上严格凸。题目选择  $x_0 = (m+1)\pi > \alpha$ , 且  $f(x_0) > 0$ 。

设  $x_k > \alpha$ 。由于  $f$  凸, 其图像位于任一切线之上:  $f(\alpha) \geq f(x_k) + f'(x_k)(\alpha - x_k)$ 。利用  $f(\alpha) = 0$  和  $f'(x_k) > 0$ ,  $\frac{f(x_k)}{f'(x_k)} \leq x_k - \alpha$ 。因此  $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} \geq \alpha$ 。又因  $f(x_k) > 0$ ,  $x_{k+1} < x_k$ 。故  $\alpha \leq x_{k+1} < x_k$ 。由归纳,  $\{x_k\}$  单调递减且以下界  $\alpha$  有界, 所以存在极限  $L \geq \alpha$ 。令  $k \rightarrow \infty$ , 由  $f'(x) \geq 1 - |\varepsilon| > 0$ ,  $L = L - \frac{f(L)}{f'(L)}$ , 故  $f(L) = 0$ 。根唯一, 所以  $L = \alpha$ 。

情形二:  $(-1)^m \varepsilon < 0$  此时  $f''(x) < 0$ , 函数在区间上严格凹。题目选择  $x_0 = m\pi < \alpha$ , 且  $f(x_0) < 0$ 。

若  $x_k < \alpha$ , 由凹函数图像位于切线之下,  $f(\alpha) \leq f(x_k) + f'(x_k)(\alpha - x_k)$ 。因此  $-\frac{f(x_k)}{f'(x_k)} \leq \alpha - x_k$ 。从而  $x_k < x_{k+1} \leq \alpha$ 。故  $\{x_k\}$  单调递增且以上界  $\alpha$  有界。同样取极限可得极限是唯一根  $\alpha$ 。

综上, 题设初值选择保证 Newton 迭代单调收敛到  $\alpha$ 。由于  $\alpha$  为简单根, 进入根邻域后还具有二次收敛。□

#### 易错点与反例

只写  $f(x_0)f''(x_0) > 0$  并引用“Newton 单调收敛定理”通常不足以获得满分。应说明  $f''$  在包含根和初值的整个区间上不变号, 并证明 Newton 点不会越过根。

## 5.7 割线法: 差商近似、误差方程与黄金分割阶

### 5.7.1 知识点七: 割线法的构造

Newton 法中的导数以两点差商近似:  $f'(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$ 。得到割线法

$$x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k), \quad k \geq 1. \quad (5.42)$$

它需要两个初始点  $x_0, x_1$ 。在实现中应缓存  $f(x_{k-1})$  与  $f(x_k)$ , 因此每步只需一个新的函数值。

#### Algorithm 17 割线法



**Input:**  $f$ ; 两个初值  $x_0, x_1$ ; 位置容差  $\text{tol}_x$ ; 残差容差  $\text{tol}_f$ ; 差商分母阈值  $\text{tol}_d$ ; 最大迭代次数  $K_{\max}$

**Output:** 根近似

```

1: Initialization:  $f_0 \leftarrow f(x_0), f_1 \leftarrow f(x_1)$ 
2: for  $k = 1, 2, \dots, K_{\max}$  do
3:    $d_k \leftarrow f_k - f_{k-1}$ 
4:   if  $|d_k| \leq \text{tol}_d$  then
5:     报告“差商分母过小”并终止
6:   end if
7:    $x_{k+1} \leftarrow x_k - f_k \frac{x_k - x_{k-1}}{d_k}$ 
8:    $f_{k+1} \leftarrow f(x_{k+1})$ 
9:   if  $|f_{k+1}| \leq \text{tol}_f$  且  $|x_{k+1} - x_k| \leq \text{tol}_x(1 + |x_{k+1}|)$  then
10:    return  $x_{k+1}$ 
11:  end if
12:  滚动更新  $(x_{k-1}, f_{k-1}) \leftarrow (x_k, f_k)$ 
13:   $(x_k, f_k) \leftarrow (x_{k+1}, f_{k+1})$ 
14: end for
15: Stopping criterion: 同时检查残差、步长和差商分母
16: Complexity: 初始化后每步一个新函数值; 运算与存储均为  $O(1)$ 

```

### 5.7.2 割线法的精确误差恒等式

记一阶和二阶差商为  $f[x, y] = \frac{f(x) - f(y)}{x - y}$ ,  $f[x, y, z] = \frac{f[x, y] - f[x, z]}{y - z}$ 。二阶差商关于节点对称。

设  $x^*$  为简单根。由  $f(x_k) = f[x_k, x^*](x_k - x^*)$ , 以及  $f(x_k) - f(x_{k-1}) = f[x_k, x_{k-1}](x_k - x_{k-1})$ , 割线公式可写为  $x_{k+1} = x_k - \frac{f(x_k)}{f[x_k, x_{k-1}]}$ 。因此

$$\begin{aligned}
 e_{k+1} &= e_k - \frac{f[x_k, x^*]e_k}{f[x_k, x_{k-1}]} \\
 &= e_k \frac{f[x_k, x_{k-1}] - f[x_k, x^*]}{f[x_k, x_{k-1}]} \\
 &= \frac{f[x_k, x_{k-1}, x^*]}{f[x_k, x_{k-1}]} e_k e_{k-1}.
 \end{aligned} \tag{5.43}$$

若  $f \in C^2$  且  $x_k, x_{k-1} \rightarrow x^*$ , 则  $f[x_k, x_{k-1}] \rightarrow f'(x^*)$ ,  $f[x_k, x_{k-1}, x^*] \rightarrow \frac{1}{2}f''(x^*)$ 。于是


$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k e_{k-1}} = \frac{f''(x^*)}{2f'(x^*)}. \tag{5.44}$$

### 5.7.3 局部收敛证明

由于  $f'(x^*) \neq 0$ , 可选择邻域  $D$  使  $|f[x, y]| \geq m_1 > 0$ ,  $x, y \in D$ , 同时  $|f[x, y, z]| \leq M_2$ ,  $x, y, z \in D$ 。于是

$$|e_{k+1}| \leq K|e_k||e_{k-1}|, \quad K = \frac{M_2}{m_1}. \tag{5.45}$$

取  $\delta > 0$  使  $K\delta < q < 1$ 。若  $|e_0| \leq \delta$ ,  $|e_1| \leq \delta$ , 则归纳可得所有迭代均留在邻域内, 并且  $|e_{k+1}| \leq q|e_k|$ 。故  $x_k \rightarrow x^*$ 。



## 5.7.4 黄金分割收敛阶

设一般情形下  $C_* = \frac{f''(x^*)}{2f'(x^*)} \neq 0$ 。由  $|e_{k+1}| \sim |C_*||e_k||e_{k-1}|$ ，若收敛阶为  $p$ ，形式上有  $|e_k| \asymp |e_{k-1}|^p$ ， $|e_{k+1}| \asymp |e_k|^p$ 。比较  $|e_{k-1}|$  的幂次： $p^2 = p + 1$ 。取  $p > 1$  的根，

$$p = \frac{1 + \sqrt{5}}{2} \approx 1.618. \quad (5.46)$$

因此割线法超线性，但慢于 Newton 法的二次收敛。

若用标准  $Q$ -阶常数定义，则在适当非退化条件下  $\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = |C_*|^{1/p}$ 。

## 易错点与反例

割线法不是二次收敛。其误差含两个连续误差的乘积： $e_{k+1} \sim C_* e_k e_{k-1}$ ，由此得到的阶是黄金分割数，而不是 2。

## 5.8 正式真题 [23F-Q1]——Newton 法与割线法误差极限

## 完整题目叙述

[23F-Q1] 设  $f \in C^2(a, b)$ ,  $x^* \in (a, b)$ ,  $f(x^*) = 0$ 。

- (1) 对 Newton 迭代  $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$ ，证明：若  $x_0$  充分接近  $x^*$  且  $f'(x^*) \neq 0$ ，则  $x_k \rightarrow x^*$  并且  $\lim_{k \rightarrow \infty} \frac{x_{k+1} - x^*}{(x_k - x^*)^2} = \frac{f''(x^*)}{2f'(x^*)}$ 。
- (2) 当导数难以计算时，使用割线迭代  $x_{k+1} = x_k - \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})} f(x_k)$ 。证明：当两个初始点  $x_0, x_1$  均充分接近  $x^*$  时， $x_k \rightarrow x^*$  且  $\lim_{k \rightarrow \infty} \frac{x_{k+1} - x^*}{(x_k - x^*)(x_{k-1} - x^*)} = \frac{f''(x^*)}{2f'(x^*)}$ 。

原试卷第 (2) 问文字中只简写了“ $x_0$  充分接近”，但割线法是二步法，严格表述必须要求两个起步值  $x_0, x_1$  均位于适当邻域内。

第 (1) 问详细解答. 由  $f'(x^*) \neq 0$  及  $f'$  连续，存在  $r > 0$  与  $m_1 > 0$  使  $|f'(x)| \geq m_1$ ,  $|x - x^*| \leq r$ 。再令  $M_2 = \max_{|x - x^*| \leq r} |f''(x)|$ 。缩小  $r$  使  $\frac{M_2 r}{2m_1} < 1$ 。

令  $e_k = x_k - x^*$ 。Taylor 公式给出某个  $\xi_k$  位于  $x_k$  与  $x^*$  之间，使  $0 = f(x_k) - f'(x_k)e_k + \frac{1}{2}f''(\xi_k)e_k^2$ 。故  $e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)}e_k^2$ 。因此  $|e_{k+1}| \leq \frac{M_2}{2m_1}|e_k|^2$ 。当  $|e_0| \leq r$  时，邻域不变，且误差收缩，故  $x_k \rightarrow x^*$ 。

再由  $\xi_k \rightarrow x^*$ ,  $x_k \rightarrow x^*$ ，有  $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^2} = \frac{f''(x^*)}{2f'(x^*)}$ 。□

第 (2) 问详细解答. 由  $x^*$  为简单根，可选邻域  $D$  使  $f'$  在  $D$  内不变号并远离零。因此对任意不同的  $x, y \in D$ ,  $f[x, y] \neq 0$ ，割线迭代有定义。

由差商恒等式， $e_{k+1} = \frac{f[x_k, x_{k-1}, x^*]}{f[x_k, x_{k-1}]} e_k e_{k-1}$ 。在足够小的邻域内，存在常数  $K$  使  $|e_{k+1}| \leq K|e_k||e_{k-1}|$ 。取  $\delta > 0$  使  $K\delta < 1$ 。若  $|e_0| \leq \delta$ ,  $|e_1| \leq \delta$ ，则归纳得到所有误差均不超过  $\delta$ ，且  $|e_{k+1}| \leq K\delta|e_k|$ 。所以  $x_k \rightarrow x^*$ 。

由于  $f \in C^2$ ,  $f[x_k, x_{k-1}] \rightarrow f'(x^*)$ ,  $f[x_k, x_{k-1}, x^*] \rightarrow \frac{1}{2}f''(x^*)$ 。故  $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k e_{k-1}} = \frac{f''(x^*)}{2f'(x^*)}$ 。

若  $f''(x^*) \neq 0$ ，则进一步可得割线法的一般收敛阶为  $\frac{1+\sqrt{5}}{2}$ 。□

## 5.9 补充训练题：丘赛 2020 Problem 2——固定锚点弦截迭代

## 完整题目叙述

设  $f$  二次连续可微，考虑迭代

$$x_{n+1} = x_n - \left( \frac{x_n - x_0}{f(x_n) - f(x_0)} \right) f(x_n), \quad (5.47)$$

用于求  $f(x) = 0$  的根。假设该方法收敛到简单根  $x^*$ ，求其收敛速度并说明理由。

严格地说，原式在  $n = 0$  时形成  $0/0$ 。应将  $x_0$  理解为固定锚点，并另给  $x_1 \neq x_0$ ，从  $n = 1$  开始迭代。

详细解答. 固定锚点记为  $a := x_0$ 。迭代函数为

$$\Phi(x) = x - \frac{x - a}{f(x) - f(a)} f(x). \quad (5.48)$$

因为  $f(x^*) = 0$ ,  $\Phi(x^*) = x^*$ 。

令  $G(x) = \frac{(x-a)f(x)}{f(x)-f(a)}$ 。在  $x = x^*$  处,  $G'(x^*) = \frac{(x^*-a)f'(x^*)}{-f(a)} = \frac{f'(x^*)}{f[a, x^]}$ , 其中  $f[a, x^*] = \frac{f(a)-f(x^*)}{a-x^*} = \frac{f(a)}{a-x^*}$ 。因此

$$\Phi'(x^*) = 1 - \frac{f'(x^*)}{f[a, x^*]}. \quad (5.49)$$

若

$$q := \left| 1 - \frac{f'(x^*)}{f[a, x^*]} \right| \in (0, 1), \quad (5.50)$$

则该方法局部  $Q$ -线性收敛，渐近因子为  $q$ ：

$$\lim_{n \rightarrow \infty} \frac{|x_{n+1} - x^*|}{|x_n - x^*|} = \left| 1 - \frac{f'(x^*)}{f[x_0, x^*]} \right|. \quad (5.51)$$

若锚点  $x_0$  接近  $x^*$ ，由差商展开  $f[x_0, x^*] = f'(x^*) + \frac{1}{2}f''(x^*)(x_0 - x^*) + o(|x_0 - x^*|)$ ，故

$$\Phi'(x^*) = \frac{f''(x^*)}{2f'(x^*)}(x_0 - x^*) + o(|x_0 - x^*|). \quad (5.52)$$

这说明锚点越接近根，线性因子通常越小，但在整个迭代中锚点固定，所以一般不会获得割线法的超线性阶。

若恰有  $\Phi'(x^*) = 0$ ，则线性主项消失，应继续检查  $\Phi''(x^*)$ ；此时可能达到二次或更高阶。对一般非退化函数，题目答案为线性收敛。□

注 5.10. 本方法每次使用当前点与同一个固定锚点形成割线；标准割线法使用连续两步  $x_{n-1}, x_n$ ，其差商随迭代一起逼近  $f'(x^*)$ ，因而具有超线性收敛。两者不能混淆。

## 5.10 正式真题 [26S-Q1]——自适应差分 Newton 型迭代

## 完整题目叙述

[26S-Q1] 设  $f \in C^2(\mathbb{R})$ ，并假设在  $x^*$  附近  $f$  有唯一零点，且  $f'(x^*) \neq 0$ 。考虑迭代

$$x_{k+1} = x_k - \frac{[f(x_k)]^2}{f(x_k + f(x_k)) - f(x_k)}, \quad k = 0, 1, \dots \quad (5.53)$$

证明  $x_k \rightarrow x^*$ ，并估计其局部收敛阶。

分母有定义与方法解释. 若  $f(x_k) \neq 0$ , 由中值定理, 存在  $\theta_k \in (0, 1)$  使

$$f(x_k + f(x_k)) - f(x_k) = f'(x_k + \theta_k f(x_k))f(x_k). \quad (5.54)$$

因此迭代可写为

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k + \theta_k f(x_k))}. \quad (5.55)$$

它相当于用自适应步长  $h_k = f(x_k)$  的前向差商近似  $f'(x_k)$ :  $f'(x_k) \approx \frac{f(x_k + f(x_k)) - f(x_k)}{f(x_k)}$ .

当  $x_k \rightarrow x^*$  时,  $x_k + \theta_k f(x_k) \rightarrow x^*$ . 由  $f'(x^*) \neq 0$ , 在充分小的根邻域内,  $f'(x_k + \theta_k f(x_k)) \neq 0$ , 故分母不为零. 若某一步  $f(x_k) = 0$ , 算法应立即停止, 而不应继续计算原式中的  $0/0$ .  $\square$

局部误差展开. 记  $e_k = x_k - x^*$ ,  $a = f'(x^*) \neq 0$ ,  $b = \frac{1}{2}f''(x^*)$ . 由  $f \in C^2$ ,

$$f(x^* + e) = ae + be^2 + o(e^2). \quad (5.56)$$

于是

$$\begin{aligned} x + f(x) - x^* &= e + ae + be^2 + o(e^2) \\ &= (1+a)e + be^2 + o(e^2). \end{aligned} \quad (5.57)$$

再次使用式 (5.56),

$$\begin{aligned} f(x + f(x)) &= a((1+a)e + be^2) + b(1+a)^2e^2 + o(e^2) \\ &= a(1+a)e + (ab + b(1+a)^2)e^2 + o(e^2). \end{aligned} \quad (5.58)$$

减去  $f(x)$ :

$$f(x + f(x)) - f(x) = a^2e + ba(a+3)e^2 + o(e^2). \quad (5.59)$$

而

$$f(x)^2 = a^2e^2 + 2abe^3 + o(e^3). \quad (5.60)$$

作级数相除:

$$\frac{f(x)^2}{f(x + f(x)) - f(x)} = e - \frac{b(a+1)}{a}e^2 + o(e^2). \quad (5.61)$$

故

$$\begin{aligned} e_{k+1} &= e_k - \frac{f(x_k)^2}{f(x_k + f(x_k)) - f(x_k)} \\ &= \frac{b(a+1)}{a}e_k^2 + o(e_k^2). \end{aligned} \quad (5.62)$$

代回  $a, b$ :

$$e_{k+1} = \frac{(1 + f'(x^*))f''(x^*)}{2f'(x^*)}e_k^2 + o(e_k^2). \quad (5.63)$$


因此该方法至少局部二次收敛. 若

$$(1 + f'(x^*))f''(x^*) \neq 0, \quad (5.64)$$

则恰为二次收敛, 渐近误差常数为

$$\left| \frac{1 + f'(x^*)|f''(x^*)|}{2|f'(x^*)|} \right|. \quad (5.65)$$

若  $f''(x^*) = 0$  或  $f'(x^*) = -1$ , 二次主项消失. 由  $f \in C^2$  只能严格断言  $e_{k+1} = o(e_k^2)$ ; 若要确定是否三次或更高阶, 需要额外高阶光滑性和进一步展开.  $\square$



局部收敛性. 由式 (5.63), 存在  $\delta > 0$  及  $C > 0$ , 使  $|e_{k+1}| \leq C|e_k|^2$ ,  $|e_k| \leq \delta$ . 进一步缩小  $\delta$  使  $C\delta \leq \frac{1}{2}$ . 则  $|e_{k+1}| \leq \frac{1}{2}|e_k| \leq \delta$ . 故根邻域对迭代不变, 并且  $e_k \rightarrow 0$ , 即  $x_k \rightarrow x^*$ .  $\square$

【复杂度与数值稳定性】 每步计算:

- $f(x_k)$  一次;
- $f(x_k + f(x_k))$  一次。

因此每步需要两个函数值, 不需要显式导数。

但当  $f(x_k)$  很小时,  $f(x_k + f(x_k)) - f(x_k)$  是两个相近数之差, 可能发生灾难性消去。数学上的二次收敛不等于浮点实现自动稳定。接近机器精度时应:

- 在残差足够小时停止;
- 若可行, 使用稳定的差商实现;
- 避免在  $f(x_k) = 0$  时计算  $0/0$ ;
- 同时监视差分分母与步长。

## 5.11 重根、修正 Newton 法与未知重数加速

### 5.11.1 知识点八: 普通 Newton 法在重根处退化为线性收敛

设  $f(x) = (x - x^*)^m g(x)$ ,  $m \geq 2$ ,  $g(x^*) \neq 0$ . 记  $e_k = x_k - x^*$ . 有  $f'(x) = (x - x^*)^{m-1} [mg(x) + (x - x^*)g'(x)]$ . 普通 Newton 法给出

$$e_{k+1} = e_k - \frac{e_k^m g(x_k)}{e_k^{m-1} [mg(x_k) + e_k g'(x_k)]} = e_k \frac{(m-1)g(x_k) + e_k g'(x_k)}{mg(x_k) + e_k g'(x_k)}. \quad (5.66)$$

因此

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k} = \frac{m-1}{m}. \quad (5.67)$$

普通 Newton 法在  $m$  重根处通常只有线性收敛, 因子为  $1 - \frac{1}{m}$ . 重数越大, 收敛越慢。

若  $g \in C^1$ , 进一步展开可得

$$e_{k+1} = \frac{m-1}{m} e_k + \frac{g'(x^*)}{m^2 g(x^*)} e_k^2 + O(e_k^3). \quad (5.68)$$

### 5.11.2 已知重数的修正 Newton 法

若  $m$  已知, 采用

$$x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}. \quad (5.69)$$


利用上式因式分解,

$$e_{k+1} = e_k - m \frac{e_k g(x_k)}{mg(x_k) + e_k g'(x_k)} = \frac{e_k^2 g'(x_k)}{mg(x_k) + e_k g'(x_k)}. \quad (5.70)$$

所以

$$\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^2} = \frac{g'(x^*)}{mg(x^*)}. \quad (5.71)$$

在一般非退化情况下恢复二次收敛。



## 5.11.3 未知重数时的自适应 Newton 法

定义

$$u(x) = \frac{f(x)}{f'(x)}. \quad (5.72)$$

对  $m$  重根,  $u(x) = \frac{x-x^*}{m} + O((x-x^*)^2)$ , 故  $x^*$  是  $u$  的简单根。对  $u(x) = 0$  应用普通 Newton 法:

$$x_{k+1} = x_k - \frac{u(x_k)}{u'(x_k)}. \quad (5.73)$$

由于  $u'(x) = \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2}$ , 得到

$$x_{k+1} = x_k - \frac{f(x_k)f'(x_k)}{[f'(x_k)]^2 - f(x_k)f''(x_k)}. \quad (5.74)$$

这不需要预先知道  $m$ , 并在标准光滑与非退化条件下二次收敛。

也可定义自适应重数估计

$$\hat{m}_k = \frac{[f'(x_k)]^2}{[f'(x_k)]^2 - f(x_k)f''(x_k)}. \quad (5.75)$$

则  $\hat{m}_k \rightarrow m$ , 且  $x_{k+1} = x_k - \hat{m}_k \frac{f(x_k)}{f'(x_k)}$  与式 (5.74) 完全相同。

## 【复杂度】

- 普通 Newton 与已知重数修正 Newton: 每步  $f, f'$  各一次;
- 未知重数公式: 每步需要  $f, f', f''$ ;
- 若  $f''$  计算昂贵, 可通过自动微分、差分或其他重数估计替代, 但需重新分析稳定性。

## 易错点与反例

正则性不能遗漏。

若只知道  $f \in C^1$  和简单根条件, 不能无条件推出 Newton 二次收敛; 通常需要  $f'$  局部 Lipschitz, 例如  $f \in C^2$ 。

对  $m$  重根, 若要从  $f = (x-x^*)^m g$  推出修正 Newton 的二次误差公式, 需要  $g$  至少在根附近一阶可微且导数有界。一个方便的充分条件是  $f \in C^{m+1}$ 。

## 5.12 正式真题 [25S-Q2]——简单根、重根与未知重数加速

## 完整题目叙述

[25S-Q2] 设  $f$  连续且具有相应阶数的导数, 并满足  $f(\alpha) = f'(\alpha) = \cdots = f^{(m-1)}(\alpha) = 0, f^{(m)}(\alpha) \neq 0$ 。

- 当  $m = 1$ , 即  $\alpha$  为简单根时, 证明存在邻域  $D(\alpha, \delta) = \{x : |x - \alpha| \leq \delta\}$ , 使任意  $x_0 \in D(\alpha, \delta)$  生成的 Newton 迭代收敛到  $\alpha$ , 且收敛阶为二次。
- 当  $m > 1$  时, 求普通 Newton 法的收敛阶; 再分析修正 Newton 法  $x_{k+1} = x_k - m \frac{f(x_k)}{f'(x_k)}$ 。
- 当  $m > 1$  但具体重数未知时, 提出一个超线性收敛的迭代方法。原题说明本问不要求证明。

注 5.11 (原题正则性的严格补充). 按题面字面, 当  $m = 1$  时只给出  $C^1$  正则性不足以保证二次收敛。以下按数值分析中的标准意图补充:



- 简单根部分假设  $f'$  局部 Lipschitz, 例如  $f \in C^2$ ;
- 重根修正部分假设  $f(x) = (x - \alpha)^m g(x)$ ,  $g \in C^1$ ,  $g(\alpha) \neq 0$ .

这些是所要求二次结论的必要技术条件, 而不是对题意范围的扩张。

第 (i) 问详细解答. 由  $f'(\alpha) \neq 0$  和  $f'$  连续, 存在  $\delta > 0$  使  $m_1 := \min_{|x-\alpha| \leq \delta} |f'(x)| > 0$ . 再令  $M_2 := \max_{|x-\alpha| \leq \delta} |f''(x)|$ . 缩小  $\delta$  使  $\frac{M_2 \delta}{2m_1} < 1$ . 令  $e_k = x_k - \alpha$ . 与定义 5.8 相同, 存在  $\xi_k$  位于  $x_k$  与  $\alpha$  之间, 使  $e_{k+1} = \frac{f''(\xi_k)}{2f'(x_k)} e_k^2$ . 因此根邻域不变,  $e_k \rightarrow 0$ , 并且  $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^2} = \frac{f''(\alpha)}{2f'(\alpha)}$ . 故 Newton 法局部二次收敛.  $\square$

第 (ii) 问详细解答. 因为  $\alpha$  是  $m$  重根, 可写  $f(x) = (x - \alpha)^m g(x)$ ,  $g(\alpha) \neq 0$ . 普通 Newton 误差为  $e_{k+1} = e_k \frac{(m-1)g(x_k) + e_k g'(x_k)}{mg(x_k) + e_k g'(x_k)}$ . 令  $k \rightarrow \infty$ :  $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k} = \frac{m-1}{m}$ . 所以普通 Newton 法为线性收敛, 渐近因子为  $\frac{m-1}{m}$ .

对修正 Newton 法,  $e_{k+1} = e_k - m \frac{e_k g(x_k)}{mg(x_k) + e_k g'(x_k)} = \frac{e_k^2 g'(x_k)}{mg(x_k) + e_k g'(x_k)}$ . 因此  $\lim_{k \rightarrow \infty} \frac{e_{k+1}}{e_k^2} = \frac{g'(\alpha)}{mg(\alpha)}$ . 在一般情况下, 修正 Newton 法恢复二次收敛. 若  $g'(\alpha) = 0$ , 则二次主项消失, 可能具有更高阶收敛.  $\square$

第 (iii) 问详细解答. 取  $u(x) = \frac{f(x)}{f'(x)}$ . 由于  $u(x) = \frac{x-\alpha}{m} + O((x-\alpha)^2)$ ,  $\alpha$  是  $u$  的简单根. 对  $u$  使用 Newton 法:  $x_{k+1} = x_k - \frac{u(x_k)}{u'(x_k)}$ . 化简得  $x_{k+1} = x_k - \frac{f(x_k)f'(x_k)}{[f'(x_k)]^2 - f(x_k)f''(x_k)}$ . 该方法不需要知道  $m$ , 在充分光滑条件下二次收敛, 因而满足题目要求的超线性收敛.

等价地, 可写成自适应重数形式  $\hat{m}_k = \frac{[f'(x_k)]^2}{[f'(x_k)]^2 - f(x_k)f''(x_k)}$ ,  $x_{k+1} = x_k - \hat{m}_k \frac{f(x_k)}{f'(x_k)}$ .  $\square$

### 5.13 补充训练题：丘赛 2025 Problem 1——两参数多点 Newton 型方法的最高阶

#### 完整题目叙述

考虑多点迭代

$$x_{k+1} = x_k - \alpha \frac{f(x_k)}{f' \left( x_k - \beta \frac{f(x_k)}{f'(x_k)} \right)}, \quad (5.76)$$

其中  $\alpha, \beta$  为待定参数. 该方法用于求解  $f(x) = 0$ . 设  $\xi$  是  $f$  的简单根. 确定  $\alpha, \beta$ , 使该两参数方法在一般情形下达到尽可能高的局部收敛阶.

详细解答. 为得到三阶展开, 假设  $f$  在  $\xi$  附近至少四次连续可微. 令  $e_k = x_k - \xi$ ,  $a = f'(\xi) \neq 0$ , 并定义归一化 Taylor 系数

$$c_j = \frac{f^{(j)}(\xi)}{j!f'(\xi)}, \quad j \geq 2. \quad (5.77)$$


于是

$$f(x_k) = a(e_k + c_2 e_k^2 + c_3 e_k^3 + O(e_k^4)), \quad (5.78)$$

$$f'(x_k) = a(1 + 2c_2 e_k + 3c_3 e_k^2 + O(e_k^3)). \quad (5.79)$$

先展开 Newton 校正量:

$$\frac{f(x_k)}{f'(x_k)} = e_k - c_2 e_k^2 + (2c_2^2 - 2c_3) e_k^3 + O(e_k^4). \quad (5.80)$$



记导数采样点  $y_k = x_k - \beta \frac{f(x_k)}{f'(x_k)}$ 。则

$$y_k - \xi = (1 - \beta)e_k + \beta c_2 e_k^2 - 2\beta(c_2^2 - c_3)e_k^3 + O(e_k^4). \quad (5.81)$$

将此代入  $f'(y_k)$ :

$$\frac{f'(y_k)}{a} = 1 + 2c_2(1 - \beta)e_k + [2\beta c_2^2 + 3c_3(1 - \beta)^2] e_k^2 + O(e_k^3). \quad (5.82)$$

作级数相除, 得到

$$\begin{aligned} \frac{f(x_k)}{f'(y_k)} &= e_k + c_2(2\beta - 1)e_k^2 \\ &\quad + [(2 - 8\beta + 4\beta^2)c_2^2 + (-2 + 6\beta - 3\beta^2)c_3] e_k^3 \\ &\quad + O(e_k^4). \end{aligned} \quad (5.83)$$

故迭代误差满足

$$\begin{aligned} e_{k+1} &= (1 - \alpha)e_k - \alpha c_2(2\beta - 1)e_k^2 \\ &\quad - \alpha [(2 - 8\beta + 4\beta^2)c_2^2 + (-2 + 6\beta - 3\beta^2)c_3] e_k^3 \\ &\quad + O(e_k^4). \end{aligned} \quad (5.84)$$

要使线性项消失, 必须取

$$\alpha = 1. \quad (5.85)$$

要使对一般  $f$  的二次项消失, 必须取  $2\beta - 1 = 0$ , 即

$$\beta = \frac{1}{2}. \quad (5.86)$$

代入后,  $2 - 8\beta + 4\beta^2 = -1$ ,  $-2 + 6\beta - 3\beta^2 = \frac{1}{4}$ 。所以

$$e_{k+1} = \left(c_2^2 - \frac{1}{4}c_3\right) e_k^3 + O(e_k^4). \quad (5.87)$$

因此最优参数为

$$\boxed{\alpha = 1, \beta = \frac{1}{2}}, \quad (5.88)$$

相应方法为

$$\boxed{x_{k+1} = x_k - \frac{f(x_k)}{f'\left(x_k - \frac{1}{2} \frac{f(x_k)}{f'(x_k)}\right)}}. \quad (5.89)$$

在一般非退化条件  $c_2^2 - \frac{1}{4}c_3 \neq 0$  下, 该方法为三次收敛。

在两参数族内, 消去线性项已经唯一确定  $\alpha = 1$ , 消去二次项又唯一确定  $\beta = 1/2$ 。此后没有剩余自由参数可同时消去一般函数中彼此独立的  $c_2^2$  和  $c_3$  三次项, 故三次是该参数族对一般简单根所能达到的最高阶。

若某个特殊函数满足  $c_2^2 - \frac{1}{4}c_3 = 0$ , 三次主项偶然消失, 可能出现更高阶; 这不改变该两参数方法族的一般最高阶结论。□

**【计算复杂度与实现】** 每一步通常需要:

- 计算  $f(x_k)$ ;

- 计算  $f'(x_k)$  以形成内部 Newton 位移；
- 在位移点再次计算  $f'$ 。

因此每步为一次函数值和两次导数值计算，标量运算与存储均为  $O(1)$ 。

若导数求值成本远高于函数值，则三次收敛并不自动意味着总计算时间优于普通 Newton 法。考试中应将“收敛阶”和“单步成本”分别说明。



## 第六章 非线性方程组、拟 Newton、Broyden、同伦、延拓与多项式求根

### 6.1 非线性方程组的统一框架：Jacobian、正则根与条件数

#### 6.1.1 知识点一：问题、对象空间与正则根

【重要性等级】 **S 级**。非线性方程组 Newton 法是隐式 ODE 方法、有限元非线性离散、约束优化 KKT 系统及许多反问题算法的共同内核。资格考试中最容易失分的不是迭代公式本身，而是遗漏 Jacobian 非奇异、局部 Lipschitz、所用范数和线性系统求解成本。

【问题与目标】 设

$$F : \Omega \subset \mathbb{R}^n \longrightarrow \mathbb{R}^n, F(\mathbf{x}) = \begin{pmatrix} F_1(\mathbf{x}) \\ \vdots \\ F_n(\mathbf{x}) \end{pmatrix}. \quad (6.1)$$

目标是求

$$F(\mathbf{x}^*) = \mathbf{0}. \quad (6.2)$$

本文默认向量采用列向量，并在每个定理中固定一个向量范数  $\|\cdot\|$  及其诱导矩阵范数。若未特别说明，复杂度讨论以稠密实矩阵为基准。

定义 6.1 (Jacobian 矩阵). 若  $F$  在  $\mathbf{x}$  处可微，则其 Jacobian 矩阵定义为

$$J_F(\mathbf{x}) = \left[ \frac{\partial F_i}{\partial x_j}(\mathbf{x}) \right]_{i,j=1}^n. \quad (6.3)$$

Fréchet 可微意味着

$$F(\mathbf{x} + \mathbf{s}) = F(\mathbf{x}) + J_F(\mathbf{x})\mathbf{s} + o(\|\mathbf{s}\|). \quad (6.4)$$

若  $J_F$  局部 Lipschitz，则可加强为

$$F(\mathbf{x} + \mathbf{s}) = F(\mathbf{x}) + J_F(\mathbf{x})\mathbf{s} + O(\|\mathbf{s}\|^2). \quad (6.5)$$

定义 6.2 (正则根与奇异根). 若  $F(\mathbf{x}^*) = \mathbf{0}$ ,  $\det J_F(\mathbf{x}^*) \neq 0$ , 则称  $\mathbf{x}^*$  为正则根或简单根。

若  $\det J_F(\mathbf{x}^*) = 0$ , 则称其为奇异根。奇异根附近可能出现：

- 多个解分支相交；
- 折点或转向点；
- Newton 步无唯一解；



- 根对数据扰动高度敏感；
- 普通 Newton 法失去二次收敛。

【残差、误差与局部条件数】 令近似解为  $\hat{\mathbf{x}}$ ，定义

$\mathbf{e} = \hat{\mathbf{x}} - \mathbf{x}^*$ ,  $\mathbf{r} = F(\hat{\mathbf{x}})$ 。在正则根附近,  $F(\hat{\mathbf{x}}) = J_F(\mathbf{x}^*)\mathbf{e} + O(\|\mathbf{e}\|^2)$ , 因此

$$\mathbf{e} = J_F(\mathbf{x}^*)^{-1}\mathbf{r} + O(\|\mathbf{r}\|^2). \quad (6.6)$$

所以, 以残差扰动为输入、根位移为输出时, 局部绝对条件数为

$$\kappa_{\text{abs}}(\mathbf{x}^*) = \|J_F(\mathbf{x}^*)^{-1}\|. \quad (6.7)$$

若方程含参数  $F(\mathbf{x}, \mathbf{p}) = \mathbf{0}$ , 且  $J_{\mathbf{x}}F(\mathbf{x}^*, \mathbf{p}^*)$  非奇异, 则由隐函数定理

$$\frac{\partial \mathbf{x}^*}{\partial \mathbf{p}} = -J_{\mathbf{x}}F(\mathbf{x}^*, \mathbf{p}^*)^{-1}J_{\mathbf{p}}F(\mathbf{x}^*, \mathbf{p}^*). \quad (6.8)$$

#### 易错点与反例

小残差不自动意味着小误差。

只有当  $\|J_F(\mathbf{x}^*)^{-1}\|$  适中, 并且  $\hat{\mathbf{x}}$  已处于局部线性化有效邻域时, 才能由式 (6.6) 把残差转化为误差。

若 Jacobian 接近奇异, 则可能出现  $\|F(\hat{\mathbf{x}})\| \ll 1$ ,  $\|\hat{\mathbf{x}} - \mathbf{x}^*\| \not\ll 1$ 。这属于问题病态, 不是单纯改变停止准则可以消除的。

### 6.1.2 知识点二：向量不动点迭代

将方程改写为

$$\mathbf{x} = \Phi(\mathbf{x}), \Phi: \Omega \rightarrow \Omega. \quad (6.9)$$

相应迭代为

$$\mathbf{x}^{(k+1)} = \Phi(\mathbf{x}^{(k)}). \quad (6.10)$$

若存在闭集  $D \subset \Omega$  及  $q < 1$  使

$$\Phi(D) \subset D, \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\| \leq q \|\mathbf{x} - \mathbf{y}\|, \quad (6.11)$$

则 Banach 不动点定理给出唯一不动点及从任意  $\mathbf{x}^{(0)} \in D$  出发的收敛性。

若  $\Phi$  连续可微, 常用充分条件为

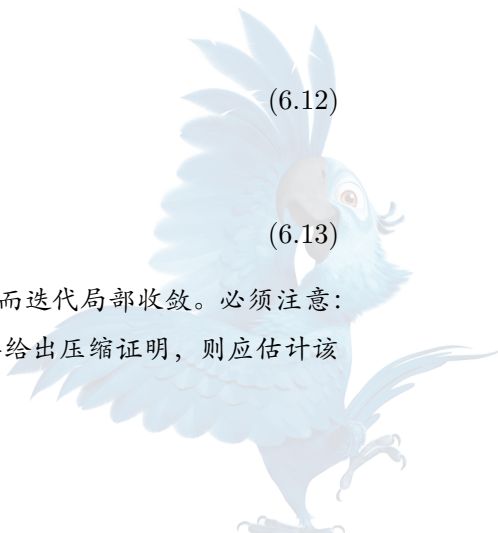
$$\sup_{\mathbf{x} \in D} \|J_{\Phi}(\mathbf{x})\| \leq q < 1. \quad (6.12)$$

局部而言, 若

$$\rho(J_{\Phi}(\mathbf{x}^*)) < 1, \quad (6.13)$$

则存在某个与欧氏范数等价的向量范数, 使相应诱导矩阵范数小于 1, 从而迭代局部收敛。必须注意:

$\rho(J_{\Phi}(\mathbf{x}^*)) < 1$  是局部线性化条件; 若要用指定的  $\ell^\infty$  或  $\ell^2$  范数直接给出压缩证明, 则应估计该指定范数下的矩阵范数。



## 6.1.3 知识点三：非线性 Jacobi 型与 Gauss-Seidel 型迭代

$$\text{设 } \Phi(\mathbf{x}) = \begin{pmatrix} \phi_1(\mathbf{x}) \\ \vdots \\ \phi_n(\mathbf{x}) \end{pmatrix}.$$

**Jacobi 型** 固定点迭代 所有分量同时使用旧迭代值：

$$x_i^{(k+1)} = \phi_i(x_1^{(k)}, \dots, x_n^{(k)}), \quad i = 1, \dots, n. \quad (6.14)$$

各分量可并行计算。

**Gauss-Seidel 型** 固定点迭代 在同一轮内立即使用已经更新的分量：

$$x_i^{(k+1)} = \phi_i(x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}, x_i^{(k)}, \dots, x_n^{(k)}). \quad (6.15)$$

该方法通常不能完全并行，但可能具有更好的收敛因子。

还可直接从方程  $F_i(x_1, \dots, x_n) = 0$  构造非线性坐标求解型迭代：

- Jacobi 型：固定其余全部旧分量，对每个  $i$  求标量方程  $F_i(x_1^{(k)}, \dots, x_{i-1}^{(k)}, u, x_{i+1}^{(k)}, \dots, x_n^{(k)}) = 0$ ；
- Gauss-Seidel 型：对第  $i$  个方程，使用本轮已更新的  $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 。

**Algorithm 18** 非线性 Gauss-Seidel 坐标求解

**Input:** 方程组  $F_i(\mathbf{x}) = 0$ ；初值  $\mathbf{x}^{(0)}$ ；内层标量求根器；外层容差  $\text{tol}$ ；最大迭代次数  $K_{\max}$

**Output:** 方程组近似解

```

1: for  $k = 0, 1, \dots, K_{\max} - 1$  do
2:    $\mathbf{x}^{(k+1)} \leftarrow \mathbf{x}^{(k)}$ 
3:   for  $i = 1, \dots, n$  do
4:     固定  $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}, x_{i+1}^{(k)}, \dots, x_n^{(k)}$ 
5:     用标量求根器解  $F_i(x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}, u, x_{i+1}^{(k)}, \dots, x_n^{(k)}) = 0$ 
6:      $x_i^{(k+1)} \leftarrow u$ 
7:   end for
8:   if  $\|F(\mathbf{x}^{(k+1)})\| \leq \text{tol}$  then
9:     return  $\mathbf{x}^{(k+1)}$ 
10:  end if
11: end for
12: 报告“外层未收敛或内层标量方程求解失败”
13: Stopping criterion: 外层残差与步长均应监视
14: Complexity: 每轮需要  $n$  次标量求根；成本取决于各坐标方程；Jacobi 型易并行，Gauss-Seidel
    型顺序依赖

```

**易错点与反例**

拟 Newton 法与有限差分 Jacobian 不是同一概念。

有限差分 Jacobian 在某个迭代点重新近似各偏导数，例如  $\frac{\partial F}{\partial x_j}(\mathbf{x}) \approx \frac{F(\mathbf{x} + h_j \mathbf{e}_j) - F(\mathbf{x})}{h_j}$ 。它通常需要每次刷新时额外计算  $O(n)$  个函数值。

Broyden 法则保留旧矩阵信息，只通过本次实际位移方向上的一个割线条件作秩一更新。



## 6.2 补充训练题：丘赛 2022 Problem 2——二维 Gauss-Seidel 型固定点迭代

### 完整题目叙述

考虑二维固定点迭代

$$x_{k+1} = f(x_k, y_k), \quad y_{k+1} = g(x_k, y_k). \quad (6.16)$$

设向量函数  $H(x, y) = \begin{pmatrix} f(x, y) \\ g(x, y) \end{pmatrix}$  连续可微，并在唯一不动点  $(x_\infty, y_\infty)$  处满足

$$\|J_H(x_\infty, y_\infty)\|_\infty < 1. \quad (6.17)$$

现考虑新的顺序迭代

$$x_{k+1} = f(x_k, y_k), \quad y_{k+1} = g(x_{k+1}, y_k). \quad (6.18)$$

证明：当初值充分接近  $(x_\infty, y_\infty)$  时，迭代式 (6.18) 收敛到与原迭代相同的不动点。

详细解答. 记  $\mathbf{z}_\infty = (x_\infty, y_\infty)^\top$ . 在该点记偏导数

$$a = f_x(\mathbf{z}_\infty), \quad b = f_y(\mathbf{z}_\infty), \quad c = g_x(\mathbf{z}_\infty), \quad d = g_y(\mathbf{z}_\infty). \quad (6.19)$$

于是

$$J_H(\mathbf{z}_\infty) = \begin{pmatrix} a & b \\ c & d \end{pmatrix}. \quad (6.20)$$

由无穷范数定义，

$$q := \|J_H(\mathbf{z}_\infty)\|_\infty = \max\{|a| + |b|, |c| + |d|\} < 1. \quad (6.21)$$

把顺序迭代写成一个普通向量固定点映射：

$$G(x, y) = \begin{pmatrix} f(x, y) \\ g(f(x, y), y) \end{pmatrix}. \quad (6.22)$$

因为  $f(x_\infty, y_\infty) = x_\infty$ ,  $g(x_\infty, y_\infty) = y_\infty$ , 有  $G(\mathbf{z}_\infty) = \mathbf{z}_\infty$ 。

利用链式法则，

$$J_G(\mathbf{z}_\infty) = \begin{pmatrix} a & b \\ ca & cb + d \end{pmatrix}. \quad (6.23)$$

第一行绝对行和为  $|a| + |b| < 1$ 。第二行绝对行和满足

$$\begin{aligned} |ca| + |cb + d| &\leq |c||a| + |c||b| + |d| \\ &= |c|(|a| + |b|) + |d| \\ &< |c| + |d| < 1. \end{aligned} \quad (6.24)$$

因此

$$\|J_G(\mathbf{z}_\infty)\|_\infty < 1. \quad (6.25)$$

由  $J_G$  连续，存在  $r > 0$  和  $\tilde{q} \in (0, 1)$ ，使在闭球  $D_r = \{\mathbf{z} : \|\mathbf{z} - \mathbf{z}_\infty\|_\infty \leq r\}$  上均有

$$\|J_G(\mathbf{z})\|_\infty \leq \tilde{q} < 1. \quad (6.26)$$



由多元均值积分公式, 对任意  $z \in D_r$ ,

$$\begin{aligned}\|G(z) - z_\infty\|_\infty &= \|G(z) - G(z_\infty)\|_\infty \\ &\leq \tilde{q}\|z - z_\infty\|_\infty \leq \tilde{q}r < r.\end{aligned}\quad (6.27)$$

故  $G(D_r) \subset D_r$ , 并且  $G$  在  $D_r$  上为压缩映射。Banach 不动点定理说明, 从任意  $z_0 \in D_r$  出发, 顺序迭代收敛到  $D_r$  内的唯一不动点。

最后证明两种迭代的不动点相同。若  $(x, y)$  是  $G$  的不动点, 则  $x = f(x, y)$ , 且  $y = g(f(x, y), y) = g(x, y)$ 。因此  $(x, y)$  也是  $H$  的不动点。反之, 若  $x = f(x, y)$ ,  $y = g(x, y)$ , 则显然  $G(x, y) = \begin{pmatrix} x \\ y \end{pmatrix}$ 。所以  $G$  与  $H$  的不动点集合相同。由题设  $H$  的不动点唯一, 顺序迭代必收敛到  $(x_\infty, y_\infty)$ 。□

#### 易错点与反例

仅由  $\|J_G(z_\infty)\|_\infty < 1$  直接引用全局 Banach 定理并不严谨。Banach 定理需要在一个完整闭集上具有统一压缩常数并保持集合不变。本题必须利用 Jacobian 连续性构造足够小的闭球。

## 6.3 非线性方程组的 Newton 法

### 6.3.1 知识点四: Jacobian 线性化与 Newton 步

在  $x_k$  附近,  $F(x_k + s) \approx F(x_k) + J_F(x_k)s$ 。令线性模型为零, 得到 Newton 方程

$$J_F(x_k)s_k = -F(x_k), \quad (6.28)$$

以及更新

$$x_{k+1} = x_k + s_k. \quad (6.29)$$

#### 易错点与反例

实际算法中不应显式形成  $J_F(x_k)^{-1}$ 。应求解线性系统  $J_F(x_k)s_k = -F(x_k)$ 。显式求逆通常更昂贵, 也更不稳定。

#### Algorithm 19 非线性方程组 Newton 法

**Input:**  $F$  及 Jacobian  $J_F$ ; 初值  $x_0$ ; 绝对残差容差 atol; 相对残差容差 rtol; 步长容差 xtol; 最大迭代次数  $K_{\max}$

**Output:** 根近似  $x_k$  及失败诊断

- 1: **Initialization:**  $F_0 \leftarrow F(x_0)$
- 2: **for**  $k = 0, 1, \dots, K_{\max} - 1$  **do**
- 3:    $F_k \leftarrow F(x_k)$
- 4:   **if**  $\|F_k\| \leq \text{atol} + \text{rtol} \|F_0\|$  **then**
- 5:     **return**  $x_k$
- 6:   **end if**
- 7:   组装或提供 Jacobian 算子  $J_k = J_F(x_k)$
- 8:   求解  $J_k s_k = -F_k$
- 9:   **if** 线性求解器报告奇异、严重病态或未收敛 **then**
- 10:     报告 Jacobian/线性子问题失败



---

```

11:      return
12:    end if
13:     $\mathbf{x}_{k+1} \leftarrow \mathbf{x}_k + \mathbf{s}_k$ 
14:    if  $\|\mathbf{s}_k\| \leq \text{xtol}(1 + \|\mathbf{x}_{k+1}\|)$  then
15:      同时检查  $\|F(\mathbf{x}_{k+1})\|$  后决定是否接受
16:    end if
17:  end for
18: 报告“达到最大迭代次数”
19: Stopping criterion: 残差与相对步长联合判断
20: Complexity: 稠密情形: Jacobian 存储  $O(n^2)$ ; 每步 LU 分解约  $O(n^3)$ , 回代  $O(n^2)$ ; 稀疏情形
    取决于非零元、填充及迭代线性求解器

```

---

### 6.3.2 知识点五: 局部二次收敛

定理 6.3 (方程组 Newton 法的局部二次收敛). 设  $F: \Omega \subset \mathbb{R}^n \rightarrow \mathbb{R}^n$ ,  $F(\mathbf{x}^*) = \mathbf{0}$ , 且  $J_F(\mathbf{x}^*)$  非奇异。假设在闭球  $\overline{B}(\mathbf{x}^*, r) \subset \Omega$  内:

1.  $J_F$  满足 Lipschitz 条件

$$\|J_F(\mathbf{x}) - J_F(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|; \quad (6.30)$$

2.  $J_F(\mathbf{x})$  均非奇异, 且

$$\|J_F(\mathbf{x})^{-1}\| \leq \beta. \quad (6.31)$$

若  $r$  足够小, 使  $\frac{\beta L}{2}r < 1$ , 则对足够接近  $\mathbf{x}^*$  的初值, Newton 迭代有定义、留在该球内, 并满足

$$\|\mathbf{e}_{k+1}\| \leq \frac{\beta L}{2} \|\mathbf{e}_k\|^2, \quad \mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*. \quad (6.32)$$

证明. 由向量值函数的积分型均值公式,

$$F(\mathbf{x}_k) - F(\mathbf{x}^*) = \int_0^1 J_F(\mathbf{x}^* + t\mathbf{e}_k) \mathbf{e}_k \, dt. \quad (6.33)$$

由于  $F(\mathbf{x}^*) = \mathbf{0}$ ,  $F(\mathbf{x}_k) = \int_0^1 J_F(\mathbf{x}^* + t\mathbf{e}_k) \mathbf{e}_k \, dt$ . Newton 误差为

$$\begin{aligned} \mathbf{e}_{k+1} &= \mathbf{e}_k - J_F(\mathbf{x}_k)^{-1} F(\mathbf{x}_k) \\ &= J_F(\mathbf{x}_k)^{-1} \int_0^1 [J_F(\mathbf{x}_k) - J_F(\mathbf{x}^* + t\mathbf{e}_k)] \mathbf{e}_k \, dt. \end{aligned} \quad (6.34)$$


由 Lipschitz 条件,

$$\|J_F(\mathbf{x}_k) - J_F(\mathbf{x}^* + t\mathbf{e}_k)\| \leq L \|\mathbf{x}_k - \mathbf{x}^* - t\mathbf{e}_k\| = L(1-t) \|\mathbf{e}_k\|.$$

故

$$\|\mathbf{e}_{k+1}\| \leq \beta \int_0^1 L(1-t) \|\mathbf{e}_k\|^2 \, dt = \frac{\beta L}{2} \|\mathbf{e}_k\|^2.$$

若  $\frac{\beta L}{2}r < 1$ , 则误差递减并保持在球内, 由归纳得到局部收敛。□



## 证明思路

识别信号：方程组 Newton 法、正则根、Jacobian Lipschitz、要求二次收敛。

构造步骤：

1. 令  $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$ ;
2. 用积分型 Taylor 公式表示  $F(\mathbf{x}_k) - F(\mathbf{x}^*)$ ;
3. 用 Newton 方程消去一阶项;
4. 把剩余误差写成两个 Jacobian 之差;
5. 用 Lipschitz 条件积分  $\int_0^1 (1-t) dt = \frac{1}{2}$ .

关键估计：  $\|\mathbf{e}_{k+1}\| \leq \frac{1}{2} \sup \|J^{-1}\| \text{Lip}(J) \|\mathbf{e}_k\|^2$ .

常见失败原因：只写形式展开  $F(\mathbf{x}_k) = J_F(\mathbf{x}^*)\mathbf{e}_k + O(\|\mathbf{e}_k\|^2)$  却未说明  $J_F(\mathbf{x}_k)$  可逆，也未证明迭代保持在局部邻域内。

## 6.3.3 知识点六：Kantorovich 型半局部条件

局部二次收敛定理假设已知根  $\mathbf{x}^*$  及其邻域，但实际计算中根未知。Kantorovich 定理从初值  $\mathbf{x}_0$  处可计算的量出发，给出半局部收敛证书。

定理 6.4 (Newton–Kantorovich 定理的一种标准形式). 设  $F$  在凸区域  $\Omega$  内连续可微， $J_0 := J_F(\mathbf{x}_0)$  非奇异。设存在  $\eta \geq 0$  与  $L > 0$  使

$$\|J_0^{-1}F(\mathbf{x}_0)\| \leq \eta, \quad (6.35)$$

$$\|J_0^{-1}(J_F(\mathbf{x}) - J_F(\mathbf{y}))\| \leq L \|\mathbf{x} - \mathbf{y}\|, \quad \mathbf{x}, \mathbf{y} \in \Omega. \quad (6.36)$$

令

$$h = L\eta. \quad (6.37)$$

若  $h \leq \frac{1}{2}$ ，并且  $\overline{B}(\mathbf{x}_0, t^{**}) \subset \Omega$ ，其中

$$t^* = \frac{1 - \sqrt{1 - 2h}}{L}, \quad (6.38)$$

$$t^{**} = \frac{1 + \sqrt{1 - 2h}}{L}, \quad (6.39)$$

则：

1. Newton 迭代从  $\mathbf{x}_0$  出发有定义;
2. 迭代留在  $\overline{B}(\mathbf{x}_0, t^*)$  内;
3. 迭代收敛到该球内的一个根  $\mathbf{x}^*$ ;
4. 在相应标准附加条件下，该根在  $\overline{B}(\mathbf{x}_0, t^{**})$  内唯一;
5. 进入根的局部邻域后恢复二次收敛。

## Kantorovich 证明框架

构造标量主函数

$$\varphi(t) = \eta - t + \frac{L}{2}t^2. \quad (6.40)$$

条件  $h = L\eta \leq 1/2$  保证  $\varphi$  有两个非负实根  $t^*, t^{**}$ 。

从  $t_0 = 0$  出发, 对  $\varphi$  作标量 Newton 迭代:  $t_{k+1} = t_k - \frac{\varphi(t_k)}{\varphi'(t_k)}$ 。证明:

1.  $t_k$  单调递增且  $t_k \uparrow t^*$ ;
2. 向量 Newton 步满足  $\|\mathbf{x}_{k+1} - \mathbf{x}_k\| \leq t_{k+1} - t_k$ ;
3. 因此  $\|\mathbf{x}_k - \mathbf{x}_0\| \leq t_k < t^*$ ;
4. 利用 Banach 引理证明每个  $J_F(\mathbf{x}_k)$  均可逆;
5. 由步长级数可和性证明  $\mathbf{x}_k$  为 Cauchy 列;
6. 极限连续性给出  $F(\mathbf{x}^*) = 0$ 。

资格考试若不要求完整证明, 至少必须写出主函数、条件  $L\eta \leq 1/2$  和半径  $t^*$  的来源。

#### 易错点与反例

Kantorovich 条件是充分条件, 不是 Newton 法收敛的充要条件。若  $L\eta > \frac{1}{2}$ , 只能说明该证书失效, 不能据此断言 Newton 法必发散。

### 6.3.4 知识点七: 阻尼 Newton 与线搜索

定义残差平方价值函数

$$\Psi(\mathbf{x}) = \frac{1}{2} \|F(\mathbf{x})\|_2^2. \quad (6.41)$$

其梯度为

$$\nabla \Psi(\mathbf{x}) = J_F(\mathbf{x})^\top F(\mathbf{x}). \quad (6.42)$$

若 Newton 方向  $\mathbf{p}_k$  满足  $J_F(\mathbf{x}_k)\mathbf{p}_k = -F(\mathbf{x}_k)$ , 则

$$\nabla \Psi(\mathbf{x}_k)^\top \mathbf{p}_k = F(\mathbf{x}_k)^\top J_F(\mathbf{x}_k)\mathbf{p}_k = -\|F(\mathbf{x}_k)\|_2^2 < 0, \quad (6.43)$$

只要  $F(\mathbf{x}_k) \neq 0$ 。因此 Newton 方向是  $\Psi$  的下降方向。

阻尼更新为

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{p}_k, \quad 0 < \lambda_k \leq 1. \quad (6.44)$$

Armijo 回溯选取  $\rho \in (0, 1)$  和  $\sigma \in (0, 1/2)$ , 从  $\lambda = 1$  开始依次试验  $\lambda = \rho^j$ , 直到

$$\Psi(\mathbf{x}_k + \lambda \mathbf{p}_k) \leq \Psi(\mathbf{x}_k) - \sigma \lambda \|F(\mathbf{x}_k)\|_2^2. \quad (6.45)$$

#### Algorithm 20 带 Armijo 回溯的阻尼 Newton 法

**Input:**  $F, J_F$ ; 初值  $\mathbf{x}_0$ ;  $\rho \in (0, 1)$ ;  $\sigma \in (0, 1/2)$ ; 最小步长  $\lambda_{\min}$ ; 停止容差

**Output:** 根近似或失败诊断

- 1: **for**  $k = 0, 1, \dots$  **do**
- 2:     求解  $J_F(\mathbf{x}_k)\mathbf{p}_k = -F(\mathbf{x}_k)$
- 3:      $\lambda \leftarrow 1$
- 4:     **while**  $\Psi(\mathbf{x}_k + \lambda \mathbf{p}_k) > \Psi(\mathbf{x}_k) - \sigma \lambda \|F(\mathbf{x}_k)\|_2^2$  **do**
- 5:          $\lambda \leftarrow \rho \lambda$
- 6:         **if**  $\lambda < \lambda_{\min}$  **then**
- 7:             报告“线搜索失败; Jacobian 可能奇异或模型不可靠”



```

8:         return
9:     end if
10: end while
11:  $\mathbf{x}_{k+1} \leftarrow \mathbf{x}_k + \lambda \mathbf{p}_k$ 
12: if 残差与步长联合准则满足 then
13:     return  $\mathbf{x}_{k+1}$ 
14: end if
15: end for
16: Stopping criterion: 残差、步长和最大迭代次数
17: Complexity: 回溯增加函数计算次数; 主成本仍通常为 Jacobian 构造和线性系统求解

```

#### 易错点与反例

最小化  $\Psi(\mathbf{x}) = \frac{1}{2} \|F(\mathbf{x})\|_2^2$  可能收敛到  $J_F(\mathbf{x})^\top F(\mathbf{x}) = \mathbf{0}$ ,  $F(\mathbf{x}) \neq \mathbf{0}$  的非零残差驻点, 特别是在 Jacobian 秩亏时。因此“价值函数下降”不是“必定找到方程根”的同义词。

### 6.3.5 基础例题：圆与直线交点的 Newton 迭代

#### 完整题目叙述

求解

$$F(x, y) = \begin{pmatrix} x^2 + y^2 - 1 \\ x - y \end{pmatrix} = \mathbf{0}, \quad (6.46)$$

并从  $(x_0, y_0) = (1, 1)$  出发写出前两步 Newton 迭代。

详细解答. Jacobian 为

$$J_F(x, y) = \begin{pmatrix} 2x & 2y \\ 1 & -1 \end{pmatrix}. \quad (6.47)$$

由第二个方程  $x - y = 0$ , 正象限根为  $x^* = y^* = \frac{1}{\sqrt{2}}$ 。

在  $(1, 1)$  处,  $F(1, 1) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ,  $J_F(1, 1) = \begin{pmatrix} 2 & 2 \\ 1 & -1 \end{pmatrix}$ 。Newton 步满足  $\begin{pmatrix} 2 & 2 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} s_x \\ s_y \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$ 。由  $s_x = s_y$  及  $4s_x = -1$ ,  $\mathbf{s}_0 = \begin{pmatrix} -1/4 \\ -1/4 \end{pmatrix}$ 。故  $(x_1, y_1) = (\frac{3}{4}, \frac{3}{4})$ 。

在  $(3/4, 3/4)$  处,  $F(x_1, y_1) = \begin{pmatrix} 2(3/4)^2 - 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1/8 \\ 0 \end{pmatrix}$ ,  $J_F(x_1, y_1) = \begin{pmatrix} 3/2 & 3/2 \\ 1 & -1 \end{pmatrix}$ 。仍有  $s_x = s_y$ , 且  $3s_x = -\frac{1}{8}$ , 所以  $\mathbf{s}_1 = \begin{pmatrix} -1/24 \\ -1/24 \end{pmatrix}$ 。因此  $(x_2, y_2) = (\frac{17}{24}, \frac{17}{24}) \approx (0.708333, 0.708333)$ 。

因为初值保持  $x_k = y_k$ , 该二维 Newton 法等价于对  $2t^2 - 1 = 0$  使用标量 Newton 法:

$$t_{k+1} = t_k - \frac{2t_k^2 - 1}{4t_k} = \frac{1}{2} \left( t_k + \frac{1}{2t_k} \right). \quad (6.48)$$

根处导数非零, 故局部二次收敛。 □



## 6.4 拟 Newton 方法与 Broyden 更新

### 6.4.1 知识点八：拟 Newton 框架与割线条件

【重要性等级】 **S 级**。Broyden 法由 [QE-Train] 和 [NA-Wang] 明确列入主要复习内容。其核心不是记住秩一公式，而是理解：

Jacobian 近似 + 割线条件 + 最小改动原则。

设  $B_k \approx J_F(\mathbf{x}_k)$ 。拟 Newton 步由

$$B_k \mathbf{p}_k = -F(\mathbf{x}_k) \quad (6.49)$$

确定，并令

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \lambda_k \mathbf{p}_k. \quad (6.50)$$

定义实际位移和函数差

$$\mathbf{s}_k = \mathbf{x}_{k+1} - \mathbf{x}_k, \quad \mathbf{y}_k = F(\mathbf{x}_{k+1}) - F(\mathbf{x}_k). \quad (6.51)$$

由积分型均值公式， $\mathbf{y}_k = \left[ \int_0^1 J_F(\mathbf{x}_k + t\mathbf{s}_k) dt \right] \mathbf{s}_k$ 。因此合理的新 Jacobian 近似应满足割线条件

$$B_{k+1} \mathbf{s}_k = \mathbf{y}_k. \quad (6.52)$$

#### 易错点与反例

多维割线条件只规定  $B_{k+1}$  在一个方向  $\mathbf{s}_k$  上的作用，因此不足以唯一确定  $n \times n$  矩阵。必须额外加入“最小改动”、“对称性”、“正定性”或其他结构条件。

### 6.4.2 知识点九：良 Broyden 更新的最小改动推导

定理 6.5 (良 Broyden 的 Jacobian 更新). 在所有满足  $B\mathbf{s}_k = \mathbf{y}_k$  的矩阵中，使  $\|B - B_k\|_F$  最小的唯一矩阵为

$$B_{k+1} = B_k + \frac{(\mathbf{y}_k - B_k \mathbf{s}_k) \mathbf{s}_k^\top}{\mathbf{s}_k^\top \mathbf{s}_k}. \quad (6.53)$$

证明. 令  $E = B - B_k$ ,  $\mathbf{r}_k = \mathbf{y}_k - B_k \mathbf{s}_k$ 。约束变为  $E\mathbf{s}_k = \mathbf{r}_k$ 。把  $E$  的第  $i$  行记为  $\mathbf{e}_i^\top$ ，把  $\mathbf{r}_k$  第  $i$  个分量记为  $r_i$ 。则每一行独立满足  $\mathbf{e}_i^\top \mathbf{s}_k = r_i$ ，并需最小化  $\|E\|_F^2 = \sum_{i=1}^n \|\mathbf{e}_i\|_2^2$ 。由 Cauchy-Schwarz 不等式， $|r_i| = |\mathbf{e}_i^\top \mathbf{s}_k| \leq \|\mathbf{e}_i\|_2 \|\mathbf{s}_k\|_2$ 。等号成立且范数最小时， $\mathbf{e}_i = \frac{r_i}{\mathbf{s}_k^\top \mathbf{s}_k} \mathbf{s}_k$ 。逐行组合得到  $E = \frac{\mathbf{r}_k \mathbf{s}_k^\top}{\mathbf{s}_k^\top \mathbf{s}_k}$ ，即式 (6.53)。严格凸性保证极小解唯一。□

该更新为秩一修正，并自动满足  $B_{k+1} \mathbf{s}_k = B_k \mathbf{s}_k + (\mathbf{y}_k - B_k \mathbf{s}_k) = \mathbf{y}_k$ 。

### 6.4.3 逆 Jacobian 的秩一更新

若维护  $H_k = B_k^{-1}$ ，由 Sherman-Morrison 公式，

$$H_{k+1} = H_k + \frac{(\mathbf{s}_k - H_k \mathbf{y}_k) \mathbf{s}_k^\top H_k}{\mathbf{s}_k^\top H_k \mathbf{y}_k}. \quad (6.54)$$

该式成立的必要条件是

$$\mathbf{s}_k^\top H_k \mathbf{y}_k \neq 0. \quad (6.55)$$

若分母绝对值过小，则逆更新可能严重放大舍入误差。实际实现应：



- 跳过此次更新;
- 重新计算 Jacobian;
- 重启  $B_k$  或  $H_k$ ;
- 或使用更稳定的 QR 分解秩一更新。

另一种更新是直接在逆矩阵空间最小改动:

$$H_{k+1}^{\text{bad}} = H_k + \frac{(s_k - H_k y_k) y_k^T}{y_k^T y_k}. \quad (6.56)$$

它满足  $H_{k+1}^{\text{bad}} y_k = s_k$ , 通常称为“坏 Broyden”逆更新。“良”与“坏”是历史名称, 不表示某一方法在所有问题上绝对优劣。

---

**Algorithm 21** 带阻尼和重启的良 Broyden 法

---

**Input:**  $F$ ; 初值  $x_0$ ; 初始 Jacobian 近似  $B_0$ ; 残差容差; 分母安全阈值  $\tau_{\text{safe}}$ ; 最大迭代次数

**Output:** 根近似

```

1: Initialization:  $F_0 \leftarrow F(x_0)$ 
2: for  $k = 0, 1, \dots$  do
3:   求解  $B_k p_k = -F_k$ 
4:   通过线搜索或其他规则选择  $\lambda_k \in (0, 1]$ 
5:    $s_k \leftarrow \lambda_k p_k$ 
6:    $x_{k+1} \leftarrow x_k + s_k$ 
7:    $F_{k+1} \leftarrow F(x_{k+1})$ 
8:    $y_k \leftarrow F_{k+1} - F_k$ 
9:   if  $\|F_{k+1}\|$  满足停止准则 then
10:    return  $x_{k+1}$ 
11:  end if
12:  if  $\|s_k\|$  过小或更新方向退化 then
13:    重新构造  $B_{k+1} \approx J_F(x_{k+1})$ 
14:  else
15:     $B_{k+1} \leftarrow B_k + \frac{(y_k - B_k s_k) s_k^T}{s_k^T s_k}$ 
16:  end if
17:   $F_k \leftarrow F_{k+1}$ 
18: end for
19: Stopping criterion: 残差、步长、线搜索和最大迭代次数联合判断
20: Complexity: 稠密直接维护  $B_k$  时每步仍需  $O(n^3)$  分解; 维护逆矩阵或分解的秩一更新可降至  $O(n^2)$ , 存储  $O(n^2)$ ; 每步通常只需一个新函数值


```

---

#### 6.4.4 知识点十: 超线性收敛与 Dennis–Moré 条件

**定理 6.6** (Dennis–Moré 型超线性判据). 设  $F$  在正则根  $x^*$  附近连续可微,  $J_* := J_F(x^*)$  非奇异. 设拟 Newton 迭代采用完整步  $B_k s_k = -F(x_k)$ ,  $x_{k+1} = x_k + s_k$ , 且:

1.  $x_k \rightarrow x^*$ ;
2.  $\{B_k^{-1}\}$  一致有界;



3. 满足 Dennis–Moré 条件

$$\frac{\|(B_k - J_*)\mathbf{s}_k\|}{\|\mathbf{s}_k\|} \rightarrow 0. \quad (6.57)$$

则

$$\frac{\|\mathbf{x}_{k+1} - \mathbf{x}^*\|}{\|\mathbf{x}_k - \mathbf{x}^*\|} \rightarrow 0, \quad (6.58)$$

即迭代超线性收敛。

证明. 记  $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$ 。由  $F$  在根处可微,

$$F(\mathbf{x}_k) = J_*\mathbf{e}_k + o(\|\mathbf{e}_k\|). \quad (6.59)$$

又因  $B_k\mathbf{s}_k = -F(\mathbf{x}_k)$ , 有

$$\begin{aligned} J_*\mathbf{e}_{k+1} &= J_*(\mathbf{e}_k + \mathbf{s}_k) \\ &= (J_*\mathbf{e}_k - F(\mathbf{x}_k)) + (J_* - B_k)\mathbf{s}_k. \end{aligned} \quad (6.60)$$

第一项为  $o(\|\mathbf{e}_k\|)$ 。由  $B_k^{-1}$  一致有界及  $\mathbf{s}_k = -B_k^{-1}F(\mathbf{x}_k)$ , 有  $\|\mathbf{s}_k\| = O(\|\mathbf{e}_k\|)$ 。再由 Dennis–Moré 条件,  $\|(J_* - B_k)\mathbf{s}_k\| = o(\|\mathbf{s}_k\|) = o(\|\mathbf{e}_k\|)$ 。故  $\|J_*\mathbf{e}_{k+1}\| = o(\|\mathbf{e}_k\|)$ 。由于  $J_*^{-1}$  有界,  $\|\mathbf{e}_{k+1}\| = o(\|\mathbf{e}_k\|)$ , 即为超线性收敛。□

在  $F'$  局部 Lipschitz、初值和初始 Jacobian 近似足够接近, 并采用完整步等标准条件下, 良 Broyden 法满足上述判据并局部超线性收敛。但是:

- 它一般不是二次收敛;
- 带长期阻尼的实现可能只表现为线性收敛;
- 更新退化、重启和噪声会改变渐近行为;
- 仅满足割线条件本身不能保证超线性收敛。

#### 6.4.5 Broyden 与有限差分 Jacobian 的比较

| 比较项   | 有限差分 Jacobian        | Broyden 更新                               |
|-------|----------------------|------------------------------------------|
| 构造信息  | 在坐标方向重新采样 $F$        | 使用实际步 $\mathbf{s}_k$ 与函数差 $\mathbf{y}_k$ |
| 函数值成本 | 一次刷新通常需 $n$ 个或更多新函数值 | 每步通常只需一个新函数值                             |
| 近似方向  | 同时近似全部坐标方向           | 每步只新增一个割线方向信息                            |
| 误差来源  | 差分截断误差与舍入误差          | 历史近似误差、秩一更新误差与线搜索影响                      |
| 稀疏结构  | 可按稀疏着色降低函数计算         | 普通稠密秩一更新可能破坏稀疏性                          |
| 局部收敛  | 足够准确时接近 Newton 行为    | 标准条件下通常超线性但非二次                           |
| 重启需要  | 步长失配或噪声大时重新选差分步长     | 分母过小、更新劣化或停滞时重算 Jacobian                 |

## 6.4.6 基础例题：验证良 Broyden 的割线条件

## 完整题目叙述

设  $B_0 = I_2$ ,  $\mathbf{s} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ ,  $\mathbf{y} = \begin{pmatrix} 3 \\ 5 \end{pmatrix}$ 。求良 Broyden 更新  $B_1$ , 并验证  $B_1 \mathbf{s} = \mathbf{y}$ 。

详细解答. 有  $\mathbf{y} - B_0 \mathbf{s} = \begin{pmatrix} 3 \\ 5 \end{pmatrix} - \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 3 \end{pmatrix}$ , 且  $\mathbf{s}^\top \mathbf{s} = 1^2 + 2^2 = 5$ 。因此

$$\begin{aligned} B_1 &= I_2 + \frac{1}{5} \begin{pmatrix} 2 \\ 3 \end{pmatrix} \begin{pmatrix} 1 & 2 \end{pmatrix} \\ &= \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \frac{1}{5} \begin{pmatrix} 2 & 4 \\ 3 & 6 \end{pmatrix} \\ &= \begin{pmatrix} 7/5 & 4/5 \\ 3/5 & 11/5 \end{pmatrix}. \end{aligned}$$

验证:  $B_1 \mathbf{s} = \begin{pmatrix} 7/5 & 4/5 \\ 3/5 & 11/5 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 3 \\ 5 \end{pmatrix} = \mathbf{y}$ 。 □

## 6.4.7 综合例题：Broyden 法求圆与直线交点

## 完整题目叙述

仍考虑  $F(x, y) = \begin{pmatrix} x^2 + y^2 - 1 \\ x - y \end{pmatrix}$ 。取  $\mathbf{x}_0 = (1, 1)^\top$ ,  $B_0 = J_F(\mathbf{x}_0)$ 。第一步采用完整拟 Newton 步, 随后用良 Broyden 公式更新  $B_1$ 。计算  $\mathbf{x}_1, B_1, \mathbf{x}_2$ 。

详细解答. 由前一节计算,  $B_0 = \begin{pmatrix} 2 & 2 \\ 1 & -1 \end{pmatrix}$ ,  $F(\mathbf{x}_0) = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ 。解  $B_0 \mathbf{s}_0 = -F(\mathbf{x}_0)$  得到  $\mathbf{s}_0 = \begin{pmatrix} -1/4 \\ -1/4 \end{pmatrix}$ 。因此


$$\mathbf{x}_1 = \begin{pmatrix} 3/4 \\ 3/4 \end{pmatrix}, F(\mathbf{x}_1) = \begin{pmatrix} 1/8 \\ 0 \end{pmatrix}. \quad (6.61)$$

函数差为  $\mathbf{y}_0 = F(\mathbf{x}_1) - F(\mathbf{x}_0) = \begin{pmatrix} -7/8 \\ 0 \end{pmatrix}$ 。同时  $B_0 \mathbf{s}_0 = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$ , 所以  $\mathbf{y}_0 - B_0 \mathbf{s}_0 = \begin{pmatrix} 1/8 \\ 0 \end{pmatrix}$ 。又  $\mathbf{s}_0^\top \mathbf{s}_0 = \frac{1}{16} + \frac{1}{16} = \frac{1}{8}$ 。故

$$\begin{aligned} B_1 &= B_0 + \frac{(\mathbf{y}_0 - B_0 \mathbf{s}_0) \mathbf{s}_0^\top}{\mathbf{s}_0^\top \mathbf{s}_0} \\ &= \begin{pmatrix} 2 & 2 \\ 1 & -1 \end{pmatrix} + \begin{pmatrix} -1/4 & -1/4 \\ 0 & 0 \end{pmatrix} \\ &= \begin{pmatrix} 7/4 & 7/4 \\ 1 & -1 \end{pmatrix}. \end{aligned} \quad (6.62)$$

第二步求解  $B_1 \mathbf{s}_1 = -F(\mathbf{x}_1) = \begin{pmatrix} -1/8 \\ 0 \end{pmatrix}$ 。第二行给出  $s_{1,x} = s_{1,y}$ 。设共同值为  $s$ , 则第一行给出  $\frac{7}{2}s = -\frac{1}{8}$ , 故  $s = -\frac{1}{28}$ 。因此

$$\mathbf{x}_2 = \begin{pmatrix} 3/4 - 1/28 \\ 3/4 - 1/28 \end{pmatrix} = \begin{pmatrix} 5/7 \\ 5/7 \end{pmatrix}. \quad (6.63)$$



此时  $F(\mathbf{x}_2) = \begin{pmatrix} 2(5/7)^2 - 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1/49 \\ 0 \end{pmatrix}$ 。正根为  $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}) \approx (0.7071068, 0.7071068)$ , 而  $\frac{5}{7} \approx 0.7142857$ 。

□

## 6.5 求根同伦与参数延拓

### 6.5.1 知识点十一：基本同伦构造

【重要性等级】 **A 级**。同伦法用于缓解 Newton 法对初值的敏感性。[NA-Wang] 给出的基本思想是：把难解方程与易解方程连续连接，并逐步用上一参数点的解作为下一参数点初值。考纲进一步要求掌握预测-校正、分支和奇点。

设目标方程为  $F(\mathbf{x}) = \mathbf{0}$ , 另选一个易解方程  $G(\mathbf{x}) = \mathbf{0}$ ,  $G(\mathbf{x}_0) = \mathbf{0}$ 。最简单的线性同伦为

$$H(\mathbf{x}, t) = (1-t)G(\mathbf{x}) + tF(\mathbf{x}), \quad 0 \leq t \leq 1. \quad (6.64)$$

于是  $H(\mathbf{x}, 0) = G(\mathbf{x})$ ,  $H(\mathbf{x}, 1) = F(\mathbf{x})$ 。

若存在连续解路径  $\mathbf{x} = \mathbf{x}(t)$ ,  $H(\mathbf{x}(t), t) = \mathbf{0}$ , 且  $H_{\mathbf{x}}(\mathbf{x}(t), t)$  始终非奇异, 则由隐函数定理, 路径局部唯一且可微。对  $H(\mathbf{x}(t), t) = \mathbf{0}$  求导:

$$H_{\mathbf{x}}(\mathbf{x}(t), t)\mathbf{x}'(t) + H_t(\mathbf{x}(t), t) = \mathbf{0}. \quad (6.65)$$

故

$$\mathbf{x}'(t) = -H_{\mathbf{x}}(\mathbf{x}(t), t)^{-1}H_t(\mathbf{x}(t), t). \quad (6.66)$$

### 6.5.2 预测-校正算法

设已知  $H(\mathbf{x}_k, t_k) = \mathbf{0}$ 。先解切向方程

$$H_{\mathbf{x}}(\mathbf{x}_k, t_k)\mathbf{v}_k = -H_t(\mathbf{x}_k, t_k). \quad (6.67)$$

取参数步长  $\Delta t_k$ , Euler 预测为

$$\mathbf{x}_{k+1}^{\text{pred}} = \mathbf{x}_k + \Delta t_k \mathbf{v}_k. \quad (6.68)$$

然后固定  $t_{k+1} = t_k + \Delta t_k$  并对  $H(\mathbf{x}, t_{k+1}) = \mathbf{0}$  使用 Newton 法校正。

---

#### Algorithm 22 参数延拓的预测-校正法

---

**Input:** 同伦  $H(\mathbf{x}, t)$ ; 已知起点  $H(\mathbf{x}_0, 0) = \mathbf{0}$ ; 初始参数步长  $\Delta t$ ; 最小/最大步长; Newton 容差

**Output:**  $t = 1$  处目标方程近似根

- 1: **Initialization:**  $t_0 \leftarrow 0$ ,  $k \leftarrow 0$
- 2: **while**  $t_k < 1$  **do**
- 3:    $\Delta t_k \leftarrow \min\{\Delta t, 1 - t_k\}$
- 4:   解切向方程  $H_{\mathbf{x}}(\mathbf{x}_k, t_k)\mathbf{v}_k = -H_t(\mathbf{x}_k, t_k)$
- 5:    $\mathbf{x}^{\text{pred}} \leftarrow \mathbf{x}_k + \Delta t_k \mathbf{v}_k$
- 6:    $t_{k+1} \leftarrow t_k + \Delta t_k$
- 7:   以  $\mathbf{x}^{\text{pred}}$  为初值, 对  $H(\mathbf{x}, t_{k+1}) = \mathbf{0}$  进行 Newton 校正
- 8:   **if** 校正成功 **then**
- 9:     接受  $\mathbf{x}_{k+1}$



```

10:      若 Newton 迭代次数很少, 则适当增大  $\Delta t$ 
11:  else
12:      拒绝本步并减小  $\Delta t$ 
13:      if  $\Delta t$  小于最小步长 then
14:          报告“路径奇异、分支或步长失败”
15:          return
16:      end if
17:  end if
18:   $k \leftarrow k + 1$ 
19: end while
20: Stopping criterion:  $t_k = 1$  且  $\|F(\mathbf{x}_k)\|$  满足容差
21: Complexity: 每个参数步需至少一次切向线性求解和若干 Newton 校正; 总成本由路径长度、曲
    率、步长与 Jacobian 求解成本决定

```

【局部误差】 Euler 预测的局部路径误差为  $O((\Delta t_k)^2)$ 。若采用二阶切向预测或高阶 ODE 积分器跟踪式 (6.66), 可提高预测阶; 但最终校正精度仍取决于 Newton 容差及 Jacobian 条件数。

#### 【失败情形】

- 同伦路径在到达  $t = 1$  前发散到无穷;
- $H_{\mathbf{x}}$  变奇异, 普通参数化失效;
- 路径发生分支, 算法未规定分支选择;
- 步长过大, Newton 校正收敛到错误分支;
- 同伦构造引入目标方程不存在的额外解;
- 目标根本身为奇异根;
- 复路径穿过实域外, 而算法被限制在实数中。

### 6.5.3 知识点十二: 伪弧长延拓

对于参数方程

$$H(\mathbf{x}, \lambda) = \mathbf{0}, H: \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^n, \quad (6.69)$$

若  $H_{\mathbf{x}}$  在折点处奇异, 则不能再把  $\lambda$  作为单值参数。改令  $\mathbf{z} = \begin{pmatrix} \mathbf{x} \\ \lambda \end{pmatrix} \in \mathbb{R}^{n+1}$  并用弧长  $s$  参数化。

切向量  $\boldsymbol{\tau}_k$  满足

$$\begin{pmatrix} H_{\mathbf{x}}(\mathbf{z}_k) & H_{\lambda}(\mathbf{z}_k) \end{pmatrix} \boldsymbol{\tau}_k = \mathbf{0}, \|\boldsymbol{\tau}_k\|_2 = 1, \quad (6.70)$$

并通过  $\boldsymbol{\tau}_k^T \boldsymbol{\tau}_{k-1} > 0$  保持方向连续。

预测点为

$$\mathbf{z}^{\text{pred}} = \mathbf{z}_k + \Delta s \boldsymbol{\tau}_k. \quad (6.71)$$

校正时求解增广系统

$$\begin{cases} H(\mathbf{x}, \lambda) = \mathbf{0}, \\ \boldsymbol{\tau}_k^T (\mathbf{z} - \mathbf{z}^{\text{pred}}) = 0. \end{cases} \quad (6.72)$$

只要增广 Jacobian 非奇异, 伪弧长法便可穿过简单折点。





折点识别:  $x^2 - \lambda = 0$

考虑  $H(x, \lambda) = x^2 - \lambda = 0$ 。若把  $\lambda$  作为参数,  $x = \pm\sqrt{\lambda}$ ,  $\frac{dx}{d\lambda} = \frac{1}{2x}$ 。在  $(x, \lambda) = (0, 0)$  处导数发散, 且  $H_x = 2x = 0$ 。普通  $\lambda$  延拓失效。

但整条解曲线可写为  $(x, \lambda) = (x, x^2)$ 。在折点处曲线切向量为  $(1, 0)^T$ , 并未消失。伪弧长法可沿曲线从正支穿过  $(0, 0)$  继续到负支, 而不要求  $\lambda$  单调。

#### 6.5.4 综合例题: 三次方程的同伦跟踪

完整题目叙述

用同伦方法求  $F(x) = x^3 - x - 1 = 0$  的正实根。取易解方程  $G(x) = x - 1 = 0$  并构造线性同伦。说明解路径的正则性, 并写出从  $t = 0$  到  $t = 1/2$  的预测-校正步骤。

详细解答. 定义

$$\begin{aligned} H(x, t) &= (1-t)(x-1) + t(x^3 - x - 1) \\ &= tx^3 + (1-2t)x - 1. \end{aligned} \quad (6.73)$$

在  $t = 0$ ,  $H(x, 0) = x - 1$ , 故已知起点  $x(0) = 1$ 。

对  $x \geq 1$ ,  $H_x(x, t) = 3tx^2 + 1 - 2t \geq 3t + 1 - 2t = 1 + t > 0$ 。同时  $H(1, t) = -t \leq 0$ ,  $H(x, t) \rightarrow +\infty$  ( $x \rightarrow +\infty$ )。因此对每个  $t \in [0, 1]$ , 在  $x \geq 1$  上存在唯一根  $x(t)$ , 并且沿该正根路径  $H_x(x(t), t) > 0$ 。所以该路径无 Jacobian 奇点。

又  $H_t(x, t) = x^3 - 2x$ 。由切向公式,

$$x'(t) = -\frac{x(t)^3 - 2x(t)}{3tx(t)^2 + 1 - 2t}. \quad (6.74)$$

在  $t = 0, x = 1$  处,  $x'(0) = 1$ 。

若取  $\Delta t = \frac{1}{2}$ , Euler 预测为  $x_{1/2}^{\text{pred}} = 1 + \frac{1}{2}x'(0) = \frac{3}{2}$ 。在  $t = 1/2$ , 方程化为  $\frac{1}{2}x^3 - 1 = 0$ , 精确根为  $x(1/2) = 2^{1/3} \approx 1.259921$ 。以  $x^{(0)} = 3/2$  进行 Newton 校正:  $x^{(j+1)} = x^{(j)} - \frac{\frac{1}{2}(x^{(j)})^3 - 1}{\frac{3}{2}(x^{(j)})^2}$ 。第一次校正:  $x^{(1)} = \frac{3}{2} - \frac{\frac{1}{2}(3/2)^3 - 1}{\frac{3}{2}(3/2)^2} = \frac{3}{2} - \frac{11/16}{27/8} = \frac{35}{27} \approx 1.296296$ 。继续 Newton 校正即可快速得到  $2^{1/3}$ 。

随后以  $t = 1/2$  处校正解为下一步初值, 继续跟踪到  $t = 1$ , 最终得到  $x^* \approx 1.324717957$ , 即方程  $x^3 - x - 1 = 0$  的正实根。□

易错点与反例

本模块中的同伦用于  $F(\mathbf{x}) = \mathbf{0}$  的求根路径跟踪。

第 29 部分讨论的优化同伦可能跟踪正则化参数、稀疏解路径或最优性条件。二者在数学上都使用连续参数化, 但问题对象、停止条件和分支意义不同, 不得静默混为同一种算法。

## 6.6 多项式求根: Horner、Newton-Horner 与降次

### 6.6.1 知识点十三: Horner 嵌套乘法

【重要性等级】 **A 级**。Horner 法是多项式 Newton 求根、综合除法、Bairstow 法和伴随矩阵法的计算前置。



设

$$p(z) = a_n z^n + a_{n-1} z^{n-1} + \cdots + a_1 z + a_0. \quad (6.75)$$

Horner 嵌套形式为

$$p(z) = a_0 + z(a_1 + z(a_2 + \cdots + z(a_{n-1} + za_n))). \quad (6.76)$$

递推为

$$b_n = a_n, \quad b_k = a_k + zb_{k+1}, \quad k = n-1, \dots, 0. \quad (6.77)$$

最终  $p(z) = b_0$ 。

---

**Algorithm 23** 同时计算  $p(z)$  与  $p'(z)$  的扩展 Horner 法

---

**Input:** 系数  $a_0, \dots, a_n$ ; 目标点  $z$

**Output:**  $p(z)$  和  $p'(z)$

- 1: **Initialization:**  $b_n \leftarrow a_n, d_n \leftarrow 0$
  - 2: **for**  $k = n-1, n-2, \dots, 0$  **do**
  - 3:      $d_k \leftarrow b_{k+1} + zd_{k+1}$
  - 4:      $b_k \leftarrow a_k + zb_{k+1}$
  - 5: **end for**
  - 6: **return**  $p(z) = b_0, p'(z) = d_0$
  - 7: **Stopping criterion:** 递推到  $k = 0$
  - 8: **Complexity:**  $O(n)$  次乘法; 滚动实现存储  $O(1)$ , 若保留商系数则存储  $O(n)$
- 

**【浮点误差】** 在无上溢和下溢的标准浮点模型下, Horner 计算通常满足前向误差估计

$$|\hat{p}(z) - p(z)| \leq \gamma_{2n} \sum_{j=0}^n |a_j| |z|^j, \quad \gamma_m = \frac{mu}{1 - mu}, \quad (6.78)$$

其中  $u$  为单位舍入误差且  $mu < 1$ 。若  $p(z)$  本身由大项相消得到很小数值, 则相对误差仍可能很大; 这是多项式求值在该点的消去条件问题。

### 6.6.2 知识点十四: Newton–Horner 法

Newton 迭代为

$$z_{k+1} = z_k - \frac{p(z_k)}{p'(z_k)}. \quad (6.79)$$

使用扩展 Horner 法在  $O(n)$  成本内同时得到  $p(z_k)$  和  $p'(z_k)$ , 称为 Newton–Horner 法。

---

**Algorithm 24** Newton–Horner 单根求解

---

**Input:** 多项式系数  $a_0, \dots, a_n$ ; 初值  $z_0 \in \mathbb{C}$ ; 容差; 最大迭代次数

**Output:** 一个根近似

- 1: **for**  $k = 0, 1, \dots$  **do**
- 2:     用扩展 Horner 计算  $p_k = p(z_k)$  与  $d_k = p'(z_k)$
- 3:     **if**  $|p_k|$  满足残差准则 **then**
- 4:         **return**  $z_k$
- 5:     **end if**
- 6:     **if**  $|d_k|$  过小 **then**
- 7:         报告“导数过小; 可能为重根或聚集根”
- 8:     **return**



```

9:   end if
10:   $s_k \leftarrow -p_k/d_k$ 
11:   $z_{k+1} \leftarrow z_k + s_k$ 
12:  if  $|s_k| \leq \text{tol}(1 + |z_{k+1}|)$  then
13:    检查原多项式残差后返回
14:  end if
15: end for
16: Stopping criterion: 原多项式残差和相对步长
17: Complexity: 每步  $O(n)$ ; 求一个根需  $O(nN_{\text{it}})$ 

```

Newton-Horner 继承 Newton 法的局部性质:

- 简单根附近二次收敛;
- 重根附近通常退化为线性收敛;
- 初值不当时可能收敛到其他根、形成周期或发散;
- 复根通常需要复初值, 除非使用 Bairstow 等实算法。

### 6.6.3 知识点十五: 综合除法与降次

给定任意  $z$ , Horner 系数满足

$$p(x) = (x - z)q_{n-1}(x; z) + p(z), \quad (6.80)$$

其中

$$q_{n-1}(x; z) = b_n x^{n-1} + b_{n-1} x^{n-2} + \cdots + b_1. \quad (6.81)$$

若  $z = \zeta$  为精确根, 则  $p(x) = (x - \zeta)q_{n-1}(x; \zeta)$ , 可将  $n$  次求根问题降为  $n - 1$  次问题。

若  $\hat{\zeta}$  只是近似根, 则

$$p(x) = (x - \hat{\zeta})q_{n-1}(x; \hat{\zeta}) + p(\hat{\zeta}). \quad (6.82)$$

直接丢弃余项等价于改变原多项式, 后续根可能受到显著污染。

#### 【稳健策略】

1. 每次降次前先把当前根充分校正;
2. 对实系数多项式, 复根应以共轭二次因子成对降次;
3. 全部根求出后, 以原多项式而非已降次多项式进行 Newton 修正;
4. 聚集根和重根情况下, 避免连续单根降次;
5. 适当缩放变量和系数, 防止 Horner 中上溢、下溢。

#### 易错点与反例

小残差不等于根准确。

对简单根,  $\hat{\zeta} - \zeta \approx \frac{p(\hat{\zeta})}{p'(\zeta)}$ 。若  $|p'(\zeta)|$  很小, 即使  $p(\hat{\zeta})$  很小, 根误差仍可能很大。



## 6.7 多项式根的敏感性与伴随矩阵

### 6.7.1 知识点十六：系数扰动与根条件数

考虑  $p(z) = \sum_{j=0}^n a_j z^j$  的简单根  $\zeta$ 。对系数作小扰动  $a_j \mapsto a_j + \delta a_j$ , 根变为  $\zeta + \delta\zeta$ 。一阶展开给出

$$\begin{aligned} 0 &= p(\zeta + \delta\zeta) + \sum_{j=0}^n \delta a_j (\zeta + \delta\zeta)^j \\ &= p'(\zeta)\delta\zeta + \sum_{j=0}^n \zeta^j \delta a_j + \text{高阶项}. \end{aligned} \quad (6.83)$$

因此

$$\delta\zeta \approx -\frac{\sum_{j=0}^n \zeta^j \delta a_j}{p'(\zeta)}. \quad (6.84)$$

若采用分量相对扰动模型  $|\delta a_j| \leq \varepsilon |a_j|$ , 则

$$|\delta\zeta| \lesssim \varepsilon \frac{\sum_{j=0}^n |a_j| |\zeta|^j}{|p'(\zeta)|}. \quad (6.85)$$

当  $\zeta \neq 0$  时, 相对根条件数可写为

$$\kappa_{\text{cw}}(\zeta) = \frac{\sum_{j=0}^n |a_j| |\zeta|^j}{|\zeta p'(\zeta)|}. \quad (6.86)$$

若  $p(z) = a_n \prod_{i=1}^n (z - \zeta_i)$ , 则对简单根  $\zeta_i$ ,

$$p'(\zeta_i) = a_n \prod_{j \neq i} (\zeta_i - \zeta_j). \quad (6.87)$$

所以根聚集时, 根间距离乘积很小, 导致  $p'(\zeta_i)$  小、条件数大。重根处  $p'(\zeta) = 0$ , 一阶条件数发散。

基础反例：双根的平方根敏感性

考虑

$$p_c(z) = z^2 - 2z + c. \quad (6.88)$$

其根为  $\zeta_{\pm}(c) = 1 \pm \sqrt{1-c}$ 。当  $c=1$  时,  $p_1(z) = (z-1)^2$  具有双根 1。

若  $c = 1 - \varepsilon$ ,  $\varepsilon > 0$ , 则根变为  $1 \pm \sqrt{\varepsilon}$ 。系数仅变化  $O(\varepsilon)$ , 而根变化为  $O(\sqrt{\varepsilon})$ 。此外  $\frac{d\zeta_{\pm}}{dc} = \mp \frac{1}{2\sqrt{1-c}}$ , 在  $c \rightarrow 1^-$  时发散。


### 6.7.2 知识点十七：Frobenius 伴随矩阵

设  $p$  为首一多项式

$$p(z) = z^n + a_{n-1}z^{n-1} + \cdots + a_1z + a_0. \quad (6.89)$$

定义上 Hessenberg 型 Frobenius 伴随矩阵

$$C_p = \begin{pmatrix} 0 & 0 & \cdots & 0 & -a_0 \\ 1 & 0 & \cdots & 0 & -a_1 \\ 0 & 1 & \ddots & 0 & -a_2 \\ \vdots & \ddots & \ddots & \vdots & \vdots \\ 0 & \cdots & 0 & 1 & -a_{n-1} \end{pmatrix}. \quad (6.90)$$



定理 6.7 (多项式根与伴随矩阵特征值). 有

$$\det(zI - C_p) = p(z). \quad (6.91)$$

因此  $p$  的全部根, 包括代数重数, 恰为  $C_p$  的全部特征值。

证明. 考虑转置矩阵  $C_p^T = \begin{pmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & 0 & 1 \\ -a_0 & -a_1 & \cdots & -a_{n-2} & -a_{n-1} \end{pmatrix}$ . 若  $p(\zeta) = 0$ , 令  $\mathbf{v}(\zeta) = \begin{pmatrix} 1 \\ \zeta \\ \vdots \\ \zeta^{n-1} \end{pmatrix}$ .

前  $n-1$  行显然满足  $(C_p^T \mathbf{v})_j = \zeta v_j$ . 最后一行为  $-a_0 - a_1 \zeta - \cdots - a_{n-1} \zeta^{n-1} = \zeta^n$ , 因为  $p(\zeta) = 0$ . 所以  $C_p^T \mathbf{v}(\zeta) = \zeta \mathbf{v}(\zeta)$ . 因此  $p$  的根均为  $C_p^T$ , 从而也是  $C_p$  的特征值. 二者特征多项式均为首一  $n$  次多项式, 故必有  $\det(zI - C_p) = p(z)$ .  $\square$

**【算法或离散格式】** 伴随矩阵法将“求所有根”转化为“求全部特征值”:

1. 将多项式归一化为首一;
2. 构造  $C_p$ ;
3. 使用带平衡的 Hessenberg QR 算法求特征值;
4. 用原多项式残差检查并校正各根。

**【复杂度】**

- 构造矩阵:  $O(n)$  有效数据;
- 一般矩阵显式存储:  $O(n^2)$ ;
- 通用无结构特征值算法: 总成本通常按  $O(n^3)$  估计;
- 伴随矩阵已为 Hessenberg, 每次 QR 扫描为  $O(n^2)$ ;
- 利用伴随矩阵秩一加移位结构的专门算法, 可把求全部根的总成本降至  $O(n^2)$  并减少存储。

**【稳定性与条件数】** 伴随矩阵法把多项式系数扰动转化为矩阵扰动. 特征值算法可以对伴随矩阵后向稳定, 但这不自动意味着根相对原多项式系数前向准确:

后向稳定算法 + 病态根  $\implies$  仍可能有大前向误差。

此外, 多项式缩放、变量缩放和矩阵平衡会显著影响实际精度。

#### 伴随矩阵求三次多项式根

考虑  $p(z) = z^3 - 6z^2 + 11z - 6$ . 伴随矩阵为

$$C_p = \begin{pmatrix} 0 & 0 & 6 \\ 1 & 0 & -11 \\ 0 & 1 & 6 \end{pmatrix}. \quad (6.92)$$

由于  $p(z) = (z-1)(z-2)(z-3)$ , 其特征值应为 1, 2, 3。

例如对  $\zeta = 2$ ,  $\mathbf{v} = \begin{pmatrix} 1 \\ 2 \\ 4 \end{pmatrix}$  满足  $C_p^T \mathbf{v} = \begin{pmatrix} 2 \\ 4 \\ 8 \end{pmatrix} = 2\mathbf{v}$ 。因此 2 是  $C_p$  的特征值。其余两个根同理。

## 6.8 Bairstow 法：实系数多项式的共轭根对

### 6.8.1 知识点十八：二次因子与综合除法

【重要性等级】 **A 级**。Bairstow 法在 [SC-Li] 中被专门用于避免实系数多项式求复根时的复数运算。

设

$$p_n(z) = a_n z^n + \cdots + a_1 z + a_0, \quad a_j \in \mathbb{R}. \quad (6.93)$$

寻找二次因子

$$z^2 - uz - v. \quad (6.94)$$

将  $p_n$  写成

$$p_n(z) = (z^2 - uz - v)q_{n-2}(z) + b_1(z - u) + b_0. \quad (6.95)$$

若  $b_1(u, v) = 0$ ,  $b_0(u, v) = 0$ , 则  $z^2 - uz - v$  为  $p_n$  的精确因子。

令  $b_{n+2} = b_{n+1} = 0$ , 对  $k = n, n-1, \dots, 0$  递推

$$b_k = a_k + ub_{k+1} + vb_{k+2}. \quad (6.96)$$

则商为

$$q_{n-2}(z) = b_n z^{n-2} + b_{n-1} z^{n-3} + \cdots + b_2. \quad (6.97)$$

### 6.8.2 导数递推与二维 Newton 校正

定义  $c_{n+2} = c_{n+1} = 0$ , 并递推

$$c_k = b_{k+1} + uc_{k+1} + vc_{k+2}, \quad k = n, n-1, \dots, 0. \quad (6.98)$$

对式 (6.96) 关于  $u, v$  求导并归纳可得


$$\frac{\partial b_k}{\partial u} = c_k, \quad \frac{\partial b_k}{\partial v} = c_{k+1}. \quad (6.99)$$

因此方程组  $\mathcal{F}(u, v) = \begin{pmatrix} b_1(u, v) \\ b_0(u, v) \end{pmatrix} = \mathbf{0}$  的 Jacobian 为

$$J_{\mathcal{F}}(u, v) = \begin{pmatrix} c_1 & c_2 \\ c_0 & c_1 \end{pmatrix}. \quad (6.100)$$

Newton 校正  $(\Delta u, \Delta v)$  满足

$$\begin{pmatrix} c_1 & c_2 \\ c_0 & c_1 \end{pmatrix} \begin{pmatrix} \Delta u \\ \Delta v \end{pmatrix} = -\begin{pmatrix} b_1 \\ b_0 \end{pmatrix}. \quad (6.101)$$





若

$$D = c_1^2 - c_0 c_2 \neq 0, \quad (6.102)$$

则

$$\Delta u = \frac{b_0 c_2 - b_1 c_1}{D}, \quad (6.103)$$

$$\Delta v = \frac{b_1 c_0 - b_0 c_1}{D}. \quad (6.104)$$

更新

$$u \leftarrow u + \Delta u, \quad v \leftarrow v + \Delta v. \quad (6.105)$$

---

**Algorithm 25** Bairstow 二次因子迭代
 

---

**Input:** 实系数  $a_0, \dots, a_n$ ; 初值  $(u_0, v_0)$ ; 余项容差; 参数步长容差; 最大迭代次数

**Output:** 二次因子  $z^2 - uz - v$  及商多项式

```

1: for  $j = 0, 1, \dots$  do
2:   设置  $b_{n+2} = b_{n+1} = 0$ 
3:   for  $k = n, n-1, \dots, 0$  do
4:      $b_k \leftarrow a_k + ub_{k+1} + vb_{k+2}$ 
5:   end for
6:   if  $\max\{|b_0|, |b_1|\}$  满足余项容差 then
7:     返回因子和商系数  $b_n, \dots, b_2$ 
8:   end if
9:   设置  $c_{n+2} = c_{n+1} = 0$ 
10:  for  $k = n, n-1, \dots, 0$  do
11:     $c_k \leftarrow b_{k+1} + uc_{k+1} + vc_{k+2}$ 
12:  end for
13:   $D \leftarrow c_1^2 - c_0 c_2$ 
14:  if  $|D|$  过小 then
15:    报告“二维 Newton Jacobian 近奇异; 需换初值或重启”
16:    return
17:  end if
18:   $\Delta u \leftarrow (b_0 c_2 - b_1 c_1)/D$ 
19:   $\Delta v \leftarrow (b_1 c_0 - b_0 c_1)/D$ 
20:   $u \leftarrow u + \Delta u$ 
21:   $v \leftarrow v + \Delta v$ 
22:  if  $\max\{|\Delta u|, |\Delta v|\}$  满足参数步长容差 then
23:    重新检查  $b_0, b_1$  后决定是否停止
24:  end if
25: end for
26: Stopping criterion: 余项和参数步长联合判断
27: Complexity: 每次 Bairstow 迭代为  $O(n)$  运算、 $O(n)$  存储; 得到因子后降为  $n-2$  次多项式

```

---

二次方程  $z^2 - uz - v = 0$  的根为

$$z_{\pm} = \frac{u \pm \sqrt{u^2 + 4v}}{2}. \quad (6.106)$$

若  $u^2 + 4v < 0$ , 则得到一对复共轭根。若  $u^2 + 4v \geq 0$ , 则得到两个实根。



【收敛性】 Bairstow 法本质上是对  $b_1(u, v) = 0$ ,  $b_0(u, v) = 0$  应用二维 Newton 法。若目标二次因子对应的参数  $(u^*, v^*)$  为正则根, 即  $c_1^2 - c_0 c_2 \neq 0$  且初值充分接近, 则局部二次收敛。

【失败情形】

- 二次因子重数大, 参数 Jacobian 可能奇异;
- 两个因子非常接近,  $D$  可能很小;
- 初值差时迭代可能收敛到另一二次因子;
- 多项式系数尺度悬殊时递推可能上溢或下溢;
- 过早降次会把因子误差传播给剩余根;
- 高次聚集根问题本身可能严重病态。

### 6.8.3 综合例题: 求 $z^4 + 5z^2 + 4$ 的复共轭因子

完整题目叙述

对  $p(z) = z^4 + 5z^2 + 4$  使用 Bairstow 法。取初值  $u_0 = 0$ ,  $v_0 = -\frac{6}{5}$ 。计算前两次参数更新, 并说明最终得到的全部根。

第一次 Bairstow 迭代. 系数为  $a_4 = 1$ ,  $a_3 = 0$ ,  $a_2 = 5$ ,  $a_1 = 0$ ,  $a_0 = 4$ 。取  $u = 0$ ,  $v = -\frac{6}{5}$ 。由  $b$  递推:

$$\begin{aligned} b_4 &= 1, \\ b_3 &= 0, \\ b_2 &= 5 + v = 5 - \frac{6}{5} = \frac{19}{5}, \\ b_1 &= 0, \\ b_0 &= 4 + vb_2 = 4 - \frac{6}{5} \frac{19}{5} = -\frac{14}{25}. \end{aligned}$$


由  $c$  递推:

$$\begin{aligned} c_4 &= 0, \\ c_3 &= b_4 = 1, \\ c_2 &= b_3 + vc_4 = 0, \\ c_1 &= b_2 + vc_3 = \frac{19}{5} - \frac{6}{5} = \frac{13}{5}, \\ c_0 &= b_1 + vc_2 = 0. \end{aligned}$$

因此  $J_{\mathcal{F}} = \begin{pmatrix} 13/5 & 0 \\ 0 & 13/5 \end{pmatrix}$ 。Newton 校正满足  $\frac{13}{5}\Delta u = 0$ ,  $\frac{13}{5}\Delta v = \frac{14}{25}$ 。所以  $\Delta u = 0$ ,  $\Delta v = \frac{14}{65}$ 。得到

$$u_1 = 0, \quad v_1 = -\frac{6}{5} + \frac{14}{65} = -\frac{64}{65}. \quad (6.107)$$

□



第二次 Bairstow 迭代. 取  $u = 0$ ,  $v = -\frac{64}{65}$ . 有  $b_4 = 1$ ,  $b_3 = 0$ ,  $b_2 = 5 - \frac{64}{65} = \frac{261}{65}$ ,  $b_1 = 0$ , 以及

$$\begin{aligned} b_0 &= 4 + vb_2 \\ &= 4 - \frac{64}{65} \frac{261}{65} \\ &= \frac{196}{4225}. \end{aligned}$$

相应地,  $c_1 = b_2 + v = \frac{261}{65} - \frac{64}{65} = \frac{197}{65}$ , 并且  $c_0 = c_2 = 0$ . 因此  $\Delta u = 0$ ,  $\Delta v = -\frac{b_0}{c_1} = -\frac{196}{4225} \frac{65}{197} = -\frac{196}{12805}$ . 故

$$v_2 = -\frac{64}{65} - \frac{196}{12805} = -\frac{12804}{12805} \approx -0.9999219. \quad (6.108)$$

已经非常接近  $v^* = -1$ 。

极限参数为  $u^* = 0$ ,  $v^* = -1$ , 对应因子  $z^2 - 0z - (-1) = z^2 + 1$ . 其根为  $z = \pm i$ . 在该参数下,  $b_2 = 4$ , 故商多项式为  $q(z) = z^2 + 4$ , 其根为  $z = \pm 2i$ . 因此  $p$  的全部根为

$$\boxed{i, -i, 2i, -2i}. \quad (6.109)$$

□

#### 易错点与反例

不同教材常把二次因子写成  $z^2 + rz + s$  或  $z^2 - rz - s$ . 相应的综合除法递推和 Newton 校正符号会改变. 本文全文采用  $z^2 - uz - v$ ,  $b_k = a_k + ub_{k+1} + vb_{k+2}$ . 不得从其他符号约定中只抄一半公式。



# 第七章 ODE 适定性、单步法、Euler、梯形、Runge–Kutta 及局部与整体误差

## 7.1 常微分方程初值问题的适定性

### 7.1.1 知识点一：初值问题、解流与适定性

【重要性等级】 **S 级**。数值格式只有在连续问题本身适时才具有明确意义。必须区分：

1. 连续初值问题是否存在唯一解；
2. 解对初值、右端项扰动是否连续依赖；
3. 离散算法是否稳定；
4. 离散解是否收敛到连续解。

考虑向量值初值问题

$$\begin{cases} \mathbf{y}'(t) = \mathbf{f}(t, \mathbf{y}(t)), & t_0 \leq t \leq T, \\ \mathbf{y}(t_0) = \mathbf{y}_0, & \mathbf{y}_0 \in \mathbb{R}^d, \end{cases} \quad (7.1)$$

其中  $\mathbf{f}: \mathcal{D} \subset \mathbb{R} \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 。本文固定一个向量范数  $\|\cdot\|$ ；所有 Lipschitz 常数、误差界和诱导矩阵范数均相对于该范数定义。

若对任意起始时刻  $s$  和初值  $\mathbf{v}$ ，方程存在唯一解，则记其解流为

$$\varphi_{t,s}(\mathbf{v}) = \mathbf{y}(t; s, \mathbf{v}). \quad (7.2)$$

解流满足半群关系

$$\varphi_{t,r} \circ \varphi_{r,s} = \varphi_{t,s}, \quad s \leq r \leq t. \quad (7.3)$$

单步数值方法的本质是构造  $\Psi_h(t, \mathbf{v}) \approx \varphi_{t+h,t}(\mathbf{v})$ 。

定理 7.1 (Picard–Lindelöf 局部存在唯一性定理). 设  $\mathcal{R} = [t_0 - a, t_0 + a] \times \overline{B}(\mathbf{y}_0, b) \subset \mathcal{D}$ ，并假设：


1.  $\mathbf{f}$  在  $\mathcal{R}$  上连续；
2. 存在  $L \geq 0$ ，使对任意  $(t, \mathbf{y}), (t, \mathbf{z}) \in \mathcal{R}$ ,

$$\|\mathbf{f}(t, \mathbf{y}) - \mathbf{f}(t, \mathbf{z})\| \leq L \|\mathbf{y} - \mathbf{z}\|. \quad (7.4)$$

令  $M = \sup_{(t, \mathbf{y}) \in \mathcal{R}} \|\mathbf{f}(t, \mathbf{y})\|$ 。若选择

$$0 < \delta \leq \min \left\{ a, \frac{b}{M}, \frac{1}{2L} \right\}, \quad (7.5)$$

其中  $M = 0$  或  $L = 0$  时相应分式理解为  $+\infty$ ，则初值问题式 (7.1) 在  $[t_0, t_0 + \delta]$  上存在唯一解。



证明. 令  $X = \{v \in C([t_0, t_0 + \delta]; \mathbb{R}^d) : \sup_{t_0 \leq t \leq t_0 + \delta} \|v(t) - y_0\| \leq b\}$ , 并赋予一致范数  $\|v\|_\infty = \sup_{t_0 \leq t \leq t_0 + \delta} \|v(t)\|$ .  $X$  是 Banach 空间中闭集, 因而自身完备。

定义 Picard 算子

$$(\mathcal{T}v)(t) = y_0 + \int_{t_0}^t f(s, v(s)) \, ds. \quad (7.6)$$

对任意  $v \in X$ ,

$$\begin{aligned} \|(\mathcal{T}v)(t) - y_0\| &\leq \int_{t_0}^t \|f(s, v(s))\| \, ds \\ &\leq M\delta \leq b. \end{aligned} \quad (7.7)$$

故  $\mathcal{T}(X) \subset X$ 。

对任意  $v, w \in X$ ,

$$\begin{aligned} \|\mathcal{T}v - \mathcal{T}w\|_\infty &\leq L\delta \|v - w\|_\infty \\ &\leq \frac{1}{2} \|v - w\|_\infty. \end{aligned} \quad (7.8)$$

因此  $\mathcal{T}$  为压缩映射。Banach 不动点定理给出唯一  $y \in X$  满足  $\mathcal{T}y = y$ 。这等价于积分方程  $y(t) = y_0 + \int_{t_0}^t f(s, y(s)) \, ds$ 。由  $f$  连续, 可对上式求导, 得到  $y'(t) = f(t, y(t))$ 。故  $y$  即为初值问题的唯一局部解。□

#### 易错点与反例

仅有  $f$  连续通常只能保证局部解存在, 不能保证唯一性。例如  $y' = 2\sqrt{|y|}$ ,  $y(0) = 0$  具有多个解。数值迭代即使稳定, 也不能替连续问题恢复唯一性。

### 7.1.2 知识点二: 初值和右端项扰动的连续依赖

考虑两个问题

$$y'(t) = f(t, y(t)), \quad y(t_0) = y_0, \quad (7.9)$$

$$\tilde{y}'(t) = \tilde{f}(t, \tilde{y}(t)), \quad \tilde{y}(t_0) = \tilde{y}_0. \quad (7.10)$$

假设  $f$  关于第二变量满足式 (7.4), 并定义右端项扰动

$$\delta_f(t) = \sup_{z \in \mathcal{K}} \|f(t, z) - \tilde{f}(t, z)\|, \quad (7.11)$$

其中  $\mathcal{K}$  包含两条解曲线。

定理 7.2 (ODE 解的连续依赖估计). 在上述条件下, 对  $t \in [t_0, T]$ ,

$$\begin{aligned} \|y(t) - \tilde{y}(t)\| &\leq e^{L(t-t_0)} \|y_0 - \tilde{y}_0\| \\ &\quad + \int_{t_0}^t e^{L(t-s)} \delta_f(s) \, ds. \end{aligned} \quad (7.12)$$

证明. 由两个积分方程相减,

$$\begin{aligned} y(t) - \tilde{y}(t) &= y_0 - \tilde{y}_0 \\ &\quad + \int_{t_0}^t [f(s, y(s)) - f(s, \tilde{y}(s))] \, ds \\ &\quad + \int_{t_0}^t [f(s, \tilde{y}(s)) - \tilde{f}(s, \tilde{y}(s))] \, ds. \end{aligned} \quad (7.13)$$



取范数得

$$\begin{aligned}\|\mathbf{y}(t) - \tilde{\mathbf{y}}(t)\| &\leq \|\mathbf{y}_0 - \tilde{\mathbf{y}}_0\| \\ &\quad + L \int_{t_0}^t \|\mathbf{y}(s) - \tilde{\mathbf{y}}(s)\| \, ds + \int_{t_0}^t \delta_f(s) \, ds.\end{aligned}\quad (7.14)$$

应用积分型 Gronwall 不等式即得 式 (7.12)。□

**【条件数解释】** 对固定终止时间  $T$ ，初值扰动的放大因子至多为  $e^{L(T-t_0)}$ 。因此，即使数值算法完全稳定，长时间积分仍可能因连续问题本身的敏感性而产生较大误差。

若系统满足更强的单边 Lipschitz 条件

$$\langle \mathbf{f}(t, \mathbf{y}) - \mathbf{f}(t, \mathbf{z}), \mathbf{y} - \mathbf{z} \rangle \leq \mu \|\mathbf{y} - \mathbf{z}\|_2^2, \quad (7.15)$$

则可得到  $\|\mathbf{y}(t) - \tilde{\mathbf{y}}(t)\|_2 \leq e^{\mu(t-t_0)} \|\mathbf{y}_0 - \tilde{\mathbf{y}}_0\|_2$ 。当  $\mu < 0$  时，连续解流具有收缩性。这种耗散结构对第 09 部分的刚性方法和 B 稳定性非常重要。

## 7.2 离散 Gronwall 不等式与单步法统一误差分析

### 7.2.1 知识点三：离散 Gronwall 不等式

引理 7.3 (常数离散 Gronwall 不等式). 设非负序列  $\{a_n\}$  满足

$$a_{n+1} \leq (1 + hL)a_n + hg_n, \quad n = 0, \dots, N-1, \quad (7.16)$$

其中  $h, L, g_n \geq 0$ 。则

$$a_n \leq (1 + hL)^n a_0 + h \sum_{j=0}^{n-1} (1 + hL)^{n-1-j} g_j. \quad (7.17)$$

特别地，若  $g_j \leq G$ ,  $t_n = t_0 + nh$ ，则当  $L > 0$  时，

$$a_n \leq e^{L(t_n - t_0)} a_0 + \frac{G}{L} (e^{L(t_n - t_0)} - 1). \quad (7.18)$$

当  $L = 0$  时，

$$a_n \leq a_0 + (t_n - t_0)G. \quad (7.19)$$

证明. 反复代入 式 (15.52) 可得 式 (7.17)。再利用  $1 + hL \leq e^{hL}$  以及有限几何级数公式即得结论。□

还经常使用隐式型递推：若

$$(1 - hL)a_{n+1} \leq a_n + hg_n, \quad hL < 1, \quad (7.20)$$

则  $a_{n+1} \leq \frac{1}{1-hL} a_n + \frac{h}{1-hL} g_n$ 。此时每一步的放大因子是  $q_h = \frac{1}{1-hL} = 1 + hL + O(h^2)$ 。


### 7.2.2 知识点四：单步法、局部缺陷与整体误差

一般单步法写成

$$\boxed{\mathbf{u}_{n+1} = \mathbf{u}_n + h\Phi(t_n, \mathbf{u}_n, h)}, \quad t_n = t_0 + nh. \quad (7.21)$$

相应数值一步映射为

$$\Psi_h(t, \mathbf{v}) = \mathbf{v} + h\Phi(t, \mathbf{v}, h). \quad (7.22)$$





定义 7.4 (未归一化局部缺陷). 从精确值  $\mathbf{y}(t_n)$  出发做一步数值更新时, 定义局部缺陷

$$\mathbf{d}_{n+1} = \mathbf{y}(t_{n+1}) - \mathbf{y}(t_n) - h\Phi(t_n, \mathbf{y}(t_n), h). \quad (7.23)$$

若

$$\|\mathbf{d}_{n+1}\| \leq Ch^{p+1} \quad (7.24)$$

在  $0 \leq n \leq N-1$  上一致成立, 则称方法具有  $p$  阶局部精度。

部分教材使用归一化局部截断误差

$$\tau_{n+1} = \frac{\mathbf{d}_{n+1}}{h}. \quad (7.25)$$

于是  $\mathbf{d}_{n+1} = O(h^{p+1}) \iff \tau_{n+1} = O(h^p)$ 。考试中必须先说明采用哪一种定义, 否则“局部误差阶”可能相差 1。

定义 7.5 (一致性). 单步法称为一致的, 若

$$\Phi(t, \mathbf{y}, 0) = \mathbf{f}(t, \mathbf{y}), \quad (7.26)$$

或更一般地,  $\Phi(t, \mathbf{y}, h) \rightarrow \mathbf{f}(t, \mathbf{y})$  ( $h \rightarrow 0$ ) 在所考察紧集上一致成立。

若  $\mathbf{y}$  是精确解, 则  $\frac{\mathbf{y}(t+h) - \mathbf{y}(t)}{h} \rightarrow \mathbf{f}(t, \mathbf{y}(t))$ , 故一致性等价于  $\tau_{n+1} \rightarrow \mathbf{0}$ 。

定义 7.6 (整体误差). 在网格点  $t_n$  处定义整体误差

$$\mathbf{e}_n = \mathbf{y}(t_n) - \mathbf{u}_n. \quad (7.27)$$

若  $\max_{0 \leq n \leq N} \|\mathbf{e}_n\| \leq Ch^p$ , 则称方法在  $[t_0, T]$  上一致  $p$  阶收敛。

定理 7.7 (单步法的局部误差到整体误差定理). 设:

1. 精确解  $\mathbf{y}(t)$  在  $[t_0, T]$  上存在;
2. 存在  $L_\Phi > 0$ , 使对充分小的  $h$ ,

$$\|\Phi(t, \mathbf{v}, h) - \Phi(t, \mathbf{w}, h)\| \leq L_\Phi \|\mathbf{v} - \mathbf{w}\|; \quad (7.28)$$

3. 局部缺陷满足  $\|\mathbf{d}_{n+1}\| \leq C_d h^{p+1}$ ;
4. 初值误差满足  $\|\mathbf{e}_0\| \leq C_0 h^p$ .

则

$$\max_{0 \leq n \leq N} \|\mathbf{e}_n\| \leq \left[ e^{L_\Phi(T-t_0)} C_0 + \frac{C_d}{L_\Phi} (e^{L_\Phi(T-t_0)} - 1) \right] h^p \quad (7.29)$$

当  $L_\Phi > 0$ 。若  $L_\Phi = 0$ , 则第二项替换为  $C_d(T-t_0)h^p$ 。


证明. 精确解满足  $\mathbf{y}(t_{n+1}) = \mathbf{y}(t_n) + h\Phi(t_n, \mathbf{y}(t_n), h) + \mathbf{d}_{n+1}$ 。减去数值格式 (7.21), 得到

$$\mathbf{e}_{n+1} = \mathbf{e}_n + h[\Phi(t_n, \mathbf{y}(t_n), h) - \Phi(t_n, \mathbf{u}_n, h)] + \mathbf{d}_{n+1}. \quad (7.30)$$

因此

$$\|\mathbf{e}_{n+1}\| \leq (1 + hL_\Phi) \|\mathbf{e}_n\| + C_d h^{p+1}. \quad (7.31)$$

在离散 Gronwall 不等式中取  $a_n = \|\mathbf{e}_n\|$ ,  $g_n = C_d h^p$ , 即可得到 (7.29)。□



## 单步法收敛阶证明模板

资格考试中，证明单步法  $p$  阶收敛通常按以下顺序书写：

1. 定义局部缺陷  $\mathbf{d}_{n+1} = \mathbf{y}(t_{n+1}) - \Psi_h(t_n, \mathbf{y}(t_n))$ .
2. **Taylor** 展开或求积误差  $\|\mathbf{d}_{n+1}\| \leq Ch^{p+1}$ .
3. 精确一步减数值一步，得到误差递推。
4. 用右端项或增量函数的 **Lipschitz** 性估计误差传播。
5. 应用离散 **Gronwall** 不等式。
6. 明确写出  $\max_n \|\mathbf{e}_n\| = O(h^p)$ .

不能只根据 Taylor 展开写出“局部误差为  $O(h^{p+1})$ ，故整体误差为  $O(h^p)$ ”，而不控制误差传播。

## 7.2.3 知识点五：扰动稳定性

考虑受扰动的离散格式

$$\tilde{\mathbf{u}}_{n+1} = \tilde{\mathbf{u}}_n + h\Phi(t_n, \tilde{\mathbf{u}}_n, h) + \boldsymbol{\eta}_{n+1}. \quad (7.32)$$

令  $\mathbf{z}_n = \mathbf{u}_n - \tilde{\mathbf{u}}_n$ 。则  $\|\mathbf{z}_{n+1}\| \leq (1 + hL_\Phi) \|\mathbf{z}_n\| + \|\boldsymbol{\eta}_{n+1}\|$ 。因此

$$\|\mathbf{z}_n\| \leq (1 + hL_\Phi)^n \|\mathbf{z}_0\| + \sum_{j=0}^{n-1} (1 + hL_\Phi)^{n-1-j} \|\boldsymbol{\eta}_{j+1}\|. \quad (7.33)$$

若扰动写成  $\boldsymbol{\eta}_{n+1} = h\mathbf{r}_{n+1}$ ，则它与右端项扰动具有相同量纲。若每一步直接产生大小  $O(u)$  的浮点舍入扰动，则最坏情况下经过  $O(h^{-1})$  步可能积累为  $O(u/h)$ 。

## 易错点与反例

必须区分以下四个概念：

1. 局部缺陷：从精确值出发只走一步产生的误差；
2. 整体误差：所有局部误差传播并累积后的结果；
3. 零稳定性：当  $h \rightarrow 0$  而区间长度固定时，对离散扰动的控制；
4. 绝对稳定性：对测试方程  $y' = \lambda y$ ，固定  $z = h\lambda$  并考察长时间迭代。

一般单步法不存在多步法的寄生根问题；只要一步映射具有适当 Lipschitz 稳定性，一致性通常即可推出收敛。第 08 部分将说明线性多步法为什么还需要根条件。


## 7.3 Euler 方法、梯形法与二阶基本单步格式

## 7.3.1 知识点六：前向 Euler 方法

前向 Euler 方法为

$$\mathbf{u}_{n+1} = \mathbf{u}_n + h\mathbf{f}(t_n, \mathbf{u}_n). \quad (7.34)$$

它可由积分方程  $\mathbf{y}(t_{n+1}) = \mathbf{y}(t_n) + \int_{t_n}^{t_{n+1}} \mathbf{f}(s, \mathbf{y}(s)) \, ds$  对积分使用左矩形公式得到。



若  $\mathbf{y} \in C^2$ , 则

$$\mathbf{y}(t_{n+1}) = \mathbf{y}(t_n) + h\mathbf{y}'(t_n) + \int_{t_n}^{t_{n+1}} (t_{n+1} - s)\mathbf{y}''(s) \, ds. \quad (7.35)$$

因此局部缺陷为

$$\mathbf{d}_{n+1}^{\text{FE}} = \int_{t_n}^{t_{n+1}} (t_{n+1} - s)\mathbf{y}''(s) \, ds, \quad (7.36)$$

从而

$$\|\mathbf{d}_{n+1}^{\text{FE}}\| \leq \frac{h^2}{2} M_2, \quad M_2 = \max_{t_0 \leq t \leq T} \|\mathbf{y}''(t)\|. \quad (7.37)$$

所以前向 Euler 方法局部缺陷为  $O(h^2)$ 。

若  $\mathbf{f}$  关于  $\mathbf{y}$  的 Lipschitz 常数为  $L$ , 则  $\|\mathbf{e}_{n+1}\| \leq (1 + hL)\|\mathbf{e}_n\| + \frac{M_2}{2}h^2$ 。于是当  $L > 0$  时,

$$\|\mathbf{e}_n\| \leq e^{L(t_n - t_0)} \|\mathbf{e}_0\| + \frac{M_2}{2L} (e^{L(t_n - t_0)} - 1) h. \quad (7.38)$$

若  $\mathbf{e}_0 = \mathbf{0}$ , 则  $\max_n \|\mathbf{e}_n\| = O(h)$ 。

#### Algorithm 26 前向 Euler 方法

**Input:**  $\mathbf{f}$ ; 初值  $(t_0, \mathbf{u}_0)$ ; 终止时间  $T$ ; 步长  $h$

**Output:** 网格解  $\{\mathbf{u}_n\}$

- 1:  $N \leftarrow \lceil (T - t_0)/h \rceil$
- 2: **for**  $n = 0, 1, \dots, N - 1$  **do**
- 3:   必要时令  $h_n \leftarrow \min\{h, T - t_n\}$
- 4:    $\mathbf{u}_{n+1} \leftarrow \mathbf{u}_n + h_n \mathbf{f}(t_n, \mathbf{u}_n)$
- 5:    $t_{n+1} \leftarrow t_n + h_n$
- 6: **end for**
- 7: **Stopping criterion:** 到达终止时间  $T$
- 8: **Complexity:** 每步一次右端项计算; 若单次成本为  $C_f$ , 总时间  $O(NC_f)$ , 滚动存储  $O(d)$

**【适用条件】** 前向 Euler 方法适合:

- 非刚性问题;
- 低精度预测;
- 构造显式预测-校正方法;
- 分析高阶格式的基本稳定性;
- 作为 SSP 方法的基本构件。

其主要缺点是精度低, 且绝对稳定域有界。对刚性问题, 稳定性而非精度常迫使  $h$  极小。

### 7.3.2 知识点七: 后向 Euler 方法

后向 Euler 方法为

$$\mathbf{u}_{n+1} = \mathbf{u}_n + h\mathbf{f}(t_{n+1}, \mathbf{u}_{n+1}). \quad (7.39)$$

每一步需要求解非线性方程

$$\mathbf{G}_n(\mathbf{v}) = \mathbf{v} - \mathbf{u}_n - h\mathbf{f}(t_{n+1}, \mathbf{v}) = \mathbf{0}. \quad (7.40)$$



若  $f$  关于  $y$  的 Lipschitz 常数为  $L$ , 且  $hL < 1$ , 则映射  $\mathcal{T}_n(v) = u_n + hf(t_{n+1}, v)$  为压缩映射, 故每一步存在唯一解。这只是充分条件, 不是必要条件。

局部缺陷为

$$\begin{aligned} d_{n+1}^{\text{BE}} &= y(t_{n+1}) - y(t_n) - hy'(t_{n+1}) \\ &= - \int_{t_n}^{t_{n+1}} (s - t_n) y''(s) \, ds, \end{aligned} \quad (7.41)$$

故  $\|d_{n+1}^{\text{BE}}\| \leq \frac{M_2}{2} h^2$ 。后向 Euler 方法也是一阶方法。

误差满足

$$(1 - hL) \|e_{n+1}\| \leq \|e_n\| + \frac{M_2}{2} h^2. \quad (7.42)$$

在固定时间区间内、 $hL < 1$  时, 由隐式型离散 Gronwall 不等式得到  $\max_n \|e_n\| = O(h)$ 。

#### 易错点与反例

“隐式”不等于“无条件容易求解”。

后向 Euler 每一步需要求解  $G_n(v) = 0$ 。对非线性系统, 必须给出:

- 初始猜测, 例如显式 Euler 预测值;
- Newton 或拟 Newton 迭代;
- 内层停止准则;
- 线性系统求解方法;
- Newton 失败或步长拒绝机制。

时间离散格式的稳定性不能替代非线性求解器的收敛性。

### 7.3.3 知识点八: 隐式梯形方法

隐式梯形方法为

$$u_{n+1} = u_n + \frac{h}{2} [f(t_n, u_n) + f(t_{n+1}, u_{n+1})]. \quad (7.43)$$

它来自对积分方程使用梯形求积。在 PDE 时间离散中, 该方法常称为 Crank–Nicolson 方法。

若  $y \in C^3$ , 则

$$\begin{aligned} d_{n+1}^{\text{TR}} &= y(t_{n+1}) - y(t_n) - \frac{h}{2} [y'(t_n) + y'(t_{n+1})] \\ &= -\frac{1}{2} \int_{t_n}^{t_{n+1}} (s - t_n)(t_{n+1} - s) y'''(s) \, ds. \end{aligned} \quad (7.44)$$

因此


$$\|d_{n+1}^{\text{TR}}\| \leq \frac{M_3}{12} h^3, \quad M_3 = \max_{t_0 \leq t \leq T} \|y'''(t)\|. \quad (7.45)$$

误差满足

$$\|e_{n+1}\| \leq \|e_n\| + \frac{hL}{2} (\|e_n\| + \|e_{n+1}\|) + \frac{M_3}{12} h^3. \quad (7.46)$$

若  $hL < 2$ , 则

$$\|e_{n+1}\| \leq q_h \|e_n\| + \frac{M_3 h^3}{12(1 - hL/2)}, \quad q_h = \frac{1 + hL/2}{1 - hL/2}. \quad (7.47)$$



反复迭代得到

$$\|e_n\| \leq q_h^n \|e_0\| + \frac{M_3}{12L} (q_h^n - 1) h^2. \quad (7.48)$$

故在固定区间上  $\max_n \|e_n\| = O(h^2)$ 。

### 7.3.4 知识点九：显式梯形、显式中点与隐式中点

显式梯形法或 **Heun 法** 先用前向 Euler 预测：

$$\hat{u}_{n+1} = u_n + h f(t_n, u_n), \quad (7.49)$$

再校正：

$$u_{n+1} = u_n + \frac{h}{2} [f(t_n, u_n) + f(t_{n+1}, \hat{u}_{n+1})]. \quad (7.50)$$

令  $\mathcal{D}f = f_t + f_y f$  表示沿精确解方向的全导数。则

$$f(t+h, y + hf(t, y)) = f(t, y) + h\mathcal{D}f(t, y) + O(h^2). \quad (7.51)$$

故显式梯形法从精确值出发的一步结果为  $y + hf + \frac{h^2}{2}\mathcal{D}f + O(h^3)$ ，与精确解 Taylor 展开一致到  $h^2$  项，因此是二阶方法。

显式中点法

$$k_1 = f(t_n, u_n), \quad (7.52)$$

$$k_2 = f\left(t_n + \frac{h}{2}, u_n + \frac{h}{2}k_1\right), \quad (7.53)$$

$$u_{n+1} = u_n + hk_2. \quad (7.54)$$


它也是二阶显式 Runge-Kutta 方法。

隐式中点法

$$u_{n+1} = u_n + hf\left(t_n + \frac{h}{2}, \frac{u_n + u_{n+1}}{2}\right). \quad (7.55)$$

该方法为二阶隐式方法，并具有良好的几何结构；例如对 Hamilton 系统，它是辛方法。

| 方法       | 更新形式摘要                     | 整体阶 | 每步主要工作   | 测试方程稳定函数                |
|----------|----------------------------|-----|----------|-------------------------|
| 前向 Euler | $u_{n+1} = u_n + hf_n$     | 1   | 1 次函数值   | $1 + z$                 |
| 后向 Euler | $u_{n+1} = u_n + hf_{n+1}$ | 1   | 1 个非线性方程 | $\frac{1}{1-z}$         |
| 显式梯形     | Euler 预测后取两端斜率平均           | 2   | 2 次函数值   | $1 + z + \frac{z^2}{2}$ |
| 显式中点     | 在预测中点处取斜率                  | 2   | 2 次函数值   | $1 + z + \frac{z^2}{2}$ |
| 隐式中点     | 在状态和时间中点处取斜率               | 2   | 1 个非线性方程 | $\frac{1+z/2}{1-z/2}$   |



| 方法   | 更新形式摘要   | 整体阶 | 每步主要工作   | 测试方程稳定函数              |
|------|----------|-----|----------|-----------------------|
| 隐式梯形 | 两端隐式斜率平均 | 2   | 1 个非线性方程 | $\frac{1+z/2}{1-z/2}$ |

### 易错点与反例

显式梯形法与隐式梯形法名称相近，但不是同一方法：

显式梯形：  $f(t_{n+1}, \mathbf{u}_n + hf_n)$ ，而 隐式梯形：  $f(t_{n+1}, \mathbf{u}_{n+1})$ 。前者每步只做函数计算，后者每步需要求解非线性方程。

## 7.4 Runge-Kutta 方法的统一表示与阶条件

### 7.4.1 知识点十：Butcher 表与阶段方程

$s$  阶段 Runge-Kutta 方法写为

$$\mathbf{K}_i = \mathbf{f} \left( t_n + c_i h, \mathbf{u}_n + h \sum_{j=1}^s a_{ij} \mathbf{K}_j \right), \quad i = 1, \dots, s, \quad (7.56)$$

$$\mathbf{u}_{n+1} = \mathbf{u}_n + h \sum_{i=1}^s b_i \mathbf{K}_i. \quad (7.57)$$

记  $A = (a_{ij})_{i,j=1}^s$ ,  $\mathbf{b} = (b_1, \dots, b_s)^\top$ ,  $\mathbf{c} = (c_1, \dots, c_s)^\top$ 。其 Butcher 表为

$$\begin{array}{c|c} \mathbf{c} & A \\ \hline & \mathbf{b}^\top \end{array}. \quad (7.58)$$

通常要求内部一致性

$$\boxed{\mathbf{c} = A\mathbf{1}}, \quad (7.59)$$

其中  $\mathbf{1} = (1, \dots, 1)^\top$ 。

- 若  $A$  严格下三角，则为显式 Runge-Kutta 方法；
- 若  $A$  下三角且对角元可非零，则为对角隐式 RK 方法；
- 若  $A$  为一般稠密矩阵，则各阶段通常需要联立求解。

#### Algorithm 27 $s$ 阶段显式 Runge-Kutta 方法

**Input:** 严格下三角  $A$ ；权重  $\mathbf{b}$ ；节点  $\mathbf{c}$ ； $\mathbf{f}$ ； $(t_n, \mathbf{u}_n)$ ；步长  $h$

**Output:**  $\mathbf{u}_{n+1}$

- 1: **for**  $i = 1, 2, \dots, s$  **do**
- 2:      $\mathbf{Y}_i \leftarrow \mathbf{u}_n + h \sum_{j=1}^{i-1} a_{ij} \mathbf{K}_j$
- 3:      $\mathbf{K}_i \leftarrow \mathbf{f}(t_n + c_i h, \mathbf{Y}_i)$
- 4: **end for**
- 5:  $\mathbf{u}_{n+1} \leftarrow \mathbf{u}_n + h \sum_{i=1}^s b_i \mathbf{K}_i$
- 6: **Stopping criterion:** 完成  $s$  个阶段
- 7: **Complexity:** 每步  $s$  次右端项计算；朴素存储  $O(sd)$ ，低存储实现可降至  $O(d)$





## 7.4.2 知识点十一：二阶段显式 RK 方法的阶条件

考虑

$$\mathbf{K}_1 = \mathbf{f}(t_n, \mathbf{u}_n), \quad (7.60)$$

$$\mathbf{K}_2 = \mathbf{f}(t_n + c_2 h, \mathbf{u}_n + a_{21} h \mathbf{K}_1), \quad (7.61)$$

$$\mathbf{u}_{n+1} = \mathbf{u}_n + h(b_1 \mathbf{K}_1 + b_2 \mathbf{K}_2). \quad (7.62)$$

内部一致性给出  $c_2 = a_{21}$ 。令  $\mathbf{f} = \mathbf{f}(t, \mathbf{y})$ ,  $\mathcal{D}\mathbf{f} = \mathbf{f}_t + \mathbf{f}_y \mathbf{f}$ 。则  $\mathbf{K}_2 = \mathbf{f} + c_2 h \mathcal{D}\mathbf{f} + O(h^2)$ 。所以数值一步为

$$\mathbf{u}_{n+1} = \mathbf{u}_n + h(b_1 + b_2)\mathbf{f} + h^2 b_2 c_2 \mathcal{D}\mathbf{f} + O(h^3). \quad (7.63)$$

与精确展开  $\mathbf{y}(t+h) = \mathbf{y}(t) + h\mathbf{f} + \frac{h^2}{2}\mathcal{D}\mathbf{f} + O(h^3)$  比较, 二阶条件为

$$\boxed{b_1 + b_2 = 1, \quad b_2 c_2 = \frac{1}{2}}. \quad (7.64)$$

因此对任意  $c_2 \neq 0$ , 可取

$$a_{21} = c_2, \quad b_2 = \frac{1}{2c_2}, \quad b_1 = 1 - \frac{1}{2c_2}. \quad (7.65)$$

典型选择为:

|                                                                        |               |
|------------------------------------------------------------------------|---------------|
| $c_2 = 1: \quad b_1 = b_2 = \frac{1}{2},$                              | 显式梯形法;        |
| $c_2 = \frac{1}{2}: \quad b_1 = 0, \quad b_2 = 1,$                     | 显式中点法;        |
| $c_2 = \frac{2}{3}: \quad b_1 = \frac{1}{4}, \quad b_2 = \frac{3}{4},$ | Ralston 二阶方法。 |

## 7.4.3 知识点十二：一般 RK 阶条件

令  $C = \text{diag}(c_1, \dots, c_s)$ , 并用  $\mathbf{c}^{\circ q} = (c_1^q, \dots, c_s^q)^\top$  表示分量幂。在内部一致性  $\mathbf{c} = A\mathbf{1}$  下, 经典阶条件前四阶为:

一阶

$$\mathbf{b}^\top \mathbf{1} = 1. \quad (7.66)$$

二阶

$$\mathbf{b}^\top \mathbf{c} = \frac{1}{2}. \quad (7.67)$$

三阶

$$\mathbf{b}^\top \mathbf{c}^{\circ 2} = \frac{1}{3}, \quad \mathbf{b}^\top A \mathbf{c} = \frac{1}{6}. \quad (7.68)$$



四阶

$$\mathbf{b}^\top \mathbf{c}^{\circ 3} = \frac{1}{4}, \quad (7.69)$$

$$\mathbf{b}^\top C A \mathbf{c} = \frac{1}{8}, \quad (7.70)$$

$$\mathbf{b}^\top A \mathbf{c}^{\circ 2} = \frac{1}{12}, \quad (7.71)$$

$$\mathbf{b}^\top A^2 \mathbf{c} = \frac{1}{24}. \quad (7.72)$$

从三阶起, 单纯比较一元 Taylor 系数不再足够; 不同的复合导数对应不同的根树, 必须分别匹配。

#### 7.4.4 知识点十三: 经典四阶 Runge-Kutta 方法

经典 RK4 的 Butcher 表为

$$\begin{array}{c|cccc} 0 & 0 & 0 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ \hline & \frac{1}{6} & \frac{1}{3} & \frac{1}{3} & \frac{1}{6} \end{array}. \quad (7.73)$$

即

$$\mathbf{K}_1 = \mathbf{f}(t_n, \mathbf{u}_n), \quad (7.74)$$

$$\mathbf{K}_2 = \mathbf{f}\left(t_n + \frac{h}{2}, \mathbf{u}_n + \frac{h}{2}\mathbf{K}_1\right), \quad (7.75)$$

$$\mathbf{K}_3 = \mathbf{f}\left(t_n + \frac{h}{2}, \mathbf{u}_n + \frac{h}{2}\mathbf{K}_2\right), \quad (7.76)$$

$$\mathbf{K}_4 = \mathbf{f}(t_n + h, \mathbf{u}_n + h\mathbf{K}_3), \quad (7.77)$$

$$\mathbf{u}_{n+1} = \mathbf{u}_n + \frac{h}{6}(\mathbf{K}_1 + 2\mathbf{K}_2 + 2\mathbf{K}_3 + \mathbf{K}_4). \quad (7.78)$$

在足够光滑条件下,  $\mathbf{d}_{n+1}^{\text{RK4}} = O(h^5)$ ,  $\max_n \|\mathbf{e}_n\| = O(h^4)$ 。

#### 7.4.5 知识点十四: RK 稳定函数

对测试方程

$$y' = \lambda y, \quad z = h\lambda, \quad (7.79)$$

阶段向量满足  $\mathbf{K} = \lambda(y_n \mathbf{1} + hA\mathbf{K})$ 。故  $(I - zA)\mathbf{K} = \lambda y_n \mathbf{1}$ 。代入更新式得

$$y_{n+1} = R(z)y_n, \quad (7.80)$$

其中

$$R(z) = 1 + z\mathbf{b}^\top (I - zA)^{-1} \mathbf{1}. \quad (7.81)$$

绝对稳定域定义为

$$\mathcal{S} = \{z \in \mathbb{C} : |R(z)| \leq 1\}. \quad (7.82)$$

显式  $s$  阶段 RK 方法的  $R(z)$  是次数不超过  $s$  的多项式, 因此其绝对稳定域必为有界集合; 任何显式 RK 方法都不可能 A 稳定。

经典 RK4 的稳定函数为

$$R_{\text{RK4}}(z) = 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \frac{z^4}{24}. \quad (7.83)$$



## 7.5 补充训练题：丘赛 2021 Problem 5——半隐式二阶段 Runge-Kutta 族

### 完整题目叙述

考虑自治常微分方程  $\mathbf{y}' = \mathbf{f}(\mathbf{y})$  以及如下半隐式 Runge-Kutta 方法族：

$$\mathbf{k}_1 = \mathbf{f}(\mathbf{y}_n + \beta h \mathbf{k}_1), \quad (7.84)$$

$$\mathbf{k}_2 = \mathbf{f}(\mathbf{y}_n + h \mathbf{k}_1 + \beta h \mathbf{k}_2), \quad (7.85)$$

$$\mathbf{y}_{n+1} = \mathbf{y}_n + h \left[ \left( \frac{1}{2} + \beta \right) \mathbf{k}_1 + \left( \frac{1}{2} - \beta \right) \mathbf{k}_2 \right]. \quad (7.86)$$

(a) 确定该方法的阶，并求局部截断误差的主部。

(b) 证明：若  $\beta > \frac{1}{2}$ ，则整个负实轴  $\{z \in \mathbb{C} : \operatorname{Re} z < 0, \operatorname{Im} z = 0\}$  均包含在该方法的绝对稳定域中。

第 (a) 问：阶与局部缺陷主部。该方法的 Butcher 表为

$$\begin{array}{c|cc} \beta & \beta & 0 \\ 1+\beta & 1 & \beta \\ \hline & \frac{1}{2} + \beta & \frac{1}{2} - \beta \end{array}. \quad (7.87)$$

因此  $A = \begin{pmatrix} \beta & 0 \\ 1 & \beta \end{pmatrix}$ ,  $\mathbf{c} = \begin{pmatrix} \beta \\ 1+\beta \end{pmatrix}$ ,  $\mathbf{b} = \begin{pmatrix} \frac{1}{2} + \beta \\ \frac{1}{2} - \beta \end{pmatrix}$ 。

首先， $\mathbf{b}^\top \mathbf{1} = (\frac{1}{2} + \beta) + (\frac{1}{2} - \beta) = 1$ 。其次，

$$\begin{aligned} \mathbf{b}^\top \mathbf{c} &= \left( \frac{1}{2} + \beta \right) \beta + \left( \frac{1}{2} - \beta \right) (1 + \beta) \\ &= \frac{1}{2}. \end{aligned} \quad (7.88)$$

所以该方法至少为二阶。

下面计算三阶主误差。在某个精确状态  $\mathbf{y}$  处记  $\mathbf{F} = \mathbf{f}(\mathbf{y})$ ,  $\mathbf{J} = \mathbf{f}'(\mathbf{y})$ ,  $\mathbf{H} = \mathbf{f}''(\mathbf{y})$ 。精确解展开为

$$\mathbf{y}(t+h) = \mathbf{y} + h\mathbf{F} + \frac{h^2}{2}\mathbf{JF} + \frac{h^3}{6} [H[\mathbf{F}, \mathbf{F}] + \mathbf{J}^2\mathbf{F}] + O(h^4). \quad (7.89)$$

一般 RK 方法三阶项中， $H[\mathbf{F}, \mathbf{F}]$  的系数为  $\frac{1}{2}\mathbf{b}^\top \mathbf{c}^{\circ 2}$ ，而  $\mathbf{J}^2\mathbf{F}$  的系数为  $\mathbf{b}^\top \mathbf{Ac}$ 。直接计算：

$$\begin{aligned} \mathbf{b}^\top \mathbf{c}^{\circ 2} &= \left( \frac{1}{2} + \beta \right) \beta^2 + \left( \frac{1}{2} - \beta \right) (1 + \beta)^2 \\ &= \frac{1}{2} - \beta^2, \end{aligned} \quad (7.90)$$

$$\mathbf{b}^\top \mathbf{Ac} = \beta(1 - \beta). \quad (7.91)$$

因此数值一步展开为

$$\begin{aligned} \mathcal{M}_h(\mathbf{y}) &= \mathbf{y} + h\mathbf{F} + \frac{h^2}{2}\mathbf{JF} \\ &\quad + h^3 \left[ \left( \frac{1}{4} - \frac{\beta^2}{2} \right) H[\mathbf{F}, \mathbf{F}] + \beta(1 - \beta)\mathbf{J}^2\mathbf{F} \right] + O(h^4). \end{aligned} \quad (7.92)$$



若局部缺陷定义为  $\mathbf{d}_{n+1} = \mathbf{y}(t_{n+1}) - \mathcal{M}_h(\mathbf{y}(t_n))$ , 则其主部为

$$\mathbf{d}_{n+1} = h^3 \left[ \frac{6\beta^2 - 1}{12} H[\mathbf{F}, \mathbf{F}] + \left( \beta^2 - \beta + \frac{1}{6} \right) J^2 \mathbf{F} \right] + O(h^4). \quad (7.93)$$

相应归一化局部截断误差为  $\tau_{n+1} = \frac{\mathbf{d}_{n+1}}{h} = O(h^2)$ 。

若方法达到三阶, 则必须同时有  $6\beta^2 - 1 = 0$ ,  $\beta^2 - \beta + \frac{1}{6} = 0$ 。第一式给出  $\beta^2 = \frac{1}{6}$ 。代入第二式得到  $\frac{1}{3} - \beta = 0$ ,  $\beta = \frac{1}{3}$ , 但此时  $\beta^2 = \frac{1}{9} \neq \frac{1}{6}$ , 矛盾。因此不存在使一般非线性问题达到三阶的  $\beta$ 。

故该方法的经典阶为

$$p = 2. \quad (7.94)$$

□

第 (b) 问: 负实轴稳定性. 对测试方程  $y' = \lambda y$ ,  $z = h\lambda$ , 第一阶段满足  $k_1 = \lambda(y_n + \beta h k_1)$ , 故

$$k_1 = \frac{\lambda}{1 - \beta z} y_n. \quad (7.95)$$

第二阶段满足  $k_2 = \lambda(y_n + h k_1 + \beta h k_2)$ , 从而

$$\begin{aligned} k_2 &= \frac{\lambda}{1 - \beta z} (y_n + h k_1) \\ &= \lambda \frac{1 + (1 - \beta)z}{(1 - \beta z)^2} y_n. \end{aligned} \quad (7.96)$$

代入更新式得到稳定函数

$$R(z) = \frac{1 + (1 - 2\beta)z + \left(\beta^2 - 2\beta + \frac{1}{2}\right)z^2}{(1 - \beta z)^2}. \quad (7.97)$$

令  $z = -x$ ,  $x \geq 0$ 。由于  $\beta > \frac{1}{2}$ , 分母  $(1 + \beta x)^2 > 0$ 。直接计算:

$$1 - R(-x) = \frac{x[2 + (4\beta - 1)x]}{2(1 + \beta x)^2} \geq 0, \quad (7.98)$$

$$1 + R(-x) = \frac{(2\beta - 1)^2 x^2 + 2(4\beta - 1)x + 4}{2(1 + \beta x)^2} > 0. \quad (7.99)$$

因此  $-1 < R(-x) \leq 1$ ,  $x \geq 0$ 。所以  $|R(-x)| \leq 1 \quad \forall x \geq 0$ 。即整个负实轴均属于绝对稳定域。 □

## 7.6 补充训练题: 丘赛 2022 Problem 4——最优二阶段二阶 SSP 方法

完整题目叙述

考虑自治初值问题

$$\frac{d\mathbf{u}}{dt} = \mathbf{f}(\mathbf{u}), \quad \mathbf{u}(0) = \mathbf{u}_0. \quad (7.100)$$

假设前向 Euler 方法

$$\mathbf{U}^{n+1} = \mathbf{U}^n + k\mathbf{f}(\mathbf{U}^n) \quad (7.101)$$

对某个范数  $\|\cdot\|$  满足

$$\|\mathbf{U}^{n+1}\| \leq \|\mathbf{U}^n\| \quad (7.102)$$

并且该性质对所有  $0 < k \leq k_{\text{FE}}$  成立。

现考虑二阶段 Runge-Kutta 方法

$$\mathbf{U}^{(1)} = \mathbf{U}^n + k\beta_{10}\mathbf{f}(\mathbf{U}^n), \quad (7.103)$$

$$\begin{aligned} \mathbf{U}^{n+1} = & \{\alpha_{20}\mathbf{U}^n + k\beta_{20}\mathbf{f}(\mathbf{U}^n)\} \\ & + \{\alpha_{21}\mathbf{U}^{(1)} + k\beta_{21}\mathbf{f}(\mathbf{U}^{(1)})\}, \end{aligned} \quad (7.104)$$

其中  $\beta_{10}, \beta_{20}, \beta_{21} \geq 0, \alpha_{20}, \alpha_{21} \geq 0, \alpha_{20} + \alpha_{21} = 1$ 。

(a) 证明该二阶段方法在适当步长限制  $0 \leq k \leq k^*$  下也满足  $\|\mathbf{U}^{n+1}\| \leq \|\mathbf{U}^n\|$ ，并用  $k_{\text{FE}}$  显式表示  $k^*$ 。

(b) 显式确定  $\beta_{10}, \beta_{20}, \beta_{21}, \alpha_{20}, \alpha_{21}$ ，使该方法：

- (i) 具有二阶精度；
- (ii) 允许的最大步长  $k^*$  尽可能大。

第 (a) 问：凸组合表示与 SSP 步长. 定义

$$r(\alpha, \beta) = \begin{cases} \frac{\alpha}{\beta}, & \beta > 0, \\ +\infty, & \beta = 0. \end{cases} \quad (7.105)$$

当  $\alpha = 0, \beta > 0$  时，上式自然给出  $r = 0$ 。

第一阶段就是步长为  $k\beta_{10}$  的前向 Euler 步。故若

$$k\beta_{10} \leq k_{\text{FE}}, \quad (7.106)$$

则  $\|\mathbf{U}^{(1)}\| \leq \|\mathbf{U}^n\|$ 。

当  $\alpha_{20} > 0$  和  $\alpha_{21} > 0$  时，将第二阶段改写为

$$\begin{aligned} \mathbf{U}^{n+1} = & \alpha_{20} \left[ \mathbf{U}^n + k \frac{\beta_{20}}{\alpha_{20}} \mathbf{f}(\mathbf{U}^n) \right] \\ & + \alpha_{21} \left[ \mathbf{U}^{(1)} + k \frac{\beta_{21}}{\alpha_{21}} \mathbf{f}(\mathbf{U}^{(1)}) \right]. \end{aligned} \quad (7.107)$$

因为  $\alpha_{20}, \alpha_{21} \geq 0, \alpha_{20} + \alpha_{21} = 1$ ，这是两个前向 Euler 步的凸组合。


若同时满足

$$k \frac{\beta_{20}}{\alpha_{20}} \leq k_{\text{FE}}, \quad (7.108)$$

$$k \frac{\beta_{21}}{\alpha_{21}} \leq k_{\text{FE}}, \quad (7.109)$$

则由范数凸性，

$$\begin{aligned} \|\mathbf{U}^{n+1}\| & \leq \alpha_{20} \left\| \mathbf{U}^n + k \frac{\beta_{20}}{\alpha_{20}} \mathbf{f}(\mathbf{U}^n) \right\| \\ & \quad + \alpha_{21} \left\| \mathbf{U}^{(1)} + k \frac{\beta_{21}}{\alpha_{21}} \mathbf{f}(\mathbf{U}^{(1)}) \right\| \\ & \leq \alpha_{20} \|\mathbf{U}^n\| + \alpha_{21} \|\mathbf{U}^{(1)}\| \\ & \leq \|\mathbf{U}^n\|. \end{aligned} \quad (7.110)$$



系数为零时, 按式 (7.105) 删除相应空项即可。

因此定义 SSP 系数

$$C = \min \left\{ \frac{1}{\beta_{10}}, \frac{\alpha_{20}}{\beta_{20}}, \frac{\alpha_{21}}{\beta_{21}} \right\}, \quad (7.111)$$

采用式 (7.105) 中的约定, 则可取

$$k^* = Ck_{\text{FE}}. \quad (7.112)$$

□

第 (b) 问: 二阶条件与最优系数. 由  $\alpha_{20} + \alpha_{21} = 1$ , 将格式展开为标准二阶段显式 RK 形式:

$$\begin{aligned} \mathbf{U}^{n+1} &= \mathbf{U}^n + k[\beta_{20} + \alpha_{21}\beta_{10}] \mathbf{f}(\mathbf{U}^n) \\ &\quad + k\beta_{21} \mathbf{f}(\mathbf{U}^n + k\beta_{10} \mathbf{f}(\mathbf{U}^n)). \end{aligned} \quad (7.113)$$

所以标准 RK 系数为  $a_{21} = \beta_{10}$ ,  $b_1 = \beta_{20} + \alpha_{21}\beta_{10}$ ,  $b_2 = \beta_{21}$ 。二阶条件为

$$\beta_{20} + \alpha_{21}\beta_{10} + \beta_{21} = 1, \quad (7.114)$$

$$\beta_{10}\beta_{21} = \frac{1}{2}. \quad (7.115)$$

下面证明  $C \leq 1$ 。反设  $C > 1$ 。由  $\frac{1}{\beta_{10}} > 1$  得  $\beta_{10} < 1$ 。由  $\frac{\alpha_{21}}{\beta_{21}} > 1$  得  $\alpha_{21} > \beta_{21}$ 。而由二阶条件  $\beta_{10}\beta_{21} = \frac{1}{2}$  及  $\beta_{10} < 1$ , 有  $\beta_{21} > \frac{1}{2}$ 。于是

$$\begin{aligned} \alpha_{21}\beta_{10} + \beta_{21} &> \beta_{21}\beta_{10} + \beta_{21} \\ &= \frac{1}{2} + \beta_{21} > 1. \end{aligned} \quad (7.116)$$

但式 (7.114) 和  $\beta_{20} \geq 0$  要求  $\alpha_{21}\beta_{10} + \beta_{21} \leq 1$ , 矛盾。故  $C \leq 1$ 。

要达到  $C = 1$ , 由  $\beta_{10} \leq 1$ ,  $\beta_{21} \leq \alpha_{21}$  及  $\beta_{10}\beta_{21} = \frac{1}{2}$  可得  $\beta_{21} \geq \frac{1}{2}$ 。另一方面,

$$1 = \beta_{20} + \alpha_{21}\beta_{10} + \beta_{21} \geq \beta_{21}\beta_{10} + \beta_{21} = \frac{1}{2} + \beta_{21} \geq 1.$$

所有不等式必须同时取等号。因此

$$\begin{aligned} \beta_{10} &= 1, \\ \beta_{20} &= 0, \\ \beta_{21} &= \frac{1}{2}, \\ \alpha_{20} &= \frac{1}{2}, \\ \alpha_{21} &= \frac{1}{2}. \end{aligned} \quad (7.117)$$

最优 SSP 系数为  $C_{\max} = 1$ , 因而

$$k^* = k_{\text{FE}}. \quad (7.118)$$

相应方法为

$$\mathbf{U}^{(1)} = \mathbf{U}^n + k\mathbf{f}(\mathbf{U}^n), \quad (7.119)$$


$$\mathbf{U}^{n+1} = \frac{1}{2}\mathbf{U}^n + \frac{1}{2}[\mathbf{U}^{(1)} + k\mathbf{f}(\mathbf{U}^{(1)})]. \quad (7.120)$$

展开后即

$$\mathbf{U}^{n+1} = \mathbf{U}^n + \frac{k}{2}[\mathbf{f}(\mathbf{U}^n) + \mathbf{f}(\mathbf{U}^n + k\mathbf{f}(\mathbf{U}^n))], \quad (7.121)$$

也就是二阶显式梯形法或 SSPRK(2, 2)。

□





注 7.8. 这道题的 (b) 问非常有代表性，不是直接算出来，而是通过不等式取等条件的方法得到参数的值，非常值得学习（这也是我当年唯一没做出来的题目）。

## 7.7 补充训练题：丘赛 2023 Problem 4——三参数二阶段单步法

完整题目叙述

考虑初值问题

$$\begin{cases} y' = f(t, y), & 0 < t \leq T, \\ y(0) = y_0, \end{cases} \quad (7.122)$$

其中  $f$  连续，并在  $[0, T] \times \mathbb{R}$  上关于  $y$  满足 Lipschitz 条件。令  $y_n \approx y(t_n)$ ,  $t_n = nh$ ,  $h = \frac{T}{N}$ 。考虑单步方法

$$y_{n+1} = y_n + \alpha h f(t_n, y_n) + \beta h f(t_n + \gamma h, y_n + \gamma h f(t_n, y_n)), \quad (7.123)$$

其中  $\alpha, \beta, \gamma \in \mathbb{R}$ 。

(a) 证明该方法一致当且仅当  $\alpha + \beta = 1$ ，并证明该方法的阶不可能超过 2。

(b) 假设取到二阶方法，并将其应用于  $f(t, y) = -\lambda y$ ,  $\lambda > 0$ ,  $y_0 = 1$ 。证明数列  $\{y_n\}$  有界当且仅当  $h \leq \frac{2}{\lambda}$ 。进一步证明，在该步长条件下，

$$|y(t_n) - y_n| \leq \frac{1}{6} \lambda^3 h^2 t_n, \quad n \geq 0. \quad (7.124)$$

第 (a) 问：一致性与最高阶。该方法是二阶段显式 RK 方法，其 Butcher 表为

$$\begin{array}{c|cc} 0 & 0 & 0 \\ \gamma & \gamma & 0 \\ \hline & \alpha & \beta \end{array}. \quad (7.125)$$

从精确值  $(t, y)$  出发，

$$\begin{aligned} f(t + \gamma h, y + \gamma h f(t, y)) &= f(t, y) \\ &+ \gamma h [f_t(t, y) + f_y(t, y) f(t, y)] + O(h^2). \end{aligned} \quad (7.126)$$

因此数值一步为

$$\mathcal{M}_h(y) = y + h(\alpha + \beta)f + \beta\gamma h^2(f_t + f_y f) + O(h^3). \quad (7.127)$$

而精确解满足


$$y(t + h) = y + hf + \frac{h^2}{2}(f_t + f_y f) + O(h^3). \quad (7.128)$$

所以一致性即一阶条件为

$$\boxed{\alpha + \beta = 1}. \quad (7.129)$$

达到二阶还需

$$\boxed{\beta\gamma = \frac{1}{2}}. \quad (7.130)$$



若要达到三阶, RK 阶条件还要求  $\mathbf{b}^T \mathbf{A} \mathbf{c} = \frac{1}{6}$ . 但本方法  $\mathbf{A} = \begin{pmatrix} 0 & 0 \\ \gamma & 0 \end{pmatrix}$ ,  $\mathbf{c} = \begin{pmatrix} 0 \\ \gamma \end{pmatrix}$ , 所以  $\mathbf{A} \mathbf{c} = \mathbf{0}$ ,  $\mathbf{b}^T \mathbf{A} \mathbf{c} = 0$ . 这不可能等于  $1/6$ . 因此该方法的最高经典阶为 2.  $\square$

第 (b) 问: 有界性及整体误差显式估计. 对二阶方法,  $\alpha + \beta = 1$ ,  $\beta\gamma = \frac{1}{2}$ . 应用于  $y' = -\lambda y$ , 令  $a = \lambda h \geq 0$ . 第一阶段预测值为  $y_n - \gamma a y_n$ . 代入格式:

$$\begin{aligned} y_{n+1} &= y_n - \alpha a y_n - \beta a(1 - \gamma a) y_n \\ &= [1 - (\alpha + \beta)a + \beta\gamma a^2] y_n \\ &= \left(1 - a + \frac{a^2}{2}\right) y_n. \end{aligned} \quad (7.131)$$

记

$$q(a) = 1 - a + \frac{a^2}{2} = \frac{1}{2} [(a-1)^2 + 1]. \quad (7.132)$$

故  $q(a) \geq \frac{1}{2} > 0$ . 又  $y_n = q(a)^n$ . 数列有界当且仅当  $q(a) \leq 1$ . 而

$$\begin{aligned} q(a) \leq 1 &\iff -a + \frac{a^2}{2} \leq 0 \\ &\iff a(a-2) \leq 0 \\ &\iff 0 \leq a \leq 2. \end{aligned} \quad (7.133)$$

由于  $a = \lambda h$ , 故

$$\boxed{\{y_n\} \text{有界} \iff h \leq \frac{2}{\lambda}}. \quad (7.134)$$

下面证明误差界. 精确解为  $y(t_n) = e^{-\lambda t_n} = e^{-an}$ . 当  $0 \leq a \leq 2$  时,  $0 < e^{-a} \leq 1$ ,  $0 < q(a) \leq 1$ . 由带余项的 Taylor 公式, 存在  $\xi \in (0, a)$  使

$$e^{-a} = 1 - a + \frac{a^2}{2} - \frac{a^3}{6} e^{-\xi}. \quad (7.135)$$

所以

$$0 \leq q(a) - e^{-a} = \frac{a^3}{6} e^{-\xi} \leq \frac{a^3}{6}. \quad (7.136)$$

利用幂差公式,

$$\begin{aligned} |q(a)^n - e^{-an}| &= |q(a) - e^{-a}| \left| \sum_{j=0}^{n-1} q(a)^{n-1-j} e^{-aj} \right| \\ &\leq n |q(a) - e^{-a}| \\ &\leq \frac{n}{6} a^3. \end{aligned} \quad (7.137)$$

又因  $a = \lambda h$ ,  $t_n = nh$ , 有  $na^3 = n\lambda^3 h^3 = \lambda^3 h^2 t_n$ . 故

$$\boxed{|y(t_n) - y_n| \leq \frac{1}{6} \lambda^3 h^2 t_n}. \quad (7.138)$$

$\square$

## 7.8 正式真题 [23F-Q4]——显式梯形 Runge-Kutta 方法



完整题目叙述: [23F-Q4]

考虑常微分方程

$$y' = f(t, y), \quad (7.139)$$

其中  $f$  关于  $y$  满足 Lipschitz 条件, 并且该条件关于  $t$  一致。考虑具有如下 Butcher 表的 Runge-Kutta 方法:

$$\begin{array}{c|cc} 0 & 0 & 0 \\ 1 & 1 & 0 \\ \hline & \frac{1}{2} & \frac{1}{2} \end{array} \quad (7.140)$$

(1) 将该格式改写成  $u_{n+1} = u_n + hF(t_n, u_n, h; f)$  的形式。

(2) 假设  $f$  足够光滑, 证明该方法收敛并确定其收敛阶。

(3) 求该方法的绝对稳定域, 并尽可能显式地描述该区域。

第 (1) 问: 写成单步增量形式. 由 Butcher 表,

$$K_1 = f(t_n, u_n), \quad (7.141)$$

$$K_2 = f(t_n + h, u_n + hK_1), \quad (7.142)$$

$$u_{n+1} = u_n + \frac{h}{2}(K_1 + K_2). \quad (7.143)$$

因此

$$F(t, u, h; f) = \frac{1}{2} [f(t, u) + f(t + h, u + hf(t, u))]. \quad (7.144)$$

该方法就是显式梯形法、Heun 法或 SSPRK(2, 2).  $\square$

第 (2) 问: 局部二阶精度和整体二阶收敛. 在精确状态  $(t, y)$  处记  $f = f(t, y)$ . 对第二阶段作二元 Taylor 展开:

$$\begin{aligned} f(t + h, y + hf) &= f(t, y) + hf_t(t, y) + hf_y(t, y)f(t, y) + O(h^2) \\ &= f + h(f_t + f_y f) + O(h^2). \end{aligned} \quad (7.145)$$

故从精确值出发的一步数值结果为


$$\begin{aligned} y + hF(t, y, h; f) &= y + \frac{h}{2} [f + f + h(f_t + f_y f) + O(h^2)] \\ &= y + hf + \frac{h^2}{2}(f_t + f_y f) + O(h^3). \end{aligned} \quad (7.146)$$

另一方面, 由  $y'' = f_t + f_y f$ , 精确解满足

$$y(t + h) = y + hf + \frac{h^2}{2}(f_t + f_y f) + O(h^3). \quad (7.147)$$

所以局部缺陷满足

$$|d_{n+1}| \leq C_d h^3. \quad (7.148)$$



下面证明误差传播稳定。设  $f$  关于  $y$  的 Lipschitz 常数为  $L$ 。对任意  $u, v$ ,

$$\begin{aligned}
 & |F(t, u, h; f) - F(t, v, h; f)| \\
 & \leq \frac{1}{2} |f(t, u) - f(t, v)| \\
 & \quad + \frac{1}{2} |f(t+h, u+hf(t, u)) - f(t+h, v+hf(t, v))| \\
 & \leq \frac{L}{2} |u - v| + \frac{L}{2} [|u - v| + h|f(t, u) - f(t, v)|] \\
 & \leq L \left(1 + \frac{hL}{2}\right) |u - v|.
 \end{aligned} \tag{7.149}$$

对  $0 < h \leq h_0$ , 可取与  $h$  无关的统一常数  $L_F = L(1 + \frac{h_0 L}{2})$ 。

令  $e_n = y(t_n) - u_n$ 。由精确一步和数值一步相减,  $|e_{n+1}| \leq (1 + hL_F)|e_n| + C_d h^3$ 。若初值精确, 即  $e_0 = 0$ , 离散 Gronwall 不等式给出

$$\begin{aligned}
 |e_n| & \leq C_d h^3 \frac{(1 + hL_F)^n - 1}{hL_F} \\
 & \leq \frac{C_d}{L_F} (e^{L_F(t_n - t_0)} - 1) h^2.
 \end{aligned} \tag{7.150}$$

因此

$$\boxed{\max_{0 \leq n \leq N} |y(t_n) - u_n| = O(h^2)}. \tag{7.151}$$

该方法整体二阶收敛。  $\square$

第 (3) 问: 绝对稳定域. 对测试方程  $y' = \lambda y$ ,  $z = h\lambda$ , 有  $K_1 = \lambda u_n$ ,  $K_2 = \lambda(u_n + hK_1) = \lambda(1 + z)u_n$ 。

因此

$$\begin{aligned}
 u_{n+1} & = u_n + \frac{h}{2} [\lambda u_n + \lambda(1 + z)u_n] \\
 & = \left(1 + z + \frac{z^2}{2}\right) u_n.
 \end{aligned} \tag{7.152}$$

稳定函数为

$$\boxed{R(z) = 1 + z + \frac{z^2}{2}}. \tag{7.153}$$

故绝对稳定域为

$$\boxed{\mathcal{S} = \left\{z \in \mathbb{C} : \left|1 + z + \frac{z^2}{2}\right| \leq 1\right\}}. \tag{7.154}$$

注意

$$1 + z + \frac{z^2}{2} = \frac{1 + (z+1)^2}{2}. \tag{7.155}$$

因此也可写为

$$\mathcal{S} = \{z \in \mathbb{C} : |1 + (z+1)^2| \leq 2\}. \tag{7.156}$$


令  $z = x + iy$ 。则

$$\operatorname{Re} R(z) = 1 + x + \frac{x^2 - y^2}{2}, \tag{7.157}$$

$$\operatorname{Im} R(z) = y(1 + x). \tag{7.158}$$

所以稳定域的显式实变量描述为

$$\boxed{\left[1 + x + \frac{x^2 - y^2}{2}\right]^2 + y^2(1 + x)^2 \leq 1}. \tag{7.159}$$



展开即

$$\boxed{x^4 + 4x^3 + 2x^2y^2 + 8x^2 + 4xy^2 + 8x + y^4 \leq 0}. \quad (7.160)$$

在实轴上, 因  $R(x) = \frac{(x+1)^2+1}{2} > 0$ , 故  $|R(x)| \leq 1 \iff (x+1)^2 \leq 1$ . 因此

$$\boxed{\mathcal{S} \cap \mathbb{R} = [-2, 0]}. \quad (7.161)$$

在虚轴上, 令  $z = iy$ , 则

$$\begin{aligned} |R(iy)|^2 &= \left(1 - \frac{y^2}{2}\right)^2 + y^2 \\ &= 1 + \frac{y^4}{4}. \end{aligned} \quad (7.162)$$

所以  $|R(iy)| \leq 1 \iff y = 0$ . 即

$$\boxed{\mathcal{S} \cap i\mathbb{R} = \{0\}}. \quad (7.163)$$

该稳定域有界, 因此该显式二阶方法不是 A 稳定方法。□

## 7.9 舍入误差、计算复杂度与失败诊断

### 7.9.1 知识点十五: 截断误差与舍入误差的平衡

设  $p$  阶稳定单步法的截断误差满足  $E_{\text{trunc}}(h) \lesssim C_t h^p$ . 若每一步产生大小至多  $C_r u$  的确定性舍入扰动, 其中  $u$  为单位舍入误差, 在固定区间上共需  $N \asymp \frac{1}{h}$  步. 最坏情况下, 稳定传播后的舍入误差量级为  $E_{\text{round}}(h) \lesssim \frac{C_r u}{h}$ . 因此总误差模型为

$$E(h) \lesssim C_t h^p + \frac{C_r u}{h}. \quad (7.164)$$

对右端求极小, 得到

$$\boxed{h_{\text{opt}} \asymp \left(\frac{C_r u}{p C_t}\right)^{1/(p+1)}}. \quad (7.165)$$

所以步长并非越小越好。

若舍入误差近似独立随机扰动, 其典型积累可能接近  $O(u\sqrt{N}) = O\left(\frac{u}{\sqrt{h}}\right)$ , 但资格考试中的确定性最坏情况分析通常采用  $O(u/h)$ 。

### 7.9.2 知识点十六: 显式与隐式 RK 的成本

设状态维数为  $d$ , 一次右端项计算成本为  $C_f$ 。

显式  $s$  阶段 RK 每步时间成本 =  $O(sC_f)$ 。若朴素保存全部阶段, 存储成本 =  $O(sd)$ 。许多特殊 RK 格式可通过低存储重排降为  $O(d)$ 。

全隐式  $s$  阶段 RK 需要求解维数为  $sd$  的非线性系统

$$\mathcal{G}(\mathbf{Y}) = \mathbf{0}. \quad (7.166)$$

Newton 线性化的块 Jacobian 具有形式

$$I_{sd} - h [a_{ij} J_f(t_n + c_j h, \mathbf{Y}_j)]_{i,j=1}^s. \quad (7.167)$$



若将其视为一般稠密  $sd \times sd$  矩阵，一次直接分解成本约为  $O((sd)^3)$ ，存储约为  $O(s^2d^2)$ 。实际算法会利用：

- 对角隐式结构；
- 稀疏 Jacobian；
- 简化 Newton；
- Kronecker 结构；
- 预条件 Krylov 方法；
- 跨时间步复用矩阵分解。

### 7.9.3 知识点十七：隐式时间步的 Newton 求解

以后向 Euler 为例，Newton 迭代为

$$[I - hJ_f(t_{n+1}, \mathbf{v}^{(\ell)})] \Delta \mathbf{v}^{(\ell)} = -[\mathbf{v}^{(\ell)} - \mathbf{u}_n - h\mathbf{f}(t_{n+1}, \mathbf{v}^{(\ell)})], \quad (7.168)$$

并更新  $\mathbf{v}^{(\ell+1)} = \mathbf{v}^{(\ell)} + \Delta \mathbf{v}^{(\ell)}$ 。常用初值为

$$\mathbf{v}^{(0)} = \mathbf{u}_n + h\mathbf{f}(t_n, \mathbf{u}_n). \quad (7.169)$$

内层非线性误差不应大于时间离散误差。若  $p$  阶时间方法要求整体误差  $O(h^p)$ ，通常应使每步非线性残差造成的状态误差显著小于  $O(h^{p+1})$ 。若内层求解过粗，则实际方法可能降阶。

#### 【常见失败情形】

- 初值问题的精确解在  $[t_0, T]$  内爆破；
- 右端项不满足局部 Lipschitz 条件，解不唯一；
- 显式方法受绝对稳定域限制而振荡或发散；
- 隐式阶段 Newton 迭代不收敛；
- Jacobian 严重病态或线性求解器失败；
- 时间步跨过不连续点、事件或尖峰；
- 局部误差虽小，但长时间条件放大因子巨大；
- 步长过小后舍入误差主导；
- 仅监视相邻步差而未估计真正局部误差；
- 对刚性问题使用高阶显式方法，精度允许但稳定性不允许。

#### 易错点与反例

误差分析得到  $\|e_n\| \leq Ch^p$  说明方法的渐近收敛阶，但并未自动给出可计算的实时误差估计器。实际误差控制需要：

- 嵌入式 Runge-Kutta 对；
- 步长加倍；



- 外推;
- 缺陷估计;
- 或后验残差估计。

这些自适应步长机制以及刚性检测将在第 09 部分系统处理。



# 第八章 线性多步法、零稳定性、根条件、Dahlquist 等价定理与绝对稳定性

## 8.1 线性多步法的统一形式与基本对象

### 8.1.1 知识点一：一般线性多步格式

【重要性等级】 **S 级**。线性多步法的核心考法不是记忆若干系数，而是：

1. 从统一格式识别  $\alpha_j, \beta_j$ ;
2. 构造第一、第二特征多项式;
3. 用阶条件判断相容性和精度;
4. 用第一特征多项式判断零稳定性;
5. 对测试方程构造  $\rho(\zeta) - z\sigma(\zeta)$ ;
6. 判断全部特征根，而不是只看某一个增长因子。

考虑初值问题

$$\begin{cases} y'(t) = f(t, y(t)), & t_0 \leq t \leq T, \\ y(t_0) = y_0, \end{cases} \quad (8.1)$$

其中  $y(t) \in \mathbb{R}^d$ 。在等距网格  $t_n = t_0 + nh$ ,  $h = \frac{T-t_0}{N}$  上,  $k$  步线性多步法写为

$$\sum_{j=0}^k \alpha_j \mathbf{u}_{n+j} = h \sum_{j=0}^k \beta_j \mathbf{f}(t_{n+j}, \mathbf{u}_{n+j}), \quad n = 0, \dots, N-k. \quad (8.2)$$

通常作归一化

$$\alpha_k = 1. \quad (8.3)$$

定义

$$\mathbf{f}_{n+j} := \mathbf{f}(t_{n+j}, \mathbf{u}_{n+j}), \quad (8.4)$$

则格式可简写为  $\sum_{j=0}^k \alpha_j \mathbf{u}_{n+j} = h \sum_{j=0}^k \beta_j \mathbf{f}_{n+j}$ 。

定义 8.1 (显式与隐式线性多步法)。在归一化  $\alpha_k = 1$  下：

- 若  $\beta_k = 0$ , 则  $\mathbf{u}_{n+k}$  可由已有量直接计算, 称为显式线性多步法;
- 若  $\beta_k \neq 0$ , 则  $\mathbf{u}_{n+k}$  同时出现在  $\mathbf{f}(t_{n+k}, \mathbf{u}_{n+k})$  内, 称为隐式线性多步法。



对非线性  $f$ , 隐式格式每一步需要求解

$$G_n(v) = \alpha_k v - h\beta_k f(t_{n+k}, v) + c_n = 0, \quad (8.5)$$

其中  $c_n$  由历史值决定。Newton 线性化的矩阵为

$$\alpha_k I - h\beta_k J_f(t_{n+k}, v). \quad (8.6)$$

【复杂度】 设状态维数为  $d$ , 方法步数为  $k$ 。

- 显式法每步通常只增加一次新的右端项计算;
- 需要保存  $k$  个历史状态及若干历史右端项, 存储为  $O(kd)$ ;
- 稠密隐式法每次 Newton 迭代需解  $d \times d$  线性系统, 若无结构直接分解, 成本约为  $O(d^3)$ ;
- 稀疏问题的成本取决于非零元数、填充、预条件器及 Krylov 迭代次数;
- 固定步长多步法可重复利用历史数据, 单步函数计算次数通常少于同阶 Runge-Kutta 方法。

### 8.1.2 知识点二: 第一与第二特征多项式

定义 8.2 (第一、第二特征多项式). 对式 (8.2), 定义

$$\rho(\zeta) = \sum_{j=0}^k \alpha_j \zeta^j, \quad (8.7)$$

$$\sigma(\zeta) = \sum_{j=0}^k \beta_j \zeta^j. \quad (8.8)$$

其中:

- $\rho$  称为第一特征多项式;
- $\sigma$  称为第二特征多项式。

本文统一使用  $\rho, \sigma$ 。部分附件把第二特征多项式记为  $\beta(\zeta)$ , 或把第一特征多项式记为  $\alpha(\zeta)$ 。换算关系只是  $\alpha(\zeta) = \rho(\zeta)$ ,  $\beta(\zeta) = \sigma(\zeta)$ , 不得将多项式符号与系数  $\alpha_j, \beta_j$  混淆。

【识别信号】

- 题目要求“根条件”: 只看  $\rho(\zeta)$ ;
- 题目要求“绝对稳定域”: 看  $\rho(\zeta) - z\sigma(\zeta)$ ;
- 题目要求“相容性”: 检查  $\rho(1) = 0$ ,  $\rho'(1) = \sigma(1)$ ;
- 题目要求“方法阶数”: 展开  $\rho(e^w) - w\sigma(e^w)$  或逐项计算阶条件。

#### 易错点与反例

第一特征多项式  $\rho$  的根决定零稳定性; 测试方程特征多项式  $\rho(\zeta) - z\sigma(\zeta)$  的根决定绝对稳定性。二者不是同一个多项式, 也不是同一个稳定性概念。



## 8.2 局部截断误差、相容性与阶条件

### 8.2.1 知识点三：未归一化局部缺陷与归一化截断误差

设  $\mathbf{y}(t)$  为精确解。把精确网格值代入多步格式，定义未归一化局部缺陷

$$\mathbf{d}_{n+k} = \sum_{j=0}^k \alpha_j \mathbf{y}(t_{n+j}) - h \sum_{j=0}^k \beta_j \mathbf{y}'(t_{n+j}). \quad (8.9)$$

相应归一化局部截断误差定义为

$$\tau_{n+k} = \frac{\mathbf{d}_{n+k}}{h}. \quad (8.10)$$

因此：

$$\mathbf{d}_{n+k} = O(h^{p+1}) \iff \tau_{n+k} = O(h^p). \quad (8.11)$$

#### 易错点与反例

不同教材对“局部截断误差”的归一化约定不同：

- 有的把  $\mathbf{d}_{n+k}$  称为局部截断误差；
- 有的把  $\tau_{n+k} = \mathbf{d}_{n+k}/h$  称为局部截断误差。

所以“ $p$  阶方法的局部误差是  $O(h^{p+1})$  还是  $O(h^p)$ ”必须先说明采用哪一种定义。本文默认：

未归一化局部缺陷  $= O(h^{p+1})$ ，归一化局部截断误差  $= O(h^p)$ 。

定义连续残差算子

$$(\mathcal{R}\mathbf{v})(t) = \mathbf{v}'(t) - \mathbf{f}(t, \mathbf{v}(t)), \quad (8.12)$$

以及离散残差算子

$$(\mathcal{R}_h \mathbf{v})_n = \frac{1}{h} \sum_{j=0}^k \alpha_j \mathbf{v}_{n+j} - \sum_{j=0}^k \beta_j \mathbf{f}(t_{n+j}, \mathbf{v}_{n+j}). \quad (8.13)$$

则精确解的截断误差就是

$$\tau_{n+k} = (\mathcal{R}_h \mathbf{y})_n. \quad (8.14)$$

### 8.2.2 知识点四：线性多步法的阶条件

在  $t_n$  处作 Taylor 展开：

$$\mathbf{y}(t_n + jh) = \sum_{q=0}^{\infty} \frac{(jh)^q}{q!} \mathbf{y}^{(q)}(t_n), \quad (8.15)$$

以及

$$\mathbf{y}'(t_n + jh) = \sum_{q=0}^{\infty} \frac{(jh)^q}{q!} \mathbf{y}^{(q+1)}(t_n). \quad (8.16)$$

代入式 (8.9)，得到

$$\mathbf{d}_{n+k} = \sum_{q=0}^{\infty} C_q h^q \mathbf{y}^{(q)}(t_n), \quad (8.17)$$



其中

$$C_0 = \sum_{j=0}^k \alpha_j, \quad (8.18)$$

$$C_q = \frac{1}{q!} \sum_{j=0}^k j^q \alpha_j - \frac{1}{(q-1)!} \sum_{j=0}^k j^{q-1} \beta_j, \quad q \geq 1. \quad (8.19)$$

定理 8.3 (线性多步法的阶条件). 线性多步法式 (8.2) 具有精确阶  $p$ , 当且仅当

$$C_0 = C_1 = \cdots = C_p = 0, \quad C_{p+1} \neq 0. \quad (8.20)$$

此时, 在精确解具有  $p+1$  阶连续导数的条件下,

$$\mathbf{d}_{n+k} = C_{p+1} h^{p+1} \mathbf{y}^{(p+1)}(t_n) + O(h^{p+2}). \quad (8.21)$$

证明. 由式 (8.17), 若  $C_0 = \cdots = C_p = 0$ , 则前  $p+1$  个低阶项消失, 从而  $\mathbf{d}_{n+k} = O(h^{p+1})$ . 若  $C_{p+1} \neq 0$ , 则对一般具有非零  $\mathbf{y}^{(p+1)}$  的解,  $h^{p+1}$  项不会消失, 故方法不能达到  $p+1$  阶.  $\square$

前几个条件写为

$$\sum_{j=0}^k \alpha_j = 0, \quad (8.22)$$

$$\sum_{j=0}^k j \alpha_j = \sum_{j=0}^k \beta_j, \quad (8.23)$$

$$\frac{1}{2} \sum_{j=0}^k j^2 \alpha_j = \sum_{j=0}^k j \beta_j, \quad (8.24)$$

$$\frac{1}{6} \sum_{j=0}^k j^3 \alpha_j = \frac{1}{2} \sum_{j=0}^k j^2 \beta_j. \quad (8.25)$$

推论 8.4 (相容性的代数判据). 线性多步法相容, 当且仅当

$$C_0 = C_1 = 0. \quad (8.26)$$

等价地,

$$\boxed{\rho(1) = 0, \quad \rho'(1) = \sigma(1)}. \quad (8.27)$$

证明. 显然  $\rho(1) = \sum_{j=0}^k \alpha_j = C_0$ . 又  $\rho'(1) = \sum_{j=0}^k j \alpha_j$ ,  $\sigma(1) = \sum_{j=0}^k \beta_j$ , 所以  $C_1 = \rho'(1) - \sigma(1)$ .  $\square$

还可使用指数生成函数判阶:

$$\boxed{\rho(e^w) - w\sigma(e^w) = O(w^{p+1}), \quad w \rightarrow 0}. \quad (8.28)$$

若恰有  $\rho(e^w) - w\sigma(e^w) = c_{p+1}w^{p+1} + O(w^{p+2})$ ,  $c_{p+1} \neq 0$ , 则方法精确阶为  $p$ .

基础例题: 用阶条件判断 BDF2 的阶

考虑

$$\frac{3}{2} \mathbf{u}_{n+2} - 2\mathbf{u}_{n+1} + \frac{1}{2} \mathbf{u}_n = h \mathbf{f}_{n+2}. \quad (8.29)$$

系数为  $\alpha_0 = \frac{1}{2}$ ,  $\alpha_1 = -2$ ,  $\alpha_2 = \frac{3}{2}$ ,  $\beta_0 = \beta_1 = 0$ ,  $\beta_2 = 1$ 。计算:

$$\begin{aligned} C_0 &= \frac{1}{2} - 2 + \frac{3}{2} = 0, \\ C_1 &= (-2 + 3) - 1 = 0, \\ C_2 &= \frac{1}{2} \left[ -2 + 4 \cdot \frac{3}{2} \right] - 2 = 0, \\ C_3 &= \frac{1}{6} \left[ -2 + 8 \cdot \frac{3}{2} \right] - \frac{1}{2} \cdot 4 \\ &= \frac{10}{6} - 2 = -\frac{1}{3} \neq 0. \end{aligned}$$

因此 BDF2 为二阶方法, 且主局部缺陷为

$$d_{n+2} = -\frac{1}{3}h^3 y^{(3)}(t_n) + O(h^4). \quad (8.30)$$

若改为在  $t_{n+2}$  处展开, 主项系数仍为  $-1/3$ , 高阶余项的表示形式相应改变。

## 8.3 Adams 方法、BDF 方法与预测-校正

### 8.3.1 知识点五: Adams-Bashforth 方法

由积分形式

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y(t)) dt \quad (8.31)$$

出发, 令  $t = t_n + \theta h$ ,  $0 \leq \theta \leq 1$ 。使用历史节点  $\theta = 0, -1, \dots, -(q-1)$  上的  $f_n, f_{n-1}, \dots, f_{n-q+1}$  构造  $q-1$  次 Lagrange 插值多项式

$$P_{q-1}(\theta) = \sum_{j=0}^{q-1} \ell_j(\theta) f_{n-j}, \quad (8.32)$$

其中

$$\ell_j(\theta) = \prod_{\substack{0 \leq m \leq q-1 \\ m \neq j}} \frac{\theta + m}{m - j}. \quad (8.33)$$

将  $P_{q-1}$  积分, 得到  $q$  步 Adams-Bashforth 公式

$$\boxed{u_{n+1} = u_n + h \sum_{j=0}^{q-1} b_j^{\text{AB}} f_{n-j}}, \quad (8.34)$$

其中

$$b_j^{\text{AB}} = \int_0^1 \ell_j(\theta) d\theta. \quad (8.35)$$


前四个公式为

$$\text{AB1: } u_{n+1} = u_n + h f_n, \quad (8.36)$$

$$\text{AB2: } u_{n+1} = u_n + \frac{h}{2} (3f_n - f_{n-1}), \quad (8.37)$$

$$\text{AB3: } u_{n+1} = u_n + \frac{h}{12} (23f_n - 16f_{n-1} + 5f_{n-2}), \quad (8.38)$$

$$\text{AB4: } u_{n+1} = u_n + \frac{h}{24} (55f_n - 59f_{n-1} + 37f_{n-2} - 9f_{n-3}). \quad (8.39)$$





若  $g(t) = f(t, \mathbf{y}(t))$  具有  $q$  阶连续导数, 则插值余项积分给出  $d_{n+1}^{\text{AB}q} = O(h^{q+1})$ 。所以 AB $q$  的整体阶为  $q$ , 前提是方法零稳定且起步值具有相同精度。

所有  $q$  步 Adams–Bashforth 方法的第一特征多项式均为

$$\rho(\zeta) = \zeta^q - \zeta^{q-1} = \zeta^{q-1}(\zeta - 1). \quad (8.40)$$

其根为:

- $\zeta = 1$ , 单根;
- $\zeta = 0$ , 重数  $q - 1$ , 严格位于单位圆内。

故所有固定阶 Adams–Bashforth 方法均零稳定。

### 8.3.2 知识点六: Adams–Moulton 方法

若插值节点包含未来节点  $t_{n+1}$ , 即使用  $\theta = 1, 0, -1, \dots$ , 则得到隐式 Adams–Moulton 方法。

常用公式为

$$\text{AM0/BE: } \mathbf{u}_{n+1} = \mathbf{u}_n + h\mathbf{f}_{n+1}, \quad (8.41)$$

$$\text{AM1/TR: } \mathbf{u}_{n+1} = \mathbf{u}_n + \frac{h}{2}(\mathbf{f}_{n+1} + \mathbf{f}_n), \quad (8.42)$$

$$\text{AM2: } \mathbf{u}_{n+1} = \mathbf{u}_n + \frac{h}{12}(5\mathbf{f}_{n+1} + 8\mathbf{f}_n - \mathbf{f}_{n-1}), \quad (8.43)$$

$$\text{AM3: } \mathbf{u}_{n+1} = \mathbf{u}_n + \frac{h}{24}(9\mathbf{f}_{n+1} + 19\mathbf{f}_n - 5\mathbf{f}_{n-1} + \mathbf{f}_{n-2}). \quad (8.44)$$

本文采用如下命名约定:

- 后向 Euler 视为退化的 AM0, 阶为 1;
- 梯形法视为一步 AM1, 阶为 2;
- AM2 为二步法, 阶为 3;
- AM3 为三步法, 阶为 4。

不同资料可能按“所用函数值个数”或“历史滞后阶数”编号, 所以必须以具体公式确认, 不得只凭“AM2”字样判断阶数。

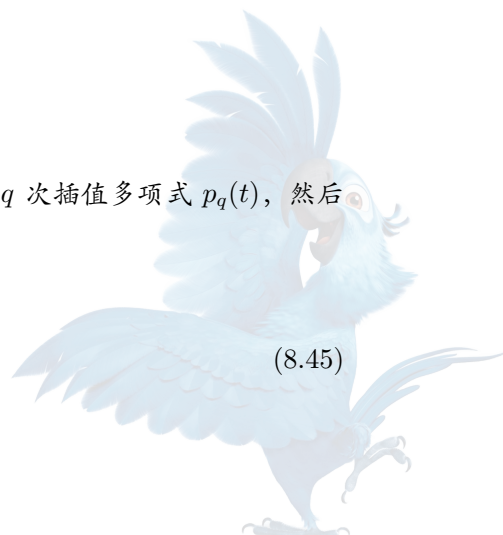
Adams–Moulton 方法的左端仍为  $\mathbf{u}_{n+1} - \mathbf{u}_n$ , 故第一特征多项式仍为  $\zeta^{q-1}(\zeta - 1)$ , 所以所有固定阶 Adams–Moulton 方法均零稳定。

### 8.3.3 知识点七: 后向差分公式 BDF

BDF 方法从数值微分出发。用  $t_{n+1}, t_n, \dots, t_{n+1-q}$  处的状态值构造  $q$  次插值多项式  $p_q(t)$ , 然后以  $p'_q(t_{n+1}) \approx \mathbf{y}'(t_{n+1}) = \mathbf{f}(t_{n+1}, \mathbf{y}(t_{n+1}))$  代替导数。

标准 BDF $q$  写为

$$\sum_{j=0}^q a_j^{(q)} \mathbf{u}_{n+1-j} = h\mathbf{f}_{n+1}. \quad (8.45)$$



前六个 BDF 公式为

$$\text{BDF1: } \mathbf{u}_{n+1} - \mathbf{u}_n = h\mathbf{f}_{n+1}, \quad (8.46)$$

$$\text{BDF2: } \frac{3}{2}\mathbf{u}_{n+1} - 2\mathbf{u}_n + \frac{1}{2}\mathbf{u}_{n-1} = h\mathbf{f}_{n+1}, \quad (8.47)$$

$$\text{BDF3: } \frac{11}{6}\mathbf{u}_{n+1} - 3\mathbf{u}_n + \frac{3}{2}\mathbf{u}_{n-1} - \frac{1}{3}\mathbf{u}_{n-2} = h\mathbf{f}_{n+1}, \quad (8.48)$$

$$\text{BDF4: } \frac{25}{12}\mathbf{u}_{n+1} - 4\mathbf{u}_n + 3\mathbf{u}_{n-1} - \frac{4}{3}\mathbf{u}_{n-2} + \frac{1}{4}\mathbf{u}_{n-3} = h\mathbf{f}_{n+1}, \quad (8.49)$$

$$\text{BDF5: } \frac{137}{60}\mathbf{u}_{n+1} - 5\mathbf{u}_n + 5\mathbf{u}_{n-1} - \frac{10}{3}\mathbf{u}_{n-2} + \frac{5}{4}\mathbf{u}_{n-3} - \frac{1}{5}\mathbf{u}_{n-4} = h\mathbf{f}_{n+1}, \quad (8.50)$$

$$\text{BDF6: } \frac{49}{20}\mathbf{u}_{n+1} - 6\mathbf{u}_n + \frac{15}{2}\mathbf{u}_{n-1} - \frac{20}{3}\mathbf{u}_{n-2} + \frac{15}{4}\mathbf{u}_{n-3} - \frac{6}{5}\mathbf{u}_{n-4} + \frac{1}{6}\mathbf{u}_{n-5} = h\mathbf{f}_{n+1}. \quad (8.51)$$

BDF $q$  的经典阶为  $q$ 。但零稳定性只在

$$\boxed{1 \leq q \leq 6} \quad (8.52)$$

时成立；BDF7 及更高阶违反根条件。

注 8.5 (关于附件中“ $p \leq 5$ ”的编号差异). [QE-Train] 和 [NA-Wang] 的部分页面写有“BDF 在  $p \leq 5$  时零稳定”。

其相邻页面使用的  $p$  是旧节点的最高滞后指标，标准 BDF 阶数相当于  $q = p + 1$ 。因此  $p \leq 5 \iff q \leq 6$ 。本文采用国际通行的 BDF $q$  命名，统一写成：

BDF1, ..., BDF6 零稳定，BDF7 及更高阶不零稳定。这里是编号换算，不是数学结论冲突。

### 8.3.4 知识点八：预测-校正方法

隐式 Adams-Moulton 公式每一步需要解非线性方程。一种常见折中是：

显式 Adams-Bashforth 预测 + Adams-Moulton 校正。

例如 AB2-梯形法预测-校正格式为

$$\mathbf{u}_{n+1}^{[0]} = \mathbf{u}_n + \frac{h}{2}(3\mathbf{f}_n - \mathbf{f}_{n-1}), \quad (8.53)$$

$$\mathbf{u}_{n+1}^{[\ell+1]} = \mathbf{u}_n + \frac{h}{2} \left[ \mathbf{f}_n + \mathbf{f}(t_{n+1}, \mathbf{u}_{n+1}^{[\ell]}) \right]. \quad (8.54)$$

若只校正一次，得到 PECE 结构：Predict  $\rightarrow$  Evaluate  $\rightarrow$  Correct  $\rightarrow$  Evaluate。

---

#### Algorithm 28 AB2-梯形法预测-校正算法

---

**Input:** 已有  $\mathbf{u}_{n-1}, \mathbf{u}_n$  及  $\mathbf{f}_{n-1}, \mathbf{f}_n$ ；步长  $h$ ；最大校正次数  $m_{\max}$ ；校正容差  $\text{tol}_{\text{corr}}$

**Output:**  $\mathbf{u}_{n+1}$

- 1: **Initialization:**  $\mathbf{u}_{n+1}^{[0]} \leftarrow \mathbf{u}_n + \frac{h}{2}(3\mathbf{f}_n - \mathbf{f}_{n-1})$
- 2: **for**  $\ell = 0, 1, \dots, m_{\max} - 1$  **do**
- 3:    $\mathbf{u}_{n+1}^{[\ell+1]} \leftarrow \mathbf{u}_n + \frac{h}{2} \left[ \mathbf{f}_n + \mathbf{f}(t_{n+1}, \mathbf{u}_{n+1}^{[\ell]}) \right]$
- 4:   **if**  $\left\| \mathbf{u}_{n+1}^{[\ell+1]} - \mathbf{u}_{n+1}^{[\ell]} \right\| \leq \text{tol}_{\text{corr}}(1 + \left\| \mathbf{u}_{n+1}^{[\ell+1]} \right\|)$  **then**
- 5:     终止校正
- 6:   **end if**
- 7: **end for**
- 8:  $\mathbf{u}_{n+1} \leftarrow \mathbf{u}_{n+1}^{[\ell+1]}$
- 9:  $\mathbf{f}_{n+1} \leftarrow \mathbf{f}(t_{n+1}, \mathbf{u}_{n+1})$



10: **Stopping criterion:** 校正差达到容差, 或达到最大校正次数

11: **Complexity:** 预测阶段不增加新函数值; 每次校正增加一次函数值; 存储  $O(d)$  至  $O(kd)$

若  $f$  关于  $y$  的 Lipschitz 常数为  $L$ , 则梯形校正映射  $\mathcal{T}(v) = u_n + \frac{h}{2} [f_n + f(t_{n+1}, v)]$  满足  $\|\mathcal{T}(v) - \mathcal{T}(w)\| \leq \frac{hL}{2} \|v - w\|$ . 因此

$$\frac{hL}{2} < 1 \quad (8.55)$$

是固定点校正收敛的一个充分条件。

#### 易错点与反例

隐式格式 A 稳定, 不代表用任意固定点迭代求解其阶段方程都无条件收敛。

例如梯形法本身 A 稳定, 但简单固定点校正仍要求类似  $hL/2 < 1$  的条件。时间离散稳定性与非线性求解器收敛性必须分别分析。

### 8.3.5 知识点九: 起步方法

$k$  步方法需要  $u_0, u_1, \dots, u_{k-1}$  共  $k$  个起步值。初值问题只直接给出  $u_0$ , 其余值必须由起步方法生成。

定理 8.6 (起步误差与整体阶). 设线性多步法零稳定、局部缺陷为  $O(h^{p+1})$ 。若起步值满足

$$\max_{0 \leq j \leq k-1} \|u_j - y(t_j)\| = O(h^r), \quad (8.56)$$

则一般只能保证整体误差阶

$$O(h^{\min\{p, r\}}). \quad (8.57)$$

要保持  $p$  阶整体精度, 必须至少有

$$u_j - y(t_j) = O(h^p), \quad j = 0, \dots, k-1. \quad (8.58)$$

常用起步方式包括:

- 同阶或更高阶 Runge-Kutta 方法;
- 更小步长的单步法;
- 已知导数时使用 Taylor 方法;
- 低阶多步法逐级升阶;
- 在发生事件、间断或步长突变后重新起步。

#### 【失败情形】

- 用一阶 Euler 法粗糙起步高阶多步法, 导致整体降阶;
- 改变步长后仍使用常步长系数;
- 忘记保存足够的历史状态或右端项;
- 隐式法内层迭代容差大于时间离散局部误差;
- 解跨越间断点后继续使用间断前历史数据;
- 自适应拒步后历史数组没有正确回滚。



## 8.4 线性差分方程、根条件与零稳定性

### 8.4.1 知识点十：齐次线性差分方程的解结构

考虑齐次差分方程

$$\sum_{j=0}^k \alpha_j v_{n+j} = 0. \quad (8.59)$$

其特征方程为

$$\rho(\zeta) = 0. \quad (8.60)$$

设互异根为  $\zeta_1, \dots, \zeta_s$ , 对应代数重数为  $m_1, \dots, m_s$ 。

定理 8.7 (齐次差分方程的通解). 式 (8.59) 的通解为

$$v_n = \sum_{\ell=1}^s \left[ \sum_{r=0}^{m_\ell-1} c_{\ell,r} n^r \right] \zeta_\ell^n. \quad (8.61)$$

根  $\zeta = 1$  对应连续 ODE 解的主模式；其余根称为寄生根或寄生模式。

若某个根满足  $|\zeta| < 1$ , 则即使带有有限次数的  $n^r$  因子,  $n^r |\zeta|^n$  仍一致有界并趋于零。

若  $|\zeta| = 1$  且根为单根, 则相应模式仅作等幅振荡。

若  $|\zeta| = 1$  且根重数  $m \geq 2$ , 则出现  $n^{m-1} \zeta^n$  的多项式增长。

### 8.4.2 知识点十一：根条件

定义 8.8 (根条件). 第一特征多项式  $\rho$  满足根条件, 是指:

1.  $\rho$  的所有根  $\zeta$  均满足

$$|\zeta| \leq 1; \quad (8.62)$$

2. 所有满足  $|\zeta| = 1$  的根均为单根。

定理 8.9 (根条件与齐次解一致有界). 以下两件事等价:

1.  $\rho$  满足根条件;
2. 存在与  $n$  无关的常数  $M$ , 使任意齐次解均满足

$$|v_n| \leq M \max_{0 \leq j \leq k-1} |v_j|, \quad n \geq 0. \quad (8.63)$$

证明. 若根条件成立, 由 式 (8.61):

- $|\zeta_\ell| < 1$  的模式  $n^r \zeta_\ell^n$  一致有界;
- $|\zeta_\ell| = 1$  的根均为单根, 只产生  $c_\ell \zeta_\ell^n$ , 模长保持常数。

有限个模式之和因此一致有界。

反之, 若存在根  $|\zeta| > 1$ , 则  $v_n = \zeta^n$  是无界齐次解。

若存在单位圆上的重根, 重数至少为 2, 则  $v_n = n \zeta^n$  或更高次  $n^{m-1} \zeta^n$  是无界齐次解。故一致有界性必推出根条件。□



## 8.4.3 知识点十二：非齐次差分方程的稳定估计

考虑

$$\sum_{j=0}^k \alpha_j v_{n+j} = \phi_{n+k}. \quad (8.64)$$

定理 8.10 (非齐次差分方程的稳定估计). 若  $\rho$  满足根条件, 则存在常数  $M > 0$ , 只依赖于  $\alpha_j$ , 使

$$|v_n| \leq M \left[ \max_{0 \leq j \leq k-1} |v_j| + \sum_{m=k}^n |\phi_m| \right]. \quad (8.65)$$

证明可通过以下任一方式完成:

1. 构造离散基本解或 Green 函数;
2. 把  $k$  阶递推写成伴随矩阵一阶系统;
3. 使用部分分式和特征根表示。

根条件保证伴随矩阵幂  $C_\rho^n$  一致有界, 进而对离散 Duhamel 公式求和。

## 8.4.4 知识点十三：零稳定性的定义

考虑原格式

$$\sum_{j=0}^k \alpha_j \mathbf{u}_{n+j} = h \sum_{j=0}^k \beta_j \mathbf{f}(t_{n+j}, \mathbf{u}_{n+j}), \quad (8.66)$$

以及带扰动格式

$$\sum_{j=0}^k \alpha_j \tilde{\mathbf{u}}_{n+j} = h \sum_{j=0}^k \beta_j \mathbf{f}(t_{n+j}, \tilde{\mathbf{u}}_{n+j}) + h \delta_{n+k}. \quad (8.67)$$

定义 8.11 (零稳定性). 若对固定终止时间  $T$ , 存在  $h_0 > 0$  及与  $h, N$  无关的常数  $C$ , 使对所有  $0 < h \leq h_0$  及  $Nh \leq T - t_0$ , 均有

$$\max_{0 \leq n \leq N} \|\tilde{\mathbf{u}}_n - \mathbf{u}_n\| \leq C \left[ \max_{0 \leq j \leq k-1} \|\tilde{\mathbf{u}}_j - \mathbf{u}_j\| + h \sum_{m=k}^N \|\delta_m\| \right], \quad (8.68)$$

则称该线性多步法零稳定。

因为  $h \sum_{m=k}^N \|\delta_m\| \leq (T - t_0) \max_m \|\delta_m\|$ , 也可把定义写成最大扰动形式。

“零稳定”中的“零”指  $h \rightarrow 0$  且终止时间固定, 不是指测试方程参数  $\lambda = 0$  本身。但在证明必要性时, 确实常取测试问题  $\mathbf{y}' = \mathbf{0}$ 。

定理 8.12 (零稳定性与根条件等价). 设  $\mathbf{f}$  关于  $\mathbf{y}$  满足一致 Lipschitz 条件。线性多步法零稳定, 当且仅当第一特征多项式  $\rho$  满足根条件。

必要性. 取  $\mathbf{f} \equiv \mathbf{0}$ 。此时误差满足齐次差分方程  $\sum_{j=0}^k \alpha_j \mathbf{e}_{n+j} = \mathbf{0}$ 。

若存在根  $|\zeta| > 1$ , 可取依赖于  $h$  的齐次误差模式  $e_n^{(h)} = h\zeta^n$ 。对固定的起步指标  $j$ ,  $e_j^{(h)} \rightarrow 0$  ( $h \rightarrow 0$ ), 但当  $n \sim \frac{T}{h}$  时,  $|e_n^{(h)}| = h|\zeta|^{T/h} \rightarrow \infty$ 。这与零稳定性矛盾。

若单位圆上存在  $m$  重根,  $m \geq 2$ , 则有齐次模式  $e_n^{(h)} = h^{m-1}n^{m-1}\zeta^n$ 。起步误差趋于零, 但当  $n \sim T/h$  时,  $|e_n^{(h)}| \sim T^{m-1}$ , 不趋于零。同样违反零稳定性。

故零稳定性必推出根条件。 □

充分性. 令  $\mathbf{e}_n = \tilde{\mathbf{u}}_n - \mathbf{u}_n$ . 两格式相减:

$$\sum_{j=0}^k \alpha_j \mathbf{e}_{n+j} = h \sum_{j=0}^k \beta_j [\mathbf{f}(t_{n+j}, \tilde{\mathbf{u}}_{n+j}) - \mathbf{f}(t_{n+j}, \mathbf{u}_{n+j})] + h \delta_{n+k}. \quad (8.69)$$

若  $\mathbf{f}$  的 Lipschitz 常数为  $L$ , 则右端函数差满足  $\|\mathbf{f}(t, \tilde{\mathbf{u}}) - \mathbf{f}(t, \mathbf{u})\| \leq L \|\tilde{\mathbf{u}} - \mathbf{u}\|$ .

由非齐次差分估计式 (8.65), 并在隐式情形取  $h$  充分小以吸收当前步误差项, 可得

$$E_n \leq C_0 E_{\text{start}} + C_1 h \sum_{m=0}^n E_m + C_2 h \sum_{m=k}^n \|\delta_m\|, \quad (8.70)$$

其中  $E_n = \max_{0 \leq j \leq n} \|\mathbf{e}_j\|$ . 应用离散 Gronwall 不等式, 即得式 (8.68).  $\square$

#### 根条件与零稳定性的答题框架

识别信号: 题目出现第一特征多项式、寄生根、零稳定性、起步扰动或根条件。

构造步骤:

1. 先令右端项  $f = 0$ ;
2. 写出齐次差分方程;
3. 求  $\rho(\zeta) = 0$ ;
4. 检查所有根是否位于闭单位圆;
5. 检查单位圆上的根是否为单根;
6. 必要时利用通解  $n^r \zeta^n$  解释失败模式;
7. 充分性用非齐次差分估计和离散 Gronwall。

常见失败原因: 只检查  $\rho(1) = 0$  而不检查其他根; 或只检查  $|\zeta| \leq 1$  而遗漏单位圆重根必须为单根。

反例 8.13 (相容但不零稳定的方法). 考虑形式上的二步法

$$\mathbf{u}_{n+2} - 2\mathbf{u}_{n+1} + \mathbf{u}_n = \mathbf{0}. \quad (8.71)$$

这里  $\rho(\zeta) = (\zeta - 1)^2$ ,  $\sigma(\zeta) = 0$ . 有  $\rho(1) = 0$ ,  $\rho'(1) = 0 = \sigma(1)$ , 所以该格式在代数意义上相容。

但  $\zeta = 1$  是二重根, 违反根条件. 其解为  $\mathbf{u}_n = \mathbf{a} + n\mathbf{b}$ . 即使初始斜率扰动  $\mathbf{b}$  很小, 经过  $O(h^{-1})$  步也会被放大为  $O(h^{-1} \|\mathbf{b}\|)$ .

因此:

相容性  $\not\Rightarrow$  收敛性.

反例 8.14 (零稳定但不相容的方法). 考虑

$$\mathbf{u}_{n+1} = \mathbf{u}_n + 2h\mathbf{f}_n. \quad (8.72)$$

第一特征多项式为  $\rho(\zeta) = \zeta - 1$ , 根  $\zeta = 1$  为单根, 所以方法零稳定。

但  $\rho'(1) = 1$ ,  $\sigma(1) = 2$ , 故不相容. 它近似的是  $\mathbf{y}' = 2\mathbf{f}(t, \mathbf{y})$ , 而不是原方程。

因此:

零稳定性  $\not\Rightarrow$  收敛性.



## 8.5 Dahlquist 等价定理与阶障碍

### 8.5.1 知识点十四：Dahlquist 等价定理

【重要性等级】 **S 级**。该定理是线性多步法理论的中心结论：

收敛  $\iff$  相容 + 零稳定。

定理 8.15 (Dahlquist 等价定理). 设  $\mathbf{f}$  关于  $\mathbf{y}$  满足一致 Lipschitz 条件。线性多步法对所有相应适定初值问题收敛，当且仅当该方法相容且零稳定。

进一步，若：

1. 方法具有  $p$  阶局部精度，即  $\max_n \|\mathbf{d}_{n+k}\| \leq C_d h^{p+1}$ ;
2. 起步误差满足  $\max_{0 \leq j \leq k-1} \|\mathbf{u}_j - \mathbf{y}(t_j)\| \leq C_s h^p$ ;

则存在与  $h$  无关的常数  $C$ ，使

$$\max_{0 \leq n \leq N} \|\mathbf{u}_n - \mathbf{y}(t_n)\| \leq C h^p. \quad (8.73)$$

充分性. 精确网格值满足

$$\sum_{j=0}^k \alpha_j \mathbf{y}(t_{n+j}) = h \sum_{j=0}^k \beta_j \mathbf{f}(t_{n+j}, \mathbf{y}(t_{n+j})) + \mathbf{d}_{n+k}. \quad (8.74)$$

把精确网格值看成带扰动格式的解，其中每步归一化扰动为  $\delta_{n+k} = \frac{\mathbf{d}_{n+k}}{h} = O(h^p)$ 。由零稳定性，

$$\max_n \|\mathbf{u}_n - \mathbf{y}(t_n)\| \leq C \left[ \max_{0 \leq j \leq k-1} \|\mathbf{u}_j - \mathbf{y}(t_j)\| + h \sum_{m=k}^N \|\delta_m\| \right]. \quad (8.75)$$

因为  $N = O(h^{-1})$ ，有  $h \sum_{m=k}^N \|\delta_m\| = O(h^p)$ 。再结合起步误差  $O(h^p)$ ，得到  $\max_n \|\mathbf{u}_n - \mathbf{y}(t_n)\| = O(h^p)$ 。□

必要性的证明框架. 若方法对所有适定初值问题收敛，则：

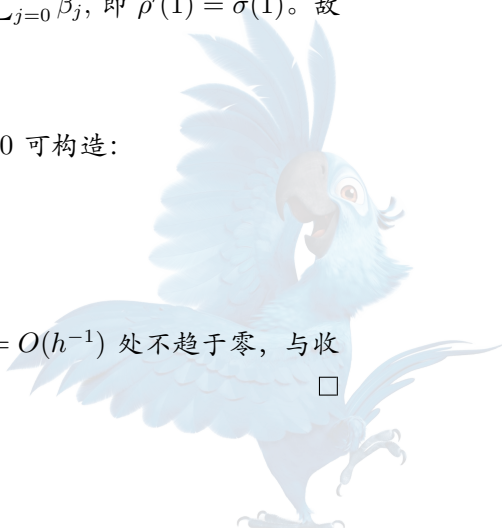
第一步：证明相容性 对常值解  $y(t) \equiv 1$ ,  $y' = 0$ ，要求离散残差趋于零，得到  $\sum_{j=0}^k \alpha_j = 0$ ，即  $\rho(1) = 0$ 。

再对线性函数  $y(t) = t$ ,  $y' = 1$ ，要求残差趋于零，得到  $\sum_{j=0}^k j \alpha_j = \sum_{j=0}^k \beta_j$ ，即  $\rho'(1) = \sigma(1)$ 。故方法相容。

第二步：证明零稳定性 若根条件不成立，则对测试问题  $y' = 0$ ,  $y(0) = 0$  可构造：

- $|\zeta| > 1$  对应的指数增长齐次模式；
- 单位圆重根对应的  $n^{m-1} \zeta^n$  增长模式。

这些模式的起步扰动可随  $h \rightarrow 0$  而趋于零，但在固定终止时间对应的  $n = O(h^{-1})$  处不趋于零，与收敛性矛盾。所以方法必须零稳定。□





## 8.5.2 知识点十五: Dahlquist 第一障碍

定理 8.16 (Dahlquist 第一障碍). 设一个  $k$  步线性多步法零稳定, 阶数为  $p$ 。则

$$p \leq \begin{cases} k+1, & k \text{ 为奇数,} \\ k+2, & k \text{ 为偶数.} \end{cases} \quad (8.76)$$

若方法显式, 则还有更强限制

$$p \leq k. \quad (8.77)$$

Adams–Bashforth 方法达到显式上界  $p = k$ 。Adams–Moulton 方法通常达到  $p = k + 1$ 。BDF $q$  达到  $p = q$ , 但高阶受到零稳定性限制。

## 第一障碍的证明框架

完整证明需要结合高阶阶条件与根条件, 通常不作为基础资格考试的逐行证明题。应掌握以下逻辑:

1. 阶  $p$  等价于  $\rho(e^w) - w\sigma(e^w) = O(w^{p+1})$ ;
2. 这要求  $w = 0$  处出现高重数消失;
3. 零稳定性要求  $\rho$  在单位圆上的根结构受限;
4. 利用单位圆上的参数化、辐角变化或相应三角多项式, 可将高阶消失条件转化为关于  $k$  的零点计数约束;
5. 由此得到奇偶不同的上界。

考试中若只要求陈述, 应准确写出奇偶上界; 不得把  $k+2$  无条件写成所有  $k$  的统一上界并声称可达到。

## 8.5.3 知识点十六: Dahlquist 第二障碍

定理 8.17 (Dahlquist 第二障碍). 在线性多步法类中:

1. 不存在  $A$  稳定的显式线性多步法;
2.  $A$  稳定线性多步法的阶数不超过 2。

因此:

- 后向 Euler 为一阶  $A$  稳定方法;
- 梯形法为二阶  $A$  稳定方法;
- BDF2 为二阶  $A$  稳定方法;
- BDF3–BDF6 虽然具有较大的无界稳定域, 但不是  $A$  稳定;
- 高阶  $A$  稳定方法需要转向隐式 Runge–Kutta 等其他方法族。

第二障碍的完整证明涉及边界轨迹、正实函数或阶星理论。资格考试通常要求准确陈述、会应用, 而不要求从头证明全部复分析细节。



## 易错点与反例

Dahlquist 第二障碍只限制线性多步法。

它不表示所有数值 ODE 方法的 A 稳定阶数都不超过 2。例如 Gauss-Legendre 隐式 Runge-Kutta 方法可具有任意偶数阶并保持 A 稳定。

## 8.6 绝对稳定性、绝对根条件与边界轨迹

## 8.6.1 知识点十七：测试方程与绝对特征多项式

对 Dahlquist 测试方程

$$y' = \lambda y, \operatorname{Re} \lambda < 0, \quad (8.78)$$

令  $z = h\lambda$ 。将线性多步法代入，得到

$$\sum_{j=0}^k (\alpha_j - z\beta_j) u_{n+j} = 0. \quad (8.79)$$

试探解  $u_n = \zeta^n$  给出绝对特征方程

$$\pi_z(\zeta) := \rho(\zeta) - z\sigma(\zeta) = 0. \quad (8.80)$$

定义 8.18 (严格衰减型绝对稳定域)。本文把线性多步法的严格绝对稳定域定义为

$$\mathcal{S}_{\text{dec}} = \{z \in \mathbb{C} : \pi_z(\zeta) = 0 \text{ 的全部根均满足 } |\zeta| < 1\}. \quad (8.81)$$

对  $z \in \mathcal{S}_{\text{dec}}$ ，任意数值解均满足  $u_n \rightarrow 0$ ， $n \rightarrow \infty$ 。

定义 8.19 (有界型绝对根条件)。若  $\pi_z$  的所有根满足  $|\zeta| \leq 1$ ，且单位圆上的根均为单根，则称该  $z$  满足绝对根条件。相应集合记为  $\mathcal{S}_{\text{bnd}}$ 。

本文正文以严格衰减域  $\mathcal{S}_{\text{dec}}$  作为绝对稳定域。绘图时可把满足简单单位根的边界并入闭稳定域。

## 易错点与反例

不同资料对稳定域边界是否包含采用不同约定：

- 若要求  $u_n \rightarrow 0$ ，应使用严格条件  $|\zeta| < 1$ ；
- 若只要求  $\{u_n\}$  有界，可允许简单单位根；
- 若题目只写“稳定域”，应先声明本文采用哪一种约定。

## 8.6.2 知识点十八：多步法不能只写一个稳定函数

对于一般线性多步法， $\pi_z(\zeta)$  是  $k$  次多项式，具有  $k$  个根  $\zeta_1(z), \dots, \zeta_k(z)$ 。必须同时检查全部根。

只有在一步法中，特征方程可化为  $\zeta = R(z)$ ，此时才有单一稳定函数  $R(z)$ 。

## 易错点与反例

对二步或更高步数方法，只找到一个“主根” $\zeta_1(z) \approx e^z$  并验证  $|\zeta_1(z)| < 1$  是不够的。

还必须检查全部寄生根  $\zeta_2(z), \dots, \zeta_k(z)$ 。寄生根离开单位圆同样会导致数值解发散。

## 8.6.3 知识点十九：边界轨迹法

当某个特征根位于单位圆上时，可令  $\zeta = e^{i\theta}$ ,  $0 \leq \theta \leq 2\pi$ 。由  $\rho(\zeta) - z\sigma(\zeta) = 0$  得到

$$z(\theta) = \frac{\rho(e^{i\theta})}{\sigma(e^{i\theta})}, \quad \sigma(e^{i\theta}) \neq 0. \quad (8.82)$$

这称为边界轨迹或根轨迹。

**Algorithm 29** 线性多步法绝对稳定域的边界轨迹法

**Input:** 系数  $\alpha_j, \beta_j$

**Output:** 稳定域边界及稳定侧

- 1: 构造  $\rho(\zeta) = \sum_{j=0}^k \alpha_j \zeta^j$ ,  $\sigma(\zeta) = \sum_{j=0}^k \beta_j \zeta^j$
- 2: **for**  $\theta \in [0, 2\pi]$  **do**
- 3:     令  $\zeta = e^{i\theta}$
- 4:     **if**  $\sigma(\zeta) \neq 0$  **then**
- 5:          $z(\theta) \leftarrow \rho(\zeta)/\sigma(\zeta)$
- 6:     **else**
- 7:         记录边界在无穷远处的方向或奇异点
- 8:     **end if**
- 9: **end for**
- 10: 检查使最高次系数  $\alpha_k - z\beta_k$  为零的点；此时可能有根穿过无穷远
- 11: 在每个连通区域选测试点，直接求  $\rho(\zeta) - z\sigma(\zeta) = 0$  的全部根
- 12: 将全部根严格位于单位圆内的连通分支标为稳定域
- 13: **Stopping criterion:** 完成边界参数化和稳定侧判定
- 14: **Complexity:** 若采样  $M$  个边界点并每次解  $k$  次多项式，朴素成本约  $O(Mk^3)$ ；低阶方法可解析处理

8.6.4 知识点二十：A 稳定与  $A(\alpha)$  稳定

**定义 8.20** (A 稳定). 若

$$\mathbb{C}_- := \{z \in \mathbb{C} : \operatorname{Re} z < 0\} \subset \mathcal{S}_{\text{dec}}, \quad (8.83)$$

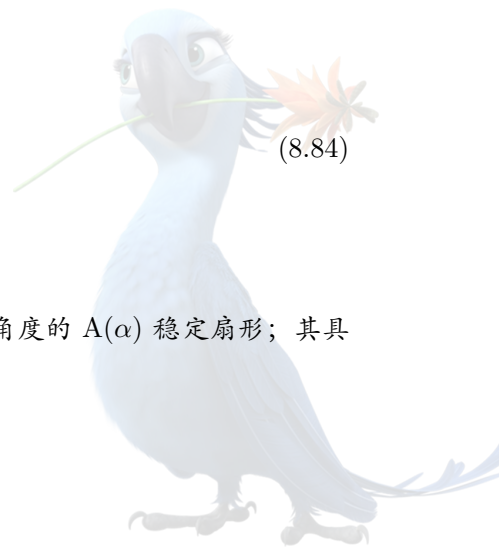
则称方法 A 稳定。

**定义 8.21** ( $A(\alpha)$  稳定). 若存在  $0 < \alpha \leq \frac{\pi}{2}$  使扇形

$$\{z \neq 0 : |\arg(-z)| < \alpha\} \subset \mathcal{S}_{\text{dec}}, \quad (8.84)$$

则称方法  $A(\alpha)$  稳定。

A 稳定是  $\alpha = \frac{\pi}{2}$  的情形。BDF3–BDF6 不是 A 稳定，但具有非零角度的  $A(\alpha)$  稳定扇形；其具体角度将在第 09 部分刚性问题中结合实际步长限制讨论。



## 8.6.5 基础例题: AB2 的负实轴稳定区间

完整题目叙述

求二步 Adams-Bashforth 方法  $u_{n+1} = u_n + \frac{h}{2}(3f_n - f_{n-1})$  在负实轴上的绝对稳定区间。详细解答. 对  $y' = \lambda y$ ,  $z = h\lambda$ , 有

$$u_{n+1} - \left(1 + \frac{3}{2}z\right)u_n + \frac{1}{2}zu_{n-1} = 0. \quad (8.85)$$

特征多项式为

$$\pi_z(\zeta) = \zeta^2 - \left(1 + \frac{3}{2}z\right)\zeta + \frac{1}{2}z. \quad (8.86)$$

令  $z = -r$ ,  $r \geq 0$ . 则  $\pi_{-r}(\zeta) = \zeta^2 - (1 - \frac{3}{2}r)\zeta - \frac{1}{2}r$ . 对实二次多项式  $\zeta^2 + a_1\zeta + a_0$ , 两根严格位于单位圆内的 Schur-Jury 条件为

$$|a_0| < 1, \quad 1 + a_1 + a_0 > 0, \quad 1 - a_1 + a_0 > 0. \quad (8.87)$$

本题中  $a_1 = -1 + \frac{3}{2}r$ ,  $a_0 = -\frac{1}{2}r$ . 三个条件分别给出

$$\begin{aligned} \frac{r}{2} &< 1, \\ r &> 0, \\ 2 - 2r &> 0. \end{aligned}$$

所以严格稳定条件为  $0 < r < 1$ . 换回  $z = -r$ :

$$\boxed{-1 < z < 0}. \quad (8.88)$$

若采用包含简单单位根的闭稳定区间约定, 则写成

$$\boxed{[-1, 0]}. \quad (8.89)$$

在  $z = -1$  时,  $\pi_{-1}(\zeta) = \zeta^2 + \frac{1}{2}\zeta - \frac{1}{2} = (\zeta + 1)(\zeta - \frac{1}{2})$ , 其中  $\zeta = -1$  为简单单位根。□

## 8.6.6 基础例题: 梯形法的 A 稳定性

完整题目叙述

证明隐式梯形法  $u_{n+1} = u_n + \frac{h}{2}(f_n + f_{n+1})$  是 A 稳定方法。

详细解答. 对测试方程,  $u_{n+1} = u_n + \frac{z}{2}(u_n + u_{n+1})$ . 故  $(1 - \frac{z}{2})u_{n+1} = (1 + \frac{z}{2})u_n$ , 稳定函数为

$$R(z) = \frac{1 + z/2}{1 - z/2}. \quad (8.90)$$

于是

$$\begin{aligned} |R(z)| \leq 1 &\iff \left|1 + \frac{z}{2}\right| \leq \left|1 - \frac{z}{2}\right| \\ &\iff \operatorname{Re} z \leq 0. \end{aligned} \quad (8.91)$$

因此整个左半平面均包含于稳定域, 梯形法 A 稳定。□



## 8.7 易错点与失败情形：线性多步法

| 错误说法或错误做法                                    | 正确处理                                                             |
|----------------------------------------------|------------------------------------------------------------------|
| 局部缺陷 $O(h^{p+1})$ , 所以无需稳定性便有整体误差 $O(h^p)$ 。 | 局部缺陷还要经过 $O(h^{-1})$ 步传播; 必须用零稳定性控制累积。                           |
| 相容性自动推出收敛。                                   | 线性多步法还必须满足根条件, 即零稳定。                                             |
| 零稳定性就是绝对稳定性。                                 | 零稳定研究 $h \rightarrow 0$ 、固定终止时间; 绝对稳定研究固定 $z = h\lambda$ 下的长期迭代。 |
| 只检查 $\rho(1) = 0$ 即可判断零稳定。                   | 必须求 $\rho$ 的全部根, 并检查单位圆根的重数。                                     |
| 单位圆上的根允许重复。                                  | 根条件要求单位圆上的根必须为单根。                                                |
| BDF 可以任意提高阶数。                                | 标准 BDF1–BDF6 零稳定; BDF7 及更高阶不零稳定。                                 |
| BDF2 稳定域只包括左半平面。                             | 其稳定域是边界闭曲线的无界外部区域, 包含整个左半平面, 也可能包含部分右半平面。                        |
| 多步法有单一稳定函数 $R(z)$ 。                          | 一般有 $k$ 个特征根, 必须检查 $\rho(\zeta) - z\sigma(\zeta)$ 的全部根。          |
| 隐式多步法绝对稳定, 所以每步非线性方程必容易求解。                   | 时间离散稳定性与 Newton 或固定点迭代收敛性是不同问题。                                  |
| 高阶多步法可用一阶 Euler 法随意起步。                       | 若起步误差只有 $O(h)$ , 整体阶通常降为 1。                                      |
| 改变步长后仍使用常步长 Adams 或 BDF 系数。                  | 变步长多步法需要重新计算系数并管理历史值。                                            |
| 预测-校正一次等于完全求解隐式校对方程。                         | 一次校正只是显式近似; 重复校正或 Newton 迭代才逐渐逼近隐式方法。                            |
| 根条件中的 $\rho$ 可以替换为 $\rho - z\sigma$ 。        | 前者判断零稳定, 后者判断给定 $z$ 的绝对稳定。                                       |
| A 稳定意味着任何 $h$ 都准确。                           | A 稳定只解除线性稳定性限制, 过大步长仍会产生严重相位和幅值误差。                               |

## 8.8 补充训练题：丘赛 2020 Problem 4——BDF2 型隐式二步法

## 完整题目叙述

[Yau-2020-Problem-4]

对初值问题

$$\begin{cases} y' = f(t, y), & 0 \leq t \leq T, \\ y(0) = y_0, \end{cases} \quad (8.92)$$

考虑隐式二步方法

$$y_{n+1} = \frac{4}{3}y_n - \frac{1}{3}y_{n-1} + \frac{2h}{3}f(t_{n+1}, y_{n+1}), \quad (8.93)$$

起步值为

$$y_1 = y_0 + hf(t_1, y_0), \quad (8.94)$$

其中  $t_n = nh$ 。

- (a) 求该格式的精度阶。
- (b) 通过稳定多项式分析该格式的稳定性。
- (c) 求该格式的绝对稳定域。

注 8.22 (题面审计). 原题起步公式确实写为  $y_1 = y_0 + hf(t_1, y_0)$ , 而不是通常的前向 Euler  $y_1 = y_0 + hf(t_0, y_0)$ 。本文保留原题公式, 并单独验证该起步误差仍为  $O(h^2)$ , 所以不会降低 BDF2 的二阶整体精度。

第 (a) 问: 二步主格式的局部精度. 将式 (8.93) 乘以  $3/2$ , 得到标准 BDF2 形式

$$\frac{3}{2}y_{n+1} - 2y_n + \frac{1}{2}y_{n-1} = hf(t_{n+1}, y_{n+1}). \quad (8.95)$$

把精确解代入, 定义未归一化局部缺陷

$$d_{n+1} = \frac{3}{2}y(t_{n+1}) - 2y(t_n) + \frac{1}{2}y(t_{n-1}) - hy'(t_{n+1}). \quad (8.96)$$

围绕  $t_{n+1}$  展开:

$$\begin{aligned} y(t_n) &= y(t_{n+1}) - hy'(t_{n+1}) + \frac{h^2}{2}y''(t_{n+1}) \\ &\quad - \frac{h^3}{6}y^{(3)}(t_{n+1}) + \frac{h^4}{24}y^{(4)}(t_{n+1}) + O(h^5), \end{aligned} \quad (8.97)$$

$$\begin{aligned} y(t_{n-1}) &= y(t_{n+1}) - 2hy'(t_{n+1}) + 2h^2y''(t_{n+1}) \\ &\quad - \frac{4}{3}h^3y^{(3)}(t_{n+1}) + \frac{2}{3}h^4y^{(4)}(t_{n+1}) + O(h^5). \end{aligned} \quad (8.98)$$

代入式 (8.96):

- 常数项消失;
- 一阶导数项恰为  $hy'(t_{n+1})$ , 与右端相消;
- 二阶导数项消失;
- 三阶导数项系数为  $-\frac{1}{3}h^3$ .

因此

$$d_{n+1} = -\frac{1}{3}h^3y^{(3)}(t_{n+1}) + \frac{1}{4}h^4y^{(4)}(t_{n+1}) + O(h^5). \quad (8.99)$$


故主二步格式的未归一化局部缺陷为  $O(h^3)$ , 归一化局部截断误差为  $O(h^2)$ 。所以主格式为二阶。□

第 (a) 问: 原题起步公式的误差. 记  $f_0 = f(0, y_0)$ 。假设  $f$  足够光滑. 原题起步值为  $y_1 = y_0 + hf(h, y_0)$ 。在  $(0, y_0)$  处展开:

$$f(h, y_0) = f_0 + hf_t(0, y_0) + O(h^2). \quad (8.100)$$

所以

$$y_1 = y_0 + hf_0 + h^2f_t(0, y_0) + O(h^3). \quad (8.101)$$



精确解满足  $y'(0) = f_0$ , 以及

$$y''(0) = f_t(0, y_0) + f_y(0, y_0)f_0. \quad (8.102)$$

因此

$$y(h) = y_0 + hf_0 + \frac{h^2}{2} [f_t(0, y_0) + f_y(0, y_0)f_0] + O(h^3). \quad (8.103)$$

二者相减:

$$y_1 - y(h) = \frac{h^2}{2} [f_t(0, y_0) - f_y(0, y_0)f_0] + O(h^3). \quad (8.104)$$

所以  $y_1 - y(h) = O(h^2)$ 。该起步误差满足二阶多步法所需的  $O(h^2)$  条件。

因此, 只要主格式零稳定, 整个算法的整体精度为

$$p = 2. \quad (8.105)$$

□

第 (b) 问: 零稳定性. 令  $f \equiv 0$ . 由原格式得到齐次递推

$$y_{n+1} - \frac{4}{3}y_n + \frac{1}{3}y_{n-1} = 0. \quad (8.106)$$

第一特征多项式为

$$\begin{aligned} \rho(\zeta) &= \zeta^2 - \frac{4}{3}\zeta + \frac{1}{3} \\ &= (\zeta - 1)\left(\zeta - \frac{1}{3}\right). \end{aligned} \quad (8.107)$$

两个根为  $\zeta_1 = 1$ ,  $\zeta_2 = \frac{1}{3}$ . 其中:

- $\zeta_1 = 1$  位于单位圆上且为单根;
- $\zeta_2 = 1/3$  严格位于单位圆内。

所以  $\rho$  满足根条件, 该方法零稳定。

结合第 (a) 问的二阶相容性和起步误差  $O(h^2)$ , 由 Dahlquist 等价定理,

$$\max_{0 \leq n \leq N} |y(t_n) - y_n| = O(h^2). \quad (8.108)$$

□

第 (c) 问: 绝对特征多项式. 对测试方程

$$y' = \lambda y, \quad z = h\lambda, \quad (8.109)$$

原格式变为


$$y_{n+1} = \frac{4}{3}y_n - \frac{1}{3}y_{n-1} + \frac{2}{3}zy_{n+1}. \quad (8.110)$$

整理得

$$\left(1 - \frac{2}{3}z\right)y_{n+1} - \frac{4}{3}y_n + \frac{1}{3}y_{n-1} = 0. \quad (8.111)$$

令  $y_n = \zeta^n$ , 得到绝对特征方程

$$\left(1 - \frac{2}{3}z\right)\zeta^2 - \frac{4}{3}\zeta + \frac{1}{3} = 0. \quad (8.112)$$





乘以 3:

$$\boxed{(3-2z)\zeta^2 - 4\zeta + 1 = 0}. \quad (8.113)$$

严格绝对稳定域为

$$\mathcal{S} = \{z \in \mathbb{C} : (8.113) \text{ 的两个根均满足 } |\zeta| < 1\}. \quad (8.114)$$

□

第 (c) 问: 边界轨迹. 采用标准 BDF2 多项式

$$\rho(\zeta) = \frac{3}{2}\zeta^2 - 2\zeta + \frac{1}{2}, \quad (8.115)$$

$$\sigma(\zeta) = \zeta^2. \quad (8.116)$$

令  $\zeta = e^{i\theta}$ . 稳定边界满足

$$\begin{aligned} z(\theta) &= \frac{\rho(e^{i\theta})}{\sigma(e^{i\theta})} \\ &= \frac{3}{2} - 2e^{-i\theta} + \frac{1}{2}e^{-2i\theta}. \end{aligned} \quad (8.117)$$

写成实部和虚部:

$$\begin{aligned} x(\theta) &:= \operatorname{Re} z(\theta) = \frac{3}{2} - 2\cos\theta + \frac{1}{2}\cos 2\theta \\ &= (1 - \cos\theta)^2, \end{aligned} \quad (8.118)$$

$$\begin{aligned} y(\theta) &:= \operatorname{Im} z(\theta) = 2\sin\theta - \frac{1}{2}\sin 2\theta \\ &= \sin\theta(2 - \cos\theta). \end{aligned} \quad (8.119)$$

因此边界参数方程为

$$\boxed{\Gamma_{\text{BDF2}} = \{((1 - \cos\theta)^2, \sin\theta(2 - \cos\theta)) : 0 \leq \theta \leq 2\pi\}}. \quad (8.120)$$

该曲线关于实轴对称, 并满足  $\operatorname{Re} z(\theta) = (1 - \cos\theta)^2 \geq 0$ . 实轴交点为

$$\theta = 0 \implies z = 0, \quad (8.121)$$

$$\theta = \pi \implies z = 4. \quad (8.122)$$

所以边界是一条位于闭右半平面的闭曲线, 从 0 出发, 在 4 处与实轴相交后返回 0。

稳定域是该闭曲线的无界外部连通分支。其内部为不稳定区域。


例如取内部测试点  $z = 2$ . 特征方程变为  $-\zeta^2 - 4\zeta + 1 = 0$ , 即  $\zeta^2 + 4\zeta - 1 = 0$ . 其中一个根为  $-2 - \sqrt{5}$ , 模长大于 1, 所以曲线内部不稳定。

再取外部测试点  $z = -1$ . 特征方程为  $5\zeta^2 - 4\zeta + 1 = 0$ . 其根为一对共轭复数, 乘积为  $\frac{1}{5}$ , 故每个根的模为  $\frac{1}{\sqrt{5}} < 1$ . 所以包含负实轴的无界外部区域是稳定区域。□

第 (c) 问: A 稳定性. 因为整个边界轨迹满足  $\operatorname{Re} z(\theta) \geq 0$ , 开左半平面  $\mathbb{C}_- = \{z : \operatorname{Re} z < 0\}$  不与边界相交。

又  $\mathbb{C}_-$  连通, 且测试点  $z = -1$  属于稳定域, 所以整个开左半平面均属于同一个稳定连通分支。因此

$$\boxed{\mathbb{C}_- \subset \mathcal{S}}. \quad (8.123)$$



故该方法即 BDF2 为 A 稳定方法。

最终稳定域可写为

$$\mathcal{S}_{\text{BDF2}} = \text{曲线 } z(\theta) = \frac{3}{2} - 2e^{-i\theta} + \frac{1}{2}e^{-2i\theta} \text{ 的无界外部区域}. \quad (8.124)$$

若采用有界型闭稳定域约定, 还可把边界上具有简单单位根的点并入稳定域。□

注 8.23 (显式根公式). 当  $z \neq \frac{3}{2}$  时, 式 (8.113) 的两个根为

$$\zeta_{\pm}(z) = \frac{2 \pm \sqrt{1+2z}}{3-2z}. \quad (8.125)$$

该公式可用于单点稳定性检验, 但求完整稳定域时, 边界轨迹法比直接处理复平方根分支更清晰。

【计算复杂度与实现】 每一步需要求解标量或向量非线性方程

$$\mathbf{G}_n(\mathbf{v}) = \frac{3}{2}\mathbf{v} - 2\mathbf{u}_n + \frac{1}{2}\mathbf{u}_{n-1} - h\mathbf{f}(t_{n+1}, \mathbf{v}) = \mathbf{0}. \quad (8.126)$$

Newton 迭代为

$$\left[ \frac{3}{2}I - hJ_{\mathbf{f}}(t_{n+1}, \mathbf{v}^{(\ell)}) \right] \Delta \mathbf{v}^{(\ell)} = -\mathbf{G}_n(\mathbf{v}^{(\ell)}). \quad (8.127)$$

常用初始猜测可取:

- 线性外推  $\mathbf{v}^{(0)} = 2\mathbf{u}_n - \mathbf{u}_{n-1}$ ;
- Adams–Bashforth 预测值;
- 前一步状态  $\mathbf{u}_n$ 。

对  $d$  维稠密系统, 每次 Newton 线性化的直接分解成本约为  $O(d^3)$ , 存储约为  $O(d^2)$ 。多步历史存储本身只需  $O(d)$ 。

#### 易错点与反例

1. 只写“这是 BDF2, 所以二阶”而不展示 Taylor 展开, 通常不能获得完整推导分;
2. 忽略原题起步值, 不能完整说明整个算法的整体阶;
3. 第 (b) 问的零稳定多项式是  $\rho(\zeta)$ , 第 (c) 问则是  $\rho(\zeta) - z\sigma(\zeta)$ ;
4. 稳定域不是边界曲线内部, 而是其无界外部;
5. “包含左半平面”只能推出 A 稳定, 不能据此说任意大步长都准确;
6. 丘赛题不得标记为博士资格考试题。



## 第九章 刚性问题、A/L 稳定、自适应步长、隐式求解、边值问题扩展与模块二真题映射

### 9.1 刚性初值问题：识别信号、时间尺度与步长限制

#### 9.1.1 知识点一：刚性不是单纯的“解变化快”

【重要性等级】 **S 级**。刚性问题是绝对稳定性理论的主要应用场景，也是选择显式或隐式方法的核心依据。考试中必须明确：

刚性是连续问题的多时间尺度结构与数值方法稳定域共同造成的计算现象。

不能把刚性简单定义为“导数很大”、“解变化很快”或“特征值很大”。

考虑线性自治系统

$$\mathbf{y}'(t) = A\mathbf{y}(t), \mathbf{y}(0) = \mathbf{y}_0, \quad (9.1)$$

假设  $A$  可对角化：

$$A = V\Lambda V^{-1}, \Lambda = \text{diag}(\lambda_1, \dots, \lambda_d). \quad (9.2)$$

则

$$\mathbf{y}(t) = V \text{diag}(e^{\lambda_1 t}, \dots, e^{\lambda_d t}) V^{-1} \mathbf{y}_0. \quad (9.3)$$

当  $\text{Re } \lambda_j < 0$  时，第  $j$  个模态的典型衰减时间尺度为

$$\tau_j \asymp \frac{1}{|\text{Re } \lambda_j|}. \quad (9.4)$$

若所有实部均严格为负，一种常用的刚性比定义为

$$\mathcal{S}(A) = \frac{\max_j |\text{Re } \lambda_j|}{\min_j |\text{Re } \lambda_j|}. \quad (9.5)$$

当  $\mathcal{S}(A) \gg 1$  时，系统含有相差很大的快、慢衰减时间尺度。

注 9.1. 式 (9.5) 只适合解释具有稳定、可分离模态的线性系统。对以下问题，仅看特征值可能不够：

- 非正规矩阵；
- 时变系统  $A(t)$ ；
- 非线性系统  $\mathbf{y}' = \mathbf{f}(t, \mathbf{y})$ ；
- 具有暂态增长的系统；
- 含有近虚轴模态或代数约束的系统。



此时还需考察 Jacobian、矩阵测度、伪谱、特征向量条件数及沿解轨道的局部线性化。

定义 9.2 (计算意义下的刚性). 若为了保持某个显式方法的数值稳定性, 必须选择远小于精度要求所允许步长的时间步, 则称该问题在所考察时间区间上对该数值方法表现为刚性。

换言之, 若  $h_{\text{stab}} \ll h_{\text{acc}}$ , 其中:

- $h_{\text{stab}}$  是绝对稳定性允许的最大步长;
- $h_{\text{acc}}$  是达到目标精度所需的步长;

则显式方法会因稳定性而非精度受到限制。

### 9.1.2 知识点二: 显式方法的稳定步长

设一显式方法的负实轴稳定区间为

$$[-r_*, 0], \quad r_* > 0. \quad (9.6)$$

对实负特征值  $\lambda_{\min} = -\max_j |\lambda_j|$ , 稳定性至少要求

$$h \leq \frac{r_*}{\max_j |\lambda_j|}. \quad (9.7)$$

例如:

- 前向 Euler 方法:  $r_* = 2$ ;
- 二阶显式梯形法:  $r_* = 2$ ;
- 经典四阶 Runge-Kutta 方法:  $r_* \approx 2.7853$ .

若慢时间尺度由  $|\lambda_{\text{slow}}| \asymp 1$  决定, 而快时间尺度满足  $|\lambda_{\text{fast}}| \gg 1$ , 则即使快模态已经在精确解中衰减到几乎为零, 显式方法仍必须满足  $h = O(|\lambda_{\text{fast}}|^{-1})$ 。

#### 易错点与反例

刚性不等于解始终快速变化。

典型刚性解可能在极短初始层之后变得非常平滑、缓慢, 但数值格式仍必须抑制离散系统中潜在的快衰减模态。显式方法若步长过大, 会把连续问题中的快速衰减模态变成离散增长模态。

### 9.1.3 知识点三: 半离散 PDE 为何产生刚性 ODE

以热方程的空间二阶中心差分为例, 空间半离散后得到

$$\mathbf{U}'(t) = \mathbf{A}_h \mathbf{U}(t) + \mathbf{g}_h(t), \quad (9.8)$$

其中离散 Laplacian 的最负特征值满足

$$|\lambda_{\max}(\mathbf{A}_h)| = O(h_x^{-2}). \quad (9.9)$$


因此前向 Euler 稳定性要求

$$\Delta t = O(h_x^2). \quad (9.10)$$

随着空间网格加密,  $h_x \rightarrow 0$ , 半离散 ODE 越来越刚性。

这说明:

空间离散精度提高  $\implies$  显式时间步长可能急剧减小。



## 9.2 A 稳定、L 稳定与 A( $\alpha$ ) 稳定

### 9.2.1 知识点四：稳定函数与 A 稳定性

对测试方程

$$y' = \lambda y, \quad z = h\lambda, \quad (9.11)$$

若一步方法给出

$$y_{n+1} = R(z)y_n, \quad (9.12)$$

则  $R(z)$  称为稳定函数。

绝对稳定域为

$$\mathcal{S} = \{z \in \mathbb{C} : |R(z)| \leq 1\}. \quad (9.13)$$

定义 9.3 (A 稳定). 若

$$\{z \in \mathbb{C} : \operatorname{Re} z \leq 0\} \subset \mathcal{S}, \quad (9.14)$$

则称该方法 A 稳定。

A 稳定意味着：对所有连续衰减测试方程  $\operatorname{Re} \lambda < 0$ , 任意步长  $h > 0$  均不会因线性绝对稳定性而发散。

但是 A 稳定只控制  $|R(z)| \leq 1$ , 并不保证：

- 误差足够小；
- 高频或快模态被迅速阻尼；
- 非线性方程易于求解；
- 非正规系统没有暂态放大；
- 大步长下不出现交替振荡。

### 9.2.2 知识点五：L 稳定性

定义 9.4 (L 稳定). 若一步方法满足：

1. 方法 A 稳定；
- 2.

$$\lim_{\substack{|z| \rightarrow \infty \\ \operatorname{Re} z < 0}} R(z) = 0, \quad (9.15)$$

则称该方法 L 稳定。


第二个条件意味着非常快的衰减模态  $|\lambda|h \gg 1$  会在一个或少数几个离散时间步内被强烈压制。

后向 Euler 法  $R_{\text{BE}}(z) = \frac{1}{1-z}$ 。它 A 稳定，且  $R_{\text{BE}}(z) \rightarrow 0$  ( $|z| \rightarrow \infty$ )，所以后向 Euler 是 L 稳定方法。

梯形法  $R_{\text{TR}}(z) = \frac{1+z/2}{1-z/2}$ 。它 A 稳定，但

$$\lim_{z \rightarrow -\infty} R_{\text{TR}}(z) = -1. \quad (9.16)$$

因此梯形法不是 L 稳定方法。对很刚的负实模态，它可能产生缓慢衰减的交替振荡。



易错点与反例

**A 稳定不等于 L 稳定。**

梯形法与隐式中点法均 A 稳定，但均不 L 稳定。在刚性问题中，二者可能稳定而不产生足够的刚性阻尼。

9.2.3 知识点六：A( $\alpha$ ) 稳定

定义 9.5 (A( $\alpha$ ) 稳定). 设  $0 < \alpha \leq \frac{\pi}{2}$ 。若扇形

$$\mathcal{W}_\alpha = \{z \in \mathbb{C} \setminus \{0\} : |\arg(-z)| \leq \alpha\} \quad (9.17)$$

包含在方法的绝对稳定域内，则称该方法 A( $\alpha$ ) 稳定。

A 稳定就是  $\alpha = \frac{\pi}{2}$  的特殊情形。

BDF 方法具有以下典型稳定性质：

| 方法   | 阶 | 稳定类型             | 说明                                                 |
|------|---|------------------|----------------------------------------------------|
| BDF1 | 1 | A 稳定             | 即后向 Euler；一步形式下还是 L 稳定方法。                          |
| BDF2 | 2 | A 稳定             | 其全部绝对特征根在 $ z  \rightarrow \infty$ 时趋于 0，具有良好刚性衰减。 |
| BDF3 | 3 | A( $\alpha$ ) 稳定 | $\alpha \approx 86.03^\circ$ 。                     |
| BDF4 | 4 | A( $\alpha$ ) 稳定 | $\alpha \approx 73.35^\circ$ 。                     |
| BDF5 | 5 | A( $\alpha$ ) 稳定 | $\alpha \approx 51.84^\circ$ 。                     |
| BDF6 | 6 | A( $\alpha$ ) 稳定 | $\alpha \approx 17.84^\circ$ 。                     |

对一般多步法，不宜在未说明定义的情况下直接套用一步法的  $\lim R(z) = 0$  或 L 稳定定义。应分析  $\rho(\zeta) - z\sigma(\zeta) = 0$  的全部特征根在刚性极限中的行为。

9.2.4 知识点七：典型隐式 Runge–Kutta 方法

| 方法族            | s 阶段阶数 | 稳定性  | 刚性特征                      |
|----------------|--------|------|---------------------------|
| Gauss–Legendre | 2s     | A 稳定 | 高阶、对称、辛；一般不 L 稳定，快模态阻尼不足。 |
| Radau IIA      | 2s - 1 | L 稳定 | 适合高精度刚性积分；阶段联立系统成本较高。     |
| 后向 Euler       | 1      | L 稳定 | 低阶但非常稳健，常用于启动、阻尼或误差估计。    |
| 隐式中点           | 2      | A 稳定 | 几何结构好，但不 L 稳定。            |

| 方法族 | $s$ 阶段阶数 | 稳定性  | 刚性特征                    |
|-----|----------|------|-------------------------|
| 梯形法 | 2        | A 稳定 | 二阶、无数值耗散极限；很刚时可能产生交替振荡。 |

Dahlquist 第二障碍说明：

A 稳定线性多步法的阶不超过 2。

该障碍不适用于隐式 Runge-Kutta 方法；因此高阶 A 稳定或 L 稳定方法通常来自隐式 RK、Rosenbrock、SDIRK 或其他广义线性方法。

### 9.3 补充训练题：丘赛 2026 Problem 3—— $\theta$ 方法的阶与 A 稳定性

#### 完整题目叙述

考虑  $\mathbb{R}^N$  上的初值问题

$$\mathbf{x}' = \mathbf{f}(t, \mathbf{x}), \quad \mathbf{x}(0) = \mathbf{x}_0 \in \mathbb{R}^N, \quad (9.18)$$

其中  $\mathbf{f}: [0, T] \times \mathbb{R}^N \rightarrow \mathbb{R}^N$  光滑。考虑单步方法族

$$\boxed{\mathbf{x}_{n+1} = \mathbf{x}_n + (1-b)h\mathbf{f}(t_n, \mathbf{x}_n) + bh\mathbf{f}(t_{n+1}, \mathbf{x}_{n+1})}, \quad (9.19)$$

其中  $b \in [0, 1]$ 。

- (a) 求使局部截断误差为  $O(h^3)$  的  $b$ ；
- (b) 将该方法应用于  $x' = \lambda x$ ,  $x(0) = x_0 \in \mathbb{R}$ , 求函数  $g$ , 使  $x_n = g(h\lambda)^n x_0$ ；
- (c) 求使该方法 A 稳定的全部  $b$ 。

第 (a) 问：局部截断误差。定义未归一化局部缺陷

$$\begin{aligned} \mathbf{d}_{n+1} &= \mathbf{x}(t_{n+1}) - \mathbf{x}(t_n) \\ &\quad - h[(1-b)\mathbf{x}'(t_n) + b\mathbf{x}'(t_{n+1})]. \end{aligned} \quad (9.20)$$

在  $t_n$  处展开：

$$\begin{aligned} \mathbf{x}(t_n + h) &= \mathbf{x}(t_n) + h\mathbf{x}'(t_n) + \frac{h^2}{2}\mathbf{x}''(t_n) \\ &\quad + \frac{h^3}{6}\mathbf{x}^{(3)}(t_n) + \frac{h^4}{24}\mathbf{x}^{(4)}(t_n) + O(h^5), \end{aligned} \quad (9.21)$$

$$\begin{aligned} \mathbf{x}'(t_n + h) &= \mathbf{x}'(t_n) + h\mathbf{x}''(t_n) + \frac{h^2}{2}\mathbf{x}^{(3)}(t_n) \\ &\quad + \frac{h^3}{6}\mathbf{x}^{(4)}(t_n) + O(h^4). \end{aligned} \quad (9.22)$$





代入得

$$\begin{aligned} \mathbf{d}_{n+1} &= \left(\frac{1}{2} - b\right) h^2 \mathbf{x}''(t_n) \\ &\quad + \left(\frac{1}{6} - \frac{b}{2}\right) h^3 \mathbf{x}^{(3)}(t_n) \\ &\quad + \left(\frac{1}{24} - \frac{b}{6}\right) h^4 \mathbf{x}^{(4)}(t_n) + O(h^5). \end{aligned} \quad (9.23)$$

要使一般光滑问题的  $h^2$  项消失, 必须且只需

$$\boxed{b = \frac{1}{2}}. \quad (9.24)$$

此时

$$\boxed{\mathbf{d}_{n+1} = -\frac{h^3}{12} \mathbf{x}^{(3)}(t_n) - \frac{h^4}{24} \mathbf{x}^{(4)}(t_n) + O(h^5)}. \quad (9.25)$$

所以局部缺陷为  $O(h^3)$ , 整体方法为二阶。

当  $b \neq \frac{1}{2}$  时, 一般只有  $\mathbf{d}_{n+1} = O(h^2)$ , 故方法为一阶。  $\square$

第 (b) 问: 稳定函数. 将  $f(t, x) = \lambda x$  代入:  $x_{n+1} = x_n + (1-b)h\lambda x_n + bh\lambda x_{n+1}$ . 令  $z = h\lambda$ . 整理得

$$(1-bz)x_{n+1} = [1 + (1-b)z]x_n. \quad (9.26)$$

因此

$$\boxed{g_b(z) = \frac{1 + (1-b)z}{1-bz}}. \quad (9.27)$$

从而

$$\boxed{x_n = g_b(h\lambda)^n x_0}. \quad (9.28)$$

$\square$

第 (c) 问: A 稳定性的充分性. 设  $z = x + iy$ ,  $x = \operatorname{Re} z \leq 0$ . 计算分母模平方与分子模平方之差:

$$\begin{aligned} &|1-bz|^2 - |1+(1-b)z|^2 \\ &= [1-2bx+b^2|z|^2] - [1+2(1-b)x+(1-b)^2|z|^2] \\ &= -2x + (2b-1)|z|^2. \end{aligned} \quad (9.29)$$

若  $b \geq \frac{1}{2}$ , 则  $-2x \geq 0$ ,  $(2b-1)|z|^2 \geq 0$ . 故  $|1+(1-b)z| \leq |1-bz|$ , 即  $|g_b(z)| \leq 1 \quad \forall \operatorname{Re} z \leq 0$ . 此外, 当  $b > 0$  时, 唯一极点  $z = \frac{1}{b}$  位于正实轴, 不在闭左半平面内. 因此  $b \geq \frac{1}{2}$  时方法 A 稳定。  $\square$

第 (c) 问: 必要性. 若  $b = 0$ , 则  $g_0(z) = 1 + z$ , 即前向 Euler 方法, 其稳定域有界, 不 A 稳定。

若  $0 < b < \frac{1}{2}$ , 取负实轴  $z = -r$ ,  $r \rightarrow +\infty$ . 则


$$g_b(-r) = \frac{1 - (1-b)r}{1-br} \rightarrow -\frac{1-b}{b}. \quad (9.30)$$

因为  $\frac{1-b}{b} > 1$ , 故对充分大的  $r$ ,  $|g_b(-r)| > 1$ . 所以  $b < 1/2$  时不 A 稳定。

综上,

$$\boxed{\text{方法 A 稳定} \iff \frac{1}{2} \leq b \leq 1}. \quad (9.31)$$

$\square$



注 9.6 (负实轴稳定区间与 L 稳定性). 若  $0 \leq b < \frac{1}{2}$ , 令  $z = -r$ , 由式 (9.29),  $|g_b(-r)| \leq 1 \iff r[2 - (1 - 2b)r] \geq 0$ . 因此负实轴稳定区间为

$$\boxed{-\frac{2}{1-2b} \leq z \leq 0}. \quad (9.32)$$

当  $b > 0$  时,  $\lim_{z \rightarrow -\infty} g_b(z) = -\frac{1-b}{b}$ . 所以在 A 稳定区间  $b \in [1/2, 1]$  内:

- $b = 1/2$ : 梯形法, A 稳定但不 L 稳定;
- $1/2 < b < 1$ : 极限模小于 1 但不为 0;
- $b = 1$ : 后向 Euler 法, L 稳定。

因此

$$\boxed{\theta \text{ 方法在该族中 L 稳定} \iff b = 1}. \quad (9.33)$$

## 9.4 补充训练题：丘赛 2025 Problem 6——刚性二维系统

### 完整题目叙述

考虑刚性常微分方程组

$$\frac{dy}{dt} = f(t, y), \quad y(0) = y_0, \quad (9.34)$$

其中

$$y = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}, \quad y_0 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \quad f(t, y) = \begin{pmatrix} -1000y_1 + 999y_2 \\ -y_2 \end{pmatrix}. \quad (9.35)$$

- 求精确解;
- 对显式 Euler 法  $y_{n+1} = y_n + hf(t_n, y_n)$ , 求绝对稳定域, 并证明当  $h > 0.002$  时数值解发散;
- 对隐式 Euler 法  $y_{n+1} = y_n + hf(t_{n+1}, y_{n+1})$ , 证明对任意  $h > 0$  无条件稳定;
- 分析梯形法  $y_{n+1} = y_n + \frac{h}{2} [f(t_n, y_n) + f(t_{n+1}, y_{n+1})]$  的稳定性。

第 (a) 问: 精确解与模态分解. 系统矩阵为


$$A = \begin{pmatrix} -1000 & 999 \\ 0 & -1 \end{pmatrix}. \quad (9.36)$$

第二个方程独立:  $y_2' = -y_2$ ,  $y_2(0) = 1$ . 所以

$$y_2(t) = e^{-t}. \quad (9.37)$$

第一个方程为  $y_1' + 1000y_1 = 999e^{-t}$ . 注意  $y_{1,p}(t) = e^{-t}$  是一个特解, 因为  $-e^{-t} = -1000e^{-t} + 999e^{-t}$ . 故  $y_1(t) = Ce^{-1000t} + e^{-t}$ . 由  $y_1(0) = 2$  得  $C = 1$ , 所以

$$\boxed{y(t) = \begin{pmatrix} e^{-1000t} + e^{-t} \\ e^{-t} \end{pmatrix}}. \quad (9.38)$$



矩阵  $A$  的两个特征值为  $\lambda_f = -1000$ ,  $\lambda_s = -1$ 。对应特征向量可取  $\mathbf{v}_f = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ,  $\mathbf{v}_s = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 。且  $\mathbf{y}_0 = \mathbf{v}_f + \mathbf{v}_s$ 。因此精确解也可写成

$$\mathbf{y}(t) = e^{-1000t}\mathbf{v}_f + e^{-t}\mathbf{v}_s. \quad (9.39)$$

快、慢时间尺度分别为  $\tau_f = 10^{-3}$ ,  $\tau_s = 1$ , 刚性比为

$$\boxed{\mathcal{S} = 1000}. \quad (9.40)$$

□

第 (b) 问: 显式 Euler 法. 显式 Euler 对标量测试方程的稳定函数为  $R_{\text{FE}}(z) = 1 + z$ 。其绝对稳定域为

$$\boxed{\mathcal{S}_{\text{FE}} = \{z \in \mathbb{C} : |1 + z| \leq 1\}}, \quad (9.41)$$

即以  $-1$  为圆心、1 为半径的闭圆盘。

对本系统,  $\mathbf{y}_{n+1} = (I + hA)\mathbf{y}_n$ 。由于  $A$  与  $I + hA$  具有相同特征向量, 两个模态的增长因子为

$$r_f^{\text{FE}} = 1 - 1000h, \quad (9.42)$$

$$r_s^{\text{FE}} = 1 - h. \quad (9.43)$$

因此

$$\boxed{\mathbf{y}_n = (1 - 1000h)^n \mathbf{v}_f + (1 - h)^n \mathbf{v}_s}. \quad (9.44)$$

即

$$\mathbf{y}_n = \begin{pmatrix} (1 - 1000h)^n + (1 - h)^n \\ (1 - h)^n \end{pmatrix}. \quad (9.45)$$

快模态稳定要求  $|1 - 1000h| \leq 1$ , 即  $0 \leq h \leq 0.002$ 。慢模态稳定要求  $|1 - h| \leq 1$ , 即  $0 \leq h \leq 2$ 。两者同时满足的条件为

$$\boxed{0 \leq h \leq 0.002}. \quad (9.46)$$

若  $h > 0.002$ , 则  $|1 - 1000h| > 1$ 。由于初值中快模态系数恰为 1,  $(1 - 1000h)^n \mathbf{v}_f$  不会消失, 并且其模随  $n \rightarrow \infty$  发散。所以

$$\boxed{h > 0.002 \implies \|\mathbf{y}_n\| \rightarrow \infty}. \quad (9.47)$$

在边界  $h = 0.002$  时,  $r_f^{\text{FE}} = -1$ , 快模态不衰减而发生等幅交替振荡。因此若要求数值解正确恢复  $\mathbf{y}_n \rightarrow \mathbf{0}$ , 则应取严格条件  $0 < h < 0.002$ 。□


第 (c) 问: 隐式 Euler 法. 隐式 Euler 对测试方程的稳定函数为

$$R_{\text{BE}}(z) = \frac{1}{1 - z}. \quad (9.48)$$

对本系统,  $(I - hA)\mathbf{y}_{n+1} = \mathbf{y}_n$ 。两个模态增长因子为

$$r_f^{\text{BE}} = \frac{1}{1 + 1000h}, \quad (9.49)$$

$$r_s^{\text{BE}} = \frac{1}{1 + h}. \quad (9.50)$$



所以

$$\mathbf{y}_n = \left( \frac{1}{1+1000h} \right)^n \mathbf{v}_f + \left( \frac{1}{1+h} \right)^n \mathbf{v}_s. \quad (9.51)$$

对任意  $h > 0$ , 均有  $0 < \frac{1}{1+1000h} < 1$ ,  $0 < \frac{1}{1+h} < 1$ 。因此两个模态均衰减到零, 方法对本问题无条件稳定。

更一般地, 令  $V = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$ ,  $A = V \begin{pmatrix} -1000 & 0 \\ 0 & -1 \end{pmatrix} V^{-1}$ 。则

$$\begin{aligned} \|(I - hA)^{-n}\|_2 &\leq \kappa_2(V) \max\{(1+1000h)^{-n}, (1+h)^{-n}\} \\ &\leq \kappa_2(V). \end{aligned} \quad (9.52)$$

稳定常数与  $n$  无关。

此外,  $\lim_{h|\lambda| \rightarrow \infty} R_{\text{BE}}(h\lambda) = 0$ , 所以后向 Euler 具有强刚性阻尼, 是 L 稳定方法。□

第 (d) 问: 梯形法. 梯形法的稳定函数为

$$R_{\text{TR}}(z) = \frac{1 + z/2}{1 - z/2}. \quad (9.53)$$

因此两个模态增长因子为

$$r_f^{\text{TR}} = \frac{1 - 500h}{1 + 500h}, \quad (9.54)$$

$$r_s^{\text{TR}} = \frac{1 - h/2}{1 + h/2}. \quad (9.55)$$

数值解为

$$\mathbf{y}_n = \left( \frac{1 - 500h}{1 + 500h} \right)^n \mathbf{v}_f + \left( \frac{1 - h/2}{1 + h/2} \right)^n \mathbf{v}_s. \quad (9.56)$$

对任意  $a > 0$ ,  $\left| \frac{1-a}{1+a} \right| < 1$ 。故对任意  $h > 0$ ,  $|r_f^{\text{TR}}| < 1$ ,  $|r_s^{\text{TR}}| < 1$ 。因此梯形法对本系统无条件稳定, 并且  $\mathbf{y}_n \rightarrow \mathbf{0}$ 。

但是当  $h \gg 10^{-3}$  时,

$$r_f^{\text{TR}} = \frac{1 - 500h}{1 + 500h} \approx -1. \quad (9.57)$$

例如取  $h = 0.1$ , 则  $r_f^{\text{TR}} = -\frac{49}{51} \approx -0.9608$ , 而精确快模态在一个时间步内的衰减因子为  $e^{-1000h} = e^{-100} \approx 3.72 \times 10^{-44}$ 。因此梯形法虽然稳定, 却把本应几乎立即消失的快模态转化为缓慢衰减的交替振荡。

这是 A 稳定但不 L 稳定的典型现象。□

注 9.7 (稳定性与精度的区别). 在  $t \gg 10^{-3}$  后, 精确解几乎只剩慢模态  $e^{-t} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 。从慢模态精度看, 步长  $h = 10^{-2}$  甚至更大可能仍有意义; 但显式 Euler 仍被快特征值强制限制为  $h < 2 \times 10^{-3}$ 。这正是刚性问题的计算本质。

---


#### Algorithm 30 线性刚性系统的方法选择诊断

---

**Input:** 线性系统  $\mathbf{y}' = A\mathbf{y} + \mathbf{g}(t)$ ; 候选步长  $h$ ; 候选方法稳定函数  $R$

**Output:** 稳定性与刚性阻尼诊断

- 1: 估计谱或数值域中相关特征值  $\lambda_j$
- 2: **for** 每个相关模态  $\lambda_j$  **do**



```

3:   计算  $z_j = h\lambda_j$ 
4:   检查  $|R(z_j)| \leq 1$ 
5:   若  $|z_j| \gg 1$ , 检查  $|R(z_j)|$  是否显著小于 1
6: end for
7: if 精度允许的  $h$  远大于显式稳定步长 then
8:   标记为刚性计算区间
9: end if
10: if A 稳定方法对大负  $z$  有  $|R(z)| \approx 1$  then
11:   警告“稳定但刚性阻尼不足; 可能出现交替振荡”
12: end if
13: Stopping criterion: 完成全部相关模态和非正规性检查
14: Complexity: 小型稠密矩阵可直接求谱  $O(d^3)$ ; 大型问题通常只估计最右/最左特征值或使用
    Jacobian-向量积

```

## 9.5 自适应步长与局部误差控制

### 9.5.1 知识点八：自适应步长的基本目标

【重要性等级】 **A 级**。固定步长无法同时高效处理：

- 初始层；
- 快、慢变化交替；
- 解的局部尖峰；
- 事件附近的高曲率；
- 长时间积分中不断变化的误差尺度。

自适应算法的目标是：在满足局部误差容差的前提下，尽可能增大时间步，并在误差估计失败时拒绝当前步。

必须区分：

- 误差估计器：根据一次或多次离散计算估计局部误差；
- 误差控制器：根据误差估计决定接受、拒绝和下一步步长；
- 稳定性控制：防止步长超出绝对稳定域；
- 非线性求解控制：保证隐式阶段求解误差不污染时间离散误差。

### 9.5.2 知识点九：嵌入式 Runge-Kutta 对

一个嵌入式 RK 对共享同一组阶段  $K_1, \dots, K_s$ , 但使用两组权重  $b, \hat{b}$ 。得到两个近似：

$$u_{n+1}^{[p]} = u_n + h \sum_{i=1}^s b_i K_i, \quad (9.58)$$

$$\hat{u}_{n+1}^{[\hat{p}]} = u_n + h \sum_{i=1}^s \hat{b}_i K_i, \quad (9.59)$$



其中通常  $p = \hat{p} + 1$ 。误差估计为

$$\mathbf{e}_{n+1}^{\text{est}} = \mathbf{u}_{n+1}^{[p]} - \hat{\mathbf{u}}_{n+1}^{[\hat{p}]} = h \sum_{i=1}^s (b_i - \hat{b}_i) \mathbf{K}_i. \quad (9.60)$$

若高、低阶方法的局部误差分别为  $O(h^{p+1})$ ,  $O(h^{\hat{p}+1})$ , 则两者差通常满足

$$\mathbf{e}_{n+1}^{\text{est}} = O(h^q), \quad q = \hat{p} + 1. \quad (9.61)$$

对常见  $p/(p-1)$  嵌入对,  $q = p$ 。

典型方法包括:

- Bogacki–Shampine RK23;
- Fehlberg RK45;
- Dormand–Prince 5(4);
- 嵌入式 SDIRK 或 Rosenbrock 方法。

### 9.5.3 知识点十: 加权误差范数

对  $d$  维状态, 定义每个分量的允许尺度

$$\text{sc}_i = \text{atol}_i + \text{rtol}_i \max \left\{ |u_{n,i}|, |u_{n+1,i}^{[p]}| \right\}. \quad (9.62)$$

常用加权均方根误差为

$$\text{err} = \left[ \frac{1}{d} \sum_{i=1}^d \left( \frac{e_{n+1,i}^{\text{est}}}{\text{sc}_i} \right)^2 \right]^{1/2}. \quad (9.63)$$

也可使用加权无穷范数  $\text{err}_\infty = \max_i \frac{|e_{n+1,i}^{\text{est}}|}{\text{sc}_i}$ 。

采用归一化后:

- 若  $\text{err} \leq 1$ , 接受该步;
- 若  $\text{err} > 1$ , 拒绝该步并减小步长。

#### 易错点与反例


只使用绝对误差或只使用相对误差都可能失败:

- 当解接近零时, 纯相对误差尺度退化;
- 当解幅值很大时, 纯绝对误差可能过于严格;
- 不同物理量纲不同时, 必须按分量设置尺度。

### 9.5.4 知识点十一: 步长更新公式

若误差估计满足  $\text{err} \approx Ch^q$ , 希望下一步误差约为 1, 则理想步长满足  $1 \approx \text{err} \left( \frac{h_{\text{new}}}{h} \right)^q$ 。所以

$$h_{\text{new}} = h \text{err}^{-1/q}. \quad (9.64)$$



实际算法加入安全因子和上下界：

$$h_{\text{new}} = h \operatorname{clip}(f_{\min}, f_{\max}, s_{\text{safe}} \operatorname{err}^{-1/q}), \quad (9.65)$$

其中通常  $0 < s_{\text{safe}} < 1$ ,  $0 < f_{\min} < 1 < f_{\max}$ 。

若  $\operatorname{err} = 0$ , 则不应直接计算  $0^{-1/q}$ ; 应把增长因子设为  $f_{\max}$ 。

更平滑的 PI 控制器可同时利用当前和上一步误差：

$$h_{n+1} = h_n \operatorname{clip}(f_{\min}, f_{\max}, s_{\text{safe}} \operatorname{err}_n^{-\alpha} \operatorname{err}_{n-1}^{\beta}), \quad (9.66)$$

其中  $\alpha, \beta > 0$  按误差估计阶数选择。PI 控制可减小步长的剧烈振荡。

---

#### Algorithm 31 嵌入式 Runge–Kutta 自适应步长算法

---

**Input:**  $f$ ;  $(t_0, \mathbf{u}_0)$ ; 终止时间  $T$ ; 初始步长  $h$ ; atol; rtol; 嵌入对阶数  $p, \hat{p}$ ; 安全因子及步长上下界

**Output:** 自适应网格解

```

1: Initialization:  $t \leftarrow t_0$ ,  $\mathbf{u} \leftarrow \mathbf{u}_0$ ,  $q \leftarrow \hat{p} + 1$ 
2: while  $t < T$  do
3:    $h \leftarrow \min\{h, T - t\}$ 
4:   用共享阶段计算  $\mathbf{u}_{\text{high}}$ ,  $\mathbf{u}_{\text{low}}$ 
5:    $\mathbf{e}^{\text{est}} \leftarrow \mathbf{u}_{\text{high}} - \mathbf{u}_{\text{low}}$ 
6:   由式 (9.62) and (9.63) 计算  $\operatorname{err}$ 
7:   if  $\operatorname{err} \leq 1$  then
8:     接受:  $t \leftarrow t + h$ ,  $\mathbf{u} \leftarrow \mathbf{u}_{\text{high}}$ 
9:     保存解、步长及必要的稠密输出信息
10:  else
11:    拒绝该步;  $t, \mathbf{u}$  保持不变
12:  end if
13:  if  $\operatorname{err} = 0$  then
14:     $\text{fac} \leftarrow f_{\max}$ 
15:  else
16:     $\text{fac} \leftarrow \operatorname{clip}(f_{\min}, f_{\max}, s_{\text{safe}} \operatorname{err}^{-1/q})$ 
17:  end if
18:   $h \leftarrow h \text{ fac}$ 
19:  if  $h < h_{\min}$  then
20:    报告“步长低于可接受下限”并终止
21:  end if
22: end while
23: Stopping criterion: 到达  $T$ , 或检测到步长下溢、函数失败、事件终止
24: Complexity: 每次尝试通常需  $s$  次函数值; 拒绝步的全部函数计算会被浪费; FSAL 方法可在连续接受步之间复用一次函数值

```

---

#### 9.5.5 知识点十二：步长加倍

对  $p$  阶单步法，分别计算：

- 一个长度为  $h$  的整步结果  $U_h$ ;
- 两个长度为  $h/2$  的半步结果  $U_{h/2, h/2}$ 。





若局部误差具有展开  $\mathbf{y}(t+h) - \mathbf{U}_h = Ch^{p+1} + O(h^{p+2})$ , 则两半步结果满足  $\mathbf{y}(t+h) - \mathbf{U}_{h/2,h/2} = \frac{C}{2^p} h^{p+1} + O(h^{p+2})$ 。因此两半步结果的误差可估计为

$$\mathbf{y}(t+h) - \mathbf{U}_{h/2,h/2} \approx \frac{\mathbf{U}_{h/2,h/2} - \mathbf{U}_h}{2^p - 1}. \quad (9.67)$$

还可作 Richardson 外推:

$$\mathbf{U}_{\text{ext}} = \mathbf{U}_{h/2,h/2} + \frac{\mathbf{U}_{h/2,h/2} - \mathbf{U}_h}{2^p - 1}. \quad (9.68)$$

在误差展开有效时, 外推解通常提高一阶。

#### 【失败情形】

- 解或右端项不光滑, 误差幂展开失效;
- 步长跨越事件、间断或切换点;
- 刚性导致显式误差估计器先因稳定性失败;
- 高、低阶误差主项偶然抵消, 误差被低估;
- 隐式阶段未充分求解, 估计器主要测到代数求解误差;
- 长时间混沌问题中, 局部误差受控不等于轨道长期准确;
- 极小步长下舍入误差主导。

## 9.6 隐式时间步的非线性求解与容差协调

### 9.6.1 知识点十三: $\theta$ 方法的非线性方程

对

$$\mathbf{u}_{n+1} = \mathbf{u}_n + h[(1-\theta)\mathbf{f}(t_n, \mathbf{u}_n) + \theta\mathbf{f}(t_{n+1}, \mathbf{u}_{n+1})], \quad (9.69)$$

定义

$$\mathbf{G}_n(\mathbf{v}) = \mathbf{v} - \mathbf{u}_n - h[(1-\theta)\mathbf{f}(t_n, \mathbf{u}_n) + \theta\mathbf{f}(t_{n+1}, \mathbf{v})]. \quad (9.70)$$

每一步要求

$$\mathbf{G}_n(\mathbf{v}) = \mathbf{0}. \quad (9.71)$$

其 Jacobian 为

$$J_{\mathbf{G}_n}(\mathbf{v}) = I - h\theta J_{\mathbf{f}}(t_{n+1}, \mathbf{v}). \quad (9.72)$$

Newton 迭代为

$$[I - h\theta J_{\mathbf{f}}(t_{n+1}, \mathbf{v}^{(\ell)})] \Delta \mathbf{v}^{(\ell)} = -\mathbf{G}_n(\mathbf{v}^{(\ell)}), \quad (9.73)$$

$$\mathbf{v}^{(\ell+1)} = \mathbf{v}^{(\ell)} + \Delta \mathbf{v}^{(\ell)}.$$

常用预测初值为

$$\mathbf{v}^{(0)} = \mathbf{u}_n + h\mathbf{f}(t_n, \mathbf{u}_n), \quad (9.74)$$

或使用历史解外推。

---

#### Algorithm 32 带拒步机制的隐式 $\theta$ 方法

---

**Input:** 当前  $(t_n, \mathbf{u}_n)$ ; 步长  $h$ ; 参数  $\theta$ ; Newton 容差; 最大 Newton 次数; 时间误差估计器

**Output:** 接受的  $u_{n+1}$  或拒步信号

```

1: Initialization:  $v^{(0)} \leftarrow u_n + h f(t_n, u_n)$ 
2: for  $\ell = 0, 1, \dots, \ell_{\max} - 1$  do
3:   计算  $G_n(v^{(\ell)})$ 
4:   组装或更新  $I - h\theta J_f(t_{n+1}, v^{(\ell)})$ 
5:   求解 Newton 线性系统式 (9.73)
6:    $v^{(\ell+1)} \leftarrow v^{(\ell)} + \Delta v^{(\ell)}$ 
7:   if 加权步长与残差均满足 Newton 停止准则 then
8:      $u_{n+1} \leftarrow v^{(\ell+1)}$ 
9:     转入时间误差估计和接受/拒绝判断
10:   return
11: end if
12: end for
13: 报告 Newton 失败
14: 拒绝当前时间步并减小  $h$ 
15: Stopping criterion: Newton 收敛且时间误差满足容差
16: Complexity: 稠密  $d$  维: 每次新 Jacobian 分解  $O(d^3)$ 、回代  $O(d^2)$ 、存储  $O(d^2)$ ; 稀疏或矩阵无
    关 Newton-Krylov 成本取决于预处理

```

### 9.6.2 知识点十四：简化 Newton、Jacobian 复用与线性求解

若每次 Newton 迭代都更新 Jacobian，局部收敛快，但组装和分解成本高。可采用简化 Newton：

$$[I - h\theta J_f(t_n, u_n)] \Delta v^{(\ell)} = -G_n(v^{(\ell)}). \quad (9.75)$$

这样可在同一时间步内复用一次矩阵分解。

若：

- 步长不变；
- Jacobian 变化缓慢；
- 系统矩阵固定；

还可跨多个时间步复用分解。

代价是：

- Newton 通常由二次收敛退化为线性收敛；
- Jacobian 过旧时可能停滞或发散；
- 步长改变后矩阵  $I - h\theta J$  也随之改变；
- 刚性很强时，预处理质量决定 Krylov 效率。

**【大型稀疏问题】** 对大规模系统，常使用 Jacobian-向量积

$$J_f(v)p \approx \frac{f(v + \varepsilon p) - f(v)}{\varepsilon}, \quad (9.76)$$

结合 GMRES 等 Krylov 方法求解 Newton 线性系统。这称为 Jacobian-free Newton-Krylov 方法。

有限差分参数  $\varepsilon$  需平衡截断与舍入误差；预处理器仍通常需要利用问题结构构造。



### 9.6.3 知识点十五：非线性求解误差必须小于时间离散误差

设精确离散解  $\mathbf{u}_{n+1}^*$  满足  $\mathbf{G}_n(\mathbf{u}_{n+1}^*) = \mathbf{0}$ ，实际只得到近似解  $\tilde{\mathbf{u}}_{n+1}$ ， $\mathbf{r}_{n+1} = \mathbf{G}_n(\tilde{\mathbf{u}}_{n+1}) \neq \mathbf{0}$ 。若  $J_{\mathbf{G}_n}(\mathbf{u}_{n+1}^*)$  非奇异，则局部有

$$\tilde{\mathbf{u}}_{n+1} - \mathbf{u}_{n+1}^* = J_{\mathbf{G}_n}(\mathbf{u}_{n+1}^*)^{-1} \mathbf{r}_{n+1} + O(\|\mathbf{r}_{n+1}\|^2). \quad (9.77)$$

若时间方法整体阶为  $p$ ，其每步局部缺陷为  $O(h^{p+1})$ 。为了不降低整体阶，一般应使代数求解误差满足

$$\|J_{\mathbf{G}_n}^{-1} \mathbf{r}_{n+1}\| = O(h^{p+1}). \quad (9.78)$$

在自适应算法中，更实用的要求是：非线性求解误差只占局部误差预算的一小部分，例如  $\text{err}_{\text{Newton}} \leq \eta_{\text{alg}} \text{err}_{\text{time}}$ ， $0 < \eta_{\text{alg}} \ll 1$ 。

#### 易错点与反例

**Newton** 迭代“收敛”不等于时间步“足够准确”。

若 Newton 停止过早，则实际离散格式已经被改变；代数误差可能：

- 降低时间方法阶数；
- 污染嵌入式误差估计；
- 造成虚假的步长接受；
- 破坏守恒或几何结构；
- 在长时间积分中累积。

### 9.6.4 知识点十六：隐式方法失败诊断

出现以下信号时，应拒绝当前时间步并减小  $h$ ：

- Newton 残差不下降；
- Newton 修正量增长；
- 线搜索连续失败；
- Jacobian 近奇异；
- 线性求解器达到最大迭代次数；
- 预条件器失效；
- 状态越出定义域；
- 函数值出现 NaN 或 Inf；
- Newton 迭代次数显著高于通常水平。

若连续多次 Newton 失败，即使局部误差估计较小，也不能接受该步。



## 9.7 两点边值问题：打靶法、差分法与配点法

### 9.7.1 知识点十七：一般两点边值问题

【重要性等级】 **B 级**。六套正式资格考试未以 ODE 两点边值问题独立设题，但该主题由课程培训资料列为 ODE 扩展，并在丘赛 2024 Problem 4 中以变系数二阶边值问题直接出现。

一般一阶系统边值问题写为

$$y'(x) = f(x, y(x)), \quad a < x < b, \quad (9.79)$$

配以

$$B(y(a), y(b)) = 0. \quad (9.80)$$

与初值问题不同，边值问题可能：

- 无解；
- 有多个解；
- 线性化算子奇异；
- 对边界数据高度敏感；
- 含有边界层；
- 作为初值问题向前积分时极不稳定。

因此，初值问题的 Lipschitz 唯一性不能直接代替边值问题的可解性分析。

### 9.7.2 知识点十八：标量打靶法

考虑二阶边值问题

$$y'' = F(x, y, y'), \quad y(a) = \alpha, \quad y(b) = \beta. \quad (9.81)$$

令未知初始斜率为  $s = y'(a)$ 。对每个  $s$  求解初值问题

$$\begin{cases} y'' = F(x, y, y'), \\ y(a) = \alpha, \\ y'(a) = s. \end{cases} \quad (9.82)$$

定义打靶残差

$$R(s) = y(b; s) - \beta. \quad (9.83)$$

边值问题转化为标量非线性方程  $R(s) = 0$ 。

Newton 打靶法为

$$s_{k+1} = s_k - \frac{R(s_k)}{R'(s_k)}. \quad (9.84)$$

为计算  $R'(s)$ ，定义灵敏度  $z(x) = \frac{\partial y(x; s)}{\partial s}$ 。对原方程关于  $s$  求导，得到变分方程

$$z'' = F_y(x, y, y')z + F_{y'}(x, y, y')z', \quad (9.85)$$

初值为

$$z(a) = 0, \quad z'(a) = 1. \quad (9.86)$$



于是

$$R'(s) = z(b). \quad (9.87)$$

---

**Algorithm 33** Newton 打靶法
 

---

**Input:** 边值问题式 (9.81); 初始斜率猜测  $s_0$ ; IVP 求解器; 边界残差容差

**Output:** 边值问题近似解

```

1: for  $k = 0, 1, \dots$  do
2:   联立积分状态方程与灵敏度方程
3:   计算  $R_k = y(b; s_k) - \beta$ ,  $R'_k = z(b)$ 
4:   if  $|R_k|$  满足边界容差 then
5:     返回轨道  $y(x; s_k)$ 
6:   end if
7:   if  $|R'_k|$  过小 then
8:     报告“打靶 Jacobian 近奇异”并终止
9:   end if
10:   $s_{k+1} \leftarrow s_k - \frac{R_k}{R'_k}$ 
11: end for
12: Stopping criterion: 终端边界残差满足容差
13: Complexity: 每次 Newton 迭代需积分状态和灵敏度系统; 标量二阶问题相当于一个四维一阶 IVP

```

---

**基础例题：线性打靶法**

求解

$$y'' + y = 0, \quad y(0) = 0, \quad y\left(\frac{\pi}{2}\right) = 1. \quad (9.88)$$

令  $y'(0) = s$ 。相应初值问题解为  $y(x; s) = s \sin x$ 。故  $R(s) = y\left(\frac{\pi}{2}; s\right) - 1 = s - 1$ 。灵敏度方程为  $z'' + z = 0$ ,  $z(0) = 0$ ,  $z'(0) = 1$ , 所以  $z(x) = \sin x$ ,  $R'(s) = z(\pi/2) = 1$ 。Newton 更新为  $s_{k+1} = s_k - (s_k - 1) = 1$ 。从任意初始斜率出发, 一步得到  $s^* = 1$ , 最终解为

$$\boxed{y(x) = \sin x}. \quad (9.89)$$

### 9.7.3 知识点十九：打靶法失败与多重打靶

单重打靶法可能失败于：

- 初值问题沿区间存在指数增长模态；
- $R'(s)$  极大或极小；
- 边值问题有多个分支；
- 初始猜测进入错误吸引域；
- 问题刚性；
- 边界层造成所需斜率极端敏感。

多重打靶法把  $[a, b]$  划分为多个子区间, 每个子区间独立积分, 并把各子区间初值作为未知量, 再施加：



- 子区间连接连续条件;
- 原始边界条件。

它增加了非线性系统维数, 却显著降低长区间初值传播的病态性。

#### 9.7.4 知识点二十: 有限差分与配点法

对线性问题

$$-y'' + q(x)y = r(x), \quad y(a) = \alpha, \quad y(b) = \beta, \quad (9.90)$$

在均匀网格上使用中心差分:

$$-\frac{U_{i+1} - 2U_i + U_{i-1}}{h^2} + q_i U_i = r_i. \quad (9.91)$$

若精确解足够光滑, 局部截断误差为  $O(h^2)$ 。若离散算子稳定, 例如形成 M 矩阵或满足离散最大值原理, 则整体误差为  $O(h^2)$ 。

配点法选取有限维函数空间  $V_h$ , 求  $y_h \in V_h$  满足边界条件, 并在配点  $x_{i,j}$  处强制

$$y'_h(x_{i,j}) = f(x_{i,j}, y_h(x_{i,j})). \quad (9.92)$$

配点法可获得高阶精度, 但需解耦合代数系统; 其收敛性依赖于连续边值问题线性化的可逆性和配点空间逼近性质。

### 9.8 补充训练题: 丘赛 2024 Problem 4——保守有限差分与特征值圆盘

#### 完整题目叙述

考虑边值问题

$$-\frac{d}{dx} \left( a(x) \frac{du}{dx} \right) = f(x), \quad 0 < x < 1, \quad (9.93)$$

$$u(0) = u(1) = 0, \quad (9.94)$$

其中  $a(x)$  在  $[0, 1]$  上有界、可微, 并满足

$$a(x) > \delta > 0. \quad (9.95)$$

假设  $a(x)$  可计算, 但  $a'(x)$  的显式表达式不可用。

取均匀网格  $x_i = ih$ ,  $i = 0, \dots, n$ ,  $h = \frac{1}{n}$ 。

(a) 构造一个  $O(h^2)$  的有限差分离散。施加边界条件后, 所得线性系统系数矩阵应为  $(n-1) \times (n-1)$  三对角矩阵。写出完整推导和矩阵元素。

(b) 利用题目给出的全部信息, 求一个尽可能小的复平面圆盘, 保证包含该系数矩阵的全部特征值。

第 (a) 问: 保守通量离散. 不能把算子直接展开为  $-a(x)u''(x) - a'(x)u'(x)$ , 因为题目明确说明  $a'(x)$  的显式表达式不可用。应保留散度形式并离散通量。

定义半节点  $x_{i+1/2} = (i + \frac{1}{2})h$ , 以及

$$a_{i+1/2} = a(x_{i+1/2}). \quad (9.96)$$

定义离散通量

$$F_{i+1/2} = a_{i+1/2} \frac{U_{i+1} - U_i}{h}. \quad (9.97)$$

在内部节点  $x_i$  处离散  $-(au')'$  为

$$-\frac{F_{i+1/2} - F_{i-1/2}}{h} = f_i, \quad f_i = f(x_i). \quad (9.98)$$

即

$$\boxed{-\frac{1}{h^2} [a_{i+1/2}(U_{i+1} - U_i) - a_{i-1/2}(U_i - U_{i-1})] = f_i}, \quad (9.99)$$

其中  $i = 1, \dots, n-1$ ,  $U_0 = U_n = 0$ 。

若  $a$  只能在整数节点求值，也可取

$$a_{i+1/2} = \frac{a_i + a_{i+1}}{2}. \quad (9.100)$$

在  $a$  足够光滑时， $\frac{a_i + a_{i+1}}{2} = a(x_{i+1/2}) + O(h^2)$ ，仍保持二阶精度。  $\square$

第 (a) 问：截断误差。为严格得到二阶局部截断误差，除题面给出的正性与可微性外，还需假设  $a$  和精确解具有足够高的局部光滑性。例如可取  $a \in C^3[0, 1]$ ,  $u \in C^5[0, 1]$ 。题目中“ $a'$  表达式不可用”是算法信息，不表示数学正则性只能为  $C^1$ 。

在半节点处，

$$\frac{u(x_{i+1}) - u(x_i)}{h} = u'(x_{i+1/2}) + \frac{h^2}{24} u^{(3)}(x_{i+1/2}) + O(h^4). \quad (9.101)$$

因此

$$\begin{aligned} a_{i+1/2} \frac{u(x_{i+1}) - u(x_i)}{h} &= (au')(x_{i+1/2}) \\ &\quad + \frac{h^2}{24} a(x_{i+1/2}) u^{(3)}(x_{i+1/2}) + O(h^4). \end{aligned} \quad (9.102)$$

对两个半节点通量作中心差分，利用

$$\frac{q(x_i + h/2) - q(x_i - h/2)}{h} = q'(x_i) + \frac{h^2}{24} q^{(3)}(x_i) + O(h^4), \quad (9.103)$$

得到

$$-\frac{F_{i+1/2} - F_{i-1/2}}{h} = -(au')'(x_i) + O(h^2). \quad (9.104)$$

所以格式为二阶相容。  $\square$

第 (a) 问：线性系统。令  $\mathbf{U} = (U_1, \dots, U_{n-1})^T$ ,  $\mathbf{f}_h = (f_1, \dots, f_{n-1})^T$ 。则

$$A_h \mathbf{U} = \mathbf{f}_h, \quad (9.105)$$

其中  $A_h \in \mathbb{R}^{(n-1) \times (n-1)}$  为对称三对角矩阵，其元素为

$$(A_h)_{ii} = \frac{a_{i-1/2} + a_{i+1/2}}{h^2}, \quad 1 \leq i \leq n-1, \quad (9.106)$$

$$(A_h)_{i,i+1} = -\frac{a_{i+1/2}}{h^2}, \quad 1 \leq i \leq n-2, \quad (9.107)$$

$$(A_h)_{i,i-1} = -\frac{a_{i-1/2}}{h^2}, \quad 2 \leq i \leq n-1. \quad (9.108)$$

即

$$A_h = \frac{1}{h^2} \begin{pmatrix} a_{1/2} + a_{3/2} & -a_{3/2} & & & \\ -a_{3/2} & a_{3/2} + a_{5/2} & -a_{5/2} & & \\ & \ddots & \ddots & \ddots & \\ & & & -a_{n-3/2} & a_{n-3/2} + a_{n-1/2} \end{pmatrix}. \quad (9.109)$$

$\square$



第 (a) 问: 对称正定性. 对任意  $\mathbf{v} = (v_1, \dots, v_{n-1})^\top$ , 补充  $v_0 = v_n = 0$ . 直接计算:

$$\mathbf{v}^\top A_h \mathbf{v} = \frac{1}{h^2} \sum_{i=0}^{n-1} a_{i+1/2} (v_{i+1} - v_i)^2. \quad (9.110)$$

由于  $a_{i+1/2} > \delta > 0$ , 且非零  $\mathbf{v}$  不可能使所有差  $v_{i+1} - v_i$  同时为零, 故  $\mathbf{v}^\top A_h \mathbf{v} > 0 \quad \forall \mathbf{v} \neq \mathbf{0}$ . 所以  $A_h$  为对称正定矩阵, 线性系统存在唯一解。□

第 (b) 问: 特征值实区间. 定义

$$a_{\min} = \min_{x \in [0,1]} a(x), \quad a_{\max} = \max_{x \in [0,1]} a(x). \quad (9.111)$$

由连续性和正性,  $a_{\min} > \delta > 0$ .

令标准 Dirichlet 离散负 Laplacian 为

$$L_h = \frac{1}{h^2} \text{tridiag}(-1, 2, -1) \in \mathbb{R}^{(n-1) \times (n-1)}. \quad (9.112)$$

由能量恒等式,

$$a_{\min} \mathbf{v}^\top L_h \mathbf{v} \leq \mathbf{v}^\top A_h \mathbf{v} \leq a_{\max} \mathbf{v}^\top L_h \mathbf{v}. \quad (9.113)$$

即 Loewner 序意义下

$$a_{\min} L_h \preceq A_h \preceq a_{\max} L_h. \quad (9.114)$$

$L_h$  的特征值为

$$\lambda_j(L_h) = \frac{4}{h^2} \sin^2 \left( \frac{j\pi}{2n} \right), \quad j = 1, \dots, n-1. \quad (9.115)$$

故

$$\lambda_{\min}(L_h) = \frac{4}{h^2} \sin^2 \left( \frac{\pi}{2n} \right), \quad (9.116)$$

$$\lambda_{\max}(L_h) = \frac{4}{h^2} \cos^2 \left( \frac{\pi}{2n} \right). \quad (9.117)$$

由 Rayleigh 商及极小极大原理,  $A_h$  的每个特征值均为实正数, 并满足

$$\ell_h \leq \lambda(A_h) \leq u_h, \quad (9.118)$$

其中

$$\ell_h = \frac{4a_{\min}}{h^2} \sin^2 \left( \frac{\pi}{2n} \right), \quad (9.119)$$

$$u_h = \frac{4a_{\max}}{h^2} \cos^2 \left( \frac{\pi}{2n} \right). \quad (9.120)$$

若只允许使用题面给定的下界  $\delta$ , 可将  $a_{\min}$  替换为  $\delta$ , 得到略弱但仍保证成立的区间。□

第 (b) 问: 包含全部特征值的圆盘. 由于全部特征值位于实区间  $[\ell_h, u_h]$ , 包含该区间的最小闭圆盘以区间中点为圆心, 以半长度为半径. 因此可取


$$c_h = \frac{\ell_h + u_h}{2}, \quad r_h = \frac{u_h - \ell_h}{2}. \quad (9.121)$$

所求圆盘为

$$\mathcal{D}_h = \{z \in \mathbb{C} : |z - c_h| \leq r_h\}. \quad (9.122)$$

该圆盘保证包含  $A_h$  全部特征值。

若线性系统在实现中整体乘以  $h^2$ , 则新的矩阵为  $h^2 A_h$ , 相应圆心和半径应同时乘以  $h^2$ 。□



注 9.8 (条件数与复杂度). 由上述界,

$$\begin{aligned}\kappa_2(A_h) &= \frac{\lambda_{\max}(A_h)}{\lambda_{\min}(A_h)} \\ &\leq \frac{a_{\max}}{a_{\min}} \cot^2\left(\frac{\pi}{2n}\right) = O\left(\frac{a_{\max}}{a_{\min}} h^{-2}\right).\end{aligned}\quad (9.123)$$

系数矩阵为对称正定三对角矩阵:

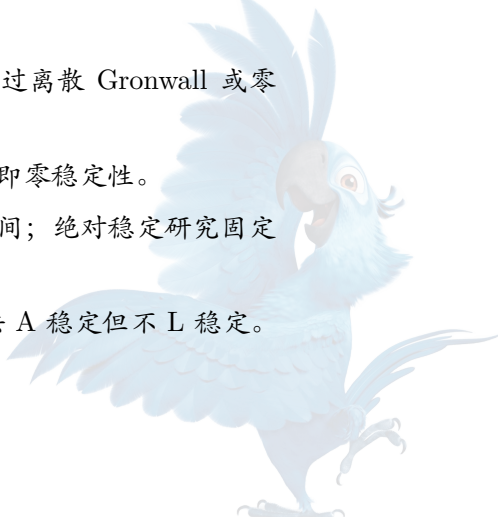
- Thomas 算法或带状 Cholesky 分解的运算复杂度为  $O(n)$ ;
- 存储复杂度为  $O(n)$ ;
- 若需要多次求解同一矩阵不同右端项, 可复用分解;
- 大规模高维推广中可使用 CG 和多重网格预处理。

#### 易错点与反例

1. 若直接展开为  $-au'' - a'u'$ , 便违反题目“不提供  $a'$ ”的算法条件;
2. 只用 Gershgorin 得到  $0 \leq \lambda \leq 4a_{\max}/h^2$  虽然正确但没有充分利用正定性和下界信息;
3. 截断误差二阶需要额外光滑性, 不能由“ $a$  可微”单独推出全部高阶 Taylor 余项;
4. 矩阵是否含  $h^{-2}$  取决于线性系统缩放, 圆盘必须与缩放一致;
5. 丘赛题不得标记为博士资格考试题。

## 9.9 模块二易错点与易混概念

| 错误说法或错误做法                          | 正确处理                                                             |
|------------------------------------|------------------------------------------------------------------|
| Newton 法总是二次收敛。                    | 二次收敛是简单根附近的局部结论; 需要非退化导数、充分光滑性和足够接近的初值。                          |
| 简单根和重根使用同一误差公式。                    | 重根使普通 Newton 法通常退化为线性收敛, 因子为 $(m-1)/m$ 。                         |
| 固定点方程的不同改写等价, 因此收敛性相同。             | 零点集合可能相同, 但迭代函数的导数、压缩常数和吸引域不同。                                   |
| 割线法是二次收敛。                          | 一般阶为 $(1+\sqrt{5})/2$ 。                                          |
| 拟 Newton 就是有限差分 Jacobian。          | 有限差分重新采样各坐标方向; Broyden 用历史割线条件作低秩更新。                             |
| 局部截断误差 $O(h^{p+1})$ 便自动得到整体 $p$ 阶。 | 必须再证明误差传播稳定, 并通过离散 Gronwall 或零稳定性累积局部误差。                         |
| 相容性自动推出多步法收敛。                      | 线性多步法还必须满足根条件, 即零稳定性。                                            |
| 零稳定性与绝对稳定性相同。                      | 零稳定研究 $h \rightarrow 0$ 、固定时间区间; 绝对稳定研究固定 $z = h\lambda$ 下的长期行为。 |
| A 稳定等于 L 稳定。                       | L 稳定还要求 $R(z) \rightarrow 0$ ; 梯形法 A 稳定但不 L 稳定。                  |



| 错误说法或错误做法                   | 正确处理                                        |
|-----------------------------|---------------------------------------------|
| 稳定域大意味着误差一定小。               | 稳定性只防止数值放大失控，不能替代精度估计。                      |
| 隐式方法可以直接写出 $u_{n+1}$ 。      | 非线性问题每一步需要 Newton、拟 Newton 或固定点求解，并需设置内层容差。 |
| 隐式方法无条件稳定，所以 Newton 也无条件收敛。 | 时间离散稳定性与非线性代数求解器收敛性是不同问题。                   |
| 刚性意味着解始终快速变化。               | 刚性解在初始层后可能很慢，但显式稳定步长仍受隐藏快模态限制。              |
| 只检查系统中最慢特征值。                | 稳定步长通常由最负或模最大的快特征值决定。                       |
| 只看矩阵特征值即可判断所有稳定性。           | 非正规系统还可能因特征向量病态和伪谱产生暂态增长。                   |
| 梯形法无条件稳定，因此特别适合任意刚性。        | 它不 L 稳定；很刚时可产生接近 $-1$ 的交替振荡。                |
| 多步法不需要起步值。                  | $k$ 步法需要 $k$ 个初始网格值，起步误差可能决定最终整体阶。          |
| 根条件只要求所有根模不超过 1。            | 单位圆上的根还必须为单根。                               |
| 自适应步长只需比较相邻两步差。             | 必须使用有理论阶数的误差估计器，并进行绝对/相对容差缩放。               |
| 误差估计满足容差便可接受隐式步。            | 还必须确保 Newton 和线性求解器已收敛，代数误差小于时间误差预算。        |
| 打靶法总能把边值问题转化为稳定初值问题。        | 不稳定模态、边界层或多解会使打靶残差严重病态；必要时使用多重打靶、差分或配点。     |
| 边值差分只需构造内部格式。               | 必须同时写明边界离散、消元、矩阵结构、稳定性和整体误差。                |



## 第三部分

### 数值线性代数



# 第十章 矩阵范数、条件数、扰动、残差、后向误差与矩阵分析基础

## 10.1 矩阵空间、复内积、酉变换与 Schur 分解

### 10.1.1 知识点一：对象空间与统一符号

【重要性等级】 **S 级**。矩阵分析中的大量错误来自：

- 把转置  $A^T$  与共轭转置  $A^H$  混用；
- 把相似、酉相似和合同混为一谈；
- 对一般矩阵误用 Hermitian 矩阵的变分结论；
- 把特征值绝对值与奇异值混为一谈。

本文使用  $\mathbb{F} \in \{\mathbb{R}, \mathbb{C}\}$ 。对  $\mathbf{x}, \mathbf{y} \in \mathbb{C}^n$ ，重申复内积约定

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^H \mathbf{y}. \quad (10.1)$$

因此内积对第一变量共轭线性，对第二变量线性。

矩阵  $A \in \mathbb{C}^{m \times n}$  的伴随矩阵为  $A^H = \overline{A}^T$ 。在实数情形， $A^H = A^T$ 。

定义 10.1 (酉矩阵与正交矩阵)。若

$$Q^H Q = Q Q^H = I, \quad (10.2)$$

则称  $Q$  为酉矩阵。

若  $Q$  为实矩阵，则称为正交矩阵。酉矩阵满足

$$Q^{-1} = Q^H. \quad (10.3)$$


酉变换保持 Euclidean 内积和二范数：

$$\langle Q\mathbf{x}, Q\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle, \quad (10.4)$$

$$\|Q\mathbf{x}\|_2 = \|\mathbf{x}\|_2. \quad (10.5)$$

定义 10.2 (相似、酉相似与合同)。设  $A, B \in \mathbb{C}^{n \times n}$ 。

1. 若存在非奇异  $S$  使  $B = S^{-1}AS$ ，则称  $A$  与  $B$  相似；
2. 若存在酉矩阵  $Q$  使  $B = Q^H A Q$ ，则称  $A$  与  $B$  酉相似；
3. 若存在非奇异  $S$  使  $B = S^H A S$ ，则称  $A$  与  $B$  合同。



相似变换保持特征值；酉相似还保持奇异值、二范数、Frobenius 范数和数值域。合同一般不保持特征值，但保持 Hermitian 矩阵的惯性指数。

#### 易错点与反例

$B = S^{-1}AS$  是相似变换，而  $B = S^H AS$  是合同变换。

Cholesky 分解和二次型分析主要使用合同；QR 算法和 Schur 分解主要使用酉相似。

### 10.1.2 知识点二：Schur 分解

**定理 10.3** (复 Schur 分解). 对任意  $A \in \mathbb{C}^{n \times n}$ , 存在酉矩阵  $Q$  和上三角矩阵  $T$ , 使

$$Q^H A Q = T. \quad (10.6)$$

$T$  的对角元恰为  $A$  的特征值，并可通过选择 Schur 向量的次序按任意顺序排列。

证明. 对  $n$  作数学归纳。

当  $n = 1$  时结论显然成立。

设结论对  $n - 1$  阶矩阵成立。由代数学基本定理， $A$  至少有一个特征值  $\lambda_1$  及单位特征向量  $\mathbf{q}_1$ :  $A\mathbf{q}_1 = \lambda_1\mathbf{q}_1$ ,  $\|\mathbf{q}_1\|_2 = 1$ 。将  $\mathbf{q}_1$  扩充为一组酉基  $Q_1 = (\mathbf{q}_1 \quad Q_\perp)$ 。于是

$$Q_1^H A Q_1 = \begin{pmatrix} \mathbf{q}_1^H A \mathbf{q}_1 & \mathbf{q}_1^H A Q_\perp \\ Q_\perp^H A \mathbf{q}_1 & Q_\perp^H A Q_\perp \end{pmatrix} = \begin{pmatrix} \lambda_1 & \mathbf{w}^H \\ \mathbf{0} & A_1 \end{pmatrix}, \quad (10.7)$$

因为  $Q_\perp^H A \mathbf{q}_1 = \lambda_1 Q_\perp^H \mathbf{q}_1 = \mathbf{0}$ 。

由归纳假设，存在  $(n - 1)$  阶酉矩阵  $Q_2$  使  $Q_2^H A_1 Q_2 = T_1$  为上三角矩阵。令  $Q = Q_1 \begin{pmatrix} 1 & 0 \\ 0 & Q_2 \end{pmatrix}$ ,

则  $Q$  酉，且  $Q^H A Q = \begin{pmatrix} \lambda_1 & \mathbf{w}^H Q_2 \\ 0 & T_1 \end{pmatrix}$ ，为上三角矩阵。归纳完成。  $\square$

**定理 10.4** (实 Schur 分解). 对任意  $A \in \mathbb{R}^{n \times n}$ , 存在正交矩阵  $Q$  使

$$Q^T A Q = R, \quad (10.8)$$

其中  $R$  为拟上三角矩阵，其对角块为：

- 对应实特征值的  $1 \times 1$  块；
- 对应共轭复特征值对的实  $2 \times 2$  块。

**【复杂度】** 把稠密矩阵约化到 Schur 形式通常分为：

1. Householder 约化到上 Hessenberg 形式，成本约  $O(n^3)$ ；
2. 隐式位移 QR 迭代，单次扫掠约  $O(n^2)$ 。

Schur 分解是一般非正规矩阵特征值计算的稳定标准形式；不能把一般矩阵无条件写成  $A = V\Lambda V^{-1}$  并假设  $V$  条件良好。



## 10.1.3 知识点三：正规、Hermitian 与正定矩阵

定义 10.5 (正规矩阵). 若

$$A^H A = A A^H, \quad (10.9)$$

则称  $A$  为正规矩阵。

定理 10.6 (正规矩阵的酉对角化). 矩阵  $A \in \mathbb{C}^{n \times n}$  正规, 当且仅当存在酉矩阵  $Q$  和对角矩阵  $\Lambda$  使

$$A = Q \Lambda Q^H. \quad (10.10)$$

证明. 若  $A = Q \Lambda Q^H$ , 则  $A^H A = Q \Lambda^H \Lambda Q^H = Q \Lambda \Lambda^H Q^H = A A^H$ 。

反之, 若  $A$  正规, 由 Schur 分解  $A = Q T Q^H$ , 其中  $T$  上三角。正规性在酉相似下保持, 故  $T$  正规。

比较  $T^H T$  与  $T T^H$  的第  $(1, 1)$  项:  $|t_{11}|^2 = |t_{11}|^2 + \sum_{j=2}^n |t_{1j}|^2$ , 故  $t_{1j} = 0, j = 2, \dots, n$ 。于是  $T$  分块为  $T = \begin{pmatrix} t_{11} & 0 \\ 0 & T_1 \end{pmatrix}$ , 且  $T_1$  仍正规。递归得到  $T$  为对角矩阵。  $\square$

定义 10.7 (Hermitian、半正定与正定). 若  $A^H = A$ , 则称  $A$  为 Hermitian 矩阵。

对 Hermitian 矩阵  $A$ :

$$A \succeq 0 \iff \mathbf{x}^H A \mathbf{x} \geq 0 \quad \forall \mathbf{x}, \quad (10.11)$$

$$A \succ 0 \iff \mathbf{x}^H A \mathbf{x} > 0 \quad \forall \mathbf{x} \neq \mathbf{0}. \quad (10.12)$$

Hermitian 矩阵具有实特征值, 并可酉对角化。若特征值按升序排列:  $\lambda_1 \leq \dots \leq \lambda_n$ , 则

$$A \succeq 0 \iff \lambda_1 \geq 0, \quad (10.13)$$

$$A \succ 0 \iff \lambda_1 > 0. \quad (10.14)$$

对  $A \succ 0$ , 定义能量内积与能量范数

$$\langle \mathbf{x}, \mathbf{y} \rangle_A = \mathbf{x}^H A \mathbf{y}, \quad (10.15)$$

$$\|\mathbf{x}\|_A = \sqrt{\mathbf{x}^H A \mathbf{x}}. \quad (10.16)$$

并有

$$\sqrt{\lambda_{\min}(A)} \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_A \leq \sqrt{\lambda_{\max}(A)} \|\mathbf{x}\|_2. \quad (10.17)$$

## 易错点与反例

正规、可对角化和 Hermitian 不是同一概念。

- Hermitian 矩阵一定正规;
- 正规矩阵一定可对角化;
- 一般可对角化矩阵不一定正规;
- 上三角正规矩阵一定是对角矩阵;
- 正定性只对 Hermitian 或实对称矩阵按上述方式定义。



## 10.2 向量范数、从属矩阵范数与 Frobenius 范数

### 10.2.1 知识点四：向量范数与对偶范数

【重要性等级】 **S 级**。资格考试中的所有扰动界都必须说明所用范数。同一个矩阵在不同范数下可能有完全不同的条件数、稳定常数和停止阈值。

定义 10.8 (向量范数). 映射  $\|\cdot\|: \mathbb{C}^n \rightarrow [0, \infty)$  若满足正定性、绝对齐次性和三角不等式, 则称为向量范数。

常用  $p$  范数为

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|, \quad (10.18)$$

$$\|\mathbf{x}\|_2 = \left( \sum_{i=1}^n |x_i|^2 \right)^{1/2}, \quad (10.19)$$

$$\|\mathbf{x}\|_\infty = \max_i |x_i|. \quad (10.20)$$

有限维空间中所有范数等价。特别地,

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{n} \|\mathbf{x}\|_2 \leq n \|\mathbf{x}\|_\infty. \quad (10.21)$$

定义 10.9 (对偶范数). 给定向量范数  $\|\cdot\|$ , 其对偶范数定义为

$$\|\mathbf{y}\|_* = \max_{\|\mathbf{x}\|=1} |\mathbf{y}^H \mathbf{x}|. \quad (10.22)$$

若  $\frac{1}{p} + \frac{1}{q} = 1$ , 则  $\ell^p$  范数的对偶范数为  $\ell^q$  范数。Hölder 不等式写为

$$|\mathbf{y}^H \mathbf{x}| \leq \|\mathbf{y}\|_q \|\mathbf{x}\|_p. \quad (10.23)$$

### 10.2.2 知识点五：从属矩阵范数

定义 10.10 (从属矩阵范数). 给定定义域和值域上的向量范数, 矩阵  $A \in \mathbb{C}^{m \times n}$  的从属算子范数定义为

$$\|A\| = \max_{\mathbf{x} \neq 0} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|. \quad (10.24)$$

从定义立即得到

$$\|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|, \quad (10.25)$$

$$\|AB\| \leq \|A\| \|B\|, \quad (10.26)$$


$$\|I\| = 1. \quad (10.27)$$

对  $p = 1, 2, \infty$ ,

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|, \quad (10.28)$$

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|, \quad (10.29)$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^H A)} = \sigma_{\max}(A). \quad (10.30)$$



二范数公式. 对任意  $\|x\|_2 = 1$ ,  $\|Ax\|_2^2 = x^H A^H A x$ . 由于  $A^H A$  为 Hermitian 半正定矩阵, Rayleigh 商的最大值为  $\lambda_{\max}(A^H A)$ . 故  $\|A\|_2^2 = \lambda_{\max}(A^H A)$ .  $\square$

### 10.2.3 知识点六: Frobenius 范数

定义 10.11 (Frobenius 范数). 对  $A = (a_{ij}) \in \mathbb{C}^{m \times n}$ ,

$$\|A\|_F = \left( \sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 \right)^{1/2} = \sqrt{\text{tr}(A^H A)}. \quad (10.31)$$

若  $A$  的非零奇异值为  $\sigma_1 \geq \cdots \geq \sigma_r > 0$ ,  $r = \text{rank}(A)$ , 则

$$\|A\|_F^2 = \sum_{j=1}^r \sigma_j^2. \quad (10.32)$$

Frobenius 范数满足酉不变性:

$$\|UAV\|_F = \|A\|_F \quad (10.33)$$

其中  $U, V$  酉.

它是矩阵空间上的 Euclidean 范数, 但当矩阵阶数大于 1 时, 一般不是由同一个向量范数诱导的从属矩阵范数.

常用关系为

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{r} \|A\|_2, \quad (10.34)$$

$$\|A\|_2 \leq \sqrt{\|A\|_1 \|A\|_\infty}, \quad (10.35)$$

$$\|AB\|_F \leq \|A\|_2 \|B\|_F, \quad (10.36)$$

$$\|AB\|_F \leq \|A\|_F \|B\|_2. \quad (10.37)$$

#### 易错点与反例

谱半径、谱范数与 **Frobenius** 范数必须区分。

一般只有  $\rho(A) \leq \|A\|_2 \leq \|A\|_F$ 。等号  $\rho(A) = \|A\|_2$  对正规矩阵成立, 但对一般非正规矩阵不成立。

#### 复杂度说明

对稠密  $m \times n$  矩阵:

- $\|A\|_1$  和  $\|A\|_\infty$  可在  $O(mn)$  时间内精确计算;
- $\|A\|_F$  可在  $O(mn)$  时间内精确计算;
- 精确计算  $\|A\|_2$  通常需要最大奇异值, 稠密情形成本约为  $O(mn \min\{m, n\})$ ;
- 大型稀疏矩阵通常用幂法、Lanczos 或随机方法估计  $\|A\|_2$ 。

## 10.3 谱半径、矩阵幂、Neumann 级数与数值域

### 10.3.1 知识点七：谱半径

定义 10.12 (谱半径). 对  $A \in \mathbb{C}^{n \times n}$ ,

$$\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|. \quad (10.38)$$

对任意从属矩阵范数,

$$\rho(A) \leq \|A\|. \quad (10.39)$$

证明只需取模最大的特征对  $Ax = \lambda x$  并使用  $|\lambda| \|x\| = \|Ax\| \leq \|A\| \|x\|$ 。

定理 10.13 (Gelfand 谱半径公式). 对任意矩阵范数,

$$\rho(A) = \lim_{k \rightarrow \infty} \|A^k\|^{1/k}. \quad (10.40)$$

#### Gelfand 公式证明框架

下界由  $\rho(A)^k = \rho(A^k) \leq \|A^k\|$  直接得到。

上界使用如下事实: 对任意  $\varepsilon > 0$ , 存在与原范数等价的从属矩阵范数  $\|\cdot\|_\varepsilon$  使  $\|A\|_\varepsilon \leq \rho(A) + \varepsilon$ 。

该范数可由缩放 Jordan 块的超对角元构造。

于是  $\|A^k\|_\varepsilon^{1/k} \leq \rho(A) + \varepsilon$ 。利用有限维范数等价性, 把结论转回任意固定矩阵范数, 再令  $\varepsilon \rightarrow 0$ 。

推论 10.14 (矩阵幂趋零判据)。

$$A^k \rightarrow 0 \iff \rho(A) < 1. \quad (10.41)$$

定理 10.15 (Neumann 级数). 若  $\|E\| < 1$ , 则  $I - E$  非奇异, 并且

$$(I - E)^{-1} = \sum_{k=0}^{\infty} E^k. \quad (10.42)$$

此外

$$\|(I - E)^{-1}\| \leq \frac{1}{1 - \|E\|}. \quad (10.43)$$

证明. 有限部分和满足  $(I - E) \sum_{k=0}^N E^k = I - E^{N+1}$ 。由  $\|E^{N+1}\| \leq \|E\|^{N+1} \rightarrow 0$ , 令  $N \rightarrow \infty$  即得结论。□

#### 易错点与反例

$\rho(A) < 1$  是  $A^k \rightarrow 0$  的充要条件。

而  $\|A\| < 1$  只是相对于某个指定范数的充分条件, 不是必要条件。


### 10.3.2 知识点八：数值域与数值半径

定义 10.16 (数值域). 矩阵  $A \in \mathbb{C}^{n \times n}$  的数值域定义为

$$W(A) = \{x^H A x : \|x\|_2 = 1\}. \quad (10.44)$$

数值半径定义为

$$w(A) = \max_{z \in W(A)} |z|. \quad (10.45)$$



基本性质包括：

$$\sigma(A) \subset W(A), \quad (10.46)$$

$$W(Q^H A Q) = W(A), \quad (10.47)$$

$$\rho(A) \leq w(A) \leq \|A\|_2 \leq 2w(A). \quad (10.48)$$

定理 10.17 (Toeplitz–Hausdorff 定理). 对任意复方阵  $A$ , 数值域  $W(A)$  是紧凸集。

#### 证明思路

对任意方向  $\theta$ , 定义 Hermitian 矩阵

$$H_\theta = \frac{1}{2} (e^{-i\theta} A + e^{i\theta} A^H). \quad (10.49)$$

则  $\max_{z \in W(A)} \operatorname{Re}(e^{-i\theta} z) = \lambda_{\max}(H_\theta)$ 。数值域可由这一族支撑半平面的交表示, 从而得到凸性。另一种经典证明把任意两条单位向量张成的二维子空间压缩为  $2 \times 2$  矩阵, 并直接验证其数值域为椭圆盘。

特殊情形：

$$A = A^H \implies W(A) = [\lambda_{\min}(A), \lambda_{\max}(A)], \quad (10.50)$$

$$A \text{ 正规} \implies W(A) = \operatorname{conv} \sigma(A). \quad (10.51)$$

反例 10.18 (只看特征值会低估非正规矩阵的放大). 令  $A = \begin{pmatrix} 0 & M \\ 0 & 0 \end{pmatrix}$ ,  $M > 0$ 。则  $\rho(A) = 0$ ,  $A^2 = 0$ , 但  $\|A\|_2 = M$ ,  $w(A) = \frac{M}{2}$ 。因此矩阵虽只有零特征值, 一次矩阵–向量乘法仍可产生任意大的瞬时放大。

#### 易错点与反例

对非正规矩阵：


- 特征值全在单位圆内不代表每一步都无放大；
- 小谱半径不代表小矩阵范数；
- Krylov 收敛和暂态增长不能只由特征值集合判断；
- 数值域和伪谱往往比特征值更能反映短期行为。

## 10.4 条件数：矩阵–向量乘法与线性方程组

### 10.4.1 知识点九：矩阵–向量乘法的局部条件数

固定  $A \in \mathbb{C}^{m \times n}$ , 考虑问题  $\mathbf{x} \mapsto A\mathbf{x}$ 。若只扰动输入  $\mathbf{x}$ , 则局部相对条件数为

$$\kappa_{\text{mv}}(A, \mathbf{x}) = \frac{\|A\| \|\mathbf{x}\|}{\|A\mathbf{x}\|}, \quad A\mathbf{x} \neq \mathbf{0}. \quad (10.52)$$



因为  $\frac{\|A(\mathbf{x}+\delta\mathbf{x})-A\mathbf{x}\|}{\|A\mathbf{x}\|} \leq \frac{\|A\|\|\delta\mathbf{x}\|}{\|A\mathbf{x}\|}$ 。

若  $A$  非奇异，则  $\kappa_{\text{mv}}(A, \mathbf{x}) \leq \|A\| \|A^{-1}\|$ 。

### 10.4.2 知识点十：矩阵条件数

定义 10.19 (矩阵条件数). 若  $A$  非奇异，定义

$$\kappa(A) = \|A\| \|A^{-1}\|. \quad (10.53)$$

若  $A$  奇异，定义  $\kappa(A) = +\infty$ 。

对  $p$  范数诱导的矩阵范数，记为  $\kappa_p(A)$ 。特别地，

$$\kappa_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}. \quad (10.54)$$

条件数具有尺度不变性：

$$\kappa(\alpha A) = \kappa(A), \alpha \neq 0. \quad (10.55)$$

对酉矩阵  $Q$ ， $\kappa_2(Q) = 1$ 。对 Hermitian 正定矩阵，

$$\kappa_2(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}. \quad (10.56)$$

### 10.4.3 知识点十一：求解映射的实际条件数

考虑

$$A\mathbf{x} = \mathbf{b}, A \text{ 非奇异}. \quad (10.57)$$

若  $A$  固定，只扰动  $\mathbf{b}$ ，则求解映射  $\mathbf{b} \mapsto A^{-1}\mathbf{b}$  在  $\mathbf{b}$  处的局部相对条件数为

$$\kappa_{\text{solve}}(A, \mathbf{b}) = \frac{\|A^{-1}\| \|\mathbf{b}\|}{\|A^{-1}\mathbf{b}\|}. \quad (10.58)$$

其最坏情形为

$$\sup_{\mathbf{b} \neq 0} \kappa_{\text{solve}}(A, \mathbf{b}) = \kappa(A). \quad (10.59)$$

因此  $\kappa(A)$  是最坏方向条件数，而具体右端项的实际敏感性可能远小于  $\kappa(A)$ 。

#### 易错点与反例

条件数大表示存在某些扰动方向被强烈放大，不表示每个右端项和每个扰动方向都达到最坏情况。

### 10.4.4 知识点十二：正规方程导致条件数平方

若  $A \in \mathbb{C}^{m \times n}$  满列秩，则正规方程矩阵  $A^H A$  满足

$$\kappa_2(A^H A) = \kappa_2(A)^2. \quad (10.60)$$

因为  $A^H A$  的特征值为  $\sigma_1(A)^2, \dots, \sigma_n(A)^2$ 。

这意味着：若  $\kappa_2(A)$  已经很大，使用正规方程解最小二乘会额外损失约一倍有效数字。第 11 部分将比较正规方程、QR 与 SVD。



## 易错点与反例

$A^H A$  总是半正定, 但只有当  $A$  满列秩时才正定、可逆。

不能对秩亏矩阵无条件写  $(A^H A)^{-1} A^H$ 。

## 10.5 线性方程组扰动分析

## 10.5.1 知识点十三: 只扰动右端项

设  $Ax = b$ ,  $A(x + \delta x) = b + \delta b$ . 则

$$\delta x = A^{-1} \delta b. \quad (10.61)$$

因此

$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|}. \quad (10.62)$$

该估计的常数  $\kappa(A)$  在最坏情形下不可改进。

## 10.5.2 知识点十四: Banach 扰动引理

引理 10.20 (Banach 扰动引理). 若  $A$  非奇异并且

$$\|A^{-1} \Delta A\| < 1, \quad (10.63)$$

则  $A + \Delta A$  非奇异, 并有

$$(A + \Delta A)^{-1} = (I + A^{-1} \Delta A)^{-1} A^{-1}, \quad (10.64)$$

以及

$$\|(A + \Delta A)^{-1}\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1} \Delta A\|}. \quad (10.65)$$

证明. 写成  $A + \Delta A = A(I + A^{-1} \Delta A)$ . 由  $\|A^{-1} \Delta A\| < 1$  及 Neumann 级数,  $I + A^{-1} \Delta A$  可逆。逆矩阵范数界由几何级数直接得到。□

## 10.5.3 知识点十五: 同时扰动系数矩阵和右端项

设

$$Ax = b, \quad (10.66)$$

$$(A + \Delta A)(x + \Delta x) = b + \Delta b. \quad (10.67)$$

两式相减, 得到精确恒等式

$$(A + \Delta A) \Delta x = \Delta b - \Delta A x. \quad (10.68)$$

定义


$$\delta_A = \frac{\|\Delta A\|}{\|A\|}, \quad \delta_b = \frac{\|\Delta b\|}{\|b\|}. \quad (10.69)$$

若

$$\kappa(A) \delta_A < 1, \quad (10.70)$$

则

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \delta_A} (\delta_A + \delta_b). \quad (10.71)$$



证明. 由 式 (10.68),

$$\|\Delta \mathbf{x}\| \leq \|(A + \Delta A)^{-1}\| (\|\Delta \mathbf{b}\| + \|\Delta A\| \|\mathbf{x}\|).$$

再使用  $\|A^{-1}\Delta A\| \leq \kappa(A)\delta_A$  及 式 (10.65). 同时  $\|\mathbf{b}\| = \|A\mathbf{x}\| \leq \|A\| \|\mathbf{x}\|$ , 故  $\frac{\|\Delta \mathbf{b}\|}{\|\mathbf{x}\|} \leq \|A\| \delta_b$ . 代入即得.  $\square$

当扰动充分小时, 一阶近似为

$$\frac{\|\Delta \mathbf{x}\|}{\|\mathbf{x}\|} \lesssim \kappa(A) (\delta_A + \delta_b). \quad (10.72)$$

#### 10.5.4 知识点十六: 逆矩阵的扰动

由恒等式

$$(A + \Delta A)^{-1} - A^{-1} = -(A + \Delta A)^{-1} \Delta A A^{-1}, \quad (10.73)$$

可得

$$\frac{\|(A + \Delta A)^{-1} - A^{-1}\|}{\|A^{-1}\|} \leq \frac{\kappa(A)\delta_A}{1 - \kappa(A)\delta_A}. \quad (10.74)$$

##### 线性系统扰动界的标准证明套路

识别信号: 题目同时给出  $A, \mathbf{b}$  及扰动  $\Delta A, \Delta \mathbf{b}$ , 要求解的相对变化。

构造步骤:

1. 写出扰动前后两个方程;
2. 相减得到精确恒等式;
3. 把  $A + \Delta A$  分解为  $A(I + A^{-1}\Delta A)$ ;
4. 用 Neumann 级数证明可逆;
5. 先得到绝对误差, 再统一除以  $\|\mathbf{x}\|$ ;
6. 用  $\|\mathbf{b}\| \leq \|A\| \|\mathbf{x}\|$  转换右端项相对误差。

常见失败: 直接把  $(A + \Delta A)^{-1}$  替换为  $A^{-1}$ , 却未说明是一阶近似; 或遗漏条件  $\kappa(A)\delta_A < 1$ 。

## 10.6 残差、前向误差与后向误差

### 10.6.1 知识点十七: 残差与真实误差

设精确解满足  $A\mathbf{x} = \mathbf{b}$ , 计算得到近似解  $\hat{\mathbf{x}}$ . 定义

$$\mathbf{e} = \mathbf{x} - \hat{\mathbf{x}}, \quad (10.75)$$


$$\mathbf{r} = \mathbf{b} - A\hat{\mathbf{x}}. \quad (10.76)$$

则有精确关系

$$A\mathbf{e} = \mathbf{r}, \quad \mathbf{e} = A^{-1}\mathbf{r}. \quad (10.77)$$

因此

$$\frac{\|\mathbf{r}\|}{\|A\|} \leq \|\mathbf{e}\| \leq \|A^{-1}\| \|\mathbf{r}\|. \quad (10.78)$$





若  $\mathbf{b} \neq \mathbf{0}$ , 则

$$\frac{1}{\kappa(A)} \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|} \leq \frac{\|\mathbf{e}\|}{\|\mathbf{x}\|} \leq \kappa(A) \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}. \quad (10.79)$$

这说明残差能否代表误差取决于条件数。

反例 10.21 (相对残差很小但前向误差很大). 令  $A = \begin{pmatrix} 1 & 0 \\ 0 & \varepsilon \end{pmatrix}$ ,  $0 < \varepsilon \ll 1$ . 取精确解  $\mathbf{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ ,  $\mathbf{b} = \begin{pmatrix} 1 \\ \varepsilon \end{pmatrix}$ , 以及近似解  $\hat{\mathbf{x}} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ . 则  $\mathbf{r} = \begin{pmatrix} 0 \\ \varepsilon \end{pmatrix}$ . 因此  $\frac{\|\mathbf{r}\|_2}{\|\mathbf{b}\|_2} \sim \varepsilon$ , 但  $\frac{\|\mathbf{x} - \hat{\mathbf{x}}\|_2}{\|\mathbf{x}\|_2} = \frac{1}{\sqrt{2}}$ . 同时  $\kappa_2(A) = \varepsilon^{-1}$ .

### 10.6.2 知识点十八: 只扰动右端项的后向误差

近似解  $\hat{\mathbf{x}}$  总是如下邻近问题的精确解:

$$A\hat{\mathbf{x}} = \mathbf{b} - \mathbf{r}. \quad (10.80)$$

所以只允许扰动右端项时, 范数型相对后向误差为

$$\eta_b(\hat{\mathbf{x}}) = \frac{\|\mathbf{r}\|}{\|\mathbf{b}\|}. \quad (10.81)$$

### 10.6.3 知识点十九: 只扰动矩阵的后向误差

若  $\hat{\mathbf{x}} \neq \mathbf{0}$ , 定义

$$\eta_A(\hat{\mathbf{x}}) = \min \left\{ \frac{\|\Delta A\|}{\|A\|} : (A + \Delta A)\hat{\mathbf{x}} = \mathbf{b} \right\}. \quad (10.82)$$

对从属矩阵范数,

$$\eta_A(\hat{\mathbf{x}}) = \frac{\|\mathbf{r}\|}{\|A\| \|\hat{\mathbf{x}}\|}. \quad (10.83)$$

证明. 条件  $(A + \Delta A)\hat{\mathbf{x}} = \mathbf{b}$  等价于  $\Delta A\hat{\mathbf{x}} = \mathbf{r}$ . 所以  $\|\mathbf{r}\| \leq \|\Delta A\| \|\hat{\mathbf{x}}\|$ , 给出下界。

取对偶单位向量  $\mathbf{w}$  使  $\|\mathbf{w}\|_* = 1$ ,  $\mathbf{w}^H \hat{\mathbf{x}} = \|\hat{\mathbf{x}}\|$ . 令

$$\Delta A = \frac{\mathbf{r}\mathbf{w}^H}{\|\hat{\mathbf{x}}\|}. \quad (10.84)$$

则  $\Delta A\hat{\mathbf{x}} = \mathbf{r}$ , 且  $\|\Delta A\| = \frac{\|\mathbf{r}\|}{\|\hat{\mathbf{x}}\|}$ . 故下界可达到。□

### 10.6.4 知识点二十: 同时扰动矩阵和右端项

采用如下统一范数型后向误差:

$$\eta(\hat{\mathbf{x}}) = \min \left\{ \varepsilon : \begin{array}{l} (A + \Delta A)\hat{\mathbf{x}} = \mathbf{b} + \Delta \mathbf{b}, \\ \|\Delta A\| \leq \varepsilon \|A\|, \\ \|\Delta \mathbf{b}\| \leq \varepsilon \|\mathbf{b}\| \end{array} \right\}. \quad (10.85)$$

则

$$\eta(\hat{\mathbf{x}}) = \frac{\|\mathbf{r}\|}{\|A\| \|\hat{\mathbf{x}}\| + \|\mathbf{b}\|}. \quad (10.86)$$



证明. 扰动方程等价于  $\Delta A \hat{\mathbf{x}} - \Delta \mathbf{b} = \mathbf{r}$ . 若两种相对扰动均不超过  $\varepsilon$ , 则  $\|\mathbf{r}\| \leq \varepsilon(\|A\| \|\hat{\mathbf{x}}\| + \|\mathbf{b}\|)$ . 这给出下界。

令  $\mathbf{u} = \frac{\mathbf{r}}{\|\mathbf{r}\|}$ , 并选取对偶单位向量  $\mathbf{w}$  满足  $\mathbf{w}^H \hat{\mathbf{x}} = \|\hat{\mathbf{x}}\|$ . 取

$$\Delta A = \eta \|A\| \mathbf{u} \mathbf{w}^H, \quad (10.87)$$

$$\Delta \mathbf{b} = -\eta \|\mathbf{b}\| \mathbf{u}. \quad (10.88)$$

则  $\Delta A \hat{\mathbf{x}} - \Delta \mathbf{b} = \eta(\|A\| \|\hat{\mathbf{x}}\| + \|\mathbf{b}\|) \mathbf{u} = \mathbf{r}$ . 故下界达到。□

### 10.6.5 知识点二十一：分量后向误差

若采用分量相对扰动模型

$$|\Delta A| \leq \varepsilon |A|, \quad (10.89)$$

$$|\Delta \mathbf{b}| \leq \varepsilon |\mathbf{b}|, \quad (10.90)$$

其中绝对值逐分量理解, 则最小分量后向误差为

$$\eta_{\text{cw}}(\hat{\mathbf{x}}) = \max_i \frac{|r_i|}{(|A| \|\hat{\mathbf{x}}\| + |\mathbf{b}|)_i}. \quad (10.91)$$

采用约定:

- $0/0 = 0$ ;
- 若分子非零而分母为零, 则比值为  $+\infty$ 。

分量后向误差比单一矩阵范数更能反映不同量级数据的实际相对扰动。

### 10.6.6 知识点二十二：后向稳定性与前向误差

若算法计算结果  $\hat{\mathbf{x}}$  是某个邻近问题  $(A + \Delta A) \hat{\mathbf{x}} = \mathbf{b} + \Delta \mathbf{b}$  的精确解, 且  $\frac{\|\Delta A\|}{\|A\|}, \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|} = O(u)$ , 其中  $u$  为单位舍入误差, 则称算法在相应模型下后向稳定。

在问题条件数为  $\kappa$  时, 典型前向误差满足

$$\text{相对前向误差} = O(\kappa u). \quad (10.92)$$

#### 易错点与反例

必须区分:

- 条件数: 问题本身对数据扰动的敏感性;
- 后向误差: 计算结果对应多大的数据扰动;
- 前向误差: 计算结果与原问题真解的距离;
- 残差: 离散方程未满足的程度。

后向稳定算法无法消除问题本身的病态性。

## 10.7 奇异值、秩亏距离与特征值扰动

## 10.7.1 知识点二十三：到奇异矩阵集合的距离

记  $\mathcal{S} = \{B \in \mathbb{C}^{n \times n} : \det B = 0\}$ 。

定理 10.22 (Eckart–Young 距离公式的秩亏特例). 若  $A$  非奇异, 则

$$\text{dist}_2(A, \mathcal{S}) := \min_{B \in \mathcal{S}} \|A - B\|_2 = \sigma_{\min}(A) = \frac{1}{\|A^{-1}\|_2}. \quad (10.93)$$

证明. 设  $A + E$  奇异, 则存在单位向量  $\mathbf{x}$  使  $(A + E)\mathbf{x} = \mathbf{0}$ 。因此  $\|E\|_2 \geq \|E\mathbf{x}\|_2 = \|A\mathbf{x}\|_2 \geq \sigma_{\min}(A)$ 。这给出下界。

设  $A\mathbf{v}_n = \sigma_{\min}\mathbf{u}_n$  为最小奇异值对应的左右奇异向量。取  $E_* = -\sigma_{\min}\mathbf{u}_n\mathbf{v}_n^H$ 。则  $(A + E_*)\mathbf{v}_n = \mathbf{0}$ , 所以  $A + E_*$  奇异, 且  $\|E_*\|_2 = \sigma_{\min}(A)$ 。下界达到。  $\square$

由此得到

$$\kappa_2(A) = \frac{\|A\|_2}{\text{dist}_2(A, \mathcal{S})}. \quad (10.94)$$

条件数大的矩阵在相对意义下接近奇异矩阵集合。

## 10.7.2 知识点二十四：奇异值扰动

定理 10.23 (Weyl 奇异值扰动界). 设  $A, B \in \mathbb{C}^{m \times n}$ , 奇异值按非增次序排列, 则

$$|\sigma_j(A) - \sigma_j(B)| \leq \|A - B\|_2, \quad j = 1, \dots, \min\{m, n\}. \quad (10.95)$$

特别地,

$$\sigma_{\min}(A + E) \geq \sigma_{\min}(A) - \|E\|_2. \quad (10.96)$$

若  $\|E\|_2 < \sigma_{\min}(A)$ , 则  $A + E$  仍非奇异。

定理 10.24 (Mirsky 不等式). 对同型矩阵  $A, B$ ,

$$\sum_j (\sigma_j(A) - \sigma_j(B))^2 \leq \|A - B\|_F^2. \quad (10.97)$$

## 10.7.3 补充训练题：由 Hoffman–Wielandt 推出 Mirsky 不等式

完整题目叙述: [NLA-Set]

设  $A, B \in \mathbb{C}^{n \times n}$ , 其奇异值分别按非增次序排列为  $\sigma_1 \geq \dots \geq \sigma_n \geq 0$ ,  $\tau_1 \geq \dots \geq \tau_n \geq 0$ 。已知对 Hermitian 矩阵  $C, D$ , 若特征值按非增次序排列为  $\lambda_i, \mu_i$ , 则  $\sum_{i=1}^n (\lambda_i - \mu_i)^2 \leq \|C - D\|_F^2$ 。证明  $\sum_{i=1}^n (\sigma_i - \tau_i)^2 \leq \|A - B\|_F^2$ 。

详细解答. 定义 Hermitian 膨胀矩阵

$$\mathcal{H}(A) = \begin{pmatrix} 0 & A \\ A^H & 0 \end{pmatrix}, \quad \mathcal{H}(B) = \begin{pmatrix} 0 & B \\ B^H & 0 \end{pmatrix}. \quad (10.98)$$

若  $Av_i = \sigma_i u_i$ ,  $A^H u_i = \sigma_i v_i$ , 则

$$\mathcal{H}(A) \begin{pmatrix} u_i \\ v_i \end{pmatrix} = \sigma_i \begin{pmatrix} u_i \\ v_i \end{pmatrix}, \quad (10.99)$$

$$\mathcal{H}(A) \begin{pmatrix} u_i \\ -v_i \end{pmatrix} = -\sigma_i \begin{pmatrix} u_i \\ -v_i \end{pmatrix}. \quad (10.100)$$

因此  $\mathcal{H}(A)$  的特征值为  $\sigma_1, \dots, \sigma_n, -\sigma_n, \dots, -\sigma_1$ 。同理,  $\mathcal{H}(B)$  的特征值为  $\tau_1, \dots, \tau_n, -\tau_n, \dots, -\tau_1$ 。

对两个  $2n$  阶 Hermitian 矩阵应用 Hoffman–Wielandt 不等式:

$$\begin{aligned} & 2 \sum_{i=1}^n (\sigma_i - \tau_i)^2 \\ & \leq \|\mathcal{H}(A) - \mathcal{H}(B)\|_F^2. \end{aligned} \quad (10.101)$$

另一方面,

$$\begin{aligned} \|\mathcal{H}(A) - \mathcal{H}(B)\|_F^2 &= \|A - B\|_F^2 + \|A^H - B^H\|_F^2 \\ &= 2 \|A - B\|_F^2. \end{aligned} \quad (10.102)$$

约去因子 2, 即得  $\sum_{i=1}^n (\sigma_i - \tau_i)^2 \leq \|A - B\|_F^2$ 。□

#### 10.7.4 知识点二十五: Hermitian 特征值扰动

设  $A = A^H$ ,  $\tilde{A} = A + E$ ,  $E = E^H$ 。若特征值按非降次序排列, 则 Weyl 定理给出

$$|\lambda_j(\tilde{A}) - \lambda_j(A)| \leq \|E\|_2. \quad (10.103)$$

更强的 Hoffman–Wielandt 不等式为

$$\sum_{j=1}^n \left[ \lambda_j(\tilde{A}) - \lambda_j(A) \right]^2 \leq \|E\|_F^2. \quad (10.104)$$

这些结论依赖 Hermitian 结构。对一般非正规矩阵, 特征值可能远比  $\|E\|$  敏感。

#### 10.7.5 知识点二十六: Bauer–Fike 定理

**定理 10.25 (Bauer–Fike).** 设  $A$  可对角化:  $A = V\Lambda V^{-1}$ 。若  $\mu$  是  $A + E$  的任一特征值, 则存在  $\lambda_j \in \sigma(A)$  使

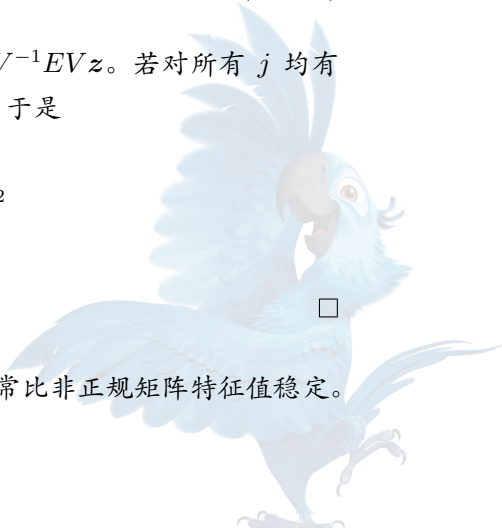
$$|\mu - \lambda_j| \leq \kappa_2(V) \|E\|_2. \quad (10.105)$$

证明. 设  $(A + E)\mathbf{y} = \mu\mathbf{y}$ ,  $\mathbf{y} \neq 0$ 。令  $\mathbf{z} = V^{-1}\mathbf{y}$ 。则  $(\Lambda - \mu I)\mathbf{z} = -V^{-1}E\mathbf{V}\mathbf{z}$ 。若对所有  $j$  均有  $|\mu - \lambda_j| > \kappa_2(V) \|E\|_2$ , 则  $\Lambda - \mu I$  可逆, 且  $\|(\Lambda - \mu I)^{-1}\|_2 < \frac{1}{\kappa_2(V) \|E\|_2}$ 。于是

$$\begin{aligned} \|\mathbf{z}\|_2 &\leq \|(\Lambda - \mu I)^{-1}\|_2 \|V^{-1}\|_2 \|E\|_2 \|V\|_2 \|\mathbf{z}\|_2 \\ &< \|\mathbf{z}\|_2, \end{aligned}$$

矛盾。□

若  $A$  正规, 可取  $V$  酉, 故  $\kappa_2(V) = 1$ 。这解释了正规矩阵特征值通常比非正规矩阵特征值稳定。



## 10.7.6 知识点二十七：简单特征值的局部条件数

设  $\lambda$  是  $A$  的简单特征值，右、左特征向量满足

$$Ax = \lambda x, \quad (10.106)$$

$$y^H A = \lambda y^H, \quad (10.107)$$

并且  $y^H x \neq 0$ 。对扰动  $A + \varepsilon E$ ,

$$\lambda(\varepsilon) = \lambda + \varepsilon \frac{y^H E x}{y^H x} + O(\varepsilon^2). \quad (10.108)$$

因此绝对特征值条件数为

$$\kappa_{\text{eig}}(\lambda) = \frac{\|x\|_2 \|y\|_2}{|y^H x|}. \quad (10.109)$$

若将左右特征向量均归一化为二范数 1，则  $\kappa_{\text{eig}}(\lambda) = \frac{1}{|y^H x|}$ 。

对正规矩阵可取  $y = x$ ,  $\|x\|_2 = 1$ , 所以  $\kappa_{\text{eig}}(\lambda) = 1$ 。

## 10.7.7 知识点二十八：特征向量与谱间隙

对 Hermitian 矩阵  $A$  的简单特征值  $\lambda_i$ , 定义谱间隙

$$\text{gap}_i = \min_{j \neq i} |\lambda_i - \lambda_j|. \quad (10.110)$$

若  $\tilde{A} = A + E$  仍为 Hermitian, 则 Davis-Kahan 型估计说明

$$\sin \angle(x_i, \tilde{x}_i) \lesssim \frac{\|E\|_2}{\text{gap}_i}. \quad (10.111)$$

所以即使特征值本身稳定, 若谱间隙很小, 特征向量仍可能高度敏感。

## 易错点与反例

特征值扰动和特征向量扰动不是同一问题。

Hermitian 特征值总满足  $|\delta \lambda_i| \leq \|E\|_2$ , 但特征向量误差还需要除以谱间隙。重特征值处应分析不变子空间, 而不是单个特征向量。

## 10.8 正式真题 [25F-Q1]——Newton-Schulz 矩阵求逆迭代

完整题目叙述: [25F-Q1]

除 LU 型分解外, 矩阵逆也可通过迭代得到。给定  $A \in \mathbb{R}^{n \times n}$ , 考虑矩阵序列

$$X_{k+1} = 2X_k - X_k A X_k, \quad k = 0, 1, 2, \dots \quad (10.112)$$

证明:

(a) 若  $\|I - AX_0\| < 1$ , 则  $A$  非奇异, 并且  $X_k$  二次收敛到  $A^{-1}$ ;

(b) 存在  $X_0$  使  $\|I - AX_0\| < 1$  当且仅当  $A$  非奇异。

第 (a) 问: 非奇异性. 定义左残差矩阵

$$E_k = I - AX_k. \quad (10.113)$$

由题设  $\|E_0\| < 1$ . 因此由 Neumann 级数,  $I - E_0 = AX_0$  非奇异。

由于  $A$  与  $X_0$  均为  $n \times n$  方阵, 乘积  $AX_0$  非奇异蕴含  $\text{rank}(A) = n$ . 故  $A$  非奇异.  $\square$

第 (a) 问: 残差平方. 由迭代公式,

$$\begin{aligned} E_{k+1} &= I - AX_{k+1} \\ &= I - A(2X_k - X_kAX_k) \\ &= I - 2AX_k + (AX_k)^2 \\ &= (I - AX_k)^2. \end{aligned} \quad (10.114)$$

因此

$$\boxed{E_{k+1} = E_k^2}. \quad (10.115)$$

归纳得

$$\boxed{E_k = E_0^{2^k}}. \quad (10.116)$$

于是

$$\|E_k\| \leq \|E_0\|^{2^k} \rightarrow 0. \quad (10.117)$$

因为  $A$  非奇异,  $X_k = A^{-1}(I - E_k)$ , 所以

$$\|X_k - A^{-1}\| \leq \|A^{-1}\| \|E_k\| \rightarrow 0. \quad (10.118)$$

$\square$

第 (a) 问: 二次收敛. 定义逆矩阵前向误差

$$\Delta_k = X_k - A^{-1}. \quad (10.119)$$

代入  $X_k = A^{-1} + \Delta_k$  可得

$$\begin{aligned} X_{k+1} &= 2(A^{-1} + \Delta_k) \\ &\quad - (A^{-1} + \Delta_k)A(A^{-1} + \Delta_k) \\ &= A^{-1} - \Delta_k A \Delta_k. \end{aligned} \quad (10.120)$$

所以

$$\boxed{\Delta_{k+1} = -\Delta_k A \Delta_k}. \quad (10.121)$$


从而

$$\boxed{\|\Delta_{k+1}\| \leq \|A\| \|\Delta_k\|^2}. \quad (10.122)$$

故  $X_k$  局部二次收敛到  $A^{-1}$ 。

更精确地, 残差满足精确平方关系  $\|E_{k+1}\| \leq \|E_k\|^2$ , 意味着每一次迭代理想情况下约使正确数字位数加倍.  $\square$

第 (b) 问: 必要性. 若存在  $X_0$  使  $\|I - AX_0\| < 1$ , 则第 (a) 问已证明  $A$  非奇异.  $\square$



第 (b) 问: 充分性. 若  $A$  非奇异, 逻辑上可直接取  $X_0 = A^{-1}$ , 此时  $\|I - AX_0\| = 0 < 1$ . 因此“存在性”已经得到证明。

为了给出可计算的初值, 考虑二范数并取

$$X_0 = \alpha A^T, \quad 0 < \alpha < \frac{2}{\|A\|_2^2}. \quad (10.123)$$

由于  $A$  非奇异,  $AA^T$  为对称正定矩阵, 特征值为  $\sigma_1(A)^2, \dots, \sigma_n(A)^2$ . 故  $I - AX_0 = I - \alpha AA^T$  的特征值为  $1 - \alpha\sigma_i(A)^2$ . 由  $0 < \alpha < \frac{2}{\sigma_1^2}$  知  $|1 - \alpha\sigma_i^2| < 1 \quad \forall i$ . 所以

$$\|I - AX_0\|_2 = \max_i |1 - \alpha\sigma_i^2| < 1. \quad (10.124)$$

一个无需预先知道  $\|A\|_2$  的常用充分选择为

$$X_0 = \frac{A^T}{\|A\|_1 \|A\|_\infty}. \quad (10.125)$$

因为  $\|A\|_2^2 \leq \|A\|_1 \|A\|_\infty$ . □

---

#### Algorithm 34 Newton-Schulz 矩阵求逆迭代

---

**Input:** 方阵  $A$ ; 初值  $X_0$ ; 残差容差  $\text{tol}$ ; 最大迭代次数  $K_{\max}$

**Output:**  $A^{-1}$  的近似

- 1: **Initialization:** 可取  $X_0 = \frac{A^H}{\|A\|_1 \|A\|_\infty}$
  - 2: **for**  $k = 0, 1, \dots, K_{\max} - 1$  **do**
  - 3:      $E_k \leftarrow I - AX_k$
  - 4:     **if**  $\|E_k\|$  满足停止准则 **then**
  - 5:         **return**  $X_k$
  - 6:     **end if**
  - 7:      $X_{k+1} \leftarrow X_k(2I - AX_k)$
  - 8: **end for**
  - 9: 报告“未达到残差容差”
  - 10: **Stopping criterion:** 可使用  $\|I - AX_k\| \leq \text{tol}$  并同时监视  $\|X_{k+1} - X_k\|$
  - 11: **Complexity:** 稠密情形每步需要约两次矩阵乘法, 时间  $O(n^3)$ 、存储  $O(n^2)$ ; 适合高并行矩阵乘法和多右端项场景, 不适合只求解单个右端项
- 

#### 易错点与反例

1. 必须先定义  $E_k = I - AX_k$  并证明  $E_{k+1} = E_k^2$ ;
2. 不能由  $\rho(E_0) < 1$  直接替换题设的指定范数条件而不作额外论证;
3. 矩阵不交换, 展开时必须保持乘法次序;
4. “二次收敛”应写明是残差或逆矩阵误差的二次递推;
5. 有限精度下残差最终会停滞, 不能无限获得平方精度;
6. 显式计算整个逆矩阵通常比解一个线性方程组成本更高。



## 10.9 正式真题 [24S-Q3]——Hilbert 矩阵

完整题目叙述: [24S-Q3]

给定  $n$  阶 Hilbert 矩阵

$$H_n = \left( \frac{1}{i+j-1} \right)_{i,j=1}^n. \quad (10.126)$$

证明:

1.  $H_n$  正定;
2. 谱半径  $\rho(H_n)$  关于  $n$  严格单调递增;
3.  $\rho(H_n) \rightarrow \pi, n \rightarrow \infty$ .

第一问: 正定性. 对任意实向量  $\mathbf{x} = (x_1, \dots, x_n)^\top$ , 利用  $\frac{1}{i+j-1} = \int_0^1 t^{i+j-2} dt$ , 有

$$\begin{aligned} \mathbf{x}^\top H_n \mathbf{x} &= \sum_{i,j=1}^n \frac{x_i x_j}{i+j-1} \\ &= \int_0^1 \left( \sum_{i=1}^n x_i t^{i-1} \right)^2 dt. \end{aligned} \quad (10.127)$$

若  $\mathbf{x} \neq \mathbf{0}$ , 多项式  $p_{\mathbf{x}}(t) = \sum_{i=1}^n x_i t^{i-1}$  不是零多项式. 非零多项式不能在整个区间  $[0, 1]$  上恒为零, 故  $\int_0^1 p_{\mathbf{x}}(t)^2 dt > 0$ . 因此

$$\boxed{H_n \succ 0}. \quad (10.128)$$

□

注 10.26. 式 (10.127) 说明  $H_n$  是函数族  $1, t, \dots, t^{n-1}$  在  $L^2(0, 1)$  内积下的 Gram 矩阵. 正定性等价于这些函数线性无关。

第二问: 谱半径严格单调. 因为  $H_n$  为实对称正定矩阵,  $\rho(H_n) = \lambda_{\max}(H_n)$ .  $H_n$  是  $H_{n+1}$  的左上主子矩阵. 由 Cauchy 交错定理,

$$\lambda_{\max}(H_{n+1}) \geq \lambda_{\max}(H_n). \quad (10.129)$$

下面证明严格不等式. 由于  $H_n$  的所有元素均严格为正, Perron–Frobenius 定理保证存在严格的单位特征向量  $\mathbf{v}_n > \mathbf{0}$ ,  $H_n \mathbf{v}_n = \lambda_{\max}(H_n) \mathbf{v}_n$ . 扩充为  $\tilde{\mathbf{v}} = \begin{pmatrix} \mathbf{v}_n \\ 0 \end{pmatrix} \in \mathbb{R}^{n+1}$ . 其 Rayleigh 商为  $\frac{\tilde{\mathbf{v}}^\top H_{n+1} \tilde{\mathbf{v}}}{\|\tilde{\mathbf{v}}\|_2^2} = \lambda_{\max}(H_n)$ .

若  $\lambda_{\max}(H_{n+1}) = \lambda_{\max}(H_n)$ , 则  $\tilde{\mathbf{v}}$  达到  $H_{n+1}$  的最大 Rayleigh 商, 故它必须是  $H_{n+1}$  的最大特征值对应特征向量。


然而,

$$(H_{n+1} \tilde{\mathbf{v}})_{n+1} = \sum_{j=1}^n \frac{(v_n)_j}{n+j} > 0, \quad (10.130)$$

而  $(\lambda_{\max}(H_n) \tilde{\mathbf{v}})_{n+1} = 0$ , 矛盾. 因此

$$\boxed{\rho(H_{n+1}) > \rho(H_n)}. \quad (10.131)$$

□



引理 10.27 (Schur 检验). 设无限非负矩阵  $K = (k_{ij})_{i,j \geq 1}$  满足: 存在  $p_i > 0$  和  $C > 0$  使

$$\sum_{j=1}^{\infty} k_{ij} p_j \leq C p_i, \quad (10.132)$$

$$\sum_{i=1}^{\infty} k_{ij} p_i \leq C p_j. \quad (10.133)$$

则  $K$  在  $\ell^2$  上的算子范数不超过  $C$ 。

证明. 对有限支撑序列  $\mathbf{x}, \mathbf{y}$ , 由 Cauchy-Schwarz 不等式,

$$\begin{aligned} \sum_{i,j} k_{ij} |x_i| |y_j| &= \sum_{i,j} \sqrt{k_{ij} \frac{p_j}{p_i}} |x_i| \sqrt{k_{ij} \frac{p_i}{p_j}} |y_j| \\ &\leq \left[ \sum_i \frac{|x_i|^2}{p_i} \sum_j k_{ij} p_j \right]^{1/2} \\ &\quad \cdot \left[ \sum_j \frac{|y_j|^2}{p_j} \sum_i k_{ij} p_i \right]^{1/2} \\ &\leq C \|\mathbf{x}\|_2 \|\mathbf{y}\|_2. \end{aligned} \quad (10.134)$$

由稠密性延拓到  $\ell^2$ 。 □

引理 10.28 (Hilbert 不等式的算子形式). 无限 Hilbert 矩阵  $H_\infty = \left( \frac{1}{i+j-1} \right)_{i,j \geq 1}$  在  $\ell^2$  上的算子范数不超过  $\pi$ 。即对任意有限序列  $\mathbf{x}, \mathbf{y}$ ,

$$\left| \sum_{i,j \geq 1} \frac{x_i \overline{y_j}}{i+j-1} \right| \leq \pi \|\mathbf{x}\|_2 \|\mathbf{y}\|_2. \quad (10.135)$$

证明. 取

$$p_j = \frac{1}{\sqrt{j - \frac{1}{2}}}. \quad (10.136)$$

固定  $i$  并令  $a = i - \frac{1}{2} > 0$ 。定义  $f_a(t) = \frac{1}{(a+t)\sqrt{t}}$ ,  $t > 0$ 。直接求导可得

$$f_a''(t) = \frac{3}{4t^{5/2}(a+t)} + \frac{1}{t^{3/2}(a+t)^2} + \frac{2}{t^{1/2}(a+t)^3} > 0. \quad (10.137)$$


所以  $f_a$  凸。由 Jensen 不等式, 对每个  $j$ ,  $f_a(j - \frac{1}{2}) \leq \int_{j-1}^j f_a(t) dt$ 。因此

$$\begin{aligned} \sum_{j=1}^{\infty} \frac{p_j}{i+j-1} &= \sum_{j=1}^{\infty} f_a\left(j - \frac{1}{2}\right) \\ &\leq \int_0^{\infty} \frac{dt}{(a+t)\sqrt{t}}. \end{aligned} \quad (10.138)$$

令  $t = as^2$ , 则

$$\begin{aligned} \int_0^{\infty} \frac{dt}{(a+t)\sqrt{t}} &= \frac{2}{\sqrt{a}} \int_0^{\infty} \frac{ds}{1+s^2} \\ &= \frac{\pi}{\sqrt{a}} = \pi p_i. \end{aligned} \quad (10.139)$$

因为 Hilbert 矩阵对称, 列条件同样成立。应用 Schur 检验, 得到算子范数不超过  $\pi$ 。 □



第三问：上界. 对任意  $\mathbf{x} \in \mathbb{R}^n$ ，把它补零扩充为  $\ell^2$  序列. 由 Hilbert 不等式， $\mathbf{x}^\top H_n \mathbf{x} \leq \pi \|\mathbf{x}\|_2^2$ . 故

$$\rho(H_n) = \lambda_{\max}(H_n) \leq \pi. \quad (10.140)$$

□

第三问：构造下界测试向量. 取

$$x_i = \frac{1}{\sqrt{i}}, \quad i = 1, \dots, n. \quad (10.141)$$

则

$$\|\mathbf{x}\|_2^2 = \sum_{i=1}^n \frac{1}{i} = H_n^{(\text{harm})}, \quad (10.142)$$

其中  $H_n^{(\text{harm})}$  为调和数，满足

$$H_n^{(\text{harm})} \sim \log n. \quad (10.143)$$

分子为

$$\begin{aligned} \mathbf{x}^\top H_n \mathbf{x} &= \sum_{i,j=1}^n \frac{1}{\sqrt{i}\sqrt{j}(i+j-1)} \\ &\geq \sum_{i,j=1}^n \frac{1}{\sqrt{i}\sqrt{j}(i+j)}. \end{aligned} \quad (10.144)$$

定义  $F(x, y) = \frac{1}{\sqrt{xy}(x+y)}$ .  $F$  对  $x, y$  均单调递减，因此  $F(i, j) \geq \int_i^{i+1} \int_j^{j+1} F(x, y) \, dy \, dx$ . 求和得

$$\mathbf{x}^\top H_n \mathbf{x} \geq \int_1^{n+1} \int_1^{n+1} \frac{dx \, dy}{\sqrt{xy}(x+y)}. \quad (10.145)$$

令  $x = e^u$ ,  $y = e^v$ ,  $0 \leq u, v \leq L$ ,  $L = \log(n+1)$ . 则

$$\begin{aligned} \frac{dx \, dy}{\sqrt{xy}(x+y)} &= \frac{e^{u+v}}{e^{(u+v)/2}(e^u + e^v)} \, du \, dv \\ &= \frac{du \, dv}{2 \cosh\left(\frac{u-v}{2}\right)}. \end{aligned} \quad (10.146)$$

故下界积分为


$$\begin{aligned} I(L) &= \int_0^L \int_0^L \frac{du \, dv}{2 \cosh\left(\frac{u-v}{2}\right)} \\ &= \int_{-L}^L \frac{L - |s|}{2 \cosh(s/2)} \, ds. \end{aligned} \quad (10.147)$$

于是

$$\frac{I(L)}{L} = \int_{-\infty}^{\infty} \left(1 - \frac{|s|}{L}\right)_+ \frac{ds}{2 \cosh(s/2)}. \quad (10.148)$$

被积函数由可积函数  $\frac{1}{2 \cosh(s/2)}$  控制. 由控制收敛定理，

$$\begin{aligned} \lim_{L \rightarrow \infty} \frac{I(L)}{L} &= \int_{-\infty}^{\infty} \frac{ds}{2 \cosh(s/2)} \\ &= \int_{-\infty}^{\infty} \frac{dt}{\cosh t} \\ &= \pi. \end{aligned} \quad (10.149)$$



这里使用变量代换  $t = s/2$  及经典积分  $\int_{-\infty}^{\infty} \operatorname{sech} t \, dt = \pi$ 。

由于  $L = \log(n+1) \sim \log n$  且调和数也渐近于  $\log n$ , 有

$$\liminf_{n \rightarrow \infty} \frac{\mathbf{x}^\top H_n \mathbf{x}}{\|\mathbf{x}\|_2^2} \geq \pi. \quad (10.150)$$

由 Rayleigh 商变分原理,  $\rho(H_n) \geq \frac{\mathbf{x}^\top H_n \mathbf{x}}{\|\mathbf{x}\|_2^2}$ . 故  $\liminf_{n \rightarrow \infty} \rho(H_n) \geq \pi$ . 结合上界  $\rho(H_n) \leq \pi$ , 得到

$$\lim_{n \rightarrow \infty} \rho(H_n) = \pi. \quad (10.151)$$

□

#### 复杂度说明

Hilbert 矩阵为稠密矩阵:

- 显式存储需要  $O(n^2)$  空间;
- 一次普通矩阵-向量乘法需要  $O(n^2)$  运算;
- 其最大特征值趋于  $\pi$ , 但最小特征值迅速趋于 0, 因而线性方程组  $H_n \mathbf{x} = \mathbf{b}$  极度病态;
- 对 Hilbert 矩阵, 残差很小尤其不能替代前向误差分析。

#### 易错点与反例

1. 只说明  $H_n$  元素全正不能推出正定;
2. 主子矩阵交错只能直接给出非减, 严格递增还需额外论证;
3. Gershgorin 圆盘不能给出精确极限  $\pi$ ;
4. 证明上界  $\pi$  时不能把无限 Hilbert 矩阵的范数结论无说明地直接引用;
5. 证明下界时测试向量必须归一化或明确除以其二范数平方。

## 10.10 补充训练题: 奇偶结构矩阵的范数与矩阵级数

完整题目叙述: [NLA-Set]

设  $A$  为  $2n$  阶矩阵,

$$a_{ij} = \begin{cases} 1, & i+j \text{ 为偶数,} \\ 0, & i+j \text{ 为奇数.} \end{cases} \quad (10.152)$$

证明  $\|A\|_F = \|A\|_\infty = n$ , 以及

$$\sum_{k=1}^{\infty} \left(\frac{1}{2n}\right)^k A^k = \frac{1}{n} A. \quad (10.153)$$

(原题如此, 事实上第一项在标准 Frobenius 范数定义下是错的)

结构分解. 令  $P$  为把奇数指标排在前、偶数指标排在后的置换矩阵。则

$$P^\top A P = \begin{pmatrix} J_n & 0 \\ 0 & J_n \end{pmatrix}, \quad (10.154)$$

其中  $J_n = \mathbf{1}\mathbf{1}^\top$  为  $n \times n$  全 1 矩阵。

因为  $J_n^2 = nJ_n$ , 所以

$$A^2 = nA. \quad (10.155)$$

归纳得

$$A^k = n^{k-1}A, \quad k \geq 1. \quad (10.156)$$

□

范数核对. 每一行恰有  $n$  个 1, 因此

$$\|A\|_\infty = n. \quad (10.157)$$

矩阵共有  $2n \cdot n = 2n^2$  个非零元素, 且每个非零元素均为 1. 故标准 Frobenius 范数为

$$\|A\|_F = \sqrt{2n^2} = \sqrt{2}n. \quad (10.158)$$

因此题面中的  $\|A\|_F = n$  不成立, 应该是  $\sqrt{2}n$ .

另一方面,  $J_n$  的特征值为  $n, 0, \dots, 0$ , 所以  $A$  的特征值为  $n, n, 0, \dots, 0$ .  $A$  为实对称矩阵, 故

$$\|A\|_2 = \rho(A) = n. \quad (10.159)$$

题面很可能原意是  $\|A\|_2 = \|A\|_\infty = n$ , 而不是 Frobenius 范数。 □

矩阵级数. 由 式 (10.156),

$$\sum_{k=1}^{\infty} \left(\frac{1}{2n}\right)^k A^k = \sum_{k=1}^{\infty} \left(\frac{1}{2n}\right)^k n^{k-1}A = \frac{1}{n} \sum_{k=1}^{\infty} \frac{1}{2^k} A = \frac{1}{n} A. \quad (10.160)$$

故

$$\sum_{k=1}^{\infty} \left(\frac{1}{2n}\right)^k A^k = \frac{1}{n} A. \quad (10.161)$$

也可由 Neumann 级数得到:  $\|A/(2n)\|_2 = \frac{1}{2} < 1$ , 所以  $\sum_{k=1}^{\infty} \left(\frac{A}{2n}\right)^k = \frac{A}{2n} (I - \frac{A}{2n})^{-1}$ . 结合  $A^2 = nA$  可化为同一结果。 □

## 10.11 补充训练题：递推矩阵的显式逆与条件数

完整题目叙述: [NLA-Set]

令  $x_0 = 0$ , 递推

$$x_k = 2x_{k-1} + b_k, \quad k = 1, \dots, n. \quad (10.162)$$

(i) 将递推写成矩阵形式  $A\mathbf{x} = \mathbf{b}$ . 当  $b_1 = -\frac{1}{3}$ ,  $b_k = (-1)^k$ ,  $k = 2, \dots, n$ , 验证  $x_k = \frac{(-1)^k}{3}$  为精确解;

(ii) 求  $A^{-1}$ , 并计算  $A$  在矩阵 1 范数下的条件数。

第 (i) 问: 矩阵形式与精确解. 递推等价于  $x_k - 2x_{k-1} = b_k$ . 因此

$$A = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ -2 & 1 & 0 & \cdots & 0 \\ 0 & -2 & 1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & -2 & 1 \end{pmatrix}, \quad (10.163)$$

并且  $\mathbf{x} = (x_1, \dots, x_n)^\top$ ,  $\mathbf{b} = (b_1, \dots, b_n)^\top$ .

当  $k = 1$  时,  $x_1 = b_1 = -\frac{1}{3} = \frac{(-1)^1}{3}$ . 若  $x_{k-1} = \frac{(-1)^{k-1}}{3}$ , 则

$$\begin{aligned} 2x_{k-1} + b_k &= \frac{2(-1)^{k-1}}{3} + (-1)^k \\ &= (-1)^k \left( -\frac{2}{3} + 1 \right) \\ &= \frac{(-1)^k}{3}. \end{aligned} \quad (10.164)$$

故结论由归纳法成立。 □

第 (ii) 问: 显式逆. 由递推逐次代入:

$$x_1 = b_1, \quad (10.165)$$

$$x_2 = 2b_1 + b_2, \quad (10.166)$$

$$x_3 = 2^2b_1 + 2b_2 + b_3, \quad (10.167)$$

一般地,

$$x_i = \sum_{j=1}^i 2^{i-j} b_j. \quad (10.168)$$

因此

$$(A^{-1})_{ij} = \begin{cases} 2^{i-j}, & i \geq j, \\ 0, & i < j. \end{cases} \quad (10.169)$$


即

$$A^{-1} = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 2 & 1 & 0 & \cdots & 0 \\ 2^2 & 2 & 1 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & 0 \\ 2^{n-1} & 2^{n-2} & \cdots & 2 & 1 \end{pmatrix}. \quad (10.170)$$

□

第 (ii) 问: 1 范数条件数. 对  $n \geq 2$ ,  $A$  的前  $n-1$  列的绝对列和为  $1+2=3$ , 最后一列绝对列和为 1. 故

$$\|A\|_1 = 3. \quad (10.171)$$



$A^{-1}$  第  $j$  列的列和为

$$\begin{aligned}\sum_{i=j}^n 2^{i-j} &= 1 + 2 + \cdots + 2^{n-j} \\ &= 2^{n-j+1} - 1.\end{aligned}\quad (10.172)$$

最大值在  $j = 1$  处取得：

$$\|A^{-1}\|_1 = 2^n - 1. \quad (10.173)$$

因此

$$\kappa_1(A) = 3(2^n - 1), \quad n \geq 2. \quad (10.174)$$

当  $n = 1$  时,  $A = [1]$ ,  $\kappa_1(A) = 1$ 。 □

注 10.29. 虽然前代求解该下三角系统只需  $O(n)$  运算和  $O(n)$  存储, 但问题条件数随  $n$  指数增长:  $\kappa_1(A) \asymp 3 \cdot 2^n$ 。因此算法成本低并不意味着问题条件良好。

#### 易错点与反例

本题必须区分：

- 前代算法本身的运算复杂度为  $O(n)$ ;
- 线性系统的条件数却为  $O(2^n)$ ;
- 病态性属于问题, 不是由前代算法的线性复杂度决定。

## 10.12 补充训练题：循环双对角矩阵的统一可逆界

完整题目叙述：[NLA-Set]

给出  $n \times n$  矩阵


$$A_n(r) = \begin{pmatrix} 1 & r & 0 & \cdots & 0 \\ 0 & 1 & r & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & 1 & r \\ r & 0 & \cdots & 0 & 1 \end{pmatrix}, \quad (10.175)$$

求  $r$  满足的充要条件, 使得对  $A_n(r)\mathbf{x} = \mathbf{b}$  有

$$\|\mathbf{x}\|_2 \leq C \|\mathbf{b}\|_2, \quad (10.176)$$

其中  $C$  与维数  $n$  无关。

Fourier 对角化. 令  $P_n$  为循环移位矩阵:  $P_n \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} x_2 \\ x_3 \\ \vdots \\ x_1 \end{pmatrix}$ 。则

$$A_n(r) = I + rP_n. \quad (10.177)$$




$P_n$  为酉矩阵, 可由离散 Fourier 矩阵对角化。其特征值为  $n$  次单位根  $\omega_k = e^{2\pi i k/n}$ ,  $k = 0, \dots, n-1$ 。所以  $A_n(r)$  正规, 特征值为

$$\lambda_k = 1 + r\omega_k. \quad (10.178)$$

故

$$\sigma_{\min}(A_n(r)) = \min_{0 \leq k < n} |1 + r\omega_k|. \quad (10.179)$$

□

充分条件. 由反三角不等式,  $|1 + r\omega_k| \geq ||r| - 1|$ 。因此若

$$|r| \neq 1, \quad (10.180)$$

则  $\sigma_{\min}(A_n(r)) \geq ||r| - 1| > 0$  对所有  $n$  一致成立。

于是

$$\begin{aligned} \|\mathbf{x}\|_2 &\leq \|A_n(r)^{-1}\|_2 \|\mathbf{b}\|_2 \\ &= \frac{1}{\sigma_{\min}(A_n(r))} \|\mathbf{b}\|_2 \\ &\leq \frac{1}{||r| - 1|} \|\mathbf{b}\|_2. \end{aligned} \quad (10.181)$$

所以可取

$$C = \frac{1}{||r| - 1|}. \quad (10.182)$$

□

必要性: 实参数情形. 若  $r = -1$ , 则  $\lambda_0 = 1 + r = 0$ , 所以  $A_n(-1)$  对所有  $n$  均奇异。

若  $r = 1$  且  $n$  为偶数, 则单位根集合包含  $-1$ , 故存在  $k = n/2$  使  $1 + \omega_k = 0$ 。因此  $A_n(1)$  奇异。

即使只取奇数  $n$ , 也有单位根趋近  $-1$ , 并且  $\sigma_{\min}(A_n(1)) \rightarrow 0$ 。所以不存在与  $n$  无关的统一常数  $C$ 。

因此, 对实  $r$ , 在所有  $n$  上一致成立式 (10.176) 的自然充要条件为

$$|r| \neq 1. \quad (10.183)$$

□



# 第十一章 Gaussian 消元、LU/PLU、Cholesky、QR、最小二乘与舍入误差

## 11.1 直接法统一框架与三角方程求解

### 11.1.1 知识点一：直接法的输入、输出与基本路线

【重要性等级】 **S 级**。考虑线性方程组

$$Ax = b, A \in \mathbb{F}^{n \times n}, b \in \mathbb{F}^n, \quad (11.1)$$

其中  $\mathbb{F} \in \{\mathbb{R}, \mathbb{C}\}$ 。

本部分默认：

1. 若未特别说明， $A$  为非奇异稠密矩阵；
2. 对复矩阵使用共轭转置  $A^H$ ；
3. 所有误差界均说明所用范数；
4. 算法是否稳定与问题是否病态必须分别讨论；
5. 不显式形成  $A^{-1}$  来求单个右端项。

直接法的典型路线为

$$A \longrightarrow \text{结构化分解} \longrightarrow \text{一个或多个三角方程} \longrightarrow x. \quad (11.2)$$

主要分解包括：

$$PA = LU, \quad \text{一般非奇异矩阵}; \quad (11.3)$$

$$A = R^H R, \quad \text{Hermitian 正定矩阵}; \quad (11.4)$$

$$A = QR, \quad \text{正交/酉三角化}; \quad (11.5)$$

$$A = U\Sigma V^H, \quad \text{一般矩阵的 SVD, 第 12 部分详述}. \quad (11.6)$$

### 11.1.2 知识点二：前代与回代

设  $L = (\ell_{ij})$  为非奇异下三角矩阵。前代按

$$x_i = \frac{b_i - \sum_{j=1}^{i-1} \ell_{ij} x_j}{\ell_{ii}}, \quad i = 1, \dots, n \quad (11.7)$$



依次求解。

设  $U = (u_{ij})$  为非奇异上三角矩阵。回代按

$$x_i = \frac{b_i - \sum_{j=i+1}^n u_{ij}x_j}{u_{ii}}, \quad i = n, n-1, \dots, 1 \quad (11.8)$$

逆序求解。

---

#### Algorithm 35 下三角方程的前代

---

**Input:** 非奇异下三角矩阵  $L \in \mathbb{F}^{n \times n}$ ; 右端项  $\mathbf{b} \in \mathbb{F}^n$

**Output:** 满足  $L\mathbf{x} = \mathbf{b}$  的  $\mathbf{x}$

- 1: **for**  $i = 1, 2, \dots, n$  **do**
  - 2:      $s_i \leftarrow \sum_{j=1}^{i-1} \ell_{ij}x_j$
  - 3:      $x_i \leftarrow \frac{b_i - s_i}{\ell_{ii}}$
  - 4: **end for**
  - 5: **Stopping criterion:** 计算完  $x_n$
  - 6: **Complexity:** 一般下三角矩阵约  $n^2$  个 FLOP; 单位下三角矩阵不需要除法; 额外存储  $O(n)$ , 允许覆盖  $\mathbf{b}$
- 

---

#### Algorithm 36 上三角方程的回代

---

**Input:** 非奇异上三角矩阵  $U \in \mathbb{F}^{n \times n}$ ; 右端项  $\mathbf{b} \in \mathbb{F}^n$

**Output:** 满足  $U\mathbf{x} = \mathbf{b}$  的  $\mathbf{x}$

- 1: **for**  $i = n, n-1, \dots, 1$  **do**
  - 2:      $s_i \leftarrow \sum_{j=i+1}^n u_{ij}x_j$
  - 3:      $x_i \leftarrow \frac{b_i - s_i}{u_{ii}}$
  - 4: **end for**
  - 5: **Stopping criterion:** 计算完  $x_1$
  - 6: **Complexity:** 一般上三角矩阵约  $n^2$  个 FLOP; 额外存储  $O(n)$ , 允许覆盖  $\mathbf{b}$
- 

若有  $s$  个右端项, 即  $AX = B$ ,  $B \in \mathbb{F}^{n \times s}$ , 在分解已知后, 三角求解成本为

$$O(n^2s). \quad (11.9)$$

这正是“先分解、后重复求解”比重复消元更经济的原因。

### 11.1.3 知识点三: 三角求解的后向稳定性

记单位舍入误差为  $u$ , 并定义

$$\gamma_k = \frac{ku}{1 - ku}, \quad ku < 1. \quad (11.10)$$

标准浮点点积满足

$$\text{fl} \left( \sum_{j=1}^k a_j b_j \right) = \sum_{j=1}^k a_j b_j (1 + \theta_j), \quad |\theta_j| \leq \gamma_k. \quad (11.11)$$

**定理 11.1** (回代的分量后向稳定性). 设  $U$  为非奇异上三角矩阵,  $\hat{\mathbf{x}}$  为浮点回代计算结果。若运算中未发生溢出或下溢, 则存在上三角扰动  $\Delta U$  使

$$(U + \Delta U)\hat{\mathbf{x}} = \mathbf{b}, \quad (11.12)$$



并且逐分量有

$$|\Delta U| \leq \gamma_n |U|. \quad (11.13)$$

因此在任意单调矩阵范数下,

$$\frac{\|\Delta U\|}{\|U\|} \leq \gamma_n \frac{\|U\|}{\|U\|}. \quad (11.14)$$

证明. 第  $i$  行的计算为

$$\hat{x}_i = \text{fl} \left[ \frac{b_i - \text{fl} \left( \sum_{j=i+1}^n u_{ij} \hat{x}_j \right)}{u_{ii}} \right]. \quad (11.15)$$

由浮点点积模型及一次减法、一次除法的舍入模型, 可把该等式改写为

$$(u_{ii} + \delta u_{ii}) \hat{x}_i + \sum_{j=i+1}^n (u_{ij} + \delta u_{ij}) \hat{x}_j = b_i, \quad (11.16)$$

其中  $|\delta u_{ij}| \leq \gamma_n |u_{ij}|$ . 把各行扰动组合为上三角矩阵  $\Delta U$ , 即得 式 (11.12) and (11.13).  $\square$

同理, 前代也是分量后向稳定的。

若原问题条件数为  $\kappa(U)$ , 则典型前向误差满足

$$\frac{\|\hat{\mathbf{x}} - \mathbf{x}\|}{\|\mathbf{x}\|} = O(\kappa(U)nu). \quad (11.17)$$

#### 易错点与反例

“三角求解后向稳定”不意味着当  $U$  病态时前向误差仍小。

正确逻辑是 小后向误差 + 条件数  $\implies$  前向误差界。

## 11.2 Gaussian 消元与 LU 分解

### 11.2.1 知识点四：一步消元与消元矩阵

设

$$A = \begin{pmatrix} a_{11} & \mathbf{a}_{12}^H \\ \mathbf{a}_{21} & A_{22} \end{pmatrix}, \quad a_{11} \neq 0. \quad (11.18)$$

定义乘子

$$\ell = \frac{\mathbf{a}_{21}}{a_{11}}, \quad (11.19)$$

以及消元矩阵

$$M_1 = \begin{pmatrix} 1 & 0 \\ -\ell & I \end{pmatrix}. \quad (11.20)$$

则

$$M_1 A = \begin{pmatrix} a_{11} & \mathbf{a}_{12}^H \\ 0 & A_{22} - \ell \mathbf{a}_{12}^H \end{pmatrix}. \quad (11.21)$$

其中

$$S = A_{22} - \frac{\mathbf{a}_{21} \mathbf{a}_{12}^H}{a_{11}} \quad (11.22)$$

称为  $a_{11}$  的 Schur 补。



消元矩阵的逆为

$$M_1^{-1} = \begin{pmatrix} 1 & 0 \\ \ell & I \end{pmatrix}. \quad (11.23)$$

连续执行  $n-1$  步消元:

$$M_{n-1} \cdots M_2 M_1 A = U, \quad (11.24)$$

其中  $U$  为上三角矩阵。因此

$$A = M_1^{-1} M_2^{-1} \cdots M_{n-1}^{-1} U = LU. \quad (11.25)$$

### 11.2.2 知识点五: LU 存在唯一性

定理 11.2 (无选主元 LU 分解的存在唯一性). 设  $A \in \mathbb{F}^{n \times n}$  非奇异. 存在唯一分解

$$A = LU, \quad (11.26)$$

其中  $L$  为单位下三角矩阵、 $U$  为非奇异上三角矩阵, 当且仅当所有顺序主子式

$$\Delta_k = \det A(1:k, 1:k) \neq 0, \quad k = 1, \dots, n. \quad (11.27)$$

证明. 若  $A = LU$ , 则  $A(1:k, 1:k) = L_k U_k$ , 其中  $L_k$  单位下三角,  $U_k$  上三角. 故  $\Delta_k = \prod_{j=1}^k u_{jj}$ . 因为  $U$  非奇异, 每个  $u_{jj} \neq 0$ , 所以  $\Delta_k \neq 0$ .

反之, 若所有顺序主子式非零, 则每一步 Gaussian 消元的主元

$$u_{kk} = \frac{\Delta_k}{\Delta_{k-1}}, \quad \Delta_0 := 1, \quad (11.28)$$

均非零, 消元可以无交换地完成, 从而得到  $A = LU$ .

最后证明唯一性. 若  $A = L_1 U_1 = L_2 U_2$ , 则  $L_2^{-1} L_1 = U_2 U_1^{-1}$ . 左端为单位下三角矩阵, 右端为上三角矩阵; 同时具有这两种结构的矩阵只能是  $I$ . 故  $L_1 = L_2$ ,  $U_1 = U_2$ .  $\square$

注 11.3. 非奇异不自动保证无选主元 LU 算法可执行. 例如  $A = \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix}$  非奇异, 但第一个主元为零. 交换两行后即可继续, 这正是 PLU 分解的动机.

### 11.2.3 知识点六: Doolittle 递推公式

设  $A = LU$ , 其中  $L$  单位下三角. 对  $k = 1, \dots, n$ , 有

$$u_{kj} = a_{kj} - \sum_{s=1}^{k-1} \ell_{ks} u_{sj}, \quad j = k, \dots, n, \quad (11.29)$$

$$\ell_{ik} = \frac{a_{ik} - \sum_{s=1}^{k-1} \ell_{is} u_{sk}}{u_{kk}}, \quad i = k+1, \dots, n. \quad (11.30)$$

---

#### Algorithm 37 Gaussian 消元/无选主元 LU 分解

---

**Input:**  $A \in \mathbb{F}^{n \times n}$ ; 假设全部消元主元非零

**Output:** 单位下三角  $L$  与上三角  $U$ , 满足  $A = LU$

1: **Initialization:**  $U \leftarrow A$ ,  $L \leftarrow I$

2: **for**  $k = 1, 2, \dots, n-1$  **do**



```

3:   if  $u_{kk} = 0$  then
4:       报告“零主元：无选主元 LU 失败”
5:   end if
6:   for  $i = k + 1, \dots, n$  do
7:        $\ell_{ik} \leftarrow u_{ik}/u_{kk}$ 
8:        $u_{i,k:n} \leftarrow u_{i,k:n} - \ell_{ik}u_{k,k:n}$ 
9:   end for
10: end for
11: Stopping criterion: 得到上三角  $U$ 
12: Complexity: 分解约  $\frac{2}{3}n^3 + O(n^2)$  个 FLOP；存储  $O(n^2)$ ；可把  $L$  的严格下三角部分与  $U$  共同覆盖存入原矩阵

```

利用分解求解  $Ax = b$ :

$$Ax = b \iff \begin{cases} Ly = b, \\ Ux = y. \end{cases} \quad (11.31)$$

总成本为

$$\frac{2}{3}n^3 + O(n^2). \quad (11.32)$$

若分解已经完成，每增加一个右端项只需  $O(n^2)$  工作。

#### 11.2.4 基础例题：无选主元消元为何会数值失败

完整题目叙述

设

$$A_\varepsilon = \begin{pmatrix} \varepsilon & 1 \\ 1 & 1 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad 0 < \varepsilon \ll 1. \quad (11.33)$$

1. 求无选主元 LU 分解；
2. 说明小主元为什么导致大乘子和严重消去；
3. 说明交换两行后的计算为何更稳定。

详细解答. 无选主元时  $\ell_{21} = \frac{1}{\varepsilon}$ 。因此

$$L = \begin{pmatrix} 1 & 0 \\ \varepsilon^{-1} & 1 \end{pmatrix}, \quad U = \begin{pmatrix} \varepsilon & 1 \\ 0 & 1 - \varepsilon^{-1} \end{pmatrix}. \quad (11.34)$$

消元后的右端项为

$$\tilde{b}_2 = 2 - \varepsilon^{-1}. \quad (11.35)$$

精确解为

$$x_1 = \frac{1}{1 - \varepsilon}, \quad (11.36)$$

$$x_2 = \frac{1 - 2\varepsilon}{1 - \varepsilon}. \quad (11.37)$$

当  $\varepsilon$  很小时,  $x_1 \approx 1$ ,  $x_2 \approx 1$ 。



但是无选主元计算中需要形成两个大小约为  $\varepsilon^{-1}$  的量:  $1 - \varepsilon^{-1}$ ,  $2 - \varepsilon^{-1}$ 。它们的商接近 1, 而随后计算  $x_1 = \frac{1-x_2}{\varepsilon}$  会把  $x_2$  中的绝对误差放大约  $\varepsilon^{-1}$  倍。

例如在低精度算术中, 若  $\varepsilon = 10^{-4}$ , 两个大数都可能舍入为  $-10^4$ , 从而得到  $\hat{x}_2 = 1$ ,  $\hat{x}_1 = 0$ , 尽管精确  $x_1 \approx 1$ 。

交换两行, 令  $P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ ,  $PA_\varepsilon = \begin{pmatrix} 1 & 1 \\ \varepsilon & 1 \end{pmatrix}$ 。此时乘子为  $\ell_{21} = \varepsilon$ , 不会产生大中间量。这说明选主元的目标不是改变问题条件数, 而是控制算法中的元素增长。□

## 11.3 选主元、PLU 分解、增长因子与稳定性

### 11.3.1 知识点七: 部分选主元与完全选主元

在第  $k$  步, 部分选主元选择

$$p_k \in \arg \max_{i=k, \dots, n} |u_{ik}|, \quad (11.38)$$

并交换第  $k$  行与第  $p_k$  行。

完全选主元则选择

$$(p_k, q_k) \in \arg \max_{i, j \geq k} |u_{ij}|, \quad (11.39)$$

同时交换行与列。

两者分别产生

$$PA = LU, \quad (11.40)$$

$$PAQ = LU. \quad (11.41)$$

部分选主元的搜索总成本为  $O(n^2)$ , 相对  $\frac{2}{3}n^3$  的消元主成本较低; 完全选主元的搜索本身为  $O(n^3)$ 。

**定理 11.4** (PLU 分解的存在性). 对任意非奇异矩阵  $A \in \mathbb{F}^{n \times n}$ , 存在置换矩阵  $P$ 、单位下三角矩阵  $L$  和非奇异上三角矩阵  $U$  使  $PA = LU$ 。

#### 证明思路

每一步在当前非零列中选择一个非零元素作为主元。若当前尾部子矩阵的第一列全部为零, 则该尾部子矩阵必奇异, 进而原矩阵奇异; 这与假设矛盾。故部分选主元总能找到非零主元并完成消元。

#### Algorithm 38 带部分选主元的 PLU 分解

**Input:** 非奇异矩阵  $A \in \mathbb{F}^{n \times n}$

**Output:**  $P, L, U$  满足  $PA = LU$

- 1: **Initialization:**  $U \leftarrow A$ ,  $L \leftarrow I$ ,  $P \leftarrow I$
- 2: **for**  $k = 1, 2, \dots, n-1$  **do**
- 3:    $p \leftarrow \arg \max_{i=k, \dots, n} |u_{ik}|$
- 4:   **if**  $u_{pk} = 0$  **then**
- 5:     报告“矩阵奇异”
- 6:   **end if**
- 7:   交换  $U(k, k:n) \longleftrightarrow U(p, k:n)$
- 8:   交换  $P(k, :) \longleftrightarrow P(p, :)$





```

9:   if  $k > 1$  then
10:       交换  $L(k, 1 : k-1) \longleftrightarrow L(p, 1 : k-1)$ 
11:   end if
12:   for  $i = k+1, \dots, n$  do
13:        $\ell_{ik} \leftarrow u_{ik}/u_{kk}$ 
14:        $U(i, k : n) \leftarrow U(i, k : n) - \ell_{ik}U(k, k : n)$ 
15:   end for
16: end for
17: Stopping criterion: 得到  $PA = LU$ 
18: Complexity: 分解约  $\frac{2}{3}n^3 + O(n^2)$  个 FLOP; 搜索主元  $O(n^2)$ ; 存储  $O(n^2)$ ; 部分选主元保证  $|\ell_{ik}| \leq 1$ 

```

#### 易错点与反例

交换  $U$  的行时，必须同步交换：

- 置换矩阵  $P$  的对应行；
- $L$  中已经计算出的前  $k-1$  列。

若只交换当前工作矩阵而不交换  $L$  的历史乘子，最终一般不再满足  $PA = LU$ 。

### 11.3.2 知识点八：增长因子

设  $A^{(k)}$  为第  $k$  步消元开始时的工作矩阵。定义部分选主元的元素增长因子

$$\rho_n(A) = \frac{\max_{i,j,k} |a_{ij}^{(k)}|}{\max_{i,j} |a_{ij}|}. \quad (11.42)$$

也常用等价的  $\rho_n(A) \asymp \frac{\max_{i,j} |u_{ij}|}{\max_{i,j} |a_{ij}|}$ 。

部分选主元保证  $|\ell_{ik}| \leq 1$ ，但不能保证  $U$  中的元素不增长。

经典最坏情形上界为

$$\rho_n(A) \leq 2^{n-1}. \quad (11.43)$$

该上界可以达到。

### 11.3.3 综合例题：Wilkinson 矩阵的指数增长因子

#### 完整题目叙述

定义  $n \times n$  矩阵

$$W_n = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 & 1 \\ -1 & 1 & 0 & \cdots & 0 & 1 \\ -1 & -1 & 1 & \cdots & 0 & 1 \\ \vdots & \vdots & \ddots & \ddots & \vdots & \vdots \\ -1 & -1 & \cdots & -1 & 1 & 1 \\ -1 & -1 & \cdots & -1 & -1 & 1 \end{pmatrix}. \quad (11.44)$$

假设部分选主元在出现并列最大值时不交换当前行。证明其增长因子为  $\rho_n(W_n) = 2^{n-1}$ 。

证明. 第一列中所有候选主元的绝对值均为 1, 按题设选择  $w_{11} = 1$ 。消去第一列后, 第  $2, \dots, n$  行最后一列变为  $1 - (-1) \cdot 1 = 2$ 。

第二步仍选择对角元 1。消去第二列后, 第  $3, \dots, n$  行最后一列变为  $2 - (-1) \cdot 2 = 4$ 。

归纳地, 完成第  $k$  步消元后, 第  $k+1, \dots, n$  行的最后一列均为  $2^k$ 。因此最终上三角矩阵的最后一个对角元为  $u_{nn} = 2^{n-1}$ 。原矩阵所有元素的最大模为 1, 故  $\rho_n(W_n) = \frac{2^{n-1}}{1} = 2^{n-1}$ 。□

### 11.3.4 知识点九: PLU 的后向误差

定理 11.5 (浮点 Gaussian 消元的分量后向误差). 设带部分选主元的 Gaussian 消元得到  $PA \approx \hat{L}\hat{U}$ 。在标准浮点模型下, 存在扰动  $\Delta A$  使

$$P(A + \Delta A) = \hat{L}\hat{U}, \quad (11.45)$$

并有

$$|\Delta A| \leq \gamma_n |\hat{L}||\hat{U}|. \quad (11.46)$$

因此

$$\frac{\|\Delta A\|}{\|A\|} \leq \gamma_n \frac{\|\hat{L}\|\|\hat{U}\|}{\|A\|}. \quad (11.47)$$

由于部分选主元给出  $|\ell_{ij}| \leq 1$ , 可以把上式粗略估计为

$$\frac{\|\Delta A\|_\infty}{\|A\|_\infty} \lesssim n^2 \gamma_n \rho_n(A). \quad (11.48)$$

因此, 部分选主元的稳定性核心是增长因子  $\rho_n(A)$ 。当  $\rho_n(A)$  温和时, 算法后向稳定; 当  $\rho_n(A)$  极大时, 后向误差可能显著放大。

结合前代、回代的后向稳定性, 最终计算解  $\hat{x}$  可解释为邻近系统的精确解:

$$(A + \Delta A_{\text{sol}})\hat{x} = b, \quad (11.49)$$

其中

$$\frac{\|\Delta A_{\text{sol}}\|}{\|A\|} = O(n^c \rho_n(A)u) \quad (11.50)$$

对某个低次多项式因子  $n^c$  成立。

#### 易错点与反例

不能无条件写: 部分选主元 Gaussian 消元总是后向稳定。

严谨表述应为: 后向误差由增长因子控制; 最坏情形可很大, 但实践中通常温和。

## 11.4 Cholesky 与 $LDL^H$ 分解

### 11.4.1 知识点十: Cholesky 存在唯一性

【重要性等级】 **S 级**。

定理 11.6 (Cholesky 分解). 设  $A \in \mathbb{C}^{n \times n}$  为 Hermitian 正定矩阵. 则存在唯一上三角矩阵  $R$ , 其对角元为正实数, 并满足

$$\boxed{A = R^H R}. \quad (11.51)$$

等价地, 存在唯一具有正对角元的下三角矩阵  $L$  使

$$A = LL^H. \quad (11.52)$$

证明. 对  $n$  作归纳. 将  $A$  分块为

$$A = \begin{pmatrix} a_{11} & \mathbf{w}^H \\ \mathbf{w} & B \end{pmatrix}. \quad (11.53)$$

由正定性,  $a_{11} > 0$ . 令  $r_{11} = \sqrt{a_{11}}$ ,  $\mathbf{r} = \frac{\mathbf{w}}{r_{11}}$ . 则

$$A = \begin{pmatrix} r_{11} & \mathbf{r}^H \\ 0 & I \end{pmatrix}^H \begin{pmatrix} 1 & 0 \\ 0 & S \end{pmatrix} \begin{pmatrix} r_{11} & \mathbf{r}^H \\ 0 & I \end{pmatrix}, \quad (11.54)$$

其中 Schur 补为

$$S = B - \frac{\mathbf{w}\mathbf{w}^H}{a_{11}}. \quad (11.55)$$

对任意  $\mathbf{z} \neq 0$ , 取  $\xi = -\frac{\mathbf{w}^H \mathbf{z}}{a_{11}}$ , 则

$$\mathbf{z}^H S \mathbf{z} = \begin{pmatrix} \bar{\xi} & \mathbf{z}^H \end{pmatrix} A \begin{pmatrix} \xi \\ \mathbf{z} \end{pmatrix} > 0. \quad (11.56)$$

所以  $S$  仍为 Hermitian 正定矩阵. 由归纳假设,  $S = R_2^H R_2$ . 于是  $R = \begin{pmatrix} r_{11} & \mathbf{r}^H \\ 0 & R_2 \end{pmatrix}$  满足  $A = R^H R$ .

唯一性可由正对角约束与逐列比较得到; 也可设  $R_1^H R_1 = R_2^H R_2$ , 则  $R_2 R_1^{-1}$  既为上三角, 又为酉矩阵, 且对角元为正, 故只能是  $I$ .  $\square$

### 11.4.2 知识点十一: Cholesky 递推与算法

由  $A = R^H R$  逐项比较得到

$$r_{kk} = \sqrt{a_{kk} - \sum_{s=1}^{k-1} |r_{sk}|^2}, \quad (11.57)$$

$$r_{kj} = \frac{a_{kj} - \sum_{s=1}^{k-1} \overline{r_{sk}} r_{sj}}{r_{kk}}, \quad j = k+1, \dots, n. \quad (11.58)$$

---

#### Algorithm 39 上三角 Cholesky 分解

---

**Input:** Hermitian 正定矩阵  $A \in \mathbb{C}^{n \times n}$

**Output:** 上三角  $R$ , 满足  $A = R^H R$  且  $r_{kk} > 0$

- 1: **for**  $k = 1, 2, \dots, n$  **do**
- 2:    $d_k \leftarrow a_{kk} - \sum_{s=1}^{k-1} |r_{sk}|^2$
- 3:   **if**  $d_k \leq 0$  **then**
- 4:     报告“矩阵不是正定矩阵, 或舍入误差导致分解失败”
- 5:   **end if**



- 6:  $r_{kk} \leftarrow \sqrt{d_k}$
- 7: **for**  $j = k + 1, \dots, n$  **do**
- $a_{kj} \leftarrow \sum_{s=1}^{k-1} r_{sk} r_{sj}$
- 8:  $r_{kj} \leftarrow \frac{a_{kj}}{r_{kk}}$
- 9: **end for**
- 10: **end for**
- 11: **Stopping criterion:** 计算完第  $n$  行
- 12: **Complexity:** 实稠密矩阵约  $\frac{1}{3}n^3 + O(n^2)$  个 FLOP; 约为一般 LU 的一半; 存储可只保留一个三角部分, 为  $\frac{1}{2}n(n+1)$  个数

用 Cholesky 解方程:

$$Ax = b \iff \begin{cases} R^H y = b, \\ Rx = y. \end{cases} \quad (11.59)$$

### 11.4.3 基础例题: Cholesky 分解与求解

完整题目叙述

对

$$A = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 5 & 1 \\ 2 & 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 8 \\ 8 \\ 6 \end{pmatrix}, \quad (11.60)$$

求 Cholesky 分解并解  $Ax = b$ 。

详细解答. 首先  $r_{11} = \sqrt{4} = 2$ ,  $r_{12} = 2/2 = 1$ ,  $r_{13} = 2/2 = 1$ 。其次  $r_{22} = \sqrt{5 - r_{12}^2} = 2$ , 以及  $r_{23} = \frac{1 - r_{12}r_{13}}{r_{22}} = 0$ 。最后  $r_{33} = \sqrt{3 - r_{13}^2 - r_{23}^2} = \sqrt{2}$ 。所以

$$R = \begin{pmatrix} 2 & 1 & 1 \\ 0 & 2 & 0 \\ 0 & 0 & \sqrt{2} \end{pmatrix}, \quad A = R^T R. \quad (11.61)$$

先解  $R^T y = b$ 。得到

$$\begin{aligned} 2y_1 &= 8, & y_1 &= 4, \\ y_1 + 2y_2 &= 8, & y_2 &= 2, \\ y_1 + \sqrt{2}y_3 &= 6, & y_3 &= \sqrt{2}. \end{aligned}$$

再解  $Rx = y$ 。由回代:

$$\begin{aligned} \sqrt{2}x_3 &= \sqrt{2}, & x_3 &= 1, \\ 2x_2 &= 2, & x_2 &= 1, \\ 2x_1 + x_2 + x_3 &= 4, & x_1 &= 1. \end{aligned}$$

故

$$\boxed{x = (1, 1, 1)^T}. \quad (11.62)$$

□



#### 11.4.4 知识点十二: Cholesky 稳定性与失败情形

定理 11.7 (Cholesky 分解的后向稳定性). 设  $A = A^H \succ 0$ , 浮点 Cholesky 算法成功得到  $\hat{R}$ . 则存在 Hermitian 扰动  $\Delta A$  使

$$\hat{R}^H \hat{R} = A + \Delta A, \quad (11.63)$$

且

$$|\Delta A| \leq \gamma_{n+1} |\hat{R}^H| |\hat{R}|. \quad (11.64)$$

从而通常有

$$\frac{\|\Delta A\|_2}{\|A\|_2} = O(nu). \quad (11.65)$$

Cholesky 分解无需选主元且通常后向稳定, 原因是  $\|R\|_2^2 = \|R^H R\|_2 = \|A\|_2$ , 因子不会像一般 LU 那样产生不受控增长。

但是以下情形不能直接使用普通 Cholesky:

- $A$  仅对称但不正定;
- $A$  半正定且秩亏;
- 舍入误差使理论上很小的正主元计算为非正数;
- 需要保持稀疏性而自然排序造成大量填充。

#### 11.4.5 知识点十三: $LDL^H$ 分解

对 Hermitian 矩阵, 可考虑

$$A = LDL^H, \quad (11.66)$$

其中  $L$  单位下三角,  $D$  为实对角矩阵。

若  $A \succ 0$ , 则  $d_i > 0$ , 且  $R = D^{1/2} L^H$  可恢复 Cholesky 分解。

对 Hermitian 不定矩阵, 普通无选主元  $LDL^H$  可能不稳定甚至失败。稳定实现通常采用对称置换:

$$P^T A P = LDL^T, \quad (11.67)$$

其中  $D$  允许包含  $1 \times 1$  和  $2 \times 2$  对角块; 典型算法为 Bunch-Kaufman 方法。

##### 易错点与反例

$A = A^H$  不能推出 Cholesky 可用。

Cholesky 要求更强条件  $A \succ 0$ 。对称不定矩阵应使用带对称选主元的  $LDL^H$ , 而不是对负数主元强行开平方。

## 11.5 QR 分解: Gram-Schmidt、Householder 与 Givens

### 11.5.1 知识点十四: 约化 QR 与完全 QR

【重要性等级】 S 级。

设  $A \in \mathbb{C}^{m \times n}$ ,  $m \geq n$ 。



约化 QR 分解写为

$$A = \widehat{Q}R, \quad (11.68)$$

其中  $\widehat{Q} \in \mathbb{C}^{m \times n}$ ,  $\widehat{Q}^H \widehat{Q} = I_n$ , 且  $R \in \mathbb{C}^{n \times n}$  为上三角矩阵。

完全 QR 分解写为

$$A = Q \begin{pmatrix} R \\ 0 \end{pmatrix}, \quad (11.69)$$

其中  $Q \in \mathbb{C}^{m \times m}$  酉。

若  $A$  满列秩, 则  $R$  非奇异。若规定  $r_{jj} > 0$  为正实数, 则约化 QR 分解唯一。

**定理 11.8** (QR 存在唯一性). 任意  $A \in \mathbb{C}^{m \times n}$ ,  $m \geq n$ , 都存在完全 QR 分解。

若  $A$  满列秩, 并要求约化分解中  $r_{jj} > 0$ , 则约化 QR 分解唯一。

#### 证明思路

存在性可由 Householder 反射逐列将  $A$  化为上三角形得到。

唯一性: 若  $A = Q_1 R_1 = Q_2 R_2$ , 则  $Q_2^H Q_1 = R_2 R_1^{-1}$ 。左端酉, 右端上三角。上三角酉矩阵必为对角酉矩阵; 正对角约定进一步迫使其为  $I$ 。

### 11.5.2 知识点十五: 经典与修正 Gram-Schmidt

设  $A = (\mathbf{a}_1 \ \cdots \ \mathbf{a}_n)$ 。

经典 Gram-Schmidt (CGS) 按

$$r_{ij} = \mathbf{q}_i^H \mathbf{a}_j, \quad i = 1, \dots, j-1, \quad (11.70)$$

$$\mathbf{v}_j = \mathbf{a}_j - \sum_{i=1}^{j-1} r_{ij} \mathbf{q}_i, \quad (11.71)$$

$$r_{jj} = \|\mathbf{v}_j\|_2, \quad (11.72)$$

$$\mathbf{q}_j = \mathbf{v}_j / r_{jj} \quad (11.73)$$

构造。

修正 Gram-Schmidt (MGS) 把投影逐个应用:

$$\mathbf{v}_j^{(0)} = \mathbf{a}_j, \quad (11.74)$$

$$r_{ij} = \mathbf{q}_i^H \mathbf{v}_j^{(i-1)}, \quad (11.75)$$

$$\mathbf{v}_j^{(i)} = \mathbf{v}_j^{(i-1)} - r_{ij} \mathbf{q}_i, \quad i = 1, \dots, j-1, \quad (11.76)$$

$$r_{jj} = \|\mathbf{v}_j^{(j-1)}\|_2, \quad \mathbf{q}_j = \mathbf{v}_j^{(j-1)} / r_{jj}. \quad (11.77)$$

在精确算术中, CGS 与 MGS 数学上等价。在浮点算术中, 减去多个近共线投影时, CGS 可能严重丢失正交性。

典型误差量级为

$$\|I - \widehat{Q}_{\text{CGS}}^H \widehat{Q}_{\text{CGS}}\|_2 = O(u\kappa_2(A)^2), \quad (11.78)$$

$$\|I - \widehat{Q}_{\text{MGS}}^H \widehat{Q}_{\text{MGS}}\|_2 = O(u\kappa_2(A)), \quad (11.79)$$

在相应非退化假设下成立。

若  $\kappa_2(A)$  很大, MGS 也可能失去正交性。常用改进是重正交化: MGS2 = 对同一新向量再做一次 MGS 投影。

**Algorithm 40** 修正 Gram-Schmidt QR 分解**Input:** 满列秩  $A = [a_1, \dots, a_n] \in \mathbb{C}^{m \times n}$ **Output:**  $A = \hat{Q}R$ 

```

1: for  $j = 1, 2, \dots, n$  do
2:    $v \leftarrow a_j$ 
3:   for  $i = 1, 2, \dots, j-1$  do
4:      $r_{ij} \leftarrow q_i^H v$ 
5:      $v \leftarrow v - r_{ij} q_i$ 
6:   end for
7:    $r_{jj} \leftarrow \|v\|_2$ 
8:   if  $r_{jj}$  低于秩判定阈值 then
9:     报告“数值秩亏或需要列主元 QR”
10:  end if
11:   $q_j \leftarrow v/r_{jj}$ 
12: end for
13: Stopping criterion: 处理完第  $n$  列
14: Complexity: 约  $2mn^2 + O(mn)$  个实 FLOP; 存储  $O(mn + n^2)$ ; 适合逐列构造 Krylov 基, 但
    稳定性弱于 Householder

```

**11.5.3 知识点十六: Householder 反射**

给定非零向量  $x \in \mathbb{C}^s$ 。希望构造酉矩阵  $H$  使  $Hx = \alpha e_1$ ,  $|\alpha| = \|x\|_2$ 。

取

$$\alpha = -\text{phase}(x_1) \|x\|_2, \quad (11.80)$$

其中  $\text{phase}(z) = \begin{cases} z/|z|, & z \neq 0, \\ 1, & z = 0. \end{cases}$  令

$$v = x - \alpha e_1. \quad (11.81)$$

定义

$$H = I - 2 \frac{vv^H}{v^H v}. \quad (11.82)$$

则

$$H^H = H, \quad (11.83)$$

$$H^2 = I, \quad (11.84)$$

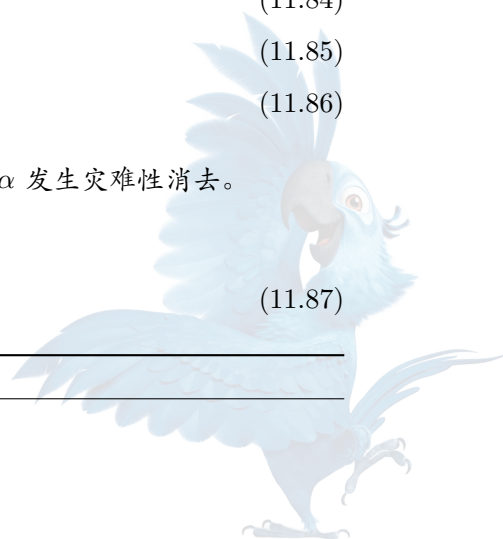
$$H^H H = I, \quad (11.85)$$

$$Hx = \alpha e_1. \quad (11.86)$$

选择  $\alpha = -\text{phase}(x_1) \|x\|_2$  而不是同相位的正号, 是为了避免  $x_1 - \alpha$  发生灾难性消去。

作用于向量  $y$  时, 不应显式形成  $H$ :

$$Hy = y - \beta v(v^H y), \quad \beta = \frac{2}{v^H v}. \quad (11.87)$$

**Algorithm 41** Householder QR 分解



**Input:**  $A \in \mathbb{C}^{m \times n}$ ,  $m \geq n$

**Output:** 反射向量及上三角  $R$ , 隐式表示  $A = \hat{Q}R$

1: **Initialization:**  $R \leftarrow A$

2: **for**  $k = 1, 2, \dots, n$  **do**

3:    $\mathbf{x} \leftarrow R(k:m, k)$

4:   选择  $\alpha \leftarrow -\text{phase}(x_1) \|\mathbf{x}\|_2$

5:    $\mathbf{v}_k \leftarrow \mathbf{x} - \alpha \mathbf{e}_1$ ,  $\beta_k \leftarrow \frac{2}{\mathbf{v}_k^H \mathbf{v}_k}$

6:    $R(k:m, k:n) \leftarrow R(k:m, k:n) - \beta_k \mathbf{v}_k [\mathbf{v}_k^H R(k:m, k:n)]$

7:   保存  $\mathbf{v}_k, \beta_k$ , 不显式形成  $Q$

8: **end for**

9: **Stopping criterion:**  $R$  的对角线以下元素全部消去

10: **Complexity:** 实稠密  $m \times n$  矩阵约  $2mn^2 - \frac{2}{3}n^3 + O(mn)$  个 FLOP; 反射向量可覆盖存入  $A$  的下三角部分; 存储  $O(mn)$

#### 11.5.4 基础例题：构造一个 Householder 反射

完整题目叙述

构造 Householder 矩阵, 将  $\mathbf{x} = (4, 3, 0)^\top$  映射到  $-5\mathbf{e}_1$ 。

详细解答. 有  $\|\mathbf{x}\|_2 = 5$ ,  $\text{phase}(x_1) = 1$ . 故  $\alpha = -5$ ,  $\mathbf{v} = \mathbf{x} - \alpha \mathbf{e}_1 = \begin{pmatrix} 9 \\ 3 \\ 0 \end{pmatrix}$ . 并且  $\mathbf{v}^\top \mathbf{v} = 90$ . 所以

$$\begin{aligned} H &= I - \frac{1}{45} \mathbf{v} \mathbf{v}^\top \\ &= \begin{pmatrix} -\frac{4}{5} & -\frac{3}{5} & 0 \\ -\frac{3}{5} & \frac{4}{5} & 0 \\ 0 & 0 & 1 \end{pmatrix}. \end{aligned} \quad (11.88)$$

直接验证:  $H\mathbf{x} = \begin{pmatrix} -5 \\ 0 \\ 0 \end{pmatrix}$ . 同时  $H^\top H = I$ ,  $H^\top = H$ . □

#### 11.5.5 知识点十七: Givens 旋转

对实数  $a, b$ , 令

$$r = \text{hypot}(a, b) = \sqrt{a^2 + b^2}, \quad c = \frac{a}{r}, \quad s = \frac{b}{r}. \quad (11.89)$$

定义

$$G = \begin{pmatrix} c & s \\ -s & c \end{pmatrix}. \quad (11.90)$$

则

$$G \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} r \\ 0 \end{pmatrix}. \quad (11.91)$$

嵌入到  $n$  维空间后,  $G(i, j; c, s)$  只修改第  $i, j$  行. 与 Householder 相比:



- Householder 一次消去一整列的多个元素;
- Givens 一次消去一个元素;
- Givens 特别适合稀疏矩阵、在线更新、QR 更新和 Hessenberg/三对角结构;
- 稠密完整 QR 中, Householder 通常更高效。

计算  $r$  时应使用稳定的  $\text{hypot}(a, b)$  实现, 避免  $a^2 + b^2$  溢出或下溢。

### 11.5.6 知识点十八: QR 算法的稳定性比较

| 方法              | 稠密复杂度                    | 稳定性特征                        | 典型用途              |
|-----------------|--------------------------|------------------------------|-------------------|
| 经典 Gram-Schmidt | 约 $2mn^2$                | 可能出现 $O(u\kappa(A)^2)$ 正交性损失 | 理论推导、条件较好的列向量     |
| 修正 Gram-Schmidt | 约 $2mn^2$                | 通常优于 CGS, 但近秩亏时仍可能失去正交性      | Arnoldi、逐列基构造     |
| MGS 重正交         | 约为 MGS 的两倍               | 通常可恢复接近机器精度的正交性              | 高精度 Krylov 基      |
| Householder     | $2mn^2 - \frac{2}{3}n^3$ | 后向稳定; 正交性可靠                  | 稠密 QR、最小二乘标准方法    |
| Givens          | 稠密情形常数较大                 | 酉变换稳定; 局部更新方便                | 稀疏 QR、在线更新、消去单元元素 |

定理 11.9 (Householder QR 的后向稳定性). 浮点 Householder 算法计算得到  $\hat{Q}, \hat{R}$  时, 可解释为存在小扰动  $\Delta A$  使

$$A + \Delta A = \hat{Q}\hat{R}, \quad (11.92)$$

且

$$\frac{\|\Delta A\|_2}{\|A\|_2} = O(mnu). \quad (11.93)$$

若  $Q$  通过反射向量隐式应用, 则其酉结构得到良好保持。

### 11.5.7 知识点十九: 用 QR 解方阵线性系统

若  $A = QR$ ,  $A \in \mathbb{C}^{n \times n}$  非奇异, 则

$$Ax = b \iff Rx = Q^H b. \quad (11.94)$$

Householder QR 加回代整体是后向稳定的: 存在  $\Delta A$  使

$$(A + \Delta A)\hat{x} = b, \quad \frac{\|\Delta A\|_2}{\|A\|_2} = O(nu). \quad (11.95)$$

但对一般稠密方阵:

- LU/PLU 分解主成本约  $\frac{2}{3}n^3$ ;
- Householder QR 主成本约  $\frac{4}{3}n^3$ ;

因此 PLU 通常快约一倍, 是一般方阵求解的标准直接法; QR 在稳定性要求高、已有 QR 结构或最小二乘问题中更自然。



## 11.6 线性最小二乘：投影、正规方程与 QR 算法

### 11.6.1 知识点二十：问题与最优性条件

考虑

$$\min_{\mathbf{x} \in \mathbb{C}^n} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2, \quad \mathbf{A} \in \mathbb{C}^{m \times n}, \quad m \geq n. \quad (11.96)$$

定义残差

$$\mathbf{r}(\mathbf{x}) = \mathbf{b} - \mathbf{A}\mathbf{x}. \quad (11.97)$$

定理 11.10 (最小二乘的等价条件). 向量  $\mathbf{x}_*$  是式 (11.96) 的最小点, 当且仅当

$$\mathbf{A}^H (\mathbf{A}\mathbf{x}_* - \mathbf{b}) = \mathbf{0}. \quad (11.98)$$

等价地,

$$\mathbf{A}^H \mathbf{A}\mathbf{x}_* = \mathbf{A}^H \mathbf{b}. \quad (11.99)$$

即残差满足

$$\mathbf{r}_* \perp \mathcal{R}(\mathbf{A}). \quad (11.100)$$

证明. 令  $\phi(\mathbf{x}) = \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2$ . 对实变量,  $\nabla \phi(\mathbf{x}) = \mathbf{A}^T (\mathbf{A}\mathbf{x} - \mathbf{b})$ . 复数情形可用方向导数或 Wirtinger 导数得到  $\mathbf{A}^H (\mathbf{A}\mathbf{x} - \mathbf{b}) = \mathbf{0}$ .

也可作纯几何证明. 设  $\mathbf{x}_*$  满足  $\mathbf{A}^H \mathbf{r}_* = \mathbf{0}$ . 对任意  $\mathbf{z}$ ,

$$\begin{aligned} \|\mathbf{b} - \mathbf{A}(\mathbf{x}_* + \mathbf{z})\|_2^2 &= \|\mathbf{r}_* - \mathbf{A}\mathbf{z}\|_2^2 \\ &= \|\mathbf{r}_*\|_2^2 + \|\mathbf{A}\mathbf{z}\|_2^2 - 2 \operatorname{Re} \langle \mathbf{r}_*, \mathbf{A}\mathbf{z} \rangle \\ &= \|\mathbf{r}_*\|_2^2 + \|\mathbf{A}\mathbf{z}\|_2^2 \geq \|\mathbf{r}_*\|_2^2. \end{aligned} \quad (11.101)$$

故  $\mathbf{x}_*$  最优。

反之, 若  $\mathbf{r}_*$  不垂直于  $\mathcal{R}(\mathbf{A})$ , 可沿某个  $\mathbf{A}\mathbf{z}$  方向减小残差范数, 与最优性矛盾。□

推论 11.11 (唯一性). 最小二乘解唯一, 当且仅当  $\operatorname{rank}(\mathbf{A}) = n$ . 此时  $\mathbf{A}^H \mathbf{A}$  为 Hermitian 正定矩阵。

若  $\mathbf{A}$  秩亏, 解集为  $\mathbf{x}_* + \mathcal{N}(\mathbf{A})$ . 最小范数最小二乘解及伪逆将在第 12 部分系统处理。

### 11.6.2 知识点二十一：正规方程法

当  $\mathbf{A}$  满列秩时:

1. 形成  $\mathbf{C} = \mathbf{A}^H \mathbf{A}$ ,  $\mathbf{d} = \mathbf{A}^H \mathbf{b}$ ;
2. 作 Cholesky 分解  $\mathbf{C} = \mathbf{R}^H \mathbf{R}$ ;
3. 解  $\mathbf{R}^H \mathbf{y} = \mathbf{d}$ ,  $\mathbf{R}\mathbf{x} = \mathbf{y}$ .

---

**Algorithm 42** 正规方程-Cholesky 最小二乘法

---

**Input:** 满列秩  $\mathbf{A} \in \mathbb{C}^{m \times n}$ ;  $\mathbf{b} \in \mathbb{C}^m$

**Output:** 最小二乘解  $\mathbf{x}_*$

- 1:  $\mathbf{C} \leftarrow \mathbf{A}^H \mathbf{A}$ ,  $\mathbf{d} \leftarrow \mathbf{A}^H \mathbf{b}$
- 2: 计算  $\mathbf{C} = \mathbf{R}^H \mathbf{R}$
- 3: 解  $\mathbf{R}^H \mathbf{y} = \mathbf{d}$



- 4: 解  $R\mathbf{x}_* = \mathbf{y}$   
 5: **Stopping criterion:** 完成第二次三角求解  
 6: **Complexity:** 利用 Hermitian 对称性形成  $A^H A$  约  $mn^2 + O(mn)$  个实 FLOP; Cholesky 约  $\frac{1}{3}n^3$ ; 存储  $O(mn + n^2)$

其主要问题是

$$\kappa_2(A^H A) = \kappa_2(A)^2. \quad (11.102)$$

因此若  $\kappa_2(A) \approx u^{-1/2}$ , 则  $A^H A$  已经接近工作精度下的数值奇异。

正规方程法并非“数学上错误”，但在病态或近秩亏问题中会显著放大舍入误差。

### 11.6.3 知识点二十二：QR 最小二乘法

设完全 QR 分解为

$$A = Q \begin{pmatrix} R \\ 0 \end{pmatrix}, \quad Q = (Q_1 \quad Q_2). \quad (11.103)$$

其中  $Q_1 \in \mathbb{C}^{m \times n}$ ,  $R \in \mathbb{C}^{n \times n}$ 。令

$$Q^H \mathbf{b} = \begin{pmatrix} \mathbf{c} \\ \mathbf{d} \end{pmatrix}, \quad \mathbf{c} \in \mathbb{C}^n, \quad \mathbf{d} \in \mathbb{C}^{m-n}. \quad (11.104)$$

则

$$\begin{aligned} \|A\mathbf{x} - \mathbf{b}\|_2^2 &= \|Q^H(A\mathbf{x} - \mathbf{b})\|_2^2 \\ &= \|R\mathbf{x} - \mathbf{c}\|_2^2 + \|\mathbf{d}\|_2^2. \end{aligned} \quad (11.105)$$

故

$$R\mathbf{x}_* = \mathbf{c} = Q_1^H \mathbf{b}. \quad (11.106)$$

最小残差范数为

$$\|\mathbf{r}_*\|_2 = \|\mathbf{d}\|_2 = \|Q_2^H \mathbf{b}\|_2. \quad (11.107)$$

---

#### Algorithm 43 Householder QR 最小二乘法

---

**Input:** 满列秩  $A \in \mathbb{C}^{m \times n}$ ;  $\mathbf{b} \in \mathbb{C}^m$

**Output:** 最小二乘解  $\mathbf{x}_*$  及残差范数

- 1: 用 Householder 反射计算  $A = Q_1 R$  并保存反射向量
  - 2: 隐式计算  $Q^H \mathbf{b} = \begin{pmatrix} \mathbf{c} \\ \mathbf{d} \end{pmatrix}$
  - 3: 回代求解  $R\mathbf{x}_* = \mathbf{c}$
  - 4:  $\rho_* \leftarrow \|\mathbf{d}\|_2$
  - 5: **Stopping criterion:** 三角方程求解完成
  - 6: **Complexity:** 约  $2mn^2 - \frac{2}{3}n^3 + O(mn)$  个 FLOP; 不形成  $A^H A$ ; 后向稳定性通常优于正规方程法
- 



## 11.6.4 综合例题：直线拟合的 QR 解法

## 完整题目叙述

用最小二乘拟合直线  $y = c_0 + c_1 t$  到数据  $(t, y) = (0, 1), (1, 2), (2, 2)$ 。要求：

1. 建立矩阵最小二乘问题；
2. 用约化 QR 分解求  $c_0, c_1$ ；
3. 验证残差与  $A$  的列空间正交。

详细解答. 矩阵和右端项为

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \mathbf{b} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}. \quad (11.108)$$

记两列为  $\mathbf{a}_1 = (1, 1, 1)^\top$ ,  $\mathbf{a}_2 = (0, 1, 2)^\top$ 。首先  $r_{11} = \|\mathbf{a}_1\|_2 = \sqrt{3}$ ,  $\mathbf{q}_1 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$ 。其次  $r_{12} = \mathbf{q}_1^\top \mathbf{a}_2 = \sqrt{3}$ 。于是  $\mathbf{v}_2 = \mathbf{a}_2 - r_{12}\mathbf{q}_1 = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$ , 故  $r_{22} = \sqrt{2}$ ,  $\mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}$ 。因此

$$Q_1 = \begin{pmatrix} \frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{3}} & 0 \\ \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} \end{pmatrix}, R = \begin{pmatrix} \sqrt{3} & \sqrt{3} \\ 0 & \sqrt{2} \end{pmatrix}. \quad (11.109)$$

计算

$$Q_1^\top \mathbf{b} = \begin{pmatrix} 5/\sqrt{3} \\ 1/\sqrt{2} \end{pmatrix}. \quad (11.110)$$

三角方程为  $\begin{pmatrix} \sqrt{3} & \sqrt{3} \\ 0 & \sqrt{2} \end{pmatrix} \begin{pmatrix} c_0 \\ c_1 \end{pmatrix} = \begin{pmatrix} 5/\sqrt{3} \\ 1/\sqrt{2} \end{pmatrix}$ 。由第二行,  $c_1 = \frac{1}{2}$ 。代入第一行:  $c_0 + c_1 = \frac{5}{3}$ , 所以


$$\boxed{c_0 = \frac{7}{6}, c_1 = \frac{1}{2}}. \quad (11.111)$$

拟合值为  $A\mathbf{c} = \begin{pmatrix} 7/6 \\ 5/3 \\ 13/6 \end{pmatrix}$ 。按本文残差约定  $\mathbf{r} = \mathbf{b} - A\mathbf{c} = \begin{pmatrix} -1/6 \\ 1/3 \\ -1/6 \end{pmatrix}$ 。

验证:  $A^\top \mathbf{r} = \begin{pmatrix} -1/6 + 1/3 - 1/6 \\ 0(-1/6) + 1(1/3) + 2(-1/6) \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$ 。故残差与列空间正交。其范数为

$$\|\mathbf{r}\|_2 = \frac{1}{\sqrt{6}}. \quad (11.112)$$

□



## 11.6.5 知识点二十三：正规方程、QR 与 SVD 的比较

| 方法                | 核心方程               | 主要成本                     | 稳定性与适用情形                     |
|-------------------|--------------------|--------------------------|------------------------------|
| 正规方程<br>+Cholesky | $A^H A x = A^H b$  | $mn^2 + \frac{1}{3}n^3$  | 速度快；条件数平方；不适合近秩亏问题           |
| Householder QR    | $Rx = Q_1^H b$     | $2mn^2 - \frac{2}{3}n^3$ | 日常标准方法；后向稳定；不显式形成 $A^H A$    |
| SVD               | $\Sigma z = U^H b$ | 通常高于 QR                  | 最可靠地处理秩亏、最小范数解和正则化；第 12 部分详述 |

## 易错点与反例

不能因为正规方程给出正确的精确数学解，就断言它在浮点计算中与 QR 同样稳定。  
关键差异为  $\kappa_2(A^H A) = \kappa_2(A)^2$ 。

## 11.6.6 知识点二十四：满秩最小二乘的条件数参数

令

$$y = Ax_* = Pb, \quad r = b - y, \quad (11.113)$$

其中  $P$  为到  $\mathcal{R}(A)$  的正交投影。

定义拟合角

$$\cos \theta = \frac{\|y\|_2}{\|b\|_2}, \quad \tan \theta = \frac{\|r\|_2}{\|y\|_2}, \quad 0 \leq \theta \leq \frac{\pi}{2}, \quad (11.114)$$

以及

$$\eta = \frac{\|A\|_2 \|x_*\|_2}{\|y\|_2}, \quad 1 \leq \eta \leq \kappa_2(A). \quad (11.115)$$

只扰动  $b$  时， $x_* = A^+ b$ ,  $y = Pb$ 。于是相对条件数分别为

$$\kappa_{b \rightarrow y} = \frac{1}{\cos \theta}, \quad (11.116)$$

$$\kappa_{b \rightarrow x} = \frac{\kappa_2(A)}{\eta \cos \theta}. \quad (11.117)$$

若扰动  $A$ ，对正规方程作一阶微分：

$$A^H A \delta x = \delta A^H r - A^H \delta A x. \quad (11.118)$$

从而得到一阶上界

$$\frac{\|\delta x\|_2}{\|x\|_2} \lesssim \left[ \kappa_2(A) + \frac{\kappa_2(A)^2 \tan \theta}{\eta} \right] \frac{\|\delta A\|_2}{\|A\|_2}. \quad (11.119)$$

因此最小二乘问题特别困难的情形包括：

- $A$  近秩亏，即  $\kappa_2(A)$  很大；
- 拟合很差，即  $\theta$  接近  $\pi/2$ ；
- $y$  相对于  $\|A\| \|x\|$  很小，即  $\eta$  较大。



## 11.7 舍入误差、增长因子与迭代改进

### 11.7.1 知识点二十五：矩阵乘法的标准误差模型

对内积  $s = \mathbf{a}^H \mathbf{b}$ , 浮点结果满足

$$\hat{s} = (\mathbf{a} + \delta \mathbf{a})^H \mathbf{b}, |\delta \mathbf{a}| \leq \gamma_n |\mathbf{a}|, \quad (11.120)$$

或等价地

$$|\hat{s} - s| \leq \gamma_n |\mathbf{a}|^H |\mathbf{b}|. \quad (11.121)$$

矩阵乘法  $\hat{C} = \text{fl}(AB)$  满足

$$|\hat{C} - AB| \leq \gamma_n |A| |B|. \quad (11.122)$$

这些逐分量模型是分析三角求解、LU、Cholesky 和 QR 后向误差的基础。

### 11.7.2 知识点二十六：直接法稳定性总逻辑

对计算线性方程组，必须按下列顺序分析：

1. 问题条件数  $\kappa(A) = \|A\| \|A^{-1}\|$ ;
2. 分解后向误差  $A + \Delta A = \hat{L}\hat{U}$  或  $\hat{R}^H \hat{R}$ ;
3. 三角求解后向误差;
4. 合并为整体邻近问题  $(A + \Delta A_{\text{tot}})\hat{\mathbf{x}} = \mathbf{b} + \Delta \mathbf{b}$ ;
5. 由条件数转换成前向误差  $\frac{\|\hat{\mathbf{x}} - \mathbf{x}\|}{\|\mathbf{x}\|} \lesssim \kappa(A) \left( \frac{\|\Delta A_{\text{tot}}\|}{\|A\|} + \frac{\|\Delta \mathbf{b}\|}{\|\mathbf{b}\|} \right).$

#### 易错点与反例

以下推理均错误：

- “残差小，所以解误差一定小”；
- “条件数大，所以算法一定不稳定”；
- “算法后向稳定，所以前向误差一定接近机器精度”；
- “PLU 有选主元，所以不需要分析增长因子”。

### 11.7.3 知识点二十七：迭代改进

设已经用 PLU 得到初始解  $\mathbf{x}^{(0)}$ 。迭代改进按

$$\mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}, \quad (11.123)$$

$$A\mathbf{d}^{(k)} = \mathbf{r}^{(k)}, \quad (11.124)$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \mathbf{d}^{(k)} \quad (11.125)$$


迭代。

校正方程使用原有 PLU 因子求解，每次只需  $O(n^2)$  工作。

---

**Algorithm 44** 基于 PLU 的迭代改进

---





**Input:**  $A, b$ ; 已计算的  $PA = LU$ ; 初始解  $x^{(0)}$ ; 容差; 最大迭代次数

**Output:** 改进解  $x$

```

1: for  $k = 0, 1, \dots, k_{\max} - 1$  do
2:   以尽可能高的精度计算  $r^{(k)} \leftarrow b - Ax^{(k)}$ 
3:   if 后向误差达到容差 then
4:     return  $x^{(k)}$ 
5:   end if
6:   解  $Ly = Pr^{(k)}$ 
7:   解  $Ud^{(k)} = y$ 
8:    $x^{(k+1)} \leftarrow x^{(k)} + d^{(k)}$ 
9: end for
10: Stopping criterion: 可使用  $\frac{\|r\|_{\infty}}{\|A\|_{\infty}\|x\|_{\infty} + \|b\|_{\infty}} \leq \text{tol}$ 
11: Complexity: 一次分解  $O(n^3)$ ; 每次改进  $O(n^2)$ ; 额外存储  $O(n)$ ; 混合精度实现中残差宜使用更高精度

```

理想情况下, 若校正求解误差算子  $E$  满足  $\rho(E) < 1$ , 则误差线性收敛。在同精度经典模型中, 常见充分条件形如

$$\kappa(A)u < 1. \quad (11.126)$$

混合精度迭代改进可以用低精度分解配合高精度残差, 降低总成本并恢复高精度解。

## 11.8 补充训练题：最小二乘增广矩阵的谱与最优缩放

完整题目叙述: [NLA-Set-2015-Problem-2]

设  $A \in \mathbb{R}^{m \times n}$ ,  $\text{rank}(A) = n$ ,  $n < m$ , 并令

$$C(\alpha) = \begin{pmatrix} \alpha I_m & A \\ A^T & 0 \end{pmatrix}, \quad \alpha \geq 0. \quad (11.127)$$

设  $A$  的奇异值为  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n > 0$ 。

(a) 证明  $C(\alpha)$  的特征值为

$$\frac{\alpha}{2} \pm \sqrt{\frac{\alpha^2}{4} + \sigma_i^2}, \quad i = 1, \dots, n, \quad (11.128)$$

以及  $\alpha$ , 重数为  $m - n$ ;

(b) 对  $\alpha > 0$ , 分析  $\kappa_2(C(\alpha))$ , 证明其最优缩放为  $\alpha_* = \frac{\sigma_n}{\sqrt{2}}$ , 并证明

$$\sqrt{2} \kappa_2(A) \leq \min_{\alpha > 0} \kappa_2(C(\alpha)) \leq 2\kappa_2(A). \quad (11.129)$$

第 (a) 问: 利用 SVD 作正交相似变换. 取薄 SVD

$$A = U_1 \Sigma V^T, \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_n), \quad (11.130)$$

并把  $U_1$  扩充为正交矩阵  $U = \begin{pmatrix} U_1 & U_2 \end{pmatrix}$ 。令

$$Q = \begin{pmatrix} U & 0 \\ 0 & V \end{pmatrix}. \quad (11.131)$$



则

$$\mathcal{Q}^T C(\alpha) \mathcal{Q} = \begin{pmatrix} \alpha I_n & 0 & \Sigma \\ 0 & \alpha I_{m-n} & 0 \\ \Sigma & 0 & 0 \end{pmatrix}. \quad (11.132)$$

再通过一个置换把第  $i$  个左奇异方向与第  $i$  个右奇异方向相邻排列, 得到  $n$  个  $2 \times 2$  块

$$B_i = \begin{pmatrix} \alpha & \sigma_i \\ \sigma_i & 0 \end{pmatrix}, \quad (11.133)$$

以及一个块  $\alpha I_{m-n}$ 。

$B_i$  的特征方程为  $\lambda^2 - \alpha\lambda - \sigma_i^2 = 0$ , 故

$$\lambda_i^\pm = \frac{\alpha}{2} \pm \sqrt{\frac{\alpha^2}{4} + \sigma_i^2}. \quad (11.134)$$

其余  $m - n$  个特征值均为  $\alpha$ 。 □

第 (b) 问: 写出精确条件数. 因为  $C(\alpha)$  为实对称矩阵, 其奇异值等于特征值绝对值。

记

$$p_i(\alpha) = \frac{\alpha + \sqrt{\alpha^2 + 4\sigma_i^2}}{2}, \quad (11.135)$$

$$q_i(\alpha) = \frac{\sqrt{\alpha^2 + 4\sigma_i^2} - \alpha}{2}. \quad (11.136)$$

则  $\lambda_i^+ = p_i > 0$ ,  $\lambda_i^- = -q_i < 0$ 。又有

$$p_i q_i = \sigma_i^2. \quad (11.137)$$

$p_i$  随  $\sigma_i$  增大,  $q_i$  也随  $\sigma_i$  增大. 因此最大奇异值为  $p_1(\alpha)$ 。由于  $n < m$ , 还存在奇异值  $\alpha$ ; 最小奇异值为  $\min\{\alpha, q_n(\alpha)\}$ 。所以

$$\kappa_2(C(\alpha)) = \frac{p_1(\alpha)}{\min\{\alpha, q_n(\alpha)\}}, \quad \alpha > 0. \quad (11.138)$$

□

第 (b) 问: 确定最优  $\alpha$ . 函数  $\alpha$  单调增大, 而  $q_n(\alpha) = \frac{\sqrt{\alpha^2 + 4\sigma_n^2} - \alpha}{2}$  严格单调减小。

当  $\alpha < q_n(\alpha)$  时,  $\kappa_2(C(\alpha)) = \frac{p_1(\alpha)}{\alpha} = \frac{1}{2} + \sqrt{\frac{1}{4} + \frac{\sigma_1^2}{\alpha^2}}$ , 它随  $\alpha$  增大而减小。

当  $\alpha > q_n(\alpha)$  时,  $\kappa_2(C(\alpha)) = \frac{p_1(\alpha)}{q_n(\alpha)}$ , 其中分子增大、分母减小, 所以整体增大。

故最小值恰在交点  $\alpha = q_n(\alpha)$  取得. 解方程

$$\begin{aligned} \alpha &= \frac{\sqrt{\alpha^2 + 4\sigma_n^2} - \alpha}{2} \\ 3\alpha &= \sqrt{\alpha^2 + 4\sigma_n^2} \\ 9\alpha^2 &= \alpha^2 + 4\sigma_n^2 \end{aligned}$$

得到

$$\alpha_\star = \frac{\sigma_n}{\sqrt{2}}. \quad (11.139)$$

□



第 (b) 问：最小条件数及上下界. 记  $\kappa = \kappa_2(A) = \frac{\sigma_1}{\sigma_n}$ . 在  $\alpha_* = \sigma_n/\sqrt{2}$  处,

$$\begin{aligned}\min_{\alpha>0} \kappa_2(C(\alpha)) &= \frac{p_1(\alpha_*)}{\alpha_*} \\ &= \frac{1}{2} + \sqrt{\frac{1}{4} + 2\kappa^2}.\end{aligned}\quad (11.140)$$

下界方面,  $\frac{1}{2} + \sqrt{\frac{1}{4} + 2\kappa^2} \geq \sqrt{2}\kappa$ .

上界方面, 由  $\kappa \geq 1$ ,

$$\sqrt{\frac{1}{4} + 2\kappa^2} \leq 2\kappa - \frac{1}{2}$$

等价于  $0 \leq 2\kappa(\kappa - 1)$ , 故  $\frac{1}{2} + \sqrt{\frac{1}{4} + 2\kappa^2} \leq 2\kappa$ . 所以

$$\boxed{\sqrt{2}\kappa_2(A) \leq \min_{\alpha>0} \kappa_2(C(\alpha)) \leq 2\kappa_2(A)}.\quad (11.141)$$

此外,  $\kappa_2(C(\alpha)) \rightarrow \infty$  当  $\alpha \rightarrow 0^+$  或  $\alpha \rightarrow \infty$ . 其中  $\alpha \rightarrow 0^+$  时,  $m-n$  个特征值  $\alpha$  趋于零;  $\alpha \rightarrow \infty$  时,  $q_n(\alpha) \sim \frac{\sigma_n^2}{\alpha}$ , 故条件数按  $O(\alpha^2/\sigma_n^2)$  增长.  $\square$

注 11.12 (方阵情形). 上述最优缩放推导使用了  $n < m$ , 因为条件数分母中含有  $m-n$  个奇异值  $\alpha$ .

若  $m = n$ , 不存在额外的  $\alpha$  特征值, 条件数公式应改为  $\kappa_2(C(\alpha)) = \frac{p_1(\alpha)}{q_n(\alpha)}$ ; 此时不能直接照搬  $\alpha_* = \sigma_n/\sqrt{2}$ .

## 11.9 补充训练题：上三角矩阵乘积减位移的快速求解

完整题目叙述: [NLA-Set-2010-Problem-5]

设

$$S = \begin{pmatrix} \sigma & \mathbf{u}^\top \\ 0 & S_c \end{pmatrix}, T = \begin{pmatrix} \tau & \mathbf{v}^\top \\ 0 & T_c \end{pmatrix}, \mathbf{b} = \begin{pmatrix} \beta \\ \mathbf{b}_c \end{pmatrix}, \quad (11.142)$$

其中  $\sigma, \tau, \beta$  为标量,  $S_c, T_c \in \mathbb{F}^{n \times n}$  为上三角矩阵。

(1) 假设已知  $\mathbf{x}_c$  满足  $(S_c T_c - \lambda I)\mathbf{x}_c = \mathbf{b}_c$ , 且已知  $\mathbf{w}_c = T_c \mathbf{x}_c$ . 证明

$$\mathbf{x} = \begin{pmatrix} \gamma \\ \mathbf{x}_c \end{pmatrix}, \gamma = \frac{\beta - \sigma \mathbf{v}^\top \mathbf{x}_c - \mathbf{u}^\top \mathbf{w}_c}{\sigma \tau - \lambda}, \quad (11.143)$$


解  $(ST - \lambda I)\mathbf{x} = \mathbf{b}$ .

(2) 设  $U_1, U_2$  为  $n \times n$  上三角矩阵, 且  $U_1 U_2 - \lambda I$  非奇异. 构造  $O(n^2)$  算法求解  $(U_1 U_2 - \lambda I)\mathbf{x} = \mathbf{b}$ .

(3) 推广到  $p$  个上三角矩阵: 构造  $O(pn^2)$  算法求解  $(U_1 U_2 \cdots U_p - \lambda I)\mathbf{x} = \mathbf{b}$ .

第 (1) 问: 块代入验证. 先计算

$$ST = \begin{pmatrix} \sigma \tau & \sigma \mathbf{v}^\top + \mathbf{u}^\top T_c \\ 0 & S_c T_c \end{pmatrix}. \quad (11.144)$$



于是

$$\begin{aligned} (ST - \lambda I) \begin{pmatrix} \gamma \\ \mathbf{x}_c \end{pmatrix} \\ = \begin{pmatrix} (\sigma\tau - \lambda)\gamma + \sigma\mathbf{v}^\top \mathbf{x}_c + \mathbf{u}^\top T_c \mathbf{x}_c \\ (S_c T_c - \lambda I) \mathbf{x}_c \end{pmatrix}. \end{aligned} \quad (11.145)$$

由  $T_c \mathbf{x}_c = \mathbf{w}_c$  及题设, 下块等于  $\mathbf{b}_c$ 。选择  $\gamma = \frac{\beta - \sigma\mathbf{v}^\top \mathbf{x}_c - \mathbf{u}^\top \mathbf{w}_c}{\sigma\tau - \lambda}$  后, 上块等于  $\beta$ 。

因为  $ST - \lambda I$  为上三角矩阵, 其非奇异性蕴含  $\sigma\tau - \lambda \neq 0$ , 故分母非零。□

第 (2) 问: 不显式形成乘积的回代递推. 记  $U_1 = (a_{ij})$ ,  $U_2 = (c_{ij})$ 。引入辅助向量

$$\mathbf{y} = U_2 \mathbf{x}. \quad (11.146)$$

原方程等价于

$$U_1 \mathbf{y} - \lambda \mathbf{x} = \mathbf{b}. \quad (11.147)$$

由于  $U_1, U_2$  均为上三角, 可从  $i = n$  向  $i = 1$  回代。假设已经知道  $x_{i+1}, \dots, x_n, y_{i+1}, \dots, y_n$ 。定义已知尾和

$$s_i^{(2)} = \sum_{j=i+1}^n c_{ij} x_j, \quad (11.148)$$

$$s_i^{(1)} = \sum_{j=i+1}^n a_{ij} y_j. \quad (11.149)$$

由  $\mathbf{y} = U_2 \mathbf{x}$ ,

$$y_i = c_{ii} x_i + s_i^{(2)}. \quad (11.150)$$

第  $i$  个原方程为  $a_{ii} y_i + s_i^{(1)} - \lambda x_i = b_i$ 。代入  $y_i$ :

$$(a_{ii} c_{ii} - \lambda) x_i = b_i - s_i^{(1)} - a_{ii} s_i^{(2)}. \quad (11.151)$$

因此

$$x_i = \frac{b_i - s_i^{(1)} - a_{ii} s_i^{(2)}}{a_{ii} c_{ii} - \lambda}, \quad (11.152)$$

再计算

$$y_i = c_{ii} x_i + s_i^{(2)}. \quad (11.153)$$

因为  $U_1 U_2 - \lambda I$  为上三角且非奇异, 每个对角元  $a_{ii} c_{ii} - \lambda \neq 0$ 。□

---

**Algorithm 45** 求解  $(U_1 U_2 - \lambda I) \mathbf{x} = \mathbf{b}$ , 不形成  $U_1 U_2$

---

**Input:** 上三角  $U_1 = (a_{ij})$ 、 $U_2 = (c_{ij})$ ; 位移  $\lambda$ ; 右端项  $\mathbf{b}$ ; 假设  $U_1 U_2 - \lambda I$  非奇异

**Output:** 解  $\mathbf{x}$

- 1: **Initialization:**  $\mathbf{x} \leftarrow 0, \mathbf{y} \leftarrow 0$
- 2: **for**  $i = n, n-1, \dots, 1$  **do**
- 3:    $s_i^{(2)} \leftarrow \sum_{j=i+1}^n c_{ij} x_j$
- 4:    $s_i^{(1)} \leftarrow \sum_{j=i+1}^n a_{ij} y_j$
- 5:    $d_i \leftarrow a_{ii} c_{ii} - \lambda$
- 6:   **if**  $d_i = 0$  **then**
- 7:     报告“位移系统奇异”
- 8:   **end if**



- 9:  $x_i \leftarrow \frac{b_i - s_i^{(1)} - a_{ii} s_i^{(2)}}{d_i}$   
 10:  $y_i \leftarrow c_{ii} x_i + s_i^{(2)}$   
 11: **end for**  
 12: **Stopping criterion:** 计算完  $x_1$   
 13: **Complexity:** 每个  $i$  计算两个长度  $n-i$  的点积；总成本  $\sum_i O(n-i) = O(n^2)$ ；存储  $\mathbf{x}, \mathbf{y}$  共  $O(n)$ ；显式形成  $U_1 U_2$  则需  $O(n^3)$

第 (3) 问：推广到  $p$  个上三角因子。定义中间向量

$$\mathbf{z}^{(p+1)} = \mathbf{x}, \mathbf{z}^{(q)} = U_q \mathbf{z}^{(q+1)}, \quad q = p, p-1, \dots, 1. \quad (11.154)$$

原方程为

$$\mathbf{z}^{(1)} - \lambda \mathbf{x} = \mathbf{b}. \quad (11.155)$$

仍按  $i = n, n-1, \dots, 1$  处理。假设所有  $j > i$  的  $x_j, z_j^{(q)}, \quad q = 1, \dots, p$  均已知。

记

$$h_i^{(q)} = \sum_{j=i+1}^n (U_q)_{ij} z_j^{(q+1)}. \quad (11.156)$$

则

$$z_i^{(q)} = (U_q)_{ii} z_i^{(q+1)} + h_i^{(q)}. \quad (11.157)$$

从  $q = p$  向  $q = 1$  递推，可写成

$$z_i^{(q)} = d_i^{(q)} x_i + c_i^{(q)}, \quad (11.158)$$

其中

$$d_i^{(p+1)} = 1, \quad c_i^{(p+1)} = 0, \quad (11.159)$$

$$d_i^{(q)} = (U_q)_{ii} d_i^{(q+1)}, \quad (11.160)$$

$$c_i^{(q)} = (U_q)_{ii} c_i^{(q+1)} + h_i^{(q)}. \quad (11.161)$$

特别地，

$$d_i^{(1)} = \prod_{q=1}^p (U_q)_{ii}. \quad (11.162)$$

由  $z_i^{(1)} - \lambda x_i = b_i$  得到

$$\boxed{x_i = \frac{b_i - c_i^{(1)}}{d_i^{(1)} - \lambda}}. \quad (11.163)$$

随后按  $q = p, p-1, \dots, 1$  计算  $z_i^{(q)} = (U_q)_{ii} z_i^{(q+1)} + h_i^{(q)}$ 。

每个  $q$ 、每个  $i$  只需一个长度  $n-i$  的尾部点积，总工作为


$$\sum_{q=1}^p \sum_{i=1}^n O(n-i) = O(pn^2). \quad (11.164)$$

存储  $p$  个中间向量需要  $O(pn)$  空间。 □

**Algorithm 46** 求解  $(U_1 \cdots U_p - \lambda I) \mathbf{x} = \mathbf{b}$

**Input:** 上三角矩阵  $U_1, \dots, U_p$ ；位移  $\lambda$ ；右端项  $\mathbf{b}$

**Output:** 解  $\mathbf{x}$



```

1: Initialization:  $\mathbf{z}^{(p+1)} \leftarrow \mathbf{x}$ ; 分配  $\mathbf{z}^{(1)}, \dots, \mathbf{z}^{(p)}$ 
2: for  $i = n, n-1, \dots, 1$  do
3:   for  $q = p, p-1, \dots, 1$  do
4:      $h_i^{(q)} \leftarrow \sum_{j=i+1}^n (U_q)_{ij} z_j^{(q+1)}$ 
5:   end for
6:    $d \leftarrow 1, c \leftarrow 0$ 
7:   for  $q = p, p-1, \dots, 1$  do
8:      $c \leftarrow (U_q)_{ii} c + h_i^{(q)}$ 
9:      $d \leftarrow (U_q)_{ii} d$ 
10:  end for
11:   $x_i \leftarrow \frac{b_i - c}{d - \lambda}$ 
12:   $z_i^{(p+1)} \leftarrow x_i$ 
13:  for  $q = p, p-1, \dots, 1$  do
14:     $z_i^{(q)} \leftarrow (U_q)_{ii} z_i^{(q+1)} + h_i^{(q)}$ 
15:  end for
16: end for
17: Stopping criterion: 完成  $i = 1$ 
18: Complexity: 时间  $O(pn^2)$ ; 存储  $O(pn)$ ; 避免形成稠密乘积  $U_1 \cdots U_p$ 

```

### 易错点与反例

本题的关键不是先计算  $U_1 U_2 \cdots U_p$ 。显式矩阵乘积一般需要  $O(pn^3)$  工作，会破坏题目要求。正确方法是：

1. 利用乘积仍为上三角；
2. 从最后一个分量向前回代；
3. 同步维护中间向量  $U_q U_{q+1} \cdots U_p \mathbf{x}$ ；
4. 对每个矩阵只作上三角尾部点积。

## 11.10 本部分易错点与标准答题规范

| 错误说法或错误做法                              | 正确处理                                        |
|----------------------------------------|---------------------------------------------|
| $A$ 非奇异，所以一定存在无选主元 LU 分解。              | 还需顺序主子式非零；一般非奇异矩阵保证的是 PLU 分解。               |
| Gaussian 消元与 LU 分解是两个完全不同的算法。          | 消元矩阵乘积正好给出 $A = LU$ ；二者是同一过程的算法与矩阵表达。       |
| 部分选主元保证严格后向稳定。                         | 后向误差还受增长因子 $\rho_n(A)$ 控制；最坏情形为 $2^{n-1}$ 。 |
| 乘子 $ \ell_{ik}  \leq 1$ ，所以 $U$ 不可能增长。 | 更新中多个项可以累积，Wilkinson 矩阵产生指数增长。              |
| 条件数大说明 Gaussian 消元算法不稳定。               | 条件数描述问题敏感性；算法稳定性由后向误差和增长因子描述。               |

| 错误说法或错误做法                                       | 正确处理                                              |
|-------------------------------------------------|---------------------------------------------------|
| Cholesky 可用于任何对称矩阵。                             | 必须要求 Hermitian 正定；不定矩阵需带对称选主元的 $LDL^H$ 。          |
| Cholesky 比 LU 慢。                                | 对稠密 SPD 矩阵，Cholesky 主成本约 $n^3/3$ ，约为 LU 的一半。      |
| QR 分解中的 $Q$ 应显式形成。                              | Householder 实现通常只保存反射向量并隐式应用 $Q, Q^H$ 。           |
| 经典 GS 和修正 GS 在浮点中完全等价。                          | 精确算术等价；浮点中 MGS 通常明显更稳定。                           |
| Householder 向量可取 $x - \ x\ e_1$ 而无需考虑符号。        | 应选反相位以避免首分量发生灾难性消去。                               |
| Givens 和 Householder 成本、用途完全相同。                 | Householder 适合稠密列消去；Givens 适合稀疏、局部和在线更新。          |
| 正规方程法与 QR 法稳定性相同。                               | 正规方程将二范数条件数平方，近秩亏时可能损失大量精度。                       |
| 最小二乘残差应与 $\mathbf{b}$ 正交。                       | 残差应与 $\mathcal{R}(A)$ 正交，即 $A^H \mathbf{r} = 0$ 。 |
| $A^H A$ 总是正定。                                   | 只有当 $A$ 满列秩时才正定；一般仅半正定。                           |
| 残差很小即可停止。                                       | 还应使用相对后向误差，并结合 $\kappa(A)$ 判断前向误差。                |
| 为解 $A\mathbf{x} = \mathbf{b}$ 应先显式计算 $A^{-1}$ 。 | 单右端项应分解后作三角求解；显式逆通常更贵且更不稳定。                       |
| 矩阵有多个右端项时应分别重新分解。                               | 分解只做一次，每个新右端项仅需 $O(n^2)$ 三角求解。                    |
| 稀疏矩阵的 FLOP 少就一定快。                               | 还需分析填充、数据局部性、存储访问和排序。                             |





## 第十二章 SVD、伪逆、低秩逼近、核范数、正则化、低秩更新与矩阵方程

### 12.1 奇异值分解：定义、存在性、基本子空间与计算

#### 12.1.1 知识点一：完整 SVD 与紧 SVD

【重要性等级】 **S 级**。奇异值分解是本部分所有结论的统一工具。看到以下信号时，应立即考虑 SVD：

- 长方矩阵或秩亏矩阵；
- 最小二乘与最小范数解；
- 谱范数或 Frobenius 范数；
- 低秩逼近、压缩、降维；
- 到秩亏矩阵集合的距离；
- 病态逆问题与正则化；
- 核范数或奇异值阈值；
- 形如  $AXB - C$  的 Frobenius 范数问题。

设  $A \in \mathbb{C}^{m \times n}$ ,  $q = \min\{m, n\}$ ,  $r = \text{rank}(A)$ 。

定理 12.1 (奇异值分解). 存在酉矩阵  $U \in \mathbb{C}^{m \times m}$ ,  $V \in \mathbb{C}^{n \times n}$ , 以及矩形对角矩阵  $\Sigma \in \mathbb{R}^{m \times n}$ , 使

$$A = U \Sigma V^H. \quad (12.1)$$

$\Sigma$  的非零对角元可按

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0 \quad (12.2)$$

排列，其余奇异值定义为零。

$\sigma_i$  称为  $A$  的奇异值； $U$  的相应列  $u_i$  称为左奇异向量； $V$  的相应列  $v_i$  称为右奇异向量。

证明.  $A^H A$  为 Hermitian 半正定矩阵，故存在酉矩阵  $V$  使

$$A^H A = V \text{diag}(\sigma_1^2, \dots, \sigma_q^2, 0, \dots, 0) V^H, \quad (12.3)$$

其中  $\sigma_i \geq 0$ 。



对每个  $\sigma_i > 0$ , 定义

$$\mathbf{u}_i = \frac{A\mathbf{v}_i}{\sigma_i}. \quad (12.4)$$

则  $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$ . 并且对  $i, j \leq r$ ,

$$\begin{aligned} \mathbf{u}_i^H \mathbf{u}_j &= \frac{\mathbf{v}_i^H A^H A \mathbf{v}_j}{\sigma_i \sigma_j} \\ &= \frac{\sigma_j^2 \mathbf{v}_i^H \mathbf{v}_j}{\sigma_i \sigma_j} = \delta_{ij}. \end{aligned} \quad (12.5)$$

所以  $\mathbf{u}_1, \dots, \mathbf{u}_r$  正交归一。将其扩充为  $\mathbb{C}^m$  的一组酉基, 组成矩阵  $U$ 。

又因为  $A^H \mathbf{u}_i = \frac{A^H A \mathbf{v}_i}{\sigma_i} = \sigma_i \mathbf{v}_i$ , 故  $A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^H = U \Sigma V^H$ .  $\square$

定义 12.2 (紧 SVD). 记

$$U_r = (\mathbf{u}_1 \ \cdots \ \mathbf{u}_r) \in \mathbb{C}^{m \times r}, \quad (12.6)$$

$$V_r = (\mathbf{v}_1 \ \cdots \ \mathbf{v}_r) \in \mathbb{C}^{n \times r}, \quad (12.7)$$

$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r). \quad (12.8)$$

则

$$A = U_r \Sigma_r V_r^H \quad (12.9)$$

称为  $A$  的紧 SVD 或经济型 SVD。

奇异三元组满足

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad A^H \mathbf{u}_i = \sigma_i \mathbf{v}_i. \quad (12.10)$$

### 12.1.2 知识点二：四个基本子空间

设完整 SVD 写为  $A = \begin{pmatrix} U_r & U_0 \end{pmatrix} \begin{pmatrix} \Sigma_r & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} V_r & V_0 \end{pmatrix}^H$ . 则

$$\mathcal{R}(A) = \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_r\}, \quad (12.11)$$

$$\mathcal{N}(A^H) = \text{span}(U_0), \quad (12.12)$$


$$\mathcal{R}(A^H) = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_r\}, \quad (12.13)$$

$$\mathcal{N}(A) = \text{span}(V_0). \quad (12.14)$$

相应正交分解为

$$\mathbb{C}^m = \mathcal{R}(A) \oplus \mathcal{N}(A^H), \quad (12.15)$$

$$\mathbb{C}^n = \mathcal{R}(A^H) \oplus \mathcal{N}(A). \quad (12.16)$$



### 12.1.3 知识点三：范数、秩与条件数的奇异值表达

由 SVD 立即得到

$$\text{rank}(A) = \#\{i : \sigma_i > 0\}, \quad (12.17)$$

$$\|A\|_2 = \sigma_1, \quad (12.18)$$

$$\|A\|_F = \left( \sum_{i=1}^r \sigma_i^2 \right)^{1/2}, \quad (12.19)$$

$$\|A\|_* = \sum_{i=1}^r \sigma_i, \quad (12.20)$$

其中  $\|\cdot\|_*$  为核范数。

若  $A$  为方阵且非奇异,

$$\kappa_2(A) = \frac{\sigma_1}{\sigma_n}. \quad (12.21)$$

更一般地, 对满列秩长方形矩阵,  $\kappa_2(A) = \frac{\sigma_1}{\sigma_n}$ 。

对任意  $\mathbf{x}$ ,

$$\sigma_r \|V_r^H \mathbf{x}\|_2 \leq \|A\mathbf{x}\|_2 \leq \sigma_1 \|\mathbf{x}\|_2. \quad (12.22)$$

若  $A$  满列秩, 则

$$\sigma_n \|\mathbf{x}\|_2 \leq \|A\mathbf{x}\|_2 \leq \sigma_1 \|\mathbf{x}\|_2. \quad (12.23)$$

#### 易错点与反例

必须区分:

- 奇异值  $\sigma_i(A)$  始终为非负实数;
- 特征值  $\lambda_i(A)$  可能为复数;
- 一般矩阵的奇异值不是特征值绝对值;
- 只有正规矩阵才满足  $\{\sigma_i(A)\} = \{|\lambda_i(A)|\}$  作为多重集合。

### 12.1.4 知识点四：SVD 的数值计算

实际算法不应通过显式形成  $A^H A$  再求特征值来计算高精度 SVD。原因是

$$\kappa_2(A^H A) = \kappa_2(A)^2, \quad (12.24)$$

且小奇异值会因平方和舍入误差而丢失相对精度。

标准稠密 SVD 通常分两阶段:

1. 用左右 Householder 变换作 Golub–Kahan 双对角化:  $A = U_B B V_B^H$ , 其中  $B$  为双对角矩阵;
2. 对双对角矩阵  $B$  使用隐式 QR、分治法或其他专门算法, 得到其奇异值和奇异向量。

#### Algorithm 47 稠密矩阵 SVD 的两阶段框架

**Input:**  $A \in \mathbb{C}^{m \times n}$ ; 相对容差 tol; 是否需要左右奇异向量

**Output:** 奇异值  $\sigma_i$  及所需奇异向量

- 1: **Initialization:** 若  $m < n$ , 可对  $A^H$  处理后交换左右奇异向量

- 2: 用左右 Householder 反射构造  $U_B^H A V_B = B$ , 其中  $B$  为上双对角矩阵
- 3: 对  $B$  进行缩放, 避免极大或极小元素导致溢出、下溢
- 4: **while**  $B$  尚未分裂为满足容差的小块 **do**
- 5:     采用隐式位移双对角 QR、分治或高相对精度算法
- 6:     若某个非对角元满足相对消去判据, 则将其置零并分裂问题
- 7: **end while**
- 8: 将双对角矩阵的奇异向量乘回  $U_B, V_B$
- 9: 对奇异值按非增次序排序, 并同步排列奇异向量
- 10: **Stopping criterion:** 所有非对角耦合均低于容差
- 11: **Complexity:** 对  $m \geq n$  的实稠密矩阵, Golub-Kahan 双对角化约为  $4mn^2 - \frac{4}{3}n^3 + O(mn)$  个 FLOP; 完整 SVD 总成本为  $O(mn^2)$ ; 存储完整奇异向量为  $O(m^2 + n^2)$ , 经济型 SVD 可降为  $O(mn + n^2)$

### 易错点与反例

SVD 的理论存在性证明可以从  $A^H A$  出发; 数值算法却不应无条件显式形成  $A^H A$ 。这是“数学推导途径”和“稳定数值实现”不同的典型例子。

## 12.2 极分解、Moore-Penrose 伪逆与最小范数解

### 12.2.1 知识点五: 极分解

定理 12.3 (右极分解). 任意  $A \in \mathbb{C}^{m \times n}$  都可写成

$$A = QH, \quad (12.25)$$

其中

$$H = (A^H A)^{1/2} \succeq 0, \quad (12.26)$$

$Q$  为从  $\mathcal{R}(A^H)$  到  $\mathcal{R}(A)$  的部分等距映射。

若  $A = U_r \Sigma_r V_r^H$  为紧 SVD, 则可取

$$H = V_r \Sigma_r V_r^H, \quad (12.27)$$

$$Q = U_r V_r^H. \quad (12.28)$$

若  $A$  满列秩, 则  $H \succ 0$  且

$$Q = A H^{-1}, \quad Q^H Q = I_n, \quad (12.29)$$

极分解唯一。

同理有左极分解

$$A = GQ, \quad G = (A A^H)^{1/2} \succeq 0. \quad (12.30)$$

对方阵非奇异  $A$ ,  $Q$  为酉矩阵。此时  $Q = UV^H$  还是距离  $A$  最近的酉矩阵之一:

$$\min_{W^H W = I} \|A - W\|_F^2 = \sum_{i=1}^n (\sigma_i - 1)^2, \quad (12.31)$$

$$\min_{W^H W = I} \|A - W\|_2 = \max_i |\sigma_i - 1|. \quad (12.32)$$



### 12.2.2 知识点六: Moore–Penrose 伪逆

定义 12.4 (Moore–Penrose 伪逆). 设  $A = U_r \Sigma_r V_r^H$  为紧 SVD。定义

$$A^\dagger = V_r \Sigma_r^{-1} U_r^H. \quad (12.33)$$

$A^\dagger$  是满足以下四个 Penrose 条件的唯一矩阵:

$$AA^\dagger A = A, \quad (12.34)$$

$$A^\dagger AA^\dagger = A^\dagger, \quad (12.35)$$

$$(AA^\dagger)^H = AA^\dagger, \quad (12.36)$$

$$(A^\dagger A)^H = A^\dagger A. \quad (12.37)$$

由 SVD 可得

$$AA^\dagger = U_r U_r^H = P_{\mathcal{R}(A)}, \quad (12.38)$$

$$A^\dagger A = V_r V_r^H = P_{\mathcal{R}(A^H)}. \quad (12.39)$$

因此

$$I - AA^\dagger = P_{\mathcal{N}(A^H)}, \quad (12.40)$$

$$I - A^\dagger A = P_{\mathcal{N}(A)}. \quad (12.41)$$

特殊情形:

$$A \text{ 满列秩} \implies A^\dagger = (A^H A)^{-1} A^H, \quad (12.42)$$

$$A \text{ 满行秩} \implies A^\dagger = A^H (A A^H)^{-1}, \quad (12.43)$$

$$A \text{ 方阵非奇异} \implies A^\dagger = A^{-1}. \quad (12.44)$$

### 12.2.3 知识点七: 一致方程与最小二乘的全部解

定理 12.5 (一致方程的全部解). 方程  $Ax = b$  有解, 当且仅当

$$AA^\dagger b = b. \quad (12.45)$$

若有解, 其全部解为

$$x = A^\dagger b + (I - A^\dagger A)z, \quad z \in \mathbb{C}^n. \quad (12.46)$$

其中  $A^\dagger b$  是唯一的 最小二范数解。

定理 12.6 (最小二乘的全部解). 最小二乘问题

$$\min_x \|Ax - b\|_2 \quad (12.47)$$

的全部解为


$$x = A^\dagger b + (I - A^\dagger A)z, \quad z \in \mathbb{C}^n. \quad (12.48)$$

唯一最小范数最小二乘解为

$$x_\dagger = A^\dagger b. \quad (12.49)$$

最小残差为

$$r_\dagger = b - AA^\dagger b = (I - AA^\dagger)b. \quad (12.50)$$



证明. 令完整 SVD 为  $A = U \begin{pmatrix} \Sigma_r & 0 \\ 0 & 0 \end{pmatrix} V^H$ . 写  $V^H \mathbf{x} = \begin{pmatrix} \mathbf{z}_1 \\ \mathbf{z}_0 \end{pmatrix}$ ,  $U^H \mathbf{b} = \begin{pmatrix} \mathbf{c}_1 \\ \mathbf{c}_0 \end{pmatrix}$ . 则

$$\|A\mathbf{x} - \mathbf{b}\|_2^2 = \|\Sigma_r \mathbf{z}_1 - \mathbf{c}_1\|_2^2 + \|\mathbf{c}_0\|_2^2. \quad (12.51)$$

最小化要求  $\mathbf{z}_1 = \Sigma_r^{-1} \mathbf{c}_1$ , 而  $\mathbf{z}_0$  任意. 因此  $\mathbf{x} = V_r \Sigma_r^{-1} U_r^H \mathbf{b} + V_0 \mathbf{z}_0$ . 又  $V_0 \mathbf{z}_0 = (I - A^\dagger A) \mathbf{z}$ , 得到全部解.

由于  $\|\mathbf{x}\|_2^2 = \|\Sigma_r^{-1} \mathbf{c}_1\|_2^2 + \|\mathbf{z}_0\|_2^2$ , 最小范数恰在  $\mathbf{z}_0 = 0$  时取得.  $\square$

此外

$$\|A^\dagger\|_2 = \frac{1}{\sigma_r}, \quad (12.52)$$

故

$$\|\mathbf{x}_\dagger\|_2 \leq \frac{\|\mathbf{b}\|_2}{\sigma_r}. \quad (12.53)$$

#### 易错点与反例

秩亏最小二乘问题通常有无穷多个最小点. 必须区分:

- 最小残差解;
- 最小范数最小残差解;
- 一致方程的最小范数精确解.

伪逆选择的是唯一最小范数解, 不是任意最小二乘解.

## 12.3 补充训练题：丘赛 2021 Problem 4——秩亏最小二乘

#### 完整题目叙述

[Yau-2021-Problem-4]

设  $A \in \mathbb{R}^{m \times n}$ ,  $m \geq n$ ,  $r = \text{rank}(A) < n$ , 并假设  $A$  具有 SVD

$$A = \begin{pmatrix} U_1 & U_2 \end{pmatrix} \begin{pmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} V_1 & V_2 \end{pmatrix}^T = U_1 \Sigma_1 V_1^T, \quad (12.54)$$

其中  $\Sigma_1 \in \mathbb{R}^{r \times r}$  非奇异,  $U_1, V_1$  各有  $r$  列.

记  $\sigma = \sigma_{\min}(\Sigma_1)$ , 即  $A$  的最小非零奇异值. 对给定  $\mathbf{b} \in \mathbb{R}^m$ , 考虑

$$\min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2. \quad (12.55)$$

(a) 证明所有最小二乘解均可写为

$$\mathbf{x} = V_1 \Sigma_1^{-1} U_1^T \mathbf{b} + V_2 \mathbf{z}_2, \quad (12.56)$$

其中  $\mathbf{z}_2$  任意;

(b) 证明当且仅当  $\mathbf{z}_2 = \mathbf{0}$  时, 解的二范数最小, 并且此时

$$\|\mathbf{x}\|_2 \leq \frac{\|\mathbf{b}\|_2}{\sigma}. \quad (12.57)$$

第 (a) 问: 全部最小二乘解. 令

$$\mathbf{z} = V^T \mathbf{x} = \begin{pmatrix} z_1 \\ z_2 \end{pmatrix}, \quad (12.58)$$

$$\mathbf{c} = U^T \mathbf{b} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}, \quad (12.59)$$

其中  $\mathbf{c}_1 = U_1^T \mathbf{b}$ . 由正交不变性,

$$\begin{aligned} \|A\mathbf{x} - \mathbf{b}\|_2^2 &= \|U^T(A\mathbf{x} - \mathbf{b})\|_2^2 \\ &= \|\Sigma_1 \mathbf{z}_1 - \mathbf{c}_1\|_2^2 + \|\mathbf{c}_2\|_2^2. \end{aligned} \quad (12.60)$$

第二项与  $\mathbf{x}$  无关. 第一项的唯一最小点为  $\mathbf{z}_1 = \Sigma_1^{-1} \mathbf{c}_1 = \Sigma_1^{-1} U_1^T \mathbf{b}$ . 而  $\mathbf{z}_2$  不出现在目标函数中, 可以任意选取.

因此

$$\begin{aligned} \mathbf{x} &= V \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} \\ &= V_1 \Sigma_1^{-1} U_1^T \mathbf{b} + V_2 \mathbf{z}_2. \end{aligned} \quad (12.61)$$

□

第 (b) 问: 最小范数与误差界. 由于  $V_1, V_2$  的列空间正交,

$$\|\mathbf{x}\|_2^2 = \|\Sigma_1^{-1} U_1^T \mathbf{b}\|_2^2 + \|\mathbf{z}_2\|_2^2. \quad (12.62)$$

所以二范数最小当且仅当  $\mathbf{z}_2 = \mathbf{0}$ . 此时

$$\begin{aligned} \|\mathbf{x}\|_2 &= \|\Sigma_1^{-1} U_1^T \mathbf{b}\|_2 \\ &\leq \|\Sigma_1^{-1}\|_2 \|U_1^T\|_2 \|\mathbf{b}\|_2 \\ &= \frac{\|\mathbf{b}\|_2}{\sigma}. \end{aligned} \quad (12.63)$$

该最小范数解正是  $\mathbf{x}_\dagger = A^\dagger \mathbf{b}$ .

□

## 12.4 补充训练题: 丘赛 2026 Problem 5——奇异值与固定点

### 完整题目叙述

[Yau-2026-Problem-5]

设  $A \in \mathbb{R}^{n \times n}$ ,  $\sigma_i(A)$  表示  $A$  的第  $i$  大奇异值. 若  $A\mathbf{x} = \mathbf{x}$ , 则称  $\mathbf{x}$  为  $A$  的固定点.

(a) 假设  $\sigma_1(A) \leq 1$ . 证明  $A$  的每个固定点也是  $A^T$  的固定点;

(b) 取  $A = \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix}$ , 验证若去掉  $\sigma_1(A) \leq 1$  的假设, 第 (a) 问结论一般不成立;

(c) 假设  $AA^T = A^T A$ . 证明  $A$  的每个固定点都是  $A^T$  的固定点.

第 (a) 问. 设  $A\mathbf{x} = \mathbf{x}$ . 若  $\mathbf{x} = \mathbf{0}$ , 结论显然. 以下设  $\mathbf{x} \neq \mathbf{0}$ .

由  $\sigma_1(A) = \|A\|_2 \leq 1$  和  $A\mathbf{x} = \mathbf{x}$ ,  $\|A\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ . 另一方面,  $I - A^T A \succeq 0$ , 因为对任意  $\mathbf{y}$ ,  $\mathbf{y}^T(I - A^T A)\mathbf{y} = \|\mathbf{y}\|_2^2 - \|A\mathbf{y}\|_2^2 \geq 0$ . 对  $\mathbf{x}$  有  $\mathbf{x}^T(I - A^T A)\mathbf{x} = \|\mathbf{x}\|_2^2 - \|A\mathbf{x}\|_2^2 = 0$ . 半正定矩阵  $M \succeq 0$  满足  $\mathbf{x}^T M \mathbf{x} = 0 \implies M\mathbf{x} = \mathbf{0}$ . 因此  $A^T A\mathbf{x} = \mathbf{x}$ . 再利用  $A\mathbf{x} = \mathbf{x}$ ,  $A^T \mathbf{x} = A^T A\mathbf{x} = \mathbf{x}$ . □



第 (b) 问. 取  $\mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ . 则  $A\mathbf{x} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \mathbf{x}$ , 所以  $\mathbf{x}$  是  $A$  的固定点。

但  $A^T \mathbf{x} = \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \neq \mathbf{x}$ . 故  $\mathbf{x}$  不是  $A^T$  的固定点。

同时  $A^T A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$  的最大特征值为 2, 所以  $\sigma_1(A) = \sqrt{2} > 1$ . □

第 (c) 问. 令  $N = A - I$ . 由  $AA^T = A^T A$  可知  $N$  也是正规矩阵:

$$\begin{aligned} NN^T &= (A - I)(A^T - I) \\ &= AA^T - A - A^T + I, \\ N^T N &= (A^T - I)(A - I) \\ &= A^T A - A - A^T + I. \end{aligned}$$

故  $NN^T = N^T N$ .

对任意  $\mathbf{x}$ ,  $\|N^T \mathbf{x}\|_2^2 = \mathbf{x}^T N N^T \mathbf{x} = \mathbf{x}^T N^T N \mathbf{x} = \|N \mathbf{x}\|_2^2$ . 若  $A\mathbf{x} = \mathbf{x}$ , 则  $N\mathbf{x} = \mathbf{0}$ . 因此  $\|N^T \mathbf{x}\|_2 = 0$ , 即  $(A^T - I)\mathbf{x} = \mathbf{0}$ . 故  $A^T \mathbf{x} = \mathbf{x}$ . □

## 12.5 最佳低秩逼近与 Eckart-Young-Mirsky 定理

### 12.5.1 知识点八: 截断 SVD

设  $A = U\Sigma V^H = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^H$ . 对  $0 \leq k < r$ , 定义截断 SVD

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^H = U_k \Sigma_k V_k^H. \quad (12.64)$$

显然  $\text{rank}(A_k) \leq k$ . 若  $\sigma_k > 0$ , 则  $\text{rank}(A_k) = k$ .

残差为

$$A - A_k = \sum_{i=k+1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^H. \quad (12.65)$$

所以

$$\|A - A_k\|_2 = \sigma_{k+1}, \quad (12.66)$$


$$\|A - A_k\|_F = \left( \sum_{i=k+1}^r \sigma_i^2 \right)^{1/2}. \quad (12.67)$$

定理 12.7 (Eckart-Young-Mirsky 定理). 设  $A \in \mathbb{C}^{m \times n}$ ,  $0 \leq k < q = \min\{m, n\}$ . 则

$$\min_{\text{rank}(B) \leq k} \|A - B\|_2 = \sigma_{k+1}, \quad (12.68)$$

$$\min_{\text{rank}(B) \leq k} \|A - B\|_F = \left( \sum_{i=k+1}^q \sigma_i^2 \right)^{1/2}. \quad (12.69)$$

两种范数下,  $A_k$  均为一个最优解。



谱范数情形. 任取  $\text{rank}(B) \leq k$ . 则  $\dim \mathcal{N}(B) \geq n - k$ . 令  $\mathcal{V}_{k+1} = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\}$ , 其维数为  $k+1$ . 由维数公式,  $\dim(\mathcal{N}(B) \cap \mathcal{V}_{k+1}) \geq 1$ . 故存在单位向量  $\mathbf{x} \in \mathcal{N}(B) \cap \mathcal{V}_{k+1}$ . 于是  $B\mathbf{x} = \mathbf{0}$ . 写  $\mathbf{x} = \sum_{i=1}^{k+1} \alpha_i \mathbf{v}_i$ ,  $\sum_{i=1}^{k+1} |\alpha_i|^2 = 1$ . 则

$$\begin{aligned} \|A - B\|_2 &\geq \|(A - B)\mathbf{x}\|_2 \\ &= \|A\mathbf{x}\|_2 \\ &= \left( \sum_{i=1}^{k+1} \sigma_i^2 |\alpha_i|^2 \right)^{1/2} \\ &\geq \sigma_{k+1}. \end{aligned} \quad (12.70)$$

而  $A_k$  达到该下界. □

Frobenius 范数情形. 设  $B$  的奇异值为  $\tau_1 \geq \dots \geq \tau_q \geq 0$ . 由  $\text{rank}(B) \leq k$ , 有  $\tau_{k+1} = \dots = \tau_q = 0$ . 由 Mirsky 奇异值扰动不等式,

$$\begin{aligned} \|A - B\|_F^2 &\geq \sum_{i=1}^q (\sigma_i - \tau_i)^2 \\ &\geq \sum_{i=k+1}^q \sigma_i^2. \end{aligned} \quad (12.71)$$

$A_k$  满足  $\|A - A_k\|_F^2 = \sum_{i=k+1}^q \sigma_i^2$ , 故达到下界. □

注 12.8 (关于“秩- $k$ ”与“秩不超过  $k$ ”). 最佳低秩逼近定理的标准可闭优化集合是  $\{B : \text{rank}(B) \leq k\}$ .

若题目字面写“ $\text{rank}(B) = k$ ”, 则:

- 当  $\sigma_k > 0$  时,  $A_k$  恰为秩  $k$ , 结论不变;
- 当  $\text{rank}(A) < k$  时, 精确秩  $k$  集合不是闭集, 最小值可能不取得; 此时只能说下确界为 0.

资格考试中应主动说明这一点。

### 12.5.2 知识点九: 最优解唯一性

在 Frobenius 范数下, 若

$$\sigma_k > \sigma_{k+1}, \quad (12.72)$$

则最佳秩不超过  $k$  逼近  $A_k$  唯一。

若  $\sigma_k = \sigma_{k+1}$ , 则在对应重奇异子空间内可以旋转, 最优解通常不唯一。

谱范数下, 即使  $\sigma_k > \sigma_{k+1}$ , 最优解也可能不唯一。例如  $A = \text{diag}(3, 2, 1)$ ,  $k = 1$ . 有  $A_1 = \text{diag}(3, 0, 0)$ , 且  $\|A - A_1\|_2 = 2$ . 但  $B = \text{diag}(2, 0, 0)$  同样满足  $\text{rank}(B) = 1$ ,  $\|A - B\|_2 = 2$ .

### 12.5.3 知识点十: 压缩、存储与快速乘法

若用  $A_k = U_k \Sigma_k V_k^H$  存储低秩矩阵, 则:

- 稠密存储  $A$  需  $mn$  个数;
- 因子存储需  $mk + k + nk = (m + n + 1)k$  个数;
- 矩阵-向量乘法  $A_k \mathbf{x} = U_k [\Sigma_k (V_k^H \mathbf{x})]$  需要  $O((m + n)k)$  运算, 而非  $O(mn)$ ;



- 若只需谱范数相对误差不超过  $\varepsilon$ , 可选择最小  $k$  满足  $\sigma_{k+1} \leq \varepsilon \sigma_1$ ;
- 若需 Frobenius 相对误差不超过  $\varepsilon$ , 可选择最小  $k$  满足  $\sum_{i=k+1}^r \sigma_i^2 \leq \varepsilon^2 \sum_{i=1}^r \sigma_i^2$ .

## 12.6 正式真题 [24S-Q1]——两种范数下的最佳秩- $k$ 逼近

完整题目叙述: [24S-Q1]

设  $k \leq n \leq m$ ,  $A \in \mathbb{C}^{m \times n}$ .

1. 求一个秩- $k$  矩阵  $X$ , 使对任意秩- $k$  矩阵  $B$ ,

$$\|A - X\|_2 \leq \|A - B\|_2; \quad (12.73)$$

2. 求一个秩- $k$  矩阵  $X$ , 使对任意秩- $k$  矩阵  $B$ ,

$$\|A - X\|_F \leq \|A - B\|_F. \quad (12.74)$$

注 12.9 (题意约定). 正式题面写“rank- $k$ ”. 其标准数学意图是最佳秩不超过  $k$  逼近, 或隐含假设  $\sigma_k(A) > 0$ . 以下在  $\text{rank}(B) \leq k$  的标准约定下作答; 若  $\sigma_k > 0$ , 所得  $X$  确为秩  $k$ .

完整解答. 设  $A$  的 SVD 为  $A = U\Sigma V^H = \sum_{i=1}^q \sigma_i \mathbf{u}_i \mathbf{v}_i^H$ ,  $q = \min\{m, n\}$ , 其中  $\sigma_1 \geq \cdots \geq \sigma_q \geq 0$ . 定义

$$X = A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^H. \quad (12.75)$$

由 Eckart–Young–Mirsky 定理,

$$\|A - A_k\|_2 = \sigma_{k+1} \leq \|A - B\|_2, \quad (12.76)$$

$$\|A - A_k\|_F = \left( \sum_{i=k+1}^q \sigma_i^2 \right)^{1/2} \leq \|A - B\|_F \quad (12.77)$$

对所有  $\text{rank}(B) \leq k$  成立。

为完整展示谱范数下界, 任取秩不超过  $k$  的  $B$ . 在  $\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_{k+1}\}$  中可找到单位向量  $\mathbf{z}$  满足  $B\mathbf{z} = 0$ , 于是  $\|A - B\|_2 \geq \|A\mathbf{z}\|_2 \geq \sigma_{k+1}$ .

Frobenius 范数下,  $B$  的第  $k+1$  及以后奇异值为零, 由 Mirsky 不等式,  $\|A - B\|_F^2 \geq \sum_{i=k+1}^q \sigma_i^2$ . 所以同一个截断 SVD 同时解决两问。□

### 易错点与反例

1. 不能把特征值截断代替一般矩阵的奇异值截断;
2. 谱范数误差不是  $\sum_{i>k} \sigma_i$ ;
3. Frobenius 误差必须对尾部奇异值平方后求和再开根号;
4. 若  $\sigma_k = 0$ ,  $A_k$  的秩小于  $k$ ;
5. 谱范数最优解一般不唯一。

## 12.7 补充训练题：数值代数题目合辑中的低秩与 PCA 母题

### 12.7.1 补充题一：Frobenius 范数下的最佳秩- $k$ 逼近

完整题目叙述：[NLA-Set-2012-Q4(2)]

给定  $A \in \mathbb{R}^{n \times n}$ ,  $A = U\Sigma V^T$ , 其中  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ ,  $\sigma_1 \geq \dots \geq \sigma_n \geq 0$ 。设  $U_k = (\mathbf{u}_1, \dots, \mathbf{u}_k)$ ,  $V_k = (\mathbf{v}_1, \dots, \mathbf{v}_k)$ ,  $\Sigma_k = \text{diag}(\sigma_1, \dots, \sigma_k)$ , 并定义  $A_k = U_k \Sigma_k V_k^T$ 。证明

$$\min_{\text{rank}(B)=k} \|A - B\|_F^2 = \|A - A_k\|_F^2 = \sum_{i=k+1}^n \sigma_i^2. \quad (12.78)$$

证明. 在  $\sigma_k > 0$  时,  $A_k$  恰为秩  $k$ 。任意秩不超过  $k$  的  $B$  只有至多  $k$  个非零奇异值。由 Mirsky 不等式,  $\|A - B\|_F^2 \geq \sum_{i=k+1}^n \sigma_i^2$ 。另一方面,  $A - A_k = \sum_{i=k+1}^n \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ 。各秩一项在 Frobenius 内积下相互正交, 故  $\|A - A_k\|_F^2 = \sum_{i=k+1}^n \sigma_i^2$ 。因此  $A_k$  最优。

若  $\sigma_k = 0$ , 则应把优化集合改写为  $\text{rank}(B) \leq k$ ; 否则“秩恰为  $k$ ”的最小值未必取得。□

### 12.7.2 补充题二：无中心 PCA

完整题目叙述：[NLA-Set-2018-Oral-Team-Q1]

给定列向量  $\mathbf{y}_1, \dots, \mathbf{y}_N \in \mathbb{R}^m$ , 记  $\mathcal{V} = \text{span}\{\mathbf{y}_1, \dots, \mathbf{y}_N\}$ 。给定  $\ell \leq \dim \mathcal{V}$ , 求  $\ell$  个正交归一向量  $\psi_1, \dots, \psi_\ell \in \mathbb{R}^m$  使

$$J(\psi_1, \dots, \psi_\ell) = \sum_{j=1}^N \left\| \mathbf{y}_j - \sum_{i=1}^{\ell} (\mathbf{y}_j^T \psi_i) \psi_i \right\|_2^2 \quad (12.79)$$

最小。

证明. 令  $Y = (\mathbf{y}_1 \ \dots \ \mathbf{y}_N) \in \mathbb{R}^{m \times N}$ , 并令  $\Psi = (\psi_1 \ \dots \ \psi_\ell)$ ,  $\Psi^T \Psi = I_\ell$ 。正交投影为  $P_\Psi = \Psi \Psi^T$ 。目标函数可写成

$$\begin{aligned} J(\Psi) &= \|(I - P_\Psi)Y\|_F^2 \\ &= \text{tr}[Y^T(I - P_\Psi)Y] \\ &= \|Y\|_F^2 - \text{tr}(\Psi^T Y Y^T \Psi). \end{aligned} \quad (12.80)$$

所以最小化  $J$  等价于最大化  $\text{tr}(\Psi^T Y Y^T \Psi)$ 。

设  $Y = U\Sigma V^T$  为 SVD。则  $Y Y^T$  的特征值为  $\sigma_i^2$ , 特征向量为左奇异向量  $\mathbf{u}_i$ 。由 Ky Fan 最大原理,

$$\max_{\Psi^T \Psi = I_\ell} \text{tr}(\Psi^T Y Y^T \Psi) = \sum_{i=1}^{\ell} \sigma_i^2. \quad (12.81)$$


因此可取

$$\psi_i = \mathbf{u}_i, \quad i = 1, \dots, \ell. \quad (12.82)$$

最小值为

$$J_{\min} = \sum_{i=\ell+1}^r \sigma_i^2. \quad (12.83)$$

若  $\sigma_\ell > \sigma_{\ell+1}$ , 最优子空间唯一; 若有重奇异值, 最优基可以在相应奇异子空间内旋转。□



## 12.7.3 补充题三：带平移的仿射 PCA

完整题目叙述：[NLA-Set-2012-Q4(3)]

原题同时用  $n$  表示环境维数和样本数。为避免混淆，等价重记如下。

给定样本  $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathbb{R}^m$ 。用  $d$  维仿射子空间近似这些样本：

$$\mathbf{x}_j = \mathbf{c} + W\mathbf{r}_j + \mathbf{e}_j, \quad j = 1, \dots, N, \quad (12.84)$$

其中  $W \in \mathbb{R}^{m \times d}$ ,  $W^\top W = I_d$ 。记  $X = \begin{pmatrix} \mathbf{x}_1 & \dots & \mathbf{x}_N \end{pmatrix}$ ,  $R = \begin{pmatrix} \mathbf{r}_1 & \dots & \mathbf{r}_N \end{pmatrix}$ ,  $E = \begin{pmatrix} \mathbf{e}_1 & \dots & \mathbf{e}_N \end{pmatrix}$ 。求  $W, R, \mathbf{c}$  使

$$\|E\|_F = \|X - \mathbf{c}\mathbf{1}^\top - WR\|_F \quad (12.85)$$

最小。

证明。定义样本均值

$$\bar{\mathbf{x}} = \frac{1}{N} X \mathbf{1}. \quad (12.86)$$

令中心化矩阵

$$X_c = X - \bar{\mathbf{x}}\mathbf{1}^\top. \quad (12.87)$$

固定  $W, \mathbf{c}$  时，关于  $R$  的最小二乘解为

$$R = W^\top (X - \mathbf{c}\mathbf{1}^\top). \quad (12.88)$$

代回得  $E = (I - WW^\top)(X - \mathbf{c}\mathbf{1}^\top)$ 。

对  $\mathbf{c}$  求最优条件：

$$\begin{aligned} 0 &= (I - WW^\top)(X - \mathbf{c}\mathbf{1}^\top)\mathbf{1} \\ &= N(I - WW^\top)(\bar{\mathbf{x}} - \mathbf{c}). \end{aligned} \quad (12.89)$$

因此只需

$$(I - WW^\top)\mathbf{c} = (I - WW^\top)\bar{\mathbf{x}}. \quad (12.90)$$

沿  $\mathcal{R}(W)$  方向改变  $\mathbf{c}$ ，可由  $R$  中的平移吸收。标准规范化选择为

$$\boxed{\mathbf{c} = \bar{\mathbf{x}}}. \quad (12.91)$$

此时

$$R = W^\top X_c, \quad (12.92)$$

且

$$\|E\|_F^2 = \|(I - WW^\top)X_c\|_F^2. \quad (12.93)$$

设  $X_c = U\Sigma V^\top$ 。由上一题，最优  $W$  由前  $d$  个左奇异向量组成：

$$\boxed{W = U_d}. \quad (12.94)$$


从而

$$\boxed{R = U_d^\top X_c = \Sigma_d V_d^\top}. \quad (12.95)$$

最小误差为

$$\boxed{\|E\|_{F,\min}^2 = \sum_{i=d+1}^r \sigma_i(X_c)^2}. \quad (12.96)$$

□



## 12.7.4 补充题四：满秩矩阵稠密性与秩稳定性

完整题目叙述：[NLA-Set-2015-Team-Q5]

 设  $A \in \mathbb{R}^{m \times n}$ ,  $r = \text{rank}(A) < q := \min\{m, n\}$ , 且  $A = U\Sigma V^T$  为 SVD,  $\sigma_1 \geq \dots \geq \sigma_r > 0$ .

 (a) 证明对任意  $\varepsilon > 0$ , 存在满秩矩阵  $A_\varepsilon$  使  $\|A - A_\varepsilon\|_2 = \varepsilon$ ;

 (b) 对  $1 \leq k \leq r-1$ , 令  $A_k = U\Sigma_k V^T$ . 证明  $\text{rank}(A_k) = k$  且

$$\sigma_{k+1} = \|A - A_k\|_2 = \min_{\text{rank}(B) \leq k} \|A - B\|_2; \quad (12.97)$$

 (c) 假设  $r = q$ , 若  $\|A - B\|_2 < \sigma_r$ , 证明  $\text{rank}(B) = r$ .

 第 (a) 问. 将完整 SVD 写为  $A = U \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0) V^T$ . 定义

$$A_\varepsilon = U \text{diag}(\sigma_1, \dots, \sigma_r, \varepsilon, \dots, \varepsilon) V^T. \quad (12.98)$$

 $A_\varepsilon$  具有  $q$  个非零奇异值, 故为满秩矩阵。

 同时  $A_\varepsilon - A = U \text{diag}(0, \dots, 0, \varepsilon, \dots, \varepsilon) V^T$ , 所以  $\|A_\varepsilon - A\|_2 = \varepsilon$ .  $\square$ 

 第 (b) 问. 由于  $\sigma_k > 0$ ,  $A_k$  恰有  $k$  个非零奇异值, 故  $\text{rank}(A_k) = k$ . 其残差最大奇异值为  $\sigma_{k+1}$ , 所以  $\|A - A_k\|_2 = \sigma_{k+1}$ . 由 Eckart-Young-Mirsky 定理, 任意秩不超过  $k$  的  $B$  满足  $\|A - B\|_2 \geq \sigma_{k+1}$ .  $\square$ 

第 (c) 问. 由奇异值扰动界,

$$\begin{aligned} \sigma_r(B) &\geq \sigma_r(A) - \|A - B\|_2 \\ &> 0. \end{aligned} \quad (12.99)$$

 所以  $B$  至少有  $r = q$  个非零奇异值. 矩阵最大可能秩即为  $q$ , 因此  $\text{rank}(B) = q = r$ .  $\square$ 

## 12.8 核范数、迹对偶与奇异值软阈值

## 12.8.1 知识点十一：Schatten 范数的统一视角

 对奇异值向量  $\sigma(A) = (\sigma_1, \dots, \sigma_q)$ , 定义 Schatten- $p$  范数  $\|A\|_{S_p} = \|\sigma(A)\|_p$ . 特别地,

$$\|A\|_{S_\infty} = \|A\|_2 = \max_i \sigma_i, \quad (12.100)$$

$$\|A\|_{S_2} = \|A\|_F = \left( \sum_i \sigma_i^2 \right)^{1/2}, \quad (12.101)$$

$$\|A\|_{S_1} = \|A\|_* = \sum_i \sigma_i. \quad (12.102)$$

 矩阵秩为  $\text{rank}(A) = \|\sigma(A)\|_0$ , 而核范数相当于对奇异值使用  $\ell^1$  范数, 因此是秩函数的重要凸替代。

定义 12.10 (核范数).

$$\|A\|_* = \sum_{i=1}^q \sigma_i(A). \quad (12.103)$$

核范数还是谱范数的对偶范数:

$$\|A\|_* = \max_{\|Y\|_2 \leq 1} \operatorname{Re} \operatorname{tr}(Y^H A). \quad (12.104)$$

证明. 设  $A = U\Sigma V^H$ . 由 von Neumann 迹不等式,  $\operatorname{Re} \operatorname{tr}(Y^H A) \leq \sum_i \sigma_i(Y) \sigma_i(A)$ . 若  $\|Y\|_2 \leq 1$ , 则  $\sigma_i(Y) \leq 1$ , 从而  $\operatorname{Re} \operatorname{tr}(Y^H A) \leq \sum_i \sigma_i(A) = \|A\|_*$ . 取  $Y = UV^H$  的相应部分等距因子, 即达到等号.  $\square$

### 12.8.2 补充训练题: 核范数的四个结论

完整题目叙述: [NLA-Set-2018-Q5]

设  $A \in \mathbb{R}^{n \times n}$ , 其核范数定义为  $\|A\|_* = \sum_{i=1}^n \sigma_i(A)$ .

(1) 证明

$$\|A\|_* = \operatorname{tr} \sqrt{A^T A}; \quad (12.105)$$

(2) 证明

$$\|A\|_* = \max_{X^T X = I} \operatorname{tr}(AX); \quad (12.106)$$

(3) 证明

$$\|A + B\|_* \leq \|A\|_* + \|B\|_*; \quad (12.107)$$

(4) 解释为什么对固定  $A_0$  最小化

$$\|A - A_0\|_F^2 + \|A\|_* \quad (12.108)$$

会产生  $A_0$  的低秩近似。

第 (1) 问. 设  $A = U\Sigma V^T$ . 则  $A^T A = V\Sigma^2 V^T$ , 所以  $\sqrt{A^T A} = V\Sigma V^T$ . 故  $\operatorname{tr} \sqrt{A^T A} = \operatorname{tr} \Sigma = \sum_{i=1}^n \sigma_i = \|A\|_*$ .  $\square$

第 (2) 问. 对任意正交矩阵  $X$ , 令  $Z = V^T X U$ . 则  $Z$  仍为正交矩阵. 于是

$$\begin{aligned} \operatorname{tr}(AX) &= \operatorname{tr}(U\Sigma V^T X) \\ &= \operatorname{tr}(\Sigma V^T X U) \\ &= \sum_{i=1}^n \sigma_i z_{ii}. \end{aligned} \quad (12.109)$$

由于正交矩阵满足  $|z_{ii}| \leq 1$ , 有  $\operatorname{tr}(AX) \leq \sum_i \sigma_i = \|A\|_*$ . 取


$$X = V U^T \quad (12.110)$$

时,  $Z = I$ , 达到等号.  $\square$

第 (3) 问. 由谱范数-核范数对偶,

$$\begin{aligned} \|A + B\|_* &= \max_{\|Y\|_2 \leq 1} \operatorname{tr}[Y^T(A + B)] \\ &\leq \max_{\|Y\|_2 \leq 1} \operatorname{tr}(Y^T A) + \max_{\|Y\|_2 \leq 1} \operatorname{tr}(Y^T B) \\ &= \|A\|_* + \|B\|_*. \end{aligned} \quad (12.111)$$

因此核范数满足三角不等式.  $\square$





第 (4) 问：奇异值软阈值的精确推导. 设  $A_0 = U \text{diag}(\sigma_1, \dots, \sigma_n) V^T$ . 更一般地, 考虑

$$\min_A \left\{ \frac{1}{2} \|A - A_0\|_F^2 + \lambda \|A\|_* \right\}, \lambda > 0. \quad (12.112)$$

设  $A$  的奇异值为  $s_i$ . 由 von Neumann 迹不等式, 在固定  $s_i$  时, 目标函数在  $A$  与  $A_0$  共享左右奇异向量时最小. 因此问题化为彼此独立的标量问题:

$$\min_{s_i \geq 0} \left[ \frac{1}{2} (s_i - \sigma_i)^2 + \lambda s_i \right]. \quad (12.113)$$

其最优解为

$$s_i^* = (\sigma_i - \lambda)_+ := \max\{\sigma_i - \lambda, 0\}. \quad (12.114)$$

故

$$A^* = U \text{diag}((\sigma_i - \lambda)_+) V^T. \quad (12.115)$$

题中的目标为  $\|A - A_0\|_F^2 + \|A\|_* = 2 \left[ \frac{1}{2} \|A - A_0\|_F^2 + \frac{1}{2} \|A\|_* \right]$ , 所以对应  $\lambda = \frac{1}{2}$ . 其解为

$$A^* = U \text{diag}((\sigma_i - \frac{1}{2})_+) V^T. \quad (12.116)$$

所有不超过阈值  $1/2$  的奇异值都变为零, 因此  $A^*$  通常是低秩矩阵.  $\square$

#### Algorithm 48 奇异值软阈值算子

**Input:** 矩阵  $A_0$ ; 阈值  $\lambda > 0$

**Output:**  $\text{prox}_{\lambda \|\cdot\|_*}(A_0)$

- 1: 计算 SVD  $A_0 = U \Sigma V^H$
- 2: 对每个奇异值执行  $\tilde{\sigma}_i \leftarrow \max\{\sigma_i - \lambda, 0\}$
- 3: 返回  $A^* = U \text{diag}(\tilde{\sigma}_i) V^H$
- 4: **Stopping criterion:** 全部奇异值完成阈值化
- 5: **Complexity:** 若使用完整稠密 SVD, 成本为  $O(mn \min\{m, n\})$ ; 若只保留大于阈值的少数奇异值, 可用 Lanczos 或随机 SVD 降低成本

## 12.9 病态最小二乘与正则化

### 12.9.1 知识点十二：小奇异值放大噪声

设  $A = U_r \Sigma_r V_r^H$ , 最小范数最小二乘解为

$$\mathbf{x}_\dagger = \sum_{i=1}^r \frac{\mathbf{u}_i^H \mathbf{b}}{\sigma_i} \mathbf{v}_i. \quad (12.117)$$

若数据含噪声  $\mathbf{b}^\delta = \mathbf{b} + \delta \mathbf{b}$ , 则

$$\mathbf{x}_\dagger^\delta - \mathbf{x}_\dagger = \sum_{i=1}^r \frac{\mathbf{u}_i^H \delta \mathbf{b}}{\sigma_i} \mathbf{v}_i. \quad (12.118)$$

小奇异值会将对应噪声分量放大为  $O(\sigma_i^{-1})$ .

#### 易错点与反例

SVD 能精确揭示病态方向, 但“使用 SVD”本身并不会自动消除病态性。

若仍对所有非零奇异值直接取倒数, 噪声放大依旧存在. 正则化的核心是抑制小奇异值方向。

### 12.9.2 知识点十三：截断 SVD 正则化

给定截断指标  $k$ ，定义

$$\mathbf{x}_k^\delta = \sum_{i=1}^k \frac{\mathbf{u}_i^H \mathbf{b}^\delta}{\sigma_i} \mathbf{v}_i. \quad (12.119)$$

其滤波因子为  $\phi_i^{(k)} = \begin{cases} 1, & i \leq k, \\ 0, & i > k. \end{cases}$

若  $\mathbf{x}^\dagger$  为无噪最小范数解，则

$$\begin{aligned} \mathbf{x}_k^\delta - \mathbf{x}^\dagger &= - \sum_{i=k+1}^r (\mathbf{v}_i^H \mathbf{x}^\dagger) \mathbf{v}_i \\ &\quad + \sum_{i=1}^k \frac{\mathbf{u}_i^H \delta \mathbf{b}}{\sigma_i} \mathbf{v}_i. \end{aligned} \quad (12.120)$$

因此

$$\|\mathbf{x}_k^\delta - \mathbf{x}^\dagger\|_2 \leq \left( \sum_{i=k+1}^r |\mathbf{v}_i^H \mathbf{x}^\dagger|^2 \right)^{1/2} + \frac{\|\delta \mathbf{b}\|_2}{\sigma_k}. \quad (12.121)$$

第一项是截断偏差，第二项是噪声传播。增大  $k$  会减小偏差，却可能增大噪声放大。

### 12.9.3 知识点十四：Tikhonov 正则化

标准 Tikhonov 问题为

$$\min_{\mathbf{x}} \left[ \|\mathbf{A}\mathbf{x} - \mathbf{b}^\delta\|_2^2 + \lambda^2 \|\mathbf{x}\|_2^2 \right], \quad \lambda > 0. \quad (12.122)$$

正规方程为

$$(\mathbf{A}^H \mathbf{A} + \lambda^2 \mathbf{I}) \mathbf{x}_\lambda^\delta = \mathbf{A}^H \mathbf{b}^\delta. \quad (12.123)$$

由于  $\mathbf{A}^H \mathbf{A} + \lambda^2 \mathbf{I} \succ 0$ ，解唯一。

SVD 表达为

$$\mathbf{x}_\lambda^\delta = \sum_{i=1}^r \frac{\sigma_i}{\sigma_i^2 + \lambda^2} (\mathbf{u}_i^H \mathbf{b}^\delta) \mathbf{v}_i. \quad (12.124)$$

相对于伪逆展开，滤波因子为

$$\phi_i(\lambda) = \frac{\sigma_i^2}{\sigma_i^2 + \lambda^2}. \quad (12.125)$$

噪声放大系数满足

$$\max_{\sigma \geq 0} \frac{\sigma}{\sigma^2 + \lambda^2} = \frac{1}{2\lambda}. \quad (12.126)$$


因此

$$\|\mathbf{x}_\lambda^\delta - \mathbf{x}_\lambda\|_2 \leq \frac{\|\delta \mathbf{b}\|_2}{2\lambda}. \quad (12.127)$$

更一般的形式为

$$\min_{\mathbf{x}} \left[ \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 + \lambda^2 \|\mathbf{L}\mathbf{x}\|_2^2 \right], \quad (12.128)$$

其中  $\mathbf{L}$  编码平滑性、导数、边界条件或先验结构。此时可用广义 SVD 分析。



| 方法       | 解的奇异向量展开                            | 参数作用             | 典型失败情形                    |
|----------|-------------------------------------|------------------|---------------------------|
| 伪逆       | $1/\sigma_i$                        | 不抑制任何非零奇异值       | 小奇异值强烈放大噪声                |
| TSVD     | $i \leq k$ 保留, $i > k$ 删除           | $k$ 控制保留维数       | 硬截断可能丢失有用信息; 谱间无明显间隙时参数敏感 |
| Tikhonov | $\sigma_i/(\sigma_i^2 + \lambda^2)$ | $\lambda$ 平滑控制衰减 | $\lambda$ 过大产生偏差, 过小仍放大噪声 |
| 核范数正则    | 对矩阵奇异值作软阈值                          | 促进低秩             | 大奇异值也被收缩, 可能产生系统性偏差       |

## 12.10 低秩更新: Sherman–Morrison、Woodbury 与行列式引理

### 12.10.1 知识点十五: Sylvester 行列式恒等式

若  $U \in \mathbb{C}^{n \times r}$ ,  $V \in \mathbb{C}^{n \times r}$ , 则

$$\det(I_n + UV^H) = \det(I_r + V^H U). \quad (12.129)$$

这使  $n \times n$  行列式转化为  $r \times r$  行列式。

一种证明使用分块矩阵  $\begin{pmatrix} I_n & U \\ -V^H & I_r \end{pmatrix}$  分别对两个对角块取 Schur 补。

### 12.10.2 知识点十六: 矩阵行列式引理

若  $A \in \mathbb{C}^{n \times n}$  非奇异, 则

$$\det(A + UV^H) = \det(A) \det(I_r + V^H A^{-1} U). \quad (12.130)$$

因为  $A + UV^H = A(I_n + A^{-1}UV^H)$ , 再应用 Sylvester 恒等式。

秩一情形为

$$\det(A + \mathbf{u}\mathbf{v}^H) = \det(A) (1 + \mathbf{v}^H A^{-1} \mathbf{u}). \quad (12.131)$$

### 12.10.3 知识点十七: Sherman–Morrison 公式

定理 12.11 (Sherman–Morrison). 设  $A$  非奇异。则  $A + \mathbf{u}\mathbf{v}^H$  非奇异, 当且仅当

$$1 + \mathbf{v}^H A^{-1} \mathbf{u} \neq 0. \quad (12.132)$$

此时

$$(A + \mathbf{u}\mathbf{v}^H)^{-1} = A^{-1} - \frac{A^{-1} \mathbf{u} \mathbf{v}^H A^{-1}}{1 + \mathbf{v}^H A^{-1} \mathbf{u}}. \quad (12.133)$$

证明. 可逆性的充要条件由 式 (12.131) 直接得到。



设  $\alpha = 1 + \mathbf{v}^H A^{-1} \mathbf{u} \neq 0$ , 并令  $M = A^{-1} - \frac{A^{-1} \mathbf{u} \mathbf{v}^H A^{-1}}{\alpha}$ 。直接计算:

$$\begin{aligned} (A + \mathbf{u} \mathbf{v}^H) M &= I - \frac{\mathbf{u} \mathbf{v}^H A^{-1}}{\alpha} + \mathbf{u} \mathbf{v}^H A^{-1} \\ &\quad - \frac{\mathbf{u} (\mathbf{v}^H A^{-1} \mathbf{u}) \mathbf{v}^H A^{-1}}{\alpha} \\ &= I + \mathbf{u} \mathbf{v}^H A^{-1} \left[ 1 - \frac{1 + \mathbf{v}^H A^{-1} \mathbf{u}}{\alpha} \right] \\ &= I. \end{aligned} \quad (12.134)$$

同理  $M(A + \mathbf{u} \mathbf{v}^H) = I$ 。 □

注 12.12. 这个公式非常重要, 在数值代数里面经常被用来处理矩阵的逆。证明就是直接展开, 没有任何秘密。

2025 年春季博资考考过这个公式, 虽然题目里面给了出来, 但我还是强烈建议你在考试前背下来:)

#### 12.10.4 知识点十八: Woodbury 公式

定理 12.13 (Woodbury 矩阵恒等式). 设  $A \in \mathbb{C}^{n \times n}$ ,  $C \in \mathbb{C}^{r \times r}$  均非奇异。则  $A + UCV^H$  非奇异, 当且仅当  $C^{-1} + V^H A^{-1} U$  非奇异。此时

$$(A + UCV^H)^{-1} = A^{-1} - A^{-1} U (C^{-1} + V^H A^{-1} U)^{-1} V^H A^{-1}. \quad (12.135)$$

当  $C = I_r$  时,

$$(A + UV^H)^{-1} = A^{-1} - A^{-1} U (I_r + V^H A^{-1} U)^{-1} V^H A^{-1}. \quad (12.136)$$

【复杂度】 假设  $A$  的分解已经可用,  $U, V \in \mathbb{C}^{n \times r}$  且  $r \ll n$ 。

求解  $(A + UV^H)\mathbf{x} = \mathbf{b}$  可按:

1. 解  $A\mathbf{y} = \mathbf{b}$ ;
2. 解  $r$  个右端项  $A\mathbf{Y} = U$ ;
3. 形成  $S = I_r + V^H \mathbf{Y}$ ;
4. 解  $S\mathbf{z} = V^H \mathbf{y}$ ;
5. 返回  $\mathbf{x} = \mathbf{y} - \mathbf{Y}\mathbf{z}$ .

稠密分解已知时, 成本约为

$$O(n^2 r + nr^2 + r^3), \quad (12.137)$$

远低于重新分解  $n \times n$  矩阵的  $O(n^3)$ 。

#### 易错点与反例

公式中出现  $A^{-1}$  不表示实现时应显式形成  $A^{-1}$ 。

稳定实现应使用线性方程求解:  $A\mathbf{Y} = U$ ,  $A\mathbf{y} = \mathbf{b}$ 。若  $I + V^H A^{-1} U$  接近奇异, 则更新后的矩阵也接近奇异, Woodbury 公式会放大舍入误差。

## 12.11 正式真题 [25S-Q3]——秩二余弦核快速算法

完整题目叙述: [25S-Q3]

Sherman–Morrison 公式指出: 若  $A \in \mathbb{R}^{n \times n}$  非奇异,  $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$  且  $1 + \mathbf{v}^\top A^{-1} \mathbf{u} \neq 0$ , 则  $(A + \mathbf{u}\mathbf{v}^\top)^{-1} = A^{-1} - \frac{A^{-1}\mathbf{u}\mathbf{v}^\top A^{-1}}{1 + \mathbf{v}^\top A^{-1} \mathbf{u}}$ .

(i) 证明上述结论;

(ii) 给定两组点  $\{s_j\}_{j=1}^n, \{t_j\}_{j=1}^n \subset [0, 1]$ , 定义

$$A_{jk} = 4n\delta_{jk} + \cos(t_j - s_k). \quad (12.138)$$

对任意  $\mathbf{b} \in \mathbb{R}^n$ , 给出计算  $A\mathbf{b}$ ,  $A^{-1}$ ,  $|A| = \det A$  的  $O(n)$  方法。

第 (i) 问. 由矩阵行列式引理,  $\det(A + \mathbf{u}\mathbf{v}^\top) = \det A (1 + \mathbf{v}^\top A^{-1} \mathbf{u})$ . 因此可逆性的充要条件正是  $1 + \mathbf{v}^\top A^{-1} \mathbf{u} \neq 0$ . 逆矩阵公式由 定义 12.11 的直接乘法验证得到.  $\square$

第 (ii) 问: 识别秩二结构. 利用

$$\cos(t_j - s_k) = \cos t_j \cos s_k + \sin t_j \sin s_k, \quad (12.139)$$

定义

$$\mathbf{c}_t = (\cos t_1, \dots, \cos t_n)^\top, \quad (12.140)$$

$$\mathbf{s}_t = (\sin t_1, \dots, \sin t_n)^\top, \quad (12.141)$$

$$\mathbf{c}_s = (\cos s_1, \dots, \cos s_n)^\top, \quad (12.142)$$

$$\mathbf{s}_s = (\sin s_1, \dots, \sin s_n)^\top. \quad (12.143)$$

令

$$U = \begin{pmatrix} \mathbf{c}_t & \mathbf{s}_t \end{pmatrix}, \quad V = \begin{pmatrix} \mathbf{c}_s & \mathbf{s}_s \end{pmatrix}. \quad (12.144)$$

则

$$A = 4nI + UV^\top. \quad (12.145)$$

因此非对角核部分的秩不超过 2.  $\square$

第 (ii) 问: 可逆性. 每一行  $(\cos t_j, \sin t_j)$  的二范数为 1, 因此  $\|U\|_F^2 = n$ ,  $\|V\|_F^2 = n$ . 故  $\|U\|_2 \leq \sqrt{n}$ ,  $\|V\|_2 \leq \sqrt{n}$ . 于是  $\|UV^\top\|_2 \leq n$ . 因此

$$\begin{aligned} \sigma_{\min}(A) &\geq 4n - \|UV^\top\|_2 \\ &\geq 3n > 0. \end{aligned} \quad (12.146)$$


所以  $A$  必非奇异。

等价地,  $\|\frac{1}{4n}V^\top U\|_2 \leq \frac{1}{4} < 1$ , 故  $M := I_2 + \frac{1}{4n}V^\top U$  非奇异.  $\square$

第 (ii) 问:  $A\mathbf{b}$  的  $O(n)$  算法. 由 式 (12.145),

$$\begin{aligned} A\mathbf{b} &= 4n\mathbf{b} + U(V^\top \mathbf{b}) \\ &= 4n\mathbf{b} + \mathbf{c}_t(\mathbf{c}_s^\top \mathbf{b}) + \mathbf{s}_t(\mathbf{s}_s^\top \mathbf{b}). \end{aligned} \quad (12.147)$$

只需两个长度  $n$  的内积和两个向量线性组合, 故时间复杂度为  $O(n)$ , 额外存储为  $O(n)$ .  $\square$



第 (ii) 问:  $A^{-1}$  的压缩表示. 由 Woodbury 公式,

$$A^{-1} = \frac{1}{4n}I - \frac{1}{(4n)^2}U \left( I_2 + \frac{1}{4n}V^T U \right)^{-1} V^T. \quad (12.148)$$

定义

$$G = V^T U = \begin{pmatrix} \mathbf{c}_s^T \mathbf{c}_t & \mathbf{c}_s^T \mathbf{s}_t \\ \mathbf{s}_s^T \mathbf{c}_t & \mathbf{s}_s^T \mathbf{s}_t \end{pmatrix}. \quad (12.149)$$

形成  $G$  需要四个长度  $n$  的内积, 即  $O(n)$  工作; 求逆  $(I_2 + \frac{1}{4n}G)^{-1}$  只需  $O(1)$  工作。

因此可以用  $(U, V, [I_2 + \frac{1}{4n}G]^{-1})$  作为  $A^{-1}$  的  $O(n)$  存储压缩表示。对任意向量  $\mathbf{b}$ ,

$$A^{-1}\mathbf{b} = \frac{1}{4n}\mathbf{b} - \frac{1}{(4n)^2}U \left( I_2 + \frac{1}{4n}G \right)^{-1} V^T \mathbf{b} \quad (12.150)$$

可在  $O(n)$  时间内计算。  $\square$

注 12.14 (输出规模的必要说明). 完整写出  $n \times n$  矩阵  $A^{-1}$  本身至少需要  $\Omega(n^2)$  输出量。因此题目所称“ $O(n)$  计算  $A^{-1}$ ”只能理解为:

- 构造  $A^{-1}$  的低秩压缩表示;
- 或在  $O(n)$  时间内计算  $A^{-1}\mathbf{b}$ 。

不能声称在  $O(n)$  时间内逐项输出  $n^2$  个逆矩阵元素。

第 (ii) 问: 行列式. 由矩阵行列式引理,

$$\begin{aligned} \det A &= \det(4nI) \det \left( I_2 + \frac{1}{4n}V^T U \right) \\ &= (4n)^n \det \left( I_2 + \frac{1}{4n}G \right). \end{aligned} \quad (12.151)$$

$G$  已在  $O(n)$  时间内形成, 剩余为  $2 \times 2$  行列式, 成本  $O(1)$ 。故总复杂度为  $O(n)$ 。  $\square$

---

#### Algorithm 49 [25S-Q3] 的统一预处理与应用

---

**Input:** 点集  $\{s_j\}, \{t_j\}$ ; 可选向量  $\mathbf{b}$

**Output:** 快速乘法、逆作用和行列式

- 1: **Initialization:** 构造  $\mathbf{c}_t, \mathbf{s}_t, \mathbf{c}_s, \mathbf{s}_s$  及  $U = [\mathbf{c}_t, \mathbf{s}_t]$ ,  $V = [\mathbf{c}_s, \mathbf{s}_s]$
  - 2: 形成  $G \leftarrow V^T U$
  - 3:  $M \leftarrow I_2 + \frac{1}{4n}G$
  - 4: 分解或显式求逆  $2 \times 2$  矩阵  $M$
  - 5: 行列式:  $\det A \leftarrow (4n)^n \det M$
  - 6: **if** 给定  $\mathbf{b}$  并要求  $A\mathbf{b}$  **then**
  - 7:      $A\mathbf{b} \leftarrow 4n\mathbf{b} + U(V^T \mathbf{b})$
  - 8: **end if**
  - 9: **if** 给定  $\mathbf{b}$  并要求  $A^{-1}\mathbf{b}$  **then**
  - 10:      $A^{-1}\mathbf{b} \leftarrow \frac{1}{4n}\mathbf{b} - \frac{1}{(4n)^2}UM^{-1}(V^T \mathbf{b})$
  - 11: **end if**
  - 12: **Stopping criterion:** 所有量均已计算
  - 13: **Complexity:** 预处理  $O(n)$ ; 每次矩阵或逆矩阵作用  $O(n)$ ; 存储  $O(n)$ ; 小矩阵运算  $O(1)$
- 



## 12.12 补充训练题：秩一更新、列替换与三对角显式逆

### 12.12.1 丘赛 2024 Problem 1：快速更新求解

完整题目叙述

[Yau-2024-Problem-1]

设  $A \in \mathbb{R}^{n \times n}$  非奇异,  $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ , 定义秩一扰动

$$\hat{A} = A + \mathbf{u}\mathbf{v}^\top. \quad (12.152)$$

- (a) 推导  $\hat{A}$  非奇异的充要条件;
- (b) 设对任意右端项, 方程  $A\mathbf{z} = \mathbf{b}$  可在  $O(n)$  个 FLOP 内求解。在第 (a) 问条件下, 设计  $O(n)$  算法求解  $\hat{A}\mathbf{x} = \mathbf{b}$ , 并证明。

第 (a) 问. 由行列式引理,  $\det \hat{A} = \det A (1 + \mathbf{v}^\top A^{-1} \mathbf{u})$ . 由于  $\det A \neq 0$ ,  $\hat{A}$  非奇异  $\iff 1 + \mathbf{v}^\top A^{-1} \mathbf{u} \neq 0$ . □

第 (b) 问. 先求解

$$A\mathbf{z} = \mathbf{b}, \quad (12.153)$$

$$A\mathbf{p} = \mathbf{u}. \quad (12.154)$$

由假设, 两次求解各需  $O(n)$  工作。

令  $d = 1 + \mathbf{v}^\top \mathbf{p} = 1 + \mathbf{v}^\top A^{-1} \mathbf{u} \neq 0$ . 定义

$$\mathbf{x} = \mathbf{z} - \mathbf{p} \frac{\mathbf{v}^\top \mathbf{z}}{d}. \quad (12.155)$$

验证:

$$\begin{aligned} \hat{A}\mathbf{x} &= (A + \mathbf{u}\mathbf{v}^\top) \left[ \mathbf{z} - \mathbf{p} \frac{\mathbf{v}^\top \mathbf{z}}{d} \right] \\ &= \mathbf{b} - \mathbf{u} \frac{\mathbf{v}^\top \mathbf{z}}{d} + \mathbf{u}\mathbf{v}^\top \mathbf{z} - \mathbf{u}(\mathbf{v}^\top \mathbf{p}) \frac{\mathbf{v}^\top \mathbf{z}}{d} \\ &= \mathbf{b} + \mathbf{u}(\mathbf{v}^\top \mathbf{z}) \left[ 1 - \frac{1 + \mathbf{v}^\top \mathbf{p}}{d} \right] \\ &= \mathbf{b}. \end{aligned} \quad (12.156)$$

两个线性方程求解、两个点积及一次向量更新均为  $O(n)$ , 故总成本为  $O(n)$ 。若  $\mathbf{u}, \mathbf{v}$  固定且有多个右端项, 可预先计算  $\mathbf{p}$  和  $d$ , 每个新右端项只需一次  $A$  求解和  $O(n)$  更新。 □

### 12.12.2 数值代数题目合辑：列替换

完整题目叙述: [NLA-Set-2013-Oral-Q1]

设  $A \in \mathbb{R}^{n \times n}$  非奇异,  $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 。

- (a) 求  $A + \mathbf{u}\mathbf{v}^\top$  可逆的条件及其逆;
- (b) 将  $A$  的第一列  $\mathbf{a}_1$  替换为  $\mathbf{b}$ , 得到新矩阵  $\tilde{A}$ 。求  $\tilde{A}^{-1}$ 。



证明. 第 (a) 问即 Sherman–Morrison 公式。

第 (b) 问中,

$$\tilde{A} = A + (\mathbf{b} - \mathbf{a}_1)\mathbf{e}_1^\top. \quad (12.157)$$

令  $\mathbf{y} = A^{-1}\mathbf{b}$ 。因为  $A^{-1}\mathbf{a}_1 = \mathbf{e}_1$ , 有

$$\begin{aligned} 1 + \mathbf{e}_1^\top A^{-1}(\mathbf{b} - \mathbf{a}_1) &= 1 + \mathbf{e}_1^\top(\mathbf{y} - \mathbf{e}_1) \\ &= y_1. \end{aligned} \quad (12.158)$$

因此

$$\boxed{\tilde{A} \text{非奇异} \iff y_1 = (A^{-1}\mathbf{b})_1 \neq 0}. \quad (12.159)$$

在此条件下,

$$\begin{aligned} \tilde{A}^{-1} &= A^{-1} - \frac{A^{-1}(\mathbf{b} - \mathbf{a}_1)\mathbf{e}_1^\top A^{-1}}{y_1} \\ &= \boxed{A^{-1} - \frac{(\mathbf{y} - \mathbf{e}_1)\mathbf{e}_1^\top A^{-1}}{y_1}}. \end{aligned} \quad (12.160)$$

□

### 12.12.3 数值代数题目合辑：三对角矩阵的显式逆及题面核对

[NLA-Set-2017-Team-Q5]

设

$$A_\gamma = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & \gamma \end{pmatrix} \in \mathbb{R}^{n \times n}. \quad (12.161)$$

1. 显式求  $A_\gamma^{-1}$ ;
2. 证明对所有的  $n$ ,  $A_\gamma^{-1}$  全部元素非负当且仅当  $\gamma \geq 1$ 。

第一步：把矩阵写成秩一更新. 令

$$B = A_1. \quad (12.162)$$

可直接验证

$$(B^{-1})_{ij} = \min\{i, j\}. \quad (12.163)$$

例如可由  $B = DD^\top$  得到, 其中  $D$  为适当的单位下双对角差分矩阵。

记  $\mathbf{q} = B^{-1}\mathbf{e}_n = (1, 2, \dots, n)^\top$ . 又  $\mathbf{e}_n^\top B^{-1}\mathbf{e}_n = n$ 。由于

$$A_\gamma = B + (\gamma - 1)\mathbf{e}_n\mathbf{e}_n^\top, \quad (12.164)$$

Sherman–Morrison 公式给出


$$A_\gamma^{-1} = B^{-1} - \frac{(\gamma - 1)\mathbf{q}\mathbf{q}^\top}{1 + n(\gamma - 1)}, \quad (12.165)$$

前提是

$$1 + n(\gamma - 1) \neq 0. \quad (12.166)$$

即  $\gamma \neq 1 - \frac{1}{n}$ 。

□



第二步：显式元素公式. 设  $p = \min\{i, j\}$ ,  $q = \max\{i, j\}$ 。由式 (12.165),

$$(A_\gamma^{-1})_{ij} = p - \frac{(\gamma - 1)ij}{1 + n(\gamma - 1)}. \quad (12.167)$$

若  $i \leq j$ , 则  $p = i, q = j$ , 化简为  $i \frac{1+(n-j)(\gamma-1)}{1+n(\gamma-1)}$ 。所以统一公式为

$$(A_\gamma^{-1})_{ij} = \frac{p[1 + (n - q)(\gamma - 1)]}{1 + n(\gamma - 1)}. \quad (12.168)$$

□

第三步：非负性的正确充要条件. 取  $q = n$ , 则  $(A_\gamma^{-1})_{in} = \frac{i}{1+n(\gamma-1)}$ 。若全部元素非负, 则必须  $1 + n(\gamma - 1) > 0$ , 即

$$\gamma > 1 - \frac{1}{n}. \quad (12.169)$$

反之, 若  $\gamma > 1 - \frac{1}{n}$ , 则分母为正。若  $\gamma \geq 1$ , 所有分子显然为正。

若  $1 - \frac{1}{n} < \gamma < 1$ , 令  $\delta = \gamma - 1 \in (-1/n, 0)$ 。对  $q \in \{1, \dots, n\}$ ,  $1 + (n - q)\delta \geq 1 + (n - 1)\delta > 1 - \frac{n-1}{n} = \frac{1}{n} > 0$ 。所以所有元素仍严格为正。

因此结论为

$$\text{对所有 } n, A_\gamma^{-1} \text{ 全部元素非负} \iff \gamma \geq 1. \quad (12.170)$$

当  $n$  给定时, 在  $\gamma = 1 - \frac{1}{n}$  处矩阵奇异。□

## 12.13 SVD 分块谱分析：鞍点矩阵补充题

完整题目叙述: [NLA-Set-2019-Team-Q3]

设  $m \leq n$ , 考虑

$$\mathcal{A} = \begin{pmatrix} I_n & X \\ X^\top & 0 \end{pmatrix} \in \mathbb{R}^{(n+m) \times (n+m)}, \quad (12.171)$$

其中  $X \in \mathbb{R}^{n \times m}$  满列秩。

(i) 证明  $\mathcal{A}$  非奇异;

(ii) 求  $\mathcal{A}$  的全部特征值, 其中一部分用  $X$  的奇异值表示;

(iii) 判断在什么条件下迭代

$$\mathbf{z}^{(k+1)} = \mathbf{z}^{(k)} - (\mathcal{A}\mathbf{z}^{(k)} - \mathbf{b}) \quad (12.172)$$

对任意  $\mathbf{b}$  收敛到  $\mathcal{A}\mathbf{z} = \mathbf{b}$  的解。

第 (i) 问. 对左上块  $I_n$  取 Schur 补:  $0 - X^\top I_n^{-1} X = -X^\top X$ 。由于  $X$  满列秩,  $X^\top X \succ 0$ 。所以 Schur 补非奇异, 从而  $\mathcal{A}$  非奇异。

亦可写  $\det \mathcal{A} = (-1)^m \det(X^\top X) \neq 0$ 。□

第 (ii) 问. 取薄 SVD  $X = U_1 \Sigma V^\top$ ,  $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_m)$ ,  $\sigma_i > 0$ 。将  $U_1$  扩充为正交矩阵  $U = \begin{pmatrix} U_1 & U_2 \end{pmatrix}$ 。在正交基  $\text{diag}(U, V)$  下,  $\mathcal{A}$  正交相似于

$$\begin{pmatrix} I_m & 0 & \Sigma \\ 0 & I_{n-m} & 0 \\ \Sigma & 0 & 0 \end{pmatrix}. \quad (12.173)$$

经过置换后, 该矩阵由:

- $m$  个  $2 \times 2$  块  $\begin{pmatrix} 1 & \sigma_i \\ \sigma_i & 0 \end{pmatrix}$ ;
- 一个  $I_{n-m}$  块

组成。

每个  $2 \times 2$  块的特征方程为  $\lambda^2 - \lambda - \sigma_i^2 = 0$ 。所以特征值为

$$\lambda_i^\pm = \frac{1 \pm \sqrt{1 + 4\sigma_i^2}}{2}, \quad i = 1, \dots, m. \quad (12.174)$$

此外还有

$$\lambda = 1 \quad \text{重数 } n - m. \quad (12.175)$$

因为  $\lambda_i^+ > 1$ ,  $\lambda_i^- < 0$ , 没有零特征值, 再次证明  $\mathcal{A}$  非奇异。□

第 (iii) 问. 迭代写成  $\mathbf{z}^{(k+1)} = (I - \mathcal{A})\mathbf{z}^{(k)} + \mathbf{b}$ 。其对所有初值收敛的充要条件为

$$\rho(I - \mathcal{A}) < 1. \quad (12.176)$$

但对任意  $\sigma_i > 0$ ,  $\lambda_i^- < 0$ 。因此  $I - \mathcal{A}$  存在特征值  $1 - \lambda_i^- > 1$ 。于是  $\rho(I - \mathcal{A}) > 1$ 。

故在题设  $m \geq 1$ ,  $X$  满列秩下, 不存在任何  $X$  使打印出的单位步长迭代收敛:

$$\boxed{\text{题设范围内无满足条件的非平凡 } X}. \quad (12.177)$$

若改为带参数 Richardson 迭代  $\mathbf{z}^{(k+1)} = \mathbf{z}^{(k)} - \omega(\mathcal{A}\mathbf{z}^{(k)} - \mathbf{b})$ , 由于  $\mathcal{A}$  同时具有正、负特征值, 任意实  $\omega \neq 0$  也不能使所有  $|1 - \omega\lambda_i| < 1$ 。这说明不定鞍点系统不能直接使用普通正参数 Richardson 法。□

## 12.14 矩阵方程、Kronecker 积与 Frobenius 最小二乘

### 12.14.1 知识点十九: 向量化与 Kronecker 积

对  $X \in \mathbb{R}^{m \times n}$ , 定义  $\text{vec}(X)$  为按列堆叠得到的  $mn$  维向量。

基本恒等式为

$$\text{vec}(AXB) = (B^T \otimes A) \text{vec}(X). \quad (12.178)$$

并且

$$\|X\|_F = \|\text{vec}(X)\|_2. \quad (12.179)$$

因此

$$\min_X \|AXB - C\|_F \quad (12.180)$$

等价于向量最小二乘


$$\min_{\mathbf{x}} \|(B^T \otimes A)\mathbf{x} - \text{vec}(C)\|_2. \quad (12.181)$$

Kronecker 积的秩满足

$$\text{rank}(B^T \otimes A) = \text{rank}(B) \text{rank}(A). \quad (12.182)$$

其非零奇异值是  $\sigma_i(A)\sigma_j(B)$  的全部乘积。因此在  $A$  满列秩、 $B$  满行秩时, 线性算子  $\mathcal{L}(X) = AXB$  的二范数条件数为

$$\kappa_2(\mathcal{L}) = \kappa_2(A)\kappa_2(B). \quad (12.183)$$



## 易错点与反例

向量化适合理论推导，但实现时通常不应显式形成  $B^T \otimes A$ 。其维数为  $\ell p \times mn$ ，可能远大于原始矩阵。应利用  $A$ 、 $B$  的分解和矩阵乘法结构。

## 12.14.2 知识点二十：矩阵最小二乘的正规方程

定义

$$\Phi(X) = \frac{1}{2} \|AXB - C\|_F^2. \quad (12.184)$$

其梯度为

$$\nabla \Phi(X) = A^T (AXB - C) B^T. \quad (12.185)$$

因此最优性条件为

$$A^T A X B B^T = A^T C B^T. \quad (12.186)$$

Hessian 算子为

$$\nabla^2 \Phi(X)[Z] = A^T A Z B B^T. \quad (12.187)$$

并且

$$\langle Z, \nabla^2 \Phi(X)[Z] \rangle_F = \|A Z B\|_F^2. \quad (12.188)$$

因此目标函数严格凸，当且仅当  $A Z B = 0 \implies Z = 0$ 。等价地， $A$  满列秩， $B$  满行秩。

## 12.14.3 知识点二十一：投影形式、最小值与全部最小点

定义

$$P_A = A A^\dagger, \quad (12.189)$$

$$P_B = B^\dagger B. \quad (12.190)$$

其中  $P_A$  是到  $\mathcal{R}(A)$  的正交投影， $P_B$  是到  $\mathcal{R}(B^T)$  即  $B$  行空间的正交投影。

集合  $\mathcal{S} = \{AXB : X \in \mathbb{R}^{m \times n}\}$  在 Frobenius 内积下的正交投影为

$$P_{\mathcal{S}}(C) = P_A C P_B. \quad (12.191)$$

因此

$$\min_X \|AXB - C\|_F = \|C - P_A C P_B\|_F. \quad (12.192)$$

一个最小范数最小点为

$$X_{\dagger} = A^\dagger C B^\dagger. \quad (12.193)$$

全部最小点可写为

$$X = A^\dagger C B^\dagger + Z - A^\dagger A Z B B^\dagger, \text{ } Z \text{ 任意}. \quad (12.194)$$

因为  $A(Z - A^\dagger A Z B B^\dagger)B = AZB - AZB = 0$ 。



## 12.15 正式真题 [26S-Q3]——矩阵方程最小二乘

完整题目叙述: [26S-Q3]

给定  $A \in \mathbb{R}^{\ell \times m}$ ,  $B \in \mathbb{R}^{n \times p}$ ,  $C \in \mathbb{R}^{\ell \times p}$ . 考虑

$$\min_{X \in \mathbb{R}^{m \times n}} \|AXB - C\|_F. \quad (12.195)$$

(a) 证明最小值为 0, 当且仅当

$$\text{rank}(A) = \text{rank} \begin{pmatrix} A & C \end{pmatrix}, \quad (12.196)$$

$$\text{rank}(B) = \text{rank} \begin{pmatrix} B \\ C \end{pmatrix}; \quad (12.197)$$

(b) 证明存在唯一最小点  $X^*$ , 当且仅当

$$\text{rank}(A) = m, \text{rank}(B) = n; \quad (12.198)$$

(c) 在第 (b) 问条件下, 提出计算唯一  $X^*$  的数值方法;(d)  $X^*$  是否也必然最小化  $\|AXB - C\|_2$ ? 说明理由。第 (a) 问: 必要性. 最小值为 0 等价于存在  $X$  使

$$AXB = C. \quad (12.199)$$

由于  $C = A(XB)$ ,  $C$  的每一列均属于  $\mathcal{R}(A)$ . 因此  $\mathcal{R}(C) \subseteq \mathcal{R}(A)$ , 等价于  $\text{rank}(A) = \text{rank} \begin{pmatrix} A & C \end{pmatrix}$ .另一方面,  $C = (AX)B$ , 所以  $C$  的每一行均属于  $B$  的行空间. 等价地,  $\mathcal{R}(C^T) \subseteq \mathcal{R}(B^T)$ , 即  $\text{rank}(B) = \text{rank} \begin{pmatrix} B \\ C \end{pmatrix}$ .  $\square$ 第 (a) 问: 充分性. 第一条秩条件等价于  $AA^\dagger C = C$ . 第二条秩条件等价于  $CB^\dagger B = C$ . 令

$$X = A^\dagger CB^\dagger. \quad (12.200)$$

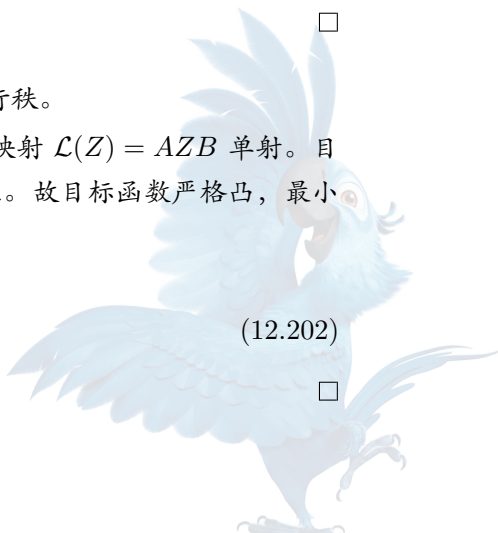
则

$$AXB = AA^\dagger CB^\dagger B = C. \quad (12.201)$$

故最小值为 0.  $\square$ 第 (b) 问: 充分性. 若  $\text{rank}(A) = m$ ,  $\text{rank}(B) = n$ , 则  $A$  满列秩、 $B$  满行秩。若  $AZB = 0$ , 左乘  $A^\dagger$ 、右乘  $B^\dagger$ :  $Z = A^\dagger(AZB)B^\dagger = 0$ . 所以线性映射  $\mathcal{L}(Z) = AZB$  单射. 目标函数的 Hessian 满足  $\langle Z, \nabla^2 \Phi[Z] \rangle_F = \|AZB\|_F^2 > 0$  对所有  $Z \neq 0$  成立. 故目标函数严格凸, 最小点唯一。

唯一解为

$$X^* = A^\dagger CB^\dagger = (A^T A)^{-1} A^T C B^T (B B^T)^{-1}. \quad (12.202)$$

 $\square$ 

第 (b) 问: 必要性. 若  $\text{rank}(A) < m$ , 则存在非零  $\mathbf{u} \in \mathcal{N}(A)$ . 任取非零  $\mathbf{v} \in \mathbb{R}^n$ , 令  $Z = \mathbf{u}\mathbf{v}^\top \neq 0$ . 则  $AZB = 0$ . 因此若  $X^*$  是最小点,  $X^* + tZ$  对任意  $t$  也是最小点, 违背唯一性.

若  $\text{rank}(B) < n$ , 则存在非零  $\mathbf{v} \in \mathcal{N}(B^\top)$ . 任取非零  $\mathbf{u} \in \mathbb{R}^m$ , 令  $Z = \mathbf{u}\mathbf{v}^\top$ . 则  $ZB = \mathbf{u}(\mathbf{v}^\top B) = 0$ , 所以  $AZB = 0$ . 同样导致最小点不唯一.

故唯一性必要求  $\text{rank}(A) = m$ ,  $\text{rank}(B) = n$ .  $\square$

第 (c) 问: 基于 QR 的稳定算法. 在第 (b) 问条件下, 计算薄 QR 分解

$$A = Q_A R_A, \quad (12.203)$$

$$B^\top = Q_B R_B, \quad (12.204)$$

其中  $Q_A^\top Q_A = I_m$ ,  $R_A \in \mathbb{R}^{m \times m}$  为非奇异上三角矩阵;  $Q_B^\top Q_B = I_n$ ,  $R_B \in \mathbb{R}^{n \times n}$  为非奇异上三角矩阵.

因为  $B = R_B^\top Q_B^\top$ , 有  $AXB = Q_A(R_A X R_B^\top)Q_B^\top$ . 定义

$$D = Q_A^\top C Q_B. \quad (12.205)$$

Frobenius 范数的正交不变性表明, 唯一最优  $X$  满足

$$R_A X R_B^\top = D. \quad (12.206)$$

因此可按两次三角矩阵方程求解:

1. 解  $R_A Y = D$ ;
2. 解  $X R_B^\top = Y$ , 等价于  $R_B X^\top = Y^\top$ .

最终

$$X^* = R_A^{-1}(Q_A^\top C Q_B)R_B^{-\top}. \quad (12.207)$$

该方法不形成  $B^\top \otimes A$ , 也不形成正规方程, 稳定性优于直接求逆或 Kronecker 正规方程.  $\square$

---

#### Algorithm 50 [26S-Q3] 的 QR 算法

---

**Input:**  $A \in \mathbb{R}^{\ell \times m}$  满列秩;  $B \in \mathbb{R}^{n \times p}$  满行秩;  $C \in \mathbb{R}^{\ell \times p}$

**Output:** 唯一 Frobenius 最小二乘解  $X^*$

- 1: 计算薄 QR  $A = Q_A R_A$
  - 2: 计算薄 QR  $B^\top = Q_B R_B$
  - 3:  $D \leftarrow Q_A^\top C Q_B$
  - 4: 解多右端项上三角系统  $R_A Y = D$
  - 5: 解  $R_B X^{*\top} = Y^\top$
  - 6: **Stopping criterion:** 两组三角求解完成
  - 7: **Complexity:** QR 成本约  $O(\ell m^2 + p n^2)$ ; 形成  $D$  约  $O(\ell m p + m p n)$ ; 三角求解约  $O(m^2 n + m n^2)$ ; 存储无需构造  $\ell p \times m n$  的 Kronecker 矩阵
- 

第 (d) 问: 一般不成立. Frobenius 范数与谱范数的最优投影一般不同. 给出满足第 (b) 问满秩条件的反例.

取

$$A = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \in \mathbb{R}^{2 \times 1}, \quad B = \begin{pmatrix} 1 & 0 \end{pmatrix} \in \mathbb{R}^{1 \times 2}, \quad (12.208)$$

以及

$$C = \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix}. \quad (12.209)$$

未知量  $X$  为标量  $x$ ，并且  $AXB = \begin{pmatrix} x & 0 \\ 0 & 0 \end{pmatrix}$ 。Frobenius 目标为

$$\|AXB - C\|_F^2 = \left\| \begin{pmatrix} x & -1 \\ -1 & -1 \end{pmatrix} \right\|_F^2 = x^2 + 3. \quad (12.210)$$

故唯一 Frobenius 最小点为  $x^* = 0$ 。

在  $x = 0$  时，残差矩阵为  $R_0 = \begin{pmatrix} 0 & -1 \\ -1 & -1 \end{pmatrix}$ 。其特征值为  $\frac{-1 \pm \sqrt{5}}{2}$ ，所以

$$\|R_0\|_2 = \frac{1 + \sqrt{5}}{2}. \quad (12.211)$$

若取  $x = 1$ ，残差为  $R_1 = \begin{pmatrix} 1 & -1 \\ -1 & -1 \end{pmatrix}$ ，其特征值为  $\pm\sqrt{2}$ ，故

$$\|R_1\|_2 = \sqrt{2}. \quad (12.212)$$

因为  $\sqrt{2} < \frac{1+\sqrt{5}}{2}$ ，所以  $x^* = 0$  并不最小化谱范数。

因此

$$\boxed{\text{Frobenius 最小点一般不必是谱范数最小点}}. \quad (12.213)$$

□

#### 易错点与反例

1.  $\text{rank}(A) = \text{rank}[A \ C]$  只保证  $C$  的列在  $\mathcal{R}(A)$  内，还必须有行空间条件；
2. 唯一性要求  $A$  满列秩且  $B$  满行秩，不是要求二者都为方阵；
3. Frobenius 最优性来自 Euclidean 投影，不能无条件推广到谱范数；
4.  $X^* = A^\dagger C B^\dagger$  在秩亏情形只是一个最小范数最小点，不是唯一最小点；
5. 直接形成  $B^T \otimes A$  会造成严重存储和条件数问题。

## 12.16 本部分易错点与易混概念

错误说法或错误做法

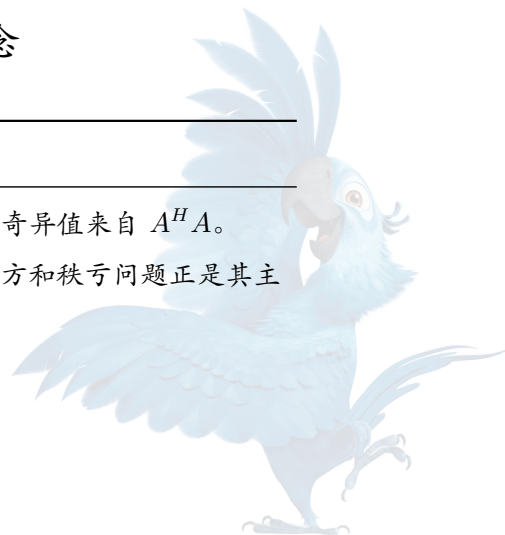
正确处理

奇异值就是特征值的绝对值。

仅对正规方阵成立；一般矩阵的奇异值来自  $A^H A$ 。

SVD 只能用于方阵。

任意  $m \times n$  矩阵均有 SVD，长方和秩亏问题正是其主要用途。





| 错误说法或错误做法                            | 正确处理                                          |
|--------------------------------------|-----------------------------------------------|
| 数值计算 SVD 应先形成 $A^H A$ 。              | 理论证明可如此；稳定算法应使用双对角化，避免条件数平方。                  |
| 伪逆与普通逆没有区别。                          | 只有方阵非奇异时 $A^\dagger = A^{-1}$ 。               |
| 秩亏最小二乘没有唯一解，所以无法定义标准答案。              | 最小范数最小二乘解 $A^\dagger b$ 唯一。                   |
| 任意最小二乘解都等于 $A^\dagger b$ 。           | 全部解还可加任意 $\mathcal{N}(A)$ 分量。                 |
| 最佳秩- $k$ 逼近总是唯一。                     | Frobenius 情形需要奇异值间隙；谱范数情形即使有间隙也可能不唯一。         |
| “秩- $k$ ”和“秩不超过 $k$ ”可以无条件互换。        | 当 $\sigma_k = 0$ 时二者不同；精确秩集合不是闭集。             |
| 谱范数低秩误差为尾部奇异值平方和。                    | 谱范数误差为 $\sigma_{k+1}$ ；平方和属于 Frobenius 范数。    |
| 核范数等于 Frobenius 范数。                  | 核范数是奇异值的 $\ell^1$ 范数，Frobenius 是 $\ell^2$ 范数。 |
| 核范数正则化只是让奇异值整体变小。                    | 其近端映射会把小奇异值精确置零，从而促进低秩。                       |
| 正则化参数越大越稳定且越准确。                      | 参数大降低噪声但增加偏差；必须平衡偏差与噪声。                       |
| Woodbury 公式意味着应该显式存储 $A^{-1}$ 。      | 实现中应通过原矩阵分解求解多个右端项。                           |
| 低秩更新总是数值稳定。                          | 若小矩阵 $I + V^H A^{-1} U$ 接近奇异，更新问题高度敏感。        |
| 能在 $O(n)$ 时间“计算逆矩阵”意味着可输出 $n^2$ 个元素。 | 只能构造压缩表示或计算逆矩阵对向量的作用。                         |
| $AXB = C$ 只需检查 $C$ 的列空间。             | 还必须检查 $C$ 的行空间是否包含于 $B$ 的行空间。                 |
| 矩阵方程最小二乘唯一只需 $A$ 非奇异。                | 一般长方情形要求 $A$ 满列秩且 $B$ 满行秩。                    |
| Frobenius 最小点也自动最小化谱范数。              | 一般不成立；两种范数的度量投影不同。                            |
| 显式形成 Kronecker 积最直接，所以一定最好。          | 理论上方便，数值实现常造成巨大维数、存储和条件数恶化。                   |
| 附件结论与推导冲突时应照抄附件。                     | 应标记待核对，给出反例和数学正确的修正结论。                        |



# 第十三章 幂法、反幂法、Rayleigh 商、Hessenberg 化、QR 迭代、位移、广义特征值与 QZ

## 13.1 标准特征值问题、残差、Rayleigh 商与后验误差

### 13.1.1 知识点一：标准特征值问题的对象与目标

【重要性等级】 **S 级**。给定  $A \in \mathbb{C}^{n \times n}$ ，标准右特征值问题为

$$Ax = \lambda x, x \neq 0. \quad (13.1)$$

左特征向量  $y$  满足

$$y^H A = \lambda y^H, y \neq 0. \quad (13.2)$$

特征向量只确定到非零倍数。若使用二范数归一化，通常要求  $\|x\|_2 = 1$ 。在复数情形，即使归一化后仍有相位不确定性： $x$  与  $e^{i\theta}x$  表示同一特征方向。

因此比较两个单位向量时，常使用相位不变距离

$$\text{dist}_{\text{ph}}(x, y) = \min_{|\omega|=1} \|x - \omega y\|_2. \quad (13.3)$$

实数情形退化为  $\min_{\omega \in \{1, -1\}} \|x - \omega y\|_2$ 。

定义 13.1 (向量与子空间的夹角). 设  $x \neq 0$ ,  $W \subset \mathbb{C}^n$  为非零子空间,  $P_W$  为到  $W$  的正交投影。定义

$$\cos \angle(x, W) = \frac{\|P_W x\|_2}{\|x\|_2}, \quad (13.4)$$

$$\sin \angle(x, W) = \frac{\|(I - P_W)x\|_2}{\|x\|_2}, \quad (13.5)$$


$$\tan \angle(x, W) = \frac{\|(I - P_W)x\|_2}{\|P_W x\|_2}, \quad (13.6)$$

其中最后一个公式要求  $P_W x \neq 0$ 。

### 13.1.2 知识点二：近似特征对与残差

给定单位向量  $\hat{x}$  和标量  $\hat{\lambda}$ ，定义特征值残差

$$r = A\hat{x} - \hat{\lambda}\hat{x}. \quad (13.7)$$



若  $\mathbf{r} = \mathbf{0}$ , 则  $(\hat{\lambda}, \hat{\mathbf{x}})$  为精确特征对。

残差具有以下意义:

- 它是特征方程满足程度的直接量;
- 对固定  $\hat{\mathbf{x}}$ , 选择恰当的  $\hat{\lambda}$  可使残差最小;
- 对正规矩阵, 小残差保证附近存在特征值;
- 对非正规矩阵, 小残差与特征值误差之间还受伪谱和左右特征向量夹角影响。

若  $\hat{\mathbf{x}}$  归一化, 则可构造秩一扰动

$$E = -\mathbf{r}\hat{\mathbf{x}}^H. \quad (13.8)$$

于是  $(A+E)\hat{\mathbf{x}} = \hat{\lambda}\hat{\mathbf{x}}$ , 且  $\|E\|_2 = \|\mathbf{r}\|_2$ 。因此  $\|\mathbf{r}\|_2$  正是使近似特征对成为某个邻近矩阵精确特征对的一个后向误差。

### 13.1.3 知识点三: Rayleigh 商

定义 13.2 (Rayleigh 商). 对  $\mathbf{x} \neq \mathbf{0}$ , 定义

$$\rho_A(\mathbf{x}) = \frac{\mathbf{x}^H A \mathbf{x}}{\mathbf{x}^H \mathbf{x}}. \quad (13.9)$$

若上下文明确, 简记为  $\rho(\mathbf{x})$ 。

命题 13.3 (Rayleigh 商最小化固定向量的残差). 对固定  $\mathbf{x} \neq \mathbf{0}$ ,

$$\rho_A(\mathbf{x}) = \arg \min_{\mu \in \mathbb{C}} \|A\mathbf{x} - \mu\mathbf{x}\|_2. \quad (13.10)$$

证明. 令  $\hat{\mathbf{x}} = \frac{\mathbf{x}}{\|\mathbf{x}\|_2}$ 。对任意  $\mu \in \mathbb{C}$ ,

$$\|A\hat{\mathbf{x}} - \mu\hat{\mathbf{x}}\|_2^2 = \|A\hat{\mathbf{x}}\|_2^2 - 2\operatorname{Re}(\bar{\mu}\hat{\mathbf{x}}^H A\hat{\mathbf{x}}) + |\mu|^2. \quad (13.11)$$

完成平方:

$$\|A\hat{\mathbf{x}} - \mu\hat{\mathbf{x}}\|_2^2 = \|A\hat{\mathbf{x}}\|_2^2 - |\rho_A(\mathbf{x})|^2 + |\mu - \rho_A(\mathbf{x})|^2. \quad (13.12)$$

故唯一最小点为  $\mu = \rho_A(\mathbf{x})$ 。 □

若  $A = A^H$ , 则 Rayleigh 商为实数, 并满足

$$\lambda_{\min}(A) \leq \rho_A(\mathbf{x}) \leq \lambda_{\max}(A). \quad (13.13)$$


定理 13.4 (正规矩阵的残差后验界). 设  $A$  正规,  $\|\hat{\mathbf{x}}\|_2 = 1$ ,  $\hat{\lambda} = \rho_A(\hat{\mathbf{x}})$ ,  $\mathbf{r} = A\hat{\mathbf{x}} - \hat{\lambda}\hat{\mathbf{x}}$ 。则

$$\min_{\lambda \in \sigma(A)} |\hat{\lambda} - \lambda| \leq \|\mathbf{r}\|_2. \quad (13.14)$$

证明. 设  $A = Q\Lambda Q^H$ ,  $\hat{\mathbf{x}} = \sum_{j=1}^n c_j \mathbf{q}_j$ ,  $\sum_j |c_j|^2 = 1$ 。则

$$\|\mathbf{r}\|_2^2 = \sum_{j=1}^n |c_j|^2 |\lambda_j - \hat{\lambda}|^2. \quad (13.15)$$

因此  $\|\mathbf{r}\|_2^2 \geq \min_j |\lambda_j - \hat{\lambda}|^2 \sum_j |c_j|^2$ , 即得结论。 □



若  $\lambda_i$  是与  $\hat{\lambda}$  对应的孤立 Hermitian 特征值，并定义

$$\text{sep}_i(\hat{\lambda}) = \min_{j \neq i} |\lambda_j - \hat{\lambda}|, \quad (13.16)$$

则

$$\sin \angle(\hat{\mathbf{x}}, \text{span}\{\mathbf{q}_i\}) \leq \frac{\|\mathbf{r}\|_2}{\text{sep}_i(\hat{\lambda})}. \quad (13.17)$$

#### 易错点与反例

对一般非正规矩阵， $\min_{\lambda \in \sigma(A)} |\hat{\lambda} - \lambda| \leq \|\mathbf{r}\|$  不必成立。

非正规矩阵的特征值误差还可能包含：

- 左右特征向量条件数；
- Schur 向量耦合；
- 伪谱半径；
- 暂态增长。

## 13.2 幂法：主特征方向、收敛率与特征值估计

### 13.2.1 知识点四：幂法的假设与基本展开

设  $A$  可对角化：

$$A = V\Lambda V^{-1}, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n), \quad (13.18)$$

并假设

$$|\lambda_1| > |\lambda_2| \geq \dots \geq |\lambda_n|. \quad (13.19)$$

写初始向量为

$$\mathbf{x}_0 = \sum_{j=1}^n \alpha_j \mathbf{v}_j, \quad \alpha_1 \neq 0. \quad (13.20)$$

则

$$A^k \mathbf{x}_0 = \alpha_1 \lambda_1^k \left[ \mathbf{v}_1 + \sum_{j=2}^n \frac{\alpha_j}{\alpha_1} \left( \frac{\lambda_j}{\lambda_1} \right)^k \mathbf{v}_j \right]. \quad (13.21)$$

因此幂法收敛到  $\mathbf{v}_1$  的方向，其渐近收敛因子由  $\left| \frac{\lambda_2}{\lambda_1} \right|$  控制。

若  $A$  正规并且  $\mathbf{v}_j$  正交归一，则令  $W_1 = \text{span}\{\mathbf{v}_1\}$ ，有精确公式


$$\tan \angle(A^k \mathbf{x}_0, W_1) = \frac{\left( \sum_{j=2}^n |\alpha_j|^2 |\lambda_j|^{2k} \right)^{1/2}}{|\alpha_1| |\lambda_1|^k}. \quad (13.22)$$

从而

$$\tan \angle(A^k \mathbf{x}_0, W_1) \leq C_0 \left| \frac{\lambda_2}{\lambda_1} \right|^k. \quad (13.23)$$

#### Algorithm 51 归一化幂法

**Input:** 矩阵  $A$  或矩阵-向量乘法算子；非零初值  $\mathbf{x}_0$ ；容差  $\text{tol}$ ；最大迭代次数  $K_{\max}$



**Output:** 主特征值和主特征向量近似

```

1: Initialization:  $\mathbf{x}_0 \leftarrow \mathbf{x}_0 / \|\mathbf{x}_0\|_2$ 
2: for  $k = 0, 1, \dots, K_{\max} - 1$  do
3:    $\mathbf{y}_{k+1} \leftarrow A\mathbf{x}_k$ 
4:   if  $\|\mathbf{y}_{k+1}\|_2 = 0$  then
5:     报告“迭代进入零空间”并终止
6:   end if
7:    $\mathbf{x}_{k+1} \leftarrow \mathbf{y}_{k+1} / \|\mathbf{y}_{k+1}\|_2$ 
8:    $\theta_{k+1} \leftarrow \mathbf{x}_{k+1}^H A \mathbf{x}_{k+1}$ 
9:    $\mathbf{r}_{k+1} \leftarrow A\mathbf{x}_{k+1} - \theta_{k+1}\mathbf{x}_{k+1}$ 
10:  if  $\|\mathbf{r}_{k+1}\|_2 \leq \text{atol} + \text{rtol}|\theta_{k+1}|$  then
11:    return  $(\theta_{k+1}, \mathbf{x}_{k+1})$ 
12:  end if
13: end for
14: Stopping criterion: 残差满足后验容差或达到最大迭代次数
15: Complexity: 稠密矩阵每步  $O(n^2)$ ; 稀疏矩阵每步  $O(\text{nnz}(A))$ ; 额外存储  $O(n)$ ; 若只提供矩阵-向量乘法, 可采用矩阵无关实现

```

### 13.2.2 知识点五：相位、符号与失败情形

设  $\omega_k = \frac{\alpha_1 \lambda_1^k}{|\alpha_1 \lambda_1^k|}$ 。归一化幂法应理解为  $\text{dist}_{\text{ph}}(\mathbf{x}_k, \mathbf{v}_1) \rightarrow 0$ , 而不一定有普通向量极限。

例如：

- 若  $\lambda_1 < 0$ , 实向量迭代通常发生符号交替;
- 若  $\lambda_1$  为非实复数, 主方向相位会随  $k$  旋转;
- 若  $\alpha_1 = 0$ , 幂法完全看不到主特征方向;
- 若  $|\lambda_1| = |\lambda_2|$ , 单向量幂法一般不会收敛到唯一特征向量;
- 若  $A$  有主 Jordan 块, 误差中可能出现  $k^s$  多项式因子;
- 若  $A$  非正规, 特征向量矩阵条件数会放大有限步误差。

### 13.2.3 知识点六：Rayleigh 商的特征值收敛

若  $A = A^H$ , 设目标特征值为  $\lambda_1$ ,  $\mathbf{x}$  为单位向量, 并写  $\mathbf{x} = c_1 \mathbf{q}_1 + \mathbf{z}$ ,  $\mathbf{z} \perp \mathbf{q}_1$ 。则


$$\rho_A(\mathbf{x}) - \lambda_1 = \sum_{j=2}^n |c_j|^2 (\lambda_j - \lambda_1). \quad (13.24)$$

因此

$$|\rho_A(\mathbf{x}) - \lambda_1| \leq \max_{j \neq 1} |\lambda_j - \lambda_1| \sin^2 \angle(\mathbf{x}, \mathbf{q}_1). \quad (13.25)$$

所以幂法中：

- 特征向量方向误差通常按  $O(|\lambda_2/\lambda_1|^k)$  收敛;
- Hermitian 情形的 Rayleigh 商特征值误差通常按  $O(|\lambda_2/\lambda_1|^{2k})$  收敛。



## 13.3 补充训练题：丘赛 2020 Problem 3——幂法渐近常数

## 完整题目叙述

[Yau-2020-Problem-3]

设  $A$  为  $m \times m$  矩阵, 具有完整的正交归一特征向量组  $\mathbf{q}_1, \dots, \mathbf{q}_m$  及对应特征值  $\lambda_1, \dots, \lambda_m$ 。假设  $|\lambda_1| > |\lambda_2| > |\lambda_3|$ ,  $\lambda_j \geq \lambda_{j+1}$ ,  $j \geq 3$ , 并考虑迭代

$$\mathbf{v}^{(k)} = \frac{A\mathbf{v}^{(k-1)}}{\lambda_1}, \quad (13.26)$$

初值为  $\mathbf{v}^{(0)} = \alpha_1 \mathbf{q}_1 + \dots + \alpha_m \mathbf{q}_m$ ,  $\alpha_1 \alpha_2 \neq 0$ 。证明  $\mathbf{v}^{(k)}$  线性收敛到  $\alpha_1 \mathbf{q}_1$ , 渐近常数为  $C = \left| \frac{\lambda_2}{\lambda_1} \right|$ 。

注 13.5. 原题如此, 但是只有条件  $\lambda_j \geq \lambda_{j+1}$ ,  $j \geq 3$  是不够的; 要推出渐近项由  $\lambda_2$  唯一主导, 数学上需要

$$|\lambda_3| \geq \max_{j \geq 3} |\lambda_j|. \quad (13.27)$$

这也是官方解答里偷偷塞的东西。以下按这一必要的模排序条件证明。

证明. 由正交谱分解,

$$\mathbf{v}^{(k)} = \frac{A^k \mathbf{v}^{(0)}}{\lambda_1^k} = \alpha_1 \mathbf{q}_1 + \sum_{j=2}^m \alpha_j \left( \frac{\lambda_j}{\lambda_1} \right)^k \mathbf{q}_j. \quad (13.28)$$

定义误差  $\mathbf{e}^{(k)} = \mathbf{v}^{(k)} - \alpha_1 \mathbf{q}_1$ 。则

$$\mathbf{e}^{(k)} = \sum_{j=2}^m \alpha_j \left( \frac{\lambda_j}{\lambda_1} \right)^k \mathbf{q}_j. \quad (13.29)$$

由正交性,

$$\begin{aligned} \|\mathbf{e}^{(k)}\|_2^2 &= \sum_{j=2}^m |\alpha_j|^2 \left| \frac{\lambda_j}{\lambda_1} \right|^{2k} \\ &= \left| \frac{\lambda_2}{\lambda_1} \right|^{2k} \left[ |\alpha_2|^2 + \sum_{j=3}^m |\alpha_j|^2 \left| \frac{\lambda_j}{\lambda_2} \right|^{2k} \right]. \end{aligned} \quad (13.30)$$

因为  $\max_{j \geq 3} \left| \frac{\lambda_j}{\lambda_2} \right| < 1$ , 且  $\alpha_2 \neq 0$ , 故

$$\lim_{k \rightarrow \infty} \frac{\|\mathbf{e}^{(k+1)}\|_2}{\|\mathbf{e}^{(k)}\|_2} = \left| \frac{\lambda_2}{\lambda_1} \right|. \quad (13.31)$$

因此该迭代以线性速度收敛, 渐近常数为  $C = |\lambda_2/\lambda_1|$ 。□

## 13.4 补充训练题：丘赛 2023 Problem 3——归一化幂法与递推比值

## 完整题目叙述

[Yau-2023-Problem-3]

设  $A \in \mathbb{R}^{n \times n}$  具有互异特征值, 并且  $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$ 。对应特征向量为  $\mathbf{v}_1, \dots, \mathbf{v}_n$ 。

(a) 证明幂迭代

$$\mathbf{z}_m = \frac{A^m \mathbf{z}_0}{\|A^m \mathbf{z}_0\|_\infty} \quad (13.32)$$

收敛到  $\pm \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|_\infty}$ ;(b) 对初值  $x_0 = y_0 = 1$  及递推

$$x_{n+1} = x_n + y_n, \quad y_{n+1} = x_{n+1} + x_n, \quad (13.33)$$

证明  $\frac{y_n}{x_n} \rightarrow \sqrt{2}$ .

注 13.6 (第 (a) 问题面缺失的必要条件). 按字面写成“对任意  $\mathbf{z}_0$ ”不成立. 若  $\mathbf{z}_0$  在  $\mathbf{v}_1$  方向的系数为零, 迭代不会产生  $\mathbf{v}_1$  分量.

正确结论需要

$$\mathbf{z}_0 = \alpha_1 \mathbf{v}_1 + \cdots + \alpha_n \mathbf{v}_n, \quad \alpha_1 \neq 0. \quad (13.34)$$

此外若  $\lambda_1 < 0$ , 普通向量序列可能符号交替; 应理解为投影方向收敛或子序列收敛到  $\pm \mathbf{v}_1$ .

第 (a) 问. 由特征向量展开,

$$A^m \mathbf{z}_0 = \alpha_1 \lambda_1^m \left[ \mathbf{v}_1 + \sum_{j=2}^n \frac{\alpha_j}{\alpha_1} \left( \frac{\lambda_j}{\lambda_1} \right)^m \mathbf{v}_j \right]. \quad (13.35)$$

括号内向量趋于  $\mathbf{v}_1$ . 因此

$$\frac{A^m \mathbf{z}_0}{\|A^m \mathbf{z}_0\|_\infty} = \frac{\alpha_1 \lambda_1^m}{|\alpha_1 \lambda_1^m|} \frac{\mathbf{v}_1 + o(1)}{\|\mathbf{v}_1 + o(1)\|_\infty}. \quad (13.36)$$

若  $\lambda_1 > 0$ , 前面的符号最终固定为  $\text{sign}(\alpha_1)$ . 若  $\lambda_1 < 0$ , 符号随  $m$  奇偶交替. 无论哪种情况, 都有

$$\text{dist}_\pm \left( \mathbf{z}_m, \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|_\infty} \right) = O \left( \left| \frac{\lambda_2}{\lambda_1} \right|^m \right). \quad (13.37)$$

□

第 (b) 问. 由  $y_{n+1} = x_{n+1} + x_n = 2x_n + y_n$ , 递推可写为

$$\begin{pmatrix} x_{n+1} \\ y_{n+1} \end{pmatrix} = M \begin{pmatrix} x_n \\ y_n \end{pmatrix}, \quad M = \begin{pmatrix} 1 & 1 \\ 2 & 1 \end{pmatrix}. \quad (13.38)$$

 $M$  的特征多项式为  $(1 - \lambda)^2 - 2 = 0$ , 故特征值为

$$\lambda_\pm = 1 \pm \sqrt{2}. \quad (13.39)$$

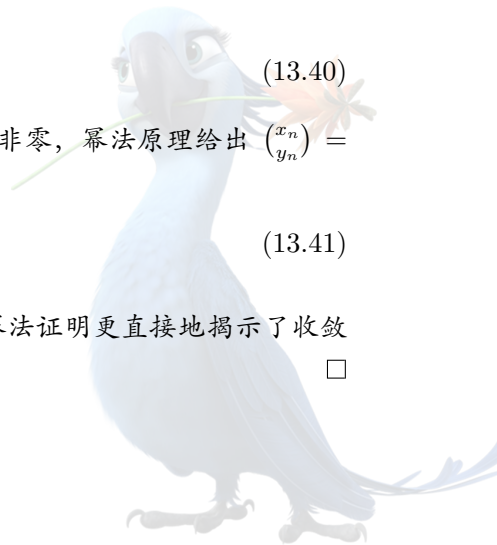
对应特征向量可取

$$\mathbf{v}_\pm = \begin{pmatrix} 1 \\ \pm \sqrt{2} \end{pmatrix}. \quad (13.40)$$

因为  $|\lambda_+| = 1 + \sqrt{2} > |\lambda_-| = \sqrt{2} - 1$ , 且初值  $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$  在  $\mathbf{v}_+$  方向的分量非零, 幂法原理给出  $\begin{pmatrix} x_n \\ y_n \end{pmatrix} = c_+ \lambda_+^n \mathbf{v}_+ + c_- \lambda_-^n \mathbf{v}_-$ ,  $c_+ \neq 0$ . 所以

$$\frac{y_n}{x_n} \rightarrow \frac{(\mathbf{v}_+)_2}{(\mathbf{v}_+)_1} = \sqrt{2}. \quad (13.41)$$

也可令  $r_n = \frac{y_n}{x_n}$ , 得到  $r_{n+1} = \frac{2+r_n}{1+r_n}$ . 其正不动点为  $\sqrt{2}$ , 但矩阵幂法证明更直接地揭示了收敛率. □





## 13.5 子空间迭代与正交迭代

### 13.5.1 知识点七：由单向量幂法到子空间迭代

若存在一簇模相同或接近的主特征值，单向量幂法无法稳定分离每个方向。此时应计算主不变子空间。

设  $A = Q\Lambda Q^H$  正规，且

$$|\lambda_1| \geq \cdots \geq |\lambda_p| > |\lambda_{p+1}| \geq \cdots \geq |\lambda_n|. \quad (13.42)$$

目标子空间为  $\mathcal{U}_p = \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_p\}$ 。

正交迭代为

$$Z_k = AQ_k, \quad Z_k = Q_{k+1}R_{k+1}, \quad (13.43)$$

其中  $Q_k \in \mathbb{C}^{n \times p}$  列正交。

---

#### Algorithm 52 正交迭代

---

**Input:** 矩阵  $A$ ; 目标维数  $p$ ; 满列秩初值  $X_0$ ; 容差

**Output:** 主  $p$  维不变子空间近似

- 1: 对  $X_0$  作薄 QR:  $X_0 = Q_0R_0$
  - 2: **for**  $k = 0, 1, \dots$  **do**
  - 3:    $Z_k \leftarrow AQ_k$
  - 4:   对  $Z_k$  作薄 QR:  $Z_k = Q_{k+1}R_{k+1}$
  - 5:   形成 Rayleigh–Ritz 压缩矩阵  $T_{k+1} = Q_{k+1}^H AQ_{k+1}$
  - 6:   计算子空间残差  $F_{k+1} = AQ_{k+1} - Q_{k+1}T_{k+1}$
  - 7:   **if**  $\|F_{k+1}\|_2$  满足容差 **then**
  - 8:     **return**  $(Q_{k+1}, T_{k+1})$
  - 9:   **end if**
  - 10: **end for**
  - 11: **Stopping criterion:** 不变子空间残差满足容差
  - 12: **Complexity:** 每步  $p$  次矩阵–向量乘法及一次  $n \times p$  薄 QR; 稀疏情形约  $O(\text{nnz}(A)p + np^2)$ ; 存储  $O(np)$
- 

在适当初值条件下，主角误差满足

$$\tan \Theta(\mathcal{R}(Q_k), \mathcal{U}_p) = O \left[ \left| \frac{\lambda_{p+1}}{\lambda_p} \right|^k \right]. \quad (13.44)$$

### 13.5.2 补充训练题——向量与主不变子空间的角

完整题目叙述: [NLA-Set-2021-Oral-Q1]

设  $A \in \mathbb{C}^{n \times n}$  为正规矩阵:  $A = QDQ^H$ , 并假设存在  $k$  个主特征值  $|\lambda_1| \geq \cdots \geq |\lambda_k| > |\lambda_{k+1}| \geq \cdots \geq |\lambda_n|$ 。考虑幂迭代  $\mathbf{x}^{(m+1)} = A\mathbf{x}^{(m)}$ 。

(1) 设  $W$  为非零子空间,  $P$  为到  $W$  的正交投影。证明

$$\cos \angle(\mathbf{x}, W) = \frac{\|P\mathbf{x}\|_2}{\|\mathbf{x}\|_2}, \quad (13.45)$$

$$\sin \angle(\mathbf{x}, W) = \frac{\|\mathbf{x} - P\mathbf{x}\|_2}{\|\mathbf{x}\|_2}, \quad (13.46)$$

$$\tan \angle(\mathbf{x}, W) = \frac{\|\mathbf{x} - P\mathbf{x}\|_2}{\|P\mathbf{x}\|_2}; \quad (13.47)$$

(2) 令  $\mathbf{e}_j$  为标准基,  $W_k = \text{span}\{Q\mathbf{e}_j : j = 1, \dots, k\}$ . 若  $\cos \angle(\mathbf{x}^{(0)}, W_k) \neq 0$ , 证明

$$\tan \angle(\mathbf{x}^{(m+1)}, W_k) \leq \frac{|\lambda_{k+1}|}{|\lambda_k|} \tan \angle(\mathbf{x}^{(m)}, W_k). \quad (13.48)$$

第 (1) 问. 将  $\mathbf{x}$  正交分解为  $\mathbf{x} = P\mathbf{x} + (I - P)\mathbf{x}$ . 其中  $P\mathbf{x} \in W$ ,  $(I - P)\mathbf{x} \perp W$ . 在  $W$  中与  $\mathbf{x}$  夹角最小的方向正是  $P\mathbf{x}$  方向, 故  $\cos \angle(\mathbf{x}, W) = \frac{|\langle \mathbf{x}, P\mathbf{x} \rangle|}{\|\mathbf{x}\|_2 \|P\mathbf{x}\|_2} = \frac{\|P\mathbf{x}\|_2}{\|\mathbf{x}\|_2}$ . 由 Pythagoras 恒等式  $\|\mathbf{x}\|_2^2 = \|P\mathbf{x}\|_2^2 + \|(I - P)\mathbf{x}\|_2^2$ , 得到正弦公式及正切公式.  $\square$

第 (2) 问. 记  $P_k = Q \begin{pmatrix} I_k & 0 \\ 0 & 0 \end{pmatrix} Q^H$ . 由于  $A$  正规,  $W_k$  及其正交补均为  $A$  的不变子空间, 并且  $AP_k = P_k A$ . 于是

$$\begin{aligned} \tan \angle(A\mathbf{x}, W_k) &= \frac{\|(I - P_k)A\mathbf{x}\|_2}{\|P_k A\mathbf{x}\|_2} \\ &= \frac{\|A(I - P_k)\mathbf{x}\|_2}{\|AP_k \mathbf{x}\|_2}. \end{aligned} \quad (13.49)$$

在  $W_k^\perp$  上,  $\|A\mathbf{z}\|_2 \leq |\lambda_{k+1}| \|\mathbf{z}\|_2$ . 在  $W_k$  上,  $\|A\mathbf{y}\|_2 \geq |\lambda_k| \|\mathbf{y}\|_2$ . 因此  $\tan \angle(A\mathbf{x}, W_k) \leq \frac{|\lambda_{k+1}|}{|\lambda_k|} \frac{\|(I - P_k)\mathbf{x}\|_2}{\|P_k \mathbf{x}\|_2}$ . 令  $\mathbf{x} = \mathbf{x}^{(m)}$  即得式 (13.48).  $\square$

### 13.5.3 补充训练题——子空间迭代的残差比

完整题目叙述: [NLA-Set-2018-Team-Q3]

设  $A \in \mathbb{R}^{n \times n}$ ,  $A = QDQ^H$ , 其中  $Q$  酉,  $D = \text{diag}(\lambda_1, \dots, \lambda_n)$ . 令  $E_k$  为  $Q$  前  $k$  列张成的子空间, 并定义

$$\hat{P} = \begin{pmatrix} I_k & 0 \\ 0 & 0 \end{pmatrix}, \quad P = Q\hat{P}Q^H. \quad (13.50)$$

(1) 证明  $P$  是到  $E_k$  的正交投影;

(2) 假设  $|\lambda_1| \geq \dots \geq |\lambda_k| > |\lambda_{k+1}| \geq \dots \geq |\lambda_n|$ , 且  $X^{(0)} \in \mathbb{R}^{n \times k}$ ,  $PX^{(0)}$  为单射. 定义  $X^{(m+1)} = AX^{(m)}$ . 证明存在  $\Lambda \in \mathbb{R}^{k \times k}$  使对任意  $\mathbf{y} \neq \mathbf{0}$ ,

$$\frac{\|(AX^{(m)} - X^{(m)}\Lambda)\mathbf{y}\|_2}{\|PX^{(m)}\mathbf{y}\|_2} \leq \left| \frac{\lambda_{k+1}}{\lambda_k} \right|^m \frac{\|(AX^{(0)} - X^{(0)}\Lambda)\mathbf{y}\|_2}{\|PX^{(0)}\mathbf{y}\|_2}. \quad (13.51)$$

证明. 由  $\hat{P}^2 = \hat{P}$ ,  $\hat{P}^H = \hat{P}$ , 可得  $P^2 = P$ ,  $P^H = P$ . 且  $\mathcal{R}(P) = E_k$ , 所以  $P$  为正交投影.

记  $Q_k = \begin{pmatrix} \mathbf{q}_1 & \dots & \mathbf{q}_k \end{pmatrix}$ ,  $D_k = \text{diag}(\lambda_1, \dots, \lambda_k)$ . 由于  $PX^{(0)}$  从  $\mathbb{R}^k$  到  $E_k$  为单射, 存在非奇异矩阵  $C \in \mathbb{R}^{k \times k}$  使

$$PX^{(0)} = Q_k C. \quad (13.52)$$

定义

$$\Lambda = C^{-1} D_k C. \quad (13.53)$$

于是

$$APX^{(0)} = Q_k D_k C = Q_k C \Lambda = PX^{(0)} \Lambda. \quad (13.54)$$

所以

$$P(AX^{(0)} - X^{(0)} \Lambda) = 0. \quad (13.55)$$

令  $R_0 = AX^{(0)} - X^{(0)} \Lambda$ 。因为  $X^{(m)} = A^m X^{(0)}$ , 有

$$AX^{(m)} - X^{(m)} \Lambda = A^m R_0. \quad (13.56)$$

$R_0$  的列位于  $E_k^\perp$ , 所以

$$\|A^m R_0 \mathbf{y}\|_2 \leq |\lambda_{k+1}|^m \|R_0 \mathbf{y}\|_2. \quad (13.57)$$

另一方面,

$$PX^{(m)} = PA^m X^{(0)} = A^m PX^{(0)}, \quad (13.58)$$

故

$$\|PX^{(m)} \mathbf{y}\|_2 \geq |\lambda_k|^m \|PX^{(0)} \mathbf{y}\|_2. \quad (13.59)$$

两式相除即得 式 (13.51)。

□

## 13.6 反幂法、位移反幂法与 Rayleigh 商迭代

### 13.6.1 知识点八：位移反幂法

给定位移  $\mu \in \mathbb{C}$ , 假设  $\mu \notin \sigma(A)$ 。反幂法对矩阵  $(A - \mu I)^{-1}$  应用幂法。

若  $\lambda_j$  是距离  $\mu$  最近的唯一特征值:

$$|\lambda_j - \mu| < |\lambda_i - \mu|, \quad i \neq j, \quad (13.60)$$

则  $\frac{1}{\lambda_j - \mu}$  是  $(A - \mu I)^{-1}$  的唯一主模特征值。

对正规矩阵, 若初始向量在  $\mathbf{q}_j$  方向分量非零, 则方向误差按

$$O\left[\left(\frac{|\lambda_j - \mu|}{\min_{i \neq j} |\lambda_i - \mu|}\right)^k\right] \quad (13.61)$$

线性收敛。

---


#### Algorithm 53 固定移位反幂法

---

**Input:** 矩阵  $A$ ; 移位  $\mu \notin \sigma(A)$ ; 单位初值  $\mathbf{x}_0$ ; 容差

**Output:** 距离  $\mu$  最近的特征对近似

- 1: **Initialization:** 分解  $P(A - \mu I) = LU$  或构造适当稀疏分解/预处理器
- 2: **for**  $k = 0, 1, \dots$  **do**
- 3:   解线性方程  $(A - \mu I)\mathbf{y}_{k+1} = \mathbf{x}_k$
- 4:    $\mathbf{x}_{k+1} \leftarrow \mathbf{y}_{k+1} / \|\mathbf{y}_{k+1}\|_2$
- 5:    $\theta_{k+1} \leftarrow \mathbf{x}_{k+1}^H A \mathbf{x}_{k+1}$
- 6:    $\mathbf{r}_{k+1} \leftarrow A \mathbf{x}_{k+1} - \theta_{k+1} \mathbf{x}_{k+1}$
- 7:   **if**  $\|\mathbf{r}_{k+1}\|_2$  满足容差 **then**
- 8:     **return**  $(\theta_{k+1}, \mathbf{x}_{k+1})$



- 9: **end if**  
 10: **end for**  
 11: **Stopping criterion:** 特征残差满足容差  
 12: **Complexity:** 稠密矩阵一次分解  $O(n^3)$ , 每步两次三角求解  $O(n^2)$ ; 存储  $O(n^2)$ ; 固定移位允许复用分解

#### 易错点与反例

反幂法的更新是  $(A - \mu I)\mathbf{y} = \mathbf{x}$ , 不是显式计算  $\mathbf{y} = (A - \mu I)^{-1}\mathbf{x}$ 。  
 实现中不应形成完整逆矩阵。

### 13.6.2 知识点九: Rayleigh 商迭代

Rayleigh 商迭代 (Rayleigh quotient iteration, RQI) 为

$$\mu_k = \rho_A(\mathbf{x}_k), \quad (13.62)$$

$$(A - \mu_k I)\mathbf{y}_{k+1} = \mathbf{x}_k, \quad (13.63)$$

$$\mathbf{x}_{k+1} = \mathbf{y}_{k+1} / \|\mathbf{y}_{k+1}\|_2. \quad (13.64)$$

#### Algorithm 54 Rayleigh 商迭代

**Input:** 矩阵  $A$ ; 单位初值  $\mathbf{x}_0$ ; 容差; 最大迭代次数

**Output:** 局部收敛的特征对近似

- 1: **for**  $k = 0, 1, \dots$  **do**  
 2:    $\mu_k \leftarrow \mathbf{x}_k^H A \mathbf{x}_k$   
 3:    $\mathbf{r}_k \leftarrow A \mathbf{x}_k - \mu_k \mathbf{x}_k$   
 4:   **if**  $\|\mathbf{r}_k\|_2$  满足容差 **then**  
 5:     **return**  $(\mu_k, \mathbf{x}_k)$   
 6:   **end if**  
 7:   分解并求解  $(A - \mu_k I)\mathbf{y}_{k+1} = \mathbf{x}_k$   
 8:    $\mathbf{x}_{k+1} \leftarrow \mathbf{y}_{k+1} / \|\mathbf{y}_{k+1}\|_2$   
 9: **end for**  
 10: **Stopping criterion:** 特征残差满足容差  
 11: **Complexity:** 移位每步改变, 稠密情形通常每步需  $O(n^3)$  新分解; Hermitian 三对角矩阵每步可降为  $O(n)$ ; 存储取决于线性求解器

**定理 13.7** (Hermitian RQI 的局部立方收敛). 设  $A = A^H$ ,  $\lambda_i$  为简单特征值,  $\mathbf{q}_i$  为对应单位特征向量。若  $\mathbf{x}_k$  充分接近  $\mathbf{q}_i$ , 则

$$\tan \angle(\mathbf{x}_{k+1}, \mathbf{q}_i) \leq C \tan^3 \angle(\mathbf{x}_k, \mathbf{q}_i). \quad (13.65)$$

#### Hermitian RQI 立方收敛的标准证明框架

写  $\mathbf{x}_k = c_i \mathbf{q}_i + \sum_{j \neq i} c_j \mathbf{q}_j$ ,  $\theta_k = \angle(\mathbf{x}_k, \mathbf{q}_i)$ 。Rayleigh 商误差满足

$$|\mu_k - \lambda_i| \leq C_1 \sin^2 \theta_k. \quad (13.66)$$

反幂一步后, 各特征分量被乘以  $(\lambda_j - \mu_k)^{-1}$ 。因此

$$\tan \theta_{k+1} \leq \frac{|\lambda_i - \mu_k|}{\min_{j \neq i} |\lambda_j - \mu_k|} \tan \theta_k$$

$$\leq C_2 \sin^2 \theta_k \tan \theta_k = O(\theta_k^3). \quad (13.67)$$

对一般非正规矩阵, RQI 通常只有局部二次收敛, 甚至可能因非正规性和奇异线性系统而表现不规则; Hermitian 结构是立方收敛的重要条件。

### 13.6.3 知识点十: 病态线性系统为何仍可能给出准确方向

当  $\mu_k$  非常接近  $\lambda_i$  时,  $A - \mu_k I$  高度病态。这不意味着归一化后的反幂向量必然不准确。

原因是:

- 沿目标特征向量  $\mathbf{q}_i$  方向的解分量本来就应放大到  $O(|\lambda_i - \mu_k|^{-1})$ ;
- 线性求解误差常主要改变向量长度;
- 归一化会消除大部分长度误差;
- 只要后向误差小且目标方向分量不消失, 方向仍可能非常准确。

下面的题目系统刻画了这一现象。

## 13.7 补充训练题——有限精度反幂法

完整题目叙述: [NLA-Set-2016-Problem-4]

设  $A \in \mathbb{R}^{n \times n}$  为对称矩阵,  $\lambda_i$  为简单特征值, 并假设它与其他特征值的间隔不随机器精度消失:

$$\gamma_i := \min_{j \neq i} |\lambda_j - \lambda_i| = O(1), \quad \gamma_i > 0. \quad (13.68)$$

反幂法中求解

$$(A - \mu I)\mathbf{y}_{k+1} = \mathbf{x}_k, \quad \|\mathbf{x}_k\|_2 = 1, \quad (13.69)$$

并归一化  $\mathbf{x}_{k+1} = \mathbf{y}_{k+1} / \|\mathbf{y}_{k+1}\|_2$ 。

有限精度计算得到  $\tilde{\mathbf{y}}_{k+1}$ , 满足后向误差模型

$$(A - \mu I + \delta A)\tilde{\mathbf{y}}_{k+1} = \mathbf{x}_k, \quad \|\delta A\|_2 = O(\varepsilon_{\text{mach}}). \quad (13.70)$$

(1) 证明

$$\left\| (A - \lambda_i I) \frac{\tilde{\mathbf{y}}_{k+1}}{\|\tilde{\mathbf{y}}_{k+1}\|_2} \right\|_2 \leq |\mu - \lambda_i| + \|\delta A\|_2 + \frac{1}{\|\tilde{\mathbf{y}}_{k+1}\|_2}; \quad (13.71)$$

(2) 令  $\alpha_i = \mathbf{x}_k^T \mathbf{q}_i$ , 其中  $\mathbf{q}_i$  为  $\lambda_i$  对应单位特征向量。证明

$$\|\tilde{\mathbf{y}}_{k+1}\|_2 \geq \frac{|\alpha_i|}{|\mu - \lambda_i| + \|\delta A\|_2}; \quad (13.72)$$

(3) 若  $|\alpha_i|$  有与机器精度无关的正下界, 证明归一化向量  $\tilde{\mathbf{x}}_{k+1} = \frac{\tilde{\mathbf{y}}_{k+1}}{\|\tilde{\mathbf{y}}_{k+1}\|_2}$  满足

$$\min_{\omega \in \{1, -1\}} \|\tilde{\mathbf{x}}_{k+1} - \omega \mathbf{q}_i\|_2 = O(|\lambda_i - \mu| + \varepsilon_{\text{mach}}). \quad (13.73)$$

第 (1) 问. 由 式 (13.70),

$$\begin{aligned}(A - \lambda_i I) \tilde{\mathbf{y}}_{k+1} &= (A - \mu I + \delta A) \tilde{\mathbf{y}}_{k+1} \\ &\quad + (\mu - \lambda_i) \tilde{\mathbf{y}}_{k+1} - \delta A \tilde{\mathbf{y}}_{k+1} \\ &= \mathbf{x}_k + (\mu - \lambda_i) \tilde{\mathbf{y}}_{k+1} - \delta A \tilde{\mathbf{y}}_{k+1}.\end{aligned}\quad (13.74)$$

取二范数并使用  $\|\mathbf{x}_k\|_2 = 1$ :

$$\|(A - \lambda_i I) \tilde{\mathbf{y}}_{k+1}\|_2 \leq 1 + (|\mu - \lambda_i| + \|\delta A\|_2) \|\tilde{\mathbf{y}}_{k+1}\|_2. \quad (13.75)$$

除以  $\|\tilde{\mathbf{y}}_{k+1}\|_2$  即得 式 (13.71)。  $\square$

第 (2) 问. 左乘  $\mathbf{q}_i^\top$ :

$$\begin{aligned}\alpha_i &= \mathbf{q}_i^\top \mathbf{x}_k \\ &= \mathbf{q}_i^\top (A - \mu I + \delta A) \tilde{\mathbf{y}}_{k+1} \\ &= (\lambda_i - \mu) \mathbf{q}_i^\top \tilde{\mathbf{y}}_{k+1} + \mathbf{q}_i^\top \delta A \tilde{\mathbf{y}}_{k+1}.\end{aligned}\quad (13.76)$$

故

$$|\alpha_i| \leq (|\lambda_i - \mu| + \|\delta A\|_2) \|\tilde{\mathbf{y}}_{k+1}\|_2. \quad (13.77)$$

整理即得 式 (13.72)。  $\square$

第 (3) 问. 定义  $\tilde{\mathbf{x}} = \tilde{\mathbf{x}}_{k+1} = \frac{\tilde{\mathbf{y}}_{k+1}}{\|\tilde{\mathbf{y}}_{k+1}\|_2}$ . 由前两问,

$$\begin{aligned}\|(A - \lambda_i I) \tilde{\mathbf{x}}\|_2 &\leq |\mu - \lambda_i| + \|\delta A\|_2 \\ &\quad + \frac{|\mu - \lambda_i| + \|\delta A\|_2}{|\alpha_i|}.\end{aligned}\quad (13.78)$$

若  $|\alpha_i| \geq c_0 > 0$ , 则

$$\|(A - \lambda_i I) \tilde{\mathbf{x}}\|_2 = O(|\mu - \lambda_i| + \varepsilon_{\text{mach}}). \quad (13.79)$$

在  $A$  的正交特征向量基中写  $\tilde{\mathbf{x}} = c_i \mathbf{q}_i + \sum_{j \neq i} c_j \mathbf{q}_j$ . 则

$$\begin{aligned}\|(A - \lambda_i I) \tilde{\mathbf{x}}\|_2^2 &= \sum_{j \neq i} |\lambda_j - \lambda_i|^2 |c_j|^2 \\ &\geq \gamma_i^2 \sum_{j \neq i} |c_j|^2.\end{aligned}\quad (13.80)$$

因此


$$\sin \angle(\tilde{\mathbf{x}}, \mathbf{q}_i) \leq \frac{\|(A - \lambda_i I) \tilde{\mathbf{x}}\|_2}{\gamma_i}. \quad (13.81)$$

对单位实向量,  $\min_{\omega=\pm 1} \|\tilde{\mathbf{x}} - \omega \mathbf{q}_i\|_2 \leq \sqrt{2} \sin \angle(\tilde{\mathbf{x}}, \mathbf{q}_i)$ . 结合 式 (13.79) 即得 式 (13.73)。  $\square$

注 13.8. 该题说明:

线性系统解向量的绝对误差可能很大  $\nrightarrow$  归一化特征向量方向不准确。

这是反幂法和 Rayleigh 商迭代在接近特征值时仍能有效工作的核心机制。



## 13.8 上 Hessenberg 约化、proper Hessenberg 与 Krylov 结构

### 13.8.1 知识点十一：上 Hessenberg 矩阵

定义 13.9 (上 Hessenberg 矩阵). 若

$$h_{ij} = 0, \quad i > j + 1, \quad (13.82)$$

则称  $H$  为上 Hessenberg 矩阵。

若进一步

$$h_{j+1,j} \neq 0, \quad j = 1, \dots, n-1, \quad (13.83)$$

则称  $H$  为不约化或 proper 上 Hessenberg 矩阵。

若某个  $h_{j+1,j} = 0$ , 则  $H = \begin{pmatrix} H_{11} & H_{12} \\ 0 & H_{22} \end{pmatrix}$ , 其特征值问题可分裂为两个更小问题。这称为消去或分裂 (deflation/splitting)。

### 13.8.2 知识点十二：Householder Hessenberg 约化

对任意  $A \in \mathbb{C}^{n \times n}$ , 存在酉矩阵  $U$  使

$$H = U^H A U \quad (13.84)$$

为上 Hessenberg 矩阵。

第  $k$  步,  $k = 1, \dots, n-2$ , 在向量  $A(k+1:n, k)$  上构造 Householder 反射  $\hat{H}_k$ , 使其后  $n-k-1$  个分量归零。令  $H_k = \text{diag}(I_k, \hat{H}_k)$ 。更新

$$A \leftarrow H_k^H A H_k. \quad (13.85)$$

左乘负责消去第  $k$  列对角线下第二条及更低位置, 右乘保证是相似变换并保持特征值。

---

#### Algorithm 55 Householder 上 Hessenberg 约化

---

**Input:**  $A \in \mathbb{C}^{n \times n}$

**Output:** 上 Hessenberg 矩阵  $H$  及酉矩阵  $U$ , 使  $H = U^H A U$

- 1: **Initialization:**  $H \leftarrow A, U \leftarrow I$
  - 2: **for**  $k = 1, 2, \dots, n-2$  **do**
  - 3:   对  $x = H(k+1:n, k)$  构造 Householder 向量  $v_k$  和系数  $\beta_k$
  - 4:   从左更新  $H(k+1:n, k:n) \leftarrow H(k+1:n, k:n) - \beta_k v_k v_k^H H(k+1:n, k:n)$
  - 5:   从右更新  $H(1:n, k+1:n) \leftarrow H(1:n, k+1:n) - \beta_k H(1:n, k+1:n) v_k v_k^H$
  - 6:   若需 Schur 向量, 则累积  $U(:, k+1:n) \leftarrow U(:, k+1:n) (I - \beta_k v_k v_k^H)$
  - 7: **end for**
  - 8: **Stopping criterion:** 所有  $i > j+1$  位置归零
  - 9: **Complexity:** 稠密矩阵时间复杂度  $O(n^3)$ ; 存储  $O(n^2)$ ; Householder 向量可覆盖存入被消去的下三角区域
- 

若  $A = A^H$ , 左右更新保持 Hermitian 结构, 上 Hessenberg 与 Hermitian 同时成立时矩阵必为三对角矩阵。因此 Hermitian 矩阵  $\rightarrow$  实对称/复 Hermitian 三对角矩阵。



### 13.8.3 知识点十三：为什么先约化再 QR

直接对稠密矩阵作一次 QR 分解并形成  $RQ$ ，成本为  $O(n^3)$ 。对上 Hessenberg 矩阵：

- QR 分解只需  $n-1$  个 Givens 旋转；
- 一次 QR 扫掠成本为  $O(n^2)$ ；
- Hessenberg 结构在 QR 步中保持；
- 初始一次  $O(n^3)$  约化可被后续多次  $O(n^2)$  迭代摊薄。

完整稠密特征值算法的典型总成本仍为  $O(n^3)$ ，而不是每步  $O(n^3)$  累积成  $O(n^4)$ 。

### 13.8.4 补充训练题——proper Hessenberg 与 Krylov 子空间

完整题目叙述：[NLA-Set-2015-Problem-1]

设  $A, H, Q \in \mathbb{C}^{n \times n}$ ,  $Q$  非奇异, 并且

$$H = Q^{-1}AQ \quad (13.86)$$

为 proper 上 Hessenberg 矩阵, 即  $h_{j+1,j} \neq 0, j = 1, \dots, n-1$ 。记  $Q$  的第  $j$  列为  $\mathbf{q}_j$ 。证明

$$\text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_j\} = \mathcal{K}_j(A, \mathbf{q}_1) \quad (13.87)$$

对  $j = 1, \dots, n$  成立, 其中  $\mathcal{K}_j(A, \mathbf{q}_1) = \text{span}\{\mathbf{q}_1, A\mathbf{q}_1, \dots, A^{j-1}\mathbf{q}_1\}$ 。

证明. 由  $AQ = QH$ , 取第  $j$  列得到

$$A\mathbf{q}_j = \sum_{i=1}^{j+1} h_{ij}\mathbf{q}_i, \quad j = 1, \dots, n-1. \quad (13.88)$$

因此  $A\text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_j\} \subset \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_{j+1}\}$ 。由归纳立即得到

$$\mathcal{K}_j(A, \mathbf{q}_1) \subseteq \text{span}\{\mathbf{q}_1, \dots, \mathbf{q}_j\}. \quad (13.89)$$

反向包含也用归纳法。 $j=1$  时显然成立。假设  $\mathbf{q}_1, \dots, \mathbf{q}_j \in \mathcal{K}_j(A, \mathbf{q}_1)$ 。由式 (13.88),

$$h_{j+1,j}\mathbf{q}_{j+1} = A\mathbf{q}_j - \sum_{i=1}^j h_{ij}\mathbf{q}_i. \quad (13.90)$$

右端属于  $\mathcal{K}_{j+1}(A, \mathbf{q}_1)$ 。又因为 proper 条件保证  $h_{j+1,j} \neq 0$ , 故  $\mathbf{q}_{j+1} \in \mathcal{K}_{j+1}(A, \mathbf{q}_1)$ 。归纳完成。□

注 13.10. proper Hessenberg 矩阵对应“每一步 Krylov 维数都增加 1”。若某个次对角元为零, 则 Krylov 空间提前停止增长, 并产生不变子空间和可分裂结构。

## 13.9 QR 迭代、同时迭代、位移与消去

### 13.9.1 知识点十四：无位移 QR 迭代

给定  $A_0 = A$ , QR 迭代为

$$A_k = Q_k R_k, \quad (13.91)$$

$$A_{k+1} = R_k Q_k. \quad (13.92)$$



由于  $R_k = Q_k^H A_k$ , 有

$$A_{k+1} = Q_k^H A_k Q_k. \quad (13.93)$$

因此所有  $A_k$  与  $A$  酉相似, 特征值保持不变。

定义累积矩阵

$$\hat{Q}_k = Q_0 Q_1 \cdots Q_{k-1}, \quad (13.94)$$

$$\hat{R}_k = R_{k-1} \cdots R_1 R_0. \quad (13.95)$$

则

$$A_k = \hat{Q}_k^H A \hat{Q}_k, \quad (13.96)$$

$$A^k = \hat{Q}_k \hat{R}_k. \quad (13.97)$$

这说明无位移 QR 与同时迭代/正交迭代密切相关。

### 13.9.2 知识点十五: 位移 QR

给定位移  $\mu_k$ , 执行

$$A_k - \mu_k I = Q_k R_k, \quad (13.98)$$

$$A_{k+1} = R_k Q_k + \mu_k I. \quad (13.99)$$

仍有

$$A_{k+1} = Q_k^H A_k Q_k. \quad (13.100)$$

常用位移包括:

1. **Rayleigh** 位移  $\mu_k = (A_k)_{nn}$ ;
2. **Wilkinson** 位移取尾部  $2 \times 2$  主子矩阵中距离  $(A_k)_{nn}$  较近的特征值;
3. 双步位移对实矩阵使用尾部  $2 \times 2$  块的共轭特征值对, 避免显式复算术;
4. 异常位移当标准位移导致停滞时, 临时采用经验位移打破对称结构。

---

**Algorithm 56** 实上 Hessenberg 矩阵的实用位移 QR 框架

---

**Input:** 上 Hessenberg 矩阵  $H$ ; 机器精度  $u$ ; 最大扫掠次数

**Output:** 实 Schur 形式及特征值

```

1: while 存在未消去活动块 do
2:   for 活动块中的每个次对角元  $h_{i+1,i}$  do
3:     if  $|h_{i+1,i}| \leq cu(|h_{ii}| + |h_{i+1,i+1}|)$  then
4:       令  $h_{i+1,i} \leftarrow 0$ , 分裂问题
5:     end if
6:   end for
7:   if 活动块阶数为 1 then
8:     锁定一个实特征值
9:   else if 活动块阶数为 2 then
10:    直接计算其两个特征值并锁定
11:   else
```



- 12:       从尾部  $2 \times 2$  块选择 Wilkinson 位移或双位移
- 13:       使用隐式 QR 步和 Givens 旋转追赶 bulge
- 14:       end if
- 15: end while
- 16: **Stopping criterion:** 得到实拟上三角 Schur 形式
- 17: **Complexity:** Hessenberg 化一次  $O(n^3)$ ; 每次 QR 扫掠  $O(n^2)$ ; 总复杂度通常  $O(n^3)$ ; 存储  $O(n^2)$

#### 易错点与反例

“无位移 QR 总会快速收敛”是错误说法。

以下情况会导致慢收敛或停滞：

- 特征值模相近；
- 共轭复特征值；
- 高度非正规矩阵；
- 特殊对称结构；
- 位移选择不当；
- 次对角元虽小但尚未满足可靠后验消去准则。

### 13.10 补充训练题：丘赛 2026 Problem 4——位移 QR 恒等式



## 完整题目叙述

[Yau-2026-Problem-4]

设  $A \in \mathbb{R}^{N \times N}$  非奇异。给定移位序列  $\{\sigma_n\}$ ，定义位移 QR 迭代

$$A_0 = A, A_n - \sigma_n I_N = Q_n R_n, A_{n+1} = R_n Q_n + \sigma_n I_N, \quad (13.101)$$

其中  $Q_n$  正交,  $R_n$  上三角且对角元为正。

(a) 若没有  $\sigma_n$  是  $A$  的特征值, 证明  $\{A_n\}, \{Q_n\}, \{R_n\}$  唯一确定, 并满足

$$A_{n+1} = Q_n^T A_n Q_n, \quad (13.102)$$

$$A_{n+1} = R_n A_n R_n^{-1}; \quad (13.103)$$

(b) 设  $A$  为对称  $2 \times 2$  矩阵, 特征值为  $\lambda_1, \lambda_2$ , 取  $\sigma_0 = \lambda_1$ 。求  $A_1$ ;

(c) 定义

$$\hat{Q}_n = Q_0 \cdots Q_{n-1}, \quad (13.104)$$

$$\hat{R}_n = R_{n-1} \cdots R_0. \quad (13.105)$$

证明

$$\hat{Q}_{k+1} \hat{R}_{k+1} = \prod_{i=0}^k (A - \sigma_i I_N). \quad (13.106)$$

第 (a) 问. 由于所有  $A_n$  与  $A$  相似,  $\sigma_n$  不是  $A$  的特征值等价于  $A_n - \sigma_n I$  非奇异。

非奇异矩阵在要求  $R_n$  对角元为正时, QR 分解唯一。因此  $Q_n, R_n$  唯一, 进而  $A_{n+1}$  唯一。

由  $A_n - \sigma_n I = Q_n R_n$  得  $R_n = Q_n^T (A_n - \sigma_n I)$ 。故

$$\begin{aligned} A_{n+1} &= R_n Q_n + \sigma_n I \\ &= Q_n^T (A_n - \sigma_n I) Q_n + \sigma_n I \\ &= Q_n^T A_n Q_n. \end{aligned} \quad (13.107)$$

另一方面,  $A_n = Q_n R_n + \sigma_n I$ , 所以

$$\begin{aligned} R_n A_n R_n^{-1} &= R_n (Q_n R_n + \sigma_n I) R_n^{-1} \\ &= R_n Q_n + \sigma_n I = A_{n+1}. \end{aligned} \quad (13.108)$$

□

第 (b) 问: 题面不唯一性及标准消去选取. 当  $\sigma_0 = \lambda_1$  时,  $A - \lambda_1 I$  奇异, 所以不存在“ $R_0$  正对角”的非奇异 QR 分解, 第 (a) 问的唯一性条件失效。

因此按题面字面,  $A_1$  一般不唯一。例如若  $A = \text{diag}(\lambda_1, \lambda_2)$ , 取  $Q_0 = I$  可得  $A_1 = A$ 。若取交换矩阵  $Q_0 = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ , 也可构造上三角  $R_0$ , 并得到  $A_1 = \text{diag}(\lambda_2, \lambda_1)$ 。

若采用标准精确消去选取: 令  $q_2$  为  $\lambda_1$  对应单位特征向量, 令  $q_1$  为  $\lambda_2$  对应单位特征向量, 并

取  $Q_0 = \begin{pmatrix} \mathbf{q}_1 & \mathbf{q}_2 \end{pmatrix}$ , 则

$$A_1 = Q_0^T A Q_0 = \begin{pmatrix} \lambda_2 & 0 \\ 0 & \lambda_1 \end{pmatrix}. \quad (13.109)$$

此时  $\lambda_1$  被精确移动到右下角并完成消去。  $\square$

第 (c) 问. 先证明

$$A_k = \widehat{Q}_k^T A \widehat{Q}_k. \quad (13.110)$$

这由第 (a) 问的相似关系归纳得到。

当  $k=0$  时,  $\widehat{Q}_1 \widehat{R}_1 = Q_0 R_0 = A - \sigma_0 I$ 。假设  $\widehat{Q}_k \widehat{R}_k = \prod_{i=0}^{k-1} (A - \sigma_i I)$ 。则

$$\begin{aligned} \widehat{Q}_{k+1} \widehat{R}_{k+1} &= \widehat{Q}_k Q_k R_k \widehat{R}_k \\ &= \widehat{Q}_k (A_k - \sigma_k I) \widehat{R}_k \\ &= \widehat{Q}_k (\widehat{Q}_k^T A \widehat{Q}_k - \sigma_k I) \widehat{R}_k \\ &= (A - \sigma_k I) \widehat{Q}_k \widehat{R}_k \\ &= (A - \sigma_k I) \prod_{i=0}^{k-1} (A - \sigma_i I). \end{aligned} \quad (13.111)$$

由于各因子均为  $A$  的多项式, 彼此可交换, 故得到 式 (13.106)。  $\square$

### 13.11 正式真题 [23F-Q2]——显式位移 QR 与尾部收敛估计

完整题目叙述: [23F-Q2]

考虑用显式位移 QR 算法计算  $A \in \mathbb{C}^{n \times n}$  的特征值:

1: 求上 Hessenberg 矩阵  $H_0$  和酉矩阵  $U_0$ , 使  $H_0 = U_0^H A U_0$ ;

2: 对  $k = 0, 1, 2, \dots$ :

1. 选取标量位移  $\mu_k$ ;
2. 计算 QR 分解  $Q_k R_k = H_k - \mu_k I$ ;
3. 更新  $H_{k+1} = R_k Q_k + \mu_k I$ .

(1) 证明  $H_i$  对  $i = 1, 2, \dots$  均为上 Hessenberg 矩阵;

(2) 解释为什么先使用  $H_0$  而不是直接对  $A$  迭代;

(3) 假设  $A$  有  $n$  个互异特征值, 且所有位移  $\mu_i$  均不是  $A$  的特征值。证明  $H_i$  均为不约化上 Hessenberg 矩阵 (原题如此, 这一问其实是错的);

(4) 写

$$H_k = \begin{pmatrix} G_k & \mathbf{u}_k \\ \varepsilon_k \mathbf{e}^T & \alpha_k \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix} \in \mathbb{C}^{n-1}. \quad (13.112)$$

若  $\mu_k \notin \sigma(G_k)$ ,  $\rho_k = \|(G_k - \mu_k I)^{-1}\|_2$ , 证明

$$|\varepsilon_{k+1}| \leq \rho_k^2 \|\mathbf{u}_k\|_2 |\varepsilon_k|^2 + \rho_k |\alpha_k - \mu_k| |\varepsilon_k|. \quad (13.113)$$

第 (1) 问: *Hessenberg* 结构保持. 因为  $H_k - \mu_k I$  仍为上 *Hessenberg* 矩阵, 其 QR 分解可用  $n-1$  个相邻 Givens 旋转计算. 所得  $Q_k$  为上 *Hessenberg* 酉矩阵,  $R_k$  为上三角矩阵.

现考察  $R_k Q_k$ . 当  $i > j+1$  时,

$$(R_k Q_k)_{ij} = \sum_{\ell=i}^n (R_k)_{i\ell} (Q_k)_{\ell j}. \quad (13.114)$$

由于  $\ell \geq i > j+1$  且  $Q_k$  为上 *Hessenberg* 矩阵,  $(Q_k)_{\ell j} = 0$ . 故  $(R_k Q_k)_{ij} = 0$ ,  $i > j+1$ . 加上  $\mu_k I$  不改变 *Hessenberg* 零结构, 所以  $H_{k+1}$  为上 *Hessenberg* 矩阵.

也可由  $H_{k+1} = Q_k^H H_k Q_k$  结合隐式 QR 结构证明.  $\square$

第 (2) 问: *Hessenberg* 预处理的目的是. 若直接对稠密  $A$  作每次 QR 步:

- QR 分解成本为  $O(n^3)$ ;
- 形成  $RQ$  成本也为  $O(n^3)$ .

先用酉相似变换作一次 *Hessenberg* 约化, 成本为  $O(n^3)$ . 以后每次 QR 扫描只需:

- $n-1$  个 Givens 旋转;
- $O(n^2)$  运算;
- $O(n^2)$  存储;
- 保持 *Hessenberg* 结构.

因此整个特征值算法的总成本保持在  $O(n^3)$  量级. 同时, 酉相似变换:

- 保持特征值;
- 保持二范数;
- 不放大条件数;
- 具有良好的舍入误差稳定性.

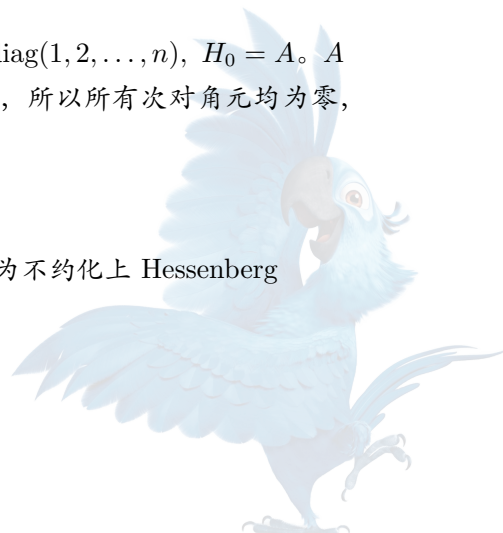
$\square$

第 (3) 问: 题面核对与预期结论. 按原题字面, 该结论不成立. 取  $A = \text{diag}(1, 2, \dots, n)$ ,  $H_0 = A$ .  $A$  有  $n$  个互异特征值. 取任意非特征值位移, QR 迭代始终保持对角形式, 所以所有次对角元均为零,  $H_k$  不是不约化 *Hessenberg* 矩阵.

正确的预期命题应为:

若  $H_0$  是不约化上 *Hessenberg* 矩阵, 且  $\mu_k \notin \sigma(A)$ , 则所有  $H_k$  均为不约化上 *Hessenberg* 矩阵.

下面证明该修正命题.



设  $H_k - \mu_k I = Q_k R_k$  通过相邻 Givens 旋转得到。因为  $H_k$  不约化，每个待消去次对角元均非零，故对应 Givens 旋转的正弦参数非零。因此  $(Q_k)_{i+1,i} \neq 0$ ,  $i = 1, \dots, n-1$ 。又因为  $\mu_k \notin \sigma(H_k) = \sigma(A)$ ，矩阵  $H_k - \mu_k I$  非奇异，故  $R_k$  非奇异，并且  $(R_k)_{ii} \neq 0$ 。对更新矩阵的次对角元，

$$\begin{aligned} (H_{k+1})_{i+1,i} &= (R_k Q_k)_{i+1,i} \\ &= (R_k)_{i+1,i+1} (Q_k)_{i+1,i} \neq 0. \end{aligned} \quad (13.115)$$

所以  $H_{k+1}$  仍不约化。

若  $A$  有互异特征值，则其最小多项式次数为  $n$ ，可以选择循环向量  $\mathbf{q}_1$ ，通过 Arnoldi 过程构造一个不约化 Hessenberg 表示  $H_0$ ；但这种构造必须明确指定，不能由“互异特征值”自动推得任意  $H_0$  不约化。□

第 (4) 问：块 QR 分解。省略下标  $k$ ，写  $H - \mu I = \begin{pmatrix} G - \mu I & \mathbf{u} \\ \varepsilon \mathbf{e}^\top & \alpha - \mu \end{pmatrix} = QR$ 。将 QR 因子分块：

$$Q = \begin{pmatrix} Q_1 & \mathbf{q}_n \end{pmatrix}, \quad R = \begin{pmatrix} R_{11} & \mathbf{r}_{12} \\ 0 & r_{nn} \end{pmatrix}, \quad (13.116)$$

其中  $Q_1 \in \mathbb{C}^{n \times (n-1)}$ ,  $R_{11} \in \mathbb{C}^{(n-1) \times (n-1)}$ 。前  $n-1$  列满足

$$M := \begin{pmatrix} G - \mu I \\ \varepsilon \mathbf{e}^\top \end{pmatrix} = Q_1 R_{11}. \quad (13.117)$$

最后一列为

$$\mathbf{c} := \begin{pmatrix} \mathbf{u} \\ \alpha - \mu \end{pmatrix}. \quad (13.118)$$

首先估计  $R_{11}^{-1}$ 。对任意  $\mathbf{z}$ ，

$$\begin{aligned} \|M\mathbf{z}\|_2^2 &= \|(G - \mu I)\mathbf{z}\|_2^2 + |\varepsilon|^2 |\mathbf{e}^\top \mathbf{z}|^2 \\ &\geq \|(G - \mu I)\mathbf{z}\|_2^2. \end{aligned} \quad (13.119)$$

因此

$$\sigma_{\min}(M) \geq \sigma_{\min}(G - \mu I) = \frac{1}{\rho}. \quad (13.120)$$

$M$  与  $R_{11}$  具有相同奇异值，故

$$\|R_{11}^{-1}\|_2 \leq \rho. \quad (13.121)$$

特别地，

$$\frac{1}{|r_{n-1,n-1}|} \leq \|R_{11}^{-1}\|_2 \leq \rho. \quad (13.122)$$

其次估计  $r_{nn}$ 。QR 分解中， $|r_{nn}|$  等于最后一列到前  $n-1$  列空间的距离：

$$|r_{nn}| = \min_{\mathbf{z} \in \mathbb{C}^{n-1}} \|\mathbf{c} - M\mathbf{z}\|_2. \quad (13.123)$$

取  $\mathbf{z}_0 = (G - \mu I)^{-1} \mathbf{u}$ 。则

$$\mathbf{c} - M\mathbf{z}_0 = \begin{pmatrix} \mathbf{0} \\ \alpha - \mu - \varepsilon \mathbf{e}^\top (G - \mu I)^{-1} \mathbf{u} \end{pmatrix}. \quad (13.124)$$





所以

$$\begin{aligned} |r_{nn}| &\leq |\alpha - \mu| + |\varepsilon| \|(G - \mu I)^{-1}\|_2 \|\mathbf{u}\|_2 \\ &= |\alpha - \mu| + \rho |\varepsilon| \|\mathbf{u}\|_2. \end{aligned} \quad (13.125)$$

最后利用 Hessenberg QR 结构。原矩阵的最后一个次对角元满足

$$\varepsilon = q_{n,n-1} r_{n-1,n-1}. \quad (13.126)$$

更新后  $H^+ - \mu I = RQ$ , 故

$$\varepsilon^+ = r_{nn} q_{n,n-1}. \quad (13.127)$$

因此

$$\begin{aligned} |\varepsilon^+| &= |\varepsilon| \frac{|r_{nn}|}{|r_{n-1,n-1}|} \\ &\leq |\varepsilon| \rho [|\alpha - \mu| + \rho |\varepsilon| \|\mathbf{u}\|_2]. \end{aligned} \quad (13.128)$$

即  $|\varepsilon^+| \leq \rho^2 \|\mathbf{u}\|_2 |\varepsilon|^2 + \rho |\alpha - \mu| |\varepsilon|$ 。恢复下标  $k$  即得 式 (13.113)。  $\square$

注 13.11 (估计的收敛含义). 若位移选择使  $|\alpha_k - \mu_k| = O(|\varepsilon_k|)$ , 并且  $\rho_k, \|\mathbf{u}_k\|$  保持有界, 则  $|\varepsilon_{k+1}| = O(|\varepsilon_k|^2)$ 。若进一步位移误差为  $|\alpha_k - \mu_k| = O(|\varepsilon_k|^2)$ , 则可能出现更高阶的局部消去速度。

## 13.12 结构化特征值母题：伴随矩阵、三对角矩阵与快速矩阵幂

### 13.12.1 补充训练题：伴随矩阵的 Vandermonde 对角化

完整题目叙述：[NLA-Set-2019-Oral-Problem-1]

设多项式

$$p(z) = z^n + c_{n-1}z^{n-1} + \cdots + c_1z + c_0 \quad (13.129)$$

的伴随矩阵为

$$C = \begin{pmatrix} 0 & 0 & \cdots & 0 & -c_0 \\ 1 & 0 & \cdots & 0 & -c_1 \\ 0 & 1 & \cdots & 0 & -c_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & 1 & -c_{n-1} \end{pmatrix}. \quad (13.130)$$

假设  $C$  有互异特征值  $\lambda_1, \dots, \lambda_n$ 。证明

$$VCV^{-1} = \text{diag}(\lambda_1, \dots, \lambda_n), \quad (13.131)$$

其中

$$V = \begin{pmatrix} 1 & \lambda_1 & \cdots & \lambda_1^{n-1} \\ 1 & \lambda_2 & \cdots & \lambda_2^{n-1} \\ \vdots & \vdots & & \vdots \\ 1 & \lambda_n & \cdots & \lambda_n^{n-1} \end{pmatrix}. \quad (13.132)$$

证明. 对任意多项式零点  $\lambda_i$ , 令  $\mathbf{w}_i^T = (1 \ \lambda_i \ \cdots \ \lambda_i^{n-1})$ . 直接乘法得到

$$\mathbf{w}_i^T C = (\lambda_i \ \lambda_i^2 \ \cdots \ \lambda_i^{n-1} \ -c_0 - c_1 \lambda_i - \cdots - c_{n-1} \lambda_i^{n-1}). \quad (13.133)$$

由于  $p(\lambda_i) = 0$ , 有  $-c_0 - c_1 \lambda_i - \cdots - c_{n-1} \lambda_i^{n-1} = \lambda_i^n$ . 因此

$$\mathbf{w}_i^T C = \lambda_i \mathbf{w}_i^T. \quad (13.134)$$

把  $n$  个等式叠放:  $VC = \text{diag}(\lambda_1, \dots, \lambda_n)V$ . 互异  $\lambda_i$  使 Vandermonde 行列式  $\det V = \prod_{1 \leq i < j \leq n} (\lambda_j - \lambda_i) \neq 0$ . 故  $V$  可逆, 并得到 式 (13.131).  $\square$

注 13.12. 伴随矩阵把多项式求根转化为矩阵特征值问题. 但当零点聚集时, Vandermonde 矩阵可能高度病态, 这与多项式根对系数扰动的敏感性一致.

### 13.12.2 补充训练题: 非对称三对角 Toeplitz 矩阵

完整题目叙述: [NLA-Set-2014-Oral]

求下列  $N \times N$  三对角矩阵的全部特征值和特征向量:

$$A = \begin{pmatrix} b & c & & & \\ a & b & c & & \\ & a & b & \ddots & \\ & & \ddots & \ddots & c \\ & & & a & b \end{pmatrix}, \quad ac > 0. \quad (13.135)$$

证明. 选择非零数  $s, \gamma$  满足

$$s^2 = \frac{a}{c}, \quad \gamma = cs = \frac{a}{s}, \quad \gamma^2 = ac. \quad (13.136)$$

令  $D = \text{diag}(1, s, s^2, \dots, s^{N-1})$ . 则

$$D^{-1}AD = \begin{pmatrix} b & \gamma & & & \\ \gamma & b & \gamma & & \\ & \gamma & b & \ddots & \\ & & \ddots & \ddots & \gamma \\ & & & \gamma & b \end{pmatrix} =: T. \quad (13.137)$$


$T$  为对称三对角 Toeplitz 矩阵。

令

$$\theta_k = \frac{k\pi}{N+1}, \quad k = 1, \dots, N, \quad (13.138)$$

并定义  $y_j^{(k)} = \sin(j\theta_k)$ ,  $j = 1, \dots, N$ . 利用边界值  $y_0^{(k)} = y_{N+1}^{(k)} = 0$  及恒等式  $\sin((j-1)\theta) + \sin((j+1)\theta) = 2\cos\theta \sin(j\theta)$ , 有

$$\begin{aligned} (Ty^{(k)})_j &= \gamma y_{j-1}^{(k)} + b y_j^{(k)} + \gamma y_{j+1}^{(k)} \\ &= [b + 2\gamma \cos \theta_k] y_j^{(k)}. \end{aligned} \quad (13.139)$$



因此

$$\lambda_k = b + 2\gamma \cos\left(\frac{k\pi}{N+1}\right). \quad (13.140)$$

由于  $A = DTD^{-1}$ ，对应右特征向量为

$$x_j^{(k)} = s^{j-1} \sin\left(\frac{jk\pi}{N+1}\right), \quad j = 1, \dots, N. \quad (13.141)$$

对实数  $a, c$  且  $ac > 0$ ，可取  $s = \sqrt{a/c} > 0$ ， $\gamma = c\sqrt{a/c} = \text{sign}(c)\sqrt{ac}$ 。若  $a, c < 0$ ， $\gamma < 0$  只会逆转特征值排列，特征值集合不变。□

### 13.12.3 补充训练题：丘赛 2025 Problem 2——路径图矩阵逆的谱半径

完整题目叙述

[Yau-2025-Problem-2]

计算  $A^{-1}$  的谱半径，其中

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}. \quad (13.142)$$

证明. 这是 8 阶对称三对角 Toeplitz 矩阵，对应  $a = c = 1$ ， $b = 0$ 。由前述公式，特征值为

$$\lambda_k(A) = 2 \cos\left(\frac{k\pi}{9}\right), \quad k = 1, \dots, 8. \quad (13.143)$$

因为 9 为奇数，没有  $k$  使  $k\pi/9 = \pi/2$ ，所以  $A$  非奇异。


$A^{-1}$  的特征值为  $\lambda_k(A^{-1}) = \frac{1}{2 \cos(k\pi/9)}$ 。故  $\rho(A^{-1}) = \frac{1}{\min_k |2 \cos(k\pi/9)|}$ 。离  $\pi/2$  最近的两个角为  $\frac{4\pi}{9}$ ， $\frac{5\pi}{9}$ 。因此

$$\begin{aligned} \min_k |2 \cos(k\pi/9)| &= 2 \cos \frac{4\pi}{9} \\ &= 2 \sin \frac{\pi}{18}. \end{aligned} \quad (13.144)$$

所以

$$\rho(A^{-1}) = \frac{1}{2 \sin(\pi/18)} \approx 2.879385. \quad (13.145)$$

□



## 13.12.4 补充训练题：快速 Fibonacci 矩阵幂

完整题目叙述：[NLA-Set-2013-Team-Q6]

设 Fibonacci 数列满足  $F_0 = 0$ ,  $F_1 = 1$ ,  $F_{n+2} = F_{n+1} + F_n$ 。建立  $M = \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix}$  的  $n$  次幂与  $F_n$  的关系，并设计一个比逐项递推更高效的算法计算  $F_n$ ，估计算法步数。

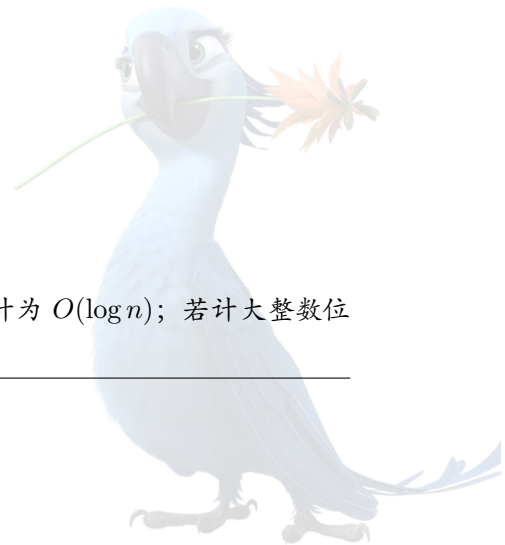
证明. 由  $\begin{pmatrix} F_n \\ F_{n+1} \end{pmatrix} = M \begin{pmatrix} F_{n-1} \\ F_n \end{pmatrix}$ , 归纳得  $\begin{pmatrix} F_n \\ F_{n+1} \end{pmatrix} = M^n \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 。更精确地, 对  $n \geq 1$ ,

$$M^n = \begin{pmatrix} F_{n-1} & F_n \\ F_n & F_{n+1} \end{pmatrix}. \quad (13.146)$$

$n = 1$  时成立。若对  $n$  成立, 则

$$\begin{aligned} M^{n+1} &= \begin{pmatrix} F_{n-1} & F_n \\ F_n & F_{n+1} \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix} \\ &= \begin{pmatrix} F_n & F_{n-1} + F_n \\ F_{n+1} & F_n + F_{n+1} \end{pmatrix} \\ &= \begin{pmatrix} F_n & F_{n+1} \\ F_{n+1} & F_{n+2} \end{pmatrix}. \end{aligned} \quad (13.147)$$

□

**Algorithm 57** 二进制快速幂计算  $F_n$ **Input:** 非负整数  $n$ **Output:** Fibonacci 数  $F_n$ 1: **if**  $n = 0$  **then**2:     **return** 03: **end if**4: **Initialization:**  $R \leftarrow I_2$ ,  $B \leftarrow \begin{pmatrix} 0 & 1 \\ 1 & 1 \end{pmatrix}$ ,  $p \leftarrow n$ 5: **while**  $p > 0$  **do**6:     **if**  $p$  为奇数 **then**7:          $R \leftarrow RB$ 8:     **end if**9:      $B \leftarrow B^2$ 10:     $p \leftarrow \lfloor p/2 \rfloor$ 11: **end while**12: **return**  $R_{12}$ 13: **Stopping criterion:**  $p = 0$ 14: **Complexity:** 需要  $O(\log n)$  次  $2 \times 2$  矩阵乘法; 按标量算术次数计为  $O(\log n)$ ; 若计大整数位复杂度, 还需考虑  $F_n$  位数随  $n$  线性增长

由矩阵恒等式还可得到快速倍增公式

$$F_{2m} = F_m (2F_{m+1} - F_m), \quad (13.148)$$

$$F_{2m+1} = F_{m+1}^2 + F_m^2. \quad (13.149)$$

### 13.13 广义特征值问题、矩阵铅笔与广义 Schur 分解

#### 13.13.1 知识点十六：齐次广义特征值

给定  $A, B \in \mathbb{C}^{n \times n}$ , 本文采用正式试卷中的齐次约定: 寻找  $\mathbf{x} \neq \mathbf{0}$ ,  $(\lambda, \mu) \in \mathbb{C}^2$ ,  $|\lambda|^2 + |\mu|^2 = 1$ , 使

$$\boxed{\mu A \mathbf{x} = \lambda B \mathbf{x}}. \quad (13.150)$$

$(\lambda, \mu)$  本质上是复射影直线中的点:  $(\lambda, \mu) \sim (\alpha\lambda, \alpha\mu)$ ,  $\alpha \neq 0$ . 归一化  $|\lambda|^2 + |\mu|^2 = 1$  只是选择一个代表元。

若  $\mu \neq 0$ , 可定义有限广义特征值

$$\theta = \frac{\lambda}{\mu}. \quad (13.151)$$

此时  $A\mathbf{x} = \theta B\mathbf{x}$ 。

若  $\mu = 0$ ,  $\lambda \neq 0$ , 则  $B\mathbf{x} = 0$ , 对应无限特征值。

定义 13.13 (矩阵铅笔的正则性). 矩阵铅笔  $A - \theta B$  称为正则, 当且仅当

$$\det(A - \theta B) \neq 0 \quad (13.152)$$

作为  $\theta$  的多项式不恒为零。

否则称为奇异矩阵铅笔。

正则铅笔有  $n$  个射影广义特征值, 按代数重数计数。奇异铅笔可能:

- 有无限多个满足方程的  $(\lambda, \mu)$ ;
- 存在公共零空间方向;
- 包含左、右最小指标;
- 不能用普通“ $n$  个特征值”描述。

#### 易错点与反例

不能无条件把广义特征值问题改写成  $B^{-1}A\mathbf{x} = \theta\mathbf{x}$  或  $AB^{-1}\mathbf{y} = \theta\mathbf{y}$ 。


只有当相应矩阵非奇异时才允许这样做, 而且显式形成逆矩阵会破坏数值稳定性和稀疏结构。

#### 13.13.2 知识点十七：酉等价变换与广义 Schur 形式

对酉矩阵  $Q, Z$ , 定义双边酉等价变换

$$Q^H(A, B)Z = (Q^H A Z, Q^H B Z). \quad (13.153)$$

它保持矩阵铅笔的广义特征值结构, 因为  $\det[\mu(Q^H A Z) - \lambda(Q^H B Z)] = \det(Q^H) \det(\mu A - \lambda B) \det Z$ 。



定理 13.14 (广义 Schur 分解). 对任意  $A, B \in \mathbb{C}^{n \times n}$ , 存在酉矩阵  $Q, Z$  使

$$Q^H A Z = S, Q^H B Z = T, \quad (13.154)$$

其中  $S, T$  均为上三角矩阵。

该分解也称 QZ 分解或广义 Schur 形式。

若矩阵对正则, 则对角元对  $(s_{ii}, t_{ii})$  不同时为零, 且广义特征值可取

$$(\lambda_i, \mu_i) = \frac{(s_{ii}, t_{ii})}{\sqrt{|s_{ii}|^2 + |t_{ii}|^2}}. \quad (13.155)$$

因为  $\mu_i s_{ii} = \lambda_i t_{ii}$ 。

若  $t_{ii} \neq 0$ , 有限特征值为  $\theta_i = \frac{s_{ii}}{t_{ii}}$ 。若  $t_{ii} = 0, s_{ii} \neq 0$ , 则该特征值为无穷。

### 13.13.3 知识点十八: Hessenberg-三角化与 QZ 算法

QZ 算法通常分两阶段:

1. 预处理: 通过双边酉变换把  $(A, B)$  约化为  $(H, T)$ , 其中  $H$  上 Hessenberg,  $T$  上三角;
2. QZ 迭代: 选取广义位移, 对铅笔作隐式双边 Givens/Householder 变换, 保持 Hessenberg-三角结构, 逐步消去  $H$  的次对角元, 最终得到  $(S, T)$ 。

---

#### Algorithm 58 QZ 算法框架

---

**Input:** 矩阵对  $(A, B)$ ; 容差; 是否累积广义 Schur 向量

**Output:**  $Q^H A Z = S, Q^H B Z = T$

- 1: 通过 QR/RQ 及双边 Householder 变换, 把  $(A, B)$  约化为 Hessenberg-三角对  $(H, T)$
  - 2: **while** 存在未消去活动块 **do**
  - 3:   检查  $H$  的次对角元及  $T$  的对角元, 执行可靠的广义消去判据
  - 4:   从尾部  $2 \times 2$  铅笔选取一个或两个广义位移
  - 5:   在  $\beta H - \alpha T$  中引入隐式 bulge
  - 6:   交替使用左、右 Givens 旋转追赶 bulge, 保持  $H$  上 Hessenberg、 $T$  上三角
  - 7:   累积  $Q, Z$ , 若只需特征值则可不显式形成全部向量
  - 8: **end while**
  - 9: 从  $(S, T)$  的对角元对读取有限或无限广义特征值
  - 10: **Stopping criterion:**  $S, T$  均达到广义 Schur 形式
  - 11: **Complexity:** Hessenberg-三角化  $O(n^3)$ ; 每次 QZ 扫掠  $O(n^2)$ ; 总体通常  $O(n^3)$ ; 存储  $O(n^2)$
- 

### 13.13.4 补充训练题——共享正弦特征向量的广义三对角问题

完整题目叙述: [NLA-Set-2015-Oral-Team-Q1]

求广义特征值  $\lambda$  及特征向量  $\mathbf{x} = (x_1, \dots, x_n)^\top$  使

$$A\mathbf{x} = \lambda B\mathbf{x}, \quad (13.156)$$

其中

$$A = \text{tridiag}(-1, 2, -1), \quad (13.157)$$

$$B = \text{tridiag}(1, 4, 1). \quad (13.158)$$

证明. 令  $\theta_k = \frac{k\pi}{n+1}$ ,  $k = 1, \dots, n$ , 并定义

$$x_j^{(k)} = \sin(j\theta_k), \quad j = 1, \dots, n. \quad (13.159)$$

利用  $x_{j-1}^{(k)} + x_{j+1}^{(k)} = 2 \cos \theta_k x_j^{(k)}$ , 得到

$$A\mathbf{x}^{(k)} = (2 - 2 \cos \theta_k) \mathbf{x}^{(k)}, \quad (13.160)$$

$$B\mathbf{x}^{(k)} = (4 + 2 \cos \theta_k) \mathbf{x}^{(k)}. \quad (13.161)$$

由于  $4 + 2 \cos \theta_k > 0$ ,  $B$  正定且非奇异. 因此

$$\lambda_k = \frac{2 - 2 \cos \theta_k}{4 + 2 \cos \theta_k} = \frac{1 - \cos \theta_k}{2 + \cos \theta_k}, \quad \theta_k = \frac{k\pi}{n+1}. \quad (13.162)$$

对应特征向量为

$$\mathbf{x}^{(k)} = (\sin \theta_k, \sin 2\theta_k, \dots, \sin n\theta_k)^T. \quad (13.163)$$

□

### 13.14 正式真题 [25F-Q3]——广义 Schur 分解与 Hessenberg-三角化

完整题目叙述: [25F-Q3]

在许多应用中需要求解广义特征值问题: 给定  $A, B \in \mathbb{C}^{n \times n}$ , 求  $\mathbf{x} \in \mathbb{C}^n$ ,  $\mu, \lambda \in \mathbb{C}$ , 满足

$$\mathbf{x} \neq \mathbf{0}, \quad |\mu|^2 + |\lambda|^2 = 1, \quad \mu A\mathbf{x} = \lambda B\mathbf{x}. \quad (13.164)$$

称  $\mathbf{x}$  和  $(\lambda, \mu)$  分别为矩阵对  $(A, B)$  的广义特征向量与广义特征值。

若  $B$  非奇异, 令  $\mathbf{y} = B\mathbf{x}$ , 则问题等价于  $AB^{-1}\mathbf{y} = \mu^{-1}\lambda\mathbf{y}$ 。

若  $Q, Z$  酉且  $Q^H A Z = S$ ,  $Q^H B Z = T$ , 称这是作用于矩阵对  $(A, B)$  的酉等价变换, 简记为  $Q^H(A, B)Z = (S, T)$ 。

- (a) 给出一个矩阵对  $(A, B)$  拥有多于  $n$  个广义特征值的例子;
- (b) 证明存在酉等价变换, 使  $Q^H(A, B)Z = (S, T)$ , 其中  $S, T$  均为上三角矩阵;
- (c) 能否从  $(S, T)$  得到  $(A, B)$  的广义特征值? 如何得到?
- (d) 提出一种方法, 构造酉等价变换  $Q_0^H(A, B)Z_0 = (A_0, B_0)$ , 其中  $A_0$  为上 Hessenberg 矩阵,  $B_0$  为上三角矩阵. 可为方便假设  $n = 4$ 。


第 (a) 问: 奇异铅笔可有无限多个广义特征值. 取  $n \geq 2$  并令

$$A = B = \text{diag}(1, 0, \dots, 0). \quad (13.165)$$

取  $\mathbf{x} = \mathbf{e}_2$ . 则  $A\mathbf{x} = B\mathbf{x} = \mathbf{0}$ . 因此对任意满足  $|\lambda|^2 + |\mu|^2 = 1$  的  $(\lambda, \mu)$ , 均有  $\mu A\mathbf{x} = \lambda B\mathbf{x} = \mathbf{0}$ . 所以该矩阵对有不可数多个广义特征值, 显然多于  $n$  个。

该例中  $\det(\mu A - \lambda B) \equiv 0$ , 所以这是奇异矩阵铅笔。 □

第 (b) 问: 广义 Schur 分解的存在性. 先处理  $B$  非奇异的情形。





对  $C = AB^{-1}$  作复 Schur 分解:

$$Q^H C Q = S, \quad (13.166)$$

其中  $Q$  酉,  $S$  上三角。

再对  $B^{-1}Q$  作 QR 分解:

$$B^{-1}Q = ZR, \quad (13.167)$$

其中  $Z$  酉,  $R$  非奇异上三角。

由  $BZR = Q$  得

$$Q^H B Z = R^{-1}, \quad (13.168)$$

为上三角矩阵。

又由  $AZR = AB^{-1}Q = CQ = QS$  得

$$Q^H A Z = S R^{-1}, \quad (13.169)$$

也为上三角矩阵。

下面处理一般可能奇异的  $B$ 。选择序列  $\varepsilon_\ell \rightarrow 0$  使  $B_\ell := B + \varepsilon_\ell I$  均非奇异。这是可行的, 因为  $\det(B + \varepsilon I)$  作为  $\varepsilon$  的多项式只有有限个零点。

对每个  $(A, B_\ell)$ , 由前述结论存在酉矩阵  $Q_\ell, Z_\ell$  使  $Q_\ell^H A Z_\ell$  和  $Q_\ell^H B_\ell Z_\ell$  均为上三角。

酉群  $U(n)$  为紧集, 故可取子序列使  $Q_\ell \rightarrow Q, Z_\ell \rightarrow Z$ 。极限  $Q, Z$  仍酉。又由于上三角矩阵集合闭,  $Q^H A Z = \lim_{\ell \rightarrow \infty} Q_\ell^H A Z_\ell$  上三角, 并且

$$Q^H B Z = \lim_{\ell \rightarrow \infty} Q_\ell^H (B + \varepsilon_\ell I) Z_\ell \quad (13.170)$$

也上三角。故一般情形的广义 Schur 分解存在。  $\square$

第 (c) 问: 从对角元读取广义特征值。设  $S = (s_{ij}), T = (t_{ij})$  均上三角。则

$$\det(\mu S - \lambda T) = \prod_{i=1}^n (\mu s_{ii} - \lambda t_{ii}). \quad (13.171)$$

由于酉等价只改变行列式一个非零常数因子,  $(A, B)$  与  $(S, T)$  具有相同广义特征值。

若矩阵铅笔正则, 每个  $(s_{ii}, t_{ii}) \neq (0, 0)$ 。取

$$(\lambda_i, \mu_i) = \frac{(s_{ii}, t_{ii})}{\sqrt{|s_{ii}|^2 + |t_{ii}|^2}}. \quad (13.172)$$

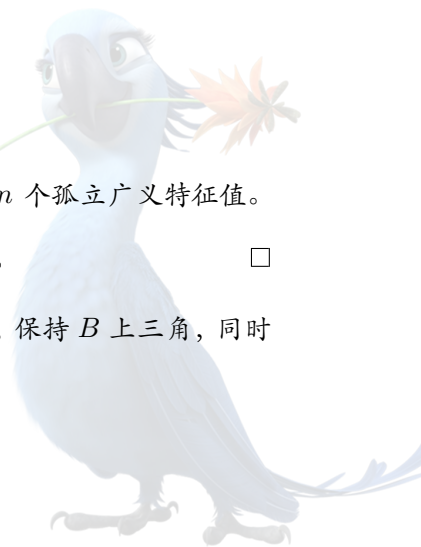
则  $\mu_i s_{ii} - \lambda_i t_{ii} = 0$ 。

具体地:

- 若  $t_{ii} \neq 0$ ,  $\theta_i = \frac{\lambda_i}{\mu_i} = \frac{s_{ii}}{t_{ii}}$ ;
- 若  $t_{ii} = 0$  而  $s_{ii} \neq 0$ , 则  $\mu_i = 0$ , 对应无限特征值;
- 若  $s_{ii} = 0$  而  $t_{ii} \neq 0$ , 则  $\lambda_i = 0$ ;
- 若某个  $s_{ii} = t_{ii} = 0$ , 则  $\det(\mu S - \lambda T) \equiv 0$ , 铅笔为奇异铅笔, 不能解释为  $n$  个孤立广义特征值。

广义特征向量可由  $(\mu_i S - \lambda_i T) \mathbf{y}_i = \mathbf{0}$  作上三角回代得到, 再令  $\mathbf{x}_i = Z \mathbf{y}_i$ 。  $\square$

第 (d) 问:  $n = 4$  的 Hessenberg-三角化构造。目标是通过交替的左、右酉变换, 保持  $B$  上三角, 同时逐列把  $A$  约化为上 Hessenberg。



第一步：先把  $B$  三角化 计算 QR 分解  $B = Q_0 T_0$ 。于是

$$A^{(0)} = Q_0^H A, \quad (13.173)$$

$$B^{(0)} = Q_0^H B = T_0 \quad (13.174)$$

且  $B^{(0)}$  上三角。初始累积变换为  $Q_{\text{acc}} = Q_0$ ,  $Z_{\text{acc}} = I$ 。

第二步：消去  $A^{(0)}$  第一列的第 3、4 个元素 对向量  $A^{(0)}(2:4, 1)$  构造  $3 \times 3$  Householder 矩阵  $\hat{Q}_1$ ，使  $\hat{Q}_1^H A^{(0)}(2:4, 1) = \begin{pmatrix} * \\ 0 \\ 0 \end{pmatrix}$ 。令  $Q_1 = \text{diag}(1, \hat{Q}_1)$ 。左乘更新

$$\tilde{A}^{(1)} = Q_1^H A^{(0)}, \quad (13.175)$$

$$\tilde{B}^{(1)} = Q_1^H B^{(0)}. \quad (13.176)$$

此时  $\tilde{A}^{(1)} = \begin{pmatrix} * & * & * & * \\ * & * & * & * \\ 0 & * & * & * \\ 0 & * & * & * \end{pmatrix}$ ，但  $\tilde{B}^{(1)}$  的右下  $3 \times 3$  块一般不再上三角。

对该尾部块作 RQ 分解：

$$\tilde{B}^{(1)}(2:4, 2:4) = R_1 \hat{Z}_1^H, \quad (13.177)$$

其中  $R_1$  上三角， $\hat{Z}_1$  酉。令  $Z_1 = \text{diag}(1, \hat{Z}_1)$ 。从右更新

$$A^{(1)} = \tilde{A}^{(1)} Z_1, \quad (13.178)$$

$$B^{(1)} = \tilde{B}^{(1)} Z_1. \quad (13.179)$$

于是  $B^{(1)}$  重新成为上三角矩阵。由于  $Z_1$  只混合第 2 至 4 列，不会破坏  $A^{(1)}$  第一列已产生的两个零元。

第三步：消去  $A_{42}^{(1)}$  对  $A^{(1)}(3:4, 2)$  构造  $2 \times 2$  Householder 或 Givens 矩阵  $\hat{Q}_2$ ，使第二个分量归零。令  $Q_2 = \text{diag}(I_2, \hat{Q}_2)$ 。左乘： $\tilde{A}^{(2)} = Q_2^H A^{(1)}$ ， $\tilde{B}^{(2)} = Q_2^H B^{(1)}$ 。随后对  $\tilde{B}^{(2)}(3:4, 3:4)$  作 RQ 分解  $\tilde{B}^{(2)}(3:4, 3:4) = R_2 \hat{Z}_2^H$ ，令  $Z_2 = \text{diag}(I_2, \hat{Z}_2)$ ，并从右更新  $A^{(2)} = \tilde{A}^{(2)} Z_2$ ， $B^{(2)} = \tilde{B}^{(2)} Z_2$ 。

最终

$$A^{(2)} = \begin{pmatrix} * & * & * & * \\ * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \end{pmatrix} \quad (13.180)$$

为上 Hessenberg 矩阵，而  $B^{(2)}$  为上三角矩阵。

累积变换为

$$Q_{\text{acc}} = Q_0 Q_1 Q_2, \quad Z_{\text{acc}} = Z_1 Z_2. \quad (13.181)$$

并满足  $Q_{\text{acc}}^H (A, B) Z_{\text{acc}} = (A^{(2)}, B^{(2)})$ 。

一般  $n$  阶高效实现不会在每一步重新计算完整尾块 RQ，而使用左右 Givens/Householder 变换进行结构化 bulge 追赶，总复杂度为  $O(n^3)$ 。□



## 易错点与反例

1.  $(\lambda, \mu)$  是齐次射影对, 不能把两个分量同时乘零;
2.  $t_{ii} = 0$  不代表算法失败, 而可能表示无限特征值;
3.  $(s_{ii}, t_{ii}) = (0, 0)$  属于奇异铅笔, 不是普通的“零除以零特征值”;
4.  $Q^H A Z$  和  $Q^H B Z$  使用同一个左、右酉变换;
5. 广义 Schur 是双边酉等价, 不是单矩阵酉相似;
6. QZ 算法的预处理目标是 Hessenberg-三角对, 不是分别独立三角化  $A$  和  $B$ ;
7. 即使  $B$  非奇异, 也不应显式形成  $B^{-1}$  或  $AB^{-1}$ 。

## 13.15 本部分易错点、失败情形与完整答题规范

| 错误说法或错误做法                                  | 正确处理                                        |
|--------------------------------------------|---------------------------------------------|
| 幂法求代数意义下最大的特征值。                            | 幂法求模最大的特征值方向; 最大实特征值与最大模特征值不是同一概念。          |
| 任意非零初值都能找到主特征向量。                           | 初值必须在主特征方向有非零分量; 否则该分量永远不会产生。               |
| 归一化幂法的向量一定普通收敛。                            | 负主特征值会导致符号交替, 复主特征值会导致相位旋转; 应使用投影方向或相位不变距离。 |
| $ \lambda_1  =  \lambda_2 $ 时仍可用单向量幂法分离两者。 | 一般需子空间迭代、正交迭代或其他特征值算法。                      |
| 幂法向量误差与 Rayleigh 商误差阶相同。                   | Hermitian 情形 Rayleigh 商误差通常是夹角误差的平方。        |
| 反幂法必须显式计算 $(A - \mu I)^{-1}$ 。             | 应分解 $A - \mu I$ 并重复解线性方程。                   |
| 移位越接近特征值, 线性系统病态, 所以反幂向量一定不准。              | 病态主要放大目标特征方向; 归一化后方向仍可很准, 但需后向稳定求解和非零目标分量。  |
| Rayleigh 商迭代全局立方收敛。                        | Hermitian 简单特征值附近局部立方收敛; 一般矩阵通常只有局部二次或更差。   |
| Rayleigh 商迭代中出现奇异矩阵必然是失败。                  | 若移位已等于目标特征值, 奇异性可能意味着已经达到精确特征对; 实现需先检查残差。   |
| 任意矩阵都可酉对角化。                                | 任意矩阵可酉三角化; 只有正规矩阵可酉对角化。                     |
| 上 Hessenberg 矩阵就是上三角矩阵。                    | Hessenberg 允许第一条次对角线非零。                     |
| $A$ 有互异特征值即可保证任意 Hessenberg 表示不约化。         | 错误; 对角矩阵是反例。需指定循环向量构造或直接假设不约化。              |
| Hessenberg 化会改变特征值。                        | 它使用酉相似变换, 特征值完全保持。                          |

| 错误说法或错误做法                            | 正确处理                                              |
|--------------------------------------|---------------------------------------------------|
| 直接对稠密矩阵反复 QR 与先 Hessenberg 化成本相同。    | 前者每步 $O(n^3)$ ; Hessenberg 化后每步 $O(n^2)$ 。        |
| QR 更新 $RQ$ 与原矩阵无关。                   | $RQ = Q^H A Q$ , 是酉相似变换。                          |
| 选取精确特征值作位移时 QR 因子仍唯一且 $R$ 正对角。       | 此时移位矩阵奇异, 标准唯一性条件失效; 需单独规定分解和消去策略。                |
| 小次对角元可无条件置零。                         | 应采用相对于相邻对角元和机器精度的后验消去判据。                          |
| 只要特征值互异, 无位移 QR 就一定快速。               | 收敛还受特征值模比、正规性和位移策略影响。                             |
| 一般广义特征值问题可直接算 $B^{-1}A$ 。            | $B$ 可能奇异; 即使可逆也不应显式形成逆, 应使用 QZ。                   |
| 广义特征值总恰有 $n$ 个。                      | 只有正则矩阵铅笔才有 $n$ 个射影特征值; 奇异铅笔可有无限多个。                |
| $t_{ii} = 0$ 表示广义特征值不存在。             | 若 $s_{ii} \neq 0$ , 它表示无限特征值。                     |
| 广义 Schur 分解是 $Q^H A Q$ 和 $Q^H B Q$ 。 | 一般需要两个不同的酉矩阵: $Q^H A Z$ 与 $Q^H B Z$ 。             |
| 谱半径 $\rho(A^{-1}) = 1/\rho(A)$ 。     | 一般应为 $1/\min_{\lambda \in \sigma(A)}  \lambda $ 。 |
| 三对角 Toeplitz 矩阵的特征向量总是纯正弦向量。         | 非对称副对角情形还需几何对角缩放。                                 |



# 第十四章 Jacobi、Gauss–Seidel、SOR、CG、Krylov、Arnoldi、Lanczos、GMRES、预处理与大型稀疏矩阵

## 14.1 定常线性迭代的统一框架

### 14.1.1 知识点一：矩阵分裂、相容性与误差方程

【重要性等级】 **S 级**。考虑线性方程组

$$A\mathbf{x} = \mathbf{b}, A \in \mathbb{C}^{n \times n}, \det A \neq 0. \quad (14.1)$$

设矩阵分裂为

$$A = M - N, \quad (14.2)$$

其中  $M$  容易求逆或容易求解线性系统。由  $M\mathbf{x} = N\mathbf{x} + \mathbf{b}$  得到定常迭代

$$\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)} + \mathbf{c}, T = M^{-1}N, \mathbf{c} = M^{-1}\mathbf{b}. \quad (14.3)$$

该迭代也可写成残差校正形式

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + M^{-1}\mathbf{r}^{(k)}, \mathbf{r}^{(k)} = \mathbf{b} - A\mathbf{x}^{(k)}. \quad (14.4)$$

设精确解为  $\mathbf{x}^* = A^{-1}\mathbf{b}$ , 并定义误差

$$\mathbf{e}^{(k)} = \mathbf{x}^* - \mathbf{x}^{(k)}. \quad (14.5)$$

由相容性  $\mathbf{x}^* = T\mathbf{x}^* + \mathbf{c}$  得到

$$\mathbf{e}^{(k+1)} = T\mathbf{e}^{(k)}, \mathbf{e}^{(k)} = T^k\mathbf{e}^{(0)}. \quad (14.6)$$

残差传播矩阵一般不是  $T$ :

$$\begin{aligned} \mathbf{r}^{(k+1)} &= \mathbf{b} - A[\mathbf{x}^{(k)} + M^{-1}\mathbf{r}^{(k)}] \\ &= (I - AM^{-1})\mathbf{r}^{(k)}. \end{aligned} \quad (14.7)$$

#### 易错点与反例

误差传播矩阵为  $T = M^{-1}N = I - M^{-1}A$ , 而残差传播矩阵为  $I - AM^{-1}$ 。两者相似:  $I - AM^{-1} = M(I - M^{-1}A)M^{-1}$ , 故具有相同特征值, 但一般并不相等。

### 14.1.2 知识点二：谱半径收敛判据

定理 14.1 (定常迭代收敛的充要条件). 迭代  $\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)} + \mathbf{c}$  对任意初值  $\mathbf{x}^{(0)}$  均收敛到唯一固定点, 当且仅当

$$\boxed{\rho(T) < 1}. \quad (14.8)$$

证明. 若  $\rho(T) < 1$ , 则由矩阵幂趋零判据  $T^k \rightarrow 0$ . 故  $\mathbf{e}^{(k)} = T^k \mathbf{e}^{(0)} \rightarrow \mathbf{0}$ .

反之, 若对任意初值均收敛, 则对任意  $\mathbf{e}^{(0)}$ ,  $T^k \mathbf{e}^{(0)} \rightarrow 0$ . 因此  $T^k \rightarrow 0$ . 由 Gelfand 公式  $\rho(T) = \lim_{k \rightarrow \infty} \|T^k\|^{1/k} < 1$ .  $\square$

若存在某个从属矩阵范数使  $\|T\| = q < 1$ , 则有先验估计

$$\boxed{\|\mathbf{e}^{(k)}\| \leq q^k \|\mathbf{e}^{(0)}\|}. \quad (14.9)$$

令  $\mathbf{d}^{(k)} = \mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}$ ,  $k \geq 1$ . 有  $\mathbf{d}^{(k+1)} = T\mathbf{d}^{(k)}$ . 于是

$$\begin{aligned} \|\mathbf{x}^* - \mathbf{x}^{(k)}\| &\leq \sum_{j=k}^{\infty} \|\mathbf{x}^{(j+1)} - \mathbf{x}^{(j)}\| \\ &\leq \frac{q}{1-q} \|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|, \end{aligned} \quad (14.10)$$

或等价地

$$\|\mathbf{x}^* - \mathbf{x}^{(k)}\| \leq \frac{1}{1-q} \|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|. \quad (14.11)$$

若使用真实残差, 则

$$\boxed{\|\mathbf{x}^* - \mathbf{x}^{(k)}\| \leq \|A^{-1}\| \|\mathbf{r}^{(k)}\|}. \quad (14.12)$$

---

#### Algorithm 59 一般定常线性迭代

---

**Input:** 线性系统  $A\mathbf{x} = \mathbf{b}$ ; 分裂  $A = M - N$ ; 初值  $\mathbf{x}^{(0)}$ ; 绝对容差 atol; 相对容差 rtol; 最大迭代次数  $K_{\max}$


**Output:** 近似解  $\mathbf{x}^{(k)}$

- 1: **for**  $k = 0, 1, \dots, K_{\max} - 1$  **do**
  - 2:      $\mathbf{r}^{(k)} \leftarrow \mathbf{b} - A\mathbf{x}^{(k)}$
  - 3:     **if**  $\|\mathbf{r}^{(k)}\| \leq \text{atol} + \text{rtol} \|\mathbf{b}\|$  **then**
  - 4:         **return**  $\mathbf{x}^{(k)}$
  - 5:     **end if**
  - 6:     解  $M\mathbf{z}^{(k)} = \mathbf{r}^{(k)}$
  - 7:      $\mathbf{x}^{(k+1)} \leftarrow \mathbf{x}^{(k)} + \mathbf{z}^{(k)}$
  - 8: **end for**
  - 9: 报告“未达到容差”
  - 10: **Stopping criterion:** 优先使用真实残差或范数型后向误差, 不能只使用相邻迭代差
  - 11: **Complexity:** 每步成本为一次残差计算和一次  $M$  求解; 若  $A, M$  稀疏, 通常为  $O(\text{nnz}(A) + \text{cost}(M^{-1}))$
- 

### 14.1.3 知识点三：Richardson 迭代

Richardson 迭代为

$$\boxed{\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \omega (\mathbf{b} - A\mathbf{x}^{(k)})}. \quad (14.13)$$



迭代矩阵为

$$T_\omega = I - \omega A. \quad (14.14)$$

若  $A$  的全部特征值均为正实数，并按  $0 < \lambda_1 \leq \cdots \leq \lambda_n$  排列，则  $\rho(T_\omega) = \max_i |1 - \omega \lambda_i|$ 。

定理 14.2 (Richardson 收敛与最优参数). 在上述假设下:

1. Richardson 迭代收敛, 当且仅当

$$0 < \omega < \frac{2}{\lambda_n}; \quad (14.15)$$

2. 最优阻尼参数为

$$\omega_{\text{opt}} = \frac{2}{\lambda_1 + \lambda_n}; \quad (14.16)$$

3. 最优谱半径为

$$\rho(T_{\omega_{\text{opt}}}) = \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}. \quad (14.17)$$

证明. 收敛条件为  $|1 - \omega \lambda_i| < 1 \quad \forall i$ , 即  $0 < \omega \lambda_i < 2$ . 最严格条件来自  $\lambda_n$ , 故得到 式 (14.15)。

对  $\omega > 0$ ,  $\rho(T_\omega) = \max \{|1 - \omega \lambda_1|, |1 - \omega \lambda_n|\}$ . 最优点要求两个端点误差等振荡:  $1 - \omega \lambda_1 = -(1 - \omega \lambda_n)$ . 解得  $\omega_{\text{opt}} = \frac{2}{\lambda_1 + \lambda_n}$ . 代入即得 式 (14.17).  $\square$

谱半径的分段表达为

$$\rho(T_\omega) = \begin{cases} 1 - \omega \lambda_1, & 0 < \omega \leq \omega_{\text{opt}}, \\ \omega \lambda_n - 1, & \omega_{\text{opt}} \leq \omega < 2/\lambda_n. \end{cases} \quad (14.18)$$

若  $A = A^H \succ 0$ , 则  $\kappa_2(A) = \frac{\lambda_n}{\lambda_1}$ , 故

$$\rho(T_{\omega_{\text{opt}}}) = \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1}. \quad (14.19)$$

#### 易错点与反例

若  $A$  非正规, 即使  $\rho(I - \omega A) < 1$ , 有限步矩阵范数  $\|(I - \omega A)^k\|$  仍可能先增大后衰减。谱半径控制渐近收敛, 不自动排除非正规暂态增长。

## 14.2 补充训练题: 一般分裂、有限步收敛与块 Jacobi/块 Gauss-Seidel

完整题目叙述: [NLA-Set-2017-Q4]

设  $A, B \in \mathbb{R}^{n \times n}$ ,  $\det A \neq 0$ ,  $\mathbf{b} \in \mathbb{R}^n$ .

(a) 对迭代

$$A\mathbf{x}^{(k+1)} = \mathbf{b} - B\mathbf{x}^{(k)}, \quad (14.20)$$

给出并证明其收敛的充要条件;

(b) 若  $\rho(A^{-1}B) = 0$ , 证明该迭代至多  $n$  步达到精确解;



(c) 设  $M = M^T \succ 0$ ,  $\omega_1 > 1$ ,  $\omega_2, \dots, \omega_s > 0$ , 考虑

$$\mathbf{x}^{(k+1)} = \omega_1 \mathbf{x}^{(k)} + \sum_{j=2}^s \omega_j (\mathbf{c}_{j-1} - M \mathbf{x}^{(k)}). \quad (14.21)$$

证明其收敛当且仅当  $M$  的所有特征值满足

$$\frac{\omega_1 - 1}{s} < \lambda(M) < \frac{\omega_1 + 1}{s}; \quad (14.22)$$

$$\sum_{j=2}^s \omega_j$$

(d) 设  $A$  非奇异。比较以下两种二分量块迭代：

同步格式

$$\begin{cases} A\mathbf{x}_1^{(k+1)} = \mathbf{b}_1 - B\mathbf{x}_2^{(k)}, \\ A\mathbf{x}_2^{(k+1)} = \mathbf{b}_2 - B\mathbf{x}_1^{(k)}, \end{cases} \quad (14.23)$$

以及顺序格式

$$\begin{cases} A\mathbf{x}_1^{(k+1)} = \mathbf{b}_1 - B\mathbf{x}_2^{(k)}, \\ A\mathbf{x}_2^{(k+1)} = \mathbf{b}_2 - B\mathbf{x}_1^{(k+1)}. \end{cases} \quad (14.24)$$

分别求收敛充要条件，并比较渐近收敛因子。

第 (a) 问. 令  $C = A^{-1}B$ . 迭代可写为  $\mathbf{x}^{(k+1)} = -C\mathbf{x}^{(k)} + A^{-1}\mathbf{b}$ . 迭代矩阵为  $T = -C$ . 因此由谱半径判据,

$$\boxed{\text{迭代收敛} \iff \rho(A^{-1}B) < 1}. \quad (14.25)$$

□

第 (b) 问. 若  $\rho(C) = 0$ , 则  $C$  的全部特征值均为零。其特征多项式为  $\chi_C(z) = z^n$ . 由 Cayley-Hamilton 定理,  $C^n = 0$ . 误差满足  $\mathbf{e}^{(k)} = (-C)^k \mathbf{e}^{(0)}$ . 故  $\mathbf{e}^{(n)} = (-1)^n C^n \mathbf{e}^{(0)} = \mathbf{0}$ . 因此至多  $n$  步后得到精确解。 □

第 (c) 问. 令  $s_\omega = \sum_{j=2}^s \omega_j > 0$ ,  $\mathbf{d} = \sum_{j=2}^s \omega_j \mathbf{c}_{j-1}$ . 则  $\mathbf{x}^{(k+1)} = (\omega_1 I - s_\omega M) \mathbf{x}^{(k)} + \mathbf{d}$ . 由于  $M$  对称正定, 迭代矩阵特征值为  $\omega_1 - s_\omega \lambda_i(M)$ . 收敛当且仅当  $|\omega_1 - s_\omega \lambda_i| < 1 \quad \forall i$ . 即  $-1 < \omega_1 - s_\omega \lambda_i < 1$ . 整理得到式 (14.22). □


第 (d) 问: 同步格式. 记  $C = A^{-1}B$ . 设精确解为  $(\mathbf{x}_1^*, \mathbf{x}_2^*)$ , 并定义误差  $\mathbf{e}_i^{(k)} = \mathbf{x}_i^* - \mathbf{x}_i^{(k)}$ . 同步格式满足

$$\begin{pmatrix} \mathbf{e}_1^{(k+1)} \\ \mathbf{e}_2^{(k+1)} \end{pmatrix} = \underbrace{\begin{pmatrix} 0 & -C \\ -C & 0 \end{pmatrix}}_{T_{\text{BJ}}} \begin{pmatrix} \mathbf{e}_1^{(k)} \\ \mathbf{e}_2^{(k)} \end{pmatrix}. \quad (14.26)$$

若  $C\mathbf{v} = \lambda\mathbf{v}$ , 则  $\begin{pmatrix} \mathbf{v} \\ \mathbf{v} \end{pmatrix}$ ,  $\begin{pmatrix} \mathbf{v} \\ -\mathbf{v} \end{pmatrix}$  分别是  $T_{\text{BJ}}$  对应特征值  $-\lambda$  和  $\lambda$  的特征向量。故  $\rho(T_{\text{BJ}}) = \rho(C)$ . 因此

$$\boxed{\text{同步格式收敛} \iff \rho(A^{-1}B) < 1}. \quad (14.27)$$

□



第 (d) 问：顺序格式. 有

$$\mathbf{e}_1^{(k+1)} = -C\mathbf{e}_2^{(k)}, \quad (14.28)$$

$$\mathbf{e}_2^{(k+1)} = -C\mathbf{e}_1^{(k+1)} = C^2\mathbf{e}_2^{(k)}. \quad (14.29)$$

因此

$$\begin{pmatrix} \mathbf{e}_1^{(k+1)} \\ \mathbf{e}_2^{(k+1)} \end{pmatrix} = \underbrace{\begin{pmatrix} 0 & -C \\ 0 & C^2 \end{pmatrix}}_{T_{\text{BGS}}} \begin{pmatrix} \mathbf{e}_1^{(k)} \\ \mathbf{e}_2^{(k)} \end{pmatrix}. \quad (14.30)$$

该块上三角矩阵的谱为  $\sigma(T_{\text{BGS}}) = \{0\} \cup \sigma(C^2)$ 。故  $\rho(T_{\text{BGS}}) = \rho(C)^2$ 。因此

$$\boxed{\text{顺序格式收敛} \iff \rho(A^{-1}B) < 1}. \quad (14.31)$$

在收敛条件下,  $\rho(T_{\text{BGS}}) = \rho(T_{\text{BJ}})^2$ , 故顺序格式的渐近收敛因子为同步格式的平方。□

## 14.3 Jacobi、Gauss-Seidel 与 SOR

### 14.3.1 知识点四：统一符号与算法公式

采用本讲义统一分裂

$$\boxed{A = D - L - U}, \quad (14.32)$$

其中：

- $D = \text{diag}(a_{11}, \dots, a_{nn})$ ;
- $-L$  为  $A$  的严格下三角部分;
- $-U$  为  $A$  的严格上三角部分。

因此  $L_{ij} = -a_{ij}$ ,  $i > j$ ,  $U_{ij} = -a_{ij}$ ,  $i < j$ 。

**Jacobi 迭代**

$$D\mathbf{x}^{(k+1)} = (L + U)\mathbf{x}^{(k)} + \mathbf{b}, \quad (14.33)$$

即

$$\boxed{\mathbf{x}^{(k+1)} = T_J\mathbf{x}^{(k)} + D^{-1}\mathbf{b}, \quad T_J = D^{-1}(L + U) = I - D^{-1}A}. \quad (14.34)$$

分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij}x_j^{(k)} \right). \quad (14.35)$$

**Gauss-Seidel 迭代**


$$(D - L)\mathbf{x}^{(k+1)} = U\mathbf{x}^{(k)} + \mathbf{b}, \quad (14.36)$$

即

$$\boxed{T_{\text{GS}} = (D - L)^{-1}U}. \quad (14.37)$$

分量形式为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right]. \quad (14.38)$$



SOR 迭代 对实参数  $\omega$ ,

$$(D - \omega L)\mathbf{x}^{(k+1)} = [(1 - \omega)D + \omega U]\mathbf{x}^{(k)} + \omega \mathbf{b}. \quad (14.39)$$

迭代矩阵为

$$T_\omega = (D - \omega L)^{-1} [(1 - \omega)D + \omega U]. \quad (14.40)$$

分量形式为

$$\begin{aligned} x_i^{(k+1)} &= (1 - \omega)x_i^{(k)} \\ &+ \frac{\omega}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right]. \end{aligned} \quad (14.41)$$

特殊情形:

$$\omega = 1 \implies \text{Gauss-Seidel}, \quad (14.42)$$

$$0 < \omega < 1 \implies \text{欠松弛}, \quad (14.43)$$

$$1 < \omega < 2 \implies \text{超松弛}. \quad (14.44)$$

---

#### Algorithm 60 Jacobi、Gauss-Seidel 与 SOR 的一次扫描

---

**Input:**  $A = (a_{ij})$ ,  $a_{ii} \neq 0$ ;  $\mathbf{b}$ ; 旧迭代  $\mathbf{x}^{(k)}$ ; 方法类型; SOR 参数  $\omega$

**Output:** 新迭代  $\mathbf{x}^{(k+1)}$

1: **if** Jacobi **then**

2:     **for**  $i = 1, \dots, n$  **do**

3:          $x_i^{(k+1)} \leftarrow \frac{b_i - \sum_{j \neq i} a_{ij}x_j^{(k)}}{a_{ii}}$

4:     **end for**

5: **else if** Gauss-Seidel 或 SOR **then**

6:     **for**  $i = 1, \dots, n$  **do**

7:          $\hat{x}_i \leftarrow \frac{1}{a_{ii}} \left[ b_i - \sum_{j < i} a_{ij}x_j^{(k+1)} - \sum_{j > i} a_{ij}x_j^{(k)} \right]$

8:          $x_i^{(k+1)} \leftarrow \begin{cases} \hat{x}_i, & \text{Gauss-Seidel,} \\ (1 - \omega)x_i^{(k)} + \omega\hat{x}_i, & \text{SOR} \end{cases}$

9:     **end for**

10: **end if**

11: **Stopping criterion:** 完成一轮全部分量更新

12: **Complexity:** 稀疏矩阵每轮  $O(\text{nnz}(A))$ ; Jacobi 天然并行; 标准 Gauss-Seidel 和 SOR 具有数据依赖, 需着色、块分解或多色方法实现并行

---

#### 14.3.2 知识点五: 严格对角占优情形

定义 14.3 (严格行对角占优). 若

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad i = 1, \dots, n, \quad (14.45)$$

则称  $A$  严格按行对角占优。

定理 14.4 (Levy-Desplanques 定理). 严格行对角占优矩阵必非奇异。



证明. 若  $Ax = 0$  且  $x \neq 0$ , 取  $i$  使  $|x_i| = \|x\|_\infty$ . 则

$$|a_{ii}||x_i| = \left| \sum_{j \neq i} a_{ij}x_j \right| \leq \sum_{j \neq i} |a_{ij}||x_j| \leq \left( \sum_{j \neq i} |a_{ij}| \right) |x_i| < |a_{ii}||x_i|, \quad (14.46)$$

矛盾。  $\square$

**定理 14.5** (严格对角占优下 Jacobi 和 Gauss-Seidel 收敛). 若  $A$  严格按行对角占优, 则 *Jacobi* 和 *Gauss-Seidel* 均对任意初值收敛。

*Jacobi*. 由  $T_J = -D^{-1}(A - D)$  可得  $\|T_J\|_\infty = \max_i \frac{\sum_{j \neq i} |a_{ij}|}{|a_{ii}|} < 1$ . 因此  $\rho(T_J) \leq \|T_J\|_\infty < 1$ .  $\square$

*Gauss-Seidel*. 设  $T_{GS}z = \lambda z$ ,  $z \neq 0$ . 则  $Uz = \lambda(D - L)z$ . 取  $i$  满足  $|z_i| = \|z\|_\infty$ . 第  $i$  个分量给出  $-\sum_{j>i} a_{ij}z_j = \lambda \left( a_{ii}z_i + \sum_{j<i} a_{ij}z_j \right)$ . 若  $|\lambda| \geq 1$ , 则

$$\begin{aligned} \sum_{j>i} |a_{ij}||z_j| &\geq |\lambda| \left[ |a_{ii}||z_i| - \sum_{j<i} |a_{ij}||z_j| \right] \\ &\geq \left[ |a_{ii}| - \sum_{j<i} |a_{ij}| \right] |z_i|. \end{aligned} \quad (14.47)$$

另一方面,  $\sum_{j>i} |a_{ij}||z_j| \leq \left( \sum_{j>i} |a_{ij}| \right) |z_i|$ . 故  $|a_{ii}| \leq \sum_{j \neq i} |a_{ij}|$ , 与严格对角占优矛盾. 所以  $|\lambda| < 1$ .  $\square$

### 14.3.3 知识点六: 对称正定情形

**定理 14.6** (对称矩阵 Jacobi 收敛的精确判据). 设  $A = A^T$ ,  $a_{ii} > 0$ ,  $D = \text{diag}(A)$ . 则 *Jacobi* 迭代收敛, 当且仅当

$$\boxed{A \succ 0 \quad \text{且} \quad 2D - A \succ 0}. \quad (14.48)$$

证明. Jacobi 矩阵  $T_J = I - D^{-1}A$  与对称矩阵

$$\tilde{T}_J = I - D^{-1/2}AD^{-1/2} \quad (14.49)$$

相似。

设  $H = D^{-1/2}AD^{-1/2}$ . Jacobi 收敛等价于  $|1 - \lambda_i(H)| < 1 \quad \forall i$ , 即  $0 < \lambda_i(H) < 2$ . 前半部分等价于  $H \succ 0 \iff A \succ 0$ ; 后半部分等价于  $2I - H \succ 0 \iff 2D - A \succ 0$ .  $\square$

**反例 14.7** (SPD 不自动保证 Jacobi 收敛). 令  $A = \begin{pmatrix} 1 & 0.6 & 0.6 \\ 0.6 & 1 & 0.6 \\ 0.6 & 0.6 & 1 \end{pmatrix}$ . 其特征值为 2.2, 0.4, 0.4, 故  $A \succ 0$ .

但  $T_J = I - A = \begin{pmatrix} 0 & -0.6 & -0.6 \\ -0.6 & 0 & -0.6 \\ -0.6 & -0.6 & 0 \end{pmatrix}$  具有特征值 -1.2, 0.6, 0.6. 因此  $\rho(T_J) = 1.2 > 1$ , Jacobi 发散。

**定理 14.8** (SPD 矩阵的 Gauss-Seidel 收敛性). 若  $A = A^H \succ 0$ , 则 *Gauss-Seidel* 迭代收敛。

证明. 在分裂  $A = D - L - U$  中, 由 Hermitian 性有  $U = L^H$ 。设  $T_{GS}z = \lambda z$ 。则  $Uz = \lambda(D - L)z$ 。记

$$d = z^H D z > 0, \quad (14.50)$$

$$s = z^H L z. \quad (14.51)$$

左乘  $z^H$  得到

$$\bar{s} = \lambda(d - s). \quad (14.52)$$

故  $|\lambda| = \frac{|s|}{|d-s|}$ 。另一方面,

$$\begin{aligned} |d - s|^2 - |s|^2 &= d^2 - d(s + \bar{s}) \\ &= d(d - s - \bar{s}) \\ &= d z^H A z > 0. \end{aligned} \quad (14.53)$$

因此  $|d - s| > |s|$ , 从而  $|\lambda| < 1$ 。□

#### 14.3.4 知识点七: SOR 的必要与充分条件

定理 14.9 (SOR 收敛的必要条件). 若  $A$  对角元均非零, 且 SOR 迭代收敛, 则

$$0 < \omega < 2. \quad (14.54)$$

证明. 由于  $D - \omega L$  为下三角矩阵,  $\det(D - \omega L) = \det D$ 。而  $(1 - \omega)D + \omega U$  为上三角矩阵, 故  $\det[(1 - \omega)D + \omega U] = (1 - \omega)^n \det D$ 。所以

$$\det T_\omega = (1 - \omega)^n. \quad (14.55)$$

若 SOR 收敛,  $\rho(T_\omega) < 1$ 。于是  $|1 - \omega|^n = |\det T_\omega| \leq \rho(T_\omega)^n < 1$ 。故  $|1 - \omega| < 1$ , 即  $0 < \omega < 2$ 。□

定理 14.10 (Ostrowski 定理: SPD 矩阵的 SOR). 若  $A = A^H \succ 0$ , 则 SOR 迭代收敛, 当且仅当

$$0 < \omega < 2. \quad (14.56)$$

证明. 必要性由 定义 14.9 得到。

证明充分性. 设  $T_\omega z = \lambda z$ 。则  $[(1 - \omega)D + \omega U]z = \lambda(D - \omega L)z$ 。记  $d = z^H D z > 0$ ,  $s = z^H L z$ 。左乘  $z^H$  得

$$(1 - \omega)d + \omega \bar{s} = \lambda(d - \omega s). \quad (14.57)$$

故  $|\lambda| = \frac{|(1 - \omega)d + \omega \bar{s}|}{|d - \omega s|}$ 。直接计算

$$\begin{aligned} |d - \omega s|^2 - |(1 - \omega)d + \omega \bar{s}|^2 &= \omega(2 - \omega)d(d - s - \bar{s}) \\ &= \omega(2 - \omega)d z^H A z. \end{aligned} \quad (14.58)$$

当  $0 < \omega < 2$  时, 右端严格为正。故  $|\lambda| < 1$ 。□

注 14.11 (最优 SOR 参数的适用条件). 对一般矩阵, 不能只由  $\rho(T_J)$  无条件写出最优 SOR 参数。



若  $A$  满足 Young 一致排序条件, 例如典型的三对角或适当块三对角离散矩阵, 并且  $\rho(T_J) < 1$ , 则

$$\omega_{\text{opt}} = \frac{2}{1 + \sqrt{1 - \rho(T_J)^2}}, \quad (14.59)$$

$$\begin{aligned} \rho(T_{\omega_{\text{opt}}}) &= \omega_{\text{opt}} - 1 \\ &= \frac{1 - \sqrt{1 - \rho(T_J)^2}}{1 + \sqrt{1 - \rho(T_J)^2}}. \end{aligned} \quad (14.60)$$

这些公式不是任意稀疏矩阵的无条件结论。

#### 一维 Poisson 矩阵的最优 SOR 参数

令  $A_n = \text{tridiag}(-1, 2, -1)$ 。Jacobi 迭代矩阵的特征值为  $\mu_j = \cos\left(\frac{j\pi}{n+1}\right)$ ,  $j = 1, \dots, n$ 。故  $\rho(T_J) = \cos\left(\frac{\pi}{n+1}\right)$ 。因此

$$\omega_{\text{opt}} = \frac{2}{1 + \sin\left(\frac{\pi}{n+1}\right)}. \quad (14.61)$$

当  $n$  大时,  $\omega_{\text{opt}} = 2 - \frac{2\pi}{n+1} + O(n^{-2})$ 。

## 14.4 正式真题 [24S-Q2]——Gauss-Seidel 收敛性

### 完整题目叙述: [24S-Q2]

考虑用 Gauss-Seidel 迭代求解  $A\mathbf{x} = \mathbf{b}$ ,  $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ ,  $a_{ii} \neq 0$ 。分量迭代为

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right]. \quad (14.62)$$

令  $A = D - L - U$ , 其中  $D, -L, -U$  分别为  $A$  的对角、严格下三角、严格上三角部分。

1. 证明

$$\mathbf{x}^{(k+1)} = (D - L)^{-1} U \mathbf{x}^{(k)} + (D - L)^{-1} \mathbf{b}; \quad (14.63)$$

2. 若  $A$  严格按行对角占优, 证明  $A$  非奇异且 Gauss-Seidel 对任意初值收敛;

3. 若  $A$  对称正定, 证明  $A$  非奇异且 Gauss-Seidel 对任意初值收敛。

第 (1) 问. 第  $i$  个分量方程式 (14.62) 等价于  $a_{ii} x_i^{(k+1)} + \sum_{j < i} a_{ij} x_j^{(k+1)} = b_i - \sum_{j > i} a_{ij} x_j^{(k)}$ 。左端正是  $[(D - L)\mathbf{x}^{(k+1)}]_i$ , 右端正是  $[U\mathbf{x}^{(k)} + \mathbf{b}]_i$ 。因此  $(D - L)\mathbf{x}^{(k+1)} = U\mathbf{x}^{(k)} + \mathbf{b}$ 。由于  $a_{ii} \neq 0$ ,  $D - L$  为非奇异下三角矩阵。故  $\mathbf{x}^{(k+1)} = (D - L)^{-1} U \mathbf{x}^{(k)} + (D - L)^{-1} \mathbf{b}$ 。□

第 (2) 问: 非奇异性. 若  $A\mathbf{x} = \mathbf{0}$  且  $\mathbf{x} \neq \mathbf{0}$ , 取  $i$  使  $|x_i| = \|\mathbf{x}\|_\infty$ 。则  $|a_{ii}||x_i| \leq \sum_{j \neq i} |a_{ij}||x_j| \leq \left(\sum_{j \neq i} |a_{ij}|\right)|x_i|$ , 与严格对角占优矛盾。故  $A$  非奇异。□

第 (2) 问: Gauss-Seidel 收敛. 迭代矩阵为  $T_{GS} = (D - L)^{-1} U$ 。设  $T_{GS}\mathbf{z} = \lambda\mathbf{z}$ 。若  $|\lambda| \geq 1$ , 取  $i$  使

$|z_i| = \|z\|_\infty$ 。由  $Uz = \lambda(D - L)z$  的第  $i$  行， $-\sum_{j>i} a_{ij}z_j = \lambda\left(a_{ii}z_i + \sum_{j<i} a_{ij}z_j\right)$ 。于是

$$\begin{aligned}\sum_{j>i} |a_{ij}||z_i| &\geq \sum_{j>i} |a_{ij}||z_j| \\ &\geq |\lambda| \left[ |a_{ii}||z_i| - \sum_{j<i} |a_{ij}||z_j| \right] \\ &\geq \left[ |a_{ii}| - \sum_{j<i} |a_{ij}| \right] |z_i|. \end{aligned} \quad (14.64)$$

从而  $|a_{ii}| \leq \sum_{j \neq i} |a_{ij}|$ ，矛盾。故  $\rho(T_{GS}) < 1$ 。  $\square$

第 (3) 问.  $A = A^T \succ 0$  立即蕴含  $A$  非奇异。

令  $U = L^T$ 。若  $T_{GS}z = \lambda z$ ，则  $Uz = \lambda(D - L)z$ 。记  $d = z^T D z > 0$ ， $s = z^T L z$ 。有  $s = \lambda(d - s)$  在实数情形应更准确写为  $z^T U z = \bar{s} = \lambda(d - s)$ ；由于此处矩阵和向量可复化分析，沿用共轭形式。

于是  $|\lambda| = \frac{|s|}{|d-s|}$ 。又  $|d-s|^2 - |s|^2 = dz^H A z > 0$ 。故  $|\lambda| < 1$ 。因此  $\rho(T_{GS}) < 1$ 。  $\square$

#### 易错点与反例

1. 不能把  $A = D + L + U$  与  $A = D - L - U$  的符号静默混用；
2. 严格对角占优是充分条件，不是 Gauss-Seidel 收敛的必要条件；
3. SPD 情形不能用  $\|T_{GS}\|_2 < 1$  作为未经证明的结论；
4. Jacobi 对 SPD 矩阵不一定收敛，不能把 Gauss-Seidel 结论照搬给 Jacobi。

## 14.5 补充训练题：丘赛 2022 Problem 3——严格对角占优矩阵的范数与谱界

完整题目叙述：[Yau-2022-Problem-3]

设  $A = (a_{ij}) \in \mathbb{R}^{m \times m}$  满足


$$a_{ii} \geq \sum_{j \neq i} |a_{ij}| + 2, \quad a_{ii} \leq 7. \quad (14.65)$$

- (a) 证明  $A^{-1}$  存在；
- (b) 证明  $\|A\|_\infty$  等于绝对行和的最大值；
- (c) 求  $\|A\|_\infty$  的上下界；
- (d) 若进一步  $A = A^T$ ，求  $\|A\|_2$  和  $\|A^{-1}\|_2$  的上下界。

第 (a) 问. 由  $a_{ii} \geq \sum_{j \neq i} |a_{ij}| + 2 > \sum_{j \neq i} |a_{ij}|$ ， $A$  严格按行对角占优。由 Levy-Desplanques 定理， $\det A \neq 0$ 。  $\square$

第 (b) 问. 对任意  $x$ ，

$$\begin{aligned}\|Ax\|_\infty &= \max_i \left| \sum_j a_{ij}x_j \right| \\ &\leq \max_i \sum_j |a_{ij}| \|x\|_\infty. \end{aligned} \quad (14.66)$$





故  $\|A\|_\infty \leq \max_i \sum_j |a_{ij}|$ 。

取  $i_*$  使绝对行和最大, 并令  $x_j = \begin{cases} \text{sign}(a_{i_*j}), & a_{i_*j} \neq 0, \\ 1, & a_{i_*j} = 0. \end{cases}$  则  $\|x\|_\infty = 1$  且  $(Ax)_{i_*} = \sum_j |a_{i_*j}|$ 。

因此

$$\|A\|_\infty = \max_i \sum_j |a_{ij}|. \quad (14.67)$$

□

第 (c) 问. 由假设  $a_{ii} \geq 2$ , 所以  $\|A\|_\infty \geq \max_i a_{ii} \geq 2$ 。又  $\sum_{j \neq i} |a_{ij}| \leq a_{ii} - 2$ 。故  $\sum_j |a_{ij}| = a_{ii} + \sum_{j \neq i} |a_{ij}| \leq 2a_{ii} - 2 \leq 12$ 。因此

$$2 \leq \|A\|_\infty \leq 12. \quad (14.68)$$

□

第 (d) 问. 当  $A = A^\top$  时, 由 Gershgorin 定理, 每个特征值  $\lambda$  满足  $\lambda \geq \min_i \left[ a_{ii} - \sum_{j \neq i} |a_{ij}| \right] \geq 2$ 。故  $A \succ 0$ ,  $\lambda_{\min}(A) \geq 2$ 。同理  $\lambda_{\max}(A) \leq \max_i \left[ a_{ii} + \sum_{j \neq i} |a_{ij}| \right] \leq 12$ 。另一方面,  $\lambda_{\max}(A) \geq \mathbf{e}_i^\top A \mathbf{e}_i = a_{ii} \geq 2$  对每个  $i$  成立。所以

$$2 \leq \|A\|_2 = \lambda_{\max}(A) \leq 12. \quad (14.69)$$

由于  $\|A^{-1}\|_2 = \frac{1}{\lambda_{\min}(A)}$ , 由  $\lambda_{\min} \geq 2$  得  $\|A^{-1}\|_2 \leq \frac{1}{2}$ 。又  $\lambda_{\min}(A) \leq \frac{\text{tr} A}{m} \leq 7$ , 故  $\|A^{-1}\|_2 \geq \frac{1}{7}$ 。因此

$$\frac{1}{7} \leq \|A^{-1}\|_2 \leq \frac{1}{2}. \quad (14.70)$$

相应地,  $\kappa_2(A) \leq \frac{12}{2} = 6$ 。

□

## 14.6 补充训练题: 分量松弛与题目有误?

[NLA-Set-2012-Team-Q3]

设  $A = (a_{ij}) \in \mathbb{C}^{N \times N}$  严格按行对角占优, 并在对角缩放后写为

$$A = I + L + U, \quad (14.71)$$

其中  $L, U$  分别为严格下、上三角部分。

令  $\Omega = \text{diag}(\omega_1, \dots, \omega_N)$ ,  $0 \leq \omega_i \leq 1$ 。扫描题给出的迭代矩阵为

$$M = (I + \alpha \Omega L)^{-1} [(I - \Omega) - (1 - \alpha) \Omega L - \Omega U]. \quad (14.72)$$

题目要求:

1. 证明  $Ax = b$  有唯一解;
2. 证明迭代收敛的必要条件为  $\prod_{i=1}^N |1 - \omega_i| < 1$ ;
3. 令

$$l_i = \sum_{j < i} |a_{ij}|, \quad (14.73)$$

$$u_i = \sum_{j > i} |a_{ij}|. \quad (14.74)$$

证明在  $|\omega_i|\alpha l_i < 1$  下,

$$\rho(M) \leq \max_i \frac{|1 - \omega_i| + |\omega_i|[(1 - \alpha)l_i + u_i]}{1 - |\omega_i|\alpha l_i}; \quad (14.75)$$

4. 证明充分条件

$$0 < \omega_i < \frac{2}{1 + l_i + u_i} \quad (14.76)$$

可保证收敛。

第 (1) 问. 由  $1 = |a_{ii}| > l_i + u_i$ ,  $A$  严格对角占优. 故  $A$  非奇异, 线性方程有唯一解.  $\square$

第 (2) 问:  $\alpha = 1$  时的正确结论. 当  $\alpha = 1$  时,  $M = (I + \Omega L)^{-1}[(I - \Omega) - \Omega U]$ . 前一因子分母矩阵为单位下三角, 行列式为 1; 后一矩阵为上三角, 主对角元为  $1 - \omega_i$ . 因此

$$\det M = \prod_{i=1}^N (1 - \omega_i). \quad (14.77)$$

若迭代收敛,  $\rho(M) < 1$ . 故  $|\det M| = \prod_i |\lambda_i(M)| \leq \rho(M)^N < 1$ . 于是  $\prod_i |1 - \omega_i| < 1$ .  $\square$

反例 14.12 (一般  $\alpha < 1$  时第 (2) 问不成立). 取  $A = \begin{pmatrix} 1 & -\frac{9}{10} \\ -\frac{9}{10} & 1 \end{pmatrix}$ ,  $\Omega = \text{diag}(\frac{3}{2}, \frac{7}{2})$ ,  $\alpha = \frac{3}{4}$ .  $A$  严格对角占优.

代入式 (14.72) 得到

$$M = \begin{pmatrix} -\frac{1}{2} & \frac{27}{20} \\ -\frac{63}{160} & \frac{1103}{1600} \end{pmatrix}. \quad (14.78)$$

其行列式为  $\det M = \frac{299}{1600}$ , 两个特征值为共轭复数, 故  $\rho(M) = \sqrt{\frac{299}{1600}} = \frac{\sqrt{299}}{40} < 1$ . 迭代收敛.

但  $\prod_{i=1}^2 |1 - \omega_i| = |1 - \frac{3}{2}| |1 - \frac{7}{2}| = \frac{5}{4} > 1$ . 因此扫描题第 (2) 问对一般  $\alpha < 1$  是错误的.

第 (3) 问. 设  $Mx = \lambda x$ ,  $x \neq 0$ . 则

$$\begin{aligned} & [(I - \Omega) - (1 - \alpha)\Omega L - \Omega U]x \\ &= \lambda(I + \alpha\Omega L)x. \end{aligned} \quad (14.79)$$

取  $i$  使  $|x_i| = \|x\|_\infty$ . 第  $i$  行给出

$$\lambda x_i = (1 - \omega_i)x_i - \omega_i[1 - \alpha + \alpha\lambda] \sum_{j < i} a_{ij}x_j - \omega_i \sum_{j > i} a_{ij}x_j. \quad (14.80)$$

取模并使用  $|1 - \alpha + \alpha\lambda| \leq 1 - \alpha + \alpha|\lambda|$  得到

$$|\lambda| \leq |1 - \omega_i| + |\omega_i|[(1 - \alpha)l_i + u_i] + |\omega_i|\alpha l_i |\lambda|. \quad (14.81)$$

若  $|\omega_i|\alpha l_i < 1$ , 则  $|\lambda| \leq \frac{|1 - \omega_i| + |\omega_i|[(1 - \alpha)l_i + u_i]}{1 - |\omega_i|\alpha l_i}$ . 对所有特征值取最大即得式 (14.75).  $\square$

第 (4) 问. 令  $s_i = l_i + u_i < 1$ . 要使式 (14.75) 右端小于 1, 只需证明

$$|1 - \omega_i| + \omega_i s_i < 1. \quad (14.82)$$

若  $0 < \omega_i \leq 1$ , 则  $|1 - \omega_i| + \omega_i s_i = 1 - \omega_i(1 - s_i) < 1$ . 若  $1 < \omega_i < 2/(1 + s_i)$ , 则  $|1 - \omega_i| + \omega_i s_i = \omega_i(1 + s_i) - 1 < 1$ . 所以  $0 < \omega_i < \frac{2}{1 + l_i + u_i}$  保证  $\rho(M) < 1$ . 同时该条件也蕴含  $\omega_i \alpha l_i < 1$ , 因为  $\omega_i \alpha l_i \leq \omega_i l_i < \frac{2l_i}{1 + l_i + u_i} < 1$ .  $\square$

## 14.7 最小残量方向与最速下降

### 14.7.1 知识点八：单方向最小残量校正

考虑  $Ax = b$ , 并取搜索方向  $p_k \neq 0$ :

$$x_{k+1} = x_k + \beta_k p_k. \quad (14.83)$$

残差为  $r_k = b - Ax_k$ 。于是  $r_{k+1} = r_k - \beta_k Ap_k$ 。

使二范数残差最小的步长为

$$\beta_k = \frac{(Ap_k)^H r_k}{\|Ap_k\|_2^2}. \quad (14.84)$$

实数情形即  $\beta_k = \frac{r_k^T Ap_k}{p_k^T A^T Ap_k}$ 。

最优残差满足

$$r_{k+1} \perp Ap_k. \quad (14.85)$$

若  $\alpha_k$  为  $r_k$  与  $Ap_k$  的锐角, 则

$$\|r_{k+1}\|_2 = \|r_k\|_2 \sin \alpha_k. \quad (14.86)$$

### 14.7.2 补充训练题: NLA-Set-2016-Team-Q4

#### 完整题目叙述

设  $A \in \mathbb{R}^{n \times n}$  非奇异, 考虑  $x_{k+1} = x_k + \beta_k p_k$ , 其中  $\beta_k$  使  $\|r_{k+1}\|_2$  最小。

1. 求  $\beta_k$ ;
2. 证明  $r_{k+1} \perp Ap_k$ ;
3. 证明  $\|r_{k+1}\|_2 \leq \|r_k\|_2 \sin \alpha_k$ , 其中  $\alpha_k$  为  $r_k$  与  $Ap_k$  的夹角;
4. 若  $r_k^T Ap_k \neq 0$  对每一步成立, 迭代是否必然收敛;
5. 若  $A = A^T \succ 0$  并取  $p_k = r_k$ , 证明对任意初值收敛。

第 (1)-(3) 问. 目标函数为  $\varphi(\beta) = \|r_k - \beta Ap_k\|_2^2$ . 求导:  $\varphi'(\beta) = -2r_k^T Ap_k + 2\beta \|Ap_k\|_2^2$ . 故  $\beta_k = \frac{r_k^T Ap_k}{\|Ap_k\|_2^2}$ . 于是  $r_{k+1}^T Ap_k = 0$ .

进一步,

$$\begin{aligned} \|r_{k+1}\|_2^2 &= \|r_k\|_2^2 - \frac{(r_k^T Ap_k)^2}{\|Ap_k\|_2^2} \\ &= \|r_k\|_2^2 (1 - \cos^2 \alpha_k) \\ &= \|r_k\|_2^2 \sin^2 \alpha_k. \end{aligned} \quad (14.87)$$

实际上是等号, 而不只是题目中的不等式。□

第 (4) 问: 不一定收敛. 仅有  $r_k^T Ap_k \neq 0$  只能保证每一步残差严格下降, 不能保证下降比例一致小于 1。

取  $A = I_2$ ,  $b = 0$ . 令  $c_k = \frac{1}{k+2}$ . 在每一步选择单位向量  $p_k$  满足  $r_k^T p_k = c_k \|r_k\|_2$ . 在二维空间中总可选择这样的方向, 且内积非零。

最小残量更新后  $\|\mathbf{r}_{k+1}\|_2 = \sqrt{1 - c_k^2} \|\mathbf{r}_k\|_2$ 。因此  $\|\mathbf{r}_k\|_2 = \|\mathbf{r}_0\|_2 \prod_{j=0}^{k-1} \sqrt{1 - c_j^2}$ 。由于  $\sum_{j=0}^{\infty} c_j^2 < \infty$ , 无穷乘积  $\prod_{j=0}^{\infty} \sqrt{1 - c_j^2}$  收敛到严格正数。故  $\|\mathbf{r}_k\|_2 \not\rightarrow 0$ 。□

第 (5) 问. 取  $\mathbf{p}_k = \mathbf{r}_k$ 。则  $\beta_k = \frac{\mathbf{r}_k^\top A \mathbf{r}_k}{\mathbf{r}_k^\top A^2 \mathbf{r}_k}$ 。设  $0 < \lambda_{\min}(A) = a \leq \lambda_{\max}(A) = b$ 。有 Kantorovich 型估计

$$\frac{(\mathbf{r}^\top A \mathbf{r})^2}{(\mathbf{r}^\top \mathbf{r})(\mathbf{r}^\top A^2 \mathbf{r})} \geq \frac{4ab}{(a+b)^2}. \quad (14.88)$$

故

$$\begin{aligned} \frac{\|\mathbf{r}_{k+1}\|_2^2}{\|\mathbf{r}_k\|_2^2} &= 1 - \frac{(\mathbf{r}_k^\top A \mathbf{r}_k)^2}{\|\mathbf{r}_k\|_2^2 \mathbf{r}_k^\top A^2 \mathbf{r}_k} \\ &\leq 1 - \frac{4ab}{(a+b)^2} \\ &= \left( \frac{b-a}{b+a} \right)^2. \end{aligned} \quad (14.89)$$

所以

$$\|\mathbf{r}_k\|_2 \leq \left( \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1} \right)^k \|\mathbf{r}_0\|_2. \quad (14.90)$$

因此对任意初值收敛。□

### 14.7.3 知识点九：最速下降法

对  $A = A^H \succ 0$ , 定义二次泛函

$$\phi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^H A \mathbf{x} - \operatorname{Re}(\mathbf{b}^H \mathbf{x}). \quad (14.91)$$

其梯度为  $\nabla \phi(\mathbf{x}) = A\mathbf{x} - \mathbf{b} = -\mathbf{r}$ 。最速下降法取  $\mathbf{p}_k = \mathbf{r}_k$ , 并沿该方向精确最小化  $\phi$ :

$$\alpha_k = \frac{\mathbf{r}_k^H \mathbf{r}_k}{\mathbf{r}_k^H A \mathbf{r}_k}. \quad (14.92)$$

误差满足

$$\|\mathbf{e}_{k+1}\|_A \leq \frac{\kappa_2(A) - 1}{\kappa_2(A) + 1} \|\mathbf{e}_k\|_A. \quad (14.93)$$

### 14.7.4 补充训练题：齐次二次型的最速下降

完整题目叙述: [NLA-Set-2015-Oral-Team-Q2]

设  $A = A^\top \succ 0$ ,  $0 < \lambda_1 \leq \dots \leq \lambda_n$ ,  $\kappa = \frac{\lambda_n}{\lambda_1}$ 。对  $g(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x}$  使用精确线搜索最速下降:  $\mathbf{x}_{k+1} = \mathbf{x}_k - \alpha_k \nabla g(\mathbf{x}_k)$ , 其中  $g(\mathbf{x}_k - \alpha_k \nabla g(\mathbf{x}_k)) = \min_{\alpha \geq 0} g(\mathbf{x}_k - \alpha \nabla g(\mathbf{x}_k))$ 。证明

$$g(\mathbf{x}_{k+1}) \leq \left( \frac{\kappa - 1}{\kappa + 1} \right)^2 g(\mathbf{x}_k). \quad (14.94)$$

证明. 由于  $\nabla g(\mathbf{x}) = 2A\mathbf{x}$ , 令  $\tau_k = 2\alpha_k$ 。则  $\mathbf{x}_{k+1} = (I - \tau_k A)\mathbf{x}_k$ 。对  $\tau$  最小化  $(\mathbf{x} - \tau A\mathbf{x})^\top A(\mathbf{x} - \tau A\mathbf{x})$  得到

$$\tau_k = \frac{\mathbf{x}_k^\top A^2 \mathbf{x}_k}{\mathbf{x}_k^\top A^3 \mathbf{x}_k}, \quad \alpha_k = \frac{\mathbf{x}_k^\top A^2 \mathbf{x}_k}{2\mathbf{x}_k^\top A^3 \mathbf{x}_k}. \quad (14.95)$$

代回：

$$g(\mathbf{x}_{k+1}) = \mathbf{x}_k^T A \mathbf{x}_k - \frac{(\mathbf{x}_k^T A^2 \mathbf{x}_k)^2}{\mathbf{x}_k^T A^3 \mathbf{x}_k}. \quad (14.96)$$

故

$$\frac{g(\mathbf{x}_{k+1})}{g(\mathbf{x}_k)} = 1 - \frac{(\mathbf{x}_k^T A^2 \mathbf{x}_k)^2}{(\mathbf{x}_k^T A \mathbf{x}_k)(\mathbf{x}_k^T A^3 \mathbf{x}_k)}. \quad (14.97)$$

令  $A = Q\Lambda Q^T$ ，并定义概率权重  $w_i = \frac{\lambda_i |(Q^T \mathbf{x}_k)_i|^2}{\mathbf{x}_k^T A \mathbf{x}_k}$ 。则  $\sum_i w_i = 1$ 。设  $m_1 = \sum_i w_i \lambda_i$ ， $m_2 = \sum_i w_i \lambda_i^2$ 。由  $(\lambda - a)(b - \lambda) \geq 0$ ， $a = \lambda_1$ ， $b = \lambda_n$ ，可得  $\lambda^2 \leq (a + b)\lambda - ab$ 。所以  $m_2 \leq (a + b)m_1 - ab$ 。进一步  $\frac{m_2}{m_1^2} \leq \frac{(a+b)^2}{4ab}$ ，即  $\frac{m_1^2}{m_2} \geq \frac{4ab}{(a+b)^2}$ 。代入式 (14.97)： $\frac{g(\mathbf{x}_{k+1})}{g(\mathbf{x}_k)} \leq 1 - \frac{4ab}{(a+b)^2} = \left(\frac{b-a}{b+a}\right)^2 = \left(\frac{\kappa-1}{\kappa+1}\right)^2$ 。□

## 14.8 共轭梯度法：Galerkin 最优性、正交性与多项式逼近

### 14.8.1 知识点十：CG 的适用条件

【重要性等级】 S 级。

共轭梯度法 (conjugate gradient, CG) 的标准适用条件为

$$A = A^H \succ 0. \quad (14.98)$$

该条件不能省略：

- 若  $A$  不 Hermitian，搜索方向的三项递推一般不再保持共轭性；
- 若  $A$  不正定，分母  $\mathbf{p}_k^H A \mathbf{p}_k$  可能为零或负数；
- 对 Hermitian 不定问题，应考虑 MINRES 或 SYMMLQ；
- 对一般非 Hermitian 问题，应考虑 GMRES、BiCG、QMR 等。

定义

$$\phi(\mathbf{x}) = \frac{1}{2} \mathbf{x}^H A \mathbf{x} - \operatorname{Re}(\mathbf{b}^H \mathbf{x}). \quad (14.99)$$

其唯一极小点为  $\mathbf{x}^* = A^{-1} \mathbf{b}$ 。并且

$$\phi(\mathbf{x}) - \phi(\mathbf{x}^*) = \frac{1}{2} \|\mathbf{x} - \mathbf{x}^*\|_A^2. \quad (14.100)$$

### 14.8.2 知识点十一：CG 算法

**Algorithm 61** 共轭梯度法

**Input:** Hermitian 正定矩阵  $A$ ；右端项  $\mathbf{b}$ ；初值  $\mathbf{x}_0$ ；容差；最大迭代次数

**Output:** 近似解  $\mathbf{x}_k$

- 1: **Initialization:**  $\mathbf{r}_0 \leftarrow \mathbf{b} - A\mathbf{x}_0$ ,  $\mathbf{p}_0 \leftarrow \mathbf{r}_0$
- 2: **for**  $k = 0, 1, \dots$  **do**
- 3:      $\mathbf{q}_k \leftarrow A\mathbf{p}_k$
- 4:      $\alpha_k \leftarrow \frac{\mathbf{r}_k^H \mathbf{r}_k}{\mathbf{p}_k^H \mathbf{q}_k}$
- 5:      $\mathbf{x}_{k+1} \leftarrow \mathbf{x}_k + \alpha_k \mathbf{p}_k$
- 6:      $\mathbf{r}_{k+1} \leftarrow \mathbf{r}_k - \alpha_k \mathbf{q}_k$



---

```

7:   if  $\|\mathbf{r}_{k+1}\|_2$  满足停止准则 then
8:       return  $\mathbf{x}_{k+1}$ 
9:   end if
10:   $\beta_k \leftarrow \frac{\mathbf{r}_{k+1}^H \mathbf{r}_{k+1}}{\mathbf{r}_k^H \mathbf{r}_k}$ 
11:   $\mathbf{p}_{k+1} \leftarrow \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k$ 
12: end for
13: Stopping criterion: 使用真实或递推残差; 有限精度下宜周期性重算  $\mathbf{r}_k = \mathbf{b} - A\mathbf{x}_k$ 
14: Complexity: 每步一次矩阵-向量乘法、两次内积及若干向量更新; 稀疏情形时间  $O(\text{nnz}(A))$ ,
    额外存储  $O(n)$ 

```

---

另一种等价的  $\beta_k$  公式为

$$\beta_k = -\frac{\mathbf{r}_{k+1}^H A \mathbf{p}_k}{\mathbf{p}_k^H A \mathbf{p}_k}. \quad (14.101)$$

它直接保证  $\mathbf{p}_{k+1}^H A \mathbf{p}_k = 0$ 。

### 14.8.3 知识点十二: CG 的四个基本结构

令  $\mathcal{K}_k(A, \mathbf{r}_0) = \text{span}\{\mathbf{r}_0, A\mathbf{r}_0, \dots, A^{k-1}\mathbf{r}_0\}$ 。

在精确算术中, CG 满足:

$$\mathbf{x}_k \in \mathbf{x}_0 + \mathcal{K}_k(A, \mathbf{r}_0), \quad (14.102)$$

$$\mathbf{r}_k \perp \mathcal{K}_k(A, \mathbf{r}_0), \quad (14.103)$$

$$\mathbf{p}_i^H A \mathbf{p}_j = 0, \quad i \neq j, \quad (14.104)$$

$$\mathbf{r}_i^H \mathbf{r}_j = 0, \quad i \neq j. \quad (14.105)$$

定理 14.13 (CG 的最优性). 第  $k$  步 CG 解满足

$$\|\mathbf{x}_k - \mathbf{x}^*\|_A = \min_{\mathbf{x} \in \mathbf{x}_0 + \mathcal{K}_k(A, \mathbf{r}_0)} \|\mathbf{x} - \mathbf{x}^*\|_A. \quad (14.106)$$

等价地,  $\phi(\mathbf{x}_k) = \min_{\mathbf{x} \in \mathbf{x}_0 + \mathcal{K}_k} \phi(\mathbf{x})$ 。

证明. 在仿射子空间  $\mathbf{x}_0 + \mathcal{K}_k$  上极小化  $\phi$  的必要充分条件为  $\nabla \phi(\mathbf{x}_k) \perp \mathcal{K}_k$ 。由于  $\nabla \phi(\mathbf{x}_k) = A\mathbf{x}_k - \mathbf{b} = -\mathbf{r}_k$ , 该条件正是  $\mathbf{r}_k \perp \mathcal{K}_k$ 。□

推论 14.14 (精确算术有限步终止). 若  $A \in \mathbb{C}^{n \times n}$  为 Hermitian 正定, 则 CG 在精确算术中至多  $n$  步得到精确解。

更准确地, 若  $\mathbf{r}_0$  相对于  $A$  的 Krylov 等级为  $m$ , 则至多  $m$  步终止。

### 14.8.4 知识点十三: CG 的多项式观点

由  $\mathbf{e}_k = \mathbf{x}^* - \mathbf{x}_k$  和 Krylov 结构, 存在次数不超过  $k$  且满足  $p(0) = 1$  的多项式  $p_k$  使

$$\mathbf{e}_k = p_k(A)\mathbf{e}_0. \quad (14.107)$$

CG 最优性给出

$$\|\mathbf{e}_k\|_A = \min_{\substack{p \in \mathbb{P}_k \\ p(0)=1}} \|p(A)\mathbf{e}_0\|_A \leq \min_{\substack{p \in \mathbb{P}_k \\ p(0)=1}} \max_{\lambda \in [\lambda_{\min}, \lambda_{\max}]} |p(\lambda)| \|\mathbf{e}_0\|_A. \quad (14.108)$$

这把 CG 收敛分析转化为区间上的多项式最佳一致逼近问题。



### 14.8.5 补充训练题——CG 结构证明

#### 完整题目叙述

设  $A = A^T \succ 0$ , CG 按  $\mathbf{r}_0 = \mathbf{b} - A\mathbf{x}_0$ ,  $\mathbf{p}_0 = \mathbf{r}_0$  及标准递推生成  $\mathbf{x}_k, \mathbf{r}_k, \mathbf{p}_k$ 。

证明:

(a)  $\alpha_k$  使  $\phi(\mathbf{x}_k + \alpha\mathbf{p}_k)$  关于  $\alpha$  最小;

(b)  $\mathbf{p}_i^T \mathbf{r}_k = 0$ ,  $i < k$ , 且  $\mathbf{p}_i^T A\mathbf{p}_j = 0$ ,  $i \neq j$ ;

(c)

$$\text{span}\{\mathbf{p}_0, \dots, \mathbf{p}_{k-1}\} = \text{span}\{\mathbf{r}_0, \dots, \mathbf{r}_{k-1}\} = \mathcal{K}_k(A, \mathbf{r}_0); \quad (14.109)$$

(d)  $\mathbf{r}_k \perp \mathcal{K}_k(A, \mathbf{r}_0)$ .

第 (a) 问. 令  $\psi(\alpha) = \phi(\mathbf{x}_k + \alpha\mathbf{p}_k)$ 。则

$$\begin{aligned} \psi'(\alpha) &= \mathbf{p}_k^T [A(\mathbf{x}_k + \alpha\mathbf{p}_k) - \mathbf{b}] \\ &= -\mathbf{p}_k^T \mathbf{r}_k + \alpha \mathbf{p}_k^T A\mathbf{p}_k. \end{aligned} \quad (14.110)$$

由  $\mathbf{p}_k = \mathbf{r}_k + \beta_{k-1}\mathbf{p}_{k-1}$  及  $\mathbf{p}_{k-1}^T \mathbf{r}_k = 0$ , 有  $\mathbf{p}_k^T \mathbf{r}_k = \mathbf{r}_k^T \mathbf{r}_k$ 。故唯一极小点为  $\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{p}_k^T A\mathbf{p}_k}$ 。□

第 (b) 问. 由精确线搜索,  $\mathbf{p}_k^T \mathbf{r}_{k+1} = 0$ 。利用  $\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A\mathbf{p}_k$  以及先前方向的  $A$  共轭性, 可归纳得到  $\mathbf{p}_i^T \mathbf{r}_{k+1} = 0$ ,  $i \leq k$ 。

再由  $\mathbf{p}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k$  及  $\beta_k = -\frac{\mathbf{r}_{k+1}^T A\mathbf{p}_k}{\mathbf{p}_k^T A\mathbf{p}_k}$ , 有  $\mathbf{p}_{k+1}^T A\mathbf{p}_k = 0$ 。对  $i < k$ , 利用  $A\mathbf{p}_i = \frac{\mathbf{r}_i - \mathbf{r}_{i+1}}{\alpha_i}$  及  $\mathbf{r}_{k+1}$  对先前残差的正交性, 得  $\mathbf{p}_{k+1}^T A\mathbf{p}_i = 0$ 。故所有搜索方向两两  $A$  共轭。□

第 (c) 问. 由  $\mathbf{p}_k = \mathbf{r}_k + \beta_{k-1}\mathbf{p}_{k-1}$ , 每个  $\mathbf{p}_k$  属于  $\text{span}\{\mathbf{r}_0, \dots, \mathbf{r}_k\}$ 。反过来,  $\mathbf{r}_k = \mathbf{p}_k - \beta_{k-1}\mathbf{p}_{k-1}$ , 故两个张成空间相同。

再由  $\mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k A\mathbf{p}_k$  可归纳证明  $\mathbf{r}_k, \mathbf{p}_k \in \mathcal{K}_{k+1}(A, \mathbf{r}_0)$ 。由于非零残差两两正交, 前  $k$  个残差线性无关。因此其张成空间维数为  $k$ , 与  $\mathcal{K}_k$  相同, 从而得到 式 (14.109)。□

第 (d) 问. 由第 (b) 问,  $\mathbf{r}_k \perp \text{span}\{\mathbf{p}_0, \dots, \mathbf{p}_{k-1}\}$ 。再用第 (c) 问即可得到  $\mathbf{r}_k \perp \mathcal{K}_k(A, \mathbf{r}_0)$ 。□

## 14.9 Krylov 子空间、Arnoldi 与 Lanczos

### 14.9.1 知识点十四: Krylov 子空间与等级


定义 14.15 (Krylov 子空间). 给定  $A \in \mathbb{C}^{n \times n}$  和  $\mathbf{r}_0 \neq \mathbf{0}$ , 定义

$$\mathcal{K}_k(A, \mathbf{r}_0) = \text{span}\{\mathbf{r}_0, A\mathbf{r}_0, \dots, A^{k-1}\mathbf{r}_0\}. \quad (14.111)$$

存在最小正整数  $m$  使  $\mathcal{K}_{m+1} = \mathcal{K}_m$ 。该  $m$  称为  $\mathbf{r}_0$  相对于  $A$  的 Krylov 等级或 grade。等价地, 存在唯一最低次首一多项式  $q_m$  使

$$q_m(A)\mathbf{r}_0 = \mathbf{0}. \quad (14.112)$$

一旦  $\mathcal{K}_{m+1} = \mathcal{K}_m$ , 则  $A\mathcal{K}_m \subseteq \mathcal{K}_m$  且  $\mathcal{K}_j = \mathcal{K}_m$ ,  $j \geq m$ 。





## 14.9.2 知识点十五: Arnoldi 过程

Arnoldi 过程对一般矩阵构造 Krylov 子空间的正交基。

**Algorithm 62** Arnoldi 过程 (修正 Gram-Schmidt 形式)

**Input:** 矩阵-向量乘法算子  $A$ ; 非零起始向量  $\mathbf{b}$ ; 最大步数  $m$ ; 正交化容差

**Output:**  $V_{m+1}$  和上 Hessenberg 矩阵  $\overline{H}_m$

```

1: Initialization:  $\beta \leftarrow \|\mathbf{b}\|_2$ ,  $\mathbf{v}_1 \leftarrow \mathbf{b}/\beta$ 
2: for  $j = 1, 2, \dots, m$  do
3:    $\mathbf{w} \leftarrow A\mathbf{v}_j$ 
4:   for  $i = 1, 2, \dots, j$  do
5:      $h_{ij} \leftarrow \mathbf{v}_i^H \mathbf{w}$ 
6:      $\mathbf{w} \leftarrow \mathbf{w} - h_{ij}\mathbf{v}_i$ 
7:   end for
8:   可选重正交化一次
9:    $h_{j+1,j} \leftarrow \|\mathbf{w}\|_2$ 
10:  if  $h_{j+1,j}$  低于容差 then
11:    报告 Arnoldi breakdown 并终止
12:  end if
13:   $\mathbf{v}_{j+1} \leftarrow \mathbf{w}/h_{j+1,j}$ 
14: end for
15: Stopping criterion: 达到  $m$  步, 或  $h_{j+1,j} = 0$  产生精确不变子空间
16: Complexity: 第  $j$  步一次矩阵-向量乘法, 以及  $O(nj)$  正交化;  $m$  步总成本  $O(m \text{ nnz}(A) + nm^2)$ ,
    存储  $O(nm)$ 

```

Arnoldi 关系为

$$AV_m = V_{m+1}\overline{H}_m = V_m H_m + h_{m+1,m}\mathbf{v}_{m+1}\mathbf{e}_m^T. \quad (14.113)$$

其中  $V_m = (\mathbf{v}_1 \ \dots \ \mathbf{v}_m)$ ,  $\overline{H}_m \in \mathbb{C}^{(m+1) \times m}$  为上 Hessenberg 矩阵,  $H_m$  为其前  $m$  行。

若  $h_{m+1,m} = 0$ , 则  $AK_m \subseteq K_m$ 。这称为精确 breakdown; 在特征值计算中意味着已找到不变子空间, 在 GMRES 中若同时残差为零则称为 happy breakdown。

## 14.9.3 补充训练题: Arnoldi、breakdown 与最优首一多项式

完整题目叙述: [NLA-Set-2016-Oral-Q1]

给定  $A \in \mathbb{R}^{m \times m}$ ,  $\mathbf{b} \in \mathbb{R}^m$ , Arnoldi 过程构造  $AQ_n = Q_{n+1}\overline{H}_n$ , 其中  $Q_n, Q_{n+1}$  列正交,  $\overline{H}_n$  为上 Hessenberg 矩阵,  $H_n$  为删除  $\overline{H}_n$  最后一行后得到的  $n \times n$  矩阵。

(a) 写出 Arnoldi 算法;

(b) 若  $h_{n+1,n} = 0$ , 证明:

(i)  $K_n$  为  $A$  不变子空间, 且  $K_n = K_{n+1} = \dots$ ;

(ii)  $H_n$  的每个特征值都是  $A$  的特征值;

(c) 设  $\mathcal{P}_n$  为所有  $n$  次首一多项式的集合。证明

$$\min_{p \in \mathcal{P}_n} \|p(A)\mathbf{b}\|_2 \quad (14.114)$$

的一个最优多项式为  $H_n$  的特征多项式。

第 (a) 问. 算法即 算法 62, 起始向量取  $\mathbf{v}_1 = \mathbf{b} / \|\mathbf{b}\|_2$ . □

第 (b)(i) 问. 若  $h_{n+1,n} = 0$ , 则 Arnoldi 关系退化为  $AQ_n = Q_n H_n$ . 因此  $AR(Q_n) \subseteq \mathcal{R}(Q_n)$ . 而  $\mathcal{R}(Q_n) = \mathcal{K}_n(A, \mathbf{b})$ , 故  $\mathcal{K}_n$  为不变子空间。

于是  $A^n \mathbf{b} \in \mathcal{K}_n$ , 从而  $\mathcal{K}_{n+1} = \mathcal{K}_n$ . 继续乘以  $A$  即得以后所有 Krylov 子空间均相同. □

第 (b)(ii) 问. 若  $H_n \mathbf{y} = \theta \mathbf{y}$ ,  $\mathbf{y} \neq \mathbf{0}$ , 令  $\mathbf{z} = Q_n \mathbf{y}$ . 由于  $Q_n$  列正交,  $\mathbf{z} \neq \mathbf{0}$ . 且  $A\mathbf{z} = AQ_n \mathbf{y} = Q_n H_n \mathbf{y} = \theta Q_n \mathbf{y} = \theta \mathbf{z}$ . 故  $\theta \in \sigma(A)$ . □

第 (c) 问. 令  $\beta = \|\mathbf{b}\|_2$ ,  $\mathbf{v}_1 = \mathbf{b} / \beta$ . 假设 Arnoldi 在前  $n$  步无提前 breakdown. 记  $\gamma_n = \prod_{j=1}^n h_{j+1,j}$ .

对任意  $n$  次首一多项式  $p(z) = z^n + c_{n-1}z^{n-1} + \cdots + c_0$ , 低次项  $c_{n-1}A^{n-1}\mathbf{v}_1 + \cdots + c_0\mathbf{v}_1$  均属于  $\mathcal{K}_n$ . 只有首项  $A^n \mathbf{v}_1$  可能含有  $\mathbf{v}_{n+1}$  分量, 且该分量系数固定为  $\gamma_n$ . 因此

$$p(A)\mathbf{v}_1 = V_n \mathbf{y}_p + \gamma_n \mathbf{v}_{n+1} \quad (14.115)$$

对某个  $\mathbf{y}_p \in \mathbb{C}^n$  成立. 由正交性,

$$\|p(A)\mathbf{v}_1\|_2^2 = \|\mathbf{y}_p\|_2^2 + |\gamma_n|^2 \geq |\gamma_n|^2. \quad (14.116)$$

令  $\chi_n(z) = \det(zI - H_n)$  为  $H_n$  的特征多项式. 由 Cayley-Hamilton 定理,  $\chi_n(H_n) = 0$ . 同时  $V_n^H \chi_n(A)\mathbf{v}_1 = \chi_n(H_n)\mathbf{e}_1 = \mathbf{0}$ . 所以  $\chi_n(A)\mathbf{v}_1 = \gamma_n \mathbf{v}_{n+1}$ . 故  $\|\chi_n(A)\mathbf{b}\|_2 = \beta|\gamma_n|$ , 达到所有首一多项式共有的下界。

因此

$$p^*(z) = \det(zI - H_n) \quad (14.117)$$

是一个最优多项式。

若所有  $h_{j+1,j} \neq 0$ , 则  $\mathcal{K}_n$  维数为  $n$ , 该最优多项式唯一. 若提前 breakdown, 则最小值可能为零. □

#### 14.9.4 知识点十六: Lanczos 过程

当  $A = A^H$  时, Arnoldi 上 Hessenberg 矩阵同时 Hermitian, 因此退化为三对角矩阵. 由此得到 Lanczos 三项递推。

##### Algorithm 63 Hermitian Lanczos 过程

**Input:** Hermitian 矩阵  $A$ ; 单位起始向量  $\mathbf{q}_1$ ; 最大步数  $m$

**Output:** 正交基  $Q_m$  及 Hermitian 三对角矩阵  $T_m$

- 1: **Initialization:**  $\mathbf{q}_0 \leftarrow \mathbf{0}$ ,  $\beta_0 \leftarrow 0$
- 2: **for**  $j = 1, 2, \dots, m$  **do**
- 3:      $\mathbf{w} \leftarrow A\mathbf{q}_j - \beta_{j-1}\mathbf{q}_{j-1}$
- 4:      $\alpha_j \leftarrow \mathbf{q}_j^H \mathbf{w}$
- 5:      $\mathbf{w} \leftarrow \mathbf{w} - \alpha_j \mathbf{q}_j$
- 6:     可选选择性或完全重正交化
- 7:      $\beta_j \leftarrow \|\mathbf{w}\|_2$
- 8:     **if**  $\beta_j = 0$  **then**



9:       报告精确终止并返回  
 10:    **end if**  
 11:     $\mathbf{q}_{j+1} \leftarrow \mathbf{w}/\beta_j$   
 12: **end for**  
 13: **Stopping criterion:**  $\beta_j = 0$  或达到  $m$  步  
 14: **Complexity:** 每步一次矩阵-向量乘法和常数次向量运算; 不重正交时额外存储  $O(n)$ ; 若保存全部 Ritz 向量则需  $O(nm)$

Lanczos 关系为

$$AQ_k = Q_k T_k + \beta_k \mathbf{q}_{k+1} \mathbf{e}_k^T. \quad (14.118)$$

其中

$$T_k = \begin{pmatrix} \alpha_1 & \beta_1 & & & \\ \beta_1 & \alpha_2 & & & \\ & & \ddots & & \\ & & & \ddots & \beta_{k-1} \\ & & & \beta_{k-1} & \alpha_k \end{pmatrix}. \quad (14.119)$$

$T_k$  的特征值称为 Ritz 值, 可用于逼近  $A$  的极端或内部特征值。

#### 14.9.5 补充训练题: Lanczos 正交性、终止与用途

完整题目叙述: [NLA-Set-2017-Oral-Team-Q2]

设  $A = A^T \in \mathbb{R}^{n \times n}$ ,  $\|\mathbf{q}_1\|_2 = 1$ 。对标准 Lanczos 递推:

- (a) 证明  $AQ_k = Q_k T_k + \mathbf{r}_k \mathbf{e}_k^T$ ;
- (b) 若算法未终止, 证明  $Q_k$  列正交, 且  $\mathcal{R}(Q_k) = \mathcal{K}_k(A, \mathbf{q}_1)$ ;
- (c) 若  $m = \dim \mathcal{K}_m(A, \mathbf{q}_1)$ , 证明算法在第  $m$  步终止;
- (d) 说明该算法的目的。

第 (a) 问. 递推式  $A\mathbf{q}_j = \beta_{j-1}\mathbf{q}_{j-1} + \alpha_j\mathbf{q}_j + \beta_j\mathbf{q}_{j+1}$  对  $j = 1, \dots, k-1$  成立。对最后一列,  $A\mathbf{q}_k = \beta_{k-1}\mathbf{q}_{k-1} + \alpha_k\mathbf{q}_k + \mathbf{r}_k$ , 其中  $\mathbf{r}_k = \beta_k\mathbf{q}_{k+1}$ 。把各列合并即得  $AQ_k = Q_k T_k + \mathbf{r}_k \mathbf{e}_k^T$ 。□

第 (b) 问. 用归纳法证明  $\mathbf{q}_{k+1}$  与  $\mathbf{q}_1, \dots, \mathbf{q}_k$  正交。

递推已通过  $\alpha_k$  消去  $\mathbf{q}_k$  方向, 通过  $\beta_{k-1}$  消去  $\mathbf{q}_{k-1}$  方向。

对  $i \leq k-2$ , 由  $A = A^T$ ,

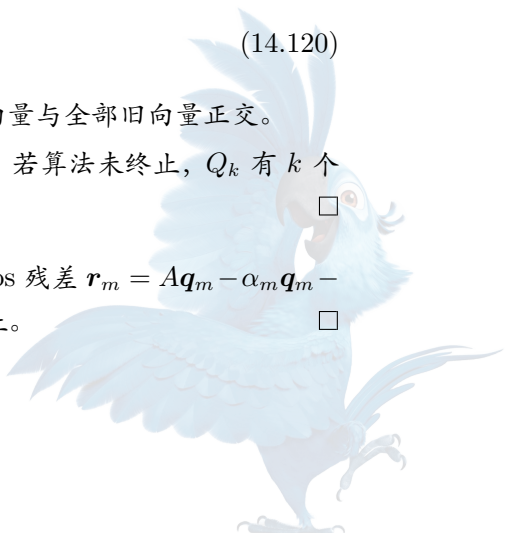
$$\mathbf{q}_i^T A\mathbf{q}_k = (A\mathbf{q}_i)^T \mathbf{q}_k. \quad (14.120)$$

而  $A\mathbf{q}_i \in \text{span}\{\mathbf{q}_{i-1}, \mathbf{q}_i, \mathbf{q}_{i+1}\}$ , 它们均与  $\mathbf{q}_k$  正交。故  $\mathbf{q}_i^T \mathbf{r}_k = 0$ 。因此新向量与全部旧向量正交。

同时每个  $\mathbf{q}_j$  由  $\mathbf{q}_1, A\mathbf{q}_1, \dots, A^{j-1}\mathbf{q}_1$  线性组合得到, 故  $\mathcal{R}(Q_k) \subseteq \mathcal{K}_k$ 。若算法未终止,  $Q_k$  有  $k$  个正交列, 而  $\mathcal{K}_k$  维数至少为  $k$ 。故两者相等。□

第 (c) 问. 由  $m$  的定义,  $\mathcal{K}_{m+1} = \mathcal{K}_m$ 。因此  $A\mathbf{q}_m \in \mathcal{K}_m = \mathcal{R}(Q_m)$ 。Lanczos 残差  $\mathbf{r}_m = A\mathbf{q}_m - \alpha_m\mathbf{q}_m - \beta_{m-1}\mathbf{q}_{m-1}$  既属于  $\mathcal{K}_m$ , 又与  $\mathcal{K}_m$  正交。所以  $\mathbf{r}_m = \mathbf{0}$ ,  $\beta_m = 0$ 。算法终止。□

第 (d) 问. Lanczos 的主要目的包括:



1. 把大型 Hermitian 矩阵在 Krylov 子空间上投影为小型三对角矩阵  $T_k$ ;
2. 用  $T_k$  的 Ritz 值近似  $A$  的特征值;
3. 为 CG、MINRES 等 Hermitian 线性系统 Krylov 方法提供短递推;
4. 只需矩阵-向量乘法, 适合大型稀疏或矩阵无关问题。

□

#### 易错点与反例

精确算术中 Lanczos 向量正交; 有限精度中三项递推会逐渐丢失正交性, 可能产生重复或“幽灵”Ritz 值。

需要时应使用:

- 完全重正交化;
- 选择性重正交化;
- 隐式重启 Lanczos;
- 锁定已收敛 Ritz 向量。

## 14.10 GMRES 与 MINRES

### 14.10.1 知识点十七: GMRES 的最小残量原理

考虑一般非奇异矩阵  $A \in \mathbb{C}^{n \times n}$ 。给定初值  $\mathbf{x}_0$  及  $\mathbf{r}_0 = \mathbf{b} - A\mathbf{x}_0$ ,  $\beta = \|\mathbf{r}_0\|_2$ 。GMRES 在仿射 Krylov 空间中求

$$\mathbf{x}_k = \arg \min_{\mathbf{x} \in \mathbf{x}_0 + \mathcal{K}_k(A, \mathbf{r}_0)} \|\mathbf{b} - A\mathbf{x}\|_2. \quad (14.121)$$

由 Arnoldi 关系  $AV_k = V_{k+1}\overline{H}_k$  及  $\mathbf{r}_0 = \beta\mathbf{e}_1$ , 写  $\mathbf{x} = \mathbf{x}_0 + V_k\mathbf{y}$ 。则

$$\begin{aligned} \mathbf{r}(\mathbf{y}) &= \mathbf{r}_0 - AV_k\mathbf{y} \\ &= V_{k+1}(\beta\mathbf{e}_1 - \overline{H}_k\mathbf{y}). \end{aligned} \quad (14.122)$$

由于  $V_{k+1}$  列正交,

$$\|\mathbf{r}(\mathbf{y})\|_2 = \|\beta\mathbf{e}_1 - \overline{H}_k\mathbf{y}\|_2. \quad (14.123)$$

因此大规模线性系统被转化为  $(k+1) \times k$  最小二乘问题。

最优性条件为

$$\overline{H}_k^H (\beta\mathbf{e}_1 - \overline{H}_k\mathbf{y}_k) = \mathbf{0}. \quad (14.124)$$


映回原空间:

$$\mathbf{r}_k \perp A\mathcal{K}_k(A, \mathbf{r}_0). \quad (14.125)$$

这与 CG 的 Galerkin 条件不同:

$$\text{CG: } \mathbf{r}_k \perp \mathcal{K}_k, \quad (14.126)$$

$$\text{GMRES: } \mathbf{r}_k \perp A\mathcal{K}_k. \quad (14.127)$$



## 14.10.2 知识点十八: GMRES 算法

**Algorithm 64** 未重启 GMRES**Input:** 矩阵-向量乘法算子  $A$ ; 右端项  $\mathbf{b}$ ; 初值  $\mathbf{x}_0$ ; 容差; 最大 Krylov 维数  $m$ **Output:** 近似解  $\mathbf{x}_k$ 


```

1: Initialization:  $\mathbf{r}_0 \leftarrow \mathbf{b} - A\mathbf{x}_0$ ,  $\beta \leftarrow \|\mathbf{r}_0\|_2$ 
2: if  $\beta$  满足停止准则 then
3:   return  $\mathbf{x}_0$ 
4: end if
5:  $\mathbf{v}_1 \leftarrow \mathbf{r}_0/\beta$ ,  $\mathbf{g} \leftarrow \beta\mathbf{e}_1$ 
6: for  $j = 1, 2, \dots, m$  do
7:   Arnoldi 一步:  $\mathbf{w} \leftarrow A\mathbf{v}_j$ 
8:   for  $i = 1, \dots, j$  do
9:      $h_{ij} \leftarrow \mathbf{v}_i^H \mathbf{w}$ 
10:     $\mathbf{w} \leftarrow \mathbf{w} - h_{ij}\mathbf{v}_i$ 
11:   end for
12:    $h_{j+1,j} \leftarrow \|\mathbf{w}\|_2$ 
13:   if  $h_{j+1,j} \neq 0$  then
14:      $\mathbf{v}_{j+1} \leftarrow \mathbf{w}/h_{j+1,j}$ 
15:   end if
16:   将此前 Givens 旋转依次作用到  $\overline{H}_j$  第  $j$  列
17:   构造新 Givens 旋转, 消去  $h_{j+1,j}$ 
18:   同一旋转作用到  $\mathbf{g}$ 
19:   if  $|g_{j+1}|$  满足容差 then
20:     解上三角系统  $R_j \mathbf{y}_j = \mathbf{g}_{1:j}$ 
21:      $\mathbf{x}_j \leftarrow \mathbf{x}_0 + V_j \mathbf{y}_j$ 
22:     return  $\mathbf{x}_j$ 
23:   end if
24:   if  $h_{j+1,j} = 0$  then
25:     解当前三角问题并返回
26:   end if
27: end for
28: 解  $R_m \mathbf{y}_m = \mathbf{g}_{1:m}$ 
29:  $\mathbf{x}_m \leftarrow \mathbf{x}_0 + V_m \mathbf{y}_m$ 
30: Stopping criterion: 旋转后的最后分量给出残差范数:  $\|\mathbf{r}_j\|_2 = |g_{j+1}|$ 
31: Complexity: 第  $j$  步一次矩阵-向量乘法和  $O(nj)$  正交化;  $m$  步总成本  $O(m \text{ nnz}(A) + nm^2)$ ;
    存储  $O(nm)$ 

```

设第  $j$  个 Givens 旋转参数为  $c_j, s_j$ 。递推更新  $\mathbf{g}$  可得

$$\|\mathbf{r}_k\|_2 = \beta \prod_{j=1}^k |s_j|. \quad (14.128)$$



### 14.10.3 知识点十九：GMRES 的多项式观点与非正规困难

存在  $p_k \in \mathbb{P}_k$  满足  $p_k(0) = 1$ , 使  $\mathbf{r}_k = p_k(A)\mathbf{r}_0$ 。GMRES 满足

$$\|\mathbf{r}_k\|_2 = \min_{\substack{p \in \mathbb{P}_k \\ p(0)=1}} \|p(A)\mathbf{r}_0\|_2. \quad (14.129)$$

若  $A$  正规, 则

$$\frac{\|\mathbf{r}_k\|_2}{\|\mathbf{r}_0\|_2} \leq \min_{\substack{p \in \mathbb{P}_k \\ p(0)=1}} \max_{\lambda \in \sigma(A)} |p(\lambda)|. \quad (14.130)$$

若  $A = V\Lambda V^{-1}$  可对角化, 则

$$\frac{\|\mathbf{r}_k\|_2}{\|\mathbf{r}_0\|_2} \leq \kappa_2(V) \min_{\substack{p \in \mathbb{P}_k \\ p(0)=1}} \max_{\lambda \in \sigma(A)} |p(\lambda)|. \quad (14.131)$$

对非正规矩阵,  $\kappa_2(V)$  可能极大, 甚至矩阵不可对角化。因此:

- 只看特征值可能严重误判 GMRES 收敛;
- 数值域、伪谱和特征向量条件数更加重要;
- 相同特征值集合的两个矩阵可有完全不同的 GMRES 历史;
- 残差最小不意味着前向误差最小。

### 14.10.4 知识点二十：重启 GMRES

未重启 GMRES 的存储和正交化成本随  $k$  增长。GMRES( $m$ ) 每达到  $m$  步后:

1. 更新近似解;
2. 重算残差;
3. 以该残差为新起点重新构造 Krylov 空间。

每个周期存储降为  $O(nm)$ , 但重启会丢失先前的多项式信息。因此 GMRES( $m$ ) 可能:

- 明显慢于未重启 GMRES;
- 长时间停滞;
- 对不同  $m$  表现非单调;
- 需要 deflation、recycling 或谐 Ritz 向量增强。

## 14.11 补充训练题：GMRES 最小二乘、残差公式与完整算法

完整题目叙述: [NLA-Set-2014-Team-Q4 / 2021-Oral-QII]

考虑  $A\mathbf{x} = \mathbf{b}$ 。GMRES 在第  $m$  个 Krylov 子空间中寻找近似解, 使残差与  $AK_m$  正交。使用 Arnoldi 过程构造正交基。

要求:

1. 证明近似解由一个小型最小二乘问题给出, 并可化为上三角问题;

2. 证明残差与 Arnoldi 生成的相应基向量正交;
3. 给出残差范数公式;
4. 推导完整 GMRES 算法。

第 (1) 问. 令  $\mathbf{r}_0 = \mathbf{b} - A\mathbf{x}_0$ ,  $\beta = \|\mathbf{r}_0\|_2$ ,  $\mathbf{v}_1 = \mathbf{r}_0/\beta$ . Arnoldi 给出  $AV_m = V_{m+1}\bar{H}_m$ . 任意候选解写为  $\mathbf{x} = \mathbf{x}_0 + V_m\mathbf{y}$ . 于是  $\mathbf{r} = V_{m+1}(\beta\mathbf{e}_1 - \bar{H}_m\mathbf{y})$ . 故  $\min_{\mathbf{x} \in \mathbf{x}_0 + \mathcal{K}_m} \|\mathbf{r}\|_2$  等价于

$$\min_{\mathbf{y} \in \mathbb{C}^m} \|\beta\mathbf{e}_1 - \bar{H}_m\mathbf{y}\|_2. \quad (14.132)$$

对  $\bar{H}_m$  依次施加 Givens 旋转, 得到

$$\Omega_m \bar{H}_m = \begin{pmatrix} R_m \\ 0 \end{pmatrix}, \quad (14.133)$$

其中  $R_m$  上三角。同时令  $\Omega_m \beta \mathbf{e}_1 = \begin{pmatrix} \mathbf{g}_m \\ \gamma_{m+1} \end{pmatrix}$ 。则最小二乘解由

$$R_m \mathbf{y}_m = \mathbf{g}_m \quad (14.134)$$

给出。  $\square$

第 (2) 问. 小型最小二乘最优性条件为  $\bar{H}_m^H (\beta\mathbf{e}_1 - \bar{H}_m\mathbf{y}_m) = \mathbf{0}$ 。利用  $AV_m = V_{m+1}\bar{H}_m$ , 有

$$\begin{aligned} (AV_m)^H \mathbf{r}_m &= \bar{H}_m^H V_{m+1}^H V_{m+1} (\beta\mathbf{e}_1 - \bar{H}_m\mathbf{y}_m) \\ &= \mathbf{0}. \end{aligned} \quad (14.135)$$

故  $\mathbf{r}_m \perp AK_m$ 。

原题采用了稍作移位的基下标: 其  $\mathbf{v}_1, \dots, \mathbf{v}_m$  用于张成  $AK_m$ 。在该下标约定下, 即得到题目所要求的  $\mathbf{r}_m \perp \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_m\}$ 。  $\square$

第 (3) 问. 旋转保持二范数, 所以

$$\begin{aligned} \|\mathbf{r}_m\|_2 &= \|\beta\mathbf{e}_1 - \bar{H}_m\mathbf{y}_m\|_2 \\ &= |\gamma_{m+1}|. \end{aligned} \quad (14.136)$$

若第  $j$  个 Givens 旋转的正弦参数为  $s_j$ , 则  $\gamma_{m+1} = (-1)^m \beta s_1 s_2 \cdots s_m$ 。因此  $\|\mathbf{r}_m\|_2 = \beta \prod_{j=1}^m |s_j|$ 。  $\square$

第 (4) 问. 完整算法即:

1. 计算  $\mathbf{r}_0 = \mathbf{b} - A\mathbf{x}_0$ ,  $\mathbf{v}_1 = \mathbf{r}_0 / \|\mathbf{r}_0\|$ ;
2. 逐步运行 Arnoldi;
3. 每生成  $\bar{H}_m$  新的一列, 用此前 Givens 旋转更新该列;
4. 构造一个新 Givens 旋转消去最新次对角元;
5. 同步更新右端向量  $\beta\mathbf{e}_1$ ;
6. 直接由最后分量得到残差范数;





7. 达到容差时回代  $R_m \mathbf{y}_m = \mathbf{g}_m$ ;

8. 返回  $\mathbf{x}_m = \mathbf{x}_0 + V_m \mathbf{y}_m$ .

对应规范伪代码见 算法 64。

□

### 14.11.1 知识点二十一：MINRES

若  $A = A^H$  但  $A$  不一定正定，CG 不再适用。MINRES 使用 Lanczos 关系  $AV_k = V_{k+1}\bar{T}_k$  并求

$$\mathbf{x}_k = \arg \min_{\mathbf{x} \in \mathbf{x}_0 + \mathcal{K}_k} \|\mathbf{b} - A\mathbf{x}\|_2. \quad (14.137)$$

小型问题为

$$\min_{\mathbf{y}} \|\beta \mathbf{e}_1 - \bar{T}_k \mathbf{y}\|_2, \quad (14.138)$$

其中  $\bar{T}_k$  为三对角矩阵附加一行。

MINRES 的特点：

- 适用于 Hermitian 不定或半正定问题；
- 最小化二范数残差；
- 利用 Lanczos 和 Givens 旋转实现短递推；
- 每步一次矩阵-向量乘法；
- 额外存储  $O(n)$ ；
- 若  $A$  奇异，需讨论  $\mathbf{b} \in \mathcal{R}(A)$  与最小二乘解。

| 方法     | 矩阵要求           | 最优性          | 主要风险             |
|--------|----------------|--------------|------------------|
| CG     | Hermitian 正定   | 最小化 $A$ 范数误差 | 非正定时可能 breakdown |
| MINRES | Hermitian, 可不定 | 最小化二范数残差     | 奇异问题需检查相容性       |
| GMRES  | 一般非奇异矩阵        | 最小化二范数残差     | 存储和正交化随步数增长      |

## 14.12 正式真题 [24F-Q2]——CG 误差估计与非 Hermitian Krylov 方法

完整题目叙述：[24F-Q2]

设  $A = A^T \succ 0$ 。用共轭梯度法求解  $A\mathbf{x} = \mathbf{b}$ ，精确解为  $\mathbf{x}^*$ 。

(i) (原题如此) 证明

$$\|\mathbf{x}_k - \mathbf{x}^*\|_A \leq \left( \frac{\sqrt{\kappa_2(A)} - 1}{\sqrt{\kappa_2(A)} + 1} \right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|_A; \quad (14.139)$$

(ii) 描述一种用于非 Hermitian 矩阵的 Krylov 子空间方法。

反例 14.16 (原题估计式 (14.139) 一般不成立). 取  $A = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$ ,  $\mathbf{b} = \mathbf{0}$ ,  $\mathbf{x}^* = \mathbf{0}$ ,  $\mathbf{x}_0 = \begin{pmatrix} 4 \\ 1 \end{pmatrix}$ . 则

$$\kappa_2(A) = 4, \quad q = \frac{\sqrt{4}-1}{\sqrt{4}+1} = \frac{1}{3}.$$

CG 第一步有  $\mathbf{r}_0 = -A\mathbf{x}_0 = \begin{pmatrix} -4 \\ -4 \end{pmatrix}$ ,  $\mathbf{p}_0 = \mathbf{r}_0$ . 步长为  $\alpha_0 = \frac{\mathbf{r}_0^\top \mathbf{r}_0}{\mathbf{p}_0^\top A \mathbf{p}_0} = \frac{32}{80} = \frac{2}{5}$ . 故  $\mathbf{x}_1 = \begin{pmatrix} 4 \\ 1 \end{pmatrix} + \frac{2}{5} \begin{pmatrix} -4 \\ -4 \end{pmatrix} = \begin{pmatrix} 12/5 \\ -3/5 \end{pmatrix}$ . 于是

$$\|\mathbf{x}_0\|_A^2 = 20, \quad (14.140)$$

$$\|\mathbf{x}_1\|_A^2 = \frac{36}{5}. \quad (14.141)$$

所以

$$\frac{\|\mathbf{x}_1\|_A}{\|\mathbf{x}_0\|_A} = \frac{3}{5} > \frac{1}{3} = q. \quad (14.142)$$

故原题的不等式是错误的 (事实上它少了一个系数 2)。

定理 14.17 (正确的 CG Chebyshev 误差估计). 令  $\kappa = \kappa_2(A)$ ,  $q = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$ . 则

$$\|\mathbf{e}_k\|_A \leq \frac{2q^k}{1+q^{2k}} \|\mathbf{e}_0\|_A \leq 2q^k \|\mathbf{e}_0\|_A. \quad (14.143)$$

证明. 设  $a = \lambda_{\min}(A)$ ,  $b = \lambda_{\max}(A)$ ,  $\kappa = b/a$ . 由 CG 多项式最优性,

$$\|\mathbf{e}_k\|_A \leq \min_{\substack{p \in \mathbb{P}_k \\ p(0)=1}} \max_{\lambda \in [a,b]} |p(\lambda)| \|\mathbf{e}_0\|_A.$$

定义线性映射  $t(\lambda) = \frac{a+b-2\lambda}{b-a}$ . 当  $\lambda \in [a, b]$  时,  $t(\lambda) \in [-1, 1]$ . 取

$$p_k(\lambda) = \frac{T_k(t(\lambda))}{T_k\left(\frac{a+b}{b-a}\right)}. \quad (14.144)$$

显然  $p_k(0) = 1$ . 由于  $|T_k(t)| \leq 1$ ,  $t \in [-1, 1]$ , 有  $\max_{\lambda \in [a,b]} |p_k(\lambda)| \leq \frac{1}{|T_k(\frac{a+b}{b-a})|}$ .

令  $c = \frac{a+b}{b-a} = \frac{\kappa+1}{\kappa-1}$ . 由  $q = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$  可验证  $c = \frac{1}{2}(q + q^{-1})$ . 对  $c > 1$ ,  $T_k(c) = \frac{1}{2}(q^{-k} + q^k)$ . 因此

$$\frac{1}{|T_k(c)|} = \frac{2q^k}{1+q^{2k}} \leq 2q^k. \quad (14.145)$$

代入即得式 (14.143).  $\square$

注 14.18. 在上述反例中,  $\kappa = 4$ ,  $q = \frac{1}{3}$ ,  $k = 1$ . 正确尖锐因子为  $\frac{2q}{1+q^2} = \frac{2/3}{10/9} = \frac{3}{5}$ , 恰好与反例中的第一步误差比相等。

第 (ii) 问: 以 GMRES 为例. 对一般非 Hermitian 矩阵  $A$ :

1. 计算  $\mathbf{r}_0 = \mathbf{b} - A\mathbf{x}_0$ ;
2. 用 Arnoldi 过程构造  $\mathcal{K}_k(A, \mathbf{r}_0)$  的正交基  $V_k$  及  $AV_k = V_{k+1}\overline{H}_k$ ;
3. 在  $\mathbf{x}_0 + \mathcal{K}_k(A, \mathbf{r}_0)$  中选择  $\mathbf{x}_k = \mathbf{x}_0 + V_k \mathbf{y}_k$ ;
4. 解小型最小二乘问题  $\mathbf{y}_k = \arg \min_{\mathbf{y}} \|\beta \mathbf{e}_1 - \overline{H}_k \mathbf{y}\|_2$ ;
5. 用 Givens 旋转逐步三角化  $\overline{H}_k$ ;
6. 返回  $\mathbf{x}_k = \mathbf{x}_0 + V_k \mathbf{y}_k$ .

该方法满足  $\|\mathbf{b} - A\mathbf{x}_k\|_2 = \min_{\mathbf{x} \in \mathbf{x}_0 + \mathcal{K}_k} \|\mathbf{b} - A\mathbf{x}\|_2$ . 完整伪代码见 算法 64.  $\square$



## 14.13 预处理

### 14.13.1 知识点二十二：预处理的目标

预处理器  $M$  应满足：

1.  $M$  容易求解；
2.  $M$  在某种意义下近似  $A$ ；
3. 预处理后谱更集中或条件数更小；
4. 构造和应用成本低于原问题求解成本；
5. 尽量保持对称、正定、稀疏和并行结构。

预处理不是直接要求  $\|M - A\|$  最小。真正目标是改善  $M^{-1}A$  或  $M^{-1/2}AM^{-1/2}$  的迭代性质。

### 14.13.2 知识点二十三：左、右与分裂预处理

左预处理

$$M^{-1}Ax = M^{-1}b. \quad (14.146)$$

若用 GMRES，则算法自然最小化  $\|M^{-1}r_k\|_2$ ，而不是必然最小化真实残差  $\|r_k\|_2$ 。

右预处理 令  $x = M^{-1}y$ 。求解

$$AM^{-1}y = b. \quad (14.147)$$

右预处理 GMRES 最小化真实残差  $r_k = b - AM^{-1}y_k$ 。但需要在输出时恢复  $x_k = M^{-1}y_k$ 。

分裂预处理

$$M_L^{-1}AM_R^{-1}y = M_L^{-1}b, x = M_R^{-1}y. \quad (14.148)$$

#### 易错点与反例

左预处理后的递推残差小，不自动说明真实残差小。

实现中应同时监视  $\|M^{-1}r_k\|$  和  $\|r_k\|$ 。

### 14.13.3 知识点二十四：预条件共轭梯度法

若  $A = A^H \succ 0$ ,  $M = M^H \succ 0$ , 则预处理系统可对称化为


$$M^{-1/2}AM^{-1/2}y = M^{-1/2}b, x = M^{-1/2}y. \quad (14.149)$$

#### Algorithm 65 预条件共轭梯度法 PCG

**Input:**  $A = A^H \succ 0$ ;  $M = M^H \succ 0$ ;  $b$ ;  $x_0$ ; 容差

**Output:** 近似解

- 1: **Initialization:**  $r_0 \leftarrow b - Ax_0$  解  $Mz_0 = r_0$  并令  $p_0 \leftarrow z_0$
- 2: **for**  $k = 0, 1, \dots$  **do**
- 3:      $q_k \leftarrow Ap_k$
- 4:      $\alpha_k \leftarrow \frac{r_k^H z_k}{p_k^H q_k}$



---

```

5:    $\mathbf{x}_{k+1} \leftarrow \mathbf{x}_k + \alpha_k \mathbf{p}_k$ 
6:    $\mathbf{r}_{k+1} \leftarrow \mathbf{r}_k - \alpha_k \mathbf{q}_k$ 
7:   if  $\|\mathbf{r}_{k+1}\|_2$  满足容差 then
8:       return  $\mathbf{x}_{k+1}$ 
9:   end if
10:  解  $M\mathbf{z}_{k+1} = \mathbf{r}_{k+1}$ 
11:   $\beta_k \leftarrow \frac{\mathbf{r}_{k+1}^H \mathbf{z}_{k+1}}{\mathbf{r}_k^H \mathbf{z}_k}$ 
12:   $\mathbf{p}_{k+1} \leftarrow \mathbf{z}_{k+1} + \beta_k \mathbf{p}_k$ 
13: end for
14: Stopping criterion: 真实残差满足容差
15: Complexity: 每步一次  $A$  乘向量、一次  $M$  求解及常数次向量运算; 总效率取决于预处理器应用成本和迭代次数降低程度

```

---

定义

$$\kappa_M = \kappa_2(M^{-1/2}AM^{-1/2}). \quad (14.150)$$

则

$$\|\mathbf{e}_k\|_A \leq 2 \left( \frac{\sqrt{\kappa_M} - 1}{\sqrt{\kappa_M} + 1} \right)^k \|\mathbf{e}_0\|_A. \quad (14.151)$$

#### 14.13.4 知识点二十五: 常见预处理器

| 预处理器         | 构造/应用                                                                            | 优点                      | 失败情形                       |
|--------------|----------------------------------------------------------------------------------|-------------------------|----------------------------|
| Jacobi       | $M = D$                                                                          | 便宜、并行、保持稀疏              | 强耦合问题效果弱                   |
| 块 Jacobi     | 局部块求逆                                                                            | 适合多物理场和并行分区             | 块选择不当时条件数改善有限              |
| Gauss-Seidel | $M = D - L$                                                                      | 比 Jacobi 捕捉更多耦合         | 顺序依赖, 非对称                  |
| SSOR         | $M_{\text{SSOR}} = \frac{1}{\omega(2-\omega)}(D - \omega L)D^{-1}(D - \omega U)$ | 对 SPD 问题保持 SPD, 可用于 PCG | 参数敏感, 仍有顺序依赖               |
| 不完全 Cholesky | $A \approx LL^H$                                                                 | 适合 SPD 稀疏系统             | 可能出现非正主元或严重填充              |
| ILU          | $A \approx LU$                                                                   | 适合一般稀疏矩阵                | 可能 breakdown; 稳定性依赖主元和填充策略 |
| 多重网格         | 平滑器加粗网格校正                                                                        | 对椭圆问题可达近线性复杂度           | 需几何或代数粗化设计                 |
| 问题专用块预处理     | 利用 Schur 补、物理变量分块                                                                | 可获得网格无关迭代数              | 设计复杂, 应用范围有限               |

#### 易错点与反例

CG 预处理器必须保持正定结构。

普通 ILU 一般不能直接作为 PCG 预处理器; 应使用不完全 Cholesky 或其他 Hermitian 正定预处理器。

### 14.14 大型稀疏矩阵的存储、复杂度与停止准则

#### 14.14.1 知识点二十六：稀疏存储

若  $\text{nnz}(A) \ll n^2$ ，不应使用稠密二维数组。

CSR 格式通常存储：

- 非零值数组 `val` 长度  $\text{nnz}(A)$ ；
- 列指标数组 `colind` 长度  $\text{nnz}(A)$ ；
- 行指针数组 `rowptr` 长度  $n + 1$ 。

存储复杂度为  $O(n + \text{nnz}(A))$ 。一次稀疏矩阵-向量乘法成本为  $O(\text{nnz}(A))$ 。

CSC 适合按列访问和稀疏直接法；COO 适合装配；块 CSR 适合有限元、多分量 PDE 和硬件向量化。

#### 14.14.2 知识点二十七：直接法与迭代法比较

| 方法            | 预处理/分解成本 | 单次求解或迭代                         | 适用性                |
|---------------|----------|---------------------------------|--------------------|
| 稠密 LU         | $O(n^3)$ | 每右端项 $O(n^2)$                   | 中小型稠密矩阵            |
| 稀疏直接法         | 依赖填充和排序  | 三角求解依赖因子非零数                     | 中等规模、多右端项、高精度需求    |
| Jacobi/GS/SOR | 几乎无设置    | 每轮 $O(\text{nnz}(A))$           | 平滑器、简单结构问题         |
| CG/PCG        | 预处理器设置   | 每步 $O(\text{nnz}(A))$ 加预处理      | 大型 SPD 问题          |
| MINRES        | 预处理器设置   | 每步一个 SpMV 及短递推                  | 大型 Hermitian 不定问题  |
| GMRES( $m$ )  | 预处理器设置   | 每周期 $O(m \text{nnz}(A) + nm^2)$ | 大型一般非 Hermitian 问题 |

稀疏直接法的主要风险是填充 (fill-in)：即原矩阵中的零元在消元因子中变为非零。常用排序包括：

- 近似最小度排序；
- 嵌套剖分；
- 图分区排序；
- 块结构排序。

#### 14.14.3 知识点二十八：停止准则与真实误差

常用相对残差准则为

$$\|\mathbf{r}_k\|_2 \leq \text{atol} + \text{rtol} \|\mathbf{b}\|_2. \tag{14.152}$$



更接近后向误差的准则为

$$\eta_k = \frac{\|\mathbf{r}_k\|}{\|A\| \|\mathbf{x}_k\| + \|\mathbf{b}\|} \leq \text{tol}. \quad (14.153)$$

若  $A$  非奇异,

$$\frac{\|\mathbf{x}_k - \mathbf{x}^*\|}{\|\mathbf{x}^*\|} \leq \kappa(A) \frac{\|\mathbf{r}_k\|}{\|\mathbf{b}\|}. \quad (14.154)$$

所以病态问题中小残差仍可能对应大前向误差。

有限精度 Krylov 方法通常递推计算残差。舍入误差积累后, 递推残差  $\hat{\mathbf{r}}_k$  可能与真实残差  $\mathbf{b} - A\hat{\mathbf{x}}_k$  偏离。应周期性重算真实残差, 必要时执行 residual replacement。

#### 易错点与反例

1. GMRES 报告的是其内部最小二乘残差估计;
2. 左预处理 GMRES 报告的可能是预处理残差;
3. CG 递推残差在有限精度下可能失真;
4. 因此最终必须至少重算一次真实残差。

#### 14.14.4 知识点二十九: 矩阵无关实现

若只需要  $A\mathbf{x}$ , 可不显式组装  $A$ 。只需提供函数  $\mathbf{y} \leftarrow \mathcal{A}(\mathbf{x})$  即可运行 CG、GMRES、Arnoldi、Lanczos。

矩阵无关方法特别适用于:

- 高阶有限元;
- 谱方法;
- 积分方程;
- 自动微分得到的 Jacobian-向量乘积;
- Newton-Krylov 方法;
- 大型图和数据算子。

但预处理器通常仍需某种显式近似结构, 这是矩阵无关 Krylov 方法的主要设计难点。



## 第四部分

### 偏微分方程数值解





# 第十五章 PDE 数值方法统一基础——网格、截断误差、相容性、稳定性、收敛性、Lax 等价、von Neumann、能量法、最大值原理与 CFL

## 15.1 连续问题的适定性与离散分析的基本对象

### 15.1.1 知识点一：连续问题的适定性

【重要性等级】 **S 级**。在讨论数值格式以前，必须先明确连续问题本身是否适定。

设连续初边值问题抽象写成

$$\begin{cases} \partial_t u = \mathcal{L}u + f, & 0 < t \leq T, \\ u(0) = u_0, \\ \mathcal{B}u = g, & \text{在空间边界上.} \end{cases} \quad (15.1)$$

定义 15.1 (Hadamard 适定性). 若问题式 (15.1) 满足:

1. 解存在;
2. 解唯一;
3. 解对初值、源项和边界数据连续依赖;

则称该问题适定。

对线性演化问题，连续依赖通常表现为

$$\|u(t)\|_X \leq M e^{\omega t} \left[ \|u_0\|_X + \int_0^t \|f(s)\|_X \, ds + \|g\|_{\mathcal{G}_t} \right]. \quad (15.2)$$

其中  $X$  为所选函数空间， $\mathcal{G}_t$  为边界数据所在空间， $M, \omega$  与网格无关，因为此时尚未离散。

#### 易错点与反例

必须区分：

- 连续 PDE 的适定性；
- 离散格式的稳定性；
- 连续问题的数据条件数；
- 数值算法求解离散代数系统的稳定性。

一个格式不能把本质上不适定的连续问题自动变成可靠问题。若连续问题不定，离散格式即使对固定网格给出有限数值，也可能只是在求解一个与原问题无关的网格正则化问题。

### 15.1.2 知识点二：统一网格与网格函数

一维有限区间  $\Omega = (a, b)$  上的均匀空间网格定义为

$$x_j = a + jh, \quad j = 0, 1, \dots, J, \quad h = \frac{b-a}{J}. \quad (15.3)$$

时间网格为

$$t_n = n\tau, \quad n = 0, 1, \dots, N, \quad N\tau = T. \quad (15.4)$$

对 Cauchy 问题可取  $j \in \mathbb{Z}$ ; 对周期问题，指标按模  $J$  计算： $U_{j+J} = U_j$ 。

二维矩形区域  $\Omega = (a, b) \times (c, d)$  上的网格为

$$x_i = a + ih_x, \quad y_j = c + jh_y. \quad (15.5)$$

若  $h_x = h_y = h$ ，称为空间均匀方格网。

**定义 15.2 (网格函数).** 定义在网格点上的数列  $V_h = \{V_j\}$  或  $V_h^n = \{V_j^n\}$  称为网格函数。

对连续函数  $u$ ，定义限制算子

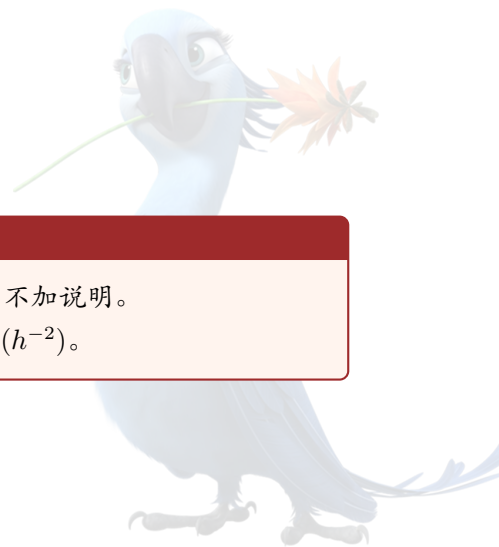
$$(R_h u)_j = u(x_j), \quad (R_{h,\tau} u)_j^n = u(x_j, t_n). \quad (15.6)$$

以下采用统一记号：

- $h$  表示空间步长；
- $\tau$  表示时间步长；
- $\nu = \frac{a\tau}{h}$  表示双曲问题的 Courant 数；
- $\mu = \frac{\kappa\tau}{h^2}$  表示热方程等抛物问题的网格比；
- Laplace 算子采用  $\Delta u = \sum_{\ell=1}^d \partial_{x_\ell x_\ell} u$ ；
- 热方程写为  $u_t = \kappa \Delta u$ ,  $\kappa > 0$ ；
- Poisson 方程通常写为  $-\Delta u = f$ 。

#### 易错点与反例

不能把双曲问题中的  $\frac{\tau}{h}$  与抛物问题中的  $\frac{\tau}{h^2}$  统称为同一个“CFL 数”而不加说明。前者来自有限传播速度；后者通常来自离散扩散算子的特征值规模  $O(h^{-2})$ 。



## 15.1.3 知识点三：离散范数

对一维网格函数  $v = \{v_j\}$ , 定义

$$\|v\|_{\infty, h} = \max_j |v_j|, \quad (15.7)$$

$$\|v\|_{1, h} = h \sum_j |v_j|, \quad (15.8)$$

$$\|v\|_{2, h} = \left( h \sum_j |v_j|^2 \right)^{1/2}, \quad (15.9)$$

$$\langle v, w \rangle_h = h \sum_j v_j \overline{w_j}. \quad (15.10)$$

二维情形相应定义为

$$\|v\|_{2, h}^2 = h_x h_y \sum_{i, j} |v_{ij}|^2. \quad (15.11)$$

若区间长度为  $L = Jh$ , 则

$$\|v\|_{2, h} \leq L^{1/2} \|v\|_{\infty, h}, \quad (15.12)$$

$$\|v\|_{\infty, h} \leq h^{-1/2} \|v\|_{2, h}. \quad (15.13)$$

第二个等价常数依赖于  $h$ 。

这说明：

每个固定网格上范数等价  $\not\Rightarrow$  网格族上的稳定性可任意转移.

(15.14)

## 15.1.4 知识点四：差分算子

定义时间差分

$$\delta_t^+ V_j^n = V_j^{n+1} - V_j^n, \quad (15.15)$$

$$\delta_t^- V_j^n = V_j^n - V_j^{n-1}, \quad (15.16)$$

$$\delta_t^0 V_j^n = V_j^{n+1} - V_j^{n-1}, \quad (15.17)$$

$$\delta_t^2 V_j^n = V_j^{n+1} - 2V_j^n + V_j^{n-1}. \quad (15.18)$$

定义空间差分

$$D_+ V_j = \frac{V_{j+1} - V_j}{h}, \quad (15.19)$$

$$D_- V_j = \frac{V_j - V_{j-1}}{h}, \quad (15.20)$$

$$D_0 V_j = \frac{V_{j+1} - V_{j-1}}{2h}, \quad (15.21)$$

$$\Delta_h V_j = D_+ D_- V_j = \frac{V_{j+1} - 2V_j + V_{j-1}}{h^2}. \quad (15.22)$$

二维五点离散 Laplace 算子为

$$\Delta_h V_{ij} = \frac{V_{i+1, j} - 2V_{ij} + V_{i-1, j}}{h_x^2} + \frac{V_{i, j+1} - 2V_{ij} + V_{i, j-1}}{h_y^2}. \quad (15.23)$$



Taylor 展开给出

$$D_+ u(x_j) = u_x(x_j) + \frac{h}{2} u_{xx}(x_j) + O(h^2), \quad (15.24)$$

$$D_0 u(x_j) = u_x(x_j) + \frac{h^2}{6} u_{xxx}(x_j) + O(h^4), \quad (15.25)$$

$$\Delta_h u(x_j) = u_{xx}(x_j) + \frac{h^2}{12} u_{xxxx}(x_j) + O(h^4). \quad (15.26)$$

15.1.5 知识点五：模板、显式、隐式与计算复杂度

一个一般线性差分格式可写为

$$\sum_{m=0}^q \sum_{\ell=-r}^s a_{m,\ell}(h, \tau) U_{j+\ell}^{n+m} = F_j^n. \quad (15.27)$$

所有参与计算的网格点集合称为模板或差分模板 (stencil)。

定义 15.3 (显式格式). 若  $U^{n+1}$  可由已知时间层直接逐点计算, 无需解耦合代数方程组, 则称格式为显式格式。

定义 15.4 (隐式格式). 若新时间层的多个空间未知量相互耦合, 每步必须求解线性或非线性代数方程组, 则称格式为隐式格式。

若一层有  $N_h$  个空间未知量, 则:

| 格式类型    | 单步运算复杂度                 | 存储复杂度            | 主要代价或限制            |
|---------|-------------------------|------------------|--------------------|
| 显式局部模板  | 通常 $O(N_h)$             | 两层格式通常 $O(N_h)$  | 常受 CFL 或扩散步长限制     |
| 一维三对角隐式 | Thomas 算法 $O(N_h)$      | $O(N_h)$         | 需组装并求解三对角系统        |
| 二维稀疏隐式  | 每步依赖线性求解器               | $O(N_h)$ 至更高     | 直接法有填充, 迭代法需要预处理   |
| $q$ 层格式 | 每步通常 $O(N_h)$ 或一次稀疏求解   | $O(qN_h)$        | 需 $q-1$ 组起步值并满足根条件 |
| 非线性隐式   | 每个时间步含 Newton/Krylov 迭代 | 依赖 Jacobian 存储策略 | 代数迭代误差必须低于离散误差尺度   |

15.2 截断误差、相容性与收敛性

15.2.1 知识点六：本文的截断误差主约定

考虑连续方程

$$\mathcal{L}u = f \quad (15.28)$$


和离散格式

$$\mathcal{L}_{h,\tau} U = f_{h,\tau}. \quad (15.29)$$

本文统一定义归一化局部截断误差为

$$\mathcal{T}_{h,\tau}(u) = \mathcal{L}_{h,\tau}(R_{h,\tau}u) - R_{h,\tau}(\mathcal{L}u).$$

(15.30)



它与原 PDE 具有相同量纲。

若

$$\|\mathcal{T}_{h,\tau}(u)\| \leq C(\tau^p + h^q), \quad (15.31)$$

则称格式在时间  $p$  阶、空间  $q$  阶相容，或简称具有相容阶  $(p, q)$ 。

对一步格式

$$U^{n+1} = S_{h,\tau}U^n + \tau F_h^n, \quad (15.32)$$

也常定义一步缺陷

$$d^n = R_h u(t_{n+1}) - S_{h,\tau}R_h u(t_n) - \tau F_h^n. \quad (15.33)$$

两种约定的换算为

$$\boxed{d^n = \tau \mathcal{T}_{h,\tau}^n(u)}. \quad (15.34)$$

因此若  $\mathcal{T}_{h,\tau} = O(\tau^p + h^q)$ ，则  $d^n = O(\tau^{p+1} + \tau h^q)$ 。

#### 易错点与反例

不同资料中“局部截断误差”可能分别指  $\mathcal{T}_{h,\tau}$  或  $d^n$ 。二者相差一个  $\tau$  因子。

资格考试作答时必须先说明采用哪一种定义，否则“局部误差几阶”可能出现表面矛盾。

### 15.2.2 知识点七：相容性的精确定义

定义 15.5 (相容性). 给定允许的网格族  $\Lambda = \{(h, \tau) : h \rightarrow 0, \tau \rightarrow 0, \text{ 并满足指定网格比限制}\}$ ，若对所有足够光滑的精确解  $u$ ,

$$\max_{t_n \leq T} \|\mathcal{T}_{h,\tau}^n(u)\|_h \rightarrow 0, \quad (h, \tau) \rightarrow (0, 0), \quad (h, \tau) \in \Lambda, \quad (15.35)$$

则称格式与连续方程相容。

相容性必须说明：

- 所用范数；
- 解的正则性；
- 时间和空间步长如何同时趋零；
- 是否包含边界离散；
- 是否要求网格比固定或受限；
- 截断误差估计是否对  $t_n \leq T$  一致。

#### 热方程显式中心格式的局部截断误差

考虑  $u_t = \kappa u_{xx}$  及格式

$$\frac{U_j^{n+1} - U_j^n}{\tau} = \kappa \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{h^2}. \quad (15.36)$$

将精确解代入：

$$\begin{aligned} \mathcal{T}_j^n &= \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{\tau} - \kappa \Delta_h u(x_j, t_n) \\ &= u_t + \frac{\tau}{2} u_{tt} + O(\tau^2) - \kappa \left[ u_{xx} + \frac{h^2}{12} u_{xxxx} + O(h^4) \right] \end{aligned}$$

$$= \frac{\tau}{2} u_{tt} - \frac{\kappa h^2}{12} u_{xxxx} + O(\tau^2 + h^4). \quad (15.37)$$

故其归一化局部截断误差为  $O(\tau + h^2)$ 。

### 15.2.3 知识点八：整体误差与收敛阶

定义整体网格误差

$$e_j^n = U_j^n - u(x_j, t_n). \quad (15.38)$$

定义 15.6 (收敛性). 若对每个固定  $T > 0$ ,

$$\max_{t_n \leq T} \|e^n\|_h \rightarrow 0, \quad (h, \tau) \rightarrow (0, 0), \quad (h, \tau) \in \Lambda, \quad (15.39)$$

则称格式在范数  $\|\cdot\|_h$  下收敛。

若

$$\max_{t_n \leq T} \|e^n\|_h \leq C_T [\tau^p + h^q + \text{初值误差} + \text{边界离散误差}], \quad (15.40)$$

则称整体时间  $p$  阶、空间  $q$  阶收敛。

#### 易错点与反例

1. 局部截断误差不是整体误差；
2. 内部模板相容不表示完整初边值格式相容；
3. 格式相容不自动推出收敛；
4. 稳定格式的整体阶数可能被低阶边界闭合或低阶起步值降低；
5. 无条件稳定不表示对任意  $\tau, h$  都准确。

## 15.3 PDE 差分格式的稳定性

### 15.3.1 知识点九：一步线性格式的稳定性

考虑齐次一步格式

$$U^{n+1} = S_{h,\tau} U^n. \quad (15.41)$$

定义 15.7 (有限时间稳定性). 若对每个固定  $T > 0$ , 存在常数  $K_T$ , 使对所有允许网格和所有满足  $t_n = n\tau \leq T$  的  $n$ ,

$$\|S_{h,\tau}^n\|_h \leq K_T, \quad (15.42)$$

且  $K_T$  与  $h, \tau, n$  无关, 则称格式在  $\|\cdot\|_h$  下稳定。


常用的等价写法为

$$\|S_{h,\tau}^n\|_h \leq K e^{\alpha t_n}. \quad (15.43)$$

若  $\|S_{h,\tau}\|_h \leq 1$ , 则称格式在该范数下为压缩格式或非增格式。

对含源项的格式

$$U^{n+1} = S_{h,\tau} U^n + \tau F^n, \quad (15.44)$$



离散 Duhamel 公式为

$$U^n = S_{h,\tau}^n U^0 + \tau \sum_{m=0}^{n-1} S_{h,\tau}^{n-1-m} F^m. \quad (15.45)$$

稳定性给出

$$\|U^n\|_h \leq K_T \left[ \|U^0\|_h + \tau \sum_{m=0}^{n-1} \|F^m\|_h \right]. \quad (15.46)$$

### 15.3.2 知识点十：隐式格式与传播矩阵

若格式写成

$$A_{h,\tau} U^{n+1} = B_{h,\tau} U^n + \tau F^n, \quad (15.47)$$

则必须先验证  $A_{h,\tau}$  可逆。传播矩阵为

$$\boxed{S_{h,\tau} = A_{h,\tau}^{-1} B_{h,\tau}}. \quad (15.48)$$

公式中出现  $A_{h,\tau}^{-1}$  不表示实现时应显式形成逆矩阵。实际算法每步应求解  $A_{h,\tau} U^{n+1} =$  已知右端。

### 15.3.3 知识点十一：多层格式的增广状态

对  $q$  层格式，应定义增广向量

$$W^n = \begin{pmatrix} U^{n+q-1} \\ U^{n+q-2} \\ \vdots \\ U^n \end{pmatrix}. \quad (15.49)$$

格式可改写为

$$W^{n+1} = \mathcal{G}_{h,\tau} W^n. \quad (15.50)$$

稳定性要求

$$\sup_{n\tau \leq T} \|\mathcal{G}_{h,\tau}^n\| \leq K_T. \quad (15.51)$$

不能只检查某一个时间层的标量放大因子，也不能忽略起步值误差。


### 15.3.4 知识点十二：离散 Grönwall 不等式

引理 15.8 (离散 Grönwall 不等式). 设  $a_n, g_n \geq 0$ , 且

$$a_n \leq A + \tau \sum_{m=0}^{n-1} (\beta a_m + g_m), \quad \beta \geq 0. \quad (15.52)$$

则

$$\boxed{a_n \leq \left( A + \tau \sum_{m=0}^{n-1} g_m \right) e^{\beta t_n}}. \quad (15.53)$$





证明. 令  $G_n = A + \tau \sum_{m=0}^{n-1} g_m$  并定义  $b_n = G_n + \beta \tau \sum_{m=0}^{n-1} a_m$ . 则  $a_n \leq b_n$ , 且

$$\begin{aligned} b_{n+1} &= G_{n+1} + \beta \tau \sum_{m=0}^n a_m \\ &\leq G_{n+1} + \beta \tau \sum_{m=0}^{n-1} a_m + \beta \tau b_n \\ &\leq (1 + \beta \tau) b_n + \tau g_n. \end{aligned} \quad (15.54)$$

迭代并利用  $(1 + \beta \tau)^n \leq e^{\beta n \tau}$  即可得到结论。□

离散 Grönwall 常用于:

- 局部截断误差向整体误差的累积;
- 非压缩格式的有限时间稳定性;
- 变系数和非线性格式;
- 能量估计中低阶项的吸收;
- 有界传播算子的扰动分析。

## 15.4 Lax–Richtmyer 等价定理

### 15.4.1 知识点十三: 定理的精确适用范围

**定理 15.9** (Lax–Richtmyer 等价定理). 考虑一个适定的线性初值问题, 以及一个与之相容的线性差分格式。在统一的连续–离散空间识别、固定有限时间区间和同一网格范数下, 该差分格式收敛, 当且仅当它稳定。

该定理要求:

1. 连续问题是线性的;
2. 连续问题适定;
3. 差分格式是线性的;
4. 格式与连续方程及初始数据相容;
5. 稳定性和收敛性使用一致的范数;
6. 网格空间通过一致有界的限制/延拓算子与连续空间比较;
7. 时间区间  $[0, T]$  固定;
8. 若有边界, 完整边界闭合必须包含在离散算子中。

#### 易错点与反例

Lax 等价定理不能被表述为无条件的“相容性 + 稳定性 = 收敛性”。

以下情形不能直接套用:

- 非线性格式;

- 连续问题不适当;
- 只分析了内部无限网格格式, 未处理边界;
- 稳定性使用  $L^2$  范数, 而收敛性声称在  $L^\infty$  范数下;
- 网格族变化时范数等价常数不一致;
- 只证明了某一个特定精确解的误差趋零;
- 只满足 von Neumann 必要条件但未建立完整边界稳定性。

### 15.4.2 知识点十四: 稳定性推出收敛性

稳定性与相容性推出收敛性. 考虑一步格式  $U^{n+1} = S_{h,\tau}U^n + \tau F^n$ . 令  $u_h^n = R_h u(t_n)$  为精确解在网格上的限制. 按本文截断误差约定,  $u_h^{n+1} = S_{h,\tau}u_h^n + \tau F^n + \tau \mathcal{T}^n$ . 定义误差  $e^n = U^n - u_h^n$ . 两式相减:

$$e^{n+1} = S_{h,\tau}e^n - \tau \mathcal{T}^n. \quad (15.55)$$

递推得到

$$e^n = S_{h,\tau}^n e^0 - \tau \sum_{m=0}^{n-1} S_{h,\tau}^{n-1-m} \mathcal{T}^m. \quad (15.56)$$

若格式稳定,  $\|S_{h,\tau}^r\|_h \leq K_T$ ,  $r\tau \leq T$ . 故

$$\begin{aligned} \|e^n\|_h &\leq K_T \|e^0\|_h + K_T \tau \sum_{m=0}^{n-1} \|\mathcal{T}^m\|_h \\ &\leq K_T \left[ \|e^0\|_h + T \max_{m\tau \leq T} \|\mathcal{T}^m\|_h \right]. \end{aligned} \quad (15.57)$$

初值相容使  $\|e^0\|_h \rightarrow 0$ , 格式相容使  $\max_{m\tau \leq T} \|\mathcal{T}^m\|_h \rightarrow 0$ . 因此  $\max_{n\tau \leq T} \|e^n\|_h \rightarrow 0$ .  $\square$

若  $\|\mathcal{T}^m\|_h \leq C(\tau^p + h^q)$ , 并且初值和边界误差具有同阶, 则

$$\max_{n\tau \leq T} \|e^n\|_h \leq C_T(\tau^p + h^q). \quad (15.58)$$

### 15.4.3 知识点十五: 收敛性推出稳定性的证明框架

必要性不是单纯的代数误差递推, 而需要一致有界原理。

#### 收敛性推出稳定性的标准函数分析框架

通过一致有界的限制和延拓算子, 把连续解算子和数值解算子视为同一 Banach 空间  $X$  上的线性算子:  $E(t): X \rightarrow X$ ,  $E_{h,\tau}(t_n): X \rightarrow X$ . 收敛性意味着对每个固定数据  $v \in X$ ,  $E_{h,\tau}(t_n)v \rightarrow E(t_n)v$ . 连续问题适当, 所以  $\sup_{0 \leq t \leq T} \|E(t)v\| < \infty$ . 故对每个  $v \in X$ ,  $\sup_{\substack{(h,\tau) \in \Lambda \\ t_n \leq T}} \|E_{h,\tau}(t_n)v\| < \infty$ . 由 Banach-Steinhaus 一致有界原理,  $\sup_{\substack{(h,\tau) \in \Lambda \\ t_n \leq T}} \|E_{h,\tau}(t_n)\|_{X \rightarrow X} < \infty$ . 这正是稳定性. 若连续和离散空间不同, 必须额外要求限制/延拓算子的范数对网格一致有界; 否则不能直接应用上述论证。

## 15.5 补充训练题：丘赛 2020 Problem 5——稳定传播算子的有界扰动

### 完整题目叙述

[Yau-2020-Problem-5]

设差分格式

$$u^{n+1} = Bu^n \quad (15.59)$$

是稳定的，且  $C(\tau)$  是一族一致有界的线性算子。证明扰动格式

$$u^{n+1} = [B + \tau C(\tau)] u^n \quad (15.60)$$

仍稳定。

证明. 固定  $T > 0$ . 由原格式稳定, 存在与  $\tau, n$  无关的常数  $K_T$ , 使

$$\|B^m\| \leq K_T, \quad m\tau \leq T. \quad (15.61)$$

由  $C(\tau)$  一致有界, 存在  $L > 0$  使

$$\|C(\tau)\| \leq L. \quad (15.62)$$

记  $S_\tau = B + \tau C(\tau)$ . 不要求  $B$  和  $C(\tau)$  交换. 利用非交换的离散 Duhamel 恒等式

$$S_\tau^n - B^n = \tau \sum_{j=0}^{n-1} B^{n-1-j} C(\tau) S_\tau^j. \quad (15.63)$$

该恒等式可由归纳法证明. 取范数:

$$\begin{aligned} \|S_\tau^n\| &\leq \|B^n\| + \tau \sum_{j=0}^{n-1} \|B^{n-1-j}\| \|C(\tau)\| \|S_\tau^j\| \\ &\leq K_T + \tau K_T L \sum_{j=0}^{n-1} \|S_\tau^j\|. \end{aligned} \quad (15.64)$$

由离散 Grönwall 不等式,

$$\|S_\tau^n\| \leq K_T \exp(K_T L n \tau) \leq K_T \exp(K_T L T). \quad (15.65)$$

右端与  $\tau, n$  无关. 所以扰动格式稳定.  $\square$

注 15.10 (指数型原稳定界). 若原格式满足  $\|B^n\| \leq K e^{\omega n \tau}$ , 则同样可得  $\|(B + \tau C)^n\| \leq K e^{(\omega + \tilde{C}) n \tau}$ , 其中  $\tilde{C}$  只依赖于  $K$  和  $\sup_\tau \|C(\tau)\|$ .

### 易错点与反例

关键条件是扰动带有因子  $\tau$ :  $B + \tau C(\tau)$ . 若改为  $B + C(\tau)$ , 即使  $C(\tau)$  一致有界, 每一步的  $O(1)$  扰动也可能在  $n = O(\tau^{-1})$  步内造成指数爆炸。

此外, 证明中不能假设  $B$  与  $C(\tau)$  可交换。

## 15.6 Fourier 与 von Neumann 稳定性分析

### 15.6.1 知识点十六：标量一步格式的 Fourier 符号

考虑实直线或周期网格上的常系数两层格式

$$\sum_{\ell=-r}^s a_{\ell} U_{j+\ell}^{n+1} = \sum_{\ell=-r}^s b_{\ell} U_{j+\ell}^n. \quad (15.66)$$

取 Fourier 模态

$$U_j^n = \hat{U}^n(\theta) e^{ij\theta}, \quad -\pi \leq \theta \leq \pi. \quad (15.67)$$

定义符号

$$a(\theta) = \sum_{\ell=-r}^s a_{\ell} e^{i\ell\theta}, \quad (15.68)$$

$$b(\theta) = \sum_{\ell=-r}^s b_{\ell} e^{i\ell\theta}. \quad (15.69)$$

若  $a(\theta) \neq 0$ , 则

$$\hat{U}^{n+1} = G(\theta) \hat{U}^n, \quad \boxed{G(\theta) = \frac{b(\theta)}{a(\theta)}}. \quad (15.70)$$

$G(\theta)$  称为增长因子或放大因子。

周期网格上, 离散 Fourier 变换为酉变换。Parseval 恒等式给出

$$\|U^n\|_{2,h}^2 = \sum_{\theta} |\hat{U}^n(\theta)|^2. \quad (15.71)$$

因此

$$\|U^n\|_{2,h} \leq \left( \sup_{\theta} |G(\theta)| \right)^n \|U^0\|_{2,h}. \quad (15.72)$$

**定理 15.11** (标量两层格式的 von Neumann 条件). 对周期问题或 *Cauchy* 问题的常系数标量两层格式, 有限时间  $\ell_h^2$  稳定性的标准条件为

$$\boxed{|G(\theta)| \leq 1 + C\tau, \quad \forall \theta}. \quad (15.73)$$

若  $C = 0$ , 则格式在  $\ell_h^2$  下为压缩格式。

因为  $(1 + C\tau)^n \leq e^{Cn\tau} \leq e^{CT}$ 。

若网格比固定, 且  $G$  只依赖于网格比和  $\theta$  而不含独立的  $\tau$  小量, 常见判据简化为

$$|G(\theta)| \leq 1. \quad (15.74)$$

### 15.6.2 知识点十七：增长矩阵与非正规情形


对  $m$  分量系统, Fourier 变换后得到

$$\hat{U}^{n+1}(\theta) = G(\theta) \hat{U}^n(\theta), \quad G(\theta) \in \mathbb{C}^{m \times m}. \quad (15.75)$$

稳定性的正确条件是

$$\boxed{\sup_{\theta} \sup_{n\tau \leq T} \|G(\theta)^n\|_2 \leq K_T}. \quad (15.76)$$

只检查  $\rho(G(\theta)) \leq 1$  一般不充分。



反例 15.12 (谱半径为 1 但幂不一致有界). 取

$$G = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}. \quad (15.77)$$

则  $\rho(G) = 1$ , 但

$$G^n = \begin{pmatrix} 1 & n \\ 0 & 1 \end{pmatrix}. \quad (15.78)$$

当  $n \sim T/\tau$  时,  $\|G^n\| = O(\tau^{-1})$ , 故格式不稳定。

若  $G(\theta)$  正规, 则  $\|G(\theta)^n\|_2 = \rho(G(\theta))^n$ , 此时特征值模条件充分。

若  $G(\theta) = V(\theta)\Lambda(\theta)V(\theta)^{-1}$  且

$$\sup_{\theta} \kappa_2(V(\theta)) < \infty, \quad (15.79)$$

则统一特征值模条件也可推出稳定性。

#### 易错点与反例

对耦合系统, 必须区分:

- 标量增长因子;
- 矩阵增长因子;
- 增长矩阵的特征值;
- 增长矩阵幂的范数;
- 正规与非正规增长矩阵。

### 15.6.3 知识点十八: 多层格式的根条件

对每个 Fourier 频率,  $q$  层格式化为标量递推

$$\sum_{m=0}^q a_m(\theta) \hat{U}^{n+m} = 0. \quad (15.80)$$

其特征多项式为


$$P(z; \theta) = \sum_{m=0}^q a_m(\theta) z^m. \quad (15.81)$$

定义 15.13 (Fourier 根条件). 若对所有允许频率  $\theta$ :

1. 所有根满足  $|z_\ell(\theta)| \leq 1$ ;
2. 位于单位圆上的根均为单根;
3. 条件对  $\theta$  和网格参数一致;

则称该多层格式满足根条件。

若存在重单位根, 例如  $P(z) = (z-1)^2$ , 则递推解包含  $c_1 + c_2 n$ 。由于  $n = O(\tau^{-1})$ , 即使没有指数增长, 也不满足网格一致稳定性。



### 15.6.4 知识点十九: von Neumann 方法的适用边界

von Neumann 分析最自然地适用于:

- 常系数;
- 无限网格 Cauchy 问题;
- 周期边界问题;
- 均匀网格;
- 线性格式。

对有限区间边界问题, 内部增长因子条件通常只是必要条件, 因为边界闭合可能:

- 产生额外边界模态;
- 破坏离散能量;
- 导致入流边界条件数目错误;
- 产生非正规增长;
- 降低整体精度。

因此正式答题时应写:

“以下 von Neumann 分析针对 Cauchy 问题或周期问题。若题目为有限区间初边值问题, 还需单独检查边界稳定性。”

## 15.7 能量法与离散分部积分

### 15.7.1 知识点二十: 离散 summation by parts

在周期边界或齐次 Dirichlet 边界下, 有离散分部积分恒等式

$$\langle D_+ v, w \rangle_h = -\langle v, D_- w \rangle_h, \quad (15.82)$$

$$\langle D_0 v, w \rangle_h = -\langle v, D_0 w \rangle_h, \quad (15.83)$$


$$\langle \Delta_h v, v \rangle_h = -\|D_+ v\|_{2,h}^2. \quad (15.84)$$

证明. 以周期情形为例:

$$\begin{aligned} \langle D_+ v, w \rangle_h &= \sum_j (v_{j+1} - v_j) \overline{w_j} \\ &= \sum_j v_j \overline{w_{j-1}} - \sum_j v_j \overline{w_j} \\ &= -\sum_j v_j (\overline{w_j} - \overline{w_{j-1}}) \\ &= -\langle v, D_- w \rangle_h. \end{aligned} \quad (15.85)$$

再取  $w = D_+ v$  即得  $\langle D_- D_+ v, v \rangle_h = -\|D_+ v\|_{2,h}^2$ 。

□



### 15.7.2 知识点二十一：半离散对流与扩散能量

对周期半离散对流方程

$$\frac{dU}{dt} + aD_0U = 0, \quad (15.86)$$

有

$$\frac{1}{2} \frac{d}{dt} \|U\|_{2,h}^2 = -a \operatorname{Re} \langle D_0U, U \rangle_h = 0. \quad (15.87)$$

这是因为  $D_0$  在周期离散内积下反 Hermitian。

对半离散热方程

$$\frac{dU}{dt} = \kappa \Delta_h U, \quad (15.88)$$

有

$$\boxed{\frac{1}{2} \frac{d}{dt} \|U\|_{2,h}^2 = -\kappa \|D_+U\|_{2,h}^2 \leq 0}. \quad (15.89)$$

### 15.7.3 知识点二十二：后向 Euler 热格式的离散能量

考虑

$$\frac{U^{n+1} - U^n}{\tau} = \kappa \Delta_h U^{n+1}. \quad (15.90)$$

与  $2\tau U^{n+1}$  作离散内积。利用

$$2 \operatorname{Re} \langle a - b, a \rangle = \|a\|^2 - \|b\|^2 + \|a - b\|^2, \quad (15.91)$$

得到

$$\begin{aligned} \|U^{n+1}\|_{2,h}^2 - \|U^n\|_{2,h}^2 + \|U^{n+1} - U^n\|_{2,h}^2 \\ + 2\kappa\tau \|D_+U^{n+1}\|_{2,h}^2 = 0. \end{aligned} \quad (15.92)$$

因此

$$\boxed{\|U^{n+1}\|_{2,h} \leq \|U^n\|_{2,h}}. \quad (15.93)$$

该估计不需要  $\tau \leq Ch^2$ 。

#### 易错点与反例

“无条件稳定”只表示稳定性估计不要求时间步长与空间步长满足某个上界关系。它不表示：

- 任意大时间步都准确；
- 相位误差或数值耗散很小；
- 非线性代数方程可随意粗略求解；
- 边界离散必然稳定；
- 条件数与计算成本不随  $\tau, h$  变化。



## 15.7.4 知识点二十三：能量法标准答题框架

识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 差分算子呈对称、反对称或正负定结构；
- 题目要求  $L^2$  稳定；
- 边界为周期或齐次边界；
- 格式为耦合系统或 von Neumann 计算过于复杂。

构造步骤：

1. 把格式写成算子形式；
2. 与新时间层、平均时间层或恰当伴随变量作离散内积；
3. 使用离散分部积分；
4. 使用  $2\langle a-b, a \rangle = \|a\|^2 - \|b\|^2 + \|a-b\|^2$ ；
5. 处理边界通量；
6. 用 Young 不等式和离散 Grönwall 控制源项及低阶项。

关键估计：构造离散能量  $E^n$  使  $E^{n+1} - E^n + \tau D^{n+1} \leq C\tau E^{n+1} + \tau \|F^n\|^2$ ，其中  $D^{n+1} \geq 0$  为耗散项。

结论：在吸收低阶项后， $E^n \leq C_T (E^0 + \tau \sum_{m < n} \|F^m\|^2)$ 。

常见失败原因：

- 忘记边界项；
- 使用了不适合的测试函数；
- 把非对称算子当作反对称算子；
- 忽略系数变号；
- 用连续分部积分代替离散 summation by parts。

## 15.8 CFL 条件与依赖域

## 15.8.1 知识点二十四：连续依赖域

对常系数一维对流方程


$$u_t + au_x = 0, \quad u(x, 0) = u_0(x), \quad (15.94)$$

精确解为

$$u(x, t) = u_0(x - at). \quad (15.95)$$

因此点  $(x_j, t_n)$  的连续依赖域在初始时刻退化为

$$x_j - at_n. \quad (15.96)$$



### 15.8.2 知识点二十五：数值依赖域

设显式格式每一步使用上一时间层的  $U_{j-r}^n, \dots, U_{j+s}^n$ 。经过  $n$  步， $U_j^n$  至多依赖初始层区间

$$x \in [x_j - rnh, x_j + snh]. \quad (15.97)$$

若格式收敛，连续依赖点必须落在数值依赖域内。因此必要条件为

$$-r \leq -\frac{a\tau}{h} \leq s. \quad (15.98)$$

等价地，

$$-s \leq \nu \leq r, \quad \nu = \frac{a\tau}{h}. \quad (15.99)$$

对三点对称模板  $r = s = 1$ ，必要条件为

$$|\nu| \leq 1. \quad (15.100)$$

对  $a > 0$  的左迎风模板  $\{j-1, j\}$ ，必要条件为

$$0 \leq \nu \leq 1. \quad (15.101)$$

### 15.8.3 知识点二十六：CFL 只是必要条件

**定理 15.14** (CFL 必要性原理). 对具有有限传播速度的双曲问题，若显式差分格式收敛，则在网格细化极限中，连续问题的依赖域必须包含于数值格式的依赖域。

#### 证明思路

若连续依赖点落在数值依赖域之外，可构造两组初始数据：

- 它们在数值依赖域内完全相同；
- 它们在连续特征线脚点附近不同。

由于数值格式只能读取数值依赖域，两组数值解在  $(x_j, t_n)$  完全相同；但精确解在该点不同。这与对两组数据均收敛矛盾。

#### 易错点与反例

满足 CFL 条件不自动意味着稳定。

CFL 只检查“信息传播速度是否可能正确”。格式仍可能因增长因子模大于 1、非正规增长、边界闭合错误或根条件失败而不稳定。

下面的 FTCS 对流题就是标准反例。

## 15.9 补充训练题——FTCS 对流格式

#### 完整题目叙述

[FDM-Set-2015I-Q9]

考虑线性双曲方程

$$u_t + au_x = 0, \quad t \geq 0, \quad (15.102)$$

其中  $a$  为常数。使用时间向前、空间中心格式

$$\frac{U_j^{n+1} - U_j^n}{k} + a \frac{U_{j+1}^n - U_{j-1}^n}{2h} = 0. \quad (15.103)$$

- (i) 当固定  $r = \frac{k}{h} > 0$  时, 证明格式与原方程相容;
- (ii) 分析稳定性. 固定  $r$  时格式是否稳定?
- (iii) 若允许  $r$  随网格变小, 结论如何改变?
- (iv) 即使通过非常小的  $r$  使格式稳定, 它是否是一个好的格式? 给出一个在固定双曲网格比下稳定的简单修正。

第 (i) 问: 相容性. 将精确解代入格式. Taylor 展开给出

$$\frac{u(x_j, t_n + k) - u(x_j, t_n)}{k} = u_t + \frac{k}{2} u_{tt} + O(k^2), \quad (15.104)$$

$$\frac{u(x_j + h, t_n) - u(x_j - h, t_n)}{2h} = u_x + \frac{h^2}{6} u_{xxx} + O(h^4). \quad (15.105)$$

故归一化截断误差为

$$\begin{aligned} \mathcal{T}_j^n &= u_t + au_x + \frac{k}{2} u_{tt} + \frac{ah^2}{6} u_{xxx} + O(k^2 + h^4) \\ &= \frac{k}{2} u_{tt} + \frac{ah^2}{6} u_{xxx} + O(k^2 + h^4). \end{aligned} \quad (15.106)$$

因此

$$\mathcal{T}_j^n = O(k + h^2). \quad (15.107)$$

若  $k = rh$ ,  $r > 0$  固定, 则  $\mathcal{T}_j^n = O(h)$ , 所以格式相容.  $\square$

第 (ii) 问: 固定网格比时不稳定. 令

$$\nu = \frac{ak}{h} = ar. \quad (15.108)$$

格式写成

$$U_j^{n+1} = U_j^n - \frac{\nu}{2} (U_{j+1}^n - U_{j-1}^n). \quad (15.109)$$

代入 Fourier 模态  $U_j^n = \hat{U}^n e^{ij\theta}$  得到增长因子

$$\begin{aligned} G(\theta) &= 1 - \frac{\nu}{2} (e^{i\theta} - e^{-i\theta}) \\ &= 1 - i\nu \sin \theta. \end{aligned} \quad (15.110)$$

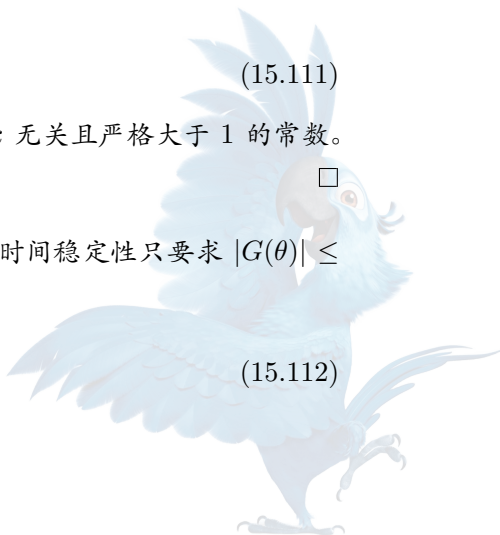
于是

$$|G(\theta)|^2 = 1 + \nu^2 \sin^2 \theta. \quad (15.111)$$

只要  $\nu \neq 0$ , 取  $\theta = \frac{\pi}{2}$  即有  $|G(\theta)| > 1$ . 当  $r$  固定时,  $|G(\pi/2)|$  为与  $h, k$  无关且严格大于 1 的常数. 而  $n = \frac{T}{k} \rightarrow \infty$ . 故  $|G(\pi/2)|^n \rightarrow \infty$ . 因此格式在固定非零  $r$  下不稳定.  $\square$

第 (iii) 问: 允许网格比趋零. 尽管每一步都有  $|G(\theta)| > 1$  的频率, 有限时间稳定性只要求  $|G(\theta)| \leq 1 + Ck$ . 由式 (15.111),

$$|G(\theta)|^2 \leq 1 + a^2 \frac{k^2}{h^2}. \quad (15.112)$$



若存在与网格无关的  $C_0$  使

$$k \leq C_0 h^2, \quad (15.113)$$

则  $\frac{k^2}{h^2} \leq C_0 k$ 。从而  $|G(\theta)|^2 \leq 1 + a^2 C_0 k \leq e^{a^2 C_0 k}$ 。因此对  $nk \leq T$ ,

$$|G(\theta)|^{2n} \leq e^{a^2 C_0 nk} \leq e^{a^2 C_0 T}. \quad (15.114)$$

所以在非标准的抛物型限制  $k = O(h^2)$  下, FTCS 对流格式可在  $\ell_h^2$  中有限时间稳定。

反之, 若  $\frac{k}{h^2} \rightarrow \infty$ , 则:

- 若  $k/h$  不趋零, 已由第 (ii) 问知不稳定;
- 若  $k/h \rightarrow 0$ , 则对  $\theta = \pi/2$ ,  $\log |G| = \frac{1}{2} \log(1 + a^2 k^2 / h^2) \sim \frac{a^2 k^2}{2h^2}$ . 因而  $\frac{T}{k} \log |G| \sim \frac{a^2 T}{2} \frac{k}{h^2} \rightarrow \infty$ .

所以稳定性的本质约束为  $\frac{k}{h^2} = O(1)$ 。  $\square$

第 (iv) 问: 格式评价与稳定修正. 虽然格式可在  $k = O(h^2)$  下稳定, 但它不是求解双曲对流问题的理想格式:

1. 双曲问题本应允许  $k = O(h)$ ;
2. 该格式却要求  $k = O(h^2)$ , 总时间步数从  $O(h^{-1})$  增至  $O(h^{-2})$ ;
3. 每个非零频率的放大因子模均大于 1, 格式缺少单调性;
4. 对高频扰动非常敏感。

一个简单修正是 Lax-Friedrichs 格式:

$$U_j^{n+1} = \frac{1}{2} (U_{j+1}^n + U_{j-1}^n) - \frac{\nu}{2} (U_{j+1}^n - U_{j-1}^n). \quad (15.115)$$

其增长因子为

$$G_{\text{LF}}(\theta) = \cos \theta - i\nu \sin \theta. \quad (15.116)$$

故

$$\begin{aligned} |G_{\text{LF}}(\theta)|^2 &= \cos^2 \theta + \nu^2 \sin^2 \theta \\ &= 1 - (1 - \nu^2) \sin^2 \theta. \end{aligned} \quad (15.117)$$

当


$$|\nu| = \left| \frac{ak}{h} \right| \leq 1 \quad (15.118)$$

时,  $|G_{\text{LF}}(\theta)| \leq 1$ 。因此该格式在固定双曲网格比下  $\ell_h^2$  稳定。

若  $a > 0$ , 也可采用一阶迎风格式

$$U_j^{n+1} = U_j^n - \nu (U_j^n - U_{j-1}^n), \quad 0 \leq \nu \leq 1. \quad (15.119)$$

$\square$



## 15.10 离散最大值原理、单调性与逆正性

### 15.10.1 知识点二十七：一般离散最大值原理

设内部网格点集合为  $\Omega_h^\circ$ ，边界网格点集合为  $\partial\Omega_h$ 。考虑离散算子

$$(L_h v)_i = c_i v_i - \sum_{j \in \mathcal{N}(i)} c_{ij} v_j, \quad c_{ij} \geq 0, \quad (15.120)$$

并假设

$$d_i := c_i - \sum_{j \in \mathcal{N}(i)} c_{ij} \geq 0. \quad (15.121)$$

若  $v_i = M > 0$  为内部全局最大值，则

$$(L_h v)_i = \sum_{j \in \mathcal{N}(i)} c_{ij} (M - v_j) + d_i M \geq 0. \quad (15.122)$$

因此：

- 若  $L_h v < 0$ ，不可能在内部取得正最大值；
- 若  $L_h v \leq 0$  且内部取得正最大值，则所有相邻差值和  $d_i M$  必须同时为零；
- 在网格连通条件下，最大值会向邻点传播；
- 若某处  $d_i > 0$ ，则正内部最大值直接导致矛盾。

**定理 15.15** (弱离散最大值原理). 若  $L_h v \leq 0$  在  $\Omega_h^\circ$ ，且算子满足式 (15.120) and (15.121)，则

$$\max_{\Omega_h} v \leq \max \left\{ 0, \max_{\partial\Omega_h} v \right\}, \quad (15.123)$$

除非存在由零行余量连接成的常数平台。

对  $-v$  应用同一结论可得最小值原理。

### 15.10.2 知识点二十八：稳定性估计

若进一步

$$d_i > 0 \quad \forall i \in \Omega_h^\circ, \quad (15.124)$$

且  $L_h v = \phi$ ,  $v|_{\partial\Omega_h} = 0$ ，则

$$\|v\|_{\infty, h} \leq \max_{i \in \Omega_h^\circ} \frac{|\phi_i|}{d_i}. \quad (15.125)$$

这是最大范数稳定性。若  $d_i \geq d_0 > 0$  与网格无关，则  $\|v\|_{\infty, h} \leq d_0^{-1} \|\phi\|_{\infty, h}$ 。

矩阵观点中， $L_h$  的系数矩阵具有：

- 正对角元；
- 非正非对角元；
- 对角占优；
- 在适当连通和严格性条件下逆矩阵非负。

这与  $M$  矩阵理论密切相关，将在第 16 部分用于 Poisson 方程和变系数椭圆问题。



### 易错点与反例

离散最大值原理不是所有中心差分格式自动具有的性质。

对流项、反应项和非均匀网格会改变系数符号。只有当所有相邻点系数具有正确符号，且中心系数满足适当对角占优时，才能使用最大值原理。

## 15.11 正式真题 [24S-Q5]——三点差分最大值原理

完整题目叙述：[24S-Q5]

给定一维网格  $I_h = \{x_j\}_{j=0}^M$ ,  $x_0 < x_1 < \cdots < x_M$ , 以及网格函数  $u = \{u_j\}_{j=0}^M$ 。设

$$Lu_j = -(a_j u_{j-1} - b_j u_j + c_j u_{j+1}) + q_j u_j, \quad j = 1, \dots, M-1, \quad (15.126)$$

其中

$$a_j, b_j, c_j > 0, \quad q_j \geq 0, \quad a_j + c_j \leq b_j. \quad (15.127)$$

1. 假设  $Lu_j \leq 0$ ,  $j = 1, \dots, M-1$ . 证明  $u_j$  不能在内部点取得正最大值，除非  $u_j \equiv C$ ;

2. 设

$$d_j = b_j - a_j - c_j + q_j > 0. \quad (15.128)$$

证明边值问题

$$Lu_j = \phi_j, \quad j = 1, \dots, M-1, \quad u_0 = u_M = 0 \quad (15.129)$$

的解满足

$$\|u\|_\infty = \max_{0 \leq j \leq M} |u_j| \leq \max_{1 \leq j \leq M-1} \frac{|\phi_j|}{d_j}. \quad (15.130)$$

第 (1) 问. 将算子改写为

$$Lu_j = a_j(u_j - u_{j-1}) + c_j(u_j - u_{j+1}) + d_j u_j, \quad (15.131)$$

其中  $d_j = b_j - a_j - c_j + q_j \geq 0$ 。

设  $M_0 = \max_{0 \leq j \leq M} u_j > 0$  在内部点  $j_*$  取得:  $u_{j_*} = M_0$ 。由于  $j_*$  是全局最大点,  $M_0 - u_{j_*-1} \geq 0$ ,  $M_0 - u_{j_*+1} \geq 0$ 。故

$$\begin{aligned} Lu_{j_*} &= a_{j_*}(M_0 - u_{j_*-1}) + c_{j_*}(M_0 - u_{j_*+1}) + d_{j_*} M_0 \\ &\geq 0. \end{aligned} \quad (15.132)$$

另一方面, 假设给出  $Lu_{j_*} \leq 0$ 。所以  $Lu_{j_*} = 0$ 。由于  $a_{j_*} > 0$ ,  $c_{j_*} > 0$ ,  $d_{j_*} \geq 0$ ,  $M_0 > 0$ , 三个非负项必须分别为零:

$$u_{j_*-1} = M_0, \quad (15.133)$$

$$u_{j_*+1} = M_0, \quad (15.134)$$

$$d_{j_*} = 0. \quad (15.135)$$

相邻点  $j_* - 1$  和  $j_* + 1$  也取得同一正全局最大值。对这些点重复上述论证, 最大值沿网格逐点传播。由于一维网格连通, 最终得到  $u_0 = u_1 = \cdots = u_M = M_0$ 。故  $u_j \equiv C$ 。

更准确地说, 若正内部最大值存在, 则除网格函数必须为常数外, 还必须所有相关行  $d_j = 0$ 。□

第 (2) 问. 令

$$C_\phi = \max_{1 \leq j \leq M-1} \frac{|\phi_j|}{d_j}. \quad (15.136)$$

先估计正最大值。若  $\max_j u_j \leq 0$ , 则无需估计。否则, 由于  $u_0 = u_M = 0$ , 正最大值必在某个内部点  $j_*$  取得。记  $u_{j_*} = M_+ > 0$ 。由 式 (15.131),

$$\begin{aligned} \phi_{j_*} &= Lu_{j_*} \\ &= a_{j_*}(M_+ - u_{j_*-1}) + c_{j_*}(M_+ - u_{j_*+1}) + d_{j_*}M_+ \\ &\geq d_{j_*}M_+. \end{aligned} \quad (15.137)$$

因此

$$M_+ \leq \frac{\phi_{j_*}}{d_{j_*}} \leq \frac{|\phi_{j_*}|}{d_{j_*}} \leq C_\phi. \quad (15.138)$$

再估计负最小值。对网格函数  $-u$  有  $L(-u) = -\phi$ 。将上述正最大值估计应用于  $-u$ , 得到

$$-\min_j u_j \leq C_\phi. \quad (15.139)$$

综上,  $|u_j| \leq C_\phi$  对所有  $j$  成立, 即  $\|u\|_\infty \leq \max_j \frac{|\phi_j|}{d_j}$ 。□

推论 15.16 (唯一性). 在  $d_j > 0$  和齐次边界条件下, 差分方程  $Lu = 0$  只有零解。

证明. 在 式 (15.130) 中令  $\phi = 0$ , 得到  $\|u\|_\infty = 0$ 。□

注 15.17 (矩阵与复杂度). 该边值问题对应一个三对角线性系统。其系数矩阵具有:

- 对角元  $b_j + q_j > 0$ ;
- 下对角元  $-a_j < 0$ ;
- 上对角元  $-c_j < 0$ ;
- 严格行对角占优余量  $d_j > 0$ 。

因此矩阵非奇异且逆非负。若直接使用 Thomas 算法, 运算复杂度和存储复杂度均为  $O(M)$ 。

#### 易错点与反例

1. 不能只写  $Lu_{j_*} \geq 0$  就直接得矛盾, 因为题设是  $Lu \leq 0$ , 可能等号成立;
2. 等号情形必须继续证明邻点也取得同一最大值;
3. “除非  $u$  为常数”依赖网格连通性;
4. 第二问必须分别处理正最大值和负最小值;
5. 若  $d_j$  没有严格正下界, 最大范数稳定常数可能随网格退化。



## 15.12 补充训练题——迎风格式与网格范数

完整题目叙述

[FDM-Set-2010T-Q14]

考虑周期边界条件下的对流方程

$$u_t + u_x = 0 \quad (15.140)$$

及迎风差分格式

$$U_j^{n+1} = U_j^n - \lambda (U_j^n - U_{j-1}^n), \quad \lambda = \frac{\tau}{h}. \quad (15.141)$$

稳定性定义为：对  $t_n = n\tau \leq T$ ，存在与  $h, \tau$  无关的常数  $C(T)$  使  $\|U^n\| \leq C(T) \|U^0\|$ 。

(i) 证明当  $0 \leq \lambda \leq 1$  时，格式分别在离散  $L^1$  范数和  $L^2$  范数下稳定；

(ii) 学生 A 认为：每个固定网格上的数值解空间是有限维空间，所以只要在一个范数下证明稳定，利用有限维空间中范数等价性，就能自动推出任意其他范数下的稳定性。

判断该论证是否正确。若不正确，说明错误并给出反例。

第 (i) 问： $L^1$  稳定性。格式可写成

$$U_j^{n+1} = (1 - \lambda)U_j^n + \lambda U_{j-1}^n. \quad (15.142)$$

当  $0 \leq \lambda \leq 1$  时，两个系数非负且和为 1。

因此

$$\begin{aligned} \|U^{n+1}\|_{1,h} &= h \sum_j |(1 - \lambda)U_j^n + \lambda U_{j-1}^n| \\ &\leq (1 - \lambda)h \sum_j |U_j^n| + \lambda h \sum_j |U_{j-1}^n|. \end{aligned} \quad (15.143)$$

周期移位不改变求和： $\sum_j |U_{j-1}^n| = \sum_j |U_j^n|$ 。故

$$\boxed{\|U^{n+1}\|_{1,h} \leq \|U^n\|_{1,h}}. \quad (15.144)$$

递推得到  $\|U^n\|_{1,h} \leq \|U^0\|_{1,h}$ 。 □

第 (i) 问： $L^2$  稳定性。对任意复数  $a, b$  和  $0 \leq \lambda \leq 1$ ，有恒等式

$$\begin{aligned} |(1 - \lambda)a + \lambda b|^2 &= (1 - \lambda)|a|^2 + \lambda|b|^2 \\ &\quad - \lambda(1 - \lambda)|a - b|^2. \end{aligned} \quad (15.145)$$

取  $a = U_j^n$ ,  $b = U_{j-1}^n$ ，并对  $j$  求和：

$$\begin{aligned} \|U^{n+1}\|_{2,h}^2 &= \|U^n\|_{2,h}^2 \\ &\quad - \lambda(1 - \lambda)h \sum_j |U_j^n - U_{j-1}^n|^2. \end{aligned} \quad (15.146)$$


因此

$$\boxed{\|U^{n+1}\|_{2,h} \leq \|U^n\|_{2,h}}. \quad (15.147)$$

Fourier 方法给出同一结论。增长因子为  $G(\theta) = 1 - \lambda + \lambda e^{-i\theta}$ ，且

$$|G(\theta)|^2 = 1 - 4\lambda(1 - \lambda)\sin^2 \frac{\theta}{2} \leq 1. \quad (15.148)$$

□



第 (ii) 问：学生 A 的论证不正确。对每个固定维数  $N$ ，所有范数确实等价。例如在  $\mathbb{R}^N$  中，

$$\|v\|_\infty \leq \|v\|_2 \leq \sqrt{N} \|v\|_\infty. \quad (15.149)$$

但差分格式稳定性要求常数对整个网格族一致，而  $N \sim h^{-1} \rightarrow \infty$ 。等价常数  $\sqrt{N}$  随网格加密发散。

给出明确反例。对每个  $N$ ，令

$$\mathbf{e}_1 = (1, 0, \dots, 0)^\top, \quad (15.150)$$

$$\mathbf{v}_N = \frac{1}{\sqrt{N}}(1, 1, \dots, 1)^\top, \quad (15.151)$$

$$S_N = \mathbf{e}_1 \mathbf{v}_N^\top. \quad (15.152)$$

这是秩一矩阵。其二范数为

$$\|S_N\|_2 = \|\mathbf{e}_1\|_2 \|\mathbf{v}_N\|_2 = 1. \quad (15.153)$$

故算子族在二范数下统一有界。

但其无穷范数为最大绝对行和：

$$\|S_N\|_\infty = \sum_{j=1}^N \frac{1}{\sqrt{N}} = \sqrt{N} \rightarrow \infty. \quad (15.154)$$

所以该算子族在无穷范数下不稳定。

错误在于：有限维范数等价常数依赖于维数，而数值 PDE 分析中的维数随  $h \rightarrow 0$  趋于无穷。

对于当前迎风格式，事实上还可直接证明  $\|U^{n+1}\|_{\infty, h} \leq \|U^n\|_{\infty, h}$ ，因为  $U_j^{n+1}$  是两个旧值的凸组合。但这来自格式本身的单调性，不是由有限维范数等价自动得到。□

## 15.13 矩阵法、边界稳定性与不同稳定工具的关系

### 15.13.1 知识点二十九：矩阵法

有限区间离散后，线性格式常写成

$$U^{n+1} = B_h U^n + \tau F^n + \tau G_\partial^n, \quad (15.155)$$

其中  $G_\partial^n$  表示边界数据贡献。

稳定性要求

$$\|B_h^n\| \leq K_T, \quad n\tau \leq T, \quad (15.156)$$

并控制边界强迫项  $\tau \sum_{m < n} B_h^{n-1-m} G_\partial^m$ 。

若  $B_h$  正规， $\|B_h^n\|_2 = \rho(B_h)^n$ 。若  $B_h$  非正规，仅有  $\rho(B_h) \leq 1$  不充分。还需考虑：

- Jordan 结构；
- 特征向量矩阵条件数；
- 数值域；
- 伪谱；
- 边界诱发的暂态增长。



15.13.2 知识点三十：边界条件的数量和方向

对  $u_t + au_x = 0$ , 若  $a > 0$ , 信息从左向右传播:

- $x = 0$  为入流边界, 必须给定边界数据;
- $x = 1$  为出流边界, 不应无条件再给一个独立连续边界条件;
- 数值模板若在出流边界需要外部虚点, 必须构造数值出流条件。

若  $a < 0$ , 入流和出流方向相反。

易错点与反例

对双曲问题, 边界条件不能像椭圆问题那样在所有边界上任意同时指定。  
边界条件的数量由入射特征数决定。错误的边界条件数目可使连续问题不适定, 或使数值格式产生边界不稳定。

15.13.3 知识点三十一：四类稳定工具的选择

| 分析工具        | 最适用情形                 | 核心对象      | 主要局限            |
|-------------|-----------------------|-----------|-----------------|
| von Neumann | 常系数、均匀网格、周期/Cauchy 问题 | 增长因子或增长矩阵 | 一般边界问题未必充分      |
| 矩阵法         | 有限区间、具体边界闭合           | 传播矩阵幂     | 大矩阵谱和非正规性可能难分析  |
| 能量法         | 对称、反对称、耗散结构           | 离散内积与能量   | 必须正确处理边界项和变系数   |
| 最大值原理       | 单调格式、椭圆/抛物问题          | 系数符号和对角占优 | 高阶中心格式和强对流下可能失效 |

15.14 资格考试稳定性分析的完整答题模板与易错点

| 错误说法或错误做法                | 正确处理                              |
|--------------------------|-----------------------------------|
| 相容格式一定收敛。                | 还需稳定性; FTCS 对流格式在固定 $k/h$ 下是标准反例。 |
| 局部截断误差就是数值解误差。           | 局部误差通过传播算子累积后才形成整体误差。             |
| 稳定性只需对固定网格成立。            | 稳定常数必须对整个网格族一致。                   |
| 所有有限维范数等价, 所以稳定性与范数无关。   | 等价常数可能随网格维数发散。                    |
| $\rho(B_h) \leq 1$ 必然稳定。 | 非正规或缺陷矩阵的幂可能增长。                   |
| 系统格式只需检查增长矩阵的特征值。        | 还需统一控制增长矩阵幂; 正规或统一可对角化条件不可省。      |



| 错误说法或错误做法                   | 正确处理                                 |
|-----------------------------|--------------------------------------|
| von Neumann 稳定即可说明任意边界问题稳定。 | 对有限区间需额外检查数值边界条件。                    |
| CFL 条件满足就一定稳定。              | CFL 通常只是双曲显式格式的必要条件。                 |
| 隐式格式不受 CFL 限制，所以可任意取大步长。    | 无条件稳定不等于无条件准确。                       |
| 无条件稳定意味着没有数值耗散。             | 稳定性与耗散、色散、相位误差是不同概念。                 |
| 最大值原理适用于所有中心差分。             | 必须检查非对角系数符号和中心系数对角占优。                |
| 离散最大值原理与连续最大值原理完全相同。        | 证明对象和条件均不同；离散结论依赖模板系数。               |
| 根都在单位圆内即可。                  | 单位圆上的根必须为单根，并需统一根条件。                 |
| 稳定区域、零稳定性和 PDE 格式稳定性是同一概念。  | 它们分别属于 ODE 绝对稳定、多步法零稳定和 PDE 网格传播稳定性。 |
| 只分析内部模板即可报告整体收敛阶。           | 边界离散和起步格式可能降低整体阶数。                   |
| 能量法中可直接套连续分部积分。             | 必须使用离散 summation by parts，并保留边界通量。   |

五个核心概念的一句话判别

- 适定性：连续 PDE 是否存在、唯一并连续依赖数据；
- 相容性：把光滑精确解代入离散算子后残差是否趋零；
- 稳定性：网格扰动在固定有限时间内是否被一致控制；
- 收敛性：数值解是否在指定范数下趋于精确解；
- CFL：数值依赖域是否足以覆盖连续依赖域。



# 第十六章 椭圆方程有限差分、Poisson 方程、边界条件、离散最大值原理、 $M$ 矩阵与误差估计

## 16.1 椭圆边值问题的统一形式与适定性

### 16.1.1 知识点一：问题对象与主约定

【重要性等级】 **S 级**。考虑有界连通区域  $\Omega \subset \mathbb{R}^d$  上的二阶线性椭圆问题

$$\mathcal{A}u := -\nabla \cdot (K(\mathbf{x})\nabla u) + \mathbf{b}(\mathbf{x}) \cdot \nabla u + c(\mathbf{x})u = f(\mathbf{x}). \quad (16.1)$$

其中  $K(\mathbf{x}) = K(\mathbf{x})^\top$  并满足一致椭圆性：存在常数  $0 < \kappa_0 \leq \kappa_1 < \infty$  使

$$\kappa_0 \|\xi\|_2^2 \leq \xi^\top K(\mathbf{x})\xi \leq \kappa_1 \|\xi\|_2^2, \quad \forall \xi \in \mathbb{R}^d, \quad \forall \mathbf{x} \in \bar{\Omega}. \quad (16.2)$$

三类标准边界条件为：

$$u = g_D \quad \text{在 } \Gamma_D, \quad (16.3)$$

$$-K\nabla u \cdot \mathbf{n} = g_N \quad \text{在 } \Gamma_N, \quad (16.4)$$

$$\alpha u - \beta K\nabla u \cdot \mathbf{n} = g_R \quad \text{在 } \Gamma_R. \quad (16.5)$$

这里  $\mathbf{n}$  为外单位法向量。本文把  $-K\nabla u \cdot \mathbf{n}$  称为向外扩散通量。

#### 易错点与反例

不同资料对 Neumann 数据存在两种约定：

$$\begin{aligned} \partial_{\mathbf{n}} u &= g, \\ -K\nabla u \cdot \mathbf{n} &= g_N. \end{aligned}$$

二者不能静默混用。本文采用通量约定  $-K\nabla u \cdot \mathbf{n} = g_N$ 。若题目直接给出  $\partial_{\mathbf{n}} u = g$ ，必须先按边界方向和扩散系数换算。

### 16.1.2 知识点二：Poisson 方程

本部分的标准 Poisson 问题写为

$$\begin{cases} -\Delta u = f, & \mathbf{x} \in \Omega, \\ u = g, & \mathbf{x} \in \partial\Omega. \end{cases} \quad (16.6)$$

采用  $\Delta = \partial_{xx} + \partial_{yy}$  的符号约定。因此离散矩阵对应  $-\Delta_h$ , 其对角元为正、非对角元为非正。

若采用另一种约定  $\Delta u = f$ , 则离散矩阵整体相差一个负号; 最大值原理中的不等号方向也随之改变。

### 16.1.3 知识点三: 三类边界问题的唯一性差异

**Dirichlet 问题** 若  $\Gamma_D$  具有正测度, 且椭圆算子满足标准 coercivity 或最大值原理条件, 则通常有唯一解。

纯 **Neumann 问题** 对

$$\begin{cases} -\nabla \cdot (K \nabla u) = f, & \mathbf{x} \in \Omega, \\ -K \nabla u \cdot \mathbf{n} = g_N, & \mathbf{x} \in \partial\Omega, \end{cases} \quad (16.7)$$

积分并使用散度定理得到必要兼容条件

$$\boxed{\int_{\Omega} f \, d\mathbf{x} = \int_{\partial\Omega} g_N \, ds}. \quad (16.8)$$

满足兼容条件时, 解只确定到加法常数。

通常再施加

$$\int_{\Omega} u \, d\mathbf{x} = 0 \quad (16.9)$$

以恢复唯一性。

**Robin 问题** 若  $\alpha \geq 0$ ,  $\beta > 0$ , 并且  $\alpha$  在一部分边界上严格为正, 则 Robin 项通常可消除常数零空间并恢复唯一性。

#### 易错点与反例

1. “Neumann 问题矩阵不可逆”不代表数值方法失败; 它反映连续问题本身只确定到常数;
2. 若兼容条件不满足, 不存在精确解; 直接调用线性求解器可能得到大残差、漂移或任意最小二乘解;
3. 固定一个节点  $U_{i_0} = 0$  可以消除代数奇异性, 但会选择一个特定常数规范; 更对称的做法是施加离散零均值条件。

## 16.2 Poisson 方程的五点差分格式


### 16.2.1 知识点四: 网格、格式与截断误差

设  $\Omega = (0, L_x) \times (0, L_y)$ , 取均匀网格

$$x_i = ih_x, \quad h_x = \frac{L_x}{N_x}, \quad i = 0, \dots, N_x, \quad (16.10)$$

$$y_j = jh_y, \quad h_y = \frac{L_y}{N_y}, \quad j = 0, \dots, N_y. \quad (16.11)$$

内部网格点集合为  $\Omega_h^\circ = \{(x_i, y_j) : 1 \leq i \leq N_x - 1, 1 \leq j \leq N_y - 1\}$ 。



定义

$$\delta_x^2 U_{ij} = \frac{U_{i+1,j} - 2U_{ij} + U_{i-1,j}}{h_x^2}, \quad (16.12)$$

$$\delta_y^2 U_{ij} = \frac{U_{i,j+1} - 2U_{ij} + U_{i,j-1}}{h_y^2}. \quad (16.13)$$

Poisson 方程的五点格式为

$$-\delta_x^2 U_{ij} - \delta_y^2 U_{ij} = f_{ij}, \quad (i, j) \in \Omega_h^\circ. \quad (16.14)$$

边界点直接取

$$U_{ij} = g(x_i, y_j), \quad (x_i, y_j) \in \partial\Omega_h. \quad (16.15)$$

若  $u \in C^6(\bar{\Omega})$ , 则

$$\delta_x^2 u(x_i, y_j) = u_{xx}(x_i, y_j) + \frac{h_x^2}{12} u_{xxxx}(x_i, y_j) + O(h_x^4), \quad (16.16)$$

$$\delta_y^2 u(x_i, y_j) = u_{yy}(x_i, y_j) + \frac{h_y^2}{12} u_{yyyy}(x_i, y_j) + O(h_y^4). \quad (16.17)$$

因此归一化截断误差

$$\tau_{ij} := -\delta_x^2 u(x_i, y_j) - \delta_y^2 u(x_i, y_j) - f_{ij} \quad (16.18)$$

满足

$$\tau_{ij} = -\frac{h_x^2}{12} u_{xxxx}(x_i, y_j) - \frac{h_y^2}{12} u_{yyyy}(x_i, y_j) + O(h_x^4 + h_y^4). \quad (16.19)$$

所以内部格式为空间二阶相容。

#### 易错点与反例

公式  $\tau_{ij} = O(h^2)$  成立需要精确解具有足够高的经典导数。

若区域有凹角、系数不光滑或边界数据不相容，即使模板形式上是二阶，解也可能不属于  $C^4$ ，此时不能直接引用经典 Taylor 余项得到全局二阶最大范数误差。

### 16.2.2 知识点五：矩阵形式


令

$$T_m = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix} \in \mathbb{R}^{m \times m}. \quad (16.20)$$

若按固定  $y_j$  逐行排列内部未知量，则五点格式矩阵为

$$A_h = \frac{1}{h_x^2} (I_{N_y-1} \otimes T_{N_x-1}) + \frac{1}{h_y^2} (T_{N_y-1} \otimes I_{N_x-1}). \quad (16.21)$$

每一行至多有五个非零元。非齐次 Dirichlet 边界值应移到右端项。例如在  $i = 1$  处，方程中的  $-\frac{U_{0,j}}{h_x^2}$  移至右端后贡献  $\frac{g(0, y_j)}{h_x^2}$ 。





### 16.2.3 知识点六：对称正定性

定理 16.1 (五点 Dirichlet 矩阵的正定性). 矩阵  $A_h$  为实对称正定矩阵。

证明. 令  $v_{ij}$  为内部网格函数, 并在边界延拓为零。定义离散内积  $\langle v, w \rangle_h = h_x h_y \sum_{i=1}^{N_x-1} \sum_{j=1}^{N_y-1} v_{ij} w_{ij}$ 。利用离散分部积分,

$$\begin{aligned} \langle A_h v, v \rangle_h &= h_x h_y \sum_{i=0}^{N_x-1} \sum_{j=1}^{N_y-1} \left| \frac{v_{i+1,j} - v_{ij}}{h_x} \right|^2 \\ &\quad + h_x h_y \sum_{i=1}^{N_x-1} \sum_{j=0}^{N_y-1} \left| \frac{v_{i,j+1} - v_{ij}}{h_y} \right|^2 \\ &\geq 0. \end{aligned} \quad (16.22)$$

若该值为零, 则所有相邻网格值均相等。由网格连通性和零边界值可知  $v_{ij} = 0$  对全部内部点成立。故  $A_h$  正定。□

由此立即得到:

- 离散 Dirichlet 问题有唯一解;
- 可使用 Cholesky 分解;
- 可使用共轭梯度法;
- 离散能量范数  $\|v\|_{A_h} = \sqrt{\langle A_h v, v \rangle_h}$  与离散  $H_0^1$  半范数等价。

### 16.2.4 知识点七：显式特征值与条件数

一维矩阵  $h^{-2}T_{N-1}$  的特征向量为

$$s_i^{(p)} = \sin \left( \frac{ip\pi}{N} \right), \quad p = 1, \dots, N-1, \quad (16.23)$$

对应特征值为

$$\lambda_p^{(1D)} = \frac{4}{h^2} \sin^2 \left( \frac{p\pi}{2N} \right). \quad (16.24)$$

二维矩阵式 (16.21) 的特征值为

$$\lambda_{pq} = \frac{4}{h_x^2} \sin^2 \left( \frac{p\pi}{2N_x} \right) + \frac{4}{h_y^2} \sin^2 \left( \frac{q\pi}{2N_y} \right). \quad (16.25)$$

对单位正方形且  $h = \frac{1}{N}$ , 有

$$\lambda_{\min}(A_h) = \frac{8}{h^2} \sin^2 \left( \frac{\pi}{2N} \right), \quad (16.26)$$

$$\lambda_{\max}(A_h) = \frac{8}{h^2} \cos^2 \left( \frac{\pi}{2N} \right). \quad (16.27)$$

故

$$\kappa_2(A_h) = \cot^2 \left( \frac{\pi}{2N} \right) \sim \frac{4}{\pi^2 h^2}. \quad (16.28)$$



## 易错点与反例

离散矩阵条件数  $\kappa_2(A_h) = O(h^{-2})$  随网格加密增长，不表示连续 Poisson 问题不适定。它表示：

- 代数系统在欧氏范数下逐渐病态；
- 无预处理 CG 的迭代次数增长；
- 舍入误差和线性求解容差需与离散误差协调；
- 需要多重网格、域分解或其他预处理。

## 16.2.5 知识点八：装配与求解算法

**Algorithm 66** 矩形区域 Poisson 五点格式的稀疏装配与求解

**Input:**  $N_x, N_y$ ; 区域长度  $L_x, L_y$ ; 右端项  $f$ ; Dirichlet 数据  $g$ ; 容差  $\text{tol}$

**Output:** 内部网格解  $U$

- 1: **Initialization:**  $h_x \leftarrow L_x/N_x, h_y \leftarrow L_y/N_y$  建立内部节点到向量指标的映射
- 2: **for**  $j = 1, \dots, N_y - 1$  **do**
- 3:     **for**  $i = 1, \dots, N_x - 1$  **do**
- 4:         在中心位置加入  $\frac{2}{h_x^2} + \frac{2}{h_y^2}$
- 5:         对每个内部相邻点加入  $-\frac{1}{h_x^2}$  或  $-\frac{1}{h_y^2}$
- 6:         若相邻点在 Dirichlet 边界，将  $\frac{g}{h_x^2}$  或  $\frac{g}{h_y^2}$  加到右端项
- 7:     **end for**
- 8: **end for**
- 9: 用稀疏 Cholesky、PCG 或多重网格求解  $A_h U = F$
- 10: 检查真实残差  $\frac{\|F - A_h U\|_2}{\|F\|_2} \leq \text{tol}$
- 11: **Stopping criterion:** 线性系统真实残差达到容差
- 12: **Complexity:** 令  $N_h = (N_x - 1)(N_y - 1)$ 。装配时间和存储均为  $O(N_h)$ ；每次稀疏矩阵-向量乘法为  $O(N_h)$ ；二维嵌套剖分 Cholesky 时间约  $O(N_h^{3/2})$ 、存储约  $O(N_h \log N_h)$ ；优良多重网格可达到  $O(N_h)$  总复杂度

16.3 Poisson 五点格式的离散最大值原理与  $M$  矩阵

## 16.3.1 知识点九：最小值原理与比较原理

令  $(A_h v)_{ij} = -\delta_x^2 v_{ij} - \delta_y^2 v_{ij}$ 。


**定理 16.2** (五点格式的离散最小值原理). 若

$$A_h v \geq 0 \quad \text{在 } \Omega_h^\circ, \quad (16.29)$$

$$v \geq 0 \quad \text{在 } \partial\Omega_h, \quad (16.30)$$

则

$$v \geq 0 \quad \text{在 } \bar{\Omega}_h. \quad (16.31)$$



证明. 反设  $v$  在内部点  $(i_*, j_*)$  取得负全局最小值  $m = v_{i_*, j_*} < 0$ . 由于相邻点均不小于  $m$ ,

$$(A_h v)_{i_*, j_*} = \frac{2m - v_{i_*+1, j_*} - v_{i_*-1, j_*}}{h_x^2} + \frac{2m - v_{i_*, j_*+1} - v_{i_*, j_*-1}}{h_y^2} \leq 0. \quad (16.32)$$

与  $A_h v \geq 0$  结合可知等号成立, 从而四个相邻点也都等于  $m$ . 由网格连通性, 该最小值逐点传播到边界, 与边界非负矛盾.  $\square$

对  $-v$  应用该定理得到离散最大值原理:

推论 16.3 (五点格式的离散最大值原理). 若  $A_h v \leq 0$  在内部, 则

$$\max_{\bar{\Omega}_h} v \leq \max_{\partial\Omega_h} v. \quad (16.33)$$

推论 16.4 (离散比较原理). 若

$$A_h u \leq A_h v \quad \text{在内部,} \quad (16.34)$$

$$u \leq v \quad \text{在边界,} \quad (16.35)$$

则  $u \leq v$  在全部网格点。

证明. 对  $w = v - u$  应用离散最小值原理.  $\square$

### 16.3.2 知识点十: $Z$ 矩阵、 $M$ 矩阵与逆正性

定义 16.5 ( $Z$  矩阵). 若实矩阵  $A = (a_{ij})$  满足  $a_{ij} \leq 0, i \neq j$ , 则称  $A$  为  $Z$  矩阵。

定义 16.6 (非奇异  $M$  矩阵). 若  $Z$  矩阵可写为

$$A = sI - B, \quad B \geq 0, \quad s > \rho(B), \quad (16.36)$$

则称  $A$  为非奇异  $M$  矩阵。

对  $Z$  矩阵, 以下条件等价:

1.  $A$  为非奇异  $M$  矩阵;
2.  $A^{-1} \geq 0$  按分量成立;
3. 存在  $v > 0$  使  $Av > 0$ ;
4.  $A$  的全部特征值实部为正。

五点 Dirichlet 矩阵:

- 对角元为正;
- 非对角元非正;
- 弱对角占优;
- 与边界相邻的行严格对角占优;
- 邻接图连通。



因此它是不可约对角占优的非奇异  $M$  矩阵。又因它对称正定，也称为 Stieltjes 矩阵。

命题 16.7 (离散最大值原理与逆正性的等价关系). 对 Dirichlet 离散系统  $A_h U = F$ , 若  $A_h^{-1} \geq 0$ , 则  $F \geq 0 \implies U \geq 0$ . 反过来, 若对每个  $F \geq 0$  均有  $U \geq 0$ , 则  $A_h^{-1} \geq 0$ .

#### 易错点与反例

以下概念不能混为一谈:

- 对称正定矩阵不一定是  $M$  矩阵;
- $M$  矩阵不一定对称;
- 严格对角占优不是  $M$  矩阵的必要条件;
- 纯 Neumann 离散矩阵通常是奇异  $M$  矩阵, 而不是非奇异  $M$  矩阵;
- 高阶差分矩阵可能是正定的, 但若非对角元出现正值, 离散最大值原理可能失效。

## 16.4 Poisson 五点格式的全局误差估计

### 16.4.1 知识点十一: 障碍函数法

设  $u$  为连续问题精确解,  $U$  为五点格式数值解, 定义

$$e_{ij} = U_{ij} - u(x_i, y_j). \quad (16.37)$$

由  $A_h U = f$  及截断误差定义  $\tau = A_h R_h u - f$  得到

$$A_h e = -\tau, \quad e = 0 \quad \text{在边界}. \quad (16.38)$$

取障碍函数

$$\psi(x, y) = \frac{1}{2}x(L_x - x). \quad (16.39)$$

它满足

$$\psi \geq 0 \quad \text{在 } \bar{\Omega}, \quad (16.40)$$

$$A_h \psi = 1 \quad \text{在内部}, \quad (16.41)$$

$$\max_{\bar{\Omega}} \psi = \frac{L_x^2}{8}. \quad (16.42)$$

第二个等式是精确的, 因为五点二阶差分对二次多项式精确。

令  $M_\tau = \|\tau\|_{\infty, h}$ . 定义

$$z^+ = M_\tau \psi + e, \quad (16.43)$$

$$z^- = M_\tau \psi - e. \quad (16.44)$$

则

$$A_h z^+ = M_\tau - \tau \geq 0, \quad (16.45)$$

$$A_h z^- = M_\tau + \tau \geq 0. \quad (16.46)$$



在边界上,  $z^\pm = M_\tau \psi \geq 0$ 。由离散最小值原理,  $z^\pm \geq 0$ 。故  $-M_\tau \psi \leq e \leq M_\tau \psi$ 。因此

$$\|e\|_{\infty, h} \leq \frac{L_x^2}{8} \|\tau\|_{\infty, h}. \quad (16.47)$$

同样可选择  $\psi(y) = \frac{1}{2}y(L_y - y)$ , 故得到更优的

$$\|e\|_{\infty, h} \leq \frac{\min\{L_x^2, L_y^2\}}{8} \|\tau\|_{\infty, h}. \quad (16.48)$$

结合式 (16.19), 得到

$$\|U - R_h u\|_{\infty, h} \leq C(h_x^2 + h_y^2). \quad (16.49)$$

### 16.4.2 知识点十二: 边界误差的影响

若边界值并非精确给定, 而满足  $\|U - g\|_{\infty, \partial\Omega_h} \leq E_{\partial, h}$ , 则对障碍函数加常数后可得

$$\|e\|_{\infty, h} \leq E_{\partial, h} + C_\Omega \|\tau\|_{\infty, h}. \quad (16.50)$$

因此整体收敛阶为内部格式阶和边界离散阶的较低者。

#### 易错点与反例

内部五点格式是二阶, 不自动保证整个边值问题二阶。

若边界闭合只有一阶, 则最大范数整体误差通常至多一阶, 除非存在可证明的边界超收敛或误差局部化机制。

### 16.4.3 知识点十三: 离散能量误差

定义离散  $H^1$  半范数

$$|v|_{1, h}^2 = h_x h_y \sum_{i=0}^{N_x-1} \sum_{j=1}^{N_y-1} \left| \frac{v_{i+1, j} - v_{ij}}{h_x} \right|^2 + h_x h_y \sum_{i=1}^{N_x-1} \sum_{j=0}^{N_y-1} \left| \frac{v_{i, j+1} - v_{ij}}{h_y} \right|^2. \quad (16.51)$$

误差方程与  $e$  作离散内积:

$$\begin{aligned} |e|_{1, h}^2 &= \langle A_h e, e \rangle_h \\ &= -\langle \tau, e \rangle_h \\ &\leq \|\tau\|_{2, h} \|e\|_{2, h}. \end{aligned} \quad (16.52)$$

离散 Poincaré 不等式给出  $\|e\|_{2, h} \leq C_P |e|_{1, h}$ 。所以

$$|e|_{1, h} \leq C_P \|\tau\|_{2, h}. \quad (16.53)$$

若  $\|\tau\|_{2, h} = O(h^2)$ , 则

$$|e|_{1, h} = O(h^2), \quad \|e\|_{2, h} = O(h^2). \quad (16.54)$$

这里比较的是网格点误差与离散导数, 不是有限元中“分片线性函数对真实梯度”的标准  $H^1$  误差。两类结论不能直接混写。

### 16.4.4 证明套路: 最大值原理误差估计



## 识别信号—构造步骤—关键估计—结论—失败原因

识别信号:

- 离散矩阵非对角元非正;
- 题目要求  $\ell^\infty$  误差;
- 右端截断误差有统一上界;
- Dirichlet 边界误差已知。

构造步骤:

1. 写误差方程  $A_h e = \pm \tau$ ;
2. 找非负障碍函数  $\psi$  满足  $A_h \psi \geq 1$ ;
3. 令  $z^\pm = M\psi \pm e$ ;
4. 验证  $A_h z^\pm \geq 0$  及边界  $z^\pm \geq 0$ ;
5. 应用离散最小值原理。

关键估计:  $|e| \leq M\psi$ ,  $M = \|\tau\|_\infty$ 。结论:  $\|e\|_\infty \leq \|\psi\|_\infty \|\tau\|_\infty$ 。

失败原因:

- 模板不单调;
- 障碍函数在边界不能控制误差;
- 反应项符号错误;
- Neumann 问题存在常数零空间;
- 精确解正则性不足。

## 16.5 基础例题: 一维 Poisson 问题的精确离散误差

## 完整题目叙述

考虑

$$\begin{cases} -u''(x) = \pi^2 \sin(\pi x), & 0 < x < 1, \\ u(0) = u(1) = 0. \end{cases} \quad (16.55)$$

在均匀网格  $x_i = ih$ ,  $h = \frac{1}{N}$  上使用中心差分格式。

1. 求离散解的显式表达;
2. 证明最大范数误差为  $O(h^2)$ ;
3. 写出主要误差常数。

证明. 连续精确解为  $u(x) = \sin(\pi x)$ . 令  $s_i = \sin(\pi ih)$ . 一维离散负 Laplace 算子满足

$$-\delta_h^2 s_i = \frac{2s_i - s_{i-1} - s_{i+1}}{h^2}$$

$$= \frac{4}{h^2} \sin^2 \left( \frac{\pi h}{2} \right) s_i. \quad (16.56)$$

记

$$\lambda_h = \frac{4}{h^2} \sin^2 \left( \frac{\pi h}{2} \right). \quad (16.57)$$

离散系统右端为  $\pi^2 s_i$ , 所以

$$U_i = \frac{\pi^2}{\lambda_h} \sin(\pi i h). \quad (16.58)$$

由  $\sin^2 z = z^2 - \frac{z^4}{3} + \frac{2z^6}{45} + O(z^8)$  得到

$$\lambda_h = \pi^2 - \frac{\pi^4}{12} h^2 + \frac{\pi^6}{360} h^4 + O(h^6). \quad (16.59)$$

因此

$$\frac{\pi^2}{\lambda_h} = 1 + \frac{\pi^2}{12} h^2 + O(h^4). \quad (16.60)$$

于是

$$U_i - u(x_i) = \left[ \frac{\pi^2}{\lambda_h} - 1 \right] \sin(\pi i h), \quad (16.61)$$

从而

$$\|U - R_h u\|_{\infty, h} = \frac{\pi^2}{12} h^2 + O(h^4) \quad (16.62)$$

在网格中包含或逼近  $x = 1/2$  时成立。  $\square$

## 16.6 九点格式与四阶 Poisson 离散

### 16.6.1 知识点十四：九点离散 Laplace 算子

在正方形均匀网格  $h_x = h_y = h$  上, 定义九点算子

$$\begin{aligned} \Delta_{9,h} U_{ij} = \frac{1}{6h^2} & \left[ 4(U_{i+1,j} + U_{i-1,j} + U_{i,j+1} + U_{i,j-1}) \right. \\ & \left. + U_{i+1,j+1} + U_{i+1,j-1} + U_{i-1,j+1} + U_{i-1,j-1} - 20U_{ij} \right]. \end{aligned} \quad (16.63)$$

Taylor 展开给出

$$\Delta_{9,h} u = \Delta u + \frac{h^2}{12} \Delta^2 u + O(h^4). \quad (16.64)$$

因此, 若只写  $-\Delta_{9,h} U = f$ , 一般仍然只有二阶精度。

对  $-\Delta u = f$  有  $\Delta^2 u = -\Delta f$ . 所以四阶修正格式为

$$-\Delta_{9,h} U_{ij} = f_{ij} + \frac{h^2}{12} \Delta_h f_{ij}. \quad (16.65)$$

其中  $\Delta_h f$  可用五点二阶差分计算。由于该误差再乘  $h^2$ , 右端修正仍保持  $O(h^4)$  精度。

命题 16.8 (九点格式的单调性). 矩阵  $-\Delta_{9,h}$  具有:

- 正中心系数  $\frac{20}{6h^2}$ ;
- 四个轴向邻点系数  $-\frac{4}{6h^2}$ ;





- 四个对角邻点系数  $-\frac{1}{6h^2}$ ;
- 行和为零。

配合 *Dirichlet* 边界后, 其内部矩阵为非奇异  $M$  矩阵, 故仍满足离散最大值原理。

#### 易错点与反例

九点格式获得四阶精度必须同时处理:

1. 内部算子展开中的  $\frac{h^2}{12}\Delta^2 u$ ;
2. 利用 PDE 把  $\Delta^2 u$  转成  $\Delta f$ ;
3. 右端修正;
4. 与四阶精度相匹配的边界闭合。

只增加对角网格点而不修正右端, 不能自动得到四阶 Poisson 格式。

#### 四阶九点格式的误差结论

设  $u \in C^8(\bar{\Omega})$ ,  $f \in C^6(\bar{\Omega})$ , 边界值精确给定, 并且所有靠近边界的闭合也保持四阶。则修正九点格式满足  $\|U - R_h u\|_{\infty, h} \leq Ch^4$ 。证明仍采用:

1. 四阶截断误差;
2. 九点矩阵的  $M$  矩阵性质;
3. 离散障碍函数;
4. 比较原理。

## 16.7 变系数散度型椭圆方程的保守离散

### 16.7.1 知识点十五: 为什么使用通量形式

考虑

$$-\nabla \cdot (a(\mathbf{x})\nabla u) + c(\mathbf{x})u = f, \quad a(\mathbf{x}) \geq a_0 > 0, \quad c(\mathbf{x}) \geq 0. \quad (16.66)$$

若把主项展开为  $-a\Delta u - \nabla a \cdot \nabla u$ , 则必须计算  $\nabla a$ 。当系数只以函数值、实验数据或分片常数形式给出时, 这种展开既不方便, 也可能破坏界面通量守恒。


应直接离散通量  $a\nabla u$ 。

在二维均匀网格上, 定义面系数

$$a_{i+\frac{1}{2},j}, \quad a_{i-\frac{1}{2},j}, \quad a_{i,j+\frac{1}{2}}, \quad a_{i,j-\frac{1}{2}}. \quad (16.67)$$

保守格式为

$$\begin{aligned} (A_h U)_{ij} = & -\frac{1}{h_x} \left[ a_{i+\frac{1}{2},j} \frac{U_{i+1,j} - U_{ij}}{h_x} - a_{i-\frac{1}{2},j} \frac{U_{ij} - U_{i-1,j}}{h_x} \right] \\ & -\frac{1}{h_y} \left[ a_{i,j+\frac{1}{2}} \frac{U_{i,j+1} - U_{ij}}{h_y} - a_{i,j-\frac{1}{2}} \frac{U_{ij} - U_{i,j-1}}{h_y} \right] \\ & + c_{ij} U_{ij}. \end{aligned} \quad (16.68)$$



其中心系数为

$$\frac{a_{i+\frac{1}{2},j} + a_{i-\frac{1}{2},j}}{h_x^2} + \frac{a_{i,j+\frac{1}{2}} + a_{i,j-\frac{1}{2}}}{h_y^2} + c_{ij}, \quad (16.69)$$

相邻点系数均为非正。

### 16.7.2 知识点十六：面系数的选择

若  $a$  光滑且可在任意位置求值，可取  $a_{i+\frac{1}{2},j} = a(x_i + h_x/2, y_j)$ 。

若只有节点值，可取算术平均

$$a_{i+\frac{1}{2},j}^A = \frac{a_{ij} + a_{i+1,j}}{2}. \quad (16.70)$$

对光滑  $a$ ，它是面值的二阶近似。

若  $a$  在界面两侧变化很大或分片常数，常采用调和平均

$$a_{i+\frac{1}{2},j}^H = \frac{2a_{ij}a_{i+1,j}}{a_{ij} + a_{i+1,j}}. \quad (16.71)$$

调和平均更符合串联介质的等效导率，并能更准确地表示法向通量连续性。

#### 易错点与反例

算术平均和调和平均不能无条件互换。

- 光滑系数下，两者通常都可保持二阶；
- 强跳跃系数下，调和平均更适合扩散通量；
- 各向异性张量系数含交叉项时，简单五点格式可能不再一致或单调；
- 网格与主扩散方向不对齐时，可能需要九点、宽模板或有限元方法。

### 16.7.3 知识点十七：矩阵性质


若  $a_{\text{face}} > 0$ ,  $c_{ij} \geq 0$ ，则变系数通量格式矩阵为  $Z$  矩阵。其离散能量为

$$\begin{aligned} \langle A_h v, v \rangle_h &= \sum_{\text{竖直面}} a_{i+\frac{1}{2},j} \left| \frac{v_{i+1,j} - v_{ij}}{h_x} \right|^2 h_x h_y \\ &+ \sum_{\text{水平面}} a_{i,j+\frac{1}{2}} \left| \frac{v_{i,j+1} - v_{ij}}{h_y} \right|^2 h_x h_y \\ &+ \sum_{i,j} c_{ij} |v_{ij}|^2 h_x h_y. \end{aligned} \quad (16.72)$$

Dirichlet 情形下矩阵对称正定，同时是非奇异  $M$  矩阵。

若  $c_{ij} \geq c_0 > 0$ ，则行和至少为  $c_0$ ，并有简单最大范数稳定性

$$\|A_h^{-1}\|_{\infty} \leq \frac{1}{c_0}. \quad (16.73)$$



## 16.8 补充训练题：丘赛 2024 Problem 4——变系数保守离散与谱圆盘

完整题目叙述

[Yau-2024-Problem-4]

考虑边值问题

$$-\frac{d}{dx} \left( a(x) \frac{du}{dx} \right) = f(x), \quad 0 < x < 1, \quad u(0) = u(1) = 0, \quad (16.74)$$

其中  $a(x)$  为有界可微函数, 且  $a(x) > \delta \geq 0$ 。虽然可以计算  $a(x)$ , 但没有  $a'(x)$  的显式表达式。

- (a) 在等距网格  $x_\ell = \ell h$ ,  $\ell = 0, \dots, n$ ,  $h = \frac{1}{n}$  上构造一个  $O(h^2)$  近似, 并写出应用边界条件后的  $(n-1) \times (n-1)$  三对角线性系统;
- (b) 利用题目给出的全部信息, 找到一个保证包含该线性系统全部特征值的复平面圆盘, 圆盘越小越好。

注 16.9 (正则性核对). 原题只写  $a$  有界可微。若只要求写出保守格式, 该条件足够说明系数可用。

若要用经典 Taylor 余项严格证明  $O(h^2)$  截断误差, 通常需补充例如  $a \in C^3[0, 1]$ ,  $u \in C^4[0, 1]$  及相应导数有界。以下在该标准正则性下证明二阶相容性。

第 (a) 问: 格式构造. 定义半网格系数

$$a_{\ell+\frac{1}{2}} = a \left( x_\ell + \frac{h}{2} \right). \quad (16.75)$$

在半网格点近似通量:

$$a_{\ell+\frac{1}{2}} u_x(x_{\ell+\frac{1}{2}}) \approx a_{\ell+\frac{1}{2}} \frac{U_{\ell+1} - U_\ell}{h}. \quad (16.76)$$

再对通量作中心差分:

$$\boxed{-\frac{1}{h^2} \left[ a_{\ell+\frac{1}{2}} (U_{\ell+1} - U_\ell) - a_{\ell-\frac{1}{2}} (U_\ell - U_{\ell-1}) \right]} = f_\ell \quad (16.77)$$

对  $\ell = 1, \dots, n-1$  成立, 并取  $U_0 = U_n = 0$ 。该格式不需要计算  $a'(x)$ 。  $\square$

第 (a) 问: 二阶截断误差. 在  $x_\ell$  处展开:

$$a_{\ell \pm \frac{1}{2}} = a \pm \frac{h}{2} a' + \frac{h^2}{8} a'' \pm \frac{h^3}{48} a''' + O(h^4), \quad (16.78)$$

$$u_{\ell+1} - u_\ell = hu' + \frac{h^2}{2} u'' + \frac{h^3}{6} u''' + \frac{h^4}{24} u'''' + O(h^5), \quad (16.79)$$


$$u_\ell - u_{\ell-1} = hu' - \frac{h^2}{2} u'' + \frac{h^3}{6} u''' - \frac{h^4}{24} u'''' + O(h^5). \quad (16.80)$$

所有导数均在  $x_\ell$  处取值。

相乘并相减可得

$$\begin{aligned} & \frac{1}{h^2} \left[ a_{\ell+\frac{1}{2}} (u_{\ell+1} - u_\ell) - a_{\ell-\frac{1}{2}} (u_\ell - u_{\ell-1}) \right] \\ &= (au')' + h^2 \left[ \frac{1}{12} au'''' + \frac{1}{6} a' u''' + \frac{1}{8} a'' u'' + \frac{1}{24} a''' u' \right] + O(h^4). \end{aligned} \quad (16.81)$$

所以格式的归一化截断误差为  $O(h^2)$ 。  $\square$



第 (a) 问：三对角矩阵. 令  $\mathbf{U} = \begin{pmatrix} U_1 & \cdots & U_{n-1} \end{pmatrix}^\top$ ,  $\mathbf{f}_h = \begin{pmatrix} f_1 & \cdots & f_{n-1} \end{pmatrix}^\top$ . 线性系统为

$$A_h \mathbf{U} = \mathbf{f}_h, \quad (16.82)$$

其中

$$(A_h)_{\ell\ell} = \frac{a_{\ell-\frac{1}{2}} + a_{\ell+\frac{1}{2}}}{h^2}, \quad (16.83)$$

$$(A_h)_{\ell,\ell-1} = -\frac{a_{\ell-\frac{1}{2}}}{h^2}, \quad \ell = 2, \dots, n-1, \quad (16.84)$$

$$(A_h)_{\ell,\ell+1} = -\frac{a_{\ell+\frac{1}{2}}}{h^2}, \quad \ell = 1, \dots, n-2. \quad (16.85)$$

即

$$A_h = \frac{1}{h^2} \begin{pmatrix} a_{\frac{1}{2}} + a_{\frac{3}{2}} & -a_{\frac{3}{2}} & & & \\ -a_{\frac{3}{2}} & a_{\frac{3}{2}} + a_{\frac{5}{2}} & -a_{\frac{5}{2}} & & \\ & \ddots & \ddots & \ddots & \\ & & & -a_{n-\frac{3}{2}} & a_{n-\frac{3}{2}} + a_{n-\frac{1}{2}} \end{pmatrix}. \quad (16.86)$$

□

第 (b) 问：正定性与谱区间. 定义

$$a_{\min} = \min_{x \in [0,1]} a(x) > 0, \quad (16.87)$$

$$a_{\max} = \max_{x \in [0,1]} a(x) < \infty. \quad (16.88)$$

对任意  $\mathbf{v} \in \mathbb{R}^{n-1}$ , 补充  $v_0 = v_n = 0$ . 则

$$\mathbf{v}^\top A_h \mathbf{v} = \frac{1}{h^2} \sum_{\ell=0}^{n-1} a_{\ell+\frac{1}{2}} (v_{\ell+1} - v_\ell)^2. \quad (16.89)$$

因此  $A_h$  实对称正定, 全部特征值均为正实数。

记标准 Dirichlet 离散 Laplace 矩阵为  $L_h = \frac{1}{h^2} \text{tridiag}(-1, 2, -1)$ . 由 式 (16.89),

$$a_{\min} \mathbf{v}^\top L_h \mathbf{v} \leq \mathbf{v}^\top A_h \mathbf{v} \leq a_{\max} \mathbf{v}^\top L_h \mathbf{v}. \quad (16.90)$$

$L_h$  的最小和最大特征值分别为

$$\lambda_{\min}(L_h) = \frac{4}{h^2} \sin^2 \left( \frac{\pi}{2n} \right), \quad (16.91)$$

$$\lambda_{\max}(L_h) = \frac{4}{h^2} \cos^2 \left( \frac{\pi}{2n} \right). \quad (16.92)$$


由 Rayleigh 商,  $A_h$  的每个特征值均属于实区间

$$\alpha_h \leq \lambda(A_h) \leq \beta_h, \quad (16.93)$$

其中

$$\alpha_h = \frac{4a_{\min}}{h^2} \sin^2 \left( \frac{\pi}{2n} \right), \quad (16.94)$$

$$\beta_h = \frac{4a_{\max}}{h^2} \cos^2 \left( \frac{\pi}{2n} \right). \quad (16.95)$$



包含实区间  $[\alpha_h, \beta_h]$  的最小圆盘为

$$\mathbb{D}(c_h, r_h) = \{z \in \mathbb{C} : |z - c_h| \leq r_h\}, \quad (16.96)$$

其中

$$c_h = \frac{\alpha_h + \beta_h}{2}, \quad (16.97)$$

$$r_h = \frac{\beta_h - \alpha_h}{2}. \quad (16.98)$$

故  $\sigma(A_h) \subset \mathbb{D}(c_h, r_h)$ 。

同时得到条件数估计

$$\kappa_2(A_h) \leq \frac{a_{\max}}{a_{\min}} \cot^2\left(\frac{\pi}{2n}\right). \quad (16.99)$$

□

注 16.10 (若只有节点系数值). 若只能获得  $a_\ell = a(x_\ell)$ , 可取  $a_{\ell+\frac{1}{2}} = \frac{a_\ell + a_{\ell+1}}{2}$ 。对光滑  $a$  仍为二阶。

若  $a$  有跳跃, 可改用  $a_{\ell+\frac{1}{2}} = \frac{2a_\ell a_{\ell+1}}{a_\ell + a_{\ell+1}}$ 。

---

#### Algorithm 67 一维变系数保守差分求解

---

**Input:** 网格数  $n$ ; 系数函数  $a$ ; 右端项  $f$ ; Dirichlet 边界值

**Output:** 内部节点解  $U$

- 1:  $h \leftarrow 1/n$
  - 2: **for**  $\ell = 0, \dots, n-1$  **do**
  - 3:    $a_{\ell+\frac{1}{2}} \leftarrow a\left((\ell + \frac{1}{2})h\right)$
  - 4: **end for**
  - 5: **for**  $\ell = 1, \dots, n-1$  **do**
  - 6:   装配  $A_{\ell\ell} \leftarrow \frac{a_{\ell-\frac{1}{2}} + a_{\ell+\frac{1}{2}}}{h^2}$
  - 7:   装配左右副对角元  $-\frac{a_{\ell-\frac{1}{2}}}{h^2}, -\frac{a_{\ell+\frac{1}{2}}}{h^2}$
  - 8:   加入 Dirichlet 边界对右端项的贡献
  - 9: **end for**
  - 10: 使用 Thomas 算法求解三对角系统
  - 11: **Stopping criterion:** 线性系统求解完成并检查真实残差
  - 12: **Complexity:** 装配  $O(n)$ ; Thomas 求解  $O(n)$ ; 存储  $O(n)$
- 

## 16.9 Dirichlet、Neumann 与 Robin 边界离散

### 16.9.1 知识点十八: Dirichlet 边界

若  $u = g_D$  在边界, 最直接的做法是  $U_P = g_D(P)$  对所有边界网格点成立。

若边界与网格对齐, 该处理不引入额外离散误差。若边界不与网格对齐, 则必须使用:

- 插值边界点;
- 嵌入边界法;
- cut-cell 有限体积;
- 有限元几何逼近;



- 坐标变换。

几何误差可能成为整体误差的主导项。

### 16.9.2 知识点十九：Neumann 边界的二阶单边差分

以左边界  $x = 0$  为例，外法向量为  $\mathbf{n} = (-1, 0)$ 。若直接给出  $\partial_{\mathbf{n}} u = g$ ，则  $-u_x(0, y) = g(y)$ 。

二阶单边近似为

$$\boxed{-\frac{3U_{0,j} + 4U_{1,j} - U_{2,j}}{2h_x} = g(y_j)}. \quad (16.100)$$

右边界  $x = L_x$  上， $\partial_{\mathbf{n}} u = u_x$ ，二阶近似为

$$\boxed{\frac{3U_{N_x,j} - 4U_{N_x-1,j} + U_{N_x-2,j}}{2h_x} = g(y_j)}. \quad (16.101)$$

上下边界公式类似，但必须根据外法向方向调整符号。

### 16.9.3 知识点二十：虚点法

在左边界，中心法向差分可写为

$$-\frac{U_{1,j} - U_{-1,j}}{2h_x} = g_j. \quad (16.102)$$

因此

$$U_{-1,j} = U_{1,j} + 2h_x g_j. \quad (16.103)$$

虚点法优点是模板规则，但必须检查消去虚点后边界行的截断误差。

#### 易错点与反例

中心法向差分本身是二阶，但若把  $U_{-1,j} = U_{1,j} + 2h_x g_j$  直接代入边界点的中心二阶 Laplace 算子，所得边界 PDE 行一般只有一阶局部截断误差。

因此不能只因为“边界导数用了中心差分”就宣称完整边界格式二阶。需要：

- 重新作边界行 Taylor 展开；
- 使用 PDE 修正；
- 采用二阶单边闭合；
- 或使用守恒有限体积边界通量。

### 16.9.4 知识点二十一：离散 Neumann 兼容条件

对保守有限体积离散，把所有控制体方程求和，内部面通量成对抵消，得到离散兼容条件

$$\boxed{\sum_K f_K |K| = \sum_{F \subset \partial\Omega} g_{N,F} |F|}. \quad (16.104)$$

纯 Neumann 矩阵  $A_h$  满足

$$A_h \mathbf{1} = \mathbf{0}. \quad (16.105)$$

若网格连通，则通常  $\ker A_h = \text{span}\{\mathbf{1}\}$ 。

常用唯一化方法：



1. 离散零均值约束  $\sum_K U_K |K| = 0$ ;

2. 增广鞍点系统

$$\begin{pmatrix} A_h & \mathbf{m} \\ \mathbf{m}^\top & 0 \end{pmatrix} \begin{pmatrix} \mathbf{U} \\ \lambda \end{pmatrix} = \begin{pmatrix} \mathbf{F} \\ 0 \end{pmatrix}; \quad (16.106)$$

3. 固定一个节点;

4. 在常数正交补空间上使用 CG 或 MINRES。

### 16.9.5 知识点二十二: Robin 边界

对  $\alpha u + \beta \partial_n u = g_R$  使用二阶法向差分:

$$\alpha_P U_P + \beta_P \partial_n^h U_P = g_{R,P}. \quad (16.107)$$

若  $\alpha \geq 0$ ,  $\beta > 0$ , 适当整理后边界行可保持单调性。但是否仍为对称矩阵, 取决于边界离散方式:

- 直接单边差分通常产生非对称边界行;
- 有限体积自然通量处理更容易保持守恒;
- 变分/有限元离散更自然地保持对称 Robin 项。

#### 易错点与反例

在矩形角点处, 不能机械地同时添加两条相互矛盾的边界方程。

角点处理必须根据:

- 边界条件类型;
- 通量守恒;
- 法向量定义;
- 所需精度;
- 矩阵结构

统一构造。

## 16.10 含一阶项和零阶项的中心差分单调性

### 16.10.1 知识点二十三: 非散度形式

考虑

$$\mathcal{L}u = u_{xx} + u_{yy} + d(x, y)u_x + e(x, y)u_y + f(x, y)u. \quad (16.108)$$

正式题采用  $f(x, y) < 0$ 。

中心差分算子为

$$(L_h V)_{ij} = \delta_x^2 V_{ij} + \delta_y^2 V_{ij} + d_{ij} D_x^0 V_{ij} + e_{ij} D_y^0 V_{ij} + f_{ij} V_{ij}. \quad (16.109)$$





定义四个相邻系数

$$a_{ij}^E = \frac{1}{h_x^2} + \frac{d_{ij}}{2h_x}, \quad (16.110)$$

$$a_{ij}^W = \frac{1}{h_x^2} - \frac{d_{ij}}{2h_x}, \quad (16.111)$$

$$a_{ij}^N = \frac{1}{h_y^2} + \frac{e_{ij}}{2h_y}, \quad (16.112)$$

$$a_{ij}^S = \frac{1}{h_y^2} - \frac{e_{ij}}{2h_y}. \quad (16.113)$$

于是

$$\begin{aligned} (L_h V)_{ij} = & a_{ij}^E (V_{i+1,j} - V_{ij}) + a_{ij}^W (V_{i-1,j} - V_{ij}) \\ & + a_{ij}^N (V_{i,j+1} - V_{ij}) + a_{ij}^S (V_{i,j-1} - V_{ij}) + f_{ij} V_{ij}. \end{aligned} \quad (16.114)$$

### 16.10.2 知识点二十四：单调性条件

要使四个相邻系数非负，需要

$$\boxed{h_x |d_{ij}| \leq 2, \quad h_y |e_{ij}| \leq 2}. \quad (16.115)$$

统一充分条件为

$$h_x \|d\|_\infty \leq 2, \quad h_y \|e\|_\infty \leq 2. \quad (16.116)$$

若扩散系数分别为  $a_x, a_y > 0$ ，则条件变为

$$\frac{|d|h_x}{2a_x} \leq 1, \quad \frac{|e|h_y}{2a_y} \leq 1. \quad (16.117)$$

左端是局部网格 Péclet 数。

若该条件失败，中心差分相邻系数会变号，离散最大值原理和  $M$  矩阵性质可能失效。此时可考虑：

- 迎风差分；
- 指数拟合；
- 人工扩散；
- 流线迎风有限元；
- 单调宽模板。

**反例 16.11** (中心差分失去单调性). 一维算子  $u'' + du'$  的中心差分中，右邻点系数为  $\frac{1}{h^2} + \frac{d}{2h}$ ，左邻点系数为  $\frac{1}{h^2} - \frac{d}{2h}$ 。若  $dh > 2$ ，则左邻点系数为负。此时在内部最大点，该项不再具有确定符号，标准最大值原理证明失效。



## 16.11 正式真题 [24F-Q5]——二维中心差分最大值原理

完整题目叙述: [24F-Q5]

考虑方程

$$u_{xx} + u_{yy} + d(x, y)u_x + e(x, y)u_y + f(x, y)u = 0, \quad f(x, y) < 0. \quad (16.118)$$

在适当假设下, 写出并证明其中心有限差分格式的最大值原理。

第一步: 写出离散算子和必要假设. 在矩形均匀网格上定义

$$(L_h V)_{ij} = \frac{V_{i+1,j} - 2V_{ij} + V_{i-1,j}}{h_x^2} + \frac{V_{i,j+1} - 2V_{ij} + V_{i,j-1}}{h_y^2} + d_{ij} \frac{V_{i+1,j} - V_{i-1,j}}{2h_x} + e_{ij} \frac{V_{i,j+1} - V_{i,j-1}}{2h_y} + f_{ij} V_{ij}. \quad (16.119)$$

取适当假设

$$h_x \|d\|_\infty \leq 2, \quad h_y \|e\|_\infty \leq 2, \quad f_{ij} < 0. \quad (16.120)$$

前两个条件保证  $a_{ij}^E, a_{ij}^W, a_{ij}^N, a_{ij}^S \geq 0$ . □

定理 16.12 (正式题所需离散最大值原理). 在式 (16.120) 下:

1. 若  $L_h V \geq 0$  在内部, 则

$$\max_{\Omega_h} V \leq \max \left\{ 0, \max_{\partial\Omega_h} V \right\}; \quad (16.121)$$

2. 若  $L_h V \leq 0$  在内部, 则

$$\min_{\Omega_h} V \geq \min \left\{ 0, \min_{\partial\Omega_h} V \right\}; \quad (16.122)$$

3. 若  $L_h V = 0$ , 则

$$\|V\|_{\infty, h} \leq \|V\|_{\infty, \partial\Omega_h}. \quad (16.123)$$

证明. 只证第一条。

反设  $V$  在内部点  $P = (i_*, j_*)$  取得正全局最大值  $M = V_P > 0$ . 由式 (16.114),

$$(L_h V)_P = a_P^E(V_E - M) + a_P^W(V_W - M) + a_P^N(V_N - M) + a_P^S(V_S - M) + f_P M. \quad (16.124)$$


由于  $P$  为全局最大点,  $V_E - M, V_W - M, V_N - M, V_S - M \leq 0$ . 又有  $a_P^E, a_P^W, a_P^N, a_P^S \geq 0, f_P < 0, M > 0$ . 因此

$$(L_h V)_P < 0, \quad (16.125)$$

与  $L_h V \geq 0$  矛盾。第二条对  $-V$  应用第一条即可。若  $L_h V = 0$ , 分别应用最大值原理和最小值原理:

$$\max_{\Omega_h} V \leq \max \left\{ 0, \max_{\partial\Omega_h} V \right\}, \quad (16.126)$$

$$-\min_{\Omega_h} V \leq \max \left\{ 0, -\min_{\partial\Omega_h} V \right\}. \quad (16.127)$$

合并即得式 (16.123). □

推论 16.13 (唯一性). 齐次 Dirichlet 边界条件下, 离散齐次方程  $L_h V = 0$  只有零解。

证明. 由  $V|_{\partial\Omega_h} = 0$  和 式 (16.123),  $\|V\|_{\infty,h} = 0$ . □

推论 16.14 (非齐次最大范数稳定性). 进一步假设存在  $c_0 > 0$  使  $f_{ij} \leq -c_0 < 0$ . 若

$$L_h V = F \quad \text{在内部}, \quad V = g \quad \text{在边界}, \quad (16.128)$$

则

$$\|V\|_{\infty,h} \leq \max \left\{ \|g\|_{\infty,\partial\Omega_h}, \frac{\|F\|_{\infty,h}}{c_0} \right\}. \quad (16.129)$$

证明. 若正最大值  $M$  严格大于边界最大值, 则它在内部取得. 在该点  $F_P = (L_h V)_P \leq f_P M \leq -c_0 M$ . 所以  $M \leq \frac{|F_P|}{c_0} \leq \frac{\|F\|_{\infty}}{c_0}$ . 对  $-V$  重复同样论证即可. □

注 16.15 (矩阵解释). 令  $A_h = -L_h$ . 则:

- $A_h$  对角元为正;
- 非对角元非正;
- 每行对角占优余量为  $-f_{ij} > 0$ ;
- 因此  $A_h$  严格行对角占优;
- $A_h$  为非奇异  $M$  矩阵;
- $A_h^{-1} \geq 0$ .

#### 易错点与反例

1. 只写  $f < 0$  而不检查一阶项系数符号, 不足以证明离散最大值原理;
2. 条件  $h|d| \leq 2, \quad h|e| \leq 2$  是中心差分单调性的网格条件;
3. 若  $f = 0$ , 正内部最大值只给出邻点相等, 还需用网格连通性传播;
4. 最大值原理针对的是完整边界格式, 不是只针对无限网格内部模板。

## 16.12 正式真题 [26S-Q5]——最大值原理与后向 Euler 稳定性

完整题目叙述: [26S-Q5]

写出并证明中心有限差分格式离散方程

$$u_{xx} + u_{yy} + du_x + eu_y + fu = 0, \quad f < 0 \quad (16.130)$$

时的最大值原理。

再利用该最大值原理证明后向 Euler 格式求解

$$u_t - (u_{xx} + u_{yy} + du_x + eu_y + fu) = 0, \quad (x, y) \in (0, 1)^2 \quad (16.131)$$

在齐次 Dirichlet 边界条件下稳定。

第一部分：椭圆离散最大值原理. 取  $h_x|d| \leq 2$ ,  $h_y|e| \leq 2$ . 若  $d, e$  为函数, 则改为相应无穷范数条件. 定义  $L_h = \delta_x^2 + \delta_y^2 + dD_x^0 + eD_y^0 + fI$ . 由 定义 16.12, 若  $L_h V \geq 0$ , 则正最大值不能在内部取得; 若  $L_h V \leq 0$ , 则负最小值不能在内部取得.  $\square$

第二部分：后向 Euler 格式. 后向 Euler 全离散格式为

$$\boxed{\frac{U_{ij}^{n+1} - U_{ij}^n}{\tau} - (L_h U^{n+1})_{ij} = 0} \quad (16.132)$$

对内部网格点成立, 并满足  $U^{n+1} = 0$  在  $\partial\Omega_h$ . 矩阵形式为

$$\boxed{(I - \tau L_h)U^{n+1} = U^n}. \quad (16.133)$$

设

$$c_0 = \min_{\Omega_h}(-f) > 0. \quad (16.134)$$

若  $f$  为负常数, 则  $c_0 = -f$ .

令  $M_{n+1} = \|U^{n+1}\|_{\infty, h}$ . 若  $M_{n+1} = 0$ , 结论显然. 否则选择符号  $\sigma \in \{-1, 1\}$  以及网格点  $P$ , 使  $W_P := \sigma U_P^{n+1} = M_{n+1} > 0$ . 由于边界值为零,  $P$  为内部点.  $W$  满足  $(I - \tau L_h)W = \sigma U^n$ .

在正内部最大点  $P$ , 四个邻点差值均非正, 所以

$$(L_h W)_P \leq f_P M_{n+1} \leq -c_0 M_{n+1}. \quad (16.135)$$

因此

$$\|U^n\|_{\infty, h} \geq \sigma U_P^n = W_P - \tau(L_h W)_P \geq (1 + \tau c_0)M_{n+1}. \quad (16.136)$$

故

$$\boxed{\|U^{n+1}\|_{\infty, h} \leq \frac{1}{1 + \tau c_0} \|U^n\|_{\infty, h} \leq \|U^n\|_{\infty, h}}. \quad (16.137)$$

递推得到

$$\boxed{\|U^n\|_{\infty, h} \leq (1 + \tau c_0)^{-n} \|U^0\|_{\infty, h} \leq \|U^0\|_{\infty, h}}. \quad (16.138)$$

该稳定性对任意  $\tau > 0$  成立, 因此后向 Euler 格式在离散最大范数下无条件稳定.  $\square$

注 16.16 (若只假设  $f \leq 0$ ). 若  $f \leq 0$  但没有统一严格负下界, 仍有  $\|U^{n+1}\|_{\infty, h} \leq \|U^n\|_{\infty, h}$ , 只是不能得到严格衰减因子  $(1 + \tau c_0)^{-1}$ .

推论 16.17 (含源项的稳定性). 若格式为

$$\frac{U^{n+1} - U^n}{\tau} - L_h U^{n+1} = F^{n+1}, \quad (16.139)$$


则

$$\boxed{\|U^{n+1}\|_{\infty, h} \leq \frac{\|U^n\|_{\infty, h} + \tau \|F^{n+1}\|_{\infty, h}}{1 + \tau c_0}}. \quad (16.140)$$

证明. 在  $W = \sigma U^{n+1}$  的正最大点重复前述论证, 右端多出  $\tau \sigma F_P^{n+1} \leq \tau \|F^{n+1}\|_{\infty}$ .  $\square$

注 16.18 (矩阵解释). 矩阵  $B_h = I - \tau L_h$  具有:

- 正对角元;
- 非正非对角元;



- 严格行对角占优余量  $1 - \tau f_{ij} = 1 + \tau(-f_{ij}) > 0$ .

因此对每个  $\tau > 0$ ,  $B_h$  都是非奇异  $M$  矩阵, 并满足  $B_h^{-1} \geq 0$ . 传播矩阵为  $S_h = B_h^{-1}$ . 由最大值原理,  $\|S_h\|_\infty \leq \frac{1}{1+\tau c_0}$ .

#### 复杂度说明

设内部未知数个数为  $N_h$ .

- 每个时间步需解一个稀疏线性系统;
- 若  $d = e = 0$ , 矩阵对称正定, 可用 PCG 或多重网格;
- 若  $d, e \neq 0$ , 中心差分矩阵一般非对称, 但在单调性条件下仍是  $M$  矩阵; 可用 GMRES、BiCGStab 或非对称多重网格;
- 一次稀疏矩阵-向量乘法为  $O(N_h)$ ;
- 不能显式形成  $(I - \tau L_h)^{-1}$ .

#### 易错点与反例

1. 无条件稳定不等于任意大  $\tau$  都准确;
2. 空间单调性仍要求  $h_x|d| \leq 2$ ,  $h_y|e| \leq 2$ ; 后向时间离散不能修复一个非单调空间模板;
3. 若边界不是齐次 Dirichlet, 稳定估计必须加入边界数据项;
4. 若  $f > 0$ , 最大范数可能出现真实指数增长, 不能继续写收缩估计;
5. 不能只用矩阵特征值实部为正代替最大范数证明。

## 16.13 非均匀网格、各向异性与单调宽模板

### 16.13.1 知识点二十五：一维非均匀网格保守格式

令  $h_{i+\frac{1}{2}} = x_{i+1} - x_i$ ,  $\bar{h}_i = \frac{h_{i-\frac{1}{2}} + h_{i+\frac{1}{2}}}{2}$ . 对  $-(au')' + cu = f$  可写

$$(A_h U)_i = -\frac{1}{\bar{h}_i} \left[ a_{i+\frac{1}{2}} \frac{U_{i+1} - U_i}{h_{i+\frac{1}{2}}} - a_{i-\frac{1}{2}} \frac{U_i - U_{i-1}}{h_{i-\frac{1}{2}}} \right] + c_i U_i. \quad (16.141)$$

该格式保持通量守恒和  $Z$  矩阵结构。但要获得标准二阶点态截断误差, 通常需网格满足平滑性条件, 例如

$$h_{i+\frac{1}{2}} - h_{i-\frac{1}{2}} = O(h^2), \quad (16.142)$$

或使用与控制体积分一致的误差定义。

#### 易错点与反例

“非均匀网格上把  $h$  替换为局部步长”不是严格推导。

必须重新检查:

- 分母中的控制体长度;
- 面通量位置;

- 局部截断误差；
- 对角占优；
- 网格正则性；
- 边界半控制体。

### 16.13.2 知识点二十六：各向异性张量

对  $-\nabla \cdot (K \nabla u) = f$ ,  $K = \begin{pmatrix} k_{11} & k_{12} \\ k_{12} & k_{22} \end{pmatrix}$ , 若  $k_{12} \neq 0$ , 算子包含混合导数。标准九点中心格式虽然可能一致, 但相邻权重可能出现正负混合, 从而失去离散最大值原理。

保持单调性通常需要:

- 网格与主扩散方向对齐；
- 限制各向异性比；
- 使用更宽的单调模板；
- 采用有限体积双点/多点通量；
- 使用满足离散最大值原理的有限元网格角度条件。

## 16.14 椭圆差分系统的求解器、条件数与停止准则

### 16.14.1 知识点二十七：线性求解误差不能超过离散误差

设精确离散解满足  $A_h U_h = F_h$ , 实际迭代解为  $\tilde{U}_h$ , 残差为  $r_h = F_h - A_h \tilde{U}_h$ 。代数误差为  $z_h = U_h - \tilde{U}_h = A_h^{-1} r_h$ 。因此

$$\|z_h\|_\infty \leq \|A_h^{-1}\|_\infty \|r_h\|_\infty. \quad (16.143)$$

若差分误差为  $O(h^p)$ , 则线性系统通常只需解到  $\|z_h\| \lesssim h^p$ 。继续把代数残差压到远低于舍入误差或离散误差, 通常不会改善最终 PDE 近似。

### 16.14.2 知识点二十八：求解器选择

| 离散矩阵           | 推荐方法                    | 单步/主要成本         | 主要注意事项              |
|----------------|-------------------------|-----------------|---------------------|
| 一维三对角 SPD      | Thomas 或 Cholesky       | $O(n)$          | 主元需非零; $M$ 矩阵通常稳定   |
| 二维 Poisson SPD | 稀疏 Cholesky, PCG, 多重网格  | SpMV 为 $O(N_h)$ | 无预处理条件数 $O(h^{-2})$ |
| 变系数 SPD        | PCG 加不完全 Cholesky, 多重网格 | 取决于预处理器         | 系数高对比度会恶化迭代         |

| 离散矩阵             | 推荐方法                   | 单步/主要成本         | 主要注意事项           |
|------------------|------------------------|-----------------|------------------|
| 含中心对流的非对称 $M$ 矩阵 | GMRES、BiCGStab、非对称多重网格 | SpMV 为 $O(N_h)$ | 非正规性可能导致暂态和重启停滞  |
| 纯 Neumann 半正定矩阵  | 约束 CG、MINRES、推广系统      | 每步 $O(N_h)$     | 必须满足兼容条件并去除常数零空间 |

### 16.14.3 知识点二十九：多重网格识别信号

椭圆离散矩阵的误差通常分为：

- 高频误差：Jacobi、Gauss-Seidel 等平滑器快速衰减；
- 低频误差：在细网格上衰减慢，但在粗网格上变成相对高频。

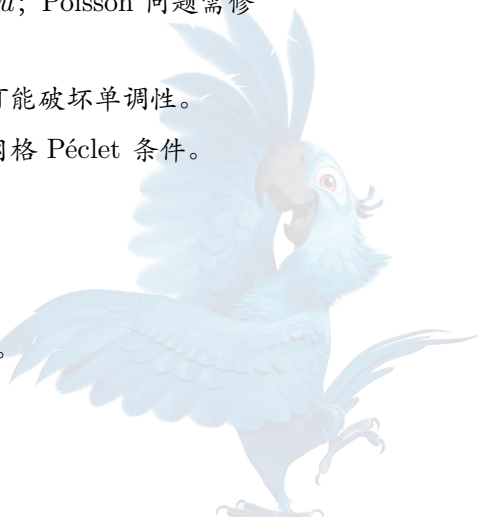
多重网格 V 循环的核心步骤为：

1. 前平滑；
2. 计算残差；
3. 限制到粗网格；
4. 解粗网格误差方程；
5. 延拓修正；
6. 后平滑。

理想情形下，一次 V 循环成本  $O(N_h)$ ，收敛因子与  $h$  无关，总复杂度近似线性。

## 16.15 椭圆有限差分易错点与参考答题规范

| 错误说法或错误做法           | 正确处理                                                           |
|---------------------|----------------------------------------------------------------|
| 五点格式是二阶，所以整体解必为二阶。  | 还需解足够光滑、边界闭合二阶、离散稳定常数网格一致。                                     |
| 局部截断误差可以直接当作数值误差。   | 必须通过最大值原理、能量估计或稳定算子把局部残差转成整体误差。                                |
| 九点格式天然四阶。           | 标准九点 Laplace 算子仍含 $\frac{h^2}{12}\Delta^2 u$ ；Poisson 问题需修正右端。 |
| 高阶格式一定满足最大值原理。      | 高阶模板常出现正非对角系数，可能破坏单调性。                                         |
| 中心差分的一阶项总是二阶且稳定。    | 精度可以是二阶，但单调性还需网格 Péclet 条件。                                    |
| $f < 0$ 可自动保证最大值原理。 | 还必须保证四个相邻点系数非负。                                                |
| 最大值原理只需引用连续定理。      | 必须在离散网格点上逐项证明。                                                 |
| SPD 矩阵必为 $M$ 矩阵。    | 还需非对角元非正等 $Z$ 矩阵结构。                                            |





| 错误说法或错误做法                                           | 正确处理                                                                                          |
|-----------------------------------------------------|-----------------------------------------------------------------------------------------------|
| $M$ 矩阵必对称正定。                                        | 一般 $M$ 矩阵可非对称；含中心对流的矩阵就是典型例子。                                                                 |
| 纯 Neumann 矩阵应当可逆。                                   | 其常数向量属于零空间；需兼容条件和唯一化约束。                                                                       |
| Neumann 兼容条件是 $\int f = \int \partial_n u$ 。        | 符号取决于通量约定；本文采用 $-K \nabla u \cdot n = g_N$ ，故 $\int_{\Omega} f = \int_{\partial\Omega} g_N$ 。 |
| 中心虚点边界一定保持二阶整体精度。                                   | 必须重新计算消去虚点后的边界行截断误差。                                                                          |
| 变系数问题应展开为 $-a \Delta u - \nabla a \cdot \nabla u$ 。 | 若 $a'$ 不可得或系数有跳跃，应直接离散通量。                                                                     |
| 算术平均总优于调和平均。                                        | 光滑系数两者可二阶；跳跃扩散系数通常优先用调和平均。                                                                    |
| 条件数 $O(h^{-2})$ 说明连续 PDE 不适定。                       | 它是离散代数系统的欧氏范数条件数增长。                                                                           |
| 残差足够小就代表 PDE 误差足够小。                                 | 还需乘以离散逆算子范数，并与截断误差比较。                                                                         |
| 隐式求解应形成矩阵逆。                                         | 实现中应解稀疏线性系统，不能显式形成逆矩阵。                                                                        |
| 无条件稳定意味着可任取粗网格。                                     | 稳定性不替代精度、正则性和网格解析能力。                                                                          |

#### 离散最大值原理的统一五步法

1. 把离散算子写成  $L_h V(P) = \sum_Q a_{PQ}(V(Q) - V(P)) + f_P V(P)$ ;
2. 验证  $a_{PQ} \geq 0$ ;
3. 假设  $V(P)$  为正内部最大值;
4. 利用  $V(Q) - V(P) \leq 0$  及  $f_P \leq 0$  判断  $L_h V(P)$  符号;
5. 由题设的不等号制造矛盾，或在等号情形下沿连通网格传播。



# 第十七章 抛物方程、对流扩散、显隐式格式、Crank–Nicolson、Du Fort–Frankel、IMEX、迎风、Lax–Friedrichs 与 Lax–Wendroff

注 17.1. 这一部分内容非常重要，属于博资考每年都必考的基础分析内容，大家一定要认真看。虽然不一定要记住所有格式的名字，但是**强烈建议大家把每道题手动推一遍**。

## 17.1 抛物方程半离散、刚性与统一 $\vartheta$ 格式

### 17.1.1 知识点一：热方程及空间半离散

【重要性等级】 **S 级**。考虑一维热方程

$$\begin{cases} u_t = \kappa u_{xx} + s(x, t), & 0 < x < L, \quad 0 < t \leq T, \\ u(0, t) = g_0(t), \quad u(L, t) = g_L(t), \\ u(x, 0) = u_0(x), \end{cases} \quad \kappa > 0. \quad (17.1)$$

在均匀网格  $x_j = jh$ ,  $h = \frac{L}{J}$ , 上使用中心差分：

$$(\Delta_h U)_j = \frac{U_{j+1} - 2U_j + U_{j-1}}{h^2}. \quad (17.2)$$

空间半离散系统为

$$\frac{dU}{dt} = \kappa \Delta_h U + s_h(t). \quad (17.3)$$

若定义  $A_h = -\kappa \Delta_h$ , 则齐次系统为

$$U'(t) + A_h U(t) = \mathbf{0}. \quad (17.4)$$

在齐次 Dirichlet 边界下,  $A_h$  为对称正定矩阵, 其特征值满足

$$\lambda_{\min}(A_h) = O(1), \quad \lambda_{\max}(A_h) = O(h^{-2}). \quad (17.5)$$

故半离散系统的刚性比为

$$\frac{\lambda_{\max}(A_h)}{\lambda_{\min}(A_h)} = O(h^{-2}). \quad (17.6)$$

这解释了显式 Euler 时间步限制  $\tau = O(h^2)$  的来源：它不是连续热方程传播速度导致的双曲 CFL 条件，而是离散扩散算子的最大特征值为  $O(h^{-2})$ 。



### 17.1.2 知识点二：统一 $\vartheta$ 格式

对  $U' + A_h U = s_h(t)$  采用  $\vartheta$  格式：

$$\begin{aligned} \frac{U^{n+1} - U^n}{\tau} + A_h [(1 - \vartheta)U^n + \vartheta U^{n+1}] \\ = (1 - \vartheta)s_h^n + \vartheta s_h^{n+1}. \end{aligned} \quad (17.7)$$

等价地，

$$(I + \vartheta \tau A_h) U^{n+1} = [I - (1 - \vartheta)\tau A_h] U^n + \tau s_h^{n+\vartheta}. \quad (17.8)$$

特殊情形为：

$$\vartheta = 0 : \quad \text{显式 Euler (FTCS)}, \quad (17.9)$$

$$\vartheta = 1 : \quad \text{隐式 Euler (后向 Euler)}, \quad (17.10)$$

$$\vartheta = \frac{1}{2} : \quad \text{Crank-Nicolson}. \quad (17.11)$$

在一维热方程中令

$$\mu = \frac{\kappa \tau}{h^2}. \quad (17.12)$$

格式的分量形式为

$$\begin{aligned} U_j^{n+1} - U_j^n = \mu \left[ (1 - \vartheta) (U_{j+1}^n - 2U_j^n + U_{j-1}^n) \right. \\ \left. + \vartheta (U_{j+1}^{n+1} - 2U_j^{n+1} + U_{j-1}^{n+1}) \right]. \end{aligned} \quad (17.13)$$

### 17.1.3 知识点三：截断误差

将光滑精确解代入 式 (17.13)，并在  $(x_j, t_n)$  处展开：

$$\frac{u_j^{n+1} - u_j^n}{\tau} = u_t + \frac{\tau}{2} u_{tt} + \frac{\tau^2}{6} u_{ttt} + O(\tau^3), \quad (17.14)$$

$$\begin{aligned} (1 - \vartheta) \Delta_h u^n + \vartheta \Delta_h u^{n+1} = u_{xx} + \vartheta \tau u_{xxt} + \frac{h^2}{12} u_{xxxx} \\ + O(\tau^2 + \tau h^2 + h^4). \end{aligned} \quad (17.15)$$

由  $u_t = \kappa u_{xx}$ ,  $u_{tt} = \kappa u_{xxt}$ ，得到归一化局部截断误差

$$\mathcal{T}_j^n = \left( \frac{1}{2} - \vartheta \right) \tau u_{tt} - \frac{\kappa h^2}{12} u_{xxxx} + O(\tau^2 + \tau h^2 + h^4). \quad (17.16)$$

因此：

$$\mathcal{T}_j^n = \begin{cases} O(\tau + h^2), & \vartheta \neq \frac{1}{2}, \\ O(\tau^2 + h^2), & \vartheta = \frac{1}{2}. \end{cases} \quad (17.17)$$

#### 易错点与反例

“Crank-Nicolson 二阶”是指时间二阶、空间中心差分二阶。

若：

- 边界数据在时间上仅一阶处理;
- 初值与边界条件在角点不相容;
- 精确解在  $t = 0$  附近缺乏高阶正则性;
- 每步线性系统求解误差过大;

则观测到的整体阶数可能低于二阶。

#### 17.1.4 知识点四: Fourier 与谱稳定性

对周期问题取 Fourier 模态  $U_j^n = \hat{U}^n e^{ij\xi}$ , 并记

$$q = 4\mu \sin^2 \frac{\xi}{2} \geq 0. \quad (17.18)$$

增长因子为

$$G_\vartheta(q) = \frac{1 - (1 - \vartheta)q}{1 + \vartheta q}. \quad (17.19)$$

定理 17.2 ( $\vartheta$  格式的  $L^2$  稳定性). 对一维热方程:

1. 若  $\vartheta \geq \frac{1}{2}$ , 则格式无条件  $L^2$  稳定;
2. 若  $0 \leq \vartheta < \frac{1}{2}$ , 则稳定的充要条件为

$$\mu \leq \frac{1}{2(1 - 2\vartheta)}. \quad (17.20)$$

证明. 因为分母  $1 + \vartheta q > 0$ , 条件  $|G_\vartheta(q)| \leq 1$  等价于  $-(1 + \vartheta q) \leq 1 - (1 - \vartheta)q \leq 1 + \vartheta q$ . 右侧不等式恒成立. 左侧不等式等价于  $2 \geq (1 - 2\vartheta)q$ . 若  $\vartheta \geq 1/2$ , 右端系数非正, 故无条件成立.

若  $0 \leq \vartheta < 1/2$ , 需对所有频率满足  $q \leq \frac{2}{1 - 2\vartheta}$ . 一维中  $q_{\max} = 4\mu$ , 故得到 式 (17.20).  $\square$

特别地:

$$\text{显式 Euler: } \mu \leq \frac{1}{2}, \quad (17.21)$$

$$\text{隐式 Euler: } \mu \geq 0 \text{ 任意}, \quad (17.22)$$

$$\text{Crank-Nicolson: } \mu \geq 0 \text{ 任意}. \quad (17.23)$$

在  $d$  维等距网格上, 显式 Euler 条件变为

$$\frac{\kappa \tau}{h^2} \leq \frac{1}{2d}. \quad (17.24)$$

#### 17.1.5 知识点五: 单调性与最大值原理

$L^2$  稳定不等于单调。

一维  $\vartheta$  格式左端矩阵  $I - \vartheta \mu \delta^2$  对  $\vartheta \geq 0$  是  $M$  矩阵。右端显式部分的系数为

$$(1 - \vartheta)\mu \quad \text{位于两个相邻点}, \quad (17.25)$$

$$1 - 2(1 - \vartheta)\mu \quad \text{位于中心点}. \quad (17.26)$$



因此充分的单调性条件为

$$\mu \leq \frac{1}{2(1-\vartheta)}, \quad 0 \leq \vartheta < 1. \quad (17.27)$$

于是：

$$\text{显式 Euler 单调: } \mu \leq \frac{1}{2}, \quad (17.28)$$

$$\text{Crank–Nicolson 单调: } \mu \leq 1, \quad (17.29)$$

$$\text{隐式 Euler 单调: } \text{无条件}. \quad (17.30)$$

#### 易错点与反例

Crank–Nicolson 在  $\mu > 1$  时仍然  $L^2$  稳定，但不再由简单系数符号得到最大值原理。  
其高频增长因子满足

$$G_{\text{CN}}(q) = \frac{1 - q/2}{1 + q/2} \rightarrow -1, \quad q \rightarrow \infty. \quad (17.31)$$

所以粗时间步下，高频分量可能发生符号交替而衰减很慢。

对粗糙初值，常采用 Rannacher 启动：先做两个半步隐式 Euler，再转入 Crank–Nicolson。

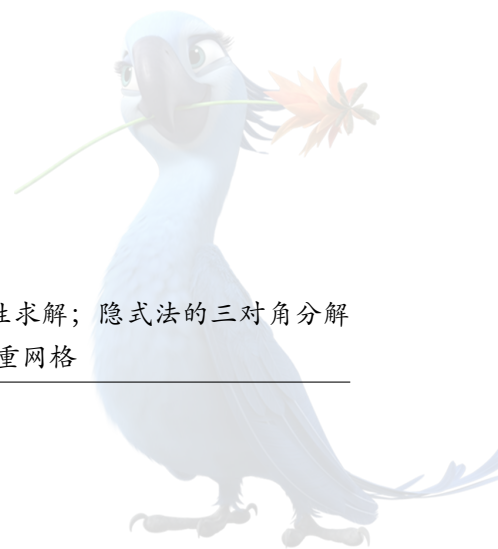
### 17.1.6 知识点六：算法与复杂度

#### Algorithm 68 一维热方程的统一 $\vartheta$ 格式

**Input:** 扩散系数  $\kappa > 0$ ；空间网格数  $J$ ；时间步数  $N$ ；参数  $\vartheta \in [0, 1]$ ；初值和边界数据

**Output:**  $U^n \approx R_h u(t_n)$

- 1: **Initialization:**  $h \leftarrow L/J$ ,  $\tau \leftarrow T/N$ ,  $\mu \leftarrow \kappa\tau/h^2$  由初值生成  $U^0$
- 2: 构造  $M_L = I - \vartheta\mu\delta^2$ ,  $M_R = I + (1 - \vartheta)\mu\delta^2$
- 3: **if**  $\vartheta > 0$  **then**
- 4:     对  $M_L$  作一次三对角分解并复用
- 5: **end if**
- 6: **for**  $n = 0, 1, \dots, N - 1$  **do**
- 7:     组装右端  $r^n = M_R U^n + \tau s^{n+\vartheta} + \text{边界贡献}$
- 8:     **if**  $\vartheta = 0$  **then**
- 9:          $U^{n+1} \leftarrow r^n$
- 10:     **else**
- 11:         解三对角系统  $M_L U^{n+1} = r^n$
- 12:     **end if**
- 13: **end for**
- 14: **Stopping criterion:** 达到终止时间  $T$
- 15: **Complexity:** 一维每步  $O(J)$  运算和  $O(J)$  存储；显式法无需线性求解；隐式法的三对角分解可复用。二维每步需解大型稀疏系统，宜使用 PCG、GMRES 或多重网格



## 17.2 补充训练题：丘赛 2023 Problem 5——显式热方程格式的一致性、稳定性与收敛性

完整题目叙述：[Yau-2023-Problem-5]

设  $u(t, x)$  满足

$$\begin{cases} u_t = Du_{xx}, & 0 < x < L, \quad 0 < t \leq T, \\ u(0, x) = f(x), \\ u(t, 0) = u(t, L) = 0, \end{cases} \quad D > 0. \quad (17.32)$$

令  $\Delta t = \frac{T}{N}$ ,  $\Delta x = \frac{L}{M}$ , 并采用显式差分格式

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} = D \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{(\Delta x)^2}. \quad (17.33)$$

边界和初值为  $U_0^n = U_M^n = 0$ ,  $U_j^0 = f(j\Delta x)$ 。

- (a) 证明格式与热方程相容；
- (b) 证明当  $\Delta t \leq \frac{(\Delta x)^2}{2D}$  时，格式在  $\ell^\infty$  范数下稳定；
- (c) 在同一条件下证明格式在  $\ell^\infty$  范数下收敛。

第 (a) 问. 记  $h = \Delta x$ ,  $\tau = \Delta t$ . 把精确解代入格式：

$$\begin{aligned} \mathcal{T}_j^n &= \frac{u(x_j, t_{n+1}) - u(x_j, t_n)}{\tau} - D\delta_x^2 u(x_j, t_n) \\ &= u_t + \frac{\tau}{2}u_{tt} + O(\tau^2) - D \left[ u_{xx} + \frac{h^2}{12}u_{xxxx} + O(h^4) \right] \\ &= \frac{\tau}{2}u_{tt} - \frac{Dh^2}{12}u_{xxxx} + O(\tau^2 + h^4). \end{aligned} \quad (17.34)$$

故  $\boxed{\mathcal{T}_j^n = O(\tau + h^2)}$ . □

第 (b) 问. 令

$$r = \frac{D\tau}{h^2}. \quad (17.35)$$

格式写成

$$U_j^{n+1} = rU_{j-1}^n + (1 - 2r)U_j^n + rU_{j+1}^n. \quad (17.36)$$

若  $0 \leq r \leq \frac{1}{2}$ , 三个系数非负且和为 1。因此

$$\begin{aligned} |U_j^{n+1}| &\leq r \|U^n\|_\infty + (1 - 2r) \|U^n\|_\infty + r \|U^n\|_\infty \\ &= \|U^n\|_\infty. \end{aligned} \quad (17.37)$$


故

$$\boxed{\|U^{n+1}\|_\infty \leq \|U^n\|_\infty \leq \|U^0\|_\infty}. \quad (17.38)$$

条件  $r \leq 1/2$  正是  $\tau \leq \frac{h^2}{2D}$ . □

第 (c) 问. 定义整体误差  $e_j^n = U_j^n - u(x_j, t_n)$ 。精确解限制满足

$$u_j^{n+1} = ru_{j-1}^n + (1 - 2r)u_j^n + ru_{j+1}^n + \tau \mathcal{T}_j^n. \quad (17.39)$$



故

$$e_j^{n+1} = re_{j-1}^n + (1-2r)e_j^n + re_{j+1}^n - \tau \mathcal{T}_j^n. \quad (17.40)$$

利用稳定性,

$$\|e^{n+1}\|_\infty \leq \|e^n\|_\infty + \tau \|\mathcal{T}^n\|_\infty. \quad (17.41)$$

初值精确给定, 所以  $e^0 = \mathbf{0}$ 。递推至  $t_n = n\tau \leq T$ :

$$\begin{aligned} \|e^n\|_\infty &\leq \tau \sum_{m=0}^{n-1} \|\mathcal{T}^m\|_\infty \\ &\leq T \max_{m\tau \leq T} \|\mathcal{T}^m\|_\infty. \end{aligned} \quad (17.42)$$

若  $u_{tt}, u_{xxxx}$  在闭区域上一致有界, 则

$$\|e^n\|_\infty \leq C_T(\tau + h^2). \quad (17.43)$$

所以格式收敛。  $\square$

### 17.3 补充训练题: 丘赛 2024 Problem 6——周期扩散问题的离散 Fourier 分析

完整题目叙述: [Yau-2024-Problem-6]

考虑周期扩散方程

$$v_t = \mu v_{xx}, \quad v(x, 0) = \phi(x), \quad \int_a^b v(x, t) dx = 0, \quad (17.44)$$

其中  $[a, b] = [0, 2\pi]$ , 空间网格为  $x_m = mh$ ,  $h = \frac{2\pi}{N}$ ,  $N$  为偶数。定义周期中心差分算子

$$(Lv)_m = \frac{v_{m+1} - 2v_m + v_{m-1}}{h^2}. \quad (17.45)$$

题面给出:

(i) Forward Euler:

$$v^{n+1} = v^n + \mu k Lv^n; \quad (17.46)$$

(ii) 题面称为 Crank-Nicolson 的格式:

$$v^{n+1} = v^n + \mu k (Lv^n + Lv^{n+1}). \quad (17.47)$$

要求:

(a) 求  $L$  逼近  $v_{xx}$  的精度;

(b) 在离散 Fourier 展开

$$v_m^n = \sum_{\ell=0}^{N-1} \hat{v}_\ell^n \exp\left(-i \frac{2\pi \ell m}{N}\right) \quad (17.48)$$

下, 求两种方法的 Fourier 系数更新;

(c) 对初值  $\phi(mh) = (-1)^m$  求离散解;

(d) 求两种方法的稳定性条件。



## 资料对应

标准 Crank–Nicolson 格式通常写为

$$v^{n+1} = v^n + \frac{\mu k}{2} (Lv^n + Lv^{n+1}). \quad (17.49)$$

题面式 (17.47) 缺少  $1/2$  因子。

第 (a) 问. Taylor 展开:

$$(Lv)_m = v_{xx}(x_m) + \frac{h^2}{12} v_{xxxx}(x_m) + O(h^4). \quad (17.50)$$

所以  $Lv = v_{xx} + O(h^2)$ . □

第 (b) 问. 对第  $\ell$  个 Fourier 模态, 令  $\theta_\ell = \frac{2\pi\ell}{N}$ . 则

$$\begin{aligned} Le^{-im\theta_\ell} &= \frac{e^{-i(m+1)\theta_\ell} - 2e^{-im\theta_\ell} + e^{-i(m-1)\theta_\ell}}{h^2} \\ &= -\frac{4}{h^2} \sin^2\left(\frac{\theta_\ell}{2}\right) e^{-im\theta_\ell}. \end{aligned} \quad (17.51)$$

记

$$r = \frac{\mu k}{h^2}, \quad s_\ell = \sin\left(\frac{\pi\ell}{N}\right). \quad (17.52)$$

Forward Euler 给出

$$\widehat{v}_\ell^{n+1} = (1 - 4rs_\ell^2) \widehat{v}_\ell^n. \quad (17.53)$$

对题面公式,  $(1 + 4rs_\ell^2) \widehat{v}_\ell^{n+1} = (1 - 4rs_\ell^2) \widehat{v}_\ell^n$ , 故

$$\widehat{v}_\ell^{n+1} = \frac{1 - 4rs_\ell^2}{1 + 4rs_\ell^2} \widehat{v}_\ell^n. \quad (17.54)$$

当  $\ell = 0$  时,  $s_0 = 0$ , 两种方法均满足  $\widehat{v}_0^{n+1} = \widehat{v}_0^n$ . 因此离散平均值保持不变. 若初始离散平均为零, 则以后始终为零。

对标准 Crank–Nicolson 公式 (17.49), 增长因子应为

$$G_{\text{CN, std}} = \frac{1 - 2rs_\ell^2}{1 + 2rs_\ell^2}. \quad (17.55)$$

□

第 (c) 问. 因  $N$  为偶数,  $(-1)^m = e^{-i\pi m} = \exp\left(-i\frac{2\pi(N/2)m}{N}\right)$ . 所以初值只含最高频模态  $\ell = \frac{N}{2}$ . 此时  $s_{N/2} = 1$ .

Forward Euler 解为

$$v_m^n = (1 - 4r)^n (-1)^m. \quad (17.56)$$


题面印刷公式的解为

$$v_m^n = \left(\frac{1 - 4r}{1 + 4r}\right)^n (-1)^m. \quad (17.57)$$

标准 Crank–Nicolson 解为

$$v_m^n = \left(\frac{1 - 2r}{1 + 2r}\right)^n (-1)^m. \quad (17.58)$$

□



第 (d) 问. Forward Euler 稳定要求  $|1 - 4rs_\ell^2| \leq 1 \quad \forall \ell$ . 由于  $0 \leq s_\ell^2 \leq 1$ , 得到  $0 \leq 4r \leq 2$ . 即

$$k \leq \frac{h^2}{2\mu}. \quad (17.59)$$

对题面公式,  $G_\ell = \frac{1-4rs_\ell^2}{1+4rs_\ell^2}$ . 因  $r \geq 0$ , 有  $|G_\ell| \leq 1$  对所有  $r$  成立, 故无时间步限制。

标准 Crank-Nicolson 同样满足  $\left| \frac{1-2rs_\ell^2}{1+2rs_\ell^2} \right| \leq 1$ , 也是无条件稳定。□

#### 易错点与反例

即使 Crank-Nicolson 无条件稳定, 当  $r$  很大时, 最高频增长因子接近  $-1$ , 会产生交替振荡。Forward Euler 若  $r = \frac{1}{2}$ , 最高频增长因子为  $-1$ , 其模恰为 1, 并不衰减。

## 17.4 正式真题 [24S-Q4]——含参数的三时间层热方程格式

完整题目叙述: [24S-Q4]

考虑热方程

$$u_t - a^2 u_{xx} = 0, \quad a > 0, \quad (17.60)$$

的 Cauchy 问题或周期问题。给定参数  $\vartheta \geq 0$ , 使用三时间层格式

$$(1 + \vartheta) \frac{U_j^{n+1} - U_j^n}{k} - \vartheta \frac{U_j^n - U_j^{n-1}}{k} = a^2 \frac{U_{j+1}^{n+1} - 2U_j^{n+1} + U_{j-1}^{n+1}}{h^2}. \quad (17.61)$$

求:

1. 格式的截断误差;
2. 格式的稳定性;
3. 使截断误差达到最高阶的  $\vartheta$  值。

截断误差. 在  $t_{n+1}$  处展开:

$$\frac{u^{n+1} - u^n}{k} = u_t - \frac{k}{2} u_{tt} + \frac{k^2}{6} u_{ttt} - \frac{k^3}{24} u_{tttt} + O(k^4), \quad (17.62)$$

$$\frac{u^n - u^{n-1}}{k} = u_t - \frac{3k}{2} u_{tt} + \frac{7k^2}{6} u_{ttt} - \frac{5k^3}{8} u_{tttt} + O(k^4). \quad (17.63)$$

故时间离散部分为

$$\begin{aligned} & (1 + \vartheta) \frac{u^{n+1} - u^n}{k} - \vartheta \frac{u^n - u^{n-1}}{k} \\ &= u_t + \left( \vartheta - \frac{1}{2} \right) k u_{tt} + \left( \frac{1}{6} - \vartheta \right) k^2 u_{ttt} \\ & \quad + \frac{14\vartheta - 1}{24} k^3 u_{tttt} + O(k^4). \end{aligned} \quad (17.64)$$

空间中心差分满足

$$a^2 \delta_x^2 u^{n+1} = a^2 u_{xx} + \frac{a^2 h^2}{12} u_{xxxx} + O(h^4). \quad (17.65)$$

由 PDE  $u_t = a^2 u_{xx}$  得到

$$\mathcal{T}_j^{n+1} = \left( \vartheta - \frac{1}{2} \right) k u_{tt} + \left( \frac{1}{6} - \vartheta \right) k^2 u_{ttt} - \frac{a^2 h^2}{12} u_{xxxx} + O(k^3 + h^4). \quad (17.66)$$

若  $\vartheta \neq \frac{1}{2}$ , 则  $\mathcal{T} = O(k + h^2)$ 。若  $\vartheta = \frac{1}{2}$ , 则  $\mathcal{T} = -\frac{k^2}{3}u_{ttt} - \frac{a^2h^2}{12}u_{xxxx} + O(k^3 + h^4)$ , 故达到  $O(k^2 + h^2)$ 。□

注 17.3. 当  $\vartheta = 0$  时, 格式就是隐式 Euler。

当  $\vartheta = \frac{1}{2}$  时, 时间离散变为  $\frac{3U^{n+1} - 4U^n + U^{n-1}}{2k}$ , 即 BDF2。

稳定性. 令  $\mu = \frac{a^2k}{h^2}$ ,  $s = \sin \frac{\xi}{2}$ 。取 Fourier 模态  $U_j^n = z^n e^{ij\xi}$ 。代入格式得到特征多项式

$$\boxed{(1 + \vartheta + 4\mu s^2)z^2 - (1 + 2\vartheta)z + \vartheta = 0}. \quad (17.67)$$

记  $A = 1 + \vartheta + 4\mu s^2 > 0$ 。归一化后为  $z^2 + \alpha_1 z + \alpha_0 = 0$ , 其中  $\alpha_1 = -\frac{1+2\vartheta}{A}$ ,  $\alpha_0 = \frac{\vartheta}{A}$ 。

二次实系数多项式的 Schur-Jury 条件为

$$1 + \alpha_1 + \alpha_0 \geq 0, \quad (17.68)$$

$$1 - \alpha_1 + \alpha_0 \geq 0, \quad (17.69)$$

$$1 - \alpha_0 \geq 0, \quad (17.70)$$

并要求单位圆上的根为单根。本题中

$$1 + \alpha_1 + \alpha_0 = \frac{4\mu s^2}{A} \geq 0, \quad (17.71)$$

$$1 - \alpha_1 + \alpha_0 = \frac{2 + 4\vartheta + 4\mu s^2}{A} > 0, \quad (17.72)$$

$$1 - \alpha_0 = \frac{1 + 4\mu s^2}{A} > 0. \quad (17.73)$$

当  $s \neq 0$  时, 第一式严格大于零, 所有根严格位于单位圆内。

当  $s = 0$  时, 多项式为  $(1 + \vartheta)z^2 - (1 + 2\vartheta)z + \vartheta = (z - 1)[(1 + \vartheta)z - \vartheta]$ 。两个根为

$$z_1 = 1, z_2 = \frac{\vartheta}{1 + \vartheta}, \quad (17.74)$$

其中  $0 \leq z_2 < 1$ 。单位根  $z_1 = 1$  为单根。

故对所有  $\vartheta \geq 0$ ,  $\mu \geq 0$ , 格式均满足根条件, 即

$$\boxed{\text{该格式无条件稳定}}. \quad (17.75)$$

□

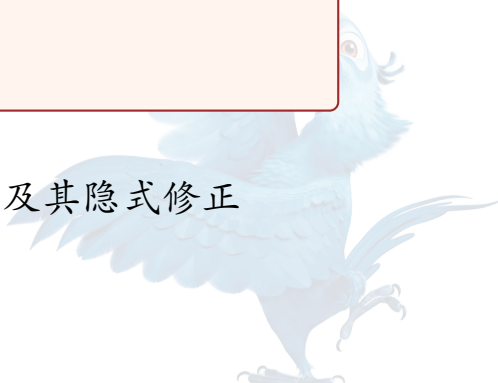
#### 易错点与反例

这是三时间层格式, 必须给定  $U^0$  和  $U^1$ 。

当  $\vartheta = 1/2$  时, 若  $U^1$  只具有一阶误差, 可能降低整体二阶精度。应使用:

- 一个二阶单步法;
- Crank-Nicolson 起步;
- 或足够精确的 Taylor 起步。

## 17.5 补充训练题: Richardson 热方程格式及其隐式修正



完整题目叙述: [FDM-Set-2019I-Q2]

考虑热方程  $u_t = u_{xx}$  的 Richardson 格式

$$\frac{U_j^{n+1} - U_j^{n-1}}{2k} = \frac{U_{j-1}^n - 2U_j^n + U_{j+1}^n}{h^2}. \quad (17.76)$$

- (i) 证明格式具有二阶截断误差;
- (ii) 用 ODE 原理或 von Neumann 分析证明格式无条件不稳定;
- (iii) 对时间差分作一个小修改, 得到一个熟悉的无条件稳定格式并证明。

第 (i) 问. 时间中心差分满足

$$\frac{u^{n+1} - u^{n-1}}{2k} = u_t + \frac{k^2}{6} u_{ttt} + O(k^4). \quad (17.77)$$

空间中心差分满足

$$\delta_x^2 u^n = u_{xx} + \frac{h^2}{12} u_{xxxx} + O(h^4). \quad (17.78)$$

故

$$\tau_j^n = \frac{k^2}{6} u_{ttt} - \frac{h^2}{12} u_{xxxx} + O(k^4 + h^4) = O(k^2 + h^2). \quad (17.79)$$

□

第 (ii) 问. 令  $\mu = \frac{k}{h^2}$ ,  $U_j^n = z^n e^{ij\xi}$ . 代入得到

$$z - z^{-1} = -8\mu \sin^2 \frac{\xi}{2}. \quad (17.80)$$

即

$$z^2 + 8\mu \sin^2 \frac{\xi}{2} z - 1 = 0. \quad (17.81)$$

两个根的乘积为  $z_1 z_2 = -1$ . 只要  $\mu \sin^2 \frac{\xi}{2} > 0$ , 两个根不可能同时位于单位圆内; 事实上一个根的模严格大于 1。

因此对任意  $k > 0$ ,  $h > 0$ , 总存在非零频率使格式不稳定。故

$$\boxed{\text{Richardson 热方程格式无条件不稳定}}. \quad (17.82)$$

□

第 (iii) 问. 把时间中心差分改为后向差分:

$$\frac{U_j^n - U_j^{n-1}}{k} = \frac{U_{j-1}^n - 2U_j^n + U_{j+1}^n}{h^2}. \quad (17.83)$$


这就是隐式 Euler 格式。

对 Fourier 模态, 其增长因子为

$$G(\xi) = \frac{1}{1 + 4\mu \sin^2(\xi/2)}. \quad (17.84)$$

故  $0 < G(\xi) \leq 1$  对任意  $\mu \geq 0$  成立。因此该修改格式无条件稳定。

□



## 易错点与反例

Richardson 格式是“高阶相容但不稳定”的标准反例。

不能因为  $\mathcal{T} = O(k^2 + h^2)$  就断言整体误差二阶；在不稳定格式中，局部误差会被指数放大。

## 17.6 Du Fort–Frankel 格式

## 17.6.1 知识点七：一维格式的构造

对  $u_t = \kappa u_{xx}$ ，从时间中心、空间中心格式出发： $\frac{U_j^{n+1} - U_j^{n-1}}{2\tau} = \kappa \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{h^2}$ 。将右端中心值  $2U_j^n$  替换为  $U_j^{n+1} + U_j^{n-1}$ ，得到 Du Fort–Frankel 格式

$$\frac{U_j^{n+1} - U_j^{n-1}}{2\tau} = \kappa \frac{U_{j+1}^n - U_j^{n+1} - U_j^{n-1} + U_{j-1}^n}{h^2}. \quad (17.85)$$

令  $r = \frac{\kappa\tau}{h^2}$ 。可显式解出

$$\boxed{U_j^{n+1} = \frac{1-2r}{1+2r}U_j^{n-1} + \frac{2r}{1+2r}(U_{j-1}^n + U_{j+1}^n)}. \quad (17.86)$$

它虽然使用三时间层，却不需解线性系统。

## 17.6.2 知识点八：相容性的特殊性

把光滑精确解代入式 (17.85)：

$$\frac{u^{n+1} - u^{n-1}}{2\tau} = u_t + \frac{\tau^2}{6}u_{ttt} + O(\tau^4), \quad (17.87)$$

$$\begin{aligned} \frac{u_{j+1}^n - u_j^{n+1} - u_j^{n-1} + u_{j-1}^n}{h^2} &= u_{xx} - \frac{\tau^2}{h^2}u_{tt} + \frac{h^2}{12}u_{xxxx} \\ &\quad + O\left(h^4 + \frac{\tau^4}{h^2}\right). \end{aligned} \quad (17.88)$$

故

$$\begin{aligned} \mathcal{T} &= u_t - \kappa u_{xx} + \kappa \frac{\tau^2}{h^2}u_{tt} + \frac{\tau^2}{6}u_{ttt} - \frac{\kappa h^2}{12}u_{xxxx} \\ &\quad + O\left(\tau^4 + h^4 + \frac{\tau^4}{h^2}\right). \end{aligned} \quad (17.89)$$

因此格式相容要求

$$\boxed{\frac{\tau}{h} \rightarrow 0}. \quad (17.90)$$

在典型抛物网格路径  $\tau = O(h^2)$  下， $\frac{\tau^2}{h^2} = O(h^2)$ ，故格式整体可达到二阶空间尺度精度。

## 易错点与反例

Du Fort–Frankel 的“无条件稳定”不能解释为：

$\tau, h \rightarrow 0$  沿任意路径均收敛。

稳定性不替代相容性。若  $\tau/h \not\rightarrow 0$ ，额外项  $\kappa \frac{\tau^2}{h^2}u_{tt}$  不消失，格式逼近的是修改方程而不是原热方程。

## 17.7 正式真题 [25F-Q4]——二维 Du Fort–Frankel 格式

完整题目叙述: [25F-Q4]

对二维扩散方程

$$u_t = u_{xx} + u_{yy}, \quad (17.91)$$

构造 Du Fort–Frankel 格式, 并讨论其相容性和稳定性。

注 17.4. 请大家在考试前务必记住一些格式的名字。

格式构造. 取等距空间网格  $x_i = ih$ ,  $y_j = jh$ , 以及时间网格  $t_n = n\tau$ . 在两个方向分别把中心值  $2U_{ij}^n$  替换为  $U_{ij}^{n+1} + U_{ij}^{n-1}$ . 得到

$$\begin{aligned} \frac{U_{ij}^{n+1} - U_{ij}^{n-1}}{2\tau} &= \frac{U_{i+1,j}^n - U_{ij}^{n+1} - U_{ij}^{n-1} + U_{i-1,j}^n}{h^2} \\ &\quad + \frac{U_{i,j+1}^n - U_{ij}^{n+1} - U_{ij}^{n-1} + U_{i,j-1}^n}{h^2}. \end{aligned} \quad (17.92)$$

令  $r = \frac{\tau}{h^2}$ . 整理后

$$(1 + 4r)U_{ij}^{n+1} = (1 - 4r)U_{ij}^{n-1} + 2r(U_{i+1,j}^n + U_{i-1,j}^n + U_{i,j+1}^n + U_{i,j-1}^n). \quad (17.93)$$

□

相容性. 在  $(x_i, y_j, t_n)$  处展开:

$$\frac{u^{n+1} - u^{n-1}}{2\tau} = u_t + \frac{\tau^2}{6}u_{ttt} + O(\tau^4). \quad (17.94)$$

两个空间方向分别给出

$$\begin{aligned} \frac{u_{i+1,j}^n - u_{ij}^{n+1} - u_{ij}^{n-1} + u_{i-1,j}^n}{h^2} &= u_{xx} - \frac{\tau^2}{h^2}u_{tt} + \frac{h^2}{12}u_{xxxx} + O\left(h^4 + \frac{\tau^4}{h^2}\right), \end{aligned} \quad (17.95)$$

$$\begin{aligned} \frac{u_{i,j+1}^n - u_{ij}^{n+1} - u_{ij}^{n-1} + u_{i,j-1}^n}{h^2} &= u_{yy} - \frac{\tau^2}{h^2}u_{tt} + \frac{h^2}{12}u_{yyyy} + O\left(h^4 + \frac{\tau^4}{h^2}\right). \end{aligned} \quad (17.96)$$

因此

$$\begin{aligned} \mathcal{T}_{ij}^n &= u_t - u_{xx} - u_{yy} + 2\frac{\tau^2}{h^2}u_{tt} + \frac{\tau^2}{6}u_{ttt} \\ &\quad - \frac{h^2}{12}(u_{xxxx} + u_{yyyy}) + O\left(\tau^4 + h^4 + \frac{\tau^4}{h^2}\right). \end{aligned} \quad (17.97)$$


利用 PDE, 主项消失. 所以必须有  $\frac{\tau^2}{h^2} \rightarrow 0$ , 即

$$\tau/h \rightarrow 0. \quad (17.98)$$

若  $\tau = O(h^2)$ , 则  $\mathcal{T} = O(h^2)$ . □

Fourier 稳定性. 令  $U_{ij}^n = z^n e^{i(i\xi + j\eta)}$ . 记  $C = \cos \xi + \cos \eta$ ,  $-2 \leq C \leq 2$ . 代入 式 (17.93):

$$(1 + 4r)z^2 - 4rCz - (1 - 4r) = 0. \quad (17.99)$$



归一化后  $z^2 + \alpha_1 z + \alpha_0 = 0$ , 其中  $\alpha_1 = -\frac{4rC}{1+4r}$ ,  $\alpha_0 = \frac{4r-1}{1+4r}$ 。Jury 条件给出

$$1 + \alpha_1 + \alpha_0 = \frac{4r(2-C)}{1+4r} \geq 0, \quad (17.100)$$

$$1 - \alpha_1 + \alpha_0 = \frac{4r(2+C)}{1+4r} \geq 0, \quad (17.101)$$

$$1 - \alpha_0 = \frac{2}{1+4r} > 0. \quad (17.102)$$

当  $-2 < C < 2$  时, 所有根严格位于单位圆内。

当  $C = 2$  时, 一个根为 1, 另一个根为  $\frac{4r-1}{4r+1}$ , 其模小于 1。

当  $C = -2$  时, 一个根为 -1, 另一个根为  $-\frac{4r-1}{4r+1}$ , 其模小于 1。

单位圆上的根均为单根。故按标准 von Neumann 根条件,

$$\boxed{\text{二维 Du Fort-Frankel 格式对任意 } r \geq 0 \text{ 稳定}}. \quad (17.103)$$

□

注 17.5 (稳定但非单调). 当  $r > \frac{1}{4}$  时, 式 (17.93) 中  $\frac{1-4r}{1+4r} < 0$ 。所以格式不再是凸组合, 不能由系数非负得到最大值原理。

因此它可能:

- $L^2$  稳定;
- 但出现时间层交替振荡;
- 不保持非负性;
- 对起步层误差敏感。

---

#### Algorithm 69 二维 Du Fort-Frankel 格式

---

**Input:** 初值  $U^0$ ; 一个足够精确且稳定的起步层  $U^1$ ;  $h, \tau$ ; 终止时间

**Output:**  $U^n$

- 1: **Initialization:**  $r \leftarrow \tau/h^2$  建议用隐式 Euler 或 Crank-Nicolson 生成  $U^1$
  - 2: **for**  $n = 1, 2, \dots, N-1$  **do**
  - 3:   **for** 每个内部网格点  $(i, j)$  **do**
  - 4:      $U_{ij}^{n+1} \leftarrow \frac{(1-4r)U_{ij}^{n-1} + 2r(U_{i+1,j}^n + U_{i-1,j}^n + U_{i,j+1}^n + U_{i,j-1}^n)}{1+4r}$
  - 5:   **end for**
  - 6:   施加第  $n+1$  层边界条件
  - 7: **end for**
  - 8: **Stopping criterion:** 达到终止时间
  - 9: **Complexity:** 每步  $O(N_h)$  运算; 只存储三层网格函数, 存储  $O(N_h)$ ; 不求解线性系统
- 

## 17.8 补充训练题：后向 Euler 热方程的非齐次边界能量估计

完整题目叙述: [FDM-Set-2014I-Q10]

考虑

$$u_t = u_{xx}, \quad 0 \leq x \leq 1, \quad (17.104)$$



边界条件为  $u(0, t) = u_0$ ,  $u(1, t) = u_1$ 。取  $h = \frac{1}{N}$ ,  $\lambda = \frac{k}{h^2}$ , 后向 Euler 格式为

$$U_j^{n+1} - U_j^n = \lambda (U_{j-1}^{n+1} - 2U_j^{n+1} + U_{j+1}^{n+1}), \quad (17.105)$$

其中  $j = 1, \dots, N-1$ ,  $U_0^{n+1} = u_0$ ,  $U_N^{n+1} = u_1$ 。证明

$$\begin{aligned} & \frac{1}{2} \sum_{j=1}^{N-1} [(U_j^{n+1})^2 - (U_j^n)^2] \\ & \leq -\lambda \sum_{j=1}^{N-2} (U_{j+1}^{n+1} - U_j^{n+1})^2 \\ & \quad - \frac{\lambda}{2} [(U_1^{n+1})^2 + (U_{N-1}^{n+1})^2] + \frac{\lambda}{2} (u_0^2 + u_1^2). \end{aligned} \quad (17.106)$$

证明. 将式 (17.105) 乘以  $U_j^{n+1}$ , 并对  $j$  求和。左端使用

$$(a-b)a = \frac{1}{2} (a^2 - b^2 + (a-b)^2) \geq \frac{1}{2} (a^2 - b^2), \quad (17.107)$$

得到

$$\sum_{j=1}^{N-1} (U_j^{n+1} - U_j^n) U_j^{n+1} \geq \frac{1}{2} \sum_{j=1}^{N-1} [(U_j^{n+1})^2 - (U_j^n)^2]. \quad (17.108)$$

省略时间上标  $n+1$ , 离散分部求和给出

$$\begin{aligned} & \sum_{j=1}^{N-1} U_j (U_{j-1} - 2U_j + U_{j+1}) \\ & = - \sum_{j=1}^{N-2} (U_{j+1} - U_j)^2 + U_1 u_0 - U_1^2 + U_{N-1} u_1 - U_{N-1}^2. \end{aligned} \quad (17.109)$$

再用 Young 不等式

$$U_1 u_0 \leq \frac{1}{2} U_1^2 + \frac{1}{2} u_0^2, \quad (17.110)$$


$$U_{N-1} u_1 \leq \frac{1}{2} U_{N-1}^2 + \frac{1}{2} u_1^2, \quad (17.111)$$

得到

$$\begin{aligned} & \sum_{j=1}^{N-1} U_j (U_{j-1} - 2U_j + U_{j+1}) \\ & \leq - \sum_{j=1}^{N-2} (U_{j+1} - U_j)^2 - \frac{1}{2} (U_1^2 + U_{N-1}^2) \\ & \quad + \frac{1}{2} (u_0^2 + u_1^2). \end{aligned} \quad (17.112)$$

乘以  $\lambda$ , 并与左端估计结合, 即得式 (17.106)。□

注 17.6. 若  $u_0 = u_1 = 0$ , 则离散能量非增:  $\sum_{j=1}^{N-1} (U_j^{n+1})^2 \leq \sum_{j=1}^{N-1} (U_j^n)^2$ 。该结论对任意  $\lambda > 0$  成立。



## 17.9 对流扩散方程与 IMEX 离散

### 17.9.1 知识点九：对流扩散模型

考虑周期问题

$$u_t + au_x = bu_{xx}, \quad b > 0. \quad (17.113)$$

连续 Fourier 模态  $u(x, t) = \hat{u}(t)e^{i\kappa x}$  满足  $\hat{u}' = (-ia\kappa - b\kappa^2)\hat{u}$ 。其中：

- $-ia\kappa$  产生相位传播；
- $-b\kappa^2$  产生高频扩散；
- 空间半离散后，扩散特征值规模为  $O(h^{-2})$ ，对流特征值规模为  $O(h^{-1})$ 。

IMEX 的基本思想是：

- 对刚性的扩散项隐式处理；
- 对非刚性或非线性的对流项显式处理；
- 避免每步求解完全非线性系统。

一阶 IMEX Euler 形式为

$$\frac{U^{n+1} - U^n}{\tau} + aD_0U^n = b\Delta_h U^{n+1}. \quad (17.114)$$

### 17.9.2 知识点十：误差与实现

对光滑解，

$$\mathcal{T} = O(\tau + h^2). \quad (17.115)$$

每步需解

$$(I - \tau b\Delta_h)U^{n+1} = U^n - \tau aD_0U^n. \quad (17.116)$$

一维周期问题中是循环三对角系统；Dirichlet 问题中是三对角系统。

---

#### Algorithm 70 一阶 IMEX 对流扩散格式

---

**Input:**  $a, b > 0$ ；周期或给定边界条件； $U^0$ ； $h, \tau$

**Output:**  $U^n$

- 1: **Initialization:** 构造  $M = I - \tau b\Delta_h$  并对  $M$  作一次可复用分解
  - 2: **for**  $n = 0, \dots, N-1$  **do**
  - 3:    $r^n \leftarrow U^n - \tau aD_0U^n$
  - 4:   解  $MU^{n+1} = r^n$
  - 5:   施加边界条件并检查真实线性残差
  - 6: **end for**
  - 7: **Stopping criterion:** 达到终止时间
  - 8: **Complexity:** 一维每步  $O(J)$ ；二维每步需一次稀疏扩散系统求解；矩阵在常数、固定步长时可复用分解或预处理器
- 



## 17.10 补充训练题：对流扩散 IMEX 格式

完整题目叙述：[FDM-Set-2018I-Q4]

考虑

$$u_t + au_x = bu_{xx}, \quad 0 \leq x < 1, \quad b > 0, \quad (17.117)$$

并采用周期边界条件。格式为

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} + a \frac{U_{j+1}^n - U_{j-1}^n}{2\Delta x} = b \frac{U_{j+1}^{n+1} - 2U_j^{n+1} + U_{j-1}^{n+1}}{(\Delta x)^2}. \quad (17.118)$$

证明存在与  $\Delta x$  无关的常数  $c$ ，使  $\Delta t \leq c$  时格式  $L^2$  稳定，并求  $c$  对  $a, b$  的依赖。

证明. 记  $h = \Delta x$ ,  $\tau = \Delta t$ ,  $\nu = \frac{a\tau}{h}$ ,  $\mu = \frac{b\tau}{h^2}$ . 代入 Fourier 模态  $U_j^n = \hat{U}^n e^{ij\xi}$  得到

$$\left[ 1 + 4\mu \sin^2 \frac{\xi}{2} \right] \hat{U}^{n+1} = [1 - i\nu \sin \xi] \hat{U}^n. \quad (17.119)$$

故

$$G(\xi) = \frac{1 - i\nu \sin \xi}{1 + 4\mu \sin^2(\xi/2)}. \quad (17.120)$$

令  $s^2 = \sin^2 \frac{\xi}{2}$ . 则  $\sin^2 \xi = 4s^2(1 - s^2)$ . 条件  $|G| \leq 1$  等价于

$$\begin{aligned} 1 + 4\nu^2 s^2(1 - s^2) &\leq (1 + 4\mu s^2)^2 \\ &= 1 + 8\mu s^2 + 16\mu^2 s^4. \end{aligned} \quad (17.121)$$

对  $s \neq 0$  约去  $4\tau s^2/h^2$ , 得到

$$a^2 \tau (1 - s^2) \leq 2b + \frac{4b^2 \tau}{h^2} s^2. \quad (17.122)$$

左端随  $s^2$  下降, 右端随  $s^2$  上升. 因此对全部频率成立的网格一致充要条件为

$$a^2 \tau \leq 2b. \quad (17.123)$$

即当  $a \neq 0$  时可取

$$c = \frac{2b}{a^2}. \quad (17.124)$$

若  $a = 0$ , 问题退化为纯扩散隐式 Euler, 无时间步限制.  $\square$

注 17.7. 该条件与  $h$  无关, 所以比显式扩散格式  $\tau = O(h^2)$  温和得多.

但当  $b \rightarrow 0^+$ , 允许的时间步  $c = \frac{2b}{a^2} \rightarrow 0$ . 这反映显式中心对流在无扩散极限下不稳定.

## 17.11 一阶对流方程的标准差分格式

### 17.11.1 知识点十一：模型与 Courant 数


考虑

$$u_t + au_x = 0, \quad a \neq 0. \quad (17.125)$$

精确解为  $u(x, t) = u_0(x - at)$ . 定义 Courant 数

$$\nu = \frac{a\tau}{h}. \quad (17.126)$$

当  $a > 0$  时, 信息从左向右传播, 迎风差分必须使用左侧点; 当  $a < 0$  时, 应使用右侧点.



### 17.11.2 知识点十二：迎风、逆风与中心 FTCS

若  $a > 0$ ，一阶迎风格式为

$$U_j^{n+1} = U_j^n - \nu (U_j^n - U_{j-1}^n). \quad (17.127)$$

它是凸组合  $U_j^{n+1} = (1-\nu)U_j^n + \nu U_{j-1}^n$  当且仅当  $0 \leq \nu \leq 1$ 。因此在该条件下同时满足  $L^1$ ,  $L^2$ ,  $L^\infty$  稳定性和单调性。

逆风格式为

$$U_j^{n+1} = U_j^n - \nu (U_{j+1}^n - U_j^n). \quad (17.128)$$

对  $a > 0$ ，它具有负数值扩散并不稳定。

FTCS 中心格式为

$$U_j^{n+1} = U_j^n - \frac{\nu}{2} (U_{j+1}^n - U_{j-1}^n). \quad (17.129)$$

其增长因子  $G = 1 - i\nu \sin \xi$  满足  $|G|^2 = 1 + \nu^2 \sin^2 \xi$ 。固定非零  $\nu$  时不稳定。其完整分析已见第 15 部分。

### 17.11.3 知识点十三：Lax-Friedrichs 格式

把 FTCS 中的旧时间层中心值  $U_j^n$  替换为相邻点平均值：

$$U_j^{n+1} = \frac{1}{2} (U_{j+1}^n + U_{j-1}^n) - \frac{\nu}{2} (U_{j+1}^n - U_{j-1}^n). \quad (17.130)$$

亦即

$$U_j^{n+1} = \frac{1+\nu}{2} U_{j-1}^n + \frac{1-\nu}{2} U_{j+1}^n. \quad (17.131)$$

当  $|\nu| \leq 1$  时为凸组合。

增长因子为

$$G_{LF} = \cos \xi - i\nu \sin \xi, \quad (17.132)$$

并且

$$|G_{LF}|^2 = 1 - (1 - \nu^2) \sin^2 \xi. \quad (17.133)$$

故稳定条件为

$$|\nu| \leq 1. \quad (17.134)$$

其修改方程的主导项为

$$u_t + au_x = \frac{h^2}{2\tau} (1 - \nu^2) u_{xx} + O(h^2), \quad (17.135)$$


所以 Lax-Friedrichs 具有较强数值耗散。

### 17.11.4 知识点十四：Lax-Wendroff 格式

由时间 Taylor 展开  $u^{n+1} = u^n + \tau u_t + \frac{\tau^2}{2} u_{tt} + O(\tau^3)$ ，利用  $u_t = -au_x$ ,  $u_{tt} = a^2 u_{xx}$ ，并用中心差分逼近空间导数，得到

$$U_j^{n+1} = U_j^n - \frac{\nu}{2} (U_{j+1}^n - U_{j-1}^n) + \frac{\nu^2}{2} (U_{j+1}^n - 2U_j^n + U_{j-1}^n). \quad (17.136)$$

该格式时间、空间均为二阶。



增长因子为

$$G_{\text{LW}} = 1 - i\nu \sin \xi + \nu^2 (\cos \xi - 1). \quad (17.137)$$

直接计算得

$$|G_{\text{LW}}|^2 = 1 - 4\nu^2 (1 - \nu^2) \sin^4 \frac{\xi}{2}. \quad (17.138)$$

故

$$|\nu| \leq 1 \quad (17.139)$$

为稳定条件。

修改方程主导项为

$$u_t + au_x = \frac{ah^2}{6} (\nu^2 - 1) u_{xxx} + O(h^3). \quad (17.140)$$

主导误差为三阶导数，体现数值色散。

### 17.11.5 知识点十五：耗散、相位和群速度

将增长因子写为

$$G(\xi) = e^{-\alpha_h(\xi)\tau} e^{-i\omega_h(\xi)\tau}. \quad (17.141)$$

定义：

$$\alpha_h(\xi) = -\frac{1}{\tau} \log |G(\xi)|, \quad \text{数值耗散率}, \quad (17.142)$$

$$c_{\text{ph}}(\xi) = \frac{\omega_h(\xi)}{\xi/h}, \quad \text{数值相速度}, \quad (17.143)$$

$$c_{\text{gr}}(\xi) = \frac{d\omega_h}{d(\xi/h)}, \quad \text{数值群速度}. \quad (17.144)$$

- $|G| < 1$ ：数值耗散；
- $\arg G$  与精确相位  $-\nu\xi$  不一致：数值色散；
- 单调一阶迎风具有较强耗散；
- Lax-Wendroff 耗散较弱，但在间断附近可能产生振荡；
- 二阶线性单调格式受 Godunov 障碍限制，因而高阶无振荡格式需要限制器或非线性重构。

| 格式             | 更新特征        | 精度              | 稳定条件           | 主要误差特征      |
|----------------|-------------|-----------------|----------------|-------------|
| 迎风             | 沿上游方向取差分    | 一阶              | $ \nu  \leq 1$ | 耗散、单调       |
| 逆风             | 沿下游方向取差分    | 一阶              | 通常不稳定          | 负数值扩散       |
| FTCS           | 时间前向、空间中心   | $O(\tau + h^2)$ | 固定非零 $\nu$ 不稳定 | 反耗散         |
| Lax-Friedrichs | 旧层中心值改为相邻平均 | 一阶              | $ \nu  \leq 1$ | 较强耗散        |
| Lax-Wendroff   | Taylor 二阶修正 | 二阶              | $ \nu  \leq 1$ | 主要色散、间断附近振荡 |

## 17.12 正式真题 [26S-Q4]——三种隐式对流格式

完整题目叙述: [26S-Q4]

对一阶对流方程

$$u_t + u_x = 0, \quad (17.145)$$

分析以下隐式格式的稳定性:

$$\frac{U_j^{n+1} - U_j^n}{\tau} + \frac{U_j^{n+1} - U_{j-1}^{n+1}}{h} = 0, \quad (17.146)$$

$$\frac{U_j^{n+1} - U_j^n}{\tau} + \frac{U_{j+1}^{n+1} - U_j^{n+1}}{h} = 0, \quad (17.147)$$

$$\frac{U_j^{n+1} - U_j^n}{\tau} + \frac{U_{j+1}^{n+1} - U_{j-1}^{n+1}}{2h} = 0. \quad (17.148)$$

格式 (a). 令  $\lambda = \frac{\tau}{h} \geq 0$ . 代入  $U_j^n = G^n e^{ij\xi}$  得  $G - 1 + \lambda G(1 - e^{-i\xi}) = 0$ . 所以

$$G_a(\xi) = \frac{1}{1 + \lambda(1 - e^{-i\xi})}. \quad (17.149)$$

分母模平方为

$$\begin{aligned} |1 + \lambda(1 - e^{-i\xi})|^2 &= 1 + 2\lambda(1 + \lambda)(1 - \cos \xi) \\ &\geq 1. \end{aligned} \quad (17.150)$$

故  $|G_a| \leq 1$  对任意  $\lambda \geq 0$  成立. 因此格式 (a) 无条件稳定.

它是隐式迎风格式, 时间、空间均为一阶。 □

格式 (b). 代入 Fourier 模态:  $G - 1 + \lambda G(e^{i\xi} - 1) = 0$ . 故

$$G_b(\xi) = \frac{1}{1 + \lambda(e^{i\xi} - 1)}. \quad (17.151)$$

分母模平方为

$$|1 + \lambda(e^{i\xi} - 1)|^2 = 1 - 2\lambda(1 - \lambda)(1 - \cos \xi). \quad (17.152)$$

若  $0 < \lambda < 1$ , 则取任意非零小频率便有分母模小于 1, 从而  $|G_b| > 1$ . 特别地,  $\lambda = 1/2$  时, 在  $\xi = \pi$  处分母为零, 离散系统奇异.

若  $\lambda \geq 1$ , 则  $-2\lambda(1 - \lambda)(1 - \cos \xi) \geq 0$ , 所以分母模不小于 1。

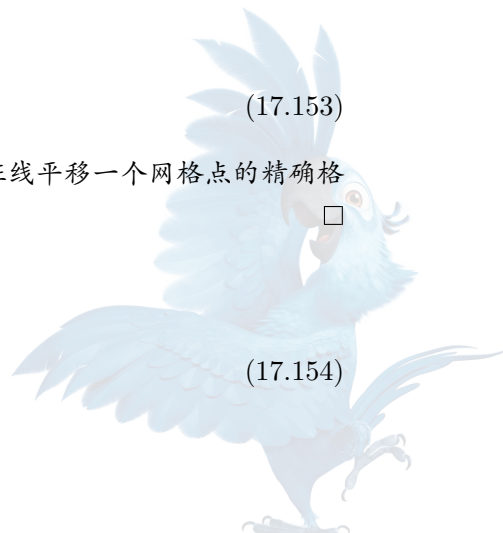
因此非平凡稳定区间为

$$\boxed{\lambda \geq 1}. \quad (17.153)$$

当  $\lambda = 1$  时, 格式化为  $U_{j+1}^{n+1} = U_j^n$ , 即  $U_j^{n+1} = U_{j-1}^n$ , 恰好是沿特征线平移一个网格点的精确格式。 □

格式 (c). 代入 Fourier 模态:  $G - 1 + i\lambda G \sin \xi = 0$ . 因此

$$G_c(\xi) = \frac{1}{1 + i\lambda \sin \xi}. \quad (17.154)$$



于是

$$|G_c(\xi)|^2 = \frac{1}{1 + \lambda^2 \sin^2 \xi} \leq 1. \quad (17.155)$$

故格式 (c) 无条件  $L^2$  稳定。

其时间一阶、空间二阶，但不是单调格式；高频  $\xi = \pi$  满足  $|G_c(\pi)| = 1$ ，棋盘格模态不衰减。□

#### 易错点与反例

“隐式”不自动推出“无条件稳定”。

本题格式 (b) 在  $0 < \tau/h < 1$  时不稳定，而在  $\tau/h \geq 1$  时反而稳定。

这说明稳定性取决于完整离散算子，不能只凭显式或隐式标签判断。

### 17.13 补充训练题：BDF2-中心隐式对流格式

完整题目叙述：[FDM-Set-2018T-Q3]

对

$$u_t + au_x = f \quad (17.156)$$

考虑格式

$$\frac{3U_m^{n+1} - 4U_m^n + U_m^{n-1}}{2k} + a \frac{U_{m+1}^{n+1} - U_{m-1}^{n+1}}{2h} = f_m^{n+1}. \quad (17.157)$$

(i) 证明格式二阶精确；

(ii) 证明格式无条件稳定。

第 (i) 问. BDF2 时间差商在  $t_{n+1}$  处满足

$$\frac{3u^{n+1} - 4u^n + u^{n-1}}{2k} = u_t^{n+1} - \frac{k^2}{3} u_{ttt}^{n+1} + O(k^3). \quad (17.158)$$

空间中心差分满足

$$\frac{u(x+h) - u(x-h)}{2h} = u_x + \frac{h^2}{6} u_{xxx} + O(h^4). \quad (17.159)$$

故  $\mathcal{T} = O(k^2 + h^2)$ . □

第 (ii) 问. 令  $f = 0$ ，取  $U_m^n = z^n e^{im\xi}$ ， $q = \frac{ak}{h} \sin \xi \in \mathbb{R}$ 。代入得到

$$(3 + 2iq)z^2 - 4z + 1 = 0. \quad (17.160)$$

令  $w = \frac{1}{z} = X + iY$ 。则

$$w^2 - 4w + 3 + 2iq = 0. \quad (17.161)$$

其实部方程为

$$(X - 2)^2 - Y^2 = 1. \quad (17.162)$$

令  $s = \sqrt{1 + Y^2} \geq 1$ 。由实部方程， $X = 2 + s$  或  $X = 2 - s$ 。

若  $X = 2 + s$ ，显然  $|w| > 1$ 。

若  $X = 2 - s$ ，则

$$\begin{aligned} |w|^2 &= (2 - s)^2 + Y^2 \\ &= (2 - s)^2 + (s^2 - 1) \\ &= 2(s - 1)^2 + 1 \geq 1. \end{aligned} \quad (17.163)$$





所以  $|w| \geq 1$ ,  $|z| \leq 1$ 。

等号只可能在  $s = 1$ ,  $Y = 0$ ,  $X = 1$  时成立。由虚部方程可知此时  $q = 0$ 。对应单位根为  $z = 1$ , 另一个根为  $z = 1/3$ , 单位根为单根。

因此格式对任意  $k, h > 0$  满足根条件, 即无条件稳定。□

### 易错点与反例

该格式为两步法, 必须提供二阶起步值。

“BDF2 是 A-稳定的”可以作为识别信号, 但资格考试中若题目给出根条件提示, 应展示特征多项式和单位根分析。

## 17.14 补充训练题：紧致四阶空间差分的隐式 Leapfrog 格式

完整题目叙述：[FDM-Set-2016I-Q8]

考虑单向波方程

$$u_t + au_x = f. \quad (17.164)$$

格式为

$$\frac{U_m^{n+1} - U_m^{n-1}}{2k} + a \left( I + \frac{h^2}{6} \delta^2 \right)^{-1} \delta_0 U_m^n = f_m^n, \quad (17.165)$$

其中  $\delta_0 U_m = \frac{U_{m+1} - U_{m-1}}{2h}$ ,  $\delta^2 U_m = \frac{U_{m+1} - 2U_m + U_{m-1}}{h^2}$ 。

1. 证明格式的阶为  $(2, 4)$ ;

2. 证明格式稳定当且仅当

$$\left| \frac{ak}{h} \right| < \frac{1}{\sqrt{3}}. \quad (17.166)$$

第 (1) 问. 时间中心差分为二阶:  $\frac{u^{n+1} - u^{n-1}}{2k} = u_t + \frac{k^2}{6} u_{ttt} + O(k^4)$ 。

对空间算子,

$$\delta_0 u = u_x + \frac{h^2}{6} u_{xxx} + \frac{h^4}{120} u_{xxxxx} + O(h^6), \quad (17.167)$$

$$\left( I + \frac{h^2}{6} \delta^2 \right) u_x = u_x + \frac{h^2}{6} u_{xxx} + \frac{h^4}{72} u_{xxxxx} + O(h^6). \quad (17.168)$$

两者相差  $O(h^4)$ , 故

$$\left( I + \frac{h^2}{6} \delta^2 \right)^{-1} \delta_0 u = u_x + O(h^4). \quad (17.169)$$

所以格式时间二阶、空间四阶。□


第 (2) 问. Fourier 符号为

$$\hat{\delta}_0 = \frac{i \sin \xi}{h}, \quad (17.170)$$

$$1 + \frac{h^2}{6} \hat{\delta}^2 = 1 - \frac{2}{3} \sin^2 \frac{\xi}{2} = \frac{2 + \cos \xi}{3}. \quad (17.171)$$

故紧致空间导数符号为

$$\hat{D}_c(\xi) = \frac{3i \sin \xi}{h(2 + \cos \xi)}. \quad (17.172)$$



令

$$\gamma(\xi) = \frac{ak}{h} \frac{3 \sin \xi}{2 + \cos \xi}. \quad (17.173)$$

齐次格式的特征方程为

$$z^2 + 2i\gamma z - 1 = 0. \quad (17.174)$$

当  $|\gamma| < 1$  时, 两个根为  $z = -i\gamma \pm \sqrt{1 - \gamma^2}$ , 且均在单位圆上并互异。

当  $|\gamma| = 1$  时出现重单位根, 导致线性增长; 当  $|\gamma| > 1$  时一个根模大于 1。

因此需  $\sup_{\xi} |\gamma(\xi)| < 1$ 。计算

$$\max_{\xi} \left| \frac{3 \sin \xi}{2 + \cos \xi} \right| = \sqrt{3}. \quad (17.175)$$

最大值在  $\cos \xi = -\frac{1}{2}$  处取得。故稳定的充要条件为  $\left| \frac{ak}{h} \right| < \frac{1}{\sqrt{3}}$ 。□

#### 复杂度说明

空间紧致算子包含  $\left(I + \frac{h^2}{6} \delta^2\right)^{-1}$ 。实现时不应显式形成逆矩阵, 而应求解一个三对角或循环三对角系统。

一维每步成本仍为  $O(J)$ , 但比普通中心差分多一次紧致线性求解。

## 17.15 补充训练题: FTCS 格式的稳定性方法

完整题目叙述: [FDM-Set-2012I-Q12]

对  $u_t + u_x = 0$  写出时间前向、空间中心格式。

(i) 作 von Neumann 稳定性分析;

(ii) 在什么  $\Delta t, \Delta x$  关系下该格式可稳定并收敛;

(iii) 当双曲 CFL 条件满足时, 列举使格式稳定的修改方法。

第 (i) 问. FTCS 格式为

$$U_j^{n+1} = U_j^n - \frac{\lambda}{2} (U_{j+1}^n - U_{j-1}^n), \quad \lambda = \frac{\Delta t}{\Delta x}. \quad (17.176)$$

增长因子为  $G = 1 - i\lambda \sin \xi$ , 故  $|G|^2 = 1 + \lambda^2 \sin^2 \xi$ 。固定非零  $\lambda$  时, 存在频率使  $|G| > 1$ , 并且  $|G|^{T/\Delta t} \rightarrow \infty$ 。因此固定双曲网格比时不稳定。□

第 (ii) 问. 有限时间稳定性允许  $|G| \leq 1 + C\Delta t$ 。利用  $\log |G| = \frac{1}{2} \log (1 + \lambda^2 \sin^2 \xi) \leq \frac{\lambda^2}{2}$ , 有

$$|G|^n \leq \exp\left(\frac{n\lambda^2}{2}\right) \leq \exp\left[\frac{T}{2} \frac{\Delta t}{(\Delta x)^2}\right]. \quad (17.177)$$

因此若


$$\Delta t \leq C_0 (\Delta x)^2, \quad (17.178)$$

格式在固定有限时间内  $L^2$  稳定。

又因其截断误差为  $O(\Delta t + (\Delta x)^2)$ , 由 Lax 等价定理可得收敛。

该条件远严于双曲问题通常希望的  $\Delta t = O(\Delta x)$ 。□

第 (iii) 问. 可采用以下标准修改:



1. 迎风格式  $U_j^{n+1} = U_j^n - \lambda(U_j^n - U_{j-1}^n)$ ,  $0 \leq \lambda \leq 1$ ;
2. Lax-Friedrichs 格式  $U_j^{n+1} = \frac{1}{2}(U_{j+1}^n + U_{j-1}^n) - \frac{\lambda}{2}(U_{j+1}^n - U_{j-1}^n)$ , 稳定条件  $|\lambda| \leq 1$ ;
3. Lax-Wendroff 格式  $U_j^{n+1} = U_j^n - \frac{\lambda}{2}(U_{j+1}^n - U_{j-1}^n) + \frac{\lambda^2}{2}(U_{j+1}^n - 2U_j^n + U_{j-1}^n)$ , 稳定条件  $|\lambda| \leq 1$ ;
4. Leapfrog 格式  $\frac{U_j^{n+1} - U_j^{n-1}}{2\Delta t} + \frac{U_{j+1}^n - U_{j-1}^n}{2\Delta x} = 0$ , 满足  $|\lambda| \leq 1$ , 但具有计算模态;
5. 隐式中心格式  $\frac{U_j^{n+1} - U_j^n}{\Delta t} + \frac{U_{j+1}^{n+1} - U_{j-1}^{n+1}}{2\Delta x} = 0$ , 对周期问题无条件  $L^2$  稳定。

□

## 17.16 二阶单边三点格式: Beam-Warming 型方法

### 17.16.1 知识点十六: 系数构造

考虑  $u_t + u_x = 0$  和格式

$$U_j^{n+1} = \alpha U_j^n + \beta U_{j-1}^n + \gamma U_{j-2}^n, \quad \lambda = \frac{\tau}{h}. \quad (17.179)$$

精确解满足  $u(x_j, t_{n+1}) = u(x_j - \lambda h, t_n)$ 。对节点  $x_j, x_j - h, x_j - 2h$  作二次插值, 得到

$$\alpha = \frac{(1-\lambda)(2-\lambda)}{2}, \quad (17.180)$$

$$\beta = \lambda(2-\lambda), \quad (17.181)$$

$$\gamma = \frac{\lambda(\lambda-1)}{2}. \quad (17.182)$$

因此

$$U_j^{n+1} = \frac{(1-\lambda)(2-\lambda)}{2} U_j^n + \lambda(2-\lambda) U_{j-1}^n + \frac{\lambda(\lambda-1)}{2} U_{j-2}^n. \quad (17.183)$$

在固定  $\lambda$  下, 一步缺陷为  $O(h^3)$ , 归一化截断误差为  $O(h^2)$ 。

### 17.16.2 知识点十七: 稳定性

增长因子为

$$G(\xi) = \alpha + \beta e^{-i\xi} + \gamma e^{-2i\xi}. \quad (17.184)$$

直接代数化简得

$$1 - |G(\xi)|^2 = \lambda(2-\lambda)(\lambda-1)^2(1 - \cos \xi)^2. \quad (17.185)$$

因此

$$0 \leq \lambda \leq 2 \quad (17.186)$$

时格式  $L^2$  稳定。

当  $\lambda = 1$  时,  $U_j^{n+1} = U_{j-1}^n$ ; 当  $\lambda = 2$  时,  $U_j^{n+1} = U_{j-2}^n$ 。两种情形均为精确网格平移。



## 17.17 补充训练题：单边三点格式及入流边界

完整题目叙述：[FDM-Set-2016T-Q7]

对全直线问题  $u_t + u_x = 0$  及紧支初值，考虑  $U_j^{n+1} = aU_j^n + bU_{j-1}^n + cU_{j-2}^n$ 。

(i) 求  $a, b, c$ ，使格式二阶；

(ii) 求  $L^2$  稳定的最大 CFL 范围；

(iii) 若问题定义在  $(0, \infty)$ ，具有入流边界  $u(0, t) = g(t)$ ，如何修改格式？讨论稳定性与精度。

第 (i)-(ii) 问. 由前述插值推导，

$$a = \frac{(1-\lambda)(2-\lambda)}{2}, \quad b = \lambda(2-\lambda), \quad c = \frac{\lambda(\lambda-1)}{2}. \quad (17.187)$$

由式 (17.185)，稳定范围为

$$0 \leq \lambda \leq 2. \quad (17.188)$$

所以可取  $\lambda_0 = 2$ . □

第 (iii) 问. 由于模板需要  $U_{j-1}^n, U_{j-2}^n$ ，在  $j = 1$  处需要边界点  $U_0^n$  和虚点  $U_{-1}^n$ 。

对速度为 1 的对流方程，入流边界的特征延拓为  $\tilde{u}(x, t) = g(t - x)$  在  $x \leq 0$ 。因此可取

$$U_0^n = g(t_n), \quad (17.189)$$

$$U_{-1}^n = g(t_n + h). \quad (17.190)$$

若不希望直接使用未来边界值，可用二阶 Taylor 近似

$$U_{-1}^n = g(t_n) + hg'(t_n) + \frac{h^2}{2}g''(t_n) + O(h^3). \quad (17.191)$$

随后对所有  $j \geq 1$  使用式 (17.183)。

对齐次边界  $g = 0$ ，令  $B$  为半直线  $\ell^2$  空间上的后移算子： $(BU)_j = U_{j-1}$ ， $U_0 = U_{-1} = 0$ 。更新算子为  $S = \alpha I + \beta B + \gamma B^2$ 。 $B$  是压缩算子。由 von Neumann 算子不等式， $\|S\|_2 \leq \max_{|z| \leq 1} |\alpha + \beta z + \gamma z^2| \leq 1$  当  $0 \leq \lambda \leq 2$  时成立。故齐次入流边界下  $L^2$  稳定。

对非齐次边界，减去一个由  $g(t-x)$  构造的光滑提升函数，再对齐次边界误差方程使用离散 Duhamel 公式，可得

$$\|U^n\|_{2,h} \leq C_T \left[ \|U^0\|_{2,h} + \|g\|_{C^2[0, T+h]} \right]. \quad (17.192)$$

若初边数据满足角点兼容条件且足够光滑，虚点误差为  $O(h^3)$ ，内部一步缺陷也为  $O(h^3)$ 。在固定  $\lambda$  和稳定传播下，整体误差为

$$O(h^2 + \tau^2). \quad (17.193)$$

□

### 易错点与反例

二阶单边格式的边界处理不能只写  $U_0^n = g(t_n)$  而忽略  $U_{-1}^n$ 。

若虚点仅作一阶外推，整个初边值格式可能退化为一阶。

## 17.18 补充训练题：精确网格平移与稳定区间

完整题目叙述：[FDM-Set-2011T-Q13]

使用

$$U_j^{n+1} = aU_{j-2}^n + bU_{j-1}^n + cU_j^n \quad (17.194)$$

求解周期问题  $u_t + u_x = 0$ 。

- (i) 求  $a, b, c$ , 使格式二阶;
- (ii) 验证当  $\lambda = 1$  或  $\lambda = 2$  时格式精确;
- (iii) 精确性是否自动推出对全部  $\lambda \leq 2$  稳定? 求实际稳定区间。

证明. 注意本题的系数排列与式 (17.179) 相反。由式 (17.183), 有

$$a = \frac{\lambda(\lambda-1)}{2}, \quad (17.195)$$

$$b = \lambda(2-\lambda), \quad (17.196)$$

$$c = \frac{(1-\lambda)(2-\lambda)}{2}. \quad (17.197)$$

当  $\lambda = 1$  时,  $a = 0, b = 1, c = 0$ , 所以  $U_j^{n+1} = U_{j-1}^n$ , 与精确特征平移一致。当  $\lambda = 2$  时,  $a = 1, b = 0, c = 0$ , 所以  $U_j^{n+1} = U_{j-2}^n$ , 也为精确平移。

但在两个孤立参数点精确, 逻辑上不能推出中间所有参数稳定。必须独立计算增长因子。

由式 (17.185),  $|G| \leq 1 \iff 0 \leq \lambda \leq 2$ 。所以实际结论恰好为

$$\boxed{\lambda_0 = 2}. \quad (17.198)$$

□

## 17.19 补充训练题：非线性扩散显式格式

完整题目叙述：[FDM-Set-2017T-Q5]

考虑周期非线性扩散方程

$$u_t = (H(u))_{xx}, \quad 0 \leq H'(u) \leq d. \quad (17.199)$$

设

$$U_j^{n+1} = U_j^n + aH(U_{j-1}^n) + bH(U_j^n) + cH(U_{j+1}^n), \quad (17.200)$$

其中  $a, b, c$  可依赖  $\mu = \frac{\tau}{h^2}$ 。

- (i) 求  $a, b, c$ , 使格式具有二阶空间精度;
- (ii) 求保证稳定性的 CFL 上界  $\mu_0$ , 说明所用范数并证明。

第 (i) 问. 要求格式逼近  $U_j^{n+1} = U_j^n + \tau(H(u))_{xx} + O(\tau^2)$ 。对  $H(U_{j\pm 1}^n)$  作空间 Taylor 展开。消去零

阶项和一阶项，并匹配二阶项，得到

$$a + b + c = 0, \quad (17.201)$$

$$c - a = 0, \quad (17.202)$$

$$\frac{h^2}{2}(a + c) = \tau. \quad (17.203)$$

所以

$$a = c = \mu, \quad b = -2\mu. \quad (17.204)$$

格式为

$$U_j^{n+1} = U_j^n + \mu [H(U_{j-1}^n) - 2H(U_j^n) + H(U_{j+1}^n)]. \quad (17.205)$$

其归一化截断误差为  $O(\tau + h^2)$ 。若保持  $\mu$  固定，则  $\tau = \mu h^2$ ，整体为二阶空间尺度精度。  $\square$

第 (ii) 问. 定义离散割线斜率

$$q_{j+\frac{1}{2}}^n = \begin{cases} \frac{H(U_{j+1}^n) - H(U_j^n)}{U_{j+1}^n - U_j^n}, & U_{j+1}^n \neq U_j^n, \\ H'(U_j^n), & U_{j+1}^n = U_j^n. \end{cases} \quad (17.206)$$

由假设  $0 \leq q_{j+\frac{1}{2}}^n \leq d$ 。格式可写为

$$U_j^{n+1} = \mu q_{j-\frac{1}{2}}^n U_{j-1}^n + \left[1 - \mu (q_{j-\frac{1}{2}}^n + q_{j+\frac{1}{2}}^n)\right] U_j^n + \mu q_{j+\frac{1}{2}}^n U_{j+1}^n. \quad (17.207)$$

若

$$\mu \leq \frac{1}{2d}, \quad (17.208)$$

则所有系数非负且和为 1。因此  $U_j^{n+1}$  是上一层三个值的凸组合，故

$$\min_{\ell} U_{\ell}^n \leq U_j^{n+1} \leq \max_{\ell} U_{\ell}^n, \quad (17.209)$$

$$\|U^{n+1}\|_{\infty} \leq \|U^n\|_{\infty}. \quad (17.210)$$

所以格式在离散  $L^{\infty}$  范数下稳定，且满足离散最大值原理。

因此

$$\mu_0 = \frac{1}{2d}. \quad (17.211)$$

若  $d = 0$ ，则  $H$  为常数，方程退化为  $u_t = 0$ ，无实际时间步限制。  $\square$

## 17.20 补充训练题：非线性守恒律半离散迎风格式

完整题目叙述：[FDM-Set-2017I/2014I-Q6]

考虑周期守恒律

$$u_t + f(u)_x = 0, \quad f'(u) \geq 0. \quad (17.212)$$

半离散迎风格式为

$$\frac{dU_j}{dt} + \frac{f(U_j) - f(U_{j-1}))}{h} = 0, \quad j = 1, \dots, N, \quad (17.213)$$

并取周期条件  $U_0 = U_N$ 。

(i) 证明  $\frac{d}{dt} \left[ h \sum_{j=1}^N |U_j|^2 \right] \leq 0$ ;

(ii) 判断对任意整数  $p \geq 1$ ,  $E_p(t) = h \sum_{j=1}^N |U_j|^{2p}$  是否也满足  $E_p'(t) \leq 0$ .

一般凸熵证明. 取任意可微凸函数  $\eta: \mathbb{R} \rightarrow \mathbb{R}$ . 定义对应熵通量

$$q_\eta(u) = \int_0^u \eta'(s) f'(s) ds. \quad (17.214)$$

对任意  $a, b \in \mathbb{R}$ , 有

$$\begin{aligned} & \eta'(a) [f(a) - f(b)] - [q_\eta(a) - q_\eta(b)] \\ &= \int_b^a [\eta'(a) - \eta'(s)] f'(s) ds \geq 0. \end{aligned} \quad (17.215)$$

最后一个不等式来自:

- $\eta'$  单调不减;
- $f'(s) \geq 0$ ;
- 当积分上下限反向时, 两个符号同时改变。

将半离散方程乘以  $\eta'(U_j)h$ :

$$\begin{aligned} \frac{d}{dt} \eta(U_j)h &= -\eta'(U_j) [f(U_j) - f(U_{j-1})] \\ &\leq -[q_\eta(U_j) - q_\eta(U_{j-1})]. \end{aligned} \quad (17.216)$$

对  $j$  求和并利用周期性, 右端望远镜消去:

$$\frac{d}{dt} \left[ h \sum_{j=1}^N \eta(U_j) \right] \leq 0. \quad (17.217)$$

第 (i) 问取  $\eta(u) = \frac{1}{2}u^2$ . 于是  $\frac{d}{dt} \left[ h \sum_j |U_j|^2 \right] \leq 0$ .

第 (ii) 问取  $\eta(u) = \frac{1}{2p}|u|^{2p}$ . 该函数对所有整数  $p \geq 1$  均为凸函数。故  $\frac{d}{dt} \left[ h \sum_j |U_j|^{2p} \right] \leq 0$ . 所

以第 (ii) 问答案为肯定。□

注 17.8. 上述证明实际上表明: 只要  $\eta$  为可微凸熵, 半离散迎风格式就满足对应的离散熵不等式。

这比只证明  $L^2$  稳定更强。


## 17.21 实现容差、复杂度与资格考试易错点

### 17.21.1 知识点十八: 隐式线性系统的求解容差

若全离散格式每步需要求解  $M_h U^{n+1} = r^n$ , 而实际得到  $\tilde{U}^{n+1}$ , 代数残差为  $\rho^{n+1} = r^n - M_h \tilde{U}^{n+1}$ . 代数误差为  $U^{n+1} - \tilde{U}^{n+1} = M_h^{-1} \rho^{n+1}$ . 因此应使

$$\|M_h^{-1} \rho^{n+1}\| \lesssim \text{时间离散误差} + \text{空间离散误差}. \quad (17.218)$$

例如 Crank-Nicolson 中心差分的目标误差为  $O(\tau^2 + h^2)$ , 故每步代数误差不应明显大于该尺度。





易错点与反例

仅检查线性系统相对残差  $\frac{\|\rho^{n+1}\|}{\|r^n\|}$  并不足以直接说明代数解误差小; 还需考虑  $\|M_h^{-1}\|$  或  $\kappa(M_h)$ 。

17.21.2 知识点十九：复杂度比较

设空间未知数总数为  $N_h$ , 固定终止时间为  $T$ 。

| 方法              | 单步成本        | 典型时间步限制                              | 总体特征            |
|-----------------|-------------|--------------------------------------|-----------------|
| 显式热方程 FTCS      | $O(N_h)$    | $\tau = O(h^2)$                      | 实现简单, 但总步数大     |
| 隐式 Euler        | 一次稀疏求解      | 稳定性无步长限制                             | 一阶、强阻尼、适合刚性问题   |
| Crank–Nicolson  | 一次稀疏求解      | 稳定性无步长限制                             | 二阶, 但高频阻尼弱      |
| Du Fort–Frankel | $O(N_h)$    | 稳定性无显式限制, 相容需 $\tau/h \rightarrow 0$ | 显式三层, 可能非单调     |
| IMEX 对流扩散       | 一次扩散系统求解    | 显式部分给出额外限制                           | 避免完全隐式非线性求解     |
| 显式迎风/LF/LW      | $O(N_h)$    | $ a \tau/h \leq 1$                   | 适合双曲传播, 耗散或色散不同 |
| 隐式对流            | 一次稀疏或循环系统求解 | 依格式而定                                | 隐式不自动无条件稳定      |

对  $d$  维显式扩散格式, 若  $N_h = O(h^{-d})$ ,  $\tau = O(h^2)$ , 则总运算量约为

$$O(N_h h^{-2}) = O(N_h^{1+2/d}). \tag{17.219}$$

这也是大规模扩散问题偏好隐式法、指数法或多重网格时间推进的原因。

17.21.3 知识点二十：高频失真与步长选择

时间步应同时满足：

1. 稳定性要求；
2. 时间精度要求；
3. 对流传播分辨率；
4. 扩散时间尺度；
5. 边界数据变化尺度；
6. 非线性迭代和线性求解成本约束。

无条件稳定方法仍可能需要  $\tau \ll 1$  以正确解析瞬态过程。



| 错误说法或错误做法                               | 正确处理                                 |
|-----------------------------------------|--------------------------------------|
| 热方程显式格式的限制是双曲 CFL。                      | 其本质来自离散扩散特征值 $O(h^{-2})$ 。           |
| Crank–Nicolson 无条件稳定，所以一定无振荡。           | 高频增长因子可接近 $-1$ ，不具 $L$ -稳定性。         |
| 隐式 Euler 和 Crank–Nicolson 稳定性相同，所以性质相同。 | 前者强阻尼、时间一阶；后者时间二阶但高频阻尼弱。             |
| Du Fort–Frankel 无条件稳定，所以沿任意网格路径收敛。      | 还需 $\tau/h \rightarrow 0$ 保证相容性。     |
| 三层格式不需要特殊起步。                            | 必须构造与目标阶数匹配的 $U^1$ 。                 |
| $L^2$ 稳定自动保持非负性。                        | 非负性和最大值原理要求单调或 $M$ 矩阵结构。             |
| 中心对流空间二阶，所以优于迎风。                        | 纯对流下 FTCS 不稳定；高 Péclet 数下中心格式可振荡。    |
| 迎风方向总是使用 $j-1$ 。                        | 只有速度 $a > 0$ 时使用左侧； $a < 0$ 时方向相反。   |
| Lax–Friedrichs 和 Lax–Wendroff 都是二阶。     | Lax–Friedrichs 通常一阶；Lax–Wendroff 二阶。 |
| Lax–Wendroff 无耗散，所以不会出问题。               | 其主要误差为色散，间断附近可出现非物理振荡。               |
| IMEX 把扩散隐式后就完全无步长限制。                    | 显式对流或反应部分仍可限制时间步。                    |
| 所有隐式对流格式都无条件稳定。                         | [26S-Q4(b)] 在 $0 < \tau/h < 1$ 时不稳定。 |
| 稳定性只需检查特征值模。                            | 多层格式还需单位圆根为单根；系统格式还需控制增长矩阵幂。         |
| 题面称某格式为 Crank–Nicolson 即可直接套标准公式。       | 先检查是否含标准的 $1/2$ 平均因子。                |
| 代数系统解得越精确越好。                            | 求解误差应与离散误差协调，过度求解浪费成本。               |
| 无条件稳定等于无条件准确。                           | 稳定性只控制扰动增长，不控制截断误差大小。                |



# 第十八章 波动方程、双曲系统、耦合格式、色散方程、数值边界条件、能量与传播

## 18.1 波动方程的连续结构：能量、特征线与有限传播速度

### 18.1.1 知识点一：问题、假设与适定性

【重要性等级】 **S 级**。考虑一维波动方程

$$\begin{cases} u_{tt} = c^2 u_{xx} + s(x, t), & 0 < x < L, \quad 0 < t \leq T, \\ u(x, 0) = f(x), \\ u_t(x, 0) = g(x), \end{cases} \quad c > 0. \quad (18.1)$$

边界条件可以是：

$$u(0, t) = g_0(t), \quad u(L, t) = g_L(t), \quad \text{Dirichlet 边界}, \quad (18.2)$$

$$u_x(0, t) = q_0(t), \quad u_x(L, t) = q_L(t), \quad \text{Neumann 边界}, \quad (18.3)$$

$$u_t(0, t) - cu_x(0, t) = 0, \quad u_t(L, t) + cu_x(L, t) = 0, \quad \text{一阶吸收边界}. \quad (18.4)$$

对经典解，通常至少要求  $f \in C^2$ ,  $g \in C^1$ ,  $s \in C$ ，并满足初边值兼容条件。要严格得到二阶中心格式的经典 Taylor 截断误差，需进一步假设  $u \in C^4$  或更高阶正则性。

### 18.1.2 知识点二：连续能量

齐次方程  $u_{tt} = c^2 u_{xx}$  的连续能量定义为

$$E(t) = \frac{1}{2} \int_0^L [u_t(x, t)^2 + c^2 u_x(x, t)^2] dx. \quad (18.5)$$

对时间求导：

$$\begin{aligned} E'(t) &= \int_0^L (u_t u_{tt} + c^2 u_x u_{xt}) dx \\ &= c^2 \int_0^L (u_t u_{xx} + u_x u_{xt}) dx \\ &= c^2 [u_t u_x]_{x=0}^{x=L}. \end{aligned} \quad (18.6)$$

因此：



- 周期边界下，边界通量相消；
- 齐次 Dirichlet 边界下， $u = 0 \implies u_t = 0$  在边界成立；
- 齐次 Neumann 边界下， $u_x = 0$  在边界成立；

均有

$$\boxed{E'(t) = 0}. \quad (18.7)$$

对右端存在源项时，

$$E'(t) = c^2 [u_t u_x]_0^L + \int_0^L s(x, t) u_t(x, t) dx. \quad (18.8)$$

#### 波动方程能量法：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 二阶时间导数；
- 空间算子为负自伴椭圆算子；
- 题目要求稳定性、唯一性或长时间行为；
- Fourier 分析受边界条件限制。

构造步骤：

1. 用  $u_t$  乘方程；
2. 对空间二阶导数积分分部；
3. 将体积分整理为时间导数；
4. 单独保留边界能量通量；
5. 由边界条件判断通量符号或消失。

关键恒等式：  $u_t u_{tt} = \frac{1}{2} \partial_t(u_t^2)$ ,  $u_x u_{xt} = \frac{1}{2} \partial_t(u_x^2)$ 。

结论：

$E(t) = E(0)$  或  $E(t) \leq E(0) + \int_0^t$  外部输入  $ds$ 。

常见失败原因：

- 忽略边界通量；
- 把周期问题的能量结论直接用于有限区间；
- 吸收边界符号写反；
- 离散能量与连续能量使用不同时间层，却未说明；
- 能量形式不是正定的，却直接声称稳定。

### 18.1.3 知识点三：特征变量与传播方向

定义

$$p = u_t + cu_x, \quad q = u_t - cu_x. \quad (18.9)$$



由波动方程可得

$$p_t - cp_x = 0, \quad (18.10)$$

$$q_t + cq_x = 0. \quad (18.11)$$

因此:

- $q$  以速度  $+c$  向右传播;
- $p$  以速度  $-c$  向左传播。

在右端点  $x = L$ , 进入计算区域的是速度为  $-c$  的分量  $p$ ; 在左端点  $x = 0$ , 进入计算区域的是速度为  $+c$  的分量  $q$ 。

无反射吸收边界应令入射特征分量为零:

$$q(0, t) = u_t(0, t) - cu_x(0, t) = 0, \quad (18.12)$$

$$p(L, t) = u_t(L, t) + cu_x(L, t) = 0. \quad (18.13)$$

#### 易错点与反例

右端吸收边界不是  $u_t - cu_x = 0$ 。对右行波  $u(x, t) = F(x - ct)$ , 有  $u_t + cu_x = 0$ 。因此右端应使用  $u_t + cu_x = 0$ 。

左端对左行波  $u(x, t) = G(x + ct)$  应使用  $u_t - cu_x = 0$ 。

#### 18.1.4 知识点四: 有限传播速度与数值依赖域

Cauchy 问题的 d'Alembert 公式为

$$u(x, t) = \frac{1}{2} [f(x - ct) + f(x + ct)] + \frac{1}{2c} \int_{x-ct}^{x+ct} g(\xi) d\xi. \quad (18.14)$$

因此  $u(x, t)$  只依赖于初始区间  $[x - ct, x + ct]$ 。这就是有限传播速度。

若差分格式每一步只使用相邻空间点, 经过  $n$  步后, 其数值依赖域横向扩展距离为  $nh = \frac{t_n}{\tau}h$ 。为了使数值依赖域至少覆盖真实依赖域, 需要

$$\frac{h}{\tau} \geq c, \text{ 即 } \boxed{\lambda := \frac{c\tau}{h} \leq 1}. \quad (18.15)$$

这是 CFL 必要条件的几何解释。它通常是稳定性的必要条件, 但自动是充分条件。

## 18.2 波动方程的标准 Störmer–Leapfrog 中心格式

### 18.2.1 知识点五: 格式构造与精度

取网格  $x_j = jh$ ,  $t_n = n\tau$ 。对  $u_{tt} = c^2 u_{xx} + s$  采用时间、空间二阶中心差分:

$$\frac{U_j^{n+1} - 2U_j^n + U_j^{n-1}}{\tau^2} = c^2 \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{h^2} + s_j^n. \quad (18.16)$$

令

$$\lambda = \frac{c\tau}{h}, \quad (18.17)$$



则齐次格式显式写为

$$U_j^{n+1} = 2U_j^n - U_j^{n-1} + \lambda^2 (U_{j+1}^n - 2U_j^n + U_{j-1}^n). \quad (18.18)$$

Taylor 展开:

$$\frac{u_j^{n+1} - 2u_j^n + u_j^{n-1}}{\tau^2} = u_{tt} + \frac{\tau^2}{12} u_{tttt} + O(\tau^4), \quad (18.19)$$

$$\frac{u_{j+1}^n - 2u_j^n + u_{j-1}^n}{h^2} = u_{xx} + \frac{h^2}{12} u_{xxxx} + O(h^4). \quad (18.20)$$

故归一化截断误差为

$$\mathcal{T}_j^n = \frac{\tau^2}{12} u_{tttt} - \frac{c^2 h^2}{12} u_{xxxx} + O(\tau^4 + h^4). \quad (18.21)$$

利用  $u_{tttt} = c^4 u_{xxxx}$  可写为

$$\mathcal{T}_j^n = \frac{c^2}{12} (c^2 \tau^2 - h^2) u_{xxxx} + O(\tau^4 + h^4). \quad (18.22)$$

因此格式为  $O(\tau^2 + h^2)$ 。

当  $c\tau = h$ , 主导截断误差抵消。在全直线或周期网格且边界不破坏结构时, 格式甚至对应精确网格平移的特征传播。

### 18.2.2 知识点六: 初始速度的二阶离散

三时间层格式需要  $U^0$ ,  $U^1$ 。由 Taylor 展开  $u(x, \tau) = f(x) + \tau g(x) + \frac{\tau^2}{2} [c^2 f''(x) + s(x, 0)] + O(\tau^3)$ , 可取

$$U_j^1 = f_j + \tau g_j + \frac{\tau^2}{2} [c^2 \delta_x^2 f_j + s_j^0]. \quad (18.23)$$

该起步公式保持整体二阶精度。

#### 易错点与反例

若简单取  $U_j^1 = f_j + \tau g_j$ , 则起步误差为  $O(\tau^2)$ 。

对三层二阶格式, 要获得固定时间上的整体二阶误差, 通常需要一步起步缺陷为  $O(\tau^3)$ , 因此不能随意省略  $\frac{\tau^2}{2} u_{tt}(x, 0)$ 。

### 18.2.3 知识点七: Fourier 稳定性与根条件

令  $U_j^n = z^n e^{ij\theta}$ 。代入 式 (18.16):

$$z^2 - 2 \left[ 1 - 2\lambda^2 \sin^2 \frac{\theta}{2} \right] z + 1 = 0. \quad (18.24)$$

记  $\alpha(\theta) = 1 - 2\lambda^2 \sin^2 \frac{\theta}{2}$ 。由于根的乘积为 1, 两根都位于单位圆上当且仅当  $|\alpha(\theta)| \leq 1$ 。这要求

$$0 \leq \lambda^2 \sin^2 \frac{\theta}{2} \leq 1 \quad \forall \theta, \quad (18.25)$$

即

$$|\lambda| \leq 1. \quad (18.26)$$

但根条件还要求单位圆上的重根受到单独检查。

- 当  $|\lambda| < 1$  时, 除零频模态外, 根通常互异;



- 当  $|\lambda| = 1$ 、 $\theta = \pi$  时,  $z = -1$  是重根;
- 对任意不相容的两层初值, 重根可能产生  $n(-1)^n$  型计算模态;
- 对由平滑初值按 式 (18.23) 生成的兼容起步层, 端点 CFL 通常仍可使用。

因此资格考试答题时应区分:

$$|\lambda| < 1 \quad \text{保证严格的统一根条件稳定性} \quad (18.27)$$

与常见工程表述

$$|\lambda| \leq 1 \quad \text{为标准 CFL 稳定区间}. \quad (18.28)$$

#### 18.2.4 知识点八: 数值色散关系

令  $z = e^{-i\omega_h\tau}$ 。由 式 (18.24), 得到

$$\sin^2\left(\frac{\omega_h\tau}{2}\right) = \lambda^2 \sin^2\left(\frac{\theta}{2}\right). \quad (18.29)$$

若  $\theta = \kappa h$ , 则数值相速度为

$$c_{\text{ph},h}(\kappa) = \frac{\omega_h(\kappa)}{\kappa}, \quad (18.30)$$

数值群速度为

$$c_{\text{gr},h}(\kappa) = \frac{d\omega_h}{d\kappa}. \quad (18.31)$$

由 式 (18.29),

$$c_{\text{gr},h} = c \frac{\cos(\theta/2)}{\sqrt{1 - \lambda^2 \sin^2(\theta/2)}}. \quad (18.32)$$

低频  $\theta \rightarrow 0$  时,  $c_{\text{ph},h} \rightarrow c$ ,  $c_{\text{gr},h} \rightarrow c$ 。高频则传播速度失真。

当  $\lambda = 1$ , 有  $\omega_h\tau = \theta$  在主支上成立, 因此离散相速度等于真实速度:  $c_{\text{ph},h} = c$ 。

#### 18.2.5 知识点九: 离散能量

定义

$$\delta_t^+ U_j^n = \frac{U_j^{n+1} - U_j^n}{\tau}, \quad (18.33)$$

$$D_x^+ U_j^n = \frac{U_{j+1}^n - U_j^n}{h}. \quad (18.34)$$

对周期或齐次 Dirichlet 问题, 定义半时间层能量


$$E_h^{n+\frac{1}{2}} = \frac{1}{2} \|\delta_t^+ U^n\|_{2,h}^2 + \frac{c^2}{2} \langle D_x^+ U^{n+1}, D_x^+ U^n \rangle_h. \quad (18.35)$$

将格式乘以  $U_j^{n+1} - U_j^{n-1}$  并求和, 利用离散分部求和可得

$$E_h^{n+\frac{1}{2}} = E_h^{n-\frac{1}{2}}. \quad (18.36)$$

交叉空间项可重写为

$$\begin{aligned} \langle D_x^+ U^{n+1}, D_x^+ U^n \rangle_h &= \left\| D_x^+ \frac{U^{n+1} + U^n}{2} \right\|_{2,h}^2 \\ &\quad - \frac{1}{4} \|D_x^+ (U^{n+1} - U^n)\|_{2,h}^2. \end{aligned} \quad (18.37)$$





利用离散逆估计  $\|D_x^+ v\|_{2,h} \leq \frac{2}{h} \|v\|_{2,h}$ , 可见当  $|\lambda| < 1$  时, 离散能量与  $\|\delta_t^+ U^n\|_{2,h}^2 + c^2 \left\| D_x^+ \frac{U^{n+1} + U^n}{2} \right\|_{2,h}^2$  一致等价。

---

**Algorithm 71** 波动方程 Störmer–Leapfrog 中心格式

---

**Input:** 波速  $c > 0$ ; 空间区间; 初位移  $f$ ; 初速度  $g$ ; 源项  $s$ ; 网格步长  $h, \tau$

**Output:**  $U_j^n \approx u(x_j, t_n)$

- 1: **Initialization:** 计算  $\lambda \leftarrow c\tau/h$  并检查  $|\lambda| \leq 1$ 。令  $U_j^0 \leftarrow f(x_j)$
  - 2: 由  $U_j^1 = U_j^0 + \tau g(x_j) + \frac{\tau^2}{2} [c^2 \delta_x^2 U_j^0 + s_j^0]$  构造二阶起步层
  - 3: **for**  $n = 1, 2, \dots, N_t - 1$  **do**
  - 4:     **for** 每个内部节点  $j$  **do**
  - 5:          $U_j^{n+1} \leftarrow 2U_j^n - U_j^{n-1} + \lambda^2 (U_{j+1}^n - 2U_j^n + U_{j-1}^n) + \tau^2 s_j^n$
  - 6:     **end for**
  - 7:     施加第  $n+1$  层边界条件
  - 8:     可选: 监测离散能量  $E_h^{n+\frac{1}{2}}$
  - 9: **end for**
  - 10: **Stopping criterion:** 达到终止时间或能量/误差触发停止条件
  - 11: **Complexity:** 设空间未知量为  $N_h$ 。每步运算  $O(N_h)$ , 只需保存三个时间层, 存储  $O(N_h)$
- 

## 18.3 补充训练题: Störmer 方法与波动方程中心格式

完整题目叙述: [FDM-Set-2019T-Q1]

考虑二阶常微分方程组

$$y'' = f(t, y), \quad y(0) = y_0, \quad y'(0) = y'_0. \quad (18.38)$$

Störmer 方法为

$$y_{n+2} - 2y_{n+1} + y_n = h^2 f(t_{n+1}, y_{n+1}), \quad n \geq 0. \quad (18.39)$$

要求:

- (i) 确定 Störmer 方法的阶;
- (ii) 对波动方程  $u_{tt} = u_{xx}$  使用空间二阶中心差分和时间 Störmer 方法构造格式;
- (iii) 求稳定性条件。

第 (i) 问: Störmer 方法的阶. 在  $t_{n+1}$  处 Taylor 展开:

$$y(t_{n+2}) = y(t_{n+1}) + hy' + \frac{h^2}{2} y'' + \frac{h^3}{6} y''' + \frac{h^4}{24} y^{(4)} + O(h^5), \quad (18.40)$$

$$y(t_n) = y(t_{n+1}) - hy' + \frac{h^2}{2} y'' - \frac{h^3}{6} y''' + \frac{h^4}{24} y^{(4)} + O(h^5). \quad (18.41)$$


相加后

$$y(t_{n+2}) - 2y(t_{n+1}) + y(t_n) = h^2 y''(t_{n+1}) + \frac{h^4}{12} y^{(4)}(t_{n+1}) + O(h^6). \quad (18.42)$$

所以一步未归一化缺陷为  $O(h^4)$ , 归一化截断误差为  $O(h^2)$ 。在零稳定且起步层二阶准确时, Störmer 方法的整体阶为

$$\boxed{2}. \quad (18.43)$$

□



第 (ii) 问: 波动方程格式. 令空间步长为  $\Delta x$ , 时间步长为  $\Delta t$ . 得到

$$\frac{U_j^{n+1} - 2U_j^n + U_j^{n-1}}{(\Delta t)^2} = \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{(\Delta x)^2}. \quad (18.44)$$

□

第 (iii) 问: 稳定性. 令  $\lambda = \frac{\Delta t}{\Delta x}$ . 代入 Fourier 模态  $U_j^n = z^n e^{ij\theta}$  得到  $z^2 - 2(1 - 2\lambda^2 \sin^2 \frac{\theta}{2})z + 1 = 0$ . 其根位于单位圆上的条件为  $\lambda^2 \sin^2 \frac{\theta}{2} \leq 1 \quad \forall \theta$ . 故标准 CFL 条件为

$$\frac{\Delta t}{\Delta x} \leq 1. \quad (18.45)$$

若要求对任意两层初值均满足严格统一根条件, 则应取  $\frac{\Delta t}{\Delta x} < 1$ . 等号情形的最高频模态出现重根, 需要与起步层兼容性一起讨论. □

## 18.4 隐式三层波动格式与无条件能量稳定性

### 18.4.1 知识点十: 时间-空间平均格式

设  $A_h = -\delta_x^2$  为非负对称离散算子. 考虑

$$\frac{U^{n+1} - 2U^n + U^{n-1}}{\tau^2} + A_h \left[ \frac{1}{4}U^{n+1} + \frac{1}{2}U^n + \frac{1}{4}U^{n-1} \right] = 0. \quad (18.46)$$

定义半时间层量

$$V^{n+\frac{1}{2}} = \frac{U^{n+1} - U^n}{\tau}, \quad (18.47)$$

$$Q^{n+\frac{1}{2}} = \frac{U^{n+1} + U^n}{2}. \quad (18.48)$$

则格式可改写为

$$\frac{V^{n+\frac{1}{2}} - V^{n-\frac{1}{2}}}{\tau} + A_h \frac{Q^{n+\frac{1}{2}} + Q^{n-\frac{1}{2}}}{2} = 0. \quad (18.49)$$

注意恒等式

$$V^{n+\frac{1}{2}} + V^{n-\frac{1}{2}} = \frac{2}{\tau} (Q^{n+\frac{1}{2}} - Q^{n-\frac{1}{2}}). \quad (18.50)$$

将式 (18.49) 与  $V^{n+\frac{1}{2}} + V^{n-\frac{1}{2}}$  作内积, 得到

$$\mathcal{E}_h^{n+\frac{1}{2}} = \mathcal{E}_h^{n-\frac{1}{2}}, \quad (18.51)$$

其中

$$\mathcal{E}_h^{n+\frac{1}{2}} = \frac{1}{2} \|V^{n+\frac{1}{2}}\|_h^2 + \frac{1}{2} \langle A_h Q^{n+\frac{1}{2}}, Q^{n+\frac{1}{2}} \rangle_h. \quad (18.52)$$

由于  $A_h \geq 0$ , 该能量非负, 且不要求  $\tau/h$  满足 CFL 限制.

## 18.5 正式真题 [25F-Q5]——波动方程隐式三层格式



完整题目叙述: [25F-Q5]

对波动方程

$$u_{tt} = u_{xx}, \quad (18.53)$$

分析下列格式的稳定性:

$$\begin{aligned} \frac{U_j^{n+1} - 2U_j^n + U_j^{n-1}}{\tau^2} &= \frac{U_{j+1}^{n+1} - 2U_j^{n+1} + U_{j-1}^{n+1}}{4h^2} \\ &\quad + \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{2h^2} \\ &\quad + \frac{U_{j+1}^{n-1} - 2U_j^{n-1} + U_{j-1}^{n-1}}{4h^2}. \end{aligned} \quad (18.54)$$

第一种证明: Fourier 根条件. 令  $\lambda = \frac{\tau}{h}$ ,  $s = \sin \frac{\theta}{2}$ , 并代入  $U_j^n = z^n e^{ij\theta}$ . 离散 Laplace 符号为  $-\frac{4s^2}{h^2}$ . 因此

$$z^2 - 2z + 1 = -\lambda^2 s^2 (z^2 + 2z + 1). \quad (18.55)$$

即

$$(z-1)^2 + q(z+1)^2 = 0, \quad q = \lambda^2 s^2 \geq 0. \quad (18.56)$$

当  $q > 0$  时,  $z-1 = \pm i\sqrt{q}(z+1)$ . 故

$$z_{\pm} = \frac{1 \pm i\sqrt{q}}{1 \mp i\sqrt{q}}. \quad (18.57)$$

分子、分母互为共轭, 因而  $|z_{\pm}| = 1$ . 当  $q > 0$  时两根互异。

当  $q = 0$  时,  $(z-1)^2 = 0$ . 这对应空间常数模态. 连续方程在该模态上退化为  $\hat{u}_{tt} = 0$ , 其解本来就是  $\hat{u}(t) = a + bt$ , 因此位移可以线性增长, 但速度保持有界. 若稳定性状态向量包含位移与离散速度, 并采用相容起步层, 则固定时间区间内仍有一致估计。

故该格式对任意  $\lambda = \tau/h$  均无高频指数增长, 即

$$\boxed{\text{格式无条件稳定}}. \quad (18.58)$$

□

第二种证明: 离散能量. 令  $A_h = -\delta_x^2$ . 则格式恰为  $\frac{U^{n+1} - 2U^n + U^{n-1}}{\tau^2} + A_h [\frac{1}{4}U^{n+1} + \frac{1}{2}U^n + \frac{1}{4}U^{n-1}] = 0$ . 由式 (18.51), 有

$$\mathcal{E}_h^{n+\frac{1}{2}} = \mathcal{E}_h^{n-\frac{1}{2}}, \quad (18.59)$$

其中

$$\mathcal{E}_h^{n+\frac{1}{2}} = \frac{1}{2} \left\| \frac{U^{n+1} - U^n}{\tau} \right\|_{2,h}^2 + \frac{1}{2} \left\| D_x^+ \frac{U^{n+1} + U^n}{2} \right\|_{2,h}^2. \quad (18.60)$$

该能量对任意  $\tau, h > 0$  均非负, 因此无条件稳定. □

补充: 截断误差. 时间中心差分为  $u_{tt} + \frac{\tau^2}{12}u_{tttt} + O(\tau^4)$ . 右端时间平均满足

$$\frac{1}{4}u_{xx}^{n+1} + \frac{1}{2}u_{xx}^n + \frac{1}{4}u_{xx}^{n-1} = u_{xx} + \frac{\tau^2}{4}u_{xxtt} + O(\tau^4). \quad (18.61)$$

再考虑空间中心差分误差:  $\delta_x^2 u = u_{xx} + \frac{h^2}{12}u_{xxxx} + O(h^4)$ . 故

$$\mathcal{T} = \frac{\tau^2}{12}u_{tttt} - \frac{\tau^2}{4}u_{xxtt} - \frac{h^2}{12}u_{xxxx} + O(\tau^4 + \tau^2 h^2 + h^4). \quad (18.62)$$



由  $u_{tttt} = u_{xxtt} = u_{xxxx}$ , 得到

$$\mathcal{T} = -\left(\frac{\tau^2}{6} + \frac{h^2}{12}\right) u_{xxxx} + O(\tau^4 + \tau^2 h^2 + h^4). \quad (18.63)$$

所以格式时间、空间均为二阶。  $\square$

注 18.1 (离散色散关系). 令  $z = e^{-i\omega_h \tau}$ . 由式 (18.56),  $\frac{z-1}{z+1} = -i \tan \frac{\omega_h \tau}{2}$ . 因此

$$\tan\left(\frac{\omega_h \tau}{2}\right) = \lambda \sin\left(\frac{\theta}{2}\right). \quad (18.64)$$

与显式中心格式的  $\sin(\omega_h \tau/2) = \lambda \sin(\theta/2)$  不同. 隐式格式无 CFL 不稳定, 但仍存在相位误差.

#### 复杂度说明

每个时间步需解

$$\left(I + \frac{\tau^2}{4} A_h\right) U^{n+1} = \text{已知右端}. \quad (18.65)$$

一维 Dirichlet 问题中矩阵为对称正定三对角矩阵:

- 一次分解成本  $O(N_h)$ ;
- 每步前后代入成本  $O(N_h)$ ;
- 存储成本  $O(N_h)$ ;
- 固定  $\tau, h$  时分解可重复使用。

二维问题中应使用稀疏 Cholesky、PCG、多重网格或 FFT 型快速求解器。

## 18.6 一阶线性双曲系统与特征分解

### 18.6.1 知识点十一: 对称双曲系统

考虑

$$W_t + A W_x = 0, \quad W(x, t) \in \mathbb{R}^m, \quad (18.66)$$

其中  $A = A^\top$ . 存在正交矩阵  $Q$  和实对角矩阵  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$  使  $A = Q \Lambda Q^\top$ . 令  $Z = Q^\top W$ , 则系统解耦为

$$(Z_\ell)_t + \lambda_\ell (Z_\ell)_x = 0. \quad (18.67)$$

因此每个特征分量沿速度  $\lambda_\ell$  传播。

### 18.6.2 知识点十二: 连续能量与边界条件个数

对  $A = A^\top$ , 有

$$\frac{d}{dt} \frac{1}{2} \int_a^b \|W(x, t)\|_2^2 dx = -\frac{1}{2} [W^\top A W]_{x=a}^{x=b}. \quad (18.68)$$

在左端点:

- $\lambda_\ell > 0$  的特征分量进入区域;



- $\lambda_\ell < 0$  的特征分量离开区域。

在右端点恰好相反。

因此每个边界应只给定进入区域的特征分量。边界条件过多会过定，过少会欠定。

#### 易错点与反例

对双曲系统，边界条件个数不是简单等于未知量个数。

必须：

1. 对法向通量矩阵作特征分解；
2. 统计入射特征值；
3. 只对入射特征变量给条件；
4. 出射特征变量由内部解决定。

### 18.6.3 知识点十三：增长矩阵

若差分格式写为

$$W_j^{n+1} = \sum_{\ell=-r}^s B_\ell W_{j+\ell}^n, \quad (18.69)$$

则 Fourier 增长矩阵为

$$G(\theta) = \sum_{\ell=-r}^s B_\ell e^{i\ell\theta}. \quad (18.70)$$

系统稳定性要求

$$\sup_{\theta} \sup_{n\tau \leq T} \|G(\theta)^n\| \leq C_T. \quad (18.71)$$

若  $G(\theta)$  正规，则  $\|G(\theta)^n\|_2 = \rho(G(\theta))^n$ 。此时检查特征值模即可。

若  $G(\theta)$  非正规，即使  $\rho(G(\theta)) \leq 1$ ，仍可能出现：

- 大的暂态放大；
- 特征向量矩阵条件数恶化；
- Jordan 块引起多项式增长；
- 边界闭合导致整体算子非正规。

因此不能无条件地用“所有增长矩阵特征值模不超过 1”替代幂有界性。

## 18.7 正式真题 [24F-Q4]——耦合双曲系统的 Lax-Friedrichs 型格式

完整题目叙述：[24F-Q4]

考虑系统

$$u_t = v_x, \quad v_t = u_x. \quad (18.72)$$

分析差分格式

$$\frac{1}{\tau} \left[ U_j^{n+1} - \frac{1}{2} (U_{j+1}^n + U_{j-1}^n) \right] = \frac{V_{j+1}^n - V_{j-1}^n}{2h}, \quad (18.73)$$

$$\frac{1}{\tau} \left[ V_j^{n+1} - \frac{1}{2} (V_{j+1}^n + V_{j-1}^n) \right] = \frac{U_{j+1}^n - U_{j-1}^n}{2h}. \quad (18.74)$$

求其截断误差和稳定性。

第一步：向量形式. 令  $W = \begin{pmatrix} u \\ v \end{pmatrix}$ ,  $A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ . 连续系统为

$$W_t = AW_x. \quad (18.75)$$

差分格式为

$$W_j^{n+1} = \frac{1}{2} (W_{j+1}^n + W_{j-1}^n) + \frac{\lambda}{2} A (W_{j+1}^n - W_{j-1}^n), \quad \lambda = \frac{\tau}{h}. \quad (18.76)$$

□

第二步：截断误差. 定义归一化残差

$$\mathcal{T} = \frac{W(x, t + \tau) - \frac{1}{2} [W(x + h, t) + W(x - h, t)]}{\tau} - A \frac{W(x + h, t) - W(x - h, t)}{2h}. \quad (18.77)$$

Taylor 展开:

$$W(x, t + \tau) = W + \tau W_t + \frac{\tau^2}{2} W_{tt} + \frac{\tau^3}{6} W_{ttt} + O(\tau^4), \quad (18.78)$$

$$\frac{1}{2} [W(x + h, t) + W(x - h, t)] = W + \frac{h^2}{2} W_{xx} + \frac{h^4}{24} W_{xxxx} + O(h^6), \quad (18.79)$$

$$\frac{W(x + h, t) - W(x - h, t)}{2h} = W_x + \frac{h^2}{6} W_{xxx} + O(h^4). \quad (18.80)$$

于是

$$\begin{aligned} \mathcal{T} &= W_t - AW_x + \frac{\tau}{2} W_{tt} - \frac{h^2}{2\tau} W_{xx} \\ &\quad + \frac{\tau^2}{6} W_{ttt} - \frac{h^2}{6} AW_{xxx} - \frac{h^4}{24\tau} W_{xxxx} + O(\tau^3 + h^4). \end{aligned} \quad (18.81)$$

因为  $A^2 = I$ , 由 PDE 得到

$$W_{tt} = W_{xx}, \quad (18.82)$$

$$W_{ttt} = AW_{xxx}. \quad (18.83)$$

故

$$\mathcal{T} = \frac{1}{2} \left( \tau - \frac{h^2}{\tau} \right) W_{xx} + \frac{1}{6} (\tau^2 - h^2) AW_{xxx} + O \left( \tau^3 + \frac{h^4}{\tau} \right). \quad (18.84)$$


若  $\tau = \lambda h$ ,  $\lambda > 0$  固定, 则  $\mathcal{T} = O(h) = O(\tau)$ . 所以格式为一阶相容。

当  $\lambda = 1$ , 前两项同时消失; 此时格式在特征变量上成为精确网格平移。

□

第三步：特征变量解耦. 定义

$$p = u + v, \quad q = u - v. \quad (18.85)$$



连续方程化为

$$p_t = p_x, \quad (18.86)$$

$$q_t = -q_x. \quad (18.87)$$

离散格式化为

$$p_j^{n+1} = \frac{1+\lambda}{2} p_{j+1}^n + \frac{1-\lambda}{2} p_{j-1}^n, \quad (18.88)$$

$$q_j^{n+1} = \frac{1-\lambda}{2} q_{j+1}^n + \frac{1+\lambda}{2} q_{j-1}^n. \quad (18.89)$$

若  $|\lambda| \leq 1$ , 系数非负且和为 1, 故每个特征分量在最大范数下非扩张。  $\square$

第四步: 增长矩阵. 取 Fourier 模态  $W_j^n = \widehat{W}^n e^{ij\theta}$ . 增长矩阵为

$$G(\theta) = \cos \theta I + i\lambda \sin \theta A. \quad (18.90)$$

因为  $A = A^\top$ ,  $A^2 = I$ ,  $G(\theta)$  为正规矩阵。其特征值为

$$g_\pm(\theta) = \cos \theta \pm i\lambda \sin \theta. \quad (18.91)$$

因此

$$|g_\pm(\theta)|^2 = \cos^2 \theta + \lambda^2 \sin^2 \theta. \quad (18.92)$$

对所有频率有  $|g_\pm| \leq 1$  当且仅当

$$|\lambda| = \left| \frac{\tau}{h} \right| \leq 1. \quad (18.93)$$

故格式在周期/Cauchy 问题上  $L^2$  稳定。  $\square$

注 18.2 (数值耗散). 对  $|\lambda| < 1$  和非特殊频率,  $|g_\pm(\theta)| < 1$ . 因此格式具有 Lax–Friedrichs 型数值耗散。

当  $|\lambda| = 1$ , 有  $|g_\pm(\theta)| = 1$ , 且特征分量恰好平移一个网格点, 不产生数值耗散。

## 18.8 耦合色散系统与 Crank–Nicolson 的酉结构

### 18.8.1 知识点十四: 实耦合系统与复数形式

考虑


$$u_t = -v_{xx}, \quad v_t = u_{xx}. \quad (18.94)$$

令

$$w = u + iv. \quad (18.95)$$

则

$$\begin{aligned} w_t &= u_t + iv_t \\ &= -v_{xx} + iu_{xx} \\ &= i(u_{xx} + iv_{xx}) \\ &= iw_{xx}. \end{aligned} \quad (18.96)$$





因此

$$\boxed{w_t = iw_{xx}} \quad (18.97)$$

或等价地  $iw_t = -w_{xx}$ 。

周期或齐次适当边界下,  $\frac{d}{dt} \|w\|_{L^2}^2 = 0$ 。在实变量中即

$$\frac{d}{dt} \int (u^2 + v^2) dx = 0. \quad (18.98)$$

### 18.8.2 知识点十五: Cayley 变换

设半离散系统为

$$\mathbf{w}'(t) = K_h \mathbf{w}(t), \quad K_h^* = -K_h. \quad (18.99)$$

Crank–Nicolson 格式为

$$\frac{\mathbf{w}^{n+1} - \mathbf{w}^n}{\tau} = K_h \frac{\mathbf{w}^{n+1} + \mathbf{w}^n}{2}. \quad (18.100)$$

传播矩阵为

$$S_h = \left(I - \frac{\tau}{2} K_h\right)^{-1} \left(I + \frac{\tau}{2} K_h\right). \quad (18.101)$$

这是反 Hermitian 矩阵的 Cayley 变换。直接计算可得

$$S_h^* S_h = I. \quad (18.102)$$

故  $\|\mathbf{w}^{n+1}\|_2 = \|\mathbf{w}^n\|_2$ 。

## 18.9 正式真题 [25S-Q4]——耦合色散系统的 Crank–Nicolson 格式

完整题目叙述: [25S-Q4]

对系统

$$u_t = -v_{xx}, \quad v_t = u_{xx}, \quad (18.103)$$

分析下列格式的截断误差和稳定性:

$$\begin{aligned} \frac{U_j^{n+1} - U_j^n}{\tau} &= -\frac{1}{2h^2} \left[ V_{j+1}^n - 2V_j^n + V_{j-1}^n \right. \\ &\quad \left. + V_{j+1}^{n+1} - 2V_j^{n+1} + V_{j-1}^{n+1} \right], \end{aligned} \quad (18.104)$$

$$\begin{aligned} \frac{V_j^{n+1} - V_j^n}{\tau} &= \frac{1}{2h^2} \left[ U_{j+1}^n - 2U_j^n + U_{j-1}^n \right. \\ &\quad \left. + U_{j+1}^{n+1} - 2U_j^{n+1} + U_{j-1}^{n+1} \right]. \end{aligned} \quad (18.105)$$

第一步: 复数化. 令  $W_j^n = U_j^n + iV_j^n$ 。则两式合并为

$$\boxed{\frac{W_j^{n+1} - W_j^n}{\tau} = \frac{i}{2} \delta_x^2 (W_j^{n+1} + W_j^n)}. \quad (18.106)$$

这就是  $w_t = iw_{xx}$  的 Crank–Nicolson 格式。 □

第二步：截断误差. 以中点  $t_{n+\frac{1}{2}}$  为展开中心。时间差商满足

$$\frac{w^{n+1} - w^n}{\tau} = w_t + \frac{\tau^2}{24} w_{ttt} + O(\tau^4). \quad (18.107)$$

时间平均的空间差分满足

$$\begin{aligned} \frac{1}{2} \delta_x^2 (w^{n+1} + w^n) &= w_{xx} + \frac{\tau^2}{8} w_{xxtt} + \frac{h^2}{12} w_{xxxx} \\ &\quad + O(\tau^4 + \tau^2 h^2 + h^4). \end{aligned} \quad (18.108)$$

因此残差为

$$\begin{aligned} \mathcal{T}_w &= w_t - i w_{xx} + \frac{\tau^2}{24} w_{ttt} - \frac{i\tau^2}{8} w_{xxtt} - \frac{ih^2}{12} w_{xxxx} \\ &\quad + O(\tau^4 + \tau^2 h^2 + h^4). \end{aligned} \quad (18.109)$$

由  $w_t = i w_{xx}$  得到

$$w_{tt} = -w_{xxxx}, \quad (18.110)$$

$$w_{ttt} = -i w_{xxxxx}, \quad (18.111)$$

$$w_{xxtt} = -w_{xxxxx}. \quad (18.112)$$

故

$$\boxed{\mathcal{T}_w = \frac{i\tau^2}{12} w_{xxxxx} - \frac{ih^2}{12} w_{xxxx} + O(\tau^4 + \tau^2 h^2 + h^4)}. \quad (18.113)$$

所以格式为  $O(\tau^2 + h^2)$ 。  $\square$

第三步：Fourier 稳定性. 离散 Laplace 算子的 Fourier 符号为  $-\delta_h(\theta)$ ,  $\delta_h(\theta) = \frac{4}{h^2} \sin^2 \frac{\theta}{2} \geq 0$ 。代入  $W_j^n = \widehat{W}^n e^{ij\theta}$ , 得到

$$\frac{\widehat{W}^{n+1} - \widehat{W}^n}{\tau} = -\frac{i\delta_h}{2} (\widehat{W}^{n+1} + \widehat{W}^n). \quad (18.114)$$

令  $\alpha = \frac{\tau\delta_h}{2} \geq 0$ 。则

$$(1 + i\alpha) \widehat{W}^{n+1} = (1 - i\alpha) \widehat{W}^n. \quad (18.115)$$

增长因子为

$$\boxed{G(\theta) = \frac{1 - i\alpha}{1 + i\alpha}}. \quad (18.116)$$

因此

$$\boxed{|G(\theta)| = 1 \quad \forall \tau, h > 0}. \quad (18.117)$$

故格式无条件  $L^2$  稳定, 并且无数值耗散。  $\square$

第四步：实变量离散质量守恒. 定义  $\overline{U}^{n+\frac{1}{2}} = \frac{U^{n+1} + U^n}{2}$ ,  $\overline{V}^{n+\frac{1}{2}} = \frac{V^{n+1} + V^n}{2}$ 。格式写为

$$U^{n+1} - U^n = -\tau \delta_x^2 \overline{V}^{n+\frac{1}{2}}, \quad (18.118)$$

$$V^{n+1} - V^n = \tau \delta_x^2 \overline{U}^{n+\frac{1}{2}}. \quad (18.119)$$

第一式与  $U^{n+1} + U^n$  作内积, 第二式与  $V^{n+1} + V^n$  作内积, 并相加:

$$\begin{aligned} &\|U^{n+1}\|_{2,h}^2 - \|U^n\|_{2,h}^2 + \|V^{n+1}\|_{2,h}^2 - \|V^n\|_{2,h}^2 \\ &= -2\tau \langle \delta_x^2 \overline{V}, \overline{U} \rangle_h + 2\tau \langle \delta_x^2 \overline{U}, \overline{V} \rangle_h \\ &= 0, \end{aligned} \quad (18.120)$$



因为周期或齐次边界下  $\delta_x^2$  自伴。故

$$\|U^{n+1}\|_{2,h}^2 + \|V^{n+1}\|_{2,h}^2 = \|U^n\|_{2,h}^2 + \|V^n\|_{2,h}^2. \quad (18.121)$$

□

注 18.3 (相位误差). 虽然  $|G| = 1$ , 但增长因子的相位为  $\arg G = -2 \arctan \alpha$ . 因此数值频率满足

$$\omega_h \tau = 2 \arctan \left[ \frac{2\tau}{h^2} \sin^2 \frac{\theta}{2} \right]. \quad (18.122)$$

无耗散不等于无色散误差。

#### 复杂度说明

每步需求解一个实  $2N_h \times 2N_h$  块线性系统, 或一个复数  $N_h \times N_h$  系统:  $(I - \frac{i\tau}{2} \delta_x^2) W^{n+1} = (I + \frac{i\tau}{2} \delta_x^2) W^n$ .

- 一维 Dirichlet 问题: 复三对角求解,  $O(N_h)$ ;
- 周期常数问题: FFT 对角化,  $O(N_h \log N_h)$ ;
- 固定步长时, 可复用矩阵分解;
- 不应显式形成传播矩阵的逆。

## 18.10 三阶色散方程的连续与半离散结构

### 18.10.1 知识点十六: 连续适定性

考虑

$$u_t + au_{xxx} = 0, \quad x \in \mathbb{R} \quad \text{或周期区间}, \quad (18.123)$$

其中  $a \in \mathbb{R}$ . 取 Fourier 变换约定  $\widehat{u}(\xi, t) = \int_{\mathbb{R}} u(x, t) e^{-i\xi x} dx$ . 有  $\widehat{u_{xxx}} = (i\xi)^3 \widehat{u} = -i\xi^3 \widehat{u}$ . 因此

$$\widehat{u}_t - ia\xi^3 \widehat{u} = 0. \quad (18.124)$$

解为

$$\widehat{u}(\xi, t) = e^{ia\xi^3 t} \widehat{u}_0(\xi). \quad (18.125)$$

由于  $|e^{ia\xi^3 t}| = 1$ , 对任意  $s \in \mathbb{R}$ , 有

$$\|u(t)\|_{H^s} = \|u_0\|_{H^s}. \quad (18.126)$$

所以 Cauchy 问题在  $H^s$  中适定。

其连续色散关系为

$$\omega(\xi) = -a\xi^3 \quad (18.127)$$

或按另一相位约定写为  $\omega = a\xi^3$ . 相速度与群速度分别为

$$c_{\text{ph}}(\xi) = \frac{\omega(\xi)}{\xi}, \quad (18.128)$$

$$c_{\text{gr}}(\xi) = \omega'(\xi). \quad (18.129)$$

因此不同频率以不同速度传播, 表现为色散而非扩散。



## 18.10.2 知识点十七：中心三阶差分算子

定义

$$D_{3,h}U_j = \frac{U_{j+2} - 2U_{j+1} + 2U_{j-1} - U_{j-2}}{2h^3}. \quad (18.130)$$

Taylor 展开给出

$$D_{3,h}u_j = u_{xxx}(x_j) + \frac{h^2}{4}u_{xxxx}(x_j) + O(h^4). \quad (18.131)$$

Fourier 符号为

$$\begin{aligned} \hat{D}_{3,h}(\theta) &= \frac{e^{2i\theta} - 2e^{i\theta} + 2e^{-i\theta} - e^{-2i\theta}}{2h^3} \\ &= -\frac{4i}{h^3} \sin \theta \sin^2 \frac{\theta}{2}. \end{aligned} \quad (18.132)$$

它是纯虚数符号。周期边界下

$$D_{3,h}^* = -D_{3,h}, \quad (18.133)$$

即离散算子反对称。

因此半离散系统

$$\frac{dU}{dt} + aD_{3,h}U = 0 \quad (18.134)$$

满足

$$\frac{d}{dt} \|U\|_{2,h}^2 = 0. \quad (18.135)$$

## 易错点与反例

空间半离散守恒不代表任意时间离散都稳定。

例如显式 Euler:  $U^{n+1} = (I - \tau a D_{3,h})U^n$ 。对纯虚特征值  $i\beta$ ，增长因子为  $1 - i\tau\beta$ ，其模  $\sqrt{1 + \tau^2\beta^2} > 1$ 。所以显式 Euler 对纯色散半离散系统不稳定。

## 18.11 正式真题 [23F-Q5]——三阶色散方程的 Lax 型格式

完整题目叙述：[23F-Q5]

对方程

$$u_t + au_{xxx} = 0 \quad (18.136)$$

考虑格式

$$\begin{aligned} U_m^{n+1} &= \frac{1}{2} (U_{m+1}^n + U_{m-1}^n) \\ &\quad - \frac{ak}{2h^3} (U_{m+2}^n - 2U_{m+1}^n + 2U_{m-1}^n - U_{m-2}^n). \end{aligned} \quad (18.137)$$

要求：

1. 求局部截断误差的主导项；
2. 分析格式的稳定性。

第一问：局部截断误差。将格式改写为

$$\frac{U_m^{n+1} - \frac{1}{2} (U_{m+1}^n + U_{m-1}^n)}{k} + aD_{3,h}U_m^n = 0. \quad (18.138)$$

精确解代入。首先

$$u(x, t+k) = u + ku_t + \frac{k^2}{2}u_{tt} + \frac{k^3}{6}u_{ttt} + O(k^4), \quad (18.139)$$

$$\frac{1}{2}[u(x+h, t) + u(x-h, t)] = u + \frac{h^2}{2}u_{xx} + \frac{h^4}{24}u_{xxxx} + O(h^6), \quad (18.140)$$

$$D_{3,h}u = u_{xxx} + \frac{h^2}{4}u_{xxxxx} + O(h^4). \quad (18.141)$$

故归一化残差为

$$\begin{aligned} \mathcal{T} = & u_t + au_{xxx} - \frac{h^2}{2k}u_{xx} + \frac{k}{2}u_{tt} \\ & - \frac{h^4}{24k}u_{xxxx} + \frac{ah^2}{4}u_{xxxxx} + \frac{k^2}{6}u_{ttt} + O\left(\frac{h^6}{k} + h^4 + k^3\right). \end{aligned} \quad (18.142)$$

利用 PDE, 前两项抵消。因此主导局部截断误差为

$$\boxed{\mathcal{T} = -\frac{h^2}{2k}u_{xx} + \frac{k}{2}u_{tt} + \text{高阶项}}. \quad (18.143)$$

若采用未除以  $k$  的一步缺陷定义, 则主导项为

$$\boxed{-\frac{h^2}{2}u_{xx} + \frac{k^2}{2}u_{tt}}. \quad (18.144)$$

要使归一化截断误差趋于零, 至少需要

$$k \rightarrow 0, \quad \frac{h^2}{k} \rightarrow 0. \quad (18.145)$$

□

第二问: *Fourier* 稳定性. 令  $r = \frac{ak}{h^3}$ . 对 *Fourier* 模态  $U_m^n = \widehat{U}^n e^{im\theta}$ , 有

$$\frac{1}{2}(e^{i\theta} + e^{-i\theta}) = \cos \theta, \quad (18.146)$$

$$e^{2i\theta} - 2e^{i\theta} + 2e^{-i\theta} - e^{-2i\theta} = -8i \sin \theta \sin^2 \frac{\theta}{2}. \quad (18.147)$$

故增长因子为

$$\boxed{G(\theta) = \cos \theta + 4ir \sin \theta \sin^2 \frac{\theta}{2}}. \quad (18.148)$$

令  $s = \sin \frac{\theta}{2}$ . 则  $\cos \theta = 1 - 2s^2$ ,  $\sin^2 \theta = 4s^2(1 - s^2)$ . 直接计算:

$$|G|^2 = \cos^2 \theta + 16r^2 \sin^2 \theta s^4, \quad (18.149)$$

$$1 - |G|^2 = 4s^2(1 - s^2)(1 - 16r^2 s^4). \quad (18.150)$$

由于  $0 \leq s^2 \leq 1$ , 要使  $|G(\theta)| \leq 1 \quad \forall \theta$ , 充要条件为

$$\boxed{|r| = \left| \frac{ak}{h^3} \right| \leq \frac{1}{4}}. \quad (18.151)$$

□

推论 18.4 (稳定性与相容性的冲突). 稳定条件要求  $k \leq Ch^3$ . 于是  $\frac{h^2}{k} \geq \frac{1}{Ch} \rightarrow \infty$ . 但相容性要求  $\frac{h^2}{k} \rightarrow 0$ . 因此不存在同时满足稳定性和相容性的网格路径。

所以

$$\boxed{\text{该格式虽然存在 } Fourier \text{ 稳定区间, 但不是原 PDE 的收敛格式}}. \quad (18.152)$$

## 易错点与反例

该题的核心不是只求  $|ak/h^3| \leq 1/4$ 。还必须检查：  
 稳定网格路径 与 截断误差趋零路径 是否兼容。  
 “格式在某些参数下稳定”不推出“格式收敛”。

## 18.12 补充训练题：丘赛 2024 Problem 5——三阶色散方程适定性与中心三层格式

完整题目叙述：[Yau-2024-Problem-5]

考虑 Cauchy 问题

$$u_t = u_{xxx}, \quad u(x, 0) = u_0(x), \quad x \in \mathbb{R}. \quad (18.153)$$

(a) 说明该问题的适定性；

(b) 对题面给出的中心三层格式作稳定性分析：

$$\frac{U_j^{n+1} - U_j^{n-1}}{2k} = \frac{1}{h} \left[ -\frac{1}{2}U_{j-2}^n + U_{j-1}^n - U_{j+1}^n + \frac{1}{2}U_{j+2}^n \right]. \quad (18.154)$$

第 (a) 问：适定性。对 PDE 作 Fourier 变换： $\widehat{u_{xxx}} = -i\xi^3 \widehat{u}$ 。所以  $\widehat{u}_t = -i\xi^3 \widehat{u}$ 。其解为

$$\widehat{u}(\xi, t) = e^{-i\xi^3 t} \widehat{u}_0(\xi). \quad (18.155)$$

从而  $|\widehat{u}(\xi, t)| = |\widehat{u}_0(\xi)|$ 。对任意  $s \in \mathbb{R}$ ,

$$\|u(t)\|_{H^s} = \|u_0\|_{H^s}. \quad (18.156)$$

所以解存在、唯一，并连续依赖于初值。  $\square$

第 (b) 问：按题面原式分析。设  $U_j^n = z^n e^{ij\theta}$ 。括号内符号为

$$\begin{aligned} & -\frac{1}{2}e^{-2i\theta} + e^{-i\theta} - e^{i\theta} + \frac{1}{2}e^{2i\theta} \\ & = 4i \sin \theta \sin^2 \frac{\theta}{2}. \end{aligned} \quad (18.157)$$

代入格式： $\frac{z-z^{-1}}{2k} = \frac{4i}{h} \sin \theta \sin^2 \frac{\theta}{2}$ 。即

$$z^2 - 2i\gamma(\theta)z - 1 = 0, \quad (18.158)$$


其中

$$\gamma(\theta) = 4\frac{k}{h} \sin \theta \sin^2 \frac{\theta}{2}. \quad (18.159)$$

符号正负取决于 Fourier 约定，但稳定条件只依赖  $|\gamma|$ 。

对实数  $\gamma$ ，特征根位于单位圆上且互异的条件为  $|\gamma| < 1$ 。计算最大值。令  $s = \sin \frac{\theta}{2}$ ,  $0 \leq s \leq 1$ 。则

$$4 \left| \sin \theta \sin^2 \frac{\theta}{2} \right| = 8s^3 \sqrt{1-s^2}. \quad (18.160)$$



其平方为  $64s^6(1-s^2)$ 。令  $x = s^2$ ，最大化  $64x^3(1-x)$ 。导数为  $64x^2(3-4x)$ ，最大值在  $x = \frac{3}{4}$  取得，因此

$$\max_{\theta} 4 \left| \sin \theta \sin^2 \frac{\theta}{2} \right| = \frac{3\sqrt{3}}{2}. \quad (18.161)$$

故严格根条件稳定性为

$$\boxed{\frac{k}{h} < \frac{2}{3\sqrt{3}}}. \quad (18.162)$$

等号时某一频率出现重单位根，可能产生线性增长，因此严格稳定条件使用“小于”。  $\square$

若分母修正为  $h^3$ 。若格式为

$$\frac{U_j^{n+1} - U_j^{n-1}}{2k} = \frac{1}{h^3} \left[ -\frac{1}{2}U_{j-2}^n + U_{j-1}^n - U_{j+1}^n + \frac{1}{2}U_{j+2}^n \right], \quad (18.163)$$

则空间离散为二阶： $D_{3,h}u = u_{xxx} + \frac{h^2}{4}u_{xxxxx} + O(h^4)$ 。同样分析给出

$$\boxed{\frac{k}{h^3} < \frac{2}{3\sqrt{3}}}. \quad (18.164)$$

该条件符合三阶色散算子最大离散频率为  $O(h^{-3})$  的尺度。  $\square$

#### 易错点与反例

本题应明确写出：

- 题面原式的空间分母；
- 原式是否与 PDE 相容；
- 若按标准三阶差分修正，稳定条件如何换算。

不能因熟悉标准公式而未经说明地把  $h$  改成  $h^3$ 。

## 18.13 高阶 Lax–Wendroff 构造：Taylor 法与特征回溯插值

### 18.13.1 知识点十八：两种等价构造观点

考虑  $u_t + au_x = 0$ ,  $a > 0$ 。精确解满足

$$u(x_j, t_{n+1}) = u(x_j - ak, t_n). \quad (18.165)$$

令  $\nu = \frac{ak}{h}$ 。要构造三阶格式，可以：

1. 对时间作三阶 Taylor 展开，并利用 PDE 把时间导数换为空间导数；
2. 在旧时间层用三次插值近似脚点  $x_j - \nu h$ 。

两种方法给出相同格式。





## 18.14 补充训练题：丘赛 2022 Problem 5——三阶 Lax-Wendroff 格式

完整题目叙述：[Yau-2022-Problem-5]

考虑

$$u_t + au_x = 0, \quad a > 0. \quad (18.166)$$

构造一个三阶 Lax-Wendroff 型显式差分格式。要求在  $h = O(k)$  时，局部归一化截断误差达到  $O(k^3)$ 。

第一种构造：特征脚点三次插值。精确特征回溯给出  $u_j^{n+1} = u(x_j - \nu h, t_n)$ ,  $\nu = \frac{ak}{h}$ 。选取四个旧时间层节点  $x_{j-2}, x_{j-1}, x_j, x_{j+1}$ 。以无量纲局部坐标  $\zeta = \frac{x-x_j}{h}$  表示，插值节点为  $-2, -1, 0, 1$ ，评价点为  $\zeta = -\nu$ 。

三次 Lagrange 插值给出

$$U_j^{n+1} = c_{-2}U_{j-2}^n + c_{-1}U_{j-1}^n + c_0U_j^n + c_1U_{j+1}^n, \quad (18.167)$$

其中

$$c_{-2} = \frac{\nu(\nu^2 - 1)}{6}, \quad (18.168)$$

$$c_{-1} = \frac{\nu(\nu + 1)(2 - \nu)}{2}, \quad (18.169)$$

$$c_0 = \frac{(1 - \nu)(1 + \nu)(2 - \nu)}{2}, \quad (18.170)$$

$$c_1 = -\frac{\nu(1 - \nu)(2 - \nu)}{6}. \quad (18.171)$$

容易验证  $c_{-2} + c_{-1} + c_0 + c_1 = 1$ 。 □

第二种构造：三阶 Taylor-Lax-Wendroff. 时间 Taylor 展开：

$$u^{n+1} = u^n + ku_t^n + \frac{k^2}{2}u_{tt}^n + \frac{k^3}{6}u_{ttt}^n + O(k^4). \quad (18.172)$$

由 PDE：

$$u_t = -au_x, \quad (18.173)$$

$$u_{tt} = a^2u_{xx}, \quad (18.174)$$

$$u_{ttt} = -a^3u_{xxx}. \quad (18.175)$$

故

$$u^{n+1} = u^n - ak u_x^n + \frac{a^2 k^2}{2} u_{xx}^n - \frac{a^3 k^3}{6} u_{xxx}^n + O(k^4). \quad (18.176)$$


在四点模板上，三次插值多项式给出

$$p'(x_j) = \frac{1}{h} \left[ \frac{1}{6}U_{j-2} - U_{j-1} + \frac{1}{2}U_j + \frac{1}{3}U_{j+1} \right], \quad (18.177)$$

$$p''(x_j) = \frac{U_{j-1} - 2U_j + U_{j+1}}{h^2}, \quad (18.178)$$

$$p'''(x_j) = \frac{-U_{j-2} + 3U_{j-1} - 3U_j + U_{j+1}}{h^3}. \quad (18.179)$$

代入式 (18.176) 并使用  $\nu = ak/h$ ，整理后恰得到式 (18.167)。 □



截断误差. 三次插值余项为

$$\begin{aligned} & u(x_j - \nu h, t_n) - p_3(x_j - \nu h) \\ &= \frac{u^{(4)}(\xi_j, t_n)}{4!} \prod_{r \in \{-2, -1, 0, 1\}} [(-\nu - r)h] \\ &= \frac{h^4}{24} \nu(1 + \nu)(1 - \nu)(2 - \nu) u^{(4)}(\xi_j, t_n). \end{aligned} \quad (18.180)$$

因此一步缺陷为  $O(h^4)$ 。除以时间步  $k$  后, 归一化局部截断误差为

$$\mathcal{T} = O\left(\frac{h^4}{k}\right). \quad (18.181)$$

若  $h = O(k)$ , 则

$$\boxed{\mathcal{T} = O(k^3)}. \quad (18.182)$$

所以该格式为三阶 Lax-Wendroff 型格式。  $\square$

注 18.5 (稳定性与单调性). 题目主要要求构造与精度。需要注意:

- 四个系数不一定全非负;
- 三阶线性格式一般不具单调性;
- 在间断或尖锐梯度附近可能出现振荡;
- 实际高分辨率算法需要限制器、ENO 或 WENO 型非线性重构。

## 18.15 Lax-Wendroff 格式的离散能量恒等式

### 18.15.1 知识点十九: 算子形式

对  $u_t + au_x = 0$ , Lax-Wendroff 格式为

$$U_j^{n+1} = U_j^n - \frac{\nu}{2} (U_{j+1}^n - U_{j-1}^n) + \frac{\nu^2}{2} (U_{j+1}^n - 2U_j^n + U_{j-1}^n), \quad (18.183)$$

其中  $\nu = \frac{a\tau}{h}$ 。

定义无量纲差分算子

$$D_0 = \frac{E - E^{-1}}{2}, \quad (18.184)$$

$$\Delta = E - 2I + E^{-1}. \quad (18.185)$$

传播算子为

$$S = I - \nu D_0 + \frac{\nu^2}{2} \Delta. \quad (18.186)$$


周期或全直线  $\ell^2$  内积下,

$$D_0^* = -D_0, \quad (18.187)$$

$$\Delta^* = \Delta, \quad (18.188)$$

$$D_0 \Delta = \Delta D_0, \quad (18.189)$$

$$D_0^2 = \Delta + \frac{1}{4} \Delta^2. \quad (18.190)$$



于是

$$\begin{aligned} S^*S &= \left(I + \nu D_0 + \frac{\nu^2}{2}\Delta\right) \left(I - \nu D_0 + \frac{\nu^2}{2}\Delta\right) \\ &= \left(I + \frac{\nu^2}{2}\Delta\right)^2 - \nu^2 D_0^2 \\ &= I - \frac{\nu^2(1-\nu^2)}{4}\Delta^2. \end{aligned} \quad (18.191)$$

故

$$\|U^{n+1}\|_2^2 = \|U^n\|_2^2 - \frac{\nu^2(1-\nu^2)}{4} \|\Delta U^n\|_2^2. \quad (18.192)$$

当  $|\nu| \leq 1$ , 右端耗散项非负, 故格式  $L^2$  稳定。

## 18.16 正式真题 [25S-Q5]——Lax-Wendroff 能量与数值出流边界

完整题目叙述: [25S-Q5]

对对流方程

$$u_t + au_x = 0, \quad a \text{ 为常数}, \quad (18.193)$$

Lax-Wendroff 格式为

$$\begin{aligned} U_j^{n+1} &= -\frac{1}{2}\nu(1-\nu)U_{j+1}^n + (1-\nu^2)U_j^n \\ &\quad + \frac{1}{2}\nu(1+\nu)U_{j-1}^n, \quad \nu = \frac{a\tau}{h}. \end{aligned} \quad (18.194)$$

(i) 对全直线 Cauchy 问题, 证明

$$\begin{aligned} \|U^{n+1}\|_2^2 &= \|U^n\|_2^2 \\ &\quad - \frac{1}{2}\nu^2(1-\nu^2) \left[ \|\delta_x^+ U^n\|_2^2 - \langle \delta_x^+ U^n, \delta_x^- U^n \rangle \right], \end{aligned} \quad (18.195)$$

其中  $\delta_x^- U_j = U_j - U_{j-1}$ ,  $\delta_x^+ U_j = U_{j+1} - U_j$ ;

(ii) 设  $a > 0$ , 问题定义在  $(0, 1)$ , 左端满足齐次入流条件  $U_0^n = 0$ . 在右端  $x = 1$  给出一个简单的数值边界条件, 使格式稳定。

第 (i) 问: 能量恒等式. 由上一节式 (18.191),  $\|U^{n+1}\|_2^2 = \|U^n\|_2^2 - \frac{\nu^2(1-\nu^2)}{4} \|\Delta U^n\|_2^2$ . 下面证明它与题面形式等价。

注意  $\Delta U_j = U_{j+1} - 2U_j + U_{j-1} = \delta_x^+ U_j - \delta_x^- U_j$ . 又因全直线或周期求和中移位不改变范数,  $\|\delta_x^+ U\|_2 = \|\delta_x^- U\|_2$ . 所以

$$\begin{aligned} \|\Delta U\|_2^2 &= \|\delta_x^+ U - \delta_x^- U\|_2^2 \\ &= \|\delta_x^+ U\|_2^2 + \|\delta_x^- U\|_2^2 - 2\langle \delta_x^+ U, \delta_x^- U \rangle \\ &= 2 \left[ \|\delta_x^+ U\|_2^2 - \langle \delta_x^+ U, \delta_x^- U \rangle \right]. \end{aligned} \quad (18.196)$$

代入即得

$$\begin{aligned} \|U^{n+1}\|_2^2 &= \|U^n\|_2^2 \\ &\quad - \frac{1}{2}\nu^2(1-\nu^2) \left[ \|\delta_x^+ U^n\|_2^2 - \langle \delta_x^+ U^n, \delta_x^- U^n \rangle \right]. \end{aligned} \quad (18.197)$$



这正是题面恒等式。

当  $|\nu| \leq 1$ , 有  $\|U^{n+1}\|_2 \leq \|U^n\|_2$ 。

□

第 (ii) 问: 一个简单且可严格证明稳定的边界闭合. 设  $x_j = jh$ ,  $j = 0, \dots, J$ . 左端入流边界为  $U_0^n = 0$ . 在右端选择简单的齐次人工出流闭合

$$\boxed{U_J^n = 0, n \geq 0}. \quad (18.198)$$

令内部向量为  $U^n = (U_1^n, \dots, U_{J-1}^n)^T$ . 把它零延拓到全整数网格:

$$\tilde{U}_j^n = \begin{cases} U_j^n, & 1 \leq j \leq J-1, \\ 0, & \text{其他.} \end{cases} \quad (18.199)$$

设  $S$  为全直线 Lax-Wendroff 传播算子,  $P$  为限制到内部节点的正交投影. 有限区间更新即为

$$U^{n+1} = PS\tilde{U}^n. \quad (18.200)$$

由正交投影非扩张性以及全直线稳定性,

$$\begin{aligned} \|U^{n+1}\|_2 &\leq \|S\tilde{U}^n\|_2 \\ &\leq \|\tilde{U}^n\|_2 \\ &= \|U^n\|_2, |\nu| \leq 1. \end{aligned} \quad (18.201)$$

故该数值边界条件保证稳定。

□

注 18.6 (边界条件的物理一致性). 边界条件  $U_J^n = 0$  是数学上最简单、稳定性证明最直接的闭合, 但它一般不是物理无反射出流条件, 可能在右端产生反射或额外误差。

更常用的物理一致闭合包括:

1. 一阶迎风出流:

$$U_J^{n+1} = U_J^n - \nu(U_J^n - U_{J-1}^n); \quad (18.202)$$

2. 零阶外推:  $U_{J+1}^n = U_J^n$ ;

3. 一阶线性外推:  $U_{J+1}^n = 2U_J^n - U_{J-1}^n$ ;

4. 离散特征吸收边界。

这些闭合的稳定性必须与内部格式一起分析, 不能仅凭“出流端无需连续边界条件”就省略数值闭合。

#### 易错点与反例

第 (ii) 问需要同时满足两点:

1. 给出能够计算边界邻近模板的闭合;
2. 证明该闭合下整体离散传播算子幂有界。

只写“右端不需要边界条件”不构成数值算法。连续出流端虽无物理数据, 但有限差分宽模板仍可能需要数值闭合。

## 18.17 有限区间双曲问题的数值边界条件

### 18.17.1 知识点二十：连续边界与数值边界的区别

连续问题中，对  $u_t + au_x = 0$ ,  $a > 0$ , 只需在左端给入流边界条件。

但若内部差分模板在右端附近使用  $U_{J+1}^n$ , 则仍需构造数值边界闭合。这不是增加新的物理边界数据，而是利用：

- PDE;
- 内部解外推;
- 特征关系;
- 吸收条件;
- 守恒通量;

消去模板外未知量。

### 18.17.2 知识点二十一：常见出流闭合

对  $a > 0$  的右端出流边界，常见方法如下。

零阶外推

$$U_{J+1}^n = U_J^n. \quad (18.203)$$

简单，但通常仅一阶。

线性外推

$$U_{J+1}^n = 2U_J^n - U_{J-1}^n. \quad (18.204)$$

对光滑解可保持较高边界精度，但稳定性需单独验证。

**PDE 型迎风闭合**

$$\frac{U_J^{n+1} - U_J^n}{\tau} + a \frac{U_J^n - U_{J-1}^n}{h} = 0. \quad (18.205)$$

特征吸收闭合 对波动方程右端使用

$$u_t + cu_x = 0. \quad (18.206)$$

一个一阶离散为

$$\frac{U_J^{n+1} - U_J^n}{\tau} + c \frac{U_J^n - U_{J-1}^n}{h} = 0. \quad (18.207)$$

### 18.17.3 知识点二十二：反射系数分析

设边界附近的离散解由入射波和反射波组成：

$$U_j^n = e^{-i\omega n\tau} [e^{i\theta j} + R_h(\theta)e^{-i\theta j}]. \quad (18.208)$$

将其代入数值边界条件可求反射系数  $R_h(\theta)$ 。



理想吸收边界要求  $R_h(\theta) = 0$ 。实际低阶边界通常只能使  $R_h(\theta) = O(h^p)$  在低频成立，高频反射可能仍很显著。

### 数值边界稳定性分析的统一框架

识别信号：

- 题目从全直线改为有限区间；
- 内部模板跨出计算域；
- 连续问题只有入流条件；
- 题目要求“给一个数值边界条件并证明稳定”。

构造步骤：

1. 确定特征速度和入流/出流方向；
2. 列出边界附近实际缺失的网格值；
3. 用外推、PDE 或特征条件闭合；
4. 把边界行与内部格式一起写成整体传播矩阵；
5. 使用能量法、半群估计、GKS/Kreiss 条件或投影压缩证明稳定。

关键估计： $E^{n+1} \leq E^n + \text{入流数据贡献}$ 。

结论必须说明：

- 使用的范数；
- CFL 条件；
- 边界闭合的阶；
- 是否产生反射；
- 是否保持整体精度。

常见失败原因：

- 只做无限网格 von Neumann 分析；
- 在出流端随意指定额外物理数据；
- 边界闭合阶低于内部格式；
- 迎风方向写反；
- 边界矩阵导致非正规暂态放大。

## 18.18 补充训练题：双向波导系统与耦合边界

完整题目叙述：[FDM-Set-2013T-Q11]

考虑波导系统

$$u_t + u_x = 0, \quad v_t - v_x = 0, \quad -1 < x < 1, \quad (18.209)$$

边界条件为

$$u(-1, t) = v(-1, t), \quad v(1, t) = u(1, t), \quad (18.210)$$

初值为  $u(x, 0) = f(x)$ ,  $v(x, 0) = g(x)$ 。取  $x_j = j\Delta x$ ,  $j = -N, \dots, N$ ,  $\Delta x = \frac{1}{N}$ , 以及  $t_n = n\Delta t$ 。采用迎风格式

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} + \frac{U_j^n - U_{j-1}^n}{\Delta x} = 0, \quad j = -N+1, \dots, N, \quad (18.211)$$

$$\frac{V_j^{n+1} - V_j^n}{\Delta t} - \frac{V_{j+1}^n - V_j^n}{\Delta x} = 0, \quad j = -N, \dots, N-1, \quad (18.212)$$

并取离散耦合边界

$$U_{-N}^{n+1} = V_{-N}^{n+1}, \quad V_N^{n+1} = U_N^{n+1}. \quad (18.213)$$

要求：

1. 证明连续系统的能量守恒；
2. 求离散格式的稳定性条件；
3. 在离散  $L^2$  与最大范数中证明稳定性；
4. 说明精度和复杂度。

连续能量. 定义

$$E(t) = \frac{1}{2} \int_{-1}^1 (u^2 + v^2) \, dx. \quad (18.214)$$

由  $u_t = -u_x$ ,  $v_t = v_x$ , 有

$$\begin{aligned} E'(t) &= \int_{-1}^1 (uu_t + vv_t) \, dx \\ &= - \int_{-1}^1 uu_x \, dx + \int_{-1}^1 vv_x \, dx \\ &= -\frac{1}{2} [u^2]_{-1}^1 + \frac{1}{2} [v^2]_{-1}^1 \\ &= \frac{1}{2} [-u(1, t)^2 + u(-1, t)^2 + v(1, t)^2 - v(-1, t)^2]. \end{aligned} \quad (18.215)$$

利用  $u(-1, t) = v(-1, t)$ ,  $v(1, t) = u(1, t)$ , 得到

$$\boxed{E'(t) = 0}. \quad (18.216)$$

□

离散更新与 CFL. 令  $\lambda = \frac{\Delta t}{\Delta x}$ . 格式写为

$$U_j^{n+1} = (1 - \lambda)U_j^n + \lambda U_{j-1}^n, \quad (18.217)$$

$$V_j^{n+1} = (1 - \lambda)V_j^n + \lambda V_{j+1}^n. \quad (18.218)$$





若

$$\boxed{0 \leq \lambda \leq 1}, \quad (18.219)$$

每个内部更新均为凸组合。  $\square$

离散  $L^2$  稳定性. 定义不重复计入入流边界变量的离散能量

$$E_h^n = \sum_{j=-N+1}^N (U_j^n)^2 + \sum_{j=-N}^{N-1} (V_j^n)^2. \quad (18.220)$$

使用恒等式

$$[(1-\lambda)a + \lambda b]^2 = (1-\lambda)a^2 + \lambda b^2 - \lambda(1-\lambda)(a-b)^2. \quad (18.221)$$

对  $U$  求和:

$$\begin{aligned} \sum_{j=-N+1}^N (U_j^{n+1})^2 &= \sum_{j=-N+1}^N [(1-\lambda)(U_j^n)^2 + \lambda(U_{j-1}^n)^2] \\ &\quad - \lambda(1-\lambda) \sum_{j=-N+1}^N (U_j^n - U_{j-1}^n)^2 \\ &= \sum_{j=-N+1}^N (U_j^n)^2 \\ &\quad + \lambda [(U_{-N}^n)^2 - (U_N^n)^2] - D_U^n, \end{aligned} \quad (18.222)$$

其中  $D_U^n \geq 0$ 。

同理

$$\begin{aligned} \sum_{j=-N}^{N-1} (V_j^{n+1})^2 &= \sum_{j=-N}^{N-1} (V_j^n)^2 \\ &\quad + \lambda [(V_N^n)^2 - (V_{-N}^n)^2] - D_V^n, \end{aligned} \quad (18.223)$$

其中  $D_V^n \geq 0$ 。

相加后, 边界贡献为

$$\begin{aligned} &\lambda [(U_{-N}^n)^2 - (U_N^n)^2 \\ &\quad + (V_N^n)^2 - (V_{-N}^n)^2]. \end{aligned} \quad (18.224)$$

由离散耦合边界  $U_{-N}^n = V_{-N}^n$ ,  $V_N^n = U_N^n$ , 该项恰为零。故

$$\boxed{E_h^{n+1} = E_h^n - D_U^n - D_V^n \leq E_h^n}. \quad (18.225)$$

$\square$

最大范数稳定性. 定义  $M^n = \max \{ \max_{-N \leq j \leq N} |U_j^n|, \max_{-N \leq j \leq N} |V_j^n| \}$ 。在  $0 \leq \lambda \leq 1$  下, 内部更新为凸组合, 因此  $|U_j^{n+1}| \leq M^n$ ,  $|V_j^{n+1}| \leq M^n$ 。

左端入流值由  $U_{-N}^{n+1} = V_{-N}^{n+1}$  给出, 而  $V_{-N}^{n+1}$  已由内部迎风公式计算并受  $M^n$  控制。

右端入流值由  $V_N^{n+1} = U_N^{n+1}$  给出, 而  $U_N^{n+1}$  也已由内部迎风公式计算并受  $M^n$  控制。

故

$$\boxed{M^{n+1} \leq M^n}. \quad (18.226)$$

$\square$

精度. 前向时间差分为一阶, 迎风空间差分为一阶。因此对光滑解, 归一化截断误差为  $O(\Delta t + \Delta x)$ 。在  $\lambda = \Delta t/\Delta x$  固定时, 整体为一阶。□

---

**Algorithm 72** 双向波导系统的耦合迎风格式

---

**Input:** 初值  $f, g$ ;  $N$ ;  $\Delta t$ ; 终止时间

**Output:**  $U_j^n, V_j^n$

- 1: **Initialization:**  $\Delta x \leftarrow 1/N$ ,  $\lambda \leftarrow \Delta t/\Delta x$ . 检查  $0 \leq \lambda \leq 1$ . 设置  $U_j^0 = f(x_j)$ ,  $V_j^0 = g(x_j)$
  - 2: **for**  $n = 0, \dots, N_t - 1$  **do**
  - 3:   **for**  $j = -N + 1, \dots, N$  **do**
  - 4:      $U_j^{n+1} \leftarrow (1 - \lambda)U_j^n + \lambda U_{j-1}^n$
  - 5:   **end for**
  - 6:   **for**  $j = -N, \dots, N - 1$  **do**
  - 7:      $V_j^{n+1} \leftarrow (1 - \lambda)V_j^n + \lambda V_{j+1}^n$
  - 8:   **end for**
  - 9:    $U_{-N}^{n+1} \leftarrow V_{-N}^{n+1}$
  - 10:    $V_N^{n+1} \leftarrow U_N^{n+1}$
  - 11:   可选: 监测  $E_h^{n+1} \leq E_h^n$
  - 12: **end for**
  - 13: **Stopping criterion:** 达到终止时间
  - 14: **Complexity:** 每步  $O(N)$  运算; 保存两分量的两个时间层, 存储  $O(N)$
- 

### 易错点与反例

耦合边界的施加顺序很重要:

- $V_{-N}^{n+1}$  是左端出射分量, 应先由内部格式计算;
- 再令  $U_{-N}^{n+1} = V_{-N}^{n+1}$ ;
- $U_N^{n+1}$  是右端出射分量, 应先由内部格式计算;
- 再令  $V_N^{n+1} = U_N^{n+1}$ .

若反过来同时联立错误的边界更新, 可能产生循环依赖或破坏能量抵消。

## 18.19 数值传播速度、耗散、色散与群速度

### 18.19.1 知识点二十三: 增长因子的极坐标分解

对线性平移不变格式, 设  $U_j^n = G(\theta)^n e^{ij\theta}$ 。将增长因子写为

$$G(\theta) = \rho_h(\theta) e^{-i\omega_h(\theta)\tau}. \quad (18.227)$$

其中:

$$\rho_h(\theta) = |G(\theta)|, \quad \text{单步振幅因子,} \quad (18.228)$$

$$\alpha_h(\theta) = -\frac{1}{\tau} \log \rho_h(\theta), \quad \text{数值耗散率,} \quad (18.229)$$

$$c_{\text{ph},h} = \frac{\omega_h}{\kappa}, \quad \text{数值相速度,} \quad (18.230)$$



$$c_{\text{gr},h} = \frac{d\omega_h}{d\kappa}, \quad \text{数值群速度.} \quad (18.231)$$

### 18.19.2 知识点二十四：三类误差的区分

**数值耗散** 若  $|G| < 1$ , 数值振幅随时间衰减。迎风和 Lax–Friedrichs 具有明显耗散。

**数值色散** 若  $|G| = 1$  但  $\omega_h(\kappa) \neq \omega(\kappa)$ , 不同频率传播相位错误。中心波动格式、Crank–Nicolson 色散格式均可能如此。

**群速度误差** 局部波包的包络以  $c_{\text{gr}} = \omega'(\kappa)$  传播。若数值群速度符号或大小失真, 会出现:

- 波包到达时间错误;
- 高频波包几乎停滞;
- 非物理反向传播;
- 边界反射到达时间错误。

#### 易错点与反例

下列推论均错误:

- $|G| = 1 \Rightarrow$  数值解准确;
- 无耗散  $\Rightarrow$  无色散;
- 稳定  $\Rightarrow$  数值传播速度正确;
- 二阶精度  $\Rightarrow$  高频也解析良好。

### 18.19.3 知识点二十五：修改方程

设差分格式的主导截断误差可写为

$$u_t + au_x = \varepsilon_2 u_{xx} + \varepsilon_3 u_{xxx} + \cdots. \quad (18.232)$$

则:

- 偶阶空间导数通常对应耗散;
- 奇阶空间导数通常对应色散;
- 若二阶项系数为负, 可能产生反扩散和不稳定;
- 修改方程只在低频、光滑解和网格尺度渐近下有效。

## 18.20 系统格式的正规性、非正规性与暂态增长

### 18.20.1 知识点二十六：可对角化增长矩阵

若  $G(\theta) = X(\theta)\Lambda(\theta)X(\theta)^{-1}$ , 则

$$\|G(\theta)^n\|_2 \leq \kappa_2(X(\theta))\rho(G(\theta))^n. \quad (18.233)$$



即使  $\rho(G) \leq 1$ , 若  $\kappa_2(X(\theta)) \rightarrow \infty$  随网格加密或频率变化, 也不能得到网格一致稳定性。

若存在 Jordan 块  $J = \lambda I + N$ ,  $N^m = 0$ , 则  $J^n = \sum_{k=0}^{m-1} \binom{n}{k} \lambda^{n-k} N^k$ 。当  $|\lambda| = 1$  且  $N \neq 0$ , 会产生多项式增长。

### 18.20.2 知识点二十七：资格考试判断顺序

遇到耦合增长矩阵, 应按以下顺序作答:

1. 写出完整增长矩阵;
2. 检查矩阵是否正规、Hermitian、酉或可同时对角化;
3. 若正规, 特征值模即为 2-范数;
4. 若非正规, 检查特征向量条件数、Jordan 结构或直接估计矩阵幂;
5. 若有边界, 分析整体离散算子而不只分析内部符号。

反例 18.7 (只看特征值会误判). 令  $G_\varepsilon = \begin{pmatrix} 1 & \varepsilon^{-1} \\ 0 & 1 - \varepsilon \end{pmatrix}$ 。其特征值为 1,  $1 - \varepsilon$ , 均不超过 1。但  $\|G_\varepsilon\|$  可随  $\varepsilon \rightarrow 0$  任意大, 且矩阵幂可产生明显暂态增长。

## 18.21 波动、双曲与色散格式的统一算法比较

| 方法                | 核心更新                                      | 精度                | 稳定性              | 主要特点与失败情形                   |
|-------------------|-------------------------------------------|-------------------|------------------|-----------------------------|
| 显式波动中心格式          | 时间、空间二阶中心                                 | $O(\tau^2 + h^2)$ | $c\tau/h \leq 1$ | 显式、能量型; 高频有色散, 端点 CFL 有重根细节 |
| 隐式平均波动格式          | 空间算子在 $n-1, n, n+1$ 层按 $1/4, 1/2, 1/4$ 平均 | $O(\tau^2 + h^2)$ | 无条件稳定            | 每步解 SPD 系统; 无条件稳定但相位误差仍存在   |
| Lax-Friedrichs    | 旧层空间平均加中心通量                               | 通常一阶              | CFL 条件           | 耗散强; 模板简单; 平滑波幅值衰减          |
| Lax-Wendroff      | 时间 Taylor 二阶修正                            | 二阶                | $ \nu  \leq 1$   | 低耗散、主要色散; 间断附近振荡            |
| 三阶 Lax-Wendroff   | 特征脚点三次插值                                  | 三阶                | 需单独分析            | 非单调; 宽模板; 边界闭合更复杂           |
| 耦合系统 Lax 型格式      | 矩阵中心通量加空间平均                               | 固定 CFL 下一阶        | 由增长矩阵决定          | 正规时可看特征值; 非正规时需矩阵幂估计        |
| 色散 Crank-Nicolson | 反 Hermitian 半离散算子的 Cayley 变换              | $O(\tau^2 + h^2)$ | 无条件 $L^2$ 稳定     | 保持离散质量; 无耗散但有相位误差           |
| 中心三层色散格式          | 时间中心配反对称空间算子                              | 通常二阶              | $\tau = O(h^3)$  | 三阶导数导致严格时间步; 等号处重单位根        |

### 18.21.1 知识点二十八：运算与存储复杂度

设空间未知量总数为  $N_h$ 。

显式局部模板 若每个点使用固定数量邻点，则：

每步运算  $= O(N_h)$ ，存储  $= O(N_h)$ 。

对波动三层格式，需存储  $U^{n-1}, U^n, U^{n+1}$ 。实现中可循环覆盖，仍为  $O(N_h)$  存储。

隐式格式 若每步解  $M_h U^{n+1} = r^n$ ，则总成本依赖求解器。

- 一维带状矩阵： $O(N_h)$ ；
- 二维稀疏直接法：通常高于线性复杂度；
- 多重网格或最优预处理 Krylov：理想情况下每步近似  $O(N_h)$ 。

色散显式格式 三阶空间导数的谱半径通常为  $O(h^{-3})$ 。若时间方法稳定区域在虚轴上有界，则常需  $\tau = O(h^3)$ 。固定终止时间下总步数为  $O(h^{-3})$ ，总成本可能达到

$$O(N_h h^{-3}). \quad (18.234)$$

这促使使用：

- 隐式中点；
- Crank–Nicolson；
- 指数积分；
- Fourier 谱时间推进；
- IMEX 或分裂方法。

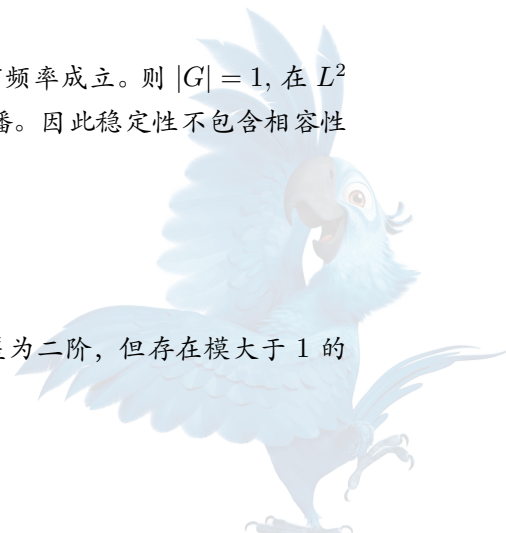
## 18.22 波动、双曲与色散题的易错点和反例

| 错误说法或错误做法                   | 正确处理                                 |
|-----------------------------|--------------------------------------|
| 波动方程中心格式只需给初位移。             | 三时间层格式还需初速度，并据此构造二阶起步层。              |
| 一步缺陷 $O(\tau^4)$ 说明整体四阶。    | 对二阶方程 Störmer 格式，归一化截断误差和整体阶通常为二阶。   |
| CFL 条件只来自 Taylor 展开。        | CFL 反映数值依赖域必须覆盖真实依赖域，也可由根条件或能量正定性得到。 |
| $ \lambda  \leq 1$ 时所有根都简单。 | 端点 CFL 和最高频可能出现重单位根，需单独处理。           |
| 能量守恒自动说明每个分量都逐点有界。          | 能量控制的是指定范数；零频位移模态可能线性变化。             |
| 无条件稳定意味着可以任取大时间步。           | 大时间步仍会产生严重相位误差和传播速度误差。               |

| 错误说法或错误做法                     | 正确处理                                     |
|-------------------------------|------------------------------------------|
| 增长矩阵所有特征值模不超过 1 就一定稳定。        | 只有正规或一致可对角化时才可直接由谱半径推出幂有界。               |
| 周期 von Neumann 稳定可直接推出有限区间稳定。 | 数值边界闭合可能破坏稳定性, 必须分析整体初边值格式。              |
| 连续出流端不需要边界条件, 所以离散模板也无需闭合。    | 宽模板可能需要虚点、外推或 PDE 型数值边界。                 |
| 在双曲系统每个边界给全部未知量。              | 只应给定入射特征分量, 出射分量由内部决定。                   |
| 迎风方向只由网格编号决定。                 | 迎风方向由特征速度符号决定。                           |
| $ G  = 1$ 表示数值解完全准确。          | 它只说明无幅值耗散, 不控制相位和群速度误差。                  |
| 色散方程和扩散方程都含高阶空间导数, 稳定性相同。     | 偶阶负定算子产生扩散, 奇阶反对称算子产生色散, 时间离散选择不同。       |
| 显式 Euler 可用于反对称半离散算子。         | 其增长因子模大于 1, 通常不稳定。                       |
| 三阶空间导数显式格式的时间步应为 $O(h)$ 。     | 离散谱半径通常为 $O(h^{-3})$ , 稳定步长常为 $O(h^3)$ 。 |
| 稳定条件与相容条件可分别满足就足够。            | 必须存在同一网格路径同时满足稳定性和相容性。                   |
| Lax 空间平均总能稳定并收敛。              | 它可能引入 $h^2/\tau$ 截断项, 与高阶空间算子的稳定尺度冲突。    |
| 高阶 Lax-Wendroff 格式一定保持单调。     | 线性三阶格式通常有负权重, 间断附近会振荡。                   |
| 吸收边界不会产生反射。                   | 离散吸收边界通常只在某些频率或渐近阶上近似无反射。                |
| 数值边界只影响边界附近。                  | 双曲方程会把边界误差沿特征线传播到整个区域。                   |

**反例 18.8** (稳定但相位完全错误). 设某格式增长因子为  $G(\theta) = 1$  对所有频率成立。则  $|G| = 1$ , 在  $L^2$  意义下稳定。但它使所有数值模态静止, 不能逼近  $u_t + au_x = 0$  中的传播。因此稳定性不包含相容性和正确色散关系。

**反例 18.9** (相容但不稳定). 对热方程的 Richardson 格式, 局部截断误差为二阶, 但存在模大于 1 的特征根。对双曲或色散问题同样可能出现: 高阶相容  $\nrightarrow$  稳定  $\nrightarrow$  收敛。



## 18.23 资格考试证明与分析套路

## 波动方程中心格式稳定性

识别信号:  $u_{tt} = c^2 u_{xx}$ , 时间、空间均为中心差分。

构造步骤:

1. 设  $U_j^n = z^n e^{ij\theta}$ ;
2. 写二次特征多项式;
3. 利用根乘积为 1;
4. 将根写为  $z = e^{\pm i\omega\tau}$ ;
5. 求 CFL 条件;
6. 检查单位圆重根。

关键估计:  $\lambda^2 \sin^2(\theta/2) \leq 1$ 。

结论:  $c\tau/h \leq 1$ 。

失败原因: 起步层低阶、边界闭合不稳定、端点 CFL 重根、解正则性不足。

## 耦合系统增长矩阵分析

识别信号: 多个未知量、交叉导数、题目要求“分析稳定性”。

构造步骤:

1. 组合为向量  $W$ ;
2. 写连续系数矩阵  $A$ ;
3. 对空间差分取 Fourier 符号;
4. 得到增长矩阵  $G(\theta)$ ;
5. 检查  $G$  是否正规;
6. 若正规, 计算特征值模;
7. 若非正规, 估计矩阵幂或特征向量条件数。

关键估计:  $\sup_{\theta, n\tau \leq T} \|G(\theta)^n\| \leq C_T$ 。

结论: 给出明确范数与网格参数范围。

失败原因: 只看单个分量; 把谱半径当矩阵范数; 忽略非正规性。

## 离散能量法

识别信号: 空间算子自伴或反对称, 时间格式对称。

构造步骤:

1. 寻找连续能量对应的离散二次型;
2. 用时间层和/差乘格式;
3. 离散分部求和;



4. 保留边界通量；

5. 证明能量正定或与目标范数等价。

关键恒等式：  $(a-b)(a+b) = a^2 - b^2$ 。

结论：  $E^{n+1} \leq E^n + \text{边界/源项}$ 。

失败原因：能量含交叉项但未证明正定；边界通量未处理；只得到形式守恒却不能控制解。

### 数值边界条件构造

识别信号：有限区间、宽模板、入流/出流、吸收或反射条件。

构造步骤：

1. 特征分解；
2. 判断入射与出射分量；
3. 对入射分量使用物理边界；
4. 对出射模板外值使用外推或 PDE 闭合；
5. 将边界贡献纳入能量估计；
6. 核对边界截断误差阶。

关键估计：边界能量通量不得为无法控制的正输入。

结论：说明稳定范数、CFL、边界阶与反射性质。

失败原因：边界条件过定；迎风方向错误；内部与边界阶不匹配；只分析周期问题。

### 色散格式分析

识别信号：奇数阶空间导数、反对称符号、连续能量守恒。


构造步骤：

1. 求连续色散关系；
2. 求离散空间符号；
3. 检查符号是否纯虚；
4. 根据时间方法求增长因子或特征根；
5. 求虚轴稳定范围；
6. 比较相位与群速度；
7. 检查稳定路径与相容路径是否兼容。

关键估计：  $\tau \max_{\theta} |\hat{D}_h(\theta)| \leq C$ 。

结论：三阶导数显式格式通常要求  $\tau = O(h^3)$ 。

失败原因：使用显式 Euler；只求  $|G|$  不看相位；漏掉 Lax 平均产生的  $h^2/\tau$  项。



# 第十九章 有限元、变分形式、Céa 引理、能量范数、Aubin–Nitsche 对偶技巧、时间依赖有限元、谱方法与配点法

## 19.1 从强形式到弱形式：试探空间、检验空间与边界条件

### 19.1.1 知识点一：Sobolev 空间与迹

【重要性等级】 **S 级**。有限元分析的对象不是逐点可微函数，而是 Sobolev 空间中的弱解。

设  $\Omega \subset \mathbb{R}^d$  为有界 Lipschitz 区域。定义

$$H^1(\Omega) = \{v \in L^2(\Omega) : \partial_{x_i} v \in L^2(\Omega), i = 1, \dots, d\}, \quad (19.1)$$

范数为

$$\|v\|_{H^1(\Omega)}^2 = \|v\|_{L^2(\Omega)}^2 + \|\nabla v\|_{L^2(\Omega)}^2. \quad (19.2)$$

定义

$$H_0^1(\Omega) = \overline{C_c^\infty(\Omega)}^{H^1(\Omega)}. \quad (19.3)$$

在 Lipschitz 区域上， $H_0^1(\Omega)$  等价于迹为零的  $H^1$  函数空间。

Poincaré 不等式给出

$$\|v\|_{L^2(\Omega)} \leq C_P \|\nabla v\|_{L^2(\Omega)}, \quad \forall v \in H_0^1(\Omega). \quad (19.4)$$

因此在  $H_0^1(\Omega)$  上， $|v|_{H^1(\Omega)} = \|\nabla v\|_{L^2(\Omega)}$  与完整  $H^1$  范数等价。

#### 易错点与反例

有限元答案中只写  $v = 0$  在  $\partial\Omega$  而不说明其含义是不充分的。

对一般  $H^1$  函数，边界值应理解为迹： $\gamma v = 0$  在  $\partial\Omega$ 。


### 19.1.2 知识点二：二阶椭圆问题的弱形式

考虑

$$-\nabla \cdot (A(\mathbf{x})\nabla u) + c(\mathbf{x})u = f \quad \text{在 } \Omega, \quad (19.5)$$

其中  $A(\mathbf{x}) = A(\mathbf{x})^T$  且存在常数  $0 < a_0 \leq a_1$  使

$$a_0 \|\boldsymbol{\xi}\|_2^2 \leq \boldsymbol{\xi}^T A(\mathbf{x}) \boldsymbol{\xi} \leq a_1 \|\boldsymbol{\xi}\|_2^2, \quad \forall \boldsymbol{\xi} \in \mathbb{R}^d. \quad (19.6)$$



进一步假设  $c(\mathbf{x}) \geq 0$ 。

将边界分解为  $\partial\Omega = \overline{\Gamma_D} \cup \overline{\Gamma_N}$ ,  $\Gamma_D \cap \Gamma_N = \emptyset$ 。采用第 16 部分的通量约定：

$$u = g_D \quad \text{在 } \Gamma_D, \quad (19.7)$$

$$-A\nabla u \cdot \mathbf{n} = g_N \quad \text{在 } \Gamma_N. \quad (19.8)$$

若先考虑齐次 Dirichlet 条件，定义

$$V = \{v \in H^1(\Omega) : v|_{\Gamma_D} = 0\}. \quad (19.9)$$

将强方程乘以  $v \in V$  并积分分部：

$$\begin{aligned} \int_{\Omega} A\nabla u \cdot \nabla v \, d\mathbf{x} + \int_{\Omega} cuv \, d\mathbf{x} - \int_{\Gamma_N} A\nabla u \cdot \mathbf{n} v \, ds \\ = \int_{\Omega} f v \, d\mathbf{x}. \end{aligned} \quad (19.10)$$

由于  $A\nabla u \cdot \mathbf{n} = -g_N$ ，得到

$$a(u, v) = \ell(v), \quad \forall v \in V, \quad (19.11)$$

其中

$$a(w, v) = \int_{\Omega} A\nabla w \cdot \nabla v \, d\mathbf{x} + \int_{\Omega} cuv \, d\mathbf{x}, \quad (19.12)$$

$$\ell(v) = \int_{\Omega} f v \, d\mathbf{x} - \int_{\Gamma_N} g_N v \, ds. \quad (19.13)$$

#### 易错点与反例

由于本文采用  $-A\nabla u \cdot \mathbf{n} = g_N$ ，Neumann 项在右端的符号是  $-\int_{\Gamma_N} g_N v$ 。

若另一资料采用  $A\nabla u \cdot \mathbf{n} = \tilde{g}_N$ ，则右端写为  $+\int_{\Gamma_N} \tilde{g}_N v$ 。两种约定不能静默混合。

### 19.1.3 知识点三：本质边界与自然边界

在弱形式中：

- Dirichlet 条件被直接编码在试探空间中，称为本质边界条件；
- Neumann 条件通过边界积分进入右端，称为自然边界条件。

若  $g_D \neq 0$ ，试探空间与检验空间不同：

$$V_g = \{w \in H^1(\Omega) : w|_{\Gamma_D} = g_D\}, \quad (19.14)$$

$$V = \{v \in H^1(\Omega) : v|_{\Gamma_D} = 0\}. \quad (19.15)$$

弱问题为：

求  $u \in V_g$ ，使  $a(u, v) = \ell(v)$ ,  $\forall v \in V$ 。

实际分析中常取一个提升函数  $G \in H^1(\Omega)$ ,  $G|_{\Gamma_D} = g_D$ ，令  $u = G + w$ ,  $w \in V$ 。则

$$a(w, v) = \ell(v) - a(G, v), \quad \forall v \in V. \quad (19.16)$$



### 易错点与反例

非齐次 Dirichlet 问题中，不能把试探函数和检验函数都写成满足  $v = g_D$  的函数。  
检验函数必须具有齐次本质边界条件，否则分部积分后的边界变分不正确。

#### 19.1.4 知识点四：弱解的含义

弱形式只要求  $u \in H^1(\Omega)$ ，而不要求  $u \in H^2(\Omega)$ 。二阶导数被转移到检验函数的一阶导数上。

如果弱解额外足够光滑，则可通过逆向积分分部恢复：

- 区域内部的强方程；
- 自然 Neumann 边界条件。

因此弱形式不是对原问题的任意修改，而是将强问题延拓到较低正则性的函数空间中。

## 19.2 Lax–Milgram 定理、能量范数与问题适定性

#### 19.2.1 知识点五：连续性与强制性

设  $V$  为实 Hilbert 空间。双线性型  $a : V \times V \rightarrow \mathbb{R}$  称为连续的，若存在  $M > 0$  使

$$|a(w, v)| \leq M \|w\|_V \|v\|_V, \quad \forall w, v \in V. \quad (19.17)$$

称  $a$  为强制的或  $V$ -椭圆的，若存在  $\alpha > 0$  使

$$a(v, v) \geq \alpha \|v\|_V^2, \quad \forall v \in V. \quad (19.18)$$

**定理 19.1** (Lax–Milgram 定理). 设  $V$  为 Hilbert 空间，双线性型  $a$  连续且强制，线性泛函  $\ell \in V'$  连续。则存在唯一  $u \in V$  使  $a(u, v) = \ell(v)$ ,  $\forall v \in V$ ，并满足

$$\|u\|_V \leq \frac{1}{\alpha} \|\ell\|_{V'}. \quad (19.19)$$

对式 (19.12)，由一致椭圆性和 Poincaré 不等式：

$$a(v, v) \geq a_0 \|\nabla v\|_{L^2}^2, \quad (19.20)$$

$$\|v\|_{H^1} \leq C \|\nabla v\|_{L^2}, \quad (19.21)$$

故  $a$  在  $V$  上强制。

#### 19.2.2 知识点六：能量范数


若  $a$  对称且正定，定义

$$\|v\|_a = \sqrt{a(v, v)} \quad (19.22)$$

称为能量范数。

对 Poisson 问题  $-\Delta u = f$ ,  $u|_{\partial\Omega} = 0$ ，有  $a(u, v) = \int_{\Omega} \nabla u \cdot \nabla v$ ，因此

$$\|v\|_a = \|\nabla v\|_{L^2(\Omega)}. \quad (19.23)$$



## 易错点与反例

“能量范数”不是固定等于  $H^1$  范数。

它由具体双线性型决定：

- 二阶 Poisson 问题： $\|v\|_a \sim |v|_{H^1}$ ；
- 梁方程： $\|v\|_E = \|v''\|_{L^2}$ ；
- 反应扩散问题： $\|v\|_a^2 = \varepsilon \|\nabla v\|^2 + \|v\|^2$ ；
- 非对称对流扩散问题中， $a(v, v)$  未必定义内积。

## 19.2.3 知识点七：适定性、条件数与离散稳定性的区分

Lax–Milgram 估计  $\|u\|_V \leq \alpha^{-1} \|\ell\|_{V'}$ ，描述连续变分问题的适定性。

离散后得到  $A_h U = F$ 。矩阵条件数  $\kappa_2(A_h)$  描述代数系统对扰动的敏感性。

线性求解器的后向稳定性又是第三个概念。

例如 Poisson 问题连续适定，但在准一致网格上，其有限元刚度矩阵通常满足  $\kappa_2(A_h) = O(h^{-2})$ 。这不表示连续 PDE 不适定，而表示离散代数系统需要预处理。

## 19.3 保形有限元空间、形函数、单元矩阵与组装

## 19.3.1 知识点八：网格与形状正则性

设  $\mathcal{T}_h = \{K\}$  是区域  $\Omega$  的三角形、四面体或区间剖分。定义  $h_K = \text{diam}(K)$ ， $h = \max_{K \in \mathcal{T}_h} h_K$ 。

若存在与  $h$  无关的常数  $\sigma > 0$ ，使

$$\frac{h_K}{\rho_K} \leq \sigma, \quad \forall K \in \mathcal{T}_h, \quad (19.24)$$

其中  $\rho_K$  为  $K$  的内切球半径，则称网格族形状正则。

若进一步所有单元尺寸同阶，称为准一致网格。

## 易错点与反例

有限元误差估计中的常数通常依赖于网格形状正则参数，但不得依赖于  $h$ 。

若三角形出现趋于零的极小角，插值常数和刚度矩阵条件数可能失控。

## 19.3.2 知识点九：连续分片多项式空间


对整数  $p \geq 1$ ，定义

$$V_h^p = \{v_h \in C^0(\bar{\Omega}) : v_h|_K \in \mathbb{P}_p(K), \quad \forall K \in \mathcal{T}_h, \quad v_h|_{\Gamma_D} = 0\}. \quad (19.25)$$

则  $V_h^p \subset V \subset H^1(\Omega)$ ，称为保形有限元空间。

有限元离散为：

$$\text{求 } u_h \in V_h^p, \quad a(u_h, v_h) = \ell(v_h), \quad \forall v_h \in V_h^p. \quad (19.26)$$



### 19.3.3 知识点十：一维 $P_1$ 单元

在单元  $K = [x_i, x_{i+1}]$ ,  $h_K = x_{i+1} - x_i$  上, 局部形函数为

$$\phi_1^K(x) = \frac{x_{i+1} - x}{h_K}, \quad (19.27)$$

$$\phi_2^K(x) = \frac{x - x_i}{h_K}. \quad (19.28)$$

它们满足  $\phi_r^K(x_s) = \delta_{rs}$ 。

对常系数扩散项, 局部刚度矩阵为

$$K^K = \frac{\gamma}{h_K} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}. \quad (19.29)$$

局部质量矩阵为

$$M^K = \frac{h_K}{6} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}. \quad (19.30)$$

对一阶项  $\beta u_x$ , 若双线性型写为  $\beta \int_K u'_h v_h$ , 局部对流矩阵  $C_{rs}^K = \int_K (\phi_s^K)' \phi_r^K$  为

$$C^K = \frac{1}{2} \begin{pmatrix} -1 & 1 \\ -1 & 1 \end{pmatrix}. \quad (19.31)$$

### 19.3.4 知识点十一：二维三角形 $P_1$ 单元

设三角形  $K = \text{conv}\{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\}$ 。局部形函数为重心坐标  $\lambda_1, \lambda_2, \lambda_3$ 。它们在  $K$  上为一次多项式, 且  $\lambda_i(\mathbf{x}_j) = \delta_{ij}$ 。

局部质量矩阵为

$$M^K = \frac{|K|}{12} \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}. \quad (19.32)$$

若扩散系数为常数  $\gamma$ , 局部刚度矩阵为

$$K_{ij}^K = \gamma |K| \nabla \lambda_i \cdot \nabla \lambda_j. \quad (19.33)$$

由于  $\lambda_i$  为一次函数,  $\nabla \lambda_i$  在单元上为常向量。

### 19.3.5 知识点十二：从局部矩阵到全局矩阵


设单元局部自由度到全局自由度的映射为  $\mathcal{I}_K: \{1, \dots, n_{\text{loc}}\} \rightarrow \{1, \dots, N_h\}$ 。组装公式为

$$A_h = \sum_{K \in \mathcal{T}_h} R_K^\top A_K R_K, \quad (19.34)$$

其中  $R_K$  是局部限制矩阵。

对于形状正则、固定次数的有限元:

- 每个自由度只与有限数量邻居耦合;



- 非零元数量  $\text{nnz}(A_h) = O(N_h)$ ;
- 装配时间为  $O(N_h)$ ;
- 稀疏存储为  $O(N_h)$ .

**Algorithm 73** 保形有限元的标准装配与求解**Input:** 网格  $\mathcal{T}_h$ ; 多项式次数  $p$ ; 系数函数; 右端项; Dirichlet 与 Neumann 数据; 积分公式**Output:** 有限元解系数向量  $\mathbf{U}$ 

- 1: **Initialization:** 建立全局自由度编号; 初始化稀疏矩阵  $A_h$  和向量  $\mathbf{F}_h$
- 2: **for** 每个单元  $K \in \mathcal{T}_h$  **do**
- 3:     构造参考单元到  $K$  的映射
- 4:     在积分点计算形函数、梯度、Jacobian 和系数
- 5:     计算局部矩阵  $(A_K)_{rs} = a_K(\phi_s^K, \phi_r^K)$
- 6:     计算局部载荷  $(F_K)_r = \ell_K(\phi_r^K)$
- 7:     按局部-全局映射累加到  $A_h, \mathbf{F}_h$
- 8: **end for**
- 9: 组装 Neumann 边界积分
- 10: 通过消元、提升或行列修改施加 Dirichlet 条件
- 11: 求解  $A_h \mathbf{U} = \mathbf{F}_h$
- 12: **Stopping criterion:** 线性系统真实残差满足与离散误差协调的容差
- 13: **Complexity:** 固定次数保形有限元的装配和存储通常均为  $O(N_h)$ ; 求解成本取决于稀疏直接法或预处理迭代法

**易错点与反例**

Dirichlet 条件的矩阵处理必须与对称性保持一致。

若只把边界行改为单位行, 而不处理相应列, 原本对称正定的矩阵可能变成非对称矩阵。

常见正确做法:

1. 直接消去边界自由度;
2. 对非齐次边界先把边界贡献移到右端;
3. 同时修改行和列以保持对称性。

## 19.4 Galerkin 正交、Céa 引理与能量范数误差

### 19.4.1 知识点十三: Galerkin 正交性

连续问题:  $a(u, v) = \ell(v)$ ,  $\forall v \in V$ 。离散问题:  $a(u_h, v_h) = \ell(v_h)$ ,  $\forall v_h \in V_h$ 。两式相减得到

$$a(u - u_h, v_h) = 0, \forall v_h \in V_h. \quad (19.35)$$

**易错点与反例**Galerkin 正交不是普通的  $L^2$  正交。对 Poisson 问题, 它是  $\int_{\Omega} \nabla(u - u_h) \cdot \nabla v_h = 0$ 。除非双线性型本身就是  $L^2$  内积, 否则不能写  $(u - u_h, v_h) = 0$ 。



### 19.4.2 知识点十四：Céa 引理

定理 19.2 (Céa 引理). 设  $a$  满足  $|a(w, v)| \leq M \|w\|_V \|v\|_V$  及  $a(v, v) \geq \alpha \|v\|_V^2$ . 则保形 *Galerkin* 解满足

$$\|u - u_h\|_V \leq \frac{M}{\alpha} \inf_{v_h \in V_h} \|u - v_h\|_V. \quad (19.36)$$

证明. 对任意  $v_h \in V_h$ , 由强制性和 Galerkin 正交:

$$\begin{aligned} \alpha \|u_h - v_h\|_V^2 &\leq a(u_h - v_h, u_h - v_h) \\ &= a(u - v_h, u_h - v_h) \\ &\leq M \|u - v_h\|_V \|u_h - v_h\|_V. \end{aligned} \quad (19.37)$$

故  $\|u_h - v_h\|_V \leq \frac{M}{\alpha} \|u - v_h\|_V$ . 更直接地对误差  $e = u - u_h$  有

$$\begin{aligned} \alpha \|e\|_V^2 &\leq a(e, e) \\ &= a(e, u - v_h) \\ &\leq M \|e\|_V \|u - v_h\|_V. \end{aligned} \quad (19.38)$$

约去  $\|e\|_V$  并取下确界即得结论.  $\square$

若  $a$  对称正定, 则在能量范数中有更强结论:

推论 19.3 (能量范数最佳逼近). 若  $\|v\|_a^2 = a(v, v)$ , 则

$$\|u - u_h\|_a = \inf_{v_h \in V_h} \|u - v_h\|_a. \quad (19.39)$$

证明. 对任意  $v_h \in V_h$ ,  $u - v_h = (u - u_h) + (u_h - v_h)$ . Galerkin 正交给出  $a(u - u_h, u_h - v_h) = 0$ . 所以

$$\|u - v_h\|_a^2 = \|u - u_h\|_a^2 + \|u_h - v_h\|_a^2 \geq \|u - u_h\|_a^2. \quad (19.40)$$

$\square$

### 19.4.3 知识点十五：插值误差

设网格形状正则,  $I_h u$  为  $p$  次 Lagrange 插值. 若  $u \in H^{p+1}(\Omega)$ , 则

$$\|u - I_h u\|_{H^m(\Omega)} \leq Ch^{p+1-m} |u|_{H^{p+1}(\Omega)}, \quad m = 0, 1. \quad (19.41)$$

对  $P_1$  有限元:

$$\|u - I_h u\|_{L^2} \leq Ch^2 |u|_{H^2}, \quad (19.42)$$


$$\|\nabla(u - I_h u)\|_{L^2} \leq Ch |u|_{H^2}. \quad (19.43)$$

结合 Céa 引理:

$$\|u - u_h\|_{H^1} \leq Ch^p |u|_{H^{p+1}}. \quad (19.44)$$

对  $P_1$ :

$$\|u - u_h\|_{H^1} \leq Ch |u|_{H^2}. \quad (19.45)$$



## 易错点与反例

有限元误差阶由三个因素共同决定：

1. 有限元空间的逼近阶；
2. 精确解的正则性；
3. 变分问题的稳定性。

若  $u \notin H^{p+1}(\Omega)$ ，不能无条件写  $O(h^p)$ 。

例如非凸多边形的 Poisson 解可能因角点奇异性而正则性不足。

19.5 Aubin–Nitsche 对偶技巧与  $L^2$  误差

## 19.5.1 知识点十六：对偶问题的构造

令  $e = u - u_h$ 。希望估计  $\|e\|_{L^2}$ 。定义对偶问题：

$$\boxed{\text{求 } z \in V, \quad a(v, z) = (e, v)_{L^2}, \quad \forall v \in V.} \quad (19.46)$$

假设对偶问题具有椭圆正则性：

$$\boxed{\|z\|_{H^2(\Omega)} \leq C_{\text{reg}} \|e\|_{L^2(\Omega)}}. \quad (19.47)$$

对 Poisson 问题，若  $\Omega$  为凸多边形或具有足够光滑边界，通常可获得该正则性。

## 19.5.2 知识点十七：对偶估计

由对偶定义和 Galerkin 正交：

$$\|e\|_{L^2}^2 = (e, e) = a(e, z) = a(e, z - I_h z). \quad (19.48)$$

由双线性型连续性和插值估计：

$$\|e\|_{L^2}^2 \leq M \|e\|_{H^1} \|z - I_h z\|_{H^1} \leq Ch \|e\|_{H^1} \|z\|_{H^2} \leq Ch \|e\|_{H^1} \|e\|_{L^2}. \quad (19.49)$$

约去  $\|e\|_{L^2}$ ：

$$\|e\|_{L^2} \leq Ch \|e\|_{H^1}. \quad (19.50)$$

再结合 式 (19.44)：

$$\boxed{\|u - u_h\|_{L^2} \leq Ch^{p+1} |u|_{H^{p+1}}}. \quad (19.51)$$

对  $P_1$ ：

$$\boxed{\|u - u_h\|_{L^2} \leq Ch^2 |u|_{H^2}}. \quad (19.52)$$

## Aubin–Nitsche：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 已知能量范数误差；
- 题目要求更高一阶的  $L^2$  误差；

- 连续算子具有椭圆正则性。

构造步骤：

1. 定义误差  $e = u - u_h$ ;
2. 以  $e$  作为对偶问题右端;
3. 写  $\|e\|_0^2 = a(e, z)$ ;
4. 插入任意  $z_h \in V_h$ ;
5. 用 Galerkin 正交消去  $a(e, z_h)$ ;
6. 用连续性、插值误差和对偶正则性。

关键估计:  $\|z - I_h z\|_1 \leq Ch \|z\|_2 \leq Ch \|e\|_0$ 。

结论:  $\|e\|_0 \leq Ch \|e\|_1$ 。

常见失败原因:

- 对偶问题的边界条件写错;
- 忘记对偶正则性假设;
- 对非对称问题把  $a(v, z)$  写成  $a(z, v)$ ;
- 非凸区域上仍无条件使用  $H^2$  正则性;
- 误把 Galerkin 正交写成  $L^2$  正交。

#### 易错点与反例

Aubin-Nitsche 多得到一阶不是纯代数事实。

它依赖于对偶解比右端多两个空间导数的正则性。若对偶问题只有  $z \in H^{1+s}$ ,  $0 < s < 1$ , 则只能得到  $\|e\|_0 \leq Ch^s \|e\|_1$ , 而不是完整多一阶。

## 19.6 补充训练题：丘赛 2021 Problem 6——悬臂梁的三次 Hermite 有限元

完整题目叙述: [Yau-2021-Problem-6]

考虑悬臂梁方程

$$u^{(4)}(x) = f(x), \quad 0 < x < 1, \quad (19.53)$$

边界条件为

$$u(0) = u'(0) = u''(1) = u'''(1) = 0. \quad (19.54)$$

- (a) 将问题改写为变分问题，并明确试探空间和检验空间;
- (b) 将变分问题解释为能量最小化问题，写出能量泛函，并证明两者等价;
- (c) 构造三次连续 Galerkin 有限元方法 CG(3);
- (d) 证明能量范数  $\|e\|_E = \left( \int_0^1 |e''(x)|^2 dx \right)^{1/2}$  下的先验误差估计;

(e) 证明  $L^2$  范数下的先验误差估计。

第 (a) 问: 变分形式. 定义

$$V = \{v \in H^2(0, 1) : v(0) = v'(0) = 0\}. \quad (19.55)$$

这里:

- $u(0) = u'(0) = 0$  为本质边界条件;
- $u''(1) = u'''(1) = 0$  将作为自然边界条件出现。

将强方程乘以  $v \in V$ :  $\int_0^1 u^{(4)}v \, dx = \int_0^1 f v \, dx$ . 分部积分两次:

$$\begin{aligned} \int_0^1 u^{(4)}v \, dx &= [u'''v]_0^1 - \int_0^1 u'''v' \, dx \\ &= [u'''v - u''v']_0^1 + \int_0^1 u''v'' \, dx. \end{aligned} \quad (19.56)$$

在  $x = 0$ ,  $v(0) = v'(0) = 0$ ; 在  $x = 1$ ,  $u''(1) = u'''(1) = 0$ . 故边界项消失。

定义

$$a(w, v) = \int_0^1 w''v'' \, dx, \quad (19.57)$$

$$\ell(v) = \int_0^1 f v \, dx. \quad (19.58)$$

变分问题为

$$\text{求 } u \in V, \quad a(u, v) = \ell(v), \quad \forall v \in V. \quad (19.59)$$

□

能量范数确为范数. 若  $\|v\|_E = \|v''\|_{L^2} = 0$ , 则  $v$  为一次多项式:  $v(x) = a + bx$ . 由  $v(0) = v'(0) = 0$  得到  $a = b = 0$ . 所以  $\|v\|_E = 0 \implies v = 0$ .

此外,

$$v'(x) = \int_0^x v''(s) \, ds, \quad (19.60)$$

$$v(x) = \int_0^x (x-s)v''(s) \, ds. \quad (19.61)$$

由 Cauchy-Schwarz 不等式:

$$\|v\|_{H^2(0,1)} \leq C \|v''\|_{L^2(0,1)}. \quad (19.62)$$


故  $a$  在  $V$  上连续且强制, 由 Lax-Milgram 定理, 弱解存在唯一。 □

第 (b) 问: 能量最小化. 定义能量泛函

$$J(v) = \frac{1}{2} \int_0^1 |v''(x)|^2 \, dx - \int_0^1 f(x)v(x) \, dx, \quad v \in V. \quad (19.63)$$

对任意方向  $w \in V$ ,

$$\begin{aligned} \left. \frac{d}{d\varepsilon} J(v + \varepsilon w) \right|_{\varepsilon=0} &= \int_0^1 v''w'' \, dx - \int_0^1 f w \, dx \\ &= a(v, w) - \ell(w). \end{aligned} \quad (19.64)$$



所以  $J'(u)[w] = 0 \quad \forall w \in V$  当且仅当  $a(u, w) = \ell(w) \quad \forall w \in V$ 。

若  $u$  为变分问题解，则对任意  $v \in V$ ，令  $e = v - u$ 。有

$$\begin{aligned} J(v) - J(u) &= \frac{1}{2}a(u+e, u+e) - \ell(u+e) - \frac{1}{2}a(u, u) + \ell(u) \\ &= a(u, e) - \ell(e) + \frac{1}{2}a(e, e) \\ &= \frac{1}{2}\|e\|_E^2 \geq 0. \end{aligned} \quad (19.65)$$

因此

$$\boxed{u = \arg \min_{v \in V} J(v)}. \quad (19.66)$$

由于  $a$  正定， $J$  严格凸，极小点唯一。  $\square$

第 (c) 问：三次 Hermite 有限元空间。取网格  $0 = x_0 < x_1 < \cdots < x_N = 1$ ， $h_i = x_{i+1} - x_i$ ， $h = \max_i h_i$ 。

四阶问题的能量空间是  $H^2$ 。因此保形有限元空间必须满足  $V_h \subset H^2(0, 1)$ ，即有限元函数及其一阶导数在单元接口连续。

定义

$$\boxed{V_h = \{v_h \in C^1[0, 1] : v_h|_{[x_i, x_{i+1}]} \in \mathbb{P}_3, \quad v_h(0) = v_h'(0) = 0\}}. \quad (19.67)$$

这是一维三次 Hermite 有限元空间。仅有  $C^0$  连续的普通三次 Lagrange 有限元不属于  $H^2$ ，不能直接作为该变分问题的保形离散空间。

在单元  $K_i = [x_i, x_{i+1}]$  上令  $\xi = \frac{x-x_i}{h_i} \in [0, 1]$ 。四个局部形函数为

$$N_1(\xi) = 1 - 3\xi^2 + 2\xi^3, \quad (19.68)$$

$$N_2(\xi) = h_i (\xi - 2\xi^2 + \xi^3), \quad (19.69)$$

$$N_3(\xi) = 3\xi^2 - 2\xi^3, \quad (19.70)$$

$$N_4(\xi) = h_i (-\xi^2 + \xi^3). \quad (19.71)$$

它们满足

$$N_1(x_i) = 1, \quad N_1'(x_i) = 0, \quad N_1(x_{i+1}) = 0, \quad N_1'(x_{i+1}) = 0, \quad (19.72)$$

$$N_2(x_i) = 0, \quad N_2'(x_i) = 1, \quad N_2(x_{i+1}) = 0, \quad N_2'(x_{i+1}) = 0, \quad (19.73)$$

其余两个形函数分别对应右端点函数值和右端点导数。

局部表示为

$$U_h|_{K_i} = U_i N_1 + \Theta_i N_2 + U_{i+1} N_3 + \Theta_{i+1} N_4, \quad (19.74)$$


其中  $U_i \approx u(x_i)$ ， $\Theta_i \approx u'(x_i)$ 。

有限元问题为

$$\boxed{\text{求 } U_h \in V_h, \quad \int_0^1 U_h'' v_h'' dx = \int_0^1 f v_h dx, \quad \forall v_h \in V_h.} \quad (19.75)$$

$\square$

局部刚度矩阵。按局部自由度顺序  $\mathbf{d}_i = (U_i \quad \Theta_i \quad U_{i+1} \quad \Theta_{i+1})^\top$ ，局部刚度矩阵为  $(K_i)_{rs} = \int_{x_i}^{x_{i+1}} N_r'' N_s'' dx$ 。



直接积分得到

$$K_i = \frac{1}{h_i^3} \begin{pmatrix} 12 & 6h_i & -12 & 6h_i \\ 6h_i & 4h_i^2 & -6h_i & 2h_i^2 \\ -12 & -6h_i & 12 & -6h_i \\ 6h_i & 2h_i^2 & -6h_i & 4h_i^2 \end{pmatrix}. \quad (19.76)$$

局部载荷向量为

$$(F_i)_r = \int_{x_i}^{x_{i+1}} f N_r \, dx. \quad (19.77)$$

若  $f$  在单元上为常数  $f_i$ ，则

$$F_i = f_i \begin{pmatrix} h_i/2 \\ h_i^2/12 \\ h_i/2 \\ -h_i^2/12 \end{pmatrix}. \quad (19.78)$$

在左端施加  $U_0 = 0$ ,  $\Theta_0 = 0$ 。右端自然边界  $u''(1) = u'''(1) = 0$  不需要额外消去自由度。  $\square$

---

**Algorithm 74** 悬臂梁三次 Hermite 有限元

---

**Input:** 区间剖分；右端项  $f$ ；数值积分规则

**Output:** 节点位移  $U_i$  与节点转角  $\Theta_i$

- 1: **Initialization:** 每个节点设置两个自由度:  $u(x_i)$ ,  $u'(x_i)$
  - 2: **for** 每个单元  $K_i = [x_i, x_{i+1}]$  **do**
  - 3:   计算  $K_i = \int_{K_i} \mathbf{N}''(\mathbf{N}'')^\top \, dx$
  - 4:   计算  $F_i = \int_{K_i} f \mathbf{N} \, dx$
  - 5:   按四个局部自由度组装
  - 6: **end for**
  - 7: 消去左端两个本质自由度  $U_0 = \Theta_0 = 0$
  - 8: 求解对称正定带状系统  $K\mathbf{d} = \mathbf{F}$
  - 9: **Stopping criterion:** 真实残差与离散误差尺度协调
  - 10: **Complexity:** 若有  $N$  个单元，则未知量约为  $2N$ ；一维矩阵带宽固定，带状 Cholesky 的时间和存储复杂度均为  $O(N)$
- 

第 (d) 问：能量范数先验误差。定义 Hermite 插值  $I_h u \in V_h$  满足每个节点

$$(I_h u)(x_i) = u(x_i), \quad (I_h u)'(x_i) = u'(x_i). \quad (19.79)$$

若  $u \in H^4(0, 1)$ ，则局部插值估计为


$$|u - I_h u|_{H^m(K_i)} \leq Ch_i^{4-m} |u|_{H^4(K_i)}, \quad m = 0, 1, 2. \quad (19.80)$$

特别地，

$$\|(u - I_h u)''\|_{L^2} \leq Ch^2 |u|_{H^4}. \quad (19.81)$$

由于双线性型正是能量内积，Galerkin 解是能量正交投影：

$$\begin{aligned} \|u - U_h\|_E &= \inf_{v_h \in V_h} \|u - v_h\|_E \\ &\leq \|u - I_h u\|_E. \end{aligned} \quad (19.82)$$



故

$$\|u - U_h\|_E \leq Ch^2 |u|_{H^4(0,1)}. \quad (19.83)$$

□

第 (e) 问:  $L^2$  误差. 令  $e = u - U_h$ . 构造对偶问题:

求  $z \in V$ , 使

$$\int_0^1 z'' v'' dx = \int_0^1 e v dx, \quad \forall v \in V. \quad (19.84)$$

其强形式为

$$z^{(4)} = e, \quad (19.85)$$

边界条件与原悬臂梁问题相同:  $z(0) = z'(0) = z''(1) = z'''(1) = 0$ . 一维正则性给出

$$\|z\|_{H^4(0,1)} \leq C \|e\|_{L^2(0,1)}. \quad (19.86)$$

由 Galerkin 正交:

$$\begin{aligned} \|e\|_{L^2}^2 &= a(e, z) \\ &= a(e, z - I_h z) \\ &\leq \|e\|_E \|z - I_h z\|_E \\ &\leq Ch^2 \|e\|_E \|z\|_{H^4} \\ &\leq Ch^2 \|e\|_E \|e\|_{L^2}. \end{aligned} \quad (19.87)$$

约去  $\|e\|_{L^2}$ :

$$\|e\|_{L^2} \leq Ch^2 \|e\|_E. \quad (19.88)$$

再使用 式 (19.83):

$$\|u - U_h\|_{L^2(0,1)} \leq Ch^4 |u|_{H^4(0,1)}. \quad (19.89)$$

□

#### 易错点与反例

1. 四阶问题的保形空间必须包含在  $H^2$  中;
2. 仅写“分片三次连续函数”若只指  $C^0$ , 是不够的;
3. 自然边界不能再次作为本质自由度强制消去;
4.  $L^2$  四阶误差依赖对偶问题的  $H^4$  正则性;
5. 能量误差阶是二阶, 不是三阶或四阶。

## 19.7 时间依赖有限元: 半离散、全离散、质量矩阵与稳定性

### 19.7.1 知识点十八: 抛物方程的空间半离散

考虑

$$\begin{cases} u_t - \nabla \cdot (A \nabla u) + cu = f, & \mathbf{x} \in \Omega, \\ u = 0, & \mathbf{x} \in \partial\Omega, \\ u(0) = u_0. \end{cases} \quad (19.90)$$





弱形式为

$$(u_t, v) + a(u, v) = (f, v), \quad \forall v \in V = H_0^1(\Omega). \quad (19.91)$$

空间半离散有限元为：

$$\boxed{\text{求 } u_h(t) \in V_h, \quad (u_{h,t}, v_h) + a(u_h, v_h) = (f, v_h), \quad \forall v_h \in V_h.} \quad (19.92)$$

取基函数  $\{\phi_i\}_{i=1}^{N_h}$ ,  $u_h(t) = \sum_{j=1}^{N_h} U_j(t) \phi_j$ 。得到矩阵系统

$$\boxed{M\dot{\mathbf{U}}(t) + K\mathbf{U}(t) = \mathbf{F}(t)}. \quad (19.93)$$

其中

$$M_{ij} = (\phi_j, \phi_i), \quad (19.94)$$

$$K_{ij} = a(\phi_j, \phi_i), \quad (19.95)$$

$$F_i = (f, \phi_i). \quad (19.96)$$

质量矩阵  $M$  和刚度矩阵  $K$  在对称椭圆问题中均为对称正定矩阵。

### 19.7.2 知识点十九：半离散能量估计

取  $v_h = u_h$  得到

$$\frac{1}{2} \frac{d}{dt} \|u_h\|_{L^2}^2 + a(u_h, u_h) = (f, u_h). \quad (19.97)$$

若  $f = 0$ , 则

$$\boxed{\|u_h(t)\|_{L^2} \leq \|u_h(0)\|_{L^2}}. \quad (19.98)$$

若  $a(v, v) \geq \alpha \|v\|_V^2$  且  $(f, v) \leq \|f\|_{V'} \|v\|_V$ , 则 Young 不等式给出

$$\frac{d}{dt} \|u_h\|_0^2 + \alpha \|u_h\|_V^2 \leq \frac{1}{\alpha} \|f\|_{V'}^2. \quad (19.99)$$

### 19.7.3 知识点二十：隐式 Euler 全离散

令  $t_n = n\tau$ 。隐式 Euler 有限元格式为

$$\boxed{\left( \frac{u_h^n - u_h^{n-1}}{\tau}, v_h \right) + a(u_h^n, v_h) = (f^n, v_h), \quad \forall v_h \in V_h.} \quad (19.100)$$

矩阵形式为

$$\boxed{(M + \tau K) \mathbf{U}^n = M \mathbf{U}^{n-1} + \tau \mathbf{F}^n}. \quad (19.101)$$

令  $v_h = u_h^n$  并使用恒等式  $2(a - b, a) = \|a\|^2 - \|b\|^2 + \|a - b\|^2$ , 得到

$$\begin{aligned} & \|u_h^n\|_0^2 - \|u_h^{n-1}\|_0^2 + \|u_h^n - u_h^{n-1}\|_0^2 \\ & + 2\tau a(u_h^n, u_h^n) = 2\tau (f^n, u_h^n). \end{aligned} \quad (19.102)$$

齐次情形下：

$$\boxed{\|u_h^n\|_0 \leq \|u_h^{n-1}\|_0}. \quad (19.103)$$



### 19.7.4 知识点二十一：Crank–Nicolson 有限元

定义  $u_h^{n-\frac{1}{2}} = \frac{1}{2}(u_h^n + u_h^{n-1})$ 。Crank–Nicolson 有限元格式为

$$\left( \frac{u_h^n - u_h^{n-1}}{\tau}, v_h \right) + a(u_h^{n-\frac{1}{2}}, v_h) = (f^{n-\frac{1}{2}}, v_h). \quad (19.104)$$

矩阵形式：

$$\left( M + \frac{\tau}{2} K \right) \mathbf{U}^n = \left( M - \frac{\tau}{2} K \right) \mathbf{U}^{n-1} + \tau \mathbf{F}^{n-\frac{1}{2}}. \quad (19.105)$$

齐次情形取  $v_h = u_h^n + u_h^{n-1}$  得到

$$\|u_h^n\|_0^2 - \|u_h^{n-1}\|_0^2 + 2\tau a(u_h^{n-\frac{1}{2}}, u_h^{n-\frac{1}{2}}) = 0. \quad (19.106)$$

所以  $\|u_h^n\|_0 \leq \|u_h^{n-1}\|_0$ 。

### 19.7.5 知识点二十二：显式时间推进与质量集中

若使用显式 Euler：

$$M \frac{\mathbf{U}^{n+1} - \mathbf{U}^n}{\tau} + K \mathbf{U}^n = \mathbf{F}^n, \quad (19.107)$$

则需计算  $M^{-1}$ 。一致质量矩阵通常不是对角矩阵，因而显式法并不真正逐点显式。

质量集中 (mass lumping) 用对角矩阵  $M_L$  近似  $M$ ，例如  $(M_L)_{ii} = \sum_j M_{ij}$ 。此时更新为

$$\mathbf{U}^{n+1} = \mathbf{U}^n - \tau M_L^{-1} K \mathbf{U}^n + \tau M_L^{-1} \mathbf{F}^n. \quad (19.108)$$

稳定性要求  $\tau \rho(M_L^{-1} K) \leq C$ 。由于  $\rho(M_L^{-1} K) = O(h^{-2})$ ，通常仍需

$$\tau = O(h^2). \quad (19.109)$$

### 19.7.6 知识点二十三：时间依赖有限元误差分解

定义 Ritz 投影  $R_h u \in V_h$  满足

$$a(R_h u - u, v_h) = 0, \quad \forall v_h \in V_h. \quad (19.110)$$

误差分解为

$$u(t_n) - u_h^n = \underbrace{u(t_n) - R_h u(t_n)}_{\eta^n: \text{空间逼近误差}} + \underbrace{R_h u(t_n) - u_h^n}_{\theta^n: \text{离散演化误差}}. \quad (19.111)$$

在足够正则性、形状正则网格和  $p$  次有限元下，典型估计为：

$$\max_{1 \leq n \leq N_t} \|u(t_n) - u_h^n\|_{L^2} \leq C(h^{p+1} + \tau) \quad \text{隐式 Euler}, \quad (19.112)$$

$$\max_{1 \leq n \leq N_t} \|u(t_n) - u_h^n\|_{L^2} \leq C(h^{p+1} + \tau^2) \quad \text{Crank–Nicolson}. \quad (19.113)$$

这些估计还要求：

- 初值投影具有相应精度；
- 时间导数具有足够正则性；
- 初边数据满足兼容条件；
- 每步代数系统的求解误差低于离散误差。



19.8 补充训练题：丘赛 2025 Problem 5——反应扩散  $\theta$  格式

完整题目叙述：[Yau-2025-Problem-5]

考虑初值问题

$$u_t + u = u_{xx}, \quad -\infty < x < \infty, \quad 0 < t \leq T, \quad (19.114)$$

以及初值  $u(x, 0) = u_0(x)$ 。取  $\Delta x > 0$ ,  $\Delta t = \frac{T}{M}$ , 考虑  $\theta$  格式

$$\frac{U_j^{m+1} - U_j^m}{\Delta t} + [\theta U_j^{m+1} + (1 - \theta) U_j^m] = \theta \frac{U_{j+1}^{m+1} - 2U_j^{m+1} + U_{j-1}^{m+1}}{(\Delta x)^2} + (1 - \theta) \frac{U_{j+1}^m - 2U_j^m + U_{j-1}^m}{(\Delta x)^2}, \quad (19.115)$$

其中  $0 \leq \theta \leq 1$ 。(a) 求常数  $A(\theta)$ , 使在条件

$$A(\theta) \Delta t \leq \frac{(\Delta x)^2}{2 + (\Delta x)^2} \quad (19.116)$$

下,

$$\|U^m\|_{\ell^\infty} \leq \left[ \frac{1 - (1 - \theta) \Delta t}{1 + \theta \Delta t} \right]^m \|U^0\|_{\ell^\infty}; \quad (19.117)$$

(b) 在离散  $\ell^2$  范数下证明:(a) 当  $\frac{1}{2} \leq \theta \leq 1$  时, 对任意  $\Delta t, \Delta x > 0$  均稳定;(b) 当  $0 \leq \theta < \frac{1}{2}$  时, 求  $B(\theta)$ , 使条件

$$B(\theta) \Delta t \leq \frac{2(\Delta x)^2}{4 + (\Delta x)^2} \quad (19.118)$$

保证  $\ell^2$  稳定。第 (a) 问：最大范数估计. 记  $r = \frac{\Delta t}{(\Delta x)^2}$ 。格式整理为

$$[1 + \theta \Delta t + 2\theta r] U_j^{m+1} - \theta r (U_{j+1}^{m+1} + U_{j-1}^{m+1}) = [1 - (1 - \theta) \Delta t - 2(1 - \theta) r] U_j^m + (1 - \theta) r (U_{j+1}^m + U_{j-1}^m). \quad (19.119)$$

定义左端离散算子

$$(\mathcal{A}_\theta W)_j = [1 + \theta \Delta t + 2\theta r] W_j - \theta r (W_{j+1} + W_{j-1}). \quad (19.120)$$

其中心系数为正、非对角系数非正、行和为  $1 + \theta \Delta t$ 。对任意有界网格函数  $W$ , 最大值原理给出

$$\|W\|_{\ell^\infty} \leq \frac{1}{1 + \theta \Delta t} \|\mathcal{A}_\theta W\|_{\ell^\infty}. \quad (19.121)$$

在无限网格上若上确界不取到, 取一列满足  $|W_{j_\varepsilon}| \geq \|W\|_{\ell^\infty} - \varepsilon$  的指标, 再令  $\varepsilon \rightarrow 0$ 。

为了使右端成为非负系数组合, 需要

$$1 - (1 - \theta) \Delta t - 2(1 - \theta) \frac{\Delta t}{(\Delta x)^2} \geq 0. \quad (19.122)$$

等价于

$$(1 - \theta) \Delta t \leq \frac{(\Delta x)^2}{2 + (\Delta x)^2}. \quad (19.123)$$



所以

$$\boxed{A(\theta) = 1 - \theta}. \quad (19.124)$$

在该条件下，右端三个系数非负且总和为  $1 - (1 - \theta)\Delta t$ 。由 式 (19.121)：

$$\|U^{m+1}\|_{\ell^\infty} \leq \frac{1 - (1 - \theta)\Delta t}{1 + \theta\Delta t} \|U^m\|_{\ell^\infty}. \quad (19.125)$$

递推得到 式 (19.117)。□

第 (b) 问：Fourier 增长因子。取 Fourier 模态  $U_j^m = \widehat{U}^m(\xi)e^{ij\xi}$ 。离散 Laplace 符号为  $-\frac{4}{(\Delta x)^2} \sin^2 \frac{\xi}{2}$ 。定义

$$q(\xi) = 1 + \frac{4}{(\Delta x)^2} \sin^2 \frac{\xi}{2}. \quad (19.126)$$

则  $1 \leq q(\xi) \leq 1 + \frac{4}{(\Delta x)^2}$ 。增长因子为

$$\boxed{G_\theta(\xi) = \frac{1 - (1 - \theta)\Delta t q(\xi)}{1 + \theta\Delta t q(\xi)}}. \quad (19.127)$$

令  $z = \Delta t q(\xi) \geq 0$ 。条件  $|G_\theta| \leq 1$  等价于  $|1 - (1 - \theta)z| \leq 1 + \theta z$ 。右侧不等式  $1 - (1 - \theta)z \leq 1 + \theta z$  恒成立。

左侧不等式要求

$$1 - (1 - \theta)z \geq -1 - \theta z, \quad (19.128)$$

即

$$2 - (1 - 2\theta)z \geq 0. \quad (19.129)$$

若  $\theta \geq \frac{1}{2}$ ，则  $1 - 2\theta \leq 0$ ，故对任意  $z \geq 0$  均成立。因此

$$\boxed{\frac{1}{2} \leq \theta \leq 1 \implies \text{无条件 } \ell^2 \text{ 稳定}}. \quad (19.130)$$

若  $0 \leq \theta < \frac{1}{2}$ ，则需  $z \leq \frac{2}{1 - 2\theta}$ 。对全部频率要求

$$\Delta t \left[ 1 + \frac{4}{(\Delta x)^2} \right] \leq \frac{2}{1 - 2\theta}. \quad (19.131)$$

等价于

$$(1 - 2\theta)\Delta t \leq \frac{2(\Delta x)^2}{4 + (\Delta x)^2}. \quad (19.132)$$

所以

$$\boxed{B(\theta) = 1 - 2\theta}. \quad (19.133)$$

由 Parseval 恒等式， $|G_\theta(\xi)| \leq 1 \quad \forall \xi$  推出  $\|U^m\|_{\ell_h^2} \leq \|U^0\|_{\ell_h^2}$ 。□

注 19.4 (最大范数条件与二范数条件不同)。当  $0 \leq \theta < \frac{1}{2}$  时：

- 最大范数稳定要求右端系数非负；
- 二范数稳定只要求增长因子模不超过 1。

因此两类稳定条件不相同。最大范数单调性一般比  $L^2$  稳定更强。

## 19.9 补充训练题：丘赛 2026 Problem 1——对流扩散方程的 $P_1$ 有限元与隐式 Euler



完整题目叙述：[Yau-2026-Problem-1]

考虑

$$\alpha u_t + \beta u_x - \gamma u_{xx} = f(x), \quad (t, x) \in (0, T) \times (0, 1), \quad (19.134)$$

其中  $\alpha > 0$ ,  $\beta \in \mathbb{R}$ ,  $\gamma > 0$ ,  $f \in L^2(0, 1)$ 。边界条件为  $u(t, 0) = u(t, 1) = 0$ , 初值为  $u(0, x) = 0$ 。令  $\mathcal{T}_h$  为均匀剖分:  $x_i = ih$ ,  $i = 0, \dots, N+1$ ,  $h = \frac{1}{N+1}$ 。时间步长为  $\tau$ ,  $t_n = n\tau$ 。

- (a) 使用空间连续分片线性  $P_1$  有限元和时间隐式 Euler, 写出全离散变分形式;  
 (b) 证明  $\|u_h^n\|_{L^2(0,1)} \leq C \|f\|_{L^2(0,1)}$ , 其中  $C$  与  $h, \tau, n$  无关;  
 (c) 设  $u_h^n = \sum_{j=1}^N U_j^n \phi_j$ , 写出每个时间步所求解的代数线性系统。

第 (a) 问: 全离散变分形式. 定义

$$V_h = \{v_h \in C^0[0, 1] : v_h|_{[x_i, x_{i+1}]} \in \mathbb{P}_1, \quad v_h(0) = v_h(1) = 0\}. \quad (19.135)$$

取  $u_h^0 = 0$ 。对  $n \geq 1$ , 求  $u_h^n \in V_h$  使对任意  $v_h \in V_h$ ,

$$\alpha \left( \frac{u_h^n - u_h^{n-1}}{\tau}, v_h \right) + \beta ((u_h^n)', v_h) + \gamma ((u_h^n)', v_h') = (f, v_h). \quad (19.136)$$

这里:

- 对流项保持为  $\beta(u_x, v)$ ;
- 扩散项积分分部一次;
- Dirichlet 边界通过  $V_h$  强制施加。

□

第 (b) 问:  $L^2$  稳定性. 在式 (19.136) 中取  $v_h = u_h^n$ 。由于  $u_h^n(0) = u_h^n(1) = 0$ , 有

$$\begin{aligned} ((u_h^n)', u_h^n) &= \frac{1}{2} \int_0^1 \frac{d}{dx} [(u_h^n)^2] dx \\ &= \frac{1}{2} [(u_h^n(1))^2 - (u_h^n(0))^2] = 0. \end{aligned} \quad (19.137)$$

记  $a_n = \|u_h^n\|_{L^2}$ 。由 Cauchy-Schwarz 不等式:


$$\begin{aligned} (u_h^n - u_h^{n-1}, u_h^n) &= a_n^2 - (u_h^{n-1}, u_h^n) \\ &\geq a_n^2 - a_{n-1} a_n \\ &= a_n(a_n - a_{n-1}). \end{aligned} \quad (19.138)$$

Poincaré 不等式给出  $a_n \leq C_P \|(u_h^n)'\|_{L^2}$ , 从而

$$\gamma \|(u_h^n)'\|_{L^2}^2 \geq \frac{\gamma}{C_P^2} a_n^2. \quad (19.139)$$

右端满足  $(f, u_h^n) \leq \|f\|_0 a_n$ 。若  $a_n > 0$ , 综合得到

$$\frac{\alpha}{\tau} (a_n - a_{n-1}) + \frac{\gamma}{C_P^2} a_n \leq \|f\|_0. \quad (19.140)$$

若  $a_n = 0$ , 结论显然成立。

令

$$q = \frac{\alpha}{\alpha + \tau\gamma/C_P^2}, \quad 0 < q < 1. \quad (19.141)$$

则

$$a_n \leq qa_{n-1} + (1-q)\frac{C_P^2}{\gamma} \|f\|_0. \quad (19.142)$$

由于  $a_0 = 0$ , 递推可得

$$a_n \leq (1-q^n)\frac{C_P^2}{\gamma} \|f\|_0. \quad (19.143)$$

因此

$$\|u_h^n\|_{L^2(0,1)} \leq \frac{C_P^2}{\gamma} \|f\|_{L^2(0,1)}. \quad (19.144)$$

常数与  $h, \tau, n$  均无关。

在区间  $(0, 1)$  上可取最优 Poincaré 常数  $C_P = \frac{1}{\pi}$ , 于是  $\|u_h^n\|_0 \leq \frac{1}{\gamma\pi^2} \|f\|_0$ . □

第 (c) 问: 代数系统. 设  $\{\phi_i\}_{i=1}^N$  为内部节点的全局帽函数. 写  $u_h^n = \sum_{j=1}^N U_j^n \phi_j$ . 定义

$$M_{ij} = (\phi_j, \phi_i), \quad (19.145)$$

$$K_{ij} = (\phi'_j, \phi'_i), \quad (19.146)$$

$$C_{ij} = (\phi'_j, \phi_i), \quad (19.147)$$

$$F_i = (f, \phi_i). \quad (19.148)$$

每步线性系统为

$$\left[ \frac{\alpha}{\tau} M + \beta C + \gamma K \right] \mathbf{U}^n = \frac{\alpha}{\tau} M \mathbf{U}^{n-1} + \mathbf{F}. \quad (19.149)$$

对均匀网格:

$$M = \frac{h}{6} \begin{pmatrix} 4 & 1 & & & \\ 1 & 4 & 1 & & \\ & \ddots & \ddots & \ddots & \\ & & 1 & 4 & 1 \\ & & & 1 & 4 \end{pmatrix}. \quad (19.150)$$

$$K = \frac{1}{h} \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix}. \quad (19.151)$$

$$C = \frac{1}{2} \begin{pmatrix} 0 & 1 & & & \\ -1 & 0 & 1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 0 & 1 \\ & & & -1 & 0 \end{pmatrix}. \quad (19.152)$$



因此  $C^T = -C$ 。

矩阵的对称部分为

$$\frac{\alpha}{\tau}M + \gamma K, \quad (19.153)$$

它正定。故全矩阵非奇异。

若按行写出，主对角元为  $\frac{2\alpha h}{3\tau} + \frac{2\gamma}{h}$ ，下对角元为  $\frac{\alpha h}{6\tau} - \frac{\gamma}{h} - \frac{\beta}{2}$ ，上对角元为  $\frac{\alpha h}{6\tau} - \frac{\gamma}{h} + \frac{\beta}{2}$ 。□

#### 复杂度说明

每个时间步求解一个非对称三对角系统。

- 一维带状 LU 时间复杂度:  $O(N)$ ;
- 存储复杂度:  $O(N)$ ;
- 若  $\alpha, \beta, \gamma, \tau, h$  固定，矩阵分解可在全部时间步复用；
- 总复杂度为  $O(NN_t)$ 。

注 19.5 (空间振荡与能量稳定的区别). 尽管  $\beta C$  在能量中为反对称项, 当局部网格 Péclet 数  $Pe_h = \frac{|\beta|h}{2\gamma}$  很大时, 标准 Galerkin 解仍可能出现非物理空间振荡。

因此:

$L^2$  稳定  $\not\Rightarrow$  单调  $\not\Rightarrow$  无振荡。

高 Péclet 数时可考虑 SUPG、迎风有限体积或人工扩散。

注 19.6 (标准误差阶). 若精确解足够光滑, 使用  $P_1$  有限元和隐式 Euler 通常有

$$\max_n \|u(t_n) - u_h^n\|_{L^2} \leq C(h^2 + \tau), \quad (19.154)$$

$$\max_n \|u(t_n) - u_h^n\|_{H^1} \leq C(h + \tau). \quad (19.155)$$

该结论需要时间、空间正则性及初值投影误差估计。

#### 易错点与反例

1. 忘记试探空间和检验空间均含齐次 Dirichlet 条件；
2. 把  $(u_x, u)$  误估成正项或负项；
3. 只用离散 Grönwall 得到随  $T$  增长的界，未利用反应扩散算子的稳态耗散；
4. 对流矩阵的上下对角符号写反；
5. 使用数值积分时若破坏  $C^T = -C$ ，能量证明需重新检查。

## 19.10 Fourier 谱 Galerkin 与 Fourier 谱配置

### 19.10.1 知识点二十四：周期谱空间

取周期区间  $\mathbb{T} = [0, 2\pi]$ 。本文采用 Fourier 约定

$$\hat{u}_k = \frac{1}{2\pi} \int_0^{2\pi} u(x) e^{-ikx} dx, \quad (19.156)$$

$$u(x) = \sum_{k \in \mathbb{Z}} \hat{u}_k e^{ikx}. \quad (19.157)$$





定义截断谱空间

$$S_N = \text{span} \{e^{ikx} : |k| \leq N\}. \quad (19.158)$$

正交投影为

$$P_N u = \sum_{|k| \leq N} \hat{u}_k e^{ikx}. \quad (19.159)$$

### 19.10.2 知识点二十五: Sobolev 逼近估计

对  $m \geq s$ ,  $u \in H^m(\mathbb{T})$ , 有

$$\begin{aligned} \|u - P_N u\|_{H^s}^2 &= \sum_{|k| > N} (1 + k^2)^s |\hat{u}_k|^2 \\ &\leq C N^{2(s-m)} \sum_{|k| > N} (1 + k^2)^m |\hat{u}_k|^2. \end{aligned} \quad (19.160)$$

所以

$$\|u - P_N u\|_{H^s} \leq C N^{s-m} \|u\|_{H^m}. \quad (19.161)$$

若  $u$  能解析延拓到复平面条带  $|\text{Im } z| < \sigma$ , 则 Fourier 系数指数衰减:  $|\hat{u}_k| \leq C e^{-\sigma|k|}$ . 从而

$$\|u - P_N u\| \leq C e^{-\sigma N}. \quad (19.162)$$

#### 易错点与反例

“谱精度”不等于对所有函数都指数收敛。

- 有限 Sobolev 正则性: 只有代数收敛;
- $C^\infty$  周期函数: 超代数收敛;
- 解析周期函数: 指数收敛;
- 函数或周期延拓在端点不光滑: Fourier 系数衰减显著变慢。

### 19.10.3 知识点二十六: Fourier 谱微分

若  $u_N(x) = \sum_{|k| \leq N} \hat{u}_k e^{ikx}$ , 则

$$\frac{du_N}{dx} = \sum_{|k| \leq N} ik \hat{u}_k e^{ikx}, \quad (19.163)$$

$$\frac{d^2 u_N}{dx^2} = - \sum_{|k| \leq N} k^2 \hat{u}_k e^{ikx}. \quad (19.164)$$

因此谱微分算法为:

1. FFT 计算离散 Fourier 系数;
2. 第  $k$  个系数乘以  $ik$  或  $-k^2$ ;
3. 逆 FFT 返回节点值。

运算复杂度为

$$O(N \log N). \quad (19.165)$$



### 19.10.4 知识点二十七: Fourier 谱 Galerkin 例子

考虑周期 Poisson 问题

$$-u_{xx} = f, \quad \int_0^{2\pi} u \, dx = 0. \quad (19.166)$$

可解条件为  $\hat{f}_0 = 0$ 。对  $k \neq 0$ ,  $k^2 \hat{u}_k = \hat{f}_k$ 。所以

$$\hat{u}_k = \frac{\hat{f}_k}{k^2}, \quad k \neq 0, \quad \hat{u}_0 = 0. \quad (19.167)$$

该算法只需两次 FFT 和逐频率除法, 复杂度为  $O(N \log N)$ 。

### 19.10.5 知识点二十八: 谱配置与混叠

取等距周期节点  $x_j = \frac{2\pi j}{M}$ ,  $j = 0, \dots, M-1$ 。离散 Fourier 系数满足混叠公式

$$\tilde{u}_k = \sum_{\ell \in \mathbb{Z}} \hat{u}_{k+\ell M}. \quad (19.168)$$

因此频率相差  $M$  的模态在节点上不可区分。

对非线性项, 例如  $u^2$ , 两个最高频模态相乘会产生超出截断范围的频率, 并折回低频, 形成混叠误差。

常用去混叠方法:

- 2/3 规则;
- 3/2 零填充规则;
- 精确或过积分;
- 模态滤波。

#### 易错点与反例

线性常系数谱方法中, Fourier 模态独立; 非线性问题中, 模态通过卷积耦合。不能把线性问题中“每个模态单独推进”的实现直接照搬到非线性项而忽略混叠。

## 19.11 Chebyshev 谱配置与微分矩阵

### 19.11.1 知识点二十九: Chebyshev-Lobatto 节点

在非周期区间  $[-1, 1]$  上取

$$x_j = \cos\left(\frac{j\pi}{n}\right), \quad j = 0, \dots, n. \quad (19.169)$$

节点顺序为  $x_0 = 1 > x_1 > \dots > x_n = -1$ 。

端点附近节点间距为  $O(n^{-2})$ , 中部间距为  $O(n^{-1})$ 。端点聚集可以缓解高次等距插值的 Runge 现象, 但会导致微分矩阵元素尺度达到  $O(n^2)$ 。



### 19.11.2 知识点三十：一般微分矩阵

给定互异节点  $x_0, \dots, x_n$ , 令

$$\ell_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^n \frac{x - x_k}{x_j - x_k} \quad (19.170)$$

为 Lagrange 基函数。

任意  $p \in \mathbb{P}_n$  满足  $p(x) = \sum_{j=0}^n p(x_j) \ell_j(x)$ 。微分后  $p'(x_i) = \sum_{j=0}^n \ell'_j(x_i) p(x_j)$ 。因此微分矩阵为

$$D_{ij} = \ell'_j(x_i). \quad (19.171)$$

定义节点多项式  $q(x) = \prod_{k=0}^n (x - x_k)$ 。则对  $i \neq j$ :

$$D_{ij} = \frac{q'(x_i)}{q'(x_j)(x_i - x_j)}. \quad (19.172)$$

对角元可写为

$$D_{ii} = \sum_{\substack{k=0 \\ k \neq i}}^n \frac{1}{x_i - x_k} = - \sum_{\substack{j=0 \\ j \neq i}}^n D_{ij}. \quad (19.173)$$

后一公式来自：常数函数的导数为零，因此  $D\mathbf{1} = \mathbf{0}$ 。

## 19.12 正式真题 [23F-Q3]——Chebyshev 微分矩阵

完整题目叙述：[23F-Q3]

设  $p$  是  $[-1, 1]$  上的  $n$  次多项式。其在  $n+1$  个节点  $x_0, \dots, x_n$  上的函数值唯一决定  $p$ 。定义微分矩阵  $D = (D_{ij}) \in \mathbb{R}^{(n+1) \times (n+1)}$  满足

$$p'(x_i) = \sum_{j=0}^n D_{ij} p(x_j). \quad (19.174)$$

1. 证明  $D_{ij} = \ell'_j(x_i)$ , 其中  $\ell_j$  为 Lagrange 基函数;
2. 若采用 Chebyshev 网格  $x_j = \cos(j\pi/n)$ ,  $0 \leq j \leq n$ , 推导  $D_{ij}$  的显式公式。

第 (1) 问. Lagrange 插值恒等式为

$$p(x) = \sum_{j=0}^n p(x_j) \ell_j(x). \quad (19.175)$$

对  $x$  求导并在  $x = x_i$  处取值:

$$p'(x_i) = \sum_{j=0}^n p(x_j) \ell'_j(x_i). \quad (19.176)$$


与微分矩阵定义比较可得

$$D_{ij} = \ell'_j(x_i). \quad (19.177)$$

□

第 (2) 问: 节点多项式. Chebyshev-Lobatto 节点由端点  $\pm 1$  和第二类 Chebyshev 多项式  $U_{n-1}$  的零点组成。节点多项式可写为

$$q(x) = 2^{1-n}(x^2 - 1)U_{n-1}(x). \quad (19.178)$$



常数  $2^{1-n}$  使  $q$  首一, 但在比值公式中会抵消。

定义

$$c_j = \begin{cases} 2, & j = 0 \text{ 或 } j = n, \\ 1, & 1 \leq j \leq n-1. \end{cases} \quad (19.179)$$

利用  $U_{n-1}(\cos \theta) = \frac{\sin(n\theta)}{\sin \theta}$ , 可得

$$q'(x_j) = 2^{1-n} n c_j (-1)^j. \quad (19.180)$$

因此对  $i \neq j$ , 由 式 (19.172):

$$\begin{aligned} D_{ij} &= \frac{c_i (-1)^i}{c_j (-1)^j} \frac{1}{x_i - x_j} \\ &= \boxed{\frac{c_i (-1)^{i+j}}{c_j x_i - x_j}}. \end{aligned} \quad (19.181)$$

□

内部对角元. 一般有  $D_{ii} = \frac{q''(x_i)}{2q'(x_i)}$ 。对内部节点  $1 \leq i \leq n-1$ , 有  $U_{n-1}(x_i) = 0$ 。第二类 Chebyshev 多项式满足微分方程

$$(1-x^2)U_{n-1}'' - 3xU_{n-1}' + (n^2-1)U_{n-1} = 0. \quad (19.182)$$

在零点  $x_i$  处:  $(1-x_i^2)U_{n-1}''(x_i) = 3x_i U_{n-1}'(x_i)$ 。由  $q = (x^2-1)U_{n-1}$  忽略无关常数, 可得

$$q'(x_i) = (x_i^2-1)U_{n-1}'(x_i), \quad (19.183)$$

$$q''(x_i) = x_i U_{n-1}'(x_i). \quad (19.184)$$

因此

$$\boxed{D_{ii} = -\frac{x_i}{2(1-x_i^2)}, \quad 1 \leq i \leq n-1.} \quad (19.185)$$

□

端点对角元. 利用  $U_{n-1}(1) = n$  和

$$U_{n-1}'(1) = \frac{n(n^2-1)}{3}, \quad (19.186)$$


有

$$\begin{aligned} D_{00} &= \frac{q''(1)}{2q'(1)} \\ &= \frac{2n + 4n(n^2-1)/3}{4n} \\ &= \boxed{\frac{2n^2+1}{6}}. \end{aligned} \quad (19.187)$$

由节点和微分矩阵的反对称镜像关系:

$$\boxed{D_{nn} = -\frac{2n^2+1}{6}}. \quad (19.188)$$

□



综上, Chebyshev 微分矩阵显式公式为

$$D_{ij} = \begin{cases} \frac{c_i (-1)^{i+j}}{c_j x_i - x_j}, & i \neq j, \\ -\frac{x_i}{2(1-x_i^2)}, & 1 \leq i = j \leq n-1, \\ \frac{2n^2+1}{6}, & i = j = 0, \\ -\frac{2n^2+1}{6}, & i = j = n. \end{cases} \quad (19.189)$$

注 19.7 (节点顺序约定). 本题采用  $x_0 = 1, x_n = -1$ . 若将节点按从  $-1$  到  $1$  重新排序, 微分矩阵需按同一置换变换, 端点对角元的排列也随之交换。

注 19.8 (精确性). 对任意  $p \in \mathbb{P}_n$ , 微分矩阵给出精确节点导数:  $D \begin{pmatrix} p(x_0) \\ \vdots \\ p(x_n) \end{pmatrix} = \begin{pmatrix} p'(x_0) \\ \vdots \\ p'(x_n) \end{pmatrix}$ . 因此

$D^{n+1} = 0$  在精确算术中成立, 因为  $n+1$  次求导消灭所有  $n$  次多项式。

所以  $D$  的全部特征值均为零, 但  $\|D\| = O(n^2)$ . 这说明  $D$  高度非正规, 仅看特征值会严重误判其数值行为。

#### 复杂度说明

直接形成并使用稠密微分矩阵:

- 存储:  $O(n^2)$ ;
- 一次矩阵-向量乘法:  $O(n^2)$ .

若先转化为 Chebyshev 系数并使用快速余弦变换, 谱微分可在  $O(n \log n)$  时间和  $O(n)$  存储内完成。

#### 易错点与反例

1.  $c_0 = c_n = 2$ , 内部  $c_j = 1$ , 不能写反;
2. 非对角公式分母是  $x_i - x_j$ , 不是  $x_j - x_i$ ;
3. 端点对角元不能使用内部公式;
4. 若节点顺序改变, 矩阵必须同步置换;
5. 微分矩阵的特征值全为零, 不代表矩阵范数小。

## 19.13 Chebyshev 配置法求解边值问题

### 19.13.1 知识点三十一: Poisson 配置法

考虑

$$\begin{cases} -u''(x) = f(x), & -1 < x < 1, \\ u(-1) = g_-, \quad u(1) = g_+. \end{cases} \quad (19.190)$$



在 Chebyshev–Lobatto 节点上形成  $D$ ,  $D^{(2)} = D^2$ 。令内部指标集为  $I = \{1, \dots, n-1\}$ , 边界指标为  $B = \{0, n\}$ 。

内部配置方程为

$$-\sum_{j=0}^n D_{ij}^{(2)} U_j = f(x_i), \quad i = 1, \dots, n-1. \quad (19.191)$$

由于  $U_0 = g_+$ ,  $U_n = g_-$ , 内部系统为

$$\boxed{-D_{II}^{(2)} \mathbf{U}_I = \mathbf{f}_I + D_{IB}^{(2)} \mathbf{g}_B}. \quad (19.192)$$

也可构造完整矩阵并用单位行替换第一、最后一行:

$$A_{0,:} = e_0^\top, \quad A_{n,:} = e_n^\top. \quad (19.193)$$

---

#### Algorithm 75 Chebyshev 谱配置求解一维 Dirichlet 边值问题

---

**Input:** 多项式次数  $n$ ; 右端项  $f$ ; 边界值  $g_+, g_-$

**Output:** 节点解  $U$

- 1: **Initialization:** 生成  $x_j = \cos(j\pi/n)$  和微分矩阵  $D$
  - 2:  $D_2 \leftarrow D^2$
  - 3: 提取内部矩阵  $A \leftarrow -(D_2)_{1:n-1, 1:n-1}$
  - 4: 组装右端  $b_i \leftarrow f(x_i) + (D_2)_{i0} g_+ + (D_2)_{in} g_-$
  - 5: 解稠密系统  $A \mathbf{U}_I = \mathbf{b}$
  - 6: 设置  $U_0 = g_+$ ,  $U_n = g_-$
  - 7: **Stopping criterion:** 离散残差与边界残差满足容差
  - 8: **Complexity:** 直接形成  $D$  和  $D^2$  需  $O(n^2)$  存储; 稠密直接求解为  $O(n^3)$ ; 结构化谱积分、快速变换或迭代预处理可降低成本
- 

### 19.13.2 知识点三十二: 谱收敛

若  $u$  在  $[-1, 1]$  上具有  $m$  阶 Sobolev 正则性, Chebyshev 插值和配置误差通常代数衰减。

若  $u$  可解析延拓到 Bernstein 椭圆  $E_\rho$ ,  $\rho > 1$ , 则 Chebyshev 系数满足  $|a_k| \leq C\rho^{-k}$ , 从而

$$\boxed{\|u - u_n\|_\infty \leq C\rho^{-n}}. \quad (19.194)$$

### 19.13.3 知识点三十三: 边界条件与条件数

Chebyshev 微分矩阵具有:

- 一阶矩阵元素尺度  $O(n^2)$ ;
- 二阶 Dirichlet 配置矩阵条件数通常增长为  $O(n^4)$ ;
- 高阶导数矩阵条件数增长更快。

因此高精度并不意味着线性系统条件数小。

常用改善方法:

- 谱积分预条件;
- 基于边界条件的 Galerkin 基;
- ultraspherical 方法;



- 基于低阶有限差分或有限元的预处理；
- 避免显式形成高次矩阵幂。

#### 易错点与反例

直接计算  $D^4$  并不总是求四阶问题的最佳方式。

由于非正规性和条件数增长，高阶谱微分矩阵可能放大舍入误差。更稳定的方法包括：

- 直接构造高阶导数递推；
- 谱系数空间求导；
- 谱积分方法；
- 满足边界条件的 Galerkin 基。

## 19.14 谱 Galerkin、谱配置与谱 Tau 方法的区别

### 19.14.1 知识点三十四：谱 Galerkin

选择  $V_N \subset V$  使基函数预先满足本质边界条件。求  $u_N \in V_N$  使

$$a(u_N, v_N) = \ell(v_N), \quad \forall v_N \in V_N. \quad (19.195)$$

特点：

- 具有 Galerkin 正交；
- 可直接使用 Céa 型分析；
- 需要计算全局积分；
- 合理选择正交基可得到对角或带状矩阵。

例如 Dirichlet 边界可选

$$\psi_k(x) = T_k(x) - T_{k+2}(x), \quad (19.196)$$

因为  $\psi_k(\pm 1) = 0$ 。

### 19.14.2 知识点三十五：谱配置

在配点  $x_j$  上强制满足微分方程：

$$\mathcal{L}_N u_N(x_j) = f(x_j). \quad (19.197)$$

特点：

- 实现直接；
- 非线性项可在节点空间逐点计算；
- 通常形成稠密微分矩阵；
- 不自动具有 Galerkin 正交；
- 稳定性需通过离散能量、矩阵谱或等价性分析。





### 19.14.3 知识点三十六：谱 Tau 方法

Tau 方法只在低阶测试模态上满足残差正交，将最高若干模态方程替换为边界条件。

它与 Galerkin 法可能在某些问题上代数等价，但一般不能不加说明地视为完全相同。

| 方法         | 方程施加方式        | 边界条件       | 主要分析工具              |
|------------|---------------|------------|---------------------|
| 谱 Galerkin | 残差与全部测试基正交    | 通常嵌入试探空间   | Galerkin 正交、Céa、能量法 |
| 谱配置        | 在配点逐点满足方程     | 边界行替换或边界消元 | 微分矩阵、离散稳定性、插值误差     |
| 谱 Tau      | 低阶残差正交，高阶方程替换 | 以 Tau 方程施加 | 正交多项式递推、矩阵等价性       |

## 19.15 有限差分、有限元与谱方法中的“稳定性”

### 19.15.1 知识点三十七：有限差分稳定性

有限差分稳定性通常指：

$\sup_{n\tau \leq T} \|S_{h,\tau}^n\| \leq C_T$ 。常用工具：

- von Neumann 分析；
- 根条件；
- 最大值原理；
- 离散能量；
- 矩阵幂估计。

### 19.15.2 知识点三十八：有限元稳定性

稳态有限元中，“稳定性”常指：

- 双线性型强制性；
- inf-sup 条件；
- 离散解满足  $\|u_h\|_V \leq C \|\ell\|_{V'}$ ；
- 常数对  $h$  一致。

时间依赖有限元中还需时间推进稳定性。

因此有限元的稳定性可分为：

1. 连续变分问题稳定性；
2. 空间离散的离散强制性或离散 inf-sup；
3. 时间离散稳定性；
4. 代数求解器稳定性。



19.15.3 知识点三十九：谱方法稳定性

谱方法的稳定性取决于实现形式：

- Fourier Galerkin：常通过正交性和模态能量分析；
- Chebyshev Galerkin：常通过加权能量和基函数结构；
- 配置法：常通过微分矩阵、加权离散内积或 SBP 性质；
- 非线性谱方法：还需处理混叠引起的能量错误。

易错点与反例

“谱方法具有高精度”不是稳定性证明。

一个谱配置离散可能：

- 空间逼近误差极小；
- 但时间步长违反稳定区间；
- 或微分矩阵高度非正规；
- 或边界行造成不稳定；
- 或非线性混叠导致能量增长。

19.16 有限元与谱方法易错点、反例与答题规范

| 错误说法或错误做法                          | 正确处理                                     |
|------------------------------------|------------------------------------------|
| 弱形式只需把二阶导数删掉。                      | 必须乘检验函数、积分分部，并处理全部边界项。                   |
| 试探空间和检验空间总是相同。                     | 非齐次 Dirichlet 问题中，试探空间是仿射空间，检验空间满足齐次边界。  |
| Dirichlet 和 Neumann 边界都应直接代入有限元空间。 | Dirichlet 是本质条件；Neumann 通常是自然条件。         |
| Galerkin 正交是 $L^2$ 正交。             | 它是相对于双线性型 $a(\cdot, \cdot)$ 的正交。         |
| Céa 引理说明有限元解等于任意插值。                | 它说明离散误差受最佳逼近误差控制。                        |
| 对称正定问题中 Céa 常数总是 $M/\alpha$ 。      | 在能量范数中可得到常数 1 的最佳逼近。                     |
| $P_1$ 有限元的 $L^2$ 误差直接由插值误差得到。      | 需先控制 Galerkin 误差，再用 Aubin–Nitsche 对偶技巧。  |
| Aubin–Nitsche 总能多得到一阶。             | 还需对偶问题的附加椭圆正则性。                          |
| 非凸区域仍有标准 $H^2$ 正则性。                | 四角可能降低正则性和 $L^2$ 收敛阶。                    |
| 普通 $C^0$ 三次有限元可直接解梁方程。             | 四阶保形方法需要 $C^1$ 三次 Hermite 元，或采用混合/非保形方法。 |



| 错误说法或错误做法                   | 正确处理                                |
|-----------------------------|-------------------------------------|
| 自然边界还应额外删除对应自由度。            | 自然边界已由变分形式自动编码。                     |
| 有限元矩阵一定对称。                  | 含对流项、Petrov–Galerkin 或非对称算子时矩阵可非对称。 |
| 能量稳定意味着无空间振荡。               | 对流占优时标准 Galerkin 可稳定但振荡。            |
| 质量矩阵总是对角矩阵。                 | 一致质量矩阵通常稀疏但非对角；质量集中才近似对角。           |
| 显式有限元无需解任何系统。               | 若不进行质量集中，仍需作用 $M^{-1}$ 。            |
| 谱方法对任何函数都指数收敛。              | 指数收敛需要解析性及正确的周期/边界相容性。              |
| Fourier 插值和 Fourier 截断完全相同。 | 插值包含混叠，正交截断不包含。                     |
| 谱配置自动具有 Galerkin 正交。        | 配置法逐点满足方程，通常没有 Galerkin 正交。         |
| Chebyshev 微分矩阵的特征值决定其范数。    | 一阶微分矩阵高度非正规，全部特征值甚至可为零。             |
| 直接形成 $D^4$ 最稳定。             | 高阶矩阵幂可能严重放大舍入误差，应考虑系数空间或谱积分。        |
| 边界条件只需在求解后覆盖端点值。            | 边界必须进入离散线性系统，否则内部解通常错误。             |
| 谱精度意味着时间步可以任意大。             | 时间稳定性仍由半离散谱半径和时间积分法决定。              |
| 高阶方法的条件数一定优于低阶方法。           | 谱和高阶方法常具有更大的代数条件数。                  |

反例 19.9 (Galerkin 正交不是  $L^2$  正交). 考虑  $-u'' = f$ ,  $u(0) = u(1) = 0$ . 有限元误差满足  $\int_0^1 (u - u_h)' v_h' dx = 0$ . 一般并没有  $\int_0^1 (u - u_h) v_h dx = 0$ . 若错误地使用后一个等式, Aubin–Nitsche 推导中的关键步骤将失去依据。

反例 19.10 (高精度空间离散仍可时间不稳定). Fourier 谱方法离散  $u_t = u_{xx}$  得到模态方程  $\hat{u}_k' = -k^2 \hat{u}_k$ . 若使用显式 Euler, 稳定要求  $\tau k_{\max}^2 \leq 2$ . 由于  $k_{\max} = O(N)$ , 需要  $\tau = O(N^{-2})$ . 所以空间谱精度不消除显式时间步限制。

## 19.17 模块四正式真题完整映射

六套正式试卷中，模块四共对应十二道题。每套试卷均有两道主要属于模块四的题目：

| 正式题目     | 主要考点           | 核心完整步骤                       | 讲义位置    |
|----------|----------------|------------------------------|---------|
| [23F-Q3] | Chebyshev 微分矩阵 | Lagrange 求导；节点多项式；端点权重；显式对角元 | 第 19 部分 |



| 正式题目     | 主要考点                | 核心完整步骤                              | 讲义位置    |
|----------|---------------------|-------------------------------------|---------|
| [23F-Q5] | 三阶色散 Lax 型格式        | 截断误差；三阶差分符号；稳定条件；稳定与相容路径冲突          | 第 18 部分 |
| [24S-Q4] | 热方程三时间层格式           | 时间 Taylor 展开；参数最优；Fourier 特征多项式；根条件 | 第 17 部分 |
| [24S-Q5] | 一维离散最大值原理           | 算子差值形式；等号传播；最大范数稳定；唯一性              | 第 15 部分 |
| [24F-Q4] | 耦合双曲系统              | 向量化；Lax 平均截断误差；特征变量；增长矩阵正规性         | 第 18 部分 |
| [24F-Q5] | 二维中心差分最大值原理         | 网格 Péclet 条件；内部极值；负零阶项； $M$ 矩阵      | 第 16 部分 |
| [25S-Q4] | 耦合色散 Crank–Nicolson | 复数化；中点截断误差；Cayley 变换；离散质量守恒         | 第 18 部分 |
| [25S-Q5] | Lax–Wendroff 能量与边界  | 移位算子； $S^*S$ ；耗散恒等式；数值出流闭合          | 第 18 部分 |
| [25F-Q4] | 二维 Du Fort–Frankel  | 格式构造； $\tau^2/h^2$ 项；根条件；稳定与相容区分    | 第 17 部分 |
| [25F-Q5] | 隐式波动三层格式            | 特征根 Cayley 形式；零频模态；离散能量；相位误差        | 第 18 部分 |
| [26S-Q4] | 三种隐式对流格式            | 三个增长因子；分母模；反迎风稳定区间；边界方向             | 第 17 部分 |
| [26S-Q5] | 椭圆最大值原理与后向 Euler    | 空间单调性； $M$ 矩阵；最大范数一步压缩；无条件稳定        | 第 16 部分 |

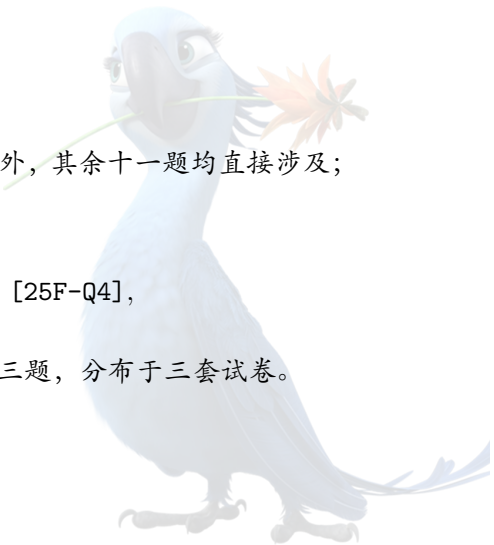
### 19.17.1 正式题型频率

只按六套正式试卷统计：

1. 明确要求稳定性、最大值原理或离散能量分析的题目：除 [23F-Q3] 外，其余十一题均直接涉及；
2. 题面直接要求截断误差、一致性或收敛阶的题目为：

[23F-Q5], [24S-Q4], [24F-Q4], [25S-Q4], [25F-Q4],

3. 离散最大值原理直接出现于 [24S-Q5], [24F-Q5], [26S-Q5], 共三题，分布于三套试卷。



4. 数值边界条件被显式要求于 [25S-Q5].
5. 谱微分矩阵被显式要求于 [23F-Q3].
6. 六套正式题中没有直接有限元题

## 19.18 模块四补充题集闭环映射

### 19.18.1 丘赛中属于模块四的题目

| 补充题                  | 主要内容                                       | 完整解答位置  |
|----------------------|--------------------------------------------|---------|
| [Yau-2020-Problem-5] | 稳定传播算子的 $O(\tau)$ 有界扰动                     | 第 15 部分 |
| [Yau-2021-Problem-6] | 悬臂梁变分形式与三次 Hermite 有限元                     | 第 19 部分 |
| [Yau-2022-Problem-5] | 三阶 Lax-Wendroff 型对流格式                      | 第 18 部分 |
| [Yau-2023-Problem-5] | 显式热方程格式的一致性、稳定性和收敛性                        | 第 17 部分 |
| [Yau-2024-Problem-4] | 变系数散度型椭圆保守差分与谱圆盘                           | 第 16 部分 |
| [Yau-2024-Problem-5] | 三阶色散问题适定性与中心三层格式                           | 第 18 部分 |
| [Yau-2024-Problem-6] | 周期扩散方程的离散 Fourier 分析                       | 第 17 部分 |
| [Yau-2025-Problem-5] | 反应扩散 $\theta$ 格式的 $\ell^\infty/\ell^2$ 稳定性 | 第 19 部分 |
| [Yau-2026-Problem-1] | $P_1$ 有限元与隐式 Euler 全离散                     | 第 19 部分 |

### 19.18.2 数值 PDE\_FDM 题目合辑的十四组题

| 题目               | 主要内容                  | 完整解答位置  |
|------------------|-----------------------|---------|
| [2019T-Q1]       | Störmer 方法与波动方程中心格式   | 第 18 部分 |
| [2019I-Q2]       | Richardson 热方程格式及不稳定性 | 第 17 部分 |
| [2018T-Q3]       | BDF2-中心隐式对流格式         | 第 17 部分 |
| [2018I-Q4]       | 对流扩散 IMEX 格式          | 第 17 部分 |
| [2017T-Q5]       | 非线性扩散显式格式             | 第 17 部分 |
| [2017I/2014I-Q6] | 非线性守恒律半离散迎风格式         | 第 17 部分 |
| [2016T-Q7]       | 二阶单边对流格式与入流边界         | 第 17 部分 |
| [2016I-Q8]       | 紧致四阶空间差分与隐式 Leapfrog  | 第 17 部分 |
| [2015I-Q9]       | FTCS 对流格式、非常规稳定路径与修正  | 第 15 部分 |
| [2014I-Q10]      | 后向 Euler 热方程的边界能量估计   | 第 17 部分 |
| [2013T-Q11]      | 双向波导系统与耦合数值边界         | 第 18 部分 |
| [2012I-Q12]      | FTCS 格式及多种稳定化方法       | 第 17 部分 |



| 题目          | 主要内容               | 完整解答位置  |
|-------------|--------------------|---------|
| [2011T-Q13] | 二阶单边三点格式的精确参数与稳定区间 | 第 17 部分 |
| [2010T-Q14] | 迎风格式多范数稳定性与网格范数反例  | 第 15 部分 |



## 第五部分

### 渐近分析





## 第二十章 渐近记号、渐近序列、渐近级数、主导平衡、量纲分析与无量纲化

### 20.1 渐近分析的对象、参数趋向与有效区域

#### 20.1.1 知识点一：渐近问题的输入与输出

【重要性等级】 **S 级**。渐近分析研究含参数对象在某个极限过程中的主导结构。典型输入为  $F(\varepsilon, x)$ ,  $0 < \varepsilon \ll 1$ , 或  $F(\lambda, x)$ ,  $\lambda \rightarrow +\infty$ 。

典型输出不是一个孤立近似值, 而应包括:

1. 主导项;
2. 若干修正项;
3. 余项的阶;
4. 极限参数的趋向;
5. 空间、时间或其他变量的有效区域;
6. 估计是点态的还是一致的;
7. 是否存在边界层、初始层、转向点或多个尺度。

标准答案必须写成类似

$$F(\varepsilon, x) = F_0(x) + \varepsilon F_1(x) + O(\varepsilon^2), \quad \varepsilon \rightarrow 0^+, \quad x \in K, \quad (20.1)$$

并说明常数是否对  $x \in K$  一致。

#### 易错点与反例

只写  $F = F_0 + \varepsilon F_1 + O(\varepsilon^2)$  而不写:

- $\varepsilon \rightarrow 0^+$  还是  $\varepsilon \rightarrow 0$ ;
- $x$  固定还是随  $\varepsilon$  变化;
- 估计在哪个区域成立;

在渐近题中通常是不完整答案。

#### 20.1.2 知识点二：大参数与小参数的换算

若  $\lambda \rightarrow +\infty$ , 可定义  $\varepsilon = \frac{1}{\lambda} \rightarrow 0^+$ 。例如  $F(\lambda) = a_0 + \frac{a_1}{\lambda} + O(\lambda^{-2})$  等价于  $F(\varepsilon) = a_0 + a_1\varepsilon + O(\varepsilon^2)$ 。

但若原问题同时含  $\lambda x$ ,  $x/\varepsilon$ , 换元后必须重新判断  $x$  的尺度。不能仅将所有  $1/\lambda$  机械替换为  $\varepsilon$ , 而忽略复合变量。

### 20.1.3 知识点三：固定变量、伸缩变量与移动区域

以下三个极限问题不同：

$$\varepsilon \rightarrow 0, x \text{ 固定}, \quad (20.2)$$

$$\varepsilon \rightarrow 0, X = \frac{x}{\varepsilon} \text{ 固定}, \quad (20.3)$$

$$\varepsilon \rightarrow 0, x \in D_\varepsilon. \quad (20.4)$$

第一种通常对应外部展开；第二种通常对应内层或快速变量；第三种要求讨论随参数变化区域上的一致估计。

例如

$$F(\varepsilon, x) = e^{-x/\varepsilon}. \quad (20.5)$$

对每个固定  $x > 0$ , 任意  $N > 0$  均有

$$e^{-x/\varepsilon} = o(\varepsilon^N), \varepsilon \rightarrow 0^+. \quad (20.6)$$

但在  $x \in [0, 1]$  上不一致, 因为  $F(\varepsilon, 0) = 1$ 。令  $X = \frac{x}{\varepsilon}$ , 则  $F = e^{-X}$  在  $X = O(1)$  区域保持非平凡。

这正是边界层尺度的基本信号。

## 20.2 大 $O$ 、小 $o$ 、渐近等价与双边阶

### 20.2.1 知识点四：大 $O$ 记号

设  $f, g: D \rightarrow \mathbb{C}$ ,  $x_0$  为  $D$  的聚点。若存在常数  $C > 0$ ,  $\delta > 0$ , 使得对所有满足  $x \in D$ ,  $0 < |x - x_0| < \delta$  的  $x$ , 均有

$$|f(x)| \leq C|g(x)|, \quad (20.7)$$

则记作

$$\boxed{f(x) = O(g(x)), x \rightarrow x_0}. \quad (20.8)$$

当  $x_0 = \infty$  时, 定义改为存在  $M, C > 0$ , 使  $|x| > M \implies |f(x)| \leq C|g(x)|$ 。

大  $O$  只给出上界, 不给出精确首项。

例如  $x^2 = O(x^3)$ ,  $x \rightarrow +\infty$ , 也有  $x^2 = O(x^2)$ 。所以不能从  $f = O(g)$  推出  $f \sim g$ 。


### 20.2.2 知识点五：小 $o$ 记号

若对任意  $\eta > 0$ , 存在  $\delta_\eta > 0$ , 使  $0 < |x - x_0| < \delta_\eta \implies |f(x)| \leq \eta|g(x)|$ , 则记作

$$\boxed{f(x) = o(g(x)), x \rightarrow x_0}. \quad (20.9)$$

若  $g(x) \neq 0$  在某个去心邻域内成立, 则等价于

$$\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = 0. \quad (20.10)$$



显然  $f = o(g) \implies f = O(g)$ , 反之一般不成立。

例如  $\sin x = O(1)$ ,  $x \rightarrow +\infty$ , 但  $\sin x \neq o(1)$ 。

### 20.2.3 知识点六：渐近等价

若  $g(x) \neq 0$  最终成立, 且

$$\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = 1, \quad (20.11)$$

则称  $f$  与  $g$  渐近等价, 记作

$$f(x) \sim g(x), \quad x \rightarrow x_0. \quad (20.12)$$

等价表述为

$$f = g[1 + o(1)] \quad (20.13)$$

或

$$f - g = o(g). \quad (20.14)$$

命题 20.1 (基本运算规则). 在所有表达式有定义且分母最终非零的条件下:

1. 若  $f = O(g)$ ,  $g = O(h)$ , 则  $f = O(h)$ .
2. 若  $f = o(g)$ ,  $g = O(h)$ , 则  $f = o(h)$ .
3. 若  $f_1 = O(g_1)$ ,  $f_2 = O(g_2)$ , 则  $f_1 f_2 = O(g_1 g_2)$ .
4. 若  $f_1 = o(g_1)$ ,  $f_2 = O(g_2)$ , 则  $f_1 f_2 = o(g_1 g_2)$ .
5. 若  $f \sim g$ ,  $h \sim k$ , 则  $fh \sim gk$ .
6. 若  $f \sim g$ ,  $g \neq 0$ , 则  $\frac{1}{f} \sim \frac{1}{g}$ .

证明. 以第 4 条为例. 写  $\frac{f_1 f_2}{g_1 g_2} = \frac{f_1}{g_1} \frac{f_2}{g_2}$ . 第一因子趋于零, 第二因子有界, 故乘积趋于零. 其余各条同理由比值、三角不等式或最终非零性得到.  $\square$

### 20.2.4 知识点七：双边阶与数量级

若  $f = O(g)$  且  $g = O(f)$ , 可记作

$$f = \Theta(g). \quad (20.15)$$

这表示两者处于同一数量级, 但不要求比值趋于 1。

例如  $2 + \sin x = \Theta(1)$ ,  $x \rightarrow \infty$ , 但  $2 + \sin x \not\sim 1$ 。

#### 相减时渐近等价不能直接代换

若  $f \sim g$ , 不能断言  $f - g$  具有与  $f$  或  $g$  相同的数量级。

例如  $f(\varepsilon) = 1 + \varepsilon$ ,  $g(\varepsilon) = 1$ . 虽然  $f \sim g$ , 但  $f - g = \varepsilon$ 。

更极端地,  $f(\varepsilon) = 1 + e^{-1/\varepsilon}$ ,  $g(\varepsilon) = 1$ , 则  $f \sim g$ , 但差值是超越所有代数阶的小量。

资格考试中出现两个大项相减时, 必须先检查首项是否抵消。

## 20.3 一致估计、多参数极限与特异极限

### 20.3.1 知识点八：一致大 $O$ 与一致小 $o$

设  $f(\varepsilon, x)$ ,  $g(\varepsilon, x)$ ,  $x \in D_\varepsilon$ 。若存在与  $\varepsilon$ 、 $x$  均无关的常数  $C$ , 使

$$|f(\varepsilon, x)| \leq C|g(\varepsilon, x)|, \quad x \in D_\varepsilon, \quad (20.16)$$

则称  $f = O(g)$  在  $D_\varepsilon$  上一致成立。

若

$$\sup_{x \in D_\varepsilon} \left| \frac{f(\varepsilon, x)}{g(\varepsilon, x)} \right| \rightarrow 0, \quad \varepsilon \rightarrow 0, \quad (20.17)$$

则称  $f = o(g)$  一致成立。

若  $g$  可能为零, 应改用不含比值的定义: 对任意  $\eta > 0$ , 最终有  $|f| \leq \eta|g|$ 。

### 20.3.2 知识点九：一个几何级数的有效区间

考虑

$$F(\varepsilon, x) = \frac{1}{1 + \varepsilon x}. \quad (20.18)$$

有限几何恒等式给出

$$\frac{1}{1 + \varepsilon x} = \sum_{k=0}^N (-\varepsilon x)^k + \frac{(-\varepsilon x)^{N+1}}{1 + \varepsilon x}. \quad (20.19)$$

若存在固定  $q < 1$ , 使  $|\varepsilon x| \leq q$ , 则

$$\left| \frac{(-\varepsilon x)^{N+1}}{1 + \varepsilon x} \right| \leq \frac{|\varepsilon x|^{N+1}}{1 - q}, \quad (20.20)$$

故展开在该区域一致成立。

但若  $x = O(\varepsilon^{-1})$ , 则  $\varepsilon x = O(1)$ , 各项不再按  $\varepsilon$  逐阶减小。所以  $\frac{1}{1 + \varepsilon x} = 1 - \varepsilon x + \varepsilon^2 x^2 - \dots$  只在

$$\boxed{|\varepsilon x| \ll 1} \quad (20.21)$$

的区域内是有效渐近展开。

### 20.3.3 知识点十：多参数联合极限

对  $F(\varepsilon, \delta)$ ,  $(\varepsilon, \delta) \rightarrow (0, 0)$ , 联合极限要求沿所有趋于原点的路径得到同一结果。

例如

$$F(\varepsilon, \delta) = \frac{\varepsilon}{\varepsilon + \delta}. \quad (20.22)$$


沿不同路径:

$$\delta = \varepsilon \implies F = \frac{1}{2}, \quad (20.23)$$

$$\delta = \varepsilon^2 \implies F = \frac{1}{1 + \varepsilon} \rightarrow 1, \quad (20.24)$$

$$\delta = \sqrt{\varepsilon} \implies F = \frac{\sqrt{\varepsilon}}{1 + \sqrt{\varepsilon}} \rightarrow 0. \quad (20.25)$$

故联合极限不存在。



### 20.3.4 知识点十一：区分极限与特征极限

若模型含两个小参数，常令

$$\delta = C\varepsilon^p, \quad C = O(1), \quad (20.26)$$

选择  $p$  使多个机制在极限中同时保留。这称为特征极限或特定平衡极限 (distinguished limit)。

例如  $\varepsilon y + \delta y^2 = 1$ 。若希望线性项和二次项同阶，设  $y \sim \varepsilon^{-1}$ ，则  $\varepsilon y = O(1)$ ， $\delta y^2 = O(\delta \varepsilon^{-2})$ 。要使二者同阶，需要  $\delta = O(\varepsilon^2)$ 。

#### 易错点与反例

以下三者不可混同：

1. 先令  $\varepsilon \rightarrow 0$ ，再令  $\delta \rightarrow 0$ ；
2. 先令  $\delta \rightarrow 0$ ，再令  $\varepsilon \rightarrow 0$ ；
3. 令  $(\varepsilon, \delta) \rightarrow (0, 0)$ ；
4. 令  $\delta = C\varepsilon^p$  后再令  $\varepsilon \rightarrow 0$ 。

它们可能给出不同结果。

## 20.4 渐近序列、Poincaré 渐近展开与系数唯一性

### 20.4.1 知识点十二：渐近序列

设  $\{\phi_n(x)\}_{n=0}^{\infty}$  定义在某个极限过程附近。若

$$\phi_{n+1}(x) = o(\phi_n(x)), \quad x \rightarrow x_0, \quad n = 0, 1, \dots \quad (20.27)$$

则称  $\{\phi_n\}$  为一个渐近序列。

典型例子：

$$1, \varepsilon, \varepsilon^2, \dots, \quad \varepsilon \rightarrow 0, \quad (20.28)$$

$$x^\alpha, x^{\alpha-1}, x^{\alpha-2}, \dots, \quad x \rightarrow +\infty, \quad (20.29)$$

$$1, \frac{1}{\log x}, \frac{1}{(\log x)^2}, \dots, \quad x \rightarrow +\infty. \quad (20.30)$$

不同渐近序列不能未经说明地混合。例如  $e^{-1/\varepsilon}$  比任意  $\varepsilon^N$  都小，称为超越所有代数阶的小量。


### 20.4.2 知识点十三：Poincaré 渐近展开

若对每个固定  $N \geq 0$ ，有

$$f(x) - \sum_{n=0}^N a_n \phi_n(x) = o(\phi_N(x)), \quad x \rightarrow x_0, \quad (20.31)$$

则记作

$$f(x) \sim \sum_{n=0}^{\infty} a_n \phi_n(x). \quad (20.32)$$



注意右端是形式符号：它不表示该无穷级数必然收敛，也不表示其和等于  $f$ 。

另一种常见约定是

$$f(x) - \sum_{n=0}^N a_n \phi_n(x) = O(\phi_{N+1}(x)). \quad (20.33)$$

该表述通常更强。若不同资料使用不同约定，必须明确说明。

### 20.4.3 知识点十四：首项与主导项

若  $a_0 \neq 0$ ，则  $a_0 \phi_0$  称为首项或主导项，并有  $f \sim a_0 \phi_0$ 。

若前若干系数为零，应从第一个非零系数开始确定真正的主导项。

例如  $f(\varepsilon) = 0 \cdot 1 + 0 \cdot \varepsilon + 3\varepsilon^2 + O(\varepsilon^3)$ ，则主导项是  $3\varepsilon^2$ ，不能称 0 为首项。

**定理 20.2** (固定渐近序列下系数的唯一性). 设  $\{\phi_n\}$  为渐近序列，且  $f$  具有两个展开

$$f \sim \sum_{n=0}^{\infty} a_n \phi_n, \quad (20.34)$$

$$f \sim \sum_{n=0}^{\infty} b_n \phi_n. \quad (20.35)$$

则  $a_n = b_n$ ,  $n = 0, 1, \dots$ 。

**证明.** 若结论不成立，令  $m$  为最小的满足  $a_m \neq b_m$  的指标。将两个展开截断到第  $m$  项并相减：

$$(a_m - b_m) \phi_m = o(\phi_m). \quad (20.36)$$

除以  $\phi_m$ ，得到  $a_m - b_m = o(1)$ 。左端为非零常数，不可能趋于零，矛盾。  $\square$

**注 20.3.** 唯一性只对固定渐近序列成立。同一个函数相对于不同尺度可以有不同形式的展开。

例如  $\frac{1}{1+\varepsilon}$  既可按  $1, \varepsilon, \varepsilon^2, \dots$  展开，也可以按某个重新组合后的尺度展开。

**【证明要求】** 渐近系数唯一性是 需要会完整证明的基础结果。证明核心只有两步：

1. 找到第一个不同系数；
2. 除以对应尺度函数并利用后续项更小。

## 20.5 渐近级数不必收敛：指数积分型标准例子

**基础例题：**一个发散但有效的渐近展开


设

$$F(z) = \int_0^{\infty} \frac{e^{-zt}}{1+t} dt, \quad z > 0. \quad (20.37)$$

求  $z \rightarrow +\infty$  时的渐近展开，并判断形式级数是否收敛。

**证明.** 使用有限恒等式

$$\frac{1}{1+t} = \sum_{k=0}^{N-1} (-1)^k t^k + (-1)^N \frac{t^N}{1+t}. \quad (20.38)$$



代入积分：

$$F(z) = \sum_{k=0}^{N-1} (-1)^k \int_0^\infty e^{-zt} t^k dt + R_N(z), \quad (20.39)$$

$$R_N(z) = (-1)^N \int_0^\infty e^{-zt} \frac{t^N}{1+t} dt. \quad (20.40)$$

利用  $\int_0^\infty e^{-zt} t^k dt = \frac{k!}{z^{k+1}}$ , 得到

$$F(z) = \sum_{k=0}^{N-1} (-1)^k \frac{k!}{z^{k+1}} + R_N(z). \quad (20.41)$$

又因为  $0 < \frac{1}{1+t} \leq 1$ , 有

$$|R_N(z)| \leq \int_0^\infty e^{-zt} t^N dt = \frac{N!}{z^{N+1}}. \quad (20.42)$$

故

$$F(z) \sim \frac{1}{z} - \frac{1}{z^2} + \frac{2!}{z^3} - \frac{3!}{z^4} + \cdots, \quad z \rightarrow +\infty. \quad (20.43)$$

对固定  $z > 0$ , 第  $k$  项的绝对值为  $\frac{k!}{z^{k+1}}$ . 相邻项比值为  $\frac{(k+1)!z^{-k-2}}{k!z^{-k-1}} = \frac{k+1}{z}$ . 当  $k+1 > z$  时, 项开始增大, 且最终不趋于零。因此形式无穷级数对任何固定  $z$  都发散。□

注 20.4 (最优截断). 当  $k \approx z$  时, 项达到最小。由 Stirling 公式  $k! \sim \sqrt{2\pi k} \left(\frac{k}{e}\right)^k$ , 取  $k \approx z$  得到最小项尺度约为

$$O(z^{-1/2} e^{-z}). \quad (20.44)$$

所以对发散渐近级数, 继续增加项数并不总能提高精度; 通常应在最小项附近截断。

#### 易错点与反例

错误说法: “余项阶数越来越高, 所以把无穷多项全部相加最准确。”

错误原因: 渐近定义要求的是对每个固定截断阶  $N$ , 再令参数趋于极限。它不允许同时令  $N \rightarrow \infty$  而忽略系数增长。

正确做法: 先估计第  $N$  项和余项, 再根据参数选择最优截断阶。

## 20.6 渐近展开的代数运算、复合、微分与积分

### 20.6.1 知识点十五: 加减法与主导项抵消

设

$$f(\varepsilon) = \sum_{k=0}^N a_k \varepsilon^k + O(\varepsilon^{N+1}), \quad (20.45)$$

$$g(\varepsilon) = \sum_{k=0}^N b_k \varepsilon^k + O(\varepsilon^{N+1}). \quad (20.46)$$

则

$$f \pm g = \sum_{k=0}^N (a_k \pm b_k) \varepsilon^k + O(\varepsilon^{N+1}). \quad (20.47)$$

但若  $a_0 \pm b_0 = 0$ , 必须继续寻找第一个非零系数。不能保留已经抵消的首项。





## 20.6.2 知识点十六：乘法与 Cauchy 卷积

若要保留到  $\varepsilon^N$ , 则

$$f(\varepsilon)g(\varepsilon) = \sum_{n=0}^N c_n \varepsilon^n + O(\varepsilon^{N+1}), \quad (20.48)$$

其中

$$c_n = \sum_{k=0}^n a_k b_{n-k}. \quad (20.49)$$

例如  $(1 + a\varepsilon + b\varepsilon^2)(1 + c\varepsilon + d\varepsilon^2)$  等于  $1 + (a + c)\varepsilon + (b + d + ac)\varepsilon^2 + O(\varepsilon^3)$ 。

## 20.6.3 知识点十七：倒数与商

若

$$A(\varepsilon) = \sum_{n=0}^N a_n \varepsilon^n, \quad a_0 \neq 0, \quad (20.50)$$

设  $\frac{1}{A(\varepsilon)} = \sum_{n=0}^N b_n \varepsilon^n + O(\varepsilon^{N+1})$ 。由  $A \cdot A^{-1} = 1$  逐阶比较得到

$$b_0 = \frac{1}{a_0}, \quad (20.51)$$

$$b_n = -\frac{1}{a_0} \sum_{k=1}^n a_k b_{n-k}, \quad n \geq 1. \quad (20.52)$$

若  $a_0 = 0$ , 则不能直接使用该递推。必须先提出最低次幂:  $A(\varepsilon) = \varepsilon^m \tilde{A}(\varepsilon)$ ,  $\tilde{A}(0) \neq 0$ 。

## 易错点与反例

从  $f = f_0 + O(\varepsilon)$  直接写  $\frac{1}{f} = \frac{1}{f_0} + O(\varepsilon)$  需要  $f_0 \neq 0$ 。

若  $f_0 = 0$ , 倒数的数量级完全不同。

## 20.6.4 知识点十八：幂、指数与对数

若  $z(\varepsilon) = o(1)$ , 则

$$(1 + z)^\alpha = 1 + \alpha z + \frac{\alpha(\alpha - 1)}{2} z^2 + O(z^3), \quad (20.53)$$

$$e^z = 1 + z + \frac{z^2}{2} + O(z^3), \quad (20.54)$$

$$\log(1 + z) = z - \frac{z^2}{2} + \frac{z^3}{3} + O(z^4). \quad (20.55)$$

若  $f(\varepsilon) = f_0 [1 + \delta(\varepsilon)]$ ,  $\delta = o(1)$ ,  $f_0 > 0$ , 则

$$\log f = \log f_0 + \delta - \frac{\delta^2}{2} + \cdots. \quad (20.56)$$

展开对数时, 最好先提出主导因子。若直接对一个趋于零或改变符号的量取实对数, 可能无定义。

## 20.6.5 知识点十九：复合展开

设  $u(\varepsilon) = u_0 + \delta(\varepsilon)$ ,  $\delta(\varepsilon) \rightarrow 0$ , 且  $F$  在  $u_0$  附近具有足够光滑性。则

$$F(u(\varepsilon)) = \sum_{k=0}^N \frac{F^{(k)}(u_0)}{k!} \delta(\varepsilon)^k + R_N. \quad (20.57)$$



必须根据  $\delta(\varepsilon)$  的实际阶数重新整理。

例如若  $\delta = a\varepsilon + b\varepsilon^2 + O(\varepsilon^3)$ , 则

$$\begin{aligned} F(u_0 + \delta) &= F(u_0) + aF'(u_0)\varepsilon \\ &\quad + \left[ bF'(u_0) + \frac{a^2}{2}F''(u_0) \right] \varepsilon^2 + O(\varepsilon^3). \end{aligned} \quad (20.58)$$

### 20.6.6 知识点二十：逐项微分并非自动成立

即使  $r(\varepsilon) = O(\varepsilon^N)$ , 也不能自动推出  $r'(\varepsilon) = O(\varepsilon^{N-1})$ 。

反例：

$$r(\varepsilon) = \varepsilon^2 \sin(\varepsilon^{-2}). \quad (20.59)$$

显然  $r = O(\varepsilon^2)$ 。但

$$r'(\varepsilon) = 2\varepsilon \sin(\varepsilon^{-2}) - 2\varepsilon^{-1} \cos(\varepsilon^{-2}), \quad (20.60)$$

其数量级可达  $O(\varepsilon^{-1})$ 。

一个足够条件是：

- 展开及其余项在所考察变量上足够光滑；
- 余项导数具有相应一致估计；
- 或函数在统一复邻域内解析，从而可用 Cauchy 估计控制导数。

### 20.6.7 知识点二十一：逐项积分所需条件

若在固定区间  $[a, b]$  上有一致展开

$$f(\varepsilon, x) = \sum_{k=0}^N \varepsilon^k f_k(x) + r_N(\varepsilon, x), \quad (20.61)$$

且  $\sup_{x \in [a, b]} |r_N(\varepsilon, x)| = o(\varepsilon^N)$ , 则

$$\int_a^b f(\varepsilon, x) dx = \sum_{k=0}^N \varepsilon^k \int_a^b f_k(x) dx + o(\varepsilon^N). \quad (20.62)$$

若积分区间随  $\varepsilon$  变化，或只有点态估计，则结论可能失败。


取光滑紧支函数  $\phi \in C_c^\infty([0, \infty))$ ,  $\int_0^\infty \phi(s) ds = 1$ , 并定义

$$f_\varepsilon(x) = \frac{1}{\varepsilon} \phi\left(\frac{x}{\varepsilon}\right). \quad (20.63)$$

对每个固定  $x > 0$ , 最终有  $f_\varepsilon(x) = 0$ , 但

$$\int_0^\infty f_\varepsilon(x) dx = 1. \quad (20.64)$$

所以点态趋零不能直接与积分交换。



## 复杂度说明

若只计算幂级数前  $N + 1$  个系数：

| 形式运算 | 朴素运算复杂度                        | 存储复杂度    |
|------|--------------------------------|----------|
| 加减   | $O(N)$                         | $O(N)$   |
| 乘法卷积 | $O(N^2)$                       | $O(N)$   |
| 倒数递推 | $O(N^2)$                       | $O(N)$   |
| 商    | $O(N^2)$                       | $O(N)$   |
| 一般复合 | 常见朴素实现为 $O(N^2)$<br>至 $O(N^3)$ | $O(N^2)$ |

长级数乘法可用 FFT 降低到近似  $O(N \log N)$ ，但博士资格考试通常要求掌握递推结构，而不要求实现快速形式幂级数算法。

符号计算还可能出现表达式膨胀；运算次数低并不保证中间表达式短。

## 20.7 主导平衡：从未知尺度到有效展开

### 20.7.1 知识点二十二：主导平衡原则

【重要性等级】 **S 级**。主导平衡用于回答：

未知量在参数极限下应具有何种尺度，才能使方程中至少两个机制相互平衡？

若方程为

$$T_1(\varepsilon, y) + \cdots + T_m(\varepsilon, y) = 0, \quad (20.65)$$

假设

$$y \sim C\varepsilon^p, \quad C \neq 0. \quad (20.66)$$

代入后，每一项具有某个幂次  $T_j = O(\varepsilon^{\gamma_j(p)})$ 。要使方程成立，最小指数  $\min_j \gamma_j(p)$  必须至少由两项同时达到；否则只有一个严格最大的主导项，无法被其他项抵消。

主导平衡：识别信号—构造步骤—关键检验—结论—失败原因

识别信号：

- 含小参数或大参数；
- 直接令参数为零会降阶或丢失根；
- 未知量可能趋零、趋无穷或集中在窄区域；
- 存在多个看似可能的数量级。

构造步骤：

1. 假设未知量尺度  $y = C\varepsilon^p$ ；
2. 计算每一项的  $\varepsilon$  指数；

3. 令两项指数相等，生成候选  $p$ ;
4. 检查其他项不比平衡项更大;
5. 解主导系数方程确定  $C$ ;
6. 将近似代回原式，验证余项确实更小;
7. 对所有有效平衡分类，避免遗漏分支。

关键检验：主导阶必须至少有两项，且主导系数之和为零。

结论：得到尺度、分支和后续展开的起点。

常见失败原因：

- 只寻找  $y = O(1)$  分支;
- 候选平衡中存在更大的第三项;
- 主导系数方程只得到  $C = 0$ ，与尺度假设矛盾;
- 未代回验证;
- 不同根或不同区域需要不同尺度，却强行使用一个展开。

### 20.7.2 知识点二十三：单项式方程的指数判据

考虑

$$\sum_{j=1}^m c_j \varepsilon^{a_j} y^{b_j} = 0, \quad c_j \neq 0. \quad (20.67)$$

设  $y = C\varepsilon^p$ 。第  $j$  项指数为

$$\gamma_j(p) = a_j + pb_j. \quad (20.68)$$

候选平衡由

$$a_j + pb_j = a_k + pb_k \quad (20.69)$$

给出，即

$$p = \frac{a_k - a_j}{b_j - b_k}, \quad b_j \neq b_k. \quad (20.70)$$

几何上，把每一项对应到点  $(b_j, a_j)$ 。有效平衡对应这些点下凸包边的斜率；这就是 Newton 多边形思想。

---

#### Algorithm 76 单项式型代数方程的主导平衡搜索

---

**Input:** 项  $c_j \varepsilon^{a_j} y^{b_j}$ ,  $j = 1, \dots, m$

**Output:** 所有候选尺度  $y \sim C\varepsilon^p$

- 1: **Initialization:** 建立空候选集合  $\mathcal{P}$
- 2: **for** 每一对  $j < k$  且  $b_j \neq b_k$  **do**
- 3:     计算  $p \leftarrow \frac{a_k - a_j}{b_j - b_k}$
- 4:     计算全部指数  $\gamma_\ell = a_\ell + pb_\ell$
- 5:     **if** 最小指数至少由两项达到 **then**
- 6:         将  $p$  加入  $\mathcal{P}$
- 7:     **end if**
- 8: **end for**



- 9: **for** 每个不同候选  $p \in \mathcal{P}$  **do**  
 10:     保留所有达到最小指数的项  
 11:     求解主导系数方程以确定非零  $C$   
 12:     代回原方程验证被忽略项为高阶  
 13: **end for**  
 14: **Stopping criterion:** 所有候选对均已检查  
 15: **Complexity:** 朴素实现有  $O(m^2)$  个候选；每个候选检查  $m$  项，故时间复杂度  $O(m^3)$ ，存储  $O(m)$

综合例题：一个方程中的有限根与大根

考虑

$$\varepsilon y^3 + y^2 - 1 = 0, \quad 0 < \varepsilon \ll 1. \quad (20.71)$$

求全部三根的主导尺度及首个修正项。

证明. 设  $y = C\varepsilon^p$ . 三项指数分别为

$$1 + 3p, \quad 2p, \quad 0. \quad (20.72)$$

第一类平衡:  $y = O(1)$  令  $2p = 0$ , 得到  $p = 0$ . 此时第一项指数为 1, 确为高阶项; 主导方程为  $C^2 - 1 = 0$ . 故有两个分支  $C = \pm 1$ .

令  $y = s + \varepsilon a + O(\varepsilon^2)$ ,  $s = \pm 1$ . 代入:

$$\begin{aligned} 0 &= \varepsilon [s^3 + O(\varepsilon)] + s^2 + 2s\varepsilon a - 1 + O(\varepsilon^2) \\ &= \varepsilon (s + 2sa) + O(\varepsilon^2). \end{aligned} \quad (20.73)$$

因为  $s \neq 0$ ,  $1 + 2a = 0$ , 所以  $a = -\frac{1}{2}$ . 两个有限根为

$$y_1 = 1 - \frac{\varepsilon}{2} + O(\varepsilon^2), \quad (20.74)$$

$$y_2 = -1 - \frac{\varepsilon}{2} + O(\varepsilon^2). \quad (20.75)$$

第二类平衡: 遗漏的大根 令  $1 + 3p = 2p$ , 得到  $p = -1$ . 此时前两项指数均为  $-2$ , 常数项指数为 0, 确为高阶. 主导系数方程为  $C^3 + C^2 = 0$ . 由于尺度假设要求  $C \neq 0$ , 得到  $C = -1$ . 故第三根满足  $y_3 \sim -\varepsilon^{-1}$ .

进一步令  $y = -\frac{1}{\varepsilon} + z$ . 代入原方程后精确化简为

$$\frac{z}{\varepsilon} - 2z^2 + \varepsilon z^3 - 1 = 0. \quad (20.76)$$

设  $z = \varepsilon + a\varepsilon^3 + O(\varepsilon^5)$ . 代入得到  $(a - 2)\varepsilon^2 + O(\varepsilon^4) = 0$ , 故  $a = 2$ . 因此

$$y_3 = -\frac{1}{\varepsilon} + \varepsilon + 2\varepsilon^3 + O(\varepsilon^5). \quad (20.77)$$

□

#### 易错点与反例

若直接令  $\varepsilon = 0$ , 只得到  $y^2 - 1 = 0$ , 因而只能找到两根。

原方程是三次方程, 第三根必须在  $|y| \rightarrow \infty$  的尺度上寻找。这类“降次后丢根”是主导平衡的高

频考法。

### 20.7.3 知识点二十四：微分方程中的导数尺度

若解在长度尺度  $\delta$  上变化，写  $X = \frac{x-x_0}{\delta}$ ,  $y(x) = Y(X)$ , 则

$$\frac{dy}{dx} = \delta^{-1} Y_X, \quad (20.78)$$

$$\frac{d^2 y}{dx^2} = \delta^{-2} Y_{XX}. \quad (20.79)$$

考虑

$$\varepsilon y'' + a(x)y' + b(x)y = f(x), \quad (20.80)$$

且在某局部区域  $a(x_0) \neq 0$ 。三个项尺度为  $\frac{\varepsilon}{\delta^2}$ ,  $\frac{1}{\delta}$ , 1。若快速层由二阶导数和一阶导数平衡:  $\frac{\varepsilon}{\delta^2} \sim \frac{1}{\delta}$ , 则

$$\boxed{\delta \sim \varepsilon}. \quad (20.81)$$

若一阶导数项不存在或其系数在该点消失，二阶导数与零阶项平衡:  $\frac{\varepsilon}{\delta^2} \sim 1$ , 则

$$\boxed{\delta \sim \sqrt{\varepsilon}}. \quad (20.82)$$

完整的边界层位置、匹配和复合展开将在第 23 部分处理。

## 20.8 量纲分析：维数矩阵与 Buckingham II 定理

### 20.8.1 知识点二十五：基本量纲与量纲向量

【重要性等级】 **A 级**。设所用基本量纲为 M 质量, L 长度, T 时间。物理量  $q$  的量纲写为

$$[q] = M^{d_1} L^{d_2} T^{d_3}. \quad (20.83)$$

定义量纲向量

$$\mathbf{d}(q) = \begin{pmatrix} d_1 \\ d_2 \\ d_3 \end{pmatrix}. \quad (20.84)$$

例如:

$$[\text{速度}] = LT^{-1}, \quad (20.85)$$

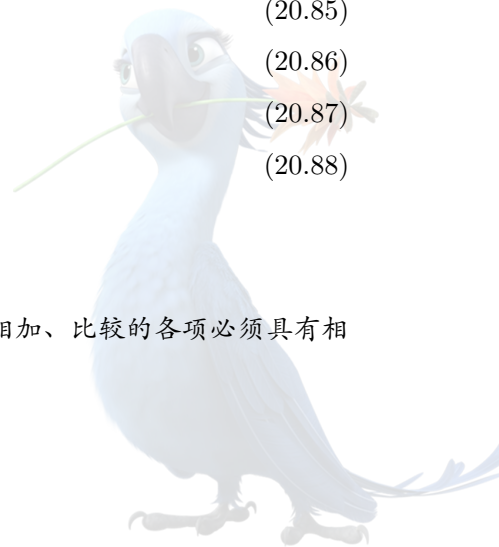
$$[\text{加速度}] = LT^{-2}, \quad (20.86)$$

$$[\text{力}] = MLT^{-2}, \quad (20.87)$$

$$[\text{动力黏度}] = ML^{-1}T^{-1}. \quad (20.88)$$

### 20.8.2 知识点二十六：量纲齐次性

物理关系  $F(q_1, \dots, q_n) = 0$  必须在单位变换下保持不变。因此能够相加、比较的各项必须具有相同量纲。



例如  $x + vt$  量纲齐次, 因为  $[x] = \text{L}$ ,  $[vt] = \text{L}$ 。

表达式  $x + v$  一般无物理意义, 因为长度与速度不可直接相加。

指数、对数、三角函数的自变量必须无量纲。例如  $e^{-t/\tau}$ ,  $\sin(\omega t)$  中  $t/\tau$ ,  $\omega t$  均无量纲。

### 20.8.3 知识点二十七: 维数矩阵

设有  $n$  个物理量  $q_1, \dots, q_n$ , 使用  $k$  个基本量纲。将每个量的量纲向量作为一列, 组成维数矩阵

$$D = \begin{pmatrix} | & & | \\ \mathbf{d}(q_1) & \cdots & \mathbf{d}(q_n) \\ | & & | \end{pmatrix} \in \mathbb{R}^{k \times n}. \quad (20.89)$$

对单项式

$$\Pi = q_1^{a_1} \cdots q_n^{a_n}, \quad (20.90)$$

其量纲指数向量为  $D\mathbf{a}$ ,  $\mathbf{a} = (a_1 \cdots a_n)^\top$ 。因此

$$\boxed{\Pi \text{ 无量纲} \iff D\mathbf{a} = \mathbf{0}}. \quad (20.91)$$

无量纲群的构造被转化为求维数矩阵零空间。

**定理 20.5** (Buckingham II 定理的线性代数形式). 设一个量纲齐次关系涉及  $n$  个物理量, 其维数矩阵  $D$  的秩为  $r$ 。则存在  $n-r$  个线性无关的无量纲群  $\Pi_1, \dots, \Pi_{n-r}$ 。在单位变换不变性和适当正则性下, 原关系可改写为

$$\boxed{\Phi(\Pi_1, \dots, \Pi_{n-r}) = 0}. \quad (20.92)$$

#### 证明思路

由秩-零度定理,  $\dim \ker D = n - r$ 。取零空间基  $\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(n-r)}$ 。定义  $\Pi_j = \prod_{i=1}^n q_i^{a_i^{(j)}}$ 。由  $D\mathbf{a}^{(j)} = \mathbf{0}$ , 每个  $\Pi_j$  均无量纲。

进一步把  $D$  的  $r$  个线性无关列选作重复变量。单位可以被重新缩放, 使这些重复变量的数值归一为 1; 其余变量在该归一化中的数值正是若干  $\Pi_j$ 。由于物理关系在单位变换下不变, 它只能依赖这些无量纲组合。

注 20.6. 无量纲群的基不唯一。

若  $\Pi_1, \Pi_2$  是一组无量纲群, 则  $\Pi_1 \Pi_2^{-2}, \Pi_2^3$  也可作为另一组, 只要对应指数向量仍线性无关。


不同答案可能形式不同, 但它们张成同一个量纲零空间。

#### Algorithm 77 Buckingham II 无量纲群构造

**Input:** 物理量  $q_1, \dots, q_n$ ; 基本量纲; 每个物理量的量纲指数

**Output:**  $n-r$  个独立无量纲群

- 1: **Initialization:** 构造维数矩阵  $D \in \mathbb{Q}^{k \times n}$
- 2: 计算  $r = \text{rank}(D)$
- 3: 求零空间基  $\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(n-r)}$
- 4: **for**  $j = 1, \dots, n-r$  **do**
- 5:     将有理指数乘以公分母, 化为较小整数
- 6:     构造  $\Pi_j = \prod_{i=1}^n q_i^{a_i^{(j)}}$





- 7: 验证  $D\mathbf{a}^{(j)} = \mathbf{0}$
- 8: **end for**
- 9: **Stopping criterion:** 得到  $n - r$  个线性无关无量纲群
- 10: **Complexity:** 对  $k \times n$  矩阵作消元; 朴素时间复杂度约为  $O(k^2n + k^3)$ , 存储  $O(kn)$ 。精确有理运算还需考虑整数位数增长

## 20.9 量纲分析基础例题：单摆周期

基础例题：单摆周期的量纲形式

假设单摆小振动周期  $\mathcal{P}$  可能依赖：

$\mathcal{P}$ ,  $\ell$ (摆长),  $g$ (重力加速度),  $m$ (摆球质量)。仅用量纲分析求其可能形式。

证明. 各量量纲为

$$[\mathcal{P}] = \text{T}, \quad (20.93)$$

$$[\ell] = \text{L}, \quad (20.94)$$

$$[g] = \text{LT}^{-2}, \quad (20.95)$$

$$[m] = \text{M}. \quad (20.96)$$

按列顺序  $\mathcal{P}, \ell, g, m$ , 维数矩阵为

$$D = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 \\ 1 & 0 & -2 & 0 \end{pmatrix}. \quad (20.97)$$

其秩为 3, 故有一个独立无量纲群。

求  $D\mathbf{a} = \mathbf{0}$ 。可取  $\mathbf{a} = \begin{pmatrix} 1 \\ -1/2 \\ 1/2 \\ 0 \end{pmatrix}$ 。于是

$$\Pi = \mathcal{P} \sqrt{\frac{g}{\ell}}. \quad (20.98)$$

由于只有一个无量纲群, 它必须为常数:  $\mathcal{P} \sqrt{\frac{g}{\ell}} = C$ 。故

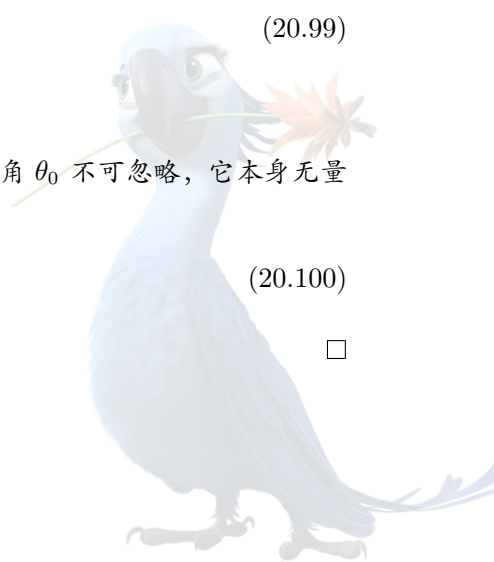
$$\boxed{\mathcal{P} = C \sqrt{\frac{\ell}{g}}}. \quad (20.99)$$

质量  $m$  不出现。

量纲分析不能确定  $C$ 。由小振幅动力学求解才得到  $C = 2\pi$ 。若振幅角  $\theta_0$  不可忽略, 它本身无量纲, 故只能得到

$$\mathcal{P} = \sqrt{\frac{\ell}{g}} \Phi(\theta_0). \quad (20.100)$$

□



## 易错点与反例

量纲分析能够确定：

- 变量的幂次组合；
- 无量纲参数个数；
- 参数依赖的可能形式。

但它一般不能确定：

- 无量纲常数  $2\pi$ ；
- 无量纲函数  $\Phi$  的具体表达式；
- 初边值条件导致的分支。

## 20.10 量纲分析综合例题：球体阻力与 Reynolds 数

## 综合例题：球体阻力的无量纲表示

设球体在黏性流体中运动，阻力  $F$  可能依赖于：

$F$ ,  $\rho$ (密度),  $U$ (特征速度),  $d$ (球直径),  $\mu$ (动力黏度)。构造全部独立无量纲群。

证明. 各量量纲为

$$[F] = \text{MLT}^{-2}, \quad (20.101)$$

$$[\rho] = \text{ML}^{-3}, \quad (20.102)$$

$$[U] = \text{LT}^{-1}, \quad (20.103)$$

$$[d] = \text{L}, \quad (20.104)$$

$$[\mu] = \text{ML}^{-1}\text{T}^{-1}. \quad (20.105)$$

按列顺序  $F, \rho, U, d, \mu$ , 维数矩阵为

$$D = \begin{pmatrix} 1 & 1 & 0 & 0 & 1 \\ 1 & -3 & 1 & 1 & -1 \\ -2 & 0 & -1 & 0 & -1 \end{pmatrix}. \quad (20.106)$$

其秩为 3, 故有  $5 - 3 = 2$  个独立无量纲群。

可取零空间向量

$$\mathbf{a}^{(1)} = \begin{pmatrix} 1 \\ -1 \\ -2 \\ -2 \\ 0 \end{pmatrix}, \quad (20.107)$$



$$\mathbf{a}^{(2)} = \begin{pmatrix} 0 \\ 1 \\ 1 \\ 1 \\ -1 \end{pmatrix}. \quad (20.108)$$

对应

$$\Pi_1 = \frac{F}{\rho U^2 d^2}, \quad (20.109)$$

$$\Pi_2 = \frac{\rho U d}{\mu} = \text{Re}. \quad (20.110)$$

Buckingham II 定理给出

$$\boxed{\frac{F}{\rho U^2 d^2} = \Phi(\text{Re})}. \quad (20.111)$$

左端可视为阻力系数的一个归一化版本，右端是 Reynolds 数的无量纲函数。  $\square$

注 20.7. 量纲分析不能自行推出 Stokes 低 Reynolds 数极限中的  $F = 3\pi\mu dU$ 。但若额外知道  $\Phi(\text{Re}) \sim C \text{Re}^{-1}$ ,  $\text{Re} \rightarrow 0$ , 则  $F \sim C\mu U d$ 。常数  $C$  仍需由方程求解或实验确定。

## 20.11 无量纲化：尺度选择、控制参数与极限模型

### 20.11.1 知识点二十八：一般无量纲化模板

设  $x = LX$ ,  $t = T_0\tau$ ,  $u = U_0v$ . 则

$$\partial_t u = \frac{U_0}{T_0} \partial_\tau v, \quad (20.112)$$

$$\partial_x u = \frac{U_0}{L} \partial_X v, \quad (20.113)$$

$$\partial_{xx} u = \frac{U_0}{L^2} \partial_{XX} v. \quad (20.114)$$

无量纲化的标准步骤是：

1. 列出变量与参数的量纲；
2. 选择特征长度、时间、振幅等尺度；
3. 代入原方程；
4. 除以一个主导系数；
5. 识别剩余无量纲组合；
6. 根据这些组合的大、小判断主导机制；
7. 给出极限模型与其适用范围。



## 易错点与反例

尺度不是任意符号替换。

合理尺度应使主要无量纲变量为  $O(1)$ ，并使希望保留的机制系数为  $O(1)$ 。

若尺度选择不当，方程中可能出现大量  $10^{12}$ ， $10^{-15}$  型系数，既妨碍渐近识别，也恶化数值条件。

## 20.11.2 知识点二十九：对流-扩散-反应方程

考虑

$$u_t + a_0 u_x = \kappa u_{xx} + ru, \quad 0 < x < L, \quad (20.115)$$

其中  $a_0 > 0$ ,  $\kappa > 0$ 。取对流时间尺度  $T_0 = \frac{L}{a_0}$  以及  $x = LX$ ,  $t = \frac{L}{a_0} \tau$ ,  $u = U_0 v$ . 代入：

$$\frac{a_0 U_0}{L} v_\tau + \frac{a_0 U_0}{L} v_X = \frac{\kappa U_0}{L^2} v_{XX} + r U_0 v. \quad (20.116)$$

除以  $a_0 U_0 / L$  得到

$$v_\tau + v_X = \frac{1}{\text{Pe}} v_{XX} + \text{Da} v. \quad (20.117)$$

其中

$$\text{Pe} = \frac{a_0 L}{\kappa}, \quad (20.118)$$

$$\text{Da} = \frac{rL}{a_0}. \quad (20.119)$$

解释：

- $\text{Pe} \gg 1$  表示对流强于扩散；
- $\text{Pe} \ll 1$  表示扩散主导；
- $|\text{Da}| \gg 1$  表示反应时间尺度短于对流时间尺度。

若扩散主导，更自然的时间尺度是  $T_0 = \frac{L^2}{\kappa}$ 。此时方程写为

$$v_\tau + \text{Pe} v_X = v_{XX} + \text{Da}_d v, \quad (20.120)$$

其中  $\text{Da}_d = \frac{rL^2}{\kappa}$ 。两种表示不是冲突，而是选取了不同基准时间尺度。

## 20.11.3 知识点三十：受迫 Duffing 型振子的无量纲化

考虑

$$m\ddot{x} + c\dot{x} + kx + \alpha x^3 = F_0 \cos(\omega t), \quad (20.121)$$

其中  $m > 0$ ,  $k > 0$ 。定义线性固有频率

$$\omega_0 = \sqrt{\frac{k}{m}}. \quad (20.122)$$

取  $x = AX$ ,  $\tau = \omega_0 t$ 。则

$$\dot{x} = A\omega_0 X', \quad (20.123)$$

$$\ddot{x} = A\omega_0^2 X''. \quad (20.124)$$



除以  $kA$ , 得到

$$X'' + 2\zeta X' + X + \beta X^3 = f \cos(\Omega\tau). \quad (20.125)$$

其中

$$\zeta = \frac{c}{2\sqrt{mk}}, \quad (20.126)$$

$$\beta = \frac{\alpha A^2}{k}, \quad (20.127)$$

$$f = \frac{F_0}{kA}, \quad (20.128)$$

$$\Omega = \frac{\omega}{\omega_0}. \quad (20.129)$$

振幅尺度  $A$  可按目标选择:

1. 若希望非线性项系数为 1, 可取  $A = \sqrt{\frac{k}{|\alpha|}}$ , 使  $\beta = \text{sgn}(\alpha)$ ;
2. 若希望外力系数为 1, 可取  $A = \frac{F_0}{k}$ ;
3. 若初始振幅已知, 常取  $A$  等于初始振幅, 使初始无量纲数据为  $O(1)$ 。

一个尺度通常不能同时消去全部无量纲参数。剩余参数正是不同物理机制的不可约比值。

#### 20.11.4 知识点三十一: 无量纲化与数值条件

良好无量纲化通常使:

$X, \tau, v = O(1)$ , 主要系数  $= O(1)$ 。这有助于:

- 避免浮点上溢、下溢;
- 减少矩阵行列尺度差异;
- 识别真正的小参数;
- 合理分配绝对与相对容差;
- 比较不同实验或不同物理尺度。

但无量纲化不能自动消除问题本身的病态性。若极限问题接近奇异、分支点或共振, 无量纲系统仍可能高度敏感。

### 20.12 尺度律: 由方程直接推导扩散长度和振幅

#### 20.12.1 知识点三十二: 扩散长度尺度

考虑  $d$  维扩散方程


$$u_t = D\Delta u, \quad D > 0. \quad (20.130)$$

设在时间  $t$  时解主要分布在长度尺度  $L(t)$  上, 振幅尺度为  $U(t)$ 。则  $u_t \sim \frac{U}{t}$ ,  $\Delta u \sim \frac{U}{L^2}$ 。主导平衡给出  $\frac{U}{t} \sim D \frac{U}{L^2}$ , 因而

$$L(t) \sim \sqrt{Dt}. \quad (20.131)$$

若总质量  $M = \int_{\mathbb{R}^d} u(x, t) dx$  守恒, 则  $U(t)L(t)^d \sim M$ 。所以

$$U(t) \sim M(Dt)^{-d/2}. \quad (20.132)$$



这给出热核  $t^{-d/2} \exp\left(-\frac{|x|^2}{4Dt}\right)$  的尺度结构, 而无需先求出精确解。

## 20.13 过渡尺度与非一致展开

### 20.13.1 知识点三十三: 平方根模型中的过渡尺度

考虑

$$F(\varepsilon, x) = \sqrt{x^2 + \varepsilon}, \quad x \geq 0, \quad \varepsilon \rightarrow 0^+. \quad (20.133)$$

对固定  $x > 0$ , 提出  $x$ :

$$\begin{aligned} F(\varepsilon, x) &= x \sqrt{1 + \frac{\varepsilon}{x^2}} \\ &= x + \frac{\varepsilon}{2x} - \frac{\varepsilon^2}{8x^3} + O\left(\frac{\varepsilon^3}{x^5}\right). \end{aligned} \quad (20.134)$$

该展开要求

$$\frac{\varepsilon}{x^2} \ll 1, \quad \text{即} \quad x \gg \sqrt{\varepsilon}. \quad (20.135)$$

当  $x = O(\sqrt{\varepsilon})$  时, 外展开各修正项不再逐阶减小。令  $x = \sqrt{\varepsilon}X$ , 则

$$F = \sqrt{\varepsilon} \sqrt{1 + X^2}. \quad (20.136)$$

因此过渡尺度由  $x^2 \sim \varepsilon$  的主导平衡得到:

$$\boxed{x \sim \sqrt{\varepsilon}}. \quad (20.137)$$

#### 易错点与反例

外展开中的  $\frac{\varepsilon}{2x}$  在  $x \rightarrow 0$  时发散, 不是原函数发散, 而是展开失效。  
看到展开系数在某点奇异时, 应优先判断:

- 原问题是否真的奇异;
- 还是所选尺度不适用;
- 需要何种内变量恢复平衡。

### 20.13.2 知识点三十四: 绝对误差和相对误差的有效性

若近似  $F_{\text{app}}$  满足  $|F - F_{\text{app}}| \rightarrow 0$ , 只能说明绝对误差小。

若  $F \rightarrow 0$ , 还需检查

$$\frac{|F - F_{\text{app}}|}{|F|}. \quad (20.138)$$

例如  $F(\varepsilon) = \varepsilon$ ,  $F_{\text{app}} = 0$ 。绝对误差为  $\varepsilon \rightarrow 0$ , 但相对误差恒为 1。

在求零点、特征值或小振幅时, 必须根据题目目标选择绝对或相对精度。



## 20.14 误差项的主导平衡与最优参数选择

综合母题：离散误差与截断误差的平衡

设一个数值近似依赖计算量参数  $N \rightarrow \infty$  和截断尺度  $L \rightarrow \infty$ ，总误差具有渐近形式

$$E(N, L) = A \frac{L^s}{N^p} + BL^{-\alpha} + o\left(\frac{L^s}{N^p} + L^{-\alpha}\right), \quad (20.139)$$

其中  $A, B, p, s, \alpha > 0$ 。求使主导误差最小的  $L = L(N)$  及最优误差阶。

证明. 若  $L = CN^q$ ,  $C > 0$ , 则两个主导误差项分别为

$$A \frac{L^s}{N^p} = AC^s N^{sq-p}, \quad (20.140)$$

$$BL^{-\alpha} = BC^{-\alpha} N^{-\alpha q}. \quad (20.141)$$

若其中一个严格大于另一个，可以调整  $L$  进一步降低较大项；故最优尺度由两个误差同阶给出：

$$sq - p = -\alpha q. \quad (20.142)$$

解得

$$q = \frac{p}{s + \alpha}. \quad (20.143)$$

所以

$$L = CN^{p/(s+\alpha)}. \quad (20.144)$$

此时两项均为  $N^{-p\alpha/(s+\alpha)}$  阶，因此

$$E_{\text{opt}}(N) = O\left(N^{-p\alpha/(s+\alpha)}\right). \quad (20.145)$$

若还要求优化主导常数，最小化  $\Psi(C) = AC^s + BC^{-\alpha}$ 。求导： $\Psi'(C) = AsC^{s-1} - B\alpha C^{-\alpha-1}$ 。令其为零：

$$C^{s+\alpha} = \frac{B\alpha}{As}. \quad (20.146)$$

故

$$C_* = \left(\frac{B\alpha}{As}\right)^{1/(s+\alpha)}. \quad (20.147)$$

□

注 20.8 (与无穷区间求积母题的联系). 若复合梯形误差主项满足  $E_{\text{disc}} = O\left(\frac{L^2}{N^2}\right)$ ，而截断尾误差满足  $E_{\text{tail}} = O(L^{-\alpha})$ ，则  $p = 2$ ,  $s = 2$ 。所以

$$L \asymp N^{2/(\alpha+2)} \quad (20.148)$$

且

$$E_{\text{opt}} = O\left(N^{-2\alpha/(\alpha+2)}\right). \quad (20.149)$$

这正是“离散误差随  $L$  增大而恶化、尾误差随  $L$  增大而改善”的标准主导平衡结构。

易错点与反例

误差优化不能只令其中一项最小：

- 令  $L \rightarrow \infty$  会减小尾误差，但可能放大离散误差；



- 令  $L$  过小会改善网格分辨率，但尾部截断误差不消失。
- 最优参数通常来自两个主导误差项同阶。

## 20.15 渐近分析中的条件数、消去与数值实现

### 20.15.1 知识点三十五：小差值的敏感性

设  $f, g = O(1)$ ,  $f - g = O(\varepsilon^p)$ 。若  $f$  和  $g$  各自含绝对扰动  $O(\delta)$ ，则差值的相对误差可能达到

$$O\left(\frac{\delta}{\varepsilon^p}\right). \quad (20.150)$$

当  $\varepsilon^p \ll \delta$  时，差值几乎不能由直接相减可靠获得。

因此渐近展开和稳定公式之间有直接联系：

- 渐近展开可揭示被两个大项相消后的真正小量；
- 数值实现应改写公式，避免直接相减；
- 展开阶数不能超过浮点精度允许的有效阶。

例如  $1 - \cos x$  在  $x \rightarrow 0$  时直接计算会消去。可改写为  $1 - \cos x = 2 \sin^2 \frac{x}{2}$  或使用  $1 - \cos x = \frac{x^2}{2} - \frac{x^4}{24} + O(x^6)$ 。

### 20.15.2 知识点三十六：渐近展开截断与舍入误差

设第  $k$  项大小为  $T_k(\varepsilon)$ ，而浮点相对精度为  $u_{\text{mach}}$ 。若后续项小于由前面大项计算产生的舍入噪声，则继续增加项数没有意义。

实际停止准则可取：

1. 新增项不再减小；
2. 新增项小于指定绝对容差；
3. 新增项小于  $u_{\text{mach}} \times$  部分和尺度；
4. 已达到理论最优截断阶。

#### 算法说明

渐近级数的数值求和应采用：

- 递推生成项，避免重复计算阶乘和幂；
- 从小项向大项求和，或使用补偿求和；
- 监测相邻项比值；
- 在最小项附近停止；
- 对交错级数记录下一项作为误差指标，但不得无条件当作严格界。

## 20.16 易错点、反例与资格考试答题模板

| 错误说法或错误做法                                              | 正确处理                                                |
|--------------------------------------------------------|-----------------------------------------------------|
| $f = O(g)$ 表示 $f/g \rightarrow 1$ 。                    | $O$ 只给有界性；比值趋于 1 应写 $f \sim g$ 。                    |
| $f = o(g)$ 和 $g = o(f)$ 可以同时成立。                        | 除非最终二者均为零等退化情形，否则对非零尺度不可能。                          |
| 渐近等价可以在加减法中任意替换。                                       | 乘除通常安全；加减必须检查首项抵消。                                  |
| 点态展开自动是一致展开。                                           | 必须估计关于其他变量的上确界，并写明有效区域。                             |
| 对固定 $x$ 有效的展开也适用于 $x = x(\varepsilon)$ 。               | 需检查复合量，如 $\varepsilon x$ 、 $x/\varepsilon$ 是否仍小或有界。 |
| 渐近级数一定收敛到原函数。                                          | 渐近级数可以发散；定义只要求固定阶截断余项更小。                            |
| 多取几项总能提高精度。                                            | 发散级数在最小项后会恶化，应使用最优截断。                               |
| 余项 $O(\varepsilon^N)$ 逐项微分后必为 $O(\varepsilon^{N-1})$ 。 | 需额外的一致光滑性或导数余项估计。                                   |
| 点态趋零可以直接交换积分。                                          | 需要一致控制、支配收敛或适当重标度；集中序列是反例。                          |
| 令 $\varepsilon = 0$ 得到的根就是全部根。                         | 降次可能丢失趋于无穷的根，必须检查其他主导尺度。                            |
| 主导平衡只需令任意两项同阶。                                         | 还需检查第三项不更大，并解非零主导系数方程。                              |
| 找到一个尺度就完成了。                                            | 一个方程可有多个分支、多个区域和多个有效尺度。                             |
| 量纲分析能给出精确常数。                                           | 量纲分析只给无量纲组合和函数形式，常数需动力学或实验确定。                       |
| 无量纲群是唯一的。                                              | 零空间基不唯一；不同无量纲群可通过可逆幂变换互换。                           |
| 变量个数减基本量纲数就是无量纲群数。                                     | 应减去维数矩阵的秩，而不是机械减基本量纲总数。                             |
| 无量纲化可以消除所有参数。                                          | 只能消去可由尺度吸收的参数，剩余无量纲比值具有物理意义。                        |
| 小的有量纲系数就是小参数。                                          | 只有与相同量纲尺度比较后形成的小无量纲比值才有渐近意义。                        |
| 绝对误差趋零即可说明相对准确。                                        | 当目标量趋零时必须单独检查相对误差。                                  |
| 形式上平衡两个误差项即可宣布最优。                                      | 还需验证其他误差项更小、参数范围可行以及常数不退化。                          |

反例 20.9 (多参数路径依赖). 函数  $F(\varepsilon, \delta) = \frac{\varepsilon}{\varepsilon + \delta}$  沿不同路径得到 0、1/2 或 1。因此不能只写  $\varepsilon, \delta \rightarrow 0$  而不说明相互关系。

反例 20.10 (逐项微分失败).  $r(\varepsilon) = \varepsilon^2 \sin(\varepsilon^{-2}) = O(\varepsilon^2)$ , 但  $r'(\varepsilon) = O(\varepsilon^{-1})$  而不是  $O(\varepsilon)$ 。

反例 20.11 (点态小量不是一致小量).  $e^{-x/\varepsilon} = o(\varepsilon^N)$  对每个固定  $x > 0$  成立，但在  $[0, 1]$  上不一致，因为端点值始终为 1。

## 有效区间判断的统一框架

识别信号：展开项含  $\varepsilon x$ ,  $\varepsilon/x^2$ ,  $t\varepsilon$ ,  $e^{-x/\varepsilon}$ 。

构造步骤：

1. 求相邻项比值；
2. 要求相邻项比值远小于 1；
3. 解出变量与参数的尺度限制；
4. 在失效边界令竞争项同阶；
5. 定义伸缩变量；
6. 重新写出局部问题。

关键估计：例如  $\frac{\varepsilon^{n+1} F_{n+1}(x)}{\varepsilon^n F_n(x)} \ll 1$ 。

结论：必须给出点态或一致有效区域。

常见失败原因：只比较  $\varepsilon$  幂次，不比较系数函数随  $x$  的增长。



# 第二十一章 Watson 引理、Laplace 方法、驻相法、最速下降法与振荡积分

## 21.1 渐近积分的统一结构：局部化、临界点与贡献比较

### 21.1.1 知识点一：问题、目标与三类基本机制

【重要性等级】 S 级。考虑

$$I(\lambda) = \int_a^b e^{\lambda \Phi(t)} A(t) dt, \lambda \rightarrow +\infty, \tag{21.1}$$

其中  $\Phi(t) = R(t) + iI(t)$ 。

指数的模为

$$|e^{\lambda \Phi(t)}| = e^{\lambda R(t)}. \tag{21.2}$$

因此渐近贡献由两种机制控制：

- 1. 指数集中：  $R$  在某些点达到最大值；
- 2. 振荡抵消：  $R \equiv 0$  或变化较弱，而相位  $I$  高速变化。


对应三类基本题型：

| 类型        | 识别信号                                 | 主导贡献位置                      |
|-----------|--------------------------------------|-----------------------------|
| Watson 型  | $\exp(-\lambda t)$ , 端点 $t = 0$      | 端点局部 Taylor 展开              |
| Laplace 型 | $\exp(\lambda R(t))$ , $R$ 实值        | $R$ 的全局最大值点                 |
| 驻相型       | $\exp(i\lambda \phi(t))$ , $\phi$ 实值 | 驻相点 $\phi'(t) = 0$ 及端点      |
| 最速下降型     | $\Phi$ 复解析, 允许路径变形                   | 可由原路径变形到达的鞍点 $\Phi'(z) = 0$ |

### 21.1.2 知识点二：局部化原则

设  $R_{\max} = \max_{t \in [a, b]} R(t)$ , 并设主导点集合为  $\mathcal{M} = \{t \in [a, b] : R(t) = R_{\max}\}$ 。

取光滑截断函数  $\chi_1 + \cdots + \chi_m + \chi_{\text{far}} = 1$ , 其中每个  $\chi_j$  支撑在一个主导点附近,  $\chi_{\text{far}}$  支撑远离  $\mathcal{M}$ 。



若在远离主导点的区域有  $R(t) \leq R_{\max} - \eta$ ,  $\eta > 0$ , 则

$$\begin{aligned} \left| \int_a^b e^{\lambda \Phi(t)} A(t) \chi_{\text{far}}(t) dt \right| &\leq e^{\lambda(R_{\max} - \eta)} \int_a^b |A(t) \chi_{\text{far}}(t)| dt \\ &= e^{\lambda R_{\max}} O(e^{-\eta \lambda}). \end{aligned} \quad (21.3)$$

所以远区相对于主导贡献通常指数小。

对纯振荡积分, 若某区域满足  $|\phi'(t)| \geq c > 0$ , 则可反复分部积分, 得到任意代数阶的小量。因此驻相法同样具有局部化结构: 驻相点邻域 + 非驻相区。

#### 渐近积分统一分析框架

识别信号:

- 积分中出现大参数  $\lambda$ ;
- 参数位于指数、三角函数或快速振荡相位中;
- 被积函数在某些点集中或发生强烈抵消。

构造步骤:

1. 写出指数的实部和虚部;
2. 求最大值点、驻相点、鞍点及端点;
3. 用截断函数局部化;
4. 对远区使用指数衰减或分部积分;
5. 对每个局部区域选择标准变量:  $s$ ,  $s^2$ ,  $s^m$ ;
6. 化为 Gamma、Gaussian、Fresnel 或 Airy 标准积分;
7. 比较不同局部贡献的指数因子和代数阶;
8. 检查路径、分支、端点和参数一致性。

关键估计:

远区  $= O(e^{\lambda(R_{\max} - \eta)})$  或 非驻相区  $= O(\lambda^{-N})$ 。

结论:

总渐近展开是所有有效局部贡献之和。

常见失败原因:

- 只找局部极值而未检查全局最大值;
- 漏掉端点贡献;
- 漏掉多个等高最大值或多个驻相点;
- 路径不能变形到所选鞍点;
- 最大点退化, 却仍使用 Gaussian 公式;
- 参数变化导致临界点合并, 标准展开失去一致性。

## 21.2 非驻相区：分部积分、端点展开与 van der Corput 估计

### 21.2.1 知识点三：一次分部积分

考虑

$$J(\lambda) = \int_a^b e^{i\lambda\phi(t)} a(t) dt, \quad (21.4)$$

假设  $\phi \in C^2[a, b]$ ,  $a \in C^1[a, b]$ ,  $\phi'(t) \neq 0 \quad \forall t \in [a, b]$ 。因为  $\frac{d}{dt} e^{i\lambda\phi(t)} = i\lambda\phi'(t)e^{i\lambda\phi(t)}$ , 有

$$\begin{aligned} J(\lambda) &= \frac{1}{i\lambda} \int_a^b \frac{a(t)}{\phi'(t)} \frac{d}{dt} e^{i\lambda\phi(t)} dt \\ &= \frac{1}{i\lambda} \left[ e^{i\lambda\phi(t)} \frac{a(t)}{\phi'(t)} \right]_a^b \\ &\quad - \frac{1}{i\lambda} \int_a^b e^{i\lambda\phi(t)} \frac{d}{dt} \left( \frac{a(t)}{\phi'(t)} \right) dt. \end{aligned} \quad (21.5)$$

因此

$$\boxed{J(\lambda) = O(\lambda^{-1})} \quad (21.6)$$

只要  $\inf_{[a,b]} |\phi'| > 0$  且相关导数有界。

### 21.2.2 知识点四：反复分部积分与端点渐近级数

定义递推算子

$$\mathcal{T}f = \frac{d}{dt} \left( \frac{f}{\phi'} \right), \quad f_0 = a, \quad f_{n+1} = \mathcal{T}f_n. \quad (21.7)$$

反复分部积分得到

$$\begin{aligned} J(\lambda) &= \sum_{n=0}^{N-1} \frac{(-1)^n}{(i\lambda)^{n+1}} \left[ e^{i\lambda\phi(t)} \frac{f_n(t)}{\phi'(t)} \right]_a^b \\ &\quad + \frac{(-1)^N}{(i\lambda)^N} \int_a^b e^{i\lambda\phi(t)} f_N(t) dt. \end{aligned} \quad (21.8)$$

若  $a \in C_c^\infty(a, b)$  且  $\phi' \neq 0$  在支撑上成立, 全部端点项为零, 因而对任意  $N \geq 1$ :

$$\boxed{J(\lambda) = O(\lambda^{-N})}. \quad (21.9)$$

这称为超代数衰减。

#### 易错点与反例

非驻相积分一般不是“指数小”。

对有限正则性振幅, 分部积分次数受可用导数限制, 只能得到有限代数阶。

只有在额外解析性、可进行复路径移动且没有奇点时, 才可能得到指数衰减。

### 21.2.3 知识点五：显式误差界

由式 (21.5), 有

$$\begin{aligned} |J(\lambda)| &\leq \frac{1}{\lambda} \left[ \left| \frac{a(b)}{\phi'(b)} \right| + \left| \frac{a(a)}{\phi'(a)} \right| \right] \\ &\quad + \frac{1}{\lambda} \int_a^b \left| \frac{d}{dt} \left( \frac{a(t)}{\phi'(t)} \right) \right| dt. \end{aligned} \quad (21.10)$$

若  $|\phi'(t)| \geq \sigma > 0$ , 则

$$|J(\lambda)| \leq \frac{C}{\lambda} \left[ \frac{|a(a)| + |a(b)| + \|a'\|_{L^1}}{\sigma} + \frac{\|a\|_{L^1} \|\phi''\|_{L^\infty}}{\sigma^2} \right]. \quad (21.11)$$

该估计显示: 当  $\sigma = \inf |\phi'| \rightarrow 0$  时, 常数发散。这正是驻相点接近积分区间时普通分部积分失效的信号。

定理 21.1 (一维 van der Corput 型估计). 设  $\phi$  为实值函数。

1. 若  $|\phi'(t)| \geq \sigma > 0$  且  $\phi'$  单调, 则

$$\left| \int_a^b e^{i\lambda\phi(t)} dt \right| \leq \frac{C}{\lambda\sigma}. \quad (21.12)$$

2. 若  $|\phi''(t)| \geq \sigma > 0$ , 则

$$\left| \int_a^b e^{i\lambda\phi(t)} dt \right| \leq C(\lambda\sigma)^{-1/2}. \quad (21.13)$$

其中  $C$  为绝对常数。

注 21.2. 式 (21.12) 对应无驻相点; 式 (21.13) 允许一个非退化驻相点, 其  $\lambda^{-1/2}$  阶与驻相公式一致。

基础例题: 线性相位的端点展开

设  $a \in C^{N+1}[0, 1]$ , 求

$$J(\lambda) = \int_0^1 e^{i\lambda t} a(t) dt, \quad \lambda \rightarrow +\infty, \quad (21.14)$$

的前  $N$  项展开。

证明. 此时  $\phi(t) = t$ ,  $\phi'(t) = 1$ ,  $f_n = a^{(n)}$ 。由 式 (21.8):

$$J(\lambda) = \sum_{n=0}^{N-1} \frac{(-1)^n}{(i\lambda)^{n+1}} [e^{i\lambda t} a^{(n)}(t)]_0^1 + R_N(\lambda), \quad (21.15)$$

其中

$$R_N(\lambda) = \frac{(-1)^N}{(i\lambda)^N} \int_0^1 e^{i\lambda t} a^{(N)}(t) dt. \quad (21.16)$$

若再分部积分一次, 则  $R_N(\lambda) = O(\lambda^{-N-1})$ 。因此

$$J(\lambda) \sim \sum_{n=0}^{\infty} \frac{(-1)^n}{(i\lambda)^{n+1}} [e^{i\lambda t} a^{(n)}(t)]_0^1. \quad (21.17)$$

□

## 21.3 Watson 引理: Laplace 变换型端点积分

### 21.3.1 知识点六: 标准 Watson 引理

【重要性等级】 S 级。





定理 21.3 (Watson 引理). 设  $T > 0$ ,  $\alpha > -1$ , 并设

$$\varphi(t) = t^\alpha g(t), \quad (21.18)$$

其中:

- $g \in C^\infty[0, \delta]$  对某个  $0 < \delta < T$  成立;
- $\varphi \in L^1(0, T)$ ;
- 对所有  $\lambda > 0$ ,  $F(\lambda) = \int_0^T e^{-\lambda t} \varphi(t) dt$  有定义。

则

$$F(\lambda) \sim \sum_{n=0}^{\infty} \frac{g^{(n)}(0)}{n!} \frac{\Gamma(\alpha + n + 1)}{\lambda^{\alpha+n+1}}, \quad \lambda \rightarrow +\infty. \quad (21.19)$$

证明. 固定  $N \geq 0$ . 将积分分成

$$F(\lambda) = \int_0^\delta e^{-\lambda t} t^\alpha g(t) dt + \int_\delta^T e^{-\lambda t} \varphi(t) dt. \quad (21.20)$$

远端部分满足

$$\begin{aligned} \left| \int_\delta^T e^{-\lambda t} \varphi(t) dt \right| &\leq e^{-\lambda \delta} \int_\delta^T |\varphi(t)| dt \\ &= o(\lambda^{-M}) \quad \forall M > 0. \end{aligned} \quad (21.21)$$

在  $[0, \delta]$  上作 Taylor 展开:

$$g(t) = \sum_{n=0}^N \frac{g^{(n)}(0)}{n!} t^n + r_N(t), \quad (21.22)$$

其中  $|r_N(t)| \leq C_N t^{N+1}$ . 代入可得

$$\begin{aligned} \int_0^\delta e^{-\lambda t} t^\alpha g(t) dt &= \sum_{n=0}^N \frac{g^{(n)}(0)}{n!} \int_0^\delta e^{-\lambda t} t^{\alpha+n} dt \\ &\quad + \int_0^\delta e^{-\lambda t} t^\alpha r_N(t) dt. \end{aligned} \quad (21.23)$$

对于每个固定  $n$ ,

$$\begin{aligned} \int_0^\delta e^{-\lambda t} t^{\alpha+n} dt &= \int_0^\infty e^{-\lambda t} t^{\alpha+n} dt + O(e^{-\lambda \delta/2}) \\ &= \frac{\Gamma(\alpha + n + 1)}{\lambda^{\alpha+n+1}} + O(e^{-\lambda \delta/2}). \end{aligned} \quad (21.24)$$


余项满足

$$\begin{aligned} \left| \int_0^\delta e^{-\lambda t} t^\alpha r_N(t) dt \right| &\leq C_N \int_0^\infty e^{-\lambda t} t^{\alpha+N+1} dt \\ &= C_N \frac{\Gamma(\alpha + N + 2)}{\lambda^{\alpha+N+2}}. \end{aligned} \quad (21.25)$$

因此

$$F(\lambda) = \sum_{n=0}^N \frac{g^{(n)}(0)}{n!} \frac{\Gamma(\alpha + n + 1)}{\lambda^{\alpha+n+1}} + O(\lambda^{-\alpha-N-2}). \quad (21.26)$$

由于  $N$  任意, 定理得证.  $\square$



【证明要求】 Watson 引理属于 需要掌握完整证明框架的结果。至少应写出:

1. 近端与远端分裂;
2. 远端指数小;
3. 近端 Taylor 展开;
4. Gamma 积分;
5. Taylor 余项积分估计。

### 21.3.2 知识点七: 无穷区间版本

若  $T = \infty$ , 除局部光滑性外, 还需控制无穷远处。一个充分条件是存在  $\lambda_0 \geq 0$  使

$$\int_0^\infty e^{-\lambda_0 t} |\varphi(t)| dt < \infty. \quad (21.27)$$

则对任意固定  $\delta > 0$  和  $\lambda > \lambda_0$ :

$$\int_\delta^\infty e^{-\lambda t} |\varphi(t)| dt \leq e^{-(\lambda-\lambda_0)\delta} \int_\delta^\infty e^{-\lambda_0 t} |\varphi(t)| dt. \quad (21.28)$$

因此远端仍为指数小。

### 21.3.3 知识点八: 非线性端点相位的广义 Watson 形式

考虑

$$I(\lambda) = \int_0^b e^{-\lambda \psi(t)} t^{\beta-1} f(t) dt, \quad \beta > 0, \quad (21.29)$$

并假设

$$\psi(0) = 0, \quad (21.30)$$

$$\psi(t) > 0 \quad (t > 0), \quad (21.31)$$

$$\psi(t) = ct^\mu [1 + O(t)], \quad c > 0, \quad \mu > 0. \quad (21.32)$$

令  $s = \psi(t)$ 。在适当可逆性条件下,  $t = t(s) \sim \left(\frac{s}{c}\right)^{1/\mu}$ 。因此

$$t^{\beta-1} f(t) \frac{dt}{ds} \sim \sum_{n=0}^{\infty} d_n s^{(\beta+n)/\mu-1}. \quad (21.33)$$

Watson 引理给出

$$I(\lambda) \sim \sum_{n=0}^{\infty} d_n \Gamma\left(\frac{\beta+n}{\mu}\right) \lambda^{-(\beta+n)/\mu}. \quad (21.34)$$

若  $f(0) \neq 0$ , 首项为

$$I(\lambda) \sim \frac{f(0)}{\mu c^{\beta/\mu}} \Gamma\left(\frac{\beta}{\mu}\right) \lambda^{-\beta/\mu}. \quad (21.35)$$

#### 易错点与反例

广义 Watson 公式中的幂次不是固定的整数次  $\lambda^{-1}, \lambda^{-2}, \dots$ 。当  $\psi(t) \sim ct^\mu$  时, 主尺度为  $t = O(\lambda^{-1/\mu})$ , 所以展开步长通常是  $\lambda^{-1/\mu}$ 。

来源例题：对数振幅的 Watson 展开

求

$$F(\lambda) = \int_0^{\infty} e^{-\lambda t} \log(1+t^2) dt, \quad \lambda \rightarrow +\infty, \quad (21.36)$$

的渐近展开。

证明. 在  $t=0$  附近,

$$\log(1+t^2) = \sum_{m=1}^{\infty} \frac{(-1)^{m+1}}{m} t^{2m}, \quad |t| < 1. \quad (21.37)$$

Watson 引理允许逐项转化为 Gamma 积分:

$$\begin{aligned} F(\lambda) &\sim \sum_{m=1}^{\infty} \frac{(-1)^{m+1}}{m} \int_0^{\infty} e^{-\lambda t} t^{2m} dt \\ &= \sum_{m=1}^{\infty} \frac{(-1)^{m+1} (2m)!}{m \lambda^{2m+1}}. \end{aligned} \quad (21.38)$$

因此

$$F(\lambda) \sim \frac{2}{\lambda^3} - \frac{12}{\lambda^5} + \frac{240}{\lambda^7} - \frac{10080}{\lambda^9} + \cdots. \quad (21.39)$$

为说明余项, 固定  $N \geq 1$ . 在  $0 \leq t \leq \delta < 1$  上:

$$\log(1+t^2) = \sum_{m=1}^N \frac{(-1)^{m+1}}{m} t^{2m} + O(t^{2N+2}). \quad (21.40)$$

故近端余项为  $O(\lambda^{-2N-3})$ , 远端为指数小。由于系数含  $(2m)!$ , 该形式级数通常发散。它应在最小项附近截断, 而不是作无穷求和。□

### 21.3.4 知识点九: Gaussian 核与偶部展开

设  $\varphi \in C^\infty[-a, a]$ ,  $a > 0$ , 考虑

$$G(\lambda) = \int_{-a}^a e^{-\lambda t^2} \varphi(t) dt. \quad (21.41)$$

定义偶部  $\varphi_e(t) = \frac{1}{2} [\varphi(t) + \varphi(-t)]$ 。奇部积分为零, 因此  $G(\lambda) = 2 \int_0^a e^{-\lambda t^2} \varphi_e(t) dt$ 。令  $s = t^2$ , 得到

$$G(\lambda) = \int_0^{a^2} e^{-\lambda s} s^{-1/2} \varphi_e(\sqrt{s}) ds. \quad (21.42)$$

由 Watson 引理:

$$G(\lambda) \sim \sqrt{\frac{\pi}{\lambda}} \sum_{n=0}^{\infty} \frac{\varphi^{(2n)}(0)}{2^{2n} n!} \lambda^{-n}. \quad (21.43)$$

前几项为

$$G(\lambda) \sim \sqrt{\frac{\pi}{\lambda}} \left[ \varphi(0) + \frac{\varphi''(0)}{4\lambda} + \frac{\varphi^{(4)}(0)}{32\lambda^2} + \cdots \right]. \quad (21.44)$$

注 21.4. 这一公式是:

- Laplace 内部非退化最大值;
- 驻相非退化临界点;
- 最速下降鞍点;

局部展开的共同模型。



## 21.4 Laplace 方法 I: 端点主导

### 21.4.1 知识点十: 非驻定端点最大值

考虑

$$I(\lambda) = \int_a^b e^{\lambda R(t)} g(t) dt, \quad \lambda \rightarrow +\infty, \quad (21.45)$$

假设:

$$R(t) < R(a), \quad a < t \leq b, \quad (21.46)$$

$$R'(a) < 0, \quad (21.47)$$

$$R, g \in C^\infty[a, a + \delta], \quad (21.48)$$

$$g \in L^1(a, b). \quad (21.49)$$

令

$$s = R(a) - R(t). \quad (21.50)$$

因  $\frac{ds}{dt} = -R'(t) > 0$  在端点附近成立, 存在局部逆函数  $t = t(s)$ 。于是

$$I(\lambda) = e^{\lambda R(a)} \int_0^{R(a)-R(b)} e^{-\lambda s} \psi(s) ds, \quad (21.51)$$

$$\psi(s) = -\frac{g(t(s))}{R'(t(s))}. \quad (21.52)$$

由 Watson 引理:

$$I(\lambda) \sim e^{\lambda R(a)} \sum_{n=0}^{\infty} \frac{\psi^{(n)}(0)}{\lambda^{n+1}}. \quad (21.53)$$

首项为

$$I(\lambda) \sim -\frac{g(a)}{R'(a)} \frac{e^{\lambda R(a)}}{\lambda}. \quad (21.54)$$

第二项系数为

$$\psi'(0) = \frac{g'(a)R'(a) - g(a)R''(a)}{[R'(a)]^3}. \quad (21.55)$$

因此

$$I(\lambda) = e^{\lambda R(a)} \left[ -\frac{g(a)}{R'(a)} \lambda^{-1} + \frac{g'(a)R'(a) - g(a)R''(a)}{[R'(a)]^3} \lambda^{-2} + O(\lambda^{-3}) \right]. \quad (21.56)$$

#### 易错点与反例

若最大值位于右端点  $b$  且  $R'(b) > 0$ , 首项为

$$I(\lambda) \sim \frac{g(b)}{R'(b)} \frac{e^{\lambda R(b)}}{\lambda}. \quad (21.57)$$

左右端点公式符号不同, 不能机械照抄。

## 基础例题：非驻定端点 Laplace 展开

求

$$I(\lambda) = \int_0^1 e^{-\lambda(x+x^2)} dx, \quad \lambda \rightarrow +\infty, \quad (21.58)$$

的前三项渐近展开。

证明. 取  $R(x) = -x - x^2$ ,  $g(x) = 1$ 。在  $[0, 1]$  上,  $R'(x) = -1 - 2x < 0$ , 故唯一最大值位于  $x = 0$ 。

令  $s = x + x^2$ 。解出

$$x = \frac{\sqrt{1+4s}-1}{2}. \quad (21.59)$$

并有

$$\frac{dx}{ds} = \frac{1}{\sqrt{1+4s}}. \quad (21.60)$$

因此

$$I(\lambda) = \int_0^2 e^{-\lambda s} (1+4s)^{-1/2} ds. \quad (21.61)$$

在  $s = 0$  展开:

$$(1+4s)^{-1/2} = 1 - 2s + 6s^2 - 20s^3 + \cdots. \quad (21.62)$$

由 Watson 引理:

$$\begin{aligned} I(\lambda) &\sim \frac{1}{\lambda} - 2\frac{1!}{\lambda^2} + 6\frac{2!}{\lambda^3} - 20\frac{3!}{\lambda^4} + \cdots \\ &= \boxed{\frac{1}{\lambda} - \frac{2}{\lambda^2} + \frac{12}{\lambda^3} - \frac{120}{\lambda^4} + \cdots}. \end{aligned} \quad (21.63)$$

□

## 21.4.2 知识点十一：端点驻定最大值

若最大值仍位于  $a$ , 但

$$R'(a) = 0, \quad R''(a) < 0, \quad (21.64)$$

则局部展开为  $R(t) = R(a) + \frac{1}{2}R''(a)(t-a)^2 + O((t-a)^3)$ 。主尺度由  $\lambda(t-a)^2 = O(1)$  给出:


$$\boxed{t-a = O(\lambda^{-1/2})}. \quad (21.65)$$

首项为半 Gaussian 积分:

$$\boxed{I(\lambda) \sim g(a)e^{\lambda R(a)} \sqrt{\frac{\pi}{-2\lambda R''(a)}}}. \quad (21.66)$$

更一般地, 若  $R(a) - R(t) = c(t-a)^m [1 + O(t-a)]$ ,  $c > 0$ , 则

$$\boxed{I(\lambda) \sim \frac{g(a)}{m} c^{-1/m} \Gamma\left(\frac{1}{m}\right) e^{\lambda R(a)} \lambda^{-1/m}}. \quad (21.67)$$



## 21.5 Laplace 方法 II: 内部非退化最大值、多最大值与退化最大值

### 21.5.1 知识点十二: 内部唯一非退化最大值

设  $t_0 \in (a, b)$  是  $R$  的唯一全局最大值, 并满足

$$R'(t_0) = 0, \quad R''(t_0) < 0. \quad (21.68)$$

记

$$A = -R''(t_0) > 0. \quad (21.69)$$

则

$$I(\lambda) \sim e^{\lambda R(t_0)} g(t_0) \sqrt{\frac{2\pi}{\lambda A}}. \quad (21.70)$$

若  $R, g \in C^6$  且需要下一项, 则写

$$R_k = R^{(k)}(t_0), \quad (21.71)$$

$$g_k = g^{(k)}(t_0). \quad (21.72)$$

有

$$I(\lambda) = e^{\lambda R(t_0)} \sqrt{\frac{2\pi}{\lambda A}} \left[ g_0 + \frac{C_1}{\lambda} + O(\lambda^{-2}) \right], \quad (21.73)$$

$$C_1 = \frac{g_2}{2A} + \frac{g_1 R_3}{2A^2} + \frac{g_0 R_4}{8A^2} + \frac{5g_0 R_3^2}{24A^3}. \quad (21.74)$$

#### 内部 Laplace 公式的推导

令  $y = t - t_0$ . Taylor 展开:

$$R(t) = R(t_0) - \frac{A}{2} y^2 + \frac{R_3}{6} y^3 + \frac{R_4}{24} y^4 + \cdots, \quad (21.75)$$

$$g(t) = g_0 + g_1 y + \frac{g_2}{2} y^2 + \cdots. \quad (21.76)$$

取伸缩  $y = \frac{z}{\sqrt{\lambda A}}$ . 则主指数化为  $e^{-z^2/2}$ . 将其余指数和振幅按  $\lambda^{-1/2}$  展开, 奇函数项在对称 Gaussian 积分中消失. 利用

$$\int_{\mathbb{R}} e^{-z^2/2} dz = \sqrt{2\pi}, \quad (21.77)$$

$$\frac{\int z^2 e^{-z^2/2} dz}{\int e^{-z^2/2} dz} = 1, \quad (21.78)$$

$$\frac{\int z^4 e^{-z^2/2} dz}{\int e^{-z^2/2} dz} = 3, \quad (21.79)$$

$$\frac{\int z^6 e^{-z^2/2} dz}{\int e^{-z^2/2} dz} = 15, \quad (21.80)$$

即可得到式 (21.74)。

### 21.5.2 知识点十三: 多个最大值

若  $R$  在  $t_1, \dots, t_m$  处均达到同一最大值  $R_{\max}$ , 且每个点均为非退化内部最大值, 则

$$I(\lambda) \sim e^{\lambda R_{\max}} \sqrt{\frac{2\pi}{\lambda}} \sum_{j=1}^m \frac{g(t_j)}{\sqrt{-R''(t_j)}}. \quad (21.81)$$



若最大值高度不同, 例如  $R(t_1) > R(t_2)$ , 则  $\frac{t_2 \text{ 贡献}}{t_1 \text{ 贡献}} = O(e^{-\lambda[R(t_1)-R(t_2)]})$ 。低峰贡献指数小。

#### 易错点与反例

不能只比较曲率  $|R''(t_j)|$ 。决定主导性的第一层因素是最大值高度  $R(t_j)$ , 曲率只决定同一指数高度下的代数系数。

### 21.5.3 知识点十四：内部退化最大值

若

$$R'(t_0) = \cdots = R^{(m-1)}(t_0) = 0, \quad R^{(m)}(t_0) < 0, \quad (21.82)$$

则内部极大值要求  $m$  为偶数。令  $c = -\frac{R^{(m)}(t_0)}{m!} > 0$ 。主尺度为  $t - t_0 = O(\lambda^{-1/m})$ 。若  $g(t_0) \neq 0$ , 则

$$I(\lambda) \sim 2g(t_0)e^{\lambda R(t_0)} \frac{\Gamma(1/m)}{m(\lambda c)^{1/m}}. \quad (21.83)$$

因此:

- 非退化最大值  $m = 2$  给出  $\lambda^{-1/2}$ ;
- 四阶退化最大值  $m = 4$  给出  $\lambda^{-1/4}$ .

退化最大值附近的积分集中更宽, 标准 Gaussian 公式失效。

## 21.6 来源例题：Stirling 公式的 Laplace 推导

完整题目叙述：[AppAna-Shi-Stirling]

对

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt, \quad z \rightarrow +\infty, \quad (21.84)$$

使用 Laplace 方法推导 Stirling 公式, 并求第一个修正项。

证明. 令  $t = zs$ ,  $dt = z ds$ 。则

$$\begin{aligned} \Gamma(z) &= z^z \int_0^\infty s^{z-1} e^{-zs} ds \\ &= z^z \int_0^\infty e^{z(\log s - s)} \frac{1}{s} ds. \end{aligned} \quad (21.85)$$

取

$$R(s) = \log s - s, \quad g(s) = s^{-1}. \quad (21.86)$$

临界点满足  $R'(s) = \frac{1}{s} - 1 = 0$ , 故  $s_0 = 1$ 。又有


$$R(1) = -1, \quad (21.87)$$

$$R''(1) = -1, \quad (21.88)$$

$$R'''(1) = 2, \quad (21.89)$$

$$R^{(4)}(1) = -6, \quad (21.90)$$

$$g(1) = 1, \quad (21.91)$$





$$g'(1) = -1, \quad (21.92)$$

$$g''(1) = 2. \quad (21.93)$$

因此  $A = -R''(1) = 1$ 。

由式 (21.70):

$$\begin{aligned} \Gamma(z) &\sim z^z e^{-z} \sqrt{\frac{2\pi}{z}} \\ &= \sqrt{2\pi} z^{z-\frac{1}{2}} e^{-z}. \end{aligned} \quad (21.94)$$

为求下一项, 使用式 (21.74):

$$\begin{aligned} C_1 &= \frac{2}{2} + \frac{(-1)(2)}{2} + \frac{-6}{8} + \frac{5(2)^2}{24} \\ &= 1 - 1 - \frac{3}{4} + \frac{5}{6} \\ &= \frac{1}{12}. \end{aligned} \quad (21.95)$$

故

$$\Gamma(z) = \sqrt{2\pi} z^{z-\frac{1}{2}} e^{-z} \left[ 1 + \frac{1}{12z} + O(z^{-2}) \right], \quad z \rightarrow +\infty. \quad (21.96)$$

取对数可得

$$\log \Gamma(z) = \left( z - \frac{1}{2} \right) \log z - z + \frac{1}{2} \log(2\pi) + \frac{1}{12z} + O(z^{-2}). \quad (21.97)$$

□

## 21.7 来源综合例题：黏性 Burgers 方程的零黏性极限

完整题目叙述: [AppAna-Shi-Burgers]

考虑黏性 Burgers 方程

$$\begin{cases} \partial_t u_\varepsilon + u_\varepsilon \partial_x u_\varepsilon = \varepsilon \partial_{xx} u_\varepsilon, \\ u_\varepsilon(x, 0) = u_0(x), \end{cases} \quad \varepsilon > 0. \quad (21.98)$$

使用 Cole-Hopf 变换和 Laplace 方法说明: 当相关相位函数具有唯一非退化最大点时,  $\varepsilon \rightarrow 0^+$  的极限恢复无黏 Burgers 方程的特征线解。并说明多个最大点出现时的含义。

第一步: Cole-Hopf 变换. 令

$$u_\varepsilon = -2\varepsilon \frac{\partial_x \varphi_\varepsilon}{\varphi_\varepsilon} = -2\varepsilon \partial_x \log \varphi_\varepsilon. \quad (21.99)$$

直接代入可验证: 若


$$\partial_t \varphi_\varepsilon = \varepsilon \partial_{xx} \varphi_\varepsilon, \quad (21.100)$$

则式 (21.99) 给出的  $u_\varepsilon$  满足式 (21.98)。

初值应满足

$$\varphi_\varepsilon(x, 0) = \exp \left[ -\frac{1}{2\varepsilon} \int_0^x u_0(\eta) d\eta \right]. \quad (21.101)$$

□



第二步：热核表示. 热方程解为

$$\begin{aligned}\varphi_\varepsilon(x, t) &= \frac{1}{\sqrt{4\pi\varepsilon t}} \int_{-\infty}^{\infty} \exp\left[-\frac{(x-\xi)^2}{4\varepsilon t}\right] \varphi_\varepsilon(\xi, 0) d\xi \\ &= \frac{1}{\sqrt{4\pi\varepsilon t}} \int_{-\infty}^{\infty} \exp\left[\frac{R(\xi; x, t)}{2\varepsilon}\right] d\xi,\end{aligned}\quad (21.102)$$

其中

$$R(\xi; x, t) = -\int_0^\xi u_0(\eta) d\eta - \frac{(x-\xi)^2}{2t}.$$

□

第三步： $u_\varepsilon$  的积分比值. 由 式 (21.99), 对热核表示求  $x$  导数:

$$u_\varepsilon(x, t) = \frac{\int_{-\infty}^{\infty} \frac{x-\xi}{t} \exp\left[\frac{R(\xi; x, t)}{2\varepsilon}\right] d\xi}{\int_{-\infty}^{\infty} \exp\left[\frac{R(\xi; x, t)}{2\varepsilon}\right] d\xi}.$$

□

第四步：最大点方程. 最大点  $\xi_*$  满足

$$\begin{aligned}0 &= \partial_\xi R(\xi_*; x, t) \\ &= -u_0(\xi_*) + \frac{x-\xi_*}{t}.\end{aligned}\quad (21.105)$$

即

$$x = \xi_* + t u_0(\xi_*).$$

这正是无黏 Burgers 方程的特征线关系。

二阶导数为

$$\partial_{\xi\xi} R(\xi_*; x, t) = -u'_0(\xi_*) - \frac{1}{t}.$$

若

$$1 + t u'_0(\xi_*) > 0,$$

则  $R_{\xi\xi}(\xi_*) < 0$ , 最大点非退化。

□

第五步：Laplace 比值极限. 假设  $\xi_*$  是唯一非退化全局最大点. 对分母使用 Laplace 方法:

$$\begin{aligned}D_\varepsilon &:= \int e^{R/(2\varepsilon)} d\xi \\ &= e^{R(\xi_*)/(2\varepsilon)} \sqrt{\frac{4\pi\varepsilon}{-R_{\xi\xi}(\xi_*)}} [1 + O(\varepsilon)].\end{aligned}\quad (21.109)$$

对分子令  $g(\xi) = \frac{x-\xi}{t}$ , 则

$$\begin{aligned}N_\varepsilon &:= \int g(\xi) e^{R/(2\varepsilon)} d\xi \\ &= g(\xi_*) e^{R(\xi_*)/(2\varepsilon)} \sqrt{\frac{4\pi\varepsilon}{-R_{\xi\xi}(\xi_*)}} [1 + O(\varepsilon)].\end{aligned}\quad (21.110)$$



相除得到

$$\begin{aligned} u_\varepsilon(x, t) &= g(\xi_*) + O(\varepsilon) \\ &= \frac{x - \xi_*}{t} + O(\varepsilon) \\ &= u_0(\xi_*) + O(\varepsilon). \end{aligned} \quad (21.111)$$

因此

$$\lim_{\varepsilon \rightarrow 0^+} u_\varepsilon(x, t) = u_0(\xi_*), \quad x = \xi_* + t u_0(\xi_*). \quad (21.112)$$

□

注 21.5 (梯度爆破与最大点退化). 无黏特征映射为  $x(\xi, t) = \xi + t u_0(\xi)$ . 其 Jacobian 为  $\partial_\xi x = 1 + t u'_0(\xi)$ . 当

$$1 + t u'_0(\xi) = 0 \quad (21.113)$$

时:

- 特征映射失去局部可逆性;
- $R_{\xi\xi} = 0$ ;
- 非退化 Laplace 公式失效;
- 无黏经典解梯度趋于无穷;
- 需要退化鞍点或统一渐近分析。

注 21.6 (多个最大点与激波). 若  $R$  有两个等高非退化最大点  $\xi_1, \xi_2$ , 则分子、分母都包含两个同指数贡献:

$$D_\varepsilon \sim e^{R_{\max}/(2\varepsilon)} \sqrt{4\pi\varepsilon} \sum_{j=1}^2 \frac{1}{\sqrt{-R_{\xi\xi}(\xi_j)}}, \quad (21.114)$$

$$N_\varepsilon \sim e^{R_{\max}/(2\varepsilon)} \sqrt{4\pi\varepsilon} \sum_{j=1}^2 \frac{g(\xi_j)}{\sqrt{-R_{\xi\xi}(\xi_j)}}. \quad (21.115)$$

在等高切换曲线两侧, 不同最大点成为主导; 极限解发生跳跃, 这对应激波形成。

在激波位置本身, 有限  $\varepsilon$  解由多个局部贡献平滑连接。

#### 复杂度说明

数值求式 (21.104) 时若直接计算指数, 可能发生上溢或下溢。应先提出  $R_{\max} = \max_\xi R(\xi; x, t)$  并写成

$$e^{R/(2\varepsilon)} = e^{R_{\max}/(2\varepsilon)} e^{[R - R_{\max}]/(2\varepsilon)}. \quad (21.116)$$

公共大因子在比值中抵消。

若用 Newton 法求唯一最大点:

- 每次迭代计算  $u_0, u'_0$ , 成本  $O(1)$ ;
- 局部二次收敛;
- 多最大点时需多初值或全局搜索;
- 只求首项时, 总成本基本与  $\varepsilon$  无关。

## 21.8 驻相法：非退化驻相点的局部贡献

### 21.8.1 知识点十五：驻相点与非驻相区

考虑

$$J(\lambda) = \int_a^b e^{i\lambda\phi(t)} a(t) dt, \quad \lambda \rightarrow +\infty, \quad (21.117)$$

其中  $\phi: [a, b] \rightarrow \mathbb{R}$ 。驻相点定义为

$$\boxed{\phi'(t_0) = 0}. \quad (21.118)$$

直观上：

- 在  $\phi' \neq 0$  处，相位快速变化，相邻区间强烈抵消；
- 在  $\phi' = 0$  处，相位变化变慢，抵消减弱；
- 因而驻相点产生比非驻相区更大的代数贡献。

### 21.8.2 知识点十六：一维非退化驻相定理

定理 21.7 (一维驻相公式). 设  $t_0 \in (a, b)$  是  $\phi$  支撑区域内唯一驻相点，并满足

$$\phi'(t_0) = 0, \quad \phi''(t_0) \neq 0. \quad (21.119)$$

设  $a \in C_c^\infty(a, b)$ ,  $\phi \in C^\infty$ 。令  $\sigma = \operatorname{sgn} \phi''(t_0)$ 。则

$$\boxed{J(\lambda) = e^{i\lambda\phi(t_0) + i\sigma\pi/4} \sqrt{\frac{2\pi}{\lambda|\phi''(t_0)|}} [a(t_0) + O(\lambda^{-1})]}. \quad (21.120)$$

证明. 由一维 Morse 型变量变换，可在  $t_0$  附近取光滑变量  $s$ ，使

$$\phi(t) = \phi(t_0) + \frac{\sigma}{2}s^2, \quad s(t_0) = 0. \quad (21.121)$$

并有

$$\left| \frac{dt}{ds}(0) \right| = \frac{1}{\sqrt{|\phi''(t_0)|}}. \quad (21.122)$$

局部积分化为

$$e^{i\lambda\phi(t_0)} \int e^{i\lambda\sigma s^2/2} A(s) ds, \quad (21.123)$$

其中  $A(0) = \frac{a(t_0)}{\sqrt{|\phi''(t_0)|}}$ 。使用 Fresnel 积分

$$\int_{-\infty}^{\infty} e^{i\lambda\sigma s^2/2} ds = e^{i\sigma\pi/4} \sqrt{\frac{2\pi}{\lambda}}, \quad \lambda > 0, \quad (21.124)$$

得到首项。


远离  $t_0$  的部分满足  $|\phi'| \geq c > 0$ ，由反复分部积分为  $O(\lambda^{-N})$  对任意  $N$  成立。□

### 21.8.3 知识点十七：第一个修正项

记

$$\phi_k = \phi^{(k)}(t_0), \quad (21.125)$$

$$a_k = a^{(k)}(t_0). \quad (21.126)$$



则

$$J(\lambda) = e^{i\lambda\phi_0 + i\sigma\pi/4} \sqrt{\frac{2\pi}{\lambda|\phi_2|}} \left[ a_0 + \frac{i}{\lambda} C_1 + O(\lambda^{-2}) \right], \quad (21.127)$$

$$C_1 = \frac{a_2}{2\phi_2} - \frac{a_1\phi_3}{2\phi_2^2} - \frac{a_0\phi_4}{8\phi_2^2} + \frac{5a_0\phi_3^2}{24\phi_2^3}. \quad (21.128)$$

#### 易错点与反例

驻相公式中的相位因子是  $e^{i\pi \operatorname{sgn}(\phi'')/4}$ 。若漏掉该因子，即使振幅阶正确，最终正弦/余弦相位也会错  $\frac{\pi}{4}$ 。

#### 21.8.4 知识点十八：端点驻相点

若  $t_0 = a$  为积分端点， $\phi'(a) = 0$ ， $\phi''(a) \neq 0$ ，且只有右侧邻域，则首项是内部公式的一半：

$$J(\lambda) \sim \frac{1}{2} e^{i\lambda\phi(a) + i\sigma\pi/4} a(a) \sqrt{\frac{2\pi}{\lambda|\phi''(a)|}}. \quad (21.129)$$

若端点振幅或截断不对称，高阶系数会同时出现整数和半整数幂。

#### 21.8.5 知识点十九：多个驻相点

若有有限多个非退化驻相点  $t_1, \dots, t_m$  且相互分离，则

$$J(\lambda) \sim \sum_{j=1}^m e^{i\lambda\phi(t_j) + i\pi \operatorname{sgn}(\phi''(t_j))/4} a(t_j) \sqrt{\frac{2\pi}{\lambda|\phi''(t_j)|}}. \quad (21.130)$$

不同驻相点贡献的模均可为  $O(\lambda^{-1/2})$ ，但其相位不同，叠加后可能增强或抵消。

#### 易错点与反例

对纯振荡积分，不能像 Laplace 方法那样仅比较  $\phi(t_j)$  的大小。

因为  $|e^{i\lambda\phi(t_j)}| = 1$ 。所有非退化驻相点通常都处于同一代数阶，必须相加。

#### 21.8.6 知识点二十：退化驻相点

若

$$\phi'(t_0) = \dots = \phi^{(m-1)}(t_0) = 0, \quad \phi^{(m)}(t_0) \neq 0, \quad (21.131)$$

则主尺度为  $t - t_0 = O(\lambda^{-1/m})$ ，局部贡献通常为

$$O(\lambda^{-1/m}). \quad (21.132)$$

当  $m = 3$  时，标准模型为 Airy 积分；当多个控制参数同时使更高阶退化发生时，需要 Pearcey 等更高阶规范积分。



## 21.9 驻相例题: Bessel 函数的大参数渐近

综合例题:  $J_0(\lambda)$  的驻相展开

利用积分表示

$$J_0(\lambda) = \frac{1}{2\pi} \int_0^{2\pi} e^{i\lambda \cos t} dt, \quad (21.133)$$

求  $\lambda \rightarrow +\infty$  时的首项渐近公式。证明. 相位为  $\phi(t) = \cos t$ . 驻相点满足  $\phi'(t) = -\sin t = 0$ , 在一个周期内有  $t_1 = 0, t_2 = \pi$ .在  $t_1 = 0$ :

$$\phi(0) = 1, \quad (21.134)$$

$$\phi''(0) = -1. \quad (21.135)$$

其贡献为

$$e^{i\lambda - i\pi/4} \sqrt{\frac{2\pi}{\lambda}}. \quad (21.136)$$

在  $t_2 = \pi$ :

$$\phi(\pi) = -1, \quad (21.137)$$

$$\phi''(\pi) = 1. \quad (21.138)$$

其贡献为

$$e^{-i\lambda + i\pi/4} \sqrt{\frac{2\pi}{\lambda}}. \quad (21.139)$$

两者相加并乘以  $1/(2\pi)$ :

$$\begin{aligned} J_0(\lambda) &\sim \frac{1}{2\pi} \sqrt{\frac{2\pi}{\lambda}} [e^{i(\lambda - \pi/4)} + e^{-i(\lambda - \pi/4)}] \\ &= \sqrt{\frac{2}{\pi\lambda}} \cos\left(\lambda - \frac{\pi}{4}\right). \end{aligned} \quad (21.140)$$

更精确地,

$$J_0(\lambda) = \sqrt{\frac{2}{\pi\lambda}} \cos\left(\lambda - \frac{\pi}{4}\right) + O(\lambda^{-3/2}). \quad (21.141)$$

□

## 21.10 Airy 函数的振荡区: 驻相法与毛细波型渐近

来源练习: Airy 函数在负实轴的大参数渐近

利用

$$\text{Ai}(-x) = \frac{1}{\pi} \int_0^\infty \cos\left(\frac{t^3}{3} - xt\right) dt, \quad x > 0, \quad (21.142)$$

证明

$$\text{Ai}(-x) = \frac{x^{-1/4}}{\sqrt{\pi}} \sin\left(\frac{2}{3}x^{3/2} + \frac{\pi}{4}\right) + O(x^{-7/4}), \quad x \rightarrow +\infty. \quad (21.143)$$

证明. 令  $t = \sqrt{x}u$ ,  $\lambda = x^{3/2}$ . 则

$$\text{Ai}(-x) = \frac{\sqrt{x}}{\pi} \operatorname{Re} \int_0^\infty e^{i\lambda\phi(u)} du, \quad (21.144)$$

$$\phi(u) = \frac{u^3}{3} - u. \quad (21.145)$$

驻相点满足  $\phi'(u) = u^2 - 1 = 0$ . 在区间  $(0, \infty)$  内只有  $u_0 = 1$ . 并且

$$\phi(1) = -\frac{2}{3}, \quad (21.146)$$

$$\phi''(1) = 2. \quad (21.147)$$

驻相公式给出

$$\int_0^\infty e^{i\lambda\phi(u)} du = e^{-2i\lambda/3 + i\pi/4} \sqrt{\frac{\pi}{\lambda}} + O(\lambda^{-3/2}). \quad (21.148)$$

乘以  $\sqrt{x}/\pi$  并取实部:

$$\begin{aligned} \text{Ai}(-x) &= \frac{\sqrt{x}}{\pi} \sqrt{\frac{\pi}{x^{3/2}}} \cos\left(\frac{\pi}{4} - \frac{2}{3}x^{3/2}\right) + O(x^{1/2}x^{-9/4}) \\ &= \frac{x^{-1/4}}{\sqrt{\pi}} \cos\left(\frac{2}{3}x^{3/2} - \frac{\pi}{4}\right) + O(x^{-7/4}). \end{aligned} \quad (21.149)$$

利用恒等式  $\cos(\theta - \frac{\pi}{4}) = \sin(\theta + \frac{\pi}{4})$ , 得到目标公式.  $\square$

## 21.11 复相位积分与最速下降路径

### 21.11.1 知识点二十一: 复相位的实部与虚部

考虑

$$F(\lambda) = \int_C e^{\lambda h(z)} g(z) dz, \quad \lambda \rightarrow +\infty, \quad (21.150)$$

其中  $h(z) = R(x, y) + iI(x, y)$ ,  $z = x + iy$ , 且  $h, g$  在相关区域解析.

Cauchy-Riemann 方程为

$$R_x = I_y, \quad R_y = -I_x. \quad (21.151)$$

因此  $\nabla R \cdot \nabla I = 0$ . 即  $R$  与  $I$  的等值线正交.

若路径满足

$$I(x, y) = I_0, \quad (21.152)$$

则沿该路径指数不再振荡:

$$e^{\lambda h(z)} = e^{i\lambda I_0} e^{\lambda R(z)}. \quad (21.153)$$

若同时  $R$  从鞍点向两侧严格减小, 该路径称为最速下降路径.

### 21.11.2 知识点二十二: 最速下降流方程

将复平面向量写成复数. 对解析函数  $h$ , 有  $\overline{h'(z)} = R_x + iR_y$ . 因此可用梯度流

$$\boxed{\frac{dz}{ds} = -\overline{h'(z)}} \quad (21.154)$$





追踪下降路径。

沿该流：

$$\begin{aligned}\frac{d}{ds}h(z(s)) &= h'(z)\frac{dz}{ds} \\ &= -|h'(z)|^2.\end{aligned}\quad (21.155)$$

右端为实非正数，故

$$\frac{dR}{ds} = -|h'(z)|^2 \leq 0, \quad (21.156)$$

$$\frac{dI}{ds} = 0. \quad (21.157)$$

这同时证明了“相位恒定、实部最快下降”。

### 21.11.3 知识点二十三：鞍点与局部方向

鞍点  $z_0$  满足

$$h'(z_0) = 0. \quad (21.158)$$

若  $h''(z_0) \neq 0$ ，称为非退化鞍点。

写  $h''(z_0) = |h''(z_0)|e^{i\alpha}$ ，以及  $z - z_0 = re^{i\theta}$ 。则

$$h(z) - h(z_0) = \frac{1}{2}|h''(z_0)|r^2e^{i(\alpha+2\theta)} + O(r^3). \quad (21.159)$$

恒相位方向满足

$$\sin(\alpha + 2\theta) = 0. \quad (21.160)$$

共有四条局部方向：

$$\theta_k = -\frac{\alpha}{2} + \frac{k\pi}{2}, \quad k = 0, 1, 2, 3. \quad (21.161)$$

其中：

- 上升方向满足  $\cos(\alpha + 2\theta) = 1$ ;
- 下降方向满足  $\cos(\alpha + 2\theta) = -1$ .

故最速下降方向为

$$\theta = \frac{\pi - \alpha}{2} + k\pi, \quad k \in \mathbb{Z}. \quad (21.162)$$

### 21.11.4 知识点二十四：单鞍点首项

若原路径可在不跨越奇点的条件下变形为通过  $z_0$  的最速下降路径，令该路径在鞍点处的有向切线为  $z'(0) = e^{i\theta}$ ，且  $h''(z_0)e^{2i\theta} = -|h''(z_0)|$ 。局部参数化  $z = z_0 + e^{i\theta}s$  给出  $h(z) = h(z_0) - \frac{1}{2}|h''(z_0)|s^2 + O(s^3)$ 。因此鞍点贡献为

$$F_{z_0}(\lambda) \sim e^{\lambda h(z_0)} g(z_0) e^{i\theta} \sqrt{\frac{2\pi}{\lambda |h''(z_0)|}}. \quad (21.163)$$

也常写成

$$F_{z_0}(\lambda) \sim e^{\lambda h(z_0)} g(z_0) \sqrt{\frac{2\pi}{-\lambda h''(z_0)}}, \quad (21.164)$$

但平方根分支必须与路径方向一致。



## 易错点与反例

公式  $\sqrt{-h''(z_0)}$  不是一个无条件的正实数。

必须明确：

- 复平方根分支；
- 路径方向；
- 积分方向；
- 是否需要额外负号。

## 21.11.5 知识点二十五：全局路径选择

不是每个鞍点都对原积分有贡献。一个鞍点必须满足：

1. 原路径与经过该鞍点的下降路径属于同一允许变形类；
2. 变形过程不穿过不可忽略的极点、支割或本性奇点；
3. 变形后的无穷远端位于指数衰减扇区；
4. 路径方向与原积分方向一致。

若路径变形跨越极点  $z_p$ ，由留数定理：

$$\int_C e^{\lambda h(z)} g(z) dz = \int_{\tilde{C}} e^{\lambda h(z)} g(z) dz + 2\pi i \sigma \operatorname{Res}_{z=z_p} [e^{\lambda h(z)} g(z)], \quad (21.165)$$

其中  $\sigma = \pm 1$  由变形方向决定。

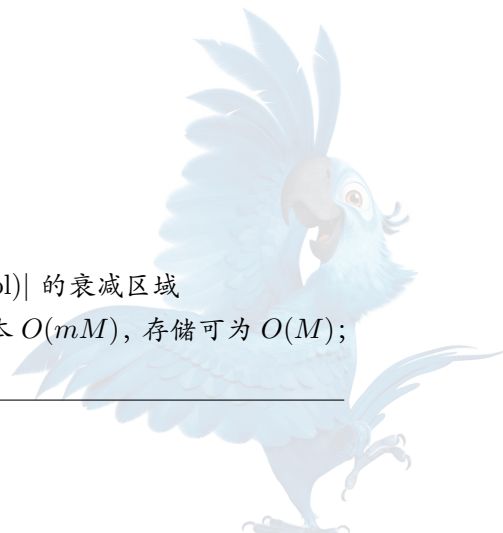
极点贡献可能比鞍点贡献更大，不能省略。

**Algorithm 78** 复积分最速下降路径与首项贡献计算

**Input:** 解析相位  $h(z)$ ；振幅  $g(z)$ ；原积分路径  $C$ ；大参数  $\lambda$ ；容差

**Output:** 主导鞍点、允许下降路径及渐近近似

- 1: **Initialization:** 求解  $h'(z) = 0$  得到候选鞍点；记录极点、支点、支割和无穷远衰减扇区
- 2: **for** 每个非退化候选鞍点  $z_j$  **do**
- 3:   计算  $h''(z_j) = |h''(z_j)|e^{i\alpha_j}$
- 4:   生成两条下降方向  $\theta = \frac{\pi - \alpha_j}{2} \pmod{\pi}$
- 5:   从鞍点附近沿  $z'(s) = -\overline{h'(z(s))}$  的正、反方向追踪路径
- 6:   检查路径是否连接原路径允许端点或衰减扇区
- 7:   检查变形是否跨越极点或支割
- 8: **end for**
- 9: 根据同伦关系选择实际贡献鞍点
- 10: 对每个贡献鞍点计算  $e^{\lambda h(z_j)} g(z_j) e^{i\theta_j} \sqrt{\frac{2\pi}{\lambda |h''(z_j)|}}$
- 11: 加上变形跨越极点的留数贡献
- 12: 按指数实部与代数阶比较并求和
- 13: **Stopping criterion:** 路径进入满足  $\lambda[\operatorname{Re} h(z_j) - \operatorname{Re} h(z)] \geq |\log(\text{tol})|$  的衰减区域
- 14: **Complexity:** 若有  $m$  个鞍点、每条路径离散为  $M$  步，路径追踪成本  $O(mM)$ ，存储可为  $O(M)$ ；局部首项系数成本  $O(m)$



## 21.12 来源例题: Airy 函数在正实轴的最速下降渐近

完整题目叙述: [AppAna-Shi-Airy]

使用复积分表示

$$\text{Ai}(x) = \frac{1}{2\pi i} \int_C \exp\left(\frac{z^3}{3} - xz\right) dz, \quad x > 0, \quad (21.166)$$

其中  $C$  由无穷远衰减扇区  $\arg z = -\frac{\pi}{3}$  连接到  $\arg z = \frac{\pi}{3}$ 。证明

$$\text{Ai}(x) = \frac{1}{2\sqrt{\pi}} x^{-1/4} \exp\left(-\frac{2}{3}x^{3/2}\right) [1 + O(x^{-3/2})]. \quad (21.167)$$

证明. 令  $z = \sqrt{x}u$ ,  $\lambda = x^{3/2}$ 。则

$$\text{Ai}(x) = \frac{\sqrt{x}}{2\pi i} \int_{C_u} e^{\lambda h(u)} du, \quad (21.168)$$

$$h(u) = \frac{u^3}{3} - u. \quad (21.169)$$

鞍点满足  $h'(u) = u^2 - 1 = 0$ , 故  $u_{\pm} = \pm 1$ 。相位值为

$$h(1) = -\frac{2}{3}, \quad (21.170)$$

$$h(-1) = \frac{2}{3}. \quad (21.171)$$

虽然  $u = -1$  的实部更大, 但原 Airy 路径不能在保持无穷远衰减且不改变积分定义的条件下选取其增长贡献。与原路径同伦的相关下降路径通过  $u = 1$ 。

在  $u = 1$ :  $h''(1) = 2$ 。由于二阶系数为正实数, 下降方向满足  $\theta = \frac{\pi}{2} \pmod{\pi}$ , 即局部路径沿虚方向。

令  $u = 1 + \frac{iy}{\sqrt{\lambda}}$ 。则

$$h(u) = -\frac{2}{3} - \frac{y^2}{\lambda} + O(\lambda^{-3/2}|y|^3), \quad (21.172)$$

$$du = \frac{i}{\sqrt{\lambda}} dy. \quad (21.173)$$

因此

$$\begin{aligned} \text{Ai}(x) &= \frac{\sqrt{x}}{2\pi i} e^{-2\lambda/3} \frac{i}{\sqrt{\lambda}} \int_{-\infty}^{\infty} e^{-y^2} [1 + O(\lambda^{-1})] dy \\ &= \frac{\sqrt{x}}{2\pi} e^{-2\lambda/3} \lambda^{-1/2} \sqrt{\pi} [1 + O(\lambda^{-1})]. \end{aligned} \quad (21.174)$$

由  $\lambda = x^{3/2}$  得到  $\sqrt{x}\lambda^{-1/2} = x^{1/2}x^{-3/4} = x^{-1/4}$ 。故  $\text{Ai}(x) = \frac{1}{2\sqrt{\pi}} x^{-1/4} e^{-2x^{3/2}/3} [1 + O(x^{-3/2})]$ 。□

## 易错点与反例

选择鞍点不能只比较  $\text{Re } h(u_{\pm})$ 。

在本题中,  $h(-1) = \frac{2}{3}$  看似给出指数增长, 但该鞍点不属于 Airy 积分原路径的有效下降同伦类。若无视路径拓扑, 会得到与  $\text{Ai}(x) \rightarrow 0$  矛盾的错误结果。

## 21.13 振荡积分中的端点奇异性: 对数振幅与复路径变形

来源例题:  $\int_0^1 e^{ixt} \log t \, dt$

设

$$I(x) = \int_0^1 e^{ixt} \log t \, dt, \quad x \rightarrow +\infty. \quad (21.175)$$

采用主值支  $-\pi < \arg z < \pi$  的复对数。求其渐近展开。

第一步: 第一象限矩形路径. 取矩形路径  $0 \rightarrow 1 \rightarrow 1 + iR \rightarrow iR \rightarrow 0$ 。函数  $e^{ixz} \log z$  在第一象限内部解析。当  $R \rightarrow +\infty$  时, 顶部积分因  $|e^{ix(u+iR)}| = e^{-xR}$  而趋于零。

记左竖边向上的积分为  $L(x) = \int_0^{i\infty} e^{ixz} \log z \, dz$ , 右竖边向上的积分为  $R_1(x) = \int_1^{1+i\infty} e^{ixz} \log z \, dz$ 。由闭路积分为零:

$$I(x) = L(x) - R_1(x). \quad (21.176)$$

□

第二步: 左端对数奇异贡献. 在左竖边令  $z = is$ ,  $s \geq 0$ 。则  $\log(is) = \log s + \frac{i\pi}{2}$ 。所以

$$L(x) = i \int_0^\infty e^{-xs} \left( \log s + \frac{i\pi}{2} \right) ds. \quad (21.177)$$

令  $u = xs$ 。得到

$$L(x) = \frac{i}{x} \int_0^\infty e^{-u} \left( \log u - \log x + \frac{i\pi}{2} \right) du. \quad (21.178)$$

使用

$$\int_0^\infty e^{-u} du = 1, \quad (21.179)$$

$$\int_0^\infty e^{-u} \log u \, du = \Gamma'(1) = -\gamma, \quad (21.180)$$

其中  $\gamma$  为 Euler 常数, 得到

$$L(x) = -\frac{\pi}{2x} - \frac{i(\log x + \gamma)}{x}. \quad (21.181)$$

□

第三步: 右端光滑贡献. 在右竖边令  $z = 1 + is$ ,  $s \geq 0$ 。则

$$R_1(x) = ie^{ix} \int_0^\infty e^{-xs} \log(1 + is) ds. \quad (21.182)$$


在  $s = 0$  附近,

$$\log(1 + is) = \sum_{n=1}^\infty \frac{(-1)^{n+1}}{n} (is)^n. \quad (21.183)$$

Watson 引理给出

$$\begin{aligned} R_1(x) &\sim ie^{ix} \sum_{n=1}^\infty \frac{(-1)^{n+1} i^n}{n} \frac{n!}{x^{n+1}} \\ &= ie^{ix} \sum_{n=1}^\infty (-1)^{n+1} i^n \frac{(n-1)!}{x^{n+1}}. \end{aligned} \quad (21.184)$$

□



第四步：合并. 由  $I = L - R_1$ , 得到

$$I(x) \sim -\frac{\pi/2 + i(\log x + \gamma)}{x} + ie^{ix} \sum_{n=1}^{\infty} \frac{(-i)^n (n-1)!}{x^{n+1}}. \quad (21.185)$$

前几项为

$$I(x) \sim -\frac{\pi/2 + i(\log x + \gamma)}{x} + e^{ix} \left[ \frac{1}{x^2} - \frac{i}{x^3} - \frac{2}{x^4} + \frac{6i}{x^5} + \cdots \right]. \quad (21.186)$$

□

注 21.8. 该题包含两个不同类型的端点贡献:

- $t = 0$ : 对数奇异产生  $\frac{\log x}{x}$  项;
- $t = 1$ : 振幅光滑但  $\log 1 = 0$ , 因而首个非零端点项从  $x^{-2}e^{ix}$  开始。

单纯使用光滑振幅分部积分会在  $t = 0$  失效。

## 21.14 多维 Laplace 方法与多维驻相公式

### 21.14.1 知识点二十六：多维 Laplace 首项

考虑

$$I_d(\lambda) = \int_{\Omega \subset \mathbb{R}^d} e^{\lambda R(\mathbf{x})} g(\mathbf{x}) d\mathbf{x}. \quad (21.187)$$

假设  $\mathbf{x}_0 \in \Omega^\circ$  为唯一非退化全局最大点:

$$\nabla R(\mathbf{x}_0) = \mathbf{0}, \quad (21.188)$$

$$H_R(\mathbf{x}_0) \prec 0. \quad (21.189)$$

令  $A = -H_R(\mathbf{x}_0) \succ 0$ 。则

$$I_d(\lambda) \sim e^{\lambda R(\mathbf{x}_0)} g(\mathbf{x}_0) \left( \frac{2\pi}{\lambda} \right)^{d/2} \frac{1}{\sqrt{\det A}}. \quad (21.190)$$

该公式来自局部二次型  $R(\mathbf{x}) = R(\mathbf{x}_0) - \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)^\top A(\mathbf{x} - \mathbf{x}_0) + \cdots$  以及多维 Gaussian 积分

$$\int_{\mathbb{R}^d} e^{-\frac{1}{2}\mathbf{y}^\top A\mathbf{y}} d\mathbf{y} = \frac{(2\pi)^{d/2}}{\sqrt{\det A}}. \quad (21.191)$$

### 21.14.2 知识点二十七：多维驻相首项

考虑


$$J_d(\lambda) = \int_{\mathbb{R}^d} e^{i\lambda\phi(\mathbf{x})} a(\mathbf{x}) d\mathbf{x}, \quad (21.192)$$

且  $\mathbf{x}_0$  为唯一非退化驻相点:  $\nabla\phi(\mathbf{x}_0) = \mathbf{0}$ ,  $\det H_\phi(\mathbf{x}_0) \neq 0$ 。设 Hessian 的正、负特征值个数分别为  $n_+$ ,  $n_-$ , 定义签名

$$\text{sgn } H_\phi = n_+ - n_-. \quad (21.193)$$

则

$$J_d(\lambda) \sim e^{i\lambda\phi(\mathbf{x}_0)} e^{i\pi \text{sgn } H_\phi / 4} a(\mathbf{x}_0) \left( \frac{2\pi}{\lambda} \right)^{d/2} \frac{1}{\sqrt{|\det H_\phi(\mathbf{x}_0)|}}. \quad (21.194)$$



**易错点与反例**

多维驻相相位因子由 Hessian 的签名决定，不是仅由  $\det H$  的正负决定。

例如二维 Hessian 的两种情况：

- 两个正特征值： $\operatorname{sgn} H = 2$ ;
- 一正一负： $\operatorname{sgn} H = 0$ .

虽然两者的  $|\det H|$  都可相同，相位因子不同。

**21.15 统一渐近失效：临界点合并、端点接近与 Stokes 现象****21.15.1 知识点二十八：参数依赖临界点**

设积分还依赖参数  $\mu$ ：

$$I(\lambda, \mu) = \int e^{\lambda \Phi(t; \mu)} A(t; \mu) dt. \quad (21.195)$$

普通 Laplace 或驻相公式通常要求存在与  $\mu$  无关的常数：

$$|\Phi''(t_*(\mu); \mu)| \geq c_0 > 0, \quad (21.196)$$

$$\operatorname{dist}(t_*(\mu), \partial[a, b]) \geq c_1 > 0, \quad (21.197)$$

$$|t_j(\mu) - t_k(\mu)| \geq c_2 > 0. \quad (21.198)$$

若其中任一常数趋于零，普通展开的系数会发散，说明展开不一致。

**21.15.2 知识点二十九：驻相点接近端点**

若  $t_*(\mu) - a = O(\lambda^{-1/2})$ ，驻相点与端点位于同一局部尺度内。此时不能简单地把：

端点贡献 + 内部驻相贡献 相加，因为两者局部邻域重叠。

标准统一模型通常是 Fresnel 积分或误差函数：

$$\int_{\eta}^{\infty} e^{is^2} ds, \quad \eta = O(1). \quad (21.199)$$

**21.15.3 知识点三十：两个驻相点合并**

若两个简单驻相点在  $\mu = \mu_c$  合并，合并点满足

$$\Phi_t = \Phi_{tt} = 0, \quad \Phi_{ttt} \neq 0. \quad (21.200)$$

二次 Gaussian 模型失效，应使用三次 Airy 规范形式：

$$\int \exp \left[ \lambda \left( \frac{s^3}{3} - \zeta s \right) \right] ds. \quad (21.201)$$

其统一参数通常为  $\lambda^{2/3} \zeta$ 。

**21.15.4 知识点三十一：Stokes 现象**

在复参数平面中，不同鞍点贡献为  $C_j(\lambda) e^{\lambda h(z_j)}$ 。当参数方向变化时：



- 两个鞍点实部相等的曲线称为反 Stokes 型分界；
- 某个次主导指数贡献的开关变化与 Stokes 线相关；
- 原函数通常解析，但不同扇区的渐近表达式不同。

Airy 函数是标准例子：

- 正实轴上主要为单个指数衰减贡献；
- 负实轴上表现为两个共轭鞍点叠加形成振荡；
- 在复平面不同扇区，鞍点组合发生改变。

#### 易错点与反例

Stokes 现象不是原函数突然不连续。

变化的是“哪一组指数小贡献应保留”的渐近表示，而不是原解析函数本身。

## 21.16 渐近积分的数值条件、实现稳定性与复杂度

### 21.16.1 知识点三十二：振荡抵消与相对条件数

将振幅扰动  $a \mapsto a + \delta a$  代入  $J(\lambda) = \int_a^b e^{i\lambda\phi(t)} a(t) dt$ 。一阶扰动满足

$$\delta J = \int_a^b e^{i\lambda\phi(t)} \delta a(t) dt. \quad (21.202)$$

若  $|\delta a(t)| \leq \eta |a(t)|$ ，则

$$|\delta J| \leq \eta \int_a^b |a(t)| dt. \quad (21.203)$$

因此一个自然相对条件数为

$$\kappa_{\text{rel}} = \frac{\int_a^b |a(t)| dt}{|J(\lambda)|}. \quad (21.204)$$

若  $J(\lambda) = O(\lambda^{-p})$ ，而  $\int |a| = O(1)$ ，则  $\kappa_{\text{rel}} = O(\lambda^p)$ 。振荡抵消越强，相对条件越差。

### 21.16.2 知识点三十三：直接求积的分辨率成本

若相位局部波数为  $k(t) = \lambda|\phi'(t)|$ ，为解析振荡通常需网格步长满足  $hk(t) \lesssim 1$ 。若  $|\phi'| = O(1)$ ，直接等距求积点数通常至少为

$$N_{\text{direct}} = O(\lambda). \quad (21.205)$$

对于多维积分，逐维分辨率均为  $O(\lambda)$  时，张量积成本可达  $O(\lambda^d)$ 。

驻相法或最速下降法只计算有限个局部贡献，首项成本原则上不随  $\lambda$  增长。这说明渐近方法不仅给出理论公式，也可显著降低高频数值成本。

### 21.16.3 知识点三十四：Laplace 积分的上溢与下溢

对  $I(\lambda) = \int e^{\lambda R(t)} g(t) dt$ ，应提出最大指数：

$$I(\lambda) = e^{\lambda R_{\max}} \int e^{\lambda[R(t) - R_{\max}]} g(t) dt. \quad (21.206)$$





括号中指数不大于 0，避免上溢。

若最终只需  $\log I$ ，应计算

$$\log I = \lambda R_{\max} + \log \left[ \int e^{\lambda(R-R_{\max})} g \right]. \quad (21.207)$$

多个峰值相加时，应使用 log-sum-exp 思想。

#### 21.16.4 知识点三十五：渐近级数的停止准则

设渐近展开为  $I(\lambda) \sim \sum_{n=0}^{\infty} T_n(\lambda)$ 。实际计算时可使用：

1. 当  $|T_{n+1}| > |T_n|$  时停止；
2. 当  $|T_n| \leq \text{tol}_{\text{abs}}$  时停止；
3. 当  $|T_n| \leq \text{tol}_{\text{rel}} |\sum_{k=0}^n T_k|$  时停止；
4. 当  $|T_n| \lesssim u_{\text{mach}} |\sum_{k=0}^n T_k|$  时不再增加项。

| 方法         | 前 $N$ 项所需局部数据        | 典型运算复杂度           | 存储复杂度                   |
|------------|----------------------|-------------------|-------------------------|
| Watson 引理  | 振幅前 $N$ 阶导数          | $O(N)$ 至 $O(N^2)$ | $O(N)$                  |
| Laplace 方法 | 相位、振幅约前 $2N$ 阶导数     | 朴素 $O(N^2)$       | $O(N)$ 至 $O(N^2)$       |
| 驻相法        | 相位、振幅高阶导数和 Fresnel 矩 | 朴素 $O(N^2)$       | $O(N)$                  |
| 最速下降       | 鞍点、局部方向、路径拓扑         | 路径追踪 $O(M)$       | $O(M)$ 或流式 $O(1)$       |
| 直接高频求积     | 全区间密集采样              | 常见 $O(\lambda)$   | $O(\lambda)$ 或流式 $O(1)$ |

## 21.17 易错点、反例与失败情形

| 错误说法或错误做法                 | 正确处理                                                         |
|---------------------------|--------------------------------------------------------------|
| 指数积分只需找导数为零的点。            | Laplace 法要找全局最大值；端点即使导数非零也可能主导。                              |
| 最大值点越尖，贡献越大。              | 同一峰值高度下，贡献与 $(-R'')^{-1/2}$ 成正比；峰越窄，积分贡献反而越小。                |
| Laplace 法只比较二阶导数。         | 首先比较指数高度 $R(t_j)$ ，其次才比较曲率和振幅。                               |
| 两个最大点中只保留曲率较小者。           | 若峰值高度相同，两者处于同一指数阶，必须相加。                                      |
| 端点最大值总是 $\lambda^{-1}$ 阶。 | 若 $R'(a) = 0$ ，阶变为 $\lambda^{-1/2}$ 或更一般的 $\lambda^{-1/m}$ 。 |
| Watson 引理要求振幅在整个区间解析。     | 只需主导端点附近具有足够展开，远区可由可积性控制。                                    |
| Watson 级数一定收敛。            | 系数常含阶乘，级数可能发散，只是 Poincaré 渐近展开。                              |
| 纯振荡积分的最大相位值主导。            | $ e^{i\lambda\phi}  = 1$ ，应找驻相点而不是相位最大值。                     |

| 错误说法或错误做法                              | 正确处理                                                  |
|----------------------------------------|-------------------------------------------------------|
| 没有驻相点就没有贡献。                            | 仍有端点贡献，通常为 $O(\lambda^{-1})$ 。                        |
| 驻相点贡献总是 $\lambda^{-1/2}$ 。             | 退化驻相点的阶为 $\lambda^{-1/m}$ 。                           |
| 多个驻相点只取一个。                             | 多个非退化驻相点一般都为 $\lambda^{-1/2}$ 阶，必须叠加。                 |
| 驻相公式不需要 $\pi/4$ 相位。                    | Fresnel 积分产生 $e^{i\pi \operatorname{sgn} \phi''/4}$ 。 |
| 驻相点靠近端点时仍可独立相加。                        | 若距离为 $O(\lambda^{-1/2})$ ，需统一 Fresnel 型展开。            |
| 两个鞍点接近时分别用 Gaussian 公式。                | 合并尺度上二阶曲率趋零，应使用 Airy 型统一展开。                           |
| 所有满足 $h'(z) = 0$ 的点都有贡献。               | 只有可由原路径合法变形到达的鞍点才贡献。                                  |
| 复路径可任意移动。                              | 不得无说明地跨越极点、支割或增长扇区。                                   |
| 跨越极点对渐近首项无影响。                          | 必须加入留数；留数甚至可能成为主导项。                                   |
| 最速下降路径是 $\operatorname{Re} h$ 的任意下降曲线。 | 还必须满足 $\operatorname{Im} h$ 为常数。                      |
| 直接使用 $\sqrt{-h''(z_0)}$ 无需选支。          | 复平方根分支必须与局部路径方向和积分方向一致。                               |
| 大参数越大，直接求积越容易。                         | 振荡更密、集中层更窄，相对条件数和分辨率成本可能增大。                           |
| 渐近首项绝对误差小就代表相对误差小。                     | 多个贡献相消时总积分很小，相对误差可能很大。                                |

反例 21.9 (局部极大但非主导). 设  $R(t) = -(t^2 - 1)^2 + \eta t$ ,  $0 < \eta \ll 1$ . 在  $\pm 1$  附近均有局部极大点, 但两点高度相差  $O(\eta)$ . 当  $\lambda\eta \gg 1$  时, 较低峰贡献指数小; 不能因两点曲率接近就同等保留。

反例 21.10 (驻相点退化). 考虑  $J(\lambda) = \int_{-1}^1 e^{i\lambda t^4} dt$ . 驻相点  $t = 0$  满足  $\phi'(0) = \phi''(0) = \phi'''(0) = 0$ ,  $\phi^{(4)}(0) \neq 0$ . 主尺度为  $t = O(\lambda^{-1/4})$ , 故  $J(\lambda) = O(\lambda^{-1/4})$ , 而不是普通驻相公式的  $O(\lambda^{-1/2})$ 。

反例 21.11 (相对条件数因抵消而变大). 设  $J(\lambda) = \int_{-1}^1 e^{i\lambda t} dt = \frac{2\sin \lambda}{\lambda}$ . 当  $\lambda \approx k\pi$  时,  $J(\lambda)$  接近零, 但  $\int_{-1}^1 |e^{i\lambda t}| dt = 2$ . 因此相对条件数  $\kappa_{\text{rel}} \approx \frac{\lambda}{|\sin \lambda|}$  可任意大。

## 21.18 资格考试证明与分析套路

**Watson 引理：识别信号—构造步骤—关键估计—结论—失败原因**

识别信号：  $\int_0^T e^{-\lambda t} t^\alpha g(t) dt$ ,  $\lambda \rightarrow \infty$ 。

构造步骤：

1. 在  $t = 0$  附近展开  $g$ ;
2. 将积分分为  $[0, \delta]$  和  $[\delta, T]$ ;
3. 近端逐项使用 Gamma 积分;
4. 远端证明指数小;
5. 对 Taylor 余项积分估计。

关键估计:  $\int_0^\infty e^{-\lambda t} t^\beta dt = \Gamma(\beta+1) \lambda^{-\beta-1}$ 。

结论: 系数由端点局部导数决定。

失败原因:  $\alpha \leq -1$  导致不可积; 远端增长失控; 振幅含对数或非整数幂却误用普通 Taylor 展开。

#### Laplace 方法: 识别信号—构造步骤—关键估计—结论—失败原因

识别信号:  $\int e^{\lambda R(t)} g(t) dt$ ,  $R$  实值。

构造步骤:

1. 求全部全局最大点;
2. 检查最大点位于端点还是内部;
3. 检查首个非零导数阶数;
4. 选择尺度  $\lambda^{-1}$ ,  $\lambda^{-1/2}$ ,  $\lambda^{-1/m}$ ;
5. 化为 Watson 或 Gaussian 积分;
6. 比较多峰指数高度;
7. 写余项和有效参数范围。

关键估计: 远离最大点有  $R \leq R_{\max} - \eta$ 。

结论:  $e^{\lambda R_{\max}} \times$  代数因子。

失败原因: 局部最大点不是全局最大点; 曲率趋零; 多个峰合并; 振幅在最大点为零。

#### 驻相法: 识别信号—构造步骤—关键估计—结论—失败原因

识别信号:  $\int e^{i\lambda\phi(t)} a(t) dt$ ,  $\phi$  实值。

构造步骤:

1. 求  $\phi'(t) = 0$ ;
2. 用截断函数分离每个驻相点;
3. 非驻相区反复分部积分;
4. 驻相点附近化为  $\pm s^2/2$ ;
5. 使用 Fresnel 积分;
6. 加上所有驻相点和端点贡献。

关键因子:  $e^{i\pi \operatorname{sgn}(\phi'')/4}$ 。

结论: 非退化驻相点贡献为  $O(\lambda^{-1/2})$ 。

失败原因: 驻相点退化; 驻相点接近端点; 多个驻相点合并; 振幅不光滑。

#### 最速下降法: 识别信号—构造步骤—关键估计—结论—失败原因

识别信号: 复积分中指数含大参数, 原路径高度振荡, 但被积函数可解析延拓。

构造步骤:

1. 求全部鞍点  $h'(z) = 0$ ;

2. 求无穷远衰减扇区；
3. 计算下降方向；
4. 判断原路径与下降路径的同伦关系；
5. 追踪恒相位路径；
6. 记录跨越极点的留数；
7. 在有效鞍点处作 Gaussian 局部化；
8. 选定平方根分支并按方向求和。

关键估计：沿下降流  $\frac{d}{ds} \operatorname{Re} h = -|h'|^2$ ,  $\frac{d}{ds} \operatorname{Im} h = 0$ 。

结论：积分由可达鞍点、端点和奇点贡献组成。

失败原因：选取不可达鞍点；跨越交割；忽略留数；Stokes 线附近非一致；复平方根分支错误。



## 第二十二章 正则摄动、隐式问题、特征值摄动、频率修正与 Poincaré–Lindstedt 方法

### 22.1 正则摄动的定义、判别与逐阶求解框架

#### 22.1.1 知识点一：什么是正则摄动

【重要性等级】 **S 级**。正则摄动的核心不是“小参数出现”，而是当参数趋于极限时：

1. 问题的阶数不降低；
2. 所需初值或边界条件数目不减少；
3. 线性化算子在适当归一化后可逆，或仅具有可由参数修正消除的有限维核；
4. 解对参数具有光滑或解析依赖；
5. 展开系数在目标区域内保持有界。

设  $X, Y$  为 Banach 空间，考虑算子方程

$$\mathcal{F}(u, \varepsilon) = 0, \quad \mathcal{F} : X \times \mathbb{R} \rightarrow Y, \quad \varepsilon \rightarrow 0. \quad (22.1)$$

设

$$\mathcal{F}(u_0, 0) = 0. \quad (22.2)$$

若 Fréchet 导数

$$L := D_u \mathcal{F}(u_0, 0) : X \rightarrow Y \quad (22.3)$$

是有界可逆算子，则由隐函数定理，在  $\varepsilon = 0$  附近存在唯一分支  $u = u(\varepsilon)$  满足  $\mathcal{F}(u(\varepsilon), \varepsilon) = 0$ 。若  $\mathcal{F}$  解析，则  $u(\varepsilon)$  解析。

这给出正则幂级数展开的理论基础：

$$u(\varepsilon) \sim u_0 + \varepsilon u_1 + \varepsilon^2 u_2 + \cdots. \quad (22.4)$$

#### 易错点与反例

“小参数不乘最高阶导数”通常提示正则摄动，但不是充分条件。

即使微分方程阶数不变，若：

- 线性化算子不可逆；
- 出现共振；

- 特征值重合;
- 解分支在  $\varepsilon = 0$  处分叉;
- 目标时间区间随  $\varepsilon^{-1}$  增长;

普通幂级数仍可能失效或只在有限区间有效。

### 22.1.2 知识点二：逐阶方程

设

$$u^{[N]}(\varepsilon) = \sum_{n=0}^N \varepsilon^n u_n. \quad (22.5)$$

将其代入  $\mathcal{F}(u, \varepsilon) = 0$  并按  $\varepsilon$  幂次比较。

前两阶的一般形式为

$$O(1): \quad \mathcal{F}(u_0, 0) = 0, \quad (22.6)$$

$$O(\varepsilon): \quad Lu_1 = -D_\varepsilon \mathcal{F}(u_0, 0), \quad (22.7)$$

$$O(\varepsilon^2): \quad Lu_2 = -\frac{1}{2} D_{uu}^2 \mathcal{F}(u_0, 0)[u_1, u_1] \\ - D_{u\varepsilon}^2 \mathcal{F}(u_0, 0)[u_1] - \frac{1}{2} D_{\varepsilon\varepsilon}^2 \mathcal{F}(u_0, 0). \quad (22.8)$$

关键结构是：

$$Lu_n = r_n(u_0, \dots, u_{n-1}). \quad (22.9)$$

每一阶使用同一个线性化算子  $L$ ，右端只依赖已知低阶系数。

---

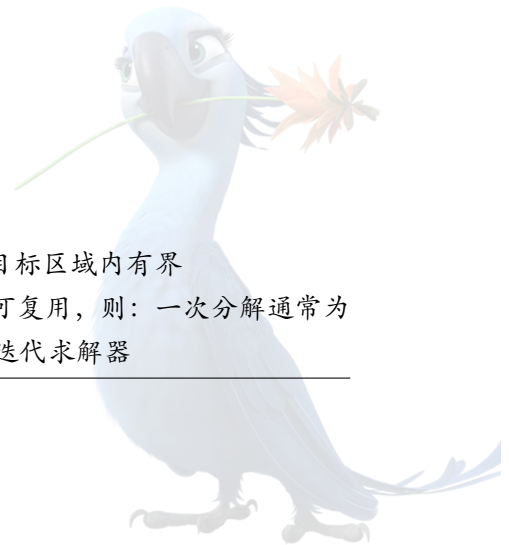
#### Algorithm 79 正则摄动系数的逐阶构造

---

**Input:** 算子方程  $\mathcal{F}(u, \varepsilon) = 0$ ; 基解  $u_0$ ; 目标阶数  $N$ ; 边界或初值条件; 归一化条件

**Output:** 系数  $u_0, \dots, u_N$  及截断展开  $u^{[N]}$

- 1: **Initialization:** 计算  $L = D_u \mathcal{F}(u_0, 0)$ ; 检查  $L$  是否可逆; 若不可逆, 则计算  $\ker L$ ,  $\ker L^*$
  - 2: **for**  $n = 1, \dots, N$  **do**
  - 3:   从  $\mathcal{F}\left(\sum_{j=0}^n \varepsilon^j u_j, \varepsilon\right)$  中提取  $\varepsilon^n$  系数
  - 4:   将所有只含  $u_0, \dots, u_{n-1}$  的项组成  $r_n$
  - 5:   **if**  $L$  可逆 **then**
  - 6:     解  $Lu_n = r_n$
  - 7:   **else**
  - 8:     对每个  $\psi \in \ker L^*$  施加可解性条件  $\langle \psi, r_n \rangle = 0$
  - 9:     利用待定参数、频率或特征值修正满足可解性条件
  - 10:    在附加归一化条件下求  $u_n$
  - 11:   **end if**
  - 12: **end for**
  - 13: 计算残量  $\mathcal{R}_N = \mathcal{F}(u^{[N]}, \varepsilon)$
  - 14: **Stopping criterion:** 确认  $\|\mathcal{R}_N\|_Y = O(\varepsilon^{N+1})$  且误差放大常数在目标区域内有界
  - 15: **Complexity:** 若每阶线性问题离散后规模为  $M$ , 且同一矩阵分解可复用, 则: 一次分解通常为  $O(M^3)$ , 每阶回代为  $O(M^2)$ ; 稀疏问题的成本取决于带宽、填充或迭代求解器
- 



## 22.1.3 知识点三：线性二阶常微分方程的标准递推

考虑

$$y''(x; \varepsilon) + g(x; \varepsilon)y(x; \varepsilon) = 0, \quad x \in [a, b], \quad (22.10)$$

其中

$$g(x; \varepsilon) = \sum_{k=0}^{\infty} \varepsilon^k g_k(x), \quad (22.11)$$

$$y(x; \varepsilon) = \sum_{n=0}^{\infty} \varepsilon^n y_n(x). \quad (22.12)$$

比较系数得到

$$y_0'' + g_0 y_0 = 0, \quad (22.13)$$

$$y_n'' + g_0 y_n = - \sum_{k=1}^n g_k y_{n-k}, \quad n \geq 1. \quad (22.14)$$

若初值不依赖  $\varepsilon$ :  $y(x_0; \varepsilon) = A$ ,  $y'(x_0; \varepsilon) = B$ , 则

$$y_0(x_0) = A, \quad y_0'(x_0) = B, \quad (22.15)$$

$$y_n(x_0) = 0, \quad y_n'(x_0) = 0, \quad n \geq 1. \quad (22.16)$$

设  $Y_1, Y_2$  为齐次方程  $z'' + g_0 z = 0$  的基解, Wronskian 为  $W[Y_1, Y_2] = Y_1 Y_2' - Y_1' Y_2$ . 由参数变易法:

$$y_n(x) = Y_2(x) \int_{x_0}^x \frac{Y_1(s) F_n(s)}{W[Y_1, Y_2](s)} ds - Y_1(x) \int_{x_0}^x \frac{Y_2(s) F_n(s)}{W[Y_1, Y_2](s)} ds, \quad (22.17)$$

$$F_n = - \sum_{k=1}^n g_k y_{n-k}. \quad (22.18)$$

若  $F_n$  含与齐次解同频的分量, 积分会产生  $x \sin(kx)$ ,  $x \cos(kx)$  型 secular term. 这不是积分计算错误, 而是频率或相位需要修正的信号。

## 22.2 隐式方程、代数根与反函数的摄动展开

## 22.2.1 知识点四：标量隐式方程的系数公式

考虑

$$F(x, \varepsilon) = 0, \quad F(x_0, 0) = 0, \quad F_x(x_0, 0) \neq 0. \quad (22.19)$$


设

$$x(\varepsilon) = x_0 + \varepsilon x_1 + \varepsilon^2 x_2 + \varepsilon^3 x_3 + \cdots. \quad (22.20)$$

以下所有偏导数均在  $(x_0, 0)$  处计算。

一阶系数为

$$x_1 = - \frac{F_\varepsilon}{F_x}. \quad (22.21)$$





二阶系数为

$$x_2 = -\frac{1}{F_x} \left[ \frac{1}{2} F_{xx} x_1^2 + F_{x\varepsilon} x_1 + \frac{1}{2} F_{\varepsilon\varepsilon} \right]. \quad (22.22)$$

三阶系数为

$$x_3 = -\frac{1}{F_x} \left[ F_{xx} x_1 x_2 + F_{x\varepsilon} x_2 + \frac{1}{6} F_{xxx} x_1^3 + \frac{1}{2} F_{xx\varepsilon} x_1^2 + \frac{1}{2} F_{x\varepsilon\varepsilon} x_1 + \frac{1}{6} F_{\varepsilon\varepsilon\varepsilon} \right]. \quad (22.23)$$

注 22.1. 若使用另一种约定  $x(\varepsilon) = x_0 + \varepsilon x'(0) + \frac{\varepsilon^2}{2} x''(0) + \cdots$ , 则  $x_2 = \frac{1}{2} x''(0)$ 。两种系数约定不得静默混合。本讲义始终采用  $x = x_0 + \varepsilon x_1 + \varepsilon^2 x_2 + \cdots$ 。

基础例题：简单代数根的正则展开

求

$$x + \varepsilon x^2 = 1 \quad (22.24)$$

在满足  $x(0) = 1$  的分支上的展开。

证明. 设  $x = 1 + a\varepsilon + b\varepsilon^2 + c\varepsilon^3 + O(\varepsilon^4)$ 。代入  $x + \varepsilon x^2 = 1$ 。由

$$x^2 = 1 + 2a\varepsilon + (a^2 + 2b)\varepsilon^2 + (2c + 2ab)\varepsilon^3 + O(\varepsilon^4), \quad (22.25)$$

逐阶比较：

$$O(\varepsilon): \quad a + 1 = 0, \quad (22.26)$$

$$O(\varepsilon^2): \quad b + 2a = 0, \quad (22.27)$$

$$O(\varepsilon^3): \quad c + a^2 + 2b = 0. \quad (22.28)$$

因此  $a = -1$ ,  $b = 2$ ,  $c = -5$ 。故

$$x(\varepsilon) = 1 - \varepsilon + 2\varepsilon^2 - 5\varepsilon^3 + O(\varepsilon^4). \quad (22.29)$$

精确分支为

$$x(\varepsilon) = \frac{-1 + \sqrt{1 + 4\varepsilon}}{2\varepsilon}, \quad (22.30)$$

其 Taylor 展开与上述结果一致。□

### 22.2.2 知识点五：多重根与分数幂展开

若  $F(x_0, 0) = 0$ ,  $F_x(x_0, 0) = 0$ , 隐函数定理失效。

例如

$$x^2 - \varepsilon = 0. \quad (22.31)$$

其两个分支为

$$x_{\pm}(\varepsilon) = \pm \varepsilon^{1/2}. \quad (22.32)$$

它们不能写成整数幂 Taylor 级数  $x_0 + \varepsilon x_1 + \varepsilon^2 x_2 + \cdots$ 。

这类展开称为 Puiseux 展开：

$$x(\varepsilon) = \sum_{k=k_0}^{\infty} a_k \varepsilon^{k/m}. \quad (22.33)$$



## 易错点与反例

错误说法：“只要方程中含小参数，就令  $x = x_0 + \varepsilon x_1 + \cdots$ .”

正确做法：

1. 先检查极限根是否简单；
2. 若 Jacobian 为零，先作主导平衡；
3. 判断是否需要  $\varepsilon^{1/2}$ ,  $\varepsilon^{1/3}$ ,  $\log \varepsilon$  等非 Taylor 尺度；
4. 对每个分支分别展开。

## 22.2.3 知识点六：隐式展开的条件数

由  $x'(\varepsilon) = -\frac{F_\varepsilon}{F_x}$ ，可以把  $|F_x|^{-1}$  看作局部灵敏度因子。

当  $F_x(x(\varepsilon), \varepsilon) \rightarrow 0$  时：

- 展开系数可能迅速增大；
- 参数分支可能折叠；
- Newton 校正变得病态；
- 级数收敛半径通常受最近分支点限制。

这说明“正则摄动”与“问题条件良好”不是同义词。一个参数分支可以在局部解析，但其系数常数很大。

## 22.3 初值问题的正则摄动、误差验证与有效区间

## 22.3.1 知识点七：非线性初值问题的逐阶方程

考虑

$$\begin{cases} \dot{\mathbf{y}} = \mathbf{F}(t, \mathbf{y}, \varepsilon), \\ \mathbf{y}(0; \varepsilon) = \boldsymbol{\eta}(\varepsilon), \end{cases} \quad \mathbf{y}(t; \varepsilon) \in \mathbb{R}^d. \quad (22.34)$$

设

$$\mathbf{y} = \mathbf{y}_0 + \varepsilon \mathbf{y}_1 + \varepsilon^2 \mathbf{y}_2 + \cdots, \quad (22.35)$$

$$\boldsymbol{\eta} = \boldsymbol{\eta}_0 + \varepsilon \boldsymbol{\eta}_1 + \varepsilon^2 \boldsymbol{\eta}_2 + \cdots. \quad (22.36)$$


记  $A(t) = D_{\mathbf{y}} \mathbf{F}(t, \mathbf{y}_0(t), 0)$ 。则

$$\dot{\mathbf{y}}_0 = \mathbf{F}(t, \mathbf{y}_0, 0), \quad \mathbf{y}_0(0) = \boldsymbol{\eta}_0, \quad (22.37)$$

$$\dot{\mathbf{y}}_1 = A(t) \mathbf{y}_1 + \mathbf{F}_\varepsilon(t, \mathbf{y}_0, 0), \quad \mathbf{y}_1(0) = \boldsymbol{\eta}_1, \quad (22.38)$$

$$\begin{aligned} \dot{\mathbf{y}}_2 = A(t) \mathbf{y}_2 + \frac{1}{2} \mathbf{F}_{\mathbf{y}\mathbf{y}}[\mathbf{y}_1, \mathbf{y}_1] \\ + \mathbf{F}_{\mathbf{y}\varepsilon} \mathbf{y}_1 + \frac{1}{2} \mathbf{F}_{\varepsilon\varepsilon}, \quad \mathbf{y}_2(0) = \boldsymbol{\eta}_2. \end{aligned} \quad (22.39)$$

每个高阶系数满足沿零阶轨道的线性变分方程。



## 22.3.2 知识点八：固定时间区间上的误差估计

设截断近似为  $\mathbf{y}^{[N]} = \sum_{n=0}^N \varepsilon^n \mathbf{y}_n$ 。定义残量

$$\mathbf{r}_N(t; \varepsilon) = \dot{\mathbf{y}}^{[N]} - \mathbf{F}(t, \mathbf{y}^{[N]}, \varepsilon). \quad (22.40)$$

假设在固定区间  $0 \leq t \leq T$  上：

$$\|\mathbf{r}_N(t; \varepsilon)\| \leq C_R |\varepsilon|^{N+1}, \quad (22.41)$$

$$\|\mathbf{y}(0; \varepsilon) - \mathbf{y}^{[N]}(0; \varepsilon)\| \leq C_0 |\varepsilon|^{N+1}, \quad (22.42)$$

$$\|D_{\mathbf{y}} \mathbf{F}\| \leq L. \quad (22.43)$$

令  $\mathbf{e} = \mathbf{y} - \mathbf{y}^{[N]}$ 。则  $\dot{\mathbf{e}} = \mathbf{F}(t, \mathbf{y}, \varepsilon) - \mathbf{F}(t, \mathbf{y}^{[N]}, \varepsilon) - \mathbf{r}_N$ 。所以

$$\|\dot{\mathbf{e}}\| \leq L \|\mathbf{e}\| + C_R |\varepsilon|^{N+1}. \quad (22.44)$$

由 Grönwall 不等式：

$$\sup_{0 \leq t \leq T} \|\mathbf{y}(t; \varepsilon) - \mathbf{y}^{[N]}(t; \varepsilon)\| \leq C_T |\varepsilon|^{N+1}. \quad (22.45)$$

这里  $C_T$  可含  $e^{LT}$ 。因此该估计通常只保证固定  $T$  上的一致有效性，不能直接令  $T = O(\varepsilon^{-1})$ 。

## 22.3.3 知识点九：secular term 与固定时间展开的失效

考虑精确可解问题

$$y'' + (1 + \varepsilon)y = 0, \quad y(0) = 1, \quad y'(0) = 0. \quad (22.46)$$

精确解为

$$y(t; \varepsilon) = \cos(\sqrt{1 + \varepsilon} t). \quad (22.47)$$

作朴素正则展开  $y = y_0 + \varepsilon y_1 + \cdots$ 。零阶：  $y_0'' + y_0 = 0$ ,  $y_0 = \cos t$ 。一阶：

$$y_1'' + y_1 = -\cos t, \quad y_1(0) = y_1'(0) = 0. \quad (22.48)$$

由于右端与齐次解共振，

$$y_1(t) = -\frac{t}{2} \sin t. \quad (22.49)$$

故

$$y(t; \varepsilon) = \cos t - \frac{\varepsilon t}{2} \sin t + \cdots. \quad (22.50)$$


该展开要求  $|\varepsilon t| \ll 1$ 。当  $t = O(\varepsilon^{-1})$  时，一阶项不再小于零阶项。

但精确解并没有增长；增长的是由频率误差展开出来的世俗系数。

事实上

$$\sqrt{1 + \varepsilon} = 1 + \frac{\varepsilon}{2} - \frac{\varepsilon^2}{8} + O(\varepsilon^3), \quad (22.51)$$

$$\cos\left[\left(1 + \frac{\varepsilon}{2} + \cdots\right)t\right] = \cos t - \frac{\varepsilon t}{2} \sin t + \cdots. \quad (22.52)$$



## 易错点与反例

secular term 不表示真实解一定发散。

它通常表示：

- 频率被错误地固定为零阶频率；
- 振幅或相位存在慢变化；
- 普通展开只在固定时间区间有效；
- 需要 Poincaré–Lindstedt 法或多尺度法重新组织展开。

## 22.4 Fredholm 可解性条件与共振消除

## 22.4.1 知识点十：抽象可解性条件

设  $H$  为 Hilbert 空间,  $L: D(L) \subset H \rightarrow H$  为闭线性算子。考虑

$$Lu = f. \quad (22.53)$$

若  $L$  不是可逆的, 则右端不能任意选取。对任意  $\psi \in \ker L^*$  有  $L^*\psi = 0$ 。若  $Lu = f$ , 则

$$\langle \psi, f \rangle = \langle \psi, Lu \rangle = \langle L^*\psi, u \rangle = 0. \quad (22.54)$$

因此必要条件为

$$\boxed{\langle \psi, f \rangle = 0, \forall \psi \in \ker L^*}. \quad (22.55)$$

若  $L$  为 Fredholm 算子且值域闭, 该条件也是充分条件:

$$\text{Ran}(L) = (\ker L^*)^\perp. \quad (22.56)$$

若  $L = L^*$  自伴, 则  $\ker L^* = \ker L$ 。可解性条件变为右端与齐次核正交。

## 22.4.2 知识点十一：周期振子的可解性条件

考虑

$$u'' + u = F(\tau), \quad u(\tau + 2\pi) = u(\tau). \quad (22.57)$$

算子  $L = \frac{d^2}{d\tau^2} + 1$  的周期核为  $\ker L = \text{span}\{\cos \tau, \sin \tau\}$ 。因此存在  $2\pi$ -周期解的充要条件为

$$\boxed{\int_0^{2\pi} F(\tau) \cos \tau \, d\tau = 0}, \quad (22.58)$$

$$\boxed{\int_0^{2\pi} F(\tau) \sin \tau \, d\tau = 0}. \quad (22.59)$$

若条件不满足, 相应解中出现  $\tau \sin \tau$  或  $\tau \cos \tau$  secular term。



## 可解性条件：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 高阶方程的线性算子具有非零核；
- 右端含齐次解同频分量；
- 待定特征值、频率、相位或振幅尚未确定。

构造步骤：

1. 写出高阶线性算子  $L$ ；
2. 求  $\ker L^*$ ；
3. 将右端与伴随核逐一作内积；
4. 令这些内积为零；
5. 用所得方程确定待定参数；
6. 添加归一化条件去除核方向的不唯一性。

关键估计：不存在统一的“把共振项积分掉”方法；必须消除右端在伴随核上的投影。

结论：可解性条件同时决定：

- 特征值修正；
- 频率修正；
- 慢振幅方程；
- 分支条件。

常见失败原因：

- 用  $\ker L$  代替  $\ker L^*$  处理非自伴问题；
- 忘记边界条件决定算子定义域；
- 只消除  $\cos \tau$  而漏掉  $\sin \tau$ ；
- 求出特解后未加归一化，导致系数不唯一。

## 22.5 矩阵简单特征值的摄动展开

## 22.5.1 知识点十二：非 Hermitian 简单特征值的一阶修正


考虑

$$A(\varepsilon) = A_0 + \varepsilon B, \quad A_0, B \in \mathbb{C}^{n \times n}. \quad (22.60)$$

设  $\lambda_0$  是  $A_0$  的简单特征值，右、左特征向量分别满足

$$A_0 \mathbf{x}_0 = \lambda_0 \mathbf{x}_0, \quad (22.61)$$

$$\mathbf{y}_0^* A_0 = \lambda_0 \mathbf{y}_0^*. \quad (22.62)$$



采用归一化

$$\boxed{\mathbf{y}_0^* \mathbf{x}_0 = 1}. \quad (22.63)$$

设

$$\lambda(\varepsilon) = \lambda_0 + \varepsilon \lambda_1 + \varepsilon^2 \lambda_2 + \cdots, \quad (22.64)$$

$$\mathbf{x}(\varepsilon) = \mathbf{x}_0 + \varepsilon \mathbf{x}_1 + \varepsilon^2 \mathbf{x}_2 + \cdots. \quad (22.65)$$

一阶方程为

$$(A_0 - \lambda_0 I) \mathbf{x}_1 = -(B - \lambda_1 I) \mathbf{x}_0. \quad (22.66)$$

左乘  $\mathbf{y}_0^*$ :  $0 = -\mathbf{y}_0^* B \mathbf{x}_0 + \lambda_1 \mathbf{y}_0^* \mathbf{x}_0$ 。由归一化得到

$$\boxed{\lambda_1 = \mathbf{y}_0^* B \mathbf{x}_0}. \quad (22.67)$$

若不采用  $\mathbf{y}_0^* \mathbf{x}_0 = 1$ , 则

$$\boxed{\lambda_1 = \frac{\mathbf{y}_0^* B \mathbf{x}_0}{\mathbf{y}_0^* \mathbf{x}_0}}. \quad (22.68)$$

### 22.5.2 知识点十三：特征向量修正与归一化

因为  $A_0 - \lambda_0 I$  奇异,  $\mathbf{x}_1$  只确定到  $\mathbf{x}_1 + c\mathbf{x}_0$ 。可采用规范条件

$$\boxed{\mathbf{y}_0^* \mathbf{x}_1 = 0}. \quad (22.69)$$

定义谱投影

$$P = \mathbf{x}_0 \mathbf{y}_0^*, \quad Q = I - P. \quad (22.70)$$

在  $Q\mathbb{C}^n$  上,  $Q(A_0 - \lambda_0 I)Q$  可逆。因此

$$\boxed{\mathbf{x}_1 = -[Q(A_0 - \lambda_0 I)Q]^{-1} Q(B - \lambda_1 I) \mathbf{x}_0}. \quad (22.71)$$

### 22.5.3 知识点十四：Hermitian 矩阵的二阶公式

若  $A_0 = A_0^*$ ,  $B = B^*$ , 可取一组标准正交特征向量  $A_0 \mathbf{x}_j = \lambda_j^{(0)} \mathbf{x}_j$ 。设研究第  $k$  个简单特征值。则

$$\boxed{\lambda_k^{(1)} = \mathbf{x}_k^* B \mathbf{x}_k}. \quad (22.72)$$

一阶特征向量修正为


$$\boxed{\mathbf{x}_k^{(1)} = \sum_{j \neq k} \frac{\mathbf{x}_j^* B \mathbf{x}_k}{\lambda_k^{(0)} - \lambda_j^{(0)}} \mathbf{x}_j}. \quad (22.73)$$

若  $A(\varepsilon) = A_0 + \varepsilon B$ , 则二阶特征值修正为

$$\boxed{\lambda_k^{(2)} = \sum_{j \neq k} \frac{|\mathbf{x}_j^* B \mathbf{x}_k|^2}{\lambda_k^{(0)} - \lambda_j^{(0)}}}. \quad (22.74)$$

若  $A(\varepsilon) = A_0 + \varepsilon B + \varepsilon^2 C$ , 则

$$\lambda_k^{(2)} = \mathbf{x}_k^* C \mathbf{x}_k + \sum_{j \neq k} \frac{|\mathbf{x}_j^* B \mathbf{x}_k|^2}{\lambda_k^{(0)} - \lambda_j^{(0)}}. \quad (22.75)$$



基础例题：一阶修正消失但二阶修正非零

考虑

$$A(\varepsilon) = \begin{pmatrix} 1 & \varepsilon \\ \varepsilon & 2 \end{pmatrix}. \quad (22.76)$$

求靠近 1 的特征值展开。

证明. 取  $A_0 = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$ ,  $B = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ . 对  $\lambda_0 = 1$ ,  $\mathbf{x}_0 = \mathbf{e}_1$ , 有  $\lambda_1 = \mathbf{e}_1^\top B \mathbf{e}_1 = 0$ . 二阶修正为  $\lambda_2 = \frac{|\mathbf{e}_2^\top B \mathbf{e}_1|^2}{1-2} = -1$ . 因此

$$\lambda_-(\varepsilon) = 1 - \varepsilon^2 + O(\varepsilon^4). \quad (22.77)$$

精确特征值为

$$\lambda_{\pm} = \frac{3 \pm \sqrt{1 + 4\varepsilon^2}}{2}, \quad (22.78)$$

展开后验证上述结果。  $\square$

#### 22.5.4 知识点十五：特征值条件数与谱间隙

对简单非正规特征值，绝对条件数为

$$\kappa_{\text{eig}}(\lambda_0) = \frac{\|\mathbf{x}_0\|_2 \|\mathbf{y}_0\|_2}{|\mathbf{y}_0^* \mathbf{x}_0|}. \quad (22.79)$$

若  $\|\mathbf{x}_0\|_2 = \|\mathbf{y}_0\|_2 = 1$ , 则  $\kappa_{\text{eig}} = \frac{1}{|\mathbf{y}_0^* \mathbf{x}_0|}$ . 一阶扰动满足

$$|\delta\lambda| \lesssim \kappa_{\text{eig}} \|E\|_2. \quad (22.80)$$

对 Hermitian 矩阵，左右特征向量相同且可单位化，所以  $\kappa_{\text{eig}} = 1$ 。

特征向量修正还受到谱间隙

$$\text{gap}_k = \min_{j \neq k} |\lambda_k^{(0)} - \lambda_j^{(0)}| \quad (22.81)$$

控制：  $\left\| \mathbf{x}_k^{(1)} \right\| \lesssim \frac{\|B\|}{\text{gap}_k}$ 。

因此：

特征值条件良好  $\not\Rightarrow$  特征向量条件良好。

#### 22.5.5 知识点十六：重特征值与分裂

若  $\lambda_0$  是 Hermitian 矩阵  $A_0$  的  $r$  重特征值，令  $X = (\mathbf{x}_1 \ \dots \ \mathbf{x}_r)$  为对应标准正交基。一阶分裂由小矩阵

$$X^* B X \quad (22.82)$$

的特征值决定。

不能任选原重特征子空间中的某个向量，直接写  $\lambda_1 = \mathbf{x}^* B \mathbf{x}$ 。必须先为重特征子空间内对扰动算子对角化。

若原特征值具有 Jordan 块，特征值甚至可能出现  $\varepsilon^{1/m}$  型 Puiseux 展开。



## 易错点与反例

1. 简单特征值公式不能无条件用于重特征值;
2. 非 Hermitian 问题不能只使用右特征向量;
3. 归一化条件不是装饰, 它决定特征向量修正的唯一性;
4. 谱间隙趋零时, 固定阶展开可能不一致;
5. 接近缺陷矩阵时, 特征值条件数可非常大。

## 22.6 微分算子的特征值摄动

## 22.6.1 知识点十七: 自伴算子的一阶公式

设

$$L(\varepsilon) = L_0 + \varepsilon L_1, \quad (22.83)$$

并考虑

$$L(\varepsilon)u(\varepsilon) = \lambda(\varepsilon)u(\varepsilon). \quad (22.84)$$

设  $L_0$  自伴,  $\lambda_0$  为简单特征值,  $L_0 u_0 = \lambda_0 u_0$ ,  $\|u_0\| = 1$ 。展开

$$u = u_0 + \varepsilon u_1 + \cdots, \quad (22.85)$$

$$\lambda = \lambda_0 + \varepsilon \lambda_1 + \cdots. \quad (22.86)$$

一阶方程为

$$(L_0 - \lambda_0 I)u_1 = -(L_1 - \lambda_1 I)u_0. \quad (22.87)$$

与  $u_0$  作内积:

$$\lambda_1 = \langle u_0, L_1 u_0 \rangle. \quad (22.88)$$

若未单位化, 则

$$\lambda_1 = \frac{\langle u_0, L_1 u_0 \rangle}{\langle u_0, u_0 \rangle}. \quad (22.89)$$

该公式就是连续算子版本的 Rayleigh 商一阶修正。

## 22.7 正式真题 [23F-Q7]——Sturm–Liouville 特征值摄动

完整题目叙述: [23F-Q7]

考虑特征值问题

$$u''(x) + [\lambda + \varepsilon f(x)]u(x) = 0, \quad 0 < x < 1, \quad 0 < \varepsilon \ll 1, \quad (22.90)$$

边界条件为

$$u(0) = 0, \quad u'(1) = 0, \quad (22.91)$$

其中  $f$  为给定光滑函数。

求特征值  $\lambda$  的渐近展开, 保留至  $\varepsilon$  一阶。

第一步：零阶特征值和特征函数. 设

$$\lambda_n(\varepsilon) = \lambda_n^{(0)} + \varepsilon \lambda_n^{(1)} + O(\varepsilon^2), \quad (22.92)$$

$$u_n(x; \varepsilon) = u_n^{(0)}(x) + \varepsilon u_n^{(1)}(x) + O(\varepsilon^2). \quad (22.93)$$

零阶问题为

$$(u_n^{(0)})'' + \lambda_n^{(0)} u_n^{(0)} = 0, \quad (22.94)$$

边界条件  $u_n^{(0)}(0) = 0$ ,  $(u_n^{(0)})'(1) = 0$ 。

令  $\lambda_n^{(0)} = \kappa_n^2$ ,  $\kappa_n > 0$ 。满足左端 Dirichlet 条件的解为  $u_n^{(0)}(x) = C_n \sin(\kappa_n x)$ 。右端 Neumann 条件要求  $C_n \kappa_n \cos \kappa_n = 0$ 。非平凡解要求  $\cos \kappa_n = 0$ 。因此

$$\kappa_n = \left(n + \frac{1}{2}\right) \pi, \quad n = 0, 1, 2, \dots \quad (22.95)$$

以及

$$\lambda_n^{(0)} = \left(n + \frac{1}{2}\right)^2 \pi^2. \quad (22.96)$$

可取

$$u_n^{(0)}(x) = \sin(\kappa_n x). \quad (22.97)$$

□

第二步：一阶方程. 将展开代入原方程，取  $\varepsilon$  一阶项：

$$(u_n^{(1)})'' + \lambda_n^{(0)} u_n^{(1)} = -[\lambda_n^{(1)} + f(x)] u_n^{(0)}. \quad (22.98)$$

边界条件逐阶展开给出

$$u_n^{(1)}(0) = 0, \quad (u_n^{(1)})'(1) = 0. \quad (22.99)$$

□

第三步：Fredholm 可解性条件. 将式 (22.98) 乘以  $u_n^{(0)}$  并在  $[0, 1]$  积分：

$$\begin{aligned} & \int_0^1 u_n^{(0)} [(u_n^{(1)})'' + \lambda_n^{(0)} u_n^{(1)}] dx \\ &= -\lambda_n^{(1)} \int_0^1 (u_n^{(0)})^2 dx - \int_0^1 f(x) (u_n^{(0)})^2 dx. \end{aligned} \quad (22.100)$$

由分部积分和零阶方程：

$$\begin{aligned} & \int_0^1 u_n^{(0)} [(u_n^{(1)})'' + \lambda_n^{(0)} u_n^{(1)}] dx \\ &= [u_n^{(0)} (u_n^{(1)})' - (u_n^{(0)})' u_n^{(1)}]_0^1. \end{aligned} \quad (22.101)$$

在  $x = 0$ :  $u_n^{(0)}(0) = u_n^{(1)}(0) = 0$ 。在  $x = 1$ :  $(u_n^{(0)})'(1) = (u_n^{(1)})'(1) = 0$ 。所以边界项为零。

因此可解性条件为

$$\lambda_n^{(1)} \int_0^1 (u_n^{(0)})^2 dx + \int_0^1 f(x) (u_n^{(0)})^2 dx = 0. \quad (22.102)$$

故

$$\lambda_n^{(1)} = - \frac{\int_0^1 f(x) \sin^2(\kappa_n x) dx}{\int_0^1 \sin^2(\kappa_n x) dx}. \quad (22.103)$$



又因为

$$\begin{aligned}\int_0^1 \sin^2(\kappa_n x) dx &= \frac{1}{2} - \frac{\sin(2\kappa_n)}{4\kappa_n} \\ &= \frac{1}{2},\end{aligned}\quad (22.104)$$

所以

$$\lambda_n^{(1)} = -2 \int_0^1 f(x) \sin^2 \left[ \left( n + \frac{1}{2} \right) \pi x \right] dx. \quad (22.105)$$

□

综上,

$$\lambda_n(\varepsilon) = \left( n + \frac{1}{2} \right)^2 \pi^2 - 2\varepsilon \int_0^1 f(x) \sin^2 \left[ \left( n + \frac{1}{2} \right) \pi x \right] dx + O(\varepsilon^2). \quad (22.106)$$

注 22.2 (算子形式与符号核对). 原方程可改写为

$$\left[ -\frac{d^2}{dx^2} - \varepsilon f(x) \right] u = \lambda u. \quad (22.107)$$

因此扰动算子是  $L_1 = -f(x)$ , 故  $\lambda_n^{(1)} = \langle \phi_n, -f\phi_n \rangle$ . 负号来自题面中  $\lambda + \varepsilon f(x)$  的放置方式, 不能套用  $-u'' + \varepsilon f u = \lambda u$  的正号公式。

注 22.3 (一阶特征函数修正). 取标准正交特征函数

$$\phi_m(x) = \sqrt{2} \sin(\kappa_m x), \quad \kappa_m = \left( m + \frac{1}{2} \right) \pi. \quad (22.108)$$

采用归一化  $\langle \phi_n, u_n^{(1)} \rangle = 0$ , 则

$$u_n^{(1)} = \sum_{m \neq n} \frac{\int_0^1 f(x) \phi_m(x) \phi_n(x) dx}{\lambda_m^{(0)} - \lambda_n^{(0)}} \phi_m. \quad (22.109)$$

题目只要求特征值时, 不必计算该式, 但应知道谱间隙控制特征函数修正。

#### 易错点与反例

1. 把未扰动边界条件误写成 Dirichlet–Dirichlet;
2. 漏掉半整数频率  $(n + \frac{1}{2})\pi$ ;
3. 一阶修正符号写反;
4. 只写  $\lambda_1 = -\int f u_0^2$  而漏掉归一化分母;
5. 分部积分后不检查边界项;
6. 把丘赛或课程例题误标为正式题;
7. 将“保留至  $O(\varepsilon)$ ”误写成余项仍为  $O(\varepsilon)$ 。

## 22.8 Poincaré–Lindstedt 方法

### 22.8.1 知识点十八: 问题与目标

【重要性等级】 **S 级**。Poincaré–Lindstedt 方法适用于:



- 稳定中心附近的小振幅周期轨道;
- 弱非线性保守振子;
- 频率依赖振幅, 但振幅不发生长期衰减或增长;
- 普通摄动展开因频率失配产生 secular term。

考虑

$$\ddot{y} + \omega_0^2 y + \varepsilon G_1(y, \dot{y}) + \varepsilon^2 G_2(y, \dot{y}) = 0. \quad (22.110)$$

引入伸缩时间

$$\tau = \Omega(\varepsilon)t. \quad (22.111)$$

则

$$\frac{d}{dt} = \Omega \frac{d}{d\tau}, \quad (22.112)$$

$$\frac{d^2}{dt^2} = \Omega^2 \frac{d^2}{d\tau^2}. \quad (22.113)$$

同时展开

$$y(t; \varepsilon) = y_0(\tau) + \varepsilon y_1(\tau) + \varepsilon^2 y_2(\tau) + \cdots, \quad (22.114)$$

$$\Omega(\varepsilon) = \omega_0 + \varepsilon \omega_1 + \varepsilon^2 \omega_2 + \cdots, \quad (22.115)$$

或展开

$$\Omega^2 = \omega_0^2 + \varepsilon \sigma_1 + \varepsilon^2 \sigma_2 + \cdots. \quad (22.116)$$

两种频率系数关系为

$$\sigma_1 = 2\omega_0\omega_1, \quad (22.117)$$

$$\sigma_2 = \omega_1^2 + 2\omega_0\omega_2. \quad (22.118)$$

#### 易错点与反例

不能在单一推导中把  $\Omega = \omega_0 + \varepsilon\omega_1 + \cdots$  和  $\Omega^2 = \omega_0^2 + \varepsilon\sigma_1 + \cdots$  的系数当作相同量。

例如当  $\omega_1 = 0$  时:  $\omega_2 = \frac{\sigma_2}{2\omega_0}$ 。

### 22.8.2 知识点十九: 每阶消除共振项

经过归一化后, 每一阶通常具有

$$y_n'' + y_n = R_n(\tau), \quad (22.119)$$

其中撇号表示对  $\tau$  求导。

为使  $y_n$  保持  $2\pi$ -周期并避免 secular term, 必须满足

$$\int_0^{2\pi} R_n(\tau) \cos \tau \, d\tau = 0, \quad (22.120)$$

$$\int_0^{2\pi} R_n(\tau) \sin \tau \, d\tau = 0. \quad (22.121)$$

在具有时间反演对称性的初值问题  $y(0) = A, \dot{y}(0) = 0$  中, 可选各阶解为偶函数, 右端通常不含  $\sin \tau$  共振项, 只需消除  $\cos \tau$  项。



为固定齐次解自由度, 可采用:

$$y_0(0) = A, \quad y'_0(0) = 0, \quad (22.122)$$

$$y_n(0) = 0, \quad y'_n(0) = 0, \quad n \geq 1. \quad (22.123)$$

---

**Algorithm 80** Poincaré–Lindstedt 频率修正
 

---

**Input:** 弱非线性振子; 平衡点; 小振幅参数  $\varepsilon$ ; 初始相位; 目标阶数  $N$

**Output:** 周期解展开、频率展开和周期展开

- 1: **Initialization:** 将平衡点平移到原点; 令  $\tau = \Omega t$ ; 选择展开  $y = \sum_{n=0}^N \varepsilon^n y_n$ ,  $\Omega^2 = \sum_{n=0}^N \varepsilon^n \sigma_n$
  - 2: 求零阶周期解及基本频率
  - 3: **for**  $n = 1, \dots, N$  **do**
  - 4:   收集  $\varepsilon^n$  项, 写成  $y''_n + y_n = R_n$
  - 5:   提取  $R_n$  的  $\cos \tau$  和  $\sin \tau$  Fourier 系数
  - 6:   令共振系数为零, 求  $\sigma_n$  或其他待定参数
  - 7:   解无共振周期方程
  - 8:   用  $y_n(0) = y'_n(0) = 0$  固定齐次项
  - 9: **end for**
  - 10: 由  $\Omega^2$  展开恢复  $\Omega$
  - 11: 计算  $T = \frac{2\pi}{\Omega}$  的渐近展开
  - 12: **Stopping criterion:** 确认每阶解有界且周期; 检查代回原方程后的残量阶; 检查轨道未接近分离曲线或其他共振
  - 13: **Complexity:** 若使用前  $K$  个 Fourier 模态, 每阶线性求解为对角运算  $O(K)$ ; 非线性卷积朴素成本  $O(K^2)$ , FFT 可降至  $O(K \log K)$
- 

### 22.8.3 知识点二十: 二次-三次非线性振子的通用频率公式

考虑

$$\ddot{y} + \omega_0^2 y + \alpha y^2 + \beta y^3 = 0, \quad y(0) = A, \quad \dot{y}(0) = 0, \quad (22.124)$$

其中  $0 < |A| \ll 1$ 。令

$$y(t) = Au(\tau), \quad \tau = \Omega t. \quad (22.125)$$

则

$$\Omega^2 u'' + \omega_0^2 u + \alpha A u^2 + \beta A^2 u^3 = 0. \quad (22.126)$$

设

$$u = u_0 + Au_1 + A^2 u_2 + \dots, \quad (22.127)$$

$$\Omega^2 = \omega_0^2 + A\sigma_1 + A^2\sigma_2 + \dots. \quad (22.128)$$


零阶:  $u''_0 + u_0 = 0$ ,  $u_0 = \cos \tau$ 。

一阶方程:

$$u''_1 + u_1 = \frac{\sigma_1}{\omega_0^2} \cos \tau - \frac{\alpha}{2\omega_0^2} (1 + \cos 2\tau). \quad (22.129)$$

消除  $\cos \tau$  共振项:

$$\boxed{\sigma_1 = 0}. \quad (22.130)$$



结合  $u_1(0) = u_1'(0) = 0$  得到

$$u_1(\tau) = \frac{\alpha}{3\omega_0^2} \cos \tau - \frac{\alpha}{2\omega_0^2} + \frac{\alpha}{6\omega_0^2} \cos 2\tau. \quad (22.131)$$

二阶方程为

$$u_2'' + u_2 = \frac{\sigma_2}{\omega_0^2} \cos \tau - \frac{2\alpha}{\omega_0^2} u_0 u_1 - \frac{\beta}{\omega_0^2} u_0^3. \quad (22.132)$$

利用  $\cos^3 \tau = \frac{1}{4}(3 \cos \tau + \cos 3\tau)$  以及  $[u_0 u_1]_{\cos \tau} = -\frac{5\alpha}{12\omega_0^2}$ , 二阶右端的  $\cos \tau$  系数为  $\frac{\sigma_2}{\omega_0^2} + \frac{5\alpha^2}{6\omega_0^4} - \frac{3\beta}{4\omega_0^2}$ . 令其为零:

$$\sigma_2 = \frac{3\beta}{4} - \frac{5\alpha^2}{6\omega_0^2}. \quad (22.133)$$

因此频率为

$$\Omega = \omega_0 \left[ 1 + \left( \frac{3\beta}{8\omega_0^2} - \frac{5\alpha^2}{12\omega_0^4} \right) A^2 + O(A^3) \right]. \quad (22.134)$$

周期为

$$T = \frac{2\pi}{\omega_0} \left[ 1 - \left( \frac{3\beta}{8\omega_0^2} - \frac{5\alpha^2}{12\omega_0^4} \right) A^2 + O(A^3) \right]. \quad (22.135)$$

注 22.4. 二次非线性  $\alpha y^2$  在一阶产生:

- 常数均值偏移;
- 二次谐波;

但不直接产生基本频率共振, 所以频率没有  $O(A)$  修正。

二次非线性通过  $\alpha^2 A^2$  在二阶影响频率。

## 22.9 正式真题 [26S-Q6]——闭轨道与周期展开

完整题目叙述: [26S-Q6]

考虑系统

$$\ddot{x} - 2x - x^2 + x^3 = 0. \quad (22.136)$$

(a) 求系统的静态解;

(b) 对充分小但非零的  $\varepsilon$ , 证明从

$$(x(0), \dot{x}(0)) = (2 + \varepsilon, 0) \quad (22.137)$$

出发的轨道在相平面  $x - \dot{x}$  中闭合, 并求该闭轨道周期保留至  $O(\varepsilon^2)$  的近似。

第 (a) 问: 静态解. 静态解满足  $\dot{x} = \ddot{x} = 0$ . 因此

$$-2x - x^2 + x^3 = 0, \quad (22.138)$$


$$x(x^2 - x - 2) = 0, \quad (22.139)$$

$$x(x-2)(x+1) = 0. \quad (22.140)$$

故全部静态解为

$$x_e = -1, \quad 0, \quad 2. \quad (22.141)$$

□



第 (b) 问第一步: 能量守恒. 将方程写成

$$\ddot{x} + V'(x) = 0, \quad (22.142)$$

其中

$$V'(x) = x^3 - x^2 - 2x. \quad (22.143)$$

可取势能

$$V(x) = \frac{x^4}{4} - \frac{x^3}{3} - x^2. \quad (22.144)$$

Hamilton 量

$$H(x, v) = \frac{1}{2}v^2 + V(x), \quad v = \dot{x}, \quad (22.145)$$

满足

$$\begin{aligned} \frac{dH}{dt} &= v\dot{v} + V'(x)\dot{x} \\ &= \dot{x}[\ddot{x} + V'(x)] = 0. \end{aligned} \quad (22.146)$$

所以轨道位于能级集  $H(x, v) = E$ 。  $\square$

第 (b) 问第二步: 平衡点类型. 有

$$V''(x) = 3x^2 - 2x - 2. \quad (22.147)$$

因此

$$V''(-1) = 3 > 0, \quad (22.148)$$

$$V''(0) = -2 < 0, \quad (22.149)$$

$$V''(2) = 6 > 0. \quad (22.150)$$

所以:

- $x = -1$  是稳定中心;
- $x = 0$  是鞍点对应的势能局部极大;
- $x = 2$  是稳定中心。

本题初值位于  $x = 2$  附近, 故研究的是  $x = 2$  周围的小振幅闭轨道。  $\square$

第 (b) 问第三步: 闭轨道的严格说明. 令  $y = x - 2$ 。由 式 (22.144) 可得

$$V(2+y) - V(2) = 3y^2 + \frac{5}{3}y^3 + \frac{1}{4}y^4. \quad (22.151)$$

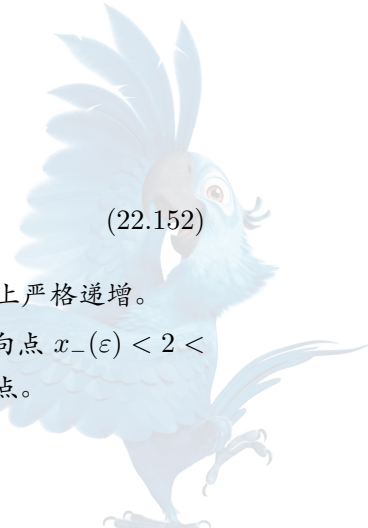
并且  $V(2) = -\frac{8}{3}$ 。

初始能量为

$$\begin{aligned} E_\varepsilon &= V(2+\varepsilon) \\ &= -\frac{8}{3} + 3\varepsilon^2 + \frac{5}{3}\varepsilon^3 + \frac{1}{4}\varepsilon^4. \end{aligned} \quad (22.152)$$

由于  $V''(2) = 6 > 0$ , 存在  $\delta > 0$ , 使  $V$  在  $(2-\delta, 2)$  上严格递减, 在  $(2, 2+\delta)$  上严格递增。

对充分小且非零的  $\varepsilon$ , 能量  $E_\varepsilon$  略高于  $V(2)$ , 在  $x = 2$  两侧各有一个非退化转向点  $x_-(\varepsilon) < 2 < x_+(\varepsilon)$ 。其中一个转向点是  $x_+(\varepsilon) = 2 + \varepsilon$  当  $\varepsilon > 0$ ; 若  $\varepsilon < 0$ , 则初始点是左侧转向点。





考虑能级的连通分支

$$\Gamma_\varepsilon = \left\{ (x, v) : \frac{1}{2}v^2 + V(x) = E_\varepsilon, \quad x_- \leq x \leq x_+ \right\}. \quad (22.153)$$

它是紧的。

在  $\Gamma_\varepsilon$  上没有平衡点, 因为  $E_\varepsilon > V(2)$  且能级充分接近  $V(2)$ 。于是  $\nabla H = (V'(x), v) \neq 0$  在该能级上成立。因此  $\Gamma_\varepsilon$  是光滑紧致一维流形, 其该连通分支同胚于圆周。

Hamilton 向量场  $(\dot{x}, \dot{v}) = (v, -V'(x))$  沿  $\Gamma_\varepsilon$  处处非零并与其相切, 所以解沿该简单闭曲线周期运行。

因此初值  $(2 + \varepsilon, 0)$  所对应的相平面轨道闭合。  $\square$

注 22.5 (周期积分表示). 周期也可写成

$$T(\varepsilon) = \sqrt{2} \int_{x_-(\varepsilon)}^{x_+(\varepsilon)} \frac{dx}{\sqrt{E_\varepsilon - V(x)}}. \quad (22.154)$$

两个转向点处的平方根奇异是可积的, 故周期有限。

但直接在移动端点上展开积分较繁琐; Poincaré-Lindstedt 方法更适合考试中的周期系数计算。

第 (b) 问第四步: 平移到稳定平衡点. 令

$$x = 2 + y. \quad (22.155)$$

代入原方程:

$$\ddot{y} + 6y + 5y^2 + y^3 = 0. \quad (22.156)$$

初值为

$$y(0) = \varepsilon, \quad \dot{y}(0) = 0. \quad (22.157)$$

线性化频率为

$$\omega_0 = \sqrt{6}. \quad (22.158)$$

$\square$

第 (b) 问第五步: Poincaré-Lindstedt 展开. 令

$$y(t) = \varepsilon u(\tau), \quad \tau = \Omega t. \quad (22.159)$$

则

$$\Omega^2 u'' + 6u + 5\varepsilon u^2 + \varepsilon^2 u^3 = 0, \quad (22.160)$$

其中撇号表示对  $\tau$  求导。

设


$$u = u_0 + \varepsilon u_1 + \varepsilon^2 u_2 + \cdots, \quad (22.161)$$

$$\Omega^2 = 6 + \varepsilon \sigma_1 + \varepsilon^2 \sigma_2 + \cdots. \quad (22.162)$$

初值逐阶为

$$u_0(0) = 1, \quad u'_0(0) = 0, \quad (22.163)$$

$$u_n(0) = 0, \quad u'_n(0) = 0, \quad n \geq 1. \quad (22.164)$$



零阶方程:

$$6(u_0'' + u_0) = 0. \quad (22.165)$$

故

$$\boxed{u_0(\tau) = \cos \tau}. \quad (22.166)$$

□

第 (b) 问第六步: 一阶方程.  $\varepsilon$  一阶方程为

$$6(u_1'' + u_1) + \sigma_1 u_0'' + 5u_0^2 = 0. \quad (22.167)$$

由于  $u_0'' = -\cos \tau$  以及  $u_0^2 = \frac{1}{2}(1 + \cos 2\tau)$ , 有

$$u_1'' + u_1 = \frac{\sigma_1}{6} \cos \tau - \frac{5}{12} - \frac{5}{12} \cos 2\tau. \quad (22.168)$$

为消除  $\cos \tau$  共振项, 必须取

$$\boxed{\sigma_1 = 0}. \quad (22.169)$$

解  $u_1'' + u_1 = -\frac{5}{12} - \frac{5}{12} \cos 2\tau$  并使用  $u_1(0) = u_1'(0) = 0$  得到

$$\boxed{u_1(\tau) = \frac{5}{18} \cos \tau - \frac{5}{12} + \frac{5}{36} \cos 2\tau}. \quad (22.170)$$

□

第 (b) 问第七步: 二阶可解性条件.  $\varepsilon^2$  阶方程为

$$6(u_2'' + u_2) + \sigma_2 u_0'' + 10u_0 u_1 + u_0^3 = 0. \quad (22.171)$$

即

$$u_2'' + u_2 = \frac{\sigma_2}{6} \cos \tau - \frac{5}{3} u_0 u_1 - \frac{1}{6} u_0^3. \quad (22.172)$$

由 式 (22.166) and (22.170):

$$u_0 u_1 = \frac{5}{36} - \frac{25}{72} \cos \tau + \frac{5}{36} \cos 2\tau + \frac{5}{72} \cos 3\tau. \quad (22.173)$$

并且

$$u_0^3 = \cos^3 \tau = \frac{3}{4} \cos \tau + \frac{1}{4} \cos 3\tau. \quad (22.174)$$

因此二阶右端的  $\cos \tau$  系数为

$$\frac{\sigma_2}{6} + \frac{125}{216} - \frac{1}{8} = \frac{\sigma_2}{6} + \frac{49}{108}. \quad (22.175)$$

周期可解性要求该系数为零:

$$\frac{\sigma_2}{6} + \frac{49}{108} = 0. \quad (22.176)$$


故

$$\boxed{\sigma_2 = -\frac{49}{18}}. \quad (22.177)$$

于是

$$\boxed{\Omega^2 = 6 - \frac{49}{18} \varepsilon^2 + O(\varepsilon^3)}. \quad (22.178)$$

□



第 (b) 问第八步: 频率和周期. 由  $\Omega = \sqrt{6 - \frac{49}{18}\varepsilon^2 + O(\varepsilon^3)}$ , 提出  $\sqrt{6}$ :

$$\begin{aligned}\Omega &= \sqrt{6} \sqrt{1 - \frac{49}{108}\varepsilon^2 + O(\varepsilon^3)} \\ &= \sqrt{6} \left[ 1 - \frac{49}{216}\varepsilon^2 + O(\varepsilon^3) \right].\end{aligned}\quad (22.179)$$

周期为  $T(\varepsilon) = \frac{2\pi}{\Omega}$ . 使用  $(1-z)^{-1} = 1+z+O(z^2)$  得到

$$T(\varepsilon) = \frac{2\pi}{\sqrt{6}} \left[ 1 + \frac{49}{216}\varepsilon^2 + O(\varepsilon^3) \right]. \quad (22.180)$$

因此非线性使该小振幅轨道的频率降低, 周期增大.  $\square$

注 22.6 (轨道的二阶近似). 由  $x = 2 + \varepsilon u$  以及  $u = u_0 + \varepsilon u_1 + O(\varepsilon^2)$ , 得到

$$\begin{aligned}x(t) &= 2 + \varepsilon \cos \tau \\ &\quad + \varepsilon^2 \left[ \frac{5}{18} \cos \tau - \frac{5}{12} + \frac{5}{36} \cos 2\tau \right] + O(\varepsilon^3),\end{aligned}\quad (22.181)$$

$$\tau = \sqrt{6} \left[ 1 - \frac{49}{216}\varepsilon^2 \right] t. \quad (22.182)$$

检查初值:

$$\begin{aligned}x(0) &= 2 + \varepsilon + \varepsilon^2 \left[ \frac{5}{18} - \frac{5}{12} + \frac{5}{36} \right] + O(\varepsilon^3) \\ &= 2 + \varepsilon + O(\varepsilon^3),\end{aligned}\quad (22.183)$$

$$\dot{x}(0) = 0. \quad (22.184)$$

括号中的二阶初值修正恰为零。

注 22.7 (与通用公式核对). 对  $\ddot{y} + 6y + 5y^2 + y^3 = 0$  有  $\omega_0^2 = 6$ ,  $\alpha = 5$ ,  $\beta = 1$ ,  $A = \varepsilon$ . 由式 (22.134):

$$\begin{aligned}\frac{3\beta}{8\omega_0^2} - \frac{5\alpha^2}{12\omega_0^4} &= \frac{3}{48} - \frac{125}{432} \\ &= -\frac{49}{216},\end{aligned}\quad (22.185)$$

与直接推导完全一致。

#### 易错点与反例

1. 只线性化而不证明轨道闭合;
2. 把  $x = 0$  误判为稳定中心;
3. 平移后把二次项系数 5 算错;
4. 忘记  $y = \varepsilon u$  后三次项变为  $\varepsilon^2 u^3$ ;
5. 把  $\Omega$  与  $\Omega^2$  的系数混用;
6. 一阶错误地认为二次非线性必产生频率修正;
7. 二阶漏掉  $10u_0u_1$  项;
8. 从  $\Omega^2$  开平方时漏掉因子  $1/2$ ;

9. 周期取倒数时符号未反转;
10. 只给周期公式而不说明  $\varepsilon \rightarrow 0$  和余项阶。

## 22.10 Poincaré–Lindstedt 法与多尺度法的区别

| 比较项                 | Poincaré–Lindstedt 法          | 多尺度法                                                         |
|---------------------|-------------------------------|--------------------------------------------------------------|
| 主要目标                | 修正单一周期轨道的频率                   | 描述振幅、相位在慢时间上的演化                                              |
| 时间变量                | $\tau = \Omega(\varepsilon)t$ | $T_0 = t, T_1 = \varepsilon t, T_2 = \varepsilon^2 t, \dots$ |
| 未知慢量                | 通常只有频率系数                      | 振幅函数、相位函数、调制方程                                               |
| 典型对象                | 弱非线性保守振子、闭轨道                  | 阻尼、外力、近共振、调制、长时间衰减                                           |
| 消除 secular term 的结果 | 代数方程确定频率修正                    | 微分方程确定慢振幅和慢相位                                                |
| 解的形式                | 周期函数的幂级数                      | 快振荡乘慢变包络                                                     |
| 主要失败情形              | 真实振幅随时间漂移; 多频率共振; 接近分离曲线      | 慢变量选择不足; 共振尺度判断错误; 更长时间需增加尺度                                 |
| 正式题对应               | [26S-Q6]                      | [25S-Q6]、[25F-Q6], 将在第 24 部分处理                               |

### 易错点与反例

以下问题不宜只用 Poincaré–Lindstedt 法:

1. 弱阻尼导致振幅缓慢衰减;
2. 弱负阻尼和非线性饱和导致极限环形成;
3. 外力频率接近固有频率;
4. 多个模态发生内部共振;
5. 需要描述  $t = O(\varepsilon^{-1})$  上的振幅调制。

这些问题应使用多尺度法或平均法。

## 22.11 有效区间、残量、相位误差与失败情形

### 22.11.1 知识点二十一: 截断频率导致的相位误差

设真实频率为  $\Omega(\varepsilon) = \Omega^{[N]}(\varepsilon) + O(\varepsilon^{N+1})$ 。则经过时间  $t$ , 相位误差为

$$\Delta\theta(t) = [\Omega - \Omega^{[N]}] t = O(\varepsilon^{N+1}t). \quad (22.186)$$

要保持相位误差小, 需要

$$\varepsilon^{N+1}t \ll 1. \quad (22.187)$$



因此:

- Poincaré-Lindstedt 展开消除了低阶 secular term;
- 各阶系数在伸缩时间  $\tau$  中保持有界;
- 但截断频率仍会在极长时间上累积相位误差;
- “系数有界”不自动等于“对所有  $t \geq 0$  一致精确”。

### 22.11.2 知识点二十二: 接近分离曲线时周期展开失效

对一维保守系统  $\ddot{x} + V'(x) = 0$ , 若能量趋近鞍点能量  $E \rightarrow E_s$ , 轨道接近分离曲线, 周期通常满足

$$T(E) \sim C |\log |E - E_s||. \quad (22.188)$$

此时:

- 周期不再接近有限线性周期;
- 小振幅 Taylor 展开失效;
- Poincaré-Lindstedt 系数可能增长;
- 应改用鞍点附近的局部渐近或椭圆积分展开。

### 22.11.3 知识点二十三: 残量小与解误差小的区别

构造近似  $u^{[N]}$  后, 残量  $\mathcal{R}_N = \mathcal{F}(u^{[N]}, \varepsilon)$  很小, 只说明近似满足方程到高阶。

要推出  $u - u^{[N]}$  很小, 还需要稳定性或可逆性估计:

$$\|u - u^{[N]}\|_X \leq C_{\text{stab}} \|\mathcal{R}_N\|_Y. \quad (22.189)$$

当  $C_{\text{stab}}$  随  $\varepsilon$  或时间区间增大时, 小残量未必对应同阶小误差。

这与数值分析中的 残差小  $\not\Rightarrow$  误差小 是同一结构。

## 22.12 正则摄动与频率修正的易错点及答题模板

| 错误说法或错误做法                             | 正确处理                                    |
|---------------------------------------|-----------------------------------------|
| 小参数出现就一定能用整数幂展开。                      | 先检查 Jacobian、线性化算子、根重数和主导平衡。            |
| 正则摄动表示展开对所有时间一致。                      | 通常只保证固定时间区间; 长时间需检查 secular term 和相位误差。 |
| 残量为 $O(\varepsilon^{N+1})$ 就自动有同阶解误差。 | 还需稳定性、可逆性或 Grönwall 估计。                 |
| 每阶线性算子都不同。                            | 标准正则摄动中每阶通常使用同一个零阶线性化算子。                |
| 线性算子有核时仍直接求逆。                         | 先施加 Fredholm 可解性条件, 再在补空间上求解。           |

| 错误说法或错误做法                       | 正确处理                                |
|---------------------------------|-------------------------------------|
| 自伴问题和非自伴问题使用同一核。                | 非自伴问题必须使用伴随核 $\ker L^*$ 。           |
| 简单矩阵特征值一阶修正只需右特征向量。             | 非 Hermitian 问题需要左右特征向量。             |
| 重特征值也可直接写 $x^* B x$ 。           | 应在原重特征子空间内对 $X^* B X$ 对角化。          |
| 一阶特征值修正为零说明特征值完全不变。             | 还需检查二阶及更高阶修正。                       |
| 特征值展开与特征向量归一化无关。                | 特征值修正不依赖向量缩放，但特征向量修正必须加规范条件。        |
| 谱间隙小只影响数值算法，不影响摄动展开。            | 谱间隙进入特征向量修正和高阶余项常数。                 |
| secular term 表示真实振幅必然增长。        | 它可能只是频率或相位展开方式不当。                   |
| Poincaré-Lindstedt 只展开解，不展开频率。  | 频率必须与解同时展开。                         |
| 消除一个共振项后即可停止。                   | 周期核通常含 $\cos \tau, \sin \tau$ 两个方向。 |
| 二次非线性一定给出一阶频率修正。                | 纯二次项在基本余弦振子中一阶只产生常数和二次谐波。           |
| 由 $\Omega^2$ 得到 $\Omega$ 时系数不变。 | 开平方会产生因子 $1/2$ 及交叉项。                |
| 周期修正与频率修正符号相同。                  | 周期是频率的倒数，一阶相对修正符号相反。                |
| 闭轨道只需线性化特征值为纯虚数。                | 完整证明还应使用能量、中心定理或局部积分结构。             |
| 小振幅周期展开可延伸到分离曲线。                | 靠近鞍点能量时周期通常对数发散。                    |



## 第二十三章 奇异摄动、边界层、内外解、匹配与复合展开

### 23.1 奇异摄动的定义、识别信号与问题分类

#### 23.1.1 知识点一：正则摄动与奇异摄动的本质区别

【重要性等级】 **S 级**。判断一个含小参数问题是否为奇异摄动，不能只看“是否出现  $\varepsilon$ ”；应考察极限  $\varepsilon \rightarrow 0$  是否改变问题的类型、阶数、边界条件数目或解空间结构。

考虑算子方程

$$\mathcal{F}_\varepsilon u_\varepsilon = f_\varepsilon. \quad (23.1)$$

若极限算子  $\mathcal{F}_0$  与  $\mathcal{F}_\varepsilon$  具有相同的微分阶数，且极限问题满足全部初边条件并保持一致可逆性，通常属于正则摄动。

若出现以下任一现象，则通常属于奇异摄动：

1. 小参数乘最高阶导数，令  $\varepsilon = 0$  后方程降阶；
2. 极限问题只能满足原问题的一部分边界条件；
3. 解在宽度  $\delta(\varepsilon) \rightarrow 0$  的窄区域内快速变化；
4. 解或其导数在参数极限下不一致有界；
5. 线性化算子的逆范数随  $\varepsilon \rightarrow 0$  发散；
6. 出现内部转向点、初始层、冲击层或快速过渡层。

典型二阶边值问题为


$$\begin{cases} \varepsilon y'' + a(x)y' + b(x)y = f(x), & \alpha < x < \beta, \\ y(\alpha) = A, y(\beta) = B, \end{cases} \quad 0 < \varepsilon \ll 1. \quad (23.2)$$

令  $\varepsilon = 0$  后得到一阶约化问题

$$a(x)y'_0(x) + b(x)y_0(x) = f(x), \quad (23.3)$$

它通常只能独立满足一个边界条件。另一个边界条件必须通过边界层修正。

**定义 23.1 (边界层)**. 若存在  $\delta(\varepsilon) \rightarrow 0$  及边界点  $x_0 \in \{\alpha, \beta\}$ ，使得解在区域  $|x - x_0| = O(\delta(\varepsilon))$  内发生  $O(1)$  或显著的快速变化，而在远离该区域时具有不同的慢变渐近展开，则称该区域为边界层， $\delta(\varepsilon)$  称为边界层厚度。





定义 **23.2** (内部层). 若快速过渡发生在  $x_0 \in (\alpha, \beta)$  的内部点附近, 则称为内部层。内部层常由以下机制引起:

- 对流系数  $a(x)$  在  $x_0$  变号或消失;
- 两个外部解分支需要连接;
- 非线性约化方程存在多个稳定分支;
- 守恒律中形成黏性冲击层。

定义 **23.3** (初始层). 对时间问题, 若初值与约化方程所要求的慢流形初值不相容, 解在  $t = O(\delta(\varepsilon))$  内快速调整, 则称该区域为初始层。

#### 易错点与反例

“小参数乘最高阶导数”是强识别信号, 但不保证一定出现  $O(1)$  边界层。

若约化解恰好满足全部边界条件, 则首项边界层振幅可能为零。此时仍是奇异摄动问题, 但可见边界层可能只出现在更高阶导数或更高阶修正中。

### 23.1.2 知识点二：四类典型快速区域

| 类型   | 典型原因                     | 快变量                             | 匹配方向                                                   |
|------|--------------------------|---------------------------------|--------------------------------------------------------|
| 左边界层 | 约化解不满足 $x = \alpha$ 处边界值 | $\xi = \frac{x-\alpha}{\delta}$ | $\xi \rightarrow +\infty$                              |
| 右边界层 | 约化解不满足 $x = \beta$ 处边界值  | $\eta = \frac{\beta-x}{\delta}$ | $\eta \rightarrow +\infty$                             |
| 内部层  | $a(x_0) = 0$ 、分支连接或冲击层   | $z = \frac{x-x_0}{\delta}$      | $z \rightarrow -\infty$ 与 $z \rightarrow +\infty$ 分别匹配 |
| 初始层  | 初值与约化慢解不相容               | $\tau = \frac{t}{\delta}$       | $\tau \rightarrow +\infty$                             |

## 23.2 外部展开：约化方程、递推关系与边界条件选择

### 23.2.1 知识点三：线性二阶问题的外部递推

对式 (23.2), 设在远离快速层的区域中


$$y_{\text{out}}(x; \varepsilon) \sim \sum_{n=0}^{\infty} \varepsilon^n y_n(x). \quad (23.4)$$

代入原方程并比较  $\varepsilon$  幂次:

$$O(1): \quad a(x)y_0'(x) + b(x)y_0(x) = f(x), \quad (23.5)$$

$$O(\varepsilon^n): \quad a(x)y_n'(x) + b(x)y_n(x) = -y_{n-1}''(x), \quad n \geq 1. \quad (23.6)$$

因此每一阶外部系数都满足一阶线性方程。



若  $a(x) \neq 0$ , 定义积分因子

$$\mu(x) = \exp \left( \int^x \frac{b(s)}{a(s)} ds \right). \quad (23.7)$$

则

$$\frac{d}{dx} [\mu(x)y_n(x)] = \mu(x) \frac{r_n(x)}{a(x)}, \quad (23.8)$$

其中  $r_0 = f$ ,  $r_n = -y_{n-1}''$ ,  $n \geq 1$ 。

### 23.2.2 知识点四：哪一个边界条件应分配给外部问题

考虑  $\varepsilon y'' + a(x)y' + b(x)y = f$ 。在左端点  $x = \alpha$  附近令  $\xi = \frac{x-\alpha}{\varepsilon}$ 。若  $a(\alpha) \neq 0$ , 领先内层齐次方程为

$$Y_{\xi\xi} + a(\alpha)Y_{\xi} = 0. \quad (23.9)$$

其快速模态为

$$\exp[-a(\alpha)\xi]. \quad (23.10)$$

因为区域内部对应  $\xi \rightarrow +\infty$ , 该模态衰减的条件是

$$\boxed{a(\alpha) > 0}. \quad (23.11)$$

在右端点令  $\eta = \frac{\beta-x}{\varepsilon}$ 。领先内层齐次方程为

$$Y_{\eta\eta} - a(\beta)Y_{\eta} = 0, \quad (23.12)$$

其快速模态为  $\exp[a(\beta)\eta]$ 。衰减条件为

$$\boxed{a(\beta) < 0}. \quad (23.13)$$

因此, 对本文符号约定  $+\varepsilon y'' + a(x)y'$  有:

|                 |        |                |
|-----------------|--------|----------------|
| $a(x) > 0$ 于全区间 | 左端可能有层 | 外部问题通常使用右端边界条件 |
| $a(x) < 0$ 于全区间 | 右端可能有层 | 外部问题通常使用左端边界条件 |

(23.14)

#### 易错点与反例

边界层位置的符号规则依赖方程中最高阶项的符号。

若问题写成  $-\varepsilon y'' + a(x)y' + b(x)y = f$ , 则快速模态和左右层的符号判据相应改变。

不能脱离原方程符号, 机械背诵“入流边界”或“出流边界”。最稳妥的方法是重新写出快变量方程并检查指数模态是否衰减。

### 23.2.3 知识点五：约化方程在转向点处失效

若  $a(x_0) = 0$ ,  $x_0 \in (\alpha, \beta)$ , 则约化方程  $a(x)y'_0 + b(x)y_0 = f$  在  $x_0$  处可能退化。

此时可能需要:

1. 在  $(\alpha, x_0)$  和  $(x_0, \beta)$  分别求外部解;
2. 使用左右边界条件分别确定两个外部解分支;
3. 在  $x_0$  附近构造内部层;
4. 通过  $z \rightarrow -\infty$  与  $z \rightarrow +\infty$  的双向匹配连接两侧。



## 23.3 边界层尺度：主导平衡与快变量选择

### 23.3.1 知识点六：统一尺度方程

在候选快速点  $x_0$  附近令

$$x = x_0 + \delta(\varepsilon)z, \quad Y(z; \varepsilon) = y(x_0 + \delta z; \varepsilon). \quad (23.15)$$

则

$$y' = \delta^{-1}Y_z, \quad (23.16)$$

$$y'' = \delta^{-2}Y_{zz}. \quad (23.17)$$

原方程变为

$$\frac{\varepsilon}{\delta^2}Y_{zz} + \frac{a(x_0 + \delta z)}{\delta}Y_z + b(x_0 + \delta z)Y = f(x_0 + \delta z). \quad (23.18)$$

层厚  $\delta$  由至少两个主导机制同阶确定。

### 23.3.2 知识点七：常见尺度表

| 局部结构                                                      | 主导平衡                                                 | 层厚                            | 领先内层方程                             |
|-----------------------------------------------------------|------------------------------------------------------|-------------------------------|------------------------------------|
| $\varepsilon y'' + a_0 y' + \cdots = 0, \quad a_0 \neq 0$ | $\frac{\varepsilon}{\delta^2} \sim \frac{1}{\delta}$ | $\delta = \varepsilon$        | $Y_{zz} + a_0 Y_z = 0$             |
| $\varepsilon y'' - c_0 y + \cdots = 0, \quad c_0 > 0$     | $\frac{\varepsilon}{\delta^2} \sim 1$                | $\delta = \sqrt{\varepsilon}$ | $Y_{zz} - c_0 Y = 0$               |
| $\varepsilon y'' + a'(x_0)(x - x_0)y' + b_0 y = 0$        | 三项均可能同阶                                              | $\delta = \sqrt{\varepsilon}$ | $Y_{zz} + a'(x_0)zY_z + b_0 Y = 0$ |
| $\varepsilon y' + a_0 y = f_0$                            | $\frac{\varepsilon}{\delta} \sim 1$                  | $\delta = \varepsilon$        | $Y_\tau + a_0 Y = f_0$             |

### 23.3.3 知识点八：退化对流系数的非整数层厚

若

$$a(x) \sim c(x - x_0)^m, \quad c \neq 0, \quad m > 0, \quad (23.19)$$

则对流项尺度为  $\frac{a(x_0 + \delta z)}{\delta} = O(\delta^{m-1})$ 。若二阶导数与该对流项主导平衡：  $\frac{\varepsilon}{\delta^2} \sim \delta^{m-1}$ ，则

$$\boxed{\delta = \varepsilon^{1/(m+1)}}. \quad (23.20)$$

但必须继续检查零阶项：

- 若  $0 < m < 1$ ，导数项系数趋大，零阶项常为低阶；
- 若  $m = 1$ ，零阶项与两个导数项可能同时为  $O(1)$ ；
- 若  $m > 1$ ，零阶项可能比对流项更重要，此时应重新比较  $\varepsilon/\delta^2 \sim 1$  并可能得到  $\delta = \sqrt{\varepsilon}$ 。



## 边界层缩放：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 约化问题降阶；
- 约化解不满足某个边界条件；
- 外部展开系数在某点发散；
- 对流系数在某点消失或变号。

构造步骤：

1. 令  $x = x_0 + \delta z$ ;
2. 将每一项写成  $\delta$  和  $\varepsilon$  的数量级；
3. 选取至少两个主导项平衡；
4. 检查其余项确实不更大；
5. 写出领先内层方程；
6. 检查其是否存在向区域内部衰减的模式；
7. 若不存在，说明所选边界或尺度不正确。

关键估计：若层函数形如  $e^{-c(x-x_0)/\delta}$ ,  $c > 0$ , 则  $\frac{d^k}{dx^k} e^{-c(x-x_0)/\delta} = O(\delta^{-k})e^{-c(x-x_0)/\delta}$ 。

结论：得到层厚、快变量和领先内层算子。

常见失败原因：

- 无条件认定  $\delta = \varepsilon$ ;
- 只平衡两项，却忽略更大的第三项；
- 快变量方向写反，导致指数增长；
- 未检查边界数据失配是否真的非零；
- 内部转向点仍使用端点边界层公式。

## 23.4 匹配原则、重叠区与一致复合展开

## 23.4.1 知识点九：为什么不能只令两个近似在某一点相等

设左边界层厚度为  $\delta(\varepsilon)$ 。外部展开在固定  $x > 0$  下有效，内层展开在固定  $z = \frac{x}{\delta}$  下有效。

不存在一个固定  $x$  同时满足：

$x = O(1)$ ,  $z = O(1)$ , 因此匹配不能简单地在某个固定点令  $y_{\text{out}} = y_{\text{in}}$ 。

应引入中间尺度

$$x = \chi(\varepsilon)\omega, \quad \delta(\varepsilon) \ll \chi(\varepsilon) \ll 1. \quad (23.21)$$

于是

$$x \rightarrow 0, \quad z = \frac{x}{\delta} = \frac{\chi}{\delta}\omega \rightarrow +\infty. \quad (23.22)$$

该区域称为重叠区。



## 23.4.2 知识点十：领先阶匹配

若

$$y_{\text{out}} \sim y_0(x) + \cdots, \quad (23.23)$$

$$y_{\text{in}} \sim Y_0(z) + \cdots, \quad (23.24)$$

则领先阶匹配通常写为

$$\lim_{z \rightarrow +\infty} Y_0(z) = \lim_{x \rightarrow x_0^+} y_0(x). \quad (23.25)$$

对内部层，应分别满足

$$\lim_{z \rightarrow -\infty} Y_0(z) = \lim_{x \rightarrow x_0^-} y_0^L(x), \quad (23.26)$$

$$\lim_{z \rightarrow +\infty} Y_0(z) = \lim_{x \rightarrow x_0^+} y_0^R(x). \quad (23.27)$$

## 23.4.3 知识点十一：高阶匹配与 Van Dyke 原则

高阶内解常含  $z$ ,  $z^2$ ,  $\log z$  等增长项，不能只取简单极限。

设：

- $\mathcal{E}_{\text{in}}$  表示把外解写成快变量并在  $x = x_0 + \delta z$  下展开；
- $\mathcal{E}_{\text{out}}$  表示把内解在  $z \rightarrow \infty$  下展开并改写回慢变量。

Van Dyke 匹配原则写为

$$\mathcal{E}_{\text{out}} \mathcal{E}_{\text{in}} y_{\text{out}} = \mathcal{E}_{\text{in}} \mathcal{E}_{\text{out}} y_{\text{in}}. \quad (23.28)$$

实际答题时，应：

1. 取中间尺度  $x - x_0 = \chi(\varepsilon)\omega$ ;
2. 将内外截断展开都改写为  $(\omega, \varepsilon)$  的表达式；
3. 按同一渐近序列比较系数；
4. 确定内解中的待定常数。

## 23.4.4 知识点十二：公共部分与加法复合展开

设外解和内解在重叠区的公共部分为  $y_{\text{match}}$ 。加法复合展开为

$$y_{\text{comp}} = y_{\text{out}} + y_{\text{in}} - y_{\text{match}}. \quad (23.29)$$

减去公共部分是为了避免在重叠区重复计数。

若左右两端分别有非重叠边界层，则领先复合形式为

$$y_{\text{comp}} = y_{\text{out}} + y_L + y_R - y_{\text{match,L}} - y_{\text{match,R}}. \quad (23.30)$$

若两层尾部在目标精度下不可忽略，还需加入层间相互作用项，不能机械相加。

**Algorithm 81** 匹配渐近展开的标准构造流程

**Input:** 含小参数的微分方程；初边条件；目标渐近阶数；目标范数与有效区域

**Output:** 外部展开、内层展开、公共部分、复合展开和误差阶

- 1: **Initialization:** 令  $\varepsilon = 0$ , 建立约化问题; 记录被丢失的微分阶数和不能满足的初边条件
- 2: 构造外部级数并逐阶求解
- 3: 根据边界失配、快速模态和系数符号定位候选层
- 4: **for** 每一个候选快速点  $x_j$  **do**
- 5:     令  $x = x_j + \delta_j z_j$
- 6:     通过主导平衡求  $\delta_j(\varepsilon)$
- 7:     构造内层渐近序列和逐阶方程
- 8:     用原始边界条件确定内解在  $z_j = 0$  处的数据
- 9:     在  $z_j \rightarrow \pm\infty$  方向与相邻外解匹配
- 10: **end for**
- 11: 选择中间尺度  $\delta_j \ll \chi_j \ll 1$  并求公共部分
- 12: 形成  $y_{\text{comp}} = \text{外解} + \sum \text{内解} - \sum \text{公共部分}$
- 13: 检查全部边界条件、残量和匹配条件
- 14: **Stopping criterion:** 复合残量和边界失配均达到目标阶; 所有层尾在目标精度下可忽略
- 15: **Complexity:** 若每阶外部和内部线性问题离散后规模为  $M$ , 目标阶数为  $N$ , 且矩阵分解可复用, 则典型成本为一次分解加  $O(N)$  次回代; 非线性卷积的符号生成通常为  $O(N^2)$

#### 易错点与反例

匹配不是  $Y_0(0) = y_0(x_0)$ 。其中:

- $Y_0(0)$  用于满足原边界条件;
- $Y_0(\infty)$  用于匹配外部解;
- 两者一般不同;
- 正是这一区别产生了边界层。

## 23.5 残量、稳定性与一致误差估计

### 23.5.1 知识点十三: 小残量何时推出小解误差

设复合近似为  $y_{\text{app}}$ , 定义残量

$$\mathcal{R}_\varepsilon = \mathcal{L}_\varepsilon y_{\text{app}} - f. \quad (23.31)$$

精确误差  $e = y - y_{\text{app}}$  满足


$$\mathcal{L}_\varepsilon e = -\mathcal{R}_\varepsilon. \quad (23.32)$$

若存在与  $\varepsilon$  无关的稳定性常数  $C$ , 使

$$\|e\|_X \leq C [\|\mathcal{L}_\varepsilon e\|_Y + \text{边界误差}], \quad (23.33)$$

则  $\mathcal{R}_\varepsilon = O(\rho(\varepsilon))$  及同阶边界失配推出  $e = O(\rho(\varepsilon))$ 。

若稳定性常数随  $\varepsilon^{-1}$  增长, 则残量阶不能直接等同于解误差阶。



## 23.5.2 知识点十四：带负零阶项问题的最大范数稳定性

命题 23.4 (一维最大范数稳定估计). 设

$$\mathcal{L}_\varepsilon v = \varepsilon v'' + a(x, \varepsilon)v' - c(x, \varepsilon)v, \quad (23.34)$$

其中  $\varepsilon > 0$ ,  $c(x, \varepsilon) \geq c_0 > 0$ . 若  $\mathcal{L}_\varepsilon v = r$  且  $v(\alpha) = g_\alpha$ ,  $v(\beta) = g_\beta$ , 则

$$\|v\|_{L^\infty(\alpha, \beta)} \leq \max \left\{ |g_\alpha|, |g_\beta|, \frac{\|r\|_{L^\infty}}{c_0} \right\}. \quad (23.35)$$

证明. 若正最大值在内部点  $x_*$  取得, 则  $v'(x_*) = 0$ ,  $v''(x_*) \leq 0$ . 因此  $r(x_*) = \mathcal{L}_\varepsilon v(x_*) \leq -c_0 v(x_*)$ . 故  $v(x_*) \leq \frac{\|r\|_{L^\infty}}{c_0}$ .

若负最小值在内部点取得, 则对  $-v$  应用同一论证. 若极值位于边界, 则由边界数据控制.  $\square$

注 23.5. 该估计对一阶导数系数  $a$  没有符号要求, 因为在内部极值点  $v' = 0$ .

但若零阶项没有严格负号, 则不能无条件使用该估计; 需要构造障碍函数、能量估计或其他一致稳定性理论。

## 23.5.3 知识点十五：函数误差与导数误差必须分开

若层宽为  $\delta$ , 层函数振幅误差为  $O(\rho)$ , 则其导数误差通常满足

$$\frac{d^k}{dx^k} O(\rho) = O\left(\frac{\rho}{\delta^k}\right) \quad \text{在层内}. \quad (23.36)$$

因此即使  $\|y - y_{\text{comp}}\|_\infty = O(\varepsilon)$ , 也不能自动断言  $\|y' - y'_{\text{comp}}\|_\infty = O(\varepsilon)$ .

资格考试中若题目要求一致误差, 必须说明所用范数。

## 23.6 课程例题：常系数问题的精确解、左边界层与一阶复合展开

完整题目叙述: [AppAna-Shi-9.2]

考虑

$$\begin{cases} \varepsilon y'' + (1 - \varepsilon)y' - (1 - \varepsilon)y = 0, & 0 < x < 1, \\ y(0) = 1, y(1) = 1, \end{cases} \quad 0 < \varepsilon \ll 1. \quad (23.37)$$

1. 求精确解;
2. 构造外部展开;
3. 构造左边界层内部展开;
4. 建立领先阶及一阶复合展开;
5. 说明误差阶。

第一步：精确解. 特征方程为

$$\varepsilon m^2 + (1 - \varepsilon)m - (1 - \varepsilon) = 0. \quad (23.38)$$

其根为

$$m_\pm(\varepsilon) = \frac{\varepsilon - 1 \pm \sqrt{1 + 2\varepsilon - 3\varepsilon^2}}{2\varepsilon}. \quad (23.39)$$



精确解写为

$$y(x; \varepsilon) = C_+ e^{m_+ x} + C_- e^{m_- x}, \quad (23.40)$$

其中

$$C_+ = \frac{1 - e^{m_-}}{e^{m_+} - e^{m_-}}, \quad (23.41)$$

$$C_- = \frac{e^{m_+} - 1}{e^{m_+} - e^{m_-}}. \quad (23.42)$$

当  $\varepsilon \rightarrow 0^+$  时,

$$m_+ = 1 - \varepsilon + \varepsilon^2 + O(\varepsilon^3), \quad (23.43)$$

$$m_- = -\frac{1}{\varepsilon} + \varepsilon + O(\varepsilon^2). \quad (23.44)$$

因此一个模态在  $O(1)$  尺度变化, 另一个模态在  $x = O(\varepsilon)$  内快速衰减。□

第二步: 外部展开. 设  $y_{\text{out}} = y_0 + \varepsilon y_1 + \cdots$ . 零阶方程为  $y'_0 - y_0 = 0$ . 因为  $a(x) = 1 > 0$ , 左端可能有边界层, 外部问题应使用右端条件  $y_0(1) = 1$ . 故

$$\boxed{y_0(x) = e^{x-1}}. \quad (23.45)$$

它在左端给出  $y_0(0) = e^{-1} \neq 1$ , 确认左边界层存在。

一阶方程为  $y'_1 - y_1 = -y''_0$ ,  $y_1(1) = 0$ . 因为  $y''_0 = e^{x-1}$ , 解得

$$\boxed{y_1(x) = (1-x)e^{x-1}}. \quad (23.46)$$

因此

$$y_{\text{out}} = e^{x-1} + \varepsilon(1-x)e^{x-1} + O(\varepsilon^2). \quad (23.47)$$

□

第三步: 内部展开. 取  $z = \frac{x}{\varepsilon}$ ,  $Y(z; \varepsilon) = y(\varepsilon z; \varepsilon)$ . 原方程乘以  $\varepsilon$  后变为

$$Y_{zz} + (1 - \varepsilon)Y_z - \varepsilon(1 - \varepsilon)Y = 0. \quad (23.48)$$

设  $Y = Y_0 + \varepsilon Y_1 + \cdots$ . 零阶方程为

$$Y''_0 + Y'_0 = 0. \quad (23.49)$$

边界条件和匹配条件为

$$Y_0(0) = 1, \quad (23.50)$$

$$\lim_{z \rightarrow +\infty} Y_0(z) = \lim_{x \rightarrow 0^+} y_0(x) = e^{-1}. \quad (23.51)$$

所以

$$\boxed{Y_0(z) = e^{-1} + (1 - e^{-1})e^{-z}}. \quad (23.52)$$


一阶方程为

$$Y''_1 + Y'_1 = Y'_0 + Y_0 = e^{-1}. \quad (23.53)$$

由  $Y_1(0) = 0$  及高阶匹配条件  $Y_1(z) \sim e^{-1}(z+1)$ ,  $z \rightarrow +\infty$ , 得到

$$\boxed{Y_1(z) = e^{-1}(z+1 - e^{-z})}. \quad (23.54)$$

□



第四步：公共部分与复合展开. 领先公共部分为  $y_{\text{match}}^{0,0} = e^{-1}$ . 故领先复合展开为

$$y_{\text{comp}}^{0,0}(x; \varepsilon) = e^{x-1} + (1 - e^{-1}) e^{-x/\varepsilon}. \quad (23.55)$$

为进行一阶匹配, 取  $x = \chi(\varepsilon)\omega$ ,  $\varepsilon \ll \chi \ll 1$ . 外解在重叠区为

$$y_{\text{out}} = e^{-1} + e^{-1}x + \varepsilon e^{-1} + o(\varepsilon) \quad (23.56)$$

在适当选择  $\varepsilon \log(\varepsilon^{-1}) \ll \chi \ll \sqrt{\varepsilon}$  时成立。

内解在重叠区具有相同公共部分

$$y_{\text{match}}^{1,1} = e^{-1} + e^{-1}x + \varepsilon e^{-1}. \quad (23.57)$$

所以一阶复合展开为

$$\begin{aligned} y_{\text{comp}}^{1,1} &= y_0 + \varepsilon y_1 + Y_0 + \varepsilon Y_1 - y_{\text{match}}^{1,1} \\ &= \left[ e^{x-1} + \varepsilon(1-x)e^{x-1} + [1 - e^{-1} - \varepsilon e^{-1}] e^{-x/\varepsilon} \right]. \end{aligned} \quad (23.58)$$

□

第五步：误差阶. 由精确根和系数的渐近展开可验证

$$\|y - y_{\text{comp}}^{0,0}\|_{\infty} = O(\varepsilon), \quad (23.59)$$

$$\|y - y_{\text{comp}}^{1,1}\|_{\infty} = O(\varepsilon^2). \quad (23.60)$$

注意：

- 领先复合解在  $x = 0$  精确满足边界条件；
- 在  $x = 1$  的边界失配为指数小量  $O(e^{-1/\varepsilon})$ ；
- 外部解单独在  $x = 0$  存在  $O(1)$  误差；
- 复合解将该误差限制在宽度  $O(\varepsilon)$  的左边界层内。

□

## 23.7 课程综合例题：一阶内外展开的系统匹配

完整题目叙述：[AppAna-Shi-9.3]

考虑

$$\begin{cases} \varepsilon y'' + (1 + x^2)y' + xy = 0, & -1 < x < 1, \\ y(-1) = 0, \quad y(1) = 2. \end{cases} \quad (23.61)$$

构造保留外部和内部一阶项的复合渐近展开。

第一步：确定边界层位置. 因为  $a(x) = 1 + x^2 > 0$  在整个区间严格为正, 根据式 (23.11), 只能在左端  $x = -1$  出现衰减边界层. 外部问题应使用右端条件  $y_n(1) = 0, \quad n \geq 1, \quad y_0(1) = 2$ . □

第二步：外部零阶解. 零阶方程为

$$(1+x^2)y'_0 + xy_0 = 0, \quad y_0(1) = 2. \quad (23.62)$$

积分得到

$$y_0(x) = 2\sqrt{\frac{2}{1+x^2}}. \quad (23.63)$$

特别地,  $y_0(-1) = 2 \neq 0$ , 故左端边界层振幅为  $O(1)$ .  $\square$

第三步：外部一阶解. 一阶方程为

$$(1+x^2)y'_1 + xy_1 = -y''_0, \quad y_1(1) = 0. \quad (23.64)$$

积分因子为  $\sqrt{1+x^2}$ . 因此

$$y_1(x) = \frac{1}{\sqrt{1+x^2}} \int_x^1 \frac{y''_0(s)}{\sqrt{1+s^2}} ds. \quad (23.65)$$

化简得到

$$y_1(x) = \frac{1}{16} \sqrt{\frac{2}{1+x^2}} \left[ \frac{24x}{(1+x^2)^2} + \frac{4x}{1+x^2} + 4 \arctan x - 8 - \pi \right]. \quad (23.66)$$

在左端

$$y_1(-1) = -\frac{8+\pi}{8}. \quad (23.67)$$

$\square$

第四步：内部零阶和一阶方程. 令  $z = \frac{x+1}{\varepsilon}$ ,  $Y(z; \varepsilon) = y(-1 + \varepsilon z; \varepsilon)$ . 方程变为

$$Y_{zz} + (2 - 2\varepsilon z + \varepsilon^2 z^2) Y_z + (-\varepsilon + \varepsilon^2 z) Y = 0. \quad (23.68)$$

设  $Y = Y_0 + \varepsilon Y_1 + \dots$ . 零阶方程为

$$Y''_0 + 2Y'_0 = 0, \quad Y_0(0) = 0. \quad (23.69)$$

故

$$Y_0(z) = C_1 (1 - e^{-2z}). \quad (23.70)$$

一阶方程为

$$Y''_1 + 2Y'_1 = 2zY'_0 + Y_0, \quad Y_1(0) = 0. \quad (23.71)$$

其满足边界条件的通解可写为

$$Y_1(z) = \frac{C_1}{4}(2z-1) + d_1 - \left[ \frac{C_1}{4}(4z^2+2z+1) + d_1 - \frac{C_1}{2} \right] e^{-2z}. \quad (23.72)$$


$\square$

第五步：高阶匹配. 取中间尺度  $x = -1 + \chi(\varepsilon)\omega$ , 满足

$$\varepsilon \log(\varepsilon^{-1}) \ll \chi(\varepsilon) \ll \sqrt{\varepsilon}. \quad (23.73)$$

外部展开在重叠区为

$$y_0 + \varepsilon y_1 = 2 + \chi\omega - \frac{8+\pi}{8}\varepsilon + o(\varepsilon). \quad (23.74)$$



另一方面,  $z = \frac{\chi\omega}{\varepsilon} \rightarrow +\infty$ , 所以内解为

$$Y_0 + \varepsilon Y_1 = C_1 + \frac{C_1}{2}\chi\omega + \varepsilon \left( d_1 - \frac{C_1}{4} \right) + o(\varepsilon). \quad (23.75)$$

比较得到

$$C_1 = 2, \quad (23.76)$$

$$d_1 - \frac{1}{2} = -\frac{8+\pi}{8}, \quad (23.77)$$

故

$$d_1 = -\frac{1}{2} - \frac{\pi}{8}. \quad (23.78)$$

公共部分为

$$y_{\text{match}}^{1,1} = x + 3 - \frac{8+\pi}{8}\varepsilon. \quad (23.79)$$

□

第六步：一阶复合展开. 令  $z = \frac{x+1}{\varepsilon}$ , 取  $C_1 = 2$ ,  $d_1 = -\frac{1}{2} - \frac{\pi}{8}$ . 则一阶复合展开为

$$y_{\text{comp}}^{1,1} = y_0(x) + \varepsilon y_1(x) + Y_0(z) + \varepsilon Y_1(z) - \left[ x + 3 - \frac{8+\pi}{8}\varepsilon \right]. \quad (23.80)$$

它具有以下性质：

1. 在  $x = -1$  处满足  $y_{\text{comp}}^{1,1}(-1) = 0$ ;
2. 在  $x = 1$  处的边界误差为指数小量;
3. 在外部区域退化为  $y_0 + \varepsilon y_1$ ;
4. 在边界层区域退化为  $Y_0 + \varepsilon Y_1$ ;
5. 形式截断误差为下一阶  $O(\varepsilon^2)$ , 严格一致误差还需相应边值算子的  $\varepsilon$ -一致稳定估计。

□

## 23.8 退化边界层：非整数尺度 $\varepsilon^{3/4}$

完整题目叙述：[AppAna-Shi-Degenerate-Layer]

考虑

$$\begin{cases} \varepsilon y'' + 12x^{1/3}y' + y = 0, & 0 < x < 1, \\ y(0) = 1, y(1) = 1, \end{cases} \quad 0 < \varepsilon \ll 1. \quad (23.81)$$

构造领先一致复合展开, 并确定边界层厚度。

第一步：外部解. 在  $x > 0$  处,  $a(x) = 12x^{1/3} > 0$ , 因此左端可能有边界层, 外部问题使用右端条件。

约化方程为

$$12x^{1/3}y'_0 + y_0 = 0, \quad y_0(1) = 1. \quad (23.82)$$

积分得到

$$y_0(x) = \exp\left(\frac{1-x^{2/3}}{8}\right). \quad (23.83)$$



其左端极限为  $y_0(0^+) = e^{1/8} \neq 1$ . □

第二步：边界层尺度. 令  $x = \delta z$ . 各项尺度为

$$\varepsilon y'' \sim \frac{\varepsilon}{\delta^2}, \quad (23.84)$$

$$12x^{1/3}y' \sim 12\delta^{-2/3}, \quad (23.85)$$

$$y \sim 1. \quad (23.86)$$

平衡前两个导数项:  $\frac{\varepsilon}{\delta^2} \sim \delta^{-2/3}$ . 故

$$\boxed{\delta = \varepsilon^{3/4}}. \quad (23.87)$$

这时两个导数项均为  $O(\varepsilon^{-1/2})$ , 零阶项比它们低  $\varepsilon^{1/2}$  阶. □

第三步：内层方程. 令  $z = \frac{x}{\varepsilon^{3/4}}$ ,  $Y(z; \varepsilon) = y(\varepsilon^{3/4}z; \varepsilon)$ . 乘以  $\varepsilon^{1/2}$  后, 方程为

$$Y_{zz} + 12z^{1/3}Y_z + \varepsilon^{1/2}Y = 0. \quad (23.88)$$

因此内层自然渐近序列为  $1, \varepsilon^{1/2}, \varepsilon, \dots$  而不是整数幂  $\varepsilon^n$ .

领先方程为

$$Y_0'' + 12z^{1/3}Y_0' = 0. \quad (23.89)$$

令  $V = Y_0'$ , 则  $V' + 12z^{1/3}V = 0$ , 故

$$V(z) = Ce^{-9z^{4/3}}. \quad (23.90)$$

由  $Y_0(0) = 1$ :

$$Y_0(z) = 1 + C \int_0^z e^{-9s^{4/3}} ds. \quad (23.91)$$

□

第四步：匹配. 需要  $\lim_{z \rightarrow +\infty} Y_0(z) = e^{1/8}$ . 又有

$$\int_0^\infty e^{-9s^{4/3}} ds = \frac{1}{4\sqrt{3}}\Gamma\left(\frac{3}{4}\right). \quad (23.92)$$

因此

$$C = \frac{4\sqrt{3}(e^{1/8} - 1)}{\Gamma(3/4)}. \quad (23.93)$$

设下不完全 Gamma 函数为

$$\gamma(a, \zeta) = \int_0^\zeta e^{-t}t^{a-1} dt. \quad (23.94)$$


则

$$\boxed{Y_0(z) = 1 + (e^{1/8} - 1) \frac{\gamma\left(\frac{3}{4}, 9z^{4/3}\right)}{\Gamma(3/4)}}. \quad (23.95)$$

□

第五步：复合展开. 公共部分为  $e^{1/8}$ . 所以领先一致复合展开为

$$\begin{aligned} y_{\text{comp}}(x; \varepsilon) &= y_0(x) + Y_0\left(\frac{x}{\varepsilon^{3/4}}\right) - e^{1/8} \\ &= \boxed{\exp\left(\frac{1-x^{2/3}}{8}\right) + 1 - e^{1/8} + (e^{1/8} - 1) \frac{\gamma\left(\frac{3}{4}, \frac{9x^{4/3}}{\varepsilon}\right)}{\Gamma(3/4)}}. \end{aligned} \quad (23.96)$$



由于首个被省略的内层项为  $O(\varepsilon^{1/2})$ , 该领先复合解的形式一致精度为

$$\boxed{O(\varepsilon^{1/2})}. \quad (23.97)$$

□

## 23.9 内部层：转向点两侧外解的连接

完整题目叙述：[AppAna-Shi-Internal-Layer]

考虑

$$\begin{cases} \varepsilon y'' + xy' - \left(1 + \frac{x}{4}\right)y = 0, & -1 < x < 1, \\ y(-1) = 3, y(1) = 1. \end{cases} \quad (23.98)$$

构造领先内部层及分片一致复合展开。

第一步：端点层排除与转向点识别. 这里  $a(-1) = -1 < 0$ ,  $a(1) = 1 > 0$ . 根据左右边界层衰减判据：

- 左端要求  $a(-1) > 0$ , 不成立;
- 右端要求  $a(1) < 0$ , 不成立。

所以两端都不存在标准  $O(\varepsilon)$  边界层。

但  $a(0) = 0$ , 约化方程在  $x = 0$  退化, 可能存在内部层。

□

第二步：左右外解. 对  $x < 0$ , 使用左边界条件：

$$xy_0^{L'} - \left(1 + \frac{x}{4}\right)y_0^L = 0, y_0^L(-1) = 3. \quad (23.99)$$

解得

$$\boxed{y_0^L(x) = -3xe^{(x+1)/4}}. \quad (23.100)$$

对  $x > 0$ , 使用右边界条件：

$$xy_0^{R'} - \left(1 + \frac{x}{4}\right)y_0^R = 0, y_0^R(1) = 1, \quad (23.101)$$

故

$$\boxed{y_0^R(x) = xe^{(x-1)/4}}. \quad (23.102)$$

两侧外解都满足  $\lim_{x \rightarrow 0^\pm} y_0^{L,R}(x) = 0$ , 但斜率不同：

$$y_0^L(x) \sim -3e^{1/4}x, \quad x \rightarrow 0^-, \quad (23.103)$$

$$y_0^R(x) \sim e^{-1/4}x, \quad x \rightarrow 0^+. \quad (23.104)$$

因此内部层主要修正导数和局部形状, 而不是连接一个  $O(1)$  函数值跳跃。

□

第三步：内部层尺度. 令  $x = \delta z$ . 各项尺度为  $\frac{\varepsilon}{\delta^2} Y_{zz}$ ,  $z Y_z$ ,  $Y$ . 平衡给出  $\frac{\varepsilon}{\delta^2} \sim 1$ , 故

$$\boxed{\delta = \sqrt{\varepsilon}}. \quad (23.105)$$

令  $q = \sqrt{\varepsilon}$ ,  $z = \frac{x}{q}$ . 因为外解在层内的振幅为  $O(q)$ , 写

$$y(x; \varepsilon) = qW_0(z) + O(q^2). \quad (23.106)$$



领先内层方程为

$$\boxed{W_0'' + zW_0' - W_0 = 0}. \quad (23.107)$$

□

第四步：内层通解及双向匹配. 一个解为  $W_1(z) = z$ . 定义

$$\Phi(z) = e^{-z^2/2} + z \int_{-\infty}^z e^{-s^2/2} ds. \quad (23.108)$$

直接微分可验证  $\Phi'' + z\Phi' - \Phi = 0$ . 并且

$$\Phi(z) \rightarrow 0, \quad z \rightarrow -\infty, \quad (23.109)$$

$$\Phi(z) \sim \sqrt{2\pi} z, \quad z \rightarrow +\infty. \quad (23.110)$$

因此

$$W_0(z) = Dz + C\Phi(z). \quad (23.111)$$

左匹配要求  $W_0(z) \sim -3e^{1/4}z$ ,  $z \rightarrow -\infty$ , 故

$$D = -3e^{1/4}. \quad (23.112)$$

右匹配要求  $W_0(z) \sim e^{-1/4}z$ ,  $z \rightarrow +\infty$ . 所以  $D + C\sqrt{2\pi} = e^{-1/4}$ , 即

$$\boxed{C = \frac{e^{-1/4} + 3e^{1/4}}{\sqrt{2\pi}}}. \quad (23.113)$$

□

第五步：分片复合展开. 左侧公共部分为  $-3e^{1/4}x$ , 右侧公共部分为  $e^{-1/4}x$ . 因此

$$y_{\text{comp}}(x; \varepsilon) = \begin{cases} y_0^L(x) + \sqrt{\varepsilon}W_0\left(\frac{x}{\sqrt{\varepsilon}}\right) + 3e^{1/4}x, & x < 0, \\ y_0^R(x) + \sqrt{\varepsilon}W_0\left(\frac{x}{\sqrt{\varepsilon}}\right) - e^{-1/4}x, & x > 0. \end{cases} \quad (23.114)$$

在  $x = 0$  处, 两侧表达式具有相同极限  $\sqrt{\varepsilon}W_0(0)$ , 故复合解连续。

首个被省略的内层项为  $O(\varepsilon)$ , 所以形式一致误差为

$$\boxed{O(\varepsilon)}. \quad (23.115)$$

□

## 23.10 初始层：快时间调整与慢流形匹配

基础例题：一阶线性初始层

考虑

$$\begin{cases} \varepsilon y'(t) + a(t)y(t) = f(t), & 0 < t \leq T, \\ y(0) = A, \end{cases} \quad (23.116)$$

其中  $a, f \in C^2[0, T]$ ,  $a(t) \geq a_* > 0$ . 构造领先复合展开。



证明. 约化方程为  $a(t)y_0(t) = f(t)$ , 故

$$y_0(t) = \frac{f(t)}{a(t)}. \quad (23.117)$$

通常  $y_0(0) \neq A$ , 因此存在初始层。

取快时间  $\tau = \frac{t}{\varepsilon}$ ,  $Y(\tau; \varepsilon) = y(\varepsilon\tau; \varepsilon)$ 。方程为

$$Y_\tau + a(\varepsilon\tau)Y = f(\varepsilon\tau). \quad (23.118)$$

领先方程

$$Y_0' + a(0)Y_0 = f(0), \quad Y_0(0) = A. \quad (23.119)$$

其解为

$$Y_0(\tau) = y_0(0) + [A - y_0(0)]e^{-a(0)\tau}. \quad (23.120)$$

当  $\tau \rightarrow +\infty$  时,  $Y_0 \rightarrow y_0(0)$ , 与外解匹配。

领先复合展开为

$$y_{\text{comp}}(t; \varepsilon) = \frac{f(t)}{a(t)} + \left[ A - \frac{f(0)}{a(0)} \right] \exp\left(-\frac{a(0)t}{\varepsilon}\right). \quad (23.121)$$

在给定光滑性和  $a(t) \geq a_* > 0$  条件下, 该领先复合展开具有  $O(\varepsilon)$  的一致函数误差。  $\square$

#### 易错点与反例

若  $a(0) < 0$ , 则  $e^{-a(0)t/\varepsilon}$  在正时间方向指数增长, 不存在向前衰减的稳定初始层。

这可能说明:

- 问题本身对前向初值不稳定;
- 应考虑终端层而不是初始层;
- 所选慢分支不是稳定慢流形。

## 23.11 正式真题 [24F-Q6]——双边 $\sqrt{\varepsilon}$ 边界层与一致精度

完整题目叙述: [24F-Q6]

考虑边值问题

$$\begin{cases} \varepsilon y'' + \varepsilon(1+x)^2 y' - y = x - 1, & 0 < x < 1, \\ y(0) = \alpha, \quad y(1) = -1, \end{cases} \quad 0 < \varepsilon \ll 1. \quad (23.122)$$

(i) 当  $\alpha = 1$  时, 构造复合渐近展开并画出解的示意图;

(ii) 当  $\alpha = 0$  时, 构造复合渐近展开;


(iii) 对第一种情形, 说明所得首项复合解关于  $\varepsilon$  的精度。

第一步: 外部展开 设  $y_{\text{out}} = y_0 + \varepsilon y_1 + \cdots$ 。零阶方程为

$$-y_0 = x - 1, \quad (23.123)$$

所以

$$y_0(x) = 1 - x. \quad (23.124)$$



一阶方程为

$$y_0'' + (1+x)^2 y_0' - y_1 = 0. \quad (23.125)$$

由于  $y_0' = -1$ ,  $y_0'' = 0$ , 有

$$\boxed{y_1(x) = -(1+x)^2}. \quad (23.126)$$

因此

$$y_{\text{out}} = 1 - x - \varepsilon(1+x)^2 + O(\varepsilon^2). \quad (23.127)$$

领先外解满足  $y_0(0) = 1$ ,  $y_0(1) = 0$ 。故:

- 当  $\alpha = 1$  时, 左端领先边界条件相容, 右端失配;
- 当  $\alpha = 0$  时, 左右两端均失配。

第二步: 层厚为何是  $\sqrt{\varepsilon}$  在候选边界附近令  $x = x_0 + \delta z$ 。三类项的尺度为

$$\varepsilon y'' \sim \frac{\varepsilon}{\delta^2}, \quad (23.128)$$

$$\varepsilon(1+x)^2 y' \sim \frac{\varepsilon}{\delta}, \quad (23.129)$$

$$-y \sim 1. \quad (23.130)$$

领先平衡是  $\frac{\varepsilon}{\delta^2} \sim 1$ , 故

$$\boxed{\delta = \sqrt{\varepsilon}}. \quad (23.131)$$

在该尺度上, 一阶导数项只有  $O(\sqrt{\varepsilon})$ , 它不进入领先内层方程, 但决定首个内层修正。

令

$$q = \sqrt{\varepsilon}. \quad (23.132)$$

第 (i) 问:  $\alpha = 1$  时的右边界层 取右快变量

$$\eta = \frac{1-x}{q}, \quad Y(\eta; q) = y(1 - q\eta; q^2). \quad (23.133)$$

有  $\frac{d}{dx} = -\frac{1}{q} \frac{d}{d\eta}$ ,  $\frac{d^2}{dx^2} = \frac{1}{q^2} \frac{d^2}{d\eta^2}$ 。代入原方程:

$$Y_{\eta\eta} - Y - q(2 - q\eta)^2 Y_\eta = -q\eta. \quad (23.134)$$

设

$$Y = Y_0 + qY_1 + q^2Y_2 + \cdots. \quad (23.135)$$

领先方程为

$$Y_0'' - Y_0 = 0. \quad (23.136)$$

边界条件为  $Y_0(0) = -1$ , 而匹配条件为  $Y_0(\eta) \rightarrow 0$ ,  $\eta \rightarrow +\infty$ , 因为  $y_0(1 - q\eta) = q\eta$ 。所以

$$\boxed{Y_0(\eta) = -e^{-\eta}}. \quad (23.137)$$


领先公共部分为 0, 故首项复合展开是

$$\boxed{y_{\text{comp}, \alpha=1}^{[0]}(x; \varepsilon) = 1 - x - \exp\left[-\frac{1-x}{\sqrt{\varepsilon}}\right]}. \quad (23.138)$$

它满足

$$y_{\text{comp}, \alpha=1}^{[0]}(1) = -1, \quad (23.139)$$

$$y_{\text{comp}, \alpha=1}^{[0]}(0) = 1 - e^{-1/\sqrt{\varepsilon}} = 1 + \text{指数小误差}. \quad (23.140)$$



第 (i) 问的首个内层修正 在  $O(q)$  阶有

$$Y_1'' - Y_1 = -\eta + 4Y_0' = -\eta + 4e^{-\eta}. \quad (23.141)$$

边界和匹配条件为

$$Y_1(0) = 0, \quad (23.142)$$

$$Y_1(\eta) \sim \eta, \quad \eta \rightarrow +\infty. \quad (23.143)$$

因为  $\left(\frac{d^2}{d\eta^2} - 1\right)\eta = -\eta$  及  $\left(\frac{d^2}{d\eta^2} - 1\right)(\eta e^{-\eta}) = -2e^{-\eta}$ , 得到

$$\boxed{Y_1(\eta) = \eta - 2\eta e^{-\eta}}. \quad (23.144)$$

外解在右层中的公共部分到  $O(q)$  为  $q\eta = 1 - x$ . 所以包含首个内层修正的复合近似为

$$\begin{aligned} y_{\text{comp}, \alpha=1}^{[1]} &= 1 - x + Y_0 + qY_1 - q\eta \\ &= \boxed{1 - x - [1 + 2(1 - x)] \exp\left[-\frac{1 - x}{\sqrt{\varepsilon}}\right]}. \end{aligned} \quad (23.145)$$

该式比 式 (23.138) 多包含一个在层内为  $O(\sqrt{\varepsilon})$  的修正。

第 (ii) 问:  $\alpha = 0$  时的左边界层 取

$$\xi = \frac{x}{q}, \quad Z(\xi; q) = y(q\xi; q^2). \quad (23.146)$$

代入原方程:

$$Z_{\xi\xi} - Z + q(1 + q\xi)^2 Z_{\xi} = q\xi - 1. \quad (23.147)$$

领先方程为

$$Z_0'' - Z_0 = -1. \quad (23.148)$$

边界和匹配条件为

$$Z_0(0) = 0, \quad (23.149)$$

$$Z_0(\xi) \rightarrow 1, \quad \xi \rightarrow +\infty. \quad (23.150)$$

所以

$$\boxed{Z_0(\xi) = 1 - e^{-\xi}}. \quad (23.151)$$

右边界层仍为  $Y_0(\eta) = -e^{-\eta}$ . 左层公共部分为 1, 右层公共部分为 0. 因此领先双层复合展开为


$$\boxed{y_{\text{comp}, \alpha=0}^{[0]} = 1 - x - \exp\left(-\frac{x}{\sqrt{\varepsilon}}\right) - \exp\left(-\frac{1 - x}{\sqrt{\varepsilon}}\right)}. \quad (23.152)$$

边界检查:

$$y_{\text{comp}, \alpha=0}^{[0]}(0) = -e^{-1/\sqrt{\varepsilon}}, \quad (23.153)$$

$$y_{\text{comp}, \alpha=0}^{[0]}(1) = -1 - e^{-1/\sqrt{\varepsilon}}. \quad (23.154)$$

两个边界误差均为超越所有代数阶的指数小量。



第 (ii) 问的首个左层修正 在  $O(q)$  阶:

$$Z_1'' - Z_1 = \xi - Z_0' = \xi - e^{-\xi}. \quad (23.155)$$

并有  $Z_1(0) = 0$ ,  $Z_1(\xi) \sim -\xi$ 。解得

$$Z_1(\xi) = -\xi + \frac{\xi}{2}e^{-\xi}. \quad (23.156)$$

因此同时包含左右首个内层修正的近似可写为

$$y_{\text{comp}, \alpha=0}^{[1]} = 1 - x - \left(1 - \frac{x}{2}\right) e^{-x/\sqrt{\varepsilon}} - [1 + 2(1-x)] e^{-(1-x)/\sqrt{\varepsilon}}. \quad (23.157)$$

第 (iii) 问: 首项复合解的精度 题目要求只讨论  $\alpha = 1$ 。

定义

$$p(x) = (1+x)^2 \quad (23.158)$$

及

$$\mathcal{L}_\varepsilon v = \varepsilon v'' + \varepsilon p(x)v' - v. \quad (23.159)$$

对首项复合解  $y_c = 1 - x - e^{-(1-x)/q}$ ,  $q = \sqrt{\varepsilon}$ , 直接计算:

$$\mathcal{L}_\varepsilon y_c - (x-1) = -\varepsilon p(x) - q p(x) e^{-(1-x)/q}. \quad (23.160)$$

因此

$$\|\mathcal{L}_\varepsilon y_c - (x-1)\|_\infty = O(q) = O(\sqrt{\varepsilon}). \quad (23.161)$$

其边界失配为  $O(e^{-1/q})$ 。因为零阶项为  $-y$ , 由 定义 23.4:

$$\left\| y - y_{\text{comp}, \alpha=1}^{[0]} \right\|_\infty = O(\sqrt{\varepsilon}). \quad (23.162)$$

这也是从内层级数  $Y_0 + \sqrt{\varepsilon}Y_1 + \cdots$  直接读出的首个省略阶。

因此第 (iii) 问的标准答案是:

$$\boxed{\text{第 (i) 问首项复合解的一致函数误差为 } O(\varepsilon^{1/2})}. \quad (23.163)$$

注 23.6 (加入首个内层修正后的精度). 对 式 (23.145), 直接计算可得

$$\begin{aligned} \mathcal{L}_\varepsilon y_{\text{comp}, \alpha=1}^{[1]} - (x-1) \\ = -q^2 p(x) + q e^{-(1-x)/q} [2qp(x) + (x-1)(2x^2 + 3x - 1)]. \end{aligned} \quad (23.164)$$

利用

$$\sup_{0 \leq s \leq 1} s e^{-s/q} \leq \frac{q}{e}, \quad (23.165)$$

得到  $\left\| \mathcal{L}_\varepsilon y_{\text{comp}, \alpha=1}^{[1]} - (x-1) \right\|_\infty = O(q^2) = O(\varepsilon)$ 。故

$$\left\| y - y_{\text{comp}, \alpha=1}^{[1]} \right\|_\infty = O(\varepsilon). \quad (23.166)$$

所以必须区分:

| 所保留的复合项                                      | 一致函数精度                  |
|----------------------------------------------|-------------------------|
| $y_0 + Y_0$ - 公共部分                           | $O(\sqrt{\varepsilon})$ |
| $y_0 + Y_0 + \sqrt{\varepsilon}Y_1$ - 高阶公共部分 | $O(\varepsilon)$        |



第 (i)、(ii) 问的示意图作答要点

易错点与反例

1. 错把层厚写成  $O(\varepsilon)$ ;
2. 只看小参数乘  $y''$ , 未与零阶项作主导平衡;
3.  $\alpha = 1$  时仍构造  $O(1)$  左边界层;
4.  $\alpha = 0$  时漏掉左层;
5. 右快变量写成  $(x-1)/\sqrt{\varepsilon}$  后仍使用  $e^{-\eta}$ , 造成指数增长;
6. 复合解中漏减公共部分;
7. 看到外部展开按  $\varepsilon$  递进, 就误判首项误差为  $O(\varepsilon)$ ;
8. 只写残量阶, 不说明边界失配和稳定性;
9. 将指数小量  $e^{-1/\sqrt{\varepsilon}}$  错写为  $O(\varepsilon)$  的主导误差。

## 23.12 数值实现、层分辨率与计算复杂度

### 23.12.1 知识点十六：直接均匀网格的代价

若边界层宽为  $\delta(\varepsilon)$ , 为了在层内至少放置固定数量的网格点, 需要  $h \lesssim \delta$ 。在长度为  $O(1)$  的区间上, 均匀网格点数至少满足

$$N = \Omega(\delta^{-1}). \quad (23.167)$$

例如:

$$\delta = \varepsilon \implies N = \Omega(\varepsilon^{-1}), \quad (23.168)$$

$$\delta = \sqrt{\varepsilon} \implies N = \Omega(\varepsilon^{-1/2}), \quad (23.169)$$

$$\delta = \varepsilon^{3/4} \implies N = \Omega(\varepsilon^{-3/4}). \quad (23.170)$$

这只是“看见边界层”的最低分辨率要求; 若还要求高阶导数精度, 网格可能需要更细。

### 23.12.2 知识点十七：层适应网格与渐近公式

常用数值策略包括:

1. 在层内局部加密;
2. 使用 Shishkin 型分片均匀网格;
3. 使用 Bakhvalov 型指数映射网格;
4. 使用迎风或指数拟合离散;
5. 先减去已知边界层近似, 再对光滑余项离散;
6. 直接使用复合渐近展开作初值或预条件。



若复合展开含  $N_a$  项，单点求值复杂度通常为  $O(N_a)$ ，存储为  $O(N_a)$ 。在参数极小时，这比在全区间直接解析窄层便宜。

易错点与反例

数值解在粗网格上看起来光滑，不说明边界层不存在。

若  $h \gg \delta$ ，网格可能完全跳过快速过渡区域，导致：

- 边界条件被错误传播到内部；
- 最大误差集中在第一个网格单元；
- 误判收敛阶；
- 中心差分产生非物理振荡。

23.13 奇异摄动易错点、反例与完整答题规范

| 错误说法或错误做法                           | 正确处理                                                   |
|-------------------------------------|--------------------------------------------------------|
| 小参数乘最高阶导数，所以层厚一定是 $\varepsilon$ 。   | 层厚由主导平衡决定；反应型问题常为 $\sqrt{\varepsilon}$ ，退化问题可为非整数幂。    |
| 令 $\varepsilon = 0$ 后所得解应满足全部边界条件。  | 降阶问题通常只能满足部分边界条件；其余条件由快速层满足。                           |
| 哪个边界不匹配，哪个边界必有层。                    | 还需存在向区域内部衰减的快速模态。                                      |
| 左、右快变量都写成 $(x - x_0)/\delta$ 。      | 右边界通常用 $(\beta - x)/\delta$ ，以便内部方向对应正无穷。              |
| 内层边界条件是外部极限。                        | 内层在 $z = 0$ 满足原始边界条件，在 $z \rightarrow \infty$ 匹配外解。    |
| 匹配就是选一个点令内解等于外解。                    | 必须在 $\delta \ll  x - x_0  \ll 1$ 的重叠区比较渐近展开。           |
| 高阶匹配只比较常数极限。                        | 高阶内解可能含 $z, z^2, \log z$ ，必须用中间变量或 Van Dyke 原则。        |
| 复合解等于外解加内解。                         | 必须减去公共部分，避免重叠区重复计数。                                    |
| 有两个边界层时只需机械相加。                      | 若层宽与区间长度同阶或尾部相互作用不可忽略，需要交互修正。                          |
| 外部展开按 $\varepsilon$ 递进，所以整体误差也是整数幂。 | 内层可能按 $\sqrt{\varepsilon}, \varepsilon^{1/2}$ 或其他尺度递进。 |
| 残量小就自动有同阶解误差。                       | 需要 $\varepsilon$ -一致稳定性估计。                             |
| 函数值一致逼近自动给出导数一致逼近。                  | 层内每次求导会产生 $\delta^{-1}$ 放大。                            |
| 对流系数变号时仍用一个全区间外解。                   | 应求左右外解，并在转向点构造内部层。                                     |



| 错误说法或错误做法               | 正确处理                             |
|-------------------------|----------------------------------|
| 两个外解在转向点函数值相同，所以不需要内部层。 | 斜率或更高导数不匹配仍可能产生内部层。              |
| 初始层指数增长也可以接受。           | 正时间初始层必须沿快时间衰减，否则慢分支不稳定或问题方向错误。  |
| 边界层只影响很小区域，所以可忽略。       | 虽然区域窄，最大范数误差和边界通量误差可为 $O(1)$ 。   |
| 指数小量就是零。                | 在有限精度、层相互作用或超渐近问题中，指数小量可能决定分支切换。 |

反例 23.7 (外解点态正确但不一致). 设  $y_\varepsilon(x) = 1 - e^{-x/\varepsilon}$ ,  $0 \leq x \leq 1$ . 对每个固定  $x > 0$ ,  $y_\varepsilon(x) \rightarrow 1$ . 所以外解为  $y_0 = 1$ . 但  $y_\varepsilon(0) = 0$ , 故  $\sup_{0 \leq x \leq 1} |y_\varepsilon(x) - 1| = 1$ . 外解仅点态有效, 不是一致近似。

反例 23.8 (边界条件相容时首层振幅可为零). 考虑  $\varepsilon y'' + y' = 0$ ,  $y(0) = 0$ ,  $y(1) = 0$ . 约化问题  $y'_0 = 0$  可取  $y_0 \equiv 0$  并满足两个边界条件. 尽管问题形式上降阶, 精确解也是  $y \equiv 0$ , 不存在非零边界层。

#### 匹配原则：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：内解含待定常数，且其远场必须连接外解。

构造步骤：

1. 选择  $\delta \ll \chi \ll 1$ ;
2. 令  $x - x_0 = \chi\omega$ ;
3. 将外解在  $x \rightarrow x_0$  下展开;
4. 将内解在  $z = \chi\omega/\delta \rightarrow \infty$  下展开;
5. 使用同一渐近序列比较;
6. 确定待定常数。

关键估计：若要求指数尾小于  $O(\varepsilon^p)$ , 应满足  $e^{-c\chi/\delta} = o(\varepsilon^p)$ , 即  $\frac{\chi}{\delta} \gg \log(\varepsilon^{-1})$ 。

结论：得到公共部分和内层常数。

常见失败原因：

- 不存在重叠区;
- 层尾在目标精度下仍不可忽略;
- 内外展开使用不同渐近序列;
- 匹配方向写反;
- 只匹配函数值, 漏掉增长项。

#### 复合展开：识别信号—构造步骤—关键检验—结论—失败原因

识别信号：外解和内解各自在部分区域有效，需要构造全区间近似。

构造步骤：

1. 求外解；
2. 求每个内解；
3. 求每个重叠公共部分；
4. 采用 外 + 内 - 公共；
5. 检查边界；
6. 检查外区和内区退化极限；
7. 计算残量。

关键检验：

$$y_{\text{comp}} \sim y_{\text{out}} \quad \text{在外部区域,} \quad (23.171)$$

$$y_{\text{comp}} \sim y_{\text{in}} \quad \text{在层内.} \quad (23.172)$$

结论：得到一致有效近似。

常见失败原因：公共部分错误、双层相互作用、边界失配未达到目标阶、稳定性常数不一致。





## 第二十四章 多尺度法、非线性振子、长时间有效性、模型定量分析与模块五真题映射

### 24.1 多尺度法的统一框架

#### 24.1.1 问题、识别信号与基本假设

【重要性等级】 **S 级**。判定依据是：

- 多尺度法在六套正式试卷中直接出现两次；
- 该方法同时统摄弱阻尼、弱非线性、近共振、缓慢调制和极限环；
- 资格考试通常不仅要求写出近似解，还要求说明  $t = O(\varepsilon^{-1})$  的有效性及相平面含义；
- 漏掉共振项、慢相位、初值匹配或误差区间会造成实质性失分。

考虑弱扰动振子

$$y'' + y + \varepsilon G(y, y') = 0, \quad 0 < \varepsilon \ll 1, \quad (24.1)$$

并假设：

1.  $G \in C^r$ ，其中  $r$  足够大；
2. 初始振幅为  $O(1)$ ，且不随  $\varepsilon$  发散；
3. 在目标慢时间区间  $0 \leq T = \varepsilon t \leq T_*$  上，精确解和调制解均保持在给定紧集内；
4. 若使用振幅-相位坐标，则在所讨论区间内振幅不穿过 0；
5. 对系统问题，还需检查内部共振和模态耦合。

典型识别信号包括：

1. 普通摄动展开中出现  $t \sin t, \quad t \cos t$ ；
2. 题目要求“对大时间有效”；
3. 解保持快速振荡，但包络缓慢变化；
4. 阻尼、激励、非线性或失谐系数为  $O(\varepsilon)$ ；
5. 需要研究极限环的吸引或排斥；
6. 固定时间展开正确，但在  $t \sim \varepsilon^{-1}$  时修正项与首项同阶。



定义 24.1 (Secular term). 若摄动系数中出现随快时间无界增长的项, 例如  $t \sin t$ ,  $t \cos t$ , 使得  $\varepsilon y_1(t) = O(1)$  当  $t = O(\varepsilon^{-1})$ , 则称该项为 secular term 或长期项。

#### 易错点与反例

secular term 不一定意味着精确解无界。

例如弱阻尼振子的精确解有界并衰减, 但普通摄动展开会出现  $-\varepsilon \gamma t \cos t$ 。该项反映的是展开基准选择失效, 而不是精确解发散。

### 24.1.2 快慢变量和导数展开

引入形式上独立的变量

$$T_0 = t, T_1 = \varepsilon t, T_2 = \varepsilon^2 t, \dots \quad (24.2)$$

并记  $D_j = \frac{\partial}{\partial T_j}$ 。链式法则给出

$$\frac{d}{dt} = D_0 + \varepsilon D_1 + \varepsilon^2 D_2 + \dots, \quad (24.3)$$

以及

$$\frac{d^2}{dt^2} = D_0^2 + 2\varepsilon D_0 D_1 + \varepsilon^2 (D_1^2 + 2D_0 D_2) + O(\varepsilon^3). \quad (24.4)$$

设

$$y(t; \varepsilon) \sim y_0(T_0, T_1, T_2, \dots) + \varepsilon y_1(T_0, T_1, T_2, \dots) + \varepsilon^2 y_2 + \dots. \quad (24.5)$$

在比较各阶系数时, 必须先把  $T_0, T_1, T_2, \dots$  视为独立变量; 完成推导后再代回  $T_j = \varepsilon^j t$ 。

#### 易错点与反例

错误做法是从一开始就把  $T_1 = \varepsilon T_0$  代入偏导数。

这样会破坏式 (24.3) and (24.4) 的分阶结构, 并漏掉  $2D_0 D_1 y_0$  等决定振幅方程的关键项。

### 24.1.3 领先解及振幅-相位表示

将式 (24.5) 代入式 (24.1),  $O(1)$  方程为

$$\mathcal{L}_0 y_0 = 0, \mathcal{L}_0 := D_0^2 + 1. \quad (24.6)$$

故可写成

$$y_0 = R(T_1) \cos \theta, \theta = T_0 + \phi(T_1), R(T_1) > 0. \quad (24.7)$$

有

$$D_0 y_0 = -R \sin \theta, \quad (24.8)$$


$$D_1 y_0 = R' \cos \theta - R \phi' \sin \theta, \quad (24.9)$$

$$2D_0 D_1 y_0 = -2R' \sin \theta - 2R \phi' \cos \theta, \quad (24.10)$$

其中撇号表示对  $T_1$  求导。

$O(\varepsilon)$  方程为

$$\mathcal{L}_0 y_1 = 2R' \sin \theta + 2R \phi' \cos \theta - G(R \cos \theta, -R \sin \theta). \quad (24.11)$$



### 24.1.4 共振投影和 Fredholm 可解性条件

命题 24.2 (周期解的可解性条件). 设  $F$  为  $2\pi$ -周期函数。方程

$$(D_0^2 + 1)w = F(T_0) \quad (24.12)$$

存在  $2\pi$ -周期解的必要充分条件是

$$\int_0^{2\pi} F(T_0) \cos T_0 \, dT_0 = 0, \quad (24.13)$$

$$\int_0^{2\pi} F(T_0) \sin T_0 \, dT_0 = 0. \quad (24.14)$$

证明. 算子  $\mathcal{L}_0 = D_0^2 + 1$  在周期内积  $\langle f, g \rangle_{\text{per}} = \int_0^{2\pi} f(T_0)g(T_0) \, dT_0$  下自伴, 并且  $\ker \mathcal{L}_0 = \text{span}\{\cos T_0, \sin T_0\}$ 。由 Fredholm 择一定理,  $F$  必须与伴随零空间正交, 从而得到 式 (24.13) and (24.14)。

反之, 将  $F$  作 Fourier 展开。若频率 1 的正弦和余弦系数均为零, 则对其余各 Fourier 模态逐项除以  $1 - k^2$ ,  $k \neq 1$ , 即可构造周期解。□

若

$$G(R \cos \theta, -R \sin \theta) = g_c(R) \cos \theta + g_s(R) \sin \theta + G_\perp(R, \theta), \quad (24.15)$$

其中  $G_\perp \perp \text{span}\{\cos \theta, \sin \theta\}$ , 则消除 式 (24.11) 中的共振项得到

$$R' = \frac{1}{2}g_s(R), \quad (24.16)$$

以及

$$\phi' = \frac{g_c(R)}{2R}. \quad (24.17)$$

等价的投影公式为

$$R' = \frac{1}{2\pi} \int_0^{2\pi} G(R \cos \theta, -R \sin \theta) \sin \theta \, d\theta, \quad (24.18)$$

以及

$$\phi' = \frac{1}{2\pi R} \int_0^{2\pi} G(R \cos \theta, -R \sin \theta) \cos \theta \, d\theta. \quad (24.19)$$

注 24.3. 若初值更适合写成  $y_0 = R(T_1) \sin \theta$ , 则应重新推导投影符号, 不能机械复制 式 (24.18) and (24.19)。

本部分的 2025 Spring 题采用余弦表示, 2025 Fall 题采用正弦表示, 以便直接匹配各自初值。

### 24.1.5 secular term 的显式来源

若  $\mathcal{L}_0 w = a \cos T_0 + b \sin T_0$ , 则一个特解为

$$w_{\text{sec}} = \frac{a}{2} T_0 \sin T_0 - \frac{b}{2} T_0 \cos T_0. \quad (24.20)$$

这是因为

$$\mathcal{L}_0(T_0 \sin T_0) = 2 \cos T_0, \quad (24.21)$$

$$\mathcal{L}_0(T_0 \cos T_0) = -2 \sin T_0. \quad (24.22)$$

当  $T_0 = t = O(\varepsilon^{-1})$ , 有  $\varepsilon w_{\text{sec}} = O(1)$ , 普通正则展开失去渐近有序性。

多尺度法的本质是把这些长期变化吸收到  $R(\varepsilon t)$ ,  $\phi(\varepsilon t)$  中, 使  $y_1$  保持有界。



## 多尺度法：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：弱扰动振荡、近共振、慢包络、普通展开产生  $t \sin t$  或  $t \cos t$ 。

构造步骤：

1. 识别快时间  $T_0 = t$ ;
2. 根据世俗增长尺度引入  $T_1 = \varepsilon t$ ;
3. 展开总导数;
4. 求解领先齐次问题;
5. 将领先解中的常数提升为慢变量函数;
6. 在下一阶方程中提取共振 Fourier 模态;
7. 令共振系数为零, 得到振幅和相位方程;
8. 求非共振高次谐波修正;
9. 代回  $T_j = \varepsilon^j t$ ;
10. 检查初值、残量和有效时间。

关键估计：标准平均理论通常给出  $\sup_{0 \leq t \leq T_*/\varepsilon} |y(t) - y_{MS}(t)| \leq C_{T_*} \varepsilon$ 。

结论：得到在一个固定慢时间区间上有效的调制振荡近似。

常见失败原因：

- 漏掉  $2D_0 D_1 y_0$ ;
- 没有消除全部共振模态;
- 只求振幅而漏掉慢相位;
- 初值与所选振幅-相位规范不一致;
- 把固定时间残量阶直接写成长时间解误差阶;
- 初始振幅随  $\varepsilon$  发散, 使扰动不再弱;
- 振幅穿过零点, 极坐标相位失去定义;
- 在内共振系统中只处理一个模态。

## Algorithm 82 弱扰动振子的多尺度展开

**Input:** 方程  $y'' + y + \varepsilon G(y, y') = 0$ ; 初值; 目标慢时间  $T_*$ ; 目标阶数  $N$

**Output:** 调制方程; 复合近似; 残量阶; 有效时间区间

- 1: **Input check:** 验证  $0 < \varepsilon \ll 1$ , 初始振幅为  $O(1)$ ,  $G$  具有所需光滑性
- 2: **Initialization:** 设置  $T_0 = t$ ,  $T_1 = \varepsilon t$  并按目标精度决定是否加入  $T_2, T_3, \dots$
- 3: 展开  $d/dt$  和  $d^2/dt^2$
- 4: 设  $y \sim \sum_{j=0}^N \varepsilon^j y_j$  并比较各阶
- 5: 求领先解  $y_0 = R(T_1) \cos(T_0 + \phi(T_1))$
- 6: 计算  $O(\varepsilon)$  右端的频率 1 模态
- 7: 令共振正弦和余弦系数为零, 得到  $R'$  和  $\phi'$
- 8: 用初值确定  $R(0)$ 、 $\phi(0)$



- 9: 求非共振修正  $y_1, \dots, y_N$
- 10: 代回  $T_j = \varepsilon^j t$
- 11: 计算原方程残量并检查初值残量
- 12: **Stopping criterion:** 残量和初值失配达到所需阶, 且目标区间满足  $0 \leq \varepsilon t \leq T_*$
- 13: **Complexity:** 若每阶保留  $M$  个 Fourier 模态, 则一次投影成本为  $O(M)$ ; 非线性卷积直接实现通常为  $O(NM^2)$ , FFT 实现可降至  $O(NM \log M)$ ; 存储为  $O(NM)$

## 24.2 平均定理、误差阶与长时间有效性

### 24.2.1 一阶平均定理

定理 24.4 (一阶平均定理的标准形式). 考虑

$$\dot{z} = \varepsilon f(z, t, \varepsilon), \quad z(0) = z_0, \quad (24.23)$$

其中  $f$  关于  $t$  为  $2\pi$ -周期函数, 在某紧集上关于  $z$  一致 Lipschitz, 并且关于  $(z, \varepsilon)$  具有足够光滑性。

定义平均向量场

$$\bar{f}(z) = \frac{1}{2\pi} \int_0^{2\pi} f(z, s, 0) ds, \quad (24.24)$$

并令

$$\dot{Z} = \varepsilon \bar{f}(Z), \quad Z(0) = z_0. \quad (24.25)$$

若  $z(t)$  和  $Z(t)$  在  $0 \leq t \leq T_*/\varepsilon$  内均留在上述紧集中, 则存在与  $\varepsilon$  无关的常数  $C_{T_*}$ , 使

$$\sup_{0 \leq t \leq T_*/\varepsilon} |z(t) - Z(t)| \leq C_{T_*} \varepsilon. \quad (24.26)$$

#### 一阶平均定理的证明框架

定义零均值周期函数  $\tilde{f}(z, t) = f(z, t, 0) - \bar{f}(z)$ 。存在有界的  $2\pi$ -周期函数  $U(z, t)$ , 满足

$$\partial_t U(z, t) = \tilde{f}(z, t). \quad (24.27)$$

作近恒等变换

$$z = w + \varepsilon U(w, t). \quad (24.28)$$

对足够小的  $\varepsilon$ , 该变换局部可逆。微分并使用 式 (24.27), 得到

$$\dot{w} = \varepsilon \bar{f}(w) + \varepsilon^2 r(w, t, \varepsilon), \quad (24.29)$$

其中  $r$  一致有界。

令  $e(t) = w(t) - Z(t)$ 。由 Lipschitz 条件,  $|\dot{e}| \leq \varepsilon L|e| + C\varepsilon^2$ 。Grönwall 不等式给出

$$\begin{aligned} |e(t)| &\leq (|e(0)| + C\varepsilon^2 t) e^{\varepsilon L t} \\ &\leq C_{T_*} \varepsilon, \quad 0 \leq t \leq T_*/\varepsilon. \end{aligned} \quad (24.30)$$

再由  $z - w = \varepsilon U(w, t) = O(\varepsilon)$  得到 式 (24.26)。

注 24.5. 对振子问题, 可先变到随未扰动旋转的坐标系, 将快速  $O(1)$  旋转消去, 得到 式 (24.23) 形式的慢系统。

振幅-相位坐标在  $R = 0$  处奇异。严格证明若需要经过原点, 宜使用二维 Cartesian 慢振幅, 而不是直接使用极坐标。

### 24.2.2 残量阶、固定时间误差与长时间误差

设近似解为  $y_{\text{app}}$ ，残量为

$$\mathcal{R}_\varepsilon(t) = y_{\text{app}}'' + y_{\text{app}} + \varepsilon G(y_{\text{app}}, y_{\text{app}}'). \quad (24.31)$$

必须区分下列概念。

| 对象                    | 正确含义                                     | 资格考试中必须说明的限制                                                    |
|-----------------------|------------------------------------------|-----------------------------------------------------------------|
| 残量 $O(\varepsilon^p)$ | 将近似解代入微分方程后的不平衡量                         | 残量阶不自动等于长时间解误差阶                                                 |
| 固定时间误差                | 在 $0 \leq t \leq T$ , $T = O(1)$ 上的误差    | 通常比长时间误差高一阶                                                     |
| 慢时间一致误差               | 在 $0 \leq \varepsilon t \leq T_*$ 上的一致估计 | 必须注明 $T_*$ 固定且与 $\varepsilon$ 无关                                |
| 振幅误差                  | 包络 $R$ 的误差                               | 不等于相位误差                                                         |
| 相位误差                  | 振荡角度的累计误差                                | $O(\varepsilon^2)$ 频率误差在 $t = O(\varepsilon^{-2})$ 时会积累成 $O(1)$ |
| 绝对误差                  | $ y - y_{\text{app}} $                   | 振幅趋零时仍可能很小                                                      |
| 相对误差                  | $ y - y_{\text{app}} / y $               | 解过零或振幅趋零时可能失去意义                                                 |
| 全时间有效                 | 对所有 $t \geq 0$ 有统一误差界                    | 不能由一阶平均定理自动推出                                                   |

#### 易错点与反例

“ $O(\varepsilon^2)$  残量”不能直接写成“在  $t = O(\varepsilon^{-1})$  上有  $O(\varepsilon^2)$  误差”。

一个  $O(\varepsilon^2)$  的共振或慢漂移项在长度  $O(\varepsilon^{-1})$  的时间区间上可能积累为  $O(\varepsilon)$ 。若要把长时间误差提高到  $O(\varepsilon^2)$ ，通常需要加入二阶慢时间  $T_2 = \varepsilon^2 t$  并消除二阶共振。

### 24.3 基础例题：线性弱阻尼振子与 secular term 重求和

完整题目叙述：弱阻尼线性振子

设

$$\begin{cases} y'' + y + 2\varepsilon\gamma y' = 0, \\ y(0) = A_0, y'(0) = 0, \end{cases} \quad \gamma > 0, \quad 0 < \varepsilon \ll 1. \quad (24.32)$$

1. 说明普通正则摄动展开为什么在  $t = O(\varepsilon^{-1})$  失效；
2. 用多尺度法构造领先长时间近似；
3. 与精确解比较并说明误差阶。

第一步：普通摄动展开产生 secular term. 设  $y = y_0 + \varepsilon y_1 + \cdots$ 。零阶问题为  $y_0'' + y_0 = 0$ ,  $y_0(0) = A_0$ ,  $y_0'(0) = 0$ , 故  $y_0 = A_0 \cos t$ 。

一阶问题为

$$y_1'' + y_1 = -2\gamma y_0' = 2\gamma A_0 \sin t. \quad (24.33)$$

由式 (24.20), 一个满足齐次初值的一阶解包含

$$y_1^{\text{sec}} = -\gamma A_0 t \cos t. \quad (24.34)$$

于是  $\varepsilon y_1^{\text{sec}} = O(1)$  当  $t = O(\varepsilon^{-1})$ , 普通展开失效。□

第二步: 多尺度法. 令  $T_0 = t$ ,  $T_1 = \varepsilon t$ , 并设  $y_0 = R(T_1) \cos(T_0 + \phi(T_1))$ 。本题  $G(y, y') = 2\gamma y'$ 。在领先阶  $y'_0 = -R \sin \theta$ , 故  $G = -2\gamma R \sin \theta$ 。由式 (24.16) and (24.17):

$$R' = -\gamma R, \quad (24.35)$$

$$\phi' = 0. \quad (24.36)$$

初值给出  $R(0) = A_0$ ,  $\phi(0) = 0$ 。所以  $R(T_1) = A_0 e^{-\gamma T_1}$ 。领先多尺度近似为

$$y_{\text{MS}}^{[0]}(t) = A_0 e^{-\varepsilon \gamma t} \cos t. \quad (24.37)$$

将指数展开:  $e^{-\varepsilon \gamma t} = 1 - \varepsilon \gamma t + \dots$ , 即可重现式 (24.34)。因此, 多尺度法可解释为将世俗级数重求和成缓慢变化的指数包络。□

第三步: 与精确解比较. 当  $\varepsilon \gamma < 1$  时, 令  $\omega_\varepsilon = \sqrt{1 - \varepsilon^2 \gamma^2}$ 。精确解为

$$y(t) = A_0 e^{-\varepsilon \gamma t} \left[ \cos(\omega_\varepsilon t) + \frac{\varepsilon \gamma}{\omega_\varepsilon} \sin(\omega_\varepsilon t) \right]. \quad (24.38)$$

又  $\omega_\varepsilon = 1 - \frac{1}{2} \varepsilon^2 \gamma^2 + O(\varepsilon^4)$ 。当  $0 \leq t \leq T_*/\varepsilon$  时,  $|\omega_\varepsilon t - t| = O(\varepsilon)$ , 且正弦修正的系数为  $O(\varepsilon)$ 。故

$$\sup_{0 \leq t \leq T_*/\varepsilon} |y(t) - y_{\text{MS}}^{[0]}(t)| = O(\varepsilon). \quad (24.39)$$

若把时间延长到  $t = O(\varepsilon^{-2})$ , 则被省略的  $O(\varepsilon^2)$  频率修正会产生  $O(1)$  相位误差。□

## 24.4 能量平均、振幅动力学与模型定量分析

### 24.4.1 速度型弱非线性性的统一振幅公式

考虑

$$y'' + y + \varepsilon g(y') = 0. \quad (24.40)$$

定义能量

$$E(t) = \frac{1}{2} [y'(t)^2 + y(t)^2]. \quad (24.41)$$

则


$$E' = y'(y'' + y) = -\varepsilon y' g(y'). \quad (24.42)$$

若领先振荡写成  $y = R(T) \cos \theta$ ,  $y' = -R(T) \sin \theta$ ,  $T = \varepsilon t$ , 则  $E \sim \frac{1}{2} R^2$ ,  $\frac{dE}{dt} \sim \varepsilon R R_T$ 。对一个快周期平均得到

$$R_T = -\frac{1}{2\pi R} \int_0^{2\pi} v(\theta) g(v(\theta)) d\theta, \quad v(\theta) = -R \sin \theta. \quad (24.43)$$

该式与共振投影式 (24.18) 一致, 因为  $v = -R \sin \theta$ 。

注 24.6. 能量平均适用于快速得到振幅方程, 但通常不能单独给出相位方程和高次谐波。完整资格考试答案仍应写出多尺度分阶和共振消除。





### 24.4.2 振幅固定点和稳定性

若平均振幅满足

$$R_T = F(R), \quad (24.44)$$

则正平衡点  $R_* > 0$  满足  $F(R_*) = 0$ 。若  $F'(R_*) < 0$ , 则  $R_*$  是慢时间下局部渐近稳定的, 并对应原振子中的稳定周期轨道或极限环。

若  $F'(R_*) > 0$ , 则该周期振幅不稳定。

物理时间中的松弛尺度为

$$t_{\text{relax}} = O\left(\frac{1}{\varepsilon|F'(R_*)|}\right). \quad (24.45)$$

若  $F'(R_*) = 0$ , 则线性化不能决定稳定速率, 常出现代数衰减而不是指数衰减。

### 24.4.3 无量纲化中的小参数识别

考虑物理模型

$$m \frac{d^2 q}{d\tau^2} + kq + c_3 \left(\frac{dq}{d\tau}\right)^3 = 0. \quad (24.46)$$

取  $q = Qy$ ,  $t = \omega_0 \tau$ ,  $\omega_0 = \sqrt{\frac{k}{m}}$ 。则式 (24.46) 化为

$$y'' + y + \varepsilon(y')^3 = 0, \quad (24.47)$$

其中

$$\varepsilon = \frac{c_3 Q^2 \omega_0}{m}. \quad (24.48)$$

这说明“ $\varepsilon$  小”不仅取决于材料系数  $c_3$ , 还取决于所选振幅尺度  $Q$ 。

即使  $\varepsilon \ll 1$ , 若实际无量纲振幅  $R = O(\varepsilon^{-1/2})$ , 则  $\varepsilon R^2 = O(1)$ , 三次阻尼不再是弱扰动, 多尺度分阶需要重新缩放。

### 24.4.4 参数敏感性方程

若  $R_T = F(R, \mu)$ ,  $R(0, \mu) = R_0(\mu)$ , 则参数敏感度  $S(T) = \frac{\partial R}{\partial \mu}$  满足

$$S_T = F_R(R, \mu)S + F_\mu(R, \mu), \quad S(0) = R'_0(\mu). \quad (24.49)$$

因此, 模型定量分析应至少报告:

1. 控制参数  $\mu$  和小参数  $\varepsilon$  的来源;
2. 稳定振幅或衰减律;
3. 松弛时间;
4. 参数扰动对包络的影响;
5. 近似有效的振幅、相位和时间范围。





## 24.5 正式真题 [25S-Q6]——三次阻尼振子的多尺度展开

完整题目叙述: [25S-Q6]

考虑带三次阻尼项的谐振子

$$\begin{cases} y'' + y + \varepsilon(y')^3 = 0, \\ y(0) = 1, y'(0) = 0, \end{cases} \quad t \geq 0, \quad \varepsilon > 0. \quad (24.50)$$

(i) 当  $\varepsilon$  很小时, 用多尺度法研究大时间下  $y(t)$  的行为, 构造适当的渐近解;

(ii) 对所得渐近解的有效性作出结论, 并简要说明理由。

第一步: 基本能量性质 定义  $E(t) = \frac{1}{2} [y'(t)^2 + y(t)^2]$ 。由原方程

$$E'(t) = -\varepsilon [y'(t)]^4 \leq 0. \quad (24.51)$$

因此:

1. 能量单调不增;
2. 解在相平面中向原点收缩;
3. 初始能量为  $E(0) = \frac{1}{2}$ ;
4. 解满足  $|y(t)| \leq 1, |y'(t)| \leq 1$ ;
5. 阻尼导致的是缓慢振幅衰减, 而不是首阶频率漂移。

第二步: 引入快慢时间 令

$$T_0 = t, T_1 = \varepsilon t, \quad (24.52)$$

并设

$$y = y_0(T_0, T_1) + \varepsilon y_1(T_0, T_1) + O(\varepsilon^2). \quad (24.53)$$

由式 (24.3) and (24.4), 代回原方程得到

$$O(1): \quad (D_0^2 + 1)y_0 = 0, \quad (24.54)$$

$$O(\varepsilon): \quad (D_0^2 + 1)y_1 = -2D_0D_1y_0 - (D_0y_0)^3. \quad (24.55)$$

取

$$y_0 = R(T_1) \cos [T_0 + \phi(T_1)]. \quad (24.56)$$


记  $\theta = T_0 + \phi(T_1)$ 。则  $D_0y_0 = -R \sin \theta$ 。

第三步: 三角分解和共振消除 有恒等式

$$\sin^3 \theta = \frac{3 \sin \theta - \sin 3\theta}{4}. \quad (24.57)$$

因此

$$\begin{aligned} (D_0y_0)^3 &= -R^3 \sin^3 \theta \\ &= -\frac{3}{4}R^3 \sin \theta + \frac{1}{4}R^3 \sin 3\theta. \end{aligned} \quad (24.58)$$



又由 式 (24.10), 式 (24.55) 化为

$$(D_0^2 + 1)y_1 = \left(2R' + \frac{3}{4}R^3\right)\sin\theta + 2R\phi'\cos\theta - \frac{1}{4}R^3\sin 3\theta. \quad (24.59)$$

为了使  $y_1$  不含 secular term, 必须令

$$2R' + \frac{3}{4}R^3 = 0, \quad (24.60)$$

$$2R\phi' = 0. \quad (24.61)$$

故

$$R' = -\frac{3}{8}R^3, \quad (24.62)$$

以及

$$\phi' = 0. \quad (24.63)$$

第四步: 求解振幅方程并匹配初值 由初值  $y(0) = 1, y'(0) = 0$  取

$$R(0) = 1, \phi(0) = 0. \quad (24.64)$$

由 式 (24.62):  $\frac{d}{dT_1}(R^{-2}) = \frac{3}{4}$ 。所以

$$R(T_1) = \frac{1}{\sqrt{1 + \frac{3}{4}T_1}}. \quad (24.65)$$

代回  $T_1 = \varepsilon t$  得到领先长时间渐近解

$$y_{\text{MS}}^{[0]}(t) = \frac{\cos t}{\sqrt{1 + \frac{3}{4}\varepsilon t}}. \quad (24.66)$$

该公式预测包络

$$R(\varepsilon t) = \left(1 + \frac{3}{4}\varepsilon t\right)^{-1/2}. \quad (24.67)$$

在平均模型中, 当  $\varepsilon t \rightarrow \infty$  时,


$$R(\varepsilon t) \sim \frac{2}{\sqrt{3\varepsilon t}}. \quad (24.68)$$

因此衰减是代数型, 而不是指数型。

第五步: 能量平均的交叉验证 由 式 (24.51), 在一个快周期内  $y' \approx -R\sin t$ 。利用

$$\frac{1}{2\pi} \int_0^{2\pi} \sin^4 t \, dt = \frac{3}{8}, \quad (24.69)$$

得到  $\langle E' \rangle = -\varepsilon \frac{3}{8} R^4$ 。另一方面  $E \approx \frac{1}{2} R^2$ ,  $E' \approx \varepsilon R R'$ 。故  $\varepsilon R R' = -\varepsilon \frac{3}{8} R^4$ , 即  $R' = -\frac{3}{8} R^3$ , 与 式 (24.62) 一致。



第六步：一阶有界修正 在消除共振后，式 (24.59) 化为

$$(D_0^2 + 1)y_1 = -\frac{1}{4}R^3 \sin 3T_0, \quad (24.70)$$

其中首阶慢相位为零。

因为  $(D_0^2 + 1) \sin 3T_0 = -8 \sin 3T_0$ ，一个非共振特解为  $\frac{R^3}{32} \sin 3T_0$ 。

为使初值在  $O(\varepsilon)$  阶也成立，需要

$$y_1(0, 0) = 0, \quad (24.71)$$

$$D_1 y_0(0, 0) + D_0 y_1(0, 0) = 0. \quad (24.72)$$

由于  $D_1 y_0(0, 0) = R'(0) = -\frac{3}{8}$ ，可取

$$y_1(T_0, T_1) = \frac{R(T_1)^3}{32} (\sin 3T_0 + 9 \sin T_0). \quad (24.73)$$

于是一个满足初值到  $O(\varepsilon^2)$  的修正近似为

$$\boxed{\begin{aligned} y_{\text{MS}}^{[1]}(t) &= R(\varepsilon t) \cos t \\ &\quad + \frac{\varepsilon}{32} R(\varepsilon t)^3 (\sin 3t + 9 \sin t), \end{aligned}} \quad (24.74)$$

其中  $R(T) = (1 + \frac{3}{4}T)^{-1/2}$ 。

注 24.7 (规范自由度).  $y_1$  中的齐次频率 1 项可通过重新定义  $R$  和  $\phi$  部分吸收。不同有界规范若均正确匹配初值，其差异只影响更高阶系数，不改变式 (24.62) 和领先答案式 (24.66)。

第七步：残量和有效性结论 对领先近似  $y_0(t) = R(\varepsilon t) \cos t$  直接代回原方程，利用  $R' = -\frac{3}{8}R^3$  可得

$$y_0'' + y_0 + \varepsilon(y_0')^3 = \frac{\varepsilon}{4}R^3 \sin 3t + O(\varepsilon^2), \quad (24.75)$$

其中余项在  $0 \leq \varepsilon t \leq T_*$  上一致。

加入式 (24.73) 后， $O(\varepsilon)$  非共振残量被消除，形式上有

$$\mathcal{R}_\varepsilon \left[ y_{\text{MS}}^{[1]} \right] = O(\varepsilon^2). \quad (24.76)$$

依据一阶平均定理，对任意固定  $T_* > 0$ ，在相应标准光滑性和紧性条件下：

$$\boxed{\sup_{0 \leq t \leq T_*/\varepsilon} \left| y(t) - \frac{\cos t}{\sqrt{1 + \frac{3}{4}\varepsilon t}} \right| \leq C_{T_*} \varepsilon.} \quad (24.77)$$

必须对第 (ii) 问作如下限定：

1. 领先近似在固定慢时间区间上具有  $O(\varepsilon)$  绝对误差；
2. 该结论允许  $t = O(\varepsilon^{-1})$ ；
3. 一阶相位修正为零，但二阶频率修正可能在  $t = O(\varepsilon^{-2})$  时积累成  $O(1)$ ；
4. 式 (24.68) 是平均振幅方程对更大慢时间的预测，不能仅凭一阶推导宣称对所有  $t \geq 0$  有统一相对误差；
5. 当振幅非常小时，绝对误差和相对误差必须分开讨论。



## 易错点与反例

本题高频失分点:

1. 把  $(-R \sin \theta)^3$  错写成  $+R^3 \sin^3 \theta$ ;
2. 漏掉  $\sin 3\theta$  高次谐波;
3. 得到错误的振幅方程  $R' = -\frac{3}{4}R^3$ ;
4. 把代数衰减误写成指数衰减;
5. 只给  $y \approx \cos t$  而没有慢包络;
6. 只写残量阶, 不说明有效时间;
7. 将“首阶相位方程为零”误写成“精确频率永不改变”;
8. 宣称一阶近似对所有  $t \geq 0$  都有统一相对误差。

## 24.6 正式真题 [25F-Q6]——Rayleigh 振子、稳定极限环与相平面

完整题目叙述: [25F-Q6]

考虑 Rayleigh 振子

$$y'' + y + \varepsilon \left[ \frac{1}{3}(y')^3 - y' \right] = 0, \quad (24.78)$$

初值为

$$y(0) = 0, \quad y'(0) = 2a, \quad a > 0, \quad \varepsilon > 0. \quad (24.79)$$

- (a) 14 分: 当  $\varepsilon$  很小时, 构造一个对大时间有效的近似解;
- (b) 4 分: 说明该近似的精度, 并简要解释;
- (c) 2 分: 对若干不同的  $a$ , 在  $y - y'$  相平面中画出近似轨道, 并解释观察到的现象。

卷面说明: 第 6 题与第 7 题二选一, 按两题得分的较大者计入。

第一步: 能量机制和定性预判 定义  $E = \frac{1}{2}[y'^2 + y^2]$ 。由原方程

$$\begin{aligned} E' &= y'(y'' + y) \\ &= -\varepsilon y' \left[ \frac{1}{3}(y')^3 - y' \right] \\ &= \varepsilon \left[ (y')^2 - \frac{1}{3}(y')^4 \right]. \end{aligned} \quad (24.80)$$

因此:

- 当速度较小时, 线性负阻尼项  $-\varepsilon y'$  向系统输入能量;
- 当速度较大时, 三次阻尼项耗散能量;
- 预计存在一个非零稳定振幅;
- 不同初始振幅的轨道应趋向同一稳定极限环。



第二步：多尺度分阶 令  $T_0 = t$ ,  $T_1 = \varepsilon t$ , 并设  $y = y_0 + \varepsilon y_1 + O(\varepsilon^2)$ 。各阶方程为

$$O(1): \quad (D_0^2 + 1)y_0 = 0, \quad (24.81)$$

$$O(\varepsilon): \quad (D_0^2 + 1)y_1 = -2D_0D_1y_0 - \frac{1}{3}(D_0y_0)^3 + D_0y_0. \quad (24.82)$$

为匹配  $y(0) = 0$ ,  $y'(0) > 0$ , 取

$$y_0 = R(T_1) \sin [T_0 + \phi(T_1)]. \quad (24.83)$$

记  $\theta = T_0 + \phi(T_1)$ 。则

$$D_0y_0 = R \cos \theta, \quad (24.84)$$

$$2D_0D_1y_0 = 2R' \cos \theta - 2R\phi' \sin \theta. \quad (24.85)$$

利用

$$\cos^3 \theta = \frac{3 \cos \theta + \cos 3\theta}{4}, \quad (24.86)$$

得到

$$\begin{aligned} (D_0^2 + 1)y_1 &= \left(-2R' + R - \frac{1}{4}R^3\right) \cos \theta \\ &\quad + 2R\phi' \sin \theta - \frac{1}{12}R^3 \cos 3\theta. \end{aligned} \quad (24.87)$$

第三步：可解性条件和振幅方程 消除频率 1 共振项：

$$-2R' + R - \frac{1}{4}R^3 = 0, \quad (24.88)$$

$$2R\phi' = 0. \quad (24.89)$$

所以

$$\boxed{R' = \frac{1}{2}R - \frac{1}{8}R^3 = \frac{R}{2} \left(1 - \frac{R^2}{4}\right)}, \quad (24.90)$$

以及

$$\boxed{\phi' = 0}. \quad (24.91)$$

初值给出

$$R(0) = 2a, \quad \phi(0) = 0. \quad (24.92)$$

第四步：显式求解振幅方程 令  $q(T_1) = R(T_1)^2$ 。则

$$\begin{aligned} q' &= 2RR' \\ &= q \left(1 - \frac{q}{4}\right). \end{aligned} \quad (24.93)$$


这是 Logistic 方程。

由  $q(0) = 4a^2$  得到

$$q(T_1) = \frac{4}{1 + (a^{-2} - 1)e^{-T_1}}. \quad (24.94)$$

因此

$$\boxed{R(T_1) = \frac{2}{\sqrt{1 + (a^{-2} - 1)e^{-T_1}}}}. \quad (24.95)$$



等价地,

$$R(T_1) = \frac{2a}{\sqrt{a^2 + (1 - a^2)e^{-T_1}}}. \quad (24.96)$$

所以领先长时间近似为

$$y_{\text{MS}}^{[0]}(t) = \frac{2a \sin t}{\sqrt{a^2 + (1 - a^2)e^{-\varepsilon t}}}. \quad (24.97)$$

第五步: 稳定极限振幅 振幅方程  $R' = F(R)$ ,  $F(R) = \frac{R}{2} - \frac{R^3}{8}$  的非负平衡点为

$$R_0 = 0, R_* = 2. \quad (24.98)$$

有

$$F'(0) = \frac{1}{2} > 0, \quad (24.99)$$

$$F'(2) = -1 < 0. \quad (24.100)$$

故:

- 原点在平均振幅动力学中不稳定;
- 振幅  $R = 2$  局部渐近稳定;
- 对任意固定  $a > 0$ ,  $\lim_{T_1 \rightarrow \infty} R(T_1) = 2$ ;
- 当  $0 < a < 1$  时, 振幅从  $2a < 2$  向外增长;
- 当  $a > 1$  时, 振幅从  $2a > 2$  向内衰减;
- 当  $a = 1$  时, 领先振幅恒为 2。

物理时间中的趋近速率为  $e^{-\varepsilon t}$ , 松弛时间为  $O(\varepsilon^{-1})$ 。

第六步: 能量平均的独立验证 由式 (24.80), 取  $y \approx R \sin t$ ,  $y' \approx R \cos t$ 。利用  $\langle \cos^2 t \rangle = \frac{1}{2}$ ,  $\langle \cos^4 t \rangle = \frac{3}{8}$ , 有

$$\langle E' \rangle = \varepsilon \left( \frac{1}{2} R^2 - \frac{1}{8} R^4 \right). \quad (24.101)$$

而  $E \approx \frac{1}{2} R^2$ ,  $E' \approx \varepsilon R R'$ 。故  $R' = \frac{1}{2} R - \frac{1}{8} R^3$ , 与多尺度法一致。

第七步: 一阶波形修正 消除共振后, 式 (24.87) 化为

$$(D_0^2 + 1) y_1 = -\frac{1}{12} R^3 \cos 3T_0. \quad (24.102)$$


因为  $(D_0^2 + 1) \cos 3T_0 = -8 \cos 3T_0$ , 一个特解为  $\frac{R^3}{96} \cos 3T_0$ 。

为满足  $y_1(0, 0) = 0$ ,  $D_1 y_0(0, 0) + D_0 y_1(0, 0) = 0$ , 可取

$$y_1(T_0, T_1) = \frac{R(T_1)^3}{96} (\cos 3T_0 - \cos T_0). \quad (24.103)$$

因此一阶修正近似为

$$y_{\text{MS}}^{[1]}(t) = R(\varepsilon t) \sin t + \frac{\varepsilon}{96} R(\varepsilon t)^3 (\cos 3t - \cos t). \quad (24.104)$$



其速度为

$$\begin{aligned} v_{\text{MS}}^{[1]}(t) &= y_{\text{MS}}^{[1]'}(t) \\ &= R \cos t + \varepsilon \left[ R' \sin t + \frac{R^3}{96} (-3 \sin 3t + \sin t) \right] + O(\varepsilon^2), \end{aligned} \quad (24.105)$$

其中  $R = R(\varepsilon t)$ ,  $R' = \frac{dR}{dT_1}$ 。

当  $T_1 \rightarrow \infty$  时,  $R \rightarrow 2$ ,  $R' \rightarrow 0$ 。稳定极限环的一阶参数方程为

$$y_{\text{lc}}(t) = 2 \sin t + \frac{\varepsilon}{12} (\cos 3t - \cos t) + O(\varepsilon^2), \quad (24.106)$$

$$v_{\text{lc}}(t) = 2 \cos t + \frac{\varepsilon}{12} (-3 \sin 3t + \sin t) + O(\varepsilon^2). \quad (24.107)$$

领先极限环是圆  $y^2 + v^2 = 4$ , 一阶三次谐波使其发生  $O(\varepsilon)$  形变。

第八步: 相平面轨道 在领先阶,


$$y(t) = R(\varepsilon t) \sin t, \quad v(t) = R(\varepsilon t) \cos t. \quad (24.108)$$

故

$$y(t)^2 + v(t)^2 = R(\varepsilon t)^2. \quad (24.109)$$

相平面中的旋转方向为顺时针: 在  $t = 0$  时  $(y, v) = (0, 2a)$ , 而  $t > 0$  很小时  $y > 0$ , 轨道从纵轴上端向右移动。

下面的图为领先阶定性示意; 中间闭曲线对应稳定振幅  $R = 2$ 。



应观察到:

1.  $0 < a < 1$ : 初始半径  $2a < 2$ , 轨道向外螺旋;
2.  $a > 1$ : 初始半径  $2a > 2$ , 轨道向内螺旋;
3.  $a = 1$ : 初始点位于领先极限环上;
4. 所有  $a > 0$  的轨道均趋向同一极限环;



5. 一阶修正使极限环不是严格圆形;
6. 趋近过程发生在  $t = O(\varepsilon^{-1})$  的慢时间尺度。

第九步: 精度与有效区间 对领先近似  $y_0 = R(\varepsilon t) \sin t$  代回原方程, 利用式 (24.90), 其首个残量为非共振三次谐波:

$$y_0'' + y_0 + \varepsilon \left[ \frac{1}{3}(y_0')^3 - y_0' \right] = \frac{\varepsilon}{12} R^3 \cos 3t + O(\varepsilon^2). \quad (24.110)$$

加入式 (24.103) 后,  $O(\varepsilon)$  残量被消除, 形式残量为  $O(\varepsilon^2)$ 。

对题目第 (b) 问, 标准且不夸大的结论为:

$$\sup_{0 \leq t \leq T_*/\varepsilon} |y(t) - y_{\text{MS}}^{[0]}(t)| = O(\varepsilon). \quad (24.111)$$

若使用一阶修正式 (24.104):

- 在固定物理时间区间上, 其形式误差可提高到  $O(\varepsilon^2)$ ;
- 在  $t = O(\varepsilon^{-1})$  上, 若未继续求二阶慢相位, 稳妥的一致结论仍为  $O(\varepsilon)$ ;
- 因为首阶  $\phi' = 0$ , 频率的首个非零修正常在  $O(\varepsilon^2)$ ;
- 当  $t = O(\varepsilon^{-2})$ , 该频率修正会累计成  $O(1)$  相位差。

#### 易错点与反例

本题高频错误包括:

1. 误把稳定振幅写成  $R = 1$ ;
2. 漏掉初始振幅  $R(0) = 2a$ ;
3. 将振幅方程写成  $R' = -R/2 - R^3/8$ ;
4. 只讨论瞬时能量符号, 不作周期平均;
5. 说所有轨道趋向原点;
6. 相平面旋转方向画反;
7. 把领先圆形轨道当作精确极限环;
8. 宣称近似对任意大时间保持  $O(\varepsilon)$  相位精度;
9. 未区分  $a < 1$ 、 $a = 1$ 、 $a > 1$ 。

## 24.7 WKB 方法: 高频相位、输运方程、射线与焦散

【重要性等级】 **C 级**。

WKB 方法未在六套正式博士资格考试中直接出现, 但在 [Yau-2023-P6] 中作为完整题目出现, 并与 [AppAna-Shi] 第 111 页以后 WKB 专题对应。因此纳入历年训练扩展, 但不得计入正式资格考试频率。



## 24.7.1 问题、适用条件与失败信号

考虑半经典 Schrödinger 方程

$$i\varepsilon \partial_t \psi^\varepsilon = -\frac{\varepsilon^2}{2} \Delta_x \psi^\varepsilon + V(x) \psi^\varepsilon. \quad (24.112)$$

WKB 基本设想为

$$\psi^\varepsilon(t, x) = A(t, x) \exp\left(\frac{iS(t, x)}{\varepsilon}\right). \quad (24.113)$$

其中：

- $S$  是快速相位；
- $A$  是慢变振幅；
- 局部波数为  $\nabla S$ ；
- 局部频率为  $-S_t$ ；
- 适用区域必须远离焦散、转向点和相位分支合并点。

单相 WKB 失效的典型信号是：

1. 射线投影的 Jacobian 趋于零；
2. 振幅公式中的分母趋于零；
3. 相位出现多值；
4. 经典速度场形成梯度灾变；
5. 转向点处局部波数消失；
6. 多个相位分支具有同阶贡献。

## 24.8 补充训练题：丘赛 2023 Problem 6——半经典 Schrödinger 方程的 WKB 展开

完整题目叙述：[Yau-2023-P6]

设  $\psi^\varepsilon(t, x)$  满足

$$i\varepsilon \frac{\partial \psi^\varepsilon}{\partial t} = -\frac{\varepsilon^2}{2} \nabla_x^2 \psi^\varepsilon + V(x) \psi^\varepsilon, \quad x = (x_1, \dots, x_n)^\top \in \mathbb{R}^n, \quad (24.114)$$

其中  $i = \sqrt{-1}$ ,  $0 < \varepsilon \ll 1$ ,  $V \in C^\infty(\mathbb{R}^n)$ , 且  $\nabla_x^2 = \sum_{j=1}^n \frac{\partial^2}{\partial x_j^2}$ 。

考虑 WKB 展开

$$\psi^\varepsilon(t, x) = A(t, x) e^{iS(t, x)/\varepsilon}, \quad (24.115)$$

其中  $A, S$  为实值函数，且与  $\varepsilon$  无关。

- (a) 通过渐近展开推导  $A(t, x)$  和  $S(t, x)$  满足的方程；
- (b) 定义  $u(t, x) = \nabla_x S(t, x)$ . 推导  $u$  满足的方程。若  $u(0, \cdot) \in C^\infty(\mathbb{R}^n)$ , 是否一定有  $u(t, \cdot) \in C^\infty(\mathbb{R}^n)$  对所有  $t > 0$ ? 说明理由。

第 (a) 问：完整微分展开 由 式 (24.115)，

$$\partial_t \psi^\varepsilon = e^{iS/\varepsilon} \left[ A_t + \frac{i}{\varepsilon} A S_t \right]. \quad (24.116)$$

空间梯度为

$$\nabla \psi^\varepsilon = e^{iS/\varepsilon} \left[ \nabla A + \frac{i}{\varepsilon} A \nabla S \right]. \quad (24.117)$$

再求散度：

$$\Delta \psi^\varepsilon = e^{iS/\varepsilon} \left[ \Delta A + \frac{2i}{\varepsilon} \nabla A \cdot \nabla S + \frac{i}{\varepsilon} A \Delta S - \frac{1}{\varepsilon^2} A |\nabla S|^2 \right]. \quad (24.118)$$

代入 式 (24.114)，并将所有项移到一侧：

$$0 = e^{iS/\varepsilon} \left\{ -A \left[ S_t + \frac{1}{2} |\nabla S|^2 + V \right] + i\varepsilon \left[ A_t + \nabla S \cdot \nabla A + \frac{1}{2} A \Delta S \right] + \frac{\varepsilon^2}{2} \Delta A \right\}. \quad (24.119)$$

比较  $\varepsilon$  各阶。

第一个方程：程函方程。  $O(1)$  项给出

$$\boxed{S_t + \frac{1}{2} |\nabla S|^2 + V(x) = 0}. \quad (24.120)$$

这是 Hamilton–Jacobi 型程函方程。

第二个方程：输运方程。  $O(\varepsilon)$  项给出

$$\boxed{A_t + \nabla S \cdot \nabla A + \frac{1}{2} A \Delta S = 0}. \quad (24.121)$$

因此，题目第 (a) 问的核心答案是 式 (24.120) and (24.121)。

#### 易错点与反例

由于题目指定  $A, S$  与  $\varepsilon$  无关，式 (24.115) 一般只是领先渐近形式，不是精确解。即使 式 (24.120) and (24.121) 成立，仍留下  $O(\varepsilon^2)$  残量  $\frac{\varepsilon^2}{2} e^{iS/\varepsilon} \Delta A$ 。除非  $\Delta A = 0$ ，不能声称该单项 WKB 表达式精确满足原方程。

概率密度形式 令

$$\rho = A^2. \quad (24.122)$$

将 式 (24.121) 乘以  $2A$ ： $2AA_t + 2A\nabla S \cdot \nabla A + A^2 \Delta S = 0$ 。因此

$$\boxed{\rho_t + \nabla \cdot (\rho \nabla S) = 0}. \quad (24.123)$$


这是沿经典射线的质量守恒方程。

第 (b) 问：速度场方程 定义

$$u = \nabla S. \quad (24.124)$$

对 式 (24.120) 取梯度：

$$u_t + \nabla \cdot \left( \frac{1}{2} |u|^2 \right) + \nabla V = 0. \quad (24.125)$$



由于  $u = \nabla S$  是无旋场,  $\nabla \left(\frac{1}{2}|u|^2\right) = (u \cdot \nabla)u$ 。所以

$$\boxed{u_t + (u \cdot \nabla)u + \nabla V = 0}. \quad (24.126)$$

当  $V = 0$  时, 式 (24.126) 退化为无黏 Burgers 方程

$$u_t + (u \cdot \nabla)u = 0. \quad (24.127)$$

特征线和 **Hamilton** 射线 定义 Hamilton 量

$$H(x, p) = \frac{1}{2}|p|^2 + V(x). \quad (24.128)$$

射线方程为

$$\dot{X}(t, a) = P(t, a), \quad (24.129)$$

$$\dot{P}(t, a) = -\nabla V(X(t, a)), \quad (24.130)$$

$$X(0, a) = a, \quad P(0, a) = u_0(a). \quad (24.131)$$

在经典解存在且射线投影可逆时,

$$u(t, X(t, a)) = P(t, a). \quad (24.132)$$

沿射线, 式 (24.121) 给出

$$\frac{d}{dt} A(t, X(t, a)) = -\frac{1}{2} (\nabla \cdot u) A. \quad (24.133)$$

令

$$J(t, a) = \det D_a X(t, a). \quad (24.134)$$

由 Jacobian 演化公式

$$\frac{dJ}{dt} = J \nabla \cdot u, \quad (24.135)$$

可得

$$\frac{d}{dt} [A^2(t, X(t, a)) J(t, a)] = 0. \quad (24.136)$$

因此

$$\boxed{A^2(t, X(t, a)) J(t, a) = A_0(a)^2}. \quad (24.137)$$

在  $J > 0$  的单值区域,

$$A(t, X(t, a)) = \frac{A_0(a)}{\sqrt{J(t, a)}}. \quad (24.138)$$

光滑初值不保证全局光滑: 显式反例 题目第 (b) 问的答案是:


$$\boxed{u(0, \cdot) \in C^\infty \text{ 并不保证 } u(t, \cdot) \in C^\infty \text{ 对所有 } t > 0}. \quad (24.139)$$

取一维且  $V = 0$ 。方程为

$$u_t + uu_x = 0. \quad (24.140)$$

特征线满足

$$x = a + tu_0(a), \quad u(t, x) = u_0(a). \quad (24.141)$$



对  $a$  求导:

$$\frac{\partial x}{\partial a} = 1 + tu'_0(a). \quad (24.142)$$

从而

$$u_x(t, x) = \frac{u'_0(a)}{1 + tu'_0(a)}. \quad (24.143)$$

若  $\min_a u'_0(a) < 0$ , 则首次梯度爆破时间为

$$t_* = -\frac{1}{\min_a u'_0(a)}. \quad (24.144)$$

取光滑有界初值

$$u_0(a) = -\tanh a. \quad (24.145)$$

则  $u'_0(a) = -\operatorname{sech}^2 a$ ,  $\min_a u'_0(a) = -1$ . 故

$$t_* = 1. \quad (24.146)$$

特征映射为  $x = a - t \tanh a$ , 其 Jacobian 为  $1 - t \operatorname{sech}^2 a$ . 在  $t = 1$ ,  $a = 0$  处 Jacobian 为零, 同时  $u_x(t, x) = -\frac{\operatorname{sech}^2 a}{1 - t \operatorname{sech}^2 a}$  发散。

因此, 尽管初始数据属于  $C^\infty$ , 速度场仍可在有限时间形成梯度灾变。

焦散、相位多值和 **WKB** 失效 当  $J(t, a) = \det D_a X(t, a) = 0$  时, 发生焦散。

由式 (24.138), 振幅形式上满足  $|A| \sim |J|^{-1/2}$ , 因而可能发散。

其几何原因是:

1. Hamilton 相空间中的射线流仍可保持光滑;
2. 但从射线参数  $a$  到物理空间  $x$  的投影失去局部可逆性;
3. 多条射线到达同一物理点;
4. 单一相位  $S(t, x)$  不能描述所有分支;
5. 需要多相 WKB、Maslov 方法、Airy 型局部模型或其他一致近似。

#### 易错点与反例

“射线在相空间中不相交”不能推出“物理空间中无焦散”。

Hamilton 流在  $(x, p)$  相空间中具有唯一性, 但不同射线投影到  $x$ -空间后仍可重合。

残量和解误差的关系 定义 WKB 近似  $\psi_{\text{WKB}}^\varepsilon = Ae^{iS/\varepsilon}$ , 以及 Schrödinger 残量

$$\mathcal{R}^\varepsilon = i\varepsilon \partial_t \psi_{\text{WKB}}^\varepsilon + \frac{\varepsilon^2}{2} \Delta \psi_{\text{WKB}}^\varepsilon - V \psi_{\text{WKB}}^\varepsilon. \quad (24.147)$$

若式 (24.120) and (24.121) 成立, 则

$$\mathcal{R}^\varepsilon = \frac{\varepsilon^2}{2} e^{iS/\varepsilon} \Delta A. \quad (24.148)$$

设精确解与近似解之差为  $e^\varepsilon = \psi - \psi_{\text{WKB}}^\varepsilon$ . 若  $V$  为实值, Schrödinger 演化在  $L^2$  中酉, Duhamel 估计给出

$$\|e^\varepsilon(t)\|_{L^2} \leq \|e^\varepsilon(0)\|_{L^2} + \frac{1}{\varepsilon} \int_0^t \|\mathcal{R}^\varepsilon(s)\|_{L^2} \, ds. \quad (24.149)$$

若在焦散前的固定时间区间  $0 \leq t \leq T$  内  $\|\Delta A(t)\|_{L^2} \leq C$ , 且初始误差为零, 则  $\|e^\varepsilon(t)\|_{L^2} \leq C_T \varepsilon$ . 因此,  $O(\varepsilon^2)$  方程残量在固定时间上通常对应  $O(\varepsilon)$  解误差, 而不是  $O(\varepsilon^2)$  解误差。

高阶 **WKB** 递推 若需要更高阶近似, 可写

$$\psi^\varepsilon = e^{iS/\varepsilon} \sum_{k=0}^N \varepsilon^k A_k. \quad (24.150)$$

定义输运算符

$$\mathcal{T} = \partial_t + \nabla S \cdot \nabla + \frac{1}{2} \Delta S. \quad (24.151)$$

则在程函方程成立后, 各阶满足

$$\mathcal{T} A_0 = 0, \quad (24.152)$$

$$\mathcal{T} A_k = \frac{i}{2} \Delta A_{k-1}, \quad k \geq 1. \quad (24.153)$$

由于右端含  $i$ , 即使  $A_0$  为实值, 高阶振幅  $A_k$  通常是复值。这与题目只要求实值领先振幅并不矛盾。

## 24.9 渐近结果与数值模拟的定量比较

### 24.9.1 验证对象必须分层

对振荡问题, 不应只比较  $|y_{\text{num}} - y_{\text{asy}}|$ 。应分别比较:

1. 波形误差;
2. 振幅包络误差;
3. 相位误差;
4. 能量误差;
5. 调制方程残量;
6. 极限环半径和形状;
7. 有效时间随  $\varepsilon$  的变化。

对余弦规范  $y \approx R \cos \theta$ ,  $v \approx -R \sin \theta$ , 可定义数值振幅

$$R_{\text{num}}(t) = \sqrt{y_{\text{num}}(t)^2 + v_{\text{num}}(t)^2}. \quad (24.154)$$

数值相位可由

$$\theta_{\text{num}}(t) = \text{unwrap}[\text{atan2}(-v_{\text{num}}(t), y_{\text{num}}(t))] \quad (24.155)$$

提取。

对正弦规范  $y \approx R \sin \theta$ ,  $v \approx R \cos \theta$ , 应相应使用  $\theta_{\text{num}} = \text{unwrap}[\text{atan2}(y_{\text{num}}, v_{\text{num}})]$ 。

---

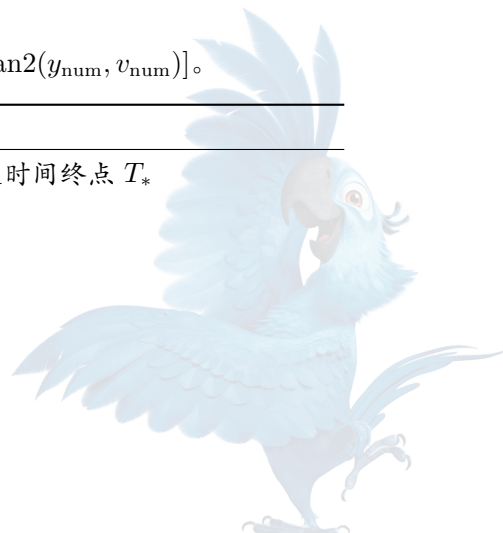
#### Algorithm 83 多尺度近似的数值误差阶验证

---

**Input:** 原始振子方程; 渐近近似  $y_{\text{asy}}$ ; 参数序列  $\varepsilon_1 > \cdots > \varepsilon_m$ ; 固定慢时间终点  $T_*$

**Output:** 波形、振幅、相位和能量误差; 观测收敛阶

- 1: **for**  $j = 1, \dots, m$  **do**
- 2:   设置终止时间  $t_{\text{max}}^{(j)} = \frac{T_*}{\varepsilon_j}$
- 3:   用高精度自适应 ODE 方法求原方程
- 4:   选取数值容差, 使时间积分误差显著小于预期渐近误差



- 5: 计算  $E_y^{(j)} = \max_{0 \leq t \leq t_{\max}^{(j)}} |y_{\text{num}} - y_{\text{asy}}|$
- 6: 提取  $R_{\text{num}}$  和  $\theta_{\text{num}}$
- 7: 计算包络误差、相位误差和能量误差
- 8: **end for**
- 9: 用  $p_j = \frac{\log(E^{(j)}/E^{(j+1)})}{\log(\varepsilon_j/\varepsilon_{j+1})}$  估计观测阶
- 10: **Stopping criterion:** 当减小数值容差不再改变观测阶时停止
- 11: **Complexity:** 若数值步长为  $h$ , 直接积分到  $T_*/\varepsilon$  约需  $O\left(\frac{T_*}{\varepsilon h}\right)$  次函数计算; 渐近公式在  $M$  个时刻求值只需  $O(M)$

### 24.9.2 渐近计算和直接积分的成本比较

若要求解到  $t_{\max} = T_*/\varepsilon$ , 直接时间步进使用固定步长  $h$  时, 成本为

$$O\left(\frac{1}{\varepsilon h}\right). \quad (24.156)$$

多尺度法先解低维慢系统  $R_T = F(R)$ ,  $\phi_T = G(R)$ , 再重构快振荡:

- 若慢系统有显式解, 单点成本为  $O(1)$ ;
- 若慢系统需数值积分, 时间区间仅为  $0 \leq T \leq T_*$ , 与  $\varepsilon^{-1}$  无关;
- 对大量参数重复计算时, 降阶收益更明显;
- 但若需要解析焦散、强非线性或复杂瞬态, 渐近降阶模型可能不足。

### 24.9.3 数值验证中的误判

#### 易错点与反例

以下数值现象不能单独作为渐近结论的证明:

1. 单个  $\varepsilon$  下两条曲线看起来接近;
2. 只比较固定  $t = O(1)$ , 却声称长时间有效;
3. 数值步长误差与渐近误差同阶;
4. 只比较波形, 不分离振幅和相位;
5. 在解过零点附近计算相对误差;
6. 用粗采样漏掉快速振荡;
7. 相位未解缠, 出现人为  $2\pi$  跳跃;
8. WKB 射线已形成焦散, 却仍用单相误差衡量。

## 24.10 模块五正式真题映射与方法总表

### 24.10.1 六套正式试卷的模块五映射

| 试卷  | 正式题号      | 主要主题                                 | 讲义位置           | 计频说明       |
|-----|-----------|--------------------------------------|----------------|------------|
| 23F | Q7        | Sturm–Liouville 特征值的正则摄动展开, 可解性条件    | 第 22 部分        | 模块五主要题 1 次 |
| 24S | 无直接模块五主问题 | 该卷主要涉及数值线性代数、PDE 差分 and 凸优化          | —              | 不计模块五      |
| 24F | Q6        | 奇异摄动边值问题、双边边界层和一致复合展开                | 第 23 部分, 23.11 | 模块五主要题 1 次 |
| 25S | Q6        | 三次阻尼振子、多尺度法和长时间有效性                   | 第 24 部分, 24.5  | 多尺度法 1 次   |
| 25F | Q6        | Rayleigh 振子、稳定极限环和相平面                | 第 24 部分, 24.6  | 多尺度法 1 次   |
| 26S | Q6        | 非线性保守系统的闭轨道和 Poincaré–Lindstedt 周期修正 | 第 22 部分        | 模块五主要题 1 次 |

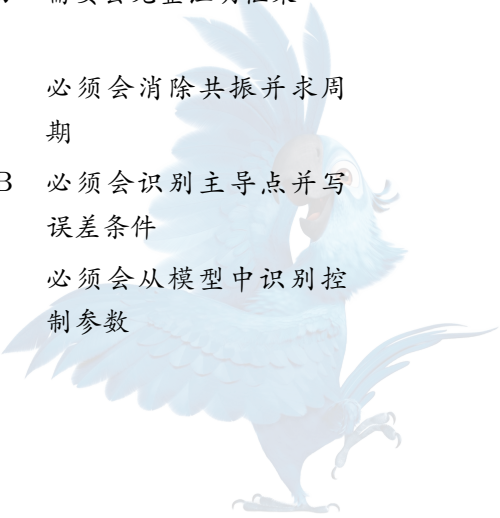
按主要标签、不重复计数的正式题型分布为:

| 主要技巧               | 正式试卷覆盖数 |
|--------------------|---------|
| 正则/特征值摄动           | 1       |
| 奇异摄动与匹配            | 1       |
| 多尺度法               | 2       |
| Poincaré–Lindstedt | 1       |

(24.157)

24.10.2 模块五知识点优先级

| 等级 | 知识点                           | 判定依据               | 要求                |
|----|-------------------------------|--------------------|-------------------|
| S  | 多尺度法、secular term、振幅方程、长时间有效性 | 两套正式试卷直接考查         | 必须完整推导、求解、解释相图和误差 |
| S  | 边界层、匹配、复合展开                   | 正式考查且步骤多、易漏条件      | 需要掌握主导平衡和一致误差     |
| S  | 可解性条件和共振投影                    | 正则摄动、多尺度和特征值摄动共同核心 | 需要会完整证明框架         |
| A  | Poincaré–Lindstedt 方法         | 正式考查闭轨道和周期修正       | 必须会消除共振并求周期       |
| A  | Laplace 方法、Watson 引理、驻相法      | 考纲核心且与振荡积分、WKB 相连  | 必须会识别主导点并写误差条件    |
| A  | 量纲分析、主导平衡、有效区域                | 所有渐近方法的前置          | 必须会从模型中识别控制参数     |





| 等级 | 知识点               | 判定依据           | 要求             |
|----|-------------------|----------------|----------------|
| B  | 高阶渐近、二阶慢时间、频率长期漂移 | 用于提高精度和解释失效    | 掌握框架和典型项       |
| C  | WKB、焦散和转向点        | 丘赛与课程扩展，未计正式频率 | 掌握领先推导、射线和失效机制 |

24.10.3 渐近方法统一比较表

| 方法                 | 识别信号                     | 关键尺度                                    | 核心构造                    | 主要失效机制                     |
|--------------------|--------------------------|-----------------------------------------|-------------------------|----------------------------|
| 正则摄动               | 极限问题不降阶，解对参数平滑           | $t = O(1)$                              | 幂级数逐阶求解；Fredholm 可解性    | secular term；参数依赖不光滑；长时间失效 |
| Poincaré–Lindstedt | 寻找近周期轨道；频率需修正            | $\tau = \omega(\varepsilon)t$           | 时间重标度；消除共振；求 $\omega_j$ | 振幅发生慢漂移；非周期或耗散瞬态           |
| 多尺度法               | 快振荡和慢包络并存                | $T_0 = t, \quad T_1 = \varepsilon t$    | 振幅–相位调制；共振投影            | 漏尺度；内共振；超出目标慢时间            |
| 匹配渐近展开             | 极限降阶；边界或内部快速层            | $x - x_0 = O(\delta(\varepsilon))$      | 外解、内解、匹配、公共部分           | 层位置或尺度错误；无重叠区；缺乏一致稳定性      |
| Laplace/Watson     | 指数权重集中于端点或极值点            | $x - x_0 = O(\lambda^{-1/2})$<br>其他平衡尺度 | 局部展开和 Gaussian 积分       | 极值退化；多个主导点遗漏；端点与驻点合并       |
| 驻相法                | 高频振荡；相位导数为零              | $x - x_0 = O(\lambda^{-1/2})$           | 驻点局部二次展开                | 驻点退化；边界贡献；多个驻点漏加           |
| WKB                | 相位按 $1/\varepsilon$ 快速振荡 | $e^{iS/\varepsilon}$                    | 程函方程、输运方程、射线            | 焦散；转向点；相位多值；振幅爆破           |

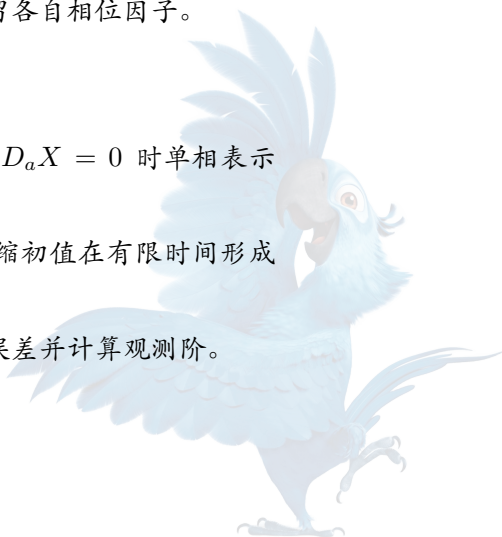
24.10.4 模型量的统一对应关系

| 模型对象     | 渐近对象                        | 考试中应说明的量            |
|----------|-----------------------------|---------------------|
| 弱阻尼振子    | 慢振幅 $R(T)$                  | 衰减律、时间尺度、是否指数衰减     |
| 自激振子     | 振幅固定点 $R_*$                 | 稳定极限环、吸引域、松弛时间      |
| 弱非线性保守振子 | 慢相位或频率修正                    | 周期、相位累计误差、闭轨道       |
| 奇异边值问题   | 边界层厚度 $\delta(\varepsilon)$ | 层位置、匹配方向、一致误差       |
| 振荡积分     | 驻点、端点、鞍点                    | 主导贡献、相位因子、误差阶       |
| 半经典波动    | 相位 $S$ 、振幅 $A$ 、射线 $X$      | 焦散时间、Jacobian、单相有效区 |
| 无量纲模型    | 控制参数 $\varepsilon, \mu$     | 参数来源、极限模型和有效参数区间    |



## 24.11 模块五易错点、反例与参考答题规范

| 错误说法或错误做法                                          | 正确处理                                                                |
|----------------------------------------------------|---------------------------------------------------------------------|
| 渐近级数必须收敛。                                          | 渐近级数只要求截断余项按给定渐近序列减小，可能发散。                                          |
| $f \sim g$ 等价于 $f - g = O(g)$ 。                    | $f \sim g$ 要求 $f/g \rightarrow 1$ ; 仅有同阶界通常不够。                      |
| 点态有效就是一致有效。                                        | 必须明确区域并估计上确界; 边界层外解常只点态有效。                                          |
| 小参数乘最高阶导数时仍作普通正则展开。                                | 先检查极限是否降阶; 若降阶, 应寻找边界层或内部层。                                         |
| 边界层厚度总是 $\varepsilon$ 。                            | 层厚由主导平衡决定, 可能是 $\sqrt{\varepsilon}$ 、 $\varepsilon^{3/4}$ 等。        |
| 匹配是在某个固定点令内外解相等。                                   | 应在 $\delta \ll  x - x_0  \ll 1$ 的重叠区比较渐近展开。                         |
| 复合解等于外解加内解。                                        | 必须减去公共部分。                                                           |
| 普通摄动出现 $t \sin t$ , 说明精确解发散。                       | 它说明展开失去长期有序性, 应引入慢时间或频率修正。                                          |
| 多尺度变量从一开始就是相互依赖的。                                  | 分阶时形式上独立, 推导结束后再代回 $T_j = \varepsilon^j t$ 。                        |
| 只要消除一个共振项即可。                                       | 二阶算子核通常有正弦和余弦两个方向, 必须分别投影。                                          |
| 振幅方程正确就无需相位方程。                                     | 慢相位决定长期频率和相位误差; 不能省略。                                               |
| $\phi' = 0$ 说明精确频率等于 1。                            | 只说明 $O(\varepsilon)$ 频率修正为零; 更高阶修正仍可能非零。                            |
| $O(\varepsilon^2)$ 残量意味着 $O(\varepsilon^2)$ 长时间误差。 | 必须结合稳定性和时间长度; 在 $t = O(\varepsilon^{-1})$ 上常只能保证 $O(\varepsilon)$ 。 |
| 平均能量单调即可证明瞬时能量单调。                                  | 平均符号和瞬时符号不同; Rayleigh 振子的瞬时能量可增可减。                                  |
| 稳定振幅就是精确圆形极限环。                                     | 高次谐波会使轨道发生 $O(\varepsilon)$ 形变。                                     |
| 相图中只需画圆, 不说明方向。                                    | 必须标出顺/逆时针、向内/向外及稳定环。                                                |
| Laplace 方法只需找极值点。                                  | 还需检查极值位置、退化性、端点贡献和正则性。                                              |
| 驻相法对任意驻点都给 $\lambda^{-1/2}$ 。                      | 退化驻点有不同尺度和幂次。                                                       |
| 多个驻点时只保留最大一个。                                      | 同阶驻点贡献必须相加, 并保留各自相位因子。                                              |
| WKB 的程函方程和输运方程合起来就是精确解。                            | 单项 WKB 仍有 $O(\varepsilon^2)$ 残量。                                    |
| Hamilton 射线光滑, 所以 $u(t, x)$ 全局光滑。                  | 物理空间投影可形成焦散; $\det D_a X = 0$ 时单相表示失效。                              |
| 初始数据光滑就不会形成冲击。                                     | 无黏 Burgers 方程可由光滑压缩初值在有限时间形成梯度灾变。                                   |
| 数值曲线在一个参数下接近即可验证误差阶。                               | 必须使用参数序列、控制离散误差并计算观测阶。                                              |



错误说法或错误做法

正确处理

模型中的  $\varepsilon$  只是一个给定小常数。 应由无量纲化说明其物理来源；其有效小量常与振幅组合出现。

## 多尺度振子题的统一答题框架

识别信号：弱非线性、弱阻尼、近周期、大时间、相平面、极限环。

构造步骤：

1. 写明  $\varepsilon \rightarrow 0^+$ ;
2. 选择  $T_0 = t, \quad T_1 = \varepsilon t$ ;
3. 展开导数;
4. 写出  $O(1)$  和  $O(\varepsilon)$  方程;
5. 用振幅-相位形式表示  $y_0$ ;
6. 将非线性展开成 Fourier 模态;
7. 消除频率 1 共振;
8. 解振幅和相位方程;
9. 匹配初值;
10. 求必要的高次谐波;
11. 说明残量阶和有效时间;
12. 用能量或相平面作独立验证。

关键估计：  $\sup_{0 \leq t \leq T_*/\varepsilon} |y - y_{MS}| \leq C_{T_*} \varepsilon$ 。

结论：得到快振荡、慢包络和慢相位的统一近似。

失败原因：漏共振、漏慢相位、初值规范错误、误差区间不清、初始振幅非  $O(1)$ 、超出目标时间尺度。

## WKB 题的统一答题框架

识别信号：小参数位于最高阶导数前，且解具有  $e^{iS/\varepsilon}$  型高频相位。

构造步骤：

1. 完整计算时间导数和 Laplacian;
2. 比较  $O(1)$  得到程函方程;
3. 比较  $O(\varepsilon)$  得到输运方程;
4. 对程函方程取梯度得到速度场方程;
5. 写 Hamilton 特征线;
6. 用 Jacobian 表示振幅;
7. 检查  $\det D_a X \neq 0$ ;

8. 给出焦散或梯度灾变的失效条件。

关键估计：焦散前若  $\|\Delta A\|_{L^2} \leq C$ ，则领先 WKB 残量为  $O(\varepsilon^2)$ ，固定时间  $L^2$  解误差通常为  $O(\varepsilon)$ 。

结论：WKB 只在单相、光滑、无焦散区域内有效。

失败原因：转向点、焦散、多相干涉、相位多值、振幅 Jacobian 发散。



## 第六部分

### 线性规划与优化



## 第二十五章 凸集、凸函数、分离、次梯度、投影、法锥、极集与双极理论

### 25.1 仿射集、凸集、凸包、凸锥与基本运算

#### 25.1.1 知识点一：仿射组合与仿射集

【重要性等级】 **A 级**。给定  $x_1, \dots, x_m \in \mathbb{R}^n$ , 若系数满足  $\sum_{i=1}^m \theta_i = 1$ , 则

$$x = \sum_{i=1}^m \theta_i x_i \quad (25.1)$$

称为这些点的仿射组合。

集合  $A \subseteq \mathbb{R}^n$  称为仿射集, 如果

$$x, y \in A, \quad \theta \in \mathbb{R} \implies \theta x + (1 - \theta)y \in A. \quad (25.2)$$

非空仿射集必可写成

$$A = x_0 + L, \quad (25.3)$$

其中  $L$  为线性子空间。

典型仿射集为线性方程组解集

$$A = \{x \in \mathbb{R}^n : Bx = b\}. \quad (25.4)$$

若该集合非空, 取任意特解  $x_0$ , 则  $A = x_0 + \ker B$ 。

#### 25.1.2 知识点二：凸组合、凸集与凸包

系数满足  $\theta_i \geq 0$ ,  $\sum_{i=1}^m \theta_i = 1$  时,  $\sum_{i=1}^m \theta_i x_i$  称为凸组合。

集合  $C \subseteq \mathbb{R}^n$  称为凸集, 如果


$$x, y \in C, \quad 0 \leq \theta \leq 1 \implies \theta x + (1 - \theta)y \in C. \quad (25.5)$$

集合  $S$  的凸包定义为

$$\operatorname{conv} S = \bigcap \{C : C \supseteq S, C \text{ 为凸集}\} \quad (25.6)$$

$$= \left\{ \sum_{i=1}^m \theta_i x_i : m \in \mathbb{N}, x_i \in S, \theta_i \geq 0, \sum_{i=1}^m \theta_i = 1 \right\}. \quad (25.7)$$

定理 25.1 (Carathéodory 定理). 若  $x \in \operatorname{conv} S \subseteq \mathbb{R}^n$ , 则  $x$  可表示为至多  $n+1$  个  $S$  中点的凸组合。



证明. 设  $x = \sum_{i=1}^m \lambda_i x_i$ ,  $\lambda_i > 0$ ,  $\sum_{i=1}^m \lambda_i = 1$ , 且  $m > n + 1$ 。

向量  $\begin{pmatrix} x_i \\ 1 \end{pmatrix} \in \mathbb{R}^{n+1}$ ,  $i = 1, \dots, m$ , 线性相关。故存在不全为零的  $\alpha_i$ , 使

$$\sum_{i=1}^m \alpha_i x_i = 0, \quad \sum_{i=1}^m \alpha_i = 0. \quad (25.8)$$

至少有一个  $\alpha_i > 0$ 。令

$$t = \min_{\alpha_i > 0} \frac{\lambda_i}{\alpha_i}. \quad (25.9)$$

定义  $\tilde{\lambda}_i = \lambda_i - t\alpha_i$ 。则:

$$\tilde{\lambda}_i \geq 0, \quad (25.10)$$

$$\sum_i \tilde{\lambda}_i = 1, \quad (25.11)$$

$$\sum_i \tilde{\lambda}_i x_i = x, \quad (25.12)$$

并且至少一个  $\tilde{\lambda}_i = 0$ 。

故可删去至少一个点。反复进行该过程, 最终只需至多  $n + 1$  个点。  $\square$

注 25.2. Carathéodory 定理给出有限维凸组合表示的稀疏性: 虽然  $\text{conv } S$  允许任意有限多个点, 在  $\mathbb{R}^n$  中至多  $n + 1$  个点已经足够。

### 25.1.3 知识点三: 凸锥与锥包

集合  $K \subseteq \mathbb{R}^n$  称为锥, 如果

$$x \in K, \quad \lambda \geq 0 \implies \lambda x \in K. \quad (25.13)$$

若  $K$  同时为凸集, 则称为凸锥。等价地,

$$x_i \in K, \quad \lambda_i \geq 0 \implies \sum_i \lambda_i x_i \in K. \quad (25.14)$$

集合  $S$  生成的锥包为


$$\text{cone } S = \left\{ \sum_{i=1}^m \lambda_i x_i : x_i \in S, \lambda_i \geq 0 \right\}. \quad (25.15)$$

典型凸锥包括:

$$\mathbb{R}_+^n = \{x : x_i \geq 0\}, \quad (25.16)$$

$$\mathbb{S}_+^n = \{X = X^\top : X \succeq 0\}, \quad (25.17)$$

$$\mathcal{Q}^{n+1} = \{(x, t) : \|x\|_2 \leq t\}. \quad (25.18)$$



## 25.1.4 知识点四：相对内部

若凸集  $C$  不满维，则通常  $\text{int } C = \emptyset$ 。为此定义仿射包  $\text{aff } C$  及相对内部

$$\text{ri } C = \{x \in C : \exists r > 0, B(x, r) \cap \text{aff } C \subseteq C\}. \quad (25.19)$$

在有限维空间中，任意非空凸集均满足  $\text{ri } C \neq \emptyset$ 。

相对内部在：

- 凸函数次微分非空性；
- 约束资格条件；
- 凸集分离；
- 次微分和规则；

中均起关键作用。

## 易错点与反例

若  $C = \{x : Ax = b\}$  为低维仿射集，则  $\text{int } C = \emptyset$ ，但  $\text{ri } C = C$ 。因此在低维可行域上，不应把  $\text{int}$  和  $\text{ri}$  混用。

## 25.1.5 知识点五：保持凸性的集合运算

下列运算保持凸性：

1. 任意族凸集的交；
2. 仿射映射的像；
3. 仿射映射的原像；
4. Cartesian 积；
5. 透视映射下的适当像与原像；
6. 对变量作部分消元后得到的可行值集合投影。

特别地，若  $F(x) = Ax + b$ ，则

$$C \text{ 凸} \implies F(C) \text{ 凸}, \quad (25.20)$$

$$D \text{ 凸} \implies F^{-1}(D) \text{ 凸}. \quad (25.21)$$

因此：

- 线性等式可行集为仿射集；
- 线性不等式可行集为半空间交；
- 线性规划可行域为多面体；
- 半正定约束的仿射原像为凸集。



## 凸集证明的标准套路

识别信号:

- 约束由仿射等式、线性不等式、范数或半正定条件构成;
- 集合被写成若干已知凸集之交或仿射原像;
- 题目要求证明某个可行域、次水平集或像集为凸集。

构造步骤:

1. 取任意  $x, y \in C$ ,  $0 \leq \theta \leq 1$ ;
2. 令  $z = \theta x + (1 - \theta)y$ ;
3. 对每一个约束逐项验证  $z$  仍可行;
4. 或将集合表示为凸集之交、仿射像或原像。

关键估计:

$$\|\theta x + (1 - \theta)y\| \leq \theta \|x\| + (1 - \theta) \|y\|.$$

结论: 线段完全包含于集合。

常见失败原因:

- 只验证中点而未说明如何推广到任意  $\theta$ ;
- 把凸集与凸锥混淆;
- 仿射像保持凸性, 但一般非线性像不保持;
- 凸集的并一般不凸;
- 低维集合使用普通内部而不是相对内部。

## 25.2 Euclidean 投影、法锥与非扩张性

## 25.2.1 知识点六: 闭凸集投影的存在唯一性

【重要性等级】 **S 级**。给定非空集合  $C \subseteq \mathbb{R}^n$  及点  $z \in \mathbb{R}^n$ , Euclidean 投影问题为


$$\min_{x \in C} \frac{1}{2} \|x - z\|_2^2. \quad (25.22)$$

若最优点存在且唯一, 记为

$$P_C(z) = \arg \min_{x \in C} \frac{1}{2} \|x - z\|_2^2. \quad (25.23)$$

定理 25.3 (闭凸集投影定理). 若  $C \subseteq \mathbb{R}^n$  非空、闭且凸, 则对每个  $z \in \mathbb{R}^n$ , 式 (25.22) 存在唯一最优解。

证明. 先证存在性. 取任意  $x_0 \in C$ , 并取极小化序列  $\{x_k\} \subset C$ , 满足  $\frac{1}{2} \|x_k - z\|_2^2 \rightarrow \inf_{x \in C} \frac{1}{2} \|x - z\|_2^2$ . 对充分大的  $k$ , 有  $\|x_k - z\|_2 \leq \|x_0 - z\|_2 + 1$ . 故  $\{x_k\}$  有界. 在有限维空间中可取收敛子列  $x_{k_j} \rightarrow p$ . 因为  $C$  闭,  $p \in C$ . 由目标函数连续,  $p$  达到最小值。





再证唯一性。若  $p, q \in C$  均为最优点且  $p \neq q$ , 由  $C$  凸,  $\frac{p+q}{2} \in C$ 。平方范数严格凸, 故

$$\left\| \frac{p+q}{2} - z \right\|_2^2 < \frac{1}{2} \|p - z\|_2^2 + \frac{1}{2} \|q - z\|_2^2, \quad (25.24)$$

与  $p, q$  均最优矛盾。  $\square$

### 易错点与反例

投影存在唯一需要分别使用不同假设:

- 非空: 问题有可行点;
- 闭: 保证极限点仍在集合中;
- 凸: 保证最优点唯一。

反例:

$$C = (0, 1), \quad z = 0 \implies \text{最小距离不取到}; \quad (25.25)$$

$$C = \{-1, 1\}, \quad z = 0 \implies \text{有两个投影点}. \quad (25.26)$$

### 25.2.2 知识点七: 投影的变分不等式

定理 25.4 (投影最优性条件). 设  $C$  非空、闭、凸,  $p \in C$ 。则

$$p = P_C(z) \quad (25.27)$$

当且仅当

$$\langle z - p, x - p \rangle \leq 0, \quad \forall x \in C. \quad (25.28)$$

证明. 若  $p = P_C(z)$ , 对任意  $x \in C$  及  $0 \leq t \leq 1$ , 由凸性  $p + t(x - p) \in C$ 。定义  $\varphi(t) = \frac{1}{2} \|p + t(x - p) - z\|_2^2$ 。  $t = 0$  是  $[0, 1]$  上的最小点, 故  $\varphi'(0^+) = \langle p - z, x - p \rangle \geq 0$ , 即 式 (25.28)。

反之, 若 式 (25.28) 成立, 则对任意  $x \in C$ :

$$\begin{aligned} \|x - z\|_2^2 &= \|(x - p) + (p - z)\|_2^2 \\ &= \|x - p\|_2^2 + \|p - z\|_2^2 + 2\langle x - p, p - z \rangle \\ &\geq \|p - z\|_2^2. \end{aligned} \quad (25.29)$$

故  $p$  为投影。  $\square$


注 25.5. 若  $C$  是线性子空间, 则  $x - p$  可同时取任意子空间方向及其相反方向, 从而  $\langle z - p, x - p \rangle = 0$ 。这退化为正交投影条件。

对一般凸集, 只能得到不等式, 不能无条件写成正交等式。

### 25.2.3 知识点八: 法锥与投影的等价关系

对闭凸集  $C$ , 法锥定义为

$$N_C(p) = \{v : \langle v, x - p \rangle \leq 0, \quad \forall x \in C\}, \quad p \in C. \quad (25.30)$$



若  $p \notin C$ , 定义  $N_C(p) = \emptyset$ .

由 定义 25.4:

$$p = P_C(z) \iff z - p \in N_C(p). \quad (25.31)$$

也可写成

$$0 \in p - z + N_C(p). \quad (25.32)$$

典型法锥如下。

半空间。 若  $C = \{x : a^\top x \leq b\}$ ,  $a \neq 0$ , 则

$$N_C(x) = \begin{cases} \{0\}, & a^\top x < b, \\ \{\lambda a : \lambda \geq 0\}, & a^\top x = b. \end{cases} \quad (25.33)$$

仿射集。 若  $C = \{x : Ax = b\}$ , 则

$$N_C(x) = \text{range}(A^\top), \quad x \in C. \quad (25.34)$$

非负正交锥。 若  $C = \mathbb{R}_+^n$ , 则

$$N_C(x) = \left\{ v : \begin{cases} v_i = 0, & x_i > 0, \\ v_i \leq 0, & x_i = 0 \end{cases} \right\}. \quad (25.35)$$

特别地,

$$N_{\mathbb{R}_+^n}(0) = -\mathbb{R}_+^n. \quad (25.36)$$

#### 25.2.4 知识点九: 法锥的单调性与投影的牢固非扩张性

命题 25.6 (法锥算子的单调性). 若  $u \in N_C(x)$ ,  $v \in N_C(y)$ , 则

$$\langle u - v, x - y \rangle \geq 0. \quad (25.37)$$

证明. 由法锥定义:  $\langle u, y - x \rangle \leq 0$ ,  $\langle v, x - y \rangle \leq 0$ . 两式相加即得  $\langle u - v, y - x \rangle \leq 0$ .  $\square$

令  $p = P_C(z)$ ,  $q = P_C(w)$ . 由 式 (25.31):  $z - p \in N_C(p)$ ,  $w - q \in N_C(q)$ . 代入 式 (25.37):  $\langle (z - p) - (w - q), p - q \rangle \geq 0$ . 因此

$$\|P_C(z) - P_C(w)\|_2^2 \leq \langle P_C(z) - P_C(w), z - w \rangle. \quad (25.38)$$

这称为牢固非扩张性 (firm nonexpansiveness)。

由 Cauchy-Schwarz 不等式:

$$\|P_C(z) - P_C(w)\|_2 \leq \|z - w\|_2. \quad (25.39)$$


故 Euclidean 投影的绝对条件数不超过 1。

残差映射

$$R_C := I - P_C \quad (25.40)$$

同样牢固非扩张:

$$\|R_C(z) - R_C(w)\|_2^2 \leq \langle R_C(z) - R_C(w), z - w \rangle. \quad (25.41)$$



特别地,

$$\|R_C(z) - R_C(w)\|_2 \leq \|z - w\|_2. \quad (25.42)$$

#### 易错点与反例

非扩张不等于压缩。

投影映射通常满足 Lipschitz 常数 1, 而不是严格小于 1。

例如投影到整个空间  $P_{\mathbb{R}^n} = I$  的 Lipschitz 常数恰为 1。因此不能直接用压缩映射定理断言投影迭代收敛。

### 25.2.5 知识点十: 距离函数与平方距离函数

定义

$$d_C(z) = \inf_{x \in C} \|z - x\|_2, \quad (25.43)$$

$$\Theta_C(z) = \frac{1}{2}d_C(z)^2 = \frac{1}{2}\|z - P_C(z)\|_2^2. \quad (25.44)$$

对非空闭凸集  $C$ :

1.  $d_C$  为凸函数;
2.  $d_C$  是 1-Lipschitz 函数:

$$|d_C(z) - d_C(w)| \leq \|z - w\|_2; \quad (25.45)$$

3. 若  $z \notin C$ , 则

$$\nabla d_C(z) = \frac{z - P_C(z)}{\|z - P_C(z)\|_2}; \quad (25.46)$$

4. 若  $z \in C$ , 则

$$\partial d_C(z) = N_C(z) \cap \{g : \|g\|_2 \leq 1\}; \quad (25.47)$$

5.  $\Theta_C$  在整个  $\mathbb{R}^n$  上连续可微, 且

$$\boxed{\nabla \Theta_C(z) = z - P_C(z)}; \quad (25.48)$$

6.  $\nabla \Theta_C$  是 1-Lipschitz:

$$\|\nabla \Theta_C(z) - \nabla \Theta_C(w)\|_2 \leq \|z - w\|_2. \quad (25.49)$$

#### 易错点与反例

距离函数和平方距离函数的可微性不同:

- $d_C$  在边界上通常不可微;
- $\frac{1}{2}d_C^2$  在闭凸情形下处处  $C^1$ ;
- 二者不能交换使用。

## 25.2.6 基础例题：投影到仿射集

投影到线性等式约束

设  $C = \{x \in \mathbb{R}^n : Ax = b\}$ ,  $A \in \mathbb{R}^{m \times n}$ , 其中  $A$  满行秩, 且  $C \neq \emptyset$ . 求  $P_C(z)$ .

证明. 考虑

$$\min_x \frac{1}{2} \|x - z\|_2^2 \quad \text{s.t.} \quad Ax = b. \quad (25.50)$$

Lagrange 函数为  $L(x, \lambda) = \frac{1}{2} \|x - z\|_2^2 + \lambda^\top (Ax - b)$ . 一阶条件为

$$x - z + A^\top \lambda = 0, \quad (25.51)$$

$$Ax = b. \quad (25.52)$$

由第一式  $x = z - A^\top \lambda$ . 代入约束:

$$AA^\top \lambda = Az - b. \quad (25.53)$$

由于  $A$  满行秩,  $AA^\top \succ 0$ . 故

$$P_C(z) = z - A^\top (AA^\top)^{-1} (Az - b). \quad (25.54)$$

投影残差  $z - P_C(z) = A^\top (AA^\top)^{-1} (Az - b) \in \text{range}(A^\top) = N_C(P_C(z))$ , 与式 (25.31) 一致.  $\square$

**Algorithm 84** 满行秩线性等式约束的 Euclidean 投影

**Input:**  $A \in \mathbb{R}^{m \times n}$  满行秩;  $b \in \mathbb{R}^m$ ; 待投影点  $z \in \mathbb{R}^n$

**Output:**  $p = P_C(z)$ , 其中  $C = \{x : Ax = b\}$

- 1: **Initialization:** 计算  $G = AA^\top$  并作 Cholesky 分解  $G = LL^\top$
- 2: 计算约束残差  $r = Az - b$
- 3: 解  $LL^\top \lambda = r$
- 4: 计算  $p = z - A^\top \lambda$
- 5: **Stopping criterion:** 检查  $\|Ap - b\|_2 \leq \text{tol}$  及  $z - p \in \text{range}(A^\top)$
- 6: **Complexity:** 稠密情形下: 形成  $AA^\top$  需  $O(m^2n)$ ; 一次 Cholesky 分解需  $O(m^3)$ ; 每个新  $z$  的投影需  $O(mn + m^2)$ ; 存储为  $O(mn + m^2)$

## 25.3 正式真题 [25S-Q7]——投影与平方距离函数

完整题目叙述: [25S-Q7]

设  $K \subseteq \mathbb{R}^n$  是非空闭凸集. 对任意  $z \in \mathbb{R}^n$ , 定义  $\Pi_K(z)$  为问题

$$\min_{y \in K} \frac{1}{2} \|y - z\|_2^2 \quad (25.55)$$

的最优解.

证明:

(i)

$$\langle z - \Pi_K(z), d - \Pi_K(z) \rangle \leq 0, \quad \forall d \in K; \quad (25.56)$$

(ii) 定义

$$\Theta(z) := \frac{1}{2} \|z - \Pi_K(z)\|_2^2. \quad (25.57)$$

证明  $\Theta$  为连续可微凸函数, 且

$$\nabla \Theta(z) = z - \Pi_K(z). \quad (25.58)$$

预备: 最优点存在且唯一. 因为  $s \mapsto s^2$  在  $s \geq 0$  上严格递增, 式 (25.55) 与  $\min_{y \in K} \frac{1}{2} \|y - z\|_2^2$  具有相同最优点。

由闭凸集投影定理, 最优点存在且唯一. 故  $\Pi_K(z)$  定义良好, 并且  $\Pi_K = P_K$ .  $\square$

第 (i) 问. 记  $p = \Pi_K(z)$ . 对任意  $d \in K$  和  $0 \leq t \leq 1$ ,  $p + t(d - p) \in K$ . 令  $\varphi(t) = \frac{1}{2} \|p + t(d - p) - z\|_2^2$ . 因为  $t = 0$  是最小点,  $\varphi'(0^+) \geq 0$ . 而  $\varphi'(0^+) = \langle p - z, d - p \rangle$ . 所以

$$\langle z - p, d - p \rangle \leq 0, \quad \forall d \in K. \quad (25.59)$$

$\square$

第 (ii) 问第一步: 证明凸性. 任取  $z_1, z_2 \in \mathbb{R}^n$ , 记  $p_i = \Pi_K(z_i)$ ,  $i = 1, 2$ . 对  $0 \leq \theta \leq 1$ , 令  $z_\theta = \theta z_1 + (1 - \theta)z_2$ ,  $p_\theta = \theta p_1 + (1 - \theta)p_2$ . 由  $K$  凸,  $p_\theta \in K$ . 所以

$$\begin{aligned} \Theta(z_\theta) &\leq \frac{1}{2} \|z_\theta - p_\theta\|_2^2 \\ &= \frac{1}{2} \|\theta(z_1 - p_1) + (1 - \theta)(z_2 - p_2)\|_2^2 \\ &\leq \theta \Theta(z_1) + (1 - \theta) \Theta(z_2). \end{aligned} \quad (25.60)$$

故  $\Theta$  为凸函数.  $\square$

第 (ii) 问第二步: 构造全局次梯度. 固定  $z, w \in \mathbb{R}^n$ , 记

$$p = \Pi_K(z), \quad q = \Pi_K(w), \quad (25.61)$$

$$r = z - p, \quad s = w - q. \quad (25.62)$$

由第 (i) 问, 取  $d = q$ :

$$\langle r, q - p \rangle \leq 0. \quad (25.63)$$


又  $w - z = (q - p) + (s - r)$ . 因此

$$\begin{aligned} \Theta(z) + \langle r, w - z \rangle &= \frac{1}{2} \|r\|_2^2 + \langle r, q - p \rangle + \langle r, s - r \rangle \\ &= -\frac{1}{2} \|r\|_2^2 + \langle r, s \rangle + \langle r, q - p \rangle \\ &\leq -\frac{1}{2} \|r\|_2^2 + \langle r, s \rangle \\ &\leq \frac{1}{2} \|s\|_2^2 \\ &= \Theta(w). \end{aligned} \quad (25.64)$$

最后一步使用  $\frac{1}{2} \|s - r\|_2^2 \geq 0$ . 因此

$$z - \Pi_K(z) \in \partial \Theta(z). \quad (25.65)$$

$\square$



第 (ii) 问第三步：证明次梯度唯一。设  $g \in \partial\Theta(z)$ 。对任意  $h \in \mathbb{R}^n$ ，由次梯度不等式：

$$\Theta(z+h) \geq \Theta(z) + \langle g, h \rangle. \quad (25.66)$$

另一方面，使用  $p = \Pi_K(z)$  作为  $z+h$  处的可行点：

$$\begin{aligned} \Theta(z+h) &\leq \frac{1}{2} \|z+h-p\|_2^2 \\ &= \Theta(z) + \langle z-p, h \rangle + \frac{1}{2} \|h\|_2^2. \end{aligned} \quad (25.67)$$

合并：

$$\langle g - (z-p), h \rangle \leq \frac{1}{2} \|h\|_2^2. \quad (25.68)$$

若  $g \neq z-p$ ，取  $h = t[g - (z-p)]$ ， $t > 0$ 。则  $t \|g - (z-p)\|_2^2 \leq \frac{t^2}{2} \|g - (z-p)\|_2^2$ 。令  $t \rightarrow 0^+$  得到矛盾。

故

$$\partial\Theta(z) = \{z - \Pi_K(z)\}. \quad (25.69)$$

有限凸函数在开域  $\mathbb{R}^n$  上次微分为单点，因此可微，且

$$\nabla\Theta(z) = z - \Pi_K(z). \quad (25.70)$$

□

第 (ii) 问第四步：证明梯度连续。由投影残差映射的非扩张性：

$$\begin{aligned} \|\nabla\Theta(z) - \nabla\Theta(w)\|_2 &= \|[z - \Pi_K(z)] - [w - \Pi_K(w)]\|_2 \\ &\leq \|z - w\|_2. \end{aligned} \quad (25.71)$$

所以  $\nabla\Theta$  连续，且 Lipschitz 常数不超过 1。

综上， $\Theta \in C^{1,1}(\mathbb{R}^n)$  且为凸函数。

□

#### 易错点与反例

本题常见错误：

1. 把  $\langle z-p, d-p \rangle \leq 0$  写成反号；
2. 未使用  $K$  的闭性证明投影存在；
3. 未使用凸性证明投影唯一；
4. 只证明方向导数，未证明 Fréchet 可微；
5. 直接对  $P_K$  求导；
6. 误称  $P_K$  为压缩映射；
7. 把  $d_K$  和  $\frac{1}{2}d_K^2$  的可微性混为一谈。

## 25.4 分离超平面、支撑超平面与分离裕量

### 25.4.1 知识点十一：超平面与半空间

超平面定义为

$$H = \{x : a^\top x = b\}, \quad a \neq 0. \quad (25.72)$$

向量  $a$  为法向量。

对应的两个闭半空间为

$$H_- = \{x : a^\top x \leq b\}, \quad (25.73)$$

$$H_+ = \{x : a^\top x \geq b\}. \quad (25.74)$$

超平面为仿射集，半空间为闭凸集。

### 25.4.2 知识点十二：弱分离和严格分离

**定理 25.7** (弱分离定理). 设  $C, D \subseteq \mathbb{R}^n$  为非空、不交凸集。则存在  $a \neq 0$ ,  $b \in \mathbb{R}$ , 使

$$a^\top x \leq b, \quad \forall x \in C, \quad (25.75)$$

$$a^\top y \geq b, \quad \forall y \in D. \quad (25.76)$$

弱分离不要求严格间隙。例如两个不交开凸集可以具有零距离，只能被弱分离。

**定理 25.8** (闭凸集与外点的严格分离). 设  $C \subseteq \mathbb{R}^n$  非空、闭、凸，且  $z \notin C$ 。则存在  $a \neq 0$ , 使

$$\sup_{x \in C} a^\top x < a^\top z. \quad (25.77)$$

证明. 令  $p = P_C(z)$ ,  $a = z - p$ 。因为  $z \notin C$ ,  $a \neq 0$ 。投影变分不等式给出  $\langle a, x - p \rangle \leq 0$ ,  $\forall x \in C$ 。故

$$a^\top x \leq a^\top p, \quad \forall x \in C. \quad (25.78)$$

而

$$a^\top z = a^\top p + \|a\|_2^2 > a^\top p. \quad (25.79)$$

于是  $\sup_{x \in C} a^\top x \leq a^\top p < a^\top z$ 。□

若将法向量单位化:  $\hat{a} = \frac{z-p}{\|z-p\|_2}$ , 则分离间隙为

$$\hat{a}^\top z - \sup_{x \in C} \hat{a}^\top x \geq \|z - p\|_2 = d_C(z). \quad (25.80)$$

因此点到集合的距离就是一个自然的分离裕量。

### 25.4.3 知识点十三：两个凸集的严格分离

若  $C, D$  不交，且一个集合紧、另一个集合闭，则距离  $\text{dist}(C, D) = \inf_{x \in C, y \in D} \|x - y\|_2$  被达到且严格为正。

令  $E = C - D = \{x - y : x \in C, y \in D\}$ 。则  $E$  闭、凸，且  $0 \notin E$ 。

对  $0$  和  $E$  应用 [定义 25.8](#)，可得存在  $a \neq 0$  使


$$\inf_{x \in C} a^\top x > \sup_{y \in D} a^\top y. \quad (25.81)$$

### 25.4.4 知识点十四：支撑超平面

设  $C$  为凸集， $x_0 \in \partial C$ 。若存在  $a \neq 0$ , 使

$$a^\top (x - x_0) \leq 0, \quad \forall x \in C, \quad (25.82)$$

则  $H = \{x : a^\top (x - x_0) = 0\}$  称为  $C$  在  $x_0$  处的支撑超平面。



**定理 25.9** (边界点支撑超平面定理). 若  $C \subseteq \mathbb{R}^n$  为非空闭凸集, 则每个边界点  $x_0 \in \partial C$  至少存在一个支撑超平面。

**证明.** 取  $z_k \notin C$ ,  $z_k \rightarrow x_0$ . 令  $p_k = P_C(z_k)$ ,  $a_k = \frac{z_k - p_k}{\|z_k - p_k\|_2}$ . 因为  $d_C(z_k) \leq \|z_k - x_0\|_2 \rightarrow 0$ , 有  $p_k \rightarrow x_0$ .

单位球紧, 故存在子列满足  $a_{k_j} \rightarrow a$ ,  $\|a\|_2 = 1$ . 投影条件给出  $a_{k_j}^\top (x - p_{k_j}) \leq 0, \forall x \in C$ . 令  $j \rightarrow \infty: a^\top (x - x_0) \leq 0, \forall x \in C$ .  $\square$

由法锥定义,  $a \in N_C(x_0) \setminus \{0\}$  恰好给出一个支撑超平面。

#### 易错点与反例

支撑超平面一般不唯一。

例如正方形顶点处存在无穷多个支撑法向量; 光滑严格凸边界处通常只有一个单位外法向量。

#### 分离超平面证明套路

识别信号:

- 要证明某点不属于闭凸集;
- 要构造对偶证书;
- 要证明双极定理;
- 要证明凸函数内部点存在次梯度;
- 要将几何不可行性转化为线性不等式。

构造步骤:

1. 对外点  $z$  求投影  $p = P_C(z)$ ;
2. 取法向量  $a = z - p$ ;
3. 用投影变分不等式证明  $a^\top x \leq a^\top p$ ;
4. 比较  $a^\top z = a^\top p + \|a\|_2^2$ ;
5. 得到严格分离及裕量。

关键估计:

$$a^\top z - \sup_{x \in C} a^\top x \geq \|a\|_2^2.$$

结论: 得到线性证书  $a^\top z > \sup_C a^\top x$ 。

常见失败原因:

- 集合不闭, 投影不存在;
- 只证明弱分离却声称有正裕量;
- 法向量取反后忘记同步改变不等号;
- 集合非凸, 投影条件不能控制全部点;
- 在双极证明中忘记处理分离常数为零的情形。



## 25.5 凸函数、严格凸、强凸、上图与次水平集

### 25.5.1 知识点十五：扩展实值凸函数

函数  $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  称为凸函数，如果：

1.  $\text{dom } f = \{x: f(x) < +\infty\}$  为凸集；
2. 对任意  $x, y \in \text{dom } f$ ,  $0 \leq \theta \leq 1$ , 有

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y). \quad (25.83)$$

若  $f \not\equiv +\infty$ ，且从不取  $-\infty$ ，称  $f$  为正常函数 (proper function)。

上图定义为

$$\text{epi } f = \{(x, t) : t \geq f(x)\}. \quad (25.84)$$

定理 25.10 (上图判据). 函数  $f$  为凸函数，当且仅当  $\text{epi } f$  为凸集。

函数  $f$  称为闭凸函数，如果  $\text{epi } f$  为闭集。在有限维空间中，对正常函数，闭性等价于下半连续性。

### 25.5.2 知识点十六：次水平集

对  $\alpha \in \mathbb{R}$ ，定义次水平集

$$L_\alpha(f) = \{x: f(x) \leq \alpha\}. \quad (25.85)$$

若  $f$  凸，则  $L_\alpha(f)$  凸。若  $f$  下半连续，则  $L_\alpha(f)$  闭。

证明凸性只需取  $x, y \in L_\alpha(f)$  并使用  $f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y) \leq \alpha$ 。

反之，所有次水平集均凸只说明  $f$  拟凸，不自动说明  $f$  凸。

### 25.5.3 知识点十七：严格凸与强凸

函数  $f$  严格凸是指对  $x \neq y$ ,  $0 < \theta < 1$  有

$$f(\theta x + (1-\theta)y) < \theta f(x) + (1-\theta)f(y). \quad (25.86)$$

给定  $\mu > 0$ ，函数  $f$  称为  $\mu$ -强凸，如果

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y) - \frac{\mu}{2}\theta(1-\theta)\|x-y\|_2^2. \quad (25.87)$$

等价地，

$$x \mapsto f(x) - \frac{\mu}{2}\|x\|_2^2 \quad (25.88)$$


为凸函数。

三者关系为 强凸  $\implies$  严格凸  $\implies$  凸，反向一般不成立。

### 25.5.4 知识点十八：一阶与二阶判据

若  $f$  在开凸集上可微，则

$$f \text{ 凸} \iff f(y) \geq f(x) + \nabla f(x)^\top (y-x), \quad \forall x, y. \quad (25.89)$$



若  $f$  可微, 则  $f$  为  $\mu$ -强凸当且仅当

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2} \|y - x\|_2^2.} \quad (25.90)$$

若  $f \in C^2$ , 则

$$f \text{ 凸} \iff \nabla^2 f(x) \succeq 0, \quad (25.91)$$

$$\nabla^2 f(x) \succeq \mu I \quad \forall x \iff f \text{ 为 } \mu\text{-强凸}. \quad (25.92)$$

若  $\nabla^2 f(x) \succ 0 \quad \forall x$ , 则  $f$  严格凸; 但该条件只是充分条件, 不是必要条件。

反例 25.11 (严格凸不要求 Hessian 处处正定). 函数  $f(x) = x^4$  严格凸, 但  $f''(0) = 0$ . 所以  $\nabla^2 f(x) \succ 0 \quad \forall x$  不是严格凸的必要条件。

### 25.5.5 知识点十九: 最优性、唯一性与灵敏度

若  $f$  凸, 则任意局部极小点都是全局极小点。

若  $f$  严格凸, 则最多存在一个全局极小点。

若  $f$  为  $\mu$ -强凸, 且  $x^*$  为极小点, 则

$$\boxed{f(x) \geq f(x^*) + \frac{\mu}{2} \|x - x^*\|_2^2.} \quad (25.93)$$

这称为二次增长性质。

考虑线性扰动问题

$$x_b = \arg \min_x [f(x) - b^\top x]. \quad (25.94)$$

若  $f$  为  $\mu$ -强凸, 则

$$\boxed{\|x_{b_1} - x_{b_2}\|_2 \leq \frac{1}{\mu} \|b_1 - b_2\|_2.} \quad (25.95)$$

证明来自次微分的强单调性:  $b_i \in \partial f(x_{b_i})$  及  $\langle b_1 - b_2, x_{b_1} - x_{b_2} \rangle \geq \mu \|x_{b_1} - x_{b_2}\|_2^2$ 。

这说明强凸参数  $\mu$  控制最优解的绝对条件数。

## 25.6 正式真题: 2024 Spring Problem 6——强凸型次水平集

完整题目叙述: [24S-Q6]

设  $S \subseteq \mathbb{R}^n$  为非空闭凸集,  $f \in C^2(S)$  为凸函数。

对任意  $x^0 \in S$ , 定义

$$L(f(x^0)) = \{x \in S : f(x) \leq f(x^0)\}. \quad (25.96)$$

若存在  $m > 0$ , 使

$$d^\top \nabla^2 f(x) d \geq m \|d\|_2^2, \quad \forall x \in L(f(x^0)), \quad \forall d \in \mathbb{R}^n, \quad (25.97)$$

证明  $L(f(x^0))$  是有界闭凸集。

注 25.12 (题面光滑性解释). 题面写  $f \in C^2(S)$ , 而  $S$  未必为开集。本文按通常含义理解为:

- $f$  可在包含所需线段的开邻域中作二阶微分;

- 或至少沿  $x^0 + t(x - x^0)$  具有题中所用的二阶方向导数。

第一步: 非空. 显然  $x^0 \in L(f(x^0))$ , 故该集合非空。□

第二步: 闭性. 函数  $f$  连续, 故  $\{x: f(x) \leq f(x^0)\}$  为闭集。

又因  $S$  闭,  $L(f(x^0)) = S \cap \{x: f(x) \leq f(x^0)\}$  为闭集。□

第三步: 凸性. 任取  $x, y \in L(f(x^0))$ ,  $0 \leq \theta \leq 1$ 。由  $S$  凸,  $z = \theta x + (1 - \theta)y \in S$ 。由  $f$  凸:

$$\begin{aligned} f(z) &\leq \theta f(x) + (1 - \theta)f(y) \\ &\leq \theta f(x^0) + (1 - \theta)f(x^0) \\ &= f(x^0). \end{aligned} \quad (25.98)$$

故  $z \in L(f(x^0))$ 。□

第四步: 有界性. 任取  $x \in L(f(x^0))$ 。令  $d = x - x^0$ ,  $\gamma(t) = x^0 + td$ ,  $0 \leq t \leq 1$ 。因为次水平集已经证明为凸集,  $\gamma(t) \in L(f(x^0))$ ,  $0 \leq t \leq 1$ 。

定义  $\varphi(t) = f(\gamma(t))$ 。则

$$\varphi'(t) = \nabla f(\gamma(t))^\top d, \quad (25.99)$$

$$\varphi''(t) = d^\top \nabla^2 f(\gamma(t)) d \geq m \|d\|_2^2. \quad (25.100)$$

Taylor 积分公式给出

$$\begin{aligned} f(x) &= f(x^0) + \nabla f(x^0)^\top d \\ &\quad + \int_0^1 (1-t) d^\top \nabla^2 f(x^0 + td) d dt \\ &\geq f(x^0) + \nabla f(x^0)^\top d + \frac{m}{2} \|d\|_2^2. \end{aligned} \quad (25.101)$$

另一方面,  $f(x) \leq f(x^0)$ 。故

$$\frac{m}{2} \|d\|_2^2 \leq -\nabla f(x^0)^\top d \leq \|\nabla f(x^0)\|_2 \|d\|_2. \quad (25.102)$$

若  $d \neq 0$ , 约去  $\|d\|_2$ :

$$\|x - x^0\|_2 \leq \frac{2\|\nabla f(x^0)\|_2}{m}. \quad (25.103)$$

若  $d = 0$ , 该结论显然成立。

因此

$$L(f(x^0)) \subseteq \overline{B}\left(x^0, \frac{2\|\nabla f(x^0)\|_2}{m}\right). \quad (25.104)$$

故次水平集有界。□

综上,  $L(f(x^0))$  非空、闭、凸且有界。在有限维空间中, 它还是紧集。

注 25.13. 若  $\nabla f(x^0) = 0$ , 则式 (25.102) 直接推出  $x = x^0$ 。因此  $L(f(x^0)) = \{x^0\}$ 。

#### 易错点与反例

本题常见错误:

1. 未先证明次水平集凸, 就直接声称线段上的 Hessian 条件可用;

2. 只写  $\nabla^2 f \succeq mI$  而未积分;
3. 错误使用  $\nabla f(x^0) = 0$ , 题目并未给出该条件;
4. 有界性只给定性描述, 没有给出半径界;
5. 把严格凸误当成自动强凸;
6. 忘记  $S$  本身可能无界。

## 25.7 次梯度、次微分、指示函数与 Fenchel 共轭

### 25.7.1 知识点二十：次梯度与次微分

设  $f$  为正常凸函数,  $x \in \text{dom } f$ . 向量  $g \in \mathbb{R}^n$  称为  $f$  在  $x$  处的次梯度, 如果

$$f(y) \geq f(x) + g^\top(y - x), \quad \forall y \in \mathbb{R}^n. \quad (25.105)$$

所有次梯度构成次微分

$$\partial f(x) = \{g : f(y) \geq f(x) + g^\top(y - x), \quad \forall y\}. \quad (25.106)$$

若  $x \notin \text{dom } f$ , 定义  $\partial f(x) = \emptyset$ .

次微分是闭凸集, 因为  $\partial f(x)$  是半空间族的交。

若  $f$  在  $x$  处可微, 则

$$\partial f(x) = \{\nabla f(x)\}. \quad (25.107)$$

### 25.7.2 知识点二十一：内部点次微分非空和有界

**定理 25.14** (内部点次微分定理). 设  $f$  为正常凸函数. 若  $x \in \text{int dom } f$ , 则  $\partial f(x)$  非空且有界。

非空性来自  $\text{epi } f$  在  $(x, f(x))$  处的非竖直支撑超平面。

有界性来自  $x$  附近存在一个完全包含于定义域的 Euclidean 球。

更一般地, 若  $x \in \text{ri dom } f$ , 则次微分通常非空; 但若定义域不满维, 次微分可沿法空间无界。

**反例 25.15** (相对内部不保证次微分有界). 设  $L \subsetneq \mathbb{R}^n$  为线性子空间, 定义指示函数  $\delta_L(x) = \begin{cases} 0, & x \in L, \\ +\infty, & x \notin L. \end{cases}$

对任意  $x \in L$ ,  $x \in \text{ri dom } \delta_L$ , 但  $\partial \delta_L(x) = L^\perp$  通常为无界集合。

### 25.7.3 知识点二十二：最优性条件


对正常凸函数  $f$ :

$$x^* \in \arg \min f \iff 0 \in \partial f(x^*). \quad (25.108)$$

证明直接来自定义:  $0 \in \partial f(x^*) \iff f(y) \geq f(x^*), \quad \forall y$ .

若  $f$  为  $\mu$ -强凸, 则  $\partial f$  强单调:

$$\langle g - h, x - y \rangle \geq \mu \|x - y\|_2^2, \quad g \in \partial f(x), \quad h \in \partial f(y). \quad (25.109)$$



### 25.7.4 知识点二十三：次微分运算规则

在适当约束资格条件下：

和规则。 若  $f, g$  正常凸，且例如  $\text{ri dom } f \cap \text{ri dom } g \neq \emptyset$ ，则

$$\partial(f+g)(x) = \partial f(x) + \partial g(x). \quad (25.110)$$

仿射复合。 若  $h(x) = f(Ax+b)$ ，则

$$A^\top \partial f(Ax+b) \subseteq \partial h(x). \quad (25.111)$$

在标准资格条件下取等号。

有限最大值。 若  $f(x) = \max_{1 \leq i \leq m} f_i(x)$ ，且  $f_i$  凸，定义活跃集  $I(x) = \{i : f_i(x) = f(x)\}$ 。则

$$\partial f(x) = \text{conv} \left( \bigcup_{i \in I(x)} \partial f_i(x) \right). \quad (25.112)$$

若  $f_i$  可微：

$$\partial f(x) = \text{conv} \{ \nabla f_i(x) : i \in I(x) \}. \quad (25.113)$$

范数。 设  $\|\cdot\|$  为任意范数， $\|\cdot\|_*$  为其对偶范数。则

$$\partial \|x\| = \begin{cases} \{g : \|g\|_* \leq 1, g^\top x = \|x\|\}, & x \neq 0, \\ \{g : \|g\|_* \leq 1\}, & x = 0. \end{cases} \quad (25.114)$$

对 Euclidean 范数：

$$\partial \|x\|_2 = \begin{cases} \{x/\|x\|_2\}, & x \neq 0, \\ \{g : \|g\|_2 \leq 1\}, & x = 0. \end{cases} \quad (25.115)$$

### 25.7.5 知识点二十四：指示函数与法锥

集合  $C$  的凸指示函数定义为

$$\delta_C(x) = \begin{cases} 0, & x \in C, \\ +\infty, & x \notin C. \end{cases} \quad (25.116)$$

若  $C$  凸，则  $\delta_C$  凸。

由定义直接得到

$$\boxed{\partial \delta_C(x) = N_C(x)}. \quad (25.117)$$

因此约束问题  $\min_{x \in C} f(x)$  可写成无显式约束形式  $\min_x f(x) + \delta_C(x)$ 。其凸最优性条件为

$$0 \in \partial f(x^*) + N_C(x^*). \quad (25.118)$$

投影正是指示函数的近端映射：

$$P_C(z) = \text{prox}_{\delta_C}(z) = \arg \min_x \left[ \frac{1}{2} \|x - z\|_2^2 + \delta_C(x) \right]. \quad (25.119)$$



## 25.7.6 知识点二十五: Fenchel 共轭

正常函数  $f$  的 Fenchel 共轭定义为

$$f^*(y) = \sup_{x \in \mathbb{R}^n} [y^\top x - f(x)]. \quad (25.120)$$

不论  $f$  是否凸,  $f^*$  总是闭凸函数。

Fenchel-Young 不等式为

$$f(x) + f^*(y) \geq x^\top y. \quad (25.121)$$

对闭正常凸函数:

$$y \in \partial f(x) \iff x \in \partial f^*(y) \iff f(x) + f^*(y) = x^\top y. \quad (25.122)$$

集合  $C$  的支撑函数定义为

$$\sigma_C(y) = \sup_{x \in C} y^\top x. \quad (25.123)$$

因为  $\delta_C^*(y) = \sup_x [y^\top x - \delta_C(x)]$ , 有

$$\delta_C^* = \sigma_C. \quad (25.124)$$

范数的共轭为对偶单位球的指示函数:

$$(\|\cdot\|)^*(y) = \delta_{\{y: \|y\|_* \leq 1\}}(y). \quad (25.125)$$

证明. 若  $\|y\|_* \leq 1$ , 由 Hölder 不等式:  $y^\top x - \|x\| \leq \|y\|_* \|x\| - \|x\| \leq 0$ . 取  $x = 0$  可得上确界为 0。

若  $\|y\|_* > 1$ , 存在  $u$  满足  $\|u\| = 1$ ,  $y^\top u > 1$ . 令  $x = tu$ , 则  $y^\top x - \|x\| = t(y^\top u - 1) \rightarrow +\infty$ .  $\square$

## 次梯度证明套路

识别信号:

- 目标函数含绝对值、最大值、范数或指示函数;
- 函数不可微但仍为凸函数;
- 需要写一阶最优性条件;
- 需要求闭式近端解或投影。

构造步骤:

1. 从定义  $f(y) \geq f(x) + g^\top(y - x)$  出发;
2. 对可分函数逐坐标处理;
3. 对最大值函数找活跃指标;
4. 对约束集合用  $\partial \delta_C = N_C$ ;
5. 对和函数检查次微分和规则资格条件;
6. 令  $0 \in \partial F(x^*)$  求最优点。

关键估计:

$$\|x\| = \sup_{\|g\|_* \leq 1} g^\top x.$$

结论: 得到全局一阶最优性条件, 而不是局部导数条件。

常见失败原因:

- 在不可微点直接写梯度为零;
- 忘记次微分可能为空;
- 次微分和规则未检查定义域相交条件;
- 法锥符号写反;
- 把一个次梯度误当成完整次微分;
- 在边界点错误声称次微分有界。

## 25.8 正式真题 [24F-Q7]——次微分与软阈值

完整题目叙述: [24F-Q7]

设  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  为凸函数, 并以  $\partial f(x)$  表示  $f$  在  $x$  处的次梯度集合。

- (i) 若  $x \in \text{int dom } f$ , 证明  $\partial f(x)$  非空且有界;
- (ii) 对  $f(x) = \|x\|_1 = \sum_{i=1}^n |x_i|$ , 写出  $\partial f(x)$ ;
- (iii) 给定  $y \in \mathbb{R}^n$ ,  $\lambda > 0$ , 求问题

$$\min_x \frac{1}{2} \|x - y\|_2^2 + \lambda \|x\|_1 \quad (25.126)$$

的闭式解。

注 25.16 (题面定义域约定). 题面写  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ , 此时  $\text{dom } f = \mathbb{R}^n$ . 题目同时使用  $\text{int dom } f$ , 说明其意图是采用一般扩展实值凸函数表述。

以下证明按  $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  的标准凸分析形式给出; 对处处有限的题面情形, 该结论直接适用。

第 (i) 问: 非空性. 因为  $x \in \text{int dom } f$ , 凸函数  $f$  在  $x$  的邻域内连续, 且  $(x, f(x))$  是凸集  $\text{epi } f$  的边界点。

由支撑超平面定理, 存在  $(a, b) \neq (0, 0)$  使

$$a^\top (y - x) + b(t - f(x)) \leq 0, \quad \forall (y, t) \in \text{epi } f. \quad (25.127)$$

若  $b > 0$ , 固定  $y$  并令  $t \rightarrow +\infty$ , 左端趋于  $+\infty$ , 矛盾。

若  $b = 0$ , 则  $a^\top (y - x) \leq 0$  对所有邻域内的  $y$  成立。由于  $x$  为定义域内部点, 可取  $y = x + \varepsilon a$  且  $\varepsilon > 0$  充分小, 得到  $\varepsilon \|a\|_2^2 \leq 0$ . 故  $a = 0$ , 与  $(a, b) \neq (0, 0)$  矛盾。


所以  $b < 0$ . 令

$$g = \frac{a}{|b|}. \quad (25.128)$$

在式 (25.127) 中取  $t = f(y)$ , 得到  $f(y) \geq f(x) + g^\top (y - x)$ ,  $\forall y$ . 故  $g \in \partial f(x)$ . 因此  $\partial f(x) \neq \emptyset$ .  $\square$

第 (i) 问: 有界性. 因为  $x$  为定义域内部点, 存在  $r > 0$ , 使  $x \pm re_i \in \text{dom } f$ ,  $i = 1, \dots, n$ . 定义

$$M = \max_{1 \leq i \leq n} \{f(x + re_i), f(x - re_i)\}. \quad (25.129)$$



任取  $g \in \partial f(x)$ 。选择  $k$  满足  $|g_k| = \|g\|_\infty$ 。令  $y = x + r \operatorname{sgn}(g_k)e_k$ 。则  $g^\top(y - x) = r \|g\|_\infty$ 。由次梯度不等式:  $f(y) \geq f(x) + r \|g\|_\infty$ 。所以

$$\|g\|_\infty \leq \frac{M - f(x)}{r}. \quad (25.130)$$

进一步,

$$\|g\|_2 \leq \sqrt{n} \frac{M - f(x)}{r}. \quad (25.131)$$

故  $\partial f(x)$  有界。  $\square$

第 (ii) 问. 函数可分离:  $\|x\|_1 = \sum_{i=1}^n |x_i|$ 。一维绝对值函数满足

$$\partial|t| = \begin{cases} \{1\}, & t > 0, \\ [-1, 1], & t = 0, \\ \{-1\}, & t < 0. \end{cases} \quad (25.132)$$

因此

$$\partial \|x\|_1 = \left\{ g \in \mathbb{R}^n : g_i = \begin{cases} 1, & x_i > 0, \\ [-1, 1], & x_i = 0, \\ -1, & x_i < 0 \end{cases} \right\}. \quad (25.133)$$

更准确地说,  $x_i = 0$  时  $g_i \in [-1, 1]$ 。  $\square$

第 (iii) 问. 目标函数  $F(x) = \frac{1}{2} \|x - y\|_2^2 + \lambda \|x\|_1$  为 1-强凸函数, 故最优解存在且唯一。

一阶最优性条件为

$$0 \in x - y + \lambda \partial \|x\|_1. \quad (25.134)$$

逐坐标写为

$$0 \in x_i - y_i + \lambda \partial |x_i|. \quad (25.135)$$

分三种情形。

情形一:  $x_i > 0$ 。此时  $\partial |x_i| = \{1\}$ , 故  $x_i = y_i - \lambda$ 。要满足  $x_i > 0$ , 必须  $y_i > \lambda$ 。

情形二:  $x_i < 0$ 。此时  $\partial |x_i| = \{-1\}$ , 故  $x_i = y_i + \lambda$ 。要满足  $x_i < 0$ , 必须  $y_i < -\lambda$ 。

情形三:  $x_i = 0$ 。此时  $0 \in -y_i + \lambda[-1, 1]$ , 即  $|y_i| \leq \lambda$ 。

因此唯一解为


$$x_i^* = \begin{cases} y_i - \lambda, & y_i > \lambda, \\ 0, & |y_i| \leq \lambda, \\ y_i + \lambda, & y_i < -\lambda. \end{cases} \quad (25.136)$$

等价地,

$$x_i^* = \operatorname{sgn}(y_i) \max\{|y_i| - \lambda, 0\}. \quad (25.137)$$

定义软阈值算子

$$\mathcal{S}_\lambda(y) = [\operatorname{sgn}(y_i)(|y_i| - \lambda)_+]_{i=1}^n, \quad (25.138)$$





则

$$x^* = \mathcal{S}_\lambda(y) = \text{prox}_{\lambda\|\cdot\|_1}(y). \quad (25.139)$$

□

---

**Algorithm 85**  $\ell^1$  近端映射的软阈值算法

---

**Input:**  $y \in \mathbb{R}^n$ , 阈值  $\lambda > 0$

**Output:**  $x = \text{prox}_{\lambda\|\cdot\|_1}(y)$

- 1: **Initialization:** 设置  $x \leftarrow 0$
  - 2: **for**  $i = 1, \dots, n$  **do**
  - 3:     **if**  $y_i > \lambda$  **then**
  - 4:          $x_i \leftarrow y_i - \lambda$
  - 5:     **else if**  $y_i < -\lambda$  **then**
  - 6:          $x_i \leftarrow y_i + \lambda$
  - 7:     **else**
  - 8:          $x_i \leftarrow 0$
  - 9:     **end if**
  - 10: **end for**
  - 11: **Stopping criterion:** 该算法为闭式逐坐标计算, 无迭代停止误差
  - 12: **Complexity:** 运算复杂度  $O(n)$ ; 输出存储  $O(n)$ ; 允许原位覆盖时附加存储为  $O(1)$
- 

软阈值映射是牢固非扩张映射, 故

$$\|\mathcal{S}_\lambda(y) - \mathcal{S}_\lambda(\tilde{y})\|_2 \leq \|y - \tilde{y}\|_2. \quad (25.140)$$

### 易错点与反例

本题常见错误:

1. 只证明次微分闭凸, 未证明非空和有界;
2. 在定义域边界点仍声称次微分一定有界;
3. 把  $\partial|0|$  写成  $\{0\}$ ;
4. 软阈值在  $|y_i| = \lambda$  处写成多值;
5. 把软阈值写成硬阈值;
6. 漏掉目标函数强凸性所保证的唯一性;
7. 把近端映射与普通梯度下降一步混为一谈。

## 25.9 补充训练题：丘赛 2026 Problem 6——最大值函数与非负正交锥

完整题目叙述：[Yau-2026-P6]

设凸函数  $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  在  $x$  处的次微分记为  $\partial f(x)$ ，并采用  $g \in \partial f(x) \iff f(z) \geq f(x) + \langle g, z - x \rangle, \forall z \in \mathbb{R}^n$ 。假设  $n \geq 2$ 。

(a) 令

$$f(x) = \max_{1 \leq i \leq n} x_i. \quad (25.141)$$

求  $\partial f(0)$ 。

(b) 令

$$g(x) = \max_{1 \leq i \leq n} x_i + \delta_{\mathbb{R}_+^n}(x). \quad (25.142)$$

证明

$$\partial g(0) = \partial f(0) - \mathbb{R}_+^n. \quad (25.143)$$

第 (a) 问：必要性。设  $p \in \partial f(0)$ 。因为  $f(0) = 0$ ，有

$$\max_i z_i \geq p^\top z, \forall z \in \mathbb{R}^n. \quad (25.144)$$

先证明  $\mathbf{1}^\top p = 1$ 。取  $z = t\mathbf{1}$ 。当  $t > 0$  时：  $t \geq t\mathbf{1}^\top p \implies \mathbf{1}^\top p \leq 1$ 。当  $t < 0$  时：  $t \geq t\mathbf{1}^\top p$ 。除以负数  $t$  后不等号反向：  $\mathbf{1}^\top p \geq 1$ 。故

$$\mathbf{1}^\top p = 1. \quad (25.145)$$

再证明  $p_i \geq 0$ 。固定  $i$ ，取  $z = -te_i, t > 0$ 。因为  $n \geq 2$ ，其他坐标为零，所以  $\max_j z_j = 0$ 。由式 (25.144)：  $0 \geq -tp_i$ ，故  $p_i \geq 0$ 。

因此

$$p \in \{p \succeq 0 : \mathbf{1}^\top p = 1\}. \quad (25.146)$$

□

第 (a) 问：充分性。反之，若  $p \succeq 0, \mathbf{1}^\top p = 1$ ，则对任意  $z$ ：

$$p^\top z = \sum_{i=1}^n p_i z_i \leq \sum_{i=1}^n p_i \max_j z_j = \max_j z_j. \quad (25.147)$$

故  $p \in \partial f(0)$ 。

综上，


$$\partial f(0) = \{p \in \mathbb{R}^n : p \succeq 0, \mathbf{1}^\top p = 1\}. \quad (25.148)$$

即标准单纯形。

该结果也可由最大值次微分公式得到：  $f(x) = \max_i e_i^\top x$ ，而在  $x = 0$  所有指标均活跃，所以  $\partial f(0) = \text{conv}\{e_1, \dots, e_n\}$ 。 □

第 (b) 问。由式 (25.117)：  $\partial \delta_{\mathbb{R}_+^n}(0) = N_{\mathbb{R}_+^n}(0)$ 。根据法锥定义：

$$\begin{aligned} N_{\mathbb{R}_+^n}(0) &= \{v : v^\top z \leq 0, \forall z \succeq 0\} \\ &= -\mathbb{R}_+^n. \end{aligned} \quad (25.149)$$



函数  $f$  处处有限且连续, 因此次微分和规则适用:

$$\begin{aligned}\partial g(0) &= \partial f(0) + \partial \delta_{\mathbb{R}_+^n}(0) \\ &= \partial f(0) - \mathbb{R}_+^n.\end{aligned}\quad (25.150)$$

即

$$\boxed{\partial g(0) = \partial f(0) - \mathbb{R}_+^n}.\quad (25.151)$$

□

注 25.17 (等价显式描述). 由  $\partial f(0) = \Delta_n := \{p \succeq 0 : \mathbf{1}^\top p = 1\}$ , 有  $\Delta_n - \mathbb{R}_+^n = \{q : \sum_{i=1}^n (q_i)_+ \leq 1\}$ . 其中  $(q_i)_+ = \max\{q_i, 0\}$ .

证明如下。

若  $q = p - r$ ,  $p \in \Delta_n$ ,  $r \succeq 0$ , 则  $(q_i)_+ \leq p_i$ , 故  $\sum_i (q_i)_+ \leq 1$ 。

反之, 若  $\sum_i (q_i)_+ \leq 1$ , 取  $p_i = (q_i)_+ + \alpha_i$ , 其中  $\alpha_i \geq 0$ ,  $\sum_i \alpha_i = 1 - \sum_i (q_i)_+$ . 则  $p \in \Delta_n$ , 且  $r = p - q \succeq 0$ 。

## 25.10 对偶锥、极集、支撑函数与双极定理

### 25.10.1 知识点二十六: 对偶锥

锥  $K \subseteq \mathbb{R}^n$  的对偶锥定义为

$$K^* = \{y : y^\top x \geq 0, \quad \forall x \in K\}.\quad (25.152)$$

不论  $K$  是否凸或闭,  $K^*$  总是闭凸锥, 因为  $K^* = \bigcap_{x \in K} \{y : y^\top x \geq 0\}$ 。

典型例子:

$$(\mathbb{R}_+^n)^* = \mathbb{R}_+^n,\quad (25.153)$$

$$(\mathbb{S}_+^n)^* = \mathbb{S}_+^n \quad \text{关于 Frobenius 内积},\quad (25.154)$$

$$(\mathcal{Q}^{n+1})^* = \mathcal{Q}^{n+1}.\quad (25.155)$$

若  $K$  为闭凸锥, 则

$$K^{**} = K.\quad (25.156)$$

### 25.10.2 知识点二十七: 极集

对任意  $C \subseteq \mathbb{R}^n$ , 定义


$$C^\circ = \{y : y^\top x \leq 1, \quad \forall x \in C\}.\quad (25.157)$$

使用支撑函数  $\sigma_C(y) = \sup_{x \in C} y^\top x$ , 可写成

$$\boxed{C^\circ = \{y : \sigma_C(y) \leq 1\}}.\quad (25.158)$$

由此立即得到:

1.  $C^\circ$  总是闭凸集;



2.  $0 \in C^\circ$ ;

3. 若  $C \subseteq D$ , 则

$$D^\circ \subseteq C^\circ; \quad (25.159)$$

4. 对  $\alpha > 0$ ,

$$(\alpha C)^\circ = \frac{1}{\alpha} C^\circ; \quad (25.160)$$

5.

$$\left( \bigcup_i C_i \right)^\circ = \bigcap_i C_i^\circ; \quad (25.161)$$

6.

$$C^\circ = (\text{conv } C)^\circ = (\text{cl conv } C)^\circ. \quad (25.162)$$

### 25.10.3 知识点二十八：锥的极与对偶锥的关系

若  $K$  为锥, 则

$$K^\circ = \{y : y^\top x \leq 0, \quad \forall x \in K\} = -K^*. \quad (25.163)$$

原因是: 若存在  $x \in K$  使  $y^\top x > 0$ , 则对任意  $t > 0$ ,  $tx \in K$  且  $y^\top(tx) = ty^\top x$  可超过 1, 从而  $y \notin K^\circ$ .

#### 易错点与反例

在本文约定下:

$K^* = \{y : y^\top x \geq 0\}$ , 而  $K^\circ = \{y : y^\top x \leq 0\}$ 。

因此  $K^\circ = -K^*$ , 不是  $K^\circ = K^*$ 。不同教材可能把“polar cone”直接定义为非正对偶锥, 必须先核对符号。

### 25.10.4 知识点二十九：范数单位球的极

设  $B = \{x : \|x\| \leq 1\}$ 。对偶范数定义为

$$\|y\|_* = \sup_{\|x\| \leq 1} y^\top x. \quad (25.164)$$

因此

$$B^\circ = \{y : \|y\|_* \leq 1\}. \quad (25.165)$$

常见对应关系:

$$\|\cdot\|_1^* = \|\cdot\|_\infty, \quad (25.166)$$


$$\|\cdot\|_2^* = \|\cdot\|_2, \quad (25.167)$$

$$\|\cdot\|_\infty^* = \|\cdot\|_1. \quad (25.168)$$

故:

$$\{x : \|x\|_1 \leq 1\}^\circ = \{y : \|y\|_\infty \leq 1\}, \quad (25.169)$$

$$\{x : \|x\|_\infty \leq 1\}^\circ = \{y : \|y\|_1 \leq 1\}. \quad (25.170)$$



## 25.10.5 知识点三十：多面体和椭球的极

若  $C = \text{conv}\{v_1, \dots, v_m\}$ , 则

$$C^\circ = \{y : v_i^\top y \leq 1, i = 1, \dots, m\}. \quad (25.171)$$

若  $C = \{x : x^\top Q^{-1}x \leq 1\}$ ,  $Q \succ 0$ , 则

$$C^\circ = \{y : y^\top Qy \leq 1\}. \quad (25.172)$$

证明使用  $\sup_{x^\top Q^{-1}x \leq 1} y^\top x = \sqrt{y^\top Qy}$ .

## 25.10.6 知识点三十一：双极定理

定理 25.18 (双极定理). 若  $C \subseteq \mathbb{R}^n$  闭、凸, 且  $0 \in C$ , 则

$$(C^\circ)^\circ = C. \quad (25.173)$$

证明. 先证  $C \subseteq (C^\circ)^\circ$ . 若  $x \in C$ , 则对任意  $y \in C^\circ$ , 由极集定义  $y^\top x \leq 1$ . 故  $x \in (C^\circ)^\circ$ .

再证反向包含. 设  $z \notin C$ . 因为  $C$  非空、闭、凸, 由严格分离定理, 存在  $a \neq 0$  及  $b \in \mathbb{R}$ , 使

$$a^\top x \leq b < a^\top z, \forall x \in C. \quad (25.174)$$

由于  $0 \in C$ , 有  $0 = a^\top 0 \leq b$ , 故  $b \geq 0$ .

分两种情形。

情形一:  $b > 0$ . 令  $y = \frac{a}{b}$ . 则对任意  $x \in C$ :  $y^\top x = \frac{a^\top x}{b} \leq 1$ . 所以  $y \in C^\circ$ . 但  $y^\top z = \frac{a^\top z}{b} > 1$ . 因此  $z \notin (C^\circ)^\circ$ .

情形二:  $b = 0$ . 此时  $a^\top x \leq 0 \quad \forall x \in C$ ,  $a^\top z > 0$ . 取  $t > \frac{1}{a^\top z}$ ,  $y = ta$ . 则  $y^\top x \leq 0 \leq 1, \quad \forall x \in C$ , 故  $y \in C^\circ$ . 而  $y^\top z = ta^\top z > 1$ . 同样有  $z \notin (C^\circ)^\circ$ .

所以  $(C^\circ)^\circ \subseteq C$ . □

推论 25.19 (一般双极公式). 对任意  $C \subseteq \mathbb{R}^n$ ,

$$(C^\circ)^\circ = \text{cl conv}(C \cup \{0\}). \quad (25.175)$$

证明. 令  $D = \text{cl conv}(C \cup \{0\})$ . 由极集对闭包、凸包和添加原点不敏感:  $D^\circ = C^\circ$ . 集合  $D$  闭、凸且含原点. 应用双极定理:  $(C^\circ)^\circ = (D^\circ)^\circ = D$ . □

反例 25.20 (双极会自动闭化、凸化并添加原点). 在  $\mathbb{R}$  中取  $C = \{1\}$ . 则  $C^\circ = (-\infty, 1]$ . 进一步可得  $(C^\circ)^\circ = [0, 1]$ . 所以若  $C$  不含 0 且不凸, 不能声称  $C^{\circ\circ} = C$ .


## 25.10.7 知识点三十二：锥的 Moreau 分解

定理 25.21 (Moreau 锥分解). 设  $K$  为闭凸锥,  $K^\circ$  采用非正极锥约定. 则任意  $z \in \mathbb{R}^n$  唯一分解为

$$z = P_K(z) + P_{K^\circ}(z), \quad (25.176)$$

并满足

$$\langle P_K(z), P_{K^\circ}(z) \rangle = 0. \quad (25.177)$$



证明. 令  $p = P_K(z)$ ,  $q = z - p$ . 由投影条件:  $\langle q, d - p \rangle \leq 0, \forall d \in K$ . 取  $d = 0$ :  $-\langle q, p \rangle \leq 0 \implies \langle q, p \rangle \geq 0$ . 取  $d = 2p$ :  $\langle q, p \rangle \leq 0$ . 故  $\langle q, p \rangle = 0$ .

对任意  $d \in K$ :  $\langle q, d \rangle \leq \langle q, p \rangle = 0$ . 所以  $q \in K^\circ$ .

再对任意  $r \in K^\circ$ :  $\langle z - q, r - q \rangle = \langle p, r - q \rangle = \langle p, r \rangle - \langle p, q \rangle \leq 0$ . 这里  $p \in K = (K^\circ)^\circ$ . 由投影变分不等式,  $q = P_{K^\circ}(z)$ .  $\square$

### 极集与双极定理证明套路

识别信号:

- 集合由全部线性不等式描述;
- 需要从集合恢复其闭凸包;
- 需要证明某点不属于集合;
- 需要求范数单位球、锥或多面体的极。

构造步骤:

1. 将极集写成  $C^\circ = \{y : \sigma_C(y) \leq 1\}$ ;
2. 对特殊集合计算支撑函数;
3. 证明  $C \subseteq C^{\circ\circ}$ ;
4. 对  $z \notin C$  应用严格分离;
5. 按分离常数  $b > 0$  或  $b = 0$  缩放法向量;
6. 构造  $y \in C^\circ, \quad y^\top z > 1$ ;
7. 排除  $z \in C^{\circ\circ}$ .

关键估计:

$$\sup_{x \in C} a^\top x < a^\top z.$$

结论:

$C^{\circ\circ} = C$  在闭、凸、含原点条件下成立。

常见失败原因:

- 漏掉闭性;
- 漏掉凸性;
- 漏掉  $0 \in C$ ;
- 锥的极和对偶锥符号混淆;
- 分离常数为零时错误地除以零;
- 单纯形的极误加下界;
- 对偶范数定义中漏掉上确界。

## 25.11 正式真题 [26S-Q7]——极集与双极定理

完整题目叙述: [26S-Q7]

集合  $C \subseteq \mathbb{R}^n$  的极集定义为

$$C^\circ = \{y \in \mathbb{R}^n : y^\top x \leq 1, \quad \forall x \in C\}. \quad (25.178)$$

(a) 证明  $C^\circ$  为凸集, 即使  $C$  不凸;

(b) 求一个锥的极;

(c) 求任意范数单位球的极;

(d) 求集合

$$C = \{x : \mathbf{1}^\top x = 1, x \succeq 0\} \quad (25.179)$$

的极;

(e) 若  $C$  闭、凸且  $0 \in C$ , 证明

$$(C^\circ)^\circ = C. \quad (25.180)$$

第 (a) 问. 对每个固定  $x \in C$ , 集合  $H_x = \{y : y^\top x \leq 1\}$  为闭半空间, 因此为闭凸集。又  $C^\circ = \bigcap_{x \in C} H_x$ . 任意族凸集之交仍为凸集, 所以

$$C^\circ \text{ 为闭凸集}. \quad (25.181)$$

该结论不要求  $C$  本身凸。 □第 (b) 问. 设  $K$  为锥。若  $y \in K^\circ$ , 则对任意  $x \in K$  和  $t > 0$ :  $tx \in K$ , 所以  $ty^\top x = y^\top(tx) \leq 1$ . 该不等式对所有  $t > 0$  成立, 故必须  $y^\top x \leq 0$ . 反之, 若  $y^\top x \leq 0, \forall x \in K$ , 则显然  $y^\top x \leq 1$ , 故  $y \in K^\circ$ .

因此

$$K^\circ = \{y : y^\top x \leq 0, \forall x \in K\} = -K^*. \quad (25.182)$$

□第 (c) 问. 设  $B = \{x : \|x\| \leq 1\}$ . 由极集定义:

$$\begin{aligned} y \in B^\circ &\iff y^\top x \leq 1, \quad \forall \|x\| \leq 1 \\ &\iff \sup_{\|x\| \leq 1} y^\top x \leq 1 \\ &\iff \|y\|_* \leq 1. \end{aligned} \quad (25.183)$$

因此

$$B^\circ = \{y : \|y\|_* \leq 1\}. \quad (25.184)$$

□第 (d) 问. 集合  $C$  是标准单纯形。对固定  $y \in \mathbb{R}^n$ ,  $y^\top x = \sum_{i=1}^n x_i y_i$  是  $y_i$  的凸组合, 因为  $x_i \geq 0, \sum_i x_i = 1$ . 故  $y^\top x \leq \max_i y_i$ . 取  $x = e_k, k \in \arg \max_i y_i$ , 可达到等号。

所以

$$\sup_{x \in C} y^\top x = \max_i y_i. \quad (25.185)$$

因此

$$\begin{aligned} C^\circ &= \{y : \max_i y_i \leq 1\} \\ &= \boxed{\{y : y_i \leq 1, i = 1, \dots, n\}}. \end{aligned} \quad (25.186)$$

注意该集合对负方向无界，没有条件  $y_i \geq -1$ 。□

第 (e) 问. 先证  $C \subseteq (C^\circ)^\circ$ 。若  $x \in C$ ，则对任意  $y \in C^\circ$ ： $y^\top x \leq 1$ 。故  $x \in (C^\circ)^\circ$ 。

反之，任取  $z \notin C$ 。因为  $C$  闭且凸，存在严格分离超平面：

$$a^\top x \leq b < a^\top z, \quad \forall x \in C. \quad (25.187)$$

又因  $0 \in C$ ， $b \geq 0$ 。

若  $b > 0$ ，令  $y = a/b$ 。则  $y^\top x \leq 1, \quad \forall x \in C$ ，所以  $y \in C^\circ$ ，而  $y^\top z > 1$ 。故  $z \notin (C^\circ)^\circ$ 。

若  $b = 0$ ，则  $a^\top x \leq 0, \quad \forall x \in C$ ， $a^\top z > 0$ 。取  $t > 1/(a^\top z)$  并令  $y = ta$ 。则  $y \in C^\circ$ ， $y^\top z > 1$ 。同样有  $z \notin (C^\circ)^\circ$ 。

所以  $(C^\circ)^\circ \subseteq C$ 。综上：

$$\boxed{(C^\circ)^\circ = C}. \quad (25.188)$$

□

### 易错点与反例

本题常见错误：

1. 认为只有  $C$  凸时  $C^\circ$  才凸；
2. 把锥的极写成  $\{y : y^\top x \leq 1\}$ ；但没有进一步化简为非正约束；
3. 把对偶范数单位球写成原范数单位球；
4. 单纯形的极误写成  $\|y\|_\infty \leq 1$ ；
5. 双极证明只给出  $C \subseteq C^{\circ\circ}$ ；
6. 分离常数为零时直接除以  $b$ ；
7. 未使用  $0 \in C$ ；
8. 忘记闭性和凸性是反向包含的关键。

## 25.12 数值稳定性、复杂度、证明套路与易错点

### 25.12.1 投影、强凸性和分离的条件性

| 对象             | 稳定性或条件性              | 考试中的正确表述                                            |
|----------------|----------------------|-----------------------------------------------------|
| 闭凸集投影 $P_C$    | 绝对 Lipschitz 常数不超过 1 | $\ P_C(z) - P_C(w)\  \leq \ z - w\ $                |
| 投影残差 $I - P_C$ | 绝对 Lipschitz 常数不超过 1 | 平方距离函数的梯度为 1-Lipschitz                              |
| 强凸最优解          | 线性扰动灵敏度至多 $1/\mu$    | $\ x_{b_1} - x_{b_2}\  \leq \mu^{-1} \ b_1 - b_2\ $ |



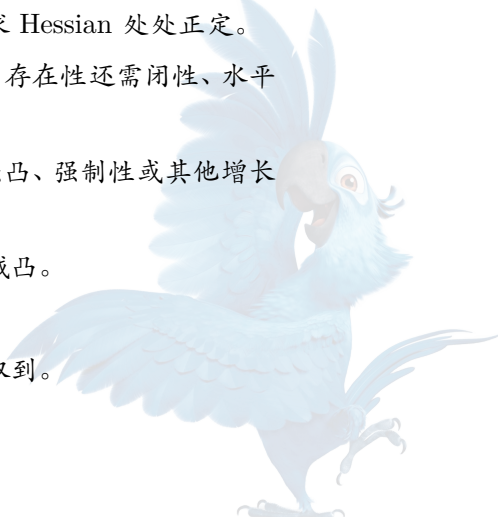
| 对象     | 稳定性或条件性                        | 考试中的正确表述                                               |
|--------|--------------------------------|--------------------------------------------------------|
| 仿射集投影  | 映射本身非扩张，但公式求解受 $AA^\top$ 条件数影响 | 数学问题稳定不等于具体线性代数实现自动稳定                                  |
| 软阈值    | 牢固非扩张                          | 阈值点处不可微，但映射连续且稳定                                       |
| 严格分离   | 单位法向量下的裕量至少与距离相关               | 点靠近集合时，分离证书的相对灵敏度恶化                                    |
| 极集成员判断 | 等价于计算 $\sigma_C(y) \leq 1$     | 若支撑函数优化困难，极集成员判断也困难                                    |
| 双极运算   | 自动闭化、凸化并加入原点                   | 一般集合满足 $C^{\circ\circ} = \text{cl conv}(C \cup \{0\})$ |

### 25.12.2 主要计算对象的复杂度

| 对象               | 主要计算                                 | 运算复杂度                                   | 存储复杂度             |
|------------------|--------------------------------------|-----------------------------------------|-------------------|
| 盒约束投影            | 逐坐标截断                                | $O(n)$                                  | $O(n)$ 或原位 $O(1)$ |
| 非负正交锥投影          | $(P_{\mathbb{R}_+^n} z)_i = (z_i)_+$ | $O(n)$                                  | $O(n)$ 或原位 $O(1)$ |
| Euclidean 球投影    | 计算范数并缩放                              | $O(n)$                                  | $O(n)$            |
| 仿射集投影            | 解 $AA^\top \lambda = r$              | 预处理 $O(m^2 n + m^3)$ ; 每点 $O(mn + m^2)$ | $O(mn + m^2)$     |
| 软阈值              | 逐坐标阈值化                               | $O(n)$                                  | $O(n)$ 或原位 $O(1)$ |
| 单纯形极集成员判断        | 计算 $\max_i y_i$                      | $O(n)$                                  | $O(1)$ 附加存储       |
| 一般极集成员判断         | 求支撑函数 $\sigma_C(y)$                  | 问题依赖                                    | 问题依赖              |
| 稠密 Hessian 正定性检查 | Cholesky 或最小特征值                      | $O(n^3)$                                | $O(n^2)$          |

### 25.12.3 凸分析高频易错点

| 错误说法或错误做法            | 正确处理                            |
|----------------------|---------------------------------|
| 凸、严格凸和强凸是同一概念。       | 强凸蕴含严格凸，严格凸蕴含凸，反向一般不成立。         |
| 凸函数的 Hessian 必须处处正定。 | 凸只需半正定；严格凸也不要求 Hessian 处处正定。    |
| 严格凸函数一定存在最小点。        | 严格凸只保证最优点至多一个；存在性还需闭性、水平有界性或紧性。 |
| 凸函数任意次水平集有界。         | 次水平集只自动凸；有界性需强凸、强制性或其他增长条件。     |
| 所有局部极小点都是全局极小点。      | 该结论要求目标函数凸且可行域凸。                |
| 闭集上的投影一定唯一。          | 闭性保证存在，凸性保证唯一。                  |
| 凸集上的投影一定存在。          | 若集合不闭，最小距离可能不取到。                |



| 错误说法或错误做法                                       | 正确处理                                                        |
|-------------------------------------------------|-------------------------------------------------------------|
| 投影残差与可行方向正交。                                    | 一般凸集只有 $\langle z - p, x - p \rangle \leq 0$ ; 子空间情形才是正交等式。 |
| 投影是压缩映射。                                        | 投影一般只是牢固非扩张, Lipschitz 常数可等于 1。                             |
| 法锥定义中的符号可以任意。                                   | 符号会影响 KKT 乘子、投影关系和极锥; 必须统一约定。                               |
| $x \in \text{ri dom } f$ 时 $\partial f(x)$ 必有界。 | 相对内部保证非空性较自然; 满维内部才排除法空间中的无界方向。                             |
| 凸函数在定义域边界处一定有次梯度。                               | 边界次微分可能为空, 例如适当的竖直切线情形。                                     |
| 不可微函数最优点满足 $\nabla f = 0$ 。                     | 应写 $0 \in \partial f(x^*)$ 。                                |
| $\partial 0  = \{0\}$ 。                         | 正确为 $\partial 0  = [-1, 1]$ 。                               |
| 负次梯度总是下降方向。                                     | 在不可微点, 任取负次梯度未必为严格下降方向。                                     |
| 软阈值等于硬阈值。                                       | 软阈值会将非零坐标再缩小 $\lambda$ , 硬阈值只删除小坐标。                         |
| 距离函数和平方距离函数都处处可微。                               | 一般只有平方距离在闭凸情形下处处 $C^1$ 。                                    |
| 极集只在原集合凸时才凸。                                    | 极集总是半空间交, 因此总是闭凸。                                           |
| 锥的极等于对偶锥。                                       | 按本文约定 $K^\circ = -K^*$ 。                                    |
| 标准单纯形的极是 $\ell^\infty$ 单位球。                     | 正确为 $\{y : \max_i y_i \leq 1\}$ , 负方向无界。                    |
| 任意集合满足 $C^{\circ\circ} = C$ 。                   | 一般为 $C^{\circ\circ} = \text{cl conv}(C \cup \{0\})$ 。       |
| 双极证明中分离常数可以直接归一化为 1。                            | 若分离常数为 0, 必须另行通过放大法向量处理。                                    |
| 问题本身非扩张, 所以任意实现都数值稳定。                           | 具体实现还会受到线性系统条件数、舍入误差和停止容差影响。                                |

反例 25.22 (边界点次微分可以为空). 定义  $f(x) = \begin{cases} -\sqrt{x}, & x \geq 0, \\ +\infty, & x < 0. \end{cases}$  函数  $f$  在  $[0, \infty)$  上为凸函数。

若  $g \in \partial f(0)$ , 则对所有  $x > 0$  应有  $-\sqrt{x} \geq gx$ . 即  $g \leq -\frac{1}{\sqrt{x}} \quad \forall x > 0$ , 不存在有限  $g$  满足该条件。故  $\partial f(0) = \emptyset$ 。

反例 25.23 (非凸闭集的投影不唯一). 取  $C = \{-1, 1\} \subset \mathbb{R}$ ,  $z = 0$ . 则  $d_C(0) = 1$ , 且  $-1$  与  $1$  均为最优投影点。

因此闭性不能替代凸性。



## 第二十六章 线性规划标准型、顶点、基可行解、单纯形法、退化与两阶段法

### 26.1 线性规划模型、标准型与等价变换

#### 26.1.1 知识点一：问题与目标

【重要性等级】 **S 级**。

线性规划 (linear programming, LP) 研究在线性等式和线性不等式约束下优化线性目标函数的问题。

一般形式可写成

$$\begin{aligned} & \text{maximize} && c^\top x, \\ & \text{subject to} && Gx \leq h, \\ & && Ex = d, \\ & && \ell \leq x \leq u, \end{aligned} \tag{26.1}$$

其中某些分量可以没有上下界。

需要输出的对象可能是：

1. 一个最优解  $x^*$ ;
2. 最优值  $p^* = c^\top x^*$ ;
3. 不可行证书;
4. 无界方向;
5. 一组原始—对偶最优证书;
6. 一个最优基或最优顶点。

线性规划必须区分三个互斥的主要状态：

1. 不可行：可行域为空；
2. 可行且有有限最优值：存在最优解；
3. 可行但目标无界：对最大化问题， $\sup c^\top x = +\infty$ 。

#### 26.1.2 知识点二：标准型

本讲义采用 ?? 作为主标准型： $\max c^\top x \quad \text{s.t.} \quad Ax = b, \quad x \geq 0$ 。



其可行域为

$$P = \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}. \quad (26.2)$$

这里：

- $P$  是一个闭凸多面体；
- $P$  可以为空；
- $P$  可以有界，也可以无界；
- $m < n$  意味着变量数多于独立等式约束数；
- $\text{rank}(A) = m$  保证不存在冗余行约束；
- $b \geq 0$  不是标准型本身的必要条件；
- 但若希望以单位列对应的松弛变量作为初始基，通常需要相应右端非负。

### 26.1.3 知识点三：最小化和最大化的转换

最小化问题  $\min c^\top x$  等价于  $\max(-c)^\top x$ 。

因此，所有结论可以在最大化和最小化形式之间换算；但单纯形法中的约化成本符号必须同步改变。

本讲义中：

| 最大化问题                    | 最小化问题                    |
|--------------------------|--------------------------|
| $\bar{c}_j > 0$ 提示改进     | $\bar{c}_j < 0$ 提示改进     |
| $\bar{c}_j \leq 0$ 为最优判据 | $\bar{c}_j \geq 0$ 为最优判据 |

### 26.1.4 知识点四：不等式转为等式

小于等于约束。 若  $a^\top x \leq \beta$ , 引入松弛变量  $s \geq 0$ :

$$a^\top x + s = \beta. \quad (26.3)$$

大于等于约束。 若  $a^\top x \geq \beta$ , 引入剩余变量  $s \geq 0$ :

$$a^\top x - s = \beta. \quad (26.4)$$

注意：

- 松弛变量的列常为单位列，可能直接构成初始基；
- 剩余变量的列为负单位列，通常不能直接给出非负初始基；
- 对大于等于约束，往往还需要人工变量。

### 26.1.5 知识点五：自由变量、上下界和变量平移

若  $u$  为自由变量，即  $u \in \mathbb{R}$ , 可写成

$$u = u^+ - u^-, u^+ \geq 0, u^- \geq 0. \quad (26.5)$$



若  $u \geq \ell$ , 令

$$u = \ell + v, \quad v \geq 0. \quad (26.6)$$

若  $\ell \leq u \leq U$ , 令  $u = \ell + v$ ,  $0 \leq v \leq U - \ell$ , 再对上界加入松弛变量:

$$v + s = U - \ell, \quad s \geq 0. \quad (26.7)$$

### 26.1.6 知识点六: 右端符号和冗余约束

若某等式约束右端为负:  $a^\top x = \beta$ ,  $\beta < 0$ , 可将整行乘以  $-1$ :  $(-a)^\top x = -\beta$ 。

该操作不改变可行域。

标准化后应检查  $\text{rank}(A)$ 。若  $\text{rank}(A) < m$ , 则存在冗余行约束或不相容行约束。

- 冗余约束应删除, 以避免基矩阵必然奇异;
- 不相容约束将由两阶段法的第一阶段检测。

### 26.1.7 基础例题: 将一般线性规划化为标准型

#### 标准型转换

将下列问题化为 ?? 的形式:

$$\begin{aligned} & \text{maximize} && 4u_1 - u_2, \\ & \text{subject to} && u_1 - u_2 \leq 2, \\ & && 2u_1 + u_2 \geq 1, \\ & && u_1 \geq -1, \\ & && u_2 \text{ 为自由变量.} \end{aligned} \quad (26.8)$$

证明. 由  $u_1 \geq -1$ , 令

$$u_1 = x_1 - 1, \quad x_1 \geq 0. \quad (26.9)$$

因为  $u_2$  自由, 令

$$u_2 = x_2^+ - x_2^-, \quad x_2^+ \geq 0, \quad x_2^- \geq 0. \quad (26.10)$$

第一条约束变为

$$x_1 - 1 - x_2^+ + x_2^- \leq 2, \quad (26.11)$$

故加入松弛变量  $s_1 \geq 0$ :

$$x_1 - x_2^+ + x_2^- + s_1 = 3. \quad (26.12)$$

第二条约束变为

$$2(x_1 - 1) + x_2^+ - x_2^- \geq 1, \quad (26.13)$$

即  $2x_1 + x_2^+ - x_2^- \geq 3$ 。加入剩余变量  $s_2 \geq 0$ :

$$2x_1 + x_2^+ - x_2^- - s_2 = 3. \quad (26.14)$$



目标函数为

$$\begin{aligned} 4u_1 - u_2 &= 4(x_1 - 1) - (x_2^+ - x_2^-) \\ &= 4x_1 - x_2^+ + x_2^- - 4. \end{aligned} \quad (26.15)$$

常数  $-4$  不影响最优点, 因此可优化

$$4x_1 - x_2^+ + x_2^-. \quad (26.16)$$

所以标准型变量为  $x = \begin{pmatrix} x_1 & x_2^+ & x_2^- & s_1 & s_2 \end{pmatrix}^\top \geq 0$ , 约束矩阵为

$$\begin{pmatrix} 1 & -1 & 1 & 1 & 0 \\ 2 & 1 & -1 & 0 & -1 \end{pmatrix} x = \begin{pmatrix} 3 \\ 3 \end{pmatrix}. \quad (26.17)$$

由于第二行的剩余变量列为  $-e_2$ , 当前标准型没有显然的非负单位基; 求初始基时需要两阶段法或其他可行化方法。□

#### 易错点与反例

标准化的等价性必须理解为:

- 原变量与新变量之间存在明确的可行解映射;
- 原目标值可能与新目标值相差常数;
- 原问题为连续线性规划时, 标准化后仍是连续线性规划;
- 若原问题含整数约束, 变量分裂和松弛化并不会自动消除整数性。

因此, 含  $d_i \in \mathbb{Z}$  的投资分配题不能仅通过普通连续单纯形法完整求解。

## 26.2 多面体、顶点、基、基本解与基可行解

### 26.2.1 知识点七: 顶点与极点

设  $P \subseteq \mathbb{R}^n$  为凸集。点  $x \in P$  称为极点或顶点, 如果

$$x = \theta y + (1 - \theta)z, \quad y, z \in P, \quad 0 < \theta < 1 \quad (26.18)$$

必然推出  $y = z = x$ 。

等价地,  $x$  不能写成两个不同可行点的非平凡凸组合。

注 26.1. “顶点”是几何概念; “基可行解”是代数概念。

二者等价需要依赖标准型结构  $Ax = b, \quad x \geq 0$  及  $\text{rank}(A) = m$ 。

### 26.2.2 知识点八: 基、基本解和基可行解

设  $A = [a_1, \dots, a_n]$ ,  $\text{rank}(A) = m$ 。

选取指标集  $\mathcal{B} \subseteq \{1, \dots, n\}$ ,  $|\mathcal{B}| = m$ , 使

$$B = A_{\mathcal{B}} \quad (26.19)$$

非奇异。



则  $B$  称为一个基指标集,  $B$  称为基矩阵。

令  $\mathcal{N} = \{1, \dots, n\} \setminus \mathcal{B}$ 。由  $Ax = b$  可写成  $Bx_B + Nx_N = b$ 。

令非基变量  $x_N = 0$ , 则得到基本解

$$x_B = B^{-1}b, \quad x_N = 0. \quad (26.20)$$

若进一步满足

$$B^{-1}b \geq 0, \quad (26.21)$$

则称其为基可行解 (basic feasible solution, BFS)。

### 26.2.3 知识点九: 退化

若基可行解满足

$$x_B > 0, \quad (26.22)$$

则称其为非退化基可行解。

若存在基本变量等于零:

$$(x_B)_i = 0, \quad (26.23)$$

则称其为退化基可行解。

退化意味着:

- 同一个顶点可能由多个不同基表示;
- 单纯形枢轴可能改变基但不改变可行点;
- 目标值可能在一次枢轴中不严格改进;
- 若枢轴规则不当, 可能发生循环。

对于标准型  $Ax = b, \quad x \geq 0$ , 每个基可行解至少有  $n - m$  个非基变量为零。

若还有基本变量为零, 则零分量数严格大于  $n - m$ 。

### 26.2.4 知识点十: 支撑集刻画

对任意  $x \geq 0$ , 定义正支撑集


$$I_+(x) = \{j : x_j > 0\}. \quad (26.24)$$

**定理 26.2** (基可行解与顶点等价). 设  $P = \{x : Ax = b, x \geq 0\}$ ,  $\text{rank}(A) = m$ 。则对  $x \in P$ , 以下命题等价:

1.  $x$  是  $P$  的顶点;
2. 列集合  $\{a_j : j \in I_+(x)\}$  线性无关;
3.  $x$  是一个基可行解。

**证明:** 基可行解蕴含顶点. 设  $x$  由基  $B$  生成:  $x_B = B^{-1}b, x_N = 0$ 。假设  $x = \theta y + (1 - \theta)z$ ,  $y, z \in P$ ,  $0 < \theta < 1$ 。

对任意  $j \in \mathcal{N}$ , 有  $0 = x_j = \theta y_j + (1 - \theta)z_j$ 。由于  $y_j \geq 0, z_j \geq 0$ , 必有  $y_j = z_j = 0$ 。所以  $y_N = z_N = 0$ 。





又因  $Ay = Az = b$ , 有  $By_B = b$ ,  $Bz_B = b$ . 基矩阵  $B$  非奇异, 故  $y_B = z_B = B^{-1}b = x_B$ . 因此  $y = z = x$ . 故  $x$  为顶点.  $\square$

证明: 顶点蕴含正支撑列线性无关. 设  $x$  是顶点. 反设  $\{a_j : j \in I_+(x)\}$  线性相关.

则存在非零向量  $d \in \mathbb{R}^n$ , 满足

$$Ad = 0, d_j = 0, j \notin I_+(x). \quad (26.25)$$

因为对  $j \in I_+(x)$  有  $x_j > 0$ , 可取充分小的  $\varepsilon > 0$ , 使  $x_j \pm \varepsilon d_j \geq 0, \forall j \in I_+(x)$ . 而对  $j \notin I_+(x)$ ,  $x_j = 0, d_j = 0$ . 故  $x^\pm := x \pm \varepsilon d \geq 0$ .

同时  $Ax^\pm = Ax \pm \varepsilon Ad = b$ . 所以  $x^+, x^- \in P$ . 由于  $d \neq 0$ ,  $x^+ \neq x^-$ . 但  $x = \frac{1}{2}x^+ + \frac{1}{2}x^-$ , 与  $x$  为顶点矛盾.

故正支撑列线性无关.  $\square$

证明: 正支撑列线性无关蕴含基可行解. 设  $I = I_+(x)$ . 因为  $\{a_j : j \in I\}$  线性无关, 有  $|I| \leq m$ .

由于  $\text{rank}(A) = m$ , 可将这些列扩充成  $A$  的一个基:  $I \subseteq \mathcal{B}, |\mathcal{B}| = m, A_{\mathcal{B}}$  非奇异.

对  $j \notin \mathcal{B}$ , 必有  $j \notin I$ , 所以  $x_j = 0$ . 即  $x_N = 0$ . 又因  $Ax = b$ , 得到  $Bx_B = b$ . 故  $x_B = B^{-1}b \geq 0$ . 所以  $x$  是基可行解.  $\square$

### 26.2.5 知识点十一: 顶点的活跃约束判据

考虑一般多面体

$$P = \{x : Gx \leq h, Ex = d\}. \quad (26.26)$$

设  $I(x)$  为在  $x$  处活跃的不等式约束指标集:  $I(x) = \{i : g_i^\top x = h_i\}$ .

若  $x \in P$ , 则  $x$  为顶点的充要条件是

$$\text{span}(\{g_i : i \in I(x)\} \cup \{E \text{ 的行向量}\}) = \mathbb{R}^n. \quad (26.27)$$

换言之, 活跃约束法向量中必须存在  $n$  个线性无关向量.

对标准型  $Ax = b, x \geq 0$ , 活跃不等式是  $x_j = 0$ . 因此, 顶点需要:

- $m$  个独立等式约束;
- 至少  $n - m$  个独立的活跃非负约束;
- 合计达到  $n$  个独立活跃约束。


### 26.2.6 知识点十二: 线性规划基本定理

定理 26.3 (非空标准型可行域含有基可行解). 若  $P = \{x : Ax = b, x \geq 0\}$  非空, 且  $\text{rank}(A) = m$ , 则  $P$  至少含有一个基可行解.

证明. 任取  $x \in P$ .

若正支撑列  $\{a_j : j \in I_+(x)\}$  线性无关, 则由 定义 26.2 可知  $x$  已经是基可行解.

若这些列线性相关, 存在非零  $d$  满足  $Ad = 0, \text{supp}(d) \subseteq I_+(x)$ . 必要时将  $d$  替换成  $-d$ , 使至少存在一个  $d_i > 0$ .





定义

$$\theta = \min_{d_i > 0} \frac{x_i}{d_i} > 0. \quad (26.28)$$

令  $\tilde{x} = x - \theta d$ . 则  $A\tilde{x} = b$ ,  $\tilde{x} \geq 0$ , 且至少有一个原正分量变为零。故  $|I_+(\tilde{x})| < |I_+(x)|$ 。

重复该过程。正支撑大小是非负整数, 因此有限步后, 正支撑列必线性无关。所得点为基可行解。□

**定理 26.4** (存在最优解时存在最优基可行解). 若标准型线性规划  $\max\{c^\top x : x \in P\}$  存在最优解, 则至少存在一个最优基可行解。

证明. 任取一个最优解  $x^*$ 。

若其正支撑列线性无关, 则  $x^*$  已是基可行解。

否则存在非零  $d$ , 满足  $Ad = 0$ ,  $\text{supp}(d) \subseteq I_+(x^*)$ 。对充分小的  $\varepsilon > 0$ ,  $x^* \pm \varepsilon d$  均可行。

因为  $x^*$  最优:

$$c^\top(x^* + \varepsilon d) \leq c^\top x^*, \quad (26.29)$$

$$c^\top(x^* - \varepsilon d) \leq c^\top x^*. \quad (26.30)$$

所以  $c^\top d \leq 0$ ,  $-c^\top d \leq 0$ 。故

$$c^\top d = 0. \quad (26.31)$$

沿  $d$  或  $-d$  移动至某个正分量首次变为零, 目标值保持不变。因此可在保持最优性的同时减少正支撑大小。

有限次后得到正支撑列线性无关的最优点, 即最优基可行解。□

**推论 26.5** (有界多面体上的线性目标在顶点取最优值). 若  $P$  非空且有界, 则对任意  $c$ ,  $\max_{x \in P} c^\top x$  至少在一个顶点处达到。

#### 易错点与反例

以下说法错误:

“每个可行点都是某个基可行解。”

正确说法是:

- 每个顶点都是基可行解;
- 每个基可行解都是顶点;
- 一般可行点可以位于边、面或内部;
- 一个可行点可以写成若干顶点和衰退方向的组合。

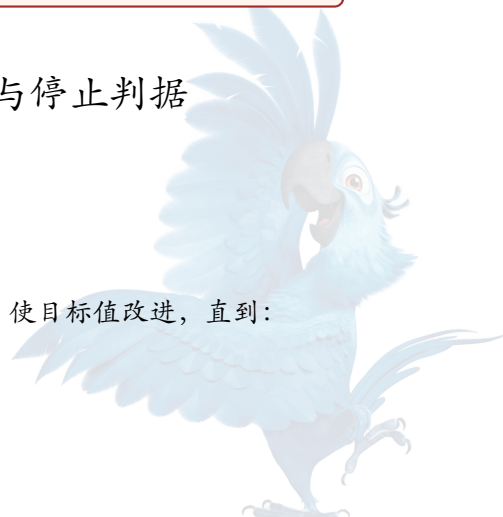
## 26.3 单纯形法的字典、约化成本、枢轴与停止判据

### 26.3.1 知识点十三: 单纯形法的核心思想

【重要性等级】 **S 级**。

单纯形法从一个基可行解出发, 沿多面体的边移动到相邻基可行解, 使目标值改进, 直到:

1. 找到最优基;



2. 发现目标无界;
3. 或在第一阶段判断原问题不可行。

单纯形法不是连续梯度迭代。它是有限个基之间的组合枢轴过程。

在精确算术下, 其主要“收敛”概念是有限终止, 而不是线性、超线性或二次收敛阶。

### 26.3.2 知识点十四: 基字典

设当前基为  $B$ , 非基集为  $\mathcal{N}$ , 并设  $B = A_B$ ,  $N = A_N$ 。由  $Bx_B + Nx_N = b$  得到

$$x_B = B^{-1}b - B^{-1}Nx_N. \quad (26.32)$$

记

$$\bar{b} = B^{-1}b, \quad (26.33)$$

$$\bar{A} = B^{-1}N. \quad (26.34)$$

则  $x_B = \bar{b} - \bar{A}x_N$ 。

当前基可行解为  $x_B = \bar{b} \geq 0$ ,  $x_N = 0$ 。

目标函数为

$$\begin{aligned} c^\top x &= c_B^\top x_B + c_N^\top x_N \\ &= c_B^\top B^{-1}b + [c_N^\top - c_B^\top B^{-1}N] x_N. \end{aligned} \quad (26.35)$$

定义基目标值

$$z_B = c_B^\top B^{-1}b \quad (26.36)$$

和约化成本向量

$$\boxed{\bar{c}_N = c_N - N^\top B^{-\top} c_B}. \quad (26.37)$$

令

$$y = B^{-\top} c_B, \quad (26.38)$$

则

$$\bar{c}_j = c_j - a_j^\top y. \quad (26.39)$$

对基本变量,  $\bar{c}_j = 0$ ,  $j \in B$ 。

### 26.3.3 知识点十五: 最优性判据

**定理 26.6** (最大化标准型的基最优性判据). 若当前基可行, 且

$$\bar{c}_j \leq 0, \quad \forall j \in \mathcal{N}, \quad (26.40)$$

则当前基可行解为全局最优解。


**证明.** 任取可行点  $x$ 。由 式 (26.35):

$$c^\top x = z_B + \bar{c}_N^\top x_N. \quad (26.41)$$

因为  $x_N \geq 0$ ,  $\bar{c}_N \leq 0$ , 有  $\bar{c}_N^\top x_N \leq 0$ 。故  $c^\top x \leq z_B$ 。而当前基可行解达到  $z_B$ , 所以它全局最优。  $\square$

**注 26.7.** 该证明没有使用强对偶定理, 只使用了基字典。

反过来,  $y = B^{-\top} c_B$  将在 [23F-Q6] 中构成对偶最优证书。



## 26.3.4 知识点十六：入基方向

若存在  $q \in \mathcal{N}$  满足  $\bar{c}_q > 0$ , 则增加  $x_q$  可能改进目标。

定义

$$u = B^{-1}a_q. \quad (26.42)$$

令方向  $d \in \mathbb{R}^n$  满足

$$d_q = 1, d_B = -u, d_j = 0, \quad j \in \mathcal{N} \setminus \{q\}. \quad (26.43)$$

则  $Ad = a_q - Bu = 0$ 。因此沿  $x(\theta) = x + \theta d$  移动时等式约束保持成立。

基本变量变为

$$x_B(\theta) = \bar{b} - \theta u. \quad (26.44)$$

目标值变化为

$$\begin{aligned} c^\top x(\theta) &= c^\top x + \theta c^\top d \\ &= c^\top x + \theta \bar{c}_q. \end{aligned} \quad (26.45)$$

## 26.3.5 知识点十七：无界性判据

若

$$u_i \leq 0, \quad i = 1, \dots, m, \quad (26.46)$$

则  $d_B = -u \geq 0$ 。因此对所有  $\theta \geq 0$ :  $x + \theta d \geq 0$ 。又  $A(x + \theta d) = b$ 。所以这是一个无限可行射线。

由于  $\bar{c}_q > 0$ , 有  $c^\top(x + \theta d) = c^\top x + \theta \bar{c}_q \rightarrow +\infty$ 。

故原问题无界。

**定理 26.8** (标准型线性规划的衰退锥). 可行域  $P = \{x : Ax = b, x \geq 0\}$  的衰退锥为

$$\text{rec}(P) = \{d : Ad = 0, d \geq 0\}. \quad (26.47)$$

若存在  $d \in \text{rec}(P)$  满足  $c^\top d > 0$ , 则最大化问题无界。

## 26.3.6 知识点十八：最小比值检验

若  $u$  至少有一个正分量, 则可行性要求  $\bar{b}_i - \theta u_i \geq 0$ 。对于  $u_i > 0$ :  $\theta \leq \frac{\bar{b}_i}{u_i}$ 。因此最大可行步长为

$$\theta^* = \min_{u_i > 0} \frac{\bar{b}_i}{u_i}. \quad (26.48)$$

若最小值在第  $\ell$  行达到, 则基本变量  $x_p$ ,  $p = B_\ell$ , 首先降为零, 称为出基变量。

新基为

$$\tilde{B} = (B \setminus \{p\}) \cup \{q\}. \quad (26.49)$$

因为  $u_\ell > 0$ , 替换后的基矩阵非奇异。

若  $\theta^* > 0$ , 则目标严格增加:

$$\Delta z = \theta^* \bar{c}_q > 0. \quad (26.50)$$

若  $\theta^* = 0$ , 则发生退化枢轴, 目标值不变。



## 26.3.7 知识点十九：入基和出基规则

常见入基规则包括：

1. **Dantzig** 规则：选择最大正约化成本；
2. **Bland** 规则：选择编号最小的正约化成本变量；
3. 最陡边规则：按单位几何步长上的目标增益选择；
4. 部分定价：只扫描部分非基变量，降低定价成本。

常见出基规则包括：

1. 最小比值检验；
2. Bland 最小编号破平；
3. 词典序比值检验；
4. Harris 两遍比值检验，用于浮点计算中的稳定枢轴选择。

## 26.3.8 单纯形算法

---


**Algorithm 86** 最大化标准型的原始修正单纯形法

---

**Input:**  $A \in \mathbb{R}^{m \times n}$ ,  $\text{rank}(A) = m$ ;  $b \in \mathbb{R}^m$ ;  $c \in \mathbb{R}^n$ ; 初始可行基  $\mathcal{B}$

**Output:** 最优基可行解，或无界证书

- 1: **Initialization:** 令  $\mathcal{N} = \{1, \dots, n\} \setminus \mathcal{B}$ ,  $B = A_{\mathcal{B}}$ ; 分解  $B$ , 解  $Bx_{\mathcal{B}} = b$ ; 验证  $x_{\mathcal{B}} \geq 0$
- 2: **loop**
- 3:   解  $B^{\top}y = c_{\mathcal{B}}$
- 4:   对  $j \in \mathcal{N}$  计算  $\bar{c}_j = c_j - a_j^{\top}y$
- 5:   **if**  $\bar{c}_j \leq 0$  对所有  $j \in \mathcal{N}$  **then**
- 6:     输出  $x_{\mathcal{B}} = B^{-1}b$ ,  $x_{\mathcal{N}} = 0$  及最优值  $c^{\top}x$
- 7:   **stop**
- 8:   **end if**
- 9:   按指定规则选择入基变量  $q \in \mathcal{N}$ ,  $\bar{c}_q > 0$
- 10:   解  $Bu = a_q$
- 11:   **if**  $u_i \leq 0$  对所有  $i$  **then**
- 12:     构造方向  $d_q = 1$ ,  $d_{\mathcal{B}} = -u$ ,  $d_{\mathcal{N} \setminus \{q\}} = 0$
- 13:     输出“原问题无界”及射线  $x + \theta d$
- 14:   **stop**
- 15:   **end if**
- 16:   计算  $\theta^* = \min_{u_i > 0} \frac{(x_{\mathcal{B}})_i}{u_i}$
- 17:   按指定破平规则选择出基行  $\ell$
- 18:   令  $p = \mathcal{B}_{\ell}$
- 19:   更新  $\mathcal{B} \leftarrow (\mathcal{B} \setminus \{p\}) \cup \{q\}$
- 20:   更新基矩阵分解和基本解
- 21: **end loop**
- 22: **Stopping criterion:** 精确算术下以约化成本符号停止; 浮点计算下检查:  $\|Ax - b\|_{\infty}$ ,  $\min_i x_i$ ,  $\max_{j \in \mathcal{N}} \bar{c}_j$  是否在容差内



23: **Complexity:** 稠密修正单纯形法中: 初始基分解为  $O(m^3)$ ; 每次三角求解为  $O(m^2)$ ; 完整约化成本定价为  $O(mn)$ ; 基更新通常为  $O(m^2)$ ; 存储为  $O(mn + m^2)$ 。枢轴次数在最坏情形可为指数级

### 26.3.9 综合例题: 完整单纯形枢轴

#### 两次枢轴求解线性规划

用单纯形法求解

$$\begin{aligned} & \text{maximize} && 3x_1 + 2x_2, \\ & \text{subject to} && x_1 + x_2 \leq 4, \\ & && 2x_1 + x_2 \leq 5, \\ & && x_1, x_2 \geq 0. \end{aligned} \tag{26.51}$$

第一步: 引入松弛变量. 加入  $x_3, x_4 \geq 0$ :

$$x_1 + x_2 + x_3 = 4, \tag{26.52}$$

$$2x_1 + x_2 + x_4 = 5. \tag{26.53}$$

初始基为  $B = \{3, 4\}$ ,  $N = \{1, 2\}$ 。初始字典为

$$x_3 = 4 - x_1 - x_2, \tag{26.54}$$

$$x_4 = 5 - 2x_1 - x_2, \tag{26.55}$$

$$z = 3x_1 + 2x_2. \tag{26.56}$$

初始基可行解为  $(x_1, x_2, x_3, x_4) = (0, 0, 4, 5)$ , 目标值为 0。 □

第二步: 第一次枢轴. 约化成本为  $\bar{c}_1 = 3$ ,  $\bar{c}_2 = 2$ 。按 Dantzig 规则令  $x_1$  入基。

增加  $x_1$  时:

$$x_3 = 4 - x_1, \tag{26.57}$$

$$x_4 = 5 - 2x_1. \tag{26.58}$$

最小比值为

$$\min \left\{ \frac{4}{1}, \frac{5}{2} \right\} = \frac{5}{2}. \tag{26.59}$$

故  $x_4$  出基, 步长  $\theta^* = \frac{5}{2}$ 。

从第二行解出


$$x_1 = \frac{5}{2} - \frac{1}{2}x_2 - \frac{1}{2}x_4. \tag{26.60}$$

代入第一行和目标函数:

$$x_3 = \frac{3}{2} - \frac{1}{2}x_2 + \frac{1}{2}x_4, \tag{26.61}$$

$$z = \frac{15}{2} + \frac{1}{2}x_2 - \frac{3}{2}x_4. \tag{26.62}$$

新基为  $B = \{3, 1\}$ ,  $N = \{2, 4\}$ 。新基可行解为  $(\frac{5}{2}, 0, \frac{3}{2}, 0)$ , 目标值为  $\frac{15}{2}$ 。 □



第三步：第二次枢轴. 在式 (26.62) 中,  $x_2$  的约化成本为  $\frac{1}{2} > 0$ , 故令  $x_2$  入基。

当  $x_4 = 0$  时:

$$x_1 = \frac{5}{2} - \frac{1}{2}x_2, \quad (26.63)$$

$$x_3 = \frac{3}{2} - \frac{1}{2}x_2. \quad (26.64)$$

比值为  $\frac{5/2}{1/2} = 5$ ,  $\frac{3/2}{1/2} = 3$ 。故  $x_3$  出基, 步长  $\theta^* = 3$ 。

由式 (26.61) 解出

$$x_2 = 3 + x_4 - 2x_3. \quad (26.65)$$

代回:

$$x_1 = 1 - x_4 + x_3, \quad (26.66)$$

$$z = 9 - x_3 - x_4. \quad (26.67)$$

新的非基变量为  $x_3 = x_4 = 0$ 。由于其约化成本均为  $-1 \leq 0$ , 当前解最优。

因此

$$x_1^* = 1, x_2^* = 3, z^* = 9. \quad (26.68)$$

□

#### 易错点与反例

比值检验不能写成  $\min_i \frac{(x_B)_i}{u_i}$  而不限制  $u_i > 0$ 。

原因是:

- $u_i < 0$  时, 增加入基变量会使相应基本变量增加;
- $u_i = 0$  时, 该基本变量不随步长变化;
- 只有  $u_i > 0$  时, 基本变量可能下降到零并限制步长。

## 26.4 退化、多重最优解、循环与 Bland 规则

### 26.4.1 知识点二十: 退化枢轴

若比值检验得到

$$\theta^* = 0, \quad (26.69)$$

则枢轴后:

- 基发生变化;
- 可行点不变;
- 目标值不变;
- 至少一个基本变量在枢轴前已经为零。

这称为退化枢轴。

退化不等于算法错误。它是多面体在顶点处有超过  $n$  个活跃约束的几何表现。



## 26.4.2 综合例题：零步长退化枢轴

退化枢轴但不循环

考虑

$$\begin{aligned}
& \text{maximize} && 2x_1 + x_2, \\
& \text{subject to} && x_1 \leq 1, \\
& && x_2 \leq 1, \\
& && x_1 + x_2 \leq 1, \\
& && x_1, x_2 \geq 0.
\end{aligned} \tag{26.70}$$

展示一次零步长枢轴。

证明. 加入松弛变量  $s_1, s_2, s_3 \geq 0$ :

$$s_1 = 1 - x_1, \tag{26.71}$$

$$s_2 = 1 - x_2, \tag{26.72}$$

$$s_3 = 1 - x_1 - x_2, \tag{26.73}$$

$$z = 2x_1 + x_2. \tag{26.74}$$

初始约化成本中  $x_1$  最大, 故令  $x_1$  入基。比值检验为  $\frac{1}{1} = 1$  来自  $s_1$ ,  $\frac{1}{1} = 1$  来自  $s_3$ 。出现并列。若令  $s_1$  出基, 则  $x_1 = 1 - s_1$ 。代回:

$$s_2 = 1 - x_2, \tag{26.75}$$

$$s_3 = s_1 - x_2, \tag{26.76}$$

$$z = 2 - 2s_1 + x_2. \tag{26.77}$$

当前基可行点为  $x_1 = 1, x_2 = 0, s_1 = 0, s_2 = 1, s_3 = 0$ 。注意  $s_3$  是基本变量, 但  $s_3 = 0$ 。故当前基可行解退化。

在式 (26.77) 中,  $x_2$  约化成本为  $1 > 0$ , 故尝试令  $x_2$  入基。增加  $x_2$  时:

$$s_2 = 1 - x_2, \tag{26.78}$$

$$s_3 = s_1 - x_2. \tag{26.79}$$

在当前非基变量  $s_1 = 0$  处, 比值为  $\frac{1}{1} = 1$  来自  $s_2$ ,  $\frac{0}{1} = 0$  来自  $s_3$ 。所以  $\theta^* = 0$ , 且  $s_3$  出基。从  $s_3 = s_1 - x_2$  解得  $x_2 = s_1 - s_3$ 。代回:


$$x_1 = 1 - s_1, \tag{26.80}$$

$$s_2 = 1 - s_1 + s_3, \tag{26.81}$$

$$z = 2 - s_1 - s_3. \tag{26.82}$$

枢轴后基发生变化, 但非基变量取零时仍得到  $x_1 = 1, x_2 = 0$ , 目标值仍为 2。

此时所有非基约化成本非正, 故该点最优。□



### 26.4.3 知识点二十一：多重最优解

在一个最优字典中，若  $\bar{c}_j = 0$  对某个非基变量成立，且该变量存在正的可行步长，则沿该方向目标值不变，可得到另一个最优可行点。

若枢轴后得到不同顶点，则存在多个最优顶点，其凸包中的所有点也最优。

但必须注意：

$$\bar{c}_j = 0 \text{ 不自动保证立即得到不同最优点.} \quad (26.83)$$

在退化情况下，对应的最大可行步长可能为零，需要经过若干退化枢轴才能到达另一个顶点；也可能最终仍没有不同的最优点。

### 26.4.4 知识点二十二：循环

若若干次枢轴后回到完全相同的基，则称单纯形法发生循环。

循环只能由退化引起，因为：

- 若每次步长均正，目标严格改进；
- 回到原基时目标值也回到原值；
- 因而循环中的所有枢轴都必须是退化枢轴。

反例 **26.9** (标准教材型循环现象，非附件题)。存在标准型线性规划，使 Dantzig 最大约化成本规则配合不当的并列破平规则重复访问同一组基。

一个经典数据形式为

$$\begin{aligned} & \text{maximize} && 10x_1 - 57x_2 - 9x_3 - 24x_4, \\ & \text{subject to} && \frac{1}{2}x_1 - \frac{11}{2}x_2 - \frac{5}{2}x_3 + 9x_4 \leq 0, \\ & && \frac{1}{2}x_1 - \frac{3}{2}x_2 - \frac{1}{2}x_3 + x_4 \leq 0, \\ & && x_1 \leq 1, \\ & && x \geq 0. \end{aligned} \quad (26.84)$$

从松弛变量基出发，某些自然的最大约化成本和比值并列规则会产生退化基循环。

本例的考试作用不是背诵全部枢轴表，而是说明：

“有限个基”  $\not\Rightarrow$  “任意枢轴规则必有限终止”。

### 26.4.5 知识点二十三：Bland 规则

Bland 规则规定：

1. 在所有具有改进符号的非基变量中，选择编号最小者入基；
2. 在最小比值并列的基本变量中，选择编号最小者出基。

定理 **26.10** (Bland 反循环定理)。在精确算术下，Bland 规则不会产生基循环。因此，只要问题可行且目标有界，原始单纯形法在有限次枢轴后终止。





**Bland 规则不循环的证明框架**

本结论的完整组合证明较长，资格考试通常要求掌握结论、使用方式和证明主线。  
证明主线如下。

1. 反设存在一个基循环；
2. 因为目标值回到原值，循环中的每次枢轴均退化；
3. 称在循环中曾经入基或出基的变量为“变动变量”；
4. 选择编号最大的变动变量  $x_r$ ；
5. 比较  $x_r$  入基前的字典和它出基时的字典；
6. 利用约化成本变换公式和最小比值并列关系，可构造一个编号大于  $r$  的变动变量，或得到某个编号更小的变量本应被 Bland 规则优先选择；
7. 两种情况均与  $r$  的选择或 Bland 最小编号规则矛盾。

关键不是目标严格增加，而是最小编号规则对可能的退化基序列建立了严格的组合次序。

**26.4.6 知识点二十四：词典序规则**

词典序比值检验通过对右端作形式微扰： $b_i \mapsto b_i + \varepsilon^i$ ,  $0 < \varepsilon \ll 1$ ，将并列比值按词典序区分。  
其作用是：

- 将原退化问题视为一个形式上非退化的微扰问题；
- 每次枢轴严格改进词典序量；
- 防止循环；
- 不需要实际选择一个极小浮点数  $\varepsilon$ 。

**易错点与反例**

不能在浮点程序中直接取  $\varepsilon = 10^{-100}$  模拟词典序微扰。  
原因是：

- 极小量可能在舍入中完全消失；
- 不同尺度约束会使固定  $\varepsilon$  无意义；
- 正确实现应比较系数向量的词典序，而不是实际加入极小数。

**26.5 两阶段法、人工变量与初始可行基****26.5.1 知识点二十五：为什么需要第一阶段**

原始单纯形法要求输入一个基可行解。

对纯小于等于约束  $Gx \leq h$ ,  $h \geq 0$ ，加入松弛变量后，松弛变量常可形成初始单位基。

但下列约束通常没有显然的初始可行基：

- 等式约束；



- 大于等于约束;
- 标准化后单位列符号不正确;
- 右端和基解不满足非负性。

两阶段法通过一个辅助线性规划寻找初始可行基。

### 26.5.2 知识点二十六：人工变量

预处理后设标准化等式为

$$\tilde{A}x = b, \quad x \geq 0, \quad b \geq 0, \quad (26.85)$$

但  $\tilde{A}$  中没有可用的单位基。

对需要人工变量的行加入  $a_i \geq 0$ 。最简单的全人工形式为

$$\tilde{A}x + Ia = b, \quad x \geq 0, \quad a \geq 0. \quad (26.86)$$

取  $x = 0, a = b$ , 得到显然的初始基可行解。

第一阶段问题可写成

$$\begin{array}{ll} \text{minimize} & w = \mathbf{1}^\top a, \\ \text{subject to} & \tilde{A}x + Ia = b, \\ & x \geq 0, \quad a \geq 0. \end{array} \quad (26.87)$$

为与本部分最大化单纯形统一, 也可最大化

$$\omega = -\mathbf{1}^\top a. \quad (26.88)$$

因为  $a \geq 0$ , 总有  $w \geq 0, \omega \leq 0$ 。

### 26.5.3 知识点二十七：第一阶段正确性

定理 26.11 (第一阶段可行性判据). 设第一阶段最优值为  $w^*$ 。则:

1. 若  $w^* > 0$ , 原问题不可行;
2. 若  $w^* = 0$ , 原问题可行。

证明. 若原问题可行, 存在  $x \geq 0$  满足  $\tilde{A}x = b$ 。则取  $a = 0$  得到第一阶段可行点, 且  $w = 0$ 。因为  $w \geq 0$ , 故  $w^* = 0$ 。

反之, 若  $w^* = 0$ , 由于每个  $a_i \geq 0$ , 必有  $a_i = 0, \forall i$ 。于是第一阶段最优解满足  $\tilde{A}x = b, x \geq 0$ 。故原问题可行。

因此若  $w^* > 0$ , 原问题不可能可行。□

### 26.5.4 知识点二十八：人工变量的清除

即使第一阶段得到  $w^* = 0$ , 仍可能有人工变量以零值留在基中。

设某个基本人工变量  $a_i = 0$ 。

处理方式:



1. 若该行中存在某个非人工非基变量具有非零枢轴系数，则作一次零步长枢轴，将该变量换入基、人工变量换出；
2. 若该行在所有原变量和松弛变量列上的系数均为零，则该行是冗余约束；可删除该行及对应人工变量；
3. 清除全部人工变量后，用所得基进入第二阶段。

第二阶段恢复原目标函数： $\max c^T x$ 。

必须重新将原目标函数按当前基化为字典形式，不能直接沿用第一阶段的约化成本。

### 26.5.5 两阶段单纯形算法

---

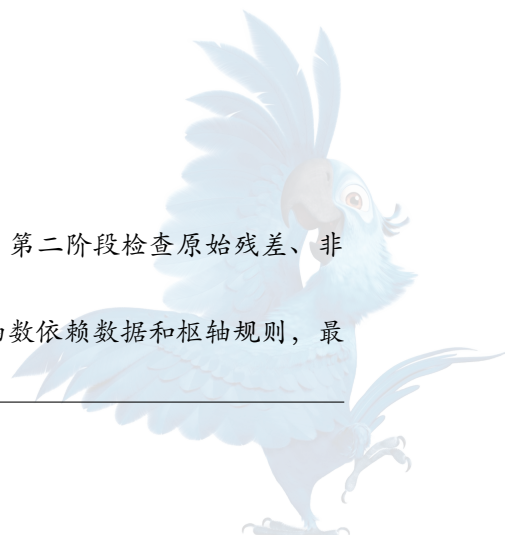
#### Algorithm 87 两阶段单纯形法

---

**Input:** 一般线性规划；线性约束；变量符号和上下界

**Output:** 最优解，或不可行证书，或无界证书

- 1: 标准化：将问题化为等式和非负变量形式
  - 2: 若某行右端为负，则将该行乘以  $-1$
  - 3: 识别可直接作为基的松弛变量列
  - 4: 对其余约束加入人工变量
  - 5: **Initialization:** 以人工变量和可用松弛变量组成初始基；构造第一阶段目标  $\min \mathbf{1}^T a$
  - 6: **Phase I:** 用单纯形法求解第一阶段问题
  - 7: **if**  $w^* > \text{tol}_{\text{feas}}$  **then**
  - 8:     输出“原问题不可行”
  - 9:     **stop**
  - 10: **end if**
  - 11: 对值为零但仍在基中的人工变量进行零步长换出
  - 12: 删除冗余行和全部人工变量列
  - 13: 恢复原目标函数并重新计算约化成本
  - 14: **Phase II:** 从当前可行基运行原始单纯形法
  - 15: **if** 出现改进约化成本且枢轴列无正分量 **then**
  - 16:     输出“原问题无界”及可行射线
  - 17: **else**
  - 18:     输出最优基可行解和最优值
  - 19: **end if**
  - 20: **Stopping criterion:** 第一阶段检查人工变量和  $w^*$  是否在容差内；第二阶段检查原始残差、非负性和约化成本
  - 21: **Complexity:** 两个阶段的单次枢轴成本与修正单纯形相同；总枢轴数依赖数据和枢轴规则，最坏情形仍可能为指数级；稠密存储为  $O(mn + m^2)$
- 



## 26.5.6 综合例题：完整两阶段计算

等式约束和大于等于约束的两阶段法

求解

$$\begin{aligned}
& \text{maximize} && 3x_1 + 2x_2, \\
& \text{subject to} && x_1 + x_2 = 4, \\
& && x_1 + 2x_2 \geq 6, \\
& && x_1, x_2 \geq 0.
\end{aligned} \tag{26.89}$$

第一步：加入剩余变量和人工变量。第一条等式需要人工变量  $a_1 \geq 0$ 。

第二条大于等于约束先减去剩余变量  $s_2 \geq 0$ ，再加入人工变量  $a_2 \geq 0$ 。

得到

$$x_1 + x_2 + a_1 = 4, \tag{26.90}$$

$$x_1 + 2x_2 - s_2 + a_2 = 6. \tag{26.91}$$

初始基为  $B = \{a_1, a_2\}$ ，初始基可行解为  $a_1 = 4, a_2 = 6, x_1 = x_2 = s_2 = 0$ 。  $\square$

第二步：第一阶段目标。最大化  $\omega = -a_1 - a_2$ 。由 式 (26.90) and (26.91)：

$$a_1 = 4 - x_1 - x_2, \tag{26.92}$$

$$a_2 = 6 - x_1 - 2x_2 + s_2. \tag{26.93}$$

故

$$\omega = -10 + 2x_1 + 3x_2 - s_2. \tag{26.94}$$

按 Dantzig 规则令  $x_2$  入基。

枢轴列在两行的正系数为 1, 2，比值为  $\frac{4}{1} = 4, \frac{6}{2} = 3$ 。故  $a_2$  出基。

从第二行解出

$$x_2 = 3 - \frac{1}{2}x_1 + \frac{1}{2}s_2 - \frac{1}{2}a_2. \tag{26.95}$$

代入第一行：

$$a_1 = 1 - \frac{1}{2}x_1 - \frac{1}{2}s_2 + \frac{1}{2}a_2. \tag{26.96}$$

第一阶段目标变为

$$\omega = -1 + \frac{1}{2}x_1 + \frac{1}{2}s_2 - \frac{3}{2}a_2. \tag{26.97}$$

$\square$

第三步：消除最后一个正人工变量。在 式 (26.97) 中， $x_1$  和  $s_2$  均有正约化成本 1/2。

按 Bland 规则选择编号较小的  $x_1$  入基。

增加  $x_1$  时：

$$x_2 = 3 - \frac{1}{2}x_1, \tag{26.98}$$

$$a_1 = 1 - \frac{1}{2}x_1. \tag{26.99}$$

比值为  $\frac{3}{1/2} = 6, \frac{1}{1/2} = 2$ 。故  $a_1$  出基。



从式 (26.96) 解出

$$x_1 = 2 - s_2 + a_2 - 2a_1. \quad (26.100)$$

代回式 (26.95):

$$x_2 = 2 + s_2 - a_2 + a_1. \quad (26.101)$$

若令非基变量  $s_2 = a_1 = a_2 = 0$ , 则  $x_1 = 2$ ,  $x_2 = 2$ , 且  $\omega = 0$ 。

因此第一阶段最优值为  $w^* = 0$ , 原问题可行。

人工变量  $a_1, a_2$  均已非基本, 可直接删除。□

第四步: 第二阶段. 恢复原目标:  $z = 3x_1 + 2x_2$ 。利用式 (26.100) and (26.101):

$$\begin{aligned} z &= 3(2 - s_2 + a_2 - 2a_1) + 2(2 + s_2 - a_2 + a_1) \\ &= 10 - s_2 + a_2 - 4a_1. \end{aligned} \quad (26.102)$$

删除人工变量后:

$$z = 10 - s_2. \quad (26.103)$$

非基变量  $s_2$  的约化成本为  $-1 \leq 0$ 。故当前基最优。

所以

$$\boxed{x_1^* = 2, x_2^* = 2, z^* = 10}. \quad (26.104)$$

□

### 26.5.7 不可行情形

考虑

$$\begin{cases} x_1 + x_2 = 1, \\ x_1 + x_2 = 2, \\ x_1, x_2 \geq 0. \end{cases} \quad (26.105)$$

加入人工变量:

$$x_1 + x_2 + a_1 = 1, \quad (26.106)$$

$$x_1 + x_2 + a_2 = 2. \quad (26.107)$$

两式相减得到  $a_2 - a_1 = 1$ 。因为  $a_1, a_2 \geq 0$ , 有  $a_1 + a_2 \geq 1$ 。取  $a_1 = 0$ ,  $a_2 = 1$ ,  $x_1 + x_2 = 1$  可达到 1。

故第一阶段最优值  $w^* = 1 > 0$ , 原问题不可行。

### 26.5.8 知识点二十九: 大 $M$ 法

大  $M$  法将人工变量直接放入原目标。

对最大化问题, 写成

$$\max [c^T x - M \mathbf{1}^T a], \quad M \gg 1. \quad (26.108)$$

其思想是对人工变量施加强烈惩罚。

但有限精度下存在以下问题:

1. 很难事先选择足够大但不过大的  $M$ ;



2.  $M$  过小可能无法排除人工变量;
3.  $M$  过大导致目标系数数量级严重失衡;
4. 约化成本计算可能发生严重消去;
5. 浮点容差难以区分真实最优性和人工惩罚误差。

因此实际数值实现通常更偏好两阶段法。

#### 易错点与反例

“两阶段法”与“大  $M$  法”都使用人工变量，但二者不是同一算法：

- 两阶段法先独立最小化人工变量之和;
- 大  $M$  法在一个目标中加入大惩罚;
- 两阶段法避免显式选择巨大数值参数  $M$ ;
- 大  $M$  法的符号推导可以精确，但浮点实现可能病态。

## 26.6 正式真题 [23F-Q6]——基可行解、顶点与对偶最优解

完整题目叙述：[23F-Q6]

考虑线性规划

$$\begin{aligned} & \text{maximize} && \langle c, x \rangle, \\ & \text{subject to} && Ax = b, \\ & && x \geq 0, \end{aligned} \quad (26.109)$$

其中  $x \in \mathbb{R}^n$ ,  $0 \leq b \in \mathbb{R}^m$ ,  $A \in \mathbb{R}^{m \times n}$ ,  $c \in \mathbb{R}^n$ ,  $A$  满行秩, 且  $m < n$ 。

- (1) 证明基可行解与可行域的顶点等价;
- (2) 写出对偶问题, 并证明: 若原问题存在最优解, 则对偶问题也存在最优解, 且二者最优目标值相等。

第 (1) 问: 基可行解等价于顶点

基可行解蕴含顶点. 设  $x$  为基可行解. 存在基指标集  $B$ , 使  $B = A_B$  非奇异, 且  $x_B = B^{-1}b \geq 0$ ,  $x_N = 0$ 。

若  $x = \theta y + (1 - \theta)z$ ,  $y, z \in P$ ,  $0 < \theta < 1$ , 则对  $j \in N$ :  $0 = x_j = \theta y_j + (1 - \theta)z_j$ . 由  $y_j, z_j \geq 0$  得到  $y_j = z_j = 0$ . 所以  $y_N = z_N = 0$ 。

由可行性:  $By_B = b$ ,  $Bz_B = b$ . 由于  $B$  非奇异:  $y_B = z_B = B^{-1}b = x_B$ . 故  $y = z = x$ . 因此  $x$  为顶点。□

顶点蕴含基可行解. 设  $x \in P$  为顶点, 定义  $I_+(x) = \{j : x_j > 0\}$ 。

若  $\{a_j : j \in I_+(x)\}$  线性相关, 则存在非零向量  $d$ , 满足  $Ad = 0$ ,  $d_j = 0$  当  $x_j = 0$ 。由于正支撑上的  $x_j > 0$ , 可取充分小  $\varepsilon > 0$ , 使  $x \pm \varepsilon d \geq 0$ . 同时  $A(x \pm \varepsilon d) = b$ . 故  $x^\pm = x \pm \varepsilon d$  是两个不同可行点, 且  $x = \frac{1}{2}x^+ + \frac{1}{2}x^-$ . 这与  $x$  是顶点矛盾。

所以正支撑列线性无关。由于  $\text{rank}(A) = m$ , 可将正支撑列扩充为  $m$  列组成的基  $B$ 。

基外变量必为零, 且  $Bx_B = b$ 。故  $x_B = B^{-1}b \geq 0$ ,  $x_N = 0$ 。所以  $x$  是基可行解。  $\square$

## 第 (2) 问: 写出对偶问题

原问题是

$$\begin{aligned} & \text{maximize} && c^\top x, \\ & \text{subject to} && Ax = b, \\ & && x \geq 0. \end{aligned} \quad (26.110)$$

其对偶问题为

$$\begin{aligned} & \text{minimize} && b^\top y, \\ & \text{subject to} && A^\top y \geq c, \\ & && y \in \mathbb{R}^m \text{ 为自由变量.} \end{aligned} \quad (26.111)$$

由于原约束为等式, 对偶变量  $y$  没有符号限制。

由于原变量满足  $x \geq 0$ , 对偶约束为  $A^\top y \geq c$ 。

## 弱对偶

任取原始可行点  $x$  和对偶可行点  $y$ 。由  $A^\top y \geq c$ ,  $x \geq 0$ , 得到  $x^\top A^\top y \geq x^\top c$ 。又  $Ax = b$ , 所以

$$c^\top x \leq b^\top y. \quad (26.112)$$

这说明任何对偶可行目标值都是原始最大化目标的上界。

## 证明对偶最优解存在并且最优值相等

基于单纯形终止的构造性证明。假设原问题存在最优解。

由 定义 26.4, 存在最优基可行解。

从任意可行基出发, 使用 Bland 规则运行单纯形法。由于原问题有有限最优值, 算法不可能以无界射线终止。由 定义 26.10, 算法不会循环, 故有限步后到达一个基  $B$ , 满足

$$\bar{c}_j \leq 0, \forall j \in \mathcal{N}. \quad (26.113)$$

令  $B = A_B$ ,  $x_B^* = B^{-1}b$ ,  $x_N^* = 0$ 。定义

$$y^* = B^{-\top} c_B. \quad (26.114)$$

对基本列:  $A_B^\top y^* = B^\top B^{-\top} c_B = c_B$ 。

对非基本列  $a_j$ :  $\bar{c}_j = c_j - a_j^\top y^* \leq 0$ 。因此  $a_j^\top y^* \geq c_j$ 。综上:

$$A^\top y^* \geq c. \quad (26.115)$$

所以  $y^*$  对偶可行。





其目标值为

$$\begin{aligned}
 b^\top y^* &= b^\top B^{-\top} c_B \\
 &= c_B^\top B^{-1} b \\
 &= c_B^\top x_B^* \\
 &= c^\top x^*.
 \end{aligned} \tag{26.116}$$

由弱对偶, 任何原始可行值不超过任何对偶可行值。现在原始可行点  $x^*$  和对偶可行点  $y^*$  达到相同目标值, 所以二者分别最优, 且

$$p^* = d^*. \tag{26.117}$$

□

注 26.12 (几何证明路线). 也可从最优点  $x^*$  处的法锥条件出发。

原问题为最大化, 因此  $c \in N_P(x^*)$ 。对  $P = \{x : Ax = b, x \geq 0\}$ , 多面体法锥可写成  $N_P(x^*) = \{A^\top y - s : s \geq 0, s_i x_i^* = 0\}$ 。故存在  $y, s$  使  $c = A^\top y - s, s \geq 0$ 。于是  $A^\top y \geq c$ , 且  $c^\top x^* = y^\top A x^* - s^\top x^* = b^\top y$ 。

第 27 部分将以 Farkas 引理、分离定理和 Lagrange 对偶系统重述该证明, 不重复本题全部题面。

#### 易错点与反例

[23F-Q6] 的典型失分点:

1. 把“基本解”与“基可行解”混为一谈;
2. 顶点反向证明中只说“显然可扩充成基”, 却未先证明正支撑列线性无关;
3. 对偶方向写反:  $A^\top y \leq c$ ;
4. 错误要求等式约束的对偶变量  $y \geq 0$ ;
5. 只写弱对偶, 没有证明对偶最优解存在;
6. 在任意退化最优基上直接假定约化成本全部非正;
7. 计算  $b^\top y$  时遗漏转置;
8. 没有说明所用最大化约定。


## 26.7 数值稳定性、复杂度、停止容差与失败情形

### 26.7.1 知识点三十: 不能显式形成 $B^{-1}$

数学推导常写  $B^{-1}b$ ,  $B^{-1}a_q$ ,  $B^{-\top}c_B$ , 但数值实现不应显式形成  $B^{-1}$ 。

应使用:

- LU 分解;
- 稀疏 LU 分解;
- Forrest-Tomlin 更新;
- Bartels-Golub 更新;





- 周期性重新分解。

原因是显式逆：

1. 成本较高；
2. 存储较大；
3. 稀疏性被破坏；
4. 往往产生更大的舍入误差；
5. 不利于残差校正。

### 26.7.2 知识点三十一：基矩阵条件数

若  $\kappa_2(B) = \|B\|_2 \|B^{-1}\|_2$  很大，则以下量对扰动敏感：

$$x_B = B^{-1}b, \quad (26.118)$$

$$u = B^{-1}a_q, \quad (26.119)$$

$$y = B^{-\top}c_B, \quad (26.120)$$

$$\bar{c}_j = c_j - a_j^\top y. \quad (26.121)$$

后果包括：

- 一个本应为零的基本变量可能计算成小负数；
- 一个本应为零的约化成本可能因舍入改变符号；
- 比值检验可能选到数值上很小的枢轴元；
- 算法可能错误判断最优、退化或无界；
- 原始和对偶残差可能逐步累积。

因此，问题的几何退化和算法的数值不稳定是不同概念：

退化  $\neq$  基矩阵病态  $\neq$  算法不稳定。

### 26.7.3 知识点三十二：浮点停止准则

最大化标准型中，常检查：

原始等式残差。

$$r_p = Ax - b. \quad (26.122)$$

非负性违反。

$$\eta_p = \max_i (-x_i)_+. \quad (26.123)$$



约化成本违反。

$$\eta_d = \max_{j \in N} (\bar{c}_j)_+. \tag{26.124}$$

可使用缩放后的判据：

$$\frac{\|Ax - b\|_\infty}{1 + \|b\|_\infty} \leq \tau_p, \tag{26.125}$$

$$\eta_p \leq \tau_p, \tag{26.126}$$

$$\frac{\eta_d}{1 + \|c\|_\infty} \leq \tau_d. \tag{26.127}$$

第一阶段还要检查

$$w^* \leq \tau_{\text{feas}}. \tag{26.128}$$

易错点与反例

浮点计算中不能机械地使用：  
 $x_i < 0, \bar{c}_j > 0, w^* > 0$  作为零容差逻辑。  
但容差也不能任意放大；否则会把：

- 真实不可行问题误判为可行；
- 真实改进方向误判为最优；
- 小但真实的无界方向误判为数值噪声。

26.7.4 知识点三十三：复杂度

设  $A \in \mathbb{R}^{m \times n}$ ,  $m < n$ 。

| 实现      | 每次枢轴主要成本                                     | 主要存储          |
|---------|----------------------------------------------|---------------|
| 完整单纯形表  | 更新全部 $m \times n$ 表，约为 $O(mn)$               | $O(mn)$       |
| 稠密修正单纯形 | 两次基三角求解 $O(m^2)$ ，完整定价 $O(mn)$ ，基更新 $O(m^2)$ | $O(mn + m^2)$ |
| 稀疏修正单纯形 | 取决于基分解填充、稀疏三角求解和定价策略                         | 原矩阵非零元加基分解填充  |
| 部分定价    | 只扫描部分非基变量，降低单次定价成本                           | 依扫描块大小而定      |
| 重新分解    | 一次稠密分解 $O(m^3)$                              | $O(m^2)$      |

单纯形法的枢轴次数：

- 实际中常较小；
- 但最坏情形可能随维数指数增长；
- 不能把“实际性能优良”写成“多项式时间保证”；
- 不存在通常意义上的固定收敛阶。



26.7.5 知识点三十四：缩放和预处理

常见数值预处理包括：

- 1. 行缩放：使各约束行范数接近；
- 2. 列缩放：使变量列尺度接近；
- 3. 删除显然冗余约束；
- 4. 固定已由界约束确定的变量；
- 5. 检测零行和零列；
- 6. 合并重复约束；
- 7. 对近奇异基周期性重新分解。

缩放不改变问题的组合结构时，应同时正确换算：

- 原变量；
- 对偶变量；
- 约化成本；
- 最终残差；
- 灵敏度解释。

26.8 线性规划与单纯形法易错点及答题模板

| 错误说法或错误做法            | 正确处理                                             |
|----------------------|--------------------------------------------------|
| 标准型必须满足 $b \geq 0$ 。 | 标准型只要求 $Ax = b, x \geq 0; b \geq 0$ 主要用于某些显然初始基。 |
| 把自由变量直接当成非负变量。       | 应写成 $u = u^+ - u^-$ , $u^\pm \geq 0$ 。           |
| 对大于等于约束加入正松弛变量。      | 应减去剩余变量；寻找初始基时往往还需人工变量。                          |
| 基本解自动可行。             | 只有 $B^{-1}b \geq 0$ 时才是基可行解。                     |
| 任意 $m$ 列都构成基。        | 必须要求对应 $m \times m$ 子矩阵非奇异。                      |
| 顶点一定恰有 $m$ 个正变量。     | 非退化顶点通常有 $m$ 个正基本变量；退化顶点可少于 $m$ 个正变量。            |
| 一个顶点只对应一个基。          | 退化顶点可对应多个基。                                      |
| 每个可行点都是基可行解。         | 只有顶点等价于基可行解。                                     |
| 线性目标的最优解一定唯一。        | 最优集可能是一条边或更高维面。                                  |
| 约化成本为零必有另一个最优顶点。     | 退化时可行步长可能为零，需要进一步分析。                             |
| 最大化问题中约化成本全非负表示最优。   | 按本文约定应为全非正。                                      |



| 错误说法或错误做法                   | 正确处理                            |
|-----------------------------|---------------------------------|
| 比值检验对所有枢轴列分量计算。             | 只对 $u_i > 0$ 的行计算。              |
| 枢轴列无正分量表示不可行。               | 若入基约化成本为正且枢轴列无正分量，表示目标无界。       |
| 目标值一次未增加就应停止。               | 可能只是退化枢轴。                       |
| 有限个基自动保证单纯形不循环。             | 退化时可能重复基；需 Bland 或词典序规则。        |
| Bland 规则选择最大约化成本。           | Bland 规则选择编号最小的可改进变量。           |
| 第一阶段最优值很小就一定严格可行。           | 浮点中需结合缩放和容差；精确理论要求 $w^* = 0$ 。  |
| 第一阶段 $w^* = 0$ 后可保留人工基本变量。  | 零人工基本变量应换出；无法换出时检查并删除冗余行。       |
| 第二阶段可以继续使用第一阶段目标字典。         | 必须恢复原目标并按当前基重新消元。               |
| 大 $M$ 越大越好。                 | 过大的 $M$ 会造成尺度失衡和数值病态。           |
| 单纯形法具有二次收敛。                 | 它是有限组合枢轴算法，通常不使用迭代收敛阶描述。        |
| 问题有最优解，任意表示该点的基都满足约化成本最优条件。 | 退化最优点的某些基仍可能含正约化成本；需作退化枢轴到达最优基。 |
| 连续 LP 与整数 LP 使用同一顶点结论即可求解。  | LP 松弛顶点不一定满足整数约束；整数规划需额外算法。     |
| 显式计算 $B^{-1}$ 最直接、最稳定。      | 应通过 LU 分解和三角求解计算相关量。            |
| 原始残差小就说明目标最优。               | 还需检查非负性、约化成本和原始—对偶间隙。           |

基可行解—顶点等价：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：标准型可行域  $Ax = b, x \geq 0$  及“顶点”、“极点”、“基可行解”等关键词。

构造步骤：

1. BFS 到顶点：先由非基变量为零和非负性，推出凸组合端点的相应分量也为零；
2. 再由基矩阵非奇异推出基本分量唯一；
3. 顶点到 BFS：取正支撑列；
4. 若线性相关，则构造  $Ad = 0$  的双向可行扰动；
5. 与顶点定义矛盾；
6. 将独立正支撑列扩充成完整基。

关键估计：

$0 < \varepsilon < \min_{d_i \neq 0} \frac{x_i}{|d_i|}$  保证  $x \pm \varepsilon d \geq 0$ 。

结论：几何顶点和代数基可行解完全等价。

常见失败原因：

- 没有限制扰动支撑；
- 忘记  $A$  满行秩；

- 没有说明如何扩充到  $m$  列基;
- 将退化误当成反例。

#### 单纯形枢轴：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：已知一个基可行解，需要判断最优或寻找相邻改进顶点。

构造步骤：

1. 解  $B^T y = c_B$ ;
2. 计算约化成本;
3. 若全非正，则停止;
4. 选取正约化成本变量入基;
5. 解  $Bu = a_q$ ;
6. 若  $u \leq 0$ ，构造无界射线;
7. 否则作最小比值检验;
8. 换基并更新分解。

关键估计：

$$\theta^* = \min_{u_i > 0} \frac{(x_B)_i}{u_i}.$$

结论：得到最优基、相邻改进基或无界证书。

常见失败原因：

- 最大化和最小化符号混淆;
- 比值检验包含非正分量;
- 退化时循环;
- 枢轴元过小;
- 显式形成基逆。

#### 两阶段法：识别信号—构造步骤—关键判据—结论—失败原因

识别信号：等式、大于等于约束或标准化后不存在显然可行基。

构造步骤：

1. 预处理负右端;
2. 加入松弛、剩余和人工变量;
3. 以人工变量构造初始基;
4. 第一阶段最小化人工变量之和;
5. 检查第一阶段最优值;
6. 清除零人工基本变量和冗余行;
7. 恢复原目标;

8. 第二阶段运行单纯形法。

关键判据：

$w^* = 0 \iff$  原问题可行。

结论：得到原问题的可行基，或证明原问题不可行。

常见失败原因：

- 人工变量符号错误；
- 第一阶段目标未消去基本人工变量；
- $w^* = 0$  后未清除人工变量；
- 第二阶段未重新建立目标字典。



## 第二十七章 线性规划对偶、强对偶、互补松弛、障碍函数与原始—对偶内点法

### 统一符号

本部分同时使用两个明确区分的线性规划约定。

约定 **A**：与 [23F-Q6] 和第 26 部分一致的最大化形式。

$$\begin{aligned} & \text{maximize} && c^\top x, \\ & \text{subject to} && Ax = b, \\ & && x \geq 0, \end{aligned} \tag{P_{\max}}$$

其对偶写为

$$\begin{aligned} & \text{minimize} && b^\top y, \\ & \text{subject to} && A^\top y \geq c, \\ & && y \in \mathbb{R}^m \text{ 自由}. \end{aligned} \tag{D_{\min}}$$

定义对偶松弛变量

$$s = A^\top y - c \geq 0. \tag{27.1}$$


约定 **B**：原始—对偶内点法的标准最小化形式。

$$\begin{aligned} & \text{minimize} && c^\top x, \\ & \text{subject to} && Ax = b, \\ & && x \geq 0, \end{aligned} \tag{P}$$

其对偶写为

$$\begin{aligned} & \text{maximize} && b^\top y, \\ & \text{subject to} && A^\top y + s = c, \\ & && s \geq 0, y \in \mathbb{R}^m \text{ 自由}. \end{aligned} \tag{D}$$

二者通过  $c \mapsto -c$  相互转换。本部分每次切换约定时均明确说明，不静默混合约化成本、对偶约束或间隙的符号。



## 27.1 线性规划的原始—对偶配对与符号换算

### 27.1.1 知识点一：最大化标准型的对偶构造

【重要性等级】 S 级。判定依据：

- 该内容在 [23F-Q6] 中直接考查；
- 是单纯形约化成本、互补松弛、灵敏度分析和内点法的共同基础；
- 符号约定错误会使整道题后续全部反号；
- 正式考试常要求从原问题独立写出对偶，而不是只套公式表。

考虑式  $(P_{\max})$ 。对任意  $y \in \mathbb{R}^m$  若满足  $A^\top y \geq c$ ，则对任意原始可行点  $x$ ：

$$\begin{aligned} c^\top x &\leq (A^\top y)^\top x \\ &= y^\top Ax \\ &= y^\top b. \end{aligned} \quad (27.2)$$

因此，每个满足  $A^\top y \geq c$  的  $y$  都给出原始最大化目标的上界。在所有上界中寻找最小者，得到式  $(D_{\min})$ 。

### 27.1.2 知识点二：用 Lagrange 函数推导最大化对偶

对最大化问题，可定义

$$L(x, y) = c^\top x + y^\top (b - Ax), \quad x \geq 0. \quad (27.3)$$

对固定  $y$ ，上确界函数为

$$\begin{aligned} q(y) &= \sup_{x \geq 0} L(x, y) \\ &= b^\top y + \sup_{x \geq 0} (c - A^\top y)^\top x. \end{aligned} \quad (27.4)$$

若存在某个分量  $c_j - (A^\top y)_j > 0$ ，令  $x_j \rightarrow +\infty$ ，则  $q(y) = +\infty$ 。

若  $A^\top y \geq c$ ，则  $(c - A^\top y)^\top x \leq 0$  对所有  $x \geq 0$  成立，且在  $x = 0$  处取到 0。因此

$$q(y) = \begin{cases} b^\top y, & A^\top y \geq c, \\ +\infty, & \text{否则}. \end{cases} \quad (27.5)$$

最小化  $q(y)$  即得到式  $(D_{\min})$ 。

### 27.1.3 知识点三：最小化标准型的对偶构造

考虑式  $(P)$ 。对任意满足  $A^\top y \leq c$  的  $y$ ，原始可行点  $x$  满足

$$\begin{aligned} b^\top y &= x^\top A^\top y \\ &\leq x^\top c. \end{aligned} \quad (27.6)$$

因此对偶为

$$\begin{aligned} &\text{maximize} && b^\top y, \\ &\text{subject to} && A^\top y \leq c. \end{aligned} \quad (27.7)$$





令  $s = c - A^\top y \geq 0$ , 得到 式 (D)。

注 27.1 (与 [ConvOpt-Bao] 的符号换算). [ConvOpt-Bao] 对最小化问题采用  $L(x, \nu) = c^\top x + \nu^\top (Ax - b)$ 。此时对偶写成  $\max -b^\top \nu, A^\top \nu + c \geq 0$ 。令  $y = -\nu$ , 即可化为  $\max b^\top y, A^\top y \leq c$ 。两种形式完全等价。

#### 27.1.4 知识点四：一般最大化线性规划的符号表

考虑最大化问题。对偶符号可按以下规则记忆。

| 原问题对象     | 原问题形式                 | 对应对偶对象                  |
|-----------|-----------------------|-------------------------|
| 第 $i$ 个约束 | $a_i^\top x \leq b_i$ | $y_i \geq 0$            |
| 第 $i$ 个约束 | $a_i^\top x \geq b_i$ | $y_i \leq 0$            |
| 第 $i$ 个约束 | $a_i^\top x = b_i$    | $y_i$ 自由                |
| 第 $j$ 个变量 | $x_j \geq 0$          | $(A^\top y)_j \geq c_j$ |
| 第 $j$ 个变量 | $x_j \leq 0$          | $(A^\top y)_j \leq c_j$ |
| 第 $j$ 个变量 | $x_j$ 自由              | $(A^\top y)_j = c_j$    |

其本质不是背诵，而是保证  $c^\top x \leq b^\top y$  对全部原始—对偶可行点成立。

##### 易错点与反例

对偶符号的最稳妥检查方法是：

$$\boxed{\text{将原始约束和变量符号代回，验证弱对偶不等式}}. \quad (27.8)$$

若写出的对偶不能推出  $c^\top x \leq b^\top y$  或  $b^\top y \leq c^\top x$ , 则符号一定存在错误。

## 27.2 弱对偶、对偶间隙与最优性证书

### 27.2.1 知识点五：弱对偶

对最大化—最小化配对 式 (P<sub>max</sub>) and (D<sub>min</sub>):

定理 27.2 (弱对偶). 若  $x$  原始可行,  $y$  对偶可行, 则

$$\boxed{c^\top x \leq b^\top y}. \quad (27.9)$$

对最小化—最大化配对 式 (P) and (D):

定理 27.3 (弱对偶的最小化形式). 若  $Ax = b, x \geq 0$ , 且  $A^\top y + s = c, s \geq 0$ , 则

$$\boxed{b^\top y \leq c^\top x}. \quad (27.10)$$

证明. 由  $A^\top y + s = c$  有

$$\begin{aligned} c^\top x - b^\top y &= x^\top (A^\top y + s) - y^\top b \\ &= y^\top (Ax - b) + x^\top s \\ &= x^\top s \geq 0. \end{aligned} \quad (27.11)$$



□

27.2.2 知识点六：对偶间隙

对式 (P) and (D)，原始—对偶可行点的对偶间隙定义为

$$\text{gap}(x, y, s) = c^\top x - b^\top y = x^\top s.$$

(27.12)

对式 (P<sub>max</sub>) and (D<sub>min</sub>)，若  $s = A^\top y - c \geq 0$ ，则

$$b^\top y - c^\top x = x^\top s.$$

(27.13)

因此，若找到原始—对偶可行点满足  $x^\top s = 0$ ，则二者目标值相同。由弱对偶可立即判定：

$$x \text{ 原始最优}, (y, s) \text{ 对偶最优}.$$

(27.14)

27.2.3 知识点七：可计算证书

线性规划中常见的证书如下。

| 结论      | 证书                | 验证条件                                                |
|---------|-------------------|-----------------------------------------------------|
| 原问题可行   | 向量 $x$            | $Ax = b, \quad x \geq 0$                            |
| 对偶可行    | 向量 $y, s$         | $A^\top y + s = c, \quad s \geq 0$                  |
| 原始—对偶最优 | $x, y, s$         | 原始可行、对偶可行且 $x^\top s = 0$                           |
| 原问题无界   | 可行点 $x_0$ 与方向 $d$ | $Ad = 0, \quad d \geq 0, \quad c^\top d < 0$ 对最小化问题 |
| 原问题不可行  | Farkas 向量 $y$     | $A^\top y \geq 0, \quad b^\top y < 0$               |

注 27.4. 对最小化问题，无界方向条件为  $c^\top d < 0$ 。对最大化问题则应改为  $c^\top d > 0$ 。

原始—对偶构造：识别信号—构造步骤—关键估计—结论—常见失败原因

识别信号：

- 题目要求“写出对偶问题”；
- 需要给出最优值上界或下界；
- 需要证明某候选解最优；
- 单纯形法已经给出约化成本和基乘子；
- 需要解释影子价格或灵敏度。

构造步骤：

1. 统一原问题是最大化还是最小化；
2. 对每个约束确定对偶变量符号；
3. 对每个原变量确定对偶约束方向；

4. 写出原始—对偶目标;
5. 用弱对偶检查符号;
6. 引入对偶松弛变量;
7. 计算对偶间隙。

关键估计:

$$c^\top x - b^\top y = x^\top s \geq 0 \text{ 或 } b^\top y - c^\top x = x^\top s \geq 0.$$

结论: 可行性加零间隙构成可独立验证的最优性证书。

常见失败原因:

- 最大化和最小化约定混用;
- 等式约束的对偶变量错误地加符号限制;
- 自由原变量对应的对偶约束没有写成等式;
- 只写出对偶形式, 没有验证弱对偶;
- 非可行迭代点上误把  $x^\top s$  当作精确目标间隙。

## 27.3 Farkas 引理、不可行证书与强对偶

### 27.3.1 知识点八: Farkas 引理

【重要性等级】 **S 级**。

定理 27.5 (Farkas 引理). 给定  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ , 下列两个系统恰有一个有解:

1.

$$Ax = b, \quad x \geq 0; \quad (27.15)$$

2.

$$A^\top y \geq 0, \quad b^\top y < 0. \quad (27.16)$$

证明. 先证二者不能同时成立。

若  $Ax = b$ ,  $x \geq 0$  且  $A^\top y \geq 0$ , 则

$$b^\top y = x^\top A^\top y \geq 0, \quad (27.17)$$

与  $b^\top y < 0$  矛盾。

再证若第一系统无解, 则第二系统有解。


令

$$K = \{Ax : x \geq 0\} = \text{cone}\{a_1, \dots, a_n\}. \quad (27.18)$$

$K$  是有限生成多面锥, 因此为闭凸锥。

第一系统无解等价于  $b \notin K$ 。由闭凸集与外点的严格分离定理, 存在  $y \neq 0$  和  $\alpha$ , 使

$$y^\top b < \alpha \leq y^\top z, \quad \forall z \in K. \quad (27.19)$$



因为  $0 \in K$ ,  $\alpha \leq 0$ . 又由于  $K$  为锥, 若存在  $z \in K$  使  $y^\top z < 0$ , 则对  $t \rightarrow +\infty$ ,  $tz \in K$ ,  $y^\top(tz) \rightarrow -\infty$ , 与式 (27.19) 矛盾。

故  $y^\top z \geq 0$ ,  $\forall z \in K$ . 特别地, 对每个列向量  $a_j$ :  $a_j^\top y \geq 0$ . 所以  $A^\top y \geq 0$ .

同时  $b^\top y < \alpha \leq 0$ , 故  $b^\top y < 0$ . □

### 27.3.2 知识点九: 不等式系统的 Farkas 证书

系统

$$Gx \leq h \quad (27.20)$$

不可行的一个标准证书是存在  $\lambda \geq 0$  满足

$$G^\top \lambda = 0, \quad h^\top \lambda < 0. \quad (27.21)$$

事实上, 若  $Gx \leq h$ , 则  $\lambda^\top Gx \leq \lambda^\top h$ . 若  $G^\top \lambda = 0$ , 左端为零, 故  $0 \leq \lambda^\top h$ , 与  $\lambda^\top h < 0$  矛盾。

注 27.6. Farkas 向量是一个有限维、可独立验证的不可行性证书。这与仅仅观察某个算法没有收敛完全不同。

“算法未收敛”不能证明不可行; 必须给出满足严格符号条件的证书, 或使用能输出此类证书的嵌入算法。

### 27.3.3 知识点十: 线性规划强对偶

定理 27.7 (标准型线性规划强对偶). 考虑最大化问题 式 (P<sub>max</sub>) 及其对偶 式 (D<sub>min</sub>)。

若原问题存在最优解  $x^*$ , 则存在对偶最优解  $y^*$ , 且

$$\boxed{c^\top x^* = b^\top y^*}. \quad (27.22)$$

证明. 记可行域  $P = \{x : Ax = b, x \geq 0\}$ . 因为  $x^*$  最大化线性函数  $c^\top x$ , 对所有可行方向  $d$  都有  $c^\top d \leq 0$ .

定义零分量指标集  $I_0 = \{i : x_i^* = 0\}$ . 在  $x^*$  处的切锥为

$$T_P(x^*) = \{d : Ad = 0, d_i \geq 0 \quad (i \in I_0)\}. \quad (27.23)$$

于是  $c^\top d \leq 0$ ,  $\forall d \in T_P(x^*)$ , 即  $c \in N_P(x^*)$ .

对多面体  $P = \{x : Ax = b, x \geq 0\}$ , 其法锥为

$$N_P(x^*) = \{A^\top y - s : y \in \mathbb{R}^m, s \geq 0, s_i x_i^* = 0\}. \quad (27.24)$$

该表示是 Farkas 引理应用于 式 (27.23) 的直接推论。

因此存在  $y^* \in \mathbb{R}^m$ ,  $s^* \geq 0$  使


$$c = A^\top y^* - s^*, \quad x_i^* s_i^* = 0. \quad (27.25)$$

于是  $A^\top y^* = c + s^* \geq c$ , 故  $y^*$  对偶可行。

又

$$\begin{aligned} b^\top y^* &= (Ax^*)^\top y^* = (x^*)^\top A^\top y^* \\ &= (x^*)^\top (c + s^*) = c^\top x^* + (x^*)^\top s^* \\ &= c^\top x^*. \end{aligned} \quad (27.26)$$

由弱对偶, 达到相同目标值的原始—对偶可行点必分别最优。 □



注 27.8 (法锥表示中的符号). 本文第 25 部分采用  $N_C(x) = \{v : \langle v, z - x \rangle \leq 0, \forall z \in C\}$ . 对非负正交锥在零分量处, 法向量方向是非正方向, 故  $N_{\mathbb{R}_+^n}(x) = \{-s : s \geq 0, s_i x_i = 0\}$ . 因此  $N_P(x) = \text{range}(A^\top) + N_{\mathbb{R}_+^n}(x) = \{A^\top y - s\}$ . 若采用相反法锥约定, 公式会整体反号。

### 27.3.4 知识点十一: 线性规划强对偶与 Slater 条件的区别

对一般凸优化问题, Slater 条件是常用的强对偶充分条件。

但对线性规划:

强对偶不要求存在严格正的原始可行点. (27.27)

例如  $\min x_1 \quad \text{s.t.} \quad x_1 = 0, \quad x_1 \geq 0$  没有  $x_1 > 0$  的严格可行点, 但原始—对偶强对偶仍成立。

原因是:

- 线性规划的可行域是多面体;
- 多面锥和多面体具有更强的闭性与分离结构;
- 可以通过 Farkas 引理证明强对偶;
- 不需要一般非线性凸问题中的严格可行性假设。

#### 易错点与反例

错误说法: “没有严格可行点, 所以线性规划可能存在对偶间隙。”

正确说法:

线性规划只要原始或对偶一侧具有有限最优解, 就满足强对偶并且另一侧最优值相同。

#### 强对偶证明: 识别信号—构造步骤—关键估计—结论—常见失败原因

识别信号:

- 题目要求证明原始与对偶最优值相等;
- 题目给出线性规划标准型;
- 已知原问题存在最优解;
- 需要构造对偶最优解而非仅给弱对偶。

构造步骤:

1. 写出原始可行域  $P$ ;
2. 从最优性得到  $c \in N_P(x^*)$ ;
3. 用多面体法锥表示  $c = A^\top y^* - s^*$ ;
4. 推出  $A^\top y^* \geq c$ ;
5. 用互补关系  $(x^*)^\top s^* = 0$  计算目标值;
6. 结合弱对偶判定二者最优。

关键估计:

$$b^\top y^* - c^\top x^* = (x^*)^\top s^* = 0.$$

结论：对偶最优解存在，且无对偶间隙。

常见失败原因：

- 只证明弱对偶；
- 未证明对偶最优解存在；
- 法锥符号写反；
- 互补关系未写；
- 错把一般 Slater 条件当作线性规划强对偶的必要条件；
- 在原问题无最优解时仍直接写目标相等。

## 27.4 正式真题 [23F-Q6]——基可行解、对偶与强对偶

完整题目叙述：[23F-Q6]

考虑线性规划

$$\begin{aligned} & \text{maximize} && \langle c, x \rangle, \\ & \text{subject to} && Ax = b, \\ & && x \geq 0, \end{aligned} \quad (27.28)$$

其中  $x \in \mathbb{R}^n$ ,  $0 \leq b \in \mathbb{R}^m$ ,  $A \in \mathbb{R}^{m \times n}$ ,  $c \in \mathbb{R}^n$ , 矩阵  $A$  满行秩, 且  $m < n$ 。

- (1) 证明基可行解与可行域的顶点等价；
- (2) 写出对偶问题，并证明：若原问题存在最优解，则对偶问题也存在最优解，且二者最优目标值相等。

第 (1) 问：基可行解蕴含顶点。设  $x$  是由基指标集  $\mathcal{B}$  生成的基可行解。记  $B = A_{\mathcal{B}}$ ,  $\mathcal{N} = \{1, \dots, n\} \setminus \mathcal{B}$ 。则  $x_{\mathcal{B}} = B^{-1}b \geq 0$ ,  $x_{\mathcal{N}} = 0$ 。

若  $x = \theta u + (1 - \theta)v$ ,  $u, v$  可行,  $0 < \theta < 1$ , 则对任意  $j \in \mathcal{N}$ :  $0 = x_j = \theta u_j + (1 - \theta)v_j$ 。由于  $u_j, v_j \geq 0$ , 必有  $u_j = v_j = 0$ 。故  $u_{\mathcal{N}} = v_{\mathcal{N}} = 0$ 。

又  $Au = Av = b$ , 所以  $Bu_{\mathcal{B}} = b$ ,  $Bv_{\mathcal{B}} = b$ 。基矩阵  $B$  非奇异, 因此  $u_{\mathcal{B}} = v_{\mathcal{B}} = B^{-1}b = x_{\mathcal{B}}$ 。故  $u = v = x$ 。因此  $x$  是顶点。□

第 (1) 问：顶点蕴含基可行解。设  $x$  是可行域的顶点。定义正支撑集  $I_+(x) = \{j : x_j > 0\}$ 。

若列集合  $\{a_j : j \in I_+(x)\}$  线性相关, 则存在非零向量  $d$  满足  $Ad = 0$ ,  $d_j = 0$  当  $j \notin I_+(x)$ 。

因为对  $j \in I_+(x)$  有  $x_j > 0$ , 可取  $0 < \varepsilon < \min_{\substack{j \in I_+(x) \\ d_j \neq 0}} \frac{x_j}{|d_j|}$ , 使  $x \pm \varepsilon d \geq 0$ 。又  $A(x \pm \varepsilon d) = b$ 。因此  $x^+ = x + \varepsilon d$ ,  $x^- = x - \varepsilon d$  是两个不同可行点, 且  $x = \frac{1}{2}x^+ + \frac{1}{2}x^-$ , 与顶点定义矛盾。

故正支撑列线性无关。

由于  $\text{rank}(A) = m$ , 可将这些列扩充为  $A$  的  $m$  个线性无关列, 得到基指标集  $\mathcal{B}$ 。

基外指标不属于正支撑集, 因此  $x_{\mathcal{N}} = 0$ 。又  $Bx_{\mathcal{B}} = b$ , 故  $x_{\mathcal{B}} = B^{-1}b \geq 0$ 。所以  $x$  是基可行解。□

第 (2) 问：对偶问题. 原问题的对偶为

$$\begin{array}{ll} \text{minimize} & b^\top y, \\ \text{subject to} & A^\top y \geq c, \\ & y \in \mathbb{R}^m \text{ 自由}. \end{array} \quad (27.29)$$

理由是：

- 原约束  $Ax = b$  为等式，因此  $y$  自由；
- 原变量  $x \geq 0$ ，因此对偶约束方向为  $A^\top y \geq c$ ；
- 对偶目标是最小化原始目标的上界  $b^\top y$ .

□

第 (2) 问：弱对偶. 任取原始可行  $x$  和对偶可行  $y$ ，有

$$\begin{aligned} c^\top x &\leq x^\top A^\top y \\ &= y^\top Ax \\ &= b^\top y. \end{aligned} \quad (27.30)$$

□

第 (2) 问：构造对偶最优解. 假设原问题存在最优解  $x^*$ 。

由 定义 27.7 的法锥构造，存在  $y^* \in \mathbb{R}^m$  和  $s^* \geq 0$  使

$$c = A^\top y^* - s^*, \quad x_i^* s_i^* = 0. \quad (27.31)$$

于是  $A^\top y^* = c + s^* \geq c$ ，所以  $y^*$  对偶可行。

并且

$$\begin{aligned} b^\top y^* &= (Ax^*)^\top y^* \\ &= (x^*)^\top (c + s^*) \\ &= c^\top x^*. \end{aligned} \quad (27.32)$$

由弱对偶，原始可行值不超过任一对偶可行值。现在  $x^*$  和  $y^*$  达到相同目标值，故：

$$x^* \text{ 原始最优}, y^* \text{ 对偶最优}, c^\top x^* = b^\top y^*. \quad (27.33)$$

□

注 27.9 (基乘子的另一构造). 若单纯形法已经找到满足最优约化成本判据的最优基  $B$ ，则可直接令


$$y^* = B^{-\top} c_B. \quad (27.34)$$

此时：

$$B^\top y^* = c_B, \quad (27.35)$$

$$a_j^\top y^* \geq c_j, \quad j \in \mathcal{N}. \quad (27.36)$$

这就是第 26 部分单纯形约化成本证明与本部分法锥证明的对应关系。



## 27.5 互补松弛与原始—对偶最优性

### 27.5.1 知识点十二：标准型的互补松弛

对最大化问题式 (P<sub>max</sub>) 和对偶式 (D<sub>min</sub>), 令  $s = A^\top y - c \geq 0$ 。若  $x, y$  分别原始、对偶可行, 则

$$b^\top y - c^\top x = x^\top s = \sum_{i=1}^n x_i s_i. \quad (27.37)$$

因为每一项均非负:  $x_i \geq 0, s_i \geq 0$ , 所以  $x^\top s = 0$  当且仅当

$$x_i s_i = 0, \quad i = 1, \dots, n. \quad (27.38)$$

定理 27.10 (线性规划互补松弛定理). 设  $x$  原始可行,  $y$  对偶可行, 并令  $s = A^\top y - c$ 。则以下命题等价:

1.  $x$  和  $y$  分别为原始、对偶最优解;
2.  $x_i s_i = 0, i = 1, \dots, n$ .

证明. 若  $x, y$  分别最优, 由强对偶:  $b^\top y - c^\top x = 0$ 。再由式 (27.37) 得到  $\sum_i x_i s_i = 0$ 。每项非负, 故逐项为零。

反之, 若逐项互补, 则  $b^\top y - c^\top x = x^\top s = 0$ 。由弱对偶, 二者分别最优。□

### 27.5.2 知识点十三：互补松弛的逻辑含义

对每个变量  $x_i$  和对应偶松弛  $s_i$ :

$$x_i > 0 \implies s_i = 0, \quad (27.39)$$

$$s_i > 0 \implies x_i = 0. \quad (27.40)$$

但反向推理一般不成立:

$$x_i = 0 \not\Rightarrow s_i > 0, \quad (27.41)$$

$$s_i = 0 \not\Rightarrow x_i > 0. \quad (27.42)$$

可能出现  $x_i = s_i = 0$ , 这与退化、多重最优解或非严格互补有关。

### 27.5.3 知识点十四：一般不等式形式的互补松弛

考虑

$$\begin{aligned} & \text{maximize} && c^\top x, \\ & \text{subject to} && Gx \leq h, \\ & && x \geq 0. \end{aligned} \quad (27.43)$$

其对偶为

$$\begin{aligned} & \text{minimize} && h^\top y, \\ & \text{subject to} && G^\top y \geq c, \\ & && y \geq 0. \end{aligned} \quad (27.44)$$





定义原始松弛和对偶松弛：

$$r = h - Gx \geq 0, \quad (27.45)$$

$$s = G^\top y - c \geq 0. \quad (27.46)$$

对偶间隙分解为

$$\begin{aligned} h^\top y - c^\top x &= y^\top (h - Gx) + x^\top (G^\top y - c) \\ &= y^\top r + x^\top s. \end{aligned} \quad (27.47)$$

因此互补松弛包括两组条件：

$$y_i r_i = 0, \quad i = 1, \dots, m, \quad (27.48)$$

$$x_j s_j = 0, \quad j = 1, \dots, n. \quad (27.49)$$

#### 易错点与反例

互补松弛不能脱离可行性使用。

仅仅满足  $x_i s_i = 0$  不够。完整最优证书必须同时验证：

1. 原始可行；
2. 对偶可行；
3. 互补松弛。

#### 27.5.4 知识点十五：严格互补

若一个原始—对偶最优对满足

$$x_i + s_i > 0, \quad i = 1, \dots, n, \quad (27.50)$$

则称其严格互补。

在线性规划中，若原始和对偶均存在最优解，则存在至少一对严格互补最优解。但并非每一对最优解都严格互补。

严格互补的作用包括：

- 更清晰地区分正变量和正对偶松弛；
- 改善活跃集识别；
- 有助于局部灵敏度和中心路径极限分析；
- 不等同于非退化；
- 不保证最优解唯一。



## 27.5.5 综合例题：用互补松弛求原始—对偶最优解

完整题目叙述：互补松弛求解

求解线性规划

$$\begin{aligned}
& \text{maximize} && 3x_1 + 2x_2, \\
& \text{subject to} && x_1 + x_2 \leq 4, \\
& && 2x_1 + x_2 \leq 5, \\
& && x_1, x_2 \geq 0.
\end{aligned} \tag{27.51}$$

写出对偶，并用互补松弛验证最优解。

证明. 原问题的对偶为

$$\begin{aligned}
& \text{minimize} && 4y_1 + 5y_2, \\
& \text{subject to} && y_1 + 2y_2 \geq 3, \\
& && y_1 + y_2 \geq 2, \\
& && y_1, y_2 \geq 0.
\end{aligned} \tag{27.52}$$

由几何分析或第 26 部分单纯形计算，原始候选解为  $x^* = (1, 3)^\top$ 。两个原始不等式均活跃：

$$x_1^* + x_2^* = 4, \tag{27.53}$$

$$2x_1^* + x_2^* = 5. \tag{27.54}$$

又因为  $x_1^* > 0$ ,  $x_2^* > 0$ , 对偶的两个列约束必须取等号：

$$y_1 + 2y_2 = 3, \tag{27.55}$$

$$y_1 + y_2 = 2. \tag{27.56}$$

解得

$$y_1^* = 1, y_2^* = 1. \tag{27.57}$$

检查对偶可行性： $y^* \geq 0$ 。原始目标值为  $3 \cdot 1 + 2 \cdot 3 = 9$ 。对偶目标值为  $4 \cdot 1 + 5 \cdot 1 = 9$ 。故

$$x^* = (1, 3)^\top, y^* = (1, 1)^\top, p^* = d^* = 9. \tag{27.58}$$

□

## 27.6 对偶变量、影子价格与灵敏度分析


## 27.6.1 知识点十六：右端扰动的影子价格

考虑最大化标准型

$$p(b) = \max \{c^\top x : Ax = b, x \geq 0\}. \tag{27.59}$$

其对偶为  $p(b) = \min \{b^\top y : A^\top y \geq c\}$  在强对偶成立时成立。设  $y^*$  是  $b$  处的一个对偶最优解。对任意扰动  $\Delta b$ ，只要扰动后问题有有限最优值， $y^*$  仍满足相同的对偶约束  $A^\top y^* \geq c$ 。因此

$$\begin{aligned}
p(b + \Delta b) &\leq (b + \Delta b)^\top y^* \\
&= p(b) + (y^*)^\top \Delta b.
\end{aligned} \tag{27.60}$$



所以  $p(b)$  作为  $b$  的函数是凹函数, 且  $y^*$  是其超梯度:

$$p(b + \Delta b) \leq p(b) + (y^*)^\top \Delta b. \quad (27.61)$$

若最优基在扰动下保持不变, 则该一阶关系变为精确仿射关系。

### 27.6.2 知识点十七: 固定最优基下的右端灵敏度

设当前最优基为  $B$ ,  $x_B = B^{-1}b$ ,  $x_N = 0$ , 并且约化成本保持最优符号。

将右端扰动为  $b + \Delta b$ 。同一基对应的基本解为

$$x_B(\Delta b) = B^{-1}(b + \Delta b) = x_B + B^{-1}\Delta b. \quad (27.62)$$

只要

$$B^{-1}(b + \Delta b) \geq 0, \quad (27.63)$$

该基仍原始可行。由于约化成本与  $b$  无关, 同一基仍最优。

目标值为

$$\begin{aligned} p(b + \Delta b) &= c_B^\top B^{-1}(b + \Delta b) \\ &= p(b) + c_B^\top B^{-1}\Delta b \\ &= p(b) + y^{*\top} \Delta b, \end{aligned} \quad (27.64)$$

其中  $y^* = B^{-\top} c_B$ 。

因此, 在基不变的区域中:

$$\frac{\partial p}{\partial b_i} = y_i^*. \quad (27.65)$$

#### 易错点与反例

“ $y_i^*$  是第  $i$  个资源永久不变的边际价值”是错误表述。

正确表述是:

$y_i^*$  只在线性规划数据的局部稳定区域、即最优基和活跃结构不变时, 给出右端小扰动的局部边际价值。

当扰动跨过基变化点时, 价值函数斜率会改变。

### 27.6.3 知识点十八: 目标系数扰动

设目标系数变为  $c + \Delta c$ 。当前基的基本解不变, 但约化成本变为

$$\begin{aligned} \bar{c}_N(\Delta c) &= c_N + \Delta c_N \\ &\quad - N^\top B^{-\top} (c_B + \Delta c_B). \end{aligned} \quad (27.66)$$

对最大化问题, 同一基保持最优的条件是

$$\bar{c}_N(\Delta c) \leq 0. \quad (27.67)$$

这给出目标系数的允许变化区间。



### 27.6.4 知识点十九：非唯一对偶解与不可微灵敏度

若对偶最优解不唯一，则价值函数  $p(b)$  在  $b$  处可能不可微。

此时所有对偶最优解组成超微分集合：

$$\partial^+ p(b) = \arg \min \{b^\top y : A^\top y \geq c\}, \quad (27.68)$$

其中  $\partial^+$  表示凹函数超微分。

不同扰动方向  $\Delta b$  可能选择不同的最优对偶乘子。

因此：

$$\boxed{\text{对偶不唯一} \implies \text{影子价格可能不是单值导数}}. \quad (27.69)$$

### 27.6.5 知识点二十：条件数与基稳定性

固定基下  $x_B = B^{-1}b$ ,  $y = B^{-\top}c_B$ 。因此：

$$\frac{\|\delta x_B\|}{\|x_B\|} \lesssim \kappa(B) \frac{\|\delta b\|}{\|b\|}, \quad (27.70)$$

$$\frac{\|\delta y\|}{\|y\|} \lesssim \kappa(B) \frac{\|\delta c_B\|}{\|c_B\|}. \quad (27.71)$$

即使线性规划整体存在稳定的最优面，某个具体基也可能高度病态。

必须区分：

- 最优值对数据的灵敏度；
- 最优解集合对数据的灵敏度；
- 某个基表示的数值条件数；
- 单纯形或内点算法的舍入稳定性。

## 27.7 一般凸问题的 Lagrange 对偶、Slater 条件与互补松弛

### 27.7.1 知识点二十一：一般 Lagrange 对偶

考虑一般约束优化问题

$$\begin{aligned} & \text{minimize} && f_0(x), \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & && h_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \quad (27.72)$$

Lagrange 函数定义为

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x), \quad (27.73)$$

其中  $\lambda \geq 0$ ,  $\nu \in \mathbb{R}^p$ 。

对偶函数定义为

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu). \quad (27.74)$$



不论原问题是否凸,  $g$  总是关于  $(\lambda, \nu)$  的凹函数, 因为它是一族仿射函数的逐点下确界。

Lagrange 对偶问题为

$$\begin{aligned} & \text{maximize} && g(\lambda, \nu), \\ & \text{subject to} && \lambda \geq 0. \end{aligned} \quad (27.75)$$

### 27.7.2 知识点二十二: 一般弱对偶

若  $x$  原始可行且  $\lambda \geq 0$ , 则

$$\begin{aligned} L(x, \lambda, \nu) &= f_0(x) + \sum_i \lambda_i f_i(x) + \sum_j \nu_j h_j(x) \\ &\leq f_0(x). \end{aligned} \quad (27.76)$$

又  $g(\lambda, \nu) \leq L(x, \lambda, \nu)$ 。故

$$\boxed{g(\lambda, \nu) \leq f_0(x)}. \quad (27.77)$$

取原始可行点上的下确界和对偶可行点上的上确界:

$$\boxed{d^* \leq p^*}. \quad (27.78)$$

### 27.7.3 知识点二十三: Slater 条件

若:

1.  $f_0, f_1, \dots, f_m$  为凸函数;
2. 等式约束为仿射约束  $Ax = b$ ;
3. 存在  $\tilde{x} \in \text{ri}(\bigcap_{i=0}^m \text{dom } f_i)$  满足

$$f_i(\tilde{x}) < 0, \quad i = 1, \dots, m, \quad A\tilde{x} = b, \quad (27.79)$$

则称 Slater 条件成立。

定理 27.11 (Slater 强对偶定理). 若凸问题 式 (27.72) 满足 Slater 条件, 且  $p^* > -\infty$ , 则:

1. 强对偶成立:  $d^* = p^*$ ;
2. 对偶最优解可达到。

#### Slater 强对偶的几何证明框架

定义扰动—目标上图集合

$$\mathcal{A} = \{(u, v, t) : \exists x, f_i(x) \leq u_i, Ax - b = v, f_0(x) \leq t\}. \quad (27.80)$$

对凸问题,  $\mathcal{A}$  为凸集。

最优点对应边界点  $(0, 0, p^*)$ 。由支撑超平面定理, 存在支撑法向量  $(\lambda, \nu, \alpha)$ 。

Slater 严格可行性排除了  $\alpha = 0$  的竖直支撑超平面, 因此可归一化为  $\alpha = 1$ 。支撑不等式给出:

- $\lambda \geq 0$ ;
- 一个对偶可行点  $(\lambda, \nu)$ ;
- 支撑截距等于  $p^*$ ;

- 从而  $g(\lambda, \nu) = p^*$ 。

#### 27.7.4 知识点二十四：一般互补松弛

若强对偶成立,  $x^*$  原始最优,  $(\lambda^*, \nu^*)$  对偶最优, 则

$$\lambda_i^* f_i(x^*) = 0, \quad i = 1, \dots, m. \quad (27.81)$$

证明链为

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, \nu^*) \\ &\leq L(x^*, \lambda^*, \nu^*) \\ &= f_0(x^*) + \sum_i \lambda_i^* f_i(x^*) \\ &\leq f_0(x^*). \end{aligned} \quad (27.82)$$

两端相等, 因此中间所有非正项之和必须为零。又  $\lambda_i^* \geq 0$ ,  $f_i(x^*) \leq 0$ , 故逐项为零。

#### 易错点与反例

Slater 条件是一般凸问题强对偶的充分条件, 不是所有凸问题强对偶的必要条件。

线性规划、某些二次规划以及部分非凸问题, 即使不满足通常形式的严格可行性, 仍可能强对偶。

#### 27.7.5 课程例题：水位填充问题

完整题目叙述: [ConvOpt-Bao-Water-Filling]

设  $\alpha_i > 0$ ,  $i = 1, \dots, n$ 。求解

$$\begin{aligned} &\text{minimize} && -\sum_{i=1}^n \log(x_i + \alpha_i), \\ &\text{subject to} && x_i \geq 0, \quad i = 1, \dots, n, \\ &&& \mathbf{1}^\top x = 1. \end{aligned} \quad (27.83)$$

证明. 将非负约束写成  $-x_i \leq 0$ 。引入乘子  $\lambda_i \geq 0$  和等式乘子  $\nu \in \mathbb{R}$ 。

Lagrange 函数为

$$L(x, \lambda, \nu) = -\sum_{i=1}^n \log(x_i + \alpha_i) - \lambda^\top x + \nu (\mathbf{1}^\top x - 1). \quad (27.84)$$


由于目标严格凸, 可行域凸且非空, 最优解唯一。

一阶驻点条件为

$$-\frac{1}{x_i + \alpha_i} - \lambda_i + \nu = 0, \quad (27.85)$$

即

$$\frac{1}{x_i + \alpha_i} + \lambda_i = \nu. \quad (27.86)$$



互补松弛为

$$\lambda_i x_i = 0. \quad (27.87)$$

若  $x_i > 0$ , 则  $\lambda_i = 0$ , 故  $x_i = \frac{1}{\nu} - \alpha_i > 0$ 。

若  $x_i = 0$ , 则  $\lambda_i = \nu - \frac{1}{\alpha_i} \geq 0$ , 即  $\nu \geq \frac{1}{\alpha_i}$ 。

所以统一写成

$$x_i^* = \left( \frac{1}{\nu^*} - \alpha_i \right)_+. \quad (27.88)$$

其中  $(z)_+ = \max\{z, 0\}$ , 而  $\nu^* > 0$  由

$$\sum_{i=1}^n \left( \frac{1}{\nu^*} - \alpha_i \right)_+ = 1 \quad (27.89)$$

唯一确定。

定义水位  $\tau = \frac{1}{\nu^*}$ , 则

$$x_i^* = (\tau - \alpha_i)_+. \quad (27.90)$$

函数  $F(\tau) = \sum_i (\tau - \alpha_i)_+$  连续、分段线性、单调递增。方程  $F(\tau) = 1$  具有唯一解。  $\square$

---

#### Algorithm 88 水位填充的排序算法

---

**Input:**  $\alpha_1, \dots, \alpha_n > 0$

**Output:** 唯一最优解  $x^*$

- 1: 将  $\alpha_i$  升序排序:  $\alpha_{(1)} \leq \dots \leq \alpha_{(n)}$
  - 2: **for**  $k = 1, \dots, n$  **do**
  - 3:     计算候选水位  $\tau_k = \frac{1 + \sum_{i=1}^k \alpha_{(i)}}{k}$
  - 4:     **if**  $\alpha_{(k)} < \tau_k$  且  $(k = n \text{ 或 } \tau_k \leq \alpha_{(k+1)})$  **then**
  - 5:         令  $\tau \leftarrow \tau_k$
  - 6:         **break**
  - 7:     **end if**
  - 8: **end for**
  - 9: 输出  $x_i^* = (\tau - \alpha_i)_+$
  - 10: **Stopping criterion:** 活跃集合满足  $\alpha_i < \tau$  且资源和为 1
  - 11: **Complexity:** 排序成本  $O(n \log n)$ ; 排序后扫描成本  $O(n)$ ; 存储为  $O(n)$ 。若用二分法求  $\tau$ , 每次函数评估为  $O(n)$
- 

## 27.8 对数障碍函数、解析中心与中心路径

### 27.8.1 知识点二十五: 障碍函数的定义与适用条件

【重要性等级】 A 级。判定依据:

- 正式考纲明确要求障碍函数、中心路径和 Newton 方程;
- 它是原始—对偶内点法的理论来源;
- 六套正式试卷中未直接完整考查算法执行, 因此不将其虚构为正式高频;
- 但它是大型线性规划、二次规划和一般凸优化的核心算法框架。



考虑凸问题

$$\begin{aligned} & \text{minimize} && f_0(x), \\ & \text{subject to} && f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & && Ax = b, \end{aligned} \quad (27.91)$$

其中:

- $f_0, f_i$  为二次连续可微凸函数;
- 等式约束仿射;
- 存在严格可行点  $f_i(x) < 0, \quad Ax = b$ ;
- 在等式可行方向上, 障碍子问题的 Hessian 足够正定, 从而 Newton 方向唯一。

定义对数障碍函数

$$\Phi(x) = -\sum_{i=1}^m \log(-f_i(x)), \quad f_i(x) < 0. \quad (27.92)$$

若存在  $i$  使  $f_i(x) \geq 0$ , 则令  $\Phi(x) = +\infty$ 。

因此障碍函数:

- 在严格可行域内部有限;
- 当接近边界  $f_i(x) \uparrow 0$  时趋于  $+\infty$ ;
- 不允许迭代点越过约束边界;
- 与允许约束违反的外罚函数不同。

### 27.8.2 知识点二十六: 梯度和 Hessian

对单项  $\phi_i(x) = -\log(-f_i(x))$ , 有

$$\nabla \phi_i(x) = \frac{\nabla f_i(x)}{-f_i(x)}. \quad (27.93)$$

Hessian 为

$$\nabla^2 \phi_i(x) = \frac{\nabla^2 f_i(x)}{-f_i(x)} + \frac{\nabla f_i(x) \nabla f_i(x)^\top}{f_i(x)^2}. \quad (27.94)$$


因此

$$\nabla \Phi(x) = \sum_{i=1}^m \frac{\nabla f_i(x)}{-f_i(x)}, \quad (27.95)$$

$$\nabla^2 \Phi(x) = \sum_{i=1}^m \left[ \frac{\nabla^2 f_i(x)}{-f_i(x)} + \frac{\nabla f_i(x) \nabla f_i(x)^\top}{f_i(x)^2} \right]. \quad (27.96)$$

若约束为仿射:  $f_i(x) = a_i^\top x - b_i$ , 则

$$\nabla^2 \Phi(x) = \sum_{i=1}^m \frac{a_i a_i^\top}{(b_i - a_i^\top x)^2}. \quad (27.97)$$





### 27.8.3 知识点二十七：障碍子问题和中心路径

给定参数  $t > 0$ ，定义障碍子问题

$$\begin{array}{ll} \text{minimize} & tf_0(x) + \Phi(x), \\ \text{subject to} & Ax = b. \end{array} \quad (27.98)$$

等价形式为

$$\min \left[ f_0(x) + \frac{1}{t} \Phi(x) \right] \quad \text{s.t.} \quad Ax = b. \quad (27.99)$$

当  $t$  增大时，障碍权重  $1/t$  减小，解逐渐靠近原约束问题的最优边界。

设障碍子问题的唯一解为  $x(t)$ 。曲线

$$\{x(t) : t > 0\} \quad (27.100)$$

称为中心路径。

### 27.8.4 知识点二十八：中心路径的近似互补关系

障碍子问题的等式约束 Lagrange 函数为

$$\mathcal{L}_t(x, \tilde{\nu}) = tf_0(x) + \Phi(x) + \tilde{\nu}^\top (Ax - b). \quad (27.101)$$

中心点满足

$$t \nabla f_0(x(t)) + \sum_{i=1}^m \frac{\nabla f_i(x(t))}{-f_i(x(t))} + A^\top \tilde{\nu}(t) = 0. \quad (27.102)$$

定义

$$\lambda_i(t) = \frac{1}{-tf_i(x(t))} > 0, \quad (27.103)$$

$$\nu(t) = \frac{\tilde{\nu}(t)}{t}. \quad (27.104)$$

将式 (27.102) 除以  $t$ :

$$\nabla f_0(x(t)) + \sum_i \lambda_i(t) \nabla f_i(x(t)) + A^\top \nu(t) = 0. \quad (27.105)$$

并有

$$-\lambda_i(t) f_i(x(t)) = \frac{1}{t}. \quad (27.106)$$


因此中心路径满足精确可行性和扰动互补关系。当  $t \rightarrow +\infty$  时， $\frac{1}{t} \rightarrow 0$ ，逐渐逼近真正的互补松弛条件。

### 27.8.5 知识点二十九：中心点的对偶间隙

在凸性和正则性条件下， $x(t)$  最小化相应 Lagrange 函数。故  $(\lambda(t), \nu(t))$  构成一个对偶可行点。

中心点的原始—对偶间隙为

$$\begin{aligned} f_0(x(t)) - g(\lambda(t), \nu(t)) &= - \sum_{i=1}^m \lambda_i(t) f_i(x(t)) \\ &= \frac{m}{t}. \end{aligned} \quad (27.107)$$



于是

$$f_0(x(t)) - p^* \leq \frac{m}{t}. \quad (27.108)$$

因此若要求目标误差不超过  $\varepsilon_{\text{opt}}$ , 可令

$$\frac{m}{t} \leq \varepsilon_{\text{opt}}. \quad (27.109)$$

#### 易错点与反例

公式  $f_0(x(t)) - p^* \leq m/t$  要求:

- $x(t)$  是精确或足够准确的中心点;
- 构造出的乘子确实对偶可行;
- 原问题为凸问题;
- 强对偶框架适用。

对一个尚未充分中心化的 Newton 迭代点, 不能机械地把  $m/t$  当作全部误差。

### 27.8.6 知识点三十: 等式约束 Newton 方程

令

$$F_t(x) = tf_0(x) + \Phi(x). \quad (27.110)$$

障碍子问题为  $\min F_t(x) \quad \text{s.t.} \quad Ax = b$ 。

在当前点  $(x, \tilde{\nu})$ , 定义残差

$$r_d = \nabla F_t(x) + A^\top \tilde{\nu}, \quad (27.111)$$

$$r_p = Ax - b. \quad (27.112)$$

Newton 方向满足

$$\begin{bmatrix} \nabla^2 F_t(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta \tilde{\nu} \end{bmatrix} = - \begin{bmatrix} r_d \\ r_p \end{bmatrix}. \quad (27.113)$$

若当前点等式可行:  $Ax = b$ , 则  $r_p = 0$  并且  $A\Delta x = 0$ 。Newton 方向位于等式约束的零空间中。

若  $Z$  的列构成  $\ker A$  的正交基, 可令  $\Delta x = Zp$ 。则约化 Newton 方程为

$$Z^\top \nabla^2 F_t(x) Zp = -Z^\top \nabla F_t(x). \quad (27.114)$$

### 27.8.7 知识点三十一: 保持严格可行的线搜索

设当前点满足  $f_i(x) < 0$ 。先计算最大可行步长

$$\alpha_{\max} = \sup \{ \alpha > 0 : f_i(x + \alpha \Delta x) < 0, \forall i \}. \quad (27.115)$$

对仿射约束  $a_i^\top x < b_i$ , 若  $a_i^\top \Delta x > 0$ , 则  $\alpha < \frac{b_i - a_i^\top x}{a_i^\top \Delta x}$ 。因此

$$\alpha_{\max} = \min_{a_i^\top \Delta x > 0} \frac{b_i - a_i^\top x}{a_i^\top \Delta x}. \quad (27.116)$$

实际取

$$\alpha = \min \{1, \eta \alpha_{\max}\}, \quad 0 < \eta < 1, \quad (27.117)$$

再通过回溯保证充分下降。



### 27.8.8 知识点三十二: Newton 减量

对无等式约束问题, Newton 减量定义为

$$\delta_N(x)^2 = \nabla F_t(x)^\top [\nabla^2 F_t(x)]^{-1} \nabla F_t(x). \quad (27.118)$$

等价地, 若  $\Delta x = -[\nabla^2 F_t(x)]^{-1} \nabla F_t(x)$ , 则  $\delta_N(x)^2 = \Delta x^\top \nabla^2 F_t(x) \Delta x$ 。

在自协调障碍理论中, 常用

$$\frac{1}{2} \delta_N(x)^2 \leq \varepsilon_{\text{cent}} \quad (27.119)$$

作为中心化子问题的停止准则。

### 27.8.9 课程基础例题: 标准单纯形的解析中心

完整题目叙述: 解析中心

求集合  $\{x \in \mathbb{R}^n : x_i > 0, \mathbf{1}^\top x = 1\}$  的对数障碍解析中心, 即求解

$$\min \left[ -\sum_{i=1}^n \log x_i \right] \quad \text{s.t.} \quad \mathbf{1}^\top x = 1. \quad (27.120)$$

证明. Lagrange 函数为  $L(x, \nu) = -\sum_i \log x_i + \nu (\sum_i x_i - 1)$ 。驻点条件为  $-\frac{1}{x_i} + \nu = 0$ , 故  $x_i = \frac{1}{\nu}$ 。代入  $\sum_i x_i = 1$  得到  $\frac{n}{\nu} = 1$ ,  $\nu = n$ 。因此

$$x_i^* = \frac{1}{n}, \quad i = 1, \dots, n. \quad (27.121)$$

Hessian 为  $\text{diag}(x_1^{-2}, \dots, x_n^{-2}) \succ 0$ , 所以该点为唯一全局最优解。□

### 27.8.10 障碍法算法

**Algorithm 89** 可行起点对数障碍法

**Input:** 凸问题  $\min f_0(x) \quad \text{s.t.} \quad f_i(x) \leq 0, Ax = b$ ; 严格可行初值  $x^{(0)}$ ; 初始  $t_0 > 0$ ; 增长因子  $\mu_t > 1$ ; 目标容差  $\varepsilon_{\text{opt}}$

**Output:** 近似最优解  $x$

1: **Initialization:** 令  $x \leftarrow x^{(0)}, t \leftarrow t_0$

2: **loop**

3: 用等式约束 Newton 法近似求解  $\min_x [tf_0(x) - \sum_{i=1}^m \log(-f_i(x))], \quad Ax = b$

4: 每个 Newton 步保持  $f_i(x) < 0$  并执行回溯线搜索

5: 当 Newton 减量满足中心化容差时停止内层迭代

6: **if**  $\frac{m}{t} \leq \varepsilon_{\text{opt}}$  **then**

7: 输出  $x$

8: **stop**

9: **end if**

10: 更新  $t \leftarrow \mu_t t$

11: **end loop**

12: **Stopping criterion:** 外层使用  $m/t$  估计中心路径对偶间隙; 内层使用 Newton 减量或 KKT 残差



13: **Complexity:** 外层次数为  $O\left(\frac{\log(m/(t_0\varepsilon_{\text{opt}}))}{\log \mu_t}\right)$ 。对自协调障碍的短步路径跟踪, 总 Newton 步数可达  $O\left(\sqrt{m} \log \frac{m}{\varepsilon_{\text{opt}}}\right)$ 。每个 Newton 步成本由 KKT 线性系统求解决定

### 易错点与反例

障碍法与罚函数法不能混为一谈。

| 比较项   | 障碍法                              | 外罚函数法               |
|-------|----------------------------------|---------------------|
| 迭代点位置 | 保持严格可行域内部                        | 通常允许不可行点            |
| 参数极限  | 障碍权重趋零, 或 $t \rightarrow \infty$ | 罚参数趋于 $+\infty$     |
| 边界行为  | 接近边界时目标趋于 $+\infty$              | 违反约束时增加惩罚           |
| 初值要求  | 通常需要严格可行起点                       | 通常不要求可行起点           |
| 主要病态性 | 接近边界时障碍 Hessian 尺度极端             | 罚参数大时 Hessian 条件数恶化 |

## 27.9 线性规划的原始障碍中心路径

### 27.9.1 知识点三十三: 原始对数障碍

对非负约束  $x \geq 0$ , 对数障碍为

$$\Phi(x) = -\sum_{i=1}^n \log x_i, \quad x > 0. \quad (27.122)$$

参数为  $t > 0$  的障碍子问题为

$$\begin{array}{ll} \text{minimize} & tc^\top x - \sum_{i=1}^n \log x_i, \\ \text{subject to} & Ax = b, \\ & x > 0. \end{array} \quad (27.123)$$

Lagrange 函数为

$$\mathcal{L}_t(x, \nu) = tc^\top x - \sum_i \log x_i + \nu^\top (Ax - b). \quad (27.124)$$

驻点条件:

$$tc - X^{-1}\mathbf{1} + A^\top \nu = 0, \quad (27.125)$$

其中  $X = \text{diag}(x_1, \dots, x_n)$ 。


令

$$y = -\frac{\nu}{t}, \quad (27.126)$$

$$s = \frac{1}{t} X^{-1}\mathbf{1}. \quad (27.127)$$

则  $s > 0$  且

$$A^\top y + s = c. \quad (27.128)$$



同时

$$Xs = \frac{1}{t}\mathbf{1}. \quad (27.129)$$

令  $\mu = \frac{1}{t}$ , 中心路径方程为

$$\begin{aligned} Ax &= b, \\ A^\top y + s &= c, \\ Xs &= \mu\mathbf{1}, \\ x &> 0, \quad s > 0. \end{aligned} \quad (27.130)$$

### 27.9.2 知识点三十四：中心路径间隙

由  $x_i s_i = \mu$  可得

$$x^\top s = n\mu. \quad (27.131)$$

又因中心路径点原始、对偶可行：

$$c^\top x(\mu) - b^\top y(\mu) = n\mu. \quad (27.132)$$

因此  $\mu$  是平均互补间隙：

$$\mu = \frac{x^\top s}{n}. \quad (27.133)$$

当  $\mu \downarrow 0$  时，中心路径逼近原始—对偶最优集合。

### 27.9.3 综合例题：二维线性规划的精确中心路径

完整题目叙述：精确中心路径

考虑

$$\begin{aligned} \text{minimize} \quad & x_1 + 2x_2, \\ \text{subject to} \quad & x_1 + x_2 = 1, \\ & x_1, x_2 \geq 0. \end{aligned} \quad (27.134)$$

求其原始—对偶中心路径，并计算  $\mu \rightarrow 0^+$  时的极限。

证明. 原问题矩阵为  $A = \begin{pmatrix} 1 & 1 \end{pmatrix}$ ,  $b = 1$ ,  $c = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ 。

对偶问题为

$$\begin{aligned} \text{maximize} \quad & y, \\ \text{subject to} \quad & y + s_1 = 1, \\ & y + s_2 = 2, \\ & s_1, s_2 \geq 0. \end{aligned} \quad (27.135)$$



中心路径方程为

$$x_1 + x_2 = 1, \quad (27.136)$$

$$y + s_1 = 1, \quad (27.137)$$

$$y + s_2 = 2, \quad (27.138)$$

$$x_1 s_1 = \mu, \quad (27.139)$$

$$x_2 s_2 = \mu. \quad (27.140)$$

由式 (27.137) and (27.138):

$$s_2 = s_1 + 1, \quad y = 1 - s_1. \quad (27.141)$$

又  $x_1 = \frac{\mu}{s_1}$ ,  $x_2 = \frac{\mu}{s_1+1}$ 。代入  $x_1 + x_2 = 1$  得到

$$\mu \left( \frac{1}{s_1} + \frac{1}{s_1 + 1} \right) = 1. \quad (27.142)$$

化简:  $s_1^2 + (1 - 2\mu)s_1 - \mu = 0$ 。取正根:

$$s_1(\mu) = \frac{2\mu - 1 + \sqrt{1 + 4\mu^2}}{2}. \quad (27.143)$$

于是

$$s_2(\mu) = 1 + s_1(\mu), \quad (27.144)$$

$$x_1(\mu) = \frac{\mu}{s_1(\mu)}, \quad (27.145)$$

$$x_2(\mu) = \frac{\mu}{1 + s_1(\mu)}, \quad (27.146)$$

$$y(\mu) = 1 - s_1(\mu). \quad (27.147)$$

当  $\mu \rightarrow 0^+$  时,  $\sqrt{1 + 4\mu^2} = 1 + 2\mu^2 + O(\mu^4)$ , 所以

$$s_1(\mu) = \mu + \mu^2 + O(\mu^4), \quad (27.148)$$

$$s_2(\mu) = 1 + \mu + O(\mu^2), \quad (27.149)$$

$$x_1(\mu) = 1 - \mu + O(\mu^2), \quad (27.150)$$

$$x_2(\mu) = \mu + O(\mu^2), \quad (27.151)$$


$$y(\mu) = 1 - \mu + O(\mu^2). \quad (27.152)$$

因此

$$x(\mu) \rightarrow \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad y(\mu) \rightarrow 1, \quad s(\mu) \rightarrow \begin{pmatrix} 0 \\ 1 \end{pmatrix}. \quad (27.153)$$

原始最优值为 1, 对偶最优值也为 1。

沿中心路径:  $x^\top s = x_1 s_1 + x_2 s_2 = 2\mu$ 。这与变量数  $n = 2$  的公式  $x^\top s = n\mu$  一致。  $\square$



## 27.10 原始—对偶内点法的扰动 KKT 系统

### 27.10.1 知识点三十五：精确 KKT 系统

对式 (P) and (D)，原始—对偶最优条件为

$$\begin{aligned} Ax - b &= 0, \\ A^\top y + s - c &= 0, \\ Xs &= 0, \\ x \geq 0, s &\geq 0. \end{aligned} \tag{27.154}$$

其中：

- 第一式是原始可行性；
- 第二式是对偶可行性；
- 第三式是逐分量互补松弛；
- 非负性保证弱对偶间隙非负。

直接对  $Xs = 0$  作 Newton 迭代会遇到边界奇异。内点法改为扰动互补：

$$Xs = \sigma\mu\mathbf{1}, \tag{27.155}$$

其中  $\mu = \frac{x^\top s}{n}$ ,  $0 \leq \sigma \leq 1$ 。

### 27.10.2 知识点三十六：三类残差

定义

$$r_p = Ax - b, \tag{27.156}$$

$$r_d = A^\top y + s - c, \tag{27.157}$$

$$r_c = Xs - \sigma\mu\mathbf{1}. \tag{27.158}$$

目标是求方向  $(\Delta x, \Delta y, \Delta s)$  使线性化后的残差消失。

### 27.10.3 知识点三十七：Newton 方程

对原始可行方程线性化：

$$A\Delta x = -r_p. \tag{27.159}$$

对对偶可行方程线性化：

$$A^\top \Delta y + \Delta s = -r_d. \tag{27.160}$$

对互补关系  $(X + \Delta X)(s + \Delta s) \approx Xs + S\Delta x + X\Delta s$  线性化：

$$S\Delta x + X\Delta s = -r_c, \tag{27.161}$$

其中  $S = \text{diag}(s_1, \dots, s_n)$ 。



合并为

$$\begin{bmatrix} 0 & A^\top & I \\ A & 0 & 0 \\ S & 0 & X \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta s \end{bmatrix} = - \begin{bmatrix} r_d \\ r_p \\ r_c \end{bmatrix}. \quad (27.162)$$

注 27.12. 矩阵 式 (27.162) 不是对称矩阵。通过消元可化成对称正定正规方程，或对称不定增广系统。数值实现不能无条件选用同一种分解。

#### 27.10.4 知识点三十八：消元到正规方程

由 式 (27.160):

$$\Delta s = -r_d - A^\top \Delta y. \quad (27.163)$$

代入互补方程:

$$S\Delta x + X(-r_d - A^\top \Delta y) = -r_c. \quad (27.164)$$

故

$$\Delta x = S^{-1}(-r_c + Xr_d + XA^\top \Delta y). \quad (27.165)$$

代入  $A\Delta x = -r_p$  得到

$$AS^{-1}XA^\top \Delta y = -r_p + AS^{-1}r_c - AS^{-1}Xr_d. \quad (27.166)$$

令

$$D^2 = XS^{-1} = \text{diag}\left(\frac{x_1}{s_1}, \dots, \frac{x_n}{s_n}\right), \quad (27.167)$$

则正规方程矩阵为

$$M = AD^2A^\top. \quad (27.168)$$

若  $\text{rank}(A) = m$  且  $x > 0$ ,  $s > 0$ , 则  $D^2 \succ 0$  并且  $AD^2A^\top \succ 0$ 。因此可用 Cholesky 分解。

求出  $\Delta y$  后, 按 式 (27.163) and (27.165) 恢复  $\Delta s, \Delta x$ 。

#### 27.10.5 知识点三十九：对称不定增广系统

由互补方程可写

$$\Delta s = -X^{-1}(r_c + S\Delta x). \quad (27.169)$$

代入对偶方程:

$$A^\top \Delta y - X^{-1}S\Delta x = -r_d + X^{-1}r_c. \quad (27.170)$$

因此

$$\begin{bmatrix} -X^{-1}S & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \end{bmatrix} = \begin{bmatrix} -r_d + X^{-1}r_c \\ -r_p \end{bmatrix}. \quad (27.171)$$

该系统对称但不定, 通常需要:

- 对称不定  $LDL^\top$  分解;
- 稳定主元策略;





- 适当正则化;
- 稀疏重排序;
- 迭代改进。

### 27.10.6 知识点四十：边界步长

为保持  $x + \alpha_p \Delta x > 0$ , 定义原始最大步长

$$\alpha_p^{\max} = \min \left\{ 1, \min_{\Delta x_i < 0} \left( -\frac{x_i}{\Delta x_i} \right) \right\}. \quad (27.172)$$

类似地,

$$\alpha_d^{\max} = \min \left\{ 1, \min_{\Delta s_i < 0} \left( -\frac{s_i}{\Delta s_i} \right) \right\}. \quad (27.173)$$

取边界缩减因子  $0 < \eta < 1$ , 例如  $\eta = 0.99$  或随迭代变化的更接近 1 的数, 并令

$$\alpha_p = \min \{1, \eta \alpha_p^{\max}\}, \quad (27.174)$$

$$\alpha_d = \min \{1, \eta \alpha_d^{\max}\}. \quad (27.175)$$

更新:

$$x^+ = x + \alpha_p \Delta x, \quad (27.176)$$

$$y^+ = y + \alpha_d \Delta y, \quad (27.177)$$

$$s^+ = s + \alpha_d \Delta s. \quad (27.178)$$

也可使用共同步长  $\alpha = \min\{\alpha_p, \alpha_d\}$ 。

#### 易错点与反例

若直接取  $\alpha = 1$  而不检查边界, 可能得到  $x_i \leq 0$  或  $s_i \leq 0$ , 使:

- 对数障碍失去定义;
- $X^{-1}$  或  $S^{-1}$  不存在;
- 中心路径 Newton 系统失效。

### 27.10.7 知识点四十一：中心化参数

参数  $\sigma \in [0, 1]$  控制两种目标的权衡:

- $\sigma$  较小: 更积极地减小对偶间隙;
- $\sigma$  较大: 更强地将点拉回中心路径附近;
- $\sigma = 0$ : 仿射缩放方向;
- $\sigma = 1$ : 主要中心化, 不主动减小当前平均间隙。

短步理论通常选取使迭代始终保持在中心邻域内的  $\sigma$ 。

实际算法中常用预测—校正策略自适应选择  $\sigma$ 。



## 27.10.8 知识点四十二: Mehrotra 预测—校正思想

先令  $\sigma = 0$  求仿射方向  $(\Delta x^{\text{aff}}, \Delta y^{\text{aff}}, \Delta s^{\text{aff}})$ 。计算仿射最大步长  $\alpha_p^{\text{aff}}, \alpha_d^{\text{aff}}$ 。

预测仿射间隙:

$$\mu_{\text{aff}} = \frac{(x + \alpha_p^{\text{aff}} \Delta x^{\text{aff}})^\top (s + \alpha_d^{\text{aff}} \Delta s^{\text{aff}})}{n}. \quad (27.179)$$

常用启发式中心化参数:

$$\sigma = \left( \frac{\mu_{\text{aff}}}{\mu} \right)^3. \quad (27.180)$$

由于真正互补关系含二阶项  $\Delta X \Delta s$ , 校正方向常使用右端

$$\sigma \mu \mathbf{1} - Xs - \Delta X^{\text{aff}} \Delta s^{\text{aff}}. \quad (27.181)$$

这里  $\Delta X^{\text{aff}} \Delta s^{\text{aff}}$  表示逐分量乘积向量:  $[\Delta x_i^{\text{aff}} \Delta s_i^{\text{aff}}]_{i=1}^n$ 。

注 27.13. Mehrotra 预测—校正法是实际中极其有效的启发式算法, 但其常用参数选择不应与最简短步多项式复杂度证明混为一谈。

理论复杂度通常针对明确中心邻域和步长规则的路径跟踪法。

## 27.10.9 原始—对偶内点算法

**Algorithm 90** 不可行起点原始—对偶路径跟踪法

**Input:** 线性规划  $\min c^\top x$  s.t.  $Ax = b, x \geq 0$ ; 初值  $x^{(0)} > 0, s^{(0)} > 0, y^{(0)} \in \mathbb{R}^m$ ; 容差  $\tau_p, \tau_d, \tau_g > 0$ ; 边界参数  $0 < \eta < 1$

**Output:** 近似原始—对偶最优解, 或交由自对偶嵌入判定不可行、无界

1: **Initialization:** 令  $k \leftarrow 0$

2: **loop**

3: 计算残差  $r_p = Ax - b, r_d = A^\top y + s - c$

4: 计算平均互补间隙  $\mu = \frac{x^\top s}{n}$

5: 计算归一化停止指标  $\eta_p = \frac{\|r_p\|_2}{1 + \|b\|_2}, \eta_d = \frac{\|r_d\|_2}{1 + \|c\|_2}$

6: 计算相对间隙指标  $\eta_g = \frac{x^\top s}{1 + |c^\top x| + |b^\top y|}$

7: **if**  $\eta_p \leq \tau_p, \eta_d \leq \tau_d, \eta_g \leq \tau_g$  **then**

8: 输出  $(x, y, s)$

9: **stop**

10: **end if**

11: 选择中心化参数  $\sigma \in [0, 1]$

12: 令  $r_c = Xs - \sigma \mu \mathbf{1}$

13: 解 Newton 系统  $\begin{bmatrix} 0 & A^\top & I \\ A & 0 & 0 \\ S & 0 & X \end{bmatrix} \begin{bmatrix} \Delta x \\ \Delta y \\ \Delta s \end{bmatrix} = - \begin{bmatrix} r_d \\ r_p \\ r_c \end{bmatrix}$

14: 计算  $\alpha_p^{\max} = \min \left\{ 1, \min_{\Delta x_i < 0} -\frac{x_i}{\Delta x_i} \right\}$

15: 计算  $\alpha_d^{\max} = \min \left\{ 1, \min_{\Delta s_i < 0} -\frac{s_i}{\Delta s_i} \right\}$

16: 取  $\alpha_p = \min\{1, \eta \alpha_p^{\max}\}, \alpha_d = \min\{1, \eta \alpha_d^{\max}\}$

17: 更新  $x \leftarrow x + \alpha_p \Delta x$

18: 更新  $y \leftarrow y + \alpha_d \Delta y, s \leftarrow s + \alpha_d \Delta s$



19:  $k \leftarrow k + 1$

20: **end loop**

21: **Stopping criterion:** 同时检查原始残差、对偶残差和相对互补间隙；不能只检查  $x^\top s$

22: **Complexity:** 若形成正规方程： $M = AD^2A^\top$ ，稠密形成成本为  $O(m^2n)$ ，Cholesky 分解为  $O(m^3)$ ，恢复方向为  $O(mn)$ ；存储为  $O(mn + m^2)$ 。

对  $n$  个非负变量的自协调障碍，短步路径跟踪的 Newton 步数典型为  $O(\sqrt{n} \log \frac{1}{\varepsilon})$ 。稀疏问题成本取决于填充和重排序

### 27.10.10 知识点四十三：非可行迭代点上的间隙

若当前点不满足  $Ax = b$  或  $A^\top y + s = c$ ，则  $x^\top s$  不再等于精确目标差。

由  $r_p = Ax - b$ ,  $r_d = A^\top y + s - c$  可得

$$c^\top x - b^\top y = x^\top s + y^\top r_p - x^\top r_d. \quad (27.182)$$

因此：

$$\boxed{x^\top s \text{ 在不可行起点算法中只是代理互补间隙}}. \quad (27.183)$$

停止时必须同时控制  $r_p$ ,  $r_d$ ,  $x^\top s$ 。

## 27.11 内点法的收敛性、复杂度与数值稳定性

### 27.11.1 知识点四十四：收敛性含义

原始—对偶内点法的“收敛”需要分层描述。

固定  $\mu$  的中心方程。对固定  $\mu > 0$ ，Newton 法用于解  $F_\mu(x, y, s) = 0$ 。若 Jacobian 非奇异、初值足够接近且二阶导数 Lipschitz，可有局部二次收敛。

路径跟踪外层。算法同时令  $\mu_k \downarrow 0$ 。整体算法的评价通常是：

- 对偶间隙下降；
- 中心邻域保持；
- Newton 步数的多项式上界；
- 而不是固定的  $q$ -线性或  $q$ -二次收敛阶。

短步复杂度。对具有障碍参数  $\nu_b$  的自协调障碍，短步路径跟踪通常需要

$$O\left(\sqrt{\nu_b} \log \frac{\nu_b}{\varepsilon}\right) \quad (27.184)$$

个 Newton 步。

对  $n$  个非负变量的线性规划对数障碍， $\nu_b = n$ 。故

$$\boxed{O\left(\sqrt{n} \log \frac{n}{\varepsilon}\right)}. \quad (27.185)$$



易错点与反例

不得写：

“内点法每次迭代二次收敛，因此总复杂度是对数级。”

固定参数中心方程的局部 Newton 收敛，与参数不断变化的全局路径跟踪复杂度，是不同层次的结论。

27.11.2 知识点四十五：正规方程的条件数平方

正规方程矩阵为  $M = AD^2A^\top = (AD)(AD)^\top$ 。若  $AD$  满行秩，则

$$\kappa_2(M) = \kappa_2(AD)^2. \quad (27.186)$$

因此形成正规方程可能平方有效条件数。

临近最优解时，互补关系导致：

- 若  $x_i^* > 0$ ，则  $s_i \rightarrow 0$ ， $\frac{x_i}{s_i} \rightarrow +\infty$ ；
- 若  $s_i^* > 0$ ，则  $x_i \rightarrow 0$ ， $\frac{x_i}{s_i} \rightarrow 0$ 。

因此  $D$  的对角尺度可能跨越许多数量级，使  $AD^2A^\top$  严重病态。

27.11.3 知识点四十六：正规方程与增广系统的比较

| 比较项  | 正规方程            | 增广系统                                                       |
|------|-----------------|------------------------------------------------------------|
| 矩阵   | $AD^2A^\top$    | $\begin{bmatrix} -X^{-1}S & A^\top \\ A & 0 \end{bmatrix}$ |
| 结构   | 对称正定            | 对称不定                                                       |
| 直接分解 | Cholesky        | 带主元 $LDL^\top$                                             |
| 维数   | $m \times m$    | $(n+m) \times (n+m)$                                       |
| 条件性  | 可能平方条件数         | 通常避免显式平方，但不定分解更复杂                                          |
| 稀疏性  | 可能产生较大填充        | 规模更大，但某些结构下更稳定                                             |
| 适用情形 | $m \ll n$ 、条件尚可 | 正规方程过病态或结构有利                                               |

27.11.4 知识点四十七：数值稳定措施

实际实现常使用：

1. 行列缩放；
2. 对称平衡；
3. 稀疏重排序；
4. 对角正则化；



5. 迭代改进;
6. 残差重计算;
7. 混合精度校正;
8. 避免显式形成  $X^{-1}$ 、 $S^{-1}$ ;
9. 使用逐分量缩放求解;
10. 对近线性相关约束删除冗余行。

例如正规方程可正则化为

$$(AD^2A^\top + \delta I) \Delta y = r, \delta > 0. \quad (27.187)$$

但正则化会扰动 Newton 方程, 因此必须:

- 控制  $\delta$ ;
- 重新计算真实 KKT 残差;
- 必要时作迭代改进;
- 不能只检查正则化系统残差。

#### 27.11.5 知识点四十八: 严格可行性与中心路径存在

原始中心路径要求存在  $x > 0$ ,  $Ax = b$ 。完整原始—对偶中心路径通常要求同时存在

$$x > 0, \quad Ax = b, \quad (27.188)$$

$$s > 0, \quad A^\top y + s = c. \quad (27.189)$$

若最优可行域位于非负正交锥的低维面上, 可能不存在严格正的原始可行点。

此时:

- 强对偶仍可能成立;
- 原始对数障碍在原变量空间中可能没有中心路径;
- 可进行面约化;
- 或使用齐次自对偶嵌入;
- 不能把“中心路径不存在”误判为“原问题无解”。

#### 27.11.6 知识点四十九: 齐次自对偶嵌入的作用

完整工程算法通常把原始和对偶问题嵌入一个齐次自对偶系统, 以统一输出:

1. 原始—对偶最优解;
2. 原问题不可行证书;
3. 对偶不可行或原问题无界证书。



本部分不展开其全部增广变量公式，但需要掌握结论：

普通不可行起点内点迭代的失败，本身不是不可行性证明。

(27.190)

需要显式证书或齐次自对偶嵌入的终止量。

27.11.7 知识点五十：停止准则

推荐同时使用：

原始残差。

$$\eta_p = \frac{\|Ax - b\|_2}{1 + \|b\|_2}.$$

(27.191)

对偶残差。

$$\eta_d = \frac{\|A^\top y + s - c\|_2}{1 + \|c\|_2}.$$

(27.192)

相对间隙。

$$\eta_g = \frac{x^\top s}{1 + |c^\top x| + |b^\top y|}.$$

(27.193)

停止条件：

$$\eta_p \leq \tau_p, \eta_d \leq \tau_d, \eta_g \leq \tau_g.$$

(27.194)

易错点与反例

以下任一单独条件都不足以证明数值最优：

$x^\top s$  小， $\|Ax - b\|$  小， $\|A^\top y + s - c\|$  小。

必须同时控制原始可行性、对偶可行性和互补间隙。

27.12 对偶理论与内点法的易错点、反例和完整答题规范

| 错误说法或错误做法                | 正确处理                          |
|--------------------------|-------------------------------|
| 原问题是最大化，所以对偶也是最大化。       | 标准配对通常为最大化—最小化或最小化—最大化。       |
| 等式约束的对偶变量必须非负。           | 等式约束对应自由对偶变量。                 |
| 原变量非负对应偶约束等号。            | 原变量非负对应单侧不等式；自由变量才对应等号。       |
| 弱对偶说明原始和对偶最优值相等。         | 弱对偶只给出一侧界；相等需要强对偶或零间隙证书。      |
| 只要原问题可行，对偶必可行。           | 原问题可行但目标无界时，对偶可能不可行。          |
| 只要对偶不可行，原问题一定无界。         | 还需排除原问题不可行；一般应结合定理择一或齐次自对偶证书。 |
| 互补松弛本身足以证明最优。            | 还必须同时验证原始和对偶可行性。              |
| $x_i = 0$ 推出 $s_i > 0$ 。 | 只知 $x_i s_i = 0$ ；可能二者同时为零。   |
| 严格互补与非退化完全等价。            | 二者相关但不是同一概念。                  |


| 错误说法或错误做法                  | 正确处理                                             |
|----------------------------|--------------------------------------------------|
| 对偶乘子是全局固定的影子价格。            | 只在最优结构不变的局部扰动范围内具有边际解释。                          |
| 对偶解不唯一时仍有唯一灵敏度导数。          | 价值函数可能不可微，对偶最优集给出超微分或次微分。                        |
| LP 没有严格可行点就可能有对偶间隙。        | 线性规划强对偶不要求通常形式的严格可行性。                            |
| Slater 条件是强对偶的必要条件。        | Slater 通常是凸问题强对偶的充分条件，不是必要条件。                    |
| 障碍函数允许迭代点违反约束。             | 对数障碍在约束外为 $+\infty$ ，要求严格内部点。                    |
| 罚函数和障碍函数只是参数符号不同。          | 罚函数允许违反约束；障碍函数保持内部可行。                            |
| 障碍参数 $t$ 越小越接近原问题。         | 在 $tf_0 + \Phi$ 约定下，应令 $t \rightarrow +\infty$ 。 |
| 中心路径满足精确互补 $x_i s_i = 0$ 。 | 中心路径满足 $x_i s_i = \mu > 0$ 。                     |
| $\mu = x^\top s$ 。         | 标准定义为 $\mu = x^\top s/n$ 。                       |
| 不可行起点上 $x^\top s$ 就是目标间隙。  | 还存在原始、对偶残差修正项。                                   |
| 原始—对偶 Newton 矩阵总是正定。       | 完整 KKT 矩阵通常不定；正规方程在适当秩条件下正定。                     |
| 形成正规方程总能改善稳定性。             | 正规方程可能平方条件数。                                     |
| Cholesky 分解可用于任意增广 KKT 矩阵。 | Cholesky 要求正定；对称不定系统通常用带主元 $LDL^\top$ 。          |
| Newton 方向求出后总可取步长 1。       | 必须进行边界步长和必要的回溯控制。                                |
| 内点法的每个变量都会趋于正的最优值。         | 互补性意味着每对 $(x_i, s_i)$ 至少一个趋零。                    |
| 原始中心路径不存在说明 LP 不可行。        | 可行域可能位于低维面上；需面约化或其他嵌入。                           |
| 内点算法未收敛就是不可行证书。            | 必须输出 Farkas 证书或齐次自对偶证书。                          |
| 内点法具有统一的二次全局收敛阶。           | 固定中心方程的局部 Newton 步骤可二次；路径跟踪整体通常用复杂度界描述。          |
| 单纯形法和内点法输出完全相同的最优点。        | 若最优解不唯一，单纯形常到顶点，中心路径通常趋向最优面的中心型点。                |

反例 27.14 (互补关系没有可行性时不能证明最优). 取  $x = 0, s = 0$ 。显然  $x_i s_i = 0$ 。但对任意非零  $b$  和一般  $A, c$ ，该点通常既不满足  $Ax = b$  也不满足  $A^\top y + s = c$ 。所以互补关系本身没有最优性意义。

反例 27.15 (强对偶不等于最优解唯一). 考虑

$$\begin{aligned}
 &\text{maximize} && x_1 + x_2, \\
 &\text{subject to} && x_1 + x_2 \leq 1, \\
 &&& x_1, x_2 \geq 0.
 \end{aligned} \tag{27.195}$$

所有满足  $x_1 + x_2 = 1, x \geq 0$  的点都最优。





原始和对偶仍满足强对偶，但原始最优解不唯一。

反例 27.16 (中心路径不存在但 LP 可行). 考虑  $\min x_1$  s.t.  $x_1 = 0, x_1 \geq 0$ . 原问题可行且最优值为 0, 但不存在满足  $x_1 > 0, x_1 = 0$  的严格原始可行点。

因此原始对数障碍  $-\log x_1$  不能在等式可行域上定义，但这不影响线性规划强对偶。

#### 互补松弛：识别信号—构造步骤—关键估计—结论—常见失败原因

识别信号：

- 已知原始或对偶候选解；
- 题目要求从活跃约束求乘子；
- 需要验证一个解是否最优；
- 变量为零与约束是否活跃需要对应。

构造步骤：

1. 写原始可行性；
2. 写对偶可行性；
3. 引入所有原始和对偶松弛；
4. 写逐分量乘积为零；
5. 根据正变量推出对应约束取等号；
6. 解剩余线性方程；
7. 检查目标值相等。

关键估计：

$\text{gap} = \sum_i \text{非负乘积}$ 。

结论：可行性加互补松弛等价于原始—对偶最优。

常见失败原因：

- 漏写某一组松弛；
- 将单向蕴含写成双向；
- 未检查乘子非负；
- 未验证原始或对偶可行性。

#### 障碍法：识别信号—构造步骤—关键估计—结论—常见失败原因

识别信号：

- 约束为  $f_i(x) \leq 0$ ；
- 需要保持严格内部可行；
- 题目出现中心路径、解析中心或  $m/t$  间隙；
- 需要用 Newton 法求一系列无约束或等式约束子问题。

构造步骤：



1. 写  $\Phi(x) = -\sum_i \log(-f_i(x))$ ;
2. 构造  $tf_0 + \Phi$ ;
3. 求梯度和 Hessian;
4. 写等式约束 Newton 系统;
5. 保持严格可行步长;
6. 内层中心化;
7. 增大  $t$ ;
8. 用  $m/t$  控制外层间隙。

关键估计:

$$-\lambda_i f_i(x) = 1/t, \quad f_0(x(t)) - p^* \leq m/t.$$

结论: 障碍中心点随  $t \rightarrow \infty$  逼近约束最优解。

常见失败原因:

- 无严格可行起点;
- 梯度或 Hessian 符号错误;
- 步长越界;
- 内层未中心化就快速增大  $t$ ;
- 参数过大导致条件数恶化。

原始—对偶内点法: 识别信号—构造步骤—关键估计—结论—常见失败原因

识别信号:

- 标准型 LP 同时给出原始和对偶;
- 题目要求扰动 KKT、中心路径或 Newton 方向;
- 需要说明原始残差、对偶残差和互补间隙;
- 需要处理大型稀疏问题。

构造步骤:

1. 写原始—对偶 KKT 系统;
2. 将  $Xs = 0$  扰动为  $Xs = \sigma\mu\mathbf{1}$ ;
3. 定义  $r_p, r_d, r_c$ ;
4. 线性化得到三块 Newton 方程;
5. 消元成正规方程或增广系统;
6. 求  $\Delta y, \Delta s, \Delta x$ ;
7. 计算原始和对偶边界步长;
8. 更新并重新计算残差;

## 9. 同时检查三类停止指标。

关键估计：

$$\mu = \frac{x^\top s}{n}, \quad x^\top s \downarrow 0.$$

短步理论： $O(\sqrt{n} \log \frac{1}{\varepsilon})$  个 Newton 步。

结论：在保持正性的同时逐步实现原始可行、对偶可行和互补最优。

常见失败原因：

- 残差符号错误；
- 消元公式反号；
- 正规方程病态；
- 步长未保持正性；
- 只看代理间隙；
- 秩亏、冗余约束和尺度差异；
- 不可行问题缺乏证书嵌入。



## 第二十八章 KKT 条件、Newton 与拟 Newton 方法、BFGS、线搜索、信赖域、罚函数、障碍函数与增广 Lagrange 方法

### 28.1 一般约束优化问题、活跃约束与 KKT 条件

#### 28.1.1 知识点一：一般非线性规划模型

【重要性等级】 **S 级**。

考虑非线性规划

$$\begin{aligned} & \text{minimize} && f(x), \\ & \text{subject to} && g_i(x) \leq 0, \quad i = 1, \dots, m, \\ & && h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned} \tag{P}$$

其中  $x \in \mathbb{R}^n$ ,  $f, g_i, h_j : \mathbb{R}^n \rightarrow \mathbb{R}$ 。

除非另作说明,本节至少假设  $f, g_i, h_j \in C^1$  于候选点邻域内;讨论二阶条件时进一步假设  $f, g_i, h_j \in C^2$ 。

可行域记为

$$\Omega = \{x \in \mathbb{R}^n : g_i(x) \leq 0, h_j(x) = 0\}. \tag{28.1}$$

在可行点  $x$  处, 活跃指标集定义为

$$\mathcal{I}(x) = \{i : g_i(x) = 0\}. \tag{28.2}$$

若  $g_i(x) < 0$ , 则称第  $i$  个不等式约束在  $x$  处不活跃。

#### 28.1.2 知识点二：Lagrange 函数与符号约定

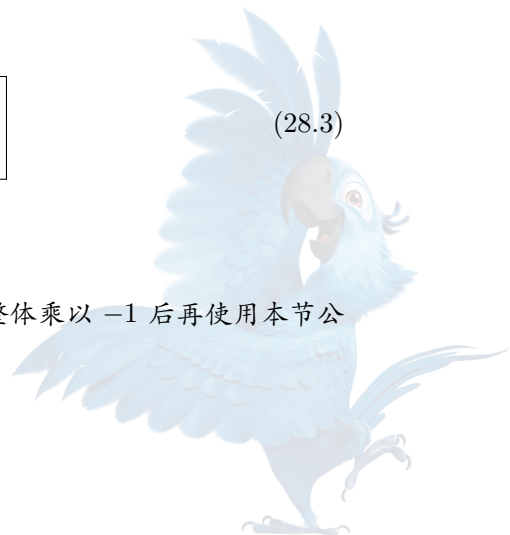
对式 (P) 定义 Lagrange 函数

$$\mathcal{L}(x, \lambda, \nu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \nu_j h_j(x) \tag{28.3}$$

其中  $\lambda \in \mathbb{R}^m$ ,  $\lambda \geq 0$ ,  $\nu \in \mathbb{R}^p$ 。

本节采用  $g_i(x) \leq 0$  的约定, 因此不等式乘子满足  $\lambda_i \geq 0$ 。

若将约束改写为  $g_i(x) \geq 0$ , 则必须相应改变乘子的符号, 或将约束整体乘以  $-1$  后再使用本节公式。



### 易错点与反例

KKT 题最常见的第一类失分是：

约束方向与乘子符号不一致。

最稳妥的处理方式是先把所有不等式统一写成  $g_i(x) \leq 0$ ，再使用  $\lambda_i \geq 0$ 。

### 28.1.3 知识点三：KKT 条件的完整形式

设  $x^*$  为候选点。KKT 条件由四组条件组成。

原始可行性。

$$g_i(x^*) \leq 0, \quad i = 1, \dots, m, \quad (28.4)$$

$$h_j(x^*) = 0, \quad j = 1, \dots, p. \quad (28.5)$$

对偶可行性。

$$\lambda_i^* \geq 0, \quad i = 1, \dots, m. \quad (28.6)$$

驻点条件。

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x^*) + \sum_{j=1}^p \nu_j^* \nabla h_j(x^*) = 0 \quad (28.7)$$

即  $\nabla_x \mathcal{L}(x^*, \lambda^*, \nu^*) = 0$ 。

互补松弛。

$$\lambda_i^* g_i(x^*) = 0, \quad i = 1, \dots, m. \quad (28.8)$$

合并写成

$$\begin{aligned} \nabla_x \mathcal{L}(x^*, \lambda^*, \nu^*) &= 0, \\ g(x^*) &\leq 0, \\ h(x^*) &= 0, \\ \lambda^* &\geq 0, \\ \lambda_i^* g_i(x^*) &= 0. \end{aligned} \quad (28.9)$$

### 28.1.4 知识点四：约束资格条件

KKT 条件并非在任意局部极小点都自动成立。必须讨论约束资格条件 (constraint qualification)。

#### 28.1.4.1 线性无关约束资格条件

在可行点  $x$  处，若向量组

$$\{\nabla h_j(x)\}_{j=1}^p \cup \{\nabla g_i(x)\}_{i \in \mathcal{I}(x)} \quad (28.10)$$

线性无关，则称线性无关约束资格条件 (linear independence constraint qualification, LICQ) 成立。

LICQ 蕴含：

- KKT 乘子的局部唯一性；



- 等式约束 Jacobian 满行秩;
- 局部活跃约束面具有规则流形结构。

#### 28.1.4.2 Mangasarian–Fromovitz 约束资格条件

记  $J_h(x) = \begin{bmatrix} \nabla h_1(x)^\top \\ \vdots \\ \nabla h_p(x)^\top \end{bmatrix}$ 。若:

1.  $J_h(x)$  满行秩;
2. 存在方向  $d \in \mathbb{R}^n$  使

$$J_h(x)d = 0, \quad \nabla g_i(x)^\top d < 0, \quad i \in \mathcal{I}(x), \quad (28.11)$$

则称 Mangasarian–Fromovitz 约束资格条件 (MFCQ) 成立。

LICQ 蕴含 MFCQ, 但 MFCQ 不要求所有活跃约束梯度线性无关。

#### 28.1.4.3 凸问题的 Slater 条件

若  $f, g_i$  凸,  $h$  仿射, 且存在  $\tilde{x}$  满足

$$g_i(\tilde{x}) < 0, \quad h(\tilde{x}) = 0, \quad (28.12)$$

则 Slater 条件成立。

Slater 条件保证:

- 强对偶;
- 对偶最优解可达到;
- 在最优点处存在 KKT 乘子。

#### 28.1.5 知识点五: KKT 必要性

**定理 28.1** (KKT 必要条件). 设  $x^*$  是式 (P) 的局部极小点, 且 MFCQ 在  $x^*$  处成立。则存在  $\lambda^* \geq 0, \nu^* \in \mathbb{R}^p$  使式 (28.9) 成立。

证明. 若存在方向  $d$  同时满足

$$\nabla f(x^*)^\top d < 0, \quad (28.13)$$

$$\nabla g_i(x^*)^\top d < 0, \quad i \in \mathcal{I}(x^*), \quad (28.14)$$


$$J_h(x^*)d = 0, \quad (28.15)$$

则在适当正则性和 MFCQ 下, 可将该线性化方向修正成实际可行曲线的切向方向, 并使目标严格下降, 这与  $x^*$  为局部极小点矛盾。

因此系统式 (28.13) to (28.15) 无解。

由 Gordan–Stiemke 型定理择一, 存在  $\alpha \geq 0, \lambda_i \geq 0 \quad (i \in \mathcal{I}(x^*)), \nu \in \mathbb{R}^p$ , 不全为零, 使

$$\alpha \nabla f(x^*) + \sum_{i \in \mathcal{I}(x^*)} \lambda_i \nabla g_i(x^*) + J_h(x^*)^\top \nu = 0. \quad (28.16)$$



先证  $\alpha > 0$ 。若  $\alpha = 0$ ，取 MFCQ 方向  $d$ ，对式 (28.16) 两边与  $d$  作内积：

$$\begin{aligned} 0 &= \sum_{i \in \mathcal{I}(x^*)} \lambda_i \nabla g_i(x^*)^\top d + \nu^\top J_h(x^*) d \\ &= \sum_{i \in \mathcal{I}(x^*)} \lambda_i \nabla g_i(x^*)^\top d. \end{aligned} \quad (28.17)$$

每个  $\nabla g_i(x^*)^\top d < 0$ ，且  $\lambda_i \geq 0$ ，故必有  $\lambda_i = 0 \quad \forall i \in \mathcal{I}(x^*)$ 。于是  $J_h(x^*)^\top \nu = 0$ 。因  $J_h(x^*)$  满行秩，有  $\nu = 0$ ，与乘子不全为零矛盾。故  $\alpha > 0$ 。

将式 (28.16) 除以  $\alpha$ ，得到驻点条件。对不活跃约束令  $\lambda_i = 0$ ，则自动满足互补松弛。  $\square$

注 28.2 (Fritz-John 条件与 KKT 条件). 若没有约束资格条件，通常只能得到 Fritz-John 条件  $\alpha \nabla f + \sum_i \lambda_i \nabla g_i + \sum_j \nu_j \nabla h_j = 0$ ，其中可能出现  $\alpha = 0$ 。约束资格条件的作用之一，就是排除这种异常乘子情形，使目标梯度前的系数可以归一化为 1。

### 28.1.6 知识点六：凸问题中的 KKT 充分性

定理 28.3 (凸问题的 KKT 充分性). 假设：

1.  $f$  为凸函数；
2. 每个  $g_i$  为凸函数；
3.  $h(x) = Ax - b$  为仿射函数；
4.  $(x^*, \lambda^*, \nu^*)$  满足 KKT 条件。

则  $x^*$  是全局最优解。

若  $f$  在凸可行域上严格凸，则  $x^*$  是唯一全局最优解。

证明. 任取可行点  $x$ 。由  $f$  凸，

$$f(x) \geq f(x^*) + \nabla f(x^*)^\top (x - x^*). \quad (28.18)$$

由驻点条件， $\nabla f(x^*) = -\sum_i \lambda_i^* \nabla g_i(x^*) - A^\top \nu^*$ 。等式约束可行性给出  $A(x - x^*) = 0$ 。因此

$$\nabla f(x^*)^\top (x - x^*) = -\sum_i \lambda_i^* \nabla g_i(x^*)^\top (x - x^*). \quad (28.19)$$

由  $g_i$  凸，


$$\nabla g_i(x^*)^\top (x - x^*) \leq g_i(x) - g_i(x^*). \quad (28.20)$$

于是

$$\begin{aligned} -\lambda_i^* \nabla g_i(x^*)^\top (x - x^*) &\geq \lambda_i^* (g_i(x^*) - g_i(x)) \\ &= -\lambda_i^* g_i(x) \geq 0, \end{aligned} \quad (28.21)$$

其中使用了  $\lambda_i^* g_i(x^*) = 0$ ， $\lambda_i^* \geq 0$ ， $g_i(x) \leq 0$ 。

代回式 (28.18)：  $f(x) \geq f(x^*)$ 。故  $x^*$  为全局最优解。  $\square$



## 易错点与反例

必须区分：

$$\begin{aligned} \text{一般非凸问题: } & \text{KKT 通常只是局部最优的必要条件;} \\ \text{凸问题: } & \text{满足 KKT 即可推出全局最优.} \end{aligned} \quad (28.22)$$

即使问题是凸的，KKT 乘子的存在仍需强对偶或适当约束资格条件；不能无条件声称“凸问题必有 KKT 乘子”。

## 28.2 KKT 条件的完整计算例题

完整题目叙述：活跃约束、乘子与唯一最优解

求解凸优化问题

$$\begin{aligned} & \text{minimize} \quad (x_1 - 1)^2 + (x_2 - 2)^2, \\ & \text{subject to} \quad x_1 + x_2 \leq 2, \\ & \quad \quad \quad x_1 \geq 0, \\ & \quad \quad \quad x_2 \geq 0. \end{aligned} \quad (28.23)$$

要求：

- (1) 写出完整 KKT 条件；
- (2) 求出全部最优乘子；
- (3) 证明所得点是唯一全局最优解。

证明。将约束统一写成

$$g_1(x) = x_1 + x_2 - 2 \leq 0, \quad (28.24)$$

$$g_2(x) = -x_1 \leq 0, \quad (28.25)$$

$$g_3(x) = -x_2 \leq 0. \quad (28.26)$$

引入乘子  $\lambda, \mu_1, \mu_2 \geq 0$ 。Lagrange 函数为

$$\begin{aligned} \mathcal{L} &= (x_1 - 1)^2 + (x_2 - 2)^2 \\ &+ \lambda(x_1 + x_2 - 2) - \mu_1 x_1 - \mu_2 x_2. \end{aligned} \quad (28.27)$$

驻点条件为

$$2(x_1 - 1) + \lambda - \mu_1 = 0, \quad (28.28)$$


$$2(x_2 - 2) + \lambda - \mu_2 = 0. \quad (28.29)$$

互补松弛条件为

$$\lambda(x_1 + x_2 - 2) = 0, \quad (28.30)$$

$$\mu_1 x_1 = 0, \quad (28.31)$$

$$\mu_2 x_2 = 0. \quad (28.32)$$



无约束极小点为  $(1, 2)^\top$ , 但  $1 + 2 > 2$ , 所以总量约束在最优点处必活跃:  $x_1 + x_2 = 2$ 。

若最优点满足  $x_1 > 0, x_2 > 0$ , 则由互补松弛  $\mu_1 = \mu_2 = 0$ 。于是

$$2(x_1 - 1) + \lambda = 0, \quad (28.33)$$

$$2(x_2 - 2) + \lambda = 0, \quad (28.34)$$

$$x_1 + x_2 = 2. \quad (28.35)$$

前两式相减:  $x_1 - x_2 + 1 = 0$ , 即  $x_2 = x_1 + 1$ 。结合总量约束:  $2x_1 + 1 = 2$ 。故

$$x_1^* = \frac{1}{2}, \quad x_2^* = \frac{3}{2}. \quad (28.36)$$

代入驻点条件:

$$\lambda^* = 1, \quad \mu_1^* = \mu_2^* = 0. \quad (28.37)$$

检查:

$$x_1^* + x_2^* - 2 = 0, \quad (28.38)$$

$$x_1^*, x_2^* > 0, \quad (28.39)$$

$$\lambda^* \geq 0, \quad (28.40)$$

$$\lambda^*(x_1^* + x_2^* - 2) = 0. \quad (28.41)$$

目标函数 Hessian 为  $\nabla^2 f(x) = 2I \succ 0$ , 故目标函数严格凸。可行域为凸多面体。因此由 [定义 28.3](#),

$$\boxed{x^* = \begin{pmatrix} 1/2 \\ 3/2 \end{pmatrix}} \quad (28.42)$$

是唯一全局最优解。

最优值为

$$f(x^*) = \left(-\frac{1}{2}\right)^2 + \left(-\frac{1}{2}\right)^2 = \frac{1}{2}. \quad (28.43)$$

□

## 28.3 二阶最优性条件、临界锥与约化 Hessian

### 28.3.1 知识点七: 线性化可行锥

在可行点  $x^*$  处定义线性化锥

$$\mathcal{T}_{\text{lin}}(x^*) = \left\{ d : \begin{cases} \nabla h_j(x^*)^\top d = 0, & j = 1, \dots, p, \\ \nabla g_i(x^*)^\top d \leq 0, & i \in \mathcal{I}(x^*) \end{cases} \right\}. \quad (28.44)$$

临界锥定义为

$$\boxed{\mathcal{C}(x^*) = \{d \in \mathcal{T}_{\text{lin}}(x^*) : \nabla f(x^*)^\top d = 0\}}. \quad (28.45)$$

临界方向是:

- 一阶上不违反活跃约束;





- 一阶上保持等式约束;
- 一阶目标变化为零。

若  $(x^*, \lambda^*, \nu^*)$  满足 KKT, 则对  $d \in \mathcal{C}(x^*)$ , 有

$$\nabla g_i(x^*)^\top d = 0, \quad \lambda_i^* > 0, \quad (28.46)$$

$$\nabla g_i(x^*)^\top d \leq 0, \quad \lambda_i^* = 0. \quad (28.47)$$

### 28.3.2 知识点八：二阶必要条件

定理 28.4 (二阶必要条件). 设  $x^*$  是局部极小点, LICQ 成立,  $(\lambda^*, \nu^*)$  为 KKT 乘子。则

$$d^\top \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*, \nu^*) d \geq 0, \quad \forall d \in \mathcal{C}(x^*). \quad (28.48)$$

必须注意, 二阶必要条件不是要求  $\nabla_{xx}^2 \mathcal{L} \succeq 0$  在整个  $\mathbb{R}^n$  上成立, 而只要求其在临界方向上半正定。

### 28.3.3 知识点九：二阶充分条件

定理 28.5 (二阶充分条件). 设  $(x^*, \lambda^*, \nu^*)$  满足 KKT, 且适当约束资格条件成立。若

$$d^\top \nabla_{xx}^2 \mathcal{L}(x^*, \lambda^*, \nu^*) d > 0, \quad \forall d \in \mathcal{C}(x^*) \setminus \{0\}, \quad (28.49)$$

则  $x^*$  是严格局部极小点。

更精确地, 在适当正则性下, 存在  $c > 0$  和邻域  $\mathcal{N}$ , 使

$$f(x) \geq f(x^*) + c \|x - x^*\|_2^2, \quad x \in \Omega \cap \mathcal{N}. \quad (28.50)$$

### 28.3.4 知识点十：等式约束问题的约化 Hessian

考虑

$$\min f(x) \quad \text{subject to} \quad h(x) = 0. \quad (28.51)$$

设  $J_h(x^*) \in \mathbb{R}^{p \times n}$  满行秩, 且矩阵  $Z \in \mathbb{R}^{n \times (n-p)}$  的列构成  $\ker J_h(x^*)$  的一组正交基。

则约化 Hessian 为

$$H_{\text{red}} = Z^\top \nabla_{xx}^2 \mathcal{L}(x^*, \nu^*) Z. \quad (28.52)$$

二阶充分条件可写成

$$H_{\text{red}} \succ 0. \quad (28.53)$$

#### 易错点与反例

对于等式约束问题, 完整 Hessian 可以是不定矩阵, 但只要它在可行切空间  $\ker J_h(x^*)$  上正定, 仍可满足二阶充分条件。

因此:

$\nabla_{xx}^2 \mathcal{L} \succ 0$  是比必要条件更强的条件, 不能机械要求。

## 28.4 KKT 系统的 Newton 线性化与序列二次规划

### 28.4.1 知识点十一：等式约束 KKT 映射

对式 (28.51) 定义 KKT 映射

$$F(x, \nu) = \begin{bmatrix} \nabla f(x) + J_h(x)^\top \nu \\ h(x) \end{bmatrix}. \quad (28.54)$$

KKT 点满足  $F(x^*, \nu^*) = 0$ 。

对  $F$  作 Newton 线性化，得到

$$\begin{bmatrix} \nabla_{xx}^2 \mathcal{L}(x_k, \nu_k) & J_h(x_k)^\top \\ J_h(x_k) & 0 \end{bmatrix} \begin{bmatrix} p_k \\ \delta \nu_k \end{bmatrix} = - \begin{bmatrix} \nabla_x \mathcal{L}(x_k, \nu_k) \\ h(x_k) \end{bmatrix}. \quad (28.55)$$

更新为

$$x_{k+1} = x_k + \alpha_k p_k, \quad (28.56)$$

$$\nu_{k+1} = \nu_k + \alpha_k \delta \nu_k. \quad (28.57)$$

若采用纯 Newton 法，则  $\alpha_k = 1$ 。为获得全局收敛，通常配合：

- 罚函数或增广 Lagrange 函数作为优值函数；
- Armijo 线搜索；
- 信赖域；
- 过滤器方法。

### 28.4.2 知识点十二：KKT 矩阵非奇异条件

引理 28.6 (鞍点 KKT 矩阵的非奇异性). 设  $A \in \mathbb{R}^{p \times n}$  满行秩,  $H = H^\top$ , 且

$$d^\top H d > 0, \quad \forall d \in \ker A \setminus \{0\}. \quad (28.58)$$

则

$$K = \begin{bmatrix} H & A^\top \\ A & 0 \end{bmatrix} \quad (28.59)$$


非奇异。

证明. 设  $K \begin{bmatrix} d \\ w \end{bmatrix} = 0$ . 则

$$Hd + A^\top w = 0, \quad (28.60)$$

$$Ad = 0. \quad (28.61)$$

对式 (28.60) 左乘  $d^\top$ :  $d^\top Hd + d^\top A^\top w = 0$ . 由  $Ad = 0$ :  $d^\top Hd = 0$ . 又因  $d \in \ker A$ , 由式 (28.58) 得到  $d = 0$ . 于是  $A^\top w = 0$ .  $A$  满行秩意味着  $A^\top$  满列秩, 故  $w = 0$ . 因此  $K$  的零空间仅含零向量.  $\square$



## 28.4.3 知识点十三：与 SQP 子问题的等价关系

若将  $\nabla_{xx}^2 \mathcal{L}(x_k, \nu_k)$  替换为对称近似  $B_k$ ，则 式 (28.55) 等价于二次规划

$$\begin{aligned} & \text{minimize}_p \quad \nabla f(x_k)^\top p + \frac{1}{2} p^\top B_k p, \\ & \text{subject to} \quad h(x_k) + J_h(x_k)p = 0. \end{aligned} \quad (28.62)$$

这就是等式约束序列二次规划 (sequential quadratic programming, SQP) 的基本子问题。

其 KKT 条件为

$$\begin{bmatrix} B_k & J_h(x_k)^\top \\ J_h(x_k) & 0 \end{bmatrix} \begin{bmatrix} p_k \\ \hat{\nu}_{k+1} \end{bmatrix} = - \begin{bmatrix} \nabla f(x_k) \\ h(x_k) \end{bmatrix}. \quad (28.63)$$

若  $B_k = \nabla_{xx}^2 \mathcal{L}(x_k, \nu_k)$ ，则局部上 SQP 就是 KKT 方程的 Newton 法。

## 28.5 无约束优化 Newton 法：方向、局部二次收敛与修正

## 28.5.1 知识点十四：优化 Newton 方向

【重要性等级】 **S** 级。

考虑无约束问题

$$\min_{x \in \mathbb{R}^n} f(x), \quad f \in C^2. \quad (28.64)$$

记  $g_k = \nabla f(x_k)$ ,  $G_k = \nabla^2 f(x_k)$ 。

在  $x_k$  处的二次 Taylor 模型为

$$m_k(p) = f(x_k) + g_k^\top p + \frac{1}{2} p^\top G_k p. \quad (28.65)$$

若  $G_k \succ 0$ ，则模型唯一极小点满足  $G_k p_k = -g_k$ 。故 Newton 方向为

$$p_k^N = -G_k^{-1} g_k. \quad (28.66)$$

实际计算中不应显式形成  $G_k^{-1}$ ，而应求解线性方程  $G_k p_k = -g_k$ 。

## 28.5.2 知识点十五：Newton 方向何时为下降方向

若  $G_k \succ 0$  且  $g_k \neq 0$ ，则


$$g_k^\top p_k^N = -g_k^\top G_k^{-1} g_k < 0. \quad (28.67)$$

因此正定 Hessian 保证 Newton 方向为严格下降方向。

若  $G_k$  不定，则：

- Newton 方向可能不是下降方向；
- 二次模型可能无下界；
- 线性系统可能有解，但所得方向会使目标上升；
- 仅仅“成功解出 Newton 方程”不能保证算法合理。

反例 28.7 (非正定 Hessian 导致 Newton 方向上升). 考虑  $f(x) = x^4 - x^2 + x$ 。在  $x_0 = 0$  处： $f'(0) = 1$ ,  $f''(0) = -2$ 。Newton 方向满足  $-2p_0 = -1$ ，故  $p_0 = \frac{1}{2}$ 。但  $f'(0)p_0 = \frac{1}{2} > 0$ ，所以  $p_0$  是上升方向而非下降方向。



### 28.5.3 知识点十六：局部二次收敛定理

定理 28.8 (优化 Newton 法的局部二次收敛). 设  $x^*$  满足  $\nabla f(x^*) = 0$ . 假设存在  $x^*$  的邻域  $\mathcal{N}$ , 使:

1.  $f \in C^2(\mathcal{N})$ ;

2.  $\nabla^2 f$  为 Lipschitz 连续, 即

$$\|\nabla^2 f(x) - \nabla^2 f(y)\|_2 \leq L_H \|x - y\|_2; \quad (28.68)$$

3.

$$\nabla^2 f(x^*) \succeq mI, \quad m > 0. \quad (28.69)$$

若  $x_0$  充分接近  $x^*$ , 则纯 Newton 迭代

$$x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1} \nabla f(x_k) \quad (28.70)$$

良定义并满足

$$\|x_{k+1} - x^*\|_2 \leq \frac{L_H}{m} \|x_k - x^*\|_2^2 \quad (28.71)$$

在充分小邻域中成立。

证明. 记  $e_k = x_k - x^*$ ,  $G_k = \nabla^2 f(x_k)$ . 由微积分基本定理,

$$\nabla f(x_k) - \nabla f(x^*) = \int_0^1 \nabla^2 f(x^* + te_k) e_k dt. \quad (28.72)$$

因  $\nabla f(x^*) = 0$ , Newton 更新给出

$$\begin{aligned} e_{k+1} &= e_k - G_k^{-1} \nabla f(x_k) \\ &= G_k^{-1} \int_0^1 [G_k - \nabla^2 f(x^* + te_k)] e_k dt. \end{aligned} \quad (28.73)$$

由 Hessian 连续性, 当  $x_k$  充分接近  $x^*$  时,  $G_k \succeq \frac{m}{2}I$ , 故

$$\|G_k^{-1}\|_2 \leq \frac{2}{m}. \quad (28.74)$$

由 Lipschitz 条件:

$$\begin{aligned} \|G_k - \nabla^2 f(x^* + te_k)\|_2 &\leq L_H \|x_k - (x^* + te_k)\|_2 \\ &= L_H(1-t) \|e_k\|_2. \end{aligned} \quad (28.75)$$

于是

$$\begin{aligned} \|e_{k+1}\|_2 &\leq \frac{2}{m} \int_0^1 L_H(1-t) dt \|e_k\|_2^2 \\ &= \frac{L_H}{m} \|e_k\|_2^2. \end{aligned} \quad (28.76)$$

□

注 28.9 (二次收敛的条件不能省略). Newton 法的二次收敛是局部结论, 依赖于:

- 初值足够接近;



- 极小点 Hessian 非奇异且正定；
- Hessian 在邻域内 Lipschitz 连续；
- Newton 方程被足够准确地求解。

若 Hessian 只 Hölder 连续： $\|G(x) - G(y)\| \leq C \|x - y\|^\alpha$ ,  $0 < \alpha < 1$ , 则局部收敛阶通常变为  $1 + \alpha$ 。

#### 28.5.4 知识点十七：修正 Newton 法

当  $G_k$  非正定或近奇异时，可构造正定近似  $B_k \succ 0$  并求解

$$B_k p_k = -g_k. \quad (28.77)$$

常见修正如下。

对角移位。

$$B_k = G_k + \tau_k I, \quad \tau_k \geq 0, \quad (28.78)$$

选择  $\tau_k$  使  $B_k \succeq \delta I$ ,  $\delta > 0$ 。

修正 Cholesky。试图分解  $G_k = LDL^\top$ 。若  $D$  出现非正或过小主元，则对其作最小必要修正，得到  $B_k = LD_{\text{mod}}L^\top \succ 0$ 。

谱截断。若  $G_k = Q\Lambda Q^\top$ , 令  $\tilde{\lambda}_i = \max\{\lambda_i, \delta\}$ , 并取  $B_k = Q\tilde{\Lambda}Q^\top$ 。该方法概念清晰，但完整特征分解成本高。

#### 28.5.5 知识点十八：不精确 Newton 法

大型问题中通常只近似求解  $G_k p = -g_k$ 。若方向满足

$$\|G_k p_k + g_k\|_2 \leq \eta_k \|g_k\|_2, \quad 0 \leq \eta_k < 1, \quad (28.79)$$

则称为不精确 Newton 步。

典型结论为：

- 若  $\sup_k \eta_k < 1$ , 可得到局部线性收敛；
- 若  $\eta_k \rightarrow 0$ , 可得到超线性收敛；
- 若  $\eta_k = O(\|g_k\|)$ , 可恢复二次收敛。

#### 28.5.6 Newton 法的算法模板

**Algorithm 91** 带正定修正和线搜索的阻尼 Newton 法

**Input:**  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  二次连续可微；初值  $x_0$ ；梯度容差  $\varepsilon_g > 0$ ；Armijo 参数  $0 < c_1 < 1$ ；回溯因子  $0 < \beta < 1$ ；正定阈值  $\delta > 0$

**Output:** 近似一阶驻点  $x_k$

1: **Initialization:** 令  $k \leftarrow 0$



```

2: loop
3:   计算  $g_k = \nabla f(x_k)$ ,  $G_k = \nabla^2 f(x_k)$ 
4:   if  $\|g_k\|_2 \leq \varepsilon_g$  then
5:     输出  $x_k$ 
6:   stop
7:   end if
8:   构造  $B_k = G_k + \tau_k I$  使  $B_k \succeq \delta I$ 
9:   求解  $B_k p_k = -g_k$ 
10:  令  $\alpha \leftarrow 1$ 
11:  while  $f(x_k + \alpha p_k) > f(x_k) + c_1 \alpha g_k^\top p_k$  do
12:     $\alpha \leftarrow \beta \alpha$ 
13:  end while
14:   $x_{k+1} = x_k + \alpha p_k$ 
15:   $k \leftarrow k + 1$ 
16: end loop
17: Stopping criterion: 主要停止条件为  $\|\nabla f(x_k)\|_2 \leq \varepsilon_g$ 。实际实现还应检查步长、目标变化和最大迭代次数
18: Complexity: 稠密 Hessian 形成和存储分别约为  $O(n^2)$ ,  $O(n^2)$ 。稠密 Cholesky 或  $LDL^\top$  分解约为  $O(n^3)$ 。稀疏问题成本由非零元、排序和填充决定。不精确 Newton-Krylov 方法可避免显式形成 Hessian

```

## 28.6 线搜索：Armijo、Wolfe 条件与全局收敛

### 28.6.1 知识点十九：下降方向与步长

给定当前点  $x_k$  和方向  $p_k$ , 若

$$\nabla f(x_k)^\top p_k < 0, \quad (28.80)$$

则称  $p_k$  为下降方向。

沿射线定义一维函数

$$\phi_k(\alpha) = f(x_k + \alpha p_k), \quad \alpha \geq 0. \quad (28.81)$$

有  $\phi'_k(0) = \nabla f(x_k)^\top p_k < 0$ 。

线搜索的目标不是精确求解  $\min_{\alpha \geq 0} \phi_k(\alpha)$ , 而是以较少函数和梯度计算找到一个能保证全局收敛的充分好步长。

### 28.6.2 知识点二十：Armijo 充分下降条件

给定  $0 < c_1 < 1$ , Armijo 条件为

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^\top p_k. \quad (28.82)$$

右端比一阶 Taylor 预测  $f(x_k) + \alpha_k \nabla f(x_k)^\top p_k$  要求更弱, 因此只要求实际下降达到预测下降的一定比例。



### 28.6.3 知识点二十一: Armijo 回溯必定终止

定理 28.10 (回溯线搜索的有限终止). 设  $\nabla f$  在相关水平集上以常数  $L_g$  Lipschitz 连续:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L_g \|x - y\|_2. \quad (28.83)$$

若  $p_k$  是下降方向, 则任意满足

$$0 < \alpha \leq \frac{2(1 - c_1)(-g_k^\top p_k)}{L_g \|p_k\|_2^2} \quad (28.84)$$

的步长均满足 Armijo 条件. 因此几何回溯  $\alpha = 1, \beta, \beta^2, \dots, 0 < \beta < 1$ , 在有限次缩步后必定停止。

证明. 由下降引理:

$$f(x_k + \alpha p_k) \leq f(x_k) + \alpha g_k^\top p_k + \frac{L_g}{2} \alpha^2 \|p_k\|_2^2. \quad (28.85)$$

要使右端不超过  $f(x_k) + c_1 \alpha g_k^\top p_k$ , 只需  $(1 - c_1) \alpha g_k^\top p_k + \frac{L_g}{2} \alpha^2 \|p_k\|_2^2 \leq 0$ . 因  $g_k^\top p_k < 0$ , 整理即得式 (28.84).  $\square$

### 28.6.4 知识点二十二: Wolfe 条件

Armijo 条件只限制目标下降, 可能接受过小步长. Wolfe 曲率条件为

$$\boxed{\nabla f(x_k + \alpha_k p_k)^\top p_k \geq c_2 \nabla f(x_k)^\top p_k} \quad (28.86)$$

其中  $0 < c_1 < c_2 < 1$ .

Armijo 条件与 式 (28.86) 合称 Wolfe 条件。

强 Wolfe 曲率条件为

$$\boxed{|\nabla f(x_k + \alpha_k p_k)^\top p_k| \leq c_2 |\nabla f(x_k)^\top p_k|}. \quad (28.87)$$

强 Wolfe 条件同时排除:

- 步长过小;
- 沿方向越过一维极小点太远。

### 28.6.5 知识点二十三: Wolfe 条件保证 BFGS 曲率条件

定义

$$s_k = x_{k+1} - x_k = \alpha_k p_k, \quad (28.88)$$

$$y_k = \nabla f(x_{k+1}) - \nabla f(x_k). \quad (28.89)$$

若步长满足 Wolfe 曲率条件, 则

$$\begin{aligned} s_k^\top y_k &= \alpha_k [\nabla f(x_{k+1})^\top p_k - \nabla f(x_k)^\top p_k] \\ &\geq \alpha_k (c_2 - 1) \nabla f(x_k)^\top p_k \\ &> 0. \end{aligned} \quad (28.90)$$

因此 Wolfe 线搜索自然保证 BFGS 更新所需的曲率条件

$$\boxed{s_k^\top y_k > 0}. \quad (28.91)$$



## 28.6.6 知识点二十四：Zoutendijk 条件

定义方向  $p_k$  与负梯度的夹角  $\theta_k$ :

$$\cos \theta_k = \frac{-g_k^\top p_k}{\|g_k\|_2 \|p_k\|_2}. \quad (28.92)$$

在下列条件下:

- $f$  在初始水平集上有下界;
- $\nabla f$  Lipschitz 连续;
- $p_k$  为下降方向;
- 步长满足 Wolfe 条件;

可证明

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|g_k\|_2^2 < \infty. \quad (28.93)$$

若方向与负梯度一致成角, 即存在  $\gamma > 0$  使  $\cos \theta_k \geq \gamma$ , 则  $\|g_k\|_2 \rightarrow 0$ 。

注 28.11. Zoutendijk 结论通常只保证一阶驻点收敛, 并不自动保证:

- 收敛到局部极小点;
- 避开鞍点;
- 目标函数凸;
- 迭代点本身唯一收敛。

## 28.6.7 最速下降法的强凸收敛率

若  $f$  满足:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{m}{2} \|y - x\|_2^2, \quad (28.94)$$

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L \|x - y\|_2, \quad (28.95)$$

其中  $0 < m \leq L$ , 则步长  $\alpha = \frac{1}{L}$  的梯度下降满足

$$f(x_k) - f(x^*) \leq \left(1 - \frac{m}{L}\right)^k [f(x_0) - f(x^*)]. \quad (28.96)$$

比值  $\kappa = \frac{L}{m}$  可视为优化问题的曲率条件数。 $\kappa$  大时, 最速下降会出现狭长谷中的锯齿现象。

## 28.7 拟 Newton 法、DFP、BFGS 与 L-BFGS

### 28.7.1 知识点二十五：割线条件的来源

Newton 法使用  $\nabla^2 f(x_k) s_k \approx y_k$ 。拟 Newton 法用对称矩阵  $B_{k+1}$  逼近 Hessian, 并要求满足割线条件

$$B_{k+1} s_k = y_k. \quad (28.97)$$



若用  $H_{k+1}$  逼近逆 Hessian, 则割线条件为

$$\boxed{H_{k+1}y_k = s_k}. \quad (28.98)$$

单个向量方程不能唯一确定  $n \times n$  矩阵, 因此还需要:

- 对称性;
- 正定性;
- 与旧矩阵尽可能接近;
- 低秩更新结构。

### 28.7.2 知识点二十六: BFGS 的 Hessian 形式

BFGS 更新为

$$\boxed{B_{k+1} = B_k - \frac{B_k s_k s_k^\top B_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top}{y_k^\top s_k}}. \quad (28.99)$$

直接验证割线条件:

$$\begin{aligned} B_{k+1}s_k &= B_k s_k - \frac{B_k s_k s_k^\top B_k s_k}{s_k^\top B_k s_k} + \frac{y_k y_k^\top s_k}{y_k^\top s_k} \\ &= y_k. \end{aligned} \quad (28.100)$$

### 28.7.3 知识点二十七: BFGS 的逆 Hessian 形式

令  $\rho_k = \frac{1}{y_k^\top s_k}$ . 则逆 BFGS 更新为

$$\boxed{H_{k+1} = (I - \rho_k s_k y_k^\top) H_k (I - \rho_k y_k s_k^\top) + \rho_k s_k s_k^\top}. \quad (28.101)$$

方向为

$$p_k = -H_k g_k. \quad (28.102)$$

若  $H_k \succ 0$ ,  $g_k \neq 0$ , 则  $g_k^\top p_k = -g_k^\top H_k g_k < 0$ 。

### 28.7.4 知识点二十八: 正定性保持


**定理 28.12** (BFGS 正定性). 若  $B_k \succ 0$  且  $s_k^\top y_k > 0$ , 则  $B_{k+1} \succ 0$ 。等价地, 若  $H_k \succ 0$  且  $s_k^\top y_k > 0$ , 则  $H_{k+1} \succ 0$ 。

证明. 对任意  $v \neq 0$ , 由 式 (28.99):

$$v^\top B_{k+1}v = v^\top B_k v - \frac{(v^\top B_k s_k)^2}{s_k^\top B_k s_k} + \frac{(v^\top y_k)^2}{y_k^\top s_k}. \quad (28.103)$$

在  $B_k$ -内积  $\langle u, v \rangle_{B_k} = u^\top B_k v$  下, 由 Cauchy-Schwarz 不等式:  $(v^\top B_k s_k)^2 \leq (v^\top B_k v)(s_k^\top B_k s_k)$ 。故前两项之和非负。

若前两项之和为零, 则  $v$  与  $s_k$  线性相关:  $v = cs_k$ 。若最后一项也为零, 则  $0 = v^\top y_k = cs_k^\top y_k$ 。由于  $s_k^\top y_k > 0$ , 必有  $c = 0$ , 与  $v \neq 0$  矛盾。因此  $v^\top B_{k+1}v > 0$ 。□



### 28.7.5 知识点二十九：DFP 更新

DFP 的逆 Hessian 更新为

$$H_{k+1}^{\text{DFP}} = H_k + \frac{s_k s_k^\top}{s_k^\top y_k} - \frac{H_k y_k y_k^\top H_k}{y_k^\top H_k y_k}. \quad (28.104)$$

DFP 和 BFGS 互为某种对偶形式：

- 对 Hessian 应用 BFGS，对应其逆矩阵的 DFP 型结构；
- 对逆 Hessian 应用 BFGS，通常数值性能优于直接 DFP；
- 两者均属于对称秩二更新。

### 28.7.6 知识点三十：BFGS 超线性收敛

在标准条件下：

1.  $f \in C^2$ ；
2.  $x^*$  为严格局部极小点；
3.  $\nabla^2 f(x^*) \succ 0$ ；
4. Hessian 在邻域中 Lipschitz 连续；
5.  $B_0 \succ 0$ ；
6. 线搜索满足适当 Wolfe 条件；

BFGS 迭代局部满足

$$\frac{\|x_{k+1} - x^*\|_2}{\|x_k - x^*\|_2} \rightarrow 0. \quad (28.105)$$

这是  $q$ -超线性收敛，一般不是二次收敛。

一个核心判据是 Dennis–Moré 条件：

$$\frac{\|(B_k - \nabla^2 f(x^*))s_k\|_2}{\|s_k\|_2} \rightarrow 0. \quad (28.106)$$

该条件只要求  $B_k$  沿实际步方向逐渐逼近真实 Hessian，不要求  $B_k \rightarrow \nabla^2 f(x^*)$  在整个矩阵范数下成立。

### 28.7.7 知识点三十一：二次函数与精确线搜索

对严格凸二次函数

$$f(x) = \frac{1}{2}x^\top Qx - b^\top x, \quad Q \succ 0, \quad (28.107)$$

若 BFGS 使用精确线搜索，则在精确算术中：

- 生成的方向彼此  $Q$ -共轭；
- 迭代与共轭梯度法存在紧密对应；
- 至多  $n$  步到达精确解。

有限精度下，共轭性会受到舍入误差破坏，故“至多  $n$  步”不是实际计算中的绝对保证。



## 28.7.8 知识点三十二：L-BFGS

完整 BFGS 需存储  $H_k \in \mathbb{R}^{n \times n}$ , 存储量为  $O(n^2)$ 。

L-BFGS 只保留最近  $r$  组  $(s_i, y_i)$ , 其中  $r \ll n$ 。存储复杂度降为  $O(rn)$ 。

**Algorithm 92** L-BFGS 两层循环递推

**Input:** 当前梯度  $g_k$ ; 最近  $r$  组  $(s_i, y_i)$ ,  $\rho_i = (y_i^\top s_i)^{-1}$ ; 初始缩放矩阵  $H_k^{(0)} = \gamma_k I$

**Output:** 近似拟 Newton 方向  $p_k$

- 1:  $q \leftarrow g_k$
- 2: **for**  $i = k-1, k-2, \dots, k-r$  **do**
- 3:      $\alpha_i \leftarrow \rho_i s_i^\top q$
- 4:      $q \leftarrow q - \alpha_i y_i$
- 5: **end for**
- 6:  $z \leftarrow H_k^{(0)} q$
- 7: **for**  $i = k-r, k-r+1, \dots, k-1$  **do**
- 8:      $\beta_i \leftarrow \rho_i y_i^\top z$
- 9:      $z \leftarrow z + s_i(\alpha_i - \beta_i)$
- 10: **end for**
- 11: 输出  $p_k = -z$
- 12: **Stopping criterion:** L-BFGS 只是方向计算模块; 外层仍需使用梯度范数、线搜索和最大迭代次数停止
- 13: **Complexity:** 每次两层递推的运算量为  $O(rn)$ , 存储量为  $O(rn)$ 。通常  $r$  取一个远小于  $n$  的固定整数

## 易错点与反例

必须区分两类“拟 Newton 法”:

1. 求解非线性方程组  $F(x) = 0$  的 Broyden 法: 逼近 Jacobian 或逆 Jacobian, 更新通常不要求对称;
2. 最小化标量目标  $f(x)$  的 BFGS 法: 逼近对称 Hessian 或逆 Hessian, 依赖曲率条件  $s_k^\top y_k > 0$ 。

二者都使用割线条件, 但对象、结构和收敛分析不同。

## 28.8 补充训练题：丘赛 2026 Problem 2——严格凸泛函、Newton 二次收敛与 Hilbert 空间 BFGS

完整题目叙述: [丘赛 2026 Problem 2]

设  $\Omega \subset \mathbb{R}^d$  为有界区域,  $d \leq 3$ 。考虑泛函

$$J: H_0^1(\Omega) \rightarrow \mathbb{R}, \quad J(u) = \int_{\Omega} \left[ \frac{1}{2} |\nabla u(x)|^2 + \frac{1}{4} u(x)^4 - f(x)u(x) \right] dx, \quad (28.108)$$

其中  $f \in L^2(\Omega)$ 。

- (a) 计算  $J$  的一阶 Fréchet 导数和二阶 Fréchet 导数, 并证明  $J$  严格凸。

(b) 写出求  $J$  的极小点  $u^*$  的 Newton 方法。假设初值  $u_0$  充分接近  $u^*$ , 证明存在  $C > 0$  使

$$\|u_{k+1} - u^*\|_{H^1} \leq C \|u_k - u^*\|_{H^1}^2. \quad (28.109)$$

(c) 令  $s_k = u_{k+1} - u_k$ ,  $y_k = \nabla J(u_{k+1}) - \nabla J(u_k)$ . 拟 Newton 法构造满足割线条件  $B_{k+1}s_k = y_k$  的近似 Hessian。给定 BFGS 更新

$$\begin{aligned} B_{k+1}v &= B_k v - \frac{\langle B_k s_k, v \rangle}{\langle B_k s_k, s_k \rangle} B_k s_k \\ &\quad + \frac{\langle y_k, v \rangle}{\langle y_k, s_k \rangle} y_k, \quad \forall v \in H_0^1(\Omega). \end{aligned} \quad (28.110)$$

假设  $B_k$  正定, 证明该 BFGS 更新良定义。

解答前的函数空间准备

令  $V = H_0^1(\Omega)$ 。采用等价范数

$$\|v\|_V = \|\nabla v\|_{L^2(\Omega)} \quad (28.111)$$

和内积

$$(u, v)_V = \int_{\Omega} \nabla u \cdot \nabla v \, dx. \quad (28.112)$$

由 Poincaré 不等式, 存在  $C_P > 0$  使

$$\|v\|_{L^2} \leq C_P \|v\|_V. \quad (28.113)$$

因  $d \leq 3$ , Sobolev 嵌入给出

$$H_0^1(\Omega) \hookrightarrow L^q(\Omega), \quad 2 \leq q \leq 6, \quad (28.114)$$

特别地,  $u \in L^4(\Omega) \cap L^6(\Omega)$ 。所以  $u^4 \in L^1(\Omega)$ ,  $fu \in L^1(\Omega)$ , 泛函  $J$  良定义。

第 (a) 问: 一阶导数、二阶导数与严格凸性

取  $u, v \in V$ 。有

$$J(u + \varepsilon v) = \int_{\Omega} \left[ \frac{1}{2} |\nabla u + \varepsilon \nabla v|^2 + \frac{1}{4} (u + \varepsilon v)^4 - f(u + \varepsilon v) \right] dx. \quad (28.115)$$

对  $\varepsilon$  求导并令  $\varepsilon = 0$ :


$$J'(u)[v] = \int_{\Omega} [\nabla u \cdot \nabla v + u^3 v - f v] \, dx. \quad (28.116)$$

对任意  $v, w \in V$ , 再次求导:

$$J''(u)[v, w] = \int_{\Omega} [\nabla v \cdot \nabla w + 3u^2 vw] \, dx. \quad (28.117)$$

这些表达式确实定义连续线性和连续双线性泛函。例如:

$$\begin{aligned} \left| \int_{\Omega} u^3 v \, dx \right| &\leq \|u\|_{L^6}^3 \|v\|_{L^2} \\ &\leq C \|u\|_V^3 \|v\|_V, \end{aligned} \quad (28.118)$$



以及

$$\begin{aligned} \left| \int_{\Omega} u^2 v w \, dx \right| &\leq \|u\|_{L^6}^2 \|v\|_{L^6} \|w\|_{L^2} \\ &\leq C \|u\|_V^2 \|v\|_V \|w\|_V. \end{aligned} \quad (28.119)$$

对任意非零  $v \in V$ :

$$\begin{aligned} J''(u)[v, v] &= \int_{\Omega} [|\nabla v|^2 + 3u^2 v^2] \, dx \\ &\geq \|\nabla v\|_{L^2}^2 \\ &= \|v\|_V^2 > 0. \end{aligned} \quad (28.120)$$

故  $J$  不仅严格凸, 而且关于  $V$ -范数是 1-强凸的。

此外,

$$\begin{aligned} J(u) &\geq \frac{1}{2} \|u\|_V^2 - \|f\|_{L^2} \|u\|_{L^2} \\ &\geq \frac{1}{2} \|u\|_V^2 - C_P \|f\|_{L^2} \|u\|_V. \end{aligned} \quad (28.121)$$

因此  $\|u\|_V \rightarrow \infty \implies J(u) \rightarrow \infty$ . 结合弱下半连续性,  $J$  存在唯一极小点  $u^* \in V$ .

注 28.13 (Fréchet 导数与 Hilbert 梯度的区别). 式 (28.116) 首先给出的是  $J'(u) \in V^*$ . 若将“梯度”定义为  $V$  中的 Riesz 代表  $\nabla_V J(u) \in V$ , 则它满足

$$(\nabla_V J(u), v)_V = J'(u)[v], \quad \forall v \in V. \quad (28.122)$$

因此不能脱离所选内积, 直接把  $-\Delta u + u^3 - f$  称作“ $H^1$  梯度”. 该表达式自然属于弱残差或  $V^*$ .

极小点满足 Euler-Lagrange 方程

$$\boxed{\int_{\Omega} [\nabla u^* \cdot \nabla v + (u^*)^3 v - f v] \, dx = 0, \quad \forall v \in V.} \quad (28.123)$$

形式上即

$$\begin{cases} -\Delta u^* + (u^*)^3 = f, & x \in \Omega, \\ u^* = 0, & x \in \partial\Omega. \end{cases} \quad (28.124)$$

### 第 (b) 问: Newton 方法

给定  $u_k \in V$ , Newton 增量  $p_k \in V$  满足

$$J''(u_k)[p_k, v] = -J'(u_k)[v], \quad \forall v \in V. \quad (28.125)$$

即


$$\boxed{\int_{\Omega} [\nabla p_k \cdot \nabla v + 3u_k^2 p_k v] \, dx = - \int_{\Omega} [\nabla u_k \cdot \nabla v + u_k^3 v - f v] \, dx, \quad \forall v \in V.} \quad (28.126)$$

更新

$$u_{k+1} = u_k + p_k. \quad (28.127)$$

定义双线性型

$$a_k(v, w) = \int_{\Omega} [\nabla v \cdot \nabla w + 3u_k^2 v w] \, dx. \quad (28.128)$$



有

$$a_k(v, v) \geq \|v\|_V^2. \quad (28.129)$$

并且由 Sobolev 嵌入,  $a_k$  连续。故由 Lax-Milgram 定理, 每个 Newton 增量唯一存在。

将式 (28.126) 用  $u_{k+1}$  重写:

$$\int_{\Omega} [\nabla u_{k+1} \cdot \nabla v + 3u_k^2 u_{k+1} v] dx = \int_{\Omega} [fv + 2u_k^3 v] dx \quad (28.130)$$

对所有  $v \in V$  成立。

二次收敛证明

令  $e_k = u_k - u^*$ 。从式 (28.130) 减去式 (28.123), 并用  $u_{k+1} = u^* + e_{k+1}$ , 得到

$$a_k(e_{k+1}, v) = \int_{\Omega} [2u_k^3 - 3u_k^2 u^* + (u^*)^3] v dx. \quad (28.131)$$

利用恒等式

$$2a^3 - 3a^2b + b^3 = (a - b)^2(2a + b), \quad (28.132)$$

有

$$a_k(e_{k+1}, v) = \int_{\Omega} e_k^2 (2u_k + u^*) v dx. \quad (28.133)$$

取  $v = e_{k+1}$ 。由强制性:

$$\|e_{k+1}\|_V^2 \leq \left| \int_{\Omega} e_k^2 (2u_k + u^*) e_{k+1} dx \right|. \quad (28.134)$$

使用 Hölder 不等式, 指数取为 3, 6, 2,  $\frac{1}{3} + \frac{1}{6} + \frac{1}{2} = 1$ :

$$\begin{aligned} & \left| \int_{\Omega} e_k^2 (2u_k + u^*) e_{k+1} dx \right| \\ & \leq \|e_k^2\|_{L^3} \|2u_k + u^*\|_{L^6} \|e_{k+1}\|_{L^2} \\ & = \|e_k\|_{L^6}^2 \|2u_k + u^*\|_{L^6} \|e_{k+1}\|_{L^2} \\ & \leq C \|e_k\|_V^2 (2\|u_k\|_V + \|u^*\|_V) \|e_{k+1}\|_V. \end{aligned} \quad (28.135)$$

若  $e_{k+1} \neq 0$ , 两边除以  $\|e_{k+1}\|_V$  得到

$$\|e_{k+1}\|_V \leq C (2\|u_k\|_V + \|u^*\|_V) \|e_k\|_V^2. \quad (28.136)$$


若  $u_k$  位于  $u^*$  的固定小邻域内, 则  $\|u_k\|_V \leq \|u^*\|_V + r$ , 故存在与  $k$  无关的常数  $C_R$  使

$$\|e_{k+1}\|_V \leq C_R \|e_k\|_V^2. \quad (28.137)$$

选  $r > 0$  使  $C_R r \leq \frac{1}{2}$ 。若  $\|e_0\|_V \leq r$ , 则归纳地  $\|e_{k+1}\|_V \leq \frac{1}{2} \|e_k\|_V \leq r$ , 所以所有迭代均留在该邻域, 并且式 (28.137) 对所有  $k$  成立。

由于  $\|\cdot\|_V$  与  $\|\cdot\|_{H^1}$  在  $H_0^1(\Omega)$  上等价, 最终得到

$$\|u_{k+1} - u^*\|_{H^1} \leq C \|u_k - u^*\|_{H^1}^2. \quad (28.138)$$



## 第 (c) 问：BFGS 更新的良定义性

为严格解释题面，将  $B_k$  视为 Hilbert 空间  $V$  上的有界、自伴、正定算子：

$$(B_k v, v)_V > 0, \forall v \neq 0. \quad (28.139)$$

假设  $s_k \neq 0$ 。若  $s_k = 0$ ，说明迭代没有移动，算法应检查停止条件，无需执行 BFGS 更新。

首先，由  $B_k$  正定：

$$(B_k s_k, s_k)_V > 0. \quad (28.140)$$

其次，由 Hilbert 梯度的微积分基本定理：

$$\begin{aligned} (y_k, s_k)_V &= (\nabla_V J(u_k + s_k) - \nabla_V J(u_k), s_k)_V \\ &= \int_0^1 J''(u_k + ts_k)[s_k, s_k] dt. \end{aligned} \quad (28.141)$$

由 式 (28.120)：

$$J''(u_k + ts_k)[s_k, s_k] \geq \|s_k\|_V^2. \quad (28.142)$$

故

$$(y_k, s_k)_V \geq \|s_k\|_V^2 > 0. \quad (28.143)$$

因此 式 (28.110) 中的两个分母均严格为正，更新良定义。

进一步验证割线条件。令  $v = s_k$ ，则

$$\begin{aligned} B_{k+1} s_k &= B_k s_k - \frac{(B_k s_k, s_k)_V}{(B_k s_k, s_k)_V} B_k s_k \\ &\quad + \frac{(y_k, s_k)_V}{(y_k, s_k)_V} y_k \\ &= y_k. \end{aligned} \quad (28.144)$$

再证正定性保持。对任意  $v \neq 0$ ：

$$\begin{aligned} (B_{k+1} v, v)_V &= (B_k v, v)_V - \frac{(B_k s_k, v)_V^2}{(B_k s_k, s_k)_V} \\ &\quad + \frac{(y_k, v)_V^2}{(y_k, s_k)_V}. \end{aligned} \quad (28.145)$$

由  $B_k$ -内积下的 Cauchy-Schwarz 不等式，前两项之和非负。若其为零，则  $v = cs_k$ 。若最后一项也为零，则  $0 = (y_k, v)_V = c(y_k, s_k)_V$ 。由 式 (28.143) 知  $c = 0$ ，与  $v \neq 0$  矛盾。故

$$B_{k+1} \succ 0. \quad (28.146)$$

所以该更新：

- 两个分母非零；
- 满足割线条件；
- 保持自伴性；
- 保持正定性；
- 因而给出合法的 Hilbert 空间 BFGS 更新。



## 28.9 信赖域方法

### 28.9.1 知识点三十三：信赖域子问题

【重要性等级】 **A 级**。

在  $x_k$  处构造二次模型

$$m_k(p) = f(x_k) + g_k^\top p + \frac{1}{2} p^\top B_k p, \quad B_k = B_k^\top. \quad (28.147)$$

信赖域子问题为

$$\begin{array}{ll} \text{minimize}_{p \in \mathbb{R}^n} & g_k^\top p + \frac{1}{2} p^\top B_k p, \\ \text{subject to} & \|p\|_2 \leq \Delta_k. \end{array} \quad (28.148)$$

其中  $\Delta_k > 0$  是信赖域半径。

即使  $B_k$  不定，可行球  $\{p: \|p\|_2 \leq \Delta_k\}$  仍为紧集，故子问题总有全局极小解。

这正是信赖域相对于纯 Newton 法的重要优势：它能在 Hessian 不定时显式利用负曲率，而不是被无界二次模型破坏。

### 28.9.2 知识点三十四：信赖域子问题的最优性条件

定理 28.14 (二范数信赖域子问题的全局最优性条件). 向量  $p^*$  是式 (28.148) 的全局最优解，当且仅当存在  $\lambda^* \geq 0$  使

$$(B_k + \lambda^* I) p^* = -g_k, \quad (28.149)$$

$$B_k + \lambda^* I \succeq 0, \quad (28.150)$$

$$\lambda^* (\Delta_k - \|p^*\|_2) = 0, \quad (28.151)$$

$$\|p^*\|_2 \leq \Delta_k. \quad (28.152)$$

充分性. 任取可行  $q$ 。由  $g_k = -(B_k + \lambda^* I) p^*$  有

$$\begin{aligned} m_k(q) - m_k(p^*) &= \frac{1}{2} (q - p^*)^\top (B_k + \lambda^* I) (q - p^*) \\ &\quad + \frac{\lambda^*}{2} (\|p^*\|_2^2 - \|q\|_2^2). \end{aligned} \quad (28.153)$$

第一项由  $B_k + \lambda^* I \succeq 0$  非负。

若  $\lambda^* = 0$ ，第二项为零。若  $\lambda^* > 0$ ，由互补条件  $\|p^*\|_2 = \Delta_k \geq \|q\|_2$ ，第二项也非负。故  $m_k(q) \geq m_k(p^*)$ 。□

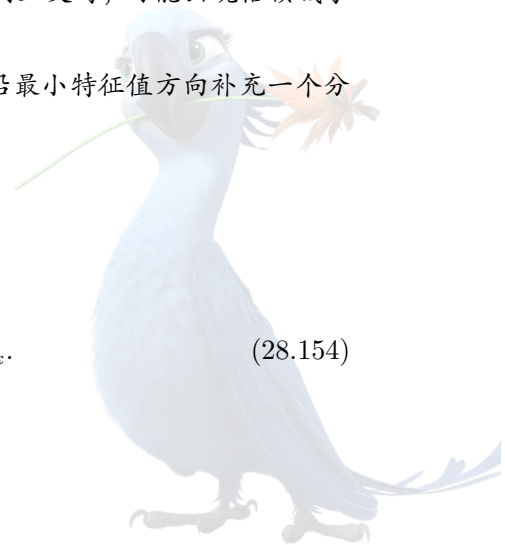
注 28.15 (困难情形). 当  $B_k + \lambda I$  奇异，且  $g_k$  与最小特征值对应特征空间正交时，可能出现信赖域子问题的“困难情形”(hard case)。

此时仅通过求解  $(B_k + \lambda I)p = -g_k$  可能不能自动达到边界，还需沿最小特征值方向补充一个分量。

### 28.9.3 知识点三十五：Cauchy 点

沿最速下降方向取  $p = -\tau g_k$ 。模型变化为

$$m_k(-\tau g_k) - m_k(0) = -\tau \|g_k\|_2^2 + \frac{1}{2} \tau^2 g_k^\top B_k g_k. \quad (28.154)$$





Cauchy 步长为

$$\tau_k^C = \begin{cases} \min \left\{ \frac{\|g_k\|_2^2}{g_k^\top B_k g_k}, \frac{\Delta_k}{\|g_k\|_2} \right\}, & g_k^\top B_k g_k > 0, \\ \frac{\Delta_k}{\|g_k\|_2}, & g_k^\top B_k g_k \leq 0. \end{cases} \quad (28.155)$$

Cauchy 点为

$$p_k^C = -\tau_k^C g_k. \quad (28.156)$$

它满足 Cauchy 下降估计

$$m_k(0) - m_k(p_k^C) \geq \frac{1}{2} \|g_k\|_2 \min \left\{ \Delta_k, \frac{\|g_k\|_2}{\|B_k\|_2} \right\}. \quad (28.157)$$

很多信赖域全局收敛定理并不要求精确求解子问题，只要求计算出的  $p_k$  至少达到固定比例的 Cauchy 下降。

#### 28.9.4 知识点三十六：实际下降、预测下降与接受比

定义预测下降

$$\text{pred}_k = m_k(0) - m_k(p_k) = -g_k^\top p_k - \frac{1}{2} p_k^\top B_k p_k. \quad (28.158)$$

实际下降为

$$\text{ared}_k = f(x_k) - f(x_k + p_k). \quad (28.159)$$

定义比值

$$\rho_k = \frac{\text{ared}_k}{\text{pred}_k}. \quad (28.160)$$

解释如下：

- $\rho_k \approx 1$ ：模型预测准确；
- $\rho_k \ll 1$ ：模型过于乐观；
- $\rho_k < 0$ ：真实目标反而上升；
- $\rho_k$  大且步长触及边界：可扩大信赖域。

#### 28.9.5 知识点三十七：Dogleg 与截断 CG

Dogleg 方法。若  $B_k \succ 0$ , 定义：

$$p_k^U = -\frac{g_k^\top g_k}{g_k^\top B_k g_k} g_k, \quad (28.161)$$

$$p_k^N = -B_k^{-1} g_k. \quad (28.162)$$

Dogleg 路径依次连接  $0 \rightarrow p_k^U \rightarrow p_k^N$ 。取该折线路径与球  $\|p\|_2 \leq \Delta_k$  的合适交点。



截断共轭梯度。对大型稀疏问题，Steihaug–Toint 截断 CG 在以下任一情形停止：

1. 残差足够小；
2. 下一步将越出信赖域边界；
3. 检测到负曲率  $d^\top B_k d \leq 0$ .

检测到负曲率时，沿当前方向走到信赖域边界，可保证模型得到显著下降。

### 28.9.6 信赖域算法

#### Algorithm 93 基本信赖域方法

**Input:** 初值  $x_0$ ；初始半径  $\Delta_0 > 0$ ；最大半径  $\Delta_{\max}$ ；接受阈值  $0 < \eta_0 < \eta_1 < \eta_2 < 1$ ；梯度容差  $\varepsilon_g$

**Output:** 近似一阶驻点

```

1: Initialization: 令  $k \leftarrow 0$ 
2: loop
3:   计算  $g_k = \nabla f(x_k)$ ,  $B_k \approx \nabla^2 f(x_k)$ 
4:   if  $\|g_k\|_2 \leq \varepsilon_g$  then
5:     输出  $x_k$ 
6:     stop
7:   end if
8:   近似求解  $\min_{\|p\|_2 \leq \Delta_k} g_k^\top p + \frac{1}{2} p^\top B_k p$  得  $p_k$ 
9:   计算  $\rho_k = \frac{f(x_k) - f(x_k + p_k)}{-g_k^\top p_k - \frac{1}{2} p_k^\top B_k p_k}$ 
10:  if  $\rho_k < \eta_1$  then
11:     $\Delta_{k+1} \leftarrow \frac{1}{4} \Delta_k$ 
12:  else if  $\rho_k > \eta_2$  且  $\|p_k\|_2 \geq 0.9 \Delta_k$  then
13:     $\Delta_{k+1} \leftarrow \min\{2\Delta_k, \Delta_{\max}\}$ 
14:  else
15:     $\Delta_{k+1} \leftarrow \Delta_k$ 
16:  end if
17:  if  $\rho_k > \eta_0$  then
18:     $x_{k+1} \leftarrow x_k + p_k$ 
19:  else
20:     $x_{k+1} \leftarrow x_k$ 
21:  end if
22:   $k \leftarrow k + 1$ 
23: end loop
24: Stopping criterion: 使用  $\|\nabla f(x_k)\|_2 \leq \varepsilon_g$ 。还应防止半径过小和子问题求解失败
25: Complexity: 精确信赖域子问题的稠密求解通常为  $O(n^3)$ 。截断 CG 每步主要为一次  $B_k$  矩阵–向量乘，若执行  $j$  步，成本约为  $O(j \operatorname{mv}(B_k))$ 。无需显式存储稠密 Hessian 时，可使用 Hessian–向量积

```

### 28.9.7 知识点三十八：信赖域收敛性

在下列典型条件下：

- $f$  在相关水平集上有下界；

- $\nabla f$  Lipschitz 连续;
- $\|B_k\|$  一致有界;
- 每个子问题方向至少取得固定比例的 Cauchy 下降;

可证明

$$\liminf_{k \rightarrow \infty} \|\nabla f(x_k)\|_2 = 0. \quad (28.163)$$

在进一步标准条件下可加强为

$$\|\nabla f(x_k)\|_2 \rightarrow 0. \quad (28.164)$$

若极限点  $x^*$  满足  $\nabla^2 f(x^*) \succ 0$ , 且  $B_k = \nabla^2 f(x_k)$ , 则信赖域最终不再限制 Newton 步:  $\|p_k^N\| < \Delta_k$ 。于是算法最终等同于纯 Newton 法, 获得局部二次收敛。

## 28.10 罚函数方法

### 28.10.1 知识点三十九: 等式约束二次罚函数

考虑

$$\min f(x) \quad \text{subject to} \quad h(x) = 0. \quad (28.165)$$

二次罚函数为

$$P_\rho(x) = f(x) + \frac{\rho}{2} \|h(x)\|_2^2, \quad \rho > 0. \quad (28.166)$$

梯度为

$$\nabla P_\rho(x) = \nabla f(x) + \rho J_h(x)^\top h(x). \quad (28.167)$$

定义乘子估计

$$\lambda_\rho = \rho h(x_\rho). \quad (28.168)$$

若  $x_\rho$  是罚函数驻点, 则

$$\nabla f(x_\rho) + J_h(x_\rho)^\top \lambda_\rho = 0. \quad (28.169)$$

这与 KKT 驻点条件一致, 但一般只有  $h(x_\rho) \rightarrow 0$  时才逼近真实可行点。

### 28.10.2 知识点四十: 不等式二次罚函数

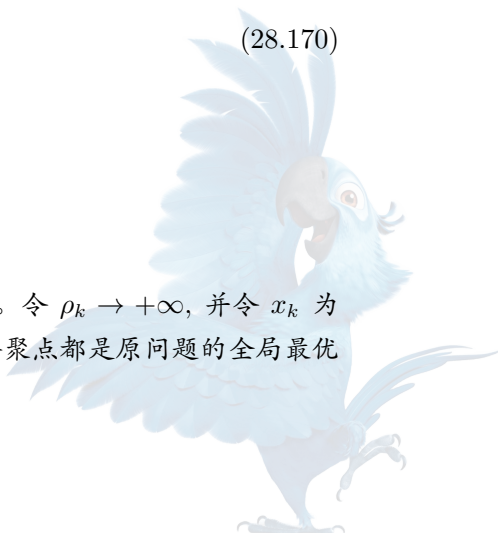
对  $g_i(x) \leq 0$ , 定义正部  $[a]_+ = \max\{a, 0\}$ 。二次外罚函数为

$$P_\rho(x) = f(x) + \frac{\rho}{2} \sum_{i=1}^m [g_i(x)]_+^2 + \frac{\rho}{2} \|h(x)\|_2^2. \quad (28.170)$$

只有违反约束  $g_i(x) > 0$  时才产生不等式罚项。

### 28.10.3 知识点四十一: 二次罚函数极小点的收敛

**定理 28.16** (二次罚函数的基本收敛性). 设原约束问题有全局最优解  $x^*$ 。令  $\rho_k \rightarrow +\infty$ , 并令  $x_k$  为  $P_{\rho_k}$  的全局极小点。假设  $\{x_k\}$  有聚点且  $f$  在相关集合上有下界。则每个聚点都是原问题的全局最优解。



证明. 以纯等式约束为例. 由  $x_k$  最优且  $x^*$  可行:

$$\begin{aligned} f(x_k) + \frac{\rho_k}{2} \|h(x_k)\|_2^2 &\leq f(x^*) + \frac{\rho_k}{2} \|h(x^*)\|_2^2 \\ &= f(x^*). \end{aligned} \quad (28.171)$$

设  $f(x) \geq \underline{f}$  于相关集合上, 则

$$\frac{\rho_k}{2} \|h(x_k)\|_2^2 \leq f(x^*) - \underline{f}. \quad (28.172)$$

所以

$$\|h(x_k)\|_2 \leq \sqrt{\frac{2(f(x^*) - \underline{f})}{\rho_k}} \rightarrow 0. \quad (28.173)$$

若子列  $x_{k_j} \rightarrow \bar{x}$ , 由连续性  $h(\bar{x}) = 0$ . 又由 式 (28.171):  $f(x_{k_j}) \leq f(x^*)$ . 取极限:  $f(\bar{x}) \leq f(x^*)$ . 因  $x^*$  已为全局最优解, 故  $f(\bar{x}) = f(x^*)$ .  $\square$

注 28.17 (局部正则情形下可有更快的约束违反阶). 全局比较通常只直接给出  $\|h(x_\rho)\| = O(\rho^{-1/2})$ . 若存在正则 KKT 点, 且罚函数驻点沿平滑分支逼近该 KKT 点, 则由  $\lambda_\rho = \rho h(x_\rho) \rightarrow \lambda^*$  可进一步得到  $h(x_\rho) = O(\rho^{-1})$ .

#### 28.10.4 知识点四十二: 二次罚函数不是有限参数精确的

反例 28.18 (二次罚函数的极小点通常不可行). 考虑

$$\min_{x \in \mathbb{R}} x \quad \text{subject to} \quad x = 0. \quad (28.174)$$

约束问题唯一可行解为  $x^* = 0$ .

二次罚函数为  $P_\rho(x) = x + \frac{\rho}{2}x^2$ . 其驻点满足  $1 + \rho x = 0$ , 故

$$x_\rho = -\frac{1}{\rho}. \quad (28.175)$$

对任意有限  $\rho$ , 都有  $x_\rho \neq 0$ . 只有当  $\rho \rightarrow +\infty$  时才有  $x_\rho \rightarrow 0$ .

#### 28.10.5 知识点四十三: 罚参数导致的条件数恶化

对等式二次罚函数, Hessian 为

$$\begin{aligned} \nabla^2 P_\rho(x) &= \nabla^2 f(x) + \rho J_h(x)^\top J_h(x) \\ &\quad + \rho \sum_{j=1}^p h_j(x) \nabla^2 h_j(x). \end{aligned} \quad (28.176)$$

若  $x$  接近可行点, 最后一项通常较小, 主导项为  $\nabla^2 f(x) + \rho J_h(x)^\top J_h(x)$ .

在约束法向方向上, 特征值可能增长为  $O(\rho)$ ; 而在切向方向上, 特征值仍可能保持  $O(1)$ . 因此条件数常满足

$$\kappa(\nabla^2 P_\rho) = O(\rho). \quad (28.177)$$

这解释了:

- $\rho$  越大, 可行性越好;
- 但内层无约束问题越病态;
- 不能一次把  $\rho$  设为极大数;
- 需要逐步增大并使用预条件或增广 Lagrange 方法。



28.10.6 知识点四十四：精确  $\ell^1$  罚函数

定义

$$P_{\rho}^{\text{exact}}(x) = f(x) + \rho \sum_{i=1}^m [g_i(x)]_+ + \rho \sum_{j=1}^p |h_j(x)|. \quad (28.178)$$

该函数一般不可微，但在适当条件下具有有限参数精确性。

定理 28.19 (凸问题的精确罚性质). 设原问题为凸问题,  $(x^*, \lambda^*, \nu^*)$  满足 KKT。若

$$\rho \geq \max \{ \|\lambda^*\|_{\infty}, \|\nu^*\|_{\infty} \}, \quad (28.179)$$

则  $x^*$  也是式 (28.178) 的全局极小点。

若不等式严格大于乘子范数，通常可获得更稳定的局部精确性结论。

证明. 由凸性和 KKT 条件,  $x^*$  全局最小化 Lagrange 函数  $\mathcal{L}(x, \lambda^*, \nu^*)$ 。所以

$$f(x) + \lambda^{*\top} g(x) + \nu^{*\top} h(x) \geq f(x^*). \quad (28.180)$$

对任意实数  $a$  和  $\lambda_i^* \geq 0$ , 若  $\rho \geq \lambda_i^*$ , 则

$$\rho[a]_+ \geq \lambda_i^* a. \quad (28.181)$$

因为:

- 若  $a \geq 0$ , 则  $\rho a \geq \lambda_i^* a$ ;
- 若  $a < 0$ , 则  $0 \geq \lambda_i^* a$ .

同理, 若  $\rho \geq |\nu_j^*|$ , 则  $\rho|h_j(x)| \geq \nu_j^* h_j(x)$ 。

因此

$$\begin{aligned} P_{\rho}^{\text{exact}}(x) &\geq f(x) + \lambda^{*\top} g(x) + \nu^{*\top} h(x) \\ &\geq f(x^*) \\ &= P_{\rho}^{\text{exact}}(x^*). \end{aligned} \quad (28.182)$$

□

#### 易错点与反例

精确罚函数的“精确”是指:

存在有限的罚参数阈值, 使原问题最优点也是罚问题最优点。

它不表示:

- 任意有限  $\rho$  都精确;
- 罚函数光滑;
- 任意局部极小点都自动对应可行解;
- 数值算法无需检查约束残差。

## 28.10.7 外罚函数算法

### Algorithm 94 二次外罚函数法

**Input:** 约束问题  $\min f(x)$  s.t.  $g(x) \leq 0, h(x) = 0$ ; 初值  $x_0$ ; 初始罚参数  $\rho_0 > 0$ ; 增长因子  $\gamma > 1$ ; 可行性容差  $\varepsilon_{\text{feas}}$

**Output:** 近似可行驻点

1: **Initialization:** 令  $k \leftarrow 0$

2: **loop**

3: 近似求解无约束子问题  $x_{k+1} \approx \arg \min_x \left[ f(x) + \frac{\rho_k}{2} \|[g(x)]_+\|_2^2 + \frac{\rho_k}{2} \|h(x)\|_2^2 \right]$

4: 计算约束违反  $v_{k+1} = \sqrt{\|[g(x_{k+1})]_+\|_2^2 + \|h(x_{k+1})\|_2^2}$

5: **if**  $v_{k+1} \leq \varepsilon_{\text{feas}}$  且罚函数驻点残差足够小 **then**

6: 输出  $x_{k+1}$

7: **stop**

8: **end if**

9:  $\rho_{k+1} \leftarrow \gamma \rho_k$

10: 以上一子问题解作为下一子问题初值

11:  $k \leftarrow k + 1$

12: **end loop**

13: **Stopping criterion:** 同时检查:

$$\|h(x_k)\|, \quad \|[g(x_k)]_+\|, \quad \|\nabla P_{\rho_k}(x_k)\|.$$

只检查罚函数梯度不足以保证原问题近似可行

14: **Complexity:** 外层次数取决于罚参数增长率; 内层成本由无约束求解器决定。随着  $\rho_k$  增大, Hessian 条件数通常恶化, 内层迭代次数可能显著增加

## 28.11 障碍函数: 与外罚法的区别及非线性约束形式

### 28.11.1 知识点四十五: 非线性约束的对数障碍

第 27 部分已系统推导线性规划中心路径和原始-对偶内点法。本节只从一般非线性优化的全局化角度说明障碍函数与罚函数的差别。

对  $g_i(x) \leq 0$  定义对数障碍子问题

$$\begin{aligned} & \text{minimize} \quad \phi_\mu(x) = f(x) - \mu \sum_{i=1}^m \log(-g_i(x)), \\ & \text{subject to} \quad h(x) = 0, \end{aligned} \tag{28.183}$$

其中  $\mu > 0, g_i(x) < 0$ 。

当  $\mu \downarrow 0$  时, 障碍影响减弱, 中心点逼近原问题最优点。


若定义

$$\lambda_i(\mu) = \frac{\mu}{-g_i(x(\mu))}, \tag{28.184}$$

则

$$-\lambda_i(\mu)g_i(x(\mu)) = \mu. \tag{28.185}$$

这正是扰动互补条件。



## 28.11.2 知识点四十六：障碍 Hessian

障碍梯度为

$$\nabla \phi_\mu(x) = \nabla f(x) + \mu \sum_i \frac{\nabla g_i(x)}{-g_i(x)}. \quad (28.186)$$

Hessian 为

$$\begin{aligned} \nabla^2 \phi_\mu(x) = & \nabla^2 f(x) + \mu \sum_i \frac{\nabla^2 g_i(x)}{-g_i(x)} \\ & + \mu \sum_i \frac{\nabla g_i(x) \nabla g_i(x)^\top}{g_i(x)^2}. \end{aligned} \quad (28.187)$$

当某个约束接近边界： $g_i(x) \uparrow 0$ ，最后一项可能迅速增大，导致显著尺度差异和条件数恶化。

## 28.11.3 知识点四十七：罚函数与障碍函数的严格区分

| 比较对象  | 外罚函数                             | 障碍函数                                                 |
|-------|----------------------------------|------------------------------------------------------|
| 迭代点位置 | 可在可行域外                           | 必须位于严格可行域内                                           |
| 典型形式  | $f + \frac{\rho}{2} \ [g]_+\ ^2$ | $f - \mu \sum_i \log(-g_i)$                          |
| 参数极限  | $\rho \rightarrow +\infty$       | $\mu \downarrow 0$ 或 $t = 1/\mu \rightarrow +\infty$ |
| 边界行为  | 违反约束时受罚                          | 接近边界时函数趋于 $+\infty$                                  |
| 初始点   | 通常不要求可行                          | 通常要求严格可行                                             |
| 可行性性质 | 有限 $\rho$ 时通常不可行                 | 每个障碍迭代点严格满足不等式                                       |
| 主要病态性 | 大 $\rho$ 导致法向曲率过大                | 靠近边界时障碍曲率过大                                          |
| 典型输出  | 从外部逼近可行集                         | 沿内部中心路径逼近边界最优点                                       |

## 易错点与反例

不得把参数方向写反：

二次罚函数： $\rho \rightarrow +\infty$ ； 对数障碍： $\mu \downarrow 0$ 。

## 28.12 增广 Lagrange 方法

## 28.12.1 知识点四十八：等式约束增广 Lagrange 函数

对  $\min f(x) \quad \text{s.t.} \quad h(x) = 0$  定义增广 Lagrange 函数

$$\mathcal{L}_\rho(x, \lambda) = f(x) + \lambda^\top h(x) + \frac{\rho}{2} \|h(x)\|_2^2. \quad (28.188)$$

其关于  $x$  的梯度为

$$\nabla_x \mathcal{L}_\rho(x, \lambda) = \nabla f(x) + J_h(x)^\top [\lambda + \rho h(x)]. \quad (28.189)$$

与纯二次罚函数相比，乘子  $\lambda$  显式表示约束反力。若  $\lambda$  逐渐逼近  $\lambda^*$ ，通常无需令  $\rho$  无限增大。



### 28.12.2 知识点四十九：乘子法

基本乘子法为

$$x_{k+1} \approx \arg \min_x \mathcal{L}_{\rho_k}(x, \lambda_k), \quad (28.190)$$

$$\lambda_{k+1} = \lambda_k + \rho_k h(x_{k+1}). \quad (28.191)$$

乘子更新可理解为：

$$\lambda_{k+1} = \lambda_k + \text{罚参数} \times \text{约束残差}. \quad (28.192)$$

在  $x_{k+1}$  为精确内层极小点时， $\nabla_x \mathcal{L}_{\rho_k}(x_{k+1}, \lambda_k) = 0$ 。结合乘子更新：

$$0 = \nabla f(x_{k+1}) + J_h(x_{k+1})^\top \lambda_{k+1}. \quad (28.193)$$

因此每个精确内层解和新乘子已经满足 KKT 驻点条件，剩余误差主要是  $h(x_{k+1})$ 。

### 28.12.3 知识点五十：与对偶近端点法的关系

对凸等式约束问题，定义对偶函数

$$d(\lambda) = \inf_x [f(x) + \lambda^\top h(x)]. \quad (28.194)$$

精确乘子法可解释为在凹对偶函数上执行近端点法：

$$\lambda_{k+1} \in \arg \max_{\lambda} \left[ d(\lambda) - \frac{1}{2\rho_k} \|\lambda - \lambda_k\|_2^2 \right]. \quad (28.195)$$

这一解释说明：

- 固定的有限  $\rho > 0$  也可能收敛；
- 增广项改善了对偶函数的可处理性；
- 乘子法本质上不只是“更复杂的罚函数法”；
- 内层极小化精度直接影响外层近端步精度。

### 28.12.4 知识点五十一：不等式约束增广 Lagrange 函数

对  $g_i(x) \leq 0$ ,  $\lambda_i \geq 0$ , Powell–Hestenes–Rockafellar 形式为


$$\mathcal{L}_\rho(x, \lambda) = f(x) + \frac{1}{2\rho} \sum_{i=1}^m ([\lambda_i + \rho g_i(x)]_+^2 - \lambda_i^2). \quad (28.196)$$

乘子更新为

$$\lambda_i^{k+1} = [\lambda_i^k + \rho_k g_i(x_{k+1})]_+. \quad (28.197)$$

该更新自动保持  $\lambda_i^{k+1} \geq 0$ 。

若约束长期严格不活跃，则  $\lambda_i^k + \rho_k g_i(x_{k+1}) < 0$  时会得到  $\lambda_i^{k+1} = 0$ ，与互补松弛一致。





### 28.12.5 知识点五十二：增广 Lagrange 的局部与全局收敛

凸仿射约束。 若：

- $f$  闭、真、凸；
- $h(x) = Ax - b$ ；
- 原始与对偶最优解存在；
- 每个内层子问题精确求解；
- $\rho_k$  有正下界；

则乘子法可由对偶近端点理论得到全局收敛，并有  $Ax_k - b \rightarrow 0$ 。

一般非凸问题。 若：

- 存在满足 LICQ 的 KKT 点；
- 二阶充分条件成立；
- 初值和乘子充分接近；
- 内层问题求解足够准确；
- $\rho$  充分大但有限；

则可得局部收敛。

固定  $\rho$  时通常为线性收敛；增大  $\rho$  可改善外层收敛率，但也可能使内层问题条件数恶化。

### 28.12.6 知识点五十三：内层停止准则

不应在每个外层步骤中把内层问题求到机器精度。常用非精确停止条件为

$$\|\nabla_x \mathcal{L}_{\rho_k}(x_{k+1}, \lambda_k)\|_2 \leq \varepsilon_k, \quad \varepsilon_k \downarrow 0. \quad (28.198)$$

外层同时检查：

$$\|h(x_{k+1})\|_2 \leq \varepsilon_{\text{feas}}, \quad (28.199)$$

$$\|\nabla f(x_{k+1}) + J_h(x_{k+1})^\top \lambda_{k+1}\|_2 \leq \varepsilon_{\text{stat}}. \quad (28.200)$$

对不等式约束还要检查：


$$\|[g(x)]_+\|_2, \quad \|[-\lambda]_+\|_2, \quad \|\lambda \odot g(x)\|_2. \quad (28.201)$$

### 28.12.7 增广 Lagrange 算法

**Algorithm 95** 等式约束增广 Lagrange 乘子法

**Input:** 问题  $\min f(x)$  s.t.  $h(x) = 0$ ; 初值  $x_0, \lambda_0$ ; 初始参数  $\rho_0 > 0$ ; 容差  $\varepsilon_{\text{feas}}, \varepsilon_{\text{stat}} > 0$

**Output:** 近似 KKT 点  $(x, \lambda)$



- 1: **Initialization:** 令  $k \leftarrow 0$
- 2: **loop**
- 3:   近似求解  $x_{k+1} \approx \arg \min_x \left[ f(x) + \lambda_k^\top h(x) + \frac{\rho_k}{2} \|h(x)\|_2^2 \right]$  使  $\|\nabla_x \mathcal{L}_{\rho_k}(x_{k+1}, \lambda_k)\|_2 \leq \varepsilon_k$
- 4:   更新乘子  $\lambda_{k+1} = \lambda_k + \rho_k h(x_{k+1})$
- 5:   计算  $r_{p,k+1} = h(x_{k+1})$
- 6:   计算  $r_{d,k+1} = \nabla f(x_{k+1}) + J_h(x_{k+1})^\top \lambda_{k+1}$
- 7:   **if**  $\|r_{p,k+1}\|_2 \leq \varepsilon_{\text{feas}}$  且  $\|r_{d,k+1}\|_2 \leq \varepsilon_{\text{stat}}$  **then**
- 8:     输出  $(x_{k+1}, \lambda_{k+1})$
- 9:   **stop**
- 10: **end if**
- 11: **if** 约束残差下降不足 **then**
- 12:    $\rho_{k+1} \leftarrow \gamma \rho_k, \gamma > 1$
- 13: **else**
- 14:    $\rho_{k+1} \leftarrow \rho_k$
- 15: **end if**
- 16:   减小内层容差  $\varepsilon_{k+1}$
- 17:    $k \leftarrow k + 1$
- 18: **end loop**
- 19: **Stopping criterion:** 必须同时控制 KKT 原始残差和驻点残差。只检查增广 Lagrange 函数梯度不足以证明原问题可行
- 20: **Complexity:** 每个外层步骤需解一个无约束子问题。若采用 Newton 法, 每个内层 Newton 步需要求解  $\nabla_{xx}^2 \mathcal{L}_{\rho_k} p = -\nabla_x \mathcal{L}_{\rho_k}$ 。稠密成本通常为  $O(n^3)$ , 稀疏成本由矩阵结构和预条件器决定

## 28.13 增广 Lagrange 方法的完整计算例题

完整题目叙述: 标量乘子法的显式收敛率

考虑等式约束问题

$$\begin{aligned} & \text{minimize} \quad \frac{1}{2}(x-2)^2, \\ & \text{subject to} \quad x = 1. \end{aligned} \tag{28.202}$$

给定固定罚参数  $\rho > 0$ , 使用精确增广 Lagrange 乘子法:

$$x_{k+1} = \arg \min_x \left[ \frac{1}{2}(x-2)^2 + \lambda_k(x-1) + \frac{\rho}{2}(x-1)^2 \right], \tag{28.203}$$

$$\lambda_{k+1} = \lambda_k + \rho(x_{k+1} - 1). \tag{28.204}$$

求:

- (1) 原问题 KKT 解;
- (2)  $x_{k+1}$  和  $\lambda_{k+1}$  的显式公式;
- (3) 乘子的收敛因子;
- (4) 原始约束残差的收敛率。

证明. 原问题的 Lagrange 函数为  $\mathcal{L}(x, \lambda) = \frac{1}{2}(x-2)^2 + \lambda(x-1)$ 。KKT 条件为

$$x - 2 + \lambda = 0, \quad (28.205)$$

$$x - 1 = 0. \quad (28.206)$$

故

$$\boxed{x^* = 1, \lambda^* = 1}. \quad (28.207)$$

对 式 (28.203) 求导:  $x - 2 + \lambda_k + \rho(x - 1) = 0$ 。因此

$$\boxed{x_{k+1} = \frac{2 + \rho - \lambda_k}{1 + \rho}}. \quad (28.208)$$

约束残差为

$$\begin{aligned} x_{k+1} - 1 &= \frac{2 + \rho - \lambda_k - (1 + \rho)}{1 + \rho} \\ &= \frac{1 - \lambda_k}{1 + \rho}. \end{aligned} \quad (28.209)$$

乘子更新:

$$\begin{aligned} \lambda_{k+1} &= \lambda_k + \rho \frac{1 - \lambda_k}{1 + \rho} \\ &= \frac{\lambda_k + \rho}{1 + \rho}. \end{aligned} \quad (28.210)$$

减去  $\lambda^* = 1$ :

$$\begin{aligned} \lambda_{k+1} - 1 &= \frac{\lambda_k + \rho - (1 + \rho)}{1 + \rho} \\ &= \frac{1}{1 + \rho}(\lambda_k - 1). \end{aligned} \quad (28.211)$$

故乘子  $q$ -线性收敛, 收敛因子为

$$\boxed{q_\lambda = \frac{1}{1 + \rho}}. \quad (28.212)$$

显式地,


$$\lambda_k - 1 = \left( \frac{1}{1 + \rho} \right)^k (\lambda_0 - 1). \quad (28.213)$$

由 式 (28.209):

$$\begin{aligned} x_{k+1} - 1 &= -\frac{1}{1 + \rho}(\lambda_k - 1) \\ &= -\left( \frac{1}{1 + \rho} \right)^{k+1} (\lambda_0 - 1). \end{aligned} \quad (28.214)$$

因此原始变量和约束残差也以因子  $\frac{1}{1+\rho}$  线性收敛。

本例中  $\rho$  越大, 外层因子越小。但在高维问题中, 大  $\rho$  会使内层 Hessian  $\nabla^2 f + \rho J_h^\top J_h$  更病态, 故不能只依据本标量例子无条件增大  $\rho$ 。□



## 28.14 算法比较、条件数、数值稳定性与失败情形

| 方法          | 主要模型              | 局部速度                    | 主要优势               | 典型失败情形                 |
|-------------|-------------------|-------------------------|--------------------|------------------------|
| 梯度下降        | 一阶线性模型            | 强凸时线性                   | 成本低, 适合大规模         | 条件数大时锯齿和缓慢             |
| 纯 Newton    | 精确二次模型            | 二次                      | 局部极快               | 初值远, Hessian 不定或奇异     |
| 阻尼 Newton   | Newton 方向加线搜索     | 最终二次                    | 兼顾全局化与局部速度         | 线搜索成本和 Hessian 分解成本高   |
| BFGS        | 割线近似 Hessian      | 通常超线性                   | 无需显式二阶导数           | 曲率条件失败; 稠密存储 $O(n^2)$  |
| L-BFGS      | 有限记忆割线更新          | 通常快于一阶法, 不统一保证完整 BFGS 阶 | 存储 $O(rn)$         | 病态或强非凸时方向质量差           |
| 信赖域 Newton  | 球内二次模型            | 最终二次                    | 可处理不定 Hessian 和负曲率 | 子问题求解成本; 半径更新不当        |
| 二次罚函数       | 目标加约束平方           | 外层依参数                   | 实现简单, 不需可行初点       | $\rho$ 大时严重病态; 有限参数不精确 |
| 精确罚函数       | 目标加 $\ell^1$ 约束违反 | 依内层非光滑算法                | 有限罚参数可精确           | 不可微; 阈值依赖乘子            |
| 对数障碍        | 严格可行域内部模型         | 路径跟踪                    | 保持不等式严格可行          | 需要严格可行初点; 近边界病态        |
| 增广 Lagrange | Lagrange 函数加二次增广  | 固定参数可线性, 局部可加速          | 通常不需罚参数趋无穷         | 内层求解不准; 乘子或参数更新不当      |

### 28.14.1 知识点五十四：问题条件数与算法稳定性

优化问题的局部条件性可由最优点 Hessian 刻画。对无约束强凸问题, 若  $H^* = \nabla^2 f(x^*) \succ 0$ , 则驻点方程  $\nabla f(x) = 0$  在小扰动下的局部灵敏度与  $\|(H^*)^{-1}\|$  有关。

若  $\lambda_{\min}(H^*)$  很小, 则:

- 最优点对梯度扰动敏感;
- Newton 方向对舍入误差敏感;
- 拟 Newton 曲率信息难以可靠估计;
- 停止条件中的小梯度不一定意味着小位置误差。

在强凸情形, 有

$$\|x - x^*\|_2 \leq \frac{1}{m} \|\nabla f(x)\|_2, \quad \nabla^2 f \succeq mI. \quad (28.215)$$

若没有强凸下界  $m > 0$ , 仅凭  $\|\nabla f(x)\| \ll 1$  不能可靠估计  $\|x - x^*\|$ 。



### 28.14.2 知识点五十五：Newton 线性系统的数值误差

Newton 方向满足  $G_k p_k = -g_k$ 。若计算方向  $\hat{p}_k$  满足  $(G_k + \delta G_k) \hat{p}_k = -(g_k + \delta g_k)$ , 则一阶相对误差受  $\kappa_2(G_k)$  放大。

因此:

- 不应显式求逆;
- 正定矩阵优先用 Cholesky;
- 对称不定 KKT 矩阵用带主元  $LDL^T$ ;
- 大型稀疏系统应使用预条件 Krylov 方法;
- 需要重新计算真实残差  $r_k = G_k \hat{p}_k + g_k$ ;
- 必要时使用迭代改进。

### 28.14.3 知识点五十六：尺度不变性与变量缩放

若变量不同分量尺度相差很大, 例如  $x_1 = O(10^{-6})$ ,  $x_2 = O(10^6)$ , 则 Euclidean 范数下的:

- 信赖域球;
- 梯度范数停止准则;
- Hessian 条件数;
- 罚参数作用;

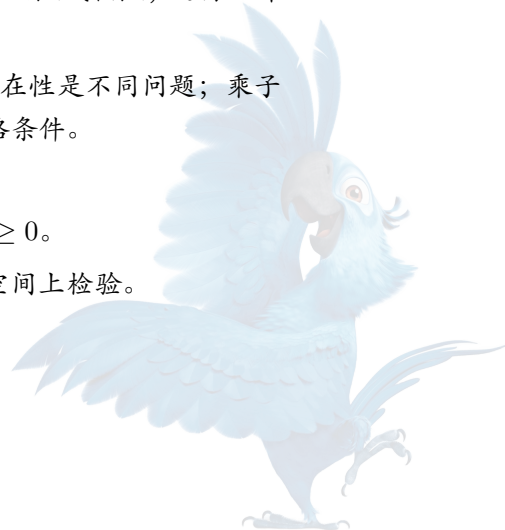
可能失去合理物理意义。

可令  $x = Dz$  进行变量缩放, 或使用加权信赖域  $\|D_k p\|_2 \leq \Delta_k$ 。

约束也应进行行缩放, 避免某一约束仅因量纲较大而主导罚函数。

## 28.15 本部分易错点与完整答题规范

| 错误说法或错误做法                       | 正确处理                                         |
|---------------------------------|----------------------------------------------|
| KKT 条件对所有局部极小点无条件成立。            | 一般需要 LICQ、MFCQ 或其他约束资格条件。                    |
| KKT 点一定是局部极小点。                  | 非凸问题中 KKT 点可能是极大点或鞍点; 还需二阶条件。                |
| 凸问题无需讨论约束资格条件。                  | KKT 充分性与 KKT 乘子存在性是不同问题; 乘子存在通常需强对偶或约束资格条件。  |
| 等式约束乘子必须非负。                     | 等式约束乘子是自由变量。                                 |
| 不等式乘子符号与约束方向无关。                 | 若统一写成 $g_i \leq 0$ , 才有 $\lambda_i \geq 0$ 。 |
| 二阶条件要求 Lagrange Hessian 在全空间正定。 | 只需在临界锥或等式约束切空间上检验。                           |



| 错误说法或错误做法                                    | 正确处理                                                      |
|----------------------------------------------|-----------------------------------------------------------|
| Newton 法全局二次收敛。                              | Newton 法通常只有局部二次收敛；全局化需线搜索或信赖域。                           |
| Newton 方程可解就说明方向下降。                          | 只有 Hessian 或修正矩阵正定时才能直接保证下降。                              |
| 显式计算 $G_k^{-1}$ 再乘梯度。                        | 应直接求解线性方程 $G_k p_k = -g_k$ 。                              |
| Armijo 条件越严格越好。                              | 过严参数会导致步长过小；标准取 $0 < c_1 \ll 1$ 。                         |
| 只使用 Armijo 即可保证 BFGS 曲率条件。                   | 通常使用 Wolfe 曲率条件保证 $s_k^\top y_k > 0$ 。                    |
| BFGS 只需割线条件，不需曲率条件。                          | 正定性保持需要 $s_k^\top y_k > 0$ 。                              |
| BFGS 是二次收敛。                                  | 标准结论通常是局部超线性，而非二次。                                        |
| Broyden 法和 BFGS 是同一算法。                       | 前者主要逼近非线性方程 Jacobian，后者逼近优化 Hessian 并保持对称正定。              |
| 信赖域要求 Hessian 正定。                            | 即使 Hessian 不定，球约束仍保证子问题有解。                                |
| 信赖域比值只看目标是否下降。                               | 应比较实际下降与模型预测下降。                                           |
| 二次罚函数存在有限精确罚参数。                              | 一般需 $\rho \rightarrow \infty$ ；有限参数精确性属于 $\ell^1$ 类精确罚函数。 |
| 罚参数越大，数值效果必然越好。                              | 可行性改善，但 Hessian 条件数通常恶化。                                  |
| 罚函数与障碍函数都是约束平方项。                             | 罚函数通常从可行域外逼近；障碍函数只在严格可行域内部定义。                             |
| 对数障碍令参数 $\mu \rightarrow \infty$ 。           | 采用 $f - \mu \sum \log(-g_i)$ 时应令 $\mu \downarrow 0$ 。     |
| 增广 Lagrange 法必须令 $\rho \rightarrow \infty$ 。 | 在适当条件下固定有限 $\rho$ 即可收敛。                                   |
| 增广 Lagrange 内层梯度小即可停止全部算法。                   | 还必须检查约束残差和 KKT 驻点残差。                                      |
| Sobolev 泛函中的形式微分自动就是 Fréchet 导数。             | 必须用 Sobolev 嵌入和 Hölder 估计验证有界性及余项。                        |
| $J'(u)$ 与 $\nabla J(u)$ 不依赖内积。               | $J'(u) \in V^*$ 内在定义；Hilbert 梯度取决于 Riesz 内积。              |

#### KKT 题：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 题目有等式或不等式约束；
- 要求判断候选点是否最优；
- 要求求 Lagrange 乘子；
- 要求讨论凸问题的全局最优性；
- 要求写二阶条件。

构造步骤：

1. 将不等式统一写成  $g_i \leq 0$ ;
2. 写 Lagrange 函数;
3. 写原始可行性;
4. 写乘子非负性;
5. 写驻点条件;
6. 写逐项互补松弛;
7. 枚举或识别活跃约束;
8. 求解候选点和乘子;
9. 检查约束资格条件;
10. 用凸性或二阶充分条件判定最优性。

关键估计:

凸问题中  $f(x) \geq f(x^*) + \nabla f(x^*)^\top (x - x^*) \geq f(x^*)$ 。

结论: 一般问题得到局部必要条件; 凸问题中 KKT 可作为全局最优证书。

失败原因:

- 乘子符号错误;
- 漏写互补松弛;
- 未验证可行性;
- 未讨论约束资格条件;
- 非凸问题中把 KKT 误当充分条件。

#### Newton 与 BFGS 题: 识别信号—构造步骤—关键估计—结论—失败原因

识别信号:

- 目标二次可微;
- 题目要求局部二次或超线性收敛;
- 出现 Hessian、割线条件、曲率条件;
- 需要线搜索或信赖域全局化。

Newton 构造:

1. 写二次 Taylor 模型;
2. 求解  $G_k p_k = -g_k$ ;
3. 检查  $G_k$  正定性;
4. 必要时作正定修正;
5. 使用 Armijo 或 Wolfe 线搜索;
6. 局部证明用积分余项和 Hessian Lipschitz 性。



### BFGS 构造:

1. 定义  $s_k = x_{k+1} - x_k$ ,  $y_k = g_{k+1} - g_k$ ;
2. 检查  $s_k^\top y_k > 0$ ;
3. 写秩二更新;
4. 验证割线条件;
5. 用 Cauchy-Schwarz 证明正定性;
6. 说明局部超线性而非二次。

关键估计:

Newton:  $\|e_{k+1}\| \leq C \|e_k\|^2$ 。

BFGS:  $s_k^\top y_k > 0$ ,  $\frac{\|(B_k - G^*)s_k\|}{\|s_k\|} \rightarrow 0$ 。

失败原因:

- Hessian 不定;
- 线性系统病态;
- 步长过小;
- 曲率条件失败;
- 初值不在局部收敛域;
- 把求根 Newton 法与优化 Newton 法混用。

### 罚函数、障碍函数和增广 Lagrange: 识别信号—构造步骤—关键估计—结论—失败原因

识别信号:

- 题目要求将约束问题转成无约束问题;
- 需要讨论罚参数极限;
- 需要解释条件数恶化;
- 需要构造乘子更新。

二次罚函数:

$$P_\rho = f + \frac{\rho}{2} \|h\|^2 + \frac{\rho}{2} \|[g]_+\|^2, \quad \rho \rightarrow \infty.$$

精确罚函数:

$$P_\rho^{\text{exact}} = f + \rho \|h\|_1 + \rho \sum [g_i]_+.$$

障碍函数:

$$\phi_\mu = f - \mu \sum_i \log(-g_i), \quad \mu \downarrow 0.$$

增广 Lagrange:

$$\mathcal{L}_\rho = f + \lambda^\top h + \frac{\rho}{2} \|h\|^2, \quad \lambda_{k+1} = \lambda_k + \rho h(x_{k+1}).$$

关键估计:

$\|h(x_\rho)\| = O(\rho^{-1/2})$  为基本全局估计;

正则局部分支中可有  $h(x_\rho) = O(\rho^{-1})$ 。

失败原因:



- 参数极限方向写反；
- 罚参数过大导致病态；
- 障碍法没有严格可行初点；
- 只解内层问题而不更新乘子；
- 只检查目标值，不检查 KKT 残差。



## 第二十九章 同伦、不动点、投影梯度、近端方法、 $\ell^1$ 优化、动态规划与总索引

### 29.1 优化同伦、参数连续化与路径跟踪

#### 29.1.1 知识点一：参数化问题与路径方程

【重要性等级】 **A 级**。

同伦或连续化方法 (homotopy/continuation method) 通过引入参数  $\tau \in [0, 1]$  将一个容易求解的问题逐渐变形为目标问题。

一般形式为

$$H(z, \tau) = 0, \quad z \in \mathbb{R}^N, \quad \tau \in [0, 1], \quad (29.1)$$

其中：

- $H(z, 0) = 0$  为容易求解的起始问题；
- $H(z, 1) = 0$  为目标问题；
- 希望构造连续或光滑路径  $\tau \mapsto z(\tau)$  满足  $H(z(\tau), \tau) = 0$ .

优化问题中的常见连续化包括：

1. 目标函数连续化

$$F_\tau(x) = (1 - \tau)F_0(x) + \tau F_1(x); \quad (29.2)$$

2. 平滑参数连续化  $F_\mu(x) \rightarrow F(x)$ ,  $\mu \downarrow 0$ ;

3. 障碍参数连续化  $\mu \downarrow 0$  或  $t = 1/\mu \uparrow +\infty$ ;

4. 正则化路径  $\lambda \mapsto x^*(\lambda)$  用于岭回归、Lasso 和稀疏恢复；

5. KKT 系统连续化  $H(x, \lambda, \nu; \tau) = 0$ .

#### 29.1.2 知识点二：隐函数定理与路径导数

设  $H \in C^1$ , 并且在路径点  $(z(\tau), \tau)$  处

$$H_z(z(\tau), \tau) \quad (29.3)$$

非奇异。

由隐函数定理，局部存在唯一光滑路径  $z(\tau)$ 。



对恒等式  $H(z(\tau), \tau) = 0$  求导:

$$H_z(z(\tau), \tau)z'(\tau) + H_\tau(z(\tau), \tau) = 0. \quad (29.4)$$

因此路径切向量满足

$$\boxed{z'(\tau) = -H_z(z(\tau), \tau)^{-1}H_\tau(z(\tau), \tau)}. \quad (29.5)$$

数值实现不应显式形成  $H_z^{-1}$ , 而应求解线性方程

$$H_z t = -H_\tau. \quad (29.6)$$

### 29.1.3 知识点三: 预测-校正方法

设已知路径点  $(z_k, \tau_k)$ 。

切线预测。先解  $H_z(z_k, \tau_k)t_k = -H_\tau(z_k, \tau_k)$ , 再取

$$z_{k+1}^p = z_k + \Delta\tau_k t_k, \quad \tau_{k+1} = \tau_k + \Delta\tau_k. \quad (29.7)$$

若路径二次可微, 则切线预测的局部路径误差为

$$z(\tau_{k+1}) - z_{k+1}^p = O(\Delta\tau_k^2). \quad (29.8)$$

**Newton 校正。** 固定  $\tau_{k+1}$ , 从预测点出发求解  $H(z, \tau_{k+1}) = 0$ 。Newton 迭代为

$$H_z(z^{(\ell)}, \tau_{k+1})\Delta z^{(\ell)} = -H(z^{(\ell)}, \tau_{k+1}), \quad (29.9)$$

$$z^{(\ell+1)} = z^{(\ell)} + \Delta z^{(\ell)}. \quad (29.10)$$

若预测点已进入 Newton 局部收敛域, 则校正迭代通常二次收敛。

---

#### Algorithm 96 参数同伦的预测-校正路径跟踪

---

**Input:**  $H(z, \tau)$ ; 起始解  $H(z_0, 0) = 0$ ; 初始参数步长  $\Delta\tau_0 > 0$ ; 校正容差  $\varepsilon_H$

**Output:** 目标参数  $\tau = 1$  处的近似解

```

1: Initialization: 令  $k \leftarrow 0$ ,  $\tau_0 \leftarrow 0$ 
2: while  $\tau_k < 1$  do
3:   令  $\Delta\tau_k \leftarrow \min\{\Delta\tau_k, 1 - \tau_k\}$ 
4:   解切向量方程  $H_z(z_k, \tau_k)t_k = -H_\tau(z_k, \tau_k)$ 
5:   预测  $z^p = z_k + \Delta\tau_k t_k$ ,  $\tau_{k+1} = \tau_k + \Delta\tau_k$ 
6:   从  $z^p$  出发, 对  $H(z, \tau_{k+1}) = 0$  作 Newton 校正
7:   if 校正允许迭代次数内达到  $\|H(z, \tau_{k+1})\|_2 \leq \varepsilon_H$  then
8:     接受校正点为  $z_{k+1}$ 
9:     若校正步数较少, 适当增大  $\Delta\tau_{k+1}$ 
10:     $k \leftarrow k + 1$ 
11:   else
12:     拒绝该步
13:     减小  $\Delta\tau_k$ , 重新预测
14:   end if
15: end while

```



16: **Stopping criterion:**  $\tau_k = 1, \|H(z_k, 1)\|_2 \leq \varepsilon_H$

17: **Complexity:** 每个参数步至少需要一次切向线性系统求解，并需要若干次 Newton 线性系统求解。稠密  $N \times N$  系统每次分解约为  $O(N^3)$ ，存储为  $O(N^2)$ ；稀疏问题取决于非零结构和分解填充

#### 29.1.4 知识点四：路径条件数与失败情形

路径对参数的敏感性受

$$\kappa_{\text{path}}(\tau) \sim \|H_z(z(\tau), \tau)^{-1}\|_2 \quad (29.11)$$

控制。

若  $\sigma_{\min}(H_z) \downarrow 0$ ，则：

- 路径切向量可能急剧增大；
- 固定参数步长的预测误差增大；
- Newton 校正域缩小；
- 线性系统变得病态；
- 路径可能出现折点、分叉或奇点。

固定  $\tau$  延拓不能跨越简单折点，因为在折点处  $H_z$  可能奇异。

#### 29.1.5 知识点五：伪弧长延拓

将  $w = \begin{pmatrix} z \\ \tau \end{pmatrix}$  作为统一未知量。设上一点为  $w_k$ ，单位切向量为  $t_k$ 。

伪弧长校正求解增广系统

$$\begin{cases} H(z, \tau) = 0, \\ t_k^\top (w - w_k) = \Delta s_k. \end{cases} \quad (29.12)$$

其 Newton 矩阵为

$$\begin{bmatrix} H_z & H_\tau \\ t_{k,z}^\top & t_{k,\tau} \end{bmatrix}. \quad (29.13)$$

即使  $H_z$  奇异，只要增广矩阵非奇异，仍可能通过折点。

#### 易错点与反例

下列说法错误：“同伦参数单调增加，因此解路径也必单调且无分叉。”

正确结论是：

- 参数可以单调变化，但解分量不必单调；
- 固定参数延拓可能在折点失效；
- 多解问题可能出现分支；
- 路径跟踪只能跟随所选分支，不能自动枚举全部解；
- 条件数恶化时必须缩小步长或改用伪弧长参数。

## 同伦路径题的标准分析框架

识别信号：题目给出参数化方程、正则化参数、障碍参数、连续模型或“从容易问题逐步过渡到目标问题”。

构造步骤：

1. 写出  $H(z, \tau) = 0$ ;
2. 验证起始点  $H(z_0, 0) = 0$ ;
3. 检查  $H_z$  非奇异性;
4. 对路径方程求导，构造切向量;
5. 切线预测;
6. Newton 校正;
7. 根据校正步数和条件数调整参数步长;
8. 若出现折点，改用伪弧长方程。

关键估计： $\|z(\tau + \Delta\tau) - z^p\| = O(\Delta\tau^2)$ ，以及  $\|H_z^{-1}\|$  对路径敏感性的控制。

结论：在路径正则、步长充分小且校正成功时，可逐段到达目标参数。

常见失败原因：Jacobian 奇异、分支切换、参数步长过大、初始问题选取不当、Newton 校正落入其他分支。

## 29.2 不动点映射、非扩张算子与优化最优性条件

### 29.2.1 知识点六：四类常用映射

设  $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 。其不动点集合为

$$\text{Fix}(T) = \{x : T(x) = x\}. \quad (29.14)$$

压缩映射。 若存在  $0 \leq q < 1$  使

$$\|T(x) - T(y)\|_2 \leq q \|x - y\|_2, \quad \forall x, y, \quad (29.15)$$

则  $T$  为压缩映射。

非扩张映射。 若

$$\|T(x) - T(y)\|_2 \leq \|x - y\|_2, \quad (29.16)$$


则  $T$  为非扩张映射。

牢固非扩张映射。 若

$$\|T(x) - T(y)\|_2^2 \leq \langle T(x) - T(y), x - y \rangle, \quad (29.17)$$

则  $T$  为牢固非扩张 (firmly nonexpansive) 映射。

由 Cauchy-Schwarz 不等式可知，牢固非扩张蕴含非扩张。



平均算子。若存在  $0 < \alpha < 1$  和非扩张映射  $R$ , 使

$$T = (1 - \alpha)I + \alpha R, \quad (29.18)$$

则称  $T$  为  $\alpha$ -平均算子。

牢固非扩张映射等价于  $\frac{1}{2}$ -平均算子。

### 29.2.2 知识点七：压缩映射定理与线性收敛

定理 29.1 (Banach 压缩映射定理). 设  $X$  是完备度量空间,  $T : X \rightarrow X$  是压缩映射, 压缩常数为  $q < 1$ . 则:

1.  $T$  存在唯一不动点  $x^*$ ;
2. 对任意初值  $x_0$ , 迭代  $x_{k+1} = T(x_k)$  收敛到  $x^*$ ;
3. 有先验误差估计

$$\|x_k - x^*\| \leq \frac{q^k}{1 - q} \|x_1 - x_0\|; \quad (29.19)$$

4. 有后验误差估计

$$\|x_k - x^*\| \leq \frac{q}{1 - q} \|x_k - x_{k-1}\|. \quad (29.20)$$

证明. 由压缩性,  $\|x_{k+1} - x_k\| \leq q^k \|x_1 - x_0\|$ . 故对  $m > k$ :

$$\begin{aligned} \|x_m - x_k\| &\leq \sum_{j=k}^{m-1} \|x_{j+1} - x_j\| \\ &\leq \sum_{j=k}^{m-1} q^j \|x_1 - x_0\| \\ &\leq \frac{q^k}{1 - q} \|x_1 - x_0\|. \end{aligned} \quad (29.21)$$

所以  $\{x_k\}$  为 Cauchy 列, 由完备性收敛到某个  $x^*$ .

由  $T$  连续:  $x^* = \lim x_{k+1} = \lim T(x_k) = T(x^*)$ . 若  $y^*$  也是不动点, 则  $\|x^* - y^*\| \leq q \|x^* - y^*\|$ , 故  $x^* = y^*$ .

令  $m \rightarrow \infty$  即得先验估计. 类似地,  $\|x_k - x^*\| \leq \sum_{j=k}^{\infty} \|x_{j+1} - x_j\| \leq \frac{q}{1-q} \|x_k - x_{k-1}\|$ , 得到后验估计.  $\square$

### 29.2.3 知识点八：平均映射的 Fejér 估计

若  $T$  为  $\alpha$ -平均映射, 则对任意  $z \in \text{Fix}(T)$  有

$$\|T(x) - z\|_2^2 \leq \|x - z\|_2^2 - \frac{1 - \alpha}{\alpha} \|x - T(x)\|_2^2. \quad (29.22)$$

因此, Picard 迭代  $x_{k+1} = T(x_k)$  满足:

- 到任意不动点的距离不减;
- $\sum_{k=0}^{\infty} \|x_k - T(x_k)\|_2^2 < \infty$ ;
- 因而  $\|x_k - T(x_k)\|_2 \rightarrow 0$ .



在有限维空间中, 若  $\text{Fix}(T) \neq \emptyset$ , 则平均映射的 Picard 迭代收敛到某个不动点。

注 29.2. 非扩张映射本身未必能直接作 Picard 迭代收敛。

例如  $T(x) = -x$  是非扩张映射, 唯一不动点为 0, 但当  $x_0 \neq 0$  时:  $x_{k+1} = -x_k$  在  $\pm x_0$  之间振荡。

可改用 Krasnosel'skiĭ–Mann 松弛:

$$x_{k+1} = (1 - \theta_k)x_k + \theta_k T(x_k), \quad 0 < \theta_k < 1. \quad (29.23)$$

#### 29.2.4 知识点九: 优化问题改写为不动点

光滑无约束问题。  $\nabla f(x^*) = 0$  等价于

$$x^* = x^* - \alpha \nabla f(x^*), \quad \alpha > 0. \quad (29.24)$$

光滑凸约束问题。 对闭凸集  $C$ ,  $x^* \in \arg \min_{x \in C} f(x)$  等价于

$$0 \in \nabla f(x^*) + N_C(x^*), \quad (29.25)$$

又等价于

$$x^* = P_C(x^* - \alpha \nabla f(x^*)), \quad \alpha > 0. \quad (29.26)$$

复合凸优化。 考虑

$$\min_x F(x) = f(x) + g(x), \quad (29.27)$$

其中  $f$  可微凸,  $g$  真闭凸。最优性条件  $0 \in \nabla f(x^*) + \partial g(x^*)$  等价于

$$x^* = \text{prox}_{\alpha g}(x^* - \alpha \nabla f(x^*)). \quad (29.28)$$

因此:

- 投影梯度是不动点迭代;
- 近端梯度是不动点迭代;
- 原始-对偶分裂法也可理解为扩大空间中的不动点迭代;
- 收敛性常由平均算子理论证明。

#### 易错点与反例

模块二中的不动点法通常直接构造  $x = T(x)$  求解非线性方程。

本模块中的不动点法通常先将  $0 \in \nabla f(x) + \partial g(x) + N_C(x)$  改写为投影或近端不动点。

二者共享压缩映射和非扩张映射工具, 但:

- 模块二重点是根的存在、局部收敛与 Jacobian;
- 本模块重点是单调算子、投影、近端映射和目标函数下降;
- 非扩张映射不一定具有唯一不动点;
- 优化算法往往只保证收敛到某个最优点。

## 29.3 补充训练题：丘赛 2021 Problem 3——标量压缩不动点迭代

完整题目叙述：[丘赛 2021 Problem 3]

定义  $f: \mathbb{R} \rightarrow \mathbb{R}$ ,  $f(x) = 2x - \cos x$ .(a) 证明方程  $f(x) = 0$  在区间  $(\frac{1}{4}, \frac{1}{2})$  中有唯一解  $x^*$ .(b) 证明对任意初值  $x_0$ , 不动点迭代

$$x_n = \frac{1}{2} \cos x_{n-1}, \quad n = 1, 2, \dots \quad (29.29)$$

收敛到  $x^*$ .(c) 当  $x_0 = \frac{\pi}{6}$  时, 确定一个  $n$ , 保证  $|x_n - x^*| < \frac{1}{2} \times 10^{-8}$ . 当  $x_0 = 20$  时, 确定一个  $n$ , 保证  $|x_n - x^*| < \frac{1}{4}$ .第 (a) 问: 存在唯一性. 有  $f'(x) = 2 + \sin x$ . 因为  $\sin x \geq -1$ , 所以

$$f'(x) \geq 1 > 0, \quad \forall x \in \mathbb{R}. \quad (29.30)$$

故  $f$  在  $\mathbb{R}$  上严格递增, 零点至多一个.在  $x = 1/4$  处, 利用  $\cos t \geq 1 - \frac{t^2}{2}$  得到  $\cos \frac{1}{4} \geq 1 - \frac{1}{32} = \frac{31}{32} > \frac{1}{2}$ . 因此  $f(\frac{1}{4}) = \frac{1}{2} - \cos \frac{1}{4} < 0$ .另一方面,  $\cos \frac{1}{2} < 1$ , 故  $f(\frac{1}{2}) = 1 - \cos \frac{1}{2} > 0$ .由介值定理, 存在  $x^* \in (\frac{1}{4}, \frac{1}{2})$  满足  $f(x^*) = 0$ . 由严格单调性, 该零点唯一.  $\square$ 第 (b) 问: 任意初值收敛. 令  $\phi(x) = \frac{1}{2} \cos x$ . 原方程  $2x - \cos x = 0$  等价于  $x = \phi(x)$ .

由中值定理,

$$\begin{aligned} |\phi(x) - \phi(y)| &= \frac{1}{2} |\cos x - \cos y| \\ &\leq \frac{1}{2} |x - y|. \end{aligned} \quad (29.31)$$

所以  $\phi: \mathbb{R} \rightarrow \mathbb{R}$  是压缩映射, 压缩常数可取  $q = \frac{1}{2}$ .由于  $\mathbb{R}$  完备, 由 Banach 压缩映射定理,  $\phi$  有唯一不动点, 且从任意  $x_0 \in \mathbb{R}$  出发, 迭代  $x_n = \phi(x_{n-1})$  均收敛到该不动点. 该不动点正是第 (a) 问的唯一零点  $x^*$ .  $\square$ 第 (c) 问: 误差步数. 由式 (29.19), 取  $q = \frac{1}{2}$ , 有

$$|x_n - x^*| \leq \frac{(1/2)^n}{1 - 1/2} |x_1 - x_0| = 2^{1-n} |x_1 - x_0|. \quad (29.32)$$

情形一:  $x_0 = \pi/6$ . 此时  $x_1 = \frac{1}{2} \cos \frac{\pi}{6} = \frac{\sqrt{3}}{4}$ . 故  $|x_1 - x_0| = \left| \frac{\sqrt{3}}{4} - \frac{\pi}{6} \right| \approx 9.05860737 \times 10^{-2}$ .要求  $2^{1-n} \left| \frac{\sqrt{3}}{4} - \frac{\pi}{6} \right| < 5 \times 10^{-9}$ . 等价于  $n > \log_2 \left( \frac{2 \left| \frac{\sqrt{3}}{4} - \frac{\pi}{6} \right|}{5 \times 10^{-9}} \right) \approx 25.1109$ . 因此可取

$$\boxed{n = 26}. \quad (29.33)$$

事实上,  $2^{-25} \left| \frac{\sqrt{3}}{4} - \frac{\pi}{6} \right| \approx 2.70 \times 10^{-9} < 5 \times 10^{-9}$ .



情形二:  $x_0 = 20$ 。此时  $x_1 = \frac{1}{2} \cos 20$  且  $|x_1 - x_0| = \left| \frac{1}{2} \cos 20 - 20 \right| \approx 19.79595897$ 。要求  $2^{1-n} \left| \frac{1}{2} \cos 20 - 20 \right| < \frac{1}{4}$ 。即  $n > \log_2 \left( 8 \left| \frac{1}{2} \cos 20 - 20 \right| \right) \approx 7.3071$ 。因此可取

$$\boxed{n = 8}. \quad (29.34)$$

这里的  $n = 26$  和  $n = 8$  是由全局压缩常数  $q = \frac{1}{2}$  及先验误差估计保证的最小整数；实际误差可能更小。□

## 29.4 补充训练题：丘赛 2022 Problem 2——二维 Gauss-Seidel 型不动点迭代

完整题目叙述：[丘赛 2022 Problem 2]

考虑二维不动点迭代

$$x_{k+1} = f(x_k, y_k), \quad y_{k+1} = g(x_k, y_k). \quad (1)$$

假设向量函数  $H(x, y) = \begin{pmatrix} f(x, y) \\ g(x, y) \end{pmatrix}$  连续可微，并且在唯一不动点  $(x_\infty, y_\infty)$  处满足

$$\|JH(x_\infty, y_\infty)\|_\infty < 1. \quad (29.35)$$

考虑新的迭代

$$x_{k+1} = f(x_k, y_k), \quad y_{k+1} = g(x_{k+1}, y_k). \quad (2)$$

证明：当初值充分接近不动点时，迭代 (2) 收敛到与迭代 (1) 相同的不动点。

证明。定义新映射

$$G(x, y) = \begin{pmatrix} f(x, y) \\ g(f(x, y), y) \end{pmatrix}. \quad (29.36)$$

迭代 (2) 正是  $z_{k+1} = G(z_k)$ ,  $z_k = (x_k, y_k)^\top$ 。

记在不动点处  $a = f_x$ ,  $b = f_y$ ,  $c = g_x$ ,  $d = g_y$ , 所有导数均在  $(x_\infty, y_\infty)$  处取值。

由  $\|JH\|_\infty < 1$  可得

$$|a| + |b| < 1, \quad (29.37)$$


$$|c| + |d| < 1. \quad (29.38)$$

对式 (29.36) 求 Jacobian:

$$JG(x, y) = \begin{pmatrix} f_x & f_y \\ g_x(f(x, y), y)f_x & g_x(f(x, y), y)f_y + g_y(f(x, y), y) \end{pmatrix}. \quad (29.39)$$

在不动点处，第一行绝对值行和为  $|a| + |b| < 1$ 。第二行绝对值行和满足

$$\begin{aligned} |ca| + |cb + d| &\leq |c||a| + |c||b| + |d| \\ &= |c|(|a| + |b|) + |d| \\ &< |c| + |d| < 1. \end{aligned} \quad (29.40)$$



因此

$$\|JG(x_\infty, y_\infty)\|_\infty < 1. \quad (29.41)$$

由  $JG$  连续, 存在闭球  $B_\delta(z_\infty) = \{z : \|z - z_\infty\|_\infty \leq \delta\}$  和常数  $q < 1$ , 使

$$\|JG(z)\|_\infty \leq q, \quad \forall z \in B_\delta(z_\infty). \quad (29.42)$$

由向量值中值定理, 对任意  $z, w \in B_\delta(z_\infty)$  有  $\|G(z) - G(w)\|_\infty \leq q \|z - w\|_\infty$ . 故  $G$  在该球上为压缩映射。

又因  $G(z_\infty) = z_\infty$ , 对任意  $z \in B_\delta(z_\infty)$ :  $\|G(z) - z_\infty\|_\infty \leq q \|z - z_\infty\|_\infty \leq q\delta < \delta$ . 所以  $G(B_\delta(z_\infty)) \subseteq B_\delta(z_\infty)$ .

由 Banach 压缩映射定理, 当初值位于该球内时, 迭代 (2) 收敛到  $G$  的唯一局部不动点。

最后验证两种迭代具有相同不动点集合。

若  $(x, y) = G(x, y)$ , 则  $x = f(x, y)$  且  $y = g(f(x, y), y) = g(x, y)$ . 故  $(x, y) = H(x, y)$ .

反之, 若  $x = f(x, y)$ ,  $y = g(x, y)$ , 则  $y = g(f(x, y), y)$ , 所以  $(x, y) = G(x, y)$ .

因此  $G$  和  $H$  具有相同不动点, 迭代 (2) 局部收敛到  $(x_\infty, y_\infty)$ .  $\square$

## 29.5 投影映射与投影梯度法

### 29.5.1 知识点十: 投影的最优性条件

设  $C \subseteq \mathbb{R}^n$  非空、闭、凸。对任意  $x$ , 投影  $p = P_C(x)$  唯一存在, 并满足

$$\langle x - p, z - p \rangle \leq 0, \quad \forall z \in C. \quad (29.43)$$

等价地,  $x - p \in N_C(p)$ 。

证明. 函数  $\varphi(z) = \frac{1}{2} \|z - x\|_2^2$  严格凸, 故极小点唯一。

凸约束问题的一阶最优性条件为  $\langle \nabla \varphi(p), z - p \rangle \geq 0, \quad \forall z \in C$ . 由于  $\nabla \varphi(p) = p - x$ , 得到式 (29.43).  $\square$

### 29.5.2 知识点十一: 投影的牢固非扩张性

令  $p = P_C(x)$ ,  $q = P_C(y)$ . 由投影最优性条件:

$$\langle x - p, q - p \rangle \leq 0, \quad (29.44)$$

$$\langle y - q, p - q \rangle \leq 0. \quad (29.45)$$

两式相加得到  $\langle x - y, p - q \rangle \geq \|p - q\|_2^2$ . 故

$$\|P_C(x) - P_C(y)\|_2^2 \leq \langle P_C(x) - P_C(y), x - y \rangle. \quad (29.46)$$


因此投影映射牢固非扩张。

### 29.5.3 知识点十二: 投影梯度迭代

考虑

$$\min_{x \in C} f(x), \quad (29.47)$$

假设:



- $C$  非空、闭、凸；
- $f$  为凸可微函数；
- 梯度为  $L$ -Lipschitz 连续：

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L \|x - y\|_2. \quad (29.48)$$

投影梯度法为

$$x_{k+1} = P_C(x_k - \alpha_k \nabla f(x_k)). \quad (29.49)$$

它可解释为：

1. 先作无约束梯度步  $x_k - \alpha_k \nabla f(x_k)$ ；
2. 再投影回可行集  $C$ 。

#### 29.5.4 知识点十三：梯度映射与停止准则

定义投影梯度映射

$$G_\alpha^C(x) = \frac{1}{\alpha} [x - P_C(x - \alpha \nabla f(x))]. \quad (29.50)$$

有

$$G_\alpha^C(x) = 0 \iff x \in \arg \min_{z \in C} f(z). \quad (29.51)$$

因此推荐停止准则为

$$\|G_\alpha^C(x_k)\|_2 \leq \varepsilon_{\text{stat}}. \quad (29.52)$$

仅检查  $\|\nabla f(x_k)\|$  通常不正确，因为在有约束最优点处，梯度未必为零。

#### 29.5.5 知识点十四：下降估计

令  $x^+ = P_C(x - \alpha \nabla f(x))$ 。在投影最优性条件中取  $z = x$ ，有  $\langle x - \alpha \nabla f(x) - x^+, x - x^+ \rangle \leq 0$ 。  
整理：

$$\langle \nabla f(x), x^+ - x \rangle \leq -\frac{1}{\alpha} \|x^+ - x\|_2^2. \quad (29.53)$$

由下降引理：

$$\begin{aligned} f(x^+) &\leq f(x) + \langle \nabla f(x), x^+ - x \rangle + \frac{L}{2} \|x^+ - x\|_2^2 \\ &\leq f(x) - \left(\frac{1}{\alpha} - \frac{L}{2}\right) \|x^+ - x\|_2^2. \end{aligned} \quad (29.54)$$

因此当  $0 < \alpha < \frac{2}{L}$  时，只要  $x^+ \neq x$ ，目标值严格下降。

#### 29.5.6 知识点十五：凸情形的 $O(1/k)$ 收敛率

设  $0 < \alpha \leq \frac{1}{L}$ 。令  $x^*$  为任意最优解。

由光滑性和凸性：

$$f(x^+) - f(x^*) \leq \langle \nabla f(x), x^+ - x^* \rangle + \frac{L}{2} \|x^+ - x\|_2^2. \quad (29.55)$$



由投影最优性条件取  $z = x^*$ :

$$\langle \nabla f(x), x^+ - x^* \rangle \leq \frac{1}{\alpha} \langle x - x^+, x^+ - x^* \rangle. \quad (29.56)$$

利用恒等式

$$2\langle x - x^+, x^+ - x^* \rangle = \|x - x^*\|_2^2 - \|x^+ - x^*\|_2^2 - \|x - x^+\|_2^2, \quad (29.57)$$

得到

$$\begin{aligned} f(x^+) - f(x^*) &\leq \frac{1}{2\alpha} \left[ \|x - x^*\|_2^2 - \|x^+ - x^*\|_2^2 \right] \\ &\quad - \left( \frac{1}{2\alpha} - \frac{L}{2} \right) \|x - x^+\|_2^2. \end{aligned} \quad (29.58)$$

因  $\alpha \leq 1/L$ , 最后一项非正, 故

$$f(x_{k+1}) - f(x^*) \leq \frac{1}{2\alpha} \left[ \|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2 \right]. \quad (29.59)$$

求和并利用目标值单调不减:

$$\boxed{f(x_k) - f(x^*) \leq \frac{\|x_0 - x^*\|_2^2}{2\alpha k}}. \quad (29.60)$$

### 29.5.7 知识点十六: 强凸情形的线性收敛

进一步假设  $f$  为  $m$ -强凸且  $L$ -光滑:  $0 < m \leq L$ . 梯度满足增强余单调性估计

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq \frac{mL}{m+L} \|x - y\|_2^2 + \frac{1}{m+L} \|\nabla f(x) - \nabla f(y)\|_2^2. \quad (29.61)$$

当  $0 < \alpha \leq \frac{2}{m+L}$  时:

$$\begin{aligned} \|(x - \alpha \nabla f(x)) - (y - \alpha \nabla f(y))\|_2^2 \\ \leq \left( 1 - \frac{2\alpha mL}{m+L} \right) \|x - y\|_2^2. \end{aligned} \quad (29.62)$$

投影非扩张, 且最优满足投影不动点条件, 故

$$\boxed{\|x_{k+1} - x^*\|_2 \leq q \|x_k - x^*\|_2, \quad q = \sqrt{1 - \frac{2\alpha mL}{m+L}} < 1}. \quad (29.63)$$

取  $\alpha = \frac{2}{m+L}$  时,

$$q = \frac{L-m}{L+m} = \frac{\kappa-1}{\kappa+1}, \quad \kappa = \frac{L}{m}. \quad (29.64)$$

---

#### Algorithm 97 投影梯度法

---

**Input:** 闭凸集  $C$ ; 凸  $L$ -光滑函数  $f$ ; 初值  $x_0 \in C$ ; 步长  $0 < \alpha \leq 1/L$ ; 容差  $\varepsilon_{\text{stat}} > 0$

**Output:** 约束问题的近似一阶最优点

- 1: **Initialization:** 令  $k \leftarrow 0$
- 2: **loop**
- 3:   计算梯度  $g_k = \nabla f(x_k)$
- 4:   计算投影  $x_{k+1} = P_C(x_k - \alpha g_k)$
- 5:   计算梯度映射  $G_k = \frac{x_k - x_{k+1}}{\alpha}$



```

6:   if  $\|G_k\|_2 \leq \varepsilon_{\text{stat}}$  then
7:       输出  $x_{k+1}$ 
8:       stop
9:   end if
10:   $k \leftarrow k + 1$ 
11: end loop
12: Stopping criterion: 优先使用投影梯度映射范数；还可同时检查目标变化和最大迭代次数
13: Complexity: 每次迭代包括一次梯度计算和一次投影。
    若  $C$  为盒约束，投影为逐分量截断，成本  $O(n)$ ；
    若  $C$  为概率单纯形，排序投影成本通常为  $O(n \log n)$ ；
    若  $C = \{x : Ax = b\}$ ，预分解  $AA^\top$  后，每次投影主要为矩阵-向量乘和三角求解

```

### 易错点与反例

投影梯度法中的三个对象必须区分：

1. 无约束梯度  $\nabla f(x)$ ；
2. 投影步  $P_C(x - \alpha \nabla f(x))$ ；
3. 约束驻点残差  $G_\alpha^C(x)$ 。

在约束边界上的最优点处，通常有  $\nabla f(x^*) \neq 0$ ，但  $G_\alpha^C(x^*) = 0$ 。

## 29.6 近端映射、Moreau 包络与近端点法

### 29.6.1 知识点十七：近端映射的存在唯一性

【重要性等级】 **S 级**。

设  $g : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  为真、闭、凸函数。

对  $\lambda > 0$ ，近端子问题  $\min_z \left[ g(z) + \frac{1}{2\lambda} \|z - x\|_2^2 \right]$  的目标函数为  $\frac{1}{\lambda}$ -强凸函数。因此存在唯一极小点，即  $\text{prox}_{\lambda g}(x)$  为单值映射。

令  $p = \text{prox}_{\lambda g}(x)$ 。一阶最优性条件为

$$0 \in \partial g(p) + \frac{1}{\lambda}(p - x). \quad (29.65)$$

等价于

$$\boxed{\frac{x - p}{\lambda} \in \partial g(p)}. \quad (29.66)$$


因此

$$\boxed{\text{prox}_{\lambda g} = (I + \lambda \partial g)^{-1}}. \quad (29.67)$$

即近端映射是次微分算子的预解算子 (resolvent)。

### 29.6.2 知识点十八：近端映射的牢固非扩张性

令  $p = \text{prox}_{\lambda g}(x)$ ， $q = \text{prox}_{\lambda g}(y)$ 。则  $\frac{x-p}{\lambda} \in \partial g(p)$ ， $\frac{y-q}{\lambda} \in \partial g(q)$ 。



凸次微分为单调算子，所以  $\langle \frac{x-p}{\lambda} - \frac{y-q}{\lambda}, p-q \rangle \geq 0$ 。整理得

$$\|p - q\|_2^2 \leq \langle p - q, x - y \rangle. \quad (29.68)$$

故近端映射牢固非扩张。

### 29.6.3 知识点十九：指标函数、投影与软阈值

指标函数。 若  $g = \delta_C$ ，则

$$\begin{aligned} \text{prox}_{\lambda\delta_C}(x) &= \arg \min_{z \in C} \frac{1}{2\lambda} \|z - x\|_2^2 \\ &= P_C(x). \end{aligned} \quad (29.69)$$

因此投影是近端映射的特殊情形。

$\ell^1$  范数。 定义软阈值算子

$$S_\tau(v)_i = \text{sign}(v_i) \max\{|v_i| - \tau, 0\}. \quad (29.70)$$

则

$$\text{prox}_{\tau\|\cdot\|_1}(v) = S_\tau(v). \quad (29.71)$$

证明可逐分量完成。对标量问题  $\min_z [\tau|z| + \frac{1}{2}(z - v)^2]$ ，最优性条件为  $0 \in z - v + \tau\partial|z|$ 。

分三种情形：

1. 若  $z > 0$ ，则  $z = v - \tau > 0$ ，要求  $v > \tau$ ；
2. 若  $z < 0$ ，则  $z = v + \tau < 0$ ，要求  $v < -\tau$ ；
3. 若  $z = 0$ ，则  $v \in [-\tau, \tau]$ 。

合并即得 式 (29.70)。

**Euclidean** 范数。 对  $g(x) = \tau\|x\|_2$ ，有向量收缩公式

$$\text{prox}_{\tau\|\cdot\|_2}(v) = \begin{cases} \left(1 - \frac{\tau}{\|v\|_2}\right)v, & \|v\|_2 > \tau, \\ 0, & \|v\|_2 \leq \tau. \end{cases} \quad (29.72)$$

### 29.6.4 知识点二十：Moreau 包络

Moreau 包络定义为

$$e_\lambda g(x) = \min_z \left\{ g(z) + \frac{1}{2\lambda} \|z - x\|_2^2 \right\}. \quad (29.73)$$

若  $g$  真闭凸，则  $e_\lambda g$  处处有限、凸且连续可微，并满足


$$\nabla e_\lambda g(x) = \frac{1}{\lambda} [x - \text{prox}_{\lambda g}(x)]. \quad (29.74)$$

其梯度为  $\frac{1}{\lambda}$ -Lipschitz 连续。

Moreau 分解为

$$x = \text{prox}_{\lambda g}(x) + \lambda \text{prox}_{g^*/\lambda}\left(\frac{x}{\lambda}\right). \quad (29.75)$$

这里  $g^*$  为 Fenchel 共轭。



## 29.6.5 知识点二十一：近端点法

考虑

$$\min_x F(x), \quad (29.76)$$

其中  $F$  真、闭、凸且最优解集合非空。

近端点法 (proximal point algorithm, PPA) 为

$$x_{k+1} = \text{prox}_{\lambda_k F}(x_k). \quad (29.77)$$

它是隐式迭代，因为每一步需要求解一个正则化优化子问题。

由最优性条件：

$$\frac{x_k - x_{k+1}}{\lambda_k} \in \partial F(x_{k+1}). \quad (29.78)$$

若  $x^*$  为最优解，则  $0 \in \partial F(x^*)$ 。次微分单调性给出  $\langle x_k - x_{k+1}, x_{k+1} - x^* \rangle \geq 0$ 。因此

$$\|x_{k+1} - x^*\|_2^2 \leq \|x_k - x^*\|_2^2 - \|x_{k+1} - x_k\|_2^2. \quad (29.79)$$

故  $\{x_k\}$  关于最优解集合 Fejér 单调。

若  $\inf_k \lambda_k > 0$ ，则在有限维空间中  $x_k \rightarrow x^*$  对某个最优解  $x^*$  成立。

## 29.6.6 知识点二十二：强凸时的线性收敛

若  $F$  为  $m$ -强凸，则  $\partial F$  为  $m$ -强单调：

$$\langle u - v, x - y \rangle \geq m \|x - y\|_2^2, \quad u \in \partial F(x), \quad v \in \partial F(y). \quad (29.80)$$

近端映射满足

$$\|\text{prox}_{\lambda F}(x) - \text{prox}_{\lambda F}(y)\|_2 \leq \frac{1}{1 + \lambda m} \|x - y\|_2. \quad (29.81)$$

因此近端点法线性收敛：

$$\|x_k - x^*\|_2 \leq \prod_{j=0}^{k-1} \frac{1}{1 + \lambda_j m} \|x_0 - x^*\|_2. \quad (29.82)$$

**Algorithm 98** 近端点法

**Input:** 真闭凸函数  $F$ ；初值  $x_0$ ；参数  $\lambda_k > 0$ ；容差  $\varepsilon > 0$

**Output:**  $F$  的近似极小点

1: **Initialization:** 令  $k \leftarrow 0$

2: **loop**

3:   近似求解强凸子问题  $x_{k+1} \approx \arg \min_x \left[ F(x) + \frac{1}{2\lambda_k} \|x - x_k\|_2^2 \right]$

4:   计算近端残差  $r_{k+1} = \frac{x_k - x_{k+1}}{\lambda_k}$

5:   **if**  $\|r_{k+1}\|_2 \leq \varepsilon$  且内层误差足够小 **then**

6:     输出  $x_{k+1}$

7:     **stop**

8:   **end if**

9:    $k \leftarrow k + 1$

10: **end loop**

11: **Stopping criterion:** 精确近端步中， $r_{k+1} \in \partial F(x_{k+1})$ ；故  $\|r_{k+1}\|$  是自然驻点残差



- 12: **Complexity:** 外层每一步包含一个强凸优化子问题。若近端映射有闭式公式，成本可为  $O(n)$ ；若无闭式公式，复杂度取决于内层求解器。内层容差必须与外层收敛要求协调

### 易错点与反例

近端点法的稳定性来自二次正则项，但它并不自动意味着每一步容易计算。

必须区分：

近端映射数学上单值 与 近端子问题数值上容易求解。

只有当  $F$  具有可分离、谱函数、范数、指标函数或其他特殊结构时，近端映射才常有快速闭式或近闭式算法。

## 29.7 近端梯度、ISTA 与 FISTA

### 29.7.1 知识点二十三：前向-后向分裂

考虑复合问题

$$\min_{x \in \mathbb{R}^n} F(x) = f(x) + g(x) \quad (29.83)$$

其中：

- $f$  为凸可微函数；
- $\nabla f$  为  $L$ -Lipschitz 连续；
- $g$  为真、闭、凸函数；
- $\text{prox}_{\alpha g}$  可高效计算；
- 最优解集合非空。

近端梯度迭代为

$$x_{k+1} = \text{prox}_{\alpha g}(x_k - \alpha \nabla f(x_k)). \quad (29.84)$$

它称为前向-后向分裂：

- 对光滑项  $\nabla f$  作显式前向步；
- 对非光滑项  $\partial g$  作隐式近端步。

当  $g = \delta_C$  时，式 (29.84) 退化为投影梯度法。

### 29.7.2 知识点二十四：近端梯度映射

定义


$$G_\alpha(x) = \frac{1}{\alpha} [x - \text{prox}_{\alpha g}(x - \alpha \nabla f(x))]. \quad (29.85)$$

则

$$G_\alpha(x) = 0 \iff 0 \in \nabla f(x) + \partial g(x) \iff x \in \arg \min F. \quad (29.86)$$

推荐停止准则为

$$\|G_\alpha(x_k)\|_2 \leq \varepsilon_{\text{stat}}. \quad (29.87)$$





### 29.7.3 知识点二十五：下降性质

令  $x^+ = \text{prox}_{\alpha g}(x - \alpha \nabla f(x))$ 。近端最优性说明  $x^+$  最小化  $g(z) + \langle \nabla f(x), z - x \rangle + \frac{1}{2\alpha} \|z - x\|_2^2$ 。与  $z = x$  比较：

$$g(x^+) + \langle \nabla f(x), x^+ - x \rangle + \frac{1}{2\alpha} \|x^+ - x\|_2^2 \leq g(x). \quad (29.88)$$

由  $f$  的光滑性： $f(x^+) \leq f(x) + \langle \nabla f(x), x^+ - x \rangle + \frac{L}{2} \|x^+ - x\|_2^2$ 。两式相加：

$$F(x^+) \leq F(x) - \left( \frac{1}{2\alpha} - \frac{L}{2} \right) \|x^+ - x\|_2^2. \quad (29.89)$$

若  $0 < \alpha < 1/L$ ，则只要  $x^+ \neq x$ ，目标严格下降。

### 29.7.4 知识点二十六：凸情形的收敛率

若  $0 < \alpha \leq 1/L$ ，则近端梯度法满足

$$F(x_k) - F(x^*) \leq \frac{\|x_0 - x^*\|_2^2}{2\alpha k}. \quad (29.90)$$

因此迭代复杂度为

$$k = O\left(\frac{L \|x_0 - x^*\|_2^2}{\varepsilon}\right) \quad (29.91)$$

以获得  $F(x_k) - F(x^*) \leq \varepsilon$ 。

若  $F$  为强凸函数，则在适当步长下可获得线性收敛。

### 29.7.5 知识点二十七：FISTA 加速

标准 FISTA 取

$$t_0 = 1, \quad (29.92)$$

$$x_0 = y_0, \quad (29.93)$$

并迭代

$$x_{k+1} = \text{prox}_{g/L}\left(y_k - \frac{1}{L} \nabla f(y_k)\right), \quad (29.94)$$

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad (29.95)$$

$$y_{k+1} = x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k). \quad (29.96)$$

其目标函数收敛率为

$$F(x_k) - F(x^*) \leq \frac{2L \|x_0 - x^*\|_2^2}{(k+1)^2}. \quad (29.97)$$


因此达到目标误差  $\varepsilon$  所需迭代次数为  $O(\varepsilon^{-1/2})$ ，优于 ISTA 的  $O(\varepsilon^{-1})$ 。

---

#### Algorithm 99 带回溯的近端梯度法

---

**Input:**  $F = f + g$ ; 可计算  $\nabla f$  和  $\text{prox}_{\alpha g}$ ; 初值  $x_0$ ; 初始 Lipschitz 估计  $L_0 > 0$ ; 增长因子  $\eta > 1$ ; 容差  $\varepsilon > 0$



**Output:** 近似复合驻点

```

1: Initialization: 令  $k \leftarrow 0, L_k \leftarrow L_0$ 
2: loop
3:   令  $\alpha_k = 1/L_k$ 
4:   计算  $x^+ = \text{prox}_{\alpha_k g}(x_k - \alpha_k \nabla f(x_k))$ 
5:   while  $f(x^+) > f(x_k) + \langle \nabla f(x_k), x^+ - x_k \rangle + \frac{L_k}{2} \|x^+ - x_k\|_2^2$  do
6:      $L_k \leftarrow \eta L_k, \alpha_k \leftarrow 1/L_k$ 
7:     重新计算  $x^+$ 
8:   end while
9:    $G_k = \frac{x_k - x^+}{\alpha_k}$ 
10:  if  $\|G_k\|_2 \leq \varepsilon$  then
11:    输出  $x^+$ 
12:    stop
13:  end if
14:   $x_{k+1} \leftarrow x^+$ 
15:   $k \leftarrow k + 1$ 
16: end loop
17: Stopping criterion: 使用近端梯度映射范数; 还可同时检查目标变化和相对步长
18: Complexity: 每步包括一次梯度计算、一次近端映射及若干次回溯函数值计算。若  $f(x) = \frac{1}{2} \|Ax - b\|_2^2$ , 主要成本是一次  $A$  乘法和一次  $A^\top$  乘法; 稠密成本为  $O(mn)$ , 稀疏成本为  $O(\text{nnz}(A))$ ; 额外存储通常为  $O(n)$ 

```

#### 易错点与反例

标准 FISTA 的目标值序列不一定单调。

加速惯性项可能使  $F(x_{k+1}) > F(x_k)$  偶尔发生, 但整体仍满足  $O(k^{-2})$  理论界。

若需要实际单调性, 可使用:

- 单调 FISTA;
- 自适应重启;
- 当  $\langle x_{k+1} - x_k, x_k - x_{k-1} \rangle > 0$  等条件触发重启。

## 29.8 $\ell^1$ 范数、稀疏性、软阈值与稀疏恢复

### 29.8.1 知识点二十八: $\ell^1$ 次微分

对  $\varphi(x) = \|x\|_1 = \sum_{i=1}^n |x_i|$ , 有

$$\partial \|x\|_1 = \left\{ z \in \mathbb{R}^n : z_i = \begin{cases} \text{sign}(x_i), & x_i \neq 0, \\ \xi_i, |\xi_i| \leq 1, & x_i = 0 \end{cases} \right\}. \quad (29.98)$$

对任意  $z \in \partial \|x\|_1$  有重要恒等式

$$z^\top x = \|x\|_1. \quad (29.99)$$

$\ell^1$  范数促进稀疏性的关键在于:



- 在  $x_i \neq 0$  处, 次梯度固定为  $\pm 1$ ;
- 在  $x_i = 0$  处, 次梯度为整个区间  $[-1, 1]$ ;
- 一个非零范围的梯度扰动可被零点处的次梯度区间吸收;
- 因而最优解中可出现大量精确零分量。

### 29.8.2 知识点二十九: Lasso 最优性条件

标准平方损失 Lasso 为

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1, \quad \lambda > 0. \quad (29.100)$$

最优点  $x^*$  满足

$$0 \in A^\top (Ax^* - b) + \lambda \partial \|x^*\|_1. \quad (29.101)$$

逐分量写成

$$\begin{cases} a_i^\top (Ax^* - b) = -\lambda \operatorname{sign}(x_i^*), & x_i^* \neq 0, \\ |a_i^\top (Ax^* - b)| \leq \lambda, & x_i^* = 0. \end{cases} \quad (29.102)$$

其中  $a_i$  为  $A$  的第  $i$  列。

若  $\lambda \geq \|A^\top b\|_\infty$ , 则  $x^* = 0$  满足最优性条件。

因此正则化路径常从

$$\lambda_{\max} = \|A^\top b\|_\infty \quad (29.103)$$

开始。

### 29.8.3 知识点三十: ISTA 的软阈值形式

对  $f(x) = \frac{1}{2} \|Ax - b\|_2^2$ , 有  $\nabla f(x) = A^\top (Ax - b)$ , 且  $L = \|A\|_2^2$ 。

ISTA 迭代为

$$x_{k+1} = S_{\alpha\lambda} (x_k - \alpha A^\top (Ax_k - b)), \quad 0 < \alpha < \frac{2}{\|A\|_2^2}. \quad (29.104)$$

为直接使用标准目标收敛率, 通常取  $0 < \alpha \leq \frac{1}{\|A\|_2^2}$ 。

### 29.8.4 知识点三十一: 基追踪及其线性规划形式

基追踪 (basis pursuit) 为

$$\min_x \|x\|_1 \quad \text{subject to} \quad Ax = b. \quad (29.105)$$

令  $x = u - v$ ,  $u \geq 0$ ,  $v \geq 0$ , 则  $\|x\|_1 = \mathbf{1}^\top u + \mathbf{1}^\top v$  可在最优解处实现, 故问题等价于线性规划

$$\begin{aligned} & \text{minimize} && \mathbf{1}^\top u + \mathbf{1}^\top v, \\ & \text{subject to} && Au - Av = b, \\ & && u, v \geq 0. \end{aligned} \quad (29.106)$$

其对偶可写成

$$\begin{aligned} & \text{maximize} && b^\top y, \\ & \text{subject to} && \|A^\top y\|_\infty \leq 1. \end{aligned} \quad (29.107)$$



## 29.8.5 知识点三十二：零空间性质

设  $x^*$  为  $s$ -稀疏向量，支撑集为  $S = \text{supp}(x^*)$ 。

若对任意  $h \in \ker A \setminus \{0\}$  均有

$$\|h_S\|_1 < \|h_{S^c}\|_1, \quad (29.108)$$

则  $x^*$  是式 (29.105) 的唯一解。

证明. 任取另一个可行点  $x = x^* + h$ ,  $h \in \ker A$ ,  $h \neq 0$ 。由于  $x_{S^c}^* = 0$ ,

$$\begin{aligned} \|x\|_1 &= \|x_S^* + h_S\|_1 + \|h_{S^c}\|_1 \\ &\geq \|x_S^*\|_1 - \|h_S\|_1 + \|h_{S^c}\|_1 \\ &> \|x^*\|_1. \end{aligned} \quad (29.109)$$

故  $x^*$  唯一。  $\square$

反之，若希望对所有支撑不超过  $s$  的向量都能通过  $\ell^1$  唯一恢复，则相应阶数的零空间性质也是必要条件。

29.8.6 知识点三十三： $\ell^1$  正则化路径与同伦

考虑 Lasso 路径  $x^*(\lambda)$ ,  $\lambda \downarrow 0$ 。

设在一段参数区间上：

- 活跃集  $I = \{i : x_i^*(\lambda) \neq 0\}$  不变；
- 符号向量  $s_I = \text{sign}(x_I^*)$  不变；
- $A_I$  满列秩。

活跃坐标的 KKT 方程为

$$A_I^\top (A_I x_I - b) + \lambda s_I = 0. \quad (29.110)$$

因此

$$x_I(\lambda) = (A_I^\top A_I)^{-1} (A_I^\top b - \lambda s_I). \quad (29.111)$$

在固定活跃集和符号下， $x_I(\lambda)$  关于  $\lambda$  为仿射函数，且

$$\frac{dx_I}{d\lambda} = -(A_I^\top A_I)^{-1} s_I. \quad (29.112)$$

路径的下一断点来自两类事件：

1. 某个活跃系数降为零；
2. 某个非活跃指标  $j \notin I$  首次满足  $|a_j^\top (Ax - b)| = \lambda$ 。

这构成 Lasso 同伦法或 LARS 型路径算法的基础。

**Algorithm 100** Lasso 正则化路径的活跃集同伦框架

**Input:**  $A, b$ ; 目标参数  $\lambda_{\text{tar}} \geq 0$

**Output:** 沿正则化路径得到  $x^*(\lambda_{\text{tar}})$

- 1: **Initialization:** 令  $\lambda_0 = \|A^\top b\|_\infty$ ,  $x(\lambda_0) = 0$ ; 选取达到最大相关性的指标进入活跃集



- 2: **while**  $\lambda > \lambda_{\text{tar}}$  **do**
- 3:     在当前活跃集  $I$  和符号  $s_I$  下解  $A_I^\top A_I d_I = -s_I$
- 4:     沿  $x_I(\lambda - \Delta\lambda) = x_I(\lambda) - \Delta\lambda d_I$  跟踪
- 5:     计算所有活跃变量到零的候选断点
- 6:     计算所有非活跃相关性达到边界的候选断点
- 7:     取最先发生的正候选步长
- 8:     更新  $\lambda$ 、活跃集和符号
- 9:     使用 Cholesky 秩一更新或降阶更新活跃 Gram 矩阵分解
- 10: **end while**
- 11: **Stopping criterion:**  $\lambda \leq \lambda_{\text{tar}}$  且 KKT 残差满足  $\|A^\top(Ax - b) + \lambda z\|_\infty \leq \varepsilon$
- 12: **Complexity:** 若活跃集大小为  $s$ ，一次活跃线性系统求解或更新通常约为  $O(s^2)$ ；非活跃相关性扫描的朴素成本为  $O(mn)$ ；路径断点数最坏可很大，且退化数据可能导致多指标同时进入或退出

#### 易错点与反例

“Lasso 路径分段线性”需要条件。

若出现：

- 活跃列线性相关；
- 解不唯一；
- 多个事件同时发生；
- 非一般位置数据；

则路径可能需要集合值描述或特殊破平规则，不能无条件使用  $(A_I^\top A_I)^{-1}$ 。

## 29.9 正式真题 [25F-Q7]—— $\ell^1$ 正则化、对偶与稀疏性



完整题目叙述: [25F-Q7]

考虑最小化问题

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2 + \gamma \|x\|_1, \quad (29.113)$$

其中  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ ,  $\gamma > 0$ 。

(a) 推导等价问题

$$\min_{x, y} \|y\|_2 + \gamma \|x\|_1, \text{ subject to } Ax - b = y \quad (29.114)$$

的 Lagrange 对偶。

(b) 设  $x^*$  为最优点, 且  $Ax^* - b \neq 0$ . 定义

$$r = \frac{Ax^* - b}{\|Ax^* - b\|_2}. \quad (29.115)$$

证明

$$\|A^\top r\|_\infty \leq \gamma, \quad r^\top Ax^* + \gamma \|x^*\|_1 = 0. \quad (29.116)$$

(c) 设  $a_i$  为  $A$  的第  $i$  列。证明若

$$\|a_i\|_2 < \gamma, \quad (29.117)$$

则  $x_i^* = 0$ 。

## 第 (a) 问: Lagrange 对偶

将等式约束写成  $Ax - b - y = 0$ 。引入自由对偶变量  $r \in \mathbb{R}^m$ 。Lagrange 函数为

$$\begin{aligned} L(x, y, r) &= \|y\|_2 + \gamma \|x\|_1 + r^\top (Ax - b - y) \\ &= -b^\top r + (\|y\|_2 - r^\top y) + (\gamma \|x\|_1 + (A^\top r)^\top x). \end{aligned} \quad (29.118)$$

对偶函数为  $q(r) = \inf_{x, y} L(x, y, r)$ 。先计算  $y$ -部分:

$$\inf_y (\|y\|_2 - r^\top y) = \begin{cases} 0, & \|r\|_2 \leq 1, \\ -\infty, & \|r\|_2 > 1. \end{cases} \quad (29.119)$$

证明如下。

若  $\|r\|_2 \leq 1$ , 由 Cauchy-Schwarz:  $r^\top y \leq \|r\|_2 \|y\|_2 \leq \|y\|_2$ 。故表达式非负, 在  $y = 0$  处取到零。若  $\|r\|_2 > 1$ , 取  $y = t \frac{r}{\|r\|_2}$ ,  $t \rightarrow +\infty$ , 则  $\|y\|_2 - r^\top y = t(1 - \|r\|_2) \rightarrow -\infty$ 。再计算  $x$ -部分:

$$\inf_x [\gamma \|x\|_1 + (A^\top r)^\top x] = \begin{cases} 0, & \|A^\top r\|_\infty \leq \gamma, \\ -\infty, & \|A^\top r\|_\infty > \gamma. \end{cases} \quad (29.120)$$

若  $\|A^\top r\|_\infty \leq \gamma$ , 由对偶范数不等式:  $-(A^\top r)^\top x \leq \|A^\top r\|_\infty \|x\|_1 \leq \gamma \|x\|_1$ , 故表达式非负, 并在  $x = 0$  处达到零。若存在指标  $i$  使  $|a_i^\top r| > \gamma$ , 可令  $x$  只在第  $i$  个分量非零, 并选取与  $a_i^\top r$  相反的符号, 使目标沿该方向趋于  $-\infty$ 。

因此

$$q(r) = \begin{cases} -b^\top r, & \|r\|_2 \leq 1, \quad \|A^\top r\|_\infty \leq \gamma, \\ -\infty, & \text{否则}. \end{cases} \quad (29.121)$$

故 Lagrange 对偶为

$$\begin{aligned} & \text{maximize}_{r \in \mathbb{R}^m} && -b^\top r, \\ & \text{subject to} && \|r\|_2 \leq 1, \\ & && \|A^\top r\|_\infty \leq \gamma. \end{aligned} \quad (29.122)$$

令  $u = -r$ , 可写成完全等价的形式

$$\begin{aligned} & \text{maximize}_u && b^\top u, \\ & \text{subject to} && \|u\|_2 \leq 1, \\ & && \|A^\top u\|_\infty \leq \gamma. \end{aligned} \quad (29.123)$$

原问题为有限维闭凸问题, 等式约束仿射且显然可行: 任取  $x$ , 令  $y = Ax - b$ . 目标函数在其定义域上连续, 故强对偶成立。

第 (b) 问: KKT 最优性条件

设  $y^* = Ax^* - b \neq 0$ . 对 Euclidean 范数,

$$\partial \|y^*\|_2 = \left\{ \frac{y^*}{\|y^*\|_2} \right\}. \quad (29.124)$$

KKT 关于  $y$  的驻点条件为

$$0 \in \partial \|y^*\|_2 - r. \quad (29.125)$$

故  $r = \frac{y^*}{\|y^*\|_2} = \frac{Ax^* - b}{\|Ax^* - b\|_2}$ , 与题目定义一致, 并且

$$\|r\|_2 = 1. \quad (29.126)$$

关于  $x$  的驻点条件为

$$0 \in A^\top r + \gamma \partial \|x^*\|_1. \quad (29.127)$$

因此存在  $z \in \partial \|x^*\|_1$  使

$$A^\top r + \gamma z = 0. \quad (29.128)$$

由于  $\|z\|_\infty \leq 1$ , 得到

$$\|A^\top r\|_\infty = \gamma \|z\|_\infty \leq \gamma. \quad (29.129)$$

将式 (29.128) 左乘  $(x^*)^\top$ :  $r^\top Ax^* + \gamma z^\top x^* = 0$ . 由式 (29.99):  $z^\top x^* = \|x^*\|_1$ . 故

$$r^\top Ax^* + \gamma \|x^*\|_1 = 0. \quad (29.130)$$


还可验证原始目标与对偶目标相等:

$$\begin{aligned} \|Ax^* - b\|_2 + \gamma \|x^*\|_1 &= r^\top (Ax^* - b) + \gamma \|x^*\|_1 \\ &= -b^\top r. \end{aligned} \quad (29.131)$$

第 (c) 问: 小列范数导致零系数

反设  $x_i^* \neq 0$ . 则由  $\ell^1$  次微分公式,  $z_i = \text{sign}(x_i^*)$ ,  $|z_i| = 1$ . 从  $A^\top r + \gamma z = 0$  的第  $i$  个分量得到

$$a_i^\top r = -\gamma \text{sign}(x_i^*). \quad (29.132)$$



故

$$|a_i^\top r| = \gamma. \quad (29.133)$$

另一方面, 由 Cauchy-Schwarz 和  $\|r\|_2 = 1$  有

$$|a_i^\top r| \leq \|a_i\|_2 \|r\|_2 = \|a_i\|_2 < \gamma, \quad (29.134)$$

与式 (29.133) 矛盾。

因此

$$\|a_i\|_2 < \gamma \implies x_i^* = 0. \quad (29.135)$$

注 29.3 (零残差时的加强形式). 若  $Ax^* - b = 0$ , 则  $\partial\|0\|_2 = \{r : \|r\|_2 \leq 1\}$ . 仍存在某个  $\|r\|_2 \leq 1$  满足  $A^\top r + \gamma z = 0$ ,  $z \in \partial\|x^*\|_1$ . 于是若  $x_i^* \neq 0$ , 仍需  $|a_i^\top r| = \gamma$ , 但  $|a_i^\top r| \leq \|a_i\|_2 \|r\|_2 < \gamma$ . 所以第 (c) 问的稀疏结论实际上不依赖非零残差假设。

## 29.10 补充训练题：丘赛 2026 Problem 6——最大函数与非负正交锥的次微分

完整题目叙述：[丘赛 2026 Problem 6]

设凸函数  $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$  在  $x$  处的次微分记为  $\partial f(x)$ 。

假设  $n \geq 2$ 。

(a) 定义

$$f(x) = \max_{i=1, \dots, n} x_i, \quad x = (x_1, \dots, x_n)^\top. \quad (29.136)$$

计算  $\partial f(0)$ 。

(b) 定义

$$g(x) = \max_{i=1, \dots, n} x_i + \delta_{\mathbb{R}_+^n}(x), \quad (29.137)$$

其中  $\delta_{\mathbb{R}_+^n}$  为非负正交锥的指标函数。证明

$$\partial g(0) = \partial f(0) - \mathbb{R}_+^n. \quad (29.138)$$

可使用次微分和式法则  $\partial(f + \delta_C) = \partial f + \partial \delta_C$ 。

第 (a) 问. 记标准概率单纯形

$$\Delta_n = \left\{ p \in \mathbb{R}^n : p_i \geq 0, \sum_{i=1}^n p_i = 1 \right\}. \quad (29.139)$$

先证  $\Delta_n \subseteq \partial f(0)$ . 任取  $p \in \Delta_n$ . 对任意  $z \in \mathbb{R}^n$ :

$$\begin{aligned} p^\top z &= \sum_{i=1}^n p_i z_i \\ &\leq \left( \max_i z_i \right) \sum_i p_i \\ &= \max_i z_i = f(z). \end{aligned} \quad (29.140)$$

又  $f(0) = 0$ , 所以  $f(z) \geq f(0) + p^\top(z - 0)$ . 故  $p \in \partial f(0)$ 。





再证  $\partial f(0) \subseteq \Delta_n$ 。设  $p \in \partial f(0)$ , 则

$$\max_i z_i \geq p^\top z, \quad \forall z \in \mathbb{R}^n. \quad (29.141)$$

取  $z = t\mathbf{1}$ ,  $t > 0$ , 得到  $t \geq t \sum_i p_i$ , 即  $\sum_i p_i \leq 1$ 。

取  $z = -t\mathbf{1}$ ,  $t > 0$ , 得到  $-t \geq -t \sum_i p_i$ , 即  $\sum_i p_i \geq 1$ 。故  $\sum_i p_i = 1$ 。

再固定指标  $j$ , 取  $z = -te_j$ ,  $t > 0$ 。由于  $n \geq 2$ , 除第  $j$  个分量外还有零分量, 所以  $\max_i z_i = 0$ 。由式 (29.141):  $0 \geq -tp_j$ , 故  $p_j \geq 0$ 。对所有  $j$  成立。

因此

$$\partial f(0) = \Delta_n = \text{conv}\{e_1, \dots, e_n\}. \quad (29.142)$$

□

第 (b) 问. 对闭凸集  $C$ ,  $\partial \delta_C(x) = N_C(x)$ 。在  $C = \mathbb{R}_+^n$ ,  $x = 0$  时:

$$\begin{aligned} N_{\mathbb{R}_+^n}(0) &= \{v : v^\top z \leq 0, \quad \forall z \geq 0\} \\ &= -\mathbb{R}_+^n. \end{aligned} \quad (29.143)$$

由次微分和式法则:

$$\begin{aligned} \partial g(0) &= \partial f(0) + \partial \delta_{\mathbb{R}_+^n}(0) \\ &= \partial f(0) - \mathbb{R}_+^n. \end{aligned} \quad (29.144)$$

故

$$\partial g(0) = \Delta_n - \mathbb{R}_+^n. \quad (29.145)$$

□

## 29.11 次梯度法与投影次梯度法

### 29.11.1 知识点三十四: 基本迭代

考虑凸问题  $\min_{x \in C} f(x)$ , 其中  $C$  非空、闭、凸,  $f$  可非光滑。

投影次梯度法为

$$x_{k+1} = P_C(x_k - \alpha_k g_k), \quad g_k \in \partial f(x_k). \quad (29.146)$$

若  $C = \mathbb{R}^n$ , 则退化为普通次梯度法。

假设:


- 存在最优解  $x^*$ ;
- 沿迭代点次梯度有界:  $\|g_k\|_2 \leq G$ 。

由投影非扩张性:

$$\begin{aligned} \|x_{k+1} - x^*\|_2^2 &\leq \|x_k - \alpha_k g_k - x^*\|_2^2 \\ &= \|x_k - x^*\|_2^2 - 2\alpha_k \langle g_k, x_k - x^* \rangle + \alpha_k^2 \|g_k\|_2^2. \end{aligned} \quad (29.147)$$

由次梯度不等式:  $\langle g_k, x_k - x^* \rangle \geq f(x_k) - f(x^*)$ 。故

$$2\alpha_k [f(x_k) - f(x^*)] \leq \|x_k - x^*\|_2^2 - \|x_{k+1} - x^*\|_2^2 + \alpha_k^2 G^2. \quad (29.148)$$



求和得到

$$\min_{0 \leq j < k} [f(x_j) - f(x^*)] \leq \frac{\|x_0 - x^*\|_2^2 + G^2 \sum_{j=0}^{k-1} \alpha_j^2}{2 \sum_{j=0}^{k-1} \alpha_j}. \quad (29.149)$$

若已知  $\|x_0 - x^*\| \leq R$  并采用固定时域步长  $\alpha_k = \frac{R}{G\sqrt{k}}$  或相应常数步长, 可得到典型复杂度

$$f_{\text{best},k} - f^* = O(k^{-1/2}). \quad (29.150)$$

若采用递减步长满足

$$\sum_{k=0}^{\infty} \alpha_k = +\infty, \quad \sum_{k=0}^{\infty} \alpha_k^2 < +\infty, \quad (29.151)$$

则在标准条件下目标值趋于最优值, 并可得到迭代聚点的最优性。

#### 易错点与反例

次梯度方向  $-g_k$  不一定是当前点的严格下降方向。

非光滑凸函数可能出现:

$f(x_k - \alpha g_k) > f(x_k)$  对某些步长成立。

次梯度法的收敛分析依赖距离递推和平均意义, 而不是每步目标单调下降。

## 29.12 动态规划、Bellman 原理与价值函数

### 29.12.1 知识点三十五: 有限时域确定性控制问题

【重要性等级】 **A 级**。

考虑离散时间系统

$$x_{k+1} = F_k(x_k, u_k), \quad k = 0, \dots, N-1, \quad (29.152)$$

其中:

- $x_k \in \mathcal{X}_k$  为状态;
- $u_k \in \mathcal{U}_k(x_k)$  为控制;
- $F_k$  为状态转移;
- $\ell_k(x_k, u_k)$  为阶段成本;
- $\phi(x_N)$  为终端成本。

给定策略  $\pi = (\mu_0, \dots, \mu_{N-1})$ ,  $u_k = \mu_k(x_k)$ , 总代价为


$$J_0^\pi(x_0) = \sum_{k=0}^{N-1} \ell_k(x_k, \mu_k(x_k)) + \phi(x_N). \quad (29.153)$$

目标是求  $\pi^* \in \arg \min_{\pi} J_0^\pi(x_0)$ 。

### 29.12.2 知识点三十六: 价值函数

从时刻  $k$  和状态  $x$  出发的最优剩余代价定义为

$$V_k(x) = \inf_{\pi_{k:N-1}} \left[ \sum_{j=k}^{N-1} \ell_j(x_j, u_j) + \phi(x_N) \right], \quad x_k = x. \quad (29.154)$$



终端条件为

$$\boxed{V_N(x) = \phi(x)}. \quad (29.155)$$

### 29.12.3 知识点三十七: Bellman 最优性原理

定理 29.4 (Bellman 最优性原理). 价值函数满足逆向递推

$$\boxed{V_k(x) = \inf_{u \in \mathcal{U}_k(x)} \{\ell_k(x, u) + V_{k+1}(F_k(x, u))\}}, \quad (29.156)$$

其中  $k = N - 1, \dots, 0$ 。

证明. 从时刻  $k$  出发, 先选择第一步控制  $u_k = u$ , 发生阶段成本  $\ell_k(x, u)$ , 并转移到  $x_{k+1} = F_k(x, u)$ 。

从新状态开始的最优剩余成本按定义为  $V_{k+1}(F_k(x, u))$ 。因此固定第一步控制  $u$  时, 最小可能总代价为  $\ell_k(x, u) + V_{k+1}(F_k(x, u))$ 。再对所有可行第一步控制取下确界, 得到 式 (29.156)。□

若最小值可达到, 可取

$$\mu_k^*(x) \in \arg \min_{u \in \mathcal{U}_k(x)} [\ell_k(x, u) + V_{k+1}(F_k(x, u))]. \quad (29.157)$$

由逆向递推得到的策略  $\pi^* = (\mu_0^*, \dots, \mu_{N-1}^*)$  为全局最优策略。

### 29.12.4 知识点三十八: 有限状态动态规划算法

**Algorithm 101** 有限时域动态规划的逆向递推

**Input:** 状态集合  $\mathcal{X}_k$ ; 控制集合  $\mathcal{U}_k(x)$ ; 转移  $F_k$ ; 阶段成本  $\ell_k$ ; 终端成本  $\phi$

**Output:** 价值函数  $V_k$  和最优策略  $\mu_k^*$

- 1: **Initialization:** 对所有终端状态  $x \in \mathcal{X}_N$ , 令  $V_N(x) \leftarrow \phi(x)$
- 2: **for**  $k = N - 1, N - 2, \dots, 0$  **do**
- 3:     **for** 每个  $x \in \mathcal{X}_k$  **do**
- 4:         计算  $V_k(x) = \min_{u \in \mathcal{U}_k(x)} [\ell_k(x, u) + V_{k+1}(F_k(x, u))]$
- 5:         保存一个达到最小值的控制  $\mu_k^*(x) \in \arg \min_u [\ell_k(x, u) + V_{k+1}(F_k(x, u))]$
- 6:     **end for**
- 7: **end for**
- 8: 从初始状态  $x_0$  开始, 按  $u_k = \mu_k^*(x_k)$  正向恢复最优轨迹
- 9: **Stopping criterion:** 有限时域算法在完成  $k = 0$  的递推后终止
- 10: **Complexity:** 若每层状态数不超过  $S$ , 每个状态控制数不超过  $U$ , 则运算复杂度为  $O(NSU)$ 。  
若只求最优值, 可滚动存储两层价值函数, 空间为  $O(S)$ ; 若需恢复完整策略, 通常存储为  $O(NS)$

### 29.12.5 知识点三十九: Bellman 算子的稳定性

定义 Bellman 算子

$$(\mathcal{T}_k V)(x) = \inf_{u \in \mathcal{U}_k(x)} [\ell_k(x, u) + V(F_k(x, u))]. \quad (29.158)$$

对任意有界函数  $V, W$ , 有

$$\boxed{\|\mathcal{T}_k V - \mathcal{T}_k W\|_\infty \leq \|V - W\|_\infty}. \quad (29.159)$$

证明使用  $|\inf_u a_u - \inf_u b_u| \leq \sup_u |a_u - b_u|$ 。



因此有限时域 Bellman 逆推对终端价值误差是非扩张的。

若每一阶段成本有一致扰动  $|\tilde{\ell}_k - \ell_k| \leq \varepsilon_k$  且终端误差  $\|\tilde{\phi} - \phi\|_\infty \leq \varepsilon_N$ , 则

$$\left\| \tilde{V}_k - V_k \right\|_\infty \leq \sum_{j=k}^N \varepsilon_j. \quad (29.160)$$

### 29.12.6 知识点四十：折扣无限时域与压缩不动点

对折扣因子  $0 < \beta < 1$ , 无限时域 Bellman 算子为

$$(\mathcal{T}V)(x) = \inf_{u \in \mathcal{U}(x)} [\ell(x, u) + \beta V(F(x, u))]. \quad (29.161)$$

有

$$\|\mathcal{T}V - \mathcal{T}W\|_\infty \leq \beta \|V - W\|_\infty. \quad (29.162)$$

所以  $\mathcal{T}$  是压缩映射, 存在唯一价值函数  $V^*$  满足

$$V^* = \mathcal{T}V^*. \quad (29.163)$$

价值迭代  $V_{k+1} = \mathcal{T}V_k$  满足

$$\|V_k - V^*\|_\infty \leq \beta^k \|V_0 - V^*\|_\infty. \quad (29.164)$$

这说明动态规划和不动点理论在折扣问题中直接统一。

### 29.12.7 知识点四十一：维数灾难

若状态  $x \in \mathbb{R}^d$  每个维度使用  $M$  个网格点, 则状态总数为

$$S = M^d. \quad (29.165)$$

故动态规划成本可能按维数指数增长, 这称为维数灾难 (curse of dimensionality)。

常见缓解方法包括:

- 状态聚合;
- 稀疏网格;
- 低秩张量;
- 近似动态规划;
- 值函数逼近;
- 策略梯度和强化学习;
- 问题特定的单调性、凸性和可分离结构。

#### 易错点与反例

动态规划不等于“把所有可能控制暴力枚举”。

动态规划的关键是:

- 状态必须包含影响未来的全部信息；
- 同一状态的最优剩余问题只计算一次；
- Bellman 原理要求未来仅通过当前状态依赖过去；
- 若状态定义不满足 Markov 递推结构，Bellman 方程可能错误；
- 连续状态问题还需离散化或函数逼近，产生额外逼近误差。

### 29.12.8 知识点四十二：动态规划与静态 KKT 方法的区别

- KKT 条件针对一个静态约束优化问题，以一阶和二阶局部结构为核心；
- 动态规划利用时间可分性和状态递推，直接建立全局价值函数；
- 动态规划可处理离散控制、非凸控制集和整数状态；
- KKT 方法通常要求可微性或凸次微分结构；
- 一个动态优化问题既可写成大规模静态优化问题，也可利用 Bellman 递推；
- 两者所得算法复杂度和适用结构可能完全不同。

## 29.13 补充训练题：丘赛 2022 Problem 6——整数投资分配与 Bellman 递推

完整题目叙述：[丘赛 2022 Problem 6]

有 60K 美元可用于投资，共有三种投资选项。投资额必须是 10K 美元的整数倍。

令  $d_i$  表示对第  $i$  种选项投入的单位数，其中一个单位为 10K 美元。对  $d_i > 0$ ，净收益为

$$r_1(d_1) = (7d_1 + 2) \times 10, \quad (29.166)$$

$$r_2(d_2) = (3d_2 + 7) \times 10, \quad (29.167)$$

$$r_3(d_3) = (4d_3 + 5) \times 10. \quad (29.168)$$

原题随后印为  $d_1(0) = d_2(0) = d_3(0)$ 。该表达式与前文收益函数记号不一致，应视为待核对的排版笔误。根据“零投资产生零收益”的语义，以下采用

$$r_1(0) = r_2(0) = r_3(0) = 0 \quad (29.169)$$

进行求解。

目标为

$$\max_{d_1, d_2, d_3} [r_1(d_1) + r_2(d_2) + r_3(d_3)], \quad (29.170)$$

满足

$$d_1 + d_2 + d_3 \leq 6, \quad d_i \in \mathbb{Z}_{\geq 0}. \quad (29.171)$$

用动态规划求最优投资方案和最大收益。

证明。虽然原题文字称其为线性规划，但由于：

- $d_i$  必须为整数;
- $r_i(0) = 0$  而  $r_i(d_i)$  在  $d_i > 0$  时含固定启动收益;

该问题严格说是可分离整数资源分配问题, 并非普通连续线性规划。

令  $V_i(s)$  表示将至多  $s$  个投资单位分配给前  $i$  个项目时的最大收益, 其中  $i = 0, 1, 2, 3$ ,  $s = 0, 1, \dots, 6$ 。

初始条件为

$$V_0(s) = 0, \quad s = 0, \dots, 6. \quad (29.172)$$

Bellman 递推为

$$V_i(s) = \max_{0 \leq d \leq s, d \in \mathbb{Z}} [V_{i-1}(s-d) + r_i(d)]. \quad (29.173)$$

先列出各投资项目的收益:

| $d$      | 0 | 1   | 2   | 3   | 4   | 5   | 6   |
|----------|---|-----|-----|-----|-----|-----|-----|
| $r_1(d)$ | 0 | 90  | 160 | 230 | 300 | 370 | 440 |
| $r_2(d)$ | 0 | 100 | 130 | 160 | 190 | 220 | 250 |
| $r_3(d)$ | 0 | 90  | 130 | 170 | 210 | 250 | 290 |

第一阶段。 只有第一个项目时:  $V_1(s) = r_1(s)$ , 故

| $s$      | 0 | 1  | 2   | 3   | 4   | 5   | 6   |
|----------|---|----|-----|-----|-----|-----|-----|
| $V_1(s)$ | 0 | 90 | 160 | 230 | 300 | 370 | 440 |

第二阶段。 使用  $V_2(s) = \max_{0 \leq d_2 \leq s} [V_1(s-d_2) + r_2(d_2)]$ 。

逐个计算:

$$V_2(0) = 0, \quad (29.174)$$

$$V_2(1) = \max\{90, 100\} = 100, \quad (29.175)$$

$$V_2(2) = \max\{160, 90 + 100, 130\} = 190, \quad (29.176)$$

$$V_2(3) = \max\{230, 160 + 100, 90 + 130, 160\} = 260, \quad (29.177)$$

$$V_2(4) = \max\{300, 230 + 100, 160 + 130, 90 + 160, 190\} = 330, \quad (29.178)$$

$$V_2(5) = \max\{370, 300 + 100, 230 + 130, 160 + 160, 90 + 190, 220\} = 400, \quad (29.179)$$

$$V_2(6) = \max\{440, 370 + 100, 300 + 130, 230 + 160, 160 + 190, 90 + 220, 250\} = 470. \quad (29.180)$$


因此

| $s$      | 0 | 1   | 2   | 3   | 4   | 5   | 6   |
|----------|---|-----|-----|-----|-----|-----|-----|
| $V_2(s)$ | 0 | 100 | 190 | 260 | 330 | 400 | 470 |

当  $s \geq 2$  时, 一个最优分配为  $d_2 = 1$ ,  $d_1 = s - 1$ 。

第三阶段。 使用  $V_3(s) = \max_{0 \leq d_3 \leq s} [V_2(s-d_3) + r_3(d_3)]$ 。

逐个计算:



$$V_3(0) = 0, \quad (29.181)$$

$$V_3(1) = \max\{100, 90\} = 100, \quad (29.182)$$

$$V_3(2) = \max\{190, 100 + 90, 130\} = 190, \quad (29.183)$$

$$V_3(3) = \max\{260, 190 + 90, 100 + 130, 170\} = 280, \quad (29.184)$$

$$V_3(4) = \max\{330, 260 + 90, 190 + 130, 100 + 170, 210\} = 350, \quad (29.185)$$

$$V_3(5) = \max\{400, 330 + 90, 260 + 130, 190 + 170, 100 + 210, 250\} = 420, \quad (29.186)$$

$$V_3(6) = \max\{470, 400 + 90, 330 + 130, 260 + 170, 190 + 210, 100 + 250, 290\} = 490. \quad (29.187)$$

最终价值表为

| $s$      | 0 | 1   | 2   | 3   | 4   | 5   | 6   |
|----------|---|-----|-----|-----|-----|-----|-----|
| $V_1(s)$ | 0 | 90  | 160 | 230 | 300 | 370 | 440 |
| $V_2(s)$ | 0 | 100 | 190 | 260 | 330 | 400 | 470 |
| $V_3(s)$ | 0 | 100 | 190 | 280 | 350 | 420 | 490 |

(29.188)

从  $V_3(6) = 490$  开始回溯。

达到最大值的第三项目投资量为  $d_3^* = 1$ , 因为  $V_2(5) + r_3(1) = 400 + 90 = 490$ 。

再回溯  $V_2(5) = 400$ 。达到最大值的第二项目投资量为  $d_2^* = 1$ , 因为  $V_1(4) + r_2(1) = 300 + 100 = 400$ 。

剩余预算投入第一项目:  $d_1^* = 4$ 。

因此最优分配为

$$(d_1^*, d_2^*, d_3^*) = (4, 1, 1). \quad (29.189)$$

最大收益为

$$\begin{aligned} r_1(4) + r_2(1) + r_3(1) &= 300 + 100 + 90 \\ &= \boxed{490}. \end{aligned} \quad (29.190)$$

这里 490 沿用原题的数值单位。若原题公式中的“ $\times 10$ ”按千美元计, 则对应 490K 美元。

由于所有正投资后的边际收益均为正, 最优解使用全部 6 个投资单位。 □

#### 复杂度说明

对一般的  $M$  个项目和整数预算  $B$ , 若直接使用  $V_i(s) = \max_{0 \leq d \leq s} [V_{i-1}(s-d) + r_i(d)]$ , 则:

- 运算复杂度为  $O(MB^2)$ ;
- 只保存相邻两层价值时, 存储复杂度为  $O(B)$ ;
- 若保存全部决策以回溯方案, 存储复杂度为  $O(MB)$ 。

本题中  $M = 3$ ,  $B = 6$ , 规模很小, 可以完整列出 Bellman 表。

## 29.14 动态规划、近端方法与不动点方法的答题规范

近端映射证明题：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 目标含不可微正则项；
- 出现  $\text{prox}$ ,  $\partial g$ ,  $(I + \lambda \partial g)^{-1}$ ;
- 题目要求软阈值、投影或算子非扩张性；
- 最优性条件需要改写为不动点。

构造步骤：

1. 写近端子问题；
2. 用强凸性说明解唯一；
3. 写  $(x - p)/\lambda \in \partial g(p)$ ;
4. 对两个输入分别写次梯度关系；
5. 使用次微分单调性；
6. 推出牢固非扩张；
7. 将目标最优性改写为近端不动点。

关键估计：  $\|p - q\|^2 \leq \langle p - q, x - y \rangle$ 。

结论：近端映射是单值、牢固非扩张的预解算子。

常见失败原因：函数不闭、不凸或不真；近端参数符号错误；把  $\text{prox}_{\lambda g}$  与  $\text{prox}_{g/\lambda}$  混淆；忘记指标函数近端等于投影。 $\ell^1$  最优性题：识别信号—构造步骤—关键估计—结论—失败原因

识别信号：

- 目标含  $\|x\|_1$ ;
- 题目要求零分量、支撑集或稀疏性；
- 需要推导对偶；
- 出现  $\|A^\top r\|_\infty$ 。

构造步骤：

1. 写  $\ell^1$  次微分；
2. 写完整最优性条件；
3. 将非零坐标和零坐标分开；
4. 对偶推导使用  $(\|\cdot\|_1)^* = \delta_{\{\|\cdot\|_\infty \leq 1\}}$ ;
5. 用严格对偶约束识别稳定零分量；
6. 若是 Lasso 路径，固定活跃集和符号后解线性方程。



关键估计:  $x_i \neq 0 \implies |a_i^\top r| = \gamma$ ; 以及  $|a_i^\top r| \leq \|a_i\|_2 \|r\|_2$ 。

结论: 对偶相关性阈值决定坐标是否可能非零。

常见失败原因: 把平方损失和非平方损失混淆; 在零点处把次梯度写成单值; 对偶范数写错; 把充分稀疏判据误写成必要条件。

### Bellman 递推题: 识别信号—构造步骤—关键估计—结论—失败原因

识别信号:

- 问题有阶段、时间或顺序结构;
- 当前决策影响下一状态;
- 总成本为阶段成本之和;
- 存在整数预算、路径、库存或控制变量。

构造步骤:

1. 定义状态, 使其包含影响未来的全部信息;
2. 定义控制集合;
3. 写状态转移;
4. 定义阶段成本和终端成本;
5. 定义价值函数;
6. 写终端条件;
7. 写 Bellman 递推;
8. 逆向计算价值;
9. 保存最优控制;
10. 正向回溯最优策略。

关键估计: 有限时域 Bellman 算子非扩张:  $\|TV - TW\|_\infty \leq \|V - W\|_\infty$ 。折扣问题中:  $\|TV - TW\|_\infty \leq \beta \|V - W\|_\infty$ 。

结论: 在状态定义正确时, 局部阶段最优选择与最优未来价值结合得到全局最优策略。

常见失败原因: 状态遗漏历史信息; 递推方向写反; 终端条件缺失; 只给最优值不回溯策略; 忽略状态空间指数增长。



