

PhD Qualification Exam in Artificial Intelligence

Mock Examination No. 1– Standard Solutions

说明。本答案给出可核查的关键推导、必要假设和结论。等价方法若逻辑完整、符号一致，可按评分细则给分。四个方向均给出答案，实际考试仍按三选一规则中的三个方向计分。

A. Machine Learning Theory

1. [3 pts.] 答案依次为

True, False, False, True, True, False.

第二项只检查对角线不够，必须要求任意有限 Gram matrix 为 PSD。第三项中，严格可分时可沿分离方向把 logistic loss 压到 0，但通常没有有限参数达到该下确界。最后一项把 training performance 当成 generalization，缺少任何概率界或独立测试证据。

Scoring Guide. 每项 0.5 分；不要求理由。

2. [7 pts.] 结论为 $\text{VCdim}(\mathcal{H}) = d$ 。

下界。取 d 个点 $x^{(i)} = e_i$ 。给定任意标记集合 $S \subseteq [d]$ ，令

$$a_i = \begin{cases} 2, & i \in S, \\ 1/2, & i \notin S. \end{cases}$$

所有 a_i 都为正。对点 e_j ，除第 j 个坐标外均为 0，故

$$h_a(e_j) = 1 \iff 1 \leq a_j \iff j \in S.$$

因此这 d 个点被打散。

上界。假设互异点 $x^{(1)}, \dots, x^{(n)}$ 被打散。对每个 r ，考虑仅把 $x^{(r)}$ 标成 0、其余点标成 1 的标记。存在阈值向量 a 包含其余所有点却排除 $x^{(r)}$ ，所以至少有一个坐标 $j(r)$ 满足

$$x_{j(r)}^{(r)} > a_{j(r)} \geq \max_{s \neq r} x_{j(r)}^{(s)}.$$

即 $x^{(r)}$ 必须在某个坐标上是严格唯一最大值。两个不同点不可能在同一坐标上都成为严格唯一最大值，因此映射 $r \mapsto j(r)$ 是单射，故 $n \leq d$ 。上下界合并得到结论。

Scoring Guide. 构造并打散 d 个点 3 分；从 “one-negative” 标记推出唯一最大坐标 3 分；单射计数和结论 1 分。

3. [8 pts.] 记 $t_i = y_i \theta^\top z_i$ ，并令 $s_i = \sigma(-t_i) = 1/(1 + e^{t_i})$ 。

(a) 单样本损失 $\ell_i = \log(1 + e^{-t_i})$ 满足

$$\frac{\partial \ell_i}{\partial t_i} = -\sigma(-t_i) = -s_i.$$

所以

$$\nabla J(\theta) = -\frac{1}{m} \sum_{i=1}^m y_i z_i \sigma(-y_i \theta^\top z_i) + \lambda \theta.$$

(b) 因为 $\frac{d}{dt}\sigma(-t) = -\sigma(t)\sigma(-t)$,

$$\nabla^2 J(\theta) = \frac{1}{m} \sum_{i=1}^m z_i z_i^\top \sigma(t_i) \sigma(-t_i) + \lambda I_p.$$

第一项为 PSD, 故 $\nabla^2 J \succeq \lambda I_p$, 即 J 是 λ -strongly convex. 又因 $J(\theta) \geq \lambda \|\theta\|^2 / 2$, 函数 coercive 且连续, 所以极小点存在; 强凸性再给出唯一性。

(c) 若存在 $\bar{\theta}$ 使 $y_i \bar{\theta}^\top z_i > 0$ 对所有 i 成立, 则

$$J_0(c\bar{\theta}) = \frac{1}{m} \sum_i \log(1 + e^{-cy_i \bar{\theta}^\top z_i}) \rightarrow 0 \quad (c \rightarrow \infty).$$

每个有限 c 下每项均严格为正, 因此下确界 0 通常不在有限参数处达到。故无正则 MLE 不必存在; 参数范数会沿分离方向发散。

Scoring Guide. 梯度 3 分; Hessian 2 分、强凸/存在唯一性 1 分; 可分数据的缩放论证与结论 2 分。

4. [9 pts.] 对 margin constraint 使用 $\alpha_i \geq 0$, 对 $\xi_i \geq 0$ 使用 $\beta_i \geq 0$. Lagrangian 为

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + C \sum_i \xi_i - \sum_i \alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] - \sum_i \beta_i \xi_i.$$

Stationarity 给出

$$w = \sum_i \alpha_i y_i x_i, \quad \sum_i \alpha_i y_i = 0, \quad C - \alpha_i - \beta_i = 0.$$

由于 $\beta_i \geq 0$, 最后一个条件等价于 $0 \leq \alpha_i \leq C$. 消去 (w, b, ξ) 后得到

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m \alpha_i \alpha_j y_i y_j x_i^\top x_j, \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0. \end{aligned}$$

除 primal/dual feasibility 与 stationarity 外, complementary slackness 为

$$\alpha_i [y_i(w^\top x_i + b) - 1 + \xi_i] = 0, \quad \beta_i \xi_i = (C - \alpha_i) \xi_i = 0.$$

若 $0 < \alpha_i < C$, 则 $\beta_i = C - \alpha_i > 0$, 故 $\xi_i = 0$; 又 $\alpha_i > 0$ 使 margin constraint 取等号。因此

$$b = y_i - w^\top x_i.$$

多个此类点存在时可平均其 b 以减小数值误差。最终

$$f(x) = \sum_{i: \alpha_i > 0} \alpha_i y_i x_i^\top x + b,$$

只有 $\alpha_i > 0$ 的 support vectors 贡献预测。

Scoring Guide. Lagrangian 与三个 stationarity 条件 3 分; 完整 dual 3 分; 两条互补松弛、 b 的恢复和 support-vector 说明各 1 分。

5. [6 pts.] 结论是

$$K_c \text{ 为 PSD kernel} \iff c \leq 1.$$

当 $c \leq 1$ 时定义 $\psi_c(i) \in \mathbb{R}^N$:

$$\psi_c(i) = (\sqrt{1-c}, \mathbf{1}\{2 \leq i\}, \mathbf{1}\{3 \leq i\}, \dots, \mathbf{1}\{N \leq i\})^\top.$$

于是

$$\langle \psi_c(i), \psi_c(j) \rangle = (1-c) + \sum_{r=2}^N \mathbf{1}\{r \leq i\} \mathbf{1}\{r \leq j\} = (1-c) + (\min\{i, j\} - 1) = K_c(i, j).$$

所以任意 Gram matrix 均为 PSD。若 $c > 1$ ，单点 Gram matrix $[K_c(1, 1)] = [1-c]$ 有负二次型，直接违反 PSD 条件。

Scoring Guide. 正确范围 2 分；显式 feature map 与内积核对 3 分； $c > 1$ 的反证 1 分。

B. Deep Learning and Reinforcement Learning
1. [8 pts.] 令 $e_y \in \mathbb{R}^C$ 为第 y 个标准基向量。softmax-cross-entropy 的合并梯度为

$$\delta_o := \nabla_o \ell = p - e_y \in \mathbb{R}^C.$$

由矩阵链式法则，

$$\nabla_{W_2} \ell = \delta_o h^\top \in \mathbb{R}^{C \times r}, \quad \nabla_{b_2} \ell = \delta_o \in \mathbb{R}^C,$$

$$\delta_h := \nabla_h \ell = W_2^\top \delta_o \in \mathbb{R}^r.$$

取 $r_a \in \mathbb{R}^r$ ，其中 $(r_a)_j = 1$ 当 $a_j > 0$ ，为 0 当 $a_j < 0$ ；在 $a_j = 0$ 时可按实现选择 $[0, 1]$ 中的一个次梯度，常取 0。于是

$$\delta_a := \nabla_a \ell = \delta_h \odot r_a \in \mathbb{R}^r,$$

$$\nabla_{W_1} \ell = \delta_a x^\top \in \mathbb{R}^{r \times d}, \quad \nabla_{b_1} \ell = \delta_a \in \mathbb{R}^r.$$

每个 outer product 的左、右因子维度与相应权重矩阵一致，因而没有转置歧义。

Scoring Guide. $p - e_y$ 2 分；第二层梯度 2 分；ReLU 链式传播 2 分；第一层梯度及全部维度 2 分。

2. [8 pts.]

(a) $Q, K \in \mathbb{R}^{L \times d_k}$, $V \in \mathbb{R}^{L \times d_v}$, score 和 attention matrix 均在 $\mathbb{R}^{L \times L}$, $Y \in \mathbb{R}^{L \times d_v}$ 。

(b) 对 $X' = PX$ ，有 $Q' = PQ, K' = PK, V' = PV$ ，从而

$$S' = \frac{Q' K'^\top}{\sqrt{d_k}} = P \frac{Q K^\top}{\sqrt{d_k}} P^\top = P S P^\top.$$

行 softmax 同时置换行和每一行中的列，故

$$\text{softmax}_{\text{row}}(P S P^\top) = P \text{softmax}_{\text{row}}(S) P^\top.$$

令 $A = \text{softmax}_{\text{row}}(S)$ ，则

$$Y' = (P A P^\top)(P V) = P A Y = P Y.$$

这证明了 permutation equivariance。

- (c) 若没有 positional information, 任意 token 重排只会导致输出按同样方式重排, 模型无法由内容本身区分序列次序。一个精确做法是在投影前令

$$X'_i = X_i + p_i,$$

其中 p_i 是位置 i 的固定 sinusoidal vector 或可学习且依赖 i 的向量; 此时一般有 $P(X + P_{\text{pos}}) \neq PX + P_{\text{pos}}$, 从而打破该对称性。

Scoring Guide. 维度 2 分; score 变换 1 分、row-softmax 恒等式 2 分、输出证明 1 分; 顺序后果和精确位置注入各 1 分。

3. [9 pts.]

- (a) 将任意 $q_\phi(z | x)$ 乘除进边缘似然:

$$\begin{aligned} \log p_\theta(x) &= \log \int q_\phi(z | x) \frac{p_\theta(x, z)}{q_\phi(z | x)} dz \\ &\geq \mathbb{E}_{q_\phi(z | x)} [\log p_\theta(x, z) - \log q_\phi(z | x)] \\ &= \mathbb{E}_q [\log p_\theta(x | z)] - \text{KL}(q_\phi(z | x) \| p_\theta(z | x)) =: \mathcal{L}(\theta, \phi; x). \end{aligned}$$

不等式为 Jensen。等号成立当且仅当 $p_\theta(x, z)/q_\phi(z | x)$ 对 q 几乎处处为常数, 即 $q_\phi(z | x) = p_\theta(z | x)$ 几乎处处。

- (b) 由 Bayes rule 直接重排可得

$$\log p_\theta(x) - \mathcal{L}(\theta, \phi; x) = \text{KL}(q_\phi(z | x) \| p_\theta(z | x)) \geq 0.$$

- (c) 取 $\varepsilon \sim \mathcal{N}(0, I)$, 使用

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \varepsilon.$$

随机性移到与参数无关的 ε 上, 因而可对 μ_ϕ, σ_ϕ 做 pathwise differentiation。

- (d) 若 decoder 足够强, 可能在不使用 z 的情况下拟合 $p(x)$ 。此时令 $q_\phi(z | x) = p(z)$ 同时把 KL 项降到 0, 导致 z 与 x 近似独立, 即 posterior collapse。

Scoring Guide. Jensen 推导、两项 ELBO、等号条件共 4 分; gap 2 分; reparameterization 2 分; collapse 机制 1 分。

4. [8 pts.] 对任意 V, W , 记

$$q_a^V(s) = r(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s').$$

利用 $|\max_a u_a - \max_a v_a| \leq \max_a |u_a - v_a|$,

$$\begin{aligned} |(TV)(s) - (TW)(s)| &\leq \max_a \gamma \left| \sum_{s'} P(s' | s, a) (V(s') - W(s')) \right| \\ &\leq \gamma \|V - W\|_\infty. \end{aligned}$$

对 s 取最大即

$$\|TV - TW\|_\infty \leq \gamma \|V - W\|_\infty.$$

有限状态空间上的 $\mathbb{R}^{|S|}$ 在 supremum norm 下完备; Banach fixed-point theorem 因而给出唯一 fixed point V^* 。Value iteration 满足

$$\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty.$$

特别地, 要把初始误差降到 ε , 只需 $k \geq \log(\|V_0 - V^*\|_\infty / \varepsilon) / \log(1/\gamma)$ 。

Scoring Guide. max inequality 2 分；逐状态概率加权界 2 分；contraction 结论 1 分；唯一 fixed point 1 分；迭代误差界 2 分。

C. Optimization Methods in Artificial Intelligence

1. [4 pts.] proximal 子问题是一强凸问题，其最优性条件为

$$0 \in \partial R(x^+) + \frac{1}{\gamma}(x^+ - x + \gamma \nabla f(x)).$$

故存在 $r^+ \in \partial R(x^+)$ 使

$$r^+ = \frac{x - x^+}{\gamma} - \nabla f(x).$$

由凸性 $R(z) \geq R(x^+) + \langle r^+, z - x^+ \rangle$ ，移项并代入 r^+ ：

$$R(x^+) + \langle \nabla f(x), x^+ - z \rangle \leq R(z) + \frac{1}{\gamma} \langle x - x^+, x^+ - z \rangle.$$

最后使用恒等式

$$2 \langle x - x^+, x^+ - z \rangle = \|x - z\|^2 - \|x^+ - z\|^2 - \|x - x^+\|^2$$

即得题设不等式。

Scoring Guide. proximal 最优性 1 分；选取正确 subgradient 1 分；凸性不等式 1 分；三点恒等式与结论 1 分。

2. [6 pts.] 由 L -smoothness,

$$f(x^+) \leq f(x) + \langle \nabla f(x), x^+ - x \rangle + \frac{L}{2} \|x^+ - x\|^2.$$

由凸性， $f(z) \geq f(x) + \langle \nabla f(x), z - x \rangle$ 。相减得到

$$f(x^+) - f(z) \leq \langle \nabla f(x), x^+ - z \rangle + \frac{L}{2} \|x^+ - x\|^2.$$

把 Problem 1 的 R 不等式相加，得到

$$F(x^+) - F(z) \leq \frac{\|x - z\|^2 - \|x^+ - z\|^2}{2\gamma} - \left(\frac{1}{2\gamma} - \frac{L}{2} \right) \|x^+ - x\|^2.$$

这里 smoothness 用于上界 $f(x^+)$ ，convexity 用于下界 $f(z)$ ；两项作用不能互换。

Scoring Guide. smoothness 2 分；convexity 1 分；相减后的 inner product 1 分；与 Problem 1 正确合并并得到系数 2 分。

3. [5 pts.] 在 Problem 2 中取 $z = x^*$ 。当 $\gamma \leq 1/L$ 时最后一项非正，因此

$$F(x^{j+1}) - F^* \leq \frac{\|x^j - x^*\|^2 - \|x^{j+1} - x^*\|^2}{2\gamma}.$$

从 $j = 0$ 到 $k - 1$ 求和，

$$\sum_{j=0}^{k-1} [F(x^{j+1}) - F^*] \leq \frac{\|x^0 - x^*\|^2}{2\gamma}.$$

再在 Problem 2 中取 $z = x^j$ 可见 $F(x^{j+1}) \leq F(x^j)$, 故最后一项不大于前 k 项平均值:

$$F(x^k) - F^* \leq \frac{\|x^0 - x^*\|^2}{2\gamma k}.$$

Scoring Guide. 单步距离递推 2 分; 望远镜求和 1 分; 说明 objective monotonicity 1 分; last-iterate 界 1 分。

4. [6 pts.] 目标按坐标分离。固定 u_j , 令

$$\phi(v) = \lambda|v| + \frac{1}{2\gamma}(v - u_j)^2.$$

若 $v > 0$, stationarity 给出 $\lambda + (v - u_j)/\gamma = 0$, 故 $v = u_j - \gamma\lambda$, 它仅在 $u_j > \gamma\lambda$ 时属于该区域。若 $v < 0$, 则 $-\lambda + (v - u_j)/\gamma = 0$, 故 $v = u_j + \gamma\lambda$, 要求 $u_j < -\gamma\lambda$ 。在 $v = 0$, 最优性为

$$0 \in \lambda[-1, 1] - u_j/\gamma \iff |u_j| \leq \gamma\lambda.$$

因此

$$[\text{prox}_{\gamma\lambda\|\cdot\|_1}(u)]_j = \text{sign}(u_j) \max\{|u_j| - \gamma\lambda, 0\}.$$

Scoring Guide. 可分性 1 分; 正区间 1.5 分; 负区间 1.5 分; 零点 subgradient 条件 1 分; 合并 soft-threshold 公式 1 分。

5. [12 pts.]

(a) 写 $\varepsilon_{k,j} = g(x^k, \xi_{k,j}) - \nabla f(x^k)$ 。则 $\mathbb{E}_k \varepsilon_{k,j} = 0$, 所以 $\mathbb{E}_k g_k = \nabla f(x^k)$ 。条件独立使交叉项消失:

$$\mathbb{E}_k \left\| \frac{1}{B} \sum_{j=1}^B \varepsilon_{k,j} \right\|^2 = \frac{1}{B^2} \sum_{j=1}^B \mathbb{E}_k \|\varepsilon_{k,j}\|^2 \leq \frac{\sigma^2}{B}.$$

(b) 令 $e_k = x^k - x^*$, $d_k = \nabla f(x^k) - \nabla f(x^*)$; 强凸可微函数在无约束最优点满足 $\nabla f(x^*) = 0$ 。条件期望消去噪声交叉项:

$$\mathbb{E}_k \|e_k - \gamma(d_k + \bar{\varepsilon}_k)\|^2 = \|e_k - \gamma d_k\|^2 + \gamma^2 \mathbb{E}_k \|\bar{\varepsilon}_k\|^2.$$

对 L -smooth、 μ -strongly convex 的 f , 有 interpolation inequality

$$\langle d_k, e_k \rangle \geq \frac{\mu L}{\mu + L} \|e_k\|^2 + \frac{1}{\mu + L} \|d_k\|^2.$$

因此在 $\gamma = 2/(L + \mu)$ 时,

$$\begin{aligned} \|e_k - \gamma d_k\|^2 &\leq \left(1 - \frac{4\mu L}{(L + \mu)^2}\right) \|e_k\|^2 \\ &= \left(\frac{L - \mu}{L + \mu}\right)^2 \|e_k\|^2 = q^2 \|e_k\|^2. \end{aligned}$$

合并方差界即得题设递推。

(c) 对全期望递推并展开几何级数:

$$\mathbb{E} \|e_k\|^2 \leq q^{2k} \|e_0\|^2 + \frac{\gamma^2 \sigma^2}{B} \frac{1 - q^{2k}}{1 - q^2}.$$

故上界的 limiting noise floor 为

$$\frac{\gamma^2 \sigma^2}{B(1 - q^2)} = \frac{\sigma^2}{B\mu L}.$$

在题设 conditional independence 下, 增大 batch size 把该方差项和 noise floor 精确按 $1/B$ 缩小, 但不改变 deterministic contraction factor q^2 ; 计算代价则通常随 B 增加。

Scoring Guide. 无偏 1 分、交叉项消失和 σ^2/B 2 分; 条件展开 1 分、interpolation inequality 2 分、 q^2 代数 2 分; 几何级数 2 分、闭式 noise floor 1 分、batch 解释 1 分。

D. Natural Language Processing

1. [7 pts.] 记 $a = u_w^\top v_c$ 、 $b_j = u_{n_j}^\top v_c$ 。利用

$$\frac{d}{da}[-\log \sigma(a)] = \sigma(a) - 1, \quad \frac{d}{db}[-\log \sigma(-b)] = \sigma(b),$$

得到

$$\nabla_{v_c} \ell = (\sigma(a) - 1)u_w + \sum_{j=1}^K \sigma(b_j)u_{n_j},$$

$$\nabla_{u_w} \ell = (\sigma(a) - 1)v_c, \quad \nabla_{u_{n_j}} \ell = \sigma(b_j)v_c.$$

若同一个 negative 多次出现, 其梯度贡献相加。Gradient descent 沿负梯度更新: 当正对得分不高时, $1 - \sigma(a) > 0$ 把 u_w 与 v_c 拉近; negative 项把 u_{n_j} 与 v_c 推远。若一个 negative 实际与 context 同义或同属有效 latent class, 算法却强迫二者分离, 形成错误监督, 尤其在高相似度时梯度 $\sigma(b_j)$ 较大。

Scoring Guide. 两个 scalar derivatives 1 分; v_c 梯度 2 分; output/negative embedding 梯度 2 分; pull/push 与 false-negative 解释各 1 分。

2. [9 pts.]

(a) 定义未归一化 forward quantity

$$\alpha_1(j) = e^{e_\theta(1,j;x)}, \quad \alpha_t(j) = e^{e_\theta(t,j;x)} \sum_{i=1}^K \alpha_{t-1}(i) e^{A_{ij}}.$$

则 $Z_\theta(x) = \sum_{j=1}^K \alpha_T(j)$ 。直接实现时间复杂度为 $O(TK^2)$, 滚动存储为 $O(K)$; 实际计算应使用 log-sum-exp 防止上溢。

(b) 若 $s_\theta(x, y) = \theta^\top F(x, y)$, 单样本 negative log-likelihood 为

$$\mathcal{L}(\theta) = -\theta^\top F(x, y^{\text{gold}}) + \log \sum_{y'} e^{\theta^\top F(x, y')}.$$

微分得到

$$\nabla \mathcal{L} = -F(x, y^{\text{gold}}) + \mathbb{E}_{Y \sim p_\theta(\cdot|x)} F(x, Y).$$

即 observed feature counts 与 model expected counts 之差。

(c) Hessian 为

$$\nabla^2 \mathcal{L} = \text{Cov}_{p_\theta(\cdot|x)}[F(x, Y)] \succeq 0,$$

所以线性参数 CRF 的 NLL 为凸函数 (未必严格凸, 故 minimizer 未必唯一)。若 emission 来自 jointly trained neural network, score 对网络参数非线性, $-s_\theta(x, y^{\text{gold}}) + \log \sum e^{\theta^\top F(x, y')}$ 一般非凸, 上述 covariance 只覆盖对线性 score parameter 的二阶结构。

Scoring Guide. forward recursion、终止求和、复杂度各 1 分；NLL 形式 1 分、完整梯度 2 分；covariance Hessian 2 分、neural nonconvex caveat 1 分。

3. [7 pts.] 取 corrupted triple $\tilde{q} = (h', r, t')$, margin $\rho > 0$ 。一项损失可写为

$$\ell = [\rho + d(h, r, t) - d(h', r, t')]_+.$$

记 $q = e_h + e_r - e_t$, $\tilde{q} = e_{h'} + e_r - e_{t'}$ 。当 hinge active 且实体不重合时,

$$\nabla_{e_h} \ell = 2q, \quad \nabla_{e_t} \ell = -2q, \quad \nabla_{e_{h'}} \ell = -2\tilde{q}, \quad \nabla_{e_{t'}} \ell = 2\tilde{q},$$

$$\nabla_{e_r} \ell = 2q - 2\tilde{q}.$$

若实体重合, 应把同一参数收到的贡献相加; hinge inactive 时所有梯度为 0。常配合 entity norm constraint, 防止仅靠放大范数满足 margin。

一种 non-identifiability 是给所有 entity embedding 同时加同一向量 a : $(e_h + a) + e_r - (e_t + a) = q$, 所有得分不变。结构性失败是 one-to-many: 固定 (h, r) 时模型希望多个正确 tail 都接近同一点 $e_h + e_r$, 难以同时区分多个合法尾实体。

Scoring Guide. margin loss 2 分; active-term 的正负 triple 梯度 3 分; non-identifiability 1 分; 结构失败 1 分。

4. [10 pts.] 一个完整方案如下。

离线数据与索引。将每个版本切成保留 section/document 边界的 chunks, 保存 (source, version, $t_{\text{from}}, t_{\text{to}}$)。稀疏索引使用 BM25 terms, 稠密索引存储 bi-encoder embedding z_c ; 同一文档版本不可跨 train/test temporal cutoff 泄漏。若无 QA labels, 可用相邻标题-正文、同一条款 paraphrase 或 citation link 构造 positive pairs, 并用同主题错误版本作 hard negatives, 训练 contrastive retriever。

查询、过滤与排序。从问题解析目标日期 τ 和实体/条款, 形成 sparse query 与 dense vector z_q 。先执行硬过滤

$$t_{\text{from}}(c) \leq \tau < t_{\text{to}}(c),$$

再合并 BM25 和 cosine top- K_0 , 例如

$$s_{\text{hybrid}}(q, c) = \alpha \tilde{s}_{\text{BM25}} + (1 - \alpha) \cos(z_q, z_c).$$

cross-encoder 对 (q, c, τ) rerank 至 K 条, 并检查同一条款是否存在版本冲突; 冲突未能消解时系统应 abstain 或明确报告。

生成与引用。Generator 输入包括 query、日期、按来源分隔的 passages、版本号 and citation IDs。用带 context 的 conditional NLL/SFT 训练, 并可加入 citation-support classification loss。推理时要求每个可核查 claim 绑定 citation ID, 最后由 verifier 检查 claim 是否被所引 passage 支持以及 passage 在 τ 有效。

复杂度。对 M 个 chunks 和 embedding dimension d , 离线 dense storage 为 $O(Md)$; 精确 dense search 为 $O(Md)$, ANN 降低平均检索代价但不改变存储主项。Reranking 约为 $O(K_0 L_q L_c d)$ 的 Transformer attention 主项 (具体取决于拼接长度); generation 对总 context length L 的标准 attention 为 $O(L^2 d)$ 每层。

无泄漏评价。按时间切分: 只用 cutoff 前可见版本建索引, 并用之后收集、但询问历史日期的问题测试。分别报告 temporal-filter accuracy、Recall@ K 、MRR、answer EM/F1、claim-level faithfulness、citation precision/recall、abstention calibration 与 latency。做 remove-retrieval、remove-reranker、remove-time-filter 消融。

失败与诊断。(i) retrieval miss: gold evidence 未入 top- K , 由 Recall@ K 定位, 改进 query rewriting/hybrid retrieval; (ii) stale-version answer: 检索到无效版本, 由 temporal-filter error 和 version-conflict rate 定位; (iii) evidence present but unsupported generation: Recall 高而 faithfulness 低, 由 claim verifier 定位; (iv) prompt injection in archived text: 通过来源隔离、指令/内容分层与 adversarial test 诊断。

Scoring Guide. 离线版本化与索引 2 分; 检索、时间约束和 rerank 2 分; 生成目标、引用和推理顺序 2 分; 复杂度 1 分; 时间切分的分层评价 2 分; 至少两个 failure/diagnostic 配对 1 分。