

PhD Qualification Exam in Artificial Intelligence

Mock Examination No. 2– Standard Solutions

说明。本答案给出可核查的关键推导、必要假设和结论。等价方法若逻辑完整、符号一致，可按评分细则给分。四个方向均给出答案，实际考试仍按三选一规则中的三个方向计分。

A. Machine Learning Theory

1. [3 pts.] 答案为

True, False, True, False, True, False.

Scoring Guide. 每项 0.5 分。

2. [8 pts.] 令 $r = \text{rank}(X)$ ，并使用 thin/full SVD，使非零奇异值为 $\sigma_1, \dots, \sigma_r$ 。梯度为

$$\nabla J_\lambda(w) = \frac{1}{m} X^\top (Xw - y) + \lambda w.$$

Hessian $X^\top X/m + \lambda I \succeq \lambda I$ ，所以解存在且唯一，并满足

$$\hat{w}_\lambda = (X^\top X + m\lambda I)^{-1} X^\top y.$$

写 $X = U\Sigma V^\top$ 后，

$$\hat{w}_\lambda = \sum_{j=1}^r \frac{\sigma_j}{\sigma_j^2 + m\lambda} (u_j^\top y) v_j.$$

在第 j 个可识别方向，least-squares coefficient $(u_j^\top y)/\sigma_j$ 被乘以

$$\frac{\sigma_j^2}{\sigma_j^2 + m\lambda} \in (0, 1).$$

对 $v \in \ker(X)$ ，data term 不变，而 penalty 在系数为 0 时最小，所以 ridge 解的 null-space component 为 0。令 $\lambda \downarrow 0$ 得

$$\hat{w}_\lambda \rightarrow \sum_{j=1}^r \frac{u_j^\top y}{\sigma_j} v_j = X^\dagger y,$$

即 least-squares 解集合中的 minimum-norm solution。

Scoring Guide. 梯度/Hessian 与唯一性 2 分；矩阵闭式解 2 分；SVD 展开 2 分；shrinkage、kernel component、极限各合计 2 分。

3. [7 pts.] 条件于训练样本后， $\mathcal{P}$ 已固定，且 validation examples 与其独立。对每个固定 T ，Hoeffding inequality 给出

$$\mathbb{P}(|\hat{L}_{\text{val}}(T) - L(T)| > \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

对 M 个候选作 union bound，取

$$\varepsilon = \sqrt{\frac{\log(2M/\delta)}{2n}},$$

则以至少 $1 - \delta$ 的概率，所有 $T \in \mathcal{P}$ 同时满足偏差不超过 ε 。令 $T^* \in \arg \min_{T \in \mathcal{P}} L(T)$ ，在该事件上

$$L(\hat{T}) \leq \hat{L}_{\text{val}}(\hat{T}) + \varepsilon \leq \hat{L}_{\text{val}}(T^*) + \varepsilon \leq L(T^*) + 2\varepsilon.$$

因此

$$L(\hat{T}) \leq \min_{T \in \mathcal{P}} L(T) + 2\sqrt{\frac{\log(2M/\delta)}{2n}}.$$

独立性使“对固定候选的 validation loss 是 i.i.d. 平均”成立。若 validation labels 参与生成 $\mathcal{P}$ ，候选类本身依赖同一随机标签；上面的固定类 union bound 不再适用，除非把整个自适应选择过程的复杂度计入或使用新的独立 holdout。

Scoring Guide. 单候选 Hoeffding 2 分；union bound 和 ε 2 分；三步 oracle comparison 2 分；independence/leakage 说明 1 分。

4. [7 pts.]

(a) 独立同分布给出

$$\mathbb{E}[D^2] = d\mu, \quad \text{Var}(D^2) = d\nu, \quad \frac{\sqrt{\text{Var}(D^2)}}{\mathbb{E}[D^2]} = \frac{\sqrt{\nu}}{\mu\sqrt{d}}.$$

(b) 相对波动按 $d^{-1/2}$ 缩小，说明在这类坐标模型中 pairwise squared distances 会集中，“最近”距离与典型距离的相对差别可能变小。这不是任意高维分布下的定理：相关坐标、低维流形、稀疏结构或适合任务的 metric 都可能改变结论。

(c) 经典一致性条件包括 $k_m \rightarrow \infty$ 且 $k_m/m \rightarrow 0$ ，并需适当的空间/分布正则条件。标准化、降维或 metric learning 的参数必须只由 training split 拟合，再原样应用于 validation/test；用 test statistics 会造成 leakage。

Scoring Guide. 三个矩量/比率 3 分；集中解释及 caveat 2 分；两个 k 条件和 train-only preprocessing 2 分。

5. [8 pts.] 充分性。 设 x 为 s -sparse, $T = \text{supp}(x)$ 。任意其他可行点可写成 $z = x + h$ ，其中 $h \in \ker(A) \setminus \{0\}$ 。由三角不等式与 NSP，

$$\|z\|_1 = \|x_T + h_T\|_1 + \|h_{T^c}\|_1 \geq \|x\|_1 - \|h_T\|_1 + \|h_{T^c}\|_1 > \|x\|_1.$$

故 x 是唯一 minimizer。

必要性。 若 NSP 失败，则存在 $h \neq 0$ 和 $|T| \leq s$ 使 $\|h_T\|_1 \geq \|h_{T^c}\|_1$ 。取

$$x = -h_T, \quad z = h_{T^c}.$$

x 是 s -sparse，且 $z - x = h \in \ker(A)$ ，所以 $Az = Ax$ ；但

$$\|z\|_1 = \|h_{T^c}\|_1 \leq \|h_T\|_1 = \|x\|_1.$$

因此 x 不是该 basis-pursuit 问题的唯一解，与“每个 s -sparse vector 均唯一恢复”矛盾。两方向合并即得等价性。

Scoring Guide. 充分方向的可行差向量 1 分、分块三角不等式 2 分、唯一性 1 分；必要方向的失败 witness 1 分、构造 x, z 2 分、结论 1 分。

B. Deep Learning and Reinforcement Learning

1. [9 pts.]

- (a) 输出公式为 $\lfloor (H + 2p - d_{il}(k - 1) - 1)/s \rfloor + 1$ 。Layer 1 输出 $32 \times 32 \times 16$ ，Layer 2 输出 $32 \times 32 \times 32$ 。参数量为

$$16(3 \cdot 3 \cdot 3 + 1) + 32(3 \cdot 3 \cdot 16 + 1) = 448 + 4640 = \boxed{5088}.$$

- (b) 初始化 receptive field $r_0 = 1$ 、jump $j_0 = 1$ 。Layer 1 有 effective kernel 3:

$$r_1 = 1 + (3 - 1) \cdot 1 = 3, \quad j_1 = 1 \cdot 2 = 2.$$

Layer 2 的 dilation 2 使 effective kernel 为 $2(3 - 1) + 1 = 5$:

$$r_2 = 3 + (5 - 1) \cdot 2 = \boxed{11}, \quad j_2 = 2.$$

- (c) 在 stride 1 且边界处理与所考察平移相容时，共享卷积满足 $C(T_\Delta X) = T_\Delta C(X)$ 。Stride 2 只对与采样格对齐的平移保持相应等变；一像素平移一般改变采样 phase。Zero padding 在边界引入与内部不同的虚拟值，故有限图像边缘处的严格等变性会失败。

Scoring Guide. 两个输出 shape 2 分、参数量 1 分；两层 receptive field/jump 各 1.5 分；等变条件、stride、boundary 各 1 分。

2. [8 pts.] 定义

$$q_a = \frac{e^{z^\top z_a / \tau}}{\sum_{b \in A} e^{z^\top z_b / \tau}}.$$

每个 positive term 的分母相同，因此

$$\ell = -\frac{1}{\tau|P|} \sum_{p \in P} z^\top z_p + \log \sum_{a \in A} e^{z^\top z_a / \tau}.$$

微分得

$$\nabla_z \ell = \frac{1}{\tau} \left(\sum_{a \in A} q_a z_a - \frac{1}{|P|} \sum_{p \in P} z_p \right).$$

负梯度把 anchor 拉向 positive centroid，并从 softmax-weighted batch centroid 拉开；高相似度样本因 q_a 大而贡献更强。较小 τ 使分布更尖锐、梯度整体含 $1/\tau$ ，会强调 hard examples，但也放大噪声。False-negative 处理可以用 label/multi-positive mask 从 denominator 移除已知同类样本，或使用 debiased contrastive weighting；不能简单把所有近邻永久删掉而不检查语义。

若 $z = \tilde{z} / \|\tilde{z}\|$ ，对未归一化参数的梯度包含切空间投影 $(I - zz^\top) \nabla_z \ell / \|\tilde{z}\|$ 。因此球面几何下只有正交于 z 的分量改变方向。

Scoring Guide. softmax weights 1 分；完整梯度 3 分；pull/push 1 分；temperature 1 分；false-negative 方法 1 分；tangent interpretation 1 分。

3. [9 pts.]

(a) 固定 x ，最大化 $a \log D + b \log(1 - D)$ ，其中 $a = p_{\text{data}}(x)$ 、 $b = p_g(x)$ 。一阶条件与负二阶导给出

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}$$

(在分母正的点上)。

(b) 令 $m = (p_{\text{data}} + p_g)/2$ 。代回得到

$$\begin{aligned} V(D^*, G) &= \int p_{\text{data}} \log \frac{p_{\text{data}}}{2m} + \int p_g \log \frac{p_g}{2m} \\ &= -\log 4 + \text{KL}(p_{\text{data}} \| m) + \text{KL}(p_g \| m) \\ &= \boxed{-\log 4 + 2 \text{JS}(p_{\text{data}} \| p_g)}. \end{aligned}$$

(c) 写 $D = \sigma(a)$ 。对 discriminator logit,

$$\frac{d}{da} \log(1 - \sigma(a)) = -D, \quad \frac{d}{da} [-\log \sigma(a)] = -(1 - D).$$

当 fake sample 上 $D \approx 0$, saturating derivative 近 0, 而 non-saturating derivative 近 -1 , 后者给 generator 更强的 early gradient。JS 结论假设固定 G 时 D 达到全局最优、容量充分且分布条件合适; 实际 alternating SGD 是 nonconvex–nonconcave dynamics, 可能振荡或停在非全局点, 故不构成收敛证明。

Scoring Guide. 点态优化和 D^* 3 分; 代回两项 KL 2 分、JS 结论 1 分; 两个 logit derivative 1 分、梯度解释 1 分、非收敛 caveat 1 分。

4. [7 pts.] SARSA 使用实际下一动作 $A_{t+1} \sim \pi(\cdot | S_{t+1})$:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha_t [R_t + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)].$$

条件于 (S_t, A_t) , target 的期望是 Bellman expectation operator

$$(T^\pi Q)(s, a) = r(s, a) + \gamma \sum_{s'} P(s' | s, a) \sum_{a'} \pi(a' | s') Q(s', a').$$

故 SARSA 是 on-policy。Q-learning 为

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha_t [R_t + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t)],$$

其条件期望 target 是 T^*Q , 行为数据可以来自探索策略, 故为 off-policy。

有限 MDP、bounded rewards、每个 (s, a) 被访问无限多次, 且相应步长满足 $\sum_t \alpha_t(s, a) = \infty$ 、 $\sum_t \alpha_t(s, a)^2 < \infty$ 等标准噪声条件时, tabular Q-learning 几乎必然收敛到 Q^* 。DQN 同时含 nonlinear function approximation、bootstrapping 与 off-policy data; 投影 Bellman operator 不再必为 contraction, 故 tabular proof 不能直接移植。

Scoring Guide. 两条更新各 1.5 分; 两个 operator/策略分类 2 分; 探索和步长条件 1 分; DQN caveat 1 分。

C. Optimization Methods in Artificial Intelligence

1. [10 pts.]

(a) 投影子问题最优性给出, 对任意 $z \in X$,

$$\langle x^+ - (x - \gamma \nabla f(x)), z - x^+ \rangle \geq 0.$$

等价地, 令 $G_\gamma = (x - x^+)/\gamma$, 有

$$\langle \nabla f(x) - G_\gamma(x), z - x^+ \rangle \geq 0.$$

(b) 凸可微 constrained optimum 的一阶充要条件为 $\langle \nabla f(x^*), z - x^* \rangle \geq 0$ 对所有 $z \in X$ 。把 $x = x^+ = x^*$ 代入上面的 projection VI, 恰得到该条件; 反向同理。因此 fixed-point 与最优性等价。

(c) 在 VI 中取 $z = x$, 得到 $\langle \nabla f(x), G_\gamma(x) \rangle \geq \|G_\gamma(x)\|^2$ 。又 $x^+ - x = -\gamma G_\gamma(x)$, 由 smoothness,

$$\begin{aligned} f(x^+) &\leq f(x) - \gamma \langle \nabla f(x), G_\gamma(x) \rangle + \frac{L\gamma^2}{2} \|G_\gamma(x)\|^2 \\ &\leq f(x) - \gamma \left(1 - \frac{L\gamma}{2}\right) \|G_\gamma(x)\|^2. \end{aligned}$$

当 $0 < \gamma < 2/L$ 时系数严格为正。

Scoring Guide. projection VI 3 分; constrained first-order condition 1 分、双向 fixed-point 2 分; 取 $z = x$ 1 分、smoothness 1 分、最终下降系数 2 分。

2. [10 pts.] 投影非扩张且 $x^* \in X$, 所以

$$\begin{aligned} \|x^{k+1} - x^*\|^2 &\leq \|x^k - x^* - \eta g^k\|^2 \\ &= \|x^k - x^*\|^2 - 2\eta \langle g^k, x^k - x^* \rangle + \eta^2 \|g^k\|^2 \\ &\leq \|x^k - x^*\|^2 - 2\eta [F(x^k) - F^*] + \eta^2 G^2, \end{aligned}$$

其中最后一步使用 subgradient inequality。移项并从 $k = 0$ 到 $K - 1$ 求和:

$$\frac{1}{K} \sum_{k=0}^{K-1} [F(x^k) - F^*] \leq \frac{R^2}{2\eta K} + \frac{\eta G^2}{2}.$$

由凸性 $F(\bar{x}^K) \leq K^{-1} \sum_k F(x^k)$, 故

$$F(\bar{x}^K) - F^* \leq \frac{R^2}{2\eta K} + \frac{\eta G^2}{2}.$$

取 $\eta = R/(G\sqrt{K})$ 得

$$F(\bar{x}^K) - F^* \leq \frac{RG}{\sqrt{K}}.$$

证明控制的是函数值之和, 再通过 Jensen 转给 average; 它没有证明 $F(x^k)$ 单调, 故不能把 $\bar{x}^K$ 无条件替换为 last iterate。

Scoring Guide. 投影递推 2 分; subgradient inequality 2 分; 望远镜 2 分; Jensen 1 分; 最优步长和 rate 2 分; last-iterate caveat 1 分。

3. [13 pts.]

(a) 令 $Q = U\Lambda U^\top$ 、 $z^k = U^\top x^k$ 。每个特征方向独立满足

$$z_i^{k+1} = (1 + \beta - \gamma\lambda_i)z_i^k - \beta z_i^{k-1}.$$

故 characteristic polynomial 为

$$p_\lambda(r) = r^2 - a_\lambda r + \beta, \quad a_\lambda = 1 + \beta - \gamma\lambda.$$

(b) 对实二次多项式 $r^2 - ar + \beta$ ，二阶 Schur/Jury 条件是

$$|\beta| < 1, \quad 1 - a + \beta > 0, \quad 1 + a + \beta > 0.$$

可用变换 $r = (1+s)/(1-s)$ 验证：单位圆内部映为左半平面，而变换后多项式系数为 $1 - a + \beta, 2(1 - \beta), 1 + a + \beta$ ，二阶 Hurwitz 条件正是三者为正。题设已有 $0 \leq \beta < 1$ 。代入 a_λ ：

$$1 - a_\lambda + \beta = \gamma\lambda, \quad 1 + a_\lambda + \beta = 2(1 + \beta) - \gamma\lambda.$$

所以单方向稳定当且仅当 $0 < \gamma\lambda < 2(1 + \beta)$ 。对所有 $\lambda \in [\mu, L]$ 同时成立当且仅当

$$0 < \gamma < \frac{2(1 + \beta)}{L}.$$

(c) 此处上界为 $2(1.6)/25 = 0.128$ ，故 $\gamma = 0.1$ 稳定。 $\lambda = 1$ 时 $a = 1.5$ ，discriminant $a^2 - 4\beta = -0.15 < 0$ ； $\lambda = 25$ 时 $a = -0.9$ ，discriminant $-1.59 < 0$ 。两方向 roots 都是 conjugate pair，乘积为 $\beta = 0.6$ ，所以每个 root 的 modulus 均为

$$\sqrt{0.6} \approx 0.775.$$

Scoring Guide. 谱分解和 recurrence 3 分、polynomial 1 分; Jury/Hurwitz criterion 2 分、代入 2 分、uniform condition 1 分; 数值稳定判断 1 分、两个 discriminants 1 分、modulus 2 分。

D. Natural Language Processing

1. [6 pts.]

(a) MLE 为 $2/4 = 0.5$ ；add-one estimate 为 $(2 + 1)/(4 + 4) = 3/8 = 0.375$ 。

(b) 插值结果为

$$0.5(0.5) + 0.3(0.4) + 0.2(0.25) = \boxed{0.42}.$$

(c) 两 token 的平均 negative log-likelihood 为 $-\frac{1}{2}(\log 0.42 + \log 0.35)$ ，故

$$\text{PPL} = \exp \left[-\frac{1}{2} \log(0.42 \cdot 0.35) \right] = \frac{1}{\sqrt{0.147}} \approx \boxed{2.61}.$$

不同 tokenizer 改变 token 数、条件事件和每 token entropy 单位，所以其 PPL 不在同一尺度上。

Scoring Guide. MLE/add-one 各 1 分；插值代入和结果 2 分；PPL 公式/结果 1 分，tokenization caveat 1 分。

2. [9 pts.]

(a) 设 initial π_i 、transition A_{ij} 、emission $B_j(o)$ ，则

$$p(y_{1:T}, o_{1:T}) = \pi_{y_1} B_{y_1}(o_1) \prod_{t=2}^T A_{y_{t-1}, y_t} B_{y_t}(o_t).$$

监督 MLE 是相应 normalized counts: $\hat{\pi}_i = N_{\text{start}}(i)/N_{\text{seq}}$, $\hat{A}_{ij} = N(i \rightarrow j)/\sum_{j'} N(i \rightarrow j')$, $\hat{B}_j(v) = N(j \text{ emits } v)/\sum_{v'} N(j \text{ emits } v')$; 零计数时需要另加 smoothing, 而非由 MLE 自动产生。

(b) Forward recursion:

$$\alpha_1(j) = \pi_j B_j(o_1), \quad \alpha_t(j) = B_j(o_t) \sum_i \alpha_{t-1}(i) A_{ij}, \quad p(o_{1:T}) = \sum_j \alpha_T(j).$$

(c) Viterbi 可在 log domain 写为

$$\delta_1(j) = \log \pi_j + \log B_j(o_1),$$

$$\delta_t(j) = \log B_j(o_t) + \max_i [\delta_{t-1}(i) + \log A_{ij}], \quad \psi_t(j) = \arg \max_i [\delta_{t-1}(i) + \log A_{ij}].$$

从 $y_T^* = \arg \max_j \delta_T(j)$ 开始按 $y_{t-1}^* = \psi_t(y_t^*)$ 回溯。Forward 和 Viterbi 时间均为 $O(TK^2)$; Viterbi 保存 backpointers 为 $O(TK)$, 仅求 score 可滚动到 $O(K)$ 。

Scoring Guide. joint 1 分、三类 MLE 2 分；forward 初始化/递推/终止各 1 分；Viterbi recurrence 1 分、backtracking 1 分、复杂度 1 分。

3. [8 pts.] 约束给出 $T = C/P$, 故 excess loss 是

$$\phi(P) = AP^{-\alpha} + BC^{-\beta} P^{\beta}.$$

一阶条件

$$-\alpha AP^{-\alpha-1} + \beta BC^{-\beta} P^{\beta-1} = 0$$

等价于 $P^{\alpha+\beta} = (\alpha A/\beta B) C^{\beta}$ 。因此

$$P^*(C) = \left(\frac{\alpha A}{\beta B} \right)^{1/(\alpha+\beta)} C^{\beta/(\alpha+\beta)},$$

$$T^*(C) = \left(\frac{\beta B}{\alpha A} \right)^{1/(\alpha+\beta)} C^{\alpha/(\alpha+\beta)}.$$

代回可见两项都按

$$C^{-\alpha\beta/(\alpha+\beta)}$$

缩放；常数是

$$A \left(\frac{\alpha A}{\beta B} \right)^{-\alpha/(\alpha+\beta)} + B \left(\frac{\beta B}{\alpha A} \right)^{-\beta/(\alpha+\beta)}.$$

使用前至少要承认：(i) 该 law 是给定数据、tokenizer、architecture 和优化 pipeline 上的 empirical fit; (ii) $PT = C$ 忽略 context length、attention、hardware utilization 和 data quality 等成本；还需最优点处在拟合区间内部且训练达到相近 optimization error。

Scoring Guide. 消去 T 和一阶条件 2 分； P^* 2 分； T^* 1 分；loss exponent/constant 2 分；两个 caveats 1 分。

4. [10 pts.] 训练数据。正 triple 为 KB 中已观测 (h, r, t) 。Graph branch 用 $d_g = \|e_h + e_r - e_t\|^2$ ；text branch 用 bi-encoder $z_q = f_\theta(\text{name/description}(h), r)$ 与 $z_t = g_\theta(\text{description}(t))$ ，score 可取 dot product。Corruption 只从 relation range type 合法的实体采样，混合 uniform、frequency 和 current hard negatives；已在 KB 中为真的 corruption 从 negative set 过滤，降低 false negatives。

目标与约束。可用

$$[\rho + d_g(h, r, t) - d_g(h', r, t')]_+$$

加 text contrastive cross-entropy，并以 learned gate 融合 $s = -d_g + \lambda s_{\text{text}} + b_r$ 。限制 entity norms 或正则化，防止 margin 通过无界缩放实现；在 validation 上学习 λ 和 temperature calibration。

推理。先按 relation range type 过滤候选。ANN text index 和 graph score 各返回 top- K_0 ，取并集后由 cross-encoder 读取 query entity、relation、candidate description 进行 rerank。若 calibrated top probability 低、top-1/top-2 margin 小或 graph/text branches 冲突，则 abstain。

复杂度。存储 M 个 d 维 entity/text vectors 为 $O(Md)$ ；全量 TransE scoring 为 $O(Md)$ 每 query，ANN 降低平均候选生成开销；对 K_0 个候选作 cross-encoder reranking，其 Transformer 成本随拼接长度二次增长。

评价。使用 held-out triples，并按 standard filtered protocol 在排名时删除其他已知正确 tails；报告 filtered MRR、Hits@ K 、按 relation/type 分层结果、calibration error、coverage–accuracy curve 和 latency。按 entity/time 做 split 可检查 inductive generalization，避免同一事实改写泄漏。

失败分析。False negatives 会把未收录真 triple 错误推远，可由人工审计 top hard negatives、使用 reciprocal relations/外部证据和 positive-unlabeled weighting 缓解。TransE 的 one-to-many 关系把多个 tails 拉向同一 $e_h + e_r$ ；按 relation 报告性能，并可采用 relation-specific projection 或更有表达力的后续 reranker，而不宣称基础 TransE 已解决该结构问题。

Scoring Guide. graph/text data 与 type-aware negatives 2 分；objectives/constraints 2 分；candidate–rerank–abstain 2 分；complexity 1 分；filtered evaluation 2 分；两类指定 failure 1 分。