

PhD Qualification Exam in Artificial Intelligence

Mock Examination No. 3– Standard Solutions

说明。本答案给出可核查的关键推导、必要假设和结论。等价方法若逻辑完整、符号一致，可按评分细则给分。四个方向均给出答案，实际考试仍按三选一规则中的三个方向计分。

A. Machine Learning Theory

1. [8 pts.] 对任意固定 $h \in \mathcal{H}$ ，zero-one loss 落在 $[0, 1]$ ，Hoeffding inequality 给出

$$\mathbb{P}\left(|\hat{L}_S(h) - L_P(h)| > a\right) \leq 2e^{-2ma^2}.$$

对 M 个假设作 union bound，并令右端为 δ ，得到：以至少 $1 - \delta$ 的概率，

$$\sup_{h \in \mathcal{H}} |\hat{L}_S(h) - L_P(h)| \leq a_m := \sqrt{\frac{\log(2M/\delta)}{2m}}.$$

在该事件上，利用 $\hat{h}$ 的 ERM 性质，

$$L_P(\hat{h}) \leq \hat{L}_S(\hat{h}) + a_m \leq \hat{L}_S(h^*) + a_m \leq L_P(h^*) + 2a_m.$$

因此

$$L_P(\hat{h}) - L_P(h^*) \leq 2\sqrt{\frac{\log(2M/\delta)}{2m}}.$$

若要求右端不超过 ε ，一个显式充分条件是

$$m \geq \frac{2}{\varepsilon^2} \log \frac{2M}{\delta}.$$

这里只要求样本 i.i.d.、loss 有界和 $\mathcal{H}$ 有限；不需要 realizability。

Scoring Guide. 固定假设的 Hoeffding 2 分；union bound 与 uniform event 2 分；ERM 三步比较 3 分；显式样本量和 assumptions 1 分。

2. [8 pts.] 按定义

$$\hat{\mathfrak{R}}_S(\mathcal{F}) = \mathbb{E}_\sigma \left[\sup_{\|w\| \leq B} \frac{1}{m} \sum_{i=1}^m \sigma_i w^\top x_i \right] = \frac{1}{m} \mathbb{E}_\sigma \left[\sup_{\|w\| \leq B} w^\top \sum_i \sigma_i x_i \right].$$

Cauchy–Schwarz 及 Euclidean ball 的 support function 给出

$$\hat{\mathfrak{R}}_S(\mathcal{F}) = \frac{B}{m} \mathbb{E}_\sigma \left\| \sum_i \sigma_i x_i \right\|_2 \leq \frac{B}{m} \sqrt{\mathbb{E}_\sigma \left\| \sum_i \sigma_i x_i \right\|_2^2}.$$

由于 Rademacher signs 独立、均值为零，交叉项消失，故

$$\mathbb{E}_\sigma \left\| \sum_i \sigma_i x_i \right\|_2^2 = \sum_i \|x_i\|^2 \leq mR^2.$$

于是

$$\widehat{\mathfrak{R}}_S(\mathcal{F}) \leq BR/\sqrt{m}.$$

若对预测值作用的 loss $u \mapsto \ell(u, y)$ 是 L_ℓ -Lipschitz (通常先减去与 u 无关的常数使其在 0 处为 0), contraction lemma 给出 loss class 的复杂度至多 L_ℓ 倍。维数没有显式出现, 是因为假设类和数据分别以 Euclidean norms B, R 控制, Rademacher 二阶矩为 $\sum_i \|x_i\|^2$; 维数影响已隐含在这些 norm bounds 中。

Scoring Guide. 定义和 supremum 2 分; Cauchy–Schwarz/Jensen 2 分; Rademacher 二阶矩 2 分; Lipschitz contraction 1 分; 无显式维数解释 1 分。

3. [8 pts.] 记 $w = A(S)$ 、 $w' = A(S')$, 且两样本只在第 j 个观测不同。两个目标均为 λ -strongly convex。最优性与 strong convexity 分别给出

$$F_S(w') \geq F_S(w) + \frac{\lambda}{2} \|w' - w\|^2, \quad F_{S'}(w) \geq F_{S'}(w') + \frac{\lambda}{2} \|w - w'\|^2.$$

相加并消去 $m - 1$ 个共同 loss 及相同 regularizer, 得到

$$\lambda \|w - w'\|^2 \leq \frac{1}{m} \{\ell(w', z_j) - \ell(w, z_j) + \ell(w, z'_j) - \ell(w', z'_j)\}.$$

两项 Lipschitz bounds 各不超过 $\rho \|w - w'\|$, 所以 (非零时约去该 norm; 零时结论显然)

$$\|A(S) - A(S')\| \leq \frac{2\rho}{\lambda m}.$$

对任意测试点 z ,

$$|\ell(A(S), z) - \ell(A(S'), z)| \leq \rho \|A(S) - A(S')\| \leq \frac{2\rho^2}{\lambda m} =: \beta.$$

在训练样本 i.i.d.、算法确定性 (或条件于其独立随机性)、population loss 可积, 且上述 uniform stability 对所有替换样本和测试点成立时, 标准 replace-one argument 给出

$$|\mathbb{E}[L_P(A(S)) - \widehat{L}_S(A(S))]| \leq \beta.$$

这是期望 generalization gap; 若需 high-probability 结论, 还要额外的 loss boundedness/tail 条件。

Scoring Guide. 两个 strong-convexity inequalities 2 分; 消项与参数距离 2 分; uniform stability 2 分; 期望泛化界及 assumptions 2 分。

4. [9 pts.] 下界。取标准基 $e_1, \dots, e_d$ 。对任意标签 $b_i \in \{0, 1\}$, 令 $w_i = 1$ 若 $b_i = 1$, 否则 $w_i = -1$, 则 $\mathbf{1}\{w^\top e_i > 0\} = b_i$ 。故这 d 点可被 shatter。

上界。任取 $d + 1$ 个点 $x_1, \dots, x_{d+1} \in \mathbb{R}^d$ 。它们线性相关, 存在不全为零的 a_i 使

$$\sum_{i=1}^{d+1} a_i x_i = 0.$$

只考虑 $a_i \neq 0$ 的 indices, 并给出标签 $b_i = 1$ 当 $a_i > 0$ 、 $b_i = 0$ 当 $a_i < 0$; 系数为零的点任意标记。若某 w 实现这些标签, 则

$$a_i w^\top x_i > 0 \quad (a_i > 0), \quad a_i w^\top x_i \leq 0 \quad (a_i < 0),$$

因为负标签意味着 $w^\top x_i \leq 0$ 。至少一个正系数时, 上式求和严格为正; 但

$$\sum_i a_i w^\top x_i = w^\top \sum_i a_i x_i = 0,$$

矛盾。若原依赖的非零系数全为负，将所有 a_i 乘以 -1 。因此任意 $d+1$ 点都不能被 shatter，结合下界得

$$\boxed{\text{VCdim}(\mathcal{H}_d) = d.}$$

该论证不要求 general position，并涵盖零点、重复点和低秩点集。

Scoring Guide. 标准基下界 3 分；任意 $d+1$ 点线性依赖 2 分；按系数符号构造标签 2 分；严格矛盾和退化情形 2 分。

B. Deep Learning and Reinforcement Learning

1. [8 pts.] 令 $\delta_y = \nabla_y J \in \mathbb{R}^d$ 。按计算图反传：

$$\delta_h = W_2^\top \delta_y \in \mathbb{R}^r, \quad \delta_a = \delta_h \odot \phi'(a) \in \mathbb{R}^r.$$

于是

$$\boxed{\nabla_{W_2} J = \delta_y h^\top \in \mathbb{R}^{d \times r}}, \quad \boxed{\nabla_{W_1} J = \delta_a x^\top \in \mathbb{R}^{r \times d}},$$

以及 identity branch 与 residual branch 相加得到

$$\boxed{\nabla_x J = \delta_y + W_1^\top \delta_a = \left[I + W_1^\top \text{diag}(\phi'(a)) W_2^\top \right] \delta_y \in \mathbb{R}^d.}$$

其中直接项 δ_y 不经过两个权重矩阵和 activation derivative，因而即使 residual Jacobian 很小仍有 gradient path；这不保证深网络绝不爆炸或消失，但改善了传播结构。

若 $W_2 = 0$ ，则 $\delta_h = \delta_a = 0$ ，所以首个 backward pass 上 $\nabla_{W_1} J = 0$ ，而

$$\nabla_{W_2} J = \delta_y h^\top$$

通常非零，且 $\nabla_x J = \delta_y$ 。若恰有 $h = 0$ 或 $\delta_y = 0$ ， W_2 的梯度才会退化为零。

Scoring Guide. 三个中间 adjoints 2 分；两个矩阵梯度及 dimensions 2 分；输入梯度 2 分；identity-path 解释 1 分；zero initialization 情形 1 分。

2. [9 pts.]

(a) 由 $x_a = z_a$ ，先得 $z_a = x_a$ ，再逐坐标解出

$$\boxed{z_b = (x_b - t(x_a)) \odot \exp[-s(x_a)].}$$

(b) Forward Jacobian 对 split 后变量呈 block triangular:

$$\frac{\partial x}{\partial z} = \begin{bmatrix} I & 0 \\ * & \text{diag}(\exp(s(z_a))) \end{bmatrix}.$$

故

$$\log \left| \det \frac{\partial x}{\partial z} \right| = \sum_j s_j(z_a).$$

Change of variables 给出

$$\boxed{\log p_X(x) = \log p_Z(z(x)) - \sum_j s_j(x_a).}$$

(c) 对数据 $x^{(1)}, \dots, x^{(n)}$, exact NLL 为

$$\mathcal{J}(s, t) = - \sum_{i=1}^n \left[\log p_Z(z(x^{(i)})) - \sum_j s_j(x_a^{(i)}) \right].$$

$\exp(s) > 0$ 保证每一尺度非零, 从而映射双射且 Jacobian determinant 非零。允许 scale 为 0 会把不同 z_b 压到同一 x_b , inverse 不存在, Lebesgue density 的 change-of-variables likelihood 也失效。

Scoring Guide. inverse 3 分; block Jacobian 与 determinant 2 分、density 1 分; dataset NLL 2 分; zero-scale 失效原因 1 分。

3. [10 pts.]

(a) Gaussian conditional 的 log-density 中与 x_t 有关部分为

$$-\frac{\|x_t - \sqrt{\bar{\alpha}_t}x_0\|^2}{2(1 - \bar{\alpha}_t)},$$

故

$$\nabla_{x_t} \log q(x_t | x_0) = -\frac{x_t - \sqrt{\bar{\alpha}_t}x_0}{1 - \bar{\alpha}_t} = -\frac{\varepsilon}{\sqrt{1 - \bar{\alpha}_t}}.$$

(b) 记 conditional score 为 $U(x_t, x_0)$, marginal score 为 $u_t(x_t)$ 。在可交换微分和积分的正则条件下, Fisher identity 给出

$$\begin{aligned} u_t(x_t) &= \frac{\nabla_{x_t} \int q(x_t | x_0) p(x_0) dx_0}{q_t(x_t)} \\ &= \mathbb{E}[U(x_t, x_0) | x_t]. \end{aligned}$$

对任意 predictor $s_\theta(x_t, t)$, 条件期望的正交分解为

$$\mathbb{E} \|s_\theta - U\|^2 = \mathbb{E} \|s_\theta - u_t\|^2 + \mathbb{E} \|U - u_t\|^2.$$

交叉项因 $\mathbb{E}[U - u_t | x_t] = 0$ 而消失。第二项与 θ 无关, 故两个 regression objectives 有相同 minimizers。

(c) 由 (a), 可令

$$s_\theta(x_t, t) = -\frac{\varepsilon_\theta(x_t, t)}{\sqrt{1 - \bar{\alpha}_t}}.$$

conditional-score squared loss 于是等价于带时间权重的 noise loss

$$\mathbb{E}_{t, x_0, \varepsilon} \left[\frac{1}{1 - \bar{\alpha}_t} \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2 \right].$$

常见的 simplified loss 去掉该正权重, 改变不同 t 的相对权重, 但不改变每个固定 t, x_t 下的 population 条件均值 minimizer。

Scoring Guide. conditional score 与 noise 形式 3 分; Fisher identity 2 分、正交分解 2 分; noise objective 2 分、score conversion 1 分。

4. [6 pts.] Score-function identity 给出

$$\mathbb{E}[u(A) \mid s] = \sum_a \pi_\theta(a \mid s) \nabla_\theta \log \pi_\theta(a \mid s) = \nabla_\theta \sum_a \pi_\theta(a \mid s) = 0$$

(连续动作时将 sum 换成 integral，并假设可交换微分)。因此

$$\mathbb{E}[g_b \mid s] = \mathbb{E}[u(A)Q(s, A) \mid s]$$

与 b 无关。令 $F(b) = \mathbb{E}[\|u\|^2 (Q - b)^2 \mid s]$ 。若分母非零，

$$F'(b) = 2\mathbb{E}[\|u\|^2 (b - Q) \mid s] = 0$$

给出

$$b^*(s) = \frac{\mathbb{E}[\|u(A)\|^2 Q(s, A) \mid s]}{\mathbb{E}[\|u(A)\|^2 \mid s]}.$$

若分母为零，则 $u = 0$ a.s.，任意 baseline 都有相同二阶矩。

Scoring Guide. score 均值为零 2 分；unbiasedness 1 分；二阶矩目标和求导 2 分；退化情形 1 分。

C. Optimization Methods in Artificial Intelligence

1. [11 pts.]

(a) 取 $t = -\partial_i f(x)/L_i$ 代入 coordinate smoothness:

$$f(x^+) \leq f(x) - \frac{(\partial_i f(x))^2}{2L_i}.$$

因此

$$\mathbb{E}[f(x^+) \mid x] \leq f(x) - \frac{1}{2} \sum_i p_i \frac{(\partial_i f(x))^2}{L_i}.$$

(b) 记 $S_L = \sum_i L_i$ 。当 $p_i = L_i/S_L$ 时，

$$\mathbb{E}[f(x^+) \mid x] \leq f(x) - \frac{1}{2S_L} \|\nabla f(x)\|^2.$$

μ -strong convexity 蕴含 Polyak–Łojasiewicz inequality $\|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^*)$ 。故重复取全期望得到

$$\mathbb{E}[f(x^k) - f^*] \leq \left(1 - \frac{\mu}{\sum_i L_i}\right)^k (f(x^0) - f^*).$$

(c) Uniform sampling 给出

$$\frac{1}{d} \sum_i \frac{(\partial_i f)^2}{L_i} \geq \frac{1}{dL_{\max}} \|\nabla f\|^2,$$

从而 contraction factor 至多 $1 - \mu/(dL_{\max})$ 。因 $\sum_i L_i \leq dL_{\max}$ ，importance bound 不差；当多数 L_i 远小于 $L_{\max}$ 时严格改善。这里比较的是 worst-case guarantees。

Scoring Guide. coordinate decrease 与条件期望 4 分；importance 代入、PL、迭代 rate 共 4 分；uniform bound 与改善条件 3 分。

2. [12 pts.] 记 $F_k = f(x_k) - f^*$ 。为与题面的 $t_0 = 1$ indexing 一致，对 $k \geq 1$ 定义

$$u_k = t_{k-1}x_k - (t_{k-1} - 1)x_{k-1} - x^*, \quad \Phi_k = \frac{2}{L}t_{k-1}^2F_k + \|u_k\|^2.$$

首先，convexity 与 L -smoothness 对 gradient step $x^+ = y - L^{-1}\nabla f(y)$ 给出，对任意 z ，

$$\begin{aligned} f(x^+) &\leq f(y) + \langle \nabla f(y), x^+ - y \rangle + \frac{L}{2} \|x^+ - y\|^2 \\ &\leq f(z) + \langle \nabla f(y), y - z \rangle - \frac{1}{2L} \|\nabla f(y)\|^2 \\ &= f(z) + \frac{L}{2} (\|y - z\|^2 - \|x^+ - z\|^2). \end{aligned} \quad (1)$$

第一行用 smoothness，第二行用 convexity 的 tangent bound，最后代入 gradient step。

在从 y_k 到 x_{k+1} 的 step 中，分别把 (1) 取 $z = x_k$ 与 $z = x^*$ ，按权重 $t_k - 1$ 与 1 组合。展开平方后得到

$$\frac{2}{L}t_k^2F_{k+1} + \|t_kx_{k+1} - (t_k - 1)x_k - x^*\|^2 \leq \frac{2}{L}(t_k^2 - t_k)F_k + \|t_ky_k - (t_k - 1)x_k - x^*\|^2. \quad (2)$$

这里使用 $2\langle a, b \rangle = \|a\|^2 + \|b\|^2 - \|a - b\|^2$ ，没有舍弃正负未定项。再由

$$t_k^2 - t_k = t_{k-1}^2, \quad t_ky_k - (t_k - 1)x_k = t_{k-1}x_k - (t_{k-1} - 1)x_{k-1},$$

可把 (2) 精确写成 $\Phi_{k+1} \leq \Phi_k$ ，因此该 potential telescopes。

对首步 $x_1 = x_0 - L^{-1}\nabla f(x_0)$ ，在 (1) 中取 $y = x_0, z = x^*$ 得

$$\frac{2}{L}F_1 + \|x_1 - x^*\|^2 \leq \|x_0 - x^*\|^2,$$

即 $\Phi_1 \leq \|x_0 - x^*\|^2$ 。故

$$F_k \leq \frac{L\|x_0 - x^*\|^2}{2t_{k-1}^2}.$$

递推可归纳得 $t_j \geq (j + 2)/2$ ，于是 $t_{k-1} \geq (k + 1)/2$ ，最终

$$f(x_k) - f^* \leq \frac{2L\|x_0 - x^*\|^2}{(k + 1)^2}, \quad k \geq 1.$$

该结论不需要 strong convexity；convexity 用于 tangent bound，smoothness 用于 (1) 的 descent inequality。

Scoring Guide. gradient-step inequality 且注明 assumptions 3 分；定义有效 potential 2 分；两条 identity 与 telescoping 4 分； t_k 下界和显式 rate 2 分；assumptions 说明 1 分。

3. [10 pts.] 由 L -smoothness，条件于历史，

$$\begin{aligned} \mathbb{E}_k f(x^{k+1}) &\leq f(x^k) - \gamma \langle \nabla f(x^k), \mathbb{E}_k g_k \rangle + \frac{L\gamma^2}{2} \mathbb{E}_k \|g_k\|^2 \\ &\leq f(x^k) - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\nabla f(x^k)\|^2 + \frac{L\gamma^2\sigma^2}{2}. \end{aligned}$$

这里使用 unbiasedness 及 $\mathbb{E}_k \|g_k\|^2 = \|\nabla f(x^k)\|^2 + \mathbb{E}_k \|g_k - \nabla f(x^k)\|^2$ 。当 $\gamma \leq 1/L$ ，梯度项系数至少 $\gamma/2$ 。取全期望并求和，利用 $f(x^K) \geq f_{\inf}$ ，得到

$$\boxed{\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E} \|\nabla f(x^k)\|^2 \leq \frac{2\Delta_0}{\gamma K} + L\gamma\sigma^2, \quad \Delta_0 = f(x^0) - f_{\inf}.}$$

当 $\sigma > 0$ ，可取

$$\gamma = \min \left\{ \frac{1}{L}, \sqrt{\frac{2\Delta_0}{L\sigma^2 K}} \right\}.$$

在 square-root 分支有效时，右端为 $2\sqrt{2L\Delta_0\sigma^2/K} = O(K^{-1/2})$ ；若 $\sigma = 0$ ，取 $\gamma = 1/L$ 得 $2L\Delta_0/K$ 。结论要求 lower boundedness、global smoothness、conditional unbiasedness 与 bounded conditional variance；它不宣称 nonconvex stationary point 是 global optimum。

Scoring Guide. smoothness 条件期望递推 3 分；二阶矩分解 1 分；求和 bound 3 分；合法步长与 rate 2 分；assumptions/caveat 1 分。

D. Natural Language Processing

1. [8 pts.] 固定 (w, c) ，记 $a = C(w, c)$ 、 $b = kC(w)q(c)$ 。目标 $a \log \sigma(x) + b \log \sigma(-x)$ 的导数为

$$a(1 - \sigma(x)) - b\sigma(x).$$

内部最优点满足 $a = (a + b)\sigma(x)$ ，所以

$$\boxed{x_{wc} = \log \frac{C(w, c)}{kC(w)q(c)}}.$$

若 $q(c) = C(c)/N$ ，其中 $N = \sum_{w,c} C(w, c)$ ，则

$$x_{wc} = \log \frac{NC(w, c)}{C(w)C(c)} - \log k = \boxed{\text{PMI}(w, c) - \log k}.$$

当 $C(w, c) = 0$ 时 optimum 在 $-\infty$ ，应按极限理解。实际 $UV^\top$ 的 rank 至多 embedding dimension，不能一般精确表示 full shifted-PMI matrix；此外 dot products 共享 vectors，且 finite-data optimization、regularization、subsampling 或非 unigram noise distribution 都会改变精确等式。

Scoring Guide. 目标导数和 stationarity 3 分；最优 log ratio 2 分；PMI 化简 1 分；至少两项不精确原因 2 分。

2. [8 pts.] complete joint distribution 为

$$p(\{\phi_k\}, \{\theta_d, z_d, w_d, y_d\} \mid \alpha, \eta, \beta) = \prod_{k=1}^K \text{Dir}(\phi_k; \eta) \prod_d \left[\text{Dir}(\theta_d; \alpha) \prod_{n=1}^{N_d} \theta_{d, z_{dn}} \phi_{z_{dn}, w_{dn}} \sigma(\beta^\top \bar{z}_d)^{y_d} [1 - \sigma(\beta^\top \bar{z}_d)]^{1-y_d} \right].$$

令 $a_d = \beta^\top \bar{z}_d$ 。单文档 label NLL 满足

$$\ell_d = -y_d \log \sigma(a_d) - (1 - y_d) \log[1 - \sigma(a_d)], \quad \frac{d\ell_d}{da_d} = \sigma(a_d) - y_d,$$

所以

$$\nabla_{\beta} \ell_d = [\sigma(\beta^{\top} \bar{z}_d) - y_d] \bar{z}_d.$$

在 joint posterior/objective 中, label likelihood 依赖 latent assignments 的 $\bar{z}_d$, 因此改变 z 的 posterior responsibilities, 进而改变 topic-word counts 和 ϕ_k 。若固定无监督学得的 topics 后才训练 β , labels 才不会反向改变 topics。

Scoring Guide. 完整 priors 与 token factors 3 分; label factor 1 分; NLL 梯度 2 分; labels 改变 topics 的路径 2 分。

3. [9 pts.] 因果版本维护

$$S_i = S_{i-1} + \varphi(k_i) v_i^{\top} \in \mathbb{R}^{r \times d_v}, \quad r_i = r_{i-1} + \varphi(k_i) \in \mathbb{R}^r,$$

并计算

$$Y_i = \frac{\varphi(q_i)^{\top} S_i}{\varphi(q_i)^{\top} r_i}.$$

假设 denominator 正且 feature computation 不占主导, 每步为 $O(rd_v)$, 总时间 $O(Lrd_v)$; streaming memory 为 $O(rd_v + r)$, 若保留全部 outputs 再加 $O(Ld_v)$ 。

展开得

$$Y_i = \frac{\sum_{j \leq i} K_{ij} v_j}{\sum_{j \leq i} K_{ij}}, \quad K_{ij} = \varphi(q_i)^{\top} \varphi(k_j) \geq 0.$$

故 $j \leq i$ 且 $K_{ij} \neq 0$ 时, $\partial Y_i / \partial v_j = [K_{ij} / \sum_{\ell \leq i} K_{i\ell}] I$ 非零, 较早位置可直接影响后续输出。局限是有限维 feature kernel 通常只近似 softmax exponential kernel, 可能有 approximation error; denominator 也可能数值不稳。

Scoring Guide. 两个 prefix states 3 分; 输出与 dimensions 1 分; 时间/空间 2 分; 直接影响证明 2 分; 局限 1 分。

4. [8 pts.] 两个 unknown atoms 构成两个 binary nodes; implication factor 连接 A, B , 另有两个 unary factors。在 satisfied-grounding convention 下, implication 只有 $(1, 0)$ 时不满足。各世界分数为

(A, B)	$(0, 0)$	$(0, 1)$	$(1, 0)$	$(1, 1)$
score	1.5	1.1	0.8	1.9

因此

$$Z = e^{1.5} + e^{1.1} + e^{0.8} + e^{1.9}, \quad (A, B)_{\text{MAP}} = (1, 1).$$

概率比为

$$\frac{P(1, 1)}{P(0, 0)} = e^{1.9-1.5} = e^{0.4}.$$

B 的负权重表示满足 unary formula B 会把 log-score 降低 0.4, 即在没有其他 factors 时偏好 $B = 0$; 它不是 hard constraint。

Scoring Guide. ground network 1 分; 四个分数 3 分; partition function 1 分; MAP 1 分; 概率比 1 分; 负权重解释 1 分。