

# PhD Qualification Exam in Artificial Intelligence

## Mock Examination No. 4– Standard Solutions

说明。本答案给出可核查的关键推导、必要假设和结论。等价方法若逻辑完整、符号一致，可按评分细则给分。四个方向均给出答案，实际考试仍按三选一规则中的三个方向计分。

### A. Machine Learning Theory

#### 1. [8 pts.]

(a) False. 学习算法可以在连续空间记住 training points，并在其他点全部输出错误标签；zero training error 本身没有控制 hypothesis-class complexity，也没有独立验证。即使  $m$  增长，每个  $m$  都可选择新的 memorizing classifier。

(b) False. 对两个输入取 Gram matrix

$$K = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}.$$

它对称，但 eigenvalues 为  $3, -1$ ，故不是 PSD kernel。

(c) False. 若存在  $v$  使  $y_i v^\top x_i > 0$ ，则 logistic log-likelihood 沿  $w = cv$  随  $c \rightarrow \infty$  逼近 supremum 0，而任意有限  $c$  的 negative log-likelihood 仍为正。因此一般不存在有限 MLE；加 coercive regularization 后才有限 minimizer。

(d) True. 任意有限样本的 Gram matrices  $K_1, K_2 \succeq 0$ 。和  $K_1 + K_2 \succeq 0$ ；逐点乘积 kernel 的 Gram matrix 是  $K_1 \circ K_2$ ，由 Schur product theorem 仍 PSD。

**Scoring Guide.** 每项判断 0.5 分、有效 proof/counterexample 1.5 分。

2. [7 pts.] 条件于被抽中的 subset 及其 observed labels，算法的输出已完全确定。对任一 unseen point  $x$ ，其 target label 在均匀随机 labeling 下仍是独立 Bernoulli(1/2)，故不论算法预测什么，

$$\mathbb{P}(\hat{h}(x) \neq h^*(x) \mid S) = \frac{1}{2}.$$

令  $U$  为  $m$  个 unseen points。由 linearity of expectation（不需要这些 error indicators 相互独立），

$$\mathbb{E} \left[ \frac{1}{m} \sum_{x \in U} \mathbf{1}\{\hat{h}(x) \neq h^*(x)\} \right] = \left[ \frac{1}{2} \right].$$

再对 subset 和 observed labels 取期望不改变结果。这是 No Free Lunch 型构造：若所有 labeling 等可能、没有 target regularity 或 data-generating structure，则未观察 labels 不可预测。它不说明真实任务无法学习；smoothness、margin、low complexity、distributional assumptions 或 inductive bias 会排除绝大多数任意 labeling，并使 generalization 可能。

**Scoring Guide.** 条件化后算法固定 2 分；unseen label 独立公平 2 分；期望误差计算 2 分；结论边界 1 分。

### 3. [8 pts.]

- (a) 单个随机 classifier 恰好猜对  $n$  个 validation labels 的概率为  $2^{-n}$ 。按题设 classifiers 的预测相互独立，故

$$\mathbb{P}(\min_j \widehat{L}_{\text{val}}(h_j) = 0) = 1 - (1 - 2^{-n})^M.$$

- (b) 选择规则只使用 validation data。对 fresh example，所有候选的预测仍与新 label 独立，因此被选 classifier 的 expected test error 仍为  $1/2$ 。当  $M \gg 2^n$  时，上式接近 1，validation error 近 0 只是对 selection noise 的过拟合。
- (c) 将数据分成 training、model-selection validation 和一次性 final test；所有候选与 hyperparameters 定稿后，final test 只使用一次，conditional on the selected model，其 sample mean 是 population error 的 unbiased estimate。若  $M$  个 candidates 在查看 independent validation labels 前已经固定，Hoeffding plus union bound 给出：以至少  $1 - \delta$  的概率，

$$\sup_{j \leq M} |\widehat{L}_{\text{val}}(h_j) - L(h_j)| \leq \sqrt{\frac{\log(2M/\delta)}{2n}}.$$

因此选择后的 oracle excess 至多该量的两倍。Repeated adaptive reuse 需要新的 holdout、nested cross-validation 或显式 adaptive-data-analysis correction。

**Scoring Guide.** 零 validation error 概率 3 分；fresh error 与 discrepancy 2 分；独立 final test 1 分、uniform correction 2 分。

### 4. [10 pts.] 令

$$\mathcal{S} = \text{span}\{k(x_i, \cdot) : i \leq m\}.$$

对任意  $f \in \mathcal{H}$  作正交分解  $f = f_{\parallel} + f_{\perp}$ ，其中  $f_{\parallel} \in \mathcal{S}$ 、 $f_{\perp} \perp \mathcal{S}$ 。由 reproducing property，

$$f_{\perp}(x_i) = \langle f_{\perp}, k(x_i, \cdot) \rangle_{\mathcal{H}} = 0,$$

故  $f(x_i) = f_{\parallel}(x_i)$ ，data-dependent term 不变。同时 Pythagoras 给出

$$\|f\|_{\mathcal{H}}^2 = \|f_{\parallel}\|_{\mathcal{H}}^2 + \|f_{\perp}\|_{\mathcal{H}}^2.$$

若  $f_{\perp} \neq 0$ ，strictly increasing  $\Omega$  使  $f_{\parallel}$  的 objective 严格更小，所以任何 minimizer 必有  $f_{\perp} = 0$ 。

写  $f(\cdot) = \sum_{j=1}^m \alpha_j k(x_j, \cdot)$ ，Gram matrix  $K_{ij} = k(x_i, x_j)$ ，则 training-value vector 为  $K\alpha$ ，且  $\|f\|_{\mathcal{H}}^2 = \alpha^{\top} K \alpha$ 。有限维问题为

$$\min_{\alpha \in \mathbb{R}^m} \Psi(K\alpha) + \Omega\left(\sqrt{\alpha^{\top} K \alpha}\right).$$

$K$  可 singular，因而 coefficient vector 不必唯一，即使 RKHS function 唯一。若  $\Omega$  只 nondecreasing，投影  $f_{\parallel}$  的 objective 不会更大，所以至少存在 span 中的 minimizer；但 flat region 允许带非零  $f_{\perp}$  的 minimizers，故不能说 every minimizer 都在 span 中。

**Scoring Guide.** 正交分解 2 分；reproducing property 2 分；strict monotonicity 排除正交分量 2 分；finite problem/-Gram/norm 3 分；nondecreasing 情形 1 分。

## B. Deep Learning and Reinforcement Learning

1. [8 pts.] 令  $q_\ell = \mathbb{E}[(a_i^{(\ell)})^2]$ ,  $a^{(\ell)} = W^{(\ell)}h^{(\ell-1)}$ 。在零均值、独立近似下,

$$q_\ell = \sigma_w^2 \mathbb{E}_{Z \sim \mathcal{N}(0, q_{\ell-1})}[\phi(Z)^2].$$

若直接跟踪 activation second moment  $s_\ell = \mathbb{E}[(h_i^{(\ell)})^2]$ , 则  $q_\ell = \sigma_w^2 s_{\ell-1}$ 、 $s_\ell = \mathbb{E}\phi(Z)^2$ 。

令  $r_\ell = \text{Var}(\partial J / \partial a_i^{(\ell)})$ 。反传式  $\delta^{(\ell)} = \phi'(a^{(\ell)})W^{(\ell+1)\top} \delta^{(\ell+1)}$  给出

$$r_\ell \approx \sigma_w^2 \mathbb{E}[\phi'(Z)^2] r_{\ell+1}.$$

对 ReLU 和 symmetric continuous  $Z$ ,

$$\mathbb{E}[\text{ReLU}(Z)^2] = q/2, \quad \mathbb{E}[\text{ReLU}'(Z)^2] = 1/2.$$

所以 forward 和 backward second moments 每层都乘  $\sigma_w^2/2$ , critical choice 为  $\sigma_w^2 = 2$ 。

若 hidden units 的 incoming/outgoing parameters 完全相同, 它们的 forward values、loss derivatives 和 parameter gradients 在任一 minibatch 上相同。Permutation symmetry 下 deterministic gradient descent 更新后仍相同, 故这些 units 不能分化; all-zero 情形还可能因 downstream zero products 造成早期 zero gradients。Random asymmetric initialization 用于打破这一对称。

**Scoring Guide.** forward recursion 3 分; backward recursion 2 分、ReLU specialization/critical variance 1 分; symmetry preservation 2 分。

2. [7 pts.]

(a) 取 latent dimension 不小于 input dimension, encoder  $e(x) = x$ 、decoder  $d(z) = z$ , 则所有样本 reconstruction loss 为 0, 但 representation 只是复制 input; 更高容量时还可把每个 training example 映到任意 code 并由 decoder 记忆 lookup table。两者都不保证 semantic organization 或 out-of-sample utility。

(b) 令 clean  $X \sim p_{\text{data}}$ , corruption  $\tilde{X} \sim c(\cdot | X)$ 。目标为

$$\min_r \mathbb{E} \left\| X - r(\tilde{X}) \right\|^2.$$

对每个  $\tilde{x}$  条件化并配平方, Bayes-optimal reconstruction 为

$$r^*(\tilde{x}) = \mathbb{E}[X | \tilde{X} = \tilde{x}].$$

(c) Bottleneck 限制通过 latent 的 information/capacity, 迫使压缩, 但过窄会丢失 task-relevant information, 且 nonlinear network 仍可 memorize finite data。Corruption 要求从邻域恢复 clean signal, 抑制逐点 identity, 但 corruption distribution 选错可能删除语义或导致学到只针对噪声模型的 features。

**Scoring Guide.** identity/lookup degeneracy 3 分; denoising objective 1 分、conditional mean 推导 1 分; 两种 remedy 及各自 limitation 2 分。

### 3. [8 pts.] Chain rule 给出

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\tau} [I - \alpha \nabla^2 L_{\tau}^{\text{sup}}(\theta)]^{\top} \nabla L_{\tau}^{\text{qry}}(\theta'_{\tau}).$$

First-order MAML 丢弃 inner-update Jacobian 的 Hessian 部分，使用

$$\nabla_{\theta} J \approx \mathbb{E}_{\tau} \nabla L_{\tau}^{\text{qry}}(\theta'_{\tau}).$$

构造一维例子

$$L^{\text{sup}}(\theta) = \frac{1}{2}(\theta - 1)^2, \quad L^{\text{qry}}(\theta) = \frac{1}{2}(\theta + 1)^2.$$

从  $\theta = 0$  取  $\alpha = 1$ ，support step 给  $\theta' = 1$ ；query loss 从  $L^{\text{qry}}(0) = 1/2$  增至  $L^{\text{qry}}(1) = 2$ 。这里 support optimum 与 query optimum 方向相反，违反同一 task 的 support/query distributions 共享 underlying objective、且 inner adaptation 对 query 有正 transfer 的建模假设。MAML 本身不保证任意 task split 上每一步 query loss 都下降。

**Scoring Guide.** inner Jacobian/Hessian 3 分；exact meta-gradient 2 分；first-order approximation 1 分；有效 quadratic counterexample 与假设 2 分。

### 4. [10 pts.]

(a) 对 action-value function,

$$\begin{aligned} (T^{\pi}Q)(s, a) &= r(s, a) + \gamma \sum_{s'} P(s' | s, a) \sum_{a'} \pi(a' | s') Q(s', a'), \\ (T^{*}Q)(s, a) &= r(s, a) + \gamma \sum_{s'} P(s' | s, a) \max_{a'} Q(s', a'). \end{aligned}$$

Expectation 是 sup-norm nonexpansive，且  $|\max_a u_a - \max_a v_a| \leq \max_a |u_a - v_a|$ ，故两者都满足

$$\|TQ - TQ'\|_{\infty} \leq \gamma \|Q - Q'\|_{\infty}.$$

(b)  $T^{\pi}$  的唯一 fixed point 是  $Q^{\pi}$ ； $T^{*}$  的唯一 fixed point 是  $Q^{*}$ 。反例：单一 state 有 actions  $a_0, a_1$ ，self-transition，rewards 0 和 1，policy 总选  $a_0$ 。Policy evaluation 的 next-action term 应为  $Q(s, a_0)$ ；改成 max 会引入  $a_1$  并计算 optimal-control value，而非该 policy 的 value ( $V^{\pi} = 0$ ，optimal value 为  $1/(1 - \gamma)$ )。

(c) Exact policy iteration 先求  $V^{\pi_k}$ ，再取

$$\pi_{k+1}(s) \in \arg \max_a Q^{\pi_k}(s, a).$$

于是对每个  $s$ ，

$$(T^{\pi_{k+1}}V^{\pi_k})(s) = \max_a Q^{\pi_k}(s, a) \geq Q^{\pi_k}(s, \pi_k(s)) = V^{\pi_k}(s).$$

$T^{\pi_{k+1}}$  单调，反复作用得递增序列，其极限为 fixed point  $V^{\pi_{k+1}}$ ，故  $V^{\pi_{k+1}} \geq V^{\pi_k}$ 。若只出现 ties，第一步可等号，value 不降低；在 finite MDP 中可用固定 tie rule 避免无意义 cycling。

**Scoring Guide.** 两个 operators 2 分、contraction 1 分；两个 fixed points 与反例 3 分；policy-improvement inequality 2 分、单调极限及 tie 2 分。

### C. Optimization Methods in Artificial Intelligence

#### 1. [9 pts.]

- (a) True。凸可微函数满足  $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$ 。若  $\nabla f(x) = 0$ ，则  $f(y) \geq f(x)$  对所有  $y$ ，所以  $x$  为 global minimizer；不要求 strict convexity 或 uniqueness。
- (b) False。取  $f(x) = -x^2/2$ 。其 gradient  $-x$  是 1-Lipschitz，但  $(\nabla f(x) - \nabla f(y))(x - y) = -(x - y)^2 < 0$ 。Gradient monotonicity 等价于 differentiable function 的 convexity，而 smoothness alone 不含 convexity。
- (c) True。令  $p = \text{prox}_g(x)$ 、 $q = \text{prox}_g(y)$ 。最优性给出  $x - p \in \partial g(p)$ 、 $y - q \in \partial g(q)$ 。Subdifferential monotonicity 得

$$\langle (x - p) - (y - q), p - q \rangle \geq 0,$$

整理即

$$\|p - q\|^2 \leq \langle p - q, x - y \rangle,$$

这正是 firm nonexpansiveness，也蕴含 nonexpansiveness。

**Scoring Guide.** 每项判断 0.5 分、完整 proof/counterexample 2.5 分。

#### 2. [8 pts.] 当 $x_t \neq 0$ 时， $g_t = x_t$ 且

$$\frac{m_t}{\sqrt{v_t}} = \frac{x_t}{|x_t|} = \text{sign}(x_t).$$

因此  $x_0 = \alpha/2$  给出

$$x_1 = \alpha/2 - \alpha = -\alpha/2, \quad x_2 = -\alpha/2 + \alpha = \alpha/2.$$

归纳得

$$x_{2k} = \alpha/2, \quad x_{2k+1} = -\alpha/2,$$

故既不收敛到 minimizer 0，也不收敛到任何点。缺少的是 diminishing effective step size 或可保证 descent 的 step-size control；固定归一化步长在 gradient 变小时仍移动  $\alpha$ 。

若  $\epsilon > 0$ ，update 为

$$x_{t+1} = x_t - \alpha \frac{x_t}{|x_t| + \epsilon}.$$

靠近 0 时近似  $x_{t+1} \approx (1 - \alpha/\epsilon)x_t$ ，所以 normalization 不再把微小 gradient 放大成 unit sign；局部稳定还要求例如  $0 < \alpha < 2\epsilon$ 。 $\epsilon$  主要防除零和控制近零 effective gain，并非无条件 convergence proof。

**Scoring Guide.** 化为 sign update 2 分；完整 two-cycle 3 分；缺失 safeguard 1 分； $\epsilon$  的局部作用与条件 2 分。

#### 3. [8 pts.] 令 $x^* = Q^{-1}b$ 、 $e^k = x^k - x^*$ ，则

$$e^{k+1} = (I - \gamma PQ)e^k.$$

取  $z^k = P^{-1/2}e^k$ ，得到对称 iteration

$$z^{k+1} = (I - \gamma H)z^k, \quad H = P^{1/2}QP^{1/2} \succ 0.$$

若  $H$  的 eigenvalues 落在  $[\lambda_{\min}, \lambda_{\max}]$ ，收敛当且仅当

$$\max_i |1 - \gamma \lambda_i| < 1 \iff 0 < \gamma < 2/\lambda_{\max}.$$

最小化两个端点的最大 modulus，令其等大反号，得到

$$\gamma^* = \frac{2}{\lambda_{\min} + \lambda_{\max}}, \quad \rho^* = \frac{\kappa_H - 1}{\kappa_H + 1}, \quad \kappa_H = \lambda_{\max}/\lambda_{\min}.$$

因此 preconditioner 的作用是令  $H$  的 spectrum 聚集、减小 condition number；若  $P \approx Q^{-1}$ ， $H \approx I$ 。任意 SPD  $P$  并不自动改善 rate，选得不好会增大  $\kappa_H$ 。

**Scoring Guide.** error recursion 1 分；symmetric transform 2 分；exact step condition 2 分；optimal step/factor 2 分；conditioning 解释 1 分。

**4. [8 pts.]** 记  $G_{t,i} = \sqrt{\sum_{s=1}^t g_{s,i}^2}$ 。Weighted projection 的 optimality 和 convexity 给出标准 one-step inequality

$$f_t(x_t) - f_t(x^*) \leq \langle g_t, x_t - x^* \rangle \leq \frac{\|x_t - x^*\|_{H_t}^2 - \|x_{t+1} - x^*\|_{H_t}^2}{2\eta} + \frac{\eta}{2} \|g_t\|_{H_t^{-1}}^2.$$

求和时  $H_t$  逐坐标增加，且  $|x_{t,i} - x_i^*| \leq D_\infty$ ，故 potential 部分至多

$$\frac{D_\infty^2}{2\eta} \sum_i (\epsilon + G_{T,i}).$$

另一方面使用标量不等式  $\sum_t a_t^2 / \sqrt{\sum_{s \leq t} a_s^2} \leq 2\sqrt{\sum_t a_t^2}$ ，得

$$\sum_t \|g_t\|_{H_t^{-1}}^2 \leq 2 \sum_i G_{T,i}.$$

因此

$$R_T \leq \frac{dD_\infty^2\epsilon}{2\eta} + \left( \frac{D_\infty^2}{2\eta} + \eta \right) \sum_{i=1}^d G_{T,i}.$$

忽略小  $\epsilon$  并取  $\eta = D_\infty/\sqrt{2}$ ，主项为  $\sqrt{2}D_\infty \sum_i G_{T,i}$ 。若 gradients 只出现在  $s$  个 coordinates，Cauchy-Schwarz 给  $\sum_i G_{T,i} \leq \sqrt{s} G\sqrt{T}$ 。相对 Euclidean  $D_2 G\sqrt{T}$ ，当  $D_\infty\sqrt{s} < D_2$  时有改善；若 gradients dense 或 coordinate scale 不合适，diagonal bound 不一定更好。

**Scoring Guide.** one-step weighted inequality 2 分；changing-metric telescope 2 分；adaptive scalar sum 2 分；最终 bound、step 和 sparse comparison 2 分。

## D. Natural Language Processing

**1. [9 pts.]** 单样本 NLL 为

$$\ell(\theta) = -\theta^\top F(x, y) + \log Z_\theta(x).$$

对 log-partition 微分得到

$$\nabla \ell(\theta) = \mathbb{E}_{Y \sim p_\theta(\cdot|x)}[F(x, Y)] - F(x, y).$$

再次微分，

$$\nabla^2 \ell(\theta) = \text{Cov}_{p_\theta(\cdot|x)}[F(x, Y)] \succeq 0.$$

所以 NLL convex。Strict convexity 失败当存在非零 direction  $a$  使  $a^\top F(x, Y)$  在 model support 上为常数，此时  $a^\top \nabla^2 \ell a = \text{Var}(a^\top F) = 0$ ；冗余 features、gauge shifts 和未出现 transitions 都可造成这种情形。对 dataset，Hessians 求和，严格性要求没有共同 null direction（或加 positive-definite regularizer）。First-order chain 的  $Z$  和 node/edge feature marginals 由 forward-backward dynamic programming 在  $O(TK^2)$  时间计算，梯度用这些 expected counts 减 observed counts。

**Scoring Guide.** NLL 1 分； gradient 2 分； Hessian covariance 2 分； convexity/strictness 2 分； forward-backward 与复杂度 2 分。

2. [8 pts.] 令  $P$  为 permutation matrix,  $X' = PX$ 。记  $S = XW_QW_K^\top X^\top / \sqrt{d_k}$ , 则  $S' = PSP^\top$ 。Row-wise softmax 对同时的 row/column permutation 满足

$$\text{softmax}_{\text{row}}(PSP^\top) = P \text{softmax}_{\text{row}}(S)P^\top.$$

因此

$$A(PX) = P \text{softmax}(S)P^\top PXW_V = \boxed{PA(X)}.$$

长度二的 causal additive mask 为

$$M = \begin{bmatrix} 0 & -\infty \\ 0 & 0 \end{bmatrix}.$$

交换 permutation  $P = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$  满足  $PMP^\top = \begin{bmatrix} 0 & 0 \\ -\infty & 0 \end{bmatrix} \neq M$ 。对原序列, 第一个 output 只能看 token 1; 交换 tokens 但仍使用 fixed  $M$  后, 第一个 output 只能看原 token 2, 而  $PA(X)$  的相应 output 一般已混合两个 tokens, 所以 equivariance 失败。对具有严格 total causal order 的 positions, 保持  $i \leq j$  的 bijection 只能是 identity; 若有同一时间层的 block-partial order, 层内 permutations 才可能兼容。

**Scoring Guide.** logit conjugation 2 分； softmax transformation 2 分； output equivariance 1 分； length-two mask counterexample 2 分； compatible permutations 1 分。

3. [7 pts.] 因  $d[-\log \sigma(z)]/dz = \sigma(z) - 1$ ,

$$\boxed{\nabla_\theta \ell = \beta[\sigma(z_\theta) - 1] [\nabla_\theta \log \pi_\theta(y^+ | x) - \nabla_\theta \log \pi_\theta(y^- | x)]}.$$

Reference policy 不依赖  $\theta$ , 故没有其 gradient。若本 pair 的两个 reference probabilities 同乘  $c > 0$ , 则两个 log-ratios 都减  $\log c$ , 在差中抵消,  $z_\theta$  与 loss 不变。

这只是 pairwise common-scale invariance。Reference 的相对 log odds  $\log \pi_{\text{ref}}(y^+ | x) - \log \pi_{\text{ref}}(y^- | x)$  仍直接进入  $z_\theta$ , 决定相对 baseline 与 implicit regularization; 对完整 normalized distribution 也不能任意只缩放两个 probabilities 而不调整其余 outputs。因此 reference policy 并非无关。

**Scoring Guide.** scalar derivative 1 分；完整 policy gradient 3 分； common-scale cancellation 1 分； relative-odds/reference 解释 2 分。

4. [9 pts.] 取 pairwise weight  $\lambda$ , 定义

$$p(e_1, e_2 | m_1, m_2) = \frac{1}{Z} \exp\{u_1(e_1) + u_2(e_2) + \lambda r(e_1, e_2)\},$$

其中

$$Z = \sum_{a \in \mathcal{C}_1} \sum_{b \in \mathcal{C}_2} \exp\{u_1(a) + u_2(b) + \lambda r(a, b)\}.$$

边缘概率为

$$p(E_1 = a) = \frac{1}{Z} \sum_b e^{u_1(a) + u_2(b) + \lambda r(a, b)},$$

$E_2$  同理；MAP 为最大化同一未归一化 score 的 pair。若 candidate sizes 为  $n_1, n_2$ , dense exact  $Z$ 、marginals 与 MAP 都需  $O(n_1 n_2)$  time; 存下所有 pair scores 需  $O(n_1 n_2)$  memory, streaming 求  $Z$ /MAP 可降为  $O(n_1 + n_2)$  或常数额外 memory。

即使 unary scores 分别偏好两个语义不相容的 entities, 足够大的 relation compatibility 可使一个次优 unary candidate 组成全局更高分 pair。反之, 若 KG 缺失真实 edge 且把 “missing” 当作负 compatibility, 模型会错误惩罚正确 pair; 应把 unknown 与 observed negative 区分、学习 soft relation feature, 并允许 text evidence 主导或 abstain。

**Scoring Guide.** 模型与 score 2 分； partition function 2 分； marginals/MAP 2 分；复杂度 1 分； global correction 与 missing-edge failure 2 分。