

PhD Qualification Exam in Artificial Intelligence

Mock Examination No. 5– Standard Solutions

说明。本答案给出可核查的关键推导、必要假设和结论。等价方法若逻辑完整、符号一致，可按评分细则给分。四个方向均给出答案，实际考试仍按三选一规则中的三个方向计分。

A. Machine Learning Theory

1. [8 pts.] 对固定 j, h , Hoeffding inequality 给出

$$\mathbb{P}(|\hat{L}(h) - L(h)| > a) \leq 2e^{-2ma^2}.$$

把 failure budget $\delta\pi_j/M_j$ 分给 $\mathcal{H}_j$ 中每个 hypothesis, 令

$$\epsilon_j = \sqrt{\frac{\log(2M_j/(\delta\pi_j))}{2m}}.$$

对所有 j, h 作 union bound; 总 failure probability 至多 $\sum_j M_j(\delta\pi_j/M_j) \leq \delta$. 故同时有

$$|\hat{L}(h) - L(h)| \leq \epsilon_j \quad \forall j, h \in \mathcal{H}_j.$$

定义 SRM rule

$$(\hat{j}, \hat{h}) \in \arg \min_{j, h \in \mathcal{H}_j} \{\hat{L}(h) + \epsilon_j\}.$$

在 simultaneous event 上, 对任意 j 和 $h \in \mathcal{H}_j$,

$$L(\hat{h}) \leq \hat{L}(\hat{h}) + \epsilon_{\hat{j}} \leq \hat{L}(h) + \epsilon_j \leq L(h) + 2\epsilon_j.$$

因此

$$L(\hat{h}) \leq \inf_j \{ \inf_{h \in \mathcal{H}_j} L(h) + 2\epsilon_j \}.$$

Summable π_j 使 countably many classes 的 failure budgets 总和有限; 对每类使用相同非衰减 budget 会使 infinite union bound 发散。

Scoring Guide. failure-budget allocation 2 分; simultaneous bound 2 分; SRM rule 1 分; oracle 三步比较 2 分; summability 1 分。

2. [8 pts.] 记 $e_y \in \mathbb{R}^K$ 为 one-hot vector。对 logits,

$$\nabla_z \ell = p - e_y, \quad \nabla_z^2 \ell = S_p := \text{diag}(p) - pp^\top.$$

链式法则给出

$$\nabla_W \ell = (p - e_y)x^\top \in \mathbb{R}^{K \times d}.$$

对任意 perturbation ΔW , 二阶 variation 为

$$d^2 \ell[\Delta W, \Delta W] = (\Delta W x)^\top S_p (\Delta W x) \geq 0,$$

因为 $v^\top S_p v = \sum_k p_k v_k^2 - (\sum_k p_k v_k)^2 = \text{Var}_{k \sim p}(v_k) \geq 0$ 。因此 Hessian PSD；在 column-wise vectorization 下可写为

$$\nabla_{\text{vec}(W)}^2 \ell = (xx^\top) \otimes S_p$$

(换一种 vec convention 时 Kronecker factors 交换)，从而 softmax NLL convex。

对任意 $a \in \mathbb{R}^d$ ，令 $W' = W + \mathbf{1}_K a^\top$ ，则 logits 全部加同一 scalar $a^\top x$ ，softmax 不变。这给出至少 d 维 gauge invariance，故 loss 不可能在完整参数空间 strict convex。可固定一类的 weight row 为零，或施加 $\sum_k W_{k,:} = 0$ 的 gauge constraint；也可加入 $\lambda \|W\|_F^2/2$ ， $\lambda > 0$ ，使 objective strongly convex 并有唯一参数 minimizer。

Scoring Guide. logit derivative 1 分；matrix gradient/dimensions 2 分；Hessian variation/Kronecker 2 分；PSD/convexity 1 分；invariance 与两种修复 2 分。

3. [8 pts.] 对 signed margin $u = yw^\top x$ 定义

$$\phi_\gamma(u) = \begin{cases} 1, & u \leq 0, \\ 1 - u/\gamma, & 0 < u < \gamma, \\ 0, & u \geq \gamma. \end{cases}$$

它取值于 $[0, 1]$ ，是 $1/\gamma$ -Lipschitz，且 $\mathbf{1}\{u \leq 0\} \leq \phi_\gamma(u)$ 。线性预测类的 empirical Rademacher complexity 满足 $\hat{\mathfrak{R}}_S(\mathcal{F}) \leq BR/\sqrt{m}$ 。Contraction lemma 因而给 margin-loss class 至多 $BR/(\gamma\sqrt{m})$ 。

标准 bounded-loss Rademacher generalization theorem 给出：以至少 $1 - \delta$ 的概率，对所有 $\|w\| \leq B$ ，

$$L_{01}(w) \leq \frac{1}{m} \sum_{i=1}^m \phi_\gamma(y_i w^\top x_i) + \frac{2BR}{\gamma\sqrt{m}} + 3\sqrt{\frac{\log(2/\delta)}{2m}}.$$

不同常数版本的 concentration term 等价。增大 γ 会减小 complexity penalty，但会把更多小正 margins 计入 empirical loss；减小 γ 可降低 empirical margin loss，却放大 $1/\gamma$ 项。选 γ 时若使用同一数据搜索，还应对候选集合或搜索复杂度作校正。

Scoring Guide. 合法 ramp loss 2 分；linear complexity 1 分；contraction 2 分；完整 high-probability bound 2 分；margin tradeoff 1 分。

4. [9 pts.] 令 $h = \hat{x} - x$ 。两个 vectors 都至多 s -sparse，所以 h 至多 $2s$ -sparse。由 feasibility 和 measurement model，

$$\|Ah\|_2 \leq \|A\hat{x} - y\|_2 + \|y - Ax\|_2 \leq 2\eta.$$

RIP lower inequality 对 $2s$ -sparse h 给出

$$\sqrt{1 - \delta_{2s}} \|h\|_2 \leq \|Ah\|_2.$$

合并得

$$\|\hat{x} - x\|_2 \leq \frac{2\eta}{\sqrt{1 - \delta_{2s}}}.$$

当 $\eta = 0$ 时 $Ah = 0$ ，RIP lower bound 强迫 $h = 0$ ，所以在 s -sparse feasible vectors 中 exact uniqueness 成立。此证明的关键是 $\hat{x} - x$ 为 $2s$ -sparse。Basis-pursuit denoising 的 optimizer 通常不是 exactly s -sparse，不能直接对整个 error vector 使用 order- $2s$ RIP。其 stability proof 还需由 ℓ_1 optimality 建立 cone constraint，把 error 分块，并使用更强的 RIP/robust null-space arguments；本题结论不能机械套用。

Scoring Guide. error sparsity 2 分; feasibility triangle bound 2 分; RIP 合并与显式常数 2 分; noiseless case 1 分; BPDN limitation 2 分。

B. Deep Learning and Reinforcement Learning

1. [8 pts.] 卷积输出仍为 $H \times W \times C'$, 其 kernel parameters 为 $9CC'$ 。Flatten 后为 $X_f \in \mathbb{R}^{L \times C'}$, embedding projection $X_f W_E$ 为 $L \times d$, $W_E \in \mathbb{R}^{C' \times d}$, 参数 $C'd$ 。每个 head 的

$$Q_a, K_a, V_a \in \mathbb{R}^{L \times d_h}, \quad Q_a K_a^\top \in \mathbb{R}^{L \times L},$$

head output 为 $L \times d_h$; concatenation 与 output 均为 $L \times d$ 。标准 combined $W_Q, W_K, W_V, W_O \in \mathbb{R}^{d \times d}$, 共 $4d^2$ 参数。因此总数 (不含 biases) 为

$$9CC' + C'd + 4d^2.$$

Leading time 为

$$O(9HWCC') + O(L(C'd + d^2)) + O(L^2d),$$

activation memory 的 attention-score 主项为 $O(hL^2)$, 另有 $O(Ld + HWC')$ 。共享卷积在 stride 1、相容边界下对 grid translations equivariant。无 positional encoding 的 self-attention 对 token permutations equivariant, 所以 grid translation 对应的 permutation 仍保持 equivariance; flatten 本身只重编号。加入 absolute positional embeddings 后, 内容平移但 position vectors 不随之平移, 严格 translation equivariance 一般被破坏。

Scoring Guide. 所有 principal shapes 2 分; 三部分参数量 2 分; 时间 2 分; memory 1 分; equivariance/position 1 分。

2. [9 pts.] SDE 的 density 满足 Fokker–Planck equation

$$\partial_t p_t(x) = -\nabla \cdot (f(x, t)p_t(x)) + \frac{g(t)^2}{2} \Delta p_t(x).$$

利用 $\nabla p_t = p_t \nabla \log p_t$, 扩散项可写为 divergence:

$$\frac{g^2}{2} \Delta p_t = \frac{g^2}{2} \nabla \cdot (p_t \nabla \log p_t).$$

因此

$$\partial_t p_t = -\nabla \cdot \left[\left(f - \frac{g^2}{2} \nabla \log p_t \right) p_t \right]. \quad (1)$$

确定性 ODE

$$\frac{dX_t}{dt} = f(X_t, t) - \frac{g(t)^2}{2} \nabla_x \log p_t(X_t)$$

的 density continuity equation 正是 (1)。若初始 density 相同且相应 PDE 解唯一, 则两者在每个 t 的 marginal density 相同; 这不表示 sample paths 或 transition laws 相同。

所需 assumptions 包括 $p_t > 0$ 且足够光滑、 f 和 score drift 保证 ODE/SDE well posed、边界衰减或 flux 条件允许上述微分与唯一性。若用 $s_\theta \neq \nabla \log p_t$, continuity equation 的 velocity field 改变, 所得 marginals 一般偏离 p_t ; 误差还可能沿数值积分累积, 低密度区的 score error 尤其不稳定。

Scoring Guide. Fokker–Planck 3 分; score 重写 2 分; probability-flow ODE 2 分; same-marginal proof/区别 1 分; assumptions 与 inaccurate score 1 分。

3. [8 pts.] 令

$$\rho_t = \frac{\pi_\theta(A_t | S_t)}{\mu(A_t | S_t)}, \quad \rho_{0:t} = \prod_{k=0}^t \rho_k.$$

初始分布和 environment transitions 在 target/behavior trajectory densities 中相消。Policy-gradient theorem 的 trajectory form 经 change of measure 给出

$$\nabla J(\theta) = \mathbb{E}_{\tau \sim \mu} \left[\sum_{t \geq 0} \gamma^t \rho_{0:t} \nabla_\theta \log \pi_\theta(A_t | S_t) Q^\pi(S_t, A_t) \right].$$

用 return 或 critic $\hat{Q}_t$ 替代 Q^π 时, 若其条件期望等于 Q^π , 仍 unbiased; state baseline 可减 variance 而不改期望。

需要 coverage/support: $\mu(a | s) > 0$ whenever target occupancy gives positive probability to (s, a) , 且 ratios、returns 可积。还假设 environment/initial distribution 相同, 并对 actor 使用正确 target-policy critic。Clipping ρ 限制 rare trajectories 的巨大 variance, 却把 change-of-measure weights 系统性改变, 通常引入 bias; self-normalization 同样有 finite-sample bias。Nonlinear off-policy actor-critic 同时含 function approximation、bootstrapping 和 changing off-policy distribution, Bellman projection 不必 contraction, critic error 又反馈到 actor, 故即使 ratios 合法也可能不稳定。

Scoring Guide. ratios/prefix product 2 分; off-policy gradient 3 分; support 与 critic assumptions 1 分; clipping tradeoff 1 分; nonlinear instability 1 分。

4. [8 pts.] 令 residual $r_x(u) = I_1(x) - I_2(x + u(x))$, 取 differentiable robust penalty ρ 及 spatial regularizer, 例如

$$\mathcal{L}(u) = \sum_{x \in \Omega} \rho(r_x(u)) + \lambda \sum_x \left(\|\nabla u_1(x)\|^2 + \|\nabla u_2(x)\|^2 \right).$$

双线性 sampling 使 warp 几乎处处可微, data-term gradient 为

$$\nabla_{u(x)} \rho(r_x) = -\rho'(r_x) \nabla I_2(x + u(x)) \in \mathbb{R}^2.$$

对小 displacement 在 $u = 0$ 线性化 $I_2(x + u) \approx I_2(x) + \nabla I_2(x)^\top u$, brightness constancy $I_1 = I_2(x + u)$ 给出

$$\nabla I_2(x)^\top u(x) = I_1(x) - I_2(x).$$

每点只有一个 scalar equation 约束二维 flow, 且沿 isophote tangent 的分量不可辨识, 这就是 aperture problem; spatial/context regularity 提供额外信息。

可引入 visibility $v(x) \in [0, 1]$:

$$\sum_x v(x) \rho(r_x) + \lambda R(u) + \alpha R_v(v) + \kappa \sum_x (1 - v(x)).$$

最后一项或规定的 occlusion prior 惩罚把所有 v 设为 0, R_v 保持 mask spatial coherence; 也可用 forward-backward flow consistency 构造 nonlearned mask。Occluded pixels 不应强制 photometric match。

Scoring Guide. objective 2 分; warp gradient 2 分; linearization 1 分; aperture problem 1 分; occlusion mask 与 anti-trivial regularization 2 分。

C. Optimization Methods in Artificial Intelligence

1. [11 pts.] 记 $a_i = \nabla f_i(x)$ 、 $\bar{a} = n^{-1} \sum_i a_i$ 。

(a)

$$\mathbb{E}[g \mid x] = \sum_i p_i \frac{a_i}{np_i} = \bar{a} = \nabla f(x).$$

而

$$\mathbb{E} \|g - \bar{a}\|^2 = \frac{1}{n^2} \sum_i \frac{\|a_i\|^2}{p_i} - \|\bar{a}\|^2.$$

(b) 只需最小化 $\sum_i \|a_i\|^2 / p_i$ subject to $\sum_i p_i = 1$ 。Lagrange stationarity 或 Cauchy-Schwarz 给出

$$p_i^* = \frac{\|a_i\|}{\sum_j \|a_j\|}$$

对 nonzero components。若 $a_i = 0$ ，允许 $p_i = 0$ 不影响 estimator；若强制 $p_i > 0$ ，optimum 作为给 zero components 的质量趋于 0 的 infimum。若所有 $a_i = 0$ ，任意 distribution 都产生 zero estimator。

(c) 对 B 个 conditionally independent copies, $\bar{g}_B = B^{-1} \sum_{b=1}^B g_b$ ，交叉 covariance 消失，故

$$\mathbb{E} \|\bar{g}_B - \nabla f\|^2 = \frac{1}{B} \mathbb{E} \|g - \nabla f\|^2.$$

(d) 若在所考虑区域有 $\|\nabla f_i(x)\| \leq G_i$ ，可预先取 $p_i \propto G_i$ ，得到可实现的 worst-case second-moment control。精确 adaptive p_i^* 需要知道所有 n 个 current gradients，通常与 full gradient 同阶；stale estimates、loss proxies 或 periodic refresh 降低成本但改变 variance guarantee，并需保证 nonzero sampling support。

Scoring Guide. unbiasedness 1 分、exact variance 2 分；优化与 distribution 3 分、zero cases 1 分；minibatch variance 2 分；fixed bounds/cost 2 分。

2. [10 pts.]

(a) 在 eigenvalue λ 方向，GD error 乘 $1 - \gamma\lambda$ 。最小化 $\max_{\lambda \in [\mu, L]} |1 - \gamma\lambda|$ ，使两个端点等大反号，得

$$\gamma_{\text{GD}}^* = \frac{2}{L + \mu}, \quad \rho_{\text{GD}} = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}.$$

(b) 令 $q = \mu/L$ 、 $\rho = 1 - \sqrt{q}$ 。在 eigenvalue λ 方向，记 $a = 1 - \lambda/L$ ，递推为

$$z_{k+1} = a[(1 + \beta)z_k - \beta z_{k-1}],$$

characteristic polynomial

$$r^2 - a(1 + \beta)r + a\beta = 0, \quad \beta = \frac{1 - \sqrt{q}}{1 + \sqrt{q}}.$$

在最慢方向 $\lambda = \mu$ ， $a = 1 - q$ ，多项式恰为

$$(r - \rho)^2,$$

所以 solution 可含 $(c_1 + c_2 k)\rho^k$ 。对 $\lambda \in [\mu, L]$ ，直接检查 roots (complex roots 时 modulus $\sqrt{a\beta}$, real roots 时检查端点) 给出 spectral radius 不超过 ρ 。故 worst-case asymptotic factor 为

$$\rho_{\text{NAG}} = 1 - 1/\sqrt{\kappa},$$

但 repeated root 解释了 polynomial transient, 不能无条件写成同一常数乘纯 ρ^k 对所有 k 。

- (c) 当 κ 大, GD contraction 为 $1 - O(1/\kappa)$, 达到固定 accuracy 需 $O(\kappa \log(1/\varepsilon))$ iterations; Nesterov 为 $1 - O(1/\sqrt{\kappa})$, 需 $O(\sqrt{\kappa} \log(1/\varepsilon))$ (适当 energy/function bound)。该 diagonal spectral proof 利用 fixed SPD quadratic; nonconvex Hessian 可变且可有负 curvature, 不能据此推出相同 global rate。

Scoring Guide. GD eigenanalysis/optimal step/factor 4 分; NAG recurrence 2 分、roots/factor/transient 2 分; complexities 与 nonconvex caveat 2 分。

3. [6 pts.] Coupled regularization 的 decay component 是 $-\alpha_t \lambda D_t w_t$, 第 i 坐标 decay rate 为 $\alpha_t \lambda D_{t,ii}$; AdamW 的 decay component 为 $-\alpha_t \lambda w_t$, 所有坐标使用同一 scalar rate, 与 normalization 无关。

在某一步, 对所有可能 w_t 通过 scalar $\lambda_c \mapsto \lambda_w$ 等价, 当且仅当

$$\lambda_c D_t = \lambda_w I,$$

即 $D_t = c_t I$, 此时取 $\lambda_w = c_t \lambda_c$ 。若要求用一个固定 scalar reparameterization 在所有 t 等价, 还需 c_t 不随 t 变化 (退化地, 也可只要求当前 w_t 落在 D_t 的单一 eigenspace)。一般 diagonal entries 不同且随历史变化, coupled L_2 对梯度小、normalization 大的坐标施加更强 effective shrinkage; AdamW 则实施明确的 isotropic multiplicative decay。因此在 adaptive methods 中 “ L_2 penalty” 与 “weight decay” 一般不等价。

Scoring Guide. 写出两个 decay components 2 分; exact scalar equivalence 条件 2 分; coordinate/time difference 2 分。

4. [6 pts.] 令 $s \in \partial \|w\|_1$, 完整 coordinate rule 为

$$s_i = \begin{cases} \text{sign}(w_i), & w_i \neq 0, \\ [-1, 1], & w_i = 0. \end{cases}$$

KKT conditions 为存在 multiplier ν 使

$$0 = A^\top (Aw - b) + \lambda s + C^\top \nu, \quad Cw = d, \quad s \in \partial \|w\|_1.$$

Equality constraint 无 multiplier sign restriction; 在 convex problem 中, feasibility 下这些条件充分, 适当 constraint qualification 下必要。

一种 primal-dual proximal iteration 是

$$\begin{aligned} w^{k+1} &= \text{soft}_{\gamma\lambda} \left(w^k - \gamma [A^\top (Aw^k - b) + C^\top \nu^k] \right), \\ \nu^{k+1} &= \nu^k + \tau (Cw^{k+1} - d), \end{aligned}$$

其中 steps 需满足相应 primal-dual convergence conditions。一般 $\text{prox}_{\lambda\|\cdot\|_1 + \iota_{\{Cw=d\}}}$ 不是 $\Pi_{\{Cw=d\}} \circ \text{soft}$, 也不是反向 composition: 两个 operators 通常不 commute, 单独 optimality conditions 含不同 normal cones/subgradients。只有特殊可分离几何下才相等。

Scoring Guide. 完整 ℓ_1 subgradient 1 分; stationarity/feasibility/multiplier 2 分; 明确 update 2 分; prox 不可分解解释 1 分。

D. Natural Language Processing

1. [7 pts.] 记 $d_{hrt} = e_h + e_r - e_t$, $s_{hrt} = -\|d_{hrt}\|^2$ 。对 corrupt triples $\tilde{t}_j$ 和 negative words $\tilde{w}_j$, 可取 joint loss

$$\begin{aligned} \mathcal{L} = & -\log \sigma(s_{hrt}) - \sum_j \log \sigma(-s_{hrt\tilde{t}_j}) \\ & -\log \sigma(u_w^\top e_h) - \sum_j \log \sigma(-u_{\tilde{w}_j}^\top e_h). \end{aligned}$$

对 positive triple term $\ell_+ = -\log \sigma(s_{hrt})$, $d\ell_+/ds = \sigma(s) - 1$, 所以

$$\nabla_{e_h} \ell_+ = \nabla_{e_r} \ell_+ = 2[1 - \sigma(s_{hrt})]d_{hrt}, \quad \nabla_{e_t} \ell_+ = -2[1 - \sigma(s_{hrt})]d_{hrt}.$$

Negative triple 的同类公式使用 $-\log \sigma(-s)$, 其 $d\ell/ds = \sigma(s)$ 。Type-aware sampling 只用 relation range/domain 合法但错误的 entities 作 corruptions, 产生更难且语义有效的 negatives; 同时要避免把 KG 中未记录的 true triple 全当负例。Graph objective 可能要求两个 entities 因结构接近, 而 text contexts 因 polysemy/domain usage 将它们分开, 造成 gradient conflict; 可用 separate projections、loss weighting 或 multi-view regularization。

Scoring Guide. 完整 joint objective 2 分; positive triple 三个 gradients 3 分; negative derivative/type sampling 1 分; objective conflict 1 分。

2. [8 pts.] 每个 ordinary token 关注 $O(w+g)$ positions, 产生 $O(L(w+g))$ scores; g global tokens 各关注 $L+g$ positions, 产生 $O(g(L+g))$ 。合并并避免只影响常数的重复计数,

$$N_{\text{score}} = O(Lw + Lg + g^2),$$

所以 attention time 为 $O((Lw + Lg + g^2)d)$, score memory 为 $O(Lw + Lg + g^2)$, Q/K/V activations 另需 $O((L+g)d)$ 。设 local window 的单侧 radius 为 $r = \lfloor (w-1)/2 \rfloor \geq 1$ 。没有 globals 时, 一层最多沿序列传播 r positions, 端点间最多需

$$\left\lceil \frac{L-1}{r} \right\rceil$$

层。有至少一个 bidirectional global token 时, 第 1 层 global representation 可吸收任意 ordinary token, 第 2 层任意 ordinary token 可读取该 updated global representation, 所以最多 2 层完成任意 pair 的 influence (同层 attention 不可先写后读)。

Causal masking 下 future token 不能影响 past output, 不存在 arbitrary bidirectional reachability。Earlier-to-later 的传播层数取决于 global token 的位置和 mask: 位于序列开头的 causal global token 不能读取未来; 可使用随时间更新且只汇总 prefix 的 memory/global state, 但仍必须保持 directionality, 不能用全局边泄露 future information。

Scoring Guide. score count 2 分; time/memory 2 分; local graph distance 2 分; global two-layer path 1 分; causal qualification 1 分。

3. [6 pts.] 令 demonstration design matrix $X \in \mathbb{R}^{n \times d}$, $y \in \mathbb{R}^n$ 。Gaussian conjugacy 给出

$$\Sigma_n = (\tau^{-2}I + \sigma^{-2}X^\top X)^{-1}, \quad m_n = \sigma^{-2}\Sigma_n X^\top y.$$

因此

$$\theta \mid X, y \sim \mathcal{N}(m_n, \Sigma_n),$$

且含 observation noise 的 posterior predictive 为

$$y_* \mid x_*, X, y \sim \mathcal{N}(x_*^\top m_n, \sigma^2 + x_*^\top \Sigma_n x_*).$$

任意 permutation matrix P 作用于 demonstrations 后, $(PX)^\top(PX) = X^\top X$ 且 $(PX)^\top Py = X^\top y$, 所以 posterior/predictive 不变。Transformer 带 positional embeddings、causal computation、有限 context 和 learned attention patterns, 并未被约束为对 demonstration blocks permutation invariant; ordering 可改变其 activations, 除非 architecture/training 特别学得该对称性。

Scoring Guide. posterior covariance 2 分; mean 1 分; predictive mean/variance 1 分; permutation proof 1 分; Transformer qualification 1 分。

4. [12 pts.] 一种完整方案如下。

Retrieval and generation. 文档切成带 immutable source ID、span offsets 和 timestamp 的 passages。Dual encoder 以

$$\mathcal{L}_{\text{ret}} = -\log \frac{e^{q^\top z^+/\tau}}{e^{q^\top z^+/\tau} + \sum_{z^-} e^{q^\top z^-/\tau}}$$

训练; negatives 包括同主题但不能支持答案的 hard passages、retriever top false positives, 并排除可能支持答案的 unlabeled positives。Online 先 ANN retrieve K 项, 再用 cross-encoder rerank。Evidence selection 在 context-token budget 下按 relevance、novelty、source reliability 和 token cost 做 knapsack/greedy selection, 并保留 citation metadata。

Generator 以 gold answer conditioned on gold/retrieved evidence 的 token NLL 训练, 并加入 citation-span alignment loss: 每个 factual claim 必须指向选中 passage 的可支持 span。可用 preference loss 奖励 entailed、完整 citations 并惩罚 unsupported claims。若最高 evidence support 或 calibrated answer confidence 低于阈值, 系统 abstains 或请求澄清; 不能让语言流畅度代替 evidence confidence。

Memory MDP. State s_t 包含 dialogue summary、当前 query、retrieved candidates、带 provenance 的 memory items、剩余 context/persistent budgets。Actions 包括 retrieve、keep、evict、compress、verify、answer/abstain。Transition 由新用户 turn、retrieval result 和 deterministic memory update 组成。Reward 可写为 answer correctness、citation entailment/coverage、calibration 的正项, 减 token、latency、unsupported-claim、privacy/staleness penalties。对 discount $\gamma < 1$,

$$Q^*(s, a) = \mathbb{E}[r(s, a, S') + \gamma \max_{a'} Q^*(S', a') \mid s, a].$$

Persistent memory 写入必须经过 provenance/consent policy, compression 后仍保留 source links, 且过期内容可撤销。

Complexity and evaluation. ANN retrieval 依 index 而定, 记为 $T_{\text{ANN}}(N, K)$; cross-encoder reranking 约 $O(KL_qL_p d)$ 或相应 Transformer cost; generator self-attention 对 selected context length B 为 $O(B^2 d)$ (若采用给定 sparse attention 则按其 pattern), memory selection 对 K candidates 的 greedy cost 通常 $O(K \log K)$ 。

在 time-split、document-deduplicated test set 上分别报告 retrieval Recall@ K /MRR, answer EM/F1 或 task score, claim-level citation precision/recall 与 entailment, selective risk/coverage 和 calibration error, p50/p95 latency 与 token cost。还需检查 answer/source temporal leakage、train-test near duplicates、citation pointing to unsupported text, 以及在 evidence missing、conflicting、stale 和 prompt-injected documents 下的 robustness。Ablations 分开评估 retriever、reranker、memory 和 generator, 避免用 end-to-end accuracy 掩盖 retrieval failure。

Scoring Guide. retriever/objective/hard negatives 2 分; budgeted evidence 与 generator/citation alignment 2 分; abstention 1 分; MDP 四要素 2 分; Bellman equation 1 分; complexity 1 分; 分解 evaluation 2 分; leakage/robustness 1 分。