

人工智能方向博士资格考试复习讲义

考纲—方向讲义—课程训练题—历年博资考真题

需要强调的是，这份复习讲义更多只是辅助你抓相应的学习或考试重点，或者来帮你查漏补缺的；**请不要过于依赖这份讲义来学习人工智能这门学科，相应的学习部分一定要看讲义看书!!!**



作者：藤藤蛇擅长找东西

使用说明、资料审计与考试总览

一、任务定位与资料边界

本讲义服务于人工智能方向博士资格考试，完整覆盖以下四个方向：

- A. 机器学习理论；
- B. 深度学习与强化学习；
- C. 人工智能中的优化方法；
- D. 自然语言处理。

易错点、反例与失败模式

本讲义严格区分两类题目：

- [25S]、[25F]、[26S] 是真正的人工智能博士资格考试卷；
- [MLT-Final]、[MLT-Practice]、[MLT-HW1]、[MLT-HW2]、[MLT-HW3] 是机器学习理论课程考试、练习或作业。


课程题只能证明“课程训练材料中多次出现”或“与博资考存在母题关系”，不得计入博资考出现频率，也不得称为历年博资考真题。

二、资料代号、性质与优先级

表 1: 上传资料审计表

代号	文件性质	层级	在本讲义中的用途与限制
[25S]	2025 Spring 人工智能博资考	第一层	核定考试结构、分值、实际题型与实考扩展；计入博资考频率。
[25F]	2025 Fall 人工智能博资考	第一层	核定四方向的广度、跨方向题和系统设计深度；计入博资考频率。
[26S]	2026 Spring 人工智能博资考	第一层	核定最新一套题的重点迁移、连续时间生成模型、长上下文与外部记忆；计入博资考频率。

代号	文件性质	层级	在本讲义中的用途与限制
[MLT-Final]	机器学习理论 2025 Spring 期末考试	第二层	证明题与母题训练；不是博资考真题，不计频率。
[MLT-Practice]	机器学习理论综合练习集	第二层	补充 VC、强凸、有限类一致收敛、核岭、多分类与树的训练题；不计博资考频率。
[MLT-HW1]	机器学习理论作业一答案	第二层	非同分布有限类界、经验风险期望、假设类并与 No Free Lunch 训练；不计博资考频率。
[MLT-HW2]	机器学习理论作业二答案	第二层	SGD 学习保证、核构造、排序/多类构造与课程实践题；不计博资考频率。
[MLT-HW3]	机器学习理论作业三答案	第二层	决策树表达、复合增长函数、神经网络表达下界与手工反向传播；不计博资考频率。
[DL-Basic]	深度学习基础讲义	第二层	统一网络、张量、训练流程、CNN、注意力、表示学习与训练实践术语。
[Gen]	生成模型讲义	第二层	统一最大似然、GAN、VAE、flow、diffusion、score 与 flow matching 的课程表述。
[RL]	强化学习讲义	第二层	统一 MDP、Bellman、动态规划、Q-learning、策略梯度与 actor-critic 记号。
[Opt-CA]	凸分析讲义	第二层	统一凸集、分离、Farkas、光滑/强凸、次微分、共轭与 prox 的定理版本。
[Opt-Alg]	优化算法讲义	第二层	统一 GD、proximal gradient、SGD、动量、预条件、自适应算法的更新式。
[NLP-Train]	自然语言处理博资考培训讲义	第二层	确定 NLP 方向的课程口径、任务建模、评价、知识推理与系统设计重点。
[UML]	<i>Understanding Machine Learning</i>	第三层	补充严格定义、PAC/VC/稳定性证明、经典模型、核、近邻、压缩感知与复杂度。
[SLP]	<i>Speech and Language Processing</i>	第三层	补充 tokenization、n-gram、embedding、Transformer、LLM、对齐、IR/RAG、HMM/CRF 与信息抽取。
[Opt-Sup]	<i>Convex Optimization: Algorithms and Complexity</i>	第三层	补充一阶方法、加速、随机优化、mini-batch、坐标下降和复杂度结论。



来源冲突处理。 第一层决定“考什么、分值多大、答案写到多深”；第二层决定课程术语、符号习惯和证明训练方式；第三层用于补全严格假设、证明细节、复杂度与反例。若资料冲突，采用数学上正确且能与第一层试题对应的统一约定，并明确给出换算关系，不静默拼接。

三、全文记号、张量维度与参数化主约定

表 2: 全文主记号与约定

对象	主约定及换算说明
标量、向量、矩阵、张量	标量用普通小写字母；列向量用粗体小写如 $\mathbf{x} \in \mathbb{R}^d$ ；矩阵用粗体大写如 $\mathbf{X} \in \mathbb{R}^{m \times d}$ ；三阶及以上张量用无衬线大写如 $\mathbf{X}$ 。内积为 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y}$ 。
样本与分布	$Z = (X, Y) \sim P$ ，样本 $S = (Z_1, \dots, Z_m) \sim P^m$ 默认独立同分布。若只讨论无噪声二分类，可写 $X_i \sim D$ 、 $Y_i = f(X_i)$ 。数据集符号 $\mathcal{D}$ 不与分布 P 混用。
风险	总体风险 $L_P(h) = \mathbb{E}_{Z \sim P}[\ell(h, Z)]$ ；经验风险采用平均值 $\hat{L}_S(h) = m^{-1} \sum_{i=1}^m \ell(h, Z_i)$ 。若附件使用损失之和，需把步长或正则系数按 m 换算。
二分类标签	统计学习与逻辑回归默认 $Y \in \{0, 1\}$ ；SVM、margin 与部分多分类推导局部使用 $\tilde{Y} \in \{-1, +1\}$ ，两者由 $\tilde{y} = 2y - 1$ 换算。
强凸性	采用 $f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \ y - x\ ^2$ 。因此 $f(w) = \lambda \ w\ ^2$ 是 2λ -强凸，而 $\frac{\lambda}{2} \ w\ ^2$ 是 λ -强凸。
岭回归	主目标为 $\frac{1}{2m} \ \mathbf{X}\mathbf{w} - \mathbf{y}\ ^2 + \frac{\lambda}{2} \ \mathbf{w}\ ^2$ 。若附件写成 $\lambda \ \mathbf{w}\ ^2 + \frac{1}{2m} \sum_i (\dots)^2$ ，主约定中的正则参数等于附件参数的两倍。
软间隔 SVM	主约定为 $\frac{\lambda}{2} \ \mathbf{w}\ ^2 + \frac{1}{m} \sum_i [1 - y_i f_w(x_i)]_+$ ；与 $\frac{1}{2} \ \mathbf{w}\ ^2 + C \sum_i \xi_i$ 对应时，在同一损失缩放下 $C = 1/(\lambda m)$ 。
mini-batch	批大小为 B 。样本梯度平均为 $\hat{g}_B = B^{-1} \sum_{i \in \mathcal{B}} g_i$ ，不是求和；若采用求和，学习率需相应缩小。
注意力维度	输入 $\mathbf{X} \in \mathbb{R}^{B \times L \times d_{\text{model}}}$ 。每头 $\mathbf{Q}, \mathbf{K} \in \mathbb{R}^{B \times L \times d_k}$ 、 $\mathbf{V} \in \mathbb{R}^{B \times L \times d_v}$ ；注意力矩阵的行对应 query、列对应 key，形状为 $B \times L \times L$ 。通常 $d_k = d_v = d_{\text{model}}/h$ 。
卷积张量	图像默认采用 $B \times H \times W \times C_{\text{in}}$ 记号；卷积核为 $k_h \times k_w \times C_{\text{in}} \times C_{\text{out}}$ 。若实现采用 channels-first，仅交换轴，不改变参数量公式。
KL 与 VAE	$\text{KL}(q p) = \mathbb{E}_q \log(q/p)$ ，方向不可交换。ELBO 定义为待最大化的 $\mathbb{E}_{q_\phi(z x)} \log p_\theta(x z) - \text{KL}(q_\phi(z x) p(z))$ ；训练“损失”取其相反数。
扩散模型	$\beta_t \in (0, 1)$ ， $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，且 $q(x_t x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$ 。

对象	主约定及换算说明
MDP 奖励下标	主文采用 $R_t = r(S_t, A_t)$ 、 $S_{t+1} \sim P(\cdot S_t, A_t)$ 、 $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k}$ 。 若资料采用 R_{t+1} ，整体平移一个下标即可。
占用测度	非归一化占用测度 $\rho^\pi(s) = \sum_{t \geq 0} \gamma^t \Pr(S_t = s \pi)$ ，总质量为 $(1 - \gamma)^{-1}$ ；归一化版本 $d^\pi = (1 - \gamma)\rho^\pi$ 。策略梯度的期望式将明确说明使用哪一个。
动量与 Adam	动量主约定： $v_{k+1} = \beta v_k + g_k$ ， $\theta_{k+1} = \theta_k - \eta v_{k+1}$ 。Adam 使用 m_k, v_k 表示一、二阶矩，并使用 $\hat{m}_k = m_k/(1 - \beta_1^k)$ 、 $\hat{v}_k = v_k/(1 - \beta_2^k)$ 。AdamW 把 weight decay 与梯度中的 ℓ_2 项解耦。


已发现的显式差异、可见笔误与处理决定

- 1. [MLT-HW3-Q2, 课程作业] 的证明建立的是复合类增长函数的上界，末行写成等号与前文不一致；全文采用正确的 $\tau_{\mathcal{F}_2 \circ \mathcal{F}_1}(m) \leq \tau_{\mathcal{F}_2}(m)\tau_{\mathcal{F}_1}(m)$ 。
- 2. [MLT-HW2-Q1, 课程作业] 的末段出现与前提 $\epsilon > 0$ 不相容的符号判断；本文不复制该段，后续依据其引用的 SGD 定理重新完成代数推导，并标记为推导补充。
- 3. [25F-A-Q10(c), 6 分题中的一小问] 的页面解析显示严格大于号；强凸性可保证的是“ $\geq$ ”，且二次函数在某些点可取等号。全文采用非严格不等号，并把严格大于写法列为考场纠错点。
- 4. [25F-B-Q3(a), 6 分] 同时称状态访问量为“未归一化”并写成概率期望形式。全文分别定义 ρ^π 与 d^π ，从而消除额外的 $1/(1 - \gamma)$ 歧义。
- 5. 任何由 PDF 文本抽取造成的 $\geq$ 、 $\leq$ 、范数、转置或上下标缺失，均以页面图像、相邻公式和数学一致性联合核对；仍无法确认者标“待核对”。

四、三套博资考结构与主题分布摘要

表 3: 三套人工智能博资考试卷主题分布摘要


试卷	方向	实际考查主题	主导题型
25S	A	固定假设经验损失方差；独立非同分布有限类保证；假设类并的 VC 维；replace-one stability 与正则化 ERM。	完整证明、概率界、稳定性。
25S	B	MLP 分类流水线、交叉熵与 SGD、batch normalization 训练/测试差异、表达力与过拟合；VP-SDE、反向 SDE、score matching。	模型设定、推导、诊断。
25S	C	光滑与强凸定义；光滑强凸插值不等式；proximal SGD 的一步递推、方差分解、线性收缩、复杂度与 noise floor。	连续多问证明链。



试卷	方向	实际考查主题	主导题型
25S	D	trigram 与平滑; 表示学习; top- p ; Transformer; scaling law; RLHF; 无标注领域语料上的问答系统。	概念简答、算法分析、系统设计。
25F	A	bias-variance、NFL、Rademacher、ERM、VC、agnostic PAC、Sauer; signed interval 的 VC 维; 强凸性质; 同心圆 PAC; 投影随机次梯度; sigmoid 通用逼近构造。	选择题、证明、构造。
25F	B	CNN 参数量; self-attention 与位置; 卷积-注意力视觉架构; MLE/KL、flow、VAE、diffusion ELBO; policy gradient 与 baseline。	计算、推导、比较。
25F	C	复合有限和 proximal SGD; 无偏估计; expected smoothness; mini-batch 插值; importance sampling; 最优点方差; AC inequality; 收敛与噪声底。	递进式算法分析。
25F	D	GloVe/Skip-gram/Node2Vec/TransE; LSTM 与 Transformer scaling; MLN; 带本体变量的主题模型; 文本条件扩散系统。	比较、概率建模、系统设计。
26S	A	agnostic PAC、Sauer、ReLU 函数类、ERM、NFL、核; 经验损失均方误差; 强凸解存在唯一; 区间并射线的增长函数/VC; multivector; ReLU 与 sigmoid 函数类交。	选择题、证明、构造。
26S	B	反向传播与复杂度; 梯度消失; 动量; attention scaling; RNN/Transformer; flow matching、连续性方程、Fokker-Planck; Bellman、policy iteration、actor-critic、RLHF/DPO。	推导、复杂度、算法步骤。
26S	C	prox 最优性、固定点、次微分单调性、非扩张性; 随机递推与 noise floor; 迭代平均及 $O(\log k/k)$ 。	基础性质到收敛率的证明链。
26S	D	InfoNCE 梯度与高维负样本; 监督主题模型; 长序列注意力; MLN 全局实体链接/关系抽取; RAG 外部记忆收益与 MDP 优化。	梯度、概率模型、复杂度、系统设计。

实考扩展判定。 Rademacher complexity、algorithmic stability、非同分布有限类界、神经网络函数类交、多分类 multivector、score-based diffusion、reverse-time SDE、Fokker-Planck、flow matching、expected smoothness、AC inequality、MLN、监督主题模型、长上下文、外部记忆 MDP 等, 虽不一定在简要考纲中单列, 但均已在三套真题中实际出现。后文相应位置统一标记:

“该主题未在简要考纲中单独列出, 但曾在历年人工智能博士资格考试中实际考查。”



五、考纲—资料—训练题—真题映射总览

表 4: 四方向资料映射总览

方向	主资料	严格性补充	课程训练证据	三套真题证据
A	[UML]; 本 Prompt 考纲	[Opt-CA]、[Opt-Sup] 用于凸性与 SGD 前置	[MLT-Final]、[MLT-Practice]、[MLT-HW1--3]	[25S-A]、[25F-A]、[26S-A]
B	[DL-Basic]、[Gen]、[RL]	[Opt-Alg] 用于训练算法; [UML] 用于表达/泛化	[MLT-Final] 与 [MLT-HW3] 中的反向传播题仅作补充	[25S-B]、[25F-B]、[26S-B]
C	[Opt-CA]、[Opt-Alg]	[Opt-Sup] 用于复杂度、加速与随机算法	机器学习课程材料中的强凸、SGD、核与次梯度题作交叉训练	[25S-C]、[25F-C]、[26S-C]
D	[NLP-Train]、[SLP]	[Gen]、[RL] 用于生成与对齐; [DL-Basic] 用于 Transformer 前置	不把机器学习课程题计入 D 方向频率	[25S-D]、[25F-D]、[26S-D]

机器学习课程训练材料的母题关系摘要

表 5: 课程训练题与博资考母题关系 (不计博资考频率)

课程材料	训练技能	与博资考的关系
[MLT-Final-Q1, 10 分, 课程期末题]	indicator 随机变量、均值与方差	与 [25S-A-Q1, 7 分] 同母题; [26S-A-Q1, 6 分] 增加 $p(1-p) \leq 1/4$ 。
[MLT-Final-Q2, 15 分, 课程期末题]、[MLT-HW1-Q1, 课程作业]	独立非同分布、AM-GM、union bound	与 [25S-A-Q2, 7 分] 同母题。
[MLT-HW1-Q3, 课程作业]	假设类并、Sauer 引理、增长函数	是 [25S-A-Q3(a), 5 分] 的直接训练母题。
[MLT-Practice-Q4, 课程练习]	特殊几何类的一致学习器与 PAC 界	与 [25F-A-Q11, 5 分] 高度同型。
[MLT-Practice-Q7, 课程练习]	multivector、偏置增广、几何间隔	与 [26S-A-Q4, 7 分] 高度同型。




课程材料	训练技能	与博资考的关系
[MLT-Final-Q6, 15 分, 课程期末题]、 [MLT-Practice-Q9, 课程练习]	ReLU 分段线性、sigmoid 光滑/解析性质	与 [26S-A-Q5, 5 分] 同母题。
[MLT-Practice-Q6, 课程练习]	representer theorem 与核岭 闭式解	补充核方法覆盖；三套博资考仅在 [26S-A-MQ6, 0.5 分] 直接考核有效核概念。
[MLT-HW3-Q2, 课程作业]、 [MLT-Final-Q5, 15 分, 课程期末题]	复合类与笛卡尔积类的增长 函数	为假设类代数与 VC 上界题提供补充，不单独计为真题频率。
[MLT-HW3-Q2, 课程实践题]	手工反向传播与自动微分核 对	与 [26S-B-Q1(a), 2 分] 的链式法则 和复杂度要求形成技能关联。

六、知识点优先级总表

优先级只使用三套博资考、明确考纲、讲义与课程训练材料作证据。表中的“真题套数”指该主题在 [25S]、[25F]、[26S] 中出现的试卷套数；同一套卷多个小问仍只计一套，课程题不计入。

表 6: 核心知识点优先级摘要

方向	主题	真题套数	代表真题或依据	等级
A	VC 维、增长函数、Sauer、假设类运算	3	25S 并类；25F signed interval 与 Sauer；26S 区间并射线	S
A	风险、经验风险及固定假设方差	2	25S-A-Q1；26S-A-Q1；课程期末同母题	S
A	PAC、有限类、可实现/agnostic、NFL	3	25S 非同分布有限类；25F PAC/NFL；26S PAC/ERM/NFL	S
A	稳定性与正则化 ERM	1	25S-A-Q4 共 10 分，且是学习保证核心工具	S
A	神经网络表达、通用逼近与函数类性质	2	25F-A-Q13；26S-A-Q5	S
A	Rademacher complexity	1	25F-A-MQ3；[UML] 高级理论章节	C



方向	主题	真题套数	代表真题或依据	等级
B	生成模型目标: MLE、ELBO、flow、diffusion、score、flow matching	3	三套 B 方向均有高分生成模型题	S
B	反向传播、激活、BN、SGD/动量、过拟合诊断	2	25S-B-Q1; 26S-B-Q1	S
B	CNN、self-attention、Transformer/ViT 与复杂度	2	25F-B-Q1; 26S-B-Q1; 并与 D 方向交叉	S
B	Bellman、策略梯度、baseline、actor-critic、RLHF/DPO	2	25F-B-Q3; 26S-B-Q3; 25S-D-Q7 交叉	S
C	光滑、强凸、插值不等式与条件数	3	三套 C 均作为收敛证明前置	S
C	prox 最优性、固定点、单调性、非扩张性	3	25S/25F/26S 的 proximal SGD 证明链	S
C	随机梯度、条件期望、方差分解、noise floor	3	三套 C 均考	S
C	expected smoothness、mini-batch、importance sampling、AC inequality	1	25F-C 的 33 分连续题	A
C	加速与 Adam 系列	0	明确考纲与 [Opt-Alg] 核心内容	A
D	embedding、对比学习与知识表示	3	25S 表示学习; 25F 四类 embedding; 26S InfoNCE	S
D	Transformer、长序列与 scaling law	3	25S、25F、26S 均有直接题	S
D	RLHF、DPO 与对齐	2	25S-D-Q7; 26S-B-Q3(d)	S
D	MLN、实体链接、关系抽取与全局一致性	2	25F-D-Q3; 26S-D-Q4	S
D	主题模型与监督/本体变量	2	25F-D-Q4; 26S-D-Q2	S
D	RAG、领域问答与外部记忆 MDP	2	25S-D-Q8; 26S-D-Q5	S
D	n-gram、平滑、解码与评价	1	25S-D-Q1/Q3; 明确考纲基础	A



七、跨方向依赖图与差异化考法




表 7: 重复主题的方向差异

主题	主要归属	其他方向的考查角度	不应重复或混淆之处
SGD	C: 无偏性、方差、步长、收敛率、noise floor	A: 学习保证与稳定性; B: mini-batch、动量与训练实践	“训练有效”不等于已有凸收敛定理; 必须说明目标类别与噪声假设。
Transformer	D: 语言建模、causal mask、解码、长上下文	B: 张量计算、表达、视觉 Transformer、与卷积组合	D 侧重序列与系统; B 侧重架构、维度、参数量和视觉归纳偏置。
Embedding	D: 词、图、实体、检索、RAG	B: 表示学习、对比学习、迁移; A: 函数类与泛化可作理论分析	余弦相似度只表示几何接近, 不自动代表事实、逻辑或因果正确。
RLHF	B/RL: 策略优化、KL 正则、actor-critic/PPO 风格目标	D: 语言模型对齐流水线、偏好数据、reward model、DPO 与失败模式	reward model、policy、reference policy 三者角色必须分开。
正则化	A: 复杂度控制、稳定性、泛化	C: 复合目标与 prox; B: weight decay、dropout、隐式正则	AdamW 的 decoupled weight decay 一般不等于把 l_2 项直接加入 Adam 梯度。
生成模型	B: 似然、ELBO、可逆变换、SDE/ODE	D: 自回归语言模型、条件生成、文本到图像系统	likelihood、ELBO、adversarial、score 与 flow-matching 目标不可混写。

答题方法

整卷时间按比例分配，而不虚构考试时长。设总作答时间为 T ：

1. 用约 $0.05T$ 浏览四方向并在答卷开头明确写出选择；

2. 三个方向各预留约 $0.30T$ ，方向内部按分值比例分配，即一道 p 分题的基础预算为 $0.90T \cdot p/99$ ；

3. 保留约 $0.05T$ 做符号、维度、KL 方向、复杂度与题号检查；

4. 若某一小问超过其预算的 1.5 倍仍无进展，先写定义、已知条件、目标式与可用引理，标

记后切换；

5. 不跨第四方向“捞分”，因为试卷明确只批改最先出现的三个方向。

八、推荐复习顺序与答题质量标准

推荐顺序不是按学科名称，而是按依赖关系：

1. 共同数学前置：条件期望、集中不等式、矩阵微分、Jacobian、凸性与光滑性；
2. A 的风险—PAC—VC 主链与 C 的凸分析—prox—随机递推主链；
3. B 的反向传播—attention—生成模型—RL 主链；
4. D 的 n-gram—embedding—Transformer—对齐—检索/知识推理/系统设计主链；
5. 三套真题按 25S、25F、26S 做闭卷模拟，再按母题回填薄弱点；
6. 最后只背“定义、假设、关键等式、复杂度、失败条件、满分步骤”，不再扩张新主题。

答题方法

资格考试答案的最低可核查标准如下：

1. **定义题**：写清对象、量词、参数范围和随机性来源；
2. **证明题**：先写假设与目标，再明确每一步使用的引理或不等式；
3. **梯度题**：写计算图、局部 Jacobian、链式乘法顺序，并在关键行标维度；
4. **收敛题**：写目标函数类别、步长、噪声条件、一步递推、望远镜或收缩、最终复杂度；
5. **复杂度题**：先定义输入规模，指出主导矩阵乘法/检索/注意力操作，再给时间与空间复杂度；
6. **系统设计题**：必须覆盖数据流、训练目标、推理流程、评价指标、消融与失败模式；
7. **经验规律**：明确写“经验拟合/启发式”，不得伪装成无条件定理。




目录


使用说明、资料审计与考试总览	ii
任务定位与资料边界	ii
十七份资料代号、性质与优先级	ii
全文记号、张量维度与参数化主约定	iv
三套博资考结构与主题分布摘要	v
考纲—资料—训练题—真题映射总览	vii
知识点优先级总表	viii
跨方向依赖图与差异化考法	x
推荐复习顺序与答题质量标准	xi
 第一部分 机器学习理论	 1
第一章 统计学习问题的形式化、风险与经验风险	2
1.1 重要性等级与考情定位	2
1.2 精确定义与问题设定	2
1.3 核心结论、条件与复杂度	3
1.4 为什么条件不能省	3
1.5 证明或推导要求	4
1.6 完整证明与算法分析	4
1.7 标准识别与使用方法	5
1.8 典型题型	5
1.9 答题方法	6
1.10 易错点、反例与失败模式	6
1.11 真题与训练材料对应	6
1.12 快速自测	7
 第二章 经验风险最小化、归纳偏置、过拟合与 No Free Lunch	 8
2.1 重要性等级与考情定位	8
2.2 精确定义与问题设定	8
2.3 核心定理、模型关系与适用范围	9




2.4	为什么条件和设计不能省	9
2.5	证明或推导要求	10
2.6	证明、推导与算法分析	10
2.7	标准识别与使用方法	11
2.8	典型题型	11
2.9	答题方法	12
2.10	易错点、反例与失败模式	12
2.11	真题与训练材料对应	13
2.12	快速自测	13
第三章	可实现 PAC、Agnostic PAC 与样本复杂度	14
3.1	重要性等级与考情定位	14
3.2	精确定义与问题设定	14
3.3	核心定理、结论与适用范围	15
3.4	为什么条件不能省	15
3.5	证明或推导要求	16
3.6	完整证明与推导	16
3.7	标准识别与使用方法	17
3.8	典型题型	17
3.9	答题方法	17
3.10	易错点、反例与失败模式	18
3.11	真题与训练材料对应	18
3.12	快速自测	18
第四章	有限假设类、集中不等式与一致收敛	19
4.1	重要性等级与考情定位	19
4.2	精确定义与问题设定	19
4.3	核心定理与样本复杂度	19
4.4	为什么条件不能省	20
4.5	证明或推导要求	21
4.6	完整证明与推导	21
4.7	标准识别与使用方法	22
4.8	典型题型	23
4.9	答题方法	23
4.10	易错点、反例与失败模式	23
4.11	真题与训练材料对应	24
4.12	快速自测	24
第五章	打散、增长函数与 VC 维	25




5.1	重要性等级与考情定位	25
5.2	精确定义、对象与量词	25
5.2.1	限制类与标记向量	25
5.2.2	打散	25
5.2.3	增长函数	26
5.2.4	VC 维	26
5.3	基本性质及其严格证明	26
5.4	为什么定义中的条件不能省	27
5.5	VC 维证明的标准母题	28
5.6	至多 k 个正例的假设类	28
5.6.1	问题设定	28
5.7	轴对齐下盒: $\text{VCdim} = p$	29
5.7.1	模型与结论	29
5.8	二维轴对齐矩形: $\text{VCdim} = 4$	30
5.9	一维区间类与 signed intervals	30
5.9.1	普通区间类	30
5.9.2	Signed intervals 的精确增长函数	31
5.10	区间与右射线之并: 增长函数与 VC 维	32
5.10.1	问题设定	32
5.11	假设类之并	33
5.11.1	增长函数的基本上界	33
5.11.2	两个类之并的 VC 维上界	33
5.11.3	二维矩形类与三角形类之并	34
5.11.4	多个假设类之并	35
5.12	笛卡尔积类与复合类的增长函数	35
5.12.1	笛卡尔积类	35
5.12.2	复合类	36
5.13	增长函数、VC 维与计算复杂度的区别	36
5.14	标准识别与使用方法	37
5.15	典型题型	37
5.16	答题方法	38
5.17	易错点、反例与失败模式	39
5.18	真题与训练材料对应	39
5.19	快速自测	40
第六章	Sauer 引理、统计学习基本定理与 VC 样本复杂度	41
6.1	重要性等级与考情定位	41
6.2	从 VC 维到有效假设类大小	41




6.2.1	增长函数的再次表述	41
6.2.2	二项式和记号	42
6.3	Sauer–Shelah–Perles 引理	42
6.4	Sauer 引理的完整归纳证明	42
6.4.1	证明结构	42
6.4.2	多项式形式的证明	43
6.4.3	Sauer 上界何时达到等号	44
6.5	从点态集中到一致收敛：为什么需要增长函数	44
6.6	二分类零一损失下的 VC 偏差不等式	44
6.6.1	损失函数类	44
6.6.2	双样本对称化	45
6.6.3	条件化后的随机交换	45
6.7	Agnostic ERM 的 VC 泛化界	46
6.8	可实现情形的 VC 泛化界	47
6.8.1	坏一致假设事件	47
6.9	统计学习基本定理：定性版本	48
6.9.1	完整蕴含关系	49
6.10	统计学习基本定理：定量版本	50
6.11	样本复杂度下界的证明框架	50
6.11.1	置信项 $\ln(1/\delta)$ 的可实现下界	50
6.11.2	VC 维项 d 的可实现下界	51
6.11.3	Agnostic 情形的 d/ε^2 下界	51
6.12	为什么定理条件不能省	51
6.12.1	二分类与零一损失	51
6.12.2	独立同分布	52
6.12.3	分布无关量词	52
6.12.4	可测性	52
6.12.5	统计可学习性与计算效率	52
6.13	证明与推导要求分级	52
6.14	标准识别与使用方法	53
6.15	典型题型	53
6.16	答题方法	54
6.17	易错点、反例与失败模式	55
6.18	真题与训练材料对应	56
6.19	快速自测	57
第七章	Rademacher Complexity 与数据依赖泛化界	58
7.1	重要性等级与实考定位	58




7.2	问题设定与三种复杂度版本	58
7.3	随机标记解释	59
7.4	对称化：从总体风险差到随机符号相关	60
7.5	高概率泛化界	61
7.6	Rademacher calculus	62
7.7	线性函数类的复杂度	62
7.7.1	ℓ_2 范数约束	62
7.7.2	ℓ_1 范数约束	63
7.8	Rademacher complexity 与 VC 维的关系	64
7.9	典型题型与答题方法	64
第八章	算法稳定性与正则化经验风险最小化	66
8.1	重要性等级与实考定位	66
8.2	替换样本与稳定性定义	66
8.3	正则化 ERM 的参数化约定	67
8.4	凸 Lipschitz 损失下的稳定性	68
8.5	Oracle inequality 与正则化参数选择	69
8.6	稳定性、拟合误差与近似 ERM	70
8.7	为什么定理条件不能省	70
8.8	Rademacher 与稳定性分析的区别	70
8.9	历年题型与满分模板	71
第九章	结构风险最小化、验证与模型选择	73
9.1	重要性等级与考情定位	73
9.2	模型选择的形式化	73
9.3	结构风险最小化	74
9.3.1	加权模型族	74
9.4	Hold-out validation	75
9.4.1	有限候选集的模型选择	75
9.5	k -fold cross-validation	76
9.6	Train-validation-test 划分与数据泄漏	76
9.7	模型选择曲线与失败诊断	77
9.8	SRM、验证与正则化的关系	78
9.9	典型题型与满分模板	78
9.10	真题与训练材料对应	79
9.11	快速自测	79
第十章	线性回归、逻辑回归、决策树与最近邻	81
10.1	线性回归与 Ridge Regression	81




10.1.1 统一数据与参数约定	81
10.1.2 最小二乘目标、梯度与 Hessian	81
10.1.3 Ridge regression	82
10.1.4 训练复杂度	83
10.2 逻辑回归	83
10.2.1 二分类模型	83
10.2.2 梯度与 Hessian	84
10.2.3 决策边界、概率与失败模式	84
10.2.4 多分类逻辑回归	84
10.3 决策树	85
10.3.1 模型与分裂准则	85
10.3.2 表示能力与 VC 维	85
10.3.3 剪枝与复杂度	86
10.4 k -最近邻	86
10.4.1 统计保证的条件	86
10.4.2 维数灾难与距离集中	87
10.4.3 计算复杂度	87
第十一章 支持向量机与核方法	88
11.1 重要性等级与考情定位	88
11.2 函数间隔与几何间隔	88
11.3 Hard-margin SVM	89
11.3.1 对偶问题	89
11.3.2 KKT 条件与支持向量	89
11.4 Soft-margin SVM 与参数化换算	90
11.4.1 Soft-margin 对偶	90
11.4.2 Hinge loss 的次梯度	90
11.5 Margin-based generalization	91
11.6 核、Gram 矩阵与 PSD 条件	91
11.6.1 核的基本构造	92
11.7 Representer theorem	92
11.8 Kernel SVM 与 Kernel Ridge Regression	93
11.8.1 Kernel SVM	93
11.8.2 Kernel ridge regression	93
第十二章 压缩感知、多分类与神经网络学习理论扩展	95
12.1 压缩感知	95
12.1.1 稀疏表示与欠定测量	95




12.1.2 Null-space property	95
12.1.3 Restricted Isometry Property	96
12.1.4 与 PCA、特征选择和正则化的区别	96
12.2 多分类与 Multivector Construction	97
12.2.1 Generalized hinge loss	98
12.2.2 历年真题构造	98
12.3 神经网络的表达能力、VC 维与可学习性	99
12.3.1 三类不同命题	99
12.3.2 Sigmoid 网络的构造性通用逼近	99
12.3.3 逼近所有 Lipschitz 函数需要指数规模	101
12.3.4 ReLU 与 sigmoid 网络共同表示函数只能为常数	101
第十三章 机器学习理论速查表与方向收束	103
13.1 核心模型、目标、复杂度与失败模式	103
13.2 本方向新增真题与训练题映射	104
13.3 A 方向考场核查清单	104
13.4 快速自测	105
第二部分 深度学习与强化学习	107
第十四章 深度学习问题设定、MLP 与计算图	108
14.1 考情定位与证明要求	108
14.2 监督深度学习问题的完整形式化	108
14.2.1 数据、任务与数据集划分	108
14.2.2 特征提取器与分类器	109
14.2.3 经验目标与总体目标	110
14.3 MLP 的逐层定义、维度与参数量	110
14.3.1 单样本的列向量约定	110
14.3.2 Mini-batch 的矩阵约定	111
14.4 计算图与局部 Jacobian	111
第十五章 链式法则、反向传播与自动微分	113
15.1 一般层状网络的反向传播公式	113
15.2 线性层的完整梯度	114
15.3 逐坐标激活函数的反向传播	114
15.4 Softmax 与交叉熵的合并梯度	115
15.5 两层 MLP 的完整反向传播例题	115
15.6 为什么反向传播与前向传播同价	116




15.7 自动微分、符号微分与数值微分	117
第十六章 训练稳定化、正则化与误差诊断	118
16.1 梯度消失与梯度爆炸	118
16.1.1 Sigmoid	118
16.1.2 Tanh	118
16.1.3 ReLU 与 dead ReLU	118
16.1.4 梯度裁剪	119
16.2 参数初始化与方差传播	119
16.2.1 为什么不能把所有权重初始化为零	119
16.2.2 线性层的前向方差	119
16.2.3 Xavier/Glorot 初始化	120
16.2.4 Kaiming/He 初始化	120
16.3 Mini-batch SGD	120
16.4 学习率与 Momentum	121
16.4.1 学习率过大的发散例子	121
16.4.2 Momentum 的主约定	121
16.5 Batch Normalization	122
16.5.1 训练阶段	122
16.5.2 推理阶段	123
16.5.3 BN 的反向传播	123
16.5.4 作用、条件与失败模式	123
16.6 残差连接	124
16.7 Dropout	125
16.7.1 主约定: inverted dropout	125
16.7.2 作用与边界	125
16.8 Weight Decay、数据增强与 Early Stopping	125
16.8.1 Weight decay 与 ℓ_2 penalty	125
16.8.2 数据增强	126
16.8.3 Early stopping	126
16.9 训练误差与测试误差的诊断矩阵	126
16.10 [25S-B-Q1, 18 分] 答题方法	127
16.11 高频易错点总表	127
16.12 本部分真题与课程训练映射	128
16.13 快速自测	129
第十七章 卷积神经网络与视觉任务	130
17.1 重要性等级与实考定位	130




17.2 卷积与互相关的统一约定	130
17.2.1 数学卷积与深度学习中的“卷积”	130
17.2.2 二维多通道卷积	131
17.2.3 参数量、计算量与存储	131
17.3 局部连接、参数共享与平移等变性	132
17.3.1 局部连接	132
17.3.2 平移等变性	132
17.4 Receptive Field、Stride、Dilation 与 Pooling	133
17.4.1 Receptive Field 递推	133
17.4.2 Pooling	134
17.5 视觉任务的统一建模框架	134
17.5.1 图像分类	134
17.5.2 语义分割	134
17.5.3 图像恢复	135
17.5.4 目标检测	135
17.5.5 光流估计	136
17.5.6 三维重构	136
17.6 视觉任务系统设计的满分模板	137
第十八章 注意力、Transformer 与 Vision Transformer	138
18.1 重要性等级与实考定位	138
18.2 单查询注意力	138
18.3 矩阵形式与张量维度	138
18.4 为什么必须除以 $\sqrt{d_k}$	139
18.5 Self-Attention、Cross-Attention 与 Mask	140
18.5.1 Self-attention	140
18.5.2 Cross-attention	140
18.5.3 Causal mask 与 padding mask	140
18.6 Multi-Head Attention	141
18.7 位置编码与排列等变性	141
18.7.1 无位置 self-attention 的性质	141
18.7.2 绝对位置编码	142
18.8 Transformer Block	142
18.9 计算复杂度与 RNN 比较	142
18.10 Vision Transformer	143
18.10.1 Patch Tokenization	143
18.10.2 卷积与 Self-Attention 的归纳偏置	144
18.10.3 最小卷积-注意力混合模型	144




18.11 窗口注意力与长序列补充	145
第十九章 自编码器、自监督学习与对比表示学习	146
19.1 表示学习的核心问题	146
19.2 确定性自编码器	146
19.2.1 模型与目标	146
19.2.2 为什么必须限制模型	147
19.3 去噪自编码器	147
19.4 自监督学习	148
19.5 对比学习与 InfoNCE	148
19.5.1 正负样本设定	148
19.5.2 InfoNCE 对 Anchor 的梯度	149
19.5.3 温度参数	149
19.6 高维负样本几何	150
19.6.1 False Negative	150
19.7 对比学习的计算复杂度与训练流程	151
第二十章 迁移学习、微调与元学习	152
20.1 迁移学习的形式化	152
20.1.1 Linear Probing	152
20.1.2 Full Fine-Tuning	152
20.1.3 迁移学习的失败模式	153
20.2 元学习的基本设定	153
20.2.1 MAML 形式	153
20.2.2 度量型元学习	154
20.3 迁移学习与元学习的区别	154
20.4 本部分核心公式与复杂度速查	154
20.5 真题与资料映射	155
20.6 本部分高频易错点	156
20.7 快速自测	157
第二十一章 生成模型的统一概率框架与自回归模型	159
21.1 重要性等级与实考定位	159
21.2 生成模型与判别模型	159
21.2.1 离散概率质量与连续概率密度	160
21.2.2 显式密度与隐式密度	160
21.3 KL 散度与最大似然	160
21.3.1 经验最大似然	161
21.4 自回归模型	162




21.4.1 链式分解	162
21.4.2 最大似然训练	163
21.4.3 Teacher forcing 的作用与边界	163
21.4.4 自回归推理	164
21.4.5 复杂度与 KV cache	164
第二十二章 生成对抗网络 (GAN)	166
22.1 重要性等级与资料定位	166
22.2 模型设定	166
22.3 固定生成器时的最优判别器	167
22.4 与 Jensen-Shannon 散度的关系	167
22.5 Generator 的饱和损失与非饱和损失	168
22.6 交替训练算法	168
22.7 失败模式	169
22.7.1 Mode collapse	169
22.7.2 Minimax 非收敛	169
22.7.3 支持集不重叠与梯度消失	169
22.8 Wasserstein GAN: 实考外扩展	170
第二十三章 变分自编码器与证据下界	171
23.1 重要性等级与实考定位	171
23.2 潜变量概率模型	171
23.3 ELBO 的 Jensen 推导	171
23.4 ELBO gap	172
23.5 重构项与正则项的严格含义	173
23.6 Gaussian VAE	173
23.6.1 Gaussian KL 的闭式形式	173
23.7 重参数化技巧	174
23.8 Gaussian VAE 的最终训练目标	175
23.9 VAE 的失败模式	175
23.9.1 模糊样本	175
23.9.2 Variational gap	175
23.9.3 Posterior collapse	176
第二十四章 Normalizing Flow	177
24.1 重要性等级与实考定位	177
24.2 变量替换公式	177
24.3 为什么可逆性和维度条件不能省	178
24.4 多层 Flow 的 log-likelihood	178




24.5 Normalizing Flow 的训练目标	179
24.6 Affine Coupling Layer	179
24.7 Jacobian 复杂度	180
24.8 离散图像的去量化	181
24.9 Normalizing Flow 的优点与失败模式	181
24.10 连续时间 Flow 的桥接	181
第二十五章 生成模型比较、真题映射与速查	183
25.1 训练目标与推理性质总表	183
25.2 相近目标函数的区别	183
25.3 历年真题映射	183
25.4 资格考试答题总模板	184
25.5 快速自测	185
第二十六章 离散时间扩散模型: DDPM 与层次 VAE	187
26.1 重要性等级与历年实考定位	187
26.2 统一记号与概率设定	187
26.3 固定前向加噪过程	188
26.3.1 为什么闭式采样极其重要	188
26.3.2 终端分布只是近似标准正态	189
26.4 可解析的反向后验	189
26.4.1 后验均值的噪声形式	190
26.5 学习的反向生成模型	190
26.6 DDPM 作为层次 VAE	190
26.7 从 Gaussian KL 到噪声预测	192
26.8 四种常见预测参数化	192
26.8.1 Noise prediction	192
26.8.2 Score prediction	192
26.8.3 Data prediction	193
26.8.4 Velocity prediction	193
26.9 DDPM 的训练算法与采样算法	193
26.10 与普通 VAE 的区别	194
第二十七章 Score Matching 与连续时间扩散 SDE	196
27.1 重要性等级与实考定位	196
27.2 一般前向 SDE	196
27.3 Reverse-time SDE	196
27.4 Variance Preserving SDE	197
27.5 VP SDE 的条件分布	197




27.6 条件 Score 的闭式表达	198
27.7 Explicit Score Matching	199
27.8 Implicit Score Matching	199
27.9 Denoising Score Matching 恒等式	199
27.10 VP SDE 的最终 Denoising Loss	200
27.11 Score-based Sampling	201
第二十八章 Fokker–Planck 方程与 Probability-Flow ODE	203
28.1 历年实考扩展标记	203
28.2 Fokker–Planck 方程	203
28.3 Continuity Equation	203
28.4 Probability-Flow ODE	204
28.5 VP SDE 的 Probability-Flow ODE	205
28.6 连续变量替换与似然	205
28.7 DDIM 与 ODE 采样: 扩展了解	206
第二十九章 Flow Matching、连续性方程与随机化流	207
29.1 重要性等级与实考定位	207
29.2 基本设定	207
29.3 线性插值与条件速度	208
29.4 Population Velocity	208
29.5 Continuity Equation 的严格证明	208
29.6 Conditional Flow Matching 目标	209
29.7 更一般的 Gaussian Conditional Path	210
29.8 Coupling 的作用	210
29.8.1 Conditional paths 可以相交	210
29.9 随机化 Flow 与 Fokker–Planck 抵消	211
29.10 如何估计 Flow Path 的 Score	211
29.10.1 Implicit Score Matching	211
29.10.2 Denoising Score Matching	212
29.10.3 确定性线性插值的特殊问题	212
29.11 Flow Matching 的训练与采样算法	212
29.12 Flow Matching 的失败模式	213
29.13 Rectified Flow: 扩展了解	213
29.14 扩散模型、Score Model 与 Flow Matching 速查	214
29.15 历年真题映射	214
29.16 综合易错点	215
29.17 快速自测	216




第三十章 Markov 决策过程与价值函数	218
30.1 重要性等级与历年实考定位	218
30.2 折扣 Markov 决策过程	218
30.2.1 期望即时奖励	219
30.3 策略与轨迹分布	219
30.4 折扣回报	219
30.5 状态价值、动作价值和优势函数	220
30.6 Bellman 期望方程	220
30.6.1 矩阵形式	221
30.7 Bellman Operator 与唯一性	221
第三十一章 Bellman 最优性与动态规划	223
31.1 最优价值函数	223
31.2 Bellman 最优性方程	223
31.3 由最优价值恢复最优策略	224
31.4 策略改进定理	224
31.5 策略迭代	225
31.6 值迭代	225
31.6.1 Bellman residual	226
第三十二章 Model-Free 价值学习: MC、TD、SARSA 与 Q-Learning	228
32.1 为什么需要 Model-Free 方法	228
32.2 Monte-Carlo 策略评估	228
32.3 Temporal-Difference Learning	229
32.3.1 表格型 TD(0) 的收敛条件	229
32.4 SARSA	229
32.4.1 ϵ -greedy 策略	230
32.5 Q-Learning	230
32.5.1 SARSA 与 Q-Learning 的本质区别	230
32.6 函数逼近与 Deep Q-Network	231
32.6.1 Experience Replay	231
32.6.2 Target Network	231
32.6.3 Double DQN	232
32.7 Deadly Triad	232
第三十三章 策略梯度定理、REINFORCE 与 Actor-Critic	233
33.1 参数化策略目标	233
33.2 折扣状态访问分布	233
33.3 Likelihood-Ratio 恒等式	233




33.4 Policy Gradient Theorem	234
33.5 状态基线不改变期望	235
33.5.1 严格的最小方差状态基线	236
33.6 REINFORCE	236
33.7 Actor-Critic	237
33.7.1 TD Error 是 Advantage 的一步估计	237
33.7.2 一步 Actor-Critic 更新	237
33.8 n -Step Return	237
33.9 Generalized Advantage Estimation	238
33.10 Actor-Critic 的 Model-Free 解释	238
第三十四章 RLHF、PPO 与 Direct Preference Optimization	240
34.1 语言模型作为强化学习策略	240
34.2 偏好数据	240
34.3 Bradley-Terry 奖励模型	241
34.4 KL 正则化的 RLHF 目标	241
34.5 KL 正则化目标的最优策略	242
34.6 PPO 型 RLHF 更新	242
34.7 DPO 的推导	243
34.8 DPO 梯度的方向	243
34.9 DPO 训练算法	244
34.10 DPO 等价性的假设边界	244
34.11 RLHF 与 DPO 的比较	245
34.12 偏好优化的典型失败模式	245
34.13 扩展: Group-Relative Baseline	246
34.14 强化学习统一视角	247
34.15 综合易错点	247
34.16 历年真题映射	248
34.17 快速自测	249
第三部分 人工智能中的优化方法	251
第三十五章 凸集、投影、分离定理与 Farkas 引理	252
35.1 重要性等级与考试定位	252
35.2 统一空间与记号	252
35.3 凸集、仿射集与凸锥	253
35.3.1 常用保凸运算	253
35.4 Euclidean 投影	254




35.4.1 闭性与凸性为什么不能省	254
35.5 投影的变分不等式	255
35.6 投影的 firm nonexpansiveness	255
35.7 点与闭凸集的严格分离	255
35.8 Farkas 引理	256
35.8.1 Farkas 引理的考试识别信号	256
第三十六章 闭凸函数、最优解存在性与强凸性	258
36.1 广义实值函数	258
36.2 Epigraph、闭函数与下半连续	258
36.3 凸函数、严格凸函数与强凸函数	259
36.4 凸函数的一阶刻画	260
36.5 二阶刻画	260
36.6 全局最优性与唯一性	260
36.7 最优解存在性	261
36.8 复合目标的存在唯一性	261
第三十七章 光滑性、下降引理与梯度余强制性	263
37.1 重要性等级	263
37.2 L -Smoothness	263
37.3 Descent Lemma	264
37.4 Bregman Divergence	264
37.5 凸光滑函数的梯度差下界	265
37.6 Co-Coercivity	265
37.7 强凸函数的梯度范数下界	266
37.8 光滑与强凸的联合插值不等式	266
37.9 条件数	267
37.10 梯度映射的压缩性	267
第三十八章 次微分、共轭函数与近端算子	269
38.1 重要性等级	269
38.2 次梯度与次微分	269
38.3 常见次微分	270
38.3.1 绝对值	270
38.3.2 ℓ_1 范数	270
38.3.3 ℓ_2 范数	270
38.3.4 逐点最大值	270
38.3.5 Hinge loss	270
38.4 次微分演算	271




38.5 次微分单调性	271
38.6 不可微凸优化的最优性条件	271
38.7 法锥与约束最优性	272
38.8 Fenchel Conjugate	272
38.9 常见共轭函数	273
38.9.1 平方范数	273
38.9.2 范数	273
38.9.3 示性函数	273
38.9.4 二次共轭	273
38.10 强凸性与共轭光滑性	273
38.11 Proximal Operator	274
38.12 Prox 的最优性条件	274
38.13 Prox 的 firm nonexpansiveness	275
38.14 Projection 是示性函数的 Prox	275
38.15 常见 Prox 闭式解	275
38.15.1 ℓ_1 Soft Thresholding	275
38.15.2 ℓ_2 范数	276
38.15.3 平方范数	276
38.16 复合最优点的 Proximal Fixed Point	276
38.17 Moreau Decomposition	276
38.18 Moreau Envelope	277
第三十九章 凸分析答题模板、映射与易错点	278
39.1 定义与结论速查	278
39.2 历年真题映射	279
39.3 课程训练材料对应	279
39.4 证明套路识别	280
39.5 综合易错点	280
39.6 快速自测	281
第四十章 梯度下降：非凸、凸与强凸情形	283
40.1 重要性等级与问题设定	283
40.2 为什么负梯度是最速下降方向	283
40.3 L -光滑目标的一步下降	284
40.4 非凸光滑情形：收敛到一阶驻点	284
40.4.1 复杂度中的 ε 必须说明含义	285
40.5 凸光滑情形：函数值 $O(1/K)$	286
40.6 强凸光滑情形：线性收敛	286




40.6.1 函数值形式	286
40.6.2 最优固定步长的迭代点收缩	287
40.7 步长过大的反例	287
第四十一章 投影梯度与约束光滑优化	289
41.1 问题设定与算法	289
41.2 投影梯度映射	289
41.3 最优性与 Fixed Point	289
41.4 投影梯度的核心三点不等式	290
41.5 函数值下降和 $O(1/K)$ 收敛率	291
41.6 强凸约束问题的距离收缩	291
41.7 每步计算复杂度	292
第四十二章 次梯度下降、一般步长与迭代平均	293
42.1 适用情形与算法	293
42.2 一步距离递推	293
42.3 一般步长与加权平均	294
42.4 一般凸非光滑目标的 $O(1/\sqrt{K})$ 率	294
42.4.1 不知道总迭代数时	295
42.5 强凸非光滑目标的加权 $O(1/K)$ 率	295
42.6 跨方向真题：随机投影次梯度的一步递推	296
第四十三章 近端梯度、复合势函数与 ISTA	298
43.1 复合优化问题	298
43.2 局部二次上界解释	298
43.3 复合梯度映射	299
43.4 近端梯度的核心三点不等式	299
43.5 函数值下降与梯度映射复杂度	300
43.6 凸复合目标的 $O(1/K)$ 收敛率	300
43.7 强凸复合目标的函数值线性收敛	300
43.8 强凸复合目标的距离收缩	301
43.9 ISTA: ℓ_1 正则最小二乘	301
43.10 未知 L 时的回溯步长	302
43.11 四种确定性一阶方法的统一关系	302
43.12 确定性收敛率总表	303
43.13 真题映射	303
43.14 答题方法	304
43.15 综合易错点	305
43.16 快速自测	306




第四十四章 随机一阶 Oracle、条件期望与方差分解	308
44.1 重要性等级与历年实考定位	308
44.2 随机优化问题	308
44.3 Filtration 与条件无偏性	309
44.3.1 为什么必须是条件无偏	309
44.4 向量方差分解	309
44.5 Tower Property	310
44.6 Mini-Batch 随机梯度的方差	310
44.7 Mini-Batch 的计算复杂度解释	311
第四十五章 SGD 在非凸、凸与强凸光滑情形下的收敛	312
45.1 非凸 L -Smooth 目标	312
45.1.1 Horizon-Dependent 步长	313
45.2 一般凸且光滑的 SGD	313
45.2.1 平衡确定性误差与随机误差	314
45.3 强凸光滑 SGD 与 Noise Floor	314
45.3.1 Noise Floor 的含义	315
45.3.2 Horizon-Tuned 步长消除常数误差层	315
45.4 期望收敛与高概率收敛	315
第四十六章 Proximal SGD、线性收缩与迭代平均	317
46.1 Composite Stochastic Optimization	317
46.2 一步非扩张不等式	317
46.3 条件期望与方差分解	318
46.4 Smooth-Strong Convex Contraction	318
46.5 递推展开与 Noise Floor	319
46.6 2025 Spring 复杂度结论	320
46.7 平均迭代误差的方差	320
46.8 递减步长与 $O(\log K/K)$ 平均函数值	321
第四十七章 有限和、多重采样与 Expected Smoothness	323
47.1 2025 Fall 真题问题设定	323
47.2 Importance Weight 为什么不能省	324
47.3 Expected Smoothness 的完整推导	324
47.4 Batch Size 的极端情形与单调性	326
47.5 Expected-Smoothness 最优 Importance Sampling	327
47.6 最优点处方差与 $1/\tau$ 缩放	328
47.6.1 Interpolation 条件	328
47.7 方差最优采样与 Smoothness 最优采样的区别	329




第四十八章 AC Inequality、闭式 Noise Floor 与真题统一解法	330
48.1 AC Inequality	330
48.2 Expected Smoothness 推出 AC Inequality	330
48.3 AC 条件下的 Proximal SGD 收敛	331
48.4 2025 Fall 的显式步长和 Noise Floor	332
48.4.1 三个互相耦合的设计量	332
48.5 历年真题完整映射	332
48.6 核心公式速查	333
48.7 综合易错点与失败模式	334
48.8 满分证明识别模板	336
48.9 快速自测	336
第四十九章 动量方法: Heavy-Ball 与 Nesterov 加速	338
49.1 重要性等级与实考定位	338
49.2 三种常见动量参数化	338
49.2.1 位置差分形式	338
49.2.2 梯度累积形式	338
49.2.3 物理速度形式	339
49.3 为什么动量能够缓解 Zig-Zag	339
49.4 Heavy-Ball 在二次型上的稳定性	340
49.5 Heavy-Ball 的最优二次型参数	340
49.6 Nesterov 动量与 Heavy-Ball 的本质区别	341
49.7 一般凸光滑情形的 Nesterov 加速	341
49.7.1 势函数证明	342
49.8 强凸光滑情形的 Nesterov 加速	343
49.9 随机 Nesterov 加速	344
49.10 Momentum 题的答题方法	345
第五十章 预条件方法与随机坐标下降	346
50.1 重要性等级	346
50.2 预条件梯度法的变量替换推导	346
50.3 预条件度量与下降条件	347
50.4 预条件如何改善条件数	347
50.4.1 Newton 方法	347
50.5 随机坐标下降的基本形式	348
50.6 坐标光滑性	349
50.7 非均匀坐标采样	349
50.8 一般凸情形的 $O(1/K)$ 收敛	350




50.9 强凸情形的线性收敛	350
50.10 坐标方法的实际复杂度	351
第五十一章 AdaGrad、RMSProp、Adam 与 AdamW	352
51.1 重要性等级与统一视角	352
51.2 AdaGrad	352
51.2.1 更新公式	352
51.2.2 为什么适合稀疏特征	353
51.2.3 AdaGrad 的可核查 regret 保证	353
51.2.4 AdaGrad 的失败模式	354
51.3 RMSProp	354
51.3.1 更新公式	354
51.3.2 RMSProp 的条件和局限	355
51.4 Adam	355
51.4.1 完整带 Bias Correction 的主约定	355
51.4.2 Bias Correction 的严格来源	356
51.4.3 Adam 的逐坐标有效步长	357
51.5 自适应归一化的一个严格反例	357
51.6 Adam 类方法的收敛假设模板	358
51.7 AdamW 与 ℓ_2 Regularization	358
51.7.1 普通 SGD 中的等价性	358
51.7.2 自适应预条件器中的不等价性	359
51.7.3 实际耦合比上述代数更强	359
51.8 自适应方法对比	359
51.9 自适应算法题的答题方法	360
第五十二章 优化方向复杂度总表、实考母题与易错点	361
52.1 确定性一阶方法复杂度总表	361
52.2 随机方法复杂度总表	362
52.3 三套博资考优化方向的统一母题	362
52.4 优化证明的统一识别图	363
52.5 优化方向高频易错点总表	363
52.6 优化方向的三选四评估	365
52.7 本部分快速自测	365
第四部分 自然语言处理	368
第五十三章 自然语言处理任务、语料单位与 Tokenization	369




53.1 重要性等级与考试定位	369
53.2 语言对象的层级	369
53.2.1 Word、Word Type、Word Instance 与 Token	370
53.3 NLP 任务的三种基本输入-输出结构	370
53.3.1 Sequence Classification	370
53.3.2 Sequence Labeling	371
53.3.3 Sequence-to-Sequence	371
53.3.4 任务形式对比	371
53.4 Tokenization 与 Normalization	372
53.4.1 为什么规则依赖任务	372
53.5 Byte-Pair Encoding	373
53.5.1 问题设定	373
53.5.2 相邻对频数	373
53.5.3 BPE 词表学习算法	373
53.5.4 测试时分词	374
53.5.5 BPE 的复杂度	374
53.5.6 词表大小的权衡	374
53.6 训练、验证、测试阶段的 Tokenizer 规范	375
53.7 快速自测	376
第五十四章 N-Gram 语言模型、平滑与 Perplexity	377
54.1 重要性等级与真题定位	377
54.2 语言模型的精确定义	377
54.3 N-Gram 的 Markov 假设	377
54.3.1 BOS 与 EOS 约定	378
54.4 基于计数的最大似然估计	378
54.4.1 MLE 的完整推导	378
54.5 为什么 Markov 假设不能省	379
54.6 Zero-Count Problem	379
54.7 Add- k Smoothing	379
54.8 Interpolation	380
54.9 Backoff	381
54.9.1 Stupid Backoff	381
54.10 Unseen Word、Unseen Context 与 $\langle \text{UNK} \rangle$	381
54.11 Perplexity	382
54.11.1 语料级 Perplexity	382
54.11.2 EOS 计数约定	382
54.11.3 Perplexity 的解释	382




54.11.4 Perplexity 的可比性条件	383
54.12 N-Gram 的训练与推理复杂度	383
54.13 基础例题	384
54.14 历年题型改写与满分模板	384
54.15 N-Gram 高频易错点	384
54.16 快速自测	385
第五十五章 文本分类、Naive Bayes 与评价指标	386
55.1 重要性等级	386
55.2 监督文本分类的数学设定	386
55.3 Multinomial Naive Bayes	386
55.3.1 生成过程与假设	386
55.3.2 Bayes 决策	387
55.3.3 参数估计	387
55.4 为什么 Naive Bayes 的条件不能省	387
55.4.1 Bag-of-Words 的代价	387
55.4.2 条件独立假设的代价	388
55.4.3 Zero Probability	388
55.5 训练与推理复杂度	388
55.6 分类评价指标	389
55.6.1 Macro 与 Micro	389
55.6.2 为什么 Accuracy 可能误导	389
55.7 Train、Development 与 Test	390
55.8 典型综合例题	390
55.9 答题方法	390
55.10 快速自测	391
第五十六章 序列标注、HMM 与 Linear-Chain CRF	392
56.1 重要性等级与资料边界	392
56.2 序列标注问题设定	392
56.3 BIO 标记	393
56.4 Hidden Markov Model	393
56.4.1 参数与维度	393
56.4.2 两个核心条件	393
56.4.3 为什么两个假设不能省	394
56.5 HMM 的监督 MLE	394
56.6 HMM Decoding	394
56.7 Viterbi Algorithm	395




56.7.1 复杂度	395
56.8 Forward Algorithm	395
56.9 HMM 的失败模式	396
56.10 Conditional Random Field	396
56.10.1 模型定义	396
56.10.2 Linear-Chain 条件	397
56.10.3 合法特征示例	397
56.11 CRF 的训练目标	398
56.11.1 梯度推导	398
56.11.2 凸性	398
56.12 CRF Partition Function 的 Forward Recurrence	398
56.13 CRF MAP Decoding	399
56.14 HMM 与 CRF 对比	399
56.15 为什么 CRF 不能省去 Partition Function	400
56.16 典型识别与使用方法	400
56.17 HMM/CRF 答题方法	401
56.18 综合易错点	401
56.19 本部分资料与真题映射	402
56.20 本部分综合快速自测	402
第五十七章 向量语义、Word2vec 与图表示学习	404
57.1 重要性等级与考试定位	404
57.2 统一记号与矩阵方向	404
57.3 Representation Learning 的精确定义	405
57.3.1 Representation Learning 不等于什么	405
57.4 Distributional Hypothesis 与向量语义	405
57.4.1 One-Hot 与 Distributional Vector	406
57.5 Cosine Similarity	406
57.5.1 为什么不用原始 Dot Product	406
57.6 TF-IDF	407
57.6.1 问题设定	407
57.6.2 Term Frequency	407
57.6.3 Inverse Document Frequency	407
57.6.4 TF-IDF 的 Inductive Bias	407
57.7 PMI 与 PPMI	408
57.7.1 概率定义	408
57.7.2 PMI 的低频偏置	408
57.8 Word2vec 的两个模型	409




57.9 Skip-Gram Full Softmax	409
57.9.1 训练样本构造	409
57.9.2 条件分布	410
57.9.3 单个 Pair 的梯度	410
57.10 Skip-Gram with Negative Sampling	410
57.10.1 Noise Distribution	410
57.10.2 Binary Classification Objective	410
57.10.3 完整梯度	411
57.10.4 梯度方向解释	411
57.11 CBOW	411
57.11.1 CBOW 与 Skip-Gram	412
57.12 SGNS 与 Shifted PMI	412
57.13 GloVe	413
57.13.1 数据与参数	413
57.13.2 为什么需要 Weighting Function	414
57.13.3 梯度	414
57.13.4 GloVe 与 SGNS	414
57.14 Embedding 的非唯一性	415
57.15 Node2Vec	415
57.15.1 资料边界	415
57.15.2 图与随机游走	415
57.15.3 Skip-Gram Objective	416
57.15.4 复杂度	416
57.15.5 Inductive Bias 与失败模式	416
57.16 TransE	417
57.16.1 问题设定	417
57.16.2 Negative Triple Construction	417
57.16.3 Margin-Ranking Loss	417
57.16.4 复杂度	418
57.16.5 失败模式	418
57.17 四类 Embedding 的真题标准答案	418
57.18 表示学习易错点	419
57.19 快速自测	419
第五十八章 RNN、LSTM、Encoder-Decoder 与 Attention	421
58.1 重要性等级与跨方向边界	421
58.2 Simple RNN 的问题设定	421
58.2.1 参数共享	422




58.3 RNN Language Model	422
58.3.1 Weight Tying	422
58.4 Backpropagation Through Time	422
58.5 梯度消失与梯度爆炸	423
58.5.1 Sigmoid/Tanh 饱和	423
58.6 RNN 的三类 NLP 用法	424
58.6.1 Sequence Labeling	424
58.6.2 Sequence Classification	424
58.6.3 Bidirectional RNN	424
58.7 LSTM	424
58.7.1 状态与维度	424
58.7.2 参数量	425
58.7.3 为何缓解梯度消失	425
58.7.4 门的作用	425
58.8 Encoder-Decoder	426
58.8.1 条件序列模型	426
58.8.2 训练目标	426
58.9 Teacher Forcing 与 Exposure Bias	426
58.10 RNN Encoder-Decoder Attention	427
58.10.1 Score	427
58.10.2 Attention Distribution	427
58.10.3 Dynamic Context	427
58.10.4 复杂度	428
58.11 RNN/LSTM 复杂度	428
58.12 RNN/LSTM 答题方法	429
58.13 快速自测	429
第五十九章 Transformer 的完整计算流程与 RNN 对比	430
59.1 重要性等级与真题定位	430
59.2 输入与主维度约定	430
59.3 Scaled Dot-Product Attention	431
59.3.1 Q、K、V	431
59.4 为什么除以 $\sqrt{d_k}$	431
59.4.1 Softmax 饱和	432
59.5 Mask	432
59.5.1 Causal Mask	432
59.5.2 Padding Mask	432
59.6 Self-Attention、Cross-Attention 与 Causal Attention	433




59.6.1 Self-Attention	433
59.6.2 Cross-Attention	433
59.6.3 Bidirectional 与 Causal	433
59.7 Multi-Head Attention	433
59.7.1 参数量	433
59.8 Positional Encoding	434
59.8.1 为什么需要位置特征	434
59.8.2 Learned Absolute Position	434
59.8.3 Sinusoidal Position	434
59.9 Transformer Block	435
59.10 Position-Wise Feed-Forward Network	435
59.11 Layer Normalization	435
59.12 Encoder、Decoder-Only 与 Encoder-Decoder	436
59.12.1 Transformer Encoder	436
59.12.2 Decoder-Only Transformer	436
59.12.3 Encoder-Decoder Transformer	436
59.13 Language Modeling Head	436
59.13.1 训练并行与推理串行	437
59.14 Transformer 时间复杂度	437
59.14.1 Q/K/V 与输出投影	437
59.14.2 Attention Score	437
59.14.3 Weighted Value Sum	437
59.14.4 FFN	437
59.14.5 空间复杂度	437
59.15 KV Cache	438
59.16 Transformer Block 参数量	438
59.17 RNN、LSTM 与 Transformer 比较	439
59.18 Transformer 相比 RNN 的真题答法	439
59.19 Self-Attention 真题满分模板	440
59.20 25F Scaling-Law 题的架构侧准备	440
59.21 Transformer 易错点	441
59.22 核心模型速查表	441
59.23 本部分真题与资料映射	442
59.24 综合快速自测	443
第六十章 自回归语言模型、预训练与解码	445
60.1 重要性等级与考试定位	445
60.2 统一记号	445




60.3 自回归条件分解	446
60.4 Maximum Likelihood 与 Cross-Entropy	446
60.4.1 带 Padding 的 Loss Mask	446
60.4.2 Logit Gradient	447
60.5 Teacher Forcing	447
60.5.1 Teacher Forcing 的优势	447
60.5.2 Exposure Bias	447
60.6 训练并行与生成串行	448
60.7 Perplexity	448
60.7.1 解释	448
60.7.2 与 Likelihood 的关系	448
60.7.3 Perplexity 的边界	449
60.8 Causal Language Model Pretraining	449
60.8.1 Document Packing	449
60.8.2 Data Mixture	449
60.8.3 数据处理	450
60.9 继续预训练与领域自适应	450
60.10 序列级 Decoding Objective	450
60.11 Greedy Decoding	451
60.12 Beam Search	451
60.12.1 长度偏置	451
60.12.2 Beam Search 的适用场景	452
60.13 Random Sampling	452
60.14 Temperature Sampling	452
60.15 Top- k Sampling	453
60.16 Top- p / Nucleus Sampling	453
60.16.1 尖锐分布	454
60.16.2 平坦分布	454
60.17 Temperature 与 Top- p 的组合	454
60.18 为什么开放式 LLM 生成通常使用 Top- p	454
60.19 其他常见 Decoding Controls	455
60.19.1 Minimum Length	455
60.19.2 Maximum Length	455
60.19.3 Repetition Penalty	455
60.19.4 No-Repeat n -Gram	455
60.20 Decoding 方法对比	455




61.1 Causal LM 与 Masked LM	457
61.2 Bidirectional Self-Attention	457
61.3 Masked Language Modeling	457
61.3.1 BERT 的经典 Corruption 比例	458
61.3.2 为什么不能直接预测未 Mask 的 Token	458
61.3.3 MLM Logit Gradient	458
61.4 Next Sentence Prediction	458
61.5 Contextual Embedding	459
61.5.1 Layer Aggregation	459
61.6 下游 Fine-Tuning	459
61.6.1 Sequence Classification	459
61.6.2 Token Classification	459
61.6.3 Full Fine-Tuning	460
61.6.4 Feature Extraction	460
61.7 Instruction Tuning / SFT	460
61.7.1 Prompt Mask	460
61.7.2 SFT 的本质	460
61.8 Parameter-Efficient Fine-Tuning 与 LoRA	461
61.9 Prompting 与 In-Context Learning	461
61.10 当前 LLM 路线取得成功的关键因素	462
61.11 经验 Scaling Law	462
61.12 双变量参数-数据缩放	463
61.12.1 固定数据	463
61.12.2 固定参数	464
61.13 从统计学习理论解释 Data Scaling	464
61.13.1 Population Risk 与 Empirical Risk	464
61.13.2 Risk Decomposition	464
61.13.3 Rademacher Complexity Bound	465
61.13.4 为什么出现 Power-Law-Like 行为	465
61.14 Compute-Optimal Joint Scaling	466
61.15 LSTM 与 Transformer 的 Scaling 比较	467
第六十二章 Reward Model、RLHF、PPO 与 DPO	468
62.1 对齐问题	468
62.2 Preference Data	468
62.3 Reward Model	469
62.4 Bradley-Terry Preference Model	469
62.4.1 Reward Gradient	469




62.4.2 Reward 的不可辨识性	469
62.5 KL-Regularized RLHF Objective	470
62.5.1 KL Regularization 的作用	470
62.6 Sequence-Level Policy Gradient	470
62.6.1 Baseline	471
62.7 Token-Level Factorization	471
62.8 Actor-Critic	471
62.9 Generalized Advantage Estimation	472
62.10 PPO Ratio	472
62.10.1 Clipping 的分段含义	472
62.10.2 常见 PPO 总目标	472
62.11 Reward-Model-Based RLHF 流程	473
62.12 RLHF 的主要失败模式	473
62.13 DPO 的基本推导	474
62.14 DPO Loss	474
62.14.1 DPO Gradient	474
62.14.2 Sequence Log-Probability	475
62.15 DPO 与 RLHF 的区别	475
62.16 SFT、RM、PPO 与 DPO 的目标区分	475
62.17 RLHF/DPO 真题模板	475
第六十三章 长序列 Transformer 与监督主题模型	477
63.1 标准 Self-Attention 的二次瓶颈	477
63.2 Attention Graph	477
63.3 方案一: Sliding Window + Global Tokens	477
63.3.1 复杂度	478
63.3.2 长距离可表达性	478
63.3.3 Causal 注意事项	478
63.4 方案二: Block-Sparse Attention	479
63.4.1 Connectivity	479
63.5 方案三: Linear Attention	479
63.5.1 复杂度	480
63.5.2 Causal Prefix Recurrence	480
63.5.3 局限	480
63.6 方案四: Recurrent Memory	481
63.6.1 复杂度	481
63.6.2 长距离传播	481
63.7 长序列方案比较	481




63.8 长序列真题推荐答案	482
63.9 LDA 基础模型	482
63.10 Unsupervised LDA Joint Probability	483
63.11 监督主题模型	483
63.12 Logistic Label Model	483
63.13 监督主题模型的 Sampling Process	483
63.14 监督主题模型的完整联合概率	484
63.15 为什么加入 Label 会改变 Learned Topics	484
63.15.1 Vanilla LDA 的一个失败模式	484
63.16 Label Model Gradient	485
63.17 Collapsed Gibbs 条件分布	485
63.18 Variational Inference	485
63.19 监督主题模型的失败模式	486
63.20 监督主题模型真题模板	487
63.21 本部分真题与资料映射	487
63.22 综合易错点	488
63.23 综合快速自测	489
第六十四章 文本、图与知识图谱的嵌入模型	491
64.1 重要性等级与考试定位	491
64.2 统一设定	491
64.3 GloVe: 全局共现的加权回归	491
64.3.1 为什么需要权重函数	492
64.3.2 数据、目标与归纳偏置	492
64.3.3 复杂度	492
64.3.4 失败模式	492
64.4 Skip-gram with Negative Sampling	493
64.4.1 局部窗口训练对	493
64.4.2 SGNS 目标	493
64.4.3 数据、目标与归纳偏置	493
64.4.4 复杂度	494
64.5 Node2Vec: 随机游走生成图上下文	494
64.5.1 参数含义	494
64.5.2 数据、目标与归纳偏置	494
64.5.3 复杂度	495
64.5.4 失败模式	495
64.6 TransE: 关系作为向量平移	495
64.6.1 数据、目标与归纳偏置	496



64.6.2 失败模式	496
64.7 四种 Embedding 的统一比较	496
第六十五章 信息检索、RAG 与对话外部记忆	498
65.1 重要性等级与考试定位	498
65.2 检索问题的形式化	498
65.3 离线文档处理与 Chunking	498
65.3.1 Chunk 太短	499
65.3.2 Chunk 太长	499
65.4 Sparse Retrieval 与 BM25	499
65.4.1 Sparse Retrieval 的优势与局限	500
65.5 Dense Retrieval 与 Bi-Encoder	500
65.5.1 Contrastive Retriever Loss	500
65.5.2 Negative Sampling	500
65.6 Approximate Nearest Neighbor Search	501
65.7 Cross-Encoder Reranker	501
65.8 Hybrid Retrieval	501
65.8.1 为什么需要 Hybrid	502
65.9 Query Rewriting 与 Multi-Hop Retrieval	502
65.10 Context Construction	502
65.11 RAG 的概率形式	503
65.12 无 QA 标注条件下的领域 RAG 系统	503
65.13 检索召回与最终正确率	504
65.14 对话外部记忆	505
65.14.1 Memory 类型	506
65.14.2 Memory 操作	506
65.15 Memory Gain 的精确分解	506
65.15.1 边界情形	507
65.16 将 Memory Management 建模为 MDP	507
65.16.1 State	507
65.16.2 Action	508
65.16.3 Transition	508
65.16.4 Reward	508
65.16.5 优化目标	509
65.17 RAG 与 Memory 的失败模式	509
第六十六章 Markov Logic Network、全局信息抽取与 Topic-Ontology LDA	511
66.1 重要性等级与考试定位	511



66.2 Markov Network	511
66.3 MLN 的定义	511
66.3.1 Ground Network	512
66.3.2 Weight 符号	512
66.4 Conditional MLN 与 MAP	512
66.4.1 参数学习梯度	513
66.5 2025 Fall MLN 题的严格分析	513
66.5.1 Ground Network	513
66.5.2 指定 World 的 True-Grounding Count	513
66.5.3 改变 Weight 的影响	514
66.5.4 MAP 枚举	514
66.6 全局 Entity Linking 与 Relation Extraction	515
66.6.1 未知变量和 Evidence	515
66.6.2 Candidate Gating	515
66.6.3 Local Entity-Link Evidence	515
66.6.4 Relation Evidence Propagation	515
66.6.5 At-Most-One Constraint	515
66.6.6 Relation Type Consistency	516
66.7 HighLink 与 HighRel 的上游模型	516
66.7.1 Entity Linking Model	516
66.7.2 Relation Extraction Model	516
66.8 Same-Era Constraint	517
66.8.1 最小例子	517
66.9 Topic-Ontology LDA for Fact Triples	518
66.9.1 全局分布	518
66.9.2 文档级和 Triple 级生成过程	519
66.10 完整联合概率	519
66.11 类型兼容性的可选扩展	520
66.12 Latent Category 自动命名	520
66.12.1 Entity Type Naming	521
66.12.2 Relation Type Naming	521
66.12.3 生成式命名的安全流程	521
第六十七章 NLP 评价、真题总览与全书答题闭环	523
67.1 分类与抽取评价	523
67.1.1 Micro 与 Macro	523
67.2 排序检索评价	524
67.2.1 Precision@K 与 Recall@K	524



67.2.2 Average Precision 与 MAP	524
67.2.3 MRR	524
67.3 QA 评价	524
67.3.1 Exact Match	524
67.3.2 Token F1	525
67.4 BLEU	525
67.5 ROUGE	525
67.6 Perplexity 与 WER	526
67.7 RAG 的分层评价	526
67.7.1 Retriever	526
67.7.2 Reranker	526
67.7.3 Answer	526
67.7.4 Faithfulness	526
67.7.5 Memory	527
67.8 NLP 系统设计题的固定答题模板	527
67.9 三套博资考 NLP 方向完整映射	528
67.10 NLP 方向的可迁移母题	529
67.10.1 母题一：概率模型	529
67.10.2 母题二：对比学习	529
67.10.3 母题三：全局一致性	529
67.10.4 母题四：端到端系统	530
67.10.5 母题五：长期决策	530





第一部分

机器学习理论

第一章 统计学习问题的形式化、风险与经验风险

1.1 重要性等级与考情定位

重要性等级：S

- 明确列入机器学习理论核心考纲，是 PAC、VC、一致收敛、稳定性和模型选择的共同起点；
- 固定假设经验损失的方差在 [25S-A-Q1, 7 分] 与 [26S-A-Q1, 6 分] 两套博资考中直接出现；
- 同一母题出现在 [MLT-Final-Q1, 10 分, 课程期末题]，经验风险期望出现在 [MLT-HW1-Q2, 15 分, 课程作业]；
- 本章的核心失分点不是计算本身，而是没有声明“ h 固定”、没有写清随机性来自样本、或把总体风险与经验风险混为一谈。

1.2 精确定义与问题设定

定义 1.1 (统计学习问题). 设输入空间为可测空间 $\mathcal{X}$ ，输出空间为 $\mathcal{Y}$ ，样本空间为 $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ 。未知数据分布为 P ，随机样本 $Z = (X, Y) \sim P$ ， $S = (Z_1, \dots, Z_m) \sim P^m$ 。假设类 $\mathcal{H}$ 是从 $\mathcal{X}$ 到预测空间的函数集合，损失函数

$$\ell : \mathcal{H} \times \mathcal{Z} \longrightarrow \mathbb{R}_+ \quad (1.1)$$

衡量假设 h 在样本 $z = (x, y)$ 上的误差。学习算法是从样本到假设的映射 $A : S \mapsto A(S)$ 。

定义 1.2 (总体风险与经验风险). 对固定 $h \in \mathcal{H}$ ，总体风险 (population risk) 与经验风险 (empirical risk) 分别定义为

$$L_P(h) := \mathbb{E}_{Z \sim P} [\ell(h, Z)], \quad (1.2)$$

$$\hat{L}_S(h) := \frac{1}{m} \sum_{i=1}^m \ell(h, Z_i). \quad (1.3)$$

若为可实现二分类， $Y = f(X)$ ， $h, f : \mathcal{X} \rightarrow \{0, 1\}$ ，并采用零一损失，则

$$L_{D,f}(h) = \Pr_{X \sim D} (h(X) \neq f(X)), \quad (1.4)$$

$$\hat{L}_{S,f}(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}\{h(X_i) \neq f(X_i)\}. \quad (1.5)$$



维度与随机性检查。 $\ell(h, Z_i)$ 是标量； $\widehat{L}_S(h)$ 是 m 个标量的平均。对固定 h ，其随机性只来自 S 。若写成 $\widehat{h} = A(S)$ ，则 $\widehat{h}$ 本身也依赖 S ，此时不能把固定假设的无偏性或方差公式直接套到 $\widehat{h}$ 上。

1.3 核心结论、条件与复杂度

命题 1.3 (固定假设经验风险的无偏性). 若 $Z_1, \dots, Z_m$ 同分布于 P ，且 $\mathbb{E}|\ell(h, Z)| < \infty$ ，则对任意固定 $h \in \mathcal{H}$ ，

$$\mathbb{E}_S[\widehat{L}_S(h)] = L_P(h). \quad (1.6)$$

该结论只需同分布和期望存在；计算期望时不需要样本之间独立。

定理 1.4 (固定二分类假设经验损失的精确方差). 设 $X_1, \dots, X_m \stackrel{\text{i.i.d.}}{\sim} D$ ， $Y_i = f(X_i)$ ，固定 $h \in \mathcal{H}$ ，并令 $p := L_{D,f}(h) = \Pr(h(X) \neq f(X))$ 。则

$$\text{Var}_S[\widehat{L}_{S,f}(h)] = \frac{p(1-p)}{m} \leq \frac{1}{4m}. \quad (1.7)$$

由于无偏，均方误差也满足

$$\mathbb{E}_S[(\widehat{L}_{S,f}(h) - p)^2] = \frac{p(1-p)}{m}. \quad (1.8)$$

计算复杂度。 若单个样本上计算 $h(x)$ 和损失的代价为 $C_h + C_\ell$ ，则直接计算经验风险的时间复杂度为 $O(m(C_h + C_\ell))$ 。流式累计只需 $O(1)$ 额外空间；若必须保存全部预测或逐样本损失，则额外空间为 $O(m)$ 。

1.4 为什么条件不能省

1. **固定 h 不能省。** 对数据依赖的 $\widehat{h} = A(S)$ ，训练误差通常向下偏。例如足够丰富的假设类可令 $\widehat{L}_S(\widehat{h}) = 0$ ，但 $L_P(\widehat{h})$ 仍可能很大。

2. **独立性决定 $1/m$ 方差缩减。** 若 $U_i = \ell(h, Z_i)$ 相关，则

$$\text{Var}\left(\frac{1}{m} \sum_{i=1}^m U_i\right) = \frac{1}{m^2} \sum_{i=1}^m \text{Var}(U_i) + \frac{2}{m^2} \sum_{i < j} \text{Cov}(U_i, U_j). \quad (1.9)$$

正协方差可能使有效样本量远小于 m 。

3. **同分布决定共同的 p 。** 独立但非同分布时，令 $p_i = \Pr(h(X_i) \neq f(X_i))$ ，则

$$\mathbb{E}\widehat{L}_S(h) = \frac{1}{m} \sum_i p_i, \quad \text{Var}(\widehat{L}_S(h)) = \frac{1}{m^2} \sum_i p_i(1-p_i),$$

一般不能写成单个 $p(1-p)/m$ ，除非所有 p_i 相同。

4. **有界性不是无偏性的必要条件，但对 Hoeffding 等高概率界至关重要。** 若损失重尾且方差不存在，样本均值仍可能有期望，却没有本章的方差公式或后续的指数集中界。



1.5 证明或推导要求

结果	资格考试要求
固定假设经验风险无偏	必须会完整推导，至少写出线性期望与同分布。
零一损失精确方差 $p(1-p)/m$	必须会完整证明，并说明交叉协方差为何为零。
上界 $1/(4m)$	必须会由 $p(1-p) = \frac{1}{4} - (p - \frac{1}{2})^2 \leq \frac{1}{4}$ 得出。
相关样本方差	必须掌握框架，用于解释非 i.i.d. 或时间序列失效。
一般损失的方差	只需会使用：若方差为 σ_h^2 ，则独立同分布下为 σ_h^2/m 。

1.6 完整证明与算法分析

命题 1.3 的证明. 由经验风险定义和期望的线性性，

$$\begin{aligned}
 \mathbb{E}_S[\widehat{L}_S(h)] &= \mathbb{E}_S \left[\frac{1}{m} \sum_{i=1}^m \ell(h, Z_i) \right] \\
 &= \frac{1}{m} \sum_{i=1}^m \mathbb{E}_{Z_i}[\ell(h, Z_i)] \\
 &= \frac{1}{m} \sum_{i=1}^m L_P(h) \\
 &= L_P(h).
 \end{aligned}$$

第二行只使用期望线性性；第三行使用 Z_i 与 Z 同分布。这里没有把 h 写成 $A(S)$ ，因此不存在算法选择带来的依赖。 $\square$

定理 1.4 的证明. 定义指标随机变量

$$U_i := \mathbf{1}\{h(X_i) \neq f(X_i)\}, \quad i = 1, \dots, m. \quad (1.10)$$

由于 h 固定且 $X_i \stackrel{\text{i.i.d.}}{\sim} D$ ，有 $U_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$ 。于是 $\mathbb{E}[U_i] = p$ ， $\text{Var}(U_i) = p(1-p)$ 。经验损失为 $\widehat{L}_{S,f}(h) = m^{-1} \sum_i U_i$ 。因此

$$\begin{aligned}
 \text{Var}(\widehat{L}_{S,f}(h)) &= \text{Var} \left(\frac{1}{m} \sum_{i=1}^m U_i \right) \\
 &= \frac{1}{m^2} \left(\sum_{i=1}^m \text{Var}(U_i) + 2 \sum_{i < j} \text{Cov}(U_i, U_j) \right) \\
 &= \frac{1}{m^2} \sum_{i=1}^m p(1-p) \\
 &= \frac{p(1-p)}{m}.
 \end{aligned}$$



第三行使用独立性, 故 $\text{Cov}(U_i, U_j) = 0$ 。又因 $p(1-p) = \frac{1}{4} - (p - \frac{1}{2})^2 \leq \frac{1}{4}$, 得到方差上界。最后, 由命题 1.3, $\mathbb{E}\hat{L}_{S,f}(h) = p$, 故均方误差等于方差, 得到式 (1.8)。□

证明或推导框架

识别信号: “固定某个 h ” “经验误差的期望/方差” “随样本量如何变化”。

构造步骤:

1. 把每个样本是否出错写成 Bernoulli 指标 U_i ;
2. 写 $\hat{L} = m^{-1} \sum_i U_i$;
3. 期望用线性性, 方差用“方差和 + 协方差和”;
4. 用独立性消去协方差;
5. 若题目要求最坏上界, 再用 $p(1-p) \leq 1/4$ 。

常见失败原因: 直接写“独立同分布所以结论成立”而没有展开; 把 $\text{Var}(m^{-1} \sum U_i)$ 错写成 $m^{-1} \sum \text{Var}(U_i)$; 忘记平均中的 m^{-2} 。

1.7 标准识别与使用方法

- 看到“固定假设” “经验风险的均值/方差”, 立即引入逐样本损失 U_i ;
- 看到“数据依赖的 ERM 输出”, 立即警惕: 固定 h 的点态结论不能直接用于 $\hat{h}(S)$, 需要一致收敛、稳定性或其他算法依赖分析;
- 看到“独立但非同分布”, 把共同风险 p 改为 p_i 或平均分布风险;
- 看到“时间序列、强化学习轨迹、同一用户多轮数据”, 先检查协方差或 mixing 条件, 而不是机械写 $1/m$;
- 看到“高概率偏差”, 本章的方差只是起点: 有界损失优先考虑 Hoeffding, 有限类再接 union bound。

1.8 典型题型

例 1.5 (基础例题: 数值方差). 若固定分类器的总体错误率为 $p = 0.2$, 样本量 $m = 100$, 则 $\text{Var}(\hat{L}) = \frac{0.2 \times 0.8}{100} = 0.0016$, $\text{sd}(\hat{L}) = 0.04$ 。这里标准差按 $m^{-1/2}$ 缩减, 方差按 m^{-1} 缩减。

例 1.6 (综合例题: 等相关样本). 设 U_i 均为 $\text{Bernoulli}(p)$, 且对 $i \neq j$, $\text{Corr}(U_i, U_j) = \rho$ 。则

$$\begin{aligned} \text{Var}(\hat{L}) &= \frac{p(1-p)}{m^2} [m + m(m-1)\rho] \\ &= p(1-p) \left(\frac{1-\rho}{m} + \rho \right). \end{aligned}$$

若 $\rho > 0$ 固定, $m \rightarrow \infty$ 时方差不趋于零。这说明“样本数多”不能替代独立性或有效样本量分析。

例 1.7 (历年题型改写). [25S-A-Q1, 7 分] 要求证明精确方差; [26S-A-Q1(a), 3 分左右] 使用均方误差写法, [26S-A-Q1(b), 3 分左右] 再要求推出 $O(1/m)$ 。满分答案必须依次写指标变量、Bernoulli 方差、独立协方差为零、无偏性及 $p(1-p) \leq 1/4$ 。

例 1.8 (课程训练题型, 不是博资考真题). [MLT-HW1-Q2, 15 分, 课程作业] 只要求证明 $\mathbb{E}\hat{L} = L$; [MLT-Final-Q1, 10 分, 课程期末题] 进一步要求精确方差。两者共同构成本章的“期望—方差”训练链, 但其出现次数不得计入博资考频率。

1.9 答题方法

答题方法

对“固定分类器经验损失方差”题, 建议按以下顺序书写:

1. 写 $p = L_{D,f}(h)$, 明确 h 固定, 随机性来自 $S \sim D^m$;
2. 定义 $U_i = \mathbf{1}\{h(X_i) \neq f(X_i)\}$, 说明 $U_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$;
3. 写 $\hat{L} = m^{-1} \sum_i U_i$;
4. 展开方差, 显式写出协方差项并由独立性置零;
5. 得到 $p(1-p)/m$; 若题目是均方误差, 再先证明无偏;
6. 用 $p(1-p) \leq 1/4$ 得到最坏上界和 $O(1/m)$;
7. 结尾用一句话解释: 方差按 m^{-1} , 标准差按 $m^{-1/2}$ 缩减。

省略第 1、2 或 4 步通常会失去“假设完整”和“推理充分”的分数。

1.10 易错点、反例与失败模式

易错点、反例与失败模式

1. **错误:** $\mathbb{E}[\hat{L}_S(A(S))] = L_P(A(S))$ 。 **错因:** $A(S)$ 与 S 相关, 右侧也是随机量。 **改法:** 固定 h , 或转用一致收敛/稳定性分析。
2. **错误:** 经验风险方差是 $p(1-p)/\sqrt{m}$ 。 **改法:** 方差是 $1/m$, 标准差才是 $1/\sqrt{m}$ 。
3. **错误:** 线性期望需要独立。 **改法:** 期望线性性不要求独立; 方差相加才需要协方差为零。
4. **错误:** 训练误差低说明总体风险低。 **反例:** 记忆训练集的假设可有零训练误差, 但在未见样本上接近随机或系统性错误。
5. **错误:** 独立非同分布时仍使用共同 p 。 **改法:** 写 p_i , 并说明研究对象是平均风险还是某个目标分布风险。

1.11 真题与训练材料对应

- 博资考: [25S-A-Q1, 7 分]; [26S-A-Q1(a), 3 分]; [26S-A-Q1(b), 3 分]。
- 课程材料: [MLT-Final-Q1, 10 分, 课程期末题]; [MLT-HW1-Q2, 15 分, 课程作业]。
- 跨方向前置: [25S-C-Q4, 6 分] 与 [26S-C-Q7, 5 分] 的条件期望/方差分解使用同一“随机性来源必须写清”的规范。



1.12 快速自测

快速自测

1. 为什么 $\mathbb{E}\hat{L}_S(h) = L_P(h)$ 不需要独立, 而 $\text{Var}(\hat{L}_S(h)) = \sigma^2/m$ 需要?
2. 若 $h = A(S)$, 固定假设的无偏性还可否直接使用? 请给出一句反例理由。
3. 独立但非同分布时, 经验零一损失的期望和方差分别是什么?
4. 方差为 $O(1/m)$ 与估计误差高概率为 $O(1/\sqrt{m})$ 是否矛盾? 为什么?



第二章 经验风险最小化、归纳偏置、过拟合与 No Free Lunch

2.1 重要性等级与考情定位

重要性等级：S

- ERM、归纳偏置和过拟合是 PAC、VC、稳定性、正则化与模型选择的共同逻辑起点；
- No Free Lunch 在 [25F-A-MQ2, 0.5 分] 与 [26S-A-MQ5, 0.5 分] 直接作为概念题出现，ERM 在两套试卷的热身题中直接出现；
- [MLT-HW1-Q4, 15 分, 课程作业] 训练了 No Free Lunch 中“期望下界如何转为高概率失败”的关键一步；
- 本章是概念简答、证明题开场和所有泛化界的解释框架。考试中只写“复杂模型会过拟合”远远不够，必须区分近似误差、估计误差和优化误差。

2.2 精确定义与问题设定

定义 2.1 (经验风险最小化). 给定假设类 $\mathcal{H}$ 、样本 $S = (Z_1, \dots, Z_m)$ 和经验风险 $\hat{L}_S$ ，经验风险最小化 (empirical risk minimization, ERM) 规则返回

$$\hat{h}_{\text{ERM}} \in \arg \min_{h \in \mathcal{H}} \hat{L}_S(h). \quad (2.1)$$

若算法只找到近似最优解 $\tilde{h}$ ，定义其经验优化误差为

$$\Delta_{\text{opt}}(S) := \hat{L}_S(\tilde{h}) - \inf_{h \in \mathcal{H}} \hat{L}_S(h) \geq 0. \quad (2.2)$$

定义 2.2 (归纳偏置). 归纳偏置 (inductive bias) 是学习算法在观察当前训练样本之前，对可选预测规则施加的限制或偏好。选择假设类 $\mathcal{H}$ 、正则项、架构、核函数、数据增强或优化器隐含偏好，均可构成归纳偏置。为避免数据泄漏，用于理论保证的假设类或选择规则必须在测试数据之外确定。

定义 2.3 (过拟合与欠拟合). 设学习输出为 $\hat{h} = A(S)$ 。

- 当 $\hat{L}_S(\hat{h})$ 很小而 $L_P(\hat{h})$ 明显较大时，称发生过拟合 (overfitting)；
- 当假设类表达能力不足，连训练数据的主要结构也不能拟合，导致训练风险和总体风险均较大时，称为欠拟合 (underfitting)。

二者不是由某个固定阈值定义，而是通过训练、验证和测试表现及误差分解诊断。

定义 2.4 (三类误差). 令 $L^* := \inf_{h \in \mathcal{G}} L_P(h)$, $L_{\mathcal{H}}^* := \inf_{h \in \mathcal{H}} L_P(h)$, 其中 $\mathcal{G}$ 是允许比较的更大预测器集合, 通常可取所有可测预测器或给定模型族的闭包。对算法输出 $\tilde{h}$, 定义

$$\mathcal{E}_{\text{app}}(\mathcal{H}) := L_{\mathcal{H}}^* - L^*, \quad \text{近似误差 (approximation error)}, \quad (2.3)$$

$$\mathcal{E}_{\text{est}}(S) := L_P(\hat{h}_{\text{ERM}}) - L_{\mathcal{H}}^*, \quad \text{估计误差 (estimation error)}, \quad (2.4)$$

$$\mathcal{E}_{\text{opt}}(S) := L_P(\tilde{h}) - L_P(\hat{h}_{\text{ERM}}), \quad \text{总体风险意义下的优化误差。} \quad (2.5)$$

式 (2.5) 可能为负, 因为不同经验近似解的总体风险排序未必与经验风险排序一致。资格考试中更稳妥的做法是使用式 (2.2) 的经验优化差, 并通过一致偏差把它传递到总体风险。

2.3 核心定理、模型关系与适用范围

定理 2.5 (近似 ERM 的统一误差分解). 对任意样本 S 和任意 $\tilde{h} \in \mathcal{H}$, 若式 (2.2) 有限, 则

$$L_P(\tilde{h}) - L^* \leq \underbrace{L_{\mathcal{H}}^* - L^*}_{\mathcal{E}_{\text{app}}} + \underbrace{2 \sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)|}_{\text{统一估计偏差}} + \underbrace{\Delta_{\text{opt}}(S)}_{\text{经验优化误差}}. \quad (2.6)$$

该式逐样本成立, 不需要最优解实际达到; 使用下确界即可。

定理 2.6 (No Free Lunch 的有限域版本). 设 $\mathcal{X}$ 至少包含 $2m$ 个不同点。对任意接收 m 个二分类样本的学习算法 A , 存在一个分布 P 和一个确定性标记函数 $f: \mathcal{X} \rightarrow \{0, 1\}$, 使得 $L_P(f) = 0$, 但

$$\mathbb{E}_{S \sim P^m} [L_P(A(S))] \geq \frac{1}{4}. \quad (2.7)$$

并且存在同一任务满足

$$\Pr_{S \sim P^m} \left(L_P(A(S)) \geq \frac{1}{8} \right) \geq \frac{1}{7}. \quad (2.8)$$

因此, 不施加任务结构或先验限制时, 不存在对所有数据生成任务都优越的学习算法。

说明 2.7 (逆命题与边界). No Free Lunch 只说明“无任何归纳偏置时不能普适学习”, 不说明某个具体任务不可学习, 也不说明所有算法在每个任务上表现相同。加入有限 VC 维、间隔、平滑性、稀疏性、核结构或其他先验后, 完全可能获得非平凡保证。

复杂度。 若 $\mathcal{H}$ 有限且可逐个评估, 朴素 ERM 的时间为 $O(|\mathcal{H}|mC_\ell)$, 空间可为 $O(1)$ 加当前候选状态; 但“统计上可学习”并不推出“ERM 可高效计算”。第 三 章将明确区分样本复杂度与计算复杂度。

2.4 为什么条件和设计不能省

1. **不能只最小化训练误差而不限搜索空间。** 若 $\mathcal{H}$ 包含所有“记忆训练点、其余点预测 0”的函数, 则训练误差可恒为零, 而总体误差可保持常数级。
2. **假设类不能在看过测试集后确定。** 若反复依据测试误差选择模型, 测试集已参与模型选择, 最终报告不再是对独立泛化性能的无偏评估。
3. **类越小并非一定越好。** 缩小 $\mathcal{H}$ 通常降低估计误差, 却可能增加近似误差; 这正是偏置-复杂度权衡, 而非单调改进。
4. **优化到更低训练损失不保证更低总体损失。** 式 (2.6) 表明, 优化误差只是三项之一。若统一估计偏差很大, 继续压低训练损失可能扩大过拟合。

5. **No Free Lunch** 的分布量词不能删。它是“对任意算法，存在一个困难任务”，不是“存在一个任务使所有算法都失败”，更不是“任意任务上所有算法等价”。

2.5 证明或推导要求

内容	资格考试要求
ERM 与归纳偏置定义	必须精确写出目标、假设类和数据依赖。
式 (2.6)	必须掌握完整三行推导，可迁移到正则化和深度学习。
No Free Lunch	必须掌握随机标记、未见点、平均论证和期望转概率四步框架。
平方损失 bias-variance 分解	必须会完整展开，并说明噪声均值为零的条件。
训练/验证/测试职责	必须会解释数据泄漏与嵌套选择。

2.6 证明、推导与算法分析

定理 2.5. 由加减经验风险和两个下确界，

$$\begin{aligned}
 L_P(\tilde{h}) - L^* &= [L_P(\tilde{h}) - \hat{L}_S(\tilde{h})] + [\hat{L}_S(\tilde{h}) - \inf_{h \in \mathcal{H}} \hat{L}_S(h)] \\
 &\quad + [\inf_{h \in \mathcal{H}} \hat{L}_S(h) - \inf_{h \in \mathcal{H}} L_P(h)] + [L_{\mathcal{H}}^* - L^*].
 \end{aligned}$$

第一项不超过 $\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)|$ ；第二项等于 $\Delta_{\text{opt}}(S)$ 。对第三项，利用一般不等式 $\inf_{h \in \mathcal{H}} a_h - \inf_{h \in \mathcal{H}} b_h \leq \sup_{h \in \mathcal{H}} (a_h - b_h)$ ，得到其也不超过统一偏差。合并即得式 (2.6)。□

定理 2.6. 从 $\mathcal{X}$ 中选取 $C = \{c_1, \dots, c_{2m}\}$ ，令输入分布在 C 上均匀。先把标记函数 $F : C \rightarrow \{0, 1\}$ 作为随机变量：对每个 c_j 独立均匀抽取 $F(c_j)$ 。

固定一个训练样本的输入序列和相应标签。样本至多包含 m 个不同输入，因此至少有 m 个点未被观察。对任一未见点 c ，在给定整个训练样本后， $F(c)$ 仍是独立均匀的 Bernoulli 随机变量；而 $A(S)(c)$ 已由样本和算法内部随机性决定。因此 $\Pr_F(A(S)(c) \neq F(c) \mid S) = \frac{1}{2}$ 。未见点在输入分布下的总质量至少为 $m/(2m) = 1/2$ ，故条件期望风险至少为 $\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$ 。再对训练输入和算法随机性取期望，得 $\mathbb{E}_F \mathbb{E}_{S \sim P_F^m} L_{P_F}(A(S)) \geq \frac{1}{4}$ 。有限个标记函数的平均至少为 $1/4$ ，所以存在某个确定的 f 使式 (2.7) 成立；相应分布由均匀输入和确定性标签 $Y = f(X)$ 构成，因此任务可实现且 $L_P(f) = 0$ 。

令 $Z = L_P(A(S)) \in [0, 1]$ 。由 $\mathbb{E}Z \leq \frac{1}{8} \Pr(Z < 1/8) + 1 \cdot \Pr(Z \geq 1/8) \leq \frac{1}{8} + \frac{7}{8} \Pr(Z \geq 1/8)$ ，以及 $\mathbb{E}Z \geq 1/4$ ，得到 $\Pr(Z \geq 1/8) \geq \frac{1/4 - 1/8}{7/8} = \frac{1}{7}$ 。这就是式 (2.8)。□

根据附件结论所作的推导补充

平方损失下的 bias–variance–noise 分解。 设 $f^*(x) = \mathbb{E}[Y | X = x]$, 写 $Y = f^*(x) + \varepsilon$, 其中 $\mathbb{E}[\varepsilon | X = x] = 0$, $\text{Var}(\varepsilon | X = x) = \sigma^2(x)$ 。对由训练集产生的随机预测 $\hat{f}_S(x)$, 令 $\bar{f}(x) = \mathbb{E}_S \hat{f}_S(x)$ 。则

$$\mathbb{E}_{S,Y|x}[(Y - \hat{f}_S(x))^2] = \sigma^2(x) + (\bar{f}(x) - f^*(x))^2 + \mathbb{E}_S[(\hat{f}_S(x) - \bar{f}(x))^2]. \quad (2.9)$$

证明只需写 $Y - \hat{f}_S = (Y - f^*) + (f^* - \bar{f}) + (\bar{f} - \hat{f}_S)$ 并展开平方。交叉项分别因条件噪声零均值和 $\mathbb{E}_S(\hat{f}_S - \bar{f}) = 0$ 消失。

注意：式 (2.9) 的“bias”是估计器平均预测与回归函数之差；偏置-复杂度权衡中的“bias”更接近假设类限制引起的近似误差。二者相关但不是同一定义。

证明或推导框架

识别信号： 题目出现“训练误差继续下降但测试误差上升”“为什么必须有归纳偏置”“任意学习算法都存在失败任务”“分解总误差”。

构造步骤：

1. 先写总体目标与经验目标；
2. 用“加减经验风险”把总体超额风险拆成近似、统一偏差和优化差；
3. 对 No Free Lunch, 构造 $2m$ 个点、随机标记、至少 m 个未见点；
4. 用未见标签条件独立得到 $1/2$ 错误, 再乘未见质量；
5. 需要高概率结论时, 用有界随机变量的期望下界反推尾概率。


常见失败原因： 只给口号不写量词；把 No Free Lunch 误解为“所有模型一样”；把优化误差和估计误差混为一谈；使用测试集反复调参却仍称其为测试集。

2.7 标准识别与使用方法

- 看到“ERM 为什么可能失败”，想到：训练风险可计算但总体风险未知；若类太丰富，数据依赖选择破坏固定假设的点态保证；
- 看到“模型太简单/太复杂”，分别检查近似误差与估计误差，而不是只谈参数数量；
- 看到“加入正则化”，把它解释成改变目标、限制有效假设类并改善稳定性，而不是保证训练误差更低；
- 看到“无万能算法”，写清量词 $\forall A \exists (P, f)$ ；
- 看到“训练、验证、测试”，写：训练拟合参数，验证选择模型/超参数，测试只做最终一次独立评估。

2.8 典型题型

例 2.8 (基础例题：误差分解诊断)。某模型训练误差为 0.01、验证误差为 0.22。增加网络宽度后训练误差降到 0.001，验证误差升到 0.25。最直接诊断是估计误差或数据分布偏移，而非近似误差。优先



措施是增加有效数据、正则化、数据增强、早停或缩小模型；若训练误差本来就很高，才优先增加表达能力或改善优化。

例 2.9 (综合例题:近似 ERM). 假设某训练算法保证 $\Delta_{\text{opt}}(S) \leq 0.01$, 且以概率 0.95 有 $\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq 0.03$. 若 $L_{\mathcal{H}}^* - L^* = 0.04$, 则同一事件上 $L_P(\tilde{h}) - L^* \leq 0.04 + 2(0.03) + 0.01 = 0.11$. 答案必须说明这是上界, 不是等式, 也不能由此断言三项统计独立。

例 2.10 (历年题型改写). [25F-A-MQ1-MQ4, 共 2 分] 把 bias-variance、No Free Lunch、Rademacher 与 ERM 连续放在热身部分。概念题的标准作法是: 先在草稿中写精确定义, 再排除把训练风险、总体风险、模型规模和计算复杂度混为一谈的选项。

例 2.11 (课程训练题型, 不是博资考真题). [MLT-HW1-Q4, 15 分, 课程作业] 给出 $\mathbb{E}Z \geq 1/4$, 要求证明 $\Pr(Z \geq 1/8) \geq 1/7$. 这是 No Free Lunch 证明末步的母题训练, 不得称为博资考真题。

2.9 答题方法

答题方法

对“解释 ERM、过拟合与 No Free Lunch”类简答或证明题:

1. 定义 $L_P(h)$ 、 $\hat{L}_S(h)$ 与 $\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{L}_S(h)$;
2. 指出 P 未知, 学习只能直接优化经验风险;
3. 写出近似误差、统一估计偏差、优化误差三项上界;
4. 解释假设类过大导致统一偏差大, 过小导致近似误差大;
5. 若要求 No Free Lunch, 明确写 $\forall A \exists (P, f)$, 并完成 $2m$ 点随机标记构造;
6. 最后说明归纳偏置的作用与边界: 它使某类任务可学习, 但不保证对所有任务优越。

2.10 易错点、反例与失败模式

易错点、反例与失败模式

1. **错误**: ERM 最小化总体风险。 **正确**: ERM 最小化训练样本上的平均损失。
2. **错误**: 训练误差为零意味着 PAC 可学习。 **反例**: 记忆训练集的类可零训练误差而总体误差为常数。
3. **错误**: 有限 VC 维等于零泛化误差。 **正确**: 它给出随样本量缩小的误差界, 不消除噪声、近似误差或优化误差。
4. **错误**: No Free Lunch 说明随机猜测在所有任务上最优。 **正确**: 它说明没有算法在所有任务上统一占优。
5. **错误**: 更强正则化总能改善测试误差。 **失败模式**: 正则过强会增大近似偏差并导致欠拟合。
6. **错误**: 验证集和测试集可以交替调参。 **正确**: 反复选择必须在训练/验证层完成, 测试集留作最终独立报告; 必要时使用嵌套交叉验证。

2.11 真题与训练材料对应

- 博资考: [25F-A-MQ1, 0.5 分]、[25F-A-MQ2, 0.5 分]、[25F-A-MQ4, 0.5 分]; [26S-A-MQ4, 0.5 分]、[26S-A-MQ5, 0.5 分]。
- 课程材料: [MLT-Final-MQ2/MQ4, 课程期末选择题]; [MLT-Practice-MQ1-MQ4, 课程练习]; [MLT-HW1-Q4, 课程作业]。
- 母题关系: 课程材料反复训练“归纳偏置—过拟合—No Free Lunch”, 但这只能表述为“课程训练材料中多次出现”。

2.12 快速自测

快速自测

1. 写出近似 ERM 的超额风险上界, 并指出每一项由什么机制控制。
2. No Free Lunch 的正确量词顺序是什么? 将 $\forall A \exists P$ 写成 $\exists P \forall A$ 会改变什么?
3. 平方损失中的 bias-variance 分解与假设类的 bias-complexity 权衡是否同义?
4. 为什么用测试集选超参数后, 最终测试误差通常偏乐观?



第三章 可实现 PAC、Agnostic PAC 与样本复杂度

3.1 重要性等级与考情定位

重要性等级：S

- PAC 是机器学习理论方向的核心语言；所有泛化界都必须落回精度 ε 、置信度 δ 与样本复杂度 $m_{\mathcal{H}}(\varepsilon, \delta)$ ；
- [25F-A-Q11, 5 分] 要求直接构造同心圆类的可实现 PAC 学习器并给出 $\lceil \log(1/\delta)/\varepsilon \rceil$ 级样本复杂度；
- [25F-A-MQ6, 1 分] 与 [26S-A-MQ1, 0.5 分] 直接考查 agnostic PAC 的比较对象；
- 高频失分点是量词顺序不完整、混淆可实现假设与零训练误差、或把 PAC 可学习性自动等同于多项式时间可计算。

3.2 精确定义与问题设定

定义 3.1 (可实现假设). 在二分类零一损失下, 给定输入分布 D 、标记函数 f 与假设类 $\mathcal{H}$, 可实现假设 (realizability assumption) 是

$$\exists h^* \in \mathcal{H} \quad \text{s.t.} \quad L_{D,f}(h^*) = 0. \quad (3.1)$$

这意味着样本由某个类内目标无噪声地产生；它不意味着任意算法都能找到 h^* , 也不意味着有限样本唯一确定 h^* 。


定义 3.2 (可实现 PAC 可学习性). 假设类 $\mathcal{H}$ 称为可实现 PAC 可学习, 如果存在学习算法 A 和样本复杂度函数 $m_{\mathcal{H}} : (0, 1)^2 \rightarrow \mathbb{N}$, 使得对任意 $\varepsilon, \delta \in (0, 1)$ 、任意输入分布 D 和任意满足式 (3.1) 的标记函数 f , 当 $S \sim D^m$, $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$, 时有

$$\Pr_S(L_{D,f}(A(S)) \leq \varepsilon) \geq 1 - \delta. \quad (3.2)$$

ε 是精度参数, δ 是失败概率上界。

定义 3.3 (Agnostic PAC 可学习性). 设 P 是 $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ 上任意分布, 损失 $\ell(h, z) \in [0, 1]$ 。假设类 $\mathcal{H}$ 称为 agnostic PAC 可学习, 如果存在算法 A 和函数 $m_{\mathcal{H}}$, 使得对任意 P 、任意 $\varepsilon, \delta \in (0, 1)$, 当 $S \sim P^m$ 且 $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$ 时,

$$\Pr_S \left(L_P(A(S)) \leq \inf_{h \in \mathcal{H}} L_P(h) + \varepsilon \right) \geq 1 - \delta. \quad (3.3)$$



这里不假设真实标记函数属于 $\mathcal{H}$ ，目标是与类内最优假设竞争。

定义 3.4 (Proper 与 improper 学习). 若算法必须返回 $A(S) \in \mathcal{H}$ ，称为 proper learning；若允许返回更大类 $\mathcal{H}' \supseteq \mathcal{H}$ 中的预测器，只要求满足相对于 $\mathcal{H}$ 的风险保证，则称为 representation-independent 或 improper learning。

统一标签约定。 PAC 与 VC 章节默认二分类标签为 $\{0, 1\}$ 。在线性分类、SVM 与 margin 章节改用 $\{-1, +1\}$ ，并在进入相应章节时显式换算。零一损失在两种编码下完全等价。

3.3 核心定理、结论与适用范围

命题 3.5 (可实现与 agnostic 的逻辑关系). 若一个算法对任意分布满足 *agnostic PAC* 保证，则在可实现情形自动得到可实现 *PAC* 保证；反向一般不成立，因为可实现分析可依赖“存在零风险类内目标”。

命题 3.6 (统计可学习性不等于计算高效). *PAC* 样本复杂度回答“需要多少样本”，并不自动限制寻找输出假设的运行时间。若另要求算法运行时间关于样本规模、表示长度、 $1/\varepsilon$ 和 $\log(1/\delta)$ 为多项式，才得到计算高效学习的更强概念。

定理 3.7 (同心圆假设类的可实现 PAC 学习). 令

$$\mathcal{H}_{\text{ball}} = \{h_r(x) = \mathbf{1}\{\|x\|_2 \leq r\} : r \geq 0\}, \quad \mathcal{X} = \mathbb{R}^2. \quad (3.4)$$

在可实现设定下，算法

$$\hat{r} := \max(\{\|X_i\|_2 : Y_i = 1\} \cup \{0\}), \quad A(S) = h_{\hat{r}}, \quad (3.5)$$

满足

$$\Pr(L_{D,f}(h_{\hat{r}}) > \varepsilon) \leq (1 - \varepsilon)^m \leq e^{-m\varepsilon}. \quad (3.6)$$


因此可取

$$m_{\mathcal{H}}(\varepsilon, \delta) \leq \left\lceil \frac{\log(1/\delta)}{\varepsilon} \right\rceil. \quad (3.7)$$

说明 3.8. 式 (3.7) 是针对该有序嵌套类和特定一致学习器的直接界。不能把它无条件推广到所有 VC 维为 1 的算法版本，也不能把 $1/\varepsilon$ 与 agnostic 情形常见的 $1/\varepsilon^2$ 混用。

3.4 为什么条件不能省

1. **取消可实现假设后，目标必须改变。** 若 $\inf_{h \in \mathcal{H}} L_P(h) > 0$ ，要求输出风险 $\leq \varepsilon$ 可能根本不可能；agnostic PAC 改为相对类内最优的超额风险。
2. **i.i.d. 不能静默省略。** 标准 PAC 的概率是对 $S \sim P^m$ 取的。独立非同分布样本可获得特定平均分布界，但那不是未经说明的标准 PAC。
3. **量词顺序不能交换。** 算法必须对所有分布和所有允许目标统一工作；不能在看到未知分布后再为它定制一个算法并仍称为分布无关 PAC。
4. **小训练误差不是定义。** PAC 结论约束总体风险；零训练误差只是可实现 ERM 中常用的中间性质。
5. **样本复杂度不等于计算复杂度。** 有限 VC 维可给统计保证，但 ERM 可能是 NP-hard 或需要不可接受的搜索。



3.5 证明或推导要求

内容	资格考试要求
可实现 PAC 定义	必须逐个写全 $\forall \epsilon, \delta, D, f$ 、可实现条件、 $m \geq m_{\mathcal{H}}$ 、概率和结论。
Agnostic PAC 定义	必须写“与 $\inf_{h \in \mathcal{H}} L_P(h)$ 竞争”，不得写成贝叶斯最优除非比较类就是全部可测分类器。
同心圆学习器	必须会完整证明固定外壳未被采到的概率界。
Proper/improper 与高效可学习	必须会解释，不必展开复杂性理论证明。
可实现与 agnostic 样本率差异	必须掌握原因：前者可利用一致性事件，后者需估计双侧风险差。

3.6 完整证明与推导

命题：*agnostic* 保证推出可实现保证。若可实现，则 $\inf_{h \in \mathcal{H}} L_P(h) = 0$ 。将其代入式 (3.3)，立即得到 $\Pr(L_P(A(S)) \leq \epsilon) \geq 1 - \delta$ 。反向不成立的原因是，可实现 PAC 只约束一类零噪声任务；它对 $\inf_{h \in \mathcal{H}} L_P(h) > 0$ 的分布没有任何承诺。 $\square$

定理 3.7. 由可实现性，存在 $r^* \geq 0$ 使 $f = h_{r^*}$ 。算法取观察到的正例中半径最大的一个，因此总有 $\hat{r} \leq r^*$ ，不会把真实负例误判为正例；其错误集合仅可能是 $E_{\hat{r}} = \{x : \hat{r} < \|x\|_2 \leq r^*\}$ 。令随机半径 $R = \|X\|_2$ 。若正类总质量小于等于 ϵ ，则任何 $\hat{r} \geq 0$ 的漏判风险至多 ϵ ，结论平凡。否则定义尾函数 $g(t) := D(t < R \leq r^*)$ ，并取 $q_\epsilon := \inf\{t \in [0, r^*] : g(t) \leq \epsilon\}$ 。由单调性和测度的连续性，固定外壳 $B_\epsilon := \{x : q_\epsilon \leq \|x\|_2 \leq r^*\}$ 的概率至少为 ϵ 。若输出风险 $g(\hat{r}) > \epsilon$ ，则必有 $\hat{r} < q_\epsilon$ ；因此训练样本中没有任何点落入 B_ϵ 。于是

$$\begin{aligned}
 \Pr(L_{D,f}(h_{\hat{r}}) > \epsilon) &\leq \Pr(S \cap B_\epsilon = \emptyset) \\
 &= (1 - D(B_\epsilon))^m \\
 &\leq (1 - \epsilon)^m \\
 &\leq e^{-m\epsilon}.
 \end{aligned}$$

令右端不超过 δ ，即 $m \geq \log(1/\delta)/\epsilon$ ，得到式 (3.7)。 $\square$

说明 3.9 (原子分布的处理). 上证使用 B_ϵ 的闭端点是为了包含分位点处的原子。若直接写 $(q_\epsilon, r^*]$ ，其质量可能小于 ϵ ，从而留下测度论缺口。考试中若默认连续分布，可用更简洁的“取概率质量为 ϵ 的最外层环带”；若未给连续性，建议采用上述分位点写法。

证明或推导框架

识别信号：“证明某个嵌套假设类 PAC 可学”“样本复杂度是 $\log(1/\delta)/\epsilon$ ”“最大正例/最小负例”。

构造步骤：

1. 找到一维有序统计量，如半径、阈值或区间端点；
2. 设计一致学习器，输出最极端的已观察关键样本；
3. 固定一个概率质量至少为 ε 的关键区域；
4. 证明“输出风险 $> \varepsilon$ ”蕴含该区域完全未被采到；
5. 用 $(1 - \varepsilon)^m \leq e^{-m\varepsilon}$ 并反解 m 。

常见失败原因：把随机错误区域直接当固定集合取概率；没有处理无正例样本；只写 VC 维而题目要求构造具体学习器；把 $\log(1/\delta)$ 写成 $1/\delta$ 。

3.7 标准识别与使用方法

- 看到“无噪声、目标在类内”，优先尝试一致学习器与坏假设消除；
- 看到“标签可能有噪声或类不含真函数”，切换到 agnostic 目标 $\inf_{h \in \mathcal{H}} L_P(h) + \varepsilon$ ；
- 看到“PAC learnable 是否意味着高效”，明确回答否，并区分统计样本复杂度与运行时间；
- 看到“某几何类是嵌套的”，寻找单参数顺序结构，而不是直接调用粗 VC 界；
- 看到“精度与置信度”，检查概率方向：好事件至少 $1 - \delta$ ，坏事件至多 δ 。

3.8 典型题型

例 3.10 (基础例题：辨析定义). 在 agnostic PAC 中，学习器竞争的是 $\inf_{h \in \mathcal{H}} L_P(h)$ ，而不是必然竞争 Bayes 分类器。只有当 $\mathcal{H}$ 包含所有可测分类器或明确把 Bayes 规则纳入比较类时，两者才相同。

例 3.11 (综合例题：阈值类). 令 $\mathcal{H} = \{h_a(x) = \mathbf{1}\{x \leq a\} : a \in \mathbb{R}\}$ ，目标为 h_{a^*} 。取最大正例 $\hat{a}$ 作为阈值，与同心圆证明完全同构：把 $\|x\|$ 换成 x ，即可得到坏事件至多 $e^{-m\varepsilon}$ 。这是识别“母题”的典型方式。

例 3.12 (历年题型改写). [25F-A-Q11, 5 分] 给定二维同心圆类并要求证明可实现 PAC 可学习。完整得分点为：定义学习器 $\hat{r}$ ；说明只产生假阴性；构造质量至少 ε 的外壳；计算未采中概率；反解样本复杂度。

例 3.13 (课程训练题型，不是博资考真题). [MLT-Practice-Q4, 课程练习] 与 [25F-A-Q11, 5 分] 高度同源，可作为逐行证明训练，但其出现不能额外增加博资考频率计数。

3.9 答题方法

答题方法

写 PAC 定义时，按以下固定顺序：

1. 声明存在算法 A 和样本复杂度函数 $m_{\mathcal{H}}$ ；
2. 写 $\forall \varepsilon, \delta \in (0, 1)$ ；
3. 写 $\forall D$ 和允许的标记机制/联合分布；

4. 可实现版本写 $\exists h^* \in \mathcal{H} : L(h^*) = 0$; agnostic 版本不写该假设;
5. 写 $S \sim P^m$ 、 $m \geq m_{\mathcal{H}}(\epsilon, \delta)$;
6. 写概率至少 $1 - \delta$;
7. 写结论: 可实现为 $L(A(S)) \leq \epsilon$, agnostic 为 $L(A(S)) \leq \inf_{h \in \mathcal{H}} L(h) + \epsilon$;
8. 若题目问效率, 再单独讨论运行时间, 不要混入统计定义。

3.10 易错点、反例与失败模式

易错点、反例与失败模式

1. **错误**: agnostic PAC 仍要求真实函数在 $\mathcal{H}$ 中。 **正确**: 它允许模型失配和噪声, 只与类内最优风险竞争。
2. **错误**: PAC 中“probably”指预测概率。 **正确**: 它指对随机训练样本, 泛化保证成立的概率至少为 $1 - \delta$ 。
3. **错误**: PAC learnability 自动包含多项式时间。 **正确**: 本讲义主约定先分离统计与计算; 题目若采用 Valiant 强版本需另写运行时间要求。
4. **错误**: 一致性 ($m \rightarrow \infty$ 风险收敛) 等价于给定 m 的 PAC 界。 **正确**: 一致性是渐近概念; PAC 给有限样本、精度和置信度的统一保证。
5. **错误**: 同心圆学习器取最小负例。 **改法**: 可取最大正例得到内缩圆; 若用最小负例则需严格处理边界与输出方向。

3.11 真题与训练材料对应

- 博资考: [25F-A-MQ6, 1 分]; [25F-A-Q11, 5 分]; [26S-A-MQ1, 0.5 分]; [26S-A-MQ4, 0.5 分]。
- 课程材料: [MLT-Final-MQ1, 2 分, 课程期末选择题]; [MLT-Practice-MQ3, 课程练习]; [MLT-Practice-Q4, 课程练习]。
- 主要母题: 定义辨析; 嵌套几何类的一致学习器; 从坏事件概率反解样本复杂度。

3.12 快速自测

快速自测

1. 可实现 PAC 和 agnostic PAC 的风险结论分别是什么?
2. 为什么“有限 VC 维”与“存在多项式时间训练算法”是两个不同命题?
3. 同心圆证明中, 为什么必须把随机错误区域转化为固定的 ϵ 质量外壳?
4. Proper learner 与 improper learner 的输出空间有何不同?

第四章 有限假设类、集中不等式与一致收敛

4.1 重要性等级与考情定位

重要性等级: S

- Hoeffding + union bound + ERM 三段链是机器学习理论最稳定的资格考试证明模板;
- [25S-A-Q2, 7 分] 把有限类可实现界扩展到“独立但非同分布”样本, 要求识别平均分布和 AM-GM;
- [MLT-Practice-Q3, 课程练习] 直接要求有限类一致收敛样本复杂度, [MLT-HW1-Q1, 课程作业] 给出非同分布完整训练;
- 本章是后续增长函数、VC、Rademacher 和稳定性比较的基准。

4.2 精确定义与问题设定

定义 4.1 (点态收敛与一致收敛事件). 对固定 h , 点态偏差事件为 $|L_P(h) - \hat{L}_S(h)| > \varepsilon$. 对整个类, ε -代表性事件为

$$\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq \varepsilon. \quad (4.1)$$

若对任意 $\varepsilon, \delta \in (0, 1)$, 存在 $m_{\mathcal{H}}^{\text{UC}}(\varepsilon, \delta)$, 使 m 足够大时式 (4.1) 以概率至少 $1 - \delta$ 成立, 则称 $\mathcal{H}$ 具有一致收敛 (uniform convergence) 性质。

引理 4.2 (Hoeffding 不等式: 有界均值版本). 若 $U_1, \dots, U_m$ 独立, 且 $U_i \in [0, 1]$, 并令 $\bar{U} = m^{-1} \sum_i U_i$, 则对任意 $\varepsilon > 0$,

$$\Pr(|\bar{U} - \mathbb{E}\bar{U}| > \varepsilon) \leq 2e^{-2m\varepsilon^2}. \quad (4.2)$$

若只需单侧偏差, 可去掉前面的因子 2。

随机性与输入规模。 在有限类定理中, 概率只对 $S \sim P^m$ 取; $\mathcal{H}$ 被视为在采样前固定。直接枚举所有假设并计算经验风险的时间复杂度为 $O(m|\mathcal{H}|C_\ell)$, 而泛化界仅含 $\log |\mathcal{H}|$; 统计复杂度与计算复杂度的尺度可以完全不同。

4.3 核心定理与样本复杂度

定理 4.3 (有限假设类的一致收敛). 设 $\mathcal{H}$ 有限, 且 $\ell(h, Z) \in [0, 1]$. 则

$$\Pr\left(\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| > \varepsilon\right) \leq 2|\mathcal{H}|e^{-2m\varepsilon^2}. \quad (4.3)$$



因此可取

$$m_{\mathcal{H}}^{\text{UC}}(\varepsilon, \delta) \leq \left\lceil \frac{\log(2|\mathcal{H}|/\delta)}{2\varepsilon^2} \right\rceil. \quad (4.4)$$

推论 4.4 (有限类 ERM 的 agnostic PAC 保证). 若 $\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{L}_S(h)$, 则以概率至少 $1 - \delta$,

$$L_P(\hat{h}) \leq \inf_{h \in \mathcal{H}} L_P(h) + \varepsilon, \quad (4.5)$$

只要

$$m \geq \frac{2}{\varepsilon^2} \log \frac{2|\mathcal{H}|}{\delta}. \quad (4.6)$$

定理 4.5 (有限类可实现一致学习器). 设二分类任务可实现, $\mathcal{H}$ 有限, 算法输出任一训练误差为零的 $\hat{h} \in \mathcal{H}$. 则

$$\Pr(L_{D,f}(\hat{h}) > \varepsilon) \leq |\mathcal{H}|e^{-m\varepsilon}. \quad (4.7)$$

所以

$$m \geq \frac{\log |\mathcal{H}| + \log(1/\delta)}{\varepsilon} \quad (4.8)$$

足以保证可实现 PAC 学习。

定理 4.6 (独立非同分布样本下的平均分布界). 令 $X_i \sim D_i$ 相互独立但不要求同分布, $Y_i = f(X_i)$, $f \in \mathcal{H}$, $\mathcal{H}$ 有限. 定义平均分布

$$\bar{D}_m := \frac{1}{m} \sum_{i=1}^m D_i, \quad L_{\bar{D}_m, f}(h) = \frac{1}{m} \sum_{i=1}^m L_{D_i, f}(h). \quad (4.9)$$


则对任意 $\varepsilon \in (0, 1)$,

$$\Pr(\exists h \in \mathcal{H} : L_{\bar{D}_m, f}(h) > \varepsilon, \hat{L}_{S, f}(h) = 0) \leq |\mathcal{H}|e^{-m\varepsilon}. \quad (4.10)$$

特别地, $\varepsilon = 1/4$ 时得到 $|\mathcal{H}|e^{-m/4}$ 。

4.4 为什么条件不能省

1. **有界损失或尾部条件不能省**。Hoeffding 使用 $[0, 1]$ 有界性; 对无界平方损失需改用次高斯、Bernstein、截断或稳健均值条件。
2. **有限类的 union bound 不能直接用于不可数类**。对无限类必须先用增长函数、VC、covering number 或 Rademacher complexity 控制“有效大小”。
3. **点态集中不能直接处理 ERM 输出**。 $\hat{h}$ 依赖样本, 必须在同一个高概率事件上同时控制所有 $h \in \mathcal{H}$ 。
4. **可实现与 agnostic 的 ε 次数不同**。可实现证明只排除“真风险大但训练误差零”的单侧事件, 给 $1/\varepsilon$; agnostic 需要双侧估计风险差, Hoeffding 产生 $1/\varepsilon^2$ 。
5. **非同分布结论的目标是平均分布**。式 (4.10) 不保证对任意单个 D_i 、未来分布或分布漂移后的目标分布泛化。



4.5 证明或推导要求

结果	资格考试要求
Hoeffding 不等式	必须会准确陈述；一般不要求从矩母函数完整证明，除非题目明确要求。
有限类一致收敛	必须会完整证明：固定 h 集中，再 union bound。
一致收敛推出 ERM 泛化	必须会写四项链，不得只写“由一致收敛显然”。
有限类可实现界	必须完整证明固定坏假设一致概率及 union bound。
独立非同分布扩展	必须完整证明：乘积概率、AM-GM、指数界、union bound。
样本复杂度反解	必须会从尾界逐行取对数，并检查 ε, δ 的位置。

4.6 完整证明与推导

定理 4.3. 固定 $h \in \mathcal{H}$ ，令 $U_i = \ell(h, Z_i) \in [0, 1]$ 。由 Hoeffding， $\Pr(|\hat{L}_S(h) - L_P(h)| > \varepsilon) \leq 2e^{-2m\varepsilon^2}$ 。统一偏差超出 ε 等价于至少存在一个 h 发生上述事件，因此由 union bound，

$$\begin{aligned}
 & \Pr\left(\sup_{h \in \mathcal{H}} |\hat{L}_S(h) - L_P(h)| > \varepsilon\right) \\
 &= \Pr\left(\bigcup_{h \in \mathcal{H}} \{|\hat{L}_S(h) - L_P(h)| > \varepsilon\}\right) \\
 &\leq \sum_{h \in \mathcal{H}} 2e^{-2m\varepsilon^2} = 2|\mathcal{H}|e^{-2m\varepsilon^2}.
 \end{aligned}$$


令右端不超过 δ ，取对数得 $-2m\varepsilon^2 + \log(2|\mathcal{H}|) \leq \log \delta$ ，即式 (4.4)。□

推论 4.4. 在事件 $\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq \varepsilon/2$ 上，取任意 $h_\eta^* \in \mathcal{H}$ 使 $L_P(h_\eta^*) \leq \inf_{h \in \mathcal{H}} L_P(h) + \eta$ 。则

$$\begin{aligned}
 L_P(\hat{h}) &\leq \hat{L}_S(\hat{h}) + \frac{\varepsilon}{2} \\
 &\leq \hat{L}_S(h_\eta^*) + \frac{\varepsilon}{2} \\
 &\leq L_P(h_\eta^*) + \varepsilon \\
 &\leq \inf_{h \in \mathcal{H}} L_P(h) + \varepsilon + \eta.
 \end{aligned}$$

令 $\eta \downarrow 0$ 得式 (4.5)。把定理 4.3 中的偏差参数换成 $\varepsilon/2$ ，即得式 (4.6)。□

定理 4.5. 固定一个坏假设 h ，设 $p = L_{D,f}(h) > \varepsilon$ 。它在 m 个独立样本上保持一致的概率为 $\Pr(\hat{L}_{S,f}(h) = 0) = (1-p)^m \leq (1-\varepsilon)^m \leq e^{-m\varepsilon}$ 。若一致学习器输出真风险大于 ε 的假设，则必存在某个坏假设在训练集上误差为零。对所有 $h \in \mathcal{H}$ 使用 union bound，得到式 (4.7)；再令右端不超过 δ ，得到式 (4.8)。□



定理 4.6. 固定 $h \in \mathcal{H}$, 令 $p_i := L_{D_i, f}(h)$, $\bar{p} := \frac{1}{m} \sum_{i=1}^m p_i = L_{\bar{D}_m, f}(h)$ 。由于样本独立, h 在所有样本上均预测正确的概率为

$$\begin{aligned} \Pr(\hat{L}_{S, f}(h) = 0) &= \prod_{i=1}^m (1 - p_i) \\ &\leq \left(\frac{1}{m} \sum_{i=1}^m (1 - p_i) \right)^m \quad (\text{几何-算术平均不等式}) \\ &= (1 - \bar{p})^m \\ &\leq e^{-m\bar{p}}. \end{aligned}$$

若 $\bar{p} > \varepsilon$, 上式小于 $e^{-m\varepsilon}$ 。最后对有限类中所有假设使用 union bound, 得到式 (4.10)。□

根据附件结论所作的推导补充

样本复杂度 inversion 的统一写法。 若尾界形如 $C \exp(-am\varepsilon^q) \leq \delta$, 其中 $C, a > 0$, 则

$$m \geq \frac{\log C + \log(1/\delta)}{a\varepsilon^q}. \quad (4.11)$$

资格考试中应先写 $\log C - am\varepsilon^q \leq \log \delta$, 再移项。最常见错误是把 $\log(1/\delta)$ 错写成 $1/\delta$, 或漏掉把 agnostic 目标中的 ε 分成两次 $\varepsilon/2$ 。

证明或推导框架

识别信号: “有限假设类”“所有训练误差为零”“经验风险和总体风险同时接近”“独立但不完全同分布”。

构造步骤:

1. 固定一个 h , 写逐样本有界随机变量;
2. 点态偏差用 Hoeffding;
3. 要控制数据依赖输出, 立即对 $h \in \mathcal{H}$ 做 union bound;
4. 可实现零训练误差时, 不必做双侧 Hoeffding, 直接算一致概率;
5. 非同分布时把乘积 $\prod_i (1 - p_i)$ 用 AM-GM 压到平均风险;
6. 最后取对数反解 m 。

常见失败原因: 把 $|\mathcal{H}|$ 放进指数而非对数; 点态结论直接代入随机 $\hat{h}$; 非同分布时把 p_i 静默写成共同 p ; 把平均分布保证解释成未来分布保证。

4.7 标准识别与使用方法

- “有限类 + 零训练误差”是可实现 union-bound 母题, 优先得到 $O((\log |\mathcal{H}| + \log(1/\delta))/\varepsilon)$;
- “有限类 + 有界损失 + 与类内最优竞争”是统一收敛母题, 得到 $O((\log |\mathcal{H}| + \log(1/\delta))/\varepsilon^2)$;
- “独立但非同分布”先定义平均分布, 不要机械调用 i.i.d. Hoeffding;
- “某个 h 的经验风险收敛”只是 pointwise convergence; “ERM 泛化”需要 uniform convergence;
- 若 $\mathcal{H}$ 无限, 下一步不是放弃, 而是用增长函数把样本上的有效标记数替换 $|\mathcal{H}|$ 。

4.8 典型题型

例 4.7 (基础例题: 有限类样本量). 若 $|\mathcal{H}| = 10^4$, 希望以置信度 0.99 保证统一偏差不超过 0.05, 由式 (4.4), 可取 $m \geq \frac{\log(2 \cdot 10^4 / 0.01)}{2(0.05)^2}$. 考试中通常保留此精确表达式即可; 若给数值, 必须说明对数底为自然对数。

例 4.8 (综合例题: 点态与数据选择). 设每个固定 h 都有 $\Pr(|L(h) - \hat{L}(h)| > 0.1) \leq 0.01$. 若 $|\mathcal{H}| = 1000$, 不能据此断言 ERM 以 0.99 概率泛化; 粗 union bound 只给失败概率至多 10, 完全无信息。需要更大样本、更紧界或更小有效复杂度。

例 4.9 (历年题型改写). [25S-A-Q2, 7 分] 给出 $\varepsilon = 1/4$ 、有限 $\mathcal{H}$ 、共同目标 $f \in \mathcal{H}$, 但 $X_i \sim D_i$ 。满分步骤为: 定义 p_i ; 写一致概率的乘积; 使用 AM-GM; 得到 $(1 - \bar{p})^m$; 使用 $\log(3/4) < -1/4$ 或 $1 - x \leq e^{-x}$; 最后 union bound。

例 4.10 (课程训练题型, 不是博资考真题). [MLT-Practice-Q3, 课程练习] 要求证明式 (4.4); [MLT-HW1-Q1, 15 分, 课程作业] 是 [25S-A-Q2, 7 分] 的一般 ε 母题; [MLT-Final-Q2, 15 分, 课程期末题] 是 $\varepsilon = 1/4$ 版本。它们均不能额外计入博资考频率。

4.9 答题方法

答题方法

有限类泛化题统一按以下格式:

1. 写清固定假设 h 的总体风险 p 或逐分布风险 p_i ;
2. 指出需要控制的坏事件: 双侧偏差, 或“真风险大但训练误差零”;
3. 固定 h 计算/上界该事件概率;
4. 写 union bound 的集合并形式, 不能只写“乘以 $|\mathcal{H}|$ ”;
5. 若是 ERM, 写完整风险比较链;
6. 令失败概率不超过 δ , 逐行取对数反解样本量;
7. 结尾说明保证针对哪个分布、哪种损失和哪个假设类。

4.10 易错点、反例与失败模式

易错点、反例与失败模式

1. **错误**: 点态收敛等于一致收敛。 **反例直觉**: 每个固定假设都可能可靠, 但算法可从极大类中挑中恰好过拟合当前样本的假设。
2. **错误**: 有限类样本复杂度线性依赖 $|\mathcal{H}|$ 。 **正确**: 统计界通常只依赖 $\log |\mathcal{H}|$, 朴素计算时间才可能线性依赖 $|\mathcal{H}|$ 。
3. **错误**: 可实现和 agnostic 都是 $1/\varepsilon^2$ 。 **正确**: 有限类一致学习器的可实现界可为 $1/\varepsilon$ 。
4. **错误**: union bound 要求事件独立。 **正确**: union bound 对任意事件成立; 独立性用于固定假设的样本概率计算。

5. **错误**：平均分布 $\bar{D}_m$ 是下一时刻的真实分布。 **正确**：它只是当前 $D_1, \dots, D_m$ 的混合；对未来漂移需额外假设。

6. **错误**：Hoeffding 可直接用于任意无界损失。 **正确**：必须检查有界或相应尾部条件。

4.11 真题与训练材料对应

- 博资考：[25S-A-Q2, 7 分]；[25F-A-MQ8, 1 分 bonus] 与 Sauer/增长函数构成下一章的无限类延伸。
- 课程材料：[MLT-Final-Q2, 15 分, 课程期末题]；[MLT-Practice-Q3, 课程练习]；[MLT-HW1-Q1, 15 分, 课程作业]。
- 技巧迁移：Hoeffding/union bound 还会用于模型选择、验证集保证、Rademacher 对称化后的尾界和多类约简。

4.12 快速自测

快速自测

1. 有限类一致收敛的失败概率界是什么？若用于 agnostic ERM，为何要把偏差设为 $\varepsilon/2$ ？
2. union bound 是否需要不同假设的偏差事件相互独立？
3. 独立非同分布证明中，AM-GM 作用于哪些数？最终控制的是哪个风险？
4. 为什么可实现有限类界是 $1/\varepsilon$ ，而双侧统一收敛界是 $1/\varepsilon^2$ ？



第五章 打散、增长函数与 VC 维

5.1 重要性等级与考情定位

重要性等级: S

- 打散 (shattering)、增长函数 (growth function) 和 VC 维 (Vapnik–Chervonenkis dimension) 是无限假设类可学习性分析的核心语言, 是下一章 Sauer 引理、统一收敛和统计学习基本定理的直接前置。
- 三套博资考均直接考查了 VC 维或增长函数: [25S-A-Q3, 9 分]、[25F-A-Q9, 5 分]、[26S-A-Q3, 8 分]; 此外 [25F-A-MQ5, 1 分]、[25F-A-MQ8, 1 分 bonus] 和 [26S-A-MQ2, 0.5 分] 直接考查定义、Sauer 引理或典型结论。
- 课程训练材料中, 稀疏正例类、轴对齐下盒、假设类之并、笛卡尔积、复合类和决策树均被用于训练 VC 维或增长函数证明。
- 本章最常见的失分原因不是不会猜出答案, 而是: 下界只展示了一个标记; 上界只否定了—个特殊点集; 把“参数个数”直接等同于 VC 维; 或把增长函数的上界误写成精确值。

5.2 精确定义、对象与量词

5.2.1 限制类与标记向量

定义 5.1 (假设类在有限样本上的限制). 设 $\mathcal{H} \subseteq \{0, 1\}^{\mathcal{X}}$ 是二分类假设类, 且 $C = (x_1, \dots, x_m) \in \mathcal{X}^m$ 由 m 个两两不同的点构成。定义 $\mathcal{H}$ 在 C 上的限制 (restriction) 或迹 (trace) 为

$$\mathcal{H}|_C := \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\} \subseteq \{0, 1\}^m. \quad (5.1)$$

集合 $\mathcal{H}|_C$ 中每个元素是 $\mathcal{H}$ 在点集 C 上能够实现的一个完整标记向量。


说明 5.2 (点集与有序元组). 打散性质与点的排列顺序无关, 但在计算一维假设类的增长函数时, 通常将样本按 $x_1 < x_2 < \dots < x_m$ 排序, 以便把可实现标记描述为若干连续标记块。式 (5.1) 使用有序元组只是为了把标记写成向量。

5.2.2 打散

定义 5.3 (打散). 若

$$\mathcal{H}|_C = \{0, 1\}^m, \quad \text{即} \quad |\mathcal{H}|_C| = 2^m, \quad (5.2)$$

则称 $\mathcal{H}$ 打散 (shatter) 点集 C 。



等价地, 对每个标记向量 $\mathbf{y} = (y_1, \dots, y_m) \in \{0, 1\}^m$, 都存在一个可能依赖于 $\mathbf{y}$ 的假设 $h_{\mathbf{y}} \in \mathcal{H}$, 使 $h_{\mathbf{y}}(x_i) = y_i$, $i = 1, \dots, m$ 。

易错点、反例与失败模式

“存在一个 $h \in \mathcal{H}$ 完全拟合 C 上的某个标记”不等于“ $\mathcal{H}$ 打散 C ”。

打散要求实现全部 2^m 种标记。不同标记通常由不同的假设实现, 不要求同一个假设同时实现互相矛盾的标记。

5.2.3 增长函数

定义 5.4 (增长函数). 对 $m \in \mathbb{N}$, 假设 $\mathcal{X}$ 至少含有 m 个不同点。定义 $\mathcal{H}$ 的增长函数为

$$\tau_{\mathcal{H}}(m) := \max_{\substack{C \subseteq \mathcal{X} \\ |C|=m}} |\mathcal{H}|_C|. \quad (5.3)$$

显然,

$$1 \leq \tau_{\mathcal{H}}(m) \leq 2^m. \quad (5.4)$$

而且

$$\tau_{\mathcal{H}}(m) = 2^m \iff \mathcal{H} \text{ 能打散某个大小为 } m \text{ 的点集}. \quad (5.5)$$

若输出空间不是 $\{0, 1\}$, 仍可定义

$$\tau_{\mathcal{F}}(m) = \sup_{x_1, \dots, x_m} |\{(f(x_1), \dots, f(x_m)) : f \in \mathcal{F}\}|, \quad (5.6)$$

但此时它不再直接对应二分类 VC 维。后文分析笛卡尔积类和复合类时采用式 (5.6)。

5.2.4 VC 维

定义 5.5 (VC 维). 二分类假设类 $\mathcal{H}$ 的 VC 维定义为

$$\text{VCdim}(\mathcal{H}) := \sup \{m \in \mathbb{N} : \tau_{\mathcal{H}}(m) = 2^m\}. \quad (5.7)$$

具体约定如下:

- 若 $\mathcal{H}$ 不能打散任何单点, 则 $\text{VCdim}(\mathcal{H}) = 0$;
- 若对任意 $m \in \mathbb{N}$, $\mathcal{H}$ 均能打散某个 m 点集, 则 $\text{VCdim}(\mathcal{H}) = +\infty$;
- 若 $\text{VCdim}(\mathcal{H}) = d < \infty$, 则存在某个 d 点集可被打散, 但不存在任何 $(d+1)$ 点集可被打散。


标签编码不影响 VC 维。 若将标签由 $\{0, 1\}$ 改为 $\{-1, +1\}$, 通过双射 $\tilde{y} = 2y - 1$ 逐点转换标记, 打散能力不变。因此 VC 维与这两种二分类标签编码无关。

5.3 基本性质及其严格证明

命题 5.6 (单调性、补类不变性与有限类上界). 设 $\mathcal{H}_1, \mathcal{H}_2 \subseteq \{0, 1\}^{\mathcal{X}}$ 。

1. 若 $\mathcal{H}_1 \subseteq \mathcal{H}_2$, 则

$$\tau_{\mathcal{H}_1}(m) \leq \tau_{\mathcal{H}_2}(m), \quad \text{VCdim}(\mathcal{H}_1) \leq \text{VCdim}(\mathcal{H}_2). \quad (5.8)$$



2. 定义补类 $1 - \mathcal{H} := \{x \mapsto 1 - h(x) : h \in \mathcal{H}\}$. 则

$$\tau_{1-\mathcal{H}}(m) = \tau_{\mathcal{H}}(m), \quad \text{VCdim}(1 - \mathcal{H}) = \text{VCdim}(\mathcal{H}). \quad (5.9)$$

3. 若 $|\mathcal{H}| < \infty$, 则

$$\tau_{\mathcal{H}}(m) \leq \min\{|\mathcal{H}|, 2^m\}, \quad \text{VCdim}(\mathcal{H}) \leq \lfloor \log_2 |\mathcal{H}| \rfloor. \quad (5.10)$$

证明. 若 $\mathcal{H}_1 \subseteq \mathcal{H}_2$, 则对任意有限点集 C , $\mathcal{H}_1|_C \subseteq \mathcal{H}_2|_C$. 取基数并对 C 最大化, 得到增长函数单调性; 若 $\mathcal{H}_1$ 能打散 C , 则 $\mathcal{H}_2$ 也能打散 C , 从而得到 VC 维单调性。

对任意 $C = (x_1, \dots, x_m)$, 映射 $(y_1, \dots, y_m) \mapsto (1 - y_1, \dots, 1 - y_m)$ 是 $\mathcal{H}|_C$ 与 $(1 - \mathcal{H})|_C$ 之间的双射, 因此两者基数相同。

最后, 一个假设在固定点集上至多贡献一个标记向量, 故 $|\mathcal{H}|_C| \leq |\mathcal{H}|$. 若 $\mathcal{H}$ 能打散 d 个点, 则 $2^d \leq |\mathcal{H}|$, 所以 $d \leq \log_2 |\mathcal{H}|$. $\square$


说明 5.7 (VC 维与参数数量). 式 (5.10) 控制的是有限假设数量, 而不是实参数个数。对实参数模型, 一个参数可以通过阈值、振荡或组合结构产生大量不同标记。因此“有 p 个参数, 所以 VC 维等于 p ”一般是错误命题。

典型正确结论包括:

- $\mathbb{R}^d$ 中带偏置仿射半空间的 VC 维为 $d + 1$;
- 某些神经网络的 VC 维可达到参数量乘对数因子的量级;
- 同样参数数量的模型可因激活函数和计算图不同而有不同 VC 维。

5.4 为什么定义中的条件不能省

1. **样本点必须不同**. 若允许重复同一点, 则该点的多个副本必须得到相同预测, 不能独立标记, 导致 2^m 的比较失去原本含义。
2. **增长函数必须对点集取最大值**. 某个位置特殊的点集不能被打散, 不代表不存在另一个可被打散的点集。
3. **VC 上界必须针对任意点集**. 为证明 $\text{VCdim}(\mathcal{H}) \leq d$, 必须证明任意 $d + 1$ 个点都不能被打散; 仅展示一个不能被打散的 $(d + 1)$ 点集不充分。
4. **VC 下界必须覆盖全部标记**. 为证明 $\text{VCdim}(\mathcal{H}) \geq d$, 必须选定一个 d 点集, 并对任意 $\mathbf{y} \in \{0, 1\}^d$ 构造相应假设。
5. **有限 VC 维并不意味着零泛化误差**. 它控制假设类的组合复杂度; 噪声、模型失配、有限样本和优化误差仍可造成正风险。



5.5 VC 维证明的标准母题

证明或推导框架

识别信号：题目要求“计算 VC 维”“给出增长函数上界”“证明某几何类可或不可打散若干点”。

下界构造：

1. 猜测候选维数 d ;
2. 选择具有对称性、极值性或仿射独立性的 d 个点;
3. 任取标记向量 $\mathbf{y} \in \{0, 1\}^d$;
4. 根据 $\mathbf{y}$ 显式设置阈值、区间端点、法向量或树结构;
5. 检查每个点的预测, 不得只依赖图形直觉。

上界反证：

1. 任取 $d + 1$ 个点;
2. 利用排序、鸽巢原理、极值点、凸包、标记变化次数或 Radon 分割;
3. 构造至少一种该类无法实现的标记;
4. 说明该构造对任意 $d + 1$ 点集均成立。

增长函数计数：

1. 先刻画可实现标记向量的结构;
2. 再计数, 不要直接数连续参数取值;
3. 不同参数可能产生相同标记, 必须数“不同标记向量”, 不是数参数区域。

5.6 至多 k 个正例的假设类

5.6.1 问题设定

定义 5.8 (稀疏正例假设类). 设 $k \in \mathbb{N}_0$, 定义

$$\mathcal{H}_{\leq k} = \{h: \mathcal{X} \rightarrow \{0, 1\} : |\{x \in \mathcal{X} : h(x) = 1\}| \leq k\}. \quad (5.11)$$

该类不是“在训练集上至多有 k 个正例”, 而是每个假设在整个定义域上至多把 k 个点标为正类。


定理 5.9 (稀疏正例类的增长函数与 VC 维). 设 $N := |\mathcal{X}|$. 当 N 有限时, 令 $q = \min\{k, N\}$; 当 $\mathcal{X}$ 无限时令 $q = k$. 则

$$\text{VCdim}(\mathcal{H}_{\leq k}) = q. \quad (5.12)$$

进一步地, 只要 $n \leq N$, 对任意 n 个不同点,

$$\tau_{\mathcal{H}_{\leq k}}(n) = \sum_{j=0}^{\min\{k, n\}} \binom{n}{j}. \quad (5.13)$$

证明. 固定任意 n 个不同点 $C = \{x_1, \dots, x_n\}$. 任意 $h \in \mathcal{H}_{\leq k}$ 在 C 上至多产生 k 个正标记, 因此



$|\mathcal{H}_{\leq k}| \leq \sum_{j=0}^{\min\{k, n\}} \binom{n}{j}$ 。反之，对任意 $I \subseteq [n]$, $|I| \leq k$, 定义 $h_I(x) = \begin{cases} 1, & x = x_i \text{ 对某个 } i \in I, \\ 0, & \text{其他.} \end{cases}$

则 $h_I \in \mathcal{H}_{\leq k}$, 且其在 C 上恰好实现正标记位置集合 I 。故式 (5.13) 为精确值。

若 $n \leq q$, 则 $\min\{k, n\} = n$, 所以 $\tau_{\mathcal{H}_{\leq k}}(n) = \sum_{j=0}^n \binom{n}{j} = 2^n$ 。因此任意 q 个不同点均可被打散, 得到 $\text{VCdim}(\mathcal{H}_{\leq k}) \geq q$ 。

若 $N < k$, 则任意假设类在有限定义域上的 VC 维至多为 $N = q$ 。若 $k \leq N$, 任取 $k+1$ 个不同点, 把它们全部标为 1 的标记向量需要某个假设在至少 $k+1$ 个点取值 1, 这与式 (5.11) 矛盾。因此 $\text{VCdim}(\mathcal{H}_{\leq k}) \leq k = q$ 。□

答题方法

[MLT-Practice-Q1, 课程训练题型, 不是博资考真题] 的满分答案应写:

1. 先区分 $k < |\mathcal{X}|$ 与 $k \geq |\mathcal{X}|$;
2. 下界: 任取 $\min\{k, |\mathcal{X}|\}$ 个点, 对任意正例位置集合构造“只在这些点为 1”的假设;
3. 上界: 若 $k < |\mathcal{X}|$, 用 $k+1$ 个点的全正标记反证;
4. 若定义域有限, 再写 VC 维不可能超过 $|\mathcal{X}|$;
5. 最终结论必须是 $\min\{k, |\mathcal{X}|\}$, 不能无条件写成 k 。

5.7 轴对齐下盒: $\text{VCdim} = p$

5.7.1 模型与结论

定义 5.10 (轴对齐下盒). 在 $\mathbb{R}^p$ 中定义

$$\mathcal{H}_{\text{lower}, p} = \{h_{\mathbf{a}}(\mathbf{x}) = \mathbf{1}\{x_1 \leq a_1, \dots, x_p \leq a_p\} : \mathbf{a} \in \mathbb{R}^p\}. \quad (5.14)$$

其正类区域是 $(-\infty, a_1] \times \dots \times (-\infty, a_p]$ 。单点预测时间复杂度为 $O(p)$, 只需逐坐标比较。

定理 5.11 (轴对齐下盒的 VC 维). 有

$$\text{VCdim}(\mathcal{H}_{\text{lower}, p}) = p. \quad (5.15)$$

证明. 下界. 取标准基点 $C = \{\mathbf{e}_1, \dots, \mathbf{e}_p\}$, 其中 $\mathbf{e}_i$ 的第 i 个坐标为 1, 其他坐标为 0。任取标记向量 $\mathbf{y} \in \{0, 1\}^p$, 设置

$$a_i = \begin{cases} 1, & y_i = 1, \\ \frac{1}{2}, & y_i = 0. \end{cases} \quad (5.16)$$

若 $y_i = 1$, 则 $\mathbf{e}_i$ 的所有坐标均不超过相应 a_j ; 若 $y_i = 0$, 则其第 i 个坐标满足 $(\mathbf{e}_i)_i = 1 > a_i = \frac{1}{2}$, 故被排除。因此 C 被打散, $\text{VCdim}(\mathcal{H}_{\text{lower}, p}) \geq p$ 。

上界. 任取 $p+1$ 个点 $C = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p+1)}\} \subseteq \mathbb{R}^p$ 。对每个坐标 $j \in [p]$, 选择一个最大值达到点 $i_j \in \arg \max_{i \in [p+1]} x_j^{(i)}$ 。集合 $E := \{\mathbf{x}^{(i_1)}, \dots, \mathbf{x}^{(i_p)}\}$ 至多含 p 个点, 故存在 $\mathbf{x}^* \in C \setminus E$ 。给 $\mathbf{x}^*$ 标记 0, 给 $C \setminus \{\mathbf{x}^*\}$ 中所有点标记 1。

若某个下盒包含所有正标记点, 则它特别包含每个 $\mathbf{x}^{(i_j)}$, 于是 $a_j \geq x_j^{(i_j)} = \max_{i \in [p+1]} x_j^{(i)} \geq x_j^*$, $j = 1, \dots, p$ 。所以该下盒也包含 $\mathbf{x}^*$, 与其负标记矛盾。故任意 $p+1$ 点均不能被打散, $\text{VCdim}(\mathcal{H}_{\text{lower}, p}) \leq p$ 。结合上下界即得结论。□

易错点、反例与失败模式

上界证明中的 $\mathbf{x}^*$ 不要求在每个坐标上都严格小于某个其他点。即使存在坐标最大值并列，只要每个坐标选择一个最大值代表，未被选择的 $\mathbf{x}^*$ 仍满足逐坐标 $x_j^* \leq \max_i x_j^{(i)}$ 。因此证明对并列极值仍成立。

课程材料对应。[MLT-Final-Q4, 15 分, 课程期末题] 直接要求证明式 (5.15)。它是“下界用标准基、上界用每个坐标极值点和鸽巢原理”的标准母题，不是人工智能博资考真题。

5.8 二维轴对齐矩形：VCdim = 4

定义 5.12 (二维轴对齐矩形类). 定义

$$\mathcal{R}_{\text{rect}} = \{h_{a_1, b_1, a_2, b_2}(\mathbf{x}) = \mathbf{1}\{a_1 \leq x_1 \leq b_1, a_2 \leq x_2 \leq b_2\}\}. \quad (5.17)$$

命题 5.13 (二维轴对齐矩形的 VC 维). 有

$$\text{VCdim}(\mathcal{R}_{\text{rect}}) = 4. \quad (5.18)$$

证明. 下界. 取四个十字形点 $\mathbf{x}_L = (-1, 0)$, $\mathbf{x}_R = (1, 0)$, $\mathbf{x}_B = (0, -1)$, $\mathbf{x}_T = (0, 1)$ 。每个点分别是四个坐标方向上的唯一极值点。对任意非空子集 A ，取包含 A 的最小轴对齐包围盒，并在必要时把退化边界做任意小扩张。若某个点未被选中，则它在自己对应的唯一极值方向上位于该包围盒之外。空标记可由远离四点的矩形实现。因此四点被打散。

上界. 任取五个点。分别选择横坐标最小、横坐标最大、纵坐标最小、纵坐标最大的代表点，得到至多四个极值代表。至少存在一个未被选中的点 $\mathbf{x}^*$ 。把 $\mathbf{x}^*$ 标为负类，其余四点标为正类。

任何包含其余四点的轴对齐矩形都必须包含这些极值代表所确定的坐标包围盒；而 $\mathbf{x}^*$ 的两个坐标均位于全体五点的最小-最大范围内，因此也在该包围盒中。故该标记不可实现，任意五点均不能被打散。 $\square$

5.9 一维区间类与 signed intervals**5.9.1 普通区间类**

定义

$$\mathcal{H}_{\text{int}} = \{x \mapsto \mathbf{1}\{x \in [a, b]\} : a \leq b\}. \quad (5.19)$$

对排序后的 n 个点 $x_1 < \dots < x_n$ ，正标记必须构成一个连续块，或者没有正标记。因此

$$\tau_{\mathcal{H}_{\text{int}}}(n) = 1 + \frac{n(n+1)}{2}. \quad (5.20)$$

其中 1 对应空正例块， $n(n+1)/2$ 对应选择块的左右端点 $1 \leq i \leq j \leq n$ 。

于是 $\tau_{\mathcal{H}_{\text{int}}}(2) = 4$, $\tau_{\mathcal{H}_{\text{int}}}(3) = 7 < 8$, 故

$$\text{VCdim}(\mathcal{H}_{\text{int}}) = 2. \quad (5.21)$$



5.9.2 Signed intervals 的精确增长函数

定义 5.14 (Signed intervals). 令标签空间为 $\{-1, +1\}$, 定义

$$\mathcal{H}_{\text{sint}} = \{h_{a,b,s} : a \leq b, s \in \{-1, +1\}\}, \quad (5.22)$$

其中

$$h_{a,b,s}(x) = \begin{cases} s, & x \in [a, b], \\ -s, & x \notin [a, b]. \end{cases} \quad (5.23)$$

定义 5.15 (标记变化次数). 对 $\mathbf{y} = (y_1, \dots, y_n) \in \{-1, +1\}^n$, 定义相邻标记变化次数

$$\text{chg}(\mathbf{y}) = \sum_{i=1}^{n-1} \mathbf{1}\{y_i \neq y_{i+1}\}. \quad (5.24)$$

定理 5.16 (Signed intervals 的增长函数与 VC 维). 对任意 $n \geq 1$,

$$\tau_{\mathcal{H}_{\text{sint}}}(n) = 2 \sum_{j=0}^2 \binom{n-1}{j}, \quad (5.25)$$

其中约定当 $j > n-1$ 时 $\binom{n-1}{j} = 0$ 。因此

$$\text{VCdim}(\mathcal{H}_{\text{sint}}) = 3. \quad (5.26)$$

证明. 将样本排序为 $x_1 < \dots < x_n$ 。对任意 $h_{a,b,s}$, 区间内标记恒为 s , 区间外标记恒为 $-s$, 故标记序列具有形式

$$(-s)^i s^j (-s)^k, \quad i, j, k \geq 0, \quad i + j + k = n. \quad (5.27)$$

因此相邻标记至多变化两次。

反之, 任意变化次数不超过 2 的二元标记序列都可由某个 signed interval 实现:

- 零次变化时, 选择覆盖全部样本或避开全部样本的区间;
- 一次变化时, 让区间的一端越过全部样本, 使区间内块接触左端或右端;
- 两次变化时, 让区间恰好覆盖中间的连续同号块, 并选择该块标记为 s 。

所以可实现标记恰好是变化次数不超过 2 的序列。

恰有 j 次变化的序列可通过以下方式唯一确定: 先选择初始标记, 共 2 种; 再从 $n-1$ 个相邻间隙中选择 j 个变化位置, 共 $\binom{n-1}{j}$ 种。于是得到式 (5.25)。

当 $n=3$ 时, $\tau_{\mathcal{H}_{\text{sint}}}(3) = 2 \left[\binom{2}{0} + \binom{2}{1} + \binom{2}{2} \right] = 2(1+2+1) = 8$, 所以任意三个有序点均可被打散。

当 $n=4$ 时, $\tau_{\mathcal{H}_{\text{sint}}}(4) = 2 \left[\binom{3}{0} + \binom{3}{1} + \binom{3}{2} \right] = 2(1+3+3) = 14 < 16$ 。具体缺失的两个标记是 $(+1, -1, +1, -1)$, $(-1, +1, -1, +1)$, 因为它们均有三次变化。故 VC 维等于 3。□

答题方法

[25F-A-Q9, 5 分] 的标准满分结构:

1. 先按 $x_1 < \dots < x_n$ 排序;
2. 说明 signed interval 的标记至多发生两次变化;
3. 下界: 指出三个点上的任意标记最多有两次变化, 因此可实现;

4. 上界：任意四个有序点的交替标记需要三次变化，无法实现；

5. 最后写 $\text{VCdim} = 3$ 。

若只写“参数有 a, b, s 三个，所以 VC 维为 3”，不给分或只能获得极少分。

易错点、反例与失败模式

普通区间类与 signed intervals 不是同一个类：

- 普通区间只允许“区间内为正、区间外为负”，VC 维为 2；
- signed intervals 还允许其补集模式“区间内为负、区间外为正”，VC 维为 3。

补充一种标记方向不仅仅是标签重命名，而是扩大了假设类。

5.10 区间与右射线之并：增长函数与 VC 维

5.10.1 问题设定

定义 5.17 (有限区间与右射线之并). 定义

$$\mathcal{H}_{\text{ir}} = \{h_{a,b,c}(x) = \mathbf{1}\{x \in [a, b]\} \vee \mathbf{1}\{x \in [c, \infty)\} : a \leq b < c\}. \quad (5.28)$$

这里 $\vee$ 是逻辑或。

对有序点 $x_1 < \dots < x_n$ ，正类由“一个有限连续块”和“一个终端后缀块”组成。

定理 5.18 (区间-射线类的精确增长函数). 对任意 $n \geq 1$,

$$\tau_{\mathcal{H}_{\text{ir}}}(n) = 2 + 2\binom{n-1}{1} + 2\binom{n-1}{2} + \binom{n-1}{3} \quad (5.29)$$

$$= \frac{(n+1)(n^2 - n + 6)}{6}. \quad (5.30)$$

因此

$$\text{VCdim}(\mathcal{H}_{\text{ir}}) = 3. \quad (5.31)$$

证明. 对任意 $h_{a,b,c}$ ，沿实轴从左向右移动时：


1. 在 a 前标记为 0；
2. 在 $[a, b]$ 内标记为 1；
3. 在 (b, c) 内标记为 0；
4. 在 $[c, \infty)$ 内标记为 1。

因此在有序样本上的标记具有形式

$$0^i 1^j 0^k 1^\ell, \quad i, j, k, \ell \geq 0, \quad i + j + k + \ell = n. \quad (5.32)$$

反之，任意这种形式的标记均可通过把 a, b, c 放在相应相邻样本间隙中实现；若某一块为空，可把对应区间放在样本范围外，或者只使用有限区间/右射线中的一个分量。

下面按变化次数计数：



- 零次变化：全 0 与全 1，共 2 种；
- 一次变化：可从 0 变 1，也可从 1 变 0，共 $2\binom{n-1}{1}$ 种；
- 两次变化：010 与 101 两种方向，共 $2\binom{n-1}{2}$ 种；
- 三次变化：只有 0101 可实现；1010 在最右侧从 1 回到 0，与右射线的终端正类性质矛盾。因此只有 $\binom{n-1}{3}$ 种；
- 四次及以上变化均不可实现。

得到式 (5.29)。代数化简即得式 (5.30)。

当 $n = 3$ 时， $\tau_{\mathcal{H}_{\text{ir}}}(3) = 2 + 2\binom{2}{1} + 2\binom{2}{2} = 2 + 4 + 2 = 8$ ，故三个点可被打散。

当 $n = 4$ 时， $\tau_{\mathcal{H}_{\text{ir}}}(4) = 2 + 2\binom{3}{1} + 2\binom{3}{2} + \binom{3}{3} = 2 + 6 + 6 + 1 = 15 < 16$ 。缺失标记可以取 $(1, 0, 1, 0)$ ，所以任何四个有序点均不能被打散。□

答题方法

[26S-A-Q3, 8 分] 同时要求增长函数上界和 VC 维。满分答案应包含：

1. 把任意样本排序；
2. 写出模式 $0^*1^*0^*1^*$ ；
3. 说明三次变化时只有 0101 方向可行；
4. 给出式 (5.29)，或者给出一个正确的 $O(n^3)$ 上界并足以完成 VC 分析；
5. 对三个点给出打散论证；
6. 对四个点给出不可实现的 1010 标记。

若题目只要求“给一个上界”，精确公式不是必要条件；但直接数参数得到 $O(n^3)$ 时，必须解释每个参数只需考虑样本间隙，不能只写结论。

5.11 假设类之并

5.11.1 增长函数的基本上界

对任意两个二分类类，

$$(\mathcal{H}_1 \cup \mathcal{H}_2)|_C = \mathcal{H}_1|_C \cup \mathcal{H}_2|_C, \quad (5.33)$$

所以

$$\tau_{\mathcal{H}_1 \cup \mathcal{H}_2}(m) \leq \tau_{\mathcal{H}_1}(m) + \tau_{\mathcal{H}_2}(m). \quad (5.34)$$

这里通常不是等号，因为两个类可能在同一点集上产生相同标记。

5.11.2 两个类之并的 VC 维上界

定理 5.19 (两个假设类之并). 设 $d_1 = \text{VCdim}(\mathcal{H}_1) < \infty$, $d_2 = \text{VCdim}(\mathcal{H}_2) < \infty$ 。则

$$\text{VCdim}(\mathcal{H}_1 \cup \mathcal{H}_2) \leq d_1 + d_2 + 1. \quad (5.35)$$



证明. 本证明使用下一章将完整证明的 Sauer 引理: 若 $\text{VCdim}(\mathcal{H}) = d$, 则对 $m > d$,

$$\tau_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j}. \quad (5.36)$$

令 $m = d_1 + d_2 + 2$. 反设 $\mathcal{H}_1 \cup \mathcal{H}_2$ 能打散某个 m 点集. 则

$$\begin{aligned} 2^m &\leq \tau_{\mathcal{H}_1 \cup \mathcal{H}_2}(m) \\ &\leq \tau_{\mathcal{H}_1}(m) + \tau_{\mathcal{H}_2}(m) \\ &\leq \sum_{j=0}^{d_1} \binom{m}{j} + \sum_{j=0}^{d_2} \binom{m}{j}. \end{aligned} \quad (5.37)$$

由二项式系数对称性 $\binom{m}{j} = \binom{m}{m-j}$ 以及 $m - d_2 = d_1 + 2$, 有

$$\sum_{j=0}^{d_2} \binom{m}{j} = \sum_{j=d_1+2}^m \binom{m}{j}. \quad (5.38)$$

所以式 (5.37) 右端等于 $\sum_{j=0}^{d_1} \binom{m}{j} + \sum_{j=d_1+2}^m \binom{m}{j} = 2^m - \binom{m}{d_1+1} < 2^m$, 产生矛盾. 故大小为 $d_1 + d_2 + 2$ 的点集不可能被打散, 从而得到式 (5.35). $\square$

说明 5.20 (该上界不是一般等式). 总有

$$\max\{d_1, d_2\} \leq \text{VCdim}(\mathcal{H}_1 \cup \mathcal{H}_2) \leq d_1 + d_2 + 1, \quad (5.39)$$

但一般不能仅由 d_1, d_2 确定并类的精确 VC 维. 例如若 $\mathcal{H}_1 \subseteq \mathcal{H}_2$, 则并类就是 $\mathcal{H}_2$, 其 VC 维为 d_2 , 通常远小于 $d_1 + d_2 + 1$.

5.11.3 二维矩形类与三角形类之并

令 $\mathcal{R}$ = 二维轴对齐矩形假设类, $\mathcal{T}$ = 二维三角形假设类. 已知 $\text{VCdim}(\mathcal{R}) = 4$, $\text{VCdim}(\mathcal{T}) = 7$. 由定理 5.19,

$$\text{VCdim}(\mathcal{R} \cup \mathcal{T}) \leq 4 + 7 + 1 = 12. \quad (5.40)$$

另一方面, 由单调性,

$$\text{VCdim}(\mathcal{R} \cup \mathcal{T}) \geq \max\{4, 7\} = 7. \quad (5.41)$$

所以从题目给出的信息可以严格推出

$$7 \leq \text{VCdim}(\mathcal{R} \cup \mathcal{T}) \leq 12. \quad (5.42)$$

易错点、反例与失败模式

[25S-A-Q3(b), 4 分] 的题面要求“use this to determine”, 但仅凭 $\text{VCdim}(\mathcal{R}) = 4$, $\text{VCdim}(\mathcal{T}) = 7$ 和定理 5.19, 只能严格得到上界 12, 不能证明精确值等于 12。

考场中应写: $\text{VCdim}(\mathcal{R} \cup \mathcal{T}) \leq 12$ 并说明这是由所给定理得到的保证; 若题目明确要求精确值, 还需额外提供一个 12 点打散构造. 没有该构造时, 不应把上界静默写成等式。

5.11.4 多个假设类之并

定理 5.21 (多个有限 VC 类之并). 设 $\mathcal{H} = \bigcup_{i=1}^r \mathcal{H}_i$, $d = \max_{i \in [r]} \text{VCdim}(\mathcal{H}_i) \geq 3$. 则课程训练材料采用的一个显式上界为

$$\text{VCdim}(\mathcal{H}) \leq 4d \log_2(2d) + 2 \log_2 r. \quad (5.43)$$

严格地说, 右端不是整数时, 可在右端取下整或上整而不影响量级结论。

证明. 若 $\mathcal{H}$ 能打散某个大小为 $m > d$ 的点集, 则由式 (5.34) 的 r 类版本及 Sauer 引理,

$$\begin{aligned} 2^m &\leq \sum_{i=1}^r \tau_{\mathcal{H}_i}(m) \\ &\leq r \sum_{j=0}^d \binom{m}{j} \\ &\leq r \left(\frac{em}{d} \right)^d. \end{aligned} \quad (5.44)$$

由于 $d \geq 3 > e$, $\left(\frac{em}{d} \right)^d \leq m^d$, 故

$$m \leq d \log_2 m + \log_2 r. \quad (5.45)$$

下面证明: 若

$$x > 4a \log_2(2a) + 2b, \quad a \geq 1, \quad b \geq 0, \quad (5.46)$$

则

$$a \log_2 x + b < x. \quad (5.47)$$

由 $x > 4a \log_2(2a)$, 令 $y = \frac{x}{2a} > 2 \log_2(2a) \geq 2$. 对 $y \geq 2$ 有 $\log_2 y \leq y/2$, 并且 $\log_2(2a) < y/2$, 从而 $\log_2 x = \log_2(2a) + \log_2 y < y = \frac{x}{2a}$. 所以 $a \log_2 x < \frac{x}{2}$. 又由 $x > 2b$ 得 $b < x/2$, 两式相加即得式 (5.47)。

在上述引理中取 $a = d$, $b = \log_2 r$. 若 $m > 4d \log_2(2d) + 2 \log_2 r$, 则 $d \log_2 m + \log_2 r < m$, 与式 (5.45) 矛盾. 因此可被打散的最大整数 m 不超过式 (5.43) 的右端. $\square$

训练材料对应。 [MLT-HW1-Q3, 课程作业] 要求证明多个类之并的一般上界, 并在 $r = 2$ 时证明更精细的 $2d + 1$ 型上界. 它与 [25S-A-Q3(a), 5 分] 存在直接母题关系, 但仍属于课程训练材料, 不计入博资考出现频率。

5.12 笛卡尔积类与复合类的增长函数


5.12.1 笛卡尔积类

设 $\mathcal{F}_1 \subseteq \mathcal{Y}_1^{\mathcal{X}}$, $\mathcal{F}_2 \subseteq \mathcal{Y}_2^{\mathcal{X}}$. 定义笛卡尔积类

$$\mathcal{F}_1 \times \mathcal{F}_2 = \{x \mapsto (f_1(x), f_2(x)) : f_1 \in \mathcal{F}_1, f_2 \in \mathcal{F}_2\}. \quad (5.48)$$

命题 5.22 (笛卡尔积类的增长函数). 有

$$\tau_{\mathcal{F}_1 \times \mathcal{F}_2}(m) \leq \tau_{\mathcal{F}_1}(m) \tau_{\mathcal{F}_2}(m). \quad (5.49)$$



证明. 固定样本 $C = (x_1, \dots, x_m)$. 任意联合输出向量可写为 $((f_1(x_1), f_2(x_1)), \dots, (f_1(x_m), f_2(x_m)))$. 其中第一坐标输出向量至多有 $|\mathcal{F}_1|_C$ 种, 第二坐标输出向量至多有 $|\mathcal{F}_2|_C$ 种, 因此联合向量数至多为两者乘积: $|(\mathcal{F}_1 \times \mathcal{F}_2)|_C \leq |\mathcal{F}_1|_C |\mathcal{F}_2|_C$. 再对 C 取上确界即得结论. $\square$

说明 5.23. 一般只能保证“ $\leq$ ”, 不能保证等号. 原因是某些第一坐标标记与第二坐标标记的组合可能无法在同一个样本点集上同时达到各自增长函数最大值.

5.12.2 复合类

设 $\mathcal{F}_1 \subseteq \mathcal{Z}^X$, $\mathcal{F}_2 \subseteq \mathcal{Y}^Z$, 定义

$$\mathcal{F}_2 \circ \mathcal{F}_1 = \{x \mapsto f_2(f_1(x)) : f_1 \in \mathcal{F}_1, f_2 \in \mathcal{F}_2\}. \quad (5.50)$$

命题 5.24 (复合类的增长函数). 采用式 (5.6) 的多值增长函数定义时,

$$\tau_{\mathcal{F}_2 \circ \mathcal{F}_1}(m) \leq \tau_{\mathcal{F}_1}(m) \tau_{\mathcal{F}_2}(m). \quad (5.51)$$

证明. 固定 $C = (x_1, \dots, x_m)$. 首先, $\mathcal{F}_1$ 在 C 上产生至多 $\tau_{\mathcal{F}_1}(m)$ 个不同中间向量 $z = (f_1(x_1), \dots, f_1(x_m)) \in \mathcal{Z}^m$. 固定其中一个中间向量 $z = (z_1, \dots, z_m)$ 后, $\mathcal{F}_2$ 在 $z_1, \dots, z_m$ 上至多产生 $\tau_{\mathcal{F}_2}(m)$ 个输出向量 $(f_2(z_1), \dots, f_2(z_m))$. 对所有可能的中间向量求并, 得到 $|(\mathcal{F}_2 \circ \mathcal{F}_1)|_C \leq \tau_{\mathcal{F}_1}(m) \tau_{\mathcal{F}_2}(m)$. 最后对输入样本 C 取最大值. $\square$

易错点、反例与失败模式

[MLT-HW3-Q2, 课程作业] 的附件解答末尾把上界写成了等号, 但其前面的计数论证只支持 $\tau_{\mathcal{F}_2 \circ \mathcal{F}_1}(m) \leq \tau_{\mathcal{F}_1}(m) \tau_{\mathcal{F}_2}(m)$. 全文采用数学上正确的不等式, 不静默继承该笔误。

课程材料对应。

- [MLT-Final-Q5, 15 分, 课程期末题]: 笛卡尔积类增长函数;
- [MLT-HW3-Q2, 课程作业]: 复合类增长函数;
- 两者用于训练“先固定样本、再按中间标记分类计数”的证明技巧, 不是博资考真题。

5.13 增长函数、VC 维与计算复杂度的区别

表 5.1: 增长函数、VC 维、样本复杂度与计算复杂度的区别

概念	数学对象	回答的问题
增长函数	$\tau_{\mathcal{H}}(m)$	在最有利的 m 个输入点上, 假设类最多能产生多少种不同二元标记。
VC 维	$\text{VCdim}(\mathcal{H})$	最大能完整实现全部 2^m 种标记的样本规模。
样本复杂度	$m_{\mathcal{H}}(\varepsilon, \delta)$	为获得精度 ε 、置信度 $1 - \delta$ 的泛化保证, 需要多少随机样本。

概念	数学对象	回答的问题
计算复杂度	运行时间与空间, 如 $O(md)$	给定样本后, 训练、预测或求 ERM 解需要多少计算资源。

易错点、反例与失败模式

以下推理均不成立:

VC 维有限 $\nRightarrow$ ERM 可在多项式时间内求解,
VC 维较大 $\nRightarrow$ 测试误差必然较大,
参数较少 $\nRightarrow$ VC 维必然较小,
能拟合当前训练集 $\nRightarrow$ 能打散该训练输入点集.

VC 维是最坏点集上的组合表达能力, 不是某次训练结果、平均测试性能或算法运行时间。

5.14 标准识别与使用方法

- 看到一维阈值、区间、射线或若干区间之并, 先排序样本, 再数标记块或变化次数。
- 看到“至多 k 个正例”, 先数正标记位置集合: $\sum_{j=0}^k \binom{m}{j}$ 。
- 看到轴对齐几何类, 下界优先考虑标准基、十字形点或坐标极值点; 上界优先考虑每个坐标方向的极值代表和鸽巢原理。
- 看到假设类之并, 先写 $\tau_{\cup_i \mathcal{H}_i}(m) \leq \sum_i \tau_{\mathcal{H}_i}(m)$, 再接 Sauer 引理。
- 看到复合类, 先固定第一层产生的中间输出向量, 再对第二层计数。
- 看到“精确 VC 维”, 答案必须同时含下界和上界。

5.15 典型题型

例 5.25 (基础例题: 阈值类). 令 $\mathcal{H}_{\text{thr}} = \{x \mapsto \mathbf{1}\{x \leq a\} : a \in \mathbb{R}\}$ 。对 n 个有序点, 阈值可位于 $n+1$ 个样本间隙中, 因此 $\tau_{\mathcal{H}_{\text{thr}}}(n) = n+1$ 。由 $\tau_{\mathcal{H}_{\text{thr}}}(1) = 2$, $\tau_{\mathcal{H}_{\text{thr}}}(2) = 3 < 4$, 得到 $\text{VCdim}(\mathcal{H}_{\text{thr}}) = 1$ 。

例 5.26 (综合例题: 至多两个正标记块). 设某一维假设类在有序样本上产生的正类至多由两个任意有限区间组成。其标记序列最多发生四次变化, 粗略增长函数为 $O(n^4)$ 。但要计算精确 VC 维, 仍需检查:

1. 是否允许区间为空;
2. 是否允许区间相接或重叠;
3. 左右无界区域的标记是什么;
4. 某些变化方向是否因模型结构而不可实现。

这正是 signed intervals 与区间-射线类得到不同答案的原因。



例 5.27 (历年题型改写: 类之并). 设 $\text{VCdim}(\mathcal{H}_1) = 3$, $\text{VCdim}(\mathcal{H}_2) = 5$. 由定理 5.19, $\text{VCdim}(\mathcal{H}_1 \cup \mathcal{H}_2) \leq 9$. 但不能据此写成等号. 若另知 $\mathcal{H}_1 \subseteq \mathcal{H}_2$, 则精确值其实为 5.

例 5.28 (课程训练题型, 不是博资考真题). [MLT-HW3-Q1, 课程作业] 说明: 在有限定义域 $\{0, 1\}^d$ 上, 若允许深度足够的决策树逐位查询所有坐标, 则可以表示该有限域上的任意二分类函数, 因此整个定义域可被打散, VC 维达到 $|\{0, 1\}^d| = 2^d$. 该例说明 VC 维可以远大于输入维数 d . 决策树的深度、叶节点数与受限树类的 VC 分析将在决策树章节完整展开.

5.16 答题方法

答题方法

模板一: 直接计算 VC 维。

1. 明确写出候选值 d ;
2. 下界: 选择 $C = \{x_1, \dots, x_d\}$, $\forall \mathbf{y} \in \{0, 1\}^d$, 构造 $h_{\mathbf{y}}$;
3. 逐点验证 $h_{\mathbf{y}}(x_i) = y_i$;
4. 上界: 任取 $d + 1$ 个点, 构造不可实现标记;
5. 说明该上界对任意点集成立;
6. 合并上下界得到等式。

模板二: 增长函数计数。

1. 对样本排序或选择规范表示;
2. 刻画可实现标记的块结构、变化次数或正例位置集合;
3. 按互斥类别计数;
4. 检查空块、全正、全负和边界退化情况;
5. 用 $m = d$ 与 $m = d + 1$ 的增长函数比较 2^m , 确定 VC 维。

模板三: 假设类运算。

1. 固定同一个样本点集 C ;
2. 写限制类之间的集合关系;
3. 对并类使用加法计数, 对乘积或复合类使用乘法计数;
4. 若要转成 VC 上界, 明确调用 Sauer 引理;
5. 不把上界静默改写为等式。

5.17 易错点、反例与失败模式

易错点、反例与失败模式

1. 错误：“找到一个能拟合所有正例的模型，所以点集被打散。”

错因：只实现了一种标记。

正确：必须对全部 2^m 种标记逐一存在模型。
2. 错误：“这五个特殊点不能被矩形打散，所以矩形类 VC 维至多为 4。”

错因：上界需要否定任意五点。

正确：利用四个坐标极值代表，对任意五点构造不可实现标记。
3. 错误：普通区间类有两个端点参数，因此 signed intervals 也仍是 VC 维 2。

错因：额外的符号选择增加了补区间模式。

正确：signed intervals 可实现所有至多两次变化的标记，VC 维为 3。
4. 错误： $\tau_{\mathcal{H}_1 \cup \mathcal{H}_2} = \tau_{\mathcal{H}_1} + \tau_{\mathcal{H}_2}$ 。

错因：两个限制类可能产生重合标记。

正确：一般只有“ $\leq$ ”。
5. 错误： $\text{VCdim}(\mathcal{H}_1 \cup \mathcal{H}_2) = \text{VCdim}(\mathcal{H}_1) + \text{VCdim}(\mathcal{H}_2) + 1$ 。

正确：右侧只是一般上界；若一类包含另一类，实际 VC 维只等于较大类的 VC 维。
6. 错误：有限 VC 维意味着任意有限样本都不能完全拟合。

正确：有限 VC 维只限制“所有标记同时可实现”的最大规模；某些更大样本上的特定标记仍可能被完全拟合。
7. 错误：通用逼近意味着神经网络能打散任意大的有限点集，因此自动 PAC 可学习。

正确：通用逼近、有限参数网络的 VC 维、样本复杂度和训练算法效率是不同命题。

5.18 真题与训练材料对应

表 5.2: 本章真题与课程训练材料映射

题目	主要标签	满分所需核心步骤
[25S-A-Q3(a), 5 分]	假设类之并、Sauer 引理	写增长函数加法上界；在 $m = d_1 + d_2 + 2$ 处使用二项式对称性；指出缺失中间项。
[25S-A-Q3(b), 4 分]	矩形、三角形、并类	写 $\text{VCdim}(\mathcal{R}) = 4$ 、题给 $\text{VCdim}(\mathcal{T}) = 7$ ；得到上界 12；不得无证明声称精确等于 12。
[25F-A-Q9, 5 分]	Signed intervals	排序；标记变化次数至多 2；三个点可打散；四点交替标记不可实现。

题目	主要标签	满分所需核心步骤
[26S-A-Q3, 8 分]	增长函数、区间与射线之并	刻画 $0^*1^*0^*1^*$; 计数变化方向; 证明 VC 维为 3。
[MLT-Practice-Q1, 课程练习]	至多 k 个正例	增长函数为截断二项式和; VC 维为 $\min\{k, \mathcal{X} \}$ 。
[MLT-Final-Q4, 15 分, 课程期末题]	轴对齐下盒	标准基下界; 坐标最大值代表与鸽巢原理上界。
[MLT-Final-Q5, 15 分, 课程期末题]	笛卡尔积类	固定样本; 分别计数两个坐标输出; 取乘积上界。
[MLT-HW1-Q3, 课程作业]	多个类之并	Sauer 上界; $2^m \leq r(em/d)^d$; 解隐式不等式。
[MLT-HW3-Q2, 课程作业]	复合类	先枚举中间表示, 再枚举第二层输出; 结论为上界而非一般等式。

5.19 快速自测

快速自测

1. 为证明 $\text{VCdim}(\mathcal{H}) \leq d$, 为什么展示一个不能被打散的 $(d+1)$ 点集不够?
2. 普通区间、signed intervals、区间与右射线之并的 VC 维分别是多少? 它们的标记变化模式有何差别?
3. 若 $|\mathcal{X}| = 5$ 、 $k = 8$, 则 $\text{VCdim}(\mathcal{H}_{\leq k})$ 是多少? 为什么不是 8?
4. 已知 $\text{VCdim}(\mathcal{H}_1) = 4$ 、 $\text{VCdim}(\mathcal{H}_2) = 7$, 能否仅据此断言 $\text{VCdim}(\mathcal{H}_1 \cup \mathcal{H}_2) = 12$?
5. 复合类增长函数证明中, 随机性是否发挥作用? 该证明本质上是概率论证明还是组合计数证明?



第六章 Sauer 引理、统计学习基本定理与 VC 样本复杂度

6.1 重要性等级与考情定位

重要性等级：S

- Sauer–Shelah–Perles 引理把“有限 VC 维”转化为“有限样本上的有效假设数仅按多项式增长”，是从组合表达能力走向概率泛化保证的关键桥梁。
- 统计学习基本定理在二分类零一损失下给出：有限 VC 维 $\iff$ 一致收敛 $\iff$ ERM 可学习 $\iff$ PAC 可学习。资格考试中必须同时记住其假设、等价条件、适用边界与样本复杂度。
- [25F-A-MQ8, 1 分 bonus] 直接考查 Sauer 引理的结论；[26S-A-MQ2, 0.5 分] 要求识别精确二项式和上界；[26S-A-MQ4, 0.5 分] 要求识别有限 VC 维与 ERM 的可实现 PAC 保证。
- [25S-A-Q3(a), 5 分] 虽未要求重新证明 Sauer 引理，但其类之并的 VC 上界证明必须调用本章结果。
- 本章的高频失分点包括：把 Sauer 上界误写成等式；把可实现与 agnostic 样本率混淆；忘记基本定理只在特定学习设定下成立；或把统计可学习性误认为存在高效训练算法。

6.2 从 VC 维到有效假设类大小

6.2.1 增长函数的再次表述

设 $\mathcal{H} \subseteq \{0, 1\}^{\mathcal{X}}$ 。对有限点集 $C = \{x_1, \dots, x_m\} \subseteq \mathcal{X}$ ，回顾其限制类 $\mathcal{H}|_C = \{(h(x_1), \dots, h(x_m)) : h \in \mathcal{H}\} \subseteq \{0, 1\}^m$ ，以及增长函数

$$\tau_{\mathcal{H}}(m) = \max_{\substack{C \subseteq \mathcal{X} \\ |C|=m}} |\mathcal{H}|_C|. \quad (6.1)$$

若 $\text{VCdim}(\mathcal{H}) = d$ ，则：

$$m \leq d \implies \tau_{\mathcal{H}}(m) = 2^m, \quad (6.2)$$

$$m > d \implies \tau_{\mathcal{H}}(m) < 2^m. \quad (6.3)$$

式 (6.2) 的原因是：若某个 d 点集被打散，则它的任意 $m \leq d$ 点子集也被打散。式 (6.3) 只说明增长不再达到全部 2^m 种标记；Sauer 引理进一步给出精确的最坏上界。



6.2.2 二项式和记号

定义

$$S(m, d) := \sum_{j=0}^d \binom{m}{j}, \quad (6.4)$$

并约定 $\binom{m}{j} = 0$ 当 $j < 0$ 或 $j > m$ 。因此若 $d \geq m$, 则 $S(m, d) = \sum_{j=0}^m \binom{m}{j} = 2^m$ 。

6.3 Sauer–Shelah–Perles 引理

引理 6.1 (Sauer–Shelah–Perles 引理). 设 $\mathcal{H} \subseteq \{0, 1\}^{\mathcal{X}}$, $\text{VCdim}(\mathcal{H}) \leq d < \infty$ 。则对任意 $m \in \mathbb{N}_0$,

$$\tau_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j}. \quad (6.5)$$

特别地, 当 $1 \leq d \leq m$ 时,

$$\tau_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d. \quad (6.6)$$

结论的含义。 若 d 固定而 $m \rightarrow \infty$, 则 $\tau_{\mathcal{H}}(m) = O(m^d)$ 。因此, 虽然 $\mathcal{H}$ 本身可能是不可数的, 但在任意 m 个训练输入上, 它能产生的不同预测向量至多按 m^d 级增长, 而不是按 2^m 指数增长。

易错点、反例与失败模式

以下两个命题不能混淆:

$$\begin{aligned} \text{VCdim}(\mathcal{H}) = d &\implies \tau_{\mathcal{H}}(m) = 2^m \quad \text{仅对 } m \leq d, \\ \text{VCdim}(\mathcal{H}) = d &\implies \tau_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j} \quad \text{对所有 } m. \end{aligned}$$

当 $m > d$ 时, Sauer 引理通常只是上界, 不保证达到等号。

6.4 Sauer 引理的完整归纳证明

6.4.1 证明结构

证明的核心不是直接枚举假设参数, 而是把一个 m 点限制类拆成:


- 删除最后一个点后, 至少能以一种标签扩展的模式;
- 删除最后一个点后, 能同时以标签 0 和 1 扩展的模式。

第二类模式的 VC 维至少下降 1, 从而产生 Pascal 递推。

引理 6.1 的二项式和上界. 对 $m + d$ 做归纳。

边界情形一: $m = 0$. 空点集上只有一个空标记, 因此 $\tau_{\mathcal{H}}(0) = 1 = \binom{0}{0}$ 。

边界情形二: $d = 0$. 若 $\text{VCdim}(\mathcal{H}) = 0$, 则任意单点都不能被打散。因此任意两个假设不可能在某个点上取不同标签; 否则该点同时可实现 0 和 1, 会被打散。故对任意有限 C , $|\mathcal{H}|_C \leq 1$, 而 $\sum_{j=0}^0 \binom{m}{j} = 1$ 。



归纳步骤。 设 $m \geq 1, d \geq 1$, 并假设结论对更小的 $m + d$ 成立。固定任意大小为 m 的点集 $C = \{x_1, \dots, x_{m-1}, x_m\}$, $C' = C \setminus \{x_m\}$ 。

对每个 $\mathbf{u} = (u_1, \dots, u_{m-1}) \in \{0, 1\}^{m-1}$, 考察它是否能以最后一位 0 或 1 扩展为 $\mathcal{H}|_C$ 中的标记。定义

$$A := \{\mathbf{u} : (\mathbf{u}, 0) \in \mathcal{H}|_C \text{ 或 } (\mathbf{u}, 1) \in \mathcal{H}|_C\}, \quad (6.7)$$

$$B := \{\mathbf{u} : (\mathbf{u}, 0) \in \mathcal{H}|_C \text{ 且 } (\mathbf{u}, 1) \in \mathcal{H}|_C\}. \quad (6.8)$$

对每个 $\mathbf{u} \in A \setminus B$, 它只有一个可行扩展; 对每个 $\mathbf{u} \in B$, 它有两个可行扩展。因此

$$|\mathcal{H}|_C| = |A \setminus B| + 2|B| = |A| + |B|. \quad (6.9)$$

集合 A 正是 $\mathcal{H}$ 在 C' 上的限制类: $A = \mathcal{H}|_{C'}$ 。故 $\text{VCdim}(A) \leq d$ 。由归纳假设,

$$|A| \leq \sum_{j=0}^d \binom{m-1}{j}. \quad (6.10)$$

下面证明 $\text{VCdim}(B) \leq d-1$ 。反设 B 能打散某个大小为 d 的子集 $T \subseteq C'$ 。任取 $T \cup \{x_m\}$ 上的任意标记 $(\mathbf{y}, b) \in \{0, 1\}^d \times \{0, 1\}$ 。因为 B 打散 T , 存在某个 $\mathbf{u} \in B$, 其在 T 上的限制等于 $\mathbf{y}$ 。又因为 $\mathbf{u} \in B$, $\mathbf{u}$ 对最后一点的两个扩展 $(\mathbf{u}, 0)$, $(\mathbf{u}, 1)$ 均由 $\mathcal{H}$ 中某些假设实现。选择扩展标签为 b 的假设, 即可实现 $(\mathbf{y}, b)$ 。因此 $\mathcal{H}$ 打散 $T \cup \{x_m\}$, 其大小为 $d+1$, 与 $\text{VCdim}(\mathcal{H}) \leq d$ 矛盾。故 $\text{VCdim}(B) \leq d-1$ 。再次使用归纳假设,

$$|B| \leq \sum_{j=0}^{d-1} \binom{m-1}{j}. \quad (6.11)$$

将式 (6.10) 与式 (6.11) 代入式 (6.9):

$$\begin{aligned} |\mathcal{H}|_C| &\leq \sum_{j=0}^d \binom{m-1}{j} + \sum_{j=0}^{d-1} \binom{m-1}{j} \\ &= \sum_{j=0}^d \left[\binom{m-1}{j} + \binom{m-1}{j-1} \right] \\ &= \sum_{j=0}^d \binom{m}{j}, \end{aligned} \quad (6.12)$$

其中最后一步使用 Pascal 恒等式 $\binom{m}{j} = \binom{m-1}{j} + \binom{m-1}{j-1}$ 。由于 C 任意, 对所有大小为 m 的点集取最大值, 得到式 (6.5)。□


6.4.2 多项式形式的证明

式 (6.6) 的证明. 设 $1 \leq d \leq m$, 令 $t = \frac{d}{m} \in (0, 1]$ 。由二项式定理, $(1+t)^m = \sum_{j=0}^m \binom{m}{j} t^j$ 。对 $0 \leq j \leq d$, 由于 $0 < t \leq 1$, 有 $t^j \geq t^d$ 。因此

$$(1+t)^m \geq \sum_{j=0}^d \binom{m}{j} t^j \geq t^d \sum_{j=0}^d \binom{m}{j}. \quad (6.13)$$

从而

$$\sum_{j=0}^d \binom{m}{j} \leq \frac{(1+t)^m}{t^d}. \quad (6.14)$$



再使用 $1 + t \leq e^t$, 得到

$$\sum_{j=0}^d \binom{m}{j} \leq \frac{e^{mt}}{t^d} = \frac{e^d}{(d/m)^d} = \left(\frac{em}{d}\right)^d. \quad (6.15)$$

□

6.4.3 Sauer 上界何时达到等号

定义 6.2 (最大类). 若 $\text{VCdim}(\mathcal{H}) = d$ 且对所有适用的 m , $\tau_{\mathcal{H}}(m) = \sum_{j=0}^d \binom{m}{j}$, 则称 $\mathcal{H}$ 在相应意义下是最大类 (maximum class)。

例 6.3 (至多 d 个正例的类达到 Sauer 上界). 若定义域足够大, 令 $\mathcal{H}_{\leq d} = \{h: \mathcal{X} \rightarrow \{0, 1\} : |\{x: h(x) = 1\}| \leq d\}$ 。上一章已证明 $\text{VCdim}(\mathcal{H}_{\leq d}) = d$ 且 $\tau_{\mathcal{H}_{\leq d}}(m) = \sum_{j=0}^d \binom{m}{j}$ 。因此 Sauer 上界可以是紧的。

例 6.4 (阈值类与区间类). 实数轴阈值类的 VC 维为 1, 其增长函数为 $\tau(m) = m + 1 = \binom{m}{0} + \binom{m}{1}$, 达到 Sauer 上界。

普通区间类的 VC 维为 2, 其增长函数为 $\tau(m) = 1 + \frac{m(m+1)}{2} = \binom{m}{0} + \binom{m}{1} + \binom{m}{2}$, 也达到 Sauer 上界。

例 6.5 (Sauer 上界可以较松). signed intervals 的 VC 维为 3, 但其增长函数为 $\tau_{\text{sint}}(m) = 2 \sum_{j=0}^2 \binom{m-1}{j} = m^2 - m + 2$, 只按 m^2 增长; 而 Sauer 上界为 $\sum_{j=0}^3 \binom{m}{j} = \Theta(m^3)$ 。因此 VC 维只决定最坏增长上界, 并不唯一决定精确增长函数。

6.5 从点态集中到一致收敛: 为什么需要增长函数

对固定假设 h , Hoeffding 不等式给出 $\Pr(|L_P(h) - \hat{L}_S(h)| > \varepsilon) \leq 2e^{-2m\varepsilon^2}$ 。但 ERM 输出 $\hat{h} = A(S)$ 依赖样本, 不能把固定 h 的点态结论直接代入 $\hat{h}$ 。

有限类情形可对全部 $|\mathcal{H}|$ 个假设做 union bound; 无限类情形则不能直接“乘以 $|\mathcal{H}|$ ”。关键观察是: 在某个固定的 $2m$ 点联合样本上, 不同假设真正产生的不同预测向量至多为 $\tau_{\mathcal{H}}(2m)$ 。因此可先对联合样本条件化, 再对有限个限制模式做 union bound。

6.6 二分类零一损失下的 VC 偏差 inequality

6.6.1 损失函数类

设 $Z = (X, Y) \sim P$, $Y \in \{0, 1\}$, 并定义

$$f_h(z) = \mathbf{1}\{h(x) \neq y\}, \quad h \in \mathcal{H}. \quad (6.16)$$


令 $\mathcal{F} = \{f_h : h \in \mathcal{H}\}$ 。记

$$Pf_h = \mathbb{E}_{Z \sim P}[f_h(Z)] = L_P(h), \quad (6.17)$$

$$P_S f_h = \frac{1}{m} \sum_{i=1}^m f_h(Z_i) = \hat{L}_S(h). \quad (6.18)$$

定义统一偏差

$$\Delta_{\mathcal{H}}(S) := \sup_{h \in \mathcal{H}} |Pf_h - P_S f_h|. \quad (6.19)$$



对固定带标签样本 $(z_1, \dots, z_n) = ((x_1, y_1), \dots, (x_n, y_n))$, 损失向量满足 $f_h(z_i) = h(x_i) \oplus y_i$, 其中 $\oplus$ 是异或。固定 $\mathbf{y}$ 后, 映射 $(h(x_1), \dots, h(x_n)) \mapsto (f_h(z_1), \dots, f_h(z_n))$ 是逐坐标双射, 因此

$$|\{(f_h(z_1), \dots, f_h(z_n)) : h \in \mathcal{H}\}| \leq \tau_{\mathcal{H}}(n). \quad (6.20)$$

6.6.2 双样本对称化

引理 6.6 (双样本对称化). 令 $S = (Z_1, \dots, Z_m) \sim P^m$, $S' = (Z'_1, \dots, Z'_m) \sim P^m$ 相互独立。若 $m\varepsilon^2 \geq 2$, 则

$$\Pr(\Delta_{\mathcal{H}}(S) > \varepsilon) \leq 2 \Pr_{S, S'} \left(\sup_{h \in \mathcal{H}} |P_{S'} f_h - P_S f_h| > \frac{\varepsilon}{2} \right). \quad (6.21)$$

证明. 固定一个满足 $\Delta_{\mathcal{H}}(S) > \varepsilon$ 的样本 S 。为简化表述, 假设上确界可达; 若不可达, 可选取任意 $\eta > 0$ 的近似最大化假设, 最后令 $\eta \downarrow 0$ 。

于是存在 $h_S \in \mathcal{H}$ 使 $|P f_{h_S} - P_S f_{h_S}| > \varepsilon$ 。由于 $f_{h_S}(Z) \in \{0, 1\}$, $\text{Var}(f_{h_S}(Z)) \leq \frac{1}{4}$ 。故 $\text{Var}(P_{S'} f_{h_S}) \leq \frac{1}{4m}$ 。由 Chebyshev 不等式,

$$\begin{aligned} \Pr_{S'} \left(|P_{S'} f_{h_S} - P f_{h_S}| > \frac{\varepsilon}{2} \right) &\leq \frac{1/(4m)}{\varepsilon^2/4} \\ &= \frac{1}{m\varepsilon^2} \leq \frac{1}{2}. \end{aligned} \quad (6.22)$$

因此, 以至少 $1/2$ 的条件概率, $|P_{S'} f_{h_S} - P f_{h_S}| \leq \frac{\varepsilon}{2}$ 。在该事件上, 由反三角不等式,

$$\begin{aligned} |P_{S'} f_{h_S} - P_S f_{h_S}| &\geq |P f_{h_S} - P_S f_{h_S}| - |P_{S'} f_{h_S} - P f_{h_S}| \\ &> \varepsilon - \frac{\varepsilon}{2} = \frac{\varepsilon}{2}. \end{aligned} \quad (6.23)$$

因此每个坏样本 S 至少以 $1/2$ 的 ghost sample 概率被右侧事件识别。对 S 取期望即得式 (6.21)。□

6.6.3 条件化后的随机交换

给定 S, S' , 引入独立 Rademacher 随机变量 $\sigma_1, \dots, \sigma_m \stackrel{\text{i.i.d.}}{\sim} \text{Unif}\{-1, +1\}$ 。在第 i 对样本 (Z_i, Z'_i) 内:

- 若 $\sigma_i = +1$, 保持原顺序;
- 若 $\sigma_i = -1$, 交换 Z_i 与 Z'_i 。

由于 (Z_i, Z'_i) 同分布且可交换, 随机交换不改变 (S, S') 的联合分布。

对固定 h 定义


$$D_h(\boldsymbol{\sigma}) = \frac{1}{m} \sum_{i=1}^m \sigma_i (f_h(Z'_i) - f_h(Z_i)). \quad (6.24)$$

固定 S, S' 后, 每项 $\sigma_i (f_h(Z'_i) - f_h(Z_i)) \in [-1, 1]$ 相互独立且均值为零。由 Hoeffding 不等式, 对任意 $t > 0$,

$$\Pr_{\boldsymbol{\sigma}} (|D_h(\boldsymbol{\sigma})| > t \mid S, S') \leq 2 \exp \left(-\frac{mt^2}{2} \right). \quad (6.25)$$

定理 6.7 (VC 统一偏差 inequality: 基本版本). 设 $\mathcal{H}$ 是二分类假设类, 损失为零一损失。若 $m\varepsilon^2 \geq 2$, 则

$$\Pr_S \left(\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| > \varepsilon \right) \leq 4\tau_{\mathcal{H}}(2m) \exp \left(-\frac{m\varepsilon^2}{8} \right). \quad (6.26)$$



根据附件结论所作的推导补充

定理 6.7 是依据附件中“ghost sample 对称化、联合样本限制类和 Hoeffding 控制”所补足的一套显式常数推导。其常数不是统计学习基本定理中最紧的常数，但证明短、条件清楚，适合作为资格考试中的标准证明框架。

证明. 由引理 6.6，只需控制 $\Pr_{S,S'}(\sup_{h \in \mathcal{H}} |P_{S'} f_h - P_S f_h| > \frac{\varepsilon}{2})$ 。对 S, S' 条件化，并使用随机交换表示。在联合的至多 $2m$ 个输入点上，不同 h 产生的不同损失向量数由式 (6.20) 至多为 $\tau_{\mathcal{H}}(2m)$ 。对每个不同限制模式，令式 (6.25) 中 $t = \frac{\varepsilon}{2}$ ，得到

$$\Pr_{\sigma} \left(|D_h(\sigma)| > \frac{\varepsilon}{2} \mid S, S' \right) \leq 2 \exp \left(-\frac{m\varepsilon^2}{8} \right). \quad (6.27)$$

对至多 $\tau_{\mathcal{H}}(2m)$ 个不同模式使用 union bound:

$$\Pr_{\sigma} \left(\sup_{h \in \mathcal{H}} |D_h(\sigma)| > \frac{\varepsilon}{2} \mid S, S' \right) \leq 2\tau_{\mathcal{H}}(2m) \exp \left(-\frac{m\varepsilon^2}{8} \right). \quad (6.28)$$

最后解除对 S, S' 的条件化，并乘上对称化引理中的因子 2，即得式 (6.26)。□

推论 6.8 (增长函数形式的高概率偏差界). 对任意 $\delta \in (0, 1)$ ，以概率至少 $1 - \delta$ ，

$$\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq \sqrt{\frac{8}{m} \ln \frac{4\tau_{\mathcal{H}}(2m)}{\delta}}. \quad (6.29)$$

证明. 令式 (6.26) 的右端等于 δ ，即取 $\varepsilon = \sqrt{\frac{8}{m} \ln \frac{4\tau_{\mathcal{H}}(2m)}{\delta}}$ 。由于 $m\varepsilon^2 = 8 \ln \frac{4\tau_{\mathcal{H}}(2m)}{\delta} > 8 \ln 4 > 2$ ，定理所需条件自动满足。□

推论 6.9 (有限 VC 维的基本统一偏差界). 若 $\text{VCdim}(\mathcal{H}) = d \geq 1$ ， $m \geq d$ ，则以概率至少 $1 - \delta$ ，

$$\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq \sqrt{\frac{8}{m} \left[d \ln \left(\frac{2em}{d} \right) + \ln \frac{4}{\delta} \right]}. \quad (6.30)$$

证明. 由 Sauer 引理， $\tau_{\mathcal{H}}(2m) \leq \left(\frac{2em}{d} \right)^d$ 。代入式 (6.29) 即得。□

说明 6.10 (重复输入点). 联合样本中可能出现重复输入点。重复点不会增加可实现标记数；把重复点删除后，限制模式数只会减少。因此使用 $\tau_{\mathcal{H}}(2m)$ 作为上界仍然成立。

6.7 Agnostic ERM 的 VC 泛化界


设 $\hat{h} \in \arg \min_{h \in \mathcal{H}} \hat{L}_S(h)$ 。令 $L_{\mathcal{H}}^* = \inf_{h \in \mathcal{H}} L_P(h)$ 。

命题 6.11 (统一偏差推出 agnostic ERM 保证). 若某个事件上

$$\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq \alpha, \quad (6.31)$$

则同一事件上

$$L_P(\hat{h}) \leq L_{\mathcal{H}}^* + 2\alpha. \quad (6.32)$$



证明. 任取 $\eta > 0$, 选择 $h_\eta \in \mathcal{H}$ 使 $L_P(h_\eta) \leq L_{\mathcal{H}}^* + \eta$. 在事件 (6.31) 上,

$$\begin{aligned} L_P(\hat{h}) &\leq \hat{L}_S(\hat{h}) + \alpha \\ &\leq \hat{L}_S(h_\eta) + \alpha \\ &\leq L_P(h_\eta) + 2\alpha \\ &\leq L_{\mathcal{H}}^* + 2\alpha + \eta. \end{aligned} \quad (6.33)$$

令 $\eta \downarrow 0$. □

推论 6.12 (Agnostic ERM 的基本 VC 上界). 若 $\text{VCdim}(\mathcal{H}) = d \geq 1$, $m \geq d$, 则以概率至少 $1 - \delta$,

$$L_P(\hat{h}) - L_{\mathcal{H}}^* \leq 2\sqrt{\frac{8}{m} \left[d \ln \left(\frac{2em}{d} \right) + \ln \frac{4}{\delta} \right]}. \quad (6.34)$$

特别地, 要使超额风险不超过 ε , 一个充分条件是

$$m\varepsilon^2 \geq 32 \left[d \ln \left(\frac{2em}{d} \right) + \ln \frac{4}{\delta} \right]. \quad (6.35)$$

式 (6.35) 是含 m 的隐式条件. 反解其量级得到

$$m = O \left(\frac{d \ln(1/\varepsilon) + \ln(1/\delta)}{\varepsilon^2} \right). \quad (6.36)$$

易错点、反例与失败模式

式 (6.36) 是由基础 Sauer 引理和简单 union-bound 型 VC 不等式直接推出的上界, 含有一个额外的 $\ln(1/\varepsilon)$ 因子。

统计学习基本定理的精细版本给出更紧的 $\Theta \left(\frac{d + \ln(1/\delta)}{\varepsilon^2} \right)$ 。考试中必须区分:

- 当前证明能够直接推出的上界;
- 参考书定量基本定理给出的最优量级。

不得把较粗证明的结论声称最紧结果。

6.8 可实现情形的 VC 泛化界

6.8.1 坏一致假设事件


设目标函数 $c \in \mathcal{H}$, $Y = c(X)$, 且 ERM 输出 $\hat{h}$. 由于任务可实现, $\hat{L}_S(c) = 0$, 故任意 ERM 输出满足 $\hat{L}_S(\hat{h}) = 0$.

定义坏事件

$$\mathcal{B}_\varepsilon(S) = \left\{ \exists h \in \mathcal{H} : L_{D,c}(h) > \varepsilon, \hat{L}_{S,c}(h) = 0 \right\}. \quad (6.37)$$

定理 6.13 (可实现 VC 界: 双样本基本版本). 若 $m\varepsilon \geq 8 \ln 2$, 则

$$\Pr_S(\mathcal{B}_\varepsilon(S)) \leq 2\tau_{\mathcal{H}}(2m) \exp \left(-\frac{m\varepsilon}{4} \right). \quad (6.38)$$



根据附件结论所作的推导补充

该证明补足了附件中“可实现 ERM 的坏一致假设、双样本见证和增长函数”之间的连接步骤。所得常数不是唯一可能的常数，但所有随机性来源和事件包含关系均被显式写出。

证明. 设 S 满足坏事件，并选取一个坏一致假设 $h_S: p := L_{D,c}(h_S) > \varepsilon$, $\hat{L}_{S,c}(h_S) = 0$. 取独立 ghost sample $S' = (X'_1, \dots, X'_m) \sim D^m$. 令 $N_{h_S} = \sum_{i=1}^m \mathbf{1}\{h_S(X'_i) \neq c(X'_i)\}$. 条件于 S 后, $N_{h_S} \sim \text{Binomial}(m, p)$, $\mathbb{E}[N_{h_S}] = mp$. 乘法 Chernoff 界给出

$$\Pr\left(N_{h_S} < \frac{mp}{2} \mid S\right) \leq e^{-mp/8} \leq e^{-m\varepsilon/8} \leq \frac{1}{2}. \quad (6.39)$$

因此，以至少 $1/2$ 的条件概率， $\hat{L}_{S',c}(h_S) = \frac{N_{h_S}}{m} \geq \frac{p}{2} > \frac{\varepsilon}{2}$. 于是

$$\Pr_S(\mathcal{B}_\varepsilon) \leq 2 \Pr_{S,S'}\left(\exists h \in \mathcal{H} : \hat{L}_{S,c}(h) = 0, \hat{L}_{S',c}(h) > \varepsilon/2\right). \quad (6.40)$$

对 S, S' 条件化，并在每对 (X_i, X'_i) 内做独立随机交换。固定一个假设 h ，定义其相对于目标 c 的分歧指标 $g_h(x) = \mathbf{1}\{h(x) \neq c(x)\}$. 若交换后满足 $\hat{L}_{S,c}(h) = 0$, $\hat{L}_{S',c}(h) > \varepsilon/2$, 则联合 $2m$ 个样本点中至少有 $k > \frac{\varepsilon m}{2}$ 个分歧点，并且这些分歧点必须全部被分配到 S' 一侧。

若某一对中两个元素都是分歧点，则该事件概率为零；否则每个分歧点必须在随机交换中落到指定一侧，其概率至多为 $2^{-k} \leq 2^{-\varepsilon m/2} = \exp\left(-\frac{\ln 2}{2}\varepsilon m\right) \leq \exp\left(-\frac{\varepsilon m}{4}\right)$. 固定联合输入点后，分歧向量 $(g_h(x_1), \dots, g_h(x_{2m}))$ 与预测向量 $(h(x_1), \dots, h(x_{2m}))$ 通过和固定目标向量逐坐标异或一一对应，故不同分歧模式至多为 $\tau_{\mathcal{H}}(2m)$. 对所有模式使用 union bound: $\Pr_{S,S'}\left(\exists h : \hat{L}_{S,c}(h) = 0, \hat{L}_{S',c}(h) > \varepsilon/2\right) \leq \tau_{\mathcal{H}}(2m)e^{-m\varepsilon/4}$. 代入式 (6.40) 即得结论。□

推论 6.14 (有限 VC 维下的一致 ERM 保证). 若 $\text{VCdim}(\mathcal{H}) = d \geq 1$, $m \geq d$, 则

$$\Pr(L_{D,c}(\hat{h}) > \varepsilon) \leq 2 \left(\frac{2em}{d}\right)^d \exp\left(-\frac{m\varepsilon}{4}\right), \quad (6.41)$$

只要 $m\varepsilon \geq 8 \ln 2$. 因此，一个充分的隐式样本量条件为

$$m\varepsilon \geq 4 \left[d \ln\left(\frac{2em}{d}\right) + \ln \frac{2}{\delta} \right]. \quad (6.42)$$

其量级为

$$m = O\left(\frac{d \ln(1/\varepsilon) + \ln(1/\delta)}{\varepsilon}\right). \quad (6.43)$$

为什么可实现情形是 $1/\varepsilon$ 而不是 $1/\varepsilon^2$. 可实现证明控制的是单侧事件: $L(h) > \varepsilon$ 但 $\hat{L}(h) = 0$. 固定坏假设在训练集上保持零误差的概率按 $(1 - \varepsilon)^m \approx e^{-m\varepsilon}$ 衰减。

Agnostic 证明则必须估计经验风险与总体风险的双侧偏差，样本均值的典型波动为 $m^{-1/2}$ ，因此精度 ε 需要 $m = \Theta(\varepsilon^{-2})$ 级样本。

6.9 统计学习基本定理：定性版本

定理 6.15 (统计学习基本定理). 设 $\mathcal{H} \subseteq \{0, 1\}^{\mathcal{X}}$, 损失为零一损失，样本为独立同分布样本。在标准分布无关二分类设定下，下列命题等价：

1. $\mathcal{H}$ 具有一致收敛性质；

2. 任意 ERM 规则都是 $\mathcal{H}$ 的成功 agnostic PAC 学习器;
3. $\mathcal{H}$ 是 agnostic PAC 可学习的;
4. $\mathcal{H}$ 是可实现 PAC 可学习的;
5. 任意 ERM 规则都是 $\mathcal{H}$ 的成功可实现 PAC 学习器;
6. $\text{VCdim}(\mathcal{H}) < \infty$.

6.9.1 完整蕴含关系

证明. 用 (i) 表示定理中的第 i 个命题。

(1) $\Rightarrow$ (2). 若一致收敛成立, 则对任意 ε, δ , 样本量足够大时, 以概率至少 $1 - \delta$, $\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| \leq \frac{\varepsilon}{2}$. 由命题 6.11, 任意 ERM 输出 $\hat{h}$ 满足 $L_P(\hat{h}) \leq \inf_{h \in \mathcal{H}} L_P(h) + \varepsilon$. 故任意 ERM 都是 agnostic PAC 学习器。

(2) $\Rightarrow$ (3). 若任意 ERM 都成功, 则至少存在一个成功学习算法, 故 agnostic PAC 可学习。

(3) $\Rightarrow$ (4). 在可实现设定下, $\inf_{h \in \mathcal{H}} L_P(h) = 0$. Agnostic PAC 保证立即退化为 $L_P(A(S)) \leq \varepsilon$ 。

(1) $\Rightarrow$ (5). 这也可由 (1) $\Rightarrow$ (2) 和 agnostic 到可实现的特化得到。更直接地, 在可实现设定中, ERM 有 $\hat{L}_S(\hat{h}) = 0$. 若统一偏差不超过 ε , 则 $L_P(\hat{h}) \leq \hat{L}_S(\hat{h}) + \varepsilon = \varepsilon$ 。

(5) $\Rightarrow$ (4). 显然: 若任意 ERM 成功, 则存在一个成功学习算法。

(4) $\Rightarrow$ (6). 反设 $\text{VCdim}(\mathcal{H}) = \infty$. 固定精度和置信参数 $\varepsilon_0 = \frac{1}{8}$, $\delta_0 < \frac{1}{7}$. 若 $\mathcal{H}$ 可实现 PAC 可学习, 则存在某个有限样本量 $m_0 = m_{\mathcal{H}}(\varepsilon_0, \delta_0)$. 由于 VC 维无限, 存在一个大小为 $2m_0$ 的点集 $C \subseteq \mathcal{X}$ 被 $\mathcal{H}$ 打散。因此 $\mathcal{H}|_C$ 包含 C 上所有二元标记函数。

对任意接收 m_0 个样本的学习算法, No Free Lunch 的有限域构造给出某个分布 P 和某个可实现目标 $f \in \mathcal{H}$, 使 $\Pr(L_P(A(S)) \geq \frac{1}{8}) \geq \frac{1}{7}$. 这与失败概率必须小于 $\delta_0 < 1/7$ 矛盾。故 $\text{VCdim}(\mathcal{H}) < \infty$ 。

(6) $\Rightarrow$ (1). 若 $\text{VCdim}(\mathcal{H}) = d < \infty$, 由 Sauer 引理, $\tau_{\mathcal{H}}(2m) \leq \sum_{j=0}^d \binom{2m}{j} \leq \left(\frac{2em}{d}\right)^d$ (对 m 足够大)。由定理 6.7, 对任意固定 $\varepsilon > 0$, $\Pr\left(\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)| > \varepsilon\right) \leq 4 \left(\frac{2em}{d}\right)^d e^{-m\varepsilon^2/8}$. 右侧的对数为 $\ln 4 + d \ln\left(\frac{2em}{d}\right) - \frac{m\varepsilon^2}{8}$. 其中正项仅按 $\ln m$ 增长, 而负项按 m 线性下降, 故右侧随 $m \rightarrow \infty$ 趋于零。因此对任意 ε, δ , 存在有限 m 使统一偏差失败概率不超过 δ , 即 $\mathcal{H}$ 具有一致收敛性质。□

证明或推导框架

基本定理的识别链:

有限 VC $\xrightarrow{\text{Sauer}}$ 有限样本有效大小为多项式 $\xrightarrow{\text{对称化} + \text{集中}}$ 一致收敛 $\xrightarrow{\text{ERM 风险比较}}$ PAC

逆向使用:

无限 VC $\xrightarrow{\text{任意大点集可打散}}$ 嵌入所有有限标记任务 $\xrightarrow{\text{No Free Lunch}}$ 不可分布无关 PAC 学习

6.10 统计学习基本定理：定量版本

定理 6.16 (定量统计学习基本定理). 设 $\text{VCdim}(\mathcal{H}) = d < \infty$, 任务为二分类, 损失为零一损失. 存在与 $\mathcal{H}, d, \varepsilon, \delta$ 无关的绝对常数 $0 < C_1 \leq C_2 < \infty$, 使下列结论成立.

一致收敛样本复杂度。

$$C_1 \frac{d + \ln(1/\delta)}{\varepsilon^2} \leq m_{\mathcal{H}}^{\text{UC}}(\varepsilon, \delta) \leq C_2 \frac{d + \ln(1/\delta)}{\varepsilon^2}. \quad (6.44)$$

Agnostic PAC 样本复杂度。

$$C_1 \frac{d + \ln(1/\delta)}{\varepsilon^2} \leq m_{\mathcal{H}}^{\text{agn}}(\varepsilon, \delta) \leq C_2 \frac{d + \ln(1/\delta)}{\varepsilon^2}. \quad (6.45)$$

可实现 PAC 样本复杂度。

$$C_1 \frac{d + \ln(1/\delta)}{\varepsilon} \leq m_{\mathcal{H}}^{\text{real}}(\varepsilon, \delta) \leq C_2 \frac{d \ln(1/\varepsilon) + \ln(1/\delta)}{\varepsilon}. \quad (6.46)$$

说明 6.17 (三种结论的精度依赖).

统一收敛: $\Theta(\varepsilon^{-2})$,

agnostic PAC: $\Theta(\varepsilon^{-2})$,

可实现 PAC: ε^{-1} 乘以复杂度项.

置信参数始终只通过 $\ln(1/\delta)$ 进入, 而不是通过 $1/\delta$ 线性进入。

说明 6.18 (可实现情形的上下界间隙). 式 (6.46) 中, 一般下界与教材给出的通用上界之间存在 $\ln(1/\varepsilon)$ 因子间隙. 因此不能无条件把可实现样本复杂度写成 $\Theta\left(\frac{d + \ln(1/\delta)}{\varepsilon}\right)$ 并称其为附件中已经给出的统一精确结论。

6.11 样本复杂度下界的证明框架

本节不复现参考书高级章节的全部技术细节, 但资格考试应掌握下界从何而来, 以及每一项参数依赖所对应的信息论困难。

6.11.1 置信项 $\ln(1/\delta)$ 的可实现下界


命题 6.19 (二点构造的置信下界). 设 $0 < \varepsilon \leq \frac{1}{4}$. 存在 VC 维至少为 1 的二分类假设类, 使任何以失败概率至多 δ 、误差至多 ε 学习该类的算法都需要

$$m = \Omega\left(\frac{\ln(1/\delta)}{\varepsilon}\right). \quad (6.47)$$

证明. 取两个输入点 $\mathcal{X} = \{a, b\}$, 并取两个假设 $h_0(a) = h_1(a) = 0$, $h_0(b) = 0$, $h_1(b) = 1$. 令 $D(b) = 2\varepsilon$, $D(a) = 1 - 2\varepsilon$. 目标函数在 h_0, h_1 中等概率选择。

若训练样本中从未出现 b , 则在两个目标下观察到的数据完全相同. 无论算法如何随机化, 对两个目标取平均后, 它在 b 上预测错误的概率至少为 $1/2$. 一旦在 b 上预测错误, 总体风险为 $D(b) = 2\varepsilon > \varepsilon$. 因此, 至少存在一个目标函数, 使失败概率不小于

$$\frac{1}{2}(1 - 2\varepsilon)^m. \quad (6.48)$$



要使其不超过 δ , 必须有 $(1 - 2\varepsilon)^m \leq 2\delta$ 。当 $\varepsilon \leq 1/4$ 时, $-\ln(1 - 2\varepsilon) \leq 4\varepsilon$, 故必要地

$$m \geq \frac{1}{4\varepsilon} \ln \frac{1}{2\delta}. \quad (6.49)$$

□

6.11.2 VC 维项 d 的可实现下界

若 $\mathcal{H}$ 打散 $C = \{x_1, \dots, x_d\}$, 则在 C 上, 学习器面对的是 d 个可独立变化的二元标记。典型下界构造为:

1. 给一个点较大概率质量;
2. 将总质量约为 ε 或 2ε 分配给其余 $d - 1$ 个点;
3. 在这些轻质量点上随机选择目标标签;
4. 未被样本观察到的点的标签对学习器仍不可辨识;
5. 每个未见点平均贡献约一半的错误概率。

要覆盖足够多的轻质量点, 需要 $m = \Omega(d/\varepsilon)$ 。把该构造与命题 6.19 组合, 得到可实现下界 $m = \Omega\left(\frac{d + \ln(1/\delta)}{\varepsilon}\right)$ 。

6.11.3 Agnostic 情形的 d/ε^2 下界

Agnostic 下界通常在一个被打散的 d 点集上构造带轻微标签偏置的分布: $\Pr(Y = 1 \mid X = x_j) = \frac{1}{2} + \sigma_j \alpha$, $\sigma_j \in \{-1, +1\}$ 。每个 σ_j 决定类内最优预测标签。学习器必须从带噪声的 Bernoulli 样本中识别 d 个偏置方向。

单个 Bernoulli 均值的标准差为 $O(n^{-1/2})$; 要区分大小为 α 的偏置, 需要每个有效坐标获得 $\Omega(\alpha^{-2})$ 级观测。把 α 与目标超额风险 ε 对齐, 并在 d 个可独立标记点上组合, 得到 $m = \Omega(d/\varepsilon^2)$ 。置信项同理产生 $\Omega\left(\frac{\ln(1/\delta)}{\varepsilon^2}\right)$ 。

易错点、反例与失败模式

下界中的“打散”作用不是直接证明训练误差大, 而是提供 d 个可独立编码的未知标记方向。下界证明的核心是不可辨识性: 样本量过小时, 不同目标或不同噪声偏置会产生高度相似的观测分布。


6.12 为什么定理条件不能省

6.12.1 二分类与零一损失

定理 6.15 的等价关系是针对 $h: \mathcal{X} \rightarrow \{0, 1\}$, $\ell(h, (x, y)) = \mathbf{1}\{h(x) \neq y\}$ 陈述的。

对一般实值预测、无界损失、多分类或某些凸学习问题, “可学习性”“统一收敛”“任意 ERM 成功”之间不一定保持完全等价。相应问题可能需要:

- pseudo-dimension;
- fat-shattering dimension;



- Natarajan dimension;
- Rademacher complexity;
- algorithmic stability;
- 或针对特定损失的校准与复杂度工具。

6.12.2 独立同分布

VC 基本定理默认 $S \sim P^m$ 。若样本相关、分布漂移或由策略交互产生，则：

- ghost sample 的可交换性可能失效；
- Hoeffding 型集中需要替换为 mixing、martingale 或其他依赖结构结果；
- 当前分布上的有限 VC 维不能自动保证未来分布上的风险。

6.12.3 分布无关量词

PAC 要求算法对所有允许分布统一工作： $\forall P$ 。有限 VC 维是这种分布无关二分类学习的刻画。若固定一个特定分布，或额外假设 margin、低噪声、流形、稀疏性，即使类本身 VC 维很大，也可能得到更强的分布相关保证。

6.12.4 可测性

严格概率论表述需要保证 $\sup_{h \in \mathcal{H}} |L_P(h) - \hat{L}_S(h)|$ 是可测随机变量。标准课程和考试通常默认假设类满足相应可测性；若处理高度病态的不可数类，可使用可分性条件或 outer probability。考场中不必展开测度论，但若题目要求“全部必要条件”，应说明默认可测。

6.12.5 统计可学习性与计算效率

有限 VC 维只控制样本复杂度，不保证：


- ERM 可以在多项式时间内求解；
- 存在可高效实现的 proper learner；
- 非凸训练能够找到经验全局最优解。

因此 PAC learnable $\not\Rightarrow$ computationally efficient learnable。

6.13 证明与推导要求分级

表 6.1: 本章结果的资格考试掌握深度

内容	要求
Sauer 引理的二项式和形式	必须会完整证明：拆分 A, B ，证明 B 的 VC 维下降一维，使用 Pascal 递推。



内容	要求
$\sum_{j=0}^d \binom{m}{j} \leq (em/d)^d$	必须会完整推导，至少能用二项式生成函数与 $1+t \leq e^t$ 。
VC 统一偏差不等式	必须掌握完整证明框架：ghost sample、随机交换、限制类计数、Hoeffding、union bound。
统一收敛推出 agnostic ERM	必须会完整写出三次风险比较，不得只写“由 ERM 显然”。
可实现 VC 界	必须掌握双样本见证和坏一致假设框架；常数可依附件版本调整，但事件方向必须正确。
统计学习基本定理	必须准确写出假设和全部等价命题，并会解释完整蕴含图。
定量样本复杂度	必须记住 ε^{-1} 与 ε^{-2} 的差异、 d 和 $\ln(1/\delta)$ 的位置，以及粗上界与紧上界的区别。
高级下界	必须掌握构造框架；除非真题明确要求，不必复现参考书高级章节的全部常数优化。

6.14 标准识别与使用方法

- 看到“有限 VC 维的增长函数”，立即写 $\tau_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j} \leq \left(\frac{em}{d}\right)^d$ 。
- 看到“无限假设类的统一泛化界”，想到：ghost sample $\rightarrow$ 限制到 $2m$ 个点 $\rightarrow \tau_{\mathcal{H}}(2m) \rightarrow$ union bound。
- 看到“有限 VC 维是否 PAC 可学习”，先检查：二分类、零一损失、i.i.d.、分布无关；条件满足时答案为是。
- 看到“可实现 ERM”，利用 $\widehat{L}_S(\widehat{h}) = 0$ 和坏一致假设概率，精度依赖为 $1/\varepsilon$ 。
- 看到“agnostic ERM”，必须与 $\inf_{h \in \mathcal{H}} L_P(h)$ 比较，并控制双侧偏差，精度依赖为 $1/\varepsilon^2$ 。
- 看到“证明不可 PAC 学习”，尝试证明 VC 维无限，再把任意大的被打散点集接到 No Free Lunch。

6.15 典型题型

例 6.20 (基础题：直接使用 Sauer 引理)。设 $\text{VCdim}(\mathcal{H}) = 3$ 。则对任意 m , $\tau_{\mathcal{H}}(m) \leq 1 + m + \binom{m}{2} + \binom{m}{3}$ 。当 $m = 5$ 时, $\tau_{\mathcal{H}}(5) \leq 1 + 5 + 10 + 10 = 26 < 32$ 。因此不存在任何 5 点集能被 $\mathcal{H}$ 打散。但不能据此断言 $\tau_{\mathcal{H}}(5) = 26$ ；实际值可以更小。

例 6.21 (综合题：由增长函数推出泛化界)。设 $\text{VCdim}(\mathcal{H}) = d$, $m \geq d$ 。则以概率至少 $1 - \delta$, $\sup_{h \in \mathcal{H}} |L_P(h) - \widehat{L}_S(h)| \leq \sqrt{\frac{8}{m} [d \ln \left(\frac{2em}{d}\right) + \ln \frac{4}{\delta}]}$ 。若题目要求 ERM 的 agnostic 超额风险，还必须乘以 2: $L_P(\widehat{h}) - \inf_{h \in \mathcal{H}} L_P(h) \leq 2\sqrt{\frac{8}{m} [d \ln \left(\frac{2em}{d}\right) + \ln \frac{4}{\delta}]}$ 。

例 6.22 (历年题型改写：Sauer 引理选择题)。[25F-A-MQ8, 1 分 bonus] 的正确含义是：当 $m > d$ 后，增长函数由 Sauer 引理控制为关于 m 的至多 d 次多项式量级。它不意味着：

- 类能打散所有大于 d 的点集；
- ERM 在 $m \leq d$ 时必有零总体风险；
- 样本复杂度与 d 无关。

例 6.23 (历年题型改写：有限 VC 与 ERM). [26S-A-MQ4, 0.5 分] 的正确命题是：在可实现二分类零一损失设定下，有限 VC 维保证 ERM 是 PAC 学习器。

以下说法均错误：

ERM 对任意假设类都一致；

ERM 直接最小化总体风险；

只有有限假设类才可由 ERM PAC 学习。

例 6.24 (课程训练题型，不是博资考真题). [MLT-Practice-Q3, 课程练习] 要求证明有限假设类的一致收敛样本复杂度；本章将其中的有限基数 $|\mathcal{H}|$ 替换为联合样本上的有效基数 $\tau_{\mathcal{H}}(2m)$ 。

[MLT-HW1-Q3, 课程作业] 要求证明多个有限 VC 类之并的 VC 上界；其核心就是： $\tau_{\cup_i \mathcal{H}_i}(m) \leq \sum_i \tau_{\mathcal{H}_i}(m)$ 后接 Sauer 引理。

6.16 答题方法

答题方法

模板一：证明 Sauer 引理。

1. 固定任意 m 点集 C ，删除最后一点得到 C' ；
2. 定义 A 为至少有一个扩展的模式， B 为有两个扩展的模式；
3. 写出精确计数 $|\mathcal{H}|_C = |A| + |B|$ ；
4. 说明 $\text{VCdim}(A) \leq d$ ；
5. 反证说明 $\text{VCdim}(B) \leq d - 1$ ；
6. 使用归纳假设和 Pascal 恒等式；
7. 最后对 C 取最大值；
8. 再用 $t = d/m$ 推出 $(em/d)^d$ 。

模板二：有限 VC 维推出统一收敛。

1. 定义损失类 $f_h(z) = \mathbf{1}\{h(x) \neq y\}$ ；
2. 定义统一偏差 $\Delta(S)$ ；
3. 引入独立 ghost sample S' ；
4. 用对称化把 $P - P_S$ 化为 $P_{S'} - P_S$ ；
5. 对每对样本做 Rademacher 随机交换；
6. 条件于联合样本后，假设模式至多为 $\tau_{\mathcal{H}}(2m)$ ；
7. 对固定模式使用 Hoeffding；

8. 使用 union bound;
9. 最后代入 Sauer 引理。

模板三：统计学习基本定理简答。

1. 先写适用范围：二分类、零一损失、i.i.d.、分布无关；
2. 写六个等价条件；
3. 正向主链：有限 VC $\Rightarrow$ Sauer $\Rightarrow$ 一致收敛 $\Rightarrow$ ERM PAC;
4. 逆向主链：无限 VC $\Rightarrow$ 任意大点集被打散 $\Rightarrow$ No Free Lunch $\Rightarrow$ 不可 PAC;
5. 写定量复杂度；
6. 最后声明不蕴含计算高效。

6.17 易错点、反例与失败模式



易错点、反例与失败模式

1. 错误: $\text{VCdim}(\mathcal{H}) = d \implies \tau_{\mathcal{H}}(m) = \sum_{j=0}^d \binom{m}{j}$.
 错因: Sauer 给的是上界。
 正确: $\tau_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j}$.
2. 错误: 有限 VC 维意味着零泛化误差。
 正确: 有限 VC 维只使估计误差随 m 缩小; 噪声、模型失配和优化误差仍可存在。
3. 错误: 可实现与 agnostic 都需要 $O(\epsilon^{-2})$ 样本。
 正确: 可实现一致性事件产生 $1/\epsilon$; agnostic 风险估计产生 $1/\epsilon^2$ 。
4. 错误: 增长函数在证明中应取 $\tau_{\mathcal{H}}(m)$ 。
 正确: 标准 ghost-sample 证明同时使用训练样本和独立样本, 因此通常出现 $\tau_{\mathcal{H}}(2m)$ 。
5. 错误: 对无限 $\mathcal{H}$ 直接使用 union bound。
 正确: 必须先条件于联合样本, 把 $\mathcal{H}$ 压缩为有限限制类。
6. 错误: 有限 VC 维保证 ERM 可高效计算。
 正确: 基本定理是统计结论, 不控制训练运行时间。
7. 错误: 基本定理对任意损失、任意多分类任务无条件成立。
 正确: 完整等价关系必须检查二分类零一损失等假设。
8. 错误: 一致性与有限样本 PAC 保证相同。
 正确: 一致性是 $m \rightarrow \infty$ 的渐近结论; PAC 明确给出 ϵ, δ 和有限样本量。
9. 错误: 通用逼近定理自动推出有限 VC 维或 PAC 可学习。
 正确: 通用逼近讨论函数逼近存在性; PAC 还需要控制函数类复杂度、有限样本误差与学习算法。

6.18 真题与训练材料对应

表 6.2: Sauer 引理与统计学习基本定理题目映射

题目	主要标签	满分或正确选择所需内容
[25S-A-Q3(a), 5 分]	类之并、增长函数、Sauer	先写 $\tau_{\mathcal{H} \cup \mathcal{H}'}(m) \leq \tau_{\mathcal{H}}(m) + \tau_{\mathcal{H}'}(m)$, 再用二项式和上界证明 VC 维不超过两类 VC 维之和加一。
[25F-A-MQ5, 1 分]	VC 维基本性质	识别仿射半空间在 $\mathbb{R}^d$ 中的 VC 维为 $d+1$; 排除“VC 维等于参数数”和“有限 VC 即零误差”。
[25F-A-MQ8, 1 分 bonus]	Sauer 引理	有限 VC 维 d 意味着 $m > d$ 后增长函数至多按 m^d 级增长。

题目	主要标签	满分或正确选择所需内容
[26S-A-MQ2, 0.5 分]	精确 Sauer 上界	选择 $\tau_{\mathcal{H}}(m) \leq \sum_{j=0}^d \binom{m}{j}$ 。不得把多项式量级描述替代精确不等式。
[26S-A-MQ4, 0.5 分]	有限 VC、ERM、可实现 PAC	在二分类零一损失可实现设定中，有限 VC 维使 ERM 成为 PAC 学习器。
[MLT-Practice-Q3, 课程练习]	有限类一致收敛	Hoeffding、union bound、样本复杂度反解；本章将 $ \mathcal{H} $ 推广为 $\tau_{\mathcal{H}}(2m)$ 。
[MLT-HW1-Q3, 课程作业]	多个类之并	Sauer 引理、增长函数求和、隐式不等式求解；与 [25S-A-Q3(a), 5 分] 存在母题关系。

6.19 快速自测

快速自测

1. Sauer 引理的精确二项式和上界是什么？为什么证明中“可双向扩展的模式类”VC 维会下降一维？
2. 若 $\text{VCdim}(\mathcal{H}) = d$, 对 $m \leq d$ 和 $m > d$, 增长函数分别满足什么性质？
3. 为什么 VC 统一偏差证明中出现的是 $\tau_{\mathcal{H}}(2m)$ 而不是 $\tau_{\mathcal{H}}(m)$ ？
4. 写出统一偏差事件上 agnostic ERM 的三步风险比较。为什么最后是 2α 而不是 α ？
5. 可实现 PAC 与 agnostic PAC 的样本复杂度对 ε 的依赖分别是什么？
6. 统计学习基本定理的完整等价关系依赖哪些问题设定？
7. 有限 VC 维能否推出 ERM 在多项式时间内可计算？为什么？
8. 基础 Sauer-union-bound 推导与定量基本定理的紧上界之间，为什么可能相差一个 $\ln(1/\varepsilon)$ 因子？



第七章 Rademacher Complexity 与数据依赖泛化界

7.1 重要性等级与实考定位

重要性等级：C（历年实考扩展）

- 该主题未在简要考纲中单独列出，但曾在历年人工智能博士资格考试中实际考查。
- [25F-A-MQ3, 0.5 分] 直接考查其核心解释：Rademacher complexity 衡量假设类在给定输入样本上拟合随机符号或随机标记的能力。
- 它是比 VC 维更细的复杂度工具：VC 维是二分类类的最坏情形组合复杂度；Rademacher complexity 可以处理实值函数类、范数约束、margin 和具体样本几何。
- 资格考试至少必须掌握：经验版本与期望版本的区别、随机标记解释、对称化、收缩引理、线性函数类的计算以及由复杂度得到泛化界的标准链条。

7.2 问题设定与三种复杂度版本

设样本空间为 $\mathcal{Z}$ ，分布为 P ，函数类为 $\mathcal{F} \subseteq \mathbb{R}^{\mathcal{Z}}$ 。在学习问题中，通常由假设类 $\mathcal{H}$ 与损失函数 ℓ 诱导

$$\mathcal{F} = \ell \circ \mathcal{H} := \{z \mapsto \ell(h, z) : h \in \mathcal{H}\}. \quad (7.1)$$

对固定 $f \in \mathcal{F}$ ，定义

$$Pf := \mathbb{E}_{Z \sim P}[f(Z)], \quad (7.2)$$


$$P_S f := \frac{1}{m} \sum_{i=1}^m f(Z_i), \quad S = (Z_1, \dots, Z_m) \sim P^m. \quad (7.3)$$

定义 7.1 (Rademacher 随机变量). 随机变量 σ 称为 Rademacher 随机变量，如果 $\Pr(\sigma = +1) = \Pr(\sigma = -1) = \frac{1}{2}$ 。向量 $\sigma = (\sigma_1, \dots, \sigma_m)$ 中的分量默认相互独立。

定义 7.2 (经验 Rademacher complexity). 给定固定样本 $S = (z_1, \dots, z_m)$ ，定义 $\mathcal{F}$ 在 S 上的经验 Rademacher complexity 为

$$\hat{\mathfrak{R}}_S(\mathcal{F}) := \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \frac{1}{m} \sum_{i=1}^m \sigma_i f(z_i) \right]. \quad (7.4)$$

这里的期望只对随机符号 σ 取，样本 S 被条件化为固定量。



定义 7.3 (期望 Rademacher complexity). 定义分布相关的期望 Rademacher complexity 为

$$\mathfrak{R}_m(\mathcal{F}) := \mathbb{E}_{S \sim P^m} [\hat{\mathfrak{R}}_S(\mathcal{F})]. \quad (7.5)$$

它依赖分布 P 和样本量 m , 但通常省略下标 P 。

定义 7.4 (双侧经验 Rademacher complexity). 若需要同时控制 $\sup_{f \in \mathcal{F}} |Pf - P_S f|$, 可定义

$$\hat{\mathfrak{R}}_S^{\text{abs}}(\mathcal{F}) := \mathbb{E}_{\sigma} \left[\sup_{f \in \mathcal{F}} \left| \frac{1}{m} \sum_{i=1}^m \sigma_i f(z_i) \right| \right]. \quad (7.6)$$

令 $-\mathcal{F} := \{-f : f \in \mathcal{F}\}$, 则有精确关系

$$\hat{\mathfrak{R}}_S^{\text{abs}}(\mathcal{F}) = \hat{\mathfrak{R}}_S(\mathcal{F} \cup (-\mathcal{F})). \quad (7.7)$$

易错点、反例与失败模式

必须区分:

$\hat{\mathfrak{R}}_S(\mathcal{F})$: 样本固定, 只对随机符号取期望;

$\mathfrak{R}_m(\mathcal{F})$: 还要对随机样本取期望;

$\hat{\mathfrak{R}}_S^{\text{abs}}(\mathcal{F})$: 在符号相关和前加入绝对值。

经验版本是数据依赖量; 期望版本是分布相关但不依赖某次具体采样的量。二者不能静默混用。

7.3 随机标记解释

命题 7.5 (拟合随机标记的等价形式). 设 $\mathcal{H} \subseteq \{-1, +1\}^{\mathcal{X}}$, $S_X = (x_1, \dots, x_m)$ 。将 Rademacher 符号 σ_i 视为随机标签, 定义随机标签经验误差 $\hat{L}_{\sigma}(h) = \frac{1}{m} \sum_{i=1}^m \mathbf{1}\{h(x_i) \neq \sigma_i\}$ 。则

$$\hat{\mathfrak{R}}_{S_X}(\mathcal{H}) = 1 - 2\mathbb{E}_{\sigma} \left[\inf_{h \in \mathcal{H}} \hat{L}_{\sigma}(h) \right]. \quad (7.8)$$

证明. 由于 $h(x_i), \sigma_i \in \{-1, +1\}$, $\mathbf{1}\{h(x_i) \neq \sigma_i\} = \frac{1 - \sigma_i h(x_i)}{2}$ 。因此

$$\begin{aligned} \hat{L}_{\sigma}(h) &= \frac{1}{2} - \frac{1}{2m} \sum_{i=1}^m \sigma_i h(x_i), \\ \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) &= 1 - 2\hat{L}_{\sigma}(h). \end{aligned}$$

对 h 取上确界, 等价于对随机标签误差取下确界: $\sup_{h \in \mathcal{H}} \frac{1}{m} \sum_{i=1}^m \sigma_i h(x_i) = 1 - 2 \inf_{h \in \mathcal{H}} \hat{L}_{\sigma}(h)$ 。再对 σ 取期望。□

解释。 若 $\mathcal{H}$ 能在样本输入上几乎完全拟合任意随机标签, 则 $\inf_{h \in \mathcal{H}} \hat{L}_{\sigma}(h) \approx 0$, 于是 $\hat{\mathfrak{R}}_{S_X}(\mathcal{H}) \approx 1$ 。若假设类不能利用随机标签中的无结构波动, 则最小随机标签误差接近 $1/2$, 复杂度接近 0 。

易错点、反例与失败模式

“Rademacher complexity 衡量随机标签拟合能力”不意味着:

- 训练时真的要用随机标签;

- complexity 等于训练误差；
- complexity 总是等于 VC 维；
- complexity 对样本量无关。

它是通过随机符号相关性定义的复杂度度量。对标准有界范数类，常见上界按 $m^{-1/2}$ 缩减；但对任意具体样本，经验复杂度未必严格单调下降。

7.4 对称化：从总体风险差到随机符号相关

定义单侧代表性偏差

$$\text{Rep}_P(\mathcal{F}, S) := \sup_{f \in \mathcal{F}} (Pf - P_S f). \quad (7.9)$$

引理 7.6 (Rademacher 对称化). 若相关期望存在, 则

$$\mathbb{E}_{S \sim P^m} [\text{Rep}_P(\mathcal{F}, S)] \leq 2\mathfrak{R}_m(\mathcal{F}). \quad (7.10)$$

证明. 引入与 S 独立且同分布的 ghost sample $S' = (Z'_1, \dots, Z'_m) \sim P^m$. 对任意固定 f , $Pf = \mathbb{E}_{S'}[P_{S'} f]$. 于是

$$\begin{aligned} \mathbb{E}_S \sup_{f \in \mathcal{F}} (Pf - P_S f) &= \mathbb{E}_S \sup_{f \in \mathcal{F}} \mathbb{E}_{S'} (P_{S'} f - P_S f) \\ &\leq \mathbb{E}_{S, S'} \sup_{f \in \mathcal{F}} (P_{S'} f - P_S f) \\ &= \frac{1}{m} \mathbb{E}_{S, S'} \sup_{f \in \mathcal{F}} \sum_{i=1}^m (f(Z'_i) - f(Z_i)). \end{aligned} \quad (7.11)$$

第二行使用 $\sup_f \mathbb{E}[X_f] \leq \mathbb{E}[\sup_f X_f]$.

由于每对 (Z_i, Z'_i) 可交换, 引入独立 Rademacher 符号后,

$$\begin{aligned} \mathbb{E}_{S, S'} \sup_{f \in \mathcal{F}} \sum_{i=1}^m (f(Z'_i) - f(Z_i)) \\ = \mathbb{E}_{S, S', \sigma} \sup_{f \in \mathcal{F}} \sum_{i=1}^m \sigma_i (f(Z'_i) - f(Z_i)). \end{aligned} \quad (7.12)$$

再利用 $\sup_f (A_f + B_f) \leq \sup_f A_f + \sup_f B_f$, 得到

$$\begin{aligned} \sup_{f \in \mathcal{F}} \sum_i \sigma_i (f(Z'_i) - f(Z_i)) \\ \leq \sup_{f \in \mathcal{F}} \sum_i \sigma_i f(Z'_i) + \sup_{f \in \mathcal{F}} \sum_i (-\sigma_i) f(Z_i). \end{aligned} \quad (7.13)$$

因为 σ 与 $-\sigma$ 同分布, 除以 m 并取期望后, 两项都等于 $\mathfrak{R}_m(\mathcal{F})$. 故得到式 (7.10). $\square$

证明或推导框架

识别信号: 题目出现 $\mathbb{E} \sup_{f \in \mathcal{F}} (Pf - P_S f)$ 或要求把未知总体期望转换为可由样本复杂度控制的量。

构造步骤: $P \rightarrow \text{ghost sample } S' \rightarrow P_{S'} - P_S \rightarrow \text{随机交换 } \sigma \rightarrow 2\mathfrak{R}$.

关键条件: S' 必须与 S 独立且同分布; 交换 (Z_i, Z'_i) 后联合分布必须不变。

7.5 高概率泛化界

定理 7.7 (期望复杂度形式的泛化界). 假设对所有 $f \in \mathcal{F}$ 和 $z \in \mathcal{Z}$,

$$|f(z)| \leq c. \quad (7.14)$$

则对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 对所有 $f \in \mathcal{F}$ 同时有

$$Pf - P_S f \leq 2\mathfrak{R}_m(\mathcal{F}) + c\sqrt{\frac{2\ln(2/\delta)}{m}}. \quad (7.15)$$

证明. 将 $G(S) := \sup_{f \in \mathcal{F}} (Pf - P_S f)$ 视为 m 个独立变量的函数。若只把 z_i 替换为 z'_i , 则对任意 f , $|P_S f - P_{S^{(i)}} f| \leq \frac{|f(z_i)| + |f(z'_i)|}{m} \leq \frac{2c}{m}$ 。因此 $|G(S) - G(S^{(i)})| \leq \frac{2c}{m}$ 。由 McDiarmid 不等式, 以概率至少 $1 - \delta$,

$$G(S) \leq \mathbb{E}G(S) + c\sqrt{\frac{2\ln(2/\delta)}{m}}. \quad (7.16)$$

再由引理 7.6, $\mathbb{E}G(S) \leq 2\mathfrak{R}_m(\mathcal{F})$ 。代入即得。 $\square$

定理 7.8 (经验复杂度形式的数据依赖界). 在式 (7.14) 的条件下, 对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 对所有 $f \in \mathcal{F}$ 同时有

$$Pf - P_S f \leq 2\hat{\mathfrak{R}}_S(\mathcal{F}) + 4c\sqrt{\frac{2\ln(4/\delta)}{m}}. \quad (7.17)$$

证明或推导框架

式 (7.15) 仍含未知量 $\mathfrak{R}_m(\mathcal{F}) = \mathbb{E}_S \hat{\mathfrak{R}}_S(\mathcal{F})$ 。为得到数据依赖界, 对 $S \mapsto \hat{\mathfrak{R}}_S(\mathcal{F})$ 再次使用 bounded differences。

替换一个样本时, 其变化量至多为 $2c/m$ 。McDiarmid 不等式控制 $\mathfrak{R}_m(\mathcal{F}) - \hat{\mathfrak{R}}_S(\mathcal{F})$, 再与式 (7.15) 使用 union bound。附件采用的显式常数即得到式 (7.17)。

推论 7.9 (ERM 的数据依赖超额风险界). 设 $\hat{f} \in \arg \min_{f \in \mathcal{F}} P_S f$, $f^* \in \arg \min_{f \in \mathcal{F}} Pf$ 。则在相同有界条件下, 以至少 $1 - \delta$ 的概率,

$$P\hat{f} - Pf^* \leq 2\hat{\mathfrak{R}}_S(\mathcal{F}) + 5c\sqrt{\frac{2\ln(8/\delta)}{m}}. \quad (7.18)$$

为什么需要额外一项。 展开

$$\begin{aligned} P\hat{f} - Pf^* &= (P\hat{f} - P_S \hat{f}) + (P_S \hat{f} - P_S f^*) + (P_S f^* - Pf^*) \\ &\leq (P\hat{f} - P_S \hat{f}) + (P_S f^* - Pf^*). \end{aligned} \quad (7.19)$$

第一项用数据依赖 Rademacher 界; 第二项针对固定 f^* 使用 Hoeffding; 中间项由 ERM 最优性不大于零。

易错点、反例与失败模式

式 (7.15) 与式 (7.17) 首先给出的是单侧界 $Pf - P_S f$ 。若需要 $|Pf - P_S f|$, 必须同时对 $\mathcal{F}$ 与 $-\mathcal{F}$ 应用界并使用 union bound, 或直接使用式 (7.6) 的对称类。

7.6 Rademacher calculus

命题 7.10 (基本运算规则). 对固定样本 S , 有:

1. 若 $\mathcal{F}_1 \subseteq \mathcal{F}_2$, 则

$$\hat{\mathfrak{R}}_S(\mathcal{F}_1) \leq \hat{\mathfrak{R}}_S(\mathcal{F}_2). \quad (7.20)$$

2. 对常数 $a \in \mathbb{R}$ 和固定函数 g ,

$$\hat{\mathfrak{R}}_S(a\mathcal{F} + g) \leq |a| \hat{\mathfrak{R}}_S(\mathcal{F}), \quad (7.21)$$

其中 $a\mathcal{F} + g = \{z \mapsto af(z) + g(z) : f \in \mathcal{F}\}$. 在通常可积条件下, 固定平移项的 Rademacher 期望为零, 因而这里实际上取等号。

3. 凸包不增加复杂度:

$$\hat{\mathfrak{R}}_S(\text{conv } \mathcal{F}) = \hat{\mathfrak{R}}_S(\mathcal{F}). \quad (7.22)$$

4. 若每个 $\phi_i : \mathbb{R} \rightarrow \mathbb{R}$ 都是 ρ -Lipschitz, 并定义 $\phi \circ \mathcal{F} = \{z_i \mapsto \phi_i(f(z_i)) : f \in \mathcal{F}\}$, 则收缩引理给出

$$\hat{\mathfrak{R}}_S(\phi \circ \mathcal{F}) \leq \rho \hat{\mathfrak{R}}_S(\mathcal{F}). \quad (7.23)$$

凸包性质的证明。 固定 σ , 线性泛函 $f \mapsto \sum_i \sigma_i f(z_i)$ 在凸包上的上确界由极端点达到:

$$\begin{aligned} \sup_{g \in \text{conv } \mathcal{F}} \sum_i \sigma_i g(z_i) &= \sup_{\substack{\alpha_j \geq 0 \\ \sum_j \alpha_j = 1}} \sum_j \alpha_j \sum_i \sigma_i f_j(z_i) \\ &= \sup_{f \in \mathcal{F}} \sum_i \sigma_i f(z_i). \end{aligned}$$

引理 7.11 (Massart 有限类引理). 设 $A = \{\mathbf{a}^{(1)}, \dots, \mathbf{a}^{(N)}\} \subseteq \mathbb{R}^m$, $\bar{\mathbf{a}} = \frac{1}{N} \sum_{j=1}^N \mathbf{a}^{(j)}$. 则

$$\hat{\mathfrak{R}}(A) \leq \max_{\mathbf{a} \in A} \|\mathbf{a} - \bar{\mathbf{a}}\|_2 \sqrt{\frac{2 \ln N}{m^2}}. \quad (7.24)$$

等价地, $\hat{\mathfrak{R}}(A) \leq \frac{\max_{\mathbf{a} \in A} \|\mathbf{a} - \bar{\mathbf{a}}\|_2}{m} \sqrt{2 \ln N}$.

证明或推导框架

固定 $t > 0$, 利用 $\max_j u_j \leq \frac{1}{t} \ln \sum_{j=1}^N e^{tu_j}$, 并对 $u_j = \langle \sigma, \mathbf{a}^{(j)} - \bar{\mathbf{a}} \rangle$ 应用指数矩母函数界 $\mathbb{E}_{\sigma} e^{t \langle \sigma, \mathbf{v} \rangle} \leq e^{t^2 \|\mathbf{v}\|_2^2 / 2}$. 最终最小化 $\frac{\ln N}{tm} + \frac{t R_A^2}{2m}$, $R_A = \max_j \|\mathbf{a}^{(j)} - \bar{\mathbf{a}}\|_2$, 取 $t = \frac{\sqrt{2 \ln N}}{R_A}$.

7.7 线性函数类的复杂度


7.7.1 ℓ_2 范数约束

定义

$$\mathcal{G}_2(B) = \{x \mapsto \langle \mathbf{w}, x \rangle : \|\mathbf{w}\|_2 \leq B\}. \quad (7.25)$$

定理 7.12 (ℓ_2 线性类). 对固定输入样本 $S_X = (\mathbf{x}_1, \dots, \mathbf{x}_m)$, 有

$$\hat{\mathfrak{R}}_{S_X}(\mathcal{G}_2(B)) \leq \frac{B}{m} \sqrt{\sum_{i=1}^m \|\mathbf{x}_i\|_2^2}. \quad (7.26)$$



若 $\|\mathbf{x}_i\|_2 \leq R$, 则

$$\widehat{\mathfrak{R}}_{S_X}(\mathcal{G}_2(B)) \leq \frac{BR}{\sqrt{m}}. \quad (7.27)$$

证明.

$$\begin{aligned} \widehat{\mathfrak{R}}_{S_X}(\mathcal{G}_2(B)) &= \frac{1}{m} \mathbb{E}_{\sigma} \sup_{\|\mathbf{w}\|_2 \leq B} \sum_{i=1}^m \sigma_i \langle \mathbf{w}, \mathbf{x}_i \rangle \\ &= \frac{1}{m} \mathbb{E}_{\sigma} \sup_{\|\mathbf{w}\|_2 \leq B} \left\langle \mathbf{w}, \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\rangle \\ &= \frac{B}{m} \mathbb{E}_{\sigma} \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2 \\ &\leq \frac{B}{m} \sqrt{\mathbb{E}_{\sigma} \left\| \sum_{i=1}^m \sigma_i \mathbf{x}_i \right\|_2^2} \\ &= \frac{B}{m} \sqrt{\sum_{i,j} \mathbb{E}[\sigma_i \sigma_j] \langle \mathbf{x}_i, \mathbf{x}_j \rangle} \\ &= \frac{B}{m} \sqrt{\sum_{i=1}^m \|\mathbf{x}_i\|_2^2}. \end{aligned} \quad (7.28)$$

第四行使用 Jensen 不等式；最后一行使用 $\mathbb{E}[\sigma_i \sigma_j] = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$ □

推论 7.13 (Lipschitz 损失下的线性预测器). 设 $\ell(\mathbf{w}, (x, y)) = \phi(\langle \mathbf{w}, \mathbf{x} \rangle, y)$, 且对每个固定 y , $a \mapsto \phi(a, y)$ 是 ρ -Lipschitz. 若 $\|\mathbf{w}\|_2 \leq B$, $\|\mathbf{x}\|_2 \leq R$, $|\ell| \leq c$, 则以至少 $1 - \delta$ 的概率, 对所有 $\mathbf{w}$ 同时有

$$L_P(\mathbf{w}) \leq \widehat{L}_S(\mathbf{w}) + \frac{2\rho BR}{\sqrt{m}} + c\sqrt{\frac{2\ln(2/\delta)}{m}}. \quad (7.29)$$

维数无关性。 式 (7.29) 不显含输入维数 d . 因此即使特征映射位于高维或无限维 Hilbert 空间, 只要能控制 $\|\mathbf{w}\|$, $\|\psi(x)\|$, 同一推导仍适用。这正是 margin 与核方法泛化分析的重要原因。

7.7.2 ℓ_1 范数约束

定义 $\mathcal{G}_1(B) = \{x \mapsto \langle \mathbf{w}, \mathbf{x} \rangle : \|\mathbf{w}\|_1 \leq B\}$, $\mathbf{x} \in \mathbb{R}^d$. 由 ℓ_1 - ℓ_∞ 对偶性, $\sup_{\|\mathbf{w}\|_1 \leq B} \langle \mathbf{w}, \sum_i \sigma_i \mathbf{x}_i \rangle = B \|\sum_i \sigma_i \mathbf{x}_i\|_\infty$. 再对 $2d$ 个带正负号的坐标向量使用 Massart 引理, 若 $\|\mathbf{x}_i\|_\infty \leq R$, 则

$$\widehat{\mathfrak{R}}_{S_X}(\mathcal{G}_1(B)) \leq BR\sqrt{\frac{2\ln(2d)}{m}}. \quad (7.30)$$

易错点、反例与失败模式

式 (7.27) 与式 (7.30) 使用不同的先验:

$$\ell_2 \text{ 约束: } \|\mathbf{w}\|_2 \leq B, \quad \|\mathbf{x}\|_2 \leq R,$$

$$\ell_1 \text{ 约束: } \|\mathbf{w}\|_1 \leq B, \quad \|\mathbf{x}\|_\infty \leq R.$$

不能只比较是否出现 $\ln d$, 而忽略 B, R 的含义也发生了变化。

7.8 Rademacher complexity 与 VC 维的关系

设 $\mathcal{H} \subseteq \{0,1\}^{\mathcal{X}}$, $\text{VCdim}(\mathcal{H}) = d$ 。固定 m 点样本 S_X , 其可实现标记向量集合大小至多为 $|\mathcal{H}|_{S_X} \leq \tau_{\mathcal{H}}(m) \leq \left(\frac{em}{d}\right)^d$ ($m \geq d$)。每个标记向量属于 $\{0,1\}^m$, 其到均值向量的欧氏距离至多 $\sqrt{m}$ 。由 Massart 引理,

$$\hat{\mathfrak{R}}_{S_X}(\mathcal{H}) \leq \sqrt{\frac{2d \ln(em/d)}{m}}. \quad (7.31)$$

表 7.1: VC 维与 Rademacher complexity 的区别

维度	VC 维	Rademacher complexity
适用输出	主要针对二分类。	可直接处理实值函数类和损失函数类。
数据依赖性	对最坏点集定义, 不依赖当前样本。	经验版本显式依赖当前样本几何。
尺度敏感性	只关心能否实现二元标记, 不感知实值输出幅度。	对函数值缩放、范数和 Lipschitz 常数敏感。
典型保证	通过 Sauer 引理得到分布无关最坏情形界。	可得到范数、margin、样本几何相关的界。
关系	有限 VC 维可推出式 (7.31)。	一般不等于 VC 维; 也不是一个整数。

7.9 典型题型与答题方法

例 7.14 (历年概念题). [25F-A-MQ3, 0.5 分] 的正确选项是: Rademacher complexity 衡量假设类拟合随机标签或随机符号的能力。

排除其他选项的理由:

- 它一般不等于 VC 维;
- 类越大时复杂度通常不减, 因为存在集合单调性;
- 它的定义显式包含样本量 m 。

例 7.15 (基础计算题). 若 $\|w\|_2 \leq 3$, $\|x_i\|_2 \leq 2$, $m = 100$, 则线性类满足 $\hat{\mathfrak{R}}_{S_X} \leq \frac{3 \cdot 2}{10} = 0.6$ 。若损失是 1-Lipschitz, 则损失类复杂度也不超过 0.6。该数值只是上界, 不是经验复杂度的精确值。

答题方法

看到“Rademacher complexity 推导泛化界”时, 应按以下顺序作答:

1. 定义损失类 $\mathcal{F} = \ell \circ \mathcal{H}$;
2. 写经验复杂度 $\hat{\mathfrak{R}}_S(\mathcal{F}) = \mathbb{E}_{\sigma} \sup_f \frac{1}{m} \sum_i \sigma_i f(z_i)$;
3. 若需证明, 从 $\mathbb{E} \sup_f (Pf - P_S f)$ 引入 ghost sample;

4. 使用随机交换得到 Rademacher 符号;
5. 若为复合损失, 写收缩引理和 Lipschitz 常数;
6. 若为线性类, 使用对偶范数: $\sup_{\|w\| \leq B} \langle w, v \rangle = B\|v\|_*$;
7. 展开 $\mathbb{E} \|\sum_i \sigma_i x_i\|^2$ 并消去交叉项;
8. 最后加上置信项 $O\left(\sqrt{\frac{\ln(1/\delta)}{m}}\right)$.

快速自测

1. 经验 Rademacher complexity 中, 哪些量是固定的, 哪些量是随机的?
2. 为什么拟合随机标签能力越强, 复杂度越大?
3. 对称化证明为什么需要一个独立 ghost sample?
4. ℓ_2 线性类的复杂度为什么不显含特征维数?
5. 收缩引理中 Lipschitz 常数 ρ 如何进入最终泛化界?
6. VC 维有限是否意味着经验 Rademacher complexity 对每个样本都达到式 (7.31) 的等号?



第八章 算法稳定性与正则化经验风险最小化

8.1 重要性等级与实考定位

重要性等级：S

- 该主题未在简要考纲中单独列出，但曾在历年人工智能博士资格考试中实际考查。
- [25S-A-Q4(a), 5 分] 要求完整证明 on-average replace-one stability 控制期望泛化差；[25S-A-Q4(b), 5 分] 要求推导凸 ρ -Lipschitz 损失下正则化 ERM 的 oracle inequality。
- 这是三套机器学习理论真题中最明确的“算法依赖泛化分析”题：它不统一控制整个假设类，而是控制训练样本替换一个点后，算法输出如何变化。
- 必须熟练掌握：替换样本构造、交换性恒等式、强凸性、Lipschitz 控制、正则化参数的拟合-稳定性权衡及参数化换算。

8.2 替换样本与稳定性定义

设 $S = (Z_1, \dots, Z_m) \sim P^m$, $Z' \sim P$ 相互独立。对 $i \in [m]$ ，定义替换一个样本后的数据集

$$S^{(i)} = (Z_1, \dots, Z_{i-1}, Z', Z_{i+1}, \dots, Z_m). \quad (8.1)$$

学习算法记为 $A: \mathcal{Z}^m \rightarrow \mathcal{H}$ 。

定义 8.1 (期望泛化差). 算法 A 的期望泛化差定义为

$$\text{gen}_m(A, P) = \mathbb{E}_{S \sim P^m} [L_P(A(S)) - \widehat{L}_S(A(S))]. \quad (8.2)$$

定理 8.2 (Replace-one 恒等式). 令 I 独立且均匀分布于 $[m]$ 。则对任意学习算法 A ,

$$\begin{aligned} \mathbb{E}_S [L_P(A(S)) - \widehat{L}_S(A(S))] \\ = \mathbb{E}_{S, Z', I} [\ell(A(S^{(I)}), Z_I) - \ell(A(S), Z_I)]. \end{aligned} \quad (8.3)$$

证明. 首先,

$$\mathbb{E}_S [L_P(A(S))] = \mathbb{E}_{S, Z'} [\ell(A(S), Z')]. \quad (8.4)$$

对固定 i ，随机向量 $(S, Z') = (Z_1, \dots, Z_i, \dots, Z_m, Z')$ 与 $(S^{(i)}, Z_i) = (Z_1, \dots, Z', \dots, Z_m, Z_i)$ 具有相同分布，因为 Z_i 与 Z' 独立同分布。因此

$$\mathbb{E}_{S, Z'} [\ell(A(S), Z')] = \mathbb{E}_{S, Z'} [\ell(A(S^{(i)}), Z_i)]. \quad (8.5)$$



再对 $I \sim \text{Unif}[m]$ 平均,

$$\mathbb{E}_S[L_P(A(S))] = \mathbb{E}_{S, Z', I}[\ell(A(S^{(I)}), Z_I)]. \quad (8.6)$$

另一方面,

$$\begin{aligned} \mathbb{E}_S[\widehat{L}_S(A(S))] &= \mathbb{E}_S\left[\frac{1}{m} \sum_{i=1}^m \ell(A(S), Z_i)\right] \\ &= \mathbb{E}_{S, I}[\ell(A(S), Z_I)]. \end{aligned} \quad (8.7)$$

用式 (8.6) 减去式 (8.7) 即得。 $\square$

定义 8.3 (On-average replace-one stability). 设 $\epsilon_{\text{stab}} : \mathbb{N} \rightarrow \mathbb{R}_+$ 随 m 非增。若对任意分布 P ,

$$\mathbb{E}_{S, Z', I}[\ell(A(S^{(I)}), Z_I) - \ell(A(S), Z_I)] \leq \epsilon_{\text{stab}}(m), \quad (8.8)$$

则称 A 以速率 $\epsilon_{\text{stab}}(m)$ 满足平均替换一个样本稳定性。

推论 8.4 (稳定算法不过拟合). 若 A 满足式 (8.8), 则

$$\mathbb{E}_S[L_P(A(S)) - \widehat{L}_S(A(S))] \leq \epsilon_{\text{stab}}(m). \quad (8.9)$$

易错点、反例与失败模式

稳定性只控制 $L_P(A(S)) - \widehat{L}_S(A(S))$, 并不自动保证 $L_P(A(S))$ 小。

反例: 算法始终输出同一个很差的常数预测器。它完全不随数据变化, 因此稳定性很好; 但其训练风险和总体风险都可能很高。一个有效学习算法必须同时满足: 拟合误差小 且 稳定性误差小。

8.3 正则化 ERM 的参数化约定

为严格对应 [25S-A-Q4(b), 5 分] 及 [UML] 的稳定性章节, 本节暂采用

$$A_{\lambda_{\text{ex}}}(S) \in \arg \min_{\mathbf{w} \in \mathcal{W}} \left\{ \widehat{L}_S(\mathbf{w}) + \lambda_{\text{ex}} \|\mathbf{w}\|_2^2 \right\}. \quad (8.10)$$

这里下标 “ex” 表示真题和附件使用的参数化。

全文主约定通常写成

$$\widehat{L}_S(\mathbf{w}) + \frac{\lambda_{\text{main}}}{2} \|\mathbf{w}\|_2^2. \quad (8.11)$$

两者换算为

$$\lambda_{\text{main}} = 2\lambda_{\text{ex}}. \quad (8.12)$$

易错点、反例与失败模式

若不说明参数化, 稳定性常数会差一倍。

在式 (8.10) 下: $\lambda_{\text{ex}} \|\mathbf{w}\|^2$ 是 $2\lambda_{\text{ex}}$ -强凸的。

在式 (8.11) 下: $\frac{\lambda_{\text{main}}}{2} \|\mathbf{w}\|^2$ 是 λ_{main} -强凸的。

8.4 凸 Lipschitz 损失下的稳定性

假设对每个 $z \in \mathcal{Z}$:

1. $\mathbf{w} \mapsto \ell(\mathbf{w}, z)$ 是凸函数;
2. 相对于欧氏范数是 ρ -Lipschitz:

$$|\ell(\mathbf{u}, z) - \ell(\mathbf{v}, z)| \leq \rho \|\mathbf{u} - \mathbf{v}\|_2. \quad (8.13)$$

定理 8.5 (正则化 ERM 的 replace-one 稳定性). 设算法由式 (8.10) 定义。则对任意 S, Z', i ,

$$\|A_{\lambda_{\text{ex}}}(S^{(i)}) - A_{\lambda_{\text{ex}}}(S)\|_2 \leq \frac{2\rho}{\lambda_{\text{ex}}m}. \quad (8.14)$$

进一步地,

$$\ell(A_{\lambda_{\text{ex}}}(S^{(i)}), Z_i) - \ell(A_{\lambda_{\text{ex}}}(S), Z_i) \leq \frac{2\rho^2}{\lambda_{\text{ex}}m}. \quad (8.15)$$

因此该算法是 *on-average replace-one stable*, 速率为

$$\epsilon_{\text{stab}}(m) = \frac{2\rho^2}{\lambda_{\text{ex}}m}. \quad (8.16)$$

证明. 记

$$\begin{aligned} \mathbf{u} &= A_{\lambda_{\text{ex}}}(S), \\ \mathbf{v} &= A_{\lambda_{\text{ex}}}(S^{(i)}), \end{aligned}$$

并定义 $F_S(\mathbf{w}) = \widehat{L}_S(\mathbf{w}) + \lambda_{\text{ex}}\|\mathbf{w}\|_2^2$ 。由于经验损失是凸函数, F_S 是 $2\lambda_{\text{ex}}$ -强凸函数。又因为 $\mathbf{u}$ 是 F_S 的极小点,

$$F_S(\mathbf{v}) - F_S(\mathbf{u}) \geq \lambda_{\text{ex}}\|\mathbf{v} - \mathbf{u}\|_2^2. \quad (8.17)$$

替换样本后,

$$\begin{aligned} F_S(\mathbf{v}) - F_S(\mathbf{u}) &= F_{S^{(i)}}(\mathbf{v}) - F_{S^{(i)}}(\mathbf{u}) \\ &\quad + \frac{1}{m} [\ell(\mathbf{v}, Z_i) - \ell(\mathbf{u}, Z_i)] \\ &\quad + \frac{1}{m} [\ell(\mathbf{u}, Z') - \ell(\mathbf{v}, Z')]. \end{aligned} \quad (8.18)$$

由于 $\mathbf{v}$ 最小化 $F_{S^{(i)}}$, $F_{S^{(i)}}(\mathbf{v}) - F_{S^{(i)}}(\mathbf{u}) \leq 0$ 。因此

$$\begin{aligned} F_S(\mathbf{v}) - F_S(\mathbf{u}) &\leq \frac{1}{m} [\ell(\mathbf{v}, Z_i) - \ell(\mathbf{u}, Z_i) \\ &\quad + \ell(\mathbf{u}, Z') - \ell(\mathbf{v}, Z')]. \end{aligned} \quad (8.19)$$

由 Lipschitz 条件, 右侧不超过 $\frac{2\rho}{m}\|\mathbf{v} - \mathbf{u}\|_2$ 。与式 (8.17) 合并:

$$\lambda_{\text{ex}}\|\mathbf{v} - \mathbf{u}\|_2^2 \leq \frac{2\rho}{m}\|\mathbf{v} - \mathbf{u}\|_2. \quad (8.20)$$

若 $\mathbf{v} = \mathbf{u}$, 结论显然成立; 否则约去 $\|\mathbf{v} - \mathbf{u}\|_2$, 得到式 (8.14)。

最后再次使用 Lipschitz 条件:

$$\begin{aligned} \ell(\mathbf{v}, Z_i) - \ell(\mathbf{u}, Z_i) &\leq \rho\|\mathbf{v} - \mathbf{u}\|_2 \\ &\leq \frac{2\rho^2}{\lambda_{\text{ex}}m}. \end{aligned} \quad (8.21)$$

□



推论 8.6 (正则化 ERM 的期望泛化差). 在定理 8.5 的条件下,

$$\mathbb{E}_S \left[L_P(A_{\lambda_{\text{ex}}}(S)) - \widehat{L}_S(A_{\lambda_{\text{ex}}}(S)) \right] \leq \frac{2\rho^2}{\lambda_{\text{ex}}m}. \quad (8.22)$$

8.5 Oracle inequality 与正则化参数选择

定理 8.7 (凸 Lipschitz 正则化 ERM 的 oracle inequality). 在定理 8.5 的条件下, 对任意比较向量 $\mathbf{w}^* \in \mathcal{W}$,

$$\mathbb{E}_S L_P(A_{\lambda_{\text{ex}}}(S)) \leq L_P(\mathbf{w}^*) + \lambda_{\text{ex}} \|\mathbf{w}^*\|_2^2 + \frac{2\rho^2}{\lambda_{\text{ex}}m}. \quad (8.23)$$

证明. 由正则化 ERM 的最优性,

$$\widehat{L}_S(A_{\lambda_{\text{ex}}}(S)) + \lambda_{\text{ex}} \|A_{\lambda_{\text{ex}}}(S)\|_2^2 \leq \widehat{L}_S(\mathbf{w}^*) + \lambda_{\text{ex}} \|\mathbf{w}^*\|_2^2. \quad (8.24)$$

删除左侧非负正则项, 得到

$$\widehat{L}_S(A_{\lambda_{\text{ex}}}(S)) \leq \widehat{L}_S(\mathbf{w}^*) + \lambda_{\text{ex}} \|\mathbf{w}^*\|_2^2. \quad (8.25)$$

对 S 取期望。因为 $\mathbf{w}^*$ 不依赖 S , $\mathbb{E}_S[\widehat{L}_S(\mathbf{w}^*)] = L_P(\mathbf{w}^*)$ 。于是

$$\mathbb{E}_S[\widehat{L}_S(A_{\lambda_{\text{ex}}}(S))] \leq L_P(\mathbf{w}^*) + \lambda_{\text{ex}} \|\mathbf{w}^*\|_2^2. \quad (8.26)$$

再使用恒等式 $\mathbb{E}L_P(A) = \mathbb{E}\widehat{L}_S(A) + \mathbb{E}[L_P(A) - \widehat{L}_S(A)]$ 和推论 8.6。 $\square$

正则化参数的解析平衡。 若已知存在比较向量满足 $\|\mathbf{w}^*\|_2 \leq B$, 则超额项由

$$\Phi(\lambda_{\text{ex}}) = \lambda_{\text{ex}} B^2 + \frac{2\rho^2}{\lambda_{\text{ex}}m} \quad (8.27)$$

控制。

求导: $\Phi'(\lambda_{\text{ex}}) = B^2 - \frac{2\rho^2}{\lambda_{\text{ex}}^2 m}$ 。令其为零, 得到

$$\lambda_{\text{ex}}^* = \frac{\sqrt{2}\rho}{B\sqrt{m}}. \quad (8.28)$$

代回:

$$\Phi(\lambda_{\text{ex}}^*) = 2\sqrt{2} \frac{\rho B}{\sqrt{m}} = \rho B \sqrt{\frac{8}{m}}. \quad (8.29)$$

所以

$$\mathbb{E}L_P(A_{\lambda_{\text{ex}}^*}(S)) \leq \inf_{\|\mathbf{w}\| \leq B} L_P(\mathbf{w}) + \rho B \sqrt{\frac{8}{m}}. \quad (8.30)$$


要使超额风险不超过 ε , 充分条件为

$$m \geq \frac{8\rho^2 B^2}{\varepsilon^2}. \quad (8.31)$$

换算到全文主约定。 由式 (8.12), 在目标 $\widehat{L}_S(\mathbf{w}) + \frac{\lambda_{\text{main}}}{2} \|\mathbf{w}\|^2$ 下,

$$\epsilon_{\text{stab}}(m) = \frac{4\rho^2}{\lambda_{\text{main}}m}, \quad (8.32)$$

$$\mathbb{E}L_P(A(S)) \leq L_P(\mathbf{w}^*) + \frac{\lambda_{\text{main}}}{2} \|\mathbf{w}^*\|^2 + \frac{4\rho^2}{\lambda_{\text{main}}m}. \quad (8.33)$$



8.6 稳定性、拟合误差与近似 ERM

定义 8.8 (平均近似 ERM). 若算法 A 满足

$$\mathbb{E}_S \left[\widehat{L}_S(A(S)) - \inf_{h \in \mathcal{H}} \widehat{L}_S(h) \right] \leq \epsilon_{\text{opt}}(m), \quad (8.34)$$

则称其是速率为 $\epsilon_{\text{opt}}(m)$ 的平均近似 ERM (asymptotic empirical risk minimizer, AERM)。

命题 8.9 (稳定性加拟合性推出学习保证). 若 A 的 *on-average replace-one stability* 速率为 $\epsilon_{\text{stab}}(m)$, 且满足式 (8.34), 则

$$\mathbb{E}_S [L_P(A(S))] - \inf_{h \in \mathcal{H}} L_P(h) \leq \epsilon_{\text{stab}}(m) + \epsilon_{\text{opt}}(m). \quad (8.35)$$

证明. 任取 $\eta > 0$, 选择固定 $h_\eta \in \mathcal{H}$ 使 $L_P(h_\eta) \leq \inf_{h \in \mathcal{H}} L_P(h) + \eta$. 则

$$\begin{aligned} \mathbb{E} L_P(A(S)) - L_P(h_\eta) &= \mathbb{E} [L_P(A(S)) - \widehat{L}_S(A(S))] \\ &\quad + \mathbb{E} [\widehat{L}_S(A(S)) - \widehat{L}_S(h_\eta)] \\ &\quad + \mathbb{E} [\widehat{L}_S(h_\eta) - L_P(h_\eta)]. \end{aligned} \quad (8.36)$$

第一项不超过 $\epsilon_{\text{stab}}(m)$; 第二项不超过 $\epsilon_{\text{opt}}(m)$; 第三项为零, 因为 h_η 固定。令 $\eta \downarrow 0$ 。□

8.7 为什么定理条件不能省

- 强凸性不能省。** 若经验目标有多个相距很远的极小点, 替换一个样本可能使算法从一个极小点跳到另一个极小点, 即使两个数据集的经验目标只相差一个样本项。
- Lipschitz 条件不能省。** 参数距离小 $\|\mathbf{u} - \mathbf{v}\| \ll 1$ 并不自动推出损失差小; 需要 $|\ell(\mathbf{u}, z) - \ell(\mathbf{v}, z)| \leq \rho \|\mathbf{u} - \mathbf{v}\|$ 。
- 凸性不能静默删除。** 凸性保证经验损失与二次正则项之和保持强凸。对一般非凸神经网络目标, 加上 ℓ_2 正则并不使整个目标全局强凸。
- 正则化参数不能无限增大。** 从式 (8.23) 看: $\lambda_{\text{ex}} \uparrow \implies$ 稳定性项下降, 但偏置项上升。
- 本节结论是期望保证。** 式 (8.22) 控制对训练集的期望。它不是未经额外集中分析的高概率保证。
- 平方损失并非全局 Lipschitz。** 对 $\ell(\mathbf{w}, (\mathbf{x}, y)) = (\langle \mathbf{w}, \mathbf{x} \rangle - y)^2$, 梯度为 $\nabla_{\mathbf{w}} \ell = 2(\langle \mathbf{w}, \mathbf{x} \rangle - y)\mathbf{x}$ 。只有在 $\|\mathbf{w}\| \leq B$, $\|\mathbf{x}\| \leq R$, $|y| \leq Y$ 等有界条件下, 才能得到 $\|\nabla \ell\| \leq 2(BR + Y)R$, 从而在该有界参数域上获得 Lipschitz 常数。

8.8 Rademacher 与稳定性分析的区别

表 8.1: 类复杂度分析与算法稳定性分析

比较项	Rademacher/VC	稳定性
分析对象	整个函数类或损失类。	特定学习算法 A 。



比较项	Rademacher/VC	稳定性
主要问题	整个类能否同时拟合样本波动。	替换一个样本后算法输出是否剧烈变化。
典型保证	统一高概率泛化界。	附件中主要给出期望泛化差。
复杂度来源	VC 维、范数、margin、样本几何。	目标强凸性、损失 Lipschitz 性、正则化强度。
可能的优势	对所有候选模型同时成立。	可利用算法结构，避免对整个大类做最坏控制。
不能保证	不保证 ERM 可高效求解。	稳定但不拟合的算法仍可能风险很大。

8.9 历年题型与满分模板

例 8.10 (历年题型改写). [25S-A-Q4(a), 5 分] 要求证明: 若 A 以速率 $\epsilon(m)$ 满足 on-average replace-one stability, 则 $\mathbb{E}_S[L_P(A(S)) - \hat{L}_S(A(S))] \leq \epsilon(m)$ 。满分关键不是直接引用定义, 而是先证明式 (8.3): $\mathbb{E}L_P(A(S)) = \mathbb{E}\ell(A(S^{(I)}), Z_I)$ 。

例 8.11 (历年题型改写). [25S-A-Q4(b), 5 分] 要求得到 $\mathbb{E}L_P(A(S)) \leq L_P(\mathbf{w}^*) + \lambda_{\text{ex}}\|\mathbf{w}^*\|^2 + \frac{2\rho^2}{\lambda_{\text{ex}}m}$ 。完整步骤必须包括:

1. 二次正则使目标 $2\lambda_{\text{ex}}$ -强凸;
2. 比较 $F_S(\mathbf{v}) - F_S(\mathbf{u})$;
3. 利用 S 与 $S^{(i)}$ 仅有两个经验损失项不同;
4. 得到参数差 $\|\mathbf{u} - \mathbf{v}\| \leq 2\rho/(\lambda_{\text{ex}}m)$;
5. 转为损失稳定性;
6. 用正则化 ERM 最优性控制训练风险;
7. 将拟合项与泛化差相加。

答题方法

对正则化 ERM 稳定性题, 建议固定写法如下:

1. 定义 $\mathbf{u} = A(S)$, $\mathbf{v} = A(S^{(i)})$, $F_S = \hat{L}_S + \lambda_{\text{ex}}\|\cdot\|^2$;
2. 写强凸下界 $F_S(\mathbf{v}) - F_S(\mathbf{u}) \geq \lambda_{\text{ex}}\|\mathbf{v} - \mathbf{u}\|^2$;
3. 将 F_S 换写为 $F_{S^{(i)}}$ 加两个样本差;
4. 使用 $\mathbf{v}$ 对 $F_{S^{(i)}}$ 的最优性;
5. 两次使用 Lipschitz 条件;
6. 约去参数距离;
7. 写出稳定性率;

8. 用 replace-one 恒等式得到泛化差；
9. 用正则化目标最优性得到 oracle inequality；
10. 最后检查正则参数到底乘在 $\|w\|^2$ 还是 $\frac{1}{2}\|w\|^2$ 前。

快速自测

1. Replace-one 恒等式中，为什么 (S, Z') 与 $(S^{(i)}, Z_i)$ 同分布？
2. 稳定算法为什么仍可能具有很大的总体风险？
3. 在真题参数化下，正则化 ERM 的参数距离稳定性率是什么？
4. 若主约定改为 $\lambda\|w\|^2/2$ ，稳定性常数如何变化？
5. 正则化参数增大时，oracle inequality 中哪一项减小，哪一项增大？
6. 平方损失为何不能无条件套用全局 Lipschitz 稳定性定理？



第九章 结构风险最小化、验证与模型选择

9.1 重要性等级与考情定位

重要性等级：A

- 模型选择、SRM、hold-out、 k -fold cross-validation、train/validation/test 划分和数据泄漏均属于明确考纲。
- [25F-A-MQ1, 0.5 分] 直接考查 bias-variance trade-off；但三套 A 方向试卷没有把完整模型选择流程单独设为高分大题。
- 该主题仍是资格考试的重要母题，因为它能够出现在：概念简答、实验设计、失败诊断、正则参数选择和跨方向系统设计中。
- [MLT-Final-MQ2, 2 分, 课程期末题] 直接把正则化目的表述为控制模型复杂度并改善泛化；但课程题不计入博资考频率。

9.2 模型选择的形式化

设候选模型族为 $\mathcal{H}_1, \mathcal{H}_2, \dots, \mathcal{H}_r$ 或可数序列 $\mathcal{H}_1, \mathcal{H}_2, \dots$ 。常见情形是嵌套结构

$$\mathcal{H}_1 \subseteq \mathcal{H}_2 \subseteq \dots, \quad (9.1)$$

例如：

- 多项式次数逐渐增大；
- 决策树最大深度逐渐增大；
- 神经网络宽度或深度逐渐增大；
- 正则化强度逐渐减小所形成的有效模型类；
- 特征数量或核字典规模逐渐增大。

对每个模型类，训练算法产生

$$\hat{h}_j = A_j(S_{\text{tr}}) \in \mathcal{H}_j. \quad (9.2)$$

模型选择的目标不是选择训练误差最小的 j ，而是选择总体风险较小的候选预测器。

回顾总体超额风险分解：

$$L_P(\tilde{h}) - L^* \leq \mathcal{E}_{\text{app}}(\mathcal{H}_j) + 2 \sup_{h \in \mathcal{H}_j} |L_P(h) - \hat{L}_S(h)| + \Delta_{\text{opt}}. \quad (9.3)$$



它对应:

模型过小 $\implies$ 近似误差可能大,

模型过大 $\implies$ 估计误差可能大,

训练不足 $\implies$ 优化误差可能大.

易错点、反例与失败模式

平方损失的 bias-variance-noise 分解 $\text{noise} + \text{bias}^2 + \text{variance}$ 与式 (9.3) 的 approximation + estimation + optimization 不是逐项同义关系。

前者针对随机估计器在平方损失下的点态分解；后者是更一般的学习误差来源分解。

9.3 结构风险最小化

9.3.1 加权模型族

设 $\mathcal{H} = \bigcup_{j=1}^{\infty} \mathcal{H}_j$, 且每个 $\mathcal{H}_j$ 都有一致收敛界: 对任意 $\delta_j \in (0, 1)$, 以至少 $1 - \delta_j$ 的概率,

$$\sup_{h \in \mathcal{H}_j} |L_P(h) - \hat{L}_S(h)| \leq \epsilon_j(m, \delta_j). \quad (9.4)$$

选择权重

$$w_j > 0, \quad \sum_{j=1}^{\infty} w_j \leq 1. \quad (9.5)$$

定理 9.1 (SRM 的同时泛化界). 对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率, 对所有 j 和所有 $h \in \mathcal{H}_j$ 同时成立

$$|L_P(h) - \hat{L}_S(h)| \leq \epsilon_j(m, w_j \delta). \quad (9.6)$$

证明. 对固定 j , 令 $\delta_j = w_j \delta$. 由式 (9.4), 第 j 类界失败的概率至多为 $w_j \delta$. 由可数 union bound, $\Pr(\text{至少一个类的界失败}) \leq \sum_{j=1}^{\infty} w_j \delta \leq \delta$. $\square$

定义 9.2 (结构风险最小化). 对每个 $h \in \mathcal{H}$, 定义其首次出现层级 $j(h) = \min\{j : h \in \mathcal{H}_j\}$. SRM 返回

$$\hat{h}_{\text{SRM}} \in \arg \min_{h \in \mathcal{H}} \left\{ \hat{L}_S(h) + \epsilon_{j(h)}(m, w_{j(h)} \delta) \right\}. \quad (9.7)$$

若二分类类 $\mathcal{H}_j$ 的 VC 维为 d_j , 可采用量级形式

$$\epsilon_j(m, w_j \delta) = C \sqrt{\frac{d_j + \ln(1/(w_j \delta))}{m}}. \quad (9.8)$$

若选

$$w_j = \frac{6}{\pi^2 j^2}, \quad (9.9)$$

则

$$\ln \frac{1}{w_j \delta} = \ln \frac{1}{\delta} + 2 \ln j + \ln \frac{\pi^2}{6}. \quad (9.10)$$

因此复杂模型不仅因 d_j 较大受到惩罚, 也因其层级索引较大受到额外惩罚。



易错点、反例与失败模式

SRM 不是 $\arg \min_h \hat{L}_S(h)$, 而是 $\arg \min_h [\text{经验风险} + \text{复杂度罚项}]$ 。罚项必须随模型复杂度、样本量和置信参数变化；不能只写“选择较简单模型”而不给出数学形式。

9.4 Hold-out validation

将可用数据随机划分为相互独立的: S_{tr}, V , 其中验证集大小为 $|V| = m_v$ 。

定理 9.3 (固定预测器的验证误差界). 设损失位于 $[0, 1]$, 且预测器 h 与验证集 V 独立。则对任意 $\delta \in (0, 1)$, 以至少 $1 - \delta$ 的概率,

$$|\hat{L}_V(h) - L_P(h)| \leq \sqrt{\frac{\ln(2/\delta)}{2m_v}}. \quad (9.11)$$

该结论直接来自 Hoeffding 不等式。关键不是 h 必须在采样验证集前由人工固定, 而是条件于训练数据后, $h = A(S_{\text{tr}})$ 仍与 V 独立。

9.4.1 有限候选集的模型选择

训练阶段产生 $\mathcal{M} = \{h_1, \dots, h_r\}$, 其中所有 h_j 可以依赖 S_{tr} , 但候选集合必须与验证集 V 独立。选择

$$\hat{j} \in \arg \min_{j \in [r]} \hat{L}_V(h_j). \quad (9.12)$$

定理 9.4 (有限候选集的验证界). 以至少 $1 - \delta$ 的概率,

$$\forall j \in [r], \quad |\hat{L}_V(h_j) - L_P(h_j)| \leq \alpha_v, \quad (9.13)$$

其中

$$\alpha_v = \sqrt{\frac{\ln(2r/\delta)}{2m_v}}. \quad (9.14)$$

因此

$$L_P(h_{\hat{j}}) \leq \min_{j \in [r]} L_P(h_j) + 2\alpha_v. \quad (9.15)$$

证明. 对每个固定 h_j 应用定理 9.3, 把失败概率取为 δ/r , 再使用 union bound, 得到式 (9.13)。

令 $j^* \in \arg \min_j L_P(h_j)$ 。在统一事件上,

$$\begin{aligned} L_P(h_{\hat{j}}) &\leq \hat{L}_V(h_{\hat{j}}) + \alpha_v \\ &\leq \hat{L}_V(h_{j^*}) + \alpha_v \\ &\leq L_P(h_{j^*}) + 2\alpha_v. \end{aligned} \quad (9.16)$$

□

验证集大小。 若希望模型选择额外误差不超过 ε , 令 $2\alpha_v \leq \varepsilon$, 则充分条件为

$$m_v \geq \frac{2}{\varepsilon^2} \ln \frac{2r}{\delta}. \quad (9.17)$$



9.5 k -fold cross-validation

将训练数据 S 划分为互不相交的 k 个 fold: $S = S_1 \cup \dots \cup S_k$ 。对每个超参数 $\theta \in \Theta$ 和 fold j , 训练

$$h_{j,\theta} = A_\theta(S \setminus S_j), \quad (9.18)$$

并计算

$$\hat{R}_{CV}(\theta) = \frac{1}{k} \sum_{j=1}^k \hat{L}_{S_j}(h_{j,\theta}). \quad (9.19)$$

选择

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} \hat{R}_{CV}(\theta), \quad (9.20)$$

最后在全部训练数据上重新拟合:

$$\hat{h} = A_{\hat{\theta}}(S). \quad (9.21)$$

计算复杂度。 若在 n 个样本上训练一次参数 θ 的代价为 $T_{\text{train}}(n, \theta)$, 则 k -fold 搜索的主要时间复杂度为

$$O\left(\sum_{\theta \in \Theta} k T_{\text{train}}\left(\left(1 - \frac{1}{k}\right)m, \theta\right)\right), \quad (9.22)$$

另加一次最终全数据拟合。当 $k = m$ 时得到 leave-one-out, 训练次数最多, 计算代价通常最高。

反例 9.5 (交叉验证并非无条件可靠)。设标签独立服从 $Y \sim \text{Bernoulli}(1/2)$ 。算法读取训练标签的奇偶性: 若训练标签和为奇数, 输出常数 1; 否则输出常数 0。

对 leave-one-out, 第 i 个样本的预测等于其余标签的奇偶性。令全部标签奇偶性为 $P \in \{0, 1\}$:

- 若 $P = 0$, 每个留出标签都被正确预测, LOO 误差为 0;
- 若 $P = 1$, 每个留出标签都被错误预测, LOO 误差为 1。

但任一常数预测器的真实风险都是 $1/2$ 。故 LOO 估计与真实风险的绝对差恒为 $1/2$ 。

该失败源于算法对单个训练标签极不稳定。

9.6 Train-validation-test 划分与数据泄漏

标准职责为:

$$S_{\text{train}} : \text{拟合模型参数}, \quad (9.23)$$

$$S_{\text{validation}} : \text{选择模型、超参数、阈值和训练轮数}, \quad (9.24)$$

$$S_{\text{test}} : \text{在所有选择完成后做最终一次独立评估}. \quad (9.25)$$

易错点、反例与失败模式

以下行为会破坏验证或测试集独立性:

1. 根据测试集结果选择模型、学习率、prompt、特征或随机种子;
2. 在全数据上先做标准化、特征选择、PCA 或词表构建, 再进行交叉验证;
3. 同一用户、同一文档、同一视频或近重复样本跨越训练和测试集合;

4. 时间序列中使用未来数据计算当前特征；
5. 在每轮验证反馈后继续生成新的候选模型，却仍使用固定的 r 候选界；
6. 数据增强产生的近重复版本被分配到不同划分。

正确原则是：任何使用验证 fold 信息估计的预处理步骤，都必须在每个 fold 的训练部分内部重新拟合。测试集一旦被用于选择，就已经成为验证集，应另设新的最终测试集。

9.7 模型选择曲线与失败诊断

若模型类满足嵌套关系 (9.1)，并且每一类都求得精确 ERM，则训练误差满足

$$\inf_{h \in \mathcal{H}_{j+1}} \widehat{L}_S(h) \leq \inf_{h \in \mathcal{H}_j} \widehat{L}_S(h). \tag{9.26}$$

因此训练误差随模型类增大而非增。

验证误差常见地先下降后上升，但这只是经验诊断模式，不是无条件数学定理。若模型不嵌套、优化不充分、训练随机性强或存在分布偏移，验证曲线可能不呈标准 U 形。

表 9.1: 训练与验证表现的标准诊断

现象	主要怀疑	优先检查或改进
训练误差高，验证误差也高	欠拟合、优化失败、特征不足、标签噪声。	检查优化是否收敛；增大模型类；改进特征；核对数据和损失。
训练误差低，验证误差高	估计误差大、过拟合、分布偏移或泄漏。	增加数据；加强正则；减小模型；数据增强；核对划分。
增加样本后验证误差持续下降	估计误差仍是主要瓶颈。	继续增加有效独立样本通常有价值。
增加样本后训练和验证误差收敛到较高值	近似误差或不可约噪声较大。	改变模型族、表示、任务定义或数据质量。
训练误差异常高但理论上类应能拟合	优化误差、实现错误或参数搜索范围不合适。	检查梯度、初始化、学习率、停止条件和代码实现。

易错点、反例与失败模式

“训练误差低、验证误差高”不必然只由模型过大引起。还应检查： $P_{\text{train}} \neq P_{\text{validation}}$ ，标签规则不一致、预处理差异、重复样本、时间漂移和实现错误。
同样，“训练误差高”也不能直接断言近似误差高；若算法没有求得近似 ERM，优化误差也可能是主因。

9.8 SRM、验证与正则化的关系

正则化 ERM 的 oracle inequality 为 $L_P(A_\lambda(S)) \lesssim L_P(w^*) + \lambda \|w^*\|^2 + \frac{\text{稳定性常数}}{\lambda m}$ 。理论最优 λ 依赖未知的 $\|w^*\|$, ρ , P 。实践中通常用验证集选择 λ :

$$\hat{\lambda} \in \arg \min_{\lambda \in \Lambda} \hat{L}_V(A_\lambda(S_{\text{tr}})). \quad (9.27)$$

其逻辑关系为:

正则化: 形成不同有效复杂度的模型候选;

SRM: 最小化经验风险加理论复杂度罚项;

validation: 以独立数据估计候选模型风险;

test: 对最终完整流程作一次独立评估。

9.9 典型题型与满分模板

例 9.6 (基础题: 有限候选模型选择). 若验证集大小为 $m_v = 1000$, 候选模型数 $r = 20$, 置信度为 0.95, 则 $\alpha_v = \sqrt{\frac{\ln(2 \cdot 20 / 0.05)}{2000}}$ 。被选模型相对于候选集中真实风险最优模型的额外误差至多为 $2\alpha_v$ 的高概率上界。不能只报告单个模型验证误差的 Hoeffding 项而漏掉 $\ln r$ 。

例 9.7 (综合题: 正则参数搜索). 设 $\Lambda = \{10^{-4}, 10^{-3}, \dots, 10^2\}$ 。正确流程是:

1. 对每个 λ 只用训练集拟合;
2. 用同一独立验证集比较;
3. 选择 $\hat{\lambda}$;
4. 使用训练集与验证集的并集重新拟合最终模型;
5. 只在此后使用测试集一次。

若根据测试结果再次改变 λ , 测试误差失去最终独立评估意义。

答题方法

模型选择题的满分结构:

1. 定义候选模型、训练数据、验证数据和测试数据;
2. 写每个候选模型的训练目标;
3. 写选择规则: $\arg \min_j \hat{L}_V(h_j)$;
4. 说明候选集合必须与验证集独立;
5. 写有限候选统一界及 $\ln r$ 项;
6. 写选中模型的 2α 超额风险链;
7. 若用 cross-validation, 写 fold 训练、平均验证误差和最终重训;
8. 给出训练次数和主要计算复杂度;
9. 最后说明测试集只用于最终评估;

10. 列出泄漏风险和失败模式。

SRM 证明题的满分结构：

1. 写 $\mathcal{H} = \bigcup_j \mathcal{H}_j$, $\sum_j w_j \leq 1$;
2. 对第 j 类令失败概率为 $w_j \delta$;
3. 对所有类使用可数 union bound;
4. 得到同时成立的类依赖置信界;
5. 写 SRM 目标为经验风险加复杂度项;
6. 解释复杂模型为什么受到更大罚项。

9.10 真题与训练材料对应

表 9.2: 本部分题目映射

题目	主要标签	满分或正确选择所需内容
[25F-A-MQ3, 0.5 分]	Rademacher complexity	识别其为随机标记拟合能力; 排除“等于 VC”“与样本量无关”等说法。
[25S-A-Q4(a), 5 分]	Replace-one stability	交换 Z_i 与独立 Z'_i ; 证明期望泛化差等于 replace-one 损失差。
[25S-A-Q4(b), 5 分]	正则化 ERM、强凸、Lipschitz	参数距离稳定性; 损失稳定性; 训练拟合项; oracle inequality; 核对 λ 参数化。
[25F-A-MQ1, 0.5 分]	Bias-variance trade-off	较强偏置通常降低方差但可能增大近似误差; 该权衡不只适用于神经网络。
[MLT-Final-MQ2, 2 分, 课程期末题]	正则化目的	控制有效模型复杂度并改善泛化; 不能声称保证零训练误差。
[UML-Ch.7/11]	SRM、validation、cross-validation	作为参考书中的考纲核心内容; 没有虚构为三套博资考中的高频大题。

9.11 快速自测

快速自测

1. SRM 与普通 ERM 的目标函数分别是什么?
2. 权重 w_j 为什么必须满足 $\sum_j w_j \leq 1$?
3. 有 r 个候选模型时, 验证集统一误差为什么含有 $\ln r$?

4. 候选模型可以依赖训练集吗? 可以依赖验证集吗?
5. k -fold cross-validation 选出参数后, 为什么还要在全部训练数据上重训?
6. 模型选择曲线中的验证误差一定呈 U 形吗?
7. 使用测试集选择超参数后, 测试集的角色发生了什么变化?
8. 训练误差高时, 如何区分近似误差和优化误差?



第十章 线性回归、逻辑回归、决策树与最近邻

10.1 线性回归与 Ridge Regression

重要性等级: **A**

- 线性回归是最小二乘、正规方程、梯度、Hessian、正则化和核化的统一基础。
- 其主要考查形式不是背诵模型名称，而是：写清数据矩阵维度、推导梯度和正规方程、讨论解的存在性与唯一性、解释 ridge 参数化，并给出训练复杂度。
- [MLT-Practice-Q6, 课程训练题型, 不是博资考真题] 进一步要求从 ridge regression 推导 kernel ridge regression。

10.1.1 统一数据与参数约定

给定监督回归样本 $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$, $\mathbf{x}_i \in \mathbb{R}^d$, $y_i \in \mathbb{R}$ 。全文采用列向量约定，并令

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_m^\top \end{bmatrix} \in \mathbb{R}^{m \times d}, \quad \mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \in \mathbb{R}^m. \quad (10.1)$$

无偏置线性预测器为 $h_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^\top \mathbf{x}$, $\mathbf{w} \in \mathbb{R}^d$ 。若包含偏置 b ，可令 $\tilde{\mathbf{x}} = \begin{bmatrix} \mathbf{x} \\ 1 \end{bmatrix}$, $\tilde{\mathbf{w}} = \begin{bmatrix} \mathbf{w} \\ b \end{bmatrix}$ ，将其转化为增广空间中的齐次线性模型。

10.1.2 最小二乘目标、梯度与 Hessian

采用平均风险和 1/2 归一化：

$$J_{\text{LS}}(\mathbf{w}) = \frac{1}{2m} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2. \quad (10.2)$$

令 $\mathbf{r}(\mathbf{w}) = \mathbf{X}\mathbf{w} - \mathbf{y} \in \mathbb{R}^m$ 。则

$$\nabla J_{\text{LS}}(\mathbf{w}) = \frac{1}{m} \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) \in \mathbb{R}^d, \quad (10.3)$$

$$\nabla^2 J_{\text{LS}}(\mathbf{w}) = \frac{1}{m} \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{d \times d}. \quad (10.4)$$

维度核对: $\mathbf{X}^\top \underbrace{(\mathbf{X}\mathbf{w} - \mathbf{y})}_{\mathbb{R}^m} \in \mathbb{R}^d$ 。



由于 $\mathbf{v}^\top \nabla^2 J_{\text{LS}} \mathbf{v} = \frac{1}{m} \|\mathbf{X}\mathbf{v}\|_2^2 \geq 0$, 最小二乘目标是凸函数。一阶最优性条件为

$$\mathbf{X}^\top \mathbf{X} \mathbf{w} = \mathbf{X}^\top \mathbf{y}, \quad (10.5)$$

称为正规方程 (normal equation)。

命题 10.1 (最小二乘解的存在性与唯一性). 1. 正规方程总有解;

2. 若 $\text{rank}(\mathbf{X}) = d$, 则解唯一, 且

$$\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}; \quad (10.6)$$

3. 若 $\text{rank}(\mathbf{X}) < d$, 则极小解通常不唯一, 其中欧氏范数最小的解为

$$\hat{\mathbf{w}}_{\min} = \mathbf{X}^\dagger \mathbf{y}, \quad (10.7)$$

其中 $\mathbf{X}^\dagger$ 是 Moore-Penrose 伪逆。

证明. 目标函数连续、非负, 且只依赖于 $\mathbf{X}\mathbf{w}$ 。最优预测向量是 $\mathbf{y}$ 到 $\text{range}(\mathbf{X})$ 的正交投影, 因此最优预测总存在。

若 $\text{rank}(\mathbf{X}) = d$, 则 $\mathbf{X}^\top \mathbf{X} \succ 0$, 目标严格凸, 故极小点唯一, 并由正规方程得到式 (10.6)。

若秩不足, 则 $\ker(\mathbf{X}) \neq \{\mathbf{0}\}$ 。若 $\hat{\mathbf{w}}$ 是一个极小解, 则对任意 $\mathbf{v} \in \ker(\mathbf{X})$, $\mathbf{X}(\hat{\mathbf{w}} + \mathbf{v}) = \mathbf{X}\hat{\mathbf{w}}$, 故 $\hat{\mathbf{w}} + \mathbf{v}$ 也是极小解。伪逆解是该仿射解集中范数最小者。□

10.1.3 Ridge regression

全文主约定为

$$J_{\text{ridge}}(\mathbf{w}) = \frac{1}{2m} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 + \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad \lambda > 0. \quad (10.8)$$

其梯度与 Hessian 为

$$\nabla J_{\text{ridge}}(\mathbf{w}) = \frac{1}{m} \mathbf{X}^\top (\mathbf{X}\mathbf{w} - \mathbf{y}) + \lambda \mathbf{w}, \quad (10.9)$$

$$\nabla^2 J_{\text{ridge}}(\mathbf{w}) = \frac{1}{m} \mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}_d \succ 0. \quad (10.10)$$

因此解总存在且唯一:

$$\hat{\mathbf{w}}_\lambda = (\mathbf{X}^\top \mathbf{X} + m\lambda \mathbf{I}_d)^{-1} \mathbf{X}^\top \mathbf{y}. \quad (10.11)$$

若附件或题面写成 $\lambda_{\text{alt}} \|\mathbf{w}\|^2 + \frac{1}{2m} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$, 则 $\lambda = 2\lambda_{\text{alt}}$ 。若偏置不正则化, 应使用 $\frac{\lambda}{2} \tilde{\mathbf{w}}^\top \begin{bmatrix} \mathbf{I}_d & \mathbf{0} \\ \mathbf{0}^\top & 0 \end{bmatrix} \tilde{\mathbf{w}}$,

不能把偏置是否正则化静默省略。

易错点、反例与失败模式

Ridge 的三个作用必须区分:

1. **统计作用**: 限制参数范数, 控制有效模型复杂度;
2. **代数作用**: 使 $\mathbf{X}^\top \mathbf{X} + m\lambda \mathbf{I}$ 可逆;
3. **优化作用**: 使目标至少 λ -强凸, 保证唯一解并改善条件数。

Ridge 通常增加训练误差, 但可能降低测试误差。

10.1.4 训练复杂度

直接正规方程实现需要：

$$\text{构造 } \mathbf{X}^\top \mathbf{X} : O(md^2),$$

$$\text{构造 } \mathbf{X}^\top \mathbf{y} : O(md),$$

$$\text{求解 } d \times d \text{ 线性系统} : O(d^3),$$

$$\text{存储数据} : O(md),$$

$$\text{存储正规矩阵} : O(d^2).$$

不应在数值实现中显式计算矩阵逆；应使用 Cholesky、QR、SVD 或线性系统求解器。若 d 极大，迭代法每次全梯度代价为 $O(md)$ 。

10.2 逻辑回归

重要性等级：A

- 必须熟练区分概率输出、判别边界、负对数似然和零一损失。
- 梯度、Hessian、凸性和完全分离时 MLE 不存在，是常见推导与易错点。
- [MLT-HW2-Q1, 课程作业] 使用 sigmoid、交叉熵和随机梯度更新训练二分类逻辑回归；该题不是博资考真题。

10.2.1 二分类模型

本节采用标签 $y_i \in \{0, 1\}$ 。定义

$$z_i = \mathbf{w}^\top \mathbf{x}_i + b, \quad (10.12)$$

$$p_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}, \quad (10.13)$$

$$\log \frac{p_i}{1 - p_i} = z_i. \quad (10.14)$$

条件分布为

$$P_\theta(Y = y | \mathbf{x}) = p(\mathbf{x})^y [1 - p(\mathbf{x})]^{1-y}. \quad (10.15)$$

负对数似然与二元交叉熵相同：


$$J_{\log}(\mathbf{w}, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]. \quad (10.16)$$

等价地，

$$J_{\log} = \frac{1}{m} \sum_{i=1}^m [\ln(1 + e^{z_i}) - y_i z_i]. \quad (10.17)$$

若使用标签 $\tilde{y}_i = 2y_i - 1 \in \{-1, +1\}$ ，则单样本损失为

$$\ell_{\log}(\mathbf{w}, b; (\mathbf{x}_i, \tilde{y}_i)) = \ln \left(1 + e^{-\tilde{y}_i (\mathbf{w}^\top \mathbf{x}_i + b)} \right). \quad (10.18)$$



10.2.2 梯度与 Hessian

令 $\mathbf{p} = (p_1, \dots, p_m)^\top$ 。由 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 可得

$$\nabla_{\mathbf{w}} J_{\log} = \frac{1}{m} \mathbf{X}^\top (\mathbf{p} - \mathbf{y}), \quad (10.19)$$

$$\frac{\partial J_{\log}}{\partial b} = \frac{1}{m} \mathbf{1}^\top (\mathbf{p} - \mathbf{y}). \quad (10.20)$$

若加入 $\frac{\lambda}{2} \|\mathbf{w}\|^2$, 则梯度增加 $\lambda \mathbf{w}$ 。

令增广设计矩阵 $\widetilde{\mathbf{X}} = \begin{bmatrix} \mathbf{x}_1^\top & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^\top & 1 \end{bmatrix} \in \mathbb{R}^{m \times (d+1)}$, 并令 $\mathbf{D} = \text{diag}(p_1(1-p_1), \dots, p_m(1-p_m))$ 。则无

正则 Hessian 为

$$\nabla^2 J_{\log} = \frac{1}{m} \widetilde{\mathbf{X}}^\top \mathbf{D} \widetilde{\mathbf{X}} \succeq 0. \quad (10.21)$$

因为对任意 $\mathbf{v}$, $\mathbf{v}^\top \widetilde{\mathbf{X}}^\top \mathbf{D} \widetilde{\mathbf{X}} \mathbf{v} = \|\mathbf{D}^{1/2} \widetilde{\mathbf{X}} \mathbf{v}\|_2^2 \geq 0$ 。因此逻辑回归的负对数似然是凸函数。

若只正则化 $\mathbf{w}$ 而不正则化 b , Hessian 增加 $\lambda \begin{bmatrix} \mathbf{I}_d & \mathbf{0} \\ \mathbf{0}^\top & 0 \end{bmatrix}$ 。

10.2.3 决策边界、概率与失败模式

在阈值 $1/2$ 下, $p(\mathbf{x}) \geq \frac{1}{2} \iff \mathbf{w}^\top \mathbf{x} + b \geq 0$ 。因此逻辑回归有线性决策边界, 但其输出是条件概率模型。

易错点、反例与失败模式

1. 逻辑回归不是对标签做最小二乘; 它最小化 Bernoulli 负对数似然。
2. 决策边界是线性的, 不代表概率函数关于 $\mathbf{x}$ 是线性的。
3. 无正则逻辑回归在完全线性可分数据上可能没有有限 MLE: 若存在 $(\mathbf{w}, b)$ 满足 $\tilde{y}_i(\mathbf{w}^\top \mathbf{x}_i + b) > 0 \quad \forall i$, 则沿 $t(\mathbf{w}, b)$, $t \rightarrow \infty$, 经验 logistic loss 趋于 0, 但通常不在有限参数处达到。
4. 较大的 logit 并不自动等于可靠校准概率; 概率校准仍依赖模型正确性、样本分布和正则化。

10.2.4 多分类逻辑回归

令类别数为 K , $\mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_K] \in \mathbb{R}^{d \times K}$ 。Softmax 概率为

$$p_\theta(y = c | \mathbf{x}) = \frac{\exp(\mathbf{w}_c^\top \mathbf{x} + b_c)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x} + b_j)}. \quad (10.22)$$

交叉熵为

$$J(\mathbf{W}, \mathbf{b}) = -\frac{1}{m} \sum_{i=1}^m \ln p_\theta(y_i | \mathbf{x}_i) + \frac{\lambda}{2} \|\mathbf{W}\|_F^2. \quad (10.23)$$

对第 c 类参数,

$$\nabla_{\mathbf{w}_c} J = \frac{1}{m} \sum_{i=1}^m [p_\theta(c | \mathbf{x}_i) - \mathbf{1}\{y_i = c\}] \mathbf{x}_i + \lambda \mathbf{w}_c. \quad (10.24)$$



若给所有类别权重同时加同一个向量 $\mathbf{a}$, 所有 logit 都增加 $\mathbf{a}^\top \mathbf{x}$, softmax 概率不变。因此无约束参数化具有冗余; 可固定一个参考类别或使用正则化选择代表解。

10.3 决策树

重要性等级: B

- 必须掌握树表示、分裂准则、深度与叶数、剪枝、复杂度和 VC 分析边界。
- [MLT-HW3-Q1, 课程作业] 与 [MLT-Practice-Q8, 课程训练题型] 要求证明有限布尔域上的任意分类函数可由决策树表示。

10.3.1 模型与分裂准则

决策树从根节点开始, 根据测试 $s(\mathbf{x}) \in \{0, 1\}$ 递归选择子节点, 在叶节点输出标签。对实值特征, 常用测试为 $s_{j,t}(\mathbf{x}) = \mathbf{1}\{x_j < t\}$ 。

设某节点样本集合为 S , 类别比例为 $p_c(S) = \frac{|\{i \in S: y_i = c\}|}{|S|}$ 。常用不纯度包括:

$$H(S) = - \sum_{c=1}^K p_c(S) \ln p_c(S), \quad (10.25)$$

$$G(S) = 1 - \sum_{c=1}^K p_c(S)^2. \quad (10.26)$$

二分类时 $G(S) = 2p(1-p)$ 。若分裂后得到子集 $S_1, \dots, S_q$, 信息增益或一般不纯度增益为

$$\text{Gain} = I(S) - \sum_{j=1}^q \frac{|S_j|}{|S|} I(S_j), \quad (10.27)$$

其中 I 可取熵、Gini 或训练误差。

熵使用自然对数或以 2 为底只差正常数, 不改变同一节点候选分裂的排序。

10.3.2 表示能力与 VC 维

命题 10.2 (布尔域上的完全表示). 任意函数 $h: \{0, 1\}^d \rightarrow \{0, 1\}$ 都可由一棵依次查询 $x_1, x_2, \dots, x_d$ 的决策树表示。该树有深度至多 $d+1$ 、叶节点至多 2^d 。因此, 在定义域 $\{0, 1\}^d$ 上, 所有此类树组成的假设类满足

$$\text{VCdim}(\mathcal{H}_{\text{tree}}) = 2^d. \quad (10.28)$$

证明. 每个输入向量 $\mathbf{x} = (x_1, \dots, x_d)$ 对应唯一根到叶路径。在对应叶节点写入 $h(\mathbf{x})$ 即可表示任意 h 。因此整个定义域的所有 2^d 个点可被打散。另一方面, 任何定义在有限域 $\mathcal{X}$ 上的假设类 VC 维不超过 $|\mathcal{X}| = 2^d$ 。□

易错点、反例与失败模式

不能无条件声称: $\text{VCdim}(\text{树类}) = \text{树深度}$ 或 $\text{VCdim}(\text{树类}) = \text{叶节点数}$ 。精确 VC 维依赖:

- 输入域;
- 允许的分裂规则;

- 最大深度或叶数；
- 特征维数；
- 是否允许重复使用特征。

任意大小的实值阈值树通常具有无限 VC 维；受限树类必须单独分析。

10.3.3 剪枝与复杂度

若树深为 D 、节点数为 N_{node} ，则单次预测： $T_{\text{pred}} = O(D)$ ， $M_{\text{model}} = O(N_{\text{node}})$ 。对 m 个样本、 d 个实值特征：

- 朴素地对每个阈值重新计算增益可达 $O(dm^2)$ ；
- 对特征排序并线性扫描候选阈值，可降到约 $O(dm \log m)$ 的单层或 stump 处理量级；
- 完整树复杂度还取决于节点样本划分是否平衡与排序结果能否复用。

剪枝可能增加训练误差，但可降低模型描述长度和估计误差。标准后剪枝应使用独立验证信息、代价复杂度目标或泛化上界，而不是仅比较训练误差。

随机森林。 随机森林对多个树进行多数投票，常同时使用：bootstrap 样本 + 节点处随机特征子集。它通过树间差异降低集成方差，但不等于单棵树的剪枝，也不保证消除偏差或分布偏移。

10.4 k -最近邻

重要性等级：B

- 必须掌握分类与回归定义、距离假设、有限样本或一致性条件、维数灾难、推理复杂度和距离集中。
- 附件没有把 k -NN 设置为博资考高分真题，但它是明确考纲节点。

设 $(\mathcal{X}, \rho)$ 是度量空间，训练集为 $S = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$ 。对测试点 $\mathbf{x}$ ，令 $\rho(\mathbf{x}, \mathbf{x}_{\pi_1}) \leq \dots \leq \rho(\mathbf{x}, \mathbf{x}_{\pi_m})$ 。

分类预测为

$$h_S(\mathbf{x}) \in \arg \max_c \sum_{j=1}^k \mathbf{1}\{y_{\pi_j} = c\}, \quad (10.29)$$


回归预测为

$$h_S(\mathbf{x}) = \frac{1}{k} \sum_{j=1}^k y_{\pi_j}. \quad (10.30)$$

10.4.1 统计保证的条件

“相近输入具有相近标签分布”是一项归纳偏置。附件采用 $\eta(\mathbf{x}) = P(Y = 1 \mid X = \mathbf{x})$ 为 c -Lipschitz 的条件：

$$|\eta(\mathbf{x}) - \eta(\mathbf{x}')| \leq c \|\mathbf{x} - \mathbf{x}'\|_2. \quad (10.31)$$



在 $\mathcal{X} = [0, 1]^d$ 上，附件给出一类有限样本界：

$$\mathbb{E}_S[L_P(h_{1NN})] \leq 2L_P(h^*) + 4c\sqrt{d}m^{-1/(d+1)}. \quad (10.32)$$

其中 h^* 是 Bayes 分类器。

经典一致性结论通常要求随样本量变化的 $k = k_m$ 满足

$$k_m \rightarrow \infty, \quad \frac{k_m}{m} \rightarrow 0, \quad (10.33)$$

并配合适当的度量空间和分布正则条件。因此“ k -NN 总是一致”是错误说法。

10.4.2 维数灾难与距离集中

附件的有限样本率包含 $m^{-1/(d+1)}$ 。要使该项小于 ε ，样本量至少按 $m \gtrsim \left(\frac{c\sqrt{d}}{\varepsilon}\right)^{d+1}$ 增长，体现维数灾难。

在常见独立坐标模型下，若 $D^2(\mathbf{X}, \mathbf{X}') = \sum_{j=1}^d (X_j - X'_j)^2$ ，且各坐标项同分布、均值为 $\mu > 0$ 、方差有限，则

$$\mathbb{E}[D^2] = d\mu, \quad (10.34)$$

$$\text{Var}(D^2) = O(d), \quad (10.35)$$

$$\frac{\sqrt{\text{Var}(D^2)}}{\mathbb{E}[D^2]} = O(d^{-1/2}). \quad (10.36)$$


即平方距离相对其均值集中。这不构成所有分布下的无条件定理，但说明高维中“最近”与“普通”距离可能缺乏显著相对差异。

10.4.3 计算复杂度

朴素实现几乎没有训练计算，只存储样本： $M_{\text{train}} = O(md)$ 。每个查询点计算全部欧氏距离： $T_{\text{query}} = O(md)$ ，再选择前 k 个邻居，可用线性选择或堆结构完成。低维可使用空间索引；高维通常采用近似最近邻，但近似检索会引入额外预测误差。

易错点、反例与失败模式

1. 归一化或标准化会改变距离，因此必须只用训练集拟合预处理参数。
2. 欧氏距离并非任意任务的正确相似度。
3. k 太小方差大， k 太大局部偏差大。
4. 1-NN 训练误差常为零，不代表总体误差为零。
5. 高维性能差既可能来自样本稀疏，也可能来自大量无关特征。



第十一章 支持向量机与核方法

11.1 重要性等级与考情定位

重要性等级：A

- SVM 是 margin、正则化、凸优化、对偶和核技巧的交汇点。
- 核方法在 [26S-A-MQ6, 0.5 分] 中直接考查 PSD 核与 Hilbert 空间特征映射；[MLT-Final-MQ3, 2 分, 课程期末选择题] 直接考查 kernel trick。
- [MLT-Practice-Q5, 课程训练题型] 训练 max-margin 函数的最优值和次梯度；[MLT-Practice-Q6, 课程训练题型] 训练 kernel ridge regression。
- 必须能够完整写出：函数间隔、几何间隔、hard/soft primal、dual、KKT、支持向量、 C 与 λ 的换算、PSD 条件和 representer theorem。

11.2 函数间隔与几何间隔

采用标签 $y_i \in \{-1, +1\}$ 。仿射分类器为 $h_{\mathbf{w}, b}(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x} + b)$ 。样本 $(\mathbf{x}_i, y_i)$ 的函数间隔为

$$\hat{\gamma}_i = y_i(\mathbf{w}^\top \mathbf{x}_i + b). \quad (11.1)$$

几何间隔为

$$\gamma_i = \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|_2}. \quad (11.2)$$

函数间隔随 $(\mathbf{w}, b) \mapsto c(\mathbf{w}, b)$, $c > 0$, 按比例变化, 而分类边界不变; 几何间隔消除了该缩放歧义。

易错点、反例与失败模式

有两种常见“margin”宽度约定:

- 从决策超平面到最近样本的距离: $\gamma = \frac{1}{\|\mathbf{w}\|}$;
- 两条支持超平面 $\mathbf{w}^\top \mathbf{x} + b = \pm 1$ 之间的距离: $\frac{2}{\|\mathbf{w}\|}$ 。

必须说明使用哪一种。

11.3 Hard-margin SVM

线性可分时，标准原问题为

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m. \end{aligned} \quad (11.3)$$

在规范化约束下，最小几何间隔为 $\frac{1}{\|\mathbf{w}\|}$ ，故最小化范数等价于最大化间隔。

11.3.1 对偶问题

引入乘子 $\alpha_i \geq 0$ 。Lagrangian 为

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1]. \quad (11.4)$$

对原变量求驻点：

$$\nabla_{\mathbf{w}} \mathcal{L} = 0 \implies \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad (11.5)$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \implies \sum_{i=1}^m \alpha_i y_i = 0. \quad (11.6)$$

代回得到对偶：

$$\begin{aligned} \max_{\boldsymbol{\alpha} \in \mathbb{R}^m} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.t.} \quad & \alpha_i \geq 0, \quad \sum_{i=1}^m \alpha_i y_i = 0. \end{aligned} \quad (11.7)$$

11.3.2 KKT 条件与支持向量

在可分且满足适当约束资格条件时，KKT 条件为：

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 \geq 0, \quad (11.8)$$


$$\alpha_i \geq 0, \quad (11.9)$$

$$\mathbf{w} - \sum_i \alpha_i y_i \mathbf{x}_i = \mathbf{0}, \quad (11.10)$$

$$\sum_i \alpha_i y_i = 0, \quad (11.11)$$

$$\alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1] = 0. \quad (11.12)$$

若 $\alpha_i > 0$ ，则 $y_i(\mathbf{w}^\top \mathbf{x}_i + b) = 1$ ，该样本位于支持超平面上，称为支持向量。由式 (11.5)， $\mathbf{w} \in \text{span}\{\mathbf{x}_i : \alpha_i > 0\}$ 。



11.4 Soft-margin SVM 与参数化换算

标准 C 参数化为

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \\ & \xi_i \geq 0. \end{aligned} \quad (11.13)$$

固定 $(\mathbf{w}, b)$ 后, 最优松弛量为 $\xi_i = \max\{0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)\}$ 。因此等价于

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max\{0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)\}. \quad (11.14)$$

全文平均损失主约定为

$$\min_{\mathbf{w}, b} \frac{\lambda}{2} \|\mathbf{w}\|^2 + \frac{1}{m} \sum_{i=1}^m \ell_{\text{hinge}, i}, \quad (11.15)$$

其中 $\ell_{\text{hinge}, i} = \max\{0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)\}$ 。将式 (11.15) 除以 λ , 得到

$$C = \frac{1}{m\lambda}. \quad (11.16)$$

若附件采用 $\lambda_{\text{alt}} \|\mathbf{w}\|^2 + \frac{1}{m} \sum_i \ell_i$, 则

$$C = \frac{1}{2m\lambda_{\text{alt}}}. \quad (11.17)$$

11.4.1 Soft-margin 对偶

式 (11.13) 的对偶为

$$\begin{aligned} \max_{\alpha} \quad & \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \\ & \sum_i \alpha_i y_i = 0. \end{aligned} \quad (11.18)$$

KKT 还包括

$$\alpha_i [y_i f_i - 1 + \xi_i] = 0, \quad (11.19)$$

$$(C - \alpha_i) \xi_i = 0. \quad (11.20)$$

非退化情况下可作如下识别:

$$\begin{aligned} \alpha_i = 0 : y_i f_i > 1, \quad & \text{间隔外样本;} \\ 0 < \alpha_i < C : y_i f_i = 1, \quad & \text{位于支持超平面;} \\ \alpha_i = C : y_i f_i \leq 1, \quad & \text{位于间隔内或被误分类.} \end{aligned}$$

11.4.2 Hinge loss 的次梯度

对齐次模型 $\ell_i(\mathbf{w}) = \max\{0, 1 - y_i \mathbf{w}^\top \mathbf{x}_i\}$, 可取

$$\partial \ell_i(\mathbf{w}) = \begin{cases} \{0\}, & y_i \mathbf{w}^\top \mathbf{x}_i > 1, \\ \{-y_i \mathbf{x}_i\}, & y_i \mathbf{w}^\top \mathbf{x}_i < 1, \\ \text{conv}\{0, -y_i \mathbf{x}_i\}, & y_i \mathbf{w}^\top \mathbf{x}_i = 1. \end{cases} \quad (11.21)$$



例 11.1 (课程训练母题: 最大违反量). [MLT-Practice-Q5, 课程训练题型, 不是博资考真题] 定义 $F(\mathbf{w}) = \max_{i \in [m]} (1 - y_i \mathbf{w}^\top \mathbf{x}_i)$, 并设 $\mathbf{w}^*$ 是满足 $y_i \mathbf{w}^\top \mathbf{x}_i \geq 1$ 的最小范数向量。

首先, $F(\mathbf{w}^*) = 0$ 。若 $F(\mathbf{w}^*) < 0$, 则存在 $\delta > 0$ 使 $y_i(\mathbf{w}^*)^\top \mathbf{x}_i \geq 1 + \delta \quad \forall i$ 。于是 $\frac{\mathbf{w}^*}{1+\delta}$ 仍满足所有约束, 但范数更小, 与最小性矛盾。

进一步地, $\min_{\|\mathbf{w}\| \leq \|\mathbf{w}^*\|} F(\mathbf{w}) = 0$ 。若该球内存在 $F(\mathbf{w}) < 0$, 同样可缩放得到比 $\mathbf{w}^*$ 范数更小的可行向量。

若 $F(\mathbf{w}) < 1$, 则对所有 i , $1 - y_i \mathbf{w}^\top \mathbf{x}_i < 1 \implies y_i \mathbf{w}^\top \mathbf{x}_i > 0$, 故 $\mathbf{w}$ 严格分离全部样本。

令活动集合 $I(\mathbf{w}) = \arg \max_i (1 - y_i \mathbf{w}^\top \mathbf{x}_i)$ 。任取 $i^* \in I(\mathbf{w})$, 则 $-y_{i^*} \mathbf{x}_{i^*} \in \partial F(\mathbf{w})$ 。更一般地, 活动次梯度的任意凸组合都是合法次梯度。

11.5 Margin-based generalization

若 $\|\mathbf{x}\| \leq R$, $\|\mathbf{w}\| \leq B$, 且损失关于线性得分是 ρ -Lipschitz, 则 Rademacher 界给出量级

$$L_P(\mathbf{w}) \lesssim \widehat{L}_S(\mathbf{w}) + O\left(\frac{\rho RB}{\sqrt{m}}\right) + O\left(\sqrt{\frac{\ln(1/\delta)}{m}}\right). \quad (11.22)$$

在规范化可分情形, $B = \frac{1}{\gamma}$, 故复杂度主要依赖 $\left(\frac{R}{\gamma}\right)^2$, 而非显式依赖特征空间维数。

易错点、反例与失败模式

Margin 界成立需要控制输入尺度。若将所有输入乘以常数 a , 函数间隔和几何距离都会改变。没有 $\|\mathbf{x}\| \leq R$ 或等价归一化时, “大间隔”不能形成尺度不变的学习保证。

11.6 核、Gram 矩阵与 PSD 条件

定义 11.2 (正半定核). 对称函数 $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ 称为正半定核, 如果对任意 m , $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathcal{X}$, $\mathbf{c} \in \mathbb{R}^m$, 其 Gram 矩阵 $\mathbf{G}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$ 满足

$$\mathbf{c}^\top \mathbf{G} \mathbf{c} = \sum_{i,j=1}^m c_i c_j K(\mathbf{x}_i, \mathbf{x}_j) \geq 0. \quad (11.23)$$

定理 11.3 (核与特征映射刻画). K 是 PSD 核, 当且仅当存在某个可能无限维的 Hilbert 空间 $\mathcal{H}_K$ 和映射 $\psi: \mathcal{X} \rightarrow \mathcal{H}_K$ 使

$$K(\mathbf{x}, \mathbf{x}') = \langle \psi(\mathbf{x}), \psi(\mathbf{x}') \rangle_{\mathcal{H}_K}. \quad (11.24)$$

证明或推导框架

若存在特征映射, 则 $\sum_{i,j} c_i c_j K(\mathbf{x}_i, \mathbf{x}_j) = \|\sum_i c_i \psi(\mathbf{x}_i)\|_{\mathcal{H}_K}^2 \geq 0$ 。

反向构造时, 先取所有有限线性组合 $f(\cdot) = \sum_i c_i K(\cdot, \mathbf{x}_i)$, 并定义半内积 $\langle \sum_i c_i K(\cdot, \mathbf{x}_i), \sum_j d_j K(\cdot, \mathbf{x}'_j) \rangle = \sum_{i,j} c_i d_j K(\mathbf{x}_i, \mathbf{x}'_j)$ 。由 PSD 性该半内积非负。再对零范数子空间取商, 并做完备化, 得到 Hilbert 空间。令 $\psi(\mathbf{x}) = K(\cdot, \mathbf{x})$, 即可得到式 (11.24)。

易错点、反例与失败模式

1. 仅有 $K(x, x) \geq 0$ 不足以保证 K 是核；必须对所有有限 Gram 矩阵检查 PSD。
2. 特征映射不要求有限维。
3. 特征映射不唯一：正交变换、等距嵌入或加入恒为零的坐标都不改变核。
4. 任意相似度函数不一定是核。
5. 核技巧不是显式构造全部高维特征，而是用内积值替代显式坐标。

11.6.1 核的基本构造

若 K_1, K_2 是 PSD 核且 $a, b \geq 0$ ，则

$$aK_1 + bK_2 \text{ 是 PSD 核,} \quad (11.25)$$

$$K_1 K_2 \text{ 是 PSD 核,} \quad (11.26)$$

$$K_f(x, x') = f(x)f(x') \text{ 是 PSD 核.} \quad (11.27)$$

常见例子：

$$K_{\text{lin}}(x, x') = x^\top x', \quad (11.28)$$

$$K_{\text{poly}}(x, x') = (c + x^\top x')^q, \quad c \geq 0, q \in \mathbb{N}, \quad (11.29)$$

$$K_{\text{RBF}}(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right). \quad (11.30)$$

例 11.4 (显式特征映射构造). [MLT-HW2-Q2, 课程作业] 给定 $K(i, j) = \min\{i, j\}$, $i, j \in \{1, \dots, N\}$ 。定义 $\psi(j) = (\underbrace{1, \dots, 1}_{j \text{ 个}}, \underbrace{0, \dots, 0}_{N-j \text{ 个}}) \in \mathbb{R}^N$ 。则 $\langle \psi(i), \psi(j) \rangle = \sum_{r=1}^N \mathbf{1}\{r \leq i\} \mathbf{1}\{r \leq j\} = \min\{i, j\}$ 。因此该函数是有效核。

11.7 Representer theorem

定理 11.5 (Representer theorem). 设 $\psi: \mathcal{X} \rightarrow \mathcal{H}$ ，并考虑


$$\min_{\mathbf{w} \in \mathcal{H}} \{F(\langle \mathbf{w}, \psi(x_1) \rangle, \dots, \langle \mathbf{w}, \psi(x_m) \rangle) + R(\|\mathbf{w}\|_{\mathcal{H}})\}, \quad (11.31)$$

其中 R 单调不减。则至少存在一个最优解具有形式

$$\mathbf{w}^* = \sum_{i=1}^m \alpha_i \psi(x_i). \quad (11.32)$$

若 R 严格单调递增，则每个最优解都位于训练特征张成的闭子空间中。

证明. 令 $\mathcal{M} = \text{span}\{\psi(x_1), \dots, \psi(x_m)\}$ 。任意 $\mathbf{w}$ 可正交分解为 $\mathbf{w} = \mathbf{w}_{\parallel} + \mathbf{w}_{\perp}$, $\mathbf{w}_{\parallel} \in \mathcal{M}$, $\mathbf{w}_{\perp} \perp \mathcal{M}$ 。对每个训练点, $\langle \mathbf{w}, \psi(x_i) \rangle = \langle \mathbf{w}_{\parallel}, \psi(x_i) \rangle$ 。因此经验拟合项不变。另一方面, $\|\mathbf{w}\|^2 = \|\mathbf{w}_{\parallel}\|^2 + \|\mathbf{w}_{\perp}\|^2 \geq \|\mathbf{w}_{\parallel}\|^2$ 。由 R 单调不减, 删除 $\mathbf{w}_{\perp}$ 不增加目标值。故存在最优解位于 $\mathcal{M}$ 中。 $\square$



11.8 Kernel SVM 与 Kernel Ridge Regression

11.8.1 Kernel SVM

在对偶式 (11.18) 中, 将 $\mathbf{x}_i^\top \mathbf{x}_j$ 替换为 $K(x_i, x_j)$ 即可得到 kernel SVM:

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j), \quad (11.33)$$

约束仍为 $0 \leq \alpha_i \leq C$, $\sum_i \alpha_i y_i = 0$ 。预测为

$$f(x) = \sum_{i=1}^m \alpha_i y_i K(x_i, x) + b. \quad (11.34)$$

只有 $\alpha_i > 0$ 的训练样本参与预测。

计算代价:

Gram 构造: $O(m^2 T_K)$,

Gram 存储: $O(m^2)$,

单次预测: $O(s T_K)$,

其中 T_K 是一次核计算代价, s 是支持向量数。通用稠密 QP 的求解代价可达 $O(m^3)$ 量级, 具体取决于算法和稀疏结构。

11.8.2 Kernel ridge regression

采用附件参数化:

$$\min_{\mathbf{w} \in \mathcal{H}} \left\{ \lambda \|\mathbf{w}\|_{\mathcal{H}}^2 + \frac{1}{2m} \sum_{i=1}^m (\langle \mathbf{w}, \psi(x_i) \rangle - y_i)^2 \right\}. \quad (11.35)$$

由 representer theorem, $\mathbf{w} = \sum_{j=1}^m \alpha_j \psi(x_j)$ 。令 $\mathbf{G}_{ij} = K(x_i, x_j)$, 则

$$\|\mathbf{w}\|_{\mathcal{H}}^2 = \boldsymbol{\alpha}^\top \mathbf{G} \boldsymbol{\alpha}, \quad (11.36)$$

$$\begin{bmatrix} \langle \mathbf{w}, \psi(x_1) \rangle \\ \vdots \\ \langle \mathbf{w}, \psi(x_m) \rangle \end{bmatrix} = \mathbf{G} \boldsymbol{\alpha}. \quad (11.37)$$

系数目标为

$$g(\boldsymbol{\alpha}) = \lambda \boldsymbol{\alpha}^\top \mathbf{G} \boldsymbol{\alpha} + \frac{1}{2m} \|\mathbf{G} \boldsymbol{\alpha} - \mathbf{y}\|_2^2. \quad (11.38)$$

其梯度为

$$\nabla g(\boldsymbol{\alpha}) = 2\lambda \mathbf{G} \boldsymbol{\alpha} + \frac{1}{m} \mathbf{G}(\mathbf{G} \boldsymbol{\alpha} - \mathbf{y}). \quad (11.39)$$


取

$$\boxed{\boldsymbol{\alpha}^* = (\mathbf{G} + 2m\lambda \mathbf{I}_m)^{-1} \mathbf{y}} \quad (11.40)$$

即可使梯度为零。由于目标凸, 该解对应一个全局极小解。

对新样本定义 $\mathbf{k}(x) = (K(x_1, x), \dots, K(x_m, x))^\top$, 预测为

$$h(x) = \mathbf{k}(x)^\top \boldsymbol{\alpha}^*. \quad (11.41)$$



若主约定改为 $\frac{\lambda}{2}\|\mathbf{w}\|^2 + \frac{1}{2m}\sum_i(\cdots)^2$, 则闭式解变为

$$\boldsymbol{\alpha}^* = (\mathbf{G} + m\lambda\mathbf{I})^{-1}\mathbf{y}. \quad (11.42)$$

训练复杂度主要为: $O(m^2T_K) + O(m^3)$, 存储 $O(m^2)$ 。

答题方法

核方法证明题的标准步骤:

1. 明确核是否对称;
2. 若构造特征映射, 逐坐标计算内积;
3. 若用 PSD 条件, 写出 $\sum_{i,j} c_i c_j K(x_i, x_j) \geq 0$;
4. 若核化算法, 先证明原解位于训练特征张成空间;
5. 令 $\mathbf{w} = \sum_i \alpha_i \psi(x_i)$;
6. 将所有预测和范数改写为 Gram 矩阵;
7. 推导 $\boldsymbol{\alpha}$ 的目标、梯度和闭式解;
8. 最后写测试点预测, 不得只写训练阶段。



第十二章 压缩感知、多分类与神经网络学习理论扩展

12.1 压缩感知

重要性等级：A

- 压缩感知是明确考纲节点，必须掌握稀疏先验、欠定系统、 ℓ_0 与 ℓ_1 、basis pursuit、RIP、精确与近似恢复。
- 三套博资考未设置该主题的大题，因此不能称其为历年高频真题；但它是适合作为构造题、条件辨析题或证明框架题的考纲核心。

12.1.1 稀疏表示与欠定测量

设信号 $\mathbf{x} = \mathbf{U}\boldsymbol{\alpha} \in \mathbb{R}^d$ ，其中 $\mathbf{U} \in \mathbb{R}^{d \times d}$ 为固定正交基， $\|\boldsymbol{\alpha}\|_0 = |\{j : \alpha_j \neq 0\}| \leq s$ 。通过 $q < d$ 个线性测量 $\mathbf{y} = \mathbf{M}\mathbf{x} = \underbrace{\mathbf{M}\mathbf{U}}_{\mathbf{A}}\boldsymbol{\alpha}$ ， $\mathbf{A} \in \mathbb{R}^{q \times d}$ 。由于 $q < d$ ，线性系统通常有无穷多解。恢复依赖“真实系数稀疏”这一额外归纳偏置。

理想恢复问题为

$$\min_{\mathbf{z} \in \mathbb{R}^d} \|\mathbf{z}\|_0 \quad \text{s.t.} \quad \mathbf{A}\mathbf{z} = \mathbf{y}. \quad (12.1)$$

该目标是组合性的，通常难以计算。Basis pursuit 使用凸松弛：

$$\min_{\mathbf{z} \in \mathbb{R}^d} \|\mathbf{z}\|_1 \quad \text{s.t.} \quad \mathbf{A}\mathbf{z} = \mathbf{y}. \quad (12.2)$$

有噪声 $\mathbf{y} = \mathbf{A}\boldsymbol{\alpha} + \mathbf{e}$ ， $\|\mathbf{e}\|_2 \leq \eta$ 时，可使用

$$\min_{\mathbf{z}} \|\mathbf{z}\|_1 \quad \text{s.t.} \quad \|\mathbf{A}\mathbf{z} - \mathbf{y}\|_2 \leq \eta. \quad (12.3)$$

12.1.2 Null-space property

定义 12.1 (阶数 s 的 null-space property). 矩阵 $\mathbf{A}$ 满足阶数 s 的 NSP，如果对任意 $\mathbf{h} \in \ker(\mathbf{A}) \setminus \{\mathbf{0}\}$ 及任意 $T \subseteq [d]$ ， $|T| \leq s$ ，都有

$$\|\mathbf{h}_T\|_1 < \|\mathbf{h}_{T^c}\|_1. \quad (12.4)$$

定理 12.2 (NSP 与精确 ℓ_1 恢复). $\mathbf{A}$ 满足阶数 s 的 NSP，当且仅当每个 s -稀疏向量 $\boldsymbol{\alpha}$ 都是 $\min_{\mathbf{z}: \mathbf{A}\mathbf{z} = \mathbf{A}\boldsymbol{\alpha}} \|\mathbf{z}\|_1$ 的唯一解。



证明. 设 α 的支撑集为 T , $|T| \leq s$. 任意其他可行解为 $z = \alpha + h$, $h \in \ker(A) \setminus \{0\}$. 于是

$$\begin{aligned}\|z\|_1 &= \|\alpha_T + h_T\|_1 + \|h_{T^c}\|_1 \\ &\geq \|\alpha_T\|_1 - \|h_T\|_1 + \|h_{T^c}\|_1 \\ &> \|\alpha\|_1.\end{aligned}\tag{12.5}$$

故 α 是唯一极小解。

反之, 若 NSP 失败, 则存在 $h \neq 0$ 和 $|T| \leq s$ 使 $\|h_T\|_1 \geq \|h_{T^c}\|_1$. 取 $\alpha = -h_T$, $z = h_{T^c}$. 则 α 为 s -稀疏, 且 $z - \alpha = h \in \ker(A)$, 所以 $Az = A\alpha$, 但 $\|z\|_1 = \|h_{T^c}\|_1 \leq \|h_T\|_1 = \|\alpha\|_1$. 因此 α 不是唯一 ℓ_1 极小解。□

12.1.3 Restricted Isometry Property

定义 12.3 (RIP). 矩阵 A 满足阶数 s 、常数 $\delta_s \in [0, 1)$ 的 RIP, 如果对所有 s -稀疏向量 z ,

$$(1 - \delta_s)\|z\|_2^2 \leq \|Az\|_2^2 \leq (1 + \delta_s)\|z\|_2^2.\tag{12.6}$$

若 $\delta_{2s} < 1$, 则任意两个 s -稀疏向量不可能产生同一测量: 若 $Az_1 = Az_2$, 则 $h = z_1 - z_2$ 至多 $2s$ -稀疏, 且 $0 = \|Ah\|^2 \geq (1 - \delta_{2s})\|h\|^2$, 故 $h = 0$. 这保证 ℓ_0 恢复的唯一性, 但尚不足以自动保证 ℓ_1 松弛成功。

附件采用的充分条件为

$$\delta_{2s} < \frac{1}{1 + \sqrt{2}}.\tag{12.7}$$

在该条件下, basis pursuit 对任意 s -稀疏向量精确恢复。

对一般非精确稀疏向量, 令 x_s 保留 x 的绝对值最大的 s 个坐标。附件给出

$$\|\hat{x} - x\|_2 \leq 2 \frac{1 + \rho}{1 - \rho} \frac{\|x - x_s\|_1}{\sqrt{s}}, \quad \rho = \frac{\sqrt{2}\delta_{2s}}{1 - \delta_{2s}}.\tag{12.8}$$

若 $x = x_s$, 右端为零, 退化为精确恢复。

随机高斯测量矩阵在测量数约为

$$q = O\left(s \log \frac{d}{s}\right)\tag{12.9}$$

时, 以高概率满足相应 RIP; 附件使用的简化表述为 $O(s \log d)$ 量级。

12.1.4 与 PCA、特征选择和正则化的区别

表 12.1: 压缩感知与相邻概念的区别

方法	核心假设	目标与恢复方式
PCA	样本整体接近低维线性子空间。	学习数据相关子空间; 编码和线性解码; 优化平均平方重构误差。
压缩感知	每个信号在已知基中稀疏或近似稀疏。	使用欠定线性混合测量; 通过 ℓ_1 非线性解码恢复。

方法	核心假设	目标与恢复方式
特征选择	少数原始特征与预测任务相关。	选择或稀疏化预测参数；通常不要求从欠定测量重构完整信号。
Ridge	参数应具有较小 ℓ_2 范数。	产生稠密收缩解，不直接鼓励精确零坐标。
Lasso / ℓ_1 正则	预测参数应稀疏。	与 basis pursuit 同用 ℓ_1 几何，但监督预测目标与信号恢复约束不同。

易错点、反例与失败模式

1. ℓ_1 不是 ℓ_0 的无条件等价替代；等价需要 NSP、RIP 等条件。
2. $q < d$ 不意味着无法恢复；稀疏先验可提供额外可辨识性。
3. RIP 是对所有稀疏向量的近等距条件，不是只对训练信号检查。
4. 精确稀疏恢复和近似稀疏恢复的误差结论不同。

12.2 多分类与 Multivector Construction

重要性等级：S

- 该主题未在简要考纲中单独列出，但曾在 [26S-A-Q4, 7 分] 中实际考查。
- [MLT-Practice-Q7, 课程训练题型] 与该真题具有直接母题关系，但不是博资考真题。
- 满分要求是构造权重、计算所有类别得分差并证明 generalized hinge loss 为零。

设 $\mathcal{Y} = [K] = \{1, \dots, K\}$, $\mathbf{x} \in \mathbb{R}^n$ 。将偏置并入输入： $\tilde{\mathbf{x}} = \begin{bmatrix} \mathbf{x} \\ 1 \end{bmatrix} \in \mathbb{R}^{n+1}$ 。Multivector 映射定义为

$$\Psi(\mathbf{x}, y) = \begin{bmatrix} \mathbf{0} \\ \vdots \\ \tilde{\mathbf{x}} \\ \vdots \\ \mathbf{0} \end{bmatrix} \in \mathbb{R}^{K(n+1)}, \quad (12.10)$$

其中只有第 y 个块为 $\tilde{\mathbf{x}}$ 。

令 $\mathbf{w} = [\mathbf{w}_1; \dots; \mathbf{w}_K]$, $\mathbf{w}_c \in \mathbb{R}^{n+1}$ 。则

$$\langle \mathbf{w}, \Psi(\mathbf{x}, c) \rangle = \mathbf{w}_c^\top \tilde{\mathbf{x}}. \quad (12.11)$$

预测器为

$$h_{\mathbf{w}}(\mathbf{x}) = \arg \max_{c \in [K]} \mathbf{w}_c^\top \tilde{\mathbf{x}}. \quad (12.12)$$



12.2.1 Generalized hinge loss

对代价函数 $\Delta(c, y) \geq 0$, $\Delta(y, y) = 0$, 定义

$$\ell_{\text{multi}}(\mathbf{w}; (\mathbf{x}, y)) = \max_{c \in [K]} [\Delta(c, y) + \langle \mathbf{w}, \Psi(\mathbf{x}, c) - \Psi(\mathbf{x}, y) \rangle]. \quad (12.13)$$

它是若干仿射函数的最大值, 因此关于 $\mathbf{w}$ 凸。并且 $\ell_{\text{multi}} \geq \Delta(h_{\mathbf{w}}(\mathbf{x}), y)$ 。

12.2.2 历年真题构造

假设每类数据位于中心 μ_y 、半径 $r > 1$ 的球中: $\mathbf{x} = \mu_y + \mathbf{v}$, $\|\mathbf{v}\| \leq r$, 且类中心满足 $\|\mu_i - \mu_j\| > 4r$, $i \neq j$ 。按题目提示构造

$$\mathbf{w}_i = \begin{bmatrix} \mu_i \\ -\frac{1}{2}\|\mu_i\|^2 \end{bmatrix}. \quad (12.14)$$

第 i 类得分为

$$\begin{aligned} s_i(\mathbf{x}) &= \mu_i^\top \mathbf{x} - \frac{1}{2}\|\mu_i\|^2 \\ &= \frac{1}{2}\|\mathbf{x}\|^2 - \frac{1}{2}\|\mathbf{x} - \mu_i\|^2. \end{aligned} \quad (12.15)$$

因此最大化得分等价于选择最近中心。

对真实类别 y 与任意 $j \neq y$,

$$\|\mathbf{x} - \mu_y\| \leq r, \quad (12.16)$$

$$\|\mathbf{x} - \mu_j\| \geq \|\mu_j - \mu_y\| - \|\mathbf{x} - \mu_y\| > 3r. \quad (12.17)$$

故

$$\begin{aligned} s_y(\mathbf{x}) - s_j(\mathbf{x}) &= \frac{1}{2} [\|\mathbf{x} - \mu_j\|^2 - \|\mathbf{x} - \mu_y\|^2] \\ &> \frac{1}{2}(9r^2 - r^2) = 4r^2. \end{aligned} \quad (12.18)$$

取零一代价 $\Delta(j, y) = \mathbf{1}\{j \neq y\}$ 。当 $j \neq y$ 时, $\Delta(j, y) + s_j - s_y < 1 - 4r^2 < 0$ 。当 $j = y$ 时, 该表达式恰为 0。所以

$$\boxed{\ell_{\text{multi}}(\mathbf{w}; (\mathbf{x}, y)) = 0} \quad (12.19)$$

对所有训练样本成立。

答题方法

[26S-A-Q4, 7 分] 的满分步骤:

1. 写清 $\Psi(\mathbf{x}, y) \in \mathbb{R}^{K(n+1)}$;
2. 将 $\mathbf{w}$ 分成 K 个块;
3. 写每类得分 $s_i = \mu_i^\top \mathbf{x} - \|\mu_i\|^2/2$;
4. 配平方得到最近中心形式;
5. 用反三角不等式得到错误中心距离 $> 3r$;

6. 计算得分间隔 $> 4r^2$;
7. 将得分差代入 generalized hinge loss;
8. 说明正确类别项为 0、其他项严格小于 0，因而最大值为 0。

12.3 神经网络的表达能力、VC 维与可学习性

重要性等级：S

- [25F-A-Q13, 5 分] 要求构造 sigmoid 通用逼近网络; [26S-A-MQ3, 0.5 分] 考查 ReLU 网络的分段线性性质; [26S-A-Q5, 5 分] 要求证明 ReLU 网络与 sigmoid 网络在全空间表示同一函数时只能得到常数。
- [MLT-HW3-Q4, 课程作业] 进一步训练“逼近所有 Lipschitz 函数所需网络规模可随维数指数增长”。
- 必须区分：表达存在性、网络规模、VC 维、样本复杂度和训练计算复杂度。

12.3.1 三类不同命题

表 12.2: 神经网络学习理论中的三个层面

层面	典型问题	不能推出什么
表达能力	是否存在某组参数近似目标函数?	不保证网络规模小、样本少或参数可计算。
统计复杂度	固定架构函数类的 VC 维或 Rademacher complexity 多大?	不保证经验风险最小化可高效求解。
优化复杂度	是否能在合理时间内找到低经验风险参数?	训练成功不自动给出总体风险保证。


有限 ReLU 网络计算连续分段仿射函数; 输入空间被有限个多面体区域划分, 每个区域上 $f(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + c$ 。区域数可随深度和宽度快速增长, 但“增加深度必然降低 VC 维”是错误命题。

有限标准 sigmoid 网络由 $\sigma(t) = \frac{1}{1+e^{-t}}$ 的有限次仿射组合与复合构成, 因此是实解析函数。在无输入到输出的线性跳连、且输出只依赖有界 sigmoid 隐单元的标准架构下, 其输出也是全局有界的。

12.3.2 Sigmoid 网络的构造性通用逼近

定理 12.4 (Lipschitz 函数的 sigmoid 逼近). 设 $f: [-1, 1]^n \rightarrow [-1, 1]$ 为 ρ -Lipschitz: $|f(\mathbf{x}) - f(\mathbf{x}')| \leq \rho \|\mathbf{x} - \mathbf{x}'\|_2$ 。则对任意 $\varepsilon > 0$, 存在有限 sigmoid 前馈网络 $N: [-1, 1]^n \rightarrow [-1, 1]$ 使

$$\sup_{\mathbf{x} \in [-1, 1]^n} |f(\mathbf{x}) - N(\mathbf{x})| \leq \varepsilon. \quad (12.20)$$



根据附件结论所作的推导补充

以下构造根据 [25F-A-Q13, 5 分] 的“划分小盒、局部常数、网络判定盒子”提示补足必要连接步骤。重点是证明存在性，不声称该构造具有多项式规模。

证明. 若 $\rho = 0$, 则 f 为常数, 结论显然。以下设 $\rho > 0$ 。

取网格边长

$$h \leq \frac{\varepsilon}{16\rho\sqrt{n}}. \quad (12.21)$$

将每个坐标区间 $[-1, 1]$ 划分为 $I_1, \dots, I_M$, $M = O\left(\frac{\rho\sqrt{n}}{\varepsilon}\right)$, 并得到 M^n 个轴对齐盒 $B_j = I_{j_1} \times \dots \times I_{j_n}$ 。在每个盒内选择中心 $\mathbf{c}_j$ 。若 $\mathbf{x} \in B_j$, 则

$$|f(\mathbf{x}) - f(\mathbf{c}_j)| \leq \rho\sqrt{n}h \leq \frac{\varepsilon}{16}. \quad (12.22)$$

下面构造软盒选择器。设一维分割点为 $-1 = t_0 < t_1 < \dots < t_M = 1$ 。对斜率参数 $\beta > 0$, 定义

$$q_1(t) = 1 - \sigma(\beta(t - t_1)), \quad (12.23)$$

$$q_j(t) = \sigma(\beta(t - t_{j-1})) - \sigma(\beta(t - t_j)), \quad 2 \leq j \leq M-1, \quad (12.24)$$

$$q_M(t) = \sigma(\beta(t - t_{M-1})). \quad (12.25)$$

因为 σ 单调递增, $q_j(t) \geq 0$, 并且望远镜求和给出

$$\sum_{j=1}^M q_j(t) = 1. \quad (12.26)$$

对多指标 $\mathbf{j} = (j_1, \dots, j_n)$, 定义理想软权重

$$a_{\mathbf{j}}(\mathbf{x}) = \prod_{r=1}^n q_{j_r}(x_r). \quad (12.27)$$

于是

$$a_{\mathbf{j}}(\mathbf{x}) \geq 0, \quad \sum_{\mathbf{j}} a_{\mathbf{j}}(\mathbf{x}) = 1. \quad (12.28)$$

当 β 足够大时, logistic 尾界 $\sigma(-u) \leq e^{-u}$, $u \geq 0$, 保证离 $\mathbf{x}$ 超过一个相邻网格宽度的盒子总权重可以任意小。具体地, 可取 β 使对所有 $\mathbf{x}$,

$$\sum_{\mathbf{j}: \|\mathbf{c}_j - \mathbf{x}\|_2 > 3\sqrt{n}h} a_{\mathbf{j}}(\mathbf{x}) \leq \eta, \quad (12.29)$$

其中 $\eta > 0$ 可任意指定。

定义理想软分段常数函数

$$N_0(\mathbf{x}) = \sum_{\mathbf{j}} f(\mathbf{c}_j) a_{\mathbf{j}}(\mathbf{x}). \quad (12.30)$$

由非负权重和为 1, $N_0(\mathbf{x}) \in [-1, 1]$ 。将近邻盒与远邻盒分开:

$$\begin{aligned} |N_0(\mathbf{x}) - f(\mathbf{x})| &\leq \sum_{\mathbf{j}} a_{\mathbf{j}}(\mathbf{x}) |f(\mathbf{c}_j) - f(\mathbf{x})| \\ &\leq 3\rho\sqrt{n}h + 2\eta. \end{aligned} \quad (12.31)$$

取 $\eta \leq \frac{\varepsilon}{16}$, 结合式 (12.21), 右端小于 $\varepsilon/2$ 。



还需说明乘积式 (12.27) 可由 sigmoid 网络任意逼近。先注意任意一维连续函数可通过足够细的区间划分, 用若干 $\sigma(\beta(t-a)) - \sigma(\beta(t-b))$ 的线性组合一致逼近。因此可用一维 sigmoid 子网络在紧区间上一致逼近平方函数。再由极化恒等式

$$uv = \frac{(u+v)^2 - (u-v)^2}{4} \quad (12.32)$$

构造乘法近似器, 并递归得到有限个 q_j 的乘积近似器。由于盒子数有限, 可令每个乘积近似误差足够小, 使所得 sigmoid 网络 $\tilde{N}$ 满足 $\sup_{\mathbf{x}} |\tilde{N}(\mathbf{x}) - N_0(\mathbf{x})| \leq \frac{\varepsilon}{4}$ 。同时 $|\tilde{N}(\mathbf{x})| \leq 1 + \frac{\varepsilon}{4}$ 。最后作常数缩放 $N(\mathbf{x}) = \frac{\tilde{N}(\mathbf{x})}{1+\varepsilon/4}$, 保证 $N(\mathbf{x}) \in [-1, 1]$ 。适当缩小前述误差预算后, $\|N - f\|_{\infty} \leq \varepsilon$ 。□

规模结论。 网格盒数为

$$M^n = O \left[\left(\frac{\rho\sqrt{n}}{\varepsilon} \right)^n \right]. \quad (12.33)$$

因此该直接构造随维数指数增长。通用逼近只说明“存在网络”, 不说明存在小网络。

12.3.3 逼近所有 Lipschitz 函数需要指数规模

附件的学习理论结论表明: 固定 $\varepsilon \in (0, 1)$, 若一个 sigmoid 网络架构能够统一逼近 $[-1, 1]^n$ 上所有 1-Lipschitz 函数, 则其最小规模随 n 指数增长。

证明母题为:

1. 任取 Boolean 函数 $f: \{-1, +1\}^n \rightarrow \{-1, +1\}$;
2. 构造一个与角点标签一致的 1-Lipschitz 扩张 g ;
3. 若网络以误差 < 1 逼近 g , 则其符号在所有 2^n 个角点上实现 f ;
4. 因而符号化网络类打散全部角点, VC 维至少 2^n ;
5. 再与网络参数数目的 VC 上界比较, 推出网络规模指数增长。

易错点、反例与失败模式

以下三句均错误:

Universal approximation $\implies$ PAC learnability,

Universal approximation $\implies$ 存在多项式规模网络,

Universal approximation $\implies$ 梯度法能找到该网络.

12.3.4 ReLU 与 sigmoid 网络共同表示函数只能为常数

定理 12.5 (ReLU-sigmoid 交集定理). 设 Φ_{ReLU} 是有限 ReLU 前馈网络, Φ_{σ} 是标准有限 sigmoid 前馈网络, 二者输入均为 $\mathbb{R}^d$ 、输出为标量。假设:

1. 两个网络无输入到输出的未激活线性跳连;
2. sigmoid 网络输出由有界 sigmoid 隐单元的有限仿射组合得到;
3. 对所有 $\mathbf{x} \in \mathbb{R}^d$, $\Phi_{\text{ReLU}}(\mathbf{x}) = \Phi_{\sigma}(\mathbf{x})$.

则共同表示的函数必为常数。



证明. 有限 ReLU 网络将 $\mathbb{R}^d$ 划分为有限个多面体区域, 并在每个满维区域上表示仿射函数。因此存在非空开集 U , 使 $\Phi_{\text{ReLU}}(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + c$, $\mathbf{x} \in U$ 。于是对所有 $r, s \in [d]$, $\frac{\partial^2 \Phi_{\text{ReLU}}}{\partial x_r \partial x_s} = 0$ 在 U 上。

Sigmoid 函数在实轴上实解析; 有限次仿射变换、加法和复合保持实解析性, 故 Φ_σ 是 $\mathbb{R}^d$ 上的实解析函数。由两函数相等, Φ_σ 的每个二阶偏导在非空开集 U 上为零。实解析函数的恒等定理说明: 在连通域 $\mathbb{R}^d$ 上, 若实解析函数在非空开集上为零, 则处处为零。因此 $\nabla^2 \Phi_\sigma(\mathbf{x}) = \mathbf{0} \quad \forall \mathbf{x}$, 共同函数在全空间上是仿射函数: $\Phi_\sigma(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + c$ 。

标准 sigmoid 网络的所有隐层输出有界, 其有限仿射输出也全局有界。一个在 $\mathbb{R}^d$ 上全局有界的仿射函数只能满足 $\mathbf{a} = \mathbf{0}$ 。故共同函数为常数。□

易错点、反例与失败模式

定理中的“无输入到输出线性跳连”不能省。若允许输出端直接加入 $\mathbf{a}^\top \mathbf{x}$, 则 sigmoid 网络也能表示非恒定仿射函数, 结论不再成立。考试中应明确使用题目隐含的标准前馈架构。

答题方法

[26S-A-Q5, 5 分] 的满分证明只需抓住两条:

1. ReLU 网络是有限分段仿射函数, 因此在某个非空开集上 Hessian 为零;
2. sigmoid 网络是有界实解析函数。

随后: 解析恒等定理 $\implies$ Hessian 处处为零 $\implies$ 全局仿射 $\implies$ 有界仿射只能为常数。只写“ReLU 分段线性、sigmoid 平滑, 所以只能常数”缺少关键逻辑。



第十三章 机器学习理论速查表与方向收束

13.1 核心模型、目标、复杂度与失败模式

表 13.1: 机器学习理论核心模型速查

模型	目标或预测	训练/推理复杂度主项	主要失败模式
Least squares	$\min_w \frac{1}{2m} \ Xw - y\ ^2$	构造 $X^\top X$: $O(md^2)$; 求解 $O(d^3)$; 预测 $O(d)$ 。	秩不足导致非唯一; 异常值敏感; 平方损失可能无界。
Ridge	$\min_w \frac{1}{2m} \ Xw - y\ ^2 + \frac{\lambda}{2} \ w\ ^2$	与最小二乘同量级; 矩阵条件通常改善。	λ 过大导致偏差; 参数化系数易混淆。
Logistic regression	$p(y=1 x) = \sigma(w^\top x + b)$ 及交叉熵。	每次全梯度 $O(md)$; 预测 $O(d)$ 。	完全分离时无正则 MLE 可发散; 概率可能未校准。
Decision tree	递归阈值分裂; 叶节点输出。	典型构建约 $O(dm \log m)$; 预测 $O(D)$ 。	深树过拟合; 贪心分裂非全局最优; 分裂不稳定。
k -NN	邻居多数票或均值。	存储 $O(md)$; 朴素查询 $O(md)$ 。	维数灾难; 尺度敏感; 测试代价高。
Hard SVM	$\min \frac{1}{2} \ w\ ^2 \quad \text{s.t. } y_i f_i \geq 1$	线性原问题可迭代; 核对称需 $O(m^2)$ 存储。	要求可分; 输入尺度未控时 margin 无意义。
Soft SVM	$\frac{\lambda}{2} \ w\ ^2 + \frac{1}{m} \sum_i [1 - y_i f_i]_+$	线性 SGD 每轮 $O(d)$; 核 QP 通常更贵。	C/λ 换算错误; hinge 近似误差。
Kernel SVM	$f(x) = \sum_i \alpha_i y_i K(x_i, x) + b$	Gram $O(m^2 T_K)$; 预测 $O(s T_K)$ 。	核或带宽选择不当; Gram 内存瓶颈。
Kernel ridge	$\alpha = (G + 2m\lambda I)^{-1} y$ (附件约定)。	训练 $O(m^3)$; 存储 $O(m^2)$; 预测 $O(m T_K)$ 。	大样本不可扩展; 正则系数换算易错。
Compressed sensing	$\min_z \ z\ _1 \quad \text{s.t. } Az = y$	凸规划; 复杂度取决于求解器与矩阵结构。	无稀疏性或无 NSP/RIP 时恢复失败; 噪声放大。
Multivector	$h(x) = \arg \max_y \langle w, \Psi(x, y) \rangle$	参数 $K(n+1)$; 预测 $O(Kn)$ 。	类别数大; 特征映射或代价函数设计不当。
有限 ReLU 网络	连续分段仿射函数。	前向与边数同阶; 训练目标通常非凸。	表达、泛化与可训练性不能混同。

13.2 本方向新增真题与训练题映射

表 13.2: 本部分真题与课程训练材料映射

题目	主要标签	满分或正确选择所需内容
[25F-A-Q13, 5 分]	Sigmoid 通用逼近	网格划分; Lipschitz 局部常数; 盒选择器; 误差预算; 不得声称网络规模多项式。
[26S-A-MQ3, 0.5 分]	ReLU 函数类	识别有限 ReLU 网络为分段线性/仿射函数; 复杂度依赖深度与宽度。
[26S-A-MQ6, 0.5 分]	PSD 核	PSD 核对应可能无限维 Hilbert 特征映射; 特征映射不唯一。
[26S-A-Q4, 7 分]	Multivector、generalized hinge	中心权重构造; 配平方; 反三角不等式; 得分间隔; 证明损失为零。
[26S-A-Q5, 5 分]	ReLU 与 sigmoid	分段仿射; 实解析恒等定理; 有界仿射函数为常数。
[MLT-Final-MQ3, 2 分, 课程期末选择题]	Kernel trick	只计算高维特征内积, 不显式构造高维特征。
[MLT-Practice-Q5, 课程练习]	SVM、max affine、次梯度	最小范数反证; $f(w) < 1$ 推出分离; 活动仿射函数次梯度。
[MLT-Practice-Q6, 课程练习]	Kernel ridge	Representer theorem; Gram 化; 推导 $(G + 2m\lambda I)^{-1}y$ 。
[MLT-Practice-Q7, 课程练习]	Multivector	与 [26S-A-Q4, 7 分] 存在母题关系, 但不是同一道博资考真题。
[MLT-HW2-Q2, 课程作业]	核函数构造	构造累计一向量, 内积等于 $\min\{i, j\}$ 。
[MLT-HW3-Q1, 课程作业]	决策树表示与 VC	逐位查询所有输入; 在有限域上表示任意 Boolean 函数。
[MLT-HW3-Q4, 课程作业]	网络规模下界	Lipschitz 扩张; 角点打散; VC 下界与参数上界比较。

13.3 A 方向考场核查清单

答题方法

机器学习理论高分答案提交前, 应逐项检查:

1. 是否明确标签采用 $\{0, 1\}$ 还是 $\{-1, +1\}$;
2. empirical risk 是总和还是平均;

3. 可实现与 agnostic 的比较对象是否正确；
4. VC 下界是否实现全部标记，上界是否针对任意点集；
5. 概率期望中的随机性来自样本、标签还是算法；
6. 正则化系数是否含 $1/2$ 、 $1/m$ ；
7. 梯度和 Hessian 的维度是否正确；
8. SVM 的函数间隔与几何间隔是否除以 $\|w\|$ ；
9. C 与 λ 是否按当前目标正确换算；
10. 对偶是否写出偏置对应的 $\sum_i \alpha_i y_i = 0$ ；
11. 核是否满足对所有 Gram 矩阵 PSD，而非只检查对角线；
12. representer theorem 是否说明正则项关于范数单调；
13. KRR 是否写出测试点预测；
14. ℓ_1 恢复是否说明 NSP/RIP 条件；
15. 通用逼近是否被误写为 PAC 可学习或高效可训练；
16. 复杂度是否说明输入规模和主导运算；
17. 课程题是否被错误称为博资考真题。

13.4 快速自测



快速自测

1. 最小二乘解何时唯一? Ridge 为什么在 $\lambda > 0$ 时唯一?
2. 逻辑回归在完全分离数据上为何可能没有有限 MLE?
3. 普通区间、决策树和 k -NN 分别通过什么归纳偏置控制泛化?
4. 函数间隔与几何间隔如何换算?
5. 在平均 hinge-loss 约定下, C 与 λ 的关系是什么?
6. 为什么 $K(x, x) \geq 0$ 不是有效核的充分条件?
7. Representer theorem 为什么允许把无限维优化降为 m 个系数?
8. 在附件 KRR 参数化下, 闭式系数为何是 $(G + 2m\lambda I)^{-1}y$?
9. NSP 如何证明所有 s -稀疏向量均可由 basis pursuit 唯一恢复?
10. Multivector 真题中, 为什么中心距离 $> 4r$ 足以使 generalized hinge loss 为零?
11. 一个函数同时由标准有限 ReLU 网络和标准有限 sigmoid 网络表示时, “分段仿射”与“实解析”如何共同推出全局仿射?
12. 通用逼近、有限 VC 维和存在多项式时间训练算法之间有何逻辑关系?



第二部分

深度学习与强化学习



第十四章 深度学习问题设定、MLP 与计算图

14.1 考情定位与证明要求

重要性等级: S

- [25S-B-Q1, 18 分] 将深度学习基础设置为一个完整的“数据准备—假设空间—损失函数—随机优化—训练稳定化—误差诊断”流水线题。该题不是单纯概念简答，而是要求将模型、维度、目标和算法连成完整系统。
- [26S-B-Q1(a), 2 分] 直接要求逐层链式法则和 backpropagation 的复杂度解释；[26S-B-Q1(b), 2 分] 考查 sigmoid 梯度消失与 ReLU；[26S-B-Q1(c), 2 分] 考查 momentum 更新及其抑制振荡的作用。
- [MLT-Final-MQ6–MQ8, 课程期末选择题] 训练可微性、mini-batch SGD 和 $\nabla_{\mathbf{w}} \tanh(\mathbf{w}^\top \mathbf{x} + b)$ 的基本计算，但不得计入博资考真题频率。

本章中：


- MLP 张量维度、链式法则、线性层反传、softmax-cross-entropy 梯度属于**必须会完整推导**；
- 反向模式自动微分的复杂度、梯度消失与初始化方差传播属于**必须掌握证明框架**；
- BN、dropout、residual connection 的训练与推理差异属于**必须会使用 and 解释**；
- “SGD 偏好平坦极小值”“隐式正则化”等只可表述为有条件的理论结果或实践观察，不得写成无条件定理。

14.2 监督深度学习问题的完整形式化

14.2.1 数据、任务与数据集划分

考虑 C 类分类问题。输入与标签空间为 $\mathcal{X} \subseteq \mathbb{R}^{d_0}$, $\mathcal{Y} = [C] = \{1, \dots, C\}$ 。未知数据分布为 $P \in \mathcal{P}(\mathcal{X} \times \mathcal{Y})$ 。完整数据集应在模型训练前划分为互不重叠的三部分：

$$\mathcal{D} = \mathcal{D}_{\text{train}} \dot{\cup} \mathcal{D}_{\text{val}} \dot{\cup} \mathcal{D}_{\text{test}}. \quad (14.1)$$



其用途分别为：

$\mathcal{D}_{\text{train}}$ ：拟合可训练参数；

$\mathcal{D}_{\text{val}}$ ：选择架构、超参数、训练轮数和决策阈值；

$\mathcal{D}_{\text{test}}$ ：在全部建模决策完成后进行一次最终评估。

训练集写为 $\mathcal{D}_{\text{train}} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$, $\mathbf{x}_i \in \mathbb{R}^{d_0}$, $y_i \in [C]$ 。one-hot 标签记为 $\mathbf{e}_{y_i} \in \{0, 1\}^C$, $(\mathbf{e}_{y_i})_c = \mathbf{1}\{c = y_i\}$ 。

易错点、反例与失败模式

下列过程构成数据泄漏：

1. 使用测试集选择网络深度、学习率或正则化参数；
2. 使用全部数据拟合标准化均值与方差后再划分训练集和测试集；
3. 根据测试集结果反复修改模型，再把最后一次测试结果称为无偏评估；
4. 在交叉验证外部预先使用全部样本完成特征选择。

标准化、数据增强参数、词表或其他可学习预处理均应只利用训练数据确定。

14.2.2 特征提取器与分类器

令

$$g_\phi : \mathbb{R}^{d_0} \rightarrow \mathbb{R}^{d_h}, \quad \mathbf{h} = g_\phi(\mathbf{x}), \quad (14.2)$$

$$c_\psi : \mathbb{R}^{d_h} \rightarrow \mathbb{R}^C, \quad \mathbf{z} = c_\psi(\mathbf{h}), \quad (14.3)$$

其中：

- g_ϕ 是特征提取器 (feature extractor)；
- c_ψ 是分类头 (classifier head)；
- $\mathbf{z} = (z_1, \dots, z_C)^\top$ 是 logits；
- 总参数为 $\theta = (\phi, \psi) \in \Theta$ 。

类别概率由 softmax 给出：

$$p_\theta(y = c \mid \mathbf{x}) = \frac{\exp(z_c)}{\sum_{r=1}^C \exp(z_r)}. \quad (14.4)$$


预测规则为

$$\hat{y}_\theta(\mathbf{x}) \in \arg \max_{c \in [C]} z_c = \arg \max_{c \in [C]} p_\theta(y = c \mid \mathbf{x}). \quad (14.5)$$

固定网络结构后，假设类为

$$\mathcal{H}_\mathcal{A} = \{\mathbf{x} \mapsto \text{softmax}(c_\psi(g_\phi(\mathbf{x}))) : (\phi, \psi) \in \Theta\}, \quad (14.6)$$

其中 $\mathcal{A}$ 表示固定的架构，包括：层数、每层宽度、连接方式、激活函数、归一化位置和输出头。架构不是某一个假设；同一架构下不同参数对应不同假设。



14.2.3 经验目标与总体目标

单样本交叉熵损失为

$$\ell_{\text{CE}}(\boldsymbol{\theta}; (\mathbf{x}_i, y_i)) = -\log p_{\boldsymbol{\theta}}(y_i | \mathbf{x}_i). \quad (14.7)$$

经验风险为

$$\hat{R}_N(\boldsymbol{\theta}) = \frac{1}{N} \sum_{i=1}^N \ell_{\text{CE}}(\boldsymbol{\theta}; (\mathbf{x}_i, y_i)). \quad (14.8)$$

含 ℓ_2 正则项的训练目标采用主约定

$$J_N(\boldsymbol{\theta}) = \hat{R}_N(\boldsymbol{\theta}) + \frac{\lambda}{2} \|\boldsymbol{\theta}_{\text{reg}}\|_2^2. \quad (14.9)$$

这里 $\boldsymbol{\theta}_{\text{reg}}$ 必须明确指出包含哪些参数。实践中常不正则化：偏置、BN 的缩放参数与平移参数。

总体风险为

$$R_P(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{X}, Y) \sim P} [\ell_{\text{CE}}(\boldsymbol{\theta}; (\mathbf{X}, Y))]. \quad (14.10)$$

深度学习的误差应区分为：

$$\underbrace{R_P(\hat{\boldsymbol{\theta}}) - R_P^*}_{\text{总超额风险}} = \underbrace{\inf_{\boldsymbol{\theta} \in \Theta} R_P(\boldsymbol{\theta}) - R_P^*}_{\text{逼近误差}} + \underbrace{R_P(\boldsymbol{\theta}_N^*) - \inf_{\boldsymbol{\theta} \in \Theta} R_P(\boldsymbol{\theta})}_{\text{估计误差}} + \underbrace{R_P(\hat{\boldsymbol{\theta}}) - R_P(\boldsymbol{\theta}_N^*)}_{\text{优化相关项}}, \quad (14.11)$$

其中 $\boldsymbol{\theta}_N^*$ 表示训练目标的全局极小参数之一。在非凸问题中，该分解主要用于诊断；最后一项未必非负，且训练算法还可能产生隐式偏置。

易错点、反例与失败模式

1. “训练误差低”只说明优化后的参数拟合训练样本；不等于总体风险低。
2. “更深的网络表达能力更强”不意味着训练误差一定更低；实际训练还受到非凸优化、梯度传播和数值稳定性的影响。
3. “测试误差高”不能直接判定是网络容量不足；必须同时查看训练误差和验证误差。

14.3 MLP 的逐层定义、维度与参数量

14.3.1 单样本的列向量约定

设 MLP 有 L 个参数化层，其宽度为 $d_0, d_1, \dots, d_L$ 。输入记为 $\mathbf{h}^{(0)} = \mathbf{x} \in \mathbb{R}^{d_0}$ 。第 ℓ 层定义为


$$\mathbf{z}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}, \quad (14.12)$$

$$\mathbf{h}^{(\ell)} = \varphi_{\ell}(\mathbf{z}^{(\ell)}), \quad \ell = 1, \dots, L, \quad (14.13)$$

其中

$$\begin{aligned} \mathbf{W}^{(\ell)} &\in \mathbb{R}^{d_{\ell} \times d_{\ell-1}}, \\ \mathbf{b}^{(\ell)} &\in \mathbb{R}^{d_{\ell}}, \\ \mathbf{z}^{(\ell)}, \mathbf{h}^{(\ell)} &\in \mathbb{R}^{d_{\ell}}. \end{aligned}$$

激活函数 φ_{ℓ} 通常逐坐标作用。分类任务的最后一层常直接输出 logits: $\mathbf{z}^{(L)} = \mathbf{W}^{(L)} \mathbf{h}^{(L-1)} + \mathbf{b}^{(L)}$ ，而不在 logits 后额外使用 ReLU。



该网络表示复合函数

$$f_{\theta} = f_L \circ f_{L-1} \circ \cdots \circ f_1. \quad (14.14)$$

若每层均含偏置，则参数总数为

$$P_{\text{MLP}} = \sum_{\ell=1}^L (d_{\ell} d_{\ell-1} + d_{\ell}) = \sum_{\ell=1}^L d_{\ell} (d_{\ell-1} + 1). \quad (14.15)$$

例 14.1 (参数量与维度核对). 输入维数为 $d_0 = 100$ ，两层隐藏层宽度分别为 $d_1 = 64, d_2 = 32$ ，输出类别数 $d_3 = C = 10$ 。则

$$\begin{aligned} \mathbf{W}^{(1)} &\in \mathbb{R}^{64 \times 100}, & \mathbf{b}^{(1)} &\in \mathbb{R}^{64}, \\ \mathbf{W}^{(2)} &\in \mathbb{R}^{32 \times 64}, & \mathbf{b}^{(2)} &\in \mathbb{R}^{32}, \\ \mathbf{W}^{(3)} &\in \mathbb{R}^{10 \times 32}, & \mathbf{b}^{(3)} &\in \mathbb{R}^{10}. \end{aligned}$$

参数总数为 $64(100 + 1) + 32(64 + 1) + 10(32 + 1) = 8874$ 。

14.3.2 Mini-batch 的矩阵约定

全文数学推导采用“样本为列”的 batch 约定： $\mathbf{H}^{(0)} = [\mathbf{x}_1 \ \cdots \ \mathbf{x}_B] \in \mathbb{R}^{d_0 \times B}$ 。第 ℓ 层为

$$\mathbf{Z}^{(\ell)} = \mathbf{W}^{(\ell)} \mathbf{H}^{(\ell-1)} + \mathbf{b}^{(\ell)} \mathbf{1}_B^{\top}, \quad (14.16)$$

$$\mathbf{H}^{(\ell)} = \varphi_{\ell}(\mathbf{Z}^{(\ell)}), \quad (14.17)$$

其中 $\mathbf{1}_B \in \mathbb{R}^B$ 。维度为 $\mathbf{Z}^{(\ell)}, \mathbf{H}^{(\ell)} \in \mathbb{R}^{d_{\ell} \times B}$ 。

多数软件库采用 batch-first 存储 $B \times d_{\ell}$ 。两种约定只是转置关系，但推导中不得在同一公式内混用。

14.4 计算图与局部 Jacobian

定义 14.2 (计算图). 计算图 (computation graph) 是一个有向无环图：

- 叶节点表示输入、参数或常量；
- 内部节点表示局部算子；
- 边表示数值依赖；
- 输出节点表示预测或标量损失。

前向传播按拓扑顺序计算节点值；反向传播按逆拓扑顺序传播梯度。


设节点 $\mathbf{u} = f(\mathbf{v})$ 满足 $\mathbf{v} \in \mathbb{R}^n$, $\mathbf{u} \in \mathbb{R}^m$ 。本文将 Jacobian 定义为

$$\mathbf{J}_f(\mathbf{v}) = \frac{\partial \mathbf{u}}{\partial \mathbf{v}} \in \mathbb{R}^{m \times n}, \quad (\mathbf{J}_f)_{ij} = \frac{\partial u_i}{\partial v_j}. \quad (14.18)$$

若最终损失 J 为标量，并采用列梯度 $\nabla_{\mathbf{u}} J \in \mathbb{R}^m$ ，则向量链式法则为

$$\nabla_{\mathbf{v}} J = \mathbf{J}_f(\mathbf{v})^{\top} \nabla_{\mathbf{u}} J. \quad (14.19)$$

右侧计算称为 vector-Jacobian product 的转置形式，也可理解为 Jacobian-transpose-vector product。



若一个节点 v 影响多个后继节点 $u_1, \dots, u_s$, 则反向梯度必须累加:

$$\nabla_v J = \sum_{r=1}^s \left(\frac{\partial u_r}{\partial v} \right)^\top \nabla_{u_r} J. \quad (14.20)$$

易错点、反例与失败模式

反向传播不是“把前向公式倒着运行”，而是：保存前向中间量 + 按逆拓扑顺序乘局部 Jacobian 的转置 + 在分支汇合处求和。若漏掉分支求和，梯度即不完整。



第十五章 链式法则、反向传播与自动微分

15.1 一般层状网络的反向传播公式

设

$$\mathbf{x}^{(\ell)} = f_{\ell}(\mathbf{x}^{(\ell-1)}, \boldsymbol{\theta}_{\ell}), \quad \ell = 1, \dots, L, \quad (15.1)$$

其中 $\mathbf{x}^{(\ell)} \in \mathbb{R}^{d_{\ell}}$, $\boldsymbol{\theta}_{\ell} \in \mathbb{R}^{p_{\ell}}$ 。标量损失为

$$J = \mathcal{L}(\mathbf{x}^{(L)}, y). \quad (15.2)$$

定义局部 Jacobian:

$$\mathbf{A}_{\ell} = \frac{\partial \mathbf{x}^{(\ell)}}{\partial \mathbf{x}^{(\ell-1)}} \in \mathbb{R}^{d_{\ell} \times d_{\ell-1}}, \quad (15.3)$$

$$\mathbf{B}_{\ell} = \frac{\partial \mathbf{x}^{(\ell)}}{\partial \boldsymbol{\theta}_{\ell}} \in \mathbb{R}^{d_{\ell} \times p_{\ell}}. \quad (15.4)$$

令伴随变量

$$\boldsymbol{\delta}^{(\ell)} = \nabla_{\mathbf{x}^{(\ell)}} J \in \mathbb{R}^{d_{\ell}}. \quad (15.5)$$

则反向递推为

$$\boldsymbol{\delta}^{(L)} = \nabla_{\mathbf{x}^{(L)}} \mathcal{L}(\mathbf{x}^{(L)}, y), \quad (15.6)$$

$$\nabla_{\boldsymbol{\theta}_{\ell}} J = \mathbf{B}_{\ell}^{\top} \boldsymbol{\delta}^{(\ell)}, \quad (15.7)$$

$$\boldsymbol{\delta}^{(\ell-1)} = \mathbf{A}_{\ell}^{\top} \boldsymbol{\delta}^{(\ell)}. \quad (15.8)$$

展开式为

$$\nabla_{\boldsymbol{\theta}_{\ell}} J = \mathbf{B}_{\ell}^{\top} \mathbf{A}_{\ell+1}^{\top} \mathbf{A}_{\ell+2}^{\top} \cdots \mathbf{A}_L^{\top} \nabla_{\mathbf{x}^{(L)}} \mathcal{L} \quad (15.9)$$

其中当 $\ell = L$ 时, 中间 Jacobian 乘积为空乘积。

答题方法

[26S-B-Q1(a), 2 分] 的链式法则部分应写成:

1. 定义 $\mathbf{A}_r = \partial \mathbf{x}^{(r)} / \partial \mathbf{x}^{(r-1)}$, $\mathbf{B}_{\ell} = \partial \mathbf{x}^{(\ell)} / \partial \boldsymbol{\theta}_{\ell}$;
2. 写明所有 Jacobian 维度;
3. 给出 $\nabla_{\boldsymbol{\theta}_{\ell}} J = \mathbf{B}_{\ell}^{\top} \mathbf{A}_{\ell+1}^{\top} \cdots \mathbf{A}_L^{\top} \nabla_{\mathbf{x}^{(L)}} \mathcal{L}$;
4. 再写递推实现 $\boldsymbol{\delta}^{(\ell-1)} = \mathbf{A}_{\ell}^{\top} \boldsymbol{\delta}^{(\ell)}$;
5. 说明反向传播缓存并复用 $\boldsymbol{\delta}^{(\ell)}$, 而不是为每个参数重复计算完整链式乘积。

15.2 线性层的完整梯度

考虑单样本仿射层

$$\mathbf{z} = \mathbf{W}\mathbf{h} + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{m \times n}, \quad \mathbf{h} \in \mathbb{R}^n, \quad \mathbf{b}, \mathbf{z} \in \mathbb{R}^m. \quad (15.10)$$

设上游梯度为 $\mathbf{g} = \nabla_{\mathbf{z}} J \in \mathbb{R}^m$ 。微分为

$$d\mathbf{z} = d\mathbf{W}\mathbf{h} + \mathbf{W}d\mathbf{h} + d\mathbf{b}. \quad (15.11)$$

于是

$$\begin{aligned} dJ &= \mathbf{g}^\top d\mathbf{z} \\ &= \mathbf{g}^\top d\mathbf{W}\mathbf{h} + \mathbf{g}^\top \mathbf{W}d\mathbf{h} + \mathbf{g}^\top d\mathbf{b} \\ &= \text{tr}(\mathbf{h}\mathbf{g}^\top d\mathbf{W}) + (\mathbf{W}^\top \mathbf{g})^\top d\mathbf{h} + \mathbf{g}^\top d\mathbf{b}. \end{aligned} \quad (15.12)$$

因此

$$\nabla_{\mathbf{W}} J = \mathbf{g}\mathbf{h}^\top \in \mathbb{R}^{m \times n}, \quad (15.13)$$

$$\nabla_{\mathbf{b}} J = \mathbf{g} \in \mathbb{R}^m, \quad (15.14)$$

$$\nabla_{\mathbf{h}} J = \mathbf{W}^\top \mathbf{g} \in \mathbb{R}^n. \quad (15.15)$$

对 batch 形式 $\mathbf{Z} = \mathbf{W}\mathbf{H} + \mathbf{b}\mathbf{1}_B^\top$, 令 $\mathbf{G} = \nabla_{\mathbf{Z}} J \in \mathbb{R}^{m \times B}$, 则

$$\nabla_{\mathbf{W}} J = \mathbf{G}\mathbf{H}^\top, \quad (15.16)$$

$$\nabla_{\mathbf{b}} J = \mathbf{G}\mathbf{1}_B, \quad (15.17)$$

$$\nabla_{\mathbf{H}} J = \mathbf{W}^\top \mathbf{G}. \quad (15.18)$$

如果 $\mathbf{G}$ 由未平均的逐样本梯度组成, 而损失定义为 batch 平均, 则上述右端还需乘 $1/B$; 若 $\mathbf{G} = \nabla_{\mathbf{Z}} J$ 已经包含平均因子, 则不得再次除以 B 。

15.3 逐坐标激活函数的反向传播

若 $\mathbf{h} = \varphi(\mathbf{z})$, $h_i = \varphi(z_i)$, 则 $\frac{\partial \mathbf{h}}{\partial \mathbf{z}} = \text{diag}(\varphi'(z_1), \dots, \varphi'(z_m))$ 。设 $\mathbf{g}_h = \nabla_{\mathbf{h}} J$, 则

$$\nabla_{\mathbf{z}} J = \mathbf{g}_h \odot \varphi'(\mathbf{z}). \quad (15.19)$$

常用激活及导数为:


$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad \sigma'(z) = \sigma(z)[1 - \sigma(z)], \quad (15.20)$$

$$\tanh'(z) = 1 - \tanh^2(z), \quad (15.21)$$

$$\text{ReLU}(z) = \max\{0, z\}, \quad \text{ReLU}'(z) = \begin{cases} 1, & z > 0, \\ 0, & z < 0. \end{cases} \quad (15.22)$$

$$\text{LeakyReLU}_a(z) = \max\{az, z\}, \quad \text{LeakyReLU}'_a(z) = \begin{cases} 1, & z > 0, \\ a, & z < 0, \end{cases} \quad 0 < a < 1. \quad (15.23)$$

在 $z = 0$ 处 ReLU 不可经典微分。自动微分软件通常选取某个次梯度约定, 常见为 0。因此: 反向传播并不要求每个节点处处经典可微, 而要求在实际计算点具有可用的导数、次导数或约定的广义导数。



例 15.1 (课程训练题型: tanh 神经元). [MLT-Final-MQ8, 2 分, 课程期末选择题] 若 $o = \tanh(\mathbf{w}^\top \mathbf{x} + b)$, 则

$$\begin{aligned}\nabla_{\mathbf{w}} o &= \tanh'(\mathbf{w}^\top \mathbf{x} + b) \mathbf{x} \\ &= (1 - o^2) \mathbf{x}.\end{aligned}\quad (15.24)$$

正确答案是 $(1 - o^2) \mathbf{x}$ 。

15.4 Softmax 与交叉熵的合并梯度

令 $p_i = \frac{e^{z_i}}{\sum_{r=1}^C e^{z_r}}$ 。其 Jacobian 元素为

$$\frac{\partial p_i}{\partial z_j} = p_i(\delta_{ij} - p_j). \quad (15.25)$$

矩阵形式为

$$\mathbf{J}_{\text{softmax}} = \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top. \quad (15.26)$$

对 one-hot 标签 $\mathbf{y} = \mathbf{e}_y$, 交叉熵为 $\ell(\mathbf{z}, \mathbf{y}) = -\sum_{i=1}^C y_i \log p_i$ 。直接利用 $\log p_i = z_i - \log \sum_{r=1}^C e^{z_r}$, 可得

$$\begin{aligned}\ell &= -\sum_i y_i z_i + \left(\sum_i y_i\right) \log \sum_r e^{z_r} \\ &= -\mathbf{y}^\top \mathbf{z} + \log \sum_r e^{z_r}.\end{aligned}\quad (15.27)$$

故

$$\boxed{\nabla_{\mathbf{z}} \ell = \mathbf{p} - \mathbf{y}} \quad (15.28)$$

这是分类网络反向传播中最重要的梯度简化之一。

对 batch 矩阵 $\mathbf{Z}, \mathbf{P}, \mathbf{Y} \in \mathbb{R}^{C \times B}$ 及 batch 平均交叉熵,

$$\nabla_{\mathbf{Z}} J = \frac{1}{B}(\mathbf{P} - \mathbf{Y}). \quad (15.29)$$

为避免数值溢出, 应计算

$$\log \sum_r e^{z_r} = a + \log \sum_r e^{z_r - a}, \quad a = \max_r z_r. \quad (15.30)$$

softmax 对所有 logit 加同一常数不变: $\text{softmax}(\mathbf{z} + a\mathbf{1}) = \text{softmax}(\mathbf{z})$ 。

15.5 两层 MLP 的完整反向传播例题

例 15.2 (基础综合推导). 设

$$\mathbf{a} = \mathbf{W}_1 \mathbf{x} + \mathbf{b}_1, \quad \mathbf{h} = \tanh(\mathbf{a}), \quad (15.31)$$

$$\mathbf{z} = \mathbf{W}_2 \mathbf{h} + \mathbf{b}_2, \quad \mathbf{p} = \text{softmax}(\mathbf{z}), \quad (15.32)$$

$$J = -\mathbf{y}^\top \log \mathbf{p}. \quad (15.33)$$

维度设为 $\mathbf{x} \in \mathbb{R}^d$, $\mathbf{W}_1 \in \mathbb{R}^{h \times d}$, $\mathbf{b}_1, \mathbf{a}, \mathbf{h} \in \mathbb{R}^h$, $\mathbf{W}_2 \in \mathbb{R}^{C \times h}$, $\mathbf{b}_2, \mathbf{z}, \mathbf{p}, \mathbf{y} \in \mathbb{R}^C$ 。



从输出向输入反传：

$$\mathbf{g}_z = \nabla_{\mathbf{z}} J = \mathbf{p} - \mathbf{y}, \quad (15.34)$$

$$\nabla_{\mathbf{W}_2} J = \mathbf{g}_z \mathbf{h}^\top \in \mathbb{R}^{C \times h}, \quad (15.35)$$

$$\nabla_{\mathbf{b}_2} J = \mathbf{g}_z, \quad (15.36)$$

$$\mathbf{g}_h = \mathbf{W}_2^\top \mathbf{g}_z \in \mathbb{R}^h, \quad (15.37)$$

$$\mathbf{g}_a = \mathbf{g}_h \odot (1 - \mathbf{h} \odot \mathbf{h}) \in \mathbb{R}^h, \quad (15.38)$$

$$\nabla_{\mathbf{W}_1} J = \mathbf{g}_a \mathbf{x}^\top \in \mathbb{R}^{h \times d}, \quad (15.39)$$

$$\nabla_{\mathbf{b}_1} J = \mathbf{g}_a, \quad (15.40)$$

$$\nabla_{\mathbf{x}} J = \mathbf{W}_1^\top \mathbf{g}_a \in \mathbb{R}^d. \quad (15.41)$$

满分推导必须按计算图逆序写出中间梯度。仅写 $\nabla_{\mathbf{W}_1} J = \frac{\partial J}{\partial \mathbf{W}_1}$ 而不给出 $\mathbf{g}_z, \mathbf{g}_h, \mathbf{g}_a$ 不能体现反向传播过程。

15.6 为什么反向传播与前向传播同阶

设前向图包含局部算子 $u_r = f_r(\text{pa}(u_r))$, $r = 1, \dots, M$, 每个算子的前向代价为 C_r 。对常用算子：

- 矩阵乘法；
- 卷积；
- 逐元素激活；
- 加法、归一化；

其 vector-Jacobian product 的计算代价至多是前向代价的常数倍。反向传播中每个节点和边只处理常数次，因此

$$T_{\text{backward}} = O\left(\sum_{r=1}^M C_r\right) = O(T_{\text{forward}}). \quad (15.42)$$

更准确地说： $T_{\text{forward}+\text{backward}} = cT_{\text{forward}}$, 其中 c 是与具体算子实现有关的常数。

反向传播通常需要保存前向激活，空间代价约为

$$M_{\text{activation}} = O\left(B \sum_{\ell=0}^L d_\ell\right) \quad (15.43)$$

或卷积网络中相应特征图大小之和。梯度检查点（gradient checkpointing）通过重新计算部分前向量来降低存储，构成时间与空间的交换。

答题方法

[26S-B-Q1(a), 2 分] 的复杂度说明应包含：

1. 前向计算每个局部算子一次；
2. 反向计算每个局部算子的 vector-Jacobian product 一次；
3. 每层的反向代价与该层前向代价同阶；

4. 反向传播复用中间伴随变量，避免为每个参数从头展开链式法则；

5. 因此求全部参数梯度的总时间仅为一次前向计算的常数倍，但需要保存激活或使用重计算。

15.7 自动微分、符号微分与数值微分

表 15.1: 三种微分方式的区别

方法	核心机制	主要特点与局限
符号微分	操作解析表达式并生成新的导数表达式。	结果可解析，但可能发生表达式膨胀；不是现代大规模神经网络训练的主要实现。
数值微分	$\frac{\partial J}{\partial \theta_j} \approx \frac{J(\theta + \varepsilon e_j) - J(\theta - \varepsilon e_j)}{2\varepsilon}$ 。	每个参数需额外前向计算，代价高；受截断误差和浮点误差影响；适合梯度检查。
自动微分	把程序分解为基本算子，使用链式法则传播精确到机器精度的导数。	反向模式适合“参数多、标量损失”的神经网络；backpropagation 是反向模式自动微分在神经网络计算图上的实现。

梯度检查常使用相对误差

$$\text{relerr} = \frac{\|\mathbf{g}_{\text{analytic}} - \mathbf{g}_{\text{numeric}}\|_2}{\max\{1, \|\mathbf{g}_{\text{analytic}}\|_2, \|\mathbf{g}_{\text{numeric}}\|_2\}}.$$

(15.44)

检查时应：

- 关闭 dropout 等随机性；
- 固定 BN 统计量或使用确定性小网络；
- 使用双精度；
- 避开 ReLU 的不可微折点；
- 选择适中的 ε ，避免过大截断误差或过小舍入误差。



第十六章 训练稳定化、正则化与误差诊断

16.1 梯度消失与梯度爆炸

重要性等级：S

[26S-B-Q1(b), 2 分] 要求从激活函数导数和深层 Jacobian 连乘解释 sigmoid 梯度消失，并与 ReLU 比较。仅回答“sigmoid 会饱和，ReLU 不会”不足以获得完整分数；必须写出导数上界和乘积结构。

考虑

$$\mathbf{h}^{(\ell)} = \varphi(\mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}). \quad (16.1)$$

令 $\mathbf{D}^{(\ell)} = \text{diag}(\varphi'(z_1^{(\ell)}), \dots, \varphi'(z_{d_\ell}^{(\ell)}))$ 。则

$$\boldsymbol{\delta}^{(\ell-1)} = (\mathbf{W}^{(\ell)})^\top \mathbf{D}^{(\ell)} \boldsymbol{\delta}^{(\ell)}. \quad (16.2)$$

因此

$$\|\boldsymbol{\delta}^{(\ell)}\|_2 \leq \left[\prod_{r=\ell+1}^L \|\mathbf{W}^{(r)}\|_2 \|\mathbf{D}^{(r)}\|_2 \right] \|\boldsymbol{\delta}^{(L)}\|_2. \quad (16.3)$$

若每层乘子的谱范数上界小于 1，梯度可能按深度指数衰减；若长期大于 1，则可能指数放大。

16.1.1 Sigmoid

由 $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ 及 $0 < \sigma(z) < 1$ 可得

$$0 < \sigma'(z) \leq \frac{1}{4}. \quad (16.4)$$


若粗略假设 $\|\mathbf{W}^{(r)}\|_2 \leq 1$ ，则 $\|\boldsymbol{\delta}^{(\ell)}\| \leq 4^{-(L-\ell)} \|\boldsymbol{\delta}^{(L)}\|$ ，体现指数级梯度衰减。当 $|z|$ 很大时， $\sigma'(z) \approx 0$ ，饱和更加严重。

16.1.2 Tanh

$\tanh'(z) = 1 - \tanh^2(z) \leq 1$ 。tanh 在原点附近最大导数为 1，且输出零中心化，通常优于 sigmoid；但当 $|z|$ 大时， $\tanh'(z) \rightarrow 0$ ，仍可能发生梯度消失。

16.1.3 ReLU 与 dead ReLU

对 $z > 0$ ， $\text{ReLU}'(z) = 1$ ，因此不会额外引入小于 1 的饱和导数因子。这只是“缓解”梯度消失，而非无条件消除，因为：



1. 权重矩阵的谱范数乘积仍可过小或过大；
2. 当 $z < 0$ 时导数为 0；
3. 若某神经元对所有训练样本都满足 $z < 0$ ，则其入边梯度长期为零，称为 dead ReLU；
4. 大学习率或不当负偏置可能使神经元进入永久不激活区域。

Leaky ReLU 在负半轴保留斜率 $a > 0$ ，可降低完全死亡风险，但仍不保证整体 Jacobian 条件良好。

16.1.4 梯度裁剪

若梯度爆炸，可采用全局范数裁剪：

$$\tilde{\mathbf{g}} = \mathbf{g} \min \left\{ 1, \frac{\tau}{\|\mathbf{g}\|_2} \right\}, \quad (16.5)$$

其中 $\tau > 0$ 是阈值。当 $\|\mathbf{g}\| \leq \tau$ 时不改变梯度；当 $\|\mathbf{g}\| > \tau$ 时只缩放大小、不改变方向。

答题方法

[26S-B-Q1(b), 2 分] 的标准答案：

1. 写 $\sigma'(z) = \sigma(z)(1 - \sigma(z)) \leq 1/4$ ；
2. 写深层反传包含 $\prod_r (\mathbf{W}^{(r)})^\top \mathbf{D}^{(r)}$ ；
3. 说明多个不超过 1/4 的因子导致指数衰减，且饱和区导数接近 0；
4. 写 ReLU 在正半轴导数为 1，因而不产生 sigmoid 式饱和缩放；
5. 同时指出 ReLU 在负半轴导数为 0，可能出现 dead ReLU，且权重谱范数仍可能造成梯度爆炸或消失。

16.2 参数初始化与方差传播

16.2.1 为什么不能把所有权重初始化为零

考虑同一隐藏层的两个神经元。若其权重和偏置完全相同，则前向输出相同，接收的反向梯度也相同，参数更新后仍相同。因此它们永久学习相同特征，无法打破置换对称性。

通常可令偏置初始化为零，但不同神经元的权重必须随机化或采用其他能打破对称性的初始化。

16.2.2 线性层的前向方差

设 $z_j = \sum_{i=1}^n W_{ji} h_i$, $n = \text{fan}_{\text{in}}$ 。假设：

1. W_{ji} 与 h_i 独立；
2. 各 W_{ji} 独立同分布、均值为零；
3. 各 h_i 独立同分布、均值为零；
4. 交叉协方差可忽略。



则

$$\text{Var}(z_j) = n \text{Var}(W_{ji}) \text{Var}(h_i). \quad (16.6)$$

为了保持前向方差数量级，可令 $n \text{Var}(W_{ji}) \approx 1$ 。

反向传播中也有类似关系。若输出宽度为 $m = \text{fan}_{\text{out}}$ ，则反向方差保持倾向于要求 $m \text{Var}(W_{ji}) \approx 1$ 。两者通常不能同时精确满足，因此需要折中。

16.2.3 Xavier/Glorot 初始化

对线性、tanh 或近似对称激活，常用

$$\text{Var}(W_{ji}) = \frac{2}{\text{fan}_{\text{in}} + \text{fan}_{\text{out}}}. \quad (16.7)$$

高斯形式为

$$W_{ji} \sim \mathcal{N}\left(0, \frac{2}{\text{fan}_{\text{in}} + \text{fan}_{\text{out}}}\right), \quad (16.8)$$

均匀形式为

$$W_{ji} \sim \text{Unif}\left[-\sqrt{\frac{6}{\text{fan}_{\text{in}} + \text{fan}_{\text{out}}}}, \sqrt{\frac{6}{\text{fan}_{\text{in}} + \text{fan}_{\text{out}}}}\right]. \quad (16.9)$$

有些资料只按前向方差使用 $\text{Var}(W) = 1/\text{fan}_{\text{in}}$ 。考试中应说明采用的是 fan-in 版本还是 fan-in/fan-out 折中版本。

16.2.4 Kaiming/He 初始化

若 Z 关于零近似对称，则

$$\mathbb{E}[\text{ReLU}(Z)^2] = \frac{1}{2} \mathbb{E}[Z^2]. \quad (16.10)$$

为补偿 ReLU 丢弃约一半信号，令

$$\text{Var}(W_{ji}) = \frac{2}{\text{fan}_{\text{in}}}. \quad (16.11)$$

相应高斯与均匀初始化为

$$W_{ji} \sim \mathcal{N}\left(0, \frac{2}{\text{fan}_{\text{in}}}\right), \quad (16.12)$$

$$W_{ji} \sim \text{Unif}\left[-\sqrt{\frac{6}{\text{fan}_{\text{in}}}}, \sqrt{\frac{6}{\text{fan}_{\text{in}}}}\right]. \quad (16.13)$$

易错点、反例与失败模式

Xavier 与 Kaiming 结论依赖近似独立、零均值和相似分布等假设。深层训练后这些假设通常不再严格成立，所以初始化只能改善训练起点，不能代替归一化、残差连接或学习率控制。

16.3 Mini-batch SGD

设 $J_N(\theta) = \frac{1}{N} \sum_{i=1}^N \ell_i(\theta)$ 。在第 k 次迭代，从训练索引中抽取 batch $\mathcal{B}_k$ ， $|\mathcal{B}_k| = B$ ，并计算

$$\hat{\mathbf{g}}_k = \frac{1}{B} \sum_{i \in \mathcal{B}_k} \nabla \ell_i(\theta_k). \quad (16.14)$$

更新为

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta_k \hat{\mathbf{g}}_k. \quad (16.15)$$

若样本索引独立均匀抽取，则条件于 $\boldsymbol{\theta}_k$,

$$\mathbb{E}_k[\hat{\mathbf{g}}_k] = \nabla J_N(\boldsymbol{\theta}_k), \quad (16.16)$$

且在独立同分布近似下

$$\text{Cov}_k(\hat{\mathbf{g}}_k) = \frac{1}{B} \text{Cov}_k(\nabla \ell_I(\boldsymbol{\theta}_k)). \quad (16.17)$$

不放回均匀抽取时存在有限总体修正：

$$\text{Cov}_k(\hat{\mathbf{g}}_k) = \frac{N-B}{B(N-1)} \boldsymbol{\Sigma}_k. \quad (16.18)$$

每轮主要计算与显存量级为 $T_{\text{step}} = O(B C_{\text{model}})$, $M_{\text{activation}} = O(B A_{\text{model}})$, 其中 C_{model} 为单样本前向/反向计算量, A_{model} 为单样本需保存的激活量。

易错点、反例与失败模式

1. SGD 不等于每轮一定使用单个样本；小 batch 更新也通常统称 SGD。
2. 随机梯度“无偏”需要说明抽样方式；数据增强、重要性采样或非均匀采样可能改变无偏权重。
3. mini-batch 增大通常降低梯度方差，但不保证墙钟时间按比例下降；还受硬件并行、通信和内存限制。
4. 非凸神经网络中，SGD 不保证有限步到达全局最优解。

16.4 学习率与 Momentum

16.4.1 学习率过大的发散例子

对一维二次函数 $J(\theta) = \frac{a}{2}\theta^2$, $a > 0$, 梯度下降为 $\theta_{k+1} = (1 - \eta a)\theta_k$ 。收敛当且仅当

$$|1 - \eta a| < 1 \iff 0 < \eta < \frac{2}{a}. \quad (16.19)$$

若 $0 < \eta < 1/a$, 迭代单调衰减；若 $1/a < \eta < 2/a$, 迭代振荡但收敛；若 $\eta \geq 2/a$, 则不收敛。

常见学习率日程包括：step decay、exponential decay、cosine annealing。它们是训练设计，不是对任意非凸问题都成立的收敛定理。

16.4.2 Momentum 的主约定

全文采用与附件一致的主约定：

$$\mathbf{v}_{k+1} = \rho \mathbf{v}_k + \hat{\mathbf{g}}_k, \quad 0 \leq \rho < 1, \quad (16.20)$$

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k - \eta_k \mathbf{v}_{k+1}. \quad (16.21)$$

另一常见约定为

$$\mathbf{u}_{k+1} = \rho \mathbf{u}_k - \eta_k \hat{\mathbf{g}}_k,$$

$$\boldsymbol{\theta}_{k+1} = \boldsymbol{\theta}_k + \mathbf{u}_{k+1}.$$



两者可通过变量缩放对应，但不得把两个约定的更新顺序静默混合。

由递推可得

$$\mathbf{v}_{k+1} = \sum_{t=0}^k \rho^{k-t} \hat{\mathbf{g}}_t + \rho^{k+1} \mathbf{v}_0. \quad (16.22)$$

因此 momentum 对历史梯度作指数加权累积：

- 一致方向的梯度会累积；
- 高频改变符号的梯度会部分抵消；
- 在狭长谷底中可减少横向振荡、加快纵向推进；
- 但学习率或 ρ 过大时也会导致过冲和不稳定。

答题方法

[26S-B-Q1(c), 2 分] 应写：

$$\begin{aligned} \mathbf{v}_{k+1} &= \rho \mathbf{v}_k + \hat{\mathbf{g}}_k, \\ \boldsymbol{\theta}_{k+1} &= \boldsymbol{\theta}_k - \eta \mathbf{v}_{k+1}. \end{aligned}$$

随后说明： $\mathbf{v}_{k+1} = \sum_{t \leq k} \rho^{k-t} \hat{\mathbf{g}}_t$ 是历史梯度的指数加权和；因此在稳定下降方向上累积速度，在梯度来回变号的方向上平滑振荡。不得只写“momentum 加快收敛”而没有更新式和机制。

16.5 Batch Normalization

重要性等级：S

[25S-B-Q1(c), 4 分] 要求明确区分 BN 在训练阶段和测试阶段使用的统计量。漏写 running mean/running variance 通常会损失主要分数。

16.5.1 训练阶段

考虑 batch 中某一标量特征 $x_1, \dots, x_B$ 。训练阶段计算 batch 均值和方差：

$$\mu_B = \frac{1}{B} \sum_{i=1}^B x_i, \quad (16.23)$$

$$\sigma_B^2 = \frac{1}{B} \sum_{i=1}^B (x_i - \mu_B)^2. \quad (16.24)$$


归一化并作可学习仿射变换：

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \quad (16.25)$$

$$y_i = \gamma \hat{x}_i + \beta. \quad (16.26)$$

其中： $\gamma, \beta \in \mathbb{R}$ 为可训练参数， $\varepsilon > 0$ 防止除零并改善数值稳定性。

对 d 维全连接特征， $\gamma, \beta \in \mathbb{R}^d$ ，均值和方差按特征维分别计算。对卷积张量 $\mathbf{X} \in \mathbb{R}^{B \times C \times H \times W}$ ，标准 BN 通常对每个通道在 B, H, W 三个维度上聚合统计量，因此 $\gamma, \beta \in \mathbb{R}^C$ 。



训练时还更新移动统计量。采用主约定

$$\bar{\mu} \leftarrow \rho \bar{\mu} + (1 - \rho) \mu_B, \quad (16.27)$$

$$\overline{\sigma^2} \leftarrow \rho \overline{\sigma^2} + (1 - \rho) \sigma_B^2. \quad (16.28)$$

不同软件库对 momentum 符号和方差是否作无偏修正存在差异；答题时只需选定一个约定并保持一致。

16.5.2 推理阶段

测试或部署时不再使用当前测试 batch 的均值与方差，而使用训练期间累计的 $\bar{\mu}$, $\overline{\sigma^2}$ 。推理公式为

$$y = \gamma \frac{x - \bar{\mu}}{\sqrt{\overline{\sigma^2} + \varepsilon}} + \beta. \quad (16.29)$$

此时输出对同一输入应是确定的，并且不应依赖同一测试 batch 中出现了哪些其他样本。

16.5.3 BN 的反向传播

对单一特征，令 $g_i = \frac{\partial J}{\partial y_i}$ 。则

$$\frac{\partial J}{\partial \beta} = \sum_{i=1}^B g_i, \quad (16.30)$$

$$\frac{\partial J}{\partial \gamma} = \sum_{i=1}^B g_i \hat{x}_i. \quad (16.31)$$

输入梯度可化为紧凑形式：

$$\frac{\partial J}{\partial x_i} = \frac{\gamma}{\sqrt{\overline{\sigma_B^2} + \varepsilon}} \left[g_i - \frac{1}{B} \sum_{r=1}^B g_r - \hat{x}_i \frac{1}{B} \sum_{r=1}^B g_r \hat{x}_r \right] \quad (16.32)$$

该式说明同一 batch 中样本的梯度相互耦合。

16.5.4 作用、条件与失败模式

BN 常可：

- 稳定中间特征尺度；
- 改善梯度传播；
- 允许使用更大的学习率；
- 通过 batch 统计噪声产生一定正则化效应。

但不能写成“BN 对任意网络和任意学习率都保证收敛”。附件中提及的任意步长收敛结论有特定线性模型和理论假设，不可外推到一般非凸深度网络。

主要失败模式：

1. batch 太小时，统计量噪声过大；
2. batch size 为 1 时方差退化；



3. 忘记切换到 evaluation mode, 导致测试输出依赖测试 batch;
4. 训练分布与部署分布变化时, running statistics 不再匹配;
5. 微调时冻结权重却错误更新 BN 统计量;
6. 把 BN 与 Layer Normalization 混为一谈。

答题方法

[25S-B-Q1(c), 4 分] 的四个必要得分点:

1. 训练阶段计算 μ_B, σ_B^2 ;
2. 归一化后使用可学习的 γ, β ;
3. 训练过程中维护 running mean 和 running variance;
4. 测试阶段使用固定 running statistics, 不使用当前测试 batch 统计量。

16.6 残差连接

残差块定义为

$$\mathbf{h}^{(\ell+1)} = \mathbf{h}^{(\ell)} + F_{\ell}(\mathbf{h}^{(\ell)}; \boldsymbol{\theta}_{\ell}). \quad (16.33)$$

要求两项维度相同。若维度不同, 可使用投影捷径 $\mathbf{h}^{(\ell+1)} = \mathbf{P}_{\ell}\mathbf{h}^{(\ell)} + F_{\ell}(\mathbf{h}^{(\ell)})$, 但此时捷径不再是纯恒等映射。

反向传播为

$$\nabla_{\mathbf{h}^{(\ell)}} J = [\mathbf{I} + \mathbf{J}_{F_{\ell}}(\mathbf{h}^{(\ell)})]^{\top} \nabla_{\mathbf{h}^{(\ell+1)}} J. \quad (16.34)$$

即使 $\mathbf{J}_{F_{\ell}}$ 很小, 仍存在恒等梯度通路 $\mathbf{I}^{\top} \nabla_{\mathbf{h}^{(\ell+1)}} J$ 。这解释了残差连接为何有助于深层信号和梯度传播。

若捷径改为 $\lambda \mathbf{h}^{(\ell)}$, $0 < \lambda < 1$, 连续多层后恒等通路会产生 λ^K 衰减, 因此纯恒等捷径具有特殊作用。

易错点、反例与失败模式

残差连接缓解深层优化困难, 但不意味着:

- 梯度绝不会消失或爆炸;
- 任意深度都能稳定训练;
- 残差网络必然具有更低总体风险;
- 增加层数没有计算和存储代价。

16.7 Dropout

16.7.1 主约定：inverted dropout

设保留概率为 $q = 1 - p$ ，并对激活向量采样 $m_j \sim \text{Bernoulli}(q)$ 。训练阶段使用

$$\tilde{\mathbf{h}} = \frac{\mathbf{m}}{q} \odot \mathbf{h}. \quad (16.35)$$

于是

$$\mathbb{E}_{\mathbf{m}}[\tilde{\mathbf{h}} \mid \mathbf{h}] = \mathbf{h}. \quad (16.36)$$

单坐标条件方差为

$$\text{Var}(\tilde{h}_j \mid h_j) = \frac{1-q}{q} h_j^2. \quad (16.37)$$

推理阶段直接使用 $\tilde{\mathbf{h}} = \mathbf{h}$ ，不再随机丢弃，也无需额外缩放。

旧式约定是在训练时不除以 q ，推理时再把权重或激活乘 q 。全文采用 inverted dropout，二者不得混用。

16.7.2 作用与边界

Dropout 在训练时随机屏蔽激活，迫使网络不能依赖单一特征通路，并可近似理解为共享参数子网络的随机集成训练。但“精确等于所有子网络的贝叶斯模型平均”通常不成立。

主要错误：

1. 标准 dropout 通常随机屏蔽激活，而不是永久删除参数；
2. 推理阶段若仍随机 dropout，单次输出会不稳定；
3. 若使用 Monte Carlo dropout，应明确多次随机前向并求平均，这不同于标准确定性推理；
4. dropout 过强会导致训练误差高和欠拟合；
5. BN 与 dropout 的噪声机制可能相互作用，顺序和强度需验证。

16.8 Weight Decay、数据增强与 Early Stopping


16.8.1 Weight decay 与 ℓ_2 penalty

对普通 SGD，若目标为 $J(\boldsymbol{\theta}) = L(\boldsymbol{\theta}) + \frac{\lambda}{2} \|\boldsymbol{\theta}\|^2$ ，则

$$\begin{aligned} \boldsymbol{\theta}_{k+1} &= \boldsymbol{\theta}_k - \eta [\nabla L(\boldsymbol{\theta}_k) + \lambda \boldsymbol{\theta}_k] \\ &= (1 - \eta \lambda) \boldsymbol{\theta}_k - \eta \nabla L(\boldsymbol{\theta}_k). \end{aligned} \quad (16.38)$$

因此在普通 SGD 中，耦合 ℓ_2 penalty 与乘法式 weight decay 等价。

对 Adam 等坐标自适应算法，正则梯度也会被预条件器缩放，一般不再等价于直接执行 $\boldsymbol{\theta} \leftarrow (1 - \eta \lambda) \boldsymbol{\theta} - \eta \cdot \text{adaptive-step}$ 。AdamW 的详细区别将在优化方向统一讨论。



16.8.2 数据增强

设 $T \sim \mathcal{A}$ 是随机变换，且任务假设 $y(T\mathbf{x}) = y(\mathbf{x})$ 。增强后的目标为

$$\frac{1}{N} \sum_{i=1}^N \mathbb{E}_{T \sim \mathcal{A}} [\ell(f_{\theta}(T\mathbf{x}_i), y_i)]. \quad (16.39)$$

数据增强将任务不变性作为归纳偏置加入训练。若变换不保持标签，例如把方向敏感任务中的图像任意翻转，则增强可能引入系统性标签噪声。

16.8.3 Early stopping

训练过程中按固定频率计算验证风险 $\hat{R}_{\text{val}}(\theta_k)$ 。选择

$$k^* \in \arg \min_k \hat{R}_{\text{val}}(\theta_k), \quad (16.40)$$

并恢复第 k^* 次迭代的参数。Early stopping 使用验证集，不使用测试集；它同时是模型选择和训练轮数选择机制。

16.9 训练误差与测试误差的诊断矩阵

表 16.1: 训练失败诊断

现象	主要诊断	优先检查与处理
训练误差高，验证误差也高	可能是表达能力不足，也可能是优化失败。	先检查数据、标签、损失实现和梯度；检查学习率、初始化、激活、归一化；训练更久；若优化正常，再增加宽度、深度、残差块或更合适架构，并适当减小过强正则。
训练误差低，验证误差高	过拟合或分布不匹配。	增加数据；使用标签保持的数据增强；weight decay、dropout、early stopping；减小模型容量；检查 train/validation 分布差异和数据泄漏。
训练与验证误差均低，测试误差异常高	测试分布变化、测试流程错误或验证集被过度调参。	检查预处理和 evaluation mode；检查 BN/dropout；检查测试分布；重新设置真正独立的测试集。
损失出现 NaN 或发散	数值不稳定、学习率过大或梯度爆炸。	减小学习率；梯度裁剪；检查 log、除法、softmax 数值稳定性；检查混合精度 loss scaling；检查异常输入和参数初始化。
损失下降极慢	学习率过小、饱和激活、条件数差或梯度消失。	调整学习率和调度；使用 ReLU/LeakyReLU；采用合适初始化、BN、残差连接；检查梯度范数分层分布。

16.10 [25S-B-Q1, 18 分] 答题方法

答题方法

(a) [25S-B-Q1(a), 4 分]: 假设空间。

设 $g_\phi: \mathbb{R}^d \rightarrow \mathbb{R}^h$ 为特征提取 MLP, $c_\psi: \mathbb{R}^h \rightarrow \mathbb{R}^C$ 为分类 MLP。写 $\mathbf{z}_\theta(\mathbf{x}) = c_\psi(g_\phi(\mathbf{x}))$, $\mathbf{p}_\theta(\mathbf{x}) = \text{softmax}(\mathbf{z}_\theta(\mathbf{x}))$ 。参数为 $\theta = (\phi, \psi)$, 输入为 $\mathbf{x} \in \mathbb{R}^d$, 输出为 $\mathbf{p} \in \Delta^{C-1}$ 。必须说明每层 $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$, $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_\ell}$ 。

(b) [25S-B-Q1(b), 4 分]: 损失与 SGD。

交叉熵: $J_N(\theta) = -\frac{1}{N} \sum_{i=1}^N \log p_\theta(y_i | \mathbf{x}_i)$ 。对 mini-batch $\mathcal{B}_k$, $\hat{\mathbf{g}}_k = \frac{1}{|\mathcal{B}_k|} \sum_{i \in \mathcal{B}_k} \nabla_\theta [-\log p_{\theta_k}(y_i | \mathbf{x}_i)]$, 并更新 $\theta_{k+1} = \theta_k - \eta_k \hat{\mathbf{g}}_k$ 。说明梯度通过 backpropagation 计算。

(c) [25S-B-Q1(c), 4 分]: BN。

训练阶段: $\mu_B = \frac{1}{B} \sum_i x_i$, $\sigma_B^2 = \frac{1}{B} \sum_i (x_i - \mu_B)^2$, $y_i = \gamma \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta$ 。同时更新 running mean/variance。测试阶段使用固定 running statistics, 不使用测试 batch 统计量。

(d) [25S-B-Q1(d), 3 分]: 训练误差高。

题目要求提升表达能力时, 应至少写两项并说明作用:

1. 增加隐藏层宽度, 增加每层可表示的特征数量;
2. 增加深度并配合 residual connection, 使模型表达更复杂的函数复合;
3. 使用适合任务的非线性激活或更合适架构。

还可补充: 先排除学习率、初始化、梯度和实现错误, 因为高训练误差不一定由容量不足导致。

(e) [25S-B-Q1(e), 3 分]: 训练低、测试高。

至少写两项: 数据增强、更多数据、weight decay、dropout、early stopping、减小容量。每一项应说明如何降低有效复杂度或扩大训练分布覆盖。不得写“继续增大网络”作为主要抗过拟合措施。

16.11 高频易错点总表

表 16.2: 深度学习基础易错点

错误说法	正确改法
反向传播要求激活函数处处可微。	ReLU 在零点不可经典微分; 实际使用选定次梯度或几乎处处导数。反向传播要求计算图中的局部算子具有可用的导数规则。
自动微分等于符号微分。	自动微分对程序中的基本算子应用链式法则, 通常不生成庞大的解析表达式。
ReLU 完全消除了梯度消失。	ReLU 在正半轴导数为 1, 缓解饱和; 负半轴导数为 0, 且权重 Jacobian 仍可导致消失或爆炸。

错误说法	正确改法
网络更深，训练误差必然更低。	函数类可能更丰富，但非凸优化、梯度传播和数值稳定性可能使实际训练更差。
BN 在训练和测试时公式完全相同。	仿射形式相同，但训练使用当前 batch 统计量，测试使用训练期间累计的 running statistics。
Dropout 在测试时也应随机丢弃。	标准 inverted dropout 只在训练时随机；测试时关闭 dropout。Monte Carlo dropout 是另一个显式推理方案。
Weight decay 总等于 ℓ_2 正则。	在普通 SGD 中等价；在自适应优化器中一般不等价，AdamW 使用解耦 weight decay。
Mini-batch 越大越好。	大 batch 降低梯度方差并提高并行度，但增加显存、减少每 epoch 更新次数，并可能需要重调学习率和正则化。
测试集可以用于 early stopping。	Early stopping 应基于验证集；测试集只用于最终评估。
低训练误差意味着模型表达能力足够且泛化良好。	低训练误差仅说明训练样本被拟合；仍需验证总体风险、分布变化和过拟合。

16.12 本部分真题与课程训练映射

表 16.3: 第 6 部分题目映射

题目	主要标签	满分或正确选择所需内容
[25S-B-Q1(a), 4 分]	MLP 假设空间	特征提取器、分类头、输入输出、参数与概率单纯形。
[25S-B-Q1(b), 4 分]	交叉熵、SGD	负对数似然、mini-batch 梯度、参数更新、backprop。
[25S-B-Q1(c), 4 分]	Batch normalization	batch 均值方差、 γ, β 、running statistics、训练/测试差异。
[25S-B-Q1(d), 3 分]	表达能力	宽度、深度、非线性或更合适架构；同时区分容量问题与优化问题。
[25S-B-Q1(e), 3 分]	过拟合	数据增强、更多数据、weight decay、dropout、early stopping、减小容量。
[26S-B-Q1(a), 2 分]	链式法则、复杂度	完整 Jacobian 链；反向传播复用中间梯度；全部梯度与前向同阶。

题目	主要标签	满分或正确选择所需内容
[26S-B-Q1(b), 2 分]	梯度消失、激活函数	$\sigma'(z) \leq 1/4$; Jacobian 连乘; ReLU 正半轴导数与 dead ReLU。
[26S-B-Q1(c), 2 分]	Momentum	缓冲变量、参数更新、指数加权历史梯度与振荡平滑。
[MLT-Final-MQ6, 1 分, 课程期末选择题]	Backprop 条件	课程题预期选择“激活函数可微”; 严格表述应补充 ReLU 可使用次梯度或几乎处处导数。
[MLT-Final-MQ7, 2 分, 课程期末选择题]	Mini-batch SGD	更新基于单样本或小 batch, 而非每轮完整数据。
[MLT-Final-MQ8, 2 分, 课程期末选择题]	Tanh 梯度	$\nabla_w o = (1 - o^2)x$ 。

16.13 快速自测

快速自测

1. 若 $\mathbf{W}^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$, 则 $\nabla_{\mathbf{W}^{(\ell)}} J$ 应是什么维度?
2. 对 $\mathbf{z} = \mathbf{W}\mathbf{h} + \mathbf{b}$, 为什么 $\nabla_{\mathbf{W}} J = \mathbf{g}\mathbf{h}^\top$ 而不是 $\mathbf{h}\mathbf{g}^\top$?
3. 为什么 softmax 与交叉熵合并后有 $\nabla_{\mathbf{z}} \ell = \mathbf{p} - \mathbf{y}$?
4. 反向传播为何需要在分支节点累加梯度?
5. 为什么求全部参数梯度不需要对每个参数分别运行一次前向传播?
6. Sigmoid 的哪一个精确导数上界导致深层梯度衰减?
7. ReLU 如何缓解梯度消失, 又如何产生 dead ReLU?
8. Xavier 和 Kaiming 初始化分别适合什么激活, 其方差是多少?
9. Mini-batch 随机梯度在什么抽样条件下无偏?
10. 本文 momentum 的更新顺序是什么? 另一种常见约定如何写?
11. BN 的 μ_B, σ_B^2 在训练和测试时分别如何使用?
12. Inverted dropout 为什么在测试时不需要再乘保留概率?
13. 普通 SGD 中 weight decay 与 ℓ_2 penalty 为何等价? 在 Adam 中为什么一般不等价?
14. 训练误差高时, 如何区分“表达能力不足”和“优化失败”?
15. 训练误差低而测试误差高时, 测试集能否用于选择 early stopping 时刻?



第十七章 卷积神经网络与视觉任务

17.1 重要性等级与实考定位

重要性等级：S

- [25F-B-Q1(a), 3 分] 要求精确计算卷积层参数量，并与相同输入、输出规模的全连接层比较。满分答案必须说明参数共享、局部连接以及参数量为何不依赖输入的空间位置数。
- [25F-B-Q1(c), 3 分] 要求同时说明卷积和 self-attention 的关键优势，并设计一个最小的卷积-注意力混合视觉模型。
- 输出尺寸、张量维度、Receptive Field 和计算复杂度是视觉网络计算题的固定母题。
- 图像恢复和语义分割在 [DL-Basic] 中通过 U-Net 展开；目标检测、光流和三维重构是考纲明确节点。对后三者，本章给出依据考纲和附件中 image-to-image 建模框架所作的标准化数学补充，不虚构附件中的具体模型。

本章要求：

- 卷积输出尺寸、参数量、计算量和 Receptive Field 必须会完整计算；
- 平移等变性的证明必须掌握；
- 各视觉任务必须会写输入、输出、损失、推理流程、评价指标和失败模式；
- 不要求背诵特定检测器或光流网络的历史结构。

17.2 卷积与互相关的统一约定

17.2.1 数学卷积与深度学习中的“卷积”

对一维离散信号，严格数学卷积定义为


$$(f * h)[i] = \sum_{n \in \mathbb{Z}} f[n]h[i - n]. \quad (17.1)$$

其中核索引发生翻转。

多数深度学习软件库实现的是互相关（cross-correlation）：

$$(f \star h)[i] = \sum_n f[i + n]h[n]. \quad (17.2)$$

由于卷积核本身是可学习参数，核是否预先翻转通常不影响函数类表达能力。但进行手工计算时必须说明采用哪个约定。



全文在神经网络层中采用软件库常见的互相关约定，并继续称其为“卷积层”。

17.2.2 二维多通道卷积

设单个输入特征张量为 $\mathbf{X} \in \mathbb{R}^{C_{\text{in}} \times H \times W}$ 。卷积核为 $\mathbf{K} \in \mathbb{R}^{C_{\text{out}} \times C_{\text{in}} \times k_h \times k_w}$ ，偏置为 $\mathbf{b} \in \mathbb{R}^{C_{\text{out}}}$ 。令： s_h, s_w 为 stride, p_h, p_w 为上下、左右每一侧的零填充大小, d_h, d_w 为 dilation。

输出 $\mathbf{Y} \in \mathbb{R}^{C_{\text{out}} \times H_{\text{out}} \times W_{\text{out}}}$ 的元素为

$$Y_{o,u,v} = b_o + \sum_{c=1}^{C_{\text{in}}} \sum_{a=0}^{k_h-1} \sum_{b=0}^{k_w-1} K_{o,c,a,b} X_{c,us_h+ad_h-p_h,vs_w+bd_w-p_w}. \quad (17.3)$$

超出原输入边界的 X 元素按零处理。

有效核尺寸为

$$k_{h,\text{eff}} = d_h(k_h - 1) + 1, \quad (17.4)$$

$$k_{w,\text{eff}} = d_w(k_w - 1) + 1. \quad (17.5)$$

输出尺寸为

$$\begin{aligned} H_{\text{out}} &= \left\lfloor \frac{H + 2p_h - k_{h,\text{eff}}}{s_h} \right\rfloor + 1 \\ &= \left\lfloor \frac{H + 2p_h - d_h(k_h - 1) - 1}{s_h} \right\rfloor + 1, \end{aligned} \quad (17.6)$$

$$W_{\text{out}} = \left\lfloor \frac{W + 2p_w - d_w(k_w - 1) - 1}{s_w} \right\rfloor + 1. \quad (17.7)$$

说明 17.1 (Padding 记号差异). 有些讲义把 p_h 表示为上下两侧的总填充量。若总填充量记为 P_h ，则式 (17.6) 中的 $2p_h$ 应改为 P_h 。全文采用“每侧填充量”约定。

当 $s_h = s_w = 1$, $d_h = d_w = 1$, 且 k_h, k_w 为奇数时, 选择 $p_h = \frac{k_h-1}{2}$, $p_w = \frac{k_w-1}{2}$ 可保持 $H_{\text{out}} = H$, $W_{\text{out}} = W$ 。

17.2.3 参数量、计算量与存储

每个输出通道有一个 $C_{\text{in}} \times k_h \times k_w$ 卷积核和一个偏置。因此参数量为

$$P_{\text{conv}} = C_{\text{out}} (C_{\text{in}} k_h k_w + 1). \quad (17.8)$$

偏置只有 C_{out} 个, 而不是每个输出空间位置一个偏置。

若将输入和输出全部展平, 并使用完全稠密映射, 则

$$D_{\text{in}} = HWC_{\text{in}}, \quad (17.9)$$

$$D_{\text{out}} = H_{\text{out}}W_{\text{out}}C_{\text{out}}, \quad (17.10)$$

全连接层参数量为

$$P_{\text{dense}} = D_{\text{out}}(D_{\text{in}} + 1). \quad (17.11)$$

当输入和输出空间尺寸较大时, $P_{\text{dense}} \gg P_{\text{conv}}$ 。

对一个 batch $\mathbf{X} \in \mathbb{R}^{B \times C_{\text{in}} \times H \times W}$, 卷积层乘加运算量主项为

$$T_{\text{conv}} = O(BH_{\text{out}}W_{\text{out}}C_{\text{out}}C_{\text{in}}k_hk_w). \quad (17.12)$$



输出激活存储为

$$M_{\text{activation}} = O(BC_{\text{out}}H_{\text{out}}W_{\text{out}}). \quad (17.13)$$

例 17.2 (历年真题型：卷积层与全连接层比较). 对应 [25F-B-Q1(a), 3 分]。

设输入为 $H \times W \times C_{\text{in}}$, 卷积核为 $k \times k$, 输出通道数为 C_{out} , 包含偏置。则 $P_{\text{conv}} = C_{\text{out}}(C_{\text{in}}k^2 + 1)$ 。

若卷积保持空间尺寸, 即输出为 $H \times W \times C_{\text{out}}$, 对应全连接映射参数量为 $P_{\text{dense}} = (HWC_{\text{out}})(HWC_{\text{in}} + 1)$ 。两者的主要差别为: $P_{\text{conv}} = O(C_{\text{in}}C_{\text{out}}k^2)$, 而 $P_{\text{dense}} = O(H^2W^2C_{\text{in}}C_{\text{out}})$ 。卷积的低参数量来自:

1. 每个输出只连接局部 $k \times k$ 邻域;
2. 同一卷积核在全部空间位置共享。

易错点、反例与失败模式

1. 卷积参数量通常与 H, W 无关, 但计算量与 $H_{\text{out}}W_{\text{out}}$ 成正比。
2. 参数共享不意味着每个空间位置的输出相同; 不同位置读取的局部输入不同。
3. stride 改变输出尺寸和采样格点, 但不改变卷积核参数量。
4. dilation 扩大有效 Receptive Field, 但不增加核参数个数。

17.3 局部连接、参数共享与平移等变性

17.3.1 局部连接

式 (17.3) 表明, 单个输出位置 (u, v) 只依赖输入中的一个有限局部邻域。这形成适合图像的局部归纳偏置: 邻近像素的统计依赖通常强于任意远距离像素。

局部连接层若不共享权重, 则每个输出位置都有独立卷积核, 其参数量为

$$P_{\text{local}} = H_{\text{out}}W_{\text{out}}C_{\text{out}}(C_{\text{in}}k_hk_w + 1). \quad (17.14)$$

卷积层比它进一步少一个 $H_{\text{out}}W_{\text{out}}$ 因子。

17.3.2 平移等变性

令二维平移算子为


$$(T_{\Delta}X)[u, v] = X[u - \Delta_h, v - \Delta_w]. \quad (17.15)$$

命题 17.3 (卷积的平移等变性). 在 stride 为 1、边界处理与平移相容的条件下, 卷积算子 $\mathcal{C}_K$ 满足

$$\mathcal{C}_K(T_{\Delta}X) = T_{\Delta}\mathcal{C}_K(X). \quad (17.16)$$

证明. 为简化记号, 先考虑单通道二维卷积:

$$\begin{aligned} [\mathcal{C}_K(T_{\Delta}X)](u, v) &= \sum_{a, b} K(a, b)(T_{\Delta}X)(u + a, v + b) \\ &= \sum_{a, b} K(a, b)X(u + a - \Delta_h, v + b - \Delta_w) \\ &= [\mathcal{C}_KX](u - \Delta_h, v - \Delta_w) \\ &= [T_{\Delta}\mathcal{C}_K(X)](u, v). \end{aligned} \quad (17.17)$$



多通道求和不改变该结论。 □

“等变”意味着：输入平移 $\implies$ 特征图相应平移。它不等于输出完全不变。

分类模型中的近似的平移不变性通常来自：

- pooling;
- stride 下采样;
- global average pooling;
- 数据增强;
- 最终空间聚合。

易错点、反例与失败模式

卷积是平移**等变**的，而非天然平移**不变**。

此外，以下因素会破坏严格的像素级等变性：

- 零填充的边界效应;
- stride > 1 的欠采样;
- 非平移相容的裁剪和 resize;
- 绝对位置相关操作。

17.4 Receptive Field、Stride、Dilation 与 Pooling

17.4.1 Receptive Field 递推

对第 ℓ 层，定义：

- r_ℓ : 该层一个神经元在原始输入上的 Receptive Field 宽度;
- j_ℓ : 相邻两个该层神经元在原始输入坐标中的间距;
- k_ℓ : 核大小;
- s_ℓ : stride;
- d_ℓ : dilation。

初始化 $r_0 = 1$, $j_0 = 1$ 。有效核宽度为 $\kappa_\ell = d_\ell(k_\ell - 1) + 1$ 。递推为


$$j_\ell = j_{\ell-1}s_\ell, \quad (17.18)$$

$$r_\ell = r_{\ell-1} + (\kappa_\ell - 1)j_{\ell-1}. \quad (17.19)$$

若所有层 $s_\ell = d_\ell = 1$, 则

$$r_L = 1 + \sum_{\ell=1}^L (k_\ell - 1). \quad (17.20)$$

例如连续三层 3×3 卷积的理论 Receptive Field 为 $1 + 3(3 - 1) = 7$, 即 7×7 。



一般一维形式为

$$r_L = 1 + \sum_{\ell=1}^L \left[d_{\ell}(k_{\ell} - 1) \prod_{q=1}^{\ell-1} s_q \right]. \quad (17.21)$$

高度和宽度分别应用该公式。

17.4.2 Pooling

对局部邻域 $\mathcal{N}(i)$ ，最大池化和平均池化分别为

$$y_i^{\max} = \max_{j \in \mathcal{N}(i)} x_j, \quad (17.22)$$

$$y_i^{\text{avg}} = \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} x_j. \quad (17.23)$$

Pooling 通常无可训练参数，但会：

- 降低空间分辨率；
- 扩大后续层相对原图的 Receptive Field；
- 丢失精确位置信息；
- 对局部小位移产生一定鲁棒性。

最大池化是分段线性、非光滑运算。若局部最大值唯一，反向梯度只传给最大元素；若最大值并列，次梯度分配依软件约定。

17.5 视觉任务的统一建模框架

设输入图像 batch 为 $\mathbf{X} \in \mathbb{R}^{B \times C_{\text{in}} \times H \times W}$ 。视觉任务的核心差异不是“是否使用 CNN”，而是：

$$\text{预测对象的结构} + \text{监督信号} + \text{损失} + \text{评价指标}. \quad (17.24)$$

17.5.1 图像分类

输出 logits: $\mathbf{Z} \in \mathbb{R}^{B \times C}$ 。通常先获得空间特征图 $\mathbf{F} \in \mathbb{R}^{B \times D \times H' \times W'}$ ，再做 global average pooling：

$$h_{b,c} = \frac{1}{H'W'} \sum_{u=1}^{H'} \sum_{v=1}^{W'} F_{b,c,u,v}. \quad (17.25)$$

最后用线性分类头和交叉熵训练。

常用评价指标: top-1 accuracy, top-k accuracy。对类别不平衡数据，还应报告 macro-F1、balanced accuracy 或每类召回率，而不能只报告总体 accuracy。

17.5.2 语义分割

每个像素都预测一个类别: $\mathbf{Z} \in \mathbb{R}^{B \times C \times H \times W}$ 。像素交叉熵为

$$\mathcal{L}_{\text{seg,CE}} = -\frac{1}{BHW} \sum_{b,u,v} \log p_{b,y_{buv},u,v}. \quad (17.26)$$



对类别 c , soft Dice 系数为

$$\text{Dice}_c = \frac{2 \sum_i p_{i,c} y_{i,c} + \varepsilon}{\sum_i p_{i,c} + \sum_i y_{i,c} + \varepsilon}, \quad (17.27)$$

相应损失可取

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{1}{C} \sum_{c=1}^C \text{Dice}_c. \quad (17.28)$$

离散预测的交并比为

$$\text{IoU}_c = \frac{\text{TP}_c}{\text{TP}_c + \text{FP}_c + \text{FN}_c}. \quad (17.29)$$

常用总体指标为 mean IoU。

U-Net 使用：下采样编码器 + 上采样解码器 + 同尺度 skip connections。跳连把高分辨率局部信息直接传给解码器，缓解仅依赖低分辨率 bottleneck 时的边界模糊。

17.5.3 图像恢复

设退化观测为 $\mathbf{y} = \mathcal{A}(\mathbf{x}) + \mathbf{n}$, 其中 $\mathcal{A}$ 可表示模糊、下采样、遮挡或压缩, $\mathbf{n}$ 是噪声。恢复模型 $f_{\theta} : \mathbf{y} \mapsto \hat{\mathbf{x}}$ 可使用:

$$\mathcal{L}_2 = \frac{1}{CHW} \|\hat{\mathbf{x}} - \mathbf{x}\|_2^2, \quad (17.30)$$

$$\mathcal{L}_1 = \frac{1}{CHW} \|\hat{\mathbf{x}} - \mathbf{x}\|_1. \quad (17.31)$$

ℓ_2 损失对应条件均值估计, 在多解问题中可能产生平均化和模糊; ℓ_1 对异常像素更稳健。

若像素最大值为 M , 均方误差为 MSE, 则

$$\text{PSNR} = 10 \log_{10} \frac{M^2}{\text{MSE}}. \quad (17.32)$$

PSNR 越高表示像素误差越小, 但不保证感知质量或语义正确性更高。

17.5.4 目标检测

目标检测输出一个可变长度集合 $\hat{\mathcal{Y}} = \{(\hat{\mathbf{b}}_j, \hat{c}_j, \hat{s}_j)\}_{j=1}^{\hat{n}}$, 其中: $\hat{\mathbf{b}}_j = (\hat{x}_j, \hat{y}_j, \hat{w}_j, \hat{h}_j)$ 是边界框, $\hat{c}_j$ 是类别, $\hat{s}_j$ 是置信分数。

典型训练目标由以下部分组成:

$$\mathcal{L}_{\text{det}} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{box}} \mathcal{L}_{\text{box}} + \lambda_{\text{iou}} \mathcal{L}_{\text{iou}} + \lambda_{\text{obj}} \mathcal{L}_{\text{obj}}. \quad (17.33)$$

其中:

$\mathcal{L}_{\text{cls}}$: 类别交叉熵或 focal loss,

$\mathcal{L}_{\text{box}}$: ℓ_1 或 smooth- ℓ_1 框回归,

$\mathcal{L}_{\text{iou}}$: $1 - \text{IoU}$ 或其变体,

$\mathcal{L}_{\text{obj}}$: 前景/背景目标性损失。

两个框 A, B 的 IoU 为

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}. \quad (17.34)$$

推理时常根据置信度筛选, 并使用 non-maximum suppression 去除高度重叠的重复框。主要评价指标是指定 IoU 阈值下的 average precision, 以及多个阈值平均后的 mAP。



17.5.5 光流估计

给定相邻帧 $\mathbf{I}_t, \mathbf{I}_{t+1} \in \mathbb{R}^{C \times H \times W}$, 光流模型输出 $\hat{\mathbf{F}} \in \mathbb{R}^{H \times W \times 2}$, 其中 $\hat{\mathbf{F}}(u, v) = (\hat{\Delta}u, \hat{\Delta}v)$ 。

有监督 endpoint error 为

$$\mathcal{L}_{\text{EPE}} = \frac{1}{HW} \sum_{u,v} \left\| \hat{\mathbf{F}}(u, v) - \mathbf{F}^*(u, v) \right\|_2. \quad (17.35)$$

无标注情形可使用亮度一致性：

$$\mathcal{L}_{\text{photo}} = \frac{1}{HW} \sum_{\mathbf{p}} \rho \left(I_t(\mathbf{p}) - I_{t+1} \left(\mathbf{p} + \hat{\mathbf{F}}(\mathbf{p}) \right) \right), \quad (17.36)$$

其中非整数位置通过可微双线性插值采样。还可加入空间平滑正则：

$$\mathcal{L}_{\text{smooth}} = \sum_{\mathbf{p}} \left(\left\| \nabla_u \hat{\mathbf{F}}(\mathbf{p}) \right\|_1 + \left\| \nabla_v \hat{\mathbf{F}}(\mathbf{p}) \right\|_1 \right). \quad (17.37)$$

亮度一致性会在以下情况失效：

- 遮挡和新出现区域；
- 光照变化；
- 非朗伯表面；
- 快速运动超出搜索范围；
- 运动模糊和无纹理区域。

17.5.6 三维重构

三维重构可预测：深度图、点云、体素、隐式占据函数或辐射场。若预测单目或多目深度 $\hat{\mathbf{D}} \in \mathbb{R}^{H \times W}$, 最直接的监督损失为

$$\mathcal{L}_{\text{depth}} = \frac{1}{HW} \sum_{\mathbf{p}} \left| \hat{\mathbf{D}}(\mathbf{p}) - D^*(\mathbf{p}) \right|. \quad (17.38)$$

多视图几何中，像素齐次坐标 $\tilde{\mathbf{p}} = (u, v, 1)^\top$ 经深度反投影为

$$\mathbf{X}_{\text{cam}} = D(\mathbf{p}) \mathbf{K}^{-1} \tilde{\mathbf{p}}. \quad (17.39)$$


若相机间外参为 $(\mathbf{R}, \mathbf{t})$, 则目标视图中的投影为

$$\tilde{\mathbf{p}}' \sim \mathbf{K} (\mathbf{R} \mathbf{X}_{\text{cam}} + \mathbf{t}). \quad (17.40)$$

可由重投影后的光度一致性训练深度和位姿。

对于预测点云 $\hat{\mathcal{P}}$ 与真实点云 $\mathcal{Q}$, Chamfer distance 为

$$\begin{aligned} \text{CD}(\hat{\mathcal{P}}, \mathcal{Q}) &= \frac{1}{|\hat{\mathcal{P}}|} \sum_{\mathbf{p} \in \hat{\mathcal{P}}} \min_{\mathbf{q} \in \mathcal{Q}} \|\mathbf{p} - \mathbf{q}\|_2^2 \\ &+ \frac{1}{|\mathcal{Q}|} \sum_{\mathbf{q} \in \mathcal{Q}} \min_{\mathbf{p} \in \hat{\mathcal{P}}} \|\mathbf{q} - \mathbf{p}\|_2^2. \end{aligned} \quad (17.41)$$



根据附件结论所作的推导补充

光流与三维重构的公式是依据本 Prompt 的明确考纲, 结合 [DL-Basic] 中卷积、U-Net 和 image-to-image 任务框架所作的必要数学补充。附件未给出统一的光流或三维重构网络, 因此本章不把任何具体架构声称为附件指定模型。

17.6 视觉任务系统设计的满分模板

答题方法

视觉系统设计题至少应写出以下七项:

1. **输入与输出张量**: 例如 $\mathbf{X} \in \mathbb{R}^{B \times C \times H \times W}$, $\hat{\mathbf{Y}} \in \mathbb{R}^{B \times C' \times H' \times W'}$.
2. **模型主干**: 编码器、特征金字塔、解码器、skip connection 或 attention 的位置。
3. **监督目标**: 明确每一项损失对应什么预测对象。
4. **推理流程**: 分类取 $\arg\max$; 分割逐像素取类别; 检测还需置信度筛选和去重。
5. **评价指标**: 分类 accuracy/F1; 分割 IoU/Dice; 检测 AP; 恢复 PSNR; 光流 EPE; 三维点云 Chamfer distance。
6. **复杂度**: 指出主导项来自卷积、全局 attention、候选框数量或高分辨率特征图。
7. **失败模式**: 包括类别不平衡、分布变化、遮挡、小目标、边界模糊、光照变化、错误几何假设和评价指标与感知质量不一致。



第十八章 注意力、Transformer 与 Vision Transformer

18.1 重要性等级与实考定位

重要性等级：S

- [25F-B-Q1(b), 3 分] 要求写 scaled dot-product self-attention, 定义 Q, K, V , 解释位置编码的必要性并给出一种实现。
- [25F-B-Q1(c), 3 分] 要求设计卷积-attention 混合视觉架构。
- [26S-B-Q1(d), 2 分] 直接要求解释 $1/\sqrt{d_k}$ 的方差归一化作用, 以及删除缩放后 softmax 与梯度的变化。
- [26S-B-Q1(e), 2 分] 要求比较 RNN 与 Transformer 的计算依赖结构和现代硬件并行性。

必须掌握: Q, K, V 维度, row-wise softmax, *mask*, *multi-head*, $O(L^2)$ 复杂度。

18.2 单查询注意力

给定: $\mathbf{q} \in \mathbb{R}^{d_k}$, $\mathbf{k}_j \in \mathbb{R}^{d_k}$, $\mathbf{v}_j \in \mathbb{R}^{d_v}$, $j = 1, \dots, L_k$ 。相似度分数为

$$s_j = \frac{\mathbf{q}^\top \mathbf{k}_j}{\sqrt{d_k}}. \quad (18.1)$$

注意力权重为

$$a_j = \frac{e^{s_j}}{\sum_{r=1}^{L_k} e^{s_r}}, \quad a_j \geq 0, \quad \sum_j a_j = 1. \quad (18.2)$$

输出是 value 的凸组合:


$$\mathbf{z} = \sum_{j=1}^{L_k} a_j \mathbf{v}_j \in \mathbb{R}^{d_v}. \quad (18.3)$$

其含义为: query-key 匹配决定权重, value 提供被聚合内容。不能把 key 与 value 混为同一数学角色。

18.3 矩阵形式与张量维度

设:

$$\mathbf{Q} \in \mathbb{R}^{L_q \times d_k}, \quad \mathbf{K} \in \mathbb{R}^{L_k \times d_k}, \quad \mathbf{V} \in \mathbb{R}^{L_k \times d_v}. \quad (18.4)$$



scaled dot-product attention 定义为

$$\text{Attn}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}_{\text{row}} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} + \mathbf{M} \right) \mathbf{V} \quad (18.5)$$

其中 $\mathbf{M} \in (\mathbb{R} \cup \{-\infty\})^{L_q \times L_k}$ 是 mask。

维度链为

$$\mathbf{Q}\mathbf{K}^\top \in \mathbb{R}^{L_q \times L_k}, \quad (18.6)$$

$$\mathbf{A} := \text{softmax}_{\text{row}} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}} + \mathbf{M} \right) \in \mathbb{R}^{L_q \times L_k}, \quad (18.7)$$

$$\mathbf{Z} = \mathbf{A}\mathbf{V} \in \mathbb{R}^{L_q \times d_v}. \quad (18.8)$$

每一行 $\mathbf{A}_{i,:}$ 都满足 $A_{ij} \geq 0$, $\sum_{j=1}^{L_k} A_{ij} = 1$ 。

给定 $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ 后, 式 (18.5) 本身没有可训练参数; 但实际 Transformer 使用的 $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ 通常由可训练线性投影产生, 因此完整 self-attention 层有参数。

18.4 为什么必须除以 $\sqrt{d_k}$

命题 18.1 (Dot-product 方差). 假设 q_r, k_r , $r = 1, \dots, d_k$ 相互独立, 且 $\mathbb{E}[q_r] = \mathbb{E}[k_r] = 0$, $\text{Var}(q_r) = \text{Var}(k_r) = 1$ 。则

$$\mathbb{E}[\mathbf{q}^\top \mathbf{k}] = 0, \quad (18.9)$$

$$\text{Var}(\mathbf{q}^\top \mathbf{k}) = d_k, \quad (18.10)$$

$$\text{Var} \left(\frac{\mathbf{q}^\top \mathbf{k}}{\sqrt{d_k}} \right) = 1. \quad (18.11)$$

证明. 由于 $\mathbf{q}^\top \mathbf{k} = \sum_{r=1}^{d_k} q_r k_r$, 且 $\mathbb{E}[q_r k_r] = \mathbb{E}[q_r] \mathbb{E}[k_r] = 0$, 均值为零。

独立性给出

$$\begin{aligned} \text{Var} \left(\sum_{r=1}^{d_k} q_r k_r \right) &= \sum_{r=1}^{d_k} \text{Var}(q_r k_r) \\ &= \sum_{r=1}^{d_k} \mathbb{E}[q_r^2] \mathbb{E}[k_r^2] = d_k. \end{aligned} \quad (18.12)$$

最后除以 $\sqrt{d_k}$ 即使方差归一到 1。 □

若不缩放, 则 score 的典型大小为 $O(\sqrt{d_k})$ 。当 d_k 大时, softmax 容易进入饱和状态: $\mathbf{p} = \text{softmax}(\mathbf{s}) \approx (0, \dots, 0, 1, 0, \dots, 0)$ 。softmax Jacobian 为

$$\frac{\partial p_i}{\partial s_j} = p_i(\delta_{ij} - p_j). \quad (18.13)$$

在近 one-hot 状态下: $p_i(1 - p_i) \approx 0$, $p_i p_j \approx 0$, 故大部分梯度接近零。这会导致:

- 注意力权重过早变得极尖锐;
- query/key 投影收到的梯度减弱;
- 训练对初始化和数值误差更敏感。



答题方法

[26S-B-Q1(d), 2 分] 的满分结构:

1. 假设 q_r, k_r 均值为零、方差为一;
2. 写 $\text{Var}(\mathbf{q}^\top \mathbf{k}) = d_k$;
3. 除以 $\sqrt{d_k}$ 后方差为 1;
4. 若不缩放, logit 量级为 $O(\sqrt{d_k})$;
5. softmax 趋于饱和或近 one-hot;
6. 由 $\partial p_i / \partial s_j = p_i(\delta_{ij} - p_j)$ 说明梯度趋小。

18.5 Self-Attention、Cross-Attention 与 Mask

18.5.1 Self-attention

输入 token 矩阵采用“每行一个 token”的约定: $\mathbf{X} \in \mathbb{R}^{L \times d_{\text{model}}}$ 。可训练投影为

$$\mathbf{W}_Q \in \mathbb{R}^{d_{\text{model}} \times d_k}, \quad \mathbf{W}_K \in \mathbb{R}^{d_{\text{model}} \times d_k}, \quad \mathbf{W}_V \in \mathbb{R}^{d_{\text{model}} \times d_v}. \quad (18.14)$$

定义

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_K, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_V. \quad (18.15)$$

三者来自同一序列, 故称 self-attention。

18.5.2 Cross-attention

若 query 来自目标序列 $\mathbf{X}_q$, key/value 来自源序列 $\mathbf{X}_s$, 则

$$\mathbf{Q} = \mathbf{X}_q \mathbf{W}_Q, \quad (18.16)$$

$$\mathbf{K} = \mathbf{X}_s \mathbf{W}_K, \quad (18.17)$$

$$\mathbf{V} = \mathbf{X}_s \mathbf{W}_V. \quad (18.18)$$

输出长度等于 query 数量: $L_{\text{out}} = L_q$ 。key 数量必须等于 value 数量, 但不要求等于 query 数量。


18.5.3 Causal mask 与 padding mask

定义

$$M_{ij} = \begin{cases} 0, & j \leq i, \\ -\infty, & j > i. \end{cases} \quad (18.19)$$

则第 i 个 token 只能关注自身和之前的 token, 形成 causal self-attention。

Padding mask 则把补齐位置对应的 M_{ij} 设为 $-\infty$, 避免其参与归一化。



易错点、反例与失败模式

1. causal mask 作用在 softmax 之前的 logits 上；不能在 softmax 后简单把未来权重置零而不重新归一化。
2. 双向 encoder self-attention 通常不使用 causal mask；自回归 decoder 必须阻止访问未来 token。
3. self-attention 与 cross-attention 的区别在于 Q, K, V 的来源，而不是公式本身。

18.6 Multi-Head Attention

设头数为 H_a 。第 h 个头使用

$$\mathbf{W}_Q^{(h)} \in \mathbb{R}^{d_{\text{model}} \times d_k}, \quad (18.20)$$

$$\mathbf{W}_K^{(h)} \in \mathbb{R}^{d_{\text{model}} \times d_k}, \quad (18.21)$$

$$\mathbf{W}_V^{(h)} \in \mathbb{R}^{d_{\text{model}} \times d_v}. \quad (18.22)$$

定义

$$\text{head}_h = \text{Attn}(\mathbf{X}\mathbf{W}_Q^{(h)}, \mathbf{X}\mathbf{W}_K^{(h)}, \mathbf{X}\mathbf{W}_V^{(h)}) \in \mathbb{R}^{L \times d_v}. \quad (18.23)$$

拼接后投影：

$$\text{MHA}(\mathbf{X}) = \text{Concat}(\text{head}_1, \dots, \text{head}_{H_a}) \mathbf{W}_O, \quad (18.24)$$

其中 $\mathbf{W}_O \in \mathbb{R}^{(H_a d_v) \times d_{\text{model}}}$ 。

标准选择为 $d_k = d_v = \frac{d_{\text{model}}}{H_a}$ 。忽略偏置时，Q/K/V 和输出投影的总参数数量为

$$P_{\text{MHA}} = 3d_{\text{model}}^2 + d_{\text{model}}^2 = 4d_{\text{model}}^2. \quad (18.25)$$

多头的意义不是简单重复相同注意力，而是允许不同投影子空间学习：局部关系、语义关系、位置关系或不同视觉通道。但不同头不保证自动学到可解释且互不重复的功能。

18.7 位置编码与排列等变性

18.7.1 无位置 self-attention 的性质

令 $\mathbf{P} \in \mathbb{R}^{L \times L}$ 为排列矩阵。若输入 token 顺序被排列： $\mathbf{X}' = \mathbf{P}\mathbf{X}$ ，则 $\mathbf{Q}' = \mathbf{P}\mathbf{Q}$ ， $\mathbf{K}' = \mathbf{P}\mathbf{K}$ ， $\mathbf{V}' = \mathbf{P}\mathbf{V}$ 。score 矩阵满足

$$\mathbf{Q}'\mathbf{K}'^\top = \mathbf{P}\mathbf{Q}\mathbf{K}^\top\mathbf{P}^\top. \quad (18.26)$$

逐行 softmax 与同时行列排列相容：

$$\text{softmax}_{\text{row}}(\mathbf{P}\mathbf{S}\mathbf{P}^\top) = \mathbf{P} \text{softmax}_{\text{row}}(\mathbf{S})\mathbf{P}^\top. \quad (18.27)$$

因此

$$\text{Attn}(\mathbf{P}\mathbf{X}) = \mathbf{P} \text{Attn}(\mathbf{X}). \quad (18.28)$$

这称为排列等变性。

若两个输入包含相同 token 多重集合而仅顺序不同，没有位置编码的 self-attention 只能使输出作相应排列，无法从结构中获得绝对或相对顺序。



18.7.2 绝对位置编码

输入可写为

$$\mathbf{X}^{(0)} = \mathbf{E}_{\text{token}} + \mathbf{E}_{\text{pos}}. \quad (18.29)$$

其中 $\mathbf{E}_{\text{token}}, \mathbf{E}_{\text{pos}} \in \mathbb{R}^{L \times d_{\text{model}}}$ 。

一种正弦位置编码为

$$\text{PE}(p, 2i) = \sin\left(\frac{p}{10000^{2i/d_{\text{model}}}}\right), \quad (18.30)$$

$$\text{PE}(p, 2i+1) = \cos\left(\frac{p}{10000^{2i/d_{\text{model}}}}\right). \quad (18.31)$$

也可直接学习 $\mathbf{E}_{\text{pos}}$ 参数。

相对位置方法不直接编码绝对 p ，而在 attention score 或 value 中加入与 $i-j$ 有关的项。使用何种位置机制必须与训练最大长度和外推需求匹配。

易错点、反例与失败模式

1. 无位置编码的 self-attention 是 permutation equivariant，不是简单的“输出完全不变”。
2. 加入 class token 但不给 patch 位置，并不能恢复二维空间顺序。
3. learned absolute embedding 在超过训练长度时通常需要插值或扩展；正弦位置编码也不自动保证模型在长于训练范围时可靠外推。

18.8 Transformer Block

全文采用 pre-layer-normalization 约定：

$$\mathbf{U} = \mathbf{X} + \text{Dropout}[\text{MHA}(\text{LN}(\mathbf{X}))], \quad (18.32)$$

$$\mathbf{Y} = \mathbf{U} + \text{Dropout}[\text{FFN}(\text{LN}(\mathbf{U}))]. \quad (18.33)$$

逐 token 的 feed-forward network 为

$$\text{FFN}(\mathbf{x}) = \mathbf{W}_2 \varphi(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2, \quad (18.34)$$

其中

$$\mathbf{W}_1 \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{model}}},$$

$$\mathbf{W}_2 \in \mathbb{R}^{d_{\text{model}} \times d_{\text{ff}}}.$$

FFN 参数量主项为 $2d_{\text{model}}d_{\text{ff}}$ 。

另一常见约定是 post-LN: $\text{LN}(\mathbf{X} + \text{MHA}(\mathbf{X}))$ 。两种约定不能在单一推导中静默混用。

Layer normalization 对单个 token 的特征维归一化，训练和推理使用当前 token 的统计量，不像 BN 那样需要 running mean 和 running variance。

18.9 计算复杂度与 RNN 比较

设序列长度为 L ，隐藏维数为 $d = d_{\text{model}}$ ，且 d_k, d_v 与 d 同阶。



Self-attention 的主要代价为:

$$Q, K, V \text{ 投影} : O(Ld^2), \quad (18.35)$$

$$QK^\top : O(L^2d), \quad (18.36)$$

$$AV : O(L^2d). \quad (18.37)$$

所以

$$T_{\text{attention}} = O(Ld^2 + L^2d). \quad (18.38)$$

attention matrix 的主要存储为

$$M_{\text{attention}} = O(L^2). \quad (18.39)$$

标准 RNN 每一步更新 $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t)$ 通常需要 $O(d^2)$ 计算, 整个序列为 $O(Ld^2)$ 。但它存在严格依赖链 $\mathbf{h}_1 \rightarrow \mathbf{h}_2 \rightarrow \cdots \rightarrow \mathbf{h}_L$, 不能在时间维完全并行。

Transformer 一层中全部 token 的 Q, K, V 、score 和 FFN 可用大规模矩阵乘法并行计算。因此其优势主要来自: 较短的顺序依赖深度 + 更高的矩阵运算吞吐。这并不意味着 Transformer 在所有 L, d 下具有更小的渐近运算量: 当 L 很大时, $O(L^2d)$ 可能成为主要瓶颈。

长距离信息传播路径:

RNN : $O(L)$ 个顺序状态转移,

全局 self-attention : 一层即可建立任意 token 对的直接连接。

答题方法

[26S-B-Q1(e), 2 分] 的完整答案:

1. RNN 有递推关系 $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t)$, 时间步必须顺序执行;
2. Transformer 一层可对全部 token 同时计算 $Q = XW_Q$, $K = XW_K$, $V = XW_V$;
3. attention 和 FFN 主要是 GPU/TPU 友好的稠密矩阵运算;
4. 任意 token 对在单层内可直接交互;
5. 同时说明标准 attention 的时间和空间为 $O(L^2)$, 因而其并行优势不等于长序列下没有代价;
6. 自回归生成在 token 级推理时仍需逐 token 生成, 不能把训练并行性误写为完全并行生成。

18.10 Vision Transformer

18.10.1 Patch Tokenization

设图像为 $\mathbf{X} \in \mathbb{R}^{B \times C \times H \times W}$, patch 高宽为 P_h, P_w , 并假设 $P_h \mid H$, $P_w \mid W$ 。patch 数量为

$$N = \frac{H}{P_h} \frac{W}{P_w}. \quad (18.40)$$

每个 patch 展平后为 $\mathbf{x}_i^{\text{patch}} \in \mathbb{R}^{CP_h P_w}$ 。用线性映射得到 token:

$$\mathbf{e}_i = \mathbf{x}_i^{\text{patch}} \mathbf{W}_E + \mathbf{b}_E, \quad \mathbf{W}_E \in \mathbb{R}^{CP_h P_w \times d}. \quad (18.41)$$



Patch embedding 参数量为

$$P_{\text{patch}} = d(CP_hP_w + 1). \quad (18.42)$$

其等价实现是一个卷积层: $\text{kernel} = P_h \times P_w$, $\text{stride} = P_h \times P_w$, $C_{\text{out}} = d$ 。

加入 class token 和位置嵌入:

$$\mathbf{X}^{(0)} = [\mathbf{e}_{\text{cls}}; \mathbf{e}_1; \dots; \mathbf{e}_N] + \mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times d}. \quad (18.43)$$

经过若干 Transformer blocks 后, 使用 class token 表示做分类:

$$\hat{\mathbf{y}} = \text{softmax} \left(\mathbf{W}_{\text{head}} \mathbf{h}_{\text{cls}}^{(L)} + \mathbf{b}_{\text{head}} \right). \quad (18.44)$$

18.10.2 卷积与 Self-Attention 的归纳偏置

卷积的核心优势:

- 局部连接;
- 参数共享;
- 平移等变性;
- 对图像局部统计具有较强先验;
- 在数据量有限时通常具有较高样本效率。

Self-attention 的核心优势:

- 任意位置之间的内容自适应交互;
- 全局 Receptive Field;
- 不同输入可产生不同的连接权重;
- 易于与多模态 token 统一。

卷积连接模式由架构固定, attention 连接强度由当前输入动态决定。反过来, attention 的弱局部先验通常要求更多数据、正则化或视觉结构设计。

18.10.3 最小卷积-注意力混合模型

一个满足 [25F-B-Q1(c), 3 分] 要求的最小架构可写为:

步骤一: 卷积 stem。


$$\mathbf{F} = \text{ConvStem}(\mathbf{X}) \in \mathbb{R}^{B \times d \times H' \times W'}. \quad (18.45)$$

卷积 stem 使用小核卷积提取局部边缘和纹理, 并可通过 stride 下采样。

步骤二: Tokenization。 令 $N = H'W'$, 将空间维展平:

$$\mathbf{T} = \text{Flatten}_{HW}(\mathbf{F}) \in \mathbb{R}^{B \times N \times d}. \quad (18.46)$$

加入位置嵌入和可选 class token。



步骤三：全局 self-attention。

$$\mathbf{T}' = \text{TransformerEncoder}(\mathbf{T}). \quad (18.47)$$

该阶段建模跨越整个图像的长距离关系。

步骤四：输出。 分类任务可对 token 做 class-token 读取或平均池化；分割、恢复任务则把 token reshape 回空间特征图，并使用卷积解码器。

另一种混合方式是在每个 Transformer block 的 FFN 中加入 depthwise convolution，以持续注入局部空间偏置。答案只需选定一种明确设计，不应同时罗列多个模型名而不说明数据流。

答题方法

[25F-B-Q1, 9 分] 的完整得分结构：

1. (a) 参数量： $P_{\text{conv}} = C_{\text{out}}(C_{\text{in}}k^2 + 1)$ ；写出全连接层展平后的参数量并说明局部连接与共享。
2. (b) Self-attention： $Q = XW_Q$, $K = XW_K$, $V = XW_V$, $Z = \text{softmax}(QK^\top/\sqrt{d_k})V$. 写明维度、row-wise softmax 和位置编码。
3. (c) 混合视觉模型：图像先经 patch embedding 或卷积 stem；展平为 token；加位置编码；在 token 上做 self-attention；明确卷积位于 stem、block 内或解码器；最后说明任务输出头。

18.11 窗口注意力与长序列补充

若图像有 $N = HW$ 个 token，标准 attention 代价为 $O(N^2d)$ 。将 token 分成大小为 $M \times M$ 的窗口，每个窗口含 $m = M^2$ 个 token，则窗口 attention 代价为

$$O\left(\frac{N}{m} \cdot m^2d\right) = O(NM^2d). \quad (18.48)$$

当 M 固定时，关于 N 近似线性。

仅在固定不重叠窗口内计算 attention 会阻止跨窗口交互。Shifted-window 机制在相邻层移动窗口边界，使原本位于不同窗口的 token 能够通过多层传播交换信息。

易错点、反例与失败模式

稀疏或窗口 attention 降低复杂度的代价是：单层连接图不再完全。必须说明长距离信息如何传播：窗口移动、多层堆叠、global token 或层级下采样。只写“使用 sparse attention，复杂度变低”不是完整系统答案。



第十九章 自编码器、自监督学习与对比表示学习

19.1 表示学习的核心问题

重要性等级：A

- 表示学习、自编码器、自监督学习和对比学习属于明确考纲。
- [25S-D-Q2, 3 分] 从 NLP 方向考查 representation learning 的核心思想和实现算法；在本讲义中，其数学基础主归属于本章，NLP 部分再讨论词和句子表示。
- [26S-D-Q1(a), 3 分] 和 [26S-D-Q1(b), 3 分] 直接考查 InfoNCE 梯度、高维负样本和 false negative。该题属于 D 方向真题，不得计入 B 方向实考频率，但其数学工具是跨方向通用表示学习工具。

表示学习希望学习映射

$$f_{\theta} : \mathcal{X} \rightarrow \mathbb{R}^d, \quad z = f_{\theta}(x), \quad (19.1)$$

使 z ：

- 保留与下游任务相关的信息；
- 对无关变化具有不变性或稳定性；
- 使简单的下游预测器即可完成任务；
- 能够迁移到未直接用于预训练的任务。

“好表示”不是无条件定义。它依赖：任务分布、允许的下游模型、数据增强和评价协议。仅使相似样本欧氏距离较小，并不自动保证事实正确、因果相关或公平。


19.2 确定性自编码器

19.2.1 模型与目标

设输入 $x \in \mathbb{R}^D$ 。编码器和解码器分别为

$$f_{\theta} : \mathbb{R}^D \rightarrow \mathbb{R}^k, \quad z = f_{\theta}(x), \quad (19.2)$$

$$g_{\phi} : \mathbb{R}^k \rightarrow \mathbb{R}^D, \quad \hat{x} = g_{\phi}(z). \quad (19.3)$$



经验重构目标为

$$\mathcal{L}_{\text{AE}}(\theta, \phi) = \frac{1}{N} \sum_{i=1}^N \ell_{\text{rec}}(\mathbf{x}_i, g_{\phi}(f_{\theta}(\mathbf{x}_i))). \quad (19.4)$$

对连续输入常用 $\ell_{\text{rec}}(\mathbf{x}, \hat{\mathbf{x}}) = \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2$ 。若像素被建模为 Bernoulli 变量，可使用逐坐标交叉熵；损失必须与数据的概率或数值假设一致。

19.2.2 为什么必须限制模型

若 $k \geq D$ 且 encoder/decoder 足够强，可取 $f(\mathbf{x}) = \mathbf{x}$, $g(\mathbf{z}) = \mathbf{z}$ ，得到零重构误差，却未学到有用压缩或不变性。

因此必须加入至少一种约束：

- undercomplete bottleneck: $k < D$;
- 稀疏 latent code;
- weight decay;
- denoising corruption;
- contractive Jacobian penalty;
- 有限架构容量。

在线性 encoder/decoder、数据中心化、平方重构误差且 $k < D$ 的条件下，最优线性自编码器的子空间与 PCA 的前 k 个主成分张成空间一致。这不意味着非线性自编码器一般等于 PCA。

易错点、反例与失败模式

普通 autoencoder 与 VAE 必须区分：

AE: $z = f_{\theta}(x)$ 通常是确定性编码，优化重构误差；

VAE: $z \sim q_{\phi}(z | x)$ 是概率潜变量模型，优化 ELBO。

VAE 将在下一部分完整推导。

19.3 去噪自编码器


给定腐化分布 $\tilde{\mathbf{x}} \sim q_{\text{corrupt}}(\tilde{\mathbf{x}} | \mathbf{x})$ ，去噪自编码器目标为

$$\mathcal{L}_{\text{DAE}} = \mathbb{E}_{\mathbf{x} \sim P_{\text{data}}, \tilde{\mathbf{x}} \sim q_{\text{corrupt}}(\cdot | \mathbf{x})} [\ell_{\text{rec}}(\mathbf{x}, g_{\phi}(f_{\theta}(\tilde{\mathbf{x}})))]. \quad (19.5)$$

输入是被破坏的 $\tilde{\mathbf{x}}$ ，目标仍是干净数据 $\mathbf{x}$ 。

常见 corruption 包括：加性高斯噪声、随机遮挡、随机置零、局部 mask。其作用是阻止网络只复制输入，并鼓励 encoder 学习：对小扰动稳定、能够恢复数据流形附近结构的表示。

若 corruption 太弱，模型仍可能近似恒等映射；若 corruption 太强，使 $I(\mathbf{x}; \tilde{\mathbf{x}})$ 过小，则重构问题本身不可辨识，网络只能输出条件平均。



19.4 自监督学习

自监督学习从原始数据自动构造监督目标：原始样本 $\rightarrow$ 预任务输入和伪标签。常见形式包括：

- mask 后预测被遮挡部分；
- 预测未来或上下文；
- 判断两个视图是否来自同一实例；
- 重建被扰动输入；
- 图像 patch、token 或时间片之间的对应关系学习。

自监督与无监督的关系是：自监督不需要人工标签，但训练目标通常仍是监督形式的损失。其成功依赖预任务是否迫使模型保留下游任务所需信息。

易错点、反例与失败模式

以下命题均不成立：

自监督预训练 $\implies$ 任意下游任务都改善；

重构误差低 $\implies$ 语义表示一定好；

数据增强越强 $\implies$ 表示一定越稳健。

若增强删除了任务相关信息，模型会被训练为对该信息不敏感。

19.5 对比学习与 InfoNCE

19.5.1 正负样本设定

对 anchor x ，采样正视图 $x^+ \sim \mathcal{A}^+(x)$ 和负样本 $x_1^-, \dots, x_n^-$ 。编码器输出单位向量：

$$\mathbf{z} = f_{\theta}(x), \quad \mathbf{z}^+ = f_{\theta}(x^+), \quad \mathbf{z}_i^- = f_{\theta}(x_i^-), \quad (19.6)$$

$$\|\mathbf{z}\|_2 = \|\mathbf{z}^+\|_2 = \|\mathbf{z}_i^-\|_2 = 1. \quad (19.7)$$

因此点积等于 cosine similarity: $s(\mathbf{z}, \mathbf{u}) = \mathbf{z}^\top \mathbf{u} \in [-1, 1]$ 。

InfoNCE loss 为


$$\mathcal{L}_{\text{NCE}} = -\log \frac{\exp(\mathbf{z}^\top \mathbf{z}^+ / \tau)}{\exp(\mathbf{z}^\top \mathbf{z}^+ / \tau) + \sum_{i=1}^n \exp(\mathbf{z}^\top \mathbf{z}_i^- / \tau)} \quad (19.8)$$

其中 $\tau > 0$ 是温度参数。

定义候选: $\mathbf{u}_0 = \mathbf{z}^+$, $\mathbf{u}_i = \mathbf{z}_i^-$, 以及 softmax 权重

$$p_j = \frac{\exp(\mathbf{z}^\top \mathbf{u}_j / \tau)}{\sum_{r=0}^n \exp(\mathbf{z}^\top \mathbf{u}_r / \tau)}. \quad (19.9)$$

则 $\mathcal{L}_{\text{NCE}} = -\log p_0$ 。



19.5.2 InfoNCE 对 Anchor 的梯度

命题 19.1 (InfoNCE 梯度). 对未考虑单位范数约束的 $\mathbf{z}$,

$$\nabla_{\mathbf{z}} \mathcal{L}_{\text{NCE}} = \frac{1}{\tau} \left(\sum_{j=0}^n p_j \mathbf{u}_j - \mathbf{z}^+ \right) \quad (19.10)$$

即

$$\nabla_{\mathbf{z}} \mathcal{L}_{\text{NCE}} = \frac{1}{\tau} \left[(p_0 - 1) \mathbf{z}^+ + \sum_{i=1}^n p_i \mathbf{z}_i^- \right]. \quad (19.11)$$

证明. 将损失写成

$$\mathcal{L}_{\text{NCE}} = -\frac{\mathbf{z}^\top \mathbf{z}^+}{\tau} + \log \left[\sum_{j=0}^n \exp \left(\frac{\mathbf{z}^\top \mathbf{u}_j}{\tau} \right) \right]. \quad (19.12)$$

第一项梯度为 $-\frac{1}{\tau} \mathbf{z}^+$. 第二项梯度为

$$\frac{\sum_{j=0}^n \exp(\mathbf{z}^\top \mathbf{u}_j / \tau) \mathbf{u}_j / \tau}{\sum_{r=0}^n \exp(\mathbf{z}^\top \mathbf{u}_r / \tau)} = \frac{1}{\tau} \sum_{j=0}^n p_j \mathbf{u}_j. \quad (19.13)$$

两者相加即得。 □

梯度下降方向为

$$-\nabla_{\mathbf{z}} \mathcal{L}_{\text{NCE}} = \frac{1}{\tau} \left[(1 - p_0) \mathbf{z}^+ - \sum_{i=1}^n p_i \mathbf{z}_i^- \right]. \quad (19.14)$$

因此:

- 向正样本方向拉近;
- 按 p_i 大小将 anchor 从高相似负样本方向推开;
- hard negative 获得更大权重。

若网络先输出 $\mathbf{h} \neq \mathbf{0}$, $\mathbf{z} = \frac{\mathbf{h}}{\|\mathbf{h}\|_2}$, 则

$$\frac{\partial \mathbf{z}}{\partial \mathbf{h}} = \frac{1}{\|\mathbf{h}\|_2} (\mathbf{I} - \mathbf{z} \mathbf{z}^\top). \quad (19.15)$$

所以

$$\nabla_{\mathbf{h}} \mathcal{L} = \frac{1}{\|\mathbf{h}\|_2} (\mathbf{I} - \mathbf{z} \mathbf{z}^\top) \nabla_{\mathbf{z}} \mathcal{L}. \quad (19.16)$$

矩阵 $\mathbf{I} - \mathbf{z} \mathbf{z}^\top$ 将梯度投影到单位球在 $\mathbf{z}$ 处的切空间。

19.5.3 温度参数

从式 (19.10) 可见, τ 有两重作用:

1. 出现在 softmax logits 中, 控制概率分布尖锐程度;
2. 通过 $1/\tau$ 直接缩放梯度。

当 τ 较小时: p_j 更集中于最相似候选, 模型更强调 hard negatives; 但梯度可能更尖锐、更不稳定。
当 τ 较大时, 权重更均匀, 区分信号可能过弱。



19.6 高维负样本几何

固定单位向量 $\mathbf{z} \in \mathbb{S}^{d-1}$, 若 $\mathbf{u} \sim \text{Unif}(\mathbb{S}^{d-1})$, 由旋转对称性:

$$\mathbb{E}[\mathbf{z}^\top \mathbf{u}] = 0, \quad (19.17)$$

$$\text{Var}(\mathbf{z}^\top \mathbf{u}) = \frac{1}{d}. \quad (19.18)$$

因此典型随机负样本相似度量级为

$$\mathbf{z}^\top \mathbf{u} = O_{\mathbb{P}}\left(\frac{1}{\sqrt{d}}\right). \quad (19.19)$$

在高维高斯近似下, $\mathbf{z}^\top \mathbf{u}_i \approx \mathcal{N}(0, 1/d)$ 。若有 n 个近似独立负样本, 且 $\log n \ll d$, 最大相似度的典型量级为

$$\max_{1 \leq i \leq n} \mathbf{z}^\top \mathbf{u}_i \approx \sqrt{\frac{2 \log n}{d}}. \quad (19.20)$$

该公式是高维启发式, 不是对所有 embedding 分布的精确无条件定理。真实负样本可能呈簇结构、各向异性或高度相关。

19.6.1 False Negative

False negative 是被采样为负例、但实际上与 anchor 语义等价或属于同一潜在类别的样本。若某 false negative 满足 $\mathbf{z}^\top \mathbf{z}_i^- \gg O(1/\sqrt{d})$, 则其指数权重 $\exp\left(\frac{\mathbf{z}^\top \mathbf{z}_i^-}{\tau}\right)$ 可能显著大于普通随机负样本。由式 (19.14), 模型会强烈把两个语义相关表示推开。

这会造成:

- 类内结构被破坏;
- 语义相似样本被错误分离;
- 小温度和大 batch 下影响更严重;
- 下游分类或检索性能下降。

可行缓解方式包括:

- 利用标签或聚类信息屏蔽同类负样本;
- 使用多个正样本;
- 对疑似 false negative 降权;
- 改进 augmentation 和 batch 构造;
- 使用不依赖显式负样本、但带有其他防塌缩机制的方法。

答题方法

[26S-D-Q1, 6 分] 的满分结构:

1. 定义 $p_0, \dots, p_n$ 为正负候选的 softmax 概率;
2. 推导 $\nabla_{\mathbf{z}} L = \frac{1}{\tau} \left(\sum_j p_j \mathbf{u}_j - \mathbf{z}^+ \right)$;
3. 解释下降方向拉近正样本、推远负样本;

4. 若要求单位球几何, 写 $I - zz^\top$ 的切空间投影;
5. 对各向同性负样本写 $\mathbb{E}\langle z, z^- \rangle = 0$, $\text{Var} = 1/d$;
6. 写最大相似度启发式 $\sqrt{2\log n/d}$;
7. 说明 false negative 的指数权重可能占主导, 从而错误地推开同语义样本。

19.7 对比学习的计算复杂度与训练流程

若 batch 中有 B 个表示 $\mathbf{Z} \in \mathbb{R}^{B \times d}$, 使用 batch 内全部样本作为负例, 需要计算

$$\mathbf{S} = \frac{\mathbf{Z}\mathbf{Z}^\top}{\tau} \in \mathbb{R}^{B \times B}. \quad (19.21)$$

主要复杂度为

$$T_{\text{contrastive}} = O(B^2 d), \quad (19.22)$$

$$M_{\text{similarity}} = O(B^2). \quad (19.23)$$

大 batch 提供更多负样本, 但增加: 显存、通信、false negative 概率和温度调参难度。

典型训练流程:

1. 从同一原始样本生成两个或多个增强视图;
2. 经过共享 encoder;
3. 经过 projection head;
4. 用 InfoNCE 优化;
5. 下游任务常丢弃 projection head, 使用 encoder 表示进行 linear probing 或 fine-tuning。

易错点、反例与失败模式

1. 正样本不是“标签相同”这一唯一可能定义; 它由预训练任务设计决定。
2. 负样本数量增加不保证单调改善; false negative 和采样偏差可能变严重。
3. 余弦相似度高不表示事实正确、因果相关或实体相同。
4. InfoNCE 的梯度应同时经过 anchor、positive 和 negatives 所在的共享编码器; 只写对 z 的梯度是局部推导。



第二十章 迁移学习、微调与元学习

20.1 迁移学习的形式化

重要性等级：B

- 迁移学习、微调和元学习属于考纲节点。

DL-Basic 将 Meta/Transfer Learning 列为深度学习方法，但三套 B 方向真题没有单独设置高分证明题。

- 本节重点是掌握问题设定、训练流程、数据划分和失败模式，而不是背诵具体预训练模型名称。

设源任务数据分布为 P_{src} ，目标任务分布为 P_{tgt} 。预训练 encoder：

$$\theta_0 \in \arg \min_{\theta} \mathcal{L}_{\text{pre}}(\theta; P_{\text{src}}). \quad (20.1)$$

目标任务模型写为 $h_{\theta, \mathbf{W}}(\mathbf{x}) = \mathbf{W} f_{\theta}(\mathbf{x})$ 。

20.1.1 Linear Probing

冻结 encoder： $\theta = \theta_0$ ，只训练线性头：

$$\widehat{\mathbf{W}} \in \arg \min_{\mathbf{W}} \frac{1}{N_{\text{tgt}}} \sum_{i=1}^{N_{\text{tgt}}} \ell(\mathbf{W} f_{\theta_0}(\mathbf{x}_i), y_i). \quad (20.2)$$

Linear probing 测量表示对线性下游模型的可用性，其计算和过拟合风险较低，但不能调整 encoder。

20.1.2 Full Fine-Tuning

联合更新全部参数：


$$(\widehat{\theta}, \widehat{\mathbf{W}}) \in \arg \min_{\theta, \mathbf{W}} \frac{1}{N_{\text{tgt}}} \sum_i \ell(\mathbf{W} f_{\theta}(\mathbf{x}_i), y_i). \quad (20.3)$$

也可加入靠近预训练参数的约束：

$$\mathcal{L}_{\text{FT}} = \widehat{R}_{\text{tgt}}(\theta, \mathbf{W}) + \frac{\lambda}{2} \|\theta - \theta_0\|_2^2. \quad (20.4)$$

常用训练策略为：

- 新分类头使用较大学习率；
- 预训练 encoder 使用较小学习率；



- 先冻结后逐层解冻；
- 以独立验证集选择解冻层数和训练轮数。

20.1.3 迁移学习的失败模式

1. **Negative transfer**: 源任务与目标任务归纳偏置不匹配, 预训练参数反而限制目标学习。
2. **Domain shift**: $P_{\text{src}}(X, Y) \neq P_{\text{tgt}}(X, Y)$.
3. **Catastrophic forgetting**: 目标数据上的大步更新破坏预训练能力。
4. **Small-data overfitting**: 目标数据很少时, 全参数微调方差很大。
5. **Pretraining contamination**: 目标测试样本或近重复样本已出现在预训练数据中, 导致迁移评估失真。
6. **BN statistics mismatch**: 微调时 BN 的 running statistics 是否更新必须明确。

20.2 元学习的基本设定

元学习不是在一个固定数据集上训练一个任务, 而是从任务分布 $\mathcal{T} \sim p(\mathcal{T})$ 中学习“快速适应规则”。

每个任务 $\mathcal{T}$ 包含:

$$S_{\mathcal{T}} : \text{support set}, \quad (20.5)$$

$$Q_{\mathcal{T}} : \text{query set}. \quad (20.6)$$

Support set 用于任务内适应, query set 用于评价和更新元参数。两者不得使用同一批样本, 否则会低估适应后的泛化误差。

20.2.1 MAML 形式

对任务 $\mathcal{T}$, 一步内循环更新为

$$\theta'_{\mathcal{T}} = \theta - \alpha \nabla_{\theta} \mathcal{L}_{S_{\mathcal{T}}}(\theta). \quad (20.7)$$

外循环目标为

$$\min_{\theta} \mathbb{E}_{\mathcal{T} \sim p(\mathcal{T})} [\mathcal{L}_{Q_{\mathcal{T}}}(\theta'_{\mathcal{T}})] \quad (20.8)$$

即

$$\min_{\theta} \mathbb{E}_{\mathcal{T}} [\mathcal{L}_{Q_{\mathcal{T}}}(\theta - \alpha \nabla_{\theta} \mathcal{L}_{S_{\mathcal{T}}}(\theta))]. \quad (20.9)$$

单任务的精确元梯度为

$$\nabla_{\theta} \mathcal{L}_{Q_{\mathcal{T}}}(\theta'_{\mathcal{T}}) = [\mathbf{I} - \alpha \nabla_{\theta}^2 \mathcal{L}_{S_{\mathcal{T}}}(\theta)]^{\top} \nabla_{\theta'} \mathcal{L}_{Q_{\mathcal{T}}}(\theta'_{\mathcal{T}}). \quad (20.10)$$

First-order MAML 忽略 Hessian 项, 将方括号近似为 $\mathbf{I}$ 。该近似降低计算和存储, 但改变了精确梯度。



20.2.2 度量型元学习

对于 K -way 分类，设 support set 中类别 c 的样本集合为 S_c 。原型向量为

$$\boldsymbol{\mu}_c = \frac{1}{|S_c|} \sum_{(\mathbf{x}_i, y_i) \in S_c} f_{\boldsymbol{\theta}}(\mathbf{x}_i). \quad (20.11)$$

对 query $\mathbf{x}$,

$$p_{\boldsymbol{\theta}}(y = c | \mathbf{x}) = \frac{\exp(-\|f_{\boldsymbol{\theta}}(\mathbf{x}) - \boldsymbol{\mu}_c\|_2^2/\tau)}{\sum_{r=1}^K \exp(-\|f_{\boldsymbol{\theta}}(\mathbf{x}) - \boldsymbol{\mu}_r\|_2^2/\tau)}. \quad (20.12)$$

元训练通过 query set 交叉熵优化 encoder。

根据附件结论所作的推导补充

MAML 和原型网络的公式是依据考纲中的“元学习基本设定”及 [DL-Basic] 对 Meta/Transfer Learning 的范式分类所作的形式化补充。附件没有指定必须使用某一种元学习算法，故考试中若题目未指定，先定义 task/support/query，再选择一种一致的算法即可。

20.3 迁移学习与元学习的区别

表 20.1: 迁移学习与元学习比较

比较项	迁移学习	元学习
训练对象	先在大规模源数据上学习表示或参数。	在多个任务上学习初始化、优化器或任务表示。
目标	提升一个或若干目标任务的性能。	使新任务只需少量 support 样本即可快速适应。
数据组织	源数据集与目标数据集。	任务分布，以及每个任务的 support/query 划分。
常见更新	冻结、部分解冻或全参数 fine-tuning。	内循环任务适应，外循环更新元参数。
主要风险	negative transfer、domain shift、catastrophic forgetting。	meta-overfitting、任务分布不匹配、内外循环计算昂贵。

20.4 本部分核心公式与复杂度速查

表 20.2: CNN、Transformer 与表示学习速查

模型/操作	核心公式	主复杂度	主要失败模式
卷积层	$Y_{o,u,v} = b_o + \sum_{c,a,b} K_{o,c,a,b} X_{c,us+ad-p,vs+bd-p}$	$O(BH'W'C_{\text{out}}C_{\text{in}}k^2)$	边界效应、stride 混叠、Receptive Field 不足。

模型/操作	核心公式	主复杂度	主要失败模式
卷积参数量	$C_{\text{out}}(C_{\text{in}}k_hk_w + 1)$	与 H, W 无关。	误把每个位置计独立偏置或卷积核。
Self-attention	$\text{softmax}(QK^\top/\sqrt{d_k} + M)V$	$O(Ld^2 + L^2d)$	长序列二次内存；无位置编码不能建模顺序。
Multi-head attention	$\text{Concat}(\text{head}_h)W_O$	标准参数约 $4d^2$ 。	头冗余； d_k 、拼接维度计算错误。
Vision Transformer	patch embedding + position + Transformer blocks。	$O(Nd^2 + N^2d)$	patch 太小导致 N^2 过大；局部归纳偏置较弱。
Autoencoder	$x \rightarrow z = f_\theta(x) \rightarrow \hat{x} = g_\phi(z)$	取决于 encoder/decoder。	无 bottleneck 时学习恒等映射。
Denoising AE	$\tilde{x} \sim q(\cdot x), \min \ell(x, g(f(\tilde{x})))$	需在线生成腐化视图。	噪声过弱无约束；过强则信息丢失。
InfoNCE	$-\log \frac{e^{z^\top z^+/\tau}}{e^{z^\top z^+/\tau} + \sum_i e^{z^\top z_i^-/\tau}}$	batch 内负例： $O(B^2d)$	false negative、温度错误、augmentation 破坏语义。
Full fine-tuning	$\min_{\theta, W} \hat{R}_{\text{tgt}}(\theta, W)$	需保存全部参数梯度。	小数据过拟合、遗忘、domain shift。
MAML	$\min_\theta \mathbb{E}_{\mathcal{T}} L_Q(\theta - \alpha \nabla L_S(\theta))$	内循环加外循环；精确梯度含 Hessian。	任务分布错配、计算昂贵、meta-overfitting。

20.5 真题与资料映射

表 20.3: 第 7 部分真题映射

题目	主要标签	满分所需内容
[25F-B-Q1(a), 3 分]	卷积参数量	卷积参数公式；全连接展平参数公式；局部连接和参数共享；不能把计算量与参数量混淆。
[25F-B-Q1(b), 3 分]	Self-attention、位置编码	Q, K, V 定义及维度；scaled dot-product；row-wise softmax；无位置时的排列等变性；一种位置编码。
[25F-B-Q1(c), 3 分]	CNN-ViT 混合设计	卷积和 attention 各一项核心优势；patch 或卷积 tokenization；attention 位置；卷积位置；完整输出头。
[26S-B-Q1(d), 2 分]	Attention scaling	未缩放 dot product 方差为 d_k ；缩放后为 1；softmax 饱和；Jacobian 梯度趋小。

题目	主要标签	满分所需内容
[26S-B-Q1(e), 2 分]	RNN 与 Transformer	顺序递推依赖; Transformer 的 token 并行矩阵计算; 长距离路径; 同时说明 $O(L^2)$ 代价。
[25S-D-Q2, 3 分]	Representation learning	说明从数据自动学习可迁移特征; 举 embedding、autoencoder、自监督或预训练模型; 该题属于 D 方向。
[26S-D-Q1(a), 3 分]	InfoNCE 梯度	推导 $\nabla_z L = \tau^{-1}(\sum_j p_j u_j - z^+)$; 解释 pull/push 和单位球切空间。
[26S-D-Q1(b), 3 分]	高维负例、false negative	均值 0、方差 $1/d$; 最大值约 $\sqrt{2 \log n/d}$; false negative 的指数权重和错误排斥作用。
[DL-Basic-CNN/Transformer] 课程讲义		卷积张量、参数共享、Receptive Field、U-Net、RNN、attention、位置编码、ViT 和 shifted windows。
[UML-25.3.1]	Autoencoder	encoder-decoder 重构; 无约束时恒等映射; PCA 和 k-means 作为受限特例的联系。

20.6 本部分高频易错点

易错点、反例与失败模式

1. **参数量与计算量混淆**。卷积参数量不含 $H_{\text{out}}W_{\text{out}}$, 计算量包含该因子。
2. **卷积不变性表述错误**。卷积首先提供平移等变性; pooling 和全局聚合才产生近似不变性。
3. **Padding 约定混淆**。必须说明 p 是单侧填充还是总填充。
4. **Receptive Field 只加核大小**。stride 和 dilation 会改变原图坐标中的跳距, 应使用式 (17.19)。
5. **Attention 矩阵方向错误**。本文 token 为行: $QK^T \in \mathbb{R}^{L_q \times L_k}$, $AV \in \mathbb{R}^{L_q \times d_v}$ 。
6. **Softmax 方向不明**。Attention 对每个 query 在 key 维度做 row-wise softmax。
7. **Attention 自身无参数的误解**。加权操作给定 Q, K, V 后无参数; W_Q, W_K, W_V, W_O 是可训练参数。
8. **缺少位置编码时称为 permutation invariant**。单层 self-attention 对 token 排列是 equivariant; 只有再做对称池化后, 整体分类表示才可能 invariant。
9. **Transformer 总比 RNN 快**。Transformer 更易并行, 但标准 attention 有 $O(L^2)$ 时间

和内存。

10. **Autoencoder 等于 VAE**。AE 是确定性重构模型；VAE 是潜变量概率模型。
11. **重构误差低等于语义表示好**。网络可能只保留低层像素细节或近似恒等映射。
12. **InfoNCE 负样本越多必然越好**。更多负样本也增加计算、通信和 false negative 风险。
13. **迁移学习评估使用测试集调参**。解冻层数、学习率和 early stopping 必须由验证集选择。
14. **元学习 support/query 不分**。Support 用于适应，query 用于评估适应后泛化并更新元参数。

20.7 快速自测



快速自测

1. 输入 $C_{\text{in}} \times H \times W$ 经 $C_{\text{out}} \times C_{\text{in}} \times k_h \times k_w$ 卷积后, 参数量为何不含 $H_{\text{out}}W_{\text{out}}$?
2. 写出同时含 stride、padding 和 dilation 的输出尺寸公式。
3. 三层 3×3 、stride 1 卷积的 Receptive Field 为何是 7×7 , 而不是 9×9 ?
4. 卷积的平移等变性与分类器的平移不变性有何区别?
5. 语义分割与图像分类的输出张量分别是什么形状?
6. 目标检测损失中分类项、框回归项、IoU 项分别约束什么?
7. 光流无监督训练中的 brightness constancy 在遮挡区域为什么失效?
8. 给定 $Q \in \mathbb{R}^{L_q \times d_k}$, $K \in \mathbb{R}^{L_k \times d_k}$, $V \in \mathbb{R}^{L_v \times d_v}$, attention 输出是什么维度?
9. 删除 $1/\sqrt{d_k}$ 后, 为什么不能只说“数值变大”, 而应进一步分析 softmax Jacobian?
10. 无位置编码的 self-attention 对输入排列是什么性质?
11. 标准 multi-head attention 在 $H_a d_k = H_a d_v = d_{\text{model}}$ 时, 忽略偏置的参数量为何约为 $4d_{\text{model}}^2$?
12. Transformer 的并行优势与 $O(L^2)$ 复杂度是否矛盾?
13. ViT 的 patch embedding 如何由一个 stride 等于 patch 大小的卷积实现?
14. 普通 autoencoder 为什么需要 bottleneck、噪声或其他约束?
15. 推导 $\nabla_z \mathcal{L}_{\text{NCE}}$ 时, 正样本项的系数为什么是 $p_0 - 1$?
16. 高维随机单位向量内积的方差为何为 $1/d$?
17. 小温度 τ 对 hard negative 权重和梯度尺度分别有什么影响?
18. Linear probing 与 full fine-tuning 分别更新哪些参数?
19. MAML 的 support loss 和 query loss 分别用于什么步骤?
20. 若目标任务分布与源任务差异很大, 迁移学习可能发生什么失败?



第二十一章 生成模型的统一概率框架与自回归模型

21.1 重要性等级与实考定位

重要性等级：S

- [25F-B-Q2(a), 2 分] 直接要求证明： $\max_{\theta} \mathbb{E}_{p_{\text{data}}} [\log p_{\theta}(\mathbf{X})] \iff \min_{\theta} \text{KL}(p_{\text{data}} \| p_{\theta})$. 满分答案必须写清 KL 的方向，并指出与参数无关的常数项。
- 最大似然是自回归模型、VAE、normalizing flow 和 diffusion 的共同起点，也是区分显式密度模型与隐式生成模型的关键。
- 自回归模型虽然未在三套 B 方向试卷中单独设置高分题，但它是生成模型讲义核心内容，也是 NLP 中自回归语言模型、teacher forcing 和 exposure bias 的数学基础。

本章中：

- 最大似然与 forward KL 的等价必须会完整证明；
- 自回归链式分解、NLL 和 teacher forcing 必须会完整写出；
- exposure bias、训练与推理复杂度、KV cache 必须会解释；
- 不得把 likelihood、样本质量和下游效用视为同一个指标。

21.2 生成模型与判别模型

设数据随机变量 $\mathbf{X} \in \mathcal{X}$, $Y \in \mathcal{Y}$ 。

判别模型通常直接建模： $p_{\theta}(y | \mathbf{x})$ 或决策函数 $h_{\theta} : \mathcal{X} \rightarrow \mathcal{Y}$ 。

生成模型则建模以下对象之一：


$$p_{\theta}(\mathbf{x}), \quad (21.1)$$

$$p_{\theta}(\mathbf{x} | \mathbf{c}), \quad (21.2)$$

$$p_{\theta}(\mathbf{x}, \mathbf{z}) = p(\mathbf{z})p_{\theta}(\mathbf{x} | \mathbf{z}), \quad (21.3)$$

其中 $\mathbf{c}$ 是条件， $\mathbf{z}$ 是潜变量。

生成的基本流程是：从模型分布采样 $\mathbf{X} \sim p_{\theta}$ 或 $\mathbf{Z} \sim p(\mathbf{z})$, $\mathbf{X} \sim p_{\theta}(\mathbf{x} | \mathbf{Z})$ 。



21.2.1 离散概率质量与连续概率密度

若 $\mathcal{X}$ 离散, 则 $p_{\theta}(\mathbf{x}) = \Pr_{\theta}(\mathbf{X} = \mathbf{x}) \in [0, 1]$, $\sum_{\mathbf{x} \in \mathcal{X}} p_{\theta}(\mathbf{x}) = 1$ 。

若 $\mathcal{X} \subseteq \mathbb{R}^d$ 连续, 则 p_{θ} 是相对于 Lebesgue 测度的密度: $p_{\theta}(\mathbf{x}) \geq 0$, $\int_{\mathcal{X}} p_{\theta}(\mathbf{x}) d\mathbf{x} = 1$ 。连续密度值可以大于 1; 概率由区域积分给出: $\Pr(\mathbf{X} \in A) = \int_A p_{\theta}(\mathbf{x}) d\mathbf{x}$ 。

易错点、反例与失败模式

“连续模型的 likelihood 必须不超过 1”是错误说法。概率质量不超过 1, 但概率密度可以大于 1。例如 $X \sim \text{Unif}[0, 1/2]$ 时, 密度为 $p(x) = 2$ 在区间 $[0, 1/2]$ 上成立。

21.2.2 显式密度与隐式密度

表 21.1: 主要生成模型的概率可计算性

模型	密度或似然	典型训练与采样性质
自回归模型	通过条件概率乘积获得精确且可计算的 $p_{\theta}(\mathbf{x})$ 。	训练可并行计算多个条件项; 采样必须按变量顺序进行。
Normalizing flow	通过可逆变换和 Jacobian determinant 得到精确密度。	训练和采样均使用可逆网络; 架构受可逆性和 log-determinant 约束。
VAE	边缘似然 $p_{\theta}(\mathbf{x}) = \int p(\mathbf{z})p_{\theta}(\mathbf{x} \mathbf{z})d\mathbf{z}$ 通常不可精确计算。	最大化 ELBO; 采样可并行; 训练含变分近似误差。
GAN	通常只定义采样过程 $\mathbf{z} \sim p(\mathbf{z})$, $\mathbf{x} = G_{\theta}(\mathbf{z})$, 而不提供可计算密度。	对抗训练; 采样通常只需一次生成器前向; 训练可能不稳定。

21.3 KL 散度与最大似然

定义 21.1 (KL 散度). 设概率分布 P 和 Q 相对于共同测度 μ 有密度 p 和 q 。若 $P \ll Q$, 即 $q(\mathbf{x}) = 0$ 蕴含 $p(\mathbf{x}) = 0$ 几乎处处, 则

$$\text{KL}(P\|Q) = \int p(\mathbf{x}) \log \frac{p(\mathbf{x})}{q(\mathbf{x})} d\mu(\mathbf{x}). \quad (21.4)$$


若存在正 P -概率区域满足 $q = 0$, 则定义 $\text{KL}(P\|Q) = +\infty$ 。

KL 散度满足:

$$\text{KL}(P\|Q) \geq 0, \quad (21.5)$$

且在适当条件下 $\text{KL}(P\|Q) = 0 \iff P = Q$ 几乎处处。它通常不对称: $\text{KL}(P\|Q) \neq \text{KL}(Q\|P)$ 。

命题 21.2 (KL 非负性). 若 $P \ll Q$, 则 $\text{KL}(P\|Q) \geq 0$ 。



证明. 由 $-\log u \geq 1 - u$, $u > 0$, 令 $u = \frac{q(\mathbf{x})}{p(\mathbf{x})}$ 并对 P 取期望:

$$\begin{aligned} \text{KL}(P\|Q) &= \mathbb{E}_P \left[-\log \frac{q(\mathbf{X})}{p(\mathbf{X})} \right] \\ &\geq \mathbb{E}_P \left[1 - \frac{q(\mathbf{X})}{p(\mathbf{X})} \right] \\ &= 1 - \int q(\mathbf{x}) d\mu(\mathbf{x}) = 0. \end{aligned} \quad (21.6)$$

等号要求 $q(\mathbf{x})/p(\mathbf{x}) = 1$ 在 P -几乎处处成立。□

定理 21.3 (最大似然与 forward KL 等价). 设真实数据分布的密度为 p_{data} , 模型族为 $\{p_{\theta} : \theta \in \Theta\}$. 假设相关期望有限, 且 $p_{\text{data}} \ll p_{\theta}$ 对考虑的参数成立。则

$$\arg \min_{\theta} \text{KL}(p_{\text{data}}\|p_{\theta}) = \arg \max_{\theta} \mathbb{E}_{\mathbf{X} \sim p_{\text{data}}} [\log p_{\theta}(\mathbf{X})]. \quad (21.7)$$

证明. 由定义,

$$\begin{aligned} \text{KL}(p_{\text{data}}\|p_{\theta}) &= \int p_{\text{data}}(\mathbf{x}) \log \frac{p_{\text{data}}(\mathbf{x})}{p_{\theta}(\mathbf{x})} d\mathbf{x} \\ &= \int p_{\text{data}}(\mathbf{x}) \log p_{\text{data}}(\mathbf{x}) d\mathbf{x} - \int p_{\text{data}}(\mathbf{x}) \log p_{\theta}(\mathbf{x}) d\mathbf{x} \\ &= -H(p_{\text{data}}) - \mathbb{E}_{p_{\text{data}}} [\log p_{\theta}(\mathbf{X})], \end{aligned} \quad (21.8)$$

其中 $H(p_{\text{data}}) = -\int p_{\text{data}}(\mathbf{x}) \log p_{\text{data}}(\mathbf{x}) d\mathbf{x}$ 是数据分布的熵, 与 θ 无关。因此最小化 KL 等价于最大化模型对真实数据的期望 log-likelihood。□

交叉熵形式为

$$\underbrace{-\mathbb{E}_{p_{\text{data}}} [\log p_{\theta}(\mathbf{X})]}_{H(p_{\text{data}}, p_{\theta})} = H(p_{\text{data}}) + \text{KL}(p_{\text{data}}\|p_{\theta}). \quad (21.9)$$

易错点、反例与失败模式

讲义第 5 页图中彩色公式的两个积分项顺序疑似写反。标准定义必须是 $\text{KL}(p_{\text{data}}\|p_{\text{model}}) = \int p_{\text{data}} \log p_{\text{data}} - \int p_{\text{data}} \log p_{\text{model}}$ 。若把顺序反过来, 得到的是 KL 的负值, 不再满足非负性。此外, 最大似然对应 $\text{KL}(p_{\text{data}}\|p_{\theta})$, 不是 $\text{KL}(p_{\theta}\|p_{\text{data}})$ 。

21.3.1 经验最大似然

给定独立同分布样本 $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)} \stackrel{\text{i.i.d.}}{\sim} p_{\text{data}}$, 经验负对数似然为


$$\hat{\mathcal{L}}_{\text{NLL}}(\theta) = -\frac{1}{N} \sum_{n=1}^N \log p_{\theta}(\mathbf{x}^{(n)}). \quad (21.10)$$

其梯度为

$$\nabla_{\theta} \hat{\mathcal{L}}_{\text{NLL}} = -\frac{1}{N} \sum_{n=1}^N \nabla_{\theta} \log p_{\theta}(\mathbf{x}^{(n)}). \quad (21.11)$$

对均匀抽取的 mini-batch $\mathcal{B}$,

$$\hat{\mathbf{g}}_{\mathcal{B}} = -\frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \nabla_{\theta} \log p_{\theta}(\mathbf{x}^{(n)}) \quad (21.12)$$



是全经验 NLL 梯度的无偏估计。

严格地说,连续数据的经验分布是有限点质量分布,它不具有相对于 Lebesgue 测度的普通密度;因此连续情形下不宜把经验 NLL 机械写成“经验分布与连续密度的有限 KL”。正确表述是: $\frac{1}{N} \sum_n -\log p_{\theta}(\mathbf{x}^{(n)})$ 是总体交叉熵 $-\mathbb{E}_{p_{\text{data}}} \log p_{\theta}(\mathbf{X})$ 的 Monte Carlo 估计。

例 21.4 (Bernoulli 最大似然). 设 $x_1, \dots, x_N \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(\theta)$, $\theta \in [0, 1]$ 。令 $S = \sum_{n=1}^N x_n$ 。log-likelihood 为 $\ell(\theta) = S \log \theta + (N - S) \log(1 - \theta)$ 。若 $0 < S < N$, 则

$$\ell'(\theta) = \frac{S}{\theta} - \frac{N - S}{1 - \theta}, \quad (21.13)$$

$$\ell'(\theta) = 0 \implies S(1 - \theta) = (N - S)\theta, \quad (21.14)$$

$$\hat{\theta}_{\text{MLE}} = \frac{S}{N}. \quad (21.15)$$

若 $S = 0$ 或 $S = N$, 极大值分别位于边界 $\theta = 0$ 或 $\theta = 1$ 。

反例 21.5 (无约束最大似然可能退化). 考虑单个连续样本 x_1 , 并拟合 $p_{\mu, \sigma}(x) = \mathcal{N}(x; \mu, \sigma^2)$ 。取 $\mu = x_1$, $\sigma \downarrow 0$, 则 $p_{\mu, \sigma}(x_1) = \frac{1}{\sqrt{2\pi}\sigma} \rightarrow +\infty$ 。因此有限样本最大似然可能不存在有限最优参数。正则化、固定方差、先验或模型结构约束不能无条件省略。

答题方法

[25F-B-Q2(a), 2 分] 的满分答案可以压缩为:

$$\begin{aligned} \text{KL}(p_{\text{data}} \| p_{\theta}) &= \mathbb{E}_{p_{\text{data}}} [\log p_{\text{data}}(\mathbf{X}) - \log p_{\theta}(\mathbf{X})] \\ &= \underbrace{\mathbb{E}_{p_{\text{data}}} [\log p_{\text{data}}(\mathbf{X})]}_{\text{与 } \theta \text{ 无关}} - \mathbb{E}_{p_{\text{data}}} [\log p_{\theta}(\mathbf{X})]. \end{aligned}$$

故 $\arg \min_{\theta} \text{KL}(p_{\text{data}} \| p_{\theta}) = \arg \max_{\theta} \mathbb{E}_{p_{\text{data}}} [\log p_{\theta}(\mathbf{X})]$ 。再写经验近似 $\mathbb{E}_{p_{\text{data}}} [\log p_{\theta}(\mathbf{X})] \approx \frac{1}{N} \sum_{n=1}^N \log p_{\theta}(\mathbf{x}^{(n)})$ 。不能遗漏 KL 的方向, 也不能把第一项说成关于 $\mathbf{x}$ 的常数; 它只是关于参数 θ 的常数。

21.4 自回归模型

21.4.1 链式分解

设 $\mathbf{X} = (X_1, \dots, X_T)$ 。概率链式法则给出

$$p_{\theta}(\mathbf{x}) = \prod_{t=1}^T p_{\theta}(x_t | x_1, \dots, x_{t-1}) = \prod_{t=1}^T p_{\theta}(x_t | \mathbf{x}_{<t}). \quad (21.16)$$

其中 $p_{\theta}(x_1 | \mathbf{x}_{<1}) = p_{\theta}(x_1)$ 。

对任意排列 $\pi = (\pi_1, \dots, \pi_T)$ 也有

$$p_{\theta}(\mathbf{x}) = \prod_{t=1}^T p_{\theta}(x_{\pi_t} | x_{\pi_1}, \dots, x_{\pi_{t-1}}). \quad (21.17)$$

因此链式分解本身没有近似; 近似来自:

- 条件分布的参数化能力有限;



- 上下文窗口有限；
- 参数共享假设；
- 训练和优化不完全；
- 选取的变量顺序带来的归纳偏置。

对离散 token, $X_t \in [V]$, 神经网络输出词表 logits $\mathbf{a}_t \in \mathbb{R}^V$, 并定义

$$p_{\theta}(X_t = v \mid \mathbf{x}_{<t}) = \frac{\exp(a_{t,v})}{\sum_{r=1}^V \exp(a_{t,r})}. \quad (21.18)$$

21.4.2 最大似然训练

对序列数据 $\mathcal{D} = \{\mathbf{x}^{(n)}\}_{n=1}^N$, $\mathbf{x}^{(n)} = (x_1^{(n)}, \dots, x_{T_n}^{(n)})$, 经验 NLL 为

$$\begin{aligned} \hat{\mathcal{L}}_{\text{AR}}(\theta) &= -\frac{1}{N} \sum_{n=1}^N \log p_{\theta}(\mathbf{x}^{(n)}) \\ &= -\frac{1}{N} \sum_{n=1}^N \sum_{t=1}^{T_n} \log p_{\theta}(x_t^{(n)} \mid \mathbf{x}_{<t}^{(n)}). \end{aligned} \quad (21.19)$$

对第 t 个位置, 输入是真实前缀 $\mathbf{x}_{<t}^{(n)}$, 目标是真实下一个 token $x_t^{(n)}$ 。这称为 teacher forcing。

若采用 decoder-only Transformer, 输入和目标通常错开一位:

输入	$\langle \text{BOS} \rangle$	x_1	x_2	$\cdots$	x_{T-1}
目标	x_1	x_2	x_3	$\cdots$	x_T

并使用 causal mask 防止位置 t 读取未来 token。


21.4.3 Teacher forcing 的作用与边界

Teacher forcing 的优点:

1. 每个条件项直接在真实上下文上优化；
2. 无需在训练中对离散 token 逐步采样；
3. 不会在一个训练前向中累积模型自己的早期生成错误；
4. 对 masked CNN 或 Transformer, 可并行计算所有位置的条件概率；
5. 梯度是序列 NLL 的普通反向传播梯度。

但对 RNN, $\mathbf{h}_t = f(\mathbf{h}_{t-1}, x_{t-1})$ 仍有隐藏状态的时间递推依赖。Teacher forcing 消除了“前一步随机采样结果”作为输入的依赖, 但不自动使 RNN 的全部时间步并行。

定义 21.6 (Exposure bias). 训练阶段模型接收真实前缀: $\mathbf{x}_{<t} \sim p_{\text{data}}$, 而推理阶段接收自己生成的前缀: $\hat{\mathbf{x}}_{<t} \sim p_{\theta}$ 。由此产生的上下文分布不匹配称为 exposure bias。



易错点、反例与失败模式

Exposure bias 不意味着 teacher forcing 的最大似然目标在数学上“不是序列似然”。式 (21.19) 正是精确联合 log-likelihood 的链式分解。问题在于有限数据、模型错设和推理时的前缀分布变化，使局部条件误差可能在生成过程中累积。

21.4.4 自回归推理

生成时没有真实未来 token。给定初始上下文 $\hat{\mathbf{x}}_{<1}$ ，依次执行：

$$\hat{x}_t \sim p_{\theta}(\cdot | \hat{\mathbf{x}}_{<t}), \quad t = 1, 2, \dots, \quad (21.20)$$

直到生成 (EOS) 或达到最大长度。

若某一步生成了低概率但不合理的 token，后续模型面对的是训练数据中罕见的前缀，误差可能继续放大。

具体的 greedy、beam、top- k 和 top- p 解码将在 NLP 部分统一讨论。

21.4.5 复杂度与 KV cache

设： T = 序列长度， d = 隐藏维度， N_{layer} = Transformer 层数。

训练时，标准 causal Transformer 的每层主要复杂度为

$$O(Td^2 + T^2d), \quad (21.21)$$

其中： Td^2 来自线性投影和 FFN， T^2d 来自 attention score 与 value 聚合。尽管 attention mask 是因果的，训练时仍可对所有 query 位置并行。

若推理时每生成一个 token 都重新计算整个前缀，总复杂度约为

$$\sum_{t=1}^T O(td^2 + t^2d) = O(T^2d^2 + T^3d). \quad (21.22)$$

使用 KV cache 后，旧 token 的 key 和 value 不再重复计算。第 t 步主要代价约为 $O(d^2 + td)$ ，整个序列约为

$$O(Td^2 + T^2d) \quad \text{每层}. \quad (21.23)$$

标准多头 attention 的 KV cache 标量数约为

$$M_{\text{KV}} = 2BN_{\text{layer}}TN_{\text{KV-head}}d_{\text{head}}, \quad (21.24)$$

其中因子 2 分别对应 key 和 value。若每个 query head 都有独立 key/value head，则 $N_{\text{KV-head}} = N_{\text{head}}$ 。

KV cache 降低重复计算，但带来随序列长度线性增长的显存开销。

易错点、反例与失败模式

1. 自回归模型的训练可以并行，不等于自回归采样可以并行。
2. Teacher forcing 只用于训练；推理阶段没有真实下一 token。
3. Causal mask 阻止读取未来信息，但不改变联合分布的链式含义。

4. KV cache 缓存的是过去层中的 key/value，不是缓存最终生成概率。
5. 精确 likelihood 高不必然意味着主观样本质量最好。



第二十二章 生成对抗网络 (GAN)

22.1 重要性等级与资料定位

重要性等级：A

- GAN 是简要考纲明确节点，必须掌握 minimax 目标、discriminator、generator、mode collapse 和替代生成器损失。
- 三套 B 方向真题没有单独设置 GAN 高分题，因此不能称为历年博资考高频真题。

Gen 对 GAN 的重点是：最优判别器、JS 散度、minimax 非收敛、mode collapse、梯度消失和 Wasserstein 距离。

原始 GAN 的最优判别器和 JS 散度关系属于 **必须掌握推导框架**；minimax 与 non-saturating loss 的梯度区别属于 **必须会完整解释**。

22.2 模型设定

设真实数据分布为 $p_{\text{data}}(\mathbf{x})$, $\mathbf{x} \in \mathbb{R}^{d_x}$ 。潜变量先验为 $\mathbf{Z} \sim p_z$, $\mathbf{Z} \in \mathbb{R}^{d_z}$ 。生成器为

$$G_{\theta} : \mathbb{R}^{d_z} \rightarrow \mathbb{R}^{d_x}, \quad \tilde{\mathbf{X}} = G_{\theta}(\mathbf{Z}). \quad (22.1)$$

生成器诱导的分布记为 p_g 。当 $d_z < d_x$ 且生成器为确定性光滑映射时， p_g 可能集中在低维流形上，并不存在普通的全维 Lebesgue 密度。这正是 GAN 常被称为隐式生成模型的原因之一。

判别器为


$$D_{\psi} : \mathbb{R}^{d_x} \rightarrow (0, 1), \quad (22.2)$$

其中 $D_{\psi}(\mathbf{x})$ 被解释为样本来自真实数据而非生成器的概率。

原始 GAN 目标为

$$\min_{\theta} \max_{\psi} V(\psi, \theta) = \mathbb{E}_{\mathbf{X} \sim p_{\text{data}}} [\log D_{\psi}(\mathbf{X})] + \mathbb{E}_{\mathbf{Z} \sim p_z} [\log (1 - D_{\psi}(G_{\theta}(\mathbf{Z})))] \quad (22.3)$$

判别器希望： $D(\mathbf{x}) \rightarrow 1$ 对真实样本， $D(G(\mathbf{z})) \rightarrow 0$ 对生成样本。生成器希望使生成样本无法被判别器区分。



22.3 固定生成器时的最优判别器

定理 22.1 (最优判别器). 假设 p_{data} 和 p_g 相对于共同测度具有密度。固定生成器 G 后, 式 (22.3) 对每个满足 $p_{\text{data}}(\mathbf{x}) + p_g(\mathbf{x}) > 0$ 的点的最优判别器为

$$D^*(\mathbf{x}) = \frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_g(\mathbf{x})}. \quad (22.4)$$

证明. 固定 $\mathbf{x}$, 令 $a = p_{\text{data}}(\mathbf{x})$, $b = p_g(\mathbf{x})$ 。需要在 $D \in (0, 1)$ 上最大化 $\phi(D) = a \log D + b \log(1 - D)$ 。一阶导数为 $\phi'(D) = \frac{a}{D} - \frac{b}{1-D}$ 。令其为零: $a(1 - D) = bD \implies D = \frac{a}{a+b}$ 。二阶导数为 $\phi''(D) = -\frac{a}{D^2} - \frac{b}{(1-D)^2} < 0$, 故该驻点是唯一极大点。□

在理想平衡点 $p_g = p_{\text{data}}$ 时, $D^*(\mathbf{x}) = \frac{1}{2}$ 。这不表示判别器“训练失败”, 而表示生成分布与数据分布无法区分。

22.4 与 Jensen-Shannon 散度的关系

定义混合分布

$$m = \frac{1}{2} (p_{\text{data}} + p_g). \quad (22.5)$$

Jensen-Shannon 散度为

$$\text{JS}(p_{\text{data}} \| p_g) = \frac{1}{2} \text{KL}(p_{\text{data}} \| m) + \frac{1}{2} \text{KL}(p_g \| m). \quad (22.6)$$

定理 22.2 (GAN 的理想化 JS 目标). 将最优判别器式 (22.4) 代回原始 GAN 目标, 可得

$$V(D^*, G) = -\log 4 + 2 \text{JS}(p_{\text{data}} \| p_g). \quad (22.7)$$

因此在无限模型容量且每一步判别器均达到最优的理想条件下, 全局极小值为 $-\log 4$, 并且当且仅当 $p_g = p_{\text{data}}$ 几乎处处时达到。

证明. 代入 D^* :

$$\begin{aligned} V(D^*, G) &= \int p_{\text{data}}(\mathbf{x}) \log \frac{p_{\text{data}}(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_g(\mathbf{x})} d\mathbf{x} \\ &\quad + \int p_g(\mathbf{x}) \log \frac{p_g(\mathbf{x})}{p_{\text{data}}(\mathbf{x}) + p_g(\mathbf{x})} d\mathbf{x}. \end{aligned} \quad (22.8)$$

由 $p_{\text{data}} + p_g = 2m$, 有

$$\begin{aligned} V(D^*, G) &= \int p_{\text{data}} \log \frac{p_{\text{data}}}{2m} + \int p_g \log \frac{p_g}{2m} \\ &= \text{KL}(p_{\text{data}} \| m) + \text{KL}(p_g \| m) - 2 \log 2 \\ &= 2 \text{JS}(p_{\text{data}} \| p_g) - \log 4. \end{aligned} \quad (22.9)$$

由 JS 非负性得出结论。□

易错点、反例与失败模式

“GAN 直接最小化 JS 散度”只在以下理想条件下成立:

- 判别器具有足够表达能力;

- 对每个生成器状态, 判别器被优化到最优;
- 分布具有适当密度或可使用相应测度版本;
- 优化过程能够达到全局均衡。

实际交替 SGD 并不满足这些条件, 因此不能据此声称 GAN 一定收敛。

22.5 Generator 的饱和损失与非饱和损失

原始 minimax 中, 固定判别器后生成器最小化

$$\mathcal{L}_G^{\text{sat}} = \mathbb{E}_{\mathbf{Z}} [\log (1 - D_{\psi}(G_{\theta}(\mathbf{Z})))] . \quad (22.10)$$

实践中常改为 non-saturating loss:

$$\mathcal{L}_G^{\text{NS}} = -\mathbb{E}_{\mathbf{Z}} [\log D_{\psi}(G_{\theta}(\mathbf{Z}))] . \quad (22.11)$$

两者希望达到相同的理想平衡点, 但早期梯度行为不同。

设判别器 logit 为 $a(\mathbf{x})$, $D(\mathbf{x}) = \sigma(a(\mathbf{x}))$ 。则

$$\frac{\partial}{\partial a} \log(1 - \sigma(a)) = -\sigma(a) = -D, \quad (22.12)$$

$$\frac{\partial}{\partial a} [-\log \sigma(a)] = -(1 - \sigma(a)) = -(1 - D). \quad (22.13)$$

若早期判别器很强, 对生成样本有 $D(G(\mathbf{z})) \approx 0$, 则: $-D \approx 0$, $-(1 - D) \approx -1$ 。因此 non-saturating loss 提供 stronger 的生成器梯度。

生成器参数梯度为

$$\nabla_{\theta} \mathcal{L}_G^{\text{NS}} = -\mathbb{E}_{\mathbf{Z}} \left[\mathbf{J}_{G_{\theta}}(\mathbf{Z})^{\top} \nabla_{\mathbf{x}} \log D_{\psi}(\mathbf{x}) \Big|_{\mathbf{x}=G_{\theta}(\mathbf{Z})} \right], \quad (22.14)$$

其中 $\mathbf{J}_{G_{\theta}}(\mathbf{Z}) = \frac{\partial G_{\theta}(\mathbf{Z})}{\partial \theta} \in \mathbb{R}^{d_x \times p_{\theta}}$ 。

22.6 交替训练算法

给定 batch size B , 一次典型迭代为:

答题方法

判别器步骤:

1. 采样真实数据 $\mathbf{x}_1, \dots, \mathbf{x}_B \sim p_{\text{data}}$;
2. 采样噪声 $\mathbf{z}_1, \dots, \mathbf{z}_B \sim p_{\mathbf{z}}$;
3. 生成假样本 $\tilde{\mathbf{x}}_i = G_{\theta}(\mathbf{z}_i)$, 在更新判别器时停止对生成器求梯度;
4. 最小化判别器负目标 $\mathcal{L}_D = -\frac{1}{B} \sum_{i=1}^B [\log D_{\psi}(\mathbf{x}_i) + \log(1 - D_{\psi}(\tilde{\mathbf{x}}_i))]$ 。

生成器步骤:

1. 重新采样 $\mathbf{z}_i \sim p_{\mathbf{z}}$;

2. 计算 $\mathcal{L}_G^{\text{NS}} = -\frac{1}{B} \sum_i \log D_\psi(G_\theta(z_i))$;

3. 固定判别器参数 ψ , 反向传播经过判别器输入和生成器, 更新 θ 。

若每轮进行 k_D 次判别器更新和一次生成器更新, 必须将 k_D 作为训练超参数说明。

若一次生成器和判别器前向-反向的代价分别为 C_G, C_D , 则一轮主计算量约为

$$O(B[k_D(C_G + C_D) + (C_G + C_D)]).$$

实际开销还取决于是否复用假样本、判别器更新次数和分布式通信。

22.7 失败模式

22.7.1 Mode collapse

定义 22.3 (Mode collapse). 生成器将许多不同潜变量映射到少量输出模式: $G_\theta(z_1) \approx G_\theta(z_2)$ 对大量不同 z_1, z_2 成立, 导致生成样本缺乏多样性。

Mode collapse 可能发生, 因为当前判别器梯度可能奖励某个能够欺骗判别器的模式, 而没有直接要求生成器覆盖全部数据模式。

易错点、反例与失败模式

Mode collapse 不等于“所有样本完全相同”这一种极端情形。只要模型系统性遗漏若干真实模式、类内变化或低频区域, 即可视为部分 mode collapse。

22.7.2 Minimax 非收敛

反例 22.4 (双线性博弈产生循环). 考虑

$$\min_x \max_y xy. \quad (22.15)$$

连续时间梯度下降-上升为

$$\dot{x}(t) = -y(t), \quad (22.16)$$

$$\dot{y}(t) = x(t). \quad (22.17)$$

于是 $\ddot{x}(t) = -x(t)$, 解为

$$x(t) = x(0) \cos t - y(0) \sin t, \quad (22.18)$$


$$y(t) = x(0) \sin t + y(0) \cos t. \quad (22.19)$$

并且 $\frac{d}{dt}(x(t)^2 + y(t)^2) = 2x(-y) + 2yx = 0$. 轨迹沿圆周运动而不收敛到鞍点 $(0, 0)$ 。这说明即使目标简单, 普通梯度下降-上升也不自动收敛。

22.7.3 支持集不重叠与梯度消失

若真实分布和生成分布集中在不重叠的低维流形上, 理想判别器可接近完美分类:

$$D(\mathbf{x}) \approx 1 \quad p_{\text{data-a.s.}}, \quad D(\mathbf{x}) \approx 0 \quad p_g\text{-a.s.}$$



此时 JS 散度可能在生成器参数的局部变化下近似常数，原始 minimax 梯度可能极弱。

这也是：理论最优判别器 与 为生成器提供有用梯度的判别器 并非完全相同训练目标的原因。

22.8 Wasserstein GAN: 实考外扩展

重要性等级：C

WGAN 未在简要考纲中单独列出，也未在三套博资考中直接考查，但 [Gen] 使用它解释 GAN 的梯度失效与距离选择问题。掌握目标形式和 Lipschitz 条件即可。

一阶 Wasserstein 距离为

$$W_1(P, Q) = \inf_{\gamma \in \Pi(P, Q)} \mathbb{E}_{(\mathbf{X}, \mathbf{Y}) \sim \gamma} [\|\mathbf{X} - \mathbf{Y}\|_2], \quad (22.20)$$

其中 $\Pi(P, Q)$ 是边缘分布分别为 P, Q 的联合分布集合。

其对偶形式为

$$W_1(P, Q) = \sup_{\|f\|_{\text{Lip}} \leq 1} [\mathbb{E}_P[f(\mathbf{X})] - \mathbb{E}_Q[f(\mathbf{X})]]. \quad (22.21)$$

WGAN 中 f_ψ 称为 critic，不输出真假概率。训练目标为

$$\max_{\psi: \|f_\psi\|_{\text{Lip}} \leq 1} \mathbb{E}_{P_{\text{data}}} [f_\psi(\mathbf{X})] - \mathbb{E}_{\mathbf{Z}} [f_\psi(G_\theta(\mathbf{Z}))], \quad (22.22)$$

$$\min_{\theta} - \mathbb{E}_{\mathbf{Z}} [f_\psi(G_\theta(\mathbf{Z}))]. \quad (22.23)$$

原始 weight clipping 可能限制 critic 的表达能力。根据附件关于 WGAN-GP 的结论所作的公式补充，一种梯度惩罚为

$$\lambda_{\text{GP}} \mathbb{E}_{\hat{\mathbf{X}}} \left[\left(\|\nabla_{\hat{\mathbf{x}}} f_\psi(\hat{\mathbf{X}})\|_2 - 1 \right)^2 \right], \quad (22.24)$$

其中 $\hat{\mathbf{X}}$ 通常取真实和生成样本之间的随机插值。

易错点、反例与失败模式

WGAN 的关键不是简单“删除 sigmoid”，而是：

1. 使用 Wasserstein 对偶目标；
2. critic 属于 1-Lipschitz 函数类；
3. 需要显式机制近似满足 Lipschitz 约束。



第二十三章 变分自编码器与证据下界

23.1 重要性等级与实考定位

重要性等级：S

- [25F-B-Q2(c), 4 分] 要求说明 VAE 为什么使用 ELBO 近似最大似然，并解释重构项和正则项。
- 满分答案必须写： $p_{\theta}(\mathbf{x}, \mathbf{z})$, $q_{\phi}(\mathbf{z} | \mathbf{x})$, $\log p_{\theta}(\mathbf{x})$, ELBO, ELBO gap.
- 只写“VAE 的损失等于重构误差加 KL”而不说明概率模型、KL 方向和期望分布，不能视为完整答案。

23.2 潜变量概率模型

设观测变量和潜变量为 $\mathbf{x} \in \mathbb{R}^{d_x}$, $\mathbf{z} \in \mathbb{R}^{d_z}$ 。VAE 的生成模型为

$$p_{\theta}(\mathbf{x}, \mathbf{z}) = p(\mathbf{z})p_{\theta}(\mathbf{x} | \mathbf{z}), \quad (23.1)$$

其中常用先验为

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}_{d_z}). \quad (23.2)$$

边缘似然为

$$p_{\theta}(\mathbf{x}) = \int_{\mathbb{R}^{d_z}} p(\mathbf{z})p_{\theta}(\mathbf{x} | \mathbf{z}) d\mathbf{z}. \quad (23.3)$$

真实后验为

$$p_{\theta}(\mathbf{z} | \mathbf{x}) = \frac{p(\mathbf{z})p_{\theta}(\mathbf{x} | \mathbf{z})}{p_{\theta}(\mathbf{x})}. \quad (23.4)$$

困难在于： $p_{\theta}(\mathbf{x})$ 包含高维积分，而分母本身正是未知的边缘似然，使真实后验通常不可计算。

VAE 引入参数化变分后验或 encoder:

$$q_{\phi}(\mathbf{z} | \mathbf{x}) \approx p_{\theta}(\mathbf{z} | \mathbf{x}). \quad (23.5)$$

23.3 ELBO 的 Jensen 推导

定理 23.1 (Evidence Lower Bound). 假设 $q_{\phi}(\mathbf{z} | \mathbf{x}) > 0$ 覆盖需要积分的联合分布支撑。则

$$\log p_{\theta}(\mathbf{x}) \geq \mathcal{L}_{\text{ELBO}}(\theta, \phi; \mathbf{x}), \quad (23.6)$$

$$\mathcal{L}_{\text{ELBO}}(\theta, \phi; \mathbf{x}) = \mathbb{E}_{q_{\phi}(\mathbf{z} | \mathbf{x})} [\log p_{\theta}(\mathbf{x} | \mathbf{z})] - \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})). \quad (23.7)$$



证明. 将边缘似然乘除以变分后验:

$$\begin{aligned}
 \log p_{\theta}(\mathbf{x}) &= \log \int p_{\theta}(\mathbf{x}, \mathbf{z}) d\mathbf{z} \\
 &= \log \int q_{\phi}(\mathbf{z} | \mathbf{x}) \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z} | \mathbf{x})} d\mathbf{z} \\
 &= \log \mathbb{E}_{q_{\phi}(\mathbf{z} | \mathbf{x})} \left[\frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z} | \mathbf{x})} \right].
 \end{aligned} \tag{23.8}$$

由于 $\log$ 是凹函数, Jensen 不等式给出

$$\begin{aligned}
 \log p_{\theta}(\mathbf{x}) &\geq \mathbb{E}_q \left[\log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z} | \mathbf{x})} \right] \\
 &= \mathbb{E}_q [\log p_{\theta}(\mathbf{x} | \mathbf{z}) + \log p(\mathbf{z}) - \log q_{\phi}(\mathbf{z} | \mathbf{x})] \\
 &= \mathbb{E}_q [\log p_{\theta}(\mathbf{x} | \mathbf{z})] - \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})).
 \end{aligned} \tag{23.9}$$

□

负 ELBO 训练损失为

$$\mathcal{J}_{\text{VAE}} = -\mathbb{E}_{q_{\phi}(\mathbf{z} | \mathbf{x})} [\log p_{\theta}(\mathbf{x} | \mathbf{z})] + \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})). \tag{23.10}$$

23.4 ELBO gap

定理 23.2 (ELBO 与真实 log-likelihood 的差). 有

$$\log p_{\theta}(\mathbf{x}) - \mathcal{L}_{\text{ELBO}}(\theta, \phi; \mathbf{x}) = \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p_{\theta}(\mathbf{z} | \mathbf{x})). \tag{23.11}$$

证明. 由 Bayes 公式, $\log p_{\theta}(\mathbf{z} | \mathbf{x}) = \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log p_{\theta}(\mathbf{x})$. 因此

$$\begin{aligned}
 \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p_{\theta}(\mathbf{z} | \mathbf{x})) &= \mathbb{E}_q [\log q_{\phi}(\mathbf{z} | \mathbf{x}) - \log p_{\theta}(\mathbf{z} | \mathbf{x})] \\
 &= \mathbb{E}_q [\log q_{\phi}(\mathbf{z} | \mathbf{x}) - \log p_{\theta}(\mathbf{x}, \mathbf{z})] + \log p_{\theta}(\mathbf{x}) \\
 &= \log p_{\theta}(\mathbf{x}) - \mathcal{L}_{\text{ELBO}}.
 \end{aligned} \tag{23.12}$$

□

所以 ELBO 等于真实 log-likelihood 当且仅当

$$q_{\phi}(\mathbf{z} | \mathbf{x}) = p_{\theta}(\mathbf{z} | \mathbf{x}) \quad \text{几乎处处.} \tag{23.13}$$

VAE 最大化的是下界, 而不是一般情况下的精确 log-likelihood。其误差来源包括:

- 变分族无法表示真实后验;
- encoder 参数未优化到当前模型的最佳后验近似;
- decoder 参数本身不适合数据分布;
- Monte Carlo 梯度和非凸优化误差。



23.5 重构项与正则项的严格含义

ELBO 的第一项

$$\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})] \quad (23.14)$$

称为重构项，但本质上是条件 log-likelihood。它不一定是均方误差。

第二项

$$-\text{KL}(q_\phi(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})) \quad (23.15)$$

约束每个样本的编码分布接近共同先验。它是潜变量分布正则，不是普通参数 weight decay。

其作用包括：

- 使从先验采样的 $\mathbf{z}$ 更可能位于 decoder 见过的区域；
- 防止 encoder 对每个样本使用彼此完全孤立的点质量编码；
- 建立较连续、可插值的潜空间；
- 在重构保真度和潜变量可采样性之间形成权衡。

易错点、反例与失败模式

1. 重构项是 $\mathbb{E}_q[\log p_\theta(\mathbf{x}|\mathbf{z})]$ ，只有在 Gaussian decoder 且方差固定时才等价于负平方误差。
2. KL 的方向是 $\text{KL}(q_\phi(\mathbf{z}|\mathbf{x})\|p(\mathbf{z}))$ ，不能反写。
3. ELBO 中另一个 KL gap 是 $\text{KL}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}|\mathbf{x}))$ 。这两个 KL 的第二个分布不同。

23.6 Gaussian VAE

采用主约定：

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_\phi(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_\phi^2(\mathbf{x}))), \quad (23.16)$$

其中 $\boldsymbol{\mu}_\phi(\mathbf{x}), \boldsymbol{\sigma}_\phi(\mathbf{x}) \in \mathbb{R}^{d_z}$, $\sigma_j(\mathbf{x}) > 0$ 。

附件将正态分布简写为 $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma})$ ，但未始终区分标准差与方差。全文明确采用： $\text{diag}(\boldsymbol{\sigma}^2)$ 为协方差矩阵。

若 decoder 为

$$p_\theta(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x}; g_\theta(\mathbf{z}), \beta \mathbf{I}_{d_x}), \quad \beta > 0, \quad (23.17)$$

则


$$\log p_\theta(\mathbf{x}|\mathbf{z}) = -\frac{d_x}{2} \log(2\pi\beta) - \frac{1}{2\beta} \|\mathbf{x} - g_\theta(\mathbf{z})\|_2^2. \quad (23.18)$$

所以最大化重构 log-likelihood 等价于最小化期望平方误差，但系数由 decoder 方差 β 决定。

23.6.1 Gaussian KL 的闭式形式

命题 23.3 (Gaussian posterior 到标准正态先验的 KL)。若 $q = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $p = \mathcal{N}(\mathbf{0}, \mathbf{I}_k)$, 且 $\boldsymbol{\Sigma} \succ 0$, 则

$$\text{KL}(q\|p) = \frac{1}{2} [\text{tr}(\boldsymbol{\Sigma}) + \|\boldsymbol{\mu}\|_2^2 - k - \log \det \boldsymbol{\Sigma}]. \quad (23.19)$$



证明. 正态密度的对数为

$$\begin{aligned}\log q(\mathbf{z}) &= -\frac{k}{2} \log(2\pi) - \frac{1}{2} \log \det \Sigma - \frac{1}{2} (\mathbf{z} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{z} - \boldsymbol{\mu}), \\ \log p(\mathbf{z}) &= -\frac{k}{2} \log(2\pi) - \frac{1}{2} \mathbf{z}^\top \mathbf{z}.\end{aligned}$$

因此

$$\begin{aligned}\text{KL}(q\|p) &= -\frac{1}{2} \log \det \Sigma - \frac{1}{2} \mathbb{E}_q [(\mathbf{Z} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{Z} - \boldsymbol{\mu})] \\ &\quad + \frac{1}{2} \mathbb{E}_q [\mathbf{Z}^\top \mathbf{Z}].\end{aligned}\tag{23.20}$$

利用

$$\mathbb{E}_q [(\mathbf{Z} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{Z} - \boldsymbol{\mu})] = k,\tag{23.21}$$

$$\mathbb{E}_q [\|\mathbf{Z}\|_2^2] = \|\boldsymbol{\mu}\|_2^2 + \text{tr}(\Sigma),\tag{23.22}$$

即得结论。 $\square$

对角协方差,

$$\boxed{\text{KL}(q_\phi(\mathbf{z} \mid \mathbf{x}) \| p(\mathbf{z})) = \frac{1}{2} \sum_{j=1}^{d_z} [\mu_j(\mathbf{x})^2 + \sigma_j(\mathbf{x})^2 - \log \sigma_j(\mathbf{x})^2 - 1]}.\tag{23.23}$$

实践中 encoder 常输出 $a_j(\mathbf{x}) = \log \sigma_j(\mathbf{x})^2$ 。此时

$$\text{KL} = \frac{1}{2} \sum_{j=1}^{d_z} [\mu_j^2 + e^{a_j} - a_j - 1].\tag{23.24}$$

直接输出 log-variance 可避免要求网络原始输出必须为正。

23.7 重参数化技巧

直接写 $\mathbf{Z} \sim q_\phi(\mathbf{z} \mid \mathbf{x})$ 时, 随机采样节点对参数 ϕ 的普通路径导数不明确。对 Gaussian location-scale family, 可写成

$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{d_z}),\tag{23.25}$$

$$\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\sigma}_\phi(\mathbf{x}) \odot \boldsymbol{\varepsilon}.\tag{23.26}$$

随机性全部来自与 ϕ 无关的 $\boldsymbol{\varepsilon}$, 而 $\mathbf{z}$ 是 ϕ 的可微函数。


对可微函数 f ,

$$\begin{aligned}\nabla_\phi \mathbb{E}_{q_\phi(\mathbf{z} \mid \mathbf{x})} [f(\mathbf{z})] &= \nabla_\phi \mathbb{E}_{\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [f(\boldsymbol{\mu}_\phi + \boldsymbol{\sigma}_\phi \odot \boldsymbol{\varepsilon})] \\ &= \mathbb{E}_\varepsilon [\mathbf{J}_{\mathbf{z}, \phi}^\top \nabla_{\mathbf{z}} f(\mathbf{z})],\end{aligned}\tag{23.27}$$

其中

$$\mathbf{J}_{\mathbf{z}, \phi} = \frac{\partial \boldsymbol{\mu}_\phi}{\partial \phi} + \text{diag}(\boldsymbol{\varepsilon}) \frac{\partial \boldsymbol{\sigma}_\phi}{\partial \phi}.\tag{23.28}$$

这称为 pathwise gradient estimator。



易错点、反例与失败模式

重参数化并不是“删除随机性”。它把 ϕ -依赖的随机变量 改写为 ϕ -无关噪声 + 可微确定性变换。随机采样仍然存在。

23.8 Gaussian VAE 的最终训练目标

结合式 (23.18) 和式 (23.23)，单样本负 ELBO 为

$$\begin{aligned} \mathcal{J}_{\text{VAE}}(\mathbf{x}) = & \frac{1}{2\beta} \mathbb{E}_{\boldsymbol{\varepsilon}} \left[\|\mathbf{x} - g_{\boldsymbol{\theta}}(\boldsymbol{\mu}_{\phi}(\mathbf{x}) + \boldsymbol{\sigma}_{\phi}(\mathbf{x}) \odot \boldsymbol{\varepsilon})\|_2^2 \right] \\ & + \frac{1}{2} \sum_{j=1}^{d_z} [\mu_j(\mathbf{x})^2 + \sigma_j(\mathbf{x})^2 - \log \sigma_j(\mathbf{x})^2 - 1] + C, \end{aligned} \quad (23.29)$$

其中 C 与可训练参数无关。

一次训练步骤为：

1. encoder 输入 $\mathbf{x}$ ，输出 $\boldsymbol{\mu}_{\phi}(\mathbf{x})$ ， $\mathbf{a}_{\phi}(\mathbf{x}) = \log \boldsymbol{\sigma}^2$ ；
2. 采样 $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ；
3. 计算 $\mathbf{z} = \boldsymbol{\mu} + \exp(\mathbf{a}/2) \odot \boldsymbol{\varepsilon}$ ；
4. decoder 输出条件分布参数；
5. 计算 reconstruction NLL 和 KL；
6. 对 $\boldsymbol{\theta}, \phi$ 联合反向传播。

生成阶段不需要 encoder：

$$\mathbf{z} \sim p(\mathbf{z}), \quad \mathbf{x} \sim p_{\boldsymbol{\theta}}(\mathbf{x} | \mathbf{z}). \quad (23.30)$$

重构阶段则使用 $\mathbf{z} \sim q_{\phi}(\mathbf{z} | \mathbf{x})$ 或其均值 $\mathbf{z} = \boldsymbol{\mu}_{\phi}(\mathbf{x})$ 。


23.9 VAE 的失败模式**23.9.1 模糊样本**

若 decoder 使用固定方差 Gaussian，重构项等价于平方误差。当给定潜变量 $\mathbf{z}$ 对应多个可能图像时，平方误差的最优预测趋向条件均值： $g_{\boldsymbol{\theta}}^*(\mathbf{z}) = \mathbb{E}[\mathbf{X} | \mathbf{Z} = \mathbf{z}]$ 。多个清晰模式的平均可能表现为视觉模糊。

因此：高 ELBO 不等于 主观样本一定清晰。

23.9.2 Variational gap

若真实后验高度多峰，而 $q_{\phi}(\mathbf{z} | \mathbf{x})$ 被限制为对角 Gaussian，则 $\text{KL}(q_{\phi} \| p_{\boldsymbol{\theta}}(\mathbf{z} | \mathbf{x}))$ 可能较大，ELBO 与真实 log-likelihood 差距明显。



23.9.3 Posterior collapse

若 decoder 足够强，它可能在不使用 $\mathbf{z}$ 的情况下建模数据： $p_{\theta}(\mathbf{x} | \mathbf{z}) \approx p_{\theta}(\mathbf{x})$ 。此时最优 encoder 可能退化为 $q_{\phi}(\mathbf{z} | \mathbf{x}) \approx p(\mathbf{z})$ ，从而 $\text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})) \approx 0$ 。潜变量几乎不携带关于输入的信息，称为 posterior collapse。

常见缓解思路包括：KL warm-up、限制 decoder、调整 KL 权重、增加潜变量层级。这些是训练策略，不构成无条件保证。

说明 23.4 (β -VAE). 一种常见变体为

$$\mathcal{J}_{\beta\text{-VAE}} = -\mathbb{E}_q[\log p_{\theta}(\mathbf{x} | \mathbf{z})] + \beta \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})). \quad (23.31)$$

当 $\beta \neq 1$ 时，它不再是标准生成模型 log-likelihood 的原始 ELBO，而是人为改变重构与先验约束权衡的目标。

答题方法

[25F-B-Q2(c), 4 分] 的满分答案：

1. 写生成模型 $p_{\theta}(\mathbf{x}, \mathbf{z}) = p(\mathbf{z})p_{\theta}(\mathbf{x} | \mathbf{z})$;
2. 说明边缘似然 $p_{\theta}(\mathbf{x}) = \int p(\mathbf{z})p_{\theta}(\mathbf{x} | \mathbf{z})d\mathbf{z}$ 通常不可积，真实后验也不可计算；
3. 引入 $q_{\phi}(\mathbf{z} | \mathbf{x})$;
4. 由 Jensen 写 $\log p_{\theta}(\mathbf{x}) \geq \mathbb{E}_q[\log p_{\theta}(\mathbf{x} | \mathbf{z})] - \text{KL}(q \| p(\mathbf{z}))$;
5. 说明第一项是 reconstruction log-likelihood，第二项把编码分布约束到先验；
6. 最好补充 $\log p_{\theta}(\mathbf{x}) - \text{ELBO} = \text{KL}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p_{\theta}(\mathbf{z} | \mathbf{x})) \geq 0$;
7. 若题目要求训练技巧，再写 $\mathbf{z} = \boldsymbol{\mu}_{\phi}(\mathbf{x}) + \boldsymbol{\sigma}_{\phi}(\mathbf{x}) \odot \boldsymbol{\varepsilon}$.



第二十四章 Normalizing Flow

24.1 重要性等级与实考定位

重要性等级: S

- [25F-B-Q2(b), 4 分] 要求对由 L 个可逆变换组成的 normalizing flow 写出数据集上的训练目标。
- 满分必须写清: forward transform, inverse transform, Jacobian 方向, $\log |\det(\cdot)|$, NLL 符号。
- Normalizing flow 是精确 likelihood 模型; 其代价是变换必须可逆, 且 inverse 与 log-determinant 必须能够高效计算。

24.2 变量替换公式

设 $\mathbf{Z} \in \mathbb{R}^d$ 具有已知密度 $p_{\mathbf{Z}}(\mathbf{z})$, 并令

$$\mathbf{X} = G_{\theta}(\mathbf{Z}), \quad (24.1)$$

其中 $G_{\theta}: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是 C^1 双射, 逆映射 G_{θ}^{-1} 也可微, 且 Jacobian determinant 非零。

定理 24.1 (多维变量替换公式). $\mathbf{X} = G_{\theta}(\mathbf{Z})$ 的密度为

$$p_{\mathbf{X}}(\mathbf{x}) = p_{\mathbf{Z}}(G_{\theta}^{-1}(\mathbf{x})) \left| \det \frac{\partial G_{\theta}^{-1}(\mathbf{x})}{\partial \mathbf{x}} \right|. \quad (24.2)$$

等价地, 若 $\mathbf{x} = G_{\theta}(\mathbf{z})$, 则

$$\log p_{\mathbf{X}}(\mathbf{x}) = \log p_{\mathbf{Z}}(\mathbf{z}) - \log \left| \det \frac{\partial G_{\theta}(\mathbf{z})}{\partial \mathbf{z}} \right|. \quad (24.3)$$

证明或推导框架

局部体积元满足 $d\mathbf{x} \approx \left| \det \frac{\partial G(\mathbf{z})}{\partial \mathbf{z}} \right| d\mathbf{z}$ 。概率质量守恒: $p_{\mathbf{X}}(\mathbf{x})d\mathbf{x} = p_{\mathbf{Z}}(\mathbf{z})d\mathbf{z}$ 。因此 $p_{\mathbf{X}}(\mathbf{x}) = p_{\mathbf{Z}}(\mathbf{z}) \left| \det \frac{\partial G(\mathbf{z})}{\partial \mathbf{z}} \right|^{-1}$ 。又因为 $\mathbf{J}_{G^{-1}}(\mathbf{x}) = \mathbf{J}_G(\mathbf{z})^{-1}$, 故 $|\det \mathbf{J}_{G^{-1}}| = |\det \mathbf{J}_G|^{-1}$ 。

易错点、反例与失败模式

Jacobian 的方向和符号是最常见失分点：

$$p_{\mathbf{X}}(\mathbf{x}) = p_{\mathbf{Z}}(\mathbf{z}) |\det \mathbf{J}_G(\mathbf{z})|^{-1}, \quad (24.4)$$

$$\log p_{\mathbf{X}}(\mathbf{x}) = \log p_{\mathbf{Z}}(\mathbf{z}) - \log |\det \mathbf{J}_G(\mathbf{z})|. \quad (24.5)$$

若使用 inverse Jacobian, 则符号变为加号: $\log p_{\mathbf{X}}(\mathbf{x}) = \log p_{\mathbf{Z}}(G^{-1}(\mathbf{x})) + \log |\det \mathbf{J}_{G^{-1}}(\mathbf{x})|$ 。两种写法不能混用。

24.3 为什么可逆性和维度条件不能省

1. 若 G 不是单射, 同一 $\mathbf{x}$ 可能有多个原像, 简单的单一 inverse 公式失效, 需要对全部原像求和。
2. 若 $d_z \neq d_x$, Jacobian 不是方阵, 普通 determinant 不存在; 生成分布可能集中在低维流形上。
3. 若 $\det \mathbf{J}_G = 0$, 局部体积被压缩为零, 逆映射不存在或密度出现奇异性。
4. 即使理论上可逆, 若 inverse 或 determinant 需要 $O(d^3)$ 甚至更高代价, 也不适合高维生成模型训练。

因此 normalizing flow 的单层通常同时要求：

$$\text{可逆} + \text{可微} + \text{inverse 高效} + \text{log-determinant 高效}. \quad (24.6)$$

24.4 多层 Flow 的 log-likelihood

令

$$\mathbf{z}_0 \sim p_0(\mathbf{z}_0), \quad (24.7)$$

$$\mathbf{z}_\ell = f_{\theta_\ell}^{(\ell)}(\mathbf{z}_{\ell-1}), \quad \ell = 1, \dots, L, \quad (24.8)$$

$$\mathbf{x} = \mathbf{z}_L. \quad (24.9)$$

整体生成器为 $G_\theta = f_{\theta_L}^{(L)} \circ \dots \circ f_{\theta_1}^{(1)}$ 。

由 Jacobian 链式法则, $\mathbf{J}_G(\mathbf{z}_0) = \mathbf{J}_{f^{(L)}}(\mathbf{z}_{L-1}) \cdots \mathbf{J}_{f^{(1)}}(\mathbf{z}_0)$ 。因此

$$\log p_\theta(\mathbf{x}) = \log p_0(\mathbf{z}_0) - \sum_{\ell=1}^L \log \left| \det \frac{\partial f_{\theta_\ell}^{(\ell)}(\mathbf{z}_{\ell-1})}{\partial \mathbf{z}_{\ell-1}} \right|. \quad (24.10)$$

给定数据 $\mathbf{x}$, 密度评估过程是：

1. 设置 $\mathbf{z}_L = \mathbf{x}$;
2. 依次运行 inverse: $\mathbf{z}_{\ell-1} = \left(f_{\theta_\ell}^{(\ell)}\right)^{-1}(\mathbf{z}_\ell)$, $\ell = L, L-1, \dots, 1$;
3. 计算 base log-density $\log p_0(\mathbf{z}_0)$;
4. 累加所有 forward 或 inverse log-determinant, 保持符号一致。



24.5 Normalizing Flow 的训练目标

给定数据集 $\mathcal{D} = \{\mathbf{x}^{(i)}\}_{i=1}^N$, 最大似然等价于最小化平均 NLL:

$$\mathcal{L}_{\text{flow}}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_{i=1}^N \log p_{\boldsymbol{\theta}}(\mathbf{x}^{(i)}). \quad (24.11)$$

利用式 (24.10),

$$\mathcal{L}_{\text{flow}} = \frac{1}{N} \sum_{i=1}^N \left[-\log p_0(\mathbf{z}_0^{(i)}) + \sum_{\ell=1}^L \log \left| \det \frac{\partial f_{\boldsymbol{\theta}_\ell}^{(\ell)}(\mathbf{z}_{\ell-1}^{(i)})}{\partial \mathbf{z}_{\ell-1}^{(i)}} \right| \right]. \quad (24.12)$$

若 $p_0(\mathbf{z}_0) = \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, 则

$$-\log p_0(\mathbf{z}_0) = \frac{d}{2} \log(2\pi) + \frac{1}{2} \|\mathbf{z}_0\|_2^2, \quad (24.13)$$

故忽略参数无关常数:

$$\mathcal{L}_{\text{flow}} = \frac{1}{N} \sum_{i=1}^N \left[\frac{1}{2} \|\mathbf{z}_0^{(i)}\|_2^2 + \sum_{\ell=1}^L \log \left| \det \mathbf{J}_{f^{(\ell)}}(\mathbf{z}_{\ell-1}^{(i)}) \right| \right] + C. \quad (24.14)$$

答题方法

[25F-B-Q2(b), 4 分] 的满分答案:

题目给定 $\mathbf{z}_0 \sim p_0$, $\mathbf{z}_\ell = f_\ell(\mathbf{z}_{\ell-1})$, $\mathbf{x} = \mathbf{z}_L$. 先写 $\log p_{\boldsymbol{\theta}}(\mathbf{x}) = \log p_0(\mathbf{z}_0) - \sum_{\ell=1}^L \log \left| \det \frac{\partial f_\ell(\mathbf{z}_{\ell-1})}{\partial \mathbf{z}_{\ell-1}} \right|$. 再写数据集上的 NLL: $\mathcal{L}(\boldsymbol{\theta}) = -\frac{1}{N} \sum_{i=1}^N \log p_{\boldsymbol{\theta}}(\mathbf{x}^{(i)})$. 完全展开为 $\mathcal{L} = \frac{1}{N} \sum_i \left[-\log p_0(\mathbf{z}_0^{(i)}) + \sum_{\ell=1}^L \log \left| \det \mathbf{J}_{f_\ell}(\mathbf{z}_{\ell-1}^{(i)}) \right| \right]$. 最后说明: $\mathbf{z}_0^{(i)} = f_1^{-1} \circ \dots \circ f_L^{-1}(\mathbf{x}^{(i)})$. 若只写“最小化负 log-likelihood”而没有 Jacobian 项, 不能获得主要推导分。

24.6 Affine Coupling Layer

将输入拆分为 $\mathbf{x} = (\mathbf{x}_A, \mathbf{x}_B)$, $\mathbf{x}_A \in \mathbb{R}^{d_A}$, $\mathbf{x}_B \in \mathbb{R}^{d_B}$. Affine coupling 定义为

$$\mathbf{y}_A = \mathbf{x}_A, \quad (24.15)$$

$$\mathbf{y}_B = \mathbf{x}_B \odot \exp(\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_A)) + \mathbf{t}_{\boldsymbol{\theta}}(\mathbf{x}_A), \quad (24.16)$$

其中 $\mathbf{s}_{\boldsymbol{\theta}}, \mathbf{t}_{\boldsymbol{\theta}}: \mathbb{R}^{d_A} \rightarrow \mathbb{R}^{d_B}$.


由于使用 $\exp(\mathbf{s}) > 0$, 变换可逆:

$$\mathbf{x}_A = \mathbf{y}_A, \quad (24.17)$$

$$\mathbf{x}_B = [\mathbf{y}_B - \mathbf{t}_{\boldsymbol{\theta}}(\mathbf{y}_A)] \odot \exp(-\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{y}_A)). \quad (24.18)$$

其 Jacobian 为块三角矩阵:

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \mathbf{I}_{d_A} & \mathbf{0} \\ * & \text{diag}(e^{\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_A)}) \end{bmatrix}. \quad (24.19)$$



所以

$$\det \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \prod_{j=1}^{d_B} e^{s_j(\mathbf{x}_A)}, \quad (24.20)$$

$$\log \left| \det \frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right| = \sum_{j=1}^{d_B} s_j(\mathbf{x}_A). \quad (24.21)$$

易错点、反例与失败模式

Coupling layer 中 $\mathbf{s}_\theta$ 和 $\mathbf{t}_\theta$ 本身不需要是可逆网络。整体变换的可逆性来自： $\mathbf{y}_A = \mathbf{x}_A$ 以及给定 $\mathbf{x}_A$ 后对 $\mathbf{x}_B$ 的可逆仿射变换。

为避免 e^{s_j} 过大或过小造成数值不稳定，实践中常对 s_j 做有界化或缩放。

单个 coupling layer 中， $\mathbf{x}_A$ 本身不被改变。若每层始终使用相同拆分，则部分坐标无法充分交互。因此层间需要：permutation、channel shuffle 或可逆线性变换。

24.7 Jacobian 复杂度

一般稠密 $d \times d$ Jacobian 的 determinant 计算为 $O(d^3)$ 。常见结构的复杂度为：

表 24.1: Flow 变换的 inverse 与 determinant 复杂度

结构	Inverse	Log-determinant	说明
一般稠密线性层	$O(d^3)$	$O(d^3)$	直接矩阵求逆和 determinant。
对角线性层	$O(d)$	$O(d)$	表达能力有限。
三角线性层	$O(d^2)$	$O(d)$	determinant 为对角线乘积。
LU 参数化	$O(d^2)$	$O(d)$	利用三角结构计算 inverse 与 log-determinant。
Affine coupling	$O(d) + C_{s,t}$	$O(d) + C_s$	$C_{s,t}$ 是 scale/translation 网络的计算代价。

对图像张量 $\mathbf{h} \in \mathbb{R}^{C \times H \times W}$ 使用可逆 1×1 卷积 $\mathbf{y}_{:,u,v} = \mathbf{W} \mathbf{h}_{:,u,v}$, $\mathbf{W} \in \mathbb{R}^{C \times C}$, 整体 log-determinant 为

$$\log |\det \mathbf{J}| = HW \log |\det \mathbf{W}|. \quad (24.22)$$

若 $\mathbf{W}$ 使用 LU 分解，可将 determinant 计算由 $O(C^3)$ 降为对角项求和的 $O(C)$ ，矩阵应用本身仍约为 $O(HWC^2)$ 。

24.8 离散图像的去量化

图像像素通常是离散值： $\mathbf{Y} \in \{0, \dots, K-1\}^d$ 。而 flow 定义连续密度 $p_\theta(\mathbf{x})$ 。若直接把离散点当作连续样本，模型可能试图在离散格点上形成无限尖锐密度，产生奇异性和不可比 likelihood。

令 $\mathbf{U} \sim \text{Unif}([0, 1]^d)$ ， $\mathbf{X} = \mathbf{Y} + \mathbf{U}$ 。连续密度诱导的离散概率质量为

$$P_\theta(\mathbf{Y} = \mathbf{y}) = \int_{[0, 1]^d} p_\theta(\mathbf{y} + \mathbf{u}) d\mathbf{u}. \quad (24.23)$$

由于 $[0, 1]^d$ 体积为 1，可写成 $P_\theta(\mathbf{y}) = \mathbb{E}_{\mathbf{U}}[p_\theta(\mathbf{y} + \mathbf{U})]$ 。Jensen 不等式给出

$$\log P_\theta(\mathbf{y}) \geq \mathbb{E}_{\mathbf{U}}[\log p_\theta(\mathbf{y} + \mathbf{U})]. \quad (24.24)$$

因此在均匀噪声后的连续样本上最大化 log-density，是在最大化离散 log-likelihood 的一个下界。

易错点、反例与失败模式

去量化不是普通数据增强。它解决的是：离散数据 与 连续密度模型 之间的测度不匹配。训练和报告 bits-per-dimension 时，必须说明是否去量化、像素缩放以及使用的对数底数。

24.9 Normalizing Flow 的优点与失败模式

优点：

- 精确 log-likelihood；
- 精确 latent inference： $\mathbf{z} = G^{-1}(\mathbf{x})$ ；
- 从 base distribution 到数据的直接采样；
- 没有 VAE 的变分后验 gap；
- 没有 GAN 的判别器-生成器博弈。

局限：

1. **可逆性限制**。普通降维 bottleneck、任意 pooling 和不可逆激活不能直接使用。
2. **同维限制**。标准 flow 要求 $d_z = d_x$ 。
3. **Jacobian 结构限制**。为获得高效 determinant，网络连接方式受到约束。
4. **低概率区域建模困难**。附件比较图指出 Glow 在某些多峰或低概率连接区域上可能产生非期望密度桥接。连续双射的拓扑结构会限制对严格不连通支撑的精确表示。
5. **Likelihood 与视觉质量不一致**。高平均 log-likelihood 不自动保证感知质量、语义一致性或下游任务性能最好。
6. **数值尺度问题**。多层 $\sum_\ell \log |\det \mathbf{J}_\ell|$ 可能产生极大正负值；scale 网络和矩阵条件数需要控制。

24.10 连续时间 Flow 的桥接

附件进一步给出连续时间 normalizing flow：

$$\frac{d\mathbf{z}_t}{dt} = \mathbf{v}_\theta(t, \mathbf{z}_t). \quad (24.25)$$



沿粒子轨迹的瞬时变量替换公式为

$$\frac{d}{dt} \log p_t(\mathbf{z}_t) = -\nabla_{\mathbf{z}} \cdot \mathbf{v}_{\theta}(t, \mathbf{z}_t) = -\text{tr} \left(\frac{\partial \mathbf{v}_{\theta}}{\partial \mathbf{z}} \right). \quad (24.26)$$

积分得到

$$\log p_1(\mathbf{z}_1) = \log p_0(\mathbf{z}_0) - \int_0^1 \nabla \cdot \mathbf{v}_{\theta}(t, \mathbf{z}_t) dt. \quad (24.27)$$

连续时间 flow、continuity equation、flow matching 和 probability-flow ODE 将在下一部分统一推导，本节不重复展开。



第二十五章 生成模型比较、真题映射与速查

25.1 训练目标与推理性质总表

表 25.1: 自回归、GAN、VAE 与 Flow 比较

模型	训练目标	Likelihood/采样	主要失败模式
自回归模型	$-\sum_t \log p_\theta(x_t x_{<t})$	Likelihood 精确; 训练可并行计算条件项; 采样严格顺序。	Exposure bias; 长序列采样慢; 局部错误累积; 上下文长度限制。
原始 GAN	$\min_G \max_D \mathbb{E}_{p_d} \log D + \mathbb{E}_{p_z} \log(1 - D(G(z)))$	通常无显式密度; 生成器一次前向即可采样。	Mode collapse; minimax 循环; 梯度消失; 训练不稳定。
VAE	$-\mathbb{E}_q \log p_\theta(x z) + \text{KL}(q_\phi(z x) \ p(z))$	优化 likelihood 下界; 采样可并行; 有 encoder。	Variational gap; posterior collapse; Gaussian/MSE 导致模糊; 先验错配。
Normalizing flow	$-\log p_0(z_0) + \sum_\ell \log \det J_{f_\ell} $	Likelihood 精确; inverse inference 精确; 采样通常高效。	可逆性和同维限制; Jacobian 代价; 拓扑限制; 数值条件问题。

25.2 相近目标函数的区别

易错点、反例与失败模式

1. 最大似然的数据级 KL: $\text{KL}(p_{\text{data}} \| p_\theta)$.
2. VAE 的先验正则 KL: $\text{KL}(q_\phi(z | x) \| p(z))$.
3. VAE 的 ELBO gap: $\text{KL}(q_\phi(z | x) \| p_\theta(z | x))$.
4. 原始 GAN 的理想化目标: $\text{JS}(p_{\text{data}} \| p_g)$.
5. WGAN: $W_1(p_{\text{data}}, p_g)$.
6. Normalizing flow: 直接计算 $-\log p_\theta(x)$, 其中 Jacobian 项不能省略。

这些量的方向、定义域、是否可计算和训练含义均不同。

25.3 历年真题映射



表 25.2: 第 8 部分真题映射

题目	主要标签	满分所需内容
[25F-B-Q2(a), 2 分]	MLE、forward KL	KL 标准定义；关于 θ 的常数项；经验 log-likelihood。不得写反 KL 方向。
[25F-B-Q2(b), 4 分]	Normalizing flow	复合可逆映射；forward/inverse Jacobian；log-determinant 符号；数据集平均 NLL。
[25F-B-Q2(c), 4 分]	VAE、ELBO	潜变量联合分布；变分后验；Jensen；重构项与先验 KL；ELBO gap。
[25F-B-Q2(d), 4 分]	Diffusion、层次 VAE	前向链、反向链和逐时刻 KL 分解。完整推导放在第 9/18 部分。
[25S-B-Q2, 15 分]	Score-based diffusion	Reverse-time SDE、conditional score、denoising score matching 和 VP SDE。放在第 9/18 部分。
[26S-B-Q2, 15 分]	Flow matching、连续性方程	条件速度、marginal velocity、回归最优性、Fokker-Planck 和 score matching。放在第 9/18 部分。

25.4 资格考试答题总模板

答题方法

看到生成模型题时，按以下顺序组织答案：

1. 先判断模型是否有显式密度。

AR/Flow：精确密度； VAE：边缘密度不可积，使用下界； GAN：通常为隐式密度。

2. 写随机变量和维度。 $x \in \mathbb{R}^{d_x}$, $z \in \mathbb{R}^{d_z}$ 。

3. 写概率分解。自回归写条件乘积；VAE 写 $p(x, z) = p(z)p_\theta(x | z)$ ；flow 写 $x = f_L \circ \dots \circ f_1(z_0)$ 。

4. 写训练目标。必须指出期望相对于哪个分布，KL 的方向是什么，loss 是最大化还是最小化。

5. 写采样过程。不得只写训练公式。

6. 写复杂度主项。自回归说明顺序生成；flow 说明 inverse/log-det；GAN 说明交替更新；VAE 说明 encoder-sample-decoder。

7. 写失败模式和条件。不得只写模型优点。

25.5 快速自测



快速自测

1. 最大似然对应 $KL(p_{\text{data}} \| p_{\theta})$ 还是反方向? 为什么?
2. 若模型在某个正数据概率区域给出零密度, forward KL 和 NLL 会发生什么?
3. 连续 density 为什么可以大于 1?
4. 自回归链式分解本身是近似还是恒等式? 近似实际来自哪里?
5. Teacher forcing 在训练阶段使用真实前缀还是模型生成前缀?
6. Teacher forcing 是否能使普通 RNN 的隐藏状态递推完全并行?
7. Exposure bias 与“最大似然公式错误”有何区别?
8. KV cache 缓存哪些张量? 其空间复杂度如何随序列长度增长?
9. 固定生成器时, GAN 的最优判别器是什么?
10. 将最优判别器代回后, 原始 GAN 目标与哪一个散度有关?
11. 为什么 non-saturating generator loss 在 $D(G(z)) \approx 0$ 时梯度更强?
12. 双线性博弈 $\min_x \max_y xy$ 为什么会产生循环而非收敛?
13. Mode collapse 与简单的低样本质量有什么区别?
14. VAE 的边缘似然为什么通常不能直接计算?
15. 写出 ELBO, 并明确其中两个 KL 分别出现在哪里。
16. 什么时候 ELBO 等于真实 log-likelihood?
17. Gaussian decoder 的重构项为什么等价于平方误差? 该结论依赖什么方差假设?
18. 若 encoder 输出 $a = \log \sigma^2$, Gaussian KL 应如何写?
19. 重参数化 $z = \mu + \sigma \odot \varepsilon$ 为什么允许梯度传播到 encoder?
20. 无条件生成时, VAE 应从 $q_{\phi}(z | x)$ 还是从 $p(z)$ 采样?
21. 变量替换公式中, 使用 forward Jacobian 时 log-determinant 前面的符号是什么?
22. Normalizing flow 为什么通常要求 $d_z = d_x$?
23. Affine coupling 中的 $s(\cdot), t(\cdot)$ 本身是否必须可逆?
24. 为什么 coupling layers 之间需要 permutation 或 channel mixing?
25. 离散图像训练连续 flow 前为什么要去量化?
26. AR、GAN、VAE 和 flow 中, 哪些具有精确 likelihood, 哪些只有下界, 哪些通常没有可计算 likelihood?

第二十六章 离散时间扩散模型：DDPM 与层次 VAE

26.1 重要性等级与历年实考定位

重要性等级：S


- [25F-B-Q2(d), 4 分] 直接要求：
 1. 写出 diffusion 的反向概率模型；
 2. 将整个模型解释为层次 VAE；
 3. 从统一 ELBO 展开出 terminal prior KL、逐步 denoising KL 和 reconstruction 项。
- [25S-B-Q2, 15 分] 进一步考查其连续时间极限：reverse-time SDE、score matching 和 VP SDE 的条件 Gaussian。
- DDPM、score-based diffusion 与 flow matching 连续三套博资考试卷均有高分题，因而属于 B 方向的核心 S 级母题。
- 本章要求：
 - 前向闭式分布必须会完整推导；
 - 后验 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 必须会通过 Gaussian completion 推导；
 - ELBO 分解必须会完整写出；
 - noise prediction 与 score prediction 的换算必须无符号错误；
 - 训练与采样的复杂度必须区分。

26.2 统一记号与概率设定

设数据维度为 d ，原始数据为 $\mathbf{X}_0 \in \mathbb{R}^d$ ， $\mathbf{X}_0 \sim q_0 = p_{\text{data}}$ 。离散扩散时间为 $t \in \{1, \dots, T\}$ 。全文采用：

$$\beta_t \in (0, 1), \quad \alpha_t := 1 - \beta_t, \quad \bar{\alpha}_t := \prod_{s=1}^t \alpha_s, \quad \bar{\alpha}_0 := 1. \quad (26.1)$$

注意以下三个量不能混淆： α_t = 第 t 步信号保留系数， $\bar{\alpha}_t$ = 从 0 到 t 的累计信号保留系数， $1 - \bar{\alpha}_t$ = 从 0 到 t 的累计噪声方差。



为避免与连续时间中的函数混淆，后文有时记

$$a_t := \sqrt{\bar{\alpha}_t}, \quad b_t := \sqrt{1 - \bar{\alpha}_t}, \quad a_t^2 + b_t^2 = 1. \quad (26.2)$$

26.3 固定前向加噪过程

DDPM 的前向过程是固定而不学习的 Markov chain:

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}), \quad (26.3)$$

其中

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}_d). \quad (26.4)$$

等价的重参数化为

$$\mathbf{X}_t = \sqrt{\alpha_t} \mathbf{X}_{t-1} + \sqrt{\beta_t} \boldsymbol{\varepsilon}_t, \quad \boldsymbol{\varepsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d), \quad (26.5)$$

其中各 $\boldsymbol{\varepsilon}_t$ 独立。

定理 26.1 (前向过程的闭式边缘分布). 对任意 $t \in \{1, \dots, T\}$, 有

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}_d). \quad (26.6)$$

因此可直接采样

$$\mathbf{X}_t = \sqrt{\bar{\alpha}_t} \mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d). \quad (26.7)$$

证明. 对 $t = 1$, 由 $\bar{\alpha}_1 = \alpha_1$, $1 - \bar{\alpha}_1 = \beta_1$ 可知结论成立。

假设在 $t - 1$ 时成立, 即 $\mathbf{X}_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \mathbf{X}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \boldsymbol{\varepsilon}_{t-1}$, 其中 $\boldsymbol{\varepsilon}_{t-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ 。代入一步转移:

$$\begin{aligned} \mathbf{X}_t &= \sqrt{\alpha_t} \mathbf{X}_{t-1} + \sqrt{\beta_t} \boldsymbol{\varepsilon}_t \\ &= \sqrt{\alpha_t \bar{\alpha}_{t-1}} \mathbf{X}_0 + \sqrt{\alpha_t (1 - \bar{\alpha}_{t-1})} \boldsymbol{\varepsilon}_{t-1} + \sqrt{\beta_t} \boldsymbol{\varepsilon}_t \\ &= \sqrt{\bar{\alpha}_t} \mathbf{X}_0 + \boldsymbol{\eta}_t, \end{aligned} \quad (26.8)$$

其中两个噪声项独立, 故 $\boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, [\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t] \mathbf{I}_d)$ 。注意

$$\begin{aligned} \alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t &= \alpha_t - \alpha_t \bar{\alpha}_{t-1} + (1 - \alpha_t) \\ &= 1 - \bar{\alpha}_t. \end{aligned} \quad (26.9)$$


所以 $\boldsymbol{\eta}_t \stackrel{d}{=} \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}$, $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, 完成归纳。□

26.3.1 为什么闭式采样极其重要

若训练时先从 $\mathbf{x}_0 \sim p_{\text{data}}$ 采样, 再随机选取某个 t , 则无需依次模拟 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_t$ 。由式 (26.7), 只需一次 Gaussian noise injection: $\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}$ 。

因此:

- 训练一个随机时间步只需一次 denoising network 前向;
- 训练复杂度不随 T 线性增长;
- 推理仍须从 T 到 0 逐步执行, 二者不能混淆。



26.3.2 终端分布只是近似标准正态

若噪声 schedule 使 $\bar{\alpha}_T \approx 0$, 则 $q(\mathbf{x}_T | \mathbf{x}_0) \approx \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ 。但对有限 T , 一般并非严格等号: $q(\mathbf{x}_T | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_T} \mathbf{x}_0, (1 - \bar{\alpha}_T) \mathbf{I}_d)$ 。因此选择 $p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ 会产生 terminal prior mismatch, 其大小由 $\text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T))$ 度量。

易错点、反例与失败模式

“经过有限步扩散后, $\mathbf{X}_T$ 严格服从标准正态”通常是错误说法。

正确说法是: 若 $\bar{\alpha}_T$ 足够小, 则条件分布和边缘分布均接近标准正态。

26.4 可解析的反向后验

真正的单步反向条件 $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 需要对未知数据分布积分, 通常不可计算。但在给定原始数据 $\mathbf{x}_0$ 后, $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 是可解析 Gaussian。

定理 26.2 (DDPM 的条件后验). 对 $t \geq 2$, 有

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I}_d), \quad (26.10)$$

其中

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t, \quad (26.11)$$

且

$$\tilde{\boldsymbol{\mu}}_t = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\bar{\alpha}_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t. \quad (26.12)$$

证明. 根据 Bayes 公式和前向 Markov 性,

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \propto q(\mathbf{x}_t | \mathbf{x}_{t-1}) q(\mathbf{x}_{t-1} | \mathbf{x}_0). \quad (26.13)$$

由式 (26.4) 和式 (26.6), 忽略与 $\mathbf{x}_{t-1}$ 无关的常数, 有

$$\begin{aligned} \log q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) &= -\frac{1}{2\beta_t} \|\mathbf{x}_t - \sqrt{\bar{\alpha}_t} \mathbf{x}_{t-1}\|_2^2 \\ &\quad - \frac{1}{2(1 - \bar{\alpha}_{t-1})} \|\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0\|_2^2 + C. \end{aligned} \quad (26.14)$$

二次项系数为

$$\begin{aligned} \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} &= \frac{\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t}{\beta_t(1 - \bar{\alpha}_{t-1})} \\ &= \frac{1 - \bar{\alpha}_t}{\beta_t(1 - \bar{\alpha}_{t-1})}. \end{aligned} \quad (26.15)$$

故协方差为其倒数: $\tilde{\beta}_t \mathbf{I}_d = \frac{\beta_t(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{I}_d$ 。

关于 $\mathbf{x}_{t-1}$ 的线性项为 $\left\langle \frac{\sqrt{\bar{\alpha}_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0, \mathbf{x}_{t-1} \right\rangle$ 。将其乘以协方差, 得到均值:

$$\begin{aligned} \tilde{\boldsymbol{\mu}}_t &= \tilde{\beta}_t \left[\frac{\sqrt{\bar{\alpha}_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right] \\ &= \frac{\sqrt{\bar{\alpha}_t} (1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0. \end{aligned} \quad (26.16)$$

□



26.4.1 后验均值的噪声形式

由 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}$ 可解出

$$\mathbf{x}_0 = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}}{\sqrt{\bar{\alpha}_t}}. \quad (26.17)$$

代入式 (26.12), 整理得

$$\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\bar{\alpha}_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right). \quad (26.18)$$

这一形式直接导出 noise-prediction parameterization。

26.5 学习的反向生成模型

DDPM 定义生成模型

$$p_{\boldsymbol{\theta}}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1} | \mathbf{x}_t), \quad (26.19)$$

其中

$$p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I}_d), \quad (26.20)$$

且通常采用 Gaussian reverse transition:

$$p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)). \quad (26.21)$$

常见简化是 $\boldsymbol{\Sigma}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I}_d$, 其中 σ_t^2 :

- 可以固定为 β_t ;
- 可以固定为 $\tilde{\beta}_t$;
- 也可以在受约束参数化下学习。

网络输入、输出维度为 $(\mathbf{x}_t, t) \in \mathbb{R}^d \times \{1, \dots, T\}$, $\boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) \in \mathbb{R}^d$ 或 $\boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) \in \mathbb{R}^d$ 。时间 t 通常先映射为 time embedding, 再注入 U-Net 或 Transformer。


26.6 DDPM 作为层次 VAE

将 $\mathbf{z} = (\mathbf{x}_1, \dots, \mathbf{x}_T)$ 视作多层潜变量, 则:

- 固定前向扩散 $q(\mathbf{x}_{1:T} | \mathbf{x}_0)$ 相当于 encoder;
- 反向链 $p_{\boldsymbol{\theta}}(\mathbf{x}_{0:T})$ 相当于 decoder/generative model;
- 训练可由统一的变分下界推导。

定理 26.3 (DDPM 的 ELBO 分解). 对固定数据 $\mathbf{x}_0$, 有

$$\begin{aligned} \log p_{\boldsymbol{\theta}}(\mathbf{x}_0) &\geq -\text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)) \\ &\quad - \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t | \mathbf{x}_0)} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1} | \mathbf{x}_t))] \\ &\quad + \mathbb{E}_{q(\mathbf{x}_1 | \mathbf{x}_0)} [\log p_{\boldsymbol{\theta}}(\mathbf{x}_0 | \mathbf{x}_1)]. \end{aligned} \quad (26.22)$$



证明. 首先使用任意变分分布的标准 ELBO:

$$\begin{aligned}\log p_{\theta}(\mathbf{x}_0) &= \log \int p_{\theta}(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T} \\ &= \log \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \\ &\geq \mathbb{E}_q \left[\log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right].\end{aligned}\quad (26.23)$$

前向 Markov chain 在给定 $\mathbf{x}_0$ 后可反向分解为

$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) = q(\mathbf{x}_T|\mathbf{x}_0) \prod_{t=2}^T q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0). \quad (26.24)$$

该式来自 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \dots, \mathbf{x}_T, \mathbf{x}_0) = q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$, 即前向 Markov 条件独立性。

代入式 (26.19) 和式 (26.24):

$$\begin{aligned}\mathcal{L}_{\text{DDPM}} &= \mathbb{E}_q \left[\log p(\mathbf{x}_T) - \log q(\mathbf{x}_T|\mathbf{x}_0) \right. \\ &\quad \left. + \sum_{t=2}^T (\log p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) - \log q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)) \right. \\ &\quad \left. + \log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1) \right].\end{aligned}\quad (26.25)$$

第一项是负 terminal KL; 中间每一项是负 conditional KL; 最后一项是 reconstruction log-likelihood, 从而得到式 (26.22)。□

通常将负 ELBO 写成

$$\mathcal{J}_{\text{VLB}} = L_T + \sum_{t=2}^T L_{t-1} + L_0, \quad (26.26)$$

其中

$$L_T = \text{KL}(q(\mathbf{x}_T|\mathbf{x}_0)\|p(\mathbf{x}_T)), \quad (26.27)$$

$$L_{t-1} = \mathbb{E}_q \text{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)\|p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)), \quad (26.28)$$

$$L_0 = -\mathbb{E}_q \log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1). \quad (26.29)$$

易错点、反例与失败模式

1. ELBO 是 $\log p_{\theta}(\mathbf{x}_0) \geq \mathcal{L}$, 而 negative ELBO 才是要最小化的损失。
2. terminal KL 的方向为 $\text{KL}(q(\mathbf{x}_T|\mathbf{x}_0)\|p(\mathbf{x}_T))$.
3. denoising KL 的第一项是可解析的真实条件后验 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$, 不是不可计算的 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$.
4. reconstruction 项是 $\log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1)$, 不应错误写成 $\log p_{\theta}(\mathbf{x}_1|\mathbf{x}_0)$.

26.7 从 Gaussian KL 到噪声预测

假设 $p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I}_d)$ ，并令模型均值参数化为

$$\boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\varepsilon}_{\theta}(\mathbf{x}_t, t) \right). \quad (26.30)$$

由于真实后验均值为式 (26.18)，当两个 Gaussian 的协方差固定时，KL 关于参数的部分为

$$\begin{aligned} L_{t-1} &= \mathbb{E} \left[\frac{1}{2\sigma_t^2} \|\tilde{\boldsymbol{\mu}}_t - \boldsymbol{\mu}_{\theta}\|_2^2 \right] + C_t \\ &= \mathbb{E}_{\mathbf{x}_0, \boldsymbol{\varepsilon}} \left[\lambda_t \|\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}_{\theta}(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, t)\|_2^2 \right] + C_t, \end{aligned} \quad (26.31)$$

其中

$$\lambda_t = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}. \quad (26.32)$$

原始 DDPM 实践中常使用简化损失

$$\mathcal{L}_{\text{simple}}(\boldsymbol{\theta}) = \mathbb{E}_{\substack{\mathbf{x}_0 \sim p_{\text{data}}, \\ t \sim \text{Unif}\{1, \dots, T\}, \\ \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)}} \left[\|\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}_{\theta}(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, t)\|_2^2 \right]. \quad (26.33)$$

易错点、反例与失败模式

将所有 λ_t 直接设为 1 后，目标与严格的原始 ELBO 权重不再完全相同。

正确表述是： $\mathcal{L}_{\text{simple}}$ 是由 variational objective 导出的重加权噪声回归目标，实践中通常更稳定，但不能无条件称为“与精确 ELBO 完全相等”。

26.8 四种常见预测参数化

令 $a_t = \sqrt{\alpha_t}$ ， $b_t = \sqrt{1 - \bar{\alpha}_t}$ ，则 $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \boldsymbol{\varepsilon}$ 。

26.8.1 Noise prediction

网络预测 $\hat{\boldsymbol{\varepsilon}} = \boldsymbol{\varepsilon}_{\theta}(\mathbf{x}_t, t)$ 。由此恢复

$$\hat{\mathbf{x}}_0 = \frac{\mathbf{x}_t - b_t \hat{\boldsymbol{\varepsilon}}}{a_t}. \quad (26.34)$$


26.8.2 Score prediction

条件 score 为

$$\begin{aligned} \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t | \mathbf{x}_0) &= -\frac{\mathbf{x}_t - a_t \mathbf{x}_0}{b_t^2} \\ &= -\frac{\boldsymbol{\varepsilon}}{b_t}. \end{aligned} \quad (26.35)$$

因此网络之间的换算为

$$\mathbf{s}_{\theta}(\mathbf{x}_t, t) = -\frac{\boldsymbol{\varepsilon}_{\theta}(\mathbf{x}_t, t)}{\sqrt{1 - \bar{\alpha}_t}}. \quad (26.36)$$



严格地说，给定 $\mathbf{x}_t$ 的平方损失最优噪声预测器是 $\boldsymbol{\varepsilon}_\theta^*(\mathbf{x}_t, t) = \mathbb{E}[\boldsymbol{\varepsilon} \mid \mathbf{X}_t = \mathbf{x}_t]$ 。于是

$$\begin{aligned} -\frac{1}{b_t} \boldsymbol{\varepsilon}_\theta^*(\mathbf{x}_t, t) &= \mathbb{E} \left[-\frac{\boldsymbol{\varepsilon}}{b_t} \mid \mathbf{X}_t = \mathbf{x}_t \right] \\ &= \nabla_{\mathbf{x}_t} \log q_t(\mathbf{x}_t), \end{aligned} \quad (26.37)$$

即恢复边缘 score。

26.8.3 Data prediction

网络直接预测 $\hat{\mathbf{x}}_0 = \mathbf{x}_\theta(\mathbf{x}_t, t)$ 。相应噪声为

$$\hat{\boldsymbol{\varepsilon}} = \frac{\mathbf{x}_t - a_t \hat{\mathbf{x}}_0}{b_t}. \quad (26.38)$$

当 a_t 很小时，式 (26.34) 中的除法可能放大预测误差；不同参数化在不同信噪比区域的数值条件不同。

26.8.4 Velocity prediction

定义

$$\mathbf{v}_t = a_t \boldsymbol{\varepsilon} - b_t \mathbf{x}_0. \quad (26.39)$$

由于 $\begin{bmatrix} \mathbf{x}_t \\ \mathbf{v}_t \end{bmatrix} = \begin{bmatrix} a_t & b_t \\ -b_t & a_t \end{bmatrix} \begin{bmatrix} \mathbf{x}_0 \\ \boldsymbol{\varepsilon} \end{bmatrix}$ ，且该矩阵正交，故

$$\mathbf{x}_0 = a_t \mathbf{x}_t - b_t \mathbf{v}_t, \quad (26.40)$$

$$\boldsymbol{\varepsilon} = b_t \mathbf{x}_t + a_t \mathbf{v}_t. \quad (26.41)$$

易错点、反例与失败模式

Noise prediction、score prediction、data prediction 和 velocity prediction 不是四个完全不同的生成模型。

在固定 noise schedule 下，它们是同一中间状态 $\mathbf{x}_t = a_t \mathbf{x}_0 + b_t \boldsymbol{\varepsilon}$ 的不同可逆参数化；但训练权重、数值稳定性和误差分布可能不同。

26.9 DDPM 的训练算法与采样算法

答题方法

DDPM 训练：

1. 采样数据 $\mathbf{x}_0 \sim p_{\text{data}}$.
2. 采样时间 $t \sim \text{Unif}\{1, \dots, T\}$.
3. 采样噪声 $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$.
4. 构造 $\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \boldsymbol{\varepsilon}$.
5. 最小化 $\|\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}_\theta(\mathbf{x}_t, t)\|_2^2$ 或带权版本。

DDPM 采样：1. 初始化 $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$.2. 对 $t = T, T-1, \dots, 1$:

$$\mathbf{z}_t \sim \begin{cases} \mathcal{N}(\mathbf{0}, \mathbf{I}_d), & t > 1, \\ \mathbf{0}, & t = 1, \end{cases}$$

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\varepsilon}_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}_t.$$

3. 输出 $\mathbf{x}_0$.

设一次 denoising network evaluation 的代价为 C_{net} 。则：

$$\text{单个训练样本的主要代价} = O(C_{\text{net}}), \quad (26.42)$$

$$\text{生成一个样本的主要代价} = O(TC_{\text{net}}). \quad (26.43)$$

训练时不需要保存全部前向扩散轨迹；标准采样也只需要保存当前状态，但必须顺序执行 T 次网络调用。

26.10 与普通 VAE 的区别

表 26.1: VAE 与 DDPM 的结构区别

比较项	普通 VAE	DDPM
Encoder	学习 $q_{\phi}(\mathbf{z} \mathbf{x})$	固定 Gaussian noising chain $q(\mathbf{x}_{1:T} \mathbf{x}_0)$
潜变量维度	通常低于数据维度	每个 $\mathbf{x}_t$ 通常与数据同维
潜变量层数	单层或少量层级	T 层 Markov latent chain
主要训练项	重构 log-likelihood 加 prior KL	terminal KL、逐步 denoising KL、reconstruction
Encoder collapse	可能出现 posterior collapse	没有学习 encoder，因而避免普通 learned-encoder collapse 机制
采样	通常一次或少量 decoder 前向	从 T 到 0 多步顺序去噪

答题方法

[25F-B-Q2(d), 4 分] 的满分答题顺序：

1. 写前向 encoder: $q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})$.

2. 写反向 decoder: $p_{\theta}(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)$, $p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\theta}(\mathbf{x}_t, t))$.

3. 写统一 ELBO: $\log p_{\theta}(\mathbf{x}_0) \geq \mathbb{E}_q \left[\log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right]$.

4. 使用反向分解 $q(\mathbf{x}_{1:T} | \mathbf{x}_0) = q(\mathbf{x}_T | \mathbf{x}_0) \prod_{t=2}^T q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$.

5. 展开为 $-\text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)) - \sum_{t=2}^T \mathbb{E}_q \text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t)) + \mathbb{E}_q \log p_{\theta}(\mathbf{x}_0 | \mathbf{x}_1)$.

6. 明确说明：DDPM 是潜变量 $\mathbf{z} = (\mathbf{x}_1, \dots, \mathbf{x}_T)$ 的层次 VAE。

若只写噪声预测 MSE 而未写概率模型和 ELBO 分解，不能覆盖该题的主要得分点。



第二十七章 Score Matching 与连续时间扩散 SDE

27.1 重要性等级与实考定位

重要性等级：S

- [25S-B-Q2(a), 4 分] 要求写 VP SDE 的 reverse-time SDE, 并说明为何必须学习 score。
- [25S-B-Q2(b), 6 分] 要求完整证明 marginal score matching 可转换为 conditional denoising score matching。
- [25S-B-Q2(c), 5 分] 要求求解 VP SDE 的条件分布, 并写出最终噪声训练目标。
- Reverse-time SDE 的时间方向、score 的符号、conditional score 与 marginal score 的关系, 是本方向最高频易错点之一。

27.2 一般前向 SDE

考虑状态独立且各向同性的扩散系数:

$$d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t) dt + g(t) d\mathbf{W}_t, \quad t \in [0, T], \quad (27.1)$$

其中: $\mathbf{X}_t \in \mathbb{R}^d$, $\mathbf{f}: \mathbb{R}^d \times [0, T] \rightarrow \mathbb{R}^d$ 为 drift, $g(t) \geq 0$ 为 scalar diffusion coefficient, $\mathbf{W}_t$ 是 d 维标准 Wiener process。

设 $\mathbf{X}_t$ 的边缘密度为 $p_t(\mathbf{x})$ 。

定义 27.1 (Score function). 若 $p_t(\mathbf{x}) > 0$ 且可微, 则时刻 t 的 score 为

$$\mathbf{s}_t(\mathbf{x}) := \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \in \mathbb{R}^d. \quad (27.2)$$

Score 有两个重要性质:

1. 它不依赖密度的归一化常数。若 $p(\mathbf{x}) = \frac{\tilde{p}(\mathbf{x})}{Z}$, 则 $\nabla \log p(\mathbf{x}) = \nabla \log \tilde{p}(\mathbf{x})$ 。
2. 它指向局部 log-density 增长最快方向, 但其大小和方向不等于样本到最近 mode 的欧氏位移。

27.3 Reverse-time SDE

定理 27.2 (状态独立扩散下的反向时间 SDE). 假设:



- $\mathbf{f}$ 满足 SDE 解存在与唯一性所需的正则条件;
- $g(t) > 0$;
- p_t 光滑、正且具有足够快的边界衰减。

则将原时间变量 t 从 T 向 0 积分时, 反向过程满足

$$d\mathbf{X}_t = [\mathbf{f}(\mathbf{X}_t, t) - g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{X}_t)] dt + g(t) d\overline{\mathbf{W}}_t, \quad t: T \rightarrow 0. \quad (27.3)$$

这里 $dt < 0$, $\overline{\mathbf{W}}_t$ 是反向时间 Wiener process。

若希望使用递增的新时间变量 $\tau = T - t$, $\mathbf{Y}_\tau = \mathbf{X}_{T-\tau}$, 则

$$d\mathbf{Y}_\tau = [-\mathbf{f}(\mathbf{Y}_\tau, T - \tau) + g(T - \tau)^2 \nabla_{\mathbf{y}} \log p_{T-\tau}(\mathbf{Y}_\tau)] d\tau + g(T - \tau) d\overline{\mathbf{W}}_\tau. \quad (27.4)$$

易错点、反例与失败模式

以下两种写法不能静默混合: $\mathbf{f} - g^2 \nabla \log p_t$ 配合 $t: T \rightarrow 0$, 以及 $-\mathbf{f} + g^2 \nabla \log p_{T-\tau}$ 配合 $\tau: 0 \rightarrow T$ 。

若只改时间方向而不改 drift 符号, 会得到错误的生成过程。

27.4 Variance Preserving SDE

VP SDE 为

$$d\mathbf{X}_t = -\frac{1}{2}\beta(t)\mathbf{X}_t dt + \sqrt{\beta(t)} d\mathbf{W}_t, \quad (27.5)$$

其中 $\beta(t) > 0$ 。

对应: $\mathbf{f}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}$, $g(t) = \sqrt{\beta(t)}$ 。

其反向时间 SDE 为

$$d\mathbf{X}_t = \left[-\frac{1}{2}\beta(t)\mathbf{X}_t - \beta(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{X}_t) \right] dt + \sqrt{\beta(t)} d\overline{\mathbf{W}}_t, \quad t: T \rightarrow 0. \quad (27.6)$$

由于反向 drift 中含有未知的 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$, 必须用神经网络 $\mathbf{s}_\theta(\mathbf{x}, t) \approx \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 进行估计。

这直接导出 weighted score-matching objective:

$$\mathcal{L}_{\text{score}}(\theta) = \mathbb{E}_{t \sim \rho(t)} \left[\frac{\lambda(t)}{2} \mathbb{E}_{\mathbf{X}_t \sim p_t} \left[\|\mathbf{s}_\theta(\mathbf{X}_t, t) - \nabla_{\mathbf{x}_t} \log p_t(\mathbf{X}_t)\|_2^2 \right] \right], \quad (27.7)$$

其中: $\rho(t)$ 是时间采样分布, $\lambda(t) > 0$ 是 weighting function。


27.5 VP SDE 的条件分布

定义累计噪声强度

$$B(t) := \int_0^t \beta(s) ds, \quad (27.8)$$

并记

$$a(t) := \exp\left(-\frac{1}{2}B(t)\right), \quad \sigma^2(t) := 1 - \exp(-B(t)) = 1 - a(t)^2. \quad (27.9)$$



定理 27.3 (VP SDE 的条件 Gaussian). 对固定 $\mathbf{X}_0 = \mathbf{x}_0$, 有

$$p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; a(t)\mathbf{x}_0, \sigma^2(t)\mathbf{I}_d). \quad (27.10)$$

等价地,

$$\mathbf{X}_t = a(t)\mathbf{X}_0 + \sigma(t)\boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d). \quad (27.11)$$

证明. 考虑 integrating factor $M(t) = \exp\left(\frac{1}{2}B(t)\right) = a(t)^{-1}$. 利用 Itô product rule, 因 $M(t)$ 为确定性函数,

$$\begin{aligned} d(M(t)\mathbf{X}_t) &= M(t) d\mathbf{X}_t + M'(t)\mathbf{X}_t dt \\ &= M(t) \left[-\frac{1}{2}\beta(t)\mathbf{X}_t dt + \sqrt{\beta(t)} d\mathbf{W}_t \right] + \frac{1}{2}\beta(t)M(t)\mathbf{X}_t dt \\ &= M(t)\sqrt{\beta(t)} d\mathbf{W}_t. \end{aligned} \quad (27.12)$$

积分得

$$\mathbf{X}_t = a(t)\mathbf{X}_0 + a(t) \int_0^t a(s)^{-1} \sqrt{\beta(s)} d\mathbf{W}_s. \quad (27.13)$$

随机积分是均值为零的 Gaussian, 其协方差为

$$\begin{aligned} a(t)^2 \int_0^t a(s)^{-2} \beta(s) ds \mathbf{I}_d &= e^{-B(t)} \int_0^t e^{B(s)} \beta(s) ds \mathbf{I}_d \\ &= e^{-B(t)} (e^{B(t)} - 1) \mathbf{I}_d \\ &= (1 - e^{-B(t)}) \mathbf{I}_d. \end{aligned} \quad (27.14)$$

故条件均值为 $a(t)\mathbf{x}_0$, 条件协方差为 $\sigma^2(t)\mathbf{I}_d$. □

名称“variance preserving”的含义是: 若 $\mathbb{E}[\mathbf{X}_0] = \mathbf{0}$, $\text{Cov}(\mathbf{X}_0) = \mathbf{I}_d$, 则

$$\begin{aligned} \text{Cov}(\mathbf{X}_t) &= a(t)^2 \mathbf{I}_d + \sigma(t)^2 \mathbf{I}_d \\ &= \mathbf{I}_d. \end{aligned} \quad (27.15)$$

它并不意味着对任意初始数据分布, 每一个方向上的方差都自动保持不变。

27.6 条件 Score 的闭式表达

由式 (27.10),

$$\nabla_{\mathbf{x}_t} \log p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) = -\frac{\mathbf{x}_t - a(t)\mathbf{x}_0}{\sigma^2(t)}. \quad (27.16)$$

若使用式 (27.11), 则

$$\nabla_{\mathbf{x}_t} \log p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) = -\frac{\boldsymbol{\varepsilon}}{\sigma(t)}. \quad (27.17)$$

这一步是从不可计算 marginal score 转向可计算 conditional score 的关键。



27.7 Explicit Score Matching

对固定 t , 理想目标为

$$\mathcal{L}_{\text{ESM}}(\boldsymbol{\theta}; t) = \frac{1}{2} \mathbb{E}_{\mathbf{X}_t \sim p_t} \left[\|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{X}_t, t) - \nabla \log p_t(\mathbf{X}_t)\|_2^2 \right]. \quad (27.18)$$

展开为

$$\begin{aligned} \mathcal{L}_{\text{ESM}} &= \mathbb{E}_{p_t} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}\|_2^2 - \mathbf{s}_{\boldsymbol{\theta}}^\top \nabla \log p_t \right] \\ &\quad + \underbrace{\frac{1}{2} \mathbb{E}_{p_t} \|\nabla \log p_t\|_2^2}_{\text{与 } \boldsymbol{\theta} \text{ 无关}}. \end{aligned} \quad (27.19)$$

困难在于: $\nabla \log p_t$ 正是未知对象, 不能直接监督。

27.8 Implicit Score Matching

命题 27.4 (Implicit Score Matching). 假设:

- p_t 和 $\mathbf{s}_{\boldsymbol{\theta}}$ 足够光滑;
- 边界项 $p_t(\mathbf{x})\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}, t)$ 在无穷远处消失;
- 相关积分绝对可积。

则

$$\mathcal{L}_{\text{ESM}} = \mathbb{E}_{p_t} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{X}_t, t)\|_2^2 + \nabla_{\mathbf{x}} \cdot \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{X}_t, t) \right] + C_t, \quad (27.20)$$

其中 C_t 与 $\boldsymbol{\theta}$ 无关。

证明. 交叉项为

$$\begin{aligned} \mathbb{E}_{p_t} [\mathbf{s}_{\boldsymbol{\theta}}^\top \nabla \log p_t] &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}, t)^\top \nabla p_t(\mathbf{x}) d\mathbf{x} \\ &= - \int p_t(\mathbf{x}) \nabla \cdot \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}, t) d\mathbf{x}, \end{aligned} \quad (27.21)$$

其中使用分部积分并令边界项为零。代回式 (27.19) 即可。□

散度为

$$\nabla \cdot \mathbf{s}_{\boldsymbol{\theta}} = \text{tr} \left(\frac{\partial \mathbf{s}_{\boldsymbol{\theta}}}{\partial \mathbf{x}} \right). \quad (27.22)$$

在高维中直接计算完整 Jacobian 昂贵, 可使用 Hutchinson identity:

$$\text{tr}(\mathbf{A}) = \mathbb{E}_{\mathbf{v}} [\mathbf{v}^\top \mathbf{A} \mathbf{v}], \quad \mathbb{E}[\mathbf{v} \mathbf{v}^\top] = \mathbf{I}. \quad (27.23)$$

27.9 Denoising Score Matching 恒等式

令联合分布为 $p_{0,t}(\mathbf{x}_0, \mathbf{x}_t) = p_0(\mathbf{x}_0)p_{t|0}(\mathbf{x}_t | \mathbf{x}_0)$ 。

引理 27.5 (Fisher identity). 有

$$\nabla_{\mathbf{x}_t} \log p_t(\mathbf{x}_t) = \mathbb{E} \left[\nabla_{\mathbf{x}_t} \log p_{t|0}(\mathbf{x}_t | \mathbf{X}_0) \mid \mathbf{X}_t = \mathbf{x}_t \right]. \quad (27.24)$$



证明. 由 $p_t(\mathbf{x}_t) = \int p_0(\mathbf{x}_0)p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) d\mathbf{x}_0$, 在可交换微分与积分的条件下,

$$\begin{aligned}\nabla p_t(\mathbf{x}_t) &= \int p_0(\mathbf{x}_0) \nabla_{\mathbf{x}_t} p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) d\mathbf{x}_0 \\ &= \int p_0(\mathbf{x}_0) p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) \nabla_{\mathbf{x}_t} \log p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) d\mathbf{x}_0.\end{aligned}\quad (27.25)$$

除以 $p_t(\mathbf{x}_t)$:

$$\begin{aligned}\nabla \log p_t(\mathbf{x}_t) &= \int \frac{p_0(\mathbf{x}_0) p_{t|0}(\mathbf{x}_t | \mathbf{x}_0)}{p_t(\mathbf{x}_t)} \nabla \log p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) d\mathbf{x}_0 \\ &= \int p(\mathbf{x}_0 | \mathbf{x}_t) \nabla \log p_{t|0}(\mathbf{x}_t | \mathbf{x}_0) d\mathbf{x}_0.\end{aligned}\quad (27.26)$$

□

定理 27.6 (Denoising Score Matching). 对任意只依赖 $(\mathbf{x}_t, t)$ 的函数 $\mathbf{s}_\theta$, 有

$$\begin{aligned}\frac{1}{2} \mathbb{E}_{\mathbf{X}_t} \left[\|\mathbf{s}_\theta(\mathbf{X}_t, t) - \nabla \log p_t(\mathbf{X}_t)\|_2^2 \right] \\ = \frac{1}{2} \mathbb{E}_{\mathbf{X}_0, \mathbf{X}_t} \left[\|\mathbf{s}_\theta(\mathbf{X}_t, t) - \nabla \log p_{t|0}(\mathbf{X}_t | \mathbf{X}_0)\|_2^2 \right] + C_t,\end{aligned}\quad (27.27)$$

其中 C_t 与 θ 无关。

证明. 定义 $\mathbf{Y} = \nabla_{\mathbf{x}_t} \log p_{t|0}(\mathbf{X}_t | \mathbf{X}_0)$, $\mathbf{m}(\mathbf{X}_t) = \mathbb{E}[\mathbf{Y} | \mathbf{X}_t]$. 由引理 27.5, $\mathbf{m}(\mathbf{X}_t) = \nabla \log p_t(\mathbf{X}_t)$.

使用条件期望的平方损失分解:

$$\begin{aligned}\mathbb{E} [\|\mathbf{s}_\theta(\mathbf{X}_t, t) - \mathbf{Y}\|_2^2] \\ = \mathbb{E} [\|\mathbf{s}_\theta(\mathbf{X}_t, t) - \mathbf{m}(\mathbf{X}_t)\|_2^2] + \mathbb{E} [\|\mathbf{Y} - \mathbf{m}(\mathbf{X}_t)\|_2^2].\end{aligned}\quad (27.28)$$

交叉项为零, 因为

$$\begin{aligned}\mathbb{E} [\langle \mathbf{s}_\theta(\mathbf{X}_t, t) - \mathbf{m}(\mathbf{X}_t), \mathbf{Y} - \mathbf{m}(\mathbf{X}_t) \rangle] \\ = \mathbb{E} [\langle \mathbf{s}_\theta(\mathbf{X}_t, t) - \mathbf{m}(\mathbf{X}_t), \mathbb{E}[\mathbf{Y} - \mathbf{m}(\mathbf{X}_t) | \mathbf{X}_t] \rangle] = 0.\end{aligned}\quad (27.29)$$

因此 $C_t = -\frac{1}{2} \mathbb{E} [\|\mathbf{Y} - \mathbf{m}(\mathbf{X}_t)\|_2^2]$ 与参数无关。 □

说明 27.7. 题目写成 $\text{marginal loss} = \text{conditional loss} + C$ 时, 常数 C 不要求为正。在上述定义下 $C \leq 0$ 。资格考试只需说明其与 θ 无关, 但不能错误声称两个损失逐样本完全相等。

27.10 VP SDE 的最终 Denoising Loss

由式 (27.17), 可训练


$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{\substack{t \sim \rho, \\ \mathbf{x}_0 \sim p_{\text{data}}, \\ \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)}} \left[\frac{\lambda(t)}{2} \left\| \mathbf{s}_\theta(a(t)\mathbf{x}_0 + \sigma(t)\boldsymbol{\varepsilon}, t) + \frac{\boldsymbol{\varepsilon}}{\sigma(t)} \right\|_2^2 \right]. \quad (27.30)$$

若参数化

$$\mathbf{s}_\theta(\mathbf{x}_t, t) = -\frac{\boldsymbol{\varepsilon}_\theta(\mathbf{x}_t, t)}{\sigma(t)}, \quad (27.31)$$

则

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E} \left[\frac{\lambda(t)}{2\sigma(t)^2} \|\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}_\theta(a(t)\mathbf{x}_0 + \sigma(t)\boldsymbol{\varepsilon}, t)\|_2^2 \right]. \quad (27.32)$$



若选择 $\lambda(t) = \sigma(t)^2$, 则化为普通噪声 MSE:

$$\mathcal{L} = \frac{1}{2} \mathbb{E} [\|\varepsilon - \varepsilon_{\theta}(\mathbf{x}_t, t)\|_2^2]. \quad (27.33)$$

易错点、反例与失败模式

1. 条件 score 是 $-\frac{\varepsilon}{\sigma(t)}$, 不是 $-\frac{\varepsilon}{\sigma(t)^2}$. 原因是 $\mathbf{x}_t - a(t)\mathbf{x}_0 = \sigma(t)\varepsilon$.
2. 一般 score loss 与 noise MSE 之间会多出 $\sigma(t)^{-2}$ 权重; 只有选择相应 $\lambda(t)$ 才能抵消。
3. $p_t(\mathbf{x}_t)$ 是边缘分布, $p_{t|0}(\mathbf{x}_t | \mathbf{x}_0)$ 是条件分布; 二者的 score 不同, 但通过条件期望相连。

27.11 Score-based Sampling

将 $\nabla \log p_t$ 替换为网络 $\mathbf{s}_{\theta}$, VP reverse SDE 变为

$$d\mathbf{X}_t = \left[-\frac{1}{2}\beta(t)\mathbf{X}_t - \beta(t)\mathbf{s}_{\theta}(\mathbf{X}_t, t) \right] dt + \sqrt{\beta(t)} d\bar{\mathbf{W}}_t, \quad t: T \rightarrow 0. \quad (27.34)$$

Euler-Maruyama 离散化时, 若从 $t_k > t_{k-1}$ 反向走, 令 $\Delta t_k = t_{k-1} - t_k < 0$, 则

$$\begin{aligned} \mathbf{x}_{k-1} = \mathbf{x}_k + & \left[-\frac{1}{2}\beta(t_k)\mathbf{x}_k - \beta(t_k)\mathbf{s}_{\theta}(\mathbf{x}_k, t_k) \right] \Delta t_k \\ & + \sqrt{\beta(t_k)|\Delta t_k|} \mathbf{z}_k, \quad \mathbf{z}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d). \end{aligned} \quad (27.35)$$

常见失败来源:

- score 在低密度区域不准确;
- 时间离散过粗;
- 高噪声和低噪声时间段的 loss scale 不平衡;
- 终端分布与实际 p_T 不匹配;
- reverse SDE 数值误差累积;
- 训练 score 的分布与采样轨迹访问分布不一致。

答题方法

[25S-B-Q2, 15 分] 的满分框架:

(a) 4 分:

1. 写 forward VP SDE: $d\mathbf{X}_t = -\frac{1}{2}\beta(t)\mathbf{X}_t dt + \sqrt{\beta(t)}d\mathbf{W}_t$.
2. 写 reverse-time SDE: $d\mathbf{X}_t = \left[-\frac{1}{2}\beta(t)\mathbf{X}_t - \beta(t)\nabla \log p_t(\mathbf{X}_t) \right] dt + \sqrt{\beta(t)}d\bar{\mathbf{W}}_t, \quad t: T \rightarrow 0$.
3. 说明反向 drift 依赖未知 marginal score, 因而引入 $\mathbf{s}_{\theta}(\mathbf{x}, t) \approx \nabla \log p_t(\mathbf{x})$ 并用 weighted score matching 训练。

(b) 6 分:

1. 证明 $\nabla \log p_t(\mathbf{x}_t) = \mathbb{E}[\nabla \log p_{t|0}(\mathbf{x}_t | \mathbf{X}_0) | \mathbf{X}_t = \mathbf{x}_t]$.
2. 展开两个平方损失;

3. 使用 tower property 证明交叉项相同；
4. 指出剩余差值只由真实 score 的二阶矩组成，与 θ 无关。

(c) 5 分：

1. 定义 $B(t) = \int_0^t \beta(s) ds$;
2. 写 $a(t) = e^{-B(t)/2}$, $\sigma^2(t) = 1 - e^{-B(t)}$;
3. 得出 $p_{t|0} = \mathcal{N}(a(t)\mathbf{x}_0, \sigma^2(t)\mathbf{I})$;
4. 写条件 score $-\frac{\mathbf{x}_t - a(t)\mathbf{x}_0}{\sigma^2(t)} = -\frac{\boldsymbol{\varepsilon}}{\sigma(t)}$;
5. 写最终 DSM: $\mathbb{E} \left[\frac{\lambda(t)}{2} \left\| \mathbf{s}_\theta(\mathbf{x}_t, t) + \frac{\boldsymbol{\varepsilon}}{\sigma(t)} \right\|^2 \right]$.



第二十八章 Fokker–Planck 方程与 Probability-Flow ODE

28.1 历年实考扩展标记

重要性等级：S

该主题未在部分早期简要考纲中单独列出，但曾在历年人工智能博士资格考试中实际考查。
具体包括：

- [26S-B-Q2(d), 5 分]：推导指定 SDE 的 Fokker–Planck equation，并证明其与确定性 ODE 具有相同边缘分布；
- [25S-B-Q2(a), 4 分]：reverse-time SDE 的 drift 依赖 score；
- probability-flow ODE 在 [Gen] 中作为 score-based diffusion 与 continuous normalizing flow 的桥梁。

28.2 Fokker–Planck 方程

考虑 $d\mathbf{X}_t = \mathbf{b}(\mathbf{X}_t, t) dt + g(t) d\mathbf{W}_t$ 。设边缘密度为 $p_t(\mathbf{x})$ 。

定理 28.1 (各向同性扩散的 Fokker–Planck equation)。在适当正则条件下，

$$\frac{\partial p_t(\mathbf{x})}{\partial t} = -\nabla_{\mathbf{x}} \cdot [\mathbf{b}(\mathbf{x}, t)p_t(\mathbf{x})] + \frac{1}{2}g(t)^2 \Delta_{\mathbf{x}} p_t(\mathbf{x}). \quad (28.1)$$

其中： $\nabla \cdot (\mathbf{b}p) = \sum_{i=1}^d \frac{\partial}{\partial x_i} (b_i p)$, $\Delta p = \sum_{i=1}^d \frac{\partial^2 p}{\partial x_i^2}$ 。

第一项描述 drift 导致的概率输运，第二项描述 Brownian noise 导致的概率扩散。

28.3 Continuity Equation


确定性 ODE

$$\frac{d\mathbf{X}_t}{dt} = \mathbf{v}_t(\mathbf{X}_t) \quad (28.2)$$

对应密度满足

$$\partial_t p_t + \nabla \cdot (p_t \mathbf{v}_t) = 0. \quad (28.3)$$

也可写成 $\partial_t p_t = -\nabla \cdot (p_t \mathbf{v}_t)$ 。



Continuity equation 是概率质量守恒方程：对任意固定区域 Ω ，区域内概率的变化只来自边界上的 probability flux。

28.4 Probability-Flow ODE

对前向 SDE $d\mathbf{X}_t = \mathbf{f}(\mathbf{X}_t, t)dt + g(t)d\mathbf{W}_t$ ，Fokker-Planck equation 为 $\partial_t p_t = -\nabla \cdot (\mathbf{f}p_t) + \frac{1}{2}g(t)^2\Delta p_t$ 。利用

$$\nabla p_t = p_t \nabla \log p_t, \quad (28.4)$$

有

$$\begin{aligned} \Delta p_t &= \nabla \cdot (\nabla p_t) \\ &= \nabla \cdot (p_t \nabla \log p_t). \end{aligned} \quad (28.5)$$

因此

$$\begin{aligned} \partial_t p_t &= -\nabla \cdot (\mathbf{f}p_t) + \frac{1}{2}g(t)^2 \nabla \cdot (p_t \nabla \log p_t) \\ &= -\nabla \cdot \left[p_t \left(\mathbf{f} - \frac{1}{2}g(t)^2 \nabla \log p_t \right) \right]. \end{aligned} \quad (28.6)$$

定理 28.2 (Probability-Flow ODE). 定义

$$\mathbf{v}_{\text{PF}}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2}g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x}). \quad (28.7)$$

则 ODE

$$\frac{d\mathbf{X}_t}{dt} = \mathbf{v}_{\text{PF}}(\mathbf{X}_t, t) \quad (28.8)$$

与原前向 SDE 在所有时刻具有相同的边缘分布 $\{p_t\}_{t \in [0, T]}$ 。

证明. 由式 (28.6)，原 SDE 的密度满足 $\partial_t p_t = -\nabla \cdot (p_t \mathbf{v}_{\text{PF}})$ 。这正是向量场 $\mathbf{v}_{\text{PF}}$ 对应 ODE 的 continuity equation。在保证该偏微分方程解唯一的正则条件下，二者具有相同初始密度和相同密度演化方程，故所有时刻的边缘分布相同。 $\square$

使用网络 score 后，

$$\mathbf{v}_{\theta}(\mathbf{x}, t) = \mathbf{f}(\mathbf{x}, t) - \frac{1}{2}g(t)^2 \mathbf{s}_{\theta}(\mathbf{x}, t). \quad (28.9)$$

易错点、反例与失败模式

“Probability-flow ODE 与 reverse SDE 完全相同”是错误说法。

正确区分：

- 二者在 score 精确时具有相同的单时刻边缘分布；
- reverse SDE 的样本路径是随机的；
- probability-flow ODE 给定初始点后路径是确定的；
- 二者的 joint path distribution 一般不同。

28.5 VP SDE 的 Probability-Flow ODE

对 VP SDE, $\mathbf{f}(\mathbf{x}, t) = -\frac{1}{2}\beta(t)\mathbf{x}$, $g(t)^2 = \beta(t)$ 。故

$$\frac{d\mathbf{X}_t}{dt} = -\frac{1}{2}\beta(t) [\mathbf{X}_t + \nabla_{\mathbf{x}} \log p_t(\mathbf{X}_t)]. \quad (28.10)$$

网络版本为

$$\frac{d\mathbf{X}_t}{dt} = -\frac{1}{2}\beta(t) [\mathbf{X}_t + \mathbf{s}_{\theta}(\mathbf{X}_t, t)]. \quad (28.11)$$

生成时从 $\mathbf{X}_T \sim p_T \approx \mathcal{N}(\mathbf{0}, \mathbf{I})$ 向后积分到 0。

密度评估时通常从数据点 $\mathbf{x}_0$ 正向积分到 $\mathbf{x}_T$, 同时累计 log-density change。

28.6 连续变量替换与似然

对一般 ODE $\dot{\mathbf{X}}_t = \mathbf{v}_{\theta}(\mathbf{X}_t, t)$, 沿轨迹有

$$\frac{d}{dt} \log p_t(\mathbf{X}_t) = -\nabla_{\mathbf{x}} \cdot \mathbf{v}_{\theta}(\mathbf{X}_t, t). \quad (28.12)$$

积分得

$$\log p_T(\mathbf{x}_T) - \log p_0(\mathbf{x}_0) = -\int_0^T \nabla \cdot \mathbf{v}_{\theta}(\mathbf{x}_t, t) dt, \quad (28.13)$$

$$\log p_0(\mathbf{x}_0) = \log p_T(\mathbf{x}_T) + \int_0^T \nabla \cdot \mathbf{v}_{\theta}(\mathbf{x}_t, t) dt. \quad (28.14)$$

若 $p_T = \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, 则 $\log p_T(\mathbf{x}_T) = -\frac{d}{2} \log(2\pi) - \frac{1}{2} \|\mathbf{x}_T\|_2^2$ 。

散度计算为 $\nabla \cdot \mathbf{v} = \text{tr}(\frac{\partial \mathbf{v}}{\partial \mathbf{x}})$ 。使用 $\boldsymbol{\xi} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$ 或 Rademacher vector, 有

$$\nabla \cdot \mathbf{v} = \mathbb{E}_{\boldsymbol{\xi}} \left[\boldsymbol{\xi}^{\top} \frac{\partial \mathbf{v}}{\partial \mathbf{x}} \boldsymbol{\xi} \right]. \quad (28.15)$$

易错点、反例与失败模式

“Probability-flow ODE 可以精确计算 likelihood”需要区分三层含义：

1. 对由给定向量场定义连续流, 连续变量替换公式是精确的；
2. 实际 score network 只是近似真实 score, 因而其 ODE 边缘分布不必等于真实扩散边缘分布；
3. 数值 ODE solver 和 Hutchinson estimator 还会带来离散化误差与随机估计误差。

28.7 DDIM 与 ODE 采样：扩展了解

重要性等级：C

DDIM 未在三套博资考试卷中单独设置高分题，但 [Gen] 将其作为 DDPM 与 probability-flow ODE 的联系。要求掌握：

- 可使用同一已训练噪声网络；
- 可选择确定性采样；
- 采样步数可少于原 DDPM；
- 训练目标不因此自动改变。

DDIM 可视为选择与原扩散共享边缘分布的非 Markov forward process，并令反向随机方差取零，从而得到确定性更新。

但必须注意：确定性采样 $\neq$ 单步采样，仍需数值积分若干时间步。

高阶 solver 可能以更昂贵的单步换取更少的 network function evaluations，但速度提升依赖：

- score field 的平滑性；
- noise schedule；
- solver order；
- 允许的采样误差；
- classifier-free guidance scale 等实际因素。



第二十九章 Flow Matching、连续性方程与随机化流

29.1 重要性等级与实考定位

重要性等级：8

- [26S-B-Q2, 15 分] 整题围绕 Flow Matching 展开：
 - linear interpolation;
 - conditional velocity;
 - population velocity;
 - continuity equation;
 - conditional-expectation regression;
 - stochastic flow 与 Fokker–Planck equation。
- 该题是“定义—概率路径—条件期望—PDE—回归最优性—系统实现”的综合母题。
- 必须区分：conditional path 与 marginal flow, coupling 与 边缘分布, conditional velocity target 与 population velocity.

29.2 基本设定

设 base distribution 与数据分布分别为 π_0 , π_1 定义在 $\mathbb{R}^d$ 。目标是学习时变向量场 $\mathbf{v}_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$ 使 ODE

$$\frac{d\mathbf{X}_t}{dt} = \mathbf{v}_t(\mathbf{X}_t), \quad \mathbf{X}_0 \sim \pi_0, \quad (29.1)$$

在 $t = 1$ 时满足 $\mathbf{X}_1 \sim \pi_1$ 。


首先选取一个 coupling:

$$(\mathbf{X}_0, \mathbf{X}_1) \sim \gamma, \quad (29.2)$$

其中边缘分布满足

$$\gamma_0 = \pi_0, \quad \gamma_1 = \pi_1. \quad (29.3)$$

Coupling 指定“哪个 base sample 与哪个 data sample 配对”，但不改变两个端点的边缘分布。



29.3 线性插值与条件速度

定义

$$\mathbf{X}_t = (1-t)\mathbf{X}_0 + t\mathbf{X}_1, \quad t \in [0, 1]. \quad (29.4)$$

则给定 pair $(\mathbf{x}_0, \mathbf{x}_1)$ 时,

$$\mathbf{u}_t(\mathbf{X}_t | \mathbf{x}_0, \mathbf{x}_1) := \frac{d\mathbf{X}_t}{dt} = \mathbf{x}_1 - \mathbf{x}_0. \quad (29.5)$$

该速度:

- 对给定 pair 与时间 t 无关;
- 是 conditional target;
- 不是仅由当前位置 $\mathbf{X}_t$ 决定的单值函数, 因为多个 pair 可能在相同 $(t, \mathbf{x})$ 处相交。

29.4 Population Velocity

定义 marginal probability path $\pi_t = \text{Law}(\mathbf{X}_t)$ 。Population velocity 定义为

$$\mathbf{v}_t(\mathbf{x}) = \mathbb{E}_\gamma [\mathbf{X}_1 - \mathbf{X}_0 | \mathbf{X}_t = \mathbf{x}]. \quad (29.6)$$

更一般地, 若 conditional velocity 为 $\mathbf{u}_t(\mathbf{X}_t | \mathbf{X}_0, \mathbf{X}_1)$, 则

$$\mathbf{v}_t(\mathbf{x}) = \mathbb{E} [\mathbf{u}_t(\mathbf{X}_t | \mathbf{X}_0, \mathbf{X}_1) | \mathbf{X}_t = \mathbf{x}]. \quad (29.7)$$

29.5 Continuity Equation 的严格证明

定理 29.1 (条件插值诱导的 continuity equation). 假设:

- $\mathbf{X}_t$ 的边缘密度 π_t 存在;
- 可以交换时间微分与期望;
- $\mathbf{v}_t \pi_t$ 具有适当可积性和边界衰减。

则


$$\partial_t \pi_t(\mathbf{x}) + \nabla_{\mathbf{x}} \cdot [\pi_t(\mathbf{x}) \mathbf{v}_t(\mathbf{x})] = 0. \quad (29.8)$$

证明. 取任意光滑紧支撑 test function $\varphi \in C_c^\infty(\mathbb{R}^d)$ 。一方面,

$$\begin{aligned} \frac{d}{dt} \mathbb{E}[\varphi(\mathbf{X}_t)] &= \mathbb{E} \left[\nabla \varphi(\mathbf{X}_t)^\top \frac{d\mathbf{X}_t}{dt} \right] \\ &= \mathbb{E} [\nabla \varphi(\mathbf{X}_t)^\top (\mathbf{X}_1 - \mathbf{X}_0)]. \end{aligned} \quad (29.9)$$

使用条件期望,

$$\begin{aligned} \frac{d}{dt} \mathbb{E}[\varphi(\mathbf{X}_t)] &= \mathbb{E} [\nabla \varphi(\mathbf{X}_t)^\top \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 | \mathbf{X}_t]] \\ &= \mathbb{E} [\nabla \varphi(\mathbf{X}_t)^\top \mathbf{v}_t(\mathbf{X}_t)] \\ &= \int \nabla \varphi(\mathbf{x})^\top \mathbf{v}_t(\mathbf{x}) \pi_t(\mathbf{x}) d\mathbf{x}. \end{aligned} \quad (29.10)$$



分部积分得

$$\frac{d}{dt} \mathbb{E}[\varphi(\mathbf{X}_t)] = - \int \varphi(\mathbf{x}) \nabla \cdot [\pi_t(\mathbf{x}) \mathbf{v}_t(\mathbf{x})] d\mathbf{x}. \quad (29.11)$$

另一方面,

$$\begin{aligned} \frac{d}{dt} \mathbb{E}[\varphi(\mathbf{X}_t)] &= \frac{d}{dt} \int \varphi(\mathbf{x}) \pi_t(\mathbf{x}) d\mathbf{x} \\ &= \int \varphi(\mathbf{x}) \partial_t \pi_t(\mathbf{x}) d\mathbf{x}. \end{aligned} \quad (29.12)$$

比较式 (29.11) 与式 (29.12), 对任意 test function 都有 $\int \varphi [\partial_t \pi_t + \nabla \cdot (\pi_t \mathbf{v}_t)] = 0$ 。故 continuity equation 在分布意义下成立。□

端点处: $\mathbf{X}_{t=0} = \mathbf{X}_0 \sim \pi_0$, $\mathbf{X}_{t=1} = \mathbf{X}_1 \sim \pi_1$ 。在向量场 flow 与 continuity equation 解唯一的正则条件下, ODE $\dot{\mathbf{X}}_t = \mathbf{v}_t(\mathbf{X}_t)$ 确实将 π_0 输运至 π_1 。

易错点、反例与失败模式

仅仅写出端点 $\mathbf{X}_0 \sim \pi_0$, $\mathbf{X}_1 \sim \pi_1$ 不足以证明 learned ODE 会得到正确中间边缘分布。必须说明 population velocity 满足 continuity equation, 且需要相应存在唯一性条件。

29.6 Conditional Flow Matching 目标

理想 Flow Matching 目标为

$$\mathcal{L}_{\text{FM}}(\boldsymbol{\theta}) = \mathbb{E}_{t \sim \text{Unif}[0,1], \mathbf{X}_t \sim \pi_t} [\|\mathbf{v}_{\boldsymbol{\theta}}(t, \mathbf{X}_t) - \mathbf{v}_t(\mathbf{X}_t)\|_2^2]. \quad (29.13)$$

困难在于 $\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 \mid \mathbf{X}_t = \mathbf{x}]$ 通常不能显式计算。

Conditional Flow Matching 使用可采样 target:

$$\mathcal{L}_{\text{CFM}}(\boldsymbol{\theta}) = \mathbb{E}_{t \sim \text{Unif}[0,1], (\mathbf{X}_0, \mathbf{X}_1) \sim \gamma} [\|\mathbf{v}_{\boldsymbol{\theta}}(t, \mathbf{X}_t) - (\mathbf{X}_1 - \mathbf{X}_0)\|_2^2], \quad (29.14)$$

其中 $\mathbf{X}_t = (1-t)\mathbf{X}_0 + t\mathbf{X}_1$ 。

定理 29.2 (平方损失的条件期望最优性). 在不限制函数类时, 式 (29.14) 的逐点最优解为

$$\mathbf{v}^*(t, \mathbf{x}) = \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 \mid \mathbf{X}_t = \mathbf{x}] = \mathbf{v}_t(\mathbf{x}). \quad (29.15)$$

而且

$$\mathcal{L}_{\text{CFM}}(\boldsymbol{\theta}) = \mathcal{L}_{\text{FM}}(\boldsymbol{\theta}) + C, \quad (29.16)$$


其中 C 与 $\boldsymbol{\theta}$ 无关。

证明. 令 $\mathbf{Y} = \mathbf{X}_1 - \mathbf{X}_0$, $\mathbf{Z} = (t, \mathbf{X}_t)$ 。则 $\mathbf{v}_t(\mathbf{X}_t) = \mathbb{E}[\mathbf{Y} \mid \mathbf{Z}]$ 。平方损失正交分解给出

$$\begin{aligned} \mathbb{E} [\|\mathbf{v}_{\boldsymbol{\theta}}(\mathbf{Z}) - \mathbf{Y}\|_2^2] \\ = \mathbb{E} [\|\mathbf{v}_{\boldsymbol{\theta}}(\mathbf{Z}) - \mathbb{E}[\mathbf{Y} \mid \mathbf{Z}]\|_2^2] + \mathbb{E} [\|\mathbf{Y} - \mathbb{E}[\mathbf{Y} \mid \mathbf{Z}]\|_2^2]. \end{aligned} \quad (29.17)$$

第二项与模型无关, 第一项正是 ideal FM loss。因此无约束最优预测器为条件期望。□

若参数化网络族有限, 只能保证得到 $\mathbf{v}_t$ 在模型族中的 $L^2(\pi_t)$ 投影, 不能无条件保证恢复真实向量场。



29.7 更一般的 Gaussian Conditional Path

设 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_d)$, 并针对数据端点 $\mathbf{x}_1$ 定义

$$\mathbf{X}_t = \boldsymbol{\mu}_t(\mathbf{x}_1) + \sigma_t(\mathbf{x}_1)\mathbf{Z}, \quad \sigma_t(\mathbf{x}_1) > 0. \quad (29.18)$$

则

$$p_t(\mathbf{x} \mid \mathbf{x}_1) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_t(\mathbf{x}_1), \sigma_t(\mathbf{x}_1)^2 \mathbf{I}_d). \quad (29.19)$$

对路径求导:

$$\begin{aligned} \frac{d\mathbf{X}_t}{dt} &= \dot{\boldsymbol{\mu}}_t(\mathbf{x}_1) + \dot{\sigma}_t(\mathbf{x}_1)\mathbf{Z} \\ &= \dot{\boldsymbol{\mu}}_t(\mathbf{x}_1) + \frac{\dot{\sigma}_t(\mathbf{x}_1)}{\sigma_t(\mathbf{x}_1)} [\mathbf{X}_t - \boldsymbol{\mu}_t(\mathbf{x}_1)]. \end{aligned} \quad (29.20)$$

因此 conditional velocity 为

$$\mathbf{u}_t(\mathbf{x} \mid \mathbf{x}_1) = \dot{\boldsymbol{\mu}}_t(\mathbf{x}_1) + \frac{\dot{\sigma}_t(\mathbf{x}_1)}{\sigma_t(\mathbf{x}_1)} [\mathbf{x} - \boldsymbol{\mu}_t(\mathbf{x}_1)]. \quad (29.21)$$

这一形式说明:

- 只要 conditional path 可采样且速度可解析, 就可构造 CFM target;
- 不一定必须使用线性插值;
- conditional path 的选择会确定训练偏好。

29.8 Coupling 的作用

给定相同的 π_0, π_1 , 可以存在许多 coupling $\gamma \in \Pi(\pi_0, \pi_1)$ 。不同 coupling 会改变:

- conditional pairs;
- conditional velocity variance;
- 中间 marginal path;
- learned vector field 的弯曲程度;
- ODE numerical integration 难度。


独立 coupling 为 $\gamma_{\text{ind}} = \pi_0 \otimes \pi_1$ 。平方代价 optimal transport coupling 求解

$$\gamma_{\text{OT}} \in \arg \min_{\gamma \in \Pi(\pi_0, \pi_1)} \mathbb{E}_\gamma [\|\mathbf{X}_1 - \mathbf{X}_0\|_2^2]. \quad (29.22)$$

较小 transport distance 常能降低 conditional target variance 并产生更直的路径, 但这属于结构性动机, 不能写成对任意数据、任意模型和任意 solver 均成立的无条件定理。

29.8.1 Conditional paths 可以相交

不同 pair 的线性路径可能在同一时间和位置相交, 并携带不同速度: $\mathbf{X}_t^{(1)} = \mathbf{X}_t^{(2)}$, $\mathbf{X}_1^{(1)} - \mathbf{X}_0^{(1)} \neq \mathbf{X}_1^{(2)} - \mathbf{X}_0^{(2)}$ 。此时 population velocity 为条件平均: $\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 \mid \mathbf{X}_t = \mathbf{x}]$ 。因此 learned marginal flow 在该点只取一个速度。



若 $\mathbf{v}_t$ 关于空间变量满足 ODE 唯一性条件, 同一时刻的 marginal ODE trajectories 不能交叉, 否则交点之后会违反解唯一性。

29.9 随机化 Flow 与 Fokker–Planck 抵消

[26S-B-Q2(d), 5 分] 给定 SDE:

$$d\mathbf{X}_t = [\mathbf{v}_t(\mathbf{X}_t) + \beta_t \nabla_{\mathbf{x}} \log \pi_t(\mathbf{X}_t)] dt + \sqrt{2\beta_t} d\mathbf{W}_t, \quad (29.23)$$

其中 $\beta_t \geq 0$ 。

定理 29.3 (随机化流与确定性 ODE 的边缘分布等价). 若式 (29.23) 中使用精确 score $\nabla \log \pi_t$, 则其 Fokker–Planck equation 化为

$$\partial_t \pi_t = -\nabla \cdot (\pi_t \mathbf{v}_t), \quad (29.24)$$

与 ODE $\dot{\mathbf{X}}_t = \mathbf{v}_t(\mathbf{X}_t)$ 的 continuity equation 相同。

证明. 式 (29.23) 的 drift 为 $\mathbf{b}_t = \mathbf{v}_t + \beta_t \nabla \log \pi_t$, 扩散方差为 $2\beta_t \mathbf{I}_d$ 。Fokker–Planck equation 为

$$\begin{aligned} \partial_t \pi_t &= -\nabla \cdot [(\mathbf{v}_t + \beta_t \nabla \log \pi_t) \pi_t] + \beta_t \Delta \pi_t \\ &= -\nabla \cdot (\mathbf{v}_t \pi_t) - \beta_t \nabla \cdot [\pi_t \nabla \log \pi_t] + \beta_t \Delta \pi_t. \end{aligned} \quad (29.25)$$

由于 $\pi_t \nabla \log \pi_t = \nabla \pi_t$, 有 $\nabla \cdot [\pi_t \nabla \log \pi_t] = \Delta \pi_t$ 。两个 diffusion-related term 精确抵消, 故 $\partial_t \pi_t = -\nabla \cdot (\mathbf{v}_t \pi_t)$ 。□

易错点、反例与失败模式

边缘分布等价要求:

- score 是精确的;
- PDE 与 SDE 解存在且唯一;
- 数值积分误差忽略不计。

若用 $\mathbf{s}_\phi \neq \nabla \log \pi_t$, 抵消不再精确, 生成分布会出现偏差。

29.10 如何估计 Flow Path 的 Score

需要训练 $\mathbf{s}_\phi(t, \mathbf{x}) \approx \nabla_{\mathbf{x}} \log \pi_t(\mathbf{x})$ 。

可采用以下方式:

29.10.1 Implicit Score Matching

若能够从 $\mathbf{X}_t \sim \pi_t$ 采样, 并且网络散度可计算, 则最小化

$$\mathbb{E}_{t, \mathbf{X}_t} \left[\frac{1}{2} \|\mathbf{s}_\phi(t, \mathbf{X}_t)\|_2^2 + \nabla \cdot \mathbf{s}_\phi(t, \mathbf{X}_t) \right]. \quad (29.26)$$



29.10.2 Denoising Score Matching

若 conditional path 有非零 Gaussian variance: $p_t(\mathbf{x} \mid \text{condition}) = \mathcal{N}(\boldsymbol{\mu}_t, \sigma_t^2 \mathbf{I})$, 则条件 score 可解析: $\nabla_{\mathbf{x}} \log p_t(\mathbf{x} \mid \text{condition}) = -\frac{\mathbf{x} - \boldsymbol{\mu}_t}{\sigma_t^2}$. 可使用 conditional DSM.

29.10.3 确定性线性插值的特殊问题

若条件于 pair $(\mathbf{x}_0, \mathbf{x}_1)$ 后 $\mathbf{X}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$ 是确定性点, 则 conditional distribution 是 Dirac measure, 不存在普通 Lebesgue density 的有限 score.

因此不能机械写 $\nabla \log p(\mathbf{x}_t \mid \mathbf{x}_0, \mathbf{x}_1)$ 并把它当作普通 Gaussian score. 需要:

- 对 marginal π_t 使用 implicit/sliced score matching; 或
- 给 conditional path 添加非零 Gaussian smoothing; 或
- 单独训练可微 energy/density model.

这是系统设计题中很容易被忽略的测度问题。

29.11 Flow Matching 的训练与采样算法

答题方法

训练:

1. 采样 $t \sim \text{Unif}[0, 1]$.
2. 从 coupling 采样 $(\mathbf{x}_0, \mathbf{x}_1) \sim \gamma$.
3. 构造 $\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1$.
4. 构造 target $\mathbf{u}_t = \mathbf{x}_1 - \mathbf{x}_0$.
5. 最小化 $\|\mathbf{v}_\theta(t, \mathbf{x}_t) - \mathbf{u}_t\|_2^2$.

确定性采样:

1. 采样 $\mathbf{x}_0 \sim \pi_0$.
2. 使用 Euler、midpoint、Runge-Kutta 或自适应 solver 积分 $\dot{\mathbf{x}}_t = \mathbf{v}_\theta(t, \mathbf{x}_t)$.
3. 输出 $\mathbf{x}_1$.

随机采样: 若另有 score network, 则积分 $d\mathbf{X}_t = [\mathbf{v}_\theta(t, \mathbf{X}_t) + \beta_t \mathbf{s}_\phi(t, \mathbf{X}_t)] dt + \sqrt{2\beta_t} d\mathbf{W}_t$.

若 solver 使用 N 次 network function evaluations, 采样主要复杂度为 $O(NC_{\text{net}})$. 训练时每个样本通常只计算一个随机 t , 主要代价为 $O(C_{\text{net}})$.

但 sampling speed 不能只看步数, 还应报告:

- NFE;
- 每次 NFE 的网络大小;
- solver order;
- batch size;



- guidance 是否增加额外网络前向；
- 允许的数值误差和样本质量。

29.12 Flow Matching 的失败模式

1. Conditional target variance 高。

对给定 $(t, \mathbf{x}_t)$ ，不同 pair 可能给出差异很大的 $\mathbf{x}_1 - \mathbf{x}_0$ 。SGD target 方差高，训练收敛较慢。

2. Marginal path 过度弯曲。

即使每条 conditional path 是直线，条件平均得到的 marginal vector field 也可能弯曲，导致 ODE solver 需要更多步。

3. Coupling 不合适。

独立 pairing 可能将相距很远、语义无关的端点连接，增加 transport distance 和 target variance。

4. 向量场不满足良好正则性。

若网络 vector field 关于 $\mathbf{x}$ 不具备局部 Lipschitz 性，ODE 解可能不唯一，连续性方程与 sample flow 的联系变得复杂。

5. 有限模型误差。

参数化网络只能近似 $\mathbf{v}_t$ ，即使训练 MSE 较小，长时间积分仍可能积累全局偏差。

6. 训练与数值积分目标不一致。

训练最小化局部 velocity MSE，采样质量却依赖整个数值轨迹；局部误差不自动给出终端分布误差的紧保证。

29.13 Rectified Flow：扩展了解

重要性等级：C

Rectified flow 出现在 [Gen] 的 flow matching 延伸中，但未在三套博资考中单独出题。要求掌握基本思想，不需把经验比较写成数学定理。

给定已有 coupling 的线性插值 $\mathbf{X}_t = (1-t)\mathbf{X}_0 + t\mathbf{X}_1$ ，训练 $\mathbf{v}_t^*(\mathbf{x}) = \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 \mid \mathbf{X}_t = \mathbf{x}]$ 。再由该 ODE 生成新的 endpoint coupling，并重复训练，称为 reflow。

目标是使轨迹更直，从而减少采样 NFE。但：

- 重复 rectification 增加训练成本；
- 有限网络和有限数据下不保证严格直线；
- 单步生成质量依赖蒸馏或额外一致性训练。

答题方法

[26S-B-Q2, 15 分] 的逐问满分框架：

(a) 2 分： $\mathbf{X}_t = (1-t)\mathbf{X}_0 + t\mathbf{X}_1$ 直接求导： $\frac{d\mathbf{X}_t}{dt} = \mathbf{X}_1 - \mathbf{X}_0$ 。

(b) 3 分: $\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 \mid \mathbf{X}_t = \mathbf{x}]$ 。对 test function φ 写 $\frac{d}{dt} \mathbb{E}[\varphi(\mathbf{X}_t)] = \mathbb{E}[\nabla \varphi(\mathbf{X}_t)^\top \mathbf{v}_t(\mathbf{X}_t)]$ 并分部积分, 得到 $\partial_t \pi_t + \nabla \cdot (\pi_t \mathbf{v}_t) = 0$ 。再利用 $\pi_{t=0} = \pi_0, \quad \pi_{t=1} = \pi_1$ 。

(c) 5 分: 写 $\mathcal{L}(\theta) = \mathbb{E}[\|\mathbf{v}_\theta(t, \mathbf{X}_t) - (\mathbf{X}_1 - \mathbf{X}_0)\|^2]$ 。使用 $\mathbb{E}\|f(Z) - Y\|^2 = \mathbb{E}\|f(Z) - \mathbb{E}[Y \mid Z]\|^2 + \mathbb{E}\|Y - \mathbb{E}[Y \mid Z]\|^2$ 证明最优解为 $\mathbf{v}_t(\mathbf{x})$ 。

(d) 5 分: 对 $d\mathbf{X}_t = (\mathbf{v}_t + \beta_t \nabla \log \pi_t) dt + \sqrt{2\beta_t} d\mathbf{W}_t$ 写 Fokker-Planck: $\partial_t \pi_t = -\nabla \cdot [(\mathbf{v}_t + \beta_t \nabla \log \pi_t) \pi_t] + \beta_t \Delta \pi_t$ 。使用 $\pi_t \nabla \log \pi_t = \nabla \pi_t$ 使最后两项抵消, 得到 $\partial_t \pi_t = -\nabla \cdot (\pi_t \mathbf{v}_t)$ 。最后说明未知 score 可由 score matching 近似; 若使用 Gaussian conditional path, 则可用 denoising score matching。

29.14 扩散模型、Score Model 与 Flow Matching 速查

表 29.1: 扩散与连续流模型核心区别

方法	学习目标	生成动力学	主要风险
DDPM	$\mathbb{E}\ \varepsilon - \varepsilon_\theta(\mathbf{x}_t, t)\ ^2$ 或 ELBO 加权版本	离散 Gaussian reverse chain	多步采样; schedule 敏感; 简化 loss 与 ELBO 权重不同
Score-based SDE	$\mathbb{E}\ \mathbf{s}_\theta - \nabla \log p_t\ ^2$ 通过 DSM 实现	Reverse-time SDE	低密度 score 误差; SDE discretization error
Probability-flow ODE	通常复用已训练 score	$\dot{\mathbf{x}} = \mathbf{f} - \frac{1}{2}g^2 \mathbf{s}_\theta$	ODE solver 误差; divergence 计算; 近似 score 导致边缘偏差
Flow Matching	$\mathbb{E}\ \mathbf{v}_\theta - \mathbf{u}_{\text{conditional}}\ ^2$	学习 ODE $\dot{\mathbf{x}} = \mathbf{v}_\theta$	coupling 与 target variance; 轨迹弯曲; 有限模型积分误差
随机化 Flow	velocity network 加 score network	$d\mathbf{X} = (\mathbf{v} + \beta \mathbf{s})dt + \sqrt{2\beta}d\mathbf{W}$	score 不精确时 Fokker-Planck 抵消失效

29.15 历年真题映射

表 29.2: 第 9 部分真题映射

真题	主要标签	满分不可缺少内容
[25F-B-Q2(d), 4 分]	DDPM、层次 VAE、ELBO	前向 encoder; 反向 decoder; reverse factorization; terminal KL; 逐步 KL; reconstruction
[25S-B-Q2(a), 4 分]	VP SDE、reverse-time SDE	时间方向; $\mathbf{f} - g^2 \nabla \log p_t$ 的正确符号; score network 训练必要性

真题	主要标签	满分不可缺少内容
[25S-B-Q2(b), 6 分]	Denoising score matching	Fisher identity; tower property; 平方损失分解; 常数与参数无关
[25S-B-Q2(c), 5 分]	VP 条件 Gaussian	integrating factor; $a(t), \sigma(t)$; conditional score; 最终噪声 MSE
[26S-B-Q2(a), 2 分]	Conditional velocity	$\frac{d}{dt}[(1-t)\mathbf{x}_0 + t\mathbf{x}_1] = \mathbf{x}_1 - \mathbf{x}_0$
[26S-B-Q2(b), 3 分]	Continuity equation	test function; 条件期望; 分部积分; 端点边缘分布
[26S-B-Q2(c), 5 分]	CFM regression	平方损失目标; conditional-expectation projection; 最优函数与有限模型的区别
[26S-B-Q2(d), 5 分]	Fokker-Planck、随机化流	drift 与 diffusion coefficient; $\pi \nabla \log \pi = \nabla \pi$; Laplacian 精确抵消; score matching

29.16 综合易错点

易错点、反例与失败模式

1. $\alpha_t \neq \bar{\alpha}_t$.
2. $q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$, 标准差是 $\sqrt{1 - \bar{\alpha}_t}$, 不是 $1 - \bar{\alpha}_t$.
3. DDPM 的 forward process 固定, reverse process 学习。
4. 训练随机采样一个 t 不等于推理可一次完成。
5. ELBO 中 denoising target 是 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$, 不是 $q(\mathbf{x}_{t-1} | \mathbf{x}_t)$.
6. Conditional score 与 marginal score 不同: $\nabla \log p_t(\mathbf{x}_t) = \mathbb{E}[\nabla \log p_{t|0} | \mathbf{X}_t = \mathbf{x}_t]$.
7. Reverse-time SDE 的 drift 符号必须与时间方向配套。
8. Probability-flow ODE 与 SDE 仅共享 marginals, 不共享随机路径分布。
9. Flow matching 的 conditional velocity $\mathbf{X}_1 - \mathbf{X}_0$ 不一定是当前位置的单值函数。
10. Population velocity 是条件期望: $\mathbf{v}_t(\mathbf{x}) = \mathbb{E}[\mathbf{X}_1 - \mathbf{X}_0 | \mathbf{X}_t = \mathbf{x}]$.
11. Conditional paths 可以交叉; 正则 ODE 的 marginal trajectories 不能在同一时刻交叉。
12. Fokker-Planck 中 $\sqrt{2\beta_t}$ 对应 diffusion term $\beta_t \Delta \pi_t$, 不能漏掉 $1/2$ 后再重复乘二。
13. 确定性 linear interpolation 条件分布是 Dirac measure, 不能直接写普通 Gaussian conditional score。


14. 较直路径通常有利于少步 ODE 采样，但不是对任意模型无条件成立的 theorem。
15. Likelihood、FID、视觉质量和 sampling NFE 是不同指标，不能用单一指标替代全部评价。

29.17 快速自测



快速自测

1. 写出 $q(\mathbf{x}_t | \mathbf{x}_0)$ 的均值和协方差。
2. 为什么训练时可以直接构造 $\mathbf{x}_t$ ，而无需模拟前 $t-1$ 步？
3. 写出 $\tilde{\beta}_t$ 和 $\tilde{\mu}_t$ 。
4. DDPM 的 ELBO 包含哪三类项？
5. Noise prediction 与 score prediction 的换算中，分母是 $\sqrt{1 - \bar{\alpha}_t}$ 还是 $1 - \bar{\alpha}_t$ ？
6. 为什么 simplified DDPM loss 不应被称为与原 ELBO 完全相同？
7. Reverse-time SDE 中为什么出现 $-g(t)^2 \nabla \log p_t$ ？
8. 使用递增 reverse time $\tau = T - t$ 后 drift 应如何变化？
9. VP SDE 中 $a(t)$ 与 $\sigma^2(t)$ 分别是什么？
10. VP conditional score 为什么等于 $-\epsilon/\sigma(t)$ ？
11. Denoising score matching 中的常数是否必须为正？
12. Explicit score matching 转为 implicit score matching 需要什么边界条件？
13. Probability-flow ODE 的 drift 中 score 前的系数是 g^2 还是 $\frac{1}{2}g^2$ ？
14. Probability-flow ODE 与 reverse SDE 的 marginals 和 path distribution 分别是否相同？
15. Flow matching 中为何不能直接监督 population velocity？
16. 平方损失最优回归函数为何是条件期望？
17. Linear interpolation 的 conditional velocity 是什么？
18. 如何用 test function 证明 continuity equation？
19. 在随机化 flow 中，哪两个 Fokker-Planck 项发生精确抵消？
20. 若 score network 有误差，随机化 SDE 是否仍与原 ODE 具有完全相同 marginals？
21. Coupling 改变端点边缘分布吗？它改变哪些训练与采样性质？
22. 为什么 conditional paths 可以交叉，而 Lipschitz marginal ODE trajectories 不能交叉？
23. DDPM、score SDE、probability-flow ODE 与 flow matching 分别直接学习什么对象？
24. 生成模型采样速度应使用 step count、NFE 还是 wall-clock time 比较？为什么最好同时报告三者？



第三十章 Markov 决策过程与价值函数

30.1 重要性等级与历年实考定位

重要性等级：S

- [26S-B-Q3(a), 2 分] 要求从折扣回报定义推导策略价值函数的 Bellman 方程。
- [26S-B-Q3(b), 2 分] 要求完整写出 policy evaluation 与 policy improvement，即策略迭代的两个步骤。
- [25F-B-Q3, 10 分] 要求证明 Policy Gradient Theorem，并证明任意状态基线不改变策略梯度的期望。
- [26S-B-Q3(c), 2 分] 要求说明未知环境模型时，如何将策略评估和策略改进改造成 Actor-Critic。
- [26S-B-Q3(d), 2 分] 要求给出一种 RLHF 或 DPO 型策略更新目标。
- Bellman 方程、动态规划、TD learning、策略梯度和偏好优化构成强化学习部分的统一主线：固定点 $\rightarrow$ 采样估计 $\rightarrow$ 随机梯度 $\rightarrow$ 人类偏好对齐。

30.2 折扣 Markov 决策过程

为便于严格证明，首先考虑有限状态、有限动作的折扣 MDP：

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, p_R, \gamma, \mu_0), \quad (30.1)$$

其中：

- $\mathcal{S}$ 是有限状态空间；
- $\mathcal{A}$ 是有限动作空间；
- $P(s' | s, a) = \Pr(S_{t+1} = s' | S_t = s, A_t = a)$ 是状态转移核；
- $p_R(r | s, a, s')$ 是给定转移后的奖励条件分布；
- $\gamma \in [0, 1)$ 是折扣因子；
- $S_0 \sim \mu_0$ 是初始状态分布。

更紧凑地，可定义状态、奖励联合核

$$p(s', r | s, a) = P(s' | s, a) p_R(r | s, a, s'). \quad (30.2)$$



MDP 的 Markov 性为

$$\begin{aligned} \Pr(S_{t+1} = s', R_t = r \mid S_0, A_0, \dots, S_t = s, A_t = a) \\ = p(s', r \mid s, a). \end{aligned} \quad (30.3)$$

即给定当前状态和动作后，下一状态与即时奖励不再依赖更早的完整历史。

30.2.1 期望即时奖励

定义

$$\bar{r}(s, a) := \mathbb{E}[R_t \mid S_t = s, A_t = a] = \sum_{s' \in \mathcal{S}} \sum_r p(s', r \mid s, a) r. \quad (30.4)$$

若奖励本身写作确定性函数 $r(s, a, s')$, 则

$$\bar{r}(s, a) = \sum_{s'} P(s' \mid s, a) r(s, a, s'). \quad (30.5)$$

后文为简洁起见，有时将 $\bar{r}(s, a)$ 直接记为 $r(s, a)$ 。

30.3 策略与轨迹分布

定义 30.1 (随机平稳策略). 随机平稳策略是映射

$$\pi : \mathcal{S} \longrightarrow \Delta(\mathcal{A}), \quad (30.6)$$

其中

$$\pi(a \mid s) = \Pr(A_t = a \mid S_t = s), \quad \sum_{a \in \mathcal{A}} \pi(a \mid s) = 1. \quad (30.7)$$

确定性策略是随机策略的特殊情况：

$$\pi(a \mid s) = \mathbf{1}\{a = \pi(s)\}. \quad (30.8)$$

给定参数化策略 $\pi_{\theta}(a \mid s)$, 有限长度轨迹 $\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots, s_T)$ 的概率为

$$p_{\theta}(\tau) = \mu_0(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t \mid s_t) p(s_{t+1}, r_t \mid s_t, a_t). \quad (30.9)$$

若环境模型不依赖 θ , 则


$$\nabla_{\theta} \log p_{\theta}(\tau) = \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t). \quad (30.10)$$

这是后续策略梯度推导的核心恒等式。

30.4 折扣回报

定义从时刻 t 开始的折扣回报：

$$G_t := \sum_{k=0}^{\infty} \gamma^k R_{t+k}. \quad (30.11)$$



若奖励有界：

$$|R_t| \leq R_{\max} \quad \text{几乎处处,} \quad (30.12)$$

则

$$|G_t| \leq \sum_{k=0}^{\infty} \gamma^k R_{\max} = \frac{R_{\max}}{1-\gamma}. \quad (30.13)$$

折扣因子有三重作用：

1. 保证无限时域回报绝对收敛；
2. 更强调近期奖励；
3. 使 Bellman operator 成为压缩映射。

30.5 状态价值、动作价值和优势函数

定义 30.2 (状态价值函数).

$$V^\pi(s) := \mathbb{E}_\pi [G_t \mid S_t = s]. \quad (30.14)$$

定义 30.3 (动作价值函数).

$$Q^\pi(s, a) := \mathbb{E}_\pi [G_t \mid S_t = s, A_t = a]. \quad (30.15)$$

定义 30.4 (优势函数).

$$A^\pi(s, a) := Q^\pi(s, a) - V^\pi(s). \quad (30.16)$$

由于 $V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s, a)$, 有

$$\sum_a \pi(a \mid s) A^\pi(s, a) = 0. \quad (30.17)$$

奖励有界时,

$$\|V^\pi\|_\infty \leq \frac{R_{\max}}{1-\gamma}, \quad \|Q^\pi\|_\infty \leq \frac{R_{\max}}{1-\gamma}. \quad (30.18)$$

30.6 Bellman 期望方程

定理 30.5 (Bellman 期望方程). 对任意固定策略 π , 有

$$V^\pi(s) = \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma V^\pi(s')], \quad (30.19)$$


$$Q^\pi(s, a) = \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \sum_{a'} \pi(a' \mid s') Q^\pi(s', a') \right]. \quad (30.20)$$

证明. 由回报递推:

$$G_t = R_t + \gamma G_{t+1}. \quad (30.21)$$

于是

$$\begin{aligned} V^\pi(s) &= \mathbb{E}_\pi [R_t + \gamma G_{t+1} \mid S_t = s] \\ &= \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma \mathbb{E}_\pi [G_{t+1} \mid S_{t+1} = s']] \\ &= \sum_a \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma V^\pi(s')]. \end{aligned} \quad (30.22)$$



动作价值方程同理。 □

若使用期望奖励 $r(s, a)$, 则

$$V^\pi(s) = \sum_a \pi(a | s) \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^\pi(s') \right], \quad (30.23)$$

$$Q^\pi(s, a) = r(s, a) + \gamma \sum_{s'} P(s' | s, a) \sum_{a'} \pi(a' | s') Q^\pi(s', a'). \quad (30.24)$$

30.6.1 矩阵形式

定义

$$P_{ss'}^\pi := \sum_a \pi(a | s) P(s' | s, a), \quad (30.25)$$

$$r_s^\pi := \sum_a \pi(a | s) r(s, a). \quad (30.26)$$

令 $\mathbf{v}^\pi = (V^\pi(s))_{s \in \mathcal{S}}$, $\mathbf{r}^\pi = (r_s^\pi)_{s \in \mathcal{S}}$. 则

$$\boxed{\mathbf{v}^\pi = \mathbf{r}^\pi + \gamma P^\pi \mathbf{v}^\pi.} \quad (30.27)$$

因此

$$\boxed{\mathbf{v}^\pi = (\mathbf{I} - \gamma P^\pi)^{-1} \mathbf{r}^\pi.} \quad (30.28)$$

由于 P^π 是随机矩阵, 其谱半径满足 $\rho(P^\pi) \leq 1$, 故 $\rho(\gamma P^\pi) < 1$, 从而 $\mathbf{I} - \gamma P^\pi$ 可逆, 并且

$$(\mathbf{I} - \gamma P^\pi)^{-1} = \sum_{k=0}^{\infty} (\gamma P^\pi)^k. \quad (30.29)$$

30.7 Bellman Operator 与唯一性

定义固定策略的 Bellman operator:

$$(\mathcal{T}^\pi V)(s) := \sum_a \pi(a | s) \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right]. \quad (30.30)$$

Bellman 方程等价于

$$V^\pi = \mathcal{T}^\pi V^\pi. \quad (30.31)$$


定理 30.6 (Bellman operator 的压缩性). 对任意有界函数 V, W ,

$$\boxed{\|\mathcal{T}^\pi V - \mathcal{T}^\pi W\|_\infty \leq \gamma \|V - W\|_\infty.} \quad (30.32)$$

证明. 对任意状态 s ,

$$\begin{aligned} & |(\mathcal{T}^\pi V)(s) - (\mathcal{T}^\pi W)(s)| \\ &= \gamma \left| \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [V(s') - W(s')] \right| \\ &\leq \gamma \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) |V(s') - W(s')| \\ &\leq \gamma \|V - W\|_\infty. \end{aligned} \quad (30.33)$$

对 s 取上确界即得结论。 □



由 Banach 不动点定理:

推论 30.7. 1. $\mathcal{T}^\pi$ 存在唯一不动点 V^π ;

2. 任意初始化 V_0 的迭代

$$V_{k+1} = \mathcal{T}^\pi V_k \quad (30.34)$$

满足

$$\|V_k - V^\pi\|_\infty \leq \gamma^k \|V_0 - V^\pi\|_\infty. \quad (30.35)$$

易错点、反例与失败模式

Bellman 方程不是普通的一次采样更新公式。

应区分:

- Bellman equation: 价值函数满足的精确期望固定点方程;
- dynamic programming: 模型 P, r 已知时计算该固定点;
- temporal-difference learning: 模型未知时用随机样本近似 Bellman 更新。



第三十一章 Bellman 最优性与动态规划

31.1 最优价值函数

定义

$$V^*(s) := \sup_{\pi} V^{\pi}(s), \quad (31.1)$$

$$Q^*(s, a) := \sup_{\pi} Q^{\pi}(s, a). \quad (31.2)$$

对有限折扣 MDP，存在确定性平稳最优策略 $\pi^* : \mathcal{S} \rightarrow \mathcal{A}$ 满足 $V^{\pi^*}(s) = V^*(s)$, $\forall s \in \mathcal{S}$ 。

31.2 Bellman 最优性方程

定义最优 Bellman operator:

$$(\mathcal{T}^*V)(s) := \max_{a \in \mathcal{A}} \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right]. \quad (31.3)$$

定理 31.1 (Bellman 最优性方程). 最优价值函数满足

$$V^* = \mathcal{T}^*V^*, \quad (31.4)$$

即

$$V^*(s) = \max_a \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right]. \quad (31.5)$$

最优动作价值满足

$$Q^*(s, a) = r(s, a) + \gamma \sum_{s'} P(s' | s, a) \max_{a'} Q^*(s', a'). \quad (31.6)$$

证明. 若当前状态为 s , 第一步先选择动作 a , 之后执行最优策略, 则总期望回报为 $r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s')$. 第一步可以在所有动作中取最大值, 从而得到式 (31.5)。

又因为 $V^*(s') = \max_{a'} Q^*(s', a')$, 代入即可得到动作价值版本。 $\square$

定理 31.2 (最优 Bellman operator 的压缩性).

$$\|\mathcal{T}^*V - \mathcal{T}^*W\|_{\infty} \leq \gamma \|V - W\|_{\infty}. \quad (31.7)$$

证明. 使用基本不等式

$$\left| \max_a x_a - \max_a y_a \right| \leq \max_a |x_a - y_a|. \quad (31.8)$$



于是对任意 s ,

$$\begin{aligned} & |(\mathcal{T}^*V)(s) - (\mathcal{T}^*W)(s)| \\ & \leq \max_a \gamma \left| \sum_{s'} P(s' | s, a) [V(s') - W(s')] \right| \\ & \leq \gamma \|V - W\|_\infty. \end{aligned} \quad (31.9)$$

□

因此 $\mathcal{T}^*$ 有唯一不动点 V^* 。

31.3 由最优价值恢复最优策略

若

$$\pi^*(s) \in \arg \max_a \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^*(s') \right], \quad (31.10)$$

则 $\mathcal{T}^{\pi^*} V^* = \mathcal{T}^* V^* = V^*$ 。由于 $\mathcal{T}^{\pi^*}$ 的不动点唯一, 故 $V^{\pi^*} = V^*$ 。

注意:

- 最优价值函数在有限折扣 MDP 中唯一;
- 最优策略不一定唯一, 因为可能存在多个并列最优动作。

31.4 策略改进定理

定理 31.3 (Policy Improvement Theorem). 设策略 π' 满足

$$(\mathcal{T}^{\pi'} V^\pi)(s) \geq V^\pi(s), \quad \forall s. \quad (31.11)$$

则

$$V^{\pi'}(s) \geq V^\pi(s), \quad \forall s. \quad (31.12)$$

证明. Bellman operator 对函数具有单调性: 若 $V \leq W$, 则 $\mathcal{T}^{\pi'} V \leq \mathcal{T}^{\pi'} W$ 。由假设, $V^\pi \leq \mathcal{T}^{\pi'} V^\pi$ 。反复使用单调性得到

$$V^\pi \leq \mathcal{T}^{\pi'} V^\pi \leq (\mathcal{T}^{\pi'})^2 V^\pi \leq \dots \quad (31.13)$$

又由于 $\mathcal{T}^{\pi'}$ 是压缩映射, 右侧收敛到唯一不动点 $V^{\pi'}$ 。故 $V^\pi \leq V^{\pi'}$ 。 □


特别地, 令新策略对 Q^π 贪心:

$$\pi'(s) \in \arg \max_a Q^\pi(s, a). \quad (31.14)$$

则

$$\begin{aligned} (\mathcal{T}^{\pi'} V^\pi)(s) &= \max_a Q^\pi(s, a) \\ &\geq \sum_a \pi(a | s) Q^\pi(s, a) \\ &= V^\pi(s). \end{aligned} \quad (31.15)$$

所以 $V^{\pi'} \geq V^\pi$ 。



31.5 策略迭代

答题方法

Policy Iteration:

初始化任意确定性策略 π_0 。

对 $k = 0, 1, \dots$ 重复:

步骤一: 策略评估。求解

$$V^{\pi_k} = \mathcal{T}^{\pi_k} V^{\pi_k}, \quad (31.16)$$

即

$$\mathbf{v}^{\pi_k} = (\mathbf{I} - \gamma P^{\pi_k})^{-1} \mathbf{r}^{\pi_k}. \quad (31.17)$$

步骤二: 策略改进。对每个状态令

$$\pi_{k+1}(s) \in \arg \max_a \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi_k}(s') \right]. \quad (31.18)$$

若 $\pi_{k+1} = \pi_k$, 则终止并输出 π_k 。

在有限状态、有限动作情况下, 确定性平稳策略总数有限。若只在存在严格改进时改变动作, 或固定处理并列动作的规则, 则:

- 每次非终止迭代都严格改善至少一个状态价值;
- 不会重复访问已出现的策略;
- 因而有限步终止于最优策略。

若在并列最优动作之间任意切换, 理论上可能出现无价值改进的策略循环, 因此实现时应使用稳定 tie-breaking。

31.6 值迭代

值迭代直接迭代最优 Bellman operator:

$$V_{k+1} = \mathcal{T}^* V_k. \quad (31.19)$$

展开为

$$V_{k+1}(s) = \max_a \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right]. \quad (31.20)$$

由压缩性,


$$\|V_k - V^*\|_\infty \leq \gamma^k \|V_0 - V^*\|_\infty. \quad (31.21)$$

得到近似价值 V_k 后, 定义贪心策略

$$\pi_k(s) \in \arg \max_a \left[r(s, a) + \gamma \sum_{s'} P(s' | s, a) V_k(s') \right]. \quad (31.22)$$

命题 31.4 (贪心策略的性能界). 若 π_V 对函数 V 贪心, 则

$$\|V^* - V^{\pi_V}\|_\infty \leq \frac{2\gamma}{1-\gamma} \|V^* - V\|_\infty. \quad (31.23)$$



证明. 由于 $\mathcal{T}^{\pi_V} V = \mathcal{T}^* V$, 有

$$\begin{aligned}\|V^* - V^{\pi_V}\|_\infty &= \|\mathcal{T}^* V^* - \mathcal{T}^{\pi_V} V^{\pi_V}\|_\infty \\ &\leq \|\mathcal{T}^* V^* - \mathcal{T}^* V\|_\infty + \|\mathcal{T}^{\pi_V} V - \mathcal{T}^{\pi_V} V^{\pi_V}\|_\infty \\ &\leq \gamma \|V^* - V\|_\infty + \gamma \|V - V^{\pi_V}\|_\infty \\ &\leq 2\gamma \|V^* - V\|_\infty + \gamma \|V^* - V^{\pi_V}\|_\infty.\end{aligned}\quad (31.24)$$

移项即可. $\square$

31.6.1 Bellman residual

对任意 V , 定义最优 Bellman residual:

$$\text{Res}(V) := \|\mathcal{T}^* V - V\|_\infty. \quad (31.25)$$

则

$$\|V - V^*\|_\infty \leq \frac{1}{1-\gamma} \text{Res}(V). \quad (31.26)$$

证明为

$$\begin{aligned}\|V - V^*\|_\infty &\leq \|V - \mathcal{T}^* V\|_\infty + \|\mathcal{T}^* V - \mathcal{T}^* V^*\|_\infty \\ &\leq \text{Res}(V) + \gamma \|V - V^*\|_\infty.\end{aligned}\quad (31.27)$$

表 31.1: 策略迭代与值迭代比较

比较项	策略迭代	值迭代
每轮核心	精确或近似评估当前策略, 再进行贪心改进	直接执行一次最优 Bellman backup
单轮代价	精确评估可能要求解线性系统	通常较低, 每个状态执行一次最大化
迭代轮数	通常较少; 有限确定性策略下可有限终止	一般需要更多 Bellman backups
固定点	交替寻找 V^{π_k} 和改进策略	直接逼近 V^*
模型要求	需要 P, r	需要 P, r

答题方法

[26S-B-Q3(a)-(b), 共 4 分] 的满分作答顺序:

1. 从 $G_t = R_t + \gamma G_{t+1}$ 出发;
2. 写出 $V^\pi(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s, a) [r(s, a) + \gamma V^\pi(s')]$;
3. 策略评估写为 $V^{\pi_k} = \mathcal{T}^{\pi_k} V^{\pi_k}$;
4. 策略改进写为 $\pi_{k+1}(s) \in \arg \max_a [r(s, a) + \gamma \sum_{s'} P(s'|s, a) V^{\pi_k}(s')]$;

5. 说明 Policy Improvement Theorem 保证 $V^{\pi_{k+1}} \geq V^{\pi_k}$, 且在有限 MDP 中配合稳定 tie-breaking 可有限终止。



第三十二章 Model-Free 价值学习：MC、TD、SARSA 与 Q-Learning

32.1 为什么需要 Model-Free 方法

模型已知时，需要计算 $P(s' | s, a)$, $r(s, a)$ 。但实际问题常只能访问环境采样器：

$$(s', r) \sim \text{Env}(s, a). \quad (32.1)$$

Model-free 方法不显式估计完整转移核，而是直接从样本 (s_t, a_t, r_t, s_{t+1}) 学习价值函数或策略。

32.2 Monte-Carlo 策略评估

固定策略 π 时， $V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s]$ 。若独立采样 N 条访问状态 s 的 episode，相应 returns 为 $G^{(1)}, \dots, G^{(N)}$ ，则 Monte-Carlo 估计为

$$\hat{V}_N^\pi(s) = \frac{1}{N} \sum_{i=1}^N G^{(i)}. \quad (32.2)$$

在 returns 独立同分布且二阶矩有限时，

$$\mathbb{E}[\hat{V}_N^\pi(s)] = V^\pi(s), \quad (32.3)$$

且

$$\text{Var}(\hat{V}_N^\pi(s)) = \frac{\text{Var}(G_t | S_t = s)}{N}. \quad (32.4)$$

增量更新形式为

$$V(S_t) \leftarrow V(S_t) + \alpha_t [G_t - V(S_t)]. \quad (32.5)$$

Monte-Carlo 的特征：

- 不需要环境模型；
- 不 bootstrap；
- 完整 episode return 对 V^π 是无偏目标；
- 必须等待回合结束；
- 长时域下方差可能很高。



32.3 Temporal-Difference Learning

TD(0) 使用一步 bootstrap target:

$$Y_t^{\text{TD}} = R_t + \gamma V(S_{t+1}). \quad (32.6)$$

定义 TD error:

$$\delta_t = R_t + \gamma V(S_{t+1}) - V(S_t). \quad (32.7)$$

表格型更新为

$$V(S_t) \leftarrow V(S_t) + \alpha_t \delta_t. \quad (32.8)$$

TD target 使用当前估计的 $V(S_{t+1})$, 因此它对真实 return 通常有偏; 但其方差一般低于完整 Monte-Carlo return。

表 32.1: Monte-Carlo 与 TD(0)

比较项	Monte-Carlo	TD(0)
目标	完整 return G_t	一步目标 $R_t + \gamma V(S_{t+1})$
是否 bootstrap	否	是
是否等待 episode 结束	是	否
目标偏差	对固定策略的完整 return 无偏	当前估计不精确时通常有偏
方差	通常较高	通常较低

32.3.1 表格型 TD(0) 的收敛条件

在有限状态空间、固定策略 π 下, 若:

1. 奖励有界;
2. 策略诱导的 Markov 链适当遍历;
3. 每个相关状态被访问无限多次;
4. 步长满足 Robbins-Monro 条件

$$\sum_{t=0}^{\infty} \alpha_t(s) = \infty, \quad \sum_{t=0}^{\infty} \alpha_t(s)^2 < \infty, \quad (32.9)$$

则表格型 TD(0) 在标准技术条件下几乎必然收敛到 V^π 。

固定常数步长通常不会严格收敛到单点, 而是在随机噪声决定的邻域内波动。

32.4 SARSA

SARSA 的更新样本序列为 $S_t, A_t, R_t, S_{t+1}, A_{t+1}$, 故其名称来自 State-Action-Reward-State-Action。



定义 SARSA TD error:

$$\delta_t^{\text{SARSA}} = R_t + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t). \quad (32.10)$$

更新为

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha_t \delta_t^{\text{SARSA}}. \quad (32.11)$$

这里 $A_{t+1} \sim \pi(\cdot | S_{t+1})$ 来自当前实际行为策略, 所以 SARSA 是 on-policy 方法。

32.4.1 ϵ -greedy 策略

给定动作价值估计 Q , 一个常用探索策略为

$$\pi_\epsilon(a | s) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}|}, & a \in \arg \max_{a'} Q(s, a') \text{ 且采用固定 tie-breaking,} \\ \frac{\epsilon}{|\mathcal{A}|}, & \text{其他动作.} \end{cases} \quad (32.12)$$

若希望 SARSA 在表格型有限 MDP 中收敛到最优策略, 常要求 GLIE:

- 每个状态动作对被访问无限多次;
- 策略在极限中变为 greedy, 例如 $\epsilon_t \rightarrow 0$.

32.5 Q-Learning

最优动作价值满足 $Q^* = \mathcal{T}_Q^* Q^*$, 其中

$$(\mathcal{T}_Q^* Q)(s, a) = r(s, a) + \gamma \sum_{s'} P(s' | s, a) \max_{a'} Q(s', a'). \quad (32.13)$$

Q-learning 用单个转移样本近似该期望:

$$\delta_t^Q = R_t + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t). \quad (32.14)$$

更新为

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha_t \delta_t^Q. \quad (32.15)$$

Q-learning 的 target 使用 $\max_{a'} Q(S_{t+1}, a')$, 而不是环境中实际执行的下一动作, 所以是 off-policy 方法。


32.5.1 SARSA 与 Q-Learning 的本质区别

$$Y_t^{\text{SARSA}} = R_t + \gamma Q(S_{t+1}, A_{t+1}), \quad (32.16)$$

$$Y_t^Q = R_t + \gamma \max_{a'} Q(S_{t+1}, a'). \quad (32.17)$$

因此:

- SARSA 学习当前行为策略的价值, 并同步改善该策略;
- Q-learning 即使由探索策略收集数据, 也试图学习 greedy target policy;



- SARSA 对当前探索风险更敏感;
- Q-learning 允许 replay buffer、旧策略数据等更灵活的数据来源。

定理 32.1 (表格型 Q-learning 的经典收敛结论). 考虑有限折扣 MDP。若:

1. 奖励有界;
2. 每个 (s, a) 被访问无限多次;
3. 对每个 (s, a) , 对应更新步长满足 $\sum_t \alpha_t(s, a) = \infty$, $\sum_t \alpha_t(s, a)^2 < \infty$;
4. 采样噪声满足标准条件;

则表格型 Q-learning 几乎必然收敛到 Q^* 。

该结论不能直接推广到任意非线性神经网络函数逼近。

32.6 函数逼近与 Deep Q-Network

令神经网络 $Q_w(s, a)$ 逼近最优动作价值。

对样本 $(s_t, a_t, r_t, s_{t+1}, d_t)$, 其中 $d_t = \begin{cases} 1, & s_{t+1} \text{ 为终止状态,} \\ 0, & \text{否则,} \end{cases}$ DQN target 为

$$y_t = r_t + \gamma(1 - d_t) \max_{a'} Q_{\bar{w}}(s_{t+1}, a'). \quad (32.18)$$

损失为

$$\mathcal{L}_Q(w) = \mathbb{E} \left[\frac{1}{2} (Q_w(s_t, a_t) - \text{stopgrad}(y_t))^2 \right]. \quad (32.19)$$

32.6.1 Experience Replay

将转移 $(s_t, a_t, r_t, s_{t+1}, d_t)$ 存入 replay buffer, 训练时随机抽取 mini-batch。

作用包括:

- 降低连续转移之间的强时间相关性;
- 重复利用历史数据;
- 支持 off-policy learning。

Replay sampling 并不会使数据严格变成独立同分布, 但通常显著减弱相邻样本相关性。

32.6.2 Target Network

目标参数 $\bar{w}$ 在若干步内固定, 然后周期性复制:

$$\bar{w} \leftarrow w, \quad (32.20)$$

或使用 Polyak update:

$$\bar{w} \leftarrow \tau w + (1 - \tau) \bar{w}. \quad (32.21)$$

Target network 的主要作用是减弱 moving target, 而不是从根本上消除 max 引起的过估计偏差。



32.6.3 Double DQN

使用 online network 选择动作：

$$a^* = \arg \max_{a'} Q_w(s_{t+1}, a'), \quad (32.22)$$

使用 target network 评估该动作：

$$y_t^{\text{Double}} = r_t + \gamma(1 - d_t)Q_{\bar{w}}(s_{t+1}, a^*). \quad (32.23)$$

这可缓解选择噪声与评估噪声共用同一最大化操作导致的过估计。

32.7 Deadly Triad

以下三项同时存在时容易发生不稳定或发散：

1. function approximation;
2. bootstrapping;
3. off-policy learning。

DQN 同时包含三者，因此 replay buffer、target network、gradient clipping、reward normalization 等稳定化技术很重要，但这些技术并不构成无条件收敛证明。

易错点、反例与失败模式

1. SARSA 并非“总是比 Q-learning 更稳定”；稳定性取决于函数逼近、探索策略、步长和环境。
2. Q-learning 的 off-policy 性并不意味着数据可以任意分布。至少需要行为数据对重要状态动作具有足够覆盖。
3. 神经网络 DQN 最小化的是 sample Bellman error 的 semi-gradient 目标，不是一般意义下对 $\|Q - Q^*\|$ 的直接凸优化。
4. $\mathbb{E}[\max_a \hat{Q}_a] \geq \max_a \mathbb{E}[\hat{Q}_a]$ 是 max 产生过估计倾向的基本原因。



第三十三章 策略梯度定理、REINFORCE 与 Actor-Critic

33.1 参数化策略目标

令 $\pi_{\theta}(a | s)$ 为关于 θ 可微的随机策略。

定义目标

$$J(\theta) := \mathbb{E}_{\tau \sim p_{\theta}} [G_0] = \mathbb{E}_{\tau \sim p_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t R_t \right]. \quad (33.1)$$

若起点固定为 s_0 ，则 $J(\theta) = V^{\pi_{\theta}}(s_0)$ 。若 $S_0 \sim \mu_0$ ，则 $J(\theta) = \mathbb{E}_{S_0 \sim \mu_0} V^{\pi_{\theta}}(S_0)$ 。

33.2 折扣状态访问分布

定义未归一化的折扣状态访问测度：

$$\rho_{\gamma}^{\pi}(s) := \sum_{t=0}^{\infty} \gamma^t \Pr_{\pi}(S_t = s). \quad (33.2)$$

有

$$\sum_s \rho_{\gamma}^{\pi}(s) = \sum_{t=0}^{\infty} \gamma^t = \frac{1}{1-\gamma}. \quad (33.3)$$

定义归一化折扣状态分布：

$$d_{\gamma}^{\pi}(s) := (1-\gamma) \rho_{\gamma}^{\pi}(s). \quad (33.4)$$

于是 $\sum_s d_{\gamma}^{\pi}(s) = 1$ 。

易错点、反例与失败模式


一般情况下， d_{γ}^{π} 不是策略诱导 Markov 链的平稳分布。

它依赖初始分布 μ_0 和折扣因子 γ ，是对不同时刻状态分布的折扣混合。

33.3 Likelihood-Ratio 恒等式

对任意可微概率密度或概率质量函数 $p_{\theta}(x) > 0$ ，有

$$\nabla_{\theta} p_{\theta}(x) = p_{\theta}(x) \nabla_{\theta} \log p_{\theta}(x). \quad (33.5)$$



因此

$$\nabla_{\theta} \mathbb{E}_{X \sim p_{\theta}} [f(X)] = \mathbb{E}_{X \sim p_{\theta}} [f(X) \nabla_{\theta} \log p_{\theta}(X)], \quad (33.6)$$

只要微分与积分可以交换。

33.4 Policy Gradient Theorem

定理 33.1 (策略梯度定理). 在环境动力学不依赖 θ 、奖励有界且相关微分与期望可交换的条件下,

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) Q^{\pi_{\theta}}(S_t, A_t) \right]. \quad (33.7)$$

等价地,

$$\nabla_{\theta} J(\theta) = \sum_s \rho_{\gamma}^{\pi_{\theta}}(s) \sum_a \pi_{\theta}(a | s) \nabla_{\theta} \log \pi_{\theta}(a | s) Q^{\pi_{\theta}}(s, a) \quad (33.8)$$

$$= \frac{1}{1-\gamma} \mathbb{E}_{\substack{S \sim d_{\gamma}^{\pi_{\theta}}, \\ A \sim \pi_{\theta}(\cdot | S)}} [\nabla_{\theta} \log \pi_{\theta}(A | S) Q^{\pi_{\theta}}(S, A)]. \quad (33.9)$$

证明. 先对有限 horizon T 推导, 最后令 $T \rightarrow \infty$ 。

根据 likelihood-ratio identity:

$$\begin{aligned} \nabla_{\theta} J_T(\theta) &= \nabla_{\theta} \sum_{\tau} p_{\theta}(\tau) G_0(\tau) \\ &= \sum_{\tau} p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau) G_0(\tau) \\ &= \mathbb{E}_{\tau} \left[G_0 \sum_{k=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(A_k | S_k) \right]. \end{aligned} \quad (33.10)$$

展开 $G_0 = \sum_{t=0}^{T-1} \gamma^t R_t$

$$\nabla J_T = \mathbb{E} \left[\sum_{k=0}^{T-1} \nabla \log \pi_{\theta}(A_k | S_k) \sum_{t=0}^{T-1} \gamma^t R_t \right]. \quad (33.11)$$

当 $t < k$ 时, R_t 在选择 A_k 之前已确定。令 $\mathcal{H}_k$ 表示选择 A_k 前的历史, 则

$$\begin{aligned} &\mathbb{E} [R_t \nabla_{\theta} \log \pi_{\theta}(A_k | S_k)] \\ &= \mathbb{E} [R_t \mathbb{E} [\nabla_{\theta} \log \pi_{\theta}(A_k | S_k) | \mathcal{H}_k]] \\ &= \mathbb{E} \left[R_t \sum_a \pi_{\theta}(a | S_k) \nabla_{\theta} \log \pi_{\theta}(a | S_k) \right] \\ &= \mathbb{E} \left[R_t \nabla_{\theta} \sum_a \pi_{\theta}(a | S_k) \right] = 0. \end{aligned} \quad (33.12)$$

因此所有先于动作 A_k 的奖励均可删除:

$$\begin{aligned} \nabla J_T &= \mathbb{E} \left[\sum_{k=0}^{T-1} \nabla \log \pi_{\theta}(A_k | S_k) \sum_{t=k}^{T-1} \gamma^t R_t \right] \\ &= \mathbb{E} \left[\sum_{k=0}^{T-1} \gamma^k \nabla \log \pi_{\theta}(A_k | S_k) G_k^{(T)} \right], \end{aligned} \quad (33.13)$$



其中 $G_k^{(T)} = \sum_{j=0}^{T-k-1} \gamma^j R_{k+j}$ 。

再利用条件期望：

$$\begin{aligned} & \mathbb{E}[G_k \nabla \log \pi_{\theta}(A_k | S_k)] \\ &= \mathbb{E}[\nabla \log \pi_{\theta}(A_k | S_k) \mathbb{E}[G_k | S_k, A_k]] \\ &= \mathbb{E}[\nabla \log \pi_{\theta}(A_k | S_k) Q^{\pi_{\theta}}(S_k, A_k)]. \end{aligned} \quad (33.14)$$

令 $T \rightarrow \infty$ 即得轨迹形式。

最后按状态访问次数整理：

$$\begin{aligned} \nabla J &= \sum_{t=0}^{\infty} \gamma^t \sum_s \Pr(S_t = s) \sum_a \pi_{\theta}(a | s) \nabla \log \pi_{\theta}(a | s) Q^{\pi}(s, a) \\ &= \sum_s \rho_{\gamma}^{\pi}(s) \sum_a \pi_{\theta}(a | s) \nabla \log \pi_{\theta}(a | s) Q^{\pi}(s, a). \end{aligned} \quad (33.15)$$

再使用 $d_{\gamma}^{\pi} = (1 - \gamma)\rho_{\gamma}^{\pi}$ 得到归一化形式。 $\square$

33.5 状态基线不改变期望

定理 33.2 (Baseline Theorem). 对任意只依赖状态而不依赖当前动作的函数 $b: \mathcal{S} \rightarrow \mathbb{R}$, 有

$$\mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^{\infty} \gamma^t \nabla_{\theta} \log \pi_{\theta}(A_t | S_t) b(S_t) \right] = 0. \quad (33.16)$$

证明. 固定状态 s ,

$$\begin{aligned} & \mathbb{E}_{A \sim \pi_{\theta}(\cdot | s)} [\nabla_{\theta} \log \pi_{\theta}(A | s) b(s)] \\ &= b(s) \sum_a \pi_{\theta}(a | s) \nabla_{\theta} \log \pi_{\theta}(a | s) \\ &= b(s) \sum_a \nabla_{\theta} \pi_{\theta}(a | s) \\ &= b(s) \nabla_{\theta} \sum_a \pi_{\theta}(a | s) \\ &= b(s) \nabla_{\theta} 1 = 0. \end{aligned} \quad (33.17)$$

再对状态和时间取期望即可。 $\square$


因此

$$\nabla J(\theta) = \mathbb{E}_{\pi} \left[\sum_t \gamma^t \nabla \log \pi_{\theta}(A_t | S_t) (Q^{\pi}(S_t, A_t) - b(S_t)) \right]. \quad (33.18)$$

标准选择为 $b(s) = V^{\pi}(s)$, 从而

$$Q^{\pi}(s, a) - b(s) = A^{\pi}(s, a). \quad (33.19)$$

基线的作用是降低估计方差，而不是改变目标函数的真实梯度。



33.5.1 严格的最小方差状态基线

令 $\mathbf{g}_\theta(s, a) = \nabla_\theta \log \pi_\theta(a | s)$ 。对固定状态 s ，若最小化

$$\mathbb{E}_{a \sim \pi} [\|\mathbf{g}_\theta(s, a)[Q^\pi(s, a) - b]\|_2^2], \quad (33.20)$$

则最优标量基线为

$$b^*(s) = \frac{\mathbb{E}_{a \sim \pi} [Q^\pi(s, a) \|\mathbf{g}_\theta(s, a)\|_2^2]}{\mathbb{E}_{a \sim \pi} [\|\mathbf{g}_\theta(s, a)\|_2^2]}. \quad (33.21)$$

因此 $V^\pi(s)$ 是最常用、语义清晰且通常有效的基线，但在一般参数化下不一定是严格的方差最小化基线。

易错点、反例与失败模式

1. 基线不得任意依赖当前动作。若写成 $b(s, a)$ ，则 $\sum_a \pi(a | s) \nabla \log \pi(a | s) b(s, a)$ 一般不为零。
2. 若 baseline network 与 actor 共享参数，actor loss 中通常要对 advantage 使用 stopgrad，否则会额外引入通过基线传播的梯度。
3. 减去基线不降低 estimator 的维数，它降低的是随机梯度的方差。

33.6 REINFORCE

对一条有限 episode，定义

$$G_t = \sum_{k=t}^{T-1} \gamma^{k-t} R_k. \quad (33.22)$$

与 $J(\theta) = \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t R_t \right]$ 严格一致的 Monte-Carlo 梯度估计为

$$\hat{\mathbf{g}}_{\text{RF}} = \sum_{t=0}^{T-1} \gamma^t \nabla_\theta \log \pi_\theta(A_t | S_t) [G_t - b(S_t)]. \quad (33.23)$$

梯度上升更新：

$$\theta \leftarrow \theta + \alpha \hat{\mathbf{g}}_{\text{RF}}. \quad (33.24)$$

若将 return 定义为绝对折扣 $\tilde{G}_t = \sum_{k=t}^{T-1} \gamma^k R_k$ ，则不需要再额外乘 γ^t 。两种写法等价，但定义不能混用。

REINFORCE：

- 不需要环境可微；
- 可学习随机策略；
- 使用完整 Monte-Carlo return，方差较高；
- 更新必须等待足够长的 rollout；
- 适合离散或连续动作，只需能够计算 $\log \pi_\theta(a | s)$ 。



33.7 Actor-Critic

Actor-Critic 同时维护:

- actor: $\pi_{\theta}(a | s)$;
- critic: $V_w(s)$ 或 $Q_w(s, a)$.

Critic 近似策略评估, Actor 执行策略改进。

33.7.1 TD Error 是 Advantage 的一步估计

若 critic 为真实价值 V^{π} , 定义

$$\delta_t^{\pi} = R_t + \gamma V^{\pi}(S_{t+1}) - V^{\pi}(S_t). \quad (33.25)$$

则

$$\begin{aligned} \mathbb{E}[\delta_t^{\pi} | S_t = s, A_t = a] &= r(s, a) + \gamma \sum_{s'} P(s' | s, a) V^{\pi}(s') - V^{\pi}(s) \\ &= Q^{\pi}(s, a) - V^{\pi}(s) \\ &= A^{\pi}(s, a). \end{aligned} \quad (33.26)$$

所以可用 TD error 替代高方差 Monte-Carlo advantage。

33.7.2 一步 Actor-Critic 更新

使用 critic V_w :

$$\delta_t = R_t + \gamma(1 - d_t)V_w(S_{t+1}) - V_w(S_t). \quad (33.27)$$

Critic 的 semi-gradient 更新:

$$\boxed{\mathbf{w} \leftarrow \mathbf{w} + \beta \delta_t \nabla_{\mathbf{w}} V_w(S_t).} \quad (33.28)$$

Actor 更新:

$$\boxed{\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \gamma^t \text{stopgrad}(\delta_t) \nabla_{\boldsymbol{\theta}} \log \pi_{\boldsymbol{\theta}}(A_t | S_t).} \quad (33.29)$$

可加入 entropy bonus:

$$J_{\text{ent}}(\boldsymbol{\theta}) = J(\boldsymbol{\theta}) + \tau \mathbb{E} [\mathcal{H}(\pi_{\boldsymbol{\theta}}(\cdot | S_t))], \quad (33.30)$$

其中

$$\mathcal{H}(\pi(\cdot | s)) = - \sum_a \pi(a | s) \log \pi(a | s). \quad (33.31)$$

Entropy regularization 鼓励探索, 但过大的 τ 会阻止策略充分集中于高价值动作。

33.8 n -Step Return

定义

$$G_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l R_{t+l} + \gamma^n V_w(S_{t+n}). \quad (33.32)$$



相应 advantage estimator 为

$$\hat{A}_t^{(n)} = G_t^{(n)} - V_{\mathbf{w}}(S_t). \quad (33.33)$$

- $n = 1$: 一步 TD, 低方差、高 bootstrap bias;
- $n = T - t$: Monte-Carlo, 低 bootstrap bias、高方差;
- 中间 n : 在偏差和方差之间折中。

33.9 Generalized Advantage Estimation

定义一步 TD residual:

$$\delta_t = R_t + \gamma V_{\mathbf{w}}(S_{t+1}) - V_{\mathbf{w}}(S_t). \quad (33.34)$$

GAE 为

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}, \quad \lambda \in [0, 1]. \quad (33.35)$$

有限 episode 中在终止处截断。

- $\lambda = 0$: 一步 TD advantage;
- $\lambda \rightarrow 1$: 接近 Monte-Carlo advantage;
- λ 增大通常降低 bootstrap bias、提高方差。

33.10 Actor-Critic 的 Model-Free 解释

在模型已知的 policy iteration 中:

evaluation $V^\pi = (\mathbf{I} - \gamma P^\pi)^{-1} \mathbf{r}^\pi$, improvement $\pi'(s) \in \arg \max_a Q^\pi(s, a)$ 。

在模型未知时:

- critic 使用 MC、TD、SARSA 或其他采样方法估计 V^π, Q^π, A^π ;
- actor 使用 $\nabla \log \pi_\theta(a | s) \hat{A}(s, a)$ 对策略进行局部梯度改进。

因此 Actor-Critic 可视为可微参数化、采样型的近似策略迭代。

答题方法

[25F-B-Q3, 10 分] 的满分框架:

(a) 策略梯度定理, 6 分:

1. 写轨迹概率 $p_\theta(\tau) = \mu_0(s_0) \prod_t \pi_\theta(a_t | s_t) P(s_{t+1} | s_t, a_t)$;
2. 写 $\nabla \log p_\theta(\tau) = \sum_t \nabla \log \pi_\theta(a_t | s_t)$;
3. 用 likelihood-ratio trick: $\nabla J = \mathbb{E}[G_0 \nabla \log p_\theta(\tau)]$;
4. 利用 causality 删除动作之前的奖励;
5. 将 reward-to-go 的条件期望替换为 $Q^\pi(s_t, A_t)$;
6. 定义 $\rho^\pi(s) = \sum_t \gamma^t \Pr(S_t = s)$, $d^\pi = (1 - \gamma) \rho^\pi$;

7. 得到 $\nabla J = \frac{1}{1-\gamma} \mathbb{E}_{S \sim d^\pi, A \sim \pi} [\nabla \log \pi(A | S) Q^\pi(S, A)]$.

(b) 基线, 4 分:

1. 对固定 s 写 $\sum_a \pi(a | s) \nabla \log \pi(a | s) b(s) = b(s) \nabla \sum_a \pi(a | s) = 0$;
2. 因而可将 Q^π 替换为 $Q^\pi - b$;
3. 在 advantage method 中选 $b(s) = V^\pi(s)$;
4. 得到 $Q^\pi(s, a) - V^\pi(s) = A^\pi(s, a)$;
5. 说明该选择保持无偏, 并通常显著降低梯度方差。



第三十四章 RLHF、PPO 与 Direct Preference Optimization

34.1 语言模型作为强化学习策略

给定 prompt $x = (x_1, \dots, x_m)$, 语言模型生成 completion $y = (y_1, \dots, y_T)$ 。

可将自回归生成视为 episodic MDP:

- 状态: $s_t = (x, y_{<t})$;
- 动作: $a_t = y_t$;
- 策略: $\pi_{\theta}(a_t | s_t) = \pi_{\theta}(y_t | x, y_{<t})$;
- 转移: 将 token y_t 追加到前缀, 通常是确定性的;
- 终止: 生成 EOS 或达到最大长度;
- 奖励: 可在终止时由 reward model 给出 sequence-level reward。

完整 completion 的条件概率为

$$\pi_{\theta}(y | x) = \prod_{t=1}^T \pi_{\theta}(y_t | x, y_{<t}), \quad (34.1)$$

故

$$\log \pi_{\theta}(y | x) = \sum_{t=1}^T \log \pi_{\theta}(y_t | x, y_{<t}). \quad (34.2)$$

实际计算偏好损失时, 通常只对 completion token 求和, 不把 prompt token 的 log-probability 计入策略目标。

34.2 偏好数据

偏好数据集写为

$$\mathcal{D}_{\text{pref}} = \{(x_i, y_i^+, y_i^-)\}_{i=1}^N, \quad (34.3)$$

其中 $y_i^+ \succ y_i^-$ 表示人类或偏好标注器认为 y_i^+ 优于 y_i^- 。

偏好可能综合:

- helpfulness;



- correctness;
- harmlessness;
- instruction following;
- style;
- factuality。

因此偏好标签通常是带噪声且依赖标注规范的，并不代表存在唯一、客观、无争议的真实奖励。

34.3 Bradley–Terry 奖励模型

设奖励模型为 $r_\psi(x, y) \in \mathbb{R}$ 。Bradley–Terry 模型假设

$$\Pr_\psi(y^+ \succ y^- \mid x) = \sigma(r_\psi(x, y^+) - r_\psi(x, y^-)), \quad (34.4)$$

其中 $\sigma(z) = \frac{1}{1+e^{-z}}$ 。

奖励模型损失为

$$\mathcal{L}_{\text{RM}}(\psi) = -\mathbb{E}_{(x, y^+, y^-) \sim \mathcal{D}_{\text{pref}}} \log \sigma(r_\psi(x, y^+) - r_\psi(x, y^-)). \quad (34.5)$$

由于概率只依赖奖励差，对任意只依赖 prompt 的函数 $c(x)$ ， $r'_\psi(x, y) = r_\psi(x, y) + c(x)$ 给出相同偏好概率。因此奖励函数只在 prompt-dependent additive constant 意义下可辨识。

34.4 KL 正则化的 RLHF 目标

令 $\pi_{\text{ref}}(y \mid x)$ 为冻结的参考策略，通常来自 supervised fine-tuning。

经典序列级 KL 正则化目标为

$$J_{\text{RLHF}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}_x} [\mathbb{E}_{y \sim \pi_\theta(\cdot \mid x)} r_\psi(x, y) - \beta \text{KL}(\pi_\theta(\cdot \mid x) \parallel \pi_{\text{ref}}(\cdot \mid x))], \quad (34.6)$$

其中 $\beta > 0$ 。

KL 项展开为

$$\begin{aligned} & \text{KL}(\pi_\theta(\cdot \mid x) \parallel \pi_{\text{ref}}(\cdot \mid x)) \\ &= \mathbb{E}_{y \sim \pi_\theta} \left[\log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)} \right]. \end{aligned} \quad (34.7)$$

所以目标也可写成

$$J_{\text{RLHF}}(\theta) = \mathbb{E}_{\substack{x \sim \mathcal{D}_x, \\ y \sim \pi_\theta(\cdot \mid x)}} \left[r_\psi(x, y) - \beta \log \frac{\pi_\theta(y \mid x)}{\pi_{\text{ref}}(y \mid x)} \right]. \quad (34.8)$$

KL 正则化的作用是：

- 限制策略偏离 SFT/reference policy;
- 缓解 reward hacking;
- 保持语言流畅性和基础能力;
- 改善训练稳定性。

但 KL 过强会使策略几乎无法利用偏好信号；KL 过弱会导致策略过度追逐奖励模型漏洞。



34.5 KL 正则化目标的最优策略

固定 prompt x , 记 $q(y) = \pi_{\text{ref}}(y | x)$, $r(y) = r(x, y)$ 。考虑在所有分布 π 上优化

$$\max_{\pi} \left\{ \sum_y \pi(y) r(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{q(y)} \right\} \quad (34.9)$$

满足 $\sum_y \pi(y) = 1$ 。

定理 34.1 (KL 正则化奖励最大化的闭式最优解). 若 $q(y) > 0$ 覆盖所有允许输出, 则

$$\pi^*(y | x) = \frac{\pi_{\text{ref}}(y | x) \exp(r(x, y)/\beta)}{Z(x)}, \quad (34.10)$$

其中

$$Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp(r(x, y)/\beta). \quad (34.11)$$

证明. 构造 Lagrangian:

$$\begin{aligned} \mathcal{J}(\pi, \lambda) = & \sum_y \pi(y) r(y) - \beta \sum_y \pi(y) \log \frac{\pi(y)}{q(y)} \\ & + \lambda \left(\sum_y \pi(y) - 1 \right). \end{aligned} \quad (34.12)$$

对 $\pi(y)$ 求导:

$$r(y) - \beta \left[\log \frac{\pi(y)}{q(y)} + 1 \right] + \lambda = 0. \quad (34.13)$$

因此

$$\log \frac{\pi(y)}{q(y)} = \frac{r(y)}{\beta} + \frac{\lambda - \beta}{\beta}. \quad (34.14)$$

即 $\pi(y) = C q(y) e^{r(y)/\beta}$ 。用归一化条件确定 $C = Z(x)^{-1}$ 。□

等价地,

$$r(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x). \quad (34.15)$$

这表明最优策略与参考策略的 log-ratio 可以隐式表示奖励。

34.6 PPO 型 RLHF 更新

Reward-model-based RLHF 常用 PPO 优化策略。


定义 old policy ratio:

$$r_t(\theta) = \frac{\pi_{\theta}(A_t | S_t)}{\pi_{\text{old}}(A_t | S_t)}. \quad (34.16)$$

PPO clipped surrogate 为

$$\mathcal{L}_{\text{PPO}}^{\text{clip}}(\theta) = \mathbb{E} \left[\min \left\{ r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right\} \right]. \quad (34.17)$$

完整实现还常包括:



- value-function loss;
- entropy bonus;
- 对 reference policy 的 KL penalty;
- reward/advantage normalization;
- gradient clipping。

PPO clipping 是稳定训练的 surrogate heuristic，不能无条件保证每一步真实策略性能单调提升。

34.7 DPO 的推导

DPO 的关键是将隐式奖励式 (34.15) 代入 Bradley-Terry 偏好模型。

对于偏好对 $y^+ \succ y^-$ ，奖励差为

$$\begin{aligned} r(x, y^+) - r(x, y^-) \\ = \beta \left[\log \frac{\pi^*(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} - \log \frac{\pi^*(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right], \end{aligned} \quad (34.18)$$

因为 $\beta \log Z(x)$ 在差分中抵消。

用可训练策略 π_{θ} 参数化 π^* ，定义

$$\begin{aligned} z_{\theta}(x, y^+, y^-) := \beta \left[\log \frac{\pi_{\theta}(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} \right. \\ \left. - \log \frac{\pi_{\theta}(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right]. \end{aligned} \quad (34.19)$$

Bradley-Terry 概率变为

$$\Pr_{\theta}(y^+ \succ y^- | x) = \sigma(z_{\theta}). \quad (34.20)$$

因此 DPO 损失为

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y^+, y^-) \sim \mathcal{D}_{\text{pref}}} \log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} - \log \frac{\pi_{\theta}(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right] \right). \quad (34.21)$$

亦可写为

$$\begin{aligned} \mathcal{L}_{\text{DPO}} = -\mathbb{E} \log \sigma \left(\beta \left[\log \pi_{\theta}(y^+ | x) - \log \pi_{\theta}(y^- | x) \right. \right. \\ \left. \left. - \log \pi_{\text{ref}}(y^+ | x) + \log \pi_{\text{ref}}(y^- | x) \right] \right). \end{aligned} \quad (34.22)$$

34.8 DPO 梯度的方向

令 $z = z_{\theta}(x, y^+, y^-)$ 。单样本损失为 $\ell = -\log \sigma(z)$ 。由于 $\frac{d\ell}{dz} = -\sigma(-z)$ ，有

$$\nabla_{\theta} \ell = -\beta \sigma(-z) \left[\nabla_{\theta} \log \pi_{\theta}(y^+ | x) - \nabla_{\theta} \log \pi_{\theta}(y^- | x) \right]. \quad (34.23)$$

梯度下降因此：



- 提高 preferred response 的相对 log-probability;
- 降低 dispreferred response 的相对 log-probability;
- 当模型已高度正确排序、 z 很大时, $\sigma(-z)$ 较小, 更新自动减弱;
- reference log-ratio 固定, 不对 π_{ref} 反向传播。

34.9 DPO 训练算法

答题方法

DPO 训练流程:

1. 从 SFT 模型初始化 π_{θ} ;
2. 冻结一份参考模型 π_{ref} ;
3. 采样 preference mini-batch (x, y^+, y^-) ;
4. 计算 completion token 的 log-probability: $\log \pi_{\theta}(y^{\pm} | x) = \sum_t \log \pi_{\theta}(y_t^{\pm} | x, y_{<t}^{\pm})$;
5. 同样计算冻结 reference 的 $\log \pi_{\text{ref}}(y^{\pm} | x)$;
6. 构造 $z = \beta \left[\log \frac{\pi_{\theta}(y^+ | x)}{\pi_{\text{ref}}(y^+ | x)} - \log \frac{\pi_{\theta}(y^- | x)}{\pi_{\text{ref}}(y^- | x)} \right]$;
7. 最小化 $-\log \sigma(z)$;
8. 只更新 θ 。

DPO 不需要:

- 显式训练单独 reward model;
- 在线从当前策略反复 rollout;
- 单独 critic/value network;
- PPO 的 ratio clipping。


但它仍需要:

- preference dataset;
- reference policy;
- chosen/rejected completion;
- 对模型序列概率的精确计算。

34.10 DPO 等价性的假设边界

DPO 与 KL-regularized RLHF 的关系依赖以下建模假设:

1. 人类偏好由 Bradley-Terry 型 latent reward 生成: $P(y^+ \succ y^-) = \sigma(r^+ - r^-)$;
2. 目标策略是某个 KL 正则化奖励最大化问题的最优解;



3. reference policy 固定；
4. preference pair 落在 reference policy 和训练策略能够表示的有效 support 内；
5. 离线 preference dataset 对目标输出区域有足够覆盖。

因此不能无条件声称：DPO 与所有形式的 RLHF 完全等价。

更准确的说法是：在指定的 Bradley-Terry 偏好模型和 KL 正则化策略最优性关系下，可消去显式奖励变量，得到 DPO logistic objective。

34.11 RLHF 与 DPO 的比较

表 34.1: Reward-model-based RLHF 与 DPO

比较项	Reward-model-based RLHF	DPO
偏好建模	先训练 $r_\psi(x, y)$	偏好 logistic loss 直接作用于策略 log-ratio
策略更新	通常使用 PPO、Actor-Critic 等在线或近在线 RL	监督学习式离线梯度下降
是否需要 reward model	需要	不需要显式 reward model
是否需要 critic	PPO 通常需要 value critic	不需要独立 critic
是否需要 reference policy	通常需要，用于 KL penalty	需要，显式出现在 DPO logit 中
数据需求	偏好数据加当前策略 rollout	离线 chosen/rejected preference pairs
主要优点	可利用任意可计算奖励，并可在线探索新输出	实现简单、稳定、计算开销较低
主要风险	reward hacking、训练复杂、PPO 不稳定	离线支持限制、长度偏差、偏好数据分布偏移

34.12 偏好优化的典型失败模式

1. Reward hacking。

策略发现奖励模型的漏洞，获得高预测奖励但不满足真实人类意图。

2. Preference overfitting。

模型记忆特定偏好数据风格，在未覆盖 prompt 分布上泛化较差。

3. Reference drift。

KL 约束过弱时，策略可能远离原语言模型并损害基础能力。

4. Length bias。

序列 log-probability 是 token log-probability 的和，长度差异可能系统性影响 chosen/rejected margin。



5. Label inconsistency。

不同标注者标准不同，同一 pair 可能存在冲突偏好。

6. Support limitation。

离线 DPO 只能学习 preference dataset 覆盖的相对比较，无法自动探索完全新的高奖励区域。

7. Implicit reward misspecification。

若真实偏好不符合单一标量奖励和 Bradley-Terry 差分模型，DPO 的理论消元关系只是近似。

34.13 扩展：Group-Relative Baseline

重要性等级：C

若对同一 prompt x 采样一组响应 $y_1, \dots, y_K$ 及其奖励 $R_1, \dots, R_K$ ，可用组内均值作为基线：

$$\bar{R} = \frac{1}{K} \sum_{i=1}^K R_i, \quad (34.24)$$

并定义标准化组内 advantage：

$$\hat{A}_i = \frac{R_i - \bar{R}}{\sqrt{K^{-1} \sum_{j=1}^K (R_j - \bar{R})^2 + \epsilon}}. \quad (34.25)$$

这类方法不需要独立 value critic，但仍可能使用 importance ratio、clipping 和 reference KL。组内均值是采样基线，不等同于精确状态价值函数。

答题方法

[26S-B-Q3(c)-(d), 共 4 分] 的满分框架：

(c) Actor-Critic, 2 分：

模型未知时不能直接计算 P^π ， $(\mathbf{I} - \gamma P^\pi)^{-1}$ 。因此：

- critic 用样本和 TD error $\delta_t = r_t + \gamma V_{\mathbf{w}}(s_{t+1}) - V_{\mathbf{w}}(s_t)$ 近似策略评估；
- actor 用 $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \delta_t \nabla_{\boldsymbol{\theta}} \log \pi_{\boldsymbol{\theta}}(a_t | s_t)$ 执行策略改进。

(d) RLHF 或 DPO, 2 分：

可选择以下任一答案。

答案 A：Reward-model-based RLHF。

先训练 $\mathcal{L}_{\text{RM}} = -\mathbb{E} \log \sigma(r_{\psi}(x, y^+) - r_{\psi}(x, y^-))$ 。再优化 $\max_{\boldsymbol{\theta}} \mathbb{E}_{x, y \sim \pi_{\boldsymbol{\theta}}} \left[r_{\psi}(x, y) - \beta \log \frac{\pi_{\boldsymbol{\theta}}(y|x)}{\pi_{\text{ref}}(y|x)} \right]$ 。

答案 B：DPO。

定义 $z_{\boldsymbol{\theta}} = \beta \left[\log \frac{\pi_{\boldsymbol{\theta}}(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \log \frac{\pi_{\boldsymbol{\theta}}(y^-|x)}{\pi_{\text{ref}}(y^-|x)} \right]$ ，最小化 $\mathcal{L}_{\text{DPO}} = -\mathbb{E} \log \sigma(z_{\boldsymbol{\theta}})$ 。

必须定义：

- x : prompt;
- y^+ : preferred completion;
- y^- : dispreferred completion;

- π_θ : 待训练策略;
- π_{ref} : 冻结参考策略;
- $\beta > 0$: KL 正则化对应的温度或权重参数。

34.14 强化学习统一视角

表 34.2: 强化学习方法的统一比较

方法	学习对象	核心更新目标	On/Off Policy
Policy Evaluation	V^π	$V^\pi = \mathcal{T}^\pi V^\pi$	固定策略
Value Iteration	V^*	$V_{k+1} = \mathcal{T}^* V_k$	模型已知
Monte-Carlo	V^π, Q^π	完整 return	通常 on-policy
TD(0)	V^π	$r + \gamma V(s')$	通常 on-policy evaluation
SARSA	当前行为策略的 Q^π	$r + \gamma Q(s', a')$	On-policy
Q-learning	Q^*	$r + \gamma \max_{a'} Q(s', a')$	Off-policy
REINFORCE	π_θ	$G_t \nabla \log \pi_\theta$	On-policy
Actor-Critic	策略加价值函数	$\delta_t \nabla \log \pi_\theta$	经典形式 on-policy
PPO	受限策略更新	clipped importance-ratio surrogate	近似 on-policy
DPO	语言模型策略	chosen/rejected reference-relative margin	离线偏好优化

34.15 综合易错点

易错点、反例与失败模式

1. Markov 性是 $P(S_{t+1}, R_t \mid \text{完整历史}) = P(S_{t+1}, R_t \mid S_t, A_t)$, 不是说状态之间相互独立。
2. $V^\pi(s) = \sum_a \pi(a \mid s) Q^\pi(s, a)$, 但 $Q^\pi(s, a) \neq r(s, a) + \gamma V^\pi(s)$; 下一价值应在 S_{t+1} 上取期望。
3. V^* 唯一, 但 π^* 可能不唯一。
4. Policy iteration 中先评估当前策略, 再对 Q^{π^k} 贪心改进; 不能直接用尚未计算的 Q^* 。
5. Value iteration 的每一步并不是完整 policy evaluation。
6. Monte-Carlo 不 bootstrap, TD 会 bootstrap。
7. SARSA 的 target 使用实际下一动作; Q-learning 使用下一状态的 greedy action。

8. Q-learning 的 off-policy 性不意味着无需探索。
9. DQN 中 target 必须 stop-gradient；否则会变成不同的 residual-gradient 问题。
10. Policy gradient 中环境转移项不含 θ ，才能在轨迹 score 中消失。
11. Reward-to-go 可以删除过去奖励，是因为未来动作不能影响过去奖励。
12. 状态基线保持无偏的条件是其不依赖当前动作。
13. d_γ^π 是归一化折扣访问分布，不是一般意义的平稳分布。
14. Critic 不精确时， δ_t 不再是严格无偏的真实 advantage estimator。
15. Actor-Critic 同时存在 actor 和 critic；仅训练 Q 网络不是 Actor-Critic。
16. RLHF 中 reward model loss 与 policy loss 是两个不同阶段。
17. DPO 不训练显式 reward model，但仍使用固定 reference policy。
18. DPO 优化的是 reference-relative preference margin，不是简单最大化 $\log \pi_\theta(y^+ | x)$ 。
19. DPO 与 KL-regularized RLHF 的关系依赖 Bradley-Terry 和最优策略形式等假设。
20. PPO clipping 是 surrogate；它不是严格的 trust-region constraint，也不自动给出单调改进定理。
21. 语言模型序列概率是 token 条件概率的乘积，序列 log-probability 是 token log-probability 的和。

34.16 历年真题映射

表 34.3: 第 10 部分真题映射

真题	主要标签	满分不可缺少内容
[25F-B-Q3(a), 6 分]	Policy Gradient Theorem	轨迹概率；log-derivative；causality；reward-to-go； Q^π ；折扣占用分布
[25F-B-Q3(b), 4 分]	Baseline 与 Advantage	$\sum_a \pi \nabla \log \pi = \nabla 1 = 0$ ； $b(s) = V^\pi(s)$ ；方差降低
[26S-B-Q3(a), 2 分]	Bellman equation	$G_t = R_t + \gamma G_{t+1}$ ；对动作和下一状态展开期望
[26S-B-Q3(b), 2 分]	Policy Iteration	policy evaluation；greedy improvement；终止条件
[26S-B-Q3(c), 2 分]	Actor-Critic	critic 用 TD 做评估；actor 用 $\delta \nabla \log \pi$ 改进

真题	主要标签	满分不可缺少内容
[26S-B-Q3(d), 2 分]	RLHF 或 DPO	完整目标; reference policy; 偏好 pair; KL 或 logistic preference loss

34.17 快速自测

快速自测

1. MDP 的 Markov 性准确条件是什么?
2. 如何从 $G_t = R_t + \gamma G_{t+1}$ 推出 Bellman 期望方程?
3. 为什么 $\mathbf{I} - \gamma P^\pi$ 一定可逆?
4. 如何证明 $\mathcal{T}^\pi$ 是 γ -压缩映射?
5. Bellman 最优性 operator 为什么仍是压缩映射?
6. 最优价值函数是否唯一? 最优策略是否唯一?
7. Policy Improvement Theorem 的关键单调迭代是什么?
8. 策略迭代为什么在有限 MDP 中可以有限终止? 并列动作处理不当会产生什么问题?
9. Value iteration 与 policy iteration 的每轮工作有何区别?
10. Bellman residual 如何控制价值函数误差?
11. Monte-Carlo 和 TD(0) 分别是否 bootstrap?
12. SARSA 和 Q-learning 的 target 分别是什么?
13. 为什么 Q-learning 是 off-policy?
14. 表格型 Q-learning 收敛需要哪些访问和步长条件?
15. Experience replay 和 target network 分别解决什么问题?
16. Double DQN 如何降低 max 过估计?
17. 强化学习中的 deadly triad 是什么?
18. 如何从轨迹概率推导 $\nabla \log p_\theta(\tau) = \sum_t \nabla \log \pi_\theta(a_t | s_t)$?
19. Policy gradient 推导中为什么可以删除动作之前的奖励?
20. 未归一化占用测度 ρ_γ^π 与归一化分布 d_γ^π 的关系是什么?
21. 为什么状态基线不改变策略梯度期望?
22. 为什么 $b(s) = V^\pi(s)$ 会得到 advantage?
23. 严格最小方差状态基线为什么不一定恰好等于 $V^\pi(s)$?

24. REINFORCE 中何时应出现外部因子 γ^t ?
25. 若 critic 等于真实价值函数, 为什么 TD error 的条件期望等于 advantage?
26. 一步 TD、 n -step return 和 Monte-Carlo return 的偏差方差关系是什么?
27. GAE 中 $\lambda = 0$ 与 $\lambda \rightarrow 1$ 分别对应什么?
28. 语言模型如何被写成 episodic MDP?
29. Bradley-Terry 模型为何只辨识奖励差而不辨识绝对奖励?
30. KL-regularized RLHF 的闭式最优策略是什么?
31. 为什么 DPO 推导中 $\log Z(x)$ 会抵消?
32. 写出完整 DPO logit 和损失。
33. DPO 的梯度为何同时提升 preferred response 并压低 dispreferred response?
34. DPO 是否完全不需要参考模型?
35. DPO 与 RLHF 等价需要哪些建模假设?
36. PPO clipping 是否等价于严格 KL trust region?
37. Reward hacking、preference overfitting 和 support limitation 分别指什么?



第三部分

人工智能中的优化方法



第三十五章 凸集、投影、分离定理与 Farkas 引理

35.1 重要性等级与考试定位

重要性等级：A

- 凸集、投影和分离定理是次梯度、约束最优性、proximal operator、对偶性和一阶算法的共同几何前置。
- 三套博士资格考试没有单独设置“证明完整分离定理”的高分题，因而不得称其为历年实考高频独立题。
- 但是：
 - prox 非扩张性依赖次微分单调性；
 - 投影梯度依赖投影的变分不等式；
 - Farkas 引理和分离定理是可行性证书、KKT 条件和对偶理论的基础；
 - 复合优化最优性条件可由分离或次微分理论导出。
- 证明要求：
 - 投影存在唯一性与变分不等式：必须掌握完整证明；
 - 点与闭凸集的严格分离：必须掌握证明框架；
 - Farkas 引理：必须掌握“互斥性 + 分离证书”的完整框架。

35.2 统一空间与记号

除非另有说明，本部分工作在有限维 Euclidean 空间 $\mathbb{R}^d$ 中，内积和范数分别为

$$\langle \mathbf{x}, \mathbf{y} \rangle := \mathbf{x}^\top \mathbf{y}, \quad \|\mathbf{x}\| := \|\mathbf{x}\|_2. \quad (35.1)$$

对集合 $C \subseteq \mathbb{R}^d$ ，记：int C = 内部，cl C = 闭包，aff C = 仿射包，ri C = 相对内部， $\partial C = \text{cl } C \setminus \text{int } C$ = 边界。

相对内部是在最小仿射空间 aff C 中的内部。若 C 位于低维仿射子空间中，则普通内部可能为空，但相对内部仍可非空。

例如，二维直线段 $C = \{(t, 0) : 0 \leq t \leq 1\} \subseteq \mathbb{R}^2$ 满足 $\text{int}_{\mathbb{R}^2} C = \emptyset$ ，但 $\text{ri } C = \{(t, 0) : 0 < t < 1\}$ 。

35.3 凸集、仿射集与凸锥

定义 35.1 (凸集). 集合 $C \subseteq \mathbb{R}^d$ 称为凸集, 若

$$\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in C, \quad \forall \mathbf{x}, \mathbf{y} \in C, \quad \forall \theta \in [0, 1]. \quad (35.2)$$

等价地, C 包含任意两点之间的完整线段。

定义 35.2 (仿射集). 集合 $A \subseteq \mathbb{R}^d$ 称为仿射集, 若

$$\theta \mathbf{x} + (1 - \theta) \mathbf{y} \in A, \quad \forall \mathbf{x}, \mathbf{y} \in A, \quad \forall \theta \in \mathbb{R}. \quad (35.3)$$

非空仿射集必可写为

$$A = \mathbf{x}_0 + \mathcal{L}, \quad (35.4)$$

其中 $\mathcal{L}$ 是线性子空间。

定义 35.3 (锥与凸锥). 集合 $K \subseteq \mathbb{R}^d$ 称为锥, 若

$$\mathbf{x} \in K, \quad \alpha \geq 0 \implies \alpha \mathbf{x} \in K. \quad (35.5)$$

若 K 同时是凸集, 则称为凸锥。

凸锥等价地满足

$$\mathbf{x}, \mathbf{y} \in K, \quad \alpha, \beta \geq 0 \implies \alpha \mathbf{x} + \beta \mathbf{y} \in K. \quad (35.6)$$

常见例子包括:

$$\mathbb{R}_+^d = \{\mathbf{x} : x_i \geq 0, i = 1, \dots, d\}, \quad (35.7)$$

$$\mathbb{S}_+^d = \{\mathbf{X} = \mathbf{X}^\top : \mathbf{z}^\top \mathbf{X} \mathbf{z} \geq 0, \forall \mathbf{z}\}, \quad (35.8)$$

$$\mathcal{Q}^{d+1} = \{(t, \mathbf{x}) \in \mathbb{R} \times \mathbb{R}^d : \|\mathbf{x}\| \leq t\}. \quad (35.9)$$

其中 $\mathbb{S}_+^d$ 是正半定矩阵锥, $\mathcal{Q}^{d+1}$ 是二阶锥。

定义 35.4 (凸包与锥包). 集合 $S \subseteq \mathbb{R}^d$ 的凸包为

$$\text{conv } S = \left\{ \sum_{i=1}^m \theta_i \mathbf{x}_i : \mathbf{x}_i \in S, \theta_i \geq 0, \sum_{i=1}^m \theta_i = 1 \right\}. \quad (35.10)$$

锥包为

$$\text{cone } S = \left\{ \sum_{i=1}^m \alpha_i \mathbf{x}_i : \mathbf{x}_i \in S, \alpha_i \geq 0 \right\}. \quad (35.11)$$

35.3.1 常用保凸运算

以下运算保持凸性:

1. 任意族凸集的交: $C = \bigcap_{\lambda \in \Lambda} C_\lambda$;
2. 仿射像: $\mathbf{A}C + \mathbf{b} = \{\mathbf{A}\mathbf{x} + \mathbf{b} : \mathbf{x} \in C\}$;
3. 仿射原像: $\{\mathbf{x} : \mathbf{A}\mathbf{x} + \mathbf{b} \in C\}$;



4. Cartesian product: $C_1 \times C_2$;

5. Minkowski sum: $C_1 + C_2 = \{\mathbf{x}_1 + \mathbf{x}_2 : \mathbf{x}_1 \in C_1, \mathbf{x}_2 \in C_2\}$.

反例 35.5 (凸集的并一般不凸). 令 $C_1 = [-2, -1]$, $C_2 = [1, 2]$. 则 C_1, C_2 均凸, 但 $C_1 \cup C_2$ 不包含 -1 与 1 的中点 0 , 因此不凸。

易错点、反例与失败模式

1. 仿射集一定凸, 但凸集不一定仿射。
2. 线性子空间一定是凸锥; 一般凸锥不要求包含负倍数。
3. 锥定义中的缩放系数是非负数, 不是任意实数。
4. 凸集的交保持凸性, 凸集的并一般不保持凸性。

35.4 Euclidean 投影

对非空集合 $C \subseteq \mathbb{R}^d$, 定义点到集合的距离:

$$\text{dist}(\mathbf{x}, C) := \inf_{\mathbf{z} \in C} \|\mathbf{x} - \mathbf{z}\|. \quad (35.12)$$

若最小值能够达到, 则投影点定义为

$$P_C(\mathbf{x}) \in \arg \min_{\mathbf{z} \in C} \frac{1}{2} \|\mathbf{z} - \mathbf{x}\|^2. \quad (35.13)$$

定理 35.6 (闭凸集投影的存在唯一性). 若 $C \subseteq \mathbb{R}^d$ 非空、闭且凸, 则对任意 $\mathbf{x} \in \mathbb{R}^d$, 投影 $P_C(\mathbf{x})$ 存在且唯一。

证明. 令 $\delta = \inf_{\mathbf{z} \in C} \|\mathbf{z} - \mathbf{x}\|$. 取极小化序列 $\{\mathbf{z}_k\} \subseteq C$, $\|\mathbf{z}_k - \mathbf{x}\| \rightarrow \delta$. 该序列有界。事实上, 对充分大的 k , $\|\mathbf{z}_k - \mathbf{x}\| \leq \delta + 1$. 有限维空间中, 有界序列存在收敛子序列: $\mathbf{z}_{k_j} \rightarrow \bar{\mathbf{z}}$. 由于 C 闭, $\bar{\mathbf{z}} \in C$. 由范数连续性, $\|\bar{\mathbf{z}} - \mathbf{x}\| = \delta$, 故投影存在。

下面证明唯一性。假设 $\mathbf{p}, \mathbf{q} \in C$ 都是投影点, 且 $\|\mathbf{x} - \mathbf{p}\| = \|\mathbf{x} - \mathbf{q}\| = \delta$. 若 $\mathbf{p} \neq \mathbf{q}$, 由凸性, $\frac{\mathbf{p} + \mathbf{q}}{2} \in C$. 利用恒等式


$$\begin{aligned} \left\| \mathbf{x} - \frac{\mathbf{p} + \mathbf{q}}{2} \right\|^2 &= \frac{1}{2} \|\mathbf{x} - \mathbf{p}\|^2 + \frac{1}{2} \|\mathbf{x} - \mathbf{q}\|^2 - \frac{1}{4} \|\mathbf{p} - \mathbf{q}\|^2 \\ &= \delta^2 - \frac{1}{4} \|\mathbf{p} - \mathbf{q}\|^2 < \delta^2, \end{aligned} \quad (35.14)$$

与 δ 的最小性矛盾。故 $\mathbf{p} = \mathbf{q}$. □

35.4.1 闭性与凸性为什么不能省

反例 35.7 (缺少闭性时投影可能不存在). 令 $C = (0, 1) \subseteq \mathbb{R}$, $x = 0$. 则 $\text{dist}(0, C) = 0$, 但不存在 $z \in C$ 满足 $|z - 0| = 0$. 故投影不存在。

反例 35.8 (缺少凸性时投影可能不唯一). 令 $C = \{-1, 1\}$, $x = 0$. 则 $|-1 - 0| = |1 - 0| = 1$, 故有两个投影点。



35.5 投影的变分不等式

定理 35.9 (投影的充要条件). 设 $C \subseteq \mathbb{R}^d$ 非空、闭、凸。则

$$\boxed{p = P_C(x) \iff \langle x - p, z - p \rangle \leq 0, \quad \forall z \in C.} \quad (35.15)$$

证明. 先证必要性。若 $p = P_C(x)$, 则对任意 $z \in C$ 和 $t \in [0, 1]$, $p + t(z - p) \in C$ 。定义 $\phi(t) = \frac{1}{2} \|x - p - t(z - p)\|^2$ 。由于 $t = 0$ 是区间 $[0, 1]$ 上的极小点, $\phi'(0^+) \geq 0$ 。而 $\phi'(0^+) = -\langle x - p, z - p \rangle$ 。故 $\langle x - p, z - p \rangle \leq 0$ 。

再证充分性。若上述不等式对所有 $z \in C$ 成立, 则

$$\begin{aligned} \|x - z\|^2 &= \|(x - p) - (z - p)\|^2 \\ &= \|x - p\|^2 + \|z - p\|^2 - 2\langle x - p, z - p \rangle \\ &\geq \|x - p\|^2. \end{aligned} \quad (35.16)$$

因此 p 是距离最小点, 即 $p = P_C(x)$ 。 $\square$

几何上, $x - P_C(x)$ 与集合 C 在投影点处的所有可行方向形成钝角。

例 35.10 (半空间投影). 设 $C = \{z : a^\top z \leq b\}$, $a \neq 0$ 。则

$$P_C(x) = \begin{cases} x, & a^\top x \leq b, \\ x - \frac{a^\top x - b}{\|a\|^2} a, & a^\top x > b. \end{cases} \quad (35.17)$$

35.6 投影的 firm nonexpansiveness

定理 35.11 (投影的牢固非扩张性). 对任意 $x, y \in \mathbb{R}^d$, 有

$$\boxed{\|P_C(x) - P_C(y)\|^2 \leq \langle P_C(x) - P_C(y), x - y \rangle.} \quad (35.18)$$

因而

$$\boxed{\|P_C(x) - P_C(y)\| \leq \|x - y\|.} \quad (35.19)$$

证明. 记 $p = P_C(x)$, $q = P_C(y)$ 。由投影变分不等式, 取 $z = q$: $\langle x - p, q - p \rangle \leq 0$, 即 $\langle x - p, p - q \rangle \geq 0$ 。同理, $\langle y - q, p - q \rangle \leq 0$ 。两式相减:


$$\begin{aligned} \langle x - y, p - q \rangle &\geq \langle p - q, p - q \rangle \\ &= \|p - q\|^2. \end{aligned} \quad (35.20)$$

这就是牢固非扩张性。再用 Cauchy-Schwarz 不等式: $\|p - q\|^2 \leq \|x - y\| \|p - q\|$, 若 $p \neq q$, 约去 $\|p - q\|$ 即得非扩张性; 若相等则显然成立。 $\square$

35.7 点与闭凸集的严格分离

定理 35.12 (严格分离超平面定理). 设 $C \subseteq \mathbb{R}^d$ 非空、闭、凸, 且 $b \notin C$ 。则存在 $a \neq 0$ 和 $\alpha \in \mathbb{R}$, 使得

$$\boxed{a^\top b > \alpha \geq a^\top x, \quad \forall x \in C.} \quad (35.21)$$



证明. 令 $\bar{x} = P_C(\mathbf{b})$, $\mathbf{a} = \mathbf{b} - \bar{x}$. 由于 $\mathbf{b} \notin C$, $\mathbf{a} \neq \mathbf{0}$. 由投影变分不等式, $\langle \mathbf{b} - \bar{x}, \mathbf{x} - \bar{x} \rangle \leq 0$, $\forall \mathbf{x} \in C$. 即 $\mathbf{a}^\top \mathbf{x} \leq \mathbf{a}^\top \bar{x}$. 另一方面,

$$\begin{aligned}\mathbf{a}^\top \mathbf{b} &= \mathbf{a}^\top \bar{x} + \mathbf{a}^\top (\mathbf{b} - \bar{x}) \\ &= \mathbf{a}^\top \bar{x} + \|\mathbf{a}\|^2 > \mathbf{a}^\top \bar{x}.\end{aligned}\quad (35.22)$$

令 $\alpha = \mathbf{a}^\top \bar{x}$, 即得结论. $\square$

说明 35.13. 严格分离依赖闭性. 若集合不闭, 外部点可能属于其闭包, 此时两者距离为零, 无法严格分离.

35.8 Farkas 引理

定理 35.14 (Farkas 引理: 等式锥版本). 给定 $\mathbf{A} \in \mathbb{R}^{m \times n}$, $\mathbf{b} \in \mathbb{R}^m$, 以下两个系统恰有一个可行:

$$(P) \quad \mathbf{Ax} = \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0}; \quad (P)$$

$$(D) \quad \mathbf{A}^\top \mathbf{y} \leq \mathbf{0}, \quad \mathbf{b}^\top \mathbf{y} > 0. \quad (D)$$

证明. 先证二者不能同时可行. 若存在 $\mathbf{Ax} = \mathbf{b}$, $\mathbf{x} \geq \mathbf{0}$, 并且存在 $\mathbf{A}^\top \mathbf{y} \leq \mathbf{0}$, $\mathbf{b}^\top \mathbf{y} > 0$, 则

$$\begin{aligned}\mathbf{b}^\top \mathbf{y} &= (\mathbf{Ax})^\top \mathbf{y} \\ &= \mathbf{x}^\top \mathbf{A}^\top \mathbf{y} \leq 0,\end{aligned}\quad (35.23)$$

与 $\mathbf{b}^\top \mathbf{y} > 0$ 矛盾.

下面证明若 (P) 不可行, 则 (D) 可行. 定义有限生成凸锥

$$K = \{\mathbf{Ax} : \mathbf{x} \geq \mathbf{0}\}. \quad (35.24)$$

有限生成锥是闭凸锥. (P) 不可行等价于 $\mathbf{b} \notin K$. 由严格分离定理, 存在 $\mathbf{y} \neq \mathbf{0}$, 使

$$\mathbf{y}^\top \mathbf{b} > \sup_{\mathbf{z} \in K} \mathbf{y}^\top \mathbf{z}. \quad (35.25)$$

由于 $\mathbf{0} \in K$, 右侧上确界至少为 0. 又因为 K 是锥, 若存在某列 $\mathbf{a}_i$ 满足 $\mathbf{y}^\top \mathbf{a}_i > 0$, 则对任意 $t \geq 0$, $t\mathbf{a}_i \in K$, 并且 $\mathbf{y}^\top (t\mathbf{a}_i) = t\mathbf{y}^\top \mathbf{a}_i \rightarrow +\infty$, 与式 (35.25) 中的有限严格分离矛盾. 因此对每一列都有 $\mathbf{y}^\top \mathbf{a}_i \leq 0$, 即 $\mathbf{A}^\top \mathbf{y} \leq \mathbf{0}$. 此时 $\sup_{\mathbf{z} \in K} \mathbf{y}^\top \mathbf{z} = 0$, 故 $\mathbf{b}^\top \mathbf{y} > 0$. 所以 (D) 可行. $\square$

35.8.1 Farkas 引理的考试识别信号

看到以下题目, 应想到 Farkas 引理或分离证书:

- 证明某线性方程组在非负约束下不可行;
- 要求构造一个向量作为 infeasibility certificate;
- 要求证明两个线性系统“恰有一个可行”;
- 从 primal feasibility 推导 dual certificate;
- 证明 KKT multiplier 或线性规划对偶中的乘子存在.



答题方法

Farkas 题的标准答题顺序:

1. 先写清楚两个候选系统及不等式方向;
2. 用 $\mathbf{b}^\top \mathbf{y} = \mathbf{x}^\top \mathbf{A}^\top \mathbf{y}$ 证明二者互斥;
3. 定义锥 $K = \{\mathbf{Ax} : \mathbf{x} \geq 0\}$;
4. 说明 K 是闭凸锥;
5. 若 $\mathbf{b} \notin K$, 用严格分离得到 $\mathbf{y}$;
6. 利用锥的可缩放性证明 $\mathbf{A}^\top \mathbf{y} \leq 0$;
7. 利用 $0 \in K$ 得到 $\mathbf{b}^\top \mathbf{y} > 0$.



第三十六章 闭凸函数、最优解存在性与强凸性

36.1 广义实值函数

令 $\bar{\mathbb{R}} = \mathbb{R} \cup \{+\infty\}$ 。优化中常使用广义实值函数 $f: \mathbb{R}^d \rightarrow \bar{\mathbb{R}}$ 。

约束 $\mathbf{x} \in C$ 可以通过示性函数编码：

$$\delta_C(\mathbf{x}) = \begin{cases} 0, & \mathbf{x} \in C, \\ +\infty, & \mathbf{x} \notin C. \end{cases} \quad (36.1)$$

于是 $\min_{\mathbf{x} \in C} f(\mathbf{x})$ 等价于 $\min_{\mathbf{x} \in \mathbb{R}^d} [f(\mathbf{x}) + \delta_C(\mathbf{x})]$ 。

定义 36.1 (有效定义域与适当函数). 定义

$$\text{dom } f := \{\mathbf{x} : f(\mathbf{x}) < +\infty\}. \quad (36.2)$$

函数 f 称为适当的 (proper), 若：

$$\text{dom } f \neq \emptyset \quad (36.3)$$

且 f 从不取 $-\infty$ 。

若函数恒为 $+\infty$ ，则没有可行点，不是 proper。允许 $+\infty$ 的目的，是统一表达约束，而不是表示数值计算中真正使用无穷大。

36.2 Epigraph、闭函数与下半连续

定义 36.2 (上方图). 函数 f 的上方图为

$$\text{epi } f := \{(\mathbf{x}, t) \in \mathbb{R}^d \times \mathbb{R} : f(\mathbf{x}) \leq t\}. \quad (36.4)$$

定义 36.3 (闭函数). 若 $\text{epi } f$ 是闭集，则称 f 为闭函数。


定义 36.4 (下半连续). 函数 f 在 $\mathbf{x}$ 处下半连续，若

$$f(\mathbf{x}) \leq \liminf_{\mathbf{y} \rightarrow \mathbf{x}} f(\mathbf{y}). \quad (36.5)$$

若对所有点均成立，则称 f 是下半连续的 (lower semicontinuous, l.s.c.)。

对 proper 广义实值函数，以下条件等价：

1. f 是下半连续的；
2. $\text{epi } f$ 是闭集；



3. 每个下水平集

$$L_\alpha(f) := \{\mathbf{x} : f(\mathbf{x}) \leq \alpha\} \quad (36.6)$$

都是闭集。

易错点、反例与失败模式

下半连续控制的是“函数值不能突然向下跳”。

若 $\mathbf{x}_k \rightarrow \mathbf{x}$, 下半连续要求 $f(\mathbf{x}) \leq \liminf_k f(\mathbf{x}_k)$ 。它不要求 $f(\mathbf{x}_k) \rightarrow f(\mathbf{x})$, 后者是普通连续性, 条件更强。

36.3 凸函数、严格凸函数与强凸函数

定义 36.5 (凸函数). proper 函数 f 称为凸函数, 若 $\text{dom } f$ 为凸集, 且

$$f(\theta \mathbf{x} + (1 - \theta)\mathbf{y}) \leq \theta f(\mathbf{x}) + (1 - \theta)f(\mathbf{y}), \quad (36.7)$$

对所有 $\mathbf{x}, \mathbf{y} \in \text{dom } f$, $\theta \in [0, 1]$ 成立。

定义 36.6 (严格凸函数). 若对任意不同的 $\mathbf{x} \neq \mathbf{y}$ 以及 $\theta \in (0, 1)$ 都有严格不等式

$$f(\theta \mathbf{x} + (1 - \theta)\mathbf{y}) < \theta f(\mathbf{x}) + (1 - \theta)f(\mathbf{y}), \quad (36.8)$$

则 f 严格凸。

定义 36.7 (μ -强凸函数). 全文采用以下主约定: 若存在 $\mu > 0$, 使

$$\begin{aligned} f(\theta \mathbf{x} + (1 - \theta)\mathbf{y}) &\leq \theta f(\mathbf{x}) + (1 - \theta)f(\mathbf{y}) \\ &\quad - \frac{\mu}{2} \theta(1 - \theta) \|\mathbf{x} - \mathbf{y}\|^2, \end{aligned} \quad (36.9)$$

则称 f 为 μ -strongly convex。

等价地,

$$f \text{ 是 } \mu\text{-强凸} \iff \mathbf{x} \mapsto f(\mathbf{x}) - \frac{\mu}{2} \|\mathbf{x}\|^2 \text{ 是凸函数.} \quad (36.10)$$

三者关系为


$$\mu\text{-强凸} \implies \text{严格凸} \implies \text{凸}. \quad (36.11)$$

反向一般不成立。

反例 36.8 (严格凸不推出强凸). 函数 $f(x) = x^4$ 在 $\mathbb{R}$ 上严格凸, 但不是任何 $\mu > 0$ 意义下的强凸函数。

若它是 μ -强凸, 则在二阶可微条件下应有 $f''(x) = 12x^2 \geq \mu$, $\forall x$ 。但 $f''(0) = 0$ 。

反例 36.9 (强凸不推出可微或光滑). 函数 $f(x) = x^2 + |x|$ 满足 $f(x) - x^2 = |x|$ 凸, 因此 f 是 2-强凸的; 但它在 $x = 0$ 处不可微。



36.4 凸函数的一阶刻画

定理 36.10 (可微凸函数的一阶刻画). 设 f 在凸开集上可微. 则 f 凸当且仅当

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle, \quad \forall \mathbf{x}, \mathbf{y}. \quad (36.12)$$

该式表示: 凸函数的任意切平面都是全局下界。

由交换 $\mathbf{x}, \mathbf{y}$ 并相加, 可得梯度单调性:

$$\langle \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq 0. \quad (36.13)$$

对 μ -强凸可微函数, 一阶刻画为

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|^2. \quad (36.14)$$

交换两点并相加, 得到梯度强单调性:

$$\langle \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \mu \|\mathbf{x} - \mathbf{y}\|^2. \quad (36.15)$$

36.5 二阶刻画

若 f 在开凸集上二阶连续可微, 则:

$$f \text{ 凸} \iff \nabla^2 f(\mathbf{x}) \succeq \mathbf{0}, \quad \forall \mathbf{x}, \quad (36.16)$$

$$f \text{ 是 } \mu\text{-强凸} \iff \nabla^2 f(\mathbf{x}) \succeq \mu \mathbf{I}_d, \quad \forall \mathbf{x}. \quad (36.17)$$

若 $\nabla^2 f(\mathbf{x}) \succ \mathbf{0}$ 对所有 $\mathbf{x}$ 成立, 则 f 严格凸; 但严格凸不要求 Hessian 在每一点均正定。

例 36.11 (二次函数). 设

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{H} \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c, \quad \mathbf{H} = \mathbf{H}^\top. \quad (36.18)$$

则 $\nabla f(\mathbf{x}) = \mathbf{H} \mathbf{x} + \mathbf{b}$, $\nabla^2 f(\mathbf{x}) = \mathbf{H}$ 。因此:

- f 凸当且仅当 $\mathbf{H} \succeq \mathbf{0}$;
- f 是 μ -强凸当且仅当 $\mathbf{H} \succeq \mu \mathbf{I}$;
- f 是 L -smooth 当且仅当 $\mathbf{H} \preceq L \mathbf{I}$ 。

特别地, $f(\mathbf{x}) = \lambda \|\mathbf{x}\|^2$ 的 Hessian 为 $2\lambda \mathbf{I}$, 故它是 2λ -强凸函数。


36.6 全局最优性与唯一性

定理 36.12 (凸函数的一阶全局最优性). 若 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微且凸, 则

$$\mathbf{x}^* \in \arg \min_{\mathbf{x}} f(\mathbf{x}) \iff \nabla f(\mathbf{x}^*) = \mathbf{0}. \quad (36.19)$$

证明. 若 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 由凸函数一阶下界, $f(\mathbf{y}) \geq f(\mathbf{x}^*) + \langle \mathbf{0}, \mathbf{y} - \mathbf{x}^* \rangle = f(\mathbf{x}^*)$, 故 $\mathbf{x}^*$ 全局最优。

反之, 若 $\mathbf{x}^*$ 是无约束局部最优点且 f 可微, 则任意方向的一阶方向导数均不能为负, 从而 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 。□



反例 36.13 (非凸情形下驻点不一定是最小点). 令 $f(x) = -x^2$. 则 $f'(0) = 0$, 但 $x = 0$ 是全局最大点而非最小点。

定理 36.14 (严格凸函数最优解唯一). 若 f 严格凸且最小值能够达到, 则最小点唯一。

证明. 若存在不同最小点 $\mathbf{x}^* \neq \mathbf{y}^*$, 则对 $\theta \in (0, 1)$, 严格凸性给出 $f(\theta\mathbf{x}^* + (1-\theta)\mathbf{y}^*) < \theta f(\mathbf{x}^*) + (1-\theta)f(\mathbf{y}^*)$, 右侧等于最小值, 矛盾。□

36.7 最优解存在性

定理 36.15 (下水平集形式的 Weierstrass 定理). 设 $f: \mathbb{R}^d \rightarrow \overline{\mathbb{R}}$ proper 且 lower semicontinuous. 若存在 $\alpha \in \mathbb{R}$, 使下水平集 $L_\alpha(f) = \{\mathbf{x}: f(\mathbf{x}) \leq \alpha\}$ 非空且有界, 则 f 的最小点集合非空且紧。

证明或推导框架

下半连续性保证下水平集闭; 有限维空间中, 闭且有界等价于紧。取极小化序列后, 可在该紧下水平集中抽取收敛子序列, 再利用下半连续性把极限证明为最优点。

定义 36.16 (强制性). 若

$$\|\mathbf{x}\| \rightarrow +\infty \implies f(\mathbf{x}) \rightarrow +\infty, \quad (36.20)$$

则称 f 是强制的或 coercive。

proper、lower semicontinuous 且 coercive 的函数必有最小点。

反例 36.17 (强凸性本身不保证最小点存在). 在开定义域 $(0, +\infty)$ 上考虑 $f(x) = x^2$. 它是 2-强凸函数, 但 $\inf_{x>0} x^2 = 0$ 未被任何可行点达到。

若把它扩展为 $f(x) = \begin{cases} x^2, & x > 0, \\ +\infty, & x \leq 0, \end{cases}$ 则扩展函数在 $x = 0$ 处不是下半连续的。因此 existence 证明不能只写“强凸所以存在唯一解”; 强凸主要直接给唯一性, 存在性仍需闭性、强制性或紧性条件。

36.8 复合目标的存在唯一性

考虑

$$F(\mathbf{x}) = f(\mathbf{x}) + R(\mathbf{x}), \quad (36.21)$$

其中:

- $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 连续可微且 μ -强凸;
- $R: \mathbb{R}^d \rightarrow (-\infty, +\infty]$ proper、closed、convex。

定理 36.18 (复合强凸目标的存在唯一性). 在上述条件下, $F = f + R$ 存在唯一全局最小点 $\mathbf{x}^*$ 。

证明. 由于 f 在全空间连续, R proper、closed、convex, 故 F proper、closed。又因为强凸函数与凸函数之和仍为同参数的强凸函数, 所以 F 是 μ -强凸函数。

下面证明强制性。取 $\bar{\mathbf{x}} \in \text{ri}(\text{dom } R)$ 。proper closed convex 函数在相对内部具有非空次微分, 故存在 $\bar{\mathbf{r}} \in \partial R(\bar{\mathbf{x}})$ 。由 f 的强凸性:

$$f(\mathbf{x}) \geq f(\bar{\mathbf{x}}) + \langle \nabla f(\bar{\mathbf{x}}), \mathbf{x} - \bar{\mathbf{x}} \rangle + \frac{\mu}{2} \|\mathbf{x} - \bar{\mathbf{x}}\|^2. \quad (36.22)$$

由 $\bar{r}$ 的次梯度不等式: $R(\mathbf{x}) \geq R(\bar{\mathbf{x}}) + \langle \bar{r}, \mathbf{x} - \bar{\mathbf{x}} \rangle$ 。相加得到

$$\begin{aligned} F(\mathbf{x}) &\geq F(\bar{\mathbf{x}}) + \langle \nabla f(\bar{\mathbf{x}}) + \bar{r}, \mathbf{x} - \bar{\mathbf{x}} \rangle \\ &\quad + \frac{\mu}{2} \|\mathbf{x} - \bar{\mathbf{x}}\|^2. \end{aligned} \quad (36.23)$$

右侧的二次项支配线性项, 因此 $\|\mathbf{x}\| \rightarrow \infty \implies F(\mathbf{x}) \rightarrow \infty$ 。故 F coercive。由 Weierstrass 定理, 最小点存在; 由强凸性, 最小点唯一。□

此外, 强凸性给出函数值误差的二次下界:

$$F(\mathbf{x}) - F(\mathbf{x}^*) \geq \frac{\mu}{2} \|\mathbf{x} - \mathbf{x}^*\|^2. \quad (36.24)$$

答题方法

[25F-C-Q2, 2 分] 与 [26S-C-Q3, 3 分] 中“证明唯一最小点”的标准写法:

1. 说明 f 是 μ -强凸, R 是凸函数, 因此 $F = f + R$ 仍为 μ -强凸;
2. proper、closed 和二次增长保证最小点存在;
3. 假设有两个不同最小点 $\mathbf{x}^* \neq \mathbf{y}^*$, 强凸性给出 $F\left(\frac{\mathbf{x}^* + \mathbf{y}^*}{2}\right) \leq \frac{1}{2}F(\mathbf{x}^*) + \frac{1}{2}F(\mathbf{y}^*) - \frac{\mu}{8}\|\mathbf{x}^* - \mathbf{y}^*\|^2$, 严格小于最小值, 矛盾;
4. 因而最小点唯一。

只写“strongly convex, 所以唯一”可获得唯一性结论分, 但若题目明确要求证明存在性, 仍需写闭性和 level-boundedness。



第三十七章 光滑性、下降引理与梯度余强制性

37.1 重要性等级

重要性等级: S

- [25S-C-Q1, 5 分]、[25F-C-Q1, 3 分]、[26S-C-Q1, 2 分] 均直接考查 L -smoothness 和 μ -strong convexity 的定义。
- [25S-C-Q2, 6 分] 要求通过 shifted function $h(\mathbf{x}) = f(\mathbf{x}) - \frac{\mu}{2}\|\mathbf{x}\|^2$ 推导光滑-强凸联合不等式。
- 该联合不等式是:
 - 梯度下降线性收敛;
 - proximal SGD 一步递推;
 - contraction factor;
 - condition number的共同母题。
- 定义和联合不等式必须会完整推导。

37.2 L -Smoothness

定义 37.1 (L -光滑). 可微函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 称为 L -smooth, 若

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|, \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d. \quad (37.1)$$

该条件是“梯度 Lipschitz”, 不是“函数值 Lipschitz”。

易错点、反例与失败模式

1. $|f(\mathbf{x}) - f(\mathbf{y})| \leq G\|\mathbf{x} - \mathbf{y}\|$ 是函数 G -Lipschitz。
2. $\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|$ 是梯度 L -Lipschitz, 即 L -smoothness。
3. $f(x) = x^2$ 在 $\mathbb{R}$ 上是 2-smooth, 但不是全局 Lipschitz, 因为 $|f'(x)| = 2|x|$ 无界。
4. $f(x) = |x|$ 是 1-Lipschitz, 但在 0 处不可微, 因此不是通常意义下的 smooth function。

Smoothness 不要求二阶导数处处存在。例如 $f(x) = \begin{cases} \frac{1}{2}x^2, & x \leq 0, \\ x^2, & x > 0 \end{cases}$ 是一阶连续且梯度 2-Lipschitz, 但二阶导数在 0 处不连续。

若 f 二阶连续可微, 则

$$f \text{ 是 } L\text{-smooth} \iff \|\nabla^2 f(\mathbf{x})\|_{\text{op}} \leq L, \quad \forall \mathbf{x}. \quad (37.2)$$

若 f 同时凸, 则等价于 $\mathbf{0} \preceq \nabla^2 f(\mathbf{x}) \preceq LI$ 。

37.3 Descent Lemma

定理 37.2 (下降引理). 若 f 是 L -smooth, 则

$$f(\mathbf{y}) \leq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{L}{2} \|\mathbf{y} - \mathbf{x}\|^2. \quad (37.3)$$

证明. 令 $\mathbf{d} = \mathbf{y} - \mathbf{x}$ 。由微积分基本定理,

$$\begin{aligned} f(\mathbf{y}) - f(\mathbf{x}) &= \int_0^1 \langle \nabla f(\mathbf{x} + t\mathbf{d}), \mathbf{d} \rangle dt \\ &= \langle \nabla f(\mathbf{x}), \mathbf{d} \rangle + \int_0^1 \langle \nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x}), \mathbf{d} \rangle dt. \end{aligned} \quad (37.4)$$

由 Cauchy-Schwarz 和 smoothness:

$$\langle \nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x}), \mathbf{d} \rangle \leq \|\nabla f(\mathbf{x} + t\mathbf{d}) - \nabla f(\mathbf{x})\| \|\mathbf{d}\| \leq Lt \|\mathbf{d}\|^2. \quad (37.5)$$

积分得 $\int_0^1 Lt \|\mathbf{d}\|^2 dt = \frac{L}{2} \|\mathbf{d}\|^2$ 。□

取 $\mathbf{y} = \mathbf{x} - \frac{1}{L} \nabla f(\mathbf{x})$ 可得

$$f\left(\mathbf{x} - \frac{1}{L} \nabla f(\mathbf{x})\right) \leq f(\mathbf{x}) - \frac{1}{2L} \|\nabla f(\mathbf{x})\|^2. \quad (37.6)$$

若 f 存在全局最小点 $\mathbf{x}^*$, 则 $f(\mathbf{x}^*) \leq f\left(\mathbf{x} - \frac{1}{L} \nabla f(\mathbf{x})\right)$, 从而

$$\frac{1}{2L} \|\nabla f(\mathbf{x})\|^2 \leq f(\mathbf{x}) - f(\mathbf{x}^*). \quad (37.7)$$

注意: 式 (37.7) 不要求 f 凸, 但要求:

- f 在全空间或该梯度步可行;
- f 存在全局最小点;
- f 是 L -smooth。


37.4 Bregman Divergence

对可微凸函数 f , 定义

$$D_f(\mathbf{x}, \mathbf{y}) := f(\mathbf{x}) - f(\mathbf{y}) - \langle \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle. \quad (37.8)$$

由凸性, $D_f(\mathbf{x}, \mathbf{y}) \geq 0$ 。

但 Bregman divergence 通常:



- 不对称: $D_f(\mathbf{x}, \mathbf{y}) \neq D_f(\mathbf{y}, \mathbf{x})$;
- 不满足三角不等式;
- 因而一般不是 metric。

关键恒等式为

$$D_f(\mathbf{x}, \mathbf{y}) + D_f(\mathbf{y}, \mathbf{x}) = \langle \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle. \quad (37.9)$$

若 f 是 L -smooth, 则 descent lemma 给出

$$D_f(\mathbf{x}, \mathbf{y}) \leq \frac{L}{2} \|\mathbf{x} - \mathbf{y}\|^2. \quad (37.10)$$

若 f 是 μ -strongly convex, 则

$$D_f(\mathbf{x}, \mathbf{y}) \geq \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|^2. \quad (37.11)$$

37.5 凸光滑函数的梯度差下界

引理 37.3 (Bregman divergence 控制梯度差). 若 f 凸且 L -smooth, 则

$$D_f(\mathbf{y}, \mathbf{x}) \geq \frac{1}{2L} \|\nabla f(\mathbf{y}) - \nabla f(\mathbf{x})\|^2. \quad (37.12)$$

证明. 固定 $\mathbf{x}$, 定义

$$h(\mathbf{z}) = f(\mathbf{z}) - \langle \nabla f(\mathbf{x}), \mathbf{z} \rangle. \quad (37.13)$$

函数 h 仍凸且 L -smooth, 并且 $\nabla h(\mathbf{x}) = \nabla f(\mathbf{x}) - \nabla f(\mathbf{x}) = \mathbf{0}$. 因此 $\mathbf{x}$ 是 h 的全局最小点。

对点 $\mathbf{y}$ 应用一步下降: $h(\mathbf{y} - \frac{1}{L} \nabla h(\mathbf{y})) \leq h(\mathbf{y}) - \frac{1}{2L} \|\nabla h(\mathbf{y})\|^2$. 又因为 $\mathbf{x}$ 是全局最小点, $h(\mathbf{x}) \leq h(\mathbf{y} - \frac{1}{L} \nabla h(\mathbf{y}))$. 故

$$h(\mathbf{y}) - h(\mathbf{x}) \geq \frac{1}{2L} \|\nabla h(\mathbf{y})\|^2 = \frac{1}{2L} \|\nabla f(\mathbf{y}) - \nabla f(\mathbf{x})\|^2. \quad (37.14)$$

而

$$h(\mathbf{y}) - h(\mathbf{x}) = f(\mathbf{y}) - f(\mathbf{x}) - \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle = D_f(\mathbf{y}, \mathbf{x}). \quad (37.15)$$

□

37.6 Co-Coercivity

定理 37.4 (Baillon–Haddad / 梯度余强制性). 若 f 凸且 L -smooth, 则

$$\langle \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{1}{L} \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2. \quad (37.16)$$

证明. 由引理 37.3,

$$D_f(\mathbf{x}, \mathbf{y}) \geq \frac{1}{2L} \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2, \quad (37.17)$$

$$D_f(\mathbf{y}, \mathbf{x}) \geq \frac{1}{2L} \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2. \quad (37.18)$$

两式相加, 并使用式 (37.9), 即得结论。 □

Co-coercivity 强于普通 gradient monotonicity: $\langle \Delta \nabla f, \Delta \mathbf{x} \rangle \geq 0$. 它还同时包含梯度差的定量控制。



37.7 强凸函数的梯度范数下界

若 f 可微且 μ -强凸, 令 $\mathbf{x}^*$ 为最小点. 由强凸一阶不等式: $f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|^2$. 对右侧关于 $\mathbf{y}$ 最小化. 最优 $\mathbf{y} = \mathbf{x} - \frac{1}{\mu} \nabla f(\mathbf{x})$, 从而 $f(\mathbf{x}^*) \geq f(\mathbf{x}) - \frac{1}{2\mu} \|\nabla f(\mathbf{x})\|^2$. 即

$$\|\nabla f(\mathbf{x})\|^2 \geq 2\mu [f(\mathbf{x}) - f(\mathbf{x}^*)]. \quad (37.19)$$

若 f 同时 L -smooth, 则

$$2\mu [f(\mathbf{x}) - f^*] \leq \|\nabla f(\mathbf{x})\|^2 \leq 2L [f(\mathbf{x}) - f^*]. \quad (37.20)$$

并且

$$\frac{\mu}{2} \|\mathbf{x} - \mathbf{x}^*\|^2 \leq f(\mathbf{x}) - f^* \leq \frac{L}{2} \|\mathbf{x} - \mathbf{x}^*\|^2. \quad (37.21)$$

37.8 光滑与强凸的联合插值不等式

定理 37.5 (Smooth-Strong Convex Interpolation Inequality). 设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 是 L -smooth 且 μ -strongly convex, 其中 $0 < \mu \leq L$. 则

$$\langle \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{\mu L}{\mu + L} \|\mathbf{x} - \mathbf{y}\|^2 + \frac{1}{\mu + L} \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2. \quad (37.22)$$

证明. 先考虑 $0 < \mu < L$. 定义 shifted function

$$h(\mathbf{x}) = f(\mathbf{x}) - \frac{\mu}{2} \|\mathbf{x}\|^2. \quad (37.23)$$

由强凸性, h 是凸函数.

下面证明 h 是 $(L - \mu)$ -smooth. 由 f 的 descent lemma, $f(\mathbf{y}) \leq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{L}{2} \|\mathbf{y} - \mathbf{x}\|^2$. 记 $\mathbf{d} = \mathbf{y} - \mathbf{x}$. 使用 $\|\mathbf{y}\|^2 = \|\mathbf{x}\|^2 + 2\langle \mathbf{x}, \mathbf{d} \rangle + \|\mathbf{d}\|^2$, 两侧减去 $\frac{\mu}{2} \|\mathbf{y}\|^2$, 得到

$$\begin{aligned} h(\mathbf{y}) &\leq h(\mathbf{x}) + \langle \nabla f(\mathbf{x}) - \mu \mathbf{x}, \mathbf{y} - \mathbf{x} \rangle + \frac{L - \mu}{2} \|\mathbf{y} - \mathbf{x}\|^2 \\ &= h(\mathbf{x}) + \langle \nabla h(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{L - \mu}{2} \|\mathbf{y} - \mathbf{x}\|^2. \end{aligned} \quad (37.24)$$

对凸可微函数, 该二次上界等价于 $(L - \mu)$ -smoothness.

因此可对 h 使用 co-coercivity:

$$\langle \nabla h(\mathbf{x}) - \nabla h(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{1}{L - \mu} \|\nabla h(\mathbf{x}) - \nabla h(\mathbf{y})\|^2. \quad (37.25)$$

记 $\Delta \mathbf{x} = \mathbf{x} - \mathbf{y}$, $\Delta \mathbf{g} = \nabla f(\mathbf{x}) - \nabla f(\mathbf{y})$. 由于 $\nabla h(\mathbf{x}) - \nabla h(\mathbf{y}) = \Delta \mathbf{g} - \mu \Delta \mathbf{x}$, 式 (37.25) 化为

$$\langle \Delta \mathbf{g} - \mu \Delta \mathbf{x}, \Delta \mathbf{x} \rangle \geq \frac{1}{L - \mu} \|\Delta \mathbf{g} - \mu \Delta \mathbf{x}\|^2. \quad (37.26)$$

乘以 $L - \mu$:

$$(L - \mu) \langle \Delta \mathbf{g}, \Delta \mathbf{x} \rangle - \mu(L - \mu) \|\Delta \mathbf{x}\|^2 \geq \|\Delta \mathbf{g}\|^2 - 2\mu \langle \Delta \mathbf{g}, \Delta \mathbf{x} \rangle + \mu^2 \|\Delta \mathbf{x}\|^2. \quad (37.27)$$

整理得 $(L + \mu) \langle \Delta \mathbf{g}, \Delta \mathbf{x} \rangle \geq \|\Delta \mathbf{g}\|^2 + \mu L \|\Delta \mathbf{x}\|^2$. 除以 $L + \mu$ 即得结论.

若 $\mu = L$, 则 $h(\mathbf{x}) = f(\mathbf{x}) - \frac{L}{2} \|\mathbf{x}\|^2$ 是凸且 0-smooth, 故 ∇h 为常向量. 于是 $\nabla f(\mathbf{x}) - \nabla f(\mathbf{y}) = L(\mathbf{x} - \mathbf{y})$, 式 (37.22) 取等号. $\square$

等价地, 乘以 $1 + \frac{\mu}{L}$ 可写成 [25S-C-Q2, 6 分] 的题面形式:

$$\mu \|\mathbf{x} - \mathbf{y}\|^2 + \frac{1}{L} \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2 \leq \left(1 + \frac{\mu}{L}\right) \langle \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle. \quad (37.28)$$

37.9 条件数

定义条件数

$$\kappa := \frac{L}{\mu} \geq 1. \quad (37.29)$$

直观上:

- L 控制最大曲率;
- μ 控制最小曲率;
- κ 衡量不同方向曲率的不均衡。

对二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{H} \mathbf{x}$, $\mathbf{H} \succ 0$, 有 $L = \lambda_{\max}(\mathbf{H})$, $\mu = \lambda_{\min}(\mathbf{H})$, 从而 $\kappa = \frac{\lambda_{\max}(\mathbf{H})}{\lambda_{\min}(\mathbf{H})}$ 。

37.10 梯度映射的压缩性

推论 37.6. 设 f 是 L -smooth 且 μ -strongly convex。令

$$T_\gamma(\mathbf{x}) = \mathbf{x} - \gamma \nabla f(\mathbf{x}). \quad (37.30)$$

取

$$\gamma = \frac{2}{L + \mu}, \quad (37.31)$$

则

$$\|T_\gamma(\mathbf{x}) - T_\gamma(\mathbf{y})\| \leq \frac{L - \mu}{L + \mu} \|\mathbf{x} - \mathbf{y}\|. \quad (37.32)$$

证明. 展开:

$$\begin{aligned} & \|T_\gamma(\mathbf{x}) - T_\gamma(\mathbf{y})\|^2 \\ &= \|\Delta \mathbf{x} - \gamma \Delta \mathbf{g}\|^2 \\ &= \|\Delta \mathbf{x}\|^2 - 2\gamma \langle \Delta \mathbf{g}, \Delta \mathbf{x} \rangle + \gamma^2 \|\Delta \mathbf{g}\|^2. \end{aligned} \quad (37.33)$$

代入式 (37.22), 并取 $\gamma = \frac{2}{L + \mu}$, 梯度差平方项恰好抵消:

$$\|T_\gamma(\mathbf{x}) - T_\gamma(\mathbf{y})\|^2 \leq \left[1 - \frac{4\mu L}{(L + \mu)^2}\right] \|\Delta \mathbf{x}\|^2 = \left(\frac{L - \mu}{L + \mu}\right)^2 \|\Delta \mathbf{x}\|^2. \quad (37.34)$$

开平方即得结论。 $\square$

答题方法

[25S-C-Q1-Q2, 共 11 分] 的答题方法:

第一问: 定义。

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|,$$

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|^2.$$

第二问: shifted function. $h(\mathbf{x}) = f(\mathbf{x}) - \frac{\mu}{2} \|\mathbf{x}\|^2$ 。先证明: h 凸, h 是 $(L - \mu)$ -smooth。再对 h 使用 co-coercivity: $\langle \nabla h(\mathbf{x}) - \nabla h(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{1}{L - \mu} \|\nabla h(\mathbf{x}) - \nabla h(\mathbf{y})\|^2$ 。代入 $\nabla h(\mathbf{x}) - \nabla h(\mathbf{y}) = \Delta \nabla f - \mu \Delta \mathbf{x}$, 完整展开平方并整理, 得到 $(L + \mu) \langle \Delta \nabla f, \Delta \mathbf{x} \rangle \geq \|\Delta \nabla f\|^2 + \mu L \|\Delta \mathbf{x}\|^2$ 。

关键失分点：

- 不得直接声称 h 是 $(L - \mu)$ -smooth 而不解释；
- 展开 $\|\Delta \nabla f - \mu \Delta \mathbf{x}\|^2$ 时不得漏掉交叉项；
- 分母是 $L - \mu$ ，最终分母是 $L + \mu$ ；
- $\mu = L$ 时应单独说明或用极限处理。



第三十八章 次微分、共轭函数与近端算子

38.1 重要性等级

重要性等级: 5

- [26S-C-Q2, 3 分]: prox 的最优性条件。
- [26S-C-Q3, 3 分]: 复合目标唯一解与 proximal fixed point。
- [26S-C-Q4, 2 分]: 次微分映射的单调性。
- [26S-C-Q5, 3 分]: prox 的非扩张性。
- 以上四个小问形成完整证明链: 次梯度不等式 $\implies$ 单调性 $\implies$ firm nonexpansiveness $\implies$ proximal SGD 一步递推。

38.2 次梯度与次微分

定义 38.1 (次梯度). 设 $f: \mathbb{R}^d \rightarrow (-\infty, +\infty]$ proper、convex, 且 $\mathbf{x} \in \text{dom } f$. 若向量 $\mathbf{g} \in \mathbb{R}^d$ 满足

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \mathbf{g}, \mathbf{y} - \mathbf{x} \rangle, \quad \forall \mathbf{y} \in \mathbb{R}^d, \quad (38.1)$$

则称 $\mathbf{g}$ 是 f 在 $\mathbf{x}$ 处的次梯度。

全部次梯度构成次微分集合:

$$\partial f(\mathbf{x}) = \{\mathbf{g} : f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \mathbf{g}, \mathbf{y} - \mathbf{x} \rangle, \forall \mathbf{y}\}. \quad (38.2)$$

若 $\mathbf{x} \notin \text{dom } f$, 规定 $\partial f(\mathbf{x}) = \emptyset$ 。

对可微凸函数,

$$\partial f(\mathbf{x}) = \{\nabla f(\mathbf{x})\}. \quad (38.3)$$

易错点、反例与失败模式

1. 次梯度不是“任意方向导数”。
2. 不可微点的次梯度通常不唯一。
3. 可微非凸函数的梯度不一定是全局线性下界, 因而式 (38.1) 是凸分析意义下的定义。
4. 边界点的次微分可能为空: proper closed convex 函数在 $\text{ri}(\text{dom } f)$ 上具有非空次微分。

38.3 常见次微分

38.3.1 绝对值

$$\partial|x| = \begin{cases} \{1\}, & x > 0, \\ [-1, 1], & x = 0, \\ \{-1\}, & x < 0. \end{cases} \quad (38.4)$$

38.3.2 ℓ_1 范数

对 $f(\mathbf{x}) = \|\mathbf{x}\|_1$, 有

$$\mathbf{g} \in \partial\|\mathbf{x}\|_1 \iff g_i \in \begin{cases} \{1\}, & x_i > 0, \\ [-1, 1], & x_i = 0, \\ \{-1\}, & x_i < 0. \end{cases} \quad (38.5)$$

38.3.3 ℓ_2 范数

$$\partial\|\mathbf{x}\|_2 = \begin{cases} \left\{ \frac{\mathbf{x}}{\|\mathbf{x}\|_2} \right\}, & \mathbf{x} \neq \mathbf{0}, \\ \{\mathbf{g} : \|\mathbf{g}\|_2 \leq 1\}, & \mathbf{x} = \mathbf{0}. \end{cases} \quad (38.6)$$

38.3.4 逐点最大值

若 $f(\mathbf{x}) = \max_{1 \leq i \leq m} f_i(\mathbf{x})$, 其中 f_i 为可微凸函数, 定义 active set: $I(\mathbf{x}) = \{i : f_i(\mathbf{x}) = f(\mathbf{x})\}$. 则

$$\partial f(\mathbf{x}) = \text{conv}\{\nabla f_i(\mathbf{x}) : i \in I(\mathbf{x})\}. \quad (38.7)$$


38.3.5 Hinge loss

对标量 $\phi(z) = \max\{0, 1 - z\}$, 有

$$\partial\phi(z) = \begin{cases} \{-1\}, & z < 1, \\ [-1, 0], & z = 1, \\ \{0\}, & z > 1. \end{cases} \quad (38.8)$$

若 $\ell(\mathbf{w}) = \max\{0, 1 - y\langle \mathbf{w}, \mathbf{x} \rangle\}$, $y \in \{-1, +1\}$, 则

$$\partial\ell(\mathbf{w}) = \begin{cases} \{-y\mathbf{x}\}, & y\langle \mathbf{w}, \mathbf{x} \rangle < 1, \\ \{-\alpha y\mathbf{x} : \alpha \in [0, 1]\}, & y\langle \mathbf{w}, \mathbf{x} \rangle = 1, \\ \{\mathbf{0}\}, & y\langle \mathbf{w}, \mathbf{x} \rangle > 1. \end{cases} \quad (38.9)$$



38.4 次微分演算

若 $g_f \in \partial f(x)$, $g_R \in \partial R(x)$, 则总有

$$g_f + g_R \in \partial(f + R)(x), \quad (38.10)$$

即

$$\partial f(x) + \partial R(x) \subseteq \partial(f + R)(x). \quad (38.11)$$

在适当的 constraint qualification 下, 例如

$$\text{ri}(\text{dom } f) \cap \text{ri}(\text{dom } R) \neq \emptyset, \quad (38.12)$$

有精确和规则:

$$\partial(f + R)(x) = \partial f(x) + \partial R(x). \quad (38.13)$$

若 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微凸, 则 f 在全空间连续, 因此

$$\partial(f + R)(x) = \nabla f(x) + \partial R(x). \quad (38.14)$$

38.5 次微分单调性

定理 38.2 (次微分映射的单调性). 设 R proper、convex。若 $r_x \in \partial R(x)$, $r_y \in \partial R(y)$, 则

$$\langle r_x - r_y, x - y \rangle \geq 0. \quad (38.15)$$

证明. 由 $r_x \in \partial R(x)$, 有

$$R(y) \geq R(x) + \langle r_x, y - x \rangle. \quad (38.16)$$

由 $r_y \in \partial R(y)$, 有

$$R(x) \geq R(y) + \langle r_y, x - y \rangle. \quad (38.17)$$

两式相加: $0 \geq \langle r_x, y - x \rangle + \langle r_y, x - y \rangle$ 。整理为 $\langle r_x - r_y, x - y \rangle \geq 0$ 。□

若 R 是 μ -强凸函数, 则更强地有

$$\langle r_x - r_y, x - y \rangle \geq \mu \|x - y\|^2. \quad (38.18)$$

答题方法

[26S-C-Q4, 2 分] 的满分答案只需两条次梯度不等式:


$R(y) \geq R(x) + \langle r_x, y - x \rangle$, $R(x) \geq R(y) + \langle r_y, x - y \rangle$ 。相加并整理: $\langle r_x - r_y, x - y \rangle \geq 0$ 。

不得只写“由凸性显然”, 因为该题的得分点就是把两条 subgradient inequalities 相加。

38.6 不可微凸优化的最优性条件

定理 38.3 (无约束凸优化的充要条件). 设 F proper、convex。则

$$x^* \in \arg \min_x F(x) \iff 0 \in \partial F(x^*). \quad (38.19)$$



证明. 若 $\mathbf{0} \in \partial F(\mathbf{x}^*)$, 则对任意 $\mathbf{x}$, $F(\mathbf{x}) \geq F(\mathbf{x}^*) + \langle \mathbf{0}, \mathbf{x} - \mathbf{x}^* \rangle = F(\mathbf{x}^*)$ 。

反之, 若 $\mathbf{x}^*$ 是全局最小点, 则 $F(\mathbf{x}) \geq F(\mathbf{x}^*)$ 对所有 $\mathbf{x}$ 成立, 这正说明 $\mathbf{0}$ 满足次梯度不等式。□

对复合目标 $F = f + R$, 其中 f 可微凸、 R proper convex, 有

$$\boxed{\mathbf{x}^* \text{ 最优} \iff \mathbf{0} \in \nabla f(\mathbf{x}^*) + \partial R(\mathbf{x}^*)}. \quad (38.20)$$

等价地,

$$\boxed{-\nabla f(\mathbf{x}^*) \in \partial R(\mathbf{x}^*)}. \quad (38.21)$$

38.7 法锥与约束最优性

对闭凸集 C 和 $\mathbf{x} \in C$, 定义法锥

$$N_C(\mathbf{x}) := \{\mathbf{v} : \langle \mathbf{v}, \mathbf{z} - \mathbf{x} \rangle \leq 0, \forall \mathbf{z} \in C\}. \quad (38.22)$$

有

$$\boxed{N_C(\mathbf{x}) = \partial \delta_C(\mathbf{x})}. \quad (38.23)$$

因此约束凸优化 $\min_{\mathbf{x} \in C} f(\mathbf{x})$ 等价于 $\min_{\mathbf{x}} f(\mathbf{x}) + \delta_C(\mathbf{x})$, 其一阶充要条件为

$$\boxed{-\nabla f(\mathbf{x}^*) \in N_C(\mathbf{x}^*)}. \quad (38.24)$$

展开法锥定义:

$$\boxed{\langle \nabla f(\mathbf{x}^*), \mathbf{z} - \mathbf{x}^* \rangle \geq 0, \quad \forall \mathbf{z} \in C.} \quad (38.25)$$

这就是约束凸优化的一阶变分不等式。

38.8 Fenchel Conjugate

定义 38.4 (Fenchel 共轭). proper 函数 f 的共轭函数为

$$\boxed{f^*(\mathbf{y}) = \sup_{\mathbf{x} \in \mathbb{R}^d} \{\langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})\}}. \quad (38.26)$$

无论原函数是否凸, f^* 总是 convex 且 lower semicontinuous, 因为它是关于 $\mathbf{y}$ 的仿射函数族的逐点上确界。

定理 38.5 (Fenchel–Young inequality). 对任意 $\mathbf{x}, \mathbf{y}$, 有

$$\boxed{f(\mathbf{x}) + f^*(\mathbf{y}) \geq \langle \mathbf{x}, \mathbf{y} \rangle}. \quad (38.27)$$


证明. 由共轭定义, $f^*(\mathbf{y}) = \sup_{\mathbf{z}} \{\langle \mathbf{y}, \mathbf{z} \rangle - f(\mathbf{z})\}$. 取候选点 $\mathbf{z} = \mathbf{x}$, 得到 $f^*(\mathbf{y}) \geq \langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})$. 移项即得。□

若 f proper、closed、convex, 则以下命题等价:

$$\boxed{f(\mathbf{x}) + f^*(\mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle} \quad (38.28)$$

$$\iff \mathbf{y} \in \partial f(\mathbf{x}) \iff \mathbf{x} \in \partial f^*(\mathbf{y}).$$

证明. $\mathbf{y} \in \partial f(\mathbf{x})$ 等价于 $f(\mathbf{z}) \geq f(\mathbf{x}) + \langle \mathbf{y}, \mathbf{z} - \mathbf{x} \rangle$, $\forall \mathbf{z}$. 整理为 $\langle \mathbf{y}, \mathbf{z} \rangle - f(\mathbf{z}) \leq \langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})$. 因此 $\mathbf{x}$ 达到共轭定义中的上确界, 故 $f^*(\mathbf{y}) = \langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})$. 反向同理。□



38.9 常见共轭函数

38.9.1 平方范数

若 $f(\mathbf{x}) = \frac{\mu}{2} \|\mathbf{x}\|^2$, $\mu > 0$, 则

$$f^*(\mathbf{y}) = \frac{1}{2\mu} \|\mathbf{y}\|^2. \quad (38.29)$$

38.9.2 范数

若 $f(\mathbf{x}) = \|\mathbf{x}\|$, 其对偶范数为

$$\|\mathbf{y}\|_* = \sup_{\|\mathbf{x}\| \leq 1} \langle \mathbf{y}, \mathbf{x} \rangle. \quad (38.30)$$

则

$$f^*(\mathbf{y}) = \delta_{\{\mathbf{y}: \|\mathbf{y}\|_* \leq 1\}}(\mathbf{y}). \quad (38.31)$$

特别地,

$$(\lambda \|\cdot\|_1)^*(\mathbf{y}) = \delta_{\{\|\mathbf{y}\|_\infty \leq \lambda\}}(\mathbf{y}). \quad (38.32)$$

38.9.3 示性函数

闭凸集 C 的示性函数共轭为支撑函数:

$$\delta_C^*(\mathbf{y}) = \sigma_C(\mathbf{y}) := \sup_{\mathbf{x} \in C} \langle \mathbf{y}, \mathbf{x} \rangle. \quad (38.33)$$

38.9.4 二次共轭

若 f proper、closed、convex, 则

$$\boxed{f^{**} = f}. \quad (38.34)$$

若 f 不是 closed convex, 则 f^{**} 是不超过 f 的最大 lower-semicontinuous convex function, 即其闭凸包络。

38.10 强凸性与共轭光滑性


若 f proper、closed 且 μ -strongly convex, 则:

- f^* 在全空间有限;
- f^* 可微;
- ∇f^* 是 $1/\mu$ -Lipschitz。

其核心关系是

$$\mathbf{y} \in \partial f(\mathbf{x}) \iff \mathbf{x} = \nabla f^*(\mathbf{y}). \quad (38.35)$$

强凸性使 ∂f 强单调, 从而其逆映射 $(\partial f)^{-1} = \nabla f^*$ 是 $1/\mu$ -Lipschitz。



38.11 Proximal Operator

定义 38.6 (近端算子). 设 R proper、closed、convex, $\gamma > 0$. 定义

$$\text{prox}_{\gamma R}(\mathbf{u}) := \arg \min_{\mathbf{x} \in \mathbb{R}^d} \left\{ R(\mathbf{x}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{u}\|^2 \right\}. \quad (38.36)$$

由于目标函数包含 $\frac{1}{2\gamma} \|\mathbf{x} - \mathbf{u}\|^2$, 它是 $1/\gamma$ -strongly convex. 结合 proper、closed, 可知最小点存在且唯一, 因此 prox 是单值映射。

易错点、反例与失败模式

1. 有些资料写 $\text{prox}_R(\mathbf{u}) = \arg \min_{\mathbf{x}} \{R(\mathbf{x}) + \frac{1}{2} \|\mathbf{x} - \mathbf{u}\|^2\}$; 这是 $\gamma = 1$ 的特殊情形。
2. $\text{prox}_{\gamma R}$ 中的 γ 同时控制函数权重和二次项系数, 不能只在一个位置改变。
3. Proximal operator 不一定有闭式解。一阶算法通常额外假设 R 是 prox-friendly, 即单次 prox 的代价可接受。

38.12 Prox 的最优性条件

定理 38.7 (近端算子最优性条件). 对任意 $\mathbf{u} \in \mathbb{R}^d$ 和 $\gamma > 0$, 有

$$\mathbf{x}^+ = \text{prox}_{\gamma R}(\mathbf{u}) \iff \frac{1}{\gamma}(\mathbf{u} - \mathbf{x}^+) \in \partial R(\mathbf{x}^+). \quad (38.37)$$

证明. 定义 $\Phi(\mathbf{x}) = R(\mathbf{x}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{u}\|^2$. Φ proper、closed、strongly convex. 根据凸优化最优性条件, $\mathbf{x}^+ = \arg \min \Phi \iff \mathbf{0} \in \partial \Phi(\mathbf{x}^+)$. 由次微分和规则:

$$\partial \Phi(\mathbf{x}^+) = \partial R(\mathbf{x}^+) + \frac{1}{\gamma}(\mathbf{x}^+ - \mathbf{u}). \quad (38.38)$$

因此

$$\mathbf{0} \in \partial R(\mathbf{x}^+) + \frac{1}{\gamma}(\mathbf{x}^+ - \mathbf{u}) \quad (38.39)$$

等价于 $\frac{1}{\gamma}(\mathbf{u} - \mathbf{x}^+) \in \partial R(\mathbf{x}^+)$. □

答题方法

[26S-C-Q2, 3 分] 的标准答法:

$\mathbf{x}^+ = \arg \min_{\mathbf{x}} \left[R(\mathbf{x}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{u}\|^2 \right]$. 因为目标是 proper closed strongly convex, 最优点唯一且满足 $\mathbf{0} \in \partial R(\mathbf{x}^+) + \frac{1}{\gamma}(\mathbf{x}^+ - \mathbf{u})$. 移项: $\frac{1}{\gamma}(\mathbf{u} - \mathbf{x}^+) \in \partial R(\mathbf{x}^+)$.

满分关键:

- 写出 prox 的定义;
- 对二次项求梯度时符号正确;
- 使用的是次微分包含关系, 不是普通等式 $\nabla R = 0$.

38.13 Prox 的 firm nonexpansiveness

定理 38.8 (近端算子的牢固非扩张性). 设 $\mathbf{p} = \text{prox}_{\gamma R}(\mathbf{u})$, $\mathbf{q} = \text{prox}_{\gamma R}(\mathbf{v})$. 则

$$\|\mathbf{p} - \mathbf{q}\|^2 \leq \langle \mathbf{p} - \mathbf{q}, \mathbf{u} - \mathbf{v} \rangle. \quad (38.40)$$

从而

$$\|\text{prox}_{\gamma R}(\mathbf{u}) - \text{prox}_{\gamma R}(\mathbf{v})\| \leq \|\mathbf{u} - \mathbf{v}\|. \quad (38.41)$$

证明. 由 prox 最优性条件,

$$\frac{1}{\gamma}(\mathbf{u} - \mathbf{p}) \in \partial R(\mathbf{p}), \quad (38.42)$$

$$\frac{1}{\gamma}(\mathbf{v} - \mathbf{q}) \in \partial R(\mathbf{q}). \quad (38.43)$$

由次微分单调性:

$$\left\langle \frac{1}{\gamma}(\mathbf{u} - \mathbf{p}) - \frac{1}{\gamma}(\mathbf{v} - \mathbf{q}), \mathbf{p} - \mathbf{q} \right\rangle \geq 0. \quad (38.44)$$

乘以 γ 并整理:

$$\begin{aligned} \langle \mathbf{u} - \mathbf{v}, \mathbf{p} - \mathbf{q} \rangle &\geq \langle \mathbf{p} - \mathbf{q}, \mathbf{p} - \mathbf{q} \rangle \\ &= \|\mathbf{p} - \mathbf{q}\|^2. \end{aligned} \quad (38.45)$$

这给出 firm nonexpansiveness. 再用 Cauchy-Schwarz 即得普通非扩张性. $\square$

答题方法

[26S-C-Q5, 3 分] 的满分证明链:

$\frac{\mathbf{u}-\mathbf{p}}{\gamma} \in \partial R(\mathbf{p})$, $\frac{\mathbf{v}-\mathbf{q}}{\gamma} \in \partial R(\mathbf{q})$. 由 monotonicity: $\langle (\mathbf{u}-\mathbf{p}) - (\mathbf{v}-\mathbf{q}), \mathbf{p}-\mathbf{q} \rangle \geq 0$. 于是 $\|\mathbf{p}-\mathbf{q}\|^2 \leq \langle \mathbf{u}-\mathbf{v}, \mathbf{p}-\mathbf{q} \rangle \leq \|\mathbf{u}-\mathbf{v}\| \|\mathbf{p}-\mathbf{q}\|$. 约去非零项后得到 $\|\mathbf{p}-\mathbf{q}\| \leq \|\mathbf{u}-\mathbf{v}\|$.

最好先写更强的 firm nonexpansiveness, 再推出 nonexpansiveness.

38.14 Projection 是示性函数的 Prox

对闭凸集 C ,

$$\begin{aligned} \text{prox}_{\gamma \delta_C}(\mathbf{u}) &= \arg \min_{\mathbf{x}} \left\{ \delta_C(\mathbf{x}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{u}\|^2 \right\} \\ &= \arg \min_{\mathbf{x} \in C} \|\mathbf{x} - \mathbf{u}\|^2 \\ &= P_C(\mathbf{u}). \end{aligned} \quad (38.46)$$


因此: projected gradient 是 proximal gradient 在 $R = \delta_C$ 时的特殊情况.

38.15 常见 Prox 闭式解

38.15.1 ℓ_1 Soft Thresholding

对 $R(\mathbf{x}) = \lambda \|\mathbf{x}\|_1$, prox 可逐坐标分离:

$$\left[\text{prox}_{\gamma \lambda \|\cdot\|_1}(\mathbf{u}) \right]_i = \text{sign}(u_i) \max\{|u_i| - \gamma \lambda, 0\}. \quad (38.47)$$



定义 soft-threshold operator: $S_\tau(u) = \text{sign}(u)(|u| - \tau)_+$, $(a)_+ := \max\{a, 0\}$ 。

38.15.2 ℓ_2 范数

对 $R(\mathbf{x}) = \lambda \|\mathbf{x}\|_2$, 有 group shrinkage:

$$\text{prox}_{\gamma\lambda\|\cdot\|_2}(\mathbf{u}) = \left(1 - \frac{\gamma\lambda}{\|\mathbf{u}\|_2}\right)_+ \mathbf{u}. \quad (38.48)$$

38.15.3 平方范数

对 $R(\mathbf{x}) = \frac{\lambda}{2} \|\mathbf{x}\|^2$, 有

$$\text{prox}_{\gamma R}(\mathbf{u}) = \frac{1}{1 + \gamma\lambda} \mathbf{u}. \quad (38.49)$$

38.16 复合最优点的 Proximal Fixed Point

定理 38.9 (Proximal fixed-point characterization). 设 f 可微凸, R proper、closed、convex。则对任意 $\gamma > 0$,

$$\mathbf{x}^* \in \arg \min_{\mathbf{x}} [f(\mathbf{x}) + R(\mathbf{x})] \quad (38.50)$$

当且仅当

$$\mathbf{x}^* = \text{prox}_{\gamma R}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*)). \quad (38.51)$$

证明. 由复合最优性条件: $\mathbf{x}^*$ 最优 $\iff -\nabla f(\mathbf{x}^*) \in \partial R(\mathbf{x}^*)$ 。乘以 γ : $-\gamma \nabla f(\mathbf{x}^*) \in \gamma \partial R(\mathbf{x}^*)$ 。等价地, $[\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*)] - \mathbf{x}^* \in \gamma \partial R(\mathbf{x}^*)$ 。由 prox 最优性条件, 这当且仅当 $\mathbf{x}^* = \text{prox}_{\gamma R}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*))$ 。□

答题方法

[26S-C-Q3, 3 分] 的完整结构:

1. 说明 $F = f + R$ 是 μ -strongly convex、proper、closed, 因而存在唯一最小点 $\mathbf{x}^*$;
2. 写复合最优性: $\mathbf{0} \in \nabla f(\mathbf{x}^*) + \partial R(\mathbf{x}^*)$;
3. 改写为 $-\nabla f(\mathbf{x}^*) \in \partial R(\mathbf{x}^*)$;
4. 利用 prox 最优性条件得到 $\mathbf{x}^* = \text{prox}_{\gamma R}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*))$ 。

不得把 fixed point 写成 $\mathbf{x}^* = \text{prox}_{\gamma R}(\mathbf{x}^*)$, 因为 smooth term 的梯度步不能遗漏。

38.17 Moreau Decomposition

定理 38.10 (广义 Moreau 分解). 设 f proper、closed、convex, $\gamma > 0$ 。则

$$\mathbf{x} = \text{prox}_{\gamma f}(\mathbf{x}) + \gamma \text{prox}_{\gamma^{-1} f^*}\left(\frac{\mathbf{x}}{\gamma}\right). \quad (38.52)$$

证明. 令 $\mathbf{p} = \text{prox}_{\gamma f}(\mathbf{x})$ 。由 prox 最优性:

$$\frac{\mathbf{x} - \mathbf{p}}{\gamma} \in \partial f(\mathbf{p}). \quad (38.53)$$

定义 $\mathbf{q} = \frac{\mathbf{x} - \mathbf{p}}{\gamma}$ 。由 Fenchel 共轭的次微分反演关系, $\mathbf{q} \in \partial f(\mathbf{p}) \iff \mathbf{p} \in \partial f^*(\mathbf{q})$ 。因此 $\frac{\mathbf{x}}{\gamma} - \mathbf{q} = \frac{\mathbf{p}}{\gamma} \in \partial \left(\frac{1}{\gamma} f^* \right)(\mathbf{q})$ 。再次使用 prox 最优性条件: $\mathbf{q} = \text{prox}_{\gamma^{-1} f^*} \left(\frac{\mathbf{x}}{\gamma} \right)$ 。由 $\mathbf{x} = \mathbf{p} + \gamma \mathbf{q}$ 得到结论。 $\square$

当 $\gamma = 1$ 时,

$$\mathbf{x} = \text{prox}_f(\mathbf{x}) + \text{prox}_{f^*}(\mathbf{x}). \quad (38.54)$$

38.18 Moreau Envelope

定义 38.11 (Moreau envelope). 对 $\gamma > 0$, 定义

$$e_{\gamma f}(\mathbf{x}) := \inf_{\mathbf{u}} \left\{ f(\mathbf{u}) + \frac{1}{2\gamma} \|\mathbf{u} - \mathbf{x}\|^2 \right\}. \quad (38.55)$$

若 $\mathbf{p} = \text{prox}_{\gamma f}(\mathbf{x})$, 则

$$e_{\gamma f}(\mathbf{x}) = f(\mathbf{p}) + \frac{1}{2\gamma} \|\mathbf{p} - \mathbf{x}\|^2. \quad (38.56)$$

Moreau envelope 的核心性质:

1. $e_{\gamma f}$ 在全空间有限且凸;
2. 即使 f 不可微, $e_{\gamma f}$ 仍可微;
3. 梯度为

$$\nabla e_{\gamma f}(\mathbf{x}) = \frac{1}{\gamma} [\mathbf{x} - \text{prox}_{\gamma f}(\mathbf{x})]; \quad (38.57)$$

4. 梯度是 $1/\gamma$ -Lipschitz;
5. 若 f 有最小点, 则

$$\arg \min e_{\gamma f} = \arg \min f. \quad (38.58)$$


Moreau envelope 把非光滑凸函数平滑化, 但不会把其最小点位置任意改变。

例 38.12 (示性函数的 Moreau envelope). 若 $f = \delta_C$, 则

$$\begin{aligned} e_{\gamma \delta_C}(\mathbf{x}) &= \min_{\mathbf{u} \in C} \frac{1}{2\gamma} \|\mathbf{u} - \mathbf{x}\|^2 \\ &= \frac{1}{2\gamma} \text{dist}(\mathbf{x}, C)^2. \end{aligned} \quad (38.59)$$

并且

$$\nabla e_{\gamma \delta_C}(\mathbf{x}) = \frac{1}{\gamma} [\mathbf{x} - P_C(\mathbf{x})]. \quad (38.60)$$



第三十九章 凸分析答题模板、映射与易错点

39.1 定义与结论速查

表 39.1: 凸分析核心定义与直接结论

概念	定义或公式	直接结论与必要条件
凸集	$\theta x + (1 - \theta)y \in C$	交、仿射像、原像保持凸；并一般不保持凸。
投影	$P_C(x) = \arg \min_{z \in C} \ z - x\ ^2$	C 非空、闭、凸时存在唯一； firmly nonexpansive。
投影变分不等式	$\langle x - P_C(x), z - P_C(x) \rangle \leq 0$	约束最优性、投影算法和分离定理的核心。
Proper	$\text{dom } f \neq \emptyset, \quad f > -\infty$	排除恒 $+\infty$ 和取 $-\infty$ 的退化函数。
Closed / l.s.c.	$\text{epi } f$ 闭	等价于所有下水平集闭；结合 level-boundedness 给 existence。
凸函数	$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$	驻点即全局最优点。
强凸	$f(y) \geq f(x) + \langle g, y - x \rangle + \frac{\mu}{2} \ y - x\ ^2$	最优点若存在则唯一；closed proper 时有二次增长。
L -smooth	$\ \nabla f(x) - \nabla f(y)\ \leq L\ x - y\ $	Descent lemma；梯度步长由 L 控制。
Co-coercivity	$\langle \Delta \nabla f, \Delta x \rangle \geq \frac{1}{L} \ \Delta \nabla f\ ^2$	要求 convex + smooth；仅 smooth 不足。
次梯度	$f(y) \geq f(x) + \langle g, y - x \rangle$	不可微凸函数的一阶工具； ∂f 单调。
凸最优性	$0 \in \partial F(x^*)$	proper convex 目标的全局最优充要条件。
Fenchel 共轭	$f^*(y) = \sup_x \{\langle y, x \rangle - f(x)\}$	恒为 closed convex； Fenchel-Young inequality。
Prox	$\text{prox}_{\gamma R}(u) = \arg \min_x \left\{ R(x) + \frac{1}{2\gamma} \ x - u\ ^2 \right\}$	proper closed convex 时单值； firmly nonexpansive。
Prox 最优性	$\frac{u - x^+}{\gamma} \in \partial R(x^+)$	连接 prox、次微分和 fixed point。
Moreau envelope	$e_{\gamma f}(x) = \inf_u \left\{ f(u) + \frac{1}{2\gamma} \ u - x\ ^2 \right\}$	$\nabla e_{\gamma f}(x) = \gamma^{-1}(x - \text{prox}_{\gamma f}(x))$ 。

39.2 历年真题映射

表 39.2: 第 11 部分真题映射

题目	主要标签	满分不可缺少内容
[25S-C-Q1, 5 分]	L -smooth、 μ -strong convex	梯度 Lipschitz 定义；强凸一阶二次下界；参数范围；不得把函数 Lipschitz 与梯度 Lipschitz 混淆。
[25S-C-Q2, 6 分]	Shifted function、co-coercivity、联合插值	证明 $h = f - \frac{\mu}{2}\ \cdot\ ^2$ 凸且 $(L - \mu)$ -smooth；对 h 用 co-coercivity；完整展开平方。
[25F-C-Q1, 3 分]	基本定义	与 [25S-C-Q1, 5 分] 相同，但作答应更精炼。
[25F-C-Q2, 2 分]	唯一最小点	$f + R$ 保持 μ -强凸；存在性条件；严格中点不等式证明唯一。
[26S-C-Q1, 2 分]	基本定义	L -smooth 与 μ -strong convex 的精确定义。
[26S-C-Q2, 3 分]	Prox 最优性	prox 定义； $0 \in \partial R(x^+) + \gamma^{-1}(x^+ - u)$ ；移项。
[26S-C-Q3, 3 分]	唯一性、proximal fixed point	$0 \in \nabla f(x^*) + \partial R(x^*)$ 与 $x^* = \text{prox}_{\gamma R}(x^* - \gamma \nabla f(x^*))$ 。
[26S-C-Q4, 2 分]	次微分单调性	在 x, y 两点各写一条次梯度不等式并相加。
[26S-C-Q5, 3 分]	Prox 非扩张性	prox 最优性；次微分单调性；firm nonexpansiveness；Cauchy-Schwarz。
[25F-A-Q10, 6 分]	强凸基本性质，跨方向	$\lambda\ w\ ^2$ 是 2λ -强凸；强凸函数加凸函数仍强凸；最优值 gap 二次下界。

39.3 课程训练材料对应

说明 39.1 (MLT-Practice-Q2). 集中训练：

1. $f(w) = \lambda\|w\|^2$ 的强凸参数；
2. 强凸函数与凸函数之和；
3. $f(w) - f(u) \geq \frac{\lambda}{2}\|w - u\|^2$ 类型的最优值 gap。

这些内容可作为强凸定义的训练证据，但不得计入人工智能博士资格考试出现频率。



39.4 证明套路识别

答题方法

看到“闭凸集最近点”时：极小化序列 $\rightarrow$ 闭性给存在 $\rightarrow$ 中点恒等式给唯一 $\rightarrow$ 单边导数给变分不等式。

看到“严格分离”时： $\bar{x} = P_C(b)$, $a = b - \bar{x}$, 再使用 $\langle b - \bar{x}, x - \bar{x} \rangle \leq 0$ 。

看到“强凸 + 光滑”时： $h(x) = f(x) - \frac{\mu}{2}\|x\|^2$, 对 h 使用 convex smooth co-coercivity。

看到“prox 非扩张”时：prox optimality $\rightarrow$ subdifferential monotonicity $\rightarrow$ firm nonexpansiveness $\rightarrow$ nonexpansiveness。

看到“复合最优点”时： $0 \in \nabla f(x^*) + \partial R(x^*)$ 并转成 proximal fixed point。

看到“不可微正则项”时：不要写 $\nabla R(x)$; 应写 $\partial R(x)$ 或 $\text{prox}_{\gamma R}$ 。

39.5 综合易错点

易错点、反例与失败模式

1. **Convex、strictly convex、strongly convex 不等价。**

正确关系：strong $\Rightarrow$ strict $\Rightarrow$ convex。

2. **强凸不自动等于存在最优解。**

若定义域不闭，最小值可能不被达到。存在性要检查 proper、closed、level-bounded 或 coercive。

3. **驻点不总是最小点。**

只有在凸可微目标中， $\nabla f(x^*) = 0$ 才是全局最优充要条件。

4. **Smoothness 不等于函数 Lipschitz。**

Smoothness 控制梯度变化，function Lipschitz 控制函数值变化。

5. **Smoothness 不要求处处二阶可微。**

Hessian 条件只是在二阶连续可微时的等价刻画。

6. **Co-coercivity 需要凸性。**

L -smooth 非凸函数一般不能保证 $\langle \Delta \nabla f, \Delta x \rangle \geq L^{-1} \|\Delta \nabla f\|^2$ 。

7. **Bregman divergence 不对称。**

必须明确 $D_f(x, y) = f(x) - f(y) - \langle \nabla f(y), x - y \rangle$ 。

8. **次梯度不一定唯一。**

例如 $\partial|0| = [-1, 1]$ 。

9. **Prox 与 projection 不完全相同。**

Projection 是 $R = \delta_C$ 时的特殊 prox。

10. **Prox 的非扩张性不是由普通微分得到。**

标准证明依赖：prox optimality + subdifferential monotonicity。

11. Fixed point 中不能漏掉梯度项。

正确形式: $x^* = \text{prox}_{\gamma R}(x^* - \gamma \nabla f(x^*))$.

12. Fenchel–Young 的等号有条件。

总有 $f(x) + f^*(y) \geq \langle x, y \rangle$; 等号当且仅当 $y \in \partial f(x)$.

13. Moreau decomposition 的缩放不能遗漏。

一般形式为 $x = \text{prox}_{\gamma f}(x) + \gamma \text{prox}_{\gamma^{-1} f^*}(x/\gamma)$.

39.6 快速自测

快速自测

1. 仿射集与凸集的定义中, 系数 θ 的范围有何不同?
2. 为什么两个凸集的并不一定凸, 而交一定凸?
3. 闭凸集投影的存在性和唯一性分别使用了什么条件?
4. 写出投影变分不等式。
5. 如何从投影点构造点与闭凸集的严格分离向量?
6. Farkas 引理中的两个系统为什么不能同时可行?
7. Farkas 证明中为何需要利用锥的可缩放性?
8. proper 函数为什么必须满足 $\text{dom } f \neq \emptyset$?
9. lower semicontinuity、closed epigraph 和闭下水平集之间是什么关系?
10. 什么条件能够保证最小点存在?
11. 强凸为何保证唯一性, 却不在任意定义域上自动保证存在性?
12. 写出强凸函数的 Jensen 形式和一阶形式。
13. $f(x) = x^4$ 为什么严格凸但不是全局强凸?
14. 函数 Lipschitz 与梯度 Lipschitz 有何区别?
15. 写出 descent lemma, 并说明每一项的维度。
16. 为什么 $\frac{1}{2L} \|\nabla f(x)\|^2 \leq f(x) - f^*$ 可以不要求凸性?
17. 写出 Bregman divergence, 并说明其线性化基点是哪一个变量。
18. Co-coercivity 需要哪些假设?
19. 如何由 $h = f - \frac{\mu}{2} \|\cdot\|^2$ 推导联合插值不等式?
20. 为什么 $L \geq \mu$?
21. 条件数 $\kappa = L/\mu$ 对二次函数有什么谱解释?

22. 写出 $|x|$ 、 $\|x\|_1$ 、hinge loss 的次微分。
23. 如何证明次微分映射单调?
24. 不可微凸目标的全局最优充要条件是什么?
25. 约束凸优化如何通过示性函数转成无约束复合优化?
26. 写出 Fenchel 共轭和 Fenchel–Young inequality。
27. Fenchel–Young 何时取等号?
28. $(\lambda\|\cdot\|_1)^*$ 是什么?
29. 写出本文采用的 prox 参数化。
30. 如何从 prox 定义得到最优性条件?
31. Firm nonexpansiveness 与 ordinary nonexpansiveness 哪一个更强?
32. 为什么 projection 是 prox 的特殊情况?
33. 写出 ℓ_1 soft-thresholding 公式。
34. 写出复合目标最优点的 proximal fixed-point 公式。
35. 写出带任意 $\gamma > 0$ 的 Moreau decomposition。
36. Moreau envelope 的梯度是什么?



第四十章 梯度下降：非凸、凸与强凸情形

40.1 重要性等级与问题设定

重要性等级：S

梯度下降（gradient descent, GD）是后续投影梯度、近端梯度、随机梯度和动量法的基本母算法。

资格考试中通常不只要求写出 $\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \nabla f(\mathbf{x}^k)$ ，而是要求说明：

1. 目标函数属于非凸光滑、凸光滑还是强凸光滑类别；
2. 步长 γ 满足什么范围；
3. 收敛指标是函数值、梯度范数还是迭代点距离；
4. 一步不等式如何建立；
5. 求和后哪些项 telescope；
6. 复杂度中的精度 ε 究竟指 $\|\nabla f\| \leq \varepsilon$ 、 $\|\nabla f\|^2 \leq \varepsilon$ 还是 $f - f^* \leq \varepsilon$ 。

考虑无约束问题

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}), \quad (40.1)$$

其中 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微。

梯度下降迭代为

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma_k \nabla f(\mathbf{x}^k), \quad k = 0, 1, \dots \quad (40.2)$$

若使用常数步长，则 $\gamma_k \equiv \gamma > 0$ 。


40.2 为什么负梯度是最速下降方向

在 Euclidean 范数下，对一阶近似 $f(\mathbf{x} + \mathbf{d}) \approx f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{d} \rangle$ ，单位方向中的最小线性变化满足

$$\arg \min_{\|\mathbf{d}\| \leq 1} \langle \nabla f(\mathbf{x}), \mathbf{d} \rangle = -\frac{\nabla f(\mathbf{x})}{\|\nabla f(\mathbf{x})\|}, \quad (40.3)$$

其中假设 $\nabla f(\mathbf{x}) \neq \mathbf{0}$ 。

这是 Cauchy-Schwarz 不等式取等号的结果： $\langle \nabla f(\mathbf{x}), \mathbf{d} \rangle \geq -\|\nabla f(\mathbf{x})\| \|\mathbf{d}\| \geq -\|\nabla f(\mathbf{x})\|$ 。



梯度下降还可写成局部二次模型的精确最小化：

$$\mathbf{x}^{k+1} = \arg \min_{\mathbf{z} \in \mathbb{R}^d} \left\{ f(\mathbf{x}^k) + \langle \nabla f(\mathbf{x}^k), \mathbf{z} - \mathbf{x}^k \rangle + \frac{1}{2\gamma} \|\mathbf{z} - \mathbf{x}^k\|^2 \right\}. \quad (40.4)$$

对 $\mathbf{z}$ 求梯度并令其为零： $\nabla f(\mathbf{x}^k) + \frac{1}{\gamma}(\mathbf{z} - \mathbf{x}^k) = \mathbf{0}$ ，即得式 (40.2)。

40.3 L -光滑目标的一步下降

定理 40.1 (梯度下降的一步下降不等式). 设 f 是 L -smooth。对常数步长梯度下降，有

$$f(\mathbf{x}^{k+1}) \leq f(\mathbf{x}^k) - \gamma \left(1 - \frac{L\gamma}{2} \right) \|\nabla f(\mathbf{x}^k)\|^2. \quad (40.5)$$

特别地，若 $0 < \gamma \leq \frac{1}{L}$ ，则

$$f(\mathbf{x}^{k+1}) \leq f(\mathbf{x}^k) - \frac{\gamma}{2} \|\nabla f(\mathbf{x}^k)\|^2. \quad (40.6)$$

证明. 由 descent lemma,

$$\begin{aligned} f(\mathbf{x}^{k+1}) &\leq f(\mathbf{x}^k) + \langle \nabla f(\mathbf{x}^k), \mathbf{x}^{k+1} - \mathbf{x}^k \rangle \\ &\quad + \frac{L}{2} \|\mathbf{x}^{k+1} - \mathbf{x}^k\|^2. \end{aligned} \quad (40.7)$$

代入 $\mathbf{x}^{k+1} - \mathbf{x}^k = -\gamma \nabla f(\mathbf{x}^k)$ ，得到

$$\begin{aligned} f(\mathbf{x}^{k+1}) &\leq f(\mathbf{x}^k) - \gamma \|\nabla f(\mathbf{x}^k)\|^2 + \frac{L\gamma^2}{2} \|\nabla f(\mathbf{x}^k)\|^2 \\ &= f(\mathbf{x}^k) - \gamma \left(1 - \frac{L\gamma}{2} \right) \|\nabla f(\mathbf{x}^k)\|^2. \end{aligned} \quad (40.8)$$

□

因此，只要 $0 < \gamma < \frac{2}{L}$ ，右侧下降系数为正。

易错点、反例与失败模式

$\gamma \leq \frac{1}{L}$ 是便于证明和记忆的安全步长，但不是函数值下降的最大可能区间。

对一般 L -smooth 函数，式 (40.5) 在 $0 < \gamma < \frac{2}{L}$ 时仍给出下降。

然而很多标准定理选择 $\gamma = \frac{1}{L}$ 是因为此时：

- 常数简单；
- 与二次上界的最小点一致；
- 便于导出 $O(1/K)$ 和线性收敛率；
- 对未知曲率误差有一定安全余量。

40.4 非凸光滑情形：收敛到一阶驻点

定理 40.2 (非凸 L -smooth 梯度下降). 设：



1. f 是 L -smooth, 但不要求凸;
2. f 有有限下界 $f_{\inf} := \inf_{\mathbf{x}} f(\mathbf{x}) > -\infty$;
3. 使用常数步长 $0 < \gamma < \frac{2}{L}$.

定义 $\Delta_0 := f(\mathbf{x}^0) - f_{\inf}$ 。则

$$\sum_{k=0}^{K-1} \|\nabla f(\mathbf{x}^k)\|^2 \leq \frac{\Delta_0}{\gamma(1 - L\gamma/2)}, \quad (40.9)$$

从而

$$\min_{0 \leq k < K} \|\nabla f(\mathbf{x}^k)\|^2 \leq \frac{\Delta_0}{K\gamma(1 - L\gamma/2)}. \quad (40.10)$$

当 $\gamma = \frac{1}{L}$ 时,

$$\min_{0 \leq k < K} \|\nabla f(\mathbf{x}^k)\|^2 \leq \frac{2L\Delta_0}{K}. \quad (40.11)$$

证明. 对式 (40.5) 从 $k = 0$ 到 $K - 1$ 求和:

$$\begin{aligned} & \gamma \left(1 - \frac{L\gamma}{2}\right) \sum_{k=0}^{K-1} \|\nabla f(\mathbf{x}^k)\|^2 \\ & \leq \sum_{k=0}^{K-1} [f(\mathbf{x}^k) - f(\mathbf{x}^{k+1})] \\ & = f(\mathbf{x}^0) - f(\mathbf{x}^K) \\ & \leq f(\mathbf{x}^0) - f_{\inf} = \Delta_0. \end{aligned} \quad (40.12)$$

再使用 $K \min_{0 \leq k < K} \|\nabla f(\mathbf{x}^k)\|^2 \leq \sum_{k=0}^{K-1} \|\nabla f(\mathbf{x}^k)\|^2$ 。

□

40.4.1 复杂度中的 ε 必须说明含义

若要求 $\min_{k < K} \|\nabla f(\mathbf{x}^k)\|^2 \leq \varepsilon$, 则 $K = O\left(\frac{L\Delta_0}{\varepsilon}\right)$ 。

若要求更常见的一阶驻点标准 $\min_{k < K} \|\nabla f(\mathbf{x}^k)\| \leq \varepsilon$, 则必须令平方范数不超过 ε^2 , 因此 $K = O\left(\frac{L\Delta_0}{\varepsilon^2}\right)$ 。

易错点、反例与失败模式

非凸情形下, 结论是“至少存在一个迭代点梯度较小”, 不是:

- 找到全局最小点;
- 找到局部最小点;
- 所有迭代点都满足小梯度;
- 函数值误差 $f(\mathbf{x}^k) - f^*$ 有 $O(1/k)$ 上界。

驻点还可能是局部最大点或鞍点。

40.5 凸光滑情形：函数值 $O(1/K)$

定理 40.3 (凸光滑梯度下降的最后迭代点收敛率). 设 f 凸且 L -smooth, 并且最小点 $\mathbf{x}^* \in \arg \min f$ 存在。

采用 $\gamma = \frac{1}{L}$ 。则对任意整数 $K \geq 1$,

$$\boxed{f(\mathbf{x}^K) - f^* \leq \frac{L\|\mathbf{x}^0 - \mathbf{x}^*\|^2}{2K}}. \quad (40.13)$$

证明. 记 $\mathbf{g}^k = \nabla f(\mathbf{x}^k)$ 。由一步下降,

$$f(\mathbf{x}^{k+1}) \leq f(\mathbf{x}^k) - \frac{1}{2L}\|\mathbf{g}^k\|^2. \quad (40.14)$$

由凸性,

$$f(\mathbf{x}^k) - f^* \leq \langle \mathbf{g}^k, \mathbf{x}^k - \mathbf{x}^* \rangle. \quad (40.15)$$

因此

$$\begin{aligned} f(\mathbf{x}^{k+1}) - f^* &\leq \langle \mathbf{g}^k, \mathbf{x}^k - \mathbf{x}^* \rangle - \frac{1}{2L}\|\mathbf{g}^k\|^2 \\ &= \frac{L}{2} \left(\|\mathbf{x}^k - \mathbf{x}^*\|^2 - \left\| \mathbf{x}^k - \frac{1}{L}\mathbf{g}^k - \mathbf{x}^* \right\|^2 \right) \\ &= \frac{L}{2} (\|\mathbf{x}^k - \mathbf{x}^*\|^2 - \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2). \end{aligned} \quad (40.16)$$

对 $k = 0, \dots, K-1$ 求和:

$$\sum_{k=0}^{K-1} [f(\mathbf{x}^{k+1}) - f^*] \leq \frac{L}{2} \|\mathbf{x}^0 - \mathbf{x}^*\|^2. \quad (40.17)$$

又由于函数值单调不减, $f(\mathbf{x}^K) - f^* \leq f(\mathbf{x}^{k+1}) - f^*$, $k+1 \leq K$ 。故 $K[f(\mathbf{x}^K) - f^*] \leq \frac{L}{2} \|\mathbf{x}^0 - \mathbf{x}^*\|^2$ 。□

得到函数值精度 $f(\mathbf{x}^K) - f^* \leq \epsilon$ 所需迭代数为

$$K \geq \frac{L\|\mathbf{x}^0 - \mathbf{x}^*\|^2}{2\epsilon}, \quad (40.18)$$

即 $O(\frac{1}{\epsilon})$ 次 full-gradient oracle 调用。

40.6 强凸光滑情形：线性收敛

40.6.1 函数值形式


定理 40.4 (步长 $1/L$ 的函数值线性收敛). 设 f 是 L -smooth 且 μ -strongly convex, 并令 $\kappa = \frac{L}{\mu}$ 。采用 $\gamma = \frac{1}{L}$ 。则

$$\boxed{f(\mathbf{x}^K) - f^* \leq \left(1 - \frac{\mu}{L}\right)^K [f(\mathbf{x}^0) - f^*]}. \quad (40.19)$$

证明. 由一步下降: $f(\mathbf{x}^{k+1}) - f^* \leq f(\mathbf{x}^k) - f^* - \frac{1}{2L}\|\nabla f(\mathbf{x}^k)\|^2$ 。强凸性给出 Polyak-Łojasiewicz 型不等式 $\|\nabla f(\mathbf{x}^k)\|^2 \geq 2\mu[f(\mathbf{x}^k) - f^*]$ 。代入得到

$$f(\mathbf{x}^{k+1}) - f^* \leq \left(1 - \frac{\mu}{L}\right) [f(\mathbf{x}^k) - f^*]. \quad (40.20)$$

递推即可。□



由于 $1 - \frac{1}{\kappa} \leq e^{-1/\kappa}$, 有

$$f(\mathbf{x}^K) - f^* \leq e^{-K/\kappa} [f(\mathbf{x}^0) - f^*]. \quad (40.21)$$

因此达到函数值精度 ε 需要

$$K \geq \kappa \log \frac{f(\mathbf{x}^0) - f^*}{\varepsilon}, \quad (40.22)$$

即 $O(\kappa \log \frac{1}{\varepsilon})$ 。

40.6.2 最优固定步长的迭代点收缩

由上一部分的 smooth-strong convex interpolation inequality, 当

$$\gamma_* = \frac{2}{L + \mu} \quad (40.23)$$

时,

$$\|\mathbf{x}^{k+1} - \mathbf{x}^*\| \leq q \|\mathbf{x}^k - \mathbf{x}^*\|, \quad q = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1}. \quad (40.24)$$

故

$$\|\mathbf{x}^K - \mathbf{x}^*\| \leq q^K \|\mathbf{x}^0 - \mathbf{x}^*\|. \quad (40.25)$$

由 L -smoothness,

$$f(\mathbf{x}^K) - f^* \leq \frac{L}{2} q^{2K} \|\mathbf{x}^0 - \mathbf{x}^*\|^2. \quad (40.26)$$

40.7 步长过大的反例

反例 40.5 (一维二次函数). 考虑 $f(x) = \frac{L}{2}x^2$. 则 $\nabla f(x) = Lx$, 梯度下降更新为

$$x^{k+1} = (1 - \gamma L)x^k. \quad (40.27)$$

收敛到 0 的充要条件为 $|1 - \gamma L| < 1$, 即

$$0 < \gamma < \frac{2}{L}. \quad (40.28)$$

具体地:

- 若 $0 < \gamma < \frac{1}{L}$, 迭代不换号地收敛;
- 若 $\frac{1}{L} < \gamma < \frac{2}{L}$, 迭代交替换号但幅度收缩;
- 若 $\gamma = \frac{2}{L}$, 则 $x^{k+1} = -x^k$, 永久振荡;
- 若 $\gamma > \frac{2}{L}$, 则 $|1 - \gamma L| > 1$, 迭代发散。

答题方法

看到“分析梯度下降收敛率”时, 标准顺序是:

1. 写更新: $\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \nabla f(\mathbf{x}^k)$;
2. 用 L -smoothness 写 descent lemma;
3. 代入更新, 得到 $f_{k+1} \leq f_k - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\nabla f_k\|^2$;

4. 根据题目类别追加：

- 非凸：直接求和，控制最小梯度范数；
- 凸：使用 $f_k - f^* \leq \langle \nabla f_k, \mathbf{x}^k - \mathbf{x}^* \rangle$ ；
- 强凸：使用 $\|\nabla f_k\|^2 \geq 2\mu(f_k - f^*)$ 或 smooth-strong interpolation；

5. 明确写出步长、误差指标和复杂度。



第四十一章 投影梯度与约束光滑优化

41.1 问题设定与算法

考虑约束问题

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}), \quad (41.1)$$

其中:

- $\mathcal{X} \subseteq \mathbb{R}^d$ 非空、闭、凸;
- f 在包含 $\mathcal{X}$ 的开集上可微;
- 需要收敛率时, 进一步假设 f 凸且 L -smooth。

投影梯度下降 (projected gradient descent, PGD) 为

$$\mathbf{x}^{k+1} = P_{\mathcal{X}}(\mathbf{x}^k - \gamma \nabla f(\mathbf{x}^k)). \quad (41.2)$$

单次迭代包括:

1. 计算 full gradient;
2. 执行无约束梯度步;
3. 将结果投影回可行集。

41.2 投影梯度映射

定义

$$\mathcal{G}_{\gamma}^{\mathcal{X}}(\mathbf{x}) := \frac{1}{\gamma} [\mathbf{x} - P_{\mathcal{X}}(\mathbf{x} - \gamma \nabla f(\mathbf{x}))]. \quad (41.3)$$

于是

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \mathcal{G}_{\gamma}^{\mathcal{X}}(\mathbf{x}^k). \quad (41.4)$$


若 $\mathcal{X} = \mathbb{R}^d$, 则投影为恒等映射, 并且 $\mathcal{G}_{\gamma}^{\mathbb{R}^d}(\mathbf{x}) = \nabla f(\mathbf{x})$ 。

在约束问题中, 真正的一阶驻点度量应是 $\|\mathcal{G}_{\gamma}^{\mathcal{X}}(\mathbf{x})\|$, 而不一定是 $\|\nabla f(\mathbf{x})\|$ 。

例如, 约束最优点位于边界时, $\nabla f(\mathbf{x}^*)$ 通常不为零。

41.3 最优性与 Fixed Point

定理 41.1 (约束最优性的投影 fixed-point 表述). 设 f 凸且可微, $\mathcal{X}$ 闭凸。则对任意 $\gamma > 0$, 以下命题等价:



1. $\mathbf{x}^* \in \arg \min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x})$;
2. $\langle \nabla f(\mathbf{x}^*), \mathbf{z} - \mathbf{x}^* \rangle \geq 0, \quad \forall \mathbf{z} \in \mathcal{X}$;
3. $\boxed{\mathbf{x}^* = P_{\mathcal{X}}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*))}$;
4. $\mathcal{G}_{\gamma}^{\mathcal{X}}(\mathbf{x}^*) = \mathbf{0}$.

证明. 凸约束问题的一阶最优性条件为 $\langle \nabla f(\mathbf{x}^*), \mathbf{z} - \mathbf{x}^* \rangle \geq 0, \quad \forall \mathbf{z} \in \mathcal{X}$.

另一方面, 由投影变分不等式, $\mathbf{x}^* = P_{\mathcal{X}}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*))$ 当且仅当

$$\langle -\gamma \nabla f(\mathbf{x}^*), \mathbf{z} - \mathbf{x}^* \rangle \leq 0, \quad \forall \mathbf{z} \in \mathcal{X}, \quad (41.5)$$

这与上述一阶条件等价。 □

41.4 投影梯度的核心三点不等式

令

$$\mathbf{x}^+ = P_{\mathcal{X}}(\mathbf{x} - \gamma \nabla f(\mathbf{x})), \quad (41.6)$$

$$\mathbf{G} = \mathcal{G}_{\gamma}^{\mathcal{X}}(\mathbf{x}) = \frac{\mathbf{x} - \mathbf{x}^+}{\gamma}. \quad (41.7)$$

定理 41.2 (投影梯度三点不等式). 若 f 凸且 L -smooth, 则对任意 $\mathbf{z} \in \mathcal{X}$ 有

$$f(\mathbf{x}^+) - f(\mathbf{z}) \leq \langle \mathbf{G}, \mathbf{x} - \mathbf{z} \rangle - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\mathbf{G}\|^2. \quad (41.8)$$

若 $0 < \gamma \leq \frac{1}{L}$, 则

$$\boxed{f(\mathbf{x}^+) - f(\mathbf{z}) \leq \frac{1}{2\gamma} (\|\mathbf{x} - \mathbf{z}\|^2 - \|\mathbf{x}^+ - \mathbf{z}\|^2)}. \quad (41.9)$$

证明. 投影最优性给出

$$\langle \mathbf{G} - \nabla f(\mathbf{x}), \mathbf{z} - \mathbf{x}^+ \rangle \leq 0. \quad (41.10)$$

等价地,

$$\langle \nabla f(\mathbf{x}), \mathbf{x}^+ - \mathbf{z} \rangle \leq \langle \mathbf{G}, \mathbf{x}^+ - \mathbf{z} \rangle. \quad (41.11)$$

由 smoothness:

$$f(\mathbf{x}^+) \leq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{x}^+ - \mathbf{x} \rangle + \frac{L}{2} \|\mathbf{x}^+ - \mathbf{x}\|^2. \quad (41.12)$$

由凸性: $f(\mathbf{x}) - f(\mathbf{z}) \leq \langle \nabla f(\mathbf{x}), \mathbf{x} - \mathbf{z} \rangle$. 相加得到

$$\begin{aligned} f(\mathbf{x}^+) - f(\mathbf{z}) &\leq \langle \nabla f(\mathbf{x}), \mathbf{x}^+ - \mathbf{z} \rangle + \frac{L\gamma^2}{2} \|\mathbf{G}\|^2 \\ &\leq \langle \mathbf{G}, \mathbf{x}^+ - \mathbf{z} \rangle + \frac{L\gamma^2}{2} \|\mathbf{G}\|^2 \\ &= \langle \mathbf{G}, \mathbf{x} - \mathbf{z} \rangle - \gamma \|\mathbf{G}\|^2 + \frac{L\gamma^2}{2} \|\mathbf{G}\|^2. \end{aligned} \quad (41.13)$$



若 $\gamma \leq 1/L$, 则 $\gamma(1 - \frac{L\gamma}{2}) \geq \frac{\gamma}{2}$ 。又因为

$$\begin{aligned} & \langle \mathbf{G}, \mathbf{x} - \mathbf{z} \rangle - \frac{\gamma}{2} \|\mathbf{G}\|^2 \\ &= \frac{1}{2\gamma} (\|\mathbf{x} - \mathbf{z}\|^2 - \|\mathbf{x} - \gamma\mathbf{G} - \mathbf{z}\|^2) \\ &= \frac{1}{2\gamma} (\|\mathbf{x} - \mathbf{z}\|^2 - \|\mathbf{x}^+ - \mathbf{z}\|^2). \end{aligned} \quad (41.14)$$

□

41.5 函数值下降和 $O(1/K)$ 收敛率

在式 (41.8) 中取 $\mathbf{z} = \mathbf{x}$, 得到

$$f(\mathbf{x}^+) \leq f(\mathbf{x}) - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\mathcal{G}_\gamma^\mathbf{x}(\mathbf{x})\|^2. \quad (41.15)$$

因此当 $0 < \gamma < \frac{2}{L}$ 时函数值下降。

定理 41.3 (投影梯度的凸收敛率). 设 f 凸且 L -smooth, $\mathcal{X}$ 非空闭凸, 最优点 $\mathbf{x}^*$ 存在。采用 $0 < \gamma \leq \frac{1}{L}$ 。则

$$\boxed{f(\mathbf{x}^K) - f^* \leq \frac{\|\mathbf{x}^0 - \mathbf{x}^*\|^2}{2\gamma K}.} \quad (41.16)$$

特别地, 当 $\gamma = 1/L$ 时,

$$f(\mathbf{x}^K) - f^* \leq \frac{L\|\mathbf{x}^0 - \mathbf{x}^*\|^2}{2K}. \quad (41.17)$$

证明. 在式 (41.9) 中取 $\mathbf{z} = \mathbf{x}^*$ $f(\mathbf{x}^{k+1}) - f^* \leq \frac{1}{2\gamma} (\|\mathbf{x}^k - \mathbf{x}^*\|^2 - \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2)$ 。求和后使用函数值单调性即可。□

同时, 由左侧非负可知

$$\|\mathbf{x}^{k+1} - \mathbf{x}^*\| \leq \|\mathbf{x}^k - \mathbf{x}^*\|, \quad (41.18)$$

即迭代序列对最优解集合是 Fejér monotone。

41.6 强凸约束问题的距离收缩

若 f 是 L -smooth 且 μ -strongly convex, 则最优点唯一。令 $T_\gamma(\mathbf{x}) = P_{\mathcal{X}}(\mathbf{x} - \gamma\nabla f(\mathbf{x}))$ 。由于投影非扩张, 并且 $\mathbf{x}^* = T_\gamma(\mathbf{x}^*)$, 当 $\gamma = \frac{2}{L+\mu}$ 时,

$$\begin{aligned} \|\mathbf{x}^{k+1} - \mathbf{x}^*\| &= \|T_\gamma(\mathbf{x}^k) - T_\gamma(\mathbf{x}^*)\| \\ &\leq \|\mathbf{x}^k - \mathbf{x}^* - \gamma[\nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^*)]\| \\ &\leq \frac{L - \mu}{L + \mu} \|\mathbf{x}^k - \mathbf{x}^*\|. \end{aligned} \quad (41.19)$$

故

$$\boxed{\|\mathbf{x}^K - \mathbf{x}^*\| \leq \left(\frac{L - \mu}{L + \mu}\right)^K \|\mathbf{x}^0 - \mathbf{x}^*\|.} \quad (41.20)$$



易错点、反例与失败模式

约束最优点一般不满足 $\nabla f(\mathbf{x}^*) = \mathbf{0}$ 。

正确条件是 $-\nabla f(\mathbf{x}^*) \in N_{\mathcal{X}}(\mathbf{x}^*)$, 或 $\mathcal{G}_{\gamma}^{\mathcal{X}}(\mathbf{x}^*) = \mathbf{0}$ 。

若在边界最优问题中仍用 $\|\nabla f(\mathbf{x})\|$ 作为唯一驻点指标, 可能错误地判断算法“尚未收敛”。

41.7 每步计算复杂度

设:

- 一次梯度计算代价为 $C_{\nabla f}$;
- 一次投影代价为 $C_{P_{\mathcal{X}}}$ 。

则单步时间复杂度为

$$O(C_{\nabla f} + C_{P_{\mathcal{X}}} + d). \quad (41.21)$$

投影可能是:

- 闭式计算, 例如 Euclidean ball、box、非负正交锥;
- 排序型算法, 例如概率单纯形投影;
- 另一个非平凡凸优化问题。

因此不能仅比较“迭代次数”, 还必须比较单步投影代价。



第四十二章 次梯度下降、一般步长与迭代平均

42.1 适用情形与算法

考虑

$$\min_{\mathbf{x} \in \mathcal{X}} F(\mathbf{x}), \quad (42.1)$$

其中:

- $\mathcal{X}$ 非空、闭、凸;
- F proper、convex, 但可能不可微;
- 对所有迭代点, 选择 $\mathbf{g}^k \in \partial F(\mathbf{x}^k)$.

投影次梯度法为

$$\mathbf{x}^{k+1} = P_{\mathcal{X}}(\mathbf{x}^k - \eta_k \mathbf{g}^k). \quad (42.2)$$

常见假设是存在 $G > 0$, 使

$$\|\mathbf{g}^k\| \leq G. \quad (42.3)$$

对凸函数, 次梯度一致有界意味着相应区域内的函数是 G -Lipschitz。

易错点、反例与失败模式

次梯度下降不一定是严格意义上的 descent method: $F(\mathbf{x}^{k+1})$ 可能大于 $F(\mathbf{x}^k)$ 。

标准理论常保证的是:


- best iterate;
- 加权平均迭代点;
- 期望函数值;

而不一定保证每一步函数值单调。

42.2 一步距离递推

引理 42.1 (投影次梯度的一步递推). 对任意 $\mathbf{x} \in \mathcal{X}$, 有

$$\|\mathbf{x}^{k+1} - \mathbf{x}\|^2 \leq \|\mathbf{x}^k - \mathbf{x}\|^2 - 2\eta_k \langle \mathbf{g}^k, \mathbf{x}^k - \mathbf{x} \rangle + \eta_k^2 \|\mathbf{g}^k\|^2. \quad (42.4)$$



证明. 由投影非扩张性,

$$\begin{aligned}\|\mathbf{x}^{k+1} - \mathbf{x}\|^2 &= \|P_{\mathcal{X}}(\mathbf{x}^k - \eta_k \mathbf{g}^k) - P_{\mathcal{X}}(\mathbf{x})\|^2 \\ &\leq \|\mathbf{x}^k - \eta_k \mathbf{g}^k - \mathbf{x}\|^2.\end{aligned}\quad (42.5)$$

展开平方即得结论。 $\square$

若 $\mathbf{x} = \mathbf{x}^*$ 是最优点, 由次梯度不等式 $F(\mathbf{x}^k) - F^* \leq \langle \mathbf{g}^k, \mathbf{x}^k - \mathbf{x}^* \rangle$, 得到

$$2\eta_k [F(\mathbf{x}^k) - F^*] \leq \|\mathbf{x}^k - \mathbf{x}^*\|^2 - \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 + \eta_k^2 G^2. \quad (42.6)$$

这是所有次梯度收敛率的基础势函数递推。

42.3 一般步长与加权平均

定义

$$S_K := \sum_{k=0}^{K-1} \eta_k, \quad \bar{\mathbf{x}}^K := \frac{1}{S_K} \sum_{k=0}^{K-1} \eta_k \mathbf{x}^k. \quad (42.7)$$

定理 42.2 (一般步长的次梯度上界). 设 $R_0 := \|\mathbf{x}^0 - \mathbf{x}^*\|$, $\|\mathbf{g}^k\| \leq G$. 则

$$F(\bar{\mathbf{x}}^K) - F^* \leq \frac{R_0^2 + G^2 \sum_{k=0}^{K-1} \eta_k^2}{2 \sum_{k=0}^{K-1} \eta_k}. \quad (42.8)$$

证明. 对式 (42.6) 求和:

$$\begin{aligned}2 \sum_{k=0}^{K-1} \eta_k [F(\mathbf{x}^k) - F^*] &\leq R_0^2 - \|\mathbf{x}^K - \mathbf{x}^*\|^2 + G^2 \sum_{k=0}^{K-1} \eta_k^2 \\ &\leq R_0^2 + G^2 \sum_{k=0}^{K-1} \eta_k^2.\end{aligned}\quad (42.9)$$

由凸性和 Jensen 不等式: $F(\bar{\mathbf{x}}^K) \leq \frac{1}{S_K} \sum_{k=0}^{K-1} \eta_k F(\mathbf{x}^k)$. 整理即得。 $\square$

42.4 一般凸非光滑目标的 $O(1/\sqrt{K})$ 率

若预先知道总迭代数 K , 选择常数步长

$$\eta = \frac{R_0}{G\sqrt{K}}. \quad (42.10)$$

则

$$\begin{aligned}F(\bar{\mathbf{x}}^K) - F^* &\leq \frac{R_0^2 + K\eta^2 G^2}{2K\eta} \\ &= \frac{R_0 G}{\sqrt{K}}.\end{aligned}\quad (42.11)$$

因此

$$F(\bar{\mathbf{x}}^K) - F^* \leq \frac{R_0 G}{\sqrt{K}}. \quad (42.12)$$

达到 $F(\bar{\mathbf{x}}^K) - F^* \leq \varepsilon$ 需要

$$K \geq \frac{R_0^2 G^2}{\varepsilon^2}, \quad (42.13)$$

即 $O(\frac{1}{\varepsilon^2})$ 次次梯度 oracle 调用。



42.4.1 不知道总迭代数时

若选择 $\eta_k = \frac{R_0}{G\sqrt{k+1}}$, 则 $\sum_{k=0}^{K-1} \eta_k = \Theta(\sqrt{K})$, $\sum_{k=0}^{K-1} \eta_k^2 = \Theta(\log K)$, 故直接使用一般上界可得 $F(\bar{\mathbf{x}}^K) - F^* = O\left(\frac{R_0 G \log K}{\sqrt{K}}\right)$ 。可用 doubling trick 消除额外对数因子。

42.5 强凸非光滑目标的加权 $O(1/K)$ 率

定理 42.3 (强凸次梯度法的加权平均). 设:

1. F 是 μ -strongly convex;
2. $\|\mathbf{g}^t\| \leq G$;
3. 使用步长

$$\eta_t = \frac{2}{\mu(t+1)}, \quad t = 1, \dots, K; \quad (42.14)$$

4. 定义加权平均

$$\tilde{\mathbf{x}}^K := \sum_{t=1}^K \frac{2t}{K(K+1)} \mathbf{x}^t. \quad (42.15)$$

则

$$\boxed{F(\tilde{\mathbf{x}}^K) - F^* \leq \frac{2G^2}{\mu(K+1)}}. \quad (42.16)$$

证明. 强凸次梯度不等式给出

$$F(\mathbf{x}^t) - F^* \leq \langle \mathbf{g}^t, \mathbf{x}^t - \mathbf{x}^* \rangle - \frac{\mu}{2} \|\mathbf{x}^t - \mathbf{x}^*\|^2. \quad (42.17)$$

由一步距离递推,

$$2\eta_t \langle \mathbf{g}^t, \mathbf{x}^t - \mathbf{x}^* \rangle \leq \|\mathbf{x}^t - \mathbf{x}^*\|^2 - \|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2 + \eta_t^2 G^2. \quad (42.18)$$

代入式 (42.17):

$$\begin{aligned} F(\mathbf{x}^t) - F^* &\leq \left(\frac{1}{2\eta_t} - \frac{\mu}{2} \right) \|\mathbf{x}^t - \mathbf{x}^*\|^2 \\ &\quad - \frac{1}{2\eta_t} \|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2 + \frac{\eta_t G^2}{2}. \end{aligned} \quad (42.19)$$

代入 $\eta_t = \frac{2}{\mu(t+1)}$ 得到


$$\begin{aligned} F(\mathbf{x}^t) - F^* &\leq \frac{\mu}{4} [(t-1)\|\mathbf{x}^t - \mathbf{x}^*\|^2 - (t+1)\|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2] \\ &\quad + \frac{G^2}{\mu(t+1)}. \end{aligned} \quad (42.20)$$

两侧乘以 t , 并用 $\frac{t}{t+1} \leq 1$

$$t [F(\mathbf{x}^t) - F^*] \leq \frac{\mu}{4} [t(t-1)\|\mathbf{x}^t - \mathbf{x}^*\|^2 - t(t+1)\|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2] + \frac{G^2}{\mu}. \quad (42.21)$$

对 $t = 1, \dots, K$ 求和, 距离项完全 telescope:

$$\sum_{t=1}^K t [F(\mathbf{x}^t) - F^*] \leq \frac{KG^2}{\mu}. \quad (42.22)$$



由凸性：

$$\begin{aligned} F(\tilde{\mathbf{x}}^K) - F^* &\leq \sum_{t=1}^K \frac{2t}{K(K+1)} [F(\mathbf{x}^t) - F^*] \\ &\leq \frac{2}{K(K+1)} \frac{KG^2}{\mu} = \frac{2G^2}{\mu(K+1)}. \end{aligned} \quad (42.23)$$

□

因此强凸但非光滑时的复杂度为 $O\left(\frac{G^2}{\mu\varepsilon}\right)$ ，仍是次线性收敛，而不是光滑强凸情形的 $O\left(\kappa \log \frac{1}{\varepsilon}\right)$ 。

42.6 跨方向真题：随机投影次梯度的一步递推

重要性等级：S

[25F-A-Q12, 7 分] 位于机器学习理论方向 A，但核心工具属于优化方法：投影非扩张性、条件期望和随机次梯度无偏性。

这类题必须标记为跨方向题，不能误记为 C 方向真题。

设 $\hat{\mathbf{g}}_t$ 是随机次梯度估计，满足

$$\mathbb{E}_t[\hat{\mathbf{g}}_t] = \mathbf{g}_t \in \partial F(\mathbf{w}_t), \quad (42.24)$$

$$\mathbb{E}_t\|\hat{\mathbf{g}}_t\|^2 \leq G^2, \quad (42.25)$$

其中 $\mathbb{E}_t[\cdot] = \mathbb{E}[\cdot | \mathbf{w}_t]$ 。更新为

$$\mathbf{w}_{t+1} = P_{\mathcal{W}}(\mathbf{w}_t - \eta_t \hat{\mathbf{g}}_t). \quad (42.26)$$

对任意 $\mathbf{w} \in \mathcal{W}$,

$$\begin{aligned} \mathbb{E}_t\|\mathbf{w}_{t+1} - \mathbf{w}\|^2 &\leq \mathbb{E}_t\|\mathbf{w}_t - \eta_t \hat{\mathbf{g}}_t - \mathbf{w}\|^2 \\ &= \|\mathbf{w}_t - \mathbf{w}\|^2 - 2\eta_t \langle \mathbb{E}_t[\hat{\mathbf{g}}_t], \mathbf{w}_t - \mathbf{w} \rangle + \eta_t^2 \mathbb{E}_t\|\hat{\mathbf{g}}_t\|^2 \\ &\leq \|\mathbf{w}_t - \mathbf{w}\|^2 - 2\eta_t \langle \mathbf{g}_t, \mathbf{w}_t - \mathbf{w} \rangle + \eta_t^2 G^2. \end{aligned} \quad (42.27)$$

再对全部历史取期望，可得题目要求的无条件期望形式。

答题方法

[25F-A-Q12, 7 分] 的满分步骤：

1. 写出 $\mathbf{w} = P_{\mathcal{W}}(\mathbf{w})$ ，因为比较点 $\mathbf{w} \in \mathcal{W}$ ；
2. 使用投影非扩张性；
3. 完整展开平方；
4. 明确条件期望所条件化的信息；
5. 使用 $\mathbb{E}_t[\hat{\mathbf{g}}_t] = \mathbf{g}_t$ ；
6. 使用 $\mathbb{E}_t\|\hat{\mathbf{g}}_t\|^2 \leq G^2$ ；
7. 最后再使用 tower property 转成无条件期望。

易错点：题面若写的是随机估计 $\hat{\mathbf{g}}_t$ ，平方项中不能直接替换成 $\|\mathbf{g}_t\|^2$ ；只能使用其二阶矩上界。

反例 42.4 (常数步长导致振荡). 令 $F(x) = |x|$, $\mathcal{X} = \mathbb{R}$. 取次梯度 $g(x) = \begin{cases} 1, & x > 0, \\ -1, & x < 0. \end{cases}$ 若常数步长为 $\eta > 0$, 且 $0 < x^0 < \eta$, 则 $x^1 = x^0 - \eta < 0$, 下一步又向正方向移动, 迭代可在零点两侧振荡。

因此:

- 常数步长通常只收敛到邻域;
- 要精确收敛, 通常需递减步长或平均;
- 不可用“每步函数值下降”分析一般次梯度法。



第四十三章 近端梯度、复合势函数与 ISTA

43.1 复合优化问题

考虑

$$\min_{\mathbf{x} \in \mathbb{R}^d} F(\mathbf{x}) := f(\mathbf{x}) + R(\mathbf{x}), \quad (43.1)$$

其中:

- $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微且 L -smooth;
- 在凸收敛理论中进一步假设 f 凸;
- $R: \mathbb{R}^d \rightarrow (-\infty, +\infty]$ proper、closed、convex;
- $\text{prox}_{\gamma R}$ 可有效计算;
- 最优值有限且至少存在一个最优点。

近端梯度下降 (proximal gradient descent) 为

$$\mathbf{x}^{k+1} = \text{prox}_{\gamma R}(\mathbf{x}^k - \gamma \nabla f(\mathbf{x}^k)). \quad (43.2)$$

它将:

- 光滑项 f 做显式梯度步;
- 非光滑项 R 做隐式 prox 步。

43.2 局部二次上界解释

定义

$$Q_\gamma(\mathbf{z}; \mathbf{x}) := f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{z} - \mathbf{x} \rangle + \frac{1}{2\gamma} \|\mathbf{z} - \mathbf{x}\|^2 + R(\mathbf{z}). \quad (43.3)$$

近端梯度更新等价于

$$\mathbf{x}^+ = \arg \min_{\mathbf{z}} Q_\gamma(\mathbf{z}; \mathbf{x}). \quad (43.4)$$

若 $0 < \gamma \leq \frac{1}{L}$, 则由 descent lemma:

$$F(\mathbf{z}) \leq Q_\gamma(\mathbf{z}; \mathbf{x}), \quad \forall \mathbf{z}. \quad (43.5)$$

因此近端梯度是 majorization-minimization: 每一步最小化当前点构造的全局二次上界。



43.3 复合梯度映射

定义

$$\mathcal{G}_\gamma(\mathbf{x}) := \frac{1}{\gamma} [\mathbf{x} - \text{prox}_{\gamma R}(\mathbf{x} - \gamma \nabla f(\mathbf{x}))]. \quad (43.6)$$

于是 $\mathbf{x}^+ = \mathbf{x} - \gamma \mathcal{G}_\gamma(\mathbf{x})$ 。

由 prox 最优性条件，

$$\mathcal{G}_\gamma(\mathbf{x}) - \nabla f(\mathbf{x}) \in \partial R(\mathbf{x}^+). \quad (43.7)$$

若 $\mathcal{G}_\gamma(\mathbf{x}) = \mathbf{0}$ ，则 $-\nabla f(\mathbf{x}) \in \partial R(\mathbf{x})$ ，即 $\mathbf{0} \in \nabla f(\mathbf{x}) + \partial R(\mathbf{x})$ 。

当 f 凸时，这等价于 $\mathbf{x}$ 是全局最优点；当 f 非凸时，它表示复合一阶驻点。

43.4 近端梯度的核心三点不等式

定理 43.1 (近端梯度基本不等式). 设 f 凸且 L -smooth, R proper, closed, convex. 令 $\mathbf{x}^+ = \text{prox}_{\gamma R}(\mathbf{x} - \gamma \nabla f(\mathbf{x}))$, $\mathcal{G}_\gamma(\mathbf{x})$ 。则对任意 $\mathbf{z} \in \text{dom } R$ 有

$$F(\mathbf{x}^+) - F(\mathbf{z}) \leq \langle \mathbf{G}, \mathbf{x} - \mathbf{z} \rangle - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\mathbf{G}\|^2. \quad (43.8)$$

若 $0 < \gamma \leq \frac{1}{L}$ ，则

$$F(\mathbf{x}^+) - F(\mathbf{z}) \leq \frac{1}{2\gamma} [\|\mathbf{x} - \mathbf{z}\|^2 - \|\mathbf{x}^+ - \mathbf{z}\|^2]. \quad (43.9)$$

证明. 由式 (43.7)，存在 $\mathbf{r}^+ = \mathbf{G} - \nabla f(\mathbf{x}) \in \partial R(\mathbf{x}^+)$ 。次梯度不等式给出

$$R(\mathbf{x}^+) - R(\mathbf{z}) \leq \langle \mathbf{r}^+, \mathbf{x}^+ - \mathbf{z} \rangle. \quad (43.10)$$

由 smoothness:

$$f(\mathbf{x}^+) \leq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{x}^+ - \mathbf{x} \rangle + \frac{L}{2} \|\mathbf{x}^+ - \mathbf{x}\|^2. \quad (43.11)$$

由凸性:

$$f(\mathbf{x}) - f(\mathbf{z}) \leq \langle \nabla f(\mathbf{x}), \mathbf{x} - \mathbf{z} \rangle. \quad (43.12)$$

将三式相加:

$$\begin{aligned} F(\mathbf{x}^+) - F(\mathbf{z}) &\leq \langle \nabla f(\mathbf{x}), \mathbf{x}^+ - \mathbf{z} \rangle + \frac{L\gamma^2}{2} \|\mathbf{G}\|^2 \\ &\quad + \langle \mathbf{G} - \nabla f(\mathbf{x}), \mathbf{x}^+ - \mathbf{z} \rangle \\ &= \langle \mathbf{G}, \mathbf{x}^+ - \mathbf{z} \rangle + \frac{L\gamma^2}{2} \|\mathbf{G}\|^2 \\ &= \langle \mathbf{G}, \mathbf{x} - \mathbf{z} \rangle - \gamma \|\mathbf{G}\|^2 + \frac{L\gamma^2}{2} \|\mathbf{G}\|^2. \end{aligned} \quad (43.13)$$

当 $\gamma \leq 1/L$ 时， $\gamma(1 - \frac{L\gamma}{2}) \geq \frac{\gamma}{2}$ 。再使用平方差恒等式即得式 (43.9)。□



43.5 函数值下降与梯度映射复杂度

在式 (43.8) 中取 $\mathbf{z} = \mathbf{x}$ 不需要使用 f 的凸性, 即可得到

$$F(\mathbf{x}^+) \leq F(\mathbf{x}) - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\mathcal{G}_\gamma(\mathbf{x})\|^2. \quad (43.14)$$

因此只要 $0 < \gamma < \frac{2}{L}$, 复合目标函数值下降。

若 F 有有限下界 $F_{\inf}$, 则

$$\min_{0 \leq k < K} \|\mathcal{G}_\gamma(\mathbf{x}^k)\|^2 \leq \frac{F(\mathbf{x}^0) - F_{\inf}}{K\gamma(1 - L\gamma/2)}. \quad (43.15)$$

该结论可用于:

- f 光滑但非凸;
- R 凸且可 prox;
- 以复合梯度映射衡量一阶驻点。

43.6 凸复合目标的 $O(1/K)$ 收敛率

定理 43.2 (近端梯度的凸函数值收敛率). 设 f 凸且 L -smooth, R proper、closed、convex, 最优点 $\mathbf{x}^*$ 存在。若 $0 < \gamma \leq \frac{1}{L}$, 则

$$F(\mathbf{x}^K) - F^* \leq \frac{\|\mathbf{x}^0 - \mathbf{x}^*\|^2}{2\gamma K}. \quad (43.16)$$

证明. 在式 (43.9) 中取 $\mathbf{z} = \mathbf{x}^*$

$$F(\mathbf{x}^{k+1}) - F^* \leq \frac{1}{2\gamma} [\|\mathbf{x}^k - \mathbf{x}^*\|^2 - \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2]. \quad (43.17)$$

求和后使用函数值单调性: $K [F(\mathbf{x}^K) - F^*] \leq \frac{1}{2\gamma} \|\mathbf{x}^0 - \mathbf{x}^*\|^2$. $\square$

同时,

$$\|\mathbf{x}^{k+1} - \mathbf{x}^*\| \leq \|\mathbf{x}^k - \mathbf{x}^*\|, \quad (43.18)$$

但若最优解不唯一, 仅凭该式不能立即断言 $\mathbf{x}^k$ 收敛到哪一个具体最优点; 需结合有限维性、渐近正则性和聚点最优性等进一步论证。

43.7 强凸复合目标的函数值线性收敛

定理 43.3 (近端梯度的强凸线性率). 设:

- f 是 L -smooth 且 μ -strongly convex;
- R proper、closed、convex;
- $0 < \gamma \leq \frac{1}{L}$.



则

$$F(\mathbf{x}^{k+1}) - F^* \leq (1 - \gamma\mu) [F(\mathbf{x}^k) - F^*]. \quad (43.19)$$

因此

$$F(\mathbf{x}^K) - F^* \leq (1 - \gamma\mu)^K [F(\mathbf{x}^0) - F^*]. \quad (43.20)$$

证明. 近端梯度点 $\mathbf{x}^+$ 最小化 $Q_\gamma(\mathbf{z}; \mathbf{x})$ 。因此对任意 $\mathbf{y}$, $F(\mathbf{x}^+) \leq Q_\gamma(\mathbf{x}^+; \mathbf{x}) \leq Q_\gamma(\mathbf{y}; \mathbf{x})$ 。

令

$$\alpha = \gamma\mu \in (0, 1], \quad \mathbf{y} = (1 - \alpha)\mathbf{x} + \alpha\mathbf{x}^*. \quad (43.21)$$

由 f 的强凸一阶不等式, $\langle \nabla f(\mathbf{x}), \mathbf{x}^* - \mathbf{x} \rangle \leq f(\mathbf{x}^*) - f(\mathbf{x}) - \frac{\mu}{2} \|\mathbf{x}^* - \mathbf{x}\|^2$ 。由 R 的凸性, $R(\mathbf{y}) \leq (1 - \alpha)R(\mathbf{x}) + \alpha R(\mathbf{x}^*)$ 。于是

$$\begin{aligned} Q_\gamma(\mathbf{y}; \mathbf{x}) &\leq (1 - \alpha)F(\mathbf{x}) + \alpha F^* \\ &\quad + \frac{1}{2} \left(\frac{\alpha^2}{\gamma} - \alpha\mu \right) \|\mathbf{x} - \mathbf{x}^*\|^2. \end{aligned} \quad (43.22)$$

由于 $\alpha = \gamma\mu$, 最后的二次项恰为零。故 $F(\mathbf{x}^+) \leq (1 - \gamma\mu)F(\mathbf{x}) + \gamma\mu F^*$ 。移项即得。 $\square$

取 $\gamma = \frac{1}{L}$ 得到

$$F(\mathbf{x}^K) - F^* \leq \left(1 - \frac{1}{\kappa}\right)^K [F(\mathbf{x}^0) - F^*], \quad \kappa = \frac{L}{\mu}. \quad (43.23)$$

43.8 强凸复合目标的距离收缩

近端算子非扩张, 且最优点满足 $\mathbf{x}^* = \text{prox}_{\gamma R}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*))$ 。因此当 $\gamma = \frac{2}{L+\mu}$ 时,

$$\begin{aligned} \|\mathbf{x}^{k+1} - \mathbf{x}^*\| &\leq \|\mathbf{x}^k - \mathbf{x}^* - \gamma [\nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^*)]\| \\ &\leq \frac{L - \mu}{L + \mu} \|\mathbf{x}^k - \mathbf{x}^*\|. \end{aligned} \quad (43.24)$$

即

$$\|\mathbf{x}^K - \mathbf{x}^*\| \leq \left(\frac{L - \mu}{L + \mu} \right)^K \|\mathbf{x}^0 - \mathbf{x}^*\|. \quad (43.25)$$

注意: 该距离收缩步长可能大于 $1/L$, 因此证明使用的是 prox 非扩张性+gradient map contraction, 而不是二次 majorization。

43.9 ISTA: ℓ_1 正则最小二乘

考虑 LASSO 型问题


$$\min_{\mathbf{x} \in \mathbb{R}^d} \left\{ F(\mathbf{x}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|^2 + \lambda \|\mathbf{x}\|_1 \right\}, \quad (43.26)$$

其中 $\mathbf{A} \in \mathbb{R}^{m \times d}$, $\mathbf{b} \in \mathbb{R}^m$ 。

光滑项为 $f(\mathbf{x}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|^2$, 其梯度和 smoothness constant 为

$$\nabla f(\mathbf{x}) = \mathbf{A}^\top (\mathbf{Ax} - \mathbf{b}), \quad (43.27)$$

$$L = \|\mathbf{A}^\top \mathbf{A}\|_{\text{op}} = \|\mathbf{A}\|_{\text{op}}^2. \quad (43.28)$$



非光滑项为 $R(\mathbf{x}) = \lambda \|\mathbf{x}\|_1$ 。近端算子是 soft thresholding: $\text{prox}_{\gamma R}(\mathbf{u}) = S_{\gamma\lambda}(\mathbf{u})$ 。

因此 ISTA 更新为

$$\mathbf{x}^{k+1} = S_{\gamma\lambda} [\mathbf{x}^k - \gamma \mathbf{A}^\top (\mathbf{A} \mathbf{x}^k - \mathbf{b})]. \quad (43.29)$$

逐坐标写为

$$x_i^{k+1} = \text{sign}(u_i^k) \max\{|u_i^k| - \gamma\lambda, 0\}, \quad (43.30)$$

其中 $\mathbf{u}^k = \mathbf{x}^k - \gamma \mathbf{A}^\top (\mathbf{A} \mathbf{x}^k - \mathbf{b})$ 。

若 $\mathbf{A}$ 为稠密矩阵:

- 计算 $\mathbf{A} \mathbf{x}^k$: $O(md)$;
- 计算 $\mathbf{A}^\top (\mathbf{A} \mathbf{x}^k - \mathbf{b})$: $O(md)$;
- soft thresholding: $O(d)$;
- 总单步时间: $O(md)$;
- 存储稠密 $\mathbf{A}$: $O(md)$ 。

若 $\mathbf{A}$ 稀疏, 则主导复杂度可写为 $O(\text{nnz}(\mathbf{A}))$ 。

43.10 未知 L 时的回溯步长

说明 43.4 (根据二次上界所作的算法补充). 当 L 未知时, 可维护局部估计 L_k , 令 $\gamma_k = \frac{1}{L_k}$, 计算 $\mathbf{x}^{k+1} = \text{prox}_{R/L_k} \left(\mathbf{x}^k - \frac{1}{L_k} \nabla f(\mathbf{x}^k) \right)$ 。检查

$$\begin{aligned} f(\mathbf{x}^{k+1}) &\leq f(\mathbf{x}^k) + \langle \nabla f(\mathbf{x}^k), \mathbf{x}^{k+1} - \mathbf{x}^k \rangle \\ &\quad + \frac{L_k}{2} \|\mathbf{x}^{k+1} - \mathbf{x}^k\|^2. \end{aligned} \quad (43.31)$$

若不成立, 则令 $L_k \leftarrow \tau L_k$, $\tau > 1$, 并重新计算。

由于真实梯度是 L -Lipschitz, 当 $L_k \geq L$ 时检查必然通过。

43.11 四种确定性一阶方法的统一关系

表 43.1: 确定性一阶方法统一比较

方法	问题结构	更新	一阶残差
Gradient Descent	$\min_x f(x)$, f 可微	$x^+ = x - \gamma \nabla f(x)$	$\nabla f(x)$
Projected Gradient	$\min_{x \in \mathcal{X}} f(x)$	$x^+ = P_{\mathcal{X}}(x - \gamma \nabla f(x))$	$\mathcal{G}_{\gamma}^{\mathcal{X}}(x)$
Subgradient Descent	$\min_{x \in \mathcal{X}} F(x)$, F 凸非光滑	$x^+ = P_{\mathcal{X}}(x - \eta g)$, $g \in \partial F(x)$	$g \in \partial F(x)$

方法	问题结构	更新	一阶残差
Proximal Gradient	$\min_x f(x) + R(x)$	$x^+ = \text{prox}_{\gamma R}(x - \gamma \nabla f(x))$	$\mathcal{G}_\gamma(x)$

关键统一关系:

$$\text{Projected Gradient} = \text{Proximal Gradient with } R = \delta_{\mathcal{X}}, \quad (43.32)$$

$$\text{Gradient Descent} = \text{Proximal Gradient with } R \equiv 0. \quad (43.33)$$

43.12 确定性收敛率总表

表 43.2: 确定性一阶算法收敛率与 oracle complexity


算法与假设	收敛指标	典型上界	达到误差 ε 的迭代数
GD: L -smooth, 非凸	$\min_{k < K} \ \nabla f(x^k)\ ^2$	$\frac{2L\Delta_0}{K}$	平方梯度误差: $O\left(\frac{L\Delta_0}{\varepsilon}\right)$
GD: 凸、 L -smooth	$f(x^K) - f^*$	$\frac{LR_0^2}{2K}$	$O\left(\frac{LR_0^2}{\varepsilon}\right)$
GD: μ -强凸、 L -smooth	$f(x^K) - f^*$	$e^{-K/\kappa} \Delta_0$	$O\left(\kappa \log \frac{\Delta_0}{\varepsilon}\right)$
Projected GD: 凸、光滑	$f(x^K) - f^*$	$\frac{LR_0^2}{2K}$	$O\left(\frac{LR_0^2}{\varepsilon}\right)$
Subgradient: 凸、 $\ g\ \leq G$	平均点函数值	$\frac{R_0 G}{\sqrt{K}}$	$O\left(\frac{R_0^2 G^2}{\varepsilon^2}\right)$
Subgradient: μ -强凸	加权平均函数值	$\frac{2G^2}{\mu(K+1)}$	$O\left(\frac{G^2}{\mu\varepsilon}\right)$
Proximal GD: 凸、光滑复合	$F(x^K) - F^*$	$\frac{LR_0^2}{2K}$	$O\left(\frac{LR_0^2}{\varepsilon}\right)$
Proximal GD: 强凸复合	$F(x^K) - F^*$	$(1 - \frac{1}{\kappa})^K \Delta_0$	$O\left(\kappa \log \frac{\Delta_0}{\varepsilon}\right)$

其中: $R_0 = \|\mathbf{x}^0 - \mathbf{x}^*\|$, $\Delta_0 = F(\mathbf{x}^0) - F^*$, $\kappa = \frac{L}{\mu}$ 。

43.13 真题映射

表 43.3: 第 12 部分真题映射

题目	主要标签	本部分提供的得分工具
[25S-C-Q3, 6 分]	Proximal SGD 一步递推	prox fixed point; prox 非扩张; 确定性递推骨架; 随机项留至第 13 部分。



题目	主要标签	本部分提供的得分工具
[25S-C-Q5, 5 分]	Smooth-strong convex contraction	$\gamma = \frac{2}{L+\mu}$, $\rho = \frac{4\mu L}{(L+\mu)^2}$ 对应的距离收缩。
[25F-A-Q12, 7 分]	投影随机次梯度, 跨方向	投影非扩张; 平方展开; 无偏性; 条件期望; 二阶矩上界。
[25F-C-Q1-Q2, 5 分]	基本定义与唯一性	强凸目标的存在唯一性; 是本部分线性收敛的前提。
[26S-C-Q3, 3 分]	Proximal fixed point	$0 \in \nabla f(x^*) + \partial R(x^*) \iff x^* = \text{prox}_{\gamma R}(x^* - \gamma \nabla f(x^*))$ 。
[26S-C-Q6, 3 分]	Proximal SGD 一步距离不等式	prox 非扩张性; 本部分 deterministic proximal map 骨架。
[26S-C-Q10(a), 3 分]	Smoothness 一步势函数	descent lemma; 梯度范数与函数值 gap; 距离平方展开。

43.14 答题方法

答题方法

模板一：证明凸光滑 GD 的 $O(1/K)$ 。

1. 写 $x^{k+1} = x^k - \frac{1}{L} \nabla f(x^k)$;
2. 用 smoothness 得 $f(x^{k+1}) \leq f(x^k) - \frac{1}{2L} \|\nabla f(x^k)\|^2$;
3. 用凸性得 $f(x^k) - f^* \leq \langle \nabla f(x^k), x^k - x^* \rangle$;
4. 合并为 $f(x^{k+1}) - f^* \leq \frac{L}{2} (\|x^k - x^*\|^2 - \|x^{k+1} - x^*\|^2)$;
5. 求和并用函数值单调性得到最后迭代点上界。

答题方法

模板二：证明 projected/subgradient 一步递推。

1. 写 $x^{k+1} = P_{\mathcal{X}}(x^k - \eta_k g^k)$;
2. 因比较点 $x \in \mathcal{X}$, 写 $x = P_{\mathcal{X}}(x)$;
3. 使用投影非扩张性: $\|x^{k+1} - x\|^2 \leq \|x^k - \eta_k g^k - x\|^2$;
4. 展开平方;
5. 若要函数值, 使用 $F(x^k) - F(x) \leq \langle g^k, x^k - x \rangle$;
6. 若是随机估计, 再取条件期望并使用无偏性。

答题方法

模板三：证明 proximal gradient 的 $O(1/K)$ 。

1. 定义 $G_\gamma(x) = \gamma^{-1} [x - \text{prox}_{\gamma R}(x - \gamma \nabla f(x))]$;
2. 由 prox 最优性写 $G_\gamma(x) - \nabla f(x) \in \partial R(x^+)$;
3. 分别写: $R(x^+) - R(z) \leq \langle G_\gamma(x) - \nabla f(x), x^+ - z \rangle$, $f(x^+) \leq f(x) + \langle \nabla f(x), x^+ - x \rangle + \frac{L}{2} \|x^+ - x\|^2$, $f(x) - f(z) \leq \langle \nabla f(x), x - z \rangle$;
4. 三式相加并化为 $F(x^+) - F(z) \leq \frac{1}{2\gamma} (\|x - z\|^2 - \|x^+ - z\|^2)$;
5. 取 $z = x^*$, 求和 telescope;
6. 使用函数值单调性转成最后迭代点上界。

43.15 综合易错点

易错点、反例与失败模式

1. 非凸、凸和强凸的收敛结论不能混写。
非凸光滑: $\min_k \|\nabla f(x^k)\|^2 = O(1/K)$.
凸光滑: $f(x^K) - f^* = O(1/K)$.
强凸光滑: $f(x^K) - f^* = O(e^{-K/\kappa})$.
2. 函数值线性收敛与迭代点线性收敛应分开表述。
必须写明使用: $f(x^k) - f^*$ 还是 $\|x^k - x^*\|$.
3. $O(1/K)$ 与线性收敛含义不同。
线性收敛指 $e_{k+1} \leq qe_k$, $q \in (0, 1)$, 因而误差按几何级数下降。
4. 投影梯度的驻点不是 $\nabla f = 0$ 。
正确残差是 $\mathcal{G}_\gamma(x)$.
5. 次梯度法一般不保证最后迭代点函数值最优。
一般凸非光滑理论优先使用: $\bar{x}^K = \frac{\sum \eta_k x^k}{\sum \eta_k}$.
6. 强凸非光滑并不自动得到线性收敛。
若没有 smoothness, 典型最优一阶 oracle rate 仍是 $O(1/K)$.
7. 有界次梯度假设不能省。
在一步递推中存在 $\eta_k^2 \|g^k\|^2$. 若该项无法控制, 标准复杂度不能成立。
8. Proximal gradient 不是对整个 F 取普通梯度。
若 $R = \lambda \|x\|_1$, ∇R 在零坐标处不存在, 应使用 prox.
9. Proximal gradient 的主步长条件依赖 f 的 smoothness。
 R 可以不可微; L 是 ∇f 的 Lipschitz constant.

10. 梯度映射的次梯度位于新点。

正确关系是 $G_\gamma(x) - \nabla f(x) \in \partial R(x^+)$, 不是一般地属于 $\partial R(x)$.

11. Projection 与 prox 的计算代价不能忽略。

具有相同 oracle iteration complexity 的两个方法, 其实际时间复杂度可能因投影或 prox 子问题不同而差异很大。

12. 步长 $2/(L + \mu)$ 和 $1/L$ 对应不同证明。

$\gamma = \frac{1}{L}$ 适合 majorization 和函数值证明;

$\gamma = \frac{2}{L+\mu}$ 适合利用 gradient map contraction 得到最优固定步长距离收缩。

43.16 快速自测

快速自测

1. 梯度下降为什么可解释为正则化线性模型的最小化?
2. 对 L -smooth 函数, 什么步长范围保证 $f(x^{k+1}) < f(x^k)$ 除非梯度为零?
3. 非凸 GD 的 $O(1/K)$ 控制的是梯度范数还是函数值误差?
4. 若要求 $\|\nabla f\| \leq \varepsilon$, 为什么复杂度是 $O(1/\varepsilon^2)$ 而不是 $O(1/\varepsilon)$?
5. 凸光滑 GD 的势函数是什么?
6. 强凸性如何将梯度范数转换为函数值 gap?
7. 条件数 $\kappa = L/\mu$ 如何进入线性收敛率?
8. 一维二次函数上, 为什么 $\gamma = 2/L$ 会导致振荡?
9. 约束最优点为什么不必满足 $\nabla f(x^*) = 0$?
10. 写出投影梯度映射。
11. 如何证明 $x^* = P_{\mathcal{X}}(x^* - \gamma \nabla f(x^*))$ 等价于约束一阶最优性?
12. 投影梯度三点不等式中的三个点分别是什么?
13. 为什么投影梯度单步代价不能只写一次梯度计算?
14. 次梯度法的一步距离递推如何得到?
15. 一般步长次梯度上界中的分子和分母分别是什么?
16. 为什么一般凸次梯度法要使用迭代平均?
17. 强凸非光滑情形为何使用与 t 成正比的平均权重?
18. [25F-A-Q12, 7 分] 中随机性来自哪里?
19. 条件期望中为什么交叉项可以把 $\hat{g}_t$ 替换为 g_t ?
20. 写出近端梯度更新的 quadratic model。

21. 什么条件保证该 quadratic model majorize 原目标?
22. 写出复合梯度映射和对应的次微分关系。
23. 为什么 $\mathcal{G}_\gamma(x) = 0$ 是复合最优性的正确 fixed-point 条件?
24. 如何从 prox 次梯度不等式、smoothness 和 convexity 推导 proximal three-point inequality?
25. 近端梯度的 $O(1/K)$ 证明中, 哪些项 telescope?
26. 强凸复合目标为何有 $F(x^{k+1}) - F^* \leq (1 - \gamma\mu)[F(x^k) - F^*]$?
27. 写出 LASSO 的 ISTA 更新。
28. 若目标写成 $\frac{1}{2m}\|Ax - b\|^2 + \lambda\|x\|_1$, smoothness constant 相比本文约定如何变化?
29. Projection、subgradient 和 prox 三者在何种特殊选择下相互转化?
30. 函数值收敛、迭代点收敛和一阶残差收敛为什么不能互相无条件替代?



第四十四章 随机一阶 Oracle、条件期望与方差分解

44.1 重要性等级与历年实考定位

重要性等级：S

- [25S-C-Q4, 6 分]、[26S-C-Q7, 5 分] 直接要求展开随机 proximal update，并通过条件无偏性消去交叉项。
- [25F-C-Q3, 5 分] 要求证明带 importance weight 的 mini-batch estimator 无偏。
- [25F-C-Q7, 3 分] 要求证明最优点处 mini-batch 方差按 $1/\tau$ 缩放。
- [26S-C-Q9, 3 分] 要求在误差互不相关的简化模型下证明平均迭代点的方差为 $O(1/K)$ 。
- 随机优化证明的固定主线是 建立 filtration $\rightarrow$ 取条件期望 $\rightarrow$ 消去零均值交叉项 $\rightarrow$ 使用方差上界 $\rightarrow$ tower property.

44.2 随机优化问题

随机优化的总体目标通常写为

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}), \quad f(\mathbf{x}) := \mathbb{E}_{\xi \sim \mathcal{D}} [\ell(\mathbf{x}; \xi)], \quad (44.1)$$

其中：

- ξ 是数据样本、随机扰动或随机索引；
- $\mathcal{D}$ 是未知或只能采样的数据分布；
- $\ell(\mathbf{x}; \xi)$ 是单样本损失；
- 若允许交换梯度与期望，则

$$\nabla f(\mathbf{x}) = \mathbb{E}_{\xi} [\nabla_{\mathbf{x}} \ell(\mathbf{x}; \xi)]. \quad (44.2)$$


单样本随机梯度记为

$$\mathbf{g}(\mathbf{x}, \xi) := \nabla_{\mathbf{x}} \ell(\mathbf{x}; \xi). \quad (44.3)$$

标准 SGD 更新为

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma_k \mathbf{g}_k, \quad \mathbf{g}_k := \mathbf{g}(\mathbf{x}^k, \xi^k). \quad (44.4)$$

由于 ξ^k 随机，所有后续迭代点 $\mathbf{x}^{k+1}, \mathbf{x}^{k+2}, \dots$ 均为随机变量。



44.3 Filtration 与条件无偏性

定义迭代开始前的历史信息

$$\mathcal{F}_k := \sigma(\mathbf{x}^0, \xi^0, \dots, \xi^{k-1}). \quad (44.5)$$

由于 $\mathbf{x}^k$ 由过去随机变量决定, $\mathbf{x}^k$ 是 $\mathcal{F}_k$ -可测的; 而当前新样本 ξ^k 尚未包含在 $\mathcal{F}_k$ 中。

记条件期望

$$\mathbb{E}_k[\cdot] := \mathbb{E}[\cdot \mid \mathcal{F}_k]. \quad (44.6)$$

随机一阶 oracle 的标准假设是:

说明 44.1. (条件无偏随机梯度) 对每个 k ,

$$\boxed{\mathbb{E}_k[\mathbf{g}_k] = \nabla f(\mathbf{x}^k).} \quad (44.7)$$

说明 44.2. (有界条件方差) 存在 $\sigma^2 \geq 0$, 使

$$\boxed{\mathbb{E}_k[\|\mathbf{g}_k - \nabla f(\mathbf{x}^k)\|^2] \leq \sigma^2.} \quad (44.8)$$

定义随机噪声

$$\boldsymbol{\xi}^k := \mathbf{g}_k - \nabla f(\mathbf{x}^k). \quad (44.9)$$

则

$$\mathbb{E}_k[\boldsymbol{\xi}^k] = \mathbf{0}, \quad \mathbb{E}_k\|\boldsymbol{\xi}^k\|^2 \leq \sigma^2. \quad (44.10)$$

44.3.1 为什么必须是条件无偏

仅有 $\mathbb{E}[\mathbf{g}_k] = \mathbb{E}[\nabla f(\mathbf{x}^k)]$ 通常不足以完成一步递推。

证明中需要处理

$$\mathbb{E}_k[\langle \mathbf{x}^k - \mathbf{x}^*, \mathbf{g}_k - \nabla f(\mathbf{x}^k) \rangle]. \quad (44.11)$$

因为 $\mathbf{x}^k - \mathbf{x}^*$ 是 $\mathcal{F}_k$ -可测的, 条件无偏性给出

$$\begin{aligned} & \mathbb{E}_k[\langle \mathbf{x}^k - \mathbf{x}^*, \boldsymbol{\xi}^k \rangle] \\ &= \langle \mathbf{x}^k - \mathbf{x}^*, \mathbb{E}_k[\boldsymbol{\xi}^k] \rangle = 0. \end{aligned} \quad (44.12)$$

若噪声与当前迭代点相关, 且不满足条件零均值, 上述交叉项可能不为零, 从而产生系统性偏差。

易错点、反例与失败模式

“每个固定 $\mathbf{x}$ 上无偏”与“沿自适应迭代轨迹条件无偏”必须加以区分。


正确的算法分析条件通常是 $\mathbb{E}[\mathbf{g}(\mathbf{x}^k, \xi^k) \mid \mathcal{F}_k] = \nabla f(\mathbf{x}^k)$ 。

若在一个 epoch 内无放回抽样, 当前剩余索引分布会依赖已抽取索引; 此时相对于完整历史的条件无偏性不一定成立, 不能机械套用独立有放回采样证明。

44.4 向量方差分解

定理 44.3 (条件方差分解). 设随机向量 $\mathbf{Z} \in \mathbb{R}^d$ 二阶可积, $\mathbf{a} \in \mathbb{R}^d$ 是 $\mathcal{F}_k$ -可测向量。则

$$\boxed{\mathbb{E}_k\|\mathbf{Z} - \mathbf{a}\|^2 = \|\mathbb{E}_k[\mathbf{Z}] - \mathbf{a}\|^2 + \mathbb{E}_k\|\mathbf{Z} - \mathbb{E}_k[\mathbf{Z}]\|^2.} \quad (44.13)$$



证明. 写成 $\mathbf{Z} - \mathbf{a} = (\mathbf{Z} - \mathbb{E}_k \mathbf{Z}) + (\mathbb{E}_k \mathbf{Z} - \mathbf{a})$. 展开平方:

$$\begin{aligned} \|\mathbf{Z} - \mathbf{a}\|^2 &= \|\mathbf{Z} - \mathbb{E}_k \mathbf{Z}\|^2 + \|\mathbb{E}_k \mathbf{Z} - \mathbf{a}\|^2 \\ &\quad + 2 \langle \mathbf{Z} - \mathbb{E}_k \mathbf{Z}, \mathbb{E}_k \mathbf{Z} - \mathbf{a} \rangle. \end{aligned} \quad (44.14)$$

条件期望下, 第二个因子是 $\mathcal{F}_k$ -可测的, 故

$$\begin{aligned} &\mathbb{E}_k [\langle \mathbf{Z} - \mathbb{E}_k \mathbf{Z}, \mathbb{E}_k \mathbf{Z} - \mathbf{a} \rangle] \\ &= \langle \mathbb{E}_k [\mathbf{Z} - \mathbb{E}_k \mathbf{Z}], \mathbb{E}_k \mathbf{Z} - \mathbf{a} \rangle = 0. \end{aligned} \quad (44.15)$$

□

取 $\mathbf{a} = \mathbf{0}$, $\mathbf{Z} = \mathbf{g}_k$, 可得

$$\mathbb{E}_k \|\mathbf{g}_k\|^2 = \|\nabla f(\mathbf{x}^k)\|^2 + \mathbb{E}_k \|\mathbf{g}_k - \nabla f(\mathbf{x}^k)\|^2. \quad (44.16)$$

因此

$$\mathbb{E}_k \|\mathbf{g}_k\|^2 \leq \|\nabla f(\mathbf{x}^k)\|^2 + \sigma^2. \quad (44.17)$$

易错点、反例与失败模式

以下两个条件不同:

$\mathbb{E}_k \|\mathbf{g}_k - \nabla f(\mathbf{x}^k)\|^2 \leq \sigma^2$ 是有界方差;

$\mathbb{E}_k \|\mathbf{g}_k\|^2 \leq G^2$ 是有界二阶矩.

有界二阶矩通常更强. 若真实梯度在定义域上无界, 有界方差不推出有界二阶矩.

44.5 Tower Property

对可积随机变量 Z , 有

$$\mathbb{E}[\mathbb{E}_k[Z]] = \mathbb{E}[Z]. \quad (44.18)$$

随机优化中应先建立 $\mathbb{E}_k[\text{下一步误差}] \leq \text{当前可测量项}$, 再对 $\mathcal{F}_k$ 取无条件期望.

不得在仍含有 $\mathcal{F}_k$ -随机量时, 把条件期望符号直接删除而不说明 tower property.

44.6 Mini-Batch 随机梯度的方差


设在给定 $\mathcal{F}_k$ 后, $\mathbf{g}_{k,1}, \dots, \mathbf{g}_{k,\tau}$ 条件独立同分布, 并满足 $\mathbb{E}_k[\mathbf{g}_{k,j}] = \nabla f(\mathbf{x}^k)$, $\mathbb{E}_k \|\mathbf{g}_{k,j} - \nabla f(\mathbf{x}^k)\|^2 \leq \sigma^2$.

定义 mini-batch 平均:

$$\bar{\mathbf{g}}_k^{(\tau)} = \frac{1}{\tau} \sum_{j=1}^{\tau} \mathbf{g}_{k,j}. \quad (44.19)$$

其条件期望为

$$\mathbb{E}_k[\bar{\mathbf{g}}_k^{(\tau)}] = \nabla f(\mathbf{x}^k). \quad (44.20)$$



令 $\zeta_{k,j} = \mathbf{g}_{k,j} - \nabla f(\mathbf{x}^k)$ 。则

$$\begin{aligned} & \mathbb{E}_k \left\| \bar{\mathbf{g}}_k^{(\tau)} - \nabla f(\mathbf{x}^k) \right\|^2 \\ &= \frac{1}{\tau^2} \mathbb{E}_k \left\| \sum_{j=1}^{\tau} \zeta_{k,j} \right\|^2 \\ &= \frac{1}{\tau^2} \left[\sum_{j=1}^{\tau} \mathbb{E}_k \|\zeta_{k,j}\|^2 + 2 \sum_{1 \leq i < j \leq \tau} \mathbb{E}_k \langle \zeta_{k,i}, \zeta_{k,j} \rangle \right]. \end{aligned} \quad (44.21)$$

条件独立和零均值给出 $\mathbb{E}_k \langle \zeta_{k,i}, \zeta_{k,j} \rangle = 0$, $i \neq j$ 。因此

$$\mathbb{E}_k \left\| \bar{\mathbf{g}}_k^{(\tau)} - \nabla f(\mathbf{x}^k) \right\|^2 \leq \frac{\sigma^2}{\tau}. \quad (44.22)$$

易错点、反例与失败模式

方差按 $1/\tau$ 缩放依赖条件独立或至少交叉协方差为零。

一般情况下，

$$\begin{aligned} \text{Var}_k \left(\frac{1}{\tau} \sum_{j=1}^{\tau} \mathbf{g}_{k,j} \right) &= \frac{1}{\tau^2} \sum_{j=1}^{\tau} \text{Var}_k(\mathbf{g}_{k,j}) \\ &\quad + \frac{2}{\tau^2} \sum_{i < j} \mathbb{E}_k \langle \zeta_{k,i}, \zeta_{k,j} \rangle. \end{aligned} \quad (44.23)$$

若样本高度正相关，mini-batch 方差可能远大于 σ^2/τ 。

44.7 Mini-Batch 的计算复杂度解释

设：

- 单个样本梯度代价为 C_g ；
- batch size 为 τ ；
- 共执行 K 次参数更新。

则：

- component-gradient oracle 调用数为 $K\tau$ ；
- 串行时间近似为 $O(K\tau C_g)$ ；
- 若有 τ 个并行处理单元且通信代价可忽略，单步 wall-clock time 可接近 $O(C_g)$ 。

因此 mini-batch 的主要收益可能来自：

1. 方差降低；
2. GPU 或多处理器并行；
3. 向量化和数据复用；
4. 更稳定的梯度方向。

但 batch size 增大并不保证按同样比例减少总 component-gradient oracle complexity。



第四十五章 SGD 在非凸、凸与强凸光滑情形下的收敛

45.1 非凸 L -Smooth 目标

考虑 $\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \mathbf{g}_k$, 假设:

1. f 是 L -smooth, 但不要求凸;
2. $f_{\inf} := \inf_{\mathbf{x}} f(\mathbf{x}) > -\infty$;
3. 条件无偏和条件方差假设成立;
4. 使用常数步长 $0 < \gamma \leq \frac{1}{L}$.

定义

$$\Delta_0 := f(\mathbf{x}^0) - f_{\inf}. \quad (45.1)$$

定理 45.1 (非凸光滑 SGD 的平均梯度上界). 对任意 $K \geq 0$,

$$\frac{1}{K+1} \sum_{k=0}^K \mathbb{E} \|\nabla f(\mathbf{x}^k)\|^2 \leq \frac{2\Delta_0}{\gamma(K+1)} + \gamma L \sigma^2. \quad (45.2)$$

证明. 由 L -smoothness,

$$\begin{aligned} f(\mathbf{x}^{k+1}) &\leq f(\mathbf{x}^k) + \langle \nabla f(\mathbf{x}^k), \mathbf{x}^{k+1} - \mathbf{x}^k \rangle \\ &\quad + \frac{L}{2} \|\mathbf{x}^{k+1} - \mathbf{x}^k\|^2. \end{aligned} \quad (45.3)$$

代入 $\mathbf{x}^{k+1} - \mathbf{x}^k = -\gamma \mathbf{g}_k$


$$f(\mathbf{x}^{k+1}) \leq f(\mathbf{x}^k) - \gamma \langle \nabla f(\mathbf{x}^k), \mathbf{g}_k \rangle + \frac{L\gamma^2}{2} \|\mathbf{g}_k\|^2. \quad (45.4)$$

取条件期望:

$$\begin{aligned} \mathbb{E}_k[f(\mathbf{x}^{k+1})] &\leq f(\mathbf{x}^k) - \gamma \|\nabla f(\mathbf{x}^k)\|^2 \\ &\quad + \frac{L\gamma^2}{2} [\|\nabla f(\mathbf{x}^k)\|^2 + \sigma^2] \\ &= f(\mathbf{x}^k) - \gamma \left(1 - \frac{L\gamma}{2}\right) \|\nabla f(\mathbf{x}^k)\|^2 + \frac{L\gamma^2\sigma^2}{2}. \end{aligned} \quad (45.5)$$

若 $\gamma \leq \frac{1}{L}$, 则 $1 - \frac{L\gamma}{2} \geq \frac{1}{2}$, 故

$$\mathbb{E}_k[f(\mathbf{x}^{k+1})] \leq f(\mathbf{x}^k) - \frac{\gamma}{2} \|\nabla f(\mathbf{x}^k)\|^2 + \frac{L\gamma^2\sigma^2}{2}. \quad (45.6)$$



取无条件期望并求和：

$$\begin{aligned} \frac{\gamma}{2} \sum_{k=0}^K \mathbb{E} \|\nabla f(\mathbf{x}^k)\|^2 &\leq f(\mathbf{x}^0) - \mathbb{E}[f(\mathbf{x}^{K+1})] + \frac{L\gamma^2\sigma^2}{2}(K+1) \\ &\leq \Delta_0 + \frac{L\gamma^2\sigma^2}{2}(K+1). \end{aligned} \quad (45.7)$$

□

45.1.1 Horizon-Dependent 步长

令

$$\gamma_K = \left[L + \sqrt{\frac{(K+1)L\sigma^2}{2\Delta_0}} \right]^{-1}, \quad (45.8)$$

其中当 $\sigma = 0$ 时取 $\gamma_K = \frac{1}{L}$ 。

则 $\gamma_K \leq \min \left\{ \frac{1}{L}, \sqrt{\frac{2\Delta_0}{(K+1)L\sigma^2}} \right\}$ ，从而

$$\frac{1}{K+1} \sum_{k=0}^K \mathbb{E} \|\nabla f(\mathbf{x}^k)\|^2 \leq \sqrt{\frac{8L\Delta_0\sigma^2}{K+1}} + \frac{2L\Delta_0}{K+1}. \quad (45.9)$$

若目标是 $\frac{1}{K+1} \sum_{k=0}^K \mathbb{E} \|\nabla f(\mathbf{x}^k)\|^2 \leq \varepsilon$ ，则典型复杂度为

$$K = O\left(\frac{L\Delta_0\sigma^2}{\varepsilon^2} + \frac{L\Delta_0}{\varepsilon}\right). \quad (45.10)$$

易错点、反例与失败模式

若题目要求 $\mathbb{E} \|\nabla f(\mathbf{x}^R)\| \leq \varepsilon$ ，而不是平方范数不超过 ε ，通常要将平方范数精度设为 ε^2 ，复杂度中的 ε 次数会相应改变。

45.2 一般凸且光滑的 SGD

设：

- f 凸且 L -smooth；
- 无约束最优解 $\mathbf{x}^* \in \arg \min f$ 存在；
- $0 < \gamma \leq \frac{1}{2L}$ 。

记


$$R_0^2 := \|\mathbf{x}^0 - \mathbf{x}^*\|^2. \quad (45.11)$$

定理 45.2 (凸光滑 SGD 的平均函数值收敛)。有

$$\frac{1}{K+1} \sum_{k=0}^K \mathbb{E} [f(\mathbf{x}^k) - f^*] \leq \frac{R_0^2}{\gamma(K+1)} + \gamma\sigma^2. \quad (45.12)$$

若定义

$$\bar{\mathbf{x}}^K = \frac{1}{K+1} \sum_{k=0}^K \mathbf{x}^k, \quad (45.13)$$



则由 Jensen 不等式,

$$\mathbb{E}[f(\bar{\mathbf{x}}^K) - f^*] \leq \frac{R_0^2}{\gamma(K+1)} + \gamma\sigma^2. \quad (45.14)$$

证明. 展开距离:

$$\begin{aligned} \mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 &= \|\mathbf{x}^k - \mathbf{x}^*\|^2 - 2\gamma \langle \nabla f(\mathbf{x}^k), \mathbf{x}^k - \mathbf{x}^* \rangle \\ &\quad + \gamma^2 \mathbb{E}_k \|\mathbf{g}_k\|^2. \end{aligned} \quad (45.15)$$

由凸性, $\langle \nabla f(\mathbf{x}^k), \mathbf{x}^k - \mathbf{x}^* \rangle \geq f(\mathbf{x}^k) - f^*$. 由凸光滑性和 $\nabla f(\mathbf{x}^*) = \mathbf{0}$, 有 $\|\nabla f(\mathbf{x}^k)\|^2 \leq 2L[f(\mathbf{x}^k) - f^*]$. 于是

$$\begin{aligned} \mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 &\leq \|\mathbf{x}^k - \mathbf{x}^*\|^2 \\ &\quad - 2\gamma[1 - L\gamma][f(\mathbf{x}^k) - f^*] + \gamma^2\sigma^2. \end{aligned} \quad (45.16)$$

若 $\gamma \leq \frac{1}{2L}$, 则 $2(1 - L\gamma) \geq 1$, 故

$$\gamma[f(\mathbf{x}^k) - f^*] \leq \|\mathbf{x}^k - \mathbf{x}^*\|^2 - \mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 + \gamma^2\sigma^2. \quad (45.17)$$

取期望并对 k 求和即可. $\square$

45.2.1 平衡确定性误差与随机误差

取

$$\gamma_K = \left[2L + \sqrt{\frac{(K+1)\sigma^2}{R_0^2}} \right]^{-1}, \quad (45.18)$$

则

$$\mathbb{E}[f(\bar{\mathbf{x}}^K) - f^*] \leq 2\sqrt{\frac{\sigma^2 R_0^2}{K+1}} + \frac{2LR_0^2}{K+1}. \quad (45.19)$$

第一项是随机噪声主导的 $O(K^{-1/2})$, 第二项是确定性光滑优化的 $O(K^{-1})$.

当 $\sigma^2 = 0$ 时, 恢复确定性 GD 的 $O(1/K)$ 量级.

45.3 强凸光滑 SGD 与 Noise Floor

设 f 是 L -smooth 且 μ -strongly convex, 采用 $0 < \gamma \leq \frac{1}{L}$. 记 $\Delta_k := \mathbb{E}[f(\mathbf{x}^k) - f^*]$.

由式 (45.6) 和 $\|\nabla f(\mathbf{x})\|^2 \geq 2\mu[f(\mathbf{x}) - f^*]$, 得到


$$\Delta_{k+1} \leq (1 - \gamma\mu)\Delta_k + \frac{L\gamma^2\sigma^2}{2}. \quad (45.20)$$

递推展开:

$$\begin{aligned} \Delta_K &\leq (1 - \gamma\mu)^K \Delta_0 + \frac{L\gamma^2\sigma^2}{2} \sum_{j=0}^{K-1} (1 - \gamma\mu)^j \\ &\leq (1 - \gamma\mu)^K \Delta_0 + \frac{L\gamma\sigma^2}{2\mu}. \end{aligned} \quad (45.21)$$

因此

$$\mathbb{E}[f(\mathbf{x}^K) - f^*] \leq e^{-\gamma\mu K} \Delta_0 + \frac{L\gamma\sigma^2}{2\mu}. \quad (45.22)$$



说明 45.3 (附件常数差异). [Opt-Alg] 的收敛率表述使用较松的上界 $(1 - \gamma\mu)^K \Delta_0 + \frac{L\gamma\sigma^2}{\mu}$ 。根据同一讲义中的一步下降式保留因子 $1/2$, 可得到式 (45.21) 的更紧常数。

两者的阶数相同: $O\left(e^{-\gamma\mu K} \Delta_0 + \frac{L\gamma\sigma^2}{\mu}\right)$ 。

45.3.1 Noise Floor 的含义

常数步长下:

- 确定性误差按几何速度下降;
- 每一步又注入大小为 $O(\gamma^2\sigma^2)$ 的新噪声;
- 历史噪声经 contraction 衰减;
- 稳态累积量为 $O\left(\frac{\gamma^2\sigma^2}{\gamma\mu}\right) = O\left(\frac{\gamma\sigma^2}{\mu}\right)$ 。

因此:

$$\boxed{\text{步长减小} \implies \text{noise floor 降低, 但瞬态收敛变慢.}} \quad (45.23)$$

45.3.2 Horizon-Tuned 步长消除常数误差层

设 $\sigma > 0$, 定义

$$r_K := \frac{2\mu^2\Delta_0 K}{L\sigma^2}, \quad \gamma_K := \min\left\{\frac{1}{L}, \frac{\log(1+r_K)}{\mu K}\right\}. \quad (45.24)$$

利用 $e^{-\min\{a,b\}} \leq e^{-a} + e^{-b}$, 有

$$\begin{aligned} \Delta_K &\leq \Delta_0 e^{-\mu K/L} + \frac{\Delta_0}{1+r_K} + \frac{L\sigma^2}{2\mu^2 K} \log(1+r_K) \\ &\leq \Delta_0 e^{-\mu K/L} + \frac{L\sigma^2}{2\mu^2 K} [1 + \log(1+r_K)]. \end{aligned} \quad (45.25)$$

即

$$\boxed{\Delta_K = \tilde{O}\left(\Delta_0 e^{-\mu K/L} + \frac{L\sigma^2}{\mu^2 K}\right)}, \quad (45.26)$$

其中 $\tilde{O}$ 隐藏对数因子。

45.4 期望收敛与高概率收敛

本部分上述结论主要是 $\mathbb{E}[Z_K] \leq B_K$ 形式的期望界。

仅由 Markov 不等式可得较弱的高概率界:

$$\Pr\left(Z_K \geq \frac{B_K}{\delta}\right) \leq \delta. \quad (45.27)$$

要得到更锋利的 $B_K + O\left(\sqrt{\log(1/\delta)}\right)$ 型高概率界, 通常需要额外假设, 例如:

- 噪声几乎处处有界;
- 条件次 Gaussian;
- 条件指数矩存在;



- 可使用 martingale concentration。

易错点、反例与失败模式

“期望收敛到零”不自动等价于：

- 几乎必然收敛；
- 以任意固定置信度具有同阶高概率界；
- 每条随机轨迹都单调下降。

必须明确结论中的概率量词。



第四十六章 Proximal SGD、线性收缩与迭代平均

46.1 Composite Stochastic Optimization

考虑

$$\min_{\mathbf{x} \in \mathbb{R}^d} F(\mathbf{x}) := f(\mathbf{x}) + R(\mathbf{x}), \quad (46.1)$$

其中:

- f 可微、 L -smooth、 μ -strongly convex;
- R proper、closed、convex;
- 随机梯度为

$$\mathbf{g}_k = \nabla f(\mathbf{x}^k) + \boldsymbol{\xi}^k; \quad (46.2)$$

- $\mathbb{E}_k[\boldsymbol{\xi}^k] = \mathbf{0}$, $\mathbb{E}_k\|\boldsymbol{\xi}^k\|^2 \leq \sigma^2$.

Proximal SGD 更新为

$$\mathbf{x}^{k+1} = \text{prox}_{\gamma R}(\mathbf{x}^k - \gamma \mathbf{g}_k). \quad (46.3)$$

由强凸性, F 有唯一最优点 $\mathbf{x}^*$, 并满足

$$\mathbf{x}^* = \text{prox}_{\gamma R}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*)). \quad (46.4)$$

注意: 若 $R \not\equiv 0$, 一般有 $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$ 。

46.2 一步非扩张不等式


定理 46.1 (Proximal SGD 一步不等式). 对任意 $\gamma > 0$,

$$\|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 \leq \|\mathbf{x}^k - \mathbf{x}^* - \gamma [\mathbf{g}_k - \nabla f(\mathbf{x}^*)]\|^2. \quad (46.5)$$

证明. 由 prox 非扩张性及最优点 fixed point:

$$\begin{aligned} \|\mathbf{x}^{k+1} - \mathbf{x}^*\| &= \|\text{prox}_{\gamma R}(\mathbf{x}^k - \gamma \mathbf{g}_k) \\ &\quad - \text{prox}_{\gamma R}(\mathbf{x}^* - \gamma \nabla f(\mathbf{x}^*))\| \\ &\leq \|\mathbf{x}^k - \mathbf{x}^* - \gamma [\mathbf{g}_k - \nabla f(\mathbf{x}^*)]\|. \end{aligned} \quad (46.6)$$

□



该式是 [25S-C-Q3, 6 分] 和 [26S-C-Q6, 3 分] 的共同母题。

46.3 条件期望与方差分解

令

$$\mathbf{e}^k := \mathbf{x}^k - \mathbf{x}^*, \quad (46.7)$$

$$\Delta \mathbf{g}^k := \nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^*). \quad (46.8)$$

由于 $\mathbf{g}_k - \nabla f(\mathbf{x}^*) = \Delta \mathbf{g}^k + \boldsymbol{\xi}^k$, 有

$$\begin{aligned} & \mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 \\ & \leq \mathbb{E}_k \|\mathbf{e}^k - \gamma \Delta \mathbf{g}^k - \gamma \boldsymbol{\xi}^k\|^2 \\ & = \|\mathbf{e}^k - \gamma \Delta \mathbf{g}^k\|^2 - 2\gamma \langle \mathbf{e}^k - \gamma \Delta \mathbf{g}^k, \mathbb{E}_k[\boldsymbol{\xi}^k] \rangle + \gamma^2 \mathbb{E}_k \|\boldsymbol{\xi}^k\|^2 \\ & \leq \boxed{\|\mathbf{e}^k - \gamma \Delta \mathbf{g}^k\|^2 + \gamma^2 \sigma^2}. \end{aligned} \quad (46.9)$$

这是 [25S-C-Q4, 6 分] 和 [26S-C-Q7, 5 分] 的满分核心式。

答题方法

条件方差题必须写出以下四步：

1. 将随机梯度拆成 $\mathbf{g}_k = \nabla f(\mathbf{x}^k) + \boldsymbol{\xi}^k$;
2. 明确 $\mathbf{e}^k, \Delta \mathbf{g}^k$ 是 $\mathcal{F}_k$ -可测的;
3. 展开 $\|\mathbf{e}^k - \gamma \Delta \mathbf{g}^k - \gamma \boldsymbol{\xi}^k\|^2$;
4. 使用 $\mathbb{E}_k[\boldsymbol{\xi}^k] = 0$ 消去交叉项, 并用 $\mathbb{E}_k \|\boldsymbol{\xi}^k\|^2 \leq \sigma^2$.

只写“由无偏性可得”而不展示交叉项, 通常不能获得完整推导分。

46.4 Smooth–Strong Convex Contraction

由 定义 37.5,


$$\langle \Delta \mathbf{g}^k, \mathbf{e}^k \rangle \geq \frac{\mu L}{\mu + L} \|\mathbf{e}^k\|^2 + \frac{1}{\mu + L} \|\Delta \mathbf{g}^k\|^2. \quad (46.10)$$

因此

$$\begin{aligned} \|\mathbf{e}^k - \gamma \Delta \mathbf{g}^k\|^2 &= \|\mathbf{e}^k\|^2 - 2\gamma \langle \Delta \mathbf{g}^k, \mathbf{e}^k \rangle + \gamma^2 \|\Delta \mathbf{g}^k\|^2 \\ &\leq \left(1 - \frac{2\gamma\mu L}{\mu + L}\right) \|\mathbf{e}^k\|^2 \\ &\quad - \left(\frac{2\gamma}{\mu + L} - \gamma^2\right) \|\Delta \mathbf{g}^k\|^2. \end{aligned} \quad (46.11)$$

若

$$0 < \gamma \leq \frac{2}{\mu + L}, \quad (46.12)$$



则最后一项非正，故

$$\|\mathbf{e}^k - \gamma \Delta \mathbf{g}^k\|^2 \leq (1 - \rho_\gamma) \|\mathbf{e}^k\|^2, \quad \rho_\gamma := \frac{2\gamma\mu L}{\mu + L}. \quad (46.13)$$

取

$$\gamma_\star = \frac{2}{\mu + L}, \quad (46.14)$$

得到

$$\rho = \frac{4\mu L}{(\mu + L)^2}. \quad (46.15)$$

于是

$$\mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^\star\|^2 \leq (1 - \rho) \|\mathbf{x}^k - \mathbf{x}^\star\|^2 + \gamma_\star^2 \sigma^2. \quad (46.16)$$

该式对应：[25S-C-Q5, 5 分], [26S-C-Q8, 4 分]。

46.5 递推展开与 Noise Floor

令 $a_k := \mathbb{E} \|\mathbf{x}^k - \mathbf{x}^\star\|^2$ 。由 tower property,

$$a_{k+1} \leq (1 - \rho) a_k + \gamma_\star^2 \sigma^2. \quad (46.17)$$

反复递推：

$$\begin{aligned} a_K &\leq (1 - \rho)^K a_0 + \gamma_\star^2 \sigma^2 \sum_{j=0}^{K-1} (1 - \rho)^j \\ &= (1 - \rho)^K a_0 + \frac{\gamma_\star^2 \sigma^2}{\rho} [1 - (1 - \rho)^K] \\ &\leq \boxed{(1 - \rho)^K a_0 + \frac{\gamma_\star^2 \sigma^2}{\rho}}. \end{aligned} \quad (46.18)$$

代入 $\gamma_\star = \frac{2}{L+\mu}$, $\rho = \frac{4\mu L}{(L+\mu)^2}$, 得到

$$\frac{\gamma_\star^2 \sigma^2}{\rho} = \frac{\sigma^2}{\mu L}. \quad (46.19)$$

由于 $\frac{1}{L} \leq \frac{2}{L+\mu} = \gamma_\star$, 还有较松但符合真题形式的上界

$$\frac{\sigma^2}{\mu L} \leq \frac{\gamma_\star \sigma^2}{\mu}. \quad (46.20)$$

易错点、反例与失败模式

Noise floor 是收敛上界中的渐近误差层，不是断言真实算法误差一定精确等于该值。实际稳态误差可能更小；上界的作用是说明在当前假设和常数步长下，证明不能保证误差继续下降到零。

46.6 2025 Spring 复杂度结论

令 $\kappa = \frac{L}{\mu} \geq 1$ 。有

$$\frac{1}{\rho} = \frac{(L + \mu)^2}{4\mu L} = \frac{(\kappa + 1)^2}{4\kappa} = \frac{1}{4} \left(\kappa + 2 + \frac{1}{\kappa} \right) \leq \frac{\kappa + 3}{4}. \quad (46.21)$$

又因为 $(1 - \rho)^K \leq e^{-\rho K}$, 若

$$K \geq \frac{\kappa + 3}{4} \log \frac{1}{\varepsilon}, \quad (46.22)$$

则 $(1 - \rho)^K \leq \varepsilon$ 。

因此

$$\mathbb{E} \|\mathbf{x}^K - \mathbf{x}^*\|^2 \leq \varepsilon \|\mathbf{x}^0 - \mathbf{x}^*\|^2 + \frac{\gamma_* \sigma^2}{\mu}. \quad (46.23)$$

这正是 [25S-C-Q6, 5 分] 要求证明的结构。

46.7 平均迭代误差的方差

定义中心化迭代误差：

$$\mathbf{e}_t := \mathbf{x}^t - \mathbb{E}[\mathbf{x}^t]. \quad (46.24)$$

定义平均迭代点及其中心化误差：

$$\bar{\mathbf{x}}^K = \frac{1}{K} \sum_{t=1}^K \mathbf{x}^t, \quad (46.25)$$

$$\bar{\mathbf{e}}_K = \bar{\mathbf{x}}^K - \mathbb{E}[\bar{\mathbf{x}}^K] = \frac{1}{K} \sum_{t=1}^K \mathbf{e}_t. \quad (46.26)$$

在 [26S-C-Q9, 3 分] 给出的简化模型中，假设：

$$\mathbb{E} \langle \mathbf{e}_s, \mathbf{e}_t \rangle = 0, \quad s \neq t, \quad (46.27)$$

并且

$$\mathbb{E} \|\mathbf{e}_t\|^2 \leq V. \quad (46.28)$$

则

$$\begin{aligned} \mathbb{E} \|\bar{\mathbf{e}}_K\|^2 &= \frac{1}{K^2} \mathbb{E} \left\| \sum_{t=1}^K \mathbf{e}_t \right\|^2 \\ &= \frac{1}{K^2} \left[\sum_{t=1}^K \mathbb{E} \|\mathbf{e}_t\|^2 + 2 \sum_{1 \leq s < t \leq K} \mathbb{E} \langle \mathbf{e}_s, \mathbf{e}_t \rangle \right] \\ &\leq \frac{V}{K}. \end{aligned} \quad (46.29)$$



易错点、反例与失败模式

实际 SGD 迭代点通常相关, 因为 $\mathbf{x}^{t+1}$ 由 $\mathbf{x}^t$ 递推得到。

因此 $\mathbb{E}\|\bar{\mathbf{e}}_K\|^2 \leq V/K$ 在该真题中依赖题面明确给出的“不相关误差”简化假设, 不能当作所有 SGD 轨迹无条件成立的定理。

46.8 递减步长与 $O(\log K/K)$ 平均函数值

本节对应 [26S-C-Q10, 5 分]。令 $R \equiv 0$, $F = f$, 并假设 f 是 μ -strongly convex 和 L -smooth。

设 $\Delta_t := \mathbb{E}[f(\mathbf{x}^t) - f^*]$, $a_t := \mathbb{E}\|\mathbf{x}^t - \mathbf{x}^*\|^2$ 。

由条件距离展开:

$$\begin{aligned} \mathbb{E}_t\|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2 &\leq \|\mathbf{x}^t - \mathbf{x}^*\|^2 - 2\gamma_t \langle \nabla f(\mathbf{x}^t), \mathbf{x}^t - \mathbf{x}^* \rangle \\ &\quad + \gamma_t^2 \|\nabla f(\mathbf{x}^t)\|^2 + \gamma_t^2 \sigma^2. \end{aligned} \quad (46.30)$$

仅使用凸性与光滑性: $\langle \nabla f(\mathbf{x}^t), \mathbf{x}^t - \mathbf{x}^* \rangle \geq f(\mathbf{x}^t) - f^*$, $\|\nabla f(\mathbf{x}^t)\|^2 \leq 2L[f(\mathbf{x}^t) - f^*]$, 得到

$$\mathbb{E}_t\|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2 \leq \|\mathbf{x}^t - \mathbf{x}^*\|^2 - 2\gamma_t(1 - L\gamma_t)[f(\mathbf{x}^t) - f^*] + \gamma_t^2 \sigma^2. \quad (46.31)$$

若 $\gamma_t \leq \frac{1}{2L}$, 则

$$\mathbb{E}_t\|\mathbf{x}^{t+1} - \mathbf{x}^*\|^2 \leq \|\mathbf{x}^t - \mathbf{x}^*\|^2 - \gamma_t[f(\mathbf{x}^t) - f^*] + \gamma_t^2 \sigma^2. \quad (46.32)$$

为了得到可 telescope 的强凸版本, 进一步使用

$$\langle \nabla f(\mathbf{x}^t), \mathbf{x}^t - \mathbf{x}^* \rangle \geq f(\mathbf{x}^t) - f^* + \frac{\mu}{2}\|\mathbf{x}^t - \mathbf{x}^*\|^2. \quad (46.33)$$

于是

$$a_{t+1} \leq (1 - \mu\gamma_t)a_t - 2\gamma_t(1 - L\gamma_t)\Delta_t + \gamma_t^2 \sigma^2. \quad (46.34)$$

当 $\gamma_t \leq \frac{1}{2L}$, 有

$$a_{t+1} \leq (1 - \mu\gamma_t)a_t - \gamma_t\Delta_t + \gamma_t^2 \sigma^2. \quad (46.35)$$

取


$$\gamma_t = \frac{1}{\mu t}, \quad (46.36)$$

对满足 $t \geq t_0 := \left\lceil \frac{2L}{\mu} \right\rceil$ 的迭代, 有 $\gamma_t \leq \frac{1}{2L}$ 。式 (46.35) 改写为

$$\Delta_t \leq \mu(t-1)a_t - \mu t a_{t+1} + \frac{\sigma^2}{\mu t}. \quad (46.37)$$

从 $t = t_0$ 到 K 求和:

$$\begin{aligned} \sum_{t=t_0}^K \Delta_t &\leq \mu(t_0-1)a_{t_0} - \mu K a_{K+1} + \frac{\sigma^2}{\mu} \sum_{t=t_0}^K \frac{1}{t} \\ &\leq \mu(t_0-1)a_{t_0} + \frac{\sigma^2}{\mu} (1 + \log K). \end{aligned} \quad (46.38)$$



将前 $t_0 - 1$ 个有限项吸收到常数 C_0 中, 并用 Jensen 不等式:

$$\begin{aligned} \mathbb{E} [f(\bar{\mathbf{x}}^K) - f^*] &\leq \frac{1}{K} \sum_{t=1}^K \Delta_t \\ &\leq \boxed{\frac{C_0 + (\sigma^2/\mu)(1 + \log K)}{K} = O\left(\frac{\log K}{K}\right)}. \end{aligned} \quad (46.39)$$

说明 46.2 (早期步长的严格处理). 若从 $t = 1$ 开始直接取 $\gamma_t = \frac{1}{\mu t}$, 早期步长可能不满足 $\gamma_t \leq \frac{1}{2L}$ 。

严格实现可采用 clipped schedule:

$$\gamma_t = \min \left\{ \frac{1}{2L}, \frac{1}{\mu t} \right\}. \quad (46.40)$$

有限个早期迭代只改变式 (46.39) 中的常数 C_0 , 不改变 $O(\log K/K)$ 渐近阶。



第四十七章 有限和、多重采样与 Expected Smoothness

47.1 2025 Fall 真题问题设定

考虑有限和复合优化：

$$\min_{\mathbf{x} \in \mathbb{R}^d} F(\mathbf{x}) = f(\mathbf{x}) + R(\mathbf{x}), \quad f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}). \quad (47.1)$$

假设：

1. 每个 $f_i : \mathbb{R}^d \rightarrow \mathbb{R}$ 凸且 L_i -smooth；
2. 聚合函数 f 是 L -smooth 和 μ -strongly convex；
3. R proper、closed、convex；
4. 抽样概率 $\mathbf{q} = (q_1, \dots, q_n)$ 满足 $q_i > 0$, $\sum_{i=1}^n q_i = 1$ ；
5. 独立抽取 $s_1, \dots, s_\tau$, $\Pr(s_t = i) = q_i$.

定义单样本 importance-weighted estimator：

$$\mathbf{Y}_s(\mathbf{x}) := \frac{1}{nq_s} \nabla f_s(\mathbf{x}). \quad (47.2)$$

定义 multisampling estimator：

$$\mathbf{g}(\mathbf{x}) = \frac{1}{\tau} \sum_{t=1}^{\tau} \frac{1}{nq_{s_t}} \nabla f_{s_t}(\mathbf{x}). \quad (47.3)$$

Proximal SGD 更新为


$$\mathbf{x}^{k+1} = \text{prox}_{\gamma R}(\mathbf{x}^k - \gamma \mathbf{g}(\mathbf{x}^k)). \quad (47.4)$$

定义 Bregman divergence：

$$D_f(\mathbf{x}, \mathbf{y}) = f(\mathbf{x}) - f(\mathbf{y}) - \langle \nabla f(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle. \quad (47.5)$$

由于 $f = \frac{1}{n} \sum_i f_i$, 有

$$D_f(\mathbf{x}, \mathbf{y}) = \frac{1}{n} \sum_{i=1}^n D_{f_i}(\mathbf{x}, \mathbf{y}). \quad (47.6)$$



47.2 Importance Weight 为什么不能省

定理 47.1 (多重采样估计器的无偏性). 对任意 $\mathbf{x}$,

$$\mathbb{E}[\mathbf{g}(\mathbf{x})] = \nabla f(\mathbf{x}). \quad (47.7)$$

证明. 对单个样本:

$$\begin{aligned} \mathbb{E}_s \left[\frac{1}{nq_s} \nabla f_s(\mathbf{x}) \right] &= \sum_{i=1}^n q_i \frac{1}{nq_i} \nabla f_i(\mathbf{x}) \\ &= \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}) = \nabla f(\mathbf{x}). \end{aligned} \quad (47.8)$$

再由期望线性性:

$$\mathbb{E}[\mathbf{g}(\mathbf{x})] = \frac{1}{\tau} \sum_{t=1}^{\tau} \mathbb{E} \left[\frac{1}{nq_{s_t}} \nabla f_{s_t}(\mathbf{x}) \right] = \nabla f(\mathbf{x}). \quad (47.9)$$

□

若省略 importance weight, 使用 $\tilde{\mathbf{g}}(\mathbf{x}) = \nabla f_s(\mathbf{x})$, $s \sim \mathbf{q}$, 则

$$\mathbb{E}[\tilde{\mathbf{g}}(\mathbf{x})] = \sum_{i=1}^n q_i \nabla f_i(\mathbf{x}), \quad (47.10)$$

它一般不等于 $\frac{1}{n} \sum_i \nabla f_i(\mathbf{x})$ 。

易错点、反例与失败模式

非均匀采样必须同时改变缩放系数。

正确形式: $s \sim q$, $\frac{1}{nq_s} \nabla f_s(\mathbf{x})$ 。

若仍使用未加权的 $\nabla f_s(\mathbf{x})$, 算法优化的是由 q_i 加权的另一个有限和目标, 而不是原始均匀平均目标。

47.3 Expected Smoothness 的完整推导

定理 47.2 (多重采样的 Expected-Smoothness Bound). 对任意 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^d$,

$$\mathbb{E} \|\mathbf{g}(\mathbf{x}) - \mathbf{g}(\mathbf{y})\|^2 \leq 2A''(\tau, \mathbf{q}) D_f(\mathbf{x}, \mathbf{y}), \quad (47.11)$$

其中


$$A''(\tau, \mathbf{q}) = \frac{1}{\tau} \left(\max_{1 \leq i \leq n} \frac{L_i}{nq_i} \right) + \left(1 - \frac{1}{\tau} \right) L. \quad (47.12)$$

证明. 定义

$$\Delta_i := \nabla f_i(\mathbf{x}) - \nabla f_i(\mathbf{y}), \quad (47.13)$$

$$\mathbf{Z}_t := \frac{1}{nq_{s_t}} \Delta_{s_t}, \quad (47.14)$$

$$\bar{\mathbf{Z}} := \frac{1}{\tau} \sum_{t=1}^{\tau} \mathbf{Z}_t. \quad (47.15)$$



则 $\bar{\mathbf{Z}} = \mathbf{g}(\mathbf{x}) - \mathbf{g}(\mathbf{y})$ 。

首先,

$$\begin{aligned}\mathbb{E}[\mathbf{Z}_t] &= \sum_{i=1}^n q_i \frac{1}{nq_i} \Delta_i \\ &= \frac{1}{n} \sum_{i=1}^n \Delta_i \\ &= \nabla f(\mathbf{x}) - \nabla f(\mathbf{y}).\end{aligned}\tag{47.16}$$

由 $s_1, \dots, s_\tau$ 独立,

$$\begin{aligned}\mathbb{E}\|\bar{\mathbf{Z}}\|^2 &= \frac{1}{\tau^2} \mathbb{E} \left\| \sum_{t=1}^{\tau} \mathbf{Z}_t \right\|^2 \\ &= \frac{1}{\tau^2} \left[\sum_{t=1}^{\tau} \mathbb{E}\|\mathbf{Z}_t\|^2 + 2 \sum_{1 \leq r < t \leq \tau} \mathbb{E}\langle \mathbf{Z}_r, \mathbf{Z}_t \rangle \right].\end{aligned}\tag{47.17}$$

对交叉项,

$$\begin{aligned}\mathbb{E}\langle \mathbf{Z}_r, \mathbf{Z}_t \rangle &= \langle \mathbb{E}\mathbf{Z}_r, \mathbb{E}\mathbf{Z}_t \rangle \\ &= \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2.\end{aligned}\tag{47.18}$$

故

$$\mathbb{E}\|\bar{\mathbf{Z}}\|^2 = \frac{1}{\tau} \mathbb{E}\|\mathbf{Z}_1\|^2 + \left(1 - \frac{1}{\tau}\right) \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2.\tag{47.19}$$

下面分别控制两项。

对于单样本二阶矩:

$$\begin{aligned}\mathbb{E}\|\mathbf{Z}_1\|^2 &= \sum_{i=1}^n q_i \left\| \frac{1}{nq_i} \Delta_i \right\|^2 \\ &= \frac{1}{n^2} \sum_{i=1}^n \frac{1}{q_i} \|\Delta_i\|^2.\end{aligned}\tag{47.20}$$

每个 f_i 凸且 L_i -smooth, 故 co-coercivity 的 Bregman 形式给出

$$\|\Delta_i\|^2 \leq 2L_i D_{f_i}(\mathbf{x}, \mathbf{y}).\tag{47.21}$$

于是

$$\begin{aligned}\mathbb{E}\|\mathbf{Z}_1\|^2 &\leq \frac{2}{n^2} \sum_{i=1}^n \frac{L_i}{q_i} D_{f_i}(\mathbf{x}, \mathbf{y}) \\ &= \frac{2}{n} \sum_{i=1}^n \frac{L_i}{nq_i} D_{f_i}(\mathbf{x}, \mathbf{y}) \\ &\leq 2 \left(\max_i \frac{L_i}{nq_i} \right) \frac{1}{n} \sum_{i=1}^n D_{f_i}(\mathbf{x}, \mathbf{y}) \\ &= 2 \left(\max_i \frac{L_i}{nq_i} \right) D_f(\mathbf{x}, \mathbf{y}).\end{aligned}\tag{47.22}$$



另一方面, f 凸且 L -smooth, 故

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|^2 \leq 2LD_f(\mathbf{x}, \mathbf{y}). \quad (47.23)$$

将式 (47.22) 与式 (47.23) 代入式 (47.19):

$$\mathbb{E}\|\mathbf{g}(\mathbf{x}) - \mathbf{g}(\mathbf{y})\|^2 \leq 2 \left[\frac{1}{\tau} \max_i \frac{L_i}{nq_i} + \left(1 - \frac{1}{\tau}\right) L \right] D_f(\mathbf{x}, \mathbf{y}). \quad (47.24)$$

□

答题方法

[25F-C-Q4, 8 分] 的满分步骤:

1. 定义 $\Delta_i = \nabla f_i(x) - \nabla f_i(y)$, $Z_t = \frac{\Delta_{s_t}}{nq_{s_t}}$;
2. 写出 $\mathbb{E}Z_t = \nabla f(x) - \nabla f(y)$;
3. 完整展开 $\mathbb{E}\left\|\frac{1}{\tau} \sum_t Z_t\right\|^2$;
4. 将 diagonal terms 和 cross terms 分开;
5. 使用独立性把 cross term 写为 $\|\mathbb{E}Z_t\|^2$;
6. 使用 $\|\nabla f_i(x) - \nabla f_i(y)\|^2 \leq 2L_i D_{f_i}(x, y)$;
7. 使用 $D_f(x, y) = \frac{1}{n} \sum_i D_{f_i}(x, y)$;
8. 使用聚合函数的 $\|\nabla f(x) - \nabla f(y)\|^2 \leq 2LD_f(x, y)$;
9. 最终得到 $A'' = \frac{1}{\tau} \max_i \frac{L_i}{nq_i} + \left(1 - \frac{1}{\tau}\right) L$.

47.4 Batch Size 的极端情形与单调性

定义

$$M(\mathbf{q}) := \max_i \frac{L_i}{nq_i}. \quad (47.25)$$

则

$$A''(\tau, \mathbf{q}) = L + \frac{M(\mathbf{q}) - L}{\tau}. \quad (47.26)$$

首先证明 $M(\mathbf{q}) \geq L$ 。事实上,

$$\begin{aligned} M(\mathbf{q}) &\geq \sum_{i=1}^n q_i \frac{L_i}{nq_i} \\ &= \frac{1}{n} \sum_{i=1}^n L_i =: \bar{L}. \end{aligned} \quad (47.27)$$

而 $\bar{L}$ 是聚合函数 f 的一个有效 smoothness constant, 因此可取最小聚合常数满足 $L \leq \bar{L}$ 。

于是:

$$A''(1, \mathbf{q}) = M(\mathbf{q}), \quad (47.28)$$

$$\lim_{\tau \rightarrow \infty} A''(\tau, \mathbf{q}) = L. \quad (47.29)$$



有限差分为

$$\begin{aligned} A''(\tau+1, \mathbf{q}) - A''(\tau, \mathbf{q}) \\ = -\frac{M(\mathbf{q}) - L}{\tau(\tau+1)} \leq 0. \end{aligned} \quad (47.30)$$

因此 A'' 关于 batch size 单调不减。

解释：

- $\tau = 1$: 单样本非均匀采样 SGD;
- τ 增大: 随机 estimator 更接近 full gradient;
- $\tau \rightarrow \infty$: 由大数定律, estimator 收敛到 $\nabla f(x)$, 常数趋于 L ;
- 对任何有限 τ , 有放回 mini-batch 并不等于精确 full gradient。

47.5 Expected-Smoothness 最优 Importance Sampling

考虑

$$\min_{\mathbf{q} \in \Delta_n^{++}} \max_i \frac{L_i}{nq_i}, \quad \Delta_n^{++} = \left\{ \mathbf{q} : q_i > 0, \sum_i q_i = 1 \right\}. \quad (47.31)$$

定理 47.3 (最优 Expected-Smoothness 采样). 假设 $L_i > 0$, $i = 1, \dots, n$ 。则最优采样概率为

$$q_i^* = \frac{L_i}{\sum_{j=1}^n L_j}. \quad (47.32)$$

最优值为

$$\min_{\mathbf{q}} \max_i \frac{L_i}{nq_i} = \frac{1}{n} \sum_{i=1}^n L_i = \bar{L}. \quad (47.33)$$

证明. 对任意 $\mathbf{q}$, $\max_i \frac{L_i}{nq_i} \geq \sum_i q_i \frac{L_i}{nq_i} = \bar{L}$ 。因此最优值至少为 $\bar{L}$ 。

令 $q_i^* = \frac{L_i}{\sum_j L_j}$, 则对每个 i ,

$$\begin{aligned} \frac{L_i}{nq_i^*} &= \frac{L_i}{n} \frac{\sum_j L_j}{L_i} \\ &= \frac{1}{n} \sum_j L_j = \bar{L}. \end{aligned} \quad (47.34)$$

所有坐标达到同一最大值, 故达到下界。 □


均匀采样 $q_i^{\text{uni}} = \frac{1}{n}$ 给出

$$M(\mathbf{q}^{\text{uni}}) = \max_i L_i = L_{\max}. \quad (47.35)$$

因此

$$A''(\tau, \mathbf{q}^*) = \frac{\bar{L}}{\tau} + \left(1 - \frac{1}{\tau}\right) L, \quad (47.36)$$

$$A''(\tau, \mathbf{q}^{\text{uni}}) = \frac{L_{\max}}{\tau} + \left(1 - \frac{1}{\tau}\right) L. \quad (47.37)$$



重要性采样带来的常数改进为

$$\frac{L_{\max} - \bar{L}}{\tau}. \quad (47.38)$$

因此 batch 越大, 非均匀 importance sampling 对 expected-smoothness constant 的边际影响越小。

说明 47.4. 若某些 $L_i = 0$, 式 (47.32) 会给出 $q_i^* = 0$, 与题面要求 $q_i > 0$ 冲突。

此时若不另设概率下界, 严格内部单纯形中可能只有 infimum: 对 $L_i = 0$ 的坐标令 $q_i \downarrow 0$, 其余正 L_i 坐标按 L_i 成比例分配。考试中通常默认 $L_i > 0$ 。

47.6 最优点处方差与 $1/\tau$ 缩放

令 $\mathbf{x}^* = \arg \min F$ 。注意在复合问题中一般 $\nabla f(\mathbf{x}^*) \neq \mathbf{0}$ 。

定义单样本随机向量

$$\mathbf{Y} = \frac{1}{nq_s} \nabla f_s(\mathbf{x}^*), \quad s \sim \mathbf{q}. \quad (47.39)$$

则 $\mathbb{E}\mathbf{Y} = \nabla f(\mathbf{x}^*)$ 。

令 $\mathbf{Y}_1, \dots, \mathbf{Y}_\tau$ 独立同分布, 并令 $\mathbf{g}(\mathbf{x}^*) = \frac{1}{\tau} \sum_{t=1}^{\tau} \mathbf{Y}_t$ 。则

$$\text{Var}[\mathbf{g}(\mathbf{x}^*)] := \mathbb{E} \|\mathbf{g}(\mathbf{x}^*) - \nabla f(\mathbf{x}^*)\|^2 = \boxed{\frac{1}{\tau} \text{Var}[\mathbf{Y}]} \quad (47.40)$$

单样本方差为

$$\begin{aligned} \text{Var}[\mathbf{Y}] &= \mathbb{E} \|\mathbf{Y}\|^2 - \|\mathbb{E}\mathbf{Y}\|^2 \\ &= \sum_{i=1}^n q_i \left\| \frac{1}{nq_i} \nabla f_i(\mathbf{x}^*) \right\|^2 - \|\nabla f(\mathbf{x}^*)\|^2 \\ &= \boxed{\frac{1}{n^2} \sum_{i=1}^n \frac{\|\nabla f_i(\mathbf{x}^*)\|^2}{q_i} - \|\nabla f(\mathbf{x}^*)\|^2}. \end{aligned} \quad (47.41)$$

故

$$\sigma_{\star}^2(\tau, \mathbf{q}) := \text{Var}[\mathbf{g}(\mathbf{x}^*)] = \frac{1}{\tau} \left[\frac{1}{n^2} \sum_{i=1}^n \frac{\|\nabla f_i(\mathbf{x}^*)\|^2}{q_i} - \|\nabla f(\mathbf{x}^*)\|^2 \right]. \quad (47.42)$$

这对应 [25F-C-Q7, 3 分]。

47.6.1 Interpolation 条件

若所有 component gradients 在最优点同时消失:

$$\nabla f_i(\mathbf{x}^*) = \mathbf{0}, \quad \forall i, \quad (47.43)$$

则 $\sigma_{\star}^2(\tau, \mathbf{q}) = 0$ 。

这类情形下, 随机梯度在最优点不再注入噪声, 常数步长可能实现精确线性收敛。

但一般有限和问题只满足 $\frac{1}{n} \sum_i \nabla f_i(\mathbf{x}^*) = \nabla f(\mathbf{x}^*)$, 各 component gradient 可以很大且相互抵消。



47.7 方差最优采样与 Smoothness 最优采样的区别

根据式 (47.41)，若只希望最小化最优方差，需要求解

$$\min_{\mathbf{q} \in \Delta_n^{++}} \sum_{i=1}^n \frac{\|\nabla f_i(\mathbf{x}^*)\|^2}{q_i}. \quad (47.44)$$

由 Cauchy-Schwarz:

$$\left(\sum_i \|\nabla f_i(\mathbf{x}^*)\| \right)^2 = \left(\sum_i \sqrt{q_i} \frac{\|\nabla f_i(\mathbf{x}^*)\|}{\sqrt{q_i}} \right)^2 \leq \left(\sum_i q_i \right) \left(\sum_i \frac{\|\nabla f_i(\mathbf{x}^*)\|^2}{q_i} \right). \quad (47.45)$$

若所有相应范数为正，等号条件给出

$$q_i^{\text{var}} = \frac{\|\nabla f_i(\mathbf{x}^*)\|}{\sum_j \|\nabla f_j(\mathbf{x}^*)\|}. \quad (47.46)$$

而 expected-smoothness 最优采样是 $q_i^{\text{ES}} \propto L_i$ 。

二者一般不同：

- $q_i \propto L_i$ 优化允许步长和全局 expected-smoothness 常数；
- $q_i \propto \|\nabla f_i(\mathbf{x}^*)\|$ 优化最优局部方差；
- $\mathbf{x}^*$ 未知，因此方差最优分布通常不能直接预先计算；
- 实际采样设计可能需要在全局稳定性和局部噪声之间折中。



第四十八章 AC Inequality、闭式 Noise Floor 与真题统一解法

48.1 AC Inequality

定义 48.1 (AC inequality). 设 $\mathbf{g}(\mathbf{x})$ 是 $\nabla f(\mathbf{x})$ 的无偏估计。若存在常数 $A > 0, C \geq 0$, 使对所有迭代点 $\mathbf{x}^k$ 有

$$\mathbb{E} [\|\mathbf{g}(\mathbf{x}^k) - \nabla f(\mathbf{x}^*)\|^2 \mid \mathbf{x}^k] \leq 2AD_f(\mathbf{x}^k, \mathbf{x}^*) + C, \quad (48.1)$$

则称随机梯度满足参数为 (A, C) 的 AC inequality。

其中:

- A 控制离开最优点时随机梯度二阶矩随函数几何误差的增长;
- C 控制最优点处不能消失的剩余随机方差;
- $C = 0$ 时不存在由该上界产生的 noise floor。

48.2 Expected Smoothness 推出 AC Inequality

设对任意 $\mathbf{x}, \mathbf{y}$, 有

$$\mathbb{E}\|\mathbf{g}(\mathbf{x}) - \mathbf{g}(\mathbf{y})\|^2 \leq 2A''D_f(\mathbf{x}, \mathbf{y}) + C''(\mathbf{y}). \quad (48.2)$$

又假设 $\mathbb{E}[\mathbf{g}(\mathbf{y})] = \nabla f(\mathbf{y})$ 。

写成

$$\mathbf{g}(\mathbf{x}) - \nabla f(\mathbf{y}) = [\mathbf{g}(\mathbf{x}) - \mathbf{g}(\mathbf{y})] + [\mathbf{g}(\mathbf{y}) - \nabla f(\mathbf{y})]. \quad (48.3)$$

利用 $\|\mathbf{a} + \mathbf{b}\|^2 \leq 2\|\mathbf{a}\|^2 + 2\|\mathbf{b}\|^2$ 可得


$$\begin{aligned} \mathbb{E}\|\mathbf{g}(\mathbf{x}) - \nabla f(\mathbf{y})\|^2 &\leq 2\mathbb{E}\|\mathbf{g}(\mathbf{x}) - \mathbf{g}(\mathbf{y})\|^2 + 2\mathbb{E}\|\mathbf{g}(\mathbf{y}) - \nabla f(\mathbf{y})\|^2 \\ &\leq 4A''D_f(\mathbf{x}, \mathbf{y}) + 2[C''(\mathbf{y}) + \text{Var}[\mathbf{g}(\mathbf{y})]]. \end{aligned} \quad (48.4)$$

与 AC 标准形式比较:

$$A = 2A'', \quad C = 2[\text{Var}[\mathbf{g}(\mathbf{y})] + C''(\mathbf{y})]. \quad (48.5)$$

对 [定义 47.2](#) 中的有限和 estimator, $C''(\mathbf{y}) = 0$ 。取 $\mathbf{y} = \mathbf{x}^*$, 得到

$$A = 2A''(\tau, \mathbf{q}), \quad C = 2\sigma_*^2(\tau, \mathbf{q}). \quad (48.6)$$



展开为

$$A = \frac{2}{\tau} \left(\max_i \frac{L_i}{nq_i} \right) + 2 \left(1 - \frac{1}{\tau} \right) L, \quad (48.7)$$

$$C = \frac{2}{\tau} \left[\frac{1}{n^2} \sum_{i=1}^n \frac{\|\nabla f_i(\mathbf{x}^*)\|^2}{q_i} - \|\nabla f(\mathbf{x}^*)\|^2 \right]. \quad (48.8)$$

这对应 [25F-C-Q8, 2 分]。

48.3 AC 条件下的 Proximal SGD 收敛

定理 48.2 (AC inequality 下的线性收敛和 noise floor). 设:

1. f 是 μ -strongly convex;
2. R proper、closed、convex;
3. $\mathbf{g}_k$ 条件无偏;
4. AC inequality (48.1) 成立;
5. $0 < \gamma \leq \frac{1}{A}$.

则 proximal SGD 满足

$$\mathbb{E} \|\mathbf{x}^K - \mathbf{x}^*\|^2 \leq (1 - \gamma\mu)^K \|\mathbf{x}^0 - \mathbf{x}^*\|^2 + \frac{\gamma C}{\mu}. \quad (48.9)$$

证明. 由 prox 非扩张性:

$$\begin{aligned} \mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 &\leq \|\mathbf{e}^k\|^2 - 2\gamma \langle \nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^*), \mathbf{e}^k \rangle \\ &\quad + \gamma^2 \mathbb{E}_k \|\mathbf{g}_k - \nabla f(\mathbf{x}^*)\|^2. \end{aligned} \quad (48.10)$$

使用 Bregman 对称化恒等式:

$$\begin{aligned} &\langle \nabla f(\mathbf{x}^k) - \nabla f(\mathbf{x}^*), \mathbf{x}^k - \mathbf{x}^* \rangle \\ &= D_f(\mathbf{x}^k, \mathbf{x}^*) + D_f(\mathbf{x}^*, \mathbf{x}^k). \end{aligned} \quad (48.11)$$

由 μ -强凸性,


$$D_f(\mathbf{x}^*, \mathbf{x}^k) \geq \frac{\mu}{2} \|\mathbf{x}^k - \mathbf{x}^*\|^2. \quad (48.12)$$

再使用 AC inequality:

$$\begin{aligned} \mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 &\leq \|\mathbf{e}^k\|^2 - 2\gamma D_f(\mathbf{x}^k, \mathbf{x}^*) - \gamma\mu \|\mathbf{e}^k\|^2 \\ &\quad + \gamma^2 [2AD_f(\mathbf{x}^k, \mathbf{x}^*) + C] \\ &= (1 - \gamma\mu) \|\mathbf{e}^k\|^2 \\ &\quad - 2\gamma(1 - \gamma A) D_f(\mathbf{x}^k, \mathbf{x}^*) + \gamma^2 C. \end{aligned} \quad (48.13)$$

当 $\gamma \leq \frac{1}{A}$ 时, 中间 Bregman 项非正, 故

$$\mathbb{E}_k \|\mathbf{x}^{k+1} - \mathbf{x}^*\|^2 \leq (1 - \gamma\mu) \|\mathbf{x}^k - \mathbf{x}^*\|^2 + \gamma^2 C. \quad (48.14)$$



取无条件期望并展开几何级数：

$$\begin{aligned}\mathbb{E}\|\mathbf{x}^K - \mathbf{x}^*\|^2 &\leq (1 - \gamma\mu)^K \|\mathbf{x}^0 - \mathbf{x}^*\|^2 + \gamma^2 C \sum_{j=0}^{K-1} (1 - \gamma\mu)^j \\ &\leq (1 - \gamma\mu)^K \|\mathbf{x}^0 - \mathbf{x}^*\|^2 + \frac{\gamma C}{\mu}.\end{aligned}\quad (48.15)$$

□

48.4 2025 Fall 的显式步长和 Noise Floor

由式 (48.6)，允许步长为

$$0 < \gamma \leq \frac{1}{2A''(\tau, \mathbf{q})}.\quad (48.16)$$

显式收敛界为

$$\begin{aligned}\mathbb{E}\|\mathbf{x}^K - \mathbf{x}^*\|^2 &\leq (1 - \gamma\mu)^K \|\mathbf{x}^0 - \mathbf{x}^*\|^2 \\ &\quad + \left[\frac{2\gamma}{\mu\tau} \left[\frac{1}{n^2} \sum_{i=1}^n \frac{\|\nabla f_i(\mathbf{x}^*)\|^2}{q_i} - \|\nabla f(\mathbf{x}^*)\|^2 \right] \right].\end{aligned}\quad (48.17)$$

这对应 [25F-C-Q9, 2 分]。

48.4.1 三个互相耦合的设计量

1. **Batch size** τ 。

增大 τ : $A''(\tau, \mathbf{q}) \downarrow L$, $C(\tau, \mathbf{q}) \propto \frac{1}{\tau}$.

2. **Sampling distribution** $\mathbf{q}$ 。

$q_i \propto L_i$ 最小化 expected-smoothness 中的最大项；

$q_i \propto \|\nabla f_i(\mathbf{x}^*)\|$ 最小化最优点方差项。

3. **Stepsize** γ 。

增大 γ ：

- 改善瞬态 contraction；
- 增大 $\gamma C/\mu$ 型 noise floor；
- 仍须满足 $\gamma \leq 1/A$.

48.5 历年真题完整映射



表 48.1: 第 13 部分历年人工智能博士资格考试映射

真题	主要标签	满分不可缺少内容
[25S-C-Q3, 6 分]	Prox 非扩张与随机一步递推	最优点 proximal fixed point; 两个 prox 输入作差; 保留 $g_k - \nabla f(x^*)$ 而不是误写为 g_k 。
[25S-C-Q4, 6 分]	条件期望与方差分解	定义 filtration; 展开平方; 零均值消去交叉项; 加入 $\gamma^2 \sigma^2$ 。
[25S-C-Q5, 5 分]	线性收缩	smooth-strong interpolation; $\gamma = \frac{2}{L+\mu}$; $\rho = \frac{4\mu L}{(L+\mu)^2}$ 。
[25S-C-Q6, 5 分]	复杂度与 noise floor	几何级数: $1/\rho \leq (\kappa + 3)/4$; $(1 - \rho)^K \leq e^{-\rho K}$; 闭式噪声项。
[25F-C-Q3, 5 分]	Importance-weighted estimator 无偏	对单样本先求期望; $q_i \cdot \frac{1}{nq_i}$; 再对 τ 个样本平均。
[25F-C-Q4, 8 分]	Expected smoothness	diagonal/cross terms; 独立性; component Bregman bound; aggregate Bregman bound; 正确常数 A'' 。
[25F-C-Q5, 4 分]	Batch interpolation	$A'' = L + \frac{M-L}{\tau}$; $\tau = 1$ 、 $\tau \rightarrow \infty$; 单调性证明。
[25F-C-Q6, 4 分]	Importance sampling 设计	下界 $M(q) \geq \bar{L}$; 构造 $q_i^* = L_i / \sum_j L_j$; 与 uniform sampling 比较。
[25F-C-Q7, 3 分]	最优点方差	batch mean 方差; $1/\tau$; 显式 $n^{-2} \sum_i \ \nabla f_i(x^*)\ ^2 / q_i - \ \nabla f(x^*)\ ^2$ 。
[25F-C-Q8, 2 分]	AC inequality	使用 $\ a + b\ ^2 \leq 2\ a\ ^2 + 2\ b\ ^2$; $A = 2A''$, $C = 2 \text{Var}[g(x^*)]$ 。
[25F-C-Q9, 2 分]	显式步长和 floor	$\gamma \leq 1/(2A'')$; 将显式 C 代入 $(1 - \gamma\mu)^K \ e_0\ ^2 + \gamma C/\mu$ 。
[26S-C-Q6, 3 分]	Proximal one-step inequality	与 [25S-C-Q3, 6 分] 同一母题, 但分值更低, 需简洁完整。
[26S-C-Q7, 5 分]	条件期望和 variance decomposition	明确 $\mathbb{E}_k[\cdot] = \mathbb{E}[\cdot x^k]$ 或完整 filtration; 消去交叉项。
[26S-C-Q8, 4 分]	Noise floor	线性 contraction; 递推意义; 说明噪声为何阻止固定步长精确收敛。
[26S-C-Q9, 3 分]	平均误差方差	展开 $\ \sum_t e_t\ ^2$; 使用题设不相关性; 得到 V/K 。
[26S-C-Q10, 5 分]	平均函数值率	smoothness 一步式; 强凸修正; $\gamma_t = 1/(\mu t)$; 加权 telescope; harmonic sum; Jensen。

48.6 核心公式速查



表 48.2: 随机优化核心公式

主题	公式	条件与解释
条件无偏	$\mathbb{E}_k[g_k] = \nabla f(x^k)$	当前点可依赖历史; 新随机样本需在条件意义下正确。
方差分解	$\mathbb{E}_k \ Z - a\ ^2 = \ \mathbb{E}_k Z - a\ ^2 + \mathbb{E}_k \ Z - \mathbb{E}_k Z\ ^2$	交叉项由条件零均值消失。
Mini-batch 方差	$\text{Var}_k \left[\frac{1}{\tau} \sum_j g_{k,j} \right] = \frac{1}{\tau} \text{Var}_k[g_{k,1}]$	要求条件独立同分布。
非凸 SGD	$\frac{1}{K} \sum_k \mathbb{E} \ \nabla f(x^k)\ ^2 \lesssim \frac{\Delta_0}{\gamma K} + \gamma L \sigma^2$	L -smooth; 结论是一阶驻点指标。
凸 SGD	$\mathbb{E}[f(\bar{x}^K) - f^*] \lesssim \frac{R_0^2}{\gamma K} + \gamma \sigma^2$	凸、 L -smooth; 使用平均迭代点。
强凸 SGD	$\mathbb{E}[f(x^K) - f^*] \lesssim e^{-\gamma \mu K} \Delta_0 + \frac{L \gamma \sigma^2}{\mu}$	常数步长导致 noise floor。
Proximal SGD	$x^{k+1} = \text{prox}_{\gamma R}(x^k - \gamma g_k)$	复合目标 $f + R$; R 可不可微。
Additive-noise contraction	$a_{k+1} \leq (1 - \rho)a_k + \gamma^2 \sigma^2$	$\gamma = 2/(L + \mu)$, $\rho = 4\mu L/(L + \mu)^2$ 。
非均匀单样本	$Y_s(x) = \frac{1}{nq_s} \nabla f_s(x)$	importance weight 保证原有限和目标的无偏性。
Expected smoothness	$\mathbb{E} \ g(x) - g(y)\ ^2 \leq 2A'' D_f(x, y)$	$A'' = \tau^{-1} \max_i \frac{L_i}{nq_i} + (1 - \tau^{-1})L$ 。
ES 最优采样	$q_i^* = \frac{L_i}{\sum_j L_j}$	使所有 $L_i/(nq_i)$ 相等。
最优点方差	$\sigma_\star^2 = \frac{1}{\tau} \left[\frac{1}{n^2} \sum_i \frac{\ \nabla f_i(x^*)\ ^2}{q_i} - \ \nabla f(x^*)\ ^2 \right]$	一般不为零; composite optimum 不要求 $\nabla f(x^*) = 0$ 。
AC 常数	$A = 2A''$, $C = 2\sigma_\star^2$	由真题给定的 expected-smoothness implication 得到。
AC 收敛	$\mathbb{E} \ x^K - x^*\ ^2 \leq (1 - \gamma \mu)^K \ x^0 - x^*\ ^2 + \frac{\gamma C}{\mu}$	步长 $0 < \gamma \leq 1/A$ 。

48.7 综合易错点与失败模式

易错点、反例与失败模式

1. 无偏性必须相对于正确目标。

非均匀抽样后若不乘 $\frac{1}{nq_i}$, estimator 对原始均匀有限和有偏。

2. 条件无偏比无条件无偏更关键。

算法中的 x^k 依赖过去样本; 证明交叉项为零需要 $\mathbb{E}[g_k | \mathcal{F}_k] = \nabla f(x^k)$ 。

3. 方差与二阶矩不能混淆。

$$\mathbb{E} \|g_k\|^2 = \|\nabla f(x^k)\|^2 + \text{Var}_k(g_k).$$

4. Mini-batch 的 $1/\tau$ 需要独立性。

相关样本会产生额外交叉协方差。

5. Iteration complexity 不等于样本梯度复杂度。

Batch size 为 τ 时, K 次参数更新使用 $K\tau$ 个 component gradients。

6. 一般凸 SGD 的标准证明控制平均点。

不得在没有额外论证时，把 $f(\bar{x}^K)$ 的界直接声称为 $f(x^K)$ 的界。

7. 非凸 SGD 只保证一阶驻点指标。

小梯度不等于全局最优，也不排除 saddle point。

8. 常数步长不自动精确收敛。

若最优点处随机方差不为零，典型上界包含 $O(\gamma\sigma^2/\mu)$ noise floor。

9. 减小步长存在速度–精度权衡。

步长越小，floor 越低；但 contraction factor 越接近 1。

10. Composite optimum 不满足普通梯度为零。

正确条件是 $-\nabla f(x^*) \in \partial R(x^*)$, 或 proximal fixed point。

11. Expected smoothness 不只是普通 smoothness。

它控制的是随机 estimator 差的二阶矩： $\mathbb{E}\|g(x) - g(y)\|^2$ 。

12. Expected-smoothness constant 中有两个来源。

$\frac{1}{\tau} \max_i \frac{L_i}{nq_i}$ 来自 diagonal terms；

$(1 - \frac{1}{\tau})L$ 来自 cross terms 的均值平方。

13. $\tau \rightarrow \infty$ 是极限，不是有限 batch 等式。

有放回采样的有限 batch 仍是随机 estimator。

14. $q_i \propto L_i$ 只优化特定常数。

它不一定最小化最优点方差；方差最优分布依赖 $\|\nabla f_i(x^*)\|$ 。

15. AC 中 A 与 A'' 不相同。

按 2025 Fall 题面给出的 implication: $A = 2A''$ 。

16. AC 中 C 是方差项，不是随机梯度均值。

在本题中 $C = 2 \text{Var}[g(x^*)]$ 。

17. Noise floor 是上界，不是精确稳态方差。

不能把 $\gamma C/\mu$ 写成算法实际误差必然达到的等式。

18. 平均误差 V/K 依赖题面不相关假设。

实际 SGD iterates 通常时间相关，需额外分析 covariance。

19. $\gamma_t = 1/(\mu t)$ 的早期迭代要检查步长条件。

严格写法可使用 $\min\{1/(2L), 1/(\mu t)\}$ 或从足够大的 t_0 开始分析。

20. 经验上增大 batch 不保证线性加速。

方差收益、并行效率、内存、通信和 total oracle calls 必须分开分析。



48.8 满分证明识别模板

答题方法

看到“随机梯度一步递推”时：

nonexpansiveness $\rightarrow$ 展开平方 $\rightarrow$ 条件无偏消交叉项 $\rightarrow$ 条件方差上界 $\rightarrow$ tower property。

看到“mini-batch expected smoothness”时：

$$Z_t = \frac{\nabla f_{s_t}(x) - \nabla f_{s_t}(y)}{nq_{s_t}}, \mathbb{E} \left\| \frac{1}{\tau} \sum_t Z_t \right\|^2 = \frac{1}{\tau} \mathbb{E} \|Z_1\|^2 + \left(1 - \frac{1}{\tau}\right) \mathbb{E} \|Z_1\|^2.$$

看到“设计 importance sampling”时：

先建立下界 $\max_i \frac{L_i}{nq_i} \geq \sum_i q_i \frac{L_i}{nq_i} = \frac{1}{n} \sum_i L_i$ ，再构造 $q_i \propto L_i$ 使所有坐标取等值。

看到“AC inequality”时：

$g(x) - \nabla f(y) = [g(x) - g(y)] + [g(y) - \nabla f(y)]$ ，使用 $\|a + b\|^2 \leq 2\|a\|^2 + 2\|b\|^2$ 。

看到“noise floor”时：


将递推写成 $a_{k+1} \leq (1 - \rho)a_k + b$ ，再完整展开 $a_K \leq (1 - \rho)^K a_0 + \frac{b}{\rho} [1 - (1 - \rho)^K]$ 。

48.9 快速自测

快速自测

1. 为什么随机优化中要定义 filtration?
2. 无条件无偏和条件无偏有什么差别?
3. 如何证明 $\mathbb{E}_k \|g_k\|^2 = \|\nabla f(x^k)\|^2 + \text{Var}_k(g_k)$?
4. 方差上界是否自动推出随机梯度二阶矩一致有界?
5. Mini-batch 方差的 $1/\tau$ 缩放使用了什么假设?
6. 若 mini-batch 样本正相关，方差表达式中多出什么项?
7. 非凸 SGD 的收敛指标是什么?
8. 若要求梯度范数而不是梯度平方范数小于 ε ，复杂度如何变化?
9. 一般凸 SGD 为什么通常输出平均迭代点?
10. 强凸光滑 SGD 的 noise floor 如何依赖 γ, σ^2, μ, L ?
11. 为什么常数步长下随机误差不会被完全消除?
12. Proximal SGD 中为什么比较项是 $g_k - \nabla f(x^*)$ 而不是简单的 g_k ?
13. 如何由 prox 非扩张性得到一步距离不等式?
14. 条件期望展开时，哪一个交叉项等于零?
15. 为什么 $\gamma = 2/(L + \mu)$ 会使梯度差平方项恰好抵消?
16. 写出 $\rho = \frac{4\mu L}{(L + \mu)^2}$ 和对应的 condition-number 表达式。
17. 如何证明 $\frac{1}{\rho} \leq \frac{\kappa + 3}{4}$?
18. 平均迭代误差方差为 V/K 需要什么特殊假设?

19. 为什么实际 SGD iterates 通常不满足互不相关?
20. 推导 $O(\log K/K)$ 时, 强凸性在哪一步使用?
21. 为什么 $\gamma_t = 1/(\mu t)$ 的前若干步需要单独处理?
22. 非均匀采样时 importance weight 为什么是 $1/(nq_i)$?
23. 写出多重采样 estimator 的输入、输出和维度。
24. Expected-smoothness 推导中 diagonal terms 给出哪一个常数?
25. Cross terms 为什么产生聚合 smoothness constant L ?
26. 为什么 $D_f(x, y) = n^{-1} \sum_i D_{f_i}(x, y)$?
27. 写出 $A''(\tau, q)$ 的完整公式。
28. 如何证明 A'' 关于 τ 单调不增?
29. $\tau = 1$ 和 $\tau \rightarrow \infty$ 分别对应什么?
30. 如何证明 $q_i^* = L_i / \sum_j L_j$ 是 expected-smoothness 最优采样?
31. 均匀采样和最优 importance sampling 的常数分别是什么?
32. 最优点处 batch estimator 的方差为什么按 $1/\tau$ 缩放?
33. 复合最优点处是否有 $\nabla f(x^*) = 0$?
34. 写出最优点方差的显式 q_i 公式。
35. Interpolation 条件为何能消除最优点随机方差?
36. Expected-smoothness 最优采样和方差最优采样为何不同?
37. AC inequality 中 A 和 C 分别控制什么?
38. 如何由 expected smoothness 推出 AC inequality?
39. 为什么 2025 Fall 题面中 $A = 2A''$ 而不是 $A = A''$?
40. 写出 2025 Fall 的允许步长范围。
41. 写出 2025 Fall 的闭式 noise floor。
42. Batch size、sampling distribution 和 stepsize 如何共同影响收敛速度与误差层?
43. 期望收敛是否自动推出同阶高概率收敛?



第四十九章 动量方法：Heavy-Ball 与 Nesterov 加速

49.1 重要性等级与实考定位

重要性等级：A

- Heavy-Ball、Nesterov acceleration 和 stochastic acceleration 均列入优化方向核心考纲。
- [26S-B-Q1(c), 2 分] 在深度学习方向直接要求 Momentum SGD 的更新式及其抑制振荡的解释。该题属于跨方向考查：深度学习方向强调训练直觉，优化方向则必须补充稳定区间、条件数和收敛率。
- Nesterov 加速是光滑凸一阶方法复杂度表中的核心结论： $O(\frac{1}{K}) \rightarrow O(\frac{1}{K^2})$ ，以及 $O(\kappa \log \frac{1}{\epsilon}) \rightarrow O(\sqrt{\kappa} \log \frac{1}{\epsilon})$ 。
- Heavy-Ball 在课程讲义中主要用于解释 “zig-zag”；一般凸目标上的统一加速保证不能由二次型分析直接外推。

49.2 三种常见动量参数化

设 $\mathbf{g}^k = \nabla f(\mathbf{x}^k)$ 或 $\mathbf{g}^k = \nabla F(\mathbf{x}^k; \xi^k)$ 。

49.2.1 位置差分形式

Heavy-Ball 或 Polyak momentum 写为


$$\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \mathbf{g}^k + \beta (\mathbf{x}^k - \mathbf{x}^{k-1}), \quad 0 \leq \beta < 1. \quad (49.1)$$

其中 $\mathbf{x}^k - \mathbf{x}^{k-1}$ 是上一轮位移，动量项沿历史移动方向继续推进。

49.2.2 梯度累积形式

定义

$$\mathbf{m}^k = \beta \mathbf{m}^{k-1} + \mathbf{g}^k, \quad \mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \mathbf{m}^k. \quad (49.2)$$



若初始化 $\mathbf{x}^{-1} = \mathbf{x}^0$, $\mathbf{m}^{-1} = \mathbf{0}$, 则由 $\mathbf{x}^k - \mathbf{x}^{k-1} = -\gamma \mathbf{m}^{k-1}$ 可得

$$\begin{aligned}\mathbf{x}^{k+1} &= \mathbf{x}^k - \gamma (\beta \mathbf{m}^{k-1} + \mathbf{g}^k) \\ &= \mathbf{x}^k - \gamma \mathbf{g}^k + \beta (\mathbf{x}^k - \mathbf{x}^{k-1}).\end{aligned}\quad (49.3)$$

故 (49.1) 与 (49.2) 等价。

49.2.3 物理速度形式

另一常见写法是

$$\mathbf{v}^{k+1} = \beta \mathbf{v}^k - \gamma \mathbf{g}^k, \quad \mathbf{x}^{k+1} = \mathbf{x}^k + \mathbf{v}^{k+1}. \quad (49.4)$$

其与 (49.1) 完全等价, 只是把 $\mathbf{v}^{k+1} = \mathbf{x}^{k+1} - \mathbf{x}^k$ 显式命名为速度。

易错点、反例与失败模式

动量存在多种参数化, 不能只凭变量名比较公式。

例如: $\mathbf{m}^k = \beta \mathbf{m}^{k-1} + \mathbf{g}^k$ 与 $\widetilde{\mathbf{m}}^k = \beta \widetilde{\mathbf{m}}^{k-1} + (1 - \beta) \mathbf{g}^k$ 相差一个比例因子。

若令 $\widetilde{\mathbf{m}}^k = (1 - \beta) \mathbf{m}^k$, 则更新学习率必须同时换算: $\gamma_{\text{new}} = \frac{\gamma_{\text{old}}}{1 - \beta}$ 。只替换动量公式而不调整学习率, 会改变实际算法。

49.3 为什么动量能够缓解 Zig-Zag

考虑二次目标

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x}, \quad \mathbf{Q} \succ 0. \quad (49.5)$$

设 $\mu \mathbf{I} \preceq \mathbf{Q} \preceq L \mathbf{I}$, $\kappa = \frac{L}{\mu}$ 。

最优点满足 $\mathbf{Q} \mathbf{x}^* + \mathbf{c} = \mathbf{0}$ 。定义误差 $\mathbf{e}^k = \mathbf{x}^k - \mathbf{x}^*$ 。Heavy-Ball 递推为

$$\mathbf{e}^{k+1} = [(1 + \beta) \mathbf{I} - \gamma \mathbf{Q}] \mathbf{e}^k - \beta \mathbf{e}^{k-1}. \quad (49.6)$$

令 $\mathbf{Q} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^\top$, $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_d)$, 其中 $\mu \leq \lambda_i \leq L$ 。在特征坐标 $\mathbf{z}^k = \mathbf{U}^\top \mathbf{e}^k$ 中, 各坐标独立满足

$$z_i^{k+1} = (1 + \beta - \gamma \lambda_i) z_i^k - \beta z_i^{k-1}. \quad (49.7)$$

梯度下降对应 $\beta = 0$, $z_i^{k+1} = (1 - \gamma \lambda_i) z_i^k$ 。

若 λ_i 很大, 方向上的梯度变化快, 容易发生符号交替; 若 λ_i 很小, 方向上的收缩慢。这造成狭长等高线中的横向振荡和纵向缓慢前进。

动量通过二阶递推综合当前梯度和历史位移:

- 在梯度反复换号的高曲率方向, 历史位移相互抵消;
- 在梯度长期同号的低曲率方向, 历史位移累积;
- 因而可减少横向振荡并增强稳定方向上的推进。



49.4 Heavy-Ball 在二次型上的稳定性

本节是根据附件更新式所作的推导补充。

对固定特征值 $\lambda > 0$, 特征方程为

$$r^2 - (1 + \beta - \gamma\lambda)r + \beta = 0. \quad (49.8)$$

记 $a_\lambda = 1 + \beta - \gamma\lambda$. 二阶实系数多项式 $r^2 - a_\lambda r + \beta$ 的两个根严格位于单位圆内, 当且仅当二阶 Jury 条件成立:

$$|\beta| < 1, \quad 1 - a_\lambda + \beta > 0, \quad 1 + a_\lambda + \beta > 0. \quad (49.9)$$

代入 $a_\lambda = 1 + \beta - \gamma\lambda$ 得到

$$1 - a_\lambda + \beta = \gamma\lambda, \quad (49.10)$$

$$1 + a_\lambda + \beta = 2 + 2\beta - \gamma\lambda. \quad (49.11)$$

因此, 当 $0 \leq \beta < 1$ 时, 单个特征方向稳定的充要条件为

$$0 < \gamma\lambda < 2(1 + \beta). \quad (49.12)$$

若要求对所有 $\lambda \in [\mu, L]$ 均稳定, 则充分且必要的统一条件为

$$0 < \gamma < \frac{2(1 + \beta)}{L}, \quad 0 \leq \beta < 1. \quad (49.13)$$

易错点、反例与失败模式

式 (49.13) 是固定正定二次型的线性稳定条件, 不是一般非二次目标的普适收敛定理。

以下推论均不合法:

- “只要 $\gamma < 2(1 + \beta)/L$, 任意非凸目标都收敛”;
- “Heavy-Ball 在所有光滑凸函数上都有 Nesterov 式最优加速”;
- “稳定意味着函数值每一步单调下降”。

二阶系统可以收敛但在迭代过程中发生振荡。

49.5 Heavy-Ball 的最优二次型参数

本节仍是根据附件更新式所作的谱分析补充。

设


$$q := \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}. \quad (49.14)$$

取

$$\gamma_{\text{HB}} = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta_{\text{HB}} = q^2. \quad (49.15)$$

对任意 $\lambda \in [\mu, L]$, 有

$$a_\lambda = 1 + q^2 - \frac{4\lambda}{(\sqrt{L} + \sqrt{\mu})^2}. \quad (49.16)$$



直接计算端点:

$$a_\mu = 2q, \quad (49.17)$$

$$a_L = -2q. \quad (49.18)$$

由于 a_λ 关于 λ 线性, $-2q \leq a_\lambda \leq 2q$ 。

特征方程为 $r^2 - a_\lambda r + q^2 = 0$ 。

当 $|a_\lambda| < 2q$ 时, 两根为共轭复数, 乘积为 q^2 , 故模长均为 $|r| = q$ 。

在端点 $\lambda = \mu, L$ 处, 出现重根 $r = q$ 或 $r = -q$ 。

因此 Heavy-Ball 在该二次型类上的最坏渐近谱半径为

$$\rho_{\text{HB}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}. \quad (49.19)$$

说明 49.1. 端点模式可能出现重根, 解中可含 kq^k 型多项式前因子。因此最严谨的说法是:

渐近谱半径为 q , 而不是无条件声称所有初值都满足 $\|e^k\| \leq q^k \|e^0\|$ 。

49.6 Nesterov 动量与 Heavy-Ball 的本质区别

Nesterov acceleration 的典型 lookahead 形式为

$$\mathbf{y}^k = \mathbf{x}^k + \beta_k (\mathbf{x}^k - \mathbf{x}^{k-1}), \quad \mathbf{x}^{k+1} = \mathbf{y}^k - \gamma_k \nabla f(\mathbf{y}^k). \quad (49.20)$$

Heavy-Ball 则在当前位置计算梯度:

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma_k \nabla f(\mathbf{x}^k) + \beta_k (\mathbf{x}^k - \mathbf{x}^{k-1}). \quad (49.21)$$

核心区别是:

$$\text{Heavy-Ball: 先在当前位置算梯度, 再叠加历史位移;} \quad (49.22)$$

$$\text{Nesterov: 先外推到 lookahead 点, 再在外推点算梯度。} \quad (49.23)$$

Nesterov 的梯度能够提前修正“按惯性将要到达的位置”, 这使其可以构造全局势函数并获得最优一阶复杂度。

49.7 一般凸光滑情形的 Nesterov 加速

采用 [Opt-Alg] 的课程参数化:

$$\beta_k = \frac{k-2}{k+1}, \quad k \geq 1, \quad (49.24)$$

$$\mathbf{y}^{k-1} = \mathbf{x}^{k-1} + \beta_k (\mathbf{x}^{k-1} - \mathbf{x}^{k-2}), \quad (49.25)$$

$$\mathbf{x}^k = \mathbf{y}^{k-1} - \frac{1}{L} \nabla f(\mathbf{y}^{k-1}), \quad (49.26)$$

并初始化 $\mathbf{x}^{-1} = \mathbf{x}^0$ 。

定理 49.2 (一般凸光滑 Nesterov 收敛率). 若 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 凸且 L -smooth, 并且最优值 $\mathbf{x}^*$ 存在, 则

$$f(\mathbf{x}^k) - f^* \leq \frac{2L \|\mathbf{x}^0 - \mathbf{x}^*\|^2}{(k+1)^2}. \quad (49.27)$$



49.7.1 势函数证明

定义

$$\theta_k = \frac{2}{k+1}, \quad \mathbf{v}^0 = \mathbf{x}^0, \quad (49.28)$$

并令

$$\mathbf{v}^k = \mathbf{x}^{k-1} + \frac{1}{\theta_k} (\mathbf{x}^k - \mathbf{x}^{k-1}). \quad (49.29)$$

可验证

$$\mathbf{y}^{k-1} = (1 - \theta_k) \mathbf{x}^{k-1} + \theta_k \mathbf{v}^{k-1}, \quad (49.30)$$

$$\mathbf{x}^k = \mathbf{y}^{k-1} - \frac{1}{L} \nabla f(\mathbf{y}^{k-1}). \quad (49.31)$$

由 L -smoothness,

$$\begin{aligned} f(\mathbf{x}^k) &\leq f(\mathbf{y}^{k-1}) + \langle \nabla f(\mathbf{y}^{k-1}), \mathbf{x}^k - \mathbf{y}^{k-1} \rangle + \frac{L}{2} \|\mathbf{x}^k - \mathbf{y}^{k-1}\|^2 \\ &= f(\mathbf{y}^{k-1}) - \frac{1}{2L} \|\nabla f(\mathbf{y}^{k-1})\|^2. \end{aligned} \quad (49.32)$$

又由凸性, 对任意 $\mathbf{z}$,

$$f(\mathbf{y}^{k-1}) - f(\mathbf{z}) \leq \langle \nabla f(\mathbf{y}^{k-1}), \mathbf{y}^{k-1} - \mathbf{z} \rangle. \quad (49.33)$$

结合 $\nabla f(\mathbf{y}^{k-1}) = L(\mathbf{y}^{k-1} - \mathbf{x}^k)$, 得到三点不等式

$$\boxed{f(\mathbf{x}^k) - f(\mathbf{z}) \leq \frac{L}{2} [\|\mathbf{y}^{k-1} - \mathbf{z}\|^2 - \|\mathbf{x}^k - \mathbf{z}\|^2]}. \quad (49.34)$$

取

$$\mathbf{z} = (1 - \theta_k) \mathbf{x}^{k-1} + \theta_k \mathbf{x}^*. \quad (49.35)$$

由凸性,

$$f(\mathbf{z}) \leq (1 - \theta_k) f(\mathbf{x}^{k-1}) + \theta_k f^*. \quad (49.36)$$

因此

$$\begin{aligned} f(\mathbf{x}^k) - f^* &- (1 - \theta_k) [f(\mathbf{x}^{k-1}) - f^*] \\ &\leq \frac{L\theta_k^2}{2} [\|\mathbf{v}^{k-1} - \mathbf{x}^*\|^2 - \|\mathbf{v}^k - \mathbf{x}^*\|^2]. \end{aligned} \quad (49.37)$$

移项并除以 $L\theta_k^2$


$$\begin{aligned} &\frac{f(\mathbf{x}^k) - f^*}{L\theta_k^2} + \frac{1}{2} \|\mathbf{v}^k - \mathbf{x}^*\|^2 \\ &\leq \frac{1 - \theta_k}{L\theta_k^2} [f(\mathbf{x}^{k-1}) - f^*] + \frac{1}{2} \|\mathbf{v}^{k-1} - \mathbf{x}^*\|^2. \end{aligned} \quad (49.38)$$

对 $\theta_k = \frac{2}{k+1}$ 有

$$\frac{1 - \theta_k}{\theta_k^2} \leq \frac{1}{\theta_{k-1}^2}, \quad k \geq 2. \quad (49.39)$$

故势函数

$$\mathcal{E}_k := \frac{f(\mathbf{x}^k) - f^*}{L\theta_k^2} + \frac{1}{2} \|\mathbf{v}^k - \mathbf{x}^*\|^2 \quad (49.40)$$



单调不增。

初始化时 $\theta_1 = 1$, $\mathbf{v}^0 = \mathbf{x}^0$, 从而

$$\mathcal{E}_k \leq \frac{1}{2} \|\mathbf{x}^0 - \mathbf{x}^*\|^2. \quad (49.41)$$

舍去非负距离项:

$$\begin{aligned} f(\mathbf{x}^k) - f^* &\leq \frac{L\theta_k^2}{2} \|\mathbf{x}^0 - \mathbf{x}^*\|^2 \\ &= \frac{2L\|\mathbf{x}^0 - \mathbf{x}^*\|^2}{(k+1)^2}. \end{aligned} \quad (49.42)$$

答题方法

若资格考试要求证明 Nesterov 的 $O(1/k^2)$, 必须写出:

1. 外推点和梯度步;
2. θ_k 与辅助点 $\mathbf{v}^k$;
3. smoothness 导出的三点不等式;
4. 特殊比较点 $(1 - \theta_k)\mathbf{x}^{k-1} + \theta_k\mathbf{x}^*$;
5. 凸性;
6. 势函数递推;
7. $(1 - \theta_k)/\theta_k^2$ 的关系;
8. telescope 后的 $O(1/k^2)$ 。

49.8 强凸光滑情形的 Nesterov 加速

设 f 是 μ -strongly convex 和 L -smooth, 定义 $\kappa = \frac{L}{\mu}$ 。

令

$$q_\kappa = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}. \quad (49.43)$$

采用 [Opt-Sup] 的参数化:

$$\mathbf{y}^{k+1} = \mathbf{x}^k - \frac{1}{L} \nabla f(\mathbf{x}^k), \quad (49.44)$$

$$\mathbf{x}^{k+1} = \mathbf{y}^{k+1} + q_\kappa (\mathbf{y}^{k+1} - \mathbf{y}^k). \quad (49.45)$$


定理 49.3 (强凸光滑 Nesterov 收敛率). 若 $\mathbf{x}^1 = \mathbf{y}^1$, 则

$$f(\mathbf{y}^k) - f^* \leq \frac{\mu + L}{2} \|\mathbf{x}^1 - \mathbf{x}^*\|^2 \exp\left(-\frac{k-1}{\sqrt{\kappa}}\right). \quad (49.46)$$

因此要达到 $f(\mathbf{y}^k) - f^* \leq \varepsilon$, 所需一阶 oracle 次数为

$$K = O\left(\sqrt{\kappa} \log \frac{(\mu + L) \|\mathbf{x}^1 - \mathbf{x}^*\|^2}{\varepsilon}\right). \quad (49.47)$$

梯度下降对应 $O(\kappa \log \frac{1}{\varepsilon})$, 故 Nesterov 将条件数依赖从 κ 改善为 $\sqrt{\kappa}$ 。



易错点、反例与失败模式

一般凸 Nesterov 和强凸 Nesterov 的动量参数不同:

- 一般凸情形通常使用随 k 变化的 β_k ;
- 已知 μ, L 的强凸情形可使用常数 $\beta = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$.

把一般凸的 $\beta_k \rightarrow 1$ 直接用于强凸线性收敛定理, 或把强凸常数动量用于未知 μ 的一般凸定理, 都需要重新分析。

49.9 随机 Nesterov 加速

考虑 $f(\mathbf{x}) = \mathbb{E}_\xi[F(\mathbf{x}; \xi)]$, 随机梯度满足

$$\mathbb{E}[\nabla F(\mathbf{y}^k; \xi^k) \mid \mathcal{F}_k] = \nabla f(\mathbf{y}^k), \quad (49.48)$$

$$\mathbb{E}[\|\nabla F(\mathbf{y}^k; \xi^k) - \nabla f(\mathbf{y}^k)\|^2 \mid \mathcal{F}_k] \leq \sigma^2. \quad (49.49)$$

[Opt-Alg] 给出的随机 Nesterov 课程形式可写为

$$\mathbf{y}^k = (1 - \theta_k)\mathbf{x}^{k-1} + \theta_k\mathbf{v}^{k-1}, \quad (49.50)$$

$$\mathbf{x}^k = \mathbf{y}^k - \gamma_k \nabla F(\mathbf{y}^k; \xi^k), \quad (49.51)$$

$$\mathbf{v}^k = \theta_k^{-1}\mathbf{x}^k + (1 - \theta_k^{-1})\mathbf{x}^{k-1}. \quad (49.52)$$

在 L -smooth、凸、条件无偏和有界方差下, 适当选择参数可得到示意性速率

$$\mathbb{E}[f(\mathbf{x}^K) - f^*] = O\left(\frac{\sigma}{\sqrt{K}} + \frac{LR_0^2}{K^2}\right), \quad (49.53)$$

其中 $R_0 = \|\mathbf{x}^0 - \mathbf{x}^*\|$ 。

标准凸 SGD 的对应结构为

$$\mathbb{E}[f(\bar{\mathbf{x}}^K) - f^*] = O\left(\frac{\sigma R_0}{\sqrt{K}} + \frac{LR_0^2}{K}\right). \quad (49.54)$$

因此:

- 确定性项从 $O(1/K)$ 加速到 $O(1/K^2)$;
- 随机噪声项仍为 $O(1/\sqrt{K})$;
- 当 K 很大且 $\sigma > 0$ 时, 随机项占主导;
- 仅增加动量不能突破一般随机 oracle 的噪声瓶颈。

易错点、反例与失败模式

“随机 Nesterov 有 $O(1/K^2)$ 收敛”是不完整甚至错误的表述。

正确表述必须同时写出噪声项: $O\left(\frac{\sigma}{\sqrt{K}} + \frac{1}{K^2}\right)$ 。

只有在 $\sigma = 0$ 或噪声足够小、迭代次数处于确定性项主导区间时, 才能观察到明显的加速项。

49.10 Momentum 题的答题方法

答题方法

对于 [26S-B-Q1(c), 2 分] 一类简答题，可在有限篇幅内写：

$\mathbf{m}^{k+1} = \beta \mathbf{m}^k + \nabla F(\mathbf{x}^k; \xi^k)$, $\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \mathbf{m}^{k+1}$, 其中 $0 \leq \beta < 1$ 。

展开可得 $\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \nabla F(\mathbf{x}^k; \xi^k) + \beta (\mathbf{x}^k - \mathbf{x}^{k-1})$ 。

动量对历史梯度作指数加权平均： $\mathbf{m}^{k+1} = \sum_{t=0}^k \beta^{k-t} \nabla F(\mathbf{x}^t; \xi^t)$ 。

在狭长等高线中，高曲率方向的梯度经常换号而相互抵消，低曲率方向的梯度长期同号而累积，因此动量可减小 zig-zag 并提高有效推进速度。

若题目要求区分 Nesterov，再补充：Nesterov 在外推点 $\mathbf{y}^k = \mathbf{x}^k + \beta(\mathbf{x}^k - \mathbf{x}^{k-1})$ 计算梯度，而普通 Momentum 在 $\mathbf{x}^k$ 计算梯度。



第五十章 预条件方法与随机坐标下降

50.1 重要性等级

重要性等级: B

- 预条件是理解 AdaGrad、RMSProp、Adam 的统一数学框架。
- 坐标下降列入考纲，重点是更新代价、无偏估计器、坐标光滑性和非均匀采样。
- 三套博资考尚未直接要求完整坐标下降证明，但 importance sampling、随机梯度方差和条件数已在 [25F-C-Q3-Q9, 共 28 分] 中成组出现，坐标采样是同类母题。

50.2 预条件梯度法的变量替换推导

考虑

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}). \quad (50.1)$$

取对称正定矩阵 $\mathbf{P} \succ 0$, 作变量替换

$$\mathbf{x} = \mathbf{P}^{1/2} \mathbf{w}, \quad g(\mathbf{w}) = f(\mathbf{P}^{1/2} \mathbf{w}). \quad (50.2)$$

链式法则给出

$$\nabla g(\mathbf{w}) = \mathbf{P}^{1/2} \nabla f(\mathbf{P}^{1/2} \mathbf{w}). \quad (50.3)$$

在 $\mathbf{w}$ 上执行梯度下降:


$$\begin{aligned} \mathbf{w}^{k+1} &= \mathbf{w}^k - \gamma \nabla g(\mathbf{w}^k) \\ &= \mathbf{w}^k - \gamma \mathbf{P}^{1/2} \nabla f(\mathbf{x}^k). \end{aligned} \quad (50.4)$$

左乘 $\mathbf{P}^{1/2}$:

$$\boxed{\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma \mathbf{P} \nabla f(\mathbf{x}^k).} \quad (50.5)$$

随机版本为

$$\boxed{\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma_k \mathbf{P}_k \nabla F(\mathbf{x}^k; \xi^k).} \quad (50.6)$$



50.3 预条件度量与下降条件

定义

$$\|\mathbf{u}\|_{P^{-1}}^2 = \mathbf{u}^\top \mathbf{P}^{-1} \mathbf{u}, \quad (50.7)$$

$$\|\mathbf{g}\|_P^2 = \mathbf{g}^\top \mathbf{P} \mathbf{g}. \quad (50.8)$$

假设 f 在该度量下满足

$$f(\mathbf{x} + \mathbf{u}) \leq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{u} \rangle + \frac{L_P}{2} \|\mathbf{u}\|_{P^{-1}}^2. \quad (50.9)$$

取 $\mathbf{u} = -\frac{1}{L_P} \mathbf{P} \nabla f(\mathbf{x})$, 则

$$\begin{aligned} f(\mathbf{x}^+) &\leq f(\mathbf{x}) - \frac{1}{L_P} \|\nabla f(\mathbf{x})\|_P^2 + \frac{1}{2L_P} \|\nabla f(\mathbf{x})\|_P^2 \\ &= \boxed{f(\mathbf{x}) - \frac{1}{2L_P} \|\nabla f(\mathbf{x})\|_P^2}. \end{aligned} \quad (50.10)$$

正定性不能省略, 因为下降方向需满足

$$\langle \nabla f(\mathbf{x}), -\mathbf{P} \nabla f(\mathbf{x}) \rangle = -\nabla f(\mathbf{x})^\top \mathbf{P} \nabla f(\mathbf{x}) < 0 \quad (50.11)$$

对所有非零梯度成立。

若 $\mathbf{P}$ 非对称或不定, $\nabla f^\top \mathbf{P} \nabla f$ 可能非正, 从而更新方向可能不是下降方向。

50.4 预条件如何改善条件数

对二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x}$, $\mathbf{Q} \succ 0$, 变量替换后的 Hessian 为

$$\nabla^2 g(\mathbf{w}) = \mathbf{P}^{1/2} \mathbf{Q} \mathbf{P}^{1/2}. \quad (50.12)$$

预条件后的有效条件数是

$$\kappa_{\text{eff}} = \frac{\lambda_{\max}(\mathbf{P}^{1/2} \mathbf{Q} \mathbf{P}^{1/2})}{\lambda_{\min}(\mathbf{P}^{1/2} \mathbf{Q} \mathbf{P}^{1/2})}. \quad (50.13)$$

理想取值 $\mathbf{P} = \mathbf{Q}^{-1}$ 使 $\mathbf{P}^{1/2} \mathbf{Q} \mathbf{P}^{1/2} = \mathbf{I}$, $\kappa_{\text{eff}} = 1$ 。

此时取 $\gamma = 1$:

$$\begin{aligned} \mathbf{x}^{k+1} &= \mathbf{x}^k - \mathbf{Q}^{-1}(\mathbf{Q} \mathbf{x}^k + \mathbf{c}) \\ &= -\mathbf{Q}^{-1} \mathbf{c} = \mathbf{x}^*. \end{aligned} \quad (50.14)$$

即正定二次型在一步内达到最优点。


50.4.1 Newton 方法

若在每轮取

$$\mathbf{P}_k = [\nabla^2 f(\mathbf{x}^k)]^{-1}, \quad (50.15)$$

则

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \gamma_k [\nabla^2 f(\mathbf{x}^k)]^{-1} \nabla f(\mathbf{x}^k), \quad (50.16)$$



即 Newton 方法。

但其每步通常需要：

- 构造 Hessian；
- 解 $d \times d$ 线性系统；
- 稠密情形时间复杂度约为 $O(d^3)$ ；
- 存储复杂度约为 $O(d^2)$ 。

因此深度学习中通常采用对角或低秩近似预条件器。

易错点、反例与失败模式

预条件矩阵不是越接近 Hessian 逆就必然越好。

还需考虑：

- 构造和存储成本；
- 数值误差；
- Hessian 非正定；
- 随机梯度噪声；
- 预条件器随迭代快速变化；
- 参数尺度和坐标表示依赖。

50.5 随机坐标下降的基本形式

设 $\nabla_i f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial x_i}$, $\mathbf{e}_i$ 为第 i 个标准基向量。

均匀随机坐标下降 (random coordinate descent, RCD) 为

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \eta \nabla_{i_k} f(\mathbf{x}^k) \mathbf{e}_{i_k}, \quad i_k \sim \text{Unif}\{1, \dots, d\}. \quad (50.17)$$

定义随机向量

$$\tilde{\mathbf{g}}(\mathbf{x}) = d \nabla_I f(\mathbf{x}) \mathbf{e}_I, \quad I \sim \text{Unif}\{1, \dots, d\}. \quad (50.18)$$

则

$$\mathbb{E}[\tilde{\mathbf{g}}(\mathbf{x})] = \frac{1}{d} \sum_{i=1}^d d \nabla_i f(\mathbf{x}) \mathbf{e}_i = \nabla f(\mathbf{x}). \quad (50.19)$$

并且

$$\mathbb{E}\|\tilde{\mathbf{g}}(\mathbf{x})\|^2 = d \|\nabla f(\mathbf{x})\|^2. \quad (50.20)$$

注意： $\mathbf{x}^+ = \mathbf{x} - \eta \nabla_I f(\mathbf{x}) \mathbf{e}_I$ 若写成标准 SGD $\mathbf{x}^+ = \mathbf{x} - \tilde{\eta} \tilde{\mathbf{g}}(\mathbf{x})$, 则需取 $\tilde{\eta} = \frac{\eta}{d}$ 。

易错点、反例与失败模式

“RCD 的坐标梯度本身是全梯度的无偏估计”不准确。

$\nabla_I f(\mathbf{x}) \mathbf{e}_I$ 的期望是 $\frac{1}{d} \nabla f(\mathbf{x})$, 而不是 $\nabla f(\mathbf{x})$ 。

无偏版本必须乘 d : $d\nabla_I f(\mathbf{x})\mathbf{e}_I$ 。

50.6 坐标光滑性

定义 50.1 (坐标光滑性). 若存在 $L_1, \dots, L_d > 0$, 使对所有 $\mathbf{x}, u \in \mathbb{R}$ 和 i ,

$$|\nabla_i f(\mathbf{x} + u\mathbf{e}_i) - \nabla_i f(\mathbf{x})| \leq L_i |u|, \quad (50.21)$$

则称 f 在第 i 个坐标上 L_i -smooth。

等价的单坐标 descent lemma 为

$$f(\mathbf{x} + u\mathbf{e}_i) \leq f(\mathbf{x}) + u\nabla_i f(\mathbf{x}) + \frac{L_i}{2} u^2. \quad (50.22)$$

取 $u = -\frac{1}{L_i} \nabla_i f(\mathbf{x})$, 得到

$$f\left(\mathbf{x} - \frac{1}{L_i} \nabla_i f(\mathbf{x})\mathbf{e}_i\right) \leq f(\mathbf{x}) - \frac{1}{2L_i} [\nabla_i f(\mathbf{x})]^2. \quad (50.23)$$

若 f 二阶可微, 则坐标光滑性可由

$$[\nabla^2 f(\mathbf{x})]_{ii} \leq L_i \quad (50.24)$$

保证。

50.7 非均匀坐标采样

令采样指数 $a \geq 0$, 定义

$$p_i^{(a)} = \frac{L_i^a}{\sum_{j=1}^d L_j^a}. \quad (50.25)$$

算法为

$$i_k \sim p^{(a)}, \quad \mathbf{x}^{k+1} = \mathbf{x}^k - \frac{1}{L_{i_k}} \nabla_{i_k} f(\mathbf{x}^k) \mathbf{e}_{i_k}. \quad (50.26)$$

记

$$S_a = \sum_{i=1}^d L_i^a. \quad (50.27)$$


由 (50.23),

$$\begin{aligned} \mathbb{E}_k[f(\mathbf{x}^{k+1})] &\leq f(\mathbf{x}^k) - \frac{1}{2} \sum_{i=1}^d p_i^{(a)} \frac{[\nabla_i f(\mathbf{x}^k)]^2}{L_i} \\ &= f(\mathbf{x}^k) - \frac{1}{2S_a} \sum_{i=1}^d L_i^{a-1} [\nabla_i f(\mathbf{x}^k)]^2. \end{aligned} \quad (50.28)$$

定义加权范数

$$\|\mathbf{x}\|_{[1-a]}^2 = \sum_{i=1}^d L_i^{1-a} x_i^2, \quad (50.29)$$

$$\|\mathbf{g}\|_{*, [1-a]}^2 = \sum_{i=1}^d L_i^{a-1} g_i^2. \quad (50.30)$$



则

$$\mathbb{E}_k[f(\mathbf{x}^{k+1})] \leq f(\mathbf{x}^k) - \frac{1}{2S_a} \|\nabla f(\mathbf{x}^k)\|_{*,[1-a]}^2. \quad (50.31)$$

50.8 一般凸情形的 $O(1/K)$ 收敛

设 $f(\mathbf{x}^k) \leq f(\mathbf{x}^1)$ 沿迭代成立, 并定义下水平集半径

$$R_{1-a}(\mathbf{x}^1) = \sup_{\mathbf{x}: f(\mathbf{x}) \leq f(\mathbf{x}^1)} \|\mathbf{x} - \mathbf{x}^*\|_{[1-a]}. \quad (50.32)$$

由凸性,

$$\begin{aligned} f(\mathbf{x}^k) - f^* &\leq \langle \nabla f(\mathbf{x}^k), \mathbf{x}^k - \mathbf{x}^* \rangle \\ &\leq \|\nabla f(\mathbf{x}^k)\|_{*,[1-a]} \|\mathbf{x}^k - \mathbf{x}^*\|_{[1-a]} \\ &\leq R_{1-a}(\mathbf{x}^1) \|\nabla f(\mathbf{x}^k)\|_{*,[1-a]}. \end{aligned} \quad (50.33)$$

记 $\delta_k = \mathbb{E}[f(\mathbf{x}^k) - f^*]$ 。由 (50.31) 和 Jensen 不等式, 可得

$$\delta_{k+1} \leq \delta_k - \frac{\delta_k^2}{2S_a R_{1-a}^2(\mathbf{x}^1)}. \quad (50.34)$$

标准倒数递推给出

$$\mathbb{E}[f(\mathbf{x}^K) - f^*] \leq \frac{2R_{1-a}^2(\mathbf{x}^1)S_a}{K-1}, \quad K \geq 2. \quad (50.35)$$

50.9 强凸情形的线性收敛

假设 f 关于 $\|\cdot\|_{[1-a]}$ 是 μ_a -strongly convex, 即

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu_a}{2} \|\mathbf{y} - \mathbf{x}\|_{[1-a]}^2. \quad (50.36)$$

强凸性推出加权 Polyak–Łojasiewicz 型不等式

$$\|\nabla f(\mathbf{x})\|_{*,[1-a]}^2 \geq 2\mu_a [f(\mathbf{x}) - f^*]. \quad (50.37)$$

代入 (50.31):

$$\mathbb{E}_k[f(\mathbf{x}^{k+1}) - f^*] \leq \left(1 - \frac{\mu_a}{S_a}\right) [f(\mathbf{x}^k) - f^*]. \quad (50.38)$$

定义坐标条件数


$$\kappa_a = \frac{S_a}{\mu_a}, \quad (50.39)$$

则

$$\mathbb{E}[f(\mathbf{x}^{K+1}) - f^*] \leq \left(1 - \frac{1}{\kappa_a}\right)^K [f(\mathbf{x}^1) - f^*]. \quad (50.40)$$

相应迭代复杂度为

$$K = O\left(\kappa_a \log \frac{1}{\varepsilon}\right). \quad (50.41)$$



50.10 坐标方法的实际复杂度

设完整梯度计算代价为 C_{full} ，单坐标偏导代价为 C_i 。

每轮 RCD:

- 只计算一个坐标偏导;
- 参数更新只改变一个坐标;
- 抽样分布预处理代价约为 $O(d)$;
- 使用前缀和或树结构抽样可约为 $O(\log d)$ 。

总时间不能只看迭代次数:

$$\text{总成本} = \text{迭代次数} \times \text{每轮坐标代价}. \quad (50.42)$$

即使 RCD 需要比 GD 更多迭代，若 $C_i \ll C_{\text{full}}$ ，总运行时间仍可能更小。

易错点、反例与失败模式

以下两种复杂度不能混为一谈:

- 坐标更新次数;
- 等价 full-gradient pass 数。

例如 d 次单坐标更新在最坏情况下才大致相当于一次全坐标扫描，但稀疏结构、缓存和增量计算可能显著改变这一比较。



第五十一章 AdaGrad、RMSProp、Adam 与 AdamW

51.1 重要性等级与统一视角

重要性等级：A

- AdaGrad、RMSProp、Adam、AdamW 均属于考纲核心。
- 必须会写目标、状态变量、逐坐标更新和超参数。
- 必须区分经验优势与数学保证。
- 必须解释 bias correction。
- 必须严格区分 AdamW 的 decoupled weight decay 与对目标加入 ℓ_2 penalty。

这些算法可以统一写成对角预条件更新：

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha_k \mathbf{P}_k \mathbf{d}^k, \quad (51.1)$$

其中：

- $\mathbf{d}^k$ 是当前梯度或动量平滑方向；
- $\mathbf{P}_k$ 是对角正定预条件器；
- 不同算法的核心差别是 $\mathbf{d}^k$ 和 $\mathbf{P}_k$ 如何构造。

51.2 AdaGrad

51.2.1 更新公式

令 $\mathbf{g}^k = \nabla F(\mathbf{x}^k; \xi^k) \in \mathbb{R}^d$ 。


初始化 $\mathbf{s}^0 = \mathbf{0}$ 。AdaGrad 更新为

$$\mathbf{s}^k = \mathbf{s}^{k-1} + \mathbf{g}^k \odot \mathbf{g}^k, \quad (51.2)$$

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha \frac{\mathbf{g}^k}{\sqrt{\mathbf{s}^k} + \varepsilon_{\text{adam}}}. \quad (51.3)$$

所有运算均逐坐标进行：

$$x_i^{k+1} = x_i^k - \frac{\alpha}{\sqrt{\sum_{t=1}^k (g_i^t)^2} + \varepsilon_{\text{adam}}} g_i^k. \quad (51.4)$$



对应预条件器为

$$\mathbf{P}_k = \text{diag} \left(\frac{1}{\sqrt{s_1^k} + \varepsilon_{\text{adam}}}, \dots, \frac{1}{\sqrt{s_d^k} + \varepsilon_{\text{adam}}} \right). \quad (51.5)$$

51.2.2 为什么适合稀疏特征

若第 i 个坐标频繁出现大梯度, 则 s_i^k 增长快, 其有效学习率 $\alpha_{k,i}^{\text{eff}} = \frac{\alpha}{\sqrt{s_i^k} + \varepsilon_{\text{adam}}}$ 迅速减小。

若第 j 个坐标很少出现非零梯度, 则 s_j^k 较小, 对该稀有坐标保留较大的更新步长。

因此 AdaGrad 可自动适配不同坐标的累计梯度尺度。

51.2.3 AdaGrad 的可核查 regret 保证

以下是根据附件更新式和投影非扩张性所作的推导补充。

考虑凸集合 $\mathcal{X}$, 在线凸损失 $f_1, \dots, f_T$ 。在 $\mathbf{x}^t$ 处取 $\mathbf{g}^t \in \partial f_t(\mathbf{x}^t)$ 。

定义

$$s_{t,i} = \delta^2 + \sum_{\tau=1}^t (g_i^\tau)^2, \quad (51.6)$$

$$h_{t,i} = \sqrt{s_{t,i}}, \quad (51.7)$$

$$\mathbf{H}_t = \text{diag}(h_{t,1}, \dots, h_{t,d}), \quad (51.8)$$

其中 $\delta > 0$ 。

采用变度量投影更新

$$\mathbf{x}^{t+1} = \arg \min_{\mathbf{x} \in \mathcal{X}} \left\{ \eta \langle \mathbf{g}^t, \mathbf{x} \rangle + \frac{1}{2} \|\mathbf{x} - \mathbf{x}^t\|_{\mathbf{H}_t}^2 \right\}. \quad (51.9)$$

假设对任意 $\mathbf{x}, \mathbf{y} \in \mathcal{X}$ 均有 $|x_i - y_i| \leq D_i$ 。

由变度量投影最优性可得

$$\begin{aligned} \langle \mathbf{g}^t, \mathbf{x}^t - \mathbf{x}^* \rangle &\leq \frac{1}{2\eta} [\|\mathbf{x}^t - \mathbf{x}^*\|_{\mathbf{H}_t}^2 - \|\mathbf{x}^{t+1} - \mathbf{x}^*\|_{\mathbf{H}_t}^2] \\ &\quad + \frac{\eta}{2} \|\mathbf{g}^t\|_{\mathbf{H}_t^{-1}}^2. \end{aligned} \quad (51.10)$$

对 t 求和时, 度量变化产生

$$\begin{aligned} &\sum_{t=1}^T [\|\mathbf{x}^t - \mathbf{x}^*\|_{\mathbf{H}_t}^2 - \|\mathbf{x}^{t+1} - \mathbf{x}^*\|_{\mathbf{H}_t}^2] \\ &\leq \sum_{i=1}^d D_i^2 h_{T,i}. \end{aligned} \quad (51.11)$$

另一方面,

$$\sum_{t=1}^T \frac{(g_i^t)^2}{h_{t,i}} \leq 2(h_{T,i} - \delta) \leq 2h_{T,i}. \quad (51.12)$$



由凸性 $f_t(\mathbf{x}^t) - f_t(\mathbf{x}^*) \leq \langle \mathbf{g}^t, \mathbf{x}^t - \mathbf{x}^* \rangle$, 故 regret 满足

$$\begin{aligned} \text{Regret}_T &:= \sum_{t=1}^T [f_t(\mathbf{x}^t) - f_t(\mathbf{x}^*)] \\ &\leq \sum_{i=1}^d \left(\frac{D_i^2}{2\eta} + \eta \right) \sqrt{\delta^2 + \sum_{t=1}^T (g_i^t)^2}. \end{aligned} \quad (51.13)$$

若 $D_i \leq D$, 选择 η 为 D 的常数量级, 得到

$$\text{Regret}_T = O \left(D \sum_{i=1}^d \sqrt{\sum_{t=1}^T (g_i^t)^2} \right). \quad (51.14)$$

若只有少量坐标长期活跃, 该界可显著优于统一欧氏界 $O \left(D \sqrt{d \sum_{t=1}^T \|\mathbf{g}^t\|^2} \right)$ 。

51.2.4 AdaGrad 的失败模式

易错点、反例与失败模式

AdaGrad 的累计量 $s_i^k = \sum_{t=1}^k (g_i^t)^2$ 单调不减。

因此即使后期目标进入新的区域, 早期大梯度仍永久保留, 使有效步长持续缩小。

若某坐标长期保持 $|g_i^t| \approx c > 0$, 则 $s_i^k \approx kc^2$, $\alpha_{k,i}^{\text{eff}} \approx \frac{\alpha}{|c|\sqrt{k}}$ 。

这有利于渐近稳定, 但在非平稳问题或深度网络中可能导致后期学习率衰减过于激进。

另一个常见错误是说: “使用 AdaGrad 后完全不需要调学习率。”

实际上仍需选择: α , $\varepsilon_{\text{adam}}$, 并需决定是否使用投影、裁剪和学习率调度。

51.3 RMSProp

51.3.1 更新公式

RMSProp 用指数移动平均替代永久累计:

$$\mathbf{s}^k = \beta_2 \mathbf{s}^{k-1} + (1 - \beta_2) \mathbf{g}^k \odot \mathbf{g}^k, \quad (51.15)$$

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha \frac{\mathbf{g}^k}{\sqrt{\mathbf{s}^k} + \varepsilon_{\text{adam}}}. \quad (51.16)$$

其中通常 $0 < \beta_2 < 1$ 。

若 $\mathbf{s}^0 = \mathbf{0}$, 则展开为

$$\mathbf{s}^k = (1 - \beta_2) \sum_{t=1}^k \beta_2^{k-t} \mathbf{g}^t \odot \mathbf{g}^t. \quad (51.17)$$

距当前 j 步之前的梯度平方权重为 $(1 - \beta_2) \beta_2^j$ 。

其有效记忆长度约为

$$O \left(\frac{1}{1 - \beta_2} \right). \quad (51.18)$$

因此 RMSProp:



- 遗忘很久以前的梯度；
- 能适应随训练阶段变化的梯度尺度；
- 避免 AdaGrad 分母永久增长。

51.3.2 RMSProp 的条件和局限

仅由更新式不能推出无条件收敛。

严谨分析通常至少需控制：

1. 目标下界和光滑性；
2. 随机梯度条件矩；
3. $\varepsilon_{\text{adam}} > 0$ ，防止分母为零；
4. 预条件器的上下界；
5. 基础步长 α_k ；
6. $\mathbf{s}^k$ 的时间变化；
7. 梯度与自适应分母之间的相关性。

若使用常数 α ，且随机噪声持续存在，通常只能期待邻域收敛或稳定振荡，而非精确达到最优点。

易错点、反例与失败模式

(Opt-Alg) 第 54 页展示的训练曲线只能说明：在该特定 MNIST 网络、数据、初始化和超参数下，若干优化器表现不同。

它不能推出：

- Adam 对所有问题都优于 SGD；
- RMSProp 一定收敛；
- 某条实验曲线代表理论复杂度；
- 某方法拥有更好的泛化定理。

51.4 Adam

51.4.1 完整带 Bias Correction 的主约定

令 $\mathbf{g}^k = \nabla F(\mathbf{x}^k; \xi^k)$ 。

初始化 $\mathbf{m}^0 = \mathbf{0}$, $\mathbf{s}^0 = \mathbf{0}$ 。

一阶矩和二阶原点矩估计为

$$\mathbf{m}^k = \beta_1 \mathbf{m}^{k-1} + (1 - \beta_1) \mathbf{g}^k, \quad (51.19)$$

$$\mathbf{s}^k = \beta_2 \mathbf{s}^{k-1} + (1 - \beta_2) \mathbf{g}^k \odot \mathbf{g}^k, \quad (51.20)$$

其中 $0 \leq \beta_1 < 1$, $0 \leq \beta_2 < 1$ 。



偏差校正量为

$$\widehat{\mathbf{m}}^k = \frac{\mathbf{m}^k}{1 - \beta_1^k}, \quad (51.21)$$

$$\widehat{\mathbf{s}}^k = \frac{\mathbf{s}^k}{1 - \beta_2^k}. \quad (51.22)$$

更新为

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha_k \frac{\widehat{\mathbf{m}}^k}{\sqrt{\widehat{\mathbf{s}}^k + \varepsilon_{\text{adam}}}}. \quad (51.23)$$

常见经验参数为 $\beta_1 = 0.9$, $\beta_2 = 0.999$, 但这些不是数学上对所有任务最优的常数。

说明 51.1 (附件中的简化版本). [Opt-Alg] 写出的 Adam 式未显式展示 $1 - \beta_1^k$, $1 - \beta_2^k$ 。[DL-Basic] 则明确给出 bias correction。

本讲义统一采用 (51.21)–(51.23)。若使用未校正版本, 必须明确说明。

51.4.2 Bias Correction 的严格来源

假设为便于说明, 梯度恒为固定向量 $\mathbf{g}^k = \mathbf{g}$ 。

由 $\mathbf{m}^0 = \mathbf{0}$ 递推:

$$\begin{aligned} \mathbf{m}^k &= (1 - \beta_1) \sum_{t=1}^k \beta_1^{k-t} \mathbf{g} \\ &= (1 - \beta_1) \frac{1 - \beta_1^k}{1 - \beta_1} \mathbf{g} \\ &= (1 - \beta_1^k) \mathbf{g}. \end{aligned} \quad (51.24)$$

同理,

$$\mathbf{s}^k = (1 - \beta_2^k) \mathbf{g} \odot \mathbf{g}. \quad (51.25)$$

因此未校正量满足 $\mathbf{m}^k \rightarrow \mathbf{g}$, $\mathbf{s}^k \rightarrow \mathbf{g} \odot \mathbf{g}$, 但早期被初始化零向量系统性压小。

校正后:

$$\widehat{\mathbf{m}}^k = \mathbf{g}, \quad (51.26)$$

$$\widehat{\mathbf{s}}^k = \mathbf{g} \odot \mathbf{g}. \quad (51.27)$$

若随机梯度是同分布序列, 且 $\mathbb{E}[\mathbf{g}^k] = \boldsymbol{\mu}_g$, $\mathbb{E}[\mathbf{g}^k \odot \mathbf{g}^k] = \boldsymbol{\nu}_g$, 则

$$\mathbb{E}[\mathbf{m}^k] = (1 - \beta_1^k) \boldsymbol{\mu}_g, \quad (51.28)$$

$$\mathbb{E}[\mathbf{s}^k] = (1 - \beta_2^k) \boldsymbol{\nu}_g. \quad (51.29)$$

这正是 bias correction 中两个分母的来源。

易错点、反例与失败模式

Bias correction 校正的是由于 $\mathbf{m}^0 = \mathbf{s}^0 = \mathbf{0}$ 造成的初始化偏差。

它不意味着:

- $\widehat{\mathbf{m}}^k$ 是当前真实梯度的无偏估计;

- $\hat{s}^k$ 是条件方差；
- Adam 的最终更新方向是无偏的。

事实上 $\frac{\hat{m}^k}{\sqrt{\hat{s}^k + \varepsilon_{\text{adam}}}}$ 是随机比值，通常不是 $\frac{\mathbb{E}[\hat{m}^k]}{\sqrt{\mathbb{E}[\hat{s}^k] + \varepsilon_{\text{adam}}}}$ 的无偏估计。

51.4.3 Adam 的逐坐标有效步长

第 i 个坐标更新为

$$x_i^{k+1} = x_i^k - \underbrace{\frac{\alpha_k}{\sqrt{\hat{s}_i^k + \varepsilon_{\text{adam}}}}}_{\text{有效学习率}} \hat{m}_i^k. \quad (51.30)$$

因此：

- 二阶矩大时，步长减小；
- 二阶矩小时，步长增大；
- 一阶矩平滑梯度符号和方向；
- $\varepsilon_{\text{adam}}$ 同时承担数值稳定和最大步长控制作用。

51.5 自适应归一化的一个严格反例

反例 51.2 (固定步长归一化更新可能不收敛). 考虑一维强凸函数

$$f(x) = \frac{1}{2}x^2. \quad (51.31)$$

取 Adam 的特殊参数 $\beta_1 = \beta_2 = 0$, $\varepsilon_{\text{adam}} = 0$, $\alpha_k \equiv \alpha > 0$ 。

则 $g^k = x^k$, $\hat{m}^k = x^k$, $\hat{s}^k = (x^k)^2$ 。

只要 $x^k \neq 0$, 更新为

$$x^{k+1} = x^k - \alpha \frac{x^k}{|x^k|} = x^k - \alpha \text{sign}(x^k). \quad (51.32)$$

设 $x^0 = q\alpha + r$, $q \in \mathbb{N}$, $0 < r < \alpha$ 。则经过 q 步后 $x^q = r$ 。接下来 $x^{q+1} = r - \alpha < 0$, 而 $x^{q+2} = r - \alpha + \alpha = r$ 。


因此序列在 r 与 $r - \alpha$ 之间形成二周期，不收敛到最优点 0。

该反例说明：

- 强凸性本身不能保证固定步长归一化方法收敛；
- $\varepsilon_{\text{adam}}$ 不能机械省略；
- 基础学习率可能需要衰减；
- 自适应归一化改变了“梯度越小，更新越小”的普通 GD 性质。

若 $\varepsilon_{\text{adam}} > 0$, 该特殊更新变成 $x^{k+1} = x^k - \alpha \frac{x^k}{|x^k| + \varepsilon_{\text{adam}}}$ 。在 x 接近零时, $x^{k+1} \approx \left(1 - \frac{\alpha}{\varepsilon_{\text{adam}}}\right) x^k$ 。局部稳定至少要求 $0 < \frac{\alpha}{\varepsilon_{\text{adam}}} < 2$ 。

这进一步表明 α 和 $\varepsilon_{\text{adam}}$ 共同决定局部稳定性。



51.6 Adam 类方法的收敛假设模板

附件没有给出 Adam 对所有凸或非凸目标的统一收敛定理，因此考试中不得仅写“Adam 一定收敛”。

可核查的分析通常需要下列条件中的若干项：

1. **目标正则性。** f 下有界、可微且 L -smooth；凸结论还需凸性，线性率通常还需强凸性。
2. **随机梯度条件。** $\mathbb{E}_k[\mathbf{g}^k] = \nabla f(\mathbf{x}^k)$ ，以及二阶矩或方差控制。
3. **预条件器有界。** 存在 $0 < p_{\min} \leq p_{\max} < \infty$ 使 $p_{\min} \mathbf{I} \preceq \mathbf{P}_k \preceq p_{\max} \mathbf{I}$ 。
4. **基础步长控制。** 随机逼近中常见条件为 $\alpha_k \downarrow 0$ ， $\sum_{k=1}^{\infty} \alpha_k = \infty$ ， $\sum_{k=1}^{\infty} \alpha_k^2 < \infty$ 。这些条件不能自动由 Adam 更新产生。
5. **动量误差控制。** 需证明 $\mathbf{m}^k$ 与当前梯度保持充分对齐，而不能无限滞后。
6. **预条件器变化控制。** 需限制 $\|\mathbf{P}_{k+1} - \mathbf{P}_k\|$ 或建立可 telescope 的势函数。
7. **数值安全。** $\varepsilon_{\text{adam}} > 0$ 防止除零，并控制极小二阶矩坐标的最大有效步长。

对精确梯度预条件更新 $\mathbf{x}^+ = \mathbf{x} - \alpha \mathbf{P} \nabla f(\mathbf{x})$ ，若 $p_{\min} \mathbf{I} \preceq \mathbf{P} \preceq p_{\max} \mathbf{I}$ ，由欧氏 L -smoothness：

$$\begin{aligned} f(\mathbf{x}^+) &\leq f(\mathbf{x}) - \alpha \nabla f(\mathbf{x})^\top \mathbf{P} \nabla f(\mathbf{x}) + \frac{L\alpha^2}{2} \|\mathbf{P} \nabla f(\mathbf{x})\|^2 \\ &\leq f(\mathbf{x}) - \left(\alpha p_{\min} - \frac{L\alpha^2 p_{\max}^2}{2} \right) \|\nabla f(\mathbf{x})\|^2. \end{aligned} \quad (51.33)$$

因此一个简单充分条件是

$$0 < \alpha < \frac{2p_{\min}}{Lp_{\max}^2}. \quad (51.34)$$

对 Adam，由于 $\mathbf{P}_k$ 和 $\mathbf{m}^k$ 均随历史随机梯度变化，证明比 (51.33) 复杂得多。

51.7 AdamW 与 ℓ_2 Regularization

51.7.1 普通 SGD 中的等价性

考虑带 ℓ_2 penalty 的目标

$$\tilde{f}(\mathbf{x}) = f(\mathbf{x}) + \frac{\lambda}{2} \|\mathbf{x}\|^2. \quad (51.35)$$

其梯度为 $\nabla \tilde{f}(\mathbf{x}) = \nabla f(\mathbf{x}) + \lambda \mathbf{x}$ 。

普通 SGD 或 GD 更新为

$$\begin{aligned} \mathbf{x}^{k+1} &= \mathbf{x}^k - \alpha [\mathbf{g}^k + \lambda \mathbf{x}^k] \\ &= (1 - \alpha\lambda) \mathbf{x}^k - \alpha \mathbf{g}^k. \end{aligned} \quad (51.36)$$

因此在无预条件、无复杂动量耦合的普通 SGD 中， ℓ_2 penalty 与乘法 weight decay 等价。



51.7.2 自适应预条件器中的不等价性

设 $\mathbf{P}_k = \text{diag} \left(\frac{1}{\sqrt{\hat{s}_i^k} + \varepsilon_{\text{adam}}} \right)$ 。

若把 ℓ_2 penalty 梯度和数据梯度一起预条件，简化写法为

$$\begin{aligned} \mathbf{x}^{k+1} &= \mathbf{x}^k - \alpha_k \mathbf{P}_k (\mathbf{d}^k + \lambda \mathbf{x}^k) \\ &= (\mathbf{I} - \alpha_k \lambda \mathbf{P}_k) \mathbf{x}^k - \alpha_k \mathbf{P}_k \mathbf{d}^k. \end{aligned} \quad (51.37)$$

第 i 个坐标的收缩因子为 $1 - \alpha_k \lambda P_{k,ii}$ ，因此不同坐标受到不同强度的“正则化”。

AdamW 使用 decoupled weight decay:

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha_k \frac{\widehat{\mathbf{m}}^k}{\sqrt{\hat{\mathbf{s}}^k} + \varepsilon_{\text{adam}}} - \alpha_k \lambda \mathbf{x}^k. \quad (51.38)$$

即

$$\mathbf{x}^{k+1} = (1 - \alpha_k \lambda) \mathbf{x}^k - \alpha_k \mathbf{P}_k \widehat{\mathbf{m}}^k. \quad (51.39)$$

AdamW 的参数收缩不经过 $\mathbf{P}_k$ ，故所有坐标使用相同的乘法衰减因子。

51.7.3 实际耦合比上述代数更强

若直接把 $\lambda \mathbf{x}^k$ 加入 Adam 的原始梯度： $\tilde{\mathbf{g}}^k = \mathbf{g}^k + \lambda \mathbf{x}^k$ ，则它不仅进入最终更新，还进入

$$\mathbf{m}^k = \beta_1 \mathbf{m}^{k-1} + (1 - \beta_1) \tilde{\mathbf{g}}^k, \quad (51.40)$$

$$\mathbf{s}^k = \beta_2 \mathbf{s}^{k-1} + (1 - \beta_2) \tilde{\mathbf{g}}^k \odot \tilde{\mathbf{g}}^k. \quad (51.41)$$

因此 regularization gradient 会同时改变：

- 一阶矩；
- 二阶矩；
- 未来若干轮的预条件器；
- 每个坐标的有效学习率。

AdamW 则将 weight decay 从 moment estimation 中解耦。

易错点、反例与失败模式

以下说法只对普通 SGD 的简单情形成立：weight decay = ℓ_2 regularization。

对 Adam、RMSProp 等坐标自适应方法，一般有 $\mathbf{I} - \alpha \lambda \mathbf{P}_k \neq (1 - \alpha \lambda) \mathbf{I}$ 。

只有当 $\mathbf{P}_k = \mathbf{I}$ 或为适当常数倍单位阵并同步换算 λ 时，两者才可能等价。

51.8 自适应方法对比




表 51.1: AdaGrad、RMSProp、Adam 与 AdamW 对比

方法	状态量与方向	主要优点	主要失败模式
AdaGrad	$s_i^k = \sum_{t \leq k} (g_i^t)^2$, $d_i^k = g_i^k / \sqrt{s_i^k}$	利用整个历史；稀疏坐标获得较大步长；有数据依赖 regret 界	分母永久增长；后期学习率可能过小；非平稳目标适应慢
RMSProp	$s^k = \beta_2 s^{k-1} + (1 - \beta_2)(g^k)^2$	遗忘早期梯度；适应当前梯度尺度；避免 AdaGrad 永久衰减	固定步长可振荡；一般收敛需额外假设；对 $\beta_2, \alpha, \varepsilon_{\text{adam}}$ 敏感
Adam	一阶 EMA m^k 加二阶 EMA s^k 并 bias correction	同时平滑方向和调节坐标尺度；对稀疏和异尺度梯度常较稳定	归一化可使小梯度仍产生大步；固定步长不保证精确收敛；moment 与当前梯度存在滞后
AdamW	Adam 更新加独立参数衰减 $-\alpha_k \lambda x^k$	将参数收缩与自适应预条件解耦；weight decay 更易解释	仍继承 Adam 的步长和 moment 问题； λ 与学习率共同决定实际衰减

51.9 自适应算法题的答题方法

答题方法

若题目要求“写出 Adam 并解释各项”，答案至少应包含：

1. 随机梯度： $g^k = \nabla F(x^k; \xi^k)$;
2. 一阶矩： $m^k = \beta_1 m^{k-1} + (1 - \beta_1)g^k$;
3. 二阶原点矩： $s^k = \beta_2 s^{k-1} + (1 - \beta_2)g^k \odot g^k$;
4. bias correction: $\hat{m}^k = \frac{m^k}{1 - \beta_1^k}$, $\hat{s}^k = \frac{s^k}{1 - \beta_2^k}$;
5. 参数更新: $x^{k+1} = x^k - \alpha_k \frac{\hat{m}^k}{\sqrt{\hat{s}^k + \varepsilon_{\text{adam}}}}$;
6. 说明所有平方、开方和除法逐坐标进行；
7. 说明 β_1 控制一阶动量记忆， β_2 控制二阶尺度记忆；
8. 说明 bias correction 修正零初始化导致的早期缩小；
9. 若比较 AdamW，写出 $-\alpha_k \lambda x^k$ 是独立衰减项，不经过自适应分母；
10. 写出至少一个失败模式：固定步长噪声层、分母过小、moment 滞后或非平稳梯度。



第五十二章 优化方向复杂度总表、实考母题与易错点

52.1 确定性一阶方法复杂度总表

以下令：

- $R = \|\mathbf{x}^0 - \mathbf{x}^*\|$ 或可行域半径；
- G 为次梯度范数上界；
- L 为 smoothness；
- μ 为 strong convexity；
- $\kappa = L/\mu$ ；
- K 为迭代次数。

表 52.1: 确定性一阶优化方法复杂度

方法	目标类别	典型保证	达到 ε 的迭代复杂度
Projected subgradient	凸、 G -Lipschitz	$f(\bar{x}^K) - f^* = O\left(\frac{RG}{\sqrt{K}}\right)$	$O\left(\frac{R^2 G^2}{\varepsilon^2}\right)$
加权次梯度法	μ -强凸、非光滑	$f(\bar{x}^K) - f^* = O\left(\frac{G^2}{\mu K}\right)$	$O\left(\frac{G^2}{\mu \varepsilon}\right)$
Gradient descent	凸、 L -smooth	$f(x^K) - f^* = O\left(\frac{LR^2}{K}\right)$	$O\left(\frac{LR^2}{\varepsilon}\right)$
Nesterov acceleration	凸、 L -smooth	$f(x^K) - f^* \leq \frac{2LR^2}{(K+1)^2}$	$O\left(\sqrt{\frac{LR^2}{\varepsilon}}\right)$
Gradient descent	μ -强凸、 L -smooth	$f(x^K) - f^* = O\left(e^{-K/\kappa}\right)$	$O\left(\kappa \log \frac{1}{\varepsilon}\right)$
Nesterov acceleration	μ -强凸、 L -smooth	$f(y^K) - f^* = O\left(e^{-K/\sqrt{\kappa}}\right)$	$O\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right)$
Proximal gradient	f smooth convex, R proper closed convex	$F(x^K) - F^* = O\left(\frac{1}{K}\right)$	$O\left(\frac{1}{\varepsilon}\right)$
Accelerated proximal gradient	复合凸目标	$F(x^K) - F^* = O\left(\frac{1}{K^2}\right)$	$O\left(\frac{1}{\sqrt{\varepsilon}}\right)$
Heavy-Ball	固定正定二次型	最优参数的渐近谱半径 $\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$	二次型上为 $O\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right)$ 量级； 一般目标不可直接外推
Random coordinate descent	坐标光滑凸	$\mathbb{E}[f(x^K) - f^*] \leq \frac{2R_{1-a}^2 \sum_i L_i^a}{K-1}$	$O\left(\frac{R_{1-a}^2 \sum_i L_i^a}{\varepsilon}\right)$

方法	目标类别	典型保证	达到 ε 的迭代复杂度
Random coordinate descent	加权强凸	$\mathbb{E}[f(x^K) - f^*] \leq \left(1 - \frac{1}{\kappa_a}\right)^K \Delta_0$	$O(\kappa_a \log \frac{1}{\varepsilon})$

52.2 随机方法复杂度总表

表 52.2: 随机一阶方法的典型保证

方法	假设	典型期望保证	关键限制
SGD	非凸、 L -smooth、方差 σ^2	$\frac{1}{K} \sum_{k < K} \mathbb{E} \ \nabla f(x^k)\ ^2 = O\left(\frac{\sigma}{\sqrt{K}} + \frac{1}{K}\right)$	只保证一阶驻点指标, 不保证全局最优
SGD	凸、 L -smooth	$\mathbb{E}[f(\bar{x}^K) - f^*] = O\left(\frac{\sigma R}{\sqrt{K}} + \frac{LR^2}{K}\right)$	通常输出平均点; 噪声项为 $K^{-1/2}$
SGD	强凸、光滑	$\tilde{O}\left(\frac{L\sigma^2}{\mu^2 K} + \Delta_0 e^{-K/\kappa}\right)$	需调节或递减步长
常数步长 SGD	强凸、光滑	$\Delta_K \lesssim e^{-\gamma\mu K} \Delta_0 + O\left(\frac{\gamma L\sigma^2}{\mu}\right)$	存在 noise floor
Mini-batch SGD	条件独立 batch, 大小 τ	$\text{Var}(\bar{g}) = \frac{1}{\tau} \text{Var}(g)$	更新次数与 component-gradient 调用数不同
Stochastic Nesterov	凸、光滑、有界方差	$\mathbb{E}[f(x^K) - f^*] = O\left(\frac{\sigma}{\sqrt{K}} + \frac{1}{K^2}\right)$	只加速确定性项; 大 K 时噪声主导
Proximal SGD	复合强凸、smooth f	$\mathbb{E}\ x^K - x^*\ ^2 \leq (1 - \rho)^K \ x^0 - x^*\ ^2 + \frac{\gamma^2 \sigma^2}{\rho}$	常数步长收敛到邻域
AdaGrad	在线凸、有界坐标直径	$\text{Regret}_T = O\left(\sum_i D_i \sqrt{\sum_t g_{t,i}^2}\right)$	累计分母可能导致后期步长过小
RMSProp	需另加 smoothness、步长及预条件器条件	附件给出更新式, 未给普适统一收敛率	不能由经验曲线声称普适收敛
Adam	需控制 moment、预条件器和有效步长	附件给出算法与 bias correction, 未给无条件普适定理	固定步长归一化可能振荡
AdamW	与 Adam 相同, 另加 decoupled decay	优化保证依赖 Adam 主体假设	weight decay 不等于自适应 ℓ_2 penalty

52.3 三套博资考优化方向的统一母题

表 52.3: 优化方向三套真题的母题结构

试卷	主设定	连续得分链
[25S-C]	强凸光滑 f 、复合 $f + R$ 、additive stochastic noise	定义 $\rightarrow$ smooth-strong interpolation $\rightarrow$ prox nonexpansiveness $\rightarrow$ variance decomposition $\rightarrow$ linear contraction $\rightarrow$ noise floor 和复杂度

试卷	主设定	连续得分链
[25F-C]	有限和 $f = n^{-1} \sum_i f_i$ 、非均匀 mini-batch、proximal SGD	无偏性 $\rightarrow$ expected smoothness $\rightarrow$ batch interpolation $\rightarrow$ importance sampling $\rightarrow$ 最优点方差 $\rightarrow$ AC inequality $\rightarrow$ 闭式 noise floor
[26S-C]	强凸光滑 composite objective、proximal SGD、迭代平均	定义 $\rightarrow$ prox 最优性 $\rightarrow$ 唯一性和 fixed point $\rightarrow$ 次微分单调性 $\rightarrow$ prox 非扩张 $\rightarrow$ 条件期望 $\rightarrow$ noise floor $\rightarrow$ 平均方差 $\rightarrow O(\log K/K)$

三套优化题具有共同结构：

$$\boxed{\text{一个统一问题设定} + \text{多个前后依赖的小问.}} \quad (52.1)$$

因此考场中若前面定义、fixed point 或一步递推写错，错误会向后传播并影响大部分分数。

52.4 优化证明的统一识别图

答题方法

看到 “smooth + convex”：descent lemma + first-order convex inequality + co-coercivity。
 看到 “smooth + strongly convex”：gradient interpolation $\rightarrow$ contraction $\rightarrow \kappa = L/\mu$ 。
 看到 “proximal”：prox optimality $\rightarrow \partial R$ monotonicity $\rightarrow$ firm/nonexpansiveness $\rightarrow$ fixed point。
 看到 “stochastic”： $\mathcal{F}_k \rightarrow \mathbb{E}_k[g_k] = \nabla f(x^k) \rightarrow$ cross term = 0 $\rightarrow$ variance term。
 看到 “constant stepsize + noise”： $a_{k+1} \leq (1 - \rho)a_k + b \rightarrow a_K \leq (1 - \rho)^K a_0 + \frac{b}{\rho}$ 。
 看到 “mini-batch”：diagonal terms + cross terms $\rightarrow 1/\tau$ variance。
 看到 “importance sampling”： $\frac{1}{nq_i} \rightarrow$ unbiasedness $\rightarrow \min_q \max_i \frac{L_i}{nq_i}$ 。
 看到 “momentum”：二阶递推 $\rightarrow$ 特征方向 $\rightarrow$ characteristic polynomial。
 看到 “Nesterov”：lookahead + auxiliary sequence + potential function。
 看到 “adaptive method”：moment estimate + diagonal preconditioner + effective stepsize + bias correction + failure mode。

52.5 优化方向高频易错点总表

易错点、反例与失败模式

1. Momentum 与 Nesterov 不同。

Momentum 在当前位置计算梯度；Nesterov 在 lookahead 点计算梯度。

2. 动量参数化不能静默混用。

是否含 $1 - \beta$ 会改变动量尺度和有效学习率。

3. Heavy-Ball 二次型结论不是一般函数定理。

特征多项式分析依赖固定 Hessian。

4. 稳定不等于单调。

动量方法可以振荡收敛。

5. Nesterov 的 $O(1/K^2)$ 需要凸和光滑。

非凸网络训练中不能直接声称全局函数值速率。

6. 随机加速只加速确定性项。

噪声项仍可能为 $O(1/\sqrt{K})$ 。

7. 预条件矩阵必须保证下降。

通常要求 $P_k \succ 0$ 。

8. 预条件的目标是改善有效条件数。

不是单纯把每个坐标学习率设得不同。

9. 坐标梯度需乘维度才是全梯度无偏估计。

$$\mathbb{E}[\nabla_I f(x) e_I] = \frac{1}{d} \nabla f(x).$$

10. 坐标下降应使用坐标 smoothness L_i 。

统一用 $1/L$ 可能过于保守。

11. 非均匀采样必须连同步长和权重分析。

不能只说“多抽大梯度坐标”。

12. AdaGrad 仍有基础学习率。

“adaptive”不等于“无需调参”。

13. RMSProp 的 EMA 不是无偏方差估计。

它是梯度平方的指数移动平均。

14. Adam 的第二矩不是方差。

s^k 估计的是原点二阶矩，而非 $\text{Var}(g)$ 。

15. Bias correction 不保证更新方向无偏。

它只修正零初始化引起的 moment 缩小。

16. $\varepsilon_{\text{adam}}$ 不是优化精度。

它是数值稳定常数。

17. $\sqrt{s} + \varepsilon$ 与 $\sqrt{s + \varepsilon}$ 不同。

全文必须选定一种约定并保持一致。

18. Adam 固定步长不自动精确收敛。

归一化更新可在强凸二次函数附近形成振荡。

19. AdamW 与 ℓ_2 penalty 一般不等价。

自适应预条件器使 coupled regularization 变为坐标相关收缩。

20. 实验曲线不是理论保证。

特定数据集上的 Adam 更快并不意味着其 oracle complexity 更优。

21. 函数值、梯度范数和迭代点收敛必须区分。

$f(x^k) \rightarrow f^*$ 不自动给出每个 x^k 收敛, 除非进一步有唯一性、强凸性或紧性条件。

22. 期望结论不等于高概率或几乎必然结论。

必须说明概率量词。

23. 迭代复杂度不等于算术复杂度。

full gradient、component gradient、coordinate update 的单步成本不同。

52.6 优化方向的三选四评估

选择优化方向通常要求考生具备以下稳定能力:

1. 能在两分钟内准确写出: L -smoothness, μ -strong convexity, ∂R , $\text{prox}_{\gamma R}$.
2. 能独立完成: 一步距离展开 + 条件期望 + 方差分解.
3. 能识别: $a_{k+1} \leq (1 - \rho)a_k + b$ 并正确求出 noise floor.
4. 能区分: $O(1/K)$, $O(1/K^2)$, $e^{-K/\kappa}$, $e^{-K/\sqrt{\kappa}}$.
5. 能处理长链式证明, 避免前一小问的符号错误传播。

优化方向的优势是:

- 题目数学结构集中;
- 大量小问可共享同一组引理;
- 即使最终结论未完成, 前置定义和中间递推可获得部分分。

主要风险是:

- 条件漏写会影响后续全部结论;
- 步长和常数错误容易连锁失分;
- 若不熟悉条件期望, 随机优化长题难以继续;
- 若只背结论而不会构造势函数, Nesterov 和复杂度题难以作答。

52.7 本部分快速自测

快速自测

1. 写出 Heavy-Ball 的位置差分形式、动量缓冲形式和速度形式。
2. 为什么不同动量公式中的 $1 - \beta$ 不能直接忽略?
3. 对二次型, Heavy-Ball 的单特征方向递推是什么?

4. 写出其特征多项式。
5. 在 $0 \leq \beta < 1$ 时, 二次型稳定步长范围是什么?
6. 为什么该稳定范围不能直接推广到任意非凸函数?
7. 写出 Heavy-Ball 在正定二次型上的经典最优参数。
8. 其渐近谱半径如何依赖 κ ?
9. Heavy-Ball 和 Nesterov 在何处计算梯度?
10. 一般凸 Nesterov 为什么需要时变变量?
11. 写出 $f(x^K) - f^* \leq 2LR^2/(K+1)^2$.
12. Nesterov 证明中的辅助变量 v^k 有何作用?
13. 为什么要选择 $z = (1 - \theta_k)x^{k-1} + \theta_k x^*$?
14. 强凸 Nesterov 的动量系数是什么?
15. GD 与 NAG 的条件数复杂度分别是什么?
16. 随机 Nesterov 的哪个项不能被一般动量加速?
17. 预条件梯度法如何由变量替换导出?
18. 为什么 $P \succ 0$ 能保证 $-P\nabla f$ 是下降方向?
19. 二次型的有效条件数是什么?
20. 取 $P = Q^{-1}$ 时为何可一步求解二次型?
21. Newton 方法对应什么预条件器?
22. RCD 的坐标梯度为什么不是直接无偏的全梯度估计?
23. 写出坐标 smoothness 的定义。
24. 步长 $1/L_i$ 产生的单步下降量是多少?
25. 非均匀坐标采样 $p_i \propto L_i^\alpha$ 的期望下降式是什么?
26. 一般凸 RCD 的速率是什么?
27. 强凸 RCD 的坐标条件数是什么?
28. AdaGrad 的累计量为何单调不减?
29. AdaGrad 为什么适合稀疏特征?
30. AdaGrad 为什么可能在后期过度衰减?
31. RMSProp 的 EMA 展开式是什么?
32. β_2 越接近 1 表示更长还是更短的记忆?
33. 写出完整的 Adam 一阶矩、二阶矩和 bias correction。

34. Bias correction 修正的具体偏差来自哪里?
35. Adam 的二阶矩估计为何不是方差?
36. 为什么 $\mathbb{E}[m/\sqrt{s}] \neq \mathbb{E}[m]/\sqrt{\mathbb{E}[s]}$ 一般成立?
37. 在 $\beta_1 = \beta_2 = 0$, $\varepsilon_{\text{adam}} = 0$ 时, Adam 在 $f(x) = x^2/2$ 上变成什么算法?
38. 如何构造该算法的二周期?
39. $\varepsilon_{\text{adam}}$ 除了防止除零, 还影响什么?
40. 普通 SGD 中 weight decay 和 ℓ_2 penalty 为什么等价?
41. 自适应预条件器中二者为何不等价?
42. AdamW 的衰减项是否经过 $1/\sqrt{s}$ 预条件?
43. 为什么固定学习率下的 AdamW 实际衰减因子是 $1 - \alpha_k \lambda$?
44. 自适应方法的实验优势能否直接写成理论复杂度优势?
45. 三套优化真题为什么都应先完整建立统一问题设定?
46. 若考场只剩十分钟, 优化长题应优先写哪些可独立得分的部分?



第四部分

自然语言处理



第五十三章 自然语言处理任务、语料单位与 Tokenization

53.1 重要性等级与考试定位

重要性等级：A

自然语言处理 (natural language processing, NLP) 资格考试并不只考“某个模型是什么”，而是要求考生先把语言任务形式化为可学习问题。

本章是后续所有 NLP 章节的共同前置。必须能够说明：

1. 原始对象是 corpus、document、sentence 还是 dialog history；
2. 基本计算单位是 character、word、subword 还是 token；
3. 输入和输出是单标签、等长标签序列还是变长输出序列；
4. 模型学习的是 $p(y|x)$, $p(x,y)$, $p(w_t|w_{<t})$ 中的哪一种；
5. 训练目标、推理算法和评价指标是否与任务一致；
6. tokenization 是否在训练、验证和测试阶段保持一致。

三套博资考中尚未单独考查 BPE 算法，但 tokenization 是语言模型、scaling law、InfoNCE、topic model 和 RAG 题目的共同数据前提，因此不能省略。

53.2 语言对象的层级

定义 53.1 (Corpus, Document, Sentence 与 Token Sequence). 设 $\mathcal{C} = \{d_1, \dots, d_D\}$ 为语料库 (corpus)，其中每个文档 d_i 可以包含一个或多个段落和句子。

经过确定的预处理与 tokenization 后，第 i 个文档表示为 $d_i = (w_{i,1}, \dots, w_{i,T_i})$, $w_{i,t} \in \mathcal{V}$, 其中：

- $\mathcal{V}$ 是词表或 token vocabulary；
- $V := |\mathcal{V}|$ 是词表大小；
- T_i 是文档的 token 数；
- $w_{i,t}$ 是一个离散 token id。

语言层级可以写成 $\text{corpus} \supset \text{document} \supset \text{paragraph} \supset \text{sentence} \supset \text{chunk} \supset \text{word} \supset \text{morpheme} \supset \text{character}$ 。



但该层级不是所有任务都必须逐层使用。模型的实际计算单位由 tokenizer 决定。

53.2.1 Word、Word Type、Word Instance 与 Token

定义 53.2 (Word Type 与 Word Instance). 设一段文本在词级切分后得到 $(u_1, \dots, u_N)$ 。则：

- word instance 是序列中的一次具体出现；
- word type 是所有不同词形构成的集合元素；
- word instance 数量是 N ；
- word type 数量是 $|\{u_1, \dots, u_N\}|$ 。

例如句子“模型学习语言，语言影响模型”在某个词级 tokenizer 下可产生两个“模型”和两个“语言”的实例，但对应的 distinct word types 仍各只有一个。

定义 53.3 (Token 与 Subword). token 是 tokenizer 输出的离散基本单位。

subword 是小于完整词、但通常大于单个字符的 token，例如 `learn+ing`，`un+break+able`。一个 word 可以对应一个、多个或零个独立 word-level token，具体取决于 tokenizer 规则。

易错点、反例与失败模式

以下概念不能混用：

- **word** 是语言学或任务层面的词；
- **token** 是 tokenizer 的输出单位；
- **subword** 是一种 token；
- **word type** 是不同词形的类别数；
- **word instance** 是文本中运行词的总出现次数。

“模型输入长度为 1000 个词”与“模型输入长度为 1000 个 token”不一定等价。

53.3 NLP 任务的三种基本输入—输出结构

设输入 token 序列为 $\mathbf{x} = (x_1, \dots, x_T) \in \mathcal{V}^T$ 。

53.3.1 Sequence Classification

序列分类的输出是单个标签：

$$f_{\theta} : \mathcal{V}^T \longrightarrow \mathcal{Y}, \quad \mathcal{Y} = \{1, \dots, C\}. \quad (53.1)$$

典型任务：

- sentiment classification；
- topic classification；
- spam detection；



- intent classification;
- document priority prediction。

概率模型输出 $p_{\theta}(y | \mathbf{x})$, 常用训练目标为

$$\mathcal{L}_{\text{cls}}(\theta) = -\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(y^{(i)} | \mathbf{x}^{(i)}). \quad (53.2)$$

53.3.2 Sequence Labeling

序列标注的输入输出长度通常相同:

$$f_{\theta} : \mathcal{V}^T \longrightarrow \mathcal{Y}^T. \quad (53.3)$$

典型任务:

- part-of-speech tagging;
- named entity recognition;
- chunking;
- slot filling。

输出为 $\mathbf{y} = (y_1, \dots, y_T)$, $y_t \in \{1, \dots, K\}$ 。

53.3.3 Sequence-to-Sequence

变长序列生成写为

$$f_{\theta} : \mathcal{V}_x^{T_x} \longrightarrow \mathcal{V}_y^{T_y}, \quad (53.4)$$

或概率形式

$$p_{\theta}(\mathbf{y} | \mathbf{x}) = \prod_{t=1}^{T_y} p_{\theta}(y_t | y_{<t}, \mathbf{x}). \quad (53.5)$$

典型任务:

- machine translation;
- summarization;
- question answering;
- dialogue generation。

53.3.4 任务形式对比

表 53.1: NLP 基本任务形式

任务形式	输入与输出	常见训练目标	常见评价
Sequence Classification	$\mathbf{x} \in \mathcal{V}^T, \quad y \in [C]$	$-\log p_{\theta}(y \mathbf{x})$	Accuracy、Precision、Recall、F1



任务形式	输入与输出	常见训练目标	常见评价
Sequence Labeling	$\mathbf{x} \in \mathcal{V}^T, \mathbf{y} \in [K]^T$	token-wise cross-entropy, 或 CRF sequence NLL	Token accuracy、entity-level F1
Sequence-to-Sequence	$\mathbf{x} \in \mathcal{V}_x^{T_x}, \mathbf{y} \in \mathcal{V}_y^{T_y}$	$-\sum_t \log p_\theta(y_t y_{<t}, \mathbf{x})$	BLEU、ROUGE、Exact Match、人工评价
Language Modeling	$w_{1:T}$ 预测下一个 token	$-\sum_t \log p_\theta(w_t w_{<t})$	Perplexity、下游任务指标

53.4 Tokenization 与 Normalization

定义 53.4 (Tokenization). tokenization 是将原始字符串 $s \in \Sigma^*$ 映射为离散 token 序列的函数

$$\text{Tok} : \Sigma^* \longrightarrow \mathcal{V}^*. \quad (53.6)$$

定义 53.5 (Normalization). normalization 是在 tokenization 前后对文本进行标准化的过程，例如：

- Unicode normalization;
- case folding;
- punctuation normalization;
- whitespace normalization;
- lemmatization;
- sentence segmentation.

Tokenization 与 normalization 不是同一操作。

例如：

- 将 `Models` 变成 `models` 是 case normalization;
- 将 `models` 切成 `model`, `s` 是 subword tokenization;
- 将 `models` 映射到 `lemma model` 是 lemmatization.

53.4.1 为什么规则依赖任务

是否保留大小写、标点和停用词必须由任务决定。

例如：

- 对信息检索，大小写归一化可能提高匹配召回率；
- 对 named entity recognition，大写特征有助于识别人名、机构名和地名；
- 对情感分析，感叹号和重复标点可能携带情感强度；
- 对语言模型，删除标点会改变待建模的真实 token 分布。



易错点、反例与失败模式

不得把 normalization 写成“总能提高性能”的无条件规则。

Normalization 会减少稀疏性，但同时可能删除判别信息。正确答案应说明：是否归一化 = 任务目标、语种、语域和评价协议的函数。

53.5 Byte-Pair Encoding

53.5.1 问题设定

设训练语料经过初始切分后表示为带频数的字符串集合 $\mathcal{S} = \{(s^{(r)}, c_r)\}_{r=1}^R$ ，其中 $s^{(r)} = (s_1^{(r)}, \dots, s_{L_r}^{(r)})$ 由基础符号组成， c_r 是该字符串在语料中的频数。

本讲义主约定采用 [SLP] 中的字符初始化 BPE: $\mathcal{V}_0 = \{\text{训练语料中出现的基础字符}\}$ 。

byte-level BPE 只需将基础字符集替换为有限 byte alphabet，其迭代合并逻辑不变。

53.5.2 相邻对频数

对符号对 (a, b) ，定义加权相邻频数

$$C_{\text{pair}}(a, b) = \sum_{r=1}^R c_r \sum_{j=1}^{L_r-1} \mathbf{1}\{s_j^{(r)} = a, s_{j+1}^{(r)} = b\}. \quad (53.7)$$

第 m 次合并选择

$$(a_m, b_m) \in \arg \max_{(a,b)} C_{\text{pair}}^{(m-1)}(a, b). \quad (53.8)$$

若存在并列最大值，应使用确定的 tie-breaking 规则，否则相同语料可能得到不同词表。

构造新符号

$$u_m = a_m \parallel b_m, \quad (53.9)$$

并将语料中所有相邻的 (a_m, b_m) 替换为 u_m 。

词表递推为

$$\mathcal{V}_m = \mathcal{V}_{m-1} \cup \{u_m\}. \quad (53.10)$$

执行 M 次合并后：

$$|\mathcal{V}_M| = |\mathcal{V}_0| + M, \quad (53.11)$$

忽略合并符号可能与已有符号重合的退化情形。

53.5.3 BPE 词表学习算法

答题方法

BPE token learner:

1. 将训练语料中的每个初始单位拆成基础字符或 bytes;
2. 统计所有相邻 token pair 的加权频数;
3. 选择最高频 pair (a_m, b_m) ;

4. 新建 token $u_m = a_m || b_m$;
5. 在整个训练表示中同时替换该 pair;
6. 更新 pair 频数;
7. 重复 M 次, 保存有序 merge list $\mathcal{M} = [(a_1, b_1), \dots, (a_M, b_M)]$.

53.5.4 测试时分词

给定新字符串 s , 先拆为基础符号, 再按训练阶段学到的顺序 $(a_1, b_1), \dots, (a_M, b_M)$ 依次执行合并。

测试集上的 pair frequency 不参与 merge rule 学习。因此 tokenizer 参数是训练阶段学得并在验证、测试和部署时固定的。

例 53.6 (未登录词的分解). 假设 merge list 已学到 $l + o \mapsto lo$, $lo + w \mapsto low$, $e + r \mapsto er$ 。即使训练词表中没有完整词 **lower**, 它仍可以编码为 **low**, **er**。

因此 subword 方法将 word-level OOV 问题转化为更细粒度序列。

53.5.5 BPE 的复杂度

设:

- 训练表示中基础符号总数为 N_{sym} ;
- 合并次数为 M ;
- 最终词表大小为 V 。

朴素实现每轮重新扫描整个语料:

$$T_{\text{train}} = O(MN_{\text{sym}}), \quad (53.12)$$

空间复杂度为

$$S_{\text{train}} = O(N_{\text{sym}} + V). \quad (53.13)$$

实际实现可用局部计数更新、优先队列或 trie 减少重复扫描, 但其精确复杂度依赖数据结构, 考试中不应在未说明实现时给出唯一更紧结论。

53.5.6 词表大小的权衡

若词表过小:

- 序列长度增加;
- self-attention 的 $O(T^2)$ 成本上升;
- 一个词的语义被拆散到更多位置。

若词表过大:

- embedding matrix 参数量 $O(Vd)$ 增大;



- output softmax 的时间与空间开销增大；
- 大量低频 token 的统计估计不稳定；
- 跨领域词形泛化可能变差。

易错点、反例与失败模式

BPE 不等于语言学形态分析。

BPE 合并的是高频相邻字符串；合并结果可能与 morpheme 一致，也可能只是统计上常见的字符片段。

此外，character-level BPE 不一定能表示训练中从未出现的新字符；byte-level BPE 才能通过有限 byte alphabet 原则上覆盖任意字节序列。

53.6 训练、验证、测试阶段的 Tokenizer 规范

1. tokenizer vocabulary 和 merge rules 应在允许的训练语料上学习；
2. validation 阶段可用于选择词表大小、normalization 和其他超参数；
3. test 阶段不得根据测试指标反复修改 tokenizer；
4. 比较两个语言模型时,应尽量固定: test corpus, tokenizer, vocabulary, special-token convention.
5. 模型部署时应保存 tokenizer 版本；否则相同 token id 可能映射到不同字符串。

答题方法

看到“设计 NLP 输入表示”时，满分答案应覆盖：

1. 原始输入的语言和语域；
2. normalization 规则及其保留/删除的信息；
3. tokenizer 类型；
4. 词表大小和 special tokens；
5. OOV 处理；
6. 最大长度、截断和 padding；
7. tokenizer 是否只在训练语料上学习；
8. 训练与推理阶段是否使用同一 tokenizer；
9. tokenization 对模型复杂度和评价指标的影响。

53.7 快速自测

快速自测

1. word type、word instance 和 token 的区别是什么?
2. 为什么同一句话在两个 tokenizer 下可能有不同序列长度?
3. Tokenization 与 case normalization 是否属于同一操作?
4. 写出 sequence classification、sequence labeling 和 sequence-to-sequence 的输入输出空间。
5. BPE 的训练阶段学习什么，测试阶段固定什么?
6. BPE 每轮选择的对象是什么?
7. character-level BPE 是否无条件解决所有 OOV 字符?
8. 词表增大为什么可能同时缩短序列并增加模型参数?
9. 为什么不能根据 test perplexity 反复修改 tokenizer?
10. 比较两个语言模型的 perplexity 时必须固定哪些设置?



第五十四章 N-Gram 语言模型、平滑与 Perplexity

54.1 重要性等级与真题定位

重要性等级：A

n-gram 语言模型属于考纲核心，并在 [25S-D-Q1, 3 分] 直接考查：

- trigram MLE;
- unseen trigram;
- unseen context;
- smoothing、interpolation 或 backoff。

该主题在三套真题中直接出现一次，因此应表述为“实考核心基础题”，而不是虚构为“三套真题高频”。

54.2 语言模型的精确定义

设词表为 $\mathcal{V}$ ， $|\mathcal{V}| = V$ 。

语言模型是定义在有限 token 序列上的概率分布：

$$p : \mathcal{V}^* \longrightarrow [0, 1], \quad \sum_{\mathbf{w} \in \mathcal{V}^*} p(\mathbf{w}) = 1. \quad (54.1)$$

对固定长度 T 的序列 $\mathbf{w} = (w_1, \dots, w_T)$ ，概率链式法则给出

$$p(w_{1:T}) = \prod_{t=1}^T p(w_t \mid w_{1:t-1}). \quad (54.2)$$

链式法则本身是精确恒等式，不含近似。

54.3 N-Gram 的 Markov 假设

N-gram 模型作出 $N - 1$ 阶 Markov 近似：

$$p(w_t \mid w_{1:t-1}) \approx p(w_t \mid w_{t-N+1:t-1}). \quad (54.3)$$



具体地：

$$\text{unigram: } p(w_t | w_{<t}) \approx p(w_t), \quad (54.4)$$

$$\text{bigram: } p(w_t | w_{<t}) \approx p(w_t | w_{t-1}), \quad (54.5)$$

$$\text{trigram: } p(w_t | w_{<t}) \approx p(w_t | w_{t-2}, w_{t-1}). \quad (54.6)$$

于是

$$p_N(w_{1:T}) = \prod_{t=1}^T p_N(w_t | w_{t-N+1:t-1}), \quad (54.7)$$

其中序列左侧不足 $N - 1$ 个 token 时使用句首标记补齐。

54.3.1 BOS 与 EOS 约定

对 trigram, 本文采用 $w_{-1} = w_0 = \langle \text{BOS} \rangle$, $w_{T+1} = \langle \text{EOS} \rangle$ 。

句子概率为

$$\begin{aligned} p(w_{1:T}, \langle \text{EOS} \rangle) &= p(w_1 | \langle \text{BOS} \rangle, \langle \text{BOS} \rangle) \\ &\quad \times p(w_2 | \langle \text{BOS} \rangle, w_1) \\ &\quad \times \prod_{t=3}^T p(w_t | w_{t-2}, w_{t-1}) \\ &\quad \times p(\langle \text{EOS} \rangle | w_{T-1}, w_T). \end{aligned} \quad (54.8)$$

EOS 不能随意省略，因为若不建模终止事件，模型不能为不同长度的全部句子构造一个统一的规范化分布。

54.4 基于计数的最大似然估计

记 $C(h, w)$ 为 history h 后出现 token w 的次数，并记 $C(h) = \sum_{u \in \mathcal{V}} C(h, u)$ 。

对 trigram: $h = (w_1, w_2)$, $C(h, w_3) = C(w_1, w_2, w_3)$ 。

当 $C(h) > 0$ 时，MLE 为

$$\hat{p}_{\text{MLE}}(w | h) = \frac{C(h, w)}{C(h)}. \quad (54.9)$$

特别地，

$$\hat{p}_{\text{MLE}}(w_3 | w_1, w_2) = \frac{C(w_1, w_2, w_3)}{C(w_1, w_2)}. \quad (54.10)$$


54.4.1 MLE 的完整推导

固定 history h ，令 $c_w = C(h, w)$, $n_h = \sum_{w \in \mathcal{V}} c_w = C(h)$ 。

条件分布参数记为 $p_w = p(w | h)$, $p_w \geq 0$, $\sum_w p_w = 1$ 。

对应的条件 log-likelihood 为

$$\ell_h(\mathbf{p}) = \sum_{w \in \mathcal{V}} c_w \log p_w. \quad (54.11)$$



构造 Lagrangian:

$$\mathcal{J}(\mathbf{p}, \lambda) = \sum_w c_w \log p_w + \lambda \left(\sum_w p_w - 1 \right). \quad (54.12)$$

对 $p_w > 0$ 的坐标求导:

$$\frac{\partial \mathcal{J}}{\partial p_w} = \frac{c_w}{p_w} + \lambda = 0, \quad (54.13)$$

故 $p_w = -\frac{c_w}{\lambda}$ 。

利用归一化条件: $1 = \sum_w p_w = -\frac{1}{\lambda} \sum_w c_w = -\frac{n_h}{\lambda}$, 因此 $\lambda = -n_h$, 得到 $p_w = \frac{c_w}{n_h}$ 。

若 $c_w = 0$, MLE 在该坐标取 $p_w = 0$ 。

若 $C(h) = 0$, 则整个 history 从未出现, 条件 likelihood 对 $p(\cdot | h)$ 没有任何约束, MLE 公式分母为零, 条件分布未定义, 而不是“自然等于零分布”。

易错点、反例与失败模式

必须区分:

1. **seen history, unseen continuation:** $C(h) > 0$, $C(h, w) = 0$. 此时 MLE 明确定义且为 0。
2. **unseen history:** $C(h) = 0$. 此时 $C(h, w)/C(h)$ 是 $0/0$, MLE 未定义。
3. **OOV token:** token 本身不在 $\mathcal{V}$ 中。此时需使用 $\langle \text{UNK} \rangle$ 或 subword tokenizer。

54.5 为什么 Markov 假设不能省

若完全建模 $p(w_t | w_{1:t-1})$, 不同 history 的数量随长度指数增长。

若词表大小为 V , 仅长度为 m 的 history 就有至多 V^m 种。

N -gram 将每个条件分布限制为只依赖 $N-1$ 个 token, 从而将最大条件表规模限制为 $O(V^N)$ 。

代价是:

- 无法直接表达超过 $N-1$ 个位置的依赖;
- 语义相似但表面 token 不同的 history 不能共享统计;
- N 增大时稀疏性和过拟合迅速加重。

54.6 Zero-Count Problem

若测试序列中某个条件概率为零: $p(w_t | h_t) = 0$, 则整个序列概率为 $p(w_{1:T}) = 0$ 。


在 log-space 中: $\log p(w_{1:T}) = -\infty$ 。

对应 perplexity 为 $+\infty$ 。

因此有限语料上的原始 MLE 不能直接作为稳健测试模型。

54.7 Add- k Smoothing

令 $k > 0$ 。



Add- k smoothed estimate 为

$$\hat{p}_k(w | h) = \frac{C(h, w) + k}{C(h) + kV}. \quad (54.14)$$

归一化检查:

$$\sum_{w \in \mathcal{V}} \hat{p}_k(w | h) = \frac{\sum_w C(h, w) + kV}{C(h) + kV} = 1. \quad (54.15)$$

若 history 从未出现: $C(h) = 0$, 则

$$\hat{p}_k(w | h) = \frac{1}{V}. \quad (54.16)$$

Add-one 是 $k = 1$ 的特殊情形。

说明 54.1. Add-one 对大型语言模型通常过度移动概率质量: 当 V 很大时, 给每个未见 token 增加 1 会产生总计 V 个伪计数。

因此它适合作为简单基线和考试推导工具, 但不应写成现代 n-gram language modeling 的无条件最佳方法。

54.8 Interpolation

对 trigram、bigram 和 unigram, 定义

$$p_3(w_t) = \hat{p}(w_t | w_{t-2}, w_{t-1}), \quad (54.17)$$

$$p_2(w_t) = \hat{p}(w_t | w_{t-1}), \quad (54.18)$$

$$p_1(w_t) = \hat{p}(w_t). \quad (54.19)$$

简单线性插值为

$$p_{\text{int}}(w_t | w_{t-2}, w_{t-1}) = \lambda_3 p_3(w_t) + \lambda_2 p_2(w_t) + \lambda_1 p_1(w_t), \quad (54.20)$$

其中

$$\lambda_r \geq 0, \quad \lambda_1 + \lambda_2 + \lambda_3 = 1. \quad (54.21)$$


若各 p_r 均为规范化分布, 则 p_{int} 也规范化。

权重可以依赖 history:

$$\lambda_r = \lambda_r(w_{t-2}, w_{t-1}), \quad \sum_r \lambda_r(h) = 1. \quad (54.22)$$

权重通常在 held-out 或 development corpus 上选择, 目标是最大化 held-out likelihood:

$$\max_{\lambda} \sum_t \log p_{\text{int}}(w_t | h_t; \lambda). \quad (54.23)$$



易错点、反例与失败模式

Interpolation 的三个分布应当已经可定义。

若直接把未定义的 $C(h, w)/C(h)$ 放入插值，仍没有解决 $C(h) = 0$ 问题。

严谨答案应说明：

- 使用平滑后的各阶估计；或
- 对不可用高阶项令其权重为零，并重新保证剩余权重和为 1。

54.9 Backoff

令 h 是高阶 history， h' 是删除最早 token 后的低一阶 history。

概率保持型 backoff 可写为

$$p_{\text{bo}}(w | h) = \begin{cases} p_{\text{high}}(w | h), & C(h, w) > 0, \\ \alpha(h)p_{\text{bo}}(w | h'), & C(h, w) = 0. \end{cases} \quad (54.24)$$

高阶已见事件需先 discount，使其概率和小于 1。定义 $\mathcal{A}_h = \{w : C(h, w) > 0\}$ 。为保证规范化，backoff coefficient 应满足

$$\alpha(h) = \frac{1 - \sum_{w \in \mathcal{A}_h} p_{\text{high}}(w | h)}{1 - \sum_{w \in \mathcal{A}_h} p_{\text{bo}}(w | h')}. \quad (54.25)$$

分子是高阶模型留给 unseen events 的概率质量；分母是低阶模型在这些 unseen events 上原有的概率质量。

54.9.1 Stupid Backoff

stupid backoff 使用固定系数 λ ：

$$S(w | h) = \begin{cases} \frac{C(h, w)}{C(h)}, & C(h, w) > 0, \\ \lambda S(w | h'), & C(h, w) = 0. \end{cases} \quad (54.26)$$

常见课程示例取 $\lambda \approx 0.4$ 。

但 S 通常不是规范化概率分布： $\sum_w S(w | h) \neq 1$ 。

因此：

- 可用于排序或打分；
- 不能在不检查归一化的情况下直接称为概率；
- 不能直接用于要求严格 probability likelihood 的推导。

54.10 Unseen Word、Unseen Context 与 <UNK>

若使用 word-level vocabulary，可以在训练前选择词频阈值 r ，将低频词映射为 <UNK>。

训练时估计 $p(\langle \text{UNK} \rangle | h)$ ，测试时把未登录词统一映射到该 token。



更常见的现代方案是 subword tokenizer: $\text{unseen word} \mapsto \text{known subword sequence}$ 。

但 subword 只解决 token coverage, 不自动解决 unseen context: 即使每个 token 都在词表内, 某个高阶 token 组合仍可能从未在训练语料中出现。

54.11 Perplexity

设测试 token 序列为 $W = (w_1, \dots, w_N)$ 。

平均负 log-likelihood 为

$$\text{NLL}_{\text{token}}(W) = -\frac{1}{N} \sum_{t=1}^N \log p(w_t | w_{<t}). \quad (54.27)$$

使用自然对数时, perplexity 定义为

$$\text{PPL}(W) = \exp \left[-\frac{1}{N} \sum_{t=1}^N \log p(w_t | w_{<t}) \right]. \quad (54.28)$$

由链式法则:

$$\text{PPL}(W) = p(W)^{-1/N}. \quad (54.29)$$

若使用以 2 为底的 log, 则 $\text{PPL}(W) = 2^{H_2(W)}$ 。

54.11.1 语料级 Perplexity

设测试语料有多个句子 $S_1, \dots, S_M$, 总预测 token 数为 $N_{\text{tot}} = \sum_{m=1}^M N_m$ 。

正确的语料级 perplexity 是

$$\text{PPL}(\mathcal{C}_{\text{test}}) = \exp \left[-\frac{1}{N_{\text{tot}}} \sum_{m=1}^M \sum_{t=1}^{N_m} \log p(w_{m,t} | h_{m,t}) \right]. \quad (54.30)$$

不能简单平均各句子的 perplexity:

$$\frac{1}{M} \sum_m \text{PPL}(S_m) \quad (54.31)$$

通常不等于 $\text{PPL}(\mathcal{C}_{\text{test}})$, 因为句子长度不同且指数函数非线性。

54.11.2 EOS 计数约定

若模型预测 $\langle \text{EOS} \rangle$, 则 EOS 应计入 NLL 和 token 数。

BOS 是给定 context, 不是被预测的目标, 通常不计入 N 。

必须在比较模型时保持同一约定。

54.11.3 Perplexity 的解释

若每一步都在 B 个 token 上均匀预测: $p(w_t | h_t) = \frac{1}{B}$, 则 $\text{PPL} = B$ 。

因此 perplexity 可理解为加权平均有效分支数。



54.11.4 Perplexity 的可比性条件

两个 PPL 数值可直接比较，至少需要固定：

1. 同一测试语料；
2. 同一 tokenizer；
3. 同一词表或可比较的 token unit；
4. 同一 BOS/EOS 计数规则；
5. 同一 log base；
6. 同一数据预处理；
7. 测试语料未用于训练或调参。

易错点、反例与失败模式

“模型 A 的 PPL 低于模型 B，所以 A 在所有下游任务上都更好”不是定理。

Perplexity 是 intrinsic language-model metric。下游准确率还取决于：

- 任务分布；
- decoding；
- fine-tuning；
- retrieval；
- calibration；
- 模型是否捕获任务所需信息。

此外，PPL 不是 p-value，也不是“模型置信度”的频率学概率解释。

54.12 N-Gram 的训练与推理复杂度

设训练语料总 token 数为 N_{train} ，最高阶数为 N_g 。

若只存储实际出现的 n-grams，记其数量为 M_{N_g} 。

一次顺序扫描可统计各阶 n-gram：

$$T_{\text{count}} = O(N_g N_{\text{train}}). \quad (54.32)$$


当 N_g 视为常数时： $T_{\text{count}} = O(N_{\text{train}})$ 。

存储复杂度为

$$S_{\text{ngram}} = O(M_{N_g}), \quad (54.33)$$

最坏稠密表可达到 $O(V^{N_g})$ ，但实际实现通常只存 observed n-grams 并进行 pruning。

使用 hash table 或 trie 时，单个条件概率查询的平均代价可近似视为 $O(1)$ ，因此长度 T 序列的打分为 $O(TN_g)$ ，固定阶数下为 $O(T)$ 。



54.13 基础例题

例 54.2 (Trigram MLE). 设训练语料包含: $\langle \text{BOS} \rangle$ 我爱学习 $\langle \text{EOS} \rangle$, $\langle \text{BOS} \rangle$ 我爱 NLP $\langle \text{EOS} \rangle$, $\langle \text{BOS} \rangle$ 你爱学习 $\langle \text{EOS} \rangle$.

则 $C(\text{我}, \text{爱}) = 2$, $C(\text{我}, \text{爱}, \text{学习}) = 1$, $C(\text{我}, \text{爱}, \text{NLP}) = 1$ 。

所以 $\hat{p}_{\text{MLE}}(\text{学习} | \text{我}, \text{爱}) = \frac{1}{2}$, $\hat{p}_{\text{MLE}}(\text{NLP} | \text{我}, \text{爱}) = \frac{1}{2}$ 。

若词表大小为 V , 使用 add- k : $\hat{p}_k(\text{数学} | \text{我}, \text{爱}) = \frac{k}{2+kV}$ 。

54.14 历年题型改写与满分模板

答题方法

[25S-D-Q1, 3 分] 满分答案:

首先写 trigram MLE: $\hat{p}_{\text{MLE}}(w_3 | w_1, w_2) = \frac{C(w_1, w_2, w_3)}{C(w_1, w_2)}$, 前提是 $C(w_1, w_2) > 0$ 。

然后区分三类情况:

1. 若 $C(w_1, w_2) > 0$, $C(w_1, w_2, w_3) = 0$, 原始 MLE 为零, 应使用 smoothing, 例如 $\hat{p}_k(w_3 | w_1, w_2) = \frac{C(w_1, w_2, w_3) + k}{C(w_1, w_2) + kV}$ 。
2. 若 $C(w_1, w_2) = 0$, trigram MLE 未定义, 应 back off 到 $p(w_3 | w_2)$, 再必要时 back off 到 $p(w_3)$ 。
3. 可采用插值: $p(w_3 | w_1, w_2) = \lambda_3 p_3 + \lambda_2 p_2 + \lambda_1 p_1$, $\lambda_r \geq 0$, $\sum_r \lambda_r = 1$ 。

若 w_1, w_2 或 w_3 本身未进入 word vocabulary, 应先映射为 $\langle \text{UNK} \rangle$ 或使用 subword tokenizer。

最后说明: 平滑必须保证 $\sum_{w_3 \in \mathcal{V}} p(w_3 | w_1, w_2) = 1$ 。

仅写“用平滑”而不写 MLE、未见情形和具体公式, 不能构成完整答案。

54.15 N-Gram 高频易错点




易错点、反例与失败模式

1. 链式法则是精确的，Markov 截断才是近似。
2. $C(h, w) = 0$ 与 $C(h) = 0$ 不是同一种问题。
3. OOV token 与 unseen n-gram 不是同一问题。
4. Add-one 必须同时修改分母: $C(h) + V$.
5. Interpolation 每个 history 下的权重必须非负且和为 1。
6. 规范化 backoff 需要 discount 和 $\alpha(h)$; stupid backoff 只是 score。
7. 句子概率应包含终止概率，否则长度模型不完整。
8. 应在 log-space 中求和，避免概率连乘下溢。
9. Corpus PPL 应按总 token NLL 聚合，不应平均句级 PPL。
10. 不同 tokenizer 的 PPL 通常不可直接比较。
11. Lower PPL 不等于自动消除 hallucination，也不保证更高事实正确率。

54.16 快速自测

快速自测

1. 链式法则和 trigram 假设的区别是什么?
2. 为什么 trigram 句首通常需要两个 BOS?
3. 推导 $\hat{p}(w | h) = C(h, w)/C(h)$.
4. 若 $C(h) = 0$, MLE 是零还是未定义?
5. Add- k 为什么能够保证归一化?
6. 若整个 history 未出现, add- k 给出什么分布?
7. Interpolation 与 backoff 的根本区别是什么?
8. 为什么 stupid backoff 不能直接称为概率模型?
9. 一个 token 概率为零时, 序列 PPL 是多少?
10. 语料级 PPL 为什么不能用句级 PPL 的算术平均?
11. 比较 PPL 时为什么必须固定 tokenizer?
12. n-gram 存储的最坏规模如何依赖 V 和阶数?



第五十五章 文本分类、Naive Bayes 与评价指标

55.1 重要性等级

重要性等级：B

文本分类和 Precision/Recall/F1 明确列入考纲，也是 topic model、retrieval、entity linking 和系统设计题的共同前置。

三套真题中尚未直接要求推导 multinomial Naive Bayes，因此不将其称为真题高频；但必须掌握其概率分解、MLE、Laplace smoothing、log-space inference 和 bag-of-words 失败模式。

55.2 监督文本分类的数学设定

训练集为

$$\mathcal{D}_{\text{train}} = \{(d_i, y_i)\}_{i=1}^N, \quad (55.1)$$

其中： $d_i = (w_{i,1}, \dots, w_{i,T_i}) \in \mathcal{V}^{T_i}$, $y_i \in \mathcal{Y} = \{1, \dots, C\}$ 。

分类器输出 $\hat{y} = f_{\theta}(d)$ ，概率分类器输出 $p_{\theta}(y | d)$ 。

对概率模型，经验负对数似然为

$$\hat{\mathcal{L}}(\theta) = -\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(y_i | d_i). \quad (55.2)$$

55.3 Multinomial Naive Bayes

55.3.1 生成过程与假设


对文档 d ，multinomial Naive Bayes 假设：

1. 先采样类别 $Y \sim p(c)$;
2. 给定类别 c ，文档中的 token 独立同分布： $W_t | Y = c \sim \text{Categorical}(\phi_c)$ ，其中

$$\phi_c = (\phi_{c,1}, \dots, \phi_{c,V}), \quad \sum_{v=1}^V \phi_{c,v} = 1.$$

给定类别的条件独立假设为

$$p(d | c) = \prod_{t=1}^T p(w_t | c). \quad (55.3)$$



若记 token v 在文档 d 中的次数为 $n_v(d)$, 则

$$p(d | c) = \prod_{v=1}^V \phi_{c,v}^{n_v(d)}. \quad (55.4)$$

该表示只依赖 token count, 不依赖 token 顺序, 即 bag-of-words 假设。

55.3.2 Bayes 决策

由 Bayes rule: $p(c | d) \propto p(c)p(d | c)$ 。

MAP 分类为

$$\hat{c} = \arg \max_{c \in \mathcal{Y}} p(c) \prod_{v=1}^V \phi_{c,v}^{n_v(d)}. \quad (55.5)$$

在 log-space 中:

$$\hat{c} = \arg \max_{c \in \mathcal{Y}} \left[\log p(c) + \sum_{v=1}^V n_v(d) \log \phi_{c,v} \right]. \quad (55.6)$$

55.3.3 参数估计

令:

- N_c 为类别 c 的训练文档数;
- N 为总文档数;
- $C(v, c)$ 为类别 c 的全部文档中 token v 的总次数;
- $C(c) = \sum_{u=1}^V C(u, c)$.

类别先验 MLE:

$$\hat{p}(c) = \frac{N_c}{N}. \quad (55.7)$$

未平滑 token likelihood:

$$\hat{\phi}_{c,v} = \frac{C(v, c)}{C(c)}. \quad (55.8)$$

使用 add- α smoothing:

$$\hat{\phi}_{c,v}^{(\alpha)} = \frac{C(v, c) + \alpha}{C(c) + \alpha V}, \quad \alpha > 0. \quad (55.9)$$

归一化: $\sum_{v=1}^V \hat{\phi}_{c,v}^{(\alpha)} = 1$ 。

55.4 为什么 Naive Bayes 的条件不能省

55.4.1 Bag-of-Words 的代价

以下文档具有相同 unigram counts: “模型不可靠”, “不, 模型可靠” 若忽略标点和顺序, 它们可能得到相同表示, 但语义和情感可能不同。

因此 bag-of-words 不能表达:



- negation scope;
- word order;
- long-range dependency;
- compositional semantics。

55.4.2 条件独立假设的代价

Naive Bayes 假设 $p(w_i, w_j | c) = p(w_i | c)p(w_j | c)$ 。实际语言中相邻词和语义相关词高度依赖。

该假设通常不真实，但分类决策仍可能有效，因为准确估计完整联合分布需要远多于现有数据的参数。

55.4.3 Zero Probability

若某个测试 token 在类别 c 的训练文档中从未出现： $C(v, c) = 0$ ，未平滑 likelihood 为零，导致整个 $p(d | c)$ 为零。

Add- α smoothing 防止单个未见 token 否定该类别的全部其他证据。

易错点、反例与失败模式

Naive Bayes 中的 $p(w | c)$ 是“给定类别生成词的概率”，不是 $p(c | w)$ 。
二者通过 Bayes rule 相关，但不能直接互换。

55.5 训练与推理复杂度

设：

- 训练总 token 数为 N_{tok} ；
- 类别数为 C ；
- 词表大小为 V ；
- 测试文档长度为 T 。

训练计数时间：

$$O(N_{\text{tok}}). \quad (55.10)$$


若显式存储所有类别-token likelihood：

$$O(CV) \quad (55.11)$$

空间。

对一个测试文档，若只遍历文档中出现的 token，推理时间为

$$O(CT). \quad (55.12)$$



55.6 分类评价指标

对二分类正类，定义：

- TP：真实为正且预测为正；
- FP：真实为负但预测为正；
- FN：真实为正但预测为负；
- TN：真实为负且预测为负。

Accuracy：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}}. \quad (55.13)$$

Precision：

$$P = \frac{\text{TP}}{\text{TP} + \text{FP}}. \quad (55.14)$$

Recall：

$$R = \frac{\text{TP}}{\text{TP} + \text{FN}}. \quad (55.15)$$

一般 F_β ：

$$F_\beta = (1 + \beta^2) \frac{PR}{\beta^2 P + R}. \quad (55.16)$$

当 $\beta = 1$ ：

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + \text{FP} + \text{FN}}. \quad (55.17)$$

55.6.1 Macro 与 Micro

对多类别任务：

Macro- F_1 ：

$$F_1^{\text{macro}} = \frac{1}{C} \sum_{c=1}^C F_{1,c}. \quad (55.18)$$

它对每个类别赋予相同权重，适合关注少数类表现。

Micro- F_1 先聚合所有类别的 TP、FP、FN：


$$F_1^{\text{micro}} = \frac{2 \sum_c \text{TP}_c}{2 \sum_c \text{TP}_c + \sum_c \text{FP}_c + \sum_c \text{FN}_c}. \quad (55.19)$$

它更受高频类别影响。

55.6.2 为什么 Accuracy 可能误导

若正类比例仅为 0.01，始终预测负类的系统有 99% accuracy，但 $R = 0$ 。

因此在 rare-event detection、NER、information extraction 和 retrieval 中，通常需报告 Precision、Recall 和 F_1 。



55.7 Train、Development 与 Test

1. training set 用于拟合模型参数;

2. development set 用于:

- 选择 α ;
- 选择 feature;
- 调整分类阈值;
- early stopping;
- 模型选择;

3. test set 只用于最终报告。

若在 test set 上选择阈值或特征, 则测试误差不再是未见数据性能的无偏估计。

55.8 典型综合例题

例 55.1 (Add- α Naive Bayes). 设有两类 $\mathcal{Y} = \{+, -\}$, 词表 $\mathcal{V} = \{\text{好, 差, 退款}\}$, $V = 3$ 。

训练计数为 $N_+ = 3$, $N_- = 2$, $C(\text{好}, +) = 4$, $C(\text{差}, +) = 0$, $C(\text{退款}, +) = 1$, $C(\text{好}, -) = 0$, $C(\text{差}, -) = 3$, $C(\text{退款}, -) = 2$ 。

取 $\alpha = 1$ 。则 $\hat{p}(+) = \frac{3}{5}$, $\hat{p}(-) = \frac{2}{5}$ 。

正类 token 总计数为 5, 故 $\hat{p}(\text{退款} | +) = \frac{1+1}{5+3} = \frac{1}{4}$ 。

负类 token 总计数也为 5, 故 $\hat{p}(\text{退款} | -) = \frac{2+1}{5+3} = \frac{3}{8}$ 。

对测试文档 $d = (\text{差}, \text{退款})$, 比较

$$s(+) = \log \frac{3}{5} + \log \frac{1}{8} + \log \frac{1}{4}, \quad (55.20)$$

$$s(-) = \log \frac{2}{5} + \log \frac{1}{2} + \log \frac{3}{8}. \quad (55.21)$$

由于 $s(-) > s(+)$, 预测为负类。

55.9 答题方法

答题方法

看到“设计文本分类模型”时, 标准答法:

1. 定义数据: $\{(d_i, y_i)\}_{i=1}^N$;
2. 说明 tokenizer、词表和文档长度处理;
3. 说明输入表示: bag-of-words、TF-IDF、embedding 或 contextual representation;
4. 写出模型: $p_\theta(y | d)$;
5. 写出训练目标: $-\sum_i \log p_\theta(y_i | d_i)$;
6. 写出推理: $\hat{y} = \arg \max_y p_\theta(y | d)$;

7. 说明类别不平衡时使用 Precision、Recall、Macro- F_1 ;
8. 说明 train/dev/test 划分;
9. 给出错误分析: OOV、domain shift、label imbalance、negation、long context;
10. 给出时间和空间复杂度。

55.10 快速自测

快速自测

1. Multinomial Naive Bayes 的两个主要独立性假设是什么?
2. 为什么推理在 log-space 中进行?
3. 写出 add- α token likelihood。
4. 为什么词表必须对所有类别统一?
5. $p(w | c)$ 与 $p(c | w)$ 有何区别?
6. Accuracy 在类别极不平衡时为什么可能失效?
7. Precision 和 Recall 分别惩罚哪类错误?
8. Macro- F_1 和 Micro- F_1 的权重偏好有何不同?
9. 使用 test set 选择阈值为什么构成数据泄漏?
10. Naive Bayes 的训练、推理和存储复杂度分别是什么?



第五十六章 序列标注、HMM 与 Linear-Chain CRF

56.1 重要性等级与资料边界

重要性等级：B

HMM 和 CRF 明确列入考纲，并由 [SLP] 作为经典 sequence labeling 生成模型与判别模型进行系统讲解。

它们未在三套博资考中被直接单独考查，因此本讲义将其定位为：

- NLP 结构化预测的必要基础；
- 理解全局归一化、动态规划和条件概率模型的母题；
- 未选择 NLP 方向时仍应保留的备用答题能力。

必须会完整写出：

- HMM joint factorization；
- HMM 的 transition 与 emission MLE；
- Viterbi recurrence；
- CRF conditional probability；
- CRF negative log-likelihood 与 gradient；
- HMM/CRF 的复杂度和假设差异。

56.2 序列标注问题设定

输入序列：

$$\mathbf{x} = (x_1, \dots, x_T) \in \mathcal{V}^T. \quad (56.1)$$

输出标签序列：

$$\mathbf{y} = (y_1, \dots, y_T) \in \mathcal{Y}^T, \quad \mathcal{Y} = \{1, \dots, K\}. \quad (56.2)$$

目标是学习：

$$f: \mathcal{V}^T \rightarrow \mathcal{Y}^T. \quad (56.3)$$

与逐 token 独立分类不同，结构化预测还需要建模标签之间的兼容性，例如：B-PER $\rightarrow$ I-PER 合理，而 O $\rightarrow$ I-PER 在标准 BIO 约定下通常非法。



56.3 BIO 标记

对 entity type c , 定义:

- B- c : 实体开头;
- I- c : 实体内部;
- O: 非实体。

例如 Jane Villanueva works in Chicago 可标记为 B-PER, I-PER, O, O, B-LOC。

易错点、反例与失败模式

NER 评价通常以完整 entity span 为单位, 而不是简单 token accuracy。

若 gold entity 是 [Jane Villanueva]_{PER}, 系统只预测 [Jane]_{PER}, 通常不能算作完整正确实体。

56.4 Hidden Markov Model

56.4.1 参数与维度

一阶离散 HMM 参数为 $\lambda = (\boldsymbol{\pi}, \mathbf{A}, \mathbf{B})$, 其中:

初始分布:

$$\boldsymbol{\pi} \in \mathbb{R}^K, \quad \pi_j = p(y_1 = j), \quad \sum_{j=1}^K \pi_j = 1. \quad (56.4)$$

转移矩阵:

$$\mathbf{A} \in \mathbb{R}^{K \times K}, \quad A_{ij} = p(y_t = j \mid y_{t-1} = i), \quad (56.5)$$

满足 $A_{ij} \geq 0$, $\sum_{j=1}^K A_{ij} = 1$ 。

发射矩阵:

$$\mathbf{B} \in \mathbb{R}^{K \times V}, \quad B_{jv} = p(x_t = v \mid y_t = j), \quad (56.6)$$

满足 $B_{jv} \geq 0$, $\sum_{v=1}^V B_{jv} = 1$ 。

56.4.2 两个核心条件

定义 56.1 (一阶 Markov 假设).

$$p(y_t \mid y_{1:t-1}) = p(y_t \mid y_{t-1}). \quad (56.7)$$


定义 56.2 (Output Independence).

$$p(x_t \mid \mathbf{y}, \mathbf{x}_{\setminus t}) = p(x_t \mid y_t). \quad (56.8)$$

由此联合分布分解为

$$p_{\lambda}(\mathbf{x}, \mathbf{y}) = \pi_{y_1} B_{y_1, x_1} \prod_{t=2}^T A_{y_{t-1}, y_t} B_{y_t, x_t}. \quad (56.9)$$

若显式建模终止状态, 还应乘 $A_{y_T, \text{EOS}}$ 。



56.4.3 为什么两个假设不能省

若去掉 Markov 假设: $p(y_t | y_{1:t-1})$ 需要为所有历史设置参数, 标签历史数随 T 指数增长。

若去掉 output independence: $p(x_t | \mathbf{y}, \mathbf{x}_{\setminus t})$ 可能依赖整个输入输出序列, 简单的局部因子分解和 $O(TK^2)$ 动态规划不再成立。

因此这两个条件不仅是统计简化, 也是高效精确推理的结构条件。

56.5 HMM 的监督 MLE

给定有标签训练语料 $\{(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})\}_{n=1}^N$, 定义:

- $C_{\text{start}}(j)$: 标签 j 作为句首标签的次数;
- $C(i, j)$: 转移 $i \rightarrow j$ 的次数;
- $C(i)$: 标签 i 作为前一标签的总次数;
- $C(j, v)$: 标签 j 发射 token v 的次数;
- $C(j)$: 标签 j 的总出现次数。

未平滑 MLE:

$$\hat{\pi}_j = \frac{C_{\text{start}}(j)}{N}, \quad (56.10)$$

$$\hat{A}_{ij} = \frac{C(i, j)}{C(i)}, \quad (56.11)$$

$$\hat{B}_{jv} = \frac{C(j, v)}{C(j)}. \quad (56.12)$$

Add- α transition smoothing:

$$\hat{A}_{ij}^{(\alpha)} = \frac{C(i, j) + \alpha}{C(i) + \alpha K}. \quad (56.13)$$

Add- β emission smoothing:

$$\hat{B}_{jv}^{(\beta)} = \frac{C(j, v) + \beta}{C(j) + \beta V}. \quad (56.14)$$

易错点、反例与失败模式


HMM emission 是 $p(x_t | y_t)$, 不是 $p(y_t | x_t)$ 。

例如 $p(\text{will} | \text{MD})$ 表示“若标签是 modal verb, 发射 will 的概率”, 不是“看到 will 后其标签为 MD 的 posterior”。

56.6 HMM Decoding

目标是

$$\hat{\mathbf{y}} = \arg \max_{\mathbf{y} \in \mathcal{Y}^T} p(\mathbf{y} | \mathbf{x}). \quad (56.15)$$



因为给定 $\mathbf{x}$ 后 $p(\mathbf{x})$ 不依赖 $\mathbf{y}$, 所以

$$\begin{aligned}\hat{\mathbf{y}} &= \arg \max_{\mathbf{y}} p(\mathbf{x}, \mathbf{y}) \\ &= \arg \max_{\mathbf{y}} \pi_{y_1} B_{y_1, x_1} \prod_{t=2}^T A_{y_{t-1}, y_t} B_{y_t, x_t}.\end{aligned}\quad (56.16)$$

直接枚举有 K^T 个标签序列, 不可行。

56.7 Viterbi Algorithm

为避免下溢, 使用 log-space。

定义

$$\delta_t(j) = \max_{y_{1:t-1}} \log p(x_{1:t}, y_{1:t-1}, y_t = j). \quad (56.17)$$

初始化:

$$\delta_1(j) = \log \pi_j + \log B_{j, x_1}. \quad (56.18)$$

递推:

$$\delta_t(j) = \log B_{j, x_t} + \max_{1 \leq i \leq K} [\delta_{t-1}(i) + \log A_{ij}]. \quad (56.19)$$

回溯指针:

$$\psi_t(j) = \arg \max_{1 \leq i \leq K} [\delta_{t-1}(i) + \log A_{ij}]. \quad (56.20)$$

终止:

$$\hat{y}_T = \arg \max_j \delta_T(j). \quad (56.21)$$

回溯:

$$\hat{y}_{t-1} = \psi_t(\hat{y}_t), \quad t = T, T-1, \dots, 2. \quad (56.22)$$

56.7.1 复杂度

每个时间步有 K 个当前状态, 每个当前状态检查 K 个前驱:

$$T_{\text{Viterbi}} = O(TK^2). \quad (56.23)$$

保存全部 backpointer:

$$S_{\text{Viterbi}} = O(TK). \quad (56.24)$$

若只需要最优分数而不需要路径, 可滚动保存两列: $O(K)$ 空间。

若转移图只有 E 条合法边, 可降为 $O(TE)$ 。

56.8 Forward Algorithm

Viterbi 使用 max, 计算最优单条路径; Forward 使用 sum, 计算所有路径总概率。

定义

$$\alpha_t(j) = p(x_{1:t}, y_t = j). \quad (56.25)$$



初始化:

$$\alpha_1(j) = \pi_j B_{j,x_1}. \quad (56.26)$$

递推:

$$\alpha_t(j) = B_{j,x_t} \sum_{i=1}^K \alpha_{t-1}(i) A_{ij}. \quad (56.27)$$

边缘似然:

$$p(\mathbf{x}) = \sum_{j=1}^K \alpha_T(j). \quad (56.28)$$

时间复杂度仍为 $O(TK^2)$ 。

易错点、反例与失败模式

Viterbi 和 Forward 的递推不能混淆:

Viterbi: $\max \implies$ 最可能路径; Forward: $\sum \implies$ 所有路径概率和。

用 Viterbi score 代替 $p(\mathbf{x})$ 会忽略其他标签路径的概率质量。

56.9 HMM 的失败模式

1. Unknown word。

若 $B_{j,x_t} = 0$ 对所有标签均成立, Viterbi 整列不可达。需使用 smoothing、UNK、subword 或 morphology feature。

2. 生成式建模负担。

HMM 必须建模 $p(\mathbf{x}, \mathbf{y})$, 包括对分类未必必要的 $p(\mathbf{x} | \mathbf{y})$ 。

3. 特征表达受限。

任意 capitalization、suffix、邻近词和字形特征难以自然加入 A 与 B 两张概率表。

4. 局部标签依赖。

一阶 HMM 只直接建模 $y_{t-1} \rightarrow y_t$ 。长距离标签约束需高阶状态扩张或其他模型。

5. Domain shift。

发射概率和转移概率高度依赖训练语料的语域。


56.10 Conditional Random Field

56.10.1 模型定义

设 feature dimension 为 M 。

对位置 t 、前一标签 i 、当前标签 j , 定义局部特征:

$$\mathbf{f}(i, j, \mathbf{x}, t) \in \mathbb{R}^M. \quad (56.29)$$



参数向量:

$$\boldsymbol{\theta} \in \mathbb{R}^M. \quad (56.30)$$

局部 score:

$$s_t(i, j; \mathbf{x}) = \boldsymbol{\theta}^\top \mathbf{f}(i, j, \mathbf{x}, t). \quad (56.31)$$

整条标签序列 score:

$$S_\theta(\mathbf{x}, \mathbf{y}) = \sum_{t=1}^T \boldsymbol{\theta}^\top \mathbf{f}(y_{t-1}, y_t, \mathbf{x}, t), \quad (56.32)$$

其中 y_0 为 BOS label。

定义全局特征:

$$\mathbf{F}(\mathbf{x}, \mathbf{y}) = \sum_{t=1}^T \mathbf{f}(y_{t-1}, y_t, \mathbf{x}, t). \quad (56.33)$$

于是 $S_\theta(\mathbf{x}, \mathbf{y}) = \boldsymbol{\theta}^\top \mathbf{F}(\mathbf{x}, \mathbf{y})$ 。

Linear-chain CRF 的条件概率为

$$p_\theta(\mathbf{y} \mid \mathbf{x}) = \frac{\exp[\boldsymbol{\theta}^\top \mathbf{F}(\mathbf{x}, \mathbf{y})]}{Z_\theta(\mathbf{x})}, \quad (56.34)$$

其中 partition function 为

$$Z_\theta(\mathbf{x}) = \sum_{\mathbf{y}' \in \mathcal{Y}^T} \exp[\boldsymbol{\theta}^\top \mathbf{F}(\mathbf{x}, \mathbf{y}')]. \quad (56.35)$$

56.10.2 Linear-Chain 条件

局部特征可以依赖: y_{t-1} , y_t , $\mathbf{x}$, t , 即可以查看完整输入 $\mathbf{x}$, 但输出标签依赖只连接相邻标签。

这一限制使 partition function 和 MAP decoding 可用 $O(TK^2)$ 动态规划精确计算。

56.10.3 合法特征示例

$f_1(i, j, \mathbf{x}, t) = \mathbf{1}\{x_t = \text{"the"}, j = \text{DET}\}$, $f_2(i, j, \mathbf{x}, t) = \mathbf{1}\{i = \text{AUX}, j = \text{VERB}\}$, $f_3(i, j, \mathbf{x}, t) = \mathbf{1}\{x_t \text{ 以 -ed 结尾}, j = \text{VBD}\}$, $f_4(i, j, \mathbf{x}, t) = \mathbf{1}\{x_t \text{ 首字母大写}, j = \text{B-PER}\}$ 。

CRF 可以自然整合:

- 当前词和邻近词;
- prefix、suffix;
- capitalization;
- word shape;
- gazetteer;
- pretrained embedding;
- neural encoder score。



56.11 CRF 的训练目标

给定有标签训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})\}_{n=1}^N$, 正则化负 log-likelihood 为

$$\begin{aligned}\mathcal{L}(\boldsymbol{\theta}) &= - \sum_{n=1}^N \log p_{\boldsymbol{\theta}}(\mathbf{y}^{(n)} | \mathbf{x}^{(n)}) + \frac{\lambda}{2} \|\boldsymbol{\theta}\|^2 \\ &= - \sum_{n=1}^N \boldsymbol{\theta}^{\top} \mathbf{F}(\mathbf{x}^{(n)}, \mathbf{y}^{(n)}) \\ &\quad + \sum_{n=1}^N \log Z_{\boldsymbol{\theta}}(\mathbf{x}^{(n)}) + \frac{\lambda}{2} \|\boldsymbol{\theta}\|^2.\end{aligned}\quad (56.36)$$

56.11.1 梯度推导

对单个样本:

$$\begin{aligned}\nabla_{\boldsymbol{\theta}} \log Z_{\boldsymbol{\theta}}(\mathbf{x}) &= \frac{1}{Z_{\boldsymbol{\theta}}(\mathbf{x})} \sum_{\mathbf{y}'} \exp[\boldsymbol{\theta}^{\top} \mathbf{F}(\mathbf{x}, \mathbf{y}')] \mathbf{F}(\mathbf{x}, \mathbf{y}') \\ &= \sum_{\mathbf{y}'} p_{\boldsymbol{\theta}}(\mathbf{y}' | \mathbf{x}) \mathbf{F}(\mathbf{x}, \mathbf{y}') \\ &= \mathbb{E}_{\mathbf{Y} \sim p_{\boldsymbol{\theta}}(\cdot | \mathbf{x})} [\mathbf{F}(\mathbf{x}, \mathbf{Y})].\end{aligned}\quad (56.37)$$

因此

$$\nabla \mathcal{L}(\boldsymbol{\theta}) = - \sum_{n=1}^N \mathbf{F}(\mathbf{x}^{(n)}, \mathbf{y}^{(n)}) + \sum_{n=1}^N \mathbb{E}_{p_{\boldsymbol{\theta}}(\mathbf{Y} | \mathbf{x}^{(n)})} [\mathbf{F}(\mathbf{x}^{(n)}, \mathbf{Y})] + \lambda \boldsymbol{\theta}.\quad (56.38)$$

梯度具有标准形式:

$$\boxed{\text{model expected feature counts} - \text{empirical feature counts} + \text{regularization}.}\quad (56.39)$$

最大化 log-likelihood 时符号相反: empirical counts – model expected counts。

56.11.2 凸性

对固定特征 $\mathbf{F}(\mathbf{x}, \mathbf{y})$, $\log Z_{\boldsymbol{\theta}}(\mathbf{x}) = \log \sum_{\mathbf{y}'} \exp(\boldsymbol{\theta}^{\top} \mathbf{F}(\mathbf{x}, \mathbf{y}'))$ 是 log-sum-exp, 因此关于 $\boldsymbol{\theta}$ 凸。

负对数似然是: 凸函数 – 线性函数, 故仍凸。

当 $\lambda > 0$ 且全部参数均受 ℓ_2 正则化时, 目标强凸且 coercive, 因此存在唯一参数最优解。

若 CRF feature 由神经网络共同学习, 整体目标对神经网络参数通常非凸; 不能把线性 CRF 的凸性结论直接推广到 neural CRF 全部参数。

56.12 CRF Partition Function 的 Forward Recurrence

定义 log-forward:

$$a_t(j) = \log \sum_{y_{1:t-1}} \exp \left[\sum_{\tau=1}^t s_{\tau}(y_{\tau-1}, y_{\tau}; \mathbf{x}) \right] \mathbf{1}\{y_t = j\}.\quad (56.40)$$



定义

$$\text{LSE}(u_1, \dots, u_K) = \log \sum_{i=1}^K e^{u_i}. \quad (56.41)$$

初始化:

$$a_1(j) = s_1(\text{BOS}, j; \mathbf{x}). \quad (56.42)$$

递推:

$$a_t(j) = \text{LSE}_{1 \leq i \leq K} [a_{t-1}(i) + s_t(i, j; \mathbf{x})]. \quad (56.43)$$

若无显式 EOS score:

$$\log Z_\theta(\mathbf{x}) = \text{LSE}_j a_T(j). \quad (56.44)$$

为数值稳定, 计算 $\text{LSE}(u_1, \dots, u_K) = m + \log \sum_i e^{u_i - m}$, $m = \max_i u_i$ 。

56.13 CRF MAP Decoding

$$\hat{\mathbf{y}} = \arg \max_{\mathbf{y}} p_\theta(\mathbf{y} | \mathbf{x}). \quad (56.45)$$

对固定 $\mathbf{x}$, $Z_\theta(\mathbf{x})$ 与 $\mathbf{y}$ 无关, 且 $\exp$ 单调, 因此

$$\begin{aligned} \hat{\mathbf{y}} &= \arg \max_{\mathbf{y}} S_\theta(\mathbf{x}, \mathbf{y}) \\ &= \arg \max_{\mathbf{y}} \sum_{t=1}^T s_t(y_{t-1}, y_t; \mathbf{x}). \end{aligned} \quad (56.46)$$

Viterbi score recurrence:

$$\delta_t(j) = \max_i [\delta_{t-1}(i) + s_t(i, j; \mathbf{x})]. \quad (56.47)$$

backpointer:

$$\psi_t(j) = \arg \max_i [\delta_{t-1}(i) + s_t(i, j; \mathbf{x})]. \quad (56.48)$$

复杂度:

$$O(TK^2) \quad (56.49)$$

次 transition score 比较。

若每条边的 dense feature score 需 $O(M)$ 计算, 朴素总成本为 $O(TK^2M)$ 。实际常通过稀疏 feature、预计算 emission score 和独立 transition matrix 降低常数。

存储 backpointer 为 $O(TK)$ 。

56.14 HMM 与 CRF 对比



表 56.1: HMM 与 linear-chain CRF

比较项	HMM	Linear-chain CRF
模型类型	生成式模型	判别式条件模型
建模分布	$p(\mathbf{x}, \mathbf{y})$	$p(\mathbf{y} \mathbf{x})$
主要分解	$p(y_1) \prod_t p(x_t y_t) p(y_t y_{t-1})$	$Z(\mathbf{x})^{-1} \exp \sum_t \theta^\top f(y_{t-1}, y_t, \mathbf{x}, t)$
输入依赖假设	发射仅依赖当前标签	特征可查看整个输入序列
输出依赖	一阶标签 Markov	一阶标签链
参数训练	监督计数 MLE; 无监督可用 EM	最大化条件 log-likelihood; 梯度需 forward-backward
解码	Viterbi	Viterbi
Marginal/Partition	Forward-Backward	Forward-Backward
时间复杂度	$O(TK^2)$	$O(TK^2)$, 不含 feature score 成本
主要优点	参数直观; 监督 MLE 闭式; 可以生成 $(\mathbf{x}, \mathbf{y})$	可使用任意输入特征; 直接优化条件判别; 全局序列归一化
主要失败模式	发射假设强; OOV; 难加入复杂特征	partition function 成本; 仍只有局部输出依赖; feature 或 encoder 可能过拟合

56.15 为什么 CRF 不能省去 Partition Function

若直接定义未归一化 score $\exp[S_\theta(\mathbf{x}, \mathbf{y})]$ 而不除以 $Z_\theta(\mathbf{x})$, 则一般有 $\sum_{\mathbf{y}} \exp[S_\theta(\mathbf{x}, \mathbf{y})] \neq 1$ 。此时:

- 不能解释为条件概率;
- 不能直接写条件 log-likelihood;
- 不同输入长度的 score 尺度不可直接比较;
- 梯度中缺少 model expectation 项。

56.16 典型识别与使用方法

答题方法

看到“隐状态生成观测”时:

想到 HMM: $p(x, y) = p(y_1) \prod_t p(y_t | y_{t-1}) p(x_t | y_t)$ 。

看到“给定整句输入预测标签序列, 并加入任意特征”时:

想到 CRF: $p(y | x) = Z(x)^{-1} \exp \sum_t \theta^\top f(y_{t-1}, y_t, x, t)$ 。

看到“最可能标签路径”时:

想到 Viterbi: max+backpointer。

看到“观测序列总概率、partition 或边缘概率”时:

想到 Forward-Backward: $\sum$ 而不是 max。

看到“CRF 梯度”时：

想到 model expected feature counts – empirical feature counts。

56.17 HMM/CRF 答题方法

答题方法

若题目要求“比较 HMM 与 CRF”，满分答案至少包括：

1. 数据和维度： $x_{1:T} \in \mathcal{V}^T$, $y_{1:T} \in [K]^T$;
2. HMM: $p(x, y) = \pi_{y_1} B_{y_1, x_1} \prod_{t=2}^T A_{y_{t-1}, y_t} B_{y_t, x_t}$;
3. HMM 假设: first-order Markov 和 output independence;
4. CRF: $p_\theta(y | x) = \frac{\exp[\theta^\top F(x, y)]}{\sum_{y'} \exp[\theta^\top F(x, y')]}$;
5. 生成式与判别式区别: $p(x, y)$ vs. $p(y | x)$;
6. HMM 参数由 transition/emission counts 估计;
7. CRF 通过 conditional log-likelihood 训练;
8. 两者 MAP inference 都可用 Viterbi;
9. 两者一阶链的主要动态规划复杂度均为 $O(TK^2)$;
10. HMM 难以加入任意输入特征; CRF 可以利用整句输入特征, 但需计算 partition function。

56.18 综合易错点

易错点、反例与失败模式

1. Sequence classification 输出一个标签; sequence labeling 输出等长标签序列。
2. HMM 的隐藏变量是标签, 观测变量是 token。
3. HMM 发射方向为 $p(x_t | y_t)$ 。
4. Viterbi 求最优路径, Forward 求全部路径概率和。
5. HMM 的 $\max_y p(x, y)$ 不是 $p(x) = \sum_y p(x, y)$ 。
6. CRF 直接建模 $p(y | x)$, 不需要建模 $p(x)$ 。
7. CRF 的 local feature 可查看整个输入, 但 linear-chain 输出依赖仍只连接相邻标签。
8. CRF partition function 依赖输入 x , 但对固定 x 的 MAP argmax 可消去。
9. CRF gradient 中 model expectation 不能省。
10. Linear CRF 的 NLL 对 θ 凸; neural encoder 与 CRF 联合训练通常非凸。
11. Token accuracy 与 entity-level F1 不等价。

12. BIO 非法转移应通过 transition mask、训练约束或解码约束处理。
13. $O(TK^2)$ 不包括神经 encoder 的前向复杂度。
14. HMM/CRF 在三套真题中没有直接出现，不能被写成“历年博资考高频”，但仍是考纲核心。

56.19 本部分资料与真题映射

表 56.2: 自然语言处理第 15 部分映射

主题	等级	博资考对应	方向资料对应
任务形式与评价	A	三套真题系统设计和模型题的共同前置；无独立计频	[NLP-Train] 建模、评估、算法总览；[SLP] Ch.4、Ch.17
Word/token/subword	A	无直接独立真题	[SLP] Ch.2
BPE	B	无直接独立真题	[SLP] Ch.2.5
Trigram MLE	A	[25S-D-Q1, 3 分]	[NLP-Train] pp.28–42；[SLP] Ch.3
Smoothing、interpolation、backoff	A	[25S-D-Q1, 3 分]	[SLP] Ch.3.6
Perplexity	B	无直接独立真题；为 scaling law 和 LM 评价前置	[NLP-Train] pp.39–42；[SLP] Ch.3.3
Multinomial Naive Bayes	B	无直接独立真题	[SLP] Ch.4
Precision、Recall、F1	A	系统设计题评价模块的共同要求	[NLP-Train] 总览；[SLP] Ch.4.7、Ch.17.6
HMM	B	三套真题无直接题	[SLP] Ch.17.4
Linear-chain CRF	B	三套真题无直接题	[NLP-Train] 课程总览；[SLP] Ch.17.5

说明 56.3. 机器学习理论课程期末、练习和作业 [MLT-Final]、[MLT-Practice]、[MLT-HW1–3] 不作为本部分 NLP 真题频率证据。

本部分未将任何 MLT 课程题计入人工智能博资考出现次数。

56.20 本部分综合快速自测

快速自测

1. 为什么 tokenization 是模型定义的一部分，而不仅是工程预处理？
2. BPE 中 token learner 与 token segmenter 分别做什么？
3. 词表大小如何同时影响 embedding 参数量和 attention 长度？
4. Trigram MLE 在什么条件下有定义？

5. Unseen continuation、unseen history 和 OOV 的处理分别是什么?
6. Add- k 、interpolation 和 backoff 各自如何保证或不保证归一化?
7. Stupid backoff 为什么只能称为 score?
8. Perplexity 与平均负 log-likelihood 的关系是什么?
9. 为什么不同 tokenizer 的 perplexity 通常不能直接比较?
10. Naive Bayes 的生成过程是什么?
11. Bag-of-words 丢失了哪些语言信息?
12. Macro- F_1 与 Micro- F_1 分别强调什么?
13. 写出 HMM 的完整 joint factorization。
14. HMM 的两个核心条件是什么?
15. 写出 HMM transition 和 emission 的监督 MLE。
16. Viterbi 的状态量、递推量和 backpointer 分别是什么?
17. Forward 与 Viterbi 唯一关键运算差别是什么?
18. 写出 linear-chain CRF 的 partition function。
19. CRF local feature 可以依赖哪些变量?
20. 推导 $\nabla_{\theta} \log Z_{\theta}(x)$ 。
21. 为什么 CRF 梯度是 empirical counts 与 expected counts 之差?
22. Linear CRF 的 NLL 为什么是凸函数?
23. HMM 和 CRF 的主要推理复杂度为何都是 $O(TK^2)$?
24. Neural CRF 的整体训练目标是否仍关于全部参数凸?
25. 为什么 NER 应优先报告 entity-level F1 而不是只报告 token accuracy?



第五十七章 向量语义、Word2vec 与图表示学习

57.1 重要性等级与考试定位

重要性等级：S

表示学习 (representation learning) 是 NLP 方向的核心母题。

直接真题包括：

- [25S-D-Q2, 3 分]: representation learning 的中心思想及代表算法；
- [25F-D-Q1, 3 分]: GloVe、Skip-gram、Node2Vec 和 TransE 的 data signal、objective type 与 inductive bias；
- [26S-D-Q1, 6 分]: unit-norm sentence embedding、InfoNCE gradient、高维负样本与 false negative。

因此必须区分：

1. sparse count representation 与 dense learned embedding；
2. static embedding 与 contextual embedding；
3. text co-occurrence、graph random walk 和 knowledge-graph triple 三类训练信号；
4. full softmax、binary negative sampling、weighted regression 和 margin ranking 四类目标函数；
5. similarity、association、事实关系和逻辑推理之间的边界。

57.2 统一记号与矩阵方向

本章采用如下主约定。

词表： $\mathcal{V} = \{1, \dots, V\}$ 。

embedding 维度： $d \ll V$ 。

one-hot 向量： $\mathbf{e}_w \in \mathbb{R}^V$ 。

embedding matrix 采用行存储：

$$\mathbf{E} \in \mathbb{R}^{V \times d}, \quad \mathbf{v}_w = \mathbf{E}^\top \mathbf{e}_w \in \mathbb{R}^d. \quad (57.1)$$

亦可等价写成查表： $\mathbf{v}_w = \mathbf{E}_{w,:}^\top$ 。



[SLP] 的部分公式采用 $\mathbf{E}_{\text{SLP}} \in \mathbb{R}^{d \times V}$, $\mathbf{v}_w = \mathbf{E}_{\text{SLP}} \mathbf{e}_w$ 。二者关系是 $\mathbf{E}_{\text{SLP}} = \mathbf{E}^\top$ 。

全文不得在同一个矩阵乘法中静默混合这两种约定。

57.3 Representation Learning 的精确定义

定义 57.1 (表示学习). 设原始输入空间为 $\mathcal{X}$, 表示空间为 $\mathbb{R}^d$ 。表示学习是从数据中学习映射

$$\phi_\theta : \mathcal{X} \rightarrow \mathbb{R}^d, \quad (57.2)$$

使得表示 $\mathbf{z} = \phi_\theta(x)$ 保留某个训练目标或下游任务所需的信息。

若存在下游预测器 $g_\omega : \mathbb{R}^d \rightarrow \mathcal{Y}$, 则端到端目标可写为

$$\min_{\theta, \omega} \frac{1}{N} \sum_{i=1}^N \ell(g_\omega(\phi_\theta(x_i)), y_i). \quad (57.3)$$

若没有人工标签, 可以从数据自身构造监督信号, 例如:

- 用中心词预测上下文词;
- 用被 mask 的 token 作为预测目标;
- 用同一语义对象的两个 view 构造正样本;
- 用图随机游走中的邻近节点构造上下文;
- 用知识图谱中的真三元组构造正例。

57.3.1 Representation Learning 不等于什么

易错点、反例与失败模式

以下说法均不准确:

1. “表示学习就是降维。”

降维可能是结果, 但表示维度也可能高于原始手工特征维度。

2. “表示学习就是 embedding lookup。”

lookup table 只是参数化方式; 真正决定表示含义的是训练信号、目标函数和 inductive bias。

3. “embedding 相近意味着事实相同。”

embedding proximity 通常只表示训练目标下的统计关联, 不能自动推出事实正确、因果关系或逻辑蕴含。

4. “表示学习一定优于手工特征。”

在数据稀缺、分布迁移、强约束或高可解释性场景中, 手工特征、规则和符号约束仍可能更稳健。

57.4 Distributional Hypothesis 与向量语义

分布假设(distributional hypothesis)的核心是: 具有相似语言环境的词, 往往具有相似语义或功能。

设语料中目标词为 w ，上下文对象为 c 。上下文可以是：

- 邻近词；
- 文档；
- 句法依存关系；
- 图随机游走中的邻近节点；
- 知识图谱中的关系与相邻实体。

由共现计数构造矩阵

$$\mathbf{X} \in \mathbb{R}_+^{V \times C}, \quad X_{wc} = \#\{w \text{ 与 context } c \text{ 共现}\}. \quad (57.4)$$

若 context 也是词，则通常 $C = V$ 。

目标词 w 的 sparse representation 是第 w 行： $\mathbf{x}_w = (X_{w1}, \dots, X_{wC})^\top$ 。

57.4.1 One-Hot 与 Distributional Vector

one-hot: $\mathbf{e}_w \in \{0, 1\}^V$ 只编码身份: $\mathbf{e}_u^\top \mathbf{e}_v = \mathbf{1}\{u = v\}$ 。

因此不同词的 one-hot 均正交，不能表达: $\text{car} \approx \text{automobile}$ 。

共现向量则通过环境重合表达相似性: $\mathbf{x}_{\text{car}} \approx \mathbf{x}_{\text{automobile}}$ 。

57.5 Cosine Similarity

定义 57.2 (余弦相似度). 对非零向量 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^d \setminus \{\mathbf{0}\}$, 余弦相似度定义为

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}. \quad (57.5)$$

若 $\|\mathbf{u}\|_2 = \|\mathbf{v}\|_2 = 1$, 则 $\cos(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top \mathbf{v}$ 。

对一般实向量: $-1 \leq \cos(\mathbf{u}, \mathbf{v}) \leq 1$ 。

对非负 count vector: $0 \leq \cos(\mathbf{u}, \mathbf{v}) \leq 1$ 。

57.5.1 为什么不用原始 Dot Product

若 $\mathbf{u}' = a\mathbf{u}$, $a > 0$, 则 $\mathbf{u}'^\top \mathbf{v} = a\mathbf{u}^\top \mathbf{v}$, 但 $\cos(\mathbf{u}', \mathbf{v}) = \cos(\mathbf{u}, \mathbf{v})$ 。

因此 cosine 消除了向量整体长度的影响，而原始 dot product 容易偏好高频词形成的长向量。

易错点、反例与失败模式

若 $\mathbf{u} = \mathbf{0}$ 或 $\mathbf{v} = \mathbf{0}$, cosine 分母为零，未定义。

工程实现中加入 ε 只是数值处理，不应把零向量解释成具有确定语义方向。

57.6 TF-IDF

57.6.1 问题设定

设文档集合为 $\mathcal{D} = \{d_1, \dots, d_D\}$ 。

词 t 在文档 d 中的 count: $c_{t,d} = \text{count}(t, d)$ 。

document frequency:

$$\text{df}_t = \sum_{d=1}^D \mathbf{1}\{c_{t,d} > 0\}. \quad (57.6)$$

注意: $\text{df}_t \neq \sum_{d=1}^D c_{t,d}$, 后者是 collection frequency。

57.6.2 Term Frequency

本文默认自然对数:

$$\text{tf}_{t,d} = \begin{cases} 1 + \log c_{t,d}, & c_{t,d} > 0, \\ 0, & c_{t,d} = 0. \end{cases} \quad (57.7)$$

[SLP] 使用 $\log_{10}$ 。两种底数只相差正常数 $\log_{10} x = \frac{\ln x}{\ln 10}$, 但在严格复现实验时必须固定约定。

57.6.3 Inverse Document Frequency

主约定:

$$\text{idf}_t = \log \frac{D}{\text{df}_t}. \quad (57.8)$$

TF-IDF:

$$\boxed{\text{tfidf}_{t,d} = \text{tf}_{t,d} \text{idf}_t}. \quad (57.9)$$

若词 t 出现在所有文档: $\text{df}_t = D$, 则 $\text{idf}_t = 0$ 。

常见平滑变体为

$$\text{idf}_t^{\text{smooth}} = \log \frac{D+1}{\text{df}_t+1} + 1. \quad (57.10)$$

式 (57.8) 与 (57.10) 不是同一个参数化, 比较实验时不得静默替换。

57.6.4 TF-IDF 的 Inductive Bias

TF 部分假设: 文档内部多次出现的词更重要, 但通过 $\log$ 抑制线性增长。

IDF 部分假设: 跨大量文档普遍出现的词缺乏区分度。

其主要适用场景:

- sparse document retrieval;
- 文档相似度;
- 传统文本分类;
- query-document matching baseline。

主要失败模式:



- 忽略顺序；
- 无法自然处理同义词；
- 无法处理 polysemy；
- document boundary 的选择会改变 IDF；
- 词表和 preprocessing 改变后数值不可直接比较。

57.7 PMI 与 PPMI

57.7.1 概率定义

设 X_{wc} 为目标词 w 与上下文 c 的共现次数。

总共现计数：

$$N = \sum_{w=1}^V \sum_{c=1}^C X_{wc}. \quad (57.11)$$

定义：

$$\hat{p}(w, c) = \frac{X_{wc}}{N}, \quad (57.12)$$

$$\hat{p}(w) = \frac{X_{w*}}{N}, \quad X_{w*} = \sum_c X_{wc}, \quad (57.13)$$

$$\hat{p}(c) = \frac{X_{*c}}{N}, \quad X_{*c} = \sum_w X_{wc}. \quad (57.14)$$

定义 57.3 (Pointwise Mutual Information). 当 $\hat{p}(w, c) > 0$ 时,

$$\text{PMI}(w, c) = \log \frac{\hat{p}(w, c)}{\hat{p}(w)\hat{p}(c)}. \quad (57.15)$$

解释：

- $\text{PMI} > 0$: 共现次数高于独立假设下的期望；
- $\text{PMI} = 0$: 与独立模型一致；
- $\text{PMI} < 0$: 共现次数低于独立模型期望。

[SLP] 采用 $\log_2$ ；本文默认自然对数。二者只差常数因子。

定义 57.4 (Positive PMI).

$$\text{PPMI}(w, c) = \max \{\text{PMI}(w, c), 0\}. \quad (57.16)$$

若 $X_{wc} = 0$, 则原始 PMI 为 $-\infty$ 。PPMI 通常将该位置设为零, 而不是显式存储 $-\infty$ 。

57.7.2 PMI 的低频偏置

若一个极低频 pair 只出现一次, 但其边缘概率也极小, 则 $\frac{p(w, c)}{p(w)p(c)}$ 可能很大。

因此 PMI 容易夸大偶然的 rare co-occurrence。

常见修正包括：



1. 对 count 加小常数;
2. 对 context distribution 使用 $p_\alpha(c) = \frac{X_{*c}^\alpha}{\sum_{c'} X_{*c'}^\alpha}$, $0 < \alpha < 1$;
3. 设最小频数阈值;
4. 对 PPMI matrix 做低秩分解。

易错点、反例与失败模式

PMI 衡量的是统计关联相对独立基线的强度, 不是:

- 条件概率 $p(w | c)$;
- 余弦相似度;
- 因果效应;
- 逻辑关系成立概率。

57.8 Word2vec 的两个模型

Word2vec 通常指两种浅层预测模型:

1. Skip-gram: 中心词预测上下文;
2. CBOW: 上下文预测中心词。

两者均学习两套参数:

$$\mathbf{E}_{\text{in}} \in \mathbb{R}^{V \times d}, \quad \mathbf{E}_{\text{out}} \in \mathbb{R}^{V \times d}. \quad (57.17)$$

对词 w : $\mathbf{v}_w = \mathbf{E}_{\text{in}}[w, :]^\top$, $\mathbf{u}_w = \mathbf{E}_{\text{out}}[w, :]^\top$ 。

其中:

- $\mathbf{v}_w$ 是 input/target embedding;
- $\mathbf{u}_w$ 是 output/context embedding。

训练后可: $\mathbf{z}_w = \mathbf{v}_w$, $\mathbf{z}_w = \mathbf{u}_w$, $\mathbf{z}_w = \mathbf{v}_w + \mathbf{u}_w$ 。

这三种导出规则不是数学上完全等价的, 必须在实验协议中说明。

57.9 Skip-Gram Full Softmax

57.9.1 训练样本构造

给定 token sequence $w_1, \dots, w_T$ 和窗口半径 m 。

对中心位置 t , 构造正 pair:

$$\mathcal{P}_t = \{(w_t, w_{t+j}) : -m \leq j \leq m, j \neq 0\}. \quad (57.18)$$



57.9.2 条件分布

中心词 w 预测 context c :

$$p_{\theta}(c | w) = \frac{\exp(\mathbf{u}_c^{\top} \mathbf{v}_w)}{\sum_{a \in \mathcal{V}} \exp(\mathbf{u}_a^{\top} \mathbf{v}_w)}. \quad (57.19)$$

整个语料的负 log-likelihood:

$$\mathcal{L}_{\text{SG}} = - \sum_{t=1}^T \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \log p_{\theta}(w_{t+j} | w_t). \quad (57.20)$$

57.9.3 单个 Pair 的梯度

对正样本 (w, o) , 定义 $s_a = \mathbf{u}_a^{\top} \mathbf{v}_w$, $p_a = \frac{e^{s_a}}{\sum_b e^{s_b}}$ 。

损失: $\ell = -\log p_o$ 。

softmax-cross-entropy 对 logit 的梯度:

$$\frac{\partial \ell}{\partial s_a} = p_a - \mathbf{1}\{a = o\}. \quad (57.21)$$

因此:

$$\nabla_{\mathbf{u}_a} \ell = (p_a - \mathbf{1}\{a = o\}) \mathbf{v}_w. \quad (57.22)$$

中心词 embedding 梯度:

$$\nabla_{\mathbf{v}_w} \ell = \sum_{a \in \mathcal{V}} (p_a - \mathbf{1}\{a = o\}) \mathbf{u}_a. \quad (57.23)$$

完整 softmax 每个 pair 需要遍历词表:

$$T_{\text{full softmax}} = O(Vd). \quad (57.24)$$

当 V 很大时成本过高。

57.10 Skip-Gram with Negative Sampling

57.10.1 Noise Distribution

对每个正 pair (w, c^+) , 采样 k 个 negative contexts: $c_1^-, \dots, c_k^- \stackrel{\text{i.i.d.}}{\sim} P_n$ 。

常见 noise distribution:

$$P_n(c) = \frac{C(c)^{\alpha}}{\sum_{a \in \mathcal{V}} C(a)^{\alpha}}, \quad \alpha \approx \frac{3}{4}. \quad (57.25)$$

$\alpha < 1$ 会相对提高低频词的采样概率, 但不会变成均匀分布。

57.10.2 Binary Classification Objective

定义 $\sigma(s) = \frac{1}{1+e^{-s}}$ 。

正 pair 被判为真实邻居的概率: $P(+ | w, c) = \sigma(\mathbf{u}_c^{\top} \mathbf{v}_w)$ 。

负 pair 被判为噪声的概率: $P(- | w, c) = \sigma(-\mathbf{u}_c^{\top} \mathbf{v}_w)$ 。



单个正 pair 加 k 个负样本的损失:

$$\ell_{\text{SGNS}} = -\log \sigma(\mathbf{u}_{c^+}^\top \mathbf{v}_w) - \sum_{i=1}^k \log \sigma(-\mathbf{u}_{c_i^-}^\top \mathbf{v}_w). \quad (57.26)$$

57.10.3 完整梯度

记 $s^+ = \mathbf{u}_{c^+}^\top \mathbf{v}_w$, $s_i^- = \mathbf{u}_{c_i^-}^\top \mathbf{v}_w$ 。

利用 $\frac{d}{ds}[-\log \sigma(s)] = \sigma(s) - 1$, $\frac{d}{ds}[-\log \sigma(-s)] = \sigma(s)$, 得到:

$$\nabla_{\mathbf{v}_w} \ell_{\text{SGNS}} = (\sigma(s^+) - 1) \mathbf{u}_{c^+} + \sum_{i=1}^k \sigma(s_i^-) \mathbf{u}_{c_i^-}. \quad (57.27)$$

正 context 梯度:

$$\nabla_{\mathbf{u}_{c^+}} \ell_{\text{SGNS}} = (\sigma(s^+) - 1) \mathbf{v}_w. \quad (57.28)$$

第 i 个 negative context 梯度:

$$\nabla_{\mathbf{u}_{c_i^-}} \ell_{\text{SGNS}} = \sigma(s_i^-) \mathbf{v}_w. \quad (57.29)$$

若同一 negative word 被重复采样, 对应梯度应累加。

57.10.4 梯度方向解释

对于正 pair: $\sigma(s^+) - 1 < 0$, 梯度下降使 $\mathbf{u}_{c^+}^\top \mathbf{v}_w$ 增大。

对于负 pair: $\sigma(s_i^-) > 0$, 梯度下降使 $\mathbf{u}_{c_i^-}^\top \mathbf{v}_w$ 减小。

每个 pair 的时间复杂度:

$$O((k+1)d), \quad (57.30)$$

参数空间:

$$O(2Vd). \quad (57.31)$$

易错点、反例与失败模式

Negative sampling 不是完整词表 softmax 的精确最大似然。

SGNS 优化的是: 真实共现 pair vs. noise pair 的二分类目标。

因此不能把式 (57.26) 直接称为 $-\log p(c | w)$ 的无偏估计, 除非另行证明特定估计关系。

57.11 CBOW

以下公式是根据附件中 CBOW/Skip-gram 的预测方向所作的数学化补充。

设中心位置 t 的 context multiset 为 $\mathcal{C}_t = \{w_{t-m}, \dots, w_{t-1}, w_{t+1}, \dots, w_{t+m}\}$ 。

有效 context 数为 M_t 。

平均 context representation:

$$\mathbf{h}_t = \frac{1}{M_t} \sum_{c \in \mathcal{C}_t} \mathbf{v}_c. \quad (57.32)$$



CBOW full-softmax:

$$p(w_t = a | \mathcal{C}_t) = \frac{\exp(\mathbf{u}_a^\top \mathbf{h}_t)}{\sum_{b \in \mathcal{V}} \exp(\mathbf{u}_b^\top \mathbf{h}_t)}. \quad (57.33)$$

损失:

$$\ell_{\text{CBOW}} = -\log p(w_t | \mathcal{C}_t). \quad (57.34)$$

若 $p_a = p(a | \mathcal{C}_t)$, 则:

$$\nabla_{\mathbf{u}_a} \ell_{\text{CBOW}} = (p_a - \mathbf{1}\{a = w_t\}) \mathbf{h}_t. \quad (57.35)$$

$$\nabla_{\mathbf{h}_t} \ell_{\text{CBOW}} = \sum_{a \in \mathcal{V}} (p_a - \mathbf{1}\{a = w_t\}) \mathbf{u}_a. \quad (57.36)$$

每个 context input embedding 的梯度为

$$\nabla_{\mathbf{v}_c} \ell_{\text{CBOW}} = \frac{1}{M_t} \nabla_{\mathbf{h}_t} \ell_{\text{CBOW}}. \quad (57.37)$$

CBOW negative-sampling 目标可写为:

$$-\log \sigma(\mathbf{u}_{w_t}^\top \mathbf{h}_t) - \sum_{i=1}^k \log \sigma(-\mathbf{u}_{n_i}^\top \mathbf{h}_t). \quad (57.38)$$

57.11.1 CBOW 与 Skip-Gram

表 57.1: CBOW 与 Skip-gram

比较项	CBOW	Skip-gram
预测方向	context $\rightarrow$ center	center $\rightarrow$ context
输入表示	多个 context embedding 的和或平均	单个 center embedding
每个位置的正目标数	通常一个 center word	窗口内多个 context words
训练成本	通常较低	pair 数更多
低频词	context 平均可能稀释低频词信号	每个 pair 单独训练, 往往更重视稀有 pair
共同局限	均为 static embedding; 同一个 word type 在所有语境中只有固定向量; 局部窗口本身不等于完整语义。	

57.12 SGNS 与 Shifted PMI

命题 57.5 (SGNS 最优内积的 shifted-PMI 形式). 设:

- X_{wc} 为 pair (w, c) 的正样本次数;
- $X_{w*} = \sum_c X_{wc}$;
- 每个正样本产生 k 个负样本;
- negative context 来自 $P_n(c)$ 。



把 $x_{wc} = \mathbf{u}_c^\top \mathbf{v}_w$ 视为可独立优化的标量，则其期望目标为

$$J_{wc}(x) = X_{wc} \log \sigma(x) + k X_{w*} P_n(c) \log \sigma(-x). \quad (57.39)$$

其驻点满足

$$x_{wc}^* = \log \frac{X_{wc}}{k X_{w*} P_n(c)}. \quad (57.40)$$

若 $P_n(c) = \frac{X_{*c}}{N}$ ，则

$$x_{wc}^* = \text{PMI}(w, c) - \log k. \quad (57.41)$$

证明. 对式 (57.39) 求导:

$$J'_{wc}(x) = X_{wc} \sigma(-x) - k X_{w*} P_n(c) \sigma(x). \quad (57.42)$$

令其为零: $X_{wc} \sigma(-x) = k X_{w*} P_n(c) \sigma(x)$ 。

利用 $\frac{\sigma(-x)}{\sigma(x)} = e^{-x}$ ，可得 $X_{wc} e^{-x} = k X_{w*} P_n(c)$ ，从而 $x = \log \frac{X_{wc}}{k X_{w*} P_n(c)}$ 。

若 $P_n(c) = X_{*c}/N$ ，则

$$x = \log \frac{X_{wc} N}{X_{w*} X_{*c}} - \log k \quad (57.43)$$

$$= \log \frac{p(w, c)}{p(w)p(c)} - \log k \quad (57.44)$$

$$= \text{PMI}(w, c) - \log k. \quad (57.45)$$

□

说明 57.6. 真实 SGNS 使用低维向量: $x_{wc} = \mathbf{u}_c^\top \mathbf{v}_w$, $d \ll V$ 。

不同 pair 的 x_{wc} 不能独立设置，因此训练相当于对 shifted-PMI structure 做受限低秩逼近。

若使用 $P_n(c) \propto X_{*c}^{3/4}$ ，则式 (57.41) 不再是原始 PMI 的精确形式，而是 noise-distribution-corrected association。

57.13 GloVe

57.13.1 数据与参数

设 $X_{ij} > 0$ 为词 i 与 context j 的全语料共现次数。


每个词学习: $\mathbf{w}_i, \tilde{\mathbf{w}}_i \in \mathbb{R}^d$, $b_i, \tilde{b}_i \in \mathbb{R}$ 。

GloVe 的加权回归目标:

$$J_{\text{GloVe}} = \sum_{\substack{i,j \\ X_{ij} > 0}} f(X_{ij}) \left(\mathbf{w}_i^\top \tilde{\mathbf{w}}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2. \quad (57.46)$$

常用 weighting function:

$$f(x) = \begin{cases} \left(\frac{x}{x_{\max}} \right)^\alpha, & 0 < x < x_{\max}, \\ 1, & x \geq x_{\max}. \end{cases} \quad (57.47)$$



57.13.2 为什么需要 Weighting Function

若不加权：

- 极大量 rare co-occurrences 可能由偶然噪声产生；
- 高频 pair 又可能因平方误差占据绝对主导。

式 (57.47) 同时做到：

- 对小 X_{ij} 降权；
- 对大 X_{ij} 截断权重，防止无界增长。

57.13.3 梯度

定义 residual：

$$r_{ij} = \mathbf{w}_i^\top \tilde{\mathbf{w}}_j + b_i + \tilde{b}_j - \log X_{ij}. \quad (57.48)$$

单个非零 pair 的损失： $\ell_{ij} = f(X_{ij})r_{ij}^2$ 。

梯度：

$$\nabla_{\mathbf{w}_i} \ell_{ij} = 2f(X_{ij})r_{ij}\tilde{\mathbf{w}}_j, \quad (57.49)$$

$$\nabla_{\tilde{\mathbf{w}}_j} \ell_{ij} = 2f(X_{ij})r_{ij}\mathbf{w}_i, \quad (57.50)$$

$$\frac{\partial \ell_{ij}}{\partial b_i} = 2f(X_{ij})r_{ij}, \quad (57.51)$$

$$\frac{\partial \ell_{ij}}{\partial \tilde{b}_j} = 2f(X_{ij})r_{ij}. \quad (57.52)$$

若共现矩阵非零元素数为 $\text{nnz}(\mathbf{X})$ ，一轮稀疏遍历成本为

$$O(\text{nnz}(\mathbf{X})d). \quad (57.53)$$

参数空间：

$$O(2Vd + 2V). \quad (57.54)$$

易错点、反例与失败模式

式 (57.46) 只对 $X_{ij} > 0$ 的 pair 求和。

若直接计算 $\log 0$ ，目标未定义。

此外，GloVe 是加权 least-squares regression，不是 Skip-gram 的 binary negative-sampling objective。

57.13.4 GloVe 与 SGNS

表 57.2: GloVe 与 SGNS

比较项	GloVe	SGNS
Data signal	全语料共现矩阵 X_{ij}	滑动窗口产生的正 pair 与 noise pair
Objective	加权 log-count regression	logistic binary classification

比较项	GloVe	SGNS
Inductive bias	全局共现比例可由低维内积近似	邻近词内积应高于随机噪声词
计算方式	先统计共现，再优化非零 pair	可在线扫描语料并采样 negatives
共同性质	均学习 static dense embedding; 通常均有 target/context 两套向量; 低维表示本身非唯一。	

57.14 Embedding 的非唯一性

若目标只依赖内积 $\mathbf{u}_c^\top \mathbf{v}_w$, 对任意正交矩阵 $\mathbf{R}^\top \mathbf{R} = \mathbf{I}$, 令 $\mathbf{v}'_w = \mathbf{R} \mathbf{v}_w$, $\mathbf{u}'_c = \mathbf{R} \mathbf{u}_c$, 则 $\mathbf{u}'_c{}^\top \mathbf{v}'_w = \mathbf{u}_c^\top \mathbf{v}_w$ 。

所以 embedding coordinate 本身通常无唯一语义; 真正可核查的是:

- 内积;
- 距离;
- 邻域;
- 下游任务性能。

57.15 Node2Vec

57.15.1 资料边界

[NLP-Train] 明确给出的主线是:

构造节点环境 $\rightarrow$ 把随机游走节点序列当作“句子” $\rightarrow$ 使用 Skip-gram 学习 node embedding.

以下 p, q 二阶随机游走公式是根据该结论所作的标准数学化补充。

57.15.2 图与随机游走

设加权图: $G = (\mathcal{V}_G, \mathcal{E}_G)$, $a_{vx} > 0$ 为边 (v, x) 的权重。

随机游走当前位于 v , 上一步节点为 t 。下一个节点 $x \in \mathcal{N}(v)$ 的未归一化权重:

$$\pi_{vx} = \alpha_{pq}(t, x) a_{vx}, \quad (57.55)$$


其中

$$\alpha_{pq}(t, x) = \begin{cases} \frac{1}{p}, & d_G(t, x) = 0, \\ 1, & d_G(t, x) = 1, \\ \frac{1}{q}, & d_G(t, x) = 2. \end{cases} \quad (57.56)$$

转移概率:

$$P(v_{r+1} = x \mid v_r = v, v_{r-1} = t) = \frac{\alpha_{pq}(t, x) a_{vx}}{\sum_{z \in \mathcal{N}(v)} \alpha_{pq}(t, z) a_{vz}}. \quad (57.57)$$

参数解释:



- p 是 return parameter; p 小时立即返回 t 的概率增大;
- $q > 1$ 抑制距离为 2 的外向节点, 更偏 local/BFS;
- $q < 1$ 提高外向探索, 更偏 DFS。

57.15.3 Skip-Gram Objective

对随机游走序列 $(v_1, \dots, v_L)$, 使用窗口半径 m 产生 node-context pairs。

full-softmax:

$$p(u | v) = \frac{\exp(\mathbf{u}_u^\top \mathbf{v}_v)}{\sum_{z \in \mathcal{V}_G} \exp(\mathbf{u}_z^\top \mathbf{v}_v)}. \quad (57.58)$$

目标:

$$\min - \sum_{v \in \mathcal{V}_G} \sum_{u \in \mathcal{C}(v)} \log p(u | v). \quad (57.59)$$

实际可使用 SGNS 将每个 pair 成本从 $O(|\mathcal{V}_G|d)$ 降为 $O(kd)$ 。

57.15.4 复杂度

若:

- 每个节点生成 r 条随机游走;
- 每条长度为 L ;
- context 半径为 m ;
- 每个正 pair 有 k 个 negatives;

正 pair 数量量级为 $O(|\mathcal{V}_G|rLm)$ 。

SGNS 训练成本:

$$O(|\mathcal{V}_G|rLmkd). \quad (57.60)$$

node embedding 参数空间: $O(2|\mathcal{V}_G|d)$ 。

57.15.5 Inductive Bias 与失败模式

Node2Vec 假设: 在特定随机游走机制下具有相似上下文的节点应具有相似表示。

失败模式:

1. 随机游走频率偏向高 degree 节点;
2. 图中的邻近不一定等于任务语义相似;
3. 不同 p, q 会改变 homophily 与 structural-role 偏好;
4. 新增节点通常需重新生成上下文或采用额外 inductive mechanism;
5. embedding 相似不能自动满足图上的全局逻辑约束。



易错点、反例与失败模式

Node2Vec 不是 Transformer，也不是 message-passing GNN。

其主要训练样本来自：random walk co-occurrence，而不是节点特征间的逐层邻居聚合。

57.16 TransE**57.16.1 问题设定**

知识图谱： $\mathcal{G} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}$ 。

一个 fact triple: (h, r, t) , 其中：

- $h \in \mathcal{E}$: head entity;
- $r \in \mathcal{R}$: relation;
- $t \in \mathcal{E}$: tail entity。

参数: $\mathbf{e}_h, \mathbf{e}_t, \mathbf{r} \in \mathbb{R}^d$ 。

TransE 的 translation inductive bias:

$$\boxed{\mathbf{e}_h + \mathbf{r} \approx \mathbf{e}_t.} \quad (57.61)$$

距离 score:

$$\boxed{d_r(h, t) = \|\mathbf{e}_h + \mathbf{r} - \mathbf{e}_t\|_p, \quad p \in \{1, 2\}.} \quad (57.62)$$

57.16.2 Negative Triple Construction

正 triple: $(h, r, t) \in \mathcal{G}$ 。

corrupted triples:

$$\mathcal{N}(h, r, t) = \{(h', r, t) : h' \in \mathcal{E}\} \cup \{(h, r, t') : t' \in \mathcal{E}\}. \quad (57.63)$$

实际应过滤已知真 triple，否则会把真实事实当作 negative。


57.16.3 Margin-Ranking Loss

设 margin $\gamma > 0$ 。

$$\boxed{\mathcal{L}_{\text{TransE}} = \sum_{(h, r, t) \in \mathcal{G}} \sum_{(h', r, t') \in \mathcal{N}_s(h, r, t)} [\gamma + d_r(h, t) - d_r(h', t')]_+,} \quad (57.64)$$

其中 $[a]_+ = \max\{a, 0\}$, $\mathcal{N}_s$ 是 sampled negatives。

满足球面约束 $\|\mathbf{e}_e\|_2 \leq 1$ 是一种常见变体，用于控制表示尺度；若使用该约束，应在答案中明确写出。



57.16.4 复杂度

每个 score 的成本: $O(d)$ 。

若每个正 triple 使用 k 个 negatives:

$$O((k+1)d) \quad (57.65)$$

时间。

参数空间:

$$O((|\mathcal{E}| + |\mathcal{R}|)d). \quad (57.66)$$

57.16.5 失败模式

1. One-to-many。

若 (h, r, t_1) , (h, r, t_2) 都为真, 则模型同时要求 $\mathbf{e}_h + \mathbf{r} \approx \mathbf{e}_{t_1}$, $\mathbf{e}_h + \mathbf{r} \approx \mathbf{e}_{t_2}$, 容易迫使两个 tail 过近。

2. Symmetric relation。

若 (h, r, t) 和 (t, r, h) 均成立, 则 $\mathbf{e}_h + \mathbf{r} \approx \mathbf{e}_t$, $\mathbf{e}_t + \mathbf{r} \approx \mathbf{e}_h$, 从而强迫 $2\mathbf{r} \approx \mathbf{0}$ 。

3. False negative。

被 corruption 产生但尚未收录的真实 triple 可能被错误当作 negative。

4. 开放世界与逻辑约束。

小距离只是模型 score, 不等于严格逻辑证明。

57.17 四类 Embedding 的真题标准答案

答题方法

[25F-D-Q1, 3 分] 建议采用四行三列结构:

方法	Data signal	Objective type	Inductive bias
GloVe	全语料 word-context 共现次数 X_{ij}	加权 log-bilinear least-squares: $w_i^\top \tilde{w}_j + b_i + \tilde{b}_j \approx \log X_{ij}$	全局共现统计和概率比例可由低维内积结构编码
Skip-gram	滑动窗口产生的 center-context pairs	full-softmax 条件似然, 或 SGNS 二分类目标	局部上下文相似的词应具有高内积; distributional hypothesis
Node2Vec	图上的 biased random walks 产生 node-context pairs	对游走序列应用 Skip-gram/SGNS	随机游走邻域相似意味着节点表示相似; p, q 控制局部与外向探索
TransE	知识图谱正三元组和 corrupted negatives	margin-ranking loss 或其他 contrastive score loss	每个 relation 对应 embedding space 中的 translation: $\mathbf{h} + \mathbf{r} \approx \mathbf{t}$

每种方法写清“数据、目标、偏置”即可; 只写“把对象映射为向量”通常不能获得满分。

57.18 表示学习易错点

易错点、反例与失败模式

1. Sparse representation 不等于 one-hot; TF-IDF、PPMI 也是 sparse vector。
2. Dense embedding 的每一维通常没有单独明确语义。
3. Static embedding: 一个 word type 对应一个固定向量; contextual embedding: 同一 token 在不同 context 中向量不同。
4. Cosine similarity 不等于概率。
5. PMI 不等于 mutual information 的期望值; PMI 是单个 pair 的 pointwise quantity。
6. Negative sampling 不等于完整 softmax maximum likelihood。
7. GloVe 是 global count regression; Skip-gram 是 local-window prediction。
8. Word2vec 通常有 input 和 output 两套 embedding。
9. Node2Vec 的“邻居”来自随机游走上下文, 不只是一跳 graph neighbor。
10. TransE 的小 score 不等于事实已经被逻辑证明。
11. Embedding space 非唯一; 不能把某一坐标轴未经验证地解释为固定语义。
12. 语料中存在的社会偏见可能被 embedding 继承和放大。

57.19 快速自测

快速自测

1. Representation learning 的输入、输出和训练信号分别是什么?
2. One-hot 与 distributional vector 的差别是什么?
3. Cosine 为什么比 raw dot product 更少受词频影响?
4. TF、DF、collection frequency 和 IDF 如何区分?
5. PMI 为正、零、负分别表示什么?
6. PPMI 为什么会丢失负关联信息?
7. 写出 Skip-gram full-softmax objective。
8. 写出 SGNS loss 和三类参数梯度。
9. Negative sampling 为什么不是完整 softmax likelihood?
10. CBOW 与 Skip-gram 的预测方向如何相反?
11. 在什么 noise distribution 下, SGNS 最优内积近似 $\text{PMI}(w, c) - \log k$?
12. GloVe 中为何只对 $X_{ij} > 0$ 求和?
13. GloVe 的 weighting function 解决什么问题?

14. Node2Vec 的 p, q 分别控制什么?
15. TransE 的正 triple 与负 triple 分别希望 score 如何变化?
16. 为什么 TransE 难以处理 one-to-many relation?
17. 为什么 cosine 高不能推出因果关系或事实正确?



第五十八章 RNN、LSTM、Encoder-Decoder 与 Attention

58.1 重要性等级与跨方向边界

重要性等级：S

RNN/LSTM 与 Transformer 的比较在 [25S-D-Q5, 3 分]、[25F-D-Q2, 5 分] 和 [26S-B-Q1(e), 2 分] 中构成直接或核心前置。

本章从 NLP 角度重点考查：

- sequence modeling;
- language modeling;
- encoder-decoder;
- teacher forcing;
- attention;
- 长依赖和顺序计算;
- 训练与推理的区别。

通用 backpropagation 已在深度学习方向讲解；本章只补充时间展开、BPTT 和序列模型特有失败模式。

58.2 Simple RNN 的问题设定

在时间步 t : $\mathbf{x}_t \in \mathbb{R}^{d_x}$, $\mathbf{h}_t \in \mathbb{R}^{d_h}$, $\mathbf{z}_t \in \mathbb{R}^{d_y}$ 。

主约定：

$$\mathbf{a}_t = \mathbf{W}_x \mathbf{x}_t + \mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{b}_h, \quad (58.1)$$

$$\mathbf{h}_t = \phi(\mathbf{a}_t), \quad (58.2)$$

$$\mathbf{z}_t = \mathbf{W}_y \mathbf{h}_t + \mathbf{b}_y, \quad (58.3)$$

$$\mathbf{p}_t = \text{softmax}(\mathbf{z}_t). \quad (58.4)$$

维度: $\mathbf{W}_x \in \mathbb{R}^{d_h \times d_x}$, $\mathbf{W}_h \in \mathbb{R}^{d_h \times d_h}$, $\mathbf{W}_y \in \mathbb{R}^{d_y \times d_h}$, $\mathbf{b}_h \in \mathbb{R}^{d_h}$, $\mathbf{b}_y \in \mathbb{R}^{d_y}$ 。

[SLP] 的简写公式省略 bias；本文主约定保留 bias。



58.2.1 参数共享

所有时间步使用相同参数: $\mathbf{W}_x, \mathbf{W}_h, \mathbf{W}_y$ 。

因此 RNN 对任意长度序列使用固定参数量:

$$P_{\text{RNN}} = d_h d_x + d_h^2 + d_y d_h + d_h + d_y. \quad (58.5)$$

58.3 RNN Language Model

词表大小为 V , embedding matrix: $\mathbf{E} \in \mathbb{R}^{V \times d_x}$ 。

输入 token w_t : $\mathbf{x}_t = \mathbf{E}[w_t, :]^\top$ 。

若预测下一个 token: $d_y = V$, 并定义

$$p_\theta(w_{t+1} = v \mid w_{1:t}) = [\mathbf{p}_t]_v. \quad (58.6)$$

序列概率:

$$p_\theta(w_{1:T}) = \prod_{t=0}^{T-1} p_\theta(w_{t+1} \mid w_{1:t}), \quad (58.7)$$

其中 w_0 表示 BOS context。

训练负 log-likelihood:

$$\mathcal{L}_{\text{RNN-LM}} = - \sum_{t=0}^{T-1} \log p_\theta(w_{t+1} \mid w_{1:t}). \quad (58.8)$$

58.3.1 Weight Tying

若 $d_x = d_h = d$, 可令 output projection 与 input embedding 共享:

$$\mathbf{W}_y = \mathbf{E}. \quad (58.9)$$

因为本文 $\mathbf{E} \in \mathbb{R}^{V \times d}$, $\mathbf{E}\mathbf{h}_t \in \mathbb{R}^V$ 。

在列存储约定下, 同一关系会写成 $\mathbf{W}_y = \mathbf{E}^\top$ 。

58.4 Backpropagation Through Time

设每步损失为 ℓ_t , $\mathcal{L} = \sum_{t=1}^T \ell_t$ 。

对 softmax-cross-entropy:

$$\mathbf{g}_t^z := \frac{\partial \mathcal{L}}{\partial \mathbf{z}_t} = \mathbf{p}_t - \mathbf{y}_t. \quad (58.10)$$


定义: $\mathbf{g}_t^h = \frac{\partial \mathcal{L}}{\partial \mathbf{h}_t}$, $\mathbf{g}_t^a = \frac{\partial \mathcal{L}}{\partial \mathbf{a}_t}$ 。

反向递推:

$$\mathbf{g}_t^h = \mathbf{W}_y^\top \mathbf{g}_t^z + \mathbf{W}_h^\top \mathbf{g}_{t+1}^a, \quad (58.11)$$

$$\mathbf{g}_t^a = \mathbf{g}_t^h \odot \phi'(\mathbf{a}_t), \quad (58.12)$$

并令 $\mathbf{g}_{T+1}^a = \mathbf{0}$ 。



参数梯度：

$$\nabla_{\mathbf{W}_y} \mathcal{L} = \sum_{t=1}^T \mathbf{g}_t^z \mathbf{h}_t^\top, \quad (58.13)$$

$$\nabla_{\mathbf{W}_x} \mathcal{L} = \sum_{t=1}^T \mathbf{g}_t^a \mathbf{x}_t^\top, \quad (58.14)$$

$$\nabla_{\mathbf{W}_h} \mathcal{L} = \sum_{t=1}^T \mathbf{g}_t^a \mathbf{h}_{t-1}^\top, \quad (58.15)$$

$$\nabla_{\mathbf{b}_h} \mathcal{L} = \sum_{t=1}^T \mathbf{g}_t^a, \quad (58.16)$$

$$\nabla_{\mathbf{b}_y} \mathcal{L} = \sum_{t=1}^T \mathbf{g}_t^z. \quad (58.17)$$

这就是 backpropagation through time (BPTT) 的核心。

58.5 梯度消失与梯度爆炸

由 $\mathbf{h}_t = \phi(\mathbf{a}_t)$, 定义 $\mathbf{D}_t = \text{Diag}(\phi'(\mathbf{a}_t))$ 。

局部 Jacobian：

$$\frac{\partial \mathbf{h}_t}{\partial \mathbf{h}_{t-1}} = \mathbf{D}_t \mathbf{W}_h. \quad (58.18)$$

长距离 Jacobian：

$$\frac{\partial \mathbf{h}_T}{\partial \mathbf{h}_t} = \prod_{s=t+1}^T \mathbf{D}_s \mathbf{W}_h. \quad (58.19)$$

由次乘性：

$$\left\| \frac{\partial \mathbf{h}_T}{\partial \mathbf{h}_t} \right\|_2 \leq \prod_{s=t+1}^T \|\mathbf{D}_s \mathbf{W}_h\|_2. \quad (58.20)$$

若存在 $\rho < 1$ 使 $\|\mathbf{D}_s \mathbf{W}_h\|_2 \leq \rho$, 则 $\left\| \frac{\partial \mathbf{h}_T}{\partial \mathbf{h}_t} \right\|_2 \leq \rho^{T-t} \rightarrow 0$ 。

这就是梯度消失。

若多个因子范数大于 1, 则乘积可能指数增长, 产生梯度爆炸。

58.5.1 Sigmoid/Tanh 饱和

对 $\tanh(a)$, 有 $\tanh'(a) = 1 - \tanh^2(a)$ 。

当 $|a| \gg 1$, 导数接近零。

因此即使 $\|\mathbf{W}_h\|_2$ 不小, 激活饱和仍会使 $\|\mathbf{D}_t\|$ 很小。

易错点、反例与失败模式

Gradient clipping 主要控制梯度爆炸: $\mathbf{g} \leftarrow \mathbf{g} \min \left\{ 1, \frac{\tau}{\|\mathbf{g}\|} \right\}$ 。
它不能从根本上恢复已经消失的长距离梯度。



58.6 RNN 的三类 NLP 用法

58.6.1 Sequence Labeling

每个位置输出: $p(y_t | x_{1:t}) = \text{softmax}(\mathbf{W}_y \mathbf{h}_t + \mathbf{b}_y)$ 。

若独立取 argmax : $\hat{y}_t = \arg \max_k p(y_t = k | x_{1:t})$ 。

若还需全局标签约束, 可在 RNN/BiLSTM 上加入 CRF, 参见第 五十六 章节。

58.6.2 Sequence Classification

可使用最后隐藏状态: $\mathbf{r} = \mathbf{h}_T$, 或 pooling:

$$\mathbf{r}_{\text{mean}} = \frac{1}{T} \sum_{t=1}^T \mathbf{h}_t. \quad (58.21)$$

分类: $p(y | x_{1:T}) = \text{softmax}(\mathbf{W}_c \mathbf{r} + \mathbf{b}_c)$ 。

只使用 $\mathbf{h}_T$ 时, 序列开头信息可能被压缩或遗忘。

58.6.3 Bidirectional RNN

前向: $\vec{\mathbf{h}}_t = f_{\rightarrow}(\mathbf{x}_t, \vec{\mathbf{h}}_{t-1})$ 。

反向: $\overleftarrow{\mathbf{h}}_t = f_{\leftarrow}(\mathbf{x}_t, \overleftarrow{\mathbf{h}}_{t+1})$ 。

拼接:

$$\mathbf{h}_t = \begin{bmatrix} \vec{\mathbf{h}}_t \\ \overleftarrow{\mathbf{h}}_t \end{bmatrix}. \quad (58.22)$$

若每个方向隐藏维度为 d_h , 拼接后维度为 $2d_h$ 。

易错点、反例与失败模式

Bidirectional RNN 可用于:

- sequence labeling;
- classification;
- encoder。

但不能直接用于严格 causal next-token generation, 因为反向状态使用了未来 token。

58.7 LSTM

58.7.1 状态与维度

输入: $\mathbf{x}_t \in \mathbb{R}^{d_x}$ 。

hidden state: $\mathbf{h}_t \in \mathbb{R}^{d_h}$ 。

cell state: $\mathbf{c}_t \in \mathbb{R}^{d_h}$ 。



标准无 peephole LSTM:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \mathbf{x}_t + \mathbf{U}_f \mathbf{h}_{t-1} + \mathbf{b}_f), \quad (58.23)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \mathbf{x}_t + \mathbf{U}_i \mathbf{h}_{t-1} + \mathbf{b}_i), \quad (58.24)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c \mathbf{x}_t + \mathbf{U}_c \mathbf{h}_{t-1} + \mathbf{b}_c), \quad (58.25)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t, \quad (58.26)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \mathbf{x}_t + \mathbf{U}_o \mathbf{h}_{t-1} + \mathbf{b}_o), \quad (58.27)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t). \quad (58.28)$$

所有 gate 均属于 $\mathbb{R}^{d_h}$ 。

58.7.2 参数量

四组 input matrices: $4d_h d_x$ 。

四组 recurrent matrices: $4d_h^2$ 。

四组 biases: $4d_h$ 。

因此:

$$P_{\text{LSTM}} = 4(d_h d_x + d_h^2 + d_h). \quad (58.29)$$

不包括 output head。

58.7.3 为何缓解梯度消失

cell update 是加法: $\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$ 。

沿显式 cell-state 直通支路, 局部 Jacobian 为

$$\left. \frac{\partial \mathbf{c}_t}{\partial \mathbf{c}_{t-1}} \right|_{\text{direct}} = \text{Diag}(\mathbf{f}_t). \quad (58.30)$$

因此长距离直通项含 $\prod_{s=t+1}^T \text{Diag}(\mathbf{f}_s)$ 。

若相关维度上 $f_{s,j} \approx 1$, 则梯度可较少衰减。

说明 58.1. 式 (58.30) 只是显式 cell-state 支路。

完整 Jacobian 还包括: $\mathbf{c}_{t-1} \rightarrow \mathbf{h}_{t-1} \rightarrow \mathbf{f}_t, \mathbf{i}_t, \tilde{\mathbf{c}}_t, \mathbf{o}_t$ 的间接项。

因此不能把 $\partial \mathbf{c}_t / \partial \mathbf{c}_{t-1} = \text{Diag}(\mathbf{f}_t)$ 无条件写成完整等式。

58.7.4 门的作用

- forget gate: 决定旧 cell information 保留多少;
- input gate: 决定候选信息写入多少;
- output gate: 决定 cell state 中多少信息暴露给当前 hidden state。



易错点、反例与失败模式

LSTM 是“缓解”而非“消除”长依赖问题。

若连续多个 $f_t \ll 1$, cell-state 梯度仍会快速衰减；若 sequence 极长，计算仍严格顺序化。

58.8 Encoder-Decoder

58.8.1 条件序列模型

source: $\mathbf{x} = (x_1, \dots, x_S)$ 。

target: $\mathbf{y} = (y_1, \dots, y_T)$ 。

条件分解:

$$p_{\theta}(\mathbf{y} | \mathbf{x}) = \prod_{t=1}^T p_{\theta}(y_t | y_{<t}, \mathbf{x}). \quad (58.31)$$

基本 RNN encoder: $\mathbf{h}_s^e = f_e(\mathbf{x}_s, \mathbf{h}_{s-1}^e)$ 。

固定 context:

$$\mathbf{c} = \mathbf{h}_S^e. \quad (58.32)$$

decoder:

$$\mathbf{h}_t^d = f_d(\mathbf{E}_y[y_{t-1}], \mathbf{h}_{t-1}^d, \mathbf{c}). \quad (58.33)$$

输出: $p(y_t | y_{<t}, \mathbf{x}) = \text{softmax}(\mathbf{W}_o \mathbf{h}_t^d + \mathbf{b}_o)$ 。

58.8.2 训练目标

$$\mathcal{L}_{\text{seq2seq}} = - \sum_{t=1}^T \log p_{\theta}(y_t^* | y_{<t}^*, \mathbf{x}). \quad (58.34)$$

58.9 Teacher Forcing 与 Exposure Bias

训练时: decoder input at $t = y_{t-1}^*$ 。

推理时: decoder input at $t = \hat{y}_{t-1}$ 。

这称为 teacher forcing。

优点:

- 训练目标条件清晰;
- 避免训练早期错误连续累积;
- 梯度不需穿过离散 sampling;
- Transformer decoder 的所有目标位置可并行计算。

缺点是 training-inference mismatch。



若推理时某一步出错: $\hat{y}_t \neq y_t^*$, 后续模型进入训练中很少见到的 history: $(\hat{y}_1, \dots, \hat{y}_t)$, 错误可能继续累积。

这称为 exposure bias。

易错点、反例与失败模式

Teacher forcing 不等于:

- 把模型输出作为下一步输入;
- beam search;
- masked language modeling;
- 强化学习。

它特指训练时使用 gold previous token。

58.10 RNN Encoder-Decoder Attention

固定 context $\mathbf{c} = \mathbf{h}_s^e$ 要求一个向量压缩全部 source 信息, 形成 bottleneck。

Attention 使每个 target step t 访问所有 encoder states: $\mathbf{h}_1^e, \dots, \mathbf{h}_S^e$ 。

58.10.1 Score

dot-product score:

$$e_{ts} = \mathbf{h}_{t-1}^d \top \mathbf{h}_s^e. \quad (58.35)$$

要求: $\dim(\mathbf{h}_{t-1}^d) = \dim(\mathbf{h}_s^e)$ 。

bilinear score:

$$e_{ts} = \mathbf{h}_{t-1}^d \top \mathbf{W}_a \mathbf{h}_s^e. \quad (58.36)$$

允许 encoder 与 decoder 维度不同。

58.10.2 Attention Distribution

$$\alpha_{ts} = \frac{\exp(e_{ts})}{\sum_{j=1}^S \exp(e_{tj})}. \quad (58.37)$$

对每个固定 t : $\alpha_{ts} \geq 0$, $\sum_{s=1}^S \alpha_{ts} = 1$ 。

58.10.3 Dynamic Context

$$\mathbf{c}_t = \sum_{s=1}^S \alpha_{ts} \mathbf{h}_s^e. \quad (58.38)$$

decoder update:

$$\mathbf{h}_t^d = f_d(\mathbf{E}_y[y_{t-1}], \mathbf{h}_{t-1}^d, \mathbf{c}_t). \quad (58.39)$$



输出可使用：

$$p(y_t | \cdot) = \text{softmax} \left(\mathbf{W}_o \begin{bmatrix} \mathbf{h}_t^d \\ \mathbf{c}_t \end{bmatrix} + \mathbf{b}_o \right). \quad (58.40)$$

58.10.4 复杂度

每个 target step 与 S 个 source states 比较。

若 source 和 target hidden 维度均为 d ：

$$O(TSd) \quad (58.41)$$

时间，attention matrix 需 $O(TS)$ 空间。

易错点、反例与失败模式

Attention weight 可用于诊断，但不应无条件解释为因果贡献或忠实解释。

一个 token 的预测可能还通过：

- residual state;
- nonlinear transformation;
- 其他层;
- value representation

受到影响。

58.11 RNN/LSTM 复杂度

Simple RNN 单步：

$$O(d_h d_x + d_h^2 + d_y d_h). \quad (58.42)$$

长度 T ：

$$O[T(d_h d_x + d_h^2 + d_y d_h)]. \quad (58.43)$$

LSTM recurrent core 约为 simple RNN 的四倍：

$$O[4T(d_h d_x + d_h^2)]. \quad (58.44)$$

训练 BPTT 需保存中间状态： $O(Td_h)$ activation memory。

最关键的计算结构是： $\mathbf{h}_t$ 必须等待 $\mathbf{h}_{t-1}$ 。

因此序列方向上的 critical path 长度为 $O(T)$ 。



58.12 RNN/LSTM 答题方法

答题方法


看到“比较 RNN 与 LSTM”时：

1. 写 simple RNN: $h_t = \phi(W_x x_t + W_h h_{t-1} + b)$;
2. 写长距离 Jacobian: $\frac{\partial h_T}{\partial h_t} = \prod_{s=t+1}^T D_s W_h$;
3. 说明 repeated multiplication 导致 vanishing/exploding;
4. 写 LSTM 四组公式: $f_t, i_t, \tilde{c}_t, c_t, o_t, h_t$;
5. 指出 LSTM 的 cell state 是 additive update;
6. 说明 forget gate 近 1 时提供更稳定的梯度支路;
7. 明确: LSTM 仍然顺序计算, 且不保证无限长依赖。

58.13 快速自测

快速自测

1. 写出 simple RNN 的输入、hidden、output 维度。
2. 为什么 RNN 参数量不随序列长度增加?
3. RNN language model 在时间 t 预测哪个 token?
4. Weight tying 在行 embedding 约定下如何写?
5. BPTT 中 g_t^h 为什么包含来自 $t+1$ 的项?
6. 梯度消失的 Jacobian 连乘形式是什么?
7. Gradient clipping 能否解决 vanishing gradient?
8. Bidirectional RNN 为什么不适用于严格 causal generation?
9. 写出 LSTM 的四个 gate/candidate 公式。
10. LSTM recurrent core 参数量为何有系数 4?
11. LSTM 通过哪条支路缓解梯度消失?
12. Teacher forcing 的训练输入和推理输入分别是什么?
13. Exposure bias 从何而来?
14. Encoder 最后状态为何形成 bottleneck?
15. RNN attention 的 score、softmax 和 context 分别是什么?
16. RNN attention 的时间复杂度为何是 $O(TSd)$?



第五十九章 Transformer 的完整计算流程与 RNN 对比

59.1 重要性等级与真题定位

重要性等级：S

Transformer 是 NLP 方向最重要的模型之一。

相关真题包括：

- [25S-D-Q5, 3 分]：Transformer 相比 recurrent model 的优势；
- [25F-B-Q1(b), 3 分]：scaled dot-product self-attention、 Q, K, V 和位置编码；
- [25F-D-Q2, 5 分]：LSTM 与 Transformer 的 scaling behavior 和架构偏置；
- [26S-B-Q1(d), 2 分]： $1/\sqrt{d_k}$ 的作用；
- [26S-B-Q1(e), 2 分]：RNN 与 Transformer 的计算结构；
- [26S-D-Q3, 7 分]：长序列 attention pattern、复杂度和长程可表达性。

必须能够：

1. 写出全部张量维度；
2. 推导 scaling factor；
3. 区分 self-attention、cross-attention 和 causal attention；
4. 写出 multi-head、residual、LayerNorm、FFN；
5. 分析 $O(L^2)$ 来源；
6. 说明训练并行与自回归推理串行的区别。

59.2 输入与主维度约定

序列长度： L 。

model dimension： d 。

token embedding： $\mathbf{x}_i \in \mathbb{R}^d$ 。



按行堆叠:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_L^\top \end{bmatrix} \in \mathbb{R}^{L \times d}. \quad (59.1)$$

对单个 head: $d_k = \text{query/key dimension}$, $d_v = \text{value dimension}$ 。

参数:

$$\mathbf{W}_Q \in \mathbb{R}^{d \times d_k}, \quad \mathbf{W}_K \in \mathbb{R}^{d \times d_k}, \quad \mathbf{W}_V \in \mathbb{R}^{d \times d_v}. \quad (59.2)$$

59.3 Scaled Dot-Product Attention

59.3.1 Q、K、V

$$\mathbf{Q} = \mathbf{XW}_Q \in \mathbb{R}^{L \times d_k}, \quad (59.3)$$

$$\mathbf{K} = \mathbf{XW}_K \in \mathbb{R}^{L \times d_k}, \quad (59.4)$$

$$\mathbf{V} = \mathbf{XW}_V \in \mathbb{R}^{L \times d_v}. \quad (59.5)$$

第 i 行: $\mathbf{q}_i^\top$, $\mathbf{k}_i^\top$, $\mathbf{v}_i^\top$ 。

未归一化 score:

$$S_{ij} = \frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d_k}}. \quad (59.6)$$

加入 mask $\mathbf{M}$:

$$\tilde{\mathbf{S}} = \frac{\mathbf{QK}^\top}{\sqrt{d_k}} + \mathbf{M} \in \mathbb{R}^{L \times L}. \quad (59.7)$$

对每一行做 softmax:

$$\mathbf{A} = \text{softmax}_{\text{row}}(\tilde{\mathbf{S}}) \in \mathbb{R}^{L \times L}. \quad (59.8)$$

输出:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \mathbf{AV} = \text{softmax}_{\text{row}}\left(\frac{\mathbf{QK}^\top}{\sqrt{d_k}} + \mathbf{M}\right) \mathbf{V}. \quad (59.9)$$

维度核对: $(L \times d_k)(d_k \times L) = L \times L$, $(L \times L)(L \times d_v) = L \times d_v$ 。

59.4 为什么除以 $\sqrt{d_k}$

假设: q_ℓ, k_ℓ 相互独立, $\mathbb{E}[q_\ell] = \mathbb{E}[k_\ell] = 0$, $\text{Var}(q_\ell) = \text{Var}(k_\ell) = 1$ 。

则: $\mathbf{q}^\top \mathbf{k} = \sum_{\ell=1}^{d_k} q_\ell k_\ell$ 。

因为 $\mathbb{E}[q_\ell k_\ell] = 0$, 且 $\text{Var}(q_\ell k_\ell) = 1$, 所以:

$$\text{Var}(\mathbf{q}^\top \mathbf{k}) = d_k. \quad (59.10)$$

因此未经缩放的 score 典型量级为 $O(\sqrt{d_k})$ 。

缩放后:

$$\text{Var}\left(\frac{\mathbf{q}^\top \mathbf{k}}{\sqrt{d_k}}\right) = 1. \quad (59.11)$$



59.4.1 Softmax 饱和

设 $\mathbf{a} = \text{softmax}(\mathbf{s})$ 。

其 Jacobian:

$$\frac{\partial \mathbf{a}}{\partial \mathbf{s}} = \text{Diag}(\mathbf{a}) - \mathbf{a}\mathbf{a}^\top. \quad (59.12)$$

若 logits 幅度很大, softmax 接近 one-hot: $a_j \approx 1, \quad a_i \approx 0 \quad (i \neq j)$ 。

此时 Jacobian 多数元素接近零, 训练梯度变小。

答题方法

[26S-B-Q1(d), 2 分] 满分结构:

1. 假设 q_ℓ, k_ℓ 独立、零均值、单位方差;
2. 推出 $\text{Var}(q^\top k) = d_k$;
3. 除以 $\sqrt{d_k}$ 后方差为 1;
4. 不缩放时 logits 随 d_k 增大;
5. softmax 饱和, 输出近 one-hot;
6. 由 $J_{\text{softmax}} = \text{Diag}(\mathbf{a}) - \mathbf{a}\mathbf{a}^\top$ 说明梯度变小。

59.5 Mask

59.5.1 Causal Mask

decoder-only causal attention:

$$M_{ij} = \begin{cases} 0, & j \leq i, \\ -\infty, & j > i. \end{cases} \quad (59.13)$$

因此: $A_{ij} = 0 \quad (j > i)$ 。

位置 i 只能看见: $1, \dots, i$ 。

59.5.2 Padding Mask

若位置 j 是 padding: $M_{ij}^{\text{pad}} = -\infty$ 。

若同时使用 causal 和 padding mask, 应组合为: $\mathbf{M} = \mathbf{M}^{\text{causal}} + \mathbf{M}^{\text{pad}}$ 。

易错点、反例与失败模式

Mask 应加在 softmax 之前的 logits 上。

若 softmax 后才把权重置零, 剩余元素之和不再为 1, 除非再次归一化。

59.6 Self-Attention、Cross-Attention 与 Causal Attention

59.6.1 Self-Attention

Q, K, V 均来自同一序列表示 X 。

59.6.2 Cross-Attention

decoder state: $Y \in \mathbb{R}^{T \times d}$ 。

encoder output: $H \in \mathbb{R}^{S \times d}$ 。

$$Q = YW_Q \in \mathbb{R}^{T \times d_k}, \quad (59.14)$$

$$K = HW_K \in \mathbb{R}^{S \times d_k}, \quad (59.15)$$

$$V = HW_V \in \mathbb{R}^{S \times d_v}. \quad (59.16)$$

输出:

$$\text{CrossAttn}(Y, H) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \in \mathbb{R}^{T \times d_v}. \quad (59.17)$$

时间主项: $O(TSd)$ 。

59.6.3 Bidirectional 与 Causal

bidirectional encoder self-attention: $M_{ij} = 0$ 对所有非 padding pair, 可读取左右 context。

causal decoder self-attention: $M_{ij} = -\infty$ ($j > i$), 不能读取 future token。

59.7 Multi-Head Attention

设 head 数为 H 。

第 h 个 head:

$$\text{head}_h = \text{Attention}\left(XW_Q^{(h)}, XW_K^{(h)}, XW_V^{(h)}\right) \in \mathbb{R}^{L \times d_v}. \quad (59.18)$$

拼接:

$$C = \text{Concat}(\text{head}_1, \dots, \text{head}_H) \in \mathbb{R}^{L \times Hd_v}. \quad (59.19)$$

输出投影:

$$\boxed{\text{MHA}(X) = CW_O, \quad W_O \in \mathbb{R}^{Hd_v \times d}.} \quad (59.20)$$

常见约定: $d_k = d_v = \frac{d}{H}$ 。

此时: $Hd_v = d$ 。

59.7.1 参数量

若所有 head 的 Q/K/V 合并实现: $W_Q, W_K, W_V \in \mathbb{R}^{d \times d}$, $W_O \in \mathbb{R}^{d \times d}$ 。



忽略 bias:

$$P_{\text{MHA}} = 4d^2. \quad (59.21)$$

易错点、反例与失败模式

Multi-head 不是把同一个 attention matrix 复制 H 次。

每个 head 有不同的: $W_Q^{(h)}, W_K^{(h)}, W_V^{(h)}$, 因而可以学习不同 projection subspaces。

59.8 Positional Encoding

59.8.1 为什么需要位置特征

不含 position feature 的 unmasked self-attention 对 token permutation 是 equivariant。

设 $P \in \mathbb{R}^{L \times L}$ 为 permutation matrix。

对输入 $X' = PX$, 有: $Q' = PQ$, $K' = PK$, $V' = PV$ 。

于是:

$$Q'K'^\top = PQK^\top P^\top. \quad (59.22)$$

row-softmax 与同步行列 permutation 相容: $\text{softmax}_{\text{row}}(PSP^\top) = P \text{softmax}_{\text{row}}(S)P^\top$ 。

因此:

$$\text{Attn}(PX) = P \text{Attn}(X). \quad (59.23)$$

模型知道“有哪些 token”，但没有显式绝对或相对顺序坐标。

说明 59.1. 固定 causal triangular mask 本身会破坏任意 permutation symmetry，因为可见集合依赖位置。

但 causal mask 只编码“能否看见未来”，并不能替代丰富的绝对/相对位置特征。

59.8.2 Learned Absolute Position

$P_{\text{learned}} \in \mathbb{R}^{L_{\text{max}} \times d}$ 。

输入:

$$X^{(0)} = E_{\text{token}} + P_{\text{learned}}. \quad (59.24)$$

59.8.3 Sinusoidal Position

本文主约定使用 base $B = 10000$ 。

对位置 p 和维度 index i :

$$\text{PE}(p, 2i) = \sin\left(\frac{p}{B^{2i/d}}\right), \quad (59.25)$$

$$\text{PE}(p, 2i+1) = \cos\left(\frac{p}{B^{2i/d}}\right). \quad (59.26)$$

[NLP-Train] 的图中把 base 写成一般常数 n ；只要全文固定，二者属于相同形式的参数化。

输入:

$$x_p^{(0)} = e_{w_p} + \text{PE}(p). \quad (59.27)$$



59.9 Transformer Block

本文采用 pre-norm 主约定。

输入: $\mathbf{X}^{(\ell)} \in \mathbb{R}^{L \times d}$ 。

Attention residual:

$$\mathbf{U}^{(\ell)} = \mathbf{X}^{(\ell)} + \text{MHA}(\text{LN}(\mathbf{X}^{(\ell)})). \quad (59.28)$$

FFN residual:

$$\mathbf{X}^{(\ell+1)} = \mathbf{U}^{(\ell)} + \text{FFN}(\text{LN}(\mathbf{U}^{(\ell)})). \quad (59.29)$$

原始 Transformer 也常写 post-norm: $\text{LN}(\mathbf{X} + \text{Sublayer}(\mathbf{X}))$ 。

两者不得静默混合。

59.10 Position-Wise Feed-Forward Network

对每个 token row 独立应用相同 MLP:

$$\text{FFN}(\mathbf{X}) = \phi(\mathbf{X}\mathbf{W}_1 + \mathbf{b}_1)\mathbf{W}_2 + \mathbf{b}_2. \quad (59.30)$$

其中: $\mathbf{W}_1 \in \mathbb{R}^{d \times d_{\text{ff}}}$, $\mathbf{W}_2 \in \mathbb{R}^{d_{\text{ff}} \times d}$ 。

常见: $d_{\text{ff}} \approx 4d$ 。

FFN 参数量:

$$P_{\text{FFN}} = 2dd_{\text{ff}} + d_{\text{ff}} + d. \quad (59.31)$$

Attention 负责跨 token 信息交换; FFN 在每个 token 位置做非线性 feature transformation。

59.11 Layer Normalization

对单个 token vector $\mathbf{x} \in \mathbb{R}^d$, 定义:

$$\mu(\mathbf{x}) = \frac{1}{d} \sum_{j=1}^d x_j, \quad (59.32)$$

$$\sigma^2(\mathbf{x}) = \frac{1}{d} \sum_{j=1}^d (x_j - \mu)^2. \quad (59.33)$$

$$\text{LN}(\mathbf{x}) = \gamma \odot \frac{\mathbf{x} - \mu(\mathbf{x})\mathbf{1}}{\sqrt{\sigma^2(\mathbf{x}) + \varepsilon}} + \beta. \quad (59.34)$$

其中: $\gamma, \beta \in \mathbb{R}^d$ 。

两个 LayerNorm 的参数量: $4d$ 。

易错点、反例与失败模式

LayerNorm 与 BatchNorm 不同:

- LayerNorm 对每个 token 的 feature dimension 归一化;



- 不依赖 batch statistics;
- training 与 inference 使用同一计算形式;
- BatchNorm 的训练/测试统计量不同。

59.12 Encoder、Decoder-Only 与 Encoder–Decoder

59.12.1 Transformer Encoder

每层包含: bidirectional self-attention + FFN。

适合:

- masked language modeling;
- classification;
- sequence labeling;
- dense retrieval encoder。

59.12.2 Decoder-Only Transformer

每层包含: causal self-attention + FFN。

概率分解: $p(w_{1:T}) = \prod_{t=1}^T p(w_t | w_{<t})$ 。

适合自回归生成。

59.12.3 Encoder–Decoder Transformer

Encoder: bidirectional self-attention。

Decoder 每层通常包含:

1. causal self-attention;
2. encoder–decoder cross-attention;
3. FFN。

适合:

- machine translation;
- summarization;
- conditional generation。

59.13 Language Modeling Head

最后一层 hidden states: $\mathbf{H} \in \mathbb{R}^{L \times d}$ 。



unembedding:

$$\mathbf{Z} = \mathbf{H}\mathbf{W}_U^\top + \mathbf{1}\mathbf{b}_U^\top, \quad \mathbf{W}_U \in \mathbb{R}^{V \times d}. \quad (59.35)$$

$\mathbf{Z} \in \mathbb{R}^{L \times V}$ 。

每行 softmax: $p_\theta(w_{t+1} = v \mid w_{\leq t}) = \text{softmax}(\mathbf{Z}_{t,:})_v$ 。

可采用 weight tying: $\mathbf{W}_U = \mathbf{E}_{\text{token}}$ 。

训练 loss:

$$\mathcal{L}_{\text{CLM}} = - \sum_{t=1}^{L-1} \log p_\theta(w_{t+1} \mid w_{\leq t}). \quad (59.36)$$

59.13.1 训练并行与推理串行

训练时, 完整 gold sequence 已知, 通过 causal mask 可一次计算所有位置的 logits。

推理时, w_{t+1} 未知, 必须先生成它, 才能构造下一步 history。

所以: Transformer 训练可沿序列并行, 但 autoregressive decoding 仍按 token 串行。

59.14 Transformer 时间复杂度

设: $\mathbf{X} \in \mathbb{R}^{L \times d}$, d_{ff} 为 FFN hidden dimension。

59.14.1 Q/K/V 与输出投影

$O(Ld^2)$ 。

59.14.2 Attention Score

$\mathbf{Q}\mathbf{K}^\top$: $O(L^2d)$ 。

59.14.3 Weighted Value Sum

$\mathbf{A}\mathbf{V}$: $O(L^2d)$ 。

59.14.4 FFN

$O(Ldd_{\text{ff}})$ 。

因此单层总时间:


$$O(Ld^2 + L^2d + Ldd_{\text{ff}}). \quad (59.37)$$

当 $d_{\text{ff}} = \Theta(d)$, 可简写为 $O(Ld^2 + L^2d)$ 。

59.14.5 空间复杂度

attention weights: $O(HL^2)$ 。

Q/K/V 和 residual activations: $O(Ld)$ 。



FFN activations: $O(Ld_{\text{ff}})$ 。

训练单层主要空间：

$$O(HL^2 + Ld + Ld_{\text{ff}}). \quad (59.38)$$

标准 attention 的 $O(L^2)$ 来自全部 token pair 的 score matrix。

59.15 KV Cache

在 decoder-only autoregressive inference 中，过去 token 的 K、V 不随新 token 改变。

第 t 步缓存: $\mathbf{K}_{1:t}$, $\mathbf{V}_{1:t}$ 。

每层 cache 空间：

$$O(td). \quad (59.39)$$

新 token 的 attention 主项: $O(td)$ 。

生成长度 L 的总 attention 成本：

$$\sum_{t=1}^L O(td) = O(L^2d). \quad (59.40)$$

KV cache 不把完整生成复杂度降为线性，而是避免每一步重新计算全部历史 K/V。

易错点、反例与失败模式

以下三种复杂度必须区分：

- prompt prefill: $O(L^2d)$;
- 使用 KV cache 的单步 decode: $O(Ld)$;
- 使用 KV cache 生成 L 个 token 的总 attention: $O(L^2d)$ 。

59.16 Transformer Block 参数量

在 $Hd_k = Hd_v = d$ 且忽略小 bias 项时：

MHA: $4d^2$ 。

FFN: $2dd_{\text{ff}}$ 。

两个 LayerNorm: $4d$ 。

单 block:

$$P_{\text{block}} \approx 4d^2 + 2dd_{\text{ff}} + 4d. \quad (59.41)$$

若 $d_{\text{ff}} = 4d$, 主项约为: $12d^2$ 。

还未计入：

- token embedding;
- position embedding;
- language-model head;



- bias;
- cross-attention parameters。

59.17 RNN、LSTM 与 Transformer 比较

表 59.1: RNN、LSTM 与 Transformer

比较项	Simple RNN	LSTM	Transformer
顺序依赖	$h_t = f(x_t, h_{t-1})$ 严格串行	同样严格串行	训练时同层各 token 可并行
顺序信息	由 recurrence 隐式编码	由 recurrence 与 gates 编码	需 position feature; causal mask 只规定可见性
长依赖路径	两个位置间路径长度 $O(L)$	仍为 $O(L)$ 但 cell state 提供较稳梯度	同层 global attention 路径长度可为 $O(1)$
主要梯度问题	vanishing/exploding	缓解 vanishing, 不能消除	无时间维 recurrent Jacobian 连乘; 仍有深层优化问题
时间复杂度	约 $O(Ld^2)$	约 $O(4Ld^2)$	$O(Ld^2 + L^2d)$
Attention memory	无 L^2 attention matrix	无 L^2 attention matrix	标准形式 $O(HL^2)$
并行硬件效率	低	低	训练阶段高
局部归纳偏差	强 temporal recurrence	强 temporal recurrence 与记忆门	content-based global interaction; 局部性需由数据、mask 或结构注入
自回归推理	逐 token	逐 token	仍逐 token, 可用 KV cache
主要失败模式	长依赖遗忘	顺序瓶颈、门控失效	长序列二次成本、位置外推和高内存

59.18 Transformer 相比 RNN 的真题答法

答题方法

[25S-D-Q5, 3 分] 或 [26S-B-Q1(e), 2 分]:

至少写两点，并给出数学或计算结构依据。

第一点：训练并行性。

RNN: $h_t = f(x_t, h_{t-1})$, 所以 h_t 必须等待 h_{t-1} 。

Transformer: $Q = XW_Q, K = XW_K, V = XW_V$, 所有位置可通过矩阵乘法并行计算。

第二点：长距离交互路径。

RNN 中位置 i 到 j 的信息需经过 $|j - i|$ 次 recurrent transition。

标准 self-attention 中，位置 i 可在一个 layer 内直接 attend 到 j 。

可加第三点：上下文化和多头关系。

Multi-head attention 可在不同 projection subspaces 中学习多种 token-token 关系。

必须补充边界：

Transformer 并非在所有输入长度和样本规模下无条件更优；标准 attention 有 $O(L^2)$ 时间和空间瓶颈。

59.19 Self-Attention 真题满分模板

答题方法

[25F-B-Q1(b), 3 分]:

令 $X \in \mathbb{R}^{L \times d}$, $Q = XW_Q \in \mathbb{R}^{L \times d_k}$, $K = XW_K \in \mathbb{R}^{L \times d_k}$, $V = XW_V \in \mathbb{R}^{L \times d_v}$ 。

写出: $\text{Attention}(Q, K, V) = \text{softmax}_{\text{row}} \left(\frac{QK^\top}{\sqrt{d_k}} + M \right) V$ 。

解释:

- Q : 当前位置寻找什么信息;
- K : 每个位置提供何种匹配特征;
- V : 被加权汇聚的内容;
- $1/\sqrt{d_k}$: 稳定 score 方差与 softmax gradient;
- position encoding: 打破无位置 self-attention 的 permutation equivariance;
- causal LM 中 $M_{ij} = -\infty$ ($j > i$)。

59.20 25F Scaling-Law 题的架构侧准备

[25F-D-Q2, 5 分] 给定: $L_{\text{arch}}(P, T) = L_\infty + A_{\text{arch}}P^{-\alpha_{\text{arch}}} + B_{\text{arch}}T^{-\beta_{\text{arch}}}$ 。

固定 $T = T_0$: $\Delta(P) := L(P, T_0) - L_\infty = AP^{-\alpha} + BT_0^{-\beta}$ 。

其 log-log 局部斜率为:

$$\frac{d \log \Delta(P)}{d \log P} = -\alpha \frac{AP^{-\alpha}}{AP^{-\alpha} + BT_0^{-\beta}}. \quad (59.42)$$

只有 parameter term 主导时, 斜率才近似 $-\alpha$ 。

固定 $P = P_0$: $\Delta(T) = AP_0^{-\alpha} + BT^{-\beta}$, 局部斜率:

$$\frac{d \log \Delta(T)}{d \log T} = -\beta \frac{BT^{-\beta}}{AP_0^{-\alpha} + BT^{-\beta}}. \quad (59.43)$$

架构侧可从三点论证 Transformer 可能表现出更有利的经验常数或指数:

1. global attention 缩短长依赖路径;
2. training parallelism 提高固定计算预算下的 token throughput;
3. 更短的计算路径和 residual structure 改善大规模优化。

但必须明确: $\alpha_{\text{Transformer}} > \alpha_{\text{LSTM}}$ 或 $A_{\text{Transformer}} < A_{\text{LSTM}}$ 属于给定实验协议下的经验判断, 不是无条件数学定理。

完整 scaling-law 分析在下一部分继续。



59.21 Transformer 易错点

易错点、反例与失败模式

1. QK^T 的形状是 $L \times L$, 不是 $d_k \times d_k$ 。
2. Softmax 对 score matrix 的每一行做归一化。
3. Attention output 是对 V 的加权和, 不是对 K 的加权和。
4. Q 、 K 、 V 是 role-specific projections, 不是三份完全相同的 embedding。
5. 缩放因子是 $1/\sqrt{d_k}$, 不是 $1/d_k$ 。
6. Self-attention 与 cross-attention 的 $Q/K/V$ 来源不同。
7. Causal attention 与 bidirectional attention 的 mask 不同。
8. Position encoding 不等于 attention mask。
9. Residual addition 要求输入输出维度一致。
10. LayerNorm training/evaluation 计算相同; 不使用 running mean/variance。
11. FFN 在 token 之间不交换信息; token interaction 主要由 attention 完成。
12. Transformer 训练可以沿序列并行; autoregressive inference 仍逐 token。
13. KV cache 减少重复计算, 不消除总生成的二次 attention 成本。
14. 标准 attention 是 $O(L^2)$ time/memory; 稀疏或线性 attention 的保证需另行说明。
15. Attention weight 不等于严格解释或因果贡献。
16. Transformer 的经验 scaling 优势不能写成无条件定理。

59.22 核心模型速查表

表 59.2: 本部分核心模型速查

模型	Data signal	核心目标/更新	主要复杂度与失败模式
TF-IDF	term-document counts	$\text{tfidf}_{t,d} = (1 + \log c_{t,d}) \log(D/\text{df}_t)$	Sparse; 忽略顺序、同义和多义
PPMI	word-context counts	$\max \left\{ \log \frac{p(w,c)}{p(w)p(c)}, 0 \right\}$	稀有 pair 偏置; 零 count 需处理
Skip-gram	局部 center-context pair	$-\log p(c w)$ 或 SGNS	full softmax: $O(Vd)$; SGNS: $O(kd)$
CBOW	多个 context 预测中心词	$h = \frac{1}{M} \sum v_c, \quad -\log p(w h)$	计算较快; context averaging 可能丢失顺序
GloVe	全局共现矩阵	$f(X_{ij})(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2$	$O(\text{nnz}(X)d)$; static, count-sensitive

模型	Data signal	核心目标/更新	主要复杂度与失败模式
Node2Vec	biased random walks	random-walk Skip-gram/SGNS	依赖 p, q ; 高 degree 偏置; transductive limitation
TransE	KG triples	$[\gamma + d(h, r, t) - d(h', r, t')]_+$	$O(kd)$ per positive; one-to-many、symmetric relation 难
RNN	ordered token sequence	$h_t = \phi(W_x x_t + W_h h_{t-1})$	$O(Ld^2)$ 但顺序深度 $O(L)$; vanishing/exploding
LSTM	ordered token sequence	$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$	约 4 倍 recurrent cost; 仍串行
Transformer	全部 token pair	$\text{softmax}(QK^\top / \sqrt{d_k} + M)V$	$O(Ld^2 + L^2 d)$; attention memory $O(HL^2)$

59.23 本部分真题与资料映射

表 59.3: 自然语言处理第 16 部分映射

主题	等级	博资考对应	方向资料对应
Representation learning	S	[25S-D-Q2, 3 分]; [26S-D-Q1, 6 分] 的前置	[NLP-Train] embedding representation; [SLP] Ch.6
TF-IDF、PMI、PPMI	B	无单独直接题; retrieval 和 embedding 的基础	[SLP] Ch.6.5–6.7
Skip-gram、GloVe	S	[25F-D-Q1, 3 分]	[NLP-Train] pp.64–72; [SLP] Ch.6.8
Node2Vec、TransE	S	[25F-D-Q1, 3 分]	[NLP-Train] pp.166–170
RNN、LSTM	S	[25S-D-Q5, 3 分]; [25F-D-Q2, 5 分]	[SLP] Ch.8
Encoder-decoder、teacher forcing	A	生成和预训练题的共同前置	[SLP] Ch.8.7; [NLP-Train] pp.74–76
RNN attention	A	Transformer 与 seq2seq 前置	[SLP] Ch.8.8; [NLP-Train] pp.75–76
Scaled self-attention	S	[25F-B-Q1(b), 3 分]; [26S-B-Q1(d), 2 分]	[SLP] Ch.9; [NLP-Train] pp.84–87
Transformer block	S	[25S-D-Q5, 3 分]; [26S-B-Q1(e), 2 分]	[SLP] Ch.9.2–9.5; [NLP-Train] pp.88–95
标准 attention 复杂度	S	[26S-D-Q3, 7 分]	[SLP] Ch.9.3; 长序列变体在下一部分
LSTM vs. Transformer scaling	S	[25F-D-Q2, 5 分]	本部分给架构依据; 完整 empirical scaling law 在下一部分

说明 59.2. 本部分没有使用 [MLT-Final]、[MLT-Practice]、[MLT-HW1–3] 来计算 NLP 博资考频率。
机器学习理论课程题不属于人工智能博资考历年真题。

59.24 综合快速自测

快速自测

1. 为什么 representation learning 不等于降维?
2. Static embedding 与 contextual embedding 的形式区别是什么?
3. 写出 TF-IDF 和 PPMI 的完整定义。
4. 为什么 cosine 不等于概率?
5. Skip-gram full softmax 与 SGNS 的目标有何根本区别?
6. 推导 SGNS 对 center embedding 的梯度。
7. 推导 shifted-PMI 关系需要什么 noise distribution?
8. GloVe 的目标变量、bias 和 weighting function 分别是什么?
9. Node2Vec 的 data signal 为什么不是原始文本?
10. p, q 如何影响随机游走?
11. TransE 的 translation bias 是什么?
12. 写出 TransE margin-ranking loss。
13. Simple RNN 参数量如何计算?
14. 写出 BPTT 的 hidden adjoint recurrence。
15. 为什么 RNN 梯度涉及 Jacobian 连乘?
16. LSTM 的 cell-state direct gradient path 是什么?
17. Teacher forcing 与 autoregressive inference 如何区分?
18. 写出 RNN attention 的三个步骤。
19. 给出 Q, K, V 的全部维度。
20. 为什么除以 $\sqrt{d_k}$?
21. causal mask 的 M_{ij} 如何定义?
22. self-attention 与 cross-attention 的 Q/K/V 来源有何不同?
23. Multi-head 输出如何恢复为 $L \times d$?
24. 无位置 unmasked self-attention 为什么 permutation equivariant?
25. 写出 pre-norm Transformer block。
26. LayerNorm 沿哪个维度计算均值与方差?
27. 标准 Transformer 单层时间和空间复杂度是什么?
28. KV cache 改变的是单步成本还是完整生成的渐近二次成本?
29. Transformer 训练为什么可并行, 而生成仍串行?

30. LSTM 与 Transformer 的 scaling 差异为何只能称为经验规律?



第六十章 自回归语言模型、预训练与解码

60.1 重要性等级与考试定位

重要性等级：S

自回归语言模型是现代生成式 LLM 的概率基础。

必须掌握：

1. 条件概率的 chain-rule factorization;
2. token-level cross-entropy 与 sequence likelihood 的关系;
3. teacher forcing 与 autoregressive inference 的差异;
4. perplexity 的数学定义和比较边界;
5. greedy、beam、temperature、top- k 、top- p ;
6. 为什么 decoding algorithm 不改变已训练模型本身的参数;
7. 为什么局部最大概率 token 不等于全局最大概率序列。

其中 [25S-D-Q3, 3 分] 直接要求解释当前 LLM 为什么使用 top- p ，而不是 greedy、beam search 或固定 top- k 。

60.2 统一记号

词表： $\mathcal{V} = \{1, \dots, V\}$ 。

prompt： $\mathbf{x} = (x_1, \dots, x_M)$ 。

待生成 response： $\mathbf{y} = (y_1, \dots, y_T)$ 。

在第 t 个生成位置之前的状态记为：


$$s_t = (\mathbf{x}, \mathbf{y}_{<t}) = (x_1, \dots, x_M, y_1, \dots, y_{t-1}). \quad (60.1)$$

语言模型 policy： $\pi_\theta(\cdot | s_t) \in \Delta^{V-1}$ ，其中 $\Delta^{V-1} = \left\{ \mathbf{p} \in \mathbb{R}^V : p_v \geq 0, \sum_{v=1}^V p_v = 1 \right\}$ 。

logits： $\mathbf{z}_\theta(s_t) = (z_{t,1}, \dots, z_{t,V}) \in \mathbb{R}^V$ 。

token probability：

$$\pi_\theta(y_t = v | s_t) = \frac{\exp z_{t,v}}{\sum_{u=1}^V \exp z_{t,u}}. \quad (60.2)$$



60.3 自回归条件分解

定义 60.1 (条件自回归语言模型). 给定 prompt $\mathbf{x}$, response 的条件概率按照 chain rule 分解为

$$\pi_{\theta}(\mathbf{y} | \mathbf{x}) = \prod_{t=1}^T \pi_{\theta}(y_t | \mathbf{x}, y_{<t}). \quad (60.3)$$

取对数:

$$\log \pi_{\theta}(\mathbf{y} | \mathbf{x}) = \sum_{t=1}^T \log \pi_{\theta}(y_t | \mathbf{x}, y_{<t}). \quad (60.4)$$

若包括 EOS token, 则序列长度也属于模型随机变量。可写成: $\mathbf{y} = (y_1, \dots, y_T, \text{EOS})$ 。

此时完整概率为

$$\pi_{\theta}(\mathbf{y}, \text{EOS} | \mathbf{x}) = \left[\prod_{t=1}^T \pi_{\theta}(y_t | \mathbf{x}, y_{<t}) \right] \pi_{\theta}(\text{EOS} | \mathbf{x}, y_{\leq T}). \quad (60.5)$$

说明 60.2. 式 (60.3) 是概率 chain rule, 本身没有近似。

模型近似发生在: $\pi_{\theta}(y_t | s_t)$ 如何由有限参数神经网络表示, 而不是发生在 chain rule。

60.4 Maximum Likelihood 与 Cross-Entropy

训练数据: $\mathcal{D} = \{(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})\}_{i=1}^N$ 。

maximum likelihood estimator:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \sum_{i=1}^N \log \pi_{\theta}(\mathbf{y}^{(i)} | \mathbf{x}^{(i)}). \quad (60.6)$$

等价地最小化 negative log-likelihood:

$$\mathcal{L}_{\text{NLL}}(\theta) = - \sum_{i=1}^N \sum_{t=1}^{T_i} \log \pi_{\theta}(y_t^{(i)} | \mathbf{x}^{(i)}, y_{<t}^{(i)}). \quad (60.7)$$

常用 token-average loss:

$$\bar{\mathcal{L}}_{\text{NLL}} = - \frac{1}{\sum_{i=1}^N T_i} \sum_{i=1}^N \sum_{t=1}^{T_i} \log \pi_{\theta}(y_t^{(i)} | \mathbf{x}^{(i)}, y_{<t}^{(i)}). \quad (60.8)$$


60.4.1 带 Padding 的 Loss Mask

若 batch 中所有 sequence padding 到长度 $T_{\max}$, 定义: $m_{it} = \begin{cases} 1, & t \leq T_i, \\ 0, & t > T_i. \end{cases}$

则:

$$\mathcal{L} = - \frac{\sum_{i,t} m_{it} \log \pi_{\theta}(y_{it} | s_{it})}{\sum_{i,t} m_{it}}. \quad (60.9)$$

padding token 不应计入 loss。



60.4.2 Logit Gradient

对单个位置 t ，令真实 token 为 y_t^* ，one-hot label 为： $q_{t,v} = \mathbf{1}\{v = y_t^*\}$ 。

交叉熵： $\ell_t = -\sum_{v=1}^V q_{t,v} \log p_{t,v} = -\log p_{t,y_t^*}$ 。

softmax-cross-entropy 的梯度为：

$$\frac{\partial \ell_t}{\partial z_{t,v}} = p_{t,v} - q_{t,v}. \quad (60.10)$$

因此：

- 对真实 token： $\frac{\partial \ell_t}{\partial z_{t,y_t^*}} = p_{t,y_t^*} - 1 < 0$ ；
- 对错误 token： $\frac{\partial \ell_t}{\partial z_{t,v}} = p_{t,v} > 0$ 。

梯度下降会提高真实 token logit，并降低其他 token logits。

60.5 Teacher Forcing

训练时，第 t 步条件使用 gold prefix：

$$s_t^{\text{train}} = (\mathbf{x}, y_{<t}^*). \quad (60.11)$$

推理时，第 t 步使用模型此前生成的 prefix：

$$s_t^{\text{test}} = (\mathbf{x}, \hat{y}_{<t}). \quad (60.12)$$

这一区别称为 teacher forcing。

60.5.1 Teacher Forcing 的优势

1. 每个训练位置都使用正确历史；
2. 不需要对离散 sampling 操作求导；
3. Transformer 可在 causal mask 下并行计算全部位置；
4. 训练早期不会因模型错误而使后续输入完全偏离数据分布。

60.5.2 Exposure Bias


训练历史分布： $s_t \sim d_{\text{data}}$ 。

推理历史分布： $s_t \sim d_{\pi_\theta}$ 。

一般有： $d_{\text{data}} \neq d_{\pi_\theta}$ 。

一个早期错误 $\hat{y}_t \neq y_t^*$ 会改变后续全部条件分布： $\pi_\theta(y_{t+1} \mid \mathbf{x}, \hat{y}_{\leq t}) \neq \pi_\theta(y_{t+1} \mid \mathbf{x}, y_{\leq t}^*)$ 。

这就是 exposure bias 或 train-test mismatch。



易错点、反例与失败模式

Teacher forcing 并不是：

- 把模型预测 token 作为下一个训练输入；
- beam search；
- top- p sampling；
- 强化学习；
- masked language modeling。

它特指训练时条件于 gold prefix。

60.6 训练并行与生成串行

在 causal Transformer 训练中，整个输入 $(w_1, \dots, w_L)$ 已知。

通过 causal mask，可一次计算： $p(w_2 | w_1)$, $p(w_3 | w_{1:2})$, $\dots$, $p(w_L | w_{1:L-1})$ 。

因此同一层中所有 token positions 可并行。

但生成时， y_t 尚未知，必须先得到： $\hat{y}_t$ 才能构造： $s_{t+1} = (\mathbf{x}, \hat{y}_{\leq t})$ 。

所以：训练阶段可在 token 维并行，而：标准 autoregressive decoding 仍然逐 token 串行。

60.7 Perplexity

定义 60.3 (平均交叉熵). 对测试序列 $w_{1:L}$, 以自然对数为主约定：

$$H_\theta(w_{1:L}) = -\frac{1}{L} \sum_{t=1}^L \log p_\theta(w_t | w_{<t}). \quad (60.13)$$

定义 60.4 (Perplexity).

$$\boxed{\text{PPL}_\theta(w_{1:L}) = \exp \left[-\frac{1}{L} \sum_{t=1}^L \log p_\theta(w_t | w_{<t}) \right]}. \quad (60.14)$$

等价地：

$$\text{PPL}_\theta(w_{1:L}) = p_\theta(w_{1:L})^{-1/L} = \left[\prod_{t=1}^L \frac{1}{p_\theta(w_t | w_{<t})} \right]^{1/L}. \quad (60.15)$$

若使用以 2 为底的 logarithm： $\text{PPL} = 2^{H_2}$ 。


60.7.1 解释

若模型在每个位置都近似在 K 个 token 间均匀选择： $p(w_t | w_{<t}) \approx \frac{1}{K}$, 则： $\text{PPL} \approx K$ 。

因此 perplexity 可粗略解释为模型的“有效平均候选分支数”。

60.7.2 与 Likelihood 的关系

固定 tokenizer 和测试数据时： $\text{PPL} \downarrow \iff \bar{\mathcal{L}}_{\text{NLL}} \downarrow \iff p_\theta(w_{1:L})^{1/L} \uparrow$ 。



60.7.3 Perplexity 的边界

易错点、反例与失败模式

Perplexity 不能无条件跨模型比较。

尤其当两个模型使用不同 tokenizer 时: $L_1 \neq L_2$, 单位 token 的平均 NLL 对应不同基本事件。

例如同一个字符串可能被切成: 3 个 token 或 8 个 token。

此时 perplexity 的数值不在同一尺度上。

此外, 低 perplexity 不必然推出:

- 事实正确;
- 指令遵循;
- 安全;
- 公平;
- 高人类偏好;
- 开放式生成更有创造性。

60.8 Causal Language Model Pretraining

给定无标注语料: $\mathcal{C} = \{w_1, \dots, w_N\}$, 自然序列本身提供监督标签。

训练 objective:

$$\mathcal{L}_{\text{CLM}}(\theta) = -\mathbb{E}_{w_{1:L} \sim \mathcal{C}} \left[\sum_{t=1}^{L-1} \log p_{\theta}(w_{t+1} \mid w_{\leq t}) \right]. \quad (60.16)$$

这称为 self-supervised learning, 因为 target token 来自原始文本自身, 而不是额外人工标签。

60.8.1 Document Packing

若单篇文档短于 context window L , 可将多篇文档打包: $d^{(1)} \parallel \text{EOS} \parallel d^{(2)} \parallel \text{EOS} \parallel \dots$ 。

必须:

- 使用文档边界 token;
- 决定是否允许跨文档 attention;
- 避免把 padding 计入 loss;
- 在数据加载时防止测试集泄漏。

60.8.2 Data Mixture

设有 J 个数据来源: $\mathcal{C}_1, \dots, \mathcal{C}_J$ 。

采样 mixture:

$$p_{\text{mix}}(d) = \sum_{j=1}^J \lambda_j p_j(d), \quad \lambda_j \geq 0, \quad \sum_j \lambda_j = 1. \quad (60.17)$$



权重 λ_j 决定不同 domain 对训练梯度的贡献。

高质量小语料常被 upsample，大规模低质量 web data 常被 downsample 或过滤。

60.8.3 数据处理

至少应检查：

1. language identification;
2. document-level 与 span-level deduplication;
3. boilerplate removal;
4. personally identifiable information;
5. copyright 和 consent;
6. toxicity、spam、机器生成文本;
7. benchmark contamination;
8. domain 和语言分布平衡。

60.9 继续预训练与领域自适应

设通用预训练参数为： θ_0 。

给定领域语料 $\mathcal{C}_{\text{dom}}$, domain-adaptive pretraining 可写为：

$$\theta_{\text{dom}} = \arg \min_{\theta} \mathcal{L}_{\text{CLM}}(\theta; \mathcal{C}_{\text{dom}}) + \lambda \Omega(\theta, \theta_0). \quad (60.18)$$

其中： $\Omega(\theta, \theta_0)$ 用于限制模型偏离通用能力。

常见选择： $\Omega(\theta, \theta_0) = \|\theta - \theta_0\|_2^2$ 或混合通用语料继续训练。

易错点、反例与失败模式

继续预训练并不等于 supervised fine-tuning。

- 继续预训练：使用无标注领域文本和 next-token objective;
- SFT：使用人工或合成的 (instruction, response) 监督 pair。


60.10 序列级 Decoding Objective

理论上的最大后验序列是：

$$\hat{\mathbf{y}}_{\text{MAP}} = \arg \max_{\mathbf{y}} \log \pi_{\theta}(\mathbf{y} | \mathbf{x}) = \arg \max_{\mathbf{y}} \sum_t \log \pi_{\theta}(y_t | \mathbf{x}, y_{<t}). \quad (60.19)$$

若每步有 V 个候选、最大长度为 T ，候选序列数量为： $O(V^T)$ 。

因此精确 exhaustive search 通常不可行。



60.11 Greedy Decoding

$$\hat{y}_t = \arg \max_{v \in \mathcal{V}} \pi_{\theta}(v \mid \mathbf{x}, \hat{y}_{<t}). \quad (60.20)$$

优点:

- 实现简单;
- 每步只保留一条 prefix;
- 确定性;
- 计算成本低。

缺点:

- 只做局部最优选择;
- 无法撤销早期错误;
- 开放式文本容易 generic、重复;
- 不保证得到式 (60.19) 的全局最优序列。

易错点、反例与失败模式

以下逻辑是错误的: $\arg \max_{y_1} p(y_1), \arg \max_{y_2} p(y_2 \mid y_1), \dots$ 不一定组成: $\arg \max_{\mathbf{y}} p(\mathbf{y})$ 。
局部最大值的乘积未必是所有完整路径中的最大值。

60.12 Beam Search

beam width: $B \geq 1$ 。

在第 t 步维护: $\mathcal{B}_t = \{(\mathbf{y}_{1:t}^{(b)}, S_t^{(b)})\}_{b=1}^B$ 。

raw log-score:

$$S_t(\mathbf{y}_{1:t}) = \sum_{j=1}^t \log \pi_{\theta}(y_j \mid \mathbf{x}, y_{<j}). \quad (60.21)$$

每一步:

1. 对每个 beam prefix 扩展所有 token;
2. 形成至多 BV 个候选;
3. 按 sequence score 取前 B 个;
4. 遇到 EOS 的候选可转入完成集合。

当: $B = 1$, beam search 退化为 greedy decoding。

60.12.1 长度偏置

因为: $\log p_t \leq 0$, raw score 随序列长度增加通常更负。



因此常使用长度归一化：

$$S_{\text{norm}}(\mathbf{y}) = \frac{\log \pi_{\theta}(\mathbf{y} \mid \mathbf{x})}{\text{LP}(|\mathbf{y}|)}, \quad (60.22)$$

例如：

$$\text{LP}(T) = \left(\frac{5+T}{6} \right)^{\alpha}, \quad \alpha \geq 0. \quad (60.23)$$

这属于 decoding heuristic，不是原模型概率本身。

60.12.2 Beam Search 的适用场景

更适合：

- machine translation;
- speech recognition;
- constrained generation;
- 输出空间相对集中、参考答案较确定的任务。

开放式生成中 beam search 常出现：

- 缺乏多样性;
- 高概率套话;
- 重复;
- 随 beam 增大，输出不一定更符合人类偏好。

60.13 Random Sampling

最直接的随机生成是：

$$y_t \sim \pi_{\theta}(\cdot \mid s_t). \quad (60.24)$$

问题是长尾中存在大量单个概率很低的 token。

虽然每个低概率 token 很少被选中，但它们的总概率质量可能不小： $\sum_{v \in \text{tail}} p_v$ 。

因此纯随机 sampling 容易偶尔选到异常 token，并使后续生成偏离。

60.14 Temperature Sampling

给定原 logits: z_v 。

temperature: $\tau > 0$ 。


温度化分布：

$$p_{\tau}(v \mid s) = \frac{\exp(z_v/\tau)}{\sum_{u=1}^V \exp(z_u/\tau)}. \quad (60.25)$$

概率比：

$$\frac{p_{\tau}(i)}{p_{\tau}(j)} = \exp\left(\frac{z_i - z_j}{\tau}\right). \quad (60.26)$$

因此：



- $0 < \tau < 1$: 放大 logit 差异, 分布更尖锐;
- $\tau = 1$: 保持原分布;
- $\tau > 1$: 压缩 logit 差异, 分布更平坦;
- $\tau \rightarrow 0^+$: 趋近 greedy;
- $\tau \rightarrow \infty$: 趋近 uniform distribution。

易错点、反例与失败模式

Temperature 改变的是相对概率, 但不改变 logit 的排序。

若: $z_i > z_j$, 则对任意 $\tau > 0$ 仍有: $p_\tau(i) > p_\tau(j)$ 。

60.15 Top- k Sampling

将温度处理后的概率按降序排列: $p_{(1)} \geq p_{(2)} \geq \dots \geq p_{(V)}$ 。

top- k candidate set:

$$\mathcal{V}_k = \{v_{(1)}, \dots, v_{(k)}\}. \quad (60.27)$$

截断并归一化:

$$q_k(v) = \frac{p(v)\mathbf{1}\{v \in \mathcal{V}_k\}}{\sum_{u \in \mathcal{V}_k} p(u)}. \quad (60.28)$$

然后: $y_t \sim q_k$ 。

性质:

- $k = 1$ 时等价于 greedy;
- $k = V$ 时等价于原始 random sampling;
- 候选数始终固定为 k 。

60.16 Top- p / Nucleus Sampling

设: $p \in (0, 1]$ 。

按降序排列: $p_{(1)} \geq p_{(2)} \geq \dots \geq p_{(V)}$ 。

定义最小整数:

$$m_p = \min \left\{ m : \sum_{j=1}^m p_{(j)} \geq p \right\}. \quad (60.29)$$

nucleus set:


$$\mathcal{V}_p = \{v_{(1)}, \dots, v_{(m_p)}\}. \quad (60.30)$$

截断归一化:

$$q_p(v) = \frac{p(v)\mathbf{1}\{v \in \mathcal{V}_p\}}{\sum_{u \in \mathcal{V}_p} p(u)}. \quad (60.31)$$

然后: $y_t \sim q_p$ 。

候选集合大小: $|\mathcal{V}_p| = m_p$ 随 context 动态变化。



60.16.1 尖锐分布

若: $p_{(1)} = 0.95$, $p = 0.9$, 则: $m_p = 1$ 。

top- p 自动接近 greedy。

60.16.2 平坦分布

若前若干 token 概率均较接近, 需要更多 token 才能达到累计概率 p , 因此: m_p 会增大。

60.17 Temperature 与 Top- p 的组合

常见顺序是:

1. 对 logits 除以 temperature;
2. softmax 得到 p_τ ;
3. 根据 p_τ 构造 top- p nucleus;
4. 在 nucleus 内重新归一化并 sampling。

即:

$$q_{\tau,p}(v) = \frac{p_\tau(v) \mathbf{1}\{v \in \mathcal{V}_p(p_\tau)\}}{\sum_{u \in \mathcal{V}_p(p_\tau)} p_\tau(u)}. \quad (60.32)$$

易错点、反例与失败模式

Temperature 与 top- p 一般不交换。

原因是 temperature 会改变累计概率质量, 从而改变: $\mathcal{V}_p$ 。

因此“先截断再温度化”和“先温度化再截断”可能得到不同候选集合。

60.18 为什么开放式 LLM 生成通常使用 Top- p

答题方法

[25S-D-Q3, 3 分] 满分结构:

第一, greedy 的问题。

Greedy 每一步选择: $\arg \max_v p(v | s_t)$, 是确定性局部最优, 容易产生高频、generic、重复文本, 且不能恢复早期错误。

第二, beam search 的问题。

Beam search 近似优化 sequence probability, 适合 translation 等约束较强的任务; 但开放式生成存在大量同样合理的 continuation, 纯概率最大化容易偏向常见套话和低多样性输出。

第三, 固定 top- k 的问题。

top- k 保留固定数量 token, 但不同 context 下分布形状不同:

- 尖锐 context 中 k 可能过大, 引入低质量 token;
- 平坦 context 中 k 可能过小, 删掉大量合理 token。

第四, top- p 的优势。

Top- p 选择满足: $\sum_{v \in \mathcal{V}_p} p(v | s_t) \geq p$ 的最小集合, 候选数随分布熵动态变化, 既截去长尾低概率 token, 又保留足够概率质量。

第五, 边界说明。

Top- p 不是无条件最优:

- 事实问答、数学、代码等低熵任务常需更低 temperature;
- translation 等强约束任务仍可能适合 beam search;
- p 与 τ 均需针对任务调节。

60.19 其他常见 Decoding Controls

60.19.1 Minimum Length

在长度小于 $T_{\min}$ 时: $z_{\text{EOS}} \leftarrow -\infty$ 。

60.19.2 Maximum Length

达到 $T_{\max}$ 后强制终止, 或只允许 EOS。

60.19.3 Repetition Penalty

一种 logit-level heuristic:

$$z'_v = \begin{cases} z_v / \rho, & v \text{ 已出现且 } z_v > 0, \\ \rho z_v, & v \text{ 已出现且 } z_v < 0, \\ z_v, & v \text{ 未出现,} \end{cases} \quad \rho > 1. \quad (60.33)$$

具体实现可能不同, 必须说明所采用的定义。

60.19.4 No-Repeat n -Gram

若扩展 token v 会形成此前已经出现的 n -gram, 则令: $z_v = -\infty$ 。

这可降低机械重复, 但也可能错误禁止合理复现, 例如:

- 人名;
- 法律条款;
- 代码变量;
- 数学公式;
- 强调性修辞。

60.20 Decoding 方法对比



表 60.1: 主要 decoding 方法比较

方法	规则	优点	主要局限
Greedy	$y_t = \arg \max_v p(v \mid s_t)$	快速、确定、易复现	局部最优；generic；重复；无多样性
Beam search	保留 B 条最高分 prefix	约束任务中能探索更多序列	仍非精确 MAP；长度偏置；开放式生成过于保守
Random sampling	从完整分布直接采样	保留完整模型不确定性	长尾异常 token 可能被抽中
Temperature	$p_\tau(v) \propto e^{z_v/\tau}$	连续控制 entropy	不删除长尾；参数过高会严重失真
Top- k	固定保留 k 个 token	简单、可控	固定候选数不适应 context-dependent entropy
Top- p	保留最小累计概率质量集合	候选数动态变化；质量与多样性折中	需调 p ；不保证事实正确；仍可能重复



第六十一章 Masked Language Model、SFT 与缩放律

61.1 Causal LM 与 Masked LM

Causal LM 使用: $p(x_t | x_{<t})$, 只能读取左侧 prefix。

Masked LM 使用: $p(x_i | \tilde{\mathbf{x}})$, 其中 $\tilde{\mathbf{x}}$ 是被 corruption 的完整序列, 模型可以读取被 mask 位置左右两侧的信息。

表 61.1: Causal LM 与 Masked LM

比较项	Causal LM	Masked LM
Attention	causal triangular mask	bidirectional attention, 无 causal mask
训练目标	预测下一 token	恢复被 corruption 的 token
Loss positions	通常除第一个 token 外的几乎全部位置	仅 selected/masked positions
生成	天然支持从左到右生成	不是天然的 autoregressive generator
表示	左上下文 contextual representation	双向 contextual representation
典型用途	开放式生成、对话、代码、条件生成	分类、NER、retrieval encoder、token representation

61.2 Bidirectional Self-Attention

对输入: $\mathbf{X} \in \mathbb{R}^{L \times d}$, bidirectional attention 为:

$$\text{Attn}_{\text{bi}}(\mathbf{X}) = \text{softmax}_{\text{row}} \left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d_k}} + \mathbf{M}_{\text{pad}} \right) \mathbf{V}. \quad (61.1)$$

与 causal attention 的区别是没有: $M_{ij}^{\text{causal}} = -\infty \quad (j > i)$ 。

因此位置 i 可同时读取: $x_{<i}$ 和 $x_{>i}$ 。

61.3 Masked Language Modeling

原始 token sequence: $\mathbf{x} = (x_1, \dots, x_L)$ 。

随机选择位置集合: $\mathcal{M} \subseteq \{1, \dots, L\}$ 。

corruption operator: $\tilde{\mathbf{x}} = C_{\mathcal{M}}(\mathbf{x})$ 。



MLM objective:

$$\mathcal{L}_{\text{MLM}} = -\frac{1}{|\mathcal{M}|} \sum_{i \in \mathcal{M}} \log p_{\theta}(x_i | \tilde{\mathbf{x}}). \quad (61.2)$$

61.3.1 BERT 的经典 Corruption 比例

经典 BERT 训练中: 15% 的 token 被选入 $\mathcal{M}$ 。

对于被选中的 token:

- 80%: 替换为 [MASK];
- 10%: 替换为随机 token;
- 10%: 保持原 token 不变。

目的包括:

1. [MASK] 提供明确恢复任务;
2. 随机替换要求模型识别不一致 token;
3. 保持不变减轻 pretrain-finetune mismatch, 因为下游输入通常没有 [MASK]。

61.3.2 为什么不能直接预测未 Mask 的 Token

若移除 causal mask, 同时要求模型预测当前位置原 token, 但输入仍直接包含该 token, 则模型可通过 identity shortcut 得到答案。

MLM 必须先破坏输入: $x_i \rightarrow \tilde{x}_i$ 才能形成非平凡自监督任务。

61.3.3 MLM Logit Gradient

对 mask 位置 i , 预测分布: $p_{i,v} = p_{\theta}(x_i = v | \tilde{\mathbf{x}})$ 。

则:

$$\frac{\partial \ell_i}{\partial z_{i,v}} = p_{i,v} - \mathbf{1}\{v = x_i\}. \quad (61.3)$$

只有: $i \in \mathcal{M}$ 的位置直接进入 MLM loss, 但所有非 mask token 都可通过 attention 间接影响 mask 位置 hidden state。

61.4 Next Sentence Prediction

构造句子对: (A, B) 。

label: $r = \begin{cases} 1, & B \text{ 是 } A \text{ 的真实相邻句,} \\ 0, & B \text{ 是随机或非相邻句.} \end{cases}$

输入形式: [CLS] A [SEP] B [SEP]。

使用最终层: $\mathbf{h}_{\text{CLS}} \in \mathbb{R}^d$ 。

分类:

$$p_{\theta}(r | A, B) = \text{softmax}(\mathbf{W}_{\text{NSP}}^{\top} \mathbf{h}_{\text{CLS}} + \mathbf{b}_{\text{NSP}}). \quad (61.4)$$



总目标可写成：

$$\mathcal{L} = \mathcal{L}_{\text{MLM}} + \lambda_{\text{NSP}} \mathcal{L}_{\text{NSP}}. \quad (61.5)$$

说明 61.1. NSP 并不是所有 BERT-family 模型的必要组成。

例如一些后续模型移除 NSP，改用更大数据、动态 masking 或其他 sentence-level objective。

61.5 Contextual Embedding

对输入： $x_{1:L}$ ，第 ℓ 层第 i 个位置的表示： $\mathbf{h}_i^{(\ell)} = f_{\theta}^{(\ell)}(x_{1:L}, i)$ 。

同一个 word type w 在两个不同 context： c_1, c_2 中可得到： $\mathbf{h}(w; c_1) \neq \mathbf{h}(w; c_2)$ 。

例如： $\mathbf{h}(\text{bank}; \text{financial context}) \neq \mathbf{h}(\text{bank}; \text{river context})$ 。

这与 static embedding： $\mathbf{e}_{\text{bank}}$ 只有一个固定向量形成区别。

61.5.1 Layer Aggregation

可使用最后一层： $\mathbf{z}_i = \mathbf{h}_i^{(L_{\text{layer}})}$ ，也可平均最后 m 层：

$$\mathbf{z}_i = \frac{1}{m} \sum_{\ell=L_{\text{layer}}-m+1}^{L_{\text{layer}}} \mathbf{h}_i^{(\ell)}. \quad (61.6)$$

不同层通常编码不同信息：

- 较低层偏局部词形和句法；
- 中间层常有较强语法与语义结构；
- 顶层更贴近预训练 objective。

此结论是经验性趋势，不是严格层级定理。

61.6 下游 Fine-Tuning

61.6.1 Sequence Classification

输入： $[\text{CLS}], x_1, \dots, x_L$ 。

分类 head：

$$p_{\omega}(y \mid \mathbf{x}) = \text{softmax}(\mathbf{W}_c \mathbf{h}_{\text{CLS}} + \mathbf{b}_c). \quad (61.7)$$

loss： $\mathcal{L}_{\text{cls}} = -\log p_{\omega}(y^* \mid \mathbf{x})$ 。

61.6.2 Token Classification

对每个位置：

$$p(y_i \mid \mathbf{x}) = \text{softmax}(\mathbf{W}_t \mathbf{h}_i + \mathbf{b}_t). \quad (61.8)$$

适用于：

- POS tagging；



- NER;
- slot filling;
- span boundary prediction。

61.6.3 Full Fine-Tuning

更新: θ 和 ω 。

目标:

$$\min_{\theta, \omega} \frac{1}{N} \sum_{i=1}^N \ell(g_{\omega}(f_{\theta}(x_i)), y_i). \quad (61.9)$$

61.6.4 Feature Extraction

冻结 pretrained parameters: $\theta = \theta_0$, 只训练 task head:

$$\min_{\omega} \frac{1}{N} \sum_i \ell(g_{\omega}(f_{\theta_0}(x_i)), y_i). \quad (61.10)$$

优点是成本低; 缺点是表示不能针对任务调整。

61.7 Instruction Tuning / SFT

训练数据: $\mathcal{D}_{\text{SFT}} = \{(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})\}_{i=1}^N$, 其中:

- $\mathbf{x}$: instruction、system prompt 和 optional input;
- $\mathbf{y}$: desired response。

response-only SFT loss:

$$\mathcal{L}_{\text{SFT}}(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{t=1}^{T_i} \log \pi_{\theta} \left(y_t^{(i)} \mid \mathbf{x}^{(i)}, y_{<t}^{(i)} \right). \quad (61.11)$$

61.7.1 Prompt Mask

将 prompt 与 response 拼接: $\mathbf{s} = [\mathbf{x}; \mathbf{y}]$ 。

定义 loss mask: $m_t = \begin{cases} 0, & t \text{ 属于 prompt,} \\ 1, & t \text{ 属于 response.} \end{cases}$

则:


$$\mathcal{L}_{\text{SFT}} = -\frac{\sum_t m_t \log p_{\theta}(s_t \mid s_{<t})}{\sum_t m_t}. \quad (61.12)$$

只在 response token 上计算 loss, 避免模型被主要训练成复制 prompt。

61.7.2 SFT 的本质

SFT 仍然是: teacher-forced next-token maximum likelihood。

它与 pretraining 的主要区别不是损失形式, 而是数据分布: 普通文本 $\rightarrow$ instruction-response pairs。



61.8 Parameter-Efficient Fine-Tuning 与 LoRA

设冻结的线性层: $W_0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ 。

LoRA 令:

$$\Delta W = \frac{\alpha}{r} B A, \quad (61.13)$$

其中: $A \in \mathbb{R}^{r \times d_{\text{in}}}$, $B \in \mathbb{R}^{d_{\text{out}} \times r}$, $r \ll \min\{d_{\text{in}}, d_{\text{out}}\}$ 。

forward:

$$y = W_0 x + \frac{\alpha}{r} B A x. \quad (61.14)$$

训练参数量:

$$P_{\text{LoRA}} = r(d_{\text{in}} + d_{\text{out}}), \quad (61.15)$$

而 full matrix 参数量为: $P_{\text{full}} = d_{\text{in}} d_{\text{out}}$ 。

参数比例:

$$\frac{P_{\text{LoRA}}}{P_{\text{full}}} = r \left(\frac{1}{d_{\text{in}}} + \frac{1}{d_{\text{out}}} \right). \quad (61.16)$$

易错点、反例与失败模式

LoRA 不是对 W_0 做离线 SVD。

训练中: W_0 被冻结, 而: A, B 通过任务 loss 直接学习。

61.9 Prompting 与 In-Context Learning

给定 demonstrations: $\mathcal{E} = \{(x^{(1)}, y^{(1)}), \dots, (x^{(K)}, y^{(K)})\}$, 以及 query x^* 。

构造 context:

$$c = \text{Format}(x^{(1)}, y^{(1)}, \dots, x^{(K)}, y^{(K)}, x^*). \quad (61.17)$$

模型生成: $y^* \sim \pi_{\theta}(\cdot | c)$ 。

在推理期间: θ 不发生 gradient update。

因此: in-context learning $\neq$ fine-tuning。

表 61.2: Prompting、ICL 与 Fine-Tuning

比较项	Prompting / ICL	Fine-Tuning / SFT
是否更新参数	否	是
任务信息位置	输入 context	模型参数
成本	无训练成本, 但增加 prompt token 和 inference cost	需要训练 compute 和 optimizer state
适应速度	即时	需训练过程
持久性	prompt 结束后不保留	能力写入参数
主要风险	prompt sensitivity、context ordering、demonstration bias	catastrophic forgetting、过拟合、训练成本

61.10 当前 LLM 路线取得成功的关键因素

答题方法

[25S-D-Q4, 3 分] 可按以下层次作答：

1. 统一的自监督目标。

大规模文本自动提供 next-token labels: $-\sum_t \log p_{\theta}(w_t | w_{<t})$.

无需为每个知识点单独人工标注。

2. Transformer 架构。

Self-attention 提供长距离 token interaction; 矩阵计算适合 GPU/TPU 并行训练。

3. 模型、数据和计算规模。

增加参数 P 、数据 token D 和 compute C 通常能按照经验 power law 降低 loss。

4. 高质量和多样化数据。

Web、书籍、代码、学术文本、对话和多语言数据提供广泛知识和任务模式。

5. Pretrain-adapt 范式。

一个 base model 可通过: fine-tuning, SFT, prompting, ICL 适配大量任务。

6. Instruction tuning 与 preference alignment。

SFT 改善指令遵循; RLHF/DPO 使模型更接近人类对 helpfulness 和 safety 的偏好。

7. 上下文学习和统一接口。

大量任务被统一为: 输入文本 $\rightarrow$ 条件生成文本。

8. 工程系统。

分布式训练、混合精度、数据并行、张量并行、pipeline parallelism、KV cache 和 PEFT 使训练与部署成为可能。

同时必须指出: 规模扩大 $\nrightarrow$ 事实正确、安全或真正通用智能的严格保证。

61.11 经验 Scaling Law

设:

- P : non-embedding parameter count;
- D : 训练 token 数;
- C : 训练 compute;
- L : test loss。



常见经验形式:

$$L(P) = L_{\infty} + A_P P^{-\alpha_P}, \quad (61.18)$$

$$L(D) = L_{\infty} + A_D D^{-\alpha_D}, \quad (61.19)$$

$$L(C) = L_{\infty} + A_C C^{-\alpha_C}. \quad (61.20)$$

其中: $A_P, A_D, A_C > 0, \alpha_P, \alpha_D, \alpha_C > 0$ 。

在 log-log 坐标中:

$$\log(L(P) - L_{\infty}) = \log A_P - \alpha_P \log P. \quad (61.21)$$

斜率为: $-\alpha_P$ 。

易错点、反例与失败模式

Power law 是特定训练区间和实验协议下的经验规律, 不是对所有:

- 架构;
- 数据分布;
- tokenizer;
- optimizer;
- downstream task

均严格成立的普适定理。

61.12 双变量参数-数据缩放

题目给定:

$$L_{\text{arch}}(P, D) = L_{\infty} + A_{\text{arch}} P^{-\alpha_{\text{arch}}} + B_{\text{arch}} D^{-\beta_{\text{arch}}}. \quad (61.22)$$

其中: $\alpha_{\text{arch}}, \beta_{\text{arch}} > 0$ 。

61.12.1 固定数据

固定: $D = D_0$ 。

定义: $\Delta_P(P) = L(P, D_0) - L_{\infty} = AP^{-\alpha} + BD_0^{-\beta}$ 。

log-log 局部斜率:

$$\frac{d \log \Delta_P}{d \log P} = -\alpha \frac{AP^{-\alpha}}{AP^{-\alpha} + BD_0^{-\beta}}. \quad (61.23)$$

因此:

- parameter-limited 区域: $AP^{-\alpha} \gg BD_0^{-\beta}$, 斜率近似 $-\alpha$;
- data-limited 区域: $AP^{-\alpha} \ll BD_0^{-\beta}$, 斜率趋近 0。

cross-over parameter scale:

$$P_{\text{cross}} = \left(\frac{A}{B}\right)^{1/\alpha} D_0^{\beta/\alpha}. \quad (61.24)$$



61.12.2 固定参数

固定: $P = P_0$ 。

$$\Delta_D(D) = AP_0^{-\alpha} + BD^{-\beta}。$$

局部斜率:

$$\frac{d \log \Delta_D}{d \log D} = -\beta \frac{BD^{-\beta}}{AP_0^{-\alpha} + BD^{-\beta}}. \quad (61.25)$$

在 data-limited 区域斜率近似: $-\beta$, 在 model-limited 区域趋近: 0。

61.13 从统计学习理论解释 Data Scaling

61.13.1 Population Risk 与 Empirical Risk

设: $Z \sim \mathcal{D}$, loss: $\ell(f, Z) \in [0, 1]$ 。

population risk:

$$R(f) = \mathbb{E}_{Z \sim \mathcal{D}}[\ell(f, Z)]. \quad (61.26)$$

empirical risk:

$$\hat{R}_n(f) = \frac{1}{n} \sum_{i=1}^n \ell(f, Z_i). \quad (61.27)$$

设模型类为: $\mathcal{F}$ 。

类内 population minimizer: $f_{\mathcal{F}}^* = \arg \min_{f \in \mathcal{F}} R(f)$ 。

学习算法输出: $\hat{f}_n$ 。

61.13.2 Risk Decomposition


对任意全局目标 f^* :

$$\begin{aligned} R(\hat{f}_n) - R(f^*) &= \underbrace{R(\hat{f}_n) - \hat{R}_n(\hat{f}_n)}_{\text{generalization gap of learned model}} \\ &+ \underbrace{\hat{R}_n(\hat{f}_n) - \hat{R}_n(f_{\mathcal{F}}^*)}_{\text{optimization/ERM gap}} \\ &+ \underbrace{\hat{R}_n(f_{\mathcal{F}}^*) - R(f_{\mathcal{F}}^*)}_{\text{generalization gap of comparator}} \\ &+ \underbrace{R(f_{\mathcal{F}}^*) - R(f^*)}_{\text{approximation error}}. \end{aligned} \quad (61.28)$$

若优化误差为: ε_{opt} , 则:

$$R(\hat{f}_n) - R(f^*) \leq 2 \sup_{f \in \mathcal{F}} |R(f) - \hat{R}_n(f)| + \varepsilon_{\text{opt}} + \varepsilon_{\text{app}}. \quad (61.29)$$

其中: $\varepsilon_{\text{app}} = R(f_{\mathcal{F}}^*) - R(f^*)$ 。



61.13.3 Rademacher Complexity Bound

经验 Rademacher complexity:

$$\hat{\mathfrak{R}}_n(\mathcal{G}) = \mathbb{E}_{\sigma} \left[\sup_{g \in \mathcal{G}} \frac{1}{n} \sum_{i=1}^n \sigma_i g(Z_i) \right], \quad (61.30)$$

其中: $\sigma_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}\{-1, +1\}$ 。

对有界 loss class $\ell \circ \mathcal{F}$, 以至少 $1 - \delta$ 的概率:

$$\sup_{f \in \mathcal{F}} |R(f) - \hat{R}_n(f)| \leq 2\hat{\mathfrak{R}}_n(\ell \circ \mathcal{F}) + 3\sqrt{\frac{\log(2/\delta)}{2n}}. \quad (61.31)$$

因此:

$$R(\hat{f}_n) - R(f^*) \lesssim 4\hat{\mathfrak{R}}_n(\ell \circ \mathcal{F}) + O\left(\sqrt{\frac{\log(1/\delta)}{n}}\right) + \varepsilon_{\text{opt}} + \varepsilon_{\text{app}}. \quad (61.32)$$

这一路径:

- 不要求数据 Gaussian;
- 主要使用 i.i.d. 或弱相关采样、有界性和函数类复杂度;
- 说明更多数据降低 estimation error;
- 同时保留 approximation 和 optimization floor。

61.13.4 为什么出现 Power-Law-Like 行为

若: $\mathfrak{R}_n(\ell \circ \mathcal{F}) \asymp Cn^{-1/2}$, 则: $R(\hat{f}_n) - R(f^*) = O(n^{-1/2})$ 。

在更强条件下, 例如:

- strong convexity;
- exp-concavity;
- margin condition;
- low-noise condition;

可出现: $O(n^{-1})$ 或其他 fast rate。

在 s -smooth 的 d -dimensional nonparametric problem 中, 典型 minimax rate 可写为:

$$R(\hat{f}_n) - R(f^*) \asymp n^{-\frac{2s}{2s+d}}. \quad (61.33)$$

因此, 不同问题可产生不同: β 。

经验 scaling law 中的 exponent 不是由 Gaussian 假设唯一决定, 而是由:

- function regularity;
- effective dimension;
- noise;
- optimization;



- model misspecification;
- data dependence;
- architecture bias

共同决定。

答题方法

[25S-D-Q6, 5 分] 建议结构:

1. 定义 population risk 与 empirical risk;
2. 做 approximation-estimation-optimization decomposition;
3. 用 uniform convergence 或 Rademacher complexity 给出 estimation term 随 n 减小;
4. 说明不同 regularity 和 effective dimension 导致不同 power exponent;
5. 说明 finite irreducible/approximation floor;
6. 明确 power law 是经验区间规律, 不是只依赖 Gaussian 分布的结论。

61.14 Compute-Optimal Joint Scaling

考虑:

$$\Delta L(P, D) = AP^{-\alpha} + BD^{-\beta}. \quad (61.34)$$

假设训练 compute 近似满足:

$$C = \kappa PD, \quad (61.35)$$

其中 $\kappa > 0$ 吸收每 token 每 parameter 的常数。

由: $D = \frac{C}{\kappa P}$, 得到:

$$\Delta L(P) = AP^{-\alpha} + B\kappa^\beta P^\beta C^{-\beta}. \quad (61.36)$$

求导:

$$-\alpha AP^{-\alpha-1} + \beta B\kappa^\beta P^{\beta-1} C^{-\beta} = 0. \quad (61.37)$$

因此:

$$P^* = \left[\frac{\alpha A}{\beta B \kappa^\beta} \right]^{\frac{1}{\alpha+\beta}} C^{\frac{\beta}{\alpha+\beta}}. \quad (61.38)$$


对应:

$$D^* = \kappa^{-1} \left[\frac{\beta B \kappa^\beta}{\alpha A} \right]^{\frac{1}{\alpha+\beta}} C^{\frac{\alpha}{\alpha+\beta}}. \quad (61.39)$$

最优 excess loss 的 compute exponent 为:

$$\Delta L^*(C) = \Theta \left(C^{-\frac{\alpha\beta}{\alpha+\beta}} \right). \quad (61.40)$$

这说明在固定 compute 下, 只扩大模型而不增加数据, 或只增加数据而模型过小, 一般都不是最优资源分配。



61.15 LSTM 与 Transformer 的 Scaling 比较

给定: $L_{\text{arch}}(P, D) = L_{\infty} + A_{\text{arch}}P^{-\alpha_{\text{arch}}} + B_{\text{arch}}D^{-\beta_{\text{arch}}}$ 。

在“Transformer 经验上扩展更有效”的前提下, 可能观察到: $A_{\text{Tr}} < A_{\text{LSTM}}$, 和/或: $\alpha_{\text{Tr}} > \alpha_{\text{LSTM}}$, 以及: $B_{\text{Tr}} < B_{\text{LSTM}}$, 和/或: $\beta_{\text{Tr}} > \beta_{\text{LSTM}}$ 。

于是 Transformer 曲线可能:

- 位于更低位置;
- 在 power-law 主导区域更陡;
- 在同一参数或数据预算下 loss 更低。

其架构解释包括:

1. 长依赖路径。

Self-attention 可在一层内直接连接远距离 token, 而 recurrent path 长度为 $O(L)$ 。

2. 并行和 throughput。

Transformer 的训练矩阵运算可并行; RNN/LSTM 的 hidden state 在时间维串行。

3. 优化动力学。

更短的信息路径、residual stream 和 LayerNorm 往往更适合深层大规模优化。

4. Inductive bias。

LSTM 的 recurrence 是较强 sequential/local bias, 小数据时可能具有 sample-efficiency 优势; Transformer 偏置更弱, 往往需要更多数据, 但在大规模数据下更灵活。


易错点、反例与失败模式

不能把: $\alpha_{\text{Tr}} > \alpha_{\text{LSTM}}$ 写成无条件数学定理。

这些常数受:

- tokenizer;
- training tokens;
- context length;
- optimizer;
- compute;
- regularization;
- parameter counting method

影响。



第六十二章 Reward Model、RLHF、PPO 与 DPO

62.1 对齐问题

仅做 next-token pretraining 的目标是： $\max_{\theta} \mathbb{E}_{s \sim \mathcal{C}} [\log p_{\theta}(s)]$ 。

它鼓励模型生成训练分布中可预测的文本，但不直接编码：

- helpfulness;
- harmlessness;
- honesty;
- instruction following;
- factuality;
- 用户个体偏好。

因此需要 post-training:

$$\text{pretraining} \longrightarrow \text{SFT} \longrightarrow \text{preference alignment.} \quad (62.1)$$

62.2 Preference Data

基本数据形式：

$$\mathcal{D}_{\text{pref}} = \{(x_i, y_i^+, y_i^-)\}_{i=1}^N, \quad (62.2)$$

其中： $y_i^+ \succ y_i^-$ 。

含义是在人类标注者看来，对同一个 prompt x_i ， y_i^+ 优于 y_i^- 。

候选 response 可来自：

- SFT policy sampling;
- 不同 decoding temperatures;
- 不同 checkpoint;
- 不同模型;
- 人工 response 与模型 response。



62.3 Reward Model

Reward model:

$$r_\psi(\mathbf{x}, \mathbf{y}) \in \mathbb{R}. \quad (62.3)$$

常用结构是在 sequence final hidden state 或 pooled representation 上添加 scalar head:

$$r_\psi(\mathbf{x}, \mathbf{y}) = \mathbf{w}_r^\top \mathbf{h}_{\text{pool}}(\mathbf{x}, \mathbf{y}) + b_r. \quad (62.4)$$

62.4 Bradley–Terry Preference Model

设: $\Delta r_\psi = r_\psi(\mathbf{x}, \mathbf{y}^+) - r_\psi(\mathbf{x}, \mathbf{y}^-)$ 。

pairwise preference probability:

$$P_\psi(\mathbf{y}^+ \succ \mathbf{y}^- \mid \mathbf{x}) = \sigma(\Delta r_\psi) = \frac{1}{1 + \exp(-\Delta r_\psi)}. \quad (62.5)$$

negative log-likelihood:

$$\mathcal{L}_{\text{RM}}(\psi) = -\mathbb{E}_{(\mathbf{x}, \mathbf{y}^+, \mathbf{y}^-)} \log \sigma [r_\psi(\mathbf{x}, \mathbf{y}^+) - r_\psi(\mathbf{x}, \mathbf{y}^-)]. \quad (62.6)$$

62.4.1 Reward Gradient

令: $u = r^+ - r^-$ 。

单 pair loss: $\ell = -\log \sigma(u)$ 。

有:

$$\frac{d\ell}{du} = \sigma(u) - 1 = -\sigma(-u). \quad (62.7)$$

因此:

$$\frac{\partial \ell}{\partial r^+} = -\sigma(-u), \quad (62.8)$$

$$\frac{\partial \ell}{\partial r^-} = \sigma(-u). \quad (62.9)$$

梯度下降会: $r^+ \uparrow$, $r^- \downarrow$ 。

参数梯度:


$$\nabla_\psi \ell = -\sigma(-u) [\nabla_\psi r_\psi(\mathbf{x}, \mathbf{y}^+) - \nabla_\psi r_\psi(\mathbf{x}, \mathbf{y}^-)]. \quad (62.10)$$

62.4.2 Reward 的不可辨识性

对任意 prompt-dependent constant $c(\mathbf{x})$, 令: $r'_\psi(\mathbf{x}, \mathbf{y}) = r_\psi(\mathbf{x}, \mathbf{y}) + c(\mathbf{x})$ 。

则: $r'_\psi(\mathbf{x}, \mathbf{y}^+) - r'_\psi(\mathbf{x}, \mathbf{y}^-) = r_\psi(\mathbf{x}, \mathbf{y}^+) - r_\psi(\mathbf{x}, \mathbf{y}^-)$ 。

因此 pairwise preference 只能识别 reward difference, 不能识别每个 prompt 上的绝对 reward offset。



62.5 KL-Regularized RLHF Objective

设:

- prompt distribution: $\mathbf{x} \sim \mathcal{D}_x$;
- trainable policy: $\pi_\theta(\mathbf{y} | \mathbf{x})$;
- reference policy: $\pi_{\text{ref}}(\mathbf{y} | \mathbf{x})$;
- fixed reward model: $r_\psi(\mathbf{x}, \mathbf{y})$.

RLHF objective:

$$J_{\text{RLHF}}(\theta) = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_x} [\mathbb{E}_{\mathbf{y} \sim \pi_\theta(\cdot | \mathbf{x})} [r_\psi(\mathbf{x}, \mathbf{y}) - \beta D_{\text{KL}}(\pi_\theta(\cdot | \mathbf{x}) \| \pi_{\text{ref}}(\cdot | \mathbf{x}))]], \quad (62.11)$$

其中: $\beta > 0$.

KL:

$$D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) = \mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\log \frac{\pi_\theta(\mathbf{y} | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y} | \mathbf{x})} \right]. \quad (62.12)$$

等价写成:

$$J_{\text{RLHF}} = \mathbb{E}_{\mathbf{x}, \mathbf{y} \sim \pi_\theta} \left[r_\psi(\mathbf{x}, \mathbf{y}) - \beta \log \frac{\pi_\theta(\mathbf{y} | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y} | \mathbf{x})} \right]. \quad (62.13)$$

62.5.1 KL Regularization 的作用

β 控制 preference optimization 与 reference preservation 的折中。

- β 大: policy 更接近 reference, 更保守;
- β 小: 更积极优化 reward, 但更容易 policy drift、reward hacking 和语言退化。

62.6 Sequence-Level Policy Gradient

对固定 prompt $\mathbf{x}$, 定义: $\pi_\theta(\mathbf{y}) = \pi_\theta(\mathbf{y} | \mathbf{x})$ 。

首先:

$$\nabla_\theta \mathbb{E}_{\mathbf{y} \sim \pi_\theta} [r(\mathbf{y})] = \mathbb{E}_{\mathbf{y} \sim \pi_\theta} [r(\mathbf{y}) \nabla_\theta \log \pi_\theta(\mathbf{y})]. \quad (62.14)$$

对于 KL:

$$\begin{aligned} \nabla_\theta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) &= \nabla_\theta \mathbb{E}_{\mathbf{y} \sim \pi_\theta} [\log \pi_\theta(\mathbf{y}) - \log \pi_{\text{ref}}(\mathbf{y})] \\ &= \mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\left(\log \frac{\pi_\theta(\mathbf{y})}{\pi_{\text{ref}}(\mathbf{y})} + 1 \right) \nabla_\theta \log \pi_\theta(\mathbf{y}) \right]. \end{aligned} \quad (62.15)$$

因为 score-function identity:


$$\mathbb{E}_{\mathbf{y} \sim \pi_\theta} [\nabla_\theta \log \pi_\theta(\mathbf{y})] = 0, \quad (62.16)$$

所以 +1 项消失:

$$\nabla_\theta D_{\text{KL}} = \mathbb{E}_{\mathbf{y} \sim \pi_\theta} \left[\log \frac{\pi_\theta(\mathbf{y})}{\pi_{\text{ref}}(\mathbf{y})} \nabla_\theta \log \pi_\theta(\mathbf{y}) \right]. \quad (62.17)$$

因此:

$$\nabla_\theta J_{\text{RLHF}} = \mathbb{E}_{\mathbf{x}, \mathbf{y} \sim \pi_\theta} \left[\left(r_\psi(\mathbf{x}, \mathbf{y}) - \beta \log \frac{\pi_\theta(\mathbf{y} | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y} | \mathbf{x})} \right) \nabla_\theta \log \pi_\theta(\mathbf{y} | \mathbf{x}) \right]. \quad (62.18)$$



62.6.1 Baseline

对任意只依赖 prompt 的 baseline $b(\mathbf{x})$:

$$\mathbb{E}_{\mathbf{y} \sim \pi_\theta} [b(\mathbf{x}) \nabla_\theta \log \pi_\theta(\mathbf{y} | \mathbf{x})] = 0. \quad (62.19)$$

因此可写:

$$\nabla_\theta J = \mathbb{E}[(\tilde{r} - b(\mathbf{x})) \nabla_\theta \log \pi_\theta(\mathbf{y} | \mathbf{x})], \quad (62.20)$$

其中: $\tilde{r} = r_\psi - \beta \log \frac{\pi_\theta}{\pi_{\text{ref}}}$ 。

baseline 不改变期望梯度, 但可降低 variance。

62.7 Token-Level Factorization

sequence log-probability:

$$\log \pi_\theta(\mathbf{y} | \mathbf{x}) = \sum_{t=1}^T \log \pi_\theta(y_t | s_t). \quad (62.21)$$

因此:

$$\nabla_\theta \log \pi_\theta(\mathbf{y} | \mathbf{x}) = \sum_{t=1}^T \nabla_\theta \log \pi_\theta(y_t | s_t). \quad (62.22)$$

若 reward model 只在 sequence 结束时给一个 scalar reward, 同一个 terminal reward 会作用于所有 token actions, 产生 credit-assignment 和 high-variance 问题。

常见 per-token KL reward:

$$r_t^{\text{KL}} = -\beta [\log \pi_\theta(y_t | s_t) - \log \pi_{\text{ref}}(y_t | s_t)]. \quad (62.23)$$

terminal reward: $r_T^{\text{RM}} = r_\psi(\mathbf{x}, \mathbf{y})$ 。

总 return: $G_t = \sum_{j=t}^T \gamma^{j-t} r_j$ 。

语言生成中通常: $\gamma \approx 1$, 因为 sequence 相对较短且 terminal preference 应传回全部 token。

62.8 Actor-Critic

Actor: $\pi_\theta(a_t | s_t)$ 。

Critic: $V_\omega(s_t) \approx \mathbb{E}[G_t | s_t]$ 。

TD residual:


$$\delta_t = r_t + \gamma V_\omega(s_{t+1}) - V_\omega(s_t). \quad (62.24)$$

critic loss:

$$\mathcal{L}_V(\omega) = \frac{1}{2} \mathbb{E}_t [V_\omega(s_t) - \hat{G}_t]^2. \quad (62.25)$$

actor gradient:

$$\nabla_\theta J \approx \mathbb{E}_t [\hat{A}_t \nabla_\theta \log \pi_\theta(a_t | s_t)]. \quad (62.26)$$



62.9 Generalized Advantage Estimation

定义： $\lambda \in [0, 1]$ 。

GAE:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{\ell=0}^{T-t} (\gamma \lambda)^\ell \delta_{t+\ell}. \quad (62.27)$$

- λ 小: bias 较大、variance 较小;
- λ 大: bias 较小、variance 较大。

62.10 PPO Ratio

收集 rollout 时的旧 policy: $\pi_{\theta_{\text{old}}}$ 。

importance ratio:

$$\rho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}. \quad (62.28)$$

unclipped surrogate: $\rho_t(\theta) \hat{A}_t$ 。

clipped surrogate:

$$L^{\text{clip}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right]. \quad (62.29)$$

训练通常最大化: L^{clip} , 或最小化: $-L^{\text{clip}}$ 。

62.10.1 Clipping 的分段含义

若: $\hat{A}_t > 0$, 动作比平均更好, 希望提高其概率。

但当: $\rho_t > 1 + \varepsilon$, 目标被截平, 不再奖励继续大幅提高概率。

若: $\hat{A}_t < 0$, 动作较差, 希望降低其概率。

但当: $\rho_t < 1 - \varepsilon$, 目标被截平, 不再奖励继续大幅降低概率。

因为:

$$\nabla_{\theta} \rho_t = \rho_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t), \quad (62.30)$$

被截平区域的 surrogate gradient 为零。

62.10.2 常见 PPO 总目标

$$\mathcal{J}_{\text{PPO}} = L^{\text{clip}} - c_V \mathcal{L}_V + c_H \mathbb{E}_t [\mathcal{H}(\pi_{\theta}(\cdot | s_t))], \quad (62.31)$$

并另外通过 reward shaping 或 objective 加入 reference KL。



62.11 Reward-Model-Based RLHF 流程

答题方法

[25S-D-Q7, 5 分] 标准回答:

1. 从 prompt 数据集采样: $\mathbf{x} \sim \mathcal{D}_x$.
 2. 用当前 policy 生成: $\mathbf{y} \sim \pi_\theta(\cdot | \mathbf{x})$.
 3. Reward model 计算: $r_\psi(\mathbf{x}, \mathbf{y})$.
 4. Reference model 计算 sequence/token KL: $\log \pi_\theta - \log \pi_{\text{ref}}$.
 5. 构造 KL-regularized reward: $\tilde{r} = r_\psi - \beta \log \frac{\pi_\theta}{\pi_{\text{ref}}}$.
 6. Critic 估计 value 和 advantage.
 7. 用 PPO 或 policy gradient 更新 policy: $\nabla_\theta J = \mathbb{E}[\hat{A} \nabla_\theta \log \pi_\theta]$.
 8. 同时更新 critic, 并监控: $D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})$, *reward* *responlength* *safetymetrics*.
- 必须写出: 数据 + 目标函数 + 梯度 + KL regularization.

62.12 RLHF 的主要失败模式

1. Reward hacking。

Policy 找到 reward model 的漏洞, 高分不等于真实人类偏好。

2. Reward model distribution shift。

RM 在旧 policy candidates 上训练, 但新 policy 可能生成训练分布外 response。

3. Length bias。

若长 response 更容易得到高分, policy 可能无意义地增加长度。

4. Annotator bias。

Pairwise labels 反映特定标注群体和 guideline。

5. Mode collapse。

过强 reward optimization 可能降低 response diversity。

6. KL 设置错误。

β 太大则几乎不学习; 太小则严重偏离 reference。

7. Credit assignment。

一个 terminal scalar reward 很难判断具体哪个 token 决策好或坏。

8. On-policy cost。

需要持续 rollout、RM inference、critic 和 policy update, 训练昂贵且复杂。



62.13 DPO 的基本推导

考虑固定 prompt $\mathbf{x}$ 下的 KL-regularized optimization:

$$\max_{\pi} \{ \mathbb{E}_{\mathbf{y} \sim \pi} [r(\mathbf{x}, \mathbf{y})] - \beta D_{\text{KL}}(\pi(\cdot | \mathbf{x}) \| \pi_{\text{ref}}(\cdot | \mathbf{x})) \}. \quad (62.32)$$

加归一化约束: $\sum_{\mathbf{y}} \pi(\mathbf{y} | \mathbf{x}) = 1$ 。

对 $\pi(\mathbf{y} | \mathbf{x})$ 求驻点, 得到:

$$\pi^*(\mathbf{y} | \mathbf{x}) = \frac{\pi_{\text{ref}}(\mathbf{y} | \mathbf{x}) \exp(r(\mathbf{x}, \mathbf{y})/\beta)}{Z(\mathbf{x})}, \quad (62.33)$$

其中:

$$Z(\mathbf{x}) = \sum_{\mathbf{y}} \pi_{\text{ref}}(\mathbf{y} | \mathbf{x}) \exp(r(\mathbf{x}, \mathbf{y})/\beta). \quad (62.34)$$

取 logarithm:

$$r(\mathbf{x}, \mathbf{y}) = \beta \log \frac{\pi^*(\mathbf{y} | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y} | \mathbf{x})} + \beta \log Z(\mathbf{x}). \quad (62.35)$$

对同一 prompt 的两个 response 作差, prompt-dependent partition function 消失:

$$\begin{aligned} r(\mathbf{x}, \mathbf{y}^+) - r(\mathbf{x}, \mathbf{y}^-) &= \beta \left[\log \frac{\pi^*(\mathbf{y}^+ | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}^+ | \mathbf{x})} \right. \\ &\quad \left. - \log \frac{\pi^*(\mathbf{y}^- | \mathbf{x})}{\pi_{\text{ref}}(\mathbf{y}^- | \mathbf{x})} \right]. \end{aligned} \quad (62.36)$$

62.14 DPO Loss

用 trainable policy π_{θ} 近似 π^* 。

定义:

$$\begin{aligned} g_{\theta}(\mathbf{x}, \mathbf{y}^+, \mathbf{y}^-) &= \beta \left[\log \pi_{\theta}(\mathbf{y}^+ | \mathbf{x}) - \log \pi_{\text{ref}}(\mathbf{y}^+ | \mathbf{x}) \right. \\ &\quad \left. - \log \pi_{\theta}(\mathbf{y}^- | \mathbf{x}) + \log \pi_{\text{ref}}(\mathbf{y}^- | \mathbf{x}) \right]. \end{aligned} \quad (62.37)$$

DPO loss:


$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(\mathbf{x}, \mathbf{y}^+, \mathbf{y}^-) \sim \mathcal{D}_{\text{pref}}} \log \sigma(g_{\theta}(\mathbf{x}, \mathbf{y}^+, \mathbf{y}^-)). \quad (62.38)$$

62.14.1 DPO Gradient

因为: $\frac{d}{dg} [-\log \sigma(g)] = -\sigma(-g)$, 且 reference policy 固定, 所以:

$$\nabla_{\theta} \mathcal{L}_{\text{DPO}} = -\beta \mathbb{E} [\sigma(-g_{\theta}) (\nabla_{\theta} \log \pi_{\theta}(\mathbf{y}^+ | \mathbf{x}) - \nabla_{\theta} \log \pi_{\theta}(\mathbf{y}^- | \mathbf{x}))]. \quad (62.39)$$

梯度下降提高: $\log \pi_{\theta}(\mathbf{y}^+ | \mathbf{x}) - \log \pi_{\theta}(\mathbf{y}^- | \mathbf{x})$, 但提高的是相对 reference 的 log-ratio margin。



62.14.2 Sequence Log-Probability

$$\log \pi_{\theta}(\mathbf{y}^{\pm} | \mathbf{x}) = \sum_{t=1}^{T^{\pm}} \log \pi_{\theta}(y_t^{\pm} | \mathbf{x}, y_{<t}^{\pm}). \quad (62.40)$$

因此 DPO 可直接用 teacher-forced forward pass 计算 preferred 和 dispreferred sequence likelihood，不需要对生成 sampling 求导。

62.15 DPO 与 RLHF 的区别

表 62.1: Reward-model RLHF 与 DPO

比较项	Reward-model RLHF / PPO	DPO
是否显式训练 RM	是	否
Policy data	通常需要 on-policy rollout	使用离线 preference pairs
是否需要 critic	PPO 通常需要	不需要
主要目标	最大化 RM reward 并加 KL	pairwise logistic objective
训练复杂度	较高；涉及 actor、critic、RM、reference	接近 supervised teacher-forced training
主要优势	可在线探索新 response；可直接利用 scalar reward	简单、稳定、计算成本低
主要局限	reward hacking、on-policy 成本、PPO instability	依赖离线 pair 覆盖；不能主动探索；仍继承 preference bias

62.16 SFT、RM、PPO 与 DPO 的目标区分

易错点、反例与失败模式

1. SFT: $-\log \pi_{\theta}(\mathbf{y}^* | \mathbf{x})$. 学习复制 supervised desired response。
2. Reward model: $-\log \sigma(r^+ - r^-)$. 学习对 response 排序。
3. RLHF: $\max_{\theta} \mathbb{E}_{\pi_{\theta}}[r_{\psi}] - \beta D_{\text{KL}}(\pi_{\theta} \| \pi_{\text{ref}})$. 用 RL 优化 policy。
4. DPO: $-\log \sigma(\beta[\Delta \log \pi_{\theta} - \Delta \log \pi_{\text{ref}}])$. 直接从 preference pair 更新 policy。

这四个 loss 不能混写。

62.17 RLHF/DPO 真题模板

答题方法

[26S-B-Q3(d), 2 分] 若选择 reward-model RLHF:

$$\mathcal{L}_{\text{RM}} = -\mathbb{E} \log \sigma(r_{\psi}(x, y^+) - r_{\psi}(x, y^-)).$$

然后更新 policy: $\max_{\theta} \mathbb{E}_{x, y \sim \pi_{\theta}}[r_{\psi}(x, y)] - \beta \mathbb{E}_x D_{\text{KL}}(\pi_{\theta}(\cdot | x) \| \pi_{\text{ref}}(\cdot | x))$ 。

可说明使用 PPO: $\max_{\theta} \mathbb{E} \min(\rho_t A_t, \text{clip}(\rho_t, 1 - \varepsilon, 1 + \varepsilon) A_t)$ 。

若选择 DPO：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y^+|x)}{\pi_{\text{ref}}(y^+|x)} - \log \frac{\pi_{\theta}(y^-|x)}{\pi_{\text{ref}}(y^-|x)} \right] \right)。$$

并说明： $y^+ \succ y^-$, reference policy 固定，DPO 无需显式 reward model 和 PPO rollout。



第六十三章 长序列 Transformer 与监督主题模型

63.1 标准 Self-Attention 的二次瓶颈

对: $\mathbf{Q}, \mathbf{K}, \mathbf{V} \in \mathbb{R}^{L \times d}$, standard attention:

$$\mathbf{O} = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}} + \mathbf{M} \right) \mathbf{V}. \quad (63.1)$$

score matrix: $\mathbf{Q}\mathbf{K}^\top \in \mathbb{R}^{L \times L}$ 。

时间:

$$O(L^2 d). \quad (63.2)$$

attention matrix memory:

$$O(L^2). \quad (63.3)$$

当: $L \approx 10^4$, 则: $L^2 \approx 10^8$ 。

每层每个 head 都需处理约一亿个 pair, 训练时还需保存 backward 所需信息。

63.2 Attention Graph

定义有向 attention graph: $G_{\text{attn}} = (\{1, \dots, L\}, E)$ 。

若位置 i 可读取位置 j , 则记: $(j \rightarrow i) \in E$ 。

单层输出: $\mathbf{h}_i^{(\ell+1)}$ 可直接依赖: $\{\mathbf{h}_j^{(\ell)} : (j \rightarrow i) \in E\}$ 。

若从 j 到 i 的最短有向路径长度为 r , 则至少需要约 r 层, 信息才能由 j 传播至 i 。

因此长序列机制不仅要分析: $|E|$, 还要分析图的:

- 连通性;
- diameter;
- causal direction;
- 层数下的信息传播距离。

63.3 方案一: Sliding Window + Global Tokens

设 regular positions: $\mathcal{R} = \{1, \dots, L\}$ 。



加入 g 个 global tokens: $\mathcal{G} = \{g_1, \dots, g_g\}$ 。

local window radius: w 。

对 regular query i , 定义:

$$\mathcal{N}(i) = \{j \in \mathcal{R} : |i - j| \leq w\} \cup \mathcal{G}. \quad (63.4)$$

对 global query g_a :

$$\mathcal{N}(g_a) = \mathcal{R} \cup \mathcal{G}. \quad (63.5)$$

mask:

$$M_{ij} = \begin{cases} 0, & j \in \mathcal{N}(i), \\ -\infty, & j \notin \mathcal{N}(i). \end{cases} \quad (63.6)$$

单位置输出:

$$\mathbf{o}_i = \sum_{j \in \mathcal{N}(i)} \frac{\exp(\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d_k})}{\sum_{u \in \mathcal{N}(i)} \exp(\mathbf{q}_i^\top \mathbf{k}_u / \sqrt{d_k})} \mathbf{v}_j. \quad (63.7)$$

63.3.1 复杂度

Regular queries: $O(L(2w + 1 + g)d)$ 。

Global queries: $O(gLd)$ 。

总时间:

$$O(L(w + g)d) \quad (63.8)$$

忽略常数 2。

attention memory:

$$O(L(w + g)). \quad (63.9)$$

当: $w, g \ll L$, 复杂度关于 L 近似线性。

63.3.2 长距离可表达性

在 bidirectional encoder 中:

第一层 global token 可读取任意位置 j ; 第二层任意位置 i 可读取 global token。

因此: $j \rightarrow g_a \rightarrow i$ 形成长度为 2 的路径。

attention graph diameter 至多为: 2 或一个小常数。

63.3.3 Causal 注意事项

在 causal LM 中, global token 不能同时读取未来并把未来信息发送到过去, 否则发生 information leakage。

可用:

- prefix-only global memory;
- 每个 block 的 causal summary token;



- 只允许 global token 汇聚其左侧 prefix;
- segment-level memory。

63.4 方案二：Block-Sparse Attention

将序列划分为： $B = \lceil \frac{L}{b} \rceil$ 个 blocks，每个 block 大小最多 b 。

第 a 个 block： $\mathcal{I}_a = \{(a-1)b+1, \dots, \min(ab, L)\}$ 。

设每个 query block 只读取：

$$\mathcal{B}(a) = \mathcal{B}_{\text{local}}(a) \cup \mathcal{B}_{\text{global}} \cup \mathcal{B}_{\text{random}}(a). \quad (63.10)$$

若每个 block 最多读取 s 个 blocks，则对： $i \in \mathcal{I}_a$ ，定义：

$$\mathcal{N}(i) = \bigcup_{c \in \mathcal{B}(a)} \mathcal{I}_c. \quad (63.11)$$

每个 query 最多读取： sb 个 keys。

总时间：

$$\boxed{O(Lsbd)}. \quad (63.12)$$

memory：

$$O(Lsb). \quad (63.13)$$

若 s, b 为常数，则关于 L 线性。

63.4.1 Connectivity

只有 local neighboring blocks 时，远距离信息需要跨越多个 layers： $O(B)$ 量级路径。

加入：

- global blocks;
- strided blocks;
- random blocks;
- hierarchical blocks

可显著减小 graph diameter。

例如每个 block 都连接一个 global block，则 block-level diameter 近似为 2。

63.5 方案三：Linear Attention

标准 softmax attention kernel： $K(\mathbf{q}, \mathbf{k}) = \exp(\mathbf{q}^\top \mathbf{k})$ 。

若可用 feature map： $\phi: \mathbb{R}^{d_k} \rightarrow \mathbb{R}^r$ 近似或替代：

$$K(\mathbf{q}, \mathbf{k}) \approx \phi(\mathbf{q})^\top \phi(\mathbf{k}), \quad (63.14)$$



并保证: $\phi(\mathbf{q}), \phi(\mathbf{k}) \geq 0$, 则 normalized attention 可写为:

$$\mathbf{o}_i = \frac{\phi(\mathbf{q}_i)^\top \left[\sum_{j=1}^L \phi(\mathbf{k}_j) \mathbf{v}_j^\top \right]}{\phi(\mathbf{q}_i)^\top \left[\sum_{j=1}^L \phi(\mathbf{k}_j) \right]}. \quad (63.15)$$

定义:

$$\mathbf{S} = \sum_{j=1}^L \phi(\mathbf{k}_j) \mathbf{v}_j^\top \in \mathbb{R}^{r \times d_v}, \quad (63.16)$$

$$\mathbf{z} = \sum_{j=1}^L \phi(\mathbf{k}_j) \in \mathbb{R}^r. \quad (63.17)$$

则:

$$\mathbf{o}_i = \frac{\phi(\mathbf{q}_i)^\top \mathbf{S}}{\phi(\mathbf{q}_i)^\top \mathbf{z} + \varepsilon}. \quad (63.18)$$

63.5.1 复杂度

构造 $\mathbf{S}$: $O(Lrd_v)$ 。

构造 $\mathbf{z}$: $O(Lr)$ 。

所有 queries: $O(Lrd_v)$ 。

总时间:

$$O(Lrd_v). \quad (63.19)$$

当: $r, d_v \ll L$, 相对 $O(L^2d)$ 显著降低。

63.5.2 Causal Prefix Recurrence

定义:

$$\mathbf{S}_i = \mathbf{S}_{i-1} + \phi(\mathbf{k}_i) \mathbf{v}_i^\top, \quad (63.20)$$

$$\mathbf{z}_i = \mathbf{z}_{i-1} + \phi(\mathbf{k}_i). \quad (63.21)$$


则 causal output:

$$\mathbf{o}_i = \frac{\phi(\mathbf{q}_i)^\top \mathbf{S}_i}{\phi(\mathbf{q}_i)^\top \mathbf{z}_i + \varepsilon}. \quad (63.22)$$

persistent state 只需: $O(rd_v + r)$ 。

63.5.3 局限

1. 一般不存在低维有限 feature map 能精确表示 softmax exponential kernel; 常为近似或改用不同 kernel。
2. 低秩压缩可能丢失 sharp pairwise attention。
3. 分母可能产生数值稳定问题。
4. 理论线性复杂度不保证实际 wall-clock 一定更快; kernel 和硬件实现同样重要。



63.6 方案四：Recurrent Memory

将长度 L 的序列分为 S 个 segments, 每段长度: b , $S = \lceil \frac{L}{b} \rceil$ 。

第 s 段 hidden states: $\mathbf{H}_s \in \mathbb{R}^{b \times d}$ 。

前一段 memory: $\mathbf{M}_{s-1} \in \mathbb{R}^{m \times d}$ 。

当前段读取:

$$\mathbf{H}_s^{(\ell+1)} = \text{Attn}(\mathbf{Q} = \mathbf{H}_s^{(\ell)} \mathbf{W}_Q, \mathbf{K} = [\mathbf{M}_{s-1}; \mathbf{H}_s^{(\ell)}] \mathbf{W}_K, \mathbf{V} = [\mathbf{M}_{s-1}; \mathbf{H}_s^{(\ell)}] \mathbf{W}_V). \quad (63.23)$$

一种简单 write rule:

$$\mathbf{M}_s = \text{StopGrad}[\text{Tail}_m([\mathbf{M}_{s-1}; \mathbf{H}_s^{(L_{\text{layer}})}])]. \quad (63.24)$$

Tail_m 表示保留最后 m 个 states。

63.6.1 复杂度

每段 attention: $O(b(b+m)d)$ 。

总计:

$$O(L(b+m)d). \quad (63.25)$$

每段 attention memory:

$$O(b(b+m)). \quad (63.26)$$

persistent memory: $O(md)$ 。

63.6.2 长距离传播

信息可通过: $\mathbf{M}_{s-1} \rightarrow \mathbf{H}_s \rightarrow \mathbf{M}_s$ 逐段传递。

若 memory 发生压缩或只保留最近 m 个 state, 远距离信息可能:

- 被覆盖;
- 被截断;
- 无法通过 gradient 跨 segment 学习。

使用: StopGrad 时训练相当于 truncated BPTT, 可节省内存但切断跨段梯度。

63.7 长序列方案比较

表 63.1: 四类长序列 Transformer 机制

机制	时间 / memory	长距离路径	主要局限
Sliding window + global	$O(L(w+g)d)$ 与 $O(L(w+g))$	通过 global token 可在约 2 层传播	global bottleneck; causal 设计需防未来泄漏



机制	时间 / memory	长距离路径	主要局限
Block sparse	$O(Lsbd)$ 与 $O(Lsb)$	取决于 block graph diameter	pattern 设计敏感; 局部模式层数可能很深
Linear attention	$O(Lrd_v)$	全局 summary 一步可用	通常不是精确 softmax; 低秩近似和数值问题
Recurrent memory	$O(L(b+m)d)$	跨 segments 逐步传播	memory 压缩、遗忘和截断梯度

63.8 长序列真题推荐答案

答题方法

[26S-D-Q3, 7 分] 推荐选择 sliding-window + global tokens。

设 window radius 为 w , global token 数为 g 。

对普通位置 i : $\mathcal{N}(i) = \{j : |i - j| \leq w\} \cup \mathcal{G}$ 。

对 global token: $\mathcal{N}(g_a) = \{1, \dots, L\} \cup \mathcal{G}$ 。

定义 mask: $M_{ij} = \begin{cases} 0, & j \in \mathcal{N}(i), \\ -\infty, & \text{otherwise.} \end{cases}$

attention: $o_i = \sum_{j \in \mathcal{N}(i)} \text{softmax}_{j \in \mathcal{N}(i)} \left(\frac{q_i^\top k_j}{\sqrt{d_k}} \right) v_j$ 。

每层时间: $O(L(w+g)d)$, memory: $O(L(w+g))$ 。

长距离 argument: 任意位置 j 的信息可在第一层进入 global token, 再在第二层由位置 i 读取, 因此 bidirectional attention graph diameter 至多约为 2。

最后补充: 在 causal LM 中, global summary 必须只聚合 prefix, 否则会泄漏 future token。

63.9 LDA 基础模型

设:

- 文档数 D ;
- topic 数 K ;
- vocabulary 大小 V ;
- 文档 d 长度 N_d 。

topic-word distributions: $\phi_k \in \Delta^{V-1}$ 。

document-topic distributions: $\theta_d \in \Delta^{K-1}$ 。


先验:

$$\phi_k \sim \text{Dirichlet}(\boldsymbol{\eta}), \quad (63.27)$$

$$\theta_d \sim \text{Dirichlet}(\boldsymbol{\alpha}). \quad (63.28)$$

token-level topic assignment:

$$z_{dn} \sim \text{Categorical}(\theta_d). \quad (63.29)$$



observed word:

$$w_{dn} \sim \text{Categorical}(\phi_{z_{dn}}). \quad (63.30)$$

63.10 Unsupervised LDA Joint Probability

记: $\Theta = \{\theta_d\}_{d=1}^D$, $\Phi = \{\phi_k\}_{k=1}^K$ 。

完整联合概率:

$$p(\mathbf{w}, \mathbf{z}, \Theta, \Phi \mid \alpha, \eta) = \left[\prod_{k=1}^K \text{Dir}(\phi_k \mid \eta) \right] \prod_{d=1}^D \left[\text{Dir}(\theta_d \mid \alpha) \prod_{n=1}^{N_d} \theta_{d,z_{dn}} \phi_{z_{dn},w_{dn}} \right]. \quad (63.31)$$

LDA 只优化文本生成 likelihood, 没有显式使用 priority label。

63.11 监督主题模型

每篇文档有 observed binary label: $y_d \in \{0, 1\}$ 。

empirical topic-frequency vector:

$$\bar{\mathbf{z}}_d = \frac{1}{N_d} \sum_{n=1}^{N_d} \mathbf{e}_{z_{dn}} \in \Delta^{K-1}, \quad (63.32)$$

其中: $\mathbf{e}_k$ 是第 k 个标准基向量。

63.12 Logistic Label Model

参数: $\beta \in \mathbb{R}^K$, $b \in \mathbb{R}$ 。

logit:

$$u_d = \beta^\top \bar{\mathbf{z}}_d + b. \quad (63.33)$$

sigmoid:

$$\sigma(u) = \frac{1}{1 + e^{-u}}. \quad (63.34)$$

label probability:

$$p(y_d \mid \bar{\mathbf{z}}_d, \beta, b) = \sigma(u_d)^{y_d} [1 - \sigma(u_d)]^{1-y_d}. \quad (63.35)$$

解释: $\beta_k > 0$ 表示 topic k 出现比例上升时, urgent label: $y_d = 1$ 的 log-odds 增大。

具体地:

$$\log \frac{p(y_d = 1 \mid \bar{\mathbf{z}}_d)}{p(y_d = 0 \mid \bar{\mathbf{z}}_d)} = \beta^\top \bar{\mathbf{z}}_d + b. \quad (63.36)$$

63.13 监督主题模型的 Sampling Process

全局:

1. 对每个 topic $k = 1, \dots, K$: $\phi_k \sim \text{Dirichlet}(\eta)$ 。



对每个文档 $d = 1, \dots, D$:

1. sample document-topic proportions: $\theta_d \sim \text{Dirichlet}(\alpha)$;
2. 对每个 token $n = 1, \dots, N_d$: $z_{dn} \sim \text{Categorical}(\theta_d)$, $w_{dn} \sim \text{Categorical}(\phi_{z_{dn}})$;
3. 计算: $\bar{z}_d = \frac{1}{N_d} \sum_n e_{z_{dn}}$;
4. sample label: $y_d \sim \text{Bernoulli}[\sigma(\beta^\top \bar{z}_d + b)]$.

63.14 监督主题模型的完整联合概率

$$\begin{aligned}
 p(\mathbf{w}, \mathbf{z}, \Theta, \Phi, \mathbf{y} \mid \alpha, \eta, \beta, b) \\
 = \left[\prod_{k=1}^K \text{Dir}(\phi_k \mid \eta) \right] \prod_{d=1}^D \left[\text{Dir}(\theta_d \mid \alpha) \right. \\
 \quad \cdot \prod_{n=1}^{N_d} \text{Cat}(z_{dn} \mid \theta_d) \text{Cat}(w_{dn} \mid \phi_{z_{dn}}) \\
 \quad \left. \cdot \text{Bernoulli}(y_d \mid \sigma(\beta^\top \bar{z}_d + b)) \right].
 \end{aligned} \tag{63.37}$$

展开 categorical factors:

$$\text{Cat}(z_{dn} = k \mid \theta_d) = \theta_{dk}, \quad \text{Cat}(w_{dn} = v \mid \phi_k) = \phi_{kv}. \tag{63.38}$$

因此联合也可写为:

$$p = \left[\prod_{k=1}^K \text{Dir}(\phi_k \mid \eta) \right] \prod_{d=1}^D \left[\text{Dir}(\theta_d \mid \alpha) \prod_{n=1}^{N_d} \theta_{d,z_{dn}} \phi_{z_{dn},w_{dn}} \cdot \sigma(u_d)^{y_d} [1 - \sigma(u_d)]^{1-y_d} \right]. \tag{63.39}$$

63.15 为什么加入 Label 会改变 Learned Topics

无监督 LDA posterior:

$$p(\mathbf{z}, \Theta, \Phi \mid \mathbf{w}) \propto p(\mathbf{w}, \mathbf{z}, \Theta, \Phi). \tag{63.40}$$

监督模型 posterior:

$$p(\mathbf{z}, \Theta, \Phi \mid \mathbf{w}, \mathbf{y}) \propto p(\mathbf{w}, \mathbf{z}, \Theta, \Phi) \prod_{d=1}^D p(y_d \mid \bar{z}_d, \beta, b). \tag{63.41}$$

因此 topic assignment 不仅需要解释 words, 还需使: $\bar{z}_d$ 对 label 有预测性。

63.15.1 Vanilla LDA 的一个失败模式

在 customer-support ticket 中, 多数文本可能围绕: shipping, account, return。

但 urgency 可能由少量 rare expressions 表示: fraud, payment blocked, account compromised。

无监督 LDA 只追求文本 likelihood, 可能:



- 将这些词并入大 topic;
- 因低频而忽略;
- 学到主题很连贯但不区分 urgent/normal。

监督 label term 会鼓励形成: 与 urgency 相关的 discriminative topics。

63.16 Label Model Gradient

label log-likelihood:

$$\ell_d^{\text{label}} = y_d \log \sigma(u_d) + (1 - y_d) \log[1 - \sigma(u_d)]. \quad (63.42)$$

其梯度:

$$\nabla_{\beta} \ell_d^{\text{label}} = [y_d - \sigma(u_d)] \bar{\mathbf{z}}_d. \quad (63.43)$$

bias:

$$\frac{\partial \ell_d^{\text{label}}}{\partial b} = y_d - \sigma(u_d). \quad (63.44)$$

若最小化 negative log-likelihood, 梯度符号相反。

63.17 Collapsed Gibbs 条件分布

设:

- n_{dk}^{-dn} : 排除位置 (d, n) 后, 文档 d 中 topic k 的 count;
- n_{kv}^{-dn} : 排除该位置后, topic k 生成 word v 的 count;
- $n_k^{-dn} = \sum_v n_{kv}^{-dn}$;
- $\eta_0 = \sum_v \eta_v$ 。

在无监督 LDA 中:

$$p(z_{dn} = k \mid \text{rest}) \propto (n_{dk}^{-dn} + \alpha_k) \frac{n_{k, w_{dn}}^{-dn} + \eta_{w_{dn}}}{n_k^{-dn} + \eta_0}. \quad (63.45)$$

监督模型中, 对候选 assignment $z_{dn} = k$, 令: $\bar{\mathbf{z}}_d^{(k)}$ 表示将当前位置赋为 k 后的 topic-frequency vector。

则:

$$p(z_{dn} = k \mid \text{rest}) \propto (n_{dk}^{-dn} + \alpha_k) \frac{n_{k, w_{dn}}^{-dn} + \eta_{w_{dn}}}{n_k^{-dn} + \eta_0} \cdot p(y_d \mid \bar{\mathbf{z}}_d^{(k)}, \beta, b). \quad (63.46)$$

最后一个 label likelihood factor 正是 supervision 改变 topic assignment 的数学位置。

63.18 Variational Inference

可设 mean-field posterior:

$$q(\Theta, \Phi, \mathbf{z}) = \left[\prod_d q(\theta_d; \gamma_d) \right] \left[\prod_k q(\phi_k; \lambda_k) \right] \left[\prod_{d,n} q(z_{dn}; \varphi_{dn}) \right]. \quad (63.47)$$



ELBO:

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_q [\log p(\mathbf{w}, \mathbf{z}, \Theta, \Phi, \mathbf{y})] - \mathbb{E}_q [\log q(\mathbf{z}, \Theta, \Phi)]. \quad (63.48)$$

label term:

$$\sum_d \mathbb{E}_q [\log p(y_d | \mathbf{z}_d, \boldsymbol{\beta}, b)] \quad (63.49)$$

通常不是 Dirichlet-multinomial conjugate, 可能需要:

- Monte Carlo gradient;
- variational bound;
- Pólya-Gamma augmentation;
- alternating optimization。

63.19 监督主题模型的失败模式

1. Label noise。

错误 priority label 会迫使 topic 朝错误判别方向变化。

2. 过强 supervision。

若 label term 权重过大, topics 可能具有判别性但失去语义 coherence。

3. Topic label switching。

对任何 topic permutation Π , 同时置换: $\Theta, \Phi, \boldsymbol{\beta}$ 可得到等价 likelihood。

4. Class imbalance。

urgent 样本过少时, classifier 可能倾向 normal。

5. Short document sparsity。

当 N_d 很小, $\mathbf{z}_d$ 方差大。

6. Model misspecification。

Bag-of-words LDA 忽略:

- word order;
- negation;
- syntax;
- contextual polysemy。



63.20 监督主题模型真题模板

答题方法

[26S-D-Q2, 6 分]:

(a) 为什么 label 改变 topics。

监督 posterior 比无监督 LDA 多出: $\prod_d p(y_d | \bar{z}_d, \beta)$ 。

所以 topic assignments 同时优化: text likelihood + label predictiveness。

Vanilla LDA 可能忽略稀有但高度 urgency-discriminative 的词。

(b) Logistic label model。

 $\sigma(u) = \frac{1}{1+e^{-u}}$, $p(y_d | \bar{z}_d, \beta, b) = \sigma(\beta^\top \bar{z}_d + b)^{y_d} [1 - \sigma(\beta^\top \bar{z}_d + b)]^{1-y_d}$ 。其中: $\beta_k > 0$ 表示 topic k 增加 urgent log-odds。

(c) Sampling process。

 $\phi_k \sim \text{Dir}(\eta)$, $\theta_d \sim \text{Dir}(\alpha)$, $z_{dn} \sim \text{Cat}(\theta_d)$, $w_{dn} \sim \text{Cat}(\phi_{z_{dn}})$, $y_d \sim \text{Bernoulli}(\sigma(\beta^\top \bar{z}_d + b))$ 。完整联合: $\prod_k p(\phi_k | \eta) \prod_d p(\theta_d | \alpha) [\prod_n p(z_{dn} | \theta_d) p(w_{dn} | z_{dn}, \Phi)] p(y_d | \bar{z}_d, \beta, b)$ 。

63.21 本部分真题与资料映射

表 63.2: 自然语言处理第 17 部分映射

主题	等级	博资考对应	方向资料对应
Autoregressive LM、teacher forcing	S	生成、RLHF、decoding 的共同基础	[SLP] Ch.10.1–10.3; [NLP-Train] autoregressive training
Top- p 、top- k 、temperature	S	[25S-D-Q3, 3 分]	[SLP] Ch.10.2; [NLP-Train] LLM decoding strategies
Perplexity	A	模型评估基础	[SLP] Ch.10.4
MLM、BERT、contextual embedding	S	预训练模型基础	[SLP] Ch.11; [NLP-Train] pp.109–112
SFT、ICL、LoRA	S	[25S-D-Q4, 3 分] 的组成	[SLP] Ch.10–12; [NLP-Train] pp.189–190
LLM 成功因素	S	[25S-D-Q4, 3 分]	预训练、scale、Transformer、SFT、alignment
Data scaling law	S	[25S-D-Q6, 5 分]	[NLP-Train] pp.180–188; 统计学习推导为补充
LSTM vs. Transformer scaling	S	[25F-D-Q2, 5 分]	本部分与上一部分共同覆盖
Reward model、RLHF、PPO	S	[25S-D-Q7, 5 分]; [26S-B-Q3(d), 2 分]	[NLP-Train] pp.194–206
DPO	S	[26S-B-Q3(d), 2 分]	标准 KL-regularized preference derivation
长序列 attention	S	[26S-D-Q3, 7 分]	标准 attention 复杂度; 四类机制为设计题补充

主题	等级	博资考对应	方向资料对应
监督主题模型	S	[26S-D-Q2, 6 分]	LDA generative model 与 logistic supervision

63.22 综合易错点

易错点、反例与失败模式

1. 自回归 factorization 是 chain rule, 不是近似。
2. Teacher forcing 只发生在训练 conditional history。
3. Greedy token-level optimum 不等于 sequence-level MAP。
4. Beam search 不是随机 sampling。
5. Top- k 固定候选数; top- p 固定累计概率质量。
6. Temperature 改变分布尖锐度, 但不改变 token 排名。
7. Top- p 不保证事实性和安全性。
8. 不同 tokenizer 的 perplexity 不能直接比较。
9. MLM 可读左右 context, 但不天然支持 left-to-right generation。
10. MLM loss 只在 selected positions 上计算, 但所有 token 参与 attention。
11. SFT 仍然是 teacher-forced cross-entropy。
12. ICL 在推理时不更新参数。
13. LoRA 学习低秩 update, 不是对原权重做固定 SVD。
14. Scaling law 是经验 power law, 不是无条件定理。
15. Data scaling 需要同时讨论 estimation、approximation 和 optimization error。
16. Reward model 学的是相对偏好, 不是绝对人类 utility。
17. RLHF 的 policy 必须有 stochastic sampling 才能使用 score-function gradient。
18. KL objective 的精确梯度中虽出现 +1, 但其期望因 score identity 为零。
19. PPO clipping 只在特定 advantage 与 ratio 区域截平梯度。
20. DPO 不需要显式 RM, 但仍依赖 preference labels 和 reference policy。
21. DPO sequence log-probability 是所有 response token log-probability 之和。
22. Sparse attention 降低 pair 数, 不自动保证全局连通。
23. Linear attention 通常不是标准 softmax attention 的精确等价。
24. Causal global token 不能聚合未来信息后再发送给过去。
25. 监督 LDA 的 label term 会改变 posterior topic assignments。


26. Topic index 可 permutation，因此 topic 编号本身不可辨识。

63.23 综合快速自测

快速自测

1. 写出 conditional autoregressive factorization。
2. 为什么 sequence NLL 等于 token NLL 之和?
3. 推导 softmax-cross-entropy 对 logits 的梯度。
4. Teacher forcing 的训练状态与推理状态分别是什么?
5. Exposure bias 的 distribution mismatch 是什么?
6. 为什么 Transformer LM 训练可并行而生成串行?
7. 写出 perplexity 与平均 NLL 的关系。
8. 为什么不同 tokenizer 的 perplexity 不宜直接比较?
9. Greedy 为什么不保证 sequence MAP?
10. Beam search 的 $B = 1$ 情况是什么?
11. 为什么 raw log-probability 有长度偏置?
12. Temperature 在 $\tau \rightarrow 0$ 和 $\tau \rightarrow \infty$ 时分别如何?
13. 写出 top- k renormalized distribution。
14. 写出 top- p nucleus 的最小集合定义。
15. 为什么 top- p 比固定 top- k 更适应 context?
16. 为什么 beam search 更适合 translation，而不一定适合开放式对话?
17. 写出 MLM objective。
18. BERT 的经典 80/10/10 corruption 是什么?
19. 为什么双向模型不能直接预测未被 mask 的当前位置?
20. NSP 使用哪个 special token representation?
21. Static embedding 与 contextual embedding 的区别是什么?
22. SFT 与继续预训练的数据和目标有何区别?
23. Response-only loss mask 为什么有必要?
24. LoRA 的 $\Delta W = BA$ 维度如何检查?
25. ICL 是否进行 gradient update?
26. 写出 $L(P, D)$ 的双变量 scaling law。

27. 推导固定数据时 log-log 局部斜率。
28. 用 risk decomposition 解释 data scaling。
29. 为什么 data scaling 不需要 Gaussian assumption?
30. 推导 compute-optimal P^* 与 D^* 。
31. 写出 Bradley-Terry reward-model loss。
32. 推导 reward model 对 r^+ 、 r^- 的梯度。
33. 写出 KL-regularized RLHF objective。
34. 推导 KL 项的精确 policy gradient。
35. 为什么加入 state-dependent baseline 不改变梯度期望?
36. 写出 GAE。
37. 写出 PPO ratio 和 clipped objective。
38. 对 $\hat{A} > 0$, PPO 在哪个区域截平?
39. 写出 DPO loss。
40. DPO 中 reference policy 是否参与梯度更新?
41. DPO 为什么无需显式 partition function $Z(x)$?
42. Standard attention 的 $O(L^2)$ 来自哪个矩阵?
43. Sliding-window + global 的 neighbor set 如何定义?
44. 为什么 bidirectional global-token graph diameter 约为 2?
45. Block-sparse complexity 为什么是 $O(Lsbd)$?
46. 写出 linear attention 的 S 、 z 预聚合形式。
47. Causal linear attention 如何做 prefix recurrence?
48. Recurrent memory 如何 read 和 write?
49. 写出 LDA 的完整 generative process。
50. 写出 logistic topic-label model。
51. $\beta_k > 0$ 如何解释?
52. 写出监督主题模型完整联合概率。
53. 为什么加入 y_d 会改变 learned topics?
54. 写出监督 collapsed Gibbs 条件中的 label factor。
55. 为什么监督 topic model 仍存在 label switching?



第六十四章 文本、图与知识图谱的嵌入模型

64.1 重要性等级与考试定位

重要性等级：3

本章对应 [25F-D-Q1, 3 分]。

该题不是要求笼统地说明“embedding 将对象映射为向量”，而是要求对四类方法分别写出：

1. 数据中被利用的关系信号；
2. 目标函数属于何种类型；
3. 模型内置了何种归纳偏置。

满分答案必须区分：全局词共现 $\neq$ 局部词窗口 $\neq$ 图随机游走邻域 $\neq$ 有类型的知识图谱三元组。

64.2 统一设定

设词表为： $\mathcal{V} = \{1, \dots, V\}$, embedding dimension 为： d 。

词 i 的 target embedding 与 context embedding 分别为： $\mathbf{w}_i, \tilde{\mathbf{w}}_i \in \mathbb{R}^d$ 。

图： $G = (\mathcal{N}, \mathcal{E})$, 其中： $|\mathcal{N}| = N_G$ 。

知识图谱实体集和关系集： $\mathcal{E}_{\text{KG}}, \mathcal{R}_{\text{KG}}$ 。

知识图谱事实： $(h, r, t) \in \mathcal{E}_{\text{KG}} \times \mathcal{R}_{\text{KG}} \times \mathcal{E}_{\text{KG}}$ 。

64.3 GloVe: 全局共现的加权回归

定义 64.1 (共现矩阵). 设： X_{ij} 为词 i 与 context word j 在整个 corpus 的滑动窗口中共现的加权次数。

总共现次数： $X_i = \sum_{j=1}^V X_{ij}$ 。


经验条件概率： $P(j | i) = \frac{X_{ij}}{X_i}$ 。

GloVe 的主约定是：

$$\mathbf{w}_i^\top \tilde{\mathbf{w}}_j + b_i + \tilde{b}_j \approx \log X_{ij}. \quad (64.1)$$

其加权最小二乘目标为：

$$\mathcal{L}_{\text{GloVe}} = \sum_{i=1}^V \sum_{j: X_{ij} > 0} f(X_{ij}) \left(\mathbf{w}_i^\top \tilde{\mathbf{w}}_j + b_i + \tilde{b}_j - \log X_{ij} \right)^2. \quad (64.2)$$



常见权重函数为：

$$f(x) = \begin{cases} \left(\frac{x}{x_{\max}}\right)^\alpha, & 0 < x < x_{\max}, \\ 1, & x \geq x_{\max}, \end{cases} \quad 0 < \alpha < 1. \quad (64.3)$$

64.3.1 为什么需要权重函数

若直接令： $f(X_{ij}) = 1$ ，则：

- 大量只出现一次或数次的共现会带来高方差噪声；
- 极高频 function words 又可能主导平方损失。

式 (64.3) 同时实现：

1. 对稀有共现降权；
2. 对高频共现的权重进行截断，避免无限增长。

64.3.2 数据、目标与归纳偏置

- **Data signal**: 整个 corpus 的全局 word-context co-occurrence count X_{ij} .
- **Objective type**: 对: $\log X_{ij}$ 做加权双线性最小二乘回归。
- **Inductive bias**: 词义由全局共现分布决定；共现统计的对数可由低维内积近似；相似词具有相似的共现行或共现比率。

训练后常使用：

$$\mathbf{e}_i = \mathbf{w}_i + \tilde{\mathbf{w}}_i \quad (64.4)$$

作为词 i 的最终向量。

64.3.3 复杂度

设非零共现对数量为: $N_X = |\{(i, j) : X_{ij} > 0\}|$ 。

一次完整遍历的内积计算复杂度约为: $O(N_X d)$ 。

embedding 参数空间: $O(Vd)$, 若显式存储稀疏共现矩阵, 还需: $O(N_X)$ 。

64.3.4 失败模式



易错点、反例与失败模式

GloVe 的主要限制包括：

1. 每个 word type 只有一个静态向量，无法表示 polysemy；
2. 共现不等于事实、因果或逻辑蕴含；
3. corpus bias 会进入 embedding；
4. 未登录词和低频词表示不稳定；
5. 向量差近似关系只是一种经验现象，不是普适代数定理。

64.4 Skip-gram with Negative Sampling

64.4.1 局部窗口训练对

给定 token sequence: $w_1, \dots, w_T$, 窗口半径: c 。

正样本集合：

$$\mathcal{D}_+ = \{(w_t, w_{t+j}) : 1 \leq |j| \leq c\}. \quad (64.5)$$

对正 pair (w, c^+) , 从 noise distribution P_n 中采样: $c_1^-, \dots, c_K^-$ 。

常见 noise distribution 约定为：

$$P_n(v) = \frac{U(v)^{3/4}}{\sum_{u \in \mathcal{V}} U(u)^{3/4}}, \quad (64.6)$$

其中 $U(v)$ 是 unigram count。

64.4.2 SGNS 目标

单个正 pair 的 negative-sampling loss:

$$\ell_{\text{SGNS}} = -\log \sigma(\mathbf{w}_w^\top \tilde{\mathbf{w}}_{c^+}) - \sum_{j=1}^K \log \sigma(-\mathbf{w}_w^\top \tilde{\mathbf{w}}_{c_j^-}). \quad (64.7)$$

其中: $\sigma(u) = \frac{1}{1+e^{-u}}$ 。

令: $a^+ = \mathbf{w}_w^\top \tilde{\mathbf{w}}_{c^+}$, $a_j^- = \mathbf{w}_w^\top \tilde{\mathbf{w}}_{c_j^-}$ 。


则:

$$\nabla_{\mathbf{w}_w} \ell_{\text{SGNS}} = [\sigma(a^+) - 1] \tilde{\mathbf{w}}_{c^+} + \sum_{j=1}^K \sigma(a_j^-) \tilde{\mathbf{w}}_{c_j^-}. \quad (64.8)$$

梯度下降使: $a^+ \uparrow$, $a_j^- \downarrow$ 。

64.4.3 数据、目标与归纳偏置

- **Data signal**: 滑动窗口内的局部 target-context pair。
- **Objective type**: 二元 logistic discrimination: 区分真实局部共现与 noise-sampled pair。



- **Inductive bias:** distributional hypothesis: 出现在相似局部 context 中的词应具有相似表示; dot product 表示 pair compatibility。

易错点、反例与失败模式

Negative sampling 不是完整 softmax likelihood 的精确计算。

它训练的是: 真实 pair vs. noise pair 的判别目标。

因此不得写成: “SGNS 精确最大化完整 vocabulary softmax likelihood”。

64.4.4 复杂度

若正 pair 数为: N_+ , 每个正 pair 使用 K 个 negatives, 则训练主复杂度约为: $O(N_+Kd)$ 。

相比 full softmax 的: $O(N_+Vd)$, 当: $K \ll V$ 时显著降低。

64.5 Node2Vec: 随机游走生成图上下文

定义 64.2 (图上下文). Node2Vec 不直接把一阶邻接节点全部视为等价 context, 而是通过带偏置的随机游走生成 node sequence, 再把 node sequence 当作“句子”, 使用 Skip-gram 学习表示。

设随机游走刚从节点 t 到达节点 v , 下一个候选节点为: $x \in \mathcal{N}(v)$ 。

边权为: $w_{vx} > 0$ 。

未归一化转移权重:

$$\pi_{vx} = \alpha_{p,q}(t, x)w_{vx}, \quad (64.9)$$

其中:

$$\alpha_{p,q}(t, x) = \begin{cases} 1/p, & d_G(t, x) = 0, \\ 1, & d_G(t, x) = 1, \\ 1/q, & d_G(t, x) = 2. \end{cases} \quad (64.10)$$

转移概率:

$$P(X_{\ell+1} = x \mid X_\ell = v, X_{\ell-1} = t) = \frac{\pi_{vx}}{\sum_{u \in \mathcal{N}(v)} \pi_{vu}}. \quad (64.11)$$

64.5.1 参数含义

- p : return parameter。 p 小时: $1/p$ 大, 鼓励立即返回上一节点。
- q : in-out parameter。
 - $q > 1$: 抑制距离上一节点为 2 的 outward move, 更接近 BFS, 强调 homophily;
 - $q < 1$: 鼓励 outward exploration, 更接近 DFS, 强调 structural equivalence。

生成随机游走序列后, 对 node pair (u, v) 使用与式 (64.7) 相同形式的 SGNS objective。

64.5.2 数据、目标与归纳偏置

- **Data signal:** graph topology、edge weight 和 biased random walk co-occurrence。



- **Objective type**: 对随机游走生成的 node-context pair 使用 Skip-gram/negative sampling。
- **Inductive bias**: 图中经随机游走容易共同出现的节点应接近; p, q 显式控制局部同质性与结构角色之间的折中。

64.5.3 复杂度

设:

- 每个节点采样 R 条 walk;
- 每条长度为 L_w ;
- context window 为 c ;
- 每个正 pair 有 K 个 negative。

则 embedding training 的主复杂度约为:

$$O(N_G R L_w c K d). \quad (64.12)$$

64.5.4 失败模式

1. 图边若带有系统性偏差, embedding 会继承偏差;
2. disconnected components 之间缺乏共同 context;
3. 随机游走只能间接表达多跳结构;
4. 一个节点只有一个静态向量, 不能自然表达 role-dependent meaning;
5. p, q 设置不当会使表示过度局部或过度扩散。

64.6 TransE: 关系作为向量平移

对实体和关系分别学习: $\mathbf{e}_h, \mathbf{e}_t, \mathbf{r} \in \mathbb{R}^d$ 。

TransE 的核心假设:

$$\boxed{\mathbf{e}_h + \mathbf{r} \approx \mathbf{e}_t}. \quad (64.13)$$

正 triple 的距离分数:

$$d_r(h, t) = \|\mathbf{e}_h + \mathbf{r} - \mathbf{e}_t\|_p, \quad p \in \{1, 2\}. \quad (64.14)$$


分数越小, triple 越可信。

负 triple 由 corrupt head 或 tail 构造: $(h', r, t), (h, r, t')$ 。

margin ranking loss:

$$\mathcal{L}_{\text{TransE}} = \sum_{(h, r, t) \in \mathcal{T}_+} \sum_{(h', r, t') \in \mathcal{N}(h, r, t)} [\gamma + d_r(h, t) - d_r(h', t')]_+, \quad (64.15)$$

其中: $[u]_+ = \max\{u, 0\}$, $\gamma > 0$ 。



常加入 entity norm constraint:

$$\|\mathbf{e}_e\|_2 \leq 1 \quad (64.16)$$

以控制尺度和训练稳定性。

64.6.1 数据、目标与归纳偏置

- **Data signal:** typed knowledge triples: (h, r, t) .
- **Objective type:** positive triple 与 corrupted negative triple 的 margin ranking.
- **Inductive bias:** 每个关系在 embedding space 中近似为统一 translation; 同一关系的 head-tail difference 应近似相等。

64.6.2 失败模式

若一个 head 通过同一关系连接多个 tail: $(h, r, t_1), (h, r, t_2)$, 则 TransE 同时要求: $\mathbf{e}_h + \mathbf{r} \approx \mathbf{e}_{t_1} \approx \mathbf{e}_{t_2}$, 可能错误地把: $\mathbf{e}_{t_1}$ 和 $\mathbf{e}_{t_2}$ 压得很近。

因此 TransE 对:

- one-to-many;
- many-to-one;
- many-to-many;
- symmetric relation;
- reflexive relation;
- 复杂 relation composition

的表达能力有限。

64.7 四种 Embedding 的统一比较

表 64.1: GloVe、Skip-gram、Node2Vec 与 TransE

方法	数据关系信号	目标函数类型	主要归纳偏置
GloVe	全 corpus 的 X_{ij} 共现计数	对 $\log X_{ij}$ 做加权双线性平方回归	全局共现统计可由低维内积重构; 共现分布相似的词语义相似
Skip-gram	局部滑动窗口中的 target-context pair	正 pair 与 noise pair 的 logistic negative-sampling loss	局部上下文决定词义; 内积衡量 pair compatibility
Node2Vec	图上的二阶 biased random walk co-occurrence	对 node sequence 应用 Skip-gram	随机游走邻域定义节点语义; p, q 控制 homophily 与 structural role
TransE	有向、有类型的 (h, r, t) 知识 triple	正负 triple 的 margin ranking loss	relation 是 translation: $\mathbf{h} + \mathbf{r} \approx \mathbf{t}$

答题方法

[25F-D-Q1, 3 分] 的限时满分写法：

GloVe：利用全局词共现矩阵 X_{ij} ，以加权 least-squares 拟合 $w_i^\top \tilde{w}_j + b_i + \tilde{b}_j \approx \log X_{ij}$ 。其偏置是全局共现统计和共现比率可由低维向量内积表达。

Skip-gram：从局部窗口构造真实 word-context pair，并通过 negative sampling 区分真实 pair 与 noise pair： $\log \sigma(w^\top c^+) + \sum_j \log \sigma(-w^\top c_j^-)$ 。其偏置是局部上下文相似的词应具有相近表示。

Node2Vec：在图上用由 p, q 控制的 biased random walk 产生 node sequence，再对 node context 使用 Skip-gram。其偏置是随机游走共现定义图邻域，并可在同质性与结构角色之间调节。

TransE：利用 knowledge triple，以 $\|h + r - t\|_p$ 作为距离，并用 corrupted triples 构造 margin ranking loss。其偏置是一个关系对应统一的向量平移。

快速自测

1. GloVe 拟合的是 X_{ij} 还是 $\log X_{ij}$?
2. SGNS 为什么不是完整 softmax MLE?
3. Node2Vec 中 $q > 1$ 更接近 BFS 还是 DFS?
4. TransE 为什么难以处理 one-to-many relation?



第六十五章 信息检索、RAG 与对话外部记忆

65.1 重要性等级与考试定位

重要性等级：3

本章对应：

- [25S-D-Q8, 8 分]：无领域 QA pair、只有领域 corpus 时设计问答系统；
- [26S-D-Q5(a), 3 分]：推导 memory gain 的正收益条件；
- [26S-D-Q5(b), 4 分]：将 memory management 建模为 MDP。

系统设计题必须覆盖：数据流 + 索引 + retrieval + reranking + generation + 评价 + 失败模式。
只写：“使用 embedding 和 RAG”不能获得满分。

65.2 检索问题的形式化

文档集合： $\mathcal{C} = \{D_1, \dots, D_M\}$ 。

用户 query： q 。

检索器输出： $R_K(q) = (c_{(1)}, \dots, c_{(K)})$ ，其中每个： c_i 是 document 或 passage/chunk。

理想目标是使 relevant passages 排在前部。

设 relevance label： $y(q, c) \in \{0, 1\}$ 或 graded relevance： $y(q, c) \in \{0, 1, \dots, G\}$ 。

检索分数： $s(q, c) \in \mathbb{R}$ 。

排序规则： $c_i \succ c_j \iff s(q, c_i) > s(q, c_j)$ 。

65.3 离线文档处理与 Chunking

对每篇文档依次执行：

1. 格式解析；
2. 去除 boilerplate；
3. 保留标题、章节、时间、来源和权限 metadata；
4. 文本规范化与 deduplication；
5. chunking；
6. sparse index 和 dense vector index 构建。



若文档 token 长度为 N ，chunk length 为： L_c ，overlap 为： $L_o < L_c$ ，则 chunk 数近似：

$$M_D = 1 + \left\lceil \frac{\max\{0, N - L_c\}}{L_c - L_o} \right\rceil. \quad (65.1)$$

65.3.1 Chunk 太短

优点：

- 检索定位精确；
- 减少无关 context。

缺点：

- 语义和论证被切断；
- 表格标题与内容分离；
- entity、时间或条件可能落在相邻 chunk。

65.3.2 Chunk 太长

优点是上下文完整；缺点是：

- embedding 混合多个主题；
- 检索相关性被稀释；
- reranker 与 LLM context 成本上升；
- 无关证据增加。

因此 chunking 是 RAG 的模型设计变量，不是纯粹的数据预处理细节。

65.4 Sparse Retrieval 与 BM25

对 term t 和 chunk c ，定义： $\text{tf}(t, c)$ 为 term frequency， $\text{df}(t)$ 为包含 term t 的 chunk 数，总 chunk 数为 M 。

本文主约定：


$$\text{IDF}(t) = \log \left(1 + \frac{M - \text{df}(t) + 1/2}{\text{df}(t) + 1/2} \right). \quad (65.2)$$

BM25：

$$s_{\text{BM25}}(q, c) = \sum_{t \in q} \text{IDF}(t) \frac{\text{tf}(t, c)(k_1 + 1)}{\text{tf}(t, c) + k_1 \left(1 - b + b \frac{|c|}{\bar{L}} \right)}. \quad (65.3)$$

其中：

- $\bar{L}$ ：平均 chunk length；
- $k_1 > 0$ ：term-frequency saturation；
- $b \in [0, 1]$ ：length normalization。



说明 65.1. 附件中可能使用不含 $k_1 + 1$ 或采用不同平滑 IDF 的版本。这些版本的排序通常只差固定缩放或平滑约定。

全文使用式 (65.3)，答题时应先说明所采用的 BM25 convention，不得把两个版本静默混合。

65.4.1 Sparse Retrieval 的优势与局限

优势：

- inverted index 高效；
- 对专有名词、编号、公式和 rare term 精确；
- 无需监督训练；
- 分数相对可解释。

局限：vocabulary mismatch。

若 query 使用：“心肌梗死”而文档使用：“急性心脏血流阻断”，缺少词面重合可能导致漏检。

65.5 Dense Retrieval 与 Bi-Encoder

query encoder: $f_{\theta_q} : \mathcal{Q} \rightarrow \mathbb{R}^d$ 。

document encoder: $g_{\theta_d} : \mathcal{C} \rightarrow \mathbb{R}^d$ 。

表示：

$$\mathbf{z}_q = f_{\theta_q}(q) \in \mathbb{R}^d, \quad (65.4)$$

$$\mathbf{z}_c = g_{\theta_d}(c) \in \mathbb{R}^d. \quad (65.5)$$

若单位归一化： $\|\mathbf{z}_q\|_2 = \|\mathbf{z}_c\|_2 = 1$ ，则 dot product 等于 cosine：

$$s_{\text{dense}}(q, c) = \mathbf{z}_q^\top \mathbf{z}_c. \quad (65.6)$$

65.5.1 Contrastive Retriever Loss

对 query q_i ，正 chunk 为 c_i^+ ，batch negatives 为： $c_{i1}^-, \dots, c_{iK}^-$ 。

retrieval InfoNCE：

$$\ell_i^{\text{ret}} = -\log \frac{\exp(s(q_i, c_i^+)/\tau)}{\exp(s(q_i, c_i^+)/\tau) + \sum_{j=1}^K \exp(s(q_i, c_{ij}^-)/\tau)}. \quad (65.7)$$

训练目标： $\mathcal{L}_{\text{ret}} = \frac{1}{B} \sum_{i=1}^B \ell_i^{\text{ret}}$ 。

65.5.2 Negative Sampling

- **Random negatives**：容易，但常常过于简单。
- **In-batch negatives**：同一个 mini-batch 中其他 positive passages 被当作当前 query 的 negatives。



- **Hard negatives**: 从 BM25 或旧 dense retriever 的高排名错误结果中采样。
- **False negatives**: 某个所谓 negative 事实上也包含正确证据，会产生错误排斥梯度。

65.6 Approximate Nearest Neighbor Search

所有文档向量可离线计算: $\mathbf{Z} = [\mathbf{z}_{c_1}, \dots, \mathbf{z}_{c_M}] \in \mathbb{R}^{M \times d}$ 。

exact search 每个 query 的复杂度为: $O(Md)$ 。

当: M 很大时, 使用 approximate nearest neighbor, ANN, 例如:

- inverted-file index;
- product quantization;
- hierarchical navigable graph;
- clustered vector search。

易错点、反例与失败模式

“ANN 是次线性复杂度”通常是经验和数据结构层面的结论, 不应写成无条件 worst-case theorem。

ANN 以: recall 换取 latency 和 memory。索引参数设置过激会直接降低 retrieval recall。

65.7 Cross-Encoder Reranker

将 query 与 candidate chunk 联合输入 Transformer:

$$\mathbf{h}_{q,c} = \text{Encoder}([\text{CLS}], q, [\text{SEP}], c, [\text{SEP}])。 \quad (65.8)$$

分数:

$$s_{\text{cross}}(q, c) = \mathbf{w}^\top \mathbf{h}_{q,c}^{[\text{CLS}]} + b。 \quad (65.9)$$

因为所有 query token 与 document token 可以在 self-attention 中交互, cross-encoder 通常比 bi-encoder 精确。

但它不能预先独立计算: $\mathbf{z}_c$, 因此不适合对全部 M 个 chunks 逐一打分。

标准两阶段流程:

$$\text{BM25 / bi-encoder top-}N \longrightarrow \text{cross-encoder rerank top-}K。 \quad (65.10)$$


其中: $K \ll N \ll M$ 。

65.8 Hybrid Retrieval

由于 sparse 与 dense 的分数尺度不同, 应先归一化: $\tilde{s}_{\text{sparse}}, \tilde{s}_{\text{dense}}$ 。

线性融合:

$$s_{\text{hybrid}}(q, c) = \lambda \tilde{s}_{\text{sparse}}(q, c) + (1 - \lambda) \tilde{s}_{\text{dense}}(q, c), \quad \lambda \in [0, 1]。 \quad (65.11)$$



另一种无需对分数标度进行对齐的方法是 reciprocal-rank fusion:

$$s_{\text{RRF}}(c) = \sum_{m=1}^J \frac{1}{k_0 + \text{rank}_m(c)}. \quad (65.12)$$

其中: $\text{rank}_m(c)$ 是 chunk c 在第 m 个 retriever 中的排名。

65.8.1 为什么需要 Hybrid

Sparse retrieval 擅长:

- exact entity name;
- product ID;
- 法条编号;
- 稀有专业术语;
- 公式符号。

Dense retrieval 擅长:

- synonym;
- paraphrase;
- 语义近似;
- query 与文档用词不同的情况。

两者结合可降低单一表示的失败概率。

65.9 Query Rewriting 与 Multi-Hop Retrieval

多轮对话中的当前用户 utterance 可能是: q_t = “那它有什么副作用?”

直接检索时: “它” 缺少实体指代。

query rewriting:

$$q'_t = g_\omega(H_t, q_t), \quad (65.13)$$

其中: H_t 为对话历史。

重写目标是得到 self-contained query, 例如: q'_t = “药物 X 的副作用是什么?”

对于 multi-hop question: $q \rightarrow R_1 \rightarrow q^{(2)} = g(q, R_1) \rightarrow R_2$ 。

风险是第一跳错误会污染第二跳, 因此必须记录: retrieval provenance。

65.10 Context Construction

候选 passages: $\mathcal{P} = \{c_1, \dots, c_N\}$ 。

在 token budget: B_{ctx} 下选择 context subset: $S \subseteq \mathcal{P}$ 。

不能只按 relevance score 机械取前 K , 因为高排名 passages 可能高度重复。



一种 maximum marginal relevance 选择为:

$$c^* = \arg \max_{c \in \mathcal{P} \setminus S} \left[\lambda s(q, c) - (1 - \lambda) \max_{c' \in S} \text{sim}(c, c') \right]. \quad (65.14)$$

context construction 还应处理:

1. duplicate removal;
2. 相邻 chunk 合并;
3. source、title、date 和 section 保留;
4. 权威来源优先;
5. conflicting evidence 并列呈现;
6. 总 token budget;
7. 证据编号, 便于 citation。

65.11 RAG 的概率形式

检索器给出: $R_K(q) = (c_1, \dots, c_K)$ 。

生成器:

$$p_\theta(y_{1:T} | q, R_K(q)) = \prod_{t=1}^T p_\theta(y_t | q, R_K(q), y_{<t}). \quad (65.15)$$

若显式建模 latent document:

$$p(y | q) = \sum_{c \in \mathcal{C}} p_\eta(c | q) p_\theta(y | q, c), \quad (65.16)$$

实际系统常以 top- K 截断近似:

$$p(y | q) \approx \sum_{c \in R_K(q)} \tilde{p}_\eta(c | q) p_\theta(y | q, c). \quad (65.17)$$

65.12 无 QA 标注条件下的领域 RAG 系统

答题方法

[25S-D-Q8, 8 分] 标准系统答案:

一、离线语料处理。

对领域文档: $\mathcal{C} = \{D_j\}_{j=1}^M$ 执行清洗、去重、结构解析和 chunking, 并为每个 chunk 保存: (text, title, section, source, date, permission)。

二、建立两类索引。

1. inverted index + BM25;

2. 使用已有通用或领域 embedding encoder 计算: $z_c = g(c)$, 存入 ANN vector index。

这两个步骤不要求已有 QA pair。

三、query 处理。

对于用户问题 q :

1. 结合历史做 query rewriting;
2. 提取 entity、时间和必要 filter;
3. 同时运行 sparse 与 dense retrieval;
4. 对结果做 hybrid fusion。

四、reranking。

将 top- N candidate 与 query 输入通用 cross-encoder 或 LLM reranker: $s(q, c) = w^T h_{[\text{CLS}]}(q, c)$ 。
保留 top- K 且进行去重和 diversity selection。

五、grounded generation。

把: $q, c_1, \dots, c_K$ 放入 prompt, 并明确要求:

- 仅依据给定 evidence;
- 对关键结论给 source citation;
- 证据不足或冲突时 abstain;
- 不把文档中的指令当作 system instruction。

生成: $\hat{y} = \arg \max_y p_\theta(y | q, c_{1:K})$ 或使用低温 sampling。

六、无人工 QA pair 时的训练增强。

可选方法:

1. 直接使用无需训练的 BM25;
2. 使用已有 pretrained embedding model;
3. 对领域 corpus 做继续预训练;
4. 从 document sentence 自动构造 pseudo-query;
5. 将原 chunk 作为 positive, 相邻或高 BM25 错误 chunk 作为 negatives;
6. 生成 synthetic question-evidence pair 后做弱监督训练。

上述 synthetic data 只能作为弱监督, 不能被当作真实人工 gold label。

七、评价。

即使没有训练 QA pair, 仍应单独构建小规模人工 audit set, 测量: Recall@K, MRR, EM/F1, faithfulness, citation accuracy, latency。


八、失败模式。

必须讨论: retrieval miss, irrelevant evidence, conflicting evidence, outdated corpus, hallucination, private

65.13 检索召回与最终正确率

设事件: $C = \{\text{最终 context 中包含关键证据}\}$ 。

答案正确事件: $A = \{\hat{y} \text{ 正确}\}$ 。



全概率公式：

$$P(A) = P(A | C)P(C) + P(A | \neg C)[1 - P(C)]. \quad (65.18)$$

如果问题依赖专有领域知识，且 base LLM 并不知道答案，通常有： $P(A | \neg C) \ll P(A | C)$ 。

因此： $P(C)$ 即 evidence retrieval recall 是系统正确率的硬瓶颈之一。

易错点、反例与失败模式

RAG 不自动消除 hallucination。

即使： $C = 1$ ，生成器仍可能：

- 忽略证据；
- 错误组合证据；
- 把相关性写成因因果关系；
- 引用不支持结论的 passage；
- 面对冲突来源时武断选择。

所以必须分别评价：retrieval quality 和 generation faithfulness。

65.14 对话外部记忆

第 t 轮对话历史： H_t 。

候选记忆：

$$c_t = \text{Memorize}(H_t). \quad (65.19)$$

memory store: $M_t = \{m_1, \dots, m_{n_t}\}$ 。

每条 memory 可表示为： $m_i = (k_i, v_i, \tau_i, \rho_i, \mu_i)$ ，其中：

- k_i : retrieval key 或 embedding；
- v_i : memory content；
- τ_i : 时间戳；
- ρ_i : 来源和可信度；
- μ_i : 类型、实体、权限等 metadata。

检索：


$$R_t = \text{Retrieve}(H_t, M_t, K). \quad (65.20)$$

回答：

$$\hat{y}_t = f_\theta(H_t, R_t). \quad (65.21)$$

更新：

$$M_{t+1} = \text{Update}(M_t, c_t, \hat{y}_t). \quad (65.22)$$



65.14.1 Memory 类型

- **Working memory**: 当前 context window 和临时推理状态;
- **Episodic memory**: 具体历史交互和事件;
- **Semantic memory**: 稳定事实、用户偏好和概念;
- **Procedural memory**: workflows、工具用法和策略;
- **Reflective memory**: 对多个 episode 的摘要、反思和规律提取。

65.14.2 Memory 操作

action space 至少包括: $\{\text{skip, write, merge, compress, tag, evict}\}$ 以及 retrieval-side: $\{K, \lambda_{\text{sparse}}, \lambda_{\text{dense}}, \text{query reward}\}$ 。

65.15 Memory Gain 的精确分解

测试样本: $(H_t, y_t^*) \sim \mathcal{D}$ 。

评价函数: $s(\hat{y}, y^*) \in [0, 1]$ 。

单轮 gain:

$$\Delta_t = s(f_\theta(H_t, R_t), y_t^*) - s(f_\theta(H_t, \emptyset), y_t^*). \quad (65.23)$$

平均 gain:

$$\Delta = \mathbb{E}_{\mathcal{D}}[\Delta_t]. \quad (65.24)$$

定义: $C_t = \mathbf{1}\{R_t \text{ 包含关键记忆}\}$, 且: $P(C_t = 0) = \varepsilon$, $P(C_t = 1) = 1 - \varepsilon$ 。

条件 gain:

$$g_c = \mathbb{E}[\Delta_t \mid C_t = 1], \quad (65.25)$$

$$g_{\neg c} = \mathbb{E}[\Delta_t \mid C_t = 0]. \quad (65.26)$$

由全期望公式:

$$\Delta = (1 - \varepsilon)g_c + \varepsilon g_{\neg c}. \quad (65.27)$$

因此:

$$\Delta > 0 \iff (1 - \varepsilon)g_c + \varepsilon g_{\neg c} > 0. \quad (65.28)$$


这就是一般情形的必要充分条件。

若: $g_c > g_{\neg c}$, 则:

$$(1 - \varepsilon)g_c + \varepsilon g_{\neg c} > 0 \quad (65.29)$$

$$g_c - \varepsilon(g_c - g_{\neg c}) > 0 \quad (65.30)$$

$$\varepsilon < \frac{g_c}{g_c - g_{\neg c}}. \quad (65.31)$$



65.15.1 边界情形

1. 若: $g_c > 0 > g_{-c}$, 则式 (65.31) 给出位于 $(0, 1)$ 内的非平凡 threshold。
2. 若: $g_{-c} \geq 0$ 且 $g_c > 0$, 则即使未检索到关键记忆也不会造成平均损害, 对全部: $\varepsilon \in [0, 1]$ 都可能保持正收益。
3. 若: $g_c \leq 0$ 且 $g_c \geq g_{-c}$, 则: $\Delta \leq 0$, memory 系统无法获得正平均 gain。
4. 若: $g_c = g_{-c}$, 则: $\Delta = g_c$, 与 ε 无关。

答题方法

[26S-D-Q5(a), 3 分] 满分答案:

先写: $\Delta = \mathbb{E}[\Delta_t] = P(C_t = 1)\mathbb{E}[\Delta_t | C_t = 1] + P(C_t = 0)\mathbb{E}[\Delta_t | C_t = 0]$ 。

所以: $\Delta = (1 - \varepsilon)g_c + \varepsilon g_{-c}$ 。

必要充分条件是: $(1 - \varepsilon)g_c + \varepsilon g_{-c} > 0$ 。

当: $g_c > g_{-c}$, 移项得到: $\varepsilon < \frac{g_c}{g_c - g_{-c}}$ 。

最后解释: 较大 ε 表示关键记忆召回率低; 若错误或无关 memory 的平均 gain $g_{-c} < 0$, 则其负效应占比上升, 会抵消正确记忆带来的收益, 所以无法稳定保证正 gain。

65.16 将 Memory Management 建模为 MDP

定义 MDP: $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$ 。

65.16.1 State

一个充分具体的状态可写成:

$$s_t = (H_t, M_t, B_t, q_t, u_t, \zeta_t), \quad (65.32)$$


其中:

- H_t : 当前对话历史;
- M_t : memory store 的压缩表示;
- B_t : 剩余 storage/token budget;
- q_t : 当前 query;
- u_t : 模型不确定性或 answer-quality proxy;
- ζ_t : 最近 retrieval hit、latency、重复率等统计量。

实际实现中不能把整个无限 memory 原样作为有限维 state, 需要用:

summary, statistics, retrieval candidates

构成可学习状态表示。



65.16.2 Action

动作分为 write-side 与 retrieval-side:

$$a_t = (a_t^{\text{write}}, a_t^{\text{ret}}). \quad (65.33)$$

write-side: $a_t^{\text{write}} \in \{\text{skip}, \text{append}, \text{merge}, \text{compress}, \text{tag}, \text{evict}\}$ 。

retrieval-side:

$$a_t^{\text{ret}} = (K_t, \lambda_t, q'_t, F_t, \mathcal{R}_t), \quad (65.34)$$

其中:

- K_t : top- K ;
- λ_t : hybrid sparse/dense weight;
- q'_t : rewritten query;
- F_t : metadata filter;
- $\mathcal{R}_t$: reranking strategy。

65.16.3 Transition

$$R_t = \text{Retrieve}(H_t, M_t; a_t^{\text{ret}}), \quad (65.35)$$

$$\hat{y}_t = f_\theta(H_t, R_t), \quad (65.36)$$

$$M_{t+1} = \text{Update}(M_t, H_t, \hat{y}_t; a_t^{\text{write}}), \quad (65.37)$$

$$H_{t+1} = \text{Append}(H_t, \hat{y}_t, \text{next user input}). \quad (65.38)$$

65.16.4 Reward

主形式:

$$r_t = \Delta_t - \lambda_{\text{mem}} C_{\text{mem}}(a_t) - \lambda_{\text{lat}} C_{\text{lat}}(a_t) - \lambda_{\text{risk}} C_{\text{risk}}(a_t). \quad (65.39)$$

其中:

- C_{mem} : storage、context token 和 write cost;
- C_{lat} : retrieval/reranking latency;
- C_{risk} : 隐私泄露、错误写入、过期事实和不可信来源。

还可加入:


$$-\lambda_{\text{red}} \text{Redundancy}(M_{t+1}) \quad (65.40)$$

和:

$$-\lambda_{\text{budget}} [|M_{t+1}| - B_{\text{max}}]_+ \quad (65.41)$$

作为 soft budget penalty。

若预算必须严格满足: $|M_t| \leq B_{\text{max}}$, 则应把超预算动作从: $\mathcal{A}(s_t)$ 中移除, 而不是仅用有限 penalty。



65.16.5 优化目标

$$J(\varphi) = \mathbb{E}_{\pi_{\varphi}, P} \left[\sum_{t=0}^T \gamma^t r_t \right]. \quad (65.42)$$

可采用：

- policy gradient;
- actor-critic;
- contextual bandit;
- Q-learning;
- logged interaction 上的 offline RL。

若动作主要影响当前轮而不显著影响未来 memory，可近似为 contextual bandit。

若 write、merge 和 evict 会改变长期可检索信息，则必须使用长期 MDP，而不能只优化当前： Δ_t 。

答题方法

[26S-D-Q5(b), 4 分] 满分结构：

状态： $s_t = (H_t, M_t, B_t, \text{retrieval statistics})$ 。

动作必须同时包含：write/merge/compress/evict 和： $K, \text{hybrid weight, query rewrite, rerank}$ 。

转移： $M_t \rightarrow M_{t+1}, \quad H_t \rightarrow H_{t+1}$ 。

奖励： $r_t = \Delta_t - \lambda_1 \text{storage cost} - \lambda_2 \text{latency} - \lambda_3 \text{risk}$ 。

目标： $\max_{\varphi} \mathbb{E}_{\pi_{\varphi}} \sum_t \gamma^t r_t$ 。

最后说明：write/evict 会影响未来轮，所以应优化 discounted long-term return，而不是逐轮贪心最大化当前答案分数。

65.17 RAG 与 Memory 的失败模式



易错点、反例与失败模式

1. **Retrieval miss**: 关键证据未进入 top- K 。
 2. **Retrieval dilution**: 关键证据虽在 context 中, 但被大量无关文本淹没。
 3. **Conflicting memories**: 新旧事实冲突却未保留时间和来源。
 4. **Over-compression**: summary 删除限定条件、否定词或时间。
 5. **Memory poisoning**: 错误生成内容被再次写入并长期传播。
 6. **Privacy leakage**: 敏感对话被写入可跨用户检索的 store。
 7. **Stale memory**: 过期事实长期保留且缺少 version/date。
 8. **Prompt injection through documents**: 检索文本中的命令被错误当成系统指令。
 9. **Cost explosion**: K 、reranking 数量和 context size 过大, latency 与费用失控。
- 正确系统必须为每条 memory 保存: source, timestamp, confidence, scope, permission。

快速自测

1. BM25 中 b 控制什么?
2. 为什么 cross-encoder 不能直接扫描全部文档?
3. exact dense search 的时间复杂度是多少?
4. hybrid retrieval 为什么需要分数归一化或 RRF?
5. RAG 的最终答案正确率如何按关键证据事件分解?
6. memory gain 的一般必要充分条件是什么?
7. write/evict 为什么使问题具有长期 MDP 性质?



第六十六章 Markov Logic Network、全局信息抽取与 Topic–Ontology LDA

66.1 重要性等级与考试定位

重要性等级：S

本章对应：

- [25F-D-Q3, 5 分]：MLN grounding、clique、概率、权重影响和 MAP；
- [26S-D-Q4, 7 分]：将 entity linking 与 relation extraction 放入统一 MLN；
- [25F-D-Q4, 10 分]：Topic–Ontology LDA for fact triples。

MLN 在两套实际博资考中被考查，且一次是概率计算，一次是全局系统设计。因此必须同时掌握：数学定义 和 规则设计。

66.2 Markov Network

设： $\mathbf{X} = (X_1, \dots, X_n)$ 为离散随机变量，undirected graph: $G = (V, E)$ 。

clique potential: $\phi_C(\mathbf{x}_C) > 0$ 。

Markov network:

$$P(\mathbf{X} = \mathbf{x}) = \frac{1}{Z} \prod_{C \in \mathcal{C}(G)} \phi_C(\mathbf{x}_C), \quad (66.1)$$

其中：

$$Z = \sum_{\mathbf{x}} \prod_C \phi_C(\mathbf{x}_C). \quad (66.2)$$


log-linear form:

$$P(\mathbf{x}) = \frac{1}{Z} \exp \left[\sum_j w_j f_j(\mathbf{x}) \right]. \quad (66.3)$$

66.3 MLN 的定义

定义 66.1 (Markov Logic Network). MLN 是一组 weighted first-order formulas: $\mathcal{L} = \{(F_i, w_i)\}_{i=1}^J$, 其中: $w_i \in \mathbb{R}$ 。

给定有限常量域，将公式中的变量替换为所有可能常量组合，得到 ground formulas。



所有 ground atoms: $\mathcal{A} = \{A_1, \dots, A_n\}$ 。

possible world: $\mathbf{x} \in \{0, 1\}^n$ 是所有 ground atoms 的完整 truth assignment。

令: $\mathcal{G}_i$ 为公式 F_i 的 groundings 集合。

true-grounding count:

$$n_i(\mathbf{x}) = \sum_{g \in \mathcal{G}_i} \mathbf{1}\{g \text{ 在 } \mathbf{x} \text{ 中为真}\}. \quad (66.4)$$

MLN 概率:

$$P(\mathbf{X} = \mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{i=1}^J w_i n_i(\mathbf{x}) \right). \quad (66.5)$$

partition function:

$$Z = \sum_{\mathbf{x} \in \{0, 1\}^n} \exp \left(\sum_i w_i n_i(\mathbf{x}) \right). \quad (66.6)$$

66.3.1 Ground Network

1. 每个 ground atom 变成一个 Boolean variable node;
2. 同一个 ground formula 中出现的 atoms 构成 clique;
3. ground formula g 对应 potential: $\phi_g(\mathbf{x}_g) = \exp(w_i \mathbf{1}\{g(\mathbf{x}) = \text{true}\})$;
4. 同一 first-order formula 的所有 groundings 共享同一个 weight w_i 。

66.3.2 Weight 符号

在式 (66.5) 的“满足 grounding 数”约定下:

- $w_i > 0$: 满足 F_i 的 world 获得更大概率;
- $w_i < 0$: 满足 F_i 会降低 score, 因而模型相对偏好违反该公式;
- $|w_i|$: 表示该 soft constraint 的强度。

易错点、反例与失败模式

另一类资料可能使用 violation count: $P(\mathbf{x}) \propto \exp(-\sum_i \lambda_i v_i(\mathbf{x}))$, $\lambda_i > 0$ 。

它与满足数 convention 可以换算, 但不能静默混合。

本讲义遵循真题给出的: $+\sum_i w_i n_i(\mathbf{x})$ 满足数约定。


66.4 Conditional MLN 与 MAP

将 observed evidence 记为: $E = e$ 。

unknown atoms: X 。

条件分布:

$$P(X = x \mid E = e) = \frac{1}{Z(e)} \exp \left[\sum_i w_i n_i(x, e) \right]. \quad (66.7)$$



MAP:

$$x_{\text{MAP}} = \arg \max_x \sum_i w_i n_i(x, e). \quad (66.8)$$

不需要显式计算: $Z(e)$, 因为 partition function 与 x 无关。

66.4.1 参数学习梯度

若观察到完整 world $\mathbf{x}^{\text{obs}}$, 则:

$$\log P_w(\mathbf{x}^{\text{obs}}) = \sum_i w_i n_i(\mathbf{x}^{\text{obs}}) - \log Z(w). \quad (66.9)$$

权重梯度:

$$\frac{\partial}{\partial w_i} \log P_w(\mathbf{x}^{\text{obs}}) = n_i(\mathbf{x}^{\text{obs}}) - \mathbb{E}_{P_w}[n_i(\mathbf{X})]. \quad (66.10)$$

第二项通常计算困难, 因为需要对指数数量的 worlds 求和。

66.5 2025 Fall MLN 题的严格分析

定义: $I_1 = \text{InTopic}(P_1, \text{AI})$, $I_2 = \text{InTopic}(P_2, \text{AI})$ 。

引用 atoms: $C_{12} = \text{Cites}(P_1, P_2)$, $C_{21} = \text{Cites}(P_2, P_1)$ 。

第一条公式:

$$F_1(p_1, p_2) : \text{Cites}(p_1, p_2) \wedge \text{InTopic}(p_1, \text{AI}) \Rightarrow \text{InTopic}(p_2, \text{AI}), \quad w_1 = 1.5. \quad (66.11)$$

第二条公式:

$$F_2(p) : \text{InTopic}(p, \text{AI}), \quad w_2 = -1. \quad (66.12)$$

66.5.1 Ground Network

若使用所有 ordered pairs, F_1 有四个 groundings: (P_1, P_1) , (P_1, P_2) , (P_2, P_1) , (P_2, P_2) 。

F_2 有两个 groundings: I_1 , I_2 。

节点包括: $C_{11}, C_{12}, C_{21}, C_{22}, I_1, I_2$ 。

其中:


- $F_1(P_1, P_2)$ 形成: $\{C_{12}, I_1, I_2\}$ clique;
- $F_1(P_2, P_1)$ 形成: $\{C_{21}, I_2, I_1\}$ clique;
- $F_2(P_i)$ 是 unary clique。

self-groundings: $C_{ii} \wedge I_i \Rightarrow I_i$ 是 tautologies, 对所有 worlds 恒为真。

66.5.2 指定 World 的 True-Grounding Count

题目给定: $C_{12} = 1$, $C_{21} = 0$, $I_1 = 1$, $I_2 = 0$ 。

四个 F_1 groundings:



1. (P_1, P_1) : $C_{11} \wedge I_1 \Rightarrow I_1$, 恒为真;
2. (P_1, P_2) : $1 \wedge 1 \Rightarrow 0$, 为假;
3. (P_2, P_1) : $0 \wedge 0 \Rightarrow 1$, antecedent 为假, 因此 implication 为真;
4. (P_2, P_2) : $C_{22} \wedge I_2 \Rightarrow I_2$, 恒为真。

所以在严格 full-grounding convention 下:

$$\boxed{n_1(x_1) = 3.} \quad (66.13)$$

第二条公式只有 I_1 为真:

$$\boxed{n_2(x_1) = 1.} \quad (66.14)$$

unnormalized probability:

$$\boxed{\tilde{P}(x_1) = \exp(1.5 \times 3 - 1 \times 1) = e^{3.5}.} \quad (66.15)$$

说明 66.2. 若试题隐含约定: $p_1 \neq p_2$, 即排除 self-citation grounding, 则: $n_1 = 1$, $n_2 = 1$, $\tilde{P} = e^{0.5}$ 。

两种写法相差: $2w_1 = 3$ 这一对所有 worlds 相同的 tautology 常数, 所以在固定 w_1 下, 归一化后的概率比和 MAP 不受影响。

考试中应明确写出: “以下采用 full grounding, 若题目排除 self-pairs, 则删去两个恒真 grounding。”

66.5.3 改变 Weight 的影响

若: $w_1 : 1.5 \rightarrow -1.5$, 则模型不再鼓励 citation topic consistency, 而是相对偏好违反: $Cites(p_1, p_2) \wedge InTopic(p_1, AI) \Rightarrow InTopic(p_2, AI)$ 。

即更偏好: AI paper 引用 non-AI paper 这种跨主题不一致 grounding。

对于: $C_{12} = 1$, $I_1 = I_2 = 1$, 非 self 公式原本满足, 其 score contribution 从: $+1.5$ 变为: -1.5 。

相对于违反该公式的 world, unnormalized odds 乘以:

$$e^{-3}. \quad (66.16)$$

因此其相对概率显著下降。

66.5.4 MAP 枚举

给定: $C_{12} = 1$, 其他 atoms 未观测。

self-groundings 只增加常数, 可忽略。

对: (I_1, I_2) 枚举, 并对 C_{21} 取最优值:

I_1	I_2	$F_1(P_1, P_2)$	最优 $F_1(P_2, P_1)$	有效 score
0	0	满足	满足	$1.5 + 1.5 = 3$
0	1	满足	令 $C_{21} = 0$ 后满足	$3 - 1 = 2$
1	0	违反	满足	$1.5 - 1 = 0.5$
1	1	满足	满足	$3 - 2 = 1$



最大 score 为: 3, 所以:

$$\boxed{I_1^{\text{MAP}} = 0, \quad I_2^{\text{MAP}} = 0.} \quad (66.17)$$

原因是负 prior: $w_2 = -1$ 惩罚每个 AI assignment, 而当: $I_1 = 0$ 时, 已观测 citation rule 的 antecedent 为假, 仍能获得正的 rule-satisfaction score。

66.6 全局 Entity Linking 与 Relation Extraction

66.6.1 未知变量和 Evidence

未知: $\text{Link}(m, e)$, 表示 mention m 链接到 entity e 。

未知: $\text{Rel}(e_1, e_2, r)$ 。

证据: $\text{Cand}(m, e)$, $\text{Type}(e, t)$, $\text{HighLink}(m, e)$, $\text{HighRel}(m_1, m_2, r)$ 。

66.6.2 Candidate Gating

不允许链接到候选集外实体:

$$\boxed{\text{Link}(m, e) \Rightarrow \text{Cand}(m, e).} \quad (66.18)$$

若 candidate generator 的召回率可靠, 可作为 hard constraint。

66.6.3 Local Entity-Link Evidence

$$\boxed{\text{HighLink}(m, e) \Rightarrow \text{Link}(m, e).} \quad (66.19)$$

使用较大的正权重: $w_{\text{link}} > 0$, 但通常不设为硬规则, 因为 local linker 可能错误。

66.6.4 Relation Evidence Propagation

$$\boxed{\begin{aligned} &\text{HighRel}(m_1, m_2, r) \wedge \text{Link}(m_1, e_1) \wedge \text{Link}(m_2, e_2) \\ &\Rightarrow \text{Rel}(e_1, e_2, r). \end{aligned}} \quad (66.20)$$

该规则将 mention-level relation evidence 传递到 entity-level relation atom。

66.6.5 At-Most-One Constraint

对任意: $e_1 \neq e_2$, 加入:


$$\boxed{\neg \text{Link}(m, e_1) \vee \neg \text{Link}(m, e_2).} \quad (66.21)$$

这应为 hard constraint, 否则同一 mention 可能同时链接多个实体。

若允许 NIL:

$$\bigvee_{e: \text{Cand}(m, e)} \text{Link}(m, e) \vee \text{Link}(m, \text{NIL}) \quad (66.22)$$

可作为 exactly-one constraint 的“至少一个”部分。



66.6.6 Relation Type Consistency

定义 evidence predicate: $\text{Allowed}(r, t_1, t_2)$, 表示 relation r 允许: $t_1 \rightarrow t_2$ 的 argument types。

规则:

$$\boxed{\begin{aligned} &\text{Rel}(e_1, e_2, r) \wedge \text{Type}(e_1, t_1) \wedge \text{Type}(e_2, t_2) \\ &\Rightarrow \text{Allowed}(r, t_1, t_2). \end{aligned}} \quad (66.23)$$

例如:

$$\text{Rel}(e_1, e_2, \text{BornIn}) \Rightarrow \text{Type}(e_1, \text{Person}) \wedge \text{Type}(e_2, \text{City}). \quad (66.24)$$

若 KB schema 完整可靠, 可设 hard; 若 type prediction 也含噪声, 应设较大但有限的 soft weight。

66.7 HighLink 与 HighRel 的上游模型

66.7.1 Entity Linking Model

mention context: x_m 。

entity description: d_e 。

bi-encoder:

$$\mathbf{z}_m = f_\theta(x_m), \quad (66.25)$$

$$\mathbf{z}_e = g_\phi(d_e), \quad (66.26)$$

$$s_{\text{EL}}(m, e) = \mathbf{z}_m^\top \mathbf{z}_e. \quad (66.27)$$

使用 contrastive objective:

$$\ell_{\text{EL}} = -\log \frac{e^{s(m, e^+)/\tau}}{e^{s(m, e^+)/\tau} + \sum_j e^{s(m, e_j^-)/\tau}}. \quad (66.28)$$

然后对 top- N candidates 使用 cross-encoder reranking:

$$s_{\text{EL}}^{\text{cross}}(m, e) = \mathbf{w}^\top h_{[\text{CLS}]}(x_m, d_e). \quad (66.29)$$

构造: $\text{HighLink}(m, e) = 1$ 可采用:

- probability threshold;
- top-1 且与 top-2 margin 大于阈值;
- calibrated confidence;
- top- K candidate evidence。

66.7.2 Relation Extraction Model

输入: $x = [\text{CLS}], \text{sentence with entity markers}, [\text{SEP}]$ 。

例如: $[\text{E1}] m_1 [/E1] \cdots [\text{E2}] m_2 [/E2]$ 。

Transformer 输出: $\mathbf{h}_{12}$ 。



relation distribution:

$$p_{\omega}(r \mid x, m_1, m_2) = \text{softmax}(\mathbf{W}_r \mathbf{h}_{12} + \mathbf{b}_r). \quad (66.30)$$

cross-entropy:

$$\mathcal{L}_{\text{RE}} = - \sum_i \log p_{\omega}(r_i^* \mid x_i, m_{i1}, m_{i2}). \quad (66.31)$$

应包含: NoRelation 类别。

构造: $\text{HighRel}(m_1, m_2, r) = 1$ 时可要求: $p_{\omega}(r \mid \cdot) > \tau_r$ 且: $p_{\omega}(r \mid \cdot) - p_{\omega}(r_2 \mid \cdot) > \delta_r$ 。

66.8 Same-Era Constraint

引入 evidence: $\text{BirthYear}(e, y)$ 。

relation 是否需要时代一致: $\text{EraSensitive}(r)$ 。

定义:

$$\text{Far}_r(y_1, y_2) = \mathbf{1}\{|y_1 - y_2| > \tau_r\}, \quad (66.32)$$

其中: τ_r 依 relation type 而定。

例如:

- CollaboratedWith: τ_r 应较小;
- Influenced: 可能允许跨时代;
- Cited: 有明显时间方向性。

引入 unknown predicate: $\text{Contemporary}(e_1, e_2)$ 。

relation evidence 推出 contemporaneity:

$$\boxed{\begin{aligned} &\text{HighRel}(m_1, m_2, r) \wedge \text{Link}(m_1, e_1) \wedge \text{Link}(m_2, e_2) \\ &\wedge \text{EraSensitive}(r) \Rightarrow \text{Contemporary}(e_1, e_2). \end{aligned}} \quad (66.33)$$

birth-year 冲突规则:

$$\boxed{\begin{aligned} &\text{BirthYear}(e_1, y_1) \wedge \text{BirthYear}(e_2, y_2) \wedge \text{Far}_r(y_1, y_2) \\ &\Rightarrow \neg \text{Contemporary}(e_1, e_2). \end{aligned}} \quad (66.34)$$

也可直接写成强 penalty:


$$\begin{aligned} &\text{HighRel}(m_1, m_2, r) \wedge \text{Link}(m_1, e_1) \wedge \text{Link}(m_2, e_2) \\ &\wedge \text{BirthYear}(e_1, y_1) \wedge \text{BirthYear}(e_2, y_2) \wedge \text{Far}_r(y_1, y_2) \Rightarrow \perp. \end{aligned} \quad (66.35)$$

66.8.1 最小例子

文本: “Ada 与 Charles Babbage 合作设计计算装置。”

mention: $m_1 = \text{Ada}$, $m_2 = \text{Charles Babbage}$ 。

候选: $e_{\text{old}} = \text{Ada Lovelace}$, 1815 年生, $e_{\text{new}} = \text{同名现代人物}$, 2015 年生, $e_B = \text{Charles Babbage}$, 1791 年生。



relation model 给出: $\text{HighRel}(m_1, m_2, \text{CollaboratedWith}) = 1$ 。

对于: (e_{old}, e_B) , birth-year difference: $|1815 - 1791| = 24$ 。

对于: (e_{new}, e_B) , difference: $|2015 - 1791| = 224$ 。

若: $\tau_{\text{CollaboratedWith}} = 80$, 则后一个 assignment 违反 strong same-era rule, 全局 MAP 会偏向: $\text{Link}(m_1, e_{\text{old}}) = 1$ 。

答题方法

[26S-D-Q4, 7 分] 满分结构:

1. 写出 HighLink propagation;
2. 写出 $\text{HighRel} + \text{Link} + \text{Link} \Rightarrow \text{Rel}$;
3. 写出 Candidate gating;
4. 写出 at-most-one hard constraint;
5. 写出 relation argument-type rule;
6. 说明 hard/soft weight 的依据;
7. entity linker 写 bi-encoder、contrastive loss 和 cross-encoder;
8. relation model 写带 entity marker 的 Transformer softmax;
9. same-era 中定义 BirthYear、Far、Contemporary;
10. 给一个最小人物消歧例子并解释 MAP。

66.9 Topic-Ontology LDA for Fact Triples

文档 d 表示为 fact triples 多重集: $F_d = \{f = (s_f, r_f, o_f)\}$ 。

观测 surface vocabularies: $s_f \in \mathcal{V}_s, \quad o_f \in \mathcal{V}_o, \quad r_f \in \mathcal{V}_r$ 。

latent entity type set: $\mathcal{C}$ 。

latent relation type set: $\mathcal{R}_o$ 。

topic 数: K 。

66.9.1 全局分布


对每个 topic k :

$$\pi_k^{(s)} \sim \text{Dir}(\beta_s \mathbf{1}_{|C|}), \quad (66.36)$$

$$\pi_k^{(o)} \sim \text{Dir}(\beta_o \mathbf{1}_{|C|}), \quad (66.37)$$

$$\pi_k^{(r)} \sim \text{Dir}(\beta_r \mathbf{1}_{|\mathcal{R}_o|}). \quad (66.38)$$

其中: $\pi_k^{(s)}$ 是 topic k 的 subject-type distribution, $\pi_k^{(o)}$ 是 object-type distribution, $\pi_k^{(r)}$ 是 relation-type distribution。



对每个 entity type $c \in \mathcal{C}$:

$$\phi_c^{(s)} \sim \text{Dir}(\eta_s \mathbf{1}_{|\mathcal{V}_s|}), \quad (66.39)$$

$$\phi_c^{(o)} \sim \text{Dir}(\eta_o \mathbf{1}_{|\mathcal{V}_o|}). \quad (66.40)$$

对每个 relation type $t \in \mathcal{R}_o$:

$$\phi_t^{(r)} \sim \text{Dir}(\eta_r \mathbf{1}_{|\mathcal{V}_r|}). \quad (66.41)$$

66.9.2 文档级和 Triple 级生成过程

对每个 document d :

$$\theta_d \sim \text{Dir}(\alpha \mathbf{1}_K). \quad (66.42)$$

对每个: $f \in F_d$, 依次生成:

1. topic:

$$z_f \sim \text{Categorical}(\theta_d); \quad (66.43)$$

2. subject ontology type:

$$c_{s,f} \sim \text{Categorical}(\pi_{z_f}^{(s)}); \quad (66.44)$$

3. object ontology type:

$$c_{o,f} \sim \text{Categorical}(\pi_{z_f}^{(o)}); \quad (66.45)$$

4. relation ontology type:

$$t_f \sim \text{Categorical}(\pi_{z_f}^{(r)}); \quad (66.46)$$

5. subject surface mention:

$$s_f \sim \text{Categorical}(\phi_{c_{s,f}}^{(s)}); \quad (66.47)$$

6. object surface mention:

$$o_f \sim \text{Categorical}(\phi_{c_{o,f}}^{(o)}); \quad (66.48)$$

7. relation surface mention:


$$r_f \sim \text{Categorical}(\phi_{t_f}^{(r)}). \quad (66.49)$$

66.10 完整联合概率

记: $\Theta = \{\theta_d\}_d$, $\Pi = \left\{ \pi_k^{(s)}, \pi_k^{(o)}, \pi_k^{(r)} \right\}_{k=1}^K$, $\Phi = \left\{ \phi_c^{(s)}, \phi_c^{(o)} \right\}_{c \in \mathcal{C}} \cup \left\{ \phi_t^{(r)} \right\}_{t \in \mathcal{R}_o}$.

latent variables: $Z = \{z_f\}$, $C_s = \{c_{s,f}\}$, $C_o = \{c_{o,f}\}$, $T = \{t_f\}$.

observations: $S = \{s_f\}$, $O = \{o_f\}$, $R = \{r_f\}$.



完整联合为：

$$\begin{aligned}
 & p(\Theta, \Pi, \Phi, Z, C_s, C_o, T, S, O, R \mid \alpha, \beta_s, \beta_o, \beta_r, \eta_s, \eta_o, \eta_r) \\
 &= \prod_d p(\theta_d \mid \alpha) \\
 & \cdot \prod_{k=1}^K p(\pi_k^{(s)} \mid \beta_s) p(\pi_k^{(o)} \mid \beta_o) p(\pi_k^{(r)} \mid \beta_r) \\
 & \cdot \prod_{c \in \mathcal{C}} p(\phi_c^{(s)} \mid \eta_s) p(\phi_c^{(o)} \mid \eta_o) \prod_{t \in \mathcal{R}_o} p(\phi_t^{(r)} \mid \eta_r) \\
 & \cdot \prod_d \prod_{f \in F_d} \left[p(z_f \mid \theta_d) p(c_{s,f} \mid \pi_{z_f}^{(s)}) p(c_{o,f} \mid \pi_{z_f}^{(o)}) \right. \\
 & \quad \left. \cdot p(t_f \mid \pi_{z_f}^{(r)}) p(s_f \mid \phi_{c_{s,f}}^{(s)}) p(o_f \mid \phi_{c_{o,f}}^{(o)}) p(r_f \mid \phi_{t_f}^{(r)}) \right].
 \end{aligned} \tag{66.50}$$

展开一个 triple factor：

$$\theta_{d,z_f} \pi_{z_f,c_{s,f}}^{(s)} \pi_{z_f,c_{o,f}}^{(o)} \pi_{z_f,t_f}^{(r)} \phi_{c_{s,f},s_f}^{(s)} \phi_{c_{o,f},o_f}^{(o)} \phi_{t_f,r_f}^{(r)}. \tag{66.51}$$

易错点、反例与失败模式

不得遗漏以下任一层：

1. document topic: θ_d ;
2. topic 到 ontology type: $\pi_k^{(s)}, \pi_k^{(o)}, \pi_k^{(r)}$;
3. ontology type 到 surface form: $\phi_c^{(s)}, \phi_c^{(o)}, \phi_t^{(r)}$;
4. 每个 triple 的七个条件因子。

66.11 类型兼容性的可选扩展

基础题目要求的模型中，给定 topic 后： $c_{s,f}$, $c_{o,f}$, t_f 条件独立。

若需要显式建模：(subject type, relation type, object type) 兼容性，可加入：

$$\psi_\omega(c_{s,f}, t_f, c_{o,f}) = \exp[\omega(c_{s,f}, t_f, c_{o,f})]. \tag{66.52}$$

但这会改变基础联合概率，并破坏部分 Dirichlet-categorical conjugacy。

因此资格考试中应先完整写出题目要求的基础模型，再把式 (66.52) 明确标为“扩展”，不能静默加入。

66.12 Latent Category 自动命名

对 entity type c ，先取 posterior mean: $\hat{\phi}_c^{(s)}(v)$, $\hat{\phi}_c^{(o)}(v)$ 。

只按最高概率 surface form 排名可能得到：“the company”，“person”，“system”等缺乏区分度的高频词。

可定义 distinctiveness：

$$D_c(v) = \log(\hat{\phi}_c(v) + \epsilon) - \frac{1}{|\mathcal{C}| - 1} \sum_{c' \neq c} \log(\hat{\phi}_{c'}(v) + \epsilon). \tag{66.53}$$



选取: $\text{TopForms}(c) = \text{TopK}_v \left[\lambda \hat{\phi}_c(v) + (1 - \lambda) D_c(v) \right]$ 。

66.12.1 Entity Type Naming

输入:

- top subject surface forms;
- top object surface forms;
- representative triples;
- 与该 type 共现的 relation types。

候选标签集合: $\mathcal{L}_{\text{ent}}$ 可来自 ontology dictionary。

计算:

$$\text{Score}(\ell, c) = \cos \left(\mathbf{e}_\ell, \frac{\sum_v \hat{\phi}_c(v) \mathbf{e}_v}{\sum_v \hat{\phi}_c(v)} \right). \quad (66.54)$$

选择: $\hat{\ell}_c = \arg \max_{\ell \in \mathcal{L}_{\text{ent}}} \text{Score}(\ell, c)$ 。

66.12.2 Relation Type Naming

对 relation type t , 同时使用:

1. top relation surface mentions: $\text{TopForms}(t)$;
2. 高频 subject/entity-type;
3. 高频 object/entity-type;
4. representative triples。

例如 top relation phrases 为: {“was born in”, “birthplace”, “native of”}, subject type 为 Person, object type 为 Location, 则命名为: BornIn。

66.12.3 生成式命名的安全流程

可让 LLM 根据 top forms 和 examples 生成 candidate name, 但必须:

1. 限定简短 ontology-style label;
2. 同时输出理由和 representative examples;
3. 用 held-out triples 检查一致性;
4. 允许人工修订;
5. 不把生成名称反过来当作已验证事实。

答题方法

[25F-D-Q4, 10 分] 满分结构:

1. 定义: $\theta_d, \pi_k^{(s)}, \pi_k^{(o)}, \pi_k^{(r)}, \phi_c^{(s)}, \phi_c^{(o)}, \phi_t^{(r)}$;

2. 写所有 Dirichlet priors;
3. 对每个 triple 写: $z_f, c_{s,f}, c_{o,f}, t_f, s_f, o_f, r_f$;
4. 写完整 joint 的: $\prod_d \prod_k \prod_c \prod_t \prod_f$ 结构;
5. 自动命名时同时使用: top surface forms、区分度、argument types 和 representative triples;
6. 说明 latent category index 本身存在 permutation ambiguity, 名字只是 posterior interpretation。

快速自测

1. MLN 中 node 和 clique 分别是什么?
2. 在满足数约定下, 负 weight 有何含义?
3. 为什么 MAP 不需要计算 Z ?
4. 25F MLN 题若包括 self-grounding, n_1 是多少?
5. at-most-one entity-link constraint 如何写?
6. same-era rule 为什么应依赖 relation type?
7. Topic-Ontology LDA 中 π 与 ϕ 的功能有何区别?



第六十七章 NLP 评价、真题总览与全书答题闭环

67.1 分类与抽取评价

定义:

- TP : 预测正且真实正;
- FP : 预测正但真实负;
- FN : 预测负但真实正。

Precision:

$$P = \frac{TP}{TP + FP}. \quad (67.1)$$

Recall:

$$R = \frac{TP}{TP + FN}. \quad (67.2)$$

F_1 :

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}. \quad (67.3)$$

一般 F_β :

$$F_\beta = (1 + \beta^2) \frac{PR}{\beta^2 P + R}. \quad (67.4)$$

67.1.1 Micro 与 Macro

对类别 $c = 1, \dots, C$:

macro:

$$F_1^{\text{macro}} = \frac{1}{C} \sum_{c=1}^C F_{1,c}. \quad (67.5)$$

micro: 先累计所有类别的: TP , FP , FN , 再代入式 (67.3)。

易错点、反例与失败模式

在类别严重不平衡时, accuracy 或 micro- F_1 可能掩盖 minority class 的失败。

relation extraction 中: NoRelation 常占多数, 应同时报告 macro- F_1 或对真实 relation classes 的 F_1 。

67.2 排序检索评价

67.2.1 Precision@K 与 Recall@K

设: $R_K(q)$ 为 top- K 返回结果, $\mathcal{G}(q)$ 为所有 gold relevant passages。

$$\text{Precision@K}(q) = \frac{|R_K(q) \cap \mathcal{G}(q)|}{K}, \quad (67.6)$$

$$\text{Recall@K}(q) = \frac{|R_K(q) \cap \mathcal{G}(q)|}{|\mathcal{G}(q)|}. \quad (67.7)$$

RAG 中通常更关注: Recall@K, 因为遗漏关键证据会阻断 reader。

67.2.2 Average Precision 与 MAP

对单 query, 在每个 relevant result 的 rank 处计算 precision:

$$\text{AP}(q) = \frac{1}{|\mathcal{G}(q)|} \sum_{k=1}^M \text{Precision@k}(q) \mathbf{1}\{c_{(k)} \in \mathcal{G}(q)\}. \quad (67.8)$$

Mean Average Precision:

$$\text{MAP} = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \text{AP}(q). \quad (67.9)$$

67.2.3 MRR

令: rank_q 为第一个正确答案或 relevant passage 的 rank。

$$\text{MRR} = \frac{1}{|\mathcal{Q}|} \sum_{q \in \mathcal{Q}} \frac{1}{\text{rank}_q}. \quad (67.10)$$

若没有正确结果, reciprocal rank 记为: 0。

67.3 QA 评价

67.3.1 Exact Match

归一化预测: $\text{norm}(\hat{y})$, gold answers: $\mathcal{Y}^*$ 。

$$\text{EM} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}\{\text{norm}(\hat{y}_i) \in \text{norm}(\mathcal{Y}_i^*)\}. \quad (67.11)$$

必须固定 normalization:

- case;
- punctuation;
- article;



- whitespace;
- numeral format。

67.3.2 Token F1

将预测和 gold 看作 token multiset。

overlap count: $n_{\cap}$ 。

$$P_{\text{tok}} = \frac{n_{\cap}}{|\hat{y}|}, \quad R_{\text{tok}} = \frac{n_{\cap}}{|y^*|}。$$

$$F_{1,\text{tok}} = \frac{2P_{\text{tok}}R_{\text{tok}}}{P_{\text{tok}}+R_{\text{tok}}}。$$

多个 gold answers 时通常取: $\max_{y^* \in \mathcal{Y}^*} F_{1,\text{tok}}(\hat{y}, y^*)$ 。

67.4 BLEU

对 n -gram order: $n = 1, \dots, N$, 计算 clipped precision:

$$p_n = \frac{\sum_{g \in \mathcal{G}_n(\hat{y})} \min\{\text{count}_{\hat{y}}(g), \text{count}_{y^*}(g)\}}{\sum_{g \in \mathcal{G}_n(\hat{y})} \text{count}_{\hat{y}}(g)}. \quad (67.12)$$

candidate length: c , effective reference length: r 。

brevity penalty:

$$\text{BP} = \begin{cases} 1, & c > r, \\ \exp(1 - r/c), & c \leq r. \end{cases} \quad (67.13)$$

BLEU:

$$\text{BLEU} = \text{BP} \exp \left(\sum_{n=1}^N w_n \log p_n \right), \quad \sum_n w_n = 1. \quad (67.14)$$

易错点、反例与失败模式


BLEU:

- 主要是 precision-oriented;
- 常用于 corpus-level machine translation;
- 对 tokenizer 敏感;
- 不充分评价事实正确性、逻辑和 discourse coherence;
- 不应把 sentence-level 小差异过度解释。

67.5 ROUGE

ROUGE-N recall:

$$\text{ROUGE-N} = \frac{\sum_{g \in \mathcal{G}_N(y^*)} \min\{\text{count}_{\hat{y}}(g), \text{count}_{y^*}(g)\}}{\sum_{g \in \mathcal{G}_N(y^*)} \text{count}_{y^*}(g)}. \quad (67.15)$$



ROUGE-L 使用 longest common subsequence: $L = \text{LCS}(\hat{y}, y^*)$ 。

$$P_{\text{LCS}} = \frac{L}{|\hat{y}|}, \quad R_{\text{LCS}} = \frac{L}{|y^*|}。$$

再取：

$$F_{\text{LCS}} = \frac{(1 + \beta^2)P_{\text{LCS}}R_{\text{LCS}}}{R_{\text{LCS}} + \beta^2 P_{\text{LCS}}}。 \quad (67.16)$$

ROUGE 常用于 summarization，但同样不能保证 factual consistency。

67.6 Perplexity 与 WER

语言模型 perplexity 已在式 (60.14) 定义。

必须再次强调：不同 tokenizer 的 PPL 不宜直接比较。

自动语音识别中：

$$\text{WER} = \frac{S + D + I}{N}, \quad (67.17)$$

其中：

- S : substitution;
- D : deletion;
- I : insertion;
- N : reference word 数。

67.7 RAG 的分层评价

RAG 不能只报告最终 answer score。

67.7.1 Retriever

Recall@K, MAP, MRR, latency。

67.7.2 Reranker

MRR, MAP, pairwise accuracy。

67.7.3 Answer

EM, token F1, ROUGE, human correctness。

67.7.4 Faithfulness

将答案拆成 atomic claims: $\mathcal{A}(\hat{y}) = \{a_1, \dots, a_m\}$ 。

定义：

$$\text{Faithfulness} = \frac{\sum_{j=1}^m \mathbf{1}\{a_j \text{ 被 retrieval context 支持}\}}{m}。 \quad (67.18)$$



citation precision:

$$P_{\text{cite}} = \frac{\text{\#确实支持所附 claim 的 citations}}{\text{\#全部 citations}}. \quad (67.19)$$

citation recall:

$$R_{\text{cite}} = \frac{\text{\#有正确 citation 的可核查 claims}}{\text{\#全部应引用 claims}}. \quad (67.20)$$

67.7.5 Memory

必须同时测量: Δ , $P(C_t = 1)$, g_c , g_{-c} , storage, latency, privacy incidents。

只报告: $\Delta > 0$ 无法诊断失败来自: retrieval miss 还是 bad-memory harm。

67.8 NLP 系统设计题的固定答题模板

答题方法

任何 7–10 分 NLP 系统设计题, 建议按以下顺序作答:

1. 任务和输入输出。

明确: 输入, 输出, 数据是否有标签, 预算和隐私约束。

2. 变量和表示。

写出: q , c , z_q , z_c , y , 或: *Link*, *Rel*, *Type*。

3. 离线数据流。

清洗、切分、索引、负样本、知识库和 metadata。

4. 训练目标。

例如: $\mathcal{L}_{\text{ret}}$, $\mathcal{L}_{\text{RE}}$, $\mathcal{L}_{\text{DPO}}$, $\log P_{\text{MLN}}$ 。

5. 推理流程。

必须写模块调用顺序和中间输出, 不能只列模块名。

6. 复杂度。

说明: M , K , d , L 分别表示什么, 并写主导项。

7. 评价。

区分: retrieval、model、end-to-end、human 和 safety metrics。

8. 失败模式。

至少写: retrieval miss、distribution shift、false evidence、hallucination、bias、privacy 和 cost。

9. 改进。

改进必须针对具体 failure, 例如: retrieval miss
hybrid retrieval + hard-negative training.

→

67.9 三套博资考 NLP 方向完整映射

表 67.1: 2025 Spring、2025 Fall、2026 Spring 的 NLP 方向题目

真题	分值	主要标签	题型与满分核心
[25S-D-Q1]	3	trigram MLE、smoothing、backoff	概念简答；count ratio、unseen context 和低阶模型
[25S-D-Q2]	3	representation learning	定义；从 raw input 自动学习 task-useful representation；举 embedding、autoencoder、self-supervised model
[25S-D-Q3]	3	top- p 、top- k 、greedy、beam	比较题；固定候选数与动态概率质量的区别
[25S-D-Q4]	3	LLM success factors	pretraining、Transformer、scale、data、SFT、alignment、engineering
[25S-D-Q5]	3	Transformer vs. RNN	并行性、长距离路径、梯度和计算结构
[25S-D-Q6]	5	data scaling law	统计学习推导；approximation-estimation-optimization 分解
[25S-D-Q7]	5	RLHF	数据、KL-regularized reward、policy gradient
[25S-D-Q8]	8	领域 RAG	完整系统设计；chunk、index、retrieve、rerank、generate、evaluate
[25F-D-Q1]	3	GloVe、Skip-gram、Node2Vec、TransE	每种方法写 data signal、objective、inductive bias
[25F-D-Q2]	5	LSTM vs. Transformer scaling	log-log slope、fixed-data、fixed-parameter、架构偏置
[25F-D-Q3]	5	MLN	ground graph、count、weight sign、MAP
[25F-D-Q4]	10	Topic-Ontology LDA	生成过程、完整 joint、automatic naming
[25F-D-Q5]	10	text-to-image diffusion	跨方向综合；forward posterior、ELBO、noise prediction、text conditioning
[26S-D-Q1]	6	InfoNCE	完整梯度、高维球面、最大 negative、false negative
[26S-D-Q2]	6	supervised topic model	label model、sampling process、joint probability
[26S-D-Q3]	7	long-context Transformer	精确 attention pattern、复杂度、graph diameter
[26S-D-Q4]	7	MLN global IE	Link、Rel、Type constraints、local model、same-era

真题	分值	主要标签	题型与满分核心
[26S-D-Q5]	7	RAG external memory、MDP	gain threshold、 write/merge/evict/retrieve、 RL objective

67.10 NLP 方向的可迁移母题

67.10.1 母题一：概率模型

识别信号：“写生成过程” 或 “写联合概率”。

固定步骤：

1. 列出 observed 与 latent variables;
2. 写 prior;
3. 写 conditional generation order;
4. 按 plate/product 展开 joint;
5. 检查每个变量恰好被生成一次。

适用：LDA, supervised topic model, Topic-Ontology LDA, HMM。

67.10.2 母题二：对比学习

识别信号：positive、negative、temperature、embedding。

固定步骤：

1. 定义 logits;
2. 写 softmax probability;
3. 写： $\nabla \ell = \text{softmax-weighted average} - \text{positive}$;
4. 解释 pull/push;
5. 检查 false negative 和高维 concentration。

67.10.3 母题三：全局一致性

识别信号：局部模型不确定 + 实体/关系/时间约束。

想到：MLN / factor graph / global MAP。

固定步骤：

1. local score 变 evidence;
2. unknown atoms;
3. hard feasibility;



4. soft evidence;
5. cross-variable consistency;
6. MAP 或 conditional inference。

67.10.4 母题四：端到端系统

识别信号：有 corpus，无 labels，要求设计。

固定结构:offline indexing $\rightarrow$ query processing $\rightarrow$ retrieval $\rightarrow$ reranking $\rightarrow$ generation $\rightarrow$ evaluation。

67.10.5 母题五：长期决策

识别信号：当前操作影响未来数据或 memory。

想到 MDP: $s_t, a_t, P, r_t, \gamma, J(\pi)$ 。

不能只写: $r_t =$ 当前准确率。

必须加入长期 cost 和 future information value。

