

Probability & Statistics

博士生资格考试复习讲义

测度论概率 · 随机过程 · 数理统计

作者：藤藤蛇擅长找东西

资料综合范围：课程讲义、Durrett、Bickel–Doksum，
以及求真书院概统方向 2024 Spring 至 2026 Spring 五次博士资格考试

面向资格考试的定义、条件、证明、计算与模拟题

2026 年 7 月

使用说明

本讲义的目标不是替代课程讲义或参考书，而是把考试所需内容重新组织成一套可执行的复习系统。正文以考纲为硬边界，以课程讲义的记号与定理版本为主，以历年题校准证明深度与计算复杂度，并用参考书补齐严格表述和考纲缺口。

考试重点

全文使用以下三级标记：

A 级

必考核心

考纲明确要求、构成多个主题的基础，或在历年题中反复承担主干作用。要求精确定义、关键假设、主要证明和资格考试难度例题。

B 级

重要应用或真题驱动补充

考纲未必逐字列出，但课程讲义或真题表明其具有现实考查价值。要求掌握核心方法，并能完成至少一个代表性问题。

C 级


拓展

仅用于建立联系或说明边界，不属于当前复习主线，不应过度挤占 A、B 级内容的复习时间。

资料优先级与引用缩写

缩写	资料	本讲义中的用途
PL	《概率论讲义》	概率部分的记号、课程边界、主要定理版本与证明路径。
SL	《统计理论讲义》	统计部分的术语、参数化、课程计算方法与课堂强调。
D	Durrett, <i>Probability: Theory and Examples</i>	补充测度论严格性、三角阵列、鞅一致可积、可选停止、马尔可夫链与布朗运动。
BD	Bickel–Doksum, <i>Mathematical Statistics</i> , Vol. I	补充统计模型、决策理论、极小充分、信息不等式、MLE 与大样本理论。
24S–26S	五次资格考试	校准题型、证明长度、分值、边缘主题和常见失分点。

正文冲突处理遵循：考纲决定必须覆盖范围；真题决定实际命题深度；课程讲义决定主记号与课堂版本；参考书补齐严格条件和缺口。若资料仅参数化不同，正文先统一约定，再给换算；若结论强度不同，正文采用课程可用且数学上成立的版本，并在“补充说明”中列出更一般版本。



考试形式与答题要求

五次试卷具有稳定的形式：每次共 11 题，考生选做 8 题；若作答超过 8 题，只批改按书写顺序最先出现的 8 题；其中 4 题每题 15 分，其余 7 题每题 10 分。试卷有强调：只有最终答案、缺乏必要解释或推导，即使结论正确，也只能得到很少分数。

资格考试答案的最低完整结构

对证明题、推导题和计算题，建议固定写成以下六步：

- (1) 明确随机对象、参数空间、过滤或样本空间，并写清待证结论；
- (2) 写出所用定理的名称和**全部关键条件**；
- (3) 逐项核查这些条件，而不是直接写“由某定理”；
- (4) 给出主计算或逻辑链条，关键等式必须有依据；
- (5) 处理极限、边界、零概率集合、随机化或参数约束；
- (6) 用一句完整话收束结论，并注明结论是精确的还是渐近的。


选题原则

- (1) 先浏览全部 11 题，把题目分为“可完整写出”，“可做但条件易漏”，“陌生或计算长”三类。
- (2) 优先选择能写出严谨过程的 15 分题；不能因“看起来会算”而忽略证明长度。
- (3) 最终只提交最有把握的 8 题。由于只批改前 8 题，草稿与正式答卷的编号顺序必须管理清楚。
- (4) 遇到可选停止、交换极限与期望、Fisher 信息恒等式、Wilks 或 MLE 渐近正态性时，条件不明应立即降级为高风险题。
- (5) 统计题先检查支撑集是否依赖参数、参数是否在边界、MLE 是否存在；概率题先检查可积性、独立性、停时有界性和极限交换条件。




目录

使用说明	ii
考试形式与答题要求	iii
考纲—资料—真题覆盖总表	xxiii
考试重点与证明深度分级表	xxv
全课程知识依赖图	xxvi
符号、参数化和分布约定	xxvii
第一部分 概率论	1
第一章 概率空间、随机变量、分布与积分基础	2
1.1 考纲定位、真题表现与前置知识	2
1.2 概率空间与概率测度	2
1.2.1 精确定义	2
1.2.2 从下连续与从上连续	3
1.3 随机变量、可测性与分布	3
1.3.1 随机变量与生成的 σ -代数	3
1.3.2 分布、分布函数、PMF 与 PDF	4
1.3.3 等分布、几乎处处相等与可识别性	4
1.4 期望、积分与极限交换	5
1.4.1 Lebesgue 期望的定义层次	5
1.4.2 三大收敛定理	5
1.4.3 Tonelli 与 Fubini	6
1.4.4 尾积分与示性函数分解	6
1.5 矩、方差、协方差与基本不等式	6
1.6 条件概率、全概率、Bayes 与独立性	7
1.6.1 事件条件化	7
1.6.2 事件与随机变量的独立性	7
1.7 随机变量函数的分布：五种标准方法	8




1.7.1	方法一: CDF 法	8
1.7.2	方法二: 单调变换与一维 Jacobian	8
1.7.3	方法三: 多对一变换	8
1.7.4	方法四: 多维 Jacobian	9
1.7.5	方法五: 卷积	9
1.8	资格考试综合例: 均匀样本的极值与条件期望	10
1.9	本章题型识别与标准流程	11
1.10	本章易错点与反例速查	12
第二章	多维分布、条件分布与随机向量变换	13
2.1	考纲定位、重要性与真题表现	13
2.2	随机向量、联合分布与边缘分布	13
2.2.1	精确定义	13
2.2.2	边缘分布	14
2.3	条件分布与条件密度	15
2.3.1	离散情形	15
2.3.2	连续情形	15
2.4	独立性的多维判据	15
2.5	随机向量的一一变换与 Jacobian	16
2.5.1	一般定理	16
2.5.2	二维常用变换	17
2.6	Beta-Gamma 代数: 高频标准变换	17
2.7	真题型完整例: 三角区域中的条件分布	18
2.7.1	历年真题: 独立均匀和的四阶矩与三重卷积	19
2.8	本章易错点总结	21
第三章	高斯向量、条件高斯与正交分解	22
3.1	定义、等价刻画与重要性	22
3.2	高斯向量的仿射变换	23
3.3	联合高斯中“不相关推出独立”	23
3.4	条件高斯分布与回归分解	23
3.5	真题完整解法: 三维高斯正交分解	24
3.6	高斯指数倾斜与换测度	25
3.7	历年实考扩展: 二维高斯随机对称矩阵	26
3.7.1	特征值之和	26
3.7.2	特征值之差	26


3.7.3	两个特征值是否独立	26
3.7.4	正交不变性	26
3.8	本章答题模板	27
第四章	特征函数、矩母函数、概率生成函数与累积量	28
4.1	考纲定位与证明要求	28
4.2	四种变换的精确定义	28
4.2.1	特征函数	28
4.2.2	矩母函数	28
4.2.3	概率生成函数	29
4.2.4	累积量生成函数	29
4.3	特征函数的基本性质	29
4.4	唯一性定理、Lévy 连续性定理与 Cramér–Wold	30
4.5	矩母函数：存在域、唯一性与收敛	31
4.5.1	特征函数总存在，但 MGF 未必存在	31
4.6	概率生成函数及其应用	31
4.7	常见分布的 CF、MGF 与 PGF 速查	32
4.8	累积量的加法性	32
4.9	真题核心定理：指数尾、矩增长与指数矩	33
4.10	真题完整例：随机幂的矩存在性	34
4.11	简单随机游动中的指数变换	35
4.12	本章答题模板	35
4.13	本章易错点与反例	36
第五章	收敛模式、Borel–Cantelli 引理与一致可积	37
5.1	考纲定位、重要性与历年考法	37
5.2	四种基本收敛模式	37
5.2.1	几乎处处收敛	37
5.2.2	依概率收敛	38
5.2.3	L^p 收敛	38
5.2.4	依分布收敛	38
5.3	收敛模式之间的蕴含关系	39
5.4	所有常见逆命题的标准反例	40
5.4.1	依概率收敛不推出几乎处处收敛	40
5.4.2	几乎处处收敛不推出 L^1 收敛	40
5.4.3	依分布收敛不推出依概率收敛	40




5.4.4 依分布收敛不推出矩收敛	40
5.5 依概率收敛的子列原理	40
5.6 $O_{\mathbb{P}}$ 与 $o_{\mathbb{P}}$ 记号	41
5.7 连续映射定理	41
5.8 Slutsky 定理	42
5.9 真题完整解法: 乘积收敛与 L^1 反例	43
5.10 Borel–Cantelli 引理	43
5.10.1 无限次发生事件	43
5.10.2 第一 Borel–Cantelli 引理	44
5.10.3 第二 Borel–Cantelli 引理	44
5.10.4 两两独立版本	44
5.11 真题完整解法: 指数变量的极值	45
5.12 一致可积	46
5.12.1 精确定义	46
5.12.2 小概率集合刻画	46
5.13 证明一致可积的标准判据	47
5.13.1 可积随机变量控制	47
5.13.2 高阶矩一致有界	47
5.13.3 de la Vallée–Poussin 判据	47
5.13.4 条件期望族的一致可积性	47
5.14 Vitali 收敛定理	48
5.15 依分布收敛下的期望与矩收敛	49
5.16 Kolmogorov 最大不等式与随机级数	50
5.17 真题完整解法: 随机级数与指数变换的 L^1 收敛	50
5.18 常见证明套路归纳	52
5.19 易错点总表	53
5.20 本章快速自测	53
第六章 大数律、截断法与随机级数	54
6.1 考纲定位、重要性与历年考法	54
6.2 弱大数律与强大数律的精确定义	54
6.3 最基本的方差型弱大数律	55
6.4 截断法与等价序列	55
6.5 有限一阶矩的 i.i.d. 弱大数律	56
6.6 Kolmogorov 三列定理	57
6.7 Kronecker 引理	58




6.8	独立非同分布变量的强大数律	58
6.9	i.i.d. 强大数律	58
6.10	真题完整解法：稀有大跳造成平均值双向振荡	60
6.11	本章易错点	61
第七章	中心极限定理、三角阵列与 Poisson 收敛	63
7.1	考纲定位、重要性 with 历年考法	63
7.2	经典 i.i.d. 中心极限定理	63
7.3	多元中心极限定理	64
7.4	三角阵列	64
7.5	Lindeberg–Feller 中心极限定理	64
7.5.1	归一化版本	64
7.5.2	未归一化版本	65
7.6	Feller 条件与 Lyapunov 条件	66
7.7	真题完整解法：无限方差下的非标准正态归一化	67
7.8	真题完整解法：总方差被可求和异常大跳污染	68
7.9	Poisson 收敛：稀有事件定律	69
7.10	正态极限与 Poisson 极限的识别	69
7.11	中心极限定理题的标准解题流程	70
7.12	母题速查表	71
7.13	本章易错点总表	71
第八章	条件期望、条件分布与条件独立	73
8.1	考纲定位、重要性 with 历年考法	73
8.2	给定 σ 代数的条件期望	73
8.2.1	精确定义	73
8.2.2	存在性与唯一性	74
8.3	条件期望的基本性质	74
8.3.1	已知量可以取出	75
8.3.2	Tower property	75
8.3.3	独立信息不改变条件期望	76
8.4	条件收敛定理	76
8.5	条件 Jensen、不等式与 L^p 收缩	77
8.6	条件方差与全方差公式	77
8.7	L^2 投影解释	78
8.8	给定随机变量的条件期望	78




8.8.1	Doob–Dynkin 引理	78
8.8.2	离散条件分布	79
8.8.3	连续条件密度	79
8.9	正则条件分布	79
8.10	交换性条件化	80
8.11	条件高斯的简明回顾	80
8.12	条件独立	80
8.13	真题完整解法：条件二阶矩刻画正态分布	81
8.14	条件期望题的答题模板	82
第九章	鞅、停时与可选停止	83
9.1	考纲定位、重要性 with 历年考法	83
9.2	过滤、适应性与鞅	83
9.3	常见鞅构造	84
9.3.1	独立中心增量之和	84
9.3.2	条件期望鞅	84
9.3.3	乘积鞅	84
9.3.4	指数鞅	84
9.3.5	平方补偿鞅	84
9.3.6	凸函数产生下鞅	84
9.4	停时	85
9.5	停时处的信息与停止过程	85
9.6	可选停止定理	86
9.6.1	有界停时版本	86
9.6.2	统一版本：停止族一致可积	86
9.7	真题完整解法：有限期望停时仍可失败	87
9.8	真题完整解法：双边首达时的概率生成函数	88
9.9	真题完整解法：偏随机游动的指数鞅	89
9.9.1	当 $p \geq 1/2$ 时的命中恒等式	89
9.9.2	当 $p < 1/2$ 时的命中概率	89
9.9.3	随机上确界的分布	89
9.10	停时题的参考流程	90
第十章	Doob 不等式与鞅收敛	91
10.1	Doob 最大不等式	91
10.2	上穿与几乎处处收敛	91




10.3 L^p 有界鞅的收敛	92
10.4 一致可积鞅与 L^1 收敛	92
10.5 a.s. 收敛不保证 L^1 收敛	93
10.6 真题完整解法: 严格凸性迫使鞅退化	93
10.7 概念区别与常见错误	94
10.8 鞅题识别信号与构造方法	95
10.9 本章快速自测	95
第十一章 离散时间马尔可夫链	96
11.1 考纲定位、重要性 with 历年考法	96
11.2 状态空间、转移矩阵与 Markov 性	97
11.2.1 基本约定	97
11.3 n 步转移概率与 Chapman–Kolmogorov 方程	98
11.4 强马尔可夫性质	99
11.5 随机映射表示	100
11.6 真题完整解法: 一般马尔可夫链的随机递推表示	100
11.7 可达性、沟通类、不可约性与闭类	101
11.8 周期与非周期性	102
11.9 常返、暂留与 Green 函数	103
11.9.1 精确定义	103
11.9.2 返回概率与访问次数	103
11.9.3 常返性是沟通类性质	104
11.10 正常返、零常返与 Kac 公式	104
11.11 平稳分布	105
11.12 不可约可数链: 平稳分布与正常返的等价性	105
11.13 详细平衡、可逆性与时间反转	107
11.14 图上的简单随机游动	108
11.15 出生–死亡链	108
11.16 遍历定理与收敛到平稳分布	109
11.16.1 总变差距离的约定	109
11.16.2 遍历定理	109
11.16.3 分布收敛定理	110
11.16.4 有限状态链的几何收敛	110
11.17 调和函数、命中概率与首步分析	111
11.18 马尔可夫链易错点总表	112



第十二章 随机游动、树上随机游动与电网络方法	114
12.1 考纲定位与证明要求	114
12.2 一维简单随机游动的基本分布	114
12.3 反射原理	115
12.4 赌徒破产：命中概率与平均退出时间	115
12.4.1 先到达上边界的概率	115
12.4.2 平均退出时间	116
12.5 半直线上的命中概率	116
12.6 简单随机游动的常返判据	117
12.7 真题完整解法：正则树与 b 叉树上的随机游动	118
12.8 课程扩展：随机游动与电网络	120
12.8.1 加权网络与可逆随机游动	120
12.8.2 电压、调和函数与命中概率	120
12.8.3 有效电阻	120
12.8.4 树上的分层电阻计算	121
12.9 随机游动证明方法总表	121
12.10 随机游动易错点总表	122
第十三章 泊松过程与连续时间马尔可夫链	124
13.1 考纲定位、优先级与资料约定	124
13.2 点过程、到达时间与计数过程	124
13.3 泊松过程的定义与基本矩	125
13.4 无记忆性与指数分布	126
13.5 到达间隔与第 n 次到达时间	126
13.6 给定总到达数后的条件结构	127
13.7 小时间刻画	128
13.8 叠加、竞争指数钟与稀疏化	128
13.8.1 叠加	128
13.8.2 竞争指数钟	129
13.8.3 稀疏化与分裂	129
13.9 泊松过程的鞅	130
13.10 泊松过程易错点	130
13.11 连续时间马尔可夫链的定义	131
13.12 停留时间、跳时刻与嵌入跳链	132
13.13 生成元与小时间转移率	132
13.14 由生成元构造连续时间链	133




13.15	首跳分解与 Kolmogorov 方程	134
13.16	有限状态空间：矩阵指数与均匀化	135
13.17	平稳分布、详细平衡与正再生	135
13.18	例题： $M/M/1$ 排队	137
第十四章 高斯过程、白噪声与布朗桥		138
14.1	考纲定位与历年扩展	138
14.2	高斯向量与高斯过程	138
14.3	联合高斯中的正交性与独立性	139
14.4	高斯条件期望是正交投影	140
14.5	高斯白噪声	140
14.6	Brownian bridge	140
14.7	一维零边界 Gaussian free field	141
14.8	真题完整解法：Brownian bridge 等于一维 GFF	142
第十五章 布朗运动		143
15.1	考纲定位与历年考法	143
15.2	精确定义与等价结构	143
15.3	平稳增量、缩放与时间平移	144
15.4	连续修改与 Hölder 正则性	144
15.5	二次变差、无限变差与处处不可微	145
15.5.1	二次变差	145
15.5.2	无限总变差	145
15.5.3	处处不可微	146
15.6	Brownian motion 的基本鞅	146
15.7	连续时间停时与强 Markov 性	147
15.8	反射原理与最大值	147
15.9	单侧首达时	148
15.10	首达时的 Laplace 变换	148
15.11	双边退出问题	149
15.12	真题完整解法：2024 Spring 首达时	149
15.13	真题完整解法：2025 Spring 对称退出时间与方向	150
15.14	吸收边界与 killed Brownian transition density	151
15.15	真题完整解法：2024 Fall 吸收前条件分布	151
15.16	Brownian 大时间线性归一化	152
15.17	真题完整解法：2025 Fall Brownian 指数鞅	152




15.18 确定性 Laplace 原理	153
15.19 真题完整解法: 2026 Spring Brownian 指数泛函	153
15.20 Brownian motion 易错点总表	154
第十六章 Galton–Watson 分枝过程与随机树	156
16.1 考纲定位	156
16.2 模型、过滤与基本递推	156
16.3 灭绝事件与固定点	157
16.4 归一化人口鞅	158
16.5 真题完整解法: 2026 Spring 第 5 题	159
16.6 遗传性质的条件 0–1 律	159
16.7 Galton–Watson 树上的独立边渗流	160
16.8 真题完整解法: 2026 Spring 第 6 题	161
16.9 分枝过程易错点	162
第二部分 数理统计	164
第十七章 统计模型、参数、统计量与随机样本	165
17.1 考纲定位与重要性	165
17.2 统计模型、参数化与可识别性	165
17.3 统计量、估计量与估计值	166
17.4 随机样本	166
17.5 经验分布函数与样本矩	167
17.6 样本均值与样本方差	167
第十八章 常见分布总表与分布关系	170
18.1 全文统一参数化约定	170
18.2 离散分布核心公式表	170
18.3 连续分布核心公式表	171
18.4 分布之间的核心关系	171
18.5 推断结构、充分统计量与共轭先验速查	173
18.6 参数化易错点	173
18.7 历年题型: Uniform 和的四阶矩与分布	174
18.8 历年题型: 指数变量的随机 Poisson 次幂	175
第十九章 指数族	176
19.1 考纲定位	176

19.2 一般形式与自然形式	176
19.3 自然参数空间的凸性	177
19.4 对数配分函数的导数	177
19.5 i.i.d. 样本的指数族结构	178
19.6 常见模型的自然形式	179
19.7 满指数族与曲指数族	179
19.8 参数依赖支持集与非正则模型	180
19.9 一般共轭先验	180
第二十章 正态总体的抽样理论	182
20.1 考纲定位	182
20.2 正态样本分解定理	182
20.3 Cochran 定理框架	183
20.4 Student t 分布	183
20.5 卡方与 F 枢轴量	184
20.6 历年题答题模板: 证明 $\bar{X} \perp S^2$	184
第二十一章 次序统计量、样本中位数与样本分位数	185
21.1 考纲定位	185
21.2 次序统计量的定义	185
21.3 第 k 个次序统计量的分布	185
21.4 极小值与极大值	186
21.5 全部次序统计量的联合密度	186
21.6 两个次序统计量的联合密度	187
21.7 Uniform 次序统计量与 Beta 分布	187
21.8 历年真题完整解法: 极小值、极大值及条件期望	188
21.9 总体分位数与经验分位数	189
21.10 样本分位数相合性的精确条件	190
21.11 连续总体下样本分位数的渐近正态性	190
21.12 历年真题完整解法: Bernoulli 样本分位数	191
21.13 次序统计量与分位数易错点	192
第二十二章 充分性、完全性、辅助性与 UMVU 估计	194
22.1 考纲定位与历年考法	194
22.2 充分统计量的精确定义	195
22.3 Neyman–Fisher 因子分解定理	195
22.4 充分统计量标准例题	196




22.4.1 Bernoulli 样本	196
22.4.2 正态总体, 两个参数均未知	196
22.5 极小充分统计量	197
22.6 极小充分统计量的似然比判别法	197
22.7 极小充分统计量的标准例题	198
22.7.1 Bernoulli 样本	198
22.7.2 正态总体, 均值和方差均未知	198
22.7.3 位置 Uniform 模型	198
22.8 辅助统计量	199
22.9 辅助统计量的标准构造	199
22.9.1 位置族	199
22.9.2 尺度族	200
22.9.3 随机样本量	200
22.10 完全统计量	200
22.11 常见完全统计量的直接证明	200
22.11.1 Binomial 完全性	200
22.11.2 Poisson 完全性	201
22.11.3 Gamma 完全性	201
22.11.4 Uniform 极大值完全性	201
22.12 满秩指数族的完全性	201
22.13 完全、充分与极小充分之间的关系	202
22.14 Rao–Blackwell 定理	203
22.15 Lehmann–Scheffé 定理	204
22.16 Basu 定理	204
22.17 Basu 定理的标准应用	205
22.17.1 正态样本均值与样本方差	205
22.17.2 指数样本的总和与比例	205
22.17.3 极小充分但不完全的反例	205
22.18 真题完整解法: 充分统计量保持相合性	206
22.19 真题完整解法: 指数样本生存概率的 UMVUE	207
22.20 真题完整解法: Bernoulli 参数多项式的 UMVUE	208
22.21 真题完整解法: Poisson($\sqrt{\lambda}$) 模型	209
22.22 真题完整解法: 相关系数模型的极小充分性与非完全性	210
22.23 真题完整解法: 受约束正态均值模型的 UMVUE	211
22.24 真题完整解法: 正态模型中 μ/σ 的 UMVUE	212

22.24.1 完全充分统计量	212
22.24.2 构造无偏估计量	212
22.24.3 二阶矩与 UMVUE 的存在条件	212
22.24.4 为什么小样本情形必须单独讨论	213
22.25 证明套路总结	214
22.25.1 证明充分性	214
22.25.2 证明极小充分性	214
22.25.3 证明完全性	215
22.25.4 求 UMVUE	215
22.26 易错点总表	216
22.27 答题模板	216
第二十三章 矩估计、最大似然估计与估计量评价	218
23.1 考纲定位与重要性	218
23.2 点估计量、估计值与参数空间	218
23.3 矩估计法	219
23.3.1 一般定义	219
23.3.2 矩估计相合性的标准定理	220
23.3.3 正态模型的矩估计	220
23.3.4 Uniform 模型中的参数空间冲突	221
23.3.5 两个未知参数的 Binomial 模型	221
23.4 似然函数与最大似然估计	221
23.4.1 似然函数	221
23.4.2 MLE 的集合值定义	222
23.5 MLE 的标准求解流程	222
23.6 MLE 的存在性与唯一性	223
23.6.1 自然指数族中的凹性	223
23.7 MLE 的不变性	224
23.8 充分统计量与 MLE	224
23.9 常见模型的 MLE	225
23.9.1 Bernoulli 模型	225
23.9.2 Poisson 模型	225
23.9.3 指数分布	225
23.9.4 正态总体，两个参数均未知	225
23.9.5 Uniform(0, θ) 模型	226
23.9.6 MLE 不唯一：固定长度位置 Uniform 模型	226



23.10 真题型：只观察正态样本的符号	226
23.11 估计量的偏差、方差与 MSE	227
23.11.1 无偏样本方差与正态 MLE 方差估计的比较	227
23.12 相合性与渐近无偏性	228
23.13 相对效率	229
23.14 历年真题完整解法：分段 Uniform 模型	229
23.15 历年真题完整解法： $\log X_i \sim N(\theta, \theta)$	230
23.16 历年真题完整解法：Gamma 尺度参数的倒数	231
23.17 历年真题完整解法：平移指数模型的非正则 MLE	232
23.18 历年真题型：MLE 未必存在	233
23.19 点估计易错点	234
第二十四章 Fisher 信息与 Cramér–Rao 下界	235
24.1 考纲定位	235
24.2 正则条件	235
24.3 Score 与 Fisher 信息	236
24.4 Score 均值为零	236
24.5 Fisher 信息的第二种公式	237
24.6 i.i.d. 样本的信息可加性	237
24.7 重参数化下的 Fisher 信息	238
24.8 指数族中的 Fisher 信息	238
24.9 标量 Cramér–Rao 信息不等式	238
24.10 有偏估计量的广义下界	239
24.11 Cramér–Rao 下界的达到条件	239
24.12 多参数 Fisher 信息矩阵	240
24.13 存在 nuisance 参数时的有效信息	240
24.14 常见模型的 Fisher 信息速查	241
24.14.1 Bernoulli(p)	241
24.14.2 Poisson(λ)	241
24.14.3 指数率参数	241
24.14.4 正态均值，方差已知	241
24.14.5 正态方差，均值已知	242
24.14.6 正态均值与方差均未知	242
24.14.7 Gamma 尺度参数	242
24.15 历年真题：高斯线性模型的信息矩阵	242
24.16 参数依赖支持集：Uniform 反例	243

24.17 正则与非正则模型对照	244
24.18 Fisher 信息与 Cramér–Rao 易错点	244
24.19 证明与计算套路	245
第二十五章 假设检验基础、误差概率与功效函数	247
25.1 考纲定位与重要性	247
25.2 本章分位数与尾概率约定	247
25.3 统计假设、原假设与备择假设	248
25.4 检验函数、拒绝域与随机化	248
25.4.1 非随机化检验	248
25.4.2 随机化检验	249
25.5 第一类错误、第二类错误与功效函数	249
25.6 size 与 level	250
25.6.1 最不利原假设参数	251
25.7 离散检验中的边界随机化	251
25.8 p -值	252
25.9 最强检验、UMP 检验与无偏检验	253
25.9.1 无偏检验	253
25.10 功效与样本量	254
25.11 假设检验基础答题模板	255
第二十六章 Neyman–Pearson 引理、单调似然比与 UMP 检验	256
26.1 简单似然比与广义似然比的区别	256
26.2 Neyman–Pearson 引理	256
26.2.1 精确陈述	256
26.2.2 边界随机化的存在性	257
26.2.3 必要性与唯一性	258
26.3 Neyman–Pearson 引理的标准例题	258
26.4 单调似然比	259
26.4.1 充分统计量版本与联合密度版本	259
26.4.2 一参数指数族的 MLR 判据	259
26.5 MLR 推出随机单调性	259
26.6 Karlin–Rubin 定理	260
26.7 识别 Karlin–Rubin 题型	261
26.8 双侧问题中 UMP 通常不存在	261
26.9 历年真题：只观察正态样本符号后的 UMP 检验	262



26.10 历年真题: Pareto 模型中总体均值的 UMP 检验	263
26.11 历年真题: Gamma 双侧检验中 UMP 不存在	264
26.12 历年真题: 变换为指数分布后的 MLR 检验	265
26.13 历年真题: 离散 Uniform 模型中的随机化 UMP	266
26.14 历年真题: nuisance 参数未知时的精确 size	269
26.15 假设检验与 UMP 易错点总表	269
26.16 证明套路总结	270
26.17 答题模板	271

第二十七章 似然比检验、广义似然比检验与大样本检验 273

27.1 考纲定位与重要性	273
27.2 广义似然比统计量	273
27.3 广义似然比检验的标准计算流程	274
27.4 充分统计量与似然比检验	274
27.5 正态均值: 方差已知时的精确 LRT	275
27.6 正态均值: 方差未知时的精确 LRT	275
27.6.1 非受限最大化	275
27.6.2 原假设下的受限最大化	276
27.7 Bernoulli 模型的广义似然比统计量	276
27.8 Poisson 模型的 LRT	277
27.9 Wilks 定理	277
27.9.1 标量简单原假设	277
27.9.2 证明框架	278
27.9.3 多参数与复合原假设	278
27.9.4 多项分布示例	278
27.10 Wald 检验	279
27.11 Score 或 Rao 检验	279
27.11.1 无 nuisance 参数	279
27.11.2 存在 nuisance 参数	280
27.12 LR、Wald 与 Score 的渐近等价	280
27.13 固定备择与局部备择	281
27.13.1 固定备择	281
27.13.2 局部备择	281
27.14 Wilks 定理不能直接使用的情形	281
27.15 本章易错点	281

第二十八章 置信区间、置信域及其与检验的对偶283

28.1 考纲定位与重要性283

28.2 区间估计量、覆盖概率与置信系数283

28.3 检验与置信集的对偶定理284

28.4 枢轴量法285

28.5 正态总体的精确置信区间285

28.5.1 均值，方差已知285

28.5.2 均值，方差未知285

28.5.3 方差285

28.6 指数分布参数的精确区间286

28.7 两个正态方差之比286

28.8 常见精确置信区间速查286

28.9 历年真题：只观察符号后的置信区间287

28.10 CDF 反演法287

28.11 渐近 Wald 置信区间288

28.12 似然比置信区域288

28.13 参数变换下的置信区间289

28.14 最短区间与等密度端点289

28.15 UMA 置信界289

28.16 频率学置信区间与 Bayes 可信区间290

28.17 最高后验密度区域290

28.18 置信区间易错点290

第二十九章 Bayes 统计与统计决策理论292

29.1 考纲定位与历年实考扩展说明292

29.2 统计决策问题的组成292

29.3 常见损失函数293

29.4 先验、似然与后验293

29.5 后验风险与 Bayes 规则294

29.6 不同损失函数下的 Bayes 估计294

29.6.1 平方损失：后验均值294


29.6.2 绝对损失：后验中位数294

29.6.3 不对称绝对损失：后验分位数295

29.6.4 离散 0-1 损失：后验众数295


29.7 常见共轭先验表295

29.8 广义 Bayes 规则与不当先验296



29.9 历年真题: Uniform 模型的不当平坦先验	297
29.10 历年真题: Uniform 模型与 Lognormal 先验	298
29.11 Bayes risk	298
29.12 风险支配与可容许性	299
29.13 proper Bayes 规则与可容许性	299
29.14 minimax 规则	299
29.15 常风险 Bayes 规则的 minimax 定理	300
29.16 Bayes risk 极限下界法	300
29.17 历年真题: 正态均值向量的 minimax 性	300
29.18 历年真题: 两点先验下的 Bayes 与 minimax 检验	301
29.19 历年真题: 约束参数空间中的不可容许性	301
29.20 历年真题: 无偏尺度估计量的不可容许性	302
29.21 历年真题: Bernoulli 加权损失下的可容许性	303
29.22 Bayes 与决策理论易错点	303
第三十章 相合性、渐近正态性与 MLE 的统一渐近理论	305
30.1 考纲定位	305
30.2 相合性的 argmax 框架	305
30.3 MLE 相合性的 Kullback–Leibler 识别	305
30.4 一维 MLE 的渐近正态性	306
30.5 多参数 MLE	306
30.6 多元 Delta 方法	307
30.7 二阶 Delta 方法	307
30.8 标准误估计与学生化	307
30.9 渐近效率	308
30.10 正则与非正则渐近理论的判断表	308
30.11 渐近题参考流程	308
第三十一章 线性模型与 Gauss–Markov	310
31.1 线性模型与基本假设	310
31.2 最小二乘估计	310
31.3 线性函数的无偏估计	311
31.4 Gauss–Markov 定理	311
31.5 一般协方差下的广义最小二乘	312
31.6 高斯线性模型中的精确分布	312
31.7 单个线性约束的精确 t 检验	313

31.8 多个线性约束的精确 F 检验	313
31.9 Fisher 信息矩阵	313
31.10 线性模型易错点	313
第三部分 应试技巧	315
第三十二章 需要记忆的定义、定理与证明清单	316
32.1 需要记忆的定义清单	316
32.2 需要记忆的定理清单	317
32.3 需要会完整证明的高频结果	317
32.4 证明套路总表	318
32.5 估计题解题流程	319
32.6 检验题解题流程	319
32.7 随机过程题解题流程	319
第三十三章 五套真题总地图与母题分类	320
33.1 考试结构与选题原则	320
33.2 五套试卷逐题映射	320
33.3 五套真题主题分布概览	322
33.4 高频母题分类	322
33.5 最终优先级	323
第四部分 模拟试题	324
第三十四章 模拟试题	325
34.1 第一套试题	325
34.2 第二套试题	330
34.3 第三套试题	333
34.4 第四套试题	336
34.5 第五套试题	339
第三十五章 模拟试题解答	342
35.1 第一套试题 + 答案	342
35.2 第二套试题 + 答案	354
35.3 第三套试题 + 答案	365
35.4 第四套试题 + 答案	379
35.5 第五套试题 + 答案	394



考纲—资料—真题覆盖总表

下表是全书结构的压缩映射。“真题表现”只列代表性题型，不表示未列年份没有相关基础内容。


考纲模块	主要资料锚点	历年题中的主要表现	优先级与深度
概率空间、事件、随机变量、分布、期望与独立性	PL 第 1 章; D 第 1-2 章	24F 第 1 题矩计算与卷积; 25S 第 1-2 题极值与高斯向量; 25F 第 1-2 题矩存在性与条件分布; 26S 第 1 题高斯换测度	A 级 ; 定义和基本证明必须完整
方差、协方差、矩与多元正态	PL 高斯向量; D 特征函数与高斯; BD 附录 B	25S 第 2 题协方差矩阵与正交分解; 25S 第 9 题相关系数; 25F 第 6 题高斯随机矩阵; 26S 第 1、11 题	A 级 ; 线性代数条件必须写明
随机变量与随机向量函数的分布	SL 变换章节; BD 附录 B.2; PL 第 1 章	24F 第 1 题 Irwin-Hall; 25S 第 1 题极值; 25F 第 2 题条件几何区域; 26S 第 11 题密度变换	A 级 ; CDF、Jacobian、卷积须熟练
特征函数、矩母函数、生成函数、累积量	PL 第 4 章; D 第 3 章; SL 矩母函数	24S 第 1、4 题; 24F 第 3 题; 25S 第 3 题; 26S 第 5 题	A 级 ; 特征函数存在性与收敛定理须严格
各种收敛与一致可积	PL 第 2 章; D 第 2、4.6 节	24S 第 2-3 题; 24F 第 5 题; 25F 第 4 题; 26S 第 8、10 题	A 级 ; 蕴含、逆命题与标准反例必须掌握
条件概率与条件期望	PL 第 5.1 节; D 第 4.1 节; BD 附录 B.1	25S 第 1、6 题; 26S 第 5 题; 多题中的 conditioning 与 tower property	A 级 ; 定义与唯一性必须严谨
大数律、Borel-Cantelli 与随机级数	PL 第 2-3 章; D 第 2 章	24S 第 2 题极值; 24F 第 5 题随机级数; 25F 第 4 题稀有大跳; 26S 第 2 题	A 级 ; 截断与 BC 是高频证明工具
中心极限定理与三角阵列	PL 第 4.5 节; D 第 3.4 节	24S 第 1、8、9 题; 24F 第 2、9 题; 25S 第 9-11 题; 26S 第 2、4、10 题	A 级 ; Lindeberg 条件与 Delta 法须会检查
鞅、停时、可选停止与鞅收敛	PL 第 5 章; D 第 4 章	24S 第 4、6 题; 25S 第 3-4 题; 25F 第 3、5 题	A 级 ; 可选停止条件是必查项
马尔可夫链、随机游动与网络	PL 第 6-8 章; D 第 5 章	24S 第 4-5 题; 24F 第 4 题树上随机游动	核心为 A 级 , 网络方法为 B 级
泊松过程与布朗运动	PL 第 9、11 章; D 第 3.7、7 章	24S 第 6 题; 24F 第 6 题; 25S 第 5 题; 25F 第 5 题; 26S 第 4 题	A 级 ; 反射、尺度、强马尔可夫须熟练

考纲模块	主要资料锚点	历年题中的主要表现	优先级与深度
分枝过程、Gaussian process、Brownian bridge、随机矩阵	PL 第 5.4、10 章; D 分枝与 Brownian bridge	24F 第 6 题; 25F 第 6 题; 26S 第 5-6 题	B 级 ; 按真题所需深度展开
常见分布族与参数化	SL 常见分布; BD 附录 A-B	五次试卷均大量使用正态、Gamma、Poisson、Beta、均匀、指数、离散均匀	A 级 ; 支撑、矩、变换与换算必须准确
指数族、满秩与弯曲指数族	SL 指数族; BD 第 1.6 节	充分性、完全性、MLR、MLE 与 Fisher 信息的统一背景	A 级 ; 结构与自然参数空间须掌握
随机样本、次序统计量、正态样本、Delta 法	SL 第 4-5 章; BD 附录 B.3	24F 第 2、9-10 题; 25S 第 1、9-10 题; 26S 第 8 题	A 级 ; 精确分布与渐近分布需区分
充分、极小充分、完全、辅助与数据简化	SL 第 6 章; BD 第 1.5 节	24S 第 11 题; 24F 第 10 题; 25S 第 9 题; 25F 第 7-9 题; 26S 第 10 题	A 级 ; 因子分解、似然比判据、完全性证明须会
点估计、MLE、UMVUE、Fisher 信息与 CRLB	SL 第 7 章; BD 第 2-3 章	24S 第 8-11 题; 24F 第 7-11 题; 25S 第 7-11 题; 25F 第 7-10 题; 26S 第 10-11 题	A 级 ; 存在性、唯一性与正则条件必须检查
假设检验、NP、MLR、Karlin-Rubin、LRT	SL 第 8 章; BD 第 4 章	24S 第 10 题; 24F 第 7 题; 25S 第 8 题; 25F 第 11 题; 26S 第 7 题	A 级 ; 两侧 UMP 不存在与离散随机化是重点
Bayes、广义 Bayes、minimax、admissibility	SL Bayes 估计; BD 第 1.2-1.3、3 章	24S 第 7 题; 24F 第 10 题; 25S 第 7、10 题; 25F 第 9-10 题; 26S 第 9 题	A 级 / B 级 ; 须会风险比较与极限 Bayes 论证
大样本理论、MLE、Wilks、Wald、score	SL 第 10 章; BD 第 5-6 章	24F 第 2、9、11 题; 25S 第 8-11 题; 26S 第 10-11 题	A 级 ; 展开式与条件核查并重
正则与非正则模型	SL 对参数相关支撑的警示; BD 正则模型与 MLE	24F 第 11 题; 25S 第 11 题; 26S 第 11 题; 多道均匀与移位指数题	A 级 ; 不能机械套用 $\sqrt{n}$ 正态理论
Gauss-Markov 与基础线性模型	BD 第 6.1 节; SL 多参数信息	24F 第 8 题	B 级 ; 证明 BLUE 与信息矩阵

考试重点与证明深度分级表

主题	建议证明层级	资格考试要求
概率测度连续性、单调类思想、CDF 性质	【必须会完整证明】	能从可列可加推出连续性；能说明 CDF 的右连续性、跳跃与原子。
收敛关系与反例、一致可积与 L^1	【必须会完整证明】	不仅会画蕴含图，还要会构造逆命题反例，并写出 UI 加依概率收敛推出 L^1 的论证。
Borel–Cantelli、WLLN、SLLN、截断法	【必须会复现证明框架】	BC 两个方向必须会；大数律证明按课程版本掌握主线和条件。
Lévy 连续性、经典 CLT、Lindeberg–Feller	【必须会复现证明框架】	特征函数展开、Lindeberg 截断和三角阵列条件必须能够复现。
条件期望、tower property、独立性条件化	【必须会完整证明】	定义、存在唯一性口径、投影性质和常用恒等式须严谨。
鞅收敛、Doob 不等式、可选停止	【必须会复现证明框架】	不同版本的条件不能混用；真题中需能对具体停时逐项检查。
有限/可数马尔可夫链与随机游动	【必须会复现证明框架】	不可约、周期、常返、正常返、平稳、可逆与极限分布的逻辑关系须清楚。
泊松过程与布朗运动	【必须会复现证明框架】	等待时间、独立平稳增量、反射原理、尺度性、强马尔可夫与首次时。
因子分解、极小充分、完全性	【必须会完整证明】	会从似然比判据构造极小充分，会用幂级数/变换证明完全性。
Rao–Blackwell、Lehmann–Scheffé、Basu	【必须会完整证明】	条件期望降方差、唯一 UMVUE、完全充分与辅助独立的条件必须完整。
MLE、Fisher 信息、Cramér–Rao	【必须会复现证明框架】	区分存在、有限、唯一、内点；交换微分积分和信息恒等式须核查。
Neyman–Pearson、MLR、Karlin–Rubin	【必须会完整证明】	会由似然比排序构造 MP/UMP，能说明两侧 UMP 不存在或需随机化。
Bayes、minimax、admissibility	【必须会复现证明框架】	会按损失求后验风险最小化，并用常风险或极限 Bayes 证明 minimax。
Delta、MLE 渐近正态、Wilks、Wald/score	【必须会复现证明框架】	会写 Taylor 展开、随机余项、Slutsky 和信息矩阵；边界和非正则情形须主动排除。
Brownian bridge/GFF、树上游动、GW、随机矩阵	【真题驱动补充】	只展开到代表性真题所需深度，但必须能识别其背后的高斯、鞅、生成函数或电网络工具。

全课程知识依赖图



考试重点

复习顺序不应从“估计”或“检验”孤立开始。统计理论中几乎所有高分题都依赖三条基础链：
分布与变换 → 充分统计量/似然 → 最优性或检验, LLN/CLT → 连续映射/Slutsky/Delta →
MLE 与 LRT 渐近理论, 条件期望 → Rao-Blackwell/Bayes 后验 → 风险改进与 UMVUE。任何一条
基础链存在断点，都会在综合题中表现为条件遗漏或无法解释关键步骤。



符号、参数化和分布约定

概率与收敛


记号	约定
$(\Omega, \mathcal{F}, \mathbb{P})$	完备概率空间；若完备性不影响问题，将不重复声明。
$\sigma(X), \sigma(X_1, \dots, X_n)$	由随机变量生成的 σ -代数。
$\text{Law}(X), X \stackrel{d}{=} Y$	X 的分布；等分布不表示定义在同一空间，更不表示几乎处处相等。
$X_n \xrightarrow{\text{a.s.}} X, X_n \xrightarrow{\mathbb{P}} X, X_n \xrightarrow{L^p} X, X_n \xrightarrow{d} X$	分别表示几乎处处、依概率、 L^p 、依分布收敛。
$\mathbf{1}_A$	事件 A 的示性函数。
$F^{-1}(u)$	广义分位数 $\inf\{x : F(x) \geq u\}$ 。

统计模型与样本

记号	约定
$\{P_\theta : \theta \in \Theta\}$	统计模型；参数化默认可识别，否则将明确指出。
$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} P_\theta$	独立同分布随机样本；观测值记为小写 $x_1, \dots, x_n$ 。
$\bar{X}$	$n^{-1} \sum_{i=1}^n X_i$ 。
S^2	$(n-1)^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ；若使用分母 n ，另记为 $\hat{\sigma}_n^2$ 。
$X_{(1)} \leq \dots \leq X_{(n)}$	次序统计量。
$L(\theta; x), \ell(\theta; x)$	似然与对数似然；MLE 记为 $\hat{\theta}$ ，但不预设其存在或唯一。
$U_n(\theta), I_n(\theta), J_n(\theta)$	score、期望 Fisher 信息、观测信息： $U_n = \partial_\theta \ell, I_n = \mathbb{E}_\theta U_n^2, J_n = -\partial_\theta^2 \ell$ 。 多参数时为向量/矩阵。
$\varphi(x) \in [0, 1]$	检验函数； $\varphi = 1$ 表示拒绝 H_0 ，介于 0 与 1 时表示随机化拒绝概率。

常见分布的统一参数化

- (1) $X \sim \text{Exp}(\lambda)$ 默认使用**率参数**： $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{(0, \infty)}(x)$ 。
- (2) $X \sim \text{Gamma}(\alpha, \theta)$ 默认使用 **shape-scale**： $f(x) = \frac{x^{\alpha-1} e^{-x/\theta}}{\Gamma(\alpha) \theta^\alpha} \mathbf{1}_{(0, \infty)}(x)$ ， $\mathbb{E}X = \alpha\theta$ ， $\text{Var}(X) = \alpha\theta^2$ 。
若使用 **shape-rate** (α, β) ，则 $\beta = 1/\theta$ 。



- (3) $G \sim \text{Geom}(p)$ 表示“首次成功所在试验次数”，支撑为 $\{1, 2, \dots\}$ ， $\mathbb{P}(G = k) = p(1-p)^{k-1}$ 。“首次成功前失败数”为 $G - 1$ ，支撑从 0 开始。
- (4) $N \sim \text{NegBin}(r, p)$ 默认表示第 r 次成功前的失败数，支撑为 $\{0, 1, \dots\}$ ： $\mathbb{P}(N = k) = \binom{k+r-1}{k} p^r (1-p)^k$ 。若题目把总试验次数作为随机变量，则为 $N + r$ 。
- (5) $N(\mu, \sigma^2)$ 的第二参数始终是方差；多元正态写为 $N_d(\mu, \Sigma)$ 。
- (6) $\chi^2_\nu = \text{Gamma}(\nu/2, 2)$ ；Student t_ν 与 F_{d_1, d_2} 采用标准自由度参数化。

资料差异、疑似笔误与正文取舍

补充说明

- (1) 课程材料中 Gamma 函数有 scale 与 rate 两种写法 (λ 和 $\frac{1}{\beta}$)，真题亦曾明确给出 scale 形式。正文统一采用 shape-scale，并在需要时即时换算。
- (2) 几何与负二项在不同资料中有“试验次数”与“失败次数”两套支撑约定。正文以上述约定为主，所有例题先写支撑再计算。
- (3) 统计讲义的个别分布汇总页存在疑似排版或转录错误；正文不沿用可疑公式，而使用由 PMF/PDF 定义直接核验后的标准公式。
- (4) Basu 定理的标准充分条件是“完全且充分”；若另加“极小充分”，只是更强但非必要的条件。正文使用标准版本，并注明完全充分统计量在通常支配模型中本身已具有极小性意义。
- (5) “MLE 相合”，“MLE 渐近正态”，“Wilks 定理”一律不写成无条件事实。正文每次使用时均检查可识别性、真参数内点、参数无关支撑、可微性、信息非退化以及余项控制。



第一部分

概率论

第一章 概率空间、随机变量、分布与积分基础

1.1 考纲定位、真题表现与前置知识

考试重点

本章整体为 **A 级**。它在真题中通常不以“背定义”的方式单独出现，而是嵌入联合分布、条件期望、收敛、鞅、高斯向量、充分统计量和大样本推导。资格考试的失分往往不是不会计算，而是：没有写支撑集；把密度当概率；在不满足条件时交换极限与期望；把等分布当成几乎处处相等；或只检查两两独立。

往年真题

代表性出现方式包括：24F 第 1 题的四阶矩与三重卷积，25S 第 1 题的极值联合分布与给定 $\sigma(Y_n)$ 的条件期望，25S 第 2 题的协方差矩阵半正定性，25F 第 1 题的随机指数矩存在域，25F 第 2 题的条件几何区域，以及 26S 第 1 题的高斯指数倾斜。

本章所需前置知识只包括集合运算、实分析中的极限与积分、基础线性代数。后续所有概率章节都依赖本章的可测性、积分与独立性语言。

1.2 概率空间与概率测度

1.2.1 精确定义

定义 1.1 (概率空间). 概率空间是三元组 $(\Omega, \mathcal{F}, \mathbb{P})$ ，其中：


- (1) Ω 是非空样本空间；
- (2) $\mathcal{F} \subseteq 2^\Omega$ 是 σ -代数，即 $\Omega \in \mathcal{F}$ ，若 $A \in \mathcal{F}$ 则 $A^c \in \mathcal{F}$ ，若 $A_n \in \mathcal{F}$ 则 $\bigcup_{n \geq 1} A_n \in \mathcal{F}$ ；
- (3) $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$ 满足 $\mathbb{P}(\Omega) = 1$ ，并对两两不交的 $A_n \in \mathcal{F}$ 有 $\mathbb{P}(\bigcup_{n=1}^\infty A_n) = \sum_{n=1}^\infty \mathbb{P}(A_n)$ 。

注 1.2. 事件是 $\mathcal{F}$ 中的集合，而不是 Ω 的任意子集。初等有限样本空间中常取 $\mathcal{F} = 2^\Omega$ ，但在不可数空间中，可测性是定义随机变量、积分和条件期望所必需的结构。

命题 1.3 (概率测度的基本性质). 对 $A, B, A_n \in \mathcal{F}$ ：

- (1) $\mathbb{P}(\emptyset) = 0$ ；
- (2) 若 $A \subseteq B$ ，则 $\mathbb{P}(A) \leq \mathbb{P}(B)$ ；
- (3) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ ；
- (4) $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ ；
- (5) $\mathbb{P}(\bigcup_n A_n) \leq \sum_n \mathbb{P}(A_n)$ 。

证明. 由 $\Omega = \Omega \dot{\cup} \emptyset$ ，可列可加给出 $1 = 1 + \mathbb{P}(\emptyset)$ ，故 $\mathbb{P}(\emptyset) = 0$ 。若 $A \subseteq B$ ，则 $B = A \dot{\cup} (B \setminus A)$ ，因此 $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A)$ 。补集公式由 $\Omega = A \dot{\cup} A^c$ 得到。又因为 $A \cup B = A \dot{\cup} (B \setminus A)$ ，且 $B = (A \cap B) \dot{\cup} (B \setminus A)$ ，相减得容斥公式。



对次可加性, 令 $B_1 = A_1$, $B_n = A_n \setminus \bigcup_{j < n} A_j$, 则 B_n 两两不交, $B_n \subseteq A_n$, 且 $\bigcup_n B_n = \bigcup_n A_n$ 。故 $\mathbb{P}(\bigcup_n A_n) = \sum_n \mathbb{P}(B_n) \leq \sum_n \mathbb{P}(A_n)$ 。□

1.2.2 从下连续与从上连续

定理 1.4 (概率测度的连续性). 【必须会完整证明】

- (1) 若 $A_n \uparrow A$, 即 $A_n \subseteq A_{n+1}$ 且 $A = \bigcup_n A_n$, 则 $\mathbb{P}(A_n) \uparrow \mathbb{P}(A)$ 。
- (2) 若 $A_n \downarrow A$, 即 $A_{n+1} \subseteq A_n$ 且 $A = \bigcap_n A_n$, 则 $\mathbb{P}(A_n) \downarrow \mathbb{P}(A)$ 。

证明. 对第一点, 令 $B_1 = A_1$, $B_n = A_n \setminus A_{n-1}$, $n \geq 2$ 。则 B_n 两两不交, 且 $A_n = \bigcup_{j=1}^n B_j$, $A = \bigcup_{j=1}^\infty B_j$ 。因此 $\mathbb{P}(A_n) = \sum_{j=1}^n \mathbb{P}(B_j) \uparrow \sum_{j=1}^\infty \mathbb{P}(B_j) = \mathbb{P}(A)$ 。

对第二点, $A_n^c \uparrow A^c$ 。由第一点, $\mathbb{P}(A_n^c) \uparrow \mathbb{P}(A^c)$, 故 $\mathbb{P}(A_n) = 1 - \mathbb{P}(A_n^c) \downarrow 1 - \mathbb{P}(A^c) = \mathbb{P}(A)$ 。□

考试时需要注意的地方

证明“从上连续”时, 有限测度条件在一般测度论中必须写出: 若 $\mu(A_1) < \infty$, 则 $\mu(A_n) \downarrow \mu(A)$ 。对概率测度, $\mathbb{P}(A_1) \leq 1$ 自动满足, 因此可以直接使用。

例 1.5 (无限次发生事件的可测表达). 令 $A_n \in \mathcal{F}$ 。定义 $\limsup_{n \rightarrow \infty} A_n = \bigcap_{m=1}^\infty \bigcup_{n \geq m} A_n$, $\liminf_{n \rightarrow \infty} A_n = \bigcup_{m=1}^\infty \bigcap_{n \geq m} A_n$ 。前者表示 A_n 发生无限多次, 后者表示从某一时刻起总发生。两者均属于 $\mathcal{F}$ 。这一表达是 Borel–Cantelli、几乎处处收敛和路径性质的标准入口。

一些需要记忆的内容

- 递增事件取并; 递减事件取交。
- “无限多次”是 $\bigcap_m \bigcup_{n \geq m} A_n$ 。
- “最终总是”是 $\bigcup_m \bigcap_{n \geq m} A_n$ 。
- 一般测度的从上连续需要首项有限; 概率测度自动满足。

1.3 随机变量、可测性与分布

1.3.1 随机变量与生成的 σ -代数

定义 1.6 (随机变量与随机向量). 设 $(\Omega, \mathcal{F})$ 为可测空间。函数 $X: \Omega \rightarrow \mathbb{R}$ 称为实值随机变量, 若对每个 Borel 集 $B \in \mathcal{B}(\mathbb{R})$, $X^{-1}(B) = \{\omega: X(\omega) \in B\} \in \mathcal{F}$ 。更一般地, $X: \Omega \rightarrow \mathbb{R}^d$ 可测时称为随机向量。

命题 1.7 (半直线判别). 函数 $X: \Omega \rightarrow \mathbb{R}$ 是随机变量, 当且仅当对每个 $x \in \mathbb{R}$, $\{X \leq x\} \in \mathcal{F}$ 。只要求对所有有理数 $x \in \mathbb{Q}$ 成立也足够。

证明. 必要性直接来自 $(-\infty, x] \in \mathcal{B}(\mathbb{R})$ 。反之, 令 $\mathcal{G} = \{B \in \mathcal{B}(\mathbb{R}): X^{-1}(B) \in \mathcal{F}\}$ 。逆像保持补集与可列并, 因此 $\mathcal{G}$ 是 σ -代数。若所有半直线 $(-\infty, x]$ 均属于 $\mathcal{G}$, 而这些半直线生成 $\mathcal{B}(\mathbb{R})$, 则 $\mathcal{G} = \mathcal{B}(\mathbb{R})$ 。若只对有理端点成立, 由 $(-\infty, x] = \bigcap_{q \in \mathbb{Q}, q > x} (-\infty, q]$ 即可扩展到任意实数端点。□

定义 1.8 (由随机变量生成的 σ -代数). $\sigma(X)$ 是使 X 可测的最小 σ -代数: $\sigma(X) = \{X^{-1}(B): B \in \mathcal{B}(\mathbb{R})\}$ 。对随机向量 $X = (X_1, \dots, X_d)$, 记 $\sigma(X) = \sigma(X_1, \dots, X_d)$ 。

命题 1.9 (可测函数复合). 若 $X: \Omega \rightarrow \mathbb{R}^d$ 可测, $g: \mathbb{R}^d \rightarrow \mathbb{R}^k$ Borel 可测, 则 $g(X)$ 可测。

证明. 对任意 $B \in \mathcal{B}(\mathbb{R}^k)$, $\{g(X) \in B\} = \{X \in g^{-1}(B)\} \in \mathcal{F}$, 因为 $g^{-1}(B) \in \mathcal{B}(\mathbb{R}^d)$. □

1.3.2 分布、分布函数、PMF 与 PDF

定义 1.10 (分布). 随机变量 X 的分布是推前概率测度 $\text{Law}(X)(B) = \mathbb{P}(X \in B)$, $B \in \mathcal{B}(\mathbb{R})$. 其累积分布函数为 $F_X(x) = \mathbb{P}(X \leq x)$ 。

定理 1.11 (分布函数的刻画). 函数 $F: \mathbb{R} \rightarrow [0, 1]$ 是某个实值随机变量的 CDF, 当且仅当:

- (1) F 单调不减;
- (2) F 右连续;
- (3) $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow \infty} F(x) = 1$ 。

并且 $\mathbb{P}(X < x) = F_X(x-)$, $\mathbb{P}(X = x) = F_X(x) - F_X(x-)$ 。

必要性的证明. 单调性来自事件包含: 若 $x \leq y$, 则 $\{X \leq x\} \subseteq \{X \leq y\}$. 取 $x_n \downarrow x$, 事件 $\{X \leq x_n\} \downarrow \{X \leq x\}$, 由测度从上连续, $F(x_n) \downarrow F(x)$, 故右连续. 极限条件分别由 $\{X \leq x\} \uparrow \Omega$ 和 $\{X \leq x\} \downarrow \emptyset$ 得到. 最后, 若 $x_n \uparrow x$, 则 $\{X \leq x_n\} \uparrow \{X < x\}$, 故 $\mathbb{P}(X < x) = F(x-)$, 原子公式随即成立. □

补充说明

充分性的构造可取 $U \sim \text{Unif}(0, 1)$, 令 $X = F^{-1}(U)$, $F^{-1}(u) = \inf\{x: F(x) \geq u\}$. 验证 $\{F^{-1}(U) \leq x\} = \{U \leq F(x)\}$, 即可得到 $\mathbb{P}(X \leq x) = F(x)$. 此构造也是逆变换模拟法的理论基础。

定义 1.12 (PMF 与 PDF). 若 X 取值于可数集 S , 其概率质量函数为 $p_X(x) = \mathbb{P}(X = x)$, $x \in S$. 若存在非负可积函数 f_X 使得 $F_X(x) = \int_{-\infty}^x f_X(t) dt$, 则称 X 绝对连续, f_X 是其概率密度函数。

易错点与失分点

- (1) 连续型随机变量满足 $\mathbb{P}(X = x) = 0$, 但 $f_X(x)$ 通常不为 0; 密度不是点概率。
- (2) CDF 连续不必然有 PDF. Cantor 分布的 CDF 连续, 但不是绝对连续。
- (3) PDF 只在 Lebesgue 零测集意义下唯一; 改变一个点的密度不改变分布。
- (4) 离散、绝对连续和奇异分布可以混合出现, 不能默认“非离散即有密度”。

1.3.3 等分布、几乎处处相等与可识别性

概念比较

概念	数学含义	关系
$X = Y$ a.s.	$\mathbb{P}(X = Y) = 1$, 要求定义在同一概率空间	推出 $X \stackrel{d}{=} Y$
$X \stackrel{d}{=} Y$	$\text{Law}(X) = \text{Law}(Y)$, 只比较边缘分布	不推出 $X = Y$ a.s., 也不决定联合结构
$P_{\theta_1} = P_{\theta_2}$	两个参数值产生同一观测分布	若 $\theta_1 \neq \theta_2$, 参数化不可识别

同分布不等于几乎处处相等

在 $\Omega = (0, 1)$ 上令 $U(\omega) = \omega$, $V(\omega) = 1 - \omega$ 。则 $U, V \sim \text{Unif}(0, 1)$, 所以 $U \stackrel{d}{=} V$; 但 $\mathbb{P}(U = V) = \mathbb{P}(U = 1/2) = 0$, 故二者不几乎处处相等。

1.4 期望、积分与极限交换**1.4.1 Lebesgue 期望的定义层次**

定义 1.13 (期望). 对非负随机变量 X , 定义 $\mathbb{E}X = \int_{\Omega} X \, d\mathbb{P} \in [0, \infty]$ 。对一般实值随机变量, 写 $X = X^+ - X^-$, 其中 $X^+ = \max(X, 0)$, $X^- = \max(-X, 0)$ 。若 $\mathbb{E}X^+ < \infty$ 或 $\mathbb{E}X^- < \infty$ 至少一个成立, 则 $\mathbb{E}X = \mathbb{E}X^+ - \mathbb{E}X^-$ 。若 $\mathbb{E}|X| < \infty$, 则称 X 可积, 记 $X \in L^1$ 。

注 1.14. 当 X 既有正无穷期望部分又有负无穷期望部分时, $\mathbb{E}X$ 不定义; 不能写成“ $\infty - \infty = 0$ ”。线性性质也只在各项表达式有意义时使用。

命题 1.15 (LOTUS). 若 g Borel 可测, 且相应期望有定义, 则 $\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \text{Law}(X)(dx)$ 。特别地, 离散型与绝对连续型分别为 $\mathbb{E}[g(X)] = \sum_x g(x)p_X(x)$, $\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x)f_X(x) \, dx$ 。

1.4.2 三大收敛定理

定理 1.16 (单调收敛定理). 若 $0 \leq X_n \uparrow X$ a.s., 则 $\mathbb{E}X_n \uparrow \mathbb{E}X$, 允许极限为 $+\infty$ 。

定理 1.17 (Fatou 引理). 若 $X_n \geq 0$, 则 $\mathbb{E}[\liminf_{n \rightarrow \infty} X_n] \leq \liminf_{n \rightarrow \infty} \mathbb{E}X_n$ 。

定理 1.18 (控制收敛定理). **【必须会完整证明】** 若 $X_n \rightarrow X$ a.s., 且存在 $Y \in L^1$ 使得 $|X_n| \leq Y$ a.s. 对所有 n 成立, 则 $X \in L^1$, 并且 $\mathbb{E}|X_n - X| \rightarrow 0$, $\mathbb{E}X_n \rightarrow \mathbb{E}X$ 。

证明. 由 $|X_n| \leq Y$ 且 $X_n \rightarrow X$ a.s., 取极限得 $|X| \leq Y$ a.s., 故 $X \in L^1$ 。又 $0 \leq |X_n - X| \leq 2Y$ 。对非负随机变量 $2Y - |X_n - X|$ 使用 Fatou 引理: $\mathbb{E}(2Y) = \mathbb{E}[\liminf_n (2Y - |X_n - X|)] \leq \liminf_n \mathbb{E}[2Y - |X_n - X|]$ 。右端等于 $2\mathbb{E}Y - \limsup_n \mathbb{E}|X_n - X|$, 故 $\limsup_n \mathbb{E}|X_n - X| \leq 0$ 。于是 $\mathbb{E}|X_n - X| \rightarrow 0$ 。最后 $|\mathbb{E}X_n - \mathbb{E}X| \leq \mathbb{E}|X_n - X| \rightarrow 0$ 。□

交换极限与期望的检查顺序

看到 $\lim_n \mathbb{E}X_n$ 时, 按以下顺序判断:

- (1) 是否非负且单调? 若是, 用 MCT;
- (2) 是否非负但不单调? Fatou 只给不等式;
- (3) 是否存在一个与 n 无关的可积控制变量? 若是, 用 DCT;
- (4) 是否只有依概率收敛? 需再找一致可积性, 不能直接交换;
- (5) 是否只有 L^1 收敛? 可直接用 $|\mathbb{E}X_n - \mathbb{E}X| \leq \mathbb{E}|X_n - X|$ 。

逐点收敛不能单独推出期望收敛

令 $U \sim \text{Unif}(0, 1)$, $X_n = n\mathbf{1}_{(0, 1/n)}(U)$ 。则对几乎每个 $U > 0$, 最终 $U > 1/n$, 故 $X_n \rightarrow 0$ a.s.; 但 $\mathbb{E}X_n = n \cdot \frac{1}{n} = 1$ 。失败原因是不存在统一可积控制变量, 且 $\{X_n\}$ 不一致可积。

1.4.3 Tonelli 与 Fubini

定理 1.19 (Tonelli–Fubini). 设 $h: \Omega_1 \times \Omega_2 \rightarrow [-\infty, \infty]$ 可测。

- (1) 若 $h \geq 0$, 则可交换积分次序, 允许结果为 $+\infty$: $\int h d(\mathbb{P}_1 \otimes \mathbb{P}_2) = \int (\int h(\omega_1, \omega_2) d\mathbb{P}_2) d\mathbb{P}_1$.
- (2) 若 $\int |h| d(\mathbb{P}_1 \otimes \mathbb{P}_2) < \infty$, 则两次迭代积分均绝对可积, 并可交换次序。

易错点与失分点

“把求和移到期望外”本质上也是 Tonelli/Fubini。若各项非负, 可直接用 Tonelli; 若有正有负, 必须证明绝对可积或用其他收敛定理。随机级数题中这是常见隐性得分点。

1.4.4 尾积分与示性函数分解

命题 1.20 (尾积分公式). 若 $X \geq 0$, 则 $\mathbb{E}X = \int_0^\infty \mathbb{P}(X > t) dt$ 。若 $p > 0$, 则 $\mathbb{E}X^p = p \int_0^\infty t^{p-1} \mathbb{P}(X > t) dt$ 。

证明. 逐点有 $X(\omega) = \int_0^\infty \mathbf{1}_{\{X(\omega) > t\}} dt$ 。由 Tonelli, $\mathbb{E}X = \int_0^\infty \mathbb{E} \mathbf{1}_{\{X > t\}} dt = \int_0^\infty \mathbb{P}(X > t) dt$ 。对 X^p 使用同一公式并作变量代换 $u = t^p$ 即得第二式。□

Indicator 分解模板

若目标是“某类对象的个数”或“某事件出现次数”, 优先写 $N = \sum_{j \in J} \mathbf{1}_{A_j}$, $\mathbb{E}N = \sum_{j \in J} \mathbb{P}(A_j)$, 其中无需 A_j 独立。若 J 可数且项非负, Tonelli 保证交换求和与期望。26S 的随机面条环数问题正是这一思想与逐步条件化的组合, 后文在真题驱动补充中完整展开。

1.5 矩、方差、协方差与基本不等式

定义 1.21. 若 $\mathbb{E}|X|^k < \infty$, 称 $\mathbb{E}X^k$ 为 k 阶原点矩。若 $\mathbb{E}X^2 < \infty$, 定义 $\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}X^2 - (\mathbb{E}X)^2$ 。若 $X, Y \in L^2$, 定义 $\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$, 若方差均为正, 定义 $\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$ 。

命题 1.22 (协方差展开). 若 $X_1, \dots, X_n \in L^2$, 则 $\text{Var}(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j)$ 。特别地, 若 X_i 两两不相关, 则方差可加; 独立且二阶矩有限必然两两不相关。

命题 1.23 (协方差矩阵半正定). 设 $X \in \mathbb{R}^d$ 且各分量二阶可积, $\Sigma = \text{Cov}(X)$ 。则 Σ 对称半正定, 即对任意 $a \in \mathbb{R}^d$, $a^\top \Sigma a = \text{Var}(a^\top X) \geq 0$ 。

证明. 由协方差双线性, $a^\top \Sigma a = \mathbb{E}[(a^\top (X - \mathbb{E}X))^2] = \text{Var}(a^\top X) \geq 0$ 。□

往年真题

25S 第 2 题里面给出三维中心高斯向量协方差矩阵 $\begin{pmatrix} 1 & \rho & \tau \\ \rho & 1 & 0 \\ \tau & 0 & 1 \end{pmatrix}$ 。取 $a = (1, -\rho, -\tau)^\top$ 或直接计算行列式, 半正定性给出 $1 - \rho^2 - \tau^2 \geq 0$ 。这个步骤的本质不是“高斯密度非负”, 而是任何协方差矩阵都必须半正定。

定理 1.24 (Cauchy-Schwarz). 若 $X, Y \in L^2$, 则 $|\mathbb{E}(XY)| \leq \sqrt{\mathbb{E}X^2 \mathbb{E}Y^2}$. 因而 $|\text{Cov}(X, Y)| \leq \sqrt{\text{Var}(X) \text{Var}(Y)}$, 故 $|\text{Corr}(X, Y)| \leq 1$.

证明. 若 $\mathbb{E}Y^2 = 0$, 结论平凡. 否则对任意 $t \in \mathbb{R}$, $0 \leq \mathbb{E}(X - tY)^2 = \mathbb{E}X^2 - 2t\mathbb{E}(XY) + t^2\mathbb{E}Y^2$. 取使二次式最小的 $t = \mathbb{E}(XY)/\mathbb{E}Y^2$, 得到 $(\mathbb{E}XY)^2 \leq \mathbb{E}X^2 \mathbb{E}Y^2$. $\square$

一些需要记忆的内容

- 独立 $\Rightarrow$ 不相关 (需二阶矩); 逆命题一般错误。
- 联合高斯时, 不相关 $\Rightarrow$ 独立; “各自边缘正态”仍不够。
- 协方差矩阵必须对称半正定; 正定对应无非平凡线性组合方差为零。
- $|\text{Corr}| = 1$ 当且仅当中心化变量在线性意义下几乎处处共线。

1.6 条件概率、全概率、Bayes 与独立性

1.6.1 事件条件化

定义 1.25 (条件概率). 若 $\mathbb{P}(B) > 0$, 定义 $\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$. 对固定 B , $A \mapsto \mathbb{P}(A | B)$ 是一个概率测度。

定理 1.26 (全概率与 Bayes 公式). 设 $\{B_j\}_{j \in J}$ 是可数可测分割, $\mathbb{P}(B_j) > 0$.

- (1) 对任意事件 A , $\mathbb{P}(A) = \sum_{j \in J} \mathbb{P}(A | B_j) \mathbb{P}(B_j)$.
- (2) 若 $\mathbb{P}(A) > 0$, 则 $\mathbb{P}(B_k | A) = \frac{\mathbb{P}(A | B_k) \mathbb{P}(B_k)}{\sum_j \mathbb{P}(A | B_j) \mathbb{P}(B_j)}$.

证明. 因为 $A = \bigcup_j (A \cap B_j)$, 可列可加给出 $\mathbb{P}(A) = \sum_j \mathbb{P}(A \cap B_j) = \sum_j \mathbb{P}(A | B_j) \mathbb{P}(B_j)$. 再由条件概率定义 $\mathbb{P}(B_k | A) = \mathbb{P}(A \cap B_k) / \mathbb{P}(A)$, 代入分子和全概率表达式即可. $\square$

易错点与失分点

条件概率 $\mathbb{P}(A | B)$ 在 B 固定且 $\mathbb{P}(B) > 0$ 时是一个数; 而给定随机变量或 σ -代数的条件期望通常是随机变量. 不能把二者混为“在条件下把参数代进去”. 一般条件概率核将在条件期望章节处理。

1.6.2 事件与随机变量的独立性

定义 1.27 (相互独立). 事件族 $\{A_i : i \in I\}$ 相互独立, 若对每个有限互异指标集合 $i_1, \dots, i_k$, $\mathbb{P}\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k \mathbb{P}(A_{i_j})$. 随机变量族 $\{X_i\}$ 相互独立, 若 $\sigma(X_i)$ 相互独立; 等价地, 对所有 Borel 集 B_i , 有限维联合概率分解为边缘概率乘积。

定义 1.28 (两两独立). 若任意 $i \neq j$ 都有 A_i 与 A_j 独立, 则称事件族两两独立. 随机变量的两两独立作同样定义。

两两独立不推出相互独立

令 U, V 独立且 $\mathbb{P}(U = 1) = \mathbb{P}(U = -1) = 1/2$, V 同分布, 定义 $X = U$, $Y = V$, $Z = UV$. 任意两个变量都独立. 例如 $\mathbb{P}(X = 1, Z = 1) = \mathbb{P}(U = 1, V = 1) = \frac{1}{4} = \mathbb{P}(X = 1)\mathbb{P}(Z = 1)$. 其他取值类似. 然而 $XYZ = 1$ a.s., 所以 $\mathbb{P}(X = 1, Y = 1, Z = -1) = 0 \neq \frac{1}{8}$. 故三者不相互独立。

命题 1.29 (独立性的期望判据). 若 X, Y 独立, $f(X), g(Y)$ 可积, 则 $\mathbb{E}[f(X)g(Y)] = \mathbb{E}f(X)\mathbb{E}g(Y)$ 。反之, 若对所有有界 Borel 函数 f, g 均有上述分解, 则 X, Y 独立。

证明. 独立意味着联合分布为乘积测度。由 Fubini, $\mathbb{E}[f(X)g(Y)] = \int f(x)g(y) \text{Law}(X)(dx) \text{Law}(Y)(dy) = \mathbb{E}f(X)\mathbb{E}g(Y)$ 。反之取 $f = \mathbf{1}_A, g = \mathbf{1}_B$, 得到 $\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B)$ 。□

概念比较

概念	检查对象	典型后果
事件独立	交集概率是否分解	条件概率不变
随机变量独立	所有 Borel 集或联合分布	可积函数期望分解
不相关	仅 $\text{Cov}(X, Y) = 0$	只控制二阶线性关系
联合高斯且不相关	协方差为零	推出独立

1.7 随机变量函数的分布：五种标准方法

考试重点

函数分布题的第一步不是求导, 而是写清原支撑、映射后的支撑和逆像个数。资格考试中, 少写一个分支、漏绝对值、把联合支撑当矩形, 都会造成整题后续错误。

1.7.1 方法一：CDF 法

对 $Y = g(X)$, 直接从 $F_Y(y) = \mathbb{P}(g(X) \leq y)$ 出发。该法最稳健, 适合最大值、最小值、绝对值、平方、比值和非单调映射。

例 1.30 (最大值与最小值). 若 $X_1, \dots, X_n$ 独立同分布, CDF 为 F , 令 $M_n = \max_i X_i, m_n = \min_i X_i$, 则 $\mathbb{P}(M_n \leq x) = F(x)^n, \mathbb{P}(m_n > x) = \mathbb{P}(X_1 > x, \dots, X_n > x) = [1 - F(x)]^n$, 因而 $F_{m_n}(x) = 1 - [1 - F(x)]^n$ 。

1.7.2 方法二：单调变换与一维 Jacobian

若 g 在 X 的支撑上严格单调、可微, 且逆函数可微, 则 $f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$, $y \in g(\text{supp } X)$ 。绝对值不可省略。若 g 递减, CDF 法中应写 $F_Y(y) = \mathbb{P}(X \geq g^{-1}(y))$, 并注意原子修正; 密度公式因绝对值仍保持同一形式。

1.7.3 方法三：多对一变换

若方程 $g(x) = y$ 在支撑内有有限多个正则根 $x_1(y), \dots, x_m(y)$, 则 $f_Y(y) = \sum_{j=1}^m f_X(x_j(y)) \left| \frac{dx_j(y)}{dy} \right|$ 。

例 1.31 (平方变换). 若 $Y = X^2$, 则对 $y > 0$, 逆像为 $\pm\sqrt{y}$, 故 $f_Y(y) = \frac{f_X(\sqrt{y}) + f_X(-\sqrt{y})}{2\sqrt{y}}$ 。若 $X \sim \mathcal{N}(0, 1)$, 得到 $Y \sim \chi_1^2$ 。

1.7.4 方法四：多维 Jacobian

设 $(U, V) = T(X, Y)$ 是一一可微变换，逆变换为 $(x, y) = T^{-1}(u, v)$ ，则

$$f_{U,V}(u, v) = f_{X,Y}(x(u, v), y(u, v)) \left| \det \frac{\partial(x, y)}{\partial(u, v)} \right|,$$

并且必须把原支撑映射为 (u, v) 的新支撑。

二维 Jacobian 标准书写

- (1) 写出变换 $(u, v) = T(x, y)$;
- (2) 解出逆变换 $(x, y) = T^{-1}(u, v)$;
- (3) 由原支撑推出新支撑，最好用不等式逐项转换；
- (4) 计算逆 Jacobian 行列式并取绝对值；
- (5) 代入联合密度；
- (6) 对一个变量积分，检查边缘密度是否归一化。

1.7.5 方法五：卷积

若 X, Y 独立且有密度， $S = X + Y$ ，则 $f_S(s) = \int_{-\infty}^{\infty} f_X(x) f_Y(s-x) dx$ 。积分上下限应由 $x \in \text{supp } X$ 与 $s-x \in \text{supp } Y$ 的交集决定，而不是机械写 $(-\infty, \infty)$ 后忽略支撑。

例 1.32 (两个均匀变量之和). 若 $X, Y \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$, 则 $f_{X+Y}(s) = \int \mathbf{1}_{\{0 < x < 1\}} \mathbf{1}_{\{0 < s-x < 1\}} dx = \begin{cases} s, & 0 < s < 1, \\ 2-s, & 1 \leq s < 2, \\ 0, & \text{其他.} \end{cases}$

三重卷积给出 24F 第 1 题中 S_3 的分段二次密度；后文在常见计算模板中给出一般 Irwin-Hall 形式。

易错点与失分点

函数分布题的常见错误：

- (1) 不写 y 的支撑；
- (2) Jacobian 用了正变换而非逆变换，却未取倒数；
- (3) 多对一映射只保留一个逆像；
- (4) 条件分布中忘记除以条件事件概率；
- (5) 卷积不根据 s 分段；
- (6) 把联合 CDF 的偏导直接当密度，却未检查绝对连续性与区域边界。

1.8 资格考试综合例：均匀样本的极值与条件期望

往年真题

本例对应 2025 Spring 第 1 题的数学结构： $U_1, \dots, U_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$ ，令 $X_n = \min_i U_i$ ， $Y_n = \max_i U_i$ 。要求联合分布，并计算 $\mathbb{E}[X_n \mid \sigma(Y_n)]$ 。该题同时考查联合支撑、极值分布、条件密度以及“给定随机变量的条件期望是随机变量”。

问题 1.33. 设 $n \geq 2$ ， $U_1, \dots, U_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$ 。求 (X_n, Y_n) 的联合 CDF 与联合密度，并求 $\mathbb{E}[X_n \mid \sigma(Y_n)]$ 。

解：第一步：确定联合支撑。 必有 $0 \leq X_n \leq Y_n \leq 1$ 。因此联合密度只可能位于三角区域 $0 < x < y < 1$ 。

第二步：求联合 CDF。 对 $0 \leq x \leq y \leq 1$,

$$F_{X_n, Y_n}(x, y) = \mathbb{P}(X_n \leq x, Y_n \leq y) = \mathbb{P}(Y_n \leq y) - \mathbb{P}(X_n > x, Y_n \leq y).$$

事件 $Y_n \leq y$ 等价于所有 $U_i \leq y$ ，其概率为 y^n ；事件 $X_n > x, Y_n \leq y$ 等价于所有 $U_i \in (x, y]$ ，其概率为 $(y - x)^n$ 。故 $F_{X_n, Y_n}(x, y) = y^n - (y - x)^n$ ， $0 \leq x \leq y \leq 1$ 。完整分段形式为

$$F_{X_n, Y_n}(x, y) = \begin{cases} 0, & x < 0 \text{ 或 } y < 0, \\ y^n - (y - x)^n, & 0 \leq x < y \leq 1, \\ y^n, & 0 \leq y \leq 1, x \geq y, \\ 1 - (1 - x)^n, & 0 \leq x \leq 1, y \geq 1, \\ 1, & x \geq 1, y \geq 1, \end{cases}$$

并按单调性在剩余边界情形延拓。

第三步：求联合密度。 在内部区域 $0 < x < y < 1$,

$$f_{X_n, Y_n}(x, y) = \frac{\partial^2}{\partial x \partial y} [y^n - (y - x)^n] = n(n - 1)(y - x)^{n-2}.$$

也可用次序统计量直观推导：选择一个样本点落在 $[x, x + dx]$ 、一个落在 $[y, y + dy]$ ，其余 $n - 2$ 个落在 (x, y) ，排列数为 $n(n - 1)$ 。


第四步：求 Y_n 的边缘密度。 由 $\mathbb{P}(Y_n \leq y) = y^n$ ， $f_{Y_n}(y) = ny^{n-1}$ ， $0 < y < 1$ 。因此，对 $0 < x < y < 1$ ，
 $f_{X_n|Y_n}(x \mid y) = \frac{f_{X_n, Y_n}(x, y)}{f_{Y_n}(y)} = \frac{(n-1)(y-x)^{n-2}}{y^{n-1}}.$

第五步：计算条件均值。

$$\mathbb{E}[X_n \mid Y_n = y] = \int_0^y x \frac{(n-1)(y-x)^{n-2}}{y^{n-1}} dx.$$

令 $u = x/y$ ，则

$$\mathbb{E}[X_n \mid Y_n = y] = y(n-1) \int_0^1 u(1-u)^{n-2} du = y(n-1)B(2, n-1) = \frac{y}{n}.$$



故作为 $\sigma(Y_n)$ -可测随机变量, $\mathbb{E}[X_n | \sigma(Y_n)] = \frac{Y_n}{n} \quad \text{a.s.}$

合理性检验。 给定最大值为 y 后, 其余 $n-1$ 个点按比例落在 $(0, y)$; 最小值应随 y 线性缩放。 $n=2$ 时条件最小值在 $(0, y)$ 上均匀, 均值为 $y/2$, 与公式一致。 $\square$

考试时需要注意的地方

本题获得完整分数的关键步骤:

- (1) 明确支撑 $0 < x < y < 1$;
- (2) 联合 CDF 中正确减去“所有点位于 $(x, y]$ ”的概率;
- (3) 条件密度除以 $f_{Y_n}(y)$;
- (4) 最终答案写成 Y_n/n , 而不是只写数值函数 y/n ;
- (5) 不把“给定 $Y_n = y$ ”误解为正概率事件, 而使用条件密度或正则条件分布。

1.9 本章题型识别与标准流程

识别信号一：出现“求联合分布/函数分布”

- (1) 先写原随机向量的支撑;
- (2) 判断 CDF、卷积、Jacobian、多对一、次序统计量哪一种最短;
- (3) 若是条件分布, 先求联合量与条件变量的边缘量;
- (4) 结果积分或求和检查为 1;
- (5) 对边界与原子单独处理。

识别信号二：出现“证明可交换期望与极限”

- (1) 写明收敛方式;
- (2) 寻找单调性、非负性、统一控制或一致可积性;
- (3) 明确使用 MCT、Fatou、DCT 或 UI 定理;
- (4) 若条件不满足, 主动考虑截断并估计尾部。

识别信号三：出现“独立/不相关/高斯”

- (1) 独立性优先从联合分布分解、联合特征函数分解或生成的 σ -代数判断;
- (2) 不相关只检查协方差, 不能替代独立;
- (3) 若明确是联合高斯向量, 可用协方差为零推出独立;
- (4) 若只是每个分量边缘正态, 不得使用联合高斯结论。



1.10 本章易错点与反例速查

原陈述	判断	正确版本或反例
同分布随机变量必然相等 a.s.	错	U 与 $1 - U$ 同为均匀分布，但几乎处处不相等。
CDF 连续就一定有密度	错	还需绝对连续；Cantor 分布是连续奇异分布。
若 $X_n \rightarrow X$ a.s., 则 $\mathbb{E}X_n \rightarrow \mathbb{E}X$	错	需 DCT、UI 等附加条件； $n\mathbf{1}_{(0,1/n)}$ 是标准反例。
两两独立推出相互独立	错	Rademacher 变量 U, V, UV 两两独立但不相互独立。
不相关推出独立	错	一般错误；联合高斯是重要特例。
密度值 $f_X(x)$ 等于 $\mathbb{P}(X = x)$	错	连续型点概率为 0，密度是局部概率的变化率。
协方差矩阵可以有负特征值	错	对任意 a , $a^\top \Sigma a = \text{Var}(a^\top X) \geq 0$ 。
卷积积分总可写成固定上下限	不完整	形式可写全实线，但实际计算必须由支撑交集分段。

一些需要记忆的内容

- (1) 概率测度：可列可加 $\Rightarrow$ 单调、次可加、从下/从上连续。
- (2) 随机变量：检查半直线逆像即可； $\sigma(X)$ 是使 X 可测的最小信息集。
- (3) CDF：单调、右连续、两端极限；跳跃大小等于点质量。
- (4) 期望极限：MCT 看单调非负，Fatou 给下界，DCT 看统一可积控制。
- (5) 独立性：必须对所有有限子族检查；两两独立不够。
- (6) 函数分布：先支撑，再逆像，再 Jacobian/卷积；最后归一化。
- (7) 条件分布：联合量除以条件变量边缘量；条件期望最后必须写成条件变量的函数。



第二章 多维分布、条件分布与随机向量变换

2.1 考纲定位、重要性 with 真题表现

考试重点

本章整体为 **S 级**。多维分布与随机向量变换不仅能够直接形成计算题，而且是高斯向量、条件期望、次序统计量、充分统计量、MLE、Delta 方法和似然比检验的共同前置。资格考试中的主要失分点不是积分本身，而是：

- (1) 没有先写联合支撑；
- (2) 把联合支撑错误地当成矩形；
- (3) 条件密度忘记除以边缘密度；
- (4) Jacobian 漏绝对值或漏掉多个逆像分支；
- (5) 只写边缘分布，未说明联合结构；
- (6) 在“给定零概率事件”时仍使用初等条件概率公式。

往年真题

本章的代表性真题包括：

- 2025 Spring 第 1 题，10 分：均匀样本最小值与最大值的联合分布，以及给定 $\sigma(Y_n)$ 的条件期望；
- 2025 Fall 第 2 题，10 分：在两个三角形条件事件下求 $\max(X, Y)$ 的条件分布；
- 2025 Spring 第 2 题，10 分：三维高斯向量的协方差限制与正交分解；
- 2026 Spring 第 1 题，10 分：高斯向量在指数测度下的分布；
- 2025 Fall 第 6 题，15 分：二维高斯随机对称矩阵的特征值与特征向量；
- 2024 Fall 第 1 题，10 分：Irwin-Hall 分布的计算。

2.2 随机向量、联合分布与边缘分布

2.2.1 精确定义

定义 2.1 (随机向量). 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间。若 $X = (X_1, \dots, X_d) : \Omega \rightarrow \mathbb{R}^d$ 关于 $\mathcal{F}/\mathcal{B}(\mathbb{R}^d)$ 可测，则称 X 为 d 维随机向量。

定义 2.2 (联合分布函数). 随机向量 $X = (X_1, \dots, X_d)$ 的联合分布函数定义为

$$F_X(x_1, \dots, x_d) = \mathbb{P}(X_1 \leq x_1, \dots, X_d \leq x_d). \quad (2.1)$$

注 2.3. 多维 CDF 不仅要逐坐标单调，还必须对每一个半开矩形给出非负概率。仅检查“每个坐标方向单调”不足以保证它来自某个概率测度。

定义 2.4 (矩形增量). 设 $a_j < b_j$, 记 $R = (a_1, b_1] \times \cdots \times (a_d, b_d]$. 对 $\varepsilon = (\varepsilon_1, \dots, \varepsilon_d) \in \{0, 1\}^d$, 定义 $c_{\varepsilon,j} = \begin{cases} b_j, & \varepsilon_j = 1, \\ a_j, & \varepsilon_j = 0. \end{cases}$ 则 F 在 R 上的矩形增量为

$$\Delta_R F = \sum_{\varepsilon \in \{0,1\}^d} (-1)^{d-|\varepsilon|} F(c_{\varepsilon,1}, \dots, c_{\varepsilon,d}). \quad (2.2)$$

若 F 是联合 CDF, 则 $\Delta_R F = \mathbb{P}(X \in R) \geq 0$.

二维时,

$$\mathbb{P}(a < X \leq b, c < Y \leq d) = F_{X,Y}(b, d) - F_{X,Y}(a, d) - F_{X,Y}(b, c) + F_{X,Y}(a, c). \quad (2.3)$$

定理 2.5 (联合 CDF 的基本性质). 若 F_X 为 d 维联合 CDF, 则:

- (1) F_X 对每个坐标单调不减;
- (2) F_X 从右连续;
- (3) 若某一坐标趋于 $-\infty$, 则 $F_X \rightarrow 0$;
- (4) 若所有坐标同时趋于 $+\infty$, 则 $F_X \rightarrow 1$;
- (5) 对任意半开矩形 R , 有 $\Delta_R F_X \geq 0$.

反之, 满足适当边界条件、右连续性和全部矩形增量非负的函数唯一确定一个 $\mathbb{R}^d$ 上的概率分布。

多维 CDF 为什么必须检查矩形增量

在一维中, 区间概率由 $\mathbb{P}(a < X \leq b) = F(b) - F(a)$ 给出, 单调性保证其非负。二维中必须使用四项容斥式 (2.3); 逐坐标单调不能保证该四项差非负。更高维则对应 (2.2)。

2.2.2 边缘分布

命题 2.6 (由联合 CDF 得到边缘 CDF). 若 (X, Y) 的联合 CDF 为 $F_{X,Y}$, 则 $F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y)$, $F_Y(y) = \lim_{x \rightarrow \infty} F_{X,Y}(x, y)$ 。

证明. 事件 $\{X \leq x, Y \leq y\}$ 随 $y \uparrow \infty$ 递增到 $\{X \leq x\}$. 由概率测度从下连续, $F_{X,Y}(x, y) \uparrow \mathbb{P}(X \leq x) = F_X(x)$. 另一个结论同理。□

定义 2.7 (联合密度与边缘密度). 若存在非负可测函数 $f_{X,Y}$, 使得对所有 Borel 集 $A \subseteq \mathbb{R}^2$, $\mathbb{P}((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy$, 则称 $f_{X,Y}$ 为联合密度。边缘密度为

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx. \quad (2.4)$$

前提条件检查

公式 (2.4) 的积分范围形式上可写为全实线, 但实际计算必须根据联合支撑确定有效上下限。若联合支撑是三角形、圆盘或参数依赖区域, 直接按矩形积分通常会得到错误答案。

2.3 条件分布与条件密度

2.3.1 离散情形

若 (X, Y) 为离散随机向量, 且 $\mathbb{P}(Y = y) > 0$, 则

$$\mathbb{P}(X = x | Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}. \quad (2.5)$$

对应的条件期望为 $\mathbb{E}[g(X) | Y = y] = \sum_x g(x) \mathbb{P}(X = x | Y = y)$ 。

2.3.2 连续情形

定义 2.8 (条件密度). 若 (X, Y) 有联合密度, 且 $f_Y(y) > 0$, 定义

$$f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}. \quad (2.6)$$

于是 $\mathbb{E}[g(X) | Y = y] = \int_{\mathbb{R}} g(x) f_{X|Y}(x | y) dx$, 只要该积分有意义。

注 2.9. 对于连续型 Y , 通常 $\mathbb{P}(Y = y) = 0$, 因此不能使用 $\frac{\mathbb{P}(X \in A, Y = y)}{\mathbb{P}(Y = y)}$ 。条件密度 (2.6) 是正则条件分布的一个版本; 不同版本在 Y 的零概率取值集合上可以不同。

定理 2.10 (条件密度的归一化). 对几乎每个满足 $f_Y(y) > 0$ 的 y , $f_{X|Y}(x | y) \geq 0$, $\int_{\mathbb{R}} f_{X|Y}(x | y) dx = 1$ 。

证明. 非负性由联合密度非负得到, 并且 $\int_{\mathbb{R}} f_{X|Y}(x | y) dx = \frac{\int_{\mathbb{R}} f_{X,Y}(x, y) dx}{f_Y(y)} = \frac{f_Y(y)}{f_Y(y)} = 1$ 。 □

条件分布计算题

- (1) 写出联合支撑 D ;
- (2) 计算条件变量的边缘 PMF 或 PDF;
- (3) 写出 条件量 = $\frac{\text{联合量}}{\text{边缘量}}$;
- (4) 将联合支撑切成给定 y 后的条件支撑;
- (5) 检查条件 PMF 求和或条件 PDF 积分等于 1;
- (6) 若要求 $\mathbb{E}[X | \sigma(Y)]$, 先得到函数 $m(y)$, 最后写成 $\mathbb{E}[X | \sigma(Y)] = m(Y)$ a.s.

2.4 独立性的多维判据

定理 2.11 (随机向量独立的等价表述). 设 $X \in \mathbb{R}^p$, $Y \in \mathbb{R}^q$ 。以下表述等价:

- (1) $\sigma(X)$ 与 $\sigma(Y)$ 独立;
- (2) 对所有 Borel 集 $A \subseteq \mathbb{R}^p$, $B \subseteq \mathbb{R}^q$, $\mathbb{P}(X \in A, Y \in B) = \mathbb{P}(X \in A) \mathbb{P}(Y \in B)$;
- (3) 联合分布为乘积分布: $\text{Law}(X, Y) = \text{Law}(X) \otimes \text{Law}(Y)$;
- (4) 对所有有界 Borel 函数 g, h , $\mathbb{E}[g(X)h(Y)] = \mathbb{E}g(X) \mathbb{E}h(Y)$ 。

若联合密度存在, 则独立性等价于 $f_{X,Y}(x, y) = f_X(x) f_Y(y)$ a.e.



证明思路

由独立的 σ -代数可直接得到矩形事件概率分解；矩形类生成乘积 Borel σ -代数，再用 π - λ 或单调类论证推广。期望分解从示性函数开始，经简单函数、非负函数和有界函数逐层推广。

易错点与失分点

- (1) 联合密度在若干点上不等于边缘密度乘积不影响独立性；密度只在几乎处处意义下确定。
- (2) 若联合支撑不是边缘支撑的笛卡尔积，通常可立即判断不独立。
- (3) 条件密度不依赖 y 可以推出独立，但必须是在几乎处处意义下，并且等于边缘密度。
- (4) 两两独立不能替代多个随机变量的相互独立。

2.5 随机向量的一一变换与 Jacobian

2.5.1 一般定理

定理 2.12 (随机向量变换公式). **【必须会复现证明框架】**

设 $X \in \mathbb{R}^d$ 有密度 f_X ，其支撑包含在开集 D 中。设 $T: D \rightarrow E$ ， $Y = T(X)$ 为一一的 C^1 变换，逆变换 $T^{-1}: E \rightarrow D$ 也是 C^1 ，且 Jacobian 行列式在所考虑区域内非零。则

$$f_Y(y) = f_X(T^{-1}(y)) |\det DT^{-1}(y)| \mathbf{1}_E(y). \quad (2.7)$$

证明. 对 Borel 集 $A \subseteq E$,

$$\mathbb{P}(Y \in A) = \mathbb{P}(X \in T^{-1}(A)) = \int_{T^{-1}(A)} f_X(x) dx.$$

由多元换元公式， $\int_{T^{-1}(A)} f_X(x) dx = \int_A f_X(T^{-1}(y)) |\det DT^{-1}(y)| dy$ 。故括号中的函数是 Y 的密度。 $\square$

为什么这些条件不能静默省略

- (1) 若 T 不是一一映射，一个 y 可能有多个逆像，必须把各分支贡献相加；
- (2) 若 Jacobian 为零，局部维数可能下降，变换后分布可能集中在低维集合上而不存在通常密度；
- (3) 边界一般可忽略的前提是其概率为零；存在原子时不能自动忽略；
- (4) 必须使用逆变换的 Jacobian，或等价地使用正变换 Jacobian 的倒数。

推论 2.13 (有限多对一变换). 若对给定 y ，方程 $T(x) = y$ 有有限多个正则逆像 $x^{(1)}(y), \dots, x^{(m)}(y)$ ，则

$$f_Y(y) = \sum_{j=1}^m f_X(x^{(j)}(y)) |\det Dx^{(j)}(y)|. \quad (2.8)$$

Jacobian 题的常见步骤

- (1) 写出原支撑 D ;
- (2) 定义变换 T ;
- (3) 解出所有逆变换分支;
- (4) 把原支撑转化为新支撑 E ;
- (5) 计算逆 Jacobian, 并取绝对值;
- (6) 若多对一, 对所有逆像求和;
- (7) 检查所得密度非负且积分为 1。

2.5.2 二维常用变换

和与差 令 $U = X + Y$, $V = X - Y$ 。则 $X = \frac{U+V}{2}$, $Y = \frac{U-V}{2}$, $\left| \det \frac{\partial(x,y)}{\partial(u,v)} \right| = \frac{1}{2}$ 。

和与比例 对正随机变量, 令 $S = X + Y$, $U = \frac{X}{X+Y}$ 。逆变换为 $X = SU$, $Y = S(1-U)$, 且

$$\left| \det \frac{\partial(x,y)}{\partial(s,u)} \right| = s. \quad (2.9)$$

新支撑通常为 $s > 0, 0 < u < 1$ 。

极坐标 令 $X = R \cos \Theta$, $Y = R \sin \Theta$ 。则 $\left| \det \frac{\partial(x,y)}{\partial(r,\theta)} \right| = r$ 。必须根据原区域决定 Θ 的范围, 不能默认总是 $[0, 2\pi)$ 。

2.6 Beta-Gamma 代数: 高频标准变换**重点****S 级 【必须会完整证明】**

该结论是 Gamma、Beta、卡方、 t 、 F 分布之间关系的核心, 也是证明正态样本中均值与样本方差独立、构造枢轴量和识别共轭结构的重要工具。

定理 2.14 (Beta-Gamma 独立性). 设 $X \sim \text{Gamma}(\alpha, \theta)$, $Y \sim \text{Gamma}(\beta, \theta)$, 且 X, Y 独立, 其中 $\alpha, \beta, \theta > 0$, 两者具有相同尺度参数 θ 。定义 $S = X + Y$, $U = \frac{X}{X+Y}$ 。则 $S \sim \text{Gamma}(\alpha + \beta, \theta)$, $U \sim \text{Beta}D(\alpha, \beta)$, 并且 $S \perp U$ 。

证明. 联合密度为 $f_{X,Y}(x,y) = \frac{x^{\alpha-1}y^{\beta-1}e^{-(x+y)/\theta}}{\Gamma(\alpha)\Gamma(\beta)\theta^{\alpha+\beta}}$, $x, y > 0$ 。使用变换 $s = x + y$, $u = \frac{x}{x+y}$, 其逆变换为 $x = su$, $y = s(1-u)$, 且由 (2.9), 逆 Jacobian 为 s 。故

$$\begin{aligned} f_{S,U}(s,u) &= \frac{(su)^{\alpha-1}[s(1-u)]^{\beta-1}e^{-s/\theta}}{\Gamma(\alpha)\Gamma(\beta)\theta^{\alpha+\beta}}s \\ &= \frac{s^{\alpha+\beta-1}e^{-s/\theta}}{\Gamma(\alpha+\beta)\theta^{\alpha+\beta}} \cdot \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}u^{\alpha-1}(1-u)^{\beta-1} \end{aligned}$$

对 $s > 0, 0 < u < 1$ 成立。右侧分解为 $\text{Gamma}(\alpha + \beta, \theta)$ 密度与 $\text{Beta}D(\alpha, \beta)$ 密度之积, 因此结论成立。□

易错点与失分点

“相同尺度参数”不能省略。若 $X \sim \text{Gamma}(\alpha, \theta_1)$, $Y \sim \text{Gamma}(\beta, \theta_2)$, $\theta_1 \neq \theta_2$, 则变换后的联合密度中指数项为 $\exp\left\{-s\left(\frac{u}{\theta_1} + \frac{1-u}{\theta_2}\right)\right\}$, 不能分解为只依赖 s 与只依赖 u 的乘积, 因而通常不独立。

推论 2.15. 若 $U_1 \sim \chi_{\nu_1}^2$ 、 $U_2 \sim \chi_{\nu_2}^2$ 独立, 则 $\frac{U_1}{U_1+U_2} \sim \text{BetaD}\left(\frac{\nu_1}{2}, \frac{\nu_2}{2}\right)$, 且该比例与 $U_1 + U_2$ 独立。

2.7 真题型完整例：三角区域中的条件分布

往年真题

历年题型改写：2025 Fall 第 2 题，10 分。

令 X, Y 独立且均服从 $\text{Unif}(0, 1)$, 定义 $Z = \max(X, Y)$ 。分别求给定 $A = \{X + Y \in [0, 1]\}$, $B = \{X + Y \in [1, 2]\}$ 时 Z 的条件分布。

解：由于 (X, Y) 在单位正方形上均匀, 条件概率可转化为面积比。两个条件区域分别为单位正方形中的下三角形与上三角形: $\mathbb{P}(A) = \mathbb{P}(B) = \frac{1}{2}$ 。

第一种条件：给定 $A = \{X + Y \leq 1\}$

对 $0 \leq z \leq 1$, $\{Z \leq z\} = \{X \leq z, Y \leq z\}$ 。

当 $0 \leq z \leq 1/2$ 时, 正方形 $[0, z]^2$ 完全包含于 A , 故 $\mathbb{P}(Z \leq z, A) = z^2$ 。因此 $\mathbb{P}(Z \leq z | A) = 2z^2$ 。

当 $1/2 < z \leq 1$ 时, 在下三角形 A 中, $\{Z > z\} = \{X > z\} \cup \{Y > z\}$ 。由于 $z > 1/2$, 两个事件在 A 内不可能同时发生。每个对应小三角形面积为 $\int_z^1 (1-x) dx = \frac{(1-z)^2}{2}$ 。故 $\mathbb{P}(Z > z, A) = (1-z)^2$, 从而 $\mathbb{P}(Z \leq z | A) = \frac{\frac{1}{2} - (1-z)^2}{1/2} = 1 - 2(1-z)^2$ 。

所以条件 CDF 为

$$F_{Z|A}(z) = \begin{cases} 0, & z < 0, \\ 2z^2, & 0 \leq z \leq \frac{1}{2}, \\ 1 - 2(1-z)^2, & \frac{1}{2} < z \leq 1, \\ 1, & z > 1. \end{cases} \quad (2.10)$$

$$\text{相应条件密度为 } f_{Z|A}(z) = \begin{cases} 4z, & 0 < z < \frac{1}{2}, \\ 4(1-z), & \frac{1}{2} < z < 1, \\ 0, & \text{其他.} \end{cases}$$

第二种条件：给定 $B = \{X + Y \geq 1\}$

在 B 上必有 $Z \geq 1/2$ 。当 $1/2 \leq z \leq 1$ 时, $\{Z \leq z, B\} = \{0 \leq X, Y \leq z, X+Y \geq 1\}$ 。该区域是正方形 $[0, z]^2$ 右上角的等腰直角三角形, 两直角边长度均为 $2z-1$, 面积为 $\frac{(2z-1)^2}{2}$ 。因此 $\mathbb{P}(Z \leq z | B) = \frac{(2z-1)^2/2}{1/2} = (2z-1)^2$ 。故

$$F_{Z|B}(z) = \begin{cases} 0, & z < \frac{1}{2}, \\ (2z-1)^2, & \frac{1}{2} \leq z \leq 1, \\ 1, & z > 1. \end{cases} \quad (2.11)$$

$$\text{条件密度为 } f_{Z|B}(z) = \begin{cases} 4(2z-1), & \frac{1}{2} < z < 1, \\ 0, & \text{其他.} \end{cases}$$

□

考试时需要注意的地方

该题完整得分必须体现：

- (1) 先写 $\mathbb{P}(A) = \mathbb{P}(B) = 1/2$;
- (2) 明确 $Z \leq z$ 对应正方形 $[0, z]^2$;
- (3) 在 $z = 1/2$ 处分段;
- (4) 条件概率最后除以条件区域面积;
- (5) 给出完整 CDF 的支撑外取值，而不只给内部公式。

2.7.1 历年真题：独立均匀和的四阶矩与三重卷积

往年真题

2024 Fall 第 1 题，10 分。

设 $U_1, U_2, \dots \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$, $S_n = \sum_{k=1}^n U_k$.

- (1) 计算 $\mathbb{E}(S_n^4)$.
- (2) 求 S_3 的分布。

解. (a) 计算 $\mathbb{E}(S_n^4)$.

对 $r = 1, 2, 3, 4$, 记 $m_r = \mathbb{E}(U_1^r)$. 由于 $U_1 \sim \text{Unif}(0, 1)$, 有

$$m_r = \int_0^1 u^r \, du = \frac{1}{r+1}. \quad (2.12)$$


特别地, $m_1 = \frac{1}{2}$, $m_2 = \frac{1}{3}$, $m_3 = \frac{1}{4}$, $m_4 = \frac{1}{5}$.

将 $S_n^4 = (\sum_{i=1}^n U_i)^4$ 中的单项式按照指数分拆 4, 3+1, 2+2, 2+1+1, 1+1+1+1 分类。利用 $U_1, \dots, U_n$ 的独立同分布性, 得到

$$\mathbb{E}(S_n^4) = nm_4 + 4n(n-1)m_3m_1 + 3n(n-1)m_2^2 + 6n(n-1)(n-2)m_2m_1^2 + n(n-1)(n-2)(n-3)m_1^4. \quad (2.13)$$

指数型	总系数
4	n
3+1	$4n(n-1)$
2+2	$6\binom{n}{2} = 3n(n-1)$
2+1+1	$12n\binom{n-1}{2} = 6n(n-1)(n-2)$
1+1+1+1	$24\binom{n}{4} = n(n-1)(n-2)(n-3)$

其中各项的计数分别为：



将 $m_1 = \frac{1}{2}$, $m_2 = \frac{1}{3}$, $m_3 = \frac{1}{4}$, $m_4 = \frac{1}{5}$ 代入 (2.13), 得

$$\mathbb{E}(S_n^4) = \frac{n}{5} + \frac{n(n-1)}{2} + \frac{n(n-1)}{3} + \frac{n(n-1)(n-2)}{2} + \frac{n(n-1)(n-2)(n-3)}{16}. \quad (2.14)$$

化简后,

$$\mathbb{E}(S_n^4) = \frac{n^4}{16} + \frac{n^3}{8} + \frac{n^2}{48} - \frac{n}{120}. \quad (2.15)$$

等价地,

$$\mathbb{E}(S_n^4) = \frac{n(15n^3 + 30n^2 + 5n - 2)}{240}. \quad (2.16)$$

(b) 求 S_3 的分布。

因为 (U_1, U_2, U_3) 在单位立方体 $[0, 1]^3$ 上的联合密度恒为 1, 所以

$$F_{S_3}(x) = P(U_1 + U_2 + U_3 \leq x) = \text{Vol} \{(u_1, u_2, u_3) \in [0, 1]^3 : u_1 + u_2 + u_3 \leq x\}. \quad (2.17)$$

对任意 $y \in \mathbb{R}$, 记 $y_+ = \max\{y, 0\}$. 三维单纯形 $\{(v_1, v_2, v_3) : v_i \geq 0, v_1 + v_2 + v_3 \leq y\}$ 的体积为 $\frac{y_+^3}{3!} = \frac{y_+^3}{6}$. 对三个约束 $u_1 \leq 1$, $u_2 \leq 1$, $u_3 \leq 1$ 使用容斥原理, 得到

$$F_{S_3}(x) = \frac{1}{6} [x_+^3 - 3(x-1)_+^3 + 3(x-2)_+^3 - (x-3)_+^3]. \quad (2.18)$$

因此, S_3 的分布函数为

$$F_{S_3}(x) = \begin{cases} 0, & x < 0, \\ \frac{x^3}{6}, & 0 \leq x \leq 1, \\ \frac{x^3 - 3(x-1)^3}{6}, & 1 \leq x \leq 2, \\ 1 - \frac{(3-x)^3}{6}, & 2 \leq x \leq 3, \\ 1, & x \geq 3. \end{cases} \quad (2.19)$$

对分布函数求导, 得到概率密度函数

$$f_{S_3}(x) = \begin{cases} \frac{x^2}{2}, & 0 < x < 1, \\ \frac{-2x^2 + 6x - 3}{2}, & 1 \leq x \leq 2, \\ \frac{(3-x)^2}{2}, & 2 < x < 3, \\ 0, & \text{其他.} \end{cases} \quad (2.20)$$

故 S_3 服从参数为 3 的 Irwin-Hall 分布。

□



考试时需要注意的地方**本题的最短参考路线：**

- (1) 写出 $\mathbb{E}(U^r) = \frac{1}{r+1}$, $r = 1, 2, 3, 4$;
- (2) 按 $4, 3+1, 2+2, 2+1+1, 1+1+1+1$ 分类展开四阶矩;
- (3) 将 $F_{S_3}(x)$ 解释为单位立方体内半空间截面的体积;
- (4) 用三维单纯形体积和容斥原理得到分段 CDF;
- (5) 若题目要求“分布”，写出 CDF 已经充分；同时写出 pdf 更完整。

考试时需要注意的地方

四阶矩展开最容易遗漏的项是 $U_i^2 U_j U_k$, i, j, k 两两不同. 该类项的总系数为 $12n \binom{n-1}{2} = 6n(n-1)(n-2)$. 此外, S_3 并不服从正态分布; 它是具有支撑集 $[0, 3]$ 的分段二次密度分布。

2.8 本章易错点总结**易错点与失分点**

- (1) **错误：**由联合 CDF 求联合密度时，只求一次偏导。
改正：二维绝对连续情形应使用 $f_{X,Y}(x,y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x,y)$ a.e.
- (2) **错误：**条件密度的支撑仍使用原联合支撑。
改正：固定 $Y = y$ 后，应取联合支撑的水平截面 $D_y = \{x : (x,y) \in D\}$.
- (3) **错误：**Jacobian 使用 $\det \partial(u,v)/\partial(x,y)$ ，但不取倒数。
改正：公式 (2.7) 使用逆 Jacobian；若计算正 Jacobian，应取其绝对值倒数。
- (4) **错误：**只因 $f_{X,Y} = f_X f_Y$ 在支撑内部成立，就认定独立。
改正：还必须检查支撑是否与边缘支撑乘积一致，且等式在几乎处处意义下成立。

一些需要记忆的内容

- (1) 给出二维 CDF 时，如何从四项差计算矩形概率？
- (2) 条件密度为什么只能在 $f_Y(y) > 0$ 时用比值定义？
- (3) 若 T 是二对一变换，密度公式为什么必须对两个逆像求和？
- (4) Beta-Gamma 独立性中哪一个参数必须相同？



第三章 高斯向量、条件高斯与正交分解

3.1 定义、等价刻画与重要性

重点

S 级 【必须会完整证明】

高斯向量贯穿协方差矩阵、线性回归、条件分布、Brownian motion、Gaussian process、正态样本和随机矩阵。必须熟练区分：每个分量边缘正态 与 整个向量联合高斯。只有后者允许使用“不相关推出独立”。

定义 3.1 (高斯随机向量). 随机向量 $X = (X_1, \dots, X_d)^\top$ 称为高斯向量, 若对任意 $a \in \mathbb{R}^d$, $a^\top X$ 均服从一维正态分布, 允许方差为零的退化正态分布。

定理 3.2 (高斯向量的等价刻画). 以下表述等价:

- (1) X 是高斯向量;
- (2) 存在整数 $r \leq d$ 、矩阵 $A \in \mathbb{R}^{d \times r}$ 和 $Z \sim N_r(0, I_r)$, 使得 $X = \mu + AZ$;
- (3) X 的特征函数具有形式

$$\varphi_X(t) = \exp\left(it^\top \mu - \frac{1}{2}t^\top \Sigma t\right), \quad t \in \mathbb{R}^d, \quad (3.1)$$

其中 Σ 为对称半正定矩阵。

此时 $\mathbb{E}X = \mu$, $\text{Cov}(X) = \Sigma = AA^\top$ 。

证明思路

由半正定矩阵的谱分解, $\Sigma = Q\Lambda Q^\top$ 并取 $A = Q\Lambda^{1/2}$ 即可构造 $\mu + AZ$ 。反方向中, 对任意 a , $a^\top X = a^\top \mu + (A^\top a)^\top Z$ 是一维正态。特征函数公式则由标准正态的特征函数直接计算。

定理 3.3 (非退化高斯密度). 若 Σ 正定, 则 $X \sim N_d(\mu, \Sigma)$ 有密度

$$f_X(x) = \frac{1}{(2\pi)^{d/2}(\det \Sigma)^{1/2}} \exp\left\{-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right\}. \quad (3.2)$$

若 Σ 奇异, 则 X 集中在某个低维仿射子空间上, 通常不存在关于 d 维 Lebesgue 测度的密度。

易错点与失分点

协方差矩阵“半正定”足以定义退化高斯向量, 但写密度 (3.2) 时必须要求“正定”。若 $\det \Sigma = 0$, 不能把行列式直接代入密度公式。

3.2 高斯向量的仿射变换

命题 3.4. 若 $X \sim \mathbf{N}_d(\mu, \Sigma)$, $Y = AX + b$, 其中 $A \in \mathbb{R}^{k \times d}$, $b \in \mathbb{R}^k$, 则

$$Y \sim \mathbf{N}_k(A\mu + b, A\Sigma A^\top). \quad (3.3)$$

证明. 对任意 $c \in \mathbb{R}^k$, $c^\top Y = c^\top b + (A^\top c)^\top X$. 右侧是一维正态, 因此 Y 联合高斯。其均值和协方差由线性运算得到。□

推论 3.5. 若 X 联合高斯, 则其任意子向量联合高斯, 任意有限个线性组合也联合高斯。

3.3 联合高斯中“不相关推出独立”

定理 3.6 (高斯块独立判据). 设 $\begin{pmatrix} X \\ Y \end{pmatrix}$ 联合高斯, 其中 $X \in \mathbb{R}^p$, $Y \in \mathbb{R}^q$. 则 $X \perp\!\!\!\perp Y \iff \text{Cov}(X, Y) = 0_{p \times q}$.

证明. 独立推出协方差为零是一般结论。反之, 若交叉协方差为零, 则联合协方差矩阵为分块对角形式 $\Sigma = \begin{pmatrix} \Sigma_X & 0 \\ 0 & \Sigma_Y \end{pmatrix}$ 。联合特征函数为

$$\varphi_{X,Y}(s, t) = \exp \left\{ i s^\top \mu_X + i t^\top \mu_Y - \frac{1}{2} s^\top \Sigma_X s - \frac{1}{2} t^\top \Sigma_Y t \right\} = \varphi_X(s) \varphi_Y(t).$$

由特征函数唯一性, 联合分布为边缘分布的乘积, 故 X 与 Y 独立。□

边缘均为正态仍不足以推出结论

令 $Z \sim \mathbf{N}(0, 1)$, ε 与 Z 独立, 且 $\mathbb{P}(\varepsilon = \pm 1) = 1/2$ 。定义 $X = Z$, $Y = \varepsilon Z$ 。则 X, Y 都服从标准正态, 且 $\text{Cov}(X, Y) = \mathbb{E}[\varepsilon Z^2] = 0$ 。但 $|X| = |Y|$ a.s., 故不独立。失败原因是 (X, Y) 并非联合高斯。

3.4 条件高斯分布与回归分解

定理 3.7 (高斯条件分布). 设 $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim \mathbf{N}_{p+q} \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right)$, 并假设 Σ_{22} 正定。则


$$X_1 | X_2 = x_2 \sim \mathbf{N}_p(\mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (x_2 - \mu_2), \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}). \quad (3.4)$$

证明. 定义残差

$$R = X_1 - \mu_1 - \Sigma_{12} \Sigma_{22}^{-1} (X_2 - \mu_2). \quad (3.5)$$

由于 R 与 X_2 均为原联合高斯向量的线性变换, (R, X_2) 联合高斯。计算交叉协方差:

$$\text{Cov}(R, X_2) = \Sigma_{12} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{22} = 0.$$



由 定理 3.6, $R \perp\!\!\!\perp X_2$ 。同时 $\mathbb{E}R = 0$ 且

$$\text{Cov}(R) = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}.$$

由 (3.5), $X_1 = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(X_2 - \mu_2) + R$ 。给定 $X_2 = x_2$ 后, 第一部分成为常数, R 的分布不变, 故得到 (3.4)。□

注 3.8 (Schur 补). 矩阵 $\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$ 称为 Σ_{22} 的 Schur 补。它必为半正定, 因为它正是条件残差 R 的协方差矩阵。

前提条件检查

条件均值是 x_2 的仿射函数, 但“条件期望为线性函数”并不是一般分布的性质。它在联合高斯模型中成立; 在一般模型中, $\mathbb{E}[X_1 | X_2]$ 可以是任意复杂的可测函数。

3.5 真题完整解法: 三维高斯正交分解

往年真题

2025 Spring 第 2 题, 10 分。

设 (X, Y, Z) 为均值零的三维高斯向量, 协方差矩阵为 $\Sigma = \begin{pmatrix} 1 & \rho & \tau \\ \rho & 1 & 0 \\ \tau & 0 & 1 \end{pmatrix}$ 。证明 $\rho^2 + \tau^2 \leq 1$, 并表示 $X = aY + bZ + cW$, 其中 $W \sim N(0, 1)$ 且与 (Y, Z) 独立。

解: 由于协方差矩阵必须半正定, 对任意线性组合方差均非负。特别地,

$$\begin{aligned} 0 &\leq \text{Var}(X - \rho Y - \tau Z) \\ &= \text{Var}(X) + \rho^2 \text{Var}(Y) + \tau^2 \text{Var}(Z) - 2\rho \text{Cov}(X, Y) - 2\tau \text{Cov}(X, Z) + 2\rho\tau \text{Cov}(Y, Z) \\ &= 1 + \rho^2 + \tau^2 - 2\rho^2 - 2\tau^2 \\ &= 1 - \rho^2 - \tau^2. \end{aligned}$$

故 $\rho^2 + \tau^2 \leq 1$ 。

令 $R = X - \rho Y - \tau Z$ 。则 $\text{Cov}(R, Y) = \text{Cov}(X, Y) - \rho \text{Var}(Y) - \tau \text{Cov}(Z, Y) = \rho - \rho = 0$, 同理 $\text{Cov}(R, Z) = 0$ 。因为 (R, Y, Z) 是 (X, Y, Z) 的线性变换, 所以仍联合高斯。由联合高斯中零协方差推出独立, $R \perp\!\!\!\perp (Y, Z)$ 。并且 $\text{Var}(R) = 1 - \rho^2 - \tau^2$ 。

若 $\rho^2 + \tau^2 < 1$, 定义 $W = \frac{R}{\sqrt{1 - \rho^2 - \tau^2}}$ 。则 $W \sim N(0, 1)$ 且 $W \perp\!\!\!\perp (Y, Z)$, 并有 $X = \rho Y + \tau Z + \sqrt{1 - \rho^2 - \tau^2} W$ 。因此 $a = \rho$, $b = \tau$, $c = \sqrt{1 - \rho^2 - \tau^2}$ 。

若 $\rho^2 + \tau^2 = 1$, 则 $\text{Var}(R) = 0$, 所以 $R = 0$ a.s., 即 $X = \rho Y + \tau Z$ a.s. 此时可在原概率空间的独立扩张上任取一个与 (Y, Z) 独立的标准正态 W , 并令 $c = 0$ 。□

考试时需要注意的地方

该题不能只写“协方差矩阵半正定，所以行列式非负”。完整答案应至少包含：

- (1) 一个明确的非负方差或主子式计算；
- (2) 残差 $R = X - \rho Y - \tau Z$ 的构造；
- (3) 分别验证 $\text{Cov}(R, Y) = \text{Cov}(R, Z) = 0$ ；
- (4) 写出“由于联合高斯，所以不相关推出独立”；
- (5) 单独处理 $\rho^2 + \tau^2 = 1$ 的退化情形。

3.6 高斯指数倾斜与换测度

重点

S 级 【必须会完整证明】

指数倾斜 (exponential tilting) 是似然比、Esscher 变换、大偏差、Girsanov 思想和指数族的共同原型。真题要求能够直接通过 MGF 或特征函数识别换测度后的分布。

定理 3.9 (高斯向量的指数倾斜). 设在概率测度 $\mathbb{P}$ 下, $X \sim \mathbf{N}_d(\mu, V)$, 其中 V 对称半正定。给定 $\alpha \in \mathbb{R}^d$, 定义新概率测度 $\mathbb{Q}$:

$$\frac{d\mathbb{Q}}{d\mathbb{P}} = \frac{\exp(\alpha^\top X)}{\mathbb{E}_{\mathbb{P}} \exp(\alpha^\top X)}. \quad (3.6)$$

则在 $\mathbb{Q}$ 下,

$$X \sim \mathbf{N}_d(\mu + V\alpha, V). \quad (3.7)$$

证明. 首先, 高斯 MGF 对所有实向量均有限, 且 $\mathbb{E}_{\mathbb{P}} e^{\alpha^\top X} = \exp(\alpha^\top \mu + \frac{1}{2} \alpha^\top V \alpha)$ 。对任意 $t \in \mathbb{R}^d$, 在 $\mathbb{Q}$ 下的 MGF 为

$$M_{\mathbb{Q}}(t) = \mathbb{E}_{\mathbb{Q}} e^{t^\top X} = \frac{\mathbb{E}_{\mathbb{P}} e^{(t+\alpha)^\top X}}{\mathbb{E}_{\mathbb{P}} e^{\alpha^\top X}} = \frac{\exp\left\{(t+\alpha)^\top \mu + \frac{1}{2}(t+\alpha)^\top V(t+\alpha)\right\}}{\exp\left\{\alpha^\top \mu + \frac{1}{2}\alpha^\top V \alpha\right\}} = \exp\left\{t^\top(\mu + V\alpha) + \frac{1}{2}t^\top V t\right\}.$$

这正是 $\mathbf{N}_d(\mu + V\alpha, V)$ 的 MGF, 因此 (3.7) 成立。□

往年真题

该定理即为 **2026 Spring 第 1 题** 的完整核心。题面没有要求 V 正定, 因此不能在证明中依赖 V^{-1} 或非退化高斯密度; 使用 MGF 可以自动覆盖奇异协方差情形。

易错点与失分点

- (1) 换测度后协方差仍为 V , 只有均值移动为 $\mu + V\alpha$;
- (2) 均值不是 $\mu + \alpha$, 除非 $V = I$;
- (3) 使用配方法时若默认 V^{-1} 存在, 会遗漏退化高斯情形;
- (4) 必须先写归一化常数, 证明 (3.6) 确实定义概率测度。

3.7 历年实考扩展：二维高斯随机对称矩阵

往年真题

【真题驱动补充】

C 级

该主题未在简要考纲中单独列出，但曾在历年真题中实际考查。

2025 Fall 第 6 题 考查二维高斯随机对称矩阵的特征值和特征向量不变性。其核心并不是一般随机矩阵理论，而是：高斯正交变换 + 极坐标 + 协方差计算 + 正交不变性。

设 $M = \begin{pmatrix} X_1 & Y \\ Y & X_2 \end{pmatrix}$ ，其中 $X_1, X_2 \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 2)$ ， $Y \sim \mathcal{N}(0, 1)$ ，三者独立。令 $\lambda_1 \geq \lambda_2$ 为特征值。

定义 $A = \frac{X_1+X_2}{2}$ ， $B = \frac{X_1-X_2}{2}$ 。则 $A, B, Y \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ 。矩阵可写成 $M = AI_2 + \begin{pmatrix} B & Y \\ Y & -B \end{pmatrix}$ 。第二项的特征值为 $\pm R$ ， $R = \sqrt{B^2 + Y^2}$ 。因此

$$\lambda_1 = A + R, \lambda_2 = A - R. \quad (3.8)$$

3.7.1 特征值之和

由 (3.8)， $\lambda_1 + \lambda_2 = 2A$ 。故 $\lambda_1 + \lambda_2 \sim \mathcal{N}(0, 4)$ 。

3.7.2 特征值之差

由于 (B, Y) 是二维标准正态向量， $R = \sqrt{B^2 + Y^2}$ 服从尺度参数为 1 的 Rayleigh 分布： $\mathbb{P}(R \leq r) = 1 - e^{-r^2/2}$ ， $r \geq 0$ 。因此 $D := \lambda_1 - \lambda_2 = 2R$ 满足 $\mathbb{P}(D \leq d) = 1 - e^{-d^2/8}$ ， $d \geq 0$ ，密度为 $f_D(d) = \frac{d}{4} e^{-d^2/8} \mathbf{1}_{(0, \infty)}(d)$ 。

3.7.3 两个特征值是否独立

由 $A \perp\!\!\!\perp R$ ，

$$\text{Cov}(\lambda_1, \lambda_2) = \text{Cov}(A + R, A - R) = \text{Var}(A) - \text{Var}(R).$$

Rayleigh(1) 分布满足 $\mathbb{E}R = \sqrt{\frac{\pi}{2}}$ ， $\mathbb{E}R^2 = 2$ ， $\text{Var}(R) = 2 - \frac{\pi}{2}$ 。所以 $\text{Cov}(\lambda_1, \lambda_2) = 1 - (2 - \frac{\pi}{2}) = \frac{\pi-2}{2} \neq 0$ 。故 λ_1, λ_2 不独立。

3.7.4 正交不变性

三维坐标 (X_1, X_2, Y) 的联合密度可写为 $p(M) = C \exp \left\{ -\frac{1}{4}(X_1^2 + X_2^2 + 2Y^2) \right\} = C \exp \left\{ -\frac{1}{4} \text{tr}(M^2) \right\}$ 。对任意正交矩阵 O ， $\text{tr}[(OMO^T)^2] = \text{tr}(OM^2O^T) = \text{tr}(M^2)$ 。而映射 $M \mapsto OMO^T$ 在实对称矩阵空间上保持 Lebesgue 体积。因此 $OMO^T \stackrel{d}{=} M$ 。这说明有序特征直线的联合分布具有正交不变性；在给特征向量附加独立随机符号后，所得正交特征框服从相应的 Haar 不变分布。

特征向量的符号约定

单位特征向量只确定到符号： v 与 $-v$ 代表同一特征直线。若使用诸如“第一坐标为正”的确定性符号规则，该规则本身未必在所有正交变换下保持不变。严格陈述应针对：

- (1) 特征直线；
- (2) 正交特征框模去逐列符号；
- (3) 或附加独立 Rademacher 符号后的特征向量。

3.8 本章答题模板

高斯向量题

- (1) 先写“所考察对象是联合高斯向量的线性变换，因此仍联合高斯”；
- (2) 计算均值与完整协方差矩阵；
- (3) 若要证明独立，先验证交叉协方差为零，再写“联合高斯故独立”；
- (4) 条件分布题构造线性残差；
- (5) 退化协方差情形单独处理；
- (6) 指数倾斜题优先使用 MGF，避免不必要地假设协方差矩阵可逆。

一些需要记忆的内容

- (1) 各分量均正态是否足以推出联合高斯？
- (2) 联合高斯中两个子向量独立的充要条件是什么？
- (3) 条件高斯协方差为什么是 Schur 补？
- (4) 高斯指数倾斜后，均值和协方差分别如何变化？



第四章 特征函数、矩母函数、概率生成函数与累积量

4.1 考纲定位与证明要求

重点

S 级

【必须会完整证明】：基本性质、独立和的乘积公式、存在性区别。

【必须会复现证明框架】：唯一性定理、Lévy 连续性定理、经典 CLT 中的特征函数展开。

【必须会熟练应用】：MGF、PGF、累积量及常见分布的变换。

往年真题

相关真题包括：

- 2024 Spring 第 1 题，10 分：利用特征函数在零点附近的非标准展开确定归一化；
- 2024 Fall 第 3 题，10 分：指数尾、矩增长和指数矩之间的等价关系；
- 2025 Fall 第 1 题，10 分：随机幂 X^N 的矩存在域；
- 2025 Spring 第 3 题，15 分：简单随机游动的指数矩和停时生成函数；
- 2026 Spring 第 5 题，10 分：Galton–Watson 过程的概率生成函数迭代。

4.2 四种变换的精确定义

4.2.1 特征函数

定义 4.1 (特征函数). 实值随机变量 X 的特征函数为

$$\varphi_X(t) = \mathbb{E}e^{itX}, \quad t \in \mathbb{R}. \quad (4.1)$$

随机向量 $X \in \mathbb{R}^d$ 的特征函数为

$$\varphi_X(t) = \mathbb{E}e^{it^\top X}, \quad t \in \mathbb{R}^d. \quad (4.2)$$


由于 $|e^{itX}| = 1$, 故特征函数对任何随机变量、任何 $t \in \mathbb{R}$ 都存在。

4.2.2 矩母函数

定义 4.2 (矩母函数). 随机变量 X 的矩母函数为

$$M_X(t) = \mathbb{E}e^{tX}, \quad (4.3)$$

其有限域为 $\mathcal{D}_X = \{t \in \mathbb{R} : \mathbb{E}e^{tX} < \infty\}$ 。通常说“ X 的 MGF 存在”，是指存在 $\delta > 0$, 使 $(-\delta, \delta) \subseteq \mathcal{D}_X$ 。



注 4.3. 由于 $M_X(0) = 1$, 零点本身总是有限; 但零点可能是有限域的边界。只有在零点邻域内有限, 才能安全地使用 MGF 唯一性、逐阶求导和 MGF 收敛定理。

4.2.3 概率生成函数

定义 4.4 (概率生成函数). 若 X 取值于 $\{0, 1, 2, \dots\}$, 定义

$$G_X(s) = \mathbb{E}s^X = \sum_{k=0}^{\infty} \mathbb{P}(X = k)s^k. \quad (4.4)$$

至少对 $s \in [0, 1]$ 总是存在。

若 X 的支撑从 1 开始, 仍可使用同一定义, 但最低次幂为 s 。

4.2.4 累积量生成函数

定义 4.5 (累积量生成函数). 若 MGF 在零点邻域存在, 定义 $K_X(t) = \log M_X(t)$ 。第 r 阶累积量为 $\kappa_r(X) = K_X^{(r)}(0)$ 。

前四阶累积量为 $\kappa_1 = \mathbb{E}X$, $\kappa_2 = \text{Var}(X)$, $\kappa_3 = \mathbb{E}[(X - \mathbb{E}X)^3]$, $\kappa_4 = \mathbb{E}[(X - \mathbb{E}X)^4] - 3\text{Var}(X)^2$ 。

4.3 特征函数的基本性质

定理 4.6 (特征函数性质). 对任意随机变量 X :

- (1) $\varphi_X(0) = 1$;
- (2) $|\varphi_X(t)| \leq 1$;
- (3) $\varphi_X(-t) = \overline{\varphi_X(t)}$;
- (4) φ_X 在 $\mathbb{R}$ 上一致连续;
- (5) 若 $Y = aX + b$, 则 $\varphi_Y(t) = e^{itb}\varphi_X(at)$;
- (6) 若 $X_1, \dots, X_n$ 独立, 则

$$\varphi_{\sum_{j=1}^n X_j}(t) = \prod_{j=1}^n \varphi_{X_j}(t). \quad (4.5)$$

证明. 前三点直接由定义得到。对一致连续性,

$$\begin{aligned} |\varphi_X(t+h) - \varphi_X(t)| &= \left| \mathbb{E} \left[e^{itX} (e^{ihX} - 1) \right] \right| \\ &\leq \mathbb{E} |e^{ihX} - 1|. \end{aligned}$$

当 $h \rightarrow 0$ 时, 被积函数逐点趋于 0, 且由 $|e^{ihX} - 1| \leq 2$ 控制, 故由控制收敛定理, 右侧趋于 0, 并且该上界不依赖 t 。

仿射变换公式直接计算: $\mathbb{E}e^{it(aX+b)} = e^{itb}\varphi_X(at)$ 。若 X_j 独立, 则 $\mathbb{E}e^{it\sum_j X_j} = \mathbb{E}\prod_j e^{itX_j} = \prod_j \mathbb{E}e^{itX_j}$ 。□

定理 4.7 (特征函数的矩导数). 若 $\mathbb{E}|X|^k < \infty$, 则 φ_X 至少 k 次连续可微, 并且

$$\varphi_X^{(j)}(t) = \mathbb{E}[(iX)^j e^{itX}], \quad 0 \leq j \leq k. \quad (4.6)$$

特别地, $\varphi_X^{(j)}(0) = i^j \mathbb{E}X^j$ 。

证明. 对差商使用控制收敛。一次导数时, $\frac{e^{i(t+h)X} - e^{itX}}{h} = e^{itX} \frac{e^{ihX} - 1}{h} \rightarrow iX e^{itX}$ 。由 $\left| \frac{e^{ihX} - 1}{h} \right| \leq |X|$ 和 $\mathbb{E}|X| < \infty$, 可交换极限与期望。高阶情形递推处理。□

易错点与失分点

- (1) 特征函数可无限次可微需要相应的全部矩条件；不能仅因特征函数总存在，就默认其光滑；
- (2) 即使所有矩都存在，矩也未必唯一确定分布；
- (3) 特征函数在零点形式导数计算必须有矩存在性或其他合法依据。

4.4 唯一性定理、Lévy 连续性定理与 Cramér–Wold

定理 4.8 (特征函数唯一性). 若 $\varphi_X(t) = \varphi_Y(t)$ 对所有 $t \in \mathbb{R}$ 都满足, 则 $X \stackrel{d}{=} Y$ 。多维结论同样成立。

证明思路

一种标准框架是先给 X, Y 加上独立高斯噪声: $X_\varepsilon = X + \varepsilon Z$, $Y_\varepsilon = Y + \varepsilon Z'$, 其中 Z, Z' 为标准正态。两者特征函数为 $\varphi_X(t)e^{-\varepsilon^2 t^2/2}$, $\varphi_Y(t)e^{-\varepsilon^2 t^2/2}$ 。乘上高斯因子后可用 Fourier 反演得到连续密度, 故 $X_\varepsilon \stackrel{d}{=} Y_\varepsilon$ 。再令 $\varepsilon \downarrow 0$, 得到 $X \stackrel{d}{=} Y$ 。

定理 4.9 (Lévy 连续性定理). **【必须会复现证明框架】**

- (1) 若 $X_n \xrightarrow{d} X$, 则对每个 $t \in \mathbb{R}$, $\varphi_{X_n}(t) \rightarrow \varphi_X(t)$.
- (2) 若对每个 $t \in \mathbb{R}$, $\varphi_{X_n}(t) \rightarrow \varphi(t)$, 且 φ 在 0 处连续, 则 φ 是某个概率分布的特征函数, 并存在 X 使 $X_n \xrightarrow{d} X$.

注 4.10. “极限函数在 0 处连续”不能省略。特征函数的点态极限可能在零点不连续, 此时质量可能逃向无穷远, 序列不紧。

例 4.11 (质量逃向无穷远). 令 $X_n = n$ 为常数。则 $\varphi_{X_n}(t) = e^{int}$ 。它一般没有逐点极限。类似构造可产生在非零点趋于 0、而在零点等于 1 的形式极限；该函数在零点不连续, 不能是概率分布的特征函数。

定理 4.12 (Cramér–Wold 装置). 设 X_n, X 为 $\mathbb{R}^d$ 值随机向量。则 $X_n \xrightarrow{d} X$ 当且仅当对每个 $a \in \mathbb{R}^d$, $a^\top X_n \xrightarrow{d} a^\top X$ 。

证明思路

必要性由连续映射定理。充分性中, 对每个 $t \in \mathbb{R}^d$, $\varphi_{X_n}(t) = \mathbb{E}e^{it^\top X_n} \rightarrow \mathbb{E}e^{it^\top X} = \varphi_X(t)$ 。再使用多维 Lévy 连续性定理。

考试重点

多元渐近题常用流程为: 多元 CLT $\rightarrow$ Cramér–Wold 或向量形式 $\rightarrow$ 连续映射/Delta 方法。若只逐坐标证明收敛, 通常不足以推出联合收敛; 还必须控制坐标间的联合结构。

4.5 矩母函数：存在域、唯一性与收敛

命题 4.13 (MGF 的基本性质). 若相关期望有限, 则:

- (1) $M_X(0) = 1$;
- (2) $M_{aX+b}(t) = e^{bt}M_X(at)$;
- (3) 若 X, Y 独立, 则 $M_{X+Y}(t) = M_X(t)M_Y(t)$;
- (4) 若 MGF 在零点邻域存在, 则 $M_X^{(k)}(0) = \mathbb{E}X^k$;
- (5) 有限域 $\mathcal{D}_X$ 是凸集, 在一维中是一个区间。

有限域为什么凸

若 $t_1, t_2 \in \mathcal{D}_X$, $0 < \lambda < 1$, 由 Hölder 不等式,

$$\mathbb{E}e^{[\lambda t_1 + (1-\lambda)t_2]X} = \mathbb{E}\left[(e^{t_1 X})^\lambda (e^{t_2 X})^{1-\lambda}\right] \leq (\mathbb{E}e^{t_1 X})^\lambda (\mathbb{E}e^{t_2 X})^{1-\lambda} < \infty.$$

定理 4.14 (MGF 唯一性). 若 M_X 与 M_Y 均在同一个包含零点的开区间内有限, 且 $M_X(t) = M_Y(t)$ 在该区间内成立, 则 $X \stackrel{d}{=} Y$ 。

定理 4.15 (MGF 收敛定理). 若存在 $\delta > 0$, 使所有 $M_{X_n}(t)$ 在 $|t| < \delta$ 内有限, 并且 $M_{X_n}(t) \rightarrow M(t)$, $|t| < \delta$, 其中 M 是某个概率分布的 MGF, 则 $X_n \xrightarrow{d} X$, 其中 $M_X = M$ 。

易错点与失分点

只知道对每个固定 t 有 $M_{X_n}(t) \rightarrow M(t)$ 并不自动足够。必须确认:

- (1) 所有 MGF 在一个共同的零点邻域内有限;
- (2) 极限函数确实是某个分布的 MGF;
- (3) 不能把仅在 $t \leq 0$ 有限的 Laplace 变换直接当作双侧 MGF。

4.5.1 特征函数总存在, 但 MGF 未必存在

对数正态分布

令 $Z \sim N(0, 1)$, $X = e^Z$ 。则对任意 $k > 0$, $\mathbb{E}X^k = \mathbb{E}e^{kZ} = e^{k^2/2} < \infty$, 所以所有正整数阶矩均存在。然而对任意 $t > 0$, $M_X(t) = \mathbb{E}e^{te^Z} = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \exp\left\{te^z - \frac{z^2}{2}\right\} dz = \infty$ 。原因是当 $z \rightarrow \infty$ 时, te^z 的增长速度远快于 $z^2/2$ 。


Cauchy 分布

标准 Cauchy 随机变量没有一阶绝对矩, 更没有 MGF; 但其特征函数存在并且为 $\varphi_X(t) = e^{-|t|}$ 。

4.6 概率生成函数及其应用

定理 4.16 (PGF 的唯一性与导数). 若 X 取值于 $\{0, 1, 2, \dots\}$, 则:

- (1) G_X 唯一确定 X 的分布;
- (2) $\mathbb{P}(X = k) = \frac{G_X^{(k)}(0)}{k!}$;



(3) 若相应矩有限, 则

$$G_X^{(r)}(1-) = \mathbb{E}[(X)_r], \quad (4.7)$$

其中 $(X)_r = X(X-1)\cdots(X-r+1)$;

(4) 若 X, Y 独立且非负整数值, 则 $G_{X+Y}(s) = G_X(s)G_Y(s)$.

证明. 由幂级数展开 $G_X(s) = \sum_{k=0}^{\infty} p_k s^k$. 在 $s=0$ 处逐阶求导即可恢复 p_k . 在 $0 \leq s < 1$ 内, $G_X^{(r)}(s) = \sum_{k=r}^{\infty} (k)_r p_k s^{k-r}$. 令 $s \uparrow 1$, 由单调收敛得到 (4.7). 独立和的乘积公式与特征函数情形相同. $\square$

例 4.17 (Poisson 分布的阶乘矩). 若 $N \sim \text{Poisson}(\lambda)$, 则 $G_N(s) = e^{\lambda(s-1)}$. 因此 $G_N^{(r)}(1) = \lambda^r$, 即 $\mathbb{E}[(N)_r] = \lambda^r$.

例 4.18 (Galton-Watson 生成函数迭代). 设后代数 ξ 的 PGF 为 $f(s) = \mathbb{E}s^\xi$, Galton-Watson 过程从 $Z_0 = 1$ 开始. 条件于 Z_n , $Z_{n+1} = \sum_{j=1}^{Z_n} \xi_{n,j}$, 故 $\mathbb{E}[s^{Z_{n+1}} | Z_n] = f(s)^{Z_n}$. 取期望得到 $G_{Z_{n+1}}(s) = G_{Z_n}(f(s))$. 由 $G_{Z_0}(s) = s$, 递推得 $G_{Z_n}(s) = f^{\circ n}(s)$, 其中 $f^{\circ n}$ 表示 n 次复合.

4.7 常见分布的 CF、MGF 与 PGF 速查

分布	特征函数 $\varphi_X(t)$	MGF 或 PGF	有限域与说明
Bernoulli(p)	$1 - p + pe^{it}$	$M(t) = 1 - p + pe^t$ $G(s) = 1 - p + ps$	全部实数
Bin(n, p)	$(1 - p + pe^{it})^n$	$M(t) = (1 - p + pe^t)^n$ $G(s) = (1 - p + ps)^n$	全部实数
Poisson(λ)	$\exp\{\lambda(e^{it} - 1)\}$	$M(t) = \exp\{\lambda(e^t - 1)\}$ $G(s) = \exp\{\lambda(s - 1)\}$	MGF 对全部实数有限
Geom(p) 支撑 $1, 2, \dots$	$\frac{pe^{it}}{1 - (1-p)e^{it}}$	$G(s) = \frac{ps}{1 - (1-p)s}$	$ s < (1-p)^{-1}$
NegBin(r, p) 失败数版本	$\left[\frac{p}{1 - (1-p)e^{it}} \right]^r$	$G(s) = \left[\frac{p}{1 - (1-p)s} \right]^r$	$ s < (1-p)^{-1}$
N(μ, σ^2)	$\exp\{i\mu t - \sigma^2 t^2/2\}$	$\exp\{\mu t + \sigma^2 t^2/2\}$	全部实数
Gamma(α, θ) shape-scale	$(1 - i\theta t)^{-\alpha}$	$(1 - \theta t)^{-\alpha}$	$t < 1/\theta$
Exp(λ) 率参数	$\frac{\lambda}{\lambda - it}$	$\frac{\lambda}{\lambda - t}$	$t < \lambda$
Unif(a, b)	$e^{it(a+b)/2} \frac{\sin[t(b-a)/2]}{t(b-a)/2}$	$\frac{e^{tb} - e^{ta}}{t(b-a)}$	$t \in \mathbb{R}$; 在 $t=0$ 连续延拓
标准 Cauchy	$e^{- t }$	MGF 不存在	无有限一阶绝对矩

4.8 累积量的加法性

命题 4.19. 若 X, Y 独立, 且其 MGF 在零点邻域存在, 则 $K_{X+Y}(t) = K_X(t) + K_Y(t)$. 因此对每个 r , $\kappa_r(X+Y) = \kappa_r(X) + \kappa_r(Y)$.

证明. 独立性给出 $M_{X+Y}(t) = M_X(t)M_Y(t)$ 。取对数后得到累积量生成函数相加, 再逐阶求导。 $\square$

例 4.20 (中心独立和的四阶矩). 若 $X_1, \dots, X_n$ 独立、均值为零且四阶矩有限, 则

$$\mathbb{E} \left(\sum_{j=1}^n X_j \right)^4 = \sum_{j=1}^n \mathbb{E} X_j^4 + 6 \sum_{i < j} \mathbb{E} X_i^2 \mathbb{E} X_j^2. \quad (4.8)$$

特别地, 若 X_j i.i.d., 则 $\mathbb{E} S_n^4 = n \mathbb{E} X_1^4 + 3n(n-1)(\mathbb{E} X_1^2)^2$ 。

证明. 展开四次方。由于各变量中心化且独立, 只保留四个指标全部相同, 或两个指标各出现两次的项。对每对 $i < j$, 排列 i, i, j, j 有 $\frac{4!}{2!2!} = 6$ 种。 $\square$

4.9 真题核心定理: 指数尾、矩增长与指数矩

往年真题

2024 Fall 第 3 题, 10 分。

题目要求证明以下三种性质在绝对常数因子意义下等价:

- (1) 指数尾界;
- (2) p 阶矩按 p^p 增长;
- (3) $|X|$ 在某个正点具有有限指数矩。

这是“尾概率—矩—MGF”三种语言之间转换的标准母题。

定理 4.21 (次指数变量的三种等价刻画). 下列三种性质在参数相差绝对常数因子的意义下等价:

- (1) 存在 $K_1 > 0$, 使对所有 $t \geq 0$,

$$\mathbb{P}(|X| \geq t) \leq 2e^{-t/K_1}; \quad (4.9)$$

- (2) 存在 $K_2 > 0$, 使对所有整数 $p \geq 1$,

$$\mathbb{E}|X|^p \leq (K_2 p)^p; \quad (4.10)$$

- (3) 存在 $K_3 > 0$, 使

$$\mathbb{E} e^{|X|/K_3} \leq 2. \quad (4.11)$$

证明. (4.9) 推出 (4.10)

由尾积分公式,

$$\mathbb{E}|X|^p = p \int_0^\infty t^{p-1} \mathbb{P}(|X| > t) dt \leq 2p \int_0^\infty t^{p-1} e^{-t/K_1} dt.$$


令 $u = t/K_1$, 则

$$\mathbb{E}|X|^p \leq 2pK_1^p \int_0^\infty u^{p-1} e^{-u} du = 2pK_1^p \Gamma(p) = 2K_1^p p!.$$

利用 $p! \leq p^p$, $\mathbb{E}|X|^p \leq 2K_1^p p^p \leq (2K_1 p)^p$. 故可取 $K_2 = 2K_1$ 。

(4.10) 推出 (4.11)

展开指数函数并使用 Tonelli: $\mathbb{E} e^{|X|/K_3} = 1 + \sum_{p=1}^\infty \frac{\mathbb{E}|X|^p}{p! K_3^p}$. 取 $K_3 = 3eK_2$. 由假设与 Stirling 下界 $p! \geq \left(\frac{p}{e}\right)^p$, 有 $\frac{\mathbb{E}|X|^p}{p! K_3^p} \leq \frac{(K_2 p)^p}{(p/e)^p (3eK_2)^p} = 3^{-p}$. 因此 $\mathbb{E} e^{|X|/K_3} \leq 1 + \sum_{p=1}^\infty 3^{-p} = 1 + \frac{1}{2} < 2$ 。



(4.11) 推出 (4.9)

由 Markov 不等式,

$$\mathbb{P}(|X| \geq t) = \mathbb{P}\left(e^{|X|/K_3} \geq e^{t/K_3}\right) \leq e^{-t/K_3} \mathbb{E}e^{|X|/K_3} \leq 2e^{-t/K_3}.$$

故可取 $K_1 = K_3$ 。

□

尾—矩—指数矩转换

识别信号: 题目同时出现 $\mathbb{P}(|X| > t)$, $\mathbb{E}|X|^p$, $\mathbb{E}e^{c|X|}$ 。

构造步骤: 尾 $\rightarrow$ 矩 $\mathbb{E}X^p = p \int t^{p-1} \mathbb{P}(X > t) dt$; 矩 $\rightarrow$ 指数矩 $e^x = \sum_{p \geq 0} \frac{x^p}{p!}$; 指数矩 $\rightarrow$ 尾 Markov 不等式。

常见失败原因:

- (1) 忘记尾积分公式前的系数 p ;
- (2) 展开指数后没有说明可用 Tonelli;
- (3) 没有使用 Stirling 比较 p^p 与 $p!$;
- (4) 试图追求最优常数, 而题目只要求绝对常数等价。

4.10 真题完整例: 随机幂的矩存在性

往年真题

2025 Fall 第 1 题, 10 分。

设 $X \sim \text{Exp}(1)$, $N \sim \text{Poisson}(\lambda)$, 且 X, N 独立。研究 $\mathbb{E}[X^N]$ 和 $\text{Var}(X^N)$ 的有限性。

解: 条件于 $N = n$ 。标准指数分布的整数阶矩为 $\mathbb{E}X^n = n!$ 。因此由非负项 Tonelli 定理,

$$\mathbb{E}X^N = \sum_{n=0}^{\infty} \mathbb{P}(N = n) \mathbb{E}X^n = \sum_{n=0}^{\infty} e^{-\lambda} \frac{\lambda^n}{n!} n! = e^{-\lambda} \sum_{n=0}^{\infty} \lambda^n.$$

故 $\boxed{\mathbb{E}X^N < \infty \iff 0 < \lambda < 1.}$ 当 $0 < \lambda < 1$ 时, $\boxed{\mathbb{E}X^N = \frac{e^{-\lambda}}{1 - \lambda}.}$

再考察二阶矩:

$$\mathbb{E}X^{2N} = \sum_{n=0}^{\infty} e^{-\lambda} \frac{\lambda^n}{n!} \mathbb{E}X^{2n} = e^{-\lambda} \sum_{n=0}^{\infty} \frac{\lambda^n (2n)!}{n!}.$$

记 $a_n = \frac{\lambda^n (2n)!}{n!}$ 。则 $\frac{a_{n+1}}{a_n} = \lambda \frac{(2n+2)(2n+1)}{n+1} = 2\lambda(2n+1) \rightarrow \infty$ 。因此对每个 $\lambda > 0$, 级数项最终增长, 特别地 不趋于零, 故 $\mathbb{E}X^{2N} = \infty$ 。于是不存在任何 $\lambda > 0$ 使 $\text{Var}(X^N) < \infty$: $\boxed{\text{Var}(X^N) = \infty \text{ 对所有 } \lambda > 0.}$ □

考试时需要注意的地方

本题的得分关键是先条件于 N , 而不是直接尝试求 X^N 的分布。第二问中不能只说“增长很快”, 必须用 比值或 Stirling 证明级数发散。

4.11 简单随机游动中的指数变换

若 $\xi_1, \xi_2, \dots$ i.i.d., 令 $S_n = \sum_{j=1}^n \xi_j$, $M(\theta) = \mathbb{E}e^{\theta\xi_1}$. 则由独立性,

$$\mathbb{E}e^{\theta S_n} = M(\theta)^n. \quad (4.12)$$

因而

$$L_n(\theta) = \frac{e^{\theta S_n}}{M(\theta)^n} \quad (4.13)$$

是后续鞅章节中的指数鞅。

对对称简单随机游动, $\mathbb{P}(\xi_j = 1) = \mathbb{P}(\xi_j = -1) = \frac{1}{2}$, 有 $M(\theta) = \frac{e^\theta + e^{-\theta}}{2} = \cosh \theta$, 所以 $\mathbb{E}e^{\theta S_n} = (\cosh \theta)^n$.

注 4.22. 公式 (4.13) 是随机游动首达时生成函数、赌徒破产概率、Wald 型恒等式和大偏差估计的共同构造。使用可选停止时仍必须检查停时条件, 不能仅因 L_n 是鞅就直接代入无界停时。

4.12 本章答题模板

特征函数与生成函数题

- (1) 写清所用变换的定义域;
- (2) 独立和先使用乘积公式;
- (3) 极限分布题写出对每个固定 t 的点态极限;
- (4) 核查极限函数在 0 处连续;
- (5) 说明极限函数是哪一个已知分布的特征函数;
- (6) 使用 Lévy 连续性定理收束;
- (7) MGF 题额外核查共同零点邻域;
- (8) PGF 题说明随机变量的整数值支撑, 并在 $s = 1$ 处区分左极限与有限矩。



4.13 本章易错点与反例

陈述	判断	正确说明
所有随机变量都有 MGF	错	所有随机变量都有特征函数；MGF 可能在任意 $t > 0$ 都发散。
所有矩存在就能保证 MGF 存在	错	对数正态分布全部正整数阶矩有限，但正半轴 MGF 发散。
MGF 在 $t = 0$ 有限就叫 MGF 存在	错	$M_X(0) = 1$ 总成立；通常要求在零点开邻域内有限。
特征函数点态收敛必推出依分布收敛	不完整	还需极限函数在 0 处连续。
逐坐标依分布收敛推出向量联合收敛	错	必须控制联合结构；常用 Cramér–Wold 装置。
PGF 在 $s = 1$ 的一阶导数总等于均值	不完整	若均值可能无限，应写 $G'(1-) = \mathbb{E}X \in [0, \infty]$ 。
$\log M_{X+Y} = \log M_X + \log M_Y$	有条件	要求 X, Y 独立，且相关 MGF 在同一邻域内有限。

一些需要记忆的内容

- (1) 为什么特征函数总存在，而 MGF 未必存在？
- (2) Lévy 连续性定理为什么要求极限函数在零点连续？
- (3) PGF 的第 r 阶导数在 1 处给出普通矩还是阶乘矩？
- (4) 对数正态分布说明“全部矩存在”不能推出什么？
- (5) 随机幂 X^N 的矩为什么应先条件于 N ？



第五章 收敛模式、Borel–Cantelli 引理与一致可积

5.1 考纲定位、重要性与历年考法

考试重点

本章整体为 **S 级**。几乎处处收敛、依概率收敛、依分布收敛和 L^p 收敛之间的关系，是大数律、中心极限定理、鞅收敛、MLE 渐近理论和 Delta 方法的共同语言。一致可积 (uniform integrability) 则是从“随机变量本身收敛”升级到“期望或矩也收敛”的关键附加条件。

资格考试中，本章常以以下方式出现：

- (1) 证明某种收敛关系在加法、乘法或连续变换下保持；
- (2) 构造反例，否定某个看似自然的逆命题；
- (3) 使用 Borel–Cantelli 引理证明几乎处处极限；
- (4) 检查能否交换极限与期望；
- (5) 证明一族随机变量一致可积，从而得到 L^1 收敛；
- (6) 将随机级数的几乎处处收敛与一致可积结合。

往年真题

代表性真题包括：

- 2024 Spring 第 2 题，15 分：指数样本的单项 $\limsup$ 与样本最大值的几乎处处极限；
- 2024 Spring 第 3 题，10 分：依概率收敛下乘积收敛，以及 L^1 收敛下乘积收敛的反例；
- 2024 Fall 第 5 题，15 分：随机级数的几乎处处收敛，以及指数变换后的 L^1 收敛；
- 2025 Fall 第 4 题，15 分：稀有大跳与负漂移共同造成 $\liminf$ 、 $\limsup$ 异号；
- 2026 Spring 第 2 题，15 分：三角阵列归一化与 Lindeberg–Feller 中心极限定理。

5.2 四种基本收敛模式

5.2.1 几乎处处收敛

定义 5.1 (几乎处处收敛). 设 X_n, X 定义在同一概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$ 上。若

$$\mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)\right\}\right) = 1, \quad (5.1)$$

则称 X_n 几乎处处收敛于 X ，记为 $X_n \xrightarrow{\text{a.s.}} X$ 。



等价地,

$$\{X_n \rightarrow X\} = \bigcap_{m=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{n \geq N} \left\{ |X_n - X| < \frac{1}{m} \right\}. \quad (5.2)$$

公式 (5.2) 同时说明收敛事件属于 $\mathcal{F}$ 。

注 5.2. 几乎处处收敛要求所有 X_n 与 X 定义在同一个概率空间上。依分布收敛只比较分布, 不要求随机变量定义在同一空间。

5.2.2 依概率收敛

定义 5.3 (依概率收敛). 若对每个 $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0, \quad (5.3)$$

则称 X_n 依概率收敛于 X , 记为 $X_n \xrightarrow{\mathbb{P}} X$ 。

注 5.4. 依概率收敛允许每个 n 上仍有少量较大误差, 但这些误差事件的概率必须趋于零。它不要求同一条样本路径最终稳定。

5.2.3 L^p 收敛

定义 5.5 (L^p 收敛). 设 $p > 0$, 且 X_n, X 均具有有限 p 阶绝对矩。若

$$\mathbb{E}|X_n - X|^p \rightarrow 0, \quad (5.4)$$

则称 X_n 在 L^p 中收敛于 X , 记为 $X_n \xrightarrow{L^p} X$ 。当 $p \geq 1$ 时, 也可写成 $\|X_n - X\|_p \rightarrow 0$, $\|Y\|_p = (\mathbb{E}|Y|^p)^{1/p}$ 。

注 5.6. L^p 收敛不仅要求误差概率变小, 还要求误差的 p 阶大小整体趋于零。它对极小概率但极大幅度的异常值非常敏感。

5.2.4 依分布收敛

定义 5.7 (依分布收敛). 设 F_n, F 分别为 X_n, X 的分布函数。若对 F 的每个连续点 x ,

$$F_n(x) \rightarrow F(x), \quad (5.5)$$

则称 X_n 依分布收敛于 X , 记为 $X_n \xrightarrow{d} X$ 。


依分布收敛也称弱收敛 (weak convergence), 本质上是概率测度 $\text{Law}(X_n) \Rightarrow \text{Law}(X)$ 的弱收敛。

定理 5.8 (Portmanteau 定理). 下列条件等价:

- (1) $X_n \xrightarrow{d} X$;
- (2) 对每个有界连续函数 $f: \mathbb{R}^d \rightarrow \mathbb{R}$,

$$\mathbb{E}f(X_n) \rightarrow \mathbb{E}f(X); \quad (5.6)$$

- (3) 对每个闭集 C , $\limsup_{n \rightarrow \infty} \mathbb{P}(X_n \in C) \leq \mathbb{P}(X \in C)$;



- (4) 对每个开集 G , $\liminf_{n \rightarrow \infty} \mathbb{P}(X_n \in G) \geq \mathbb{P}(X \in G)$;
 (5) 对每个满足 $\mathbb{P}(X \in \partial A) = 0$ 的 Borel 集 A , $\mathbb{P}(X_n \in A) \rightarrow \mathbb{P}(X \in A)$.

证明思路

一维情形中, 从 CDF 收敛出发, 用阶梯函数逼近有界连续函数; 从有界连续函数刻画出发, 用连续函数从上或从下逼近闭集、开集示性函数。多维情形的证明使用同样的逼近思想和概率测度的紧性。

易错点与失分点

依分布收敛只允许在极限 CDF 的连续点代入极限。若 F 在 x 处有跳跃, $F_n(x)$ 不一定收敛到 $F(x)$ 。

5.3 收敛模式之间的蕴含关系

定理 5.9 (基本蕴含图). 在概率空间上: $X_n \xrightarrow{\text{a.s.}} X \implies X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{d} X$, 并且对 $p \geq q > 0$, $X_n \xrightarrow{L^p} X \implies X_n \xrightarrow{L^q} X \implies X_n \xrightarrow{\mathbb{P}} X$ 。一般情况下, 图中未标出的逆向蕴含均不成立。

证明. 若 $X_n \xrightarrow{\text{a.s.}} X$, 则对固定 $\varepsilon > 0$, $\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \rightarrow 0$ a.s. 且示性函数由 1 控制。由控制收敛定理, $\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{E}\mathbf{1}_{\{|X_n - X| > \varepsilon\}} \rightarrow 0$ 。故 $X_n \xrightarrow{\mathbb{P}} X$ 。

若 $X_n \xrightarrow{\mathbb{P}} X$, 取 F_X 的连续点 x 。对任意 $\delta > 0$, $\{X_n \leq x\} \subseteq \{X \leq x + \delta\} \cup \{|X_n - X| > \delta\}$, 所以 $\limsup_n F_{X_n}(x) \leq F_X(x + \delta)$ 。同理, $\{X \leq x - \delta\} \subseteq \{X_n \leq x\} \cup \{|X_n - X| > \delta\}$, 从而 $F_X(x - \delta) \leq \liminf_n F_{X_n}(x)$ 。令 $\delta \downarrow 0$, 利用 F_X 在 x 处连续, 得到 $F_{X_n}(x) \rightarrow F_X(x)$ 。

若 $p \geq q > 0$, 由概率空间总质量为 1 和 Lyapunov 不等式, $(\mathbb{E}|X_n - X|^q)^{1/q} \leq (\mathbb{E}|X_n - X|^p)^{1/p}$ 。故 L^p 收敛推出 L^q 收敛。


最后, 由 Markov 不等式, $\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}|X_n - X|^q}{\varepsilon^q} \rightarrow 0$ 。 □

推论 5.10 (收敛到常数时的特殊结论). 若 c 是常数, 则

$$X_n \xrightarrow{d} c \iff X_n \xrightarrow{\mathbb{P}} c. \quad (5.7)$$

证明. 依概率收敛推出依分布收敛已证。反之, 对任意 $\varepsilon > 0$, 闭集 $C_\varepsilon = (-\infty, c - \varepsilon] \cup [c + \varepsilon, \infty)$ 不包含 c 。由 Portmanteau 定理, $\limsup_n \mathbb{P}(|X_n - c| \geq \varepsilon) \leq \mathbb{P}(c \in C_\varepsilon) = 0$ 。 □

收敛关系图



除非增加控制、单调性、一致可积性或其他结构, 否则不能反向使用箭头。

5.4 所有常见逆命题的标准反例

5.4.1 依概率收敛不推出几乎处处收敛

令 A_n 相互独立, 且 $\mathbb{P}(A_n) = \frac{1}{n}$. 定义 $X_n = \mathbf{1}_{A_n}$. 则 $\mathbb{E}|X_n| = \frac{1}{n} \rightarrow 0$, 所以 $X_n \xrightarrow{L^1} 0$, 从而 $X_n \xrightarrow{\mathbb{P}} 0$. 但 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$, 由第二 Borel-Cantelli 引理, $\mathbb{P}(A_n \text{ i.o.}) = 1$. 因此 X_n 几乎处处取值 1 无穷多次, 不可能几乎处处收敛到 0.

该反例同时说明: L^1 收敛不推出 a.s. 收敛。

5.4.2 几乎处处收敛不推出 L^1 收敛

令 $U \sim \text{Unif}(0, 1)$, 定义

$$X_n = n\mathbf{1}_{\{U \leq 1/n\}}. \quad (5.8)$$

对几乎每个 $U > 0$, 最终有 $U > 1/n$, 故 $X_n \xrightarrow{\text{a.s.}} 0$. 但 $\mathbb{E}|X_n| = n \cdot \frac{1}{n} = 1$. 所以 X_n 不在 L^1 中收敛到 0.

5.4.3 依分布收敛不推出依概率收敛

令 X 为非退化对称随机变量, 例如 $X \sim \mathbf{N}(0, 1)$, 并定义 $X_n = (-1)^n X$. 由于 $X \stackrel{d}{=} -X, X_n \stackrel{d}{=} X$ 对所有 n , 所以 $X_n \stackrel{d}{\rightarrow} X$. 但对所有奇数 n , $\mathbb{P}(|X_n - X| > \varepsilon) = \mathbb{P}(2|X| > \varepsilon) > 0$, 故 X_n 不依概率收敛于 X .

5.4.4 依分布收敛不推出矩收敛

仍取 $X_n = n\mathbf{1}_{\{U \leq 1/n\}}$. 有 $X_n \xrightarrow{\mathbb{P}} 0, X_n \xrightarrow{d} 0$, 但 $\mathbb{E}X_n = 1 \not\rightarrow 0$. 该失败正是由稀有但幅度巨大的尾部质量造成的; 一致可积性用于排除此类现象。

易错点与失分点

“ $X_n \xrightarrow{d} X$, 所以 $\mathbb{E}X_n \rightarrow \mathbb{E}X$ ”是资格考试中最常见的错误之一。必须额外证明:

- 随机变量有界; 或
- 存在统一可积控制变量; 或
- $\{X_n\}$ 一致可积; 或
- 相应高阶矩一致有界, 从而推出一致可积。

一些需要记忆的内容

- (1) 依概率收敛为什么不要每一条样本路径最终稳定?
- (2) 构造“a.s. 收敛但期望不收敛”反例时, 应让异常事件的概率和幅度满足什么关系?
- (3) 为什么 $X_n \stackrel{d}{=} X$ 对所有 n 仍不能推出 $X_n \xrightarrow{\mathbb{P}} X$?
- (4) 依分布收敛到常数为什么是一个特殊情形?

5.5 依概率收敛的子列原理

定理 5.11 (子列刻画). 【必须会完整证明】



以下两条等价:

- (1) $X_n \xrightarrow{\mathbb{P}} X$;
- (2) X_n 的每一个子列都含有一个进一步子列, 该进一步子列几乎处处收敛于 X 。

证明. 先设 $X_n \xrightarrow{\mathbb{P}} X$. 任取子列 $\{X_{n_{j_k}}\}$. 可递归选择 $j_k \uparrow \infty$, 使 $\mathbb{P}(|X_{n_{j_k}} - X| > 2^{-k}) \leq 2^{-k}$. 于是 $\sum_{k=1}^{\infty} \mathbb{P}(|X_{n_{j_k}} - X| > 2^{-k}) < \infty$. 由第一 Borel-Cantelli 引理, $\mathbb{P}(|X_{n_{j_k}} - X| > 2^{-k} \text{ i.o.}) = 0$. 因此几乎处处存在随机整数 $K(\omega)$, 使对 $k \geq K(\omega)$, $|X_{n_{j_k}}(\omega) - X(\omega)| \leq 2^{-k}$. 故 $X_{n_{j_k}} \xrightarrow{\text{a.s.}} X$.

反之, 假设每个子列均存在几乎处处收敛于 X 的进一步子列, 但 X_n 不依概率收敛于 X . 则存在 $\varepsilon, \delta > 0$ 和一个子列 $\{X_{n_j}\}$, 使 $\mathbb{P}(|X_{n_j} - X| > \varepsilon) \geq \delta$ 对所有 j . 根据假设, 该子列含有进一步子列 $X_{n_{j_k}} \xrightarrow{\text{a.s.}} X$. 几乎处处收敛推出依概率收敛, 故 $\mathbb{P}(|X_{n_{j_k}} - X| > \varepsilon) \rightarrow 0$, 与其始终不小于 δ 矛盾. $\square$

从依概率收敛抽取 a.s. 子列

识别信号: 需要把依概率收敛转化为逐点论证, 或需要使用只能处理 a.s. 收敛的定理。

标准构造: 选择子列使 $\mathbb{P}(|X_{n_k} - X| > \varepsilon_k) \leq \delta_k$, 其中 $\varepsilon_k \downarrow 0$, $\sum_k \delta_k < \infty$. 再用第一 Borel-Cantelli 引理。

常见失败: 只取满足概率趋于零的任意子列, 而未保证概率可求和。

5.6 $O_{\mathbb{P}}$ 与 $o_{\mathbb{P}}$ 记号

定义 5.12 (随机阶). 设 $a_n > 0$.

- (1) 若 $\frac{X_n}{a_n} \xrightarrow{\mathbb{P}} 0$, 则记 $X_n = o_{\mathbb{P}}(a_n)$.
- (2) 若 $\{X_n/a_n\}$ 依概率有界, 即对任意 $\varepsilon > 0$, 存在 $M < \infty$, 使 $\limsup_{n \rightarrow \infty} \mathbb{P}(|X_n| > Ma_n) \leq \varepsilon$, 则记 $X_n = O_{\mathbb{P}}(a_n)$.

命题 5.13 (基本运算法则). (1) $X_n \xrightarrow{\mathbb{P}} X$ 推出 $X_n = O_{\mathbb{P}}(1)$;

- (2) $O_{\mathbb{P}}(a_n) + O_{\mathbb{P}}(a_n) = O_{\mathbb{P}}(a_n)$;
- (3) $O_{\mathbb{P}}(a_n)o_{\mathbb{P}}(b_n) = o_{\mathbb{P}}(a_nb_n)$;
- (4) $o_{\mathbb{P}}(a_n) + o_{\mathbb{P}}(a_n) = o_{\mathbb{P}}(a_n)$.


乘积法则的证明. 设 $U_n = O_{\mathbb{P}}(1)$, $V_n = o_{\mathbb{P}}(1)$. 给定 $\varepsilon, \eta > 0$, 先选 M 使 $\limsup_n \mathbb{P}(|U_n| > M) < \eta$. 再由 $V_n \xrightarrow{\mathbb{P}} 0$, $\mathbb{P}(|V_n| > \frac{\varepsilon}{M}) \rightarrow 0$. 于是 $\mathbb{P}(|U_n V_n| > \varepsilon) \leq \mathbb{P}(|U_n| > M) + \mathbb{P}(|V_n| > \frac{\varepsilon}{M})$. 取上极限后不超过 η . 由于 η 任意, $U_n V_n \xrightarrow{\mathbb{P}} 0$. $\square$

注 5.14. 在渐近统计中, $\hat{\theta}_n - \theta = \frac{1}{\sqrt{n}} O_{\mathbb{P}}(1)$ 表示 $\sqrt{n}$ 速率; $R_n = o_{\mathbb{P}}(n^{-1/2})$ 表示余项在 $\sqrt{n}$ 尺度下可忽略。

5.7 连续映射定理

定理 5.15 (连续映射定理). 设 $g: \mathbb{R}^d \rightarrow \mathbb{R}^k$ 为 Borel 可测函数, 其不连续点集合为 D_g .

- (1) 若 $X_n \xrightarrow{\text{a.s.}} X$ 且 $\mathbb{P}(X \in D_g) = 0$, 则 $g(X_n) \xrightarrow{\text{a.s.}} g(X)$.
- (2) 若 $X_n \xrightarrow{\mathbb{P}} X$ 且 $\mathbb{P}(X \in D_g) = 0$, 则 $g(X_n) \xrightarrow{\mathbb{P}} g(X)$.
- (3) 若 $X_n \xrightarrow{d} X$ 且 $\mathbb{P}(X \in D_g) = 0$, 则 $g(X_n) \xrightarrow{d} g(X)$.



证明. 第一点逐路径使用连续性即可。

对第二点, 任取子列 $\{X_{n_j}\}$ 。由 定理 5.11, 存在进一步子列 $X_{n_{j_k}} \xrightarrow{\text{a.s.}} X$ 。除去零概率集合后, $X(\omega) \notin D_g$, 故 $g(X_{n_{j_k}}) \rightarrow g(X)$ a.s. 再次使用子列刻画, 得到 $g(X_n) \xrightarrow{\mathbb{P}} g(X)$ 。

第三点是 Portmanteau 定理的标准推论。对任意闭集 C , $\{x : g(x) \in C\}$ 可能不是闭集, 但其闭包与原集合的差异只能在 g 的不连续点处影响极限概率。利用 $\mathbb{P}(X \in D_g) = 0$ 可完成闭集上界论证。□

前提条件检查

连续映射定理不要求 g 处处连续, 只要求 $\mathbb{P}(X \in D_g) = 0$ 。例如 $g(x) = \mathbf{1}_{\{x \leq a\}}$ 在 a 处不连续。若 $\mathbb{P}(X = a) = 0$, 则 $\mathbf{1}_{\{X_n \leq a\}} \xrightarrow{d} \mathbf{1}_{\{X \leq a\}}$ 可以成立; 若 $\mathbb{P}(X = a) > 0$, 则不能机械使用。

5.8 Slutsky 定理

定理 5.16 (Slutsky 定理). 若 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{\mathbb{P}} c$, 其中 c 为常数, 则 $(X_n, Y_n) \xrightarrow{d} (X, c)$ 。因此:

$$X_n + Y_n \xrightarrow{d} X + c, \quad (5.9)$$

$$X_n Y_n \xrightarrow{d} cX, \quad (5.10)$$

$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}, \quad c \neq 0. \quad (5.11)$$

证明思路

对任意 $s, t \in \mathbb{R}$,

$$\left| \mathbb{E} e^{i(sX_n + tY_n)} - e^{itc} \mathbb{E} e^{isX_n} \right| \leq \mathbb{E} |e^{itY_n} - e^{itc}|.$$

由于 $Y_n \xrightarrow{\mathbb{P}} c$, 右侧趋于 0; 这是因为被积函数有界且依概率趋于零。同时 $\mathbb{E} e^{isX_n} \rightarrow \mathbb{E} e^{isX}$ 。故联合特征函数趋于 $\varphi_X(s)e^{itc}$, 即 (X, c) 的联合特征函数。再对加法、乘法和除法使用连续映射定理。

易错点与失分点

除法结论必须要求 $c \neq 0$ 。若分母极限为零, 即使 Y_n 从不等于零, X_n/Y_n 也可能发散或需要完全不同的归一化。

渐近代数题

若已知 $X_n \xrightarrow{d} X$, $R_n = o_{\mathbb{P}}(1)$, $Y_n \xrightarrow{\mathbb{P}} c$, 则考场中应写:

- (1) $R_n \xrightarrow{\mathbb{P}} 0$;
- (2) 由 Slutsky, $X_n + R_n \xrightarrow{d} X$;
- (3) 若 $c \neq 0$, $\frac{X_n + R_n}{Y_n} \xrightarrow{d} \frac{X}{c}$;
- (4) 明确指出所用映射在极限点处连续。

5.9 真题完整解法：乘积收敛与 L^1 反例

往年真题

2024 Spring 第 3 题, 10 分。

- (1) 若 $X_n \xrightarrow{\mathbb{P}} X$ 且 $Y_n \xrightarrow{\mathbb{P}} Y$, 证明 $X_n Y_n \xrightarrow{\mathbb{P}} XY$.
 (2) 判断: 若 $X_n \xrightarrow{L^1} X$ 且 $Y_n \xrightarrow{L^1} Y$, 是否必有 $X_n Y_n \xrightarrow{L^1} XY$?

解: 第一问

由 $X_n \xrightarrow{\mathbb{P}} X$, 有 $X_n = O_{\mathbb{P}}(1)$ 。同时 $Y_n - Y = o_{\mathbb{P}}(1)$, $X_n - X = o_{\mathbb{P}}(1)$, $Y = O_{\mathbb{P}}(1)$ 。分解 $X_n Y_n - XY = X_n(Y_n - Y) + Y(X_n - X)$ 。由 定理 5.13, $X_n(Y_n - Y) = o_{\mathbb{P}}(1)$, $Y(X_n - X) = o_{\mathbb{P}}(1)$ 。因此 $X_n Y_n - XY = o_{\mathbb{P}}(1)$, 即 $X_n Y_n \xrightarrow{\mathbb{P}} XY$ 。

也可由 $(X_n, Y_n) \xrightarrow{\mathbb{P}} (X, Y)$ 和连续映射 $g(x, y) = xy$ 直接得到。

第二问

该陈述为假。

令 $U \sim \text{Unif}(0, 1)$, 并定义 $X_n = Y_n = \sqrt{n} \mathbf{1}_{\{U \leq 1/n\}}$, $X = Y = 0$ 。则 $\mathbb{E}|X_n| = \sqrt{n} \cdot \frac{1}{n} = \frac{1}{\sqrt{n}} \rightarrow 0$, 所以 $X_n \xrightarrow{L^1} 0$, $Y_n \xrightarrow{L^1} 0$ 。但是 $X_n Y_n = n \mathbf{1}_{\{U \leq 1/n\}}$, 故 $\mathbb{E}|X_n Y_n - XY| = n \cdot \frac{1}{n} = 1$ 。因此 $X_n Y_n \not\xrightarrow{L^1} 0$ 。

结论为 L^1 收敛对乘法并不封闭。

□

考试时需要注意的地方

第二问的反例必须同时核查:

- (1) 两个因子分别确实在 L^1 中收敛;
- (2) 乘积仍可积;
- (3) 乘积的 L^1 距离不趋于零。

只写“可能有大尾部”而不给出具体随机变量, 不能获得完整分数。

注 5.17. 若进一步假设 $X_n \xrightarrow{L^p} X$, $Y_n \xrightarrow{L^q} Y$, $\frac{1}{p} + \frac{1}{q} = 1$, 则由 Hölder 不等式可以推出 $X_n Y_n \xrightarrow{L^1} XY$ 。事实上,

$$\mathbb{E}|X_n Y_n - XY| \leq \mathbb{E}|X_n(Y_n - Y)| + \mathbb{E}|Y(X_n - X)| \leq \|X_n\|_p \|Y_n - Y\|_q + \|Y\|_q \|X_n - X\|_p,$$

而 $\|X_n\|_p$ 有界。

5.10 Borel–Cantelli 引理

5.10.1 无限次发生事件

定义 5.18 (无限次发生). 对事件序列 $\{A_n\}$, 定义

$$\{A_n \text{ i.o.}\} = \limsup_{n \rightarrow \infty} A_n = \bigcap_{m=1}^{\infty} \bigcup_{n \geq m} A_n. \quad (5.12)$$

该事件表示 A_n 发生无穷多次。



其补事件为 $\{A_n \text{ 仅发生有限多次}\} = \bigcup_{m=1}^{\infty} \bigcap_{n \geq m} A_n^c$ 。

5.10.2 第一 Borel–Cantelli 引理

定理 5.19 (第一 Borel–Cantelli 引理). **【必须会完整证明】**

若 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) < \infty$, 则 $\mathbb{P}(A_n \text{ i.o.}) = 0$ 。不需要任何独立性条件。

证明. 对任意 m , $\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) \leq \sum_{n \geq m} \mathbb{P}(A_n)$ 。右侧是收敛级数的尾和, 因此当 $m \rightarrow \infty$ 时趋于 0。同时 $\bigcup_{n \geq m} A_n \downarrow \bigcap_{m=1}^{\infty} \bigcup_{n \geq m} A_n = \{A_n \text{ i.o.}\}$ 。由概率测度从上连续, $\mathbb{P}(A_n \text{ i.o.}) = \lim_{m \rightarrow \infty} \mathbb{P}\left(\bigcup_{n \geq m} A_n\right) = 0$ 。□

5.10.3 第二 Borel–Cantelli 引理

定理 5.20 (第二 Borel–Cantelli 引理). **【必须会完整证明】**

若事件 $A_1, A_2, \dots$ 相互独立, 且 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \infty$, 则 $\mathbb{P}(A_n \text{ i.o.}) = 1$ 。

证明. 固定 m 。由独立性, 对 $N \geq m$,

$$\mathbb{P}\left(\bigcap_{n=m}^N A_n^c\right) = \prod_{n=m}^N [1 - \mathbb{P}(A_n)] \leq \exp\left\{-\sum_{n=m}^N \mathbb{P}(A_n)\right\},$$

其中使用 $1 - x \leq e^{-x}$ 。由于级数发散, $N \rightarrow \infty$ 时右侧趋于 0。故 $\mathbb{P}\left(\bigcap_{n=m}^{\infty} A_n^c\right) = 0$, 即 $\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) = 1$ 。对所有 m 取交, $\mathbb{P}\left(\bigcap_{m=1}^{\infty} \bigcup_{n \geq m} A_n\right) = 1$ 。这正是 $\mathbb{P}(A_n \text{ i.o.}) = 1$ 。□

前提条件检查


第二 Borel–Cantelli 引理中的独立性不能静默删除。

在 $\Omega = (0, 1)$ 上令 $A_n = (0, 1/n)$ 。则 $\sum_n \mathbb{P}(A_n) = \sum_n \frac{1}{n} = \infty$, 但 $A_n \downarrow \emptyset$, 所以 $\mathbb{P}(A_n \text{ i.o.}) = 0$ 。

5.10.4 两两独立版本

命题 5.21. 若 A_n 两两独立, 且 $\sum_n \mathbb{P}(A_n) = \infty$, 则仍有 $\mathbb{P}(A_n \text{ i.o.}) = 1$ 。

证明. 固定 m , 令 $S_{m,N} = \sum_{n=m}^N \mathbf{1}_{A_n}$, $\mu_{m,N} = \mathbb{E}S_{m,N} = \sum_{n=m}^N \mathbb{P}(A_n)$ 。两两独立给出 $\text{Var}(S_{m,N}) = \sum_{n=m}^N \text{Var}(\mathbf{1}_{A_n}) \leq \mu_{m,N}$ 。由 Cauchy–Schwarz 不等式, $\mathbb{E}S_{m,N} = \mathbb{E}[S_{m,N} \mathbf{1}_{\{S_{m,N} > 0\}}] \leq \sqrt{\mathbb{E}S_{m,N}^2} \sqrt{\mathbb{P}(S_{m,N} > 0)}$ 。因此 $\mathbb{P}(S_{m,N} > 0) \geq \frac{\mu_{m,N}^2}{\mathbb{E}S_{m,N}^2} = \frac{\mu_{m,N}^2}{\text{Var}(S_{m,N}) + \mu_{m,N}^2} \geq \frac{\mu_{m,N}^2}{\mu_{m,N} + \mu_{m,N}^2}$ 。令 $N \rightarrow \infty$, 由于 $\mu_{m,N} \rightarrow \infty$, $\mathbb{P}\left(\bigcup_{n \geq m} A_n\right) = 1$ 。再对 m 取交即可。□



Borel-Cantelli 识别信号

看到以下关键词时，应立即考虑 Borel-Cantelli:

- “最终总有”，“只有有限多次”，“无穷多次”；
- $\limsup X_n/a_n$ ；
- 最大值的几乎处处阶；
- 稀有大跳；
- 从概率估计升级到 a.s. 结论。

标准步骤是定义 $A_n = \{|X_n| > \varepsilon_n\}$ ，然后检查 $\sum_n \mathbb{P}(A_n)$ 收敛还是发散，并明确是否具有足够的独立性。

5.11 真题完整解法：指数变量的极值

往年真题

2024 Spring 第 2 题，15 分。

设 $X_1, X_2, \dots$ i.i.d., 且 $\mathbb{P}(X_k > x) = e^{-x}$, $x \geq 0$ 。令 $M_n = \max_{1 \leq k \leq n} X_k$ 。证明 $\limsup_{n \rightarrow \infty} \frac{X_n}{\log n} = 1$ a.s., 以及 $\frac{M_n}{\log n} \rightarrow 1$ a.s.

解：第一步：证明单项序列的上界

固定 $\varepsilon > 0$ ，令 $A_n^+ = \{X_n > (1 + \varepsilon) \log n\}$ 。则 $\mathbb{P}(A_n^+) = n^{-(1+\varepsilon)}$ 。因此 $\sum_{n=2}^{\infty} \mathbb{P}(A_n^+) < \infty$ 。由第一 Borel-Cantelli 引理， $\mathbb{P}(A_n^+ \text{ i.o.}) = 0$ 。故几乎处处最终有 $X_n \leq (1 + \varepsilon) \log n$ ，从而 $\limsup_{n \rightarrow \infty} \frac{X_n}{\log n} \leq 1 + \varepsilon$ a.s.

第二步：证明单项序列的下界

令 $A_n^- = \{X_n > (1 - \varepsilon) \log n\}$ 。则 $\mathbb{P}(A_n^-) = n^{-(1-\varepsilon)}$ 。由于 $\sum_{n=2}^{\infty} n^{-(1-\varepsilon)} = \infty$ ，且事件 A_n^- 独立，第二 Borel-Cantelli 引理给出 $\mathbb{P}(A_n^- \text{ i.o.}) = 1$ 。所以 $\limsup_{n \rightarrow \infty} \frac{X_n}{\log n} \geq 1 - \varepsilon$ a.s. 令 ε 沿正有理数趋于零，得到

$$\limsup_{n \rightarrow \infty} \frac{X_n}{\log n} = 1 \quad \text{a.s.}$$

第三步：样本最大值的上界

由第一部分，几乎处处对任意 $\varepsilon > 0$ ，存在随机整数 N ，使对所有 $k \geq N$ ， $X_k \leq (1 + \varepsilon) \log k$ 。因此对 $n \geq N$ ， $M_n \leq \max\{\max_{1 \leq k < N} X_k, (1 + \varepsilon) \log n\}$ 。有限个初始变量的最大值除以 $\log n$ 趋于零，所以 $\limsup_{n \rightarrow \infty} \frac{M_n}{\log n} \leq 1 + \varepsilon$ a.s.


第四步：样本最大值的下界

对 $n \geq 2$,

$$\mathbb{P}(M_n \leq (1 - \varepsilon) \log n) = \left[1 - n^{-(1-\varepsilon)}\right]^n \leq \exp(-n^\varepsilon).$$

而 $\sum_{n=2}^{\infty} e^{-n^\varepsilon} < \infty$ 。由第一 Borel-Cantelli 引理，几乎处处最终有 $M_n > (1 - \varepsilon) \log n$ 。故 $\liminf_{n \rightarrow \infty} \frac{M_n}{\log n} \geq$

$1 - \varepsilon$ a.s. 再令 $\varepsilon \downarrow 0$ ，得到 $\frac{M_n}{\log n} \rightarrow 1$ a.s. $\square$



考试时需要注意的地方

本题两部分不能混为一谈：

- 对 X_n ，下界依赖第二 Borel–Cantelli 引理；
- 对 M_n ，需要证明整个序列的 $\liminf$ ，仅由 $M_n \geq X_n$ 只能得到 $\limsup$ 下界，不足以完成证明；
- 最大值下界应直接估计 $\mathbb{P}(M_n \leq u_n) = F(u_n)^n$ 。

5.12 一致可积**5.12.1 精确定义**

定义 5.22 (一致可积). 随机变量族 $\mathcal{K}$ 称为一致可积，若

$$\lim_{K \rightarrow \infty} \sup_{X \in \mathcal{K}} \mathbb{E} [|X| \mathbf{1}_{\{|X| > K\}}] = 0. \quad (5.13)$$

对序列 $\{X_n\}$ ，即要求 $\lim_{K \rightarrow \infty} \sup_n \mathbb{E} [|X_n| \mathbf{1}_{\{|X_n| > K\}}] = 0$ 。

一致可积控制的是所有随机变量的尾部期望，而不仅是尾部概率。

命题 5.23. 一致可积必然推出 L^1 一致有界：

$$\sup_{X \in \mathcal{K}} \mathbb{E}|X| < \infty. \quad (5.14)$$

证明. 由一致可积性，存在 K 使 $\sup_{X \in \mathcal{K}} \mathbb{E} [|X| \mathbf{1}_{\{|X| > K\}}] \leq 1$ 。于是 $\mathbb{E}|X| \leq K + \mathbb{E} [|X| \mathbf{1}_{\{|X| > K\}}] \leq K + 1$ 。□

 L^1 一致有界不推出一致可积

令 $X_n = n \mathbf{1}_{\{U \leq 1/n\}}$ 。则 $\sup_n \mathbb{E}|X_n| = 1$ 。但对任意固定 K ，取 $n > K$ ，则 $\mathbb{E} [|X_n| \mathbf{1}_{\{|X_n| > K\}}] = 1$ 。故 $\sup_n \mathbb{E} [|X_n| \mathbf{1}_{\{|X_n| > K\}}] = 1$ ，并不趋于零。

5.12.2 小概率集合刻画

定理 5.24 (一致绝对连续性刻画). 随机变量族 $\mathcal{K}$ 一致可积，当且仅当：

- (1) $\sup_{X \in \mathcal{K}} \mathbb{E}|X| < \infty$;
- (2) 对任意 $\varepsilon > 0$ ，存在 $\delta > 0$ ，使对所有事件 A 只要 $\mathbb{P}(A) < \delta$ ，就有

$$\sup_{X \in \mathcal{K}} \mathbb{E}[|X| \mathbf{1}_A] < \varepsilon. \quad (5.15)$$

证明. 先设 $\mathcal{K}$ 一致可积。 L^1 一致有界已证。给定 $\varepsilon > 0$ ，取 K 使 $\sup_{X \in \mathcal{K}} \mathbb{E} [|X| \mathbf{1}_{\{|X| > K\}}] < \frac{\varepsilon}{2}$ 。令 $\delta = \frac{\varepsilon}{2K}$ 。若 $\mathbb{P}(A) < \delta$ ，则

$$\mathbb{E}[|X| \mathbf{1}_A] \leq \mathbb{E}[|X| \mathbf{1}_{A \cap \{|X| \leq K\}}] + \mathbb{E}[|X| \mathbf{1}_{\{|X| > K\}}] \leq K\mathbb{P}(A) + \frac{\varepsilon}{2} < \varepsilon.$$

反之，设两条件成立，并令 $C = \sup_{X \in \mathcal{K}} \mathbb{E}|X| < \infty$ 。给定 $\varepsilon > 0$ ，由第二条件选择 $\delta > 0$ 。若 $K > \frac{C}{\delta}$ ，则由 Markov 不等式， $\mathbb{P}(|X| > K) \leq \frac{\mathbb{E}|X|}{K} < \delta$ 对所有 $X \in \mathcal{K}$ 成立。因此 $\sup_{X \in \mathcal{K}} \mathbb{E} [|X| \mathbf{1}_{\{|X| > K\}}] < \varepsilon$ 。□

5.13 证明一致可积的标准判据

5.13.1 可积随机变量控制

命题 5.25 (控制变量判据). 若存在 $Y \in L^1$, 使对所有 $X \in \mathcal{K}$, $|X| \leq Y$ a.s., 则 $\mathcal{K}$ 一致可积。

证明. 若 $|X| > K$, 则 $Y > K$. 因此 $|X|\mathbf{1}_{\{|X|>K\}} \leq Y\mathbf{1}_{\{Y>K\}}$. 故 $\sup_{X \in \mathcal{K}} \mathbb{E}[|X|\mathbf{1}_{\{|X|>K\}}] \leq \mathbb{E}[Y\mathbf{1}_{\{Y>K\}}] \rightarrow 0$. $\square$

5.13.2 高阶矩一致有界

命题 5.26 (L^p 判据). 若存在 $p > 1$, 使 $\sup_{X \in \mathcal{K}} \mathbb{E}|X|^p < \infty$, 则 $\mathcal{K}$ 一致可积。

证明. 在事件 $\{|X| > K\}$ 上, $|X| \leq \frac{|X|^p}{K^{p-1}}$. 因此 $\mathbb{E}[|X|\mathbf{1}_{\{|X|>K\}}] \leq \frac{\mathbb{E}|X|^p}{K^{p-1}}$. 取上确界得 $\sup_{X \in \mathcal{K}} \mathbb{E}[|X|\mathbf{1}_{\{|X|>K\}}] \leq \frac{\sup_{X \in \mathcal{K}} \mathbb{E}|X|^p}{K^{p-1}} \rightarrow 0$. $\square$

前提条件检查

条件 $p > 1$ 不能替换为 $p = 1$. 反例 $X_n = n\mathbf{1}_{\{U \leq 1/n\}}$ 满足 $\sup_n \mathbb{E}|X_n| = 1$, 但不一致可积。

5.13.3 de la Vallée–Poussin 判据

定理 5.27 (de la Vallée–Poussin). 随机变量族 $\mathcal{K}$ 一致可积, 当且仅当存在凸、非负、递增函数 $\Phi: [0, \infty) \rightarrow [0, \infty)$, 使 $\frac{\Phi(x)}{x} \rightarrow \infty$ ($x \rightarrow \infty$) 且

$$\sup_{X \in \mathcal{K}} \mathbb{E}\Phi(|X|) < \infty. \quad (5.16)$$

证明思路

充分性是资格考试中必须会写的部分。令 $\varepsilon_K = \sup_{x \geq K} \frac{x}{\Phi(x)}$. 由 $\Phi(x)/x \rightarrow \infty$, $\varepsilon_K \rightarrow 0$. 因此

$$\mathbb{E}[|X|\mathbf{1}_{\{|X|>K\}}] \leq \varepsilon_K \mathbb{E}[\Phi(|X|)\mathbf{1}_{\{|X|>K\}}] \leq \varepsilon_K \sup_{Y \in \mathcal{K}} \mathbb{E}\Phi(|Y|).$$

取上确界即得一致可积。

必要性的证明通过选择递增阈值 K_j , 使统一尾期望按几何速度下降, 再构造分段线性的凸函数 Φ ; 资格考试通常只要求掌握该构造框架。

常用选择包括 $\Phi(x) = x^p, p > 1$, 以及 $\Phi(x) = x \log^+ x$.

5.13.4 条件期望族的一致可积性

命题 5.28. 若 $X \in L^1$, 则当 $\mathcal{G}$ 遍历任意子 σ -代数时, $\{\mathbb{E}[X | \mathcal{G}]\}$ 构成一致可积族。

证明. 由条件 Jensen 不等式, $|\mathbb{E}[X | \mathcal{G}]| \leq \mathbb{E}[|X| | \mathcal{G}]$. 令 $A_{\mathcal{G}, K} = \{|\mathbb{E}[X | \mathcal{G}]| > K\} \in \mathcal{G}$. 则 $\mathbb{P}(A_{\mathcal{G}, K}) \leq \frac{\mathbb{E}|\mathbb{E}[X | \mathcal{G}]|}{K} \leq \frac{\mathbb{E}|X|}{K}$, 该上界与 $\mathcal{G}$ 无关。并且

$$\mathbb{E}[|\mathbb{E}[X | \mathcal{G}]|\mathbf{1}_{A_{\mathcal{G}, K}}] \leq \mathbb{E}[\mathbb{E}[|X| | \mathcal{G}]\mathbf{1}_{A_{\mathcal{G}, K}}] = \mathbb{E}[|X|\mathbf{1}_{A_{\mathcal{G}, K}}].$$

由于 $X \in L^1$, Lebesgue 积分对小概率集合绝对连续; 而 $\sup_{\mathcal{G}} \mathbb{P}(A_{\mathcal{G},K}) \leq \frac{\mathbb{E}|X|}{K} \rightarrow 0$. 故右侧一致趋于零。□

注 5.29. 该命题是后续证明闭鞅 $M_n = \mathbb{E}[X | \mathcal{F}_n]$ 一致可积并在 L^1 中收敛的核心工具。

一致可积证明流程

按以下优先顺序寻找条件:

- (1) 是否有统一可积控制变量 $|X_n| \leq Y \in L^1$;
- (2) 是否有某个 $p > 1$ 使 $\sup_n \mathbb{E}|X_n|^p < \infty$;
- (3) 是否能找到超线性凸函数 Φ 满足 $\sup_n \mathbb{E}\Phi(|X_n|) < \infty$;
- (4) 是否能直接估计 $\sup_n \mathbb{E}[|X_n|; |X_n| > K]$;
- (5) 若对象是条件期望, 考虑 定理 5.28。

5.14 Vitali 收敛定理

定理 5.30 (依概率收敛与一致可积). 【必须会完整证明】

设 $X_n \in L^1$, 且 $X_n \xrightarrow{\mathbb{P}} X$. 则下列条件等价:

- (1) $\{X_n\}$ 一致可积;
- (2) $X \in L^1$ 且 $X_n \xrightarrow{L^1} X$;
- (3) $X \in L^1$ 且 $\mathbb{E}|X_n| \rightarrow \mathbb{E}|X|$.

证明. (1) $\Rightarrow$ (2)

先证明 $X \in L^1$. 由依概率收敛的子列原理, 存在子列 $X_{n_k} \xrightarrow{\text{a.s.}} X$. 由 Fatou 引理, $\mathbb{E}|X| \leq \liminf_{k \rightarrow \infty} \mathbb{E}|X_{n_k}| \leq \sup_n \mathbb{E}|X_n| < \infty$.

定义截断函数 $\phi_K(x) = \begin{cases} -K, & x < -K, \\ x, & |x| \leq K, \\ K, & x > K. \end{cases}$ 则 ϕ_K 连续且 1-Lipschitz. 由连续映射定理, $\phi_K(X_n) \xrightarrow{\mathbb{P}} \phi_K(X)$.

又因为 $|\phi_K(X_n) - \phi_K(X)| \leq 2K$, 有界依概率收敛推出 L^1 收敛: $\mathbb{E}|\phi_K(X_n) - \phi_K(X)| \rightarrow 0$. 并且

$$|X_n - X| \leq |X_n - \phi_K(X_n)| + |\phi_K(X_n) - \phi_K(X)| + |\phi_K(X) - X|.$$

其中 $|Y - \phi_K(Y)| \leq |Y| \mathbf{1}_{\{|Y| > K\}}$. 因此

$$\mathbb{E}|X_n - X| \leq \mathbb{E}|\phi_K(X_n) - \phi_K(X)| + \mathbb{E}[|X_n|; |X_n| > K] + \mathbb{E}[|X|; |X| > K].$$

先由一致可积性及 $X \in L^1$ 选取足够大的 K 控制后两项, 再令 $n \rightarrow \infty$ 控制第一项, 得到 $\mathbb{E}|X_n - X| \rightarrow 0$.

(2) $\Rightarrow$ (1): 令 $D_n = X_n - X$. 由 L^1 收敛, $\mathbb{E}|D_n| \rightarrow 0$. 因此 $\{D_n\}$ 一致可积: 对给定 $\varepsilon > 0$, 大 n 时 $\mathbb{E}[|D_n|; |D_n| > K] \leq \mathbb{E}|D_n| < \varepsilon$, 而有限个早期 D_n 自动构成一致可积族。

单元素族 $\{X\}$ 一致可积, 两个一致可积族之和仍一致可积. 由于 $X_n = X + D_n$, 故 $\{X_n\}$ 一致可积。

(2) $\Rightarrow$ (3): 由反三角不等式, $|\mathbb{E}|X_n| - \mathbb{E}|X|| \leq \mathbb{E}||X_n| - |X|| \leq \mathbb{E}|X_n - X| \rightarrow 0$.

(3) $\Rightarrow$ (2): 先证明如下 Scheffé 型结论: 若非负随机变量 $U_n \rightarrow U$ a.s. 且 $\mathbb{E}U_n \rightarrow \mathbb{E}U < \infty$, 则 $\mathbb{E}|U_n - U| \rightarrow 0$

0。事实上, $|U_n - U| = U_n + U - 2(U_n \wedge U)$, 而 $U_n \wedge U \rightarrow U$ a.s., $0 \leq U_n \wedge U \leq U$ 。由控制收敛定理, $\mathbb{E}(U_n \wedge U) \rightarrow \mathbb{E}U$ 。

现任取 $\{X_n\}$ 的一个子列。由依概率收敛, 可抽取进一步子列 $X_{n_k} \xrightarrow{\text{a.s.}} X$ 。于是 $|X_{n_k}| \rightarrow |X|$ a.s. 且 $\mathbb{E}|X_{n_k}| \rightarrow \mathbb{E}|X|$ 。由上述非负 Scheffé 结论, $\mathbb{E}||X_{n_k}| - |X|| \rightarrow 0$ 。又有不等式 $|x - y| \leq ||x| - |y|| + 2|y|\mathbf{1}_{\{xy < 0\}}$ 。当 $X_{n_k} \rightarrow X$ a.s. 时, $\mathbf{1}_{\{X_{n_k}X < 0\}} \rightarrow 0$ a.s. 在 $\{X \neq 0\}$ 上, 而在 $\{X = 0\}$ 上第二项本身为零。由控制收敛, $\mathbb{E}[2|X|\mathbf{1}_{\{X_{n_k}X < 0\}}] \rightarrow 0$ 。故 $\mathbb{E}|X_{n_k} - X| \rightarrow 0$ 。

由于原序列的每一个子列都含有一个 L^1 收敛的进一步子列, 只能有 $\mathbb{E}|X_n - X| \rightarrow 0$ 。 $\square$

考试重点

Vitali 定理的核心思想是 依概率收敛 + 一致可积 $\iff L^1$ 收敛。依概率收敛控制“主体”, 一致可积控制“尾部”。

易错点与失分点

- (1) $\sup_n \mathbb{E}|X_n| < \infty$ 不能替代一致可积;
- (2) 仅有 a.s. 收敛也不能直接使用 Vitali, 必须再证明 UI;
- (3) 一致可积是一个随机变量族的性质, 不是单个极限过程的名称;
- (4) 若只证明每个固定 n 的尾期望趋于零, 仍不足够; 必须对 n 取上确界。

5.15 依分布收敛下的期望与矩收敛

定理 5.31 (弱收敛加一致可积). 设 $X_n \xrightarrow{d} X$, 且 $\{X_n\}$ 一致可积。则 $X \in L^1$, 并且

$$\mathbb{E}X_n \rightarrow \mathbb{E}X. \quad (5.17)$$

证明. 先令 $h_K(x) = |x| \wedge K$ 。该函数有界连续。由弱收敛, $\mathbb{E}h_K(X_n) \rightarrow \mathbb{E}h_K(X)$ 。因此 $\mathbb{E}h_K(X) \leq \sup_n \mathbb{E}|X_n| < \infty$ 。令 $K \rightarrow \infty$, 由单调收敛, $\mathbb{E}|X| < \infty$ 。


再令 $\phi_K(x) = (-K) \vee (x \wedge K)$ 。它也是有界连续函数, 所以 $\mathbb{E}\phi_K(X_n) \rightarrow \mathbb{E}\phi_K(X)$ 。并且 $|\mathbb{E}X_n - \mathbb{E}\phi_K(X_n)| \leq \mathbb{E}[|X_n|; |X_n| > K]$, 而 $|\mathbb{E}X - \mathbb{E}\phi_K(X)| \leq \mathbb{E}[|X|; |X| > K]$ 。一致可积性控制第一项, $X \in L^1$ 控制第二项。先选大 K , 再令 $n \rightarrow \infty$, 得到 (5.17)。 $\square$

推论 5.32 (矩收敛). 若 $X_n \xrightarrow{d} X$, 且对某个 $r > 0$, $\{|X_n|^r : n \geq 1\}$ 一致可积, 则 $\mathbb{E}|X_n|^r \rightarrow \mathbb{E}|X|^r$ 。

证明. 由连续映射定理, $|X_n|^r \xrightarrow{d} |X|^r$ 。再对非负随机变量 $|X_n|^r$ 使用 **定理 5.31**。 $\square$

推论 5.33 (高阶矩控制低阶矩). 若 $X_n \xrightarrow{d} X$ 且存在 $s > r > 0$ 使 $\sup_n \mathbb{E}|X_n|^s < \infty$, 则 $\mathbb{E}|X_n|^r \rightarrow \mathbb{E}|X|^r$ 。

证明. 令 $Y_n = |X_n|^r$ 。则 $\sup_n \mathbb{E}|Y_n|^{s/r} = \sup_n \mathbb{E}|X_n|^s < \infty$, 且 $s/r > 1$ 。由 **定理 5.26**, $\{Y_n\}$ 一致可积。 $\square$



证明矩收敛

若目标是 $\mathbb{E}g(X_n) \rightarrow \mathbb{E}g(X)$, 应分两步:

(1) 用连续映射定理证明 $g(X_n) \xrightarrow{d} g(X)$;

(2) 证明 $\{g(X_n)\}$ 一致可积。

只有第一步时, 只能得到分布收敛, 不能自动得到期望收敛。

5.16 Kolmogorov 最大不等式与随机级数

定理 5.34 (Kolmogorov 最大不等式). 设 $Y_1, \dots, Y_n$ 独立, 满足 $\mathbb{E}Y_k = 0$, $\mathbb{E}Y_k^2 < \infty$. 令 $S_j = \sum_{k=1}^j Y_k$. 则对任意 $\lambda > 0$,

$$\mathbb{P}\left(\max_{1 \leq j \leq n} |S_j| \geq \lambda\right) \leq \frac{\text{Var}(S_n)}{\lambda^2} = \frac{\sum_{k=1}^n \text{Var}(Y_k)}{\lambda^2}. \quad (5.18)$$

证明. 令 $A_j = \{|S_i| < \lambda, 1 \leq i < j, |S_j| \geq \lambda\}$. 这些事件两两不交, 且 $\bigcup_{j=1}^n A_j = \{\max_{1 \leq j \leq n} |S_j| \geq \lambda\}$. 事件 A_j 只依赖 $Y_1, \dots, Y_j$. 写 $S_n = S_j + (S_n - S_j)$. 由于 $S_n - S_j$ 与 A_j, S_j 独立, 且均值为零, $\mathbb{E}[S_j(S_n - S_j)\mathbf{1}_{A_j}] = 0$. 因此

$$\mathbb{E}[S_n^2 \mathbf{1}_{A_j}] = \mathbb{E}[S_j^2 \mathbf{1}_{A_j}] + \mathbb{E}[(S_n - S_j)^2 \mathbf{1}_{A_j}] \geq \lambda^2 \mathbb{P}(A_j).$$

对 j 求和: $\text{Var}(S_n) = \mathbb{E}S_n^2 \geq \lambda^2 \sum_{j=1}^n \mathbb{P}(A_j)$. 即得 (5.18). $\square$

定理 5.35 (平方可和方差的随机级数). 若 $Y_1, Y_2, \dots$ 独立, 且 $\mathbb{E}Y_k = 0$, $\sum_{k=1}^{\infty} \text{Var}(Y_k) < \infty$, 则随机级数 $\sum_{k=1}^{\infty} Y_k$ 几乎处处收敛, 并且部分和在 L^2 中收敛。

证明. 令 $S_n = \sum_{k=1}^n Y_k$. 若 $m < n$, 由独立性和中心化, $\mathbb{E}|S_n - S_m|^2 = \sum_{k=m+1}^n \text{Var}(Y_k) \rightarrow 0$. 故 $\{S_n\}$ 是 L^2 Cauchy 序列, 从而在 L^2 中收敛。

为证明 a.s. 收敛, 选择递增整数 N_r , 使 $\sum_{k > N_r} \text{Var}(Y_k) \leq 2^{-3r}$. 由 Kolmogorov 最大不等式, 对每个 $M > N_r$, $\mathbb{P}(\max_{N_r < j \leq M} |S_j - S_{N_r}| > 2^{-r}) \leq 2^{2r} \sum_{k > N_r} \text{Var}(Y_k) \leq 2^{-r}$. 令 $M \rightarrow \infty$, 由事件单调性, $\mathbb{P}(\sup_{j > N_r} |S_j - S_{N_r}| > 2^{-r}) \leq 2^{-r}$. 概率可求和. 由第一 Borel-Cantelli 引理, 几乎处处对充分大的 r , $\sup_{j > N_r} |S_j - S_{N_r}| \leq 2^{-r}$. 故 $\{S_n\}$ 几乎处处为 Cauchy 序列, 因而收敛. $\square$

5.17 真题完整解法: 随机级数与指数变换的 L^1 收敛

往年真题

2024 Fall 第 5 题, 15 分。

设 $X_1, X_2, \dots$ i.i.d., 服从率参数为 1 的指数分布, 并定义 $M_n = \sum_{k=1}^n \frac{X_k}{k}$.

(1) 证明 $M_n - \log n$ 几乎处处收敛;

(2) 对每个 $p \in (0, 1)$, 证明 $\frac{\exp(pM_n)}{n^p}$ 在 L^1 中收敛。

解: 第一问: 中心化随机级数

标准指数分布满足 $\mathbb{E}X_k = 1$, $\text{Var}(X_k) = 1$. 令 $Y_k = \frac{X_k - 1}{k}$. 则 Y_k 独立、中心化, 且 $\sum_{k=1}^{\infty} \text{Var}(Y_k) = \sum_{k=1}^{\infty} \frac{1}{k^2} < \infty$. 由 **定理 5.35**, $\sum_{k=1}^{\infty} \frac{X_k - 1}{k}$ 几乎处处收敛。

另一方面, 调和数 $H_n = \sum_{k=1}^n \frac{1}{k}$ 满足 $H_n - \log n \rightarrow \gamma$, 其中 γ 为 Euler 常数。因此

$$M_n - \log n = \sum_{k=1}^n \frac{X_k - 1}{k} + H_n - \log n \rightarrow Y \quad \text{a.s.}$$

其中 $Y = \sum_{k=1}^{\infty} \frac{X_k - 1}{k} + \gamma$ 。故 $M_n - \log n \rightarrow Y \quad \text{a.s.}$

第二问: 先得 a.s. 极限

令 $R_n = \frac{\exp(pM_n)}{n^p} = \exp\{p(M_n - \log n)\}$ 。由第一问和连续映射定理, $R_n \xrightarrow{\text{a.s.}} e^{pY}$ 。

要升级为 L^1 收敛, 只需证明 $\{R_n\}$ 一致可积。

第三步: 构造高阶矩界

由于 $p \in (0, 1)$, 可选择 $q > 1$ 使 $r := pq < 1$ 。则 $R_n^q = \frac{e^{rM_n}}{n^r}$ 。利用 X_k 独立, 且标准指数分布的 MGF 为 $\mathbb{E}e^{tX_k} = \frac{1}{1-t}$, $t < 1$, 得到

$$\mathbb{E}R_n^q = n^{-r} \prod_{k=1}^n \mathbb{E} \exp\left(\frac{r}{k} X_k\right) = n^{-r} \prod_{k=1}^n \left(1 - \frac{r}{k}\right)^{-1}.$$

取对数: $\log \mathbb{E}R_n^q = -r \log n - \sum_{k=1}^n \log\left(1 - \frac{r}{k}\right)$ 。因为 $0 < r < 1$, 有一致展开 $-\log(1-x) = x + O(x^2)$, $0 \leq x \leq r$ 。所以

$$-\sum_{k=1}^n \log\left(1 - \frac{r}{k}\right) = r \sum_{k=1}^n \frac{1}{k} + O\left(\sum_{k=1}^{\infty} \frac{1}{k^2}\right) = r \log n + O(1).$$

因此 $\sup_n \mathbb{E}R_n^q < \infty$ 。由于 $q > 1$, 由 定理 5.26, $\{R_n\}$ 一致可积。

第四步: 使用 Vitali 定理

已有 $R_n \xrightarrow{\text{a.s.}} e^{pY}$, 从而 $R_n \xrightarrow{\mathbb{P}} e^{pY}$, 并且 $\{R_n\}$ 一致可积。由 定理 5.30, $\frac{e^{pM_n}}{n^p} \xrightarrow{L^1} e^{pY}$ 。 □

为什么要求 $p \in (0, 1)$

若 $p \geq 1$, 则第一项已经造成问题: $\mathbb{E}e^{pX_1} = \infty$ 。因此 $\mathbb{E}\left[\frac{e^{pM_n}}{n^p}\right] = \infty$ 对所有 $n \geq 1$ 成立, 根本不能讨论通常意义下的 L^1 收敛。

考试时需要注意的地方

本题完整答案的结构必须是: 平方可和方差 $\implies$ 随机级数 a.s. 收敛, 连续映射 $\implies R_n \rightarrow R$ a.s., $\sup_n \mathbb{E}R_n^q < \infty$, $q > 1 \implies$ UI, a.s. 收敛 + UI $\implies L^1$ 收敛。只证明逐点极限, 不能得到第二问的完整分数。

5.18 常见证明套路归纳

套路一：概率估计升级为 a.s. 结论

识别信号：目标是“最终”，“无穷多次”，“ $\limsup$ ”，“a.s.”。

步骤：

- (1) 定义坏事件 A_n ;
- (2) 估计 $\mathbb{P}(A_n)$;
- (3) 判断概率级数收敛或发散;
- (4) 发散方向核查独立性;
- (5) 使用 Borel-Cantelli;
- (6) 对 $\varepsilon = 1/m$ 取可数交。

失败原因：直接令 $\varepsilon \rightarrow 0$ ，却未处理不同 ε 对应的零概率集合。

套路二：弱收敛升级为矩收敛

识别信号：已知 $X_n \xrightarrow{d} X$ ，目标是 $\mathbb{E}g(X_n) \rightarrow \mathbb{E}g(X)$ 。

步骤：

- (1) 用连续映射定理得到 $g(X_n) \xrightarrow{d} g(X)$;
- (2) 证明 $\{g(X_n)\}$ 一致可积;
- (3) 使用弱收敛加 UI 定理。

失败原因：把 Portmanteau 中“有界连续函数”错误地用于无界函数 $g(x) = x, x^2$ 。

套路三：依概率收敛升级为 L^1

识别信号：已知依概率或 a.s. 收敛，目标是交换期望、风险或积分。

步骤：

- (1) 证明极限变量可积;
- (2) 证明序列一致可积;
- (3) 使用 Vitali 定理。

常见 UI 工具： $|X_n| \leq Y \in L^1$, $\sup_n \mathbb{E}|X_n|^{1+\delta} < \infty$, 或 $\sup_n \mathbb{E}\Phi(|X_n|) < \infty$, $\Phi(x)/x \rightarrow \infty$ 。

套路四：构造收敛反例

- (1) **稀有大值：** $X_n = a_n \mathbf{1}_{A_n}$, $\mathbb{P}(A_n) = p_n$. 通过调整 $a_n p_n$ 控制一阶矩，调整 $a_n^2 p_n$ 控制二阶矩。
- (2) **移动事件：**令 $p_n \rightarrow 0$ 但 $\sum p_n = \infty$ ，并使事件独立，可得到依概率收敛但不 a.s. 收敛。
- (3) **保持边缘分布、改变耦合：**令 $X_n = (-1)^n X$ 且 X 对称，可得到依分布收敛而不依概率收敛。




5.19 易错点总表

陈述	判断	正确说明
$X_n \xrightarrow{d} X$ 推出 $\mathbb{E}X_n \rightarrow \mathbb{E}X$	错	需要有界性、一致可积性或其他尾部控制。
$X_n \xrightarrow{\mathbb{P}} X$ 推出 $X_n \xrightarrow{\text{a.s.}} X$	错	只能保证每个子列存在 a.s. 收敛的进一步子列。
$X_n \xrightarrow{L^1} X$ 推出 $X_n \xrightarrow{\text{a.s.}} X$	错	独立事件 $\mathbb{P}(A_n) = 1/n$ 的示性函数给出反例。
$X_n \xrightarrow{\text{a.s.}} X$ 推出 $X_n \xrightarrow{L^1} X$	错	需要控制收敛或一致可积；稀有大值是标准反例。
$\sup_n \mathbb{E} X_n < \infty$ 等价于 UI	错	UI 比 L^1 有界严格更强。
$\sum_n \mathbb{P}(A_n) = \infty$ 推出 A_n i.o.	错	第二 Borel-Cantelli 需要独立性或足够弱的依赖条件。
连续映射定理要求 g 处处连续	过强	只需 $\mathbb{P}(X \in D_g) = 0$ 。
Slutsky 的除法结论可用于 $Y_n \xrightarrow{\mathbb{P}} 0$	错	极限分母必须非零。
L^1 收敛对乘法封闭	错	需要更高阶矩或 Hölder 共轭条件。
每个 X_n 的尾期望趋于零即可得到 UI	错	必须对 n 取统一上确界。

5.20 本章快速自测

一些需要记忆的内容

- (1) 证明：若 $\sum_n \mathbb{P}(|X_n - X| > \varepsilon) < \infty$ 对每个 $\varepsilon > 0$, 则 $X_n \xrightarrow{\text{a.s.}} X$ 。是否真的需要对所有实数 $\varepsilon > 0$ 检查?
- (2) 构造 $X_n \xrightarrow{\mathbb{P}} 0$ 但 $\mathbb{E}X_n^2 \rightarrow \infty$ 的例子。
- (3) 若 $X_n \xrightarrow{d} X$ 且 $\sup_n \mathbb{E}|X_n|^{2+\delta} < \infty$, 可以推出哪些一阶、二阶矩结论?
- (4) 设 $X_n \xrightarrow{\mathbb{P}} X$ 且 $|X_n| \leq Y_n$, $Y_n \xrightarrow{L^1} Y$. 如何证明 $X_n \xrightarrow{L^1} X$?
- (5) 第二 Borel-Cantelli 中, 相互独立、两两独立分别能得到什么?
- (6) 为什么 $X_n = n\mathbf{1}_{\{U \leq 1/n\}}$ 同时是否定多个错误命题的核心反例?
- (7) 若 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{\mathbb{P}} c \neq 0$, $R_n = o_{\mathbb{P}}(1)$, 求 $\frac{X_n + R_n}{Y_n}$ 的极限分布。
- (8) 证明一族随机变量 UI 时, 为什么 $\sup_n \mathbb{E}|X_n|^{1+\delta} < \infty$ 通常是最快的充分条件?



第六章 大数律、截断法与随机级数

6.1 考纲定位、重要性与历年考法

重点

S 级

【必须会完整证明】：弱大数律的截断证明、独立变量的方差判据、Kronecker 引理、i.i.d. 强大数律的截断证明。

【必须会复现证明框架】：Kolmogorov 三列定理的必要性、随机级数收敛的最大不等式方法。

【必须会熟练应用】：Borel–Cantelli、等价序列、分块、稀有大跳与非同分布强大数律。

考试重点

大数律问题的核心不是机械判断 $\frac{S_n}{n} \rightarrow \mathbb{E}X_1$ ，而是依次检查：

- (1) 随机变量是否独立、同分布；
- (2) 一阶矩是否存在；
- (3) 结论要求依概率收敛还是几乎处处收敛；
- (4) 是否存在极少发生但幅度极大的跳跃；
- (5) 是否需要截断，并证明原序列与截断序列等价；
- (6) 能否将随机级数收敛转化为平均值收敛。

往年真题

本章直接对应或支撑以下真题：


- 2024 Spring 第 2 题，15 分：利用 Borel–Cantelli 研究指数变量及其最大值；
- 2024 Fall 第 5 题，15 分：随机级数、平方可和方差与 L^1 收敛；
- 2025 Fall 第 4 题，15 分：稀有正向大跳和持续负向小步共同导致 $\liminf \frac{S_n}{n} < 0 < \limsup \frac{S_n}{n}$ ；
- 2026 Spring 第 2 题，15 分：可求和的异常大跳与三角阵列中心极限定理。

6.2 弱大数律与强大数律的精确定义

定义 6.1 (弱大数律). 设 $S_n = X_1 + \cdots + X_n$. 若存在常数 μ 使 $\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$, 则称该序列满足弱大数律 (weak law of large numbers)。

定义 6.2 (强大数律). 若 $\frac{S_n}{n} \xrightarrow{\text{a.s.}} \mu$, 则称该序列满足强大数律 (strong law of large numbers)。

强大数律立即推出弱大数律，但逆命题一般不成立。



易错点与失分点

“大数律”不是一个无条件公式。至少应明确：

- 随机变量是否同分布；
- 独立性或弱依赖条件；
- 一阶矩或方差条件；
- 收敛方式；
- 中心项是 $\mathbb{E}X_1$ 、 $n^{-1}\mathbb{E}S_n$ ，还是其他量。

6.3 最基本的方差型弱大数律

定理 6.3 (Chebyshev 型弱大数律). 设 $X_1, X_2, \dots$ 具有有限二阶矩, 令 $S_n = \sum_{k=1}^n X_k$. 若

$$\frac{\text{Var}(S_n)}{n^2} \rightarrow 0, \quad (6.1)$$

则

$$\frac{S_n - \mathbb{E}S_n}{n} \xrightarrow{\mathbb{P}} 0. \quad (6.2)$$

证明. 对任意 $\varepsilon > 0$, 由 Chebyshev 不等式, $\mathbb{P}\left(\left|\frac{S_n - \mathbb{E}S_n}{n}\right| > \varepsilon\right) \leq \frac{\text{Var}(S_n)}{n^2\varepsilon^2} \rightarrow 0$. $\square$

推论 6.4. 若 X_k 相互独立, 且 $\frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) \rightarrow 0$, 则 $\frac{S_n - \mathbb{E}S_n}{n} \xrightarrow{\mathbb{P}} 0$.

推论 6.5 (有限方差的 i.i.d. 弱大数律). 若 $X_1, X_2, \dots$ i.i.d., 且 $\mathbb{E}X_1 = \mu$, $\text{Var}(X_1) = \sigma^2 < \infty$, 则 $\bar{X}_n = \frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$.

注 6.6. 有限方差只是一种容易检查的充分条件。i.i.d. 弱大数律实际上只需 $\mathbb{E}|X_1| < \infty$ 。证明这一更强结论必须使用截断。


6.4 截断法与等价序列

定义 6.7 (等价随机变量序列). 称随机变量序列 $\{X_n\}$ 与 $\{Y_n\}$ 等价, 若

$$\sum_{n=1}^{\infty} \mathbb{P}(X_n \neq Y_n) < \infty. \quad (6.3)$$

命题 6.8 (等价序列的后果). 若 $\{X_n\}$ 与 $\{Y_n\}$ 等价, 则由第一 Borel–Cantelli 引理, $\mathbb{P}(X_n \neq Y_n \text{ i.o.}) = 0$. 因此几乎处处只有有限多个 n 满足 $X_n \neq Y_n$, 从而:

- (1) $\sum_{n=1}^{\infty} (X_n - Y_n)$ 几乎处处收敛;
- (2) $\frac{1}{n} \sum_{k=1}^n (X_k - Y_k) \xrightarrow{\text{a.s.}} 0$;
- (3) $\sum X_n$ 与 $\sum Y_n$ 的几乎处处收敛性相同;
- (4) $n^{-1} \sum_{k \leq n} X_k$ 与 $n^{-1} \sum_{k \leq n} Y_k$ 具有相同的依概率或几乎处处极限。



截断法标准流程

识别信号：随机变量缺少二阶矩，或存在极少发生的巨大值。

构造：选择阈值 $a_n \uparrow \infty$ ，令 $Y_n = X_n \mathbf{1}_{\{|X_n| \leq a_n\}}$ 。

必须完成的三项检查：

- (1) **异常部分可忽略：** $\sum_n \mathbb{P}(|X_n| > a_n) < \infty$ 或至少证明相应概率趋于零；
- (2) **中心化部分可控：** 估计 $\sum \text{Var}(Y_n)$ 或 $\text{Var}\left(\sum_{k \leq n} Y_k\right)$ ；
- (3) **截断均值正确：** 证明 $\frac{1}{n} \sum_{k=1}^n \mathbb{E}Y_k \rightarrow \mu$ 。

常见失败：只对随机变量做了截断，却没有证明截断误差确实可以忽略。

6.5 有限一阶矩的 i.i.d. 弱大数律

定理 6.9 (Khinchin 弱大数律). 【必须会完整证明】

设 $X_1, X_2, \dots$ i.i.d., 且 $\mathbb{E}|X_1| < \infty$, $\mathbb{E}X_1 = \mu$ 。则 $\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$ 。

证明. 令 $Z \stackrel{d}{=} X_1$ ，并对每个 k 定义 $Y_k = X_k \mathbf{1}_{\{|X_k| \leq k\}}$, $T_n = \sum_{k=1}^n Y_k$ 。

第一步：证明原序列与截断序列等价

由尾和判据和 $\mathbb{E}|Z| < \infty$, $\sum_{k=1}^{\infty} \mathbb{P}(|Z| > k) < \infty$ 。因此 $\sum_{k=1}^{\infty} \mathbb{P}(X_k \neq Y_k) = \sum_{k=1}^{\infty} \mathbb{P}(|Z| > k) < \infty$ 。故

$$\frac{S_n - T_n}{n} \xrightarrow{\text{a.s.}} 0. \quad (6.4)$$

第二步：处理截断均值

由控制收敛定理, $\mathbb{E}[Z \mathbf{1}_{\{|Z| \leq k\}}] \rightarrow \mathbb{E}Z = \mu$ 。因此由 Cesàro 平均,

$$\frac{\mathbb{E}T_n}{n} = \frac{1}{n} \sum_{k=1}^n \mathbb{E}[Z \mathbf{1}_{\{|Z| \leq k\}}] \rightarrow \mu. \quad (6.5)$$

第三步：控制截断和的方差

由于 Y_k 独立, $\text{Var}(T_n) = \sum_{k=1}^n \text{Var}(Y_k) \leq \sum_{k=1}^n \mathbb{E}Y_k^2$ 。又因为 $\mathbb{E}Y_k^2 = \mathbb{E}[Z^2 \mathbf{1}_{\{|Z| \leq k\}}] \leq \mathbb{E}[Z^2 \mathbf{1}_{\{|Z| \leq n\}}]$, 所以 $\frac{\text{Var}(T_n)}{n^2} \leq \frac{1}{n} \mathbb{E}[Z^2 \mathbf{1}_{\{|Z| \leq n\}}]$ 。逐点有 $0 \leq \frac{1}{n} Z^2 \mathbf{1}_{\{|Z| \leq n\}} \leq |Z|$ 。并且该随机变量逐点趋于 0。由控制收敛定理, $\frac{\text{Var}(T_n)}{n^2} \rightarrow 0$ 。故由 Chebyshev 不等式,

$$\frac{T_n - \mathbb{E}T_n}{n} \xrightarrow{\mathbb{P}} 0. \quad (6.6)$$

结合 (6.4)、(6.5) 和 (6.6), 由 Slutsky 定理, $\frac{S_n}{n} \xrightarrow{\mathbb{P}} \mu$ 。□



有限一阶矩不是弱大数律的必要条件

考虑对称分布 $\mathbb{P}(Z = k) = \mathbb{P}(Z = -k) = \frac{c}{k^2 \log k}$, $k = 2, 3, \dots$, 其中 c 为归一化常数。则 $\mathbb{E}|Z| = 2c \sum_{k=2}^{\infty} \frac{1}{k \log k} = \infty$ 。但若 X_i i.i.d. 服从该分布, 仍有 $\frac{S_n}{n} \xrightarrow{\mathbb{P}} 0$ 。

证明思路是统一在水平 n 截断: $T_n = \sum_{j=1}^n X_j \mathbf{1}_{\{|X_j| \leq n\}}$ 。可验证 $\mathbb{P}(S_n \neq T_n) \leq n\mathbb{P}(|Z| > n) = O\left(\frac{1}{\log n}\right) \rightarrow 0$, 且 $\text{Var}(T_n) = n\mathbb{E}[Z^2 \mathbf{1}_{\{|Z| \leq n\}}] = O\left(\frac{n^2}{\log n}\right)$ 。再用 Chebyshev 不等式即可。

6.6 Kolmogorov 三列定理**定理 6.10 (Kolmogorov 三列定理). 【必须会复现证明框架】**

设 $X_1, X_2, \dots$ 相互独立。固定 $A > 0$, 令 $Y_n = X_n \mathbf{1}_{\{|X_n| \leq A\}}$ 。则随机级数 $\sum_{n=1}^{\infty} X_n$ 几乎处处收敛, 当且仅当以下三个数值级数均收敛:

$$\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > A), \quad (6.7)$$

$$\sum_{n=1}^{\infty} \mathbb{E}Y_n, \quad (6.8)$$

$$\sum_{n=1}^{\infty} \text{Var}(Y_n). \quad (6.9)$$

条件对某个 $A > 0$ 成立即等价于对每个 $A > 0$ 成立。

充分性的完整证明. 若 (6.7) 收敛, 则 $\sum_n \mathbb{P}(X_n \neq Y_n) < \infty$ 。由第一 Borel–Cantelli 引理, $X_n = Y_n$ 最终成立, 故只需证明 $\sum Y_n$ 几乎处处收敛。

由 (6.9) 和 定理 5.35, $\sum_{n=1}^{\infty} (Y_n - \mathbb{E}Y_n)$ 几乎处处收敛。再由 (6.8), $\sum_{n=1}^{\infty} \mathbb{E}Y_n$ 作为确定性级数收敛。因此 $\sum_{n=1}^{\infty} Y_n = \sum_{n=1}^{\infty} (Y_n - \mathbb{E}Y_n) + \sum_{n=1}^{\infty} \mathbb{E}Y_n$ 几乎处处收敛, 进而 $\sum X_n$ 几乎处处收敛。□

必要性证明框架

设 $\sum X_n$ 几乎处处收敛。

- (1) 必有 $X_n \rightarrow 0$ a.s., 所以 $\mathbb{P}(|X_n| > A \text{ i.o.}) = 0$ 。事件独立, 由第二 Borel–Cantelli 引理的逆否命题, $\sum_n \mathbb{P}(|X_n| > A) < \infty$ 。因而 X_n 与 Y_n 最终相同, $\sum Y_n$ 也 a.s. 收敛。
- (2) Y_n 一致有界。使用有界独立随机变量的反向最大不等式: 若某一段的方差和趋于无穷, 则该段部分和以高概率不能始终停留在一个固定小区间中。这与已收敛级数的尾部一致 Cauchy 性矛盾, 故 $\sum_n \text{Var}(Y_n) < \infty$ 。
- (3) 由平方可和方差, $\sum_n (Y_n - \mathbb{E}Y_n)$ a.s. 收敛。它与已知收敛的 $\sum Y_n$ 相减, 得到 $\sum_n \mathbb{E}Y_n$ 收敛。

前提条件检查

三列定理需要独立性。若没有独立性, 方差可加、第二 Borel–Cantelli 和最大不等式中的交叉项消失均可能失败。

例 6.11 (Rademacher 随机级数). 设 ε_n 独立, 且 $\mathbb{P}(\varepsilon_n = 1) = \mathbb{P}(\varepsilon_n = -1) = \frac{1}{2}$ 。则 $\sum_{n=1}^{\infty} \frac{\varepsilon_n}{n}$ 几乎处处收敛, 因为 $\sum_n \text{Var}\left(\frac{\varepsilon_n}{n}\right) = \sum_n \frac{1}{n^2} < \infty$ 。但 $\sum_{n=1}^{\infty} \frac{\varepsilon_n}{\sqrt{n}}$ 几乎处处发散, 因为其方差级数 $\sum_n \frac{1}{n}$ 发散, 而大跳概率与均

值级数均无问题。

6.7 Kronecker 引理

引理 6.12 (Kronecker 引理). 【必须会完整证明】

设 $a_n > 0$ 且 $a_n \uparrow \infty$ 。若数值级数 $\sum_{n=1}^{\infty} \frac{x_n}{a_n}$ 收敛, 则

$$\frac{1}{a_n} \sum_{k=1}^n x_k \rightarrow 0. \quad (6.10)$$

证明. 令 $b_n = \sum_{k=1}^n \frac{x_k}{a_k}$, $a_0 = b_0 = 0$ 。则 $x_k = a_k(b_k - b_{k-1})$ 。由分部求和,

$$\frac{1}{a_n} \sum_{k=1}^n x_k = \frac{1}{a_n} \sum_{k=1}^n a_k(b_k - b_{k-1}) = b_n - \frac{1}{a_n} \sum_{k=0}^{n-1} (a_{k+1} - a_k)b_k.$$

设 $b_n \rightarrow b$ 。由于 $\frac{a_{k+1}-a_k}{a_n} \geq 0$, $\sum_{k=0}^{n-1} \frac{a_{k+1}-a_k}{a_n} = 1$, 第二项是 $b_0, \dots, b_{n-1}$ 的加权平均, 且权重最终集中于大指标。故 $\frac{1}{a_n} \sum_{k=0}^{n-1} (a_{k+1} - a_k)b_k \rightarrow b$ 。于是 (6.10) 成立。□

考试重点

随机级数与大数律之间的标准桥梁是: $\sum_{n=1}^{\infty} \frac{X_n - \mathbb{E}X_n}{n}$ a.s. 收敛 $\implies \frac{1}{n} \sum_{k=1}^n (X_k - \mathbb{E}X_k) \xrightarrow{\text{a.s.}} 0$ 。其中最后一步正是 Kronecker 引理。

6.8 独立非同分布变量的强大数律

定理 6.13 (Kolmogorov 强大数律判据). 设 $X_1, X_2, \dots$ 相互独立, 具有有限二阶矩, 并满足

$$\sum_{n=1}^{\infty} \frac{\text{Var}(X_n)}{n^2} < \infty. \quad (6.11)$$

则


$$\frac{1}{n} \sum_{k=1}^n (X_k - \mathbb{E}X_k) \xrightarrow{\text{a.s.}} 0. \quad (6.12)$$

证明. 令 $Y_n = \frac{X_n - \mathbb{E}X_n}{n}$ 。则 Y_n 独立、中心化, 且 $\sum_n \text{Var}(Y_n) = \sum_n \frac{\text{Var}(X_n)}{n^2} < \infty$ 。由 定理 5.35, $\sum_{n=1}^{\infty} Y_n$ 几乎处处收敛。再由 Kronecker 引理, $\frac{1}{n} \sum_{k=1}^n (X_k - \mathbb{E}X_k) \xrightarrow{\text{a.s.}} 0$ 。□

推论 6.14. 若 X_n 相互独立, 且存在常数 C 使 $\text{Var}(X_n) \leq C$ 对所有 n , 则 $\frac{S_n - \mathbb{E}S_n}{n} \xrightarrow{\text{a.s.}} 0$ 。

6.9 i.i.d. 强大数律

定理 6.15 (Kolmogorov i.i.d. 强大数律). 【必须会完整证明】



设 $X_1, X_2, \dots$ i.i.d., 令 $S_n = \sum_{k=1}^n X_k$ 。若 $\mathbb{E}|X_1| < \infty$, 则

$$\frac{S_n}{n} \xrightarrow{\text{a.s.}} \mathbb{E}X_1. \quad (6.13)$$

反之, 若 $\mathbb{E}|X_1| = \infty$, 则

$$\limsup_{n \rightarrow \infty} \frac{|S_n|}{n} = \infty \quad \text{a.s.} \quad (6.14)$$

特别地, S_n/n 不可能几乎处处收敛到有限常数。

有限一阶矩时. 记 $\mu = \mathbb{E}X_1$, $Y_n = X_n \mathbf{1}_{\{|X_n| \leq n\}}$ 。

第一步：截断误差最终消失

由 $\mathbb{E}|X_1| < \infty$, $\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > n) = \sum_{n=1}^{\infty} \mathbb{P}(|X_1| > n) < \infty$ 。故 $X_n = Y_n$ 最终成立, 因而

$$\frac{1}{n} \sum_{k=1}^n (X_k - Y_k) \xrightarrow{\text{a.s.}} 0. \quad (6.15)$$

第二步：证明加权方差可和

令 $Z \stackrel{d}{=} X_1$ 。有

$$\sum_{n=1}^{\infty} \frac{\text{Var}(Y_n)}{n^2} \leq \sum_{n=1}^{\infty} \frac{\mathbb{E}[Z^2 \mathbf{1}_{\{|Z| \leq n\}}]}{n^2} = \mathbb{E} \left[Z^2 \sum_{n \geq |Z|} \frac{1}{n^2} \right].$$

存在绝对常数 C , 使对所有 $x \geq 0$, $x^2 \sum_{n \geq \max(1, \lceil x \rceil)} \frac{1}{n^2} \leq Cx$ 。因此 $\sum_{n=1}^{\infty} \frac{\text{Var}(Y_n)}{n^2} \leq C\mathbb{E}|Z| < \infty$ 。

由 定理 6.13,

$$\frac{1}{n} \sum_{k=1}^n (Y_k - \mathbb{E}Y_k) \xrightarrow{\text{a.s.}} 0. \quad (6.16)$$

第三步：截断均值趋于正确中心

由控制收敛定理, $\mathbb{E}Y_k = \mathbb{E}[X_1 \mathbf{1}_{\{|X_1| \leq k\}}] \rightarrow \mu$ 。由 Cesàro 平均,

$$\frac{1}{n} \sum_{k=1}^n \mathbb{E}Y_k \rightarrow \mu. \quad (6.17)$$

结合 (6.15)、(6.16) 和 (6.17), 得到 $\frac{S_n}{n} \xrightarrow{\text{a.s.}} \mu$ 。□

无限一阶矩时. 若 $\mathbb{E}|X_1| = \infty$, 则对任意 $A > 0$, $\sum_{n=1}^{\infty} \mathbb{P}(|X_n| > An) = \sum_{n=1}^{\infty} \mathbb{P}(|X_1| > An) = \infty$ 。事件相互独立, 故由第二 Borel–Cantelli 引理, $|X_n| > An$ i.o. a.s. 而 $X_n = S_n - S_{n-1}$ 。若 $|X_n| > An$, 则至少有一个不等式成立: $|S_n| > \frac{An}{2}$, $|S_{n-1}| > \frac{An}{2}$ 。因此 $\limsup_{m \rightarrow \infty} \frac{|S_m|}{m} \geq \frac{A}{2}$ a.s. 对 $A = 1, 2, \dots$ 取可数交, 得到 $\limsup_{m \rightarrow \infty} \frac{|S_m|}{m} = \infty$ a.s. □

前提条件检查

对 i.i.d. 强大数律而言, $\mathbb{E}|X_1| < \infty$ 不仅是充分条件, 而且是收敛到有限常数的必要条件。
但对弱大数律, 有限一阶矩并非必要条件。两者不能混淆。

6.10 真题完整解法：稀有大跳造成平均值双向振荡

往年真题

2025 Fall 第 4 题，15 分。

独立随机变量 X_n 满足 $\mathbb{P}(X_n = -1) = \frac{1}{2}$, $\mathbb{P}(X_n = 4n) = \frac{1}{8n}$, $\mathbb{P}(X_n = 0) = \frac{1}{2} - \frac{1}{8n}$ 。令 $S_n = \sum_{k=1}^n X_k$ 。
证明 $\liminf_{n \rightarrow \infty} \frac{S_n}{n} < 0 < \limsup_{n \rightarrow \infty} \frac{S_n}{n}$ a.s.

解：首先注意 $\mathbb{E}X_n = -\frac{1}{2} + 4n \cdot \frac{1}{8n} = 0$ ，但方差随 n 增长： $\text{Var}(X_n) = \mathbb{E}X_n^2 = \frac{1}{2} + 2n$ 。因此不能使用具有一致方差界的强大数律。

第一步：证明正的上极限

令 $A_n = \{X_n = 4n\}$ 。则 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \frac{1}{8n} = \infty$ 。事件 A_n 独立，由第二 Borel-Cantelli 引理， A_n i.o. a.s. 又因为每个 $X_k \geq -1$ ，所以 $S_{n-1} \geq -(n-1)$ 。在 A_n 上， $S_n = S_{n-1} + 4n \geq -(n-1) + 4n = 3n+1$ 。

故 $\limsup_{n \rightarrow \infty} \frac{S_n}{n} \geq 3$ a.s.

第二步：构造独立的大块

取整数序列 $n_2 = 1$, $n_{j+1} = j^4 n_j$, $j \geq 2$ 。令 $I_j = \{n_j + 1, \dots, n_{j+1}\}$, $L_j = |I_j| = n_{j+1} - n_j$ 。不同 I_j 不相交。

定义事件 $H_j = \{X_k \neq 4k, \forall k \in I_j\}$ ，即第 j 个块内没有正向大跳。

对 $0 \leq x \leq 1/2$ 有 $\log(1-x) \geq -2x$ 。因此

$$\mathbb{P}(H_j) = \prod_{k=n_j+1}^{n_{j+1}} \left(1 - \frac{1}{8k}\right) \geq \exp \left\{ -\frac{1}{4} \sum_{k=n_j+1}^{n_{j+1}} \frac{1}{k} \right\}.$$

而 $\sum_{k=n_j+1}^{n_{j+1}} \frac{1}{k} \leq \log \frac{n_{j+1}}{n_j} + 1 = 4 \log j + 1$ 。故存在常数 $c > 0$ ，使

$$\mathbb{P}(H_j) \geq \frac{c}{j}. \quad (6.18)$$

第三步：块内出现足够多的 -1

在条件 H_j 下，各 X_k 仍相互独立，并且 $\mathbb{P}(X_k = -1 \mid X_k \neq 4k) = \frac{1/2}{1-1/(8k)} \geq \frac{1}{2}$ 。令 $N_j = \sum_{k \in I_j} \mathbf{1}_{\{X_k = -1\}}$ 。条件于 H_j , $\mathbb{E}(N_j \mid H_j) \geq \frac{L_j}{2}$, $\text{Var}(N_j \mid H_j) \leq \frac{L_j}{4}$ 。由 Chebyshev 不等式, $\mathbb{P}\left(N_j < \frac{L_j}{3} \mid H_j\right) \leq \frac{L_j/4}{(L_j/6)^2} = \frac{9}{L_j} \rightarrow 0$ 。故对充分大的 j , $\mathbb{P}\left(N_j \geq \frac{L_j}{3} \mid H_j\right) \geq \frac{1}{2}$ 。

定义 $E_j = H_j \cap \left\{N_j \geq \frac{L_j}{3}\right\}$ 。由 (6.18), $\mathbb{P}(E_j) \geq \frac{c}{2j}$ 对充分大的 j 成立。因此 $\sum_j \mathbb{P}(E_j) = \infty$ 。事件 E_j 依赖于不相交的随机变量块，故相互独立。第二 Borel-Cantelli 引理给出

$$E_j \text{ i.o. a.s.} \quad (6.19)$$

第四步：控制每个块起点的已有部分和

由独立性， $\text{Var}(S_n) = \sum_{k=1}^n (2k + \frac{1}{2}) \leq Cn^2$ 对某个常数 C 成立。因此 $\mathbb{P}(|S_{n_j}| > jn_j) \leq \frac{Cn_j^2}{j^2 n_j^2} = \frac{C}{j^2}$ 。概

率可求和, 故由第一 Borel–Cantelli 引理,

$$|S_{n_j}| \leq j n_j \quad \text{最终 a.s.} \quad (6.20)$$

第五步：在好块末端得到负平均

在 E_j 上, 块内没有正向大跳, 且至少有 $L_j/3$ 个变量等于 -1 , 所以 $\sum_{k \in I_j} X_k \leq -\frac{L_j}{3}$ 。结合 (6.20), $S_{n_{j+1}} \leq j n_j - \frac{n_{j+1} - n_j}{3}$ 。由于 $n_{j+1} = j^4 n_j$,

$$\frac{S_{n_{j+1}}}{n_{j+1}} \leq \frac{1}{j^3} - \frac{1}{3} \left(1 - \frac{1}{j^4}\right) < -\frac{1}{4}$$

对充分大的 j 成立。

由 (6.19), 这样的 j 无穷多个, 故 $\liminf_{n \rightarrow \infty} \frac{S_n}{n} \leq -\frac{1}{4} < 0 \quad \text{a.s.}$ 与第一步结合, 得到题目结论。□

考试时需要注意的地方

这道 15 分题的标准得分结构是:

- (1) 用第二 Borel–Cantelli 证明正向大跳无穷多次;
 - (2) 用确定性下界 $S_{n-1} \geq -(n-1)$ 得到正的 $\limsup$;
 - (3) 选取互不相交的乘法尺度块;
 - (4) 证明“块内无大跳”的概率级数发散;
 - (5) 证明该块内有线性数量的 -1 ;
 - (6) 用 Chebyshev 加第一 Borel–Cantelli 控制块起点;
 - (7) 在块末端得到严格负的平均值。
- 只证明大跳无穷多次, 只能得到右侧不等式, 不能完成整题。

6.11 本章易错点

陈述	判断	正确说明
i.i.d. 加独立就一定满足强大数律	错	还需 $\mathbb{E} X_1 < \infty$ 才能收敛到有限均值。
弱大数律必须要求有限方差	错	有限一阶矩足够; 某些无限一阶矩分布也可能满足弱大数律。
$\sum \text{Var}(X_n) < \infty$ 推出 $\sum X_n$ 收敛	不完整	通常需中心化和独立性; 还要处理均值级数。
随机级数收敛等价于绝对收敛	错	$\sum \varepsilon_n/n$ a.s. 收敛但一般不绝对收敛。
截断变量收敛即可代替原变量	错	必须证明异常事件只发生有限次或概率趋于零。
$\mathbb{E}X_n = 0$ 推出 $S_n/n \rightarrow 0$	错	非同分布变量可能有随 n 增大的稀有大跳。
方差和可加不需要独立性	错	一般还存在协方差交叉项。
三列定理中的均值级数要求绝对收敛	错	只要求通常意义下的数值级数收敛。

一些需要记忆的内容

- (1) i.i.d. 强大数律的最弱标准矩条件是什么?
- (2) 截断证明中, 为什么必须同时控制异常概率、中心化方差和截断均值?
- (3) Kronecker 引理把哪一种随机级数结论转化成平均值结论?
- (4) 三列定理的三个级数分别控制什么现象?
- (5) 为什么 $\mathbb{E}X_n = 0$ 不能单独保证 $S_n/n \rightarrow 0$?



第七章 中心极限定理、三角阵列与 Poisson 收敛

7.1 考纲定位、重要性与历年考法

重点

S 级

【必须会完整证明】：经典 i.i.d. 中心极限定理的特征函数证明、Poisson 稀有事件极限定理。

【必须会复现证明框架】：Lindeberg–Feller 定理、Lyapunov 条件、异常项截断后使用 Slutsky。

【必须会熟练应用】：多元 CLT、非标准归一化、无限方差边界情形、三角阵列。

往年真题

本章的代表性真题包括：

- 2024 Spring 第 1 题，10 分：方差无穷但仍属于正态吸引域，归一化为 $\sqrt{n \log n}$ ；
- 2024 Fall 第 2 题，10 分：CLT 与 Delta 方法；
- 2025 Spring 第 9 题，15 分：多元 CLT 加 Delta 方法推导样本相关系数的渐近正态性；
- 2026 Spring 第 2 题，15 分：总方差被“几乎从不出现的大跳”污染，不能机械使用总标准差；
- 多套统计题中的 MLE、样本均值、样本比例和检验统计量，均以内含 CLT 为核心。

7.2 经典 i.i.d. 中心极限定理

定理 7.1 (Lindeberg–Lévy 中心极限定理). 【必须会完整证明】

设 $X_1, X_2, \dots$ i.i.d., 且 $\mathbb{E}X_1 = \mu$, $\text{Var}(X_1) = \sigma^2 \in (0, \infty)$ 。则

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathbf{N}(0, 1). \quad (7.1)$$

等价地, $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathbf{N}(0, \sigma^2)$ 。

证明. 令 $Y_k = \frac{X_k - \mu}{\sigma}$ 。则 $\mathbb{E}Y_k = 0$, $\mathbb{E}Y_k^2 = 1$ 。记 Y_1 的特征函数为 φ 。由二阶矩存在, $\varphi(u) = 1 - \frac{u^2}{2} + o(u^2)$, $u \rightarrow 0$ 。利用独立性,

$$\mathbb{E} \exp \left\{ it \frac{S_n - n\mu}{\sigma\sqrt{n}} \right\} = \left[\varphi \left(\frac{t}{\sqrt{n}} \right) \right]^n = \left[1 - \frac{t^2}{2n} + o \left(\frac{1}{n} \right) \right]^n \rightarrow e^{-t^2/2}.$$

右侧是标准正态分布的特征函数。由 Lévy 连续性定理, $\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathbf{N}(0, 1)$ 。□

前提条件检查

经典 CLT 的有限方差条件不能简单改成“均值存在”。若方差无穷：

- 极限可能仍为正态，但归一化不是 $\sqrt{n}$ ；
- 极限也可能是非高斯稳定分布，甚至可能不存在非退化极限。

推论 7.2 (二项分布的正态近似). 若 $B_n \sim \text{Bin}(n, p)$, $0 < p < 1$, 则 $\frac{B_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1)$ 。

注 7.3. CLT 给出的是渐近分布，不是精确分布。只有当原始变量本身正态时， $\frac{S_n - n\mu}{\sigma\sqrt{n}} \sim N(0, 1)$ 才对每个有限 n 精确成立。

7.3 多元中心极限定理

定理 7.4 (多元 i.i.d. CLT). 设 $X_1, X_2, \dots$ 为 $\mathbb{R}^d$ 值 i.i.d. 随机向量，满足 $\mathbb{E}X_1 = \mu$, $\text{Cov}(X_1) = \Sigma$, 且每个分量具有有限二阶矩。则

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N_d(0, \Sigma). \quad (7.2)$$

允许 Σ 奇异。

证明. 对任意 $a \in \mathbb{R}^d$, $a^\top \sqrt{n}(\bar{X}_n - \mu) = \frac{1}{\sqrt{n}} \sum_{k=1}^n a^\top (X_k - \mu)$ 。右侧是标量 i.i.d. 和，均值为零，方差为 $a^\top \Sigma a$ 。由一维 CLT, $a^\top \sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, a^\top \Sigma a)$ 。该分布正是 $a^\top Z$ 的分布，其中 $Z \sim N_d(0, \Sigma)$ 。由 Cramér-Wold 装置，得到 (7.2)。□

考试重点

涉及多个样本矩的渐近题，标准第一步通常是定义向量 $W_i = (X_i, Y_i, X_i^2, Y_i^2, X_i Y_i)^\top$ ，先对 $\bar{W}_n$ 使用多元 CLT，再对目标函数使用多元 Delta 方法。样本相关系数的渐近正态性即为这一母题。

7.4 三角阵列

定义 7.5 (三角阵列). 三角阵列是一族随机变量 $\{X_{n,k} : 1 \leq k \leq k_n, n \geq 1\}$ ，其中第 n 行为 $X_{n,1}, \dots, X_{n,k_n}$ 。通常假设每一行内部独立，但不要求不同行之间独立。

三角阵列允许每个加数的分布随 n 变化，对非同分布独立变量做标准化，处理截断变量，以及处理稀有事件与局部渐近模型。

7.5 Lindeberg–Feller 中心极限定理

7.5.1 归一化版本

定理 7.6 (Lindeberg–Feller 定理). 【必须会复现证明框架】

对每个 n ，设 $X_{n,1}, \dots, X_{n,k_n}$ 相互独立，且 $\mathbb{E}X_{n,k} = 0$ 。假设

$$\sum_{k=1}^{k_n} \mathbb{E}X_{n,k}^2 \longrightarrow \sigma^2 \in (0, \infty), \quad (7.3)$$



并且对每个 $\varepsilon > 0$,

$$\sum_{k=1}^{k_n} \mathbb{E} \left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| > \varepsilon\}} \right] \rightarrow 0. \quad (7.4)$$

则

$$\sum_{k=1}^{k_n} X_{n,k} \xrightarrow{d} \mathbf{N}(0, \sigma^2). \quad (7.5)$$

7.5.2 未归一化版本

设 $Y_{n,k}$ 每行独立, 并定义 $\mu_{n,k} = \mathbb{E}Y_{n,k}$, $s_n^2 = \sum_{k=1}^{k_n} \text{Var}(Y_{n,k})$ 。若 $s_n > 0$, 且对每个 $\varepsilon > 0$,

$$\frac{1}{s_n^2} \sum_{k=1}^{k_n} \mathbb{E} \left[(Y_{n,k} - \mu_{n,k})^2 \mathbf{1}_{\{|Y_{n,k} - \mu_{n,k}| > \varepsilon s_n\}} \right] \rightarrow 0, \quad (7.6)$$

则

$$\frac{\sum_{k=1}^{k_n} (Y_{n,k} - \mu_{n,k})}{s_n} \xrightarrow{d} \mathbf{N}(0, 1). \quad (7.7)$$

注 7.7. (7.6) 的含义是: 在总标准差尺度 s_n 上, 不允许少数单项携带不可忽略的二阶质量。

Lindeberg–Feller 的特征函数证明

记 $\sigma_{n,k}^2 = \mathbb{E}X_{n,k}^2$, $f_{n,k}(t) = \mathbb{E}e^{itX_{n,k}}$ 。目标是证明 $\prod_{k=1}^{k_n} f_{n,k}(t) \rightarrow e^{-\sigma^2 t^2/2}$ 。

第一步: Lindeberg 推出单项方差可忽略。

对任意 $\varepsilon > 0$, $\sigma_{n,k}^2 \leq \varepsilon^2 + \mathbb{E} \left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| > \varepsilon\}} \right]$ 。故

$$\max_{k \leq k_n} \sigma_{n,k}^2 \rightarrow 0. \quad (7.8)$$

第二步: 二阶 Taylor 近似。

设 $g_{n,k}(t) = 1 - \frac{t^2 \sigma_{n,k}^2}{2}$ 。利用 $|e^{ix} - 1 - ix + x^2/2| \leq C(|x|^3 \wedge x^2)$, 并在 $|X_{n,k}| \leq \varepsilon$ 和 $|X_{n,k}| > \varepsilon$ 上分解, 可得

$$|f_{n,k}(t) - g_{n,k}(t)| \leq C|t|^3 \varepsilon \mathbb{E} \left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| \leq \varepsilon\}} \right] + Ct^2 \mathbb{E} \left[X_{n,k}^2 \mathbf{1}_{\{|X_{n,k}| > \varepsilon\}} \right].$$

先对 k 求和, 再令 $n \rightarrow \infty$, 最后令 $\varepsilon \downarrow 0$, 得到 $\sum_{k=1}^{k_n} |f_{n,k}(t) - g_{n,k}(t)| \rightarrow 0$ 。

第三步: 乘积转化为对数和。

由 (7.8), $\max_k \frac{t^2 \sigma_{n,k}^2}{2} \rightarrow 0$ 。因此

$$\sum_{k=1}^{k_n} \log g_{n,k}(t) = \sum_{k=1}^{k_n} \log \left(1 - \frac{t^2 \sigma_{n,k}^2}{2} \right) = -\frac{t^2}{2} \sum_{k=1}^{k_n} \sigma_{n,k}^2 + o(1) \rightarrow -\frac{\sigma^2 t^2}{2}.$$

故 $\prod_{k=1}^{k_n} g_{n,k}(t) \rightarrow e^{-\sigma^2 t^2/2}$ 。再由两个乘积之差可由各项差之和控制, 得到 $\prod_{k=1}^{k_n} f_{n,k}(t) \rightarrow e^{-\sigma^2 t^2/2}$ 。最后使用 Lévy 连续性定理。

7.6 Feller 条件与 Lyapunov 条件

定义 7.8 (Feller 条件). 在未归一化记号下, Feller 条件为

$$\max_{1 \leq k \leq k_n} \frac{\text{Var}(Y_{n,k})}{s_n^2} \rightarrow 0. \quad (7.9)$$

Lindeberg 条件推出 Feller 条件, 但 Feller 条件本身不足以保证正态极限。

Feller 条件不充分

令 $B_{n,1}, \dots, B_{n,n} \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(\frac{1}{n})$, 并定义 $X_{n,k} = B_{n,k} - \frac{1}{n}$ 。则 $\sum_{k=1}^n \text{Var}(X_{n,k}) = 1 - \frac{1}{n} \rightarrow 1$, 且 $\max_k \text{Var}(X_{n,k}) = \frac{1}{n} (1 - \frac{1}{n}) \rightarrow 0$ 。故 Feller 条件成立。
然而 $\sum_{k=1}^n X_{n,k} = \text{Bin}(n, \frac{1}{n}) - 1 \xrightarrow{d} \text{Poisson}(1) - 1$, 并非正态分布。这里 Lindeberg 条件失败, 因为每一次成功产生约为 1 的跳跃, 在总标准差尺度下并不小。

定理 7.9 (Lyapunov 条件). 设 $Y_{n,k}$ 每行独立, s_n^2 为总方差。若存在 $\delta > 0$, 使


$$\frac{1}{s_n^{2+\delta}} \sum_{k=1}^{k_n} \mathbb{E} |Y_{n,k} - \mathbb{E} Y_{n,k}|^{2+\delta} \rightarrow 0, \quad (7.10)$$

则 $\frac{\sum_k (Y_{n,k} - \mathbb{E} Y_{n,k})}{s_n} \xrightarrow{d} N(0, 1)$ 。

证明. 在事件 $|Y_{n,k} - \mathbb{E} Y_{n,k}| > \varepsilon s_n$ 上, $|Y_{n,k} - \mathbb{E} Y_{n,k}|^2 \leq \frac{|Y_{n,k} - \mathbb{E} Y_{n,k}|^{2+\delta}}{(\varepsilon s_n)^\delta}$ 。因此 Lindeberg 表达式不超过 $\frac{1}{\varepsilon^\delta s_n^{2+\delta}} \sum_k \mathbb{E} |Y_{n,k} - \mathbb{E} Y_{n,k}|^{2+\delta}$, 由 (7.10) 趋于零。再使用 Lindeberg-Feller 定理。□

概念比较

条件	强弱关系	使用特点
Lindeberg 条件	最接近本质	直接控制超过总标准差尺度的二阶尾部
Lyapunov 条件	比 Lindeberg 强	有统一 $2 + \delta$ 阶矩时最容易检查
Feller 条件	比 Lindeberg 弱	只排除单项方差占比过大, 不足以保证正态



7.7 真题完整解法：无限方差下的非标准正态归一化

往年真题

2024 Spring 第 1 题, 10 分。

设 $X_1, X_2, \dots$ i.i.d., 密度为 $f(x) = |x|^{-3} \mathbf{1}_{\{|x|>1\}}$, 特征函数为 φ 。已知

$$\lim_{t \rightarrow 0} \frac{1 - \varphi(t)}{t^2 \log |t|} = -1. \quad (7.11)$$

求 $a_n > 0$, 使 $\frac{S_n}{a_n} \xrightarrow{d} N(0, 1)$ 。

解：第一问：验证二阶矩发散

密度已经归一化, 因为 $\int_{\mathbb{R}} f(x) dx = 2 \int_1^\infty x^{-3} dx = 1$ 。而 $\mathbb{E}X_1^2 = 2 \int_1^\infty x^2 x^{-3} dx = 2 \int_1^\infty \frac{dx}{x} = \infty$ 。分布对称, 因此 $\mathbb{E}X_1 = 0$ 且 $\varphi(t)$ 为实偶函数。

第二步：选择归一化

由 (7.11), $1 - \varphi(u) = -u^2 \log |u| [1 + o(1)]$ ($u \rightarrow 0$)。希望 $\left[\varphi\left(\frac{t}{a_n}\right)\right]^n \rightarrow e^{-t^2/2}$ 。这要求 $n \left[1 - \varphi\left(\frac{t}{a_n}\right)\right] \rightarrow \frac{t^2}{2}$ 。

取 $a_n = \sqrt{n \log n}$, 则对固定 $t \neq 0$, 有

$$n \left[1 - \varphi\left(\frac{t}{a_n}\right)\right] = -n \frac{t^2}{a_n^2} \log \left|\frac{t}{a_n}\right| [1 + o(1)] = \frac{t^2}{\log n} (\log a_n - \log |t|) [1 + o(1)].$$

由于 $\log a_n = \frac{1}{2} \log n + \frac{1}{2} \log \log n$, 所以 $\frac{\log a_n - \log |t|}{\log n} \rightarrow \frac{1}{2}$ 。故

$$n \left[1 - \varphi\left(\frac{t}{a_n}\right)\right] \rightarrow \frac{t^2}{2}. \quad (7.12)$$

第三步：从单项展开得到乘积极限

记 $u_n = 1 - \varphi\left(\frac{t}{a_n}\right)$ 。由 (7.12), $u_n \rightarrow 0$, $nu_n \rightarrow \frac{t^2}{2}$ 。并且 $nu_n^2 = (nu_n)u_n \rightarrow 0$ 。因此 $n \log(1 - u_n) = -nu_n + o(nu_n) \rightarrow -\frac{t^2}{2}$ 。于是 $\left[\varphi\left(\frac{t}{a_n}\right)\right]^n \rightarrow e^{-t^2/2}$ 。这正是 S_n/a_n 的特征函数极限。由 Lévy 连续性定理,

$$\frac{S_n}{\sqrt{n \log n}} \xrightarrow{d} N(0, 1).$$

□

考试时需要注意的地方

该题不能直接套用有限方差 CLT。完整得分步骤是：

- (1) 计算并明确写出 $\mathbb{E}X_1^2 = \infty$;
- (2) 根据给定的特征函数局部展开反推尺度;
- (3) 选取 $a_n = \sqrt{n \log n}$;
- (4) 证明 $n[1 - \varphi(t/a_n)] \rightarrow t^2/2$;
- (5) 再证明特征函数乘积趋于 $e^{-t^2/2}$;
- (6) 最后使用 Lévy 连续性定理。

7.8 真题完整解法：总方差被可求和异常大跳污染

往年真题

2026 Spring 第 2 题, 15 分。

独立随机变量 X_n 满足 $\mathbb{P}(X_n = n^2) = \mathbb{P}(X_n = -n^2) = \frac{1}{6n^2}$, $\mathbb{P}(X_n = n) = \mathbb{P}(X_n = -n) = \frac{1}{6}$, $\mathbb{P}(X_n = 0) = \frac{2}{3} - \frac{1}{3n^2}$. 令 $S_n = \sum_{j=1}^n X_j$. 求 $b_n > 0$, 使 $\frac{S_n}{b_n} \xrightarrow{d} \mathbf{N}(0, 1)$.

解：由于 $n = 1$ 时数值 n 与 n^2 重合，有限个初始项的具体合并方式不影响极限。以下从 $n \geq 2$ 讨论。

第一步：分解为常规部分与异常部分

定义 $Y_n = X_n \mathbf{1}_{\{|X_n|=n\}}$, $Z_n = X_n \mathbf{1}_{\{|X_n|=n^2\}}$. 则 $X_n = Y_n + Z_n$ 对 $n \geq 2$ 成立。

常规部分满足 $\mathbb{P}(Y_n = n) = \mathbb{P}(Y_n = -n) = \frac{1}{6}$, 其余情形 $Y_n = 0$. 因此 $\mathbb{E}Y_n = 0$, $\text{Var}(Y_n) = \frac{n^2}{3}$.

令

$$b_n^2 = \sum_{k=1}^n \frac{k^2}{3} = \frac{n(n+1)(2n+1)}{18}. \quad (7.13)$$

于是 $b_n \sim \frac{n^{3/2}}{3}$.

第二步：对常规部分使用 Lindeberg–Feller

对第 n 行定义 $U_{n,k} = \frac{Y_k}{b_n}$, $1 \leq k \leq n$. 则 $\sum_{k=1}^n \text{Var}(U_{n,k}) = 1$. 同时 $|U_{n,k}| \leq \frac{n}{b_n} \sim \frac{3}{\sqrt{n}} \rightarrow 0$. 因此对任意 $\varepsilon > 0$, 充分大的 n 满足 $|U_{n,k}| \leq \varepsilon$ 对所有 $k \leq n$. Lindeberg 条件最终恒为零，故

$$\frac{\sum_{k=1}^n Y_k}{b_n} \xrightarrow{d} \mathbf{N}(0, 1). \quad (7.14)$$

第三步：异常大跳只发生有限次

异常部分非零的概率为 $\mathbb{P}(Z_n \neq 0) = \frac{1}{3n^2}$. 因此 $\sum_{n=1}^{\infty} \mathbb{P}(Z_n \neq 0) < \infty$. 由第一 Borel–Cantelli 引理, $Z_n \neq 0$ 只发生有限多次 a.s., 所以随机级数 $\sum_{n=1}^{\infty} Z_n$ 实际上只有有限多个非零项。因而 $\frac{\sum_{k=1}^n Z_k}{b_n} \xrightarrow{\text{a.s.}} 0$.

第四步：使用 Slutsky 定理

由 $S_n = \sum_{k=1}^n Y_k + \sum_{k=1}^n Z_k$, 结合 (7.14) 和 Slutsky 定理, $\frac{S_n}{b_n} \xrightarrow{d} \mathbf{N}(0, 1)$, $b_n^2 = \frac{n(n+1)(2n+1)}{18}$. 也可

取渐近等价尺度 $b_n = \frac{n^{3/2}}{3}$. □

为什么不能直接使用总标准差

对原变量, $\text{Var}(X_n) = \frac{n^2}{3} + \frac{n^2}{3} = \frac{2n^2}{3}$. 因此 $s_n^2 = \text{Var}(S_n) = 2b_n^2$. 若机械取总标准差 s_n , 则 $\frac{S_n}{s_n} = \frac{1}{\sqrt{2}} \frac{S_n}{b_n} \xrightarrow{d} \mathbf{N}(0, \frac{1}{2})$, 而不是标准正态。

虽然每个 S_n/s_n 的方差都等于 1, 其极限分布方差却为 1/2. 原因是平方族不一致可积: 可求和的异常大跳几乎处处最终消失, 却贡献了与常规部分同阶的二阶矩。

考试时需要注意的地方

本题最关键的识别是: $\sum_n \mathbb{P}(|X_n| = n^2) < \infty$. 一旦发现异常大跳只发生有限次, 就应把它们从 CLT 主体中剥离。不能因为它们对方差有巨大贡献, 就把它纳入正态尺度。

7.9 Poisson 收敛：稀有事件定律

定理 7.10 (Bernoulli 三角阵列的 Poisson 收敛). **【必须会完整证明】**

对每个 n , 设 $X_{n,1}, \dots, X_{n,k_n}$ 相互独立, 且 $X_{n,k} \sim \text{Bernoulli}(p_{n,k})$ 。若

$$\lambda_n := \sum_{k=1}^{k_n} p_{n,k} \longrightarrow \lambda \in (0, \infty), \quad (7.15)$$

并且

$$\max_{1 \leq k \leq k_n} p_{n,k} \longrightarrow 0, \quad (7.16)$$

则

$$\sum_{k=1}^{k_n} X_{n,k} \xrightarrow{d} \text{Poisson}(\lambda). \quad (7.17)$$

证明. 令 $S_n = \sum_{k=1}^{k_n} X_{n,k}$ 。单个 Bernoulli 变量的特征函数为 $\mathbb{E}e^{itX_{n,k}} = 1 + p_{n,k}(e^{it} - 1)$ 。由独立性, $\varphi_{S_n}(t) = \prod_{k=1}^{k_n} [1 + p_{n,k}(e^{it} - 1)]$ 。取对数: $\log \varphi_{S_n}(t) = \sum_{k=1}^{k_n} \log [1 + p_{n,k}(e^{it} - 1)]$ 。当 $|z|$ 足够小时, $|\log(1+z) - z| \leq C|z|^2$ 。由 (7.16), 对充分大的 n 可统一使用该估计。于是

$$\left| \log \varphi_{S_n}(t) - (e^{it} - 1) \sum_{k=1}^{k_n} p_{n,k} \right| \leq C|e^{it} - 1|^2 \sum_{k=1}^{k_n} p_{n,k}^2 \leq C|e^{it} - 1|^2 \left(\max_k p_{n,k} \right) \sum_{k=1}^{k_n} p_{n,k} \rightarrow 0.$$

由 (7.15), $\log \varphi_{S_n}(t) \rightarrow \lambda(e^{it} - 1)$ 。因此 $\varphi_{S_n}(t) \rightarrow \exp\{\lambda(e^{it} - 1)\}$, 右侧是 $\text{Poisson}(\lambda)$ 的特征函数。由 Lévy 连续性定理, 得到 (7.17)。□

推论 7.11 (二项分布的 Poisson 极限). 若 $B_n \sim \text{Bin}(n, p_n)$, $np_n \rightarrow \lambda$, 则 $B_n \xrightarrow{d} \text{Poisson}(\lambda)$ 。特别地, $\text{Bin}\left(n, \frac{\lambda}{n}\right) \xrightarrow{d} \text{Poisson}(\lambda)$ 。

最大成功概率趋于零不能省略

令每一行只有一个非零变量: $X_{n,1} \sim \text{Bernoulli}\left(\frac{1}{2}\right)$, $X_{n,k} = 0$, $k \geq 2$ 。则 $\sum_k p_{n,k} = \frac{1}{2}$, 但 $\max_k p_{n,k} = \frac{1}{2} \not\rightarrow 0$ 。此时 $\sum_k X_{n,k} \sim \text{Bernoulli}\left(\frac{1}{2}\right)$, 不可能收敛到 $\text{Poisson}(1/2)$ 。

7.10 正态极限与 Poisson 极限的识别

概念比较		
现象	典型条件	极限
大量小波动，总方差有限或发散后标准化	Lindeberg 条件；没有宏观跳跃	正态分布
大量稀有 0-1 事件，总期望趋于有限常数	$\sum p_{n,k} \rightarrow \lambda, \max p_{n,k} \rightarrow 0$	Poisson(λ)
稀有跳跃幅度在总尺度下不消失	Feller 可能成立但 Lindeberg 失败	复合 Poisson 或其他非正态极限
异常事件概率可求和	$\sum_n \mathbb{P}(A_n) < \infty$	异常项 a.s. 只出现有限次，可从主体中剥离

7.11 中心极限定理题的标准解题流程

CLT 与三角阵列题

(1) 计算或识别中心： $\mathbb{E}S_n$.

(2) 计算候选尺度，但不要立即认定总标准差一定正确；

(3) 检查是否存在：

- 可求和的异常大跳；
- 单项占据总方差的宏观比例；
- 参数依赖的截断；
- 无限方差边界情形。

(4) 若是 i.i.d. 有限方差，使用经典 CLT；

(5) 若是非同分布独立变量，定义三角阵列并检查： $\sum \text{Var}$, Lindeberg 或 Lyapunov 条件；

(6) 若先对变量截断，必须证明原和与截断和之差为 $o_{\mathbb{P}}(b_n)$ ；

(7) 写出极限特征函数或明确引用 Lindeberg–Feller；

(8) 最后使用 Slutsky 处理渐近等价尺度和可忽略余项。

异常项剥离法

设 $X_k = Y_k + Z_k$, 其中 Y_k 为规则部分, Z_k 为异常部分。

第一种情形： $\sum_k \mathbb{P}(Z_k \neq 0) < \infty$ 。则由 Borel–Cantelli, $\sum_{k \leq n} Z_k$ 最终成为固定有限随机变量，除以任何趋于无穷的尺度均趋于零。

第二种情形： 异常概率不可求和，但对每个 n 有 $\mathbb{P}\left(\sum_{k \leq n} Z_{n,k} \neq 0\right) \rightarrow 0$ 。则异常和依概率可忽略。

第三种情形： 异常项在极限尺度下仍保留有限次数跳跃。此时极限往往是 Poisson、复合 Poisson 或稳定分布，而非正态。

7.12 母题速查表

输入结构	关键条件	归一化	结论或工具
i.i.d., 有限一阶矩	$\mathbb{E} X_1 < \infty$	n	WLLN、SLLN
i.i.d., 有限非零方差	$\text{Var}(X_1) = \sigma^2$	$\sigma\sqrt{n}$	经典 CLT
独立非同分布	Lindeberg	总标准差 s_n	Lindeberg–Feller
独立非同分布, 有高阶矩	Lyapunov 条件	总标准差 s_n	由 Lyapunov 推 Lindeberg
Bernoulli 稀有事件	$\sum p_{n,k} \rightarrow \lambda, \max p_{n,k} \rightarrow 0$	不中心化	Poisson 极限
尾部临界为 x^{-2}	截断二阶矩缓慢发散	常见为 $\sqrt{n \log n}$	特征函数或正态吸引域
异常事件概率可求和	$\sum \mathbb{P}(A_n) < \infty$	由规则部分决定	Borel–Cantelli 后剥离异常项
均值为零但方差随指标增长	检查 $\sum \text{Var}(X_k)/n^2$	未必是 n	可能不满足任何大数律

7.13 本章易错点总表

陈述	判断	正确说明
CLT 要求随机变量有 MGF	错	经典 CLT 只要求有限二阶矩；特征函数总存在。
总方差是唯一正确的归一化	错	Lindeberg 失败时，总方差可能被几乎不出现的异常值污染。
方差无穷就不可能有正态极限	错	临界重尾可在 $\sqrt{n \log n}$ 等尺度下趋于正态。
Feller 条件等价于 Lindeberg 条件	错	Lindeberg 推出 Feller；Feller 单独不充分。
Lyapunov 条件比 Lindeberg 更一般	错	Lyapunov 更强、更容易检查，但适用范围更窄。
逐项最大绝对值趋于零即可得到 CLT	不完整	还需总方差收敛和尾部二阶质量控制。
方差归一化后极限分布必有方差 1	错	矩可能不收敛；需一致可积性。
$\sum p_{n,k} \rightarrow \lambda$ 已足以得到 Poisson 极限	错	还需 $\max p_{n,k} \rightarrow 0$ ，排除单个非稀有事件。
Poisson 极限需要中心化	错	稀有事件和本身趋于 Poisson；中心化后趋于 $\text{Poisson}(\lambda) - \lambda$ 。
依分布收敛后可以直接比较方差	错	需要平方的一致可积性。



一些需要记忆的内容

- (1) 经典 CLT 的特征函数证明中，为什么需要二阶矩而不需要 MGF?
- (2) Lindeberg 条件如何推出最大单项方差占比趋于零?
- (3) 给出一个满足 Feller 条件但极限不是正态的三角阵列。
- (4) 为什么 2026 Spring 第 2 题中不能使用原和的总标准差?
- (5) Poisson 极限中 $\sum p_{n,k} \rightarrow \lambda$ 与 $\max p_{n,k} \rightarrow 0$ 分别控制什么?
- (6) 无限方差时，应通过什么信息寻找正确归一化?



第八章 条件期望、条件分布与条件独立

8.1 考纲定位、重要性与历年考法

重点

S 级

【必须会完整证明】：条件期望的定义、唯一性、基本性质、Tower property、取出已知量、条件 Jensen 不等式和 L^2 投影性质。

【必须会复现证明框架】：条件期望的存在性、条件收敛定理、正则条件分布。

【必须会熟练应用】：条件密度、条件高斯、交换性条件化、条件方差分解、利用条件期望导出特征函数方程。

考试重点

条件期望不是把一个随机变量“代入某个条件”，而是将随机变量投影到给定信息所生成的可测函数空间。资格考试中必须同时检查：

- (1) 被条件化的随机变量是否可积；
- (2) 条件期望是否对给定 σ -代数可测；
- (3) 积分刻画是否对该 σ -代数中的全部事件成立；
- (4) 所写等式是否只在几乎处处意义下成立；
- (5) 条件在零概率事件上是否需要正则条件分布；
- (6) 使用 Tower property 时两个 σ -代数是否嵌套。

往年真题

本章的主要真题锚点包括：

- 2025 Spring 第 1 题，10 分：计算 $\mathbb{E}[X_n | \sigma(Y_n)]$ ；
- 2025 Spring 第 6 题，15 分：由 $\mathbb{E}[(X - Y)^2 | \sigma(X + Y)] = 2$ 推出正态分布；
- 多套试卷中的高斯条件分布、Bayes 后验、Rao-Blackwell 化和充分统计量，本质上都依赖条件期望。


8.2 给定 σ 代数的条件期望

8.2.1 精确定义

定义 8.1 (条件期望). 设 $(\Omega, \mathcal{F}, \mathbb{P})$ 为概率空间， $\mathcal{G} \subseteq \mathcal{F}$ 为子 σ -代数，且 $X \in L^1$ 。若随机变量 Y 满足：

- (1) Y 是 $\mathcal{G}$ -可测的；
- (2) 对每个 $G \in \mathcal{G}$,

$$\int_G Y \, d\mathbb{P} = \int_G X \, d\mathbb{P}, \quad (8.1)$$



则称 Y 是 X 给定 $\mathcal{G}$ 的条件期望的一个版本, 记为 $Y = \mathbb{E}[X | \mathcal{G}]$ 。

注 8.2. $\mathbb{E}[X | \mathcal{G}]$ 严格来说是一个几乎处处等价类, 而不是唯一的逐点函数。不同版本可以在零概率集合上取不同值。

概念比较

条件期望的两个要求分别表示:

可测性 答案只能使用 $\mathcal{G}$ 中包含的信息;

积分刻画 在每个可由 $\mathcal{G}$ 判断的事件上, 条件期望与原变量具有相同的平均总量。

只有其中一个条件成立, 均不足以定义条件期望。

8.2.2 存在性与唯一性

定理 8.3 (条件期望的存在唯一性). 【必须会复现证明框架】

对任意 $X \in L^1$ 和子 σ -代数 $\mathcal{G} \subseteq \mathcal{F}$, 条件期望 $\mathbb{E}[X | \mathcal{G}]$ 存在, 并且在几乎处处意义下唯一。

证明. **存在性**

先设 $X \geq 0$ 。在可测空间 $(\Omega, \mathcal{G})$ 上定义有限测度 $\nu(G) = \int_G X \, d\mathbb{P}$, $G \in \mathcal{G}$ 。若 $\mathbb{P}(G) = 0$, 则 $\nu(G) = 0$, 故 $\nu \ll \mathbb{P}|_{\mathcal{G}}$ 。由 Radon-Nikodym 定理, 存在非负 $\mathcal{G}$ -可测函数 Y , 使 $\nu(G) = \int_G Y \, d\mathbb{P}$, $G \in \mathcal{G}$ 。取 $G = \Omega$ 得 $\mathbb{E}Y = \mathbb{E}X < \infty$, 故 $Y \in L^1$, 并且 Y 满足 (8.1)。

对一般 $X \in L^1$, 写 $X = X^+ - X^-$ 。分别取 $Y^+ = \mathbb{E}[X^+ | \mathcal{G}]$, $Y^- = \mathbb{E}[X^- | \mathcal{G}]$, 并令 $Y = Y^+ - Y^-$ 。则 $Y \in L^1$ 、 $\mathcal{G}$ -可测, 且满足积分刻画。

唯一性

设 Y, Z 均满足定义。对任意 $\varepsilon > 0$, 令 $G_\varepsilon = \{Y > Z + \varepsilon\} \in \mathcal{G}$ 。由积分刻画, $0 = \int_{G_\varepsilon} (Y - Z) \, d\mathbb{P} \geq \varepsilon \mathbb{P}(G_\varepsilon)$ 。故 $\mathbb{P}(G_\varepsilon) = 0$ 。对 $\varepsilon = 1/m$ 取可数并, 得到 $\mathbb{P}(Y > Z) = 0$ 。交换 Y, Z 的角色, 得到 $\mathbb{P}(Z > Y) = 0$ 。因此 $Y = Z$ a.s. $\square$

非负随机变量的扩展定义

若 $X \geq 0$ 但 $\mathbb{E}X$ 可能为无穷, 仍可用单调截断 $X_n = X \wedge n$ 定义 $\mathbb{E}[X | \mathcal{G}] = \lim_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}] \in [0, \infty]$ 。该扩展版本允许条件期望取 $+\infty$ 。

考试时需要注意的地方

错误写法: $\mathbb{E}[X | \mathcal{G}] = \frac{\mathbb{E}[X \mathbf{1}_G]}{\mathbb{P}(G)}$ 。

右侧只描述给定一个正概率事件 G 的条件平均, 而不是给定整个 σ -代数的条件期望。给定 $\mathcal{G}$ 的条件期望通常是随机变量。

8.3 条件期望的基本性质

以下等式均在几乎处处意义下成立。

定理 8.4 (线性、单调性与保期望). 设 $X, Y \in L^1$, $a, b \in \mathbb{R}$ 。

- (1) 线性: $\mathbb{E}[aX + bY | \mathcal{G}] = a\mathbb{E}[X | \mathcal{G}] + b\mathbb{E}[Y | \mathcal{G}]$.
- (2) 正性: 若 $X \geq 0$ a.s., 则 $\mathbb{E}[X | \mathcal{G}] \geq 0$ a.s.
- (3) 单调性: 若 $X \leq Y$ a.s., 则 $\mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[Y | \mathcal{G}]$.
- (4) 保期望: $\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}X$.
- (5) L^1 收缩:

$$\mathbb{E}|\mathbb{E}[X | \mathcal{G}]| \leq \mathbb{E}|X|. \quad (8.2)$$

证明. 线性由定义中的可测性和积分刻画直接验证。

证明正性. 令 $Y = \mathbb{E}[X | \mathcal{G}]$. 对 $m \geq 1$, 设 $G_m = \{Y \leq -1/m\} \in \mathcal{G}$. 则 $0 \leq \mathbb{E}[X \mathbf{1}_{G_m}] = \mathbb{E}[Y \mathbf{1}_{G_m}] \leq -\frac{1}{m} \mathbb{P}(G_m)$. 故 $\mathbb{P}(G_m) = 0$, 从而 $\mathbb{P}(Y < 0) = 0$.

单调性对 $Y - X \geq 0$ 使用正性即可. 保期望在积分刻画中取 $G = \Omega$ 即得。

最后, 由 $-X \leq X \leq |X|$ 和单调性, $-\mathbb{E}[|X| | \mathcal{G}] \leq \mathbb{E}[X | \mathcal{G}] \leq \mathbb{E}[|X| | \mathcal{G}]$. 故 $|\mathbb{E}[X | \mathcal{G}]| \leq \mathbb{E}[|X| | \mathcal{G}]$. 再取期望得到 (8.2). $\square$

8.3.1 已知量可以取出

定理 8.5 (Taking out what is known). 若 Z 是 $\mathcal{G}$ -可测的, 并且 $X, ZX \in L^1$, 则

$$\mathbb{E}[ZX | \mathcal{G}] = Z\mathbb{E}[X | \mathcal{G}]. \quad (8.3)$$

特别地, 若 Z 有界且 $\mathcal{G}$ -可测, 只需假设 $X \in L^1$.

证明. 先设 $Z = \mathbf{1}_G$, 其中 $G \in \mathcal{G}$. 对任意 $A \in \mathcal{G}$,

$$\begin{aligned} \mathbb{E}[\mathbf{1}_G \mathbb{E}[X | \mathcal{G}] \mathbf{1}_A] &= \mathbb{E}[\mathbb{E}[X | \mathcal{G}] \mathbf{1}_{A \cap G}] \\ &= \mathbb{E}[X \mathbf{1}_{A \cap G}] \\ &= \mathbb{E}[ZX \mathbf{1}_A]. \end{aligned}$$

故结论对示性函数成立. 由线性推广到简单函数, 再用截断和控制收敛推广到一般 $\mathcal{G}$ -可测 Z . $\square$

考试时需要注意的地方

“可以取出条件外”的对象必须是对条件信息可测的. 一般不能写 $\mathbb{E}[ZX | \mathcal{G}] = Z\mathbb{E}[X | \mathcal{G}]$ 而不检查 Z 是否 $\mathcal{G}$ -可测。


8.3.2 Tower property

定理 8.6 (Tower property). 若 $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{F}$ 且 $X \in L^1$, 则

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]. \quad (8.4)$$

同时, 由于 $\mathbb{E}[X | \mathcal{H}]$ 已经是 $\mathcal{G}$ -可测的,

$$\mathbb{E}[\mathbb{E}[X | \mathcal{H}] | \mathcal{G}] = \mathbb{E}[X | \mathcal{H}]. \quad (8.5)$$



证明. $\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}]$ 是 $\mathcal{H}$ -可测的。对任意 $H \in \mathcal{H} \subseteq \mathcal{G}$,

$$\begin{aligned}\mathbb{E}[\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] \mathbf{1}_H] &= \mathbb{E}[\mathbb{E}[X | \mathcal{G}] \mathbf{1}_H] \\ &= \mathbb{E}[X \mathbf{1}_H].\end{aligned}$$

由条件期望唯一性得到 (8.4)。第二式由“已知量条件化后不变”直接得到。 $\square$

考试时需要注意的地方

若 $\mathcal{G}$ 与 $\mathcal{H}$ 不具有包含关系, 一般不能写 $\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]$ 。Tower property 的关键条件是两个信息集嵌套。

8.3.3 独立信息不改变条件期望

定理 8.7 (独立性与条件期望). (1) 若 $X \in L^1$ 且 X 与 $\mathcal{G}$ 独立, 则

$$\mathbb{E}[X | \mathcal{G}] = \mathbb{E}X. \quad (8.6)$$

(2) 更一般地, 若 $\mathcal{H}$ 与 $\sigma(X, \mathcal{G})$ 独立, 则

$$\mathbb{E}[X | \sigma(\mathcal{G}, \mathcal{H})] = \mathbb{E}[X | \mathcal{G}]. \quad (8.7)$$

证明. 第一点中, 常数 $\mathbb{E}X$ 是 $\mathcal{G}$ -可测的。对任意 $G \in \mathcal{G}$, $\mathbb{E}[X \mathbf{1}_G] = \mathbb{E}X \mathbb{P}(G) = \mathbb{E}[(\mathbb{E}X) \mathbf{1}_G]$ 。故由唯一性得到结论。

第二点先在矩形事件 $G \cap H$, $G \in \mathcal{G}, H \in \mathcal{H}$ 上验证积分刻画, 再由单调类定理推广到 $\sigma(\mathcal{G}, \mathcal{H})$ 。 $\square$

8.4 条件收敛定理

定理 8.8 (条件单调收敛、Fatou 与控制收敛). 设 $\mathcal{G} \subseteq \mathcal{F}$ 。

(1) 若 $0 \leq X_n \uparrow X$, 则 $\mathbb{E}[X_n | \mathcal{G}] \uparrow \mathbb{E}[X | \mathcal{G}]$ 。

(2) 若 $X_n \geq 0$, 则

$$\mathbb{E} \left[\liminf_{n \rightarrow \infty} X_n \middle| \mathcal{G} \right] \leq \liminf_{n \rightarrow \infty} \mathbb{E}[X_n | \mathcal{G}]. \quad (8.8)$$

(3) 若 $X_n \rightarrow X$ a.s., 且存在 $Z \in L^1$ 使 $|X_n| \leq Z$, 则 $\mathbb{E}[X_n | \mathcal{G}] \rightarrow \mathbb{E}[X | \mathcal{G}]$ a.s. 并且收敛也在 L^1 中成立。

证明思路

条件单调收敛由普通单调收敛定理和条件期望的积分刻画得到。条件 Fatou 对 $Y_n = \inf_{m \geq n} X_m$ 使用条件单调收敛和单调性。

控制收敛可分别对 $Z + X_n \geq 0, Z - X_n \geq 0$ 使用条件 Fatou, 得到条件期望的上、下极限相同。此外,

$$\mathbb{E} |\mathbb{E}[X_n - X | \mathcal{G}]| \leq \mathbb{E} |X_n - X| \rightarrow 0,$$

故也有 L^1 收敛。

8.5 条件 Jensen、不等式与 L^p 收缩

定理 8.9 (条件 Jensen 不等式). 设 $\phi: \mathbb{R} \rightarrow \mathbb{R}$ 为凸函数, $X \in L^1$, 且 $\phi(X) \in L^1$. 则

$$\phi(\mathbb{E}[X | \mathcal{G}]) \leq \mathbb{E}[\phi(X) | \mathcal{G}] \quad a.s. \quad (8.9)$$

若 ϕ 严格凸, 则等号意味着给定 $\mathcal{G}$ 后 X 几乎处处退化: $X = \mathbb{E}[X | \mathcal{G}] \quad a.s.$

证明. 有限凸函数可表示为可数个仿射函数的上确界: $\phi(x) = \sup_{m \geq 1} (a_m x + b_m)$. 对每个 m , $\phi(X) \geq a_m X + b_m$. 由条件期望的单调性和线性性, $\mathbb{E}[\phi(X) | \mathcal{G}] \geq a_m \mathbb{E}[X | \mathcal{G}] + b_m$. 对 m 取上确界, 得到 (8.9). $\square$

推论 8.10 (L^p 收缩). 若 $p \geq 1$ 且 $X \in L^p$, 则

$$\|\mathbb{E}[X | \mathcal{G}]\|_p \leq \|X\|_p. \quad (8.10)$$

证明. 取 $\phi(x) = |x|^p$: $|\mathbb{E}[X | \mathcal{G}]|^p \leq \mathbb{E}[|X|^p | \mathcal{G}]$. 再取期望. $\square$

推论 8.11 (条件 Cauchy-Schwarz). 若 $X, Y \in L^2$, 则

$$|\mathbb{E}[XY | \mathcal{G}]|^2 \leq \mathbb{E}[X^2 | \mathcal{G}] \mathbb{E}[Y^2 | \mathcal{G}] \quad a.s. \quad (8.11)$$

证明. 对任意有理数 t , $0 \leq \mathbb{E}[(X - tY)^2 | \mathcal{G}] = \mathbb{E}[X^2 | \mathcal{G}] - 2t\mathbb{E}[XY | \mathcal{G}] + t^2\mathbb{E}[Y^2 | \mathcal{G}]$. 在每个 ω 上, 该关于 t 的二次式非负, 其判别式不大于零, 即得结论. $\square$

8.6 条件方差与全方差公式

定义 8.12 (条件方差). 若 $X \in L^2$, 定义

$$\text{Var}(X | \mathcal{G}) = \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}])^2 | \mathcal{G}]. \quad (8.12)$$

等价地,

$$\text{Var}(X | \mathcal{G}) = \mathbb{E}[X^2 | \mathcal{G}] - \mathbb{E}[X | \mathcal{G}]^2. \quad (8.13)$$

定理 8.13 (全方差公式). 若 $X \in L^2$, 则

$$\text{Var}(X) = \mathbb{E}[\text{Var}(X | \mathcal{G})] + \text{Var}(\mathbb{E}[X | \mathcal{G}]). \quad (8.14)$$

证明. 由 $X - \mathbb{E}X = (X - \mathbb{E}[X | \mathcal{G}]) + (\mathbb{E}[X | \mathcal{G}] - \mathbb{E}X)$, 展开平方. 交叉项的期望为

$$\begin{aligned} & \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}]) (\mathbb{E}[X | \mathcal{G}] - \mathbb{E}X)] \\ &= \mathbb{E}[(\mathbb{E}[X | \mathcal{G}] - \mathbb{E}X) \mathbb{E}[X - \mathbb{E}[X | \mathcal{G}] | \mathcal{G}]] \\ &= 0. \end{aligned}$$

其余两项分别为 $\mathbb{E}[\text{Var}(X | \mathcal{G})]$ 和 $\text{Var}(\mathbb{E}[X | \mathcal{G}])$. $\square$



推论 8.14 (全协方差公式). 若 $X, Y \in L^2$, 定义 $\text{Cov}(X, Y | \mathcal{G}) = \mathbb{E}[(X - \mathbb{E}[X | \mathcal{G}]) (Y - \mathbb{E}[Y | \mathcal{G}]) | \mathcal{G}]$. 则 $\text{Cov}(X, Y) = \mathbb{E}[\text{Cov}(X, Y | \mathcal{G})] + \text{Cov}(\mathbb{E}[X | \mathcal{G}], \mathbb{E}[Y | \mathcal{G}])$.

考试重点

全方差公式的解释为 总变异 = 条件内变异的平均 + 条件均值之间的变异. 在统计中, Rao-Blackwell 化通过条件期望删除第一部分中的不必要随机性。

8.7 L^2 投影解释

定理 8.15 (条件期望是正交投影). 若 $X \in L^2$, 令 $m = \mathbb{E}[X | \mathcal{G}]$. 则:

(1) 对每个 $Z \in L^2(\mathcal{G})$,

$$\mathbb{E}[(X - m)Z] = 0; \quad (8.15)$$

(2) m 是 $\min_{Z \in L^2(\mathcal{G})} \mathbb{E}[(X - Z)^2]$ 的唯一几乎处处解;

(3) 对任意 $Z \in L^2(\mathcal{G})$,

$$\mathbb{E}[(X - Z)^2] = \mathbb{E}[(X - m)^2] + \mathbb{E}[(m - Z)^2]. \quad (8.16)$$

证明. 若 Z 有界且 $\mathcal{G}$ -可测, 由 定理 8.5,

$$\mathbb{E}[(X - m)Z] = \mathbb{E}[Z\mathbb{E}[X - m | \mathcal{G}]] = 0.$$

一般 $Z \in L^2(\mathcal{G})$ 可用截断逼近。

再写 $X - Z = (X - m) + (m - Z)$. 展开平方并使用 $\mathbb{E}[(X - m)(m - Z)] = 0$, 得到 (8.16). 因此误差在且仅在 $Z = m$ a.s. 时达到最小。□

注 8.16. 条件期望不仅是“最佳线性预测”, 而是在全部 $\mathcal{G}$ -可测平方可积函数中的最佳均方预测。联合高斯时, 该投影恰好是线性的; 一般分布中不必线性。

8.8 给定随机变量的条件期望

8.8.1 Doob-Dynkin 引理

定理 8.17 (Doob-Dynkin 引理). 若 Y 为实值随机变量, 且 Z 是 $\sigma(Y)$ -可测随机变量, 则存在 Borel 可测函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 使 $Z = g(Y)$ a.s. 因此

$$\mathbb{E}[X | \sigma(Y)] = g(Y) \quad a.s. \quad (8.17)$$

证明思路

先对 $Z = \mathbf{1}_A$, $A \in \sigma(Y)$ 证明 $A = Y^{-1}(B)$, 从而 $Z = \mathbf{1}_B(Y)$; 再依次推广到简单函数、非负函数和一般函数。

通常将 $\mathbb{E}[X | \sigma(Y)]$ 简写为 $\mathbb{E}[X | Y]$. 但必须记住, 右侧仍是随机变量, 而 $\mathbb{E}[X | Y = y]$ 是某个版本 $g(y)$ 的数值。

8.8.2 离散条件分布

若 Y 离散且 $\mathbb{P}(Y = y) > 0$, 则 $\mathbb{E}[X | Y = y] = \frac{\mathbb{E}[X \mathbf{1}_{\{Y=y\}}]}{\mathbb{P}(Y=y)}$. 于是

$$\mathbb{E}[X | Y] = \sum_{y: \mathbb{P}(Y=y) > 0} \frac{\mathbb{E}[X \mathbf{1}_{\{Y=y\}}]}{\mathbb{P}(Y=y)} \mathbf{1}_{\{Y=y\}}. \quad (8.18)$$

8.8.3 连续条件密度

若 (X, Y) 有联合密度 $f_{X,Y}$, 且 $f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y) dx > 0$, 则条件密度为 $f_{X|Y}(x | y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$. 因此

$$\mathbb{E}[h(X) | Y = y] = \int_{\mathbb{R}} h(x) \frac{f_{X,Y}(x, y)}{f_Y(y)} dx. \quad (8.19)$$

考试时需要注意的地方

连续型 Y 通常满足 $\mathbb{P}(Y = y) = 0$. 所以 $\mathbb{E}[X | Y = y]$ 不能由 $\frac{\mathbb{E}[X \mathbf{1}_{\{Y=y\}}]}{\mathbb{P}(Y=y)}$ 定义. 必须使用条件密度或正则条件分布.

8.9 正则条件分布

定义 8.18 (正则条件分布). 给定随机变量 X, Y , 若概率核 $K(y, A)$, $y \in \mathcal{Y}$, $A \in \mathcal{B}(\mathcal{X})$, 满足:

- (1) 对固定 y , $A \mapsto K(y, A)$ 是概率测度;
- (2) 对固定 A , $y \mapsto K(y, A)$ 可测;
- (3) $K(Y, A) = \mathbb{P}(X \in A | \sigma(Y))$ a.s.,

则称 K 是 X 给定 Y 的一个正则条件分布。

在标准 Borel 空间中, 正则条件分布存在. 此时对可积 h ,

$$\mathbb{E}[h(X) | Y] = \int h(x) K(Y, dx) \quad \text{a.s.} \quad (8.20)$$

注 8.19. $K(y, \cdot)$ 只在 $\text{Law}(Y)$ -几乎处处的 y 上唯一. 在 Y 不可能取到的点上, 可以任意修改条件分布而不改变 $\mathbb{E}[h(X) | Y]$ 的随机变量版本。

Borel 悖论的正确教训

给定一个零概率几何事件时, 答案可能依赖于该事件被怎样逼近, 或者依赖于选择何种条件变量参数化. 条件对象必须写成明确的 σ -代数或正则条件分布, 不能只写含糊的“条件于某条曲线”。

8.10 交换性条件化

命题 8.20 (给定总和时各分量条件均值相同). 设 $X_1, \dots, X_n$ 可积且交换, 即 $(X_{\pi(1)}, \dots, X_{\pi(n)}) \stackrel{d}{=} (X_1, \dots, X_n)$ 对任意排列 π 成立. 令 $S_n = \sum_{j=1}^n X_j$. 则

$$\mathbb{E}[X_j | S_n] = \frac{S_n}{n}, \quad j = 1, \dots, n. \quad (8.21)$$

证明. 交换性说明 $(X_j, S_n) \stackrel{d}{=} (X_1, S_n)$. 故对任意有界 Borel 函数 h , $\mathbb{E}[X_j h(S_n)] = \mathbb{E}[X_1 h(S_n)]$. 因此 $\mathbb{E}[X_j | S_n] = \mathbb{E}[X_1 | S_n]$ a.s. 对 j 求和: $\sum_{j=1}^n \mathbb{E}[X_j | S_n] = \mathbb{E}[S_n | S_n] = S_n$. 所以每一项均等于 S_n/n . $\square$

注 8.21. 独立同分布蕴含交换性, 但本命题只需交换性, 不需独立。

8.11 条件高斯的简明回顾

设 $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_{p+q} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \right)$, 且 Σ_{YY} 可逆. 则 $\mathbb{E}[X | Y] = \mu_X + \Sigma_{XY} \Sigma_{YY}^{-1} (Y - \mu_Y)$, 并且 $\text{Var}(X | Y) = \Sigma_{XX} - \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$.

考试时需要注意的地方

对一般相关的高斯向量, 回归系数不是逐坐标写成 $\frac{\text{Cov}(X, Y_j)}{\text{Var}(Y_j)}$. 除非 Y_j 两两不相关, 否则必须使用矩阵公式 $\Sigma_{XY} \Sigma_{YY}^{-1}$.

8.12 条件独立

定义 8.22 (给定 $\mathcal{G}$ 的条件独立). 随机变量 X, Y 称为给定 $\mathcal{G}$ 条件独立, 若对所有有界 Borel 函数 f, g ,

$$\mathbb{E}[f(X)g(Y) | \mathcal{G}] = \mathbb{E}[f(X) | \mathcal{G}] \mathbb{E}[g(Y) | \mathcal{G}] \quad \text{a.s.} \quad (8.22)$$

记为 $X \perp\!\!\!\perp Y | \mathcal{G}$.

等价地, 对所有 Borel 集 A, B , $\mathbb{P}(X \in A, Y \in B | \mathcal{G}) = \mathbb{P}(X \in A | \mathcal{G}) \mathbb{P}(Y \in B | \mathcal{G})$.

易错点与失分点

- (1) 无条件独立不必在任意条件下保持;
- (2) 条件独立也不必推出无条件独立;
- (3) 给定共同原因后可能独立, 给定共同结果后可能产生依赖;
- (4) 不能通过只检查条件协方差为零来证明一般条件独立; 联合条件高斯是重要例外。

8.13 真题完整解法：条件二阶矩刻画正态分布

往年真题

2025 Spring 第 6 题, 15 分。

设 X, Y 独立同分布, 满足 $\mathbb{E}X = 0$, $\text{Var}(X) = 1$, 并且 $\mathbb{E}[(X - Y)^2 | \sigma(X + Y)] = 2$ 。证明 X, Y 为独立标准正态随机变量。

解：独立性已经包含在 i.i.d. 的标准含义中, 关键是证明共同分布为 $N(0, 1)$ 。

令 $S = X + Y$, $D = X - Y$, 并记 X 的特征函数为 $\varphi(t) = \mathbb{E}e^{itX}$ 。由于 $\mathbb{E}X^2 < \infty$, φ 二次连续可微, 且 $\varphi(0) = 1$, $\varphi'(0) = i\mathbb{E}X = 0$ 。

由条件期望假设, 对任意 $t \in \mathbb{R}$, $\mathbb{E}[D^2 e^{itS}] = 2\mathbb{E}e^{itS}$ 。严格地说, 可分别对 e^{itS} 的实部和虚部使用“取出已知量”。

利用 X, Y 独立同分布, $\mathbb{E}e^{itS} = \varphi(t)^2$ 。另一方面,

$$\mathbb{E}[D^2 e^{itS}] = \mathbb{E}[(X - Y)^2 e^{it(X+Y)}] = 2\mathbb{E}[X^2 e^{itX}] \varphi(t) - 2(\mathbb{E}[X e^{itX}])^2.$$

由 $\varphi'(t) = i\mathbb{E}[X e^{itX}]$, $\varphi''(t) = -\mathbb{E}[X^2 e^{itX}]$, 得到 $\mathbb{E}[X e^{itX}] = -i\varphi'(t)$, $\mathbb{E}[X^2 e^{itX}] = -\varphi''(t)$ 。因此 $\mathbb{E}[D^2 e^{itS}] = 2[\varphi'(t)^2 - \varphi(t)\varphi''(t)]$ 。与右侧 $2\varphi(t)^2$ 比较, 得到微分方程

$$\varphi'(t)^2 - \varphi(t)\varphi''(t) = \varphi(t)^2. \quad (8.23)$$

由于 $\varphi(0) = 1$ 且 φ 连续, 零点附近 $\varphi(t) \neq 0$ 。在 $\varphi \neq 0$ 的区间上, $\left(\frac{\varphi'}{\varphi}\right)' = \frac{\varphi''\varphi - \varphi'^2}{\varphi^2} = -1$ 。故 $\frac{\varphi'(t)}{\varphi(t)} = -t + C$ 。由 $\varphi'(0) = 0$ 得 $C = 0$, 所以 $\log \varphi(t) = -\frac{t^2}{2}$, 即 $\varphi(t) = e^{-t^2/2}$ 在零点附近成立。

令 I 为集合 $\{t : \varphi(t) \neq 0\}$ 中包含 0 的最大连通区间。上述推导表明在整个 I 上 $\varphi(t) = e^{-t^2/2}$ 。若 I 有有限端点 a , 则由连续性, $\varphi(a) = e^{-a^2/2} > 0$, 与 a 是边界点矛盾。因此 $I = \mathbb{R}$, 从而 $\varphi(t) = e^{-t^2/2}$, $t \in \mathbb{R}$ 。由特征函数唯一性, $X \sim N(0, 1)$ 。 Y 与 X 同分布且二者独立, 故 X, Y 是独立标准正态随机变量。□

考试时需要注意的地方

该题的完整得分点包括:

- (1) 用条件期望把假设转化为 $\mathbb{E}[D^2 e^{itS}] = 2\mathbb{E}e^{itS}$;
- (2) 利用独立性将联合期望分解;
- (3) 正确处理 φ' 、 φ'' 的符号;
- (4) 得到并求解微分方程 (8.23);
- (5) 说明为什么局部解可延拓到整条实线;
- (6) 最后引用特征函数唯一性。

8.14 条件期望题的答题模板

试题举例

若要求计算或证明 $\mathbb{E}[X | \mathcal{G}]$, 建议按以下顺序书写:

- (1) 先猜测一个 $\mathcal{G}$ -可测候选变量 Y ;
- (2) 明确说明 Y 对 $\mathcal{G}$ 可测;
- (3) 对任意 $G \in \mathcal{G}$ 验证 $\mathbb{E}[X \mathbf{1}_G] = \mathbb{E}[Y \mathbf{1}_G]$;
- (4) 若 $\mathcal{G} = \sigma(Z)$, 写成 $Y = g(Z)$;
- (5) 若使用条件密度, 写出条件支撑和归一化因子;
- (6) 最后写 $\mathbb{E}[X | \mathcal{G}] = Y$ a.s.

一些需要记忆的内容

- (1) 条件期望定义中的两个条件分别是什么?
- (2) 为什么 $\mathbb{E}[X | \mathcal{G}]$ 只在 a.s. 意义下唯一?
- (3) Tower property 使用时需要哪一个关键包含关系?
- (4) 若 $X \perp \mathcal{G}$, $\mathbb{E}[X | \mathcal{G}]$ 等于什么?
- (5) 条件期望为什么是 $L^2(\mathcal{G})$ 中的最佳均方预测?
- (6) 依分布意义下“给定 $Y = y$ ”为什么不能使用零概率比值?



第九章 鞅、停时与可选停止

9.1 考纲定位、重要性与历年考法

重点

S 级

【必须会完整证明】：鞅定义、一阶条件判别、停止过程仍为鞅、有界停时的可选停止、典型指数鞅构造。

【必须会复现证明框架】：Doob 最大不等式、上穿不等式、鞅收敛定理和 UI 鞅表示。

【必须会熟练应用】：赌徒破产、首达时生成函数、指数鞅、平方补偿鞅、判断可选停止条件是否成立。

往年真题

直接相关真题包括：

- 2024 Spring 第 4 题，15 分：偏随机游动的指数鞅、命中概率和上确界分布；
- 2024 Spring 第 6 题，10 分：Brownian 首达时、停时与指数鞅；
- 2025 Spring 第 3 题，15 分：简单随机游动首达两个边界的生成函数；
- 2025 Spring 第 4 题，10 分：有限期望停时下可选停止失败；
- 2025 Fall 第 3 题，10 分：严格凸函数与鞅退化；
- 2025 Fall 第 5 题，10 分：连续时间指数鞅及其积分。

9.2 过滤、适应性与鞅

定义 9.1 (过滤). 过滤 (filtration) 是一个递增的子 σ -代数族 $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \cdots \subseteq \mathcal{F}$. $\mathcal{F}_n$ 表示到时刻 n 为止可以使用的全部信息。

定义 9.2 (适应过程). 随机过程 $\{X_n\}_{n \geq 0}$ 称为适应于 $\{\mathcal{F}_n\}$, 若 X_n 是 $\mathcal{F}_n$ -可测的 对每个 n 成立。

过程自身生成的自然过滤为 $\mathcal{F}_n^X = \sigma(X_0, \dots, X_n)$ 。


定义 9.3 (鞅、下鞅与上鞅). 设 $\{X_n\}$ 适应于 $\{\mathcal{F}_n\}$, 且每个 $X_n \in L^1$ 。

- (1) 若对所有 $m \leq n$, $\mathbb{E}[X_n | \mathcal{F}_m] = X_m$, 则称 $\{X_n, \mathcal{F}_n\}$ 为鞅 (martingale)。
- (2) 若 $\mathbb{E}[X_n | \mathcal{F}_m] \geq X_m$, 则称为下鞅 (submartingale)。
- (3) 若 $\mathbb{E}[X_n | \mathcal{F}_m] \leq X_m$, 则称为上鞅 (supermartingale)。

命题 9.4 (一步判别). 对适应且可积的过程, 只需检查 $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n$ 即可证明其为鞅。相应不等式给出下鞅和上鞅。

证明. 若一步条件成立, 则对 $m < n$, 反复使用 Tower property:

$$\mathbb{E}[X_n | \mathcal{F}_m] = \mathbb{E}[\mathbb{E}[X_n | \mathcal{F}_{n-1}] | \mathcal{F}_m] = \mathbb{E}[X_{n-1} | \mathcal{F}_m] = \cdots = X_m.$$



□

命题 9.5 (鞅的均值). 若 $\{X_n\}$ 为鞅, 则 $\mathbb{E}X_n = \mathbb{E}X_0$. 若为下鞅, 则 $\mathbb{E}X_n$ 单调不减; 若为上鞅, 则单调不减。

考试时需要注意的地方

下鞅并不表示样本路径单调递增。它只表示在当前信息下, 下一时刻的条件均值不小于当前值。

9.3 常见鞅构造

9.3.1 独立中心增量之和

若 $\xi_1, \xi_2, \dots$ 独立、可积且 $\mathbb{E}\xi_n = 0$, 令 $S_n = \sum_{j=1}^n \xi_j$, $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$. 则 $\mathbb{E}[S_{n+1} | \mathcal{F}_n] = S_n + \mathbb{E}\xi_{n+1} = S_n$.

9.3.2 条件期望鞅

命题 9.6 (闭鞅). 若 $Z \in L^1$, 定义 $M_n = \mathbb{E}[Z | \mathcal{F}_n]$, 则 $\{M_n, \mathcal{F}_n\}$ 为鞅。

证明. 由 Tower property, $\mathbb{E}[M_{n+1} | \mathcal{F}_n] = \mathbb{E}[\mathbb{E}[Z | \mathcal{F}_{n+1}] | \mathcal{F}_n] = \mathbb{E}[Z | \mathcal{F}_n] = M_n$. □

9.3.3 乘积鞅

若 ξ_n 独立、可积且 $\mathbb{E}\xi_n = 1$, 则 $M_n = \prod_{j=1}^n \xi_j$ 满足 $\mathbb{E}[M_{n+1} | \mathcal{F}_n] = M_n \mathbb{E}\xi_{n+1} = M_n$.

9.3.4 指数鞅

设 ξ_n i.i.d., 且 $m(\theta) = \mathbb{E}e^{\theta\xi_1} < \infty$. 令 $S_n = \sum_{j=1}^n \xi_j$. 则

$$L_n(\theta) = \frac{e^{\theta S_n}}{m(\theta)^n} \quad (9.1)$$

是非负鞅, 因为 $\mathbb{E}[L_{n+1}(\theta) | \mathcal{F}_n] = \frac{e^{\theta S_n}}{m(\theta)^{n+1}} \mathbb{E}e^{\theta\xi_{n+1}} = L_n(\theta)$.

9.3.5 平方补偿鞅

若 ξ_n i.i.d., 满足 $\mathbb{E}\xi_1 = 0$, $\text{Var}(\xi_1) = \sigma^2$, 则

$$M_n = S_n^2 - n\sigma^2 \quad (9.2)$$

是鞅。事实上,

$$\mathbb{E}[S_{n+1}^2 | \mathcal{F}_n] = \mathbb{E}[(S_n + \xi_{n+1})^2 | \mathcal{F}_n] = S_n^2 + \sigma^2.$$

9.3.6 凸函数产生下鞅

命题 9.7. 若 $\{M_n\}$ 为鞅, ϕ 为凸函数, 且 $\phi(M_n)$ 可积, 则 $\{\phi(M_n)\}$ 为下鞅。



证明. 由条件 Jensen 不等式, $\mathbb{E}[\phi(M_{n+1}) | \mathcal{F}_n] \geq \phi(\mathbb{E}[M_{n+1} | \mathcal{F}_n]) = \phi(M_n)$. □

特别地, $|M_n|$, $|M_n|^p$, $p \geq 1$ 在可积时均为下鞅。

概念比较

概念	条件对象	控制内容
鞅	条件均值	公平游戏或零漂移
下鞅	条件均值不减	平均意义上的上升趋势
Markov 过程	条件分布	给定当前状态后, 未来与更早历史无关
独立增量过程	不同时间段增量	比 Markov 性更强的一种结构

9.4 停时

定义 9.8 (停时). 设 $\{\mathcal{F}_n\}$ 为过滤。取值于 $\mathbb{N}_0 \cup \{\infty\}$ 的随机变量 T 称为停时, 若对每个 n ,

$$\{T \leq n\} \in \mathcal{F}_n. \quad (9.3)$$

等价条件包括: $\{T = n\} \in \mathcal{F}_n$, $\{T > n\} \in \mathcal{F}_n$, $\{T \geq n\} \in \mathcal{F}_{n-1}$ 。

例 9.9 (首达时). 若 X_n 适应, A 为 Borel 集, 则 $T_A = \inf\{n \geq 0 : X_n \in A\}$ 是停时, 因为 $\{T_A \leq n\} = \bigcup_{k=0}^n \{X_k \in A\} \in \mathcal{F}_n$ 。

最后访问时间通常不是停时

固定 N , 令 $L = \sup\{0 \leq k \leq N : X_k \in A\}$ 。在时刻 $n < N$ 判断 $L \leq n$, 需要知道未来 $n+1, \dots, N$ 是否再次访问 A , 所以 L 一般不是停时。

命题 9.10 (停时的运算). 若 S, T, T_j 为停时, 则 $S \wedge T, S \vee T, \inf_j T_j$ 均为停时。对可数族, $\sup_j T_j$ 在离散时间中也为停时。

考试时需要注意的地方

停时必须能够仅用“当前及过去的信息”判断是否已经发生。随机时间的有限性、可测性或过程的关系, 均不能替代停时条件。

9.5 停时处的信息与停止过程

定义 9.11 (停时 σ -代数). 对停时 T , 定义

$$\mathcal{F}_T = \{A \in \mathcal{F} : A \cap \{T \leq n\} \in \mathcal{F}_n \text{ 对所有 } n\}. \quad (9.4)$$

$\mathcal{F}_T$ 表示在随机时刻 T 到来时可以获得的信息。



若 $S \leq T$, 则 $\mathcal{F}_S \subseteq \mathcal{F}_T$ 。

若 X_n 适应, 则 $X_T \mathbf{1}_{\{T < \infty\}}$ 是 $\mathcal{F}_T$ -可测的。

定义 9.12 (停止过程). 对过程 X_n 和停时 T , 定义 $X_n^T = X_{n \wedge T}$ 。

定理 9.13 (停止鞅仍为鞅). 若 $\{M_n, \mathcal{F}_n\}$ 为鞅, T 为停时, 则 $\{M_{n \wedge T}, \mathcal{F}_n\}$ 仍为鞅。

证明. 有恒等式 $M_{n \wedge T} = M_{(n-1) \wedge T} + (M_n - M_{n-1}) \mathbf{1}_{\{T \geq n\}}$ 。由于 $\{T \geq n\} \in \mathcal{F}_{n-1}$, 故

$$\mathbb{E}[M_{n \wedge T} \mid \mathcal{F}_{n-1}] = M_{(n-1) \wedge T} + \mathbf{1}_{\{T \geq n\}} \mathbb{E}[M_n - M_{n-1} \mid \mathcal{F}_{n-1}] = M_{(n-1) \wedge T}.$$

□

9.6 可选停止定理

9.6.1 有界停时版本

定理 9.14 (有界停时的可选停止). 设 $\{M_n, \mathcal{F}_n\}$ 为鞅, S, T 为有界停时且 $S \leq T$ 。则

$$\mathbb{E}[M_T \mid \mathcal{F}_S] = M_S \quad a.s. \quad (9.5)$$

特别地,

$$\mathbb{E}M_T = \mathbb{E}M_S = \mathbb{E}M_0. \quad (9.6)$$

证明. 设 $T \leq N$ 。先证明 $\mathbb{E}[M_N \mid \mathcal{F}_T] = M_T$ 。对任意 $A \in \mathcal{F}_T$,

$$\mathbb{E}[M_N \mathbf{1}_A] = \sum_{j=0}^N \mathbb{E}[M_N \mathbf{1}_{A \cap \{T=j\}}] = \sum_{j=0}^N \mathbb{E}[\mathbb{E}[M_N \mid \mathcal{F}_j] \mathbf{1}_{A \cap \{T=j\}}] = \sum_{j=0}^N \mathbb{E}[M_j \mathbf{1}_{A \cap \{T=j\}}] = \mathbb{E}[M_T \mathbf{1}_A].$$

因此 $M_T = \mathbb{E}[M_N \mid \mathcal{F}_T]$ 。同理, $M_S = \mathbb{E}[M_N \mid \mathcal{F}_S]$ 。由于 $\mathcal{F}_S \subseteq \mathcal{F}_T$, 由 Tower property, $\mathbb{E}[M_T \mid \mathcal{F}_S] = \mathbb{E}[\mathbb{E}[M_N \mid \mathcal{F}_T] \mid \mathcal{F}_S] = \mathbb{E}[M_N \mid \mathcal{F}_S] = M_S$ 。□

9.6.2 统一版本: 停止族一致可积


定理 9.15 (UI 停止定理). 设 $T < \infty$ a.s., $\{M_n\}$ 为鞅。若 $\{M_{T \wedge n} : n \geq 0\}$ 一致可积, 则

$$\mathbb{E}M_T = \mathbb{E}M_0. \quad (9.7)$$

证明. 由 **定理 9.13**, $\mathbb{E}M_{T \wedge n} = \mathbb{E}M_0$ 。又因为 $M_{T \wedge n} \rightarrow M_T$ a.s. 且停止族一致可积, Vitali 定理给出 $M_{T \wedge n} \xrightarrow{L^1} M_T$ 。故 $\mathbb{E}M_T = \lim_n \mathbb{E}M_{T \wedge n} = \mathbb{E}M_0$ 。□

推论 9.16 (常用充分条件). 以下任一条件均足以保证 $\mathbb{E}M_T = \mathbb{E}M_0$ 。

- (1) T 有界;
- (2) 存在 $Y \in L^1$, 使 $|M_{T \wedge n}| \leq Y$ 对所有 n ;
- (3) 鞅增量一致有界: $|M_n - M_{n-1}| \leq C$, 且 $\mathbb{E}T < \infty$;



(4) $\{M_n\}$ 本身是一致可积鞅。

第三点. 由 $M_{T \wedge n} = M_0 + \sum_{j=1}^{T \wedge n} (M_j - M_{j-1})$, 有 $|M_{T \wedge n}| \leq |M_0| + CT$. 右侧可积, 故使用控制收敛。 $\square$

定理 9.17 (上鞅版本). 若 $\{M_n\}$ 为上鞅, 则在相应可选停止条件下, $\mathbb{E}M_T \leq \mathbb{E}M_S$ 对 $S \leq T$ 成立。下鞅的不等式方向相反。

可选停止定理绝不能无条件使用

以下条件均单独不足以保证 $\mathbb{E}M_T = \mathbb{E}M_0$:

- $T < \infty$ a.s.;
- $\mathbb{E}T < \infty$;
- $\mathbb{E}M_n = \mathbb{E}M_0$ 对所有固定 n ;
- M_T 本身可积。

必须控制停止过程的尾部, 例如有界性、可积控制或一致可积性。

9.7 真题完整解法：有限期望停时仍可失败

往年真题

2025 Spring 第 4 题, 10 分。

令 ξ_j 独立且 $\mathbb{P}(\xi_j = 1) = \mathbb{P}(\xi_j = -1) = \frac{1}{2}$, 并定义 $X_n = \sum_{j=1}^n 2^{j-1} \xi_j$. 令 $T = \inf\{j \geq 1 : \xi_j = 1\}$. 求 T 的分布、 $\mathbb{E}T$, 证明 X_n 为鞅, 并计算 $\mathbb{E}X_T$.

解：第一步：T 的分布

事件 $\{T = k\}$ 表示前 $k-1$ 次均为 -1 , 第 k 次为 1 , 故 $\mathbb{P}(T = k) = 2^{-k}$, $k = 1, 2, \dots$. 因此 T 是成功概率 $1/2$ 、支撑从 1 开始的几何随机变量, $\boxed{\mathbb{E}T = 2}$.

第二步：证明 X_n 为鞅

令 $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$. 显然 X_n 适应且可积。又 $X_{n+1} = X_n + 2^n \xi_{n+1}$. 所以 $\mathbb{E}[X_{n+1} | \mathcal{F}_n] = X_n + 2^n \mathbb{E}\xi_{n+1} = X_n$. 故 $\{X_n, \mathcal{F}_n\}$ 为鞅。

第三步：计算 X_T

在 $\{T = k\}$ 上, $\xi_1 = \dots = \xi_{k-1} = -1$, $\xi_k = 1$. 因此

$$X_T = -\sum_{j=1}^{k-1} 2^{j-1} + 2^{k-1} = -(2^{k-1} - 1) + 2^{k-1} = 1.$$

故 $\boxed{X_T = 1 \text{ a.s., } \mathbb{E}X_T = 1}$.

但 $\mathbb{E}X_0 = 0$. 所以 $\mathbb{E}X_T \neq \mathbb{E}X_0$.

这并不违反可选停止定理。虽然 $\mathbb{E}T = 2 < \infty$, 但增量 $|X_n - X_{n-1}| = 2^{n-1}$ 不一致有界。

事实上, 停止族也不一致可积。在事件 $\{T > n\}$ 上, $X_{T \wedge n} = X_n = -(2^n - 1)$, 且 $\mathbb{P}(T > n) = 2^{-n}$. 因此对 $K < 2^n - 1$, $\mathbb{E}[|X_{T \wedge n}| \mathbf{1}_{\{|X_{T \wedge n}| > K\}}] \geq (2^n - 1)2^{-n} \rightarrow 1$. $\square$

考试时需要注意的地方

该题的核心不是简单算出 $\mathbb{E}X_T = 1$, 而是明确指出: $\mathbb{E}T < \infty$ 不足以单独保证可选停止. 必须检查增量有界性或停止族的一致可积性。

9.8 真题完整解法: 双边首达时的概率生成函数

往年真题

2025 Spring 第 3 题, 15 分。

设 ξ_j 独立且 $\mathbb{P}(\xi_j = \pm 1) = \frac{1}{2}$, $S_n = \sum_{j=1}^n \xi_j$, 并令 $\tau = \inf\{n : S_n = -a \text{ 或 } S_n = b\}$, $a, b \in \mathbb{Z}_{>0}$ 。

(1) 计算 $\mathbb{E}e^{\lambda S_n}$;

(2) 对 $s \in (0, 1)$ 计算 $\mathbb{E}s^\tau$ 。

解: 第一问

由独立性, $\mathbb{E}e^{\lambda S_n} = \prod_{j=1}^n \mathbb{E}e^{\lambda \xi_j}$. 而 $\mathbb{E}e^{\lambda \xi_j} = \frac{e^\lambda + e^{-\lambda}}{2} = \cosh \lambda$. 所以 $\mathbb{E}e^{\lambda S_n} = (\cosh \lambda)^n$.

第二问: 构造指数鞅

固定 $s \in (0, 1)$. 取唯一的 $\theta > 0$, 使 $\cosh \theta = \frac{1}{s}$, 即 $\theta = \operatorname{arcosh}(\frac{1}{s})$. 定义 $M_n^+ = s^n e^{\theta S_n}$, $M_n^- = s^n e^{-\theta S_n}$. 因为 $s \mathbb{E}e^{\pm \theta \xi_1} = s \cosh \theta = 1$, 所以 M_n^+ 与 M_n^- 均为鞅。

证明 $\tau < \infty$ a.s.

从区间 $\{-a+1, \dots, b-1\}$ 中任意状态出发, 在接下来的 $a+b$ 步内连续向同一方向移动即可到达某个边界。因此存在常数 $c = 2^{-(a+b)} > 0$ 使 $\mathbb{P}(\tau > (m+1)(a+b) \mid \tau > m(a+b)) \leq 1-c$. 故 $\mathbb{P}(\tau > m(a+b)) \leq (1-c)^m \rightarrow 0$.

对停止鞅使用控制收敛

在 τ 之前, $-a < S_n < b$, 在 τ 时, $S_\tau \in \{-a, b\}$. 因此 $0 \leq M_{\tau \wedge n}^+ \leq e^{\theta b}$, $0 \leq M_{\tau \wedge n}^- \leq e^{\theta a}$. 由有界控制和可选停止, $\mathbb{E}[s^\tau e^{\theta S_\tau}] = 1$, $\mathbb{E}[s^\tau e^{-\theta S_\tau}] = 1$.

令 $A = \mathbb{E}[s^\tau \mathbf{1}_{\{S_\tau = b\}}]$, $B = \mathbb{E}[s^\tau \mathbf{1}_{\{S_\tau = -a\}}]$. 则 $e^{\theta b} A + e^{-\theta a} B = 1$, $e^{-\theta b} A + e^{\theta a} B = 1$. 解得 $A = \frac{\sinh(a\theta)}{\sinh((a+b)\theta)}$, $B = \frac{\sinh(b\theta)}{\sinh((a+b)\theta)}$. 所以

$$\mathbb{E}s^\tau = \frac{\sinh(a\theta) + \sinh(b\theta)}{\sinh((a+b)\theta)}, \quad \theta = \operatorname{arcosh}(1/s). \quad (9.8)$$

□

考试时需要注意的地方

该 15 分题必须写出的关键细节:

- (1) 选择 θ 使 $s \cosh \theta = 1$;
- (2) 明确写出两个指数鞅, 而不是只写一个;
- (3) 证明 $\tau < \infty$ a.s.;
- (4) 证明停止后的变量有统一有界控制;
- (5) 分别计算在两个边界上的加权概率;
- (6) 最后相加得到 (9.8)。

9.9 真题完整解法：偏随机游动的指数鞅

往年真题

2024 Spring 第 4 题, 15 分。

设 $\mathbb{P}(\xi_n = 1) = p$, $\mathbb{P}(\xi_n = -1) = q = 1 - p$, 且 $S_n = \sum_{j=1}^n \xi_j$, $T_k = \inf\{n \geq 1 : S_n = k\}$ 。令 $M(t) = \mathbb{E}e^{t\xi_1} = pe^t + qe^{-t}$ 。

9.9.1 当 $p \geq 1/2$ 时的命中恒等式

由 (9.1), $L_n(t) = \frac{e^{tS_n}}{M(t)^n}$ 是非负鞅。

当 $p > 1/2$ 时, 由强大数律 $S_n/n \rightarrow 2p - 1 > 0$, 所以 $T_k < \infty$ a.s.。当 $p = 1/2$ 时, 简单对称随机游动常返, 故同样有 $T_k < \infty$ a.s.

对 $p \geq 1/2$ 和 $t > 0$, $M(t) \geq M(0) = 1$, 并且在 T_k 之前 $S_n \leq k - 1$ 。因此 $0 \leq L_{T_k \wedge n}(t) \leq e^{tk}$ 。由可选停止和控制收敛, $1 = \mathbb{E}L_0(t) = \mathbb{E}L_{T_k}(t) = e^{tk}\mathbb{E}[M(t)^{-T_k}]$ 。故

$$e^{tk}\mathbb{E}[M(t)^{-T_k}] = 1, \quad p \geq \frac{1}{2}, \quad t > 0. \quad (9.9)$$

9.9.2 当 $p < 1/2$ 时的命中概率

此时 $q > p$ 。取 $\theta = \log \frac{q}{p} > 0$ 。则 $M(\theta) = p\frac{q}{p} + q\frac{p}{q} = 1$ 。所以 $e^{\theta S_n}$ 是鞅。

令 $T_{-m} = \inf\{n : S_n = -m\}$, $\tau_m = T_k \wedge T_{-m}$ 是有限停时, 且 $S_{\tau_m} \in \{k, -m\}$ 。令 $\alpha_m = \mathbb{P}(T_k < T_{-m})$ 。可选停止给出 $1 = \mathbb{E}e^{\theta S_{\tau_m}} = e^{\theta k}\alpha_m + e^{-\theta m}(1 - \alpha_m)$ 。因此 $\alpha_m = \frac{1 - e^{-\theta m}}{e^{\theta k} - e^{-\theta m}}$ 。当 $m \rightarrow \infty$ 时, $\{T_k < T_{-m}\} \uparrow \{T_k < \infty\}$,

故 $\mathbb{P}(T_k < \infty) = e^{-\theta k} = \left(\frac{p}{q}\right)^k$ 。

9.9.3 随机上确界的分布

令 $Y = 1 + \sup_{n \geq 0} S_n$ 。因为 $S_0 = 0$, Y 取值于 $\{1, 2, \dots\}$ 。对 $r \geq 1$,

$$\mathbb{P}(Y \geq r) = \mathbb{P}\left(\sup_{n \geq 0} S_n \geq r - 1\right) = \mathbb{P}(T_{r-1} < \infty) = \left(\frac{p}{q}\right)^{r-1}.$$

所以 $\mathbb{P}(Y = r) = \left(1 - \frac{p}{q}\right) \left(\frac{p}{q}\right)^{r-1}$, $r = 1, 2, \dots$ 即 Y 服从成功概率 $1 - \frac{p}{q} = \frac{q-p}{q}$ 的几何分布。

9.10 停时题的参考流程

试题举例

看到“鞅加停时”时，必须逐项写：

- (1) 定义过滤 $\mathcal{F}_n$ ；
- (2) 验证过程适应且可积；
- (3) 计算一步条件期望，证明是鞅；
- (4) 验证随机时间是停时；
- (5) 先对 $T \wedge n$ 使用有界停时定理；
- (6) 明确给出令 $n \rightarrow \infty$ 的合法理由：有界收敛、控制收敛、一致可积、或单调/Fatou 不等式。
- (7) 处理 $T = \infty$ 的可能性；
- (8) 最后才写 $\mathbb{E}M_T = \mathbb{E}M_0$.



第十章 Doob 不等式与鞅收敛

10.1 Doob 最大不等式

定理 10.1 (Doob 的 L^1 最大不等式). 设 $\{X_k\}_{k=0}^n$ 为非负下鞅, 并令 $X_n^* = \max_{0 \leq k \leq n} X_k$. 则对任意 $\lambda > 0$,

$$\lambda \mathbb{P}(X_n^* \geq \lambda) \leq \mathbb{E}[X_n \mathbf{1}_{\{X_n^* \geq \lambda\}}] \leq \mathbb{E}X_n. \quad (10.1)$$

证明. 令 $T = \inf\{k \leq n : X_k \geq \lambda\}$, 并在未命中时令 $T = \infty$. 则 $\{X_n^* \geq \lambda\} = \{T \leq n\}$. 由于 $\{X_k\}$ 为下鞅, $\mathbb{E}[X_n \mathbf{1}_{\{T=k\}}] \geq \mathbb{E}[X_k \mathbf{1}_{\{T=k\}}]$. 对 $k \leq n$ 求和:

$$\mathbb{E}[X_n \mathbf{1}_{\{T \leq n\}}] \geq \mathbb{E}[X_T \mathbf{1}_{\{T \leq n\}}] \geq \lambda \mathbb{P}(T \leq n).$$

□

定理 10.2 (Doob 的 L^p 最大不等式). 设 $\{M_k\}_{k=0}^n$ 为鞅, $p > 1$, 并令 $M_n^* = \max_{0 \leq k \leq n} |M_k|$. 则

$$\|M_n^*\|_p \leq \frac{p}{p-1} \|M_n\|_p. \quad (10.2)$$

证明思路

$\{|M_k|\}$ 是非负下鞅. 对 **定理 10.1** 使用尾积分公式: $\mathbb{E}(M_n^*)^p = \int_0^\infty p\lambda^{p-1} \mathbb{P}(M_n^* \geq \lambda) d\lambda$. 代入最大不等式, 交换积分与期望后得到 $\mathbb{E}(M_n^*)^p \leq \frac{p}{p-1} \mathbb{E}[|M_n| (M_n^*)^{p-1}]$. 再用 Hölder 不等式并约去 $\|M_n^*\|_p^{p-1}$.

前提条件检查

$p > 1$ 不能省略。Doob 的 L^p 范数不等式在 $p = 1$ 时没有同样的强形式; $p = 1$ 时只能使用弱型最大不等式 (10.1)。

10.2 上穿与几乎处处收敛

定义 10.3 (上穿次数). 给定实数列 $x_0, x_1, \dots$ 和 $a < b$, 上穿区间 $[a, b]$ 是指先到达不高于 a 的位置, 之后再到达不低于 b 的位置. 记 $U_n[a, b]$ 为时刻 n 之前完成的上穿次数。

定理 10.4 (Doob 上穿不等式). 若 $\{X_n\}$ 为上鞅, 则

$$(b-a) \mathbb{E}U_n[a, b] \leq \mathbb{E}[(a - X_n)^+]. \quad (10.3)$$



证明思路

构造每次在 $X \leq a$ 时“买入”、在 $X \geq b$ 时“卖出”的有界可预测策略。每次完整上穿至少赚取 $b - a$ ，未完成交易的损失可由 $(a - X_n)^+$ 控制。

由于对上鞅采用该策略的期望收益不为正，得到 (10.3)。

定理 10.5 (几乎处处鞅收敛定理). **【必须会复现证明框架】**

若 $\{X_n\}$ 为上鞅，且

$$\sup_n \mathbb{E}|X_n| < \infty, \quad (10.4)$$

则存在 $X_\infty \in L^1$ ，使 $X_n \xrightarrow{\text{a.s.}} X_\infty$ 。

证明思路

固定有理数 $a < b$ 。由上穿不等式， $\sup_n \mathbb{E}U_n[a, b] \leq \frac{|a| + \sup_n \mathbb{E}|X_n|}{b - a} < \infty$ 。由单调收敛， $\mathbb{E}U_\infty[a, b] < \infty$ ，故 $U_\infty[a, b] < \infty$ a.s. 对全部有理 $a < b$ 取可数交，得到几乎处处每个有理区间只被上穿有限次。这排除了 $\liminf_n X_n < \limsup_n X_n$ 。故 X_n 在扩展实数中收敛。

再由 Fatou 引理， $\mathbb{E}|X_\infty| \leq \liminf_n \mathbb{E}|X_n| \leq \sup_n \mathbb{E}|X_n| < \infty$ ，所以极限有限且属于 L^1 。

推论 10.6 (非负上鞅收敛). 若 $\{X_n\}$ 为非负上鞅，则 $X_n \xrightarrow{\text{a.s.}} X_\infty$ 对某个有限非负随机变量 X_∞ 成立。

证明. 因为 $\mathbb{E}X_n \leq \mathbb{E}X_0$ ，故 $\sup_n \mathbb{E}|X_n| = \sup_n \mathbb{E}X_n \leq \mathbb{E}X_0$ 。□

10.3 L^p 有界鞅的收敛

定理 10.7 (L^p 鞅收敛定理). 设 $\{M_n, \mathcal{F}_n\}$ 为鞅， $p > 1$ 。以下条件等价：

- (1) $\sup_n \mathbb{E}|M_n|^p < \infty$;
- (2) 存在 $M_\infty \in L^p$ ，使 $M_n \rightarrow M_\infty$ a.s. 且在 L^p 中；
- (3) 存在 $Z \in L^p$ ，使

$$M_n = \mathbb{E}[Z | \mathcal{F}_n]. \quad (10.5)$$

证明思路

(1) $\Rightarrow$ (2): L^p 有界推出 L^1 有界，先由 定理 10.5 得到 a.s. 极限。Doob 的 L^p 最大不等式给出 $\mathbb{E}[\sup_n |M_n|]^p < \infty$ 。因此 $|M_n - M_\infty|^p \leq 2^p \sup_k |M_k|^p$ 具有可积控制，使用控制收敛。

(2) $\Rightarrow$ (3): 取 $Z = M_\infty$ 。对 $m \geq n$ ， $M_n = \mathbb{E}[M_m | \mathcal{F}_n]$ 。令 $m \rightarrow \infty$ ，利用条件期望的 L^1 收缩得到 $M_n = \mathbb{E}[M_\infty | \mathcal{F}_n]$ 。

(3) $\Rightarrow$ (1): 由条件 Jensen， $|M_n|^p \leq \mathbb{E}[|Z|^p | \mathcal{F}_n]$ ，故 $\mathbb{E}|M_n|^p \leq \mathbb{E}|Z|^p$ 。

10.4 一致可积鞅与 L^1 收敛

定理 10.8 (UI 鞅收敛定理). 设 $\{M_n, \mathcal{F}_n\}$ 为鞅。以下条件等价：

- (1) $\{M_n : n \geq 0\}$ 一致可积；
- (2) 存在 $M_\infty \in L^1$ ，使 $M_n \rightarrow M_\infty$ a.s. 且在 L^1 中；

(3) 存在 $Z \in L^1$, 使 $M_n = \mathbb{E}[Z | \mathcal{F}_n]$.

在此情况下,

$$M_n = \mathbb{E}[M_\infty | \mathcal{F}_n]. \quad (10.6)$$

证明思路

UI 推出 L^1 有界, 所以先有 a.s. 收敛; 再由 Vitali 定理升级为 L^1 收敛。

若 $M_n \rightarrow M_\infty$ 于 L^1 , 则 $M_n = \mathbb{E}[M_\infty | \mathcal{F}_n]$ 。反之, 对固定 $Z \in L^1$, 条件期望族 $\{\mathbb{E}[Z | \mathcal{G}] : \mathcal{G} \subseteq \mathcal{F}\}$ 一致可积, 故闭鞅一致可积。

推论 10.9 (Lévy 向上定理). 若 $\mathcal{F}_n \uparrow \mathcal{F}_\infty := \sigma(\bigcup_n \mathcal{F}_n)$ 且 $Z \in L^1$, 则

$$\mathbb{E}[Z | \mathcal{F}_n] \rightarrow \mathbb{E}[Z | \mathcal{F}_\infty] \quad a.s. \text{ 且在 } L^1 \text{ 中}. \quad (10.7)$$

若 $Z \in L^p$, $p > 1$, 则收敛也在 L^p 中成立。

10.5 a.s. 收敛不保证 L^1 收敛

非负鞅极限可能丢失期望

设 ξ_j 独立且 $\mathbb{P}(\xi_j = \pm 1) = \frac{1}{2}$, $S_n = \sum_{j=1}^n \xi_j$ 。对固定 $\theta \neq 0$, 定义 $M_n = \frac{e^{\theta S_n}}{(\cosh \theta)^n}$ 。这是非负鞅, 且 $\mathbb{E}M_n = 1$ 。

由强大数律, $\frac{S_n}{n} \xrightarrow{a.s.} 0$ 。故 $\frac{1}{n} \log M_n = \theta \frac{S_n}{n} - \log \cosh \theta \xrightarrow{a.s.} -\log \cosh \theta < 0$ 。所以 $M_n \xrightarrow{a.s.} 0$ 。但 $\mathbb{E}M_n = 1 \not\rightarrow 0$ 。因此: M_n 不在 L^1 中收敛, 且不一致可积。

考试时需要注意的地方

非负鞅一定 a.s. 收敛, 但不一定有 $\mathbb{E}M_\infty = \mathbb{E}M_0$ 。保期望需要 L^1 收敛或一致可积性。

10.6 真题完整解法: 严格凸性迫使鞅退化

往年真题

2025 Fall 第 3 题, 10 分。

设 $(X_n, \mathcal{F}_n)$ 为鞅。

(1) 若 $(X_n^2, \mathcal{F}_n)$ 也是鞅, 证明 $X_m = X_n$ a.s. 对任意 m, n 成立;

(2) 若 $(|X_n|^p, \mathcal{F}_n)$ 对某个 $p > 1$ 是鞅, 证明 $(|X_n|^q, \mathcal{F}_n)$ 对每个 $1 \leq q \leq p$ 均为鞅。

解: 固定 $m < n$ 。

第一问

由于 X_n 和 X_n^2 都是鞅, $\mathbb{E}[X_n | \mathcal{F}_m] = X_m$, $\mathbb{E}[X_n^2 | \mathcal{F}_m] = X_m^2$ 。因此

$$\begin{aligned}\mathbb{E}[(X_n - X_m)^2 | \mathcal{F}_m] &= \mathbb{E}[X_n^2 | \mathcal{F}_m] - 2X_m\mathbb{E}[X_n | \mathcal{F}_m] + X_m^2 \\ &= X_m^2 - 2X_m^2 + X_m^2 \\ &= 0.\end{aligned}$$

非负随机变量条件期望为零推出该变量本身为零 a.s., 故 $X_n = X_m$ a.s. 所以整个鞅在时间上几乎处处恒定。

第二问

由条件 Jensen 不等式, $|\mathbb{E}[X_n | \mathcal{F}_m]|^p \leq \mathbb{E}[|X_n|^p | \mathcal{F}_m]$ 。两边分别为 $|X_m|^p$ 和 $|X_m|^p$, 所以条件 Jensen 取等号。

由于 $x \mapsto |x|^p$ 在 $p > 1$ 时严格凸, 等号情形推出 $X_n = \mathbb{E}[X_n | \mathcal{F}_m] = X_m$ a.s. 因此 $\{X_n\}$ 实际上是恒定过程。于是对任意 $q \geq 1$, $|X_n|^q = |X_m|^q$ a.s. 从而 $\mathbb{E}[|X_n|^q | \mathcal{F}_m] = |X_m|^q$ 。特别地, 对所有 $1 \leq q \leq p$, $(|X_n|^q, \mathcal{F}_n)$ 是鞅。□

考试时需要注意的地方

第二问最直接的结论不是先证明 $|X_n|^q$ 是下鞅, 而是利用 $p > 1$ 时的严格凸性证明原鞅已经退化为恒定过程。若只写 Jensen 不等式而未讨论等号条件, 证明不完整。

10.7 概念区别与常见错误

陈述	判断	正确说明
鞅的样本路径保持不变	错	鞅只要求条件均值保持不变。
下鞅路径单调递增	错	只能说条件均值不减。
Markov 过程一定是鞅	错	Markov 性控制条件分布; 鞅性控制条件均值。
所有鞅都是 Markov 过程	错	鞅可以依赖完整历史而不具 Markov 性。
任何首达时都是停时	有条件	过程必须适应, 目标集合必须可测。
最后访问时间是停时	一般错误	判断它需要未来信息。
$T < \infty$ a.s. 即可使用可选停止	错	还需 UI、可积控制或其他充分条件。
$\mathbb{E}T < \infty$ 即可使用可选停止	错	还需如增量一致有界等条件。
非负鞅必在 L^1 中收敛	错	只保证 a.s. 收敛; L^1 收敛需要 UI。
L^1 有界鞅必在 L^1 中收敛	错	L^1 有界只保证 a.s. 收敛; 需一致可积。
L^p 有界鞅, $p > 1$, 在 L^p 中收敛	对	由 Doob 最大不等式和控制收敛。
$\mathbb{E}M_n = \mathbb{E}M_0$ 推出 $\mathbb{E}M_\infty = \mathbb{E}M_0$	错	必须证明期望可以通过极限, 通常依赖 UI。

10.8 鞅题识别信号与构造方法

套路一：随机游动首达时

识别信号： $S_n = \sum \xi_j$, $T = \inf\{n : S_n \in A\}$ 。

优先尝试的鞅： $S_n - n\mathbb{E}\xi_1$, $S_n^2 - n\text{Var}(\xi_1)$, $\frac{e^{\theta S_n}}{[\mathbb{E}e^{\theta\xi_1}]^n}$ 。

用途：

- 线性鞅求命中概率；
- 平方鞅求期望停时；
- 指数鞅求 Laplace/PGF、单侧命中概率和尾界。

套路二：证明过程是鞅

- (1) 写出过滤；
- (2) 检查 X_n 为 $\mathcal{F}_n$ -可测；
- (3) 检查 $\mathbb{E}|X_n| < \infty$ ；
- (4) 将 $X_{n+1} = X_n + \Delta_{n+1}$ 分解；
- (5) 证明 $\mathbb{E}[\Delta_{n+1} | \mathcal{F}_n] = 0$ 。

套路三：证明鞅收敛

按以下顺序检查：

- (1) 是否非负上鞅；
- (2) 是否满足 $\sup_n \mathbb{E}|M_n| < \infty$ ；
- (3) 是否有 $\sup_n \mathbb{E}|M_n|^p < \infty$, $p > 1$ ；
- (4) 是否可写为 $M_n = \mathbb{E}[Z | \mathcal{F}_n]$ ；
- (5) 是否一致可积。

相应结论： L^1 有界 $\Rightarrow$ a.s. 收敛, L^p 有界, $p > 1 \Rightarrow$ a.s. 与 L^p 收敛, UI $\Rightarrow$ a.s. 与 L^1 收敛。

10.9 本章快速自测

一些需要记忆的内容

- (1) 给出一个既是 Markov 过程又是鞅的例子；给出一个是 Markov 过程但不是鞅的例子。
- (2) 为什么 $T = \inf\{n : S_n = 1\}$ 对简单随机游动是停时，而最后一次访问 0 的时间一般不是？
- (3) 可选停止定理中，一致可积的对象是 $\{M_n\}$ 、 $\{M_{T \wedge n}\}$ ，还是 M_T ？
- (4) 非负鞅 a.s. 收敛时，为什么期望可能下降？
- (5) 若 $\sup_n \mathbb{E}|M_n|^{1+\delta} < \infty$ ，可以得到哪些收敛结论？
- (6) 若 M_n 与 M_n^2 都是鞅，为什么条件方差必为零？
- (7) 在首达时间问题中，线性鞅、平方鞅和指数鞅分别适合求什么？
- (8) 说明 2025 Spring 第 4 题中 $\mathbb{E}T < \infty$ 为什么仍不能使用“有界增量可积停时”版本。

第十一章 离散时间马尔可夫链

11.1 考纲定位、重要性与历年考法

重点

S 级

【必须会完整证明】：马尔可夫性质的等价形式、Chapman–Kolmogorov 方程、强马尔可夫性质、随机映射表示、常返判据、平稳分布的验证、详细平衡推出平稳性。

【必须会复现证明框架】：不可约链中常返性的类性质、Kac 公式、不可约正再生链与平稳分布的等价性、遍历定理、不可约非周期正再生链的收敛定理。

【必须会熟练应用】：首步分析、调和方程、Poisson 方程、返回概率、出生–死亡链、图上的随机游动、耦合与总变差距离。

考试重点

资格考试中的马尔可夫链题通常不是要求背诵定义，而是要求完成下列逻辑链：确定状态空间 $\rightarrow$ 写转移核 $\rightarrow$ 验证 Markov 性 $\rightarrow$ 分类不可约类 $\rightarrow$ 判断周期与常返类型 $\rightarrow$ 求平稳分布 $\rightarrow$ 判断是否收敛到平稳分布。

必须严格区分：

- (1) 平稳分布的存在；
- (2) 平稳分布的唯一性；
- (3) 链从任意初始状态收敛到平稳分布；
- (4) 时间平均收敛到平稳平均。

以上四件事互不等价，分别需要不同条件。

往年真题

本章和下一章的直接真题对应为：

- 2024 Spring 第 5 题，10 分：随机递推 $X_n = f(X_{n-1}, Z_n)$ 与一般齐次马尔可夫链的随机映射表示；
- 2024 Fall 第 4 题，10 分：无限正则树和无限 b 叉树上简单随机游动的常返与暂留；
- 2024 Spring 第 4 题，15 分：偏随机游动的命中概率及上确界分布；
- 2025 Spring 第 3 题，15 分：简单随机游动双边退出时间的概率生成函数。

其中前两题是本部分的主要真题锚点；后两题已在鞅章节中处理，本部分将从马尔可夫链与调和函数角度重新组织其母题结构。

11.2 状态空间、转移矩阵与 Markov 性

11.2.1 基本约定

全文主要考虑有限或可数状态空间 S ，并赋予离散 σ -代数 $\mathcal{P}(S)$ 。

对概率测度 μ ，使用行向量约定： $(\mu P)(y) = \sum_{x \in S} \mu(x) P(x, y)$ 。对函数 $f : S \rightarrow \mathbb{R}$ ，使用列向量约定： $(Pf)(x) = \sum_{y \in S} P(x, y) f(y)$ 。

若 $X_0 = x$ a.s.，相应概率和期望分别记为 $\mathbb{P}_x$ ， $\mathbb{E}_x$ 。若 $X_0 \sim \mu$ ，则记为 $\mathbb{P}_\mu$ ， $\mathbb{E}_\mu$ 。

定义 11.1 (随机矩阵). 矩阵 $P = (P(x, y))_{x, y \in S}$ 称为随机矩阵或转移矩阵，若 $P(x, y) \geq 0$ ， $\sum_{y \in S} P(x, y) = 1$ 对每个 $x \in S$ 。

定义 11.2 (齐次马尔可夫链). 随机变量序列 $\{X_n\}_{n \geq 0}$ 称为状态空间 S 、转移矩阵 P 的齐次马尔可夫链，若对任意 $n \geq 0$ 和任意满足条件事件具有正概率的 $x_0, \dots, x_n, y \in S$,

$$\mathbb{P}(X_{n+1} = y \mid X_0 = x_0, \dots, X_n = x_n) = P(x_n, y). \quad (11.1)$$

注 11.3. 式 (11.1) 包含两个要求：

- (1) **Markov 性**：给定现在 X_n 后，未来一步与更早历史无关；
- (2) **时间齐次性**：转移概率 $P(x, y)$ 不依赖时间 n 。

非齐次马尔可夫链允许转移矩阵写成 $P_n(x, y)$ 。

令自然过滤为 $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$ 。

定理 11.4 (条件期望形式的 Markov 性). 对可数状态空间上的适应过程，以下条件等价：

- (1) $\{X_n\}$ 是转移矩阵 P 的齐次马尔可夫链；
- (2) 对任意有界函数 $f : S \rightarrow \mathbb{R}$,

$$\mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] = (Pf)(X_n) \quad a.s.; \quad (11.2)$$

- (3) 对任意 $m \geq 1$ 和任意有界函数 f ,


$$\mathbb{E}[f(X_{n+m}) \mid \mathcal{F}_n] = (P^m f)(X_n) \quad a.s. \quad (11.3)$$

证明. (1) $\Rightarrow$ (2): 对任意 $x \in S$ ，在事件 $\{X_n = x\}$ 上，

$$\mathbb{E}[f(X_{n+1}) \mid \mathcal{F}_n] = \sum_{y \in S} f(y) \mathbb{P}(X_{n+1} = y \mid \mathcal{F}_n) = \sum_{y \in S} f(y) P(x, y) = (Pf)(x).$$

故得到 (11.2)。

(2) $\Rightarrow$ (1): 取 $f = \mathbf{1}_{\{y\}}$ ，则 $\mathbb{P}(X_{n+1} = y \mid \mathcal{F}_n) = P(X_n, y)$ ，这正是 Markov 性。



(2) $\Rightarrow$ (3): 对 m 归纳。若结论对 m 成立, 则由 Tower property,

$$\begin{aligned}\mathbb{E}[f(X_{n+m+1}) \mid \mathcal{F}_n] &= \mathbb{E}[\mathbb{E}[f(X_{n+m+1}) \mid \mathcal{F}_{n+m}] \mid \mathcal{F}_n] \\ &= \mathbb{E}[(Pf)(X_{n+m}) \mid \mathcal{F}_n] \\ &= (P^m Pf)(X_n) \\ &= (P^{m+1}f)(X_n).\end{aligned}$$

(3) $\Rightarrow$ (2) 显然。 □

考试时需要注意的地方

Markov 性并不是 $X_{n+1} \perp\!\!\!\perp (X_0, \dots, X_{n-1})$ 。正确陈述是条件独立: $X_{n+1} \perp\!\!\!\perp (X_0, \dots, X_{n-1}) \mid X_n$ 。无条件下, X_{n+1} 通常与过去高度相关。

11.3 n 步转移概率与 Chapman–Kolmogorov 方程

定义 $P^0(x, y) = \mathbf{1}_{\{x=y\}}$, 并递归定义矩阵乘法 $P^{n+1}(x, y) = \sum_{z \in S} P^n(x, z)P(z, y)$ 。

定理 11.5 (n 步转移概率). 若 $\{X_n\}$ 是转移矩阵 P 的马尔可夫链, 则

$$\mathbb{P}_x(X_n = y) = P^n(x, y). \quad (11.4)$$

更一般地,

$$\mathbb{P}(X_{m+n} = y \mid X_m = x) = P^n(x, y). \quad (11.5)$$

证明. 由 定理 11.4 对 $f = \mathbf{1}_{\{y\}}$ 使用 (11.3): $\mathbb{P}(X_{m+n} = y \mid \mathcal{F}_m) = P^n(X_m, y)$ 。在事件 $\{X_m = x\}$ 上即得结论。 □

定理 11.6 (Chapman–Kolmogorov 方程). 对任意 $m, n \geq 0$,

$$P^{m+n}(x, y) = \sum_{z \in S} P^m(x, z)P^n(z, y). \quad (11.6)$$

证明. 按中间状态 $X_m = z$ 分解:

$$\begin{aligned}\mathbb{P}_x(X_{m+n} = y) &= \sum_{z \in S} \mathbb{P}_x(X_m = z, X_{m+n} = y) \\ &= \sum_{z \in S} \mathbb{P}_x(X_m = z) \mathbb{P}_x(X_{m+n} = y \mid X_m = z) \\ &= \sum_{z \in S} P^m(x, z) P^n(z, y).\end{aligned}$$

左侧为 $P^{m+n}(x, y)$ 。 □



命题 11.7 (有限维分布). 若初始分布为 μ , 则

$$\mathbb{P}_\mu(X_0 = x_0, \dots, X_n = x_n) = \mu(x_0) \prod_{j=0}^{n-1} P(x_j, x_{j+1}). \quad (11.7)$$

因此初始分布 μ 与转移矩阵 P 唯一确定链的全部有限维分布。

证明. 使用条件概率连乘公式:

$$\begin{aligned} \mathbb{P}_\mu(X_0 = x_0, \dots, X_n = x_n) \\ = \mathbb{P}_\mu(X_0 = x_0) \prod_{j=0}^{n-1} \mathbb{P}_\mu(X_{j+1} = x_{j+1} \mid X_0 = x_0, \dots, X_j = x_j), \end{aligned}$$

再应用 Markov 性。 □

11.4 强马尔可夫性质

定义 11.8 (马尔可夫链的首达时). 对 $A \subseteq S$, 定义 $\tau_A = \inf\{n \geq 0 : X_n \in A\}$, 并约定 $\inf \emptyset = \infty$ 。

对单点 x , 记 $\tau_x = \tau_{\{x\}}$, $\tau_x^+ = \inf\{n \geq 1 : X_n = x\}$ 。 τ_x 是首达时, τ_x^+ 是首次正返回时间。

定理 11.9 (离散时间强马尔可夫性质). **【必须会完整证明】**

设 T 是相对于自然过滤 $\{\mathcal{F}_n\}$ 的停时。对任意 $m \geq 1$ 和任意有界函数 $g: S^m \rightarrow \mathbb{R}$, 在事件 $\{T < \infty\}$ 上,

$$\begin{aligned} \mathbb{E}_\mu[g(X_{T+1}, \dots, X_{T+m}) \mid \mathcal{F}_T] \\ = \mathbb{E}_{X_T}[g(X_1, \dots, X_m)]. \end{aligned} \quad (11.8)$$

特别地,

$$\mathbb{E}_\mu[f(X_{T+m}) \mid \mathcal{F}_T] = (P^m f)(X_T) \quad \text{在 } \{T < \infty\} \text{ 上.} \quad (11.9)$$

证明. 定义 $h(x) = \mathbb{E}_x[g(X_1, \dots, X_m)]$ 。需要证明 $\mathbb{E}[g(X_{T+1}, \dots, X_{T+m}) \mathbf{1}_{\{T < \infty\}} \mid \mathcal{F}_T] = h(X_T) \mathbf{1}_{\{T < \infty\}}$ 。

任取 $A \in \mathcal{F}_T$ 。由停时 σ -代数定义, $A \cap \{T = k\} \in \mathcal{F}_k$ 。于是

$$\begin{aligned} \mathbb{E}[\mathbf{1}_A \mathbf{1}_{\{T < \infty\}} g(X_{T+1}, \dots, X_{T+m})] \\ = \sum_{k=0}^{\infty} \mathbb{E}[\mathbf{1}_{A \cap \{T=k\}} g(X_{k+1}, \dots, X_{k+m})] \\ = \sum_{k=0}^{\infty} \mathbb{E}[\mathbf{1}_{A \cap \{T=k\}} \mathbb{E}[g(X_{k+1}, \dots, X_{k+m}) \mid \mathcal{F}_k]]. \end{aligned}$$

由普通 Markov 性, $\mathbb{E}[g(X_{k+1}, \dots, X_{k+m}) \mid \mathcal{F}_k] = h(X_k)$ 。故

$$\begin{aligned} \mathbb{E}[\mathbf{1}_A \mathbf{1}_{\{T < \infty\}} g(X_{T+1}, \dots, X_{T+m})] \\ = \sum_{k=0}^{\infty} \mathbb{E}[\mathbf{1}_{A \cap \{T=k\}} h(X_k)] \\ = \mathbb{E}[\mathbf{1}_A \mathbf{1}_{\{T < \infty\}} h(X_T)]. \end{aligned}$$



由条件期望唯一性得到结论。 □

考试重点

强马尔可夫性质的标准语言是：

在停时 T 之后，给定 X_T ，未来过程 $(X_{T+n})_{n \geq 0}$ 与 $\mathcal{F}_T$ 中更早的信息无关，并且其条件分布等于从状态 X_T 重新启动的原马尔可夫链。

考试时需要注意的地方

强马尔可夫性质要求 T 是停时。对依赖未来的随机时间，例如“最后一次访问某状态的时刻”，不能直接重新启动链。

11.5 随机映射表示

定义 11.10 (随机映射表示). 设 $(E, \mathcal{E})$ 为可测空间， Z 为 E 值随机变量。若可测函数 $f: S \times E \rightarrow S$ 满足

$$\mathbb{P}(f(x, Z) = y) = P(x, y), \quad x, y \in S, \quad (11.10)$$

则称 (f, Z) 是转移矩阵 P 的随机映射表示 (random mapping representation)。

随机映射表示将马尔可夫链写成随机递推：

$$X_n = f(X_{n-1}, Z_n), \quad n \geq 1, \quad (11.11)$$

其中 $Z_1, Z_2, \dots$ 是独立随机输入。

11.6 真题完整解法：一般马尔可夫链的随机递推表示

往年真题

2024 Spring 第 5 题，10 分。

设 S 为可数状态空间， Z_n 为取值于可测空间 $(E, \mathcal{E})$ 的 i.i.d. 随机变量。

- (1) 若 $X_n = f(X_{n-1}, Z_n)$ ，且 X_0 与所有 Z_n 独立，证明 $\{X_n\}$ 是马尔可夫链，并求其转移概率；
- (2) 证明任意可数状态空间上的齐次马尔可夫链均可写成上述形式。

解：第一问：随机递推推出 Markov 性

令 $\mathcal{F}_n = \sigma(X_0, Z_1, \dots, Z_n)$ 。由递推关系， $X_0, \dots, X_n$ 均为 $\mathcal{F}_n$ -可测。

定义

$$P(x, y) = \mathbb{P}(f(x, Z_1) = y), \quad x, y \in S. \quad (11.12)$$

对固定 x ， $\sum_{y \in S} P(x, y) = \sum_{y \in S} \mathbb{P}(f(x, Z_1) = y) = 1$ ，故 P 是随机矩阵。

由于 Z_{n+1} 与 $\mathcal{F}_n$ 独立, 并且与 Z_1 同分布,

$$\begin{aligned}\mathbb{P}(X_{n+1} = y \mid \mathcal{F}_n) &= \mathbb{P}(f(X_n, Z_{n+1}) = y \mid \mathcal{F}_n) \\ &= P(X_n, y).\end{aligned}$$

再对较小的 $\sigma(X_0, \dots, X_n) \subseteq \mathcal{F}_n$ 取条件期望, 得到 $\mathbb{P}(X_{n+1} = y \mid X_0, \dots, X_n) = P(X_n, y)$ 。所以 $\{X_n\}$ 是转移矩阵 (11.12) 的齐次马尔可夫链。

第二问: 任意可数链均有随机映射表示

设 $S = \{s_1, s_2, \dots\}$ 为有限或可数集合, 给定转移矩阵 P 。令 $U_1, U_2, \dots \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, 1)$, 并令其与 X_0 独立。对每个 $i \geq 1$ 定义累积和 $F_i(0) = 0$, $F_i(k) = \sum_{j=1}^k P(s_i, s_j)$, $k \geq 1$ 。由于每一行概率和为 1, $F_i(k) \uparrow 1$ 。定义

$$f(s_i, u) = s_k \iff F_i(k-1) \leq u < F_i(k), \quad 0 \leq u < 1. \quad (11.13)$$

在零概率点 $u = 1$ 上可任意定义, 例如令 $f(s_i, 1) = s_1$ 。

该函数是可测的, 因为对任意 k , $f^{-1}(\{s_k\}) = \bigcup_{i \geq 1} \{s_i\} \times [F_i(k-1), F_i(k))$, 右侧属于 $\mathcal{P}(S) \otimes \mathcal{B}([0, 1])$ 。

并且

$$\begin{aligned}\mathbb{P}(f(s_i, U_1) = s_k) &= \text{Leb}([F_i(k-1), F_i(k))) \\ &= F_i(k) - F_i(k-1) \\ &= P(s_i, s_k).\end{aligned}$$

因此 (f, U_1) 是 P 的随机映射表示。

若原链初始分布为 μ , 取 $X_0 \sim \mu$ 且与 U_n 独立, 并递归定义 $X_n = f(X_{n-1}, U_n)$ 。第一问表明该递推链的转移矩阵为 P 。其初始分布也是 μ , 故由路径概率公式 (11.7), 它与原马尔可夫链具有相同的全部有限维分布。 $\square$

考试时需要注意的地方

该题完整得分必须包含:


- (1) 写出 $P(x, y) = \mathbb{P}(f(x, Z_1) = y)$;
- (2) 明确使用 Z_{n+1} 与过去信息独立;
- (3) 在逆向构造中枚举状态空间;
- (4) 使用累积转移概率划分 $[0, 1)$;
- (5) 验证 f 的可测性;
- (6) 说明递推链与原链具有相同的初始分布和转移矩阵, 因而有限维分布相同。

11.7 可达性、沟通类、不可约性与闭类

定义 11.11 (可达与沟通). 对 $x, y \in S$:

- (1) 若存在 $n \geq 0$ 使 $P^n(x, y) > 0$, 则称 y 可由 x 到达, 记为 $x \rightarrow y$;
- (2) 若 $x \rightarrow y$ 且 $y \rightarrow x$, 则称 x, y 沟通, 记为 $x \leftrightarrow y$.

关系 $\leftrightarrow$ 是等价关系, 因此将状态空间分解成互不相交的沟通类。



定义 11.12 (不可约). 若所有状态属于同一个沟通类, 即 $\forall x, y \in S, \exists n \geq 0: P^n(x, y) > 0$, 则称链或转移矩阵 P 不可约 (irreducible)。

定义 11.13 (闭类与吸收状态). 沟通类 $C \subseteq S$ 称为闭类, 若 $x \in C, y \notin C \implies P(x, y) = 0$ 。若单点集合 $\{x\}$ 为闭类, 即 $P(x, x) = 1$, 则称 x 为吸收状态。

命题 11.14. 任意有限状态马尔可夫链至少含有一个闭沟通类。一旦链进入闭类, 就永远不会离开该类。

证明思路

将沟通类缩并为有向无环图。有限有向无环图必有出度为零的顶点, 对应一个闭沟通类。

易错点与失分点

- (1) 不可约并不意味着每个一步转移概率都为正; 要求的是某个有限步数后可达。
- (2) 存在吸收状态的链通常不是不可约链, 除非状态空间只有该状态。
- (3) 沟通关系描述图结构; 常返、平稳性和周期性是进一步的概率性质。

11.8 周期与非周期性

定义 11.15 (状态的周期). 对状态 x , 定义返回时间集合 $\mathcal{T}(x) = \{n \geq 1: P^n(x, x) > 0\}$ 。状态 x 的周期定义为

$$d(x) = \gcd \mathcal{T}(x). \quad (11.14)$$

若 $d(x) = 1$, 则称 x 非周期。

定理 11.16 (周期是沟通类性质). 若 $x \leftrightarrow y$, 则 $d(x) = d(y)$ 。因此不可约链的所有状态具有相同周期, 称为该链的周期。

证明. 由 $x \leftrightarrow y$, 存在 $a, b \geq 0$ 使 $P^a(x, y) > 0, P^b(y, x) > 0$ 。若 $n \in \mathcal{T}(x)$, 则 $P^{a+n+b}(y, y) \geq P^b(y, x)P^n(x, x)P^a(x, y) > 0$, 故 $a + n + b \in \mathcal{T}(y)$ 。同时 $a + b \in \mathcal{T}(y)$ 。因此 $d(y)$ 同时整除 $a + n + b$ 和 $a + b$, 从而整除 n 。对所有 $n \in \mathcal{T}(x)$ 成立, 所以 $d(y) \mid d(x)$ 。交换 x, y 得 $d(x) \mid d(y)$ 。故二者相等。□

推论 11.17. 若不可约链存在某个状态 x 满足 $P(x, x) > 0$, 则链非周期, 因为 $1 \in \mathcal{T}(x)$ 。

命题 11.18 (图上简单随机游动的周期). 设 G 为连通、无自环的无向图, 其简单随机游动不可约。

- (1) 若 G 为二分图, 则链的周期为 2;
- (2) 若 G 不是二分图, 则链非周期。

证明. 若 G 为二分图, 链每一步在两个部之间交替, 所以返回原状态只能发生在偶数时刻; 同时沿任意边往返产生 2 步返回, 故周期为 2。

若 G 不是二分图, 则含有奇环。任意状态均可沿路径到达该奇环、绕环一周再返回, 因而存在奇数长度的返回路径。同时总有沿某条边往返的 2 步返回路径。因此返回时间集合同时含有一个奇数和 2, 最大公因数为 1。□

考试时需要注意的地方

周期性影响的是 $P^n(x, \cdot)$ 是否逐点收敛, 而不妨碍时间平均 $\frac{1}{n} \sum_{k=0}^{n-1} f(X_k)$ 满足遍历定理。

例如确定性交替链 $0 \leftrightarrow 1$ 有唯一平稳分布 $(1/2, 1/2)$, 但从 0 出发的分布在 δ_0 与 δ_1 之间振荡, 不收敛。

11.9 常返、暂留与 Green 函数

11.9.1 精确定义

定义 11.19 (常返与暂留). 状态 x 称为常返状态 (recurrent), 若

$$\mathbb{P}_x(\tau_x^+ < \infty) = 1. \quad (11.15)$$

若 $\mathbb{P}_x(\tau_x^+ < \infty) < 1$, 则称 x 为暂留状态 (transient)。

定义 11.20 (Green 函数). 定义

$$G(x, y) = \sum_{n=0}^{\infty} P^n(x, y) = \mathbb{E}_x \left[\sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=y\}} \right]. \quad (11.16)$$

该值允许为 $+\infty$ 。

等式 (11.16) 由 Tonelli 定理得到:

$$\mathbb{E}_x \left[\sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=y\}} \right] = \sum_{n=0}^{\infty} \mathbb{P}_x(X_n = y) = \sum_{n=0}^{\infty} P^n(x, y).$$

11.9.2 返回概率与访问次数

定理 11.21 (常返判据). 【必须会完整证明】

固定状态 x , 令 $f_x = \mathbb{P}_x(\tau_x^+ < \infty)$ 以及 $N_x = \sum_{n=0}^{\infty} \mathbf{1}_{\{X_n=x\}}$, 即从 x 出发对 x 的总访问次数, 包含时刻 0 的访问。则

$$\mathbb{P}_x(N_x \geq k) = f_x^{k-1}, \quad k \geq 1. \quad (11.17)$$

因此

$$G(x, x) = \mathbb{E}_x N_x = \begin{cases} \frac{1}{1-f_x}, & f_x < 1, \\ \infty, & f_x = 1. \end{cases} \quad (11.18)$$

特别地,

$$x \text{ 常返} \iff \sum_{n=0}^{\infty} P^n(x, x) = \infty. \quad (11.19)$$

证明. 第一次返回 x 的概率为 f_x . 每次返回 x 后, 由强马尔可夫性质, 后续能否再次返回的条件概率仍为 f_x , 且与返回前的历史无关。

因此, 要至少访问 x 共 k 次, 需要完成 $k-1$ 次返回, 故 $\mathbb{P}_x(N_x \geq k) = f_x^{k-1}$. 由正整数值随机变量的尾和公式, $\mathbb{E}_x N_x = \sum_{k=1}^{\infty} \mathbb{P}_x(N_x \geq k) = \sum_{k=1}^{\infty} f_x^{k-1}$. 当 $f_x < 1$ 时, 该和为 $1/(1-f_x)$; 当 $f_x = 1$ 时发散。

另一方面, $\mathbb{E}_x N_x = \sum_{n=0}^{\infty} P^n(x, x) = G(x, x)$ 。故得到全部结论。 $\square$

推论 11.22. 若 x 常返, 则从 x 出发几乎处处无穷多次访问 x 。若 x 暂留, 则对 x 的访问次数几乎处处有限。

11.9.3 常返性是沟通类性质

定理 11.23 (常返性的类性质). 若 $x \leftrightarrow y$, 则 x 常返当且仅当 y 常返。因此不可约链只能属于以下两类之一:

- (1) 所有状态均常返;
- (2) 所有状态均暂留。

证明思路

假设 x 常返且 $x \leftrightarrow y$ 。

由 $x \rightarrow y$, 存在一条从 x 到 y 的正概率路径。链每次返回 x 后都有一个固定正概率沿该路径到达 y 。由于 x 被访问无穷多次, 反复使用强马尔可夫性质可知 $\mathbb{P}_x(\tau_y < \infty) = 1$ 。

再由 $y \rightarrow x$ 。若从 y 出发有正概率永远不返回 x , 则从 x 出发先到达 y 、再永远不返回 x 的概率为正, 与 x 常返矛盾。因此 $\mathbb{P}_y(\tau_x < \infty) = 1$ 。从 y 出发先到达 x , 再由 x 几乎必然到达 y , 故 y 常返。反方向对称。

易错点与失分点

“常返”指最终返回概率为 1; 它不表示平均返回时间有限。这正是正常返与零常返的区别。

11.10 正常返、零常返与 Kac 公式

定义 11.24 (正常返与零常返). 状态 x 称为正常返或正再生状态 (positive recurrent), 若

$$\mathbb{E}_x \tau_x^+ < \infty. \quad (11.20)$$

若 x 常返但 $\mathbb{E}_x \tau_x^+ = \infty$, 则称 x 为零常返状态 (null recurrent)。

正常返必然推出常返, 因为若 $\mathbb{P}_x(\tau_x^+ = \infty) > 0$, 则扩展期望 $\mathbb{E}_x \tau_x^+ = \infty$ 。

定理 11.25 (正常返是不可约类性质). 若链不可约, 且某个状态正常返, 则所有状态均正常返。因此不可约常返链可进一步分成:

- (1) 正常返链;
- (2) 零常返链。

证明思路

设 x_0 正常返。由不可约性, 从任意 x 到达 x_0 以及从 x_0 到达任意 y 均存在正概率有限路径。利用每次返回 x_0 作为再生时刻, 并对未命中目标状态的循环次数使用几何尾估计, 可证明任意状态之间的平均首达时间有限。特别地, $\mathbb{E}_y \tau_y^+ < \infty$ 。

11.11 平稳分布

定义 11.26 (平稳分布). 概率分布 π 称为转移矩阵 P 的平稳分布 (stationary distribution), 若

$$\pi P = \pi, \quad (11.21)$$

即对每个 $y \in S$,

$$\pi(y) = \sum_{x \in S} \pi(x) P(x, y). \quad (11.22)$$

若 $X_0 \sim \pi$, 则 $X_n \sim \pi$ 对所有 $n \geq 0$. 此时称链处于平稳状态。

考试时需要注意的地方

平稳分布描述的是边缘分布在时间推进下保持不变: $\text{Law}(X_n) = \pi$. 它不表示样本路径保持不变, 也不表示 X_n 相互独立。

11.12 不可约可数链: 平稳分布与正常返的等价性

定理 11.27 (平稳分布存在的充要条件). **【必须会复现证明框架】**

设 P 是可数状态空间上的不可约转移矩阵。以下条件等价:

- (1) 链正常返;
- (2) 存在平稳概率分布 π 。

在此情况下, 平稳分布唯一、严格为正, 并满足 *Kac* 公式

$$\pi(x) = \frac{1}{\mathbb{E}_x \tau_x^+}, \quad x \in S. \quad (11.23)$$


证明. 正常返推出平稳分布

固定状态 z , 令 $T = \tau_z^+$. 定义一个循环内的平均访问次数:

$$\tilde{\pi}(y) = \mathbb{E}_z \left[\sum_{n=0}^{T-1} \mathbf{1}_{\{X_n=y\}} \right]. \quad (11.24)$$

由于 $\sum_{y \in S} \tilde{\pi}(y) = \mathbb{E}_z T < \infty$, 可定义概率分布

$$\pi(y) = \frac{\tilde{\pi}(y)}{\mathbb{E}_z T}. \quad (11.25)$$



验证不变性。对任意 $y \in S$,

$$\begin{aligned} (\tilde{\pi}P)(y) &= \sum_{x \in S} \tilde{\pi}(x)P(x, y) \\ &= \mathbb{E}_z \left[\sum_{n=0}^{T-1} P(X_n, y) \right] \\ &= \mathbb{E}_z \left[\sum_{n=0}^{T-1} \mathbb{E}[\mathbf{1}_{\{X_{n+1}=y\}} \mid \mathcal{F}_n] \right] \\ &= \mathbb{E}_z \left[\sum_{n=1}^T \mathbf{1}_{\{X_n=y\}} \right]. \end{aligned}$$

若 $y \neq z$, 在首次返回 z 之前与返回时刻均不额外出现 y , 所以 $\sum_{n=1}^T \mathbf{1}_{\{X_n=y\}} = \sum_{n=0}^{T-1} \mathbf{1}_{\{X_n=y\}}$ 。若 $y = z$, 左边只计返回时刻 T 的一次访问, 右边只计初始时刻 0 的一次访问, 二者仍相等。因此 $\tilde{\pi}P = \tilde{\pi}$, 归一化后得到 $\pi P = \pi$ 。

此外, 在一个从 z 到再次返回 z 的循环内, z 恰被计数一次, 所以 $\tilde{\pi}(z) = 1$ 。由 (11.25), $\pi(z) = \frac{1}{\mathbb{E}_z \tau_z^+}$ 。

平稳分布推出正常返

设 $\pi P = \pi$ 。先证明 $\pi(x) > 0$ 对所有 x 。选取 z 使 $\pi(z) > 0$ 。由不可约性, 对任意 x 存在 n 使 $P^n(z, x) > 0$ 。由于 $\pi P^n = \pi$, $\pi(x) = \sum_y \pi(y)P^n(y, x) \geq \pi(z)P^n(z, x) > 0$ 。

下面证明原链常返。令链从平稳分布 π 启动, 固定 x , 定义 $A_n = \{X_n = x, X_m \neq x \text{ 对所有 } m > n\}$ 。 A_n 表示时刻 n 是对 x 的最后一次访问。事件 A_n 两两不交。由 Markov 性与平稳性,

$$\begin{aligned} \mathbb{P}_\pi(A_n) &= \mathbb{P}_\pi(X_n = x) \mathbb{P}_x(\tau_x^+ = \infty) \\ &= \pi(x) \mathbb{P}_x(\tau_x^+ = \infty). \end{aligned}$$

右侧与 n 无关。若 $\mathbb{P}_x(\tau_x^+ = \infty) > 0$, 则 $\sum_{n=0}^{\infty} \mathbb{P}_\pi(A_n) = \infty$, 与 A_n 两两不交且总概率不超过 1 矛盾。因此 $\mathbb{P}_x(\tau_x^+ < \infty) = 1$ 。不可约链由此全部常返。

定义时间反转转移矩阵

$$\hat{P}(x, y) = \frac{\pi(y)P(y, x)}{\pi(x)}. \quad (11.26)$$

由 $\pi P = \pi$, $\sum_y \hat{P}(x, y) = \frac{1}{\pi(x)} \sum_y \pi(y)P(y, x) = 1$, 故 $\hat{P}$ 是随机矩阵。它也不可约且以 π 为平稳分布, 因此由刚才的论证, 反向链同样常返。


对任意路径 $x_0, \dots, x_n$, 有路径反转恒等式

$$\pi(x_0) \prod_{j=0}^{n-1} P(x_j, x_{j+1}) = \pi(x_n) \prod_{j=0}^{n-1} \hat{P}(x_{n-j}, x_{n-j-1}). \quad (11.27)$$

利用正整数值随机变量的尾和公式, $\mathbb{E}_x \tau_x^+ = \sum_{n=1}^{\infty} \mathbb{P}_x(\tau_x^+ \geq n)$ 。于是

$$\pi(x) \mathbb{E}_x \tau_x^+ = \sum_{n=1}^{\infty} \sum_{y \in S} \pi(y) \mathbb{P}_x(X_n = y, X_1, \dots, X_{n-1} \neq x).$$

由路径反转恒等式, $\pi(x) \mathbb{P}_x(X_n = y, X_1, \dots, X_{n-1} \neq x) = \pi(y) \hat{\mathbb{P}}_y(\hat{\tau}_x = n)$, 其中 $\hat{\tau}_x = \inf\{m \geq 1 : \hat{X}_m = x\}$ 。



因此

$$\begin{aligned}\pi(x)\mathbb{E}_x\tau_x^+ &= \sum_{y \in S} \pi(y) \sum_{n=1}^{\infty} \hat{\mathbb{P}}_y(\hat{\tau}_x = n) \\ &= \sum_{y \in S} \pi(y) \hat{\mathbb{P}}_y(\hat{\tau}_x < \infty) \\ &= \sum_{y \in S} \pi(y) \\ &= 1.\end{aligned}$$

反向链常返保证第二行中的命中概率为 1。故 $\mathbb{E}_x\tau_x^+ = \frac{1}{\pi(x)} < \infty$ 。这既证明正常返，也证明 Kac 公式。

唯一性

若 μ 是另一个平稳概率分布，则同样由 Kac 公式， $\mu(x) = \frac{1}{\mathbb{E}_x\tau_x^+} = \pi(x)$ ，所以 $\mu = \pi$ 。 $\square$

推论 11.28 (有限不可约链)。有限不可约马尔可夫链必正常返，并存在唯一严格为正的平稳分布。

证明。 固定 z 。由于状态空间有限且链不可约，存在 $R < \infty$ 和 $\varepsilon > 0$ ，使从任意状态出发在接下来 R 步内命中 z 的概率至少为 ε 。故 $\mathbb{P}_x(\tau_z > kR) \leq (1 - \varepsilon)^k$ 。于是 $\mathbb{E}_x\tau_z \leq R \sum_{k=0}^{\infty} (1 - \varepsilon)^k = \frac{R}{\varepsilon} < \infty$ 。特别地， $\mathbb{E}_z\tau_z^+ < \infty$ ，再应用 定理 11.27。 $\square$

考试重点

对不可约可数链： 存在平稳概率分布 $\iff$ 正常返。

因此：

- 零常返链没有平稳概率分布；
- 暂留链没有平稳概率分布；
- 不可约正常返链的平稳分布自动唯一；
- Kac 公式将平稳质量与平均返回时间互相转换。

11.13 详细平衡、可逆性与时间反转

定义 11.29 (详细平衡)。概率分布 π 称为满足详细平衡方程，若

$$\pi(x)P(x, y) = \pi(y)P(y, x), \quad x, y \in S. \quad (11.28)$$


定理 11.30 (详细平衡推出平稳性)。若 π 满足 (11.28)，则 $\pi P = \pi$ 。

证明。 对任意 y ，

$$(\pi P)(y) = \sum_x \pi(x)P(x, y) = \sum_x \pi(y)P(y, x) = \pi(y) \sum_x P(y, x) = \pi(y).$$

$\square$

定义 11.31 (可逆链)。若链以 π 为初始分布，且对每个 n ， $(X_0, X_1, \dots, X_n) \stackrel{d}{=} (X_n, X_{n-1}, \dots, X_0)$ ，则称链关于 π 可逆。



定理 11.32 (可逆性的等价刻画). 若 $\pi(x) > 0$, 则以下条件等价:

- (1) 链关于 π 可逆;
- (2) 详细平衡方程成立;
- (3) 时间反转核 $\hat{P}(x, y) = \frac{\pi(y)P(y, x)}{\pi(x)}$ 等于原核 P 。

证明思路

由详细平衡反复交换相邻因子:

$$\pi(x_0)P(x_0, x_1) \cdots P(x_{n-1}, x_n) = \pi(x_n)P(x_n, x_{n-1}) \cdots P(x_1, x_0).$$

这正是正向路径与反向路径概率相等。反之, 只取 $n = 1$ 即得到详细平衡。

前提条件检查

详细平衡是平稳性的充分条件, 但不是必要条件。

例如三状态确定性顺时针链 $0 \rightarrow 1 \rightarrow 2 \rightarrow 0$ 具有均匀平稳分布 $\pi = (1/3, 1/3, 1/3)$, 但 $\pi(0)P(0, 1) = \frac{1}{3}$, $\pi(1)P(1, 0) = 0$, 所以链不满足详细平衡, 也不可逆。

11.14 图上的简单随机游动

定义 11.33 (无向图上的简单随机游动). 设 $G = (V, E)$ 为局部有限无向图。记 $\deg(x) = |\{y : y \sim x\}|$ 。简单随机游动的转移概率为

$$P(x, y) = \begin{cases} \frac{1}{\deg(x)}, & y \sim x, \\ 0, & \text{其他.} \end{cases} \quad (11.29)$$

若 G 有限且连通, 则链不可约, 并且

$$\pi(x) = \frac{\deg(x)}{\sum_{z \in V} \deg(z)} = \frac{\deg(x)}{2|E|} \quad (11.30)$$

是平稳分布。

事实上, $\pi(x)P(x, y) = \frac{1_{\{x \sim y\}}}{2|E|} = \pi(y)P(y, x)$, 所以该链可逆。


推论 11.34. 若有限连通图是 d -正则图, 即 $\deg(x) = d$ 对所有 x , 则平稳分布为均匀分布: $\pi(x) = \frac{1}{|V|}$ 。

11.15 出生-死亡链

定义 11.35 (出生-死亡链). 状态空间为 $S = \{0, 1, 2, \dots\}$ 或 $S = \{0, 1, \dots, N\}$ 。转移概率满足 $P(k, k+1) = p_k$, $P(k, k-1) = q_k$, $P(k, k) = r_k$, 其中 $p_k + q_k + r_k = 1$, $q_0 = 0$, 有限状态情形还规定 $p_N = 0$ 。

详细平衡方程化为 $\pi(k)p_k = \pi(k+1)q_{k+1}$ 。因此定义未归一化权重

$$\tilde{\pi}(0) = 1, \quad \tilde{\pi}(k) = \prod_{j=1}^k \frac{p_{j-1}}{q_j}, \quad k \geq 1. \quad (11.31)$$



若

$$Z = \sum_{k \in S} \tilde{\pi}(k) < \infty, \quad (11.32)$$

则

$$\pi(k) = \frac{\tilde{\pi}(k)}{Z} \quad (11.33)$$

是平稳分布，且链可逆。

前提条件检查

有限状态出生-死亡链自动满足 $Z < \infty$ 。无限状态情形必须检查 (11.32)。

若该和发散，只能说明上述不变测度不能归一化为概率分布；链可能是零常返，也可能是暂留，仍需额外判断。

11.16 遍历定理与收敛到平稳分布

11.16.1 总变差距离的约定

全文使用标准总变差距离

$$\|\mu - \nu\|_{\text{TV}} = \sup_{A \subseteq S} |\mu(A) - \nu(A)| = \frac{1}{2} \sum_{x \in S} |\mu(x) - \nu(x)|. \quad (11.34)$$

注 11.36. 部分课程讲义将无系数的 ℓ^1 距离 $\sum_x |\mu(x) - \nu(x)|$ 也记为某种矩阵距离。该距离等于 $2\|\mu - \nu\|_{\text{TV}}$ 。本文统一采用 (11.34)。

命题 11.37 (Markov 核的总变差收缩性). 对任意概率分布 μ, ν ,

$$\|\mu P - \nu P\|_{\text{TV}} \leq \|\mu - \nu\|_{\text{TV}}. \quad (11.35)$$

证明. 对任意 $A \subseteq S$, 定义 $P(x, A) = \sum_{y \in A} P(x, y) \in [0, 1]$ 。则

$$\begin{aligned} |(\mu P)(A) - (\nu P)(A)| &= \left| \sum_x (\mu(x) - \nu(x)) P(x, A) \right| \\ &\leq \|\mu - \nu\|_{\text{TV}}. \end{aligned}$$

对 A 取上确界。 □

11.16.2 遍历定理

定理 11.38 (不可约正再生链的遍历定理). 设链不可约、正常返，平稳分布为 π 。若 $f: S \rightarrow \mathbb{R}$ 有界，则对任意初始分布 μ ,

$$\frac{1}{n} \sum_{k=0}^{n-1} f(X_k) \xrightarrow{\text{a.s.}} \pi(f) := \sum_{x \in S} \pi(x) f(x). \quad (11.36)$$



特别地,

$$\frac{1}{n} \sum_{k=0}^{n-1} \mathbf{1}_{\{X_k=x\}} \xrightarrow{\text{a.s.}} \pi(x). \quad (11.37)$$

再生循环证明

固定状态 z , 定义连续返回时刻 $T_0 = 0$, $T_{j+1} = \inf\{n > T_j : X_n = z\}$. 从第一次到达 z 以后, 各循环 $(X_{T_j}, X_{T_j+1}, \dots, X_{T_{j+1}-1})$ 在强马尔可夫性质下独立同分布。

定义循环长度与循环收益 $L_j = T_{j+1} - T_j$, $R_j = \sum_{k=T_j}^{T_{j+1}-1} f(X_k)$. 正常返保证 $\mathbb{E}_z L_0 < \infty$, 有界 f 保证 $\mathbb{E}_z |R_0| < \infty$. 由强大数律, $\frac{\sum_{j=0}^{m-1} R_j}{\sum_{j=0}^{m-1} L_j} \xrightarrow{\text{a.s.}} \frac{\mathbb{E}_z R_0}{\mathbb{E}_z L_0}$. 由循环占用测度构造, $\frac{\mathbb{E}_z R_0}{\mathbb{E}_z L_0} = \pi(f)$. 最后证明当前未完成循环对总时间平均的贡献趋于零, 即得 (11.36)。

前提条件检查

遍历定理不需要非周期性。

周期只会造成时刻分布振荡; 长时间占用比例仍可收敛。

11.16.3 分布收敛定理

定理 11.39 (不可约非周期正再生链的收敛). 设链不可约、非周期、正常返, 平稳分布为 π . 则对任意 $x \in S$,

$$\|P^n(x, \cdot) - \pi\|_{\text{TV}} \longrightarrow 0. \quad (11.38)$$

特别地, 对每个 $y \in S$,

$$P^n(x, y) \longrightarrow \pi(y). \quad (11.39)$$

证明思路

构造两个独立副本: $X_0 = x$, $Y_0 \sim \pi$. 利用不可约、非周期和正常返性, 乘积链 (X_n, Y_n) 能够以概率 1 命中对角线 $\{(z, z) : z \in S\}$. 一旦两链相遇, 之后令它们使用同一随机输入并保持相等。

若耦合时间为 $T_c = \inf\{n : X_n = Y_n\}$, 则耦合不等式给出 $\|P^n(x, \cdot) - \pi\|_{\text{TV}} \leq \mathbb{P}(T_c > n) \rightarrow 0$.

11.16.4 有限状态链的几何收敛

定理 11.40 (有限不可约非周期链的几何混合). 设 S 有限, 链不可约且非周期, 平稳分布为 π . 则存在 $C < \infty$, $\rho \in (0, 1)$, 使

$$\max_{x \in S} \|P^n(x, \cdot) - \pi\|_{\text{TV}} \leq C\rho^n. \quad (11.40)$$

证明. 有限不可约非周期性保证存在整数 $r \geq 1$, 使 $P^r(x, y) > 0$ 对所有 $x, y \in S$. 由于 $\pi(y) > 0$, 令 $\varepsilon = \min_{x,y} \frac{P^r(x,y)}{\pi(y)} > 0$. 于是 $P^r(x, y) \geq \varepsilon\pi(y)$. 若 $\varepsilon < 1$, 定义 $Q(x, y) = \frac{P^r(x,y) - \varepsilon\pi(y)}{1-\varepsilon}$. 则 Q 为随机矩阵, 并且

$$P^r = \varepsilon\Pi + (1-\varepsilon)Q, \quad (11.41)$$

其中 Π 的每一行均为 π . 由 $\pi P^r = \pi$ 可得 $\pi Q = \pi$.

因此对任意分布 μ ,

$$\begin{aligned}\|\mu P^r - \pi\|_{\text{TV}} &= (1 - \varepsilon)\|\mu Q - \pi Q\|_{\text{TV}} \\ &\leq (1 - \varepsilon)\|\mu - \pi\|_{\text{TV}}.\end{aligned}$$

迭代得 $\|\mu P^{kr} - \pi\|_{\text{TV}} \leq (1 - \varepsilon)^k$ 。再对余数 $0 \leq j < r$ 使用总变差收缩性, 即得 (11.40)。若 $\varepsilon = 1$, 则 $P^r = \Pi$, 结论更直接。 $\square$

概念比较

目标	主要条件	结论
平稳分布存在	不可约正常返	存在且唯一, Kac 公式成立
时间平均收敛	不可约正常返	不需要非周期性
时刻分布收敛	不可约、正常返、非周期	$P^n(x, \cdot) \rightarrow \pi$
有限链指数速度	有限、不可约、非周期	总变差几何收敛

11.17 调和函数、命中概率与首步分析

定义 11.41 (调和函数). 函数 $h: S \rightarrow \mathbb{R}$ 称为在状态 x 处调和, 若 $h(x) = (Ph)(x) = \sum_y P(x, y)h(y)$ 。若该关系对区域 D 中所有状态成立, 则称 h 在 D 上调和。

定理 11.42 (命中概率的 Dirichlet 问题). 设 $A, B \subseteq S$ 不交, 并定义 $\tau_A = \inf\{n \geq 0 : X_n \in A\}$, $\tau_B = \inf\{n \geq 0 : X_n \in B\}$ 。令

$$h(x) = \mathbb{P}_x(\tau_A < \tau_B). \quad (11.42)$$

则 $h(x) = 1, \quad x \in A, \quad h(x) = 0, \quad x \in B$, 并且对 $x \notin A \cup B$,

$$h(x) = \sum_y P(x, y)h(y). \quad (11.43)$$


若有限区域内从每个状态均几乎必然命中 $A \cup B$, 则上述边界值问题的有界解唯一。

证明. 边界值显然。若 $x \notin A \cup B$, 按第一步位置分解:

$$\begin{aligned}h(x) &= \sum_y \mathbb{P}_x(X_1 = y) \mathbb{P}_x(\tau_A < \tau_B \mid X_1 = y) \\ &= \sum_y P(x, y)h(y),\end{aligned}$$

其中第二个等号使用 Markov 性。

唯一性可由最大值原理证明。若 u, v 均为解, 令 $w = u - v$ 。则 $w = 0$ 于边界, 且内部调和。若 w 在内部取得严格正最大值, 调和平均关系迫使所有可达邻点都取同一最大值, 最终传播到边界, 与边界为零矛盾。对 $-w$ 同理。 $\square$



定理 11.43 (平均首达时间的 Poisson 方程). 设 $C \subseteq S$, $\tau_C = \inf\{n \geq 0 : X_n \in C\}$, 并假设 $m(x) := \mathbb{E}_x \tau_C < \infty$. 则 $m(x) = 0$, $x \in C$, 且对 $x \notin C$,

$$m(x) = 1 + \sum_y P(x, y)m(y).$$

(11.44)

证明. 若 $x \notin C$, 第一步必然消耗一个单位时间. 给定 $X_1 = y$ 后, 剩余命中时间的条件期望为 $m(y)$, 故 $m(x) = 1 + \mathbb{E}_x[m(X_1)] = 1 + \sum_y P(x, y)m(y)$. □

首步分析法

识别信号: 求命中概率、退出概率、平均命中时间、累计报酬。


构造:

- (1) 定义目标函数, 例如 $h(x) = \mathbb{P}_x(\tau_A < \tau_B)$, $m(x) = \mathbb{E}_x \tau_C$;
- (2) 写边界条件;
- (3) 给定第一步 X_1 分解;
- (4) 得到调和方程或 Poisson 方程;
- (5) 解差分方程;
- (6) 说明解的唯一性。

常见失分: 只写出差分方程, 没有写边界条件; 或者写出一个解, 却没有说明为什么它是所求概率或期望的唯一解。

11.18 马尔可夫链易错点总表

陈述	判断	正确说明
Markov 性表示未来与过去独立	错	是给定现在后, 未来与过去条件独立。
不可约表示 $P(x, y) > 0$	错	只需存在某个 n 使 $P^n(x, y) > 0$ 。
常返表示平均返回时间有限	错	平均返回时间有限是正常返; 常返还包括零常返。
平稳分布存在即唯一	错	不可约正常返时才自动唯一; 可约链可有多个平稳分布。
平稳分布唯一即 $P^n(x, \cdot) \rightarrow \pi$	错	还可能因周期性而振荡。
非周期性是遍历定理的必要条件	错	时间平均收敛不需要非周期性。
详细平衡等价于平稳性	错	详细平衡推出平稳性, 但平稳链未必可逆。
不可约可数链一定有平稳分布	错	只有正常返不可约链才有平稳概率分布。
零常返链有平稳概率分布	错	Kac 公式会要求 $\pi(x) = 1/\infty = 0$, 无法归一化。
暂留链永远不会回到起点	错	它仍可能返回若干次, 只是最终返回概率小于 1。



马尔可夫链综合题

- (1) 明确状态空间 S ;
- (2) 写出全部非零转移概率并核查每行和为 1;
- (3) 用条件概率或独立随机输入证明 Markov 性;
- (4) 判断沟通类、闭类与不可约性;
- (5) 计算周期;
- (6) 判断常返、零常返、正常返或暂留;
- (7) 求平稳分布:
 - 直接解 $\pi = \pi P$;
 - 或使用详细平衡;
 - 或使用 Kac 公式;
- (8) 若要声称分布收敛, 必须再检查非周期性;
- (9) 若只要求长期占用比例, 使用遍历定理, 不需非周期性。

一些需要记忆的内容

- (1) Markov 性的条件期望形式是什么?
- (2) 强马尔可夫性质与普通 Markov 性的区别是什么?
- (3) 如何用 $\sum_n P^n(x, x)$ 判断常返与暂留?
- (4) 正常返、零常返、暂留三者如何区分?
- (5) 详细平衡为什么能推出平稳性?
- (6) 平稳分布存在、唯一和收敛到平稳分布分别需要什么条件?
- (7) 为什么周期链仍可满足遍历定理?
- (8) Kac 公式如何由平均返回时间求平稳质量?



第十二章 随机游动、树上随机游动与电网络方法

12.1 考纲定位与证明要求

重点

S 级

【必须会完整证明】：一维简单随机游动的分布、赌徒破产公式、反射原理、常返判据、树上随机游动真题。

【必须会复现证明框架】：Pólya 常返定理、电网络与有效电阻判据。

【必须会熟练应用】：指数鞅、调和函数、首步分析、生成函数、径向链与分层电阻。

考试重点

随机游动题常同时具有三种可用结构：

- (1) 独立和结构： $S_n = S_0 + \xi_1 + \cdots + \xi_n$;
- (2) 马尔可夫结构：命中概率满足调和方程；
- (3) 鞅结构： $S_n - n\mathbb{E}\xi_1$, $S_n^2 - n\text{Var}(\xi_1)$, $\frac{e^{\theta S_n}}{M(\theta)^n}$.

高分答案应选择最短且条件最容易核查的方法，而不是机械使用某一固定工具。

往年真题

随机游动的实考形式包括：

- 一维偏随机游动的命中概率与上确界分布；
- 双边退出时间的概率生成函数；
- 正则树和 b 叉树上的常返与暂留；
- Brownian motion 首达问题中的离散随机游动类比。

12.2 一维简单随机游动的基本分布

设 $\xi_1, \xi_2, \dots \stackrel{\text{i.i.d.}}{\sim}$ 且 $\mathbb{P}(\xi_k = 1) = p$, $\mathbb{P}(\xi_k = -1) = q = 1 - p$ 。定义

$$S_n = S_0 + \sum_{k=1}^n \xi_k. \quad (12.1)$$

当 $p = q = 1/2$ 时，称为简单对称随机游动。



若 $S_0 = 0$, 则 $S_n = 2B_n - n$, $B_n \sim \text{Bin}(n, p)$ 。因此对满足 $|j| \leq n$, $n + j$ 为偶数 的整数 j ,

$$\mathbb{P}(S_n = j) = \binom{n}{(n+j)/2} p^{(n+j)/2} q^{(n-j)/2}. \quad (12.2)$$

若奇偶性不匹配, 则概率为零。

特别地, 在对称情形,

$$\mathbb{P}(S_n = j) = 2^{-n} \binom{n}{(n+j)/2}. \quad (12.3)$$

矩为 $\mathbb{E}S_n = S_0 + n(p - q)$, $\text{Var}(S_n) = 4npq$ 。对称情形下, $\mathbb{E}S_n = S_0$, $\text{Var}(S_n) = n$ 。

命题 12.1 (随机游动的基本鞅). 令 $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$ 。

- (1) $S_n - n(p - q)$ 是鞅;
- (2) $(S_n - n(p - q))^2 - 4npq$ 是鞅;
- (3) 若 $M(\theta) = \mathbb{E}e^{\theta\xi_1} = pe^\theta + qe^{-\theta} < \infty$, 则 $\frac{e^{\theta(S_n - S_0)}}{M(\theta)^n}$ 是非负鞅。

12.3 反射原理

令简单对称随机游动从 0 出发, 并定义 $M_n = \max_{0 \leq k \leq n} S_k$ 。

定理 12.2 (离散反射原理). 设 $a \geq 1$, $b < a$ 为整数, 且 b 与 n 奇偶性一致。则

$$\mathbb{P}(M_n \geq a, S_n = b) = \mathbb{P}(S_n = 2a - b). \quad (12.4)$$

因此

$$\mathbb{P}(M_n \geq a) = \mathbb{P}(S_n \geq a) + \mathbb{P}(S_n > a). \quad (12.5)$$

证明. 考虑满足 $M_n \geq a$, $S_n = b < a$ 的路径。令 $T_a = \inf\{k : S_k = a\}$ 。在时刻 T_a 之后, 将每个增量反号: $\xi_k \mapsto -\xi_k$, $k > T_a$ 。反射后路径在时刻 T_a 前不变, 之后关于水平线 a 反射。原终点 b 被映为 $a + (a - b) = 2a - b$ 。该变换可逆, 并且对称随机游动的每条长度 n 路径概率均为 2^{-n} , 所以得到 (12.4)。

所有终点不低于 a 的路径本身已经满足 $M_n \geq a$; 终点低于 a 的部分经反射一一对应于终点严格大于 a 的路径。求和即得 (12.5)。□

注 12.3. 由于格点奇偶性, 式 $\mathbb{P}(S_n > a)$ 比连续 Brownian 反射原理中的相应表达式多出格点修正。不能无条件写成 $2\mathbb{P}(S_n \geq a)$ 。

12.4 赌徒破产: 命中概率与平均退出时间

设 $\tau_0 = \inf\{n \geq 0 : S_n = 0\}$, $\tau_N = \inf\{n \geq 0 : S_n = N\}$, 并假设 $S_0 = i$, $0 \leq i \leq N$ 。令 $\tau = \tau_0 \wedge \tau_N$ 。

12.4.1 先到达上边界的概率

定义 $h(i) = \mathbb{P}_i(\tau_N < \tau_0)$ 。首步分析给出 $h(i) = ph(i+1) + qh(i-1)$, $1 \leq i \leq N-1$, 边界条件为 $h(0) = 0$, $h(N) = 1$ 。



定理 12.4 (赌徒破产命中概率).
$$h(i) = \begin{cases} \frac{i}{N}, & p = q = \frac{1}{2}, \\ \frac{1 - (q/p)^i}{1 - (q/p)^N}, & p \neq q. \end{cases}$$

证明. 若 $p = q = 1/2$, 差分方程等价于 $h(i+1) - h(i) = h(i) - h(i-1)$, 故 h 为仿射函数, 由边界条件得到 $h(i) = i/N$.

若 $p \neq q$, 特征方程为 $pr^2 - r + q = 0$, 两个根为 1, q/p . 故通解为 $h(i) = A + B(q/p)^i$. 代入 $h(0) = 0$, $h(N) = 1$, 得到 (12.4). $\square$

12.4.2 平均退出时间

定义 $m(i) = \mathbb{E}_i \tau$. 首步分析给出 $m(i) = 1 + pm(i+1) + qm(i-1)$, 边界条件为 $m(0) = m(N) = 0$.

定理 12.5 (赌徒破产平均退出时间).
$$m(i) = \begin{cases} i(N-i), & p = q = \frac{1}{2}, \\ \frac{i}{q-p} - \frac{N}{q-p} \frac{1 - (q/p)^i}{1 - (q/p)^N}, & p \neq q. \end{cases}$$

证明思路

对称情形猜测二次函数并代入. 非对称情形中, 非齐次方程的一个特解为 $\frac{i}{q-p}$, 齐次解仍为 $A + B(q/p)^i$. 再使用两个边界条件确定常数.

一维退出问题

- (1) 定义目标函数 $h(i)$ 或 $m(i)$;
- (2) 写清状态范围 $0 \leq i \leq N$;
- (3) 对内部状态进行首步分析;
- (4) 写出两个边界条件;
- (5) 分别处理 $p = q$ 与 $p \neq q$;
- (6) 说明所得解唯一;
- (7) 若令 $N \rightarrow \infty$, 检查极限方向和参数范围.


12.5 半直线上的命中概率

令随机游动从 $a \geq 1$ 出发, 定义 $\tau_0 = \inf\{n \geq 0 : S_n = 0\}$.

由有限区间公式令 $N \rightarrow \infty$, 得到

$$\mathbb{P}_a(\tau_0 < \infty) = \begin{cases} 1, & p \leq q, \\ \left(\frac{q}{p}\right)^a, & p > q. \end{cases} \quad (12.6)$$

证明. 对 $p \neq q$, $\mathbb{P}_a(\tau_0 < \tau_N) = 1 - \frac{1 - (q/p)^a}{1 - (q/p)^N} = \frac{(q/p)^a - (q/p)^N}{1 - (q/p)^N}$. 当 $p > q$ 时, $q/p < 1$, 令 $N \rightarrow \infty$ 得 $(q/p)^a$. 当 $p < q$ 时, $q/p > 1$, 分子分母同阶, 极限为 1. 对称情形 $\mathbb{P}_a(\tau_0 < \tau_N) = 1 - \frac{a}{N} \rightarrow 1$. $\square$



12.6 简单随机游动的常返判据

设 S_n 是从原点出发的 $\mathbb{Z}^d$ 上简单随机游动。每一步以概率 $1/(2d)$ 移动到某个 $\pm e_j$, $j = 1, \dots, d$ 。

由 定理 11.21,

$$S_n \text{ 常返} \iff \sum_{n=0}^{\infty} \mathbb{P}_0(S_n = 0) = \infty. \quad (12.7)$$

定理 12.6 (Pólya 常返定理). (1) $\mathbb{Z}$ 和 $\mathbb{Z}^2$ 上的简单随机游动常返;

(2) 对所有 $d \geq 3$, $\mathbb{Z}^d$ 上的简单随机游动暂留。

证明. 奇数时刻不能返回原点, 因此只考虑 $2n$ 。

$d = 1$

$\mathbb{P}_0(S_{2n} = 0) = \binom{2n}{n} 2^{-2n}$ 。由 Stirling 公式,

$$\mathbb{P}_0(S_{2n} = 0) \sim \frac{1}{\sqrt{\pi n}}. \quad (12.8)$$

因此 $\sum_n \mathbb{P}_0(S_{2n} = 0) = \infty$, 故一维随机游动常返。

$d = 2$

在 $2n$ 步中, 设沿第一坐标正、负方向各走 m 步, 沿第二坐标正、负方向各走 $n - m$ 步。则

$$\begin{aligned} \mathbb{P}_0(S_{2n} = 0) &= 4^{-2n} \sum_{m=0}^n \frac{(2n)!}{m!^2(n-m)!^2} \\ &= 4^{-2n} \binom{2n}{n} \sum_{m=0}^n \binom{n}{m}^2 \\ &= 4^{-2n} \binom{2n}{n}^2. \end{aligned}$$

其中使用 Vandermonde 恒等式 $\sum_{m=0}^n \binom{n}{m}^2 = \binom{2n}{n}$ 。因此

$$\mathbb{P}_0(S_{2n} = 0) \sim \frac{1}{\pi n}. \quad (12.9)$$

调和级数发散, 故二维随机游动常返。

$d = 3$

设沿三个坐标轴的正、负方向分别各走 j , k , $n - j - k$ 步。则

$$\begin{aligned} p_3(2n) &:= \mathbb{P}_0(S_{2n} = 0) \\ &= 6^{-2n} \sum_{\substack{j,k \geq 0 \\ j+k \leq n}} \frac{(2n)!}{j!^2 k!^2 (n-j-k)!^2}. \end{aligned}$$

可重写为 $p_3(2n) = p_1(2n) \sum_{j,k} \left[\frac{3^{-n} n!}{j! k! (n-j-k)!} \right]^2$, 其中 $p_1(2n) = 2^{-2n} \binom{2n}{n} = O(n^{-1/2})$ 。记 $a_{j,k} = \frac{3^{-n} n!}{j! k! (n-j-k)!}$ 。这些是参数为 $(n; 1/3, 1/3, 1/3)$ 的多项分布概率, 故 $\sum_{j,k} a_{j,k} = 1$ 。于是 $\sum_{j,k} a_{j,k}^2 \leq \max_{j,k} a_{j,k}$ 。最大值在



$j, k, n - j - k$ 均接近 $n/3$ 时取得。由 Stirling 公式, $\max_{j,k} a_{j,k} = O(n^{-1})$ 。所以

$$p_3(2n) = O(n^{-3/2}). \quad (12.10)$$

因此 $\sum_n p_3(2n) < \infty$, 三维随机游动暂留。

$$d > 3$$

将 d 维随机游动投影到前三个坐标。投影过程每一步以概率 $3/d$ 做一次三维简单随机游动步, 以概率 $1 - 3/d$ 保持不动。去除保持不动的时刻后, 其嵌入链是三维简单随机游动, 因而暂留。原链返回原点必然导致投影返回原点, 所以原链也暂留。□

推论 12.7. $\mathbb{Z}$ 与 $\mathbb{Z}^2$ 上的简单随机游动均为零常返。

证明. 已经证明其不可约且常返。若其正常返, 则存在唯一平稳概率分布。对任意平移向量 a , 平移后的分布 $\pi_a(x) = \pi(x - a)$ 仍为平稳分布。唯一性迫使 $\pi_a = \pi$ 对所有 a , 所以 π 必为常数分布, 不可能在无限格点上归一化。因此不存在平稳概率分布, 链只能是零常返。□

12.7 真题完整解法: 正则树与 b 叉树上的随机游动

往年真题

2024 Fall 第 4 题, 10 分。

- (1) T_d 为无限 d -正则树, 每个顶点度数均为 d , $d \geq 2$ 。判断其简单随机游动常返或暂留;
- (2) T_b 为以 o 为根的无限 b 叉树: 每个顶点有 b 个孩子, 每个非根顶点另有一个父亲。判断其简单随机游动常返或暂留。

解: 两问均使用到根的距离过程, 将树上的随机游动降维为半直线上的出生-死亡链。

第一问: 无限 d -正则树

固定根顶点 o , 令 $R_n = \text{dist}(X_n, o)$ 。显然 $R_0 = 0$ 。当 $R_n = 0$ 时, 下一步必到达第 1 层: $\mathbb{P}(R_{n+1} = 1 \mid R_n = 0) = 1$ 。当 $R_n = r \geq 1$ 时, 当前顶点有:

- 唯一的一个邻点位于第 $r - 1$ 层;
- 其余 $d - 1$ 个邻点位于第 $r + 1$ 层。

所以


$$\mathbb{P}(R_{n+1} = r + 1 \mid R_n = r) = \frac{d - 1}{d}, \quad (12.11)$$

$$\mathbb{P}(R_{n+1} = r - 1 \mid R_n = r) = \frac{1}{d}. \quad (12.12)$$

树上随机游动从根出发后是否返回根, 等价于径向链从 1 出发是否命中 0。

$$\text{令 } p = \frac{d-1}{d}, q = \frac{1}{d}.$$

若 $d = 2$, 则 $p = q = \frac{1}{2}$ 。此时 T_2 就是双向无限路径, 图同构于 $\mathbb{Z}$ 。由一维简单随机游动常返性, $\mathbb{P}_o(\tau_o^+ < \infty) = 1$ 。故 $d = 2$ 时常返。



若 $d \geq 3$, 则 $p > q$ 。由半直线命中公式 (12.6), $\mathbb{P}_1(\tau_0 < \infty) = \frac{q}{p} = \frac{1}{d-1} < 1$ 。从根 o 出发第一步必到第 1 层, 因此 $\mathbb{P}_o(\tau_o^+ < \infty) = \frac{1}{d-1} < 1$ 。故 $d \geq 3$ 时暂留。

综上, T_d 上的简单随机游动 $\begin{cases} \text{常返, } d = 2, \\ \text{暂留, } d \geq 3. \end{cases}$

第二问: 无限 b 叉树

同样令 $R_n = \text{dist}(X_n, o)$ 。根 o 的度数为 b , 但从根出发时下一步仍必到第 1 层。对任意第 $r \geq 1$ 层顶点:

- 有一个父亲, 位于第 $r-1$ 层;
- 有 b 个孩子, 位于第 $r+1$ 层;
- 总度数为 $b+1$ 。

因此 $\mathbb{P}(R_{n+1} = r+1 \mid R_n = r) = \frac{b}{b+1}$, $\mathbb{P}(R_{n+1} = r-1 \mid R_n = r) = \frac{1}{b+1}$ 。

若 $b = 1$, 径向链在正整数处是对称随机游动, 根处反射到 1。它几乎处处返回 0, 故 $b = 1$ 时常返。此时图是一条半无限路径。

若 $b \geq 2$, 则向外概率严格大于向内概率。由 (12.6), $\mathbb{P}_1(\tau_0 < \infty) = \frac{1/(b+1)}{b/(b+1)} = \frac{1}{b} < 1$ 。所以 $b \geq 2$ 时暂留。

综上, T_b 上的简单随机游动 $\begin{cases} \text{常返, } b = 1, \\ \text{暂留, } b \geq 2. \end{cases}$ □

考试时需要注意的地方

该题完整得分步骤为:

- (1) 选定根并定义距离过程 R_n ;
- (2) 说明 R_n 本身是半直线上的出生-死亡链;
- (3) 正确计算向内、向外的转移概率;
- (4) 将返回根转化为从 1 命中 0;
- (5) 使用偏随机游动命中概率;
- (6) 分别处理临界情形 $d = 2$ 、 $b = 1$;
- (7) 明确写出常返或暂留, 而非只说“有向外漂移”。

易错点与失分点

“距离过程有正漂移”是正确直觉, 但仅凭漂移符号不能代替证明。资格考试中应计算实际返回概率 $\frac{q}{p}$ 或使用有效电阻判据。

12.8 课程扩展：随机游动与电网络

重点

B 级 【必须会复现证明框架】

该主题未在简要考纲中单独列出，但属于概率论课程讲义中的随机游动模块，并可为树上随机游动、命中概率和 Green 函数提供统一工具。

12.8.1 加权网络与可逆随机游动

定义 12.8 (电网络). 设 $G = (V, E)$ 为连通无向图。对每条边 $e = \{x, y\}$ 赋予电导 $c(e) = c(x, y) > 0$, 并定义电阻 $r(e) = \frac{1}{c(e)}$ 。令 $c(x) = \sum_{y: y \sim x} c(x, y)$ 。相应加权随机游动为

$$P(x, y) = \frac{c(x, y)}{c(x)}. \quad (12.13)$$

在有限网络中, $\pi(x) = \frac{c(x)}{\sum_z c(z)}$ 满足详细平衡: $\pi(x)P(x, y) = \frac{c(x, y)}{\sum_z c(z)} = \pi(y)P(y, x)$ 。

12.8.2 电压、调和函数与命中概率

固定两个边界点 a, z 。电压函数 W 在内部满足 $W(x) = \sum_y P(x, y)W(y)$, $x \notin \{a, z\}$, 即 W 是调和函数。

若边界条件为 $W(a) = 1, W(z) = 0$, 则由调和函数唯一性,

$$W(x) = \mathbb{P}_x(\tau_a < \tau_z). \quad (12.14)$$

12.8.3 有效电阻

给定电压 W , 边 $x \rightarrow y$ 上的电流为 $I(x, y) = c(x, y)(W(x) - W(y))$ 。从源点 a 流出的总电流为 $\|I\| = \sum_y I(a, y)$ 。有效电阻定义为

$$R_{\text{eff}}(a \leftrightarrow z) = \frac{W(a) - W(z)}{\|I\|}. \quad (12.15)$$

定理 12.9 (逃逸概率与有效电阻). 对有限网络,

$$\mathbb{P}_a(\tau_z < \tau_a^+) = \frac{1}{c(a)R_{\text{eff}}(a \leftrightarrow z)}. \quad (12.16)$$

证明思路

函数 $x \mapsto \mathbb{P}_x(\tau_z < \tau_a)$ 与归一化电压 $x \mapsto \frac{W(a) - W(x)}{W(a) - W(z)}$ 具有相同边界值, 且在内部均调和, 故二者相等。从 a 做第一步分解后, 流出 a 的总电流恰好给出 (12.16)。

定理 12.10 (无限网络的常返判据). 设 G 为无限、局部有限连通网络。取有限集合递增穷尽 $V_1 \subseteq V_2 \subseteq \cdots \uparrow V$, $o \in V_1$, 并将 V_n^c 胶合为边界点 ∂V_n 。则 $R_{\text{eff}}(o \leftrightarrow \infty) := \lim_{n \rightarrow \infty} R_{\text{eff}}(o \leftrightarrow \partial V_n)$ 存在, 且

$$\text{随机游动常返} \iff R_{\text{eff}}(o \leftrightarrow \infty) = \infty. \quad (12.17)$$

证明思路

由 (12.16), $\mathbb{P}_o(\tau_{\partial V_n} < \tau_o^+) = \frac{1}{c(o)R_{\text{eff}}(o \leftrightarrow \partial V_n)}$ 。令 $n \rightarrow \infty$, 左侧递减到从 o 出发后永远不再返回 o 的概率。该逃逸概率为零当且仅当有效电阻趋于无穷。

12.8.4 树上的分层电阻计算

对单位电阻的 d -正则树, 固定根 o 。第 $k-1$ 层与第 k 层之间共有 $d(d-1)^{k-1}$ 条边。

由对称性, 同一层顶点具有相同电压, 可将同层顶点胶合。该层所有边并联, 等效电阻为 $r_k = \frac{1}{d(d-1)^{k-1}}$ 。不同层串联, 因此 $R_{\text{eff}}(o \leftrightarrow \infty) = \sum_{k=1}^{\infty} \frac{1}{d(d-1)^{k-1}}$ 。若 $d=2$, 该和为 $\sum_{k=1}^{\infty} \frac{1}{2} = \infty$; 若 $d \geq 3$, 则 $R_{\text{eff}} = \frac{1}{d} \frac{1}{1-(d-1)^{-1}} = \frac{d-1}{d(d-2)} < \infty$ 。故再次得到: $d=2$ 常返, $d \geq 3$ 暂留。

对无限 b 叉树, 第 $k-1$ 层与第 k 层之间有 b^k 条边, 所以 $R_{\text{eff}}(o \leftrightarrow \infty) = \sum_{k=1}^{\infty} b^{-k}$ 。该和在 $b=1$ 时发散, 在 $b > 1$ 时等于 $\frac{1}{b-1} < \infty$ 。这与径向链方法完全一致。

12.9 随机游动证明方法总表

方法一：调和函数

适用目标：命中概率、先到某边界的概率。

方程： $h(x) = Ph(x)$ 加边界条件。

优势：直接、无需额外矩条件。

风险：必须证明边界值问题的唯一性。

方法二：鞅与可选停止

适用目标：命中概率、平均退出时间、首达时变换。

常用鞅： $S_n - n\mu$, $(S_n - n\mu)^2 - n\sigma^2$, $\frac{e^{\theta S_n}}{M(\theta)^n}$ 。

风险：必须先对 $T \wedge n$ 停止, 并核查有界性、UI 或控制收敛条件。

方法三：返回概率级数

适用目标：常返与暂留。

判据： $\sum_n P^n(x, x) \begin{cases} = \infty, & \text{常返,} \\ < \infty, & \text{暂留.} \end{cases}$

常用工具：组合计数、Stirling 公式、局部中心极限定理。

方法四：径向链

适用目标：树、分层图或具有球面对称性的图。

构造： $R_n = \text{dist}(X_n, o)$ 。

核心：将高维图上的随机游动化为半直线上的出生-死亡链。

方法五：有效电阻

适用目标：无向网络上的常返性、逃逸概率、Green 函数。

判据： $R_{\text{eff}}(o \leftrightarrow \infty) = \infty \iff$ 常返。

优势：并联、串联和对称胶合可大幅简化树和格图。

12.10 随机游动易错点总表

陈述	判断	正确说明
零漂移随机游动一定常返	错	维数及增量分布同样关键； $\mathbb{Z}^3$ 简单对称随机游动暂留。
正漂移足以作为暂留的完整证明	不完整	应计算命中概率或使用大数律加严格论证。
$\mathbb{Z}^2$ 随机游动因为均值为零而常返	错	常返性来自返回概率级数发散。
树上随机游动可只看顶点总数增长	不完整	应构造径向出生-死亡链或计算有效电阻。
反射原理可直接用于偏随机游动	一般错误	路径反射后概率权重改变；简单形式依赖对称性。
命中概率只需解差分方程	不完整	还需边界条件和唯一性。
常返链必有平稳概率分布	错	零常返链没有平稳概率分布。
有效电阻有限表示常返	错	有效电阻有限表示存在正逃逸概率，即暂留。
d 维随机游动的返回概率总是 $n^{-1/2}$	错	典型阶为 $n^{-d/2}$ ，维数决定级数是否收敛。
树的根度数不同会使径向方法失效	错	根处只影响第一步；返回分类由正层上的向内、向外概率决定。

随机游动综合题

(1) 写清起点、增量分布和过滤；

(2) 判断题目属于：

- 命中概率；
- 平均时间；
- 生成函数；
- 常返性；
- 极值或最大值；

(3) 选择相应工具：调和函数、鞅、反射原理、返回概率级数、径向链或电阻；

(4) 写出边界条件或停止条件；

(5) 若使用可选停止，核查全部合法性条件；

(6) 若使用渐近返回概率，说明级数收敛或发散；

(7) 最终明确写出“常返、零常返、正常返或暂留”。

一些需要记忆的内容

- (1) 一维简单对称随机游动在时刻 n 能到达哪些整数?
- (2) 反射原理如何把穿越水平 a 后落在 $b < a$ 的路径映到另一条路径?
- (3) 赌徒破产概率在 $p = q$ 和 $p \neq q$ 时为何形式不同?
- (4) 为什么 $\sum_n \mathbb{P}_0(S_n = 0)$ 是常返性的判据?
- (5) $\mathbb{Z}^2$ 与 $\mathbb{Z}^3$ 的返回概率级数分别为何发散和收敛?
- (6) 树上随机游动的距离过程为什么是 Markov 链?
- (7) d -正则树上从第 1 层返回根的概率是多少?
- (8) 有效电阻与逃逸概率之间是什么关系?
- (9) 为什么 $\mathbb{Z}$ 上简单随机游动是零常返而不是正常返?



第十三章 泊松过程与连续时间马尔可夫链

13.1 考纲定位、优先级与资料约定

重点

泊松过程：A 级。

【必须会完整证明】：泊松过程的等价刻画、等待时间的指数分布、第 n 次到达时间的 Gamma 分布、给定总到达数后的条件分布、叠加与稀疏化。

【必须会熟练应用】：独立平稳增量、到达时间与计数过程的互换、补偿鞅、指数鞅、条件于总到达数的二项或多项分布。

连续时间马尔可夫链：B 级课程扩展。

该主题未在简要考纲中单独列出，但在 [P-Lec] 中作为泊松过程之后的完整章节出现，是理解泊松过程、排队模型和连续时间随机过程的自然工具。五套真题中未见以一般连续时间马尔可夫链为题干核心的独立题目，故其证明深度低于布朗运动和离散时间鞅。

Notations

全文统一采用以下参数化：

- (1) $X \sim \text{Exp}(\lambda)$ 表示率参数为 $\lambda > 0$ 的指数分布： $f_X(x) = \lambda e^{-\lambda x} \mathbf{1}_{\{x>0\}}$, $\mathbb{E}X = \frac{1}{\lambda}$;
- (2) $T \sim \text{Gamma}(n, \lambda)$ 表示形状参数 $n > 0$ 、率参数 $\lambda > 0$ ： $f_T(t) = \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t} \mathbf{1}_{\{t>0\}}$;
- (3) 泊松过程的强度记为 λ ;
- (4) 连续时间马尔可夫链的生成元本文记为 $Q = (q_{xy})_{x,y \in S}$. [P-Lec] 中生成元主要记为 A ；两种记号完全等价。

13.2 点过程、到达时间与计数过程

定义 13.1 (简单点过程). 一系列随机时间 $0 = T_0 < T_1 < T_2 < \dots$, $T_n \uparrow \infty$ a.s., 称为 $\mathbb{R}_+$ 上的简单点过程。

定义第 n 个间隔时间

$$S_n = T_n - T_{n-1}, \quad n \geq 1. \quad (13.1)$$

定义 13.2 (计数过程). 对 $0 \leq a < b$, 定义 $N(a, b] = \sum_{n \geq 1} \mathbf{1}_{\{T_n \in (a, b]\}}$ 。特别地，

$$N_t = N(0, t] = \max\{n : T_n \leq t\}, \quad t \geq 0. \quad (13.2)$$

到达时间和计数过程之间具有基本等价关系：

$$\{T_n \leq t\} = \{N_t \geq n\}, \quad (13.3)$$

$$\{T_n > t\} = \{N_t \leq n-1\}. \quad (13.4)$$



考试时需要注意的地方

T_n 与 N_t 的下标含义不同:

- T_n 是随机时间;
- N_t 是随机计数;
- $T_{N_t} \leq t < T_{N_t+1}$ 在每条样本路径上成立。

13.3 泊松过程的定义与基本矩

定义 13.3 (齐次泊松过程). 计数过程 $\{N_t\}_{t \geq 0}$ 称为强度 $\lambda > 0$ 的泊松过程, 若满足:

- (1) $N_0 = 0$ a.s.;
- (2) 对任意 $0 \leq t_0 < t_1 < \cdots < t_k$, 增量 $N_{t_1} - N_{t_0}, \dots, N_{t_k} - N_{t_{k-1}}$ 相互独立;
- (3) 对任意 $0 \leq s < t$,

$$N_t - N_s \sim \text{Poisson}(\lambda(t - s)). \quad (13.5)$$

第二点称为**独立增量**, 第三点同时包含:

- 增量的分布只依赖区间长度, 即平稳增量;
- 长度为 u 的区间内计数服从 $\text{Poisson}(\lambda u)$ 。

命题 13.4 (一维分布与生成函数). 若 $\{N_t\}$ 为强度 λ 的泊松过程, 则 $N_t \sim \text{Poisson}(\lambda t)$ 。因此对 $z \geq 0$,

$$\mathbb{E}[z^{N_t}] = \exp\{\lambda t(z - 1)\}, \quad (13.6)$$

对 $\theta \in \mathbb{R}$,

$$\mathbb{E}[e^{\theta N_t}] = \exp\{\lambda t(e^\theta - 1)\}, \quad (13.7)$$


并且

$$\mathbb{E}N_t = \lambda t, \quad \text{Var}(N_t) = \lambda t. \quad (13.8)$$

命题 13.5 (协方差函数). 对任意 $s, t \geq 0$,

$$\text{Cov}(N_s, N_t) = \lambda(s \wedge t). \quad (13.9)$$

证明. 不妨设 $s \leq t$ 。写成 $N_t = N_s + (N_t - N_s)$ 。由独立增量, $\text{Cov}(N_s, N_t - N_s) = 0$, 故 $\text{Cov}(N_s, N_t) = \text{Var}(N_s) = \lambda s$ 。□



概念比较

泊松随机变量和泊松过程必须区分：

对象	记号	需要描述的信息
泊松随机变量	$X \sim \text{Poisson}(\mu)$	一个固定时刻的计数分布
泊松过程	$\{N_t : t \geq 0\}$	所有时刻的联合分布，以及独立平稳增量

[25F-Q1] 中的 N 是泊松随机变量，不是泊松过程。

13.4 无记忆性与指数分布

定理 13.6 (无记忆性的刻画). 设 T 为几乎处处严格正的随机变量。以下条件等价：

(1) 对任意 $s, t \geq 0$,

$$\mathbb{P}(T > s + t \mid T > s) = \mathbb{P}(T > t); \quad (13.10)$$

(2) 存在 $\lambda > 0$, 使 $T \sim \text{Exp}(\lambda)$.

证明. 令 $G(t) = \mathbb{P}(T > t)$. 无记忆性等价于

$$G(s + t) = G(s)G(t), \quad s, t \geq 0. \quad (13.11)$$

又因 $T > 0$ a.s., $G(0) = 1$, 且 G 单调不减、右连续。

若存在 $t_0 > 0$ 使 $G(t_0) = 0$, 则由 $G(t_0) = G(t_0/n)^n$ 得到 $G(t_0/n) = 0$, 令 $n \rightarrow \infty$ 与 $G(0) = 1$ 的右连续性矛盾。故 $G(t) > 0$ 对所有 $t \geq 0$ 。

定义 $h(t) = -\log G(t)$. 则 h 非负、单调不减, 并由 (13.11) 得 $h(s + t) = h(s) + h(t)$. 单调的 Cauchy 方程解必为线性: $h(t) = \lambda t$ 对某个 $\lambda \geq 0$ 成立。因为 T 几乎处处有限, $G(t) \rightarrow 0$, 故 $\lambda > 0$. 于是 $G(t) = e^{-\lambda t}$ 。

反方向由 $\frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}$ 直接得到。□

13.5 到达间隔与第 n 次到达时间

定理 13.7 (泊松过程的间隔时间). 若 $\{N_t\}$ 是强度 λ 的泊松过程, 则 $S_1, S_2, \dots \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ 。反之, 若 $S_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$, $T_n = \sum_{j=1}^n S_j$, 并令 $N_t = \max\{n : T_n \leq t\}$, 则 $\{N_t\}$ 是强度 λ 的泊松过程。

证明. 首先, $\mathbb{P}(S_1 > t) = \mathbb{P}(N_t = 0) = e^{-\lambda t}$, 故 $S_1 \sim \text{Exp}(\lambda)$ 。

更一般地, 在事件 $\{T_{n-1} < \infty\}$ 上, 泊松过程在 T_{n-1} 之后的增量过程与过去独立, 并具有与原过程相同的分布。因此 $S_n = T_n - T_{n-1}$ 与 $\sigma(S_1, \dots, S_{n-1})$ 独立, 且与 S_1 同分布。

反方向可通过计算 $\mathbb{P}(N_t = n) = \mathbb{P}(T_n \leq t < T_{n+1})$ 得到泊松分布, 再利用指数分布的无记忆性证明独立平稳增量。也可直接计算有限维联合分布。□

定理 13.8 (第 n 次到达时间). 对 $n \geq 1$,

$$T_n = S_1 + \cdots + S_n \sim \text{Gamma}(n, \lambda), \quad (13.12)$$

即

$$f_{T_n}(t) = \frac{\lambda^n t^{n-1}}{(n-1)!} e^{-\lambda t} \mathbf{1}_{\{t>0\}}. \quad (13.13)$$

相应分布函数为

$$\mathbb{P}(T_n \leq t) = \mathbb{P}(N_t \geq n) = 1 - e^{-\lambda t} \sum_{k=0}^{n-1} \frac{(\lambda t)^k}{k!}. \quad (13.14)$$

证明. 由独立指数变量之和的卷积可得 Gamma 密度. 也可从 $\mathbb{P}(T_n \leq t) = \mathbb{P}(N_t \geq n)$ 对 t 求导:

$$\begin{aligned} \frac{d}{dt} \mathbb{P}(T_n \leq t) &= -\frac{d}{dt} \left[e^{-\lambda t} \sum_{k=0}^{n-1} \frac{(\lambda t)^k}{k!} \right] \\ &= \frac{\lambda^n t^{n-1}}{(n-1)!} e^{-\lambda t}. \end{aligned}$$

□

推论 13.9. $\mathbb{E}T_n = \frac{n}{\lambda}$, $\text{Var}(T_n) = \frac{n}{\lambda^2}$.

13.6 给定总到达数后的条件结构

定理 13.10 (条件于 $N_t = n$ 的到达时刻). 固定 $t > 0$. 给定 $N_t = n$, 有序到达时刻 $0 < T_1 < \cdots < T_n < t$ 的联合条件密度为

$$f(t_1, \dots, t_n \mid N_t = n) = \frac{n!}{t^n} \mathbf{1}_{\{0 < t_1 < \cdots < t_n < t\}}. \quad (13.15)$$

因此 $(T_1, \dots, T_n) \mid \{N_t = n\}$ 与 n 个独立 $\text{Unif}(0, t)$ 随机变量的次序统计量同分布。

证明. 对 $0 < t_1 < \cdots < t_n < t$, 事件“在每个小区间 $(t_j, t_j + dt_j]$ 中恰有一个到达, 其余位置无到达”的概率密度为 $\lambda^n e^{-\lambda t}$. 而 $\mathbb{P}(N_t = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}$. 相除得 $\frac{\lambda^n e^{-\lambda t}}{e^{-\lambda t} (\lambda t)^n / n!} = \frac{n!}{t^n}$. □

推论 13.11 (条件二项分布). 若 $0 < s < t$, 则

$$N_s \mid \{N_t = n\} \sim \text{Bin}\left(n, \frac{s}{t}\right). \quad (13.16)$$

证明. 给定 $N_t = n$ 后, n 个无序到达点独立均匀分布于 $(0, t)$. 每个点落入 $(0, s]$ 的概率为 s/t . □

推论 13.12 (条件多项分布). 若 $0 = t_0 < t_1 < \cdots < t_k = t$, 则给定 $N_t = n$ 后, $(N(t_0, t_1], \dots, N(t_{k-1}, t_k])$ 服从参数 n ; $\frac{t_1 - t_0}{t}, \dots, \frac{t_k - t_{k-1}}{t}$ 的多项分布。

考试时需要注意的地方

无条件下, 不同不交区间中的计数独立; 给定总计数 $N_t = n$ 后, 这些计数不再独立, 而具有总和固定为 n 的多项分布。

13.7 小时间刻画

定理 13.13 (泊松过程的小时间刻画). 设 $\{N_t\}_{t \geq 0}$ 为整数值、非减、右连续过程, 且 $N_0 = 0$ 。若:

- (1) 过程有独立平稳增量;
- (2) 当 $h \downarrow 0$ 时,

$$\mathbb{P}(N_h = 1) = \lambda h + o(h), \quad (13.17)$$

$$\mathbb{P}(N_h \geq 2) = o(h), \quad (13.18)$$

则 $\{N_t\}$ 是强度 λ 的泊松过程。

等价地, 可将第二组条件写为 $\mathbb{P}(N_h = 0) = 1 - \lambda h + o(h)$, $\mathbb{P}(N_h = 1) = \lambda h + o(h)$ 。

证明. 令 $p_k(t) = \mathbb{P}(N_t = k)$ 。由独立平稳增量,

$$\begin{aligned} p_0(t+h) &= p_0(t)\mathbb{P}(N_h = 0) \\ &= p_0(t)(1 - \lambda h + o(h)). \end{aligned}$$

因此 $p'_0(t) = -\lambda p_0(t)$, $p_0(0) = 1$, 故 $p_0(t) = e^{-\lambda t}$ 。

对 $k \geq 1$,

$$\begin{aligned} p_k(t+h) &= \sum_{j=0}^k p_j(t)\mathbb{P}(N_h = k-j) \\ &= p_k(t)(1 - \lambda h) + p_{k-1}(t)\lambda h + o(h). \end{aligned}$$

从而得到前向方程

$$p'_k(t) = -\lambda p_k(t) + \lambda p_{k-1}(t), \quad k \geq 1. \quad (13.19)$$

结合 $p_k(0) = 0$, $k \geq 1$, 归纳解得 $p_k(t) = e^{-\lambda t} \frac{(\lambda t)^k}{k!}$ 。因此所有增量均为相应参数的泊松分布。 $\square$

前提条件检查

条件 $\mathbb{P}(N_h \geq 2) = o(h)$ 表示一个极短区间内出现两次及以上跳跃的概率比区间长度低一个阶。若只知道 $\mathbb{P}(N_h \geq 1) = \lambda h + o(h)$, 不足以排除成批跳跃的复合泊松过程。

13.8 叠加、竞争指数钟与稀疏化

13.8.1 叠加

定理 13.14 (泊松过程叠加). 设 $N^{(1)}, \dots, N^{(m)}$ 相互独立, 且 $N^{(j)}$ 的强度为 λ_j 。则

$$N_t = \sum_{j=1}^m N_t^{(j)} \quad (13.20)$$

是强度 $\lambda = \sum_{j=1}^m \lambda_j$ 的泊松过程。

证明. 不交区间上的总增量是各独立过程相应增量之和, 故仍相互独立。



对任意 $0 \leq s < t$, $N_t - N_s = \sum_{j=1}^m (N_t^{(j)} - N_s^{(j)})$ 。右侧是独立泊松随机变量之和, 参数和为 $(t - s) \sum_{j=1}^m \lambda_j$ 。□

13.8.2 竞争指数钟

定理 13.15 (最小指数变量). 设 $T_j \sim \text{Exp}(\lambda_j)$, $j = 1, \dots, m$, 相互独立。令 $T = \min_j T_j$, $J = \arg \min_j T_j$ 。则

$$T \sim \text{Exp} \left(\sum_{j=1}^m \lambda_j \right), \quad (13.21)$$

并且

$$\mathbb{P}(J = j) = \frac{\lambda_j}{\sum_{i=1}^m \lambda_i}. \quad (13.22)$$

此外, T 与 J 独立。

证明. 令 $\Lambda = \sum_{i=1}^m \lambda_i$ 。则 $\mathbb{P}(T > t) = \prod_{i=1}^m \mathbb{P}(T_i > t) = e^{-\Lambda t}$ 。又对 $t \geq 0$,

$$\begin{aligned} \mathbb{P}(T > t, J = j) &= \int_t^\infty \lambda_j e^{-\lambda_j u} \prod_{i \neq j} e^{-\lambda_i u} du \\ &= \int_t^\infty \lambda_j e^{-\Lambda u} du \\ &= \frac{\lambda_j}{\Lambda} e^{-\Lambda t} \\ &= \mathbb{P}(J = j) \mathbb{P}(T > t). \end{aligned}$$

□

13.8.3 稀疏化与分裂

定理 13.16 (泊松稀疏化). 设 N 为强度 λ 的泊松过程。对每个到达点独立地以概率 p 标记为第一类, 以概率 $1 - p$ 标记为第二类, 并且标记与 N 独立。

令 $N_t^{(1)}, N_t^{(2)}$ 分别为两类到达数。则:

- (1) $N^{(1)}$ 是强度 λp 的泊松过程;
- (2) $N^{(2)}$ 是强度 $\lambda(1 - p)$ 的泊松过程;
- (3) 两个过程相互独立。

证明. 固定 t 。给定 $N_t = n$, $N_t^{(1)} \mid N_t = n \sim \text{Bin}(n, p)$, $N_t^{(2)} = n - N_t^{(1)}$ 。联合概率生成函数为

$$\mathbb{E}[z_1^{N_t^{(1)}} z_2^{N_t^{(2)}}] = \mathbb{E}[(pz_1 + (1 - p)z_2)^{N_t}] = \exp\{\lambda t[pz_1 + (1 - p)z_2 - 1]\} = \exp\{\lambda p t(z_1 - 1)\} \times \exp\{\lambda(1 - p)t(z_2 - 1)\}.$$

联合生成函数分解为两个泊松变量生成函数的乘积, 故固定时刻的两个计数独立, 参数分别为 $\lambda p t$ 和 $\lambda(1 - p)t$ 。

对任意不交时间区间重复相同论证, 并使用原泊松过程的独立增量, 得到两个独立泊松过程。□

注 13.17 (多类型标记). 若每个到达点独立赋予类型 j , 概率为 p_j , 其中 $p_j \geq 0$, $\sum_j p_j = 1$, 则各类型点过程相互独立, 强度分别为 λp_j 。

13.9 泊松过程的鞅

令 $\mathcal{F}_t = \sigma(N_s : 0 \leq s \leq t)$ 。

定理 13.18 (补偿泊松鞅). 过程

$$M_t = N_t - \lambda t \quad (13.23)$$

是平方可积鞅。

证明. 对 $s \leq t$, $N_t = N_s + (N_t - N_s)$, 且增量 $N_t - N_s$ 与 $\mathcal{F}_s$ 独立, 均值为 $\lambda(t-s)$ 。故

$$\begin{aligned} \mathbb{E}[M_t | \mathcal{F}_s] &= N_s + \lambda(t-s) - \lambda t \\ &= N_s - \lambda s \\ &= M_s. \end{aligned}$$

□

命题 13.19 (平方补偿). 过程

$$M_t^2 - \lambda t = (N_t - \lambda t)^2 - \lambda t \quad (13.24)$$

是鞅。

证明. 对 $s < t$, 令 $\Delta = N_t - N_s - \lambda(t-s)$ 。则 $M_t = M_s + \Delta$, 且 $\mathbb{E}[\Delta | \mathcal{F}_s] = 0$, $\mathbb{E}[\Delta^2 | \mathcal{F}_s] = \lambda(t-s)$ 。所以 $\mathbb{E}[M_t^2 | \mathcal{F}_s] = M_s^2 + \lambda(t-s)$ 。□

定理 13.20 (泊松指数鞅). 对任意 $\theta \in \mathbb{R}$,

$$L_t(\theta) = \exp \left\{ \theta N_t - \lambda t(e^\theta - 1) \right\} \quad (13.25)$$

是非负鞅。

证明. 对 $s \leq t$,

$$\begin{aligned} \mathbb{E}[L_t(\theta) | \mathcal{F}_s] &= L_s(\theta) \mathbb{E} \left[\exp \left\{ \theta(N_t - N_s) - \lambda(t-s)(e^\theta - 1) \right\} \right] \\ &= L_s(\theta), \end{aligned}$$

因为 $\mathbb{E}e^{\theta(N_t - N_s)} = \exp\{\lambda(t-s)(e^\theta - 1)\}$ 。□

推论 13.21 (泊松过程大数定律).

$$\frac{N_t}{t} \xrightarrow{\text{a.s.}} \lambda. \quad (13.26)$$

证明思路

由间隔时间的强大数律, $\frac{T_n}{n} = \frac{1}{n} \sum_{j=1}^n S_j \xrightarrow{\text{a.s.}} \frac{1}{\lambda}$ 。再使用 $T_{N_t} \leq t < T_{N_t+1}$ 进行反演。

13.10 泊松过程易错点

陈述	判断	正确说明
N_t 的样本路径连续	错	样本路径右连续、分段常数，并在到达时刻跳跃。
N_t 的增量相互独立	表述不完整	只有不交时间区间上的增量相互独立。
N_s 与 N_t 独立, $s < t$	错	N_s 是 N_t 的一部分，协方差为 λs 。
给定 $N_t = n$ 后，两个不交区间计数仍独立	错	给定总和后服从多项分布，通常负相关。
第 n 次到达时间服从指数分布	错	T_n 服从 Gamma 分布；只有间隔 S_n 服从指数分布。
两个泊松过程之和总是泊松过程	错	需要两个过程相互独立。
稀疏化后的两个计数仅边缘为泊松	不完整	独立标记还推出两个子过程相互独立。
小区间内至少一次到达概率为 λh	渐近正确	精确值为 $1 - e^{-\lambda h}$ ；只有当 $h \downarrow 0$ 时等于 $\lambda h + o(h)$ 。

泊松过程题

- (1) 判断题目给的是：
 - 计数 N_t ；
 - 间隔时间 S_n ；
 - 到达时间 T_n ；
 - 条件于 $N_t = n$ 的到达位置；
- (2) 使用互换关系 $\{T_n \leq t\} = \{N_t \geq n\}$ ；
- (3) 对不交区间使用独立增量；
- (4) 给定总计数后改用二项或多项分布；
- (5) 多个独立流合并时强度相加；
- (6) 独立分类时使用稀疏化；
- (7) 若题目涉及期望或停止，尝试 $N_t - \lambda t$ 或泊松指数鞅。

13.11 连续时间马尔可夫链的定义

定义 13.22 (连续时间马尔可夫链). 设 S 为有限或可数状态空间。右连续过程 $\{X_t\}_{t \geq 0}$ 称为齐次连续时间马尔可夫链，若对 $0 \leq t_0 < \dots < t_n < t_{n+1}$ 及状态 $x_0, \dots, x_{n+1}$,

$$\begin{aligned} \mathbb{P}(X_{t_{n+1}} = x_{n+1} \mid X_{t_0} = x_0, \dots, X_{t_n} = x_n) \\ = \mathbb{P}(X_{t_{n+1}} = x_{n+1} \mid X_{t_n} = x_n), \end{aligned}$$

并且右侧只依赖于 $t_{n+1} - t_n$ 。

在离散状态空间中，样本路径右连续意味着：对每个 t ，存在随机 $\varepsilon > 0$ ，使 $X_{t+s} = X_t$, $0 \leq s < \varepsilon$ 。



定义 13.23 (转移半群). 定义

$$P_t(x, y) = \mathbb{P}_x(X_t = y). \quad (13.27)$$

矩阵族 $\{P_t\}_{t \geq 0}$ 称为转移半群。

定理 13.24 (半群性质). $P_0 = I$, $P_{t+s} = P_t P_s$. 即

$$P_{t+s}(x, y) = \sum_{z \in S} P_t(x, z) P_s(z, y). \quad (13.28)$$

证明. 按时刻 t 的状态分解, 并使用 Markov 性:

$$\begin{aligned} P_{t+s}(x, y) &= \sum_z \mathbb{P}_x(X_t = z) \mathbb{P}_x(X_{t+s} = y \mid X_t = z) \\ &= \sum_z P_t(x, z) P_s(z, y). \end{aligned}$$

□

13.12 停留时间、跳时刻与嵌入跳链

定义 $J_0 = 0$, $J_{n+1} = \inf\{t > J_n : X_t \neq X_{J_n}\}$, 并令 $Y_n = X_{J_n}$ 为嵌入跳链, 令 $H_{n+1} = J_{n+1} - J_n$ 为第 $n+1$ 个停留时间。

定义 13.25 (爆炸). 若 $J_n \uparrow \zeta < \infty$, 则称在时间 ζ 发生爆炸, 即有限时间内发生无穷多次跳跃。

本文除特别说明外, 均假设 $\zeta = \infty$ a.s.

定理 13.26 (停留时间为指数分布). 从状态 x 出发, 首个离开时间 $J_1 = \inf\{t > 0 : X_t \neq x\}$ 具有无记忆性, 因此存在 $q_x \in [0, \infty)$ 使

$$\mathbb{P}_x(J_1 > t) = e^{-q_x t}. \quad (13.29)$$

若 $q_x = 0$, 则 x 为吸收状态。

证明. 对 $s, t \geq 0$,

$$\begin{aligned} \mathbb{P}_x(J_1 > s+t \mid J_1 > s) &= \mathbb{P}_x(X_u = x, 0 \leq u \leq s+t \mid X_u = x, 0 \leq u \leq s) \\ &= \mathbb{P}_x(X_{s+u} = x, 0 \leq u \leq t \mid X_s = x) \\ &= \mathbb{P}_x(J_1 > t), \end{aligned}$$

其中最后一步使用时间齐次 Markov 性。由 定理 13.6 得结论。

□

13.13 生成元与小时间转移率

定义 13.27 (生成元). 对 $y \neq x$, 定义

$$q_{xy} = \lim_{h \downarrow 0} \frac{P_h(x, y)}{h}, \quad (13.30)$$



并定义

$$q_{xx} = \lim_{h \downarrow 0} \frac{P_h(x, x) - 1}{h} = -q_x. \quad (13.31)$$

矩阵 $Q = (q_{xy})_{x, y \in S}$ 称为无穷小生成元。

生成元满足 $q_{xy} \geq 0$, $y \neq x$, $q_{xx} \leq 0$, 并在保守情形下满足

$$q_x = -q_{xx} = \sum_{y \neq x} q_{xy}. \quad (13.32)$$

相应小时间展开为

$$P_h(x, x) = 1 - q_x h + o(h), \quad (13.33)$$

$$P_h(x, y) = q_{xy} h + o(h), \quad y \neq x. \quad (13.34)$$

定理 13.28 (首跳时间与首跳位置). 若 $q_x > 0$, 则:

(1) $J_1 \sim \text{Exp}(q_x)$;

(2)

$$\mathbb{P}_x(Y_1 = y) = \frac{q_{xy}}{q_x}, \quad y \neq x; \quad (13.35)$$

(3) J_1 与 Y_1 独立;

(4) 联合分布可写成

$$\mathbb{P}_x(J_1 \in dt, Y_1 = y) = e^{-q_x t} q_{xy} dt. \quad (13.36)$$

证明思路

由生成元定义, $\mathbb{P}_x(Y_1 = y \mid J_1 \leq h) = \frac{P_h(x, y) + o(h)}{1 - P_h(x, x)} \rightarrow \frac{q_{xy}}{q_x}$. Markov 性和指数停留时间的无记忆性说明, 等待多久与最终跳向何处相互独立。

考试时需要注意的地方

q_x 是离开状态 x 的总速率, 而不是下一状态的概率。下一状态概率是 $\frac{q_{xy}}{q_x}$ 。速率可以大于 1, 概率不能。

13.14 由生成元构造连续时间链

设 Q 满足 $q_{xy} \geq 0$, $y \neq x$, $q_x := -q_{xx} < \infty$, $\sum_y q_{xy} = 0$ 。

定义跳链转移矩阵

$$R(x, y) = \begin{cases} \frac{q_{xy}}{q_x}, & y \neq x, q_x > 0, \\ 0, & y = x, q_x > 0, \\ \mathbf{1}_{\{x=y\}}, & q_x = 0. \end{cases} \quad (13.37)$$

令 $\{Y_n\}$ 为转移矩阵 R 的离散时间马尔可夫链。给定 $Y_n = x$, 令 $H_{n+1} \sim \text{Exp}(q_x)$, 且在给定跳链后各停留时间条件独立。设置 $J_n = H_1 + \cdots + H_n$, 并令 $X_t = Y_n$, $J_n \leq t < J_{n+1}$ 。若 $J_n \uparrow \infty$ a.s., 则所得过程是生成元为 Q 的连续时间马尔可夫链。

命题 13.29 (非爆炸的常用充分条件). 若

$$\sup_{x \in S} q_x < \infty, \quad (13.38)$$

则链非爆炸。特别地, 有限状态空间上的有限速率链必非爆炸。

证明思路

设 $\Lambda \geq \sup_x q_x$ 。可在强度 Λ 的泊松时钟到达时尝试跳转, 每次以概率 q_x/Λ 做真实跳跃, 否则保留原状态。因此有限时间内真实跳跃次数不超过一个有限参数的泊松随机变量。

前提条件检查

对可数状态空间, 给出一个形式上合法的 Q 矩阵不自动保证非爆炸。若 q_x 随状态快速增大, 可能在有限时间内经过无穷多个状态。

13.15 首跳分解与 Kolmogorov 方程

定理 13.30 (首跳分解). 对 $q_x > 0$,

$$P_t(x, y) = e^{-q_x t} \mathbf{1}_{\{x=y\}} + \sum_{z \neq x} \int_0^t e^{-q_x s} q_{xz} P_{t-s}(z, y) ds. \quad (13.39)$$

证明. 第一项对应于在整个 $[0, t]$ 中不离开 x 。若第一次跳跃发生于 $s \in ds$ 且跳到 z , 其概率为 $e^{-q_x s} q_{xz} ds$ 。由强 Markov 性, 跳跃之后在剩余时间 $t-s$ 内由 z 到达 y 的概率为 $P_{t-s}(z, y)$ 。对 s, z 积分求和。□

定理 13.31 (Kolmogorov 向后方程). 在相应可微与非爆炸条件下,

$$\frac{d}{dt} P_t = Q P_t, \quad P_0 = I. \quad (13.40)$$

逐项写为

$$\frac{d}{dt} P_t(x, y) = \sum_z q_{xz} P_t(z, y). \quad (13.41)$$

定理 13.32 (Kolmogorov 向前方程). 在有限状态空间或适当可交换极限与求和的条件下,

$$\frac{d}{dt} P_t = P_t Q, \quad P_0 = I. \quad (13.42)$$

逐项写为

$$\frac{d}{dt} P_t(x, y) = \sum_z P_t(x, z) q_{zy}. \quad (13.43)$$



概念比较

方程	矩阵形式	概率解释
向后方程	$P_t' = Q P_t$	按初始状态 x 的第一次跳跃分解
向前方程	$P_t' = P_t Q$	按终点 y 前的最后一次跳跃或小时间终段分解

13.16 有限状态空间：矩阵指数与均匀化

定理 13.33 (矩阵指数表示). 若 S 有限, 则

$$P_t = e^{tQ} := \sum_{n=0}^{\infty} \frac{t^n Q^n}{n!} \quad (13.44)$$

是向前和向后方程的唯一解。

证明. 矩阵级数绝对收敛, 可逐项微分: $\frac{d}{dt} e^{tQ} = Q e^{tQ} = e^{tQ} Q$. 若 $\tilde{P}_t$ 是另一解, 则 $\frac{d}{dt} (\tilde{P}_t e^{-tQ}) = 0$, 结合 $\tilde{P}_0 = I$ 得 $\tilde{P}_t = e^{tQ}$. $\square$

定理 13.34 (均匀化公式). 设 S 有限, 取 $\Lambda \geq \max_x q_x$, 并定义随机矩阵

$$R = I + \frac{Q}{\Lambda}. \quad (13.45)$$

则

$$P_t = e^{-\Lambda t} \sum_{n=0}^{\infty} \frac{(\Lambda t)^n}{n!} R^n. \quad (13.46)$$

证明. 因为 $Q = \Lambda(R - I)$, 且 R 与 I 交换, $e^{tQ} = e^{\Lambda t(R-I)} = e^{-\Lambda t} e^{\Lambda t R}$. 展开第二个矩阵指数即可. $\square$

注 13.35. 均匀化的概率解释为:

- (1) 使用强度 Λ 的泊松时钟;
- (2) 每次时钟响起时, 按转移矩阵 R 更新状态;
- (3) $R(x, x) > 0$ 对应虚拟跳跃。


13.17 平稳分布、详细平衡与正再生

定义 13.36 (连续时间平稳分布). 概率分布 π 称为连续时间链的平稳分布, 若

$$\pi P_t = \pi \text{ 对所有 } t \geq 0. \quad (13.47)$$

定理 13.37 (生成元判据). 在有限状态空间中,

$$\pi P_t = \pi \text{ 对所有 } t \iff \pi Q = 0. \quad (13.48)$$



证明. 若 $\pi P_t = \pi$, 在 $t = 0$ 右微分得到 $\pi Q = 0$. 反之, 若 $\pi Q = 0$, 则 $\frac{d}{dt}(\pi P_t) = \pi Q P_t = 0$. 结合 $\pi P_0 = \pi$ 即得结论. $\square$

定义 13.38 (连续时间详细平衡). 若

$$\pi(x)q_{xy} = \pi(y)q_{yx}, \quad x \neq y, \quad (13.49)$$

则称 π 满足详细平衡.

详细平衡推出 $\pi Q = 0$. 事实上,

$$\begin{aligned} (\pi Q)(y) &= \sum_{x \neq y} \pi(x)q_{xy} - \pi(y)q_y \\ &= \pi(y) \sum_{x \neq y} q_{yx} - \pi(y)q_y \\ &= 0. \end{aligned}$$

命题 13.39 (与跳链平稳测度的关系). 设 $q_x > 0$, 跳链转移矩阵为 $R(x, y) = \frac{q_{xy}}{q_x}$, $y \neq x$. 若 $\pi Q = 0$, 则

$$\mu(x) = \pi(x)q_x \quad (13.50)$$

是跳链的不变测度: $\mu R = \mu$. 反之, 若 $\mu R = \mu$ 且 $\sum_x \frac{\mu(x)}{q_x} < \infty$, 则 $\pi(x) = \frac{\mu(x)/q_x}{\sum_z \mu(z)/q_z}$ 是连续时间链的平稳分布.

定理 13.40 (连续时间 Kac 公式). 设链不可约、正常返, 平稳分布为 π . 令 $T_x^+ = \inf\{t \geq J_1 : X_t = x\}$ 为离开 x 后的首次返回时间. 则

$$\pi(x) = \frac{1}{q_x \mathbb{E}_x T_x^+}. \quad (13.51)$$

证明思路

一个从 x 到再次返回 x 的再生循环中:

- 循环总平均长度为 $\mathbb{E}_x T_x^+$;
- 在 x 的平均停留时间为 $1/q_x$.

由更新报酬定理, 长期处于 x 的比例为二者之比.

定理 13.41 (连续时间遍历与收敛). 设连续时间链不可约并存在平稳分布 π . 则对有界 f ,

$$\frac{1}{t} \int_0^t f(X_s) ds \xrightarrow{\text{a.s.}} \sum_x \pi(x) f(x). \quad (13.52)$$

在标准非爆炸正再生条件下,

$$P_t(x, y) \longrightarrow \pi(y), \quad t \rightarrow \infty. \quad (13.53)$$

注 13.42. 连续时间中通常不需要另加离散时间意义下的非周期性. 对任意 $h > 0$, $P_h(x, x) \geq e^{-q_x h} > 0$, 故取固定时间间隔 h 得到的骨架链具有自环.

13.18 例题: $M/M/1$ 排队

设顾客按强度 λ 的泊松过程到达, 服务时间独立且服从率参数 μ 的指数分布。令 X_t 为系统中人数。

生成元为 $q_{0,1} = \lambda$, $q_{0,0} = -\lambda$, 以及对 $n \geq 1$, $q_{n,n+1} = \lambda$, $q_{n,n-1} = \mu$, $q_{n,n} = -(\lambda + \mu)$ 。

令 $\rho = \frac{\lambda}{\mu}$ 。详细平衡方程为 $\pi(n)\lambda = \pi(n+1)\mu$, 故 $\pi(n+1) = \rho\pi(n)$ 。因此未归一化平稳测度为 $\tilde{\pi}(n) = \rho^n$ 。

命题 13.43 ($M/M/1$ 分类).
$$\begin{cases} \rho < 1: & \text{正常返, 且 } \pi(n) = (1 - \rho)\rho^n; \\ \rho = 1: & \text{零常返, 无平稳概率分布;} \\ \rho > 1: & \text{暂留, 无平稳概率分布.} \end{cases}$$

考试时需要注意的地方

“存在形式解 $\pi Q = 0$ ”并不保证存在平稳概率分布。还必须验证: $\pi(n) \geq 0$, $\sum_n \pi(n) = 1$ 。当 $\rho \geq 1$ 时, 几何级数不能归一化。

一些需要记忆的内容

- (1) 泊松过程的三种核心描述是什么?
- (2) T_n 与 N_t 之间的事件互换关系是什么?
- (3) 给定 $N_t = n$ 后, N_s 服从什么分布?
- (4) 独立泊松过程叠加后强度如何变化?
- (5) 稀疏化为什么还会产生相互独立的子过程?
- (6) 连续时间生成元 q_{xy} 是概率还是速率?
- (7) q_x 与平均停留时间有什么关系?
- (8) 有限状态连续时间链的半群为何等于 e^{tQ} ?
- (9) 平稳分布应满足 $\pi Q = 0$ 还是 $Q\pi = 0$?
- (10) 连续时间不可约链为什么通常没有周期障碍?



第十四章 高斯过程、白噪声与布朗桥

14.1 考纲定位与历年扩展

重点

高斯过程基础：B 级。

【必须会完整证明】：高斯过程由均值和协方差确定有限维分布；联合高斯情形下零协方差推出独立。

【必须会熟练应用】：条件高斯、正交投影、Brownian bridge 的均值与协方差。

Brownian bridge 与一维 Gaussian free field：C 级实考扩展。

该主题未在简要考纲中单独列出，但曾在 [24F-Q6, 15 分] 中实际考查。必须掌握该题所需的协方差计算与 Green 函数求解，不需要扩展到高维 GFF 的完整理论。

14.2 高斯向量与高斯过程

定义 14.1 (高斯向量). 随机向量 $X = (X_1, \dots, X_d)^\top$ 称为高斯向量，若对任意 $a = (a_1, \dots, a_d)^\top \in \mathbb{R}^d$ ，线性组合 $a^\top X$ 为一维高斯随机变量，允许退化为常数。

若 $m = \mathbb{E}X$, $\Sigma = \text{Cov}(X)$ ，则特征函数为

$$\mathbb{E}e^{it^\top X} = \exp \left\{ it^\top m - \frac{1}{2} t^\top \Sigma t \right\}. \quad (14.1)$$

因此高斯向量的分布由 (m, Σ) 唯一确定。

定义 14.2 (高斯过程). 指标集 T 上的实随机过程 $\{X_t : t \in T\}$ 称为高斯过程，若任取 $t_1, \dots, t_n \in T$ 及 $a_1, \dots, a_n \in \mathbb{R}$ ，都有 $\sum_{j=1}^n a_j X_{t_j}$ 为高斯随机变量。等价地，每个有限维向量 $(X_{t_1}, \dots, X_{t_n})$ 均为高斯向量。

定义均值函数

$$m(t) = \mathbb{E}X_t \quad (14.2)$$

与协方差核


$$K(s, t) = \text{Cov}(X_s, X_t). \quad (14.3)$$

定理 14.3 (均值和协方差决定高斯过程的有限维分布). 若两个高斯过程 X, Y 满足 $\mathbb{E}X_t = \mathbb{E}Y_t$ ，以及 $\text{Cov}(X_s, X_t) = \text{Cov}(Y_s, Y_t)$ 对所有 $s, t \in T$ 成立，则 $(X_{t_1}, \dots, X_{t_n}) \stackrel{d}{=} (Y_{t_1}, \dots, Y_{t_n})$ 对任意有限指标集成立。

证明. 两边均为高斯向量，且具有相同均值向量和协方差矩阵。由高斯向量特征函数公式 (14.1)，其分布相同。 $\square$

定义 14.4 (正半定核). 函数 $K : T \times T \rightarrow \mathbb{R}$ 称为正半定核，若：

- (1) $K(s, t) = K(t, s)$;



(2) 对任意 $n, t_1, \dots, t_n$ 和 $a_1, \dots, a_n \in \mathbb{R}$,

$$\sum_{j,k=1}^n a_j a_k K(t_j, t_k) \geq 0. \quad (14.4)$$

任何协方差核均为正半定核, 因为 $\sum_{j,k} a_j a_k K(t_j, t_k) = \text{Var}\left(\sum_j a_j X_{t_j}\right) \geq 0$ 。

定理 14.5 (高斯过程存在性). 给定函数 $m: T \rightarrow \mathbb{R}$ 和正半定核 $K: T \times T \rightarrow \mathbb{R}$, 存在一个高斯过程, 其均值函数为 m 、协方差核为 K 。

证明思路

对任意有限指标集 $t_1, \dots, t_n$, 定义均值向量 $(m(t_1), \dots, m(t_n))$ 和协方差矩阵 $(K(t_j, t_k))_{j,k}$ 。正半定性保证相应高斯向量存在。这些有限维分布满足边缘一致性和排列一致性, 故由 Kolmogorov 扩张定理构造过程。

前提条件检查

存在性定理只构造给定有限维分布的过程, 不自动保证样本路径连续、可测或有界。路径正则性需要额外的增量矩条件, 例如 Kolmogorov 连续性定理。

14.3 联合高斯中的正交性与独立性

定理 14.6 (联合高斯: 不相关等价于独立). 设 (X, Y) 为联合高斯向量。则 $X \perp\!\!\!\perp Y$ 当且仅当 $\text{Cov}(X_i, Y_j) = 0$ 对所有坐标 i, j 成立。

证明. 独立推出零协方差是一般结论。

反之, 若交叉协方差块为零, 则联合协方差矩阵为分块对角形: $\Sigma = \begin{pmatrix} \Sigma_{XX} & 0 \\ 0 & \Sigma_{YY} \end{pmatrix}$ 。联合特征函数分解:

$$\begin{aligned} \varphi_{X,Y}(u, v) &= \exp \left\{ iu^\top m_X + iv^\top m_Y - \frac{1}{2}u^\top \Sigma_{XX}u - \frac{1}{2}v^\top \Sigma_{YY}v \right\} \\ &= \varphi_X(u)\varphi_Y(v). \end{aligned}$$

□

边缘均为高斯且不相关, 仍未必独立

设 $Z \sim \mathcal{N}(0, 1)$, 令 ε 与 Z 独立, 且 $\mathbb{P}(\varepsilon = 1) = \mathbb{P}(\varepsilon = -1) = \frac{1}{2}$ 。定义 $X = Z$, $Y = \varepsilon Z$ 。则 X, Y 均为标准正态, 且 $\mathbb{E}[XY] = \mathbb{E}[\varepsilon Z^2] = 0$ 。但 $|X| = |Y|$ a.s., 故不独立。

失败原因是 (X, Y) 不是联合高斯向量。

14.4 高斯条件期望是正交投影

设 H 为由一族中心高斯变量生成的闭线性子空间，内积为 $\langle X, Y \rangle_{L^2} = \mathbb{E}[XY]$ 。设 $K \subseteq H$ 为闭线性子空间， $\Pi_K X$ 表示 X 在 K 上的正交投影。

定理 14.7 (高斯投影公式). 对 $X \in H$,

$$\mathbb{E}[X \mid \sigma(K)] = \Pi_K X. \quad (14.5)$$

并且残差 $X - \Pi_K X$ 与 $\sigma(K)$ 独立。

证明. 残差与 K 中每个元素正交。由于所有变量属于同一高斯空间，零协方差推出残差与 $\sigma(K)$ 独立。故 $\mathbb{E}[X - \Pi_K X \mid \sigma(K)] = \mathbb{E}[X - \Pi_K X] = 0$. $\square$

有限维版本即熟知的条件高斯公式。若 $\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \right)$, 且 Σ_{YY} 可逆, 则 $X \mid Y \sim \mathcal{N}(\mu_X + \Sigma_{XY}\Sigma_{YY}^{-1}(Y - \mu_Y), \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX})$ 。

14.5 高斯白噪声

定义 14.8 (高斯白噪声). 设 $(E, \mathcal{E}, \mu)$ 为 σ -有限测度空间。高斯白噪声是从 $L^2(E, \mathcal{E}, \mu)$ 到某个中心高斯空间的线性等距映射 $W : f \mapsto W(f)$, 满足

$$\mathbb{E}[W(f)W(g)] = \int_E f(x)g(x)\mu(dx). \quad (14.6)$$

特别地, $W(f) \sim \mathcal{N}(0, \|f\|_{L^2(\mu)}^2)$ 。

若 $A, B \in \mathcal{E}$ 且 $\mu(A), \mu(B) < \infty$, 记 $W(A) = W(\mathbf{1}_A)$ 。则 $\text{Cov}(W(A), W(B)) = \mu(A \cap B)$ 。若 $A \cap B = \emptyset$, 则 $W(A) \perp W(B)$, 因为它们联合高斯且协方差为零。

注 14.9. 白噪声不是通常意义下逐点定义的函数 $t \mapsto W_t$ 。它首先是作用于测试函数或 L^2 函数的随机线性泛函。

14.6 Brownian bridge

定义 14.10 (Brownian bridge). 设 $\{B_t : 0 \leq t \leq 1\}$ 为标准 Brownian motion。定义

$$W_t = B_t - tB_1, \quad 0 \leq t \leq 1. \quad (14.7)$$

则称 $\{W_t\}$ 为标准 Brownian bridge。

显然 $W_0 = W_1 = 0$ 。

命题 14.11 (Brownian bridge 的协方差). $\{W_t\}$ 是中心高斯过程, 且

$$\text{Cov}(W_s, W_t) = s \wedge t - st. \quad (14.8)$$



证明. W 是 B 的线性变换, 故为高斯过程。又

$$\begin{aligned}\mathbb{E}[W_s W_t] &= \mathbb{E}[(B_s - sB_1)(B_t - tB_1)] \\ &= s \wedge t - t\mathbb{E}[B_s B_1] - s\mathbb{E}[B_t B_1] + st\mathbb{E}[B_1^2] \\ &= s \wedge t - st - st + st \\ &= s \wedge t - st.\end{aligned}$$

□

命题 14.12 (条件分布解释). 对任意 $0 \leq t_1 < \cdots < t_n \leq 1$, 向量 $(W_{t_1}, \dots, W_{t_n})$ 的分布等于 $(B_{t_1}, \dots, B_{t_n})$ 给定 $B_1 = 0$ 的正则条件分布。

证明. 对任意 t , $\text{Cov}(W_t, B_1) = \text{Cov}(B_t - tB_1, B_1) = t - t = 0$ 。因此向量 $(W_{t_1}, \dots, W_{t_n})$ 与 B_1 联合高斯且交叉协方差为零, 故相互独立。

又 $B_{t_j} = W_{t_j} + t_j B_1$ 。给定 $B_1 = 0$ 后, 右侧等于 W_{t_j} 。

□

考试时需要注意的地方

事件 $\{B_1 = 0\}$ 的概率为零。“给定 $B_1 = 0$ ”必须理解为正则条件高斯分布, 不能使用 $\frac{\mathbb{P}(A \cap \{B_1 = 0\})}{\mathbb{P}(B_1 = 0)}$ 。

14.7 一维零边界 Gaussian free field

定义 14.13 (一维零边界 GFF). 在区间 $[0, 1]$ 上, 一维零边界 Gaussian free field 是中心高斯过程 $\{h_t : 0 \leq t \leq 1\}$ 满足 $h_0 = h_1 = 0$ 且协方差为 Dirichlet Laplace 算子 $-\frac{d^2}{dt^2}$ 的 Green 函数: $\mathbb{E}[h_t h_s] = G(t, s)$ 。

固定 $s \in (0, 1)$, $G(\cdot, s)$ 应满足: $-G''(t, s) = \delta_s$ 的分布意义等式, 以及 $G(0, s) = G(1, s) = 0$ 。

命题 14.14 (一维 Dirichlet Green 函数).

$$G(t, s) = (t \wedge s) - ts = \begin{cases} t(1-s), & 0 \leq t \leq s, \\ s(1-t), & s \leq t \leq 1. \end{cases} \quad (14.9)$$

证明. 在 $t \neq s$ 时, Green 函数应满足 $G''(t, s) = 0$, 所以在 $(0, s)$ 与 $(s, 1)$ 上分别为仿射函数。边界条件给出形式 $G(t, s) = \begin{cases} A_s t, & t \leq s, \\ B_s(1-t), & t \geq s. \end{cases}$ 连续性要求 $A_s s = B_s(1-s)$ 。分布导数条件 $-G''(\cdot, s) = \delta_s$ 等价于一阶导数跳跃 $G'_t(s+, s) - G'_t(s-, s) = -1$ 。即 $-B_s - A_s = -1$ 。联立得到 $A_s = 1-s$, $B_s = s$ 。

严格验证: 对任意 $\phi \in C_c^\infty(0, 1)$, 分段积分两次得 $\int_0^1 G(t, s) \phi''(t) dt = -\phi(s)$ 。

□

14.8 真题完整解法: Brownian bridge 等于一维 GFF

往年真题

2024 Fall 第 6 题第 (b) 问, 15 分题的一部分。

证明标准 Brownian bridge $W_t = (B_t \mid B_1 = 0)$ 与 $[0, 1]$ 上零边界一维 Gaussian free field 具有相同有限维分布。

解: 由 Brownian bridge 的线性表示, $W_t = B_t - tB_1$ 。它是中心高斯过程, 且由 定理 14.11, $\mathbb{E}[W_t W_s] = t \wedge s - ts$ 。

另一方面, 一维零边界 GFF 是中心高斯过程, 协方差为 $-\Delta$ 的 Dirichlet Green 函数。由 定理 14.14, $G(t, s) = t \wedge s - ts$ 。所以 $\mathbb{E}[h_t h_s] = t \wedge s - ts = \mathbb{E}[W_t W_s]$ 。

任取 $0 \leq t_1 < \cdots < t_n \leq 1$ 。向量 $(W_{t_1}, \dots, W_{t_n})$ 和 $(h_{t_1}, \dots, h_{t_n})$ 均为均值为零的高斯向量, 且具有同一协方差矩阵 $(t_i \wedge t_j - t_i t_j)_{1 \leq i, j \leq n}$ 。因此二者特征函数相同, 从而 $(W_{t_1}, \dots, W_{t_n}) \stackrel{d}{=} (h_{t_1}, \dots, h_{t_n})$ 。故两个过程具有相同有限维分布。 $\square$

考试时需要注意的地方

该题必须出现以下四步:

- (1) 写出 $W_t = B_t - tB_1$;
- (2) 计算 $\text{Cov}(W_s, W_t) = s \wedge t - st$;
- (3) 解出 Green 函数 $G(t, s) = s \wedge t - st$;
- (4) 使用“中心高斯过程由协方差决定有限维分布”。

只写“协方差相同, 所以过程相同”而不说明双方均为高斯过程, 论证不完整。

一些需要记忆的内容

- (1) 什么条件保证一个核可以作为高斯过程协方差?
- (2) 两个高斯过程何时具有相同有限维分布?
- (3) “每个坐标边缘均为高斯”是否足以推出联合高斯?
- (4) Brownian bridge 的协方差是什么?
- (5) 为什么 W_t 与 B_1 独立?
- (6) $[0, 1]$ 上 $-\Delta$ 的零边界 Green 函数是什么?



第十五章 布朗运动

15.1 考纲定位与历年考法

重点

S 级

【必须会完整证明】: Brownian motion 的定义与协方差、缩放不变性、Markov 性、反射原理、首达时分布和 Laplace 变换、对称区间退出时间与退出方向独立。

【必须会复现证明框架】: Kolmogorov 连续性定理、强 Markov 性、路径无限变差和处处不可微。

【必须会熟练应用】: 指数鞅、平方补偿鞅、首达时停止、吸收边界反射、Brownian bridge、指数泛函的 Laplace 原理。

往年真题

五套真题中, Brownian motion 连续出现:

- [24S-Q6, 10 分]: 首达时是停时, 计算 Laplace 变换;
- [24F-Q6, 15 分]: 吸收于零前的条件分布, 以及 Brownian bridge/GFF;
- [25S-Q5, 10 分]: 对称区间退出时间有限, 且退出时间与退出方向独立;
- [25F-Q5, 10 分]: 指数鞅的极限和时间积分;
- [26S-Q4, 10 分]: Brownian 指数泛函的大时间分布极限。

因此 Brownian motion 是近五套试卷中最稳定的随机过程考点之一。

15.2 精确定义与等价结构

定义 15.1 (标准 Brownian motion). 实值过程 $B = \{B_t : t \geq 0\}$ 称为标准 Brownian motion, 若:

- (1) $B_0 = 0$ a.s.;
- (2) 对任意 $0 \leq t_0 < t_1 < \cdots < t_n$, 增量 $B_{t_1} - B_{t_0}, \dots, B_{t_n} - B_{t_{n-1}}$ 相互独立;
- (3) 对 $0 \leq s < t$,

$$B_t - B_s \sim N(0, t - s); \quad (15.1)$$

- (4) 样本路径 $t \mapsto B_t(\omega)$ 几乎处处连续。

定理 15.2 (高斯协方差刻画). 若 $B_0 = 0$, 则以下两组条件等价:

- (1) B 是 Brownian motion;
- (2) B 是具有连续样本路径的中心高斯过程, 且

$$\mathbb{E}[B_s B_t] = s \wedge t. \quad (15.2)$$

证明. 若 B 为 Brownian motion, 不妨设 $s \leq t$. 写成 $B_t = B_s + (B_t - B_s)$. 由独立增量和中心性, $\mathbb{E}[B_s B_t] =$



$$\mathbb{E}[B_s^2] = s.$$

反之, 设 B 是中心高斯过程, 协方差为 $s \wedge t$. 对 $s < t$, $\text{Var}(B_t - B_s) = t + s - 2s = t - s$. 若 $0 \leq t_0 < t_1 < \cdots < t_n$, 则不相交增量之间协方差为零. 例如 $i < j$ 时,

$$\text{Cov}(B_{t_i} - B_{t_{i-1}}, B_{t_j} - B_{t_{j-1}}) = t_i - t_i - t_{i-1} + t_{i-1} = 0.$$

所有增量联合高斯, 故零协方差推出相互独立. □

15.3 平稳增量、缩放与时间平移

命题 15.3 (时间平移与 Markov 性). 固定 $s \geq 0$, 定义

$$B_t^{(s)} = B_{s+t} - B_s. \quad (15.3)$$

则 $\{B_t^{(s)}\}_{t \geq 0}$ 是标准 *Brownian motion*, 并且独立于 $\mathcal{F}_s = \sigma(B_u : 0 \leq u \leq s)$.

证明. 过程 $B^{(s)}$ 的增量是原 *Brownian motion* 在 s 之后不交区间上的增量, 故具有独立性和相应正态分布; 路径连续性也保持. 它与 $\mathcal{F}_s$ 的独立性来自独立增量. □

命题 15.4 (缩放不变性). 对任意 $c > 0$,

$$\tilde{B}_t = \frac{1}{\sqrt{c}} B_{ct} \quad (15.4)$$

仍为标准 *Brownian motion*. 等价地,

$$\{B_{ct} : t \geq 0\} \stackrel{d}{=} \{\sqrt{c} B_t : t \geq 0\}. \quad (15.5)$$

证明. $\tilde{B}$ 为中心高斯过程, 且 $\mathbb{E}[\tilde{B}_s \tilde{B}_t] = \frac{1}{c}(cs \wedge ct) = s \wedge t$. 路径连续性显然. □

命题 15.5 (对称性). $\{-B_t : t \geq 0\}$ 仍为标准 *Brownian motion*.

15.4 连续修改与 Hölder 正则性

定理 15.6 (Kolmogorov 连续性定理). 设过程 $\{X_t : t \in [0, T]\}$ 取值于完备度量空间 (E, d) . 若存在 $p > 0$, $\alpha > 0$, $C < \infty$ 使

$$\mathbb{E}[d(X_s, X_t)^p] \leq C|t - s|^{1+\alpha}, \quad (15.6)$$

则 X 有一个修改, 其样本路径对每个 $0 < \gamma < \frac{\alpha}{p}$ 均局部 γ -Hölder 连续.

证明思路

在二进有理点网格上, 对相邻点增量使用 Markov 不等式: $\mathbb{P}(d(X_{(j+1)2^{-n}}, X_{j2^{-n}}) > 2^{-n\gamma}) \leq C2^{-n(1+\alpha-p\gamma)}$. 对 j 求和后得到 $C2^{-n(\alpha-p\gamma)}$. 当 $\gamma < \alpha/p$ 时, 该级数可求和. 由 Borel-Cantelli, 引理保证高层二进网格的相邻增量均受控. 再用链式二进逼近把控制扩展到全部二进点, 最后利用完备性连续延拓.

推论 15.7 (Brownian motion 的 Hölder 正则性). *Brownian motion* 存在连续修改, 并且其样本路径几乎处处在每个紧区间上对所有 $\gamma < \frac{1}{2}$ 均局部 γ -Hölder 连续。

证明. 对任意 $p > 0$, $B_t - B_s \stackrel{d}{=} \sqrt{|t-s|}Z$, $Z \sim N(0, 1)$, 故 $\mathbb{E}|B_t - B_s|^p = \mathbb{E}|Z|^p|t-s|^{p/2}$. 取 $p > 2$, 则 $1 + \alpha = \frac{p}{2}$, $\frac{\alpha}{p} = \frac{1}{2} - \frac{1}{p}$. 令 p 任意大. $\square$

前提条件检查

Brownian 路径对任意 $\gamma < 1/2$ 局部 Hölder, 但一般不具有 $1/2$ -Hölder 正则性。尺度 $\sqrt{|t-s|}$ 是临界振荡尺度。

15.5 二次变差、无限变差与处处不可微

15.5.1 二次变差

设 $\pi_n : 0 = t_{n,0} < t_{n,1} < \cdots < t_{n,k_n} = T$ 为分割, 并记网格 $|\pi_n| = \max_j(t_{n,j} - t_{n,j-1})$ 。

定理 15.8 (Brownian 二次变差). 若 $|\pi_n| \rightarrow 0$, 则

$$\sum_{j=1}^{k_n} (B_{t_{n,j}} - B_{t_{n,j-1}})^2 \xrightarrow{L^2} T. \quad (15.7)$$

对二进分割, 收敛还几乎处处成立。

证明. 令 $\Delta_j B = B_{t_{n,j}} - B_{t_{n,j-1}}$, $\Delta_j t = t_{n,j} - t_{n,j-1}$. 则 $\Delta_j B$ 独立, 且 $\Delta_j B \sim N(0, \Delta_j t)$. 因此 $\mathbb{E}[(\Delta_j B)^2] = \Delta_j t$, 并且正态四阶矩给出 $\text{Var}((\Delta_j B)^2) = 2(\Delta_j t)^2$. 故 $\mathbb{E} \sum_j (\Delta_j B)^2 = T$, 以及

$$\begin{aligned} \text{Var} \left(\sum_j (\Delta_j B)^2 \right) &= 2 \sum_j (\Delta_j t)^2 \\ &\leq 2|\pi_n| \sum_j \Delta_j t \\ &= 2T|\pi_n| \rightarrow 0. \end{aligned}$$

二进分割时方差为 $O(2^{-n})$, 由 Chebyshev 和 Borel-Cantelli 得 a.s. 收敛. $\square$

15.5.2 无限总变差

定理 15.9 (Brownian 路径无限变差). 几乎处处地, *Brownian* 路径在每个非退化区间上具有无限总变差。

证明. 只需考虑 $[0, T]$. 取二进分割, 并记 $V_n = \sum_j |\Delta_j B|$, $Q_n = \sum_j (\Delta_j B)^2$. 有 $Q_n \leq (\max_j |\Delta_j B|) V_n$. 由路径连续性和分割网格趋于零, $\max_j |\Delta_j B| \xrightarrow{\text{a.s.}} 0$. 另一方面, 由定理 15.8, 沿二进分割 $Q_n \xrightarrow{\text{a.s.}} T > 0$. 因此 $V_n \rightarrow \infty$. 总变差是所有分割变差和的上确界, 所以总变差为无穷. $\square$

15.5.3 处处不可微

定理 15.10 (Brownian 路径处处不可微). 几乎处处地, 函数 $t \mapsto B_t$ 在每个 $t \geq 0$ 都不存在有限导数。

二进增量法

只说明 $[0, 1]$ 。

固定整数 $M \geq 1$ 。若路径在某点 t 可微且导数绝对值不超过 M , 则存在 $\delta > 0$, 使对 $|u - t| < \delta$, $|B_u - B_t| \leq 2M|u - t|$ 。取足够细的二进网格, 使包含 t 的网格单元及其左右相邻单元均落在 $(t - \delta, t + \delta)$ 内。相邻三至四个二进增量于是均满足 $|\Delta B| \leq C_M 2^{-n}$ 。

但单个长度 2^{-n} 的 Brownian 增量满足 $\Delta B \stackrel{d}{=} 2^{-n/2} Z$, 所以 $\mathbb{P}(|\Delta B| \leq C_M 2^{-n}) = \mathbb{P}(|Z| \leq C_M 2^{-n/2}) \leq C'_M 2^{-n/2}$ 。三个不交相邻增量独立, 故同时很小的概率至多为 $C''_M 2^{-3n/2}$ 。可能的相邻三元组仅有 $O(2^n)$ 个, 因此 $\mathbb{P}(\text{第 } n \text{ 层存在三个连续小增量}) \leq C'''_M 2^{-n/2}$ 。右侧对 n 可求和。由 Borel–Cantelli, 几乎处处仅有限多个 n 会发生该事件。

若某点存在有限导数, 则对某个整数 M , 上述连续小增量事件会在所有充分大 n 发生, 矛盾。最后对 $M \in \mathbb{N}$ 取可数并。

概念比较

Brownian 路径同时满足: 连续 + 任意 $\gamma < 1/2$ 局部 Hölder + 无限变差 + 处处不可微. 这些结论并不矛盾。

15.6 Brownian motion 的基本鞅

令 $\mathcal{F}_t = \sigma(B_s : 0 \leq s \leq t)$ 。

命题 15.11. 以下过程均为鞅:

- (1) B_t ;
- (2) $B_t^2 - t$;
- (3) 对任意 $\theta \in \mathbb{R}$, $\mathcal{E}_t(\theta) = \exp\{\theta B_t - \frac{1}{2}\theta^2 t\}$ 。

证明. 对 $s < t$, 写 $B_t = B_s + (B_t - B_s)$, 其中增量独立于 $\mathcal{F}_s$, 均值为零、方差为 $t - s$ 。

于是 $\mathbb{E}[B_t | \mathcal{F}_s] = B_s$ 。又

$$\begin{aligned}\mathbb{E}[B_t^2 | \mathcal{F}_s] &= B_s^2 + \mathbb{E}[(B_t - B_s)^2] \\ &= B_s^2 + t - s.\end{aligned}$$

最后,

$$\begin{aligned}\mathbb{E}\left[e^{\theta B_t - \theta^2 t/2} \middle| \mathcal{F}_s\right] &= e^{\theta B_s - \theta^2 s/2} \mathbb{E}\left[e^{\theta(B_t - B_s) - \theta^2(t-s)/2}\right] \\ &= e^{\theta B_s - \theta^2 s/2}.\end{aligned}$$

□



15.7 连续时间停时与强 Markov 性

定义 15.12 (连续时间停时). 取值于 $[0, \infty]$ 的随机变量 T 称为停时, 若

$$\{T \leq t\} \in \mathcal{F}_t \text{ 对所有 } t \geq 0. \quad (15.8)$$

定义 15.13 (停时信息). 定义

$$\mathcal{F}_T = \{A \in \mathcal{F}_\infty : A \cap \{T \leq t\} \in \mathcal{F}_t \text{ 对所有 } t\}. \quad (15.9)$$

命题 15.14 (闭集首达时). 若 X_t 连续且适应, $F \subseteq \mathbb{R}$ 为闭集, 则 $T_F = \inf\{t \geq 0 : X_t \in F\}$ 是停时。

证明. $\{T_F \leq t\} = \{\inf_{0 \leq s \leq t} d(X_s, F) = 0\}$. 连续性允许将下确界限制到 $\mathbb{Q} \cap [0, t]$, 从而该事件属于 $\mathcal{F}_t$. $\square$

定理 15.15 (Brownian 强 Markov 性). 设 T 为停时, 且 $\mathbb{P}(T < \infty) = 1$. 则过程

$$B_t^{(T)} = B_{T+t} - B_T, \quad t \geq 0, \quad (15.10)$$

是标准 *Brownian motion*, 且独立于 $\mathcal{F}_T$.

证明思路

先对取有限多个确定值的停时证明: 在事件 $\{T = t_k\}$ 上应用确定时刻的独立增量性质。

再用上方二进逼近 $T_n = 2^{-n} \lceil 2^n T \rceil \downarrow T$. 每个 T_n 是离散值停时. 由 Brownian 路径连续性, $B_{T_n+t} - B_{T_n} \rightarrow B_{T+t} - B_T$. 对有界连续测试函数使用控制收敛, 将离散停时结论传递到 T .

考试时需要注意的地方

普通 Markov 性只允许在确定时刻 s 重新启动; 强 Markov 性允许在停时 T 重新启动. 若随机时间不是停时, 结论一般不成立。

15.8 反射原理与最大值

定义 $M_t = \sup_{0 \leq s \leq t} B_s$.

定理 15.16 (Brownian 反射原理). 对 $a > 0$ 和 $b \leq a$,

$$\mathbb{P}(M_t \geq a, B_t \leq b) = \mathbb{P}(B_t \geq 2a - b). \quad (15.11)$$

特别地,

$$\mathbb{P}(M_t \geq a) = 2\mathbb{P}(B_t \geq a), \quad (15.12)$$

从而

$$M_t \stackrel{d}{=} |B_t|. \quad (15.13)$$



证明. 令 $\tau_a = \inf\{s \geq 0 : B_s = a\}$. 在事件 $\{\tau_a \leq t\}$ 上, 将 τ_a 后的路径反射: $\tilde{B}_s = \begin{cases} B_s, & s \leq \tau_a, \\ 2a - B_s, & s > \tau_a. \end{cases}$ 由强

Markov 性和 Brownian 对称性, $\tilde{B}$ 与 B 同分布。

原路径满足 $M_t \geq a$, $B_t \leq b$ 当且仅当反射路径满足 $\tilde{B}_t \geq 2a - b$. 故得到 (15.11)。

令 $b = a$: $\mathbb{P}(M_t \geq a, B_t \leq a) = \mathbb{P}(B_t \geq a)$. 再加上 $\mathbb{P}(B_t \geq a)$ 本身, 得到 (15.12)。 $\square$

15.9 单侧首达时

对 $a > 0$, 定义

$$\tau_a = \inf\{t \geq 0 : B_t = a\}. \quad (15.14)$$

定理 15.17 (首达时分布). $\mathbb{P}(\tau_a \leq t) = 2 \left[1 - \Phi \left(\frac{a}{\sqrt{t}} \right) \right]$, $t > 0$. 因此

$$f_{\tau_a}(t) = \frac{a}{\sqrt{2\pi}t^{3/2}} \exp \left\{ -\frac{a^2}{2t} \right\}, \quad t > 0. \quad (15.15)$$

并且

$$\tau_a \stackrel{d}{=} \frac{a^2}{Z^2}, \quad Z \sim N(0, 1). \quad (15.16)$$

证明. 由反射原理,

$$\mathbb{P}(\tau_a \leq t) = \mathbb{P}(M_t \geq a) = 2\mathbb{P}(B_t \geq a) = 2 \left[1 - \Phi \left(\frac{a}{\sqrt{t}} \right) \right].$$

对 t 求导得到密度。

又

$$\mathbb{P} \left(\frac{a^2}{Z^2} \leq t \right) = \mathbb{P} \left(|Z| \geq \frac{a}{\sqrt{t}} \right) = 2 \left[1 - \Phi \left(\frac{a}{\sqrt{t}} \right) \right].$$

即证。 $\square$

推论 15.18. $\mathbb{P}(\tau_a < \infty) = 1$, 但

$$\mathbb{E}\tau_a = \infty. \quad (15.17)$$


证明. 第一点令 $t \rightarrow \infty$. 第二点可由密度尾部 $f_{\tau_a}(t) \asymp t^{-3/2}$ 得到 $\int^\infty t f_{\tau_a}(t) dt = \infty$. $\square$

15.10 首达时的 Laplace 变换

定理 15.19 (Brownian 首达时 Laplace 变换). 对 $\lambda > 0$,

$$\boxed{\mathbb{E}e^{-\lambda\tau_a} = e^{-a\sqrt{2\lambda}}}. \quad (15.18)$$

证明. 取 $\theta = \sqrt{2\lambda}$. 指数鞅 $M_t = e^{\theta B_t - \lambda t}$ 在停时 $\tau_a \wedge n$ 处满足 $\mathbb{E}M_{\tau_a \wedge n} = 1$. 在 $t < \tau_a$ 时 $B_t < a$, 在 τ_a 时 $B_{\tau_a} = a$, 因此 $0 \leq M_{\tau_a \wedge n} \leq e^{\theta a}$. 又因 $\tau_a < \infty$ a.s., $M_{\tau_a \wedge n} \rightarrow e^{\theta a - \lambda\tau_a}$ a.s. 由控制收敛, $1 = e^{\theta a} \mathbb{E}e^{-\lambda\tau_a}$. $\square$



15.11 双边退出问题

设 $a, b > 0$, 定义

$$\tau_{-a,b} = \inf\{t \geq 0 : B_t \notin (-a, b)\}. \quad (15.19)$$

由连续性, $B_{\tau_{-a,b}} \in \{-a, b\}$ 。

定理 15.20 (双边退出概率与平均时间). $\mathbb{P}(B_{\tau_{-a,b}} = b) = \frac{a}{a+b}$, $\mathbb{P}(B_{\tau_{-a,b}} = -a) = \frac{b}{a+b}$, 并且

$$\mathbb{E}\tau_{-a,b} = ab. \quad (15.20)$$

证明. 先对 $\tau_{-a,b} \wedge n$ 使用鞅 B_t 。停止后的变量有界于 $[-a, b]$, 故可令 $n \rightarrow \infty: 0 = \mathbb{E}B_{\tau_{-a,b}}$ 。令 $p = \mathbb{P}(B_{\tau_{-a,b}} = b)$, 则 $bp - a(1-p) = 0$, 故 $p = \frac{a}{a+b}$ 。

再对鞅 $B_t^2 - t$ 使用可选停止: $\mathbb{E}B_{\tau \wedge n}^2 = \mathbb{E}(\tau \wedge n)$ 。左侧有界, 令 $n \rightarrow \infty: \mathbb{E}\tau = \mathbb{E}B_\tau^2$ 。因此

$$\mathbb{E}\tau = b^2 \frac{a}{a+b} + a^2 \frac{b}{a+b} = ab.$$

□

对称情形定义

$$\sigma_a = \inf\{t \geq 0 : |B_t| = a\}. \quad (15.21)$$

推论 15.21 (对称区间退出). $\mathbb{P}(B_{\sigma_a} = a) = \mathbb{P}(B_{\sigma_a} = -a) = \frac{1}{2}$, $\mathbb{E}\sigma_a = a^2$ 。此外,

$$\mathbb{E}e^{-\lambda\sigma_a} = \frac{1}{\cosh(a\sqrt{2\lambda})}. \quad (15.22)$$

证明. 前两点由 定理 15.20 取 $a = b$ 。

对 Laplace 变换, 取 $\theta = \sqrt{2\lambda}$ 。对指数鞅停止: $1 = \mathbb{E}[e^{\theta B_{\sigma_a} - \lambda\sigma_a}]$ 。由路径对称性, 退出方向与 σ_a 独立, 且等概率取 $\pm a$, 故

$$1 = \mathbb{E}e^{-\lambda\sigma_a} \frac{e^{\theta a} + e^{-\theta a}}{2} = \mathbb{E}e^{-\lambda\sigma_a} \cosh(\theta a).$$

□

15.12 真题完整解法: 2024 Spring 首达时

往年真题

2024 Spring 第 6 题, 10 分。

设 B 为从 0 出发的 Brownian motion, $T_a = \inf\{t > 0 : B_t \geq a\}$, $a > 0$ 。

(1) 证明 T_a 是停时;

(2) 对 $\lambda > 0$ 计算 $\mathbb{E}e^{-\lambda T_a}$, 并证明 $T_a < \infty$ a.s.

解: 由于路径连续, $T_a = \inf\{t > 0 : B_t = a\}$ 。

第一问: 停时性

对每个 $t \geq 0$, $\{T_a \leq t\} = \{\sup_{0 \leq s \leq t} B_s \geq a\}$ 。由路径连续性, $\sup_{0 \leq s \leq t} B_s = \sup_{s \in \mathbb{Q} \cap [0, t]} B_s$, 故右侧属于 $\sigma(B_s : s \leq t) = \mathcal{F}_t$ 。

第二问：先证明有限性

由反射原理, $\mathbb{P}(T_a \leq t) = 2\mathbb{P}(B_t \geq a) = 2\left[1 - \Phi\left(\frac{a}{\sqrt{t}}\right)\right]$ 。令 $t \rightarrow \infty$, $\mathbb{P}(T_a < \infty) = 1$ 。

计算 Laplace 变换

令 $u = \sqrt{2\lambda}$ 并定义 $M_t = \exp\{uB_t - \frac{1}{2}u^2t\}$ 。这是非负鞅。

对有界停时 $T_a \wedge n$, $\mathbb{E}M_{T_a \wedge n} = 1$ 。又因 $B_{T_a \wedge n} \leq a$, 有 $0 \leq M_{T_a \wedge n} \leq e^{ua}$ 。由于 $T_a < \infty$ a.s., $M_{T_a \wedge n} \rightarrow e^{ua - \lambda T_a}$ 。控制收敛给出 $1 = e^{ua} \mathbb{E}e^{-\lambda T_a}$ 。因此 $\mathbb{E}e^{-\lambda T_a} = e^{-a\sqrt{2\lambda}}$ 。□

考试时需要注意的地方

该题常见失分包括：

- (1) 未说明连续性使 $B_{T_a} = a$;
- (2) 未证明 T_a 是停时;
- (3) 直接对无界停时使用可选停止;
- (4) 未给出 $M_{T_a \wedge n} \leq e^{ua}$ 的控制;
- (5) 用 λ 同时充当指数鞅参数和 Laplace 参数, 导致缺少 $\sqrt{2}$ 。

15.13 真题完整解法：2025 Spring 对称退出时间与方向

往年真题

2025 Spring 第 5 题, 10 分。

令 $T_a = \inf\{t \geq 0 : |B_t| = a\}$, $a > 0$ 。

- (1) 证明 $T_a < \infty$ a.s.;
- (2) 证明 T_a 与 $\mathbf{1}_{\{B_{T_a}=a\}}$ 独立。

解：第一问

若 $T_a > t$, 则整个区间 $[0, t]$ 上 $|B_s| < a$, 特别地 $|B_t| < a$ 。因此 $\mathbb{P}(T_a > t) \leq \mathbb{P}(|B_t| < a) = \mathbb{P}\left(|Z| < \frac{a}{\sqrt{t}}\right)$, 其中 $Z \sim N(0, 1)$ 。令 $t \rightarrow \infty$, 右侧趋于零, 故 $\mathbb{P}(T_a < \infty) = 1$ 。

第二问

由连续性, $B_{T_a} \in \{-a, a\}$ 。令 $\varepsilon_a = \mathbf{1}_{\{B_{T_a}=a\}}$ 。取任意 Borel 集 $C \subseteq [0, \infty)$ 。

映射 $(B_t)_{t \geq 0} \mapsto (-B_t)_{t \geq 0}$ 保持 Brownian motion 的分布, 并且保持 T_a 不变, 同时交换退出端点 a 与 $-a$ 。因此 $\mathbb{P}(T_a \in C, B_{T_a} = a) = \mathbb{P}(T_a \in C, B_{T_a} = -a)$ 。两事件互不相交且并为 $\{T_a \in C\}$, 故 $\mathbb{P}(T_a \in C, B_{T_a} = a) = \frac{1}{2}\mathbb{P}(T_a \in C)$ 。取 $C = [0, \infty)$ 得 $\mathbb{P}(B_{T_a} = a) = \frac{1}{2}$ 。所以 $\mathbb{P}(T_a \in C, \varepsilon_a = 1) = \mathbb{P}(T_a \in C)\mathbb{P}(\varepsilon_a = 1)$ 。同理对 $\varepsilon_a = 0$ 成立, 故二者独立。□

考试时需要注意的地方

证明独立不能只写“由对称性显然”。必须至少验证对任意 Borel 集 C , $\mathbb{P}(T_a \in C, B_{T_a} = a) = \frac{1}{2}\mathbb{P}(T_a \in C)$ 。

15.14 吸收边界与 killed Brownian transition density

设 $X_t = x + B_t$, $x > 0$, 并定义 $\tau_0 = \inf\{t \geq 0 : X_t = 0\}$ 。记高斯热核

$$p_t(u) = \frac{1}{\sqrt{2\pi t}} \exp\left\{-\frac{u^2}{2t}\right\}. \quad (15.23)$$

定理 15.22 (半直线吸收热核). 对 $y > 0$,

$$\mathbb{P}_x(X_t \in dy, \tau_0 > t) = [p_t(y-x) - p_t(y+x)] dy. \quad (15.24)$$

证明. 无条件密度为 $p_t(y-x)$ 。考虑在 t 前已命中 0 且最终落在 $y > 0$ 的路径。在首次命中 0 后反射路径, 终点 y 被映为 $-y$ 。反射映射保持 Wiener 概率, 故 $\mathbb{P}_x(X_t \in dy, \tau_0 \leq t) = p_t(-y-x) dy = p_t(y+x) dy$ 。两者相减。□

积分得到生存概率

$$\mathbb{P}_x(\tau_0 > t) = 2\Phi\left(\frac{x}{\sqrt{t}}\right) - 1. \quad (15.25)$$

15.15 真题完整解法：2024 Fall 吸收前条件分布

往年真题

2024 Fall 第 6 题第 (a) 问。

令 $X_t = x + B_t$, $x > 0$ 。对 $t > 0$ 和 $b > a > 0$, 计算 $\mathbb{P}(X_t \in [a, b] \mid \min_{0 \leq s \leq t} X_s > 0)$ 。

解: 由于路径连续, $\{\min_{0 \leq s \leq t} X_s > 0\} = \{\tau_0 > t\}$ 。由吸收热核,

$$\mathbb{P}_x(X_t \in [a, b], \tau_0 > t) = \int_a^b \frac{1}{\sqrt{2\pi t}} \left[\exp\left\{-\frac{(y-x)^2}{2t}\right\} - \exp\left\{-\frac{(y+x)^2}{2t}\right\} \right] dy.$$

分母为 $\mathbb{P}_x(\tau_0 > t) = 2\Phi\left(\frac{x}{\sqrt{t}}\right) - 1$ 。因此

$$\mathbb{P}\left(X_t \in [a, b] \mid \min_{0 \leq s \leq t} X_s > 0\right) = \frac{\int_a^b \frac{1}{\sqrt{2\pi t}} \left[e^{-(y-x)^2/(2t)} - e^{-(y+x)^2/(2t)} \right] dy}{2\Phi(x/\sqrt{t}) - 1}.$$

□

考试时需要注意的地方

完整答案必须同时给出:

- (1) 反射后的镜像密度 $p_t(y+x)$;
- (2) killed density $p_t(y-x) - p_t(y+x)$;
- (3) 正确归一化分母;
- (4) 条件支撑 $y > 0$ 。

15.16 Brownian 大时间线性归一化

引理 15.23 (Brownian 强大数律).

$$\frac{B_t}{t} \xrightarrow{\text{a.s.}} 0. \quad (15.26)$$

证明. 在整数时刻, $B_n = \sum_{k=1}^n (B_k - B_{k-1})$, 其中增量 i.i.d. $N(0, 1)$ 。由强大数律, $\frac{B_n}{n} \xrightarrow{\text{a.s.}} 0$ 。

令 $Y_n = \sup_{0 \leq u \leq 1} |B_{n+u} - B_n|$ 。由平稳独立增量, Y_n 同分布于 $\sup_{0 \leq u \leq 1} |B_u|$ 。由反射原理和高斯尾界, 对任意 $\varepsilon > 0$, $\sum_{n=1}^{\infty} \mathbb{P}(Y_n > \varepsilon n) < \infty$ 。故 $\frac{Y_n}{n} \xrightarrow{\text{a.s.}} 0$ 。若 $n \leq t < n+1$, $\frac{|B_t|}{t} \leq \frac{|B_n| + Y_n}{n}$, 结论成立。□

15.17 真题完整解法: 2025 Fall Brownian 指数鞅

往年真题

2025 Fall 第 5 题, 10 分。

定义 $X_t = \exp(B_t - \frac{1}{2}t)$ 。

- (1) 证明 X_t 当 $t \rightarrow \infty$ 时几乎处处收敛;
- (2) 计算 $\mathbb{E} \int_0^t X_s ds$, $\text{Var} \left(\int_0^t X_s ds \right)$;
- (3) 证明 $\int_0^\infty X_t dt < \infty$ a.s.

解: 第一问

由 定理 15.23, $\frac{B_t}{t} \xrightarrow{\text{a.s.}} 0$ 。因此 $\frac{1}{t} \log X_t = \frac{B_t}{t} - \frac{1}{2} \xrightarrow{\text{a.s.}} -\frac{1}{2}$ 。故 $X_t \xrightarrow{\text{a.s.}} 0$ 。

也可先注意 X_t 为非负鞅, 由鞅收敛定理存在有限极限, 再用上式识别极限为零。

第二问: 期望

由于 $\mathbb{E} X_s = e^{-s/2} \mathbb{E} e^{B_s} = e^{-s/2} e^{s/2} = 1$, Tonelli 定理给出 $\mathbb{E} \int_0^t X_s ds = t$ 。

第二问: 二阶矩

不妨设 $0 \leq s \leq u$ 。向量 (B_s, B_u) 联合高斯, 且 $\text{Var}(B_s + B_u) = s + u + 2s = u + 3s$ 。因此

$$\begin{aligned} \mathbb{E}[X_s X_u] &= \mathbb{E} \exp \left\{ B_s + B_u - \frac{s+u}{2} \right\} \\ &= \exp \left\{ \frac{1}{2}(u + 3s) - \frac{s+u}{2} \right\} \\ &= e^s. \end{aligned}$$

于是

$$\begin{aligned} \mathbb{E} \left[\left(\int_0^t X_s ds \right)^2 \right] &= 2 \int_0^t \int_s^t \mathbb{E}[X_s X_u] du ds \\ &= 2 \int_0^t (t-s) e^s ds \\ &= 2(e^t - t - 1). \end{aligned}$$

所以 $\text{Var} \left(\int_0^t X_s ds \right) = 2(e^t - t - 1) - t^2$ 。



第三问

由 $B_t/t \rightarrow 0$ a.s., 几乎处处存在随机 $T_0 < \infty$, 使对 $t \geq T_0$, $B_t \leq \frac{1}{4}t$. 因此 $X_t = e^{B_t - t/2} \leq e^{-t/4}$, $t \geq T_0$. 故 $\int_{T_0}^{\infty} X_t dt \leq \int_{T_0}^{\infty} e^{-t/4} dt < \infty$. 连续性保证 $\int_0^{T_0} X_t dt < \infty$. 于是 $\int_0^{\infty} X_t dt < \infty$ a.s. $\square$

考试时需要注意的地方

虽然 $X_t \xrightarrow{\text{a.s.}} 0$, 但 $\mathbb{E}X_t = 1$ 对所有 t 成立. 因此 X_t 不在 L^1 中收敛到零, 且族 $\{X_t : t \geq 0\}$ 不一致可积.

15.18 确定性 Laplace 原理

引理 15.24 (连续函数的 Laplace 原理). 设 $f \in C([0, 1])$. 则

$$\lim_{T \rightarrow \infty} \frac{1}{T} \log \int_0^1 e^{Tf(s)} ds = \max_{0 \leq s \leq 1} f(s). \quad (15.27)$$

证明. 记 $M = \max_{[0,1]} f$. 上界: $\int_0^1 e^{Tf(s)} ds \leq e^{TM}$, 故 $\limsup_{T \rightarrow \infty} \frac{1}{T} \log \int_0^1 e^{Tf(s)} ds \leq M$.

任取 $\varepsilon > 0$. 取最大点 s_0 . 由连续性, 存在长度为 $\delta > 0$ 的区间 $I \subseteq [0, 1]$, 使 $f(s) \geq M - \varepsilon$ 对 $s \in I$. 于是 $\int_0^1 e^{Tf(s)} ds \geq \delta e^{T(M-\varepsilon)}$. 故 $\liminf_{T \rightarrow \infty} \frac{1}{T} \log \int_0^1 e^{Tf(s)} ds \geq M - \varepsilon$. 令 $\varepsilon \downarrow 0$. $\square$

15.19 真题完整解法: 2026 Spring Brownian 指数泛函

往年真题

2026 Spring 第 4 题, 10 分。


求并证明 $\left[\int_0^{T^2} e^{B_t} dt \right]^{1/T}$ 当 $T \rightarrow \infty$ 时的分布极限, 并将答案写成标准正态随机变量的函数。

解: 令 $Y_T = \left[\int_0^{T^2} e^{B_t} dt \right]^{1/T}$. 作变量代换 $t = T^2 s$, $0 \leq s \leq 1$, 得到 $Y_T = \exp \left\{ \frac{2 \log T}{T} + \frac{1}{T} \log \int_0^1 \exp(B_{T^2 s}) ds \right\}$.

由 Brownian 缩放, $\{\frac{1}{T} B_{T^2 s} : 0 \leq s \leq 1\} \stackrel{d}{=} \{B_s : 0 \leq s \leq 1\}$. 因此 $Y_T \stackrel{d}{=} \exp \left\{ \frac{2 \log T}{T} + \frac{1}{T} \log \int_0^1 e^{TB_s} ds \right\}$.

对几乎每条连续 Brownian 路径, 由定理 15.24, $\frac{1}{T} \log \int_0^1 e^{TB_s} ds \rightarrow \sup_{0 \leq s \leq 1} B_s$. 同时 $\frac{2 \log T}{T} \rightarrow 0$. 故右侧几乎处处收敛于 $\exp \{ \sup_{0 \leq s \leq 1} B_s \}$. 由反射原理, $\sup_{0 \leq s \leq 1} B_s \stackrel{d}{=} |B_1| \stackrel{d}{=} |Z|$, $Z \sim N(0, 1)$. 因此

$$\left[\int_0^{T^2} e^{B_t} dt \right]^{1/T} \xrightarrow{d} e^{|Z|}, \quad Z \sim N(0, 1). \quad \square$$



考试时需要注意的地方

该题的关键尺度是上限 T^2 : $B_{T^2s} \stackrel{d}{=} TB_s$ 。若误看成 $T/2$, 会得到完全不同的结论。

完整得分需要:

- (1) 时间换元;
- (2) Brownian 缩放;
- (3) 连续函数 Laplace 原理;
- (4) 反射原理 $\sup_{s \leq 1} B_s \stackrel{d}{=} |Z|$.

15.20 Brownian motion 易错点总表

陈述	判断	正确说明
Brownian motion 的独立增量表示 B_s 与 B_t 独立	错	$B_t - B_s$ 与过去独立; B_s 与 B_t 协方差为 s 。
路径连续, 所以路径可微	错	Brownian 路径几乎处处不可微。
Brownian 路径有有限总变差	错	其在每个非退化区间上的总变差无穷。
Brownian 二次变差为零	错	在 $[0, t]$ 上二次变差为 t 。
单侧首达时 τ_a 有有限均值	错	$\tau_a < \infty$ a.s., 但 $\mathbb{E}\tau_a = \infty$ 。
对称区间退出时间也有无穷均值	错	若 $\sigma_a = \inf\{ B_t = a\}$, 则 $\mathbb{E}\sigma_a = a^2$ 。
可选停止可直接用于 τ_a	错	应先对 $\tau_a \wedge n$ 停止, 并给出控制收敛或 UI 理由。
Brownian bridge 仍有独立增量	错	条件 $W_1 = 0$ 引入全局相关性。
B_t/t 与 $B_t/\sqrt{t}$ 都趋于零	错	$B_t/t \rightarrow 0$ a.s.; 但 $B_t/\sqrt{t}$ 对每个 t 都是标准正态分布。
反射原理只给最大值尾概率	不完整	它还给吸收边界热核和首达时分布。

Brownian 首达与退出题

- (1) 明确定义停时, 并用连续性验证;
- (2) 判断是单侧首达还是双侧退出;
- (3) 单侧最大值题优先想到反射原理;
- (4) Laplace 变换优先尝试 $e^{\theta B_t - \theta^2 t/2}$;
- (5) 平均退出时间优先尝试 $B_t^2 - t$;
- (6) 退出概率优先尝试 B_t ;
- (7) 必须先停止于 $T \wedge n$;
- (8) 明确说明令 $n \rightarrow \infty$ 的依据;
- (9) 连续路径保证退出时恰落在边界, 而不会越过边界。

一些需要记忆的内容

- (1) Brownian motion 的协方差函数是什么?
- (2) 为什么不相交 Brownian 增量相互独立?
- (3) Brownian 缩放中空间和时间分别按什么比例变化?
- (4) 单侧首达时的分布函数、密度和 Laplace 变换是什么?
- (5) 为什么单侧首达时均值无穷, 而双侧退出时间均值有限?
- (6) killed Brownian density 中为什么出现镜像项 $p_t(y+x)$?
- (7) Brownian bridge 的条件分布如何严格理解?
- (8) Brownian 指数鞅为何 a.s. 趋于零但期望恒为一?
- (9) 2026 Spring 第 4 题中为什么使用确定性 Laplace 原理?



第十六章 Galton–Watson 分枝过程与随机树

16.1 考纲定位

重点

A 级

该主题未在简要考纲中单独列出，但曾在历年真题中实际考查。

- [26S-Q5, 10 分]: 条件期望、概率生成函数、固定点与灭绝概率;
- [26S-Q6, 15 分]: 遗传性质的条件 0–1 律, 以及 Galton–Watson 树上的渗流临界值。

同时, [P-Lec] 将 Galton–Watson tree 作为鞅的重要应用单列一节。因此本章虽然归入实考扩展, 但 2026 Spring 已连续用两题、合计 25 分考查, 不能忽略。

16.2 模型、过滤与基本递推

设 $\{\xi_{j,n} : j \geq 1, n \geq 0\}$ 为 i.i.d. 非负整数值随机变量, 公共分布为 $\mathbb{P}(\xi_{j,n} = k) = p_k, \quad k = 0, 1, 2, \dots$ 。
设 $Z_0 = 1$, 并递归定义

$$Z_{n+1} = \sum_{j=1}^{Z_n} \xi_{j,n}, \quad (16.1)$$

其中空和定义为零。

令 $\mathcal{F}_n = \sigma(Z_0, \dots, Z_n)$ 或更细地取包含前 n 代全部繁殖变量的自然过滤。

定义后代分布均值

$$m = \mathbb{E}\xi_{1,0} = \sum_{k=0}^{\infty} k p_k < \infty, \quad (16.2)$$

以及概率生成函数

$$f(s) = \mathbb{E}[s^{\xi_{1,0}}] = \sum_{k=0}^{\infty} p_k s^k, \quad 0 \leq s \leq 1. \quad (16.3)$$


于是 $f(1) = 1, f'(1-) = m$ 。

命题 16.1 (条件均值与条件生成函数). 对 $n \geq 0$,

$$\mathbb{E}[Z_{n+1} \mid \mathcal{F}_n] = m Z_n, \quad (16.4)$$

以及对 $s \in [0, 1]$,

$$\mathbb{E}[s^{Z_{n+1}} \mid \mathcal{F}_n] = f(s)^{Z_n}. \quad (16.5)$$



证明. 给定 $\mathcal{F}_n$ 后, Z_n 已知, 且第 n 代每个个体的子女数独立同分布。因此

$$\begin{aligned}\mathbb{E}[Z_{n+1} | \mathcal{F}_n] &= \sum_{j=1}^{Z_n} \mathbb{E}[\xi_{j,n} | \mathcal{F}_n] \\ &= mZ_n.\end{aligned}$$

同理,

$$\begin{aligned}\mathbb{E}[s^{Z_{n+1}} | \mathcal{F}_n] &= \mathbb{E}\left[\prod_{j=1}^{Z_n} s^{\xi_{j,n}} \middle| \mathcal{F}_n\right] \\ &= \prod_{j=1}^{Z_n} \mathbb{E}[s^{\xi_{j,n}}] \\ &= f(s)^{Z_n}.\end{aligned}$$

□

推论 16.2 (代数均值).

$$\mathbb{E}Z_n = m^n. \quad (16.6)$$

证明. 由 Tower property, $\mathbb{E}Z_{n+1} = m\mathbb{E}Z_n$ 。结合 $Z_0 = 1$ 归纳。□

推论 16.3 (迭代生成函数). 记 $f^{\circ n} = \underbrace{f \circ \dots \circ f}_{n \text{ 次}}$, $f^{\circ 0}(s) = s$ 。则

$$\mathbb{E}[s^{Z_n}] = f^{\circ n}(s). \quad (16.7)$$

证明. 由条件生成函数,

$$\begin{aligned}\mathbb{E}[s^{Z_{n+1}}] &= \mathbb{E}[f(s)^{Z_n}] \\ &= f^{\circ n}(f(s)) \\ &= f^{\circ(n+1)}(s).\end{aligned}$$

□

16.3 灭绝事件与固定点

定义灭绝时间

$$\tau = \inf\{n \geq 0 : Z_n = 0\}. \quad (16.8)$$


由于 0 为吸收状态, $Z_n = 0 \implies Z_{n+1} = 0$ 。灭绝事件为 $\mathcal{E} = \{\tau < \infty\} = \bigcup_{n \geq 0} \{Z_n = 0\}$ 。

定理 16.4 (灭绝概率固定点定理). 令 $q = \mathbb{P}(\mathcal{E})$ 。则 q 是方程

$$f(s) = s, \quad 0 \leq s \leq 1 \quad (16.9)$$

的最小解。

在非退化假设 $p_0 > 0$, $p_0 + p_1 < 1$ 下:



- (1) 若 $m \leq 1$, 则 $q = 1$;
 (2) 若 $m > 1$, 则存在唯一 $q \in (0, 1)$ 使 $f(q) = q$, 并且另一个固定点为 1。

证明. 由 (16.7), $\mathbb{P}(Z_n = 0) = f^{\circ n}(0)$ 。由于事件 $\{Z_n = 0\}$ 递增, $q = \lim_{n \rightarrow \infty} f^{\circ n}(0)$ 。序列 $a_n = f^{\circ n}(0)$ 单调递增且有界于 1, 故收敛到某个 $a \in [0, 1]$ 。由 f 连续, $a = \lim_n a_{n+1} = \lim_n f(a_n) = f(a)$ 。所以 a 是固定点。

若 $r \in [0, 1]$ 满足 $f(r) = r$, 则由 $0 \leq r$ 和 f 单调, $a_n = f^{\circ n}(0) \leq f^{\circ n}(r) = r$ 。令 $n \rightarrow \infty$ 得 $q = a \leq r$ 。所以 q 是最小固定点。

下面分析固定点个数。令 $g(s) = f(s) - s$ 。由 $p_0 > 0$, $\mathbb{P}(\xi \geq 2) > 0$, 有 $g(0) = p_0 > 0$, $g(1) = 0$, 且 g 在 $(0, 1)$ 严格凸。

若 $m \leq 1$, 则 $g'(1) = m - 1 \leq 0$ 。凸性说明 g' 单调不减, 因此对 $s < 1$, $g'(s) < g'(1) \leq 0$ 。故 g 在 $[0, 1]$ 上严格递减, $g(s) > g(1) = 0$ ($s < 1$), 唯一固定点为 1。

若 $m > 1$, 则 $g'(1) > 0$ 。因此当 $s < 1$ 充分接近 1 时, $g(s) < 0$ 。结合 $g(0) > 0$, 连续性保证存在 $q \in (0, 1)$ 使 $g(q) = 0$ 。严格凸函数与水平轴至多有两个交点, 故固定点恰为 q 和 1。□

概念比较

$m < 1$	次临界	$q = 1$
$m = 1$	临界	$q = 1$
$m > 1$	超临界	$q < 1$

必须区分:

- $\mathbb{E}Z_n = m^n$ 描述平均规模;
- q 描述最终灭绝概率;
- 即使 $m = 1$, 每一代平均人数仍为 1, 但过程仍几乎必然灭绝。

16.4 归一化人口鞅

若 $m > 0$, 定义

$$W_n = \frac{Z_n}{m^n}. \quad (16.10)$$

命题 16.5. $\{W_n, \mathcal{F}_n\}$ 是非负鞅, 且 $\mathbb{E}W_n = 1$ 。因此存在有限随机变量 W , 使 $W_n \xrightarrow{\text{a.s.}} W$ 。

证明. $\mathbb{E}[W_{n+1} | \mathcal{F}_n] = \frac{mZ_n}{m^{n+1}} = W_n$ 。非负鞅收敛定理给出 a.s. 收敛。□

定理 16.6 (有限方差超临界情形). 设 $m > 1$, $\sigma^2 = \text{Var}(\xi_{1,0}) < \infty$ 。则 $\{W_n\}$ 在 L^2 中有界, 因而 $W_n \rightarrow W$ a.s. 且在 L^2 中。此外 $\mathbb{P}(W = 0) = q$, 所以在存活事件上 $W > 0$ a.s.

证明. 给定 Z_n , $\mathbb{E}[Z_{n+1}^2 | \mathcal{F}_n] = \sigma^2 Z_n + m^2 Z_n^2$ 。除以 m^{2n+2} 并取期望: $\mathbb{E}W_{n+1}^2 = \mathbb{E}W_n^2 + \frac{\sigma^2}{m^{n+2}}$ 。因此 $\sup_n \mathbb{E}W_n^2 \leq 1 + \sum_{n=0}^{\infty} \frac{\sigma^2}{m^{n+2}} < \infty$ 。

令 $r = \mathbb{P}(W = 0)$ 。分枝性质给出分布递推 $mW \stackrel{d}{=} \sum_{j=1}^{Z_1} W^{(j)}$, 其中 $W^{(j)}$ 是独立的 W 副本。由于各项非负, $r = \mathbb{E}[r^{Z_1}] = f(r)$ 。灭绝时从某代起 $Z_n = 0$, 故 $\mathcal{E} \subseteq \{W = 0\}$, $r \geq q$ 。固定点只有 q 与 1。又因 L^2 收敛推出 $\mathbb{E}W = \lim_n \mathbb{E}W_n = 1$, 所以 $r \neq 1$, 故 $r = q$ 。□

注 16.7. 一般超临界情形下, 确保 $W > 0$ 在存活事件上的精确条件是 Kesten-Stigum 型矩条件 $\mathbb{E}[\xi \log^+ \xi] < \infty$. 该高级定理在 [P-Lec] 中作为扩展出现, 资格考试通常只需知道结论和条件, 不要求完整证明.

16.5 真题完整解法: 2026 Spring 第 5 题

往年真题

2026 Spring 第 5 题, 10 分。

在假设 $p_0 > 0$, $p_0 + p_1 < 1$ 下:

- (1) 计算 $\mathbb{E}[Z_{n+1} | \mathcal{F}_n]$, $\mathbb{E}Z_n$, $\mathbb{E}[s^{Z_{n+1}} | \mathcal{F}_n]$, $\mathbb{E}[s^{Z_n}]$;
- (2) 判断 $f(s) = s$ 在 $[0, 1]$ 上的解数;
- (3) 求灭绝概率。

解: 第一问

由给定 Z_n 后各个体独立繁殖, $\mathbb{E}[Z_{n+1} | \mathcal{F}_n] = mZ_n$. 取期望并归纳: $\mathbb{E}Z_n = m^n$.

对 $s \in [0, 1]$,

$$\begin{aligned}\mathbb{E}[s^{Z_{n+1}} | \mathcal{F}_n] &= \mathbb{E}\left[s^{\sum_{j=1}^{Z_n} \xi_{j,n}} \middle| \mathcal{F}_n\right] \\ &= \prod_{j=1}^{Z_n} \mathbb{E}[s^{\xi_{j,n}}] \\ &= f(s)^{Z_n}.\end{aligned}$$

故 $\mathbb{E}[s^{Z_{n+1}} | \mathcal{F}_n] = f(s)^{Z_n}$. 再归纳得到 $\mathbb{E}[s^{Z_n}] = f^{\circ n}(s)$.

第二问

令 $g(s) = f(s) - s$. 由假设, $g(0) = p_0 > 0$, $g(1) = 0$, 且 $g''(s) = f''(s) > 0$ ($0 < s < 1$), 所以 g 严格凸。

若 $m = f'(1) \leq 1$, 则 $g'(1) \leq 0$, 严格凸性推出 $g(s) > 0$ 对所有 $s < 1$ 成立, 所以仅有一个解: $s = 1$.

若 $m > 1$, 则 $g'(1) > 0$, 故 g 在 1 左侧为负, 而 $g(0) > 0$. 存在唯一 $q \in (0, 1)$ 使 $g(q) = 0$, 再加上 $s = 1$: 共有两个解 q 与 1.

第三问

因为 $\mathbb{P}(Z_n = 0) = f^{\circ n}(0)$, 且 $\{Z_n = 0\}$ 递增, $\mathbb{P}(\tau < \infty) = \lim_{n \rightarrow \infty} f^{\circ n}(0)$. 该极限是 f 的最小固定点 q .

因此 $\mathbb{P}(\tau < \infty) = q$. 特别地, $q = \begin{cases} 1, & m \leq 1, \\ (0, 1) \text{ 中唯一的固定点}, & m > 1. \end{cases}$ □

考试时需要注意的地方

第二问不能只写“由凸性可知”。应明确写出: $g(0) > 0$, $g(1) = 0$, $g'(1) = m - 1$, $g'' > 0$. 这些量共同决定固定点数。

16.6 遗传性质的条件 0-1 律

定义 16.8 (遗传性质). rooted tree 的性质 $\mathcal{A}$ 称为遗传的 (inherited), 若:

- (1) 每棵有限 rooted tree 均具有性质 $\mathcal{A}$;
 (2) 若一棵 rooted tree 具有性质 $\mathcal{A}$, 则根的孩子所根植的子树也具有性质 $\mathcal{A}$ 。

注意第二条只有单向蕴含: $T \in \mathcal{A} \implies T_i \in \mathcal{A}$ 对所有根子树 T_i 。

引理 16.9 (固定点几何). 在超临界非退化情形 $m > 1$ 下, 若 $s \leq f(s)$, $s \in [0, 1]$, 则

$$s \in [0, q] \cup \{1\}, \quad (16.11)$$

其中 $q \in (0, 1)$ 为最小固定点。

证明. 函数 $g(s) = f(s) - s$ 严格凸, 零点恰为 q 和 1 . 因此 $g(s) \geq 0$ 恰在 $[0, q] \cup \{1\}$ 上成立. $\square$

定理 16.10 (遗传性质条件 0-1 律). 设 Galton-Watson 过程超临界, 即 $m > 1$, $q < 1$. 若 $\mathcal{A}$ 为遗传性质, 则

$$\mathbb{P}(T \in \mathcal{A} \mid T \text{ 不灭绝}) \in \{0, 1\}. \quad (16.12)$$

证明. 令 $r = \mathbb{P}(T \in \mathcal{A})$. 由于所有有限树均具有 $\mathcal{A}$, 灭绝事件包含于 $\mathcal{A}$: $\mathcal{E} \subseteq \{T \in \mathcal{A}\}$. 故 $r \geq q$.

给定根有 $Z_1 = k$ 个孩子, 其 k 棵根子树独立且均为原 Galton-Watson 树的副本. 若 $T \in \mathcal{A}$, 遗传性要求全部根子树属于 $\mathcal{A}$. 因此 $\{T \in \mathcal{A}\} \subseteq \bigcap_{j=1}^{Z_1} \{T_j \in \mathcal{A}\}$. 所以

$$r \leq \mathbb{E}[r^{Z_1}] = f(r).$$

由 定理 16.9, $r \in [0, q] \cup \{1\}$. 结合 $r \geq q$, 得到 $r = q$ 或 $r = 1$.

又因 $\mathcal{E} \subseteq \mathcal{A}$,

$$\mathbb{P}(T \in \mathcal{A} \mid \mathcal{E}^c) = \frac{\mathbb{P}(T \in \mathcal{A}) - \mathbb{P}(\mathcal{E})}{1 - q} = \frac{r - q}{1 - q}.$$

若 $r = q$, 条件概率为 0; 若 $r = 1$, 条件概率为 1. $\square$

前提条件检查

若 $m \leq 1$, 则 $\mathbb{P}(T \text{ 不灭绝}) = 0$, 通常意义下不能对该零概率事件定义普通条件概率. 真题结论的实质对象是超临界情形。

16.7 Galton-Watson 树上的独立边渗流


固定一棵局部有限 rooted tree T . 对每条边独立地以概率 p 打开、以概率 $1 - p$ 关闭. 令 C_o 为根 o 的开放连通分支。

定义给定树的 quenched 存活概率

$$\theta_p(T) = \mathbb{P}_p(|C_o| = \infty \mid T). \quad (16.13)$$

定义临界概率

$$p_c(T) = \sup\{p \in [0, 1] : \theta_p(T) = 0\}. \quad (16.14)$$



命题 16.11 (退火后的开放簇仍为分枝过程). 若原 Galton-Watson 后代变量为 ξ , 则开放根簇 C_o 在同时平均树和渗流随机性后, 是后代变量 $\eta \mid \xi \sim \text{Bin}(\xi, p)$ 的 Galton-Watson 树。

其生成函数为

$$f_p(s) = f(1 - p + ps), \quad (16.15)$$

均值为

$$f'_p(1) = pm. \quad (16.16)$$

证明. 一个原树个体有 ξ 个孩子, 通向每个孩子的边独立以概率 p 开放. 因此开放孩子数在给定 ξ 后服从 $\text{Bin}(\xi, p)$. 不同顶点对应的原后代数和边状态独立, 故仍具有分枝性质。

条件生成函数为 $\mathbb{E}[s^\eta \mid \xi] = (1 - p + ps)^\xi$. 再对 ξ 取期望。□

16.8 真题完整解法：2026 Spring 第 6 题

往年真题

2026 Spring 第 6 题, 15 分。

- (1) 证明: 给定 Galton-Watson 树不灭绝, 任意遗传性质的概率只能为 0 或 1;
- (2) 设原后代均值 $m > 1$. 在 Galton-Watson 树上做密度 p 的独立边渗流. 条件于原树不灭绝, 求 $p_c(T)$.

解: 第一问已由 定理 16.10 完整证明. 下面证明第二问。

对固定 $p \in [0, 1]$, 定义树性质 $\mathcal{A}_p = \{T : \theta_p(T) = 0\}$ 。

第一步: $\mathcal{A}_p$ 是遗传性质

有限树显然属于 $\mathcal{A}_p$ 。

若 $T \in \mathcal{A}_p$, 设根的孩子子树为 $T_1, \dots, T_k$. 若某个 T_j 满足 $\theta_p(T_j) > 0$, 则只要根到第 j 个孩子的边开放, 并且该子树内发生无限开放簇, 根簇就无限. 因此 $\theta_p(T) \geq p\theta_p(T_j) > 0$ 对 $p > 0$ 成立, 与 $T \in \mathcal{A}_p$ 矛盾. $p = 0$ 时结论显然. 故 $T \in \mathcal{A}_p \implies T_j \in \mathcal{A}_p$ 对所有 j . 因此 $\mathcal{A}_p$ 为遗传性质。

由第一问,

$$\mathbb{P}(T \in \mathcal{A}_p \mid T \text{ 不灭绝}) \in \{0, 1\}. \quad (16.17)$$

第二步: 计算退火临界值

由 定理 16.11, 开放根簇是均值为 pm 的 Galton-Watson 过程。

若 $p \leq \frac{1}{m}$, 则 $pm \leq 1$, 开放簇几乎必然灭绝: $\mathbb{P}(|C_o| = \infty) = 0$. 另一方面, $\mathbb{P}(|C_o| = \infty) = \mathbb{E}[\theta_p(T)]$. 由于 $\theta_p(T) \geq 0$, $\mathbb{E}[\theta_p(T)] = 0 \implies \theta_p(T) = 0$ a.s. 因此

$$p \leq \frac{1}{m} \implies \mathbb{P}(T \in \mathcal{A}_p \mid T \text{ 不灭绝}) = 1. \quad (16.18)$$

若 $p > \frac{1}{m}$, 则 $pm > 1$, 开放簇以正概率不灭绝: $\mathbb{P}(|C_o| = \infty) > 0$. 因此 $\mathbb{E}[\theta_p(T)] > 0$, 从而 $\mathbb{P}(\theta_p(T) > 0) > 0$. 故 $\mathbb{P}(T \in \mathcal{A}_p) < 1$. 结合 (16.17), 条件概率不可能为 1, 只能为 0:

$$p > \frac{1}{m} \implies \mathbb{P}(T \in \mathcal{A}_p \mid T \text{ 不灭绝}) = 0. \quad (16.19)$$

第三步：从固定 p 推到同时对所有 p

对所有有理数 $p \in \mathbb{Q} \cap [0, 1]$ 取可数交。于是条件于原树不灭绝,几乎每棵树同时满足: $\theta_p(T) = 0$ 对所有有理 $p \leq 1/m$, 以及 $\theta_p(T) > 0$ 对所有有理 $p > 1/m$ 。

由于 $p \mapsto \theta_p(T)$ 单调不减, 对任意实数 $p < 1/m$, 取有理数 r 使 $p < r \leq 1/m$, 则 $0 \leq \theta_p(T) \leq \theta_r(T) = 0$ 。对任意 $p > 1/m$, 取有理数 r 使 $1/m < r < p$, 则 $\theta_p(T) \geq \theta_r(T) > 0$ 。临界点 $p = 1/m$ 处开放簇为临界 Galton–Watson 过程, 仍几乎必然灭绝。

所以条件于原树不灭绝, $p_c(T) = \frac{1}{m}$ a.s.

□

考试时需要注意的地方

该 15 分题的完整得分点为:

(1) 定义 $\mathcal{A}_p = \{\theta_p(T) = 0\}$;

(2) 证明 $\mathcal{A}_p$ 为遗传性质;

(3) 识别开放簇为均值 pm 的新 Galton–Watson 过程;

(4) 分别处理 $pm \leq 1$ 与 $pm > 1$;

(5) 使用遗传性质条件 0–1 律;

(6) 对有理 p 取可数交;

(7) 使用 $p \mapsto \theta_p(T)$ 的单调性推广到全部实数 p 。

若只从退火均值 pm 写出 $p_c = 1/m$, 但未把结论升级为“给定几乎每棵不灭绝随机树”的 quenched 结论, 证明不完整。

16.9 分枝过程易错点

陈述	判断	正确说明
$\mathbb{E}Z_n = 1$ 表示过程不会灭绝	错	临界过程 $m = 1$ 仍几乎必然灭绝。
灭绝概率总是 1	错	仅在 $m \leq 1$ 的非退化情形成立; $m > 1$ 时 $q < 1$ 。
方程 $f(s) = s$ 的任意根都是灭绝概率	错	灭绝概率是 $[0, 1]$ 中的最小固定点。
$f^{\circ n}(s)$ 表示 $f(s)^n$	错	前者是函数复合迭代, 后者是普通幂。
Z_n/m^n 总在 L^1 中收敛	错	非负鞅只自动 a.s. 收敛; L^1 收敛需要 UI 或矩条件。
遗传性质要求“子树有性质则原树有性质”	错	定义使用反方向: 原树有性质推出所有根子树有性质。
退火渗流临界值自动等于 quenched 临界值	不完整	需要遗传 0–1 律及有理参数的可数交论证。
在 $p = 1/m$ 时开放簇有正概率无限	错	对应临界 Galton–Watson 过程, 非退化时几乎必然灭绝。

Galton-Watson 题

- (1) 写清递推 $Z_{n+1} = \sum_{j=1}^{Z_n} \xi_{j,n}$;
- (2) 给定 $\mathcal{F}_n$ 后使用条件独立;
- (3) 均值题写 $\mathbb{E}[Z_{n+1} | \mathcal{F}_n] = mZ_n$;
- (4) 生成函数题写 $\mathbb{E}[s^{Z_{n+1}} | \mathcal{F}_n] = f(s)^{Z_n}$;
- (5) 灭绝题使用 $\mathbb{P}(Z_n = 0) = f^{\circ n}(0)$;
- (6) 固定点数使用 $g = f - \text{id}$, $g(0), g(1), g'(1), g''$;
- (7) 随机树性质题判断是否为 inherited;
- (8) 渗流题先求稀疏化后代生成函数 $f_p(s) = f(1 - p + ps)$.

一些需要记忆的内容

- (1) 为什么 $\mathbb{E}[s^{Z_{n+1}} | \mathcal{F}_n] = f(s)^{Z_n}$?
- (2) 灭绝概率为什么是最小固定点, 而不只是某个固定点?
- (3) $m = 1$ 时为什么仍几乎必然灭绝?
- (4) $W_n = Z_n/m^n$ 为什么是鞅?
- (5) 遗传性质条件 0-1 律中为什么有 $r \leq f(r)$?
- (6) 为什么灭绝事件一定包含在任意遗传性质中?
- (7) 渗流后代生成函数为什么是 $f(1 - p + ps)$?
- (8) 从固定有理 p 的结论推广到全部实数 p 时, 为何必须使用单调性?



第二部分

数理统计



第十七章 统计模型、参数、统计量与随机样本

17.1 考纲定位与重要性

重点

重要性等级：A 级。

本章中的定义本身通常不是单独的高分证明题，但它们是后续充分性、估计、检验、Bayes 决策和渐近理论的语言基础。资格考试中大量失分并非来自计算错误，而是来自以下对象混淆：参数、参数化、统计量、估计量、估计值、抽样分布。

【必须会完整证明】：

- 样本方差无偏性的证明；
- 正态总体下样本均值与样本方差独立的证明；
- 次序统计量密度的证明。

【必须会熟练应用】：

- 写出随机样本的联合密度或联合质量函数；
- 判断一个表达式是否为统计量；
- 区分精确抽样分布与渐近分布；
- 正确使用 n 分母与 $n-1$ 分母的样本方差。

17.2 统计模型、参数化与可识别性

定义 17.1 (统计模型). 设观测随机元素 $X : \Omega \rightarrow \mathcal{X}$ 的分布未知，但已知属于某个概率分布族 $\mathcal{P} = \{P : P \text{ 是 } \mathcal{X} \text{ 上的概率分布}\}$ 。称 $(\mathcal{X}, \mathcal{A}, \mathcal{P})$ 为一个统计模型。

若存在参数空间 Θ 以及映射 $\theta \mapsto P_\theta$, $\theta \in \Theta$, 使 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, 则称 $\theta \mapsto P_\theta$ 为该模型的一个参数化。

定义 17.2 (可识别参数化). 参数化 $\theta \mapsto P_\theta$ 称为可识别的 (identifiable), 若

$$P_{\theta_1} = P_{\theta_2} \implies \theta_1 = \theta_2. \quad (17.1)$$

前提条件检查

可识别性不能省略。

若存在 $\theta_1 \neq \theta_2$ 但 $P_{\theta_1} = P_{\theta_2}$, 则即使获得无限多观测, 也无法仅由数据区分 θ_1 与 θ_2 。此时:

- 参数化本身不是一一对应的；
- 某些参数分量可能不是分布的可识别函数；
- 相合估计通常不可能同时对两个不可区分参数值成立。

定义 17.3 (参数). 参数是定义在模型 $\mathcal{P}$ 上的一个函数 $\psi : \mathcal{P} \rightarrow \Psi$ 。在可识别参数模型 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ 中,

通常将参数写为 $\psi(\theta) = \psi(P_\theta)$ 。

参数可以是：

- 标量，例如均值 $\mu(P) = \int x P(\mathrm{d}x)$;
- 向量，例如 (μ, σ^2) ;
- 函数，例如分布函数 $F_P(x) = P((-\infty, x])$;
- 集合或其他数学对象。

17.3 统计量、估计量与估计值

定义 17.4 (统计量). 设样本空间为 $(\mathcal{X}, \mathcal{A})$ 。若 $T : \mathcal{X} \longrightarrow \mathcal{T}$ 是可测函数，并且其定义中不含未知参数，则 $T(X)$ 称为统计量 (statistic)。

定义 17.5 (抽样分布). 统计量 $T(X)$ 在 P_θ 下的分布 $\mathcal{L}_\theta(T)$ 称为 T 的抽样分布 (sampling distribution)。

定义 17.6 (估计量与估计值). 若统计量 $\hat{\psi} = \delta(X)$ 被用来估计参数 $\psi(\theta)$ ，则称 $\hat{\psi}$ 为估计量。

观测到具体数据 $X = x$ 后得到的数值 $\hat{\psi}(x) = \delta(x)$ 称为估计值。

概念比较		
对象	数学本质	例子
参数	分布 P 的函数，未知但非随机	μ, σ^2, p, F
参数化	$\theta \mapsto P_\theta$ 的索引方式	$\theta = (\mu, \sigma^2)$
统计量	不含未知参数的数据函数	$\bar{X}, S^2, X_{(n)}$
估计量	用于估计参数的统计量	$\hat{\mu} = \bar{X}$
估计值	代入实际数据后的数值	$\bar{x} = 3.17$
抽样分布	统计量在重复抽样下的分布	$\bar{X} \sim N(\mu, \sigma^2/n)$

考试时需要注意的地方

下列表达式不是统计量： $\frac{\bar{X}-\mu}{S/\sqrt{n}}$ ，因为其中含有未知参数 μ 。
但是在讨论其在真实参数值下的分布时，它是一个随机变量，并可作为枢轴量 (pivot)。
下列表达式是统计量： $\frac{\bar{X}-\mu_0}{S/\sqrt{n}}$ ，只要 μ_0 是检验问题中给定的已知常数。

17.4 随机样本

定义 17.7 (随机样本). 若 $X_1, \dots, X_n$ 相互独立且具有共同分布 P_θ ，则称其为来自 P_θ 的容量为 n 的随机样本，记作 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} P_\theta$ 。

若每个 X_i 有密度或质量函数 $f(x | \theta)$, 则联合密度或联合质量函数为

$$f_n(x_1, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta). \quad (17.2)$$

前提条件检查

“同分布”不能代替“独立同分布”。

若 $X_1, \dots, X_n$ 仅同分布但相关, 则:

- 联合密度通常不能分解为乘积;
- $\text{Var}(\bar{X}) \neq \frac{\sigma^2}{n}$ 一般不成立;
- 标准似然、Fisher 信息相加和经典中心极限定理可能失效。

17.5 经验分布函数与样本矩

定义 17.8 (经验分布函数). 随机样本 $X_1, \dots, X_n$ 的经验分布函数定义为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}, \quad x \in \mathbb{R}. \quad (17.3)$$

对固定 x , $nF_n(x) \sim \text{Bin}(n, F(x))$ 。因此

$$\mathbb{E}F_n(x) = F(x), \quad \text{Var}(F_n(x)) = \frac{F(x)(1 - F(x))}{n}. \quad (17.4)$$

定义 17.9 (样本原点矩与样本中心矩). 第 k 阶样本原点矩定义为

$$M_{k,n} = \frac{1}{n} \sum_{i=1}^n X_i^k. \quad (17.5)$$

第 k 阶样本中心矩定义为

$$\widetilde{M}_{k,n} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k. \quad (17.6)$$

若 $\mathbb{E}|X|^k < \infty$, 则强大数律给出 $M_{k,n} \xrightarrow{\text{a.s.}} \mathbb{E}X^k$ 。

17.6 样本均值与样本方差

定义 17.10 (样本均值).

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i. \quad (17.7)$$

定义 17.11 (样本方差). 本讲义全文将

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (17.8)$$



称为样本方差。

同时记

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2 \quad (17.9)$$

为经验方差或使用分母 n 的样本方差。

引理 17.12 (离差平方和分解). 对任意实数 $x_1, \dots, x_n$ 和任意 $a \in \mathbb{R}$,

$$\sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - a)^2. \quad (17.10)$$

因此 $\sum_{i=1}^n (x_i - a)^2$ 在 $a = \bar{x}$ 处达到唯一最小值。

证明. 写成 $x_i - a = (x_i - \bar{x}) + (\bar{x} - a)$. 展开后交叉项为 $2(\bar{x} - a) \sum_{i=1}^n (x_i - \bar{x}) = 0$. □

取 $a = 0$ 得到常用计算恒等式

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2. \quad (17.11)$$

定理 17.13 (样本均值与样本方差的基本矩). 设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} P$, 且 $\mathbb{E}X_1 = \mu$, $\text{Var}(X_1) = \sigma^2 < \infty$. 则

$$\mathbb{E}\bar{X} = \mu, \quad (17.12)$$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad (17.13)$$

以及

$$\mathbb{E}S^2 = \sigma^2. \quad (17.14)$$

相应地,

$$\mathbb{E}\hat{\sigma}_n^2 = \frac{n-1}{n} \sigma^2. \quad (17.15)$$

证明. 前两式由线性性和独立性直接得到: $\mathbb{E}\bar{X} = \frac{1}{n} \sum_i \mathbb{E}X_i = \mu$, $\text{Var}(\bar{X}) = \frac{1}{n^2} \sum_i \text{Var}(X_i) = \frac{\sigma^2}{n}$.

使用 [定理 17.12](#), 取 $a = \mu$: $\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2$. 取期望: $n\sigma^2 = \mathbb{E} \sum_{i=1}^n (X_i - \bar{X})^2 + n \text{Var}(\bar{X})$. 代入 $n \text{Var}(\bar{X}) = \sigma^2$ 得到 $\mathbb{E} \sum_{i=1}^n (X_i - \bar{X})^2 = (n-1)\sigma^2$. 除以 $n-1$ 即得. □

命题 17.14 (样本方差的方差). 若进一步假设 $\mu_4 = \mathbb{E}[(X_1 - \mu)^4] < \infty$, 则

$$\text{Var}(S^2) = \frac{1}{n} \left[\mu_4 - \frac{n-3}{n-1} \sigma^4 \right]. \quad (17.16)$$

特别地, 若总体正态, 则 $\mu_4 = 3\sigma^4$, 所以

$$\text{Var}(S^2) = \frac{2\sigma^4}{n-1}. \quad (17.17)$$



证明思路

令 $Y_i = X_i - \mu$, $\bar{Y} = \bar{X} - \mu$ 。由 $(n-1)S^2 = \sum_i Y_i^2 - n\bar{Y}^2$, 平方并取期望。使用独立性、 $\mathbb{E}Y_i = 0$ 以及 $\mathbb{E}Y_i^2 = \sigma^2$, $\mathbb{E}Y_i^4 = \mu_4$ 整理同指标和异指标项即可得到 (17.16)。

定理 17.15 (样本均值的矩母函数). 若 X_1 的矩母函数 $M_X(t)$ 在零点邻域存在, 则

$$M_{\bar{X}}(t) = \left[M_X\left(\frac{t}{n}\right) \right]^n. \quad (17.18)$$

证明. 由独立性,

$$\mathbb{E}e^{t\bar{X}} = \mathbb{E} \prod_{i=1}^n e^{(t/n)X_i} = \prod_{i=1}^n \mathbb{E}e^{(t/n)X_i}.$$

□

考试时需要注意的地方

期望的可加性不需要独立性: $\mathbb{E} \sum_i X_i = \sum_i \mathbb{E}X_i$ 。

方差的可加性需要零协方差; 在随机样本中由独立性保证: $\text{Var}(\sum_i X_i) = \sum_i \text{Var}(X_i)$ 。

样本均值与方差基础题

- (1) 先确认是否为 i.i.d. 样本;
- (2) 写出 $\mathbb{E}\bar{X} = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$;
- (3) 处理样本方差时先写离差分解;
- (4) 明确题目中的方差分母是 n 还是 $n-1$;
- (5) 若要求精确分布, 必须识别总体是否正态;
- (6) 非正态总体下不要擅自写 $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ 。



第十八章 常见分布总表与分布关系

18.1 全文统一参数化约定

Notations

(1) $\text{Exp}(\lambda)$ 使用率参数 $\lambda > 0$: $f(x) = \lambda e^{-\lambda x} \mathbf{1}_{\{x>0\}}$.

(2) $\Gamma(\alpha, \lambda)$ 使用形状-率参数:

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbf{1}_{\{x>0\}}, \quad \alpha, \lambda > 0. \quad (18.1)$$

[S-Lec] 和 [25S-Q8] 使用的形状-尺度参数 $\Gamma(\alpha, \theta)$ 满足 $\theta = \frac{1}{\lambda}$. 其密度为 $\frac{1}{\Gamma(\alpha)\theta^\alpha} x^{\alpha-1} e^{-x/\theta}$.

(3) $\text{Geom}(p)$ 主约定表示首次成功所需的试验次数: $\mathbb{P}(X = k) = p(1-p)^{k-1}$, $k = 1, 2, \dots$

若 $Y = X - 1$ 表示首次成功前的失败次数, 则 $\mathbb{P}(Y = k) = p(1-p)^k$, $k = 0, 1, \dots$

(4) $\text{NegBin}(r, p)$ 主约定表示第 r 次成功前的失败次数: $\mathbb{P}(X = k) = \binom{r+k-1}{k} p^r (1-p)^k$, $k = 0, 1, \dots$

(5) 正态分布写为 $N(\mu, \sigma^2)$, 第二个参数始终是方差。

(6) 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

为书写 CDF, 定义 $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-u^2/2} du$, $B_x(a, b) = \int_0^x t^{a-1} (1-t)^{b-1} dt$, $I_x(a, b) = \frac{B_x(a, b)}{B(a, b)}$, 以及 $\gamma(a, x) = \int_0^x t^{a-1} e^{-t} dt$, $P(a, x) = \frac{\gamma(a, x)}{\Gamma(a)}$ 。

18.2 离散分布核心公式表

分布	支持集与 pmf	均值与方差	PGF 或 MGF	CDF
Bernoulli(p)	$x \in \{0, 1\}$, $p^x (1-p)^{1-x}$, $0 \leq p \leq 1$	$\mathbb{E}X = p$, $\text{Var } X = p(1-p)$	$G_X(z) = 1-p+pz$, $M_X(t) = 1-p+pe^t$	$F(x) = \begin{cases} 0, & x < 0, \\ 1-p, & 0 \leq x < 1, \\ 1, & x \geq 1 \end{cases}$
Binomial(m, p)	$x = 0, \dots, m$, $\binom{m}{x} p^x (1-p)^{m-x}$	$\mathbb{E}X = mp$, $\text{Var } X = mp(1-p)$	$G_X(z) = (1-p+pz)^m$, $M_X(t) = (1-p+pe^t)^m$	$F(k) = \sum_{j=0}^{\lfloor k \rfloor} \binom{m}{j} p^j (1-p)^{m-j}$
Multinomial($m; p_1, \dots, p_K$)	$x_j \in \mathbb{Z}_{\geq 0}$, $\sum_j x_j = m$, $\frac{m!}{\prod_j x_j!} \prod_{j=1}^K p_j^{x_j}$	$\mathbb{E}X_j = mp_j$, $\text{Var } X_j = mp_j(1-p_j)$, $\text{Cov}(X_i, X_j) = -mp_i p_j$	联合 PGF: $G(\mathbf{z}) = \left(\sum_{j=1}^K p_j z_j \right)^m$	联合正交矩形概率由对允许的 $\mathbf{x}$ 求和得到
Geometric(p)	$k = 1, 2, \dots$, $p(1-p)^{k-1}$	$\mathbb{E}X = \frac{1}{p}$, $\text{Var } X = \frac{1-p}{p^2}$	$G_X(z) = \frac{pz}{1-(1-p)z}$, $M_X(t) = \frac{pe^t}{1-(1-p)e^t}$	对 $k \geq 1$, $F(k) = 1 - (1-p)^{\lfloor k \rfloor}$
Negative Binomial NegBin(r, p)	$k = 0, 1, \dots$, $\binom{r+k-1}{k} p^r (1-p)^k$	$\mathbb{E}X = \frac{r(1-p)}{p}$, $\text{Var } X = \frac{r(1-p)}{p^2}$	$G_X(z) = \left[\frac{p}{1-(1-p)z} \right]^r$	$F(k) = \sum_{j=0}^{\lfloor k \rfloor} \binom{r+j-1}{j} p^r (1-p)^j$
Poisson(λ)	$k = 0, 1, \dots$, $e^{-\lambda} \frac{\lambda^k}{k!}$, $\lambda > 0$	$\mathbb{E}X = \lambda$, $\text{Var } X = \lambda$	$G_X(z) = e^{\lambda(z-1)}$, $M_X(t) = e^{\lambda(e^t-1)}$	$F(k) = e^{-\lambda} \sum_{j=0}^{\lfloor k \rfloor} \frac{\lambda^j}{j!}$
Discrete Uniform(N)	$k = 1, \dots, N$, $\mathbb{P}(X = k) = \frac{1}{N}$	$\mathbb{E}X = \frac{N+1}{2}$, $\text{Var } X = \frac{N^2-1}{12}$	$M_X(t) = \frac{1}{N} \sum_{k=1}^N e^{tk}$	$F(x) = \frac{\lfloor x \rfloor}{N}$ 在 $1 \leq x < N$, 并在端点截断到 $[0, 1]$

分布	支持集与 pmf	均值与方差	PGF 或 MGF	CDF
Hypergeometric (N, M, m)	总体 N 个, 其中 M 个成功, 无放回 抽 m 个: $\mathbb{P}(X = k) = \frac{\binom{M}{k} \binom{N-M}{m-k}}{\binom{N}{m}}$	$\mathbb{E}X = \frac{mM}{N}$, $\text{Var } X = m \frac{M}{N} \left(1 - \frac{M}{N}\right) \frac{N-m}{N-1}$	一般无简洁初等 MGF; 用有 限和计算	对允许的 $j \leq k$ 累加 pmf

18.3 连续分布核心公式表

分布	支持集与 pdf	均值与方差	MGF、CF 或矩	CDF
Uniform(a, b)	$a < x < b$, $f(x) = \frac{1}{b-a}$	$\mathbb{E}X = \frac{a+b}{2}$, $\text{Var } X = \frac{(b-a)^2}{12}$	$M_X(t) = \frac{e^{bt} - e^{at}}{(b-a)t}$, $t \neq 0$	$F(x) = \begin{cases} 0, & x \leq a, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & x \geq b \end{cases}$
Exponential(λ)	$x > 0$, $f(x) = \lambda e^{-\lambda x}$	$\mathbb{E}X = \frac{1}{\lambda}$, $\text{Var } X = \frac{1}{\lambda^2}$	$M_X(t) = \frac{\lambda}{\lambda - t}$, $t < \lambda$	$F(x) = 1 - e^{-\lambda x}$, $x \geq 0$
Gamma(α, λ)	$x > 0$, $f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$	$\mathbb{E}X = \frac{\alpha}{\lambda}$, $\text{Var } X = \frac{\alpha}{\lambda^2}$	$M_X(t) = \left(\frac{\lambda}{\lambda - t}\right)^\alpha$, $t < \lambda$	$F(x) = P(\alpha, \lambda x)$
Beta(α, β)	$0 < x < 1$, $f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}$	$\mathbb{E}X = \frac{\alpha}{\alpha+\beta}$, $\text{Var } X = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$	$\mathbb{E}X^k = \frac{(\alpha)_k}{(\alpha+\beta)_k}$, $M_X(t) = {}_1F_1(\alpha; \alpha+\beta; t)$	$F(x) = I_x(\alpha, \beta)$
Normal(μ, σ^2)	$x \in \mathbb{R}$, $f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)}$	$\mathbb{E}X = \mu$, $\text{Var } X = \sigma^2$	$M_X(t) = e^{i\mu t + \sigma^2 t^2/2}$, $\varphi_X(t) = e^{i\mu t - \sigma^2 t^2/2}$	$F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$
Lognormal(μ, σ^2)	$x > 0$, $f(x) = \frac{1}{x\sigma\sqrt{2\pi}} e^{-(\log x - \mu)^2/(2\sigma^2)}$	$\mathbb{E}X = e^{\mu + \sigma^2/2}$, $\text{Var } X = (e^{\sigma^2} - 1)e^{2\mu + \sigma^2}$	对 $k \in \mathbb{R}$, $\mathbb{E}X^k = e^{k\mu + k^2\sigma^2/2}$; 对任意 $t > 0$, MGF 发散	$F(x) = \Phi\left(\frac{\log x - \mu}{\sigma}\right)$
Chi-square(ν)	$x > 0$, $f(x) = \frac{x^{\nu/2-1} e^{-x/2}}{2^{\nu/2} \Gamma(\nu/2)}$	$\mathbb{E}X = \nu$, $\text{Var } X = 2\nu$	$M_X(t) = (1 - 2t)^{-\nu/2}$, $t < 1/2$	$F(x) = P(\nu/2, x/2)$
Student t_ν	$x \in \mathbb{R}$, $f(x) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi}\Gamma(\nu/2)} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}$	$\mathbb{E}X = 0$ ($\nu > 1$), $\text{Var } X = \frac{\nu}{\nu-2}$ ($\nu > 2$)	非零点邻域内 MGF 不存在; 当 $\nu = 1$ 为标准 Cauchy	记作 $F_{t_\nu}(x)$
F_{ν_1, ν_2}	$x > 0$, $f(x) = \frac{(\nu_1/\nu_2)^{\nu_1/2}}{B(\nu_1/2, \nu_2/2)} \frac{x^{\nu_1/2-1}}{(1+\nu_1 x/\nu_2)^{(\nu_1+\nu_2)/2}}$	$\mathbb{E}X = \frac{\nu_2}{\nu_2-2}$, $\nu_2 > 2$, $\text{Var } X = \frac{2\nu_2^2(\nu_1+\nu_2-2)}{\nu_1(\nu_2-2)^2(\nu_2-4)}$, $\nu_2 > 4$	正参数 MGF 不存在	$F(x) = I_{\frac{\nu_1 x}{\nu_1 x + \nu_2}}\left(\frac{\nu_1}{2}, \frac{\nu_2}{2}\right)$
Cauchy(x_0, γ)	$x \in \mathbb{R}$, $f(x) = \frac{1}{\pi\gamma} \frac{1}{1+((x-x_0)/\gamma)^2}$	通常意义下均值、方差均不存在	$\varphi_X(t) = e^{ix_0 t - \gamma t }$; MGF 不存在	$F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{x-x_0}{\gamma}\right)$
Laplace(μ, b)	$x \in \mathbb{R}$, $f(x) = \frac{1}{2b} e^{- x-\mu /b}$	$\mathbb{E}X = \mu$, $\text{Var } X = 2b^2$	$M_X(t) = \frac{e^{i\mu t}}{1-b^2 t^2}$, $ t < 1/b$	$F(x) = \begin{cases} \frac{1}{2} e^{(x-\mu)/b}, & x \leq \mu, \\ 1 - \frac{1}{2} e^{-(x-\mu)/b}, & x > \mu \end{cases}$
Pareto(x_m, α)	$x \geq x_m > 0$, $f(x) = \alpha x_m^\alpha x^{-\alpha-1}$	$\mathbb{E}X = \frac{\alpha x_m}{\alpha-1}$, $\alpha > 1$, $\text{Var } X = \frac{\alpha x_m^2}{(\alpha-1)^2(\alpha-2)}$, $\alpha > 2$	$\mathbb{E}X^k = \frac{\alpha x_m^k}{\alpha-k}$, $k < \alpha$; 正参数 MGF 不存在	$F(x) = 1 - \left(\frac{x_m}{x}\right)^\alpha$

18.4 分布之间的核心关系

定理 18.1 (Bernoulli、Binomial 与 Multinomial). (1) 若 $X_i \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$, 则 $\sum_{i=1}^m X_i \sim \text{Bin}(m, p)$.
(2) 若每次试验有 K 类结果, 概率为 $p_1, \dots, p_K$, 则各类计数向量服从 $\text{Multinomial}(m; p_1, \dots, p_K)$.
(3) 若 $(N_1, \dots, N_K) \sim \text{Multinomial}(m; p_1, \dots, p_K)$, 则任意合并若干类别后的新计数仍为多项分布。

定理 18.2 (几何与负二项). 设 $G_1, \dots, G_r \stackrel{\text{iid}}{\sim} \text{Geom}(p)$, 其中 G_j 表示相邻成功之间所需的试验次数。则 $G_1 + \dots + G_r$ 表示第 r 次成功出现的试验序号, 且 $G_1 + \dots + G_r - r \sim \text{NegBin}(r, p)$ 。

定理 18.3 (Poisson 可加性). 若 $X_i \sim \text{Poisson}(\lambda_i)$ 相互独立, 则 $\sum_{i=1}^m X_i \sim \text{Poisson}(\sum_{i=1}^m \lambda_i)$ 。

定理 18.4 (指数和 Gamma 可加性). 若 $X_i \sim \Gamma(\alpha_i, \lambda)$ 相互独立且具有共同率参数 λ , 则

$$\sum_{i=1}^m X_i \sim \Gamma\left(\sum_{i=1}^m \alpha_i, \lambda\right). \quad (18.2)$$

特别地, m 个独立 $\text{Exp}(\lambda)$ 之和服从 $\Gamma(m, \lambda)$ 。

证明. 矩母函数相乘: $\prod_{i=1}^m \left(\frac{\lambda}{\lambda-t}\right)^{\alpha_i} = \left(\frac{\lambda}{\lambda-t}\right)^{\sum_{i=1}^m \alpha_i}$. □

定理 18.5 (Gamma-Beta 关系). 设 $U \sim \Gamma(\alpha, \lambda)$, $V \sim \Gamma(\beta, \lambda)$, $U \perp V$ 。定义 $R = \frac{U}{U+V}$, $S = U + V$ 。则

$$R \sim \text{Beta}(\alpha, \beta), \quad (18.3)$$

$$S \sim \Gamma(\alpha + \beta, \lambda), \quad (18.4)$$

且

$$R \perp S. \quad (18.5)$$

证明. 反变换为 $u = rs$, $v = (1-r)s$, 其中 $0 < r < 1$, $s > 0$ 。Jacobian 为 $\left|\frac{\partial(u,v)}{\partial(r,s)}\right| = s$ 。因此

$$\begin{aligned} f_{R,S}(r,s) &= \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} (rs)^{\alpha-1} ((1-r)s)^{\beta-1} e^{-\lambda s} \\ &= \left[\frac{r^{\alpha-1}(1-r)^{\beta-1}}{B(\alpha, \beta)} \right] \left[\frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha+\beta)} s^{\alpha+\beta-1} e^{-\lambda s} \right]. \end{aligned}$$

联合密度分解为 r 的 Beta 密度与 s 的 Gamma 密度之积。 □

推论 18.6 (卡方比值). 若 $U \sim \chi_{\nu_1}^2$, $V \sim \chi_{\nu_2}^2$, $U \perp V$, 则 $\frac{U}{U+V} \sim \text{Beta}\left(\frac{\nu_1}{2}, \frac{\nu_2}{2}\right)$ 。

定理 18.7 (t 与 F 的构造). 若 $Z \sim N(0, 1)$, $U \sim \chi_{\nu}^2$, $Z \perp U$, 则

$$T = \frac{Z}{\sqrt{U/\nu}} \sim t_{\nu}. \quad (18.6)$$

若 $U_1 \sim \chi_{\nu_1}^2$, $U_2 \sim \chi_{\nu_2}^2$, $U_1 \perp U_2$, 则

$$F = \frac{U_1/\nu_1}{U_2/\nu_2} \sim F_{\nu_1, \nu_2}. \quad (18.7)$$

并且

$$T_{\nu}^2 \sim F_{1, \nu}, \quad (18.8)$$

$$F_{\nu_1, \nu_2}^{-1} \sim F_{\nu_2, \nu_1}. \quad (18.9)$$




18.5 推断结构、充分统计量与共轭先验速查

抽样模型	未知参数	典型充分统计量	常用共轭先验	常用近似或关系
Bernoulli/Binomial	p	$\sum_i X_i$	$p \sim \text{Beta}(a, b)$	大样本正态; p 小、 np 有限时 Poisson
Multinomial	$(p_1, \dots, p_K)$	类别计数 $(N_1, \dots, N_K)$	Dirichlet	多元正态近似
Geometric/Negative Binomial	p	$\sum_i X_i$ 或总失败数	Beta	负二项为几何变量之和
Poisson	λ	$\sum_i X_i$	Gamma	大 λ 时 $N(\lambda, \lambda)$ 近似
Exponential	率 λ	$\sum_i X_i$	Gamma	样本和为 Gamma; 最小值率为 $n\lambda$
Gamma	率 λ , 形状 α 已知	$\sum_i X_i$	Gamma	大形状时正态近似
Gamma	(α, λ) 均未知	$(\sum_i \log X_i, \sum_i X_i)$	一般使用二维自然共轭族	两参数指数族
Beta	(α, β)	$(\sum_i \log X_i, \sum_i \log(1 - X_i))$	二维自然共轭族	大参数时正态近似
Normal	μ, σ^2 已知	$\sum_i X_i$	Normal	精确正态
Normal	σ^2, μ 已知	$\sum_i (X_i - \mu)^2$	Inverse-Gamma 或精度的 Gamma	卡方精确分布
Normal	(μ, σ^2)	$(\sum_i X_i, \sum_i X_i^2)$ $(\bar{X}, S^2)$	等价于 Normal-Inverse-Gamma	t, χ^2, F
Uniform(0, θ)	θ	$X_{(n)}$	Pareto 型先验	非正则; $n(\theta - X_{(n)})$ 有非正态极限
Pareto(x_m, α)	α, x_m 已知	$\sum_i \log(X_i/x_m)$	Gamma	对数变换后为指数分布
Shifted exponential	(λ, α)	$(X_{(1)}, \sum_i X_i)$	依参数化而定	参数依赖支持集; 非正则

18.6 参数化易错点

分布	两种常见约定	换算及风险
Gamma	率参数: $\Gamma(\alpha, \lambda)$ 尺度参数: $\Gamma(\alpha, \theta)$	$\lambda = 1/\theta$ 。均值分别写作 α/λ 或 $\alpha\theta$ 。不得把两种密度混用。
Exponential	率 λ ; 均值或尺度 θ	$\theta = 1/\lambda$ 。若密度写作 $\lambda e^{-\lambda x}$, 则参数是率。
Geometric	试验次数 $1, 2, \dots$; 失败次数 $0, 1, \dots$	两变量相差 1。均值分别为 $1/p, (1 - p)/p$ 。
Negative Binomial	第 r 次成功前的失败数; 第 r 次成功所在试验序号	两者相差 r 。写答案时必须说明支持集。
Normal	$N(\mu, \sigma^2)$; 少数文献用第二参数表示标准差	本讲义第二参数始终表示方差。



分布	两种常见约定	换算及风险
样本方差	分母 $n-1$; 分母 n	前者无偏; 后者是经验分布的 plug-in 方差, 偏差为 $-\sigma^2/n$ 。

18.7 历年题型: Uniform 和的四阶矩与分布

往年真题

[24F-Q1, 10 分]

设 $U_1, U_2, \dots \stackrel{\text{iid}}{\sim} \text{Unif}(0, 1)$, $S_n = \sum_{i=1}^n U_i$ 。

- (1) 计算 $\mathbb{E}S_n^4$;
- (2) 求 S_3 的分布。

解: 对 $U \sim \text{Unif}(0, 1)$, $\mathbb{E}U^k = \frac{1}{k+1}$ 。展开 $(\sum_{i=1}^n U_i)^4$ 并按指标重合类型分类:

$$\mathbb{E}S_n^4 = n\mathbb{E}U^4 + 4n(n-1)\mathbb{E}U^3\mathbb{E}U + 3n(n-1)(\mathbb{E}U^2)^2 + 6n(n-1)(n-2)\mathbb{E}U^2(\mathbb{E}U)^2 + n(n-1)(n-2)(n-3)(\mathbb{E}U)^4.$$

代入 $\mathbb{E}U = \frac{1}{2}$, $\mathbb{E}U^2 = \frac{1}{3}$, $\mathbb{E}U^3 = \frac{1}{4}$, $\mathbb{E}U^4 = \frac{1}{5}$, 得到

$$\mathbb{E}S_n^4 = \frac{n(15n^3 + 30n^2 + 5n - 2)}{240}. \quad (18.10)$$

下面求 S_3 的分布。对 $0 \leq s \leq 3$, $F_{S_3}(s) = \text{Vol} \{(u_1, u_2, u_3) \in [0, 1]^3 : u_1 + u_2 + u_3 \leq s\}$ 。由容斥原理,

$$F_{S_3}(s) = \frac{1}{6} \sum_{k=0}^{\lfloor s \rfloor} (-1)^k \binom{3}{k} (s-k)^3, \quad 0 \leq s \leq 3. \quad (18.11)$$

$$\text{即 } F_{S_3}(s) = \begin{cases} 0, & s < 0, \\ \frac{s^3}{6}, & 0 \leq s \leq 1, \\ \frac{s^3 - 3(s-1)^3}{6}, & 1 \leq s \leq 2, \\ 1 - \frac{(3-s)^3}{6}, & 2 \leq s \leq 3, \\ 1, & s \geq 3. \end{cases} \text{, 求导得到密度 } f_{S_3}(s) = \begin{cases} \frac{s^2}{2}, & 0 < s < 1, \\ \frac{-2s^2 + 6s - 3}{2}, & 1 < s < 2, \\ \frac{(3-s)^2}{2}, & 2 < s < 3, \\ 0, & \text{其他.} \end{cases} \quad \square$$

考试时需要注意的地方

四阶矩展开时应明确区分五类指标模式: 4 , $3+1$, $2+2$, $2+1+1$, $1+1+1+1$ 。只写最终多项式而不说明组合系数, 难以获得完整推导分。

18.8 历年题型：指数变量的随机 Poisson 次幂

往年真题

[25F-Q1, 10 分]

设 $X \sim \text{Exp}(1)$, $N \sim \text{Poisson}(\lambda)$, $X \perp N$ 。研究 X^N 的一阶矩和二阶矩。

解：给定 $N = n$, $\mathbb{E}[X^N | N = n] = \mathbb{E}X^n = \Gamma(n+1) = n!$ 。因此

$$\mathbb{E}X^N = \sum_{n=0}^{\infty} n! e^{-\lambda} \frac{\lambda^n}{n!} = e^{-\lambda} \sum_{n=0}^{\infty} \lambda^n.$$

故

$$\mathbb{E}X^N < \infty \iff 0 < \lambda < 1, \quad (18.12)$$

且在此条件下

$$\mathbb{E}X^N = \frac{e^{-\lambda}}{1-\lambda}. \quad (18.13)$$

对二阶矩, $\mathbb{E}[(X^N)^2] = \mathbb{E}[X^{2N}] = e^{-\lambda} \sum_{n=0}^{\infty} \frac{(2n)!}{n!} \lambda^n$ 。记第 n 项为 $a_n = \frac{(2n)!}{n!} \lambda^n$ 。则 $\frac{a_{n+1}}{a_n} = \lambda \frac{(2n+2)(2n+1)}{n+1} = 2\lambda(2n+1) \rightarrow \infty$ 。所以对每个 $\lambda > 0$, 级数均发散: $\mathbb{E}[X^{2N}] = \infty$ 。因此不存在 $\lambda > 0$ 使 $\text{Var}(X^N) < \infty$ 。□

考试时需要注意的地方

一阶矩有限不推出二阶矩有限。本题在 $0 < \lambda < 1$ 时具有 $\mathbb{E}X^N < \infty$, $\mathbb{E}(X^N)^2 = \infty$ 。



第十九章 指数族

19.1 考纲定位

重点

重要性等级：S 级。

指数族连接以下核心主题：充分统计量 $\longleftrightarrow$ 完全性 $\longleftrightarrow$ UMVU $\longleftrightarrow$ Fisher 信息 $\longleftrightarrow$ MLE 渐近理论 $\longleftrightarrow$ 共轭先验。

【必须会完整证明】：

- 对数配分函数一阶、二阶导数公式；
- i.i.d. 样本的自然统计量形式；
- 自然参数空间凸性。

【必须会熟练应用】：

- 将给定密度改写为自然形式；
- 识别自然参数、自然统计量和自然参数空间；
- 判断模型是否为满秩或曲指数族；
- 识别参数依赖支持集导致的非正则性；
- 写出共轭先验和后验更新。

19.2 一般形式与自然形式

定义 19.1 (k 参数指数族). 若一族密度或质量函数可写为

$$f(x | \theta) = h(x) \exp \left\{ \sum_{j=1}^k \eta_j(\theta) T_j(x) - B(\theta) \right\}, \quad x \in \mathcal{X}_0, \quad (19.1)$$

其中：

- $\mathcal{X}_0$ 不依赖于 θ ；
- $h, T_1, \dots, T_k$ 不依赖于 θ ；
- $\eta_1, \dots, \eta_k, B$ 不依赖于 x ；

则称其为 k 参数指数族。

定义 19.2 (自然指数族). 若直接以 $\eta = (\eta_1, \dots, \eta_k)^\top$ 为参数，并写成

$$f_\eta(x) = h(x) \exp \left\{ \eta^\top T(x) - A(\eta) \right\}, \quad (19.2)$$

则称其为自然形式或典范形式。



其中

$$A(\eta) = \log \int_{\mathcal{X}_0} h(x) e^{\eta^\top T(x)} \mu(\mathrm{d}x) \quad (19.3)$$

称为对数配分函数或 cumulant function。

定义 19.3 (自然参数空间).

$$\mathcal{H} = \left\{ \eta \in \mathbb{R}^k : \int_{\mathcal{X}_0} h(x) e^{\eta^\top T(x)} \mu(\mathrm{d}x) < \infty \right\} \quad (19.4)$$

称为自然参数空间。

19.3 自然参数空间的凸性

定理 19.4 (自然参数空间凸). 自然参数空间 $\mathcal{H}$ 是凸集, 且 $A(\eta)$ 是凸函数。

证明. 取 $\eta, \xi \in \mathcal{H}$, $0 < t < 1$ 。由 Hölder 不等式,

$$\begin{aligned} & \int h(x) e^{[t\eta + (1-t)\xi]^\top T(x)} \mu(\mathrm{d}x) \\ &= \int \left[h(x) e^{\eta^\top T(x)} \right]^t \left[h(x) e^{\xi^\top T(x)} \right]^{1-t} \mu(\mathrm{d}x) \\ &\leq \left[\int h(x) e^{\eta^\top T(x)} \mu(\mathrm{d}x) \right]^t \left[\int h(x) e^{\xi^\top T(x)} \mu(\mathrm{d}x) \right]^{1-t} < \infty. \end{aligned}$$

故 $t\eta + (1-t)\xi \in \mathcal{H}$ 。

对两边取对数: $A(t\eta + (1-t)\xi) \leq tA(\eta) + (1-t)A(\xi)$, 所以 A 凸。 □

19.4 对数配分函数的导数

定理 19.5 (均值与协方差公式). 设 η 位于 $\mathcal{H}$ 的内点, 并且可在积分号下对 η 求一阶、二阶导数。则

$$\nabla A(\eta) = \mathbb{E}_\eta[T(X)], \quad (19.5)$$

以及

$$\nabla^2 A(\eta) = \text{Cov}_\eta(T(X)). \quad (19.6)$$

逐项写为

$$\frac{\partial A(\eta)}{\partial \eta_j} = \mathbb{E}_\eta[T_j(X)], \quad (19.7)$$

$$\frac{\partial^2 A(\eta)}{\partial \eta_j \partial \eta_\ell} = \text{Cov}_\eta(T_j(X), T_\ell(X)). \quad (19.8)$$



证明. 记 $Z(\eta) = \int h(x)e^{\eta^\top T(x)}\mu(\mathrm{d}x)$, $A(\eta) = \log Z(\eta)$ 。则

$$\begin{aligned}\frac{\partial A}{\partial \eta_j} &= \frac{1}{Z(\eta)} \frac{\partial Z(\eta)}{\partial \eta_j} \\ &= \frac{\int T_j(x)h(x)e^{\eta^\top T(x)}\mu(\mathrm{d}x)}{Z(\eta)} \\ &= \int T_j(x)f_\eta(x)\mu(\mathrm{d}x) \\ &= \mathbb{E}_\eta T_j(X).\end{aligned}$$

再次求导:

$$\begin{aligned}\frac{\partial^2 A}{\partial \eta_j \partial \eta_\ell} &= \frac{\partial}{\partial \eta_\ell} \mathbb{E}_\eta T_j(X) \\ &= \mathbb{E}_\eta [T_j(X)T_\ell(X)] - \mathbb{E}_\eta T_j(X)\mathbb{E}_\eta T_\ell(X).\end{aligned}$$

□

推论 19.6 (自然统计量的矩母函数). 若 $\eta + s \in \mathcal{H}$, 则

$$\mathbb{E}_\eta e^{s^\top T(X)} = \exp\{A(\eta + s) - A(\eta)\}. \quad (19.9)$$

证明.

$$\begin{aligned}\mathbb{E}_\eta e^{s^\top T(X)} &= \int h(x)e^{(\eta+s)^\top T(x)-A(\eta)}\mu(\mathrm{d}x) \\ &= e^{A(\eta+s)-A(\eta)}.\end{aligned}$$

□

前提条件检查

导数公式不能无条件使用。

必须核查:

- (1) 参数位于自然参数空间内点;
- (2) 相应矩有限;
- (3) 可以交换微分与积分;
- (4) 支持集不随参数变化, 或边界项已被正确处理。

19.5 i.i.d. 样本的指数族结构

定理 19.7 (样本的自然统计量). 设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} f_\eta(x) = h(x)e^{\eta^\top T(x)-A(\eta)}$ 。则联合密度为

$$f_\eta(\mathbf{x}) = \left[\prod_{i=1}^n h(x_i) \right] \exp \left\{ \eta^\top \sum_{i=1}^n T(x_i) - nA(\eta) \right\}. \quad (19.10)$$

因此自然统计量为

$$T_n = \sum_{i=1}^n T(X_i). \quad (19.11)$$



证明. 直接将单个密度相乘: $\prod_{i=1}^n e^{\eta^\top T(x_i) - A(\eta)} = e^{\eta^\top \sum_i T(x_i) - nA(\eta)}$ 。由因子分解形式, 样本对 η 的全部似然依赖仅通过 T_n 。充分性的严格定理将在下一部分完整证明。□

推论 19.8. $\mathbb{E}_\eta T_n = n\nabla A(\eta)$, $\text{Cov}_\eta(T_n) = n\nabla^2 A(\eta)$ 。

19.6 常见模型的自然形式

模型	自然参数	自然统计量	$A(\eta)$	自然参数空间
Bernoulli(p)	$\eta = \log \frac{p}{1-p}$	$T(x) = x$	$A(\eta) = \log(1 + e^\eta)$	$\eta \in \mathbb{R}$
Binomial(m, p)	$\eta = \log \frac{p}{1-p}$	$T(x) = x$	$A(\eta) = m \log(1 + e^\eta)$	$\eta \in \mathbb{R}$
Poisson(λ)	$\eta = \log \lambda$	$T(x) = x$	$A(\eta) = e^\eta$	$\eta \in \mathbb{R}$
Geometric(p)	$\eta = \log(1 - p)$	$T(x) = x - 1$	$A(\eta) = -\log(1 - e^\eta)$	$\eta < 0$
Exponential(λ)	$\eta = -\lambda$	$T(x) = x$	$A(\eta) = -\log(-\eta)$	$\eta < 0$
Gamma(α, λ), α 已知	$\eta = -\lambda$	$T(x) = x$	$A(\eta) = -\alpha \log(-\eta)$	$\eta < 0$
Normal(μ, σ^2), σ^2 已知	$\eta = \frac{\mu}{\sigma^2}$	$T(x) = x$	$A(\eta) = \frac{\sigma^2 \eta^2}{2}$	$\eta \in \mathbb{R}$
Normal(μ, σ^2), 二者未知	$\eta_1 = \frac{\mu}{\sigma^2}, \eta_2 = -\frac{1}{2\sigma^2}$	$T(x) = (x, x^2)^\top$	$A(\eta) = -\frac{\eta_1^2}{4\eta_2} + \frac{1}{2} \log \frac{\pi}{-\eta_2}$	$\eta_1 \in \mathbb{R}, \eta_2 < 0$
Beta(α, β)	$\eta_1 = \alpha - 1, \eta_2 = \beta - 1$	$T(x) = (\log x, \log(1 - x))^\top$	$A(\eta) = \log B(\eta_1 + 1, \eta_2 + 1)$	$\eta_1 > -1, \eta_2 > -1$
Gamma(α, λ), 二者未知	$\eta_1 = \alpha - 1, \eta_2 = -\lambda$	$T(x) = (\log x, x)^\top$	$A(\eta) = \log \Gamma(\eta_1 + 1) - (\eta_1 + 1) \log(-\eta_2)$	$\eta_1 > -1, \eta_2 < 0$
Multinomial	$\eta_j = \log \frac{p_j}{p_K}, j < K$	$T(x) = (x_1, \dots, x_{K-1})^\top$	$A(\eta) = m \log \left(1 + \sum_{j=1}^{K-1} e^{\eta_j} \right)$	$\eta \in \mathbb{R}^{K-1}$

19.7 满指数族与曲指数族

定义 19.9 (满指数族). 若自然参数 η 的取值集合包含 $\mathbb{R}^k$ 中的非空开集, 则称该指数族为满秩或满指数族。

定义 19.10 (曲指数族). 若原参数 $\theta \in \mathbb{R}^d$, 但自然统计量维数为 $k > d$, 且 $\eta = \eta(\theta)$ 只在 $\mathbb{R}^k$ 中的低维曲面上取值, 则称其为曲指数族。

例如 $X \sim N(\mu, \mu^2)$, $\mu > 0$, 可写成以 $T(X) = (X, X^2)$ 为自然统计量的二维指数形式, 但参数 μ 只有一维, 且自然参数满足确定的曲线关系。

考试时需要注意的地方

“参数只有一个”不代表自然充分统计量一定只有一维。

曲指数族可能具有: $\dim(\theta) < \dim(T)$ 。这会影响完全性和最小充分性结论。

19.8 参数依赖支持集与非正则模型

Uniform(0, θ) 不是本讲义约定下的正则指数族

$f(x | \theta) = \frac{1}{\theta} \mathbf{1}_{\{0 < x < \theta\}}$ 。指示函数 $\mathbf{1}_{\{x < \theta\}}$ 同时依赖 x 与 θ ，无法放入只依赖 x 的 $h(x)$ 中，且支持集随 θ 变化。

若错误地忽略支持边界，写 $\frac{\partial}{\partial \theta} \log f(X | \theta) = -\frac{1}{\theta}$ ，则 $\mathbb{E}_{\theta} \left[\frac{\partial}{\partial \theta} \log f(X | \theta) \right] = -\frac{1}{\theta} \neq 0$ 。这说明常规 score 均值为零公式失效。

类似的非正则模型包括： $\lambda e^{-\lambda(x-\alpha)} \mathbf{1}_{\{x \geq \alpha\}}$ ，以及参数位于边界、密度不可微或 Fisher 信息发散的模型。

前提条件检查

有些文献允许把参数依赖支持集的模型称为“广义指数形式”；[S-Lec] 和本讲义采用正则指数族约定：支持集必须与参数无关。不得在同一证明中静默混用两种定义。

19.9 一般共轭先验

对自然指数族 $f_{\eta}(x) = h(x)e^{\eta^{\top}T(x)-A(\eta)}$ ，自然共轭先验写为

$$\pi(\eta | \tau, \nu) \propto \exp \left\{ \eta^{\top} \tau - \nu A(\eta) \right\} \mathbf{1}_{\{\eta \in \mathcal{H}\}}, \quad (19.12)$$

其中超参数必须使右侧可积。

观测样本 $x_1, \dots, x_n$ 后，

$$\begin{aligned} \pi(\eta | \mathbf{x}) &\propto \pi(\eta) \prod_{i=1}^n f_{\eta}(x_i) \\ &\propto \exp \left\{ \eta^{\top} \left(\tau + \sum_{i=1}^n T(x_i) \right) - (\nu + n) A(\eta) \right\}. \end{aligned}$$

因此后验超参数更新为

$$\tau_{\text{post}} = \tau + \sum_{i=1}^n T(x_i), \quad \nu_{\text{post}} = \nu + n. \quad (19.13)$$

识别指数族

- (1) 写出完整密度，包括支持集指示函数；
- (2) 将所有含参数的项放入指数；
- (3) 分离： $h(x)$, $T(x)$, $\eta(\theta)$, $A(\eta)$ ；
- (4) 检查支持集是否依赖参数；
- (5) 写出自然参数空间；
- (6) 对样本，将自然统计量替换为 $\sum_i T(X_i)$ ；
- (7) 若要求均值或方差，优先使用 ∇A , $\nabla^2 A$ ；
- (8) 若要求共轭后验，直接更新 τ, ν 。

一些需要记忆的内容

- (1) 自然参数空间为什么一定是凸集?
- (2) $A'(\eta)$ 和 $A''(\eta)$ 分别表示什么?
- (3) 二参数正态族的自然统计量是什么?
- (4) Beta 族的自然统计量为什么包含对数?
- (5) $\text{Uniform}(0, \theta)$ 为什么不是正则指数族?
- (6) 曲指数族与满指数族的区别是什么?
- (7) 一般自然共轭先验的后验超参数如何更新?



第二十章 正态总体的抽样理论

20.1 考纲定位

重点

重要性等级：S 级。

【必须会完整证明】：

$$\bar{X} \perp S^2, \bar{X} \sim N(\mu, \sigma^2/n), \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

【必须会熟练应用】：

- 构造 t 枢轴量；
- 构造方差的卡方枢轴量；
- 比较两个正态方差时构造 F 统计量；
- 使用正交变换或 Cochran 定理。

真题对应：[24F-Q10(a), 15 分题的一部分]。

20.2 正态样本分解定理

定理 20.1 (正态样本均值与方差). 设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$, $n \geq 2$ 。则：

(1)

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right); \quad (20.1)$$

(2)

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2; \quad (20.2)$$


(3)

$$\bar{X} \perp S^2. \quad (20.3)$$

证明. 定义标准化向量 $Z = \frac{1}{\sigma} \begin{pmatrix} X_1 - \mu \\ \vdots \\ X_n - \mu \end{pmatrix}$ 。则 $Z \sim N_n(0, I_n)$ 。

取一个 $n \times n$ 正交矩阵 H , 其第一行为 $\frac{1}{\sqrt{n}}(1, \dots, 1)$ 。令 $Y = HZ$ 。正交变换保持标准多元正态分布： $Y \sim N_n(0, I_n)$ 。因此 $Y_1, \dots, Y_n \stackrel{\text{iid}}{\sim} N(0, 1)$ 。

第一坐标为 $Y_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$ 。所以 $\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$, 得到 (20.1)。



由于 H 正交, $\sum_{i=1}^n Z_i^2 = \sum_{j=1}^n Y_j^2$ 。另一方面,

$$\begin{aligned} \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 &= \frac{1}{\sigma^2} \left[\sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2 \right] \\ &= \sum_{i=1}^n Z_i^2 - Y_1^2 \\ &= \sum_{j=2}^n Y_j^2. \end{aligned}$$

故 $\frac{(n-1)S^2}{\sigma^2} = \sum_{j=2}^n Y_j^2 \sim \chi_{n-1}^2$ 。

最后, $\bar{X}$ 仅是 Y_1 的函数, 而 S^2 仅是 $Y_2, \dots, Y_n$ 的函数。因 $Y_1, \dots, Y_n$ 相互独立, 故 $\bar{X} \perp\!\!\!\perp S^2$ 。 $\square$

前提条件检查

正态性是独立结论的关键。

对一般 i.i.d. 总体, 即使二阶矩有限, 通常只有 $\text{Cov}(\bar{X}, S^2)$ 可能在某些对称情形下为零, 但不能推出 $\bar{X} \perp\!\!\!\perp S^2$ 。

20.3 Cochran 定理框架

定理 20.2 (Cochran 定理). 设 $Z \sim N_n(0, I_n)$ 。设 $A_1, \dots, A_m$ 为对称半正定矩阵, 满足 $A_1 + \dots + A_m = I_n$, 并且 $\sum_{j=1}^m \text{rank}(A_j) = n$ 。则:

- (1) 每个 A_j 是正交投影矩阵;
- (2) 二次型 $Z^\top A_1 Z, \dots, Z^\top A_m Z$ 相互独立;
- (3) $Z^\top A_j Z \sim \chi_{\text{rank}(A_j)}^2$ 。

在样本均值与方差问题中, $P = \frac{1}{n} \mathbf{1}\mathbf{1}^\top$ 是投影到常数向量空间的秩一投影, $I - P$ 是投影到 $\{x : \mathbf{1}^\top x = 0\}$ 的秩 $n-1$ 投影。

于是 $Z^\top P Z = \frac{n(\bar{X} - \mu)^2}{\sigma^2} \sim \chi_1^2$, $Z^\top (I - P) Z = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$, 且二者独立。

20.4 Student t 分布

推论 20.3 (单样本 t 枢轴量). 在 定理 20.1 的条件下,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}. \quad (20.4)$$

证明. 令 $Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$, $U = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ 。且 $Z \perp\!\!\!\perp U$ 。于是 $T = \frac{Z}{\sqrt{U/(n-1)}}$ 。 $\square$

注 20.4. t_ν 分布关于零对称。随着 $\nu \rightarrow \infty$, $t_\nu \xrightarrow{d} N(0, 1)$ 。但有限自由度下其尾部比正态更厚。

20.5 卡方与 F 枢轴量

推论 20.5 (正态方差的卡方枢轴量).

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2. \quad (20.5)$$

推论 20.6 (两个独立正态样本的方差比). 若 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu_X, \sigma_X^2)$, $Y_1, \dots, Y_m \stackrel{\text{iid}}{\sim} N(\mu_Y, \sigma_Y^2)$, 且两组样本相互独立, 则

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F_{n-1, m-1}. \quad (20.6)$$

20.6 历年题答题模板: 证明 $\bar{X} \perp\!\!\!\perp S^2$

往年真题

[24F-Q10(a), 15 分题的一部分]

设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$. 证明 $\bar{X} \perp\!\!\!\perp S^2$.

试题举例

参考证明至少应出现:

- (1) 标准化: $Z_i = \frac{X_i - \mu}{\sigma}$;
- (2) 选择第一行是 $n^{-1/2}(1, \dots, 1)$ 的正交矩阵;
- (3) 说明正交变换后的坐标仍为独立标准正态;
- (4) 识别 $Y_1 = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}$;
- (5) 写出 $\frac{(n-1)S^2}{\sigma^2} = \sum_{j=2}^n Y_j^2$;
- (6) 由独立坐标的可测函数仍独立得到结论。

考试时需要注意的地方

仅计算 $\text{Cov}(\bar{X}, S^2) = 0$ 不足以证明独立。

只有在联合高斯向量的**线性分量**之间, 零协方差才直接推出独立; S^2 是二次函数, 不是高斯线性分量。正确证明必须使用正交分解或 Cochran 定理。

一些需要记忆的内容

- (1) 正态样本中 $\bar{X}$ 的精确分布是什么?
- (2) 为什么样本方差损失一个自由度?
- (3) $\bar{X}$ 与 S^2 的独立性在哪里使用了正态性?
- (4) t 统计量的分子和分母分别来自什么分布?
- (5) 两个独立正态样本的方差比服从什么分布?
- (6) T_ν^2 与哪个 F 分布同分布?

第二十一章 次序统计量、样本中位数与样本分位数

21.1 考纲定位

重点

重要性等级：S 级。

【必须会完整证明】：

- 第 k 个次序统计量的 CDF 与密度；
- 全部次序统计量的联合密度；
- 两个次序统计量的联合密度；
- 样本分位数相合性的基本证明。

【必须会熟练应用】：

- 极小值、极大值分布；
- Uniform 次序统计量与 Beta 分布；
- 给定极大值后的条件分布；
- 样本中位数与样本分位数；
- 离散分布中分位数相合性可能失效。

真题对应：[25S-Q1, 10 分], [26S-Q8, 15 分]。

21.2 次序统计量的定义

定义 21.1 (次序统计量). 设 $X_1, \dots, X_n$ 为随机样本。将样本值由小到大排列： $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 。称 $X_{(1)}, \dots, X_{(n)}$ 为次序统计量。

特别地， $X_{(1)} = \min_i X_i$, $X_{(n)} = \max_i X_i$ 。


考试时需要注意的地方

圆括号下标表示次序，而不是原样本编号： $X_{(2)}$ 是第二小样本值， X_2 是第二个抽到的观测。

21.3 第 k 个次序统计量的分布

定理 21.2 (次序统计量的 CDF). 设样本来自 CDF F 。则对任意分布，无论连续或离散，

$$\mathbb{P}(X_{(k)} \leq x) = \sum_{j=k}^n \binom{n}{j} F(x)^j [1 - F(x)]^{n-j}. \quad (21.1)$$



证明. 事件 $\{X_{(k)} \leq x\}$ 等价于至少有 k 个样本值不超过 x 。

令 $N_x = \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}$ 。则 $N_x \sim \text{Bin}(n, F(x))$ 。所以 $\mathbb{P}(X_{(k)} \leq x) = \mathbb{P}(N_x \geq k)$ 。 $\square$

定理 21.3 (次序统计量的密度). 若总体 CDF F 绝对连续, 密度为 f , 则

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1} [1 - F(x)]^{n-k} f(x). \quad (21.2)$$

证明. 对 (21.1) 求导. 也可直接进行小区间计数:

- $k-1$ 个样本落在 $(-\infty, x]$;
- 一个样本落在 $(x, x + dx]$;
- $n-k$ 个样本落在 $(x + dx, \infty)$ 。

相应排列数为 $\frac{n!}{(k-1)!\mathbf{1}!(n-k)!}$ 。 $\square$

21.4 极小值与极大值

推论 21.4 (极小值).

$$F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n. \quad (21.3)$$

若 F 有密度 f , 则

$$f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1} f(x). \quad (21.4)$$

推论 21.5 (极大值).

$$F_{X_{(n)}}(x) = F(x)^n. \quad (21.5)$$

若 F 有密度 f , 则


$$f_{X_{(n)}}(x) = nF(x)^{n-1} f(x). \quad (21.6)$$

21.5 全部次序统计量的联合密度

定理 21.6 (全部次序统计量). 若总体连续, 密度为 f , 则

$$f_{X_{(1)}, \dots, X_{(n)}}(x_1, \dots, x_n) = n! \prod_{j=1}^n f(x_j) \mathbf{1}_{\{x_1 < \dots < x_n\}}. \quad (21.7)$$

证明. 在连续分布下, 样本值相等的概率为零. 固定 $x_1 < \dots < x_n$. 无序样本 $(X_1, \dots, X_n)$ 可按任意一个排列落入 $(x_1, x_1 + dx_1] \times \dots \times (x_n, x_n + dx_n]$. 共有 $n!$ 个排列. 每个排列的密度贡献均为 $\prod_{j=1}^n f(x_j)$. 各排列事件互不相交, 故相加得到 $n!$ 倍。 $\square$



21.6 两个次序统计量的联合密度

定理 21.7 (第 i 与第 j 个次序统计量). 设 $1 \leq i < j \leq n$. 若总体连续, CDF 为 F 、密度为 f , 则对 $u < v$,

$$\begin{aligned} f_{X_{(i)}, X_{(j)}}(u, v) &= \frac{n!}{(i-1)!(j-i-1)!(n-j)!} F(u)^{i-1} [F(v) - F(u)]^{j-i-1} \\ &\quad \times [1 - F(v)]^{n-j} f(u) f(v). \end{aligned} \quad (21.8)$$

证明. 要求:

- $i-1$ 个样本小于 u ;
- 一个样本落在 du ;
- $j-i-1$ 个样本落在 (u, v) ;
- 一个样本落在 dv ;
- $n-j$ 个样本大于 v 。

多项排列数为 $\frac{n!}{(i-1)!1!(j-i-1)!1!(n-j)!}$ 。

□

推论 21.8 (极小值与极大值的联合密度). 对 $u < v$,

$$f_{X_{(1)}, X_{(n)}}(u, v) = n(n-1)[F(v) - F(u)]^{n-2} f(u) f(v). \quad (21.9)$$

21.7 Uniform 次序统计量与 Beta 分布

定理 21.9 (Uniform 次序统计量). 若 $U_1, \dots, U_n \stackrel{\text{iid}}{\sim} \text{Unif}(0, 1)$, 则

$$U_{(k)} \sim \text{Beta}(k, n-k+1). \quad (21.10)$$

因此

$$\mathbb{E}U_{(k)} = \frac{k}{n+1}, \quad (21.11)$$

$$\text{Var}(U_{(k)}) = \frac{k(n-k+1)}{(n+1)^2(n+2)}. \quad (21.12)$$


证明. 在 (21.2) 中取 $F(u) = u$, $f(u) = 1$, $0 < u < 1$. 得到 $f_{U_{(k)}}(u) = \frac{n!}{(k-1)!(n-k)!} u^{k-1} (1-u)^{n-k}$, 即 Beta 密度。 □

若 $X_i \sim \text{Unif}(a, b)$, 则

$$\frac{X_{(k)} - a}{b - a} \sim \text{Beta}(k, n-k+1). \quad (21.13)$$

命题 21.10 (Uniform 次序统计量协方差). 若 $1 \leq i \leq j \leq n$, 则

$$\text{Cov}(U_{(i)}, U_{(j)}) = \frac{i(n-j+1)}{(n+1)^2(n+2)}. \quad (21.14)$$



命题 21.11 (Uniform spacings). 定义 $D_1 = U_{(1)}$, $D_j = U_{(j)} - U_{(j-1)}$, $2 \leq j \leq n$, $D_{n+1} = 1 - U_{(n)}$ 。则

$$(D_1, \dots, D_{n+1}) \sim \text{Dirichlet}(1, \dots, 1). \quad (21.15)$$

21.8 历年真题完整解法：极小值、极大值及条件期望

往年真题

[25S-Q1, 10 分]

设 $U_1, U_2, \dots \stackrel{\text{iid}}{\sim} \text{Unif}(0, 1)$, 对 $n \geq 2$ 定义 $X_n = \min(U_1, \dots, U_n)$, $Y_n = \max(U_1, \dots, U_n)$ 。

(1) 求 (X_n, Y_n) 的联合分布；

(2) 计算 $\mathbb{E}[X_n | \sigma(Y_n)]$ 。

解：为简化记号，写 $X = X_n$, $Y = Y_n$ 。

第一问：联合 CDF

当 $0 \leq x < y \leq 1$ 时，

$$\begin{aligned} \mathbb{P}(X \leq x, Y \leq y) &= \mathbb{P}(Y \leq y) - \mathbb{P}(X > x, Y \leq y) \\ &= y^n - (y - x)^n. \end{aligned}$$

$$\text{完整地, } F_{X,Y}(x, y) = \begin{cases} 0, & x < 0 \text{ 或 } y < 0, \\ y^n - (y - x)^n, & 0 \leq x < y \leq 1, \\ y^n, & 0 \leq y \leq 1, x \geq y, \\ 1 - (1 - x)^n, & y > 1, 0 \leq x \leq 1, \\ 1, & y > 1, x > 1. \end{cases}$$

在内部区域 $0 < x < y < 1$ 求混合偏导，得到联合密度

$$f_{X,Y}(x, y) = n(n-1)(y-x)^{n-2} \mathbf{1}_{\{0 < x < y < 1\}}. \quad (21.16)$$

第二问：条件分布

极大值的密度为 $f_Y(y) = ny^{n-1}$, $0 < y < 1$ 。因此

$$\begin{aligned} f_{X|Y}(x | y) &= \frac{f_{X,Y}(x, y)}{f_Y(y)} \\ &= \frac{(n-1)(y-x)^{n-2}}{y^{n-1}}, \quad 0 < x < y. \end{aligned}$$

于是

$$\mathbb{E}[X | Y = y] = \frac{n-1}{y^{n-1}} \int_0^y x(y-x)^{n-2} dx.$$



令 $x = yu$:

$$\begin{aligned}\mathbb{E}[X | Y = y] &= (n-1)y \int_0^1 u(1-u)^{n-2} du \\ &= (n-1)y B(2, n-1) \\ &= \frac{y}{n}.\end{aligned}$$

故作为 $\sigma(Y_n)$ -可测随机变量,

$$\boxed{\mathbb{E}[X_n | \sigma(Y_n)] = \frac{Y_n}{n} \quad \text{a.s.}} \quad (21.17)$$

□

注 21.12. 给定 $Y_n = y$ 后, 其余 $n-1$ 个未达到最大值的样本, 在适当的条件分布意义下相当于来自 $\text{Unif}(0, y)$ 的样本。因此其最小值均值为 $\frac{y}{(n-1)+1} = \frac{y}{n}$ 。

考试时需要注意的地方

条件于连续随机变量 $Y_n = y$ 时, 不能使用 $\frac{\mathbb{P}(X_n \in A, Y_n = y)}{\mathbb{P}(Y_n = y)}$, 因为 $\mathbb{P}(Y_n = y) = 0$ 。必须使用条件密度或正则条件分布。

21.9 总体分位数与经验分位数

定义 21.13 (总体下分位数). 对 $0 < p < 1$, 定义

$$\xi_p = F^{-1}(p) = \inf\{x \in \mathbb{R} : F(x) \geq p\}. \quad (21.18)$$

定义 21.14 (经验下分位数). 定义

$$\hat{\xi}_p = F_n^{-1}(p) = \inf\{x : F_n(x) \geq p\}. \quad (21.19)$$

由于经验分布函数每次跳跃 $1/n$,

$$\hat{\xi}_p = X_{(\lceil np \rceil)}. \quad (21.20)$$

Notations

本讲义采用真题 [26S-Q8] 使用的下分位数约定 $F^{-1}(p) = \inf\{x : F(x) \geq p\}$ 。

[BD] 在某些章节中对 np 为整数时采用相邻两个次序统计量的平均: $\frac{1}{2} [X_{(np)} + X_{(np+1)}]$ 。两种约定在连续总体的大样本一阶渐近理论中通常等价, 但在离散总体和有限样本中可以给出不同答案, 故不得静默混用。

定义 21.15 (样本中位数). 总体中位数为 $\xi_{1/2}$ 。按下分位数约定, 样本中位数为 $\hat{\xi}_{1/2} = X_{(\lceil n/2 \rceil)}$ 。

常见的对称约定是: $\tilde{X} = \begin{cases} X_{((n+1)/2)}, & n \text{ 为奇数,} \\ \frac{1}{2} [X_{(n/2)} + X_{(n/2+1)}], & n \text{ 为偶数.} \end{cases}$ 答题时必须说明采用哪一种定义。

21.10 样本分位数相合性的精确条件

定理 21.16 (样本分位数的相合性). 固定 $p \in (0, 1)$, 令 $\xi_p = F^{-1}(p)$. 若对每个 $\varepsilon > 0$,

$$F(\xi_p - \varepsilon) < p < F(\xi_p + \varepsilon), \quad (21.21)$$

则

$$\hat{\xi}_p \xrightarrow{\mathbb{P}} \xi_p. \quad (21.22)$$

证明. 对任意 $\varepsilon > 0$, $\{\hat{\xi}_p \leq \xi_p - \varepsilon\} = \{F_n(\xi_p - \varepsilon) \geq p\}$. 而 $F_n(\xi_p - \varepsilon) \xrightarrow{\mathbb{P}} F(\xi_p - \varepsilon) < p$, 故 $\mathbb{P}(\hat{\xi}_p \leq \xi_p - \varepsilon) \rightarrow 0$.

同理, $\{\hat{\xi}_p > \xi_p + \varepsilon\} = \{F_n(\xi_p + \varepsilon) < p\}$. 又因 $F_n(\xi_p + \varepsilon) \xrightarrow{\mathbb{P}} F(\xi_p + \varepsilon) > p$, 故 $\mathbb{P}(\hat{\xi}_p > \xi_p + \varepsilon) \rightarrow 0$. 所以 $\mathbb{P}(|\hat{\xi}_p - \xi_p| > \varepsilon) \rightarrow 0$. $\square$

注 21.17. 左侧严格不等式 $F(\xi_p - \varepsilon) < p$ 由下分位数定义自动成立。

真正需要额外检查的是: $F(\xi_p + \varepsilon) > p$. 若 F 在 ξ_p 右侧存在平台, 该条件可能失败。

21.11 连续总体下样本分位数的渐近正态性

定理 21.18 (样本分位数渐近正态). 设 F 在 ξ_p 的邻域内可微, 且密度 f 在 ξ_p 连续并满足 $f(\xi_p) > 0$, $F(\xi_p) = p$. 则

$$\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right). \quad (21.23)$$

证明. 令 $k_n = \lceil np \rceil$, $x_n = \xi_p + \frac{t}{\sqrt{n}}$. 则

$$\begin{aligned} \mathbb{P}\left(\sqrt{n}(\hat{\xi}_p - \xi_p) \leq t\right) &= \mathbb{P}(X_{(k_n)} \leq x_n) \\ &= \mathbb{P}(N_n(x_n) \geq k_n), \end{aligned}$$

其中 $N_n(x_n) = \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x_n\}} \sim \text{Bin}(n, p_n)$, $p_n = F(x_n)$. Taylor 展开给出 $p_n = p + \frac{tf(\xi_p)}{\sqrt{n}} + o(n^{-1/2})$. 因此 $\frac{k_n - np_n}{\sqrt{np_n(1-p_n)}} \rightarrow -\frac{tf(\xi_p)}{\sqrt{p(1-p)}}$. 由二项分布中心极限定理,

$$\mathbb{P}(N_n(x_n) \geq k_n) \rightarrow \Phi\left(\frac{tf(\xi_p)}{\sqrt{p(1-p)}}\right).$$

这正是方差 $p(1-p)/f(\xi_p)^2$ 的中心正态分布函数。 $\square$

前提条件检查

以下情形不能直接套用标准分位数渐近正态结论:

- F 在 ξ_p 有跳跃;
- $f(\xi_p) = 0$;
- ξ_p 不唯一;
- F 在分位点附近有平台;
- $p = p_n$ 随 n 趋近 0 或 1, 形成极端分位数问题。

21.12 历年真题完整解法: Bernoulli 样本分位数

往年真题

[26S-Q8, 15 分]

设 $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(\theta)$, $0 < \theta < 1$. 给定 $0 < p < 1$, 定义 $\hat{\xi}_p = \inf\{x : F_n(x) \geq p\}$.

(1) 对每个 p , 是否都有 $\hat{\xi}_p \xrightarrow{\mathbb{P}} \xi_p$?

(2) 是否存在非退化离散分布 F , 使所有 $p \in (0, 1)$ 的样本分位数都相合?

解: 记 $q = 1 - \theta$. Bernoulli 分布函数为 $F(x) = \begin{cases} 0, & x < 0, \\ q, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$ 因此总体下分位数为

$$\xi_p = \begin{cases} 0, & 0 < p \leq q, \\ 1, & q < p < 1. \end{cases} \quad (21.24)$$

令 $N_{0,n} = \sum_{i=1}^n \mathbf{1}_{\{X_i=0\}} \sim \text{Bin}(n, q)$. 经验分位数满足 $\hat{\xi}_p = 0 \iff \frac{N_{0,n}}{n} \geq p$.

情形一: $p < q$

由大数定律, $\frac{N_{0,n}}{n} \xrightarrow{\mathbb{P}} q > p$, 故 $\mathbb{P}(\hat{\xi}_p = 0) \rightarrow 1$. 而 $\xi_p = 0$, 所以 $\hat{\xi}_p \xrightarrow{\mathbb{P}} 0$.

情形二: $p > q$

由大数定律, $\mathbb{P}\left(\frac{N_{0,n}}{n} \geq p\right) \rightarrow 0$. 故 $\mathbb{P}(\hat{\xi}_p = 1) \rightarrow 1$. 而 $\xi_p = 1$, 所以 $\hat{\xi}_p \xrightarrow{\mathbb{P}} 1$.

情形三: $p = q$

此时总体下分位数为 $\xi_q = 0$. 但是 $\mathbb{P}(\hat{\xi}_q = 0) = \mathbb{P}(N_{0,n} \geq nq)$. 更精确地, 因 $N_{0,n}$ 为整数, 阈值为 $\lceil nq \rceil$. 由中心极限定理, $\frac{N_{0,n} - nq}{\sqrt{nq(1-q)}} \xrightarrow{d} N(0, 1)$, 且 $\frac{\lceil nq \rceil - nq}{\sqrt{nq(1-q)}} \rightarrow 0$. 因此 $\mathbb{P}(\hat{\xi}_q = 0) \rightarrow \frac{1}{2}$, $\mathbb{P}(\hat{\xi}_q = 1) \rightarrow \frac{1}{2}$. 于是 $\hat{\xi}_q$ 不依概率收敛到 $\xi_q = 0$.

综上,

$$\hat{\xi}_p \xrightarrow{\mathbb{P}} \xi_p \iff p \neq 1 - \theta. \quad (21.25)$$

第二问: 答案为“可以”

枚举有理数: $\mathbb{Q} = \{r_1, r_2, \dots\}$. 定义离散随机变量 X :

$$\mathbb{P}(X = r_j) = 2^{-j}, \quad j = 1, 2, \dots \quad (21.26)$$

因为 $\sum_{j=1}^{\infty} 2^{-j} = 1$, 这是一个非退化离散分布.

其支持集 $\mathbb{Q}$ 在 $\mathbb{R}$ 中稠密. 任取 $x < y$, 可选某个 $r_j \in (x, y]$, 故 $F(y) - F(x) = \mathbb{P}(x < X \leq y) \geq 2^{-j} > 0$. 所以 F 严格递增.

固定任意 $p \in (0, 1)$, 令 $\xi_p = F^{-1}(p)$. 对任意 $\varepsilon > 0$, 由下分位数定义, $F(\xi_p - \varepsilon) < p$. 又因 F 严格递增, $F(\xi_p + \varepsilon) > F(\xi_p) \geq p$. 所以 $F(\xi_p - \varepsilon) < p < F(\xi_p + \varepsilon)$. 由定理 21.16, $\hat{\xi}_p \xrightarrow{\mathbb{P}} \xi_p$. 由于 p 任意, 得到

$$\text{存在非退化离散分布, 使每个 } p \in (0, 1) \text{ 的样本分位数均相合.} \quad (21.27)$$

考试时需要注意的地方

第二问不能仅凭 Bernoulli 反例就回答“不可能”。


Bernoulli 失败的原因是 CDF 在 0 与 1 之间有平台。离散分布的支持集可以是稠密的；纯离散并不意味着支持点之间一定存在正距离间隔。

考试时需要注意的地方

- 第二问的完整构造必须验证：
- (1) 概率质量之和为 1；
 - (2) 分布非退化；
 - (3) 支持集稠密；
 - (4) CDF 严格递增；
 - (5) 严格递增推出分位数分离条件；
 - (6) 调用分位数相合定理。

21.13 次序统计量与分位数易错点

陈述	判断	正确说明
$X_{(k)} = X_k$	错	前者表示第 k 小值，后者表示第 k 个观测。
次序统计量相互独立	错	它们具有强烈依赖关系，并满足确定次序约束。
$F(X)$ 对任意 F 都是 $\text{Uniform}(0, 1)$	错	需 F 连续；有跳跃时不成立。
$F(X_{(k)}) \sim \text{Beta}(k, n - k + 1)$ 对任意 F	错	需 F 连续；更严格地使用概率积分变换。
样本中位数定义唯一	错	偶数样本下有下中位数、上中位数和平均中位数等约定。
样本分位数对所有分布和所有 p 都相合	错	需分位点附近满足严格分离条件。
离散分布的样本分位数必不相合	错	稠密原子支持可使 CDF 严格递增，从而所有固定 p 均相合。
给定连续随机变量 $Y = y$ 可用普通事件条件概率公式	错	通常 $\mathbb{P}(Y = y) = 0$ ，应使用条件密度或正则条件分布。



次序统计量题

- (1) 将事件翻译为“有多少个样本落在某区间”;
- (2) 单个次序统计量优先使用二项计数;
- (3) 两个次序统计量使用多项区间计数;
- (4) 极小值使用补事件: $\mathbb{P}(X_{(1)} > x) = [1 - F(x)]^n$;
- (5) 极大值直接使用: $\mathbb{P}(X_{(n)} \leq x) = F(x)^n$;
- (6) Uniform 次序统计量优先识别为 Beta;
- (7) 条件于极大值或极小值时先求联合密度与边缘密度;
- (8) 分位数题先写 $\hat{\xi}_p = X_{(\lceil np \rceil)}$;
- (9) 离散分布必须检查 p 是否等于某个 CDF 跳跃后的累积概率。

一些需要记忆的内容

- (1) $X_{(k)} \leq x$ 等价于什么二项计数事件?
- (2) $X_{(1)}$ 与 $X_{(n)}$ 的 CDF 分别是什么?
- (3) 全部次序统计量联合密度中的系数为什么是 $n!$?
- (4) $U_{(k)}$ 服从哪个 Beta 分布?
- (5) 给定 $U_{(n)} = y$ 后, $U_{(1)}$ 的条件均值是什么?
- (6) 下样本分位数等于哪个次序统计量?
- (7) 分位数相合性的严格分离条件是什么?
- (8) Bernoulli 分位数在哪个 p 值上不相合?
- (9) 为什么稠密离散支持可以避免上述失败?



第二十二章 充分性、完全性、辅助性与 UMVU 估计

22.1 考纲定位与历年考法

重点

重要性等级：S 级。

本章是数理统计资格考试中最稳定的理论主线之一：

充分统计量 $\rightarrow$ Rao-Blackwell 化 $\rightarrow$ 完全性 $\rightarrow$ Lehmann-Scheffé $\rightarrow$ UMVUE.

另一条重要主线是

完全充分统计量 + 辅助统计量 $\xrightarrow{\text{Basu}}$ 独立性.

必须会完整证明：

- Neyman-Fisher 因子分解定理的主要方向；
- 极小充分统计量的似然比判别法；
- Binomial、Poisson、Gamma、Uniform 极大值的完全性；
- Rao-Blackwell 定理；
- Lehmann-Scheffé 定理；
- Basu 定理；
- 满秩指数族自然统计量完全性的证明框架。

必须会完整计算：

- 从一个“粗糙无偏估计量”出发，条件于完全充分统计量；
- 由组合计数计算 Bernoulli 或 Binomial 条件期望；
- 由单纯形体积计算指数样本给定总和后的条件概率；
- 判断一个极小充分统计量是否完全；
- 在受约束参数模型中先消去冗余参数，再找完全充分统计量。

历年直接对应题目：

[25F-Q7, 10 分],

[25F-Q8, 15 分],

[25F-Q9(a), 15 分题的一部分],

[25S-Q9(b), 15 分题的一部分],

[24S-Q11, 15 分],

[24F-Q10(b), 15 分题的一部分],

[26S-Q10, 10 分].

22.2 充分统计量的精确定义

设统计模型为 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, 观测为 $X : (\Omega, \mathcal{F}) \rightarrow (\mathcal{X}, \mathcal{A})$, 统计量为 $T = T(X) : \mathcal{X} \rightarrow \mathcal{T}$.

定义 22.1 (充分统计量). 统计量 T 称为参数 θ 的充分统计量 (sufficient statistic), 若给定 T 后 X 的条件分布不再依赖于 θ .

严格地说, 存在一个 Markov 核 $K(t, A)$, $t \in \mathcal{T}$, $A \in \mathcal{A}$, 使得对每个 $\theta \in \Theta$,

$$P_\theta(X \in A | T) = K(T, A) \quad P_\theta\text{-a.s.}, \quad (22.1)$$

且同一个核 K 对所有 θ 均适用。

等价地, 对每个有界可测函数 $a : \mathcal{X} \rightarrow \mathbb{R}$, 存在与 θ 无关的可测函数 r_a , 使

$$\mathbb{E}_\theta[a(X) | T] = r_a(T) \quad P_\theta\text{-a.s.} \quad (22.2)$$

注 22.2. “给定 T 后不依赖参数”不是说 $X \perp \theta$. 在频率学派模型中 θ 不是随机变量。准确含义是：同一个条件分布核适用于所有参数值。

概念比较

充分性表达的是**无损数据压缩**：

若 $T(x) = T(y)$, 则在关于 θ 的推断中, 样本点 x 与 y 应被视为等价。

但是充分性本身不说明：

- T 是否达到最大程度的数据压缩；
- T 是否完全；
- T 是否与某个辅助统计量独立；
- T 的函数是否一定是最优估计量。

22.3 Neyman–Fisher 因子分解定理

定理 22.3 (Neyman–Fisher 因子分解定理). 设模型由同一个 σ -有限测度 ν 控制, 且 P_θ 关于 ν 的密度为 $f_\theta(x)$ 。在标准 Borel 样本空间等通常正则条件下, 统计量 T 对 θ 充分, 当且仅当存在非负可测函数 $h(x)$ 和 $g_\theta(t)$, 其中 h 不依赖 θ , 使得

$$f_\theta(x) = g_\theta(T(x))h(x) \quad \nu\text{-a.e.} \quad (22.3)$$

对所有 $\theta \in \Theta$ 成立。

证明. 先证明资格考试中最常使用的“因子分解推出充分性”。

定义测度 $H(dx) = h(x)\nu(dx)$ 。令 H_T 为 H 在映射 T 下的像测度。在标准 Borel 空间上, 可将 H 关于 T 分解为 $H(dx) = K(t, dx)H_T(dt)$, $t = T(x)$, 其中 $K(t, \cdot)$ 是集中在纤维 $\{x : T(x) = t\}$ 上的条件分布核。

由因子分解, $P_\theta(dx) = g_\theta(T(x))H(dx)$ 。将其推到 T 空间上, 得到 $P_\theta^T(dt) = g_\theta(t)H_T(dt)$ 。因此 $P_\theta(dx) = K(t, dx)P_\theta^T(dt)$ 。给定 $T = t$ 后, X 的条件分布为 $K(t, dx)$, 其中不含 θ , 故 T 充分。

反方向, 若 T 充分, 则存在与 θ 无关的条件核 $K(t, dx)$, 使 $P_\theta(dx) = K(t, dx)P_\theta^T(dt)$ 。由于原模型被 ν 控制, T 的分布也被相应像测度控制。对条件核和 T 的边缘分布分别使用 Radon–Nikodym 分解, 即可写成 $f_\theta(x) = g_\theta(T(x))h(x)$ 。在离散模型中, 该方向可直接取 $g_\theta(t) = P_\theta(T = t)$, $h(x) = P_\theta(X = x | T = T(x))$, 其中充分性保证 $h(x)$ 与 θ 无关。□

前提条件检查

因子分解定理中的关键要求是: $h(x)$ 不得依赖 θ 。

支持集依赖参数并不妨碍应用因子分解定理, 因为相应指示函数可能仍能通过 $T(x)$ 表示。

例如 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$ 的联合密度为 $f_\theta(\mathbf{x}) = \theta^{-n} \mathbf{1}_{\{0 < x_{(1)} \leq x_{(n)} < \theta\}}$, 可以写成 $f_\theta(\mathbf{x}) = \underbrace{\theta^{-n} \mathbf{1}_{\{x_{(n)} < \theta\}}}_{g_\theta(x_{(n)})} \underbrace{\mathbf{1}_{\{x_{(1)} > 0\}}}_{h(\mathbf{x})}$ 。故 $X_{(n)}$ 充分。

但该模型不是上一章定义的正则指数族, 因为支持集依赖 θ 。

22.4 充分统计量标准例题

22.4.1 Bernoulli 样本

若 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, 则

$$\begin{aligned} f_p(\mathbf{x}) &= \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \mathbf{1}_{\{0,1\}}(x_i) \\ &= p^{\sum_i x_i} (1-p)^{n-\sum_i x_i} \prod_{i=1}^n \mathbf{1}_{\{0,1\}}(x_i). \end{aligned}$$

因此

$$T = \sum_{i=1}^n X_i \quad (22.4)$$

充分。

给定 $T = t$ 后, 所有恰含 t 个 1 的二元样本向量等概率:

$$P_p(X = \mathbf{x} | T = t) = \frac{1}{\binom{n}{t}} \quad (22.5)$$

只要 $\sum_i x_i = t$ 。该条件分布与 p 无关。

22.4.2 正态总体, 两个参数均未知

若 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, 则

$$\begin{aligned} f_{\mu, \sigma^2}(\mathbf{x}) &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\sum_i x_i^2 - 2\mu \sum_i x_i + n\mu^2}{2\sigma^2} \right\}. \end{aligned}$$



因此

$$\left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right) \quad (22.6)$$

充分。

由于 $\sum_i X_i = n\bar{X}$, $\sum_i X_i^2 = (n-1)S^2 + n\bar{X}^2$, 故

$$(\bar{X}, S^2) \quad (22.7)$$

是其一一变换, 也充分。

考试时需要注意的地方

“统计量维数等于参数维数”不是充分性的定义, 也不是充分性的必要条件。

例如曲指数族 $X \sim N(\theta, \theta^2)$ 只有一个参数, 但自然充分统计量通常仍为二维: $(\sum_i X_i, \sum_i X_i^2)$ 。

22.5 极小充分统计量

定义 22.4 (极小充分统计量). 充分统计量 T 称为极小充分统计量 (minimal sufficient statistic), 若对任意其他充分统计量 S , 存在可测函数 r 使

$$T = r(S) \quad P_\theta\text{-a.s. 对所有 } \theta. \quad (22.8)$$

等价地,

$$\sigma(T) \subseteq \sigma(S) \quad \text{模共同零测集}. \quad (22.9)$$

极小充分统计量不是“数值最小”或“维数最小”。其含义是：它所生成的样本划分比任何其他充分统计量的划分都不更细。

命题 22.5 (一一变换不改变极小充分性). 若 T 极小充分, 且 r 在 T 的值域上一一对应, 则 $r(T)$ 也极小充分。

例如, 下列统计量包含完全相同的信息: $\sum_i X_i, \bar{X}, \exp(\sum_i X_i)$ 。

22.6 极小充分统计量的似然比判别法

定理 22.6 (似然比判别法: 正密度版本). 设模型具有与参数无关的共同支持集 $\mathcal{X}_0$, 且 $f_\theta(x) > 0$ ($x \in \mathcal{X}_0, \theta \in \Theta$)。若统计量 T 满足: 对任意 $x, y \in \mathcal{X}_0$,

$$\frac{f_\theta(x)}{f_\theta(y)} \text{ 与 } \theta \text{ 无关} \iff T(x) = T(y), \quad (22.10)$$

则 T 极小充分。

证明. 固定一个参数值 θ_0 。若 $T(x) = T(y)$, 则 $\frac{f_\theta(x)}{f_\theta(y)}$ 与 θ 无关, 因此 $\frac{f_\theta(x)}{f_{\theta_0}(x)} = \frac{f_\theta(y)}{f_{\theta_0}(y)}$ 。所以比值 $\frac{f_\theta(x)}{f_{\theta_0}(x)}$ 在每个 T 的纤维上为常数。可定义 $g_\theta(T(x)) = \frac{f_\theta(x)}{f_{\theta_0}(x)}$ 。于是 $f_\theta(x) = g_\theta(T(x))f_{\theta_0}(x)$ 。由因子分解定理, T 充分。

现令 S 为任意充分统计量。若 $S(x) = S(y)$, 由 S 的因子分解表示, $f_{\theta}(x) = a_{\theta}(S(x))b(x)$, $f_{\theta}(y) = a_{\theta}(S(y))b(y)$, 故 $\frac{f_{\theta}(x)}{f_{\theta}(y)} = \frac{b(x)}{b(y)}$ 与 θ 无关。由假设, $T(x) = T(y)$ 。因此 T 在 S 的每个纤维上为常数, 即 T 是 S 的函数。□

定理 22.7 (含零密度时的交叉乘积版本). 当密度可能为零时, 可定义关系 $x \sim y$ 当且仅当对所有 $\theta, \theta' \in \Theta$,

$$f_{\theta}(x)f_{\theta'}(y) = f_{\theta}(y)f_{\theta'}(x). \quad (22.11)$$

若 $T(x) = T(y) \iff x \sim y$, 则在通常可测性条件下 T 极小充分。

考试时需要注意的地方

当 $f_{\theta}(y) = 0$ 时, 直接写 $\frac{f_{\theta}(x)}{f_{\theta}(y)}$ 没有意义。

参数依赖支持集模型中, 优先使用:

- 指示函数的支持区间比较; 或
- 交叉乘积判别法。

22.7 极小充分统计量的标准例题

22.7.1 Bernoulli 样本

设 $T(\mathbf{x}) = \sum_{i=1}^n x_i$ 。对两个合法样本点 $\mathbf{x}, \mathbf{y}$, $\frac{f_p(\mathbf{x})}{f_p(\mathbf{y})} = \left(\frac{p}{1-p}\right)^{\sum_i x_i - \sum_i y_i}$ 。该比值与 p 无关, 当且仅当 $\sum_i x_i = \sum_i y_i$ 。故

$$\sum_{i=1}^n X_i \quad (22.12)$$

极小充分。

22.7.2 正态总体, 均值和方差均未知

设 $T(\mathbf{x}) = (\sum_i x_i, \sum_i x_i^2)$ 。对 $\mathbf{x}, \mathbf{y}$, $\log \frac{f_{\mu, \sigma^2}(\mathbf{x})}{f_{\mu, \sigma^2}(\mathbf{y})} = -\frac{1}{2\sigma^2} [\Delta_2 - 2\mu\Delta_1]$, 其中 $\Delta_1 = \sum_i x_i - \sum_i y_i$, $\Delta_2 = \sum_i x_i^2 - \sum_i y_i^2$ 。该表达式对全部 (μ, σ^2) 为常数, 当且仅当 $\Delta_1 = 0$, $\Delta_2 = 0$ 。故 $(\sum_i X_i, \sum_i X_i^2)$ 极小充分, 等价地 $(\bar{X}, S^2)$ 极小充分。


22.7.3 位置 Uniform 模型

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(\theta, \theta + 1)$, $\theta \in \mathbb{R}$ 。联合密度为 $f_{\theta}(\mathbf{x}) = \mathbf{1}_{\{x_{(n)} - 1 < \theta < x_{(1)}\}}$ 。两个样本点 $\mathbf{x}, \mathbf{y}$ 的似然函数之比与 θ 无关, 当且仅当对应的支持区间相同: $(x_{(n)} - 1, x_{(1)}) = (y_{(n)} - 1, y_{(1)})$ 。因此

$$(X_{(1)}, X_{(n)}) \quad (22.13)$$

极小充分。

一一变换 $R = X_{(n)} - X_{(1)}$, $M = \frac{X_{(1)} + X_{(n)}}{2}$ 也极小充分。



22.8 辅助统计量

定义 22.8 (辅助统计量). 若统计量 $A = A(X)$ 的分布不依赖于参数 θ , 即

$$\mathcal{L}_\theta(A) \text{ 对所有 } \theta \in \Theta \text{ 相同,}$$

(22.14)

则称 A 为辅助统计量 (ancillary statistic)。

概念比较		
概念	直观作用	数学定义
充分统计量	保留样本中关于参数的全部信息	给定该统计量后, 样本条件分布不依赖参数
辅助统计量	其边缘分布本身不携带参数信息	该统计量的分布不依赖参数

考试时需要注意的地方

“辅助统计量不含参数信息”只指其**边缘分布**不依赖参数。
辅助统计量与其他统计量联合使用时, 仍可能影响关于参数的推断。例如在 $\text{Unif}(\theta, \theta + 1)$ 模型中, 样本极差 R 是辅助统计量, 但给定中程 M 后, 不同的 R 会给出不同的 θ 可行区间。

22.9 辅助统计量的标准构造

22.9.1 位置族

设 $X_i = \theta + Z_i$, 其中 Z_i 的联合分布不含 θ 。则任意平移不变量, 例如 $X_i - X_j, X_{(n)} - X_{(1)}, X_i - \bar{X}$, 其分布均不依赖 θ 。

特别地,

$$R = X_{(n)} - X_{(1)}$$

(22.15)

为辅助统计量。

在 $X_i \overset{\text{i.i.d.}}{\sim} \text{Unif}(\theta, \theta + 1)$ 中,

$$R \sim \text{Beta}(n - 1, 2),$$

(22.16)

其密度为


$$f_R(r) = n(n - 1)r^{n-2}(1 - r)\mathbf{1}_{\{0 < r < 1\}}.$$

(22.17)

因此

$$\mathbb{E}R = \frac{n - 1}{n + 1}.$$

(22.18)



22.9.2 尺度族

设 $X_i = \sigma Z_i$, $\sigma > 0$, 其中 Z_i 的联合分布不含 σ 。则任意尺度不变量, 例如 $\frac{X_i}{X_j}$, $\frac{X_i}{\sum_j X_j}$, $\frac{X_{(n)}}{X_{(1)}}$, 只要定义良好, 均为辅助统计量。

22.9.3 随机样本量

若样本量 N 是随机变量, 且其已知分布不依赖参数 θ , 则 N 本身为辅助统计量。

但极小充分统计量可能必须包含 N 。例如条件于 $N = n$ 的样本来自一参数指数族时, 常见极小充分统计量为 $(N, \sum_{i=1}^N T(X_i))$ 。

22.10 完全统计量

定义 22.9 (完全统计量). 统计量 T 称为参数族 $\{P_\theta : \theta \in \Theta\}$ 下的完全统计量 (complete statistic), 若对任意可测函数 g , 只要 $\mathbb{E}_\theta[g(T)] < \infty$ 对所有 θ , 且

$$\mathbb{E}_\theta[g(T)] = 0 \text{ 对所有 } \theta \in \Theta, \quad (22.19)$$

就有

$$P_\theta(g(T) = 0) = 1 \text{ 对所有 } \theta \in \Theta. \quad (22.20)$$

定义 22.10 (有界完全). 若上述定义只要求对有界函数 g 成立, 则称 T 有界完全 (boundedly complete)。

前提条件检查

完全性是统计量分布族的性质。

应说: $\{\mathcal{L}_\theta(T) : \theta \in \Theta\}$ 是完全族。

不能只说“原始样本分布是完全的”, 除非明确把完整样本本身视为统计量。

命题 22.11 (完全性保证无偏函数唯一). 若 T 完全, 且 $\mathbb{E}_\theta[g_1(T)] = \mathbb{E}_\theta[g_2(T)]$ 对所有 θ 成立, 则

$$g_1(T) = g_2(T) \quad P_\theta\text{-a.s. 对所有 } \theta. \quad (22.21)$$

证明. 对 $g = g_1 - g_2$ 应用完全性定义。 □


22.11 常见完全统计量的直接证明

22.11.1 Binomial 完全性

定理 22.12 (Binomial 完全性). 若 $T \sim \text{Bin}(n, p)$, $0 < p < 1$, 则 T 完全。

证明. 设 $\mathbb{E}_p[g(T)] = \sum_{t=0}^n g(t) \binom{n}{t} p^t (1-p)^{n-t} = 0$ 对所有 $0 < p < 1$ 成立。

除以非零因子 $(1-p)^n$, 令 $z = \frac{p}{1-p} \in (0, \infty)$, 得到 $\sum_{t=0}^n g(t) \binom{n}{t} z^t = 0$ 对所有 $z > 0$ 。左侧是一个多项式。一个多项式若在开区间上恒等于零, 则每个系数均为零: $g(t) \binom{n}{t} = 0$, $t = 0, \dots, n$ 。故 $g(t) = 0$ $t = 0, \dots, n$ 。 □



22.11.2 Poisson 完全性

定理 22.13 (Poisson 完全性). 若 $T \sim \text{Poisson}(\lambda)$, $\lambda > 0$, 则 T 完全。

证明. 若 $0 = \mathbb{E}_\lambda[g(T)] = e^{-\lambda} \sum_{t=0}^{\infty} g(t) \frac{\lambda^t}{t!}$, 则

$$\sum_{t=0}^{\infty} g(t) \frac{\lambda^t}{t!} = 0 \text{ 对所有 } \lambda > 0. \quad (22.22)$$

由可积性, 该幂级数在适当邻域内绝对收敛, 并定义解析函数。解析函数在开区间上恒为零, 故所有 Taylor 系数均为零: $\frac{g(t)}{t!} = 0$ 。所以 $g(t) = 0 \quad t = 0, 1, \dots$ 。□

22.11.3 Gamma 完全性

定理 22.14 (固定形状 Gamma 族完全性). 设 $T \sim \Gamma(\alpha, \lambda)$, $\lambda > 0$, 其中形状参数 $\alpha > 0$ 已知, 率参数 λ 未知。则 T 对 λ 完全。

证明. 若 $\mathbb{E}_\lambda[g(T)] = 0$, 则 $\frac{\lambda^\alpha}{\Gamma(\alpha)} \int_0^\infty g(t) t^{\alpha-1} e^{-\lambda t} dt = 0$ 。因前置因子非零,

$$\int_0^\infty g(t) t^{\alpha-1} e^{-\lambda t} dt = 0 \text{ 对所有 } \lambda > 0. \quad (22.23)$$

左侧是函数 $q(t) = g(t) t^{\alpha-1}$ 的 Laplace 变换。由 Laplace 变换唯一性, $q(t) = 0$ Lebesgue-a.e. 由于 $t^{\alpha-1} > 0$ 对 $t > 0$ 成立, $g(t) = 0$ a.e. □

22.11.4 Uniform 极大值完全性

定理 22.15 (Uniform 极大值完全性). 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$ 。则 $T = X_{(n)}$ 是完全充分统计量。

证明. 充分性已由因子分解定理得到。

T 的密度为 $f_T(t | \theta) = \frac{nt^{n-1}}{\theta^n} \mathbf{1}_{\{0 < t < \theta\}}$ 。若 $\mathbb{E}_\theta[g(T)] = 0$ 对所有 $\theta > 0$ 成立, 则 $\frac{n}{\theta^n} \int_0^\theta g(t) t^{n-1} dt = 0$ 。因此

$$\int_0^\theta g(t) t^{n-1} dt = 0 \text{ 对所有 } \theta > 0. \quad (22.24)$$

左侧作为 θ 的绝对连续函数恒为零, 故其导数几乎处处为零: $g(\theta) \theta^{n-1} = 0$ a.e. 于是 $g(\theta) = 0$ a.e. on $(0, \infty)$ 。□

注 22.16. 该例说明: 参数依赖支持集 $\not\Rightarrow$ 不存在完全充分统计量。 参数依赖支持集只意味着常规正则指数族和常规 Fisher 信息公式可能失效。

22.12 满秩指数族的完全性

定理 22.17 (满秩指数族自然统计量完全性). 设样本的联合密度可写为

$$f_\eta(x) = h(x) \exp \left\{ \eta^\top T(x) - A(\eta) \right\}, \quad (22.25)$$



其中自然参数集合 $\mathcal{E}_0 = \{\eta(\theta) : \theta \in \Theta\}$ 包含 $\mathbb{R}^k$ 中的一个非空开集。

则自然统计量 T 是完全统计量。

证明. 设 $\mathbb{E}_\eta[g(T)] = 0$ 对所有 $\eta \in \mathcal{E}_0$ 。选取开集内部一点 η_0 。记 T 在基准测度下的密度或测度因子为 $h_T(t)$ 。则 $0 = \int g(t)h_T(t)e^{\eta^\top t - A(\eta)}\nu_T(dt)$ 。乘以 $e^{A(\eta)}$: $\int g(t)h_T(t)e^{\eta^\top t}\nu_T(dt) = 0$ 。令 $s = \eta - \eta_0$ 。在 $s = 0$ 的某个邻域内,

$$\int e^{s^\top t} \underbrace{g(t)h_T(t)e^{\eta_0^\top t}}_{q(t)} \nu_T(dt) = 0. \quad (22.26)$$

左侧是有限符号测度 $q(t)\nu_T(dt)$ 的多元 Laplace 变换。该变换在零点邻域恒为零。由多元 Laplace 变换或矩母函数的唯一性, 该符号测度必为零: $q(t) = 0$ ν_T -a.e. 而 $h_T(t)e^{\eta_0^\top t} > 0$ 在 T 的有效支持上成立, 因此 $g(t) = 0$ ν_T -a.e. $\square$

前提条件检查

“自然参数像包含开集”不能省略。

若自然参数只沿低维曲线变化, 则只是曲指数族, 上述多元 Laplace 变换只在一条曲线上为零, 不足以确定一个多元函数必为零。

曲指数族的自然统计量未必完全

后文的 [25S-Q9(b)] 中, 二元正态相关系数模型只有一个参数 ρ , 但极小充分统计量为二维 (A_n, B_n) 。其中 $A_n = \sum_i (X_i^2 + Y_i^2)$ 满足 $\mathbb{E}_\rho A_n = 2n$ 对所有 ρ 成立。因此 $A_n - 2n$ 是非零的零均值函数, 说明该极小充分统计量不完全。

22.13 完全、充分与极小充分之间的关系

一般地: 极小充分 $\not\Rightarrow$ 完全, 完全 $\not\Rightarrow$ 充分。

在通常控制模型下,

$$\boxed{\text{完全} + \text{充分} \Rightarrow \text{极小充分}}. \quad (22.27)$$

该结论可在 Lehmann–Scheffé 定理之后如下证明。

命题 22.18 (完全充分统计量必极小充分). 设 T 完全且充分, S 是任意充分统计量。则 T 是 S 的函数, 因而 T 极小充分。

证明. 任取有界可测函数 $a(T)$ 。由于 T 完全充分, Lehmann–Scheffé 定理说明 $a(T)$ 是其期望函数 $\tau_a(\theta) = \mathbb{E}_\theta a(T)$ 的唯一 UMVU 无偏估计量。

对 $a(T)$ 条件于充分统计量 S : $b(S) = \mathbb{E}_\theta[a(T) | S]$ 。由 S 的充分性, $b(S)$ 可选为不含 θ 的统计量。它仍无偏估计 $\tau_a(\theta)$, 且 Rao–Blackwell 定理给出 $\text{Var}_\theta(b(S)) \leq \text{Var}_\theta(a(T))$ 。由唯一性, $b(S) = a(T)$ a.s. 因此每个有界 $a(T)$ 都是 S -可测的。

令 a 遍历 T 值域上的一个可数生成类的指示函数, 可得 $\sigma(T) \subseteq \sigma(S)$, 即 T 是 S 的函数。 $\square$

22.14 Rao–Blackwell 定理

定义 22.19 (无偏估计量). 统计量 $W = W(X)$ 称为参数函数 $\tau(\theta)$ 的无偏估计量, 若

$$\mathbb{E}_\theta W = \tau(\theta) \text{ 对所有 } \theta \in \Theta. \quad (22.28)$$

定义 22.20 (UMVU/UMVUE). 若 W 无偏估计 $\tau(\theta)$, 具有有限方差, 并且对任意其他有限方差无偏估计量 V ,

$$\text{Var}_\theta(W) \leq \text{Var}_\theta(V) \text{ 对所有 } \theta \in \Theta, \quad (22.29)$$

则称 W 为 $\tau(\theta)$ 的一致最小方差无偏估计量, 即 UMVU 或 UMVUE。

定理 22.21 (Rao–Blackwell). 设 W 是 $\tau(\theta)$ 的无偏估计量, 且 $\mathbb{E}_\theta W^2 < \infty$. 设 T 是 θ 的充分统计量. 定义

$$\phi(T) = \mathbb{E}_\theta[W | T]. \quad (22.30)$$

由充分性, 右侧可选为不依赖 θ 的同一个函数。

则:

(1) $\phi(T)$ 仍无偏:

$$\mathbb{E}_\theta \phi(T) = \tau(\theta); \quad (22.31)$$

(2) 方差不增加:

$$\text{Var}_\theta(\phi(T)) \leq \text{Var}_\theta(W); \quad (22.32)$$

(3) 等号成立当且仅当 $W = \phi(T)$ P_θ -a.s., 即 W 本身已经是 T 的函数。

证明. 由 Tower property, $\mathbb{E}_\theta \phi(T) = \mathbb{E}_\theta [\mathbb{E}_\theta(W | T)] = \mathbb{E}_\theta W = \tau(\theta)$ 。

由条件方差分解, $\text{Var}_\theta(W) = \text{Var}_\theta(\mathbb{E}_\theta[W | T]) + \mathbb{E}_\theta[\text{Var}_\theta(W | T)]$. 因此 $\text{Var}_\theta(W) = \text{Var}_\theta(\phi(T)) + \mathbb{E}_\theta[\text{Var}_\theta(W | T)] \geq \text{Var}_\theta(\phi(T))$. 等号成立当且仅当 $\text{Var}_\theta(W | T) = 0$ a.s., 即 $W = \mathbb{E}_\theta(W | T)$ a.s. $\square$

定理 22.22 (凸损失下的 Rao–Blackwell 改进). 若对每个 θ , $a \mapsto L(\theta, a)$ 为凸函数, 则

$$\mathbb{E}_\theta L(\theta, \mathbb{E}_\theta[W | T]) \leq \mathbb{E}_\theta L(\theta, W), \quad (22.33)$$

只要两侧期望有定义。

证明. 由条件 Jensen 不等式, $L(\theta, \mathbb{E}[W | T]) \leq \mathbb{E}[L(\theta, W) | T]$. 再取期望。 $\square$

考试时需要注意的地方

若 T 不是充分统计量, $\mathbb{E}_\theta(W | T)$ 虽然仍有较小或相等的方差, 但它可能显式依赖未知参数 θ , 因而不 再是一个可计算的估计量。

例如 $X_1, X_2 \stackrel{\text{i.i.d.}}{\sim} N(\theta, 1)$, $W = \bar{X}$. 若错误地条件于非充分统计量 X_1 , 则 $\mathbb{E}_\theta(\bar{X} | X_1) = \frac{X_1 + \theta}{2}$, 其中含 有未知 θ 。

22.15 Lehmann–Scheffé 定理

定理 22.23 (Lehmann–Scheffé). 设 T 是 θ 的完全充分统计量。若 $\phi(T)$ 是 $\tau(\theta)$ 的有限方差无偏估计量, 则 $\phi(T)$ 是 $\tau(\theta)$ 的唯一 UMVUE。

更一般地, 若 W 是任意无偏估计量, 则

$$\mathbb{E}_\theta[W | T] \quad (22.34)$$

是 $\tau(\theta)$ 的 UMVUE, 只要其方差有限。

证明. 令 V 为任意有限方差无偏估计量。由 Rao–Blackwell 定理, $\psi(T) = \mathbb{E}_\theta[V | T]$ 是基于 T 的无偏估计量, 并满足 $\text{Var}_\theta(\psi(T)) \leq \text{Var}_\theta(V)$ 。

由于 $\mathbb{E}_\theta[\psi(T) - \phi(T)] = 0$ 对所有 θ , 且 T 完全, $\psi(T) = \phi(T)$ P_θ -a.s. 故 $\text{Var}_\theta(\phi(T)) = \text{Var}_\theta(\psi(T)) \leq \text{Var}_\theta(V)$ 。因此 $\phi(T)$ 为 UMVUE。

若 $\phi_1(T)$ 和 $\phi_2(T)$ 都是基于 T 的无偏估计量, 则 $\mathbb{E}_\theta[\phi_1(T) - \phi_2(T)] = 0$ 对所有 θ 成立。完全性给出 $\phi_1(T) = \phi_2(T)$ a.s., 故唯一。□

用 Lehmann–Scheffé 构造 UMVUE

- (1) 找到充分统计量 T ;
- (2) 证明 T 完全;
- (3) 找一个容易构造的无偏估计量 W :
 - 单个观测的指示函数;
 - 样本中固定若干观测的乘积;
 - factorial moment;
 - 次序统计量的适当倍数;
- (4) 计算 $\mathbb{E}(W | T)$;
- (5) 明确写出: 由 Rao–Blackwell 与 Lehmann–Scheffé, 所得估计量为唯一 UMVUE;
- (6) 若题目使用“最小方差”, 检查二阶矩是否有限。

22.16 Basu 定理


定理 22.24 (Basu). 设 T 是参数 θ 的完全充分统计量, A 是辅助统计量。则

$$T \perp\!\!\!\perp A. \quad (22.35)$$

证明. 任取事件 $C \in \sigma(A)$ 。由于 A 辅助, $P_\theta(C) = c_C$ 不依赖 θ 。

由 T 的充分性, 条件概率 $q_C(T) = P_\theta(C | T)$ 可选为不含 θ 的同一个 T 的函数。由 Tower property, $\mathbb{E}_\theta[q_C(T)] = P_\theta(C) = c_C$ 。所以 $\mathbb{E}_\theta[q_C(T) - c_C] = 0$ 对所有 θ 。由 T 的完全性, $q_C(T) = c_C$ P_θ -a.s. 即 $P_\theta(C | T) = P_\theta(C)$ a.s. 对所有 $C \in \sigma(A)$ 成立。这正是 $A \perp\!\!\!\perp T$ 。□

注 22.25 (讲义版本与标准版本). [S-Lec] 将 Basu 定理表述为: T 完全且极小充分 $\implies T$ 与每个辅助统计量独立。



标准表述使用“完全充分”。在通常控制模型下，完全充分 $\implies$ 极小充分，故两种表述在本讲义使用的模型中等价。

考试中最安全的写法是：Basu 定理需要完全充分统计量，而不仅仅是充分统计量。

22.17 Basu 定理的标准应用

22.17.1 正态样本均值与样本方差

假设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma_0^2)$ ，其中 σ_0^2 已知， μ 未知。

此时： $\bar{X}$ 是 μ 的完全充分统计量；而 S^2 的分布为 $\frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$ ，不依赖 μ ，故 S^2 是辅助统计量。

由 Basu 定理， $\bar{X} \perp\!\!\!\perp S^2$ 。

前提条件检查

若参数是完整向量 (μ, σ^2) ，则 S^2 的分布依赖 σ^2 ，因此 S^2 不再是该完整参数的辅助统计量。必须先明确“辅助性是相对于哪个参数而言的”。

22.17.2 指数样本的总和与比例

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ 。则 $T = \sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$ 是完全充分统计量。

向量 $(\frac{X_1}{T}, \dots, \frac{X_n}{T})$ 是尺度不变量，其分布不依赖 λ ，故为辅助统计量。由 Basu 定理，

$$T \perp\!\!\!\perp \left(\frac{X_1}{T}, \dots, \frac{X_n}{T} \right). \quad (22.36)$$

实际上，

$$\left(\frac{X_1}{T}, \dots, \frac{X_n}{T} \right) \sim \text{Dirichlet}(1, \dots, 1). \quad (22.37)$$

由交换对称性， $\mathbb{E} \frac{X_i}{T} = \frac{1}{n}$ 。

22.17.3 极小充分但不完全的反例

在 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(\theta, \theta + 1)$ 中， $T = (X_{(1)}, X_{(n)})$ 极小充分。

但 $R = X_{(n)} - X_{(1)}$ 是 T 的非退化函数，且为辅助统计量。于是 $g(T) = R - \mathbb{E}R = R - \frac{n-1}{n+1}$ 满足 $\mathbb{E}_\theta g(T) = 0$ 对所有 θ 成立，但 $g(T) \neq 0$ 以正概率成立。故 T 不完全。

这说明：极小充分 $\not\Rightarrow$ 完全。



22.18 真题完整解法：充分统计量保持相合性

往年真题

[25F-Q7, 10 分]

设 $\hat{\theta}_n$ 是参数 θ 的相合估计量，且已知 $\theta \in [-1, 1]$ 。设 T_n 是基于 n 个观测的充分统计量。证明存在一个仅依赖于 T_n 的相合估计量。

解：首先将原估计量投影到已知参数空间：

$$\tilde{\theta}_n = \Pi_{[-1,1]}(\hat{\theta}_n) = \max\{-1, \min\{1, \hat{\theta}_n\}\}. \quad (22.38)$$

因为真实参数 $\theta \in [-1, 1]$ ，投影不会增加误差：

$$|\tilde{\theta}_n - \theta| \leq |\hat{\theta}_n - \theta|. \quad (22.39)$$

所以 $\tilde{\theta}_n \xrightarrow{\mathbb{P}} \theta$ 。

此外， $|\tilde{\theta}_n - \theta| \leq 2$ 。对任意 $\varepsilon > 0$ ，

$$\begin{aligned} \mathbb{E}_\theta(\tilde{\theta}_n - \theta)^2 &= \mathbb{E}_\theta \left[(\tilde{\theta}_n - \theta)^2 \mathbf{1}_{\{|\tilde{\theta}_n - \theta| \leq \varepsilon\}} \right] \\ &\quad + \mathbb{E}_\theta \left[(\tilde{\theta}_n - \theta)^2 \mathbf{1}_{\{|\tilde{\theta}_n - \theta| > \varepsilon\}} \right] \\ &\leq \varepsilon^2 + 4P_\theta(|\tilde{\theta}_n - \theta| > \varepsilon). \end{aligned}$$

令 $n \rightarrow \infty$ ，再令 $\varepsilon \downarrow 0$ ，得到

$$\mathbb{E}_\theta(\tilde{\theta}_n - \theta)^2 \rightarrow 0. \quad (22.40)$$

现定义

$$\delta_n(T_n) = \mathbb{E}_\theta[\tilde{\theta}_n | T_n]. \quad (22.41)$$

由于 T_n 充分，条件分布不依赖 θ ，因此右侧可选为同一个不含未知参数的 T_n 的函数。

由条件 Jensen 不等式，

$$\begin{aligned} \mathbb{E}_\theta[(\delta_n(T_n) - \theta)^2] &= \mathbb{E}_\theta \left[\left(\mathbb{E}_\theta[\tilde{\theta}_n - \theta | T_n] \right)^2 \right] \\ &\leq \mathbb{E}_\theta \left[\mathbb{E}_\theta[(\tilde{\theta}_n - \theta)^2 | T_n] \right] \\ &= \mathbb{E}_\theta(\tilde{\theta}_n - \theta)^2 \\ &\rightarrow 0. \end{aligned}$$

所以 $\delta_n(T_n) \xrightarrow{L^2} \theta$ ，从而

$$\boxed{\delta_n(T_n) \xrightarrow{\mathbb{P}} \theta.} \quad (22.42)$$

□



考试时需要注意的地方

该题的必要步骤为：

- (1) 利用 $\theta \in [-1, 1]$ 对估计量截断；
- (2) 证明截断后仍相合；
- (3) 利用有界性把依概率收敛升级为 L^2 收敛；
- (4) 条件于充分统计量；
- (5) 用条件 Jensen 不等式证明新的估计量 L^2 相合；
- (6) 说明充分性保证条件期望不含未知参数。

若直接写 $\mathbb{E}(\hat{\theta}_n | T_n)$ 而不先控制其矩，不能仅由依概率相合推出新估计量相合。

22.19 真题完整解法：指数样本生存概率的 UMVUE

往年真题

[25F-Q8, 15 分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$, $\lambda > 0$, 并令固定 $x > 0$ 。参数函数为 $\phi(\lambda) = P_\lambda(X_1 > x) = e^{-\lambda x}$ 。

- (1) 找一个完全充分统计量；
- (2) 求 $\phi(\lambda)$ 的 UMVUE。

解：第一步：完全充分统计量

联合密度为 $f_\lambda(\mathbf{x}) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i} \prod_{i=1}^n \mathbf{1}_{\{x_i > 0\}}$ 。因此 $T = \sum_{i=1}^n X_i$ 充分。

又 $T \sim \Gamma(n, \lambda)$ 。由固定形状 Gamma 族的完全性， $T = \sum_{i=1}^n X_i$ 是完全充分统计量。

第二步：选择一个粗糙无偏估计量

令 $W = \mathbf{1}_{\{X_1 > x\}}$ 。则 $\mathbb{E}_\lambda W = P_\lambda(X_1 > x) = e^{-\lambda x} = \phi(\lambda)$ 。

由 Lehmann–Scheffé 定理， $\mathbb{E}(W | T)$ 即为 UMVUE。

第三步：求给定总和后的条件分布

固定 $T = t$ 。对 $n \geq 2$ ，向量 $(X_1, \dots, X_{n-1}) | \{T = t\}$ 在单纯形 $\{x_i > 0 : \sum_{i=1}^{n-1} x_i < t\}$ 上具有常数密度。因此 $\frac{X_1}{T} | T \sim \text{Beta}(1, n-1)$ 。其尾概率为 $P\left(\frac{X_1}{T} > u | T\right) = (1-u)^{n-1}$, $0 < u < 1$ 。

所以，当 $t > x$ 时，

$$\begin{aligned} P(X_1 > x | T = t) &= P\left(\frac{X_1}{t} > \frac{x}{t} \middle| T = t\right) \\ &= \left(1 - \frac{x}{t}\right)^{n-1}. \end{aligned}$$

当 $t \leq x$ 时，因为 $X_1 \leq T = t$ ，条件概率为零。

故

$$\hat{\phi}_{\text{UMVU}} = \left(1 - \frac{x}{T}\right)^{n-1} \mathbf{1}_{\{T > x\}}, \quad T = \sum_{i=1}^n X_i. \quad (22.43)$$

当 $n = 1$ 时，该式按 $(1 - x/T)^0 \mathbf{1}_{\{T > x\}} = \mathbf{1}_{\{T > x\}}$ 解释，仍然正确。

□

考试时需要注意的地方

15 分题完整得分点:

- (1) 写出联合密度;
- (2) 证明 $T = \sum_i X_i$ 充分;
- (3) 证明 Gamma 族的完全性, 或正确引用满指数族完全性;
- (4) 构造 $W = \mathbf{1}_{\{X_1 > x\}}$;
- (5) 计算给定 $T = t$ 后的单纯形条件分布;
- (6) 得到 Beta(1, $n-1$) 尾概率;
- (7) 引用 Lehmann-Scheffé 得出唯一 UMVUE。

22.20 真题完整解法: Bernoulli 参数多项式的 UMVUE

往年真题

[25F-Q9(a), 15 分题的一部分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, $0 < p < 1$ 。固定整数 $0 \leq k \leq n$ 。求

$$g(p) = p^k + (1-p)^{n-k} \quad (22.44)$$

的 UMVUE。

解: 令 $T = \sum_{i=1}^n X_i$ 。则 $T \sim \text{Bin}(n, p)$, 并且 T 是完全充分统计量。

构造粗糙无偏估计量

$$W = \prod_{i=1}^k X_i + \prod_{i=k+1}^n (1 - X_i), \quad (22.45)$$

其中空乘积约定为 1。

由独立性, $\mathbb{E}_p \prod_{i=1}^k X_i = p^k$, $\mathbb{E}_p \prod_{i=k+1}^n (1 - X_i) = (1-p)^{n-k}$ 。故 $\mathbb{E}_p W = g(p)$ 。

给定 $T = t$ 后, 所有含 t 个成功的二元样本向量等概率。

第一项的条件期望为

$$P(X_1 = \dots = X_k = 1 \mid T = t) = \frac{\binom{n-k}{t-k}}{\binom{n}{t}} = \frac{\binom{t}{k}}{\binom{n}{k}},$$


其中当 $t < k$ 时组合数按零解释。

第二项的条件期望为

$$P(X_{k+1} = \dots = X_n = 0 \mid T = t) = \frac{\binom{k}{t}}{\binom{n}{t}} = \frac{\binom{n-t}{n-k}}{\binom{n}{n-k}}.$$

由于 $\binom{n}{n-k} = \binom{n}{k}$, 得到

$$\hat{g}_{\text{UMVU}}(T) = \frac{\binom{T}{k}}{\binom{n}{k}} + \frac{\binom{n-T}{n-k}}{\binom{n}{n-k}}. \quad (22.46)$$



等价地,
$$\hat{g}_{\text{UMVU}}(T) = \frac{\binom{T}{k} + \binom{n-T}{n-k}}{\binom{n}{k}}.$$

由 Lehmann-Scheffé 定理, 该估计量为唯一 UMVUE。 □

注 22.26 (边界指标 $k=0$ 或 $k=n$). 若 $k=0$, $g(p) = 1 + (1-p)^n$, 公式给出 $1 + \mathbf{1}_{\{T=0\}}$ 。

若 $k=n$, $g(p) = p^n + 1$, 公式给出 $\mathbf{1}_{\{T=n\}} + 1$ 。

22.21 真题完整解法: $\text{Poisson}(\sqrt{\lambda})$ 模型

往年真题

[26S-Q10, 10 分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\sqrt{\lambda})$, $\lambda > 0$ 。

(1) 求 λ 的 UMVUE $\tilde{\lambda}$;

(2) 设 $\hat{\lambda}$ 为 MLE, 证明 $\sqrt{n}(\tilde{\lambda} - \hat{\lambda}) \xrightarrow{\mathbb{P}} 0$ 。

解: 令 $\mu = \sqrt{\lambda} > 0$ 。定义 $T = \sum_{i=1}^n X_i$ 。则 $T \sim \text{Poisson}(n\mu)$ 。Poisson 族是完全族, 因此 T 是关于 μ 的完全充分统计量。由于 $\lambda = \mu^2$ 是一一重参数化, T 对 λ 也完全充分。

Poisson 变量的二阶下降阶乘矩满足 $\mathbb{E}[T(T-1)] = (n\mu)^2 = n^2\lambda$ 。所以

$$\tilde{\lambda} = \frac{T(T-1)}{n^2}. \quad (22.47)$$

它是 T 的无偏函数, 由 Lehmann-Scheffé 定理即为 UMVUE。

另一方面, μ 的 MLE 为 $\hat{\mu} = \frac{T}{n}$ 。由 MLE 不变性,

$$\hat{\lambda} = \hat{\mu}^2 = \frac{T^2}{n^2}. \quad (22.48)$$

因此 $\tilde{\lambda} - \hat{\lambda} = -\frac{T}{n^2}$, 从而 $\sqrt{n}(\tilde{\lambda} - \hat{\lambda}) = -\frac{T}{n^{3/2}} = -\frac{1}{\sqrt{n}}\frac{T}{n}$ 。由大数定律, $\frac{T}{n} = \bar{X} \xrightarrow{\mathbb{P}} \mu = \sqrt{\lambda}$ 。故

$$\sqrt{n}(\tilde{\lambda} - \hat{\lambda}) \xrightarrow{\mathbb{P}} 0. \quad (22.49)$$

□

考试时需要注意的地方

MLE $\hat{\lambda} = \bar{X}^2$ 不是无偏的: $\mathbb{E}(\bar{X}^2) = \lambda + \frac{\sqrt{\lambda}}{n}$ 。UMVUE 通过下降阶乘修正了该偏差: $\frac{T(T-1)}{n^2}$ 。

22.22 真题完整解法：相关系数模型的极小充分性与非完全性

往年真题

[25S-Q9(b), 15 分题的一部分]

设 (X_i, Y_i) , $i = 1, \dots, n$, 相互独立, 且 $\begin{pmatrix} X_i \\ Y_i \end{pmatrix} \sim N_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$, $-1 < \rho < 1$. 求 ρ 的极小充分统计量, 并判断其是否完全。

解: 单个观测密度为 $f_\rho(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp \left\{ -\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)} \right\}$. 样本似然为 $L(\rho) = (2\pi)^{-n} (1-\rho^2)^{-n/2} \exp \left\{ -\frac{A_n - 2\rho B_n}{2(1-\rho^2)} \right\}$, 其中

$$A_n = \sum_{i=1}^n (X_i^2 + Y_i^2), \quad B_n = \sum_{i=1}^n X_i Y_i. \quad (22.50)$$

由因子分解定理, (A_n, B_n) 充分。

现用似然比判别极小性。对两个样本点 z, z' , 记 $\Delta A = A(z) - A(z')$, $\Delta B = B(z) - B(z')$. 对数似然比中含参数部分为

$$R(\rho) = \frac{-\Delta A/2 + \rho \Delta B}{1 - \rho^2}. \quad (22.51)$$

若该表达式关于 ρ 为常数 C , 则 $-\frac{\Delta A}{2} + \rho \Delta B = C(1 - \rho^2)$ 对所有 $\rho \in (-1, 1)$ 成立。比较多项式系数:
 $-\rho^2$ 项: $C = 0$; ρ 项: $\Delta B = 0$; $\Delta A = 0$. 反之, 若 $\Delta A = \Delta B = 0$, 似然比显然与 ρ 无关。

因此

$$T = (A_n, B_n) \quad (22.52)$$

是极小充分统计量。

下面判断完全性。对每个 ρ , 边缘分布均为标准正态, 所以 $\mathbb{E}_\rho X_i^2 = 1$, $\mathbb{E}_\rho Y_i^2 = 1$. 故 $\mathbb{E}_\rho A_n = 2n$ 对所有 ρ . 于是

$$g(T) = A_n - 2n \quad (22.53)$$

满足 $\mathbb{E}_\rho g(T) = 0$ 对所有 ρ , 但 $g(T)$ 显然不是几乎处处为零。因此

$$(A_n, B_n) \text{ 不完全}. \quad (22.54)$$

□

考试时需要注意的地方

本题必须区分:

- “二维统计量、一个参数”并不自动说明不完全;
- 真正的非完全性证明必须构造一个非零函数 $g(A_n, B_n)$ 使其对所有 ρ 均值为零;
- $A_n - 2n$ 是最直接的反例。

22.23 真题完整解法：受约束正态均值模型的 UMVUE

往年真题

[24S-Q11, 15 分]

参数满足 $\theta_1, \theta_2, \theta_3 \geq 0$, $\theta_1 + \theta_2 + \theta_3 = 1$ 。观测 $X_{ik} = \theta_k + \varepsilon_{ik}$, $i = 1, \dots, n$, $k = 1, 2, 3$, 其中所有 $\varepsilon_{ik} \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$ 。求 θ_1 的 UMVUE。

解：令 $S_k = \sum_{i=1}^n X_{ik}$, $\bar{X}_k = \frac{S_k}{n}$ 。联合似然中与参数有关的部分为 $\exp \left\{ \sum_{k=1}^3 \theta_k S_k - \frac{n}{2} \sum_{k=1}^3 \theta_k^2 \right\}$ 。利用约束 $\theta_3 = 1 - \theta_1 - \theta_2$, 有

$$\begin{aligned} \sum_{k=1}^3 \theta_k S_k &= \theta_1 S_1 + \theta_2 S_2 + (1 - \theta_1 - \theta_2) S_3 \\ &= S_3 + \theta_1 (S_1 - S_3) + \theta_2 (S_2 - S_3). \end{aligned}$$

数据项 S_3 可吸收到 $h(x)$ 中。因此

$$T_1 = S_1 - S_3, \quad T_2 = S_2 - S_3 \quad (22.55)$$

构成充分统计量。

自然参数为 (θ_1, θ_2) , 其内部参数空间为 $\{(\theta_1, \theta_2) : \theta_1 > 0, \theta_2 > 0, \theta_1 + \theta_2 < 1\}$, 这是 $\mathbb{R}^2$ 中非空开集。故由满秩指数族完全性定理, (T_1, T_2) 是完全充分统计量。

令 $d_1 = \theta_1 - \theta_3$, $d_2 = \theta_2 - \theta_3$ 。由 $\theta_1 + \theta_2 + \theta_3 = 1$ 解得 $\theta_1 = \frac{1+2d_1-d_2}{3}$ 。而 $\bar{X}_1 - \bar{X}_3$ 无偏估计 d_1 , $\bar{X}_2 - \bar{X}_3$ 无偏估计 d_2 。所以 $\hat{\theta}_1 = \frac{1+2(\bar{X}_1 - \bar{X}_3) - (\bar{X}_2 - \bar{X}_3)}{3}$ 无偏。

化简得

$$\hat{\theta}_{1, \text{UMVU}} = \frac{1 + 2\bar{X}_1 - \bar{X}_2 - \bar{X}_3}{3}. \quad (22.56)$$

该估计量是完全充分统计量 (T_1, T_2) 的函数, 故由 Lehmann-Scheffé 定理, 它是唯一 UMVUE。

其方差为

$$\begin{aligned} \text{Var}(\hat{\theta}_{1, \text{UMVU}}) &= \frac{1}{9} [4 \text{Var}(\bar{X}_1) + \text{Var}(\bar{X}_2) + \text{Var}(\bar{X}_3)] \\ &= \frac{1}{9} \left(\frac{4}{n} + \frac{1}{n} + \frac{1}{n} \right) \\ &= \frac{2}{3n}. \end{aligned}$$

相较于直接使用 $\bar{X}_1$ 的方差 $1/n$, 参数约束确实提供了额外信息。□

考试时需要注意的地方

不能把 (S_1, S_2, S_3) 直接当作三参数满指数族的自然统计量, 因为参数受约束 $\theta_1 + \theta_2 + \theta_3 = 1$ 。应先消去一个参数, 再寻找与自由参数维数相匹配的自然统计量。

22.24 真题完整解法：正态模型中 μ/σ 的 UMVUE

往年真题

[24F-Q10(b), 15 分题的一部分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\mu \geq 0$, $\sigma > 0$, $n \geq 2$. 求 $\frac{\mu}{\sigma}$ 的 UMVUE, 若其存在。

22.24.1 完全充分统计量

联合正态族的自然统计量为 $(\sum_i X_i, \sum_i X_i^2)$, 等价于 $T = (\bar{X}, S^2)$ 。自然参数为 $\eta_1 = \frac{\mu}{\sigma^2}$, $\eta_2 = -\frac{1}{2\sigma^2}$ 。当 $\mu > 0$, $\sigma > 0$ 时, $\eta_1 > 0$, $\eta_2 < 0$, 该集合包含 $\mathbb{R}^2$ 中非空开集。所以 $(\bar{X}, S^2)$ 是完全充分统计量。边界 $\mu = 0$ 不影响完全性, 因为完全性已由内部开参数集确定。

22.24.2 构造无偏估计量

记 $\nu = n - 1$, $U = \frac{\nu S^2}{\sigma^2} \sim \chi_\nu^2$ 。并且 $\bar{X} \perp S$ 。

当 $\nu > 1$, 即 $n \geq 3$ 时, $\mathbb{E}(U^{-1/2}) = 2^{-1/2} \frac{\Gamma((\nu-1)/2)}{\Gamma(\nu/2)}$ 。又 $S = \sigma \sqrt{\frac{U}{\nu}}$, 所以

$$\begin{aligned} \mathbb{E}\left(\frac{1}{S}\right) &= \frac{\sqrt{\nu}}{\sigma} \mathbb{E}(U^{-1/2}) \\ &= \frac{\sqrt{\nu}}{\sigma \sqrt{2}} \frac{\Gamma((\nu-1)/2)}{\Gamma(\nu/2)}. \end{aligned}$$

令

$$c_n = \frac{\sqrt{2} \Gamma(\nu/2)}{\sqrt{\nu} \Gamma((\nu-1)/2)} = \frac{\sqrt{2} \Gamma((n-1)/2)}{\sqrt{n-1} \Gamma((n-2)/2)}. \quad (22.57)$$

由独立性,

$$\begin{aligned} \mathbb{E}_{\mu, \sigma} \left[c_n \frac{\bar{X}}{S} \right] &= c_n \mathbb{E} \bar{X} \mathbb{E} \left(\frac{1}{S} \right) \\ &= c_n \mu \frac{\sqrt{\nu}}{\sigma \sqrt{2}} \frac{\Gamma((\nu-1)/2)}{\Gamma(\nu/2)} \\ &= \frac{\mu}{\sigma}. \end{aligned}$$


因此对 $n \geq 3$,

$$\delta_n = c_n \frac{\bar{X}}{S} \quad (22.58)$$

是唯一的可积无偏函数。

22.24.3 二阶矩与 UMVUE 的存在条件

UMVUE 的通常定义要求有限方差。当 $\nu > 2$, 即 $n \geq 4$ 时, $\mathbb{E}(U^{-1}) = \frac{1}{\nu-2}$ 。故 $\mathbb{E}\left(\frac{1}{S^2}\right) = \frac{\nu}{\sigma^2(\nu-2)}$ 。于是 δ_n 具有有限二阶矩。



由完全充分性和 Lehmann–Scheffé 定理, 对 $n \geq 4$,

$$\widehat{\mu/\sigma}_{\text{UMVU}} = \frac{\sqrt{2}\Gamma((n-1)/2)}{\sqrt{n-1}\Gamma((n-2)/2)} \frac{\bar{X}}{\bar{S}}. \quad (22.59)$$

若记 $\Delta = \frac{\mu}{\sigma}$, 其方差为

$$\text{Var}(\delta_n) = c_n^2 \frac{\nu}{\nu-2} \left(\Delta^2 + \frac{1}{n} \right) - \Delta^2, \quad n \geq 4. \quad (22.60)$$

22.24.4 为什么小样本情形必须单独讨论

命题 22.27. 在通常要求有限方差的 UMVUE 定义下:

$n \geq 4$	UMVUE 存在, 且由 (22.59) 给出
$n = 3$	存在唯一可积无偏估计量, 但其方差无穷, 故无有限方差 UMVUE
$n = 2$	不存在可积无偏估计量

证明. 当 $n = 3$ 时, $\nu = 2$ 。此时 $\mathbb{E}(U^{-1/2}) < \infty$, 所以 (22.58) 仍无偏; 但 $\mathbb{E}(U^{-1}) = \infty$, 所以 $\mathbb{E}\left(\frac{\bar{X}^2}{\bar{S}^2}\right) = \infty$ 。若存在另一个有限方差无偏估计量, 将其 Rao–Blackwell 化到完全充分统计量 $(\bar{X}, S^2)$ 后, 所得估计量仍具有有限方差。完全性又迫使它等于 (22.58), 形成矛盾。

下面说明 $n = 2$ 时不存在可积无偏估计量。这里只给出资格考试所需的完整识别框架。

假设存在可积无偏估计量。先 Rao–Blackwell 化, 可设其为 $\psi(\bar{X}, S)$ 的形式。

目标参数 μ/σ 在同时变换 $(\mu, \sigma) \mapsto (a\mu, a\sigma)$, $a > 0$, 下不变。因此 $\psi_a(x, s) = \psi(ax, as)$ 也是同一参数的无偏估计量。由完全性, $\psi(ax, as) = \psi(x, s)$ a.e. 所以存在函数 h , 使 $\psi(\bar{X}, S) = h\left(\frac{\bar{X}}{S}\right)$ 。

令 $\nu = n - 1$, $Z = \frac{\sqrt{n}\bar{X}}{\sigma} \sim N\left(\sqrt{n}\frac{\mu}{\sigma}, 1\right)$, $B = \frac{\sqrt{\nu}S}{\sigma} \sim \sqrt{\chi_\nu^2}$, $Z \perp B$ 。则 $\frac{\bar{X}}{S} = \sqrt{\frac{\nu}{n}} \frac{Z}{B}$ 。

无偏性要求 $\mathbb{E}h\left(\sqrt{\frac{\nu}{n}} \frac{Z}{B}\right) = \frac{\mu}{\sigma}$ 。对正态位置参数使用卷积唯一性, 再对正尺度混合使用 Mellin 变换唯一性, 可得唯一可能的形式为 $h(r) = cr$ 。而当 $n = 2$ 时 $\nu = 1$, $\frac{\bar{X}}{S}$ 具有 Cauchy 型尾部, 满足 $\mathbb{E}\left|\frac{\bar{X}}{S}\right| = \infty$ 。因此任何非零线性函数 cr 都不可积; $c = 0$ 又不能无偏估计 μ/σ 。故不存在可积无偏估计量。□

考试时需要注意的地方

若试卷未要求讨论所有小样本边界, 并默认无偏估计量具有有限方差, 应至少写明: $n \geq 4$ 时 UMVUE 为 (22.59)。

若题目明确给出 $n \geq 2$ 且写有“if it exists”, 完整答案必须讨论 $n = 2, 3$ 。

22.25 证明套路总结

22.25.1 证明充分性

证明思路

识别信号：联合密度可将所有参数依赖压缩到少数样本函数中。

构造步骤：

- (1) 写完整联合密度，包括支持集指示函数；
- (2) 把含参数部分集中到 $g_{\theta}(T(x))$ ；
- (3) 剩余部分写成不含参数的 $h(x)$ ；
- (4) 引用因子分解定理。

常见失败：

- 丢掉参数依赖支持集；
- 把含参数的因子误放入 $h(x)$ ；
- 只写“似然依赖于 T ”，但未展示具体分解。

22.25.2 证明极小充分性

证明思路

识别信号：题目明确要求“minimal sufficient”。

构造步骤：

- (1) 取两个样本点 x, y ；
- (2) 化简 $f_{\theta}(x)/f_{\theta}(y)$ ；
- (3) 找出比值与参数无关的充要条件；
- (4) 将该条件写成 $T(x) = T(y)$ ；
- (5) 引用似然比判别法。

常见失败：只证明了 $T(x) = T(y) \implies \frac{f_{\theta}(x)}{f_{\theta}(y)}$ 与参数无关，却未证明逆方向。这只能帮助证明充分性，不能完成极小性。



22.25.3 证明完全性

证明思路

统一起点：假设 $\mathbb{E}_\theta[g(T)] = 0$ 对所有 θ 。

按模型选择工具：

模型	证明工具
Binomial	变为关于 $p/(1-p)$ 的多项式
Poisson	乘以 e^λ ，使用幂级数唯一性
Gamma/Exponential	使用 Laplace 变换唯一性
Uniform(0, θ) 极大值	将积分上限视为参数并求导
满秩指数族	多元 Laplace 变换或 MGF 唯一性

常见失败：只写“属于指数族，所以完全”，但未核查自然参数空间是否包含开集。

22.25.4 求 UMVUE

证明思路

识别信号：题目出现 UMVU、UMVUE、BUE、best unbiased。

标准流程：

完全充分 T + 任意粗糙无偏 $W \implies \mathbb{E}(W \mid T)$.

粗糙无偏估计量的常见来源：

- $\mathbf{1}_{\{X_1 \in A\}}$ 无偏估计概率 $P_\theta(X_1 \in A)$ ；
- $X_1 X_2 \cdots X_k$ 在 Bernoulli 模型中无偏估计 p^k ；
- 下降阶乘 $(T)_k$ 产生 Poisson 或 Binomial 参数幂；
- 次序统计量的适当常数倍；
- 参数约束给出的线性恒等式。



22.26 易错点总表

陈述	判断	正确说明
完整样本总是极小充分	错	完整样本总是充分，但通常不是极小充分。
统计量维数等于参数维数就充分	错	充分性由条件分布或因子分解决定。
一一变换会改变充分性	错	一一变换生成同一 σ -代数，充分性和极小充分性均不变。
极小充分统计量一定完全	错	相关系数模型和位置 Uniform 模型均给出反例。
完全统计量一定充分	错	完全性与充分性是不同性质。
完全充分统计量不一定极小充分	错	在通常控制模型中，完全充分推出极小充分。
辅助统计量与参数无关，所以没有任何用途	错	其边缘分布无参数，但条件推断中可能非常重要。
Basu 定理只需要充分统计量	错	必须是完全充分统计量。
Rao-Blackwell 可条件于任意统计量得到更好估计量	不完整	方差虽不增加，但若条件统计量不充分，条件期望可能依赖未知参数。
Rao-Blackwell 后方差一定严格下降	错	若原估计量已是 T 的函数，则方差相等。
基于完全充分统计量的任意函数都是 UMVUE	错	还必须无偏估计所讨论的参数函数，并具有所需有限方差。
UMVUE 在所有估计量中 MSE 最小	错	UMVUE 只在无偏估计量类中比较方差。有偏估计量可能具有更小 MSE。
Cramér-Rao 下界达到者才可能是 UMVUE	错	Lehmann-Scheffé 可在下界不可达到或正则条件失效时确定 UMVUE。
指数族的自然统计量总是完全	错	需要自然参数像包含相应欧氏空间中的非空开集。
参数依赖支持集不可能有完全充分统计量	错	$U(0, \theta)$ 的极大值就是完全充分统计量。

22.27 答题模板

证明 T 是完全充分统计量

- (1) 写出联合密度；
- (2) 用因子分解定理证明充分；
- (3) 明确写出 T 的分布；
- (4) 假设 $\mathbb{E}_{\theta}g(T) = 0$ ；
- (5) 使用多项式、幂级数、Laplace 变换或求导证明 $g(T) = 0$ a.s.；
- (6) 得出“ T 完全充分”，而不是分别含糊写“充分且应该完全”。

求 UMVUE

- (1) 找到并证明完全充分统计量 T ;
- (2) 构造一个容易验证的无偏估计量 W ;
- (3) 计算 $\phi(T) = \mathbb{E}(W | T)$;
- (4) 验证结果中不含未知参数;
- (5) 明确引用 Rao–Blackwell + Lehmann–Scheffé;
- (6) 检查二阶矩和样本量条件;
- (7) 若题目为 15 分, 不能只写最终公式。

判断极小充分统计量是否完全

- (1) 先用似然比判别法证明极小充分;
- (2) 若怀疑不完全, 寻找 T 的某个分量或函数, 其期望不依赖参数;
- (3) 构造 $g(T) = h(T) - \mathbb{E}_\theta h(T)$;
- (4) 验证该中心化常数确实对所有参数相同;
- (5) 证明 $g(T)$ 非退化。

一些需要记忆的内容

- (1) 因子分解定理中的 $h(x)$ 是否可以依赖参数?
- (2) 如何用两个样本点的似然比证明极小充分性?
- (3) 极小充分统计量和低维统计量是否是同一概念?
- (4) 为什么 $\sum_i X_i$ 在 Bernoulli 模型中完全?
- (5) 为什么 $\text{Uniform}(0, \theta)$ 极大值的完全性不能直接引用正则指数族定理?
- (6) 满指数族完全性中“自然参数像含开集”有什么作用?
- (7) Rao–Blackwell 条件于非充分统计量时会发生什么问题?
- (8) Lehmann–Scheffé 定理需要哪些条件?
- (9) Basu 定理中的两个统计量分别需要满足什么条件?
- (10) 在指数样本中, 为什么总和与标准化比例向量独立?



第二十三章 矩估计、最大似然估计与估计量评价

23.1 考试大纲定位与重要性

重点

重要性等级：S 级。

点估计题在历年资格考试中通常不只要求写出估计量，而要求同时处理：

推导 + 参数空间 + 边界 + 存在性 + 唯一性 + 相合性 + 渐近分布.

必须会完整证明或推导：

- 矩估计方程及其相合性的连续映射证明；
- 一维和多维 MLE 的标准求解流程；
- MLE 不变性；
- 指数族中对数似然的凹性；
- 支持集依赖参数时的边界极值；
- MLE 不存在、不唯一及扩展 MLE 的区分；
- 偏差-方差-MSE 分解；
- 真题中的正则与非正则渐近分布。

直接真题对应：

[24F-Q7(a)], [24F-Q11, 15 分],
[24S-Q9, 10 分], [25S-Q8(b)],
[25S-Q11, 15 分], [26S-Q11(b)].

23.2 点估计量、估计值与参数空间

定义 23.1 (点估计量). 设 $X = (X_1, \dots, X_n)$ 为样本，参数为 $\tau(\theta) \in \mathcal{A}$ 。任意不含未知参数的可测函数 $\delta: \mathcal{X}^n \rightarrow \mathcal{A}$ 均称为 $\tau(\theta)$ 的点估计量。

观测到 $X = x$ 后， $\delta(x)$ 称为估计值。



前提条件检查

估计量应当取值于预先规定的动作空间 $\mathcal{A}$ 。

若目标参数满足 $\theta > 0$, 而某种方法产生负数, 则该表达式虽然仍是统计量, 但不是严格意义上的参数空间值估计量。

常见处理方式包括:

- 修改估计量, 例如投影到参数空间闭包;
- 使用约束优化;
- 明确称为“形式矩估计解”, 并说明其可能不可行。

23.3 矩估计法**23.3.1 一般定义**

设模型含 k 个未知参数: $\theta = (\theta_1, \dots, \theta_k)^\top \in \Theta \subseteq \mathbb{R}^k$ 。假设总体前 k 阶原点矩存在:

$$\mu'_j(\theta) = \mathbb{E}_\theta X^j, \quad j = 1, \dots, k. \quad (23.1)$$

相应样本矩为

$$M_{j,n} = \frac{1}{n} \sum_{i=1}^n X_i^j. \quad (23.2)$$

定义 23.2 (矩估计量). 矩估计量 $\tilde{\theta}_n = (\tilde{\theta}_{1,n}, \dots, \tilde{\theta}_{k,n})^\top$ 由方程组

$$M_{j,n} = \mu'_j(\theta), \quad j = 1, \dots, k \quad (23.3)$$

的解给出。

更一般地, 可以选择可测函数 $h_1, \dots, h_k$ 并解

$$\frac{1}{n} \sum_{i=1}^n h_j(X_i) = \mathbb{E}_\theta h_j(X), \quad j = 1, \dots, k. \quad (23.4)$$

考试时需要注意的地方

“有 k 个参数就取前 k 阶矩”只是一种常用规则, 并非数学上唯一的选择。

不同矩条件可能产生不同估计量。例如 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$ 时: $\mathbb{E}X = \lambda$, $\text{Var}(X) = \lambda$ 。由样本均值或样本方差都能得到无偏估计量, 但二者的方差通常不同。

23.3.2 矩估计相合性的标准定理

定理 23.3 (矩估计相合性). 设 $X_1, X_2, \dots \stackrel{\text{i.i.d.}}{\sim} P_\theta$. 定义矩映射

$$m(\theta) = \begin{pmatrix} \mathbb{E}_\theta h_1(X) \\ \vdots \\ \mathbb{E}_\theta h_k(X) \end{pmatrix}, \quad (23.5)$$

并令

$$\hat{m}_n = \begin{pmatrix} n^{-1} \sum_{i=1}^n h_1(X_i) \\ \vdots \\ n^{-1} \sum_{i=1}^n h_k(X_i) \end{pmatrix}. \quad (23.6)$$

假设:

- (1) 对每个 j , $\mathbb{E}_\theta |h_j(X)| < \infty$;
- (2) m 在参数真值 θ 附近是一一对应的;
- (3) 逆映射 m^{-1} 在 $m(\theta)$ 处连续;
- (4) 以概率趋于 1, $\hat{m}_n$ 落在 m 的逆映射定义域内。

则

$$\tilde{\theta}_n = m^{-1}(\hat{m}_n) \xrightarrow{\mathbb{P}} \theta. \quad (23.7)$$

若使用强大数律, 则相应地有 $\tilde{\theta}_n \xrightarrow{\text{a.s.}} \theta$ 。

证明. 由大数律, $\hat{m}_n \xrightarrow{\mathbb{P}} m(\theta)$. 由连续映射定理, $m^{-1}(\hat{m}_n) \xrightarrow{\mathbb{P}} m^{-1}(m(\theta)) = \theta$. □

前提条件检查

下列条件不能忽略:

- 若矩映射不了一一对应, 则参数可能不可由所选矩识别;
- 若逆映射在真值处不连续, 则小的样本矩误差可能导致大的参数误差;
- 若样本矩落在总体矩空间之外, 矩方程可能无解;
- 若所用总体矩不存在, 则矩估计法本身无定义。


23.3.3 正态模型的矩估计

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$. 总体前两阶原点矩为 $\mathbb{E}X = \mu$, $\mathbb{E}X^2 = \mu^2 + \sigma^2$. 令 $M_{1,n} = \bar{X}$, $M_{2,n} = \frac{1}{n} \sum_{i=1}^n X_i^2$. 解方程 $\bar{X} = \mu$, $M_{2,n} = \mu^2 + \sigma^2$ 得到

$$\tilde{\mu} = \bar{X}, \quad (23.8)$$

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (23.9)$$

注意 $\tilde{\sigma}^2 = \frac{n-1}{n} S^2$, 因此它不是 σ^2 的无偏估计量。



23.3.4 Uniform 模型中的参数空间冲突

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$ 。因为 $\mathbb{E}X = \frac{\theta}{2}$, 矩估计量为

$$\tilde{\theta} = 2\bar{X}. \quad (23.10)$$

但是由样本支持约束, 任何与观测相容的参数必须满足 $\theta \geq X_{(n)}$ 。矩估计量可能出现 $2\bar{X} < X_{(n)}$ 。此时 $\tilde{\theta}$ 与已观测样本的支持约束冲突。

考试时需要注意的地方

矩估计法只匹配总体矩, 不自动使用全部支持信息。

因此: 矩估计量可能相合, 但有限样本下不满足参数可行性约束。

23.3.5 两个未知参数的 Binomial 模型

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Bin}(k, p)$, 其中整数 k 与 p 均未知。记 $V_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 。由 $\mathbb{E}X = kp$, $\text{Var } X = kp(1-p)$ 得到 $k = \frac{(\mathbb{E}X)^2}{\mathbb{E}X - \text{Var } X}$, $p = \frac{\mathbb{E}X}{k}$ 。形式矩估计解为

$$\tilde{k} = \frac{\bar{X}^2}{\bar{X} - V_n}, \quad \tilde{p} = \frac{\bar{X}}{\tilde{k}}. \quad (23.11)$$

可能出现: $V_n > \bar{X}$, 从而 $\tilde{k} < 0$, $\tilde{p} < 0$ 。即使 $\tilde{k} > 0$, 它也未必是整数或满足 $\tilde{k} \geq X_{(n)}$ 。

这说明矩估计法的主要优点是计算简单, 而不是自动满足最优性或参数空间约束。

23.4 似然函数与最大似然估计

23.4.1 似然函数

定义 23.4 (似然函数). 设观测 $X = x$ 的联合密度或质量函数为 $f_{\theta}(x)$ 。将 x 固定并把该表达式视为参数 θ 的函数:

$$L(\theta | x) = f_{\theta}(x), \quad (23.12)$$

称为似然函数。

若样本为 i.i.d.,

$$L(\theta | x_1, \dots, x_n) = \prod_{i=1}^n f(x_i | \theta). \quad (23.13)$$

对数似然定义为

$$\ell(\theta | x) = \log L(\theta | x), \quad (23.14)$$

并约定 $\log 0 = -\infty$ 。



概念比较

密度与似然使用同一个代数表达式，但自变量角色不同：

	固定量	变化量
$f(x \theta)$	θ	x
$L(\theta x)$	x	θ

尤其地， $\int L(\theta | x) d\theta$ 不必等于 1；似然不是参数的概率密度。

考试时需要注意的地方

频率学派中参数 θ 是固定但未知的常数。因此不能把 $\frac{L(\theta_1|x)}{L(\theta_2|x)}$ 解释为 $\frac{P(\theta=\theta_1|X=x)}{P(\theta=\theta_2|X=x)}$ ，除非另行引入先验分布。

23.4.2 MLE 的集合值定义

定义 23.5 (最大似然估计集合). 对给定样本点 x ，定义

$$\hat{\Theta}(x) = \arg \max_{\theta \in \Theta} L(\theta | x). \quad (23.15)$$

可能出现三种情况：

- (1) $\hat{\Theta}(x) = \{\hat{\theta}(x)\}$, MLE 唯一；
- (2) $|\hat{\Theta}(x)| > 1$, MLE 不唯一；
- (3) $\hat{\Theta}(x) = \emptyset$, 似然上确界不在参数空间内达到，MLE 不存在。

定义 23.6 (MLE). 若可选择一个可测函数 $\hat{\theta}(x) \in \hat{\Theta}(x)$ ，则称 $\hat{\theta}(X)$ 为最大似然估计量。

定义 23.7 (扩展 MLE). 若似然在 Θ 内不达到最大值，但在闭包 $\bar{\Theta}$ 上达到最大值，有时称闭包上的最大点为扩展 MLE。

扩展 MLE 不一定属于原参数空间，必须与严格意义下的 MLE 区分。

23.5 MLE 的标准求解流程

MLE 参考求解流程

- (1) 写出完整似然，包括支持集指示函数；
- (2) 写明参数空间 Θ ；
- (3) 能取对数时写 $\ell(\theta) = \log L(\theta)$ ；
- (4) 对内部点求 score 方程 $\nabla_{\theta} \ell(\theta) = 0$ ；
- (5) 检查 Hessian、凹性或其他全局极值条件；
- (6) 检查参数空间边界；
- (7) 检查支持约束导致的分段情形；

- (8) 检查最大值是否真的达到;
- (9) 检查是否唯一;
- (10) 对参数函数使用 MLE 不变性时, 说明原 MLE 已存在。

考试时需要注意的地方

解出 $\ell'(\theta) = 0$ 只得到驻点候选。

驻点可能是: 局部极大、局部极小、鞍点或拐点。而最大值也可能:

- 位于边界;
- 位于参数依赖支持集的端点;
- 只在参数空间闭包上达到;
- 根本不存在。

23.6 MLE 的存在性与唯一性

定理 23.8 (一个常用存在性充分条件). 若:

- (1) 参数空间 Θ 为紧集;
- (2) 对固定样本 x , 函数 $\theta \mapsto L(\theta | x)$ 在 Θ 上上半连续;

则 $\hat{\Theta}(x)$ 非空。

证明. 由 Weierstrass 极值定理, 上半连续函数在紧集上达到其上确界。□

定理 23.9 (严格凹性保证至多一个最大点). 若 Θ 为凸集, 并且 $\ell(\theta | x)$ 在 Θ 上严格凹, 则 MLE 至多一个。

若存在内部点 $\hat{\theta}$ 满足 $\nabla \ell(\hat{\theta}) = 0$, 则它是唯一全局最大点。

证明. 若存在两个不同最大点 θ_1, θ_2 , 则对 $0 < t < 1$, 严格凹性给出 $\ell(t\theta_1 + (1-t)\theta_2) > t\ell(\theta_1) + (1-t)\ell(\theta_2)$, 右侧等于最大值, 矛盾。□

23.6.1 自然指数族中的凹性

定理 23.10 (指数族对数似然的凹性). 设 $f_\eta(x) = h(x) \exp\{\eta^\top T(x) - A(\eta)\}$, $\eta \in \mathcal{H}$, 其中 $\mathcal{H}$ 为凸的自然参数空间。对 i.i.d. 样本,

$$\ell_n(\eta) = \eta^\top \sum_{i=1}^n T(X_i) - nA(\eta) + \sum_{i=1}^n \log h(X_i). \quad (23.16)$$

则

$$\nabla \ell_n(\eta) = \sum_{i=1}^n T(X_i) - n\nabla A(\eta), \quad (23.17)$$

$$\nabla^2 \ell_n(\eta) = -n\nabla^2 A(\eta) = -n \text{Cov}_\eta(T(X)) \preceq 0. \quad (23.18)$$

因此 ℓ_n 为凹函数。

若 $\text{Cov}_\eta(T(X))$ 在参数空间中处处正定, 则 ℓ_n 严格凹。

推论 23.11 (指数族似然方程). 若 MLE 是自然参数空间内部点, 则它满足

$$\frac{1}{n} \sum_{i=1}^n T(X_i) = \mathbb{E}_{\hat{\eta}} T(X). \quad (23.19)$$

前提条件检查

即使对数似然严格凹, MLE 也未必存在。

严格凹性只保证: 若最大点存在, 则它至多一个。

在指数族中, 内部 MLE 的存在通常还要求样本自然统计量均值 $\bar{T} = \frac{1}{n} \sum_i T(X_i)$ 落在均值参数空间 $\nabla A(\mathcal{H})$ 内。若落在边界上, 最大值可能只在 $\|\eta\| \rightarrow \infty$ 时逼近。

23.7 MLE 的不变性

定理 23.12 (MLE 不变性). 设 $\hat{\theta}$ 是 θ 的 MLE , $\tau: \Theta \rightarrow \mathcal{H}$ 为任意函数。定义参数 $\eta = \tau(\theta)$ 的诱导似然为

$$L_{\eta}(\eta | x) = \sup_{\theta: \tau(\theta) = \eta} L(\theta | x). \quad (23.20)$$

则

$$\hat{\eta} = \tau(\hat{\theta}) \quad (23.21)$$

是 $\eta = \tau(\theta)$ 的 MLE 。

证明. 任取 $\eta \in \tau(\Theta)$, $L_{\eta}(\eta | x) \leq \sup_{\theta \in \Theta} L(\theta | x) = L(\hat{\theta} | x)$ 。另一方面, $L_{\eta}(\tau(\hat{\theta}) | x) \geq L(\hat{\theta} | x)$ 。故 $L_{\eta}(\tau(\hat{\theta}) | x) = \sup_{\eta} L_{\eta}(\eta | x)$ 。□

考试时需要注意的地方

MLE 不变性与无偏性无关。

即使 $\hat{\theta}$ 无偏, 一般也没有 $\mathbb{E}[\tau(\hat{\theta})] = \tau(\theta)$ 。

此外:

- 若原 MLE 不存在, 不变性不能创造 MLE ;
- 若原 MLE 不唯一, 不同最大点经 τ 映射后可能给出不同结果;
- 非一一函数 τ 应使用诱导或 profile likelihood 理解。


23.8 充分统计量与 MLE

若 T 充分, 且 $L(\theta | x) = g_{\theta}(T(x))h(x)$, 其中 h 不含 θ , 则

$$\arg \max_{\theta} L(\theta | x) = \arg \max_{\theta} g_{\theta}(T(x)). \quad (23.22)$$

因此最大点集合只通过 $T(x)$ 依赖样本。

注 23.13. 若 MLE 唯一, 则它必为充分统计量的函数。



若 MLE 不唯一, 最大点集合仍只依赖 T ; 但若任意选择不同最大点而不规定统一选择规则, 所得到的选择可能人为依赖样本的其他部分。

23.9 常见模型的 MLE

23.9.1 Bernoulli 模型

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, $0 \leq p \leq 1$, 并记 $S_n = \sum_{i=1}^n X_i$ 。似然为 $L(p) = p^{S_n}(1-p)^{n-S_n}$ 。当 $0 < S_n < n$ 时, $\ell'(p) = \frac{S_n}{p} - \frac{n-S_n}{1-p}$, 所以 $\hat{p} = \frac{S_n}{n}$ 。且 $\ell''(p) = -\frac{S_n}{p^2} - \frac{n-S_n}{(1-p)^2} < 0$ 。当 $S_n = 0$ 时最大点为 $p = 0$; 当 $S_n = n$ 时最大点为 $p = 1$ 。故统一写为

$$\boxed{\hat{p}_{\text{MLE}} = \bar{X}.} \quad (23.23)$$

23.9.2 Poisson 模型

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$ 。忽略不含参数的项, $\ell(\lambda) = -n\lambda + S_n \log \lambda$ 。因此 $\ell'(\lambda) = -n + \frac{S_n}{\lambda}$ 。若 $S_n > 0$, $\hat{\lambda} = \frac{S_n}{n}$ 。若参数空间为 $[0, \infty)$, 则 $S_n = 0$ 时 $\hat{\lambda} = 0$ 。故

$$\boxed{\hat{\lambda}_{\text{MLE}} = \bar{X}.} \quad (23.24)$$

若参数空间严格规定为 $(0, \infty)$, 则当 $S_n = 0$ 时最大值只在 $\lambda \downarrow 0$ 时逼近, 严格意义下 MLE 不存在。

23.9.3 指数分布

若 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ 采用率参数, 则 $\ell(\lambda) = n \log \lambda - \lambda \sum_i X_i$ 。故

$$\boxed{\hat{\lambda} = \frac{1}{\bar{X}}.} \quad (23.25)$$


若采用尺度参数 $\beta = 1/\lambda$, 则由不变性

$$\boxed{\hat{\beta} = \bar{X}.} \quad (23.26)$$

23.9.4 正态总体, 两个参数均未知

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ 。对数似然为 $\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$ 。对 μ 最大化得到 $\hat{\mu} = \bar{X}$ 。代回后对 σ^2 最大化: $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 。因此

$$\boxed{\hat{\mu}_{\text{MLE}} = \bar{X}, \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.} \quad (23.27)$$



前提条件检查

若所有观测恰好相等, 则 $\sum_i (X_i - \bar{X})^2 = 0$ 。由于参数空间要求 $\sigma^2 > 0$, 此时似然在 $\mu = \bar{X}$, $\sigma^2 \downarrow 0$ 时趋于无穷, 有限 MLE 不存在。

对连续正态样本且 $n \geq 2$, 该事件概率为零; 但若题目问“对每个样本是否存在”, 不能忽略这一点。

23.9.5 Uniform(0, θ) 模型

在标准闭支持版本 $f(x | \theta) = \frac{1}{\theta} \mathbf{1}_{\{0 \leq x \leq \theta\}}$ 下, $L(\theta) = \theta^{-n} \mathbf{1}_{\{\theta \geq X_{(n)}\}} \mathbf{1}_{\{X_{(1)} \geq 0\}}$ 。在可行区间 $\theta \geq X_{(n)}$ 上, θ^{-n} 严格递减, 故

$$\hat{\theta}_{\text{MLE}} = X_{(n)}. \quad (23.28)$$

这类题不能通过普通 score 方程求解, 因为最大点由参数依赖支持集产生。

23.9.6 MLE 不唯一: 固定长度位置 Uniform 模型

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(\theta - \frac{1}{2}, \theta + \frac{1}{2})$ 。似然非零当且仅当 $X_{(n)} - \frac{1}{2} \leq \theta \leq X_{(1)} + \frac{1}{2}$ 。在该区间上似然恒为 1。因此

$$\hat{\Theta}(X) = \left[X_{(n)} - \frac{1}{2}, X_{(1)} + \frac{1}{2} \right]. \quad (23.29)$$

只要样本极差不超过 1, 区间非空。

MLE 可以是一个区间, 而不是唯一数值。

23.10 真题型: 只观察正态样本的符号

往年真题

[24F-Q7(a), 10 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$, 但只记录 $Y_i = \mathbf{1}_{\{X_i < 0\}}$ 。求基于 $Y_1, \dots, Y_n$ 的 μ 的 MLE。

解: 记 $q(\mu) = P_\mu(X_i < 0) = \Phi(-\mu)$ 。则 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(q(\mu))$ 。令 $S = \sum_{i=1}^n Y_i$ 。似然为 $L(\mu) = \Phi(-\mu)^S [1 - \Phi(-\mu)]^{n-S}$ 。

映射 $\mu \mapsto q(\mu) = \Phi(-\mu)$ 是从 $\mathbb{R}$ 到 $(0, 1)$ 的一一连续映射。

若 $0 < S < n$, Bernoulli 参数的 MLE 为 $\hat{q} = \frac{S}{n}$ 。故

$$\hat{\mu} = -\Phi^{-1}\left(\frac{S}{n}\right) = \Phi^{-1}\left(1 - \frac{S}{n}\right). \quad (23.30)$$

若 $S = 0$, 似然为 $L(\mu) = \Phi(\mu)^n$, 随 μ 严格增加, 且 $L(\mu) \uparrow 1$ ($\mu \rightarrow +\infty$)。最大值不在 $\mathbb{R}$ 中达到, 所以有限 MLE 不存在; 扩展 MLE 为 $+\infty$ 。

若 $S = n$, 同理有限 MLE 不存在, 扩展 MLE 为 $-\infty$ 。 □



考试时需要注意的地方

不能无条件写 $\hat{\mu} = -\Phi^{-1}(S/n)$, 因为当 $S/n \in \{0, 1\}$ 时, Φ^{-1} 不是有限实数。
该题同时考查: 参数变换不变性 + 边界样本 + MLE 存在性。

23.11 估计量的偏差、方差与 MSE

设 δ 用于估计标量参数函数 $\tau(\theta)$ 。

定义 23.14 (偏差).

$$\text{Bias}_\theta(\delta) = \mathbb{E}_\theta[\delta] - \tau(\theta).$$

(23.31)

若对所有 θ , $\text{Bias}_\theta(\delta) = 0$, 则称 δ 无偏。

定义 23.15 (均方误差).

$$\text{MSE}_\theta(\delta) = \mathbb{E}_\theta [(\delta - \tau(\theta))^2].$$

(23.32)

定理 23.16 (偏差-方差分解). 若 δ 具有有限二阶矩, 则

$$\text{MSE}_\theta(\delta) = \text{Var}_\theta(\delta) + \text{Bias}_\theta(\delta)^2.$$

(23.33)

证明. 写成 $\delta - \tau = (\delta - \mathbb{E}\delta) + (\mathbb{E}\delta - \tau)$. 平方后取期望. 交叉项为 $2(\mathbb{E}\delta - \tau)\mathbb{E}(\delta - \mathbb{E}\delta) = 0$. □

概念比较		
指标	衡量内容	不能推出的结论
偏差	长期平均估计误差	无偏不保证方差小或 MSE 小
方差	估计量自身波动	方差小不保证靠近真值, 常数估计量方差为零
MSE	平均平方距离	在全部估计量中通常不存在逐点统一最优者
相合性	样本量趋于无穷时是否接近真值	不说明有限样本 MSE 大小

23.11.1 无偏样本方差与正态 MLE 方差估计的比较

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, 并记 $S^2 = \frac{1}{n-1} \sum_i (X_i - \bar{X})^2$. 无偏估计量 S^2 满足 $\text{MSE}(S^2) = \text{Var}(S^2) = \frac{2\sigma^4}{n-1}$.
MLE 为 $\hat{\sigma}_{\text{MLE}}^2 = \frac{n-1}{n} S^2$. 其偏差为


$$\text{Bias}(\hat{\sigma}_{\text{MLE}}^2) = -\frac{\sigma^2}{n}.$$

(23.34)

其方差为

$$\text{Var}(\hat{\sigma}_{\text{MLE}}^2) = \frac{2(n-1)}{n^2} \sigma^4.$$

(23.35)



所以

$$\text{MSE}(\hat{\sigma}_{\text{MLE}}^2) = \frac{2n-1}{n^2} \sigma^4. \quad (23.36)$$

并且

$$\frac{2n-1}{n^2} \sigma^4 < \frac{2}{n-1} \sigma^4. \quad (23.37)$$

考试时需要注意的地方

S^2 是 σ^2 的 UMVUE, 只说明它在**无偏估计量类**中具有最小方差。
它不保证在所有估计量中具有最小 MSE。本例中有偏的 MLE 具有更小 MSE。

23.12 相合性与渐近无偏性

定义 23.17 (弱相合). 估计量序列 δ_n 称为 $\tau(\theta)$ 的弱相合估计量, 若

$$\delta_n \xrightarrow{\mathbb{P}} \tau(\theta) \text{ 对每个固定 } \theta. \quad (23.38)$$

定义 23.18 (强相合). 若

$$\delta_n \xrightarrow{\text{a.s.}} \tau(\theta), \quad (23.39)$$

则称其强相合。

定义 23.19 (渐近无偏). 若

$$\mathbb{E}_\theta \delta_n \longrightarrow \tau(\theta), \quad (23.40)$$

则称其渐近无偏。

命题 23.20 (MSE 相合推出依概率相合). 若

$$\text{MSE}_\theta(\delta_n) \longrightarrow 0, \quad (23.41)$$

则 $\delta_n \xrightarrow{\mathbb{P}} \tau(\theta)$ 。

证明. 由 Markov 不等式, $P_\theta(|\delta_n - \tau(\theta)| > \varepsilon) \leq \frac{\mathbb{E}_\theta(\delta_n - \tau(\theta))^2}{\varepsilon^2} \rightarrow 0$ 。

□

推论 23.21. 若 $\text{Bias}_\theta(\delta_n) \rightarrow 0$ 且 $\text{Var}_\theta(\delta_n) \rightarrow 0$, 则 δ_n 相合。

考试时需要注意的地方

相合不自动推出无偏, 也不自动推出矩收敛。
依概率收敛允许估计量在小概率事件上取极大值。若要推出 $\mathbb{E}\delta_n \rightarrow \tau(\theta)$, 还需要一致可积性或适当矩控制。

23.13 相对效率

若 δ_1, δ_2 均无偏估计同一参数函数, 可定义点态相对效率

$$\text{RE}_\theta(\delta_1, \delta_2) = \frac{\text{Var}_\theta(\delta_2)}{\text{Var}_\theta(\delta_1)}. \quad (23.42)$$

若该值大于 1, 则在参数值 θ 处, δ_1 方差更小。

若 Cramér–Rao 下界适用, 可定义无偏估计量的 CR 效率

$$e_\theta(\delta) = \frac{\text{Cramér–Rao 下界}}{\text{Var}_\theta(\delta)} \leq 1. \quad (23.43)$$

注 23.22. 有限样本效率、渐近效率、可容许性和 minimax 性是不同概念。不能把“达到 Cramér–Rao 下界”、“UMVUE”与“可容许”视为同义词。

23.14 历年真题完整解法：分段 Uniform 模型

往年真题

[24F-Q11, 15 分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}[\theta, \theta + |\theta|], \theta \neq 0$ 。

- (1) 求矩估计量;
- (2) 求 MLE;
- (3) 判断 MLE 是否相合。

解：模型必须按 θ 的符号分段：

若 $\theta > 0$, $X_i \sim \text{Unif}(\theta, 2\theta)$ 。若 $\theta < 0$, $X_i \sim \text{Unif}(\theta, 0)$ 。

第一问：矩估计量

总体均值为 $\mathbb{E}_\theta X = \frac{\theta + \theta + |\theta|}{2} = \theta + \frac{|\theta|}{2}$ 。所以 $\mathbb{E}_\theta X = \begin{cases} \frac{3}{2}\theta, & \theta > 0, \\ \frac{1}{2}\theta, & \theta < 0. \end{cases}$ 将其与 $\bar{X}$ 相等, 得到

$$\tilde{\theta} = \begin{cases} \frac{2}{3}\bar{X}, & \bar{X} > 0, \\ 2\bar{X}, & \bar{X} < 0. \end{cases} \quad (23.44)$$

在事件 $\{\bar{X} = 0\}$ 上可任意定义；该事件在任意 $\theta \neq 0$ 下概率为零。

第二问：MLE

先考虑 $\theta > 0$ 。联合似然为 $L_+(\theta) = \theta^{-n} \mathbf{1}_{\{\theta \leq X_{(1)}, X_{(n)} \leq 2\theta\}}$ 。可行参数区间为 $\frac{X_{(n)}}{2} \leq \theta \leq X_{(1)}$ 。在该区间上 θ^{-n} 严格递减, 故

$$\hat{\theta} = \frac{X_{(n)}}{2} \text{ 当样本全为正时。} \quad (23.45)$$

再考虑 $\theta < 0$ 。此时区间为 $[\theta, 0]$, 密度为 $\frac{1}{-\theta}$ 。联合似然为 $L_-(\theta) = (-\theta)^{-n} \mathbf{1}_{\{\theta \leq X_{(1)}, X_{(n)} \leq 0\}}$ 。可行参数满

足 $\theta \leq X_{(1)} < 0$ 。函数 $(-\theta)^{-n}$ 随 θ 增加而增加，故最大值在最大可行点 $\theta = X_{(1)}$ 达到。

因此

$$\hat{\theta}_{\text{MLE}} = \begin{cases} \frac{1}{2}X_{(n)}, & X_{(1)} > 0, \\ X_{(1)}, & X_{(n)} < 0. \end{cases} \quad (23.46)$$

在模型下，样本跨越零点的概率为零。

第三问：相合性

若 $\theta > 0$ ，则总体上端点为 2θ 。对任意 $0 < \varepsilon < \frac{\theta}{2}$ ，

$$P_{\theta}(|\hat{\theta} - \theta| > \varepsilon) = P_{\theta}\left(\frac{X_{(n)}}{2} < \theta - \varepsilon\right) = P_{\theta}(X_{(n)} < 2\theta - 2\varepsilon) = \left(\frac{(2\theta - 2\varepsilon) - \theta}{\theta}\right)^n = \left(1 - \frac{2\varepsilon}{\theta}\right)^n \rightarrow 0.$$

若 $\theta < 0$ ，总体下端点为 θ 。对任意 $0 < \varepsilon < |\theta|$ ，

$$\begin{aligned} P_{\theta}(|\hat{\theta} - \theta| > \varepsilon) &= P_{\theta}(X_{(1)} > \theta + \varepsilon) \\ &= \left(\frac{0 - (\theta + \varepsilon)}{-\theta}\right)^n \\ &= \left(1 - \frac{\varepsilon}{|\theta|}\right)^n \rightarrow 0. \end{aligned}$$

因此

$$\hat{\theta}_{\text{MLE}} \xrightarrow{\mathbb{P}} \theta. \quad (23.47)$$

事实上由极端次序统计量的强相合性，还有 $\hat{\theta}_{\text{MLE}} \xrightarrow{\text{a.s.}} \theta$ 。

矩估计量也相合： $\bar{X} \xrightarrow{\text{a.s.}} \mathbb{E}_{\theta} X$ ，且真值处相应分段逆映射连续。□

考试时需要注意的地方

本题 15 分的关键是：

- (1) 必须按 $\theta > 0$ 与 $\theta < 0$ 分段；
- (2) MLE 必须保留支持集指示函数；
- (3) 正参数分支使用极大值，负参数分支使用极小值；
- (4) 相合性应给出概率计算或端点次序统计量定理；
- (5) 不能只写“由大数定律显然相合”，因为 MLE 不是样本均值。

23.15 历年真题完整解法： $\log X_i \sim N(\theta, \theta)$

往年真题

[24S-Q9, 10 分]

令 $Y_i = \log X_i \stackrel{\text{i.i.d.}}{\sim} N(\theta, \theta)$, $\theta > 0$ 。

- (1) 求 θ 的 MLE；
- (2) 求其渐近分布。

解: 单个 Y_i 的密度为 $f(y | \theta) = \frac{1}{\sqrt{2\pi\theta}} \exp\left\{-\frac{(y-\theta)^2}{2\theta}\right\}$. 对数似然为 $\ell_n(\theta) = -\frac{n}{2} \log(2\pi\theta) - \frac{1}{2\theta} \sum_{i=1}^n (Y_i - \theta)^2$. 展开平方: $\ell_n(\theta) = C(\mathbf{y}) - \frac{n}{2} \log \theta - \frac{1}{2\theta} \sum_i Y_i^2 + \sum_i Y_i - \frac{n}{2} \theta$. 故 $\ell'_n(\theta) = -\frac{n}{2\theta} + \frac{\sum_i Y_i^2}{2\theta^2} - \frac{n}{2}$. 令 $Q_n = \frac{1}{n} \sum_{i=1}^n Y_i^2$. 似然方程为 $-\theta + Q_n - \theta^2 = 0$, 即 $\theta^2 + \theta - Q_n = 0$. 唯一正根为

$$\hat{\theta} = \frac{\sqrt{1+4Q_n} - 1}{2}. \quad (23.48)$$

在驻点处, $Q_n = \hat{\theta}^2 + \hat{\theta}$, 并且 $\ell''_n(\hat{\theta}) = -\frac{n(2\hat{\theta}+1)}{2\hat{\theta}^2} < 0$. 又在一般样本下, $\ell_n(\theta) \rightarrow -\infty$ 当 $\theta \downarrow 0$ 或 $\theta \rightarrow \infty$, 所以该驻点为唯一全局最大点。

下面求渐近分布. 对 $Y \sim N(\theta, \theta)$, 有 $\mathbb{E}Y^2 = \theta^2 + \theta$. 四阶矩为 $\mathbb{E}Y^4 = \theta^4 + 6\theta^3 + 3\theta^2$. 因此

$$\begin{aligned} \text{Var}(Y^2) &= \mathbb{E}Y^4 - (\mathbb{E}Y^2)^2 \\ &= \theta^4 + 6\theta^3 + 3\theta^2 - (\theta^2 + \theta)^2 \\ &= 4\theta^3 + 2\theta^2 \\ &= 2\theta^2(2\theta + 1). \end{aligned}$$

由中心极限定理, $\sqrt{n}[Q_n - (\theta^2 + \theta)] \xrightarrow{d} N(0, 2\theta^2(2\theta + 1))$.

令 $g(q) = \frac{\sqrt{1+4q}-1}{2}$. 则 $g(\theta^2 + \theta) = \theta$, 且 $g'(q) = \frac{1}{\sqrt{1+4q}}$, 所以 $g'(\theta^2 + \theta) = \frac{1}{2\theta+1}$. 由 Delta 方法,

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N\left(0, \frac{2\theta^2}{2\theta+1}\right). \quad (23.49)$$

□

注 23.23. 单个观测的 Fisher 信息为 $I_1(\theta) = \frac{2\theta+1}{2\theta^2}$. 所以渐近方差恰为 $I_1(\theta)^{-1}$.

23.16 历年真题完整解法: Gamma 尺度参数的倒数

往年真题

[25S-Q8(b), 10 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \Gamma(\alpha_0, \theta)$, $\alpha_0 = 2025$, 其中使用形状-尺度参数化: $f(x | \theta) = \frac{x^{\alpha_0-1} e^{-x/\theta}}{\Gamma(\alpha_0)\theta^{\alpha_0}}$, $x > 0$. 求 $1/\theta$ 的 MLE 及其渐近分布。

解: 忽略不含 θ 的项, $\ell(\theta) = -n\alpha_0 \log \theta - \frac{1}{\theta} \sum_i X_i$. 求导: $\ell'(\theta) = -\frac{n\alpha_0}{\theta} + \frac{\sum_i X_i}{\theta^2}$. 所以 $\hat{\theta} = \frac{\bar{X}}{\alpha_0}$. 由 MLE 不变性,

$$\widehat{\theta^{-1}} = \frac{\alpha_0}{\bar{X}} = \frac{2025}{\bar{X}}. \quad (23.50)$$

又因为 $\mathbb{E}X_i = \alpha_0\theta$, $\text{Var}(X_i) = \alpha_0\theta^2$, 中心极限定理给出 $\sqrt{n}(\bar{X} - \alpha_0\theta) \xrightarrow{d} N(0, \alpha_0\theta^2)$. 令 $g(x) = \frac{\alpha_0}{x}$. 则 $g'(\alpha_0\theta) = -\frac{1}{\alpha_0\theta^2}$. 由 Delta 方法,

$$\sqrt{n}\left(\frac{\alpha_0}{\bar{X}} - \frac{1}{\theta}\right) \xrightarrow{d} N\left(0, \frac{1}{\alpha_0\theta^2}\right). \quad (23.51)$$

代入 $\alpha_0 = 2025$:
$$\sqrt{n} \left(\frac{2025}{\bar{X}} - \frac{1}{\theta} \right) \xrightarrow{d} N \left(0, \frac{1}{2025 \theta^2} \right).$$

□

23.17 历年真题完整解法：平移指数模型的非正则 MLE

历年真题

[25S-Q11, 15 分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x; \lambda, \alpha)$, 其中

$$f(x; \lambda, \alpha) = \lambda e^{-\lambda(x-\alpha)} \mathbf{1}_{\{x \geq \alpha\}}, \quad \lambda > 0, \quad \alpha \in \mathbb{R}. \quad (23.52)$$

求 (λ, α) 的 MLE, 并求 $\begin{pmatrix} \sqrt{n}(\hat{\lambda} - \lambda) \\ n(\hat{\alpha} - \alpha) \end{pmatrix}$ 的极限分布。

解：似然为 $L(\lambda, \alpha) = \lambda^n \exp \{-\lambda \sum_{i=1}^n (X_i - \alpha)\} \mathbf{1}_{\{\alpha \leq X_{(1)}\}}$ 。

对固定 λ , 在可行区域 $\alpha \leq X_{(1)}$ 上, 似然含有因子 $e^{n\lambda\alpha}$, 故随 α 严格增加。因此

$$\hat{\alpha} = X_{(1)}. \quad (23.53)$$

代入后, $L(\lambda, \hat{\alpha}) = \lambda^n \exp \{-\lambda [\sum_i X_i - nX_{(1)}]\}$ 。若 $n \geq 2$ 且样本不全相等, 则 $W_n = \sum_i X_i - nX_{(1)} > 0$ 。对 λ 求导: $\frac{\partial}{\partial \lambda} \log L = \frac{n}{\lambda} - W_n$ 。所以

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n (X_i - X_{(1)})} = \frac{1}{\bar{X} - X_{(1)}}. \quad (23.54)$$

若 $n = 1$, 则令 $\alpha = X_1$ 后似然为 λ , 随 $\lambda \rightarrow \infty$ 无界, MLE 不存在。以下假设 $n \geq 2$ 。

令 $Z_i = X_i - \alpha$ 。则 $Z_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ 。记 $M_n = Z_{(1)} = X_{(1)} - \alpha$ 。由于独立指数变量的最小值服从 $M_n \sim \text{Exp}(n\lambda)$, 所以

$$n(\hat{\alpha} - \alpha) = nM_n \sim \text{Exp}(\lambda) \quad (23.55)$$

对每个 n 都精确成立。

下面研究 $\hat{\lambda}$ 。给定最小值及达到最小值的指标后, 其余 $n-1$ 个超额 $Z_i - M_n$ 由无记忆性相当于独立的 $\text{Exp}(\lambda)$ 变量, 并且与 M_n 独立。因此

$$W_n = \sum_{i=1}^n (Z_i - M_n) \sim \Gamma(n-1, \lambda) \quad (23.56)$$

使用形状-率参数化, 并且 $W_n \perp\!\!\!\perp M_n$ 。

可得 $W_n \stackrel{d}{=} E_1 + \dots + E_{n-1}$, $E_j \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ 。于是 $\frac{W_n}{n-1} \xrightarrow{\mathbb{P}} \frac{1}{\lambda}$, 并且 $\sqrt{n-1} \left(\frac{W_n}{n-1} - \frac{1}{\lambda} \right) \xrightarrow{d} N \left(0, \frac{1}{\lambda^2} \right)$ 。对函数 $g(x) = 1/x$ 使用 Delta 方法, $\sqrt{n-1} \left(\frac{n-1}{W_n} - \lambda \right) \xrightarrow{d} N(0, \lambda^2)$ 。由于 $\hat{\lambda} = \frac{n}{W_n} = \frac{n}{n-1} \frac{n-1}{W_n}$, 且 $\frac{n}{n-1} = 1 + O(n^{-1})$, 故

$$\sqrt{n}(\hat{\lambda} - \lambda) \xrightarrow{d} N(0, \lambda^2). \quad (23.57)$$

又因 W_n 与 M_n 独立, 两个分量对每个 n 都独立。所以联合极限为

$$\begin{pmatrix} \sqrt{n}(\hat{\lambda} - \lambda) \\ n(\hat{\alpha} - \alpha) \end{pmatrix} \xrightarrow{d} \begin{pmatrix} Z \\ E \end{pmatrix}, \quad (23.58)$$

其中 $Z \sim N(0, \lambda^2)$, $E \sim \text{Exp}(\lambda)$, $Z \perp\!\!\!\perp E$. □

考试时需要注意的地方

该题是典型非正则 15 分题:

- (1) $\hat{\alpha}$ 位于支持边界;
- (2) $\hat{\alpha}$ 的收敛速度是 n , 不是 $\sqrt{n}$;
- (3) 极限是指数分布, 不是正态分布;
- (4) $\hat{\lambda}$ 仍有通常的 $\sqrt{n}$ 正态极限;
- (5) 必须说明两个极限分量独立。

23.18 历年真题型: MLE 未必存在

往年真题

[26S-Q11(b), 15 分题的一部分]

设 $Y = \sigma(\rho|U| + \sqrt{1-\rho^2}V)$, 其中 $U, V \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $-1 < \rho < 1$, $\sigma > 0$ 。判断基于 $Y_1, \dots, Y_n$ 的 (ρ, σ) 的 MLE 是否总存在。

解: 先推导密度。令 $W = \frac{Y}{\sigma}$ 。给定 $|U| = u$, $W \mid |U| = u \sim N(\rho u, 1 - \rho^2)$ 。而 $|U|$ 的密度为 $2\phi(u)\mathbf{1}_{\{u>0\}}$ 。故

$$f_W(w) = 2 \int_0^\infty \phi(u) \frac{1}{\sqrt{1-\rho^2}} \phi\left(\frac{w-\rho u}{\sqrt{1-\rho^2}}\right) du.$$

注意恒等式 $u^2 + \frac{(w-\rho u)^2}{1-\rho^2} = w^2 + \frac{(u-\rho w)^2}{1-\rho^2}$ 。因此

$$\begin{aligned} f_W(w) &= 2\phi(w) \int_0^\infty \frac{1}{\sqrt{1-\rho^2}} \phi\left(\frac{u-\rho w}{\sqrt{1-\rho^2}}\right) du \\ &= 2\phi(w) \Phi\left(\frac{\rho w}{\sqrt{1-\rho^2}}\right). \end{aligned}$$


缩放后,

$$f_Y(y \mid \rho, \sigma) = \frac{2}{\sigma} \phi\left(\frac{y}{\sigma}\right) \Phi\left(\frac{\rho y}{\sigma \sqrt{1-\rho^2}}\right). \quad (23.59)$$

所以试卷所给形式中的常数为 $a = 2$, $b = 1$ 。

现今

$$\kappa = \frac{\rho}{\sqrt{1-\rho^2}}. \quad (23.60)$$



映射 $\rho \in (-1, 1) \longleftrightarrow \kappa \in \mathbb{R}$ 是一一对应。

假设观测满足 $y_1, \dots, y_n > 0$ 。对数似然中与 κ 有关的部分为 $\sum_{i=1}^n \log \Phi\left(\frac{\kappa y_i}{\sigma}\right)$ 。对任意有限 κ , $\frac{\partial}{\partial \kappa} \log \Phi\left(\frac{\kappa y_i}{\sigma}\right) = \frac{y_i}{\sigma} \frac{\phi(\kappa y_i / \sigma)}{\Phi(\kappa y_i / \sigma)} > 0$ 。因此在固定 σ 下, 似然关于 κ 严格增加。对任何有限 (κ, σ) , 选择更大的 κ' 即可得到更大的似然。

似然的上确界只在 $\kappa \rightarrow +\infty, \rho \rightarrow 1$ 时逼近, 而 $\rho = 1$ 不属于参数空间。所以此时 MLE 不存在。

同理, 若所有 $y_i < 0$, 似然在 $\kappa \rightarrow -\infty, \rho \rightarrow -1$ 时逼近上确界, 也不存在有限 MLE。

因此


(ρ, σ) 的 MLE 不总是存在。

(23.61)

而“所有观测同号”的事件具有正概率, 所以该问题不是零概率的纯技术例外。 □

23.19 点估计易错点

陈述	判断	正确说明
矩估计量一定属于参数空间	错	矩方程的形式解可能为负数、非整数或违反支持约束。
矩估计量一定无偏	错	矩匹配不等于期望无偏。
矩估计量一定相合	错	需要矩存在、可识别性和逆映射连续性等条件。
解 score 方程即可得到 MLE	错	还需检查全局最大性、边界、支持和存在性。
MLE 一定存在	错	参数空间开、非紧或似然上确界在边界时可能不存在。
MLE 一定唯一	错	固定长度 Uniform 位置族可有整段最大点。
MLE 一定无偏	错	正态方差的 MLE 即有偏。
MLE 不变性意味着无偏性在变换下保持	错	不变性只是最大化性质。
MLE 一定是充分统计量的函数	基本正确 但需说明	唯一 MLE 必为充分统计量的函数; 非唯一时最大点集合依赖充分统计量, 但选择规则需固定。
相合估计量一定渐近无偏	错	还需一致可积性或矩控制。
无偏估计量一定比有偏估计量 MSE 小	错	小偏差可能换来更大的方差下降。
正则模型中的 $\sqrt{n}$ 正态结论适用于所有 MLE	错	边界参数、支持依赖参数、不可识别和非光滑模型可能具有不同速率与非正态极限。



第二十四章 Fisher 信息与 Cramér–Rao 下界

24.1 考纲定位

重点

重要性等级：S 级。

本章最容易因“公式记住但条件漏写”而失分。

必须区分：

$$\begin{aligned}\mathbb{E}_\theta U_\theta &= 0, \\ I(\theta) &= \mathbb{E}_\theta U_\theta^2, \\ I(\theta) &= -\mathbb{E}_\theta \ell''_\theta, \\ \text{Var}_\theta(W) &\geq \frac{[\partial_\theta \mathbb{E}_\theta W]^2}{I(\theta)}\end{aligned}$$

分别需要什么条件。

必须会完整证明：

- score 均值为零；
- Fisher 信息两种公式等价；
- i.i.d. 信息可加性；
- 标量 Cramér–Rao 不等式；
- 等号达到条件；
- 多参数矩阵形式的证明框架；
- 参数依赖支持集反例。

真题对应：[24F-Q8(b)], [24S-Q9], [25S-Q8(b)], [25S-Q11]。

24.2 正则条件

以下是一组常用的**充分正则条件**，并非唯一可能的最弱条件。

设单个观测的密度为 $f(x | \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$ 。

前提条件检查

常用正则条件包括：

- (1) Θ 为开区间，真值位于内部；
- (2) 支持集 $\mathcal{X}_0 = \{x : f(x | \theta) > 0\}$ 不依赖 θ ；
- (3) 对几乎所有 x , $\theta \mapsto f(x | \theta)$ 一次或二次可微；

- (4) 可以交换微分与积分: $\frac{d}{d\theta} \int f(x | \theta) \nu(dx) = \int \frac{\partial}{\partial \theta} f(x | \theta) \nu(dx)$;
 (5) 相应 score 的二阶矩有限且正: $0 < I(\theta) < \infty$;
 (6) 对待估统计量 W , $\frac{d}{d\theta} \mathbb{E}_\theta W = \int W(x) \frac{\partial}{\partial \theta} f(x | \theta) \nu(dx)$.

交换微分与积分可由局部支配条件保证: 存在可积函数 $M(x)$, 使在 θ 的某个邻域内 $|\frac{\partial}{\partial \theta} f(x | \theta)| \leq M(x)$ 。

注 24.1. 支持集不依赖参数是一条方便而强的充分条件, 并非逻辑上绝对必要。

某些支持集变化模型仍可满足特定微分恒等式; 但不能在未检查边界项时直接使用标准公式。

24.3 Score 与 Fisher 信息

定义 24.2 (score). 单个观测的 score 定义为

$$U_\theta(X) = \frac{\partial}{\partial \theta} \log f(X | \theta). \quad (24.1)$$

若 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(\cdot | \theta)$, 样本对数似然为 $\ell_n(\theta) = \sum_{i=1}^n \log f(X_i | \theta)$, 样本 score 为

$$U_n(\theta) = \ell'_n(\theta) = \sum_{i=1}^n U_\theta(X_i). \quad (24.2)$$

定义 24.3 (Fisher 信息). 单个观测的 Fisher 信息定义为

$$I_1(\theta) = \mathbb{E}_\theta [U_\theta(X)^2], \quad (24.3)$$

只要右侧有限。

样本 Fisher 信息定义为

$$I_n(\theta) = \mathbb{E}_\theta [U_n(\theta)^2]. \quad (24.4)$$

定义 24.4 (观测信息). 观测信息定义为

$$J_n(\theta) = -\ell''_n(\theta). \quad (24.5)$$

考试时需要注意的地方

观测信息 $J_n(\theta)$ 是样本的随机函数, 不一定对每个样本和每个参数都为正。

Fisher 信息是其期望或 score 平方期望, 在正则条件下为非负确定量。

24.4 Score 均值为零

定理 24.5 (score 均值为零). 若可以交换微分与积分, 则

$$\mathbb{E}_\theta U_\theta(X) = 0. \quad (24.6)$$

证明.

$$\begin{aligned}\mathbb{E}_\theta U_\theta(X) &= \int \frac{\partial}{\partial \theta} \log f(x | \theta) f(x | \theta) \nu(\mathrm{d}x) = \int \frac{\partial_\theta f(x | \theta)}{f(x | \theta)} f(x | \theta) \nu(\mathrm{d}x) \\ &= \int \partial_\theta f(x | \theta) \nu(\mathrm{d}x) = \frac{\mathrm{d}}{\mathrm{d}\theta} \int f(x | \theta) \nu(\mathrm{d}x) = \frac{\mathrm{d}}{\mathrm{d}\theta} 1 = 0.\end{aligned}$$

□

前提条件检查

若支持集随参数变化, $\frac{\mathrm{d}}{\mathrm{d}\theta} \int_{\mathcal{X}_\theta} f(x | \theta) \mathrm{d}x$ 通常包含边界项。
忽略边界项会错误地得到 $\mathbb{E}_\theta U_\theta = 0$ 。

24.5 Fisher 信息的第二种公式

定理 24.6 (Fisher 恒等式). 若可对 *score* 的期望再次交换微分与积分, 则

$$I_1(\theta) = -\mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right]. \quad (24.7)$$

证明. 由 $\mathbb{E}_\theta U_\theta(X) = 0$ 对 θ 求导: $0 = \frac{\mathrm{d}}{\mathrm{d}\theta} \int U_\theta(x) f(x | \theta) \nu(\mathrm{d}x)$. 交换微分与积分:

$$\begin{aligned}0 &= \int \left[\frac{\partial U_\theta(x)}{\partial \theta} f(x | \theta) + U_\theta(x) \frac{\partial f(x | \theta)}{\partial \theta} \right] \nu(\mathrm{d}x) \\ &= \mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right] + \mathbb{E}_\theta [U_\theta(X)^2].\end{aligned}$$

移项即得。

□

考试时需要注意的地方

下式不是无条件恒等式: $\mathbb{E}_\theta \left[(\partial_\theta \log f)^2 \right] = -\mathbb{E}_\theta \left[\partial_\theta^2 \log f \right]$ 。


在以下模型中应格外警惕:

- Uniform(0, θ);
- shifted exponential;
- 边界参数;
- 密度不可微;
- Fisher 信息无穷;
- 参数依赖支持集。

24.6 i.i.d. 样本的信息可加性

定理 24.7 (Fisher 信息可加性). 若 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(\cdot | \theta)$ 且正则条件成立, 则

$$I_n(\theta) = nI_1(\theta). \quad (24.8)$$



证明. 样本 score 为 $U_n = \sum_{i=1}^n U_i$, 其中 $\mathbb{E}U_i = 0$. 由独立性,

$$\begin{aligned} I_n(\theta) &= \mathbb{E} \left(\sum_{i=1}^n U_i \right)^2 \\ &= \sum_{i=1}^n \mathbb{E}U_i^2 + \sum_{i \neq j} \mathbb{E}(U_i U_j) \\ &= nI_1(\theta) + \sum_{i \neq j} (\mathbb{E}U_i)(\mathbb{E}U_j) \\ &= nI_1(\theta). \end{aligned}$$

□

24.7 重参数化下的 Fisher 信息

设 $\eta = g(\theta)$ 是一一可微重参数化, 逆函数为 $\theta = q(\eta)$. 则 $\frac{\partial}{\partial \eta} \log f(X | q(\eta)) = \frac{d\theta}{d\eta} U_\theta(X)$. 因此

$$I_\eta(\eta) = I_\theta(\theta) \left(\frac{d\theta}{d\eta} \right)^2. \quad (24.9)$$

考试时需要注意的地方

不能把同一模型在不同参数化下的 Fisher 信息数值直接比较。

信息的数值会随参数尺度改变, 但 Cramér-Rao 下界与参数导数共同变换, 最终推断结论保持一致。

24.8 指数族中的 Fisher 信息

对自然指数族 $f_\eta(x) = h(x)e^{\eta^\top T(x) - A(\eta)}$, score 为 $U_\eta(X) = T(X) - \nabla A(\eta)$. 故 Fisher 信息矩阵为

$$I_1(\eta) = \text{Cov}_\eta(T(X)) = \nabla^2 A(\eta). \quad (24.10)$$

样本量为 n 时,

$$I_n(\eta) = n\nabla^2 A(\eta). \quad (24.11)$$


24.9 标量 Cramér-Rao 信息不等式

定理 24.8 (Cramér-Rao 信息不等式). 设统计量 $W = W(X)$ 满足 $\mathbb{E}_\theta W = \psi(\theta)$, $\text{Var}_\theta(W) < \infty$, 并且:

$$\psi'(\theta) = \int W(x) \frac{\partial}{\partial \theta} f_\theta(x) \nu(dx). \quad (24.12)$$

若 $0 < I(\theta) < \infty$, 则

$$\boxed{\text{Var}_\theta(W) \geq \frac{[\psi'(\theta)]^2}{I(\theta)}}. \quad (24.13)$$



证明. 记 $U_\theta = \partial_\theta \log f_\theta(X)$ 。由 score 均值为零, $\text{Cov}_\theta(W, U_\theta) = \mathbb{E}_\theta[WU_\theta]$ 。又

$$\begin{aligned}\mathbb{E}_\theta[WU_\theta] &= \int W(x) \frac{\partial_\theta f_\theta(x)}{f_\theta(x)} f_\theta(x) \nu(\mathrm{d}x) \\ &= \int W(x) \partial_\theta f_\theta(x) \nu(\mathrm{d}x) \\ &= \psi'(\theta).\end{aligned}$$

由 Cauchy-Schwarz 不等式, $\text{Cov}(W, U_\theta)^2 \leq \text{Var}(W) \text{Var}(U_\theta)$ 。而 $\text{Var}(U_\theta) = I(\theta)$ 。故 $[\psi'(\theta)]^2 \leq \text{Var}(W)I(\theta)$ 。□

推论 24.9 (无偏估计量的 CR 下界). 若 $\mathbb{E}_\theta W = \tau(\theta)$, 则

$$\boxed{\text{Var}_\theta(W) \geq \frac{[\tau'(\theta)]^2}{I(\theta)}}. \quad (24.14)$$

特别地, 若 W 无偏估计 θ ,

$$\text{Var}_\theta(W) \geq \frac{1}{I(\theta)}. \quad (24.15)$$

24.10 有偏估计量的广义下界

若 δ 估计 $\tau(\theta)$, 偏差为 $b(\theta) = \mathbb{E}_\theta \delta - \tau(\theta)$, 则 $\psi(\theta) = \tau(\theta) + b(\theta)$ 。若相同正则条件成立,

$$\text{Var}_\theta(\delta) \geq \frac{[\tau'(\theta) + b'(\theta)]^2}{I(\theta)}. \quad (24.16)$$

因此

$$\boxed{\text{MSE}_\theta(\delta) \geq \frac{[\tau'(\theta) + b'(\theta)]^2}{I(\theta)} + b(\theta)^2}. \quad (24.17)$$

前提条件检查

该式仍要求: $\frac{\mathrm{d}}{\mathrm{d}\theta} \mathbb{E}_\theta \delta = \int \delta(x) \partial_\theta f_\theta(x) \nu(\mathrm{d}x)$ 。它不是对任意有偏估计量都无条件成立。

24.11 Cramér-Rao 下界的达到条件

定理 24.10 (达到下界的充要条件). 在 [定理 24.8](#) 条件下, 等号成立当且仅当

$$W - \psi(\theta) = \frac{\psi'(\theta)}{I(\theta)} U_\theta(X) \quad P_\theta\text{-a.s.} \quad (24.18)$$

证明. Cramér-Rao 不等式唯一使用的非等式步骤是 Cauchy-Schwarz。其等号成立当且仅当中心化随机变量线性相关: $W - \mathbb{E}W = c(\theta)U_\theta$ 。两边与 U_θ 取协方差: $\psi'(\theta) = c(\theta)I(\theta)$, 所以 $c(\theta) = \frac{\psi'(\theta)}{I(\theta)}$ 。□

推论 24.11. 若 W 无偏估计 $\tau(\theta)$, 达到 CR 下界当且仅当

$$U_\theta(X) = a(\theta)[W - \tau(\theta)] \quad (24.19)$$

对某个仅依赖 θ 的函数 a 成立。

考试时需要注意的地方

Cramér-Rao 下界不保证可达到。

可能出现: $\inf_{\text{无偏} W} \text{Var}_{\theta}(W) > \frac{[\tau'(\theta)]^2}{I(\theta)}$ 。

即使某个估计量没有达到 CR 下界, 它仍可能是 UMVUE; 上一章中的正态未知均值下 S^2 即为典型例子。

24.12 多参数 Fisher 信息矩阵

设 $\theta = (\theta_1, \dots, \theta_p)^\top$ 。score 向量定义为

$$U_{\theta}(X) = \nabla_{\theta} \log f(X | \theta). \quad (24.20)$$

Fisher 信息矩阵为

$$I(\theta) = \mathbb{E}_{\theta} [U_{\theta}(X) U_{\theta}(X)^\top]. \quad (24.21)$$

在二阶正则条件下,

$$I(\theta) = -\mathbb{E}_{\theta} [\nabla_{\theta}^2 \log f(X | \theta)]. \quad (24.22)$$

矩阵序 $A \succeq B$ 表示 $a^\top (A - B) a \geq 0$ 对所有 a 。

定理 24.12 (多参数 Cramér-Rao). 设 $W \in \mathbb{R}^q$ 无偏估计 $\tau(\theta) \in \mathbb{R}^q$ 。令 *Jacobian* $G(\theta) = D_{\theta} \tau(\theta)$ 为 $q \times p$ 矩阵。若 $I(\theta)$ 正定且正则条件成立, 则

$$\text{Cov}_{\theta}(W) \succeq G(\theta) I(\theta)^{-1} G(\theta)^\top. \quad (24.23)$$

证明思路

由正则条件, $\text{Cov}(W, U_{\theta}) = G(\theta)$ 。考虑随机向量 $W - \tau(\theta) - G(\theta) I(\theta)^{-1} U_{\theta}$ 。其协方差矩阵半正定。展开该协方差矩阵即得到 $\text{Cov}(W) - G I^{-1} G^\top \succeq 0$ 。

若 W 无偏估计参数向量 θ 本身, 则 $G(\theta) = I_p$, 从而


$$\text{Cov}_{\theta}(W) \succeq I(\theta)^{-1}. \quad (24.24)$$

24.13 存在 nuisance 参数时的有效信息

设 $\theta = \begin{pmatrix} \psi \\ \lambda \end{pmatrix}$, 其中 ψ 为标量目标参数, λ 为 nuisance 参数。将信息矩阵分块: $I(\theta) = \begin{pmatrix} I_{\psi\psi} & I_{\psi\lambda} \\ I_{\lambda\psi} & I_{\lambda\lambda} \end{pmatrix}$ 。则

任意无偏估计 ψ 的方差满足

$$\text{Var}(W) \geq [I(\theta)^{-1}]_{\psi\psi}. \quad (24.25)$$



若 $I_{\lambda\lambda}$ 可逆,

$$[I^{-1}]_{\psi\psi} = \frac{1}{I_{\psi\psi} - I_{\psi\lambda}I_{\lambda\lambda}^{-1}I_{\lambda\psi}}. \quad (24.26)$$

分母

$$I_{\psi\cdot\lambda} = I_{\psi\psi} - I_{\psi\lambda}I_{\lambda\lambda}^{-1}I_{\lambda\psi} \quad (24.27)$$

称为消除 nuisance 参数后的有效信息。

考试时需要注意的地方

存在 nuisance 参数时, 一般不能只使用 $1/I_{\psi\psi}$ 。正确下界是 $[I^{-1}]_{\psi\psi}$ 。只有在信息正交 $I_{\psi\lambda} = 0$ 时二者相同。

24.14 常见模型的 Fisher 信息速查

24.14.1 Bernoulli(p)

$\ell(p) = X \log p + (1 - X) \log(1 - p)$ 。score 为 $U_p(X) = \frac{X}{p} - \frac{1-X}{1-p} = \frac{X-p}{p(1-p)}$ 。故

$$I_1(p) = \frac{1}{p(1-p)}. \quad (24.28)$$

样本信息为 $I_n(p) = \frac{n}{p(1-p)}$ 。于是无偏估计 p 的方差下界为 $\frac{p(1-p)}{n}$ 。而 $\text{Var}(\bar{X}) = \frac{p(1-p)}{n}$, 故 $\bar{X}$ 达到下界。

24.14.2 Poisson(λ)

$U_\lambda(X) = -1 + \frac{X}{\lambda} = \frac{X-\lambda}{\lambda}$ 。因此

$$I_1(\lambda) = \frac{1}{\lambda}, \quad I_n(\lambda) = \frac{n}{\lambda}. \quad (24.29)$$

$\bar{X}$ 无偏且 $\text{Var}(\bar{X}) = \frac{\lambda}{n}$, 达到 CR 下界。

24.14.3 指数率参数

若 $X \sim \text{Exp}(\lambda)$, 则 $U_\lambda(X) = \frac{1}{\lambda} - X$ 。所以


$$I_1(\lambda) = \frac{1}{\lambda^2}. \quad (24.30)$$

对参数函数 $\tau(\lambda) = \frac{1}{\lambda}$, 有 $\tau'(\lambda) = -\frac{1}{\lambda^2}$ 。CR 下界为 $\frac{1/\lambda^4}{n/\lambda^2} = \frac{1}{n\lambda^2}$ 。样本均值满足 $\mathbb{E}\bar{X} = \frac{1}{\lambda}$, $\text{Var}(\bar{X}) = \frac{1}{n\lambda^2}$, 故其达到下界。

24.14.4 正态均值, 方差已知

若 $X \sim N(\mu, \sigma^2)$, σ^2 已知, 则 $U_\mu(X) = \frac{X-\mu}{\sigma^2}$ 。因此

$$I_1(\mu) = \frac{1}{\sigma^2}, \quad I_n(\mu) = \frac{n}{\sigma^2}. \quad (24.31)$$



$\bar{X}$ 达到方差下界 σ^2/n 。

24.14.5 正态方差，均值已知

令 $v = \sigma^2$ 。若 μ 已知， $U_v(X) = -\frac{1}{2v} + \frac{(X-\mu)^2}{2v^2}$ 。所以

$$I_1(v) = \frac{1}{2v^2} = \frac{1}{2\sigma^4}. \quad (24.32)$$

估计量 $\frac{1}{n} \sum_i (X_i - \mu)^2$ 无偏，方差为 $\frac{2\sigma^4}{n}$ ，达到下界。

24.14.6 正态均值与方差均未知

参数为 $\theta = (\mu, v)$ 。单个观测的信息矩阵为

$$I_1(\mu, v) = \begin{pmatrix} 1/v & 0 \\ 0 & 1/(2v^2) \end{pmatrix}. \quad (24.33)$$

交叉项为零，因为正态分布第三中心矩为零。

样本信息矩阵为 $I_n(\mu, v) = nI_1(\mu, v)$ 。因此 $I_n(\mu, v)^{-1} = \begin{pmatrix} v/n & 0 \\ 0 & 2v^2/n \end{pmatrix}$ 。

$\bar{X}$ 达到 μ 的下界。但 S^2 的方差为 $\frac{2v^2}{n-1} > \frac{2v^2}{n}$ 。它没有达到 v 的 CR 下界。

若达到下界，矩阵等号条件要求 $W - v = \frac{2v^2}{n} U_{n,v}$ ，其中 $U_{n,v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_i (X_i - \mu)^2$ 。因此唯一可能形式为 $W = \frac{1}{n} \sum_i (X_i - \mu)^2$ 。但该表达式含未知 μ ，不是统计量。

所以在 μ 未知时，没有参数无关的无偏估计量达到 $2v^2/n$ 。尽管如此， S^2 仍由 Lehmann-Scheffé 定理成为 UMVUE。

24.14.7 Gamma 尺度参数

若 $X \sim \Gamma(\alpha, \theta)$ 采用形状-尺度参数化， α 已知，则 $U_\theta(X) = -\frac{\alpha}{\theta} + \frac{X}{\theta^2}$ 。故

$$I_1(\theta) = \frac{\alpha}{\theta^2}. \quad (24.34)$$

估计量 $\hat{\theta} = \frac{\bar{X}}{\alpha}$ 无偏，且 $\text{Var}(\hat{\theta}) = \frac{\theta^2}{n\alpha}$ ，正好达到 CR 下界。

24.15 历年真题：高斯线性模型的信息矩阵

往年真题

[24F-Q8(b), 10 分题的一部分]

设 $Y = Z\beta + \varepsilon$ ，其中 $\varepsilon \sim N_n(0, \sigma^2 I_n)$ ， σ^2 已知， Z 为固定 $n \times d$ 设计矩阵。求 β 的 Fisher 信息矩阵。

解: $Y \sim N_n(Z\beta, \sigma^2 I_n)$ 。对数似然为 $\ell(\beta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2}(Y - Z\beta)^\top(Y - Z\beta)$ 。score 向量为

$$U_\beta = \nabla_\beta \ell(\beta) = \frac{1}{\sigma^2} Z^\top (Y - Z\beta). \quad (24.35)$$

Hessian 为 $\nabla_\beta^2 \ell(\beta) = -\frac{1}{\sigma^2} Z^\top Z$ 。因此

$$I(\beta) = -\mathbb{E}_\beta \nabla_\beta^2 \ell(\beta) = \frac{1}{\sigma^2} Z^\top Z. \quad (24.36)$$

也可由 score 协方差计算:

$$\text{Cov}(U_\beta) = \frac{1}{\sigma^4} Z^\top \text{Cov}(Y) Z = \frac{1}{\sigma^4} Z^\top (\sigma^2 I_n) Z = \frac{1}{\sigma^2} Z^\top Z.$$

若 $\text{rank}(Z) = d$, 则信息矩阵正定。 □

24.16 参数依赖支持集: Uniform 反例

错误套用 Cramér-Rao 下界

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$ 。若只看支持内部的对数密度, $\log f(X | \theta) = -\log \theta$, 会错误地写出 $U_\theta(X) = -\frac{1}{\theta}$ 。于是 $\mathbb{E}_\theta U_\theta(X) = -\frac{1}{\theta} \neq 0$, 已经直接违反正则模型的 score 均值为零结论。

若仍机械计算 $I_1(\theta) = \frac{1}{\theta^2}$, 会得到错误下界 $\text{Var}(W) \geq \frac{\theta^2}{n}$ 用于无偏估计 θ 。

但令 $M = X_{(n)}$ 。有 $\mathbb{E}_\theta M = \frac{n}{n+1}\theta$ 。所以

$$W = \frac{n+1}{n} M \quad (24.37)$$

无偏估计 θ 。又 $\text{Var}(M) = \frac{n\theta^2}{(n+1)^2(n+2)}$, 故

$$\text{Var}(W) = \frac{\theta^2}{n(n+2)} < \frac{\theta^2}{n}. \quad (24.38)$$

这不是 Cramér-Rao 定理错误, 而是其正则条件不成立。

边界项可由 Leibniz 公式看出。对一个观测, $\mathbb{E}_\theta h(X) = \frac{1}{\theta} \int_0^\theta h(x) dx$ 。求导:

$$\frac{d}{d\theta} \mathbb{E}_\theta h(X) = -\frac{1}{\theta^2} \int_0^\theta h(x) dx + \frac{h(\theta)}{\theta}.$$

而只将微分移入密度会得到 $-\frac{1}{\theta^2} \int_0^\theta h(x) dx$, 缺少边界项 $\frac{h(\theta)}{\theta}$ 。

注 24.13 (非标准 MLE 极限). $\text{Uniform}(0, \theta)$ 的 MLE 为 $\hat{\theta} = X_{(n)}$ 。对 $t \geq 0$,

$$P_\theta \left(\frac{n(\theta - \hat{\theta})}{\theta} > t \right) = P_\theta \left(X_{(n)} < \theta \left(1 - \frac{t}{n} \right) \right) = \left(1 - \frac{t}{n} \right)^n \rightarrow e^{-t}.$$



因此

$$\frac{n(\theta - \hat{\theta})}{\theta} \xrightarrow{d} \text{Exp}(1).$$

(24.39)

其速度为 n ，极限不是正态。

24.17 正则与非正则模型对照

特征	正则模型典型结论	非正则模型可能现象
支持集	不依赖参数	依赖参数，产生边界项
score 均值	$\mathbb{E}U = 0$	可能不为零或普通 score 无定义
Fisher 公式	$\mathbb{E}U^2 = -\mathbb{E}\ell''$	两式可能不等价
MLE 位置	常为内部 score 方程根	常位于支持边界
收敛速度	通常为 $\sqrt{n}$	可能为 n 或其他速度
极限分布	通常正态	可能为指数、截断正态、混合分布
Cramér-Rao	在正则条件下适用	可能完全不适用
典型例子	Bernoulli 内部参数、Poisson、正态、固定支持 Gamma	Uniform(0, θ)、shifted exponential、边界参数

24.18 Fisher 信息与 Cramér-Rao 易错点

陈述	判断	正确说明
score 的期望总是零	错	需要微分与积分可交换，支持依赖参数时尤其要检查。
Fisher 信息总可写成负的期望二阶导数	错	该等价公式需要额外二阶正则条件。
观测信息总是正数	错	观测 Hessian 可随样本变化；期望信息才必为半正定。
i.i.d. 样本信息总是 n 倍	需条件	需要独立性及 score 均值为零等正则条件。
Fisher 信息越大，任何估计量方差都越小	不严谨	信息不等式控制满足条件的无偏或给定均值函数估计量。
CR 下界一定可达到	错	它可能严格小于所有无偏估计量的方差。
未达到 CR 下界就不是 UMVUE	错	CR 下界可能不可达到，UMVUE 可由完全充分性确定。
有 nuisance 参数时使用 $1/I_{\psi\psi}$	通常错	应使用 $[I^{-1}]_{\psi\psi}$ 或 Schur 补有效信息。

陈述	判断	正确说明
重参数化后 Fisher 信息不变	错	信息按 Jacobian 变换；不变的是相应统计推断内容。
Uniform($0, \theta$) 可直接使用普通 CRLB	错	支持依赖 θ ，边界项不可省。
MLE 渐近方差总是 Fisher 信息逆	错	只在正则、可识别、内部参数等条件下成立。

24.19 证明与计算套路

证明思路

Fisher 信息题的识别信号： score、信息矩阵、CRLB、MLE 渐近方差。

标准步骤：

- (1) 写单个观测对数密度；
- (2) 对参数求 score；
- (3) 先检查 $\mathbb{E}U = 0$ ；
- (4) 优先选择较容易的公式： $I = \mathbb{E}U^2$ 或 $I = -\mathbb{E}\ell''$ ；
- (5) i.i.d. 样本乘以 n ；
- (6) 多参数时写完整矩阵，包括交叉项；
- (7) 有 nuisance 参数时求逆矩阵或 Schur 补；
- (8) 使用 CRLB 前列出正则条件。

Cramér–Rao 证明题

- (1) 定义 $U = \partial_\theta \log f_\theta(X)$ ；
- (2) 证明 $\mathbb{E}U = 0$ ；
- (3) 证明 $\text{Cov}(W, U) = \frac{\text{d}}{\text{d}\theta} \mathbb{E}W$ ；
- (4) 使用 $\text{Cov}(W, U)^2 \leq \text{Var}(W) \text{Var}(U)$ ；
- (5) 识别 $\text{Var}(U) = I(\theta)$ ；
- (6) 若要求等号条件，写出中心化变量线性相关；
- (7) 若模型支持依赖参数，先停止并检查边界项。



非正则 MLE 题

- (1) 保留支持集指示函数；
- (2) 先对支持边界参数最大化；
- (3) 再代回求其他参数；
- (4) 求极值统计量的精确分布；
- (5) 识别正确速度： n , $\sqrt{n}$, 或其他；
- (6) 不预设极限为正态；
- (7) 检查不同分量是否独立；
- (8) 明确说明标准 Fisher 信息理论为什么失效。

一些需要记忆的内容

- (1) 矩估计量相合需要矩映射满足哪些条件？
- (2) 为什么矩估计量可能落在参数空间之外？
- (3) MLE 的严格定义为什么使用 $\arg \max$ 而不是只解 score 方程？
- (4) 严格凹性保证的是存在性还是唯一性？
- (5) MLE 不变性在参数函数非一时如何理解？
- (6) 正态方差 MLE 为什么有偏但 MSE 小于 S^2 ？
- (7) 什么条件保证 score 的期望为零？
- (8) Fisher 信息的两种公式为什么可能不等价？
- (9) i.i.d. 信息可加性的交叉项为什么为零？
- (10) 标量 CRLB 的证明中应对哪两个随机变量使用 Cauchy-Schwarz？
- (11) CRLB 的等号条件是什么？
- (12) 有 nuisance 参数时正确的标量下界是什么？
- (13) $\text{Uniform}(0, \theta)$ 的 CRLB 错误计算漏掉了什么？
- (14) 为什么 [26S-Q11(b)] 中所有观测为正时 MLE 不存在？
- (15) 正则模型和非正则模型的典型收敛速度分别是什么？



第二十五章 假设检验基础、误差概率与功效函数

25.1 考纲定位与重要性

重点

重要性等级：S 级。

资格考试中的检验题通常不是单纯要求“写出拒绝域”，而是要求完成如下逻辑链：

参数化与假设翻译

⇒ 选择检验统计量

⇒ 确定拒绝方向

⇒ 选临界值或随机化概率

⇒ 验证 size/level

⇒ 证明 MP 或 UMP.

必须会完整证明：

- 第一类错误、第二类错误和功效函数的关系；
- size 与 level 的严格区别；
- 随机化检验如何实现精确 size；
- Neyman–Pearson 引理的充分性与必要性；
- 单调似然比推出功效函数单调；
- Karlin–Rubin 定理；
- 双侧问题中 UMP 不存在的标准证明；
- 历年真题中的参数变换、最不利原假设边界和临界值计算。

直接真题对应：

[24F-Q7(b)], [24S-Q10],

[25S-Q8(a)], [25F-Q11],

[26S-Q7], [26S-Q11(c)].

25.2 本章分位数与尾概率约定

定义 25.1 (分位数约定). 对分布函数 F ，定义其左连续广义逆为

$$F^{-1}(q) = \inf\{x \in \mathbb{R} : F(x) \geq q\}, \quad 0 < q < 1. \quad (25.1)$$



全文在本章采用下尾分位数记号：

$$z_q = \Phi^{-1}(q), \quad (25.2)$$

$$t_{\nu,q} = F_{t_\nu}^{-1}(q), \quad (25.3)$$

$$\chi_{\nu,q}^2 = F_{\chi_\nu^2}^{-1}(q). \quad (25.4)$$

因此 $P(Z > z_{1-\alpha}) = \alpha$, $P(\chi_\nu^2 > \chi_{\nu,1-\alpha}^2) = \alpha$ 。

概念比较

部分课程讲义把 z_α 定义为**上尾** α 分位点，即 $P(Z > z_\alpha) = \alpha$ 。按照本章主约定，该数应写为 $z_{1-\alpha}$ 。考试中必须先声明分位数约定，否则 z_α , $z_{\alpha/2}$ 可能产生方向歧义。

25.3 统计假设、原假设与备择假设

设统计模型为 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ 。

定义 25.2 (统计假设). 统计假设是关于真实分布或参数所属集合的陈述。

通常写成

$$H_0 : \theta \in \Theta_0, H_1 : \theta \in \Theta_1, \quad (25.5)$$

其中 $\Theta_0, \Theta_1 \subseteq \Theta$, $\Theta_0 \cap \Theta_1 = \emptyset$ 。

通常取 $\Theta_1 = \Theta \setminus \Theta_0$ ，但这不是必要条件。

例如 $H_0 : \theta \geq 1$, $H_1 : \theta < \frac{1}{2}$ 在 $\frac{1}{2} \leq \theta < 1$ 之间留有不作决策要求的**无差异区间 (indifference region)**。

定义 25.3 (简单假设与复合假设). 若假设对应的参数集合只含一个点，则称为简单假设： $H_0 : \theta = \theta_0$ 。若其参数集合含有多个可能值，则称为复合假设。

考试时需要注意的地方

“目标参数被固定”不等于“假设简单”。

例如 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $H_0 : \mu = \mu_0$, 若 σ^2 未知，则原假设下仍有 $\{N(\mu_0, \sigma^2) : \sigma^2 > 0\}$ 一整族分布，因此 H_0 是复合假设。

只有当原假设下随机样本的分布被完全确定时，才是简单假设。


25.4 检验函数、拒绝域与随机化

25.4.1 非随机化检验

定义 25.4 (非随机化检验). 非随机化检验是可测函数 $\phi : \mathcal{X} \rightarrow \{0, 1\}$, 其中约定 $\phi(x) = \begin{cases} 1, & \text{拒绝 } H_0, \\ 0, & \text{不拒绝 } H_0. \end{cases}$

拒绝域为

$$R = \{x : \phi(x) = 1\}, \quad (25.6)$$



此时 $\phi(x) = \mathbf{1}_R(x)$ 。

拒绝域的补集 R^c 常被称为接受域，但资格考试答题中更严谨的表述是：

$x \in R^c \implies$ 不拒绝 H_0 ，而不是“证明了 H_0 为真”。

考试时需要注意的地方

“不拒绝 H_0 ”与“接受并证明 H_0 ”不是同一结论。

不拒绝可能仅仅因为：

- 样本量过小；
- 检验功效不足；
- 真实参数位于靠近原假设边界的位置；
- 数据噪声较大。

25.4.2 随机化检验

定义 25.5 (随机化检验). 随机化检验是可测函数

$$\phi : \mathcal{X} \rightarrow [0, 1]. \quad (25.7)$$

观测到 $X = x$ 后，以概率 $\phi(x)$ 拒绝 H_0 。

严格实现方法如下。另取 $U \sim \text{Unif}(0, 1)$, $U \perp\!\!\!\perp X$, 并规定

$$\text{拒绝 } H_0 \iff U \leq \phi(X). \quad (25.8)$$

命题 25.6 (随机化检验的拒绝概率). 对任意参数值 θ ,

$$P_\theta(\text{拒绝 } H_0) = \mathbb{E}_\theta[\phi(X)]. \quad (25.9)$$

证明. 由条件期望，

$$\begin{aligned} P_\theta(U \leq \phi(X)) &= \mathbb{E}_\theta[P(U \leq \phi(X) \mid X)] \\ &= \mathbb{E}_\theta[\phi(X)]. \end{aligned}$$

□

注 25.7. 在连续分布中，通常可以通过连续调节临界值达到任意 $0 < \alpha < 1$ 。在离散分布中，拒绝概率只能取离散的一组值，若要求精确 size 为 α ，常需在某个边界点随机化。


25.5 第一类错误、第二类错误与功效函数

定义 25.8 (第一类错误). 当 $\theta \in \Theta_0$ 而检验拒绝 H_0 时，发生第一类错误 (Type I error)。

其参数依赖概率为

$$\alpha_\phi(\theta) = P_\theta(\text{拒绝 } H_0) = \mathbb{E}_\theta[\phi(X)], \theta \in \Theta_0. \quad (25.10)$$

定义 25.9 (第二类错误). 当 $\theta \in \Theta_1$ 而检验不拒绝 H_0 时，发生第二类错误 (Type II error)。



其参数依赖概率为

$$\beta_{\Pi, \phi}(\theta) = P_{\theta}(\text{不拒绝 } H_0) = 1 - \mathbb{E}_{\theta}[\phi(X)], \theta \in \Theta_1. \quad (25.11)$$

定义 25.10 (功效函数). 检验 ϕ 的功效函数定义在整个参数空间上:

$$\beta_{\phi}(\theta) = \mathbb{E}_{\theta}[\phi(X)] = P_{\theta}(\text{拒绝 } H_0), \theta \in \Theta. \quad (25.12)$$

因此:

$$\beta_{\phi}(\theta) = \begin{cases} P_{\theta}(\text{第一类错误}), & \theta \in \Theta_0, \\ 1 - P_{\theta}(\text{第二类错误}), & \theta \in \Theta_1. \end{cases} \quad (25.13)$$

真实情况	不拒绝 H_0	拒绝 H_0
$\theta \in \Theta_0$	正确决定	第一类错误
$\theta \in \Theta_1$	第二类错误	正确决定

考试时需要注意的地方

当原假设或备择假设是复合假设时, 第一类错误和第二类错误一般不是单个数, 而是参数的函数。

错误写法: $P(\text{第一类错误}) = \alpha$ 。

正确写法应先说明: $P_{\theta}(\text{第一类错误}) = \beta_{\phi}(\theta)$, $\theta \in \Theta_0$, 再取原假设参数集合上的上确界。

25.6 size 与 level

定义 25.11 (检验的 size). 检验 ϕ 的 size 定义为

$$\text{size}(\phi) = \sup_{\theta \in \Theta_0} \beta_{\phi}(\theta) = \sup_{\theta \in \Theta_0} \mathbb{E}_{\theta}[\phi(X)]. \quad (25.14)$$

定义 25.12 (level α 检验). 若

$$\sup_{\theta \in \Theta_0} \beta_{\phi}(\theta) \leq \alpha, \quad (25.15)$$

则称 ϕ 为 level α 检验。

定义 25.13 (size α 检验). 若

$$\sup_{\theta \in \Theta_0} \beta_{\phi}(\theta) = \alpha, \quad (25.16)$$

则称 ϕ 为 size α 检验。



概念比较

size 是检验本身的实际最大第一类错误概率；level 是允许的上界。

因此：

- size α 检验一定是 level α 检验；
- level α 检验的实际 size 可能严格小于 α ；
- 一个 size 0.03 的检验同时也是 level 0.05、level 0.10 检验；
- 离散模型中，非随机化检验可能无法达到精确 size α 。

25.6.1 最不利原假设参数

若拒绝域为 $R_c = \{T > c\}$ ，且 $P_\theta(T > c)$ 关于 θ 在 Θ_0 上单调，则 size 通常在原假设边界达到。

例如若功效函数随 θ 增加， $H_0: \theta \leq \theta_0$ ，则

$$\sup_{\theta \leq \theta_0} P_\theta(T > c) = P_{\theta_0}(T > c). \quad (25.17)$$

若功效函数随 θ 减少， $H_0: \theta \geq \theta_0$ ，则

$$\sup_{\theta \geq \theta_0} P_\theta(T < c) = P_{\theta_0}(T < c). \quad (25.18)$$

考试时需要注意的地方

不能仅凭“ θ_0 是边界”就写上确界在 θ_0 达到。

必须说明： $\beta_\phi(\theta)$ 在原假设参数区域上的单调性，或者直接计算并比较。

25.7 离散检验中的边界随机化

命题 25.14 (上尾检验的精确随机化). 设在原假设最不利参数值 θ_0 下，检验统计量 T 为离散型。若存在 c 使

$$P_{\theta_0}(T > c) \leq \alpha \leq P_{\theta_0}(T \geq c), \quad (25.19)$$

定义

$$\gamma = \frac{\alpha - P_{\theta_0}(T > c)}{P_{\theta_0}(T = c)}, \quad (25.20)$$

并令

$$\phi(t) = \mathbf{1}_{\{t > c\}} + \gamma \mathbf{1}_{\{t = c\}}. \quad (25.21)$$


则 $\mathbb{E}_{\theta_0} \phi(T) = \alpha$ 。

证明. 由定义，

$$\begin{aligned} \mathbb{E}_{\theta_0} \phi(T) &= P_{\theta_0}(T > c) + \gamma P_{\theta_0}(T = c) \\ &= \alpha. \end{aligned}$$

由 equation (25.19) 知 $0 \leq \gamma \leq 1$ 。

□



下尾检验相应地取

$$\phi(t) = \mathbf{1}_{\{t < c\}} + \gamma \mathbf{1}_{\{t = c\}}, \quad (25.22)$$

其中

$$\gamma = \frac{\alpha - P_{\theta_0}(T < c)}{P_{\theta_0}(T = c)}. \quad (25.23)$$

离散模型中构造 size α 检验

- (1) 先确定拒绝方向：大值拒绝还是小值拒绝；
- (2) 找到边界整数 c ，使 α 落在相邻两个尾概率之间；
- (3) 写出随机化概率 γ ；
- (4) 明确写出检验函数，而不能只写拒绝域；
- (5) 验证 $\mathbb{E}_{\theta_0} \phi = \alpha$ ；
- (6) 再证明原假设其他参数值下拒绝概率不超过 α 。

25.8 p -值

定义 25.15 (有效 p -值). 统计量 $p(X) \in [0, 1]$ 称为原假设 H_0 的一个有效 p -值，若对每个 $0 \leq u \leq 1$ 都有

$$\sup_{\theta \in \Theta_0} P_{\theta}(p(X) \leq u) \leq u. \quad (25.24)$$

定理 25.16 (p -值产生 level 检验). 若 $p(X)$ 满足 [equation \(25.24\)](#)，则检验

$$\phi_{\alpha}(X) = \mathbf{1}_{\{p(X) \leq \alpha\}} \quad (25.25)$$

是 level α 检验。

证明. 对任意 $\theta \in \Theta_0$ ， $P_{\theta}(\phi_{\alpha} = 1) = P_{\theta}(p(X) \leq \alpha) \leq \alpha$ 。对 $\theta \in \Theta_0$ 取上确界即可。□

若简单原假设下，大的 T 更反对 H_0 ，则观测值 t_{obs} 的上尾 p -值通常为


$$p_{\text{obs}} = P_{\theta_0}(T \geq t_{\text{obs}}). \quad (25.26)$$

若小的 T 更反对 H_0 ，则

$$p_{\text{obs}} = P_{\theta_0}(T \leq t_{\text{obs}}). \quad (25.27)$$

对对称双侧检验，若 $Z \sim N(0, 1)$ ，常有

$$p_{\text{obs}} = 2[1 - \Phi(|z_{\text{obs}}|)]. \quad (25.28)$$



考试时需要注意的地方

p -值不是：

- 原假设为真的概率；
- 备择假设为假的概率；
- 本次拒绝决定犯错的概率；
- 效应大小；
- 检验功效。

频率学 p -值是在原假设分布下，得到“至少与已观测统计量同样不利于 H_0 ”的结果的概率。“更极端”的方向必须由备择假设和所选统计量决定。

25.9 最强检验、UMP 检验与无偏检验

定义 25.17 (最强检验). 对简单备择 $H_1: \theta = \theta_1$, 若 level α 检验 ϕ^* 满足

$$\beta_{\phi^*}(\theta_1) \geq \beta_{\phi}(\theta_1) \quad (25.29)$$

对所有其他 level α 检验 ϕ 成立，则称 ϕ^* 为 level α 的最强检验 (most powerful test, MP test)。

定义 25.18 (一致最强检验). 若 level α 检验 ϕ^* 满足

$$\beta_{\phi^*}(\theta) \geq \beta_{\phi}(\theta) \text{ 对每个 } \theta \in \Theta_1 \quad (25.30)$$

以及每个其他 level α 检验 ϕ 都成立，则称 ϕ^* 为 level α 的一致最强检验 (uniformly most powerful test, UMP test)。

前提条件检查

UMP 是逐点最优: $\forall \theta \in \Theta_1, \beta_{\phi^*}(\theta) \geq \beta_{\phi}(\theta)$ 。

它不是：


- 仅在某一个备择点最优；
- 平均功效最大；
- 最小功效最大；
- Bayes risk 最小；
- minimax 风险最小。

25.9.1 无偏检验

课程讲义使用如下定义。

定义 25.19 (检验的无偏性). 检验 ϕ 称为无偏的，若

$$\beta_{\phi}(\theta_1) \geq \beta_{\phi}(\theta_0) \quad \forall \theta_1 \in \Theta_1, \forall \theta_0 \in \Theta_0. \quad (25.31)$$



等价地,

$$\inf_{\theta \in \Theta_1} \beta_\phi(\theta) \geq \sup_{\theta \in \Theta_0} \beta_\phi(\theta). \quad (25.32)$$

对 size α 检验, 常见的更强表述是

$$\beta_\phi(\theta) \geq \alpha, \theta \in \Theta_1. \quad (25.33)$$

注 25.20. 当双侧问题中 UMP 检验不存在时, 常将比较类限制为无偏检验, 寻找 UMPU (uniformly most powerful unbiased) 检验。

但: UMPU 只是在无偏检验类中最优, 并非所有 level α 检验中最优。

25.10 功效与样本量

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, 其中 σ^2 已知, 考虑 $H_0: \mu \leq \mu_0$, $H_1: \mu > \mu_0$ 。检验

$$\phi = \mathbf{1} \left\{ \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} > z_{1-\alpha} \right\} \quad (25.34)$$

的功效函数为

$$\begin{aligned} \beta(\mu) &= P_\mu \left(\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} > z_{1-\alpha} \right) \\ &= 1 - \Phi \left(z_{1-\alpha} - \frac{\sqrt{n}(\mu - \mu_0)}{\sigma} \right). \end{aligned} \quad (25.35)$$

若要求在 $\mu = \mu_0 + \Delta$, $\Delta > 0$, 处功效至少为 $1 - \beta_0$, 则需 $1 - \Phi \left(z_{1-\alpha} - \frac{\sqrt{n}\Delta}{\sigma} \right) \geq 1 - \beta_0$ 。等价于 $\frac{\sqrt{n}\Delta}{\sigma} \geq z_{1-\alpha} + z_{1-\beta_0}$ 。因此

$$n \geq \frac{\sigma^2}{\Delta^2} (z_{1-\alpha} + z_{1-\beta_0})^2. \quad (25.36)$$

实际样本量取右侧的向上取整。

考试时需要注意的地方

增大样本量不能在所有无限接近原假设边界的备择参数上同时保证高功效。

若 $\mu \downarrow \mu_0$, 则对任意固定 n , $\beta(\mu) \downarrow \alpha$ 。因此样本量设计必须指定一个有实际意义的最小效应 $\Delta > 0$ 。



25.11 假设检验基础答题模板

检验题的完整答题顺序

- (1) 写明模型、参数空间和所有参数范围；
- (2) 将题目中的科学陈述转换成 $H_0 : \theta \in \Theta_0, \quad H_1 : \theta \in \Theta_1$;
- (3) 判断原假设与备择假设是简单还是复合；
- (4) 选定检验统计量 T 并说明其分布；
- (5) 说明大值还是小值支持备择；
- (6) 连续模型写临界值，离散模型必要时写随机化概率；
- (7) 验证 $\sup_{\theta \in \Theta_0} \mathbb{E}_{\theta} \phi(X) = \alpha$ 或 $\leq \alpha$;
- (8) 若题目要求 MP/UMP，必须引用并验证相应定理的全部条件；
- (9) 写出功效函数，至少说明其单调方向；
- (10) 最后以检验函数或明确拒绝规则作答。



第二十六章 Neyman–Pearson 引理、单调似然比与 UMP 检验

26.1 简单似然比与广义似然比的区别

设 P_{θ_0} 与 P_{θ_1} 相对于共同支配测度 ν 具有密度 $f_0(x) = f(x | \theta_0)$, $f_1(x) = f(x | \theta_1)$ 。

定义 26.1 (简单似然比). 检验 $H_0 : \theta = \theta_0$ 对 $H_1 : \theta = \theta_1$ 时, 简单似然比定义为

$$L_{10}(x) = \frac{f_1(x)}{f_0(x)}. \tag{26.1}$$

采用扩展值约定:
$$L_{10}(x) = \begin{cases} f_1(x)/f_0(x), & f_0(x) > 0, \\ +\infty, & f_0(x) = 0, f_1(x) > 0, \\ 0, & f_0(x) = f_1(x) = 0. \end{cases}$$

大的 $L_{10}(x)$ 表示样本在备择分布下相对于原假设分布更可能出现, 因此 Neyman–Pearson 检验拒绝于 $L_{10}(x)$ 大。

概念比较

必须区分两个方向相反的统计量:

名称	统计量	拒绝方向
简单似然比	$\frac{f(x \theta_1)}{f(x \theta_0)}$	大值拒绝
广义似然比	$\Lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta x)}{\sup_{\theta \in \Theta} L(\theta x)}$	小值拒绝


二者有时都被简称为 likelihood ratio, 考试中必须明确所用定义。

26.2 Neyman–Pearson 引理

26.2.1 精确陈述

定理 26.2 (Neyman–Pearson 引理: 充分性). 考虑简单假设 $H_0 : \theta = \theta_0$, $H_1 : \theta = \theta_1$ 。设检验函数 ϕ^* 满足, 对某个 $0 \leq k < \infty$,

$$\phi^*(x) = \begin{cases} 1, & f_1(x) > k f_0(x), \\ \gamma(x) \in [0, 1], & f_1(x) = k f_0(x), \\ 0, & f_1(x) < k f_0(x), \end{cases} \tag{26.2}$$



并且

$$\mathbb{E}_{\theta_0} \phi^*(X) = \alpha. \quad (26.3)$$

则 ϕ^* 是所有 level α 检验中, 对备择 θ_1 的最强检验。

证明. 任取另一个 level α 检验 ϕ , 则 $0 \leq \phi \leq 1$, $\mathbb{E}_{\theta_0} \phi \leq \alpha$ 。

由 equation (26.2), 对每个 x 均有

$$[\phi^*(x) - \phi(x)][f_1(x) - kf_0(x)] \geq 0. \quad (26.4)$$

确实:

- 若 $f_1 > kf_0$, 则 $\phi^* = 1 \geq \phi$;
- 若 $f_1 < kf_0$, 则 $\phi^* = 0 \leq \phi$;
- 若 $f_1 = kf_0$, 第二个因子为零。

对 equation (26.4) 关于 ν 积分:

$$0 \leq \int (\phi^* - \phi)(f_1 - kf_0) d\nu = \mathbb{E}_{\theta_1} \phi^* - \mathbb{E}_{\theta_1} \phi - k[\mathbb{E}_{\theta_0} \phi^* - \mathbb{E}_{\theta_0} \phi].$$

因此

$$\mathbb{E}_{\theta_1} \phi^* - \mathbb{E}_{\theta_1} \phi \geq k[\alpha - \mathbb{E}_{\theta_0} \phi] \geq 0.$$

故 $\beta_{\phi^*}(\theta_1) \geq \beta_{\phi}(\theta_1)$ 。 □

26.2.2 边界随机化的存在性

定理 26.3 (任意 size 下的 NP 检验存在性). 对任意 $0 < \alpha < 1$, 存在 $k \in [0, \infty)$ 使

$$P_{\theta_0}(L_{10} > k) \leq \alpha \leq P_{\theta_0}(L_{10} \geq k). \quad (26.5)$$

若 $P_{\theta_0}(L_{10} = k) > 0$, 定义

$$\gamma = \frac{\alpha - P_{\theta_0}(L_{10} > k)}{P_{\theta_0}(L_{10} = k)}. \quad (26.6)$$

则

$$\phi^* = \mathbf{1}_{\{L_{10} > k\}} + \gamma \mathbf{1}_{\{L_{10} = k\}} \quad (26.7)$$

是 size α 的最强检验。

证明思路

在 P_{θ_0} 下考察随机变量 $L_{10}(X)$ 的分布。函数 $k \mapsto P_{\theta_0}(L_{10} > k)$ 单调不增, 因此可取一个分位点 k 满足 equation (26.5)。

若边界无原子, 则已经有精确等号; 若边界有正概率, 则在 $\{L_{10} = k\}$ 上以概率 γ 拒绝, 从而补足到精确 α 。

26.2.3 必要性与唯一性

定理 26.4 (Neyman-Pearson 引理: 必要性). 设 ϕ^* 是 equation (26.2) 形式的 size α 检验, 且 $k > 0$.

若 ϕ 也是 level α 的最强检验, 则:

- (1) ϕ 必须也是 size α : $\mathbb{E}_{\theta_0}\phi = \alpha$;
- (2) 在 $\{x: f_1(x) \neq kf_0(x)\}$ 上, $\phi(x) = \phi^*(x)$ 对 P_{θ_0} 与 P_{θ_1} 几乎处处成立。

证明. 由于 ϕ^* 与 ϕ 都是最强检验, $\mathbb{E}_{\theta_1}\phi^* = \mathbb{E}_{\theta_1}\phi$. 在充分性证明中的不等式给出 $0 \leq -k[\alpha - \mathbb{E}_{\theta_0}\phi]$. 因为 $k > 0$, $\mathbb{E}_{\theta_0}\phi \geq \alpha$. 另一方面 ϕ 是 level α 检验, 所以 $\mathbb{E}_{\theta_0}\phi \leq \alpha$. 故 $\mathbb{E}_{\theta_0}\phi = \alpha$.

于是 $\int(\phi^* - \phi)(f_1 - kf_0) d\nu = 0$. 被积函数由 equation (26.4) 处处非负, 因此它必须几乎处处为零。

在 $f_1 > kf_0$ 处, $\phi^* = 1$, 从而 $(1 - \phi)(f_1 - kf_0) = 0$ 迫使 $\phi = 1$.

在 $f_1 < kf_0$ 处, $\phi^* = 0$, 从而 $-\phi(f_1 - kf_0) = 0$ 迫使 $\phi = 0$. □

推论 26.5 (NP 检验的唯一性). 若

$$P_{\theta_0}(L_{10} = k) = P_{\theta_1}(L_{10} = k) = 0, \quad (26.8)$$

则 size α 的最强检验在 P_{θ_0} 与 P_{θ_1} 几乎处处意义下唯一。

考试时需要注意的地方

Neyman-Pearson 引理直接解决的是: 简单原假设 对 简单备择假设.

对于复合备择, 必须额外证明同一个最强检验对所有备择参数都不变, 才能得到 UMP。

对于复合原假设, 还必须验证: $\sup_{\theta \in \Theta_0} \mathbb{E}_{\theta}\phi \leq \alpha$ 。

26.3 Neyman-Pearson 引理的标准例题

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, σ^2 已知, 检验 $H_0: \mu = \mu_0$, $H_1: \mu = \mu_1$, $\mu_1 > \mu_0$ 。简单似然比为

$$\begin{aligned} \frac{L(\mu_1)}{L(\mu_0)} &= \exp \left\{ -\frac{1}{2\sigma^2} \sum_i [(X_i - \mu_1)^2 - (X_i - \mu_0)^2] \right\} \\ &= C(\mu_0, \mu_1) \exp \left\{ \frac{\mu_1 - \mu_0}{\sigma^2} \sum_{i=1}^n X_i \right\}, \end{aligned}$$


其中 $C(\mu_0, \mu_1)$ 不依赖样本。

因为 $\mu_1 - \mu_0 > 0$, 似然比随 $\sum_i X_i$ 严格增加。所以最强检验拒绝于 $\bar{X}$ 大。

选择临界值使 $P_{\mu_0} \left(\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} > z_{1-\alpha} \right) = \alpha$ 。故拒绝规则为

$$\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} > z_{1-\alpha}. \quad (26.9)$$

关键是: 该拒绝规则不依赖具体的 $\mu_1 > \mu_0$ 。因此它实际上对所有 $\mu_1 > \mu_0$ 同时最强, 进而产生一侧 UMP 检验。



26.4 单调似然比

定义 26.6 (单调似然比). 设 $\{P_\theta : \theta \in \Theta \subseteq \mathbb{R}\}$ 相对于共同支配测度具有密度 f_θ 。若存在实值统计量 $T = T(X)$, 使对任意 $\theta_2 > \theta_1$, 比值

$$\frac{f_{\theta_2}(x)}{f_{\theta_1}(x)} \quad (26.10)$$

是 $T(x)$ 的非减函数, 则称该模型关于 T 具有单调似然比 (monotone likelihood ratio, MLR)。

注 26.7. 若 $f_{\theta_2}/f_{\theta_1}$ 是 T 的非增函数, 则等价地说该模型关于 $-T$ 具有非减单调似然比。

前提条件检查

MLR 的方向依赖:

- 参数的排序方式;
- 参数化;
- 所选统计量的符号。

例如指数分布既可用率参数 λ , 也可用尺度参数 $\theta = 1/\lambda$ 。在同一个统计量上, 两个参数化的单调方向相反。

26.4.1 充分统计量版本与联合密度版本

课程讲义常采用如下表述:

若 T 充分, 且 T 的密度 $g_\theta(t)$ 满足 $g_{\theta_2}(t)/g_{\theta_1}(t)$ 关于 t 单调, 则使用 Karlin-Rubin 定理。

更一般的表述直接要求联合密度族 $f_\theta(x)$ 关于某个统计量 $T(x)$ 具有 MLR, 并不逻辑上要求 T 充分。

若 $f_\theta(x) = g_\theta(T(x))h(x)$, 则 $\frac{f_{\theta_2}(x)}{f_{\theta_1}(x)} = \frac{g_{\theta_2}(T(x))}{g_{\theta_1}(T(x))}$, 所以充分性是验证 MLR 的常用便捷条件。

26.4.2 一参数指数族的 MLR 判据

命题 26.8 (指数族的 MLR). 设

$$f_\theta(x) = h(x) \exp \{ \eta(\theta)T(x) - A(\theta) \}, \quad \theta \in \Theta \subseteq \mathbb{R}. \quad (26.11)$$

若 $\eta(\theta)$ 严格增加, 则该族关于 T 具有 MLR。


若 $\eta(\theta)$ 严格减少, 则该族关于 $-T$ 具有 MLR。

证明. 对 $\theta_2 > \theta_1$, $\frac{f_{\theta_2}(x)}{f_{\theta_1}(x)} = \exp \{ [\eta(\theta_2) - \eta(\theta_1)]T(x) - [A(\theta_2) - A(\theta_1)] \}$ 。若 $\eta(\theta_2) - \eta(\theta_1) > 0$, 该比值关于 $T(x)$ 增加。若其小于零, 则关于 $T(x)$ 减少。□

26.5 MLR 推出随机单调性

命题 26.9 (阈值检验的功效单调性). 若模型关于 T 具有非减 MLR, 定义上尾随机化检验

$$\delta_{c,\gamma}(x) = \mathbf{1}_{\{T(x) > c\}} + \gamma \mathbf{1}_{\{T(x) = c\}}, \quad 0 \leq \gamma \leq 1. \quad (26.12)$$



则

$$\theta \mapsto \mathbb{E}_\theta[\delta_{c,\gamma}(X)] \quad (26.13)$$

是非减函数。

证明. 任取 $\theta_1 < \theta_2$ 。由于 $f_{\theta_2}/f_{\theta_1}$ 随 T 增加, 阈值检验 $\delta_{c,\gamma}$ 是检验 $H_0 : \theta = \theta_1$ 对 $H_1 : \theta = \theta_2$ 的 Neyman–Pearson 检验, 其 size 为 $a = \mathbb{E}_{\theta_1}\delta_{c,\gamma}$ 。

常数随机化检验 $\phi(x) \equiv a$ 也是 size a 的检验, 并且在 θ_2 下功效仍为 a 。

由 Neyman–Pearson 引理, $\mathbb{E}_{\theta_2}\delta_{c,\gamma} \geq \mathbb{E}_{\theta_2}\phi = a = \mathbb{E}_{\theta_1}\delta_{c,\gamma}$ 。 $\square$

推论 26.10. 若模型关于 T 具有非减 MLR , 则 $P_\theta(T > c)$ 随 θ 非减, 而 $P_\theta(T < c)$ 随 θ 非增。

26.6 Karlin–Rubin 定理

定理 26.11 (Karlin–Rubin 定理: 上尾形式). 设 $\{P_\theta : \theta \in \Theta \subseteq \mathbb{R}\}$ 关于统计量 T 具有非减 MLR 。

考虑

$$H_0 : \theta \leq \theta_0, H_1 : \theta > \theta_0. \quad (26.14)$$

若 c, γ 使

$$\mathbb{E}_{\theta_0} [\mathbf{1}_{\{T > c\}} + \gamma \mathbf{1}_{\{T = c\}}] = \alpha, \quad (26.15)$$

则

$$\phi^* = \mathbf{1}_{\{T > c\}} + \gamma \mathbf{1}_{\{T = c\}} \quad (26.16)$$

是 level α 的 UMP 检验。

证明. 第一步, 验证 level。

由 定理 26.9, $\beta_{\phi^*}(\theta)$ 随 θ 非减。因此对所有 $\theta \leq \theta_0$, $\beta_{\phi^*}(\theta) \leq \beta_{\phi^*}(\theta_0) = \alpha$ 。所以 ϕ^* 是 level α , 且 size 为 α 。

第二步, 证明 UMP。

固定任意 $\theta_1 > \theta_0$ 。由 MLR , $f_{\theta_1}/f_{\theta_0}$ 随 T 非减, 所以 ϕ^* 是检验 $\theta = \theta_0$ 对 $\theta = \theta_1$ 的 Neyman–Pearson size α 检验。

任取另一个对复合原假设 $\theta \leq \theta_0$ 为 level α 的检验 ϕ 。特别地, $\mathbb{E}_{\theta_0}\phi \leq \alpha$ 。由 Neyman–Pearson 引理, $\mathbb{E}_{\theta_1}\phi^* \geq \mathbb{E}_{\theta_1}\phi$ 。因为 $\theta_1 > \theta_0$ 任意, 所以 ϕ^* 在整个备择参数集合上逐点支配所有 level α 检验。 $\square$

定理 26.12 (Karlin–Rubin 定理: 下尾形式). 在相同 MLR 条件下, 考虑 $H_0 : \theta \geq \theta_0, H_1 : \theta < \theta_0$ 。若 $\mathbb{E}_{\theta_0} [\mathbf{1}_{\{T < c\}} + \gamma \mathbf{1}_{\{T = c\}}] = \alpha$, 则

$$\phi^* = \mathbf{1}_{\{T < c\}} + \gamma \mathbf{1}_{\{T = c\}} \quad (26.17)$$

是 level α 的 UMP 检验。

证明. 对统计量 $-T$ 应用 定理 26.11。 $\square$

26.7 识别 Karlin–Rubin 题型

证明思路

识别信号：

- 一维参数；
- 一侧原假设与一侧备择；
- 一参数指数族；
- 题目明确要求证明 MLR；
- 似然比化为 $C(\theta_1, \theta_2)e^{a(\theta_1, \theta_2)T}$ ；
- 需要 UMP 检验。

构造步骤：

- (1) 找出统计量 T ；
- (2) 对 $\theta_2 > \theta_1$ 计算 $f_{\theta_2}/f_{\theta_1}$ ；
- (3) 判断关于 T 的增减方向；
- (4) 根据备择方向选择上尾或下尾；
- (5) 在原假设最不利边界 θ_0 下选临界值；
- (6) 离散型时加入随机化；
- (7) 由 Karlin–Rubin 说明 UMP；
- (8) 写出功效函数并说明单调性。

常见失败原因：

- 只说明 T 充分，没有证明 MLR；
- 只证明 MLR，没有验证 size；
- 拒绝方向写反；
- 参数经过非单调变换后仍沿用原方向；
- 离散分布要求 size α 却未随机化；
- 双侧备择错误套用 Karlin–Rubin。

26.8 双侧问题中 UMP 通常不存在

定理 26.13 (正态均值双侧检验不存在 UMP). 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, 其中 σ^2 已知, 且 $0 < \alpha < 1$. 对检验问题 $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$, 不存在 level α 的 UMP 检验。

证明. 取任意 $\mu_1 < \mu_0$. 由 Neyman–Pearson 引理, 针对简单备择 μ_1 的唯一 MP size α 检验为 $\phi_L = \mathbf{1}\left\{\frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma} < z_\alpha\right\}$. 这里 $z_\alpha < 0$.

再取任意 $\mu_2 > \mu_0$. 针对简单备择 μ_2 的唯一 MP size α 检验为 $\phi_U = \mathbf{1}\left\{\frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma} > z_{1-\alpha}\right\}$.

若 UMP 检验 ϕ^* 存在, 则它必须在 μ_1 处达到最大功效. 由 NP 必要性与唯一性, $\phi^* = \phi_L$ P_{μ_0} -a.s. 同理, 为了在 μ_2 处达到最大功效, 必须有 $\phi^* = \phi_U$ P_{μ_0} -a.s. 但 ϕ_L 与 ϕ_U 的拒绝域分别位于相反两尾, 且二者在正概率集合上不同, 矛盾. $\square$

考试时需要注意的地方

常见错误：“双侧 LRT 存在，所以双侧 UMP 存在。”

广义似然比检验通常能够构造，但它未必 UMP。

“可构造一个合理检验”与“存在对每个备择点都逐点最优的检验”是完全不同的命题。

26.9 历年真题：只观察正态样本符号后的 UMP 检验**往年真题**

[24F-Q7(b), 10 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$, 但只记录 $Y_i = \mathbf{1}_{\{X_i < 0\}}$ 。基于 $Y = (Y_1, \dots, Y_n)$ 构造 size α 的 UMP 检验: $H_0: \mu \leq \mu_0, H_1: \mu > \mu_0$ 。

解：定义 $q(\mu) = P_\mu(X_i < 0) = \Phi(-\mu)$ 。由于 Φ 严格增加， $q(\mu)$ 关于 μ 严格减少。

又有 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(q(\mu))$ 。令

$$S = \sum_{i=1}^n Y_i. \quad (26.18)$$

则 $S \sim \text{Bin}(n, q(\mu))$ 。

原假设与备择可重写为 $H_0: q \geq q_0, H_1: q < q_0, q_0 = \Phi(-\mu_0)$ 。

对 $\mu_2 > \mu_1$ 有 $q_2 = q(\mu_2) < q_1 = q(\mu_1)$ 。 S 的似然比为

$$\begin{aligned} \frac{g_{\mu_2}(s)}{g_{\mu_1}(s)} &= \frac{q_2^s (1 - q_2)^{n-s}}{q_1^s (1 - q_1)^{n-s}} \\ &= \left[\frac{q_2(1 - q_1)}{q_1(1 - q_2)} \right]^s \left[\frac{1 - q_2}{1 - q_1} \right]^n. \end{aligned}$$

因为 $q_2 < q_1$, 所以 $\frac{q_2(1-q_1)}{q_1(1-q_2)} < 1$ 。故似然比关于 s 严格减少。

因此， μ 越大，较小的 S 越支持备择。最优拒绝域应位于 S 的下尾。

选择整数 c 使

$$P_{q_0}(S < c) \leq \alpha \leq P_{q_0}(S \leq c). \quad (26.19)$$

令

$$\gamma = \frac{\alpha - P_{q_0}(S < c)}{P_{q_0}(S = c)}. \quad (26.20)$$

定义检验

$$\phi(Y) = \mathbf{1}_{\{S < c\}} + \gamma \mathbf{1}_{\{S = c\}}. \quad (26.21)$$

在 $\mu = \mu_0$ 下， $\mathbb{E}_{\mu_0} \phi = \alpha$ 。当 $\mu \leq \mu_0$ 时， $q(\mu) \geq q_0$ 。二项分布的下尾概率随 q 增加而减小，因此 $\mathbb{E}_\mu \phi \leq \mathbb{E}_{\mu_0} \phi = \alpha$ 。故该检验是 size α 。

又因为模型关于 $-S$ 对参数 μ 具有 MLR，由 Karlin-Rubin 定理，该检验是 UMP。



其功效函数为

$$\beta(\mu) = \sum_{j=0}^{c-1} \binom{n}{j} q(\mu)^j [1 - q(\mu)]^{n-j} + \gamma \binom{n}{c} q(\mu)^c [1 - q(\mu)]^{n-c}. \quad (26.22)$$

该函数关于 μ 非减。 □

考试时需要注意的地方

参考答案必须包含：

- (1) 写出 $q(\mu) = \Phi(-\mu)$;
- (2) 将问题化为二项参数的下尾检验;
- (3) 证明似然比随 S 减少;
- (4) 写出离散边界随机化;
- (5) 验证原假设上确界在 μ_0 达到;
- (6) 明确引用 Karlin-Rubin, 而不是只写“显然 UMP”。

26.10 历年真题：Pareto 模型中总体均值的 UMP 检验

往年真题

[24S-Q10, 10 分]

设 $X_1, \dots, X_n$ 为收入样本, 服从 Pareto 密度

$$f(x | \theta) = \theta 100^\theta x^{-(1+\theta)} \mathbf{1}_{\{x > 100\}}, \quad \theta > 1. \quad (26.23)$$

令 $\mu = \mathbb{E}_\theta X$ 。写出 level α 的 UMP 检验 $H_0: \mu = \mu_0$, $H_1: \mu > \mu_0$ 的拒绝域。

解：先计算总体均值：

$$\begin{aligned} \mu(\theta) &= \int_{100}^{\infty} x \theta 100^\theta x^{-(1+\theta)} dx \\ &= \theta 100^\theta \int_{100}^{\infty} x^{-\theta} dx \\ &= \theta 100^\theta \frac{100^{1-\theta}}{\theta - 1} \\ &= \frac{100\theta}{\theta - 1}. \end{aligned}$$

因此


$$\mu(\theta) = \frac{100\theta}{\theta - 1}, \quad \mu'(\theta) = -\frac{100}{(\theta - 1)^2} < 0. \quad (26.24)$$

均值关于 θ 严格减少。

由 $\mu_0 = \frac{100\theta_0}{\theta_0 - 1}$ 解得

$$\theta_0 = \frac{\mu_0}{\mu_0 - 100}, \quad \mu_0 > 100. \quad (26.25)$$

由于 $\mu(\theta)$ 严格减少, $H_0: \mu = \mu_0 \iff H_0: \theta = \theta_0$, 而 $H_1: \mu > \mu_0 \iff H_1: \theta < \theta_0$ 。



令

$$Y_i = \log \frac{X_i}{100}. \quad (26.26)$$

对 $y > 0$, $x = 100e^y$, $\frac{dx}{dy} = 100e^y$ 。故

$$\begin{aligned} f_Y(y) &= \theta 100^\theta (100e^y)^{-(1+\theta)} 100e^y \\ &= \theta e^{-\theta y}. \end{aligned}$$

所以 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\text{rate } \theta)$ 。

令

$$T = \sum_{i=1}^n \log \frac{X_i}{100}. \quad (26.27)$$

则 $T \sim \text{Gamma}(n, \text{rate } \theta)$ 。

对任意 $\theta_1 < \theta_0$, 似然比为 $\frac{L(\theta_1)}{L(\theta_0)} = \left(\frac{\theta_1}{\theta_0}\right)^n \exp\{(\theta_0 - \theta_1)T\}$, 它关于 T 严格增加。

因此对所有 $\theta_1 < \theta_0$, NP 最强检验均拒绝于 T 大, 且拒绝规则不依赖具体 θ_1 , 故得到 UMP 检验。

在 H_0 下, $2\theta_0 T \sim \chi_{2n}^2$ 。因此拒绝域为

$$2\theta_0 \sum_{i=1}^n \log \frac{X_i}{100} \geq \chi_{2n, 1-\alpha}^2, \quad \theta_0 = \frac{\mu_0}{\mu_0 - 100}. \quad (26.28)$$

由于卡方分布连续, $P_{\theta_0}(\text{拒绝 } H_0) = \alpha$ 。

□

考试时需要注意的地方

本题最常见的错误是忽略 $\mu(\theta)$ 关于 θ 是递减函数。

错误方向: $\mu > \mu_0 \implies \theta > \theta_0$ 。

正确方向: $\mu > \mu_0 \iff \theta < \theta_0$ 。

26.11 历年真题: Gamma 双侧检验中 UMP 不存在

往年真题

[25S-Q8(a), 10 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Gamma}(2025, \theta)$, $\theta > 0$, 采用形状-尺度参数化: $f(x | \theta) = \frac{x^{2025-1} e^{-x/\theta}}{\Gamma(2025)\theta^{2025}}$, $x > 0$ 。考虑 $H_0: \theta = 1$, $H_1: \theta \neq 1$ 。判断是否存在 level 0.05 的 UMP 检验。

解: 记 $a = 2025$, $T = \sum_{i=1}^n X_i$ 。忽略不依赖 θ 的因子, $L(\theta) \propto \theta^{-na} \exp(-\frac{T}{\theta})$ 。

先取简单备择 $0 < \theta_1 < 1$ 。似然比为 $\frac{L(\theta_1)}{L(1)} = \theta_1^{-na} \exp\left\{-T\left(\frac{1}{\theta_1} - 1\right)\right\}$ 。因为 $\frac{1}{\theta_1} - 1 > 0$, 该比值关于 T 严格减少。由 Neyman-Pearson 引理, 针对 $\theta_1 < 1$ 的唯一 MP size 0.05 检验拒绝于 T 的下尾:

$$T \leq \frac{1}{2} \chi_{2na, 0.05}^2. \quad (26.29)$$

再取简单备择 $\theta_2 > 1$ 。此时 $\frac{L(\theta_2)}{L(1)} = \theta_2^{-na} \exp \left\{ T \left(1 - \frac{1}{\theta_2} \right) \right\}$ ，它关于 T 严格增加。针对 $\theta_2 > 1$ 的唯一 MP size 0.05 检验拒绝于上尾：

$$T \geq \frac{1}{2} \chi_{2na, 0.95}^2. \quad (26.30)$$

由于 $T | \theta = 1$ 具有连续 Gamma 分布，两个 NP 检验分别在相反尾部拒绝，且在正概率集合上不同。

若 UMP 检验存在，它必须同时等于 equation (26.29) 与 equation (26.30) 所对应的唯一 MP 检验，矛盾。

因此

$$H_0 : \theta = 1 \quad \text{对} \quad H_1 : \theta \neq 1 \quad \text{不存在 level 0.05 的 UMP 检验。} \quad (26.31)$$

□

考试时需要注意的地方

只写“因为是双侧检验，所以 UMP 不存在”论证不足。

参考证明必须：

- (1) 选一个 $\theta_1 < 1$ ，得到下尾唯一 MP 检验；
- (2) 选一个 $\theta_2 > 1$ ，得到上尾唯一 MP 检验；
- (3) 使用 NP 必要性或唯一性说明任何 UMP 检验必须同时等于二者；
- (4) 指出两个拒绝域在正概率集合上不同。

26.12 历年真题：变换为指数分布后的 MLR 检验

往年真题

[26S-Q7, 10 分]

设 $X_1, \dots, X_n$ 独立同分布，密度为

$$f(x; \theta) = \frac{1}{2\theta\sqrt{x}} e^{-\sqrt{x}/\theta} \mathbf{1}_{\{x>0\}}, \quad \theta > 0. \quad (26.32)$$


- (1) 证明联合密度关于某个统计量具有 MLR；
- (2) 构造 size α 的 UMP 检验： $H_0 : \theta \geq 1$, $H_1 : \theta < \frac{1}{2}$.

解：令 $Y_i = \sqrt{X_i}$ 。对 $y > 0$, $x = y^2$, $\frac{dx}{dy} = 2y$ 。于是

$$\begin{aligned} f_Y(y; \theta) &= f_X(y^2; \theta) 2y \\ &= \frac{1}{2\theta y} e^{-y/\theta} 2y \\ &= \frac{1}{\theta} e^{-y/\theta}. \end{aligned}$$

故

$$Y_i = \sqrt{X_i} \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\text{scale } \theta). \quad (26.33)$$



定义

$$T = \sum_{i=1}^n \sqrt{X_i}. \quad (26.34)$$

联合密度可写为 $f_{\theta}(\mathbf{x}) = \left[2^{-n} \prod_{i=1}^n x_i^{-1/2} \mathbf{1}_{\{x_i > 0, \forall i\}} \right] \theta^{-n} \exp\left(-\frac{T}{\theta}\right)$.

对 $\theta_2 > \theta_1$,

$$\frac{f_{\theta_2}(\mathbf{x})}{f_{\theta_1}(\mathbf{x})} = \left(\frac{\theta_1}{\theta_2}\right)^n \exp\left\{T\left(\frac{1}{\theta_1} - \frac{1}{\theta_2}\right)\right\}.$$

由于 $\frac{1}{\theta_1} - \frac{1}{\theta_2} > 0$, 该比值关于 T 严格增加。故模型关于 $T = \sum_i \sqrt{X_i}$ 具有 MLR。

参数较小时, T 倾向于较小, 因此针对 $H_1: \theta < \frac{1}{2}$ 应在 T 的下尾拒绝。

由于 $T \sim \text{Gamma}(n, \text{scale } \theta)$, 有

$$\frac{2T}{\theta} \sim \chi_{2n}^2. \quad (26.35)$$

对拒绝域 $T \leq c$, 拒绝概率随 θ 增大而减小。因此在原假设 $\theta \geq 1$ 中, 最大第一类错误概率在边界 $\theta = 1$ 达到。

选择 c 使 $P_{\theta=1}(T \leq c) = \alpha$ 。由 equation (26.35), $2c = \chi_{2n, \alpha}^2$ 。所以拒绝域为

$$\boxed{2 \sum_{i=1}^n \sqrt{X_i} \leq \chi_{2n, \alpha}^2}. \quad (26.36)$$

该检验事实上是检验 $H_0: \theta \geq 1$ 对 $H_1: \theta < 1$ 的 UMP 检验, 因此对较小的备择集合 $\theta < \frac{1}{2}$ 当然仍为 UMP。□

考试时需要注意的地方

题目中的原假设与备择假设并不覆盖整个参数空间: $\frac{1}{2} \leq \theta < 1$ 是无差异区间。
这不妨碍定义 UMP: 只需在 Θ_0 上控制 level, 并在题目规定的 Θ_1 上比较功效。

26.13 历年真题: 离散 Uniform 模型中的随机化 UMP

往年真题

[25F-Q11, 10 分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}\{1, 2, \dots, \theta\}$, 其中 θ 是未知正整数。记 $M = X_{(n)} = \max_{1 \leq i \leq n} X_i$ 。

(1) 对 $H_0: \theta \leq \theta_0$, $H_1: \theta > \theta_0$, 证明 $\phi(x) = \begin{cases} 1, & M > \theta_0, \\ \alpha, & M \leq \theta_0 \end{cases}$ 是 size α 的随机化 UMP 检验;

(2) 对 $H_0: \theta = \theta_0$, $H_1: \theta \neq \theta_0$, 若 $c = \theta_0 \alpha^{1/n}$ 是整数, 证明 $\phi(x) = \mathbf{1}_{\{M > \theta_0 \text{ 或 } M \leq c\}}$ 是 size α 的 UMP 检验。

解: 联合质量函数为

$$f_{\theta}(\mathbf{x}) = \theta^{-n} \mathbf{1}_{\{1 \leq M \leq \theta\}}. \quad (26.37)$$

而

$$P_\theta(M \leq m) = \left(\frac{m}{\theta}\right)^n, \quad 1 \leq m \leq \theta. \quad (26.38)$$

第一问：一侧复合原假设

定义

$$\phi_1(\mathbf{x}) = \begin{cases} 1, & M > \theta_0, \\ \alpha, & M \leq \theta_0. \end{cases} \quad (26.39)$$

若 $\theta \leq \theta_0$, 则 $M \leq \theta \leq \theta_0$ 几乎必然。因此 $\mathbb{E}_\theta \phi_1 = \alpha \quad \forall \theta \leq \theta_0$ 。故

$$\text{size}(\phi_1) = \sup_{\theta \leq \theta_0} \mathbb{E}_\theta \phi_1 = \alpha. \quad (26.40)$$

下面证明 UMP。

固定任意简单备择 $\theta_1 > \theta_0$ 。考虑 $H_0: \theta = \theta_0$ 对 $H_1: \theta = \theta_1$ 。似然比为

$$\frac{f_{\theta_1}(\mathbf{x})}{f_{\theta_0}(\mathbf{x})} = \begin{cases} +\infty, & \theta_0 < M \leq \theta_1, \\ \left(\frac{\theta_0}{\theta_1}\right)^n, & M \leq \theta_0. \end{cases} \quad (26.41)$$

因此 Neyman-Pearson 检验首先必须在 $M > \theta_0$ 时拒绝，因为该事件在 H_0 下概率为零而在备择下有正概率。

在 $M \leq \theta_0$ 上，似然比是常数，所有样本点并列。为了达到 size α ，可在这一整组并列点上以概率 α 拒绝。这恰好是 equation (26.39)。

因此 ϕ_1 对每一个 $\theta_1 > \theta_0$ 都是简单原假设 $\theta = \theta_0$ 下的 NP 最强检验。

任意对复合原假设 $\theta \leq \theta_0$ 为 level α 的检验，特别地在 $\theta = \theta_0$ 下也是 level α 。故 NP 最优性说明 ϕ_1 在每个 $\theta_1 > \theta_0$ 处都支配所有复合原假设的 level α 检验。

所以 ϕ_1 是 UMP。

$$\text{其功效函数为 } \beta_1(\theta) = \begin{cases} \alpha, & \theta \leq \theta_0, \\ P_\theta(M > \theta_0) + \alpha P_\theta(M \leq \theta_0), & \theta > \theta_0. \end{cases} \quad \text{由 equation (26.38),}$$

$$\beta_1(\theta) = \begin{cases} \alpha, & \theta \leq \theta_0, \\ 1 - (1 - \alpha) \left(\frac{\theta_0}{\theta}\right)^n, & \theta > \theta_0. \end{cases} \quad (26.42)$$


第二问：双侧备择

设

$$c = \theta_0 \alpha^{1/n} \quad (26.43)$$

为整数，并定义

$$\phi_2(\mathbf{x}) = \mathbf{1}_{\{M > \theta_0\}} + \mathbf{1}_{\{M \leq c\}}. \quad (26.44)$$



两个事件互不相交。

在 $\theta = \theta_0$ 下, $P_{\theta_0}(M > \theta_0) = 0$, 且 $P_{\theta_0}(M \leq c) = \left(\frac{c}{\theta_0}\right)^n = (\alpha^{1/n})^n = \alpha$ 。故

$$\text{size}(\phi_2) = \alpha. \quad (26.45)$$

下面分别验证对 $\theta_1 > \theta_0$ 和 $\theta_1 < \theta_0$ 的最强性。

情形一: $\theta_1 > \theta_0$ 由 equation (26.41), 似然比在 $M > \theta_0$ 上为 $+\infty$, 在 $M \leq \theta_0$ 上为同一个常数。

因此 size α 的 NP 检验必须:

- 在 $M > \theta_0$ 时必然拒绝;
- 在 $M \leq \theta_0$ 的并列区域中选择一个 P_{θ_0} 概率为 α 的子集拒绝。

集合 $\{M \leq c\}$ 在 P_{θ_0} 下概率恰为 α , 所以 equation (26.44) 是对每个 $\theta_1 > \theta_0$ 的 NP 最强检验。

情形二: $\theta_1 < \theta_0$ 此时 $\frac{f_{\theta_1}(x)}{f_{\theta_0}(x)} = \begin{cases} \left(\frac{\theta_0}{\theta_1}\right)^n, & M \leq \theta_1, \\ 0, & \theta_1 < M \leq \theta_0. \end{cases}$

若 $\theta_1 \geq c$, 则 $\{M \leq c\} \subseteq \{M \leq \theta_1\}$, 且 $P_{\theta_0}(M \leq c) = \alpha$ 。在似然比最大的区域 $M \leq \theta_1$ 内选取原假设概率为 α 的子集拒绝, 正是 NP 最强检验。

若 $\theta_1 < c$, 则在备择分布下 $M \leq \theta_1 < c$ 几乎必然, 所以 $P_{\theta_1}(\phi_2 = 1) = 1$ 。功效已达到可能的最大值 1, 因此仍为最强检验。

综上, ϕ_2 对每个 $\theta_1 \neq \theta_0$ 均为最强检验, 故是双侧备择下的 UMP 检验。

其功效函数可写为

$$\beta_2(\theta) = \begin{cases} 1, & \theta \leq c, \\ \left(\frac{c}{\theta}\right)^n, & c < \theta < \theta_0, \\ \alpha, & \theta = \theta_0, \\ 1 - (1 - \alpha) \left(\frac{\theta_0}{\theta}\right)^n, & \theta > \theta_0. \end{cases} \quad (26.46)$$

□

考试时需要注意的地方

“双侧问题一般不存在 UMP”不是无条件定理。

本题能够存在双侧 UMP, 是因为:

- 不同参数的支持集嵌套;
- 似然比在大块样本区域上取常数或无穷;
- 同一个拒绝域能够同时成为所有左右备择的 NP 检验。

因此应说: 正则一参数指数族的常见双侧问题通常无 UMP, 而不能说“所有双侧问题都无 UMP”。

26.14 历年真题：nuisance 参数未知时的精确 size

往年真题

[26S-Q11(c), 15 分题的一部分]

在题设模型中检验 $H_0 : \rho = 0, H_1 : \rho \neq 0$ 。给定拒绝规则 $\frac{\sqrt{n}|\bar{Y}|}{s_Y} > c$, 求使检验 size 为 0.05 的 c 。

解：当 $\rho = 0$ 时，题设随机变量退化为 $Y = \sigma V, V \sim N(0, 1)$ 。因此在 H_0 下， $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2)$ ，其中 $\sigma > 0$ 是 nuisance 参数。

若样本标准差定义为 $s_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$, 则

$$T = \frac{\sqrt{n} \bar{Y}}{s_Y} \sim t_{n-1}$$

(26.47)

对每个 $\sigma > 0$ 都精确成立。

检验拒绝当且仅当 $|T| > c$ 。要求 size 为 0.05，即 $P_{H_0}(|T| > c) = 0.05$ 。由于 t_{n-1} 分布关于零对称， $P(T > c) = 0.025$ 。故

$c = t_{n-1, 0.975}.$

(26.48)

□

注 26.14. 该检验的 size 不依赖 nuisance 参数 σ ，因为 Student 化统计量 $\sqrt{n} \bar{Y} / s_Y$ 在 H_0 下具有参数自由的精确分布。

这说明“原假设是复合的”并不妨碍构造精确 size 检验；关键是能否找到在整个原假设下分布相同的枢轴量。

26.15 假设检验与 UMP 易错点总表

陈述	判断	正确说明
简单假设就是只固定目标参数	错	若仍有 nuisance 参数未知，则假设仍为复合假设。
不拒绝 H_0 等于证明 H_0 为真	错	不拒绝只表示现有数据未达到预定拒绝标准。
第一类错误概率总是 α	错	level α 只保证其在原假设上的上确界不超过 α 。
size 与 level 是同义词	错	size 是实际最大第一类错误概率；level 是允许上界。
功效函数只定义在备择参数空间	不严谨	功效函数通常定义在整个 Θ ；原假设下它等于第一类错误概率。
离散模型总能构造非随机化 size α 检验	错	尾概率是离散的，精确 size 通常需边界随机化。
p -值是 $P(H_0 X)$	错	频率学 p -值是在原假设分布下计算的尾概率。
p -值小意味着效应一定很大	错	p -值还受样本量和方差影响。

陈述	判断	正确说明
Neyman–Pearson 引理直接给出复合对复合的 UMP 检验	错	它直接处理简单原假设对简单备择。
NP 检验拒绝于 f_0/f_1 大	错	若定义简单似然比为 f_1/f_0 ，则拒绝于该比值大。
广义似然比检验也拒绝于统计量大	错	若 $\Lambda = \sup_{\Theta_0} L / \sup_{\Theta} L$ ，则拒绝于 Λ 小。
充分统计量自动产生 UMP 检验	错	还需 MLR 或其他最优性结构。
一参数指数族必然关于原参数具有递增 MLR	错	须检查自然参数 $\eta(\theta)$ 的单调方向。
Karlin–Rubin 可直接用于双侧备择	错	其标准形式解决一侧有序假设。
双侧检验永远不存在 UMP	错	一般正则模型中常不存在，但支持集嵌套等特殊模型可能存在。
存在 LRT 就意味着存在 UMP	错	LRT 是构造方法，UMP 是全体 level 检验中的逐点最优性质。
原假设边界一定是最不利参数	错	需证明拒绝概率在原假设区域单调。
随机化只允许在一个临界点进行	错	NP 似然比并列区域上可以按满足 size 的方式随机化；一个临界点只是最常见情形。

26.16 证明套路总结

证明思路

套路一：证明某检验为 MP。

- (1) 写出 $L_{10} = f_1/f_0$;
- (2) 将其化为统计量 T 的单调函数;
- (3) 写出 NP 拒绝方向;
- (4) 选临界值或随机化使原假设拒绝概率为 α ;
- (5) 引用 Neyman–Pearson 引理。

证明思路

套路二：证明某检验为 UMP。

- (1) 对任意备择点 θ_1 计算简单似然比;
- (2) 证明所有 θ_1 给出同一个拒绝统计量和方向;
- (3) 验证同一个临界值不依赖 θ_1 ;
- (4) 对复合原假设验证最不利边界;
- (5) 结论：同一检验对每个简单备择都 $MP \implies UMP$ 。

证明思路**套路三：证明 UMP 不存在。**

- (1) 选两个方向相反的备择点；
- (2) 分别求各自唯一 NP 检验；
- (3) 证明两个拒绝域在正概率集合上不同；
- (4) 假设 UMP 存在，则由 NP 必要性必须同时等于二者；
- (5) 得到矛盾。

证明思路**套路四：参数函数检验。**若题目检验的是 $\tau(\theta)$ ，先完成：

- (1) 求 $\tau(\theta)$ ；
- (2) 判断其关于 θ 的单调性；
- (3) 将 $H_0: \tau(\theta) \in A_0$ 转换为关于 θ 的假设；
- (4) 再决定拒绝方向。

Pareto 真题中 $\mu(\theta) = \frac{100\theta}{\theta-1}$ 递减，正是最典型的方向翻转。**26.17 答题模板****一侧 UMP 检验题**设题目要求检验 $H_0: \theta \leq \theta_0$ 对 $H_1: \theta > \theta_0$ 。

参考答案应依次写：

- (1) 联合密度或充分统计量密度；
- (2) 对 $\theta_2 > \theta_1$: $\frac{f_{\theta_2}(x)}{f_{\theta_1}(x)} = C(\theta_1, \theta_2)h_{\theta_1, \theta_2}(T(x))$;
- (3) 说明 h 对 T 非减，所以有 MLR；
- (4) 由 Karlin-Rubin, UMP 检验拒绝于 T 大；
- (5) 若连续: $P_{\theta_0}(T > c_\alpha) = \alpha$; 若离散: $P_{\theta_0}(T > c) + \gamma P_{\theta_0}(T = c) = \alpha$;
- (6) 说明功效随 θ 增加，故 $\sup_{\theta \leq \theta_0} \beta(\theta) = \beta(\theta_0) = \alpha$;
- (7) 给出最终检验函数。

证明 UMP 不存在

- (1) 取 θ_L 与 θ_U 分别位于原假设两侧；
- (2) 由 NP 引理得到对 θ_L 的唯一 MP 检验 ϕ_L ；
- (3) 由 NP 引理得到对 θ_U 的唯一 MP 检验 ϕ_U ；
- (4) 证明 $P_{\theta_0}(\phi_L \neq \phi_U) > 0$;
- (5) 若 ϕ^* UMP，则必须同时满足 $\phi^* = \phi_L$ 与 $\phi^* = \phi_U$ a.s., 矛盾。

一些需要记忆的内容

- (1) 简单原假设的严格含义是什么?
- (2) 为什么 $H_0: \mu = \mu_0$ 在 σ^2 未知的正态模型中仍是复合假设?
- (3) 随机化检验函数 $\phi(x) = 0.3$ 如何实际实施?
- (4) 为什么随机化检验的拒绝概率等于 $\mathbb{E}_\theta \phi(X)$?
- (5) 功效函数在原假设区域和备择区域分别表示什么?
- (6) size 与 level 的区别是什么?
- (7) 离散模型中如何通过边界随机化达到精确 size?
- (8) 有效 p -值必须满足什么超均匀性质?
- (9) 为什么 p -值不是原假设为真的概率?
- (10) MP 与 UMP 的量词顺序有何区别?
- (11) Neyman-Pearson 引理的关键点态不等式是什么?
- (12) NP 检验在什么条件下几乎处处唯一?
- (13) MLR 是关于参数还是关于统计量的单调性?
- (14) 一参数指数族何时关于 T 具有递增 MLR?
- (15) Karlin-Rubin 定理为什么需要先验证原假设边界是最不利参数?
- (16) 双侧正态均值检验为什么不存在 UMP?
- (17) nuisance 参数存在时, 如何利用枢轴量得到精确 size?



第二十七章 似然比检验、广义似然比检验与大样本检验

27.1 考纲定位与重要性

重点

重要性等级：S 级。

本章连接以下四条主线：MLE $\rightarrow$ 受限与非受限最大化 $\rightarrow$ 似然比统计量 $\rightarrow$ 精确或渐近检验。

资格考试常见要求包括：

- 从头推导广义似然比统计量；
- 将抽象拒绝域化为熟悉的 z 、 t 、 χ^2 或 F 检验；
- 正确计算自由度；
- 区分精确零假设分布与 Wilks 渐近分布；
- 说明 Wilks 定理的正则条件；
- 比较 LR、Wald 与 score/Rao 检验；
- 识别边界参数、参数依赖支持集和不可识别模型中的失效。

证明要求：

- (1) 一维 Wilks 定理：必须掌握完整证明框架；
- (2) 多维 Wilks 定理：必须掌握几何与二次型框架；
- (3) 正态均值未知方差的 GLRT：必须会完整推导；
- (4) LR、Wald、score 的一阶渐近等价：必须掌握证明框架；
- (5) 非正则模型：必须会解释标准结论为何不能直接使用。

27.2 广义似然比统计量

设统计模型为 $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ ，待检验 $H_0 : \theta \in \Theta_0$, $H_1 : \theta \in \Theta \setminus \Theta_0$ 。

定义 27.1 (广义似然比)。广义似然比统计量定义为

$$\Lambda_n(x) = \frac{\sup_{\theta \in \Theta_0} L_n(\theta | x)}{\sup_{\theta \in \Theta} L_n(\theta | x)}. \quad (27.1)$$

显然

$$0 \leq \Lambda_n(x) \leq 1. \quad (27.2)$$

若受限与非受限 MLE 分别存在，记为 $\hat{\theta}_0 \in \arg \max_{\theta \in \Theta_0} L_n(\theta)$, $\hat{\theta} \in \arg \max_{\theta \in \Theta} L_n(\theta)$ ，则

$$\Lambda_n = \frac{L_n(\hat{\theta}_0)}{L_n(\hat{\theta})}. \quad (27.3)$$



由于原假设限制了参数空间， $L_n(\hat{\theta}_0) \leq L_n(\hat{\theta})$ 。当 Λ_n 很小时，原假设约束使最大似然显著下降，因而应拒绝 H_0 。

定义 27.2 (似然比离差统计量). 定义

$$D_n = -2 \log \Lambda_n = 2 \left[\ell_n(\hat{\theta}) - \ell_n(\hat{\theta}_0) \right]. \tag{27.4}$$

拒绝域可等价写为 $\{\Lambda_n \leq c\} \iff \{D_n \geq d\}$, 其中 $d = -2 \log c$ 。

概念比较

	统计量	定义	拒绝方向
简单似然比与广义似然比的方向相反：	简单似然比	$\frac{f_{\theta_1}(x)}{f_{\theta_0}(x)}$	大值拒绝 H_0
	广义似然比	$\frac{\sup_{\Theta_0} L}{\sup_{\Theta} L}$	小值拒绝 H_0

27.3 广义似然比检验的标准计算流程

GLRT 参考答题流程

(1) 写明完整参数空间 Θ 和原假设参数空间 Θ_0 ;

(2) 写出含支持集指示函数的似然;

(3) 求非受限 MLE $\hat{\theta}$;

(4) 在 Θ_0 内重新最大化, 求受限 MLE $\hat{\theta}_0$;

(5) 代入 $\Lambda_n = L_n(\hat{\theta}_0)/L_n(\hat{\theta})$;

(6) 删除不影响单调性的常数, 并把拒绝域化为熟悉统计量;

(7) 给出 H_0 下统计量的精确或渐近分布;

(8) 选择临界值并验证 level 或渐近 level;

(9) 明确指出自由度和所用正则条件;

(10) 检查边界、支持集和 MLE 存在性。

考试时需要注意的地方


受限 MLE 不是把非受限 MLE“形式上代入原假设”即可得到。

必须重新求解 $\sup_{\theta \in \Theta_0} L_n(\theta)$ 。当 Θ_0 含有不等式约束或 nuisance 参数时, 受限最大点常落在边界, 且与简单代入不同。

27.4 充分统计量与似然比检验

命题 27.3 (LRT 只依赖充分统计量). 若 $T = T(X)$ 对 θ 充分, 并且 $f_{\theta}(x) = g_{\theta}(T(x))h(x)$, 其中 h 不含 θ , 则

$$\Lambda_n(x) = \frac{\sup_{\theta \in \Theta_0} g_{\theta}(T(x))}{\sup_{\theta \in \Theta} g_{\theta}(T(x))}. \tag{27.5}$$



因此 Λ_n 是 T 的函数。

证明. 由因子分解,

$$\begin{aligned}\Lambda_n(x) &= \frac{\sup_{\theta \in \Theta_0} g_\theta(T(x))h(x)}{\sup_{\theta \in \Theta} g_\theta(T(x))h(x)} \\ &= \frac{\sup_{\theta \in \Theta_0} g_\theta(T(x))}{\sup_{\theta \in \Theta} g_\theta(T(x))}.\end{aligned}$$

□

注 27.4. 该命题说明可直接从充分统计量的分布推导 LRT, 但不等于“任意充分统计量函数都是最优检验”。最优性仍需 Neyman–Pearson、Karlin–Rubin、无偏性或渐近理论支持。

27.5 正态均值：方差已知时的精确 LRT

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, 其中 σ^2 已知, 检验 $H_0: \mu = \mu_0$, $H_1: \mu \neq \mu_0$ 。

非受限 MLE 为 $\hat{\mu} = \bar{X}$, 受限 MLE 为 $\hat{\mu}_0 = \mu_0$ 。由平方和分解

$$\sum_{i=1}^n (X_i - \mu_0)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu_0)^2, \quad (27.6)$$

可得

$$\begin{aligned}\Lambda_n &= \frac{\exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu_0)^2\right\}}{\exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2\right\}} \\ &= \exp\left\{-\frac{n(\bar{X} - \mu_0)^2}{2\sigma^2}\right\}.\end{aligned} \quad (27.7)$$

因此 Λ_n 小等价于 $\left|\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}\right|$ 大。

在 H_0 下, $Z = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \sim N(0, 1)$ 。故 size α 的精确 LRT 为

$$\left|\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}\right| \geq z_{1-\alpha/2}. \quad (27.8)$$

同时 $D_n = -2\log \Lambda_n = Z^2 \sim \chi_1^2$ 在有限样本下精确成立。

27.6 正态均值：方差未知时的精确 LRT

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$, 检验 $H_0: \mu = \mu_0$, $H_1: \mu \neq \mu_0$ 。

记 $Q = \sum_{i=1}^n (X_i - \bar{X})^2$, $S^2 = \frac{Q}{n-1}$ 。

27.6.1 非受限最大化

非受限 MLE 为 $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{Q}{n}$ 。因此 $\sup_{\mu, \sigma^2} L(\mu, \sigma^2) = (2\pi)^{-n/2} \left(\frac{Q}{n}\right)^{-n/2} e^{-n/2}$ 。



27.6.2 原假设下的受限最大化

在 H_0 下固定 $\mu = \mu_0$, 对 σ^2 最大化得到 $\hat{\sigma}_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2$ 。由 equation (27.6), $\hat{\sigma}_0^2 = \frac{Q + n(\bar{X} - \mu_0)^2}{n}$ 。故

$$\begin{aligned}\Lambda_n &= \left[\frac{Q}{Q + n(\bar{X} - \mu_0)^2} \right]^{n/2} \\ &= \left[1 + \frac{n(\bar{X} - \mu_0)^2}{Q} \right]^{-n/2}.\end{aligned}\quad (27.9)$$

定义 Student 统计量 $T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}$ 。因为 $Q = (n-1)S^2$, 所以

$$\Lambda_n = \left(1 + \frac{T^2}{n-1} \right)^{-n/2}.\quad (27.10)$$

因此 Λ_n 小当且仅当 $|T|$ 大。在 H_0 下, $T \sim t_{n-1}$ 。故精确 size α 的 LRT 为

$$\left| \frac{\sqrt{n}(\bar{X} - \mu_0)}{S} \right| \geq t_{n-1, 1-\alpha/2}.\quad (27.11)$$

考试时需要注意的地方

该题常见步骤:

- (1) 必须分别求受限与非受限的 σ^2 MLE;
- (2) 必须使用平方和分解;
- (3) 必须将 Λ_n 化为 T^2 的单调函数;
- (4) 最终临界值使用 t_{n-1} , 而不是正态渐近分布;
- (5) 说明该结论是有限样本精确结论。

27.7 Bernoulli 模型的广义似然比统计量

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, $0 < p < 1$, 检验 $H_0: p = p_0$, $H_1: p \neq p_0$ 。记 $S = \sum_{i=1}^n X_i$, $\hat{p} = \frac{S}{n}$ 。


似然为 $L(p) = p^S(1-p)^{n-S}$ 。所以

$$\Lambda_n = \frac{p_0^S(1-p_0)^{n-S}}{\hat{p}^S(1-\hat{p})^{n-S}},\quad (27.12)$$

$$\begin{aligned}D_n &= 2 \left[S \log \frac{\hat{p}}{p_0} + (n-S) \log \frac{1-\hat{p}}{1-p_0} \right] \\ &= 2n \left[\hat{p} \log \frac{\hat{p}}{p_0} + (1-\hat{p}) \log \frac{1-\hat{p}}{1-p_0} \right].\end{aligned}\quad (27.13)$$

约定 $0 \log 0 = 0$ 。

在 H_0 下, $S \sim \text{Bin}(n, p_0)$ 。因此小样本时可由二项分布计算精确拒绝概率; 在正则条件和 $0 < p_0 < 1$ 下, $D_n \xrightarrow{d} \chi_1^2$ 。



考试时需要注意的地方

当 $p_0 = 0$ 或 $p_0 = 1$ 时, 参数位于边界, 普通 Wilks 定理的内部点条件不成立。
不能无条件写 $D_n \xrightarrow{d} \chi_1^2$ 。

27.8 Poisson 模型的 LRT

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, $\lambda > 0$, 检验 $H_0 : \lambda = \lambda_0$, $H_1 : \lambda \neq \lambda_0$ 。非受限 MLE 为 $\hat{\lambda} = \bar{X}$ 。于是

$$\begin{aligned} D_n &= -2 \log \frac{e^{-n\lambda_0} \lambda_0^{\sum X_i}}{e^{-n\hat{\lambda}} \hat{\lambda}^{\sum X_i}} \\ &= 2n \left[\lambda_0 - \hat{\lambda} + \hat{\lambda} \log \frac{\hat{\lambda}}{\lambda_0} \right]. \end{aligned} \quad (27.14)$$

当 $\lambda_0 > 0$ 固定时, $D_n \xrightarrow{d} \chi_1^2$ 。渐近 level α 检验拒绝于

$$D_n \geq \chi_{1,1-\alpha}^2. \quad (27.15)$$

小样本下也可直接利用 $\sum_i X_i \sim \text{Poisson}(n\lambda_0)$ 构造精确检验, 但离散性通常导致实际 size 小于指定 level, 或需要随机化。

27.9 Wilks 定理**27.9.1 标量简单原假设**

定理 27.5 (Wilks 定理: 一维简单原假设). 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(\cdot | \theta)$, $\theta \in \Theta \subseteq \mathbb{R}$, 检验 $H_0 : \theta = \theta_0$ 。

假设:

- (1) θ_0 是 Θ 的内部点;
- (2) 模型可识别;
- (3) 支持集不依赖 θ ;
- (4) $\ell_n(\theta)$ 在 θ_0 邻域内至少三次可微;
- (5) 微分与积分可交换, score 均值为零;
- (6) $0 < I_1(\theta_0) < \infty$;
- (7) MLE 相合且以概率趋于 1 位于内部;
- (8) 三阶余项可以在 $n^{-1/2}$ 邻域内一致控制。

则在 H_0 下,

$$\boxed{-2 \log \Lambda_n \xrightarrow{d} \chi_1^2.} \quad (27.16)$$



27.9.2 证明框架

证明思路

记 $U_n(\theta) = \ell'_n(\theta)$, $J_n(\theta) = -\ell''_n(\theta)$ 。在 MLE $\hat{\theta}$ 处, $U_n(\hat{\theta}) = 0$ 。

对 $\ell_n(\theta_0)$ 在 $\hat{\theta}$ 附近作 Taylor 展开: $\ell_n(\theta_0) = \ell_n(\hat{\theta}) + \frac{1}{2}\ell''_n(\tilde{\theta}_n)(\theta_0 - \hat{\theta})^2$, 其中 $\tilde{\theta}_n$ 位于 θ_0 与 $\hat{\theta}$ 之间。

因此

$$D_n = 2[\ell_n(\hat{\theta}) - \ell_n(\theta_0)] = J_n(\tilde{\theta}_n)(\hat{\theta} - \theta_0)^2 = \left[\sqrt{n}(\hat{\theta} - \theta_0) \sqrt{I_1(\theta_0)} \right]^2 \frac{J_n(\tilde{\theta}_n)/n}{I_1(\theta_0)}. \quad (27.17)$$

由 MLE 渐近正态性, $\sqrt{n}(\hat{\theta} - \theta_0) \sqrt{I_1(\theta_0)} \xrightarrow{d} N(0, 1)$ 。由相合性及 Hessian 大数律, $\frac{J_n(\tilde{\theta}_n)}{n} \xrightarrow{\mathbb{P}} I_1(\theta_0)$ 。由 Slutsky 定理, $D_n \xrightarrow{d} Z^2 \sim \chi_1^2$ 。

考试时需要注意的地方

不能把 $\ell''_n(\hat{\theta})$ 直接替换为其期望而不说明原因。

完整论证需要: $\hat{\theta} \xrightarrow{\mathbb{P}} \theta_0$, $\tilde{\theta}_n \xrightarrow{\mathbb{P}} \theta_0$, $-\frac{1}{n}\ell''_n(\tilde{\theta}_n) \xrightarrow{\mathbb{P}} I_1(\theta_0)$ 。

27.9.3 多参数与复合原假设

定理 27.6 (Wilks 定理: 光滑复合原假设). 设 $\theta \in \Theta \subseteq \mathbb{R}^p$, Θ 为开集。假设原假设参数集合 $\Theta_0 = \{\theta : g(\theta) = 0\}$, 其中 $g : \Theta \rightarrow \mathbb{R}^q$ 连续可微, 且在真值 θ_0 处 *Jacobian* $G(\theta_0) = Dg(\theta_0)$ 具有满行秩 q 。

若通常的多参数正则条件成立, Fisher 信息矩阵 $I_1(\theta_0)$ 正定, 则在 H_0 下

$$-2 \log \Lambda_n \xrightarrow{d} \chi_q^2. \quad (27.18)$$

这里 $q = \dim(\Theta) - \dim(\Theta_0)$ 是原假设施加的独立约束数。

Wilks 自由度计算

- (1) 先数非受限模型中的自由参数数目 p ;
- (2) 再数原假设模型中的自由参数数目 p_0 ;
- (3) 检查约束是否独立;
- (4) 自由度为 $p - p_0$;
- (5) 不要把参数向量的形式分量数直接当成自由度;
- (6) 概率向量满足和为 1 时须先减去一个自由度。

27.9.4 多项分布示例

设五分类计数为 $(Y_1, \dots, Y_5) \sim \text{Multinomial}(n; p_1, \dots, p_5)$, 其中 $p_j \geq 0$, $\sum_{j=1}^5 p_j = 1$ 。非受限模型有 $5 - 1 = 4$ 个自由参数。

考虑 $H_0 : p_1 = p_2 = p_3, p_4 = p_5$ 。在 H_0 下可令 $p_1 = p_2 = p_3 = a$, $p_4 = p_5 = \frac{1-3a}{2}$, 故原假设模型只有一个自由参数。

因此 Wilks 极限自由度为 $4 - 1 = 3$ 。受限 MLE 为 $\hat{p}_{01} = \hat{p}_{02} = \hat{p}_{03} = \frac{Y_1+Y_2+Y_3}{3n}$, $\hat{p}_{04} = \hat{p}_{05} = \frac{Y_4+Y_5}{2n}$ 。于是 $D_n = 2 \sum_{j=1}^5 Y_j \log \frac{Y_j/n}{\hat{p}_{0j}} \xrightarrow{d} \chi_3^2$ 。

前提条件检查

若某些真实分类概率等于零，则真值位于概率单纯形边界，标准 Wilks 内部点条件失效。因此多项模型应用 Wilks 时通常要求 $p_{0j} > 0 \forall j$ 。

27.10 Wald 检验

设 $\hat{\theta}_n$ 满足 $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N_p(0, I_1(\theta_0)^{-1})$ 。考虑 $H_0 : g(\theta) = 0$, $g : \Theta \rightarrow \mathbb{R}^q$ 。

定义 27.7 (Wald 统计量). 若 $G(\theta) = Dg(\theta)$ 具有满行秩，定义

$$W_n = n g(\hat{\theta}_n)^\top \left[G(\hat{\theta}_n) I_1(\hat{\theta}_n)^{-1} G(\hat{\theta}_n)^\top \right]^{-1} g(\hat{\theta}_n). \quad (27.19)$$

在 H_0 与正则条件下，

$$W_n \xrightarrow{d} \chi_q^2. \quad (27.20)$$

若 $p = q = 1$ 且 $H_0 : \theta = \theta_0$ ，则

$$W_n = n I_1(\hat{\theta}_n) (\hat{\theta}_n - \theta_0)^2. \quad (27.21)$$

也可写成学生化形式 $Z_n = \frac{\hat{\theta}_n - \theta_0}{\widehat{\text{se}}(\hat{\theta}_n)}$, $W_n = Z_n^2$ 。

考试时需要注意的地方

Wald 检验并非严格参数化不变。

若对参数作非线性变换，有限样本 Wald 区域可能明显改变；LR 检验则由似然比定义，对一一重参数化保持不变。

27.11 Score 或 Rao 检验

27.11.1 无 nuisance 参数

设 $U_n(\theta) = \nabla_\theta \ell_n(\theta)$ 为 score 向量， $I_n(\theta) = n I_1(\theta)$ 。


对简单原假设 $H_0 : \theta = \theta_0$ ，定义

$$R_n = U_n(\theta_0)^\top I_n(\theta_0)^{-1} U_n(\theta_0). \quad (27.22)$$

在 H_0 下，

$$R_n \xrightarrow{d} \chi_p^2. \quad (27.23)$$

Score 检验只需在原假设参数值处计算 score 和信息，不要求非受限 MLE。



27.11.2 存在 nuisance 参数

令 $\theta = \begin{pmatrix} \psi \\ \lambda \end{pmatrix}$, 其中 $\psi \in \mathbb{R}^q$ 为目标参数, λ 为 nuisance 参数。检验 $H_0 : \psi = \psi_0$ 。记受限 MLE 为 $\hat{\theta}_0 = (\psi_0, \hat{\lambda}_0)$ 。

将 score 与信息矩阵分块: $U = \begin{pmatrix} U_\psi \\ U_\lambda \end{pmatrix}$, $I = \begin{pmatrix} I_{\psi\psi} & I_{\psi\lambda} \\ I_{\lambda\psi} & I_{\lambda\lambda} \end{pmatrix}$ 。由于受限 MLE 对 nuisance 参数满足 $U_\lambda(\hat{\theta}_0) = 0$, 有效信息为

$$I_{\psi \cdot \lambda} = I_{\psi\psi} - I_{\psi\lambda} I_{\lambda\lambda}^{-1} I_{\lambda\psi}. \quad (27.24)$$

Score 统计量为

$$R_n = U_\psi(\hat{\theta}_0)^\top I_{\psi \cdot \lambda}(\hat{\theta}_0)^{-1} U_\psi(\hat{\theta}_0). \quad (27.25)$$

在 H_0 下, $R_n \xrightarrow{d} \chi_q^2$ 。

概念比较

检验	主要计算对象	典型优缺点
LR	受限和非受限 MLE	参数化不变; 需做两次最大化
Wald	非受限 MLE 与标准误	计算直接; 有限样本参数化敏感
Score/Rao	受限 MLE 与原假设处 score	不需非受限 MLE; 信息矩阵处理较繁

27.12 LR、Wald 与 Score 的渐近等价

定理 27.8 (三类检验的一阶渐近等价). 在同一组正则条件下, 对具有 q 个独立光滑约束的原假设,

$$D_n - W_n = o_p(1), D_n - R_n = o_p(1), W_n - R_n = o_p(1) \quad (27.26)$$

在 H_0 下成立。

因此三者均收敛到 χ_q^2 。

证明思路

核心是局部二次近似:

$$\ell_n \left(\theta_0 + \frac{h}{\sqrt{n}} \right) - \ell_n(\theta_0) = h^\top \frac{U_n(\theta_0)}{\sqrt{n}} - \frac{1}{2} h^\top I_1(\theta_0) h + o_p(1), \quad (27.27)$$

其中余项在有界 h 集合上一致。

最大化右侧二次函数得到 $\sqrt{n}(\hat{\theta} - \theta_0) = I_1(\theta_0)^{-1} \frac{U_n(\theta_0)}{\sqrt{n}} + o_p(1)$ 。将这一展开分别代入 LR、Wald 与 score 统计量, 得到相同的主导二次型。

27.13 固定备择与局部备择

27.13.1 固定备择

若真实参数 $\theta \notin \Theta_0$ 固定, 并且模型可识别、检验相合, 则通常 $D_n \xrightarrow{\mathbb{P}} +\infty$, 从而 $P_\theta(D_n > \chi_{q,1-\alpha}^2) \rightarrow 1$ 。

27.13.2 局部备择

考虑 $\theta_n = \theta_0 + \frac{h}{\sqrt{n}}$ 。在正则模型中, LR、Wald 与 score 统计量通常共同收敛到非中心卡方:

$$D_n, W_n, R_n \xrightarrow{d} \chi_q^2(\lambda), \quad (27.28)$$

其中非中心参数为相应有效信息二次型。

在简单原假设且无 nuisance 参数时,

$$\lambda = h^\top I_1(\theta_0)h. \quad (27.29)$$

这给出局部渐近功效: $P[\chi_q^2(\lambda) > \chi_{q,1-\alpha}^2]$ 。

27.14 Wilks 定理不能直接使用的情形

前提条件检查

以下任一情形出现时, 都必须重新分析:

- (1) 真值位于参数空间边界;
- (2) 样本支持集依赖参数;
- (3) Fisher 信息奇异;
- (4) 参数不可识别;
- (5) MLE 不存在或不唯一;
- (6) 原假设不是光滑流形;
- (7) 模型含混合分布、标签交换或维数变化;
- (8) 参数收敛速度不是 $\sqrt{n}$;
- (9) 对数似然在真值处不可二次微分。

前文的 $\text{Unif}(0, \theta)$ 与平移指数模型就是典型反例: $\hat{\theta} - \theta = O_p(n^{-1})$, 极限通常为指数型而非正态型, 不能使用普通 Fisher 信息和 Wilks 结论。

考试时需要注意的地方

“样本量大”不能修复错误的正则条件。

若模型本质上非正则, 即使 $n \rightarrow \infty$, 错误套用 $\sqrt{n}$ 正态 或 χ^2 仍会得到错误答案。

27.15 本章易错点

陈述	判断	正确说明
LRT 与 GLRT 是完全不同的方法	错	通常所称 LRT 即使用广义似然比；简单对简单时退化为简单似然比检验。
广义似然比大时拒绝	错	按 $\Lambda = \sup_{\Theta_0} L / \sup_{\Theta} L$ 定义，应在 Λ 小或 $-2\log \Lambda$ 大时拒绝。
Wilks 定理给出精确分布	错	一般只给出渐近分布；正态等特殊模型可化为精确枢轴量。
自由度等于参数向量分量数	错	自由度是非受限与受限模型维数之差。
有 nuisance 参数时只需固定目标参数	错	分子中仍须对所有 nuisance 参数最大化。
Wald、LR、score 在有限样本中完全相同	错	它们通常只是一阶渐近等价。
MLE 在边界时仍可直接用 Wilks	错	内部点和局部二次近似条件失效。
LRT 一定是 UMP	错	LRT 是通用构造；UMP 是全体 level 检验中的逐点最优性质。

一些需要记忆的内容

(1) 为什么广义似然比一定落在 $[0, 1]$?

(2) 受限 MLE 与非受限 MLE 的定义有何不同?

(3) 正态均值未知方差的 GLRT 为什么等价于双侧 t 检验?

(4) Wilks 定理的自由度如何计算?

(5) 为什么参数位于边界时不能直接使用普通 Wilks 定理?

(6) score 检验为什么只需计算受限 MLE?

(7) 有 nuisance 参数时，有效信息为何是 Schur 补?

(8) LR、Wald、score 渐近等价的共同核心展开是什么?

(9) 固定备择和 $n^{-1/2}$ 局部备择下的极限行为有何区别?



第二十八章 置信区间、置信域及其与检验的对偶

28.1 考纲定位与重要性

重点

重要性等级：S 级。

置信区间问题通常同时考查：枢轴量 + 分位数方向 + 不等式反演 + 覆盖概率解释 + 检验对偶。

必须熟练掌握：

- 覆盖概率与置信系数；
- 通过检验族反演置信集；
- 正态、卡方、 t 、 F 枢轴量；
- 参数单调变换下的区间；
- 精确区间、保守区间和渐近区间的区别；
- 似然比区间、Wald 区间和 score 区间；
- 频率学置信区间与 Bayes 可信区间的解释差异；
- 最短区间、UMA 和 HPD 的适用范围。

直接真题对应：[24F-Q7(c), 10 分题的一部分], [26S-Q11(c), 15 分题的一部分]。

28.2 区间估计量、覆盖概率与置信系数

定义 28.1 (区间估计量). 设 $\theta \in \mathbb{R}$. 若统计量 $L(X)$, $U(X)$ 满足 $L(x) \leq U(x)$ 对每个样本点 x , 则随机集合 $C(X) = [L(X), U(X)]$ 称为 θ 的区间估计量。

也允许单侧区间: $[L(X), \infty)$, $(-\infty, U(X)]$ 。

定义 28.2 (覆盖概率). 区间估计量 $C(X)$ 在参数值 θ 处的覆盖概率为

$$c_C(\theta) = P_\theta\{\theta \in C(X)\}. \quad (28.1)$$

定义 28.3 (置信系数). 置信系数定义为

$$\text{conf}(C) = \inf_{\theta \in \Theta} P_\theta\{\theta \in C(X)\}. \quad (28.2)$$

若

$$\inf_{\theta \in \Theta} P_\theta\{\theta \in C(X)\} \geq 1 - \alpha, \quad (28.3)$$

则称 $C(X)$ 为 $1 - \alpha$ 置信集。



若对所有 θ 都有 $P_\theta\{\theta \in C(X)\} = 1 - \alpha$, 则称其具有精确覆盖概率 $1 - \alpha$ 。

考试时需要注意的地方

在频率学框架中， θ 是固定常数， $C(X)$ 是随机集合。
在观测数据之前可写 $P_\theta\{\theta \in C(X)\} = 0.95$ 。观测后区间端点已经固定，不能再把同一频率学陈述解释为： $P(\theta \in C(x) \mid X = x) = 0.95$ 。
正确解释是：按照同一抽样和构造方法无限重复实验，至少 95% 的随机区间会覆盖真实参数。

28.3 检验与置信集的对偶定理

定理 28.4 (检验反演定理). 对每个 $\theta_0 \in \Theta$, 设 $A(\theta_0)$ 是检验 $H_0 : \theta = \theta_0$ 的 level α 接受域, 即 $P_{\theta_0}\{X \in A(\theta_0)\} \geq 1 - \alpha$ 。定义

$$C(x) = \{\theta_0 : x \in A(\theta_0)\}.$$

(28.4)

则 $C(X)$ 是 $1 - \alpha$ 置信集。

反之，若 $C(X)$ 是 $1 - \alpha$ 置信集，定义

$$A(\theta_0) = \{x : \theta_0 \in C(x)\},$$

(28.5)

则 $A(\theta_0)$ 是检验 $H_0 : \theta = \theta_0$ 的 level α 接受域。

证明. 由定义中的逻辑等价，

$$\theta_0 \in C(x) \iff x \in A(\theta_0).$$

(28.6)

因此在参数真值为 θ 时，

$$\begin{aligned} P_\theta\{\theta \in C(X)\} &= P_\theta\{X \in A(\theta)\} \\ &\geq 1 - \alpha. \end{aligned}$$

故 $C(X)$ 是 $1 - \alpha$ 置信集。

反过来，若 $C(X)$ 为 $1 - \alpha$ 置信集，则

$$\begin{aligned} P_{\theta_0}\{X \notin A(\theta_0)\} &= P_{\theta_0}\{\theta_0 \notin C(X)\} \\ &\leq \alpha. \end{aligned}$$

故相应检验为 level α 。

概念比较

	方法	固定对象	寻找对象
检验与区间固定的对象不同：	假设检验	候选参数 θ_0	哪些样本与 θ_0 相容
	置信区间	已观测样本 x	哪些参数值与 x 相容

注 28.5. 反演的是一整族检验： $\{H_0 : \theta = \theta_0 : \theta_0 \in \Theta\}$, 而不是只反演某一个固定 θ_0 的检验。

28.4 枢轴量法

定义 28.6 (枢轴量). 若 $Q(X, \theta)$ 同时依赖样本和参数, 但其分布不依赖任何未知参数, 则称其为枢轴量 (pivotal quantity)。

若存在常数 a, b 使 $P_\theta\{a \leq Q(X, \theta) \leq b\} = 1 - \alpha$ 对所有 θ 成立, 则可对不等式 $a \leq Q(x, \theta) \leq b$ 关于 θ 求解, 得到置信集。

枢轴量构造流程

- (1) 找到统计量的精确分布;
- (2) 消去未知参数, 构造分布参数自由的 $Q(X, \theta)$;
- (3) 选分位点 a, b , 写出概率等式;
- (4) 严格反演不等式;
- (5) 若乘除负数, 必须改变不等号方向;
- (6) 最后按从小到大的顺序整理端点;
- (7) 验证参数范围, 如 $\sigma^2 > 0$ 、 $p \in [0, 1]$ 。

28.5 正态总体的精确置信区间

28.5.1 均值, 方差已知

若 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, σ^2 已知, 则 $Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$ 。所以 $P(-z_{1-\alpha/2} \leq Z \leq z_{1-\alpha/2}) = 1 - \alpha$ 。反演得

$$\mu \in \left[\bar{X} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right]. \quad (28.7)$$

28.5.2 均值, 方差未知

若 σ^2 未知, $T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}$ 。故

$$\mu \in \left[\bar{X} - t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}} \right]. \quad (28.8)$$

28.5.3 方差

有 $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ 。因此 $P\left(\chi_{n-1, \alpha/2}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{n-1, 1-\alpha/2}^2\right) = 1 - \alpha$ 。反演时注意 σ^2 位于分母, 得到

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi_{n-1, 1-\alpha/2}^2}, \quad \frac{(n-1)S^2}{\chi_{n-1, \alpha/2}^2} \right]. \quad (28.9)$$



考试时需要注意的地方

方差区间最常见错误是把两个卡方分位数放反。

因为 $\sigma^2 = \frac{(n-1)S^2}{Q}$, Q 越大, σ^2 越小。因此下端点除以较大的卡方分位数。

28.6 指数分布参数的精确区间

采用率参数化 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$, $f(x | \lambda) = \lambda e^{-\lambda x}$, $x > 0$ 。记 $T = \sum_{i=1}^n X_i$ 。则 $T \sim \Gamma_{\text{rate}}(n, \lambda)$, $2\lambda T \sim \chi_{2n}^2$ 。所以

$$\lambda \in \left[\frac{\chi_{2n, \alpha/2}^2}{2T}, \frac{\chi_{2n, 1-\alpha/2}^2}{2T} \right]. \quad (28.10)$$

若使用尺度参数 $\beta = \frac{1}{\lambda}$, 由单调变换得到

$$\beta \in \left[\frac{2T}{\chi_{2n, 1-\alpha/2}^2}, \frac{2T}{\chi_{2n, \alpha/2}^2} \right]. \quad (28.11)$$

28.7 两个正态方差之比

设两独立样本满足 $X_1, \dots, X_{n_1} \stackrel{\text{i.i.d.}}{\sim} N(\mu_1, \sigma_1^2)$, $Y_1, \dots, Y_{n_2} \stackrel{\text{i.i.d.}}{\sim} N(\mu_2, \sigma_2^2)$ 。则 $\frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}$ 。等价地, $\frac{S_X^2/S_Y^2}{\sigma_1^2/\sigma_2^2} \sim F_{\nu_1, \nu_2}$ 。故

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[\frac{S_X^2/S_Y^2}{F_{\nu_1, \nu_2, 1-\alpha/2}}, \frac{S_X^2/S_Y^2}{F_{\nu_1, \nu_2, \alpha/2}} \right]. \quad (28.12)$$

28.8 常见精确置信区间速查

目标参数	枢轴量	$1 - \alpha$ 置信区间
正态 μ , σ 已知	$\frac{\sqrt{n}(\bar{X}-\mu)}{\sigma} \sim N(0, 1)$	$\bar{X} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$
正态 μ , σ 未知	$\frac{\sqrt{n}(\bar{X}-\mu)}{S} \sim t_{n-1}$	$\bar{X} \pm t_{n-1, 1-\alpha/2} \frac{S}{\sqrt{n}}$
正态 σ^2	$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$	$\left[\frac{(n-1)S^2}{\chi_{n-1, 1-\alpha/2}^2}, \frac{(n-1)S^2}{\chi_{n-1, \alpha/2}^2} \right]$
指数率 λ	$2\lambda \sum X_i \sim \chi_{2n}^2$	$\left[\frac{\chi_{2n, \alpha/2}^2}{2\sum X_i}, \frac{\chi_{2n, 1-\alpha/2}^2}{2\sum X_i} \right]$
方差比	$\frac{S_X^2/S_Y^2}{\sigma_X^2/\sigma_Y^2} \sim F_{\nu_1, \nu_2}$	见 equation (28.12)

28.9 历年真题：只观察符号后的置信区间

往年真题

[24F-Q7(c), 10 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$, 但只观察 $Y_i = \mathbf{1}_{\{X_i < 0\}}$ 。基于 $Y_1, \dots, Y_n$ 构造 μ 的 $1 - \alpha$ 置信区间。

解：令 $S = \sum_{i=1}^n Y_i$, $q = P_\mu(X_i < 0) = \Phi(-\mu)$ 。则 $S \sim \text{Bin}(n, q)$ 。

先对 q 构造精确 Clopper–Pearson 区间。观测 $S = s$ 后定义

$$q_L = \begin{cases} 0, & s = 0, \\ B_{\alpha/2}^{-1}(s, n - s + 1), & s > 0, \end{cases} \quad (28.13)$$

$$q_U = \begin{cases} 1, & s = n, \\ B_{1-\alpha/2}^{-1}(s + 1, n - s), & s < n, \end{cases} \quad (28.14)$$

其中 $B_u^{-1}(a, b)$ 表示 $\text{Beta}(a, b)$ 分布的下尾 u 分位数。

该区间满足 $P_q(q_L(S) \leq q \leq q_U(S)) \geq 1 - \alpha$ 。

又因为 $q = \Phi(-\mu)$ 关于 μ 严格递减, $\mu = -\Phi^{-1}(q)$ 。故端点方向反转:

$$\mu \in [-\Phi^{-1}(q_U), -\Phi^{-1}(q_L)]. \quad (28.15)$$

边界情形: $q_L = 0 \implies -\Phi^{-1}(q_L) = +\infty$, $q_U = 1 \implies -\Phi^{-1}(q_U) = -\infty$ 。因此当所有符号相同, 精确区间可以是单侧无界的。□

注 28.7. 也可通过反演上一章构造的二项 UMP 单侧检验, 分别得到上下置信界, 再取交集。

这种方法直接体现: 检验的备择方向 $\iff$ 置信界方向。

28.10 CDF 反演法

设统计量 T 的连续分布函数为 $F_T(t | \theta)$ 。概率积分变换给出 $F_T(T | \theta) \sim \text{Unif}(0, 1)$ 。若 $F_T(t | \theta)$ 对每个固定 t 关于 θ 单调, 则可求解 $\alpha_1 \leq F_T(t | \theta) \leq 1 - \alpha_2$, $\alpha_1 + \alpha_2 = \alpha$, 得到区间。

定理 28.8 (连续 CDF 反演). 若 $F_T(t | \theta)$ 关于 θ 严格递减, 定义 $F_T(t | \theta_U(t)) = \alpha_1$, $F_T(t | \theta_L(t)) = 1 - \alpha_2$ 。则 $[\theta_L(T), \theta_U(T)]$ 是 $1 - \alpha$ 置信区间。

若 $F_T(t | \theta)$ 关于 θ 严格增加, 则两个分位方程方向相反。

前提条件检查

离散型 T 中 $F_T(T | \theta)$ 一般不服从精确 $\text{Unif}(0, 1)$ 。直接反演通常得到覆盖概率至少为 $1 - \alpha$ 的保守区间, 或需随机化才能得到精确覆盖。

28.11 渐近 Wald 置信区间

若 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, V(\theta))$, 且 $\hat{V} \xrightarrow{\mathbb{P}} V(\theta)$, 则 $\frac{\sqrt{n}(\hat{\theta} - \theta)}{\sqrt{\hat{V}}} \xrightarrow{d} N(0, 1)$ 。因此 Wald 区间为

$$\hat{\theta} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{V}}{n}}.$$

(28.16)

考试时需要注意的地方

Wald 区间可能：

- 超出参数空间；
- 在边界附近覆盖率差；
- 对非线性重参数化敏感；
- 在标准误接近零时严重失真。

例如对 $p \in [0, 1]$, 区间 $\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ 可能超出 $[0, 1]$, 且当 $\hat{p} \in \{0, 1\}$ 时退化。

28.12 似然比置信区域

由 Wilks 定理，若参数维数为 p ，则近似置信区域可定义为

$$C_{\text{LR}}(x) = \left\{ \theta : 2[\ell_n(\hat{\theta}) - \ell_n(\theta)] \leq \chi_{p,1-\alpha}^2 \right\}.$$

(28.17)

若只关心标量参数 ψ ，而 λ 为 nuisance 参数，定义 profile log-likelihood

$$\ell_{p,n}(\psi) = \sup_{\lambda} \ell_n(\psi, \lambda).$$

(28.18)

则 profile LR 区间为

$$\left\{ \psi : 2[\ell_n(\hat{\psi}, \hat{\lambda}) - \ell_{p,n}(\psi)] \leq \chi_{1,1-\alpha}^2 \right\}.$$

(28.19)

概念比较		
区间	主要依据	特点
Wald	估计量渐近正态	计算简单，但重参数化敏感
Score	原假设处 score	通过反演 score 检验得到
LR	profile likelihood 差	——重参数化不变，常较稳定
精确枢轴区间	有限样本参数自由分布	有枢轴时优先使用

28.13 参数变换下的置信区间

若 $C_\theta(X) = [L(X), U(X)]$ 是 θ 的 $1 - \alpha$ 置信区间, 且 $\eta = g(\theta)$ 严格单调, 则:

若 g 严格增加,

$$C_\eta(X) = [g(L(X)), g(U(X))]. \quad (28.20)$$

若 g 严格减少,

$$C_\eta(X) = [g(U(X)), g(L(X))]. \quad (28.21)$$

覆盖概率保持不变, 因为 $\theta \in [L, U] \iff g(\theta) \in g([L, U])$ 。

考试时需要注意的地方

置信区间具有单调变换等变性, 但普通 Wald 区间不具有精确等变性。

即: $g(\hat{\theta} \pm z \hat{se})$ 一般不等于直接对 $g(\theta)$ 使用 Delta 方法得到的 Wald 区间。

28.14 最短区间与等密度端点

定理 28.9 (单峰密度下的最短概率区间). 设 f 为单峰密度, 众数为 x^* 。若区间 $[a, b]$ 满足:

- (1) $\int_a^b f(x) dx = 1 - \alpha$;
- (2) $f(a) = f(b) > 0$;
- (3) $a \leq x^* \leq b$;

则 $[a, b]$ 是所有概率质量为 $1 - \alpha$ 的区间中长度最短者。

对称单峰分布中, 等密度端点等价于等尾概率; 对偏斜分布则通常不等价。

考试时需要注意的地方

“每侧放 $\alpha/2$ ”不一定产生最短区间。

它对正态、 t 等对称单峰分布成立; 对卡方、Gamma 等偏斜分布, 最短区间通常满足 $f(a) = f(b)$ 而非等尾。

28.15 UMA 置信界

一侧 UMP 检验反演后可得到一致最准确 (uniformly most accurate, UMA) 置信界。

例如对每个 θ_0 , 若检验 $H_0: \theta = \theta_0$ 对 $H_1: \theta > \theta_0$ 存在 UMP level α 检验, 则反演其接受域得到下置信界 $[L(X), \infty)$ 。

该置信界在保持真实覆盖概率至少为 $1 - \alpha$ 的条件下, 对任意假值 $\theta' < \theta$ 最小化错误覆盖概率 $P_{\theta'}\{\theta' \in C(X)\}$ 。

注 28.10. 双侧问题中若 UMP 检验不存在, 通常不能得到无条件 UMA 双侧区间。

此时可限制在无偏检验类中寻找 UMPU, 反演后得到相应的 UMAU 置信区间。

28.16 频率学置信区间与 Bayes 可信区间

定义 28.11 (Bayes 可信集). 给定观测 $X = x$, 若集合 $A(x) \subseteq \Theta$ 满足

$$P\{\theta \in A(x) \mid X = x\} = \int_{A(x)} \pi(\theta \mid x) \, d\theta = 1 - \alpha, \tag{28.22}$$

则称其为 $1 - \alpha$ Bayes 可信集。

概念比较		
	频率学置信区间	Bayes 可信区间
参数	固定未知	具有后验分布
概率陈述	对随机区间重复抽样	给定已观测数据后的参数概率
保证	覆盖概率 $P_\theta(\theta \in C(X))$	后验概率 $P(\theta \in A \mid x)$
依赖先验	否	是

28.17 最高后验密度区域

定义 28.12 (HPD 区域). 最高后验密度 (highest posterior density, HPD) 区域定义为

$$C_{\text{HPD}}(x) = \{\theta : \pi(\theta \mid x) \geq k_x\}, \tag{28.23}$$

其中 k_x 选择为使 $\int_{C_{\text{HPD}}(x)} \pi(\theta \mid x) \, d\theta = 1 - \alpha$ 。


若后验密度单峰, 则 HPD 区间是给定后验概率下长度最短的区间, 且内部任一点的后验密度不低于外部任一点。

考试时需要注意的地方

HPD 区域一般不具有非线性重参数化不变性, 因为密度会乘以 Jacobian。
同一个后验分布在 θ 参数化下的 HPD 集, 映射到 $\eta = g(\theta)$ 后未必是 η 参数化下的 HPD 集。

28.18 置信区间易错点

陈述	判断	正确说明
已观测的 95% 置信区间以 0.95 概率含真值	频率学解释下不严谨	0.95 是构造程序的长期覆盖率; 观测后区间已固定。
覆盖概率一定不依赖参数	错	只有枢轴量等特殊构造才常产生常数覆盖率。



陈述	判断	正确说明
置信系数等于某一参数点的覆盖率	错	置信系数是整个参数空间覆盖概率的下确界。
两侧各放 $\alpha/2$ 总是最短	错	偏斜分布的最短区间通常由等密度端点确定。
反演一个检验即可得到完整置信区间	不准确	应反演对所有候选参数值构成的一族检验。
精确区间一定恰有覆盖率 $1 - \alpha$	错	离散模型中的非随机化精确区间通常保守，覆盖率至少为 $1 - \alpha$ 。
可信区间和置信区间只是名称不同	错	两者的概率对象与解释不同。
Wald 区间总在参数空间内	错	Bernoulli、方差和率参数中均可能越界。

一些需要记忆的内容

(1) 覆盖概率和置信系数有何区别?

(2) 为什么频率学概率是关于 $C(X)$ 而不是关于固定 θ ?

(3) 检验接受域与置信集之间的逻辑等价是什么?

(4) 正态方差区间的两个卡方分位数为什么反向出现?

(5) 指数率参数和尺度参数的区间如何换算?

(6) 离散模型的精确区间为什么常保守?

(7) Wald 区间和 LR 区间在参数化不变性上有何区别?

(8) 等尾区间与最短区间何时相同?

(9) HPD 区域与频率学 UMA 区间分别优化什么?



第二十九章 Bayes 统计与统计决策理论

29.1 考纲定位与历年实考扩展说明

重点

重要性等级：S/A 级。

先验、后验、共轭先验和常见损失下的 Bayes 估计属于明确考纲核心。

统计决策、Bayes risk、minimax 与 admissibility 在简要考纲中未全部单独列出，但多套真题实际考查：

[24S-Q7, 15 分],

[24F-Q10(c), 15 分题的一部分],

[25S-Q7, 10 分],

[25S-Q10(b), 10 分题的一部分],

[25F-Q9(b), 15 分题的一部分],

[25F-Q10, 10 分],

[26S-Q9, 10 分].

该主题未在简要考纲中全部单独列出，但曾在历年真题中实际考查。

29.2 统计决策问题的组成

一个统计决策问题由以下对象组成： $(\mathcal{X}, \Theta, \mathcal{A}, \{P_\theta\}, L)$.

定义 29.1 (动作空间). 动作空间 $\mathcal{A}$ 是统计者可以采取的全部行动的集合。

估计问题中常取 $\mathcal{A} = \Theta$ 或 $\mathcal{A} = \mathbb{R}^d$ 。检验问题中常取 $\mathcal{A} = \{0, 1\}$ 。

定义 29.2 (损失函数). 损失函数是映射

$$L : \Theta \times \mathcal{A} \rightarrow [0, \infty], \quad (29.1)$$


其中 $L(\theta, a)$ 表示真实参数为 θ 而采取动作 a 时的损失。

定义 29.3 (决策规则). 非随机化决策规则是可测映射 $\delta : \mathcal{X} \rightarrow \mathcal{A}$ 。观测到 $X = x$ 后采取动作 $\delta(x)$ 。

定义 29.4 (风险函数). 决策规则 δ 的风险函数为

$$R(\theta, \delta) = \mathbb{E}_\theta L(\theta, \delta(X)). \quad (29.2)$$

风险是参数 θ 的函数，而不是单个数。



29.3 常见损失函数

损失	表达式	典型含义
平方损失	$L(\theta, a) = (a - \theta)^2$	大误差受到二次惩罚
绝对损失	$L(\theta, a) = a - \theta $	对离群误差较平方损失稳健
加权平方损失	$L(\theta, a) = w(\theta)(a - \theta)^2$	不同参数值赋予不同重要性
相对平方损失	$L(\theta, a) = \left(\frac{a}{\theta} - 1\right)^2$	适合正尺度参数
0-1 损失	$L(\theta, a) = \mathbf{1}_{\{a \neq \theta\}}$	分类或离散参数判断
不对称绝对损失	$\rho_\tau(\theta - a)$	高估和低估代价不同

29.4 先验、似然与后验

设参数具有先验密度或质量函数 $\pi(\theta)$ 。给定 θ 时，样本密度为 $f(x \mid \theta)$ 。

边际密度为

$$m(x) = \int_{\Theta} f(x \mid \theta)\pi(\theta) \, \mathrm{d}\theta$$

(29.3)

或离散情形下的相应求和。

若 $0 < m(x) < \infty$, 则 Bayes 公式给出

$$\pi(\theta \mid x) = \frac{f(x \mid \theta)\pi(\theta)}{m(x)}.$$

(29.4)

常用比例记号：

$$\pi(\theta \mid x) \propto L(\theta \mid x)\pi(\theta).$$

(29.5)

后验推导常见步骤

(1) 写出先验及其参数范围；

(2) 写出完整似然，包括支持集；

(3) 相乘得到未归一化后验核；

(4) 识别分布族或计算归一化常数；

(5) 写出后验参数；

(6) 检查后验是否为 proper distribution；

(7) 若要求 Bayes 估计，再根据损失函数选择后验泛函；

(8) 不得把 posterior mode、posterior mean 和 MLE 混为一谈。

29.5 后验风险与 Bayes 规则

定义 29.5 (后验风险). 观测到 $X = x$ 后, 采取动作 a 的后验风险为

$$\rho(a | x) = \mathbb{E}[L(\theta, a) | X = x] = \int L(\theta, a) \pi(\theta | x) d\theta. \quad (29.6)$$

定理 29.6 (逐点最小化后验风险). 若存在可测函数 δ^* 使

$$\rho(\delta^*(x) | x) = \inf_{a \in \mathcal{A}} \rho(a | x) \quad (29.7)$$

对边际分布几乎所有 x 成立, 则 δ^* 是 Bayes 规则。

证明. Bayes risk 为

$$\begin{aligned} r(\pi, \delta) &= \int_{\Theta} R(\theta, \delta) \pi(\theta) d\theta \\ &= \mathbb{E}L(\theta, \delta(X)) \\ &= \mathbb{E}[\mathbb{E}\{L(\theta, \delta(X)) | X\}] \\ &= \mathbb{E}[\rho(\delta(X) | X)]. \end{aligned}$$

由于对几乎每个 x , $\rho(\delta^*(x) | x) \leq \rho(\delta(x) | x)$, 取期望即得 $r(\pi, \delta^*) \leq r(\pi, \delta)$. □

29.6 不同损失函数下的 Bayes 估计

29.6.1 平方损失：后验均值

定理 29.7 (平方损失下的 Bayes 估计). 若 $\mathbb{E}(\theta^2 | X = x) < \infty$, 则在平方损失 $L(\theta, a) = (a - \theta)^2$ 下, 唯一 Bayes 动作为

$$\boxed{a^*(x) = \mathbb{E}(\theta | X = x).} \quad (29.8)$$

证明. 令 $m(x) = \mathbb{E}(\theta | x)$. 则

$$\begin{aligned} \mathbb{E}[(\theta - a)^2 | x] &= \mathbb{E}[(\theta - m + m - a)^2 | x] \\ &= \text{Var}(\theta | x) + (a - m)^2. \end{aligned}$$

第一项不依赖 a , 第二项在 $a = m$ 时唯一最小。 □

29.6.2 绝对损失：后验中位数

定理 29.8 (绝对损失下的 Bayes 估计). 在损失 $L(\theta, a) = |\theta - a|$ 下, 任意后验中位数均为 Bayes 动作。

即任意满足

$$P(\theta \leq a | x) \geq \frac{1}{2}, \quad P(\theta \geq a | x) \geq \frac{1}{2} \quad (29.9)$$

的 a 都是 Bayes 动作。



证明思路

后验风险为 $\rho(a | x) = \int_{-\infty}^a (a - \theta)\pi(\theta | x) d\theta + \int_a^{\infty} (\theta - a)\pi(\theta | x) d\theta$ 。在连续后验下求导： $\frac{\partial}{\partial a}\rho(a | x) = P(\theta \leq a | x) - P(\theta > a | x) = 2F_{\theta|x}(a) - 1$ 。风险在后验 CDF 穿过 1/2 的位置达到最小。有原子时使用左右次梯度即可得到 equation (29.9)。

29.6.3 不对称绝对损失：后验分位数

定义 check loss $\rho_{\tau}(u) = u(\tau - \mathbf{1}_{\{u < 0\}})$, $0 < \tau < 1$ 。在损失 $L(\theta, a) = \rho_{\tau}(\theta - a)$ 下, Bayes 动作为后验 τ 分位数:

$$a^{\star} = F_{\theta|x}^{-1}(\tau). \quad (29.10)$$

29.6.4 离散 0-1 损失：后验众数

若参数空间离散, 并使用 $L(\theta, a) = \mathbf{1}_{\{\theta \neq a\}}$, 则 $\rho(a | x) = 1 - P(\theta = a | x)$ 。故 Bayes 动作为

$$a^{\star} \in \arg \max_a P(\theta = a | x). \quad (29.11)$$

考试时需要注意的地方

连续参数下, 普通点质量 0-1 损失满足 $P(\theta = a | x) = 0$ 对所有单点 a 成立, 因此不能用该损失严格推出 MAP。

连续参数的 MAP 更适理解解为:

- 后验密度的众数;
- 小邻域 0-1 损失极限;
- 或某种特定参考测度下的密度最大点。

MAP 依赖参数化及 Jacobian。

29.7 常见共轭先验表

本节统一采用 Gamma 的形状-率参数化:

$$\lambda \sim \Gamma_{\text{rate}}(a, b) \iff \pi(\lambda) = \frac{b^a}{\Gamma(a)} \lambda^{a-1} e^{-b\lambda}. \quad (29.12)$$

其均值和方差为 $\mathbb{E}\lambda = \frac{a}{b}$, $\text{Var}(\lambda) = \frac{a}{b^2}$ 。

若采用尺度参数 $\beta = 1/b$, 需将所有后验率参数取倒数后再换算。



抽样模型	先验	后验	平方损失 Bayes 估计
Bernoulli/Binomial	$p \sim \text{Beta}(a, b)$	$p \mid x \sim \text{Beta}(a + S, b + n - S)$	$\frac{a+S}{a+b+n}$
Poisson	$\lambda \sim \Gamma_{\text{rate}}(a, b)$	$\lambda \mid x \sim \Gamma_{\text{rate}}(a + S, b + n)$	$\frac{a+S}{b+n}$
指数率 $f(x \lambda) = \lambda e^{-\lambda x}$	$\lambda \sim \Gamma_{\text{rate}}(a, b)$	$\lambda \mid x \sim \Gamma_{\text{rate}}(a + n, b + \sum x_i)$	$\frac{a+n}{b+\sum x_i}$
正态均值, σ^2 已知	$\mu \sim N(m_0, \tau_0^2)$	$\mu \mid x \sim N(m_n, v_n)$	$m_n = v_n \left(\frac{m_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2} \right)$
正态精度 $\kappa = 1/\sigma^2$, μ 已知	$\kappa \sim \Gamma_{\text{rate}}(a, b)$	$\kappa \mid x \sim \Gamma_{\text{rate}}\left(a + \frac{n}{2}, b + \frac{1}{2} \sum (x_i - \mu)^2\right)$	$\frac{a+n/2}{b+\frac{1}{2} \sum (x_i - \mu)^2}$

正态均值后验中的

$$v_n = \left(\frac{1}{\tau_0^2} + \frac{n}{\sigma^2} \right)^{-1}$$

(29.13)

且

$$m_n = \frac{n/\sigma^2}{n/\sigma^2 + 1/\tau_0^2} \bar{X} + \frac{1/\tau_0^2}{n/\sigma^2 + 1/\tau_0^2} m_0.$$

(29.14)

这体现后验均值是样本均值与先验均值的精度加权平均。

29.8 广义 Bayes 规则与不当先验

定义 29.9 (不当先验). 若非负函数 π 满足 $\int_{\Theta} \pi(\theta) \, d\theta = \infty$, 则称其为不当先验。

不当先验不是概率分布, 但若 $0 < \int_{\Theta} L(\theta \mid x) \pi(\theta) \, d\theta < \infty$, 仍可归一化得到 proper posterior。
由该形式后验最小化后验风险所得规则称为广义 Bayes 规则。

前提条件检查

使用不当先验时必须依次检查：

(1) 后验是否 proper；

(2) 所需后验矩是否存在；

(3) 后验期望损失是否有限；

(4) 广义 Bayes 规则是否真正定义；

(5) 广义 Bayes 不自动推出可容许或 minimax。

29.9 历年真题: Uniform 模型的不当平坦先验

往年真题

[25S-Q7, 10 分]

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$, 在平方损失下使用不当先验 $\pi(\theta) = 1$ 。求广义 Bayes 规则并判断相合性。

解: 记 $M = X_{(n)}$ 。似然为 $L(\theta | x) = \theta^{-n} \mathbf{1}_{\{\theta \geq M\}}$ 。因此形式后验核为 $\pi(\theta | x) \propto \theta^{-n} \mathbf{1}_{\{\theta \geq M\}}$ 。

当 $n > 1$ 时, $\int_M^\infty \theta^{-n} d\theta = \frac{M^{1-n}}{n-1} < \infty$ 。故后验为 Pareto 型分布:

$$\pi(\theta | x) = (n-1)M^{n-1}\theta^{-n}\mathbf{1}_{\{\theta \geq M\}}. \quad (29.15)$$

当 $n > 2$ 时, 后验均值存在:

$$\begin{aligned} \mathbb{E}(\theta | x) &= (n-1)M^{n-1} \int_M^\infty \theta^{1-n} d\theta \\ &= \frac{n-1}{n-2} M. \end{aligned}$$

因此形式广义 Bayes 估计为

$$\delta_n(x) = \frac{n-1}{n-2} X_{(n)}, \quad n > 2. \quad (29.16)$$

需要严格区分矩条件: $\mathbb{E}(\theta^2 | x) < \infty \iff n > 3$ 。事实上, 当 $n > 3$, $\mathbb{E}(\theta^2 | x) = \frac{n-1}{n-3} M^2$ 。故:

- $n = 2$: 后验 proper, 但后验均值发散;
- $n = 3$: 后验均值有限, 但平方后验风险对每个有限动作均为无穷;
- $n \geq 4$: 后验二阶矩有限, 后验均值是严格意义下平方损失 Bayes 动作。

若按常见“形式广义 Bayes”约定, 只要求一阶矩, 则 equation (29.16) 适用于 $n > 2$ 。

下面证明相合性。对任意 $0 < \varepsilon < \theta$, $P_\theta(M \leq \theta - \varepsilon) = (1 - \frac{\varepsilon}{\theta})^n \rightarrow 0$ 。又因 $M \leq \theta$ 几乎必然, 所以 $M \xrightarrow{\mathbb{P}} \theta$ 且事实上 $M \xrightarrow{\text{a.s.}} \theta$ 。同时 $\frac{n-1}{n-2} \rightarrow 1$ 。由 Slutsky 定理,

$$\delta_n = \frac{n-1}{n-2} M \xrightarrow{\mathbb{P}} \theta. \quad (29.17)$$

事实上也有强相合。

□

考试时需要注意的地方

该题容易遗漏的条件:

- (1) 后验 proper 只需 $n > 1$;
- (2) 后验均值存在需要 $n > 2$;
- (3) 有限平方后验风险需要 $n > 3$;
- (4) 相合性中估计量本身随 n 改变, 比例因子趋于 1。

29.10 历年真题: Uniform 模型与 Lognormal 先验

往年真题

[25F-Q10, 10 分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, \theta)$, $\theta > 0$, 且 $\eta = \log \theta \sim N(\mu_0, \sigma_0^2)$ 。

- (1) 求 $\eta | X$ 的后验密度;
- (2) 求最大化 θ 后验密度的 Bayes 估计, 并判断相合性。

解: 令 $M = X_{(n)}$ 。在参数 $\eta = \log \theta$ 下, $\theta = e^\eta$, 似然为 $L(\eta | x) = e^{-n\eta} \mathbf{1}_{\{\eta \geq \log M\}}$ 。先验密度为 $\pi(\eta) = \frac{1}{\sqrt{2\pi}\sigma_0} \exp\left\{-\frac{(\eta-\mu_0)^2}{2\sigma_0^2}\right\}$ 。故 $\pi(\eta | x) \propto \exp\left\{-\frac{(\eta-\mu_0)^2}{2\sigma_0^2} - n\eta\right\} \mathbf{1}_{\{\eta \geq \log M\}}$ 。完成平方: $-\frac{(\eta-\mu_0)^2}{2\sigma_0^2} - n\eta = -\frac{[\eta - (\mu_0 - n\sigma_0^2)]^2}{2\sigma_0^2} + C_n$ 。令 $m_n = \mu_0 - n\sigma_0^2$ 。则

$$\eta | x \sim N(m_n, \sigma_0^2) \text{ 在 } [\log M, \infty) \text{ 上左截断。} \quad (29.18)$$

其归一化密度为

$$\pi(\eta | x) = \frac{\phi\left(\frac{\eta - m_n}{\sigma_0}\right)}{\sigma_0 \left[1 - \Phi\left(\frac{\log M - m_n}{\sigma_0}\right)\right]} \mathbf{1}_{\{\eta \geq \log M\}}. \quad (29.19)$$

第二问要求最大化的是 θ 的后验密度, 而非 η 的后验密度。先验在 θ 参数化下为 $\pi_\theta(\theta) = \frac{1}{\theta\sigma_0\sqrt{2\pi}} \exp\left\{-\frac{(\log \theta - \mu_0)^2}{2\sigma_0^2}\right\}$ 。因此 $\pi_\theta(\theta | x) \propto \theta^{-(n+1)} \exp\left\{-\frac{(\log \theta - \mu_0)^2}{2\sigma_0^2}\right\} \mathbf{1}_{\{\theta \geq M\}}$ 。令 $\eta = \log \theta$, 对数后验核为 $-(n+1)\eta - \frac{(\eta - \mu_0)^2}{2\sigma_0^2}$, $\eta \geq \log M$ 。无约束最大点为 $\eta^* = \mu_0 - (n+1)\sigma_0^2$ 。考虑下界约束后, $\hat{\eta}_{\text{MAP}, \theta} = \max\{\log M, \mu_0 - (n+1)\sigma_0^2\}$ 。故

$$\hat{\theta}_{\text{MAP}} = \max\{M, \exp[\mu_0 - (n+1)\sigma_0^2]\}. \quad (29.20)$$

因为 $M \xrightarrow{\text{a.s.}} \theta$ 且 $\exp[\mu_0 - (n+1)\sigma_0^2] \rightarrow 0$, 而真值 $\theta > 0$, 故

$$\hat{\theta}_{\text{MAP}} \xrightarrow{\text{a.s.}} \theta. \quad (29.21)$$

□

考试时需要注意的地方

后验众数不具有普通重参数化不变性。

最大化 $\eta = \log \theta$ 的后验密度得到的点为 $\max\{\log M, \mu_0 - n\sigma_0^2\}$, 而最大化 θ 的后验密度得到 $\max\{\log M, \mu_0 - (n+1)\sigma_0^2\}$ 。差异来自 Jacobian $\left|\frac{d\eta}{d\theta}\right| = \frac{1}{\theta}$ 。

29.11 Bayes risk

定义 29.10 (Bayes risk). 给定 proper prior π , 决策规则 δ 的 Bayes risk 为

$$r(\pi, \delta) = \int_{\Theta} R(\theta, \delta) \pi(\theta) d\theta. \quad (29.22)$$

由 Fubini 与 Tower property, $r(\pi, \delta) = \mathbb{E}L(\theta, \delta(X)) = \mathbb{E}[\rho(\delta(X) | X)]$ 。

定义 29.11 (Bayes 规则). 若

$$r(\pi, \delta^\pi) = \inf_{\delta} r(\pi, \delta), \quad (29.23)$$

则称 δ^π 为先验 π 下的 Bayes 规则。

29.12 风险支配与可容许性

定义 29.12 (支配). 若决策规则 δ_1 满足 $R(\theta, \delta_1) \leq R(\theta, \delta_0) \forall \theta \in \Theta$, 且至少对一个 θ 严格不等, 则称 δ_1 支配 δ_0 。

定义 29.13 (可容许与不可容许). 若不存在任何决策规则支配 δ , 则称 δ 可容许 (admissible)。

否则称 δ 不可容许 (inadmissible)。

考试时需要注意的地方

可容许不表示“风险最小”。

它只表示不存在一个规则在所有参数点都不差、且至少一点更好。

两个可容许规则的风险函数通常会交叉。

29.13 proper Bayes 规则与可容许性

定理 29.14 (唯一 proper Bayes 规则的可容许性准则). 设 π 为 *proper prior*, δ^π 是唯一 Bayes 规则。若任意严格风险改进都发生在一个具有正先验概率的参数集合上, 则 δ^π 可容许。

证明. 若 δ_1 支配 δ^π , 则 $R(\theta, \delta_1) \leq R(\theta, \delta^\pi)$ 对所有 θ 成立, 并在某个正先验概率集合上严格小于。积分得到 $r(\pi, \delta_1) < r(\pi, \delta^\pi)$, 与 δ^π 为 Bayes 规则矛盾。□

注 29.15. 若只知道在单个参数点严格改进, 而先验对单点概率为零, 还需风险连续性与先验满支撑等条件, 才能推出在该点邻域内也有严格改进。

因此“任意 proper Bayes 规则都可容许”需要适当唯一性和正则性条件。

29.14 minimax 规则

定义 29.16 (最大风险). 决策规则 δ 的最大风险为

$$\bar{R}(\delta) = \sup_{\theta \in \Theta} R(\theta, \delta). \quad (29.24)$$

定义 29.17 (minimax 规则). 若

$$\sup_{\theta} R(\theta, \delta^*) = \inf_{\delta} \sup_{\theta} R(\theta, \delta), \quad (29.25)$$

则称 δ^* 为 minimax 规则。

minimax 规则优化最坏参数情况下的风险。



29.15 常风险 Bayes 规则的 minimax 定理

定理 29.18 (常风险 Bayes 准则). 若 δ^* 是先验 π 下的 Bayes 规则, 且

$$R(\theta, \delta^*) = c \text{ 对 } \pi \text{ 支撑上的所有 } \theta, \quad (29.26)$$

并且 $\sup_{\theta \in \Theta} R(\theta, \delta^*) = c$, 则 δ^* 为 minimax, π 为最不利先验。

证明. 任取规则 δ , $\sup_{\theta} R(\theta, \delta) \geq \int R(\theta, \delta) \pi(\theta) d\theta = r(\pi, \delta)$ 。又因 δ^* 为 Bayes, $r(\pi, \delta) \geq r(\pi, \delta^*) = c$ 。所以 $\sup_{\theta} R(\theta, \delta) \geq c = \sup_{\theta} R(\theta, \delta^*)$ 。□

29.16 Bayes risk 极限下界法

定理 29.19 (Bayes 下界逼近 minimax 值). 设 $\sup_{\theta} R(\theta, \delta^*) = c < \infty$ 。若存在 proper priors π_k , 使相应最小 Bayes risk $r_k = \inf_{\delta} r(\pi_k, \delta)$ 满足 $r_k \rightarrow c$, 则 δ^* 为 minimax。

证明. 对任意 δ , $\sup_{\theta} R(\theta, \delta) \geq r(\pi_k, \delta) \geq r_k$ 。令 $k \rightarrow \infty$, $\sup_{\theta} R(\theta, \delta) \geq c$ 。而 δ^* 的最大风险恰为 c 。□

29.17 历年真题：正态均值向量的 minimax 性

往年真题

[24S-Q7, 15 分]

设 $X_i \sim N(\mu_i, 1)$ 相互独立, $X = (X_1, \dots, X_n)^{\top}$, $\mu = (\mu_1, \dots, \mu_n)^{\top}$ 。在损失 $L(\mu, a) = \sum_{i=1}^n (a_i - \mu_i)^2$ 下, 证明 $\delta(X) = X$ 是 minimax。

解: 首先, $X - \mu \sim N_n(0, I_n)$ 。因此

$$\begin{aligned} R(\mu, \delta) &= \mathbb{E}_{\mu} \|X - \mu\|^2 \\ &= \sum_{i=1}^n \mathbb{E}_{\mu} (X_i - \mu_i)^2 \\ &= n. \end{aligned}$$


所以

$$\sup_{\mu} R(\mu, \delta) = n. \quad (29.27)$$

下面构造一系列 proper priors。令 $\mu \sim N_n(0, \tau^2 I_n)$ 。在平方损失下, Bayes 规则为后验均值: $\delta_{\tau}(X) = \frac{\tau^2}{1+\tau^2} X$ 。后验协方差为 $\frac{\tau^2}{1+\tau^2} I_n$, 故最小 Bayes risk 为

$$r_{\tau} = n \frac{\tau^2}{1+\tau^2}. \quad (29.28)$$

当 $\tau^2 \rightarrow \infty$ 时, $r_{\tau} \rightarrow n$ 。由 **定理 29.19**, $\delta(X) = X$ 是 minimax。□



考试时需要注意的地方

该题不能仅凭“风险为常数”就断言 minimax。

还必须给出：

- 一个 Bayes risk 下界；
- 或证明该规则本身是某 proper prior 下的 Bayes 规则；
- 或使用一系列扩散先验使最小 Bayes risk 逼近常风险。

29.18 历年真题：两点先验下的 Bayes 与 minimax 检验

往年真题

[26S-Q9, 10 分]

观测 $Y \mid \mu \sim N(\mu, 1)$, 先验为 $P(\mu = -1) = P(\mu = 1) = \frac{1}{2}$, 动作空间为 $\{-1, 1\}$ 。在绝对损失 $L(\mu, a) = |\mu - a|$ 下求 Bayes 规则, 并判断其是否 minimax。

解：后验似然比为 $\frac{P(\mu=1|y)}{P(\mu=-1|y)} = \frac{\phi(y-1)}{\phi(y+1)} = e^{2y}$ 。因此

$$P(\mu = 1 \mid y) = \frac{e^{2y}}{1 + e^{2y}} = \frac{1}{1 + e^{-2y}}. \quad (29.29)$$

错误动作的绝对损失为 $|1 - (-1)| = 2$ 。故在 $y > 0$ 时后验概率更支持 $\mu = 1$, 在 $y < 0$ 时支持 $\mu = -1$ 。Bayes 规则为

$$\delta^*(y) = \begin{cases} 1, & y > 0, \\ -1, & y < 0. \end{cases} \quad (29.30)$$

在 $y = 0$ 可任意选择或随机化, 该事件概率为零。

若 $\mu = 1$, $R(1, \delta^*) = 2P_1(Y < 0) = 2\Phi(-1)$ 。若 $\mu = -1$, $R(-1, \delta^*) = 2P_{-1}(Y > 0) = 2\Phi(-1)$ 。故风险为常数: $R(\mu, \delta^*) = 2\Phi(-1) \mu \in \{-1, 1\}$ 。该规则是等权 proper prior 下的 Bayes 规则, 由 定理 29.18,

$$\delta^* \text{ 是 minimax.} \quad (29.31)$$

□

29.19 历年真题：约束参数空间中的不可容许性

往年真题

[24F-Q10(c), 15 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\mu \geq 0$, $\sigma > 0$, 判断 $\bar{X}$ 在平方损失下估计 μ 是否可容许。

解：考虑投影估计量

$$\delta^+(X) = \max\{0, \bar{X}\}. \quad (29.32)$$

对任意 $\mu \geq 0$, 逐点比较损失。

若 $\bar{X} \geq 0$, 则 $\delta^+ = \bar{X}$, 两者损失相同。

若 $\bar{X} < 0$, 则 $\delta^+ = 0$ 。由于 $\mu \geq 0$, $|0 - \mu| = \mu < \mu - \bar{X} = |\bar{X} - \mu|$ 除零概率退化情形外严格成立。故 $(\delta^+ - \mu)^2 \leq (\bar{X} - \mu)^2$ 对每个样本点成立, 且事件 $\{\bar{X} < 0\}$ 在任意有限 μ 与 $\sigma > 0$ 下具有正概率。

因此 $R(\mu, \delta^+) < R(\mu, \bar{X}) \forall \mu \geq 0$ 。所以

$$\boxed{\bar{X} \text{ 不可容许。}} \quad (29.33)$$

□

注 29.20 (投影原理). 在平方欧氏损失下, 若参数空间是闭凸集 C , 将任意估计量投影到 C 上不会增加到任意 $\theta \in C$ 的欧氏距离。

因此未尊重已知参数约束的估计量常可被投影估计量支配。

29.20 历年真题：无偏尺度估计量的不可容许性

往年真题

[25S-Q10(b), 10 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2)$, $\sigma > 0$, 并令 $W = \frac{1}{n} \sum_{i=1}^n |X_i|$ 。前一问得到基于 W 的无偏估计量。判断其在平方损失下是否可容许。

解：因为 $\mathbb{E}|X_i| = \sigma\sqrt{\frac{2}{\pi}}$, 故无偏估计量为

$$\delta_U = \sqrt{\frac{\pi}{2}} W. \quad (29.34)$$

令 $T = \frac{\delta_U}{\sigma}$ 。则 $\mathbb{E}T = 1$ 。又因 $\text{Var}(|Z|) = 1 - \frac{2}{\pi}$, $Z \sim N(0, 1)$, 有 $\text{Var}(T) = \frac{\pi/2-1}{n} =: v > 0$ 。因此 $\mathbb{E}T^2 = 1 + v$ 。

考虑缩放估计量 $\delta_c = c\delta_U$ 。其风险为

$$\begin{aligned} R(\sigma, \delta_c) &= \mathbb{E}_\sigma (c\delta_U - \sigma)^2 \\ &= \sigma^2 \mathbb{E}(cT - 1)^2 \\ &= \sigma^2 [c^2(1+v) - 2c + 1]. \end{aligned}$$


关于 c 最小化, 得到

$$c^* = \frac{1}{1+v}. \quad (29.35)$$

此时 $R(\sigma, \delta_{c^*}) = \sigma^2 \frac{v}{1+v}$ 。而无偏估计量的风险为 $R(\sigma, \delta_U) = \sigma^2 v$ 。因为 $\frac{v}{1+v} < v$, 所以 $R(\sigma, \delta_{c^*}) < R(\sigma, \delta_U) \forall \sigma > 0$ 。故

$$\boxed{\delta_U \text{ 不可容许。}} \quad (29.36)$$

□



考试时需要注意的地方

无偏性既不推出可容许性，也不推出 minimax。

本题通过引入小的向下偏差，换取足够大的方差下降，从而在所有 $\sigma > 0$ 上严格降低 MSE。

29.21 历年真题：Bernoulli 加权损失下的可容许性**往年真题**

[25F-Q9(b), 15 分题的一部分]

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, $0 < p < 1$ 。证明 $\bar{X}$ 在损失

$$L(p, a) = \frac{(p - a)^2}{p(1 - p)} \quad (29.37)$$

下可容许。

解：记 $S = \sum_{i=1}^n X_i$ 。取 proper 均匀先验 $\pi(p) = 1$, $0 < p < 1$ 。

给定 $S = s$ ，需最小化 $\int_0^1 \frac{(p-a)^2}{p(1-p)} p^s (1-p)^{n-s} dp$ 。忽略不含 a 的二项系数，该式为

$$Q_s(a) = \int_0^1 (p-a)^2 p^{s-1} (1-p)^{n-s-1} dp. \quad (29.38)$$

当 $1 \leq s \leq n-1$ 时，权函数可归一化为 Beta($s, n-s$) 密度。因此唯一最小点为其均值 $a_s = \frac{s}{n}$ 。

当 $s=0$ 时，若 $a \neq 0$ ，被积函数在 $p \downarrow 0$ 附近含有 $\frac{a^2}{p}$ ，积分发散；而 $a=0$ 时风险有限，故唯一最小点为 0。

同理，当 $s=n$ 时唯一最小点为 1。

综上，唯一 Bayes 规则为 $\delta^\pi(S) = \frac{S}{n} = \bar{X}$ 。

其频率风险为

$$\begin{aligned} R(p, \bar{X}) &= \frac{\mathbb{E}_p(\bar{X} - p)^2}{p(1-p)} \\ &= \frac{\text{Var}_p(\bar{X})}{p(1-p)} \\ &= \frac{1}{n}. \end{aligned}$$

风险为常数。

由于 $\bar{X}$ 是 full-support proper prior 下的唯一 Bayes 规则，它可容许；又由常风险 Bayes 准则，它也是 minimax：

$\bar{X}$ 可容许且 minimax。

(29.39)

□

29.22 Bayes 与决策理论易错点

陈述	判断	正确说明
Bayes 估计量总是后验均值	错	后验泛函取决于损失：平方损失为均值，绝对损失为中位数。
MAP 与 MLE 相同	通常错	MAP 最大化似然乘先验；平坦先验下有时相同。
MAP 具有重参数化不变性	错	密度变换含 Jacobian，众数可能改变。
不当先验一定不可使用	错	若后验 proper，可定义广义 Bayes 规则；但必须检查后验矩和风险。
广义 Bayes 自动可容许	错	proper Bayes 的可容许性定理不能直接套到不当先验。
常风险规则一定 minimax	条件不足	还需证明相应的风险下界，例如它是 Bayes 或 Bayes risk 极限达到该常数。
Bayes 规则一定 minimax	错	只在额外的常风险或最不利先验条件下成立。
minimax 一定可容许	错	可能存在多个 minimax 规则，其中部分可被另一 minimax 规则支配。
无偏估计量一定可容许	错	[25S-Q10] 给出直接反例。
可容许等于 UMVU	错	前者在全部规则中按风险支配比较；后者仅在无偏估计量类中比较方差。

一些需要记忆的内容

(1) 决策问题由哪五个基本对象组成?

(2) 风险函数与 Bayes risk 的积分对象分别是什么?

(3) 为什么平方损失对应后验均值?

(4) 为什么绝对损失对应后验中位数?

(5) 连续参数的 MAP 为什么不能简单由普通 0-1 损失推出?

(6) 不当先验使用前必须检查哪些有限性条件?

(7) 风险支配与可容许性的量词是什么?

(8) 常风险 Bayes 规则为什么 minimax?



第三十章 相合性、渐近正态性与 MLE 的统一 渐近理论

30.1 考纲定位

重点

重要性等级：S 级。

资格考试中的渐近题通常要求完成：

识别统计量 $\rightarrow$ 建立联合 CLT $\rightarrow$ Taylor/Delta $\rightarrow$ Slutsky $\rightarrow$ 写出最终协方差。

MLE 题则要求：

相合性 + score 展开 + Hessian 收敛 + Fisher 信息逆。

本章与前文 Delta 方法、Fisher 信息及非正则 MLE 章节共同构成完整渐近理论。

30.2 相合性的 argmax 框架

设经验准则函数为 $M_n(\theta) = \frac{1}{n} \sum_{i=1}^n m_\theta(X_i)$ ，总体准则函数为 $M(\theta) = \mathbb{E}_{\theta_0} m_\theta(X)$ 。

定理 30.1 (Argmax 相合性定理)。假设：

- (1) 参数空间 Θ 为紧集，或估计量以高概率落在某个紧集内；
- (2) $\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{\mathbb{P}} 0$ ；
- (3) M 在真值 θ_0 处唯一达到最大值；
- (4) $\hat{\theta}_n$ 是近似最大化点，即 $M_n(\hat{\theta}_n) \geq \sup_{\theta \in \Theta} M_n(\theta) - o_p(1)$ 。

则


$$\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_0. \quad (30.1)$$

证明. 任取 $\varepsilon > 0$ 。由唯一最大性与紧性， $\Delta_\varepsilon = M(\theta_0) - \sup_{\|\theta - \theta_0\| \geq \varepsilon} M(\theta) > 0$ 。在事件 $\sup_{\theta} |M_n(\theta) - M(\theta)| < \Delta_\varepsilon/3$ 上， $M_n(\theta_0) > M(\theta_0) - \Delta_\varepsilon/3$ ，而对 $\|\theta - \theta_0\| \geq \varepsilon$ ， $M_n(\theta) < M(\theta_0) - 2\Delta_\varepsilon/3$ 。故任何误差小于 $\Delta_\varepsilon/3$ 的近似最大点都必须落在 $\|\theta - \theta_0\| < \varepsilon$ 。而上述一致收敛事件概率趋于 1。□

30.3 MLE 相合性的 Kullback–Leibler 识别

对 MLE， $m_\theta(x) = \log f(x | \theta)$ 。总体准则为 $M(\theta) = \mathbb{E}_{\theta_0} \log f(X | \theta)$ 。有

$$M(\theta_0) - M(\theta) = \mathbb{E}_{\theta_0} \log \frac{f(X | \theta_0)}{f(X | \theta)}$$



$$= D_{\text{KL}}(P_{\theta_0} \| P_{\theta}) \geq 0. \quad (30.2)$$

若模型可识别, 则等号仅在 $\theta = \theta_0$ 成立。因此 KL 散度提供总体准则唯一最大性的核心。

前提条件检查

仅有逐点大数律 $M_n(\theta) \xrightarrow{\mathbb{P}} M(\theta)$ 对每个固定 θ 通常不足以证明 $\arg\max$ 相合性。
还需要: $\sup_{\theta \in \Theta} |M_n(\theta) - M(\theta)| \xrightarrow{\mathbb{P}} 0$ 或其他可替代的一致控制。

30.4 一维 MLE 的渐近正态性

定理 30.2 (正则 MLE 渐近正态性). 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(\cdot | \theta_0)$, $\theta_0 \in \text{int}(\Theta)$ 。假设:

- (1) $\hat{\theta}_n \xrightarrow{\mathbb{P}} \theta_0$;
- (2) 对数密度在真值邻域内二次可微;
- (3) $\mathbb{E}_{\theta_0} U_{\theta_0}(X) = 0$;
- (4) $I_1(\theta_0) = \text{Var}_{\theta_0} U_{\theta_0}(X) \in (0, \infty)$;
- (5) score 满足中心极限定理;
- (6) Hessian 满足局部一致大数律: $-\frac{1}{n} \ell_n''(\theta) \xrightarrow{\mathbb{P}} I_1(\theta_0)$ 在 θ_0 邻域内一致成立;
- (7) 以概率趋于 1, $\ell_n'(\hat{\theta}_n) = 0$ 。

则

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, I_1(\theta_0)^{-1}). \quad (30.3)$$

证明. 由均值定理, 存在 $\tilde{\theta}_n$ 位于 $\hat{\theta}_n$ 与 θ_0 之间, 使 $0 = \ell_n'(\hat{\theta}_n) = \ell_n'(\theta_0) + \ell_n''(\tilde{\theta}_n)(\hat{\theta}_n - \theta_0)$ 。因此

$$\sqrt{n}(\hat{\theta}_n - \theta_0) = \left[-\frac{1}{n} \ell_n''(\tilde{\theta}_n) \right]^{-1} \frac{\ell_n'(\theta_0)}{\sqrt{n}}. \quad (30.4)$$

由 score CLT, $\frac{\ell_n'(\theta_0)}{\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^n U_{\theta_0}(X_i) \xrightarrow{d} N(0, I_1(\theta_0))$ 。由相合性, $\tilde{\theta}_n \xrightarrow{\mathbb{P}} \theta_0$ 。由 Hessian 一致大数律, $-\frac{1}{n} \ell_n''(\tilde{\theta}_n) \xrightarrow{\mathbb{P}} I_1(\theta_0)$ 。应用 Slutsky 定理即得结论。□

考试时需要注意的地方

MLE 渐近正态证明中的四个不可缺步骤:

- (1) score 方程;
- (2) 在真值处 Taylor 展开;
- (3) score 的 CLT;
- (4) 随机中间点处 Hessian 的概率收敛。

30.5 多参数 MLE

设 $\theta \in \mathbb{R}^p$ 。score 向量为 $U_n(\theta) = \nabla_{\theta} \ell_n(\theta)$, Hessian 为 $H_n(\theta) = \nabla_{\theta}^2 \ell_n(\theta)$ 。

在正则条件下, $0 = U_n(\hat{\theta}) = U_n(\theta_0) + H_n(\tilde{\theta}_n)(\hat{\theta} - \theta_0)$, 其中多维 Taylor 展开可用积分形式严格表示。

若 $-\frac{1}{n}H_n(\tilde{\theta}_n) \xrightarrow{\mathbb{P}} I_1(\theta_0)$ 且 $\frac{1}{\sqrt{n}}U_n(\theta_0) \xrightarrow{d} N_p(0, I_1(\theta_0))$, 则

$$\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N_p(0, I_1(\theta_0)^{-1}). \quad (30.5)$$

30.6 多元 Delta 方法

定理 30.3 (多元 Delta 方法). 若 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N_p(0, \Sigma)$, 且 $g: \mathbb{R}^p \rightarrow \mathbb{R}^q$ 在 θ 处可微, *Jacobian* 为 $G = Dg(\theta)$, 则

$$\sqrt{n}[g(\hat{\theta}) - g(\theta)] \xrightarrow{d} N_q(0, G\Sigma G^\top). \quad (30.6)$$

证明. 可微性给出 $g(\hat{\theta}) - g(\theta) = G(\hat{\theta} - \theta) + r_n$, 其中 $\frac{\|r_n\|}{\|\hat{\theta} - \theta\|} \xrightarrow{\mathbb{P}} 0$. 而 $\hat{\theta} - \theta = O_p(n^{-1/2})$, 故 $\sqrt{n}r_n = o_p(1)$. 再应用 Slutsky 定理. $\square$

30.7 二阶 Delta 方法

若 $\sqrt{n}(Y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$, 但 $g'(\theta) = 0$, $g''(\theta) \neq 0$, 则一阶 Delta 方法给出退化极限。二阶 Taylor 展开为 $g(Y_n) - g(\theta) = \frac{1}{2}g''(\theta)(Y_n - \theta)^2 + o_p(n^{-1})$. 因此

$$n[g(Y_n) - g(\theta)] \xrightarrow{d} \frac{1}{2}g''(\theta)\sigma^2\chi_1^2. \quad (30.7)$$

考试时需要注意的地方

看到 $g'(\theta) = 0$ 时不能继续写普通正态极限。

必须:

- 检查二阶导数;
- 改用速度 n ;
- 极限通常是卡方变换而非正态。

30.8 标准误估计与学生化

若 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, V(\theta))$, 且 $\hat{V} \xrightarrow{\mathbb{P}} V(\theta)$, 则

$$\frac{\hat{\theta} - \theta}{\sqrt{\hat{V}/n}} \xrightarrow{d} N(0, 1). \quad (30.8)$$

MLE 的常用方差估计有:

$$\widehat{\text{Var}}(\hat{\theta}) = \frac{1}{nI_1(\hat{\theta})}, \quad (30.9)$$

$$\widehat{\text{Var}}(\hat{\theta}) = \left[-\ell''_n(\hat{\theta})\right]^{-1}. \quad (30.10)$$



多参数情形使用相应矩阵的对角元或目标函数的 Delta 方差。

30.9 渐近效率

若 $\sqrt{n}[T_n - \tau(\theta)] \xrightarrow{d} N(0, V_T(\theta))$, 且 $V_T(\theta) = \tau'(\theta)^2 I_1(\theta)^{-1}$, 则称 T_n 对 $\tau(\theta)$ 渐近有效。
正则 MLE 及其光滑变换满足 $\sqrt{n}[\tau(\hat{\theta}) - \tau(\theta)] \xrightarrow{d} N\left(0, \frac{\tau'(\theta)^2}{I_1(\theta)}\right)$ 。

定义 30.4 (渐近相对效率). 若 $\sqrt{n}(T_n - \tau) \xrightarrow{d} N(0, V_T)$, $\sqrt{n}(S_n - \tau) \xrightarrow{d} N(0, V_S)$, 定义 T_n 相对于 S_n 的渐近相对效率为

$$\text{ARE}(T, S) = \frac{V_S}{V_T}.$$

(30.11)

30.10 正则与非正则渐近理论的判断表

检查项	正则情形	失败后可能现象
真值位置	参数空间内部	边界截断、混合极限
支持集	与参数无关	极值统计量主导、速度 n
可识别性	不同参数给出不同分布	信息奇异、MLE 不唯一
信息矩阵	有限正定	不同速度或不可估方向
对数似然	局部二次	尖点、绝对值型或非光滑极限
MLE	存在且相合	只在闭包达到或发散
典型极限	$\sqrt{n}$ 正态、LR 卡方	指数、截断、混合或非标准极限

30.11 渐近题参考流程

一般统计量的渐近分布

(1) 将估计量写成样本矩向量的函数: $T_n = g(\bar{h}_n)$;

(2) 写出 $\mu_h = \mathbb{E}h(X)$, $\Sigma_h = \text{Cov}(h(X))$;

(3) 用多元 CLT: $\sqrt{n}(\bar{h}_n - \mu_h) \xrightarrow{d} N(0, \Sigma_h)$;

(4) 计算 Jacobian $Dg(\mu_h)$;

(5) 用 Delta 方法得到 $Dg \Sigma_h Dg^\top$;

(6) 若有样本方差或其他随机标准误, 再用 Slutsky;

(7) 若一阶导数为零, 改用二阶 Delta;

(8) 明确区分精确等式、 $o_p(1)$ 和渐近近似。



MLE 渐近分布

- (1) 检查真值是否为内部点；
- (2) 检查支持集是否依赖参数；
- (3) 写 score 方程；
- (4) 在真值处 Taylor 展开；
- (5) 对 score 使用 CLT；
- (6) 对 Hessian 使用大数律；
- (7) 得到 $I_1(\theta)^{-1}$ ；
- (8) 对参数函数使用 Delta 方法；
- (9) 若模型非正则，停止使用该模板并重新找速度。

一些需要记忆的内容

- (1) MLE 相合性为何需要一致大数律而非仅逐点大数律？
- (2) KL 散度在 MLE 相合性中起什么作用？
- (3) MLE 渐近正态证明中随机中间点如何处理？
- (4) 多参数 MLE 的渐近协方差为何是 Fisher 信息矩阵的逆？
- (5) 一阶 Delta 方法退化时应检查什么？
- (6) 学生化统计量为什么仍收敛到标准正态？
- (7) 渐近方差与有限样本方差有什么区别？
- (8) 参数依赖支持集时，哪一步正则证明首先失效？
- (9) LR、Wald、score 共同依赖的局部二次展开是什么？



第三十一章 线性模型与 Gauss–Markov

重点

重要性等级：C/A 级。

该主题未在简要考纲中单独列出，但曾在历年真题中实际考查。

直接对应：[24F-Q8, 10 分]。

其中 Gauss–Markov 定理要求完整证明；高斯线性模型的信息矩阵、 t 检验、 F 检验和置信区间属于必须会使用内容。

31.1 线性模型与基本假设

考虑

$$Y = Z\beta + \varepsilon, \quad (31.1)$$

其中： $Y \in \mathbb{R}^n$, $Z \in \mathbb{R}^{n \times d}$, $\beta \in \mathbb{R}^d$ 。假设

$$\text{rank}(Z) = d. \quad (31.2)$$

定义 31.1 (Gauss–Markov 假设). Gauss–Markov 假设为

$$\mathbb{E}(\varepsilon) = 0, \quad (31.3)$$

$$\text{Cov}(\varepsilon) = \sigma^2 I_n, \quad 0 < \sigma^2 < \infty. \quad (31.4)$$

该假设只要求：

- 零均值；
- 同方差；
- 不相关。

不要求误差正态，也不要求误差独立。

考试时需要注意的地方

“不相关”与“独立”不是同义词。

Gauss–Markov 定理本身不需要正态性；只有在推导有限样本 t 、 F 、卡方分布时才需要高斯误差。

31.2 最小二乘估计

最小二乘准则为 $Q(\beta) = \|Y - Z\beta\|^2$ 。正规方程为 $Z^\top Z \hat{\beta} = Z^\top Y$ 。由满列秩， $Z^\top Z$ 可逆，故

$$\boxed{\hat{\beta} = (Z^\top Z)^{-1} Z^\top Y.} \quad (31.5)$$

定义帽子矩阵

$$H = Z(Z^\top Z)^{-1}Z^\top \quad (31.6)$$

和残差投影矩阵

$$M = I_n - H. \quad (31.7)$$

则 $\hat{Y} = HY$, $\hat{\varepsilon} = MY$ 。

有 $H^\top = H$, $H^2 = H$, $\text{rank}(H) = d$, $M^\top = M$, $M^2 = M$, $\text{rank}(M) = n - d$, $HZ = Z$, $MZ = 0$, $HM = 0$ 。

31.3 线性函数的无偏估计

设目标参数为 $\theta = b^\top \beta$, $b \in \mathbb{R}^d$ 。自然估计量为

$$\hat{\theta} = b^\top \hat{\beta}. \quad (31.8)$$

由 $\hat{\beta} = \beta + (Z^\top Z)^{-1}Z^\top \varepsilon$, 有

$$\mathbb{E}(\hat{\beta}) = \beta, \quad (31.9)$$

$$\text{Cov}(\hat{\beta}) = \sigma^2(Z^\top Z)^{-1}. \quad (31.10)$$

因此

$$\boxed{\mathbb{E}(\hat{\theta}) = b^\top \beta, \text{Var}(\hat{\theta}) = \sigma^2 b^\top (Z^\top Z)^{-1} b.} \quad (31.11)$$

31.4 Gauss-Markov 定理

定理 31.2 (Gauss-Markov). 在线性模型 $Y = Z\beta + \varepsilon$ 满足 $\mathbb{E}\varepsilon = 0$, $\text{Cov}(\varepsilon) = \sigma^2 I_n$, $\text{rank}(Z) = d$ 时, $b^\top \hat{\beta}$ 是 $b^\top \beta$ 的所有线性无偏估计量中方差最小者。

即它是 BLUE: *best linear unbiased estimator*。

证明. 任意线性估计量可写为 $c^\top Y$, $c \in \mathbb{R}^n$ 。其无偏性等价于 $\mathbb{E}(c^\top Y) = c^\top Z\beta = b^\top \beta \quad \forall \beta$, 即

$$Z^\top c = b. \quad (31.12)$$

OLS 线性函数可写成 $b^\top \hat{\beta} = b^\top (Z^\top Z)^{-1}Z^\top Y = c_0^\top Y$, 其中

$$c_0 = Z(Z^\top Z)^{-1}b. \quad (31.13)$$

并且 $Z^\top c_0 = b$ 。

对任意满足 equation (31.12) 的 c , 令 $h = c - c_0$ 。则 $Z^\top h = Z^\top c - Z^\top c_0 = 0$ 。又因 $c_0 \in \text{col}(Z)$, 而 $h \perp \text{col}(Z)$, 所以 $c_0^\top h = 0$ 。因此 $\|c\|^2 = \|c_0 + h\|^2 = \|c_0\|^2 + \|h\|^2 \geq \|c_0\|^2$ 。由 $\text{Cov}(Y) = \sigma^2 I_n$, 有 $\text{Var}(c^\top Y) = \sigma^2 \|c\|^2 \geq \sigma^2 \|c_0\|^2 = \text{Var}(c_0^\top Y)$ 。等号成立当且仅当 $h = 0$, 即 $c = c_0$ 。□

考试时需要注意的地方

Gauss-Markov 证明必须写出：

- (1) 线性无偏条件 $Z^T c = b$;
- (2) OLS 对应系数向量 c_0 ;
- (3) 分解 $c = c_0 + h$;
- (4) 正交关系 $Z^T h = 0$;
- (5) Pythagoras 方差分解;
- (6) 等号成立条件。

31.5 一般协方差下的广义最小二乘

若 $\text{Cov}(\varepsilon) = \sigma^2 \Omega$, 其中 Ω 已知正定, 则普通 OLS 一般不再 BLUE。

广义最小二乘估计量为

$$\hat{\beta}_{\text{GLS}} = (Z^T \Omega^{-1} Z)^{-1} Z^T \Omega^{-1} Y. \quad (31.14)$$

其协方差为

$$\text{Cov}(\hat{\beta}_{\text{GLS}}) = \sigma^2 (Z^T \Omega^{-1} Z)^{-1}. \quad (31.15)$$

证明可对模型左乘 $\Omega^{-1/2}$ 转化为球形协方差模型, 再应用 Gauss-Markov 定理。

31.6 高斯线性模型中的精确分布

进一步假设

$$\varepsilon \sim N_n(0, \sigma^2 I_n). \quad (31.16)$$

则

$$\hat{\beta} \sim N_d(\beta, \sigma^2 (Z^T Z)^{-1}). \quad (31.17)$$

残差平方和为 $\text{SSE} = \|Y - Z\hat{\beta}\|^2 = Y^T M Y$ 。由正交投影的卡方性质,

$$\frac{\text{SSE}}{\sigma^2} \sim \chi_{n-d}^2. \quad (31.18)$$


定义

$$s^2 = \frac{\text{SSE}}{n-d}. \quad (31.19)$$

则 $\mathbb{E}s^2 = \sigma^2$ 。

又因为 HY 与 MY 为联合高斯随机向量, 且 $\text{Cov}(HY, MY) = H(\sigma^2 I)M = 0$, 故

$$\hat{\beta} \perp\!\!\!\perp \text{SSE}. \quad (31.20)$$



31.7 单个线性约束的精确 t 检验

检验 $H_0: b^\top \beta = \theta_0$ 。在 H_0 下,

$$T = \frac{b^\top \hat{\beta} - \theta_0}{s \sqrt{b^\top (Z^\top Z)^{-1} b}} \sim t_{n-d}. \quad (31.21)$$

故双侧 size α 检验拒绝于 $|T| \geq t_{n-d, 1-\alpha/2}$ 。相应置信区间为

$$b^\top \beta \in b^\top \hat{\beta} \pm t_{n-d, 1-\alpha/2} s \sqrt{b^\top (Z^\top Z)^{-1} b}. \quad (31.22)$$

31.8 多个线性约束的精确 F 检验

设 $R \in \mathbb{R}^{q \times d}$, $\text{rank}(R) = q$, 检验 $H_0: R\beta = r$ 。定义

$$F = \frac{(R\hat{\beta} - r)^\top [R(Z^\top Z)^{-1} R^\top]^{-1} (R\hat{\beta} - r)}{q s^2}. \quad (31.23)$$

则在 H_0 下

$$F \sim F_{q, n-d}. \quad (31.24)$$

拒绝域为 $F \geq F_{q, n-d, 1-\alpha}$ 。

当 $q = 1$ 时, $F = T^2$ 。

31.9 Fisher 信息矩阵

若 σ^2 已知, $Y \sim N_n(Z\beta, \sigma^2 I_n)$ 。对数似然为 $\ell(\beta) = C - \frac{1}{2\sigma^2} (Y - Z\beta)^\top (Y - Z\beta)$ 。score 为 $U_\beta = \frac{1}{\sigma^2} Z^\top (Y - Z\beta)$, Hessian 为 $\nabla_\beta^2 \ell(\beta) = -\frac{1}{\sigma^2} Z^\top Z$ 。故

$$I(\beta) = \frac{1}{\sigma^2} Z^\top Z. \quad (31.25)$$

若 $\text{rank}(Z) < d$, 则信息矩阵奇异, β 不可全部识别。

31.10 线性模型易错点

陈述	判断	正确说明
Gauss-Markov 要求正态误差	错	BLUE 结论只需零均值和球形协方差。
不相关误差必独立	错	只有联合高斯等额外条件下成立。
OLS 总是唯一	错	需要设计矩阵满列秩; 否则 β 不可唯一估计。
OLS 在异方差下仍为 BLUE	通常错	一般需 GLS 或其他加权估计。

陈述	判断	正确说明
残差平方和自由度为 n	错	估计了 d 个线性参数后，自由度为 $n - d$ 。
$\hat{\beta}$ 与 SSE 总独立	错	有限样本独立性依赖高斯误差；一般只有不相关。
t 检验可在任意误差分布下精确使用	错	非高斯时通常只具大样本近似。

一些需要记忆的内容

(1) 线性估计量 $c^T Y$ 无偏估计 $b^T \beta$ 的充要条件是什么?

(2) Gauss–Markov 证明中的两个正交子空间是什么?

(3) 为什么正态性不是 BLUE 结论的条件?

(4) 帽子矩阵和残差矩阵的秩分别是多少?

(5) 为什么 $\hat{\beta}$ 与 SSE 在高斯模型下独立?

(6) 单个线性约束的 t 统计量自由度是多少?

(7) 多个约束的 F 统计量分子自由度如何确定?

(8) 设计矩阵不满秩时 Fisher 信息发生什么?



第三部分

应试技巧



第三十二章 需要记忆的定义、定理与证明清单

32.1 需要记忆的定义清单

定义	考试中必须写出的核心内容
概率空间	$(\Omega, \mathcal{F}, P)$, $\mathcal{F}$ 为 σ -代数, P 可列可加且 $P(\Omega) = 1$ 。
随机变量	从 $(\Omega, \mathcal{F})$ 到 Borel 空间的可测函数。
独立 σ -代数	任取各 σ -代数中的事件, 其有限交概率等于概率乘积。
条件期望	$\mathcal{G}$ -可测, 且对每个 $G \in \mathcal{G}$, $\int_G \mathbb{E}(X \mathcal{G}) dP = \int_G X dP$ 。
一致可积	$\lim_{K \rightarrow \infty} \sup_{\alpha} \mathbb{E}[X_{\alpha} \mathbf{1}_{\{ X_{\alpha} > K\}}] = 0$ 。
停时	$\{\tau \leq n\} \in \mathcal{F}_n$ 或连续时间相应条件。
鞅	适应、可积, 且 $\mathbb{E}(M_{n+1} \mathcal{F}_n) = M_n$ 。
常返与暂留	状态返回概率分别等于 1 或小于 1。
平稳分布	概率向量 π 满足 $\pi P = \pi$ 。
充分统计量	给定该统计量后, 样本条件分布不依赖参数; 或使用因子分解定理。
极小充分	对任意充分统计量 S , 存在函数使 $T = h(S)$ 几乎处处成立。
完全统计量	$\mathbb{E}_{\theta} g(T) = 0 \quad \forall \theta \implies g(T) = 0 \quad \text{a.s.}$
辅助统计量	其分布不依赖参数。
UMVUE	在所有无偏估计同一参数函数的估计量中, 对每个参数值方差最小。
Fisher 信息	$I(\theta) = \mathbb{E}_{\theta}[(\partial_{\theta} \log f_{\theta})^2]$, 其他公式需正则条件。
检验的 size	$\sup_{\theta \in \Theta_0} P_{\theta}(\text{拒绝 } H_0)$ 。
level α	size 不超过 α 。
功效函数	$\beta(\theta) = P_{\theta}(\text{拒绝 } H_0)$ 。
UMP	在全部 level α 检验中, 对每个备择参数逐点功效最大。
置信系数	$\inf_{\theta} P_{\theta}\{\theta \in C(X)\}$ 。
Bayes 规则	最小化 Bayes risk, 等价于对几乎每个样本最小化后验风险。
可容许	不存在在所有参数点不差且至少一点更好的规则。
minimax	最小化最大风险 $\sup_{\theta} R(\theta, \delta)$ 。

32.2 需要记忆的定理清单

定理	证明要求	必须记住的条件
单调收敛、Fatou、控制收敛	完整证明框架	非负性或可积控制变量。
Borel–Cantelli	完整证明	第二引理需要独立性或适当弱化条件。
收敛模式关系	完整论证	$L^p \Rightarrow P$; a.s. $\Rightarrow P$; $P \Rightarrow d$ 。
一致可积与 L^1 收敛	证明框架	依概率收敛加 UI。
弱、强大数律	证明框架	矩条件、截断条件须与版本匹配。
Lindeberg–Feller	证明框架	三角阵、方差归一化、Lindeberg 条件。
Lévy 连续性定理	会使用	极限函数须在零点连续且为特征函数。
条件期望 Tower property	完整证明	σ -代数包含关系。
Doob 不等式与鞅收敛	证明框架	非负下鞅或 L^p 有界条件。
可选停止	完整证明常用版本	有界停时、UI、有限期望增量等条件不可省。
马尔可夫链收敛	证明框架	不可约、非周期、正常返等。
反射原理	完整证明	布朗运动独立平稳增量与路径连续性。
因子分解定理	完整证明框架	共同支配测度。
Rao–Blackwell	完整证明	凸损失、条件期望存在。
Lehmann–Scheffé	完整证明	完全充分统计量。
Basu	证明框架	完全充分而非仅充分。
Cramér–Rao	完整证明	交换微分积分、score 均值零、信息有限。
Neyman–Pearson	完整证明	简单对简单，边界可随机化。
Karlin–Rubin	完整证明框架	一维参数、MLR、一侧假设。
Wilks	证明框架	内部点、可识别、正定信息、局部二次性。
Gauss–Markov	完整证明	零均值、球形协方差、设计满秩。

32.3 需要会完整证明的高频结果


- (1) 两两独立不推出相互独立的反例；
- (2) L^p 收敛推出依概率收敛；
- (3) 依概率收敛子列的几乎处处收敛子子列；
- (4) Borel–Cantelli 两个引理；
- (5) 条件期望存在唯一性的核心论证；
- (6) 条件期望的 Tower property 与取出已知量；
- (7) 鞅的可选停止常用有界版本；
- (8) 简单随机游动破产概率的鞅解法；



- (9) 布朗运动首达时间 Laplace 变换;
- (10) 因子分解定理;
- (11) Rao–Blackwell 与 Lehmann–Scheffé;
- (12) Neyman–Pearson 引理;
- (13) Karlin–Rubin 定理;
- (14) Cramér–Rao 下界;
- (15) Gauss–Markov 定理;
- (16) MLE 渐近正态性的 score–Hessian 展开;
- (17) Wilks 定理的一维证明框架;
- (18) 常风险 Bayes 规则的 minimax 证明。

32.4 证明套路总表

套路	识别信号	标准构造
截断	重尾、矩不存在、三角阵	$X = X\mathbf{1}_{\{ X \leq b_n\}} + X\mathbf{1}_{\{ X >b_n\}}$ 分别控制。
Borel–Cantelli	无限多次、limsup、极值	把目标写成事件序列的 $\limsup A_n$ 。
特征函数	和的分布、CLT、非标准归一化	展开 $\phi(t/a_n)^n$ 并取对数。
条件期望	给定信息、最优预测	验证可测性和积分刻画, 使用 Tower property。
鞅构造	首达概率、停时、随机游动	寻找 $e^{\lambda S_n}/M(\lambda)^n$ 或调和函数。
反射原理	布朗最大值、首达时间	在首次穿越时反射路径。
生成函数	分枝过程、首达时间、整数分布	写递推并转化为函数方程。
因子分解	充分统计量	将联合密度写为 $g_\theta(T(x))h(x)$ 。
Rao–Blackwell	改进无偏估计	取 $\mathbb{E}(W \mid T)$ 。
完全性	证明 UMVU 唯一	令无偏差为零的函数期望恒零。
MLR	一侧 UMP	计算 $f_{\theta_2}/f_{\theta_1}$ 关于 T 的单调性。
Delta	光滑函数统计量	CLT 后乘 Jacobian。
score 展开	MLE 渐近正态	$0 = U_n(\hat{\theta}) = U_n(\theta_0) + H_n(\tilde{\theta})(\hat{\theta} - \theta_0)$ 。
风险支配	admissibility	直接逐点比较损失或风险。
Bayes 下界	minimax	构造先验使最小 Bayes risk 逼近候选最大风险。



32.5 估计题解题流程

点估计题

- (1) 明确目标参数、参数空间和损失；
- (2) 求矩估计或 MLE 时保留支持约束；
- (3) 检查估计量是否属于参数空间；
- (4) 求偏差、方差和 MSE；
- (5) 若问 UMVUE: 充分 $\rightarrow$ 完全 $\rightarrow$ 无偏函数；
- (6) 若问 CRLB, 先检查正则条件；
- (7) 若问相合性, 找 LLN、连续映射或次序统计量极限；
- (8) 若问渐近分布, 写成样本矩函数并用 CLT/Delta；
- (9) 若问可容许性, 寻找支配规则或 proper Bayes 表示；
- (10) 若问 minimax, 计算最大风险并构造 Bayes 下界。

32.6 检验题解题流程

假设检验题

- (1) 把参数函数假设转化为原参数假设；
- (2) 判断简单/复合及单侧/双侧；
- (3) 简单对简单优先 NP；
- (4) 一参数一侧优先检查 MLR；
- (5) 通用复合问题计算 GLRT；
- (6) 离散模型检查随机化；
- (7) 写功效函数并找最不利原假设参数；
- (8) 说明 size、level 或渐近 size；
- (9) 双侧 UMP 存在性必须证明, 不能凭印象；
- (10) nuisance 参数下寻找枢轴量或 profile likelihood。

32.7 随机过程题解题流程

随机过程题

- (1) 写清 filtration、适应性和可积性；
- (2) 判断对象是鞅、Markov 链、Poisson 过程还是布朗运动；
- (3) 停时题先验证停时性；
- (4) 可选停止前逐条核对条件；
- (5) 首达题尝试指数鞅、调和函数或反射原理；
- (6) 马尔可夫链题依次检查: 不可约 $\rightarrow$ 周期 $\rightarrow$ 常返性 $\rightarrow$ 平稳分布；
- (7) 分枝过程题优先使用概率生成函数；
- (8) 布朗缩放题先写 $(B_{ct})_{t \geq 0} \stackrel{d}{=} (\sqrt{c}B_t)_{t \geq 0}$ 。

第三十三章 五套真题总地图与母题分类

33.1 考试结构与选题原则

五套试卷均采用：11 题中选做8 题。每套均有：4 道15 分题，7 道10 分题。

试卷明确说明：若作答超过 8 题，只批改最先作答的 8 题；只有结论而缺少必要解释或推导，只能获得极少分数。

考试时需要注意的地方

考场上不要“先写很多题，最后再选”。

正确策略：

- (1) 先用约 8–12 分钟扫描全部 11 题；
- (2) 明确圈定恰好 8 题；
- (3) 优先选择能写出完整条件和证明框架的题；
- (4) 不要因一道 15 分题已做一半而放弃更稳定的 10 分题；
- (5) 最终确认答题顺序不会使未完成题进入“前八题”。

33.2 五套试卷逐题映射

题号	分值	类别	主要标签	核心工具	题型/扩展
[24S-Q1]	10	概率	重尾、无穷方差、非标准 CLT	特征函数小量展开、Lévy 连续性定理、归一化序列选择	证明与构造
[24S-Q2]	15	概率	指数样本极值、几乎处处极限	尾概率估计、Borel–Cantelli、最大值夹逼	完整证明
[24S-Q3]	10	概率	依概率与 L^1 收敛、乘积	连续映射、分解不等式、反例构造	证明/反例
[24S-Q4]	15	概率	偏随机游动、首达时间	指数鞅、可选停止、首达概率、生成函数	完整计算
[24S-Q5]	10	概率	Markov 链随机映射表示	独立噪声递推、条件分布、逆变换构造	证明/构造
[24S-Q6]	10	概率	Brownian 首达时间	指数鞅、可选停止、Laplace 变换	证明与计算
[24S-Q7]	15	统计	正态均值向量、minimax	常风险、扩散正态先验、Bayes risk 下界	决策扩展
[24S-Q8]	10	统计	平移 Uniform、相合性、渐近分布	次序统计量、LLN、Slutsky、非正则速度比较	计算
[24S-Q9]	10	统计	$\log X \sim N(\theta, \theta)$ 、MLE	score 方程、唯一性、CLT、Delta	完整推导
[24S-Q10]	10	统计	Pareto 均值、UMP	参数单调变换、指数变换、MLR、Karlin–Rubin	检验
[24S-Q11]	15	统计	约束正态模型、UMVUE	充分性、完全性、Rao–Blackwell、Lehmann–Scheffé	综合证明
[24F-Q1]	10	概率	Uniform 矩与有限卷积	矩展开、独立性、分段卷积	计算
[24F-Q2]	10	概率	Delta 方法、Binomial 对数变换	CLT、Taylor、边界事件控制	证明
[24F-Q3]	10	概率	指数尾、矩、指数矩等价	尾积分、Markov 不等式、Stirling	证明
[24F-Q4]	10	概率	树上随机游动常返与暂留	电网络、有效电阻、径向链	实考扩展
[24F-Q5]	15	概率	指数变量加权、a.s. 与 L^1	鞅收敛、一致可积、指数矩	完整证明

题号	分值	类别	主要标签	核心工具	题型/扩展
[24F-Q6]	15	概率	Brownian 条件路径、Brownian bridge、GFF	反射原理、高斯条件分布、Green 函数、协方差识别	实考扩展
[24F-Q7]	10	统计	符号数据、MLE、UMP、置信区间	Bernoulli 化、参数反演、MLR、精确二项区间	综合
[24F-Q8]	10	统计	线性模型、Gauss–Markov、Fisher 信息	正交分解、BLUE、正态似然 Hessian	实考扩展
[24F-Q9]	10	统计	经验比例与 plug-in、渐近方差	CLT、Delta、渐近效率、稀有事件尺度	渐近计算
[24F-Q10]	15	统计	正态独立性、UMVUE、可容许性	Basu/正交分解、完全充分性、参数空间投影	综合/决策
[24F-Q11]	15	统计	分段 Uniform、MoM、MLE、相合性	参数分段、支持边界、极端次序统计量	非正则综合
[25S-Q1]	10	概率	最小值与最大值联合分布、条件期望	次序统计量联合密度、条件密度	计算
[25S-Q2]	10	概率	三维高斯向量、协方差约束	半正定性、线性回归表示、独立高斯残差	证明
[25S-Q3]	15	概率	简单随机游动双边吸收	指数鞅、差分方程、可选停止、生成函数	完整计算
[25S-Q4]	10	概率	非均匀权随机和、鞅与停时	适应性、条件期望、可选停止条件	证明
[25S-Q5]	10	概率	Brownian 双边首达、出口方向	强 Markov、对称性、条件独立	证明
[25S-Q6]	15	概率	条件二阶矩刻画高斯	特征函数微分、函数方程、独立性识别	高难证明
[25S-Q7]	10	统计	Uniform、不当先验、广义 Bayes	Pareto 型后验、矩存在性、极大次序统计量相合性	Bayes
[25S-Q8]	10	统计	Gamma 双侧 UMP、倒尺度 MLE	NP 唯一性、UMP 不存在、MLE 不变性、Delta	综合
[25S-Q9]	15	统计	样本相关系数、极小充分、完全性	多元 CLT、Delta、似然比判别、反例	综合渐近
[25S-Q10]	10	统计	绝对值估计尺度、渐近分布、可容许性	CLT、缩放估计、风险支配	决策扩展
[25S-Q11]	15	统计	平移指数、双参数 MLE、非正则联合极限	边界 MLE、无记忆性、Gamma 分解、不同收敛速度	高频非正则
[25F-Q1]	10	概率	随机指数 X^N 的矩	条件期望、Poisson 生成函数、矩存在区间	计算
[25F-Q2]	10	概率	二维 Uniform 条件分布	几何区域、条件密度、变量变换	计算
[25F-Q3]	10	概率	鞅与幂函数	条件 Jensen、严格凸性、等号条件	证明
[25F-Q4]	15	概率	独立非同分布和的振荡	Borel–Cantelli、稀有大跳、分块控制	高难证明
[25F-Q5]	10	概率	指数 Brownian 鞅与积分	指数鞅、Fubini、二阶矩、几乎处处可积性	计算/证明
[25F-Q6]	15	概率	2×2 GOE 随机矩阵	正交不变性、特征值变换、卡方/Rayleigh 分布	随机矩阵扩展
[25F-Q7]	10	统计	充分统计量与相合估计	条件期望、Rao–Blackwell、截断保持相合	证明
[25F-Q8]	15	统计	指数分布完全充分统计量、UMVUE	Gamma 完全性、条件概率、Lehmann–Scheffé	完整推导
[25F-Q9]	15	统计	Bernoulli 参数函数 UMVUE、admissibility	二项完全性、组合恒等式、proper Bayes、常风险	决策综合
[25F-Q10]	10	统计	Uniform、Lognormal 先验、MAP	截断正态后验、Jacobian、次序统计量相合性	Bayes
[25F-Q11]	10	统计	离散 Uniform、随机化 UMP、双侧 UMP	嵌套支持、NP 引理、边界随机化	特殊 UMP
[26S-Q1]	10	概率	高斯指数倾斜	Radon–Nikodym、MGF 配方、均值平移	证明
[26S-Q2]	15	概率	三角阵非同分布 CLT	方差计算、Lindeberg 条件、归一化选择	完整证明
[26S-Q3]	10	概率	随机配对面环数	指示变量、条件概率、线性期望	组合扩展
[26S-Q4]	10	概率	Brownian 指数泛函的幂极限	Brownian 缩放、最大值渐近、Laplace 原理	渐近扩展
[26S-Q5]	10	概率	Galton–Watson 基础	条件 PGF、迭代、固定点、灭绝概率	分枝过程扩展

题号	分值	类别	主要标签	核心工具	题型/扩展
[26S-Q6]	15	概率	继承性质零一律、树上渗流	分枝性质、固定点、有效后代均值	分枝/渗流扩展
[26S-Q7]	10	统计	变量变换、MLR、UMP	$\sqrt{X}$ 指数化、Karlin–Rubin、卡方临界值	检验
[26S-Q8]	15	统计	离散总体样本分位数	经验 CDF、LLN、分位数跳跃、反例	非正则分位数
[26S-Q9]	10	统计	两点先验、Bayes、minimax	后验赔率、绝对损失、常风险 Bayes	决策扩展
[26S-Q10]	10	统计	Poisson 复合参数、UMVUE 与 MLE 等价	完全充分性、阶乘矩、Delta/概率收敛	综合
[26S-Q11]	15	统计	skew-normal、MLE 存在性、精确 t 检验	条件积分、参数边界、Student 枢轴量	综合非正则

33.3 五套真题主题分布概览

主题	24S	24F	25S	25F	26S
收敛、LLN、CLT、Delta	✓	✓	✓	✓	✓
鞅、停时、随机游动	✓	✓	✓	✓	✓
Brownian motion	✓	✓	✓	✓	✓
Markov 链或随机网络	✓	✓			
分枝过程/随机过程扩展					✓
充分性、完全性、UMVUE	✓	✓	✓	✓	✓
MLE 与渐近分布	✓	✓	✓		✓
检验、UMP、MLR	✓	✓	✓	✓	✓
Bayes/决策/minimax/admissibility	✓	✓	✓	✓	✓
线性模型		✓			
非正则模型	✓	✓	✓	✓	✓

注 33.1. 上表只表示某主题在相应试卷中是否出现，不以主观印象替代逐题映射。同一道题可能同时属于多个主题，例如：[25S-Q11] 同时涉及 MLE、次序统计量、无记忆性、非正则渐近和联合分布。

33.4 高频题分类

母题	识别信号	标准解法
非标准 CLT	无穷方差、三角阵、稀有大值	特征函数或 Lindeberg；先选归一化。
极值几乎处处极限	最大值、最小值、limsup	尾概率 +Borel–Cantelli。
首达时间	随机游动/Brownian hitting time	指数鞅、调和函数、可选停止。
条件期望计算	给定最大值、和或统计量	联合密度、交换性、充分性。

母题	识别信号	标准解法
UMVUE	“最佳无偏估计”	找完全充分统计量，再构造无偏函数。
MLE 存在性	开参数空间、边界、支持依赖参数	分析似然全局形状，不只解 score。
一侧 UMP	一维参数、指数族、一侧备择	MLR+Karlin–Rubin。
双侧 UMP 不存在	左右备择要求相反拒绝域	选两个简单备择，用 NP 唯一性反证。
Bayes/minimax	给先验、损失或要求最坏风险	最小化后验风险；常风险或 Bayes risk 下界。
admissibility	问是否被支配	投影、缩放、proper Bayes 唯一性。
非正则渐近	极端次序统计量、参数依赖支持	求精确尾概率，识别 n 速度和非正态极限。



第四部分

模拟试题



第三十四章 模拟试题

为了方便大家准备,我出了五套概率与统计博资考的模拟题目,题目风格都和往年差不多,难度会比往年稍微高一点。做题的时候请不要偷看前面的内容。

最后两套试卷的计算量和难度比之前显著大,它可能更适合查漏补缺。如果你很想拿来自测,你可以适当增加做题时间。

希望你能从这些试卷里面学到一些东西!

34.1 第一套试题

Problem 1 (10 分)

设 $r \in \mathbb{N}$, 且 $b, c_1, c_2 > 0$ 。随机变量 Λ 服从 $\text{Gamma}(r, b)$ 。在给定 $\Lambda = \lambda$ 的条件下, 随机变量 X, Y 条件独立, 并且

$$X \mid \Lambda = \lambda \sim \text{Poisson}(c_1 \lambda), \quad Y \mid \Lambda = \lambda \sim \text{Poisson}(c_2 \lambda).$$

(a) (3 分) 求 (X, Y) 的联合概率生成函数

$$G(s, t) = \mathbb{E} [s^X t^Y], \quad 0 \leq s, t \leq 1,$$

(b) (4 分) 计算 $\mathbb{E}X$, $\mathbb{E}Y$, $\text{Var}(X)$, $\text{Var}(Y)$, $\text{Cov}(X, Y)$, $\text{Corr}(X, Y)$ 。

(c) (3 分) 对任意 $x, y \in \{0, 1, 2, \dots\}$, 求

$$\Lambda \mid (X = x, Y = y)$$

的后验分布及后验均值。

Problem 2 (15 分)

固定常数 $\lambda > 0$ 。对每个满足 $n > \lambda$ 的整数 n , 令

$$\varepsilon_{n,1}, \dots, \varepsilon_{n,n}, \quad \eta_{n,1}, \dots, \eta_{n,n}$$

相互独立, 并满足

$$\mathbb{P}(\varepsilon_{n,k} = 1) = \mathbb{P}(\varepsilon_{n,k} = -1) = \frac{1}{2},$$

以及

$$\mathbb{P}(\eta_{n,k} = 1) = \mathbb{P}(\eta_{n,k} = -1) = \frac{\lambda}{2n}, \quad \mathbb{P}(\eta_{n,k} = 0) = 1 - \frac{\lambda}{n}.$$

不同 n 所对应的全部随机变量亦假设相互独立。定义

$$R_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k}, \quad J_n = \sum_{k=1}^n \eta_{n,k}, \quad S_n = R_n + J_n.$$



- (a) (7 分) 求 S_n 的分布极限, 并将极限随机变量表示为若干相互独立的熟知随机变量 (比如正态分布、指数分布、几何分布、泊松分布等等) 之和或差。
- (b) (4 分) 定义

$$A_n = \frac{1}{n} \sum_{k=1}^n \varepsilon_{n,k} + \frac{1}{\sqrt{n}} \sum_{k=1}^n \eta_{n,k}.$$

分别判断 A_n 是否依概率收敛及是否在 L^2 中收敛, 并给出相应极限。

- (c) (4 分) 判断随机变量族 $\{S_n^2 : n > \lambda\}$ 是否一致可积, 并证明你的结论。

Problem 3 (10 分)

设 $\{N_t : t \geq 0\}$ 是强度为 $\lambda > 0$ 的 Poisson 过程。固定 $T > 0$, 定义

$$A_T = \int_0^T N_s \, ds.$$

- (a) (5 分) 求 $\mathbb{E}[A_T | \sigma(N_T)]$ 和 $\text{Var}(A_T | \sigma(N_T))$ 的具体值。
- (b) (5 分) 对 $0 \leq z \leq 1$ 和 $u > 0$, 求联合变换 $\mathbb{E}[z^{N_T} e^{-u A_T}]$, 并计算 $\text{Cov}(A_T, N_T)$ 。

Problem 4 (10 分)

设 $p \in (0, 1)$, $q = 1 - p$ 。考虑状态空间为 $\mathcal{S} = \{0, 1, 2, \dots\}$ 的时间齐次 Markov 链 $\{X_n : n \geq 0\}$, 其转移概率为 $P(0, 0) = q, P(0, 1) = p$, 且对每个 $i \geq 1$, $P(i, i+1) = p, P(i, i-1) = q$ 。记

$$\tau_0^+ = \inf\{n \geq 1 : X_n = 0\}.$$

- (a) (5 分) 对 $p < q$ 、 $p = q$ 和 $p > q$ 三种情形, 分别判断该链是正常返、零常返还是暂留, 并证明你的结论。
- (b) (5 分) 在 $p < q$ 时, 求该链的平稳分布 π , 计算

$$\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j), \quad i, j \in \mathcal{S},$$

并求 $\mathbb{E}_0[\tau_0^+]$ 。


Problem 5 (15 分)

固定 $p \in (1/2, 1)$ 。构造如下连续时间分枝 Brownian 系统。

在时刻 0, 只有一个位于原点的粒子。每个存活粒子独立地按照标准 Brownian motion 运动, 并具有参数为 1 的指数寿命。一个粒子寿命结束时以概率 p 产生两个子粒子, 以概率 $1 - p$ 不产生子粒子。子粒子从母粒子死亡时的位置出发, 并按照相同规则独立演化。

记 $\mathcal{N}_t$ 为时刻 t 的存活粒子集合, $N_t = |\mathcal{N}_t|$ 并以 $X_u(t)$ 表示粒子 $u \in \mathcal{N}_t$ 在时刻 t 的位置。令 $\{\mathcal{F}_t\}$ 为该系统的自然滤过。

- (a) (4 分) 求 $\mathbb{E}[N_t]$ 以及该系统最终灭绝的概率。



(b) (6 分) 对任意固定 $\theta \in \mathbb{R}$, 定义

$$W_t(\theta) = \exp \left\{ - \left(2p - 1 + \frac{\theta^2}{2} \right) t \right\} \sum_{u \in \mathcal{N}_t} e^{\theta X_u(t)}.$$

证明 $\{W_t(\theta) : t \geq 0\}$ 是关于 $\{\mathcal{F}_t\}$ 的鞅, 并求其期望。

(c) (5 分) 定义 $M_t = \max_{u \in \mathcal{N}_t} X_u(t)$, 并约定当 $N_t = 0$ 时 $M_t = -\infty$ 。证明: 对任意 $a > \sqrt{2(2p-1)}$ 均有

$$\lim_{t \rightarrow \infty} \mathbb{P}(M_t \geq at) = 0.$$

Problem 6 (10 分)

设 $\xi_1, \xi_2, \dots$ 为独立同分布的随机变量, 且 $\mathbb{P}(\xi_k = 1) = \mathbb{P}(\xi_k = -1) = \frac{1}{2}$ 。定义简单对称随机游动

$$S_0 = 0, \quad S_k = \sum_{j=1}^k \xi_j,$$

以及

$$M_{2n} = \max_{0 \leq k \leq 2n} S_k.$$

(a) (5 分) 对整数 $1 \leq a \leq n$, 计算 $\mathbb{P}(M_{2n} < a \mid S_{2n} = 0)$ 。

(b) (5 分) 对每个 $x > 0$, 求极限 $\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{M_{2n}}{\sqrt{2n}} < x \mid S_{2n} = 0\right)$ 。

Problem 7 (10 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), \quad \mu \in \mathbb{R}, \quad \sigma > 0,$$

其中 $n = 2m + 1$ 为奇数。记

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2,$$

并令样本中位数为 $\tilde{X}_n = X_{(m+1)}$ 。

(a) (3 分) 求 $\tilde{X}_n$ 的精确密度函数。

(b) (5 分) 当 $n \rightarrow \infty$ 且 n 沿奇数取值时, 求二维随机向量 $\sqrt{n} \begin{pmatrix} (\bar{X}_n - \mu)/\sigma \\ (\tilde{X}_n - \mu)/\sigma \end{pmatrix}$ 的极限分布, 并将其协方差矩阵写成显式常数矩阵。

(c) (2 分) 求 $\frac{\sqrt{n}(\tilde{X}_n - \bar{X}_n)}{S_n}$ 的极限分布。

Problem 8 (15 分)

设 $n \geq 2$, 且 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Gamma}(2, \lambda)$, 其中 $\lambda > 0$, 即 $f(x \mid \lambda) = \lambda^2 x e^{-\lambda x} \mathbf{1}_{\{x > 0\}}$ 。定义 $T = \sum_{i=1}^n X_i, U = \frac{X_1}{T}$ 。

(a) (6 分) 判断 T 是否为 λ 的极小充分统计量及完全统计量, 并证明你的结论。

(b) (4 分) 求 U 的分布。判断 U 是否为辅助统计量, 并判断 U 与 T 是否独立。

(c) (5 分) 固定 $c > 0$, 求 $\psi(\lambda) = \mathbb{P}_\lambda(X_1 > c)$ 的一致最小方差无偏估计量, 并将答案写成 T 的显式函数。

Problem 9 (10 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), \quad \mu \in \mathbb{R}, \quad \sigma^2 > 0.$$

给定如下层次先验:

$$\mu | \sigma^2 \sim N\left(m_0, \frac{\sigma^2}{\kappa_0}\right), \quad \sigma^2 \sim \text{IG}(\alpha_0, \beta_0),$$

其中 $\kappa_0 > 0, \alpha_0 > 2, \beta_0 > 0$, 且逆 Gamma 分布采用密度

$$\pi(v) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} v^{-\alpha_0-1} \exp\left(-\frac{\beta_0}{v}\right) \mathbf{1}_{\{v>0\}}.$$

(a) (4 分) 求 $(\mu, \sigma^2) | X_1, \dots, X_n$ 的联合后验分布, 并给出全部后验超参数。

(b) (3 分) 分别在平方误差损失

$$L_\mu(\mu, a) = (a - \mu)^2, \quad L_{\sigma^2}(\sigma^2, d) = (d - \sigma^2)^2$$

下, 求 μ 和 σ^2 的 Bayes 估计量。

(c) (3 分) 求新观测 X_{n+1} 的后验预测分布。将其写成位置-尺度 Student t 分布, 并进一步写出相应标准化随机变量平方后的分布。

Problem 10 (15 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x | \theta), \quad \theta > 0,$$

其中

$$f(x | \theta) = \frac{2x}{\theta^2} \exp\left(-\frac{x^2}{\theta^2}\right) \mathbf{1}_{\{x>0\}}.$$

(a) (5 分) 基于一阶原点矩求 θ 的矩估计量, 并求最大似然估计量。证明二者均为相合估计量。

(b) (5 分) 计算单个观测所含的 Fisher 信息。求上述两个估计量的渐近分布, 并比较二者的渐近相对效率。

(c) (5 分) 考虑检验

$$H_0: \theta = \theta_0 \quad \text{对} \quad H_1: \theta \neq \theta_0,$$


其中 $\theta_0 > 0$ 已知。

推导广义似然比统计量, 并将 $-2 \log \Lambda_n$ 写成 $\hat{\theta}/\theta_0$ 的显式函数。指出在 H_0 下一个相关枢轴量的精确分布, 给出渐近 level α 的拒绝域, 并写出由该似然比统计量反演得到的渐近 $1 - \alpha$ 置信集。

Problem 11 (10 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Beta}(\theta, 1), \quad \theta > 0,$$



即 $f(x | \theta) = \theta x^{\theta-1} \mathbf{1}_{\{0 < x < 1\}}$ 。定义 $T = -\sum_{i=1}^n \log X_i$ 。

(a) (4 分) 对已知 $\theta_0 > 0$ ，构造检验

$$H_0 : \theta \leq \theta_0 \quad \text{对} \quad H_1 : \theta > \theta_0$$

的 size α 一致最大功效检验。将拒绝域写成卡方分位数的形式，并求其功效函数。

(b) (3 分) 对

$$H_0 : \theta = \theta_0 \quad \text{对} \quad H_1 : \theta \neq \theta_0,$$

判断当 $0 < \alpha < 1/2$ 时是否存在 size α 的一致最大功效检验，并严格论证你的结论。

(c) (3 分) 构造 θ 的精确等尾 $1 - \alpha$ 置信区间。



34.2 第二套试题

Problem 1 (10 分)

设 $X_1, X_2, X_3 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 并定义

$$R = \sqrt{X_1^2 + X_2^2 + X_3^2}, \quad V = \frac{X_1 + X_2 + X_3}{R}.$$

由于 $\mathbb{P}(R=0)=0$, 上述 V 几乎处处有定义。

- (1) 求随机向量 (R, V) 的联合密度, 明确写出其支持集, 并判断 R 与 V 是否独立。
- (2) 求条件期望 $\mathbb{E}(R | \sigma(V))$.
- (3) 计算 $\text{Corr}(R^2, (X_1 + X_2 + X_3)^2)$.

Problem 2 (15 分)

固定 $\lambda \in (0, 1]$. 对每个 $n \geq 1$, 设 $\{\varepsilon_{n,k}, J_{n,k} : 1 \leq k \leq n\}$ 相互独立, 其中 $\mathbb{P}(\varepsilon_{n,k} = 1) = \mathbb{P}(\varepsilon_{n,k} = -1) = \frac{1}{2}$, 且

$$\mathbb{P}(J_{n,k} = 1) = \mathbb{P}(J_{n,k} = -1) = \frac{\lambda}{2n}, \quad \mathbb{P}(J_{n,k} = 0) = 1 - \frac{\lambda}{n}.$$

定义

$$\xi_{n,k} = \frac{\varepsilon_{n,k}}{\sqrt{n}} + J_{n,k}, \quad S_n = \sum_{k=1}^n \xi_{n,k}, \quad Q_n = \sum_{k=1}^n \xi_{n,k}^2.$$

- (1) 求 (S_n, Q_n) 的联合弱极限。要求用三个相互独立的随机变量

$$Z \sim N(0, 1), \quad N_+ \sim \text{Poisson}(\lambda/2), \quad N_- \sim \text{Poisson}(\lambda/2)$$

明确表示该极限。

- (2) 求 $\frac{S_n}{\sqrt{Q_n}}$ 的极限分布。
- (3) 判断随机变量族 $\{S_n^2 : n \geq 1\}$ 是否一致可积, 并求 $\lim_{n \rightarrow \infty} \mathbb{E}(S_n^2)$.

Problem 3 (10 分)

设 $\{\varepsilon_k\}_{k \geq 1}$ 为独立同分布随机变量, 且 $\mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}$. 令 $\mathcal{F}_n = \sigma(\varepsilon_1, \dots, \varepsilon_n)$, $M_0 = 1$, 并对 $n \geq 1$ 定义 $M_n = \prod_{k=1}^n \left(1 + \frac{\varepsilon_k}{\sqrt{k+1}}\right)$.

- (1) 证明 $\{M_n, \mathcal{F}_n\}_{n \geq 0}$ 是一个非负鞅, 并证明存在有限随机变量 M_∞ 使得 $M_n \rightarrow M_\infty$ a.s..
- (2) 确定 M_∞ 的值, 并判断 M_n 是否在 L^1 中收敛。进一步判断随机变量族 $\{M_n : n \geq 0\}$ 是否一致可积。

Problem 4 (10 分)

设 $\{X_n\}_{n \geq 0}$ 是状态空间 $\mathcal{S} = \{0, 1, 2, \dots\}$ 上的时齐 Markov 链, 其转移概率为 $P(0, 1) = 1$, 且对每个 $i \geq 1$, $P(i, i+1) = \frac{i+1}{2i+1}$, $P(i, i-1) = \frac{i}{2i+1}$. 对 $j \in \mathcal{S}$, 定义 $\tau_j = \inf\{n \geq 0 : X_n = j\}$.

- (1) 对整数 $m \geq 2$ 和 $1 \leq i \leq m-1$, 求 $\mathbb{P}_i(\tau_m < \tau_0)$. 其中 $\mathbb{P}_i$ 表示在 $X_0 = i$ 条件下的概率。
- (2) 判断该链是暂留、正常返还是零常返, 并求其周期。

(3) 求一个严格正的可逆测度 $\{\pi_i\}_{i \geq 0}$ 。判断该链是否存在平稳概率分布。

Problem 5 (10 分)

设 $\{N_t\}_{t \geq 0}$ 是强度为 $\lambda > 0$ 的 Poisson 过程, 并定义 $A_t = \int_0^t N_s \, ds, \quad t \geq 0$ 。

- (1) 对任意 $u, v \geq 0$, 求联合 Laplace 变换 $\mathbb{E}[\exp\{-uN_t - vA_t\}]$ 。在 $v = 0$ 时, 答案中出现的 $\frac{1-e^{-vt}}{v}$ 按连续延拓定义为 t 。
- (2) 求 $\mathbb{E}(A_t | \sigma(N_t))$ 和 $\text{Var}(A_t | \sigma(N_t))$ 。
- (3) 对 $0 < s \leq t$, 计算 $\text{Cov}(A_s, A_t)$ 。

Problem 6 (15 分)

设 $\{B_t\}_{0 \leq t \leq 1}$ 是从 0 出发的一维标准 Brownian motion, 并定义 Brownian bridge

$$W_t = B_t - tB_1, \quad 0 \leq t \leq 1.$$

令

$$K(s, t) = \min\{s, t\} - st, \quad e_k(t) = \sqrt{2} \sin(k\pi t), \quad k \geq 1,$$

以及 $A = \int_0^1 W_t^2 \, dt$ 。

- (1) 求 W 的均值函数和协方差函数, 并证明对每个 $k \geq 1$,

$$\int_0^1 K(s, t) e_k(s) \, ds = \frac{1}{k^2 \pi^2} e_k(t).$$

- (2) 定义 $Z_k = k\pi \int_0^1 W_t e_k(t) \, dt, k \geq 1$ 。证明 $\{Z_k\}_{k \geq 1}$ 是独立同分布的标准正态随机变量, 并证明 $A = \sum_{k=1}^{\infty} \frac{Z_k^2}{k^2 \pi^2}$ a.s.。
- (3) 对任意 $\theta \geq 0$, 求 $\mathbb{E}(e^{-\theta A})$ 的收敛无穷乘积表达式, 并计算 $\mathbb{E}(A)$ 和 $\text{Var}(A)$ 。

Problem 7 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x; \theta), \theta > 0$, 其中

$$f(x; \theta) = \sqrt{\frac{2}{\pi}} \frac{x^2}{\theta^3} \exp\left(-\frac{x^2}{2\theta^2}\right) \mathbf{1}_{\{x>0\}}.$$

- (1) 分别构造基于二阶原点矩 $\mathbb{E}_\theta(X^2)$ 的矩估计量和 θ 的最大似然估计量, 并判断二者是否相同。
- (2) 求最大似然估计量的有限样本精确分布, 并据此构造 θ 的一个精确 $1 - \alpha$ 置信区间。
- (3) 求单个观测关于 θ 的 Fisher 信息, 并求最大似然估计量的渐近分布。

Problem 8 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), \quad \mu \in \mathbb{R}, \quad \sigma^2 > 0, \quad n \geq 4$ 。定义 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 以及 $T = (\bar{X}, S^2)$ 。在事件 $\{S > 0\}$ 上定义 $A_i = \frac{X_i - \bar{X}}{S}, \quad i = 1, \dots, n$, 并在零概率事件 $\{S = 0\}$ 上令 $A_i = 0$ 。记 $A = (A_1, \dots, A_n)$ 。

- (1) 证明 T 是参数 (μ, σ^2) 的极小充分统计量, 并判断 T 是否完全; 对你的结论给出严格证明。
- (2) 证明 A 是辅助统计量, 并判断随机向量 A 与统计量 T 是否独立。
- (3) 求随机变量 $\frac{nA_1^2}{(n-1)^2}$ 的分布, 并计算 $\mathbb{E}(A_1^4)$ 。

Problem 9 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{IG}(\mu, \lambda)$, 其中 $\lambda > 0$ 已知, $\mu > 0$ 未知。这里 $\text{IG}(\mu, \lambda)$ 表示逆高斯分布, 其密度为 $f(x; \mu, \lambda) = \left(\frac{\lambda}{2\pi x^3}\right)^{1/2} \exp\left\{-\frac{\lambda(x-\mu)^2}{2\mu^2 x}\right\} \mathbf{1}_{\{x>0\}}$ 。记 $F_{\mu, \lambda}$ 为该分布的分布函数。

- (1) 求 μ 的最大似然估计量和单个观测关于 μ 的 Fisher 信息, 并求最大似然估计量的渐近分布。
- (2) 确定 $S_n = \sum_{i=1}^n X_i$ 的分布。进而构造检验 $H_0: \mu \leq \mu_0$ 对 $H_1: \mu > \mu_0$ 的 size α 一致最大功效检验, 并写出该检验在任意 $\mu > 0$ 处的功效函数。
- (3) 对双侧问题 $H_0: \mu = \mu_0$ 对 $H_1: \mu \neq \mu_0$, 推导广义似然比统计量, 并将 $-2 \log \Lambda_n$ 化为 $\bar{X}$ 、 μ_0 、 λ 和 n 的显式函数。给出其在 H_0 下的渐近分布以及渐近 level α 的拒绝域。

Problem 10 (10 分)

给定参数 $\lambda > 0$, 设 $X_1, \dots, X_n | \lambda \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$ 。 λ 的先验分布采用形状-率参数化: $\lambda \sim \text{Gamma}(a, b)$, $a \in \{2, 3, \dots\}$, $b > 0$, 其密度为 $\pi(\lambda) = \frac{b^a}{\Gamma(a)} \lambda^{a-1} e^{-b\lambda} \mathbf{1}_{\{\lambda>0\}}$ 。另设在给定 λ 后, $Y | \lambda \sim \text{Poisson}(c\lambda)$, $c > 0$, 且 Y 与 $X_1, \dots, X_n$ 条件独立。记 $S = \sum_{i=1}^n X_i$ 。

- (1) 求 $\lambda | X_1, \dots, X_n$ 的后验分布。
- (2) 分别求下列两个损失函数下 λ 的 Bayes 估计量: $L_1(\lambda, d) = (d - \lambda)^2$, $d \in \mathbb{R}$, 以及 $L_2(\lambda, d) = \frac{d}{\lambda} - \log\left(\frac{d}{\lambda}\right) - 1$, $d > 0$ 。
- (3) 求后验预测分布 $\mathbb{P}(Y = y | X_1, \dots, X_n)$, $y = 0, 1, 2, \dots$, 并将其识别为某个明确参数化的负二项分布。

Problem 11 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x; \theta)$, $f(x; \theta) = \theta x^{\theta-1} \mathbf{1}_{\{0 < x < 1\}}$, $\theta > 0$ 。记 F_n 为经验分布函数。对固定的 $p \in (0, 1)$, 定义总体 p 分位数和样本 p 分位数 $\xi_p = \inf\{x : F_\theta(x) \geq p\}$, $\hat{\xi}_{p,n} = \inf\{x : F_n(x) \geq p\}$, 并定义分位数估计量 $\tilde{\theta}_{p,n} = \frac{\log p}{\log \hat{\xi}_{p,n}}$ 。

- (1) 求 θ 的最大似然估计量 $\hat{\theta}_n$, 证明其相合性, 并求 $\sqrt{n}(\hat{\theta}_n - \theta)$ 的极限分布。
- (2) 证明 $\tilde{\theta}_{p,n}$ 相合, 并求 $\sqrt{n}(\tilde{\theta}_{p,n} - \theta)$ 的极限分布。
- (3) 以 $\text{ARE}(\tilde{\theta}_{p,n}, \hat{\theta}_n) = \frac{\hat{\theta}_n \text{ 的渐近方差}}{\tilde{\theta}_{p,n} \text{ 的渐近方差}}$ 定义分位数估计量相对于最大似然估计量的渐近相对效率。求使该渐近相对效率最大的 $p \in (0, 1)$; 可以用一个明确的方程刻画该最优值。



34.3 第三套试题

Problem 1 (10 分)

设 $N \sim \text{Poisson}(\lambda)$, $\lambda > 0$. 给定 $N = n$ 后, 将 n 个对象相互独立地分入三类, 每个对象进入第 j 类的概率为 p_j , 其中 $p_j > 0$, $p_1 + p_2 + p_3 = 1$. 记三类对象的个数分别为 Y_1, Y_2, Y_3 , 因而 $Y_1 + Y_2 + Y_3 = N$.

- (1) 求 (Y_1, Y_2, Y_3) 的联合概率质量函数和联合概率生成函数 $G(z_1, z_2, z_3) = \mathbb{E}[z_1^{Y_1} z_2^{Y_2} z_3^{Y_3}]$. 由此确定 Y_1, Y_2, Y_3 的边缘分布, 并判断三者是否相互独立。
- (2) 令 $S = Y_1 + Y_2$. 分别求 $\text{Law}(Y_1 | \sigma(S))$, $\text{Law}(N | \sigma(S))$, 并求 $\mathbb{E}(Y_1 | \sigma(S))$, $\mathbb{E}(N | \sigma(S))$.
- (3) 求随机向量 $(Y_1, Y_2, Y_3, N)^\top$ 的协方差矩阵, 并计算 $\text{Corr}(Y_j, N)$, $j = 1, 2, 3$.

Problem 2 (15 分)

设 $\{\varepsilon_k : k \geq 1\}$ 为相互独立的 Rademacher 随机变量, 即 $\mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}$. 另设 $\{B_k : k \geq 1\}$ 相互独立, 且与所有 ε_k 独立, 并满足 $\mathbb{P}(B_k = 1) = \frac{1}{(k+1)^2}$, $\mathbb{P}(B_k = 0) = 1 - \frac{1}{(k+1)^2}$. 定义 $X_k = \varepsilon_k(1 + kB_k)$, $S_n = \sum_{k=1}^n X_k$.

- (1) 令 $R_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_k$. 求 R_n 的特征函数, 并直接由特征函数证明 $R_n \xrightarrow{d} N(0, 1)$.
- (2) 求 $S_n/\sqrt{n}$ 的极限分布. 随后计算 $\text{Var}(S_n)$, 并求 $\frac{S_n}{\sqrt{\text{Var}(S_n)}}$ 的极限分布.
- (3) 证明 $\frac{S_n^2}{n} \xrightarrow{d} \chi_1^2$, 但随机变量族 $\left\{\frac{S_n^2}{n} : n \geq 1\right\}$ 不是一致可积的. 说明这一现象为什么不与依分布收敛相矛盾.

Problem 3 (10 分)

设 $\{X_n : n \geq 0\}$ 是状态空间 $S = \{0, 1, 2\}$ 上的时间齐次 Markov 链, 其转移矩阵为 $P = \begin{pmatrix} 0 & 1 & 0 \\ p & 0 & 1-p \\ 0 & 1 & 0 \end{pmatrix}$, $0 < p < 1$.

- (1) 判断该链是否不可约, 求各状态的周期, 并求其所有平稳分布. 判断该链在所求平稳分布下是否可逆.
- (2) 求 P^n . 对每个 $i, j \in S$, 分别求 $\lim_{n \rightarrow \infty} P^{2n}(i, j)$, $\lim_{n \rightarrow \infty} P^{2n+1}(i, j)$. 由此判断从任意确定初始状态出发时, $\text{Law}(X_n)$ 是否必然收敛.
- (3) 定义另一条 Markov 链的转移矩阵 $Q = \frac{1}{2}(I + P)$. 判断 Q 对应的链是否不可约、非周期和可逆, 并求 $\lim_{n \rightarrow \infty} Q^n(i, j)$, $i, j \in S$.

Problem 4 (15 分)

设 $\{B_t : t \geq 0\}$ 为从 0 出发的一维标准 Brownian motion. 给定 $a, b > 0$, 定义首次离开区间 $(-a, b)$ 的时间 $\tau = \inf\{t \geq 0 : B_t \notin (-a, b)\}$.

- (1) 证明 $\tau < \infty$ a.s. 并求 $\mathbb{P}(B_\tau = b)$, $\mathbb{P}(B_\tau = -a)$, $\mathbb{E}\tau$.
- (2) 对任意 $\lambda > 0$, 求下列两个量的闭式表达式: $\mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=b\}}]$, $\mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=-a\}}]$. 由此求 $\mathbb{E}e^{-\lambda\tau}$.
- (3) 在区间 $[0, 1]$ 上定义过程 $W_t = B_t - tB_1$. 证明整个过程 $\{W_t : 0 \leq t \leq 1\}$ 与随机变量 B_1 独立, 并求 $\mathbb{E}W_t$, $\text{Cov}(W_s, W_t)$. 对任意 $0 \leq t_1 < \dots < t_k < 1$, 写出 $(B_{t_1}, \dots, B_{t_k})$ 在给定 $B_1 = 0$ 条件下的条件

分布。

Problem 5 (10 分)

设 $m \geq 3$, 在循环群 $\mathbb{Z}/m\mathbb{Z} = \{0, 1, \dots, m-1\}$ 上考虑简单随机游动 $\{X_n : n \geq 0\}$: 在每一步中, 游动者以相同概率移动到两个相邻顶点, 即 $X_{n+1} = X_n + 1 \pmod{m}$ 或 $X_{n+1} = X_n - 1 \pmod{m}$, 两种情况各以概率 $1/2$ 发生。

- (1) 判断该链是否不可约, 并根据 m 的奇偶性确定其周期。求其平稳分布, 并判断该平稳分布是否可逆。
- (2) 对 $i \in \{1, \dots, m-1\}$, 令 $T_0 = \inf\{n \geq 0 : X_n = 0\}$ 。求 $\mathbb{E}_i T_0$ 。
- (3) 定义从 0 出发的首次正返时间 $T_0^+ = \inf\{n \geq 1 : X_n = 0\}$ 。求 $\mathbb{E}_0 T_0^+$ 。判断该答案是否依赖 m 的奇偶性, 并说明原因。

Problem 6 (10 分)

设 $\{N_t : t \geq 0\}$ 为强度 $\lambda > 0$ 的 Poisson process, 其自然过滤记为 $\mathcal{F}_t = \sigma(N_s : 0 \leq s \leq t)$ 。令 $T_k = \inf\{t \geq 0 : N_t \geq k\}$, $k \geq 1$, 为第 k 个到达时刻。

- (1) 求 T_k 的分布、密度、均值、方差和矩母函数的存在区间。
- (2) 对 $0 \leq s \leq t$, 求 $\mathbb{E}(N_t | \mathcal{F}_s)$ 和 $\mathbb{E}[(N_t - N_s)^2 | \mathcal{F}_s]$ 。判断并证明下列两个过程是否为鞅: $M_t = N_t - \lambda t$, $K_t = (N_t - \lambda t)^2 - \lambda t$ 。
- (3) 固定 $t > 0$ 和整数 $n \geq k$ 。求 $(T_1, \dots, T_n) | N_t = n$ 的联合密度, 并由此确定 $T_k | N_t = n$ 的分布。

Problem 7 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \Gamma(\alpha, \lambda)$, $n \geq 2$, 其中 shape 参数 $\alpha > 0$ 已知, rate 参数 $\lambda > 0$ 未知。定义 $T = \sum_{i=1}^n X_i$, $V_i = \frac{X_i}{T}$, $i = 1, \dots, n-1$, 并令 $V_n = 1 - \sum_{i=1}^{n-1} V_i$ 。

- (1) 求随机向量 $(T, V_1, \dots, V_{n-1})$ 的联合密度, 包括其完整支撑集。识别 T 与 $(V_1, \dots, V_n)$ 的分布, 并判断二者是否独立。特别地, 求 V_1 的边缘分布。
- (2) 证明 T 是参数 λ 的极大充分统计量且是完全统计量。证明 $(V_1, \dots, V_n)$ 是辅助统计量。说明这些结论与第 (a) 问所得独立性之间的关系。
- (3) 求总体均值 $m(\lambda) = \mathbb{E}_\lambda X_1 = \frac{\alpha}{\lambda}$ 和总体方差 $v(\lambda) = \text{Var}_\lambda(X_1) = \frac{\alpha}{\lambda^2}$ 的 UMVUE。
再给定 $0 < \delta < 1$, 构造 λ 的一个精确 $1 - \delta$ 置信区间。

Problem 8 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $n = 2r + 1 \geq 3$, 其中 $\mu \in \mathbb{R}$, $\sigma > 0$ 均未知。记样本中位数为 $M_n = X_{(r+1)}$, 样本均值和样本方差分别为 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。

- (1) 当 $n \rightarrow \infty$ 且始终取奇数时, 证明 $\sqrt{n}(M_n - \mu)$ 渐近正态, 并明确给出其渐近方差。将其与 $\sqrt{n}(\bar{X} - \mu)$ 的渐近方差比较, 并求样本中位数相对于样本均值的渐近相对效率。
- (2) 确定 $\bar{X}$ 与 S_X^2 的独立性及各自的精确分布。对任意 $0 < \delta < 1$, 分别构造 μ 和 σ^2 的精确 $1 - \delta$ 置信区间。
- (3) 另有与上述样本独立的随机样本 $Y_1, \dots, Y_m \stackrel{\text{i.i.d.}}{\sim} N(\nu, \tau^2)$, $m \geq 2$, 其样本方差为 S_Y^2 。构造方差比 $\frac{\sigma^2}{\tau^2}$ 的精确 $1 - \delta$ 置信区间。

Problem 9 (15 分)

设 $X_1, \dots, X_n$ 为来自密度族 $f(x | \theta) = \theta x^{\theta-1} \mathbb{1}_{\{0 < x < 1\}}$, $\theta > 0$, 的 iid 样本。定义 $T = -\sum_{i=1}^n \log X_i$.

- (1) 求 θ 的最大似然估计量 $\hat{\theta}_n$, 证明其强相合性, 并求 $\sqrt{n}(\hat{\theta}_n - \theta)$ 的极限分布。

求单个观测的 Fisher 信息 $I_1(\theta)$, 并说明 $\hat{\theta}_n$ 的渐近方差与信息下界之间的关系。

进一步求 $\sqrt{n}(\log \hat{\theta}_n - \log \theta)$ 的极限分布。

- (2) 固定 $\theta_0 > 0$ 和 $0 < \delta < 1$. 构造检验 $H_0: \theta \leq \theta_0$ 对 $H_1: \theta > \theta_0$ 的 size δ 一致最强检验, 并将拒绝域写成 T 的显式不等式。

求该检验在任意 $\theta > 0$ 下的功效函数, 并写出备择参数 $\theta_1 > \theta_0$ 下的第二类错误概率。

- (3) 考虑双侧检验 $H_0: \theta = \theta_0$ 对 $H_1: \theta \neq \theta_0$. 判断 size δ 的 UMP 检验是否存在, 并给出严格理由。推导该问题的广义似然比统计量。将精确 GLR 拒绝域写成 $T < c_1$ 或 $T > c_2$, 其中 $c_1 < \frac{n}{\theta_0} < c_2$. 允许用一个由两个方程组成的方程组刻画 c_1, c_2 , 但必须明确写出这两个方程。最后求在 H_0 下 $-2 \log \Lambda_n$ 的渐近分布。

Problem 10 (10 分)

给定参数 $\lambda > 0$ 后, 设 $X_1, \dots, X_n | \lambda \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$. 先验分布取为 $\lambda \sim \Gamma(a, b)$, 其中 $a \in \{2, 3, \dots\}$, $b > 0$ 均为已知常数。记 $S = \sum_{i=1}^n X_i$.

- (1) 求 λ 的后验分布。分别求其后验均值和后验众数, 并说明两者何时相等、何时不同。
- (2) 给定 λ 后, 设未来还有 m 个与原样本条件独立的观测 $X_{n+1}, \dots, X_{n+m} | \lambda \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, 并定义 $Y = \sum_{j=1}^m X_{n+j}$. 求 $Y | X_1, \dots, X_n$ 的后验预测分布, 将其识别为一个负二项分布, 并求其后验预测均值和方差。
- (3) 分别在下列两种损失函数下求 λ 的 Bayes 估计量: $L_1(\lambda, d) = (d - \lambda)^2$, $L_2(\lambda, d) = \frac{(d - \lambda)^2}{\lambda}$. 比较第二个 Bayes 估计量与第 (a) 问所得后验众数。

Problem 11 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(\theta, \theta+1)$, $\theta \in \mathbb{R}$, $n \geq 3$. 记 $X_{(1)} = \min_{1 \leq i \leq n} X_i$, $X_{(n)} = \max_{1 \leq i \leq n} X_i$.

- (1) 求 θ 的矩估计量。求最大似然估计量的全体最大化点, 并判断 MLE 是否唯一。定义所选取的一个 MLE 为 $\hat{\theta}_{\text{mid}} = \frac{X_{(1)} + X_{(n)} - 1}{2}$ 。
- (2) 求随机向量 $(n(X_{(1)} - \theta), n(\theta + 1 - X_{(n)}))$ 的联合极限分布, 并说明两个极限分量是否独立。由此求 $n(\hat{\theta}_{\text{mid}} - \theta)$ 的极限分布, 并写出该极限分布的密度。
- (3) 分别求矩估计量和 $\hat{\theta}_{\text{mid}}$ 的偏差与均方误差。对 $n \geq 3$, 比较两者在平方损失下的风险, 并比较两种估计量的收敛速度。



34.4 第四套试题

Problem 1 (10 分)

设 $X = (X_1, X_2, X_3, X_4)^\top \sim N_4(0, \Sigma_\rho)$, 其中 $\Sigma_\rho = (1 - \rho)I_4 + \rho \mathbf{1}\mathbf{1}^\top$, $\mathbf{1} = (1, 1, 1, 1)^\top$. 定义

$$S = \sum_{i=1}^4 X_i, \quad \bar{X} = \frac{S}{4}, \quad Q = \sum_{i=1}^4 (X_i - \bar{X})^2, \quad R = \sqrt{Q}.$$

- (1) 求使 Σ_ρ 正定的全部 ρ 的取值范围. 在该范围内, 求 (S, Q) 的联合分布, 并判断 S 与 Q 是否独立.
- (2) 推导 R 的密度, 求随机变量 $T = \frac{S/(2\sqrt{1+3\rho})}{\sqrt{Q/[3(1-\rho)]}}$ 的分布.
- (3) 求 $\mathbb{E}(X_1 | \sigma(S, Q))$, $\text{Cov}(X_1, Q)$, $\text{Cov}(X_1^2, Q)$. 据此判断 X_1 与 Q 是否独立, 并给出严格理由.

Problem 2 (15 分)

设 $\{\varepsilon_k : k \geq 1\}$ 为 iid Rademacher 随机变量, 即 $\mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}$. 令 $\mathcal{F}_n = \sigma(\varepsilon_1, \dots, \varepsilon_n)$, $M_n = \sum_{k=1}^n \frac{\varepsilon_k}{k}$.

- (1) 证明存在随机变量 M_∞ , 使 $M_n \xrightarrow{\text{a.s.}} M_\infty$ 且 $M_n \rightarrow M_\infty$ in L^2 . 求 $\mathbb{E}(M_\infty | \mathcal{F}_n)$, 并证明随机变量族 $\{M_n : n \geq 1\}$ 一致可积.
- (2) 求 M_∞ 的特征函数, 并将其写为收敛的无穷乘积. 进一步求 $\mathbb{E}M_\infty$, $\text{Var}(M_\infty)$, $\mathbb{E}(M_\infty^4)$, 并判断 M_∞ 是否服从正态分布.
- (3) 证明联合收敛 $(M_n, \sqrt{n}(M_\infty - M_n)) \xrightarrow{d} (M_\infty, Z)$, 其中 $Z \sim N(0, 1)$, 且极限中的 Z 与 M_∞ 独立.

Problem 3 (10 分)

设 $m \geq 3$, $\lambda > 0$, $0 < p < 1$, 并记 $q = 1 - p$. 令 $\{N_t : t \geq 0\}$ 为强度 λ 的 Poisson process, 令 $\{\xi_k : k \geq 1\}$ 为与该过程独立的 iid 随机变量, 满足 $\mathbb{P}(\xi_k = 1) = p$, $\mathbb{P}(\xi_k = -1) = q$. 令 $S_n = \sum_{k=1}^n \xi_k$, $X_t = i + S_{N_t} \pmod{m}$, $X_0 = i \in \{0, 1, \dots, m-1\}$.

- (1) 令 C_t 和 D_t 分别表示时刻 t 前取值为 $+1$ 和 -1 的跳数. 求 (C_t, D_t) 的联合概率生成函数和联合分布, 并求 $\mathbb{E}e^{iuS_{N_t}}$, $u \in \mathbb{R}$.
- (2) 求过程 $\{X_t : t \geq 0\}$ 的无穷小生成矩阵. 令 $\omega_r = e^{2\pi ir/m}$, $r = 0, 1, \dots, m-1$. 求转移概率 $p_t(i, j) = \mathbb{P}_i(X_t = j)$ 的显式有限和表达式.
- (3) 判断该连续时间 Markov chain 是否不可约, 求其平稳分布, 并确定它可逆的充要条件. 证明对任意 i, j , $\lim_{t \rightarrow \infty} p_t(i, j)$ 存在, 并求该极限.

Problem 4 (15 分)

设 $\{B_t : t \geq 0\}$ 为一维标准 Brownian motion. 对 $x \in (-a, b)$, 记 $\mathbb{P}_x$ 和 $\mathbb{E}_x$ 为从 $B_0 = x$ 出发时的概率和期望, 其中 $a > 0$, $b > 0$. 定义首次离开时间 $\tau = \inf\{t \geq 0 : B_t \notin (-a, b)\}$.

- (1) 对 $\lambda > 0$ 和 Borel 集 $A \subset (-a, b)$, 定义 $R_\lambda(x, A) = \mathbb{E}_x \left[\int_0^\tau e^{-\lambda t} \mathbb{1}_{\{B_t \in A\}} dt \right]$. 证明 $R_\lambda(x, \cdot)$ 关于 Lebesgue 测度绝对连续, 并求其密度 $r_\lambda(x, y)$, $x, y \in (-a, b)$, 的闭式表达式.
- (2) 对 $\theta \in \mathbb{R}$, 求 $U_\theta(x) = \mathbb{E}_x \left[\int_0^\tau e^{-\lambda t + \theta B_t} dt \right]$ 的闭式表达式. 当 $\theta^2 = 2\lambda$ 时, 答案应给出有限的连续延拓值, 而不能保留为未定式.

- (3) 给定 $q_- > 0$ 和 $q_+ > 0$, 令 $V(x) = q_- \mathbb{1}_{\{x < 0\}} + q_+ \mathbb{1}_{\{x \geq 0\}}$. 求 $\mathbb{E}_0[\exp\{-\int_0^\tau V(B_s) ds\}]$ 的闭式表达式, 并验证当 $q_- = q_+$ 时所得结果与常数折现率情形一致。

(提示: 利用双曲函数恒等式 $\frac{\operatorname{csch}(\gamma a) + \operatorname{csch}(\gamma b)}{\operatorname{coth}(\gamma a) + \operatorname{coth}(\gamma b)} = \frac{\cosh(\gamma(a-b)/2)}{\cosh(\gamma(a+b)/2)}.$)

Problem 5 (10 分)

设随机参数 $\Theta \sim \operatorname{Beta}(a, b)$, $a > 0$, $b > 0$, 其密度为 $\pi(\theta) = \frac{\theta^{a-1}(1-\theta)^{b-1}}{B(a, b)} \mathbb{1}_{\{0 < \theta < 1\}}$. 给定 Θ 后, 随机变量 $X_1, X_2, \dots$ 条件独立同分布, 且 $\mathbb{P}(X_k = 1 | \Theta) = \Theta$, $\mathbb{P}(X_k = 0 | \Theta) = 1 - \Theta$. 记 $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$, $S_n = \sum_{k=1}^n X_k$.

- (1) 求 $\Theta | \mathcal{F}_n$ 的条件分布, 以及 $\mathbb{P}(X_{n+1} = 1 | \mathcal{F}_n)$. 求任意 $i \neq j$ 时的 $\operatorname{Cov}(X_i, X_j)$, $\operatorname{Corr}(X_i, X_j)$, 并判断序列 $\{X_k\}$ 是否相互独立、是否交换。
- (2) 定义 $M_n = \mathbb{E}(\Theta | \mathcal{F}_n)$. 求 M_n 的显式表达式, 证明 $\{M_n, \mathcal{F}_n\}$ 为一致可积鞅, 并证明 $\frac{S_n}{n} \xrightarrow{\text{a.s.}} \Theta$, $M_n \xrightarrow{\text{a.s.}} \Theta$. 进一步确定对哪些 $p \in [1, \infty)$ 有 $M_n \rightarrow \Theta$ in L^p .

Problem 6 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $n = 2r + 1 \geq 3$, 其中 $\mu \in \mathbb{R}$, $\sigma > 0$ 均未知. 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, $M_n = X_{(r+1)}$. 另设 $Y_1, \dots, Y_m \stackrel{\text{i.i.d.}}{\sim} N(\nu, \tau^2)$, $m \geq 2$, 与 X -样本独立, 并定义样本方差 S_Y^2 与上式相同。

- (1) 求 $\bar{X}$, $\frac{(n-1)S_X^2}{\sigma^2}$, $\frac{(m-1)S_Y^2}{\tau^2}$ 的精确分布及其相互独立关系. 进一步求 $\frac{\sqrt{n}(\bar{X} - \mu)}{S_X}$, $\frac{S_X^2/\sigma^2}{S_Y^2/\tau^2}$ 的精确分布。
- (2) 当 $n \rightarrow \infty$ 且始终取奇数时, 求联合极限分布 $\sqrt{n} \begin{pmatrix} \bar{X} - \mu \\ M_n - \mu \end{pmatrix}$, 并明确给出极限协方差矩阵的每一个元素。
- (3) 求 $\frac{\sqrt{n}(M_n - \bar{X})}{S_X}$ 的极限分布. 计算样本中位数相对于样本均值的渐近相对效率, 并说明该效率的比较基于何种损失或评价标准。

Problem 7 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x | \theta) = \theta x^{\theta-1} \mathbb{1}_{\{0 < x < 1\}}$, $\theta > 0$, $n \geq 2$. 定义 $Y_i = -\log X_i$, $T = \sum_{i=1}^n Y_i$, $A = \frac{Y_1}{T}$.

- (1) 推导 (T, A) 的联合密度及完整支撑集, 并求二者的边缘分布. 判断 T 与 A 是否独立. 证明 T 是 θ 的极小充分且完全统计量, 并证明 A 是辅助统计量。
- (2) 固定 $c \in (0, 1)$. 分别求下列两个参数函数的 UMVUE: θ , $\mathbb{P}_\theta(X_1 \leq c) = c^\theta$. 两个答案均须写成观测样本的显式函数, 并验证其无偏性。
- (3) 对给定 $0 < \alpha < 1$, 构造 θ 的一个等尾、精确 $1 - \alpha$ 置信区间. 区间端点应使用 $\chi_{2n, \alpha/2}^2$, $\chi_{2n, 1-\alpha/2}^2$ 显式表示, 并严格说明覆盖概率。

Problem 8 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \operatorname{NegBin}(r, p)$, $r \in \mathbb{N}$ 已知, $0 < p < 1$, 其中 X_i 表示第 r 次成功前出现的失败次数, 即 $\mathbb{P}_p(X_i = x) = \binom{r+x-1}{x} p^r (1-p)^x$, $x = 0, 1, 2, \dots$. 记 $S = \sum_{i=1}^n X_i$.

- (1) 对给定 $p_0 \in (0, 1)$ 和 $0 < \alpha < 1$, 构造并严格证明一个 size 为 α 的一致最强检验, 用于检验 $H_0: p \leq p_0$ 对 $H_1: p > p_0$. 拒绝规则必须写成 S 的显式随机化阈值形式; 当非随机化阈值不能使 size 恰

等于 α 时, 必须给出随机化概率。

- (2) 求第 (a) 问检验的功效函数。明确写出在 $p \leq p_0$ 时的第一类错误概率、在 $p > p_0$ 时的第二类错误概率, 并证明功效函数关于 p 的单调性。
- (3) 考虑 $H_0: p = p_0$ 对 $H_1: p \neq p_0$ 。判断是否存在 size 为 α 的 UMP 检验, 并给出严格理由。同时推导该问题的广义似然比统计量; 当 $S = 0$ 时, 应明确说明所取的上确界及相应约定。

Problem 9 (10 分)

给定 $\lambda > 0$ 后, 设 $X_i | \lambda \sim \text{Poisson}(w_i \lambda)$, $i = 1, \dots, n$, 且在给定 λ 后相互独立, 其中 $w_i > 0$ 为已知暴露量。先验分布为 $\lambda \sim \text{Gamma}(a, b)$, $a > 1$, $b > 0$ 。记 $S = \sum_{i=1}^n X_i$, $W = \sum_{i=1}^n w_i$ 。

- (1) 先求给定总计数 S 后随机向量 $(X_1, \dots, X_n) | S$ 的条件概率质量函数, 并判断该条件分布是否依赖 λ 。随后求 $\lambda | X_1, \dots, X_n$ 的后验分布、后验均值和后验众数。说明后验众数位于参数空间内部所需的条件, 并比较后验均值与后验众数。
- (2) 给定 λ 后, 令未来计数 $Y | \lambda \sim \text{Poisson}(w_0 \lambda)$, $w_0 > 0$, 且 Y 与原样本条件独立。求 $Y | X_1, \dots, X_n$ 的后验预测概率质量函数, 将其识别为本卷约定下的负二项分布, 并求其后验预测均值和方差。
- (3) 固定 $c > 0$ 。在平方损失下求 $\tau(\lambda) = e^{-c\lambda}$ 的 Bayes 估计量。再在损失 $L(\lambda, d) = \frac{(d-\lambda)^2}{\lambda}$ 下求 λ 的 Bayes 估计量, 并与第 (a) 问的后验众数比较。

Problem 10 (15 分)

设 $a > 0$ 与 $\sigma > 0$ 为已知常数, 并设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathbf{N}(\theta, \sigma^2)$, $\theta \in \Theta := \{-a, a\}$, $n \geq 1$ 。行动空间为 $\mathcal{A} = \mathbb{R}$, 损失函数为平方损失 $L(\theta, d) = (d - \theta)^2$ 。对任意估计量 (决策规则) $\delta = \delta(X_1, \dots, X_n)$, 定义其风险函数为 $R(\theta, \delta) = \mathbb{E}_\theta[(\delta(X_1, \dots, X_n) - \theta)^2]$ 。记 $T = \sum_{i=1}^n X_i$ 。

- (1) 对 $p \in (0, 1)$, 考虑先验分布 $\pi_p(\theta) = p \mathbb{1}_{\{\theta=a\}} + (1-p) \mathbb{1}_{\{\theta=-a\}}$ 。求该先验下唯一的 Bayes 估计量 δ_p 及其 Bayes 风险 $r(p) = (1-p)R(-a, \delta_p) + pR(a, \delta_p)$ 。确定 $r(p)$ 在 $p \in [0, 1]$ 上的全部最大点。
- (2) 求该统计决策问题的 minimax risk, 并刻画全部 minimax 估计量; 在刻画时, 可以忽略在 P_{-a} 和 P_a 下均为零概率的样本集合上的差异。判断 minimax 估计量是否 admissible, 并严格证明结论。
- (3) 求 θ 的最大似然估计量 δ_{MLE} , 计算其风险函数, 并判断它是否为 minimax 估计量以及是否 admissible。若它不是 admissible 的, 给出一个严格支配它的估计量, 并证明严格支配关系。

Problem 11 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x | \theta) = \frac{1}{2}(x - \theta)^2 e^{-(x-\theta)} \mathbb{1}_{\{x > \theta\}}$, $\theta \in \mathbb{R}$ 。记 $X_{(1)} = \min_{1 \leq i \leq n} X_i$ 。

- (1) 求 θ 的最大似然估计量 $\hat{\theta}_n$ 。证明它以概率 1 存在且唯一, 并将其刻画为区间 $(-\infty, X_{(1)})$ 内某个方程的唯一解。
- (2) 证明 $\hat{\theta}_n$ 强相合, 并求 $\sqrt{n}(\hat{\theta}_n - \theta)$ 的极限分布。你的论证必须处理似然支撑依赖 θ 所造成的边界问题, 不能仅引用固定共同支撑下的通常 MLE 渐近正态定理。
- (3) 求 $n^{1/3}(X_{(1)} - \theta)$ 的极限分布, 并比较 $X_{(1)}$ 与 $\hat{\theta}_n$ 的收敛速度。计算单个观测在真参数处的形式 score 的均值与方差, 并说明本模型中“支撑依赖参数”与第 (b) 问所得极限之间为何并不矛盾。

34.5 第五套试题

Problem 1 (10 分)

设 $X_1, X_2, X_3, X_4 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $\bar{X} = \frac{1}{4} \sum_{i=1}^4 X_i$, 并定义

$$Z_0 = \frac{X_1 + X_2 + X_3 + X_4}{2}, \quad Z_1 = \frac{X_1 - X_2}{\sqrt{2}}, \quad Z_2 = \frac{X_1 + X_2 - 2X_3}{\sqrt{6}}, \quad Z_3 = \frac{X_1 + X_2 + X_3 - 3X_4}{\sqrt{12}}.$$

进一步令 $R = \sqrt{Z_1^2 + Z_2^2 + Z_3^2}$, $U = \begin{cases} Z_3/R, & R > 0, \\ 0, & R = 0. \end{cases}$

- (1) 确定随机向量 (Z_0, Z_1, Z_2, Z_3) 的联合分布, 并完整说明其各分量之间的独立关系。
- (2) 求 R 的概率密度、 U 的分布, 并判断 R 与 U 是否独立。
- (3) 计算 $\mathbb{E}[(X_1 - \bar{X})^2 | \sigma(R)]$ 以及 $\text{Cov}(\bar{X}, R^2)$.

Problem 2 (10 分)

固定常数 $\lambda_+ > 0$, $\lambda_- > 0$. 对每个充分大的正整数 n 以及 $1 \leq k \leq n$, 设 $\varepsilon_{n,k}$ 为取值 ± 1 、概率各为

$1/2$ 的随机变量, 并设 $J_{n,k} = \begin{cases} 1, & \text{概率为 } \lambda_+/n, \\ -1, & \text{概率为 } \lambda_-/n, \\ 0, & \text{概率为 } 1 - (\lambda_+ + \lambda_-)/n. \end{cases}$ 假设所有 $\{\varepsilon_{n,k}, J_{n,k} : n \geq 1, 1 \leq k \leq n\}$ 彼此

独立. 定义 $S_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k} + \sum_{k=1}^n J_{n,k}$.

- (1) 求 S_n 的极限分布, 并将极限随机变量表示为三个相互独立的标准分布随机变量之和或差。
- (2) 证明随机变量族 $\{S_n^2 : n \geq 1\}$ 一致可积, 并计算 $\lim_{n \rightarrow \infty} \mathbb{E}(S_n^2)$.
- (3) 另设事件 A_n 与上述所有随机变量独立, 且 $\mathbb{P}(A_n) = \frac{1}{n^2}$. 定义 $\tilde{S}_n = S_n + n^2 \mathbf{1}_{A_n}$. 分别判断 $\tilde{S}_n - S_n$ 是否依概率收敛、几乎处处收敛、依分布收敛以及在 L^1 中收敛, 并确定 $\tilde{S}_n$ 的极限分布。

Problem 3 (10 分)

设 $\{N_t^{(1)} : t \geq 0\}$, $\{N_t^{(2)} : t \geq 0\}$ 是相互独立的 Poisson 过程, 速率分别为 $\lambda_1 > 0$, $\lambda_2 > 0$. 令 $N_t = N_t^{(1)} + N_t^{(2)}$. 对固定整数 $m \geq 2$, 定义 $T_m = \inf\{t \geq 0 : N_t = m\}$, $K_m = N_{T_m}^{(1)}$.

- (1) 对任意 $s \geq 0$ 和 $0 \leq z \leq 1$, 计算联合变换 $\mathbb{E}[e^{-sT_m} z^{K_m}]$.
- (2) 求 (T_m, K_m) 的联合分布, 分别写出 T_m 和 K_m 的边缘分布, 并判断 T_m 与 K_m 是否独立。
- (3) 记 $\Delta N_{T_m}^{(1)} = N_{T_m}^{(1)} - N_{T_m-}^{(1)}$. 对每个 $0 \leq k \leq m$, 计算 $\mathbb{P}(\Delta N_{T_m}^{(1)} = 1 | K_m = k)$.

Problem 4 (15 分)

设 $\xi_1, \xi_2, \dots$ 相互独立, 且 $\mathbb{P}(\xi_k = 1) = \mathbb{P}(\xi_k = -1) = \frac{1}{2}$. 令 $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$, 并设 $\{a_k\}_{k \geq 1}$ 是满足 $0 < a_k \leq \frac{1}{2}$ 的确定性数列. 定义 $M_0 = 1$, $M_n = \prod_{k=1}^n (1 + a_k \xi_k)$, $n \geq 1$.

- (1) 证明 $\{M_n, \mathcal{F}_n\}_{n \geq 0}$ 是非负鞅, 并证明存在有限随机变量 M_∞ 使得 $M_n \rightarrow M_\infty$ a.s.
- (2) 证明 $\sup_{n \geq 1} \mathbb{E}(M_n^2) < \infty \iff \sum_{k=1}^{\infty} a_k^2 < \infty$. 在上述条件成立时, 证明 $M_n \rightarrow M_\infty$ 于 L^2 , 并计算 $\mathbb{E}(M_\infty)$ 与 $\mathbb{E}(M_\infty^2)$.

- (3) 假设 $\sum_{k=1}^{\infty} a_k^2 = \infty$. 证明 $M_n \rightarrow 0$ a.s. 并据此完整刻画 $\{M_n\}$ 何时一致可积、何时在 L^1 中收敛。

Problem 5 (15 分)

设 $\{B_t : t \geq 0\}$ 是一维标准 Brownian motion。对 $x \in [-a, a]$, 以 $\mathbb{P}_x$ 和 $\mathbb{E}_x$ 分别表示 $B_0 = x$ 时的概率与期望, 其中 $a > 0$ 。定义 $\tau_a = \inf\{t \geq 0 : |B_t| = a\}$, 以及正半轴上的占用时间 $A_a = \int_0^{\tau_a} \mathbf{1}_{\{B_t > 0\}} dt$. 对 $\lambda > 0$, $q \geq 0$, 令 $u_{\lambda, q}(x) = \mathbb{E}_x[\exp\{-\lambda\tau_a - qA_a\}]$, $-a \leq x \leq a$.

- (1) 证明 $u_{\lambda, q}$ 在 $[-a, a]$ 上连续, 在 $(-a, a)$ 上连续可微, 并在 $(-a, 0)$ 与 $(0, a)$ 上二次连续可微。确定它在两个子区间内满足的微分方程, 以及在 $-a, 0, a$ 处满足的全部边界条件和拼接条件, 并证明这些条件唯一确定 $u_{\lambda, q}$ 。
- (2) 令 $k_0 = \sqrt{2\lambda}$, $k_1 = \sqrt{2(\lambda + q)}$. 求 $u_{\lambda, q}(0)$ 的闭式表达式。答案须完全化为 a, k_0, k_1 及初等双曲函数的组合, 不得保留未求解的常微分方程。进一步计算 $\lim_{q \downarrow 0} u_{\lambda, q}(0)$ 和 $\lim_{\lambda \downarrow 0} u_{\lambda, q}(0)$ 。
- (3) 计算 $\mathbb{E}_0(\tau_a)$ 以及 $\mathbb{E}_0(A_a)$ 。

Problem 6 (10 分)

考虑状态空间 $\mathcal{S} = \{0, 1, 2, \dots\}$ 上的时齐 Markov 链 $\{X_n\}_{n \geq 0}$ 。其转移概率如下: $P(0, 1) = \frac{1}{8}$, $P(0, 0) = \frac{7}{8}$, 而对每个 $i \geq 1$, $P(i, i-1) = \frac{1}{2}$, $P(i, i+1) = \frac{1}{2} \left(\frac{i+1}{i+2}\right)^2$, $P(i, i) = \frac{1}{2} - \frac{1}{2} \left(\frac{i+1}{i+2}\right)^2$ 。

- (1) 判断该链是否不可约、非周期及可逆, 并求出其全部平稳概率分布。
- (2) 判断该链是暂留、零常返还是正常返。若 $\tau_0^+ = \inf\{n \geq 1 : X_n = 0\}$, 计算 $\mathbb{E}_0(\tau_0^+)$. 答案可以用 $\zeta(2) = \sum_{k=1}^{\infty} \frac{1}{k^2}$ 表示。
- (3) 对任意 $i, j \in \mathcal{S}$, 求 $\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j)$ 。

Problem 7 (10 分)

设 $X_1, \dots, X_n$ 为来自下列分布的独立同分布样本: $f_\theta(x) = \frac{2x}{\theta^2} \mathbf{1}_{\{0 < x \leq \theta\}}$, $\theta > 0$. 记 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, $M_n = X_{(n)} = \max_{1 \leq i \leq n} X_i$.

- (1) 求 θ 的矩估计量和最大似然估计量。
- (2) 分别求 $\sqrt{n}(\frac{3}{2}\bar{X}_n - \theta)$ 和 $n(\theta - M_n)$ 的极限分布, 并明确说明二者的收敛速度为何不同。
- (3) 对固定 $0 < p < 1$, 定义经验分布函数 F_n 及样本 p 分位数 $\hat{\xi}_{p,n} = \inf\{x : F_n(x) \geq p\}$. 令 $\hat{\theta}_{p,n} = \frac{\hat{\xi}_{p,n}}{\sqrt{p}}$. 求 $\hat{\theta}_{p,n}$ 的渐近分布, 并确定哪些 p 使 $\hat{\theta}_{p,n}$ 的渐近方差严格小于矩估计量的渐近方差。特别写出 $p = 1/2$ 时由样本中位数得到的估计量之渐近方差。

Problem 8 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$, $n \geq 4$. 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 并定义 $T = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$.

- (1) 证明 T 是参数 (μ, σ^2) 的极小充分统计量, 并判断 T 是否完全; 你的结论必须附有完整论证。

- (2) 定义 $A = \begin{cases} \frac{X_1 - \bar{X}}{S}, & S > 0, \\ 0, & S = 0. \end{cases}$ 证明 A 是辅助统计量, 并证明 A 与 T 相互独立。

- (3) 求参数函数 $\eta(\mu, \sigma^2) = \frac{\mu^2}{\sigma^2}$ 的一致最小方差无偏估计量。最终答案须写成 $\bar{X}$ 与 S^2 的显式函数, 并验证其无偏性所需的矩存在条件。

Problem 9 (10 分)

设 $X_1, \dots, X_n$ 为来自 $\text{Beta}(\theta, 1)$ 分布的独立同分布样本, 其密度为 $f_\theta(x) = \theta x^{\theta-1} \mathbf{1}_{\{0 < x < 1\}}$, $\theta > 0$. 固定 $\theta_0 > 0$ 与 $0 < \alpha < 1$, 并令 $T = -\sum_{i=1}^n \log X_i$.

- (1) 对检验问题 $H_0: \theta \leq \theta_0$ 对 $H_1: \theta > \theta_0$, 求一个 size 为 α 的一致最大功效检验。拒绝域必须用 χ^2 分布分位数显式表示。进一步写出该检验在任意 $\theta > 0$ 下的功效函数, 并验证其 size 的确等于 α 。
- (2) 通过反演上述检验, 构造 θ 的精确 $1 - \alpha$ 单侧下置信界, 并严格验证其覆盖概率。

Problem 10 (15 分)

设 $X_1, \dots, X_n$ 独立同分布, 且每个 X_i 服从负二项分布 $\mathbb{P}_p(X_i = x) = \binom{r+x-1}{x} p^r (1-p)^x$, $x = 0, 1, 2, \dots$, 其中 $r \in \mathbb{N}$ 已知, $0 < p < 1$ 未知。这里 X_i 表示第 r 次成功之前出现的失败次数。记 $S = \sum_{i=1}^n X_i$, $\bar{X} = \frac{S}{n}$, 并以 $\mu = \frac{r(1-p)}{p}$ 重新参数化模型。另令 $\psi = \log(r + \mu)$ 。


- (1) 求 μ 的最大似然估计量, 并完整讨论该估计量是否对每一个可能样本都存在。无论内部最大值是否存在, 定义闭包上的估计量 $\tilde{\mu} = \bar{X}$. 证明 $\tilde{\mu}$ 对 μ 相合。求单个观测关于 ψ 的 Fisher 信息, 并求 $\hat{\psi} = \log(r + \bar{X})$ 的渐近分布。
- (2) 假设先验分布为 $p \sim \text{Beta}(a, b)$, $a > 0$, $b > 0$. 求 p 的后验分布。以平方误差损失估计 $\mu = \frac{r(1-p)}{p}$, 求其 Bayes 估计量, 并完整说明后验均值存在以及平方后验风险有限分别需要满足的条件。当平方后验风险对每个有限动作均为无穷时, 也须明确说明。
- (3) 考虑 $H_0: \mu = \mu_0$ 对 $H_1: \mu \neq \mu_0$, $\mu_0 > 0$. 推导广义似然比统计量及 $-2 \log \Lambda_n$ 的显式表达式。约定 $0 \log 0 = 0$, 并使表达式覆盖 $S = 0$ 的情形。给出渐近 level 为 α 的拒绝域, 并写出由该检验反演得到的 $1 - \alpha$ 渐近似然比置信集。

Problem 11 (10 分)

设两组样本相互独立: $X_1, \dots, X_m \stackrel{\text{i.i.d.}}{\sim} N(\mu_X, \sigma_X^2)$, $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} N(\mu_Y, \sigma_Y^2)$, 其中 $m, n \geq 2$. 记 $\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$, $\bar{Y} = \frac{1}{n} \sum_{j=1}^n Y_j$, $S_X^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2$, $S_Y^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2$.

- (1) 在限制 $\sigma_X^2 = \sigma_Y^2 = \sigma^2$ 下, 构造 $\mu_X - \mu_Y$ 的精确 $1 - \alpha$ 置信区间, 并写出检验 $H_0: \mu_X - \mu_Y = \delta_0$ 对 $H_1: \mu_X - \mu_Y \neq \delta_0$ 的精确 level α 拒绝域。
- (2) 不再假定两总体方差相等。构造 $\rho = \frac{\sigma_X^2}{\sigma_Y^2}$ 的精确 $1 - \alpha$ 置信区间, 并写出检验 $H_0: \rho = \rho_0$ 对 $H_1: \rho \neq \rho_0$ 的精确 level α 拒绝域。
- (3) 重新假设 $\sigma_X^2 = \sigma_Y^2$. 判断第 (a) 问中使用的 Student t 统计量与随机变量 $\frac{S_X^2}{S_Y^2}$ 是否独立, 并给出完整证明。

试题结束



第三十五章 模拟试题解答

35.1 第一套试题 + 答案

Problem 1 (10 分)

设 $r \in \mathbb{N}$, 且 $b, c_1, c_2 > 0$ 。随机变量 Λ 服从 $\text{Gamma}(r, b)$ 。在给定 $\Lambda = \lambda$ 的条件下, 随机变量 X, Y 条件独立, 并且

$$X | \Lambda = \lambda \sim \text{Poisson}(c_1 \lambda), \quad Y | \Lambda = \lambda \sim \text{Poisson}(c_2 \lambda).$$

(a) (3 分) 求 (X, Y) 的联合概率生成函数

$$G(s, t) = \mathbb{E}[s^X t^Y], \quad 0 \leq s, t \leq 1,$$

(b) (4 分) 计算 $\mathbb{E}X$, $\mathbb{E}Y$, $\text{Var}(X)$, $\text{Var}(Y)$, $\text{Cov}(X, Y)$, $\text{Corr}(X, Y)$ 。

(c) (3 分) 对任意 $x, y \in \{0, 1, 2, \dots\}$, 求

$$\Lambda | (X = x, Y = y)$$

的后验分布及后验均值。

第 1 题解答

(1) 条件于 Λ , 由 X, Y 的条件独立性, $\mathbb{E}[s^X t^Y | \Lambda] = \mathbb{E}(s^X | \Lambda) \mathbb{E}(t^Y | \Lambda) = \exp\{c_1 \Lambda(s - 1) + c_2 \Lambda(t - 1)\}$ 。

由于 $\Lambda \sim \text{Gamma}(r, b)$ 的 Laplace 变换为 $\mathbb{E}(e^{-u\Lambda}) = \left(\frac{b}{b+u}\right)^r, u \geq 0$, 所以 $G(s, t) = \left[\frac{b}{b + c_1(1-s) + c_2(1-t)}\right]^r$ 。

(2) 令 $t = 1$, 则 $G_X(s) = \left[\frac{b}{b + c_1(1-s)}\right]^r = \left[\frac{p_1}{1 - (1-p_1)s}\right]^r, \quad p_1 = \frac{b}{b + c_1}$ 。同理我们可得 $G_Y(s)$ 。由全期望公式, $\mathbb{E}X = \mathbb{E}[\mathbb{E}(X | \Lambda)] = \mathbb{E}(c_1 \Lambda) = \frac{rc_1}{b}, \mathbb{E}Y = \frac{rc_2}{b}$ 。由全方差公式, $\text{Var}(X) = \mathbb{E}[\text{Var}(X | \Lambda)] + \text{Var}(\mathbb{E}[X | \Lambda])$ 。同理, $\text{Var}(Y) = \frac{rc_2(b+c_2)}{b^2}$ 。由全协方差公式, $\text{Cov}(X, Y) = \mathbb{E}[\text{Cov}(X, Y | \Lambda)] + \text{Cov}(\mathbb{E}[X | \Lambda], \mathbb{E}[Y | \Lambda]) = 0 +$

$$\text{Cov}(c_1 \Lambda, c_2 \Lambda) = c_1 c_2 \text{Var}(\Lambda) = \frac{rc_1 c_2}{b^2}。因此 \text{Corr}(X, Y) = \frac{rc_1 c_2 / b^2}{\sqrt{rc_1(b+c_1)/b^2} \sqrt{rc_2(b+c_2)/b^2}} = \sqrt{\frac{c_1 c_2}{(b+c_1)(b+c_2)}}。$$

(3) 给定 $X = x, Y = y$ 后, 后验密度核为 $\pi(\lambda | x, y) \propto \lambda^{r-1} e^{-b\lambda} \cdot e^{-c_1 \lambda} \frac{(c_1 \lambda)^x}{x!} \cdot e^{-c_2 \lambda} \frac{(c_2 \lambda)^y}{y!} \propto \lambda^{r+x+y-1} e^{-(b+c_1+c_2)\lambda}$ 。

故 $\Lambda | (X = x, Y = y) \sim \text{Gamma}(r + x + y, b + c_1 + c_2)$ 。其后验均值为 $\mathbb{E}[\Lambda | X = x, Y = y] = \frac{r + x + y}{b + c_1 + c_2}$ 。

Problem 2 (15 分)

固定常数 $\lambda > 0$ 。对每个满足 $n > \lambda$ 的整数 n , 令

$$\varepsilon_{n,1}, \dots, \varepsilon_{n,n}, \quad \eta_{n,1}, \dots, \eta_{n,n}$$

相互独立, 并满足

$$\mathbb{P}(\varepsilon_{n,k} = 1) = \mathbb{P}(\varepsilon_{n,k} = -1) = \frac{1}{2},$$

以及

$$\mathbb{P}(\eta_{n,k} = 1) = \mathbb{P}(\eta_{n,k} = -1) = \frac{\lambda}{2n}, \quad \mathbb{P}(\eta_{n,k} = 0) = 1 - \frac{\lambda}{n}.$$

不同 n 所对应的全部随机变量亦假设相互独立。定义

$$R_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k}, \quad J_n = \sum_{k=1}^n \eta_{n,k}, \quad S_n = R_n + J_n.$$

(a) (7 分) 求 S_n 的分布极限, 并将极限随机变量表示为若干相互独立的熟知随机变量 (比如正态分布、指数分布、几何分布、泊松分布等等) 之和或差。

(b) (4 分) 定义

$$A_n = \frac{1}{n} \sum_{k=1}^n \varepsilon_{n,k} + \frac{1}{\sqrt{n}} \sum_{k=1}^n \eta_{n,k}.$$

分别判断 A_n 是否依概率收敛及是否在 L^2 中收敛, 并给出相应极限。

(c) (4 分) 判断随机变量族 $\{S_n^2 : n > \lambda\}$ 是否一致可积, 并证明你的结论。

第 2 题解答

(1) R_n 的特征函数为 $\varphi_{R_n}(t) = \prod_{k=1}^n \mathbb{E} \exp\left(\frac{it\varepsilon_{n,k}}{\sqrt{n}}\right) = \left[\cos\left(\frac{t}{\sqrt{n}}\right)\right]^n$. 利用 $\cos u = 1 - \frac{u^2}{2} + o(u^2)$, $u \rightarrow 0$,

可得 $\varphi_{R_n}(t) \rightarrow e^{-t^2/2}$ 。故 $R_n \xrightarrow{d} Z$, $Z \sim N(0, 1)$ 。

另一方面, $\varphi_{J_n}(t) = \prod_{k=1}^n \mathbb{E}(e^{it\eta_{n,k}}) = \left[1 - \frac{\lambda}{n} + \frac{\lambda}{2n}e^{it} + \frac{\lambda}{2n}e^{-it}\right]^n = \left[1 + \frac{\lambda}{n}(\cos t - 1)\right]^n \rightarrow \exp\{\lambda(\cos t - 1)\}$ 。

设 P_+, P_- 相互独立且 $P_+, P_- \sim \text{Poisson}(\lambda/2)$ 。则

$$\mathbb{E}e^{it(P_+ - P_-)} = \exp\left\{\frac{\lambda}{2}(e^{it} - 1)\right\} \exp\left\{\frac{\lambda}{2}(e^{-it} - 1)\right\} = \exp\{\lambda(\cos t - 1)\}.$$

所以 $J_n \xrightarrow{d} P_+ - P_-$ 。

对每个 n , R_n 与 J_n 独立, 故 $\varphi_{S_n}(t) = \varphi_{R_n}(t)\varphi_{J_n}(t) \rightarrow e^{-t^2/2} \exp\{\lambda(\cos t - 1)\}$ 。因此可取 Z, P_+, P_-

相互独立, 使 $S_n \xrightarrow{d} Z + P_+ - P_-$ 。

(2) 注意 $A_n = \frac{1}{n} \sum_{k=1}^n \varepsilon_{n,k} + \frac{1}{\sqrt{n}} \sum_{k=1}^n \eta_{n,k} = \frac{R_n + J_n}{\sqrt{n}} = \frac{S_n}{\sqrt{n}}$ 。各项均值为零, 且两组随机变量相互独立, 因

此 $\mathbb{E}A_n^2 = \text{Var}(A_n) = \frac{1}{n^2} \text{Var}\left(\sum_{k=1}^n \varepsilon_{n,k}\right) + \frac{1}{n} \text{Var}\left(\sum_{k=1}^n \eta_{n,k}\right)$ 。因为 $\text{Var}(\varepsilon_{n,k}) = 1$, $\text{Var}(\eta_{n,k}) =$

$\mathbb{E}\eta_{n,k}^2 = \frac{\lambda}{n}$, 所以 $\mathbb{E}A_n^2 = \frac{n}{n^2} + \frac{1}{n} \cdot n \frac{\lambda}{n} = \frac{1+\lambda}{n} \rightarrow 0$ 。故 $A_n \xrightarrow{L^2} 0$ 。特别地, $A_n \xrightarrow{P} 0$ 。

(3) 对 R_n , 利用独立、中心化随机变量和的四阶矩公式,

$$\mathbb{E}R_n^4 = \frac{1}{n^2} \mathbb{E}\left(\sum_{k=1}^n \varepsilon_{n,k}\right)^4 = \frac{1}{n^2} [n\mathbb{E}\varepsilon_{n,1}^4 + 3n(n-1)(\mathbb{E}\varepsilon_{n,1}^2)^2] = \frac{n + 3n(n-1)}{n^2} = 3 - \frac{2}{n} \leq 3.$$

对单个 $\eta_{n,k}$, $\mathbb{E}\eta_{n,k}^2 = \mathbb{E}\eta_{n,k}^4 = \frac{\lambda}{n}$. 故 $\mathbb{E}J_n^4 = n\mathbb{E}\eta_{n,1}^4 + 3n(n-1)(\mathbb{E}\eta_{n,1}^2)^2 = \lambda + 3\lambda^2 \frac{n-1}{n} \leq \lambda + 3\lambda^2$. 此外, $\mathbb{E}R_n^2 = 1$, $\mathbb{E}J_n^2 = \lambda$. 由 R_n, J_n 独立且中心化,

$$\mathbb{E}S_n^4 = \mathbb{E}(R_n + J_n)^4 = \mathbb{E}R_n^4 + 6\mathbb{E}R_n^2\mathbb{E}J_n^2 + \mathbb{E}J_n^4 \leq 3 + 7\lambda + 3\lambda^2 =: C_\lambda.$$

于是对任意 $K > 0$, $\sup_{n>\lambda} \mathbb{E}[S_n^2 \mathbf{1}_{\{S_n^2 > K\}}] \leq \frac{1}{K} \sup_{n>\lambda} \mathbb{E}S_n^4 \leq \frac{C_\lambda}{K} \rightarrow 0$, $K \rightarrow \infty$. 故 $\{S_n^2 : n > \lambda\}$ 一致可积.

Problem 3 (10 分)

设 $\{N_t : t \geq 0\}$ 是强度为 $\lambda > 0$ 的 Poisson 过程. 固定 $T > 0$, 定义

$$A_T = \int_0^T N_s \, ds.$$

(a) (5 分) 求 $\mathbb{E}[A_T | \sigma(N_T)]$ 和 $\text{Var}(A_T | \sigma(N_T))$ 的具体值.

(b) (5 分) 对 $0 \leq z \leq 1$ 和 $u > 0$, 求联合变换 $\mathbb{E}[z^{N_T} e^{-uA_T}]$, 并计算 $\text{Cov}(A_T, N_T)$.

第 3 题解答

(1) 条件于 $N_T = n$, 区间 $(0, T]$ 内的 n 个到达时刻的无序版本可表示为 $U_1, \dots, U_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, T)$. 由

$$N_s = \sum_{j=1}^{N_T} \mathbf{1}_{\{U_j \leq s\}}, \text{ 以及 Fubini 定理, } A_T = \int_0^T N_s \, ds = \sum_{j=1}^{N_T} \int_0^T \mathbf{1}_{\{U_j \leq s\}} \, ds = \sum_{j=1}^{N_T} (T - U_j). \text{ 因此在}$$

$$N_T = n \text{ 条件下, } \mathbb{E}(A_T | N_T = n) = n\mathbb{E}(T - U_1) = \frac{nT}{2}, \text{Var}(A_T | N_T = n) = n\text{Var}(T - U_1) = \frac{nT^2}{12}. \text{ 故}$$

$$\mathbb{E}[A_T | \sigma(N_T)] = \frac{T}{2} N_T, \text{ 以及 } \text{Var}(A_T | \sigma(N_T)) = \frac{T^2}{12} N_T.$$

(2) 令 $a(u) = \mathbb{E}[e^{-u(T-U_1)}] = \frac{1}{T} \int_0^T e^{-u(T-s)} \, ds = \frac{1 - e^{-uT}}{uT}$. 条件于 $N_T = n$, $\mathbb{E}[z^{N_T} e^{-uA_T} | N_T = n] =$

$$[za(u)]^n. \text{ 由于 } N_T \sim \text{Poisson}(\lambda T), \text{ 所以 } \mathbb{E}[z^{N_T} e^{-uA_T}] = \exp\{\lambda T(za(u) - 1)\} = \exp\left\{-\lambda T + \frac{\lambda z}{u}(1 - e^{-uT})\right\}.$$

又因为给定 N_T 后, N_T 是常数, $\text{Cov}(A_T, N_T | N_T) = 0$. 故

$$\text{Cov}(A_T, N_T) = \text{Cov}(\mathbb{E}[A_T | N_T], N_T) = \text{Cov}\left(\frac{T}{2} N_T, N_T\right) = \frac{T}{2} \text{Var}(N_T) = \frac{\lambda T^2}{2}.$$

Problem 4 (10 分)


设 $p \in (0, 1)$, $q = 1 - p$. 考虑状态空间为 $\mathcal{S} = \{0, 1, 2, \dots\}$ 的时间齐次 Markov 链 $\{X_n : n \geq 0\}$, 其转移概率为 $P(0, 0) = q, P(0, 1) = p$, 且对每个 $i \geq 1$, $P(i, i+1) = p, P(i, i-1) = q$. 记

$$\tau_0^+ = \inf\{n \geq 1 : X_n = 0\}.$$

(a) (5 分) 对 $p < q$ 、 $p = q$ 和 $p > q$ 三种情形, 分别判断该链是正常返、零常返还是暂留, 并证明你的结论.

(b) (5 分) 在 $p < q$ 时, 求该链的平稳分布 π , 计算

$$\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j), \quad i, j \in \mathcal{S},$$



并求 $\mathbb{E}_0[\tau_0^+]$ 。

第 4 题解答

- (1) 记从状态 $i \geq 1$ 出发最终到达 0 的概率为 $h_i = \mathbb{P}_i(\tau_0 < \infty)$ 。先考虑有限状态区间 $\{0, 1, \dots, M\}$ ，并令 $h_i^{(M)} = \mathbb{P}_i(\tau_0 < \tau_M)$ 。若 $p \neq q$ ，令 $\rho = \frac{q}{p}$ ，则破产概率为 $h_i^{(M)} = \frac{\rho^i - \rho^M}{1 - \rho^M}$ 。若 $p = q$ ，则 $h_i^{(M)} = 1 - \frac{i}{M}$ 。

$$\text{令 } M \rightarrow \infty, \text{ 得到 } h_i = \begin{cases} 1, & p \leq q, \\ (q/p)^i, & p > q. \end{cases}$$

从状态 0 出发，第一步以概率 q 留在 0，以概率 p 到达 1，故 $\mathbb{P}_0(\tau_0^+ < \infty) = q + ph_1$ 。若 $p \leq q$ ，则 $q + ph_1 = q + p = 1$ ，所以链常返。

若 $p > q$ ，则 $q + ph_1 = q + p\frac{q}{p} = 2q < 1$ ，所以链暂留。

当 $p < q$ 时，下一问将构造平稳概率分布，因此该不可约链正常返。

当 $p = q$ 时，若存在平稳概率分布 π ，令 $d_i = p\pi_i - q\pi_{i+1}$ ， $i \geq 0$ 。状态 0 的平衡方程给出 $d_0 = 0$ ，而各内部状态的平衡方程给出 $d_i = d_{i-1}$ ， $i \geq 1$ 。所以 $d_i = 0$ 对所有 i 成立，即 $p\pi_i = q\pi_{i+1}$ 。当 $p = q$ 时， $\pi_{i+1} = \pi_i$ ，从而所有 π_i 相同，无法归一化。因此该链常返但非正常返，即零常返。

综上，

$p < q$	正常返
$p = q$	零常返
$p > q$	暂留

- (2) 设 $p < q$ ，并令 $\rho = \frac{p}{q} \in (0, 1)$ 。详细平衡方程为 $\pi_i p = \pi_{i+1} q$ ， $i \geq 0$ 。故 $\pi_i = \pi_0 \rho^i$ 。归一化条件给出

$$1 = \sum_{i=0}^{\infty} \pi_i = \pi_0 \sum_{i=0}^{\infty} \rho^i = \frac{\pi_0}{1-\rho}. \text{ 因此 } \pi_i = (1-\rho)\rho^i = \left(1 - \frac{p}{q}\right) \left(\frac{p}{q}\right)^i, \quad i \geq 0.$$

该链不可约，并且 $P(0,0) = q > 0$ ，故链非周期。由不可约、非周期、正常返 Markov 链的收敛定理，

$$\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j) = \pi_j, \quad i, j \in \mathcal{S}.$$

由正常返链的返时公式， $\mathbb{E}_0[\tau_0^+] = \frac{1}{\pi_0}$ 。而 $\pi_0 = 1 - \frac{p}{q} = \frac{q-p}{q}$ ，所以 $\mathbb{E}_0[\tau_0^+] = \frac{q}{q-p}$ 。

Problem 5 (15 分)

固定 $p \in (1/2, 1)$ 。构造如下连续时间分枝 Brownian 系统。

在时刻 0，只有一个位于原点的粒子。每个存活粒子独立地按照标准 Brownian motion 运动，并具有参数为 1 的指数寿命。一个粒子寿命结束时以概率 p 产生两个子粒子，以概率 $1-p$ 不产生子粒子。子粒子从母粒子死亡时的位置出发，并按照相同规则独立演化。

记 $\mathcal{N}_t$ 为时刻 t 的存活粒子集合， $N_t = |\mathcal{N}_t|$ 并以 $X_u(t)$ 表示粒子 $u \in \mathcal{N}_t$ 在时刻 t 的位置。令 $\{\mathcal{F}_t\}$ 为该系统的自然滤过。

- (a) (4 分) 求 $\mathbb{E}[N_t]$ 以及该系统最终灭绝的概率。

- (b) (6 分) 对任意固定 $\theta \in \mathbb{R}$ ，定义

$$W_t(\theta) = \exp \left\{ - \left(2p - 1 + \frac{\theta^2}{2} \right) t \right\} \sum_{u \in \mathcal{N}_t} e^{\theta X_u(t)}.$$

证明 $\{W_t(\theta) : t \geq 0\}$ 是关于 $\{\mathcal{F}_t\}$ 的鞅，并求其期望。



(c) (5 分) 定义 $M_t = \max_{u \in \mathcal{N}_t} X_u(t)$, 并约定当 $N_t = 0$ 时 $M_t = -\infty$. 证明: 对任意 $a > \sqrt{2(2p-1)}$ 均有

$$\lim_{t \rightarrow \infty} \mathbb{P}(M_t \geq at) = 0.$$

第 5 题解答

令 $r = 2p - 1 > 0$.

(1) 在长度为 dt 的短时间内, 一个粒子:

$$\begin{cases} \text{以概率 } 1 - dt + o(dt) \text{ 保持为一个粒子,} \\ \text{以概率 } p dt + o(dt) \text{ 变为两个粒子,} \\ \text{以概率 } (1-p) dt + o(dt) \text{ 变为零个粒子.} \end{cases}$$

因此 $\frac{d}{dt} \mathbb{E}N_t = (2p-1)\mathbb{E}N_t = r\mathbb{E}N_t$, $\mathbb{E}N_0 = 1$. 解得 $\mathbb{E}N_t = e^{rt} = e^{(2p-1)t}$.

最终灭绝概率只由嵌入的 Galton-Watson 家谱决定. 其子代生成函数为 $f(s) = 1 - p + ps^2$. 灭绝概率是区间 $[0, 1]$ 中方程 $f(s) = s$ 的最小根. 该方程等价于 $ps^2 - s + 1 - p = 0$, 其两个根为 1, $\frac{1-p}{p}$. 因为

$p > 1/2$, 有 $\frac{1-p}{p} < 1$. 故 $\mathbb{P}(\text{最终灭绝}) = \frac{1-p}{p}$.

(2) 定义 $Z_t(\theta) = \sum_{u \in \mathcal{N}_t} e^{\theta X_u(t)}$. 分枝机制与空间 Brownian 运动独立. 条件于家谱, 每个在时刻 t 存活粒子的总位移均为若干独立 Brownian 增量之和, 因此其边际分布为 $N(0, t)$. 故 $\mathbb{E}[e^{\theta X_u(t)} | \text{家谱}] = e^{\theta^2 t/2}$. 由期望的线性性, $\mathbb{E}Z_t(\theta) = \mathbb{E}[N_t e^{\theta^2 t/2}] = e^{rt} e^{\theta^2 t/2} = \exp\left\{\left(r + \frac{\theta^2}{2}\right)t\right\}$.

固定 $0 \leq s < t$. 给定 $\mathcal{F}_s$, 每个粒子 $u \in \mathcal{N}_s$ 的后代系统相互独立, 并且是从位置 $X_u(s)$ 出发、运行时间 $t-s$ 的同型系统. 因此 $\mathbb{E}[Z_t(\theta) | \mathcal{F}_s] = \sum_{u \in \mathcal{N}_s} e^{\theta X_u(s)} \exp\left\{\left(r + \frac{\theta^2}{2}\right)(t-s)\right\}$. 所以

$$\mathbb{E}[W_t(\theta) | \mathcal{F}_s] = e^{-(r+\theta^2/2)t} \mathbb{E}[Z_t(\theta) | \mathcal{F}_s] = e^{-(r+\theta^2/2)s} \sum_{u \in \mathcal{N}_s} e^{\theta X_u(s)} = W_s(\theta).$$

故 $\{W_t(\theta) : t \geq 0\}$ 是关于 $\{\mathcal{F}_t\}$ 的非负鞅.

又 $W_0(\theta) = 1$, 所以 $\mathbb{E}W_t(\theta) = 1, \quad t \geq 0$.

(3) 任取 $\theta > 0$. 在事件 $\{M_t \geq at\}$ 上, 至少存在一个粒子 $u \in \mathcal{N}_t$ 满足 $X_u(t) \geq at$. 因此 $\sum_{u \in \mathcal{N}_t} e^{\theta X_u(t)} \geq e^{\theta at}$.

由 Markov 不等式, $\mathbb{P}(M_t \geq at) \leq e^{-\theta at} \mathbb{E}\left[\sum_{u \in \mathcal{N}_t} e^{\theta X_u(t)}\right] = \exp\left\{\left(r + \frac{\theta^2}{2} - a\theta\right)t\right\}$. 右侧指数关于 θ 在

$\theta = a$ 处达到最小值. 因此取 $\theta = a$, 得到 $\mathbb{P}(M_t \geq at) \leq \exp\left\{\left(r - \frac{a^2}{2}\right)t\right\}$. 当 $a > \sqrt{2r} = \sqrt{2(2p-1)}$ 时, $r - \frac{a^2}{2} < 0$. 所以 $\lim_{t \rightarrow \infty} \mathbb{P}(M_t \geq at) = 0$.

Problem 6 (10 分)

设 $\xi_1, \xi_2, \dots$ 为独立同分布的随机变量, 且 $\mathbb{P}(\xi_k = 1) = \mathbb{P}(\xi_k = -1) = \frac{1}{2}$. 定义简单对称随机游动

$$S_0 = 0, \quad S_k = \sum_{j=1}^k \xi_j,$$

以及

$$M_{2n} = \max_{0 \leq k \leq 2n} S_k.$$

- (a) (5 分) 对整数 $1 \leq a \leq n$, 计算 $\mathbb{P}(M_{2n} < a \mid S_{2n} = 0)$ 。
 (b) (5 分) 对每个 $x > 0$, 求极限 $\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{M_{2n}}{\sqrt{2n}} < x \mid S_{2n} = 0\right)$ 。

第 6 题解答

- (1) 在条件 $S_{2n} = 0$ 下, 路径共有 n 个向上步和 n 个向下步, 故共有 $\binom{2n}{n}$ 条等概率路径。

考虑所有满足 $S_{2n} = 0$, $M_{2n} \geq a$ 的路径。在路径第一次到达水平 a 后, 将后续部分关于水平线 a 反射。该反射映射将这类路径一一对应到从 0 出发、在时刻 $2n$ 到达 $2a$ 的路径。

从 0 到达 $2a$ 需要 $n+a$ 个向上步和 $n-a$ 个向下步, 故这样的路径数为 $\binom{2n}{n+a}$ 。所以

$$\mathbb{P}(M_{2n} \geq a \mid S_{2n} = 0) = \frac{\binom{2n}{n+a}}{\binom{2n}{n}}.$$

因此 $\mathbb{P}(M_{2n} < a \mid S_{2n} = 0) = 1 - \frac{\binom{2n}{n+a}}{\binom{2n}{n}}.$

- (2) 固定 $x > 0$, 令 $a_n = \lceil x\sqrt{2n} \rceil$ 。由于 M_{2n} 为整数, $\left\{\frac{M_{2n}}{\sqrt{2n}} < x\right\} = \{M_{2n} < a_n\}$ 。由上一问, $\mathbb{P}\left(\frac{M_{2n}}{\sqrt{2n}} < x \mid S_{2n} = 0\right)$

其中 $R_n = \frac{\binom{2n}{n+a_n}}{\binom{2n}{n}} = \frac{n!n!}{(n+a_n)!(n-a_n)!} = \prod_{j=1}^{a_n} \frac{n-j+1}{n+j}$ 。由于 $a_n = O(\sqrt{n})$, 对数展开给出

$$\log R_n = \sum_{j=1}^{a_n} \left[\log \left(1 - \frac{j-1}{n}\right) - \log \left(1 + \frac{j}{n}\right) \right] = -\frac{1}{n} \sum_{j=1}^{a_n} (2j-1) + O\left(\frac{1}{n^2} \sum_{j=1}^{a_n} j^2\right) = -\frac{a_n^2}{n} + o(1).$$

而 $\frac{a_n^2}{n} \rightarrow 2x^2$, 所以 $R_n \rightarrow e^{-2x^2}$ 。因此 $\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{M_{2n}}{\sqrt{2n}} < x \mid S_{2n} = 0\right) = 1 - e^{-2x^2}, \quad x > 0.$

Problem 7 (10 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), \quad \mu \in \mathbb{R}, \quad \sigma > 0,$$

其中 $n = 2m+1$ 为奇数。记

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2,$$

并令样本中位数为 $\tilde{X}_n = X_{(m+1)}$ 。

- (a) (3 分) 求 $\tilde{X}_n$ 的精确密度函数。

- (b) (5 分) 当 $n \rightarrow \infty$ 且 n 沿奇数取值时, 求二维随机向量 $\sqrt{n} \begin{pmatrix} (\bar{X}_n - \mu)/\sigma \\ (\tilde{X}_n - \mu)/\sigma \end{pmatrix}$ 的极限分布, 并将其协方差矩阵写成显式常数矩阵。



(c) (2 分) 求 $\frac{\sqrt{n}(\tilde{X}_n - \bar{X}_n)}{S_n}$ 的极限分布。

第 7 题解答

记 $F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$, $f(x) = \frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right)$ 。

(1) 因 $n = 2m+1$, $\tilde{X}_n = X_{(m+1)}$, 由次序统计量密度公式, $f_{\tilde{X}_n}(x) = \frac{(2m+1)!}{m!m!} [F(x)]^m [1-F(x)]^m f(x)$ 。

$$\text{即 } f_{\tilde{X}_n}(x) = \frac{(2m+1)!}{(m!)^2 \sigma} \Phi\left(\frac{x-\mu}{\sigma}\right)^m \times \left[1 - \Phi\left(\frac{x-\mu}{\sigma}\right)\right]^m \phi\left(\frac{x-\mu}{\sigma}\right), \quad x \in \mathbb{R}.$$

(2) 令 $Z_i = \frac{X_i - \mu}{\sigma} \sim N(0, 1)$, 并记 $\tilde{Z}_n = \frac{\tilde{X}_n - \mu}{\sigma}$ 。标准样本分位数的渐近线性展开为

$$\sqrt{n} \tilde{Z}_n = \frac{1}{\phi(0)} \frac{1}{\sqrt{n}} \sum_{i=1}^n \left(\frac{1}{2} - \mathbf{1}_{\{Z_i \leq 0\}} \right) + o_p(1).$$

同时 $\sqrt{n} \bar{Z}_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i$ 。故 $\sqrt{n} \begin{pmatrix} \bar{Z}_n \\ \tilde{Z}_n \end{pmatrix} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \begin{pmatrix} Z_i \\ \phi(0)^{-1} \left(\frac{1}{2} - \mathbf{1}_{\{Z_i \leq 0\}} \right) \end{pmatrix} + o_p(1)$ 。

第二个分量的方差为 $\frac{\text{Var}(\mathbf{1}_{\{Z \leq 0\}})}{\phi(0)^2} = \frac{1/4}{1/(2\pi)} = \frac{\pi}{2}$ 。又 $\mathbb{E}[Z \mathbf{1}_{\{Z \leq 0\}}] = \int_{-\infty}^0 z \phi(z) dz = -\phi(0)$ 。因此两

个分量的协方差为 $\frac{1}{\phi(0)} \mathbb{E} \left[Z \left(\frac{1}{2} - \mathbf{1}_{\{Z \leq 0\}} \right) \right] = \frac{-\mathbb{E}[Z \mathbf{1}_{\{Z \leq 0\}}]}{\phi(0)} = 1$ 。由二维中心极限定理,

$$\sqrt{n} \begin{pmatrix} (\bar{X}_n - \mu)/\sigma \\ (\tilde{X}_n - \mu)/\sigma \end{pmatrix} \xrightarrow{d} N_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 1 & \pi/2 \end{pmatrix} \right).$$

(3) 由强大数律, $\frac{S_n}{\sigma} \xrightarrow{\text{a.s.}} 1$ 。由上一问的联合极限, $\frac{\sqrt{n}(\tilde{X}_n - \bar{X}_n)}{\sigma} \xrightarrow{d} N(0, \frac{\pi}{2} - 1)$, 因为对协方差矩阵 $\Sigma = \begin{pmatrix} 1 & 1 \\ 1 & \pi/2 \end{pmatrix}$, 有 $(-1, 1)\Sigma(-1, 1)^\top = 1 + \frac{\pi}{2} - 2 = \frac{\pi}{2} - 1$ 。由 Slutsky 定理, $\frac{\sqrt{n}(\tilde{X}_n - \bar{X}_n)}{S_n} \xrightarrow{d} N(0, \frac{\pi}{2} - 1)$ 。

Problem 8 (15 分)

设 $n \geq 2$, 且 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Gamma}(2, \lambda)$, 其中 $\lambda > 0$, 即 $f(x | \lambda) = \lambda^2 x e^{-\lambda x} \mathbf{1}_{\{x > 0\}}$ 。定义 $T = \sum_{i=1}^n X_i$, $U = \frac{X_1}{T}$ 。

(a) (6 分) 判断 T 是否为 λ 的极小充分统计量及完全统计量, 并证明你的结论。

(b) (4 分) 求 U 的分布。判断 U 是否为辅助统计量, 并判断 U 与 T 是否独立。

(c) (5 分) 固定 $c > 0$, 求 $\psi(\lambda) = \mathbb{P}_\lambda(X_1 > c)$ 的一致最小方差无偏估计量, 并将答案写成 T 的显式函数。

第 8 题解答

(1) 联合密度为 $f_\lambda(\mathbf{x}) = \prod_{i=1}^n [\lambda^2 x_i e^{-\lambda x_i} \mathbf{1}_{\{x_i > 0\}}] = \lambda^{2n} \exp\left(-\lambda \sum_{i=1}^n x_i\right) \prod_{i=1}^n x_i \mathbf{1}_{\{x_i > 0\}}$ 。由因子分解定理, $T = \sum_{i=1}^n X_i$ 是充分统计量。

对任意 $\mathbf{x}, \mathbf{y} \in (0, \infty)^n$, 有 $\frac{f_\lambda(\mathbf{x})}{f_\lambda(\mathbf{y})} = \prod_{i=1}^n \frac{x_i}{y_i} \exp\{-\lambda[T(\mathbf{x}) - T(\mathbf{y})]\}$ 。该比值与 λ 无关, 当且仅当 $T(\mathbf{x}) = T(\mathbf{y})$ 。

故 T 是极小充分统计量。

又因为独立 Gamma 随机变量可加, $T \sim \text{Gamma}(2n, \lambda)$ 。设可测函数 g 满足 $\mathbb{E}_\lambda |g(T)| < \infty$ 并且 $\mathbb{E}_\lambda [g(T)] = 0, \quad \forall \lambda > 0$ 。则 $\frac{\lambda^{2n}}{\Gamma(2n)} \int_0^\infty g(t) t^{2n-1} e^{-\lambda t} dt = 0, \quad \forall \lambda > 0$ 。所以 $\int_0^\infty g(t) t^{2n-1} e^{-\lambda t} dt = 0, \quad \forall \lambda > 0$ 。左侧为 $g(t) t^{2n-1}$ 的 Laplace 变换。由 Laplace 变换唯一性, $g(t) t^{2n-1} = 0 \quad \text{a.e. on } (0, \infty)$ 。由于 $t^{2n-1} > 0$, 故 $g(t) = 0 \quad \text{a.e.}$ 因此 T 完全。

综上, $T = \sum_{i=1}^n X_i$ 是完全且极小充分统计量。

- (2) 令 $V = \sum_{i=2}^n X_i$ 。则 $X_1 \sim \text{Gamma}(2, \lambda)$, $V \sim \text{Gamma}(2n-2, \lambda)$, 且 $X_1 \perp V$ 。

作变换 $T = X_1 + V$, $U = \frac{X_1}{X_1 + V}$, 其逆变换为 $X_1 = UT$, $V = (1-U)T$ 。Jacobian 的绝对值为 T 。故

$$\begin{aligned} f_{T,U}(t, u) &= \frac{\lambda^2}{\Gamma(2)} (ut) e^{-\lambda ut} \times \frac{\lambda^{2n-2}}{\Gamma(2n-2)} [(1-u)t]^{2n-3} e^{-\lambda(1-u)t} \cdot t \\ &= \frac{\lambda^{2n}}{\Gamma(2n)} t^{2n-1} e^{-\lambda t} \times \frac{\Gamma(2n)}{\Gamma(2)\Gamma(2n-2)} u(1-u)^{2n-3}, \end{aligned}$$

其中 $t > 0, 0 < u < 1$ 。因此联合密度分解为 T 的 Gamma 密度与 U 的 Beta 密度之积。故 $U \sim \text{Beta}(2, 2n-2)$ 。

其密度为 $f_U(u) = (2n-1)(2n-2)u(1-u)^{2n-3}, \quad 0 < u < 1$ 。该分布不含 λ , 所以 U 是辅助统计量。

同时, 由联合密度的乘积分解, $U \perp T$ 。

- (3) 首先计算 $\psi(\lambda) = \mathbb{P}_\lambda(X_1 > c) = \int_c^\infty \lambda^2 x e^{-\lambda x} dx = e^{-\lambda c}(1 + \lambda c)$ 。取无偏估计量 $W = \mathbf{1}_{\{X_1 > c\}}$ 。则 $\mathbb{E}_\lambda W = \psi(\lambda)$ 。由于 T 完全充分, Lehmann-Scheffé 定理说明 $\mathbb{E}(W | T)$ 是唯一 UMVUE。

给定 $T = t$ 时, $X_1 = tU$, 其中 $U \sim \text{Beta}(2, m)$, $m = 2n-2$ 。若 $t \leq c$, 则 $\mathbb{P}(X_1 > c | T = t) = 0$ 。若 $t > c$, 令 $x = \frac{c}{t} \in (0, 1)$, 则

$$\mathbb{P}(U > x) = m(m+1) \int_x^1 u(1-u)^{m-1} du = m(m+1) \left[\frac{(1-x)^m}{m} - \frac{(1-x)^{m+1}}{m+1} \right] = (1-x)^m(1+mx).$$

所以 $\hat{\psi}_{\text{UMVU}} = \mathbf{1}_{\{T > c\}} \left(1 - \frac{c}{T}\right)^{2n-2} \left[1 + (2n-2)\frac{c}{T}\right]$ 。

Problem 9 (10 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2), \quad \mu \in \mathbb{R}, \quad \sigma^2 > 0.$$

给定如下层次先验:

$$\mu | \sigma^2 \sim N\left(m_0, \frac{\sigma^2}{\kappa_0}\right), \quad \sigma^2 \sim \text{IG}(\alpha_0, \beta_0),$$

其中 $\kappa_0 > 0, \alpha_0 > 2, \beta_0 > 0$, 且逆 Gamma 分布采用密度

$$\pi(v) = \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} v^{-\alpha_0-1} \exp\left(-\frac{\beta_0}{v}\right) \mathbf{1}_{\{v>0\}}.$$

- (a) (4 分) 求 $(\mu, \sigma^2) | X_1, \dots, X_n$ 的联合后验分布, 并给出全部后验超参数。

- (b) (3 分) 分别在平方误差损失

$$L_\mu(\mu, a) = (a - \mu)^2, \quad L_{\sigma^2}(\sigma^2, d) = (d - \sigma^2)^2$$



下, 求 μ 和 σ^2 的 Bayes 估计量。

- (c) (3 分) 求新观测 X_{n+1} 的后验预测分布。将其写成位置-尺度 Student t 分布, 并进一步写出相应标准化随机变量平方后的分布。

第 9 题解答

记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $Q = \sum_{i=1}^n (X_i - \bar{X})^2$ 。定义 $\kappa_n = \kappa_0 + n$, $m_n = \frac{\kappa_0 m_0 + n \bar{X}}{\kappa_n}$, $\alpha_n = \alpha_0 + \frac{n}{2}$, 以及 $\beta_n = \beta_0 + \frac{1}{2}Q + \frac{\kappa_0 n}{2\kappa_n}(\bar{X} - m_0)^2$ 。

- (1) 似然核为 $L(\mu, \sigma^2 | \mathbf{x}) \propto (\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$ 。条件先验核为 $\pi(\mu | \sigma^2) \propto (\sigma^2)^{-1/2} \exp \left\{ -\frac{\kappa_0(\mu - m_0)^2}{2\sigma^2} \right\}$

使用恒等式 $\sum_{i=1}^n (X_i - \mu)^2 + \kappa_0(\mu - m_0)^2 = Q + \frac{\kappa_0 n}{\kappa_n}(\bar{X} - m_0)^2 + \kappa_n(\mu - m_n)^2$, 得到后验分布仍属于

Normal-Inverse-Gamma 族, 且 $\mu | \sigma^2, \mathbf{X} \sim N \left(m_n, \frac{\sigma^2}{\kappa_n} \right)$, 以及 $\sigma^2 | \mathbf{X} \sim \text{IG}(\alpha_n, \beta_n)$ 。因此联合后验分

布可写为 $\pi(\mu, \sigma^2 | \mathbf{x}) = \pi(\mu | \sigma^2, \mathbf{x})\pi(\sigma^2 | \mathbf{x})$ 。

- (2) 平方损失下的 Bayes 估计量是后验均值, 因此 $\hat{\mu}_B = \mathbb{E}(\mu | \mathbf{X}) = m_n$ 。

对本题采用的逆 Gamma 参数化, 若 $V \sim \text{IG}(\alpha, \beta)$, 则 $\mathbb{E}V = \frac{\beta}{\alpha-1}$, $\alpha > 1$ 。故 $\widehat{\sigma^2}_B = \mathbb{E}(\sigma^2 | \mathbf{X}) = \frac{\beta_n}{\alpha_n - 1}$ 。

由于 $\alpha_0 > 2$, 故后验二阶矩也有限, 平方损失下的后验风险有定义。

- (3) 给定 σ^2 和数据,

$$\begin{aligned} X_{n+1} | \sigma^2, \mathbf{X} &= \mu + \varepsilon_{n+1}, \\ \mu | \sigma^2, \mathbf{X} &\sim N \left(m_n, \frac{\sigma^2}{\kappa_n} \right), \\ \varepsilon_{n+1} | \sigma^2 &\sim N(0, \sigma^2), \end{aligned}$$

且二者条件独立。因此 $X_{n+1} | \sigma^2, \mathbf{X} \sim N \left(m_n, \sigma^2 \left(1 + \frac{1}{\kappa_n} \right) \right)$ 。积分掉 $\sigma^2 | \mathbf{X} \sim \text{IG}(\alpha_n, \beta_n)$, 得到

$$X_{n+1} | \mathbf{X} \stackrel{d}{=} m_n + s_n T_{2\alpha_n},$$

其中 $T_{2\alpha_n} \sim t_{2\alpha_n}$, 且 $s_n^2 = \frac{\beta_n}{\alpha_n} \left(1 + \frac{1}{\kappa_n} \right) = \frac{\beta_n(\kappa_n + 1)}{\alpha_n \kappa_n}$ 。即 $\frac{X_{n+1} - m_n}{s_n} | \mathbf{X} \sim t_{2\alpha_n}$ 。由于 t_ν 随机变量

的平方服从 $F_{1,\nu}$, 故 $\left(\frac{X_{n+1} - m_n}{s_n} \right)^2 | \mathbf{X} \sim F_{1,2\alpha_n}$ 。

Problem 10 (15 分)


设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x | \theta), \quad \theta > 0,$$

其中

$$f(x | \theta) = \frac{2x}{\theta^2} \exp \left(-\frac{x^2}{\theta^2} \right) \mathbf{1}_{\{x>0\}}.$$

- (a) (5 分) 基于一阶原点矩求 θ 的矩估计量, 并求最大似然估计量。证明二者均为相合估计量。
 (b) (5 分) 计算单个观测所含的 Fisher 信息。求上述两个估计量的渐近分布, 并比较二者的渐近相对效率。



(c) (5 分) 考虑检验

$$H_0: \theta = \theta_0 \quad \text{对} \quad H_1: \theta \neq \theta_0,$$

其中 $\theta_0 > 0$ 已知。

推导广义似然比统计量, 并将 $-2\log \Lambda_n$ 写成 $\hat{\theta}/\theta_0$ 的显式函数。指出在 H_0 下一个相关枢轴量的精确分布, 给出渐近 level α 的拒绝域, 并写出由该似然比统计量反演得到的渐近 $1 - \alpha$ 置信集。

第 10 题解答

令 $Q_n = \sum_{i=1}^n X_i^2$ 。先作变换 $Y = X^2$ 。当 $y > 0$ 时, $x = \sqrt{y}$, $\left|\frac{dx}{dy}\right| = \frac{1}{2\sqrt{y}}$ 。故

$$f_Y(y) = \frac{2\sqrt{y}}{\theta^2} e^{-y/\theta^2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\theta^2} e^{-y/\theta^2} \mathbf{1}_{\{y>0\}}.$$

因此 $X^2 \sim \text{Exp}(\text{rate } 1/\theta^2)$ 。从而 $\mathbb{E}X^2 = \theta^2$, $\text{Var}(X^2) = \theta^4$ 。此外, $\mathbb{E}X = \theta \int_0^\infty u^{1/2} e^{-u} du = \theta \Gamma(3/2) = \frac{\sqrt{\pi}}{2} \theta$ 。故 $\text{Var}(X) = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \theta^2 \left(1 - \frac{\pi}{4}\right)$ 。

(1) 由一阶原点矩方程 $\bar{X} = \frac{\sqrt{\pi}}{2} \theta$, 得到矩估计量 $\tilde{\theta} = \frac{2\bar{X}}{\sqrt{\pi}}$ 。

样本似然为 $L_n(\theta) = \prod_{i=1}^n \left[\frac{2x_i}{\theta^2} e^{-x_i^2/\theta^2} \right]$ 。忽略不含 θ 的常数, $\ell_n(\theta) = -2n \log \theta - \frac{Q_n}{\theta^2} + C(x)$ 。一

阶导数为 $\ell'_n(\theta) = -\frac{2n}{\theta} + \frac{2Q_n}{\theta^3}$ 。令其为零, 得到 $\hat{\theta}^2 = \frac{Q_n}{n}$ 。由于 $\theta > 0$, $\hat{\theta} = \sqrt{\frac{1}{n} \sum_{i=1}^n X_i^2}$ 。在该点,

$\ell''_n(\hat{\theta}) = \frac{2n}{\hat{\theta}^2} - \frac{6Q_n}{\hat{\theta}^4} = -\frac{4n}{\hat{\theta}^2} < 0$ 。又当 $\theta \downarrow 0$ 或 $\theta \rightarrow \infty$ 时, $\ell_n(\theta) \rightarrow -\infty$, 故该驻点为唯一全局最大点。

由强大数律, $\bar{X} \xrightarrow{\text{a.s.}} \frac{\sqrt{\pi}}{2} \theta$, 所以 $\tilde{\theta} = \frac{2\bar{X}}{\sqrt{\pi}} \xrightarrow{\text{a.s.}} \theta$ 。又 $\frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{\text{a.s.}} \mathbb{E}X^2 = \theta^2$ 。由连续映射定理, $\hat{\theta} \xrightarrow{\text{a.s.}} \theta$ 。

因此 $\tilde{\theta}$ 与 $\hat{\theta}$ 均为强相合估计量。

(2) 单个观测的对数密度为 $\ell(\theta; X) = \log(2X) - 2 \log \theta - \frac{X^2}{\theta^2}$ 。score 为 $U_\theta(X) = \frac{\partial}{\partial \theta} \ell(\theta; X) = -\frac{2}{\theta} + \frac{2X^2}{\theta^3} = \frac{2(X^2 - \theta^2)}{\theta^3}$ 。

故 $I_1(\theta) = \mathbb{E}[U_\theta(X)^2] = \frac{4}{\theta^6} \text{Var}(X^2) = \frac{4}{\theta^2}$ 。

对矩估计量, 由中心极限定理, $\sqrt{n} \left(\bar{X} - \frac{\sqrt{\pi}}{2} \theta \right) \xrightarrow{d} N(0, \theta^2 (1 - \frac{\pi}{4}))$ 。乘以 $2/\sqrt{\pi}$, 得到

$$\sqrt{n}(\tilde{\theta} - \theta) \xrightarrow{d} N\left(0, \frac{\theta^2(4 - \pi)}{\pi}\right).$$

对 MLE, 令 $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n X_i^2$ 。则 $\mathbb{E}\bar{Y}_n = \theta^2$, $\text{Var}(X_i^2) = \theta^4$ 。由中心极限定理, $\sqrt{n}(\bar{Y}_n - \theta^2) \xrightarrow{d} N(0, \theta^4)$ 。

由于 $\hat{\theta} = g(\bar{Y}_n)$, $g(y) = \sqrt{y}$, 且 $g'(\theta^2) = \frac{1}{2\theta}$, 由 Delta 方法, $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N\left(0, \frac{\theta^2}{4}\right)$ 。注

意 $\frac{\theta^2}{4} = I_1(\theta)^{-1}$, 所以 MLE 渐近有效。

若定义矩估计相对于 MLE 的渐近相对效率为 $\text{ARE}(\tilde{\theta}, \hat{\theta}) = \frac{V_{\hat{\theta}}}{V_{\tilde{\theta}}}$, 则 $\text{ARE}(\tilde{\theta}, \hat{\theta}) = \frac{\theta^2/4}{\theta^2(4 - \pi)/\pi} = \frac{\pi}{4(4 - \pi)} < 1$ 。

等价地, MLE 相对于矩估计的效率比为 $\frac{V_{\tilde{\theta}}}{V_{\hat{\theta}}} = \frac{4(4 - \pi)}{\pi} > 1$ 。

(3) 非受限 MLE 为 $\hat{\theta} = \sqrt{\frac{Q_n}{n}}$ 。因此 $\Lambda_n = \frac{L_n(\theta_0)}{L_n(\hat{\theta})} = \frac{\theta_0^{-2n} \exp(-Q_n/\theta_0^2)}{\hat{\theta}^{-2n} \exp(-Q_n/\hat{\theta}^2)} = \left(\frac{\hat{\theta}}{\theta_0}\right)^{2n} \exp\left\{-\frac{Q_n}{\theta_0^2} + \frac{Q_n}{\hat{\theta}^2}\right\}$ 。由于 $Q_n = n\hat{\theta}^2$, 故 $\Lambda_n = \left(\frac{\hat{\theta}}{\theta_0}\right)^{2n} \exp\left\{n - n\frac{\hat{\theta}^2}{\theta_0^2}\right\}$ 。令 $r = \frac{\hat{\theta}}{\theta_0}$, 则

$$-2 \log \Lambda_n = -4n \log r - 2n(1 - r^2) = \boxed{2n(r^2 - 1 - 2 \log r)} = \boxed{2n(r^2 - 1 - \log r^2)}.$$

在 H_0 下, $\frac{X_i^2}{\theta_0^2} \sim \text{Exp}(1)$ 。所以 $\frac{2X_i^2}{\theta_0^2} \sim \chi_2^2$, 并且 $\boxed{\frac{2Q_n}{\theta_0^2} = \frac{2n\hat{\theta}^2}{\theta_0^2} \sim \chi_{2n}^2}$ 。若记 $V \sim \chi_{2n}^2$, 则在 H_0 下,

$$-2 \log \Lambda_n \stackrel{d}{=} 2n \left[\frac{V}{2n} - 1 - \log \left(\frac{V}{2n} \right) \right].$$

由 Wilks 定理, $-2 \log \Lambda_n \xrightarrow{d} \chi_1^2$ 。故渐近 level α 的拒绝域为 $\boxed{-2 \log \Lambda_n > \chi_{1,1-\alpha}^2}$ 。

反演该检验, 得到渐近 $1-\alpha$ 似然比置信集 $\boxed{C_{n,1-\alpha}^{\text{LR}} = \left\{ \theta > 0 : 2n \left[\left(\frac{\hat{\theta}}{\theta} \right)^2 - 1 - 2 \log \left(\frac{\hat{\theta}}{\theta} \right) \right] \leq \chi_{1,1-\alpha}^2 \right\}}$ 。

若 $q_- < 1 < q_+$ 是方程 $q - 1 - \log q = \frac{\chi_{1,1-\alpha}^2}{2n}$ 的两个正根, 则上述置信集等价于 $\boxed{C_{n,1-\alpha}^{\text{LR}} = \left[\frac{\hat{\theta}}{\sqrt{q_+}}, \frac{\hat{\theta}}{\sqrt{q_-}} \right]}$ 。

此外, 由精确枢轴量还可得到精确等尾区间 $\boxed{\left[\sqrt{\frac{2Q_n}{\chi_{2n,1-\alpha/2}^2}}, \sqrt{\frac{2Q_n}{\chi_{2n,\alpha/2}^2}} \right]}$ 。

Problem 11 (10 分)

设

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Beta}(\theta, 1), \quad \theta > 0,$$

即 $f(x | \theta) = \theta x^{\theta-1} \mathbf{1}_{\{0 < x < 1\}}$ 。定义 $T = -\sum_{i=1}^n \log X_i$ 。

(a) (4 分) 对已知 $\theta_0 > 0$, 构造检验

$$H_0 : \theta \leq \theta_0 \quad \text{对} \quad H_1 : \theta > \theta_0$$

的 size α 一致最大功效检验。将拒绝域写成卡方分位数的形式, 并求其功效函数。

(b) (3 分) 对

$$H_0 : \theta = \theta_0 \quad \text{对} \quad H_1 : \theta \neq \theta_0,$$

判断当 $0 < \alpha < 1/2$ 时是否存在 size α 的一致最大功效检验, 并严格论证你的结论。

(c) (3 分) 构造 θ 的精确等尾 $1-\alpha$ 置信区间。

第 11 题解答

令 $Y_i = -\log X_i$ 。对 $y > 0$, 有 $x = e^{-y}$, $\left| \frac{dx}{dy} \right| = e^{-y}$ 。因此 $f_{Y_i}(y) = \theta(e^{-y})^{\theta-1} e^{-y} = \theta e^{-\theta y}$, $y > 0$ 。故 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\text{rate } \theta)$ 。于是 $T = \sum_{i=1}^n Y_i \sim \text{Gamma}(n, \theta)$, 并且 $\boxed{2\theta T \sim \chi_{2n}^2}$ 。

(1) T 的密度为 $g_\theta(t) = \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t}$, $t > 0$ 。若 $\theta_2 > \theta_1$, 则 $\frac{g_{\theta_2}(t)}{g_{\theta_1}(t)} = \left(\frac{\theta_2}{\theta_1}\right)^n e^{-(\theta_2-\theta_1)t}$ 。该比值关于 t 严格递减。因此较大的 θ 对应较小的 T , 故针对 $H_1 : \theta > \theta_0$ 应在 T 较小时拒绝。

选择 c_α 满足 $\mathbb{P}_{\theta_0}(T \leq c_\alpha) = \alpha$ 。由 $2\theta_0 T \sim \chi_{2n}^2$, 有 $c_\alpha = \frac{\chi_{2n,\alpha}^2}{2\theta_0}$ 。故拒绝域为 $\boxed{2\theta_0 T \leq \chi_{2n,\alpha}^2}$ 。

对于固定临界值 c_α , $\mathbb{P}_\theta(T \leq c_\alpha)$ 关于 θ 非减。因此在原假设 $\theta \leq \theta_0$ 上, 最大拒绝概率在边界 θ_0 达到, 并且等于 α 。所以该检验的 size 为 α 。

由单调似然比性质和 Karlin–Rubin 定理, 该检验是 UMP。

其功效函数为 $\beta(\theta) = \mathbb{P}_\theta\left(T \leq \frac{\chi_{2n,\alpha}^2}{2\theta_0}\right) = \mathbb{P}\left(2\theta T \leq \frac{\theta}{\theta_0} \chi_{2n,\alpha}^2\right)$ 。因为 $2\theta T \sim \chi_{2n}^2$, 故 $\beta(\theta) = F_{\chi_{2n}^2}\left(\frac{\theta}{\theta_0} \chi_{2n,\alpha}^2\right)$ 。

(2) 不存在这样的 UMP 检验。

任取 $\theta_1 > \theta_0$ 。由 Neyman–Pearson 引理, 检验 $H_0: \theta = \theta_0$ 对 $H_1: \theta = \theta_1$ 的唯一 size α 最强检验在下尾拒绝, 即 $\phi_L = \mathbf{1}_{\{T \leq c_L\}}$, 其中 $c_L = \frac{\chi_{2n,\alpha}^2}{2\theta_0}$ 。

再任取 $0 < \theta_2 < \theta_0$ 。此时 $\frac{g_{\theta_2}(t)}{g_{\theta_0}(t)} = \left(\frac{\theta_2}{\theta_0}\right)^n e^{(\theta_0 - \theta_2)t}$, 它关于 t 严格增加。因此针对简单备择 θ_2 的唯一 size α 最强检验在上尾拒绝, 即 $\phi_U = \mathbf{1}_{\{T \geq c_U\}}$, 其中 $c_U = \frac{\chi_{2n,1-\alpha}^2}{2\theta_0}$ 。

因为 $0 < \alpha < \frac{1}{2}$, 所以 $\chi_{2n,\alpha}^2 < \chi_{2n,1-\alpha}^2$, 从而 $c_L < c_U$ 。两个拒绝域分别位于相反两尾, 并且在 P_{θ_0} 的概率集合上不同。

若双侧 UMP 检验存在, 则它必须在备择点 θ_1 处与唯一的最强检验 ϕ_L 几乎处处相同; 同时又必须在备择点 θ_2 处与唯一的最强检验 ϕ_U 几乎处处相同。这不可能。

故 $H_0: \theta = \theta_0$ 对 $H_1: \theta \neq \theta_0$ 不存在 size α 的 UMP 检验。

(3) 由枢轴量 $2\theta T \sim \chi_{2n}^2$, 有 $\mathbb{P}_\theta\left(\chi_{2n,\alpha/2}^2 \leq 2\theta T \leq \chi_{2n,1-\alpha/2}^2\right) = 1 - \alpha$ 。由于 $T > 0$, 直接反演不等式得到

$$\theta \in \left[\frac{\chi_{2n,\alpha/2}^2}{2T}, \frac{\chi_{2n,1-\alpha/2}^2}{2T} \right].$$

该区间为精确等尾 $1 - \alpha$ 置信区间。



35.2 第二套试题 + 答案

Problem 1 (10 分)

设 $X_1, X_2, X_3 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 并定义

$$R = \sqrt{X_1^2 + X_2^2 + X_3^2}, \quad V = \frac{X_1 + X_2 + X_3}{R}.$$

由于 $\mathbb{P}(R=0)=0$, 上述 V 几乎处处有定义。

- (1) 求随机向量 (R, V) 的联合密度, 明确写出其支持集, 并判断 R 与 V 是否独立。
- (2) 求条件期望 $\mathbb{E}(R \mid \sigma(V))$ 。
- (3) 计算 $\text{Corr}(R^2, (X_1 + X_2 + X_3)^2)$ 。

第 1 题解答

令 $Y_1 = \frac{X_1 + X_2 + X_3}{\sqrt{3}}$. 再选择 Y_2, Y_3 , 使 $(Y_1, Y_2, Y_3)^\top$ 是 $(X_1, X_2, X_3)^\top$ 的一个正交变换。于是 $Y_1, Y_2, Y_3 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 并且 $R = \sqrt{Y_1^2 + Y_2^2 + Y_3^2}$, $V = \sqrt{3} \frac{Y_1}{R}$ 。

- (1) 由三维标准正态分布的球对称性, $R \perp \frac{(Y_1, Y_2, Y_3)}{R}$ 。又 $R \sim \chi_3$, 因而 $f_R(r) = \sqrt{\frac{2}{\pi}} r^2 e^{-r^2/2} \mathbf{1}_{\{r>0\}}$ 。

令 $U = \frac{Y_1}{R}$ 。球面上的方向均匀分布。在三维情形, 固定方向上的投影 U 在 $[-1, 1]$ 上均匀分布: $f_U(u) = \frac{1}{2} \mathbf{1}_{\{-1 < u < 1\}}$ 。因为 $V = \sqrt{3}U$, $f_V(v) = \frac{1}{2\sqrt{3}} \mathbf{1}_{\{-\sqrt{3} < v < \sqrt{3}\}}$ 。

因此 R 与 V 独立, 且联合密度为 $f_{R,V}(r, v) = \frac{r^2 e^{-r^2/2}}{\sqrt{6\pi}} \mathbf{1}_{\{r>0, |v|<\sqrt{3}\}}$ 。

- (2) 由 $R \perp V$, $\mathbb{E}(R \mid \sigma(V)) = \mathbb{E}R$ a.s.。 χ_3 分布的均值为 $\mathbb{E}R = \sqrt{2} \frac{\Gamma(2)}{\Gamma(3/2)} = 2\sqrt{\frac{2}{\pi}}$ 。故

$$\mathbb{E}(R \mid \sigma(V)) = 2\sqrt{\frac{2}{\pi}} \quad \text{a.s.}$$

- (3) 记 $Z = Y_1 \sim N(0, 1)$, $H = Y_2^2 + Y_3^2$ 。则 $Z \perp H$, 且 $R^2 = Z^2 + H$, $(X_1 + X_2 + X_3)^2 = 3Z^2$ 。因此 $\text{Cov}(R^2, 3Z^2) = 3 \text{Var}(Z^2) = 3 \cdot 2 = 6$ 。另一方面, $\text{Var}(R^2) = \text{Var}(\chi_3^2) = 6$, 以及 $\text{Var}(3Z^2) = 9 \text{Var}(Z^2) = 18$ 。所以 $\text{Corr}(R^2, (X_1 + X_2 + X_3)^2) = \frac{6}{\sqrt{6 \cdot 18}} = \frac{1}{\sqrt{3}}$ 。


Problem 2 (15 分)

固定 $\lambda \in (0, 1]$ 。对每个 $n \geq 1$, 设 $\{\varepsilon_{n,k}, J_{n,k} : 1 \leq k \leq n\}$ 相互独立, 其中 $\mathbb{P}(\varepsilon_{n,k} = 1) = \mathbb{P}(\varepsilon_{n,k} = -1) = \frac{1}{2}$, 且

$$\mathbb{P}(J_{n,k} = 1) = \mathbb{P}(J_{n,k} = -1) = \frac{\lambda}{2n}, \quad \mathbb{P}(J_{n,k} = 0) = 1 - \frac{\lambda}{n}.$$

定义

$$\xi_{n,k} = \frac{\varepsilon_{n,k}}{\sqrt{n}} + J_{n,k}, \quad S_n = \sum_{k=1}^n \xi_{n,k}, \quad Q_n = \sum_{k=1}^n \xi_{n,k}^2.$$



(1) 求 (S_n, Q_n) 的联合弱极限。要求用三个相互独立的随机变量

$$Z \sim N(0, 1), \quad N_+ \sim \text{Poisson}(\lambda/2), \quad N_- \sim \text{Poisson}(\lambda/2)$$

明确表示该极限。

(2) 求 $\frac{S_n}{\sqrt{Q_n}}$ 的极限分布。

(3) 判断随机变量族 $\{S_n^2 : n \geq 1\}$ 是否一致可积, 并求 $\lim_{n \rightarrow \infty} \mathbb{E}(S_n^2)$.

第 2 题解答

定义 $A_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k}$, 以及 $N_{n,+} = \sum_{k=1}^n \mathbf{1}_{\{J_{n,k}=1\}}$, $N_{n,-} = \sum_{k=1}^n \mathbf{1}_{\{J_{n,k}=-1\}}$. 则 $S_n = A_n + N_{n,+} - N_{n,-}$.

(1) 对任意 $z_+, z_- \geq 0$,

$$\mathbb{E} \left(z_+^{N_{n,+}} z_-^{N_{n,-}} \right) = \left[1 + \frac{\lambda}{2n} (z_+ - 1) + \frac{\lambda}{2n} (z_- - 1) \right]^n \longrightarrow \exp \left\{ \frac{\lambda}{2} (z_+ - 1) + \frac{\lambda}{2} (z_- - 1) \right\}.$$

因而 $(N_{n,+}, N_{n,-}) \xrightarrow{d} (N_+, N_-)$, 其中 $N_+, N_- \perp\!\!\!\perp$, $N_+, N_- \sim \text{Poisson}(\lambda/2)$ 。

由中心极限定理, $A_n \xrightarrow{d} Z$, $Z \sim N(0, 1)$ 。对每个 n , $A_n \perp\!\!\!\perp (N_{n,+}, N_{n,-})$, 因此极限中的 Z, N_+, N_- 相互独立。

再考察 Q_n 。有

$$Q_n = \sum_{k=1}^n \left(\frac{1}{n} + \frac{2\varepsilon_{n,k} J_{n,k}}{\sqrt{n}} + J_{n,k}^2 \right) = 1 + N_{n,+} + N_{n,-} + R_n,$$

其中 $R_n = \frac{2}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k} J_{n,k}$ 。由于 $\mathbb{E} R_n = 0$ 且

$$\mathbb{E}(R_n^2) = \frac{4}{n} \sum_{k=1}^n \mathbb{E}(J_{n,k}^2) = \frac{4}{n} \cdot n \cdot \frac{\lambda}{n} = \frac{4\lambda}{n} \longrightarrow 0,$$

故 $R_n \xrightarrow{\mathbb{P}} 0$ 。

由 Slutsky 定理, $(S_n, Q_n) \xrightarrow{d} (Z + N_+ - N_-, 1 + N_+ + N_-)$, 其中 Z, N_+, N_- 相互独立。

(2) 极限中的第二个分量至少为 1, 故函数 $(x, y) \mapsto \frac{x}{\sqrt{y}}$ 在极限随机向量的取值范围上连续。由连续映射定

理, $\frac{S_n}{\sqrt{Q_n}} \xrightarrow{d} \frac{Z + N_+ - N_-}{\sqrt{1 + N_+ + N_-}}.$

(3) 对每个 k , $\mathbb{E} \xi_{n,k} = 0$, 且 $\mathbb{E}(\xi_{n,k}^2) = \frac{1}{n} + \frac{\lambda}{n} = \frac{1+\lambda}{n}$ 。因此 $\mathbb{E}(S_n^2) = 1 + \lambda$ 对所有 n 都成立。


为证明 $\{S_n^2\}$ 一致可积, 计算四阶矩。由对称性和独立性,

$$\mathbb{E}(\xi_{n,k}^4) = \frac{1}{n^2} + \frac{6}{n} \mathbb{E}(J_{n,k}^2) + \mathbb{E}(J_{n,k}^4) = \frac{1}{n^2} + \frac{6\lambda}{n^2} + \frac{\lambda}{n}.$$

对独立零均值随机变量,

$$\mathbb{E}(S_n^4) = n \mathbb{E}(\xi_{n,1}^4) + 3n(n-1) [\mathbb{E}(\xi_{n,1}^2)]^2 = \lambda + \frac{1+6\lambda}{n} + 3 \frac{n-1}{n} (1+\lambda)^2.$$

因而 $\sup_n \mathbb{E}(S_n^4) < \infty$ 。即 $\sup_n \mathbb{E}[(S_n^2)^2] < \infty$, 所以 $\{S_n^2\}$ 一致可积。



最后, $\lim_{n \rightarrow \infty} \mathbb{E}(S_n^2) = 1 + \lambda$.

Problem 3 (10 分)

设 $\{\varepsilon_k\}_{k \geq 1}$ 为独立同分布随机变量, 且 $\mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}$. 令 $\mathcal{F}_n = \sigma(\varepsilon_1, \dots, \varepsilon_n)$, $M_0 = 1$, 并对 $n \geq 1$ 定义 $M_n = \prod_{k=1}^n \left(1 + \frac{\varepsilon_k}{\sqrt{k+1}}\right)$.

- (1) 证明 $\{M_n, \mathcal{F}_n\}_{n \geq 0}$ 是一个非负鞅, 并证明存在有限随机变量 M_∞ 使得 $M_n \rightarrow M_\infty$ a.s..
- (2) 确定 M_∞ 的值, 并判断 M_n 是否在 L^1 中收敛. 进一步判断随机变量族 $\{M_n : n \geq 0\}$ 是否一致可积.

第 3 题解答

- (1) 对每个 n , $M_n = M_{n-1} \left(1 + \frac{\varepsilon_n}{\sqrt{n+1}}\right)$. 显然 M_n 是 $\mathcal{F}_n$ -可测的, 并且 $1 - \frac{1}{\sqrt{n+1}} > 0$, 故 $M_n \geq 0$. 又因为 ε_n 独立于 $\mathcal{F}_{n-1}$, 且 $\mathbb{E}\varepsilon_n = 0$,

$$\mathbb{E}(M_n | \mathcal{F}_{n-1}) = M_{n-1} \mathbb{E} \left(1 + \frac{\varepsilon_n}{\sqrt{n+1}}\right) = M_{n-1}.$$

同时 $\mathbb{E}M_n = \mathbb{E}M_0 = 1$, 故 M_n 可积.

因此 $\{M_n, \mathcal{F}_n\}$ 是非负鞅. 由非负鞅收敛定理, 存在有限随机变量 M_∞ , 使得 $M_n \rightarrow M_\infty$ a.s..

- (2) 令 $a_k = \frac{1}{\sqrt{k+1}}$, $b_k = \frac{1}{2} \log \frac{1+a_k}{1-a_k}$. 对 $\varepsilon_k \in \{-1, 1\}$, $\log(1 + \varepsilon_k a_k) = \frac{1}{2} \log(1 - a_k^2) + \varepsilon_k b_k$. 因此

$$\log M_n = \frac{1}{2} \sum_{k=1}^n \log \left(1 - \frac{1}{k+1}\right) + \sum_{k=1}^n \varepsilon_k b_k = \frac{1}{2} \log \prod_{k=1}^n \frac{k}{k+1} + \sum_{k=1}^n \varepsilon_k b_k = -\frac{1}{2} \log(n+1) + \sum_{k=1}^n \varepsilon_k b_k.$$

当 $k \rightarrow \infty$ 时, $b_k \sim \frac{1}{\sqrt{k+1}}$, 因而 $\sum_{k=1}^{\infty} \frac{b_k^2}{[\log(k+1)]^2} < \infty$. 独立零均值级数 $\sum_{k=1}^{\infty} \frac{\varepsilon_k b_k}{\log(k+1)}$ 的方差和有限, 故该级数几乎处处收敛. 由 Kronecker 引理, $\frac{1}{\log(n+1)} \sum_{k=1}^n \varepsilon_k b_k \rightarrow 0$ a.s.. 因此 $\frac{\log M_n}{\log(n+1)} \rightarrow -\frac{1}{2}$ a.s., 从而 $\log M_n \rightarrow -\infty$ a.s.. 所以 $M_\infty = 0$ a.s..

但是对所有 n , $\mathbb{E}M_n = 1$. 若 $M_n \rightarrow 0$ 在 L^1 中成立, 则应有 $\mathbb{E}M_n \rightarrow 0$, 与 $\mathbb{E}M_n = 1$ 矛盾. 因此 M_n 不在 L^1 中收敛.

若 $\{M_n\}$ 一致可积, 则由 $M_n \rightarrow 0$ a.s. 可推出 $M_n \rightarrow 0$ 于 L^1 , 同样矛盾. 因此 $\{M_n : n \geq 0\}$ 不是一致可积的.

Problem 4 (10 分)

设 $\{X_n\}_{n \geq 0}$ 是状态空间 $\mathcal{S} = \{0, 1, 2, \dots\}$ 上的时齐 Markov 链, 其转移概率为 $P(0, 1) = 1$, 且对每个 $i \geq 1$, $P(i, i+1) = \frac{i+1}{2i+1}$, $P(i, i-1) = \frac{i}{2i+1}$. 对 $j \in \mathcal{S}$, 定义 $\tau_j = \inf\{n \geq 0 : X_n = j\}$.

- (1) 对整数 $m \geq 2$ 和 $1 \leq i \leq m-1$, 求 $\mathbb{P}_i(\tau_m < \tau_0)$. 其中 $\mathbb{P}_i$ 表示在 $X_0 = i$ 条件下的概率.
- (2) 判断该链是暂留、正常返还是零常返, 并求其周期.
- (3) 求一个严格正的可逆测度 $\{\pi_i\}_{i \geq 0}$. 判断该链是否存在平稳概率分布.

第 4 题解答

记调和数 $H_j = \sum_{k=1}^j \frac{1}{k}$, $H_0 = 0$.

- (1) 令 $h_i = \mathbb{P}_i(\tau_m < \tau_0)$, $0 \leq i \leq m$. 边界条件为 $h_0 = 0$, $h_m = 1$. 对 $1 \leq i \leq m-1$, $h_i = \frac{i+1}{2i+1} h_{i+1} + \frac{i}{2i+1} h_{i-1}$

$\frac{i}{2i+1}h_{i-1}$ 。等价地, $(i+1)(h_{i+1}-h_i) = i(h_i-h_{i-1})$ 。令 $\Delta_i = h_i - h_{i-1}$ 。则 $\Delta_{i+1} = \frac{i}{i+1}\Delta_i$, 从而 $\Delta_i = \frac{\Delta_1}{i}$ 。

因此 $h_i = \Delta_1 \sum_{k=1}^i \frac{1}{k} = \Delta_1 H_i$ 。由 $h_m = 1$, $\Delta_1 = \frac{1}{H_m}$ 。所以 $\mathbb{P}_i(\tau_m < \tau_0) = \frac{H_i}{H_m}$, $1 \leq i \leq m-1$ 。

- (2) 从状态 1 出发, $\mathbb{P}_1(\tau_m < \tau_0) = \frac{1}{H_m} \rightarrow 0$ 。对固定 m , 从集合 $\{1, \dots, m-1\}$ 出发, $\tau_0 \wedge \tau_m < \infty$ 几乎处处成立。因此 $\mathbb{P}_1(\tau_0 = \infty) \leq \lim_{m \rightarrow \infty} \mathbb{P}_1(\tau_m < \tau_0) = 0$ 。即从 1 出发几乎必然到达 0。由于从 0 必然先走到 1, 故 0 几乎必然返回自身。该链不可约, 所以所有状态均常返。

下面求一个不变测度。取 $\pi_i = 2i+1$, $i \geq 0$ 。对边 $0 \leftrightarrow 1$, $\pi_0 P(0, 1) = 1 = 3 \cdot \frac{1}{3} = \pi_1 P(1, 0)$ 。对 $i \geq 1$,

$$\begin{aligned}\pi_i P(i, i+1) &= (2i+1) \frac{i+1}{2i+1} = i+1, \\ \pi_{i+1} P(i+1, i) &= (2i+3) \frac{i+1}{2i+3} = i+1.\end{aligned}$$

因此 π 是可逆测度。

但是 $\sum_{i=0}^{\infty} \pi_i = \sum_{i=0}^{\infty} (2i+1) = \infty$, 不能归一化为概率分布。不可约常返链若正常返, 则存在平稳概率分布。因此该链不是正常返, 而是零常返: 该链是零常返链。

该链每一步都改变状态的奇偶性, 故返回任一状态所需步数必为偶数。又 $P^2(0, 0) = P(0, 1)P(1, 0) = \frac{1}{3} > 0$ 。所以 该链的周期为 2。

- (3) 一个严格正的可逆测度为 $\pi_i = C(2i+1)$, $i \geq 0$, 其中 $C > 0$ 为任意常数。

下面直接说明不存在其他平稳概率分布。若 ρ 是平稳概率分布, 在状态 0 的平衡方程给出 $\rho_0 = \frac{1}{3}\rho_1$ 。定义相邻状态间的概率流 $J_i = \rho_i P(i, i+1) - \rho_{i+1} P(i+1, i)$ 。平稳方程蕴含 $J_i = J_{i-1}$, 而 $J_0 = \rho_0 - \frac{1}{3}\rho_1 = 0$ 。因而 $J_i = 0$ 对所有 i 成立, 即 ρ 必须满足详细平衡。递推得到 $\rho_i = (2i+1)\rho_0$ 。若 $\rho_0 > 0$, 则其总和发散; 若 $\rho_0 = 0$, 则所有 $\rho_i = 0$ 。所以 该链不存在平稳概率分布。

Problem 5 (10 分)

设 $\{N_t\}_{t \geq 0}$ 是强度为 $\lambda > 0$ 的 Poisson 过程, 并定义 $A_t = \int_0^t N_s \, ds$, $t \geq 0$ 。

- (1) 对任意 $u, v \geq 0$, 求联合 Laplace 变换 $\mathbb{E}[\exp\{-uN_t - vA_t\}]$ 。在 $v = 0$ 时, 答案中出现的 $\frac{1-e^{-vt}}{v}$ 按连续延拓定义为 t 。
- (2) 求 $\mathbb{E}(A_t \mid \sigma(N_t))$ 和 $\text{Var}(A_t \mid \sigma(N_t))$ 。
- (3) 对 $0 < s \leq t$, 计算 $\text{Cov}(A_s, A_t)$ 。

第 5 题解答

设 Poisson 过程在 $(0, t]$ 内的到达时刻为 $0 < T_1 < \dots < T_{N_t} \leq t$ 。则 $A_t = \int_0^t N_s \, ds = \sum_{j=1}^{N_t} (t - T_j)$ 。

- (1) 给定 $N_t = n$ 后, 无序到达时刻与 $U_1, \dots, U_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}(0, t)$ 同分布。因此对 $v > 0$,

$$\mathbb{E}[e^{-uN_t - vA_t} \mid N_t = n] = e^{-un} \left[\frac{1}{t} \int_0^t e^{-v(t-s)} \, ds \right]^n = \left[e^{-u} \frac{1 - e^{-vt}}{vt} \right]^n.$$

由于 $N_t \sim \text{Poisson}(\lambda t)$, $\mathbb{E}(q^{N_t}) = \exp\{\lambda t(q-1)\}$ 。取 $q = e^{-u} \frac{1 - e^{-vt}}{vt}$, 得

$$\mathbb{E}[e^{-uN_t - vA_t}] = \exp \left\{ \lambda \left[e^{-u} \frac{1 - e^{-vt}}{v} - t \right] \right\}, \quad v > 0.$$

当 $v = 0$ 时取连续延拓, $\mathbb{E}(e^{-uN_t}) = \exp\{\lambda t(e^{-u} - 1)\}$.

- (2) 给定 $N_t = n$, $A_t \stackrel{d}{=} \sum_{j=1}^n (t - U_j)$, 且 $t - U_j \sim \text{Unif}(0, t)$ 。所以 $\mathbb{E}(A_t | N_t = n) = \frac{nt}{2}$, 以及 $\text{Var}(A_t | N_t = n) = \frac{nt^2}{12}$ 。因此 $\mathbb{E}(A_t | \sigma(N_t)) = \frac{t}{2}N_t$, 且 $\text{Var}(A_t | \sigma(N_t)) = \frac{t^2}{12}N_t$ 。
- (3) 对 Poisson 过程, $\text{Cov}(N_u, N_v) = \lambda \min\{u, v\}$ 。因而, 当 $0 < s \leq t$ 时,

$$\begin{aligned}\text{Cov}(A_s, A_t) &= \int_0^s \int_0^t \text{Cov}(N_u, N_v) \, dv \, du = \lambda \int_0^s \left[\int_0^u v \, dv + \int_u^t u \, dv \right] du \\ &= \lambda \int_0^s \left(ut - \frac{u^2}{2} \right) du = \lambda \left(\frac{ts^2}{2} - \frac{s^3}{6} \right).\end{aligned}$$

$$\text{故 } \boxed{\text{Cov}(A_s, A_t) = \frac{\lambda s^2(3t - s)}{6}, \quad 0 < s \leq t.}$$

Problem 6 (15 分)

设 $\{B_t\}_{0 \leq t \leq 1}$ 是从 0 出发的一维标准 Brownian motion, 并定义 Brownian bridge

$$W_t = B_t - tB_1, \quad 0 \leq t \leq 1.$$

令

$$K(s, t) = \min\{s, t\} - st, \quad e_k(t) = \sqrt{2} \sin(k\pi t), \quad k \geq 1,$$

以及 $A = \int_0^1 W_t^2 \, dt$ 。

- (1) 求 W 的均值函数和协方差函数, 并证明对每个 $k \geq 1$,

$$\int_0^1 K(s, t) e_k(s) \, ds = \frac{1}{k^2 \pi^2} e_k(t).$$

- (2) 定义 $Z_k = k\pi \int_0^1 W_t e_k(t) \, dt, k \geq 1$ 。证明 $\{Z_k\}_{k \geq 1}$ 是独立同分布的标准正态随机变量, 并证明 $A = \sum_{k=1}^{\infty} \frac{Z_k^2}{k^2 \pi^2}$ a.s.。
- (3) 对任意 $\theta \geq 0$, 求 $\mathbb{E}(e^{-\theta A})$ 的收敛无穷乘积表达式, 并计算 $\mathbb{E}(A)$ 和 $\text{Var}(A)$ 。


第 6 题解答

- (1) 由于 $W_t = B_t - tB_1$, 有 $\mathbb{E}W_t = 0$ 。对 $s, t \in [0, 1]$,

$$\begin{aligned}\text{Cov}(W_s, W_t) &= \text{Cov}(B_s - sB_1, B_t - tB_1) \\ &= \min\{s, t\} - t \text{Cov}(B_s, B_1) - s \text{Cov}(B_t, B_1) + st \text{Var}(B_1) \\ &= \min\{s, t\} - st.\end{aligned}$$

$$\text{因此 } \boxed{\mathbb{E}W_t = 0, \quad \text{Cov}(W_s, W_t) = K(s, t) = \min\{s, t\} - st.}$$

对固定 k , 令 $g_k(t) = \int_0^1 K(s, t) e_k(s) \, ds$ 。由 $K(s, t) = \begin{cases} s(1-t), & s \leq t, \\ t(1-s), & s > t, \end{cases}$ 可写为 $g_k(t) = (1-t) \int_0^t s e_k(s) \, ds + t \int_t^1 (1-s) e_k(s) \, ds$ 。直接微分得到 $-g_k''(t) = e_k(t)$, $g_k(0) = g_k(1) = 0$ 。又因为 $-e_k''(t) = k^2 \pi^2 e_k(t)$, $e_k(0) =$



$e_k(1) = 0$, 函数 $\frac{1}{k^2\pi^2}e_k(t)$ 满足同一个边值问题。由解的唯一性, $\int_0^1 K(s, t)e_k(s) ds = \frac{1}{k^2\pi^2}e_k(t)$.

(2) 对任意有限的 m , $(\int_0^1 W_t e_1(t) dt, \dots, \int_0^1 W_t e_m(t) dt)$ 是中心高斯向量。事实上, 这些积分可由高斯 Riemann 和在 L^2 中逼近。

对 $j, k \geq 1$,

$$\begin{aligned}\text{Cov}(Z_j, Z_k) &= j\pi k\pi \int_0^1 \int_0^1 K(s, t)e_j(s)e_k(t) ds dt = j\pi k\pi \int_0^1 \frac{e_j(t)}{j^2\pi^2}e_k(t) dt \\ &= \frac{k}{j} \int_0^1 e_j(t)e_k(t) dt = \mathbf{1}_{\{j=k\}}.\end{aligned}$$

因此 $\{Z_k\}$ 是一族联合高斯、均值为零、协方差矩阵为单位阵的随机变量, 所以 $Z_1, Z_2, \dots \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. Brownian bridge 的样本路径几乎处处连续, 故几乎处处属于 $L^2[0, 1]$ 。而 $\{e_k : k \geq 1\}$ 是 $L^2[0, 1]$ 的完备标准正交基。由 Parseval 恒等式,

$$A = \int_0^1 W_t^2 dt = \sum_{k=1}^{\infty} \left(\int_0^1 W_t e_k(t) dt \right)^2 = \sum_{k=1}^{\infty} \frac{Z_k^2}{k^2\pi^2} \quad \text{a.s.}$$

即 $A = \sum_{k=1}^{\infty} \frac{Z_k^2}{k^2\pi^2} \quad \text{a.s.}$

(3) 令 $A_m = \sum_{k=1}^m \frac{Z_k^2}{k^2\pi^2}$ 。则 $A_m \uparrow A$ 。利用 Z_k 的独立性以及 $\mathbb{E}(e^{-aZ^2}) = (1+2a)^{-1/2}$, $a \geq 0$, 得

$$\mathbb{E}(e^{-\theta A_m}) = \prod_{k=1}^m \left(1 + \frac{2\theta}{k^2\pi^2} \right)^{-1/2}. \quad \text{令 } m \rightarrow \infty, \text{ 由有界收敛定理, } \mathbb{E}(e^{-\theta A}) = \prod_{k=1}^{\infty} \left(1 + \frac{2\theta}{k^2\pi^2} \right)^{-1/2}, \quad \theta \geq 0.$$

该乘积收敛, 因为 $\sum_{k=1}^{\infty} \frac{2\theta}{k^2\pi^2} < \infty$ 。

由 Euler 乘积 $\frac{\sinh x}{x} = \prod_{k=1}^{\infty} \left(1 + \frac{x^2}{k^2\pi^2} \right)$, 还可写成 $\mathbb{E}(e^{-\theta A}) = \left(\frac{\sqrt{2\theta}}{\sinh \sqrt{2\theta}} \right)^{1/2}$, 其中 $\theta = 0$ 时按连续延拓取值 1。

由于 $\mathbb{E}(Z_k^2) = 1$, $\text{Var}(Z_k^2) = 2$, 有 $\mathbb{E}A = \frac{1}{\pi^2} \sum_{k=1}^{\infty} \frac{1}{k^2} = \frac{1}{\pi^2} \cdot \frac{\pi^2}{6} = \frac{1}{6}$, 以及 $\text{Var}(A) = \frac{2}{\pi^4} \sum_{k=1}^{\infty} \frac{1}{k^4} = \frac{2}{\pi^4} \cdot \frac{\pi^4}{90} = \frac{1}{45}$ 。

因此 $\mathbb{E}A = \frac{1}{6}, \quad \text{Var}(A) = \frac{1}{45}.$

Problem 7 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x; \theta), \theta > 0$, 其中

$$f(x; \theta) = \sqrt{\frac{2}{\pi}} \frac{x^2}{\theta^3} \exp\left(-\frac{x^2}{2\theta^2}\right) \mathbf{1}_{\{x>0\}}.$$

- (1) 分别构造基于二阶原点矩 $\mathbb{E}_{\theta}(X^2)$ 的矩估计量和 θ 的最大似然估计量, 并判断二者是否相同。
- (2) 求最大似然估计量的有限样本精确分布, 并据此构造 θ 的一个精确 $1 - \alpha$ 置信区间。
- (3) 求单个观测关于 θ 的 Fisher 信息, 并求最大似然估计量的渐近分布。



第 7 题解答

注意 $\frac{X_i^2}{\theta^2} \sim \chi_3^2$. 因此 $\mathbb{E}_\theta(X_i^2) = 3\theta^2$, $\text{Var}_\theta(X_i^2) = 6\theta^4$.

(1) 令 $M_{2,n} = \frac{1}{n} \sum_{i=1}^n X_i^2$. 由矩方程 $M_{2,n} = 3\theta^2$ 得矩估计量 $\tilde{\theta}_n = \sqrt{\frac{1}{3n} \sum_{i=1}^n X_i^2}$.

对数似然中与 θ 有关的部分为 $\ell_n(\theta) = -3n \log \theta - \frac{1}{2\theta^2} \sum_{i=1}^n X_i^2 + C$. 求导得 $\ell'_n(\theta) = -\frac{3n}{\theta} + \frac{\sum_i X_i^2}{\theta^3}$. 似然方程的唯一正根为 $\hat{\theta}_n^2 = \frac{1}{3n} \sum_{i=1}^n X_i^2$. 由于当 $\theta \downarrow 0$ 或 $\theta \rightarrow \infty$ 时 $\ell_n(\theta) \rightarrow -\infty$, 该根为全局最大点. 因此

此 $\hat{\theta}_n = \sqrt{\frac{1}{3n} \sum_{i=1}^n X_i^2}$. 所以矩估计量与最大似然估计量完全相同.

(2) 因为 $\sum_{i=1}^n \frac{X_i^2}{\theta^2} \sim \chi_{3n}^2$, 故 $\frac{3n\hat{\theta}_n^2}{\theta^2} \sim \chi_{3n}^2$. 这给出了 $\hat{\theta}_n$ 的有限样本精确分布; 等价地, $\frac{\sqrt{3n}\hat{\theta}_n}{\theta}$ 服从自由度为 $3n$ 的 χ 分布.

由 $\mathbb{P}\left(\chi_{3n,\alpha/2}^2 \leq \frac{3n\hat{\theta}_n^2}{\theta^2} \leq \chi_{3n,1-\alpha/2}^2\right) = 1-\alpha$, 解出 θ , 得到精确置信区间 $\theta \in \left[\hat{\theta}_n \sqrt{\frac{3n}{\chi_{3n,1-\alpha/2}^2}}, \hat{\theta}_n \sqrt{\frac{3n}{\chi_{3n,\alpha/2}^2}}\right]$.

(3) 单个观测的对数密度为 $\ell(\theta; X) = C(X) - 3 \log \theta - \frac{X^2}{2\theta^2}$. score 为 $U_\theta(X) = -\frac{3}{\theta} + \frac{X^2}{\theta^3} = \frac{X^2 - 3\theta^2}{\theta^3}$. 因而

$$I_1(\theta) = \mathbb{E}_\theta[U_\theta(X)^2] = \frac{\text{Var}_\theta(X^2)}{\theta^6} = \frac{6\theta^4}{\theta^6} = \frac{6}{\theta^2}.$$

由正则 MLE 渐近理论, $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N\left(0, \frac{\theta^2}{6}\right)$.

也可直接由 $\sqrt{n}(M_{2,n} - 3\theta^2) \xrightarrow{d} N(0, 6\theta^4)$ 对函数 $g(x) = \sqrt{x/3}$ 使用 Delta 方法得到同一结论.

Problem 8 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$, $n \geq 4$. 定义 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 以及 $T = (\bar{X}, S^2)$. 在事件 $\{S > 0\}$ 上定义 $A_i = \frac{X_i - \bar{X}}{S}$, $i = 1, \dots, n$, 并在零概率事件 $\{S = 0\}$ 上令 $A_i = 0$. 记 $A = (A_1, \dots, A_n)$.

- (1) 证明 T 是参数 (μ, σ^2) 的极小充分统计量, 并判断 T 是否完全; 对你的结论给出严格证明.
- (2) 证明 A 是辅助统计量, 并判断随机向量 A 与统计量 T 是否独立.
- (3) 求随机变量 $\frac{nA_1^2}{(n-1)^2}$ 的分布, 并计算 $\mathbb{E}(A_1^4)$.

第 8 题解答

令 $T_0 = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$. 由于 $\sum_i X_i = n\bar{X}$, $\sum_i X_i^2 = (n-1)S^2 + n\bar{X}^2$, 统计量 T 与 T_0 是一一对应的.

(1) 联合密度为

$$f_{\mu, \sigma^2}(\mathbf{x}) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{\sum_i x_i^2 - 2\mu \sum_i x_i + n\mu^2}{2\sigma^2}\right\}.$$

由因子分解定理, T_0 , 从而 T 是充分统计量.

对任意两个样本点 $\mathbf{x}, \mathbf{y}$, 令 $\Delta_1 = \sum_i x_i - \sum_i y_i$, $\Delta_2 = \sum_i x_i^2 - \sum_i y_i^2$. 则 $\log \frac{f_{\mu, \sigma^2}(\mathbf{x})}{f_{\mu, \sigma^2}(\mathbf{y})} = -\frac{\Delta_2 - 2\mu\Delta_1}{2\sigma^2}$. 上式对所有 (μ, σ^2) 均与参数无关, 当且仅当 $\Delta_1 = 0$, $\Delta_2 = 0$. 因此由极小充分统计量的似然比判别法, $T = (\bar{X}, S^2)$ 是极小充分统计量。

下面证明完全性。令 $\eta_1 = \frac{\mu}{\sigma^2}$, $\eta_2 = -\frac{1}{2\sigma^2}$. 自然参数空间为 $\mathcal{H} = \mathbb{R} \times (-\infty, 0)$, 它是 $\mathbb{R}^2$ 中的非空开集, 而 T_0 是相应的自然统计量。

为严谨起见, 设可测函数 g 满足 $\mathbb{E}_\eta |g(T_0)| < \infty$ 且 $\mathbb{E}_\eta g(T_0) = 0 \quad \forall \eta \in \mathcal{H}$. 固定 $\eta_0 \in \mathcal{H}$, 定义有限符号测度 $\nu_g(B) = \mathbb{E}_{\eta_0} [g(T_0) \mathbf{1}_{\{T_0 \in B\}}]$. 对充分小的 $h \in \mathbb{R}^2$, 有 $\eta_0 + h \in \mathcal{H}$, 并且

$$\int e^{h^\top t} \nu_g(dt) = \mathbb{E}_{\eta_0} [g(T_0) e^{h^\top T_0}] = e^{A(\eta_0+h) - A(\eta_0)} \mathbb{E}_{\eta_0+h} g(T_0) = 0.$$

因此 ν_g 的 Laplace 变换在原点的一个邻域内恒为零。由多元 Laplace 变换的唯一性, $\nu_g = 0$. 从而 $g(T_0) = 0 \quad P_{\eta_0}$ -a.s. 所有正态联合密度在 $\mathbb{R}^n$ 上严格为正, 故不同参数下的分布彼此等价, 于是该结论对所有参数值成立。

因此 $T = (\bar{X}, S^2)$ 是完全统计量。

综上, T 是完全且极小充分的统计量。

- (2) 令 $Z_i = \frac{X_i - \mu}{\sigma}$. 则 $Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 且 $\bar{X} = \mu + \sigma \bar{Z}$, $S = \sigma S_Z$, 其中 $S_Z^2 = \frac{1}{n-1} \sum_{i=1}^n (Z_i - \bar{Z})^2$.

因此 $A_i = \frac{Z_i - \bar{Z}}{S_Z}$. 右侧的分布与 μ, σ^2 无关, 所以 A 是辅助统计量。

又因为 T 是完全充分统计量, A 是辅助统计量, 由 Basu 定理, $A \perp\!\!\!\perp T$.

- (3) 记 $\mathbf{Z} = (Z_1, \dots, Z_n)^\top$, $P = I_n - \frac{1}{n} \mathbf{1}\mathbf{1}^\top$. 则残差向量为 $P\mathbf{Z}$. 子空间 $\mathcal{H}_0 = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{1}^\top \mathbf{x} = 0\}$ 的维数为 $n-1$, 而 $P\mathbf{Z}$ 在该子空间上是球对称的标准高斯向量。

令 $U = \frac{P\mathbf{Z}}{\|P\mathbf{Z}\|}$. 则 U 在 $\mathcal{H}_0$ 的单位球面上均匀分布。

设 $\mathbf{e}_1 = (1, 0, \dots, 0)^\top$, 并令 $\mathbf{h} = \frac{P\mathbf{e}_1}{\|P\mathbf{e}_1\|}$. 因为 $\|P\mathbf{e}_1\|^2 = 1 - \frac{1}{n} = \frac{n-1}{n}$, 若 $C = \langle U, \mathbf{h} \rangle$, 则

$$A_1 = \sqrt{n-1} \frac{(P\mathbf{Z})_1}{\|P\mathbf{Z}\|} = \sqrt{n-1} \langle U, \mathbf{e}_1 \rangle = \sqrt{n-1} \langle U, P\mathbf{e}_1 \rangle = \frac{n-1}{\sqrt{n}} C.$$

在 $n-1$ 维单位球面上, 固定坐标的平方满足 $C^2 \sim \text{Beta}(\frac{1}{2}, \frac{n-2}{2})$. 因此 $\frac{nA_1^2}{(n-1)^2} \sim \text{Beta}(\frac{1}{2}, \frac{n-2}{2})$.

对 $d = n-1$ 维单位球面上的坐标 C , $\mathbb{E}(C^4) = \frac{3}{d(d+2)} = \frac{3}{(n-1)(n+1)}$. 故

$$\mathbb{E}(A_1^4) = \frac{(n-1)^4}{n^2} \mathbb{E}(C^4) = \frac{(n-1)^4}{n^2} \frac{3}{(n-1)(n+1)}.$$

即 $\mathbb{E}(A_1^4) = \frac{3(n-1)^3}{n^2(n+1)}.$

Problem 9 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{IG}(\mu, \lambda)$, 其中 $\lambda > 0$ 已知, $\mu > 0$ 未知。这里 $\text{IG}(\mu, \lambda)$ 表示逆高斯分布, 其密度为 $f(x; \mu, \lambda) = \left(\frac{\lambda}{2\pi x^3}\right)^{1/2} \exp\left\{-\frac{\lambda(x-\mu)^2}{2\mu^2 x}\right\} \mathbf{1}_{\{x>0\}}$. 记 $F_{\mu, \lambda}$ 为该分布的分布函数。

- 求 μ 的最大似然估计量和单个观测关于 μ 的 Fisher 信息, 并求最大似然估计量的渐近分布。
- 确定 $S_n = \sum_{i=1}^n X_i$ 的分布。进而构造检验 $H_0: \mu \leq \mu_0$ 对 $H_1: \mu > \mu_0$ 的 size α 一致最大功效检验, 并写出该检验在任意 $\mu > 0$ 处的功效函数。

- (3) 对双侧问题 $H_0: \mu = \mu_0$ 对 $H_1: \mu \neq \mu_0$, 推导广义似然比统计量, 并将 $-2 \log \Lambda_n$ 化为 $\bar{X}$ 、 μ_0 、 λ 和 n 的显式函数。给出其在 H_0 下的渐近分布以及渐近 level α 的拒绝域。

第 9 题解答

先给出逆高斯分布的矩母函数。将密度中的指数展开: $-\frac{\lambda(x-\mu)^2}{2\mu^2x} = \frac{\lambda}{\mu} - \frac{\lambda x}{2\mu^2} - \frac{\lambda}{2x}$. 利用积分恒等式

$$\int_0^\infty x^{-3/2} e^{-ax-b/x} dx = \sqrt{\frac{\pi}{b}} e^{-2\sqrt{ab}}, \quad a, b > 0,$$

可得当 $t < \frac{\lambda}{2\mu^2}$ 时, $M_X(t) = \mathbb{E}(e^{tX}) = \exp \left\{ \frac{\lambda}{\mu} \left[1 - \sqrt{1 - \frac{2\mu^2 t}{\lambda}} \right] \right\}$. 由此 $\mathbb{E}X = \mu$, $\text{Var}(X) = \frac{\mu^3}{\lambda}$.

- (1) 忽略与 μ 无关的项, 样本对数似然为 $\ell_n(\mu) = \frac{n\lambda}{\mu} - \frac{\lambda}{2\mu^2} \sum_{i=1}^n X_i + C$. 求导得 $\ell'_n(\mu) = -\frac{n\lambda}{\mu^2} + \frac{\lambda \sum_i X_i}{\mu^3} = \frac{n\lambda}{\mu^3} (\bar{X} - \mu)$. 因此 $\ell'_n(\mu) > 0$ 当 $\mu < \bar{X}$, 而 $\ell'_n(\mu) < 0$ 当 $\mu > \bar{X}$. 所以唯一全局最大点为 $\hat{\mu}_n = \bar{X}$. 单个观测的 score 为 $U_\mu(X) = \frac{\lambda(X-\mu)}{\mu^3}$. 所以

$$I_1(\mu) = \mathbb{E}_\mu[U_\mu(X)^2] = \frac{\lambda^2}{\mu^6} \text{Var}_\mu(X) = \frac{\lambda^2}{\mu^6} \frac{\mu^3}{\lambda} = \frac{\lambda}{\mu^3}.$$

由中心极限定理, $\sqrt{n}(\hat{\mu}_n - \mu) = \sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N\left(0, \frac{\mu^3}{\lambda}\right)$.

- (2) 由独立性, $M_{S_n}(t) = [M_X(t)]^n$. 因而 $M_{S_n}(t) = \exp \left\{ \frac{n\lambda}{\mu} \left[1 - \sqrt{1 - \frac{2\mu^2 t}{\lambda}} \right] \right\}$. 对 $\mu' = n\mu$, $\lambda' = n^2\lambda$, 有 $\frac{\lambda'}{\mu'} = \frac{n\lambda}{\mu}$, $\frac{2(\mu')^2 t}{\lambda'} = \frac{2\mu^2 t}{\lambda}$. 因此 $S_n \sim \text{IG}(n\mu, n^2\lambda)$.

对任意 $\mu_2 > \mu_1$, 联合似然比为 $\frac{L(\mu_2)}{L(\mu_1)} = C(\mu_1, \mu_2) \exp \left\{ -\frac{\lambda}{2} \left(\frac{1}{\mu_2^2} - \frac{1}{\mu_1^2} \right) S_n \right\}$. 因为 $\frac{1}{\mu_2^2} - \frac{1}{\mu_1^2} < 0$, 该比值是 S_n 的严格递增函数。因此模型关于 S_n 具有单调似然比。

令 $c_\alpha = F_{n\mu_0, n^2\lambda}^{-1}(1-\alpha)$. 则在 $\mu = \mu_0$ 下, $\mathbb{P}_{\mu_0}(S_n > c_\alpha) = \alpha$. 由 Karlin-Rubin 定理, size α 的 UMP 检验为 $\phi(\mathbf{X}) = \mathbf{1}_{\{S_n > c_\alpha\}}$.

其功效函数为 $\beta(\mu) = \mathbb{P}_\mu(S_n > c_\alpha) = 1 - F_{n\mu, n^2\lambda}(c_\alpha)$, $\mu > 0$. 该函数随 μ 单调增加, 故原假设 $\mu \leq \mu_0$ 中的最大拒绝概率在 μ_0 处达到。

- (3) 非受限 MLE 为 $\hat{\mu}_n = \bar{X}$, 而在 H_0 下受限 MLE 为 μ_0 . 因此 $\Lambda_n = \frac{L(\mu_0)}{L(\bar{X})}$. 由 $\ell_n(\mu) = \frac{n\lambda}{\mu} - \frac{n\lambda\bar{X}}{2\mu^2} + C$, 有

$$\ell_n(\bar{X}) = \frac{n\lambda}{2\bar{X}} + C. \text{ 所以 } -2 \log \Lambda_n = 2[\ell_n(\bar{X}) - \ell_n(\mu_0)] = n\lambda \left[\frac{1}{\bar{X}} + \frac{\bar{X}}{\mu_0^2} - \frac{2}{\mu_0} \right] = \frac{n\lambda(\bar{X} - \mu_0)^2}{\bar{X} \mu_0^2}. \text{ 等价地,}$$

$$\Lambda_n = \exp \left\{ -\frac{n\lambda(\bar{X} - \mu_0)^2}{2\bar{X} \mu_0^2} \right\}.$$

在 H_0 下, $\sqrt{n}(\bar{X} - \mu_0) \xrightarrow{d} N\left(0, \frac{\mu_0^3}{\lambda}\right)$, 且 $\bar{X} \xrightarrow{\mathbb{P}} \mu_0$. 因此 $-2 \log \Lambda_n = \frac{\lambda}{\bar{X} \mu_0^2} [\sqrt{n}(\bar{X} - \mu_0)]^2 \xrightarrow{d} \chi_1^2$. 即

$$-2 \log \Lambda_n \xrightarrow{d} \chi_1^2.$$

渐近 level α 的拒绝域为 $\frac{n\lambda(\bar{X} - \mu_0)^2}{\bar{X} \mu_0^2} > \chi_{1, 1-\alpha}^2$.

Problem 10 (10 分)

给定参数 $\lambda > 0$, 设 $X_1, \dots, X_n \mid \lambda \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$. λ 的先验分布采用形状-率参数化: $\lambda \sim \text{Gamma}(a, b)$, $a \in \{2, 3, \dots\}$, $b > 0$, 其密度为 $\pi(\lambda) = \frac{b^a}{\Gamma(a)} \lambda^{a-1} e^{-b\lambda} \mathbf{1}_{\{\lambda > 0\}}$. 另设在给定 λ 后, $Y \mid \lambda \sim \text{Poisson}(c\lambda)$, $c > 0$, 且 Y 与 $X_1, \dots, X_n$ 条件独立. 记 $S = \sum_{i=1}^n X_i$.

- (1) 求 $\lambda \mid X_1, \dots, X_n$ 的后验分布。
- (2) 分别求下列两个损失函数下 λ 的 Bayes 估计量: $L_1(\lambda, d) = (d - \lambda)^2$, $d \in \mathbb{R}$, 以及 $L_2(\lambda, d) = \frac{d}{\lambda} - \log\left(\frac{d}{\lambda}\right) - 1$, $d > 0$.
- (3) 求后验预测分布 $\mathbb{P}(Y = y \mid X_1, \dots, X_n)$, $y = 0, 1, 2, \dots$, 并将其识别为某个明确参数化的负二项分布。

第 10 题解答

记 $S = \sum_{i=1}^n X_i$.

- (1) 似然核为 $L(\lambda \mid \mathbf{x}) \propto e^{-n\lambda} \lambda^S$. 先验核为 $\pi(\lambda) \propto \lambda^{a-1} e^{-b\lambda}$. 因此后验核为 $\pi(\lambda \mid \mathbf{x}) \propto \lambda^{a+S-1} e^{-(b+n)\lambda}$. 所以 $\boxed{\lambda \mid X_1, \dots, X_n \sim \text{Gamma}(a+S, b+n)}$, 其中第二个参数为率参数。

后验密度为 $\pi(\lambda \mid \mathbf{x}) = \frac{(b+n)^{a+S}}{\Gamma(a+S)} \lambda^{a+S-1} e^{-(b+n)\lambda} \mathbf{1}_{\{\lambda > 0\}}$.

- (2) 在平方损失 $L_1(\lambda, d) = (d - \lambda)^2$ 下, Bayes 估计量为后验均值: $\boxed{\delta_1(\mathbf{X}) = \mathbb{E}(\lambda \mid \mathbf{X}) = \frac{a+S}{b+n}}$.

对损失 L_2 , 给定数据后的后验风险为

$$\rho_2(d \mid \mathbf{X}) = \mathbb{E} \left[\frac{d}{\lambda} - \log \left(\frac{d}{\lambda} \right) - 1 \mid \mathbf{X} \right] = d \mathbb{E}(\lambda^{-1} \mid \mathbf{X}) - \log d + \mathbb{E}(\log \lambda \mid \mathbf{X}) - 1.$$

关于 $d > 0$ 求导: $\frac{\partial}{\partial d} \rho_2(d \mid \mathbf{X}) = \mathbb{E}(\lambda^{-1} \mid \mathbf{X}) - \frac{1}{d}$. 二阶导数为 $\frac{\partial^2}{\partial d^2} \rho_2(d \mid \mathbf{X}) = \frac{1}{d^2} > 0$. 因此唯一最小点为 $d = \frac{1}{\mathbb{E}(\lambda^{-1} \mid \mathbf{X})}$.

若 $\lambda \mid \mathbf{X} \sim \text{Gamma}(\alpha, \beta)$, $\alpha = a+S$, $\beta = b+n$, 则由于 $\alpha \geq 2$, $\mathbb{E}(\lambda^{-1} \mid \mathbf{X}) = \frac{\beta}{\alpha-1}$. 所以

$$\boxed{\delta_2(\mathbf{X}) = \frac{a+S-1}{b+n}}.$$

- (3) 令 $\alpha = a+S$, $\beta = b+n$. 则

$$\begin{aligned} \mathbb{P}(Y = y \mid \mathbf{X}) &= \int_0^\infty \frac{e^{-c\lambda} (c\lambda)^y}{y!} \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} d\lambda \\ &= \frac{c^y \beta^\alpha}{y! \Gamma(\alpha)} \int_0^\infty \lambda^{\alpha+y-1} e^{-(\beta+c)\lambda} d\lambda \\ &= \frac{\Gamma(\alpha+y)}{\Gamma(\alpha) y!} \frac{c^y \beta^\alpha}{(\beta+c)^{\alpha+y}}. \end{aligned}$$

$$\text{因而 } \boxed{\mathbb{P}(Y = y \mid \mathbf{X}) = \binom{\alpha+y-1}{y} \left(\frac{\beta}{\beta+c} \right)^\alpha \left(\frac{c}{\beta+c} \right)^y, \quad y = 0, 1, 2, \dots}$$

若采用负二项分布参数化 $\mathbb{P}(W = y) = \binom{r+y-1}{y} p^r (1-p)^y$, $y = 0, 1, \dots$, 则

$$\boxed{Y \mid \mathbf{X} \sim \text{NegBin} \left(r = a+S, p = \frac{b+n}{b+n+c} \right)}.$$

这里 Y 表示获得第 r 次成功前的失败次数。



Problem 11 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x; \theta)$, $f(x; \theta) = \theta x^{\theta-1} \mathbf{1}_{\{0 < x < 1\}}$, $\theta > 0$. 记 F_n 为经验分布函数. 对固定的 $p \in (0, 1)$, 定义总体 p 分位数和样本 p 分位数 $\xi_p = \inf\{x : F_\theta(x) \geq p\}$, $\hat{\xi}_{p,n} = \inf\{x : F_n(x) \geq p\}$, 并定义分位数估计量 $\tilde{\theta}_{p,n} = \frac{\log p}{\log \hat{\xi}_{p,n}}$.

- (1) 求 θ 的最大似然估计量 $\hat{\theta}_n$, 证明其相合性, 并求 $\sqrt{n}(\hat{\theta}_n - \theta)$ 的极限分布.
- (2) 证明 $\tilde{\theta}_{p,n}$ 相合, 并求 $\sqrt{n}(\tilde{\theta}_{p,n} - \theta)$ 的极限分布.
- (3) 以 $\text{ARE}(\tilde{\theta}_{p,n}, \hat{\theta}_n) = \frac{\hat{\theta}_n \text{ 的渐近方差}}{\tilde{\theta}_{p,n} \text{ 的渐近方差}}$ 定义分位数估计量相对于最大似然估计量的渐近相对效率. 求使该渐近相对效率最大的 $p \in (0, 1)$; 可以用一个明确的方程刻画该最优值.

第 11 题解答

该分布的分布函数为 $F_\theta(x) = \begin{cases} 0, & x \leq 0, \\ x^\theta, & 0 < x < 1, \\ 1, & x \geq 1. \end{cases}$ 因此 $\xi_p = p^{1/\theta}$.

- (1) 样本似然为 $L(\theta) = \theta^n \prod_{i=1}^n X_i^{\theta-1}$. 对数似然为 $\ell_n(\theta) = n \log \theta + (\theta - 1) \sum_{i=1}^n \log X_i$. 求导: $\ell'_n(\theta) = \frac{n}{\theta} + \sum_{i=1}^n \log X_i$. 由于 $\sum_i \log X_i < 0$ a.s., 唯一驻点为 $\hat{\theta}_n = -\frac{n}{\sum_{i=1}^n \log X_i}$. 又 $\ell''_n(\theta) = -\frac{n}{\theta^2} < 0$, 故该驻点是唯一全局最大点.

令 $Y_i = -\log X_i$. 对 $y > 0$, $\mathbb{P}(Y_i > y) = \mathbb{P}(X_i < e^{-y}) = e^{-\theta y}$, 所以 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\theta)$, 其中 θ 为率参数. 于是 $\hat{\theta}_n = \frac{1}{\bar{Y}}$.

由强大数律, $\bar{Y} \rightarrow \frac{1}{\theta}$ a.s. 因此 $\hat{\theta}_n \rightarrow \theta$ a.s., 特别地 $\hat{\theta}_n$ 相合.

又因为 $\mathbb{E}Y_i = \frac{1}{\theta}$, $\text{Var}(Y_i) = \frac{1}{\theta^2}$, 中心极限定理给出 $\sqrt{n}(\bar{Y} - \frac{1}{\theta}) \xrightarrow{d} N(0, \frac{1}{\theta^2})$. 对函数 $g(y) = \frac{1}{y}$ 使用 Delta 方法. 由于 $g'(\frac{1}{\theta}) = -\theta^2$, 得 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \theta^2)$.

- (2) 因为 F_θ 连续且严格增加, $\xi_p = p^{1/\theta}$ 是唯一的总体 p 分位数, 并且 $f_\theta(\xi_p) = \theta \xi_p^{\theta-1} > 0$. 由经验分布函数的一致收敛或样本分位数相合定理, $\hat{\xi}_{p,n} \xrightarrow{\mathbb{P}} \xi_p$. 函数 $h(x) = \frac{\log p}{\log x}$, $0 < x < 1$, 在 $x = \xi_p$ 处连续, 且 $h(\xi_p) = \theta$. 因此 $\tilde{\theta}_{p,n} \xrightarrow{\mathbb{P}} \theta$.

由样本分位数的渐近正态性, $\sqrt{n}(\hat{\xi}_{p,n} - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{f_\theta(\xi_p)^2}\right)$. 这里 $f_\theta(\xi_p)^2 = \theta^2 \xi_p^{2\theta-2}$.

又 $h'(x) = -\frac{\log p}{x(\log x)^2}$. 因为 $\log \xi_p = \frac{\log p}{\theta}$, 所以 $h'(\xi_p) = -\frac{\theta^2}{\xi_p \log p}$. 由 Delta 方法, $\sqrt{n}(\tilde{\theta}_{p,n} - \theta) \xrightarrow{d} N(0, V_p)$,

其中 $V_p = \frac{\theta^4}{\xi_p^2 (\log p)^2} \frac{p(1-p)}{\theta^2 \xi_p^{2\theta-2}} = \frac{\theta^2 p(1-p)}{(\log p)^2 \xi_p^{2\theta}}$. 由于 $\xi_p^{2\theta} = p^2$, 得 $\sqrt{n}(\tilde{\theta}_{p,n} - \theta) \xrightarrow{d} N\left(0, \frac{\theta^2(1-p)}{p(\log p)^2}\right)$.

- (3) 最大似然估计量的渐近方差为 $V_{\text{MLE}} = \theta^2$, 而分位数估计量的渐近方差为 $V_p = \frac{\theta^2(1-p)}{p(\log p)^2}$. 因而

$$\text{ARE}(\tilde{\theta}_{p,n}, \hat{\theta}_n) = \frac{p(\log p)^2}{1-p}.$$

令 $r(p) = \frac{p(\log p)^2}{1-p}$. 求导得 $r'(p) = \frac{\log p [\log p + 2(1-p)]}{(1-p)^2}$. 在 $0 < p < 1$ 中, $\log p \neq 0$, 故内部驻点满足 $\log p + 2(1-p) = 0$. 等价地, $-\log p = 2(1-p)$. 此即满足要求的方程.

35.3 第三套试题 + 答案

Problem 1 (10 分)

设 $N \sim \text{Poisson}(\lambda)$, $\lambda > 0$. 给定 $N = n$ 后, 将 n 个对象相互独立地分入三类, 每个对象进入第 j 类的概率为 p_j , 其中 $p_j > 0$, $p_1 + p_2 + p_3 = 1$. 记三类对象的个数分别为 Y_1, Y_2, Y_3 , 因而 $Y_1 + Y_2 + Y_3 = N$.

- (1) 求 (Y_1, Y_2, Y_3) 的联合概率质量函数和联合概率生成函数 $G(z_1, z_2, z_3) = \mathbb{E}[z_1^{Y_1} z_2^{Y_2} z_3^{Y_3}]$. 由此确定 Y_1, Y_2, Y_3 的边缘分布, 并判断三者是否相互独立.
- (2) 令 $S = Y_1 + Y_2$. 分别求 $\text{Law}(Y_1 | \sigma(S))$, $\text{Law}(N | \sigma(S))$, 并求 $\mathbb{E}(Y_1 | \sigma(S))$, $\mathbb{E}(N | \sigma(S))$.
- (3) 求随机向量 $(Y_1, Y_2, Y_3, N)^\top$ 的协方差矩阵, 并计算 $\text{Corr}(Y_j, N)$, $j = 1, 2, 3$.

第 1 题解答

记 $n = y_1 + y_2 + y_3$.

- (1) 给定 $N = n$ 时, $(Y_1, Y_2, Y_3) | N = n \sim \text{Multinomial}(n; p_1, p_2, p_3)$. 因此, 对任意 $y_1, y_2, y_3 \in \mathbb{N}_0$,

$$\mathbb{P}(Y_1 = y_1, Y_2 = y_2, Y_3 = y_3) = \mathbb{P}(N = n) \frac{n!}{y_1! y_2! y_3!} p_1^{y_1} p_2^{y_2} p_3^{y_3} = e^{-\lambda} \frac{\lambda^n}{n!} \frac{n!}{y_1! y_2! y_3!} p_1^{y_1} p_2^{y_2} p_3^{y_3} = \prod_{j=1}^3 e^{-\lambda p_j} \frac{(\lambda p_j)^{y_j}}{y_j!},$$

其中使用了 $p_1 + p_2 + p_3 = 1$.

故联合概率质量函数为
$$\mathbb{P}(Y_1 = y_1, Y_2 = y_2, Y_3 = y_3) = \prod_{j=1}^3 e^{-\lambda p_j} \frac{(\lambda p_j)^{y_j}}{y_j!}.$$

联合概率生成函数为

$$\begin{aligned} G(z_1, z_2, z_3) &= \mathbb{E} \left[\mathbb{E} \left(z_1^{Y_1} z_2^{Y_2} z_3^{Y_3} \mid N \right) \right] = \mathbb{E} \left[(p_1 z_1 + p_2 z_2 + p_3 z_3)^N \right] \\ &= \exp \{ \lambda (p_1 z_1 + p_2 z_2 + p_3 z_3 - 1) \} = \prod_{j=1}^3 \exp \{ \lambda p_j (z_j - 1) \}. \end{aligned}$$

因此 $Y_j \sim \text{Poisson}(\lambda p_j)$, $j = 1, 2, 3$, 且联合概率生成函数分解为边缘概率生成函数之积, 所以

$$Y_1, Y_2, Y_3 \text{ 相互独立.}$$

- (2) 令 $S = Y_1 + Y_2$. 由独立 Poisson 随机变量之和的性质, $S \sim \text{Poisson}(\lambda(p_1 + p_2))$.

给定 $S = s$ 时, $Y_1 | S = s \sim \text{Bin} \left(s, \frac{p_1}{p_1 + p_2} \right)$. 即
$$\mathbb{P}(Y_1 = k | S = s) = \binom{s}{k} \left(\frac{p_1}{p_1 + p_2} \right)^k \left(\frac{p_2}{p_1 + p_2} \right)^{s-k},$$

其中 $k = 0, \dots, s$. 所以
$$\mathbb{E}(Y_1 | \sigma(S)) = \frac{p_1}{p_1 + p_2} S.$$

另一方面, $N = S + Y_3$, 且 Y_3 与 S 独立, $Y_3 \sim \text{Poisson}(\lambda p_3)$. 因此, 给定 $S = s$ 后, $N = s + Z$, $Z \sim$

$\text{Poisson}(\lambda p_3)$. 即对 $\ell = 0, 1, 2, \dots$,
$$\mathbb{P}(N = s + \ell | S = s) = e^{-\lambda p_3} \frac{(\lambda p_3)^\ell}{\ell!}.$$

故
$$\mathbb{E}(N | \sigma(S)) = S + \lambda p_3.$$

- (3) 由于 Y_1, Y_2, Y_3 相互独立, $\text{Var}(Y_j) = \lambda p_j$, $\text{Cov}(Y_i, Y_j) = 0$, $i \neq j$. 又因为 $N = Y_1 + Y_2 + Y_3$, 故 $\text{Cov}(Y_j, N) = \text{Cov} \left(Y_j, \sum_{i=1}^3 Y_i \right) = \text{Var}(Y_j) = \lambda p_j$, 并且 $\text{Var}(N) = \lambda$.

因此

$$\text{Cov} \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ N \end{pmatrix} = \lambda \begin{pmatrix} p_1 & 0 & 0 & p_1 \\ 0 & p_2 & 0 & p_2 \\ 0 & 0 & p_3 & p_3 \\ p_1 & p_2 & p_3 & 1 \end{pmatrix}.$$

最后,

$$\text{Corr}(Y_j, N) = \frac{\text{Cov}(Y_j, N)}{\sqrt{\text{Var}(Y_j) \text{Var}(N)}} = \frac{\lambda p_j}{\sqrt{\lambda p_j \cdot \lambda}} = \sqrt{p_j}.$$

所以 $\boxed{\text{Corr}(Y_j, N) = \sqrt{p_j}, \quad j = 1, 2, 3.}$

Problem 2 (15 分)

设 $\{\varepsilon_k : k \geq 1\}$ 为相互独立的 Rademacher 随机变量, 即 $\mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}$. 另设 $\{B_k : k \geq 1\}$ 相互独立, 且与所有 ε_k 独立, 并满足 $\mathbb{P}(B_k = 1) = \frac{1}{(k+1)^2}$, $\mathbb{P}(B_k = 0) = 1 - \frac{1}{(k+1)^2}$. 定义 $X_k = \varepsilon_k(1 + kB_k)$, $S_n = \sum_{k=1}^n X_k$.

- (1) 令 $R_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_k$. 求 R_n 的特征函数, 并直接由特征函数证明 $R_n \xrightarrow{d} N(0, 1)$.
- (2) 求 $S_n/\sqrt{n}$ 的极限分布. 随后计算 $\text{Var}(S_n)$, 并求 $\frac{S_n}{\sqrt{\text{Var}(S_n)}}$ 的极限分布.
- (3) 证明 $\frac{S_n^2}{n} \xrightarrow{d} \chi_1^2$, 但随机变量族 $\left\{ \frac{S_n^2}{n} : n \geq 1 \right\}$ 不是一致可积的. 说明这一现象为什么不与依分布收敛相矛盾.

第 2 题解答

记 $R_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_k$.

- (1) 由于 ε_k 相互独立,

$$\varphi_{R_n}(t) = \mathbb{E} e^{itR_n} = \prod_{k=1}^n \mathbb{E} e^{it\varepsilon_k/\sqrt{n}} = \left[\frac{1}{2} e^{it/\sqrt{n}} + \frac{1}{2} e^{-it/\sqrt{n}} \right]^n = \left[\cos \left(\frac{t}{\sqrt{n}} \right) \right]^n.$$

当 $u \rightarrow 0$ 时, $\log \cos u = -\frac{u^2}{2} + O(u^4)$. 因此

$$\log \varphi_{R_n}(t) = n \log \cos \left(\frac{t}{\sqrt{n}} \right) = n \left[-\frac{t^2}{2n} + O \left(\frac{t^4}{n^2} \right) \right] = -\frac{t^2}{2} + O(n^{-1}).$$

故 $\varphi_{R_n}(t) \rightarrow e^{-t^2/2}$.

右端是 $N(0, 1)$ 的特征函数, 由特征函数连续性定理, $\boxed{R_n \xrightarrow{d} N(0, 1).}$

- (2) 写成 $S_n = \sum_{k=1}^n \varepsilon_k + \sum_{k=1}^n k \varepsilon_k B_k$. 令 $D_n = \sum_{k=1}^n k \varepsilon_k B_k$.

由于 $\sum_{k=1}^{\infty} \mathbb{P}(B_k = 1) = \sum_{k=1}^{\infty} \frac{1}{(k+1)^2} < \infty$, 由第一 Borel-Cantelli 引理, $\mathbb{P}(B_k = 1 \text{ 无穷多次}) = 0$. 故几乎处处只有有限多个 B_k 等于 1, 从而 $D_n \xrightarrow{\text{a.s.}} D$ 对某个有限随机变量 D 成立. 因此 $\frac{D_n}{\sqrt{n}} \xrightarrow{\text{a.s.}} 0$.

于是 $\frac{S_n}{\sqrt{n}} = R_n + \frac{D_n}{\sqrt{n}}$. 由 Slutsky 定理, $\boxed{\frac{S_n}{\sqrt{n}} \xrightarrow{d} N(0, 1).}$

下面计算方差. 由于 $\mathbb{E} X_k = 0$, 且各 X_k 相互独立, $\text{Var}(S_n) = \sum_{k=1}^n \text{Var}(X_k)$.

又

$$\text{Var}(X_k) = \mathbb{E}X_k^2 = \mathbb{E}(1 + kB_k)^2 = 1 + (2k + k^2)\mathbb{P}(B_k = 1) = 1 + \frac{k^2 + 2k}{(k+1)^2} = 2 - \frac{1}{(k+1)^2}.$$

所以 $\text{Var}(S_n) = 2n - \sum_{k=1}^n \frac{1}{(k+1)^2}$. 特别地, $\frac{\text{Var}(S_n)}{n} \rightarrow 2$.

因此 $\frac{S_n}{\sqrt{\text{Var}(S_n)}} = \frac{S_n/\sqrt{n}}{\sqrt{\text{Var}(S_n)/n}} \xrightarrow{d} \frac{Z}{\sqrt{2}}, \quad Z \sim N(0, 1)$. 即 $\frac{S_n}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} N\left(0, \frac{1}{2}\right)$.

注意, 该极限并非 $N(0, 1)$. 原因是少数稀有大值对方差有显著贡献, 但这些大值几乎处处只出现有限次, 因而不影响通常的弱极限.

(3) 由第 (b) 问, $\frac{S_n}{\sqrt{n}} \xrightarrow{d} Z, \quad Z \sim N(0, 1)$. 平方函数连续, 因此由连续映射定理, $\frac{S_n^2}{n} \xrightarrow{d} Z^2 \sim \chi_1^2$.

另一方面, $\mathbb{E}\left(\frac{S_n^2}{n}\right) = \frac{\text{Var}(S_n)}{n} \rightarrow 2$. 但 $\mathbb{E}(\chi_1^2) = 1$.

若 $\left\{\frac{S_n^2}{n} : n \geq 1\right\}$ 一致可积, 则由依分布收敛与一致可积性可推出期望收敛: $\mathbb{E}\left(\frac{S_n^2}{n}\right) \rightarrow \mathbb{E}(\chi_1^2) = 1$, 这与实际极限 2 矛盾.

因此 $\left\{\frac{S_n^2}{n} : n \geq 1\right\}$ 不是一致可积的.

这不与依分布收敛矛盾, 因为依分布收敛只控制有界连续函数的期望, 一般不保证一阶矩或更高阶矩收敛. 本题中的稀有大值在概率上消失, 却仍对二阶矩保留非忽略贡献.

Problem 3 (10 分)

设 $\{X_n : n \geq 0\}$ 是状态空间 $S = \{0, 1, 2\}$ 上的时间齐次 Markov 链, 其转移矩阵为 $P = \begin{pmatrix} 0 & 1 & 0 \\ p & 0 & 1-p \\ 0 & 1 & 0 \end{pmatrix}, 0 <$

$p < 1$.

- (1) 判断该链是否不可约, 求各状态的周期, 并求其所有平稳分布. 判断该链在所求平稳分布下是否可逆.
- (2) 求 P^n . 对每个 $i, j \in S$, 分别求 $\lim_{n \rightarrow \infty} P^{2n}(i, j), \lim_{n \rightarrow \infty} P^{2n+1}(i, j)$. 由此判断从任意确定初始状态出发时, $\text{Law}(X_n)$ 是否必然收敛.
- (3) 定义另一条 Markov 链的转移矩阵 $Q = \frac{1}{2}(I + P)$. 判断 Q 对应的链是否不可约、非周期和可逆, 并求 $\lim_{n \rightarrow \infty} Q^n(i, j), i, j \in S$.

第 3 题解答

转移矩阵为 $P = \begin{pmatrix} 0 & 1 & 0 \\ p & 0 & 1-p \\ 0 & 1 & 0 \end{pmatrix}$.

- (1) 由 $0 \leftrightarrow 1 \leftrightarrow 2$ 且 $0 < p < 1$, 任意状态之间均可互达, 所以该链不可约.

状态空间可分为 $\{1\}$ 和 $\{0, 2\}$, 链每一步都在这两个集合之间交替. 因此所有返还时间均为偶数.

另一方面, 每个状态均可在两步后返回自身, 所以 $d(0) = d(1) = d(2) = 2$.

设平稳分布为 $\pi = (\pi_0, \pi_1, \pi_2)$. 方程 $\pi P = \pi$ 给出 $\pi_0 = p\pi_1, \quad \pi_2 = (1-p)\pi_1$, 以及 $\pi_0 + \pi_1 + \pi_2 = 1$.

于是 $2\pi_1 = 1$, 故 $\pi = \left(\frac{p}{2}, \frac{1}{2}, \frac{1-p}{2}\right)$.

检查详细平衡: $\pi_0 P_{01} = \frac{p}{2} = \pi_1 P_{10}$, $\pi_1 P_{12} = \frac{1-p}{2} = \pi_2 P_{21}$, 其他非对角边均为零。因此该链在平稳分布 π 下可逆。

(2) 直接计算 $P^2 = \begin{pmatrix} p & 0 & 1-p \\ 0 & 1 & 0 \\ p & 0 & 1-p \end{pmatrix}$. 容易验证 $(P^2)^2 = P^2$, $P^2 P = P$. 因此 $P^{2k} = P^2$, $k \geq 1$, 以及

$$P^{2k+1} = P, \quad k \geq 0.$$

所以 $\lim_{n \rightarrow \infty} P^{2n} = \begin{pmatrix} p & 0 & 1-p \\ 0 & 1 & 0 \\ p & 0 & 1-p \end{pmatrix}$, 而 $\lim_{n \rightarrow \infty} P^{2n+1} = \begin{pmatrix} 0 & 1 & 0 \\ p & 0 & 1-p \\ 0 & 1 & 0 \end{pmatrix}$.

对任意确定初始状态 i , 偶数时刻和奇数时刻的分布不同。例如从 0 出发, $\text{Law}(X_{2n}) = (p, 0, 1-p)$, $\text{Law}(X_{2n+1}) = (0, 1, 0)$. 故从任意确定初始状态出发, $\text{Law}(X_n)$ 不收敛。

(3) 有 $Q = \frac{1}{2}(I + P)$. 由于 P 不可约, 加入自环后 Q 仍不可约。又 $Q_{ii} = \frac{1}{2} > 0$, 所以所有状态周期均为 1, 即 Q 非周期。

因为 I 和 P 均关于 π 可逆, $\pi_i Q_{ij} = \frac{1}{2}\pi_i \mathbb{1}_{\{i=j\}} + \frac{1}{2}\pi_i P_{ij} = \pi_j Q_{ji}$. 故 Q 关于同一个 π 可逆并以 π 为平稳分布。

有限状态不可约非周期 Markov 链满足收敛定理, 因此 $\lim_{n \rightarrow \infty} Q^n(i, j) = \pi_j$. 即

$$\lim_{n \rightarrow \infty} Q^n(i, \cdot) = \left(\frac{p}{2}, \frac{1}{2}, \frac{1-p}{2}\right), \quad i = 0, 1, 2.$$

Problem 4 (15 分)

设 $\{B_t : t \geq 0\}$ 为从 0 出发的一维标准 Brownian motion。给定 $a, b > 0$, 定义首次离开区间 $(-a, b)$ 的时间 $\tau = \inf\{t \geq 0 : B_t \notin (-a, b)\}$.

- (1) 证明 $\tau < \infty$ a.s. 并求 $\mathbb{P}(B_\tau = b)$, $\mathbb{P}(B_\tau = -a)$, $\mathbb{E}\tau$.
- (2) 对任意 $\lambda > 0$, 求下列两个量的闭式表达式: $\mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=b\}}]$, $\mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=-a\}}]$. 由此求 $\mathbb{E}e^{-\lambda\tau}$.
- (3) 在区间 $[0, 1]$ 上定义过程 $W_t = B_t - tB_1$. 证明整个过程 $\{W_t : 0 \leq t \leq 1\}$ 与随机变量 B_1 独立, 并求 $\mathbb{E}W_t$, $\text{Cov}(W_s, W_t)$. 对任意 $0 \leq t_1 < \dots < t_k < 1$, 写出 $(B_{t_1}, \dots, B_{t_k})$ 在给定 $B_1 = 0$ 条件下的条件分布。


第 4 题解答

令 $\tau = \inf\{t \geq 0 : B_t \notin (-a, b)\}$.

(1) 若 $\tau > t$, 则必有 $-a < B_t < b$. 因此

$$\mathbb{P}(\tau > t) \leq \mathbb{P}(-a < B_t < b) = \Phi\left(\frac{b}{\sqrt{t}}\right) - \Phi\left(-\frac{a}{\sqrt{t}}\right) \rightarrow 0.$$

故 $\tau < \infty$ a.s.



由于 Brownian motion 路径连续, $B_\tau \in \{-a, b\}$ a.s.

令 $\tau_n = \tau \wedge n$. 过程 B_t 为鞅, 且 τ_n 有界, 所以 $\mathbb{E}B_{\tau_n} = 0$. 又 $-a \leq B_{\tau_n} \leq b$, 由支配收敛定理, $\mathbb{E}B_\tau = 0$.

设 $q = \mathbb{P}(B_\tau = b)$. 则 $0 = \mathbb{E}B_\tau = bq - a(1 - q)$. 解得 $\mathbb{P}(B_\tau = b) = \frac{a}{a+b}$, 以及 $\mathbb{P}(B_\tau = -a) = \frac{b}{a+b}$.

再考虑鞅 $B_t^2 - t$. 对 τ_n 使用可选停止, $\mathbb{E}B_{\tau_n}^2 = \mathbb{E}\tau_n$. 由于 $B_{\tau_n}^2 \leq \max(a^2, b^2)$, 故 $\mathbb{E}\tau_n \leq \max(a^2, b^2)$. 由单调收敛定理, $\mathbb{E}\tau < \infty$. 再令 $n \rightarrow \infty$, 得到 $\mathbb{E}\tau = \mathbb{E}B_\tau^2$. 因此

$$\mathbb{E}\tau = b^2 \frac{a}{a+b} + a^2 \frac{b}{a+b} = ab.$$

故 $\mathbb{E}\tau = ab$.

(2) 固定 $\lambda > 0$, 令 $c = \sqrt{2\lambda}$. 则 $M_t^+ = \exp\{cB_t - \lambda t\}$, $M_t^- = \exp\{-cB_t - \lambda t\}$ 均为鞅.

对 $\tau_n = \tau \wedge n$ 使用可选停止, $\mathbb{E}M_{\tau_n}^+ = 1$, $\mathbb{E}M_{\tau_n}^- = 1$. 由于 $B_{\tau_n} \in [-a, b]$, 停止后的随机变量一致有界. 令 $n \rightarrow \infty$, 得到 $\mathbb{E}e^{cB_\tau - \lambda\tau} = 1$, $\mathbb{E}e^{-cB_\tau - \lambda\tau} = 1$.

记 $A = \mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=b\}}]$, $C = \mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=-a\}}]$. 则 $e^{cb}A + e^{-ca}C = 1$, $e^{-cb}A + e^{ca}C = 1$.

解此线性方程组得 $A = \frac{\sinh(ca)}{\sinh(c(a+b))}$, 以及 $C = \frac{\sinh(cb)}{\sinh(c(a+b))}$. 即 $\mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=b\}}] = \frac{\sinh(a\sqrt{2\lambda})}{\sinh((a+b)\sqrt{2\lambda})}$.

同理, $\mathbb{E}[e^{-\lambda\tau} \mathbb{1}_{\{B_\tau=-a\}}] = \frac{\sinh(b\sqrt{2\lambda})}{\sinh((a+b)\sqrt{2\lambda})}$. 两式相加可得 $\mathbb{E}e^{-\lambda\tau} = \frac{\sinh(a\sqrt{2\lambda}) + \sinh(b\sqrt{2\lambda})}{\sinh((a+b)\sqrt{2\lambda})}$.

利用双曲函数恒等式, 也可写为 $\mathbb{E}e^{-\lambda\tau} = \frac{\cosh\left(\frac{a-b}{2}\sqrt{2\lambda}\right)}{\cosh\left(\frac{a+b}{2}\sqrt{2\lambda}\right)}$.

(3) 对任意有限个时刻 $t_1, \dots, t_k$, $(W_{t_1}, \dots, W_{t_k}, B_1)$ 是 Gaussian 向量, 因为它是 $(B_{t_1}, \dots, B_{t_k}, B_1)$ 的线性变换.

对任意 $t \in [0, 1]$,

$$\text{Cov}(W_t, B_1) = \text{Cov}(B_t - tB_1, B_1) = t - t = 0.$$

因此任意有限维向量 $(W_{t_1}, \dots, W_{t_k})$ 与 B_1 不相关. 由于它们联合 Gaussian, 所以相互独立.

又因 W_t 具有连续路径, $\sigma(W_t : 0 \leq t \leq 1) = \sigma(W_q : q \in \mathbb{Q} \cap [0, 1])$. 由有限维独立性和单调类论证,

$\{W_t : 0 \leq t \leq 1\}$ 与 B_1 独立.

均值为 $\mathbb{E}W_t = 0$, 协方差为

$$\text{Cov}(W_s, W_t) = \text{Cov}(B_s - sB_1, B_t - tB_1) = s \wedge t - t \text{Cov}(B_s, B_1) - s \text{Cov}(B_t, B_1) + st \text{Var}(B_1) = s \wedge t - st.$$

故 $\text{Cov}(W_s, W_t) = s \wedge t - st$. 令 $\mathbf{B} = (B_{t_1}, \dots, B_{t_k})^\top$. 则 $\mathbf{B} | B_1 = 0 \sim N_k(\mathbf{0}, K)$, 其中 $K_{ij} = t_i \wedge t_j - t_i t_j$.

即 $(B_{t_1}, \dots, B_{t_k}) | B_1 = 0 \sim N_k\left(\mathbf{0}, [t_i \wedge t_j - t_i t_j]_{i,j=1}^k\right)$.

Problem 5 (10 分)

设 $m \geq 3$, 在循环群 $\mathbb{Z}/m\mathbb{Z} = \{0, 1, \dots, m-1\}$ 上考虑简单随机游动 $\{X_n : n \geq 0\}$: 在每一步中, 游动者以相同概率移动到两个相邻顶点, 即 $X_{n+1} = X_n + 1 \pmod{m}$ 或 $X_{n+1} = X_n - 1 \pmod{m}$, 两种情况各以概率 $1/2$ 发生.

- (1) 判断该链是否不可约, 并根据 m 的奇偶性确定其周期. 求其平稳分布, 并判断该平稳分布是否可逆.
- (2) 对 $i \in \{1, \dots, m-1\}$, 令 $T_0 = \inf\{n \geq 0 : X_n = 0\}$. 求 $\mathbb{E}_i T_0$.
- (3) 定义从 0 出发的首次正返时间 $T_0^+ = \inf\{n \geq 1 : X_n = 0\}$. 求 $\mathbb{E}_0 T_0^+$. 判断该答案是否依赖 m 的奇偶性, 并说明原因.

第 5 题解答

- (1) 循环图是连通图, 因此简单随机游动不可约.

若 m 为偶数, 循环图为二分图, 每一步在两个顶点类之间交替, 所有返还时间均为偶数; 又存在两步返还, 所以周期为 $[2]$.

若 m 为奇数, 存在两步返还, 也存在沿同一方向走 m 步后返还. 因为 $\gcd(2, m) = 1$, 所以周期为 $[1]$.

转移矩阵是双随机矩阵, 因此均匀分布 $\pi_j = \frac{1}{m}, \quad j = 0, \dots, m-1$ 为平稳分布. 由于链有限且不可约, 该平稳分布唯一.

对任意相邻顶点 i, j , $\pi_i P_{ij} = \frac{1}{m} \cdot \frac{1}{2} = \pi_j P_{ji}$. 对不相邻顶点, 两边均为零. 故 该链关于均匀平稳分布可逆.

- (2) 在首次到达 0 之前, 可将循环图展开为区间 $\{0, 1, \dots, m\}$, 其中顶点 0 与 m 都代表原循环图中的状态 0. 令 $h_i = \mathbb{E}_i T_0, \quad i = 0, \dots, m$. 边界条件为 $h_0 = h_m = 0$. 对 $1 \leq i \leq m-1$, 第一步分析给出 $h_i = 1 + \frac{1}{2}h_{i-1} + \frac{1}{2}h_{i+1}$. 等价地, $h_{i+1} - 2h_i + h_{i-1} = -2$.

该差分方程的一般二次型解为 $h_i = -i^2 + Ci + D$. 由 $h_0 = 0$ 得 $D = 0$, 由 $h_m = 0$ 得 $C = m$. 因此

$$\mathbb{E}_i T_0 = i(m-i), \quad i = 1, \dots, m-1.$$

- (3) 从 0 出发, 第一步以概率 $1/2$ 到达 1, 以概率 $1/2$ 到达 $m-1$. 因此

$$\mathbb{E}_0 T_0^+ = 1 + \frac{1}{2}\mathbb{E}_1 T_0 + \frac{1}{2}\mathbb{E}_{m-1} T_0 = 1 + \frac{1}{2}(m-1) + \frac{1}{2}(m-1) = m.$$

故 $\mathbb{E}_0 T_0^+ = m$.

该答案不依赖 m 的奇偶性. 周期性决定返还时间可以取哪些整数值以及转移概率是否收敛, 但不改变有限不可约链中的平均返还时间 $\mathbb{E}_0 T_0^+ = \frac{1}{\pi_0} = m$.

Problem 6 (10 分)

设 $\{N_t : t \geq 0\}$ 为强度 $\lambda > 0$ 的 Poisson process, 其自然过滤记为 $\mathcal{F}_t = \sigma(N_s : 0 \leq s \leq t)$. 令 $T_k = \inf\{t \geq 0 : N_t \geq k\}$, $k \geq 1$, 为第 k 个到达时刻.

- (1) 求 T_k 的分布、密度、均值、方差和矩母函数的存在区间.
- (2) 对 $0 \leq s \leq t$, 求 $\mathbb{E}(N_t | \mathcal{F}_s)$ 和 $\mathbb{E}[(N_t - N_s)^2 | \mathcal{F}_s]$. 判断并证明下列两个过程是否为鞅: $M_t = N_t - \lambda t$, $K_t = (N_t - \lambda t)^2 - \lambda t$.
- (3) 固定 $t > 0$ 和整数 $n \geq k$. 求 $(T_1, \dots, T_n) | N_t = n$ 的联合密度, 并由此确定 $\frac{T_k}{t} | N_t = n$ 的分布.

第 6 题解答

- (1) 事件 $\{T_k \leq t\}$ 等价于 $\{N_t \geq k\}$. 因此, 对 $t \geq 0$,

$$\mathbb{P}(T_k \leq t) = 1 - \mathbb{P}(N_t \leq k-1) = 1 - e^{-\lambda t} \sum_{j=0}^{k-1} \frac{(\lambda t)^j}{j!}.$$

故 $F_{T_k}(t) = 1 - e^{-\lambda t} \sum_{j=0}^{k-1} \frac{(\lambda t)^j}{j!}, \quad t \geq 0$ 。求导得到密度 $f_{T_k}(t) = \frac{\lambda^k}{(k-1)!} t^{k-1} e^{-\lambda t} \mathbb{1}_{\{t>0\}}$ 。

因此 $T_k \sim \text{Gamma}(k, \lambda)$ 。所以 $\mathbb{E}T_k = \frac{k}{\lambda}, \quad \text{Var}(T_k) = \frac{k}{\lambda^2}$ 。

对实数 $u < \lambda$, $\mathbb{E}e^{uT_k} = \left(\frac{\lambda}{\lambda-u}\right)^k$ 。当 $u \geq \lambda$ 时该期望发散。因此矩母函数的存在区间为 $(-\infty, \lambda)$ 。

(2) 令 $h = t - s$ 。由 Poisson process 的独立平稳增量, $N_t - N_s \sim \text{Poisson}(\lambda h)$, 且与 $\mathcal{F}_s$ 独立。因此

$$\mathbb{E}(N_t | \mathcal{F}_s) = N_s + \lambda(t - s).$$

又

$$\mathbb{E}[(N_t - N_s)^2 | \mathcal{F}_s] = \text{Var}(N_t - N_s) + [\mathbb{E}(N_t - N_s)]^2 = \lambda(t - s) + \lambda^2(t - s)^2.$$

故 $\mathbb{E}[(N_t - N_s)^2 | \mathcal{F}_s] = \lambda(t - s) + \lambda^2(t - s)^2$ 。

对 $M_t = N_t - \lambda t$, 有

$$\mathbb{E}(M_t | \mathcal{F}_s) = \mathbb{E}(N_t | \mathcal{F}_s) - \lambda t = N_s + \lambda(t - s) - \lambda t = N_s - \lambda s = M_s.$$

所以 $\{M_t\}_{t \geq 0}$ 是鞅。

再令 $\Delta = N_t - N_s$ 。则 $M_t = M_s + \Delta - \lambda(t - s)$ 。由于 $\mathbb{E}[\Delta - \lambda(t - s)] = 0$, 且 $\mathbb{E}[\Delta - \lambda(t - s)]^2 = \lambda(t - s)$, 故 $\mathbb{E}(M_t^2 | \mathcal{F}_s) = M_s^2 + \lambda(t - s)$ 。于是

$$\mathbb{E}(K_t | \mathcal{F}_s) = \mathbb{E}(M_t^2 - \lambda t | \mathcal{F}_s) = M_s^2 + \lambda(t - s) - \lambda t = M_s^2 - \lambda s = K_s.$$

因此 $K_t = (N_t - \lambda t)^2 - \lambda t$ 也是鞅。

(3) 对 $0 < t_1 < \dots < t_n < t$, Poisson process 的到达时刻联合密度满足 $f_{T_1, \dots, T_n, N_t}(t_1, \dots, t_n, n) = \lambda^n e^{-\lambda t}$ 。而

$\mathbb{P}(N_t = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}$ 。因此条件联合密度为 $f_{T_1, \dots, T_n | N_t = n}(t_1, \dots, t_n) = \frac{n!}{t^n} \mathbb{1}_{\{0 < t_1 < \dots < t_n < t\}}$ 。

这恰是 n 个独立 $\text{Uniform}(0, t)$ 随机变量的次序统计量联合密度。

因此 $\frac{T_k}{t} | N_t = n$ 服从第 k 个标准均匀次序统计量的分布, 即 $\frac{T_k}{t} | N_t = n \sim \text{Beta}(k, n - k + 1)$ 。

其密度为 $f(u) = \frac{n!}{(k-1)!(n-k)!} u^{k-1} (1-u)^{n-k} \mathbb{1}_{\{0 < u < 1\}}$ 。

Problem 7 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \Gamma(\alpha, \lambda)$, $n \geq 2$, 其中 shape 参数 $\alpha > 0$ 已知, rate 参数 $\lambda > 0$ 未知。定义 $T = \sum_{i=1}^n X_i$, $V_i = \frac{X_i}{T}$, $i = 1, \dots, n-1$, 并令 $V_n = 1 - \sum_{i=1}^{n-1} V_i$ 。

- (1) 求随机向量 $(T, V_1, \dots, V_{n-1})$ 的联合密度, 包括其完整支撑集。识别 T 与 $(V_1, \dots, V_n)$ 的分布, 并判断二者是否独立。特别地, 求 V_1 的边缘分布。
- (2) 证明 T 是参数 λ 的极大充分统计量且是完全统计量。证明 $(V_1, \dots, V_n)$ 是辅助统计量。说明这些结论与第 (a) 问所得独立性之间的关系。

(3) 求总体均值 $m(\lambda) = \mathbb{E}_\lambda X_1 = \frac{\alpha}{\lambda}$ 和总体方差 $v(\lambda) = \text{Var}_\lambda(X_1) = \frac{\alpha}{\lambda^2}$ 的 UMVUE。

再给定 $0 < \delta < 1$, 构造 λ 的一个精确 $1 - \delta$ 置信区间。

第 7 题解答

设 $T = \sum_{i=1}^n X_i$, $V_i = \frac{X_i}{T}$.

(1) 作变量变换 $x_i = tv_i$, $i = 1, \dots, n-1$, 以及 $x_n = t(1 - \sum_{i=1}^{n-1} v_i) = tv_n$. 其支撑集为

$$t > 0, \quad v_i > 0, \quad \sum_{i=1}^{n-1} v_i < 1.$$

Jacobian 的绝对值为 $\left| \frac{\partial(x_1, \dots, x_n)}{\partial(t, v_1, \dots, v_{n-1})} \right| = t^{n-1}$.

原联合密度为 $f_{\mathbf{X}}(\mathbf{x}) = \frac{\lambda^{n\alpha}}{\Gamma(\alpha)^n} (\prod_{i=1}^n x_i^{\alpha-1}) e^{-\lambda \sum x_i}$. 代入变换得到

$$f_{T, \mathbf{V}}(t, v_1, \dots, v_{n-1}) = \frac{\lambda^{n\alpha}}{\Gamma(\alpha)^n} t^{n(\alpha-1)} \left(\prod_{i=1}^n v_i^{\alpha-1} \right) e^{-\lambda t} t^{n-1} = \frac{\lambda^{n\alpha}}{\Gamma(\alpha)^n} t^{n\alpha-1} e^{-\lambda t} \prod_{i=1}^n v_i^{\alpha-1}.$$

将其分解为

$$f_{T, \mathbf{V}} = \left[\frac{\lambda^{n\alpha}}{\Gamma(n\alpha)} t^{n\alpha-1} e^{-\lambda t} \right] \times \left[\frac{\Gamma(n\alpha)}{\Gamma(\alpha)^n} \prod_{i=1}^n v_i^{\alpha-1} \right].$$

因此 $T \sim \text{Gamma}(n\alpha, \lambda)$, 以及 $(V_1, \dots, V_n) \sim \text{Dirichlet}(\alpha, \dots, \alpha)$. 联合密度分解为 t 的函数与 $\mathbf{v}$ 的函数之积, 所以 T 与 $(V_1, \dots, V_n)$ 独立。Dirichlet 分布的边缘分布给出 $V_1 \sim \text{Beta}(\alpha, (n-1)\alpha)$.

(2) 样本联合密度可写为 $f_{\lambda}(\mathbf{x}) = \frac{\lambda^{n\alpha}}{\Gamma(\alpha)^n} e^{-\lambda T(\mathbf{x})} \prod_{i=1}^n x_i^{\alpha-1} \mathbb{1}_{\{x_i > 0\}}$. 由因子分解定理, $T = \sum_{i=1}^n X_i$ 对 λ 充分。

对两个样本点 $\mathbf{x}, \mathbf{y} \in (0, \infty)^n$, $\frac{f_{\lambda}(\mathbf{x})}{f_{\lambda}(\mathbf{y})} = \frac{\prod_{i=1}^n x_i^{\alpha-1}}{\prod_{i=1}^n y_i^{\alpha-1}} \exp\{-\lambda[T(\mathbf{x}) - T(\mathbf{y})]\}$. 该比值与 λ 无关, 当且仅当 $T(\mathbf{x}) = T(\mathbf{y})$. 因此由极小充分统计量的似然比判据, T 是极小充分统计量。

下面证明完全性。设可测函数 g 满足 $\mathbb{E}_\lambda g(T) = 0 \quad \forall \lambda > 0$. 由于 $T \sim \text{Gamma}(n\alpha, \lambda)$, 有 $\int_0^\infty g(t) t^{n\alpha-1} e^{-\lambda t} dt = 0, \quad \forall \lambda > 0$. 左端是函数 $h(t) = g(t) t^{n\alpha-1}$ 的 Laplace 变换。由 Laplace 变换的唯一性, $h(t) = 0$ Lebesgue-a.e. 因为 $t^{n\alpha-1} > 0$ 对 $t > 0$ 成立, 所以 $g(t) = 0$ Lebesgue-a.e. 从而 $g(T) = 0$ $\mathbb{P}_\lambda$ -a.s. 故 T 是完全统计量。

第 (a) 问已得到 $(V_1, \dots, V_n) \sim \text{Dirichlet}(\alpha, \dots, \alpha)$, 其分布不含 λ . 所以 $(V_1, \dots, V_n)$ 是辅助统计量。

由于 T 完全充分而 $\mathbf{V}$ 辅助, Basu 定理给出 $T \perp \mathbf{V}$, 这与第 (a) 问由联合密度直接得到的独立性完全一致。

(3) 总体均值为 $m(\lambda) = \frac{\alpha}{\lambda}$. 由于 $\mathbb{E}_\lambda T = \frac{n\alpha}{\lambda}$, 所以 $\mathbb{E}_\lambda \left(\frac{T}{n}\right) = \frac{\alpha}{\lambda}$. 又 T/n 是完全充分统计量 T 的函数, 因此由

Lehmann-Scheffé 定理, $\hat{m}_{\text{UMVUE}} = \frac{T}{n} = \bar{X}$.

总体方差为 $v(\lambda) = \frac{\alpha}{\lambda^2}$. 对于 $T \sim \text{Gamma}(n\alpha, \lambda)$, 有 $\mathbb{E}T^2 = \frac{n\alpha(n\alpha+1)}{\lambda^2}$. 故 $\mathbb{E}\left[\frac{T^2}{n(n\alpha+1)}\right] = \frac{\alpha}{\lambda^2}$. 因此

$$\hat{v}_{\text{UMVUE}} = \frac{T^2}{n(n\alpha+1)}.$$

由于 $T \sim \text{Gamma}(n\alpha, \lambda)$, 有精确分布 $2\lambda T \sim \chi_{2n\alpha}^2$. 因此 $\mathbb{P}\left(\chi_{2n\alpha, \delta/2}^2 \leq 2\lambda T \leq \chi_{2n\alpha, 1-\delta/2}^2\right) = 1 - \delta$. 解出 λ , 得到精确置信区间 $\left[\frac{\chi_{2n\alpha, \delta/2}^2}{2T}, \frac{\chi_{2n\alpha, 1-\delta/2}^2}{2T}\right]$.

Problem 8 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $n = 2r + 1 \geq 3$, 其中 $\mu \in \mathbb{R}$, $\sigma > 0$ 均未知. 记样本中位数为 $M_n = X_{(r+1)}$, 样本均值和样本方差分别为 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

- (1) 当 $n \rightarrow \infty$ 且始终取奇数时, 证明 $\sqrt{n}(M_n - \mu)$ 渐近正态, 并明确给出其渐近方差. 将其与 $\sqrt{n}(\bar{X} - \mu)$ 的渐近方差比较, 并求样本中位数相对于样本均值的渐近相对效率.
- (2) 确定 $\bar{X}$ 与 S_X^2 的独立性及各异的精确分布. 对任意 $0 < \delta < 1$, 分别构造 μ 和 σ^2 的精确 $1 - \delta$ 置信区间.
- (3) 另有与上述样本独立的随机样本 $Y_1, \dots, Y_m \stackrel{\text{i.i.d.}}{\sim} N(\nu, \tau^2)$, $m \geq 2$, 其样本方差为 S_Y^2 . 构造方差比 $\frac{\sigma^2}{\tau^2}$ 的精确 $1 - \delta$ 置信区间.

第 8 题解答

记正态密度为 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$. 特别地, $f(\mu) = \frac{1}{\sigma\sqrt{2\pi}}$.

- (1) 固定 $x \in \mathbb{R}$, 令 $y_n = \mu + \frac{x}{\sqrt{n}}$, 并定义 $K_n = \sum_{i=1}^n \mathbb{1}_{\{X_i \leq y_n\}}$. 则 $K_n \sim \text{Bin}(n, p_n)$, $p_n = F(y_n)$. 由 F 在 μ 处可微, $p_n = \frac{1}{2} + f(\mu)\frac{x}{\sqrt{n}} + o(n^{-1/2})$.

因为 $n = 2r + 1$, 且样本来自连续分布, $\{M_n \leq y_n\} = \{K_n \geq r + 1\}$. 令 $Z_n = \frac{K_n - np_n}{\sqrt{np_n(1-p_n)}}$. 由于 $p_n \rightarrow 1/2$, 二项分布中心极限定理给出 $Z_n \xrightarrow{d} N(0, 1)$.

同时,

$$\frac{r + 1 - np_n}{\sqrt{np_n(1-p_n)}} = \frac{(n+1)/2 - n[1/2 + f(\mu)x/\sqrt{n} + o(n^{-1/2})]}{\sqrt{n}/2 + o(\sqrt{n})} \rightarrow -2f(\mu)x.$$

因此

$$\mathbb{P}(\sqrt{n}(M_n - \mu) \leq x) = \mathbb{P}(K_n \geq r + 1) \rightarrow 1 - \Phi(-2f(\mu)x) = \Phi(2f(\mu)x).$$

所以 $\sqrt{n}(M_n - \mu) \xrightarrow{d} N\left(0, \frac{1}{4f(\mu)^2}\right)$. 代入 $f(\mu) = \frac{1}{\sigma\sqrt{2\pi}}$, 得到 $\sqrt{n}(M_n - \mu) \xrightarrow{d} N\left(0, \frac{\pi\sigma^2}{2}\right)$.

另一方面, $\sqrt{n}(\bar{X} - \mu) \sim N(0, \sigma^2)$ 对每个 n 都精确成立.

因此样本中位数相对于样本均值的渐近相对效率为 $\text{ARE}(M_n, \bar{X}) = \frac{\sigma^2}{\pi\sigma^2/2} = \frac{2}{\pi}$.

- (2) 正态样本的经典结论为 $\bar{X} \perp S_X^2$, 且 $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$, 以及 $\frac{(n-1)S_X^2}{\sigma^2} \sim \chi_{n-1}^2$.

进一步,
$$\frac{\sqrt{n}(\bar{X} - \mu)}{S_X} \sim t_{n-1}.$$

因此 μ 的精确 $1 - \delta$ 置信区间为
$$\left[\bar{X} - t_{n-1, 1-\delta/2} \frac{S_X}{\sqrt{n}}, \bar{X} + t_{n-1, 1-\delta/2} \frac{S_X}{\sqrt{n}} \right].$$

由卡方 pivot, $\mathbb{P}\left(\chi_{n-1, \delta/2}^2 \leq \frac{(n-1)S_X^2}{\sigma^2} \leq \chi_{n-1, 1-\delta/2}^2\right) = 1 - \delta$. 所以 σ^2 的精确置信区间为
$$\left[\frac{(n-1)S_X^2}{\chi_{n-1, 1-\delta/2}^2}, \frac{(n-1)S_X^2}{\chi_{n-1, \delta/2}^2} \right].$$

(3) 由于两个样本相互独立, $\frac{(n-1)S_X^2}{\sigma^2} \sim \chi_{n-1}^2$, $\frac{(m-1)S_Y^2}{\tau^2} \sim \chi_{m-1}^2$, 且二者独立. 因此
$$\frac{S_X^2/\sigma^2}{S_Y^2/\tau^2} = \frac{S_X^2/S_Y^2}{\sigma^2/\tau^2} \sim F_{n-1, m-1}.$$

令 $\rho = \frac{\sigma^2}{\tau^2}$. 则 $\mathbb{P}\left(F_{n-1, m-1, \delta/2} \leq \frac{S_X^2/S_Y^2}{\rho} \leq F_{n-1, m-1, 1-\delta/2}\right) = 1 - \delta$. 解出 ρ , 得到
$$\left[\frac{S_X^2/S_Y^2}{F_{n-1, m-1, 1-\delta/2}}, \frac{S_X^2/S_Y^2}{F_{n-1, m-1, \delta/2}} \right].$$

Problem 9 (15 分)

设 $X_1, \dots, X_n$ 为来自密度族 $f(x | \theta) = \theta x^{\theta-1} \mathbb{1}_{\{0 < x < 1\}}$, $\theta > 0$, 的 iid 样本. 定义 $T = -\sum_{i=1}^n \log X_i$.

(1) 求 θ 的最大似然估计量 $\hat{\theta}_n$, 证明其强相合性, 并求 $\sqrt{n}(\hat{\theta}_n - \theta)$ 的极限分布.

求单个观测的 Fisher 信息 $I_1(\theta)$, 并说明 $\hat{\theta}_n$ 的渐近方差与信息下界之间的关系.

进一步求 $\sqrt{n}(\log \hat{\theta}_n - \log \theta)$ 的极限分布.

(2) 固定 $\theta_0 > 0$ 和 $0 < \delta < 1$. 构造检验 $H_0: \theta \leq \theta_0$ 对 $H_1: \theta > \theta_0$ 的 size δ 一致最强检验, 并将拒绝域写成 T 的显式不等式.

求该检验在任意 $\theta > 0$ 下的功效函数, 并写出备择参数 $\theta_1 > \theta_0$ 下的第二类错误概率.

(3) 考虑双侧检验 $H_0: \theta = \theta_0$ 对 $H_1: \theta \neq \theta_0$. 判断 size δ 的 UMP 检验是否存在, 并给出严格理由. 推导该问题的广义似然比统计量. 将精确 GLR 拒绝域写成 $T < c_1$ 或 $T > c_2$, 其中 $c_1 < \frac{n}{\theta_0} < c_2$. 允许用一个由两个方程组成的方程组刻画 c_1, c_2 , 但必须明确写出这两个方程.

最后求在 H_0 下 $-2 \log \Lambda_n$ 的渐近分布.

第 9 题解答

定义 $Y_i = -\log X_i$. 对 $y > 0$, $\mathbb{P}(Y_i > y) = \mathbb{P}(X_i < e^{-y}) = e^{-\theta y}$. 所以 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\theta)$, 并且 $T = \sum_{i=1}^n Y_i \sim \text{Gamma}(n, \theta)$.

(1) 似然函数为

$$L(\theta) = \prod_{i=1}^n \theta X_i^{\theta-1} = \theta^n \exp \left\{ (\theta - 1) \sum_{i=1}^n \log X_i \right\} = e^T \theta^n e^{-\theta T}.$$

忽略与 θ 无关的因子 e^T , $\ell(\theta) = n \log \theta - \theta T + C$. 因此 $\ell'(\theta) = \frac{n}{\theta} - T$, $\ell''(\theta) = -\frac{n}{\theta^2} < 0$. 唯一 MLE 为 $\hat{\theta}_n = \frac{n}{T}$.

由强大数律, $\frac{T}{n} = \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{\text{a.s.}} \mathbb{E}Y_1 = \frac{1}{\theta}$. 连续映射定理给出 $\hat{\theta}_n = \frac{1}{T/n} \xrightarrow{\text{a.s.}} \theta$.

由于 $\mathbb{E}Y_1 = \frac{1}{\theta}$, $\text{Var}(Y_1) = \frac{1}{\theta^2}$, 中心极限定理给出 $\sqrt{n} \left(\frac{T}{n} - \frac{1}{\theta} \right) \xrightarrow{d} N \left(0, \frac{1}{\theta^2} \right)$. 令 $g(y) = \frac{1}{y}$, $g'(1/\theta) = -\theta^2$. 由 Delta 方法, $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \theta^2)$.

单个观测的 log-likelihood 为 $\ell_1(\theta) = \log \theta + (\theta - 1) \log X$. score 为 $U_1(\theta) = \frac{1}{\theta} + \log X = \frac{1}{\theta} - Y$. 因此

$I_1(\theta) = \text{Var}_\theta(U_1(\theta)) = \text{Var}(Y) = \frac{1}{\theta^2}$. 也可由 $-\mathbb{E}\ell_1''(\theta) = \frac{1}{\theta^2}$ 得到。

故 $I_1(\theta) = \frac{1}{\theta^2}$. MLE 的渐近方差为 $\frac{I_1(\theta)^{-1}}{n} = \frac{\theta^2}{n}$, 所以 $\hat{\theta}_n$ 达到一阶 Fisher 信息下界, 是渐近有效的。

再对函数 $h(\theta) = \log \theta$ 使用 Delta 方法。因为 $h'(\theta) = \frac{1}{\theta}$, 有 $\sqrt{n}(\log \hat{\theta}_n - \log \theta) \xrightarrow{d} N(0, 1)$.

- (2) T 的密度为 $g_\theta(t) = \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t}$, $t > 0$. 若 $\theta_1 > \theta_0$, 则 $\frac{g_{\theta_1}(t)}{g_{\theta_0}(t)} = \left(\frac{\theta_1}{\theta_0}\right)^n e^{-(\theta_1 - \theta_0)t}$, 它关于 t 严格递减。因此较大的 θ 对应较小的 T 。

故 size 为 δ 的 UMP 检验拒绝 H_0 当 T 足够小。原假设中的最不利参数点为 θ_0 。

由于 $2\theta_0 T \sim \chi_{2n}^2$ 在 $\theta = \theta_0$ 下, 取 $c_\delta = \frac{\chi_{2n, \delta}^2}{2\theta_0}$. 检验函数为 $\phi(\mathbf{X}) = \mathbb{I}_{\{T \leq \chi_{2n, \delta}^2 / (2\theta_0)\}}$. 其 size 为 $\sup_{\theta \leq \theta_0} \mathbb{P}_\theta(T \leq c_\delta) = \mathbb{P}_{\theta_0}(T \leq c_\delta) = \delta$.

对任意 $\theta > 0$, 功效函数为

$$\pi(\theta) = \mathbb{P}_\theta(T \leq c_\delta) = \mathbb{P}(2\theta T \leq 2\theta c_\delta) = F_{\chi_{2n}^2} \left(\frac{\theta}{\theta_0} \chi_{2n, \delta}^2 \right).$$

$$\text{即 } \pi(\theta) = F_{\chi_{2n}^2} \left(\frac{\theta}{\theta_0} \chi_{2n, \delta}^2 \right).$$

在备择参数 $\theta_1 > \theta_0$ 下, 第二类错误概率为 $1 - F_{\chi_{2n}^2} \left(\frac{\theta_1}{\theta_0} \chi_{2n, \delta}^2 \right)$.

- (3) 先说明 UMP 检验不存在。

固定 $\theta_+ > \theta_0$. 对于简单假设 $H_0: \theta = \theta_0$ 对 $H_1: \theta = \theta_+$, 似然比关于 T 严格递减, 所以唯一的 size δ 最强检验拒绝 T 的左尾。

另一方面, 固定 $0 < \theta_- < \theta_0$. 此时 $\frac{g_{\theta_-}(t)}{g_{\theta_0}(t)} = \left(\frac{\theta_-}{\theta_0}\right)^n e^{(\theta_0 - \theta_-)t}$ 关于 t 严格递增, 所以唯一的 size δ 最强检验拒绝 T 的右尾。

同一个检验不可能同时等于左尾检验和右尾检验。因此双侧备择下不存在 size δ 的 UMP 检验。

下面推导广义似然比。无约束 MLE 为 $\hat{\theta} = \frac{n}{T}$. 故

$$\Lambda_n = \frac{L(\theta_0)}{\sup_{\theta > 0} L(\theta)} = \frac{\theta_0^n e^{-\theta_0 T}}{(n/T)^n e^{-n}} = \left(\frac{\theta_0 T}{n}\right)^n e^{n - \theta_0 T}.$$

$$\text{所以 } \Lambda_n(T) = \left(\frac{\theta_0 T}{n}\right)^n e^{n - \theta_0 T}.$$

函数 $\Lambda_n(T)$ 在 $T = \frac{n}{\theta_0}$ 处取得最大值 1, 并在该点两侧严格下降。因此 GLR 拒绝域具有形式

$$T < c_1 \quad \text{或} \quad T > c_2, \quad \text{其中 } c_1 < \frac{n}{\theta_0} < c_2.$$

两个边界对应同一个似然比临界值, 因此满足 $\left(\frac{\theta_0 c_1}{n}\right)^n e^{n - \theta_0 c_1} = \left(\frac{\theta_0 c_2}{n}\right)^n e^{n - \theta_0 c_2}$. 同时, 为使检验具

有精确 size δ , 还需 $F_{\chi_{2n}^2}(2\theta_0 c_1) + 1 - F_{\chi_{2n}^2}(2\theta_0 c_2) = \delta$.

因此 c_1, c_2 由上述两个方程唯一确定。

该模型是正则的一维参数模型, θ_0 是参数空间内部点。由 Wilks 定理, $-2 \log \Lambda_n \xrightarrow{d} \chi_1^2$ 在 H_0 下。

Problem 10 (10 分)

给定参数 $\lambda > 0$ 后, 设 $X_1, \dots, X_n \mid \lambda \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$. 先验分布取为 $\lambda \sim \Gamma(a, b)$, 其中 $a \in \{2, 3, \dots\}$, $b > 0$ 均为已知常数。记 $S = \sum_{i=1}^n X_i$.

- (1) 求 λ 的后验分布。分别求其后验均值和后验众数, 并说明两者何时相等、何时不同。
- (2) 给定 λ 后, 设未来还有 m 个与原样本条件独立的观测 $X_{n+1}, \dots, X_{n+m} \mid \lambda \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, 并定义 $Y = \sum_{j=1}^m X_{n+j}$ 。求 $Y \mid X_1, \dots, X_n$ 的后验预测分布, 将其识别为一个负二项分布, 并求其后验预测均值和方差。
- (3) 分别在下列两种损失函数下求 λ 的 Bayes 估计量: $L_1(\lambda, d) = (d - \lambda)^2$, $L_2(\lambda, d) = \frac{(d - \lambda)^2}{\lambda}$ 。比较第二个 Bayes 估计量与第 (a) 问所得后验众数。

第 10 题解答

记 $S = \sum_{i=1}^n X_i$, $A = a + S$, $B = b + n$ 。

- (1) 似然函数为 $L(\lambda) \propto \lambda^S e^{-n\lambda}$ 。先验密度为 $\pi(\lambda) = \frac{b^a}{\Gamma(a)} \lambda^{a-1} e^{-b\lambda}$ 。因此后验密度核为 $\pi(\lambda \mid \mathbf{X}) \propto \lambda^{a+S-1} e^{-(b+n)\lambda}$ 。

故 $\lambda \mid \mathbf{X} \sim \text{Gamma}(A, B) = \text{Gamma}(a + S, b + n)$, 后验均值为 $\mathbb{E}(\lambda \mid \mathbf{X}) = \frac{A}{B} = \frac{a + S}{b + n}$ 。

由于 $A = a + S \geq 2$, 后验众数位于正半轴内部, 为 $\text{Mode}(\lambda \mid \mathbf{X}) = \frac{A - 1}{B} = \frac{a + S - 1}{b + n}$ 。

二者之差为 $\frac{A}{B} - \frac{A-1}{B} = \frac{1}{B} = \frac{1}{b+n} > 0$ 。因此在题设条件下二者从不严格相等, 且后验均值始终比后验众数大 $\frac{1}{b+n}$ 。

- (2) 给定 λ 后, $Y = \sum_{j=1}^m X_{n+j} \mid \lambda \sim \text{Poisson}(m\lambda)$ 。因此, 对 $y = 0, 1, 2, \dots$,

$$\begin{aligned} \mathbb{P}(Y = y \mid \mathbf{X}) &= \int_0^\infty \frac{e^{-m\lambda} (m\lambda)^y}{y!} \frac{B^A}{\Gamma(A)} \lambda^{A-1} e^{-B\lambda} d\lambda \\ &= \frac{m^y B^A}{\Gamma(A) y!} \int_0^\infty \lambda^{A+y-1} e^{-(B+m)\lambda} d\lambda \\ &= \frac{\Gamma(A+y)}{\Gamma(A) y!} \left(\frac{B}{B+m} \right)^A \left(\frac{m}{B+m} \right)^y. \end{aligned}$$

由于 $A = a + S$ 为正整数, 这正是负二项分布 $Y \mid \mathbf{X} \sim \text{NegBin} \left(A, \frac{B}{B+m} \right)$ 。¹

按照题目中负二项分布的约定, $p = \frac{B}{B+m}$, $1 - p = \frac{m}{B+m}$ 。故 $\mathbb{E}(Y \mid \mathbf{X}) = \frac{A(1-p)}{p} = \frac{Am}{B}$ 。

方差为 $\text{Var}(Y \mid \mathbf{X}) = \frac{A(1-p)}{p^2} = \frac{Am(B+m)}{B^2}$ 。

代回 A, B , $\mathbb{E}(Y \mid \mathbf{X}) = \frac{m(a+S)}{b+n}$, $\text{Var}(Y \mid \mathbf{X}) = \frac{m(a+S)(b+n+m)}{(b+n)^2}$ 。

- (3) 在平方损失 $L_1(\lambda, d) = (d - \lambda)^2$ 下, Bayes 估计量为后验均值: $d_1^*(\mathbf{X}) = \frac{A}{B} = \frac{a + S}{b + n}$ 。

对于 $L_2(\lambda, d) = \frac{(d - \lambda)^2}{\lambda}$, 后验风险为

$$\rho_2(d \mid \mathbf{X}) = \mathbb{E} \left[\frac{(d - \lambda)^2}{\lambda} \mid \mathbf{X} \right] = d^2 \mathbb{E}(\lambda^{-1} \mid \mathbf{X}) - 2d + \mathbb{E}(\lambda \mid \mathbf{X}).$$

对 d 求导: $\frac{\partial \rho_2}{\partial d} = 2d \mathbb{E}(\lambda^{-1} \mid \mathbf{X}) - 2$ 。因此唯一极小点为 $d_2^* = \frac{1}{\mathbb{E}(\lambda^{-1} \mid \mathbf{X})}$ 。

若 $\lambda \mid \mathbf{X} \sim \text{Gamma}(A, B)$, $A > 1$, 则 $\mathbb{E}(\lambda^{-1} \mid \mathbf{X}) = \frac{B}{A-1}$ 。所以 $d_2^*(\mathbf{X}) = \frac{A-1}{B} = \frac{a + S - 1}{b + n}$ 。

¹ $\text{NegBin}(r, p)$ 表示第 r 次成功前的失败次数。

这恰好等于后验众数: $d_2^*(\mathbf{X}) = \text{Mode}(\lambda | \mathbf{X})$.

Problem 11 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(\theta, \theta+1)$, $\theta \in \mathbb{R}$, $n \geq 3$. 记 $X_{(1)} = \min_{1 \leq i \leq n} X_i$, $X_{(n)} = \max_{1 \leq i \leq n} X_i$.

(1) 求 θ 的矩估计量. 求最大似然估计量的全体最大化点, 并判断 MLE 是否唯一.

定义所选取的一个 MLE 为 $\hat{\theta}_{\text{mid}} = \frac{X_{(1)} + X_{(n)} - 1}{2}$.

(2) 求随机向量 $(n(X_{(1)} - \theta), n(\theta + 1 - X_{(n)}))$ 的联合极限分布, 并说明两个极限分量是否独立.

由此求 $n(\hat{\theta}_{\text{mid}} - \theta)$ 的极限分布, 并写出该极限分布的密度.

(3) 分别求矩估计量和 $\hat{\theta}_{\text{mid}}$ 的偏差与均方误差.

对 $n \geq 3$, 比较两者在平方损失下的风险, 并比较两种估计量的收敛速度.

第 11 题解答

令 $U_i = X_i - \theta$. 则 $U_1, \dots, U_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(0, 1)$.

(1) 总体均值为 $\mathbb{E}_\theta X_i = \theta + \frac{1}{2}$. 令总体均值等于样本均值, 得到矩估计量 $\hat{\theta}_{\text{MOM}} = \bar{X} - \frac{1}{2}$.

似然函数为 $L(\theta) = \prod_{i=1}^n \mathbb{1}_{\{\theta \leq X_i \leq \theta+1\}}$. 该似然为 1 当且仅当 $\theta \leq X_{(1)}$ 且 $\theta \geq X_{(n)} - 1$. 因此全体最大化点为 $\arg \max_{\theta \in \mathbb{R}} L(\theta) = [X_{(n)} - 1, X_{(1)}]$.

由于连续样本几乎处处满足 $X_{(n)} - X_{(1)} < 1$, 该区间几乎处处具有正长度, 所以 MLE 几乎处处不唯一.

题目给定的 $\hat{\theta}_{\text{mid}} = \frac{X_{(1)} + X_{(n)} - 1}{2}$ 正是最大化区间的中点, 因而确为一个 MLE.

(2) 记 $U_{(1)} = \min_i U_i$, $U_{(n)} = \max_i U_i$. 则 $X_{(1)} - \theta = U_{(1)}$, 且 $\theta + 1 - X_{(n)} = 1 - U_{(n)}$.

对任意 $x, y \geq 0$, 当 $x + y \leq n$ 时,

$$\mathbb{P}(nU_{(1)} > x, n(1 - U_{(n)}) > y) = \mathbb{P}\left(\frac{x}{n} < U_i < 1 - \frac{y}{n} \text{ 对所有 } i\right) = \left(1 - \frac{x+y}{n}\right)^n \rightarrow e^{-(x+y)} = e^{-x}e^{-y}.$$

右端是两个独立标准指数随机变量的联合生存函数. 因此 $(n(X_{(1)} - \theta), n(\theta + 1 - X_{(n)})) \xrightarrow{d} (E_1, E_2)$, 其中 $E_1, E_2 \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(1)$. 特别地, 两个极限分量独立.

又

$$\hat{\theta}_{\text{mid}} - \theta = \frac{U_{(1)} + U_{(n)} - 1}{2} = \frac{U_{(1)} - (1 - U_{(n)})}{2}.$$

所以 $n(\hat{\theta}_{\text{mid}} - \theta) \xrightarrow{d} \frac{E_1 - E_2}{2}$.

令 $D = E_1 - E_2$. 当 $d \geq 0$ 时,

$$f_D(d) = \int_0^\infty e^{-(d+y)} e^{-y} dy = \frac{1}{2} e^{-d}.$$

当 $d < 0$ 时同理有 $f_D(d) = \frac{1}{2} e^d$. 故 $f_D(d) = \frac{1}{2} e^{-|d|}$.

令 $W = \frac{D}{2}$. 则 $f_W(w) = 2f_D(2w) = e^{-2|w|}$. 因此 $n(\hat{\theta}_{\text{mid}} - \theta) \xrightarrow{d} W$, $f_W(w) = e^{-2|w|}$, $w \in \mathbb{R}$. 这是一项位置为 0、尺度为 1/2 的 Laplace 分布.

(3) 首先, $\hat{\theta}_{\text{MOM}} = \theta + \bar{U} - \frac{1}{2}$. 由于 $\mathbb{E}U_i = \frac{1}{2}$, $\text{Var}(U_i) = \frac{1}{12}$, 所以 $\boxed{\text{Bias}_{\theta}(\hat{\theta}_{\text{MOM}}) = 0}$, 并且 $\boxed{\text{MSE}_{\theta}(\hat{\theta}_{\text{MOM}}) = \frac{1}{12n}}$.

下面考虑中点 MLE. 标准均匀次序统计量满足 $\mathbb{E}U_{(1)} = \frac{1}{n+1}$, $\mathbb{E}U_{(n)} = \frac{n}{n+1}$. 因此 $\mathbb{E}\hat{\theta}_{\text{mid}} = \theta + \frac{1}{2} \left[\frac{1}{n+1} + \frac{n}{n+1} - 1 \right] = \theta$. 故 $\boxed{\text{Bias}_{\theta}(\hat{\theta}_{\text{mid}}) = 0}$.

此外, $\text{Var}(U_{(1)}) = \text{Var}(U_{(n)}) = \frac{n}{(n+1)^2(n+2)}$. 联合密度 $f_{U_{(1)}, U_{(n)}}(u, v) = n(n-1)(v-u)^{n-2}$, $0 < u < v < 1$, 给出 $\mathbb{E}[U_{(1)}U_{(n)}] = \frac{1}{n+2}$. 因此

$$\text{Cov}(U_{(1)}, U_{(n)}) = \frac{1}{n+2} - \frac{1}{n+1} \frac{n}{n+1} = \frac{1}{(n+1)^2(n+2)}.$$

于是

$$\text{Var}(\hat{\theta}_{\text{mid}}) = \frac{1}{4} \text{Var}(U_{(1)} + U_{(n)}) = \frac{1}{4} \left[2 \frac{n}{(n+1)^2(n+2)} + 2 \frac{1}{(n+1)^2(n+2)} \right] = \frac{1}{2(n+1)(n+2)}.$$

因为该估计量无偏, $\boxed{\text{MSE}_{\theta}(\hat{\theta}_{\text{mid}}) = \frac{1}{2(n+1)(n+2)}}$.

比较两个风险: $\frac{1}{2(n+1)(n+2)} < \frac{1}{12n}$ 等价于 $2(n+1)(n+2) > 12n$, 即 $(n-1)(n-2) > 0$. 因此对 $n \geq 3$,

$$\boxed{R_{\theta}(\hat{\theta}_{\text{mid}}) < R_{\theta}(\hat{\theta}_{\text{MOM}}) \quad \forall \theta \in \mathbb{R}.}$$

最后, 由中心极限定理, $\boxed{\sqrt{n}(\hat{\theta}_{\text{MOM}} - \theta) \xrightarrow{d} N\left(0, \frac{1}{12}\right)}$. 所以矩估计量具有 $\sqrt{n}$ 收敛速度。

而第 (b) 问表明 $\boxed{n(\hat{\theta}_{\text{mid}} - \theta) \xrightarrow{d} W}$, 所以中点 MLE 具有 n 收敛速度。

因此 $\boxed{\hat{\theta}_{\text{mid}}$ 的收敛速度快于 $\hat{\theta}_{\text{MOM}}$.



35.4 第四套试题 + 答案

Problem 1 (10 分)

设 $X = (X_1, X_2, X_3, X_4)^\top \sim N_4(0, \Sigma_\rho)$, 其中 $\Sigma_\rho = (1 - \rho)I_4 + \rho \mathbf{1}\mathbf{1}^\top$, $\mathbf{1} = (1, 1, 1, 1)^\top$. 定义

$$S = \sum_{i=1}^4 X_i, \quad \bar{X} = \frac{S}{4}, \quad Q = \sum_{i=1}^4 (X_i - \bar{X})^2, \quad R = \sqrt{Q}.$$

- (1) 求使 Σ_ρ 正定的全部 ρ 的取值范围。在该范围内, 求 (S, Q) 的联合分布, 并判断 S 与 Q 是否独立。
- (2) 推导 R 的密度, 求随机变量 $T = \frac{S/(2\sqrt{1+3\rho})}{\sqrt{Q/[3(1-\rho)]}}$ 的分布。
- (3) 求 $\mathbb{E}(X_1 | \sigma(S, Q))$, $\text{Cov}(X_1, Q)$, $\text{Cov}(X_1^2, Q)$ 。据此判断 X_1 与 Q 是否独立, 并给出严格理由。

第 1 题解答

解: 记 $P_0 = \frac{1}{4}\mathbf{1}\mathbf{1}^\top$, $P_\perp = I_4 - P_0$. 其中 P_0 是到 $\text{span}\{\mathbf{1}\}$ 的正交投影, $P_\perp$ 是到其正交补的正交投影。

- (1) 对任意满足 $\mathbf{1}^\top v = 0$ 的 v , $\Sigma_\rho v = (1 - \rho)v$. 而 $\Sigma_\rho \mathbf{1} = (1 - \rho + 4\rho)\mathbf{1} = (1 + 3\rho)\mathbf{1}$. 因此 Σ_ρ 的特征值为 $1 - \rho$ (重数 3), $1 + 3\rho$ (重数 1). 故 $-\frac{1}{3} < \rho < 1$ 是 Σ_ρ 正定的充要条件。

将 X 分解为 $X = P_0 X + P_\perp X = \bar{X}\mathbf{1} + U$, $U = P_\perp X$. 由于 $\text{Cov}(P_0 X, P_\perp X) = P_0 \Sigma_\rho P_\perp = 0$, 且二者联合高斯, 所以 $P_0 X \perp P_\perp X$.

注意 $S = \mathbf{1}^\top X$, $Q = \|P_\perp X\|^2 = \|U\|^2$. 又 $\text{Var}(S) = \mathbf{1}^\top \Sigma_\rho \mathbf{1} = 4(1 + 3\rho)$, 因此 $S \sim N(0, 4(1 + 3\rho))$. 在三维子空间 $\mathbf{1}^\perp$ 上, U 的协方差算子为 $(1 - \rho)I_{\mathbf{1}^\perp}$. 因而存在三个独立标准正态变量 Z_1, Z_2, Z_3 , 使 $Q \stackrel{d}{=} (1 - \rho)(Z_1^2 + Z_2^2 + Z_3^2)$. 即 $\frac{Q}{1 - \rho} \sim \chi_3^2$. 而且 $S \perp Q$.

因此 (S, Q) 的联合分布是上述两个独立分布的乘积分布。

- (2) 由于 $R = \sqrt{Q} = \sqrt{1 - \rho} \sqrt{\chi_3^2}$, $R/\sqrt{1 - \rho}$ 服从自由度为 3 的 χ 分布. 故 R 的密度为

$$f_R(r) = \sqrt{\frac{2}{\pi}} \frac{r^2}{(1 - \rho)^{3/2}} \exp\left\{-\frac{r^2}{2(1 - \rho)}\right\} \mathbb{1}_{\{r > 0\}}.$$

这就是尺度参数为 $\sqrt{1 - \rho}$ 的 Maxwell-Boltzmann 分布。

令 $Z = \frac{S}{2\sqrt{1+3\rho}}$. 则 $Z \sim N(0, 1)$, $\frac{Q}{1-\rho} \sim \chi_3^2$, $Z \perp Q$. 因此 $T = \frac{Z}{\sqrt{[Q/(1-\rho)]/3}} \sim t_3$. 即 $T \sim t_3$.

- (3) 由 $X_1 = \frac{S}{4} + U_1$ 以及 $U \perp S$, 可得 $\mathbb{E}(X_1 | S, Q) = \frac{S}{4} + \mathbb{E}(U_1 | Q)$. 条件于 Q 后, U 的条件分布关于变换 $U \mapsto -U$ 对称, 因此 $\mathbb{E}(U_1 | Q) = 0$. 故 $\mathbb{E}(X_1 | \sigma(S, Q)) = \frac{S}{4}$.

其次, $\text{Cov}(X_1, Q) = \mathbb{E}(X_1 Q)$, 因为 $\mathbb{E}X_1 = 0$. 由 $X_1 = \frac{S}{4} + U_1$, $S \perp Q$, $\mathbb{E}S = 0$, 以及 $U_1 Q$ 关于 $U \mapsto -U$ 为奇函数, 得 $\text{Cov}(X_1, Q) = 0$.

再计算 $\text{Cov}(X_1^2, Q)$. 由于 $S \perp U$, 交叉项的协方差为零, 且 $S^2/16$ 与 Q 独立, 所以 $\text{Cov}(X_1^2, Q) = \text{Cov}(U_1^2, Q)$. U 的协方差矩阵为 $\Sigma_U = (1 - \rho)P_\perp$. 对零均值高斯向量, 若 $Q = U^\top U$, 则 $\text{Cov}(U_1^2, Q) = 2e_1^\top \Sigma_U^2 e_1$. 因为 $\Sigma_U^2 = (1 - \rho)^2 P_\perp$, $e_1^\top P_\perp e_1 = 1 - \frac{1}{4} = \frac{3}{4}$, 所以 $\text{Cov}(X_1^2, Q) = \frac{3}{2}(1 - \rho)^2$.

由于 $-1/3 < \rho < 1$, 上式严格为正. 因此 X_1^2 与 Q 不独立, 从而 X_1 与 Q 不独立. 这也说明 $\text{Cov}(X_1, Q) = 0$ 只表示不相关, 并不表示独立.

□

Problem 2 (15 分)

设 $\{\varepsilon_k : k \geq 1\}$ 为 iid Rademacher 随机变量, 即 $\mathbb{P}(\varepsilon_k = 1) = \mathbb{P}(\varepsilon_k = -1) = \frac{1}{2}$. 令 $\mathcal{F}_n = \sigma(\varepsilon_1, \dots, \varepsilon_n)$, $M_n = \sum_{k=1}^n \frac{\varepsilon_k}{k}$.

- (1) 证明存在随机变量 M_∞ , 使 $M_n \xrightarrow{\text{a.s.}} M_\infty$ 且 $M_n \rightarrow M_\infty$ in L^2 . 求 $\mathbb{E}(M_\infty | \mathcal{F}_n)$, 并证明随机变量族 $\{M_n : n \geq 1\}$ 一致可积.
- (2) 求 M_∞ 的特征函数, 并将其写为收敛的无穷乘积. 进一步求 $\mathbb{E}M_\infty$, $\text{Var}(M_\infty)$, $\mathbb{E}(M_\infty^4)$, 并判断 M_∞ 是否服从正态分布.
- (3) 证明联合收敛 $(M_n, \sqrt{n}(M_\infty - M_n)) \xrightarrow{d} (M_\infty, Z)$, 其中 $Z \sim \mathcal{N}(0, 1)$, 且极限中的 Z 与 M_∞ 独立.

第 2 题解答

解:

- (1) 显然 M_n 是 $\mathcal{F}_n$ -可测的, 且 $\mathbb{E}|M_n|^2 = \sum_{k=1}^n \frac{1}{k^2} < \infty$. 又因为 ε_{n+1} 与 $\mathcal{F}_n$ 独立且均值为零, $\mathbb{E}(M_{n+1} | \mathcal{F}_n) = M_n + \frac{1}{n+1}\mathbb{E}(\varepsilon_{n+1} | \mathcal{F}_n) = M_n$. 故 $\{M_n, \mathcal{F}_n\}$ 是平方可积鞅. 同时 $\sup_n \mathbb{E}M_n^2 = \sum_{k=1}^\infty \frac{1}{k^2} = \frac{\pi^2}{6} < \infty$. 由平方可积鞅收敛定理, 存在 $M_\infty \in L^2$, 使

$$M_n \xrightarrow{\text{a.s.}} M_\infty, \quad M_n \rightarrow M_\infty \text{ in } L^2.$$

事实上 $M_\infty = \sum_{k=1}^\infty \frac{\varepsilon_k}{k}$ 在 L^2 和几乎处处意义下均成立.

由于 $M_n \rightarrow M_\infty$ in L^1 , 而条件期望是 L^1 -压缩算子, $\mathbb{E}(M_\infty | \mathcal{F}_n) = \lim_{m \rightarrow \infty} \mathbb{E}(M_m | \mathcal{F}_n) = M_n$. 即

$$\mathbb{E}(M_\infty | \mathcal{F}_n) = M_n.$$

此外, $\sup_n \mathbb{E}|M_n|^2 < \infty$. 对任意 $K > 0$, 由 Cauchy-Schwarz 和 Markov 不等式,

$$\mathbb{E}[|M_n| \mathbb{1}_{\{|M_n| > K\}}] \leq (\mathbb{E}M_n^2)^{1/2} \mathbb{P}(|M_n| > K)^{1/2} \leq \frac{\mathbb{E}M_n^2}{K}.$$

因而 $\sup_n \mathbb{E}[|M_n| \mathbb{1}_{\{|M_n| > K\}}] \leq \frac{\pi^2}{6K} \rightarrow 0$. 所以 $\{M_n : n \geq 1\}$ 一致可积.

- (2) 对有限部分和, $\phi_{M_n}(t) = \mathbb{E} \exp \left\{ it \sum_{k=1}^n \frac{\varepsilon_k}{k} \right\} = \prod_{k=1}^n \mathbb{E} e^{it\varepsilon_k/k} = \prod_{k=1}^n \cos \left(\frac{t}{k} \right)$. 因为 $M_n \xrightarrow{d} M_\infty$, 故


$$\phi_{M_\infty}(t) = \prod_{k=1}^\infty \cos \left(\frac{t}{k} \right).$$

对每个固定 t , 该无穷乘积收敛, 因为 $\sum_{k=1}^\infty |1 - \cos(\frac{t}{k})| < \infty$.

由对称性, $\mathbb{E}M_\infty = 0$. 又由独立性, $\text{Var}(M_\infty) = \sum_{k=1}^\infty \frac{1}{k^2} = \frac{\pi^2}{6}$.

对独立、均值为零的随机变量 $a_k \varepsilon_k$, 有 $\mathbb{E}(\sum_k a_k \varepsilon_k)^4 = \sum_k a_k^4 + 6 \sum_{j < k} a_j^2 a_k^2$. 等价地, $\mathbb{E}(\sum_k a_k \varepsilon_k)^4 = 3(\sum_k a_k^2)^2 - 2 \sum_k a_k^4$. 令 $a_k = 1/k$, 得到 $\mathbb{E}M_\infty^4 = 3 \left(\frac{\pi^2}{6} \right)^2 - 2 \frac{\pi^4}{90} = \frac{11\pi^4}{180}$.

若 M_∞ 为均值零、方差 $\pi^2/6$ 的正态变量, 则其四阶矩应为 $3 \left(\frac{\pi^2}{6} \right)^2 = \frac{\pi^4}{12} = \frac{15\pi^4}{180}$. 这与 $11\pi^4/180$ 不同.



因此 M_∞ 不服从正态分布.

- (3) 令 $T_n = \sqrt{n}(M_\infty - M_n) = \sum_{k=n+1}^{\infty} \frac{\sqrt{n}}{k} \varepsilon_k$. 其方差为 $\text{Var}(T_n) = n \sum_{k=n+1}^{\infty} \frac{1}{k^2} \rightarrow 1$. 且 $\max_{k>n} \frac{\sqrt{n}}{k} = \frac{\sqrt{n}}{n+1} \rightarrow 0$. 因而该三角阵列满足 Lindeberg 条件, 故 $T_n \xrightarrow{d} Z, \quad Z \sim \mathbf{N}(0, 1)$.

也可直接由特征函数验证: $\phi_{T_n}(t) = \prod_{k=n+1}^{\infty} \cos\left(\frac{t\sqrt{n}}{k}\right)$. 利用 $\log \cos x = -\frac{x^2}{2} + O(x^4)$, $x \rightarrow 0$, 有 $\log \phi_{T_n}(t) = -\frac{t^2}{2} n \sum_{k>n} \frac{1}{k^2} + O\left(t^4 n^2 \sum_{k>n} \frac{1}{k^4}\right) \rightarrow -\frac{t^2}{2}$.

对每个 n , M_n 只依赖 $\varepsilon_1, \dots, \varepsilon_n$, 而 T_n 只依赖 $\varepsilon_{n+1}, \varepsilon_{n+2}, \dots$, 所以 $M_n \perp T_n$. 因此对任意 $s, t \in \mathbb{R}$, $\mathbb{E}e^{isM_n + itT_n} = \mathbb{E}e^{isM_n} \mathbb{E}e^{itT_n} \rightarrow \phi_{M_\infty}(s)e^{-t^2/2}$. 右侧是 M_∞ 与独立标准正态变量的联合特征函数. 故

$$(M_n, \sqrt{n}(M_\infty - M_n)) \xrightarrow{d} (M_\infty, Z),$$

其中 $Z \sim \mathbf{N}(0, 1), \quad Z \perp M_\infty$.

□

Problem 3 (10 分)

设 $m \geq 3, \lambda > 0, 0 < p < 1$, 并记 $q = 1 - p$. 令 $\{N_t : t \geq 0\}$ 为强度 λ 的 Poisson process, 令 $\{\xi_k : k \geq 1\}$ 为与该过程独立的 iid 随机变量, 满足 $\mathbb{P}(\xi_k = 1) = p, \quad \mathbb{P}(\xi_k = -1) = q$. 令 $S_n = \sum_{k=1}^n \xi_k, \quad X_t = i + S_{N_t} \pmod{m}, \quad X_0 = i \in \{0, 1, \dots, m-1\}$.

- 令 C_t 和 D_t 分别表示时刻 t 前取值为 $+1$ 和 -1 的跳数. 求 (C_t, D_t) 的联合概率生成函数和联合分布, 并求 $\mathbb{E}e^{iuS_{N_t}}, \quad u \in \mathbb{R}$.
- 求过程 $\{X_t : t \geq 0\}$ 的无穷小生成矩阵. 令 $\omega_r = e^{2\pi ir/m}, \quad r = 0, 1, \dots, m-1$. 求转移概率 $p_t(i, j) = \mathbb{P}_i(X_t = j)$ 的显式有限和表达式.
- 判断该连续时间 Markov chain 是否不可约, 求其平稳分布, 并确定它可逆的充要条件. 证明对任意 i, j , $\lim_{t \rightarrow \infty} p_t(i, j)$ 存在, 并求该极限.

第 3 题解答

解: 记 $q = 1 - p$.

- (1) 每个 Poisson 到达被独立标记为 $+1$ 或 -1 , 其概率分别为 p 和 q . 因此 $C_t \sim \text{Poisson}(\lambda pt), \quad D_t \sim \text{Poisson}(\lambda qt), \quad C_t \perp D_t$. 联合概率生成函数为 $G_t(z_1, z_2) = \mathbb{E}(z_1^{C_t} z_2^{D_t}) = \exp\{\lambda pt(z_1 - 1) + \lambda qt(z_2 - 1)\}$.

即 $G_t(z_1, z_2) = \exp\{\lambda t[p(z_1 - 1) + q(z_2 - 1)]\}$.

联合概率质量函数为 $\mathbb{P}(C_t = c, D_t = d) = e^{-\lambda t} \frac{(\lambda pt)^c}{c!} \frac{(\lambda qt)^d}{d!}, \quad c, d \in \mathbb{N} \cup \{0\}$.

又 $S_{N_t} = C_t - D_t$, 所以 $\mathbb{E}e^{iuS_{N_t}} = \mathbb{E}e^{iuC_t} \mathbb{E}e^{-iuD_t} = \exp\{\lambda t[p(e^{iu} - 1) + q(e^{-iu} - 1)]\}$.

- (2) 对状态 $x \in \mathbb{Z}/m\mathbb{Z}$, 从 x 到 $x+1$ 的跳率为 λp , 从 x 到 $x-1$ 的跳率为 λq . 因此生成矩阵 $Q = (q_{xy})$ 满足 $q_{x, x+1} = \lambda p, \quad q_{x, x-1} = \lambda q, \quad q_{x, x} = -\lambda$, 其余元素为零, 所有下标均模 m 理解.

对 $f_r(x) = \omega_r^x, \quad \omega_r = e^{2\pi ir/m}$, 有

$$Qf_r(x) = \lambda p(f_r(x+1) - f_r(x)) + \lambda q(f_r(x-1) - f_r(x)) = \kappa_r f_r(x),$$

其中 $\kappa_r = \lambda(p\omega_r + q\omega_r^{-1} - 1)$ 。因而 $P_t f_r(i) = e^{t\kappa_r} \omega_r^i$ 。利用离散 Fourier 反演,

$$p_t(i, j) = \frac{1}{m} \sum_{r=0}^{m-1} \exp \{ \lambda t (p\omega_r + q\omega_r^{-1} - 1) \} \omega_r^{i-j}.$$

虽然右侧写成复数形式, 但共轭项成对出现, 故总和为实数。

- (3) 因为 $p, q > 0$, 从任一状态均可沿循环的两个方向到达任意其他状态, 所以该链不可约。

令 $\pi_j = \frac{1}{m}$, $j = 0, \dots, m-1$ 。对任一 j , 流入 j 的总平稳流为 $\pi_{j-1}\lambda p + \pi_{j+1}\lambda q = \frac{\lambda}{m} = \pi_j\lambda$, 故

$\pi = (1/m, \dots, 1/m)$ 是平稳分布。有限不可约链的平稳分布唯一。

可逆性要求详细平衡: $\pi_j q_{j,j+1} = \pi_{j+1} q_{j+1,j}$ 。即 $\frac{\lambda p}{m} = \frac{\lambda q}{m}$ 。因而 $\text{该链可逆} \iff p = q \iff p = \frac{1}{2}$ 。

对 $r \neq 0$, $\text{Re } \kappa_r = \lambda \left[(p+q) \cos \left(\frac{2\pi r}{m} \right) - 1 \right] = \lambda \left[\cos \left(\frac{2\pi r}{m} \right) - 1 \right] < 0$ 。对 $r = 0$, $\kappa_0 = 0$ 。因此在转移概

率的 Fourier 表达式中, 所有 $r \neq 0$ 的项均趋于零, 只剩 $r = 0$ 项。故 $\lim_{t \rightarrow \infty} p_t(i, j) = \frac{1}{m}, \quad i, j \in \mathbb{Z}/m\mathbb{Z}$ 。

□

Problem 4 (15 分)

设 $\{B_t : t \geq 0\}$ 为一维标准 Brownian motion。对 $x \in (-a, b)$, 记 $\mathbb{P}_x$ 和 $\mathbb{E}_x$ 为从 $B_0 = x$ 出发时的概率和期望, 其中 $a > 0$, $b > 0$ 。定义首次离开时间 $\tau = \inf\{t \geq 0 : B_t \notin (-a, b)\}$ 。

- (1) 对 $\lambda > 0$ 和 Borel 集 $A \subset (-a, b)$, 定义 $R_\lambda(x, A) = \mathbb{E}_x \left[\int_0^\tau e^{-\lambda t} \mathbb{1}_{\{B_t \in A\}} dt \right]$ 。证明 $R_\lambda(x, \cdot)$ 关于 Lebesgue 测度绝对连续, 并求其密度 $r_\lambda(x, y)$, $x, y \in (-a, b)$, 的闭式表达式。
- (2) 对 $\theta \in \mathbb{R}$, 求 $U_\theta(x) = \mathbb{E}_x \left[\int_0^\tau e^{-\lambda t + \theta B_t} dt \right]$ 的闭式表达式。当 $\theta^2 = 2\lambda$ 时, 答案应给出有限的连续延拓值, 而不能保留为未定式。
- (3) 给定 $q_- > 0$ 和 $q_+ > 0$, 令 $V(x) = q_- \mathbb{1}_{\{x < 0\}} + q_+ \mathbb{1}_{\{x \geq 0\}}$ 。求 $\mathbb{E}_0 \left[\exp \left\{ - \int_0^\tau V(B_s) ds \right\} \right]$ 的闭式表达式, 并验证当 $q_- = q_+$ 时所得结果与常数折现率情形一致。

(提示: 利用双曲函数恒等式 $\frac{\text{csch}(\gamma a) + \text{csch}(\gamma b)}{\text{coth}(\gamma a) + \text{coth}(\gamma b)} = \frac{\cosh(\gamma(a-b)/2)}{\cosh(\gamma(a+b)/2)}$ 。)

第 4 题解答

解: 记 $\ell = -a$, $r = b$, $L = a + b$, $\kappa = \sqrt{2\lambda}$ 。

- (1) 对有界 Borel 函数 f , 定义 $u_f(x) = \mathbb{E}_x \left[\int_0^\tau e^{-\lambda t} f(B_t) dt \right]$ 。 u_f 是边值问题 $\lambda u - \frac{1}{2} u'' = f$ 于 $(-a, b)$, $u(-a) = u(b) = 0$ 的唯一有界解。

相应 Green 核满足 $\left(\lambda - \frac{1}{2} \frac{\partial^2}{\partial y^2} \right) r_\lambda(x, y) = \delta_x(y)$, 且 $r_\lambda(x, -a) = r_\lambda(x, b) = 0$ 。在 $y = x$ 处连续, 导数跳跃满足 $\partial_y r_\lambda(x, x+) - \partial_y r_\lambda(x, x-) = -2$ 。

解此分段常系数方程得到 $r_\lambda(x, y) = \frac{2 \sinh(\kappa(x \wedge y + a)) \sinh(\kappa(b - x \vee y))}{\kappa \sinh(\kappa(a + b))}$, 其中 $x, y \in (-a, b)$ 。

因而 $u_f(x) = \int_{-a}^b r_\lambda(x, y) f(y) dy$ 。取 $f = \mathbb{1}_A$, 可得 $R_\lambda(x, A) = \int_A r_\lambda(x, y) dy$ 。因此 $R_\lambda(x, \cdot) \ll \text{Lebesgue 测度}$, 且其密度就是上述 $r_\lambda(x, y)$ 。

- (2) 函数 $U_\theta(x) = \mathbb{E}_x \left[\int_0^\tau e^{-\lambda t + \theta B_t} dt \right]$ 满足 $\frac{1}{2} U_\theta''(x) - \lambda U_\theta(x) = -e^{\theta x}$, $U_\theta(-a) = U_\theta(b) = 0$ 。即 $U_\theta'' - \kappa^2 U_\theta = -2e^{\theta x}$ 。

$$\text{先假设 } \theta^2 \neq \kappa^2 = 2\lambda. \text{ 令 } A_\kappa(x) = \frac{\sinh(\kappa(b-x))}{\sinh(\kappa(a+b))}, B_\kappa(x) = \frac{\sinh(\kappa(x+a))}{\sinh(\kappa(a+b))}. \text{ 则 } U_\theta(x) = \frac{e^{\theta x} - e^{-a\theta} A_\kappa(x) - e^{b\theta} B_\kappa(x)}{\lambda - \theta^2/2}.$$

直接代入可验证其满足微分方程和两个边界条件。

当 $\theta = s\kappa$, $s \in \{-1, 1\}$, 上式分子和分母同时趋于零。对 θ 使用 L'Hospital 法则, 得到连续延拓

$$U_{s\kappa}(x) = \frac{be^{s\kappa b} B_\kappa(x) - xe^{s\kappa x} - ae^{-s\kappa a} A_\kappa(x)}{s\kappa}. \text{ 该表达式有限, 并且仍满足边界条件。}$$

- (3) 记 $\kappa_- = \sqrt{2q_-}$, $\kappa_+ = \sqrt{2q_+}$ 。对 $F(x) = \mathbb{E}_x[\exp\{-\int_0^\tau V(B_s) ds\}]$, 有分段边值问题 $\frac{1}{2}F'' - q_-F = 0$, $-a < x < 0$, $\frac{1}{2}F'' - q_+F = 0$, $0 < x < b$, 以及 $F(-a) = F(b) = 1$ 。因为 V 没有 δ -型奇点, F 和 F' 在 0 处连续。

令 $u = F(0)$ 。左半区间上的解为 $F_-(x) = \frac{\sinh(-\kappa_-x)}{\sinh(\kappa_-a)} + u \frac{\sinh(\kappa_-(x+a))}{\sinh(\kappa_-a)}$ 。因而 $F'_-(0) = \kappa_- [u \coth(\kappa_-a) - \operatorname{csch}(\kappa_-a)]$ 。

右半区间上的解为 $F_+(x) = u \frac{\sinh(\kappa_+(b-x))}{\sinh(\kappa_+b)} + \frac{\sinh(\kappa_+x)}{\sinh(\kappa_+b)}$ 。因而 $F'_+(0) = \kappa_+ [\operatorname{csch}(\kappa_+b) - u \coth(\kappa_+b)]$ 。

令 $F'_-(0) = F'_+(0)$, 得到 $u [\kappa_- \coth(\kappa_-a) + \kappa_+ \coth(\kappa_+b)] = \kappa_- \operatorname{csch}(\kappa_-a) + \kappa_+ \operatorname{csch}(\kappa_+b)$ 。因而

$$\mathbb{E}_0 \left[\exp \left\{ - \int_0^\tau V(B_s) ds \right\} \right] = \frac{\kappa_- \operatorname{csch}(\kappa_-a) + \kappa_+ \operatorname{csch}(\kappa_+b)}{\kappa_- \coth(\kappa_-a) + \kappa_+ \coth(\kappa_+b)}.$$

当 $q_- = q_+ = q$ 时, 令 $\gamma = \sqrt{2q}$ 。上式化为 $\frac{\operatorname{csch}(\gamma a) + \operatorname{csch}(\gamma b)}{\coth(\gamma a) + \coth(\gamma b)}$ 。利用双曲函数恒等式,

$$\frac{\operatorname{csch}(\gamma a) + \operatorname{csch}(\gamma b)}{\coth(\gamma a) + \coth(\gamma b)} = \frac{\cosh(\gamma(a-b)/2)}{\cosh(\gamma(a+b)/2)}.$$

这正是常数折现率 q 下的 $\mathbb{E}_0 e^{-q\tau}$ 。

□

Problem 5 (10 分)

设随机参数 $\Theta \sim \text{Beta}(a, b)$, $a > 0$, $b > 0$, 其密度为 $\pi(\theta) = \frac{\theta^{a-1}(1-\theta)^{b-1}}{B(a, b)} \mathbb{I}_{\{0 < \theta < 1\}}$ 。给定 Θ 后, 随机变量 $X_1, X_2, \dots$ 条件独立同分布, 且 $\mathbb{P}(X_k = 1 \mid \Theta) = \Theta$, $\mathbb{P}(X_k = 0 \mid \Theta) = 1 - \Theta$ 。记 $\mathcal{F}_n = \sigma(X_1, \dots, X_n)$, $S_n = \sum_{k=1}^n X_k$ 。

- (1) 求 $\Theta \mid \mathcal{F}_n$ 的条件分布, 以及 $\mathbb{P}(X_{n+1} = 1 \mid \mathcal{F}_n)$ 。求任意 $i \neq j$ 时的 $\operatorname{Cov}(X_i, X_j)$, $\operatorname{Corr}(X_i, X_j)$, 并判断序列 $\{X_k\}$ 是否相互独立、是否交换。
- (2) 定义 $M_n = \mathbb{E}(\Theta \mid \mathcal{F}_n)$ 。求 M_n 的显式表达式, 证明 $\{M_n, \mathcal{F}_n\}$ 为一致可积鞅, 并证明 $\frac{S_n}{n} \xrightarrow{\text{a.s.}} \Theta$, $M_n \xrightarrow{\text{a.s.}} \Theta$ 。进一步确定对哪些 $p \in [1, \infty)$ 有 $M_n \rightarrow \Theta$ in L^p 。

第 5 题解答

解:

- (1) 给定观测 $X_1, \dots, X_n$, 记 $S_n = \sum_{k=1}^n X_k$ 。似然核为 $L(\theta) \propto \theta^{S_n}(1-\theta)^{n-S_n}$ 。与先验相乘, $\pi(\theta \mid \mathcal{F}_n) \propto \theta^{a+S_n-1}(1-\theta)^{b+n-S_n-1}$ 。因而 $\Theta \mid \mathcal{F}_n \sim \text{Beta}(a+S_n, b+n-S_n)$ 。

由条件期望,

$$\mathbb{P}(X_{n+1} = 1 \mid \mathcal{F}_n) = \mathbb{E}[\mathbb{P}(X_{n+1} = 1 \mid \Theta, \mathcal{F}_n) \mid \mathcal{F}_n] = \mathbb{E}(\Theta \mid \mathcal{F}_n) = \frac{a + S_n}{a + b + n}.$$

对 $i \neq j$, 给定 Θ 后 X_i, X_j 独立, 因此 $\text{Cov}(X_i, X_j) = \text{Cov}(\mathbb{E}(X_i | \Theta), \mathbb{E}(X_j | \Theta)) = \text{Var}(\Theta)$ 。Beta 分布

的方差为 $\text{Var}(\Theta) = \frac{ab}{(a+b)^2(a+b+1)}$ 。所以 $\text{Cov}(X_i, X_j) = \frac{ab}{(a+b)^2(a+b+1)}$ 。

边缘上, $\mathbb{P}(X_i = 1) = \mathbb{E}\Theta = \frac{a}{a+b}$ 。因此 $\text{Var}(X_i) = \frac{ab}{(a+b)^2}$ 。从而 $\text{Corr}(X_i, X_j) = \frac{1}{a+b+1}$ 。

由于协方差严格为正, $\{X_k\}$ 不相互独立。另一方面, 对任意有限置换 π , 给定 Θ 后 $(X_1, \dots, X_n)$ 的条件联合分布在置换下不变; 对 Θ 积分后仍然不变。因而 $\{X_k\}$ 是交换序列。

(2) 由第 (a) 问, $M_n = \mathbb{E}(\Theta | \mathcal{F}_n) = \frac{a + S_n}{a + b + n}$ 。由 tower property, $\mathbb{E}(M_{n+1} | \mathcal{F}_n) = \mathbb{E}[\mathbb{E}(\Theta | \mathcal{F}_{n+1}) | \mathcal{F}_n] = \mathbb{E}(\Theta | \mathcal{F}_n) = M_n$ 。因此 $\{M_n, \mathcal{F}_n\}$ 是鞅。

又因为 $0 \leq M_n \leq 1$, 所以它是有界鞅, 进而一致可积。

给定 $\Theta = \theta$ 后, X_i 为 iid Bernoulli(θ)。由条件强大数律, $\mathbb{P}(\frac{S_n}{n} \rightarrow \Theta | \Theta) = 1$ a.s. 再取期望可得

$$\frac{S_n}{n} \xrightarrow{\text{a.s.}} \Theta.$$

同时 $M_n - \frac{S_n}{n} = \frac{a+S_n}{a+b+n} - \frac{S_n}{n} = \frac{na-(a+b)S_n}{n(a+b+n)}$ 。因为 $0 \leq S_n \leq n$, $|M_n - \frac{S_n}{n}| \leq \frac{na+(a+b)n}{n(a+b+n)} \rightarrow 0$ 。故

$$M_n \xrightarrow{\text{a.s.}} \Theta.$$

对任意有限 $p \geq 1$, $|M_n - \Theta|^p \leq 1$ 。又 $M_n \rightarrow \Theta$ a.s., 由支配收敛定理, $\mathbb{E}|M_n - \Theta|^p \rightarrow 0$, $1 \leq p < \infty$ 。

因此 $M_n \rightarrow \Theta$ in L^p 对所有 $1 \leq p < \infty$ 。

□

Problem 6 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathbf{N}(\mu, \sigma^2)$, $n = 2r+1 \geq 3$, 其中 $\mu \in \mathbb{R}, \sigma > 0$ 均未知。记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, $M_n = X_{(r+1)}$ 。另设 $Y_1, \dots, Y_m \stackrel{\text{i.i.d.}}{\sim} \mathbf{N}(\nu, \tau^2)$, $m \geq 2$, 与 X -样本独立, 并定义样本方差 S_Y^2 与上式相同。

(1) 求 $\bar{X}$, $\frac{(n-1)S_X^2}{\sigma^2}$, $\frac{(m-1)S_Y^2}{\tau^2}$ 的精确分布及其相互独立关系。进一步求 $\frac{\sqrt{n}(\bar{X}-\mu)}{S_X}$, $\frac{S_X^2/\sigma^2}{S_Y^2/\tau^2}$ 的精确分布。

(2) 当 $n \rightarrow \infty$ 且始终取奇数时, 求联合极限分布 $\sqrt{n} \begin{pmatrix} \bar{X} - \mu \\ M_n - \mu \end{pmatrix}$, 并明确给出极限协方差矩阵的每一个元素。

(3) 求 $\frac{\sqrt{n}(M_n - \bar{X})}{S_X}$ 的极限分布。计算样本中位数相对于样本均值的渐近相对效率, 并说明该效率的比较基于何种损失或评价标准。

第 6 题解答

解:

(1) 正态样本的精确分布给出 $\bar{X} \sim \mathbf{N}\left(\mu, \frac{\sigma^2}{n}\right)$, $\frac{(n-1)S_X^2}{\sigma^2} \sim \chi_{n-1}^2$, 且 $\bar{X} \perp S_X^2$ 。

同理, $\frac{(m-1)S_Y^2}{\tau^2} \sim \chi_{m-1}^2$ 。由于两个样本相互独立, $\bar{X}$, $\frac{(n-1)S_X^2}{\sigma^2}$, $\frac{(m-1)S_Y^2}{\tau^2}$ 相互独立。

因而 $\frac{\sqrt{n}(\bar{X} - \mu)}{S_X} \sim t_{n-1}$ 。

另外, $\frac{S_X^2/\sigma^2}{S_Y^2/\tau^2} = \frac{[(n-1)S_X^2/\sigma^2]/(n-1)}{[(m-1)S_Y^2/\tau^2]/(m-1)}$, 故 $\frac{S_X^2/\sigma^2}{S_Y^2/\tau^2} \sim F_{n-1, m-1}$ 。

(2) 记总体分布函数为 $F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$ 。总体中位数为 μ , 且 $f(\mu) = \frac{1}{\sigma\sqrt{2\pi}}$ 。

样本中位数具有 Bahadur 表示 $\sqrt{n}(M_n - \mu) = \frac{1}{f(\mu)} \frac{1}{\sqrt{n}} \sum_{i=1}^n \left[\frac{1}{2} - \mathbb{1}_{\{X_i \leq \mu\}}\right] + o_{\mathbb{P}}$ 。同时 $\sqrt{n}(\bar{X} - \mu) = \frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu)$ 。

因此只需对二维随机向量 $(X_i - \mu, \frac{1}{2} - \mathbb{1}_{\{X_i \leq \mu\}})$ 使用多元中心极限定理。

首先, $\text{Var}(X_i - \mu) = \sigma^2$ 。其次, $\text{Var}\left(\frac{1}{2} - \mathbb{1}_{\{X_i \leq \mu\}}\right) = \frac{1}{4}$ 。又因为正态分布关于 μ 对称,

$$\text{Cov}\left(X_i - \mu, \frac{1}{2} - \mathbb{1}_{\{X_i \leq \mu\}}\right) = \frac{1}{2}\mathbb{E}|X_i - \mu| = \frac{\sigma}{2}\sqrt{\frac{2}{\pi}} = \frac{\sigma}{\sqrt{2\pi}}.$$

因此 $\text{Var}(\sqrt{n}(M_n - \mu)) \rightarrow \frac{1/4}{f(\mu)^2} = \frac{\pi\sigma^2}{2}$, 且极限协方差为 $\frac{\sigma/\sqrt{2\pi}}{1/(\sigma\sqrt{2\pi})} = \sigma^2$ 。

$$\text{故 } \sqrt{n} \begin{pmatrix} \bar{X} - \mu \\ M_n - \mu \end{pmatrix} \xrightarrow{d} N_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \sigma^2 \begin{pmatrix} 1 & 1 \\ 1 & \pi/2 \end{pmatrix} \right).$$

(3) 由第 (b) 问, $\sqrt{n}(M_n - \bar{X}) \xrightarrow{d} N(0, \sigma^2[\frac{\pi}{2} + 1 - 2])$ 。即 $\sqrt{n}(M_n - \bar{X}) \xrightarrow{d} N(0, \sigma^2(\frac{\pi}{2} - 1))$ 。又 $S_X \xrightarrow{P} \sigma$ 。

由 Slutsky 定理, $\frac{\sqrt{n}(M_n - \bar{X})}{S_X} \xrightarrow{d} N\left(0, \frac{\pi}{2} - 1\right)$ 。

在估计 μ 的平方损失下, 两个估计量均渐近无偏, 因而其一阶渐近风险由渐近方差决定。样本均值和样本中

位数的渐近方差分别为 $\frac{\sigma^2}{n}$, $\frac{\pi\sigma^2}{2n}$ 。因此样本中位数相对于样本均值的渐近相对效率为 $\text{ARE}(M_n, \bar{X}) = \frac{\sigma^2}{\pi\sigma^2/2} = \frac{2}{\pi}$ 。

□

Problem 7 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x|\theta) = \theta x^{\theta-1} \mathbb{1}_{\{0 < x < 1\}}$, $\theta > 0$, $n \geq 2$ 。定义 $Y_i = -\log X_i$, $T = \sum_{i=1}^n Y_i$, $A = \frac{Y_1}{T}$ 。

(1) 推导 (T, A) 的联合密度及完整支撑集, 并求二者的边缘分布。判断 T 与 A 是否独立。证明 T 是 θ 的极小充分且完全统计量, 并证明 A 是辅助统计量。

(2) 固定 $c \in (0, 1)$ 。分别求下列两个参数函数的 UMVUE: θ , $\mathbb{P}_\theta(X_1 \leq c) = c^\theta$ 。两个答案均须写成观测样本的显式函数, 并验证其无偏性。

(3) 对给定 $0 < \alpha < 1$, 构造 θ 的一个等尾、精确 $1 - \alpha$ 置信区间。区间端点应使用 $\chi_{2n, \alpha/2}^2$, $\chi_{2n, 1-\alpha/2}^2$ 显式表示, 并严格说明覆盖概率。

第 7 题解答

解: 令 $Y_i = -\log X_i$ 。对 $y > 0$, $\mathbb{P}(Y_i > y) = \mathbb{P}(X_i < e^{-y}) = e^{-\theta y}$, 故 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\theta)$ 。

(1) 令 $W = \sum_{i=2}^n Y_i$ 。则 $Y_1 \sim \text{Gamma}(1, \theta)$, $W \sim \text{Gamma}(n-1, \theta)$, $Y_1 \perp W$ 。变换 $T = Y_1 + W$, $A = \frac{Y_1}{T}$ 的逆变换为 $Y_1 = AT$, $W = (1-A)T$ 。Jacobian 的绝对值为 $\left|\frac{\partial(Y_1, W)}{\partial(T, A)}\right| = T$ 。因此当 $t > 0$, $0 < a < 1$ 时,

$$f_{T,A}(t, a) = \theta e^{-\theta at} \frac{\theta^{n-1}}{\Gamma(n-1)} [(1-a)t]^{n-2} e^{-\theta(1-a)t} = \frac{\theta^n}{\Gamma(n-1)} t^{n-1} e^{-\theta t} (1-a)^{n-2}.$$

$$\text{故 } f_{T,A}(t, a) = \frac{\theta^n}{\Gamma(n-1)} t^{n-1} e^{-\theta t} (1-a)^{n-2} \mathbb{1}_{\{t>0, 0<a<1\}}.$$

将其因子分解为 $\frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t} \cdot (n-1)(1-a)^{n-2}$ 。因而 $T \sim \text{Gamma}(n, \theta)$, $A \sim \text{Beta}(1, n-1)$, 且

$T \perp\!\!\!\perp A$.

原样本的联合密度可写成 $\prod_{i=1}^n \theta x_i^{\theta-1} = \theta^n \exp\{-\theta T\} \prod_{i=1}^n x_i^{-1} \perp\!\!\!\perp_{\{0 < x_i < 1\}}$. 由因子分解定理, T 充分. 对两个样本点 x, y , 似然比中与 θ 有关的部分为 $\exp\{-\theta[T(x) - T(y)]\}$. 该比值与 θ 无关, 当且仅当 $T(x) = T(y)$. 故 T 是极小充分统计量.

若可测函数 g 满足 $\mathbb{E}_\theta g(T) = 0 \quad \forall \theta > 0$, 则 $\int_0^\infty g(t) t^{n-1} e^{-\theta t} dt = 0 \quad \forall \theta > 0$. 由 Laplace 变换的唯一性, $g(t) t^{n-1} = 0$ 几乎处处, 即 $g(T) = 0$ a.s. 所以 T 完全.

A 的分布 $\text{Beta}(1, n-1)$ 不含参数 θ , 故 A 是辅助统计量. 完全充分统计量 T 与辅助统计量 A 的独立性也可由 Basu 定理得到.

- (2) 因为 $T \sim \text{Gamma}(n, \theta)$, 对 $n \geq 2$, $\mathbb{E}_\theta(\frac{1}{T}) = \frac{\theta}{n-1}$. 因此 $\hat{\theta}_{\text{UMVUE}} = \frac{n-1}{T} = \frac{n-1}{-\sum_{i=1}^n \log X_i}$. 其无偏性由 $\mathbb{E}_\theta \frac{n-1}{T} = \theta$ 得到; 又因其为完全充分统计量 T 的函数, 由 Lehmann-Scheffé 定理, 它是 θ 的 UMVUE. 下面估计 $c^\theta = \mathbb{P}_\theta(X_1 \leq c)$. 令 $d = -\log c > 0$. 则 $X_1 \leq c \iff Y_1 \geq d$. 指示变量 $U = \perp\!\!\!\perp_{\{Y_1 \geq d\}}$ 是 c^θ 的无偏估计量.

给定 $T = t$ 后, $A = \frac{Y_1}{T} \sim \text{Beta}(1, n-1)$. 因此

$$\mathbb{E}(U | T = t) = \mathbb{P}(Y_1 \geq d | T = t) = \begin{cases} \mathbb{P}(A \geq d/t), & t \geq d, \\ 0, & t < d. \end{cases}$$

对 $A \sim \text{Beta}(1, n-1)$, $\mathbb{P}(A \geq u) = (1-u)^{n-1}$, $0 \leq u \leq 1$. 因而

$$\hat{c}^\theta_{\text{UMVUE}} = \left(1 - \frac{d}{T}\right)^{n-1} \perp\!\!\!\perp_{\{T \geq d\}}, \quad d = -\log c.$$

等价地, $\hat{c}^\theta_{\text{UMVUE}} = \left(1 + \frac{\log c}{T}\right)^{n-1} \perp\!\!\!\perp_{\{T \geq -\log c\}}$. 由 tower property, $\mathbb{E}_\theta \mathbb{E}(U | T) = \mathbb{E}_\theta U = c^\theta$, 故该估计量无偏; 完全充分性保证其为唯一 UMVUE.

- (3) 因为 $T \sim \text{Gamma}(n, \theta)$, 有精确 pivot $2\theta T \sim \chi_{2n}^2$. 因而 $\mathbb{P}_\theta(\chi_{2n, \alpha/2}^2 \leq 2\theta T \leq \chi_{2n, 1-\alpha/2}^2) = 1 - \alpha$. 由于 $T > 0$, 反解得到 $\left[\frac{\chi_{2n, \alpha/2}^2}{2T}, \frac{\chi_{2n, 1-\alpha/2}^2}{2T}\right]$ 是 θ 的等尾、精确 $1 - \alpha$ 置信区间. □

Problem 8 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{NegBin}(r, p)$, $r \in \mathbb{N}$ 已知, $0 < p < 1$, 其中 X_i 表示第 r 次成功前出现的失败次数, 即 $\mathbb{P}_p(X_i = x) = \binom{r+x-1}{x} p^r (1-p)^x$, $x = 0, 1, 2, \dots$. 记 $S = \sum_{i=1}^n X_i$.

- 对给定 $p_0 \in (0, 1)$ 和 $0 < \alpha < 1$, 构造并严格证明一个 size 为 α 的一致最强检验, 用于检验 $H_0: p \leq p_0$ 对 $H_1: p > p_0$. 拒绝规则必须写成 S 的显式随机化阈值形式; 当非随机化阈值不能使 size 恰等于 α 时, 必须给出随机化概率.
- 求第 (a) 问检验的功效函数. 明确写出在 $p \leq p_0$ 时的第一类错误概率、在 $p > p_0$ 时的第二类错误概率, 并证明功效函数关于 p 的单调性.
- 考虑 $H_0: p = p_0$ 对 $H_1: p \neq p_0$. 判断是否存在 size 为 α 的 UMP 检验, 并给出严格理由. 同时推导该问题的广义似然比统计量; 当 $S = 0$ 时, 应明确说明所取的上确界及相应约定.

第 8 题解答

解: 令 $R = nr$. 由于负二项随机变量具有可加性, $S = \sum_{i=1}^n X_i \sim \text{NegBin}(R, p)$, 即 $\mathbb{P}_p(S = s) = \binom{R+s-1}{s} p^R (1-p)^s$, $s = 0, 1, \dots$

- (1) 对 $p_1 > p_0$, 似然比为 $\frac{\mathbb{P}_{p_1}(S=s)}{\mathbb{P}_{p_0}(S=s)} = \left(\frac{p_1}{p_0}\right)^R \left(\frac{1-p_1}{1-p_0}\right)^s$. 因为 $\frac{1-p_1}{1-p_0} < 1$, 该似然比关于 s 严格递减. 因此较小的 S 支持较大的 p .

令 $F_0(s) = \mathbb{P}_{p_0}(S \leq s)$, $F_0(-1) = 0$. 选择唯一的非负整数 c , 使 $F_0(c-1) \leq \alpha \leq F_0(c)$. 定义 $\gamma = \frac{\alpha - F_0(c-1)}{\mathbb{P}_{p_0}(S=c)}$. 则 $0 \leq \gamma \leq 1$.

定义随机化检验函数 $\varphi(S) = \mathbb{I}_{\{S < c\}} + \gamma \mathbb{I}_{\{S=c\}}$. 在 $p = p_0$ 时, $\mathbb{E}_{p_0} \varphi = F_0(c-1) + \gamma \mathbb{P}_{p_0}(S=c) = \alpha$. 由于分布族在 S 中具有单调似然比, 并且参数 p 增大时 S 随机变小, 检验的功效关于 p 单调递增. 因而在复合原假设 $p \leq p_0$ 中, 最大拒绝概率在边界 $p = p_0$ 处取得. 故该检验的 size 为 α .

由 Karlin-Rubin 定理, φ 是检验 $H_0: p \leq p_0$ 对 $H_1: p > p_0$ 的 size α UMP 检验.

- (2) 功效函数为

$$\beta_\varphi(p) = \mathbb{E}_p \varphi(S) = \sum_{s=0}^{c-1} \binom{R+s-1}{s} p^R (1-p)^s + \gamma \binom{R+c-1}{c} p^R (1-p)^c.$$

当 $p \leq p_0$ 时, 第一类错误概率为 $\beta_\varphi(p)$, 且 $\sup_{p \leq p_0} \beta_\varphi(p) = \beta_\varphi(p_0) = \alpha$.

当 $p > p_0$ 时, 第二类错误概率为 $1 - \beta_\varphi(p)$.

为严格说明单调性, 可将 $S_p = G_1(p) + \dots + G_R(p)$, 其中 $G_j(p)$ 为一次成功前的失败数, 即 $\mathbb{P}(G_j(p) \geq k) = (1-p)^k$. 用同一组独立均匀随机变量作逆分布耦合. 若 $p_2 > p_1$, 则可构造使 $G_j(p_2) \leq G_j(p_1)$ a.s., 从而 $S_{p_2} \leq S_{p_1}$ a.s. 而检验函数 $\varphi(s)$ 关于 s 非增, 故 $\beta_\varphi(p_2) = \mathbb{E} \varphi(S_{p_2}) \geq \mathbb{E} \varphi(S_{p_1}) = \beta_\varphi(p_1)$. 所以功效函数关于 p 非减.

- (3) 考虑简单备择 $p_1 > p_0$. 由 Neyman-Pearson 引理及严格单调似然比, 最强检验必须在 S 的较小值处拒绝.

考虑另一简单备择 $p_2 < p_0$. 此时 $\frac{\mathbb{P}_{p_2}(S=s)}{\mathbb{P}_{p_0}(S=s)}$ 关于 s 严格递增, 因此最强检验必须在 S 的较大值处拒绝.

由于 $0 < \alpha < 1$, 且 S 在每个非负整数点的原假设概率均严格为正, 一个非平凡检验不可能同时既是严格的下尾检验又是严格的上尾检验. 因此 $H_0: p = p_0$ 对 $H_1: p \neq p_0$ 不存在 size α 的 UMP 检验.

对观测 $S = s$, 忽略与 p 无关的因子, 似然为 $L(p; s) \propto p^R (1-p)^s$. 当 $s > 0$ 时, $\hat{p} = \frac{R}{R+s}$. 当 $s = 0$ 时, $L(p; 0) \propto p^R$ 在 $0 < p < 1$ 上没有最大值, 但 $\sup_{0 < p < 1} L(p; 0) = \lim_{p \uparrow 1} L(p; 0)$. 因此可形式上令 $\hat{p} = 1$ 表示上确界点.

广义似然比为 $\Lambda(s) = \frac{L(p_0; s)}{\sup_{0 < p < 1} L(p; s)}$. 当 $s > 0$ 时, $\Lambda(s) = \frac{p_0^R (1-p_0)^s}{\left(\frac{R}{R+s}\right)^R \left(\frac{s}{R+s}\right)^s}$. 当 $s = 0$ 时, $\Lambda(0) = p_0^R$.

若采用约定 $0^0 = 1$, 上述统一公式在 $s = 0$ 时仍成立. GLR 检验在 $\Lambda(S)$ 较小时拒绝原假设.

□

Problem 9 (10 分)

给定 $\lambda > 0$ 后, 设 $X_i | \lambda \sim \text{Poisson}(w_i \lambda)$, $i = 1, \dots, n$, 且在给定 λ 后相互独立, 其中 $w_i > 0$ 为已知暴露量. 先验分布为 $\lambda \sim \text{Gamma}(a, b)$, $a > 1$, $b > 0$. 记 $S = \sum_{i=1}^n X_i$, $W = \sum_{i=1}^n w_i$.

- (1) 先求给定总计数 S 后随机向量 $(X_1, \dots, X_n) | S$ 的条件概率质量函数, 并判断该条件分布是否依赖 λ 。随后求 $\lambda | X_1, \dots, X_n$ 的后验分布、后验均值和后验众数。说明后验众数位于参数空间内部所需的条件, 并比较后验均值与后验众数。
- (2) 给定 λ 后, 令未来计数 $Y | \lambda \sim \text{Poisson}(w_0\lambda)$, $w_0 > 0$, 且 Y 与原样本条件独立。求 $Y | X_1, \dots, X_n$ 的后验预测概率质量函数, 将其识别为本卷约定下的负二项分布, 并求其后验预测均值和方差。
- (3) 固定 $c > 0$ 。在平方损失下求 $\tau(\lambda) = e^{-c\lambda}$ 的 Bayes 估计量。再在损失 $L(\lambda, d) = \frac{(d-\lambda)^2}{\lambda}$ 下求 λ 的 Bayes 估计量, 并与第 (a) 问的后验众数比较。

第 9 题解答

解: 记 $S = \sum_{i=1}^n X_i$, $W = \sum_{i=1}^n w_i$ 。

- (1) 给定 λ 后, $S | \lambda \sim \text{Poisson}(W\lambda)$ 。对满足 $x_i \in \mathbb{N} \cup \{0\}$, $\sum_{i=1}^n x_i = s$ 的向量,

$$\mathbb{P}(X_1 = x_1, \dots, X_n = x_n | S = s, \lambda) = \frac{\prod_{i=1}^n e^{-w_i\lambda} (w_i\lambda)^{x_i} / x_i!}{e^{-W\lambda} (W\lambda)^s / s!} = \frac{s!}{\prod_{i=1}^n x_i!} \prod_{i=1}^n \left(\frac{w_i}{W}\right)^{x_i}.$$

若 $\sum_i x_i \neq s$, 条件概率为零。该条件分布不依赖 λ 。

原样本似然核为 $L(\lambda) \propto \lambda^S e^{-W\lambda}$ 。与先验 $\pi(\lambda) \propto \lambda^{a-1} e^{-b\lambda}$ 相乘, 得到 $\lambda | X_1, \dots, X_n \sim \text{Gamma}(a + S, b + W)$ 。

令 $A = a + S$, $B = b + W$ 。后验均值为 $\mathbb{E}(\lambda | X) = \frac{A}{B} = \frac{a + S}{b + W}$ 。当 $A > 1$ 时, 后验众数为

$$\text{mode}(\lambda | X) = \frac{A - 1}{B} = \frac{a + S - 1}{b + W}.$$

后验众数位于参数空间内部的充要条件是 $A > 1$ 。题设 $a > 1$, 故该条件总是成立。

两者之差为 $\mathbb{E}(\lambda | X) - \text{mode}(\lambda | X) = \frac{1}{b + W}$ 。

- (2) 对 $y = 0, 1, \dots$,

$$\mathbb{P}(Y = y | X) = \int_0^\infty \frac{e^{-w_0\lambda} (w_0\lambda)^y}{y!} \frac{B^A}{\Gamma(A)} \lambda^{A-1} e^{-B\lambda} d\lambda = \frac{\Gamma(A+y)}{\Gamma(A)y!} \frac{B^A w_0^y}{(B + w_0)^{A+y}}.$$

即 $\mathbb{P}(Y = y | X) = \frac{\Gamma(A+y)}{\Gamma(A)y!} \left(\frac{B}{B + w_0}\right)^A \left(\frac{w_0}{B + w_0}\right)^y$ 。因而 $Y | X \sim \text{NegBin}\left(A, \frac{B}{B + w_0}\right)$, 这里采用 $\mathbb{P}(Y = y) = \frac{\Gamma(A+y)}{\Gamma(A)y!} p^A (1-p)^y$ 的参数化。

其后验预测均值为 $\mathbb{E}(Y | X) = \frac{Aw_0}{B}$ 。后验预测方差为 $\text{Var}(Y | X) = \frac{Aw_0(B + w_0)}{B^2}$ 。也可由全方差公式验证: $\text{Var}(Y | X) = \mathbb{E}(w_0\lambda | X) + \text{Var}(w_0\lambda | X)$ 。

- (3) 在平方损失下, $\tau(\lambda) = e^{-c\lambda}$ 的 Bayes 估计量是后验均值: $\hat{\tau}_B = \mathbb{E}(e^{-c\lambda} | X) = \left(\frac{B}{B + c}\right)^A$ 。因此

$$\hat{\tau}_B = \left(\frac{b + W}{b + W + c}\right)^{a+S}.$$

对损失 $L(\lambda, d) = \frac{(d-\lambda)^2}{\lambda}$, 后验风险为

$$\rho(d | X) = \mathbb{E} \left(\frac{d^2}{\lambda} - 2d + \lambda \middle| X \right) = d^2 \mathbb{E}(\lambda^{-1} | X) - 2d + \mathbb{E}(\lambda | X).$$

这是关于 d 的严格凸二次函数, 最小点满足 $d_B = \frac{1}{\mathbb{E}(\lambda^{-1} | X)}$ 。因为 $A > 1$, $\mathbb{E}(\lambda^{-1} | X) = \frac{B}{A-1}$ 。所以

$$d_B = \frac{A-1}{B} = \frac{a+S-1}{b+W}. \quad \text{这恰好等于后验众数: } d_B = \text{mode}(\lambda | X).$$

□

Problem 10 (15 分)

设 $a > 0$ 与 $\sigma > 0$ 为已知常数, 并设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathbf{N}(\theta, \sigma^2)$, $\theta \in \Theta := \{-a, a\}$, $n \geq 1$ 。行动空间为 $\mathcal{A} = \mathbb{R}$, 损失函数为平方损失 $L(\theta, d) = (d - \theta)^2$ 。对任意估计量 (决策规则) $\delta = \delta(X_1, \dots, X_n)$, 定义其风险函数为 $R(\theta, \delta) = \mathbb{E}_\theta[(\delta(X_1, \dots, X_n) - \theta)^2]$ 。记 $T = \sum_{i=1}^n X_i$ 。

- (1) 对 $p \in (0, 1)$, 考虑先验分布 $\pi_p(\theta) = p \mathbb{I}_{\{\theta=a\}} + (1-p) \mathbb{I}_{\{\theta=-a\}}$ 。求该先验下唯一的 Bayes 估计量 δ_p 及其 Bayes 风险 $r(p) = (1-p)R(-a, \delta_p) + pR(a, \delta_p)$ 。确定 $r(p)$ 在 $p \in [0, 1]$ 上的全部最大点。
- (2) 求该统计决策问题的 minimax risk, 并刻画全部 minimax 估计量; 在刻画时, 可以忽略在 P_{-a} 和 P_a 下均为零概率的样本集合上的差异。判断 minimax 估计量是否 admissible, 并严格证明结论。
- (3) 求 θ 的最大似然估计量 δ_{MLE} , 计算其风险函数, 并判断它是否为 minimax 估计量以及是否 admissible。若它不是 admissible 的, 给出一个严格支配它的估计量, 并证明严格支配关系。

第 10 题解答

解: 记样本向量为 $\mathbf{X} = (X_1, \dots, X_n)$, 并分别以 $f_+(\mathbf{x})$ 和 $f_-(\mathbf{x})$ 表示参数为 a 和 $-a$ 时的联合密度。

对任意样本点 $\mathbf{x} = (x_1, \dots, x_n)$, 记 $T(\mathbf{x}) = \sum_{i=1}^n x_i$ 。

- (1) 首先计算两个参数点的似然比。由正态联合密度,

$$\log \frac{f_+(\mathbf{x})}{f_-(\mathbf{x})} = -\frac{1}{2\sigma^2} \sum_{i=1}^n [(x_i - a)^2 - (x_i + a)^2] = -\frac{1}{2\sigma^2} \sum_{i=1}^n (-4ax_i) = \frac{2a}{\sigma^2} T(\mathbf{x}).$$

因此 $\frac{f_+(\mathbf{x})}{f_-(\mathbf{x})} = \exp \left\{ \frac{2a}{\sigma^2} T(\mathbf{x}) \right\}.$

由 Bayes 公式,

$$q_p(\mathbf{x}) := \mathbb{P}_{\pi_p}(\theta = a | \mathbf{X} = \mathbf{x}) = \frac{pf_+(\mathbf{x})}{pf_+(\mathbf{x}) + (1-p)f_-(\mathbf{x})} = \frac{p \exp\{2aT(\mathbf{x})/\sigma^2\}}{(1-p) + p \exp\{2aT(\mathbf{x})/\sigma^2\}}.$$

相应地, $\mathbb{P}_{\pi_p}(\theta = -a | \mathbf{X} = \mathbf{x}) = 1 - q_p(\mathbf{x})$ 。

对给定样本 $\mathbf{x}$, 行动 $d \in \mathbb{R}$ 的后验风险为 $\rho_p(d | \mathbf{x}) = q_p(\mathbf{x})(d - a)^2 + [1 - q_p(\mathbf{x})](d + a)^2$ 。由平方损失的条件方差分解, $\rho_p(d | \mathbf{x}) = \text{Var}_{\pi_p}(\theta | \mathbf{X} = \mathbf{x}) + [d - \mathbb{E}_{\pi_p}(\theta | \mathbf{X} = \mathbf{x})]^2$ 。因而后验风险关于 d 严格凸, 唯一最小点为后验均值: $\delta_p(\mathbf{x}) = \mathbb{E}_{\pi_p}(\theta | \mathbf{X} = \mathbf{x}) = aq_p(\mathbf{x}) - a[1 - q_p(\mathbf{x})] = a[2q_p(\mathbf{x}) - 1]$ 。代入 q_p 得

$$\delta_p(\mathbf{x}) = a \frac{p \exp\{2aT(\mathbf{x})/\sigma^2\} - (1-p)}{p \exp\{2aT(\mathbf{x})/\sigma^2\} + (1-p)}. \quad \text{等价地, } \delta_p(\mathbf{x}) = a \tanh \left(\frac{a}{\sigma^2} T(\mathbf{x}) + \frac{1}{2} \log \frac{p}{1-p} \right).$$

下面计算 Bayes 风险。记先验预测密度为 $m_p(\mathbf{x}) = pf_+(\mathbf{x}) + (1-p)f_-(\mathbf{x})$ 。因为平方损失下最小后验风险等于后验方差, $r(p) = \int_{\mathbb{R}^n} \text{Var}_{\pi_p}(\theta | \mathbf{X} = \mathbf{x}) m_p(\mathbf{x}) d\mathbf{x}$ 。两点分布的后验方差为

$$\text{Var}_{\pi_p}(\theta | \mathbf{x}) = 4a^2 q_p(\mathbf{x}) [1 - q_p(\mathbf{x})] = 4a^2 \frac{p(1-p)f_+(\mathbf{x})f_-(\mathbf{x})}{m_p(\mathbf{x})^2}$$

因此
$$r(p) = 4a^2 p(1-p) \int_{\mathbb{R}^n} \frac{f_+(\mathbf{x})f_-(\mathbf{x})}{pf_+(\mathbf{x}) + (1-p)f_-(\mathbf{x})} d\mathbf{x}.$$

下面确定 $r(p)$ 的最大点。固定 $\mathbf{x}$, 令 $A = f_+(\mathbf{x}) > 0$, $B = f_-(\mathbf{x}) > 0$, 并定义 $h_{\mathbf{x}}(p) = \frac{p(1-p)AB}{pA + (1-p)B}$ 。

直接求导得到
$$h_{\mathbf{x}}''(p) = -\frac{2A^2B^2}{[pA + (1-p)B]^3} < 0, \quad 0 < p < 1.$$
 所以对每个 $\mathbf{x}$, $h_{\mathbf{x}}(p)$ 关于 p 严格凹。由于 $r(p) = 4a^2 \int_{\mathbb{R}^n} h_{\mathbf{x}}(p) d\mathbf{x}$, $r(p)$ 在 $(0, 1)$ 上也严格凹。

另一方面, 由 $f_+(-\mathbf{x}) = f_-(\mathbf{x})$, $f_-(-\mathbf{x}) = f_+(\mathbf{x})$, 在积分中作变换 $\mathbf{x} \mapsto -\mathbf{x}$, 可得 $r(p) = r(1-p)$ 。

若 $p \neq 1/2$, 由严格凹性, $r\left(\frac{1}{2}\right) = r\left(\frac{p + (1-p)}{2}\right) > \frac{1}{2}r(p) + \frac{1}{2}r(1-p) = r(p)$ 。此外, 退化先验下

$r(0) = r(1) = 0$ 。因而 $r(p)$ 在 $[0, 1]$ 上的唯一最大点为 $p = \frac{1}{2}$ 。

(2) 当 $p = \frac{1}{2}$ 时, Bayes 估计量化为
$$\delta^*(\mathbf{X}) = a \tanh\left(\frac{a}{\sigma^2} T\right).$$

先证明其在两个参数点处具有相同风险。注意 $\delta^*(-\mathbf{x}) = -\delta^*(\mathbf{x})$ 。在 $\theta = -a$ 下, 随机向量 $-\mathbf{X}$ 与参数为 a 时的 $\mathbf{X}$ 同分布。因此 $R(-a, \delta^*) = \mathbb{E}_{-a}[(\delta^*(\mathbf{X}) + a)^2] = \mathbb{E}_a[(\delta^*(-\mathbf{X}) + a)^2] = \mathbb{E}_a[(-\delta^*(\mathbf{X}) + a)^2] = R(a, \delta^*)$ 。

记这一共同风险为 V 。因为 δ^* 是等概率先验下的 Bayes 估计量, $r\left(\frac{1}{2}\right) = \frac{1}{2}R(-a, \delta^*) + \frac{1}{2}R(a, \delta^*) = V$ 。

对任意估计量 δ , 有 $\sup_{\theta \in \{-a, a\}} R(\theta, \delta) \geq \frac{1}{2}R(-a, \delta) + \frac{1}{2}R(a, \delta) \geq \inf_{\tilde{\delta}} \left[\frac{1}{2}R(-a, \tilde{\delta}) + \frac{1}{2}R(a, \tilde{\delta}) \right] = r\left(\frac{1}{2}\right) = V$ 。

而 $\sup_{\theta \in \{-a, a\}} R(\theta, \delta^*) = V$ 。因而
$$\delta^*(\mathbf{X}) = a \tanh\left(\frac{a}{\sigma^2} \sum_{i=1}^n X_i\right)$$
 是 minimax 估计量, 且 minimax risk

为
$$V = r\left(\frac{1}{2}\right).$$

下面给出 V 的一维积分表达式。在等概率先验的边际分布下, $T \sim \frac{1}{2}\mathbf{N}(na, n\sigma^2) + \frac{1}{2}\mathbf{N}(-na, n\sigma^2)$ 。其密度为
$$g(t) = \frac{e^{-(t-na)^2/(2n\sigma^2)} + e^{-(t+na)^2/(2n\sigma^2)}}{2\sqrt{2\pi n\sigma^2}}.$$
 等概率先验下的后验方差为 $\text{Var}(\theta | T) = a^2 - [\delta^*(T)]^2 = a^2 \text{sech}^2\left(\frac{aT}{\sigma^2}\right)$ 。

因此
$$V = a^2 \int_{-\infty}^{\infty} \text{sech}^2\left(\frac{at}{\sigma^2}\right) g(t) dt.$$
 化简两个正态密度之和, 也可写成
$$V = \frac{a^2 e^{-na^2/(2\sigma^2)}}{\sqrt{2\pi n\sigma^2}} \int_{-\infty}^{\infty} \frac{e^{-t^2/(2n\sigma^2)}}{\cosh(at/\sigma^2)} dt.$$

现在刻画全部 minimax 估计量。若 δ 为任意 minimax 估计量, 则 $\sup_{\theta \in \{-a, a\}} R(\theta, \delta) = V$ 。因而 $\frac{1}{2}R(-a, \delta) + \frac{1}{2}R(a, \delta) \leq V$ 。但 V 是等概率先验下的最小 Bayes 风险, 所以反向不等式也成立: $\frac{1}{2}R(-a, \delta) + \frac{1}{2}R(a, \delta) \geq V$ 。因此 $\frac{1}{2}R(-a, \delta) + \frac{1}{2}R(a, \delta) = V$ 。这说明 δ 也是等概率先验下的 Bayes 估计量。

对每个样本点 $\mathbf{x}$, 平方损失下的后验风险满足 $\rho(d | \mathbf{x}) = \text{Var}(\theta | \mathbf{x}) + [d - \delta^*(\mathbf{x})]^2$ 。因而后验风险具有唯一最小点 $\delta^*(\mathbf{x})$ 。等概率先验的边际密度在整个 $\mathbb{R}^n$ 上严格为正, 所以任意 minimax 估计量都必须满足 $\delta(\mathbf{x}) = \delta^*(\mathbf{x})$ 除了一个在 P_{-a} 和 P_a 下均为零概率的集合之外。

因此 **全部 minimax 估计量均与 δ^* 几乎处处相等。**

最后证明 δ^* admissible。假设存在估计量 $\tilde{\delta}$ 支配 δ^* , 即 $R(-a, \tilde{\delta}) \leq R(-a, \delta^*)$, $R(a, \tilde{\delta}) \leq R(a, \delta^*)$, 且至

少一个不等式严格成立。因为等概率先验对两个参数点均赋予正概率，

$$\frac{1}{2}R(-a, \tilde{\delta}) + \frac{1}{2}R(a, \tilde{\delta}) < \frac{1}{2}R(-a, \delta^*) + \frac{1}{2}R(a, \delta^*) = r\left(\frac{1}{2}\right),$$

这与 δ^* 是等概率先验下的 Bayes 估计量矛盾。所以 δ^* 是 admissible 的。

(3) 由第 (a) 问的似然比, $\frac{f_+(\mathbf{x})}{f_-(\mathbf{x})} \geq 1 \iff T(\mathbf{x}) \geq 0$ 。因此最大似然估计量可取为 $\delta_{\text{MLE}}(\mathbf{X}) = \begin{cases} a, & T \geq 0, \\ -a, & T < 0. \end{cases}$

当 $T = 0$ 时两个参数值的似然相同；由于 T 连续，该事件在两个参数点下的概率均为零，所以此处如何定义不影响风险。

当 $\theta = a$ 时, $T \sim N(na, n\sigma^2)$ 。只有在 $T < 0$ 时估计错误，此时平方损失为 $(-a - a)^2 = 4a^2$ 。因而 $R(a, \delta_{\text{MLE}}) = 4a^2\mathbb{P}_a(T < 0) = 4a^2\Phi\left(-\frac{a\sqrt{n}}{\sigma}\right)$ 。由模型对称性, $R(-a, \delta_{\text{MLE}}) = R(a, \delta_{\text{MLE}})$ 。所以

$$R(\theta, \delta_{\text{MLE}}) = 4a^2\Phi\left(-\frac{a\sqrt{n}}{\sigma}\right), \quad \theta \in \{-a, a\}.$$

下面比较 δ_{MLE} 与 δ^* 。在等概率先验下，对任意估计量 δ ，条件平方损失分解为 $\mathbb{E}[(\delta - \theta)^2 | \mathbf{X}] = \text{Var}(\theta | \mathbf{X}) + [\delta - \delta^*(\mathbf{X})]^2$ 。因而 $\frac{1}{2}R(-a, \delta_{\text{MLE}}) + \frac{1}{2}R(a, \delta_{\text{MLE}}) - V = \mathbb{E}_{m_{1/2}}[(\delta_{\text{MLE}}(\mathbf{X}) - \delta^*(\mathbf{X}))^2]$ 。对每个有限的 T , $|a \tanh(\frac{aT}{\sigma^2})| < a$ ，而 $|\delta_{\text{MLE}}| = a$ 。所以 $\delta_{\text{MLE}}(\mathbf{X}) \neq \delta^*(\mathbf{X})$ 在边际分布下以概率 1 成立，从而 $\mathbb{E}_{m_{1/2}}[(\delta_{\text{MLE}} - \delta^*)^2] > 0$ 。因此 $\frac{1}{2}R(-a, \delta_{\text{MLE}}) + \frac{1}{2}R(a, \delta_{\text{MLE}}) > V$ 。

δ_{MLE} 和 δ^* 都是关于样本的奇函数，因此二者在 $\theta = -a$ 与 $\theta = a$ 处的风险分别相等。于是上面的严格 Bayes 风险不等式实际上给出 $R(-a, \delta^*) < R(-a, \delta_{\text{MLE}})$ 和 $R(a, \delta^*) < R(a, \delta_{\text{MLE}})$ 。

因而 δ^* 在参数空间的每一个参数点都严格改进 δ_{MLE} 。所以 δ_{MLE} 不是 admissible 的。同时 $\sup_{\theta} R(\theta, \delta_{\text{MLE}}) > V$ ，所以 δ_{MLE} 也不是 minimax 估计量。

一个严格支配它的估计量正是 $\delta^*(\mathbf{X}) = a \tanh\left(\frac{a}{\sigma^2} \sum_{i=1}^n X_i\right)$ 。特别地，还得到严格不等式 $V < 4a^2\Phi\left(-\frac{a\sqrt{n}}{\sigma}\right)$ 。

□

Problem 11 (10 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f(x | \theta) = \frac{1}{2}(x - \theta)^2 e^{-(x - \theta)} \mathbb{1}_{\{x > \theta\}}$, $\theta \in \mathbb{R}$ 。记 $X_{(1)} = \min_{1 \leq i \leq n} X_i$ 。

- (1) 求 θ 的最大似然估计量 $\hat{\theta}_n$ 。证明它以概率 1 存在且唯一，并将其刻画为区间 $(-\infty, X_{(1)})$ 内某个方程的唯一解。
- (2) 证明 $\hat{\theta}_n$ 强相合，并求 $\sqrt{n}(\hat{\theta}_n - \theta)$ 的极限分布。你的论证必须处理似然支撑依赖 θ 所造成的边界问题，不能仅引用固定共同支撑下的通常 MLE 渐近正态定理。
- (3) 求 $n^{1/3}(X_{(1)} - \theta)$ 的极限分布，并比较 $X_{(1)}$ 与 $\hat{\theta}_n$ 的收敛速度。计算单个观测在真参数处的形式 score 的均值与方差，并说明本模型中“支撑依赖参数”与第 (b) 问所得极限之间为何并不矛盾。

第 11 题解答

解：记真实参数为 θ ，并令 $Y_i = X_i - \theta$ 。则 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Gamma}(3, 1)$ ，其密度为 $g(y) = \frac{1}{2}y^2 e^{-y} \mathbb{1}_{\{y > 0\}}$ 。

(1) 对给定样本 $x_1, \dots, x_n$, 只有 $u < x_{(1)}$ 时似然为正。忽略与 u 无关的常数,

$$\ell_n(u) = 2 \sum_{i=1}^n \log(x_i - u) - \sum_{i=1}^n (x_i - u) = 2 \sum_{i=1}^n \log(x_i - u) + nu + C(x).$$

一阶导数为 $\ell'_n(u) = n - 2 \sum_{i=1}^n \frac{1}{x_i - u}$ 。二阶导数为 $\ell''_n(u) = -2 \sum_{i=1}^n \frac{1}{(x_i - u)^2} < 0$ 。因而 ℓ_n 在 $(-\infty, x_{(1)})$ 上严格凹。

当 $u \rightarrow -\infty$ 时, $\ell'_n(u) \rightarrow n > 0$ 。当 $u \uparrow x_{(1)}$ 时, $\ell'_n(u) \rightarrow -\infty$ 。所以存在唯一的根 $\hat{\theta}_n \in (-\infty, x_{(1)})$ 满足

$$\frac{1}{n} \sum_{i=1}^n \frac{1}{X_i - \hat{\theta}_n} = \frac{1}{2}. \quad \text{由于 log-likelihood 严格凹, 该根是唯一全局最大点。因此 } \hat{\theta}_n \text{ 以概率 1 存在且唯一。}$$

(2) 首先证明强相合性。

由于 $Y_i > 0$, $X_{(1)} = \theta + Y_{(1)}$ 。对任意 $\varepsilon > 0$, $\mathbb{P}(Y_{(1)} > \varepsilon) = \mathbb{P}(Y_1 > \varepsilon)^n \rightarrow 0$ 。而 $Y_{(1)}$ 随 n 单调下降, 因此 $Y_{(1)} \xrightarrow{\text{a.s.}} 0$ 。所以 $\limsup_{n \rightarrow \infty} \hat{\theta}_n \leq \lim_{n \rightarrow \infty} X_{(1)} = \theta \quad \text{a.s.}$

固定 $\varepsilon > 0$ 。由强大数律, $\frac{1}{n} \sum_{i=1}^n \frac{1}{X_i - (\theta - \varepsilon)} = \frac{1}{n} \sum_{i=1}^n \frac{1}{Y_i + \varepsilon} \xrightarrow{\text{a.s.}} \mathbb{E} \frac{1}{Y_1 + \varepsilon}$ 。且严格有 $\mathbb{E} \frac{1}{Y_1 + \varepsilon} < \mathbb{E} \frac{1}{Y_1}$ 。对 $Y_1 \sim \text{Gamma}(3, 1)$, $\mathbb{E} \frac{1}{Y_1} = \frac{1}{3-1} = \frac{1}{2}$ 。因而最终有 $\frac{1}{n} \sum_{i=1}^n \frac{1}{X_i - (\theta - \varepsilon)} < \frac{1}{2}$ 。左侧作为参数 u 的函数严格递增, 而 $\hat{\theta}_n$ 是其等于 $1/2$ 的唯一一点, 所以最终 $\hat{\theta}_n > \theta - \varepsilon$ 。结合上界, 得到 $\hat{\theta}_n \xrightarrow{\text{a.s.}} \theta$ 。

下面求渐近分布。定义单个观测的形式 score $\psi(Y_i) = 1 - \frac{2}{Y_i}$ 。对 $\text{Gamma}(3, 1)$, $\mathbb{E} \frac{1}{Y} = \frac{1}{2}$, $\mathbb{E} \frac{1}{Y^2} = \frac{1}{(3-1)(3-2)} = \frac{1}{2}$ 。因而 $\mathbb{E} \psi(Y) = 0$, 且 $\text{Var}(\psi(Y)) = \mathbb{E} \left(1 - \frac{2}{Y}\right)^2 = 1 - 4\mathbb{E} \frac{1}{Y} + 4\mathbb{E} \frac{1}{Y^2} = 1$ 。因此 $Z_n :=$

$$\frac{1}{\sqrt{n}} \ell'_n(\theta) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \left(1 - \frac{2}{Y_i}\right) \xrightarrow{d} \text{N}(0, 1).$$

虽然支撑依赖参数, 但在 $\sqrt{n}$ 局部尺度下, 样本边界以高概率不会被触及。事实上, 对任意固定 $K > 0$, $\mathbb{P}(\sqrt{n} Y_{(1)} \leq K) \leq n \mathbb{P}\left(Y_1 \leq \frac{K}{\sqrt{n}}\right)$ 。因为 $\mathbb{P}(Y_1 \leq y) = \frac{y^3}{6} + o(y^3)$, $y \downarrow 0$, 所以 $n \mathbb{P}\left(Y_1 \leq \frac{K}{\sqrt{n}}\right) = O(n^{-1/2}) \rightarrow 0$ 。即 $\sqrt{n} Y_{(1)} \xrightarrow{\text{P}} \infty$ 。

对任意固定 K , 在事件 $\sqrt{n} Y_{(1)} > 2K$ 上, 若 $|h| \leq K$, 则 $\frac{1}{n} \ell''_n\left(\theta + \frac{h}{\sqrt{n}}\right) = -\frac{2}{n} \sum_{i=1}^n \frac{1}{(Y_i - h/\sqrt{n})^2}$ 。而 $\sup_{|h| \leq K} \left| \frac{1}{(Y_i - h/\sqrt{n})^2} - \frac{1}{Y_i^2} \right|$ 可由 $\frac{C_K}{\sqrt{n} Y_{(1)}} \frac{1}{Y_i^2}$ 控制。由 $\frac{1}{n} \sum_{i=1}^n \frac{1}{Y_i^2} \xrightarrow{\text{a.s.}} \frac{1}{2}$ 以及 $\frac{1}{\sqrt{n} Y_{(1)}} \xrightarrow{\text{P}} 0$, 得

$$\sup_{|h| \leq K} \left| \frac{1}{n} \ell''_n\left(\theta + \frac{h}{\sqrt{n}}\right) + 1 \right| \xrightarrow{\text{P}} 0.$$

由 ℓ_n 的严格凹性和上述局部展开, $\sqrt{n}(\hat{\theta}_n - \theta) = O_{\mathbb{P}}$ 。对 score 方程使用中值定理, 存在 $\tilde{\theta}_n$ 位于 θ 与 $\hat{\theta}_n$ 之间, 使 $0 = \ell'_n(\hat{\theta}_n) = \ell'_n(\theta) + \ell''_n(\tilde{\theta}_n)(\hat{\theta}_n - \theta)$ 。因此 $\sqrt{n}(\hat{\theta}_n - \theta) = -\frac{n^{-1/2} \ell'_n(\theta)}{n^{-1} \ell''_n(\tilde{\theta}_n)}$ 。分子趋于 $N(0, 1)$, 分母

依概率趋于 -1 , 故 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \text{N}(0, 1)$ 。

(3) 对 $y \downarrow 0$, $F_Y(y) = 1 - e^{-y} \left(1 + y + \frac{y^2}{2}\right) = \frac{y^3}{6} + o(y^3)$ 。对 $z \geq 0$,

$$\mathbb{P}\left(n^{1/3}(X_{(1)} - \theta) > z\right) = \mathbb{P}\left(Y_{(1)} > \frac{z}{n^{1/3}}\right) = \left[1 - F_Y\left(\frac{z}{n^{1/3}}\right)\right]^n \rightarrow \exp\left(-\frac{z^3}{6}\right).$$

因此 $n^{1/3}(X_{(1)} - \theta) \xrightarrow{d} W$, 其中 W 的分布函数为 $F_W(z) = \begin{cases} 0, & z < 0, \\ 1 - \exp(-z^3/6), & z \geq 0. \end{cases}$ 这是 shape 参

数为 3、尺度参数为 $6^{1/3}$ 的 Weibull 分布。

因而 $X_{(1)} - \theta = O_{\mathbb{P}}(n^{-1/3})$, 而 $\hat{\theta}_n - \theta = O_{\mathbb{P}}(n^{-1/2})$ 。所以 $\hat{\theta}_n$ 的收敛速度快于 $X_{(1)}$ 。

单个观测的形式 score 为 $U_{\theta}(X) = \frac{\partial}{\partial \theta} \log f(X | \theta) = 1 - \frac{2}{X - \theta} = 1 - \frac{2}{Y}$ 。已计算得到 $\mathbb{E}_{\theta} U_{\theta}(X) = 0$, $\text{Var}_{\theta}(U_{\theta}(X)) = 1$ 。因而形式 Fisher 信息为 $I(\theta) = 1$ 。

支撑依赖参数并不必然导致非正态极限。本题中密度在支撑左端满足 $g(y) \asymp \frac{1}{2}y^2$, $y \downarrow 0$ 。所以最小次序统计量到边界的距离为 $Y_{(1)} = O_{\mathbb{P}}(n^{-1/3})$ 。而 MLE 的局部变化尺度为 $n^{-1/2}$ 。因为 $n^{-1/2} = o(n^{-1/3})$, 在 $\sqrt{n}$ 局部邻域中, 参数变化以概率趋于 1 不会越过样本支撑边界。更具体地, $n\mathbb{P}\left(Y_1 \leq \frac{h}{\sqrt{n}}\right) \rightarrow 0$ 。因而局部 log-likelihood 仍具有通常的二次展开, 最终得到根号 n 正态极限。这与支撑依赖参数并不矛盾。

□



35.5 第五套试题 + 答案

Problem 1 (10 分)

设 $X_1, X_2, X_3, X_4 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $\bar{X} = \frac{1}{4} \sum_{i=1}^4 X_i$, 并定义

$$Z_0 = \frac{X_1 + X_2 + X_3 + X_4}{2}, \quad Z_1 = \frac{X_1 - X_2}{\sqrt{2}}, \quad Z_2 = \frac{X_1 + X_2 - 2X_3}{\sqrt{6}}, \quad Z_3 = \frac{X_1 + X_2 + X_3 - 3X_4}{\sqrt{12}}.$$

进一步令 $R = \sqrt{Z_1^2 + Z_2^2 + Z_3^2}$, $U = \begin{cases} Z_3/R, & R > 0, \\ 0, & R = 0. \end{cases}$

- (1) 确定随机向量 (Z_0, Z_1, Z_2, Z_3) 的联合分布, 并完整说明其各分量之间的独立关系。
- (2) 求 R 的概率密度、 U 的分布, 并判断 R 与 U 是否独立。
- (3) 计算 $\mathbb{E}[(X_1 - \bar{X})^2 | \sigma(R)]$ 以及 $\text{Cov}(\bar{X}, R^2)$.

第 1 题解答

记 $\mathbf{X} = (X_1, X_2, X_3, X_4)^\top$, $\mathbf{Z} = (Z_0, Z_1, Z_2, Z_3)^\top$. 题中变换可写为 $\mathbf{Z} = H\mathbf{X}$, 其中

$$H = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} & \frac{1}{2} & \frac{1}{2} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & 0 \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & -\frac{2}{\sqrt{6}} & 0 \\ \frac{1}{\sqrt{12}} & \frac{1}{\sqrt{12}} & \frac{1}{\sqrt{12}} & -\frac{3}{\sqrt{12}} \end{pmatrix}.$$

直接计算可得 $HH^\top = I_4$, 故 H 为正交矩阵。

- (1) 由于 $\mathbf{X} \sim N_4(\mathbf{0}, I_4)$, 正交变换保持标准多元正态分布, 因此 $\mathbf{Z} \sim N_4(\mathbf{0}, I_4)$. 具体地, $Z_0, Z_1, Z_2, Z_3 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 由于多元正态向量中不相关分量相互独立, 而 $\text{Cov}(Z_i, Z_j) = 0$, $i \neq j$, 故四个分量相互独立. 另外, $\sum_{i=1}^4 X_i = 2Z_0$, $\bar{X} = \frac{Z_0}{2}$.

- (2) 向量 $(Z_1, Z_2, Z_3) \sim N_3(\mathbf{0}, I_3)$. 因此 $R^2 = Z_1^2 + Z_2^2 + Z_3^2 \sim \chi_3^2$. 于是 R 服从三维 Maxwell 分布, 其密度为

$$f_R(r) = \sqrt{\frac{2}{\pi}} r^2 e^{-r^2/2} \mathbf{1}_{\{r>0\}}.$$

标准三维正态分布具有旋转不变性。写成球坐标 $(Z_1, Z_2, Z_3) = R\boldsymbol{\Theta}$, $\boldsymbol{\Theta} \in S^2$, 则 R 与方向 $\boldsymbol{\Theta}$ 相互独立, 且 $\boldsymbol{\Theta}$ 在单位球面 S^2 上服从均匀分布。

由于 $U = \frac{Z_3}{R}$ 是方向向量的第三个坐标, 若以极角 ϑ 表示方向, 则 $U = \cos \vartheta$. 球面均匀测度满足 $\mathbb{P}(U \leq u) = \frac{u+1}{2}$, $-1 \leq u \leq 1$. 因此 $U \sim \text{Unif}[-1, 1]$, $f_U(u) = \frac{1}{2} \mathbf{1}_{\{-1 < u < 1\}}$. 并且 $R \perp\!\!\!\perp U$.

- (3) 由正交变换的逆变换 $\mathbf{X} = H^\top \mathbf{Z}$ 可得 $X_1 = \frac{1}{2}Z_0 + \frac{1}{\sqrt{2}}Z_1 + \frac{1}{\sqrt{6}}Z_2 + \frac{1}{\sqrt{12}}Z_3$. 又因为 $\bar{X} = Z_0/2$, 所以 $X_1 - \bar{X} = \frac{1}{\sqrt{2}}Z_1 + \frac{1}{\sqrt{6}}Z_2 + \frac{1}{\sqrt{12}}Z_3$. 令 $\mathbf{c} = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{6}}, \frac{1}{\sqrt{12}}\right)^\top$. 则 $X_1 - \bar{X} = \mathbf{c}^\top (Z_1, Z_2, Z_3)^\top$, 且 $\|\mathbf{c}\|^2 = \frac{1}{2} + \frac{1}{6} + \frac{1}{12} = \frac{3}{4}$.

给定 R 后, 方向在球面上均匀分布, 由旋转对称性, $\mathbb{E}(Z_i Z_j | R) = \begin{cases} R^2/3, & i = j, \\ 0, & i \neq j. \end{cases}$ 故

$$\mathbb{E}[(X_1 - \bar{X})^2 | \sigma(R)] = \mathbb{E}[(\mathbf{c}^\top \mathbf{Z}_{1:3})^2 | R] = \frac{R^2}{3} \|\mathbf{c}\|^2 = \frac{R^2}{4}.$$

最后, $\bar{X} = \frac{Z_0}{2}$ 只依赖 Z_0 , 而 $R^2 = Z_1^2 + Z_2^2 + Z_3^2$ 只依赖 (Z_1, Z_2, Z_3) 。由四个 Z_i 相互独立, $\bar{X} \perp R^2$. 因此 $\text{Cov}(\bar{X}, R^2) = 0$.

Problem 2 (10 分)

固定常数 $\lambda_+ > 0$, $\lambda_- > 0$. 对每个充分大的正整数 n 以及 $1 \leq k \leq n$, 设 $\varepsilon_{n,k}$ 为取值 ± 1 、概率各为

$1/2$ 的随机变量, 并设 $J_{n,k} = \begin{cases} 1, & \text{概率为 } \lambda_+/n, \\ -1, & \text{概率为 } \lambda_-/n, \\ 0, & \text{概率为 } 1 - (\lambda_+ + \lambda_-)/n. \end{cases}$ 假设所有 $\{\varepsilon_{n,k}, J_{n,k} : n \geq 1, 1 \leq k \leq n\}$ 彼此

独立. 定义 $S_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k} + \sum_{k=1}^n J_{n,k}$.

- (1) 求 S_n 的极限分布, 并将极限随机变量表示为三个相互独立的标准分布随机变量之和或差。
- (2) 证明随机变量族 $\{S_n^2 : n \geq 1\}$ 一致可积, 并计算 $\lim_{n \rightarrow \infty} \mathbb{E}(S_n^2)$.
- (3) 另设事件 A_n 与上述所有随机变量独立, 且 $\mathbb{P}(A_n) = \frac{1}{n^2}$. 定义 $\tilde{S}_n = S_n + n^2 \mathbf{1}_{A_n}$. 分别判断 $\tilde{S}_n - S_n$ 是否依概率收敛、几乎处处收敛、依分布收敛以及在 L^1 中收敛, 并确定 $\tilde{S}_n$ 的极限分布。

第 2 题解答

记 $A_n = \frac{1}{\sqrt{n}} \sum_{k=1}^n \varepsilon_{n,k}$, $B_n = \sum_{k=1}^n J_{n,k}$, 则 $S_n = A_n + B_n$.

- (1) 对任意 $t \in \mathbb{R}$, $\mathbb{E}e^{itA_n} = \left(\cos \frac{t}{\sqrt{n}}\right)^n \rightarrow e^{-t^2/2}$. 故 $A_n \xrightarrow{d} G$, $G \sim N(0, 1)$.

另一方面, $\mathbb{E}e^{itB_n} = \left[1 + \frac{\lambda_+}{n}(e^{it} - 1) + \frac{\lambda_-}{n}(e^{-it} - 1)\right]^n \rightarrow \exp\{\lambda_+(e^{it} - 1) + \lambda_-(e^{-it} - 1)\}$. 右侧是 $P_+ - P_-$ 的特征函数, 其中 $P_+ \sim \text{Poisson}(\lambda_+)$, $P_- \sim \text{Poisson}(\lambda_-)$, 且 P_+, P_- 相互独立。

由于每个 n 下 $A_n \perp B_n$, 联合特征函数分解, 因此极限可取为 G, P_+, P_- 相互独立. 于是 $S_n \xrightarrow{d} S := G + P_+ - P_-$, 其中 $G \sim N(0, 1)$, $P_+ \sim \text{Poisson}(\lambda_+)$, $P_- \sim \text{Poisson}(\lambda_-)$ 相互独立。

- (2) 令 $c = \lambda_+ + \lambda_-$, $d = \lambda_+ - \lambda_-$. 首先, $\mathbb{E}A_n^4 = \frac{1}{n^2} \mathbb{E}(\sum_{k=1}^n \varepsilon_{n,k})^4$. 由于 $\mathbb{E}\varepsilon_{n,k} = 0$, $\mathbb{E}\varepsilon_{n,k}^2 = 1$, $\mathbb{E}(\sum_{k=1}^n \varepsilon_{n,k})^4 = n + 6\binom{n}{2} = 3n^2 - 2n$. 因此 $\mathbb{E}A_n^4 = 3 - \frac{2}{n} \leq 3$.

再令 $C_n = \sum_{k=1}^n \mathbf{1}_{\{J_{n,k} \neq 0\}}$. 则 $C_n \sim \text{Binomial}(n, \frac{c}{n})$, $|B_n| \leq C_n$. 利用恒等式 $x^4 = (x)_4 + 6(x)_3 + 7(x)_2 + x$, 其中 $(x)_j = x(x-1)\cdots(x-j+1)$, 以及二项分布的阶乘矩, $\mathbb{E}(C_n)_j = (n)_j \left(\frac{c}{n}\right)^j \leq c^j$, 得到 $\mathbb{E}C_n^4 \leq c^4 + 6c^3 + 7c^2 + c$. 故 $\sup_n \mathbb{E}B_n^4 < \infty$.

由 $|x+y|^4 \leq 8(|x|^4 + |y|^4)$ 可得 $\sup_n \mathbb{E}|S_n|^4 < \infty$. 于是 $\sup_n \mathbb{E}[(S_n^2)^2] < \infty$, 从而 $\{S_n^2 : n \geq 1\}$ 一致可积。

下面计算二阶矩。显然 $\mathbb{E}A_n = 0$, $\text{Var}(A_n) = 1$. 对单个 $J_{n,k}$, $\mathbb{E}J_{n,k} = \frac{d}{n}$, $\mathbb{E}J_{n,k}^2 = \frac{c}{n}$. 因此 $\mathbb{E}B_n = d$, 且 $\text{Var}(B_n) = n\left(\frac{c}{n} - \frac{d^2}{n^2}\right) = c - \frac{d^2}{n}$. 故 $\mathbb{E}B_n^2 = c - \frac{d^2}{n} + d^2$. 由于 $A_n \perp B_n$ 且 $\mathbb{E}A_n = 0$, $\mathbb{E}S_n^2 = 1 + c + d^2\left(1 - \frac{1}{n}\right)$. 所以 $\lim_{n \rightarrow \infty} \mathbb{E}S_n^2 = 1 + \lambda_+ + \lambda_- + (\lambda_+ - \lambda_-)^2$.

这也等于极限随机变量 $S = G + P_+ - P_-$ 的二阶矩。

- (3) 令 $D_n = \tilde{S}_n - S_n = n^2 \mathbf{1}_{A_n}$.

对任意 $\varepsilon > 0$, 当 $n^2 > \varepsilon$ 时, $\mathbb{P}(|D_n| > \varepsilon) = \mathbb{P}(A_n) = \frac{1}{n^2} \rightarrow 0$. 所以 $D_n \xrightarrow{P} 0$.

又因为 $\sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} \frac{1}{n^2} < \infty$, 由第一 Borel-Cantelli 引理, $\mathbb{P}(A_n \text{ 无穷多次发生}) = 0$. 因此几乎处处存在随机的 $N(\omega)$, 使得对所有 $n \geq N(\omega)$, $1_{A_n}(\omega) = 0$. 故 $D_n \xrightarrow{\text{a.s.}} 0$.

几乎处处收敛蕴含依分布收敛, 所以 $D_n \xrightarrow{d} 0$.

但 $\mathbb{E}|D_n| = n^2 \mathbb{P}(A_n) = 1$. 因此 $\mathbb{E}|D_n - 0| \not\rightarrow 0$, 故 D_n 不在 L^1 中收敛到 0. 由于依概率极限唯一, 它也不可能在 L^1 中收敛到其他随机变量.

最后, 由 $\tilde{S}_n = S_n + D_n$, $D_n \xrightarrow{P} 0$, 以及 Slutsky 定理, $\tilde{S}_n \xrightarrow{d} G + P_+ - P_-$.

Problem 3 (10 分)

设 $\{N_t^{(1)} : t \geq 0\}$, $\{N_t^{(2)} : t \geq 0\}$ 是相互独立的 Poisson 过程, 速率分别为 $\lambda_1 > 0$, $\lambda_2 > 0$. 令 $N_t = N_t^{(1)} + N_t^{(2)}$. 对固定整数 $m \geq 2$, 定义 $T_m = \inf\{t \geq 0 : N_t = m\}$, $K_m = N_{T_m}^{(1)}$.

- (1) 对任意 $s \geq 0$ 和 $0 \leq z \leq 1$, 计算联合变换 $\mathbb{E}[e^{-sT_m} z^{K_m}]$.
- (2) 求 (T_m, K_m) 的联合分布, 分别写出 T_m 和 K_m 的边缘分布, 并判断 T_m 与 K_m 是否独立.
- (3) 记 $\Delta N_{T_m}^{(1)} = N_{T_m}^{(1)} - N_{T_m-}^{(1)}$. 对每个 $0 \leq k \leq m$, 计算 $\mathbb{P}(\Delta N_{T_m}^{(1)} = 1 \mid K_m = k)$.

第 3 题解答

令 $\lambda = \lambda_1 + \lambda_2$, $p = \frac{\lambda_1}{\lambda_1 + \lambda_2}$. 两个独立 Poisson 过程的叠加 $N_t = N_t^{(1)} + N_t^{(2)}$ 是速率为 λ 的 Poisson 过程.

叠加过程的每次到达独立地带有类型标记: $\mathbb{P}(\text{该次到达来自过程1}) = p$, $\mathbb{P}(\text{该次到达来自过程2}) = 1 - p$, 并且这些标记与到达时刻序列相互独立.

- (1) T_m 是速率 λ 的 Poisson 过程的第 m 个到达时刻, 因此 $T_m \sim \text{Gamma}(\text{shape } m, \text{rate } \lambda)$, 且 $\mathbb{E}e^{-sT_m} = \left(\frac{\lambda}{\lambda+s}\right)^m$.
 K_m 是前 m 次到达中类型 1 的到达数, 因此 $K_m \sim \text{Binomial}(m, p)$, 并且 $K_m \perp T_m$. 于是

$$\mathbb{E}[e^{-sT_m} z^{K_m}] = \mathbb{E}e^{-sT_m} \mathbb{E}z^{K_m} = \left(\frac{\lambda}{\lambda+s}\right)^m (1-p+pz)^m = \left(\frac{\lambda_2 + \lambda_1 z}{\lambda_1 + \lambda_2 + s}\right)^m.$$

- (2) 对 $t > 0$ 和 $k = 0, 1, \dots, m$, $f_{T_m}(t) = \frac{\lambda^m}{(m-1)!} t^{m-1} e^{-\lambda t}$, 且 $\mathbb{P}(K_m = k) = \binom{m}{k} p^k (1-p)^{m-k}$. 由独立性,

$$\mathbb{P}(T_m \in dt, K_m = k) = f_{T_m}(t) \mathbb{P}(K_m = k) dt = \binom{m}{k} \frac{\lambda_1^k \lambda_2^{m-k}}{(m-1)!} t^{m-1} e^{-(\lambda_1 + \lambda_2)t} dt.$$

边缘分布为 $T_m \sim \text{Gamma}(m, \text{rate } \lambda_1 + \lambda_2)$, 以及 $K_m \sim \text{Binomial}\left(m, \frac{\lambda_1}{\lambda_1 + \lambda_2}\right)$. 并且 $T_m \perp K_m$.

- (3) 记前 m 次叠加到达的类型标记为 $I_1, \dots, I_m$, 其中 $I_j = \begin{cases} 1, & \text{第 } j \text{ 次到达来自过程1,} \\ 0, & \text{第 } j \text{ 次到达来自过程2.} \end{cases}$ 则 $K_m = \sum_{j=1}^m I_j$.

且 $\Delta N_{T_m}^{(1)} = I_m$.

给定 $K_m = k$, 在 m 个位置中恰有 k 个位置的标记等于 1, 由于标记的交换对称性, 最后一个位置为 1

的条件概率为 $\frac{k}{m}$. 因此 $\mathbb{P}(\Delta N_{T_m}^{(1)} = 1 \mid K_m = k) = \frac{k}{m}, \quad k = 0, 1, \dots, m.$

Problem 4 (15 分)

设 $\xi_1, \xi_2, \dots$ 相互独立, 且 $\mathbb{P}(\xi_k = 1) = \mathbb{P}(\xi_k = -1) = \frac{1}{2}$. 令 $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$, 并设 $\{a_k\}_{k \geq 1}$ 是满足 $0 < a_k \leq \frac{1}{2}$ 的确定性数列. 定义 $M_0 = 1, \quad M_n = \prod_{k=1}^n (1 + a_k \xi_k), \quad n \geq 1.$

- (1) 证明 $\{M_n, \mathcal{F}_n\}_{n \geq 0}$ 是非负鞅, 并证明存在有限随机变量 M_∞ 使得 $M_n \rightarrow M_\infty$ a.s.
- (2) 证明 $\sup_{n \geq 1} \mathbb{E}(M_n^2) < \infty \iff \sum_{k=1}^\infty a_k^2 < \infty$. 在上述条件成立时, 证明 $M_n \rightarrow M_\infty$ 于 L^2 , 并计算 $\mathbb{E}(M_\infty)$ 与 $\mathbb{E}(M_\infty^2)$.
- (3) 假设 $\sum_{k=1}^\infty a_k^2 = \infty$. 证明 $M_n \rightarrow 0$ a.s. 并据此完整刻画 $\{M_n\}$ 何时一致可积、何时在 L^1 中收敛.

第 4 题解答

- (1) 由于 $0 < a_k \leq \frac{1}{2}$, 有 $1 + a_k \xi_k \geq 1 - a_k \geq \frac{1}{2} > 0$. 因此 $M_n \geq 0$. 又 M_n 是 $\mathcal{F}_n$ -可测的, 并且 $\mathbb{E}M_n = \prod_{k=1}^n \mathbb{E}(1 + a_k \xi_k) = 1$, 故 M_n 可积.

利用 ξ_{n+1} 与 $\mathcal{F}_n$ 独立, $\mathbb{E}(M_{n+1} \mid \mathcal{F}_n) = M_n \mathbb{E}(1 + a_{n+1} \xi_{n+1} \mid \mathcal{F}_n) = M_n (1 + a_{n+1} \mathbb{E} \xi_{n+1}) = M_n$. 所以

$\{M_n, \mathcal{F}_n\}_{n \geq 0}$ 是非负鞅.

非负鞅是非负超鞅, 且 $\sup_n \mathbb{E}M_n = 1 < \infty$. 由非负鞅收敛定理, 存在有限随机变量 M_∞ , 使 $M_n \xrightarrow{\text{a.s.}} M_\infty$.

- (2) 由独立性, $\mathbb{E}M_n^2 = \prod_{k=1}^n \mathbb{E}(1 + a_k \xi_k)^2 = \prod_{k=1}^n [1 + 2a_k \mathbb{E} \xi_k + a_k^2 \mathbb{E} \xi_k^2] = \prod_{k=1}^n (1 + a_k^2)$. 由于 $0 < a_k^2 \leq \frac{1}{4}$, 存在绝对常数 $c_1, c_2 > 0$, 使 $c_1 a_k^2 \leq \log(1 + a_k^2) \leq c_2 a_k^2$. 例如可取 $\frac{1}{2} a_k^2 \leq \log(1 + a_k^2) \leq a_k^2$. 因此 $\prod_{k=1}^\infty (1 + a_k^2) < \infty \iff \sum_{k=1}^\infty a_k^2 < \infty$. 即 $\sup_n \mathbb{E}M_n^2 < \infty \iff \sum_{k=1}^\infty a_k^2 < \infty$.

若 $\sum_{k=1}^\infty a_k^2 < \infty$, 则 $\{M_n\}$ 在 L^2 中有界. 由 L^2 鞅收敛定理, $M_n \rightarrow M_\infty$ 于 L^2 . 因此也在 L^1 中收

敛, 从而 $\mathbb{E}M_\infty = \lim_{n \rightarrow \infty} \mathbb{E}M_n = 1$. 同时, 由 L^2 收敛, $\mathbb{E}M_\infty^2 = \lim_{n \rightarrow \infty} \mathbb{E}M_n^2$, 故 $\mathbb{E}M_\infty^2 = \prod_{k=1}^\infty (1 + a_k^2)$.

- (3) 假设 $\sum_{k=1}^\infty a_k^2 = \infty$. 由于每个因子严格为正, 可以取对数: $\log M_n = \sum_{k=1}^n \log(1 + a_k \xi_k)$. 令 $Y_k = \log(1 + a_k \xi_k)$, $m_k = \mathbb{E}Y_k$. 则 $m_k = \frac{1}{2} \log(1 + a_k) + \frac{1}{2} \log(1 - a_k) = \frac{1}{2} \log(1 - a_k^2)$. 由 $\log(1 - x) \leq -x$, $0 < x < 1$, 有 $m_k \leq -\frac{1}{2} a_k^2$.

令 $D_k = Y_k - m_k$, $A_n = \sum_{k=1}^n a_k^2$. 则 D_k 相互独立且均值为零. 并且 $\text{Var}(D_k) = \frac{1}{4} \left[\log \frac{1+a_k}{1-a_k} \right]^2$. 当 $0 < a_k \leq 1/2$ 时, $\log \frac{1+a_k}{1-a_k} = \int_{-a_k}^{a_k} \frac{dx}{1+x} \leq \frac{2a_k}{1-a_k} \leq 4a_k$. 故 $\text{Var}(D_k) \leq 4a_k^2$.

由于 $A_n \rightarrow \infty$, $\sum_{k=2}^\infty \frac{\text{Var}(D_k)}{A_k^2} \leq 4 \sum_{k=2}^\infty \frac{A_k - A_{k-1}}{A_k^2} \leq 4 \sum_{k=2}^\infty \frac{A_k - A_{k-1}}{A_{k-1} A_k} = 4 \sum_{k=2}^\infty \left(\frac{1}{A_{k-1}} - \frac{1}{A_k} \right) < \infty$. 所以随机级数 $\sum_{k=1}^\infty \frac{D_k}{A_k}$ 几乎处处收敛. 由 Kronecker 引理, $\frac{1}{A_n} \sum_{k=1}^n D_k \xrightarrow{\text{a.s.}} 0$.

于是 $\log M_n = \sum_{k=1}^n m_k + \sum_{k=1}^n D_k \leq -\frac{1}{2} A_n + o(A_n) \rightarrow -\infty$ a.s. 从而 $M_n \xrightarrow{\text{a.s.}} 0$.

现在刻画一致可积性.

若 $\sum_{k=1}^\infty a_k^2 < \infty$, 则 $\{M_n\}$ 在 L^2 中有界, 故一致可积.

若 $\sum_{k=1}^\infty a_k^2 = \infty$, 则 $M_n \xrightarrow{\text{a.s.}} 0$, 但 $\mathbb{E}M_n = 1$ 对所有 n . 若 $\{M_n\}$ 一致可积, 则几乎处处收敛加一致可积应推出 $M_n \rightarrow 0$ 于 L^1 , 进而 $\mathbb{E}M_n \rightarrow 0$, 与 $\mathbb{E}M_n = 1$ 矛盾. 因此该情形下不一致可积.

综上, $\{M_n\}$ 一致可积 $\iff \sum_{k=1}^{\infty} a_k^2 < \infty$. 同理, M_n 在 L^1 中收敛 $\iff \sum_{k=1}^{\infty} a_k^2 < \infty$. 当平方和有限时, $M_n \rightarrow M_\infty$ 于 L^1 ; 当平方和发散时, 其几乎处处极限为 0, 但 $\mathbb{E}|M_n - 0| = \mathbb{E}M_n = 1$, 故不在 L^1 中收敛.

Problem 5 (15 分)

设 $\{B_t : t \geq 0\}$ 是一维标准 Brownian motion. 对 $x \in [-a, a]$, 以 $\mathbb{P}_x$ 和 $\mathbb{E}_x$ 分别表示 $B_0 = x$ 时的概率与期望, 其中 $a > 0$. 定义 $\tau_a = \inf\{t \geq 0 : |B_t| = a\}$, 以及正半轴上的占用时间 $A_a = \int_0^{\tau_a} \mathbf{1}_{\{B_t > 0\}} dt$. 对 $\lambda > 0$, $q \geq 0$, 令 $u_{\lambda, q}(x) = \mathbb{E}_x[\exp\{-\lambda\tau_a - qA_a\}]$, $-a \leq x \leq a$.

- (1) 证明 $u_{\lambda, q}$ 在 $[-a, a]$ 上连续, 在 $(-a, a)$ 上连续可微, 并在 $(-a, 0)$ 与 $(0, a)$ 上二次连续可微. 确定它在两个子区间内满足的微分方程, 以及在 $-a, 0, a$ 处满足的全部边界条件和拼接条件, 并证明这些条件唯一确定 $u_{\lambda, q}$.
- (2) 令 $k_0 = \sqrt{2\lambda}$, $k_1 = \sqrt{2(\lambda + q)}$. 求 $u_{\lambda, q}(0)$ 的闭式表达式. 答案须完全化为 a, k_0, k_1 及初等双曲函数的组合, 不得保留未求解的常微分方程. 进一步计算 $\lim_{q \downarrow 0} u_{\lambda, q}(0)$ 和 $\lim_{\lambda \downarrow 0} u_{\lambda, q}(0)$.
- (3) 计算 $\mathbb{E}_0(\tau_a)$ 以及 $\mathbb{E}_0(A_a)$.

第 5 题解答

令 $V(x) = \lambda + q\mathbf{1}_{\{x > 0\}}$. 则 $u_{\lambda, q}(x) = \mathbb{E}_x \exp\left\{-\int_0^{\tau_a} V(B_s) ds\right\}$.

- (1) 设 v 满足以下分段边值问题: $\frac{1}{2}v''(x) - \lambda v(x) = 0$, $-a < x < 0$, 以及 $\frac{1}{2}v''(x) - (\lambda + q)v(x) = 0$, $0 < x < a$, 边界条件为 $v(-a) = v(a) = 1$, 拼接条件为 $v(0-) = v(0+)$, $v'(0-) = v'(0+)$.

令 $k_0 = \sqrt{2\lambda}$, $k_1 = \sqrt{2(\lambda + q)}$. 若记 $c = v(0)$, 则满足端点条件的分段解必为 $v_-(x) = \frac{\sinh(-k_0 x) + c \sinh(k_0(x+a))}{\sinh(k_0 a)}$, $x \leq 0$, 以及 $v_+(x) = \frac{c \sinh(k_1(a-x)) + \sinh(k_1 x)}{\sinh(k_1 a)}$, $0 \leq x \leq a$.

其左右导数为 $v'_-(0) = k_0 [c \coth(k_0 a) - \operatorname{csch}(k_0 a)]$, $v'_+(0) = k_1 [\operatorname{csch}(k_1 a) - c \coth(k_1 a)]$. 导数连续条件等价于 $c[k_0 \coth(k_0 a) + k_1 \coth(k_1 a)] = k_0 \operatorname{csch}(k_0 a) + k_1 \operatorname{csch}(k_1 a)$. 左侧 c 的系数严格为正, 所以 c 唯一, 进而边值问题的解唯一.

下面证明该解等于 $u_{\lambda, q}$.

由于 v 在 $[-a, a]$ 上连续, 在 $(-a, a)$ 上连续可微, 并且在 $(-a, 0)$ 、 $(0, a)$ 上二次连续可微, 可对分段 C^2 且一阶导数连续的函数使用 Itô-Tanaka 公式. 一阶导数在 0 处连续, 所以局部时项的系数为零.

令 $\tau = \tau_a$, $Y_t = \exp\left\{-\int_0^{t \wedge \tau} V(B_s) ds\right\} v(B_{t \wedge \tau})$. 利用上述微分方程, Y_t 的有限变差漂移项为零, 因此 Y_t 是局部鞅. 由于 $B_{t \wedge \tau} \in [-a, a]$, 而 v, v' 在紧区间上有界, 故 Y_t 实际上是有界或一致可积鞅. 因此 $v(x) = \mathbb{E}_x Y_t$.

Brownian motion 从有界区间中几乎处处有限时刻退出, 即 $\tau_a < \infty$ a.s. 令 $t \rightarrow \infty$, 由有界收敛定理, $v(x) = \mathbb{E}_x \left[\exp\left\{-\int_0^{\tau_a} V(B_s) ds\right\} v(B_{\tau_a}) \right] = \mathbb{E}_x \exp\{-\lambda\tau_a - qA_a\}$, 因为 $B_{\tau_a} \in \{-a, a\}$, $v(B_{\tau_a}) = 1$. 故 $v(x) = u_{\lambda, q}(x)$.

因此 $u_{\lambda, q}$ 连续、分段 C^2 、整体 C^1 , 且满足上面的分段 Schrödinger 型方程、端点条件和拼接条件.

若 w 是同一微分方程和拼接条件下、边界值为零的解, 对 w 重复上述论证可得 $w(x) = \mathbb{E}_x [e^{-\lambda\tau_a - qA_a} w(B_{\tau_a})] = 0$, 所以解唯一.

(2) 由上一问的导数拼接方程,
$$u_{\lambda,q}(0) = \frac{k_0 \operatorname{csch}(k_0 a) + k_1 \operatorname{csch}(k_1 a)}{k_0 \coth(k_0 a) + k_1 \coth(k_1 a)}.$$
 等价地,

$$u_{\lambda,q}(0) = \frac{k_0 \sinh(k_1 a) + k_1 \sinh(k_0 a)}{k_0 \cosh(k_0 a) \sinh(k_1 a) + k_1 \cosh(k_1 a) \sinh(k_0 a)}.$$

当 $q \downarrow 0$ 时, $k_1 \rightarrow k_0 = \sqrt{2\lambda}$. 因此 $\lim_{q \downarrow 0} u_{\lambda,q}(0) = \frac{2k_0 \operatorname{csch}(k_0 a)}{2k_0 \coth(k_0 a)} = \frac{1}{\cosh(a\sqrt{2\lambda})}$.

再令 $\lambda \downarrow 0$. 记 $k = \sqrt{2q}$. 有 $k_0 \operatorname{csch}(k_0 a) \rightarrow \frac{1}{a}$, $k_0 \coth(k_0 a) \rightarrow \frac{1}{a}$. 若 $q > 0$, 则

$$\lim_{\lambda \downarrow 0} u_{\lambda,q}(0) = \frac{a^{-1} + k \operatorname{csch}(ka)}{a^{-1} + k \coth(ka)} = \frac{\sinh(ka) + ak}{\sinh(ka) + ak \cosh(ka)}.$$

若 $q = 0$, 则被积指数恒为 1, 所以 $\lim_{\lambda \downarrow 0} u_{\lambda,0}(0) = 1$.

(3) 对停时 $\tau_a \wedge t$ 应用鞅 $B_t^2 - t$. 由于 $|B_{\tau_a \wedge t}| \leq a$, 可选停止给出 $\mathbb{E}_0 B_{\tau_a \wedge t}^2 = \mathbb{E}_0(\tau_a \wedge t)$. 当 $t \rightarrow \infty$ 时, $B_{\tau_a \wedge t}^2 \rightarrow a^2$ a.s. 且左侧被 a^2 控制. 由控制收敛定理及单调收敛定理, $\mathbb{E}_0 \tau_a = a^2$. 故 $\mathbb{E}_0 \tau_a = a^2$.
定义 $A_a^+ = \int_0^{\tau_a} \mathbf{1}_{\{B_t > 0\}} dt$, $A_a^- = \int_0^{\tau_a} \mathbf{1}_{\{B_t < 0\}} dt$. Brownian motion 的零点集具有 Lebesgue 测度零. 事实上, $\mathbb{E} \int_0^{\tau_a} \mathbf{1}_{\{B_t = 0\}} dt \leq \int_0^{\infty} \mathbb{P}(B_t = 0) dt = 0$. 所以 $A_a^+ + A_a^- = \tau_a$ a.s. 又由 B 与 $-B$ 同分布, $A_a^+ \stackrel{d}{=} A_a^-$. 因此二者期望相等, $2\mathbb{E}_0 A_a = \mathbb{E}_0 \tau_a = a^2$. 故 $\mathbb{E}_0 A_a = \frac{a^2}{2}$.

Problem 6 (10 分)

考虑状态空间 $\mathcal{S} = \{0, 1, 2, \dots\}$ 上的时齐 Markov 链 $\{X_n\}_{n \geq 0}$. 其转移概率如下: $P(0, 1) = \frac{1}{8}$, $P(0, 0) = \frac{7}{8}$, 而对每个 $i \geq 1$, $P(i, i-1) = \frac{1}{2}$, $P(i, i+1) = \frac{1}{2} \left(\frac{i+1}{i+2} \right)^2$, $P(i, i) = \frac{1}{2} - \frac{1}{2} \left(\frac{i+1}{i+2} \right)^2$.

- (1) 判断该链是否不可约、非周期及可逆, 并求出其全部平稳概率分布.
- (2) 判断该链是暂留、零常返还是正常返. 若 $\tau_0^+ = \inf\{n \geq 1 : X_n = 0\}$, 计算 $\mathbb{E}_0(\tau_0^+)$. 答案可以用 $\zeta(2) = \sum_{k=1}^{\infty} \frac{1}{k^2}$ 表示.
- (3) 对任意 $i, j \in \mathcal{S}$, 求 $\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j)$.

第 6 题解答

记 $p_i = P(i, i+1)$, $q_i = P(i, i-1)$.

- (1) 对所有相邻状态, $P(i, i+1) > 0$, $P(i+1, i) > 0$. 因此任意两个状态之间均可通过有限条相邻边互达, 所以该链不可约.

又因为 $P(0, 0) = \frac{7}{8} > 0$, 状态 0 的周期为 1. 不可约链的所有状态周期相同, 所以该链非周期.

下面求可逆平稳分布. 详细平衡方程为 $\pi_i P(i, i+1) = \pi_{i+1} P(i+1, i)$.

当 $i = 0$ 时, $\pi_0 \frac{1}{8} = \pi_1 \frac{1}{2}$, 所以 $\pi_1 = \frac{\pi_0}{4}$.

当 $i \geq 1$ 时, $\pi_i \frac{1}{2} \left(\frac{i+1}{i+2} \right)^2 = \pi_{i+1} \frac{1}{2}$, 即 $\pi_{i+1} = \pi_i \left(\frac{i+1}{i+2} \right)^2$. 递推得到 $\pi_i = \frac{\pi_0}{(i+1)^2}$, $i \geq 0$.

归一化条件为 $1 = \sum_{i=0}^{\infty} \pi_i = \pi_0 \sum_{i=0}^{\infty} \frac{1}{(i+1)^2} = \pi_0 \zeta(2)$. 所以 $\pi_0 = \frac{1}{\zeta(2)}$. 因此 $\pi_i = \frac{1}{\zeta(2)(i+1)^2}$, $i = 0, 1, 2, \dots$

上述 π 满足详细平衡方程, 故链可逆. 由于链不可约, 平稳概率分布若存在必唯一, 因此上述 π 是全部

平稳概率分布。

- (2) 不可约可数状态 Markov 链存在平稳概率分布, 当且仅当其为正常返链。因此该链正常返。

由 Kac 公式, $\mathbb{E}_0 \tau_0^+ = \frac{1}{\pi_0}$. 所以 $\mathbb{E}_0 \tau_0^+ = \zeta(2) = \frac{\pi^2}{6}$.

- (3) 该链不可约、非周期且正常返。由可数状态 Markov 链的遍历收敛定理, 对任意 $i, j \in \mathcal{S}$, $P^n(i, j) \rightarrow \pi_j$.

因此 $\lim_{n \rightarrow \infty} \mathbb{P}_i(X_n = j) = \frac{1}{\zeta(2)(j+1)^2}$.

Problem 7 (10 分)

设 $X_1, \dots, X_n$ 为来自下列分布的独立同分布样本: $f_\theta(x) = \frac{2x}{\theta^2} \mathbf{1}_{\{0 < x \leq \theta\}}$, $\theta > 0$. 记 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, $M_n = X_{(n)} = \max_{1 \leq i \leq n} X_i$.

- 求 θ 的矩估计量和最大似然估计量。
- 分别求 $\sqrt{n}(\frac{3}{2}\bar{X}_n - \theta)$ 和 $n(\theta - M_n)$ 的极限分布, 并明确说明二者的收敛速度为何不同。
- 对固定 $0 < p < 1$, 定义经验分布函数 F_n 及样本 p 分位数 $\hat{\xi}_{p,n} = \inf\{x : F_n(x) \geq p\}$. 令 $\hat{\theta}_{p,n} = \frac{\hat{\xi}_{p,n}}{\sqrt{p}}$. 求 $\hat{\theta}_{p,n}$ 的渐近分布, 并确定哪些 p 使 $\hat{\theta}_{p,n}$ 的渐近方差严格小于矩估计量的渐近方差。特别写出 $p = 1/2$ 时由样本中位数得到的估计量之渐近方差。

第 7 题解答

该分布的分布函数为 $F_\theta(x) = \begin{cases} 0, & x \leq 0, \\ \frac{x^2}{\theta^2}, & 0 < x \leq \theta, \\ 1, & x > \theta. \end{cases}$

首先计算矩: $\mathbb{E}_\theta X = \int_0^\theta x \frac{2x}{\theta^2} dx = \frac{2\theta}{3}$, 以及 $\mathbb{E}_\theta X^2 = \int_0^\theta x^2 \frac{2x}{\theta^2} dx = \frac{\theta^2}{2}$. 所以 $\text{Var}_\theta(X) = \frac{\theta^2}{2} - \frac{4\theta^2}{9} = \frac{\theta^2}{18}$.

- (1) 由矩方程 $\bar{X}_n = \frac{2\theta}{3}$, 矩估计量为 $\tilde{\theta}_{\text{MOM}} = \frac{3}{2}\bar{X}_n$.

似然函数为 $L(\theta) = \frac{2^n \prod_{i=1}^n X_i}{\theta^{2n}} \mathbf{1}_{\{\theta \geq M_n\}}$. 在可行区间 $\theta \geq M_n$ 上, θ^{-2n} 严格递减, 所以 $\hat{\theta}_{\text{MLE}} = M_n = X_{(n)}$.

- (2) 由中心极限定理, $\sqrt{n}(\bar{X}_n - \frac{2\theta}{3}) \xrightarrow{d} N(0, \frac{\theta^2}{18})$. 因此 $\sqrt{n}(\frac{3}{2}\bar{X}_n - \theta) \xrightarrow{d} N(0, \frac{\theta^2}{8})$.

下面考虑最大值。对任意 $y \geq 0$, 当 n 充分大时,

$$\mathbb{P}_\theta(n(\theta - M_n) > y) = \mathbb{P}_\theta(M_n < \theta - \frac{y}{n}) = \left[F_\theta\left(\theta - \frac{y}{n}\right)\right]^n = \left(1 - \frac{y}{n\theta}\right)^{2n} \rightarrow e^{-2y/\theta}.$$

故 $n(\theta - M_n) \xrightarrow{d} \text{Exp}\left(\text{rate } \frac{2}{\theta}\right)$.

矩估计量是样本均值的光滑函数, 其随机误差由普通中心极限定理控制, 故收敛速度为 $\sqrt{n}$.

最大似然估计量是样本上端点的次序统计量。其误差只有在所有样本均未落入长度约为 $1/n$ 的端点邻域时才显著, 故误差为 $O_p(n^{-1})$, 收敛速度为 n , 极限也不是正态分布。

- (3) 总体 p 分位数满足 $F_\theta(\xi_p) = p$, 所以 $\xi_p = \theta\sqrt{p}$. 在该点, $f_\theta(\xi_p) = \frac{2\xi_p}{\theta^2} = \frac{2\sqrt{p}}{\theta}$.

由样本分位数渐近正态性, $\sqrt{n}(\hat{\xi}_{p,n} - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{f_\theta(\xi_p)^2}\right)$. 代入密度得 $\sqrt{n}(\hat{\xi}_{p,n} - \theta\sqrt{p}) \xrightarrow{d} N\left(0, \frac{\theta^2(1-p)}{4}\right)$.

由于 $\hat{\theta}_{p,n} = \frac{\hat{\xi}_{p,n}}{\sqrt{p}}$, 所以 $\sqrt{n}(\hat{\theta}_{p,n} - \theta) \xrightarrow{d} N\left(0, \frac{\theta^2(1-p)}{4p}\right)$.

矩估计量的渐近方差为 $\frac{\theta^2}{8}$. 故分位数估计量的渐近方差严格更小时, $\frac{\theta^2(1-p)}{4p} < \frac{\theta^2}{8}$. 约去 θ^2 后, $2(1-p) < p$,

$$\text{即 } p > \frac{2}{3}.$$

当 $p = 1/2$ 时, $\hat{\theta}_{1/2,n} = \sqrt{2}\hat{\xi}_{1/2,n}$, 且 $\sqrt{n}(\hat{\theta}_{1/2,n} - \theta) \xrightarrow{d} N\left(0, \frac{\theta^2}{4}\right)$.

Problem 8 (15 分)

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$, $n \geq 4$. 记 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 并定义 $T = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$.

(1) 证明 T 是参数 (μ, σ^2) 的极小充分统计量, 并判断 T 是否完全; 你的结论必须附有完整论证.

(2) 定义 $A = \begin{cases} \frac{X_1 - \bar{X}}{S}, & S > 0, \\ 0, & S = 0. \end{cases}$ 证明 A 是辅助统计量, 并证明 A 与 T 相互独立.

(3) 求参数函数 $\eta(\mu, \sigma^2) = \frac{\mu^2}{\sigma^2}$ 的一致最小方差无偏估计量. 最终答案须写成 $\bar{X}$ 与 S^2 的显式函数, 并验证其无偏性所需的矩存在条件.

第 8 题解答

(1) 联合密度为 $f_{\mu, \sigma^2}(\mathbf{x}) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{\sum_i x_i^2 - 2\mu \sum_i x_i + n\mu^2}{2\sigma^2}\right\}$.

由因子分解定理, $T = (\sum_i X_i, \sum_i X_i^2)$ 是充分统计量.

下面证明极小充分性. 取两个样本点 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 令 $\Delta_1 = \sum_i x_i - \sum_i y_i$, $\Delta_2 = \sum_i x_i^2 - \sum_i y_i^2$. 则 $\log \frac{f_{\mu, \sigma^2}(\mathbf{x})}{f_{\mu, \sigma^2}(\mathbf{y})} = -\frac{\Delta_2 - 2\mu\Delta_1}{2\sigma^2}$. 该比值与 (μ, σ^2) 无关, 当且仅当 $\Delta_1 = 0$, $\Delta_2 = 0$. 这等价于 $T(\mathbf{x}) = T(\mathbf{y})$.

由极小充分统计量的似然比判别法, T 是极小充分统计量.

下面判断完全性. 令 $\eta_1 = \frac{\mu}{\sigma^2}$, $\eta_2 = -\frac{1}{2\sigma^2}$. 自然参数空间为 $\mathcal{H} = \mathbb{R} \times (-\infty, 0)$, 它是 $\mathbb{R}^2$ 中的非空开集.

联合密度可写为 $f_{\eta}(\mathbf{x}) = h(\mathbf{x}) \exp\{\eta_1 \sum_i x_i + \eta_2 \sum_i x_i^2 - A(\eta)\}$. 故这是满秩二参数指数族.

为完整说明完全性, 设可测函数 g 满足 $\mathbb{E}_{\eta}|g(T)| < \infty$ 且 $\mathbb{E}_{\eta}g(T) = 0$ 对所有 $\eta \in \mathcal{H}$. 固定 $\eta_0 \in \mathcal{H}$,

定义有限符号测度 $\nu(C) = \mathbb{E}_{\eta_0}[g(T)\mathbf{1}_{\{T \in C\}}]$. 若 h 足够小使 $\eta_0 + h \in \mathcal{H}$, 则指数族的换测度关系给出

$\int_{\mathbb{R}^2} e^{h^\top t} \nu(dt) = e^{A(\eta_0+h)-A(\eta_0)} \mathbb{E}_{\eta_0+h}g(T) = 0$. 因此 ν 的多元 Laplace 变换在点邻域恒为零. 由 Laplace

变换唯一性, $\nu = 0$. 故 $g(T) = 0$ P_{η_0} -a.s. 由于不同参数下的正态联合密度在 $\mathbb{R}^n$ 上均严格为正, 各概率测度相互等价, 所以上述结论对所有参数成立.

因此 T 是完全统计量. 综上, T 是完全且极小充分统计量.

(2) 写成标准正态变量 $X_i = \mu + \sigma Z_i$, $Z_i \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$. 令 $\bar{Z} = \frac{1}{n} \sum_i Z_i$, $S_Z^2 = \frac{1}{n-1} \sum_i (Z_i - \bar{Z})^2$. 则 $\bar{X} = \mu + \sigma \bar{Z}$, $S = \sigma S_Z$. 由于 $\sigma > 0$, $A = \frac{X_1 - \bar{X}}{S} = \frac{Z_1 - \bar{Z}}{S_Z}$ a.s. 右侧的分布与 μ, σ^2 均无关. 因此 A 是辅助统计量.

上一问已经证明 T 是完全充分统计量. 由 Basu 定理, $A \perp\!\!\!\perp T$.

(3) 记 $\nu = n-1$, $V = \frac{(n-1)S^2}{\sigma^2}$. 则 $V \sim \chi_{\nu}^2$, $\bar{X} \perp\!\!\!\perp S^2$. 并且 $\mathbb{E}\bar{X}^2 = \mu^2 + \frac{\sigma^2}{n}$.

当 $\nu > 2$, 即 $n \geq 4$ 时, $\mathbb{E}(V^{-1}) = \frac{1}{\nu-2} = \frac{1}{n-3}$. 因此 $\mathbb{E}\left(\frac{1}{S^2}\right) = \frac{n-1}{\sigma^2(n-3)}$. 由独立性,

$$\mathbb{E}\left(\frac{\bar{X}^2}{S^2}\right) = \mathbb{E}(\bar{X}^2)\mathbb{E}\left(\frac{1}{S^2}\right) = \left(\mu^2 + \frac{\sigma^2}{n}\right) \frac{n-1}{\sigma^2(n-3)} = \frac{n-1}{n-3} \left(\frac{\mu^2}{\sigma^2} + \frac{1}{n}\right).$$

故 $\delta_n = \frac{n-3}{n-1} \frac{\bar{X}^2}{S^2} - \frac{1}{n}$ 满足 $\mathbb{E}_{\mu, \sigma^2} \delta_n = \frac{\mu^2}{\sigma^2}$. 无偏性只需要 $\mathbb{E}(S^{-2}) < \infty$, 即 $n \geq 4$.

由于 δ_n 是完全充分统计量 $(\bar{X}, S^2)$ 的函数, 若其方差有限, 则由 Lehmann-Scheffé 定理, 它是唯一 UMVUE.

下面检查二阶矩. 对 $V \sim \chi_\nu^2$, 有 $\mathbb{E}(V^{-2}) = \frac{1}{(\nu-2)(\nu-4)}$ 当且仅当 $\nu > 4$. 因此 $\mathbb{E}(S^{-4}) < \infty \iff n-1 > 4 \iff n \geq 6$. 又因为 $\bar{X}$ 的四阶矩有限且 $\bar{X} \perp\!\!\!\perp S^2$, 所以 $\mathbb{E}\delta_n^2 < \infty \iff n \geq 6$.

因此, 在通常要求有限方差的 UMVUE 定义下, $n \geq 6$ 时, $\delta_n = \frac{n-3}{n-1} \frac{\bar{X}^2}{S^2} - \frac{1}{n}$ 是唯一 UMVUE.

对于 $n = 4, 5$, 上述 δ_n 仍是可积的无偏估计量, 但其二阶矩无穷.

事实上, 此时不存在任何有限方差无偏估计量. 否则若 W 是有限方差无偏估计量, 则 $W^* = \mathbb{E}(W | T)$ 仍无偏且具有有限方差. 完全性迫使 $W^* = \delta_n$ a.s. 这与 $\mathbb{E}\delta_n^2 = \infty$ 矛盾.

所以 $n = 4, 5$ 时, 在标准有限方差定义下不存在 UMVUE.

Problem 9 (10 分)

设 $X_1, \dots, X_n$ 为来自 $\text{Beta}(\theta, 1)$ 分布的独立同分布样本, 其密度为 $f_\theta(x) = \theta x^{\theta-1} \mathbf{1}_{\{0 < x < 1\}}$, $\theta > 0$. 固定 $\theta_0 > 0$ 与 $0 < \alpha < 1$, 并令 $T = -\sum_{i=1}^n \log X_i$.

- (1) 对检验问题 $H_0: \theta \leq \theta_0$ 对 $H_1: \theta > \theta_0$, 求一个 size 为 α 的一致最大功效检验. 拒绝域必须用 χ^2 分布分位数显式表示. 进一步写出该检验在任意 $\theta > 0$ 下的功效函数, 并验证其 size 的确等于 α .
- (2) 通过反演上述检验, 构造 θ 的精确 $1 - \alpha$ 单侧下置信界, 并严格验证其覆盖概率.

第 9 题解答

令 $Y_i = -\log X_i$. 由 $X_i = e^{-Y_i}$, $\left| \frac{dx}{dy} \right| = e^{-y}$, 可得 $f_{Y_i}(y) = \theta e^{-(\theta-1)y} e^{-y} = \theta e^{-\theta y} \mathbf{1}_{\{y > 0\}}$. 因此 $Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\text{rate } \theta)$, 并且 $T = \sum_{i=1}^n Y_i \sim \text{Gamma}(n, \text{rate } \theta)$. 特别地, $2\theta T \sim \chi_{2n}^2$.

- (1) T 的密度为 $g_\theta(t) = \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-\theta t} \mathbf{1}_{\{t > 0\}}$. 若 $\theta_2 > \theta_1$, 则 $\frac{g_{\theta_2}(t)}{g_{\theta_1}(t)} = \left(\frac{\theta_2}{\theta_1}\right)^n e^{-(\theta_2-\theta_1)t}$, 它关于 t 严格递减. 因此较大的 θ 倾向于产生较小的 T , 检验应在 T 的下尾拒绝.

令 $c_\alpha = \chi_{2n, \alpha}^2$. 定义检验 $\phi(X) = \mathbf{1}_{\{2\theta_0 T \leq c_\alpha\}}$. 在 $\theta = \theta_0$ 下, $\mathbb{P}_{\theta_0}(2\theta_0 T \leq c_\alpha) = \alpha$.

对任意 $\theta > 0$, 功效函数为 $\beta(\theta) = \mathbb{P}_\theta(2\theta_0 T \leq c_\alpha) = \mathbb{P}_\theta\left(2\theta T \leq \frac{\theta}{\theta_0} c_\alpha\right) = F_{\chi_{2n}^2}\left(\frac{\theta}{\theta_0} \chi_{2n, \alpha}^2\right)$. 该函数关于 θ 单调增加.

因此在原假设 $\theta \leq \theta_0$ 上, $\sup_{\theta \leq \theta_0} \beta(\theta) = \beta(\theta_0) = \alpha$. 所以检验的 size 恰为 α .

由于模型关于 $-T$ 具有单调似然比, 由 Karlin-Rubin 定理, 上述检验是 level α 的 UMP 检验. 即

$$\text{拒绝域为 } 2\theta_0 \left(-\sum_{i=1}^n \log X_i \right) \leq \chi_{2n, \alpha}^2.$$

- (2) 对每个候选值 θ_0 , 接受原假设的条件为 $2\theta_0 T > \chi_{2n, \alpha}^2$. 给定观测值 $T = t > 0$, 未被拒绝的候选参数集合为 $\left\{ \theta_0 : \theta_0 > \frac{\chi_{2n, \alpha}^2}{2t} \right\}$. 因此可取下置信界 $L(X) = \frac{\chi_{2n, \alpha}^2}{2T} = \frac{\chi_{2n, \alpha}^2}{-2 \sum_{i=1}^n \log X_i}$. 相应的单侧置信区间为 $[L(X), \infty)$.

验证覆盖概率: $\mathbb{P}_\theta\{L(X) \leq \theta\} = \mathbb{P}_\theta\left\{\frac{\chi_{2n,\alpha}^2}{2T} \leq \theta\right\} = \mathbb{P}_\theta\{2\theta T \geq \chi_{2n,\alpha}^2\} = 1 - \alpha$, 因为 $2\theta T \sim \chi_{2n}^2$ 且卡方分布连续。因此 $[L(X), \infty)$ 是精确 $1 - \alpha$ 单侧置信区间。

Problem 10 (15 分)

设 $X_1, \dots, X_n$ 独立同分布, 且每个 X_i 服从负二项分布 $\mathbb{P}_p(X_i = x) = \binom{r+x-1}{x} p^r (1-p)^x$, $x = 0, 1, 2, \dots$, 其中 $r \in \mathbb{N}$ 已知, $0 < p < 1$ 未知。这里 X_i 表示第 r 次成功之前出现的失败次数。记 $S = \sum_{i=1}^n X_i$, $\bar{X} = \frac{S}{n}$, 并以 $\mu = \frac{r(1-p)}{p}$ 重新参数化模型。另令 $\psi = \log(r + \mu)$ 。

- (1) 求 μ 的最大似然估计量, 并完整讨论该估计量是否对每一个可能样本都存在。无论内部最大值是否存在, 定义闭包上的估计量 $\tilde{\mu} = \bar{X}$. 证明 $\tilde{\mu}$ 对 μ 相合。求单个观测关于 ψ 的 Fisher 信息, 并求 $\hat{\psi} = \log(r + \bar{X})$ 的渐近分布。
- (2) 假设先验分布为 $p \sim \text{Beta}(a, b)$, $a > 0$, $b > 0$. 求 p 的后验分布。以平方误差损失估计 $\mu = \frac{r(1-p)}{p}$, 求其 Bayes 估计量, 并完整说明后验均值存在以及平方后验风险有限分别需要满足的条件。当平方后验风险对每个有限动作均为无穷时, 也须明确说明。
- (3) 考虑 $H_0: \mu = \mu_0$ 对 $H_1: \mu \neq \mu_0$, $\mu_0 > 0$. 推导广义似然比统计量及 $-2 \log \Lambda_n$ 的显式表达式。约定 $0 \log 0 = 0$, 并使表达式覆盖 $S = 0$ 的情形。给出渐近 level 为 α 的拒绝域, 并写出由该检验反演得到的 $1 - \alpha$ 渐近似然比置信集。

第 10 题解答

由 $\mu = \frac{r(1-p)}{p}$ 可解得 $p = \frac{r}{r+\mu}$, $1-p = \frac{\mu}{r+\mu}$, $\mu > 0$ 。

样本似然中与 μ 有关的部分为 $L(\mu) \propto \left(\frac{r}{r+\mu}\right)^{nr} \left(\frac{\mu}{r+\mu}\right)^S = r^{nr} \frac{\mu^S}{(r+\mu)^{nr+S}}$ 。

- (1) 对数似然为 $\ell(\mu) = C + S \log \mu - (nr + S) \log(r + \mu)$. 当 $S > 0$ 时, $\ell'(\mu) = \frac{S}{\mu} - \frac{nr + S}{r + \mu} = \frac{r(S - n\mu)}{\mu(r + \mu)}$. 因此

$$\ell'(\mu) > 0 \iff \mu < \frac{S}{n}, \text{ 而 } \ell'(\mu) < 0 \iff \mu > \frac{S}{n}. \text{ 故唯一内部最大点为 } \hat{\mu}_{\text{MLE}} = \frac{S}{n} = \bar{X}, \quad S > 0.$$

若 $S = 0$, 则 $\ell(\mu) = C - nr \log(r + \mu)$, 它在 $\mu > 0$ 上严格递减, 且上确界仅在 $\mu \downarrow 0$ 时达到。因此:

$S = 0$ 时, 参数空间 $(0, \infty)$ 内不存在 MLE.

若把参数空间扩充为闭包 $[0, \infty)$, 则闭包上的 MLE 为 $\tilde{\mu} = 0$. 统一地, $\tilde{\mu} = \bar{X}$ 是闭包上的最大似然估计量。

负二项分布的均值为 $\mathbb{E}_\mu X_i = \frac{r(1-p)}{p} = \mu$. 由强大数律, $\bar{X} \xrightarrow{\text{a.s.}} \mu$. 因此 $\tilde{\mu} = \bar{X}$ 强相合, 从而弱相合。

下面计算关于 $\psi = \log(r + \mu)$ 的 Fisher 信息。

单个观测关于 μ 的 score 为 $U_\mu(X) = \frac{X}{\mu} - \frac{r+X}{r+\mu} = \frac{r(X-\mu)}{\mu(r+\mu)}$. 由于 $\frac{d\mu}{d\psi} = r + \mu$, 关于 ψ 的 score 为

$$U_\psi(X) = U_\mu(X) \frac{d\mu}{d\psi} = \frac{r(X-\mu)}{\mu}.$$

负二项分布的方差为 $\text{Var}(X) = \frac{r(1-p)}{p^2} = \frac{\mu(r+\mu)}{r}$. 因此单个观测的 Fisher 信息为

$$I_1(\psi) = \mathbb{E} U_\psi(X)^2 = \frac{r^2}{\mu^2} \text{Var}(X) = \frac{r(r+\mu)}{\mu}.$$

等价地, $I_1(\psi) = \frac{r e^\psi}{e^\psi - r}$.

由中心极限定理, $\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N\left(0, \frac{\mu(r+\mu)}{r}\right)$. 令 $g(x) = \log(r+x)$, $g'(\mu) = \frac{1}{r+\mu}$. 由 Delta 方法,

$$\sqrt{n}(\hat{\psi} - \psi) \xrightarrow{d} N\left(0, \frac{\mu}{r(r+\mu)}\right). \text{ 该渐近方差正好等于 } I_1(\psi)^{-1}.$$

- (2) 先验为 $p \sim \text{Beta}(a, b)$. 似然关于 p 的核为 $p^{nr}(1-p)^S$. 因此后验核为 $p^{a+nr-1}(1-p)^{b+S-1}$. 令 $A = a + nr$, $B = b + S$. 则 $p | X \sim \text{Beta}(A, B)$.

目标参数为 $\mu = r \frac{1-p}{p} = r \left(\frac{1}{p} - 1\right)$. 在平方损失下, 若后验二阶矩有限, Bayes 估计量为后验均值.

对于 $p \sim \text{Beta}(A, B)$, 当 $A > 1$ 时, $\mathbb{E}(p^{-1} | X) = \frac{A+B-1}{A-1}$. 故 $\mathbb{E}(\mu | X) = r \left[\frac{A+B-1}{A-1} - 1 \right] = r \frac{B}{A-1}$.

所以形式上的后验均值为 $\delta_B(X) = \frac{r(b+S)}{a+nr-1}$.

后验均值存在的充要条件是 $A = a + nr > 1$. 在本题中 $a > 0$, $n, r \geq 1$, 所以 $A > 1$ 自动成立.

平方后验风险有限需要 $\mathbb{E}(\mu^2 | X) < \infty$. 当 $p \downarrow 0$ 时, $\mu^2 = r^2 \left(\frac{1-p}{p}\right)^2 \asymp r^2 p^{-2}$, 而 Beta 后验密度在零附近为 p^{A-1} . 故积分在零附近形如 $\int_0^\varepsilon p^{A-3} dp$, 其有限的充要条件为 $A > 2$.

当 $A > 2$ 时, $\mathbb{E}(p^{-2} | X) = \frac{(A+B-1)(A+B-2)}{(A-1)(A-2)}$, 并且 $\text{Var}(\mu | X) = \frac{r^2 B(A+B-1)}{(A-1)^2(A-2)}$. 因此当 $a + nr > 2$

时, 上述 δ_B 是平方损失下唯一的 Bayes 估计量.

若 $1 < A \leq 2$, 则后验均值有限, 但 $\mathbb{E}(\mu^2 | X) = \infty$. 对任意有限动作 d , $\mathbb{E}[(\mu - d)^2 | X] = \infty$, 所以所有有限动作的平方后验风险均为无穷. 此时后验均值虽然作为一阶矩存在, 但不能称为具有有限平方后验风险的 Bayes 动作.

若 $A \leq 1$, 则后验均值本身也不存在; 但本题给定的参数条件下该情形不会发生.

- (3) 记 $\hat{\mu} = \bar{X}$ 为闭包上的非受限最大点.

当 $S > 0$ 时, $\Lambda_n = \frac{L(\mu_0)}{L(\hat{\mu})} = \left(\frac{\mu_0}{\bar{X}}\right)^S \left(\frac{r + \bar{X}}{r + \mu_0}\right)^{nr+S}$. 当 $S = 0$ 时, 非受限似然的上确界在 $\mu \downarrow 0$ 时达

到, 故 $\Lambda_n = \left(\frac{r}{r+\mu_0}\right)^{nr}$. 因此

$$\Lambda_n = \begin{cases} \left(\frac{\mu_0}{\bar{X}}\right)^S \left(\frac{r + \bar{X}}{r + \mu_0}\right)^{nr+S}, & S > 0, \\ \left(\frac{r}{r + \mu_0}\right)^{nr}, & S = 0. \end{cases}$$

对所有 $S \geq 0$, 约定 $0 \log 0 = 0$, 则离差统计量可统一写成

$$-2 \log \Lambda_n = 2 [\ell(\bar{X}) - \ell(\mu_0)] = 2n \left[\bar{X} \log \frac{\bar{X}}{\mu_0} + (r + \bar{X}) \log \frac{r + \mu_0}{r + \bar{X}} \right].$$

所以 $D_n := -2 \log \Lambda_n = 2n \left[\bar{X} \log \frac{\bar{X}}{\mu_0} + (r + \bar{X}) \log \frac{r + \mu_0}{r + \bar{X}} \right]$.

当真实参数 $\mu_0 > 0$ 时, 参数位于内部, 模型正则. 由 Wilks 定理, $D_n \xrightarrow{d} \chi_1^2$ 在 H_0 下. 因此渐近 level α 的拒绝域为 $D_n > \chi_{1,1-\alpha}^2$.

反演对每个候选 $\mu > 0$ 的似然比检验, 得到 $C_{1-\alpha}^{\text{LR}}(X) = \left\{ \mu > 0 : 2n \left[\bar{X} \log \frac{\bar{X}}{\mu} + (r + \bar{X}) \log \frac{r + \mu}{r + \bar{X}} \right] \leq \chi_{1,1-\alpha}^2 \right\}$.

该集合是 μ 的渐近 $1 - \alpha$ 似然比置信集. 当 $\bar{X} = 0$ 时, 第一项按 $0 \log 0 = 0$ 解释.

Problem 11 (10 分)

设两组样本相互独立: $X_1, \dots, X_m \stackrel{\text{i.i.d.}}{\sim} N(\mu_X, \sigma_X^2)$, $Y_1, \dots, Y_n \stackrel{\text{i.i.d.}}{\sim} N(\mu_Y, \sigma_Y^2)$, 其中 $m, n \geq 2$. 记 $\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i$, $\bar{Y} = \frac{1}{n} \sum_{j=1}^n Y_j$, $S_X^2 = \frac{1}{m-1} \sum_{i=1}^m (X_i - \bar{X})^2$, $S_Y^2 = \frac{1}{n-1} \sum_{j=1}^n (Y_j - \bar{Y})^2$.

- (1) 在限制 $\sigma_X^2 = \sigma_Y^2 = \sigma^2$ 下, 构造 $\mu_X - \mu_Y$ 的精确 $1 - \alpha$ 置信区间, 并写出检验 $H_0: \mu_X - \mu_Y = \delta_0$ 对 $H_1: \mu_X - \mu_Y \neq \delta_0$ 的精确 level α 拒绝域。
- (2) 不再假定两总体方差相等. 构造 $\rho = \frac{\sigma_X^2}{\sigma_Y^2}$ 的精确 $1 - \alpha$ 置信区间, 并写出检验 $H_0: \rho = \rho_0$ 对 $H_1: \rho \neq \rho_0$ 的精确 level α 拒绝域。
- (3) 重新假设 $\sigma_X^2 = \sigma_Y^2$. 判断第 (a) 问中使用的 Student t 统计量与随机变量 $\frac{S_X^2}{S_Y^2}$ 是否独立, 并给出完整证明。

第 11 题解答

记 $\nu_1 = m - 1$, $\nu_2 = n - 1$.

- (1) 假设 $\sigma_X^2 = \sigma_Y^2 = \sigma^2$. 定义合并样本方差 $S_p^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}$. 则 $\frac{(m+n-2)S_p^2}{\sigma^2} \sim \chi_{m+n-2}^2$. 同时 $\bar{X} - \bar{Y} \sim N(\mu_X - \mu_Y, \sigma^2(\frac{1}{m} + \frac{1}{n}))$, 并且 $\bar{X} - \bar{Y} \perp S_p^2$. 因此 $T = \frac{(\bar{X} - \bar{Y}) - (\mu_X - \mu_Y)}{S_p \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t_{m+n-2}$.

所以 $\mu_X - \mu_Y$ 的精确 $1 - \alpha$ 置信区间为

$$\left[\bar{X} - \bar{Y} - t_{m+n-2, 1-\alpha/2} S_p \sqrt{\frac{1}{m} + \frac{1}{n}}, \bar{X} - \bar{Y} + t_{m+n-2, 1-\alpha/2} S_p \sqrt{\frac{1}{m} + \frac{1}{n}} \right].$$

检验 $H_0: \mu_X - \mu_Y = \delta_0$ 时, 定义 $T_0 = \frac{\bar{X} - \bar{Y} - \delta_0}{S_p \sqrt{\frac{1}{m} + \frac{1}{n}}}$. 在 H_0 下, $T_0 \sim t_{m+n-2}$. 故精确 level α 拒绝域为

$$|T_0| > t_{m+n-2, 1-\alpha/2}.$$

- (2) 不要求两总体方差相等. 由正态样本方差的分布, $U = \frac{(m-1)S_X^2}{\sigma_X^2} \sim \chi_{m-1}^2$, $V = \frac{(n-1)S_Y^2}{\sigma_Y^2} \sim \chi_{n-1}^2$, 且 $U \perp V$. 因此 $\frac{U/(m-1)}{V/(n-1)} = \frac{S_X^2/S_Y^2}{\sigma_X^2/\sigma_Y^2} = \frac{S_X^2/S_Y^2}{\rho} \sim F_{m-1, n-1}$. 于是 $\mathbb{P}\left\{F_{m-1, n-1, \alpha/2} \leq \frac{S_X^2/S_Y^2}{\rho} \leq F_{m-1, n-1, 1-\alpha/2}\right\} = 1 - \alpha$.

反演不等式可得 $\rho \in \left[\frac{S_X^2/S_Y^2}{F_{m-1, n-1, 1-\alpha/2}}, \frac{S_X^2/S_Y^2}{F_{m-1, n-1, \alpha/2}} \right].$

检验 $H_0: \rho = \rho_0$ 时, 令 $F_0 = \frac{S_X^2/S_Y^2}{\rho_0}$. 在 H_0 下, $F_0 \sim F_{m-1, n-1}$. 故精确 level α 的双侧拒绝域为

$$F_0 < F_{m-1, n-1, \alpha/2} \text{ 或 } F_0 > F_{m-1, n-1, 1-\alpha/2}.$$

- (3) 重新假设 $\sigma_X^2 = \sigma_Y^2 = \sigma^2$. 令 $U = \frac{(m-1)S_X^2}{\sigma^2} \sim \chi_{\nu_1}^2$, $V = \frac{(n-1)S_Y^2}{\sigma^2} \sim \chi_{\nu_2}^2$, 其中 $\nu_1 = m-1$, $\nu_2 = n-1$. U 与 V 独立。

作变换 $W = U + V$, $R = \frac{U}{U+V}$. 其逆变换为 $U = WR$, $V = W(1-R)$, Jacobian 的绝对值为 $\left| \frac{\partial(U, V)}{\partial(W, R)} \right| = W$.

U, V 的联合密度为 $f_{U, V}(u, v) = \frac{u^{\nu_1/2-1} v^{\nu_2/2-1} e^{-(u+v)/2}}{2^{(\nu_1+\nu_2)/2} \Gamma(\nu_1/2) \Gamma(\nu_2/2)}$, $u, v > 0$. 代入变换得

$$f_{W, R}(w, r) = \frac{w^{(\nu_1+\nu_2)/2-1} e^{-w/2}}{2^{(\nu_1+\nu_2)/2} \Gamma((\nu_1+\nu_2)/2)} \times \frac{\Gamma((\nu_1+\nu_2)/2)}{\Gamma(\nu_1/2) \Gamma(\nu_2/2)} r^{\nu_1/2-1} (1-r)^{\nu_2/2-1},$$

其中 $w > 0$, $0 < r < 1$. 该联合密度分解为 w 的密度与 r 的密度之积, 所以 $W \perp R$.

又有 $S_p^2 = \frac{\sigma^2(U+V)}{\nu_1+\nu_2} = \frac{\sigma^2 W}{\nu_1+\nu_2}$, 而 $\frac{S_X^2}{S_Y^2} = \frac{U/\nu_1}{V/\nu_2} = \frac{\nu_2}{\nu_1} \frac{R}{1-R}$. 因此 S_p^2 是 W 的函数, 而 S_X^2/S_Y^2 是 R 的函数。

再令 $Z_{\delta_0} = \frac{\bar{X} - \bar{Y} - \delta_0}{\sigma \sqrt{\frac{1}{m} + \frac{1}{n}}}$. 正态样本中样本均值与样本方差独立, 并且两组样本相互独立, 所以 $Z_{\delta_0} \perp (U, V)$,

从而 $Z_{\delta_0} \perp\!\!\!\perp (W, R)$.

第 (a) 问中的 Student 统计量可写为 $T_0 = \frac{Z_{\delta_0}}{\sqrt{W/(\nu_1 + \nu_2)}}$. 因此 T_0 是 (Z_{δ_0}, W) 的函数, 而 S_X^2/S_Y^2 是 R 的函数。

由于 $(Z_{\delta_0}, W) \perp\!\!\!\perp R$, 所以 $T_0 \perp\!\!\!\perp \frac{S_X^2}{S_Y^2}$.

该独立性不仅在 H_0 下成立; 只要两总体方差相等, 它对任意 μ_X, μ_Y, δ_0 都成立。

